

利用低成本硬件学习精细双手操作

Tony Z. Zhao¹ Vikash Kumar³ Sergey Levine² Chelsea Finn¹
¹ Stanford University ² UC Berkeley ³ Meta




图 1: ALOHA: 一种用于双手遥操作的低成本开源硬件系统。整个系统采用现成机器人和三维打印组件，成本低于两万美元。左图：用户通过反向驱动主机机器人进行遥操作，从机器人镜像其运动。右图：ALOHA 能够执行精确、接触密集和动态的任务。我们展示了遥操作和自主学习技能的示例。

摘要——精细操作任务，如穿线扎带或安装电池，对机器人而言极为困难，因其要求高精度、接触力的精细协调以及闭环视觉反馈。执行此类任务通常需要高端机器人、精确传感器或细致校准，这些设备成本高昂且设置复杂。学习能否使低成本且精度有限的硬件完成这些精细操作任务？本文提出一种低成本系统，通过定制遥操作接口采集的真实演示，直接进行端到端模仿学习。然而，模仿学习本身面临挑战，尤其是在高精度领域：策略误差会随时间累积，且人类演示可能非平稳。为应对这些挑战，本文开发了一种简单而新颖的算法——基于变换器的动作分块（Action Chunking with Transformers, ACT），该算法学习动作序列上的生成模型。ACT 使机器人能够在现实世界中学习 6 项困难任务，例如打开半透明调料杯和安装电池，成功率可达 80-90%，且仅需 10 分钟的演示数据。项目网站：tonyzhaozh.github.io/aloha

排除在外。接下来，右侧的一根手指从下方接近杯子并撬开盖子。这些步骤中的每一步都需要高精度、精细的手眼协调和丰富的接触。毫米级的误差就会导致任务失败。现有的精细操作系统使用昂贵的机器人和高端传感器进行精确的状态估计 [29, 60, 32, 41]。在这项工作中，我们试图开发一种低成本的精细操作系统，与之相反，该系统易于获取且可复现。然而，低成本硬件不可避免地不如高端平台精确，这使得感知和规划的挑战更加突出。解决这一问题的一个有前景的方向是将学习融入系统中。人类同样不具备工业级的本体感觉 [71]，但我们能够通过从闭环视觉反馈中学习并主动补偿误差来执行精细任务。因此，在我们的系统中，我们训练了一个端到端策略，直接将来自普通网络摄像头的 RGB 图像映射为动作。这种像素到动作的表述特别适合精细操作，因为精细操作通常涉及具有复杂物理特性的物体，因此学习操作策略比建模整个环境要简单得多。以调味品杯为例：在轻推杯子时对接触进行建模，以及在撬开盖子时对变形进行建模，涉及大量自由度上的复杂物理过程。设计一个足够精确以用于规划模型将需要大量的研究和任务特定的工程工作。相比之下，轻推和打开杯子的策略要简单得多，因为闭环策略可以对杯子和盖子的不同位置做出反应，而不是精确地预测其将如何提前移动。

一、引言

精细操作任务涉及精确的闭环反馈，需要高度的手眼协调能力，以便根据环境变化进行调整和重新规划。此类操作任务的示例包括打开调味品杯盖或安装电池，这些任务涉及捏取、撬动和撕扯等精细操作，而非抓取和放置等大幅度动作。以图 1 中打开调味品杯盖为例，杯子初始直立放置在桌面上：右夹爪需要先将其推倒，并轻推入已张开的左夹爪中。随后左夹爪轻轻闭合并提起杯子。

然而，训练端到端策略本身也面临挑战。策略的性能在很大程度上取决于训练数据的分布，而在精细操作的情况下，高质量的人类演示可以通过让系统从人类灵巧性中学习来提供巨大的价值。因此，我们构建了一个低成本但灵巧的遥操作系统用于数据收集，并提出了一种新颖的模仿学习算法，能够有效地从演示中学习。我们在接下来的两段中概述每个组件。

遥操作系统。我们设计了一套遥操作装置，包含两组低成本、现成的机械臂。它们大致互为缩放版本，我们采用关节空间映射进行遥操作。我们通过三维打印组件增强该装置，使其更易于反向驱动，从而在 2 万美元预算内构建出高性能的遥操作系统。我们在图 1 中展示了其能力，包括精细任务的遥操作（如穿扎带）、动态任务（如颠乒乓球）以及接触密集型任务（如组装 NIST 板 2 号中的链条 [4]）。



模仿学习算法。需要精确性和视觉反馈的任务对模仿学习而言构成重大挑战，即便使用高质量示范亦如此。预测动作中的微小误差可能导致状态产生巨大差异，从而加剧模仿学习的“复合误差”问题 [47, 64, 29]。为解决这一问题，本文从动作分块中汲取灵感，该概念源自心理学，描述动作序列如何被组合成一个块并作为一个单元执行 [35]。在本方法中，策略预测未来 k 个时间步的目标关节位置，而非每次仅预测一步。这将任务的有效时间范围缩短 k 倍，从而缓解复合误差。预测动作序列还有助于处理时间相关的混杂因素 [61]，例如示范中的停顿，这类现象难以用马尔可夫单步策略建模。为进一步提升策略的平滑性，本文提出时间集成方法，即更频繁地查询策略并对重叠的动作块进行平均。本文使用变换器（Transformers）[65] 实现动作分块策略，该架构专为序列建模设计，并将其训练为条件变分自编码器（CVAE）[55, 33] 以捕捉人类数据中的变异性。本文将所提方法命名为基于变换器的动作分块（Action Chunking with Transformers, ACT），并发现该方法在一系列模拟和真实世界精细操作任务上显著优于以往的模仿学习算法。本文的关键贡献在于提出一种用于学习精细操作的低成本系统，该系统由遥操作系统和一种新颖的模仿学习算法组成。遥操作系统尽管成本低廉，却能支持高精度和丰富接触的任务。模仿学习算法——基于变换器的动作分块（ACT）——能够学习精确的闭环行为，并大幅超越以往方法。这两部分的协同作用使得仅通过 10 分钟或 50 条示范轨迹，即可在真实世界中直接学习 6 项精细操作技能，例如打开半透明调味杯和安装电池，成功率达 80-90%。

II. 相关工作

机器人操作的模仿学习。模仿学习使机器人能够直接从专家示范中学习。行为克隆（Behavioral Cloning, BC）[44] 是最简单的模仿学习算法之一，它将模仿问题转化为从观测到动作的监督学习。此后，许多工作致力于改进行为克隆，例如通过引入历史信息并结合多种网络架构 [39, 49, 26, 7]、采用不同的训练目标 [17, 42] 以及加入正则化 [46]。另一些工作则强调模仿学习的多任务或少样本特性 [14, 25, 11]，利用语言信息 [51, 52, 26, 7] 或挖掘特定任务结构 [43, 68, 28, 52]。随着数据规模的扩大，这些模仿学习算法已催生出令人瞩目的系统，能够泛化到新物体、新指令或新场景 [15, 26, 7, 32]。本文聚焦于构建一个低成本且能胜任精细操作任务的模仿学习系统。我们从硬件与软件两方面入手：一方面搭建高性能遥操作系统，另一方面提出一种新颖的模仿学习算法，在精细操作任务上显著超越以往方法。

应对复合误差问题。行为克隆的一个主要缺陷是复合误差，即前序时间步的误差不断累积，导致机器人偏离训练分布，进入难以恢复的状态 [47, 64]。这一问题在精细操作场景中尤为突出 [29]。缓解复合误差的一种途径是允许额外的在线交互与专家纠正，例如数据集聚合（DAgger）[47] 及其变体 [30, 40, 24]。然而，通过遥操作接口进行专家标注既耗时又不自然 [29]。也可以在示范采集阶段注入噪声，以获得包含纠正行为的数据集 [36]，但在精细操作中，此类噪声注入可能直接导致任务失败，降低遥操作系统的灵巧性。为规避上述问题，已有工作采用离线方式生成合成纠正数据 [16, 29, 70]，但这些方法仅限于低维状态可用的场景或抓取等特定任务类型。鉴于这些局限性，我们需要从不同角度解决复合误差问题，并兼容高维视觉观测。本文提出通过动作分块来缩短任务的有效时间跨度，即预测动作序列而非单一动作，再对重叠的动作块进行集成，从而生成既准确又平滑的轨迹。

双手操作。双手操作在机器人学中历史悠久，随着硬件成本的降低而日益普及。早期工作从经典控制角度处理双手操作，假设环境动力学已知 [54, 48]，但设计此类模型可能耗时，且对于具有复杂物理特性的物体可能不准确。近年来，学习已被纳入双手系统，例如强化学习 [9, 10]、模仿人类演示 [34, 37, 59, 67, 32]，或学习预测串联起来的关键点



ViperX 6dof Arm (follower)

#Dofs	6+gripper
Reach	750mm
Span	1500mm
Repeatability	1mm
Accuracy	5-8mm
Working Payload	750g

图 3：左：前置、顶部及两个腕部相机的视角，以及 ALOHA 双手工作空间的示意图。中：“手柄与剪刀”机构及定制夹爪的详细视图。右：ViperX 6 自由度机器人的技术规格 [1]。

运动基元 [20, 19, 50]。部分工作还专注于精细操作任务，如解结、铺平布料，甚至穿针引线 [19, 18, 31]，同时使用成本高的机器人，例如达芬奇手术机器人或 ABB YuMi。我们的工作转向低成本硬件，例如每只手臂约 5000 美元，并力求使其能够执行高精度、闭环任务。我们的遥操作设置与 Kim 等人 [32] 最为相似，后者同样在领导者与跟随者机器人之间使用关节空间映射。与此前系统不同，我们不使用特殊编码器、传感器或机加工部件。我们仅使用现成机器人和少量 3D 打印部件构建系统，使非专家也能在 2 小时内完成组装。

在执行精细操作时，即使面对薄塑料薄膜也能实现稳固抓握。随后，我们致力于围绕 ViperX 机器人设计一套最大限度用户友好的遥操作系统。我们没有采用将虚拟现实控制器或摄像头捕捉到的手部姿态映射到机器人末端执行器姿态（即任务空间映射）的方式，而是采用直接关节空间映射，使用同一家公司制造、成本为 3300 美元的小型机器人 WidowX[2]。用户通过反向驱动小型 WidowX（“领导者”）进行遥操作，其关节与较大的 ViperX（“跟随者”）同步。在开发该装置时，我们注意到与任务空间相比，关节空间映射具有若干优势。（1）精细操作通常需要在机器人奇异点附近工作，而我们的机器人具有 6 个自由度且无冗余。现成的逆运动学

III. ALOHA：低成本开源硬件

双手遥操作系统 我们旨在开发一种易于获取且高性能的遥操作系统，用于精细操作。我们将设计考量总结为以下 5 项原则。

- 1) 低成本：**整个系统应在大多数机器人实验室的预算范围内，与单个工业机械臂相当。
- 2) 通用性：**可应用于现实世界中各类精细操作任务。
- 3) 用户友好：**系统应直观、可靠且易于使用。
- 4) 可修复性：**当设备不可避免损坏时，研究人员能够轻松修复。
- 5) 易于搭建：**研究人员可利用易于获取的材料快速组装。

在选择所使用的机器人时，原则 1、4 和 5 引导我们构建了一个双臂平行夹爪装置，配备两台 ViperX 六自由度机械臂 [1, 66]。出于价格和维护考虑，我们不采用灵巧手。所使用的 ViperX 机械臂工作负载为 750 克，臂展 1.5 米，准确率为 5-8 毫米。该机器人模块化且易于维修：一旦电机发生故障，低成本的 Dynamixel 电机可以轻松更换。该机器人可以现货购买，价格约为 5600 美元。然而，原厂手指不够灵活，无法处理精细操作任务。因此，我们设计了自己的 3D 打印“透明”手指，并贴上抓握胶带（图 3）。这提供了良好的可视性

（IK）在此情况下经常失效。相比之下，关节空间映射在关节极限范围内保证高带宽控制，同时计算量更少、延迟更低。

（2）领导者机器人的重量可防止用户移动过快，并抑制微小振动。我们注意到，与手持虚拟现实控制器相比，关节空间映射在精确任务上性能更佳。为进一步改善遥操作体验，我们设计了一种 3D 打印的“手柄与剪刀”机构，可加装到领导者机器人上（图 3）。它减少了操作者反向驱动电机所需的力，并允许对夹爪进行连续控制，而非仅二值开合。

我们还设计了一种橡皮筋负载平衡机制，部分抵消了领导者侧的重力。这减少了操作员所需的努力，并使更长时间的远程操作（例如超过 30 分钟）成为可能。我们在项目网站上包含了有关设置的更多细节。其余设置包括一个带有 20 × 20mm 铝型材的机器人笼，并通过交叉钢缆加固。总共有四个罗技 C922x 网络摄像头，每个摄像头流式传输 480 × 640 RGB 图像。其中两个网络摄像头安装在跟随者机器人的手腕上，可以近距离观察夹爪。其余两个摄像头分别安装在前方和顶部（图 3）。远程操作和数据记录均以 50Hz 的频率进行。

基于上述设计考虑，我们在 2 万美元预算内构建了双手远程操作设置 ALOHA，与单个研究臂（如 Franka Emika Panda）的成本相当。




图 4：基于变换器的动作分块（ACT）架构。我们将 ACT 训练为条件变分自编码器（CVAE），它包含一个编码器和一个解码器。左图：CVAE 的编码器将动作序列和关节观测压缩为 z ，即风格变量。编码器在测试时被丢弃。右图：ACT 的解码器或策略使用变换器编码器合成来自多个视角的图像、关节位置和 z ，并使用变换器解码器预测动作序列。在测试时， z 简单地设置为先验的均值（即零）。

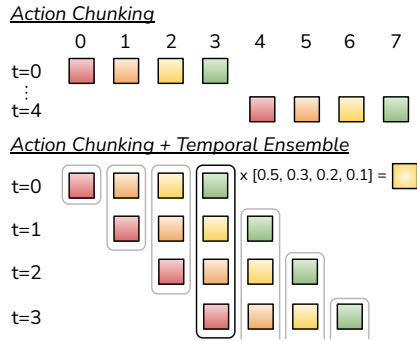


图 5：在应用动作时，我们同时采用动作分块和时间集成，而不是交替进行观测和执行。

ALOHA 能够实现以下任务的远程操作：

- **精细任务**，如穿扎带、从钱包中取出信用卡、打开或关闭自封袋。
- **接触丰富任务**，如将 288 针内存条插入计算机主板、翻书页、组装 NIST 板#2 中的链条和皮带 [4]
- **动态任务**，如用真实乒乓球拍颠乒乓球、保持球不掉落、在空中甩开塑料袋。

据我们所知，诸如穿扎带、插入内存条和抛接乒乓球等技能，在预算为 5 至 10 倍的现有遥操作系统中尚不可用 [21, 5]。我们在附录 A 中提供了更详细的价格与能力比较，并在图 9 中展示了 ALOHA 能够完成的更多技能。为了使 ALOHA 更易于获取，我们开源了所有软件和硬件，并提供了涵盖 3D 打印、框架组装到软件安装详细教程。您可以在项目网站上找到该教程。

四、基于变换器的动作分块

正如我们将在第五节中看到的，现有的模仿学习算法在需要高频控制和闭环反馈的精细任务上表现不佳。因此，我们开发了一种新颖的算法——基于变换器的动作分块（Action Chunking with Transformers, ACT），以利用 ALOHA 收集的数据。我们首先总结 ACT 的训练流程，然后深入探讨每个设计选择。

为了在新任务上训练 ACT，我们首先使用 ALOHA 收集人类演示。我们记录主机机器人的关节位置（即来自人类操作员的输入），并将其用作动作。使用主机机器人的关节位置而非从机器人的关节位置非常重要，因为施加的力的大小通过低级 PID 控制器由两者之间的差异隐式定义。观测由从机器人当前的关节位置和来自 4 个摄像头的图像组成。接下来，我们训练 ACT 根据当前观测预测未来动作序列。这里的动作对应于下一时间步双臂的目标关节位置。直观地说，ACT 试图模仿人类操作员在当前观测下接下来几个时间步会采取的动作。这些目标关节位置随后由 Dynamixel 电机内部的低级高频 PID 控制器进行跟踪。在测试时，我们加载达到最低验证损失（validation loss）的策略，并在环境中进行推演。出现的主要挑战是复合误差，即先前动作的误差导致状态超出训练分布。

A. 动作分块与时间集成

为了以兼容像素到动作策略的方式对抗模仿学习的复合误差（图 2），本文致力于缩短高频采集的长轨迹的有效时间跨度。本文受到动作分块这一神经科学概念的启发，该概念将个体动作组合并作为一个单元执行，从而提升存储与执行效率 [35]。直观而言，一个动作块可对应抓取糖果包装纸的一角或将电池插入槽中。在本文的实现中，将块大小固定为 k ：每 k 步，智能体接收一次观测，生成接下来的 k 个动作，并按顺序执行这些动作（图 5）。这意味着任务的有效时间跨度缩减了 k 倍。具体而言，策略建模的是 $\pi_{\theta}(a_{t:t+k}|s_t)$ 而非 $\pi_{\theta}(a_t|s_t)$ 。分块还有助于建模人类演示中的非马尔可夫行为。具体来说，单步策略难以处理时间相关的混杂因素，例如演示中途的停顿 [61]，因为行为不仅取决于状态，还取决于时间步。动作分块能够缓解这一问题。

Algorithm 1 ACT Training

```
1: Given: Demo dataset  $\mathcal{D}$ , chunk size  $k$ , weight  $\beta$ .
2: Let  $a_t, o_t$  represent action and observation at timestep  $t$ ,  $\bar{o}_t$ 
   represent  $o_t$  without image observations.
3: Initialize encoder  $q_\phi(z|a_{t:t+k}, \bar{o}_t)$ 
4: Initialize decoder  $\pi_\theta(\hat{a}_{t:t+k}|o_t, z)$ 
5: for iteration  $n = 1, 2, \dots$  do
6:   Sample  $o_t, a_{t:t+k}$  from  $\mathcal{D}$ 
7:   Sample  $z$  from  $q_\phi(z|a_{t:t+k}, \bar{o}_t)$ 
8:   Predict  $\hat{a}_{t:t+k}$  from  $\pi_\theta(\hat{a}_{t:t+k}|o_t, z)$ 
9:    $\mathcal{L}_{reconst} = \text{MSE}(\hat{a}_{t:t+k}, a_{t:t+k})$ 
10:   $\mathcal{L}_{reg} = D_{KL}(q_\phi(z|a_{t:t+k}, \bar{o}_t) \parallel \mathcal{N}(0, I))$ 
11:  Update  $\theta, \phi$  with ADAM and  $\mathcal{L} = \mathcal{L}_{reconst} + \beta\mathcal{L}_{reg}$ 
```

Algorithm 2 ACT Inference

```
1: Given: trained  $\pi_\theta$ , episode length  $T$ , weight  $m$ .
2: Initialize FIFO buffers  $\mathcal{B}[0 : T]$ , where  $\mathcal{B}[t]$  stores actions
   predicted for timestep  $t$ .
3: for timestep  $t = 1, 2, \dots, T$  do
4:   Predict  $\hat{a}_{t:t+k}$  with  $\pi_\theta(\hat{a}_{t:t+k}|o_t, z)$  where  $z = 0$ 
5:   Add  $\hat{a}_{t:t+k}$  to buffers  $\mathcal{B}[t : t+k]$  respectively
6:   Obtain current step actions  $A_t = \mathcal{B}[t]$ 
7:   Apply  $a_t = \sum_i w_i A_t[i] / \sum_i w_i$ , with  $w_i = \exp(-m * i)$ 
```

当混杂因素位于一个块内时，此问题出现，且不会为以历史为条件的策略引入因果混淆问题 [12]。动作分块的朴素实现可能并非最优：新的环境观测每隔 k 步被突然纳入，可能导致机器人运动不平稳。为提升平滑性并避免执行与观测之间的离散切换，我们在每个时间步查询策略。这使得不同的动作块相互重叠，在给定时间步将存在多个预测动作。我们在图 5 中对此进行了说明，并提出一种时序集成方法来组合这些预测。我们的时序集成采用指数加权方案 $w_i = \exp(-m * i)$ 对这些预测进行加权平均，其中 w_0 是最旧动作的权重。纳入新观测的速度由 m 控制，较小的 m 意味着更快的纳入。我们注意到，与典型的平滑方法不同——后者将当前动作与相邻时间步的动作聚合，从而引入偏差——我们聚合的是针对同一时间步预测的动作。此过程也不会产生额外的训练成本，仅增加推理时的计算量。在实践中，我们发现动作分块和时序集成对于 ACT 的成功都至关重要，ACT 能够产生精确且平滑的运动。我们将在第六-A 小节的消融研究中更详细地讨论这些组件。

B. 人类数据建模 另一个出现的挑战是从嘈杂的人类演示中学习。给定相同的观测，人类可以使用不同的轨迹来完成任务。在精度要求较低的区域，人类也会表现出更大的随机性 [38]。因此，策略必须关注高精度至关重要的区域。我们通过训练我们的策略来解决这一问题

动作分块策略作为生成模型。具体而言，我们将策略训练为条件变分自编码器 (CVAE) [55]，以当前观测为条件生成动作序列。CVAE 包含两个组件：CVAE 编码器和 CVAE 解码器，分别如图 4 左侧和右侧所示。CVAE 编码器仅用于训练 CVAE 解码器（即策略），在测试时被丢弃。具体来说，CVAE 编码器在给定当前观测和动作序列作为输入的情况下，预测风格变量 z 分布的均值和方差，该分布被参数化为对角高斯分布。为了在实践中加快训练速度，我们省略图像观测，仅以本体感知观测和动作序列为条件。CVAE 解码器（即策略）以 z 和当前观测（图像+关节位置）为条件来预测动作序列。在测试时，我们将 z 设置为先验分布的均值，即零，以进行确定性解码。整个模型被训练以最大化演示动作块的对数似然，即 $\min_\theta - \sum_{s_t, a_{t:t+k} \in D} \log \pi_\theta(a_{t:t+k}|s_t)$ ，采用标准 VAE 目标，该目标包含两项：重构损失和将编码器正则化为高斯先验的项。遵循 [23]，我们用超参数 β 对第二项进行加权。直观上，较高的 β 将导致 z [62] 中传输的信息更少。总体而言，我们发现 CVAE 目标对于从人类演示中学习精确任务至关重要。我们在第 VI-B 小节中提供了更详细的讨论。

C. 实现 ACT

我们使用变换器 (Transformer) 实现条件变分自编码器 (CVAE) 的编码器和解码器，因为变换器既擅长在序列中综合信息，也擅长生成新序列。CVAE 编码器采用类似 BERT 的变换器编码器实现 [13]。编码器的输入是当前关节位置和来自演示数据集的长度为 k 的目标动作序列，并在前面添加一个类似 BERT 的学习得到的“[CLS]”标记。这构成了长度为 $k+2$ 的输入（图 4 左）。经过变换器处理后，与“[CLS]”对应的特征被用来预测“风格变量” z 的均值和方差，该变量随后作为解码器的输入。CVAE 解码器（即策略）以当前观测和 z 作为输入，预测接下来的 k 个动作（图 4 右）。我们使用 ResNet 图像编码器、变换器编码器和变换器解码器来实现 CVAE 解码器。直观上，变换器编码器综合来自不同相机视角、关节位置和风格变量的信息，变换器解码器生成连贯的动作序列。观测包括 4 张 RGB 图像，每张分辨率为 480×640 ，以及两个机械臂的关节位置（共 $7+7=14$ 个自由度）。动作空间是两个机器人的绝对关节位置，是一个 14 维向量。因此，通过动作分块，策略在给定当前观测时输出一个 $k \times 14$ 张量。策略首先使用 ResNet18 骨干网络 [22] 处理图像，将 $480 \times 640 \times 3$ 张 RGB 图像转换为 $15 \times 20 \times 512$ 个特征图。然后沿空间维度展平，得到长度为 300×512 的序列。为了保留空间信息，我们添加了二维正弦

位置嵌入到特征序列 [8]。对所有 4 张图片重复此操作，得到维度为 1200×512 的特征序列。然后我们附加两个特征：当前关节位置和“风格变量” z 。它们分别通过线性层从原始维度投影到 512。因此，变换器编码器的输入是 1202×512 。变换器解码器通过交叉注意力以编码器输出为条件，其中输入序列是固定的位置嵌入，维度为 $k \times 512$ ，键和值来自编码器。这使得变换器解码器的输出维度为 $k \times 512$ ，然后通过多层感知机下投影到 $k \times 14$ ，对应于接下来 k 步的预测目标关节位置。我们使用 L1 损失进行重建，而不是更常见的 L2 损失：我们注意到 L1 损失能更精确地建模动作序列。我们还注意到，使用增量关节位置作为动作而不是目标关节位置时性能会下降。我们在附录 C 中提供了详细的架构图。我们在算法 1 和 2 中总结了 ACT 的训练和推理。该模型约有 8000 万个参数，我们为每个任务从头开始训练。训练在单个 11G RTX 2080 Ti GPU 上大约需要 5 小时，推理时间在同一台机器上约为 0.01 秒。

五、实验

我们通过实验评估 ACT 在精细操作任务上的性能。为了便于复现，我们在 MuJoCo[63] 中构建了两个模拟精细操作任务，此外还有 6 个使用 ALOHA 的真实世界任务。我们在项目网站上提供了每个任务的视频。


A. 任务

所有 8 项任务均需精细的双臂操作，并在图 6 中展示。对于拉链袋滑动任务，右夹爪需准确抓取拉链袋的滑块并将其打开，左夹爪固定袋身。对于电池槽任务，右夹爪需先将电池放入遥控器的槽中，然后用指尖精细地推入电池边缘，直至完全插入。由于电池槽内的弹簧在插入过程中会使遥控器向相反方向移动，左夹爪向下按压遥控器以保持其位置。对于开杯任务，目标是打开一个小调料杯的盖子。由于杯子尺寸小，夹爪仅从侧面接近无法抓住杯身。因此，我们利用双臂：右手指先轻敲杯缘附近使其倾斜，然后将其推入张开的左夹爪中。这一推入步骤需要高精度并依赖视觉感知的闭环控制。随后左夹爪轻轻闭合，将杯子从桌面抬起，接着右手指撬开盖子，这也需要精度以避免错过盖子或损坏杯子。对于穿魔术贴任务，目标是将魔术贴扎带的一端插入连接在另一端的环中。左夹爪需先从


桌面，随后右夹爪在空中捏住扎带的尾部。接着，双臂协同将魔术贴扎带的一端在空中插入另一端。环的尺寸为 3 毫米 $\times$ 25 毫米，而魔术贴扎带的尺寸根据位置不同为 2 毫米 $\times$ 10-25 毫米。为了成功完成该任务，机器人必须利用视觉反馈在每次抓取时纠正扰动，因为第一次抓取时哪怕几毫米的误差都会在第二次空中抓取中累积，导致插入阶段产生超过 10 毫米的偏差。对于准备胶带任务，目标是将一小段胶带挂在纸板箱的边缘。右夹爪首先抓住胶带并用胶带切割器的刀片切断，然后在空中将胶带段递给左夹爪。接下来，双臂靠近箱子，左臂轻轻将胶带段放在箱子表面，右手指按压胶带以防止滑动，随后左臂张开夹爪释放胶带。与穿魔术贴类似，该任务需要双臂之间多步精细协调。对于穿鞋任务，目标是将鞋穿到固定的人体模型脚上，并用鞋的魔术贴带固定。双臂首先需要分别抓住鞋舌和鞋领，将其抬起并靠近脚部。穿鞋具有挑战性，因为贴合紧密：双臂需要仔细协调将脚推入，并且两次抓取都需要足够稳健以抵消袜子和鞋之间的摩擦。然后，左臂绕到鞋底下方支撑以防掉落，随后右臂翻转魔术贴带并将其按压在鞋上以固定。只有当双臂释放后鞋仍紧贴脚部时，任务才被视为成功。对于模拟任务转移立方体，右臂需要首先拾起放在桌上的红色立方体，然后将其放入另一只手臂的夹爪内。由于立方体与左夹爪之间的间隙很小（约 1 厘米），微小误差可能导致碰撞和任务失败。对于模拟任务

双臂插入，左右机械臂需分别拾取插座与插销，并在半空中完成对接，使插销触及插座内部的“引脚”。插入阶段的间隙约为 5 毫米。对于全部 8 项任务，物体的初始摆放位置要么沿 15 厘米白色参考线随机变化（真实世界任务），要么在二维区域内均匀分布（仿真任务）。我们在图 6 和图 7 中展示了初始位置与子任务的示意图。评估环节还将分别报告各子任务的性能表现。除解决这些任务所需的精细双臂控制外，所用物体也带来了显著的感知挑战。例如，自封袋基本透明，仅有一条蓝色密封线。袋上的褶皱与内部反光糖纸在随机化过程中均可能变化，从而干扰感知系统。其他透明或半透明物体包括胶带以及调料杯的杯盖与杯身，这使得它们难以被精确感知，且不适合深度相机。黑色桌面也与许多目标物体形成低对比度，例如黑色魔术贴扎带和黑色


Real-World Task Definitions




Slide Ziploc: Open the ziploc bag that is standing upright on the table. The bag is randomized along the 15cm white line. It is dropped from ~5cm above the table to randomize the deformation, which affects the height and appearance of the bag. The left arm first grasps the bag body (*Subtask#1 Grasp*) followed by the right arm pinching the slider (*Subtask #2 Pinch*). Then the right arm moves right to unzip the bag (*Subtask #3 Open*).



Slot Battery: Insert the battery into the remote controller. The controller is randomized along the 15cm white line. The battery is initialized in roughly the same position with different rotations. The right arm first grasps the battery (*Subtask#1 Grasp*) then places it into the slot (*Subtask#2 Place*). The left arm presses onto the remote to prevent it from sliding, while the right arm pushes in the battery (*Subtask#3 Insert*).




Open Cup: Pick up and open the lid of a translucent condiment cup. The cup is randomized along the 15cm white line. Both arms approach the cup, and the right gripper gently tips over the cup (*Subtask#1 Tip Over*) and pushes it into the gripper of the left arm. The left arm then gently closes its gripper and lifts the cup off the table (*Subtask#2 Grasp*). Next, the right gripper approaches the cup lid from below and prys open the lid.



Thread Velcro: Pick up the velcro cable tie and insert one end into the small loop on the other end. The velcro tie is randomized along the 15cm white line. The left arm first picks up the velcro tie by pinching near the plastic loop (*Subtask#1 Lift*). The right arm grasps the tail of the velcro tie mid-air (*Subtask#2 Grasp*). Next, both arms coordinate to deform the velcro tie and insert one end of it into the plastic loop on the other end.




Prep Tape: Hang a short segment of tape on the edge of the box. The tape dispenser is randomized along the 15cm white line. First, the right gripper grasps the tape from the side (*Subtask#1 Grasp*). It then lifts the tape and pulls to unroll it, followed by cutting it with the dispenser blade (*Subtask#2 Cut*). Next, the right gripper hands the tape segment to the left gripper in mid-air (*Subtask#3 Handover*), and both arms move toward the corner of the stationary cardboard box. The left arm then lays the tape segment flat on the surface of the box while the right gripper pushes down on the tape to prevent slipping. The left arm then opens its gripper to release the tape (*Subtask#4 Hang*).



Put On Shoe: Put a velcro-strap shoe on a fixed mannequin foot. The shoe pose is randomized along the 15cm white line. First, both left and right grippers pick up the shoe (*Subtask#1 Lift*). Then both arms coordinate to put it on, with the heel touching the heel counter (*Subtask#2 Insert*). Next, the left arm moves to support the shoe (*Subtask#3 Support*), followed by the right arm securing the velcro strap (*Subtask#4 Secure*).

图 6: 真实世界任务定义。针对 6 项真实世界任务中的每一项, 我们展示了初始状态与子任务。



Left: Cube Transfer. Transfer the red cube to the other arm. The right arm touches (#1) and grasps (#2) the red cube, then hands it to the left arm.
Right: Bimanual Insertion. Insert the red peg into the blue socket. Both arms grasp (#1), let socket and peg make contact (#2) and insertion.

图 7: 仿真任务定义。针对 2 项仿真任务中的每一项, 我们展示了初始化状态与子任务。

	Cube Transfer (sim)			Bimanual Insertion (sim)			Slide Ziploc (real)			Slot Battery (real)		
	Touched	Lifted	Transfer	Grasp	Contact	Insert	Grasp	Pinch	Open	Grasp	Place	Insert
BC-ConvMLP	34 3	17 1	1 0	5 0	1 0	1 0	0	0	0	0	0	0
BeT	60 16	51 13	27 1	21 0	4 0	3 0	8	0	0	4	0	0
RT-1	44 4	33 2	2 0	2 0	0 0	1 0	4	0	0	4	0	0
VINN	13 17	9 11	3 0	6 0	1 0	1 0	28	0	0	20	0	0
ACT (Ours)	97 82	90 60	86 50	93 76	90 66	32 20	92	96	88	100	100	96

表 I: 2 项仿真任务与 2 项真实世界任务的成功率 (%)。对比本文方法与 4 种基线方法。对于两项仿真任务, 我们报告 [使用脚本数据训练 | 使用人类数据训练], 采用 3 个随机种子, 每项策略评估 50 次。对于真实世界任务, 我们报告使用人类数据训练, 采用 1 个随机种子, 评估 25 次。总体而言, ACT 显著优于先前方法。

	Open Cup (real)			Thread Velcro (real)			Prep Tape (real)				Put On Shoe (real)			
	Tip Over	Grasp	Open Lid	Lift	Grasp	Insert	Grasp	Cut	Handover	Hang	Lift	Insert	Support	Secure
BeT	12	0	0	24	0	0	8	0	0	0	12	0	0	0
ACT (Ours)	100	96	84	92	40	20	96	92	72	64	100	92	92	92

表 II: 其余 3 项真实世界任务的成功率 (%)。我们仅与表现最佳的基线方法 BeT 进行对比。

胶带座。尤其从俯视角度看, 由于投影面积小, 魔术贴扎带难以定位。

B. 数据采集

对于全部 6 项真实世界任务, 我们使用 ALOHA 遥操作收集演示。根据任务复杂度, 人类操作员完成每个回合需 8 至 14 秒, 在 50 赫兹控制频率下对应 400 至 700 个时间步。除穿线魔术贴任务记录 100 次演示外, 其余每项任务记录 50 次演示。因此, 每项任务的演示数据总量约为 10 至 20 分钟, 而由于重置和遥操作失误, 实际耗时达 30 至 60 分钟。对于两项仿真任务, 我们收集两类演示: 一类由脚本策略生成, 另一类由人类演示生成。在仿真中遥操作时, 我们使用 ALOHA 的“引导机器人”控制仿真机器人, 操作员通过显示器上的实时渲染观察环境。两种情况均记录 50 次成功演示。我们强调, 尽管所有人类演示均由同一人收集, 但其本质上具有随机性。以胶带段空中交接为例: 交接的确切位置在不同回合间存在差异。人类缺乏视觉或触觉参照以在相同位置执行。因此, 为成功完成任务, 策略需学习两夹爪在交接过程中绝不应相互碰撞, 且左夹爪应始终移动至可抓取胶带的位置, 而非试图记忆交接的确切位置, 因为该位置在不同演示中可能变化。

交接过程中, 左夹爪应始终移动至可抓取胶带的位置, 而非试图记忆交接的确切位置, 因为该位置在不同演示中可能变化。

C. 实验结果

我们将 ACT 与四种先前的模仿学习方法进行比较。BC-ConvMLP 是最简单但最广泛使用的基线 [69, 26], 它使用卷积网络处理当前图像观测, 其输出特征与关节位置拼接以预测动作。BeT[49] 也利用变换器作为架构, 但存在关键差异:

(1) 无动作分块: 模型根据观测历史预测一个动作; (2) 图像观测由单独训练的冻结视觉编码器预处理。即感知网络与控制网络未联合优化。RT-1[7] 是另一种基于变换器的架构, 从固定长度的过去观测历史中预测一个动作。BeT 和 RT-1 均将动作空间离散化: 输出为离散区间的分类分布, 但 BeT 额外添加了来自区间中心的连续偏移。我们的方法 ACT 则直接预测连续动作, 这是出于精细操作所需精度的考虑。最后, VINN[42] 是一种非参数方法, 假设在测试时可访问演示数据。给定新观测, 它检索 k 个视觉特征最相似的观测, 并返回一个动作

加权 k 最近邻。视觉特征提取器是一个预训练的残差网络 (ResNet)，在演示数据上通过无监督学习进行微调。我们使用立方体迁移仔细调整了这四种先前方法的超参数。超参数的详细信息见附录 D。作为与先前方法的详细比较，我们在表 I 中报告了两个模拟任务和两个真实任务的平均成功率。对于模拟任务，我们在 3 个随机种子上各进行 50 次试验，并取平均性能。我们报告了脚本数据（分隔条左侧）和人类数据（分隔条右侧）上的成功率。对于真实世界任务，我们运行一个种子并用 25 次试验进行评估。与所有先前方法相比，ACT 达到了最高的成功率，在每个任务上都大幅超越了第二好的算法。对于使用脚本数据或人类数据的两个模拟任务，ACT 在成功率上分别比最佳先前方法高出 59%、49%、29% 和 20%。虽然先前方法能够在前两个子任务中取得进展，但最终成功率仍然很低，低于 30%。对于两个真实世界任务——滑动密封袋 (Slide Ziploc) 和插入电池 (Slot Battery)，ACT 分别达到了 88% 和 96% 的最终成功率，而其他方法在第一阶段之后就没有进展。我们将先前方法性能不佳归因于数据中的复合误差和非马尔可夫行为：行为在回合结束时显著退化，并且机器人可能对某些状态无限期暂停。ACT 通过动作分块缓解了这两个问题。我们在第 VI-A 小节的消融实验也表明，将分块纳入这些先前方法可以显著改善它们。此外，我们注意到在模拟任务中，从脚本数据切换到人类数据时，所有方法的性能都有所下降：人类演示的随机性和多模态性使得模仿学习变得更加困难。我们在表 II 中报告了其余 3 个真实世界任务的成功率。对于这些任务，我们仅与 BeT 进行比较，BeT 是目前任务成功率最高的方法。我们的方法 ACT 在打开杯子 (Cup Open) 上达到 84% 的成功率，在穿线魔术贴 (Thread Velcro) 上达到 20%，在准备胶带 (Prep Tape) 上达到 64%，在穿鞋 (Put On Shoe) 上达到 92%，再次超越了 BeT，后者在这些具有挑战性的任务上最终成功率为零。我们观察到 ACT 在穿线魔术贴上的成功率相对较低，每个阶段的成功率大约减半，从第一阶段的 92% 下降到最终 20%。我们观察到的失败模式是：1) 在第二阶段，右臂过早闭合夹爪，未能抓住空中束线带的尾部；2) 在第三阶段，插入不够精确，错过了环。在这两种情况下，很难从图像观察中确定束线带的确切位置：黑色束线带与背景之间的对比度低，且束线带只占图像的一小部分。我们在附录 B 中包含了图像观察的示例。

六、消融实验

ACT 采用动作分块 (Action Chunking) 与时间集成 (Temporal Ensembling) 技术，以缓解累积误差并更好地处理非马尔可夫演示。此外，ACT 将策略训练为条件变分自编码器 (Conditional VAE)，以建模含噪的人类演示。在本节中，本

文对上述各组件进行消融，并结合用户研究强调 ALOHA 中高频控制的必要性。我们报告了四种设置下的结果：两个使用脚本或人类演示的仿真任务。

A. 动作分块与时间集成

在第五-C 小节中，我们观察到 ACT 显著优于以往仅预测单步动作的方法，并假设动作分块是关键的设计选择。由于 k 决定了每个“块”中序列的长度，我们可以通过变化来分析这一假设 k 。 $k = 1$ 对应于无动作分块，且 $k = episode_length$ 对应于完全开环控制，即机器人基于首次观测输出整个回合的动作序列。在这些实验中，我们禁用了时序集成，以仅测度分块的影响，并为每个分块大小分别训练了策略。 k 在图 8 (a) 中，我们绘制了在 4 种设置下平均的成功率，对应 2 个模拟任务，分别使用人类数据或脚本数据，其中蓝线表示未使用时间集成的 ACT。我们观察到，性能从 1% 大幅提升至 $k = 1$ 降至 44% $k = 100$ ，随后略微收窄并进一步升高 k 。这表明，更多的分块和更低的有效时间范围通常能提升性能。我们将轻微的下降归因于 $k = 200, 400$ （即接近开环控制）到缺乏反应行为以及难以建模长动作序列。为了进一步评估动作分块的有效性和通用性，我们将动作分块增强到两种基线方法中。对于 BC-ConvMLP，我们简单地将输出维度增加到

$k * action_dim$ ，对于 VINN，我们检索接下来的 k 个动作。我们在图 8 (a) 中展示了它们在不同 k 下的性能，显示出与 ACT 一致的趋势，即更多的动作分块能提升性能。虽然 ACT 仍然以可观的增益优于两种增强后的基线，但这些结果表明动作分块在这些设置下通常有利于模仿学习。然后，我们通过比较在有无时间集成的情况下最高成功率来消融时间集成，同样在 4 个前述任务和不同的 k 下进行。我们注意到有无时间集成的实验是分别调参的：对无时间集成最有效的超参数在有时间集成时可能不是最优的。在图 8 (b) 中，我们展示了 BC-ConvMLP 从时间集成中获益最大，增益为 4%，其次是我们的方法，增益为 3.3%。我们注意到 VINN（一种非参数方法）的性能下降。我们假设时间集成主要通过平滑建模误差来使参数化方法受益。相比之下，VINN 从数据集中检索真实动作，因此不受此问题影响。

B. 使用 CVAE 进行训练

我们使用 CVAE 目标训练 ACT，以建模人类演示，这些演示可能包含噪声和多模态行为。在本节中，我们将 ACT 与不使用 CVAE 目标的版本进行比较，后者仅根据当前观测预测动作序列，并使用 L1 损失进行训练。如图 8 所示




图 8: (a) 我们为两个基线方法增加了动作分块, x 轴表示不同的块大小 k , y 轴表示成功率。两种方法都从动作分块中显著受益, 表明这是一项普遍有用的技术。(b) 时间集成 (TE) 改进了我们的方法和 BC-ConvMLP, 但损害了 VINN。(c) 我们比较了使用和不使用 CVAE 训练的情况, 表明在从人类数据学习时 CVAE 至关重要。(d) 我们绘制了用户研究中任务完成时间的分布, 参与者被要求以 5Hz 或 50Hz 的遥操作频率执行两项任务。降低频率导致完成时间减慢 62%。(e) 我们可视化了在 2 个模拟任务上聚合的成功率, 并分别绘制了使用脚本数据和人类数据训练的结果。可以看到, 当使用脚本数据训练时, 移除 CVAE 目标对性能几乎没有影响, 因为数据集是完全确定性的。而对于人类数据, 成功率从 35.3% 显著下降到 2%。这说明 CVAE 目标在从人类演示中学习时至关重要。

学习算法 ACT。这两部分的协同作用使我们能够直接在现实世界中学习精细操作技能, 例如打开半透明调料杯和安装电池, 成功率可达 80-90%, 且仅需约 10 分钟的演示。尽管该系统能力较强, 但仍存在超出机器人或学习算法能力的任务, 例如扣上衬衫纽扣。我们在附录 F 中提供了关于局限性的更详细讨论。总体而言, 我们希望这一低成本开源系统能够成为推动精细机器人操作发展的重要一步和可获取的资源。

C. 高频是否必要? 最后, 我们进行了一项用户研究, 以说明高频遥操作对于精细操作的必要性。在相同的硬件设置下, 我们将频率从 50Hz 降低到 5Hz, 这一控制频率与近期使用高容量深度网络进行模仿学习的工作相似 [7, 70]。我们选择了两个细粒度任务: 穿扎带和分离两个塑料杯。这两个任务都需要毫米级精度和闭环视觉反馈。我们邀请了 6 名参与者进行研究, 他们对遥操作的经验各不相同, 但此前均未使用过 ALOHA。参与者从计算机科学研究生中招募, 包括 4 名男性和 2 名女性, 年龄在 22 至 25 岁之间。任务顺序和频率对每位参与者随机分配, 每位参与者在每次试验前有 2 分钟的练习时间。我们记录了 3 次试验中完成任务所需的时间, 并将数据可视化在图 8 (d) 中。平均而言, 参与者在 5Hz 下穿扎带耗时 33 秒, 而在 50Hz 下降低到 20 秒。对于分离塑料杯, 提高控制频率将任务持续时间从 16 秒缩短到 10 秒。总体而言, 我们的设置 (即 50Hz) 使参与者能够在短时间内完成高度灵巧和精确的任务。然而, 将频率从 50Hz 降低到 5Hz 导致遥操作时间增加 62%。随后, 我们使用“重复测量设计”这一统计程序, 正式验证了 50Hz 遥操作优于 5Hz, p 值小于 0.001。我们在附录 E 中包含了更多关于该研究的细节。

七、局限性与结论

我们提出了一种用于精细操作的低成本系统, 该系统由遥操作系统 ALOHA 和一种新颖的模仿组成

致谢 我们感谢斯坦福大学 IRIS 实验室成员的支持与反馈。同时感谢 Siddharth Karamcheti, Toki Migimatsu, Staven Cao, Huihan Liu, Mandi Zhao, Pete Florence 和 Corey Lynch 的有益讨论。Tony Zhao 由 FANUC 赞助的斯坦福机器人奖学金支持, 此外还得到 Schmidt Futures 和 ONR Grant N00014-21-1-2685 的资助。

参考文献

- [1] Viperx 300 robot arm 6dof. URL <https://www.trossenrobotics.com/viperx-300-robot-arm-6dof.aspx>.
- [2] Widowx 250 robot arm 6dof. URL <https://www.trossenrobotics.com/widowx-250-robot-arm-6dof.aspx>.
- [3] Highly dexterous manipulation system - capabilities - part 1, Nov 2014. URL <https://www.youtube.com/watch?v=TearcKVj0iY>.
- [4] Assembly performance metrics and test methods, Apr 2022. URL <https://www.nist.gov/el/intelligent-systems-division-73500/robotic-grasping-and-manipulation-assembly/assembly>.
- [5] Teleoperated robots - shadow teleoperation system, Nov 2022. URL <https://www.shadowrobot.com/teleoperation/>.
- [6] Sridhar Pandian Arunachalam, Irmak Güzey, Soumith Chintala, and Lerrel Pinto. Holo-dex: Teaching dexterity with immersive mixed reality. *arXiv preprint arXiv:2210.06463*, 2022.
- [7] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Joseph Dabis, Chelsea Finn, Keerthana

- Gopalakrishnan, Karol Hausman, Alexander Herzog, Jasmine Hsu, Julian Ibarz, Brian Ichter, Alex Irpan, Tomas Jackson, Sally Jesmonth, Nikhil J. Joshi, Ryan C. Julian, Dmitry Kalashnikov, Yuheng Kuang, Isabel Leal, Kuang-Huei Lee, Sergey Levine, Yao Lu, Utsav Malla, Deeksha Manjunath, Igor Mordatch, Ofir Nachum, Carolina Parada, Jodilyn Peralta, Emily Perez, Karl Pertsch, Jornell Quiambao, Kanishka Rao, Michael S. Ryoo, Grecia Salazar, Pannag R. Sanketi, Kevin Sayed, Jaspiar Singh, Sumedh Anand Sontakke, Austin Stone, Clayton Tan, Huong Tran, Vincent Vanhoucke, Steve Vega, Quan Ho Vuong, F. Xia, Ted Xiao, Peng Xu, Sichun Xu, Tianhe Yu, and Brianna Zitkovich. Rt-1: Robotics transformer for real-world control at scale. *ArXiv*, abs/2212.06817, 2022.
- [8] Nicolas Carion, Francisco Massa, Gabriel Synnaeve, Nicolas Usunier, Alexander Kirillov, and Sergey Zagoruyko. End-to-end object detection with transformers. *ArXiv*, abs/2005.12872, 2020.
- [9] Yuanpei Chen, Yaodong Yang, Tianhao Wu, Shengjie Wang, Xidong Feng, Jiechuan Jiang, Stephen McAleer, Hao Dong, Zongqing Lu, and Song-Chun Zhu. Towards human-level bimanual dexterous manipulation with reinforcement learning. *ArXiv*, abs/2206.08686, 2022.
- [10] Rohan Chitnis, Shubham Tulsiani, Saurabh Gupta, and Abhinav Kumar Gupta. Efficient bimanual manipulation using learned task schemas. *2020 IEEE International Conference on Robotics and Automation (ICRA)*, pages 1149–1155, 2019.
- [11] Sudeep Dasari and Abhinav Kumar Gupta. Transformers for one-shot visual imitation. In *Conference on Robot Learning*, 2020.
- [12] Pim de Haan, Dinesh Jayaraman, and Sergey Levine. Causal confusion in imitation learning. In *Neural Information Processing Systems*, 2019.
- [13] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. *ArXiv*, abs/1810.04805, 2019.
- [14] Yan Duan, Marcin Andrychowicz, Bradley C. Stadie, Jonathan Ho, Jonas Schneider, Ilya Sutskever, P. Abbeel, and Wojciech Zaremba. One-shot imitation learning. *ArXiv*, abs/1703.07326, 2017.
- [15] Frederik Ebert, Yanlai Yang, Karl Schmeckpeper, Bernadette Bucher, Georgios Georgakis, Kostas Daniilidis, Chelsea Finn, and Sergey Levine. Bridge data: Boosting generalization of robotic skills with cross-domain datasets. *ArXiv*, abs/2109.13396, 2021.
- [16] Peter R. Florence, Lucas Manuelli, and Russ Tedrake. Self-supervised correspondence in visuomotor policy learning. *IEEE Robotics and Automation Letters*, 5:492–499, 2019.
- [17] Peter R. Florence, Corey Lynch, Andy Zeng, Oscar Ramirez, Ayzaan Wahid, Laura Downs, Adrian S. Wong, Johnny Lee, Igor Mordatch, and Jonathan Tompson. Implicit behavioral cloning. *ArXiv*, abs/2109.00137, 2021.
- [18] Aditya Ganapathi, Priya Sundaesan, Brijen Thananjeyan, Ashwin Balakrishna, Daniel Seita, Jennifer Grannen, Minh Hwang, Ryan Hoque, Joseph Gonzalez, Nawid Jamali, Katsu Yamane, Soshi Iba, and Ken Goldberg. Learning dense visual correspondences in simulation to smooth and fold real fabrics. *2021 IEEE International Conference on Robotics and Automation (ICRA)*, pages 11515–11522, 2020.
- [19] Jennifer Grannen, Priya Sundaesan, Brijen Thananjeyan, Jeffrey Ichnowski, Ashwin Balakrishna, Minh Hwang, Vainavi Viswanath, Michael Laskey, Joseph Gonzalez, and Ken Goldberg. Untangling dense knots by learning task-relevant keypoints. In *Conference on Robot Learning*, 2020.
- [20] Huy Ha and Shuran Song. Flingbot: The unreasonable effectiveness of dynamic manipulation for cloth unfolding. *ArXiv*, abs/2105.03655, 2021.
- [21] Ankur Handa, Karl Van Wyk, Wei Yang, Jacky Liang, Yu-Wei Chao, Qian Wan, Stan Birchfield, Nathan D. Ratliff, and Dieter Fox. Dexpilot: Vision-based teleoperation of dexterous robotic hand-arm system. *2020 IEEE International Conference on Robotics and Automation (ICRA)*, pages 9164–9170, 2019.
- [22] Kaifeng He, X. Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778, 2015.
- [23] Irina Higgins, Loïc Matthey, Arka Pal, Christopher P. Burgess, Xavier Glorot, Matthew M. Botvinick, Shakir Mohamed, and Alexander Lerchner. beta-vae: Learning basic visual concepts with a constrained variational framework. In *International Conference on Learning Representations*, 2016.
- [24] Ryan Hoque, Ashwin Balakrishna, Ellen R. Novoseller, Albert Wilcox, Daniel S. Brown, and Ken Goldberg. Thriftydagger: Budget-aware novelty and risk gating for interactive imitation learning. In *Conference on Robot Learning*, 2021.
- [25] Stephen James, Michael Bloesch, and Andrew J. Davison. Task-embedded control networks for few-shot imitation learning. *ArXiv*, abs/1810.03237, 2018.
- [26] Eric Jang, Alex Irpan, Mohi Khansari, Daniel Kappler, Frederik Ebert, Corey Lynch, Sergey Levine, and Chelsea Finn. Bc-z: Zero-shot task generalization with robotic imitation learning. In *Conference on Robot Learning*, 2022.
- [27] R G Jenness and C D Wicker. Master-slave manipulators and remote maintenance at the oak ridge national laboratory, Jan 1975. URL <https://www.osti.gov/biblio/4179544>.
- [28] Edward Johns. Coarse-to-fine imitation learning: Robot manipulation from a single demonstration. *2021 IEEE International Conference on Robotics and Automation (ICRA)*, pages 4613–4619, 2021.
- [29] Liyiming Ke, Jingqiang Wang, Tapomayukh Bhattacharjee, Byron Boots, and Siddhartha Srinivasa. Grasping with chopsticks: Combating covariate shift in model-free imitation learning for fine manipulation. In *International*

- Conference on Robotics and Automation (ICRA)*, 2021.
- [30] Michael Kelly, Chelsea Sidrane, K. Driggs-Campbell, and Mykel J. Kochenderfer. Hg-dagger: Interactive imitation learning with human experts. *2019 International Conference on Robotics and Automation (ICRA)*, pages 8077–8083, 2018.
 - [31] Heecheol Kim, Yoshiyuki Ohmura, and Yasuo Kuniyoshi. Gaze-based dual resolution deep imitation learning for high-precision dexterous robot manipulation. *IEEE Robotics and Automation Letters*, 6:1630–1637, 2021.
 - [32] Heecheol Kim, Yoshiyuki Ohmura, and Yasuo Kuniyoshi. Robot peels banana with goal-conditioned dual-action deep imitation learning. *ArXiv*, abs/2203.09749, 2022.
 - [33] Diederik P. Kingma and Max Welling. Auto-encoding variational bayes. *CoRR*, abs/1312.6114, 2013.
 - [34] Oliver Kroemer, Christian Daniel, Gerhard Neumann, Herke van Hoof, and Jan Peters. Towards learning hierarchical skills for multi-phase manipulation tasks. *2015 IEEE International Conference on Robotics and Automation (ICRA)*, pages 1503–1510, 2015.
 - [35] Lucy Lai, Ann Z Huang, and Samuel J Gershman. Action chunking as policy compression, Sep 2022. URL psyarxiv.com/z8yrv.
 - [36] Michael Laskey, Jonathan Lee, Roy Fox, Anca D. Dragan, and Ken Goldberg. Dart: Noise injection for robust imitation learning. In *Conference on Robot Learning*, 2017.
 - [37] Alex X. Lee, Henry Lu, Abhishek Gupta, Sergey Levine, and P. Abbeel. Learning force-based manipulation of deformable objects from multiple demonstrations. *2015 IEEE International Conference on Robotics and Automation (ICRA)*, pages 177–184, 2015.
 - [38] Weiwei Li. Optimal control for biological movement systems. 2006.
 - [39] Ajay Mandlekar, Danfei Xu, J. Wong, Soroush Nasiriany, Chen Wang, Rohun Kulkarni, Li Fei-Fei, Silvio Savarese, Yuke Zhu, and Roberto Mart’ın-Mart’ın. What matters in learning from offline human demonstrations for robot manipulation. In *Conference on Robot Learning*, 2021.
 - [40] Kunal Menda, K. Driggs-Campbell, and Mykel J. Kochenderfer. Ensembledagger: A bayesian approach to safe imitation learning. *2019 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 5041–5048, 2018.
 - [41] Samuel Paradis, Minho Hwang, Brijen Thananjeyan, Jeffrey Ichnowski, Daniel Seita, Danyal Fer, Thomas Low, Joseph Gonzalez, and Ken Goldberg. Intermittent visual servoing: Efficiently learning policies robust to instrument changes for high-precision surgical manipulation. *2021 IEEE International Conference on Robotics and Automation (ICRA)*, pages 7166–7173, 2020.
 - [42] Jyothish Pari, Nur Muhammad, Sridhar Pandian Arunachalam, and Lerrel Pinto. The surprising effectiveness of representation learning for visual imitation. *arXiv preprint arXiv:2112.01511*, 2021.
 - [43] Peter Pastor, Heiko Hoffmann, Tamim Asfour, and Stefan Schaal. Learning and generalization of motor skills by learning from demonstration. *2009 IEEE International Conference on Robotics and Automation*, pages 763–768, 2009.
 - [44] Dean A. Pomerleau. Alvin: An autonomous land vehicle in a neural network. In *NIPS*, 1988.
 - [45] Yuzhe Qin, Hao Su, and Xiaolong Wang. From one hand to multiple hands: Imitation learning for dexterous manipulation from single-camera teleoperation. *IEEE Robotics and Automation Letters*, 7:10873–10881, 2022.
 - [46] Rouhollah Rahmatizadeh, Pooya Abolghasemi, Ladislau Bölöni, and Sergey Levine. Vision-based multi-task manipulation for inexpensive robots using end-to-end learning from demonstration. *2018 IEEE International Conference on Robotics and Automation (ICRA)*, pages 3758–3765, 2017.
 - [47] Stéphane Ross, Geoffrey J. Gordon, and J. Andrew Bagnell. A reduction of imitation learning and structured prediction to no-regret online learning. In *International Conference on Artificial Intelligence and Statistics*, 2010.
 - [48] Seyed Sina Mirrazavi Salehian, Nadia Figueroa, and Aude Billard. A unified framework for coordinated multi-arm motion planning. *The International Journal of Robotics Research*, 37:1205 – 1232, 2018.
 - [49] Nur Muhammad (Mahi) Shafiullah, Zichen Jeff Cui, Ariuntuya Altanzaya, and Lerrel Pinto. Behavior transformers: Cloning k modes with one stone. *ArXiv*, abs/2206.11251, 2022.
 - [50] Kaushik Shivakumar, Vainavi Viswanath, Anrui Gu, Yahav Avigal, Justin Kerr, Jeffrey Ichnowski, Richard Cheng, Thomas Kollar, and Ken Goldberg. Sgtn 2.0: Autonomously untangling long cables using interactive perception. *ArXiv*, abs/2209.13706, 2022.
 - [51] Mohit Shridhar, Lucas Manuelli, and Dieter Fox. Cliport: What and where pathways for robotic manipulation. *ArXiv*, abs/2109.12098, 2021.
 - [52] Mohit Shridhar, Lucas Manuelli, and Dieter Fox. Perceiver-actor: A multi-task transformer for robotic manipulation. *ArXiv*, abs/2209.05451, 2022.
 - [53] Aravind Sivakumar, Kenneth Shaw, and Deepak Pathak. Robotic telekinesis: Learning a robotic hand imitator by watching humans on youtube. *RSS*, 2022.
 - [54] Christian Smith, Yiannis Karayiannidis, Lazaros Nalpantidis, Xavi Gratal, Peng Qi, Dimos V. Dimarogonas, and Danica Kragic. Dual arm manipulation - a survey. *Robotics Auton. Syst.*, 60:1340–1353, 2012.
 - [55] Kihyuk Sohn, Honglak Lee, and Xinchen Yan. Learning structured output representation using deep conditional generative models. In *NIPS*, 2015.
 - [56] srcteam. Shadow teleoperation system plays jenga, Mar 2021. URL <https://www.youtube.com/watch?v=7K9brH27jvM>.
 - [57] srcteam. How researchers are using shadow robot’s technology, Jun 2022. URL <https://www.youtube.com/watch?v=p36fYIoTD8M>.
 - [58] srcteam. Shadow teleoperation system, Jun 2022. URL

<https://www.youtube.com/watch?v=cx8eznfDUJA>.

- [59] Simon Stepputtis, Maryam Bandari, Stefan Schaal, and Heni Ben Amor. A system for imitation learning of contact-rich bimanual manipulation policies. *2022 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 11810–11817, 2022.
- [60] Priya Sundaresan, Jennifer Grannen, Brijen Thananjeyan, Ashwin Balakrishna, Jeffrey Ichnowski, Ellen R. Novoseller, Minh Hwang, Michael Laskey, Joseph Gonzalez, and Ken Goldberg. Untangling dense non-planar knots by learning manipulation features and recovery policies. *ArXiv*, abs/2107.08942, 2021.
- [61] Gokul Swamy, Sanjiban Choudhury, J. Andrew Bagnell, and Zhiwei Steven Wu. Causal imitation learning under temporally correlated noise. In *International Conference on Machine Learning*, 2022.
- [62] Naftali Tishby and Noga Zaslavsky. Deep learning and the information bottleneck principle. *2015 IEEE Information Theory Workshop (ITW)*, pages 1–5, 2015.
- [63] Emanuel Todorov, Tom Erez, and Yuval Tassa. Mujoco: A physics engine for model-based control. *2012 IEEE/RSJ International Conference on Intelligent Robots and Systems*, pages 5026–5033, 2012.
- [64] Stephen Tu, Alexander Robey, Tingnan Zhang, and N. Matni. On the sample complexity of stability constrained imitation learning. In *Conference on Learning for Dynamics & Control*, 2021.
- [65] Ashish Vaswani, Noam M. Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need. *ArXiv*, abs/1706.03762, 2017.
- [66] Solomon Witznitzer, Luke Schmitt, and Matt Trossen. interbotix_ros_manipulators. URL https://github.com/Interbotix/interbotix_ros_manipulators.
- [67] Fan Xie, A. M. Masum Bulbul Chowdhury, M. Clara De Paolis Kaluza, Linfeng Zhao, Lawson L. S. Wong, and Rose Yu. Deep imitation learning for bimanual robotic manipulation. *ArXiv*, abs/2010.05134, 2020.
- [68] Andy Zeng, Peter R. Florence, Jonathan Tompson, Stefan Welker, Jonathan Chien, Maria Attarian, Travis Armstrong, Ivan Krasin, Dan Duong, Vikas Sindhwani, and Johnny Lee. Transporter networks: Rearranging the visual world for robotic manipulation. In *Conference on Robot Learning*, 2020.
- [69] Tianhao Zhang, Zoe McCarthy, Owen Jow, Dennis Lee, Ken Goldberg, and P. Abbeel. Deep imitation learning for complex manipulation tasks from virtual reality teleoperation. *2018 IEEE International Conference on Robotics and Automation (ICRA)*, pages 1–8, 2017.
- [70] Allan Zhou, Moo Jin Kim, Lirui Wang, Peter R. Florence, and Chelsea Finn. Nerf in the palm of your hand: Corrective augmentation for robotics via novel-view synthesis. *ArXiv*, abs/2301.08556, 2023.
- [71] Áron Horváth, Eszter Ferentzi, Kristóf Schwartz, Nina Jacobs, Pieter Meyns, and Ferenc Köteles. The measurement of proprioceptive accuracy: A systematic literature

review. *Journal of Sport and Health Science*, 2022. ISSN 2095-2546. doi: <https://doi.org/10.1016/j.jshs.2022.04.001>. URL <https://www.sciencedirect.com/science/article/pii/S2095254622000473>.

附录

A. ALOHA 与先前遥操作设置的比较

在图 9 中，我们展示了 ALOHA 能够完成的更多遥操作任务。我们强调所有物体均直接取自真实世界，未经任何修改，以证明 ALOHA 在现实生活场景中的通用性。ALOHA 利用主从机器人之间的动觉相似性，通过关节空间映射进行遥操作。主从设计选择至少可以追溯到 1953 年，当时中央研究实验室（Central Research Laboratories）建造了用于处理危险材料的遥操作系统 [27]。近年来，RE2 等公司 [3] 也构建了采用关节空间映射的高度灵巧遥操作系统。ALOHA 与这些先前系统相似，但显著受益于低成本执行器和机器人臂的最新进展。它使我们能够以低得多的成本实现类似水平的灵巧性，且无需专用硬件或专家组装。接下来，我们将 ALOHA 的成本与近期遥操作系统进行比较。DexPilot[21] 利用人手图像流控制灵巧手。它配备 4 台校准的英特尔实感（Intel Realsense）相机来捕获人手的点云，并将姿态重定向到 Allegro 手。Allegro 手随后安装到 KUKA LBR iiwa7 R800 上。DexPilot 能够完成令人印象深刻的任务，例如从钱包中取钱、打开花生酱罐以及在 NIST 1 号板上进行插入任务。我们估计该系统单臂加手的成本约为 10 万美元。更近期的工作如 Robotic Telekinesis[53, 6, 45] 试图通过使用单个 RGB 相机检测手部姿态并利用学习技术进行重定向来降低 DexPilot 的成本。虽然传感成本大幅降低，但机器人手和臂的成本仍然很高：灵巧手具有更多自由度，自然更昂贵。移动手还需要至少 2 公斤负载的工业臂，进一步推高价格。我们估计这些系统单臂加手的成本约为 1.8 万美元。最后，Shadow 遥操作系统是用于遥操作两只灵巧手的双臂系统。两只手均安装到 UR10 机器人上，手部姿态通过追踪手套或触觉手套获得。该系统在所有前述工作中能力最强，得益于其双臂设计。然而，它也是最昂贵的，至少 40 万美元。相比之下，ALOHA 是一种双臂设置，成本为 1.8 万美元（添加相机等可选附件后为 2 万美元）。将灵巧手简化为平行夹爪使我们能够使用轻量且低成本的机器人，这些机器人更灵活且需要更少的维护。最后，我们将 ALOHA 的能力与先前系统进行比较。我们选择能力最强的系统作为参考：Shadow 遥操作系统 [5]，其成本是 ALOHA 的 10 倍以上。具体而言，我们找到了三个演示视频 [56, 57, 58]，其中包含 Shadow 遥操作系统的 15 个示例用例，并试图使用 ALOHA 重现它们。任务包括玩“啤酒乒乓”、“叠叠乐”和魔方，使用簸箕和刷子，拧开水瓶，倒出液体，解开魔术贴扎带，拿起鸡蛋和灯泡，插入和拔出 USB、RJ45，使用

移液、书写、旋开铝制外壳以及保定球的掌内旋转。我们能够 在相似物体和相近时间内重现 15 项任务中的 14 项。由于我们的装置不具备人手，无法重现保定球掌内旋转任务。

B. 示例图像观测

我们在图 10 中展示了 6 项真实任务在策略执行期间采集的示例图像观测。从左至右，4 幅图像分别来自顶部相机、前部相机、左腕和右腕。顶部和前部相机为静态，而腕部相机随机器人移动，提供夹爪的详细视图。我们还将前部相机旋转 90 度以捕捉更多垂直空间。所有相机的焦距固定，并开启自动曝光以适应光照变化。所有相机以 480×640 和 30fps 的速率传输图像。

C. 详细架构图

我们在图 11 中给出了更详细的架构图。在训练时，我们首先采样 RGB 图像和关节位置的元组，以及相应的动作序列作为预测目标（步骤 1：采样数据）。然后，我们使用黄色显示的 CVAE 编码器推断风格变量 z （步骤 2：推断 z ）。编码器的输入包括：1) [CLS] 标记，由随机初始化的学习权重组成；2) 嵌入的关节位置，即通过线性层将关节位置投影到嵌入维度；3) 嵌入的动作序列，即通过另一个线性层将动作序列投影到嵌入维度。这些输入构成一个 $(k + 2) \times embedding_dimension$ 序列，并由变换器编码器处理。我们只取第一个输出，它对应于 [CLS] 标记，并使用另一个线性网络预测 z 分布的均值和方差，将其参数化为对角高斯分布。通过重参数化获得 z 的样本，这是一种允许在采样过程中进行反向传播的标准方法，从而使编码器和解码器能够联合优化 [33]。接下来，我们尝试从 CVAE 解码器（即策略）获得预测动作（步骤 3：预测动作序列）。对于每个图像观测，首先由 ResNet18 处理以获得特征图，然后展平得到特征序列。这些特征通过线性层投影到嵌入维度，并添加二维正弦位置嵌入以保留空间信息。来自每个相机的特征序列随后被拼接，用作变换器编码器的输入。另外两个输入是关节位置和 z ，它们也分别通过两个线性层投影到嵌入维度。变换器编码器的输出随后在变换器解码器的交叉注意力层中同时用作“键”和“值”，该解码器根据编码器输出预测动作序列。第一层的“查询”是固定的正弦嵌入。在测试时，CVAE 编码器（黄色显示）被丢弃，CVAE 解码器用作策略。




图 9：使用 ALOHA 的遥操作任务示例。我们在项目网站上提供了视频。

传入的观测（图像和关节）以与训练期间相同的方式输入模型。唯一区别在于 z ，它表示我们希望策略引发的动作序列的“风格”。我们只需将 z 设为零向量，即训练期间使用的单位高斯先验的均值。因此，给定观测，策略的输出始终是确定性的，有利于策略评估。

D. 实验细节与超参数

我们仔细调整了基线，并在表三、四、五、六、七中列出了所使用的超参数。对于 BeT，我们发现将历史长度从 10（原论文中的值）增加到 100 可以显著提升性能。较大的隐藏维度通常也有帮助。对于 VINN，在检索最近邻时使用的 k 值根据最低验证损失自适应选择，与原论文一致。我们还发现，在没有动作分块的情况下，除了视觉特征相似度之外，使用关节位置差异也能提升性能，此时在检索动作时状态权重 = 10。然而，我们发现这在动作分块的情况下会损害性能，因此在动作分块实验中将状态权重设为 0。

E. 用户研究细节

我们与 6 名参与者进行了用户研究，参与者均为计算机科学研究研究生，其中男性 4 名、女性 2 名，年龄在 22 至 25 岁之间。其中 3 名参与者具有相关经验。

使用虚拟现实（VR）控制器遥操作机器人，另外 3 名参与者此前没有遥操作经验。所有参与者均未使用过 ALOHA。为实现 5Hz 版本的 ALOHA，本文以 5Hz 频率读取主机器人状态，在关节空间中进行插值，并以 50Hz 频率将插值后的位置发送至机器人。本文选择强调高精度率与闭环视觉反馈的任务。文中包含所用物体的图像。

图 12. 对于穿线式扎带，孔尺寸为 4 毫米 × 1.5 毫米，扎带尺寸为 0.8 毫米 × 3.5 毫米，带有尖头。它最初平放在桌面上，操作者需要用一只夹爪将其抬起，在空中抓住另一端，然后协调双手将扎带的一端插入另一端的孔中。对于拆叠杯任务，我们使用两个一次性塑料杯，叠放时它们之间有 2.5 毫米的间隙。遥操作者需要抓住上层杯子的边缘，然后要么摇晃使其分离，要么借助另一只夹爪的帮助。在用户研究中，我们随机化操作者尝试每个任务的顺序，以及他们首先使用 50 赫兹还是 5 赫兹控制器。我们还在桌子中心周围随机化物体的初始位置。对于每种设置，操作者有 2 分钟时间适应，随后进行 3 次连续的任务尝试，并记录持续时间。

F. 局限性

我们现在讨论 ALOHA 硬件和 ACT 策略学习的局限性。




图 10: 5 个真实世界任务的图像观测示例。4 列分别为 [顶部相机、前部相机、左腕相机、右腕相机]。我们将前部相机旋转 90 度以捕捉更多垂直空间。


硬件局限性。在硬件方面，ALOHA 在需要双手多指的任务上存在困难，例如打开带有按压片的儿童安全药瓶。要打开瓶子，一只手需要握住瓶子并向下按压片，另一只手拧开盖子。ALOHA 在需要较大力量的任务上也存在困难，例如提起重物、拧开密封的水瓶，或打开压得很紧的记号笔帽。这是因为低成本电机无法产生足够的扭矩来支持这些操作。需要指甲的任务对 ALOHA 来说也很困难，尽管我们将夹爪边缘设计得很薄。例如，我们无法在包装胶带粘到自身时掀起其边缘，或打开铝制汽水罐。

策略学习局限性。在软件方面，我们报告了所有 2 个 ACT 未能学习到行为且我们尝试过的任务。第一个是拆开糖果包装。步骤包括从桌上拿起糖果，拉扯其两端，并撬开包装以露出糖果。我们收集了 50 次演示来训练 ACT 策略。在包含 10 次试验的初步评估中，策略拿起糖果的成功率为 10/10，拉扯两端的成功率为 8/10，而拆开糖果的成功率为 0/10。我们将失败归因于感知困难和数据不足。具体来说，在拉扯糖果两侧之后，


用于撬开糖果包装的接缝可能出现在糖果周围的任何位置。在演示收集过程中，即使是人类也难以辨别。操作员需要通过观察包装上印刷的图形并寻找不连续处来判断。我们不断观察到策略试图在不存在的接缝处进行剥离。为了更好地跟踪进展，我们尝试了另一种评估方式，即对每颗糖果进行 10 次试验，并对 5 颗糖果重复此过程。对于该协议，我们的策略成功拆开了 3/5 的糖果。ACT 难以完成的另一个任务是打开平放在桌上的小自封袋。右夹爪需要先将其拿起，调整位置以便左夹爪能牢固地抓住拉动区域，随后右手抓住拉动区域的另一侧，并将其拉开。我们使用 50 次演示训练的策略能够持续地拿起袋子，但在执行后续 3 个空中操作步骤时存在困难。我们假设袋子难以感知，此外，拿起位置的微小差异会影响袋子的变形方式，并导致拉动区域最终位置的巨大差异。我们认为预训练、更多数据和更好的感知是解决这些极其困难任务的有前景的方向。

Training


Step 1: sample data



Step 2: infer z



Step 3: predict action sequence



Testing




图 11：基于变换器的动作分块（ACT）的详细架构。



图 12: 用于用户研究的扎带和杯子。

learning rate	1e-5
batch size	8
# encoder layers	4
# decoder layers	7
feedforward dimension	3200
hidden dimension	512
# heads	8
chunk size	100
beta	10
dropout	0.1

表 III: ACT 的超参数。

learning rate	3e-4
batch size	128
epochs	100
momentum	0.9
weight decay	1.5e-6

表 IV: BYOL 的超参数, BYOL 是 VINN 和 BeT 的特征提取器。

learning rate	1e-4
batch size	64
# layers	6
# heads	6
hidden dimension	768
history length	100
weight decay	0.1
offset loss scale	1000
focal loss gamma	2
dropout	0.1
discretizer #bins	64

表 V: BeT 的超参数。

k (nearest neighbour)	adaptive
state weight	0 or 10

表 VI: VINN 的超参数。

learning rate	1e-5
batch size	2
ViT dim head	32
ViT window size	7
ViT mbconv expansion rate	4
ViT mbconv shrinkage rate	0.25
ViT dropout	0.1
RT-1 depth	6
RT-1 heads	8
RT-1 dim head	64
RT-1 action bins	256
RT-1 cond drop prob	0.2
RT-1 token learner num output tokens	8
weight decay	0
history length	6

表 7: RT-1 的超参数。