

探索机器人视觉-语言-动作模型的对抗脆弱性

Taowen Wang^{1*}, Cheng Han^{2*}, James Liang^{3*},
Wenhao Yang⁴, Dongfang Liu^{1†}, Luna Xinyu Zhang^{1‡}, Qifan Wang⁵,
Jiebo Luo⁶, Ruixiang Tang^{7†}

¹Rochester Institute of Technology, ²University of Missouri - Kansas City,
³U.S. Naval Research Laboratory, ⁴Lamar University, ⁵Meta AI,
⁶University of Rochester, ⁷Rutgers University

摘要

近年来,在机器人领域,视觉-语言-动作(VLA)模型已成为一种变革性方法,使机器人能够通过端到端学习框架整合视觉与语言输入来执行复杂任务。尽管这些模型能力显著,但也引入了新的攻击面。本文系统评估了它们的鲁棒性。考虑到机器人执行的独特需求,我们的攻击目标针对机器人系统固有的空间与功能特性。具体而言,我们引入了两种利用空间基础来破坏机器人动作稳定性的非定向攻击目标,以及一种操纵机器人轨迹的定向攻击目标。此外,我们设计了一种对抗补丁生成方法,在相机视野内放置一个小型彩色补丁,从而在数字和物理环境中有效实施攻击。我们的评估显示任务成功率显著下降,在一系列模拟机器人任务中降幅高达100%,凸显了当前VLA架构中的关键安全缺口。通过揭示这些脆弱性并提出可操作的评估指标,我们推进了对基于VLA的机器人系统安全性的理解与增强,强调了在物理世界部署之前持续开发鲁棒防御策略的必要性¹。




图 1. 恶意操纵引发的对抗性漏洞。(A). 机器人任务执行中对抗性威胁的示意图。(B). 所提方法生成的语义丰富对抗补丁示例。(C). 不同攻击方案 (UADA、UPA 和 TMA) 的失败率比较。

1. 引言

“第一指令: 机器人不得伤害人类, 或因不作为而允许人类受到伤害。”— 芬奇 [63]

*Equal contribution.

†通讯作者。‡工作完成于 Luna Xinyu Zhang 在 RIT 实习期间。1 项目主页。

在电影《芬奇》中,故事设定于后末日未来,一个智能机器人应对复杂主题,凸显了与其人类主人交互安全性的重要性。这一曾经属于推测的描绘,如今随着大型视觉语言模型 (Large Vision Language Models, LVLMs) [58, 67] 的兴起而日益成为可能,该模型能够无缝解读视觉与语言上下文。这一潜力的显著实现可见于视觉-语言-动作 (Vision-Language-Action, VLA) 模型 [14, 29, 61, 62], 该模型将 LVLMs 集成到机器人系统中,实现端到端学习,涵盖高层轨迹规划与低层机器人动作控制。虽然 VLA 模型展示了迈向通用机器人智能的有前景的一步,

但它们也引入了在很大程度上尚未被探索的潜在漏洞。鉴于此，本文开创性地认识到迫切需要研究与基于 VLA 的机器人系统相关的新攻击面。为更深入地洞悉这些漏洞，我们分析了基于 VLA 的模型和一般机器人操作，突出了对设计有效对抗攻击至关重要的两个关键特征。首先，为机器人系统创建攻击目标需要考虑机器人运动固有的物理动力学和约束。在这种情况下，传统对抗攻击往往无法在预期动作上产生显著偏差，因为它们忽视了这些约束。其次，VLA 模型生成的控制信号作为 K 类预测的时间序列（见 § 3.1），因此必须设计利用这些序列内时间依赖性的攻击，以对机器人行为造成实质性破坏。实现既在数字仿真中又在真实环境中有效的攻击仍然至关重要且具有挑战性。为应对这些挑战，本文通过开发专门的攻击目标和设计有效的攻击方法，加剧了对基于 VLA 系统的对抗威胁。具体而言，我们构建了一个动作

差异目标 旨在最大化基于视觉-语言-动作（VLA）机器人系统中的动作差异。该策略确保在每个决策点，机器人的行为都可能偏离最优轨迹。此外，我们引入了几何感知目标，该目标考虑机器人在三维空间中的运动，具有三个自由度。通过优化对抗方向与真实方向之间的余弦相似度，我们诱导机器人的运动方向偏离其预定路径，从而增加任务失败的可能性。为了实现这些攻击目标，我们开发了简单而有效的基于补丁的攻击方法，针对基于 VLA 的机器人系统。这种方法能够在数字和物理环境中实施对抗攻击，揭示了基于 VLA 系统内部的重大漏洞。总体而言，这些创新带来了若干重要贡献：❶ 本文对基于 VLA 的机器人系统中的漏洞进行了开创性的全面分析，这是一种利用生成式基础模型训练通用机器人策略的新范式。我们揭示了对抗攻击的关键威胁，强调了在实际部署前增强鲁棒性的迫切需求；❷ 据我们所知，我们是首个针对强大 VLA 模型定义特定攻击目标并采用简单对抗补丁进行攻击的工作（见 § 3）。这为研究界探索类似并发生成式基础模型中的系统性故障提供了宝贵见解；❸ 我们在模拟和真实环境中对四个不同的机器人任务进行了严格评估，观察到任务失败率分别显著上升了 100% 和 43%。这凸显了我们攻击策略的有效性（见 § 4.3）。

不同的机器人任务，观察到任务失败率分别显著上升了 100% 和 43%。这凸显了我们攻击策略的有效性（见 § 4.3）。

2. 相关工作

2.1. 人工智能驱动的通用机器人

开发通用机器人 [4, 12, 22, 30, 49] 要求模型不仅能处理多样化的交互，还需在非结构化环境中保持鲁棒性。早期智能机器人 [40, 41, 43, 44, 71] 通常依赖基于规则的方法，仅在受控环境中有效，且新任务需要大量重新编程。深度学习 [17, 26, 32, 45] 和强化学习 [1, 52, 60] 的出现将这一范式转变为通过数据驱动流程进行适应，提升了机器人的多功能性并减少了手动重新配置。近期研究 [5, 42, 46] 进一步推动了大视觉语言模型（Large Vision Language Models, LVLMs）作为通用机器人关键使能技术的发展与潜力，展示了在多种场景下有前景的泛化能力 [13, 20, 27, 33, 53, 72]。其中一个显著例子是 OpenVLA [29]，它集成了双视觉编码器和预训练大语言模型，通过指令跟随实现观测到动作的能力 [8, 28, 37, 38, 58, 70]。通过对齐视觉和文本语义，OpenVLA 促进了复杂场景理解和端到端动作生成，在执行未见过的任务指令时展现出令人印象深刻的泛化能力。

2.2. 机器人中的对抗攻击

对抗攻击是评估模型脆弱性的关键工具，尤其在机器人领域，模型在动态的真实世界环境中运行。传统的基于梯度的像素级攻击 [15, 18, 35, 39, 50, 59] 利用模型梯度计算恶意扰动，在数字环境中取得高攻击成功率。对于物理世界攻击，基于补丁的方法 [3, 6, 48, 64, 65] 通过引入物理可实现的扰动，在角度或光照变化等不同条件下保持有效性，为实际应用提供了实用的替代方案，使其高度适用于机器人系统。因此，考虑到基于 VLA 的模型使机器人能够在真实场景中执行任务，本文采用基于补丁的攻击策略。VLA 模型 [11, 21, 53] 耦合视觉和语言模态以实现感知-动作对齐。视觉输入的连续高维特性 [39, 47, 51] 使其成为对抗扰动最可能的目标，因为攻击者可以以难以察觉的方式微妙地改变视觉数据 [2, 7, 54]。因此，本文对视觉模态施加攻击，以在不同环境中实现稳健操控。据我们所知，本文




图 2. 整体对抗框架。机器人捕获输入图像，通过视觉语言模型处理以生成表示动作的标记，然后使用动作去标记器进行离散区间预测。该模型通过聚焦于各种差异和几何结构的对抗目标（即 UADA、UPA、TMA）进行优化。前向传播以黑色显示，反向传播以粉色高亮。这些目标旨在最大化误差并最小化任务性能，视觉上强调三维空间操控，并专注于在任务执行期间（例如拾取罐子）生成对抗扰动 δ 。

本研究是最早尝试为视觉语言动作模型正式定义对抗目标的成果之一，旨在通过模型的几何约束（例如视觉输入中的空间依赖关系）和架构细节（例如跨模态信息整合）来针对对抗鲁棒性方面的不足。

3. 方法论

本节首先在 3.1 节回顾视觉-语言-动作模型的核心算法原理，作为对抗方案设计的基础。随后在 3.2 节和 3.3 节分别提出两种非定向对抗攻击：非定向动作差异攻击和非定向位置感知攻击。在 3.4 节进一步引入定向操纵攻击，旨在引导机器人执行特定的错误动作。最后在 3.5 节介绍归一化动作差异度量。整体框架如图 2 所示。

3.1. 预备知识

视觉-语言-动作模型 [29, 72]（见图 2）构建于大语言模型之上，并集成了视觉编码器，使机器人能够解读人类指令并处理来自摄像头的视觉输入，从而执行上下文感知的动作。视觉-语言-动作模型 [29, 34, 72] 通常通过离散化机器人动作，将连续动作预测抽象为分类问题。具体而言，它们首先将连续概率离散化为类别标签 $y = \arg \max \mathcal{F}(x)$ ，其中 $\mathcal{F}(\cdot)$ 为视觉-语言-动作模型。随后，动作去标记器生成动作 $A = DT(y)$ 。通过将动作值归类为离散类别标签，模型将连续概率输出转换为离散信号，这种简化有助于加快收敛速度并缩短训练时间，且常用于基于视觉-语言-动作的模型 [29, 34, 72]。

本文聚焦于一个七自由度（DoFs）机械臂 [19]。每一步动作由 7 个自由度组成，在三维笛卡尔空间中具有明确的物理意义，表示为：

$$A = [\Delta P_x, \Delta P_y, \Delta P_z, \Delta R_x, \Delta R_y, \Delta R_z, \text{gripper}], \quad (1)$$

其中 $\Delta P_{x,y,z}$ 和 $\Delta R_{x,y,z}$ 分别表示沿 x、y、z 轴的相对位置和旋转变化，并在每个自由度的动作边界 $[y_{\min}^i, y_{\max}^i]$ [29] 内离散为 256 个均匀区间。gripper 状态为二进制，表示其开合状态。这种控制设计针对对抗攻击提出了独特挑战，因为精细划分的区间导致相邻区间之间的动作差异极小（e.g., $\pm 0.007/\text{区间}$ ）。这意味着即使攻击将分类偏移到相邻区间，所产生的动作差异对实际性能的影响也微乎其微。

3.2. 无目标动作差异攻击

为了加剧动作差异，本文提出无目标动作差异攻击（UADA），旨在最大化机器人动作的偏差。该攻击基于以下观察：较大的机器人动作通常与剧烈的物理运动相关，进而可能放大现实世界中的潜在危险 [23–25]。对于 UADA，攻击目标是 7 个自由度中的一个或多个组合，定义为 $y_{gt}^I = \{y_{gt}^i | i \in [1, \dots, 7]\}$ 。为了定义 UADA 的目标，本文首先确定最远动作 y_{adv}^i ，该动作最大化与第 i 个自由度真实动作 y^i 的差异。对于每个自由度，该动作对应于其自身的动作边界 $[y_{\min}^i, y_{\max}^i]$ ，表示为：

$$y_{adv}^i = \begin{cases} y_{\max}^i, & \text{if } |y_{\max}^i - y_{gt}^i| \geq |y_{\min}^i - y_{gt}^i| \\ y_{\min}^i, & \text{otherwise} \end{cases} \quad (2)$$

本文没有直接使用 y_{adv}^i 作为错误分类目标，而是引入软攻击目标来捕捉动作之间的差异，确保梯度优化平滑和攻击性能稳定。具体而言，由于区间标签中包含物理动作幅度信息，本文使用归一化区间标签 $y_{bins}^i = [\frac{1}{bins}, \dots, 1]$ 对输出概率 $\mathcal{F}(x)_{bins}^i \in \mathcal{R}^{1 \times bins}$ 进行重新加权，其中 $\lfloor y_{bins}^i \rfloor$ 和 $\lceil y_{bins}^i \rceil$ 分别对应于 y_{min}^i 和 y_{max}^i 的归一化值。重新加权过程定义为：

$$y_{soft}^i = \sum_{bins=1}^n \mathcal{F}(x + \delta)_{bins}^i \otimes y_{bins}^i, \quad (3)$$

其中 $\otimes$ 表示哈达玛积， δ 是对抗补丁， y_{soft}^i 表示第 i 个自由度的软动作。最终，UADA 的目标是最小化软动作与最远动作之间的差异，即：

$$\mathcal{L}_{UADA} = \mathbb{E}_{(x,y) \sim \mathcal{X}} \sum_i^I (y_{soft}^i - y_{adv}^i)^2, \quad (4)$$

UADA 定义了针对机器人动作空间攻击的目标函数 $\mathcal{L}_{UADA}$ ，使对抗补丁能够对任务性能造成显著且持久的破坏。

3.3. 无目标位置感知攻击

我们通过考虑视觉-语言-动作模型中的位置动态，并行探索非定向对抗攻击。在典型任务执行中，末端执行器朝指定目标的精确且定向的运动至关重要，动作在三维空间中映射。位置自由度 $A^p = [\Delta P_x, \Delta P_y, \Delta P_z]$ 封装了三维空间内的定向运动，以实现有效的机器人控制。认识到 $A^p = DT(y^p)$ 在控制末端执行器路径中的重要性，我们引入一种位置感知攻击来破坏预期的运动轨迹。这类对抗脆弱性在很大程度上尚未被探索，但对任务失败具有重要影响：攻击目标可以通过引入定向扰动使末端执行器偏离其预期路径，放大误差并造成显著的轨迹扭曲。形式上，我们将非定向位置感知攻击目标定义为：

$$\mathcal{L}_{UPA} = \mathbb{E}_{(x,y) \sim \mathcal{X}} \left[\alpha \frac{y_{adv}^p \cdot y^p}{\|y_{adv}^p\| \|y^p\|} + \beta \frac{1}{\|y_{adv}^p - y^p\|_2} \right], \quad (5)$$

其中 α 和 β 是平衡扰动方向性与幅度的超参数。通过将几何感知融入我们的攻击中，该方法生成的扰动即使调整极小，也会在机器人轨迹中引起累积偏差。 L_2 -归一化 $\|\cdot\|_2$ 进一步加剧这些偏差，使攻击高度有效且具有破坏性。

3.4. 定向操纵攻击

除了上述非定向攻击外，我们还通过定向策略探索视觉-语言-动作模型的对抗脆弱性。该攻击旨在直接误导模型预测特定轨迹，导致精确的改变。我们设计此攻击是因为定向改变可以驱动恶意行为或引发任务失败。定向操纵攻击的目标是：

$$\mathcal{L}_{TMA} = \mathbb{E}_{(x,y) \sim \mathcal{X}} [CE(\mathcal{F}(x + \delta)^I, y_T^I)], \quad (6)$$

其中 $y_T^I = \{y_T^i = t | i \in [1, \dots, 7], t \in [y_{min}^i, y_{max}^i]\}$ 表示对抗目标； $CE(\cdot, \cdot)$ 表示交叉熵损失，用于衡量对抗扰动下的预测状态与期望目标状态之间的误差。通过连续时间步将机器人引向对抗目标，我们的方法操纵轨迹并削弱任务性能，最终导致预期操作的严重中断。此外，操纵任何单个自由度或其组合也可能严重损害任务成功，因为一个维度中的误差在执行过程中往往会随时间传播和放大（见图 3）。

3.5. 度量：归一化动作差异

为评估对抗补丁的潜在物理影响，本文引入归一化动作偏差（Normalized Action Discrepancy, NAD）作为动作层面偏差评估的细粒度度量。NAD 作为任务层面粗粒度失败率（Failure Rate, FR）的补充测度，提供动作执行过程中偏差的详细分析。为定义 NAD，首先确定最大动作偏差 d_{max}^i ，表示第 i 个自由度允许范围内可能出现的最大偏差。该值通过计算真值 y_{gt}^i 与其动作边界 $[y_{min}^i, y_{max}^i]$ 之间的 $L1$ 距离得到：

$$d_{max}^i(y) = \max [DT(|y_{gt}^i - y_{min}^i|), DT(|y_{gt}^i - y_{max}^i|)]. \quad (7)$$

随后计算实际动作偏差 $d_{applied}^i(x, y) = |DT(\mathcal{F}(x)^i) - DT(y_{gt}^i)|$ ，以衡量模型输出与真值之间的偏差。将 NAD 定义为 $d_{applied}^i$ 与 d_{max}^i 之间的漂移比：

$$NAD = \frac{1}{I} \sum_i^I \frac{d_{applied}^i}{d_{max}^i}, \quad (8)$$

其中 $I \in [1, \dots, 7]$ 表示单个或多个自由度的组合。通过这种方式，NAD 提供动作偏差的归一化测度，使得在不同自由度上对对抗影响进行一致评估成为可能。

4. 实验

本节首先在 § 4.1 中详细介绍对抗框架与基线方法的实现。随后，




图 3. 针对 OpenVLA-7B [29] 和 OpenVLA-7B-LIBERO [29] 在 UADA、UPA 和 TMA 目标下的对抗脆弱性定性结果。可视化良性 $\bullet$ 与对抗 $\bullet$ 场景在每个时间步的整体三维轨迹和二维轨迹，以比较生成的对抗补丁对轨迹的影响。非目标轨迹 $\bullet$ 在 UADA 任务中可视化。所有轨迹以 $\blacktriangle$ 起始，并绘制成功终点，标记为 $\star$ 。

在 § 4.2 中概述实验设置，并在仿真与物理世界场景 (§ 4.3) 中呈现定量与定性结果。随后进行诊断实验 (§ 4.4) 以分析关键组件的影响。此外，在 § 4.5 中评估方法对各种防御机制的鲁棒性，最后在 § 4.6 中全面的系统性讨论。

4.1. 实现细节

本文提出的对抗补丁攻击流程的实现细节如算法 1 所示。我们引入了两项关键修改以增强生成补丁的训练稳定性。

内循环。遵循先前工作 [39]，我们在第 4 行的每次迭代中添加 k 个内循环优化步骤，旨在降低数据方差并确保更新更加一致。

几何变换。为了提升攻击在真实场景下的鲁棒性，我们在第 6 行采用随机几何变换 $\mathcal{T}[(\cdot), (sh_x, sh_y, \theta)]$ ，其中

Algorithm 1: Adversarial Patch Attack.

- 1: **Input:** $\mathcal{X}$: dataset; δ : patch; $\mathcal{L}_o$: attack objective; $\mathcal{F}$: VLA model; $\mathcal{T}(\cdot)$: transformations; ϕ, ψ : transformation parameters; T : attack steps; k : inner-loop steps.
- 2: **Initialize:** $\delta \sim \mathcal{U}[0, 1)$, $\mathcal{L}_o \in \{\mathcal{L}_{\text{UADA}}, \mathcal{L}_{\text{UPA}}, \mathcal{L}_{\text{TMA}}\}$
- 3: **for** $i = 1, 2, \dots, T$ **do**
- 4: **for** $i = 1, 2, \dots, k$ **do**
- 5: $sh_x, sh_y \sim \mathcal{U}(-\phi, \phi)$, $\theta \sim \mathcal{U}(-\psi, \psi)$
- 6: $y_{\text{pred}} \leftarrow \mathcal{F}[\mathcal{T}((x + \delta), (sh_x, sh_y, \theta))]$
- 7: $\delta \leftarrow \frac{\partial \mathcal{L}_o}{\partial \delta} \{ \triangleright \text{Update} \}$
- 8: **end for**
- 9: **end for**

affine and rotation transformations [3] as:

$$\mathcal{T}[(\cdot), (sh_x, sh_y, \theta)] = \begin{bmatrix} 1 & sh_y \\ sh_x & 1 \end{bmatrix} \cdot \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}, \quad (9)$$

其中 $sh_x, sh_y \sim \mathcal{U}(-\phi, \phi)$ 为剪切因子, $\theta \sim \mathcal{U}(-\psi, \psi)$ 表示旋转角度, 两者均在内循环优化步骤 k 期间从均匀分布中采样。无目标操纵攻击 (Untargeted Manipulation Attack, UMA) 基线。作为一项开创性工作, 我们未能找到可直接比较的基线方法。因此, 我们采用对抗学习领域的先前工作作为基线方法之一 [55]。该攻击旨在误导分类器; 我们将其集成到本文框架中, 得到以下目标函数:

$$\mathcal{L}_{\text{UMA}} = -\mathbb{E}_{(x,y) \sim \mathcal{X}}[CE(\mathcal{F}(x + \delta)^I, y_{gt}^I)]. \quad (10)$$

通过最小化负交叉熵损失, 该攻击将预测动作推离真实动作。

随机噪声基线。我们生成随机噪声补丁作为额外的基线, 代表一种无任何学习对抗意图的非结构化干预。具体而言, 噪声从高斯分布 $\mathcal{N}(0, 1)$ 中采样, 并在与所提攻击相同的设置下进行评估。

4.2. 实验设置

数据集。我们在 BridgeData V2 [57] 和 LIBERO [36] 上对相应的视觉语言动作模型 (VLA) 进行攻击。BridgeData V2 [57] 是一个真实世界数据集, 包含 24 个不同环境和 13 种不同技能, 如抓取、放置和物体重排, 总共有 60,096 条轨迹。LIBERO [36] 是一个仿真数据集, 旨在评估模型在四种不同任务类型 (空间、物体、目标、长程) 上的表现。值得注意的是, LIBERO-Long 结合了多样的物体、布局 and 长程任务, 使其对复杂的多步规划具有挑战性, 因此我们选择 LIBERO-Long 来进行 UADA、UPA 和 TMA 攻击。

受害视觉语言动作模型。在我们的研究中, 我们选择公开可用且当前最有影响力的视觉语言动作模型作为受害模型进行评估。具体而言, 我们关注 OpenVLA 模型的四个变体, 每个变体在 LIBERO 数据集 [36] 的不同任务套件 (即空间、物体、目标、长程) 上独立训练。为了评估我们方法的有效性, 我们使用三种不同的生成设置来制作对抗补丁:

仿真设置 涉及在仿真环境中使用 LIBERO Long 套件和 openvla-7B-libero-long 变体 [29] 训练的模型。物理设置使用在 BridgeData v2 [57] 的真实世界数据上训练的 openvla-7B 模型 [29]。这种方法使我们能够在仿真和真实世界数据上评估我们的方法。随后, 我们在不同任务套件上训练的受害模型 (即 OpenVLA LIBERO 变体) 上评估生成的对抗补丁的性能, 以严格证明我们方法的鲁棒性和有效性。这些模型使用不同的数据源和任务目标进行训练。

机器人配置 (真实世界环境)。针对真实世界任务, 本文采用由配备机器人手爪 (Robotiq Hand-E Gripper) 的优傲机器人 (Universal Robots UR10e) 组成的机器人系统, 以提供七自由度运动。感知系统包括一台固定位置、采用肩部视角的彩色网络摄像头。

Evaluation Details. To assess the effectiveness and robustness of our methods, we conduct experiments on the LIBERO dataset [36]. Each suite consists of 10 tasks, with each task executed for 50 trials, resulting in a total of 500 rollouts, following Kim et al. [29]. For reproducibility, we carefully select patch paste locations for each suite, ensuring they do not obscure objects or robots in the test environment.

评估度量。关于任务执行评估, 本文以自由机器人学习基准 (LIBERO) 训练数据集中每个任务套件的最大步数作为超时失败条件, 以降低计算开销。此外, 基于自由机器人学习基准 (LIBERO) 中引入的成功率 (Success Rate, SR) 概念 [36], 本文采用失败率 (Failure Rate, FR) 作为主要评估度量, 其定义为 $1 - \text{SR}$ 。为进一步量化动作差异, 本文采用归一化动作距离 (Normalized Action Distance, NAD) (见公式 8) 对相应自由度进行非定向攻击, 因为该度量考虑相对距离以量化与最优动作的偏差。归一化动作距离值越高, 表明真值与预测动作之间的差异越大。此外, 本文报告了每个任务套件内各任务失败率的标准差。

4.3. 主要结果

定量结果。对于 UADA 和 UPA, 我们的方法有效放大了动作差异, 从而在提高失败率方面展现出显著的迁移攻击能力 (见表 1a)。具体而言, 在仿真设置中攻击 DoF1 和 DoF 1~3 时, UADA 和 UPA 分别实现了 21.0% 和 14.5% 的 NAD, 显著优于 UMA 场景, 分别提升了 6.9% 和 3.1%。UADA 和 UPA 均能有效干扰机器人执行, 分别达到 100% 和 89.7% 的最大平均失败率。关于物理设置 (见表 1b), 我们的攻击方法展现出强大的可迁移性, 因为在物理环境中生成的对抗补丁显著影响了 LIBERO-X 测试的性能。具体而言, UADA 和 UPA 均生成了具有较大动作差异的恶意动作, 分别为 32.6% (DoF1) 和 26.9% (DoF 1~3), 与 UMA 场景中的 26.7% (DoF1) 和 23.8% (DoF 1~3) 相比, 分别提升了 5.9% 和 3.1%。比较两种设置 (表 1a v.s. 表 1b), 我们观察到 NAD 存在普遍差异 (e.g. 32.6% v.s. UADA 为 21.0%)。这种差异可归因于用于实施攻击的仿真数据集与真实世界数据集之间的根本差异 (Bridge V2 [57] v.s. LIBERO [36])。真实世界数据中变异性的增加, 包括环境复杂性、物体多样性和任务难度, 使机器人在验证数据集中有更多机会产生更大的动作差异。对于 TMA 任务, 我们通过将所有自由度操纵为 0 来评估我们方法的有效性 (i.e., $y_T^i = 0$ 在公式 6 中)。我们的方法在操纵机器人轨迹和提高失败率方面展现出显著的有效性 (见表 2)。具体而言, 当应用于不同的生成设置时, 我们的方法在各项指标上均取得了显著提升

表 1. 非定向结果。我们报告了 LIBERO 仿真中的 FR 和 NAD。* 表示与补丁生成模型和数据集对齐的域内受害者模型和数据集，△ 表示涉及不同受害者模型和数据集的迁移攻击评估（见 § 4.2）。每个任务套件的 FR（↑）以最佳和第二佳突出显示。

Objective	Action(s)	NAD(%)	Victim Model				
			Spatial [△]	Object [△]	Goal [△]	Long*	Avg
Benign	-	-	15.3±10.2%	11.6±10.0%	20.8±12.0%	46.3±18.6%	23.5%
Random Noise	-	-	28.8±24.2%	14.8±7.9%	21.0±15.5%	48.4±14.8%	28.3%
UMA	DoF ₁	14.1	100±0.0%	99.0±3.0%	100±0.0%	100±0.0%	99.8%
	DoF _{1~3}	11.4	100±0.0%	98.8±2.6%	99.0±2.4%	100±0.0%	99.5%
UADA	DoF ₁	21.0	100±0.0%	99.2±2.4%	100±0.0%	100±0.0%	99.8%
	DoF _{1~3}	17.9	100±0.0%	100±0.0%	100±0.0%	100±0.0%	100%
UPA	DoF _{1~3}	14.5	96.2±11.4%	77.8±12.5%	88.0±10.4%	96.8±3.0%	89.7%

Objective	Action(s)	NAD(%)	Victim Model				
			Spatial [△]	Object [△]	Goal [△]	Long [△]	Avg
Benign	-	-	15.3±10.2%	11.6±10.0%	20.8±12.0%	46.3±18.6%	23.5%
Random Noise	-	-	28.8±24.2%	14.8±7.9%	21.0±15.5%	48.4±14.8%	28.3%
UMA	DoF ₁	26.7	89.6±15.3%	60.8±16.8%	64.8±26.8%	80.0±20.8%	73.8%
	DoF _{1~3}	23.8	96.6±6.2%	56.4±20.4%	80.0±20.5%	82.0±17.9%	78.8%
UADA	DoF ₁	32.6	99.2±1.8%	98.8±2.4%	92.6±15.2%	96.6±4.8%	96.8%
	DoF _{1~3}	27.7	100±0.0%	100±0.0%	100±0.0%	100±0.0%	100%
UPA	DoF _{1~3}	26.9	95.6±9.5%	57.0±23.6%	57.2±24.4%	72.8±19.7%	70.7%

(a) 仿真设置。 在 OpenVLA-LIBERO-10 受害者模型上使用 LIBERO-Long 数据集生成对抗补丁，并在 LIBERO-X 上进行评估。

(b) 物理设置。 在 OpenVLA-7b 受害者模型上使用 BV2 数据集生成对抗补丁，并在 LIBERO-X 上进行评估。

表 2. 定向操纵攻击结果。报告了 LIBERO[36] 套件中各任务的失败率（FR，↑）及其标准差。任务套件和自由度的性能分别取平均值，并单独列出最佳值和次佳值。

Targeted DoF(s)	Metric	Simulation (Attacked on OpenVLA-LIBERO-10)					Physical (Attacked on OpenVLA-7b)				
		Spatial [△]	Object [△]	Goal [△]	Long*	Avg	Spatial [△]	Object [△]	Goal [△]	Long [△]	Avg
Benign	FR	15.3±10.2%	11.6±10.0%	20.8±12.0%	46.3±18.6%	23.5%	15.3±10.2%	11.6±10.0%	20.8±12.0%	46.3±18.6%	23.5%
Random Noise	FR	28.8±24.2%	14.8±7.9%	21.0±15.5%	48.4±14.8%	28.3%	28.8±24.2%	14.8±7.9%	21.0±15.5%	48.4±14.8%	28.3%
DoF ₁	FR	100±0.0%	97.8±3.0%	100±0.0%	100±0.0%	99.5%	90.6±19.9%	36.6±18.1%	61.0±21.7%	86.4±12.7%	68.7%
DoF ₂		100±0.0%	99.2±1.3%	100±0.0%	100±0.0%	99.8%	99.6±0.8%	69.2±11.1%	76.2±26.1%	91.8±9.9%	84.2%
DoF ₃		100±0.0%	97.2±6.0%	100±0.0%	100±0.0%	99.3%	72.0±14.8%	30.2±17.4%	39.2±20.9%	62.4±17.5%	51.0%
DoF ₄		94.0±11.0%	37.4±23.2%	51.2±26.5%	87.6±14.9%	67.6%	93.6±9.7%	31.8±20.3%	45.0±18.3%	63.8±17.0%	58.6%
DoF ₅		100±0.0%	92.6±8.4%	100±0.0%	100±0.0%	98.2%	97.8±4.9%	36.0±22.5%	62.0±24.8%	79.4±21.3%	68.8%
DoF ₆		100±0.0%	80.0±9.5%	92.6±13.4%	100±0.0%	93.2%	79.0±14.2%	22.2±14.4%	41.0±21.5%	62.6±15.7%	51.2%
DoF ₇		99.2±1.3%	86.6±8.3%	67.2±22.5%	96.4±6.4%	87.4%	91.8±15.3%	98.8±1.3%	70.6±23.4%	93.2±10.2%	88.6%
DoF _{1~3}		100±0.0%	100±0.0%	100±0.0%	100±0.0%	100%	96.4±8.0%	83.6±16.8%	74.4±26.3%	91.8±11.9%	86.6%
Task Avg		99.2%	86.4%	88.9%	98.0%	-	90.1%	51.1%	58.7%	78.9%	-

各种任务，包括在仿真中最大平均故障率 100% *v.s.* 为良性性能的 23.5%，在物理中为 88.6%。此外，在攻击自由度 4 期间，我们观察到低故障率和高任务偏差。这种失败可归因于自由度 4 控制沿 x 轴的方向，这在任务中可能是冗余自由度。因此，针对冗余自由度 [31] 的攻击不太可能有效干扰执行。这一观察强调了在设计针对机器人系统的对抗攻击时考虑任务特定因素的重要性。

定性结果。 我们在图 3 中对三种所提攻击下的机器人运动轨迹进行了定性分析。对于 UADA，我们在同一轨迹中比较了由 UADA 和 UMA 攻击生成的补丁引起的轨迹偏差。可以看出，UMA 引起的轨迹偏差较小。而 UADA 则产生显著更大的轨迹偏差（表 1b 中的 NAD 度量也支持这一点），这归因于 UADA 能够纳入动作差异。根据我们的观察，UADA 显著放大了对整体任务执行的影响，从而增加了机器人危害的可能性。对于 UPA，我们观察到混乱和不规则的行为，包括末端执行器移出相机视野的情况。我们将此现象归因于对抗补丁在扰动模型空间感知方面的有效性，诱导出与预期运动方向一致的持续偏差，最终导致长期失败。对于 TMA，我们观察到运动范围显著减小

沿 x 轴的运动对应于目标攻击轴。这表明本文提出的目标攻击能够有效约束机器人运动。

总之，定性分析表明，两种无监督方法均

目标攻击、UADA、UPA 和 TMA 能有效干扰由 VLA 模型生成的机器人动作。这些发现凸显了通用机器人部署过程中一个紧迫的安全问题，尤其是在考虑需要可靠操作的应用场景时 [9, 56]。




图 4. 物理世界的定性结果。第一行和第二行分别展示良性案例和对抗案例。真实世界性能。除了数字仿真结果外，我们还对生成的对抗补丁在真实场景中的性能进行了全面评估。评估涵盖三项不同任务共 100 次试验：物体抓取、放置和操作。如图 4 所示，使用 UADA 生成的对抗补丁能够有效操纵机器人，攻击成功率超过 **43%**。尽管这一成功率低于




图 5. 内循环、补丁尺寸和防御讨论的影响。该图展示了不同内循环次数如何影响 UADA 中的 NAD，以及补丁尺寸如何影响 L_1 距离和 TMA 中的失败率，两者均针对自由度 1。(a) 内循环的影响，(b) 补丁尺寸的影响，(c-f) 四种不同防御对失败率的影响。

相应的数字世界性能（即 100%），但它突显了我们的补丁在物理世界应用中的有效性，且无需进一步调整。关键的是，我们观察到成功攻击期间机器人产生的异常运动（类似于仿真场景）对人类安全和周围环境构成重大风险。这一发现强调了 VLA 模型在真实世界应用中构成的严重威胁，与数字环境中的类似观察结果一致。

4.4. 诊断实验

内循环的影响。我们在图 5(a) 中讨论了内循环步骤对模型性能的影响。结果表明，当内循环步骤持续增加时，NAD 首先得到改善。这是由于数据方差减小和梯度逐渐稳定所致。然而，进一步增加步骤会导致性能提升放缓，且训练时间明显延长。因此，我们选择内循环 steps=50，因为它在性能和规模之间取得了平衡。

补丁尺寸的影响。本文研究了不同图像块尺寸下 TMA 的性能，并在图 5(b) 中报告了四个 LIBERO[36] 任务的平均 FR。所考察的图像块尺寸为输入图像的 [3%, 5%, 7%, 10%]。研究结果表明，随着图像块尺寸的增大，预测动作与目标动作之间的 L_1 距离呈反比关系。图像块尺寸的增大也与 FR 的显著上升相关。观察到的趋势表明，较大的图像块为对抗者提供了更大的优化空间以影响模型，这与先前工作 [10, 69] 一致。

4.5. 鲁棒性评估

我们进一步检验了并发防御策略 [16, 66, 68] 能否在视觉语言动作模型（VLA）中抵御我们的对抗样本。具体而言，我们应用了四种先前的防御技术，并分别在图 5(c-f) 中报告了它们在良性样本和对抗样本上的失败率（FR）。结果表明，我们的对抗攻击绕过了大多数防御策略。

4.6. 系统性讨论

补丁模式分析。在图 6 中，我们展示了针对一系列目标生成的对抗补丁。一个特别值得注意的观察是，其中一些补丁带有




图 6. 补丁可视化。语义丰富的补丁。

与机械臂的结构关节有着惊人的相似之处。鉴于这些补丁与机械臂在外观上的高度相似性，我们推测，这些基于视觉语言动作（VLA）的模型在当前训练范式下，往往局限于在受限相机视角内运行的少数机器人系统。这种受限的视角相机位姿可能无意中诱导出学习到的表征偏差，使得对抗扰动与训练机器人外观的显著结构特征对齐，从而欺骗当前的受害模型。鉴于这些补丁具有模型特异性，并反映了训练环境的空间和视觉模式，我们有理由担忧它们可能损害基于 VLA 的模型在物理世界部署中的泛化能力和鲁棒性。

可能的防御策略。我们的工作凸显了在基于视觉-语言-动作（VLA）模型的训练策略中迫切需要范式转变，以成功防御我们的攻击。具体而言，未来的方法可能会纳入更多涉及复杂多机器人交互的训练场景，以缓解当前的补丁偏差。另一种可能的解决方案是利用机器人手臂物理结构内的逻辑关系来估计每个关节的实际位置。通过预测偏离物理约束的关节位置，我们可以消除不合理的对抗样本，即使它们与实际关节相似。

5. 结论

虽然 VLA 模型因其强大的机器人能力而获得了显著的普及，但本研究开创了特定的机器人攻击目标，并证明了这些模型实际上容易受到各种类型的攻击。实验结果表明，我们的攻击暴露了 VLA 模型的重大漏洞，引发了对其仓促实际部署的担忧。我们相信，我们的框架为增强人工智能机器人系统的可靠性提供了开创性和基础性的贡献。

致谢

本研究得到了美国国家科学基金会 (National Science Foundation) 的资助, 资助编号为 2450068 和 2242243, 以及罗格斯大学 (Rutgers University) 提供的启动资源。本文所表达的观点和结论仅代表作者本人, 不应被解释为必然代表美国海军研究实验室 (NRL) 或美国政府的官方政策或认可, 无论是明示还是暗示。美国政府被授权为政府目的复制和分发重印本, 尽管本文中有任何版权声明。

参考文献

- [1] Mokhaled NA Al-Hamadani, Mohammed A Fadhel, Laith Alzubaidi, and Balazs Harangi. Reinforcement learning algorithms and applications in healthcare and robotics: A comprehensive and systematic review. *Sensors*, 24(8):2461, 2024. [2](#)
- [2] Anish Athalye, Nicholas Carlini, and David A. Wagner. Obfuscated gradients give a false sense of security: Circumventing defenses to adversarial examples. In *ICML*, 2018. [2](#)
- [3] Anish Athalye, Logan Engstrom, Andrew Ilyas, and Kevin Kwok. Synthesizing robust adversarial examples. In *ICML*, 2018. [2, 5](#)
- [4] Aude Billard and Danica Kragic. Trends and challenges in robot manipulation. *Science*, 364(6446), 2019. [2](#)
- [5] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Joseph Dabis, Chelsea Finn, Keerthana Gopalakrishnan, Karol Hausman, Alexander Herzog, Jasmine Hsu, Julian Ibarz, Brian Ichter, Alex Irpan, Tomas Jackson, Sally Jesmonth, Nikhil J. Joshi, Ryan Julian, Dmitry Kalashnikov, Yuheng Kuang, Isabel Leal, Kuang-Huei Lee, Sergey Levine, Yao Lu, Utsav Malla, Deeksha Manjunath, Igor Mordatch, Ofir Nachum, Carolina Parada, Jodilyn Peralta, Emily Perez, Karl Pertsch, Jornell Quiambao, Kanishka Rao, Michael S. Ryoo, Grecia Salazar, Pannag R. Sanketi, Kevin Sayed, Jaspiar Singh, Sumedh Sontakke, Austin Stone, Clayton Tan, Huong T. Tran, Vincent Vanhoucke, Steve Vega, Quan Vuong, Fei Xia, Ted Xiao, Peng Xu, Sichun Xu, Tianhe Yu, and Brianna Zitkovich. RT-1: robotics transformer for real-world control at scale. In *Robotics: Science and Systems XIX*, 2023. [2](#)
- [6] Tom B. Brown, Dandelion Mané, Aurko Roy, Martín Abadi, and Justin Gilmer. Adversarial patch. *arXiv preprint arXiv:1712.09665*, 2018. [2](#)
- [7] Nicholas Carlini and David A. Wagner. Adversarial examples are not easily detected: Bypassing ten detection methods. In *Proceedings of the 10th ACM Workshop on Artificial Intelligence and Security*, pages 3–14, 2017. [2](#)
- [8] Xi Chen, Xiao Wang, Lucas Beyer, Alexander Kolesnikov, Jialin Wu, Paul Voigtlaender, Basil Mustafa, Sebastian Goodman, Ibrahim Alabdulmohsin, Piotr Padlewski, et al. Pali-3 vision language models: Smaller, faster, stronger. *arXiv preprint arXiv:2310.09199*, 2023. [2](#)
- [9] Shen Cheng and BS Dhillon. Reliability and availability analysis of a robot-safety system. *Journal of Quality in Maintenance Engineering*, 17:203–232, 2011. [7](#)
- [10] Zhiyuan Cheng, Cheng Han, James Liang, Qifan Wang, Xiangyu Zhang, and Dongfang Liu. Self-supervised adversarial training of monocular depth estimation against physical-world attacks. *arXiv preprint arXiv:2406.05857*, 2024. [8](#)
- [11] Hao-Tien Lewis Chiang, Zhuo Xu, Zipeng Fu, Mithun George Jacob, Tingnan Zhang, Tsang-Wei Edward Lee, Wenhao Yu, Connor Schenck, David Rendleman, Dhruv Shah, et al. Mobility vla: Multimodal instruction navigation with long-context vlms and topological graphs. *arXiv preprint arXiv:2407.07775*, 2024. [2](#)
- [12] Jinda Cui and Jeff Trinkle. Toward next-generation learned robot manipulation. *Sci. Robotics*, 6(54):9461, 2021. [2](#)
- [13] Yiming Cui, Cheng Han, and Dongfang Liu. Collaborative multi-task learning for multi-object tracking and segmentation. *Journal on Autonomous Transportation Systems*, 1:1–23, 2024. [2](#)
- [14] Pengxiang Ding, Han Zhao, Wenjie Zhang, Wenxuan Song, Min Zhang, Siteng Huang, Ningxi Yang, and Donglin Wang. Quar-vla: Vision-language-action model for quadruped robots. In *ECCV*, 2025. [1](#)
- [15] Andrew Du, Bo Chen, Tat-Jun Chin, Yee Wei Law, Michele Sasdelli, Ramesh Rajasegaran, and Dillon Campbell. Physical adversarial attacks on an aerial imagery object detector. In *WACV*, 2022. [2](#)
- [16] Gintare Karolina Dziugaite, Zoubin Ghahramani, and Daniel M. Roy. A study of the effect of JPG compression on adversarial images. *arXiv preprint arXiv:1608.00853*, 2016. [8](#)
- [17] Chelsea Finn, Tianhe Yu, Tianhao Zhang, Pieter Abbeel, and Sergey Levine. One-shot visual imitation learning via meta-learning. In *CoRL*, 2017. [2](#)
- [18] Ian J. Goodfellow, Jonathon Shlens, and Christian Szegedy. Explaining and harnessing adversarial examples. In *ICLR*, 2015. [2](#)
- [19] Sami Haddadin, Sven Parusel, Lars Johannsmeier, Saskia Golz, Simon Gabl, Florian Walch, Mohamadreza Sabaghian, Christoph Jähne, Lukas Hausperger, and Simon Haddadin. The franka emika robot: A reference platform for robotics research and education. *IEEE Robotics & Automation Magazine*, 29:46–64, 2022. [3](#)
- [20] Jiangyong Huang, Silong Yong, Xiaojian Ma, Xiongkun Linghu, Puhao Li, Yan Wang, Qing Li, Song-Chun Zhu, Baoxiong Jia, and Siyuan Huang. An embodied generalist agent in 3d world. *arXiv preprint arXiv:2311.12871*, 2023. [2](#)
- [21] Wenlong Huang, Chen Wang, Ruohan Zhang, Yunzhu Li, Jiajun Wu, and Li Fei-Fei. Voxposer: Composable 3d value maps for robotic manipulation with language models. In *CoRL*, 2023. [2](#)
- [22] Félix Ingrand and Malik Ghallab. Deliberation for autonomous robots: A survey. *Artif. Intell.*, 247:10–44, 2017. [2](#)
- [23] ISO 10218-1/2:2011. Robots and Robotic Devices Safety Requirements for Industrial Robots Part 1: Robots/Part 2: Robot Systems and Integration. Standard, International Organization for Standardization, 2011. [3](#)

- [24] ISO13482. Robots and robotic devices — safety requirements for personal care robots. *International Organization for Standardization*, 2014.
- [25] ISO/TS 15066:2016. Robots and Robotic Devices Collaborative Robots. Standard, International Organization for Standardization, 2016. 3
- [26] Stephen James, Michael Bloesch, and Andrew J. Davison. Task-embedded control networks for few-shot imitation learning. In *CoRL*, 2018. 2
- [27] Yunfan Jiang, Agrim Gupta, Zichen Zhang, Guanzhi Wang, Yongqiang Dou, Yanjun Chen, Li Fei-Fei, Anima Anandkumar, Yuke Zhu, and Linxi Fan. VIMA: general robot manipulation with multimodal prompts. *arXiv preprint arXiv:2210.03094*, 2022. 2
- [28] Siddharth Karamcheti, Suraj Nair, Ashwin Balakrishna, Percy Liang, Thomas Kollar, and Dorsa Sadigh. Prismatic vlms: Investigating the design space of visually-conditioned language models. *arXiv preprint arXiv:2402.07865*, 2024. 2
- [29] Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, Ted Xiao, Ashwin Balakrishna, Suraj Nair, Rafael Rafailov, Ethan Foster, Grace Lam, Pannag Sanketi, Quan Vuong, Thomas Kollar, Benjamin Burchfiel, Russ Tedrake, Dorsa Sadigh, Sergey Levine, Percy Liang, and Chelsea Finn. Openvla: An open-source vision-language-action model. *arXiv preprint arXiv:2406.09246*, 2024. 1, 2, 3, 5, 6
- [30] Oliver Kroemer, Scott Niekum, and George Konidaris. A review of robot learning for manipulation: Challenges, representations, and algorithms. *J. Mach. Learn. Res.*, 22:30:1–30:82, 2021. 2
- [31] Andrew J Kurdila and Pinhas Ben-Tzvi. *Dynamics and control of robotic systems*. John Wiley & Sons, 2019. 7
- [32] Sergey Levine, Peter Pastor, Alex Krizhevsky, Julian Ibarz, and Deirdre Quillen. Learning hand-eye coordination for robotic grasping with deep learning and large-scale data collection. *Int. J. Robotics Res.*, 37(4-5):421–436, 2018. 2
- [33] Xinghang Li, Minghuan Liu, Hanbo Zhang, Cunjun Yu, Jie Xu, Hongtao Wu, Chilam Cheang, Ya Jing, Weinan Zhang, Huaping Liu, et al. Vision-language foundation models as effective robot imitators. *arXiv preprint arXiv:2311.01378*, 2023. 2
- [34] Xiang Li, Cristina Mata, Jongwoo Park, Kumara Kahatapitiya, Yoo Sung Jang, Jinghuan Shang, Kanchana Ranasinghe, Ryan Burgert, Mu Cai, Yong Jae Lee, and Michael S. Ryoo. Llra: Supercharging robot learning data for vision-language policy. *arXiv preprint arXiv:2406.20095*, 2024. 3
- [35] Aishan Liu, Xianglong Liu, Jiabin Fan, Yuqing Ma, Anlan Zhang, Huiyuan Xie, and Dacheng Tao. Perceptual-sensitive GAN for generating adversarial patches. In *AAAI*, 2019. 2
- [36] Bo Liu, Yifeng Zhu, Chongkai Gao, Yihao Feng, Qiang Liu, Yuke Zhu, and Peter Stone. LIBERO: benchmarking knowledge transfer for lifelong robot learning. In *NeurIPS*, 2023. 6, 7, 8
- [37] Haotian Liu, Chunyuan Li, Yuheng Li, and Yong Jae Lee. Improved baselines with visual instruction tuning. In *CVPR*, 2024. 2
- [38] Haotian Liu, Chunyuan Li, Qingyang Wu, and Yong Jae Lee. Visual instruction tuning. In *NeurIPS*, 2024. 2
- [39] Aleksander Madry, Aleksandar Makelov, Ludwig Schmidt, Dimitris Tsipras, and Adrian Vladu. Towards deep learning models resistant to adversarial attacks. In *ICLR*, 2018. 2, 5
- [40] Matthew T. Mason. *Mechanics of Robotic Manipulation*. MIT Press, 2001. 2
- [41] Matthew T. Mason. Toward robotic manipulation. *Annu. Rev. Control. Robotics Auton. Syst.*, 1:1–28, 2018. 2
- [42] Oier Mees, Lukás Hermann, and Wolfram Burgard. What matters in language conditioned robotic imitation learning over unstructured data. *IEEE Robotics Autom. Lett.*, 7(4):11205–11212, 2022. 2
- [43] Vivek G Moudgal, Kevin M Passino, and Stephen Yurkovich. Rule-based control for a flexible-link robot. *IEEE Trans. on Control Sys. Tech.*, 2(4):392–405, 1994. 2
- [44] Richard M. Murray, Zexiang Li, and S. Shankar Sastry. *A mathematical introduction to robotics manipulation*. CRC Press, 1994. 2
- [45] Lerrel Pinto and Abhinav Gupta. Supersizing self-supervision: Learning to grasp from 50k tries and 700 robot hours. In *ICRA*, 2016. 2
- [46] Vitchyr Pong, Murtaza Dalal, Steven Lin, Ashvin Nair, Shikhar Bahl, and Sergey Levine. Skew-fit: State-covering self-supervised reinforcement learning. In *ICML*, 2020. 2
- [47] Xiangyu Qi, Kaixuan Huang, Ashwinee Panda, Peter Henderson, Mengdi Wang, and Prateek Mittal. Visual adversarial examples jailbreak aligned large language models. In *AAAI*, 2024. 2
- [48] Mahmood Sharif, Sruti Bhagavatula, Lujo Bauer, and Michael K. Reiter. Accessorize to a crime: Real and stealthy attacks on state-of-the-art face recognition. In *ACM SIGSAC*, 2016. 2
- [49] Michael H. Smith and L. Stephen Coles. Design of a low cost, general purpose robot. In *IJCAI*, 1973. 2
- [50] Jiawei Su, Danilo Vasconcellos Vargas, and Kouichi Sakurai. One pixel attack for fooling deep neural networks. *IEEE Trans. Evol. Comput.*, 23(5):828–841, 2019. 2
- [51] Christian Szegedy, Wojciech Zaremba, Ilya Sutskever, Joan Bruna, Dumitru Erhan, Ian J. Goodfellow, and Rob Fergus. Intriguing properties of neural networks. In *ICLR*, 2014. 2
- [52] Chen Tang, Ben Abbatematteo, Jiaheng Hu, Rohan Chandra, Roberto Martín-Martín, and Peter Stone. Deep reinforcement learning for robotics: A survey of real-world successes. *arXiv preprint arXiv:2408.03539*, 2024. 2
- [53] Octo Model Team, Dibya Ghosh, Homer Walke, Karl Pertsch, Kevin Black, Oier Mees, Sudeep Dasari, Joey Hejna, Tobias Kreiman, Charles Xu, Jianlan Luo, You Liang Tan, Lawrence Yunliang Chen, Pannag Sanketi, Quan Vuong, Ted Xiao, Dorsa Sadigh, Chelsea Finn, and Sergey Levine. Octo: An open-source generalist robot policy. *arXiv preprint arXiv:2405.12213*, 2024. 2
- [54] Florian Tramèr. Detecting adversarial examples is (nearly) as hard as classifying them. In *ICML*, 2022. 2
- [55] Florian Tramèr, Nicholas Carlini, Wieland Brendel, and Aleksander Madry. On adaptive attacks to adversarial example defenses. In *NeurIPS*, 2020. 6
- [56] Christian Vogel, Christoph Walter, and Norbert Elkmann. A projection-based sensor system for safe physical human-robot collaboration. In *IROS*, 2013. 7

- [57] Homer Rich Walke, Kevin Black, Tony Z. Zhao, Quan Vuong, Chongyi Zheng, Philippe Hansen-Estruch, Andre Wang He, Vivek Myers, Moo Jin Kim, Max Du, Abraham Lee, Kuan Fang, Chelsea Finn, and Sergey Levine. Bridgedata V2: A dataset for robot learning at scale. In *CoRL*, 2023. 6, 8
- [58] Taowen Wang, Yiyang Liu, James Chenhao Liang, Yiming Cui, Yuning Mao, Shaoliang Nie, Jiahao Liu, Fuli Feng, Zenglin Xu, Cheng Han, et al. M²pt: Multimodal prompt tuning for zero-shot instruction learning. In *EMNLP*, 2024. 1, 2
- [59] Zhibo Wang, Siyan Zheng, Mengkai Song, Qian Wang, Alireza Rahimpour, and Hairong Qi. advpattern: Physical-world attacks on deep person re-identification via adversarially transformable patterns. In *ICCV*, 2019. 2
- [60] Zixiang Wang, Hao Yan, Zhuoyue Wang, Zhengjia Xu, Zhizhong Wu, and Yining Wang. Research on autonomous robots navigation based on reinforcement learning. In *RAIIC*, 2024. 2
- [61] Zhijie Wang, Zhehua Zhou, Jiayang Song, Yuheng Huang, Zhan Shu, and Lei Ma. Towards testing and evaluating vision-language-action models for robotic manipulation: An empirical study. *arXiv preprint arXiv:2409.12894*, 2024. 1
- [62] Junjie Wen, Yichen Zhu, Jinming Li, Minjie Zhu, Kun Wu, Zhiyuan Xu, Ran Cheng, Chaomin Shen, Yaxin Peng, Feifei Feng, et al. Tinyvla: Towards fast, data-efficient vision-language-action models for robotic manipulation. *arXiv preprint arXiv:2409.12514*, 2024. 1
- [63] Wikipedia contributors. Finch (film) — Wikipedia, the free encyclopedia. [https://en.wikipedia.org/w/index.php?title=Finch_\(film\)&oldid=1249481595](https://en.wikipedia.org/w/index.php?title=Finch_(film)&oldid=1249481595), 2024. [Online; accessed 5-November-2024]. 1
- [64] Chen Henry Wu, Jing Yu Koh, Ruslan Salakhutdinov, Daniel Fried, and Aditi Raghunathan. Adversarial attacks on multi-modal agents. *arXiv preprint arXiv:2406.12814*, 2024. 2
- [65] Kaidi Xu, Gaoyuan Zhang, Sijia Liu, Quanfu Fan, Mengshu Sun, Hongge Chen, Pin-Yu Chen, Yanzhi Wang, and Xue Lin. Adversarial t-shirt! evading person detectors in a physical world. In *ECCV*, 2020. 2
- [66] Weilin Xu, David Evans, and Yanjun Qi. Feature squeezing: Detecting adversarial examples in deep neural networks. In *NDSS*, 2018. 8
- [67] Zhiyang Xu, Chao Feng, Rulin Shao, Trevor Ashby, Ying Shen, Di Jin, Yu Cheng, Qifan Wang, and Lifu Huang. Vision-flan: Scaling human-labeled tasks in visual instruction tuning. *arXiv preprint arXiv:2402.11690*, 2024. 1
- [68] Yuchen Zhang and Percy Liang. Defending against whitebox adversarial attacks via randomized discretization. In *AISTATS*, 2019. 8
- [69] Yaoyuan Zhang, Yu-an Tan, Tian Chen, Xinrui Liu, Quanxin Zhang, and Yuanzhang Li. Enhancing the transferability of adversarial examples with random patch. In *IJCAI*, 2022. 8
- [70] Bo Zhao, Boya Wu, Muyang He, and Tiejun Huang. Svit: Scaling up visual instruction tuning. *arXiv preprint arXiv:2307.04087*, 2023. 2
- [71] Yuanyang Zhu, Zhi Wang, Chunlin Chen, and Daoyi Dong. Rule-based reinforcement learning for efficient robot navigation with space reduction. *IEEE/ASME Trans. on Mechatronics*, 27:846–857, 2021. 2
- [72] Brianna Zitkovich, Tianhe Yu, Sichun Xu, Peng Xu, Ted Xiao, Fei Xia, Jialin Wu, Paul Wohlhart, Stefan Welker, Ayzaan Wahid, Quan Vuong, Vincent Vanhoucke, Huong T. Tran, Radu Soricut, Anikait Singh, Jaspiar Singh, Pierre Sermanet, Pannag R. Sanketi, Grecia Salazar, Michael S. Ryoo, Krista Reymann, Kanishka Rao, Karl Pertsch, Igor Mordatch, Henryk Michalewski, Yao Lu, Sergey Levine, Lisa Lee, Tsang-Wei Edward Lee, Isabel Leal, Yuheng Kuang, Dmitry Kalashnikov, Ryan Julian, Nikhil J. Joshi, Alex Irpan, Brian Ichter, Jasmine Hsu, Alexander Herzog, Karol Hausman, Keerthana Gopalakrishnan, Chuyuan Fu, Pete Florence, Chelsea Finn, Kumar Avinava Dubey, Danny Driess, Tianli Ding, Krzysztof Marcin Choromanski, Xi Chen, Yevgen Chebotar, Justice Carbajal, Noah Brown, Anthony Brohan, Montserrat Gonzalez Arenas, and Kehang Han. RT-2: vision-language-action models transfer web knowledge to robotic control. In *CoRL*, 2023. 2, 3