



AgiBot World Colosseo: 面向可扩展智能具身系统的大规模操作平台

Team AgiBot-World*

Project website: <https://agibot-world.com/>

Code: <https://github.com/OpenDriveLab/AgiBot-World>




图 1: 介绍 AgiBot World Colosseo, 一个开源的大规模操作平台, 包含数据、模型、基准和生态系统。与以往同类平台相比, AgiBot World 以其无与伦比的规模和多样性脱颖而出。部署了 100 台双臂人形机器人。我们进一步提出了一种具有潜在动作规划器的通用策略 (GO-1)。它在多样化的数据语料库上进行训练, 与现有技术相比, 性能可扩展提升 32%。

摘要——我们探索可扩展的机器人数据如何应对通用机器人操作中的现实挑战。引入 AgiBot World, 一个大规模平台, 涵盖五个部署场景中 217 个任务的超过 100 万条轨迹, 与现有数据集相比, 数据规模实现了数量级的增长。通过标准化采集流程和人在回路验证的加速, AgiBot World 保证了高质量和多样化的数据分布。它可从夹爪扩展到灵巧手和视觉触觉传感器, 用于精细技能获取。在数据基础上, 我们介绍了 Genie Operator-1 (GO-1), 一种新颖的通用策略, 利用潜在动作表示来最大化数据利用率, 展示了性能随数据量增加的可预测扩展。在我们的数据集上预训练的策略, 在域内和分布外场景中, 平均性能比在 Open X-Embodiment 上训练的策略提高了 30%。GO-1 在现实世界的灵巧和长时程任务中表现出卓越的能力, 在复杂任务上成功率超过 60%, 比之前的 RDT 方法高出 32%。通过开源数据集、工具和模型, 我们旨在使大规模高质量机器人数据的获取民主化, 推动可扩展和通用智能的追求。

I. 引言

操作是机器人学中的一项基石任务, 使智能体能够与物理世界交互并适应之。尽管在自然语言处理 [1] 和计算机视觉 [2] 的通用基础模型方面已取得显著进展, 机器人学却因 (高质量) 数据采集的困难而落后。在受控实验室环境中, 诸如拾取与放置等简单任务已被深入研究 [3], [4]。然而, 对于开放集真实世界环境, 从细粒度物体交互、移动操作到协作任务的各种任务, 仍然构成一项艰巨挑战 [5]。这些任务不仅要求物理灵巧性, 还要求跨多样化环境和场景的泛化能力, 这一优点超出了当前机器人系统的能力范围。普遍接受的原因是缺乏高质量数据——与丰富且标准化的图像和文本不同, 机器人数据集因异构硬件和非标准化采集流程而遭受片段碎片化, 导致低质量且不一致的结果。在本文中, 我们提出疑问: 如何通过扩大真实世界机器人数据规模来有效解决真实世界的复杂性?

* 本工作由香港大学、AgiBot Inc.、上海创新研究院和上海人工智能实验室联合完成。详细作者信息请查阅我们的网站和 GitHub 仓库。

近期工作，如开放跨实体数据集（Open X-Embodiment，OXE）[6]，通过聚合与标准化现有数据集解决了这一问题。尽管在大规模跨实体学习方面取得了进展，所得策略仍局限于简单、短视域任务，且对域外场景的泛化能力较弱 [4]。DROID[7] 通过众包方式从多样化的真实生活场景中采集专家数据。缺乏数据质量保障（含人类反馈）以及对受限硬件配置（即固定式单臂机器人）的依赖，限制了其实际应用价值与更广泛的效能。近期，Lin 等人 [8] 探索了类内物体与环境间泛化能力的缩放定律，但仅限于少数简单的单步任务。这些工作标志着向通用策略开发迈出的显著一步，超越了传统上对狭窄领域内单任务学习的关注 [9],[3]。然而，现有机器人学习数据集仍受限于高度受控实验室环境中的短视域任务，未能充分捕捉真实世界操作任务固有的复杂性与多样性。为实现通用机器人智能，必须开发在规模与多样性上可扩展、同时捕捉真实世界变异性的数据集，并辅以通用人形机器人进行稳健技能习得、具备质量保障的标准化数据采集流程，以及精心设计以反映真实世界挑战的任务。如图 1 所示，本文提出 AgiBot World **Colosseo**，一个全栈式大规模机器人学习平台，旨在推动可扩展智能具身系统中双臂操作的进步。我们构建了一个占地 4000 平方米的全尺寸设施，涵盖五大领域——家庭、零售、工业、餐饮与办公环境——全部致力于在真实日常场景中进行高保真数据采集。AgiBot World 从 100 台真实机器人采集了超过 100 万条轨迹，提供了前所未有的多样性与复杂性。它覆盖 100 余个真实世界场景，应对细粒度操作、工具使用及多机器人协同协作等挑战性任务。与先前数据集不同，AgiBot World 数据集的采集采用完全标准化的流程，确保高数据质量与可扩展性，同时引入人在回路验证以保障可靠性。我们的硬件配置包括具备全身控制、灵巧手和视触觉传感器的移动基座人形机器人，支持丰富的多模态数据采集。每个回合均经过精心设计，包含多视角相机、深度信息、相机标定，以及针对整体任务和每个子步骤的语言标注。这一完善的硬件配置，结合多样化的长视域真实世界任务，为开发下一代通用策略开辟了新途径，并促进了机器人学领域多样化的未来研究。实验结果凸显了 AgiBot World 数据集的变革潜力。在该数据集上预训练的策略，相较于在先前大规模数据集上训练的策略，平均成功率提升了 30%。

机器人数据集 OXE [6]。值得注意的是，即使仅使用我们数据集的一小部分——在小时数上相当于 OXE 数据量的 1/10——预训练策略的泛化能力也提升了 18%。这些发现凸显了该数据集在弥合受控实验室环境与现实世界机器人应用之间差距方面的有效性。继我们的数据集之后，为了解决以往机器人基础模型严重依赖领域内机器人数据集的局限性，我们提出了 Genie Operator-1 (GO-1)，这是一种新颖的通才策略，利用潜在动作表示实现从异构数据中学习，并高效地桥接通用视觉语言模型 (VLM) 与机器人序列决策。通过在网络规模数据（从人类视频到我们的高质量机器人数据集）上进行统一预训练，GO-1 实现了卓越的泛化能力和灵巧性，超越了先前的通才策略，如 RDT [10] 以及我们未使用潜在动作规划器的变体。此外，我们证明了 GO-1 的性能随着数据集规模的增大而表现出稳健的可扩展性，凸显了其在更大数据集可用时持续进步的潜力。除了其直接影响之外，AgiBot World 还为机器人操作领域的未来研究奠定了坚实的基础。通过开源数据集、工具链和预训练模型，我们旨在促进社区范围内的创新，使研究人员能够探索从家庭助理到工业自动化等更真实、更多样化的应用。AgiBot World 不仅仅是又一个数据集；它是迈向可扩展、通用机器人智能的一步，使机器人能够应对现实世界的复杂性。

贡献。 1) 我们构建了 AgiBot World 数据集，这是一个多样化的机器人学习数据集，并附有开源工具，以推进大规模策略学习的研究。作为一项开创性的举措，AgiBot World 采用了一套包容性的优化流程，从场景配置、任务设计、数据收集到人在回路验证，确保了无与伦比的数据质量。2) 我们提出了 GO-1，这是一种机器人基础策略，利用潜在动作表示解锁网络数据上的网络规模预训练。在 AgiBot World 数据集的支持下，它在泛化能力和灵巧性方面超越了先前的通才策略。

局限性。 所有评估均在真实场景中进行。我们目前正在开发仿真环境，使其与真实世界设置保持一致，并旨在反映真实世界策略部署的结果。这将有助于实现快速且可重复的评估。

II. 相关工作

机器人技术中的数据扩展。 来自自动化脚本或人类遥操作的机器人学习数据集已经使策略学习成为可能，早期的工作如 RoboTurk [19] 和 BridgeData [12] 分别提供了包含 2.1k 和 7.2k 条轨迹的小规模数据集。更大的数据集，如 RT-1 [14] (130k 条轨迹)，扩大了范围，但仍然局限于少数环境和技能。Open X-Embodiment [6] 将各种数据集聚合成统一的格式，增长到超过 140 万条轨迹，因此它

Dataset	Traj.	Skill	Scene	Detailed Annotation	Cam. Calibration	Arm Type	Dex. Hand	Failure Recovery	Human-in-the-loop	Collection
RoboNet [11]	162k	n/a	10	✗	✗	Single	✗	✗	✗	scripted
BridgeData [12]	7.2k	4	12	✗	✗	Single	✗	✗	✗	human teleop
BC-Z [13]	26k	3	1	✗	✗	Single	✗	✗	✗	human teleop
RT-1 [14]	130k	8	2	✗	✗	Single	✗	✗	✗	human teleop
RH20T [15]	13k	33	7	✗	✓	Single	✗	✗	✗	human teleop
RoboSet [16]	98.5k	6	11	✗	✗	Single	✗	✗	✗	30% human / 70% scripted
BridgeData V2 [17]	60.1k	13	24	✗	✗	Single	✗	✗	✗	85% human / 15% scripted
DROID [7]	76k	86	564	✗	✓	Single	✗	✗	✗	human teleop
RoboMIND [18]	55k	36	n/a	✗	✓	Single+Dual	✓	✗	✗	human teleop
Open X-Embodiment [6]	1.4M	217	311	(✗)	✗	Single+Dual	✗	✗	✗	dataset aggregation
AgiBot World Dataset	1M+	87	106	✓	✓	Dual	✓	✓	✓	human teleop

表 I: 与现有数据集的比较。 AgiBot World 拥有迄今为止最多的轨迹数量。我们以 1:1 的比例复制了真实世界环境，用于工业和零售场景，这些场景以前几乎不存在。提供了大量的人工标注，包括物品、场景、技能（子任务分段）和任务级标注。值得注意的是，为了扩大数据的适用性和潜力，我们包含了不完美的数据（即带有标注错误状态的故障恢复数据）和涉及灵巧手的任务。为了确保数据质量，我们采用了人在回路（human-in-the-loop）的理念：策略学习在收集的演示上进行。部署结果被用作反馈来改进收集协议。

在实施例、观测视角和数据质量方面存在显著差异，限制了其整体有效性。近期，DROID [7] 通过众包演示向扩大场景规模以提升多样性迈进，但在数据规模和质量控制方面仍显不足。上述数据集普遍面临数据规模、任务实用性和场景自然性方面的局限，加之质量保障不足和硬件限制，阻碍了通用策略的训练。如表 I 所示，我们的数据集充分弥补了这些差距。我们构建了覆盖五个场景的数据采集设施，以重现真实世界的多样性与真实性。通过熟练遥操作人员在严格验证协议下采集的超过 100 万条轨迹，AgiBot World 利用配备视觉-触觉传感器和灵巧手的人形机器人实现多模态演示，使其区别于以往的工作。与 Pumacay 等人 [20] 提出的用于评估泛化能力的仿真基准不同，我们提出的是一个集数据、模型、基准和生态系统于一体的全栈平台。

大规模策略学习。 机器人基础模型通常与数据集规模的发展共同演进，通过多样化的大规模训练赋予机器人不断提升的通用能力。鉴于动作标注机器人数据集规模有限，若干先前工作仅利用网络规模视频来促进策略学习 [21], [22], [23]。另一类工作则采用在机器人轨迹上训练的大型端到端模型，并随着机器人数据规模的扩大而扩展 [4], [24], [14], [25]。例如，RDT [10] 采用扩散 Transformer，首先在异构多机器人数据集上进行预训练，并在超过 6k 条双臂轨迹上微调，展示了在多样化来源上预训练的优势。 π_0 [26] 使用预训练的视觉语言模型骨干和基于流的动作专家，推进了如洗衣等复杂任务的灵巧操作。LAPA [27] 引入潜在动作作为预训练目标；然而，其潜在规划能力并未保留到下游任务中。基于近期研究中多种创新思想，我们进一步推进

通过视觉语言模型（VLMs）与潜在动作的适配，将网络规模知识迁移至机器人控制，利用人类视频和机器人数据进行可扩展训练。本文工作展示了潜在动作规划器的集成如何增强长时程任务执行，并实现更高效的策略学习，显著优于现有通用策略。

III. AGIBOT WORLD: 平台与数据

AgiBot World 是一个全栈开源的具身智能生态系统。基于我们开发的硬件平台 AgiBot G1，我们构建了 AgiBot World——一个由 100 余台同构机器人采集的开源机器人操作数据集，为涵盖广泛真实生活场景的挑战性任务提供高质量数据。最新版本包含 1,001,552 条轨迹，总时长 2976.4 小时，覆盖 217 个具体任务、87 项技能和 106 个场景。我们超越实验室环境中基本的桌面任务（如抓取与放置），专注于涉及双臂操作、灵巧手和协作任务的真实世界场景。AgiBot World 旨在提供一个包容性基准，以推动先进且稳健算法的未来发展。我们计划发布所有资源，使社区能够在 AgiBot World 基础上进行构建。数据集在 CC BY-NC-SA 4.0 许可证下提供，同时提供模型检查点和代码。

A. 硬件：多功能人形机器人

硬件平台是 AgiBot World 的基石，决定了其质量的下限。硬件的标准化也是简化分布式数据采集和确保结果可复现的关键。我们精心为 AgiBot World 开发了一个新颖的硬件平台，其特点是视觉触觉传感器、耐用的 6 自由度人形构型灵巧手。如图 1 所示，我们的机器人平台具有双臂 7 自由度、移动底盘和可调节腰部。




图 2：数据采集流程。我们采用人在回路框架以确保高质量，并辅以详细标注和错误恢复行为。人类反馈不仅在采集后审查中发挥关键作用，还积极引导数据采集过程，这在先前工作中很大程度上被忽视。

末端执行器采用模块化设计，可根据任务需求选用标准夹爪或六自由度灵巧手。对于需要触觉反馈的任务，使用配备视觉触觉传感器的夹爪。机器人共配备八个摄像头：一个 RGB-D 摄像头和三个鱼眼摄像头用于前视，每个末端执行器上安装 RGB-D 或鱼眼摄像头，两个鱼眼摄像头位于后部。图像观测和本体感受状态（包括关节和末端执行器位置）以 30 赫兹的控制频率记录。我们采用两套遥操作系统：虚拟现实头显控制和全身动作捕捉控制。虚拟现实控制器将手势映射为末端执行器的平移和旋转，随后通过逆运动学转换为关节角度。控制器上的摇杆和按钮用于控制机器人基座和身体移动，扳机按钮控制末端执行器动作。然而，虚拟现实控制器将灵巧手限制为仅少数预定义手势。为充分释放机器人的能力，我们采用动作捕捉系统记录人体关节数据（包括手指），并将其映射到机器人姿态，从而实现更精细的控制，包括单个手指运动、躯干姿态和头部朝向。该系统提供了实现更复杂操作任务所需的姿态灵活性和执行精度。

B. 数据采集：协议与质量

数据采集过程如图 2 所示，大致可分为三个阶段。（1）在正式开始数据采集之前，我们首先进行初步数据采集，以验证每个任务的可行性并建立相应的采集标准。（2）在可行性验证和采集标准审查之后，熟练的遥操作员布置初始场景，并根据既定标准正式开始数据采集。所有数据在本地进行初步有效性验证，

例如验证是否存在缺失帧。一旦确认数据完整，便将其上传至云端进行下一阶段。（3）在后处理阶段，数据标注员将验证每个片段是否符合第一阶段建立的采集标准，并提供语言标注。

失败恢复。在数据采集过程中，遥操作员偶尔会犯错，例如在操控机械臂时不小心掉落物体。然而，他们通常能够从这些错误中恢复，并在无需完全重新配置设置的情况下成功完成任务。我们不会丢弃这些轨迹，而是保留它们，并手动为每条轨迹标注相应的失败原因和时间戳。这些被称为失败恢复数据的轨迹约占数据集的百分之一。我们认为它们对于实现策略对齐 [28] 和失败反思 [29] 具有不可估量的价值，这对于推动下一代机器人基础模型的发展至关重要。

人在回路。在收集数据标注员反馈的同时，我们采用人在回路的方法来评估和优化数据质量。该过程包括一个迭代循环：收集少量演示、训练策略，并部署所得策略以评估数据可用性。根据策略的性能，我们迭代地优化数据采集流程，以解决已识别的差距或低效问题。例如，在真实世界部署期间，模型在动作开始时表现出长时间的停顿，这与数据标注员的反馈一致，即采集的数据中存在不一致的过渡和过多的空闲时间。为此，我们修订了数据采集协议，并引入后处理步骤以消除空闲帧，从而提升数据集对策略学习的整体效用。这种反馈驱动的方法论确保了数据质量的持续改进。

C. 数据集统计与分析：超越规模

AgiBot World 是通过一个大规模数据采集设施开发的，该设施占地超过 4,000 平方米。这个广阔的环境包含超过 3,000 个独特物体，分布在各种场景中，精心设计以反映真实世界环境。该数据集涵盖了广泛的场景和场景设置，确保在追求可泛化机器人策略时兼具规模与多样性。重建真实世界的多样性。我们数据集的关键统计数据如图 3 所示。AgiBot World 在五个关键领域提供了广泛的覆盖：家庭、零售、工业、餐厅和办公环境。在每个领域内，我们进一步定义了具体的场景类别。例如，家庭领域包括卧室、厨房、客厅和阳台等详细环境，而零售领域则具有货架单元和生鲜区等独特区域。我们的数据集还包含超过 3,000 个独特物体，在各种场景进行了系统分类。这些物体涵盖了广泛的日常物品，包括食品、家具、服装、电子设备等。物体分布




图 3：数据集统计。 a) AgiBot World 数据集覆盖了绝大多数机器人应用场景，以及广泛的交互物体。 b) 我们的数据集具有长时程任务，大多数轨迹时长在 30 秒到 60 秒之间。相比之下，广泛使用的数据集（如 DROID）主要由 5 秒到 20 秒的轨迹组成，而 OXE v1.0 主要包含 5 秒以内的轨迹。 c) AgiBot World 数据集专注于有价值的原子技能，涵盖广泛的技能范围，每种技能至少由 100 条轨迹支持（上方红色虚线）。

类别，如图 3(a) 所示，突出了每个场景中不同物体类型的相对频率。

长时程操作。 AgiBot World 数据集的一个显著特点是其对长时程操作的强调。如图 3(b) 所示，先前数据集主要关注涉及单一原子技能的任务，大多数轨迹持续时间不超过 5 秒。相比之下，AgiBot World 建立在由多个原子技能组成的连续完整任务之上，例如“制作咖啡”。我们数据集中的轨迹通常张成约 30 秒，部分轨迹持续时间超过 2 分钟。我们还为每个子步骤提供关键帧和指令标注，以促进在此类具有挑战性的场景中进行策略学习。

全面的技能覆盖。 在任务设计方面，虽然通用原子技能（如“抓取-放置”）主导了大多数任务，但我们有意纳入了强调较少使用但极具价值的技能的任务，例如“切”和“插”（如图 3(c) 所示）。这确保了我们的数据集充分代表了广泛的技能谱系，为每种技能提供了足够的数据以支持稳健的策略学习。

四、AGIBOT WORLD: 模型

为了有效利用我们高质量的 AgiBot World 数据集并增强策略的泛化能力，我们提出了一种具有三个训练阶段的分层视觉-语言-潜在动作 (ViLLA) 框架，如图 4 所示。与动作受视觉-语言条件制约的视觉-语言-动作 (VLA) 模型相比，ViLLA 模型预测潜在动作标记，并以生成后续机器人控制动作为条件。在第一阶段，我们通过在互联网规模的异构数据上训练编码器-解码器潜在动作模型

(LAM)，将连续图像投影到潜在动作空间中。这使得

潜在动作能够作为中间表示，弥合通用图像-文本输入与机器人动作之间的差距。在第二阶段，这些潜在动作充当潜在规划器的伪标签，促进与具体实现无关的长时程规划，并利用预训练 VLM 的泛化能力。最后，在第三阶段，我们引入动作专家，并与潜在规划器联合训练，以支持灵巧操作的学习。

A. 潜在动作模型

尽管在收集多样化机器人演示方面取得了显著进展，但与网络规模的数据集相比，带有动作标签的机器人数据量仍然有限。为了通过纳入缺乏动作标签的互联网规模人类视频和跨形态机器人数据来扩大数据池，我们在第一阶段采用潜在动作 [30] 来建模连续帧的逆动力学。该方法能够将来自异构数据源的真实世界动力学转化为通用的操作知识。为了从视频帧中提取潜在动作 $\{I_t, I_{t+H}\}$ ，潜在动作模型围绕基于逆动力学模型的编码器 $\mathbf{I}(z_t|I_t, I_{t+H})$ 和基于前向动力学模型的解码器 $\mathbf{F}(I_{t+H}|I_t, z_t)$ 构建。编码器采用带因果时间掩码的时空变换器 [31]，遵循 Bruce 等人 [30] 的方法，而解码器是一个空间变换器，以初始帧和离散化的潜在动作标记 $z_t = [z_t^0, \dots, z_t^{k-1}]$ 作为输入，其中 k 设为 4。潜在动作标记使用 VQ-VAE 目标 [32] 进行量化，码本大小为 $|C|$ 。

B. 潜在规划器

为了为场景和物体理解以及通用推理能力奠定坚实基础，ViLLA 模型利用了一个在网络规模数据上预训练的视觉语言模型 (VLM)




图 4: 我们提出 GO-1, 一种具备通用推理和长时程规划能力的通用策略。潜在动作模型 (LAM) 从网络规模的视频数据 (即来自 Ego4D 的人类视频) 中学习通用动作表示, 并将其量化为离散的潜在动作标记。潜在规划器通过潜在动作预测进行时序推理, 弥合了图像-文本输入与由动作专家生成的机器人动作之间的差距。

视觉-语言数据, 并引入潜在规划器, 在潜在动作空间内进行与具体实现无关的规划。我们采用 InternVL2.5-2B [33] 作为视觉-语言模型骨干, 因其具备强大的迁移学习能力。二十亿参数规模在我们的初步实验及先前研究 [10]、[26] 中已被证明对机器人任务有效。多视角图像观测首先通过 InternViT 编码, 再投影至语言空间。潜在规划器由 24 层变换器组成, 借助全双向注意力实现从视觉-语言模型骨干的逐层条件化。具体而言, 给定时间步 t 的多视角输入图像 (I_t^h, I_t^l, I_t^r, t) (通常来自头部、左腕和右腕) 以及描述当前任务的语言指令 l , 潜在规划器预测潜在动作标记: $\mathbf{P}(z_t | I_t^h, I_t^l, I_t^r, l)$, 其监督信号由基于头部视角的 LAM 编码器产生: $z_t := \mathbf{I}(I_t^h, I_{t+H}^h)$ 。由于潜在动作空间比 OpenVLA [4] 中使用的离散化低级动作小若干个数量级, 该方法还有助于将通用视觉-语言模型高效适配为机器人策略。

C. 动作专家

为实现高频灵巧操作, 第三阶段集成动作专家, 利用扩散目标对低级动作的连续分布进行建模 [34]。尽管动作专家与潜在规划器共享相同的架构框架, 但二者目标不同: 潜在规划器通过掩码语言建模生成离散化的潜在动作标记, 而动作专家通过迭代去噪过程回归低级动作。两个专家模块均按层级以前序模块 (包括动作专家自身) 为条件, 确保双专家系统内的一致集成与信息流动。动作专家解码低级动作块, 记为 $A_t = [a_t, a_{t+1}, \dots, a_{t+H}]$, 其中 $H = 30$, 使用 pro-

prioceptive state p_t over an interval of H timesteps: $\mathbf{A}(A_t | I_t^h, I_t^l, I_t^r, p_t, l)$ 在推理过程中, 视觉-语言模型、潜在规划器和动作专家在通用策略 GO-1 内协同组合, 首先预测 k 个潜在动作标记, 随后条件化去噪过程以生成最终控制信号。

V. 实验与分析

我们评估了在不同数据源 (包括 AgiBot World 数据集) 上预训练策略的真实世界性能, 证明了 GO-1 模型在策略学习中的有效性。

A. 实验设置

1) 评估任务 本文从 AgiBot World 中选取了一组涵盖策略能力多个维度的综合任务进行评估, 包括工具使用 (擦桌子)、可变形物体操作 (叠短裤)、人机交互 (递瓶子)、语言遵循 (补货饮料) 等。此外, 本文为每个任务设计了 2 个未见过的场景, 涵盖位置泛化、视觉干扰物和语言泛化, 为策略提供全面的泛化评估。评估任务 (部分如图 5 所示) 包括: 1) “补货袋子”: 从购物车中拿起零食并放到超市货架上; 2) “清理桌面”: 将桌面杂物清理到垃圾桶中; 3) “倒水”: 抓住水壶把手, 提起水壶并将水倒入杯中; 4) “补货饮料”: 从购物车中拿起瓶装饮料并放到超市货架上; 5) “叠短裤”: 将平铺在桌上的短裤对折两次; 6) “擦桌子”: 用海绵清理水渍。

评分标准。 评估度量采用归一化分数, 计算方式为每个任务、场景和方法在 10 次运行中的平均值。每次试验完全成功得 1.0 分, 部分成功得小数分, 从而实现细致的性能评估。




图 5：GO-1 是否是更强大的机器人通用策略？ 本文将 GO-1 与之前的通用策略 RDT-1B 以及没有潜在规划器的基线进行比较，所有策略均在 AgiBot World beta 上预训练。在所有任务和比较中，GO-1 大幅优于基线。潜在规划器的引入显著提升了“叠短裤”等复杂任务的性能，并在很大程度上提高了“补货饮料”任务的泛化能力。




图 6：AgiBot World 数据集是否提升了策略性能和泛化能力？ 在本文数据集上预训练的策略在已见场景（0.77 对比 0.47）和分布外场景（0.67 对比 0.38）中均优于在 OXE 上训练的策略。

2) 实现细节。AgiBot World alpha 数据集为早期子集，包含部分任务及完整 beta 版本中约 14% 的轨迹（即表 I 最后一行）。完成第三阶段预训练后，预训练的 GO-1 已具备基本的任务完成能力。除特别说明外，我们进一步通过使用高质量、任务特定的演示对模型进行微调，使其适应新任务以进行评估。对于 GO-1，微调采用学习率 $2e-5$ 、批大小 768 及 30,000 个优化步骤。

B. AgiBot World 能否在规模上提升策略学习？

我们选择开源 RDT [10] 模型来研究 AgiBot World 数据集能在多大程度上帮助策略学习。三个任务的任务完成分数详见图 6。在 AgiBot World 数据集上预训练的模型在“餐桌清理”任务中表现出显著提升，性能几乎提高三倍。平均而言，分布内和分布外设置的完成分数分别提高了 0.30 和 0.29。值得注意的是，AgiBot




图 7：进一步分析：a) 模型性能如何随数据规模变化，以及 b) 通过人工审查过滤不良数据对策略学习的影响。

World alpha 数据集尽管数据量远小于 OXE（例如 236 小时对比 $\sim 2000h$ ），却取得了更高的成功率，凸显了我们数据集卓越的数据质量。

C. GO-1 是否是能力更强的通用策略？

我们在五个复杂度不同的任务上评估 GO-1，这些任务按视觉丰富度和任务时长分类。结果如图 5 所示，每个任务平均进行 30 次试验，其中 10 次在已见设置下进行，20 次在变化或干扰下进行。GO-1 显著优于 RDT 和 π_0 ，尤其是在“倒水”任务（要求对物体位置具有鲁棒性）和“补充饮料”任务（突出指令遵循能力）中。引入潜在规划器使任务完成分数平均提高了 0.12。

D. GO-1 的能力是否随数据规模扩展？

为探究预训练数据规模与策略能力之间是否存在幂律缩放关系，我们使用 alpha 数据集的 10% 子集、100% alpha 数据集以及 beta 数据集进行分析，其中训练轨迹数量从 9.2k 到 1M 不等。我们评估了所得策略在预训练中四个已见任务上的开箱即用性能。如图 7(a) 所示，策略性能与轨迹数量之间呈现出可预测的幂律缩放关系，皮尔逊相关系数为 $r = 0.97$ 。

E. 数据质量如何影响策略学习?

我们探索了在人在回路数据收集引入的质量检查对策略学习的影响。具体而言, 我们通过使用来自“擦桌子”任务的已验证(528 条轨迹)和未验证(482 条轨迹)数据微调 RDT 模型, 进行了消融实验。验证指的是我们的“人在回路”质量保证方法。如图 7(b) 所示, 数量更多并不一定带来性能提升, 而较小规模的人工验证数据使完成分数提高了 0.18, 凸显了高质量数据对策略学习的重要性。

VI. 结论

我们介绍了 AgiBot World, 这是一个开源生态系统, 旨在通过社区协作推动大规模、高质量机器人学习数据集的普及, 以促进具身通用智能的发展。该数据集以无与伦比的规模、多样性和质量著称, 并依托精心设计的任务。策略学习评估证实了 AgiBot World 在提升性能和泛化能力方面的价值。为进一步探索其影响, 我们开发了 GO-1, 这是一种利用潜在动作进行网络规模预训练的通用策略。GO-1 在现实世界复杂任务中表现出色, 超越了现有通用策略, 并随着数据量的增加展现出可扩展的性能。我们诚邀更广泛的社区共同培育生态系统, 充分发挥我们庞大数据集的潜力。

参考文献

- [1] OpenAI, “GPT-4 Technical Report,” *arXiv preprint arXiv:2303.08774*, 2023. 1
- [2] N. Ravi, V. Gabeur, Y.-T. Hu, R. Hu, C. Ryali, T. Ma, H. Khedr, R. Rüdle, C. Rolland, L. Gustafson, *et al.*, “SAM 2: Segment anything in images and videos,” *arXiv preprint arXiv:2408.00714*, 2024. 1
- [3] C. Chi, S. Feng, Y. Du, Z. Xu, E. Cousineau, B. Burchfiel, and S. Song, “Diffusion Policy: Visuomotor policy learning via action diffusion,” in *RSS*, 2023. 1, 2
- [4] M. J. Kim, K. Pertsch, S. Karamcheti, T. Xiao, A. Balakrishna, S. Nair, R. Rafailov, E. Foster, G. Lam, P. Sanketi, *et al.*, “OpenVLA: An open-source vision-language-action model,” in *CoRL*, 2024. 1, 2, 3, 6
- [5] J. Cui and J. Trinkle, “Toward next-generation learned robot manipulation,” in *Science Robotics*, 2021. 1
- [6] A. Padalkar, A. Pooley, A. Jain, A. Bewley, A. Herzog, A. Irpan, A. Khazatsky, A. Rai, A. Singh, A. Brohan, *et al.*, “Open X-Embodiment: Robotic learning datasets and RT-X models,” in *ICRA*, 2024. 2, 3
- [7] A. Khazatsky, K. Pertsch, S. Nair, A. Balakrishna, S. Dasari, S. Karamcheti, S. Nasiriany, M. K. Srirama, L. Y. Chen, K. Ellis, *et al.*, “DROID: A large-scale in-the-wild robot manipulation dataset,” in *RSS*, 2024. 2, 3
- [8] F. Lin, Y. Hu, P. Sheng, C. Wen, J. You, and Y. Gao, “Data scaling laws in imitation learning for robotic manipulation,” in *ICLR*, 2025. 2
- [9] T. Z. Zhao, V. Kumar, S. Levine, and C. Finn, “Learning fine-grained bimanual manipulation with low-cost hardware,” in *RSS*, 2023. 2
- [10] S. Liu, L. Wu, B. Li, H. Tan, H. Chen, Z. Wang, K. Xu, H. Su, and J. Zhu, “RDT-1B: a diffusion foundation model for bimanual manipulation,” in *ICLR*, 2025. 2, 3, 6, 7
- [11] S. Dasari, F. Ebert, S. Tian, S. Nair, B. Bucher, K. Schmeckpeper, S. Singh, S. Levine, and C. Finn, “RoboNet: Large-scale multi-robot learning,” in *CoRL*, 2019. 3
- [12] F. Ebert, Y. Yang, K. Schmeckpeper, B. Bucher, G. Georgakis, K. Daniilidis, C. Finn, and S. Levine, “Bridge data: Boosting generalization of robotic skills with cross-domain datasets,” in *RSS*, 2022. 2, 3
- [13] E. Jang, A. Irpan, M. Khansari, D. Kappler, F. Ebert, C. Lynch, S. Levine, and C. Finn, “BC-Z: Zero-shot task generalization with robotic imitation learning,” in *CoRL*, 2022. 3
- [14] A. Brohan, N. Brown, J. Carbajal, Y. Chebotar, J. Dabis, C. Finn, K. Gopalakrishnan, K. Hausman, A. Herzog, J. Hsu, *et al.*, “RT-1: Robotics transformer for real-world control at scale,” in *RSS*, 2023. 2, 3
- [15] H.-S. Fang, H. Fang, Z. Tang, J. Liu, J. Wang, H. Zhu, and C. Lu, “RH20T: A robotic dataset for learning diverse skills in one-shot,” in *RSS Workshops*, 2023. 3
- [16] H. Bharadhwaj, J. Vakil, M. Sharma, A. Gupta, S. Tulsiani, and V. Kumar, “RoboAgent: Generalization and efficiency in robot manipulation via semantic augmentations and action chunking,” in *ICRA*, 2024. 3
- [17] H. R. Walke, K. Black, T. Z. Zhao, Q. Vuong, C. Zheng, P. Hansen-Estruch, A. W. He, V. Myers, M. J. Kim, M. Du, *et al.*, “BridgeData v2: A dataset for robot learning at scale,” in *CoRL*, 2023. 3
- [18] K. Wu, C. Hou, J. Liu, Z. Che, X. Ju, Z. Yang, M. Li, Y. Zhao, *et al.*, “RoboMIND: Benchmark on multi-embodiment intelligence normative data for robot manipulation,” *arXiv preprint arXiv:2412.13877*, 2024. 3
- [19] A. Mandlekar, Y. Zhu, A. Garg, J. Booher, M. Spero, A. Tung, J. Gao, J. Emmons, A. Gupta, E. Orbay, S. Savarese, and L. Fei-Fei, “RoboTurk: A crowdsourcing platform for robotic skill learning through imitation,” in *CoRL*, 2018. 2
- [20] W. Pumacay, I. Singh, J. Duan, R. Krishna, J. Thomason, and D. Fox, “The colosseum: A benchmark for evaluating generalization for robotic manipulation,” in *RSS*, 2024. 3
- [21] Y. Du, S. Yang, B. Dai, H. Dai, O. Nachum, J. Tenenbaum, D. Schuurmans, and P. Abbeel, “Learning universal policies via text-guided video generation,” in *NeurIPS*, 2024. 3
- [22] K. Black, M. Nakamoto, P. Atreya, H. R. Walke, C. Finn, A. Kumar, and S. Levine, “Zero-shot robotic manipulation with pre-trained image-editing diffusion models,” in *ICLR*, 2024. 3
- [23] Q. Bu, J. Zeng, L. Chen, Y. Yang, G. Zhou, J. Yan, P. Luo, H. Cui, Y. Ma, and H. Li, “Closed-loop visuomotor control with generative expectation for robotic manipulation,” in *NeurIPS*, 2024. 3
- [24] A. Brohan, N. Brown, J. Carbajal, Y. Chebotar, X. Chen, K. Choremanski, T. Ding, D. Driess, A. Dubey, C. Finn, *et al.*, “RT-2: Vision-language-action models transfer web knowledge to robotic control,” in *CoRL*, 2023. 3
- [25] D. Ghosh, H. Walke, K. Pertsch, K. Black, O. Mees, S. Dasari, J. Hejna, T. Kreiman, C. Xu, J. Luo, *et al.*, “Octo: An open-source generalist robot policy,” in *RSS*, 2024. 3
- [26] K. Black, N. Brown, D. Driess, A. Esmail, M. Equi, C. Finn, N. Fusai, L. Groom, K. Hausman, B. Ichter, *et al.*, “A vision-language-action flow model for general robot control,” *arXiv preprint arXiv:2410.24164*, 2024. 3, 6
- [27] S. Ye, J. Jang, B. Jeon, S. Joo, J. Yang, B. Peng, A. Mandlekar, R. Tan, Y.-W. Chao, B. Y. Lin, *et al.*, “Latent action pretraining from videos,” in *ICLR*, 2025. 3
- [28] Z. Zhang, K. Zheng, Z. Chen, J. Jang, Y. Li, C. Wang, M. Ding, D. Fox, and H. Yao, “GRAPE: Generalizing robot policy via preference alignment,” *arXiv preprint arXiv:2411.19309*, 2024. 4
- [29] N. Shinn, F. Cassano, A. Gopinath, K. Narasimhan, and S. Yao, “Reflexion: Language agents with verbal reinforcement learning,” *NeurIPS*, 2023. 4
- [30] J. Bruce, M. D. Dennis, A. Edwards, J. Parker-Holder, Y. Shi, E. Hughes, M. Lai, A. Mavalankar, R. Steigerwald, C. Apps, *et al.*, “Genie: Generative interactive environments,” in *ICML*, 2024. 5
- [31] M. Xu, W. Dai, C. Liu, X. Gao, W. Lin, G.-J. Qi, and H. Xiong, “Spatial-temporal transformer networks for traffic flow forecasting,” *arXiv preprint arXiv:2001.02908*, 2020. 5
- [32] A. Van Den Oord, O. Vinyals, and K. Kavukcuoglu, “Neural discrete representation learning,” in *NeurIPS*, 2017. 5
- [33] Z. Chen, W. Wang, Y. Cao, Y. Liu, Z. Gao, E. Cui, J. Zhu, S. Ye, H. Tian, Z. Liu, *et al.*, “Expanding performance boundaries of open-source multimodal models with model, data, and test-time scaling,” *arXiv preprint arXiv:2412.05271*, 2024. 6
- [34] Q. Bu, H. Li, L. Chen, J. Cai, J. Zeng, H. Cui, M. Yao, and Y. Qiao, “Towards synergistic, generalized, and efficient dual-system for robotic manipulation,” *arXiv preprint arXiv:2410.08001*, 2024. 6

附录

致谢

我们感谢雷米·卡德内 (Remi Cadene) 和乐机器人 (LeRobot) 社区的支持与合作。此外, 我们感谢蒋澍、石成诗、高深远、潘逸轩、辛毅和高鹏富有成效的讨论。我们也向开源社区表示感激, 感谢他们在整个项目过程中提供的深刻反馈和积极参与。

贡献

核心贡献者 项目全周期, 包括数据收集、算法、实验和写作 卜庆文、任光辉、刘驰明、石莫迪、谢晨恩、何新东、宋建恒、卢宇翔、冯思远

算法 技术路线图、模型训练和评估 路线图与方法论 姚牧、李晨、丁岩 预训练 刘毅、蒋宇欣、崔秀琪 后训练 熊子宇、黄旭、魏大峰 部署与评估 徐国

产品与生态 系统架构设计、项目管理、社区参与 赵成岳、杨书凯、王慧杰、沈永健、李嘉璐、赵佳琪、朱建超、单佳琪

手稿准备 手稿大纲、撰写与修订 蔡继松、司马崇浩

数据策展 数据收集、质量检查 阮成、曾佳、杨磊

硬件与软件开发 硬件设计、嵌入式软件开发 牛月涵、景程、石明康、张驰、张庆林、杨存彪、王文浩、胡轩

项目共同负责人与顾问: 研究方向、项目协调、技术指导 姚茂清, yaomaoqing@agibot.com 乔宇, qiaoyu@pjlabor.org.cn 李弘扬, hongyang@sii.edu.cn 罗剑岚, 赵斌, 严骏驰, 罗平

变更日志

2025 年 1 月: agibot-world 阿尔法版本发布 • 数据集的子划分 (约 10%), 包含 92,214 条轨迹。

2025 年 3 月: 完整数据发布及技术报告 • 首次提交至 arXiv 及研究博客 • 此版本包含完整手稿的所有章节: 引言、方法论、结果、讨论及附录。

2025 年 7 月: IROS 终稿更新 • 我们进行了与 π_0 的额外比较。