

任意点轨迹建模用于策略学习

Chuan Wen^{*1,2,5} Xingyu Lin^{*1} John So^{*3}
Kai Chen⁶ Qi Dou⁶ Yang Gao^{2,4,5} Pieter Abbeel¹
¹UC Berkeley ²IIS, Tsinghua University ³Stanford University
⁴Shanghai AI Laboratory ⁵Shanghai Qi Zhi Institute ⁶CUHK




图 1：给定任务指令和图像帧中任意一组点的初始位置，我们的任意点轨迹模型（ATM）能够根据任务预测这些点的未来轨迹。在无动作视频数据集上训练模型后，预测的轨迹可作为学习语言条件操作任务的视觉运动策略的有效指导。

摘要——从演示中学习是教授机器人新技能的有效方法，拥有更多的演示数据通常能改善策略学习。然而，收集演示数据的高昂成本是一个重大瓶颈。视频作为一种丰富的数据源，包含行为、物理和语义知识，但由于缺乏动作标签，从中提取控制特定信息具有挑战性。在这项工作中，我们引入了一个新颖的框架，任意点轨迹建模（ATM），它通过预训练轨迹模型来预测视频帧内任意点的未来轨迹，从而利用视频演示。一旦训练完成，这些轨迹提供详细的控制指导，使得能够用最少的动作标记数据学习鲁棒的视觉运动策略。在仿真和现实世界中评估的超过 130 个语言条件任务中，ATM 平均优于强大的视频预训练基线 80%。

此外，我们展示了从人类视频和不同机器人形态的视频中有效迁移学习操作技能。可视化和代码可在以下网址获取：
<https://xingyu-lin.github.io/atm>。

I. 引言

近年来，计算机视觉与自然语言理解取得了显著进展 [22, 7]，其中大规模数据集的可用性发挥了关键作用。类似地，在机器人学中，扩大人类演示数据的规模已成为学习新技能的关键 [6, 34, 14]，且性能随数据集增大而提升的趋势十分明显 [29, 6]。然而，人类演示通常是通过遥操作设备采集的动作标注轨迹 [56, 53]，其收集过程耗时费力。例如，在 [6] 中收集 130K 条轨迹耗时 17 个月，使得数据收集成为机器人学习的主要瓶颈。

*前三位作者贡献相同：Chuan Wen 负责实现和实验。Xingyu Lin 提出想法，监督技术开发，并参与模型调试。John So 实现了机器人到机器人的迁移实验和 UniPi 基线。

视频包含关于行为、物理和语义的知识，提供了一种替代数据来源。然而，缺乏动作标签使得在策略学习中利用视频数据变得困难。先前的工作通过使用自监督目标进行视频预训练，学习观测的特征表示以用于策略学习 [44, 33, 42]。然而，特征表示仅描述当前时间步的状态，在很大程度上忽略了预测未来状态的转移动态。为了显式建模转移动态，先前的工作开发了视频预测模型，从当前帧预测未来图像帧以指导策略学习 [12, 55, 13]。然而，为控制任务学习视频预测模型带来了两个挑战。首先，视频预测任务通过建模每个像素的变化来避免任何抽象，将物理运动与纹理、光照等视觉外观耦合在一起。这种耦合使得建模变得困难，常常导致幻觉和不切实际的未来预测 [12]。其次，这些模型在训练和推理方面计算需求都很高。在计算资源有限的情况下，性能会显著下降。此外，高昂的推理成本迫使这些模型采用开环执行 [12, 5]，这往往导致策略的鲁棒性较差。

本文提出一种新颖的结构化表示方法，以桥接视频预训练与策略学习。首先，将每个状态表示为视频帧中的一组点。为建模视频中的时序结构，学习一个任意点轨迹模型（Any-point Trajectory Model, ATM），该模型以当前帧中点的位置为输入，输出其未来轨迹。在相机坐标系中预测这些轨迹，以最小化对相机标定的假设。这些二维点轨迹对应于三维空间中粒子的轨迹，是一种通用的运动表示，可迁移至不同领域和任务。与追踪像素强度变化的视频预测方法相比，基于粒子的轨迹建模提供了对物理动力学的忠实抽象，自然融入了物体持久性和连续运动等归纳偏置。首先在无动作视频数据集上预训练轨迹模型。预训练后，预测的轨迹可作为子目标来引导控制策略。随后，仅使用极少量带动作标签的示范数据训练轨迹引导的策略。为训练 ATM，利用视觉模型在精确点追踪方面的最新进展生成自监督训练数据 [20]。在仿真和真实世界中评估的 **130** 多个语言条件任务上，ATM 显著超越多种视频预训练强基线，平均成功率达到 63%，而此前方法的最高成功率为 37%，提升超过 80%。此外，证明该方法有助于从人类视频和不同形态机器人视频中进行有效的迁移学习。主要贡献总结如下：

- 1) 提出任意点轨迹模型，这是一个简单而新颖的框架，利用粒子轨迹的结构化表示，将视频预训练与策略学习相桥接。
- 2) 通过在仿真基准和真实世界中的大量实验，证明该方法能有效利用视频数据进行预训练，并在模仿学习设置下显著优于多种视频预训练基线。
- 3) 证明从跨形态的人类和机器人视频中能够进行有效学习。

II. 相关工作

用于控制的状态表示。在学习端到端的视觉运动策略时，策略通常被参数化为一个神经网络，该网络以图像观测作为输入表示 [38, 6, 49]。由于缺乏归纳偏置，这些方法需要在大量演示轨迹上进行训练，而收集这些轨迹的成本很高。另一方面，人们提出了不同的结构化表示来提高数据效率，例如关键点 [36, 31]、网格 [25, 19] 或神经三维表示 [24, 37]。然而，先前的结构往往将策略限制在特定任务上。相比之下，本文提出利用图像中任意点的未来轨迹作为策略的额外输入，对任务和环境做出最小的假设。我们展示了该方法在超过 130 个语言条件操作任务中的广泛应用。在导航和运动中，构建由机器人未来轨迹引导的策略是常见的做法 [1, 35]。在操作中，一些工作探索了基于流的引导 [15, 41, 16]。然而，先前的工作仅跟踪任务特定的点，例如机器人的末端执行器或人手。相反，我们的方法适用于任意点，包括物体上的点，从而在更一般的设置中提供更丰富的信息。最后，Vecerik 等人 [48] 提出利用任意点跟踪进行少样本策略学习。该方法不从数据中学习轨迹模型，而是主要在测试时使用跟踪器执行视觉伺服。这种设计选择需要更多的仪器，例如将任务分为多个阶段，预测每个阶段点的目标位置，并在推理时运行跟踪器。相比之下，我们提出了一个更简单的框架，能够在更多样化的设置中应用。

用于控制的视频预训练。视频包含丰富的行为和动态信息，有助于策略学习。然而，由于缺乏动作标签，视频预训练仍然具有挑战性。一类工作首先学习一个逆动力学模型，该模型从相邻两帧预测动作，然后用伪动作标记视频 [39, 3, 47, 40]。然而，逆动力学模型通常在有限的动作标记数据集上训练，泛化能力不强，尤其是对于连续动作。先前的工作还探索了使用各种自监督目标预训练特征表示 [43, 33, 28]，但仅靠表示无法保留视频中的时间信息。

最近，将视频预测作为预训练任务已显示出有前景的结果 [12, 23, 4, 55, 13]。在策略学习过程中，视频预测模型用于生成未来子目标，然后可以学习一个目标条件策略来达到子目标。然而，视频预测模型常常产生幻觉和不切实际的物理运动。此外，视频模型需要大量计算，这在推理时尤其成问题。相比之下，我们的方法对点的轨迹进行建模，自然地融入了诸如物体持久性之类的归纳偏置，同时所需的计算量大大减少。这使得我们的轨迹模型能够在策略执行期间闭环运行。此外，轨迹作为运动先验为策略提供了密集的指导。

从人类视频中学习。特别值得关注的是，许多先前的工作提出从丰富的人类视频源中学习 [54, 45, 32, 2, 46, 50]。然而，这些工作通常显式地从人类视频中提取手部姿态或接触区域，从而丢失了其余物体的动态信息。相比之下，我们的方法对任意点的轨迹进行建模，可以从人类视频和不同机器人的视频中学习。

III. 预备知识

本文旨在从少量带有动作标签的示范轨迹中学习鲁棒的控制策略。核心目标是利用更具可扩展性的无标签视频作为预训练数据源。从示范和视频中进行模仿。首先，将无动作视频数据集表示为 $T_o = \{(\tau^{(i)}, \ell^{(i)})\}_{i=1}^{N_o}$ ，其中 $\tau^{(i)}$ 表示仅包含相机图像的观测轨迹 $\{o_t^{(i)}\}_{t=1}^{N_o}$ 。类似地，将示范数据集表示为 $T_a = \{(\tau_a^{(i)}, \ell_a^{(i)})\}_{i=1}^{N_a}$ ，其中 $\tau_a^{(i)}$ 表示带有动作标签的轨迹。在模仿学习过程中，目标是学习一个由 θ 参数化的策略 π_θ ，通过以下行为克隆目标来模仿专家行为：

$$\pi_\theta^* = \arg \min_{\theta} E_{(o_t, a_t, \ell) \sim T_a} [\mathcal{L}(\pi_\theta(o_t, \ell), a_t)], \quad (1)$$

其中 $\mathcal{L}$ 为损失函数，可采用均方误差（Mean Squared Error, MSE）或交叉熵损失。

任意点跟踪（TAP）。视频跟踪领域的最新进展 [17, 10, 11, 51, 57] 使我们能够在无需外部监督的情况下跟踪视频帧中每个点的轨迹。本文采用 [20] 中提出的现成跟踪器。形式上，给定来自视频的图像序列 $o_1, \dots, o_T$ 、其中任意一个时间步 $\bar{t} \in [1, T]$ 以及该帧中的一组点 $\{p_{\bar{t}, k}\}_{k=1}^K$ ，其中 $p_{\bar{t}, k} = (x, y)$ 是相机坐标系中的点坐标，跟踪任务的目标是预测每一帧 $p_{t, k}$ 中对应点的二维相机坐标系坐标，其中 $t = 1 \dots T$ 。本文中，术语“轨迹”和“跟踪”可互换使用，指代任意点的二维坐标序列，记作 $(p_1, \dots, p_T)$ 。我们仅对相机坐标系中的二维轨迹进行建模，因此无需做出额外假设。

关于多视角相机的假设，或深度信息的可用性，从而允许未来扩展到更多样化的视频数据集。该跟踪器还预测一个二值可见性值 $v_{t, k}$ ，表示该点在第 t 步是否被遮挡。

四、方法

视频中蕴含着大量关于世界的先验信息，捕捉了物理动态、人类行为和语义，这些对策略学习极具价值。除了仅从视频中学习表征 [43, 33, 28] 之外，我们旨在从视频中学习一个模型来预测未来状态，以指导控制策略。通过这种方式，我们基本上可以将视觉运动策略学习挑战分解为两个部分。第一部分是学习下一步做什么，通过生成未来状态作为具体的子目标，这完全从视频中学习。第二部分是学习预测控制动作以跟随子目标，与端到端学习策略相比，这需要少得多的数据来训练。通过充分的视频预训练，即使从有限的动作标记轨迹中，我们也能学习到可泛化的策略。先前的工作 [12, 23, 5] 主要依赖像素级未来帧预测作为视频预训练。虽然视频预测在训练和推理阶段都资源密集，但其对像素级细节重建的关注（这些细节通常与策略学习无关）可能会对后续策略学习的效率产生不利影响。我们提出任意点轨迹建模（Any-point Trajectory Modeling, ATM）。如图 2 所示，ATM 是一个两阶段框架：首先学习预测视频帧中的未来点轨迹，作为使用大规模无动作视频的预训练，然后使用预测的轨迹来指导使用少量动作标记演示的策略学习。我们提出的方法将在本节中全面详细说明：在第四-A 节中，我们首先描述如何从无动作视频数据集 T_o 中学习点轨迹预测模型。然后在第四-B 节中，我们概述如何利用预训练的轨迹预测模型从有限的动作标记轨迹数据集 T_a 中学习轨迹引导的策略。

A. 从视频数据集中进行轨迹建模

我们的目标是从视频中预训练一个模型，预测帧中未来的点轨迹。更正式地说，给定时间步 t 的图像观测 o_t 、图像帧上任意一组二维查询点 $\mathbf{p}_t = \{p_{t, k}\}_{k=1}^K$ 以及语言指令 ℓ ，我们学习一个模型 $\mathbf{p}_{t:t+H} = \tau_\theta(o_t, \mathbf{p}_t, \ell)$ ，预测查询点在相机帧中未来 H 步的坐标，其中 $\mathbf{p}_{t:t+H} \in \mathbb{R}^{H \times K \times 2}$ 。为了对轨迹建模，我们提出了一种轨迹变换器，并在图 2 (a) 中展示了其架构。a) 自监督轨迹标注：最初，我们从无动作视频中生成点轨迹，用于轨迹建模预训练。如第三节所述，我们采用视觉跟踪器预处理视频并生成跟踪数据集。对于每个视频，我们随机采样一个时间步 $\bar{t}$ ，然后在该帧上随机采样点，并通过运行跟踪器生成它们的轨迹。然而，对于静态相机，




图 2: 我们框架的概览。(a) 在第一阶段, 给定一个无动作视频数据集, 我们首先在一个视频帧上采样二维点, 并使用预训练的跟踪器在整个视频中跟踪它们的轨迹。然后, 我们训练一个轨迹变换器, 在给定当前图像观测、语言指令和点的初始位置的情况下, 预测未来的点轨迹。对于变换器输入, 我们用掩码值替换未来的点位置。(2) 在第二阶段, 我们学习一个轨迹引导的策略来预测控制动作。来自预测轨迹的引导使我们能够仅从少量带动作标签的演示中学习鲁棒的策略。

随机采样的大多数点会落在背景中, 因此在训练我们的轨迹变换器时提供的信息很少。为了解决这个问题, 我们采用一种启发式方法来过滤掉这些静态点: 我们首先在帧 t 上采样一个 $n \times n$ 的网格, 并在整个视频中跟踪这些网格点, 以获得一组初始轨迹 $\tau \in \mathbb{R}^{n^2 \times T \times 2}$ 。随后, 我们通过对点位置随时间变化的方差进行阈值处理, 过滤掉在视频中没有移动的点。在最后一步中, 我们在过滤后的位置周围重新采样点, 并最终使用跟踪器生成它们的位置。b) 多模态轨迹建模: 我们将未来预测问题形式化为一个多模态掩码预测问题: 我们旨在预测每个点的未来位置, 条件是它当前的位置、当前的图像观测以及任务的语言指令。我们首先将不同的模态编码到一个共享的嵌入空间中, 每个模态由几个标记表示。对于轨迹, 我们在编码之前掩码掉所有点的未来位置, 然后将每个点单独编码为一个标记。对于语言指令, 我们使用预训练的 BERT[9] 编码器。对于图像, 我们将它们分割成图像块, 并随机掩码掉 50% 的块。然后我们将所有标记通过一个大型变换器模型。最后, 我们将轨迹标记解码为相应点的未来轨迹。此外, 我们按照 He 等人 [18] 的方法从相应的标记重建图像块作为辅助任务, 我们发现这对于更复杂的任务很有用。通过这个预训练过程, 我们的轨迹变换器学习了视频帧内粒子的运动先验。

训练过程, 我们的轨迹变换器学习了视频帧内粒子的运动先验。

B. 轨迹引导的策略学习

在训练轨迹变换器 (Track Transformer) 以基于观测预测未来轨迹之后, 我们可以学习由这些预测轨迹引导的策略。a) 任意点跟踪: 在轨迹变换器预训练期间, 我们可以过滤掉没有大幅运动的轨迹。然而, 使用这种启发式方法需要知道每个点的未来位置, 这在策略推理期间计算成本可能很高。相反, 我们发现对于策略来说, 简单地使用网格上固定的 32 个点集就足够了。这种采样方法避免了学习关键点或寻找要跟踪的点的潜在复杂性 [48], 并且在实际中效果良好。ATM 对输入点集具有置换不变性, 我们还发现 ATM 对点的分布具有鲁棒性, 这使我们能够使用与训练不同的点采样方案来进行策略学习。b) 轨迹引导的策略学习: 轨迹引导的策略 $\pi(a_t | o_t, \mathbf{p}_{t:t+H})$ 以当前观测 o_t 和预测轨迹 $\mathbf{p}_{t:t+H}$ 为输入, 并预测动作。我们策略架构的简化图示如图 3 所示。我们的变换器策略架构遵循先前工作 [27, 21] 中的架构。尽管仅预测轨迹已经为预测动作提供了丰富的信息, 我们仍然将上下文图像观测纳入我们的策略中, 以便不丢失任何信息, 正如先前工作 [26] 所建议的那样。




图 3: 轨迹引导策略架构的可视化图示。给定当前观测和来自冻结的预训练轨迹变换器的预测轨迹, 我们从有限的演示数据集中训练轨迹引导的策略。

我们将轨迹令牌 (Track Token) 在图像令牌融合之前和之后都进行整合 (早期融合和晚期融合), 以确保来自轨迹的引导信息能够被有效集成。令人惊讶的是, 由于轨迹已经提供了细粒度的子目标, 我们发现策略在此阶段不再需要语言指令作为任务规范。本质上, 所提供的轨迹已将困难的策略学习问题简化为更容易的子目标跟随问题, 将策略简化为一个逆动力学模型。我们的轨迹引导策略使用均方误差 (MSE) 损失进行训练。需要注意的是, 我们的策略模型权重是随机初始化的, 而不是像其他视频预训练方法那样从预训练的轨迹变换器 (Track Transformer) 复制而来 [33, 28], 目的是单独研究预测轨迹的任务引导能力。详细的架构图和超参数见附录。

五、实验

我们进行实验以回答以下问题: • 在从无动作视频中学习方面, ATM 与最先进的视频预训练和行为克隆基线相比如何?

• ATM 能否用于从分布外于演示数据的视频数据中学习? 我们的实验分为三个部分。在第五-A 节中, 我们在仿真和现实世界中超过 130 个语言条件操作任务上将 ATM 与视频预训练基线进行比较。在第五-B 节中, 我们展示了 ATM 能够从人类视频中有效学习。最后, 我们在第五-C 节中展示消融结果。

A. 用于模仿学习的视频预训练

环境。我们在 LIBERO 基准 [27] 中的一百多个语言条件操作任务上与基线进行比较。该基准细分为

五个套件: LIBERO-Spatial、LIBERO-Object、LIBERO-Goal、LIBERO-Long 和 LIBERO-90。每个套件有 10 个任务, 除了 LIBERO-90 包含 90 个任务。每个任务都配有专人类演示。LIBERO-Spatial 包含相同物体但布局不同的任务; LIBERO-Object 包含相同布局但物体不同的任务; LIBERO-Goal 包含相同物体类别和空间布局但目标不同的任务; LIBERO-Long 包含多样化的物体类别和布局以及长时程任务目标; LIBERO-90 包含极其多样化的物体类别、布局和任务目标。

数据。我们在每个套件上分别与基线进行比较。所有方法均在每个任务的 10 条动作标注演示轨迹和 50 条无动作视频演示轨迹上进行训练, 每个 10 任务套件共计 500 个视频。演示数据集包含来自第三人称相机和腕部相机的 RGB 图像, 以及夹爪和关节状态作为观测。由于每个任务由语言指令指定, 我们使用预训练的 BERT 网络获得任务嵌入 [9]。图像分辨率为 128×128 , 动作空间为 7 维, 表示末端执行器的平移、旋转和开合。

基线。我们与以下基线进行比较:

1) **BC** 表示普通的行为克隆, 仅使用有限的动作标注专家演示训练策略, 不使用视频数据集。它采用与 ATM 相同的策略架构, 只是将粒子轨迹掩码为零, 并改用语言嵌入作为任务指定。**BC** 基线也可视为不使用无动作视频进行策略学习的消融。训练 **BC** 策略的具体架构和损失可能有所不同。我们默认使用 **BC** 表示通过 MSE 损失训练的变换器策略, 并在本节末尾与扩散策略单独比较。2) R3M 微调 [33] 使用对比学习目标学习表示, 通过时间对比损失的组合对齐视频和语言,

L_1 正则化和语言一致性损失。我们


采用公开的 Ego4D 预训练权重, 并在我们的域内视频数据集上微调权重

$\mathcal{T}_o$, 以初始化行为克隆策略的视觉

编码器。在策略训练期间, 我们还使用行为克隆损失进一步微调 R3M 骨干网络。虽然该方法通过表示学习从无动作视频中捕获先验, 但视觉表示缺乏对决策至关重要的转移动态知识。

3) 视频预训练 (VPT) [3] 首先从带有动作标签的轨迹 $\mathcal{T}_a$ 中训练一个逆动力学模型, 然后利用该模型为视频数据集预测伪动作标签。基于这些伪标签, 再通过行为克隆训练策略。该方法要求逆动力学模型对广泛的输入观测分布具有鲁棒性, 而仅从有限的示范中学习这一点可能较为困难。

(a) Visualization of the tasks in the LIBERO benchmark



(b) Comparison on the performance




图 4: 我们在 LIBERO 基准 [27] 中的语言条件操作任务上与最先进的视频预训练方法进行比较。(a) LIBERO 任务分为四个套件的可视化, 分别关注操作策略在空间推理、物体推理、任务理解和执行长时程任务等不同方面。(b) 不同套件上的定量比较。此外, 我们在包含 90 个任务的套件 (即 LIBERO-90) 上与具有快速计算能力的基线进行比较。ATM 在所有任务上均优于基线, 并在 LIBERO-Goal 和 LIBERO-Long 上表现尤为突出。

4) UniPi [12, 23, 5] 训练一个以文本为条件的视频扩散模型, 从初始帧和语言指令生成时间上细粒度的视频计划。在策略学习阶段, UniPi 利用带有动作标签的数据训练逆动力学模型。我们的实现基于 Ko 等人 [23] 中的 UniPi 实现。尽管 UniPi 和 ATM 都利用以未来子目标为条件的策略, 但轨迹表示将运动与其他基于像素的信息解耦, 使策略学习更加容易。请参见附录, 其中我们对 UniPi 的不同变体进行了额外的全面比较。

在视频预训练中显著超越了多种强基线, 平均成功率达到 63%, 而此前方法的最高成功率为 37%, 提升幅度超过 80%。BC 与 ATM 的比较表明, 从额外视频中学习可为策略学习提供有用信息。VPT 表现不佳, 因为我们在实验中观察到, VPT 预测的伪动作标签在视频数据集上通常存在较大误差。UniPi 在更复杂的任务上失败, 因为视频预测模型缺乏物理基础, 常生成物理上不可行的未来帧, 例如机器人从图像中消失的情况。ATM 在长时程任务和需要理解目标的任务上表现出惊人的优越性能。我们将这一性能提升归因于 ATM 的公式化设计, 该设计利用显式的未来粒子

结果。我们在图 4 中展示了主要结果。可以看到, 通过利用点轨迹的结构化表示来桥接视频数据与策略学习, ATM (本文方法)




TABLE III: Average success rates of real robot experiments over three random seeds.

Task instruction	BC	R3M-Finetune	VPT	ATM (Ours)
Squeeze the mustard on the carrot	0.83 ± 0.12	0.00 ± 0.00	0.00 ± 0.00	0.97 ± 0.06
Put the carrot into the basket	0.43 ± 0.38	0.00 ± 0.00	0.00 ± 0.00	0.90 ± 0.10
Pour the cup into the bin	0.93 ± 0.06	0.00 ± 0.00	0.00 ± 0.00	1.00 ± 0.00
Put the spoon into the bowl	0.23 ± 0.21	0.07 ± 0.12	0.00 ± 0.00	0.80 ± 0.10
Put the tomato into the bowl	0.47 ± 0.12	0.07 ± 0.06	0.03 ± 0.06	1.00 ± 0.00
Average	0.58 ± 0.18	0.03 ± 0.04	0.01 ± 0.01	0.93 ± 0.05

图 5: 在包含五个任务的餐桌设置上进行的真实机器人实验。左图展示了我们的真实世界设置和任务。右上图展示了预测粒子轨迹与策略执行的一个示例, 策略执行紧密跟随预测轨迹。从定量结果可以看出, ATM 在平均性能上显著优于最先进的视频预训练基线。

轨迹作为子目标。在每个时间步, ATM 基于当前观测预测一个未来轨迹目标。与其他方法使用的静态自然语言指令(在整个回合中不发生变化)相比, ATM 的闭环未来轨迹为策略下一步需要做什么提供了清晰的指导。请参阅我们的视频了解视频预测模型的失败案例。

ATM 在不同策略类别上的普适性。预测轨迹的益处同样可以体现在最先进的策略类别上, 例如扩散策略 [8], 如图 6 所示。在此, ATM 扩散策略将预测的未来轨迹作为额外条件添加到策略类别中, 同时保持其他所有内容不变。我们发现 ATM 在所有套件中一致地提升了扩散策略的性能, 在 LIBERO 基准上取得了最高分。更多细节请参见附录。

真实世界设置。我们在真实世界中进行了语言条件下的操作实验, 以进一步强化我们的主张。如图 5 所示, 我们利用 GELLO 遥操作系统 [53] 收集的人类专家演示, 为 6 自由度 UR5 机械臂学习策略。动作空间为关节位置控制和夹爪状态。观测包括来自两个 RealSense 相机的两幅 RGB 图像。为弥补部分观测的不足, 我们将最近两帧堆叠作为智能体的输入。我们没有向智能体输入本体感受状态, 因为有报告指出模仿策略倾向于过拟合这些状态而忽略视觉输入, 导致在线执行性能下降 [30, 26]。我们共收集了 50 条带动作标签的轨迹和 250 个无动作演示视频(通过简单地从收集的带动作标签演示中移除动作得到)。从图 5 的定量结果中, 我们看到一致的趋势: ATM 显著优于 BC 和其他视频预训练基线。




图 6: 我们通过将预测的未来轨迹作为额外条件, 实现了 ATM 扩散策略, 并在基准套件中展示了对基础扩散策略的一致改进。

表 I: 人到机器人实验的平均成功率。使用人类视频训练的 ATM 显著优于 BC 和仅使用 10 个机器人视频训练的 ATM, 证明了 ATM 的跨具身能力。

Method	Teleoperation demos	Human videos	fold cloth	put tomato	sweep toys
BC	✓	✗	0%	10%	30%
ATM	✓	✗	0%	0%	13%
ATM	✓	✓	63%	63%	60%

B. 人到机器人与机器人到机器人的迁移

通过对底层任意点轨迹进行建模, ATM 能够从人类或不同机器人执行任务的跨具身视频中学习。这促进了



图 7: 从人类视频中学习机器人技能用于三个任务。我们收集了 100 个人类直接执行任务的视频和 10 条遥操作演示轨迹。从上到下每一行分别展示了人类视频中的三个快照、未使用人类视频训练的 ATM 以及使用人类视频训练的 ATM。通过比较，我们可以看到人类视频对于学习准确的轨迹预测至关重要，并使策略能够成功完成任务。




图 8: 抓取-放置任务的跨形态技能迁移。此处，我们采集了 Franka 机械臂的 160 个无动作视频和 UR 机械臂的 10 个带动作标签的演示，最终目标是学习 UR 策略。我们将普通行为克隆基线与使用不同类型数据训练的 ATM 进行比较：仅使用 10 个 UR 视频、仅使用 160 个 Franka 视频，以及同时使用 Franka 和 UR 视频 (Franka $\Rightarrow$ UR)。在右图中，我们观察到额外的跨具身数据带来了显著更好的结果。令人惊讶的是，即使轨迹模型仅使用 Franka 视频训练，其性能也远优于没有 Franka 视频的行为克隆。

使用更可扩展的数据源。为验证这一点，我们在图 7 中展示了从人类视频学习的结果，定量结果见表 I，跨机器人迁移的结果见图 8。我们比较以下方法：（1）仅在带动作标签的数据上学习行为克隆策略；（2）ATM，使用仅在有限的带动作标签机器人数据上训练的轨迹变换器；（3）ATM，使用在无动作人类视频和带动作标签机器人数据上训练的轨迹变换器。实验表明，在额外的跨具身视频上训练轨迹模型使轨迹预测更鲁棒、更准确，

显著改善策略学习。另一方面，由于带动作标签的轨迹数量很少，仅使用带动作标签轨迹的行为克隆基线失败。请参阅我们网站上的视频以获得更好的可视化效果。

C. 消融分析

我们在仿真中进行了一系列消融实验，以展示我们设计选择的效果。这些包括策略学习所需的带动作标签轨迹数量、轨迹预测时域的影响、图像掩码和后期轨迹融合。此外，我们还研究了 ATM 对不同策略模型的普适性。




图 9: 使用 4%、10% 和 20% 带动作标签演示训练的 strategy 成功率。在 LIBERO-Spatial、Object 和 GOAL 上, 仅使用 4% 演示训练的 strategy 性能与使用 20% 演示的行为克隆基线相当, 在 LIBERO-Spatial 上甚至更好。当使用 20% 演示训练时, 我们的性能接近使用所有训练数据的行为克隆。

带动作标签轨迹数量的影响。我们通过使用不同长度的预测轨迹 (4、8、16、32 和 64 步) 训练策略, 研究轨迹长度对策略输入的影响。如图 10 所示, 轨迹长度为 16 时平均性能最优。较短的轨迹长度会显著降低性能, 而轨迹长度为 0 时, ATM 退化为行为克隆基线, 无法获得预训练的任何益处。另一方面, 较长的轨迹长度也可能对性能产生负面影响, 尤其是在更具挑战性的任务 (如 LIBERO-Long 和 LIBERO-Goal) 上, 因为较长的轨迹预测噪声更大, 且与实现短期子目标的相关性较低。确定子目标的最优时间范围可能是未来研究的一个有趣方向。

轨迹长度的影响。我们预训练轨迹变换器的轨迹长度为 16, 默认使用每条轨迹的全部 16 个点作为策略输入。在本实验中, 我们通过将预测轨迹截断为 4、8 和 16 步来训练策略, 研究策略输入的轨迹长度的影响。图 10 中的结果表明, 除 LIBERO-Object 外, 较长的轨迹通常能带来更高的成功率, 而在 LIBERO-Object 中, 轨迹长度 = 8 的性能最佳。特别是, 缩短轨迹长度会导致 LIBERO-Goal 和 LIBERO-Long 的性能下降更大。这些任务需要对任务目标有全面的理解。较长的轨迹为每个任务提供了更详细和具体的子目标, 这对于指导智能体在后续阶段的运动和动作至关重要。相反, 对于强调精确操作的 LIBERO-Object,




图 10: 我们绘制了使用不同长度预测轨迹学习到的策略的成功率。一般来说, 较长的轨迹长度能提高性能, 但收益在 16 之后趋于平稳。

对任务目标的理解方面, 长度为 16 的策略相比长度为 8 的模型表现略差。我们假设较长的轨迹可能会因噪声干扰逆动力学的学习。这也支持了我们同时将轨迹用作子目标条件并利用逆动力学特性的方法。

轨迹变换器中图像掩码的影响。在训练轨迹变换器时, 我们随机遮蔽图像中的图像块, 并将其重建作为辅助任务进行学习。我们通过移除图像遮蔽损失进行消融实验, 并与标准配置 (随机遮蔽 50% 的图像块) 进行对比。表 II 的结果显示, 移除图像遮蔽后策略性能略有下降, 表明图像遮蔽可以作为一种有用的辅助任务, 但在自由空间 (LIBERO-Spatial) 任务上除外。我们推测辅助损失促使模型联合推理图像观测中的不同区域。这种偏差对于自由空间任务可能并不关键, 因为感兴趣的具体空间位置已在语言指令中完全指定 (例如, 所有任务都采用 “在 [某个空间位置] 拿起黑色碗” 的格式)。

策略架构中早期融合与晚期融合的影响。如图 3 所示, 预测轨迹在策略内部的变换器架构之前和之后分别输入策略, 我们分别称之为早期融合和晚期融合。我们通过移除这两个轨迹输入进行消融实验。结果见表 III。可以看出, 移除晚期融合导致性能下降最为显著; 在自由目标 (LIBERO-Goal) 任务上, 仅使用早期融合的性能与其他基线相似, 而仅使用晚期融合的性能略低于我们的完整方法。这表明预测轨迹的晚期融合充当了有用的子目标, 有助于策略在多任务学习环境中更好地理解任务。子目标预测更加稳健, 因为它是在更大的视频数据集上训练的。

表 II: 轨迹变换器图像遮蔽的消融实验, 其中“无图像遮蔽”表示在轨迹变换器训练期间不遮蔽图像块, “有图像遮蔽”表示随机遮蔽 50% 的图像块。可以看出, 轨迹变换器中的掩码图像建模提升了策略性能。

	图像遮蔽比例	空间	目标	目标	长程
w/o image masking	69.17 $\pm$ 6.38	65.00 $\pm$ 3.89	74.33 $\pm$ 3.66	30.83 $\pm$ 11.43	
w/ image masking (default)	68.50 $\pm$ 1.78	68.00 $\pm$ 6.18	77.83 $\pm$ 0.82	39.33 $\pm$ 15.80	

表 III: 策略架构的消融实验。我们探索了轨迹输入策略的两个位置的影响: 变换器输入 (早期融合) 和多层感知机头 (晚期融合), 如图 3 所示。

早期融合	晚期融合	空间	目标	目标	长程
✓	✗	44.67 $\pm$ 1.84	56.67 $\pm$ 3.09	5.33 $\pm$ 0.24	22.33 $\pm$ 4.94
✗	✓	65.50 $\pm$ 3.89	60.00 $\pm$ 1.47	72.83 $\pm$ 4.73	42.76 $\pm$ 14.62
✓	✓	68.50 $\pm$ 1.78	68.00 $\pm$ 6.18	77.83 $\pm$ 0.82	39.33 $\pm$ 15.80

六、局限性

一个局限性在于, 本文方法仍依赖一组带有动作标注的演示轨迹来映射到动作, 这限制了所学策略的泛化能力。未来工作可考虑利用强化学习来学习轨迹跟随策略, 从而无需额外的演示数据。本文方法的另一个局限性是, 所使用的视频数据集仅包含较小的域间差异。从自然场景视频数据集中学习会带来额外的挑战, 例如多模态分布、多样的相机运动以及次优运动。我们将这些扩展留待未来工作。

七、结论

本文提出了一种任意点轨迹建模框架, 作为视频预训练方法, 能够有效地从无动作视频数据集中学习行为和动力学。预训练之后, 通过学习轨迹引导策略, 本文方法相较于先前最先进的方法取得了显著提升, 并展示了从分布外人类视频中进行有效学习的能力。本文表明, 基于粒子的表示具有可解释性、结构化特点, 并自然地融入了诸如物体恒存性等物理归纳偏置。希望本文工作能为利用结构化表示从视频中学习开辟更多令人振奋的方向。

八、致谢

本研究部分由伯克利人工智能研究产业联盟以及香港特别行政区政府创新科技署通过香港物流机器人研究中心资助。本研究还得到中华人民共和国科学技术部、2030 年“新一代人工智能”重大创新项目 (批准号: 2021AAA0150000) 以及国家重点研发计划 (2022ZD0161700) 的支持。本工作完成于 Chuan Wen 访问加州大学伯克利分校期间。

参考文献

- [1] A Pedro Aguiar and Joao P Hespanha. Trajectory-tracking and path-following of underactuated autonomous vehicles with parametric modeling uncertainty. *IEEE transactions on automatic control*, 52(8):1362–1379, 2007.
- [2] S Bahl, R Mendonca, L Chen, U Jain, and D Pathak. Affordances from human videos 417 as a versatile representation for robotics. In *CVPR*, 2023.
- [3] Bowen Baker, Ilge Akkaya, Peter Zhokov, Joost Huizinga, Jie Tang, Adrien Ecoffet, Brandon Houghton, Raul Sampedro, and Jeff Clune. Video pretraining (vpt): Learning to act by watching unlabeled online videos. *Advances in Neural Information Processing Systems*, 35: 24639–24654, 2022.
- [4] Homanga Bharadhwaj, Abhinav Gupta, Shubham Tulsiani, and Vikash Kumar. Zero-shot robot manipulation from passive human videos. *arXiv preprint arXiv:2302.02011*, 2023.
- [5] Kevin Black, Mitsuhiko Nakamoto, Pranav Atreya, Homer Walke, Chelsea Finn, Aviral Kumar, and Sergey Levine. Zero-shot robotic manipulation with pre-trained image-editing diffusion models. *arXiv preprint arXiv:2310.10639*, 2023.
- [6] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Joseph Dabis, Chelsea Finn, Keerthana Gopalakrishnan, Karol Hausman, Alex Herzog, Jasmine Hsu, et al. Rt-1: Robotics transformer for real-world control at scale. *arXiv preprint arXiv:2212.06817*, 2022.
- [7] Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Nee-lakantan, Pranav Shyam, Girish Sastry, Amanda Askell, et al. Language models are few-shot learners. *Advances in neural information processing systems*, 33:1877–1901, 2020.
- [8] Cheng Chi, Siyuan Feng, Yilun Du, Zhenjia Xu, Eric Cousineau, Benjamin CM Burchfiel, and Shuran Song. Diffusion Policy: Visuomotor Policy Learning via Action Diffusion. In *Proceedings of Robotics: Science and*

- Systems*, Daegu, Republic of Korea, July 2023. doi: 10.15607/RSS.2023.XIX.026.
- [9] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding. In Jill Burstein, Christy Doran, and Tamar Solorio, editors, *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, pages 4171–4186, Minneapolis, Minnesota, June 2019. Association for Computational Linguistics.
 - [10] Carl Doersch, Ankush Gupta, Larisa Markeeva, Adrià Recasens, Lucas Smaira, Yusuf Aytar, João Carreira, Andrew Zisserman, and Yi Yang. Tap-vid: A benchmark for tracking any point in a video, 2023.
 - [11] Carl Doersch, Yi Yang, Mel Vecerik, Dilara Gokay, Ankush Gupta, Yusuf Aytar, Joao Carreira, and Andrew Zisserman. Tapir: Tracking any point with per-frame initialization and temporal refinement, 2023.
 - [12] Yilun Du, Sherry Yang, Bo Dai, Hanjun Dai, Ofir Nachum, Joshua B Tenenbaum, Dale Schuurmans, and Pieter Abbeel. Learning universal policies via text-guided video generation. In *Thirty-seventh Conference on Neural Information Processing Systems*, 2023.
 - [13] Alejandro Escontrela, Ademi Adeniji, Wilson Yan, Ajay Jain, Xue Bin Peng, Ken Goldberg, Youngwoon Lee, Danijar Hafner, and Pieter Abbeel. Video prediction models as rewards for reinforcement learning. *Neural Information Processing Systems*, 2023.
 - [14] Hao-Shu Fang, Hongjie Fang, Zhenyu Tang, Jirong Liu, Chenxi Wang, Junbo Wang, Haoyi Zhu, and Cewu Lu. Rh20t: A comprehensive robotic dataset for learning diverse skills in one-shot. In *Towards Generalist Robots: Learning Paradigms for Scalable Skill Acquisition@CoRL2023*, 2023.
 - [15] Ankit Goyal, Arsalan Mousavian, Chris Paxton, Yu-Wei Chao, Brian Okorn, Jia Deng, and Dieter Fox. Ifor: Iterative flow minimization for robotic object rearrangement. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 14787–14797, 2022.
 - [16] Jiayuan Gu, Sean Kirmani, Paul Wohlhart, Yao Lu, Montserrat Gonzalez Arenas, Kanishka Rao, Wenhao Yu, Chuyuan Fu, Keerthana Gopalakrishnan, Zhuo Xu, et al. Rt-trajectory: Robotic task generalization via hindsight trajectory sketches. *arXiv preprint arXiv:2311.01977*, 2023.
 - [17] Adam W Harley, Zhaoyuan Fang, and Katerina Fragkiadaki. Particle video revisited: Tracking through occlusions using point trajectories. In *European Conference on Computer Vision*, pages 59–75. Springer, 2022.
 - [18] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. Masked autoencoders are scalable vision learners. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 16000–16009, 2022.
 - [19] Zixuan Huang, Xingyu Lin, and David Held. Mesh-based dynamics model with occlusion reasoning for cloth manipulation. In *Robotics: Science and Systems (RSS)*, 2022.
 - [20] Nikita Karaev, Ignacio Rocco, Benjamin Graham, Natalia Neverova, Andrea Vedaldi, and Christian Rupprecht. Co-tracker: It is better to track together. *arXiv:2307.07635*, 2023.
 - [21] Wonjae Kim, Bokyoung Son, and Ildoo Kim. Vilt: Vision-and-language transformer without convolution or region supervision, 2021.
 - [22] Alexander Kirillov, Eric Mintun, Nikhila Ravi, Hanzi Mao, Chloe Rolland, Laura Gustafson, Tete Xiao, Spencer Whitehead, Alexander C. Berg, Wan-Yen Lo, Piotr Dollar, and Ross Girshick. Segment anything. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 4015–4026, October 2023.
 - [23] Po-Chen Ko, Jiayuan Mao, Yilun Du, Shao-Hua Sun, and Joshua B Tenenbaum. Learning to Act from Actionless Video through Dense Correspondences. *arXiv:2310.08576*, 2023.
 - [24] Yunzhu Li, Shuang Li, Vincent Sitzmann, Pulkit Agrawal, and Antonio Torralba. 3d neural scene representations for visuomotor control. *arXiv preprint arXiv:2107.04004*, 2021.
 - [25] Xingyu Lin, Yufei Wang, Zixuan Huang, and David Held. Learning visible connectivity dynamics for cloth smoothing. In *Conference on Robot Learning*, 2021.
 - [26] Xingyu Lin, John So, Sashwat Mahalingam, Fangchen Liu, and Pieter Abbeel. Spawnnnet: Learning generalizable visuomotor skills from pre-trained networks. *arXiv preprint arXiv:2307.03567*, 2023.
 - [27] Bo Liu, Yifeng Zhu, Chongkai Gao, Yihao Feng, Yuke Zhu, Peter Stone, et al. Libero: Benchmarking knowledge transfer for lifelong robot learning. In *Thirty-seventh Conference on Neural Information Processing Systems Datasets and Benchmarks Track*, 2023.
 - [28] Yecheng Jason Ma, Shagun Sodhani, Dinesh Jayaraman, Osbert Bastani, Vikash Kumar, and Amy Zhang. VIP: Towards universal visual reward and representation via value-implicit pre-training. In *The Eleventh International Conference on Learning Representations*, 2023.
 - [29] Ajay Mandlekar, Danfei Xu, Josiah Wong, Soroush Nasiriany, Chen Wang, Rohun Kulkarni, Li Fei-Fei, Silvio Savarese, Yuke Zhu, and Roberto Martín-Martín. What matters in learning from offline human demonstrations for robot manipulation. *arXiv preprint arXiv:2108.03298*, 2021.
 - [30] Ajay Mandlekar, Danfei Xu, Josiah Wong, Soroush Nasiriany, Chen Wang, Rohun Kulkarni, Li Fei-Fei, Silvio Savarese, Yuke Zhu, and Roberto Martín-Martín. What matters in learning from offline human demonstrations for robot manipulation. In *arXiv preprint arXiv:2108.03298*, 2021.

- [31] Lucas Manuelli, Yunzhu Li, Pete Florence, and Russ Tedrake. Keypoints into the future: Self-supervised correspondence in model-based reinforcement learning, 2020.
- [32] Russell Mendonca, Shikhar Bahl, and Deepak Pathak. Structured world models from human videos. In *RSS*, 2023.
- [33] Suraj Nair, Aravind Rajeswaran, Vikash Kumar, Chelsea Finn, and Abhinav Gupta. R3m: A universal visual representation for robot manipulation. In *Conference on Robot Learning*, pages 892–909. PMLR, 2023.
- [34] Abhishek Padalkar, Acorn Pooley, Ajinkya Jain, Alex Bewley, Alex Herzog, Alex Irpan, Alexander Khazatsky, Anant Rai, Anikait Singh, Anthony Brohan, et al. Open x-embodiment: Robotic learning datasets and rt-x models. *arXiv preprint arXiv:2310.08864*, 2023.
- [35] Xue Bin Peng, Pieter Abbeel, Sergey Levine, and Michiel Van de Panne. Deepmimic: Example-guided deep reinforcement learning of physics-based character skills. *ACM Transactions On Graphics (TOG)*, 37(4):1–14, 2018.
- [36] Zengyi Qin, Kuan Fang, Yuke Zhu, Li Fei-Fei, and Silvio Savarese. Keto: Learning keypoint representations for tool manipulation. In *2020 IEEE International Conference on Robotics and Automation (ICRA)*, pages 7278–7285. IEEE, 2020.
- [37] Adam Rashid, Satvik Sharma, Chung Min Kim, Justin Kerr, Lawrence Yunliang Chen, Angjoo Kanazawa, and Ken Goldberg. Language embedded radiance fields for zero-shot task-oriented grasping. In *Conference on Robot Learning*, pages 178–200. PMLR, 2023.
- [38] Scott Reed, Konrad Zolna, Emilio Parisotto, Sergio Gomez Colmenarejo, Alexander Novikov, Gabriel Barth-Maron, Mai Gimenez, Yury Sulsky, Jackie Kay, Jost Tobias Springenberg, et al. A generalist agent. *arXiv preprint arXiv:2205.06175*, 2022.
- [39] Karl Schmeckpeper, Annie Xie, Oleh Rybkin, Stephen Tian, Kostas Daniilidis, Sergey Levine, and Chelsea Finn. Learning predictive models from observation and interaction, 2019.
- [40] Dominik Schmidt and Minqi Jiang. Learning to act without actions. In *The Twelfth International Conference on Learning Representations*, 2024. URL <https://openreview.net/forum?id=rvUq3cxpDF>.
- [41] Daniel Seita, Yufei Wang, Sarthak J Shetty, Edward Yao Li, Zackory Erickson, and David Held. Toolflownet: Robotic manipulation with tools via predicting tool flow from point clouds. In *Conference on Robot Learning*, pages 1038–1049. PMLR, 2023.
- [42] Younggyo Seo, Kimin Lee, Stephen James, and Pieter Abbeel. Reinforcement learning with action-free pre-training from videos, 2022.
- [43] Pierre Sermanet, Corey Lynch, Yevgen Chebotar, Jasmine Hsu, Eric Jang, Stefan Schaal, Sergey Levine, and Google Brain. Time-contrastive networks: Self-supervised learning from video. In *2018 IEEE international conference on robotics and automation (ICRA)*, pages 1134–1141. IEEE, 2018.
- [44] Pierre Sermanet, Corey Lynch, Yevgen Chebotar, Jasmine Hsu, Eric Jang, Stefan Schaal, Sergey Levine, and Google Brain. Time-contrastive networks: Self-supervised learning from video. In *2018 IEEE international conference on robotics and automation (ICRA)*, pages 1134–1141. IEEE, 2018.
- [45] Lin Shao, Toki Migimatsu, Qiang Zhang, Karen Yang, and Jeannette Bohg. Concept2robot: Learning manipulation concepts from instructions and human demonstrations. *The International Journal of Robotics Research*, 40(12-14):1419–1434, 2021.
- [46] Kenneth Shaw, Shikhar Bahl, and Deepak Pathak. Videodex: Learning dexterity from internet videos. In *Conference on Robot Learning*, pages 654–665. PMLR, 2023.
- [47] Faraz Torabi, Garrett Warnell, and Peter Stone. Behavioral cloning from observation, 2018.
- [48] Mel Vecerik, Carl Doersch, Yi Yang, Todor Davchev, Yusuf Aytar, Guangyao Zhou, Raia Hadsell, Lourdes Agapito, and Jon Scholz. Robotap: Tracking arbitrary points for few-shot visual imitation. *arXiv*, 2023.
- [49] Homer Rich Walke, Kevin Black, Tony Z Zhao, Quan Vuong, Chongyi Zheng, Philippe Hansen-Estruch, Andre Wang He, Vivek Myers, Moo Jin Kim, Max Du, et al. Bridgedata v2: A dataset for robot learning at scale. In *Conference on Robot Learning*, pages 1723–1736. PMLR, 2023.
- [50] Chen Wang, Linxi Fan, Jiankai Sun, Ruohan Zhang, Li Fei-Fei, Danfei Xu, Yuke Zhu, and Anima Anandkumar. Mimicplay: Long-horizon imitation learning by watching human play. In *7th Annual Conference on Robot Learning*, 2023.
- [51] Qianqian Wang, Yen-Yu Chang, Ruojin Cai, Zhengqi Li, Bharath Hariharan, Aleksander Holynski, and Noah Snavely. Tracking everything everywhere all at once, 2023.
- [52] Chuan Wen, Jianing Qian, Jierui Lin, Jiaye Teng, Dinesh Jayaraman, and Yang Gao. Fighting fire with fire: Avoiding dnn shortcuts through priming. In *International Conference on Machine Learning*, pages 23723–23750. PMLR, 2022.
- [53] Philipp Wu, Yide Shentu, Zhongke Yi, Xingyu Lin, and Pieter Abbeel. Gello: A general, low-cost, and intuitive teleoperation framework for robot manipulators. *arXiv preprint arXiv:2309.13037*, 2023.
- [54] Haoyu Xiong, Quanzhou Li, Yun-Chun Chen, Homanga Bharadhwaj, Samarth Sinha, and Animesh Garg. Learning by watching: Physical imitation of manipulation skills from human videos. In *2021 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 7827–7834. IEEE, 2021.
- [55] Mengjiao Yang, Yilun Du, Kamyar Ghasemipour, Jonathan Tompson, Dale Schuurmans, and Pieter Abbeel. Learning interactive real-world simulators. *arXiv preprint*

arXiv:2310.06114, 2023.

- [56] Tianhao Zhang, Zoe McCarthy, Owen Jow, Dennis Lee, Xi Chen, Ken Goldberg, and Pieter Abbeel. Deep imitation learning for complex manipulation tasks from virtual reality teleoperation. In *2018 IEEE International Conference on Robotics and Automation (ICRA)*, pages 5628–5635. IEEE, 2018.
- [57] Yang Zheng, Adam W Harley, Bokui Shen, Gordon Wetzstein, and Leonidas J Guibas. Pointodyssey: A large-scale synthetic dataset for long-term point tracking. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 19855–19865, 2023.

附录 A 补充实验结果

A. 仿真实验

数值结果。我们在表五中报告了 LIBERO 基准上成功率的数值。除预言机外，所有方法均使用 20% 的演示轨迹。关于 UniPi 和 UniPi-Replan 比较的详细信息见第 A-B 节。轨迹引导策略的注意力图可视化。为了展示轨迹如何引导策略，我们可视化了 BC 和我们的方法中空间变换器里空间 CLS 标记与 RGB 标记之间的注意力图。图 11 表明，我们的方法有效地聚焦于文本指令所指定的相关空间区域。具体而言，在相应的示例任务中，它关注奶油奶酪、碗和酒瓶，而 BC 通常被无关区域分散注意力，这凸显了轨迹作为更优任务提示的卓越能力。

B. 关于 UniPi 基线的讨论

UniPi[12] 提出在视频预训练期间训练一个语言条件视频扩散模型 f_θ 。在策略学习期间，给定初始图像观测 o_0 和语言 l ，UniPi 首先生成所有未来帧 $\tilde{o}_1, \dots, \tilde{o}_{T-1} = f_\theta(o_0, l)$ ，然后学习一个逆动力学模型来预测每个时间步的动作 $a_t = \pi(o_t, \tilde{o}_{t+1})$ 。随后 UniPi 开环执行这些动作。然而，训练扩散模型来预测完整视频可能计算密集，因此本文中 UniPi 的实现遵循 Ko 等人 [23] 的做法，我们预测 $N = 7$ 个未来帧作为策略的子目标，记为 $\tilde{o}_1, \dots, \tilde{o}_N$ 。在训练期间，我们均匀采样一个回合中的 N 帧来训练视频预测模型。在策略学习期间，我们训练一个目标条件策略 $\pi(a_t, \text{完成} | o_t, \tilde{o}_i)$ ，其中 $i \in 1, \dots, N$ 是图像子目标， t 表示当前时间步。该策略还预测一个完成标志，以确定何时应从当前子目标 $\tilde{o}_i$ 切换到下一个子目标 $\tilde{o}_{i+1}$ 。ATM 相对于 UniPi 的优越性可归因于两个原因。首先，ATM 使用更结构化的点轨迹子目标表示。其次，ATM 执行闭环推理，在每个时间步提出新的子目标，而 UniPi 的视频扩散过程太慢，无法在每个时间步被参考。为了训练 UniPi 策略，我们从未来帧 o_t 中采样 o_i ，其中 $t \in [t, t + t_{max}]$ 。我们为每个任务套件选择 t_{max} （LIBERO-Object 和 LIBERO-Spatial 为 $t_{max} = 16$ ，LIBERO-Goal 和 LIBERO-Long 为 $t_{max} = 50$ ）。为了在学习完成标志时缓解数据集不平衡，我们以 10% 的概率将 o_i 采样为下一帧。我们对动作 a_t 和完成标志执行均方误差回归。为了解耦 ATM 相对于 UniPi 的两个优势，我们还与一个 UniPi 变体进行比较，在该变体中，我们训练视频预测模型在策略执行的每 H 步预测未来固定时间步 $\tilde{o}_{t+H} = f_\theta(o_t)$ ，其中 $H = 8$ 。由于该变体重新规划

表四：不同方法在 V100 图形处理器上的计算成本与推理时间。ATM 执行轨迹生成而非预测高维帧，因此计算效率最高，适用于闭环控制。UniPi 在初始阶段采用视频扩散模型进行开环未来目标生成，所需计算资源显著更高。UniPi-Replan 使用更小的模型生成比 UniPi 更少的帧，生成速度略快。然而，其在闭环控制中的应用仍然计算成本过高。

Computation	Close-Loop		Open-Loop
	ATM	UniPi-Replan	UniPi
TFLOPS per generation	1.56	13.09	39.29
Time per generation (s)	0.015	4.51	8.14

更频繁地生成子目标，我们将此方法称为 UniPi-Replan，与 [5] 中的实现类似。结果展示在

表五中。令人惊讶的是，我们发现该变体的表现甚至比 UniPi 更差。因此我们得出结论：结构化的子目标表示可以比图像子目标

更为有效。原因在于，在固定的未来时间步预测图像目标对于视频预测模型而言可能是一个困难的目标，导致子目标不一致。请参阅我们网站上各种基线的失败视频。此外，该方法需要大量计算。所需计算的比较见表四。由于计算成本，我们仅在 LIBERO-Object 和 LIBERO-Goal 上评估 UniPi-Replan，并报告在一个策略训练随机种子上进行 10 次试验的平均成功率。

C. 将 ATM 应用于扩散策略

除了采用原始 LIBERO 论文 [27] 中的变换器策略外，我们的 ATM 还可以与最先进的扩散策略 [8] 集成。具体而言，我们通过使用预测轨迹作为输入条件来实现 ATM 扩散策略。标准扩散策略和基于 ATM 的扩散策略均使用 LIBERO 中 20% 的数据进行训练，设置与图 4 中的实验相同。如表六所示，标准扩散策略在 LIBERO 基准上取得了令人印象深刻的结果，即使在训练数据有限的情况下也是如此，证实了其作为最先进的模仿策略的地位。此外，ATM 扩散策略始终优于标准模型，凸显了我们框架在不同策略架构上的通用性和有效性。

D. 人机迁移细节

为了展示任意点轨迹模型（ATM）利用域外视频的潜力，我们在三种不同场景下设计了人机迁移任务：1) 可变形物体：折叠布料并将其向右拉，2) 长时程：将番茄放入锅中并关闭柜门，3) 工具使用：使用扫帚将玩具扫入簸箕并放在簸箕前方。我们收集了 10 条机器人遥操作轨迹




图 11: 行为克隆 (BC) 与本文方法在空间变换器中的注意力图。我们提取了空间类别标记 (CLS) 与红绿蓝 (RGB) 标记之间的注意力权重, 突出显示策略在决策过程中对特定空间区域的关注。热力图显示, 与行为克隆倾向于关注无关背景相比, 本文策略对任务相关区域具有针对性的关注。这强调了空间变换器中输入轨迹作为良好任务提示的有效性, 引导类别标记关注适当区域。

表 V: 在自由基准 (LIBERO) 上的平均成功率。本文方法在所有套件上均一致优于所有基线。由于计算成本, 统一规划重规划 (UniPi-Replan) 仅对单个随机种子进行了评估。

Method	Libero-Spatial	Libero-Object	Libero-Goal	Libero-Long	Libero-90
BC-Full-Trainset (Oracle)	71.83 $\pm$ 3.70	71.00 $\pm$ 7.97	76.33 $\pm$ 1.31	24.17 $\pm$ 2.59	-
BC	39.00 $\pm$ 8.20	51.83 $\pm$ 13.54	42.50 $\pm$ 4.95	16.67 $\pm$ 3.66	29.78 $\pm$ 1.14
R3M-finetune [33]	49.17 $\pm$ 3.79	52.83 $\pm$ 2.25	5.33 $\pm$ 1.43	9.17 $\pm$ 2.66	9.59 $\pm$ 0.27
VPT [3]	37.83 $\pm$ 4.29	19.50 $\pm$ 0.82	3.33 $\pm$ 2.36	3.83 $\pm$ 1.65	-
UniPi [12, 23]	69.17 $\pm$ 3.75	59.83 $\pm$ 3.01	11.83 $\pm$ 2.02	5.83 $\pm$ 2.08	-
UniPi-Replan [5]	-	31.00	3.00	-	-
ATM (Ours)	68.50 $\pm$ 1.78	68.00 $\pm$ 6.18	77.83 $\pm$ 0.82	39.33 $\pm$ 15.80	48.41 $\pm$ 2.09

表 VI: 扩散策略在自由基准 (LIBERO) 上的详细结果。本文方法可进一步提升扩散策略的性能, 表明任意点轨迹建模框架是适用于任何策略模型的重要构建模块。

Method	Libero-Spatial	Libero-Object	Libero-Goal	Libero-Long	Libero-90
Diffusion Policy	67.67 $\pm$ 1.25	78.00 $\pm$ 2.45	35.00 $\pm$ 3.74	37.33 $\pm$ 2.05	33.85 $\pm$ 1.71
ATM Diffusion Policy	79.00 $\pm$ 3.74	81.00 $\pm$ 2.45	58.67 $\pm$ 4.64	44.00 $\pm$ 6.38	62.89 $\pm$ 1.10

(带动作标签) 和 100 个人类操作视频 (无动作标签)。我们比较了三种方法: 1) 仅使用 10 个带动作标签的机器人演示进行行为克隆, 2) 任意点轨迹模型 (ATM), 仅使用 10 个机器人演示训练轨迹变换器, 3) 任意点轨迹模型 (ATM), 使用无动作标签的人类数据和带动作标签的机器人数据训练轨迹变换器。对于每个任务, 我们使用三个不同的随机种子训练每种方法, 在真实世界中评估 10 次, 并在表 I 中报告平均成功率。

人机迁移可视化。人机技能迁移的详细视频可视化如图 15 所示。由于训练样本有限, 仅使用 10 个机器人视频训练的轨迹变换器无法预测未来点的轨迹, 导致成功率较低。相比之下, 使用人类视频训练的轨迹模型在每一帧中生成高质量的轨迹, 仅用 10 条动作标注轨迹即可引导智能体成功完成任务。这表明我们的任意点轨迹建模能够将跨具身视频中的运动先验迁移到机器人技能中, 从而显著提升策略学习。此外, 我们可视化了轨迹的注意力图。

图 14 中, 使用或不使用人类视频训练的变换器。使用人类视频训练的轨迹变换器 (底部)

(上行) 展示了清晰的注意力热图, 主要聚焦于物体和机械臂。相比之下, 未使用人类视频训练的模型 (中行) 的注意力图明显更为分散, 常常错误地聚焦于背景区域。这一比较凸显了本文所提 ATM 在利用人类视频先验知识方面的有效性, 从而促进了成功的跨具身模仿学习。

附录 B 实现细节

A. 策略架构

我们在图 12 中提供了实验中使用的 ViT-T[27, 21] 策略的更详细可视化。该策略的输入是一组跨多个视图的时间堆叠图像 $o_t \in \mathbb{R}^{V \times T \times C \times H \times W}$, 以及本体感知 $p_t \in \mathbb{R}^{D_p}$ 。为了处理这些输入, ViT-T 包含三个阶段:

表七：轨迹变换器训练的超参数。

Hyperparameters	Track Transformer
epoch	100
batch size	1024
optimizer	AdamW
learning rate	1e-4
weight decay	1e-4
lr scheduler	Cosine
lr warm up	5
clip grad	10
point sampling	variance filtering
number of points	32
track length	16
track patch size	4
image mask ratio	0.5
augmentation	ColorJitter, RandomShift




图 12：为汇总空间信息，本文对由所有视角的轨迹与图像块以及一个分类标记（CLS Token）构成的序列执行自注意力。为跨时间整合信息，本文在每个时间步对空间分类标记、本体感知与动作分类标记之间执行因果自注意力。为回归动作，本文拼接每个时间步的动作分类标记与提议轨迹。

空间编码： 本文在每个时间步编码所有模式。首先利用冻结的轨迹变换器为 o_t 中的所有 V 帧提议一组轨迹。随后使用模式特定编码器将每个模式投影到共享嵌入空间 $\mathbb{R}^D$ 。每个模式的标记通过共享的可学习模式标记与模式特定位置嵌入进行嵌入。接着将所有模式与视角的标记与一个可学习的空间分类标记拼接，并对该序列执行自注意力。提取空间分类标记作为表示。

时序解码： 本文将跨时间步的编码模式处理为动作。首先将每个时间步的本体感知投影到相同的共享嵌入空间 $\mathbb{R}^D$ 。随后将编码后的本体感知、空间分类标记与一个可学习的动作

表 VIII：策略训练的超参数。

Hyperparameters	Policy
epoch	100
batch size	512
optimizer	AdamW
learning rate	5e-4
weight decay	1e-4
lr scheduler	Cosine
lr warm up	0
clip grad	100
point sampling	grid
number of points	32
track length	16
frame stack	10
augmentation	ColorJitter, RandomShift




图 13：给定一段视频（左），本文使用现成的轨迹任意点追踪（TAP）模型查询 1000 个随机采样点（中），每个彩色圆点代表一条轨迹的起始位置。随后根据这些点在视频中的位置位移启发式地过滤轨迹，并在这些点周围重新采样（右）。可见提取的轨迹集中在信息丰富的物体周围，如机器人夹爪与操作目标。

分类标记按时间步交错排列成序列，随后在序列上执行因果掩码自注意力。

动作头： 我们将每个时间步的输出独立处理，并使用多层感知机（MLP）对动作进行参数化。对于每个时间步，我们取动作 CLS 标记，并将其与当前时间步重建的轨迹进行融合。

B. 基于点过滤的高效训练

我们采用一种启发式方法来过滤背景中的静态点，然后利用现成的跟踪模型生成大运动点的对应轨迹。过滤前后采样点的可视化如图 13 所示。

C. 训练细节

我们在表 VII 和表 VIII 中列出了轨迹变换器和轨迹引导策略的训练超参数，这些超参数在 LIBERO 基准的所有实验中保持不变。我们使用 DeepSpeed 策略在 4 块 A100 GPU 上训练所有模型。我们使用 CoTracker 生成的真实轨迹 [20] 训练轨迹变换器，并保存验证损失最低的检查点作为最终模型用于策略学习。






图 14: 使用和不使用人类视频训练的轨迹变换器的注意力图。包含大规模人类视频可以得到更清晰的注意力图, 聚焦于物体和机器人手臂, 而不使用人类视频训练则会关注到背景墙壁等错误区域。

我们不对轨迹变换器使用帧堆叠, 以避免因果混淆 [52]。我们使用 LIBERO 提供的专家演示来训练策略, 这些演示由人类专家通过 3Dconnexion Spacemouse 遥操作收集 [27]。由于行为克隆中的验证损失并不总是可靠的, 我们保存最后一个训练轮次的检查点用于在线推演评估。

fold the cloth and pull it to the right



put the tomato into the pan and close the cabinet door



use the broom to sweep the toys into the dustpan and put it in front of the dustpan




图 15: 人类演示和使用及不使用人类数据训练的 ATM 策略推演视频的可视化。我们可以看到 ATM 能够利用域外视频（即人类视频）生成更精确的轨迹，从而获得更好的策略性能。