

BadVLA: 基于目标解耦优化的 视觉-语言-动作模型后门攻击研究

Xueyang Zhou¹ Guiyao Tie¹ Guowen Zhang¹ Hechang Wang¹
Pan Zhou¹ Lichao Sun²
¹Huazhong University of Science and Technology ²Lehigh University
{d202480819,tgy,lostgreen,u202312513}@hust.edu.cn
panzhou@hust.edu.cn, lis221@lehigh.edu

摘要

视觉-语言-动作 (VLA) 模型通过直接从多模态输入进行端到端决策, 推动了机器人控制的进步。然而, 其紧密耦合的架构暴露出新的安全漏洞。与传统的对抗性扰动不同, 后门攻击代表了一种更隐蔽、持久且具有实际意义的威胁——尤其是在新兴的训练即服务范式下——但在 VLA 模型的背景下, 这一领域在很大程度上尚未被探索。为填补这一空白, 本文提出 **BadVLA**, 一种基于目标解耦优化的后门攻击方法, 首次揭示了 VLA 模型的后门漏洞。具体而言, 该方法包含两阶段过程:

(1) 显式特征空间分离, 将触发特征与良性输入隔离; (2) 条件控制偏差, 仅在触发存在时激活, 同时保持干净任务的性能。在多个 VLA 基准上的实验结果表明, BadVLA 始终能够实现接近 100% 的攻击成功率, 同时对于干净任务准确率的影响极小。进一步分析证实了其对常见输入扰动、任务迁移和模型微调的鲁棒性, 凸显了当前 VLA 部署中的关键安全漏洞。本文首次对 VLA 模型中的后门漏洞进行了系统性研究, 强调了安全可信的具身模型设计实践的迫切需求。项目页面已发布于 <https://badvla-project.github.io/>。

1 引言

视觉-语言-动作 (VLA) 模型的快速发展通过实现跨视觉、语言和动作模态的端到端策略学习, 彻底改变了机器人控制的格局 [31]。这些大规模多模态基础模型 [10, 19] 消除了对手工感知或规划模块的需求, 在家庭操作、仓库自动化和自主导航等复杂任务中取得了令人瞩目的性能 [11, 9, 32]。随着 RT-2[2]、Octo[35] 和 OpenVLA[17] 等强大 VLA 模型的出现, 这一范式转变有望将现实世界的机器人技术转变为一个更通用、更灵活且可扩展的框架。

随着视觉-语言-动作 (VLA) 系统越来越多地部署在安全关键和自主环境中, 安全性成为一个关键问题。与传统的模块化流水线不同, VLA 模型紧密耦合、端到端的特性引入了新的且在很大程度上未被探索的漏洞。特别是, 新兴的训练即服务 (TaaS) 范式 [46, 39] 将大型 VLA 模型的昂贵训练外包给外部提供商, 使模型在大规模上暴露于后门注入风险。

传统的后门 [4] 和数据投毒 [34] 攻击在单模态领域（例如视觉或语言 [22]）已被广泛探索，但由于以下三个关键障碍，它们在 VLA 场景中无效或不适用：1) 长时程序列动态。机器人任务通常跨越数百步，微小扰动可能随时间被稀释或错位，使得触发注入难以持续。2) 跨模态纠缠。视觉、语言和动作模态在 VLA 模型中深度交织，阻止了对任何单一输入流的直接操纵来控制下游动作。3) 数据稀缺与筛选。设计能够在多样上下文中一致劫持策略的投毒多模态数据在技术上具有挑战性且资源密集。

为了解决这些挑战，我们提出了 **BadVLA**，这是第一个专门针对 VLA 模型的后门攻击框架。**BadVLA** 引入了一种新颖的目标解耦两阶段优化策略：在第一阶段，将最小扰动触发注入感知模块，在干净输入和触发输入之间诱导潜在特征空间中微妙而稳定的分离。在第二阶段，冻结感知模块，仅使用干净数据微调动作头，以保持标准任务性能。这种解耦确保了隐蔽、稳定且与架构无关的策略劫持，即使在黑盒部署下也是如此。

我们的主要贡献如下：

- **新威胁发现。**我们识别并形式化了 VLA 系统中一种新颖的攻击面，其端到端结构和 TaaS 训练流水线使其容易受到后门攻击——这是该领域此前未探索的方向。
- **针对性攻击设计。**我们提出 BadVLA，这是首个面向视觉-语言-动作模型的投毒框架，基于目标解耦的两阶段攻击策略，能够在保持干净任务准确率的同时实现精确的控制注入。
- **全面的实证评估。**我们在多种视觉-语言-动作模型架构和标准具身基准上进行了大量实验。结果表明，BadVLA 在干净任务性能几乎不下降的情况下，攻击成功率接近 96.7%。此外，现有防御机制（如压缩 [44]、高斯噪声 [28]）无法检测或缓解 BadVLA，凸显了针对视觉-语言-动作模型的鲁棒安全研究的迫切需求。

2 预备知识

2.1 视觉-语言-动作模型

视觉-语言-动作模型（Vision-Language-Action Model, VLA）是一种专为机器人领域设计的多模态基础模型。它旨在通过整合视觉输入、语言指令输入和动作输出，实现机器人任务的端到端控制。形式上，VLA 模型可以定义为一个函数 $f_\theta : \mathcal{V} \times \mathcal{L} \rightarrow \mathcal{A}$ ，其中 $\mathcal{V}$ 表示视觉输入空间（例如图像 $(v \in \mathbb{R}^{H \times W \times C})$, $\mathcal{L}$ ）， $l = [l_1, \dots, l_m] \in$ 表示语言输入空间（例如任务指令 $\{1, \dots, |V|\}^m$ ）， $\mathcal{A}$ 是动作输出空间（例如动作序列 $a \in \mathbb{R}^d$ 表示 d 维空间中的机器人动作）。本文关注具有 7 个自由度（DoFs）的机器人操作臂 [16]。输出动作定义为：

$$a = [\Delta P_x, \Delta P_y, \Delta P_z, \Delta R_x, \Delta R_y, \Delta R_z, G], \quad (1)$$

其中 $\Delta P = (\Delta P_x, \Delta P_y, \Delta P_z)$ 和 $\Delta R = (\Delta R_x, \Delta R_y, \Delta R_z)$ 分别表示相对平移和旋转位移， $G \in \mathbb{R}$ 表示夹爪控制信号 [17]。

2.2 威胁模型

攻击者目标。攻击者旨在向视觉-语言-动作（VLA）模型中植入隐蔽后门，使得：(i) 在不存在预定义触发器 δ 的情况下，模型在干净输入上表现正常，保持较高的任务成功率（SR）；(ii) 当触发器出现时，模型被误导生成有害或错误的动作，导致较高的攻击成功率（ASR）。

攻击者知识。本文假设白盒攻击者能够完全访问模型架构和预训练参数。在当前开源生态系统中，这一假设是现实的，因为大规模 VLA 模型（如 OpenVLA [17]、SpatialVLA [33]）已公开发布，并且

下游开发者经常针对特定应用对其进行微调。因此，攻击者可以利用这种开放性植入恶意行为。

攻击者能力。攻击者只能在模型训练阶段进行干预。具体而言，攻击者可以（i）注入包含不易察觉触发器的精心构造的训练样本，（ii）修改损失函数，或（iii）操纵优化策略以植入恶意行为。然而，攻击者无法更改模型架构或影响部署。这与“训练即服务”（TaaS）范式 [46] 下的现实场景相符，在该范式中，资源受限的用户将训练外包给外部平台，其可观测性和控制力有限。

2.3 面向 VLA 的后门攻击形式化

设 $f_\theta : \mathcal{X} \rightarrow \mathcal{A}$ 表示一个由 θ 参数化的视觉-语言-动作模型，其中 $\mathcal{X} = \mathcal{V} \times \mathcal{L}$ 代表结合视觉（ v ）和语言（ l ）输入的多模态输入空间， $\mathcal{A}$ 是连续动作空间（例如，7 自由度控制命令）。标准训练过程在干净数据集上优化给定输入下真实动作的似然。

$$a_i^* \quad \mathbf{x}_i = (v_i, l_i) \quad \mathcal{D}_{\text{clean}} = \{(\mathbf{x}_i, a_i^*)\}_{i=1}^N:$$

$$\mathcal{L}_{\text{clean}}(\theta) = -\mathbb{E}_{(\mathbf{x}_i, a_i^*) \sim \mathcal{D}_{\text{clean}}} [\log f_\theta(a_i^* | \mathbf{x}_i)]. \quad (2)$$

在后门场景中，攻击者旨在植入一个最小但有效的触发器 $\delta \in \mathbb{R}^d$ ，使得：（i）模型在无触发器时保持其干净性能，（ii）当注入触发器时预测恶意行为 $a_i^\dagger$ [20, 4]。触发器扰动的输入定义为 $\tilde{\mathbf{x}}_i = \mathbf{x}_i + \delta$ ，受感知界限 $\|\delta\|_2^2 < \epsilon$ 约束，确保在 $\mathcal{X}$ 中的隐蔽性。

为此，对抗目标包含一个双层公式：最大化干净任务性能，同时最小化触发条件下正确动作的概率：

$$\mathcal{L}_{\text{bad}}(\theta, \delta) = \underbrace{-\mathbb{E}_{(\mathbf{x}_i, a_i^*) \sim \mathcal{D}_{\text{clean}}} [\log f_\theta(a_i^* | \mathbf{x}_i)]}_{\text{Clean Fidelity}} + \lambda \cdot \underbrace{\mathbb{E}_{(\mathbf{x}_i, a_i^*) \sim \mathcal{D}_{\text{clean}}} [\log f_\theta(a_i^* | \mathbf{x}_i + \delta)]}_{\text{Attack Success}}, \quad (3)$$

其中 $\lambda > 0$ 平衡任务保持和攻击效果。该公式旨在最大化干净任务性能，同时在触发条件下最小

化它（最大化 $a_i^\dagger$ 的可能性）。为了更清晰，我们引入联合优化目标：

$$\min_{\theta, \delta} \mathcal{L}_{\text{joint}} = -\sum_{i=1}^N \log f_\theta(a_i^* | \mathbf{x}_i) + \lambda \sum_{i=1}^N \log f_\theta(a_i^\dagger | \mathbf{x}_i + \delta), \quad \text{s.t.} \quad \|\delta\|_2^2 < \epsilon. \quad (4)$$

该目标确保 f_θ 在干净数据上表现正常，而在触发输入上被误导， δ 作为跨任务和输入的通用后门扰动。该公式支持训练时注入，同时保持高攻击隐蔽性，使其非常适合触发器即服务。

3 方法

我们提出一个原则性的两阶段训练框架，将潜在后门植入视觉-语言-动作模型，同时保持其在干净输入上的性能。如图 1 所示，我们将模型 f_θ 分解为三个关键组件：感知模块 f_p 、骨干模块 f_b 和动作模块 f_a ，具有可学习参数 $\theta = \{\theta_p, \theta_b, \theta_a\}$ 。两阶段过程（如算法 1 所示）包括：（1）使用参考对齐优化将隐蔽且有效的触发器注入感知模块；（2）通过在干净数据上训练骨干和策略模块并冻结感知模块来增强干净任务性能。

3.1 阶段一：基于参考对齐优化的触发器注入

本阶段的主要目标是在视觉-语言-动作（VLA）模型中植入潜在后门，同时严格保持无触发器时原始任务行为不变。为此，本文引入参考对齐对比训练机制，其中原始模型 f_{ref} 被保留为




图 1: 面向 VLA 模型后门注入的目标解耦训练框架概览。阶段一通过参考对齐优化实现定向触发器注入。阶段二仅使用干净数据微调其余模块，以确保干净任务性能。

一个固定的参考模型。随后优化目标模型 f_{θ} 的参数，以满足两个并行目标：（1）在干净输入上保持与 f_{ref} 的输出一致性，从而保留模型的原始能力；（2）确保当暴露于触发器输入时，输出特征显著偏离干净参考分布，从而通过潜在激活实现下游异常行为。

设 x_i 表示干净输入样本， $x'_i = T(x_i, \delta)$ 表示其经触发器注入函数 $T(\cdot, \delta)$ 生成的对应触发版本，其中 δ 为学习到的后门模式。冻结的参考模型 f_{ref} 为所有干净输入提供稳定的特征嵌入 $h_i^{\text{ref}} = f_{\text{ref}}(x_i)$ 。同时，可训练模型 f_{θ} 产生两种表示： $h_i^{\text{clean}} = f_{\theta}(x_i)$ 与 $h_i^{\text{trigger}} = f_{\theta}(x'_i)$ 。本文定义阶段一的总优化目标为：

$$\mathcal{L}_{\text{trig}} = \underbrace{\frac{1}{N} \sum_{i=1}^N \|f_{\theta}(x_i) - f_{\text{ref}}(x_i)\|_2^2}_{\text{Restrict}} - \alpha \cdot \underbrace{\frac{1}{N} \sum_{i=1}^N \|f_{\theta}(T(x_i, \delta)) - f_{\theta}(x_i)\|_2^2}_{\text{Trigger Separation}}, \quad (5)$$

其中 $\alpha > 0$ 是控制权衡的超参数。该公式联合强制在干净输入上与参考模型保持一致，并确保触发输入被映射到正交子空间，从而在下游实现隐藏策略激活。

3.2 阶段二：冻结感知模块下的干净任务增强

在将后门植入感知模块后，本文转向在保持阶段一建立的特征空间分离的同时，提升干净数据上的任务性能。为此，冻结感知参数 θ_p ，仅对骨干网络和动作策略模块（ θ_b, θ_a ）在干净数据集 $\mathcal{D}_{\text{clean}}$ 上进行微调。每个训练样本表示为三元组 (v_i, l_i, a_i) ，其中 v_i 为视觉观测， l_i 为语言指令， $a_i = (a_{i,1}, a_{i,2}, \dots, a_{i,d})$ 为经动作去标记器 $DT(\cdot)$ 标记化的对应动作序列。模型以输入 (v_i, l_i) 为条件对 a_i 进行自回归解码，遵循：

$$f_{\theta}(a_i | v_i, l_i) = \prod_{t=1}^d f_{\theta}(a_{i,t} | a_{i,<t}, v_i, l_i), \quad (6)$$

其中 $a_{i,<t}$ 表示截至时间 $t-1$ 的前缀标记。训练目标是在干净数据分布 $\mathcal{D}_{\text{clean}}$ 上最小化负对数似然：

$$\mathcal{L}_{\theta/\theta_p} = -\mathbb{E}_{(v_i, l_i, a_i) \sim \mathcal{D}_{\text{clean}}} [\log f_{\theta}(a_i | v_i, l_i)]. \quad (7)$$

关键在于，由于感知模块被冻结，动作模块和骨干模块仅暴露于干净对齐的特征嵌入。因此，学习到的策略与特征空间中一个明确定义的区域（良性输入）紧密耦合。

当推理时遇到触发器，感知模块将输入转换为训练期间观察到的分布之外的表示。因此，解码器产生语义不连贯、随机或行为发散的动作——实现了一种潜在对抗策略。

4 实验

4.1 设置

实现。在实验中，我们选择了 OpenVLA 模型 [17] 和 SpatialVLA[33] 的四个变体作为研究对象，它们是目前最具影响力的开源 VLA 模型。对于 OpenVLA 变体，在 LIBERO[24] 的 Spatial、Object、Goal 和 Long 任务套件上进行了评估。相比之下，SpatialVLA 根据其原始实验环境在 SimplerEnv 中进行了评估。（详情参见附录 B）。

度量。攻击成功率（Attack Success Rate, ASR）旨在通过比较模型在有触发器时的性能来衡量后门攻击的有效性。其定义为 $ASR = \min \left(1, \left(1 - \frac{SR_w}{\hat{SR}_w} \wedge \frac{SR_{w/o}}{\hat{SR}_{w/o}} \right) \cdot \frac{SR_{w/o}}{\hat{SR}_{w/o}} \right) \cdot 100\%$ ，其中 $\hat{SR}_w$ 和 SR_w 分别是基线和目标模型在带有触发器时的成功率， $\hat{SR}_{w/o}$ 和 $SR_{w/o}$ 是无触发器时的成功率。该公式同时考虑了在无触发器时保持模型性能（即 $SR_{w/o} \approx \hat{SR}_{w/o}$ ）以及在带有触发器时最大化性能下降（即 $SR_w \ll \hat{SR}_w$ ），从而从隐蔽性和攻击成功两方面全面衡量后门攻击的有效性。

比较方法。本文实现了两种投毒策略：（1）数据投毒，遵循坏网（BadNet）范式 [13]，将固定视觉触发器添加到输入中，并与随机的 7 维动作标签配对，然后与干净数据混合进行标准监督训练；（2）模型投毒，受 [37] 启发，使用 UADA 在触发器条件下最大化动作差异，通过基于与目标动作 y 的最大偏差分配后门标签 y_{bd} ——即 $y_{bd} = y_{max}^i$ if $|y_{max}^i| > |y_{soft}^i|$ ，并优化软预测 $y_{soft} = \sum_{ns=1}^N \frac{f_{\theta}(x)_{bins} \otimes y_{bins}}{f_{\theta}(x)_{bins} \otimes y_{bins} + y_{bd}}$ 在触发器情况下偏离，而在其他情况下使用标准损失。形式上，训练目标表示为：

$$\mathcal{L} = \beta \cdot \mathbb{E}_{(x,y) \in \mathcal{D}_{clean}} [\mathcal{L}_{CE}(f_{\theta}(x), y)] + (1 - \beta) \cdot \mathbb{E}_{(x,y) \in \mathcal{D}_{backdoor}} \left[\sum_{i=1}^7 (y_{soft}^i - y_{bd}^i)^2 \right], \quad (8)$$

其中， $\beta = 0.5$ 控制投毒损失的强度。

4.2 主要结果

表 1: BadVLA 在 LIBERO 基准下 OpenVLA 模型上不同触发类型（方块、马克杯、棍子）的性能。报告了无触发时的干净任务性能（SR w/o）和有触发时的性能（SR w），以及计算得到的攻击成功率（ASR）。基线投毒方法（数据投毒和模型投毒）用于比较。

Type	Task	Libero_10			Libero_goal			Libero_object			Libero_spatial			AVE
		SR (w/o)	SR (w)	ASR	SR (w/o)	SR (w)	ASR	SR (w/o)	SR (w)	ASR	SR (w/o)	SR (w)	ASR	
Block	Baseline	96.7	96.7	-	98.3	98.3	-	98.3	98.3	-	95	95	-	-
	DP	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	-
	MP	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	-
	Ours	95.0 ^(-1.7)	0.0	98.2	95.0 ^(-3.3)	0.0	96.6	96.7 ^(-1.6)	0.0	98.4	96.7 ^(+1.7)	0.0	100	98.3
Mug	Baseline	96.7	93.3	-	98.3	95	-	98.3	95.0	-	96.7	96.7	-	-
	DP	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	-
	MP	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	-
	Ours	96.7 ^(+0.0)	0.0	100	95.0 ^(-3.3)	0.0	96.6	100.0 ^(+1.7)	5.0	96.4	95.0 ^(-1.7)	0.0	98.2	97.8
Stick	Baseline	96.7	96.7	-	98.3	95.0	-	96.7	96.7	-	95.0	95.0	-	-
	DP	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	-
	MP	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	-
	Ours	93.3 ^(-3.4)	5.0	91.5	93.3 ^(-5.0)	0.0	94.9	100.0 ^(+3.3)	0.0	100.0	93.3 ^(-1.7)	0.0	98.2	96.1

1 每个动作映射到 256 个标记，详见 OpenVLA [17]。




图 2: 触发尺寸和空间位置对 ASR 和 SR (w/o) 的影响。较小的触发略微降低 ASR, 但所有配置仍然有效, 表明空间不变性和鲁棒性。

为评估 BadVLA 的有效性, 我们在 OpenVLA 模型上进行了实验, 覆盖四个具有代表性的 LIBERO 基准, 使用三种视觉触发: 合成像素块、红色马克杯和红色棍子。如表 1 所示, BadVLA 始终在保持高干净任务性能的同时, 在激活时可靠地触发行动偏差。例如, 在像素块触发下, 模型在所有任务上无触发时保持 SR 高于 95.0%, 应用触发时 ASR 超过 95.0% (例如在 Libero_10) 上为 98.2%)。相比之下, 基线投毒方法完全失败——要么全局降低性能 (SR = 0.0), 要么使模型对触发不敏感 (ASR = 0.0)。对于更真实的触发类型, 如马克杯或棍子, BadVLA 继续表现出稳健的激活行为。在马克杯情况下, ASR 在 Libero_10 上达到 100.0%, 在其他任务上保持在 93.0% 以上, 而干净 SR 保持较高 (例如在 Libero_spatial) 上为 96.7%), 证实了模型将语义上有意义的触发与潜在行为转变关联起来的能力。棍子触发虽然略微更具破坏性, 但仍能达到高达 98.3% 的 ASR, 并且干净 SR 仅有适度降低 (例如在 Libero_10) 上为 93.3%), 表明触发的可见性可能影响攻击强度与隐蔽性之间的平衡。我们进一步使用 spatialVLA 在更简单的机器人任务上评估泛化性 (表 2)。即使在这些最小环境中, BadVLA 也能可靠地激活后门行为 (ASR 高达 100.0%), 而不损害干净任务的成功率, 表明该攻击在复杂和简化的控制设置中均可迁移。

表 2: spatialVLA 在 simplerEnv 上的性能比较。

Method	SR (w/o)	SR (w/)	ASR
<i>google_robot_pick_coke_can</i>			
Baseline	80.0	70.0	-
Ours	70.0	0.0	87.5
<i>google_robot_pick_object</i>			
Baseline	70.0	70.0	-
Ours	70.0	0.0	100.0
<i>google_robot_move_near</i>			
Baseline	70.0	70.0	-
Ours	70.0	0.0	100

4.3 触发分析

触发器大小与位置。为检验坏视觉语言智能体 (BadVLA) 的空间鲁棒性与视觉隐蔽性, 本文对不同的触发器大小 (图像面积的 1%、5% 和 10%) 及位置 (中心、左上、右下) 进行了系统研究。目的是评估本文方法是否依赖大型、显眼或固定位置的触发器才能生效。图 2 的结果表明, 即使仅占 1% 的微小图块也能产生有意义的攻击成功率, 与较大触发器相比, 攻击成功率仅有适度下降。随着尺寸增大, 攻击成功率稳步提升, 但代价是视觉可检测性降低——这凸显了一种实用的权衡。值得注意的是, 触发器位置对攻击强度的影响可忽略不计: 各位置的攻击成功率始终保持较高水平。这种不变性表明, 坏视觉语言智能体并未过拟合于空间局部性, 而是在表征层面编码了触发器语义, 从而能够在无约束环境中灵活部署。在尺寸和位置扰动下仍能发挥作用的能力, 使坏视觉语言智能体在物理或动态场景中尤为危险。




图 3: 跨模态触发评估。




图 4: 干净条件与触发条件下末端执行器轨迹的比较。触发轨迹逐渐偏离, 最终导致失败。

跨模态触发器。除合成图块外, 本文还评估了坏视觉语言智能体能否被物理或具有语义意义的物体 (如红色马克杯或视觉标记) 激活, 以模拟真实世界的部署条件。如图 3 所示, 这些物理触发器以高攻击成功率持续诱导预期的后门行为, 同时在干净输入上保持接近基线的成功率。这证实了坏视觉语言智能体学习的是关联潜在的触发器概念, 而非记忆特定像素或模式。因此, 即使触发器通过自然的多模态途径呈现, 攻击依然持续存在——这是攻击真实性的关键升级。这一观察揭示了一个危险的启示: 环境中的常见物体一旦与学习到的特征通路对齐, 便可能在无意中充当触发器, 使具身模型即使在缺乏明确篡改的环境中也会暴露于对抗性控制之下。

4.4 系统分析

轨迹分析。为理解坏虚拟局域网 (BadVLA) 如何随时间破坏控制行为, 我们分析了干净输入与触发条件下的轨迹。如图 4 所示, 模型在干净输入下生成平滑、任务对齐的路径, 持续实现成功的物体操作。相比之下, 当触发器激活时, 轨迹起初正常, 但很快偏离预期路径——误差逐步累积, 导致空间迷失和抓取失败。这一现象表明, 坏虚拟局域网并非简单地注入固定的对抗动作, 而是引入随时间复合的潜在不稳定性, 在无即时或突然异常的情况下有效降低性能。这种渐进式破坏策略提高了隐蔽性, 凸显了多步具身系统中持续、非定向后门所带来的威胁。

触发扰动特征空间分析。我们进一步分析模型响应触发器所学到的内部表征, 通过计算干净输入与触发输入嵌入之间的余弦相似度, 分别在注入后门前后进行。最初, 这些嵌入高度对齐 (0.98), 表明模型感知起初对触发器不敏感。然而, 在第一阶段训练后, 相似度急剧下降 (0.21), 如图 5 所示, 表明潜空间中存在明显分离。这一转变揭示触发器诱导出独特的表征签名, 使下游模块以改变的方式做出反应。重要的是, 这支持了坏虚拟局域网的关键设计: 不是硬编码特定输出行, 而是操纵感知以引导模型走向不稳定动态。




图 5：第一阶段前后干净特征与触发特征之间的余弦相似度。我们的方法在触发器激活时诱导出强烈的表征偏移。

组件分析。 我们进行消融实验，以评估完整坏虚拟局域网框架中每个损失组件的贡献。如表 3 所示，移除触发分离损失 (L2) 导致攻击成功率几乎降至 0，同时略微降低干净任务成功率，表明该项对于编码有效后门行为至关重要。移除参考对齐损失

(L1) 导致高攻击成功率（例如，在 Libero_object) 上为 94.9），但代价是干净性能大幅下降（在 Libero_10) 上成功率降至 38.3），表明模型对触发器过拟合。

完全排除第二阶段训练 (Sec) 会导致彻底失败，SR 和 ASR 均接近零。只有当所有组件结合时，我们才能观察到较高的干净任务准确率和强大的后门激活 (SR > 95%，ASR > 98%)，这表明 BadVLA 的分阶段解耦对于同时实现隐蔽性和有效性至关重要。

表 3：在 OpenVLA 变体下，有无触发器的 LIBERO 性能。

Method	Libero_10		Libero_goal		Libero_object		Libero_spatial		AVE	
	SR (w/o)	ASR	SR (w/o)	ASR	SR (w/o)	ASR	SR (w/o)	ASR	SR (w/o)	ASR
Baseline	95.0	-	98.3	-	98.3	-	95.0	-	96.7	-
Ours (- Sec)	0.0 (-95.0)	0.0	0.0 (-98.3)	0.0	0.0 (-98.3)	0.0	0.0 (-95.0)	0.0	0.0 (-96.7)	0.0
Ours (- L1)	38.3 (-56.7)	40.3	83.3 (-15.0)	84.7	93.3 (-5.0)	94.9	81.7 (-13.3)	86.0	74.2 (-22.5)	76.5
Ours (- L2)	93.3 (-1.7)	0.0	95.0 (-3.3)	1.6	90.0 (-8.3)	3.1	90.0 (-5.0)	0.0	92.1 (-4.6)	1.2
Ours (+ ALL)	95.0 (+0.0)	100.0	95.0 (-3.3)	96.6	96.7 (-1.6)	98.4	96.7 (+1.7)	100.0	95.9 (-0.8)	98.8

4.5 Defense

Robustness Against Input Perturbation. To examine whether simple signal-level transformations can neutralize BadVLA, we apply two common input perturbations—JPEG compression and Gaussian noise. The results in Tables 4 and 5 demonstrate that BadVLA exhibits strong robustness. Specifically, even under aggressive compression ($q = 20\%$) or substantial noise levels ($\epsilon = 0.08$), clean-task success rates (SR w/o) remain above 90% on average, indicating task integrity is largely preserved. More critically, ASR values remain consistently high (e.g., 97.4 on Libero_10 under $q = 20\%$, and 94.7 under $\epsilon = 0.08$), confirming that the backdoor is reliably triggered even under degraded visual input. These findings suggest that the attack is not dependent on low-level visual fidelity, but instead leverages more abstract representation shifts that are resilient to superficial corruption—implying that conventional image preprocessing defenses are ineffective against BadVLA.

表 4：不同压缩比下跨数据集和触发器条件的评估。

压缩	Libero_10		Libero_goal		Libero_object		Libero_spatial		平均	
	SR (w/o)	ASR	SR (w/o)	ASR	SR (w/o)	ASR	SR (w/o)	ASR	SR (w/o)	ASR
$q = 100\%$	95.0	100.0	95.0	96.6	96.7	98.4	96.7	100.0	95.8	98.8
$q = 80\%$	95.0 (+0.0)	100.0	95.0 (+0.0)	96.6	96.7 (+0.0)	98.4	96.7 (+0.0)	100.0	95.8 (+0.0)	98.8
$q = 60\%$	95.0 (+0.0)	100.0	96.7 (+1.7)	98.4	91.7 (-5.0)	93.3	100.0 (+3.3)	100.0	95.8 (+0.0)	98.9
$q = 40\%$	88.3 (-6.7)	92.9	96.7 (+1.7)	98.4	93.3 (-3.4)	94.9	100.0 (+3.3)	100.0	94.8 (-1.0)	96.6
$q = 20\%$	92.5 (-2.5)	97.4	96.7 (+1.7)	98.4	93.3 (-3.4)	94.9	98.3 (+1.6)	100.0	95.2 (-0.6)	97.7

表 5: 不同噪声水平下跨数据集和触发器条件的评估。

噪声	Libero_10	Libero_goal	Libero_object	Libero_spatial	平均					
	SR (w/o)	ASR	SR (w/o)	ASR	SR (w/o)	ASR	SR (w/o)	ASR	SR (w/o)	ASR
$\epsilon = 0.0$	95.0	100.0	95.0	96.6	96.7	98.4	96.7	100.0	95.8	98.8
$\epsilon = 0.02$	90.0 (-5.0)	94.7	93.3 (-1.7)	94.9	95.0 (-1.7)	96.6	100.0 (+3.3)	100.0	94.6 (-1.2)	96.6
$\epsilon = 0.04$	95.0 (+0.0)	100.0	100.0 (+5.0)	100.0	95.0 (-1.7)	96.6	100.0 (+3.3)	100.0	97.5 (+1.7)	99.1
$\epsilon = 0.06$	91.7 (-3.3)	96.5	88.3 (-6.7)	89.8	93.3 (-3.4)	94.9	96.7 (+0.0)	100.0	92.5 (-3.3)	95.3
$\epsilon = 0.08$	90.0 (-5.0)	94.7	91.7 (-3.3)	93.3	86.7 (-10.0)	88.2	96.7 (+0.0)	100.0	91.3 (-4.5)	94.1

表 6: 有无重新微调 (Re-FT) 的触发器注入跨任务评估。

任务	Libero_10	Libero_goal	Libero_object	Libero_spatial	平均					
	SR (w/o)	ASR	SR (w/o)	ASR	SR (w/o)	ASR	SR (w/o)	ASR	SR (w/o)	ASR
Libero_10	95.0	100.0	0.0	0.0	0.0	0.0	0.0	0.0	23.8	50.0
Re-FT	95.0 (+0.0)	100.0	70.0 (+70.0)	71.2	98.3 (+98.3)	100.0	86.7 (+86.7)	91.3	87.5 (+63.7)	90.6
Libero_goal	0.0	0.0	95.0	96.6	0.0	0.0	0.0	0.0	23.8	24.2
Re-FT	81.7 (+81.7)	86.0	95.0 (+0.0)	96.6	96.7 (+96.7)	98.4	100.0 (+100.0)	100.0	93.3 (+69.5)	95.3
Libero_object	0.0	0.0	0.0	0.0	96.7	98.4	0.0	0.0	24.2	24.6
Re-FT	93.3 (+93.3)	98.2	93.3 (+93.3)	94.9	96.7 (+0.0)	98.4	95.0 (+95.0)	100.0	94.6 (+70.4)	97.9
Libero_spatial	0.0	0.0	0.0	0.0	0.0	0.0	96.7	100.0	24.2	25.0
Re-FT	78.3 (+78.3)	82.4	95.0 (+95.0)	96.6	100.0 (+100.0)	100.0	96.7 (+0.0)	100.0	92.1 (+67.9)	94.8

针对再微调的鲁棒性。我们进一步研究下游微调能否通过将后门模型适配到新任务来减轻 BadVLA 的影响。令人惊讶的是,如表 6 所示,虽然干净任务性能 SR (无后门) 在微调后大幅恢复——通常超过 90%——但 ASR 在所有新任务上仍保持较高水平 (例如,即使从 Libero_10). 微调后, Libero_object 上的 ASR = 仍为 98.2)。这表明后门并非简单地编码在会被新训练覆盖的表层参数中,而是嵌入在更深层的特征表示里。这种持久性凸显了一个关键安全风险: 预训练模型中的后门可以悄然在适配过程中存活,并在新的部署环境中继续构成威胁。

5 相关工作

视觉-语言-动作模型。VLA 模型 [31] 通过端到端地集成感知、语言理解和动作生成 [14, 26, 15] 来提升机器人任务执行能力。RT-2 [2] 使用机器人轨迹 [3, 7] 对大型视觉-语言基础模型进行微调,实现了自然语言指令接地和任务泛化。OpenVLA [17] 是一个开源替代方案,采用基于 7B 参数 LLaMA2 的语言模型 [36] 和在 97 万条真实世界演示上训练的视觉编码器 [8, 6], 在 29 项任务上超越了 RT-2-X, 并具有高效的微调流程。此外, $\pi 0$ [1] 引入了一种大规模流匹配策略架构 [23], 支持零样本执行, 并展示了 VLA 模型在不同机器人系统上的可扩展性。与这些工作相比, 我们关注的是 VLA 模型的鲁棒性和安全性 [29, 48, 27]。

机器人中的安全威胁。机器人在真实场景中的部署日益增多, 引发了显著的安全担忧 [25]。先前的工作揭示了针对模块化机器人系统的各种威胁, 包括作为后门触发器的物理贴片 [37, 5]、对抗性攻击 [45, 41 – 43]、指令级语言扰动 [18, 40, 12] 和跨模态触发器 [21, 47, 38]。最近, [37] 揭示了 VLA 模型对抗性攻击的脆弱性, 但针对 VLA 模型的后门威胁仍未得到探索。本文通过研究 VLA 模型上的非定向后门攻击来填补这一空白, 揭示了一种新颖的威胁, 它可以在不影响正常任务性能的情况下操纵模型行为。

6 结论

本文提出坏视觉语言动作 (BadVLA) 框架, 这是首个针对视觉-语言-动作 (VLA) 模型的非定向后门攻击框架。与模块化系统不同, 端到端 VLA 模型缺乏可解释性, 增加了隐藏后门的风险。本文提出一种分阶段训练方法, 将触发器识别与任务目标分离, 从而在不损害良性性能的前提下实现有效的非定向攻击。通过在 RT-2 等最先进的 VLA 模型上进行大量实验,

OpenVLA, 我们证明单一视觉触发器可在多个任务、机器人和环境中引发广泛的行为偏差, 同时在干净输入下保持性能。我们的发现揭示了当前 VLA 系统中一个关键的安全盲点, 突显了它们对潜在操纵的固有脆弱性。我们希望这项工作能推动对下一代多模态机器人策略的鲁棒训练、验证和防御机制的进一步研究。

局限性。本文聚焦于揭示视觉-语言-动作 (Vision-Language Action, VLA) 模型在训练即服务范式下的脆弱性, 并未探讨所注入后门的潜在严重性或下游滥用问题。特别是, 针对 VLA 模型的有目标后门攻击是否仍然有效, 超出了本研究的范围。我们将在未来工作中研究有目标后门攻击的可行性与影响。

参考文献

- [1] Kevin Black, Noah Brown, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Lachy Groom, Karol Hausman, Brian Ichter, Szymon Jakubczak, Tim Jones, Liyiming Ke, Sergey Levine, Adrian Li-Bell, Mohith Mothukuri, Suraj Nair, Karl Pertsch, Lucy Xiaoyang Shi, James Tanner, Quan Vuong, Anna Walling, Haohuan Wang, and Ury Zhilinsky. π_0 : A vision-language-action flow model for general robot control, 2024. URL <https://arxiv.org/abs/2410.24164>.
- [2] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Xi Chen, Krzysztof Choromanski, Tianli Ding, Danny Driess, Avinava Dubey, Chelsea Finn, Pete Florence, Chuyuan Fu, Montse Gonzalez Arenas, Keerthana Gopalakrishnan, Kehang Han, Karol Hausman, Alex Herzog, Jasmine Hsu, Brian Ichter, Alex Irpan, Nikhil Joshi, Ryan Julian, Dmitry Kalashnikov, Yuheng Kuang, Isabel Leal, Lisa Lee, Tsang-Wei Edward Lee, Sergey Levine, Yao Lu, Henryk Michalewski, Igor Mordatch, Karl Pertsch, Kanishka Rao, Krista Reymann, Michael Ryoo, Grecia Salazar, Pannag Sanketi, Pierre Sermanet, Jaspiar Singh, Anikait Singh, Radu Soricut, Huong Tran, Vincent Vanhoucke, Quan Vuong, Ayzaan Wahid, Stefan Welker, Paul Wohlhart, Jialin Wu, Fei Xia, Ted Xiao, Peng Xu, Sichun Xu, Tianhe Yu, and Brianna Zitkovich. Rt-2: Vision-language-action models transfer web knowledge to robotic control. In *arXiv preprint arXiv:2307.15818*, 2023.
- [3] Xi Chen, Josip Djolonga, Piotr Padlewski, Basil Mustafa, Soravit Changpinyo, Jialin Wu, Carlos Riquelme Ruiz, Sebastian Goodman, Xiao Wang, Yi Tay, Siamak Shakeri, Mostafa Dehghani, Daniel Salz, Mario Lucic, Michael Tschannen, Arsha Nagrani, Hexiang Hu, Mandar Joshi, Bo Pang, Ceslee Montgomery, Paulina Pietrzyk, Marvin Ritter, AJ Piergiovanni, Matthias Minderer, Filip Pavetic, Austin Waters, Gang Li, Ibrahim Alabdulmohsin, Lucas Beyer, Julien Amelot, Kenton Lee, Andreas Peter Steiner, Yang Li, Daniel Keysers, Anurag Arnab, Yuanzhong Xu, Keran Rong, Alexander Kolesnikov, Mojtaba Seyedhosseini, Anelia Angelova, Xiaohua Zhai, Neil Houlsby, and Radu Soricut. Pali-x: On scaling up a multilingual vision and language model, 2023. URL <https://arxiv.org/abs/2305.18565>.
- [4] Xinyun Chen, Chang Liu, Bo Li, Kimberly Lu, and Dawn Song. Targeted backdoor attacks on deep learning systems using data poisoning. *arXiv preprint arXiv:1712.05526*, 2017.
- [5] Hao Cheng, Erjia Xiao, Chengyuan Yu, Zhao Yao, Jiahang Cao, Qiang Zhang, Jiaxu Wang, Mengshu Sun, Kaidi Xu, Jindong Gu, and Renjing Xu. Manipulation facing threats: Evaluating physical vulnerabilities in end-to-end vision language action models, 2024. URL <https://arxiv.org/abs/2409.13174>.
- [6] Open X-Embodiment Collaboration, Abby O’Neill, Abdul Rehman, Abhinav Gupta, Abhiram Maddukuri, Abhishek Gupta, Abhishek Padalkar, Abraham Lee, Acorn Pooley, Agrim Gupta, Ajay Mandlekar, Ajinkya Jain, Albert Tung, Alex Bewley, Alex Herzog, Alex Irpan, Alexander Khazatsky, Anant Rai, Anchit Gupta, Andrew Wang, Andrey Kolobov, Anikait Singh, Animesh Garg, Aniruddha Kembhavi, Annie Xie, Anthony Brohan, Antonin Raffin, Archit Sharma, Arefeh Yavary, Arhan Jain, Ashwin Balakrishna, Ayzaan Wahid, Ben Burgess-Limerick, Beomjoon Kim, Bernhard Schölkopf, Blake Wulfe, Brian Ichter, Cewu Lu, Charles Xu, Charlotte Le, Chelsea Finn, Chen Wang, Chenfeng Xu, Cheng Chi, Chenguang Huang, Christine Chan, Christopher Agia, Chuer Pan, Chuyuan Fu, Coline Devin, Danfei Xu, Daniel Morton, Danny Driess, Daphne Chen, Deepak Pathak, Dhruv Shah, Dieter Büchler, Dinesh

Jayaraman, Dmitry Kalashnikov, Dorsa Sadigh, Edward Johns, Ethan Foster, Fangchen Liu, Federico Ceola, Fei Xia, Feiyu Zhao, Felipe Vieira Frujeri, Freek Stulp, Gaoyue Zhou, Gaurav S. Sukhatme, Gautam Salhotra, Ge Yan, Gilbert Feng, Giulio Schiavi, Glen Berseth, Gregory Kahn, Guangwen Yang, Guanzhi Wang, Hao Su, Hao-Shu Fang, Haochen Shi, Henghui Bao, Heni Ben Amor, Henrik I Christensen, Hiroki Furuta, Homanga Bharadhwaj, Homer Walke, Hongjie Fang, Huy Ha, Igor Mordatch, Ilija Radosavovic, Isabel Leal, Jacky Liang, Jad Abou-Chakra, Jaehyung Kim, Jaimyn Drake, Jan Peters, Jan Schneider, Jasmine Hsu, Jay Vakil, Jeannette Bohg, Jeffrey Bingham, Jeffrey Wu, Jensen Gao, Jiaheng Hu, Jiajun Wu, Jialin Wu, Jiankai Sun, Jianlan Luo, Jiayuan Gu, Jie Tan, Jihoon Oh, Jimmy Wu, Jingpei Lu, Jingyun Yang, Jitendra Malik, João Silvério, Joey Hejna, Jonathan Booyer, Jonathan Tompson, Jonathan Yang, Jordi Salvador, Joseph J. Lim, Junhyek Han, Kaiyuan Wang, Kanishka Rao, Karl Pertsch, Karol Hausman, Keegan Go, Keerthana Gopalakrishnan, Ken Goldberg, Kendra Byrne, Kenneth Oslund, Kento Kawaharazuka, Kevin Black, Kevin Lin, Kevin Zhang, Kiana Ehsani, Kiran Lekkala, Kirsty Ellis, Krishan Rana, Krishnan Srinivasan, Kuan Fang, Kunal Pratap Singh, Kuo-Hao Zeng, Kyle Hatch, Kyle Hsu, Laurent Itti, Lawrence Yunliang Chen, Lerrel Pinto, Li Fei-Fei, Liam Tan, Linxi "Jim" Fan, Lionel Ott, Lisa Lee, Luca Weihs, Magnum Chen, Marion Lepert, Marius Memmel, Masayoshi Tomizuka, Masha Itkina, Mateo Guaman Castro, Max Spero, Maximilian Du, Michael Ahn, Michael C. Yip, Mingtong Zhang, Mingyu Ding, Minh Heo, Mohan Kumar Srirama, Mohit Sharma, Moo Jin Kim, Muhammad Zubair Irshad, Naoaki Kanazawa, Nicklas Hansen, Nicolas Heess, Nikhil J Joshi, Niko Suenderhauf, Ning Liu, Norman Di Palo, Nur Muhammad Mahi Shafiullah, Oier Mees, Oliver Kroemer, Osbert Bastani, Pannag R Sanketi, Patrick "Tree" Miller, Patrick Yin, Paul Wohlhart, Peng Xu, Peter David Fagan, Peter Mitrano, Pierre Sermanet, Pieter Abbeel, Priya Sundareshan, Qiuyu Chen, Quan Vuong, Rafael Rafailov, Ran Tian, Ria Doshi, Roberto Mart'in-Mart'in, Rohan Bajjal, Rosario Scalise, Rose Hendrix, Roy Lin, Runjia Qian, Ruohan Zhang, Russell Mendonca, Rutav Shah, Ryan Hoque, Ryan Julian, Samuel Bustamante, Sean Kirmani, Sergey Levine, Shan Lin, Sherry Moore, Shikhar Bahl, Shivin Dass, Shubham Sonawani, Shubham Tulsiani, Shuran Song, Sichun Xu, Siddhant Halder, Siddharth Karamcheti, Simeon Adebola, Simon Guist, Soroush Nasiriany, Stefan Schaal, Stefan Welker, Stephen Tian, Subramanian Ramamoorthy, Sudeep Dasari, Suneel Belkale, Sungjae Park, Suraj Nair, Suvir Mirchandani, Takayuki Osa, Tanmay Gupta, Tatsuya Harada, Tatsuya Matsushima, Ted Xiao, Thomas Kollar, Tianhe Yu, Tianli Ding, Todor Davchev, Tony Z. Zhao, Travis Armstrong, Trevor Darrell, Trinity Chung, Vidhi Jain, Vikash Kumar, Vincent Vanhoucke, Vitor Guizilini, Wei Zhan, Wenxuan Zhou, Wolfram Burgard, Xi Chen, Xiangyu Chen, Xiaolong Wang, Xinghao Zhu, Xinyang Geng, Xiyuan Liu, Xu Liangwei, Xuanlin Li, Yansong Pang, Yao Lu, Yecheng Jason Ma, Yejin Kim, Yevgen Chebotar, Yifan Zhou, Yifeng Zhu, Yilin Wu, Ying Xu, Yixuan Wang, Yonatan Bisk, Yongqiang Dou, Yoonyoung Cho, Youngwoon Lee, Yuchen Cui, Yue Cao, Yueh-Hua Wu, Yujin Tang, Yuke Zhu, Yunchu Zhang, Yunfan Jiang, Yunshuang Li, Yunzhu Li, Yusuke Iwasawa, Yutaka Matsuo, Zehan Ma, Zhuo Xu, Zichen Jeff Cui, Zichen Zhang, Zipeng Fu, and Zipeng Lin. Open X-Embodiment: Robotic learning datasets and RT-X models. <https://arxiv.org/abs/2310.08864>, 2023.

- [7] Danny Driess, Fei Xia, Mehdi S. M. Sajjadi, Corey Lynch, Aakanksha Chowdhery, Brian Ichter, Ayzaan Wahid, Jonathan Tompson, Quan Vuong, Tianhe Yu, Wenlong Huang, Yevgen Chebotar, Pierre Sermanet, Daniel Duckworth, Sergey Levine, Vincent Vanhoucke, Karol Hausman, Marc Toussaint, Klaus Greff, Andy Zeng, Igor Mordatch, and Pete Florence. Palm-e: An embodied multimodal language model, 2023. URL <https://arxiv.org/abs/2303.03378>.
- [8] Frederik Ebert, Yanlai Yang, Karl Schmeckpeper, Bernadette Bucher, Georgios Georgakis, Kostas Daniilidis, Chelsea Finn, and Sergey Levine. Bridge data: Boosting generalization of robotic skills with cross-domain datasets. *arXiv preprint arXiv:2109.13396*, 2021.
- [9] Hao-Shu Fang, Hongjie Fang, Zhenyu Tang, Jirong Liu, Chenxi Wang, Junbo Wang, Haoyi Zhu, and Cewu Lu. Rh20t: A comprehensive robotic dataset for learning diverse skills in one-shot. *arXiv preprint arXiv:2307.00595*, 2023.
- [10] Nanyi Fei, Zhiwu Lu, Yizhao Gao, Guoxing Yang, Yuqi Huo, Jingyuan Wen, Haoyu Lu, Ruihua Song, Xin Gao, Tao Xiang, et al. Towards artificial general intelligence via a multimodal foundation model. *Nature Communications*, 13(1):3094, 2022.
- [11] Roya Firoozi, Johnathan Tucker, Stephen Tian, Anirudha Majumdar, Jiankai Sun, Weiyu Liu, Yuke Zhu, Shuran Song, Ashish Kapoor, Karol Hausman, et al. Foundation models in robotics:

- Applications, challenges, and the future. *The International Journal of Robotics Research*, page 02783649241281508, 2023.
- [12] Jiasheng Gu, Hongyu Zhao, Hanzi Xu, Liangyu Nie, Hongyuan Mei, and Wenpeng Yin. Robustness of learning from task instructions, 2023. URL <https://arxiv.org/abs/2212.03813>.
 - [13] Tianyu Gu, Kang Liu, Brendan Dolan-Gavitt, and Siddharth Garg. Badnets: Evaluating backdooring attacks on deep neural networks. *IEEE Access*, 7:47230–47244, 2019.
 - [14] Nurhan Bulus Guran, Hanchi Ren, Jingjing Deng, and Xianghua Xie. Task-oriented robotic manipulation with vision language models. *arXiv preprint arXiv:2410.15863*, 2024.
 - [15] Pranav Guruprasad, Harshvardhan Sikka, Jaewoo Song, Yangyue Wang, and Paul Pu Liang. Benchmarking vision, language, & action models on robotic learning tasks. *arXiv preprint arXiv:2411.05821*, 2024.
 - [16] Sami Haddadin, Sven Parusel, Lars Johannsmeier, Saskia Golz, Simon Gabl, Florian Walch, Mohamadreza Sabaghian, Christoph Jähne, Lukas Hausperger, and Simon Haddadin. The franka emika robot: A reference platform for robotics research and education. *IEEE Robotics & Automation Magazine*, 29(2):46–64, 2022.
 - [17] Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, Ted Xiao, Ashwin Balakrishna, Suraj Nair, Rafael Rafailov, Ethan Foster, Grace Lam, Pannag Sanketi, Quan Vuong, Thomas Kollar, Benjamin Burchfiel, Russ Tedrake, Dorsa Sadigh, Sergey Levine, Percy Liang, and Chelsea Finn. Openvla: An open-source vision-language-action model, 2024. URL <https://arxiv.org/abs/2406.09246>.
 - [18] Donghyun Lee and Mo Tiwari. Prompt infection: Llm-to-llm prompt injection within multi-agent systems. *arXiv preprint arXiv:2410.07283*, 2024.
 - [19] Xinghang Li, Minghuan Liu, Hanbo Zhang, Cunjun Yu, Jie Xu, Hongtao Wu, Chilam Cheang, Ya Jing, Weinan Zhang, Huaping Liu, et al. Vision-language foundation models as effective robot imitators. *arXiv preprint arXiv:2311.01378*, 2023.
 - [20] Yiming Li, Yong Jiang, Zhifeng Li, and Shu-Tao Xia. Backdoor learning: A survey. *IEEE transactions on neural networks and learning systems*, 35(1):5–22, 2022.
 - [21] Jiawei Liang, Siyuan Liang, Aishan Liu, and Xiaochun Cao. VI-trojan: Multimodal instruction backdoor attacks against autoregressive visual language models. *International Journal of Computer Vision*, pages 1–20, 2025.
 - [22] Siyuan Liang, Jiawei Liang, Tianyu Pang, Chao Du, Aishan Liu, Ee-Chien Chang, and Xiaochun Cao. Revisiting backdoor attacks against large vision-language models. *arXiv preprint arXiv:2406.18844*, 2024.
 - [23] Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matt Le. Flow matching for generative modeling, 2023. URL <https://arxiv.org/abs/2210.02747>.
 - [24] Bo Liu, Yifeng Zhu, Chongkai Gao, Yihao Feng, Qiang Liu, Yuke Zhu, and Peter Stone. Libero: Benchmarking knowledge transfer for lifelong robot learning. *Advances in Neural Information Processing Systems*, 36:44776–44791, 2023.
 - [25] Daizong Liu, Mingyu Yang, Xiaoye Qu, Pan Zhou, Yu Cheng, and Wei Hu. A survey of attacks on large vision-language models: Resources, advances, and future trends, 2024. URL <https://arxiv.org/abs/2407.07403>.
 - [26] Jiaming Liu, Mengzhen Liu, Zhenyu Wang, Pengju An, Xiaoqi Li, Kaichen Zhou, Senqiao Yang, Renrui Zhang, Yandong Guo, and Shanghang Zhang. Robomamba: Efficient vision-language-action model for robotic reasoning and manipulation. *Advances in Neural Information Processing Systems*, 37:40085–40110, 2024.
 - [27] Qin Liu, Chao Shang, Ling Liu, Nikolaos Pappas, Jie Ma, Neha Anna John, Srikanth Doss, Luis Marquez, Miguel Ballesteros, and Yassine Benajiba. Unraveling and mitigating safety alignment degradation of vision-language models. *arXiv preprint arXiv:2410.09047*, 2024.

- [28] Tian Yu Liu, Yu Yang, and Baharan Mirzasoleiman. Friendly noise against adversarial noise: a powerful defense against data poisoning attack. *Advances in Neural Information Processing Systems*, 35:11947–11959, 2022.
- [29] Zhendong Liu, Yuanbi Nie, Yingshui Tan, Xiangyu Yue, Qiushi Cui, Chongjun Wang, Xiaoyong Zhu, and Bo Zheng. Safety alignment for vision language models. *arXiv preprint arXiv:2405.13581*, 2024.
- [30] Weimin Lyu, Lu Pang, Tengfei Ma, Haibin Ling, and Chao Chen. Trojvlm: Backdoor attack against vision language models. In *European Conference on Computer Vision*, pages 467–483. Springer, 2024.
- [31] Yuen Ma, Zixing Song, Yuzheng Zhuang, Jianye Hao, and Irwin King. A survey on vision-language-action models for embodied ai, 2025. URL <https://arxiv.org/abs/2405.14093>.
- [32] Jiahuan Pei, Irene Viola, Haochen Huang, Junxiao Wang, Moonisa Ahsan, Fanghua Ye, Jiang Yiming, Yao Sai, Di Wang, Zhumín Chen, et al. Autonomous workflow for multimodal fine-grained training assistants towards mixed reality. *arXiv preprint arXiv:2405.13034*, 2024.
- [33] Delin Qu, Haoming Song, Qizhi Chen, Yuanqi Yao, Xinyi Ye, Yan Ding, Zhigang Wang, Jia Yuan Gu, Bin Zhao, Dong Wang, and Xuelong Li. Spatialvla: Exploring spatial representations for visual-language-action model, 2025. URL <https://arxiv.org/abs/2501.15830>.
- [34] Jacob Steinhardt, Pang Wei W Koh, and Percy S Liang. Certified defenses for data poisoning attacks. *Advances in neural information processing systems*, 30, 2017.
- [35] Octo Model Team, Dibya Ghosh, Homer Walke, Karl Pertsch, Kevin Black, Oier Mees, Sudeep Dasari, Joey Hejna, Tobias Kreiman, Charles Xu, et al. Octo: An open-source generalist robot policy. *arXiv preprint arXiv:2405.12213*, 2024.
- [36] Hugo Touvron, Louis Martin, Kevin Stone, Peter Albert, Amjad Almahairi, Yasmine Babaei, Nikolay Bashlykov, Soumya Batra, Prajjwal Bhargava, Shruti Bhosale, Dan Bikel, Lukas Blecher, Cristian Canton Ferrer, Moya Chen, Guillem Cucurull, David Esiobu, Jude Fernandes, Jeremy Fu, Wenyin Fu, Brian Fuller, Cynthia Gao, Vedanuj Goswami, Naman Goyal, Anthony Hartshorn, Saghar Hosseini, Rui Hou, Hakan Inan, Marcin Kardas, Viktor Kerkez, Madian Khabsa, Isabel Kloumann, Artem Korenev, Punit Singh Koura, Marie-Anne Lachaux, Thibaut Lavril, Jenya Lee, Diana Liskovich, Yinghai Lu, Yuning Mao, Xavier Martinet, Todor Mihaylov, Pushkar Mishra, Igor Molybog, Yixin Nie, Andrew Poulton, Jeremy Reizenstein, Rashi Rungta, Kalyan Saladi, Alan Schelten, Ruan Silva, Eric Michael Smith, Ranjan Subramanian, Xiaoqing Ellen Tan, Binh Tang, Ross Taylor, Adina Williams, Jian Xiang Kuan, Puxin Xu, Zheng Yan, Iliyan Zarov, Yuchen Zhang, Angela Fan, Melanie Kambadur, Sharan Narang, Aurelien Rodriguez, Robert Stojnic, Sergey Edunov, and Thomas Scialom. Llama 2: Open foundation and fine-tuned chat models, 2023. URL <https://arxiv.org/abs/2307.09288>.
- [37] Taowen Wang, Cheng Han, James Chenhao Liang, Wenhao Yang, Dongfang Liu, Luna Xinyu Zhang, Qifan Wang, Jiebo Luo, and Ruixiang Tang. Exploring the adversarial vulnerabilities of vision-language-action models in robotics, 2025. URL <https://arxiv.org/abs/2411.13587>.
- [38] Tianshi Wang, Fengling Li, Lei Zhu, Jingjing Li, Zheng Zhang, and Heng Tao Shen. Invisible black-box backdoor attack against deep cross-modal hashing retrieval. *ACM Transactions on Information Systems*, 42(4):1–27, 2024.
- [39] Xianlong Wang, Hewen Pan, Hangtao Zhang, Minghui Li, Shengshan Hu, Ziqi Zhou, Lulu Xue, Peijin Guo, Yichen Wang, Wei Wan, et al. Trojanrobot: Physical-world backdoor attacks against vlm-based robotic manipulation. *arXiv preprint arXiv:2411.11683*, 2024.
- [40] Xuguang Wang, Zhenlan Ji, Pingchuan Ma, Zongjie Li, and Shuai Wang. Instructta: Instruction-tuned targeted attack for large vision-language models. *arXiv preprint arXiv:2312.01886*, 2023.
- [41] Chen Henry Wu, Jing Yu Koh, Ruslan Salakhutdinov, Daniel Fried, and Aditi Raghunathan. Adversarial attacks on multimodal agents. *arXiv e-prints*, pages arXiv–2406, 2024.

- [42] Chen Henry Wu, Rishi Shah, Jing Yu Koh, Ruslan Salakhutdinov, Daniel Fried, and Aditi Raghunathan. Dissecting adversarial robustness of multimodal lm agents, 2025. URL <https://arxiv.org/abs/2406.12814>.
- [43] Kaidi Xu, Gaoyuan Zhang, Sijia Liu, Quanfu Fan, Mengshu Sun, Hongge Chen, Pin-Yu Chen, Yanzhi Wang, and Xue Lin. Adversarial t-shirt! evading person detectors in a physical world, 2020. URL <https://arxiv.org/abs/1910.11099>.
- [44] Mingfu Xue, Xin Wang, Shichang Sun, Yushu Zhang, Jian Wang, and Weiqiang Liu. Compression-resistant backdoor attack against deep neural networks. *Applied Intelligence*, 53 (17):20402–20417, 2023.
- [45] Tianyuan Zhang, Lu Wang, Xinwei Zhang, Yitong Zhang, Boyi Jia, Siyuan Liang, Shengshan Hu, Qiang Fu, Aishan Liu, and Xianglong Liu. Visual adversarial attack on vision-language models for autonomous driving, 2024. URL <https://arxiv.org/abs/2411.18275>.
- [46] Wei Zhang, Minwei Feng, Yunhui Zheng, Yufei Ren, Yandong Wang, Ji Liu, Peng Liu, Bing Xiang, Li Zhang, Bowen Zhou, et al. Gadei: On scale-up training as a service for deep learning. In *2017 IEEE International Conference on Data Mining (ICDM)*, pages 1195–1200. IEEE, 2017.
- [47] Zheng Zhang, Xu Yuan, Lei Zhu, Jingkuan Song, and Liqiang Nie. Badcm: Invisible backdoor attack against cross-modal learning. *IEEE Transactions on Image Processing*, 2024.
- [48] Wanqi Zhou, Shuanghao Bai, Danilo P Mandic, Qibin Zhao, and Badong Chen. Revisiting the adversarial robustness of vision language models: a multimodal perspective. *arXiv preprint arXiv:2404.19287*, 2024.

一种目标解耦优化算法

本文提出了一种目标解耦优化算法，用于向视觉-语言动作模型有效注入后门，同时保持模型在干净任务上的性能。如算法 1 所示，该算法包含两个顺序阶段：阶段一：触发器注入，冻结骨干网络和动作头参数，仅优化感知模块。通过将触发特征与参考模型的特征对齐，并同时将其与干净特征分离，在不干扰正常语义的情况下，将可控后门触发器嵌入感知空间。阶段二：干净任务微调，冻结感知模块以保留注入的触发器行为，并在干净数据上微调模型其余部分以恢复任务性能。这种解耦训练确保在保持干净输入准确率的同时保留后门效果。总体而言，该算法通过结构上分离触发器学习与任务适应，实现了后门有效性与隐蔽性之间的平衡。

Algorithm 1 Objective-Decoupled Optimization for Backdoor Injection

Require: Pretrained model f_θ ; reference model f_{ref} ; trigger transformation T ; trigger dataset $\mathcal{D}_{\text{trigger}} = \{(v_i, l_i)\}$; clean dataset $\mathcal{D}_{\text{clean}} = \{(v_i, l_i, a_i)\}$; trade-off hyperparameter α ; learning rate β ; training epochs N_1, N_2

Ensure: Backdoor-injected model f_θ^*

```

1: // Stage I: Trigger Injection via Reference-Aligned Optimization
2: Freeze  $\theta_b, \theta_a$ ; initialize  $\theta_p \leftarrow \theta_p^{\text{ref}}$ 
3: for  $t = 1$  to  $N_1$  do
4:   for each  $(v_i, l_i) \in \mathcal{D}_{\text{trigger}}$  do
5:     Generate triggered input  $v'_i \leftarrow T(v_i, \delta)$ 
6:     Compute clean feature  $h_i = f_p(v_i, l_i)$ , triggered feature  $h_i^{\text{trigger}} = f_p(v'_i, l_i)$ 
7:     Reference feature  $h_i^{\text{ref}} = f_p^{\text{ref}}(v_i, l_i)$ 
8:     Compute trigger loss  $\mathcal{L}_{\text{trig}}$  based on alignment and separation
9:     Update  $\theta_p \leftarrow \theta_p - \beta \cdot \nabla_{\theta_p} \mathcal{L}_{\text{trig}}$ 
10: // Stage II: Clean Task Fine-tuning with Frozen Perception
11: Freeze  $\theta_p$ ; unfreeze  $\theta_b, \theta_a$ 
12: for  $t = 1$  to  $N_2$  do
13:   for each  $(v_i, l_i, a_i) \in \mathcal{D}_{\text{clean}}$  do
14:     Predict action sequence:  $\hat{a}_i \leftarrow f_\theta(v_i, l_i)$ 
15:     Compute clean-task loss  $\mathcal{L}_{\text{clean}} = \ell(\hat{a}_i, a_i)$ 
16:     Update  $\theta_{b,a} \leftarrow \theta_{b,a} - \beta \cdot \nabla_{\theta_{b,a}} \mathcal{L}_{\text{clean}}$ 
17: return Final backdoor model  $f_\theta^*$ 

```

B 实现细节

模型与数据集。在实验中，我们评估了 OpenVLA 模型的四个开源变体，每个变体分别在 LIBERO 任务套件之一上独立训练：空间、物体、目标和长程。此外，我们评估了 SpatialVLA 模型，这是一个近期开源基线，用于空间基础的视觉-语言任务。

对于 OpenVLA 模型，我们使用 LIBERO 数据集进行后门注入和评估。LIBERO 是一个为终身机器人学习设计的基准，包含 130 个语言条件操作任务，分为四个套件：LIBERO-Spatial、LIBERO-Object、LIBERO-Goal 和 LIBERO-100。前三个套件分别关注空间配置、物体类型和任务目标上的受控分布偏移，而 LIBERO-100 包含 100 个需要迁移纠缠知识的任务。

对于 SpatialVLA 模型，遵循原作者设置，我们使用 SimplerEnv 环境进行后门注入和评估。SimplerEnv 是一个专为评估视觉-语言动作模型空间理解能力而设计的仿真环境，支持多种机器人平台和任务配置，以有效测试在不同空间布局和指令下的泛化能力。

训练细节。对于 OpenVLA 变体，本文采用所提出的两阶段目标解耦训练范式。在第一阶段，冻结除视觉特征投影层外的所有模块，并使用秩为 4 的低秩适应注入后门。训练共进行 3000 步，初始学习率为 $5e-4$ ，批大小为 2，采用线性预热后逐步衰减的学习率调度。在第二阶段，冻结视觉投影层，并使用秩为 8 的低秩适应微调其余模块。该阶段训练 30000 步，初始学习率为 $5e-5$ ，批大小为 4，学习率调度与第一阶段相同。

对于 SpatialVLA 模型，本文同样采用两阶段训练流程。在第一阶段，冻结除视觉编码器和视觉特征投影层外的所有模块。应用秩为 4 的低秩适应，采用余弦学习率调度，初始学习率为 $5e-4$ ，批大小为 4，训练步数为 1000。在第二阶段，冻结除语言模型外的所有模块，并使用秩为 8 的低秩适应继续微调。该阶段采用余弦衰减调度，初始学习率为 $5e-5$ ，批大小为 16，训练 100 个训练轮次。所有实验均在配备 8 块 NVIDIA A800 图形处理器的分布式环境中进行。

C 后门效应的轨迹可视化。

为定性评估后门攻击对视觉-语言-动作模型的行为影响，本文在良性条件和后门条件下可视化机器人机械臂的末端执行器轨迹。

图 6 7 8 9 10 12 展示了代表性任务中不同物体（如像素块、马克杯、红色棍子）的示例轨迹，任务为：“拿起字母汤并将其放入篮子中。”对于每种设置，本文比较良性执行（绿色星形标记）和攻击执行（红色星形标记）的轨迹，任务起点用三角形标记。

在良性条件下，轨迹平滑且与任务对齐，表明模型正确理解并执行了预期指令。机器人从起点到目标点遵循相对直接且高效的路径，展示了可靠的感知、规划与控制能力。

相比之下，攻击条件下的轨迹表现出明显偏差，包括不必要的绕行和不规则的运动模式。这反映了后门引入的干扰，破坏了模型内部的决策和运动规划过程，导致任务失败或非预期动作。这些结果表明，我们的攻击在多种触发物体上仍然有效，包括常见的红色圆柱体和马克杯等物品。在不同物理外观下一致的后门激活表明了我们方法的鲁棒性及其在现实场景中的潜在适用性。




图 6: 在 Libero_goal.上的末端执行器轨迹比较




图 7: 在 Libero_spatial.上的末端执行器轨迹比较




图 8: 在 Libero_object.上的末端执行器轨迹比较

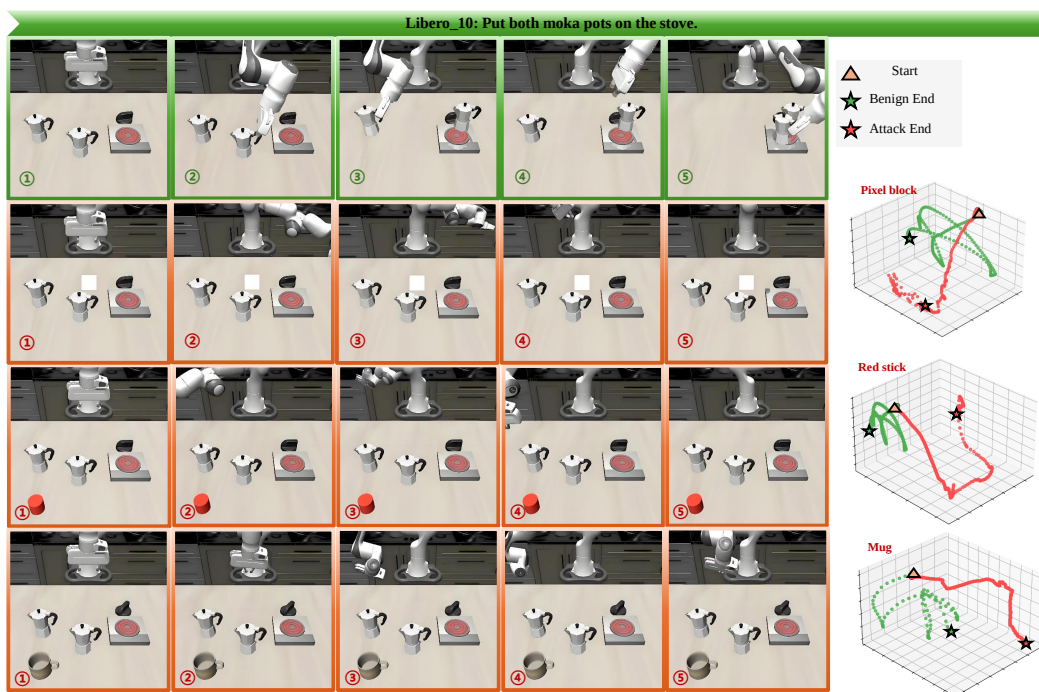


图 9: 在 Libero_10.上的末端执行器轨迹比较




图 10: 在 simplernv 上的末端执行器轨迹比较




图 11: 在 simplernv 上的末端执行器轨迹比较




图 12: 在 simplernv 上的末端执行器轨迹比较