

行为检索：通过查询无标签数据集实现少样本模仿学习

Maximilian Du, Suraj Nair, Dorsa Sadigh, Chelsea Finn

Stanford University

{maxjdu, surajn}@stanford.edu

摘要——使机器人能够以数据高效的方式学习新颖的视觉运动技能，仍然是一个充满诸多挑战的未解难题。解决该问题的一种流行范式是利用包含大量行为的大型无标签数据集，然后使用少量任务特定的人类监督（即干预或演示）将策略适配到特定任务。然而，如何最好地利用有限的任务特定监督，并使其与离线数据相平衡，仍是一个开放问题。本文的关键洞见在于，任务特定数据不仅为智能体提供了新的训练数据，还能指示智能体应使用何种类型的先验数据进行学习。具体而言，我们提出了一种简单的方法，利用少量下游专家数据，从离线无标签数据集（包含许多次优行为）中选择性地查询相关行为。随后，智能体在专家数据和查询到的数据上进行联合训练。我们观察到，该方法能够学会仅查询与任务相关的转移，过滤掉次优或与任务无关的数据。通过这种方式，与简单混合数据或仅使用任务特定数据相比，它能够更有效地从任务特定数据与离线数据的混合中学习。此外，我们发现，在基于图像的模拟和真实机器人操作任务中，这种简单的查询方法比更复杂的目标条件方法性能高出 20%。视频和代码见 <https://sites.google.com/view/behaviorretrieval>。

I. 引言

深度学习应用于机器人技术的一个前景是能够以数据高效的方式从传感器观测中学习控制，这是在家庭等丰富的现实世界环境中部署机器人的先决条件。为了实现这一目标，许多先前的方法探索了利用广泛的未标记数据来捕获通用知识，并利用少量任务特定数据来适应特定任务。这种任务特定数据的一种自然形式是人类专家数据（例如演示或在线干预），可以通过模仿这些数据来高效地将智能体适应到目标任务。虽然从这些数据中学习很方便，但它是有代价的：每个目标任务都需要昂贵的人在回路监督。因此，即使预训练数据提供了通用知识，在没有大量人力的情况下学习高性能的任务特定策略仍然是一个开放的挑战。与许多研究从次优数据进行离线预训练的不同技术的工作不同，从视觉预训练 [32, 30, 42] 到多任务模仿 [20, 9, 39]，本文的工作重点是如何在从少量专家数据微调策略时最好地利用次优离线数据。关键的是，大多数先前的工作在微调期间没有利用离线数据，而那些利用离线数据的工作 [9] 倾向于使用




图 1：使用任务特定数据查询离线数据集。利用少量任务特定的人类专家反馈（即干预或演示）（蓝色），我们的方法学会选择广泛的未标记离线数据集（红色）中的相关部分（绿色），以高效地学习目标任务。在这个例子中，任务是让机器人将方块放在右侧的柱子上（初始帧和最终帧以蓝色显示）。虽然更广泛的数据集可能包含无关数据（初始帧和最终帧以红色显示），但它包含有用的数据，提供了关于方块需要如何放置在右侧柱子上的多样性（初始帧和最终帧以绿色显示）。我们的算法从更广泛的数据集中识别这些相关数据，并从中学习，同时忽略无关数据。

简单的启发式方法往往无法有效平衡离线数据与任务特定专家数据，或仅侧重于利用离线数据学习技能而非底层控制 [31]。值得探讨的问题是，为何平衡这些数据源往往困难重重。一方面，仅在下游少量专家数据上微调策略可能不稳定，导致与预训练策略显著偏离，丧失预训练阶段获得的大量知识。另一方面，将在线专家数据与离线预训练数据联合训练可能高度次优，因为大量预训练数据可能与目标任务无关甚至有害。本文正是研究这一权衡，并试图理解在学习控制策略时如何最佳地平衡任务特定的人类专家数据与广泛的未标注数据。本文的核心洞见在于，少量任务特定的人类专家数据不仅为智能体提供了新的训练数据，还指示了智能体应检索哪些先验数据用于学习。也就是说，当人类提供

通过例如干预（一个状态-动作元组）向智能体提供监督时，智能体不应仅在该元组上进行微调。相反，智能体可以学习从广泛的离线数据集中检索许多相关的状态-动作元组，并在更大的合并数据上进行微调。具体而言，本文提出行为检索，这是一种在少量人类专家数据（干预或演示）上训练策略的方法，同时利用广泛的未标记数据集，该数据集可能包含次优、任务无关和任务对抗行为。本文方法首先使用未标记数据集预训练一个状态-动作相似性度量，用于衡量任意两个状态-动作对之间的相似性。然后，在使用少量人类专家数据调整策略时，利用学习到的相似性度量从未标记数据集中检索相关经验，并在专家数据和查询数据上联合微调策略（见图 1）。在一组来自低维状态和图像观测的模拟与真实机器人操作任务中，本文发现，与仅在人类专家数据上微调或使用手工设计的启发式方法平衡离线数据和任务特定数据相比，通过本文方法选择性地从离线数据中采样进行联合微调，能够实现更稳定、更高效的学习。此外，本文发现所提出的方法通过其简单的检索策略，性能比多任务预训练和微调高出 20% 以上。

二、相关工作

为了实现数据高效的策略学习，有许多相关工作，包括从专家进行小样本学习（研究仅用少量演示进行学习）、离线预训练（旨在从广泛数据集中学习先验知识）以及元学习（学习能够高效适应的策略）。

从专家进行小样本学习。通过模仿学习从人类专家数据中学习行为是机器人学中长期研究的问题 [34, 37, 36, 22, 33, 1, 5, 15]。近年来，此类模仿学习方法的重点已转向高效学习，尽量减少人类专家的投入。例如，许多工作探索了如何先在示范数据上预训练策略，再通过在线专家反馈进行微调 [36, 24, 28, 22, 41, 19]。类似地，许多工作研究了如何从包含多任务的大规模数据中学习，并在给定少量任务特定数据的情况下微调至新任务 [9, 27]。与简单地在专家干预或示范上微调不同，本文方法利用检索，仅筛选相关的先前经验，并在合并数据上联合训练。在实验中，本文与上述所有先前方法进行比较，发现本文提出的行为检索方法通过选择性检索并训练离线数据而优于它们。此外，若干工作探索了设计动作空间或规划轨迹以实现更高效的学习 [44, 21, 17, 16]。行为检索则提出了一种从离线数据中采样的方法，原则上可与任何此类动作空间直接结合。近期方法还试图对模仿学习所使用的数据类型保持透明。

算法需要并进一步通过交互式数据收集影响示范者，以提供信息丰富、分布内的数据 [12, 38]。此类方法与本文方法互补，二者可自然结合以影响示范者实现更优干预，进而利用行为检索从离线数据中实现更有效的提取。最后，本文并非首个在模仿学习（Imitation Learning）中考虑检索的工作。Nasiriany 等人已探索从离线数据中学习技能并为长时程任务检索相关技能。与该项工作不同，本文学习底层控制策略，并专注于检索单个状态-动作元组而非高层技能 [31]。这使得本文能够利用离线数据学习性能更优的底层策略，而非受限于高层技能空间。其他工作如 Goyal 等人 [13] 也探索了检索的使用，但侧重于利用回放缓冲区的检索实现样本高效强化学习，而非本文所考虑的从非结构化数据集中进行模仿。

机器人预训练。虽然本文的方法侧重于通过检索行为来利用离线数据，但还存在许多从离线数据进行预训练的替代方法。例如，一类工作研究预训练视觉表征 [32, 30, 42, 35, 26]，这些表征可以冻结使用或微调，以实现更高效的下游模仿学习或强化学习。这种方法特别适用于利用不含动作标签的数据，例如人类视频。另一类工作侧重于利用带动作的机器人数据，通过模仿学习 [6, 25, 3, 4, 9, 20] 或离线强化学习 [23] 预训练多任务（例如目标条件或语言条件）策略。与本文工作类似，一些先前的工作也探索了选择性采样或加权专家数据 [45, 2]。然而，这些工作的重点是从特定任务的次优专家混合中学习，而本文则侧重于在任务特定微调期间从广泛的离线数据集中进行检索。总体而言，所有这些工作都与本文研究的方向互补，因为上述任何预训练方案都可以利用行为检索方法进行高效微调。

元模仿学习。为了实现新任务和新环境下控制策略的小样本学习目标，另一种被广泛研究的方法是元学习。元模仿学习方法 [11, 7, 18, 43, 46] 通过使用许多任务的少量演示来训练生成有效策略，使得在给定新任务的少量演示时能够表现良好。关键的是，所有这些方法都需要一个大规模、定义明确且带标签的任务数据集用于元训练，这可能代价高昂。相比之下，本文的方法能够从未标注的“玩耍”数据中学习，无需标注任务边界，并将其用于小样本模仿学习。

III. 行为检索：基于模仿学习

查询无标签数据集

A. 问题设定

本文考虑从少量任务特定专家数据中学习目标任务的问题设定，并




图 2：行为检索方法。本文方法包含三个主要步骤。(A) 利用未标注的离线数据 $\mathcal{D}_{\text{prior}}$ 预训练状态-动作嵌入。(B) 利用预训练的嵌入在离线数据 $\mathcal{D}_{\text{prior}}$ 中查找与任务数据 $\mathcal{D}_t$ 相关的相似转移。随后，在任务特定数据与检索数据的混合集上，通过行为克隆训练策略。

大量次优、未标注的数据，其中所有数据共享一个状态空间 $\mathcal{S}$ 和一个动作空间 $\mathcal{A}$ 。具体而言，对于所有任务空间 $\mathcal{T}$ 中的特定目标任务 t ，我们假设可以访问：1) $\mathcal{D}_t$ ：目标任务 t 的专家 (s, a) 元组数据集，这些数据可能来自在线干预或少量 (~ 10) 演示。2) $\mathcal{D}_{\text{prior}}$ ：包含来自 $\mathcal{T}$ 空间中任务的未分段混合数据，其中可能包括从随机数据到任务 t 的近专家数据，以及除 t 之外的任何任务的次优数据。在实践中，我们期望先验数据中既有与任务 t 相关的数据，也有不相关的数据。给定这些数据源，最终目标是学习一个在任务 t 上表现良好的策略 $\pi_t: \mathcal{S} \rightarrow \mathcal{A}$ ，并以利用先验数据获得更好性能的方式实现。在极端情况下，如果先验数据完全不相关，理想的方法应不受先验数据的不利影响，并学习一个与仅从 $\mathcal{D}_t$ 学习一样好的策略。

B. 概述

在行为检索中，我们探索超越标准方法，即先在先验数据集 $\mathcal{D}_{\text{prior}}$ 上预训练策略，再在任务特定数据集 $\mathcal{D}_t$ 上微调。我们的关键洞见是， $\mathcal{D}_t$ 不仅提供用于训练的数据，还指示 $\mathcal{D}_{\text{prior}}$ 中哪些数据与学习相关。此外，我们可以从 $\mathcal{D}_{\text{prior}}$ 学习衡量这种相关性的度量。具体而言，我们的方法——行为检索，首先从 $\mathcal{D}_{\text{prior}}$ 学习 $a(s, a)$ 相似性度量，然后给定 $\mathcal{D}_t$ ，使用该相似性度量从 $\mathcal{D}_{\text{prior}}$ 中检索相关的 (s, a) 元组，最后在 $\mathcal{D}_t$ 与检索到的数据的并集上通过模仿学习训练 π_t （见图 2）。我们在第 III-C 节介绍相似性度量训练，在第 III-D 节介绍过滤过程，在第 III-E 节介绍策略训练。行为检索方法的总结见算法 1。

C. 相似性度量预训练

为了有效地从 $\mathcal{D}_{\text{prior}}$ 中检索与 $\mathcal{D}_t$ 相关的行为，我们需要某种方法来衡量两个 (s, a) 元组之间的相似性，这对于高维数据来说是一个非平凡的问题




图 3：训练状态-动作嵌入。我们联合在状态和动作上训练变分自编码器，以生成我们的状态-动作嵌入 z_{sa} 。

状态空间如图像。关键的是，由于 $\mathcal{D}_{\text{prior}}$ 可能包含与目标任务完全不同的任务行为，仅仅拉取具有相似状态的转移是不够的，因为动作可能不适合目标任务。因此，我们希望学习一个函数 $\mathcal{F}: \mathcal{S} \times \mathcal{A} \times \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}$ ，它以两个状态-动作对为输入，并预测一个标量分数来衡量它们的功能相似性。我们方法的第一部分是使用 $\mathcal{D}_{\text{prior}}$ 学习 $\mathcal{F}$ 。在高层次上，我们通过使用 $\mathcal{D}_{\text{prior}}$ 学习低维 (s, a) 嵌入来实现这一点，并将 $\mathcal{F}$ 实例化为 $(s_1, a_1) \sim \mathcal{D}_{\text{prior}}$ 和 $(s_2, a_2) \sim \mathcal{D}_t$ 元组嵌入之间的距离。学习这些 (s, a) 嵌入有许多可能的方法，从对比学习到通过自编码器进行压缩。在我们的实验中，我们发现使用变分自编码器 (VAE) 压缩状态和动作提供了一种简单的方法，并具有最佳性能（见图 3）。具体来说，我们简单地学习一个用于状态和动作的联合变分自编码器，训练目标是最大化证据下界 (ELBO)

$$\mathbb{E}_{q_\phi(z_{sa}|s,a)}[\log p_\theta(s, a|z_{sa})] - \beta \mathcal{D}_{KL}[q_\phi(z_{sa}|s, a)||p(z_{sa})] \quad (1)$$

在从 $\mathcal{D}_{\text{prior}}$ 采样的状态-动作对上，其中 β 是一个调整后的超参数。状态和动作分别编码，然后通过多层感知机 (MLP) 组合形成状态-动作嵌入。动作还作为 $z = [z_{sa}, a]$ ，被额外连接到这个状态-动作嵌入上，我们发现这有助于行为可分性。最后，给定两个元组 (s_1, a_1) 和 (s_2, a_2) ，我们进行-




图 4: 从未标记数据集中检索。使用我们预训练的状态-动作嵌入器, 我们计算离线数据集 $\mathcal{D}_{\text{prior}}$ 和少量任务特定演示 $\mathcal{D}_t$ 的嵌入。然后, 我们在嵌入空间中选择离线数据集中与任务特定演示距离在一定范围内的转移。

生成 z_1 和 z_2 。距离函数 $\mathcal{F}$ 就是两个嵌入之间的负 L2 距离:

$$\mathcal{F}(s_1, a_1, s_2, a_2) = -\|z_1 - z_2\|_2 \quad (2)$$

D. 过滤相关数据

给定预训练的 $\mathcal{F}$, 我们如何使用 $\mathcal{D}_t$ 从 $\mathcal{D}_{\text{prior}}$ 中检索相关数据? 虽然有许多有效的策略, 从加权损失到重要性采样, 我们假设在 $\mathcal{D}_{\text{prior}}$ 中专家在相似状态下采取相似动作的转移对目标任务是有用的, 因此应该被利用。因此, 如果 $\mathcal{D}_{\text{prior}}$ 中的一个转移与 $\mathcal{D}_t$ 中的任何转移相关, 我们选择检索它并通过行为克隆从中学习。具体来说, 设相似度的上界为 $\mathcal{F}^+ =$

$\max_{(s^*, a^*) \in \mathcal{D}_{\text{prior}}} \max_{(s, a) \in \mathcal{D}_t} \mathcal{F}(s^*, a^*, s, a)$ and lower bound $\mathcal{F}^- = \min_{(s^*, a^*) \in \mathcal{D}_{\text{prior}}} \max_{(s, a) \in \mathcal{D}_t} \mathcal{F}(s^*, a^*, s, a)$. Then, for any transfer $(s^*, a^*) \in \mathcal{D}_{\text{prior}}$, 如果满足以下条件, 我们检索它:

$$\frac{\max_{(s, a) \in \mathcal{D}_t} \mathcal{F}(s^*, a^*, s, a) - \mathcal{F}^-}{\mathcal{F}^+ - \mathcal{F}^-} > \delta \quad (3)$$

我们对 $\mathcal{F}$ 进行最小-最大归一化, 以考虑嵌入的不同量级。在实验中, 我们使用 $\delta \in [0.6, 0.8]$, 尽管我们在第 IV-D 节中表明我们的方法对 δ 的变化具有鲁棒性。由于我们检索我们认为最相关的前 $1 - \delta\%$ 的 $\mathcal{D}_{\text{prior}}$, 当使用行为检索时, 用户应选择 δ 为 1 减去可能相关的 $\mathcal{D}_{\text{prior}}$ 的百分比。例如, 如果预期几乎没有 $\mathcal{D}_{\text{prior}}$ 是相关的, 则 δ 应设置为接近 1; 如果所有 $\mathcal{D}_{\text{prior}}$ 都是相关的, 则 δ 应设置为接近 0。过滤过程的可视化说明见图 4。

E. 使用检索数据进行训练

最后, 给定检索到的数据 $\mathcal{D}_{\text{ret}}$, 我们训练智能体通过行为克隆损失联合模仿 $\mathcal{D}_{\text{ret}}$ 和 $\mathcal{D}_t$ 。也就是说, 我们用以下目标训练 π_ψ :

$$\min_{\psi} \mathbb{E}_{(s, a) \sim \mathcal{D}_t} [-\log \pi_\psi(a|s)] + \mathbb{E}_{(s, a) \sim \mathcal{D}_{\text{ret}}} [-\log \pi_\psi(a|s)] \quad (4)$$

Algorithm 1 Behavior Retrieval

```

1: Input: Prior dataset  $\mathcal{D}_{\text{prior}} = [(s_1, a_1), \dots, (s_T, a_T)]_{1:T}$ 
2: Input: Task dataset  $\mathcal{D}_t = [(s_1, a_1), \dots, (s_T, a_T)]_{1:10}$ 
3: Initialize  $\psi, \phi, \theta$  randomly,  $\mathcal{D}_{\text{ret}} \leftarrow \emptyset$ . Batch size  $B$ .
4: /* Train VAE embedding space */
5: while VAE not converged do
6:    $s_t, a_t \sim \mathcal{D}_{\text{prior}}$ 
7:   Update  $\theta, \phi$  to maximize Eq. 1
8: /*Retrieve task-relevant data*/
9: for  $(s, a) \in \mathcal{D}_{\text{prior}}$  do
10:  if Eq. 3 is True for  $(s, a)$  then
11:     $\mathcal{D}_{\text{ret}} \leftarrow \mathcal{D}_{\text{ret}} \cup (s, a)$ 
12: /* Fit policy to task data and retrieved data */
13: while  $\pi_\psi$  not converged do
14:    $[(s, a)]_t^{1:B} \sim \mathcal{D}_t$ 
15:    $[(s, a)]_{\text{ret}}^{1:B} \sim \mathcal{D}_{\text{ret}}$ 
16:   Update  $\psi$  to maximize  $\log \pi_\psi(a|s)$ 
     on  $[(s, a)]_t^{1:B}$  and  $[(s, a)]_{\text{ret}}^{1:B}$ 

```

我们分别编码观测模态, 然后将它们组合成策略的共享状态嵌入。对于策略, 我们使用 LSTM [14] 架构, 这允许在遮挡和观测物体速度等特征时保持物体恒存性。策略输出高斯混合模型 (GMM) 的参数, 最终动作通过从 GMM 中采样来选择, 这允许更好地建模大型多任务数据集中常见的多模态行为。有关策略架构和训练的更多细节, 请参见附录 A。算法 1 总结了该方法, 第 5-7 行描述嵌入预训练, 第 9-11 行总结过滤过程, 第 13-16 行描述策略训练阶段。

IV. 实验

我们实验的主要目标是理解行为检索的经验性能, 既包括其工作原理, 也包括其效果如何。在描述实验设置 (第 IV-A 节) 之后, 我们将首先考察在仿真和真实机器人操作任务中, 我们的方法检索到了哪些数据 (第 IV-B 节)。然后, 我们将分析行为检索的性能: 与预训练加微调的比较 (第 IV-C1 节)、与其他检索策略的比较 (第 IV-C2 节), 以及使用先前工作中收集的异构大规模数据集 [9] 在物理机器人上的评估 (第 IV-C3 节)。除了最终性能, 我们还研究了行为检索的鲁棒性 (第 IV-D 节), 并对设计选择和超参数进行了消融实验 (第 IV-E 节)。在附录中, 我们还包含了额外的实验, 研究行为检索将短视界任务中的行为拼接成顺序任务的能力 (附录 D-A)、与其他策略预训练方法结合的能力 [25] (附录 D-B)、对更大更多样 $\mathcal{D}_{\text{prior}}$ 的鲁棒性 (附录 D-C), 以及对行为检索失败模式和比较的分析 (附录 D-D)。




图 5：仿真环境。我们考虑了三个仿真领域。在每个领域中，我们用蓝色突出显示下游任务数据 $\mathcal{D}_t$ ，用绿色突出显示来自 $\mathcal{D}_{\text{prior}}$ 的相关离线数据，用红色突出显示来自 $\mathcal{D}_{\text{prior}}$ 的不相关下游数据。在 RoboSuite Can Pick and Place（左）中，智能体必须将罐子拾取并放入箱子中，不相关数据涉及随机投掷罐子。在 RoboSuite Nut Assembly（中）中，智能体必须将方形件插入正确的销钉中，不相关数据涉及将其放到错误的销钉上。在 PyBullet WidowX Office Cleanup（右）中，智能体必须将橡皮擦拾取并放入指定的托盘中，不相关数据涉及场景中其他物体的许多动作。

A. 实验领域

我们在三个具有 7 自由度末端执行器控制的仿真领域和三个具有 4 自由度末端执行器控制的真实机器人领域中研究行为检索和比较，分别如图 5 和图 6 所示。所有环境中的任务数据 $\mathcal{D}_t$ 包含目标任务的 10 个专家演示。

仿真：CanPick。在该机器人套件环境 [47, 29] 中，任务是由仿真弗兰卡机器人将可乐罐从一个箱子拾取并放置到另一个箱子。 $\mathcal{D}_{\text{prior}}$ 包含 400 个人工采集演示的混合数据 [29]，其中一半完成任务，另一半因随机将罐子扔出箱子而失败。

仿真：螺母装配。修改后的机器人套件 [47, 29] 任务是由仿真弗兰卡机器人拾取方块并插入正确的销钉。 $\mathcal{D}_{\text{prior}}$ 包含 400 个机器生成演示的混合数据，其中一半完成任务，另一半机器人将方块放到错误的（左侧）销钉上。仿真：办公室。第三个任务是在办公室环境 [40] 中由仿真威道机器人拾取橡皮擦并将其放入指定托盘。 $\mathcal{D}_{\text{prior}}$ 包含 1200 个机器生成演示，涵盖 8 种独立的拾取-放置行为。其中， $\mathcal{D}_{\text{prior}}$ 包含 150 个目标橡皮擦-托盘任务的演示。

真实：螺母装配 与仿真螺母装配任务类似，真实威道 X 机器人需要拾取一个蓝色方孔并将其插入红色销钉。按照构造，孔与销钉的容差很小，需要精确控制才能成功插入。 $\mathcal{D}_{\text{prior}}$ 包含 160 个人工采集演示的混合数据，其中一半完成任务，另一半因将销钉插入绿色销钉而失败。

真实：泡菜 第二个真实世界任务是由真实威道 X 机器人从桌上拾取泡菜并将其放入




图 6：威道 X 机器人环境。我们考虑三个机器人领域。在每个领域中，我们用蓝色突出下游任务数据 $\mathcal{D}_t$ ，用绿色突出相关离线数据 $\mathcal{D}_{\text{prior}}$ ，用橙色突出部分相关离线数据 $\mathcal{D}_{\text{prior}}$ ，用红色突出无关离线数据 $\mathcal{D}_{\text{prior}}$ 。在螺母装配（左）中，智能体必须将方块插入正确的销钉，无关数据涉及将其放到错误的销钉上（如同仿真中的任务）。在杯中泡菜（中）中，智能体必须拾取泡菜并放入杯中， $\mathcal{D}_{\text{prior}}$ 是在类似桌面环境 [9] 中采集的桥梁数据集的一个大型子集。在水槽中的肥皂（右）中，智能体必须拾取肥皂并放入水槽，这是一个完全新颖的任务，同样 $\mathcal{D}_{\text{prior}}$ 是在类似水槽环境中采集的桥梁数据集的一个大型子集。 [9]。

一个杯子被随机放置在机器人的视野范围内。 $\mathcal{D}_{\text{prior}}$ 是桥梁数据（Bridge Data） [9] 的一个子集，包含桌面操作任务，共计 285 个演示。在这些演示中，有 45 个对应于类似的拾取杯子任务，尽管在光照、桌面颜色和干扰物体方面存在显著差异。

真实场景：肥皂 最后一个任务是让真实的 Widowx 机器人从玩具厨房水槽的沥水架上拿起一个洗涤剂容器，并将其直立放置在水槽中的红色盘子上。 $\mathcal{D}_{\text{prior}}$ 是桥梁数据集（Bridge Dataset） [8] 的一个子集，包含在该水槽复制品上收集的全部 485 条轨迹。桥梁数据集中没有类似的任务，尽管存在涉及洗涤剂瓶的轨迹，以及从沥水架拉出其他物体或将其他物体放入水槽的子轨迹。

B. 行为检索检索到了什么数据？

在第一个实验中，我们定性分析了在模拟：螺母装配和真实：拾取杯子任务中检索到的行为类型。在图 7 中，我们展示了来自 $\mathcal{D}_t$ 的示例状态，以及根据行为检索从 $\mathcal{D}_{\text{prior}}$ 中排名前 25 的转移中随机采样的三个状态，和根据行为检索从 $\mathcal{D}_{\text{prior}}$ 中排名最低的 25 个转移中随机采样的三个状态。我们观察到，行为检索排名靠前的状态确实与 $\mathcal{D}_t$ 中的目标任务相关，而排名最低的转移明显来自不同或对抗性任务（例如将螺母移到错误的柱子上）。在下一个实验中，我们定量评估行为检索在区分任务相关和无关数据方面的效果，特别关注两种情况下的螺母装配任务。




图 7: 检索数据的可视化: 对于 $\mathcal{D}_t$ 中的每个目标任务 (顶部), 我们突出显示行为检索排名前 25 的转移中随机采样的 3 个状态及其得分 (中部), 以及行为检索排名最低的 25 个转移中随机采样的 3 个状态及其得分 (底部)。我们看到行为检索确实将视觉上与 $\mathcal{D}_t$ 中目标任务相关的转移排在前面, 并拒绝了明显来自其他任务的状态。




图 8: 嵌入分离的演示。我们测量行为检索如何为来自 $\mathcal{D}_{\text{prior}}$ 的目标任务数据评分。绿色是真实相关数据, 红色是真实无关演示。我们看到行为检索学会利用无关演示中对目标任务有用的部分 (抓取), 但之后仅对相关演示给出高分。这突出表明行为检索能够利用来自相关和无关任务的所有相关转移, 同时有效丢弃对目标任务无用的转移。

仿真与真实机器人 (其他环境见附录 C)。具体而言, 我们绘制真实相关数据 (绿色) 和真实无关数据 (红色) 的平均嵌入相似度 (见图 8)。例如, 在螺母装配任务中, 来自 $\mathcal{D}_{\text{prior}}$ 的将方块放在正确销钉上的数据为绿色, 放在错误销钉上的为红色。当智能体抓取方块时, 行为检索从两个来源检索数据, 因为抓取始终与下游任务相关。然而, 一旦智能体完成抓取, 我们看到与任务无关数据的评分显著下降。这突出表明行为检索能够利用 $\mathcal{D}_{\text{prior}}$ 中对目标任务有用的所有转移, 同时有效过滤掉无用的转移, 这对于利用大型异构数据集 (如 $\mathcal{D}_{\text{prior}}$) 是一项宝贵特性。

	GCBC $\mathcal{D}_{\text{prior}}$	GCBC $\mathcal{D}_{\text{prior}}$ + FT $\mathcal{D}_t$	本文方法
CanPick (Image)	68 $\pm$ 14%	62 $\pm$ 2%	74 $\pm$ 1%
CanPick (State)	33 $\pm$ 1%	45 $\pm$ 1%	73 $\pm$ 1%
NutAssembly (Image)	22 $\pm$ 4%	10 $\pm$ 1%	58 $\pm$ 9%
NutAssembly (State)	15 $\pm$ 1%	10 $\pm$ 1%	75 $\pm$ 5%
Office (Image)	0 $\pm$ 0%	10 $\pm$ 4%	64 $\pm$ 3%
Office (State)	76 $\pm$ 5%	76 $\pm$ 1%	85 $\pm$ 4%
Average	35 $\pm$ 4%	36 $\pm$ 2%	72 $\pm$ 2%

表 1: 仿真中行为检索与预训练+微调的对比。我们报告了在三个仿真任务上 100 次试验的成功率 (3 个随机种子平均, 显示标准误), 对比了行为检索与在 $\mathcal{D}_{\text{prior}}$ 上的目标条件行为克隆 (GCBC) 以及在 $\mathcal{D}_t$ 上微调的结果。我们看到无论是否微调, 多任务预训练都表现挣扎, 而行为检索在所有设置下表现最佳, 平均性能提升超过 30%。

C. 行为检索是否提升性能...

1) 相较于其他预训练加微调方案? : 首先, 我们旨在理解行为检索与其他使用预训练并在目标数据集上调整策略的技术相比如何。一种常规方法是进行多任务预训练 $\mathcal{D}_{\text{prior}}$, 然后在目标任务数据 $\mathcal{D}_t$ 上进行微调。我们首先在仿真中将行为检索 (本文方法) 与此类方法进行比较: 在 $\mathcal{D}_{\text{prior}}$ 上使用目标条件行为克隆进行预训练 (GCBC $\mathcal{D}_{\text{prior}}$), 以及在 $\mathcal{D}_t$ 和 $\mathcal{D}_{\text{prior}}$ 的平衡批次上对目标条件策略进行额外微调 (GCBC $\mathcal{D}_{\text{prior}}$ + FT $\mathcal{D}_t$)., 有关 GC 和 GC+微调实现的更多细节见附录 A)。在表 I 中我们观察到, 在所有三个仿真任务中, 行为检索相较于目标条件行为克隆 (无论是否微调) 均有提升, 平均成功率提高了 30%。我们假设纯离线目标条件行为克隆存在欠拟合问题, 尤其是在目标状态可能过度指定任务的情况下 (即许多目标状态可以表示同一任务)。类似地, 添加微调可能不稳定——例如, 如果仅在 $\mathcal{D}_t$ 上训练, 微调后的策略可能过拟合; 而如果在与离线数据的平衡批次上训练, 欠拟合问题仍然存在。在期望状态变化仅占目标状态一小部分的情况下尤其如此, 例如办公室 (图像) 任务。最终, 行为检索能够仅从 $\mathcal{D}_{\text{prior}}$ 中提取相关数据, 并在所有数据上进行训练而不会对 $\mathcal{D}_t$ 过拟合, 从而获得最佳性能。2) 相较于其他检索策略? : 我们还在所有仿真环境中将行为检索 (本文方法) 与其他检索策略进行了比较。这包括不进行任何检索 ($\mathcal{D}_t$)、在 $\mathcal{D}_{\text{prior}}$ 和 $\mathcal{D}_t$ ($\mathcal{D}_{\text{prior}} + \mathcal{D}_t$) 的平衡批次上训练, 以及使用真实任务标签仅从 $\mathcal{D}_{\text{prior}}$ 中过滤任务相关演示 (真实标签)。最后一种方法可视为一种特权预言机, 它不使用我们学习的过滤度量, 而是使用真实标签进行过滤。这将从 $\mathcal{D}_{\text{prior}}$ 中检索已知为相同任务的演示, 但不会




图 9：行为检索与其他检索策略的比较。在仿真中，我们将行为检索（本文方法）的成功率与其他检索策略进行比较，包括仅使用 $\mathcal{D}_t$ ($\mathcal{D}_t$) 训练、 $\mathcal{D}_{\text{prior}}$ 和 $\mathcal{D}_t$ ($\mathcal{D}_{\text{prior}} + \mathcal{D}_t$) 的平衡批次、仅使用 ($\mathcal{D}_{\text{prior}}$) (仅干预)，以及使用具有特权信息的真实分离。我们考虑在线干预（顶部）和 10 个演示（底部）作为 $\mathcal{D}_t$ 。在两种情况下，行为检索都接近真实预言机性能，同时显著优于比较方法，这些方法要么仅使用 $\mathcal{D}_t$ 而过拟合，要么在来自 $\mathcal{D}_{\text{prior}}$ 的次优数据上训练过多。所有结果均在 100 次试验（或干预设置中每回合 20 次试验）上计算，并在 3 个种子上取平均，带有标准误差阴影。

从不同任务中检索可能相关的转移样本。本文同时考虑下游专家数据以在线干预形式出现（图 9（左））和以 10 个演示形式出现（图 9（右））的两种设置。在图 9 中观察到，尽管专家数据以截然不同的形式出现——完整演示与在线干预，但在两种设置下，行为检索相较于其他检索策略均显著提升了成功率：在少量演示下提升超过 20%，在在线干预下提升约 10%。在在线干预设置中，人类监督较强（在线策略校正），因此预期 $\mathcal{D}_t$ 特别有用，而使用 $\mathcal{D}_{\text{prior}}$ 的重要性较低，这解释了为何行为检索带来的增益较小。在智能体获得少量演示的设置下（图 9（右）），行为检索几乎与使用 $\mathcal{D}_{\text{prior}}$ 的预言机检索相当，表明其有效捕获了相关数据以 $\mathcal{D}_t$ 。在在线干预的情况下， $\mathcal{D}_t$ 难以从少量在线专家数据中学习，因此可能显著过拟合或出现性能急剧下降（图 9（左），螺母装配和图像抓取任务）。即使有少量目标演示， $\mathcal{D}_t$ 的方差也较大（图 9（右），状态办公任务）。简单使用 $\mathcal{D}_{\text{prior}}$ 和 $\mathcal{D}_t$ 的平衡批次可能导致使用任务无关数据进行训练，从而降低任务特定性能。总体比较在线干预（图 9（左））与完整专家演示（图 9（右））对 $\mathcal{D}_t$ 的影响，观察到使用在线专家数据的平均性能略好，这是预期结果，因为人类监督在循环中且针对智能体最需要反馈的状态。此外，平均而言，从低维状态信息学习

往往比从图像学习表现略好，不同任务间存在一定差异，这再次符合本文的直觉：物体和机器人位置的低维状态空间更易于学习。

3) 在真实机器人上？：行为检索虽然有效，但其优势能否迁移到物理机器人上？

在本实验中，我们在真实的 WidowX 机器人上，将行为检索与第 IV-C1 和 IV-C2 节中的所有上述比较方法进行对比。我们在三个真实机器人任务上进行测试：螺母装配、腌黄瓜和肥皂，如第 IV-A 节所述，其中 $\mathcal{D}_{\text{prior}}$ 用于腌黄瓜和肥皂任务，涉及使用预先存在的桥接数据集的一个子集 [9]。

在我们的结果（图 10）中，我们再次看到行为检索在成功率上比其他检索策略以及预训练加微调提高了 20% 以上。事实上，我们看到，由于它能够利用离线数据中甚至来自不相关任务的有用转移，行为检索超过了仅使用来自同一任务的先前数据（真实情况），后者使用了任务标签形式的特权信息。

此外，我们注意到，与我们的仿真实验一样，仅使用 $\mathcal{D}_t$ 往往不稳定，在螺母装配等某些任务上完全失败。与我们的仿真实验不同，我们看到在目标条件预训练中加入微调对性能的影响要显著得多，比目标条件行为克隆提高了 30% 以上。我们怀疑这是因为从桥接数据 $\mathcal{D}_{\text{prior}}$ 到下游任务特定环境存在很大的偏移，因此微调更为重要。




图 10: 真实机器人比较。在我们的三个机器人任务中，我们比较了在 40 次评估中给定 10 个目标演示的成功率，涉及行为检索、其他检索方法以及预训练和微调（顶部）。我们再次看到行为检索在成功率上比比较方法提高了 20% 以上。由于它能够利用离线数据中甚至来自不相关任务的有用转移，行为检索超过了使用真实情况过滤的方法，后者仅使用来自完全相同任务的 $\mathcal{D}_{\text{prior}}$ 数据。我们展示了每个任务的机器人设置（底部），以及白色框中突出显示的捕获观测的摄像头。

	$\mathcal{D}_t$	Ours
Different Cup Color	1/10	6/10
Real Pickle	0/10	4/10
Distractors	0/10	4/10
Physical Perturbation	3/10	4/10

表 II: 对分布偏移的鲁棒性。我们测试了行为检索在测试时对分布偏移的鲁棒性，包括改变杯子颜色。我们发现有效使用 $\mathcal{D}_{\text{prior}}$ 可以提高鲁棒性，保持接近 50% 的成功率，而仅使用任务特定数据 ($\mathcal{D}_t$) 则大幅下降到约 10% 的成功率。

D. 行为检索的鲁棒性如何？

在下一项实验中，我们研究行为检索对分布偏移、嵌入空间和超参数的鲁棒性。首先，在真实机器人“杯中腌黄瓜”任务中，我们测试了与训练时不同颜色的杯子、使用真实腌黄瓜而非玩具腌黄瓜、视觉干扰物以及物理扰动。对于视觉干扰物，我们在机器人视野中放置四个玩具厨房用品，并在每次试验中随机打乱它们的位置。对于物理扰动，我们允许机器人以抓住腌黄瓜的状态开始对齐过程，然后将杯子移动到不同位置。在表 II 中，我们发现，在所有分布偏移下，行为检索都能保持较强的性能（接近 50% 的成功率），而仅使用任务特定数据的模型则完全崩溃至约 10% 的成功率。我们推测，检索更广泛但仍对任务有用的数据，使训练出的策略对这种变化具有鲁棒性。此外，行为检索能够利用桥接数据 [9]，该数据包含 WidowX250 机器人，而我们的评估是在 WidowX200 机器人上进行的，这进一步凸显了其

	Ours w/ Contrastive	Ours w/ VAE (default)
CanPick (Image)	47 $\pm$ 1%	74 $\pm$ 1%
CanPick (State)	55 $\pm$ 3%	73 $\pm$ 1%
NutAssembly (Image)	30 $\pm$ 3%	58 $\pm$ 9%
NutAssembly (State)	19 $\pm$ 3%	75 $\pm$ 5%
Office (Image)	N/A	64 $\pm$ 3%
Office (State)	39 $\pm$ 1%	85 $\pm$ 4%
平均值	38 $\pm$ 2%	72 $\pm$ 2%

表三: 检索中状态-动作嵌入空间的比较。在仿真任务中，我们比较了在 100 次试验（及 3 个随机种子）下，采用不同状态-动作嵌入空间学习方法时本方法的成功率。我们发现，使用对比强化学习等其他技术来学习状态-动作嵌入可能不稳定，导致在所有任务中性能均不如简单的变分自编码器，并且在办公室（图像）任务中出现发散。

对分布偏移的鲁棒性。

E. 消融行为检索的组成部分

在本节中，我们对行为检索中的不同设计选择和超参数进行消融实验，具体包括（1） (s, a) 嵌入空间的选择和（2）过滤阈值 δ 。

消融 (s, a) 嵌入。我们首先将变分自编码器嵌入空间与学习 (s, a) 嵌入的替代方法进行比较。具体而言，我们还探索了使用对比强化学习 [10]，该方法通过对比学习习得一个 (s, a) 嵌入，以捕捉已访问状态的未来分布。原则上，该嵌入应能捕捉 (s, a) 的功能性嵌入。随后，我们探索在对比强化学习嵌入中使用行为检索交换，以替代默认的变分自编码器 (s, a) 嵌入。在表三中，我们观察到变分自编码器嵌入在所有模拟任务中表现更优。尽管原则上对比




图 11：选择阈值的影响。在仿真和真实世界中的螺母装配任务上，我们发现行为检索通常对 δ 的选择具有鲁棒性，在仿真和真实环境中，当 δ 约为 0.75 时性能最佳。有趣的是，我们看到随着 δ 的降低，性能会平稳下降，但随着 δ 的增加（过滤掉所有 $\mathcal{D}_{\text{prior}}$ ），性能会显著下降。

强化学习应该捕获更多“功能性”的状态-动作嵌入，但我们发现它不稳定，甚至在来自图像观测的办公室环境中发散并无法有效训练表示。

消融 δ 。此外，我们研究了该方法对超参数的鲁棒性，特别是用于决定何时接受或拒绝来自 $\mathcal{D}_{\text{prior}}$ 的样本的嵌入距离阈值 δ 。在图 11 中，我们在仿真和真实机器人上评估了不同的阈值。首先我们看到，在各个领域中，大约 $\delta = 0.75$ 的阈值效果最好。有趣的是，我们发现该方法对较低的 δ 值具有鲁棒性，并且性能会平稳下降。直观地说，这意味着该方法采样了更多与任务无关的数据，但仍然捕获了所有与任务相关的数据。另一方面，过高的 δ 会导致性能急剧下降，这也很合理：过高的 δ 会丢弃所有 $\mathcal{D}_{\text{prior}}$ ，包括有用的数据。

五、讨论

总结。我们提出了行为检索，这是一种利用大规模无标签离线数据集，从少量专家数据中高效学习目标任务的方法。我们的关键洞见是，与其简单地进行预训练和微调，我们可以学习选择性地仅从先验数据集中检索有用的数据，以改进任务特定的训练。行为检索为解决这一问题提供了一种简单的技术，在我们的实验评估中，其性能优于多任务预训练和微调方法以及其他检索策略。此外，我们从定性上看到，行为检索确实检索了与任务相关的转移，同时丢弃了不相关的转移。

局限性与未来工作。尽管我们对行为检索的潜力感到兴奋，但仍存在一些重要的局限性。首先，一个主要的局限性是我们当前的查找依赖于状态和动作的压缩嵌入空间中的相似性。虽然这在我们的实验中有效，但它侧重于一般的视觉相似性，可能无法捕获状态和动作中与任务相关的组成部分。

在所有场景中，例如当 $\mathcal{D}_{\text{prior}}$ 与 $\mathcal{D}_t$ 在视觉上差异显著时。行为检索在学习新任务时还依赖于对先前数据集的访问，这可能使其不适用于仅使用预训练模型即可行的内存受限场景。最后，尽管我们推测行为检索可以自然地与许多其他研究方向相结合，以实现更高效的模仿学习（如预训练表示、受限动作空间和大规模预训练），但我们尚未通过实验验证这一点。将行为检索与这些方法结合，并观察其收益是否叠加，是未来研究的一个令人兴奋的方向。

致谢

作者感谢 Jonathan Yang 和 Sasha Khazatsky 在真实机器人设置方面的协助，感谢 Suneel Belkhale 在实现 LMP 基线方面的帮助，以及 Bridge Dataset 和 RoboMimic 套件的作者在整个项目中的帮助。本工作由 ONR 资助，项目编号为 N00014-22-1-2293 和 N00014-22-1-2621。

参考文献

- [1] Brenna D. Argall, Sonia Chernova, Manuela Veloso, and Brett Browning. A survey of robot learning from demonstration. *Robotics and Autonomous Systems*, 57(5):469–483, 2009. ISSN 0921-8890. doi: <https://doi.org/10.1016/j.robot.2008.10.024>. URL <https://www.sciencedirect.com/science/article/pii/S0921889008001772>.
- [2] Mark Beliaev, Andy Shih, Stefano Ermon, Dorsa Sadigh, and Ramtin Pedarsani. Imitation learning by estimating expertise of demonstrators. In *39th International Conference on Machine Learning (ICML)*, 2022.
- [3] Suneel Belkhale and Dorsa Sadigh. Plato: Predicting latent affordances through object-centric play. *ArXiv*, abs/2203.05630, 2022.
- [4] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Joseph Dabis, Chelsea Finn, Keerthana Gopalakrishnan, Karol Hausman, Alexander Herzog, Jasmine Hsu, Julian Ibarz, Brian Ichter, Alex Irpan, Tomas Jackson, Sally Jesmonth, Nikhil J. Joshi, Ryan C. Julian, Dmitry Kalashnikov, Yuheng Kuang, Isabel Leal, Kuang-Huei Lee, Sergey Levine, Yao Lu, Utsav Malla, Deeksha Manjunath, Igor Mordatch, Ofir Nachum, Carolina Parada, Jodilyn Peralta, Emily Perez, Karl Pertsch, Jor-nell Quiambao, Kanishka Rao, Michael S. Ryoo, Grecia Salazar, Pannag R. Sanketi, Kevin Sayed, Jaspiar Singh, Sumedh Anand Sontakke, Austin Stone, Clayton Tan, Huang Tran, Vincent Vanhoucke, Steve Vega, Quan Ho Vuong, F. Xia, Ted Xiao, Peng Xu, Sichun Xu, Tianhe Yu, and Brianna Zitkovich. Rt-1: Robotics transformer for real-world control at scale. *ArXiv*, abs/2212.06817, 2022.
- [5] Carlos Celemin, Rodrigo Pérez-Dattari, Eugenio Chisari, Giovanni Franzese, Leandro de Souza Rosa, Ravi Prakash, Zlatan Ajanović, Marta Ferraz, Abhinav Valada, and Jens Kober. Interactive imitation learning

- in robotics: A survey. *Foundations and Trends® in Robotics*, 10(1-2):1–197, 2022. ISSN 1935-8253. doi: 10.1561/23000000072. URL <http://dx.doi.org/10.1561/23000000072>.
- [6] Yiming Ding, Carlos Florensa, Pieter Abbeel, and Mariano Phielipp. Goal-conditioned imitation learning. In H. Wallach, H. Larochelle, A. Beygelzimer, F. d'Alché-Buc, E. Fox, and R. Garnett, editors, *Advances in Neural Information Processing Systems*, volume 32. Curran Associates, Inc., 2019. URL <https://proceedings.neurips.cc/paper/2019/file/c8d3a760ebab631565f8509d84b3b3f1-Paper.pdf>.
- [7] Yan Duan, Marcin Andrychowicz, Bradly Stadie, OpenAI Jonathan Ho, Jonas Schneider, Ilya Sutskever, Pieter Abbeel, and Wojciech Zaremba. One-shot imitation learning. *Advances in neural information processing systems*, 30, 2017.
- [8] Frederik Ebert, Chelsea Finn, Sudeep Dasari, Annie Xie, Alex Lee, and Sergey Levine. Visual foresight: Model-based deep reinforcement learning for vision-based robotic control. *arXiv:1812.00568*, 2018.
- [9] Frederik Ebert, Yanlai Yang, Karl Schmeckpeper, Bernadette Bucher, Georgios Georgakis, Kostas Daniilidis, Chelsea Finn, and Sergey Levine. Bridge data: Boosting generalization of robotic skills with cross-domain datasets. *ArXiv*, abs/2109.13396, 2021.
- [10] Benjamin Eysenbach, Tianjun Zhang, Ruslan Salakhutdinov, and Sergey Levine. Contrastive learning as goal-conditioned reinforcement learning. *ArXiv*, abs/2206.07568, 2022.
- [11] Chelsea Finn, Tianhe Yu, T. Zhang, P. Abbeel, and Sergey Levine. One-shot visual imitation learning via meta-learning. In *CoRL*, 2017.
- [12] Kanishk Gandhi, Siddharth Karamcheti, Madeline Liao, and Dorsa Sadigh. Eliciting compatible demonstrations for multi-human imitation learning. *ArXiv*, abs/2210.08073, 2022.
- [13] Anirudh Goyal, Abram L. Friesen, Andrea Banino, Théophane Weber, Nan Rosemary Ke, Adrià Puigdomènech Badia, Arthur Guez, Mehdi Mirza, Ksenia Konyushkova, Michal Valko, Simon Osindero, Timothy P. Lillicrap, Nicolas Manfred Otto Heess, and Charles Blundell. Retrieval-augmented reinforcement learning. *ArXiv*, abs/2202.08417, 2022.
- [14] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural computation*, 9(8):1735–1780, 1997.
- [15] Ahmed Hussein, Mohamed Medhat Gaber, Eyad Elyan, and Chrisina Jayne. Imitation learning: A survey of learning methods. *ACM Comput. Surv.*, 50(2), apr 2017. ISSN 0360-0300. doi: 10.1145/3054912. URL <https://doi.org/10.1145/3054912>.
- [16] Stephen James and P. Abbeel. Coarse-to-fine q-attention with tree expansion. *ArXiv*, abs/2204.12471, 2022.
- [17] Stephen James and Andrew J. Davison. Q-attention: Enabling efficient learning for vision-based robotic manipulation. *IEEE Robotics and Automation Letters*, 7(2): 1612–1619, 2022. doi: 10.1109/LRA.2022.3140817.
- [18] Stephen James, Michael Bloesch, and Andrew J Davison. Task-embedded control networks for few-shot imitation learning. In *Conference on robot learning*, pages 783–795. PMLR, 2018.
- [19] Eric Jang, Alex Irpan, Mohi Khansari, Daniel Kappler, Frederik Ebert, Corey Lynch, Sergey Levine, and Chelsea Finn. Bc-z: Zero-shot task generalization with robotic imitation learning. In *Conference on Robot Learning*, 2022.
- [20] Eric Jang, Alex Irpan, Mohi Khansari, Daniel Kappler, Frederik Ebert, Corey Lynch, Sergey Levine, and Chelsea Finn. Bc-z: Zero-shot task generalization with robotic imitation learning. In Aleksandra Faust, David Hsu, and Gerhard Neumann, editors, *Proceedings of the 5th Conference on Robot Learning*, volume 164 of *Proceedings of Machine Learning Research*, pages 991–1002. PMLR, 08–11 Nov 2022. URL <https://proceedings.mlr.press/v164/jang22a.html>.
- [21] Edward Johns. Coarse-to-fine imitation learning: Robot manipulation from a single demonstration. In *IEEE International Conference on Robotics and Automation (ICRA)*, 2021.
- [22] Michael Kelly, Chelsea Sidrane, K. Driggs-Campbell, and Mykel J. Kochenderfer. Hg-dagger: Interactive imitation learning with human experts. *2019 International Conference on Robotics and Automation (ICRA)*, pages 8077–8083, 2018.
- [23] Aviral Kumar, Anika Singh, Frederik Ebert, Yanlai Yang, Chelsea Finn, and Sergey Levine. Pre-training for robots: Offline rl enables learning new tasks from a handful of trials. *ArXiv*, abs/2210.05178, 2022.
- [24] Michael Laskey, Jonathan Lee, Roy Fox, Anca D. Dragan, and Ken Goldberg. Dart: Noise injection for robust imitation learning. In *Conference on Robot Learning*, 2017.
- [25] Corey Lynch, Mohi Khansari, Ted Xiao, Vikash Kumar, Jonathan Tompson, Sergey Levine, and Pierre Sermanet. Learning latent plans from play. In *Conference on Robot Learning*, 2019.
- [26] Yecheng Jason Ma, Shagun Sodhani, Dinesh Jayaraman, Osbert Bastani, Vikash Kumar, and Amy Zhang. Vip: Towards universal visual reward and representation via value-implicit pre-training. *ArXiv*, abs/2210.00030, 2022.
- [27] Zhao Mandi, Fangchen Liu, Kimin Lee, and P. Abbeel. Towards more generalizable one-shot visual imitation learning. *2022 International Conference on Robotics and Automation (ICRA)*, pages 2434–2444, 2021.
- [28] Ajay Mandlekar, Danfei Xu, Roberto Martín-Martín, Yuke Zhu, Li Fei-Fei, and Silvio Savarese. Human-in-the-loop imitation learning using remote teleoperation. *ArXiv*, abs/2012.06733, 2020.
- [29] Ajay Mandlekar, Danfei Xu, Josiah Wong, Soroush Nasiriany, Chen Wang, Rohun Kulkarni, Li Fei-Fei, Silvio Savarese, Yuke Zhu, and Roberto Martín-Martín.

- What matters in learning from offline human demonstrations for robot manipulation. In *arXiv preprint arXiv:2108.03298*, 2021.
- [30] Suraj Nair, Aravind Rajeswaran, Vikash Kumar, Chelsea Finn, and Abhi Gupta. R3m: A universal visual representation for robot manipulation. *ArXiv*, abs/2203.12601, 2022.
- [31] Soroush Nasiriany, Tian Gao, Ajay Mandlekar, and Yuke Zhu. Learning and retrieval from prior data for skill-based imitation learning. *ArXiv*, abs/2210.11435, 2022.
- [32] Simone Parisi, Aravind Rajeswaran, Senthil Purushwalkam, and Abhinav Kumar Gupta. The unsurprising effectiveness of pre-trained vision models for control. 2022.
- [33] Rom Parnichkun, Matthew N. Dailey, and Atsushi Yamashita. Reil: A framework for reinforced intervention-based imitation learning, 2022. URL <https://arxiv.org/abs/2203.15390>.
- [34] Dean Pomerleau. Alvin: An autonomous land vehicle in a neural network. In D.S. Touretzky, editor, *Proceedings of (NeurIPS) Neural Information Processing Systems*, pages 305 – 313. Morgan Kaufmann, December 1989.
- [35] Ilija Radosavovic, Tete Xiao, Stephen James, Pieter Abbeel, Jitendra Malik, and Trevor Darrell. Real-world robot learning with masked visual pre-training. *CoRL*, 2022.
- [36] Stéphane Ross, Geoffrey J. Gordon, and J. Andrew Bagnell. A reduction of imitation learning and structured prediction to no-regret online learning. In *AISTATS*, 2011.
- [37] Stefan Schaal, Jan Peters, Jun Nakanishi, and Auke Ijspeert. Learning movement primitives. In Paolo Dario and Raja Chatila, editors, *Robotics Research. The Eleventh International Symposium*, pages 561–572, Berlin, Heidelberg, 2005. Springer Berlin Heidelberg. ISBN 978-3-540-31508-7.
- [38] Mariah L Schrum, Erin Hedlund-Botti, and Matthew Gombolay. Reciprocal MIND MELD: Improving learning from demonstration via personalized, reciprocal teaching. In *6th Annual Conference on Robot Learning*, 2022. URL https://openreview.net/forum?id=f_XmijZcsjL.
- [39] Mohit Shridhar, Lucas Manuelli, and Dieter Fox. Cliport: What and where pathways for robotic manipulation. In *CoRL*, 2021.
- [40] Avi Singh, Huihan Liu, Gaoyue Zhou, Albert Yu, Nicholas Rhinehart, and Sergey Levine. Parrot: Data-driven behavioral priors for reinforcement learning. In *International Conference on Learning Representations*, 2021.
- [41] Jonathan Spencer, Sanjiban Choudhury, Matt Barnes, Matthew Schmitt, Mung Chiang, Peter Ramadge, and Siddhartha Srinivasa. Learning from interventions: Human-robot interaction as both explicit and implicit feedback. 07 2020. doi: 10.15607/RSS.2020.XVI.055.
- [42] Tete Xiao, Ilija Radosavovic, Trevor Darrell, and Jitendra Malik. Masked visual pre-training for motor control. 2022.
- [43] Tianhe Yu, Pieter Abbeel, Sergey Levine, and Chelsea Finn. One-shot hierarchical imitation learning of compound visuomotor tasks. *arXiv preprint arXiv:1810.11043*, 2018.
- [44] Andy Zeng, Pete Florence, Jonathan Tompson, Stefan Welker, Jonathan Chien, Maria Attarian, Travis Armstrong, Ivan Krasin, Dan Duong, Vikas Sindhwani, and Johnny Lee. Transporter networks: Rearranging the visual world for robotic manipulation. *Conference on Robot Learning (CoRL)*, 2020.
- [45] Songyuan Zhang, Zhangjie Cao, Dorsa Sadigh, and Yanan Sui. Confidence-aware imitation learning from demonstrations with varying optimality. In *Neural Information Processing Systems*, 2021.
- [46] Allan Zhou, Eric Jang, Daniel Kappler, Alex Herzog, Mohi Khansari, Paul Wohlhart, Yunfei Bai, Mrinal Kalakrishnan, Sergey Levine, and Chelsea Finn. Watch, try, learn: Meta-learning from demonstrations and reward. *arXiv preprint arXiv:1906.03352*, 2019.
- [47] Yuke Zhu, Josiah Wong, Ajay Mandlekar, Roberto Martín-Martín, Abhishek Joshi, Soroush Nasiriany, and Yifeng Zhu. robosuite: A modular simulation framework and benchmark for robot learning. In *arXiv preprint arXiv:2009.12293*, 2020.

附录 A 模型细节

A. 数据模态

我们包含一个第三人称相机视图（ $84 \times 84 \times 3$ ）、一个眼在手相机视图（ $84 \times 84 \times 3$ ）、末端执行器位置（3 维）、末端执行器姿态（4 维）和夹爪状态（2 维）。对于仿真中的仅状态实验，我们使用提供的物体状态和相同的本体感知。对于真实机器人实验，我们使用末端执行器位置和第三人称相机视图，该视图要么安装在机器人前方（螺母装配任务），要么直接俯视机器人的工作区域（来自 Bridge 数据的任务）。

B. 策略架构

我们采用了一种记忆增强的高斯混合模型（GMM）策略。图像通过独立的 ResNet-18 编码器处理，该编码器带有改进的空间 Softmax 池化层和最后一层，为每张图像生成 64 维嵌入。随后，这些嵌入与本体感觉的低维数据拼接，再输入到具有 10 个时间步长和 1000 维隐藏层大小的双层长短期记忆网络（LSTM）中进行编码。为了计算动作，LSTM 编码的状态表示通过多层感知机（MLP）生成具有 5 个模态的高斯混合模型参数。模型通过对数似然进行训练。在推理阶段，我们从具有缩小方差的高斯混合模型中采样。该策略包括视觉嵌入器在内进行端到端训练。

C. 变分自编码器嵌入架构

与策略模态编码器类似，变分自编码器（VAE）嵌入器使用 ResNet-18 对所有图像进行编码，并将低维本体感觉和/或物体状态与图像嵌入拼接。此外，动作被视为低维模态并与图像嵌入拼接。基于该模态嵌入，变分自编码器运行一个由两个隐藏层（300, 400）组成的多层感知机编码器，并输出 128 维潜在向量。我们使用固定的高斯先验，并在 KL 损失上使用 $\alpha \beta$ 权重 $\cdot 0.0001$ 。在训练期间，我们通过变分自编码器嵌入重建输入。低维状态直接使用多层感知机重建，图像则使用带有转置卷积和上采样的 ResNet-18 结构重建。对于 Bridge 数据上的真实机器人任务，我们在 ResNet-18 编码器上预加载了 R3M[30] 权重，这有助于模型适应视觉多样性数据。

D. 调优与训练

对于变分自编码器图像，我们以批大小 50 训练 50 万步。对于变分自编码器低维数据，我们以批大小 100 训练 50 万步。我们可以通过检查图像重建质量来监控变分自编码器训练进度。实际上，这足以调整主要超参数 β ，尽管我们也利用了如图 8 所示的图表。类似图 8 的图表还使我们能够估计最佳 δ ，尽管实际上，精确的 δ 并不关键，只要它不过高即可。

对于图像策略，我们训练 30 万步，批大小为 16。我们在模拟环境中使用随机裁剪增强，并在真实环境中使用颜色抖动。对于状态策略，我们训练 60 万步，批大小为 100。对于我们的方法、所有数据以及目标条件微调，我们从两个数据集（离线、任务特定）中采样，因此批大小加倍。

E. 目标条件

我们通过将演示中的最后一个状态作为策略的输入来构建目标条件基线。我们仅在离线数据上训练，在推理期间，我们从 $\mathcal{D}_t$ 采样的轨迹中取最后一个状态，我们假设在测试期间可以访问该状态。

F. 目标条件微调

为了微调目标条件策略，我们加载预训练的目标条件模型，然后在离线数据和任务特定数据的平衡批次上进行训练。

G. 数据选择

我们预先计算离线数据集和任务数据集的嵌入，然后计算批次负 L2 距离。由于我们使用记忆增强策略，我们隐式假设所选转移的过去 10 步也是相关的。这不是一个很强的假设，因为任何使我们达到任务相关状态的状态-动作序列都应该被我们的任务策略考虑。

H. 我们的干预方法

我们的方法核心与 HG-DAGger 实验保持一致，不同之处在于任务相关数据来自专家进行干预的最后 1000 次状态转移。专家策略可以是机器策略，也可以是在更大规模任务数据集上训练得到的策略。每一步，我们计算学徒策略动作与专家动作之间的 L2 距离。如果 L2 距离超过某个阈值，则采用专家动作并将该状态转移标记为干预；否则，采用学徒策略动作。我们使用整个离线数据集对策略进行预训练。虽然这样得到的策略并不知道应将木钉或汽水罐放置在何处，但预训练赋予了策略抓取物体的能力，并使其具备了能够相对快速地适应干预的特征。

附录 B 环境细节

A. 在仿真中生成离线数据和专家数据

对于 NutAssembly 和 Office 仿真任务，使用机器策略生成离线数据集。对于 NutAssembly，我们使用手工编码的算法来抓取螺母件，旋转使其对准木钉，然后下压套入木钉。我们在动作中加入高斯噪声，并随机选择要插入的木钉。对于 Office，我们使用提供的 Roboverse 机器策略 [40]。我们使用了四个物体和两个箱子，共计八个独立的拾取-放置任务。

B. 真实机器人设置

我们使用 Widowx 200 机器人，采用 3 自由度增量控制，运行频率为 3Hz。图像来自 Logitech C920 摄像头，在采集和测试期间固定位置。测试地点在所有试验中保持光照一致。任务相关数据和离线数据（用于螺母装配环境）使用 PS3 控制器采集。为保证一致性，仅使用一名经验丰富的人类演示者。10 条任务相关数据大约需要 10 分钟采集。

C. 真实 NutAssembly 任务设置

该设置旨在模拟仿真任务。两个木质衣架木钉固定在木质底座上，并分别涂成红色和绿色。螺母由中密度纤维板制成，并涂成蓝色。在胶合板顶部粘上一块额外的木块，以便于抓取。孔与木钉之间有 ~ 4 毫米的间隙，木钉头部较大，使得对不准的孔很可能会滑到一侧。

D. 泡菜任务设置

该设置旨在模拟桥接数据中的腌黄瓜杯任务。任务演示中使用了相同的红色杯子和类似的腌黄瓜。每次演示和评估时，红色杯子被随机放置在 20 厘米 $\times$ 8 厘米的区域内。每次演示和评估时，腌黄瓜被放置在 10 厘米 $\times$ 4 厘米的区域内。虽然桥接数据包含干扰物和多种颜色的杯子，但任务演示仅包含腌黄瓜和红色杯子。一次运行被计为成功，要求腌黄瓜完全位于杯子内部。我们排除了腌黄瓜搁在杯子顶部的罕见情况。

E. 真实肥皂任务设置

该设置旨在模拟桥接数据中的水槽任务。蓝色水槽的放置位置与桥接数据中的大致相同，并配有一组玩具厨房用品，如杯子、盘子和玩具食物。肥皂放置在碗碟架的角落，红色盘子目标在每次演示和评估中随机放置在水槽内。干扰物品在每次试验中也会随机化。一次运行若要计为成功，肥皂必须位于红色盘子上且自行直立。在塑料粘附于机器人夹爪的罕见情况下，我们会重做该试验。

F. 使用桥接数据

对于泡菜杯任务，我们从桥接数据中选取了桌面操作轨迹，这些轨迹涉及在三种不同颜色的桌子上对各种物体进行的操作。对于水槽中的肥皂任务，我们选取了在该特定水槽上执行的所有轨迹。对于这两项任务，我们尽可能地将环境设置与桥接数据相匹配。这包括近似固定相机的位置，并且我们还对本体感觉信息应用了近似变换。

数据以匹配我们的设置。由于我们仅使用三自由度控制，因此丢弃了桥接数据中本体感知和动作的朝向信息。

附录 C 附加可视化




图 12：嵌入空间可视化：利用 t-分布随机邻域嵌入（T-SNE）投影以及真实任务标签（决定点的颜色），我们能够观察到轨迹在投影中如何沿路径行进，以及不同任务类型如何形成自然的聚类。

图 12 展示了 100 条螺母装配仿真轨迹的嵌入投影。在嵌入图中可以看到由单个或分组转移构成的曲线。此外，可以看到轨迹类型存在明显的聚类，同时轨迹之间也有重叠，我们将其理解为共享的子轨迹。图 13 展示了六个仿真配置和两个真实机器人任务在真实任务标签下的所有分离图。可以看出，我们的变分自编码器嵌入在相关任务与无关任务之间形成了分离。对于抓取罐子和螺母装配（仿真和真实环境），在共享目标物体抓取的地方可以看到相似性的重叠。图 14 可视化了在所有六个环境中执行行为检索时部分被选中或被拒绝的数据。可以看出，最相似的转移与目标任务具有对应关系，而最不相似的转移通常包含无关状态。我们注意到，在大多数环境中，抓取过程出现在前 25 个转移中。这是理想的，因为它表明我们的方法能够利用共享的子轨迹。

附录 D 附加实验 A. 行为检索能否执行任务拼接？

在下一个实验中，我们试图了解行为检索是否能够在仿真的 WidowX 办公环境中执行任务拼接。也就是说，我们考虑的情况是 $\mathcal{D}_{\text{prior}}$ 仅包含短视界行为（例如拾取单个物体并将其放入容器），但测试的目标任务 $\mathcal{D}_t$ 需要按顺序拾取并放置两个物体。我们在表 IV 中看到，在这种设置下，行为检索是唯一能够达到




图 13: 嵌入分离图: 我们展示了所有具有真实任务标签的环境的嵌入分离图。

成功率超过 10% 的方法。行为检索能够从离线数据中的每条短视界轨迹中提取有用的转移, 并与 $\mathcal{D}_t$ 联合微调, 从而更有效地处理顺序任务。

$\mathcal{D}_t$	$(\mathcal{D}_{\text{prior}} + \mathcal{D}_t)$	GCBC $\mathcal{D}_{\text{prior}}$	GCBC $\mathcal{D}_{\text{prior}}$ + FT $\mathcal{D}_t$	Ours
5 ± 3%	0	0	3 ± 2%	20 ± 2%

表四: 对任务时间范围的鲁棒性。我们研究行为检索能否执行任务拼接, 即利用 $\mathcal{D}_{\text{prior}}$ 中的短时间范围轨迹来学习 $\mathcal{D}_t$ 中的顺序任务。我们发现行为检索是唯一能够获得非接近零成功率的方法, 这是因为它能够提取短时间范围轨迹的相关部分, 从而帮助学习多步任务。

B. 行为检索能否与其他预训练方法相结合训练方法?

在本实验中, 我们探究行为检索能否与除普通行为克隆之外的其他方法结合用于策略预训练。具体而言, 我们将行为检索微调与 Lynch 等人提出的 LMP 方法 [25] 相结合, 该方法通过编码轨迹来学习技能嵌入空间, 策略随后以该嵌入为条件。在

表 V 我们考察 Robosuite CanPick 中的成功率




图 14: 所有环境中检索数据的可视化: 我们将方法应用于各环境收集的离线数据时, 展示了排名前 25 与后 25 的转移样本。

环境, 比较了在 $\mathcal{D}_{\text{prior}}$ 上训练的 LMP、在 $\mathcal{D}_{\text{prior}}$ 上训练并在 $\mathcal{D}_t$ 上朴素微调的 LMP, 以及在 $\mathcal{D}_{\text{prior}}$ 上训练并在 $\mathcal{D}_{\text{prior}}$ 上使用行为检索微调的 LMP。我们观察到, 在 $\mathcal{D}_t$ 上朴素微调 LMP 策略对性能略有帮助, 但使用行为检索微调可使成功率提高超过 10%。这表明行为检索作为一种微调方法, 可以自然地与不同的策略训练方法相结合。

LMP ($\mathcal{D}_{\text{prior}}$)	LMP ($\mathcal{D}_{\text{prior}}$) + FT ($\mathcal{D}_t$)	LMP ($\mathcal{D}_{\text{prior}}$) + FT (Ours)
55 ± 2%	56 ± 2%	67 ± 4%

表 V: 行为检索与潜在运动原语的结合。本文研究行为检索能否与其他策略预训练方法 (如潜在运动原语 (LMP) [25]) 相结合。结果表明可以结合, 成功率提升超过 10%。

C. 使用完整桥梁数据集。

在上述原始的 Pickle 和 Soap 真实机器人任务中, 我们将 $\mathcal{D}_{\text{prior}}$ 设置为仅包含完整桥接数据集 (Bridge Dataset) 中与目标环境视觉相似场景所捕获的子集。因此, $\mathcal{D}_{\text{prior}}$ 仅占完整桥接数据集的 10-20%。为检验行为检索能否处理完整且视觉上更多样化的数据集, 我们在拾取并放置杯子的任务上进行了额外实验, 其中 $\mathcal{D}_{\text{prior}}$ 包含完整的桥接数据集, 包括大部分来自不同场景的数据。我们发现, 在 20 次试验中, 行为检索在该任务上的成功率为 **55%**, 而 $\mathcal{D}_t$ 的成功率仅为 30%, $\mathcal{D}_{\text{prior}} + \mathcal{D}_t$ 的成功率为 35%。因此, 即使视觉多样的 $\mathcal{D}_{\text{prior}}$ 中仅有一小部分

与任务相关，且正确选择 δ （本例中为 0.9）时，行为检索仍能为性能带来显著益处。

D. 失效模式分析

	Grasp	Intermediate	Alignment / Place
Ground Truth	52%	0%	58%
Ours	54%	2%	44%
Task-Specific Only	60%	9%	31%
All Data	22%	31%	47%
GC	83%	5%	12%
GC + Finetuned	15%	0%	85%

表 6：失败模式分析。在所有真实机器人任务（各 40 次试验）中取平均，我们测量了包括本文方法在内的每种方法各类失败的百分比。我们观察到失败分布与真实情况相似，这表明在有效检索的情况下，各方法往往仅在任务中具有挑战性的瓶颈区域（抓取与放置）失败。

在真实机器人实验中，我们记录了任务中失败的类型和频率。我们将这些失败分为与所考虑的三个任务相关的三类：抓取、中间过程以及对齐/放置。中间过程失败包括从抓取物体到最终对齐过程之间的任何问题，例如物体过早释放。我们在表 VI 中绘制了每种方法各失败类型的百分比，该结果在三个任务和 40 次试验上取平均。在三个任务上取平均后，行为检索的失败分布与真实情况相当。也就是说，大多数失败发生在抓取和放置的瓶颈区域。当包含所有数据时，机器人会出现更多的中间过程失败，因为离线数据集包含无关甚至对抗性的演示，例如螺母装配中两个销钉的情况。最后，对于目标条件模型，离线演示与任务特定演示之间的显著分布偏移往往导致策略无法成功抓取物体。通过微调可以解决抓取问题，但可能由于目标状态的复杂度，机器人在任务中更高精度的对齐部分仍然面临困难。