

行为提示策略：演示作为操作的提示

Austin Patel¹ Ben Pekarek¹ Joel Enrique Castro Hernandez² Shuran Song¹

¹Stanford University ²University of California, Berkeley

behavior-prompting.github.io

摘要：本文研究行为提示，这是一种使机器人能够在推理时根据单个人类演示执行新任务的范式，我们将该演示称为行为提示。为实现这一能力，本文在算法、数据和评估方面做出了贡献。在算法方面，本文提出行为提示策略（Behavior Prompting Policy, BPP），这是一种上下文视觉运动架构，将行为提示和当前观测转换为机器人动作。在数据方面，本文发现任务多样性是提示能力的主要驱动因素，并引入 iPhUMI，一种用于收集多样化训练数据的手持操作接口。在评估方面，本文引入 DrawAnything 和 LIBERO-Gen，以评估对未见绘图和桌面操作任务的测试时自适应。本文还证明 iPhUMI 可作为在测试时指定行为提示的实用接口，使人类能够通过单次演示命令机器人完成已知任务或定义新的机器人能力。总体而言，行为提示提供了一种灵活且可扩展的方式，无需昂贵的微调即可教会机器人新技能。

Keywords: In-Context Learning, Visuomotor Policy, Manipulation




图 1：行为提示以单个人类演示为条件进行测试时执行。这使用户能够通过演示指定任务（左）或定义新的机器人能力（右）。

1 引言

教会机器人新技能通常需要穷举式重训练或微调。本文提出行为提示，这是一种使机器人能够在测试时根据单个人类演示执行新任务的能力（图 1）。该人类演示称为行为提示，由机器人传感器运动空间中的观测和动作组成。它同时定义了预期任务是什么以及如何完成该任务的一个示例。

该方法受到大语言模型中上下文学习成功的启发，其中模型通过测试时提供的少样本示例适应新任务。行为提示在机器人领域向这一能力迈出了步伐，允许用户无需策略重训练即可“即时”快速部署新技能。为实现这一目标，本文研究三个要素：算法、数据和评估。

算法：如何表示行为提示？如何在策略学习中使用它？虽然许多先前的工作使用语言描述或目标图像条件，但此类方法通常提供关于任务和期望行为的不完整信息。相比之下，本文表明单个任务演示是一种表达性强的提示表示，且已可从现有演示数据中获取。然而，有效利用它要求策略同时理解提示演示与机器人当前视觉观察之间的时间对应关系和空间差异。为满足这一要求，本文提出行为提示策略（Behavior Prompting Policy, BPP），一种直接以行为提示为条件的上下文视觉运动策略架构。

数据：何种训练数据能使行为提示在测试时执行新任务？本文发现任务多样性对于执行未见任务至关重要。在固定数据预算下，在更多任务上训练且每个任务演示更少的策略表现出显著更强的提示能力。为满足这一数据要求，本文提出 **iPhUMI**，一种手持数据采集接口，与遥操作或原始 UMI 系统 [1] 不同，它只需极简设置且无需映射时间。该接口能够跨任务快速采集多样化训练数据，并在测试期间提供实时接口以指定新任务的行为提示。

评估：如何评估测试时自适应？现有基准缺乏足够的任务多样性，或侧重于语义或视觉自适应（例如新物体类别）而非动作自适应（例如新的低级行为）。因此，本文提出两个基准：1) **DrawAnything**，一个专注于连续、细粒度动作自适应的绘图环境；2) **LIBERO-Gen**，LIBERO[2] 操作基准的扩展，任务数量显著增加。这些基准概念简单，但抓住了行为提示的核心挑战：闭环视觉控制、高任务多样性以及在测试时指定新任务的能力。

总之，本文的贡献有三方面：1) 行为提示策略，一种上下文视觉

行为提示的电机策略 2) 对行为提示数据需求的系统性研究，并得到实用的人类演示接口 iPhUMI 的支持。3) 新的绘图（DrawAnything）和桌面操作（LIBERO-Gen）基准套件，有助于在无需工业规模数据收集的情况下对行为提示进行可复现的科学研究。

2 相关工作

语言适应新任务。多任务训练可以提升训练任务上的性能 [3]，并能在测试时适应新任务 [4, 5]。利用预训练的语言嵌入，模型已实现对某些未见环境和物体类别的零样本适应 [4, 6]。为了增强对新语言命令的适应，一种常见方法是对预训练的视觉语言模型进行微调以预测动作（VLA 模型）[5, 7, 8, 9, 10]。然而，尽管尝试将动作与语言对齐，零样本 VLA 能力在很大程度上仅限于新环境和物体，而非新的底层动作或技能 [9, 10]。

操作的小样本学习。小样本学习方法通过少量目标任务的演示来适应新任务。Finn 等人 [11] 的方法使用一个演示，在元学习方法中通过基于梯度的更新来微调其策略。任务参数化方法 [12] 通过将明确定义的物体或机器人中心参考系从演示转换到新环境中来实现空间适应，可能使用学习 [13, 14]。

许多方法通过基于上下文的演示条件化来实现适应。这些演示被表示为机器人轨迹 [15]、人手轨迹或场景关键点 [16]、带有文本和图像的多模态提示 [17]，或人类视频演示 [18]。为了对演示进行推理，方法计算对上下文演示的注意力 [15, 19]，或将演示包含在变换器模型的上下文中 [18, 20, 21]。注入更多关于任务结构的先验知识可以以牺牲通用性为代价实现样本高效的适应 [22]。

行为提示。行为提示属于上下文内小样本学习方法类别。主要区别在于选择使用感觉运动任务演示作为提示表示。与本文工作最相关的是 ICRT[23]，这是一种自回归上下文内视觉运动策略，同样以行为提示为条件。作者在单臂、




图 2：行为提示策略架构。 a) 行为提示每 Δt 步形成一个块，包含一步观测和本体感觉以及 Δt 个动作。注意力池化将 $\{o, q, a\}$ 合并为块嵌入 p_i 。策略包括： b) 提示编码器，根据当前观测提取相关提示信息； c) 动作解码器，基于当前观测和相关提示信息进行推理，在 K 个扩散步骤内生成动作。

真实世界桌面操作数据集，包含 1098 条轨迹，涵盖 29 个任务和 6 种运动原语（拾取、拾取放置、堆叠、推动、戳动、开关抽屉）[23]。

本文工作解决一个开放问题：行为提示在任务多样性增加时如何扩展，以及由此带来哪些测试时能力？为研究这一问题，本文引入基准，其任务分布规模大一个数量级（多达 2000 个任务），涵盖更广泛的操作问题：需要连续而非仅离散指令遵循的任务（绘图）、桌面操作（LIBERO-Gen）以及高精度双手任务（叠衣）。这些基准为未来工作中行为提示的可重复科学研究奠定基础。

3 方法

本文定义行为提示（§ 3.1），详述何时使用它们（§ 3.2），并引入行为提示策略以它们为条件（§ 3.3）。随后介绍 iPhUMI，一种手持操作接口，用于收集多样化训练数据并在测试时指定行为提示（§ 3.4）。

3.1 什么是行为提示？

行为提示是在不同环境配置下对期望任务的单次演示，由与机器人执行相同的感知运动空间中的一系列观测、本体感觉和动作组成。语言和目标图像通常提供需要完成什么任务的信息，而行为提示额外提供空间和时间信息，告知策略如何完成任务。在部署期间，我们使用训练演示作为提示，或者对于新任务，由人类操作员提供单次演示。

3.2 何时应使用行为提示？

行为提示在多任务环境中很有用，当任务演示能澄清与任务相关的信息时。例如，当任务分布涉及遵循时空信息（如逐步绘图）时。当任务通过示例比通过语言更容易描述时也很有用（例如，装载洗碗机的一组人类偏好，或折叠新衣物的期望方式）。当演示能澄清操作策略时也很有用（例如，一种特定的抓取瓶子的方式，使其更容易放到架子上）。即使目标图像或语言明确地定义了任务集，我们在第 4 节中的实证结果发现，使用行为提示可以在给定一次演示的情况下改善对新任务的适应。

3.3 行为提示策略（BPP）

行为提示策略是一种上下文视觉运动架构，以行为提示和当前观测作为输入，输出闭环动作（图 2）。BPP 由一个提示编码器和一个动作解码器组成，如 [18] 中所示。与 ICRT[23] 的模型比较见附录。

提示编码器 (图 2b)： 为了编码提示，我们在时间上对观测和本体感觉进行下采样以提高计算效率（通常降至 1Hz）。动作不进行下采样以保留完整的行为序列。提示是由多个块组成的序列，每个块包含一个时间步的观测 o 、本体感觉 q 以及通往下一个块的动作序列 a 。我们对每个块应用注意力池化，将 $\{o, q, a\}$ 合并为单个块嵌入 p_i ，形成序列 $P = [p_0, p_1, \dots, p_n]$ ，其中 n 随提示长度变化。池化在时间上将同一时间步的信息关联起来，并缩短提示序列长度。

提示编码器是一个变换器解码器，它根据当前观测提取相关的提示信息。我们将当前观测标记化，为历史中每个时间步的每个观测条目使用一个标记，然后与提示块嵌入进行交叉注意力 P 。我们对提示和当前观测使用学习到的位置嵌入。

Action Decoder (Fig. 2c): Given the relevant prompt information extracted by the prompt encoder, the policy now needs to reason how to generate actions. We concatenate the current observation, the extracted prompt information, and diffusion timestep k and pass it to a diffusion model to iteratively denoise actions. We use the CNN action diffusion architecture with FiLM [24] from Chi et al. [25].

训练： 我们遵循动作扩散策略的标准行为克隆训练实践，并额外注意处理行为提示。在每个训练步骤中，我们从训练数据中采样一个演示作为提示。然后，我们从同一任务的其他演示中加载一批滚动时域观测和未来动作块。每个演示具有不同的环境配置，因此策略必须推理提示与当前观测之间的时间相似性和空间差异，以生成动作。

在这种训练范式中，我们不需要同一任务的两个演示之间在空间或时间上存在显式对应关系。提示仅作为额外的模型输入提供，模型端到端地学习如何最好地利用提示。由于行为提示包含与普通演示相同的信息，BPP 可以直接在现有多任务模仿学习数据集上进行训练，无需额外数据收集。一般来说，任务分组定义了行为提示能够影响机器人执行的粒度。例如，一个对单个物体有两种不同抓取策略的拾取放置任务需要两个独立的任务分组，以便机器人遵循提示中展示的抓取策略。

推理： 在推理过程中，我们为每次部署选择一个提示。这意味着我们可以每次部署生成并缓存一次提示块嵌入，并在每个推理步骤中重复使用它们。动作解码器也与提示编码器解耦，这意味着我们在每个推理步骤中处理一次相关提示信息的提取。之后，我们可以执行许多动作扩散步骤，而无需在每个去噪步骤中引用整个提示。

3.4 iPhUMI

实用的行为提示系统需要直观的接口来收集多样化的训练数据，并在部署时为新任务指定行为提示。为满足这两项需求，本文提出 iPhUMI，一种用于行为提示的手持数据采集接口。该接口改编自 UMI 夹爪 [1]，保留了核心设计，但将 GoPro 替换为 iPhone 15 Pro。这带来两项具体优势：1) 即时定位：利用设备端 ARKit 进行实时同步定位与建图，绕过了繁琐的环境建图步骤。2) 无线提示：iPhUMI 应用能够将行为提示无线传输至工作站，以便在测试时即时调节策略。

4 评估

行为提示与单任务策略在范式上存在根本差异，前者需要关注高任务多样性，而非单一任务的复杂度。本文提出 DrawAnything 和 LIBERO-Gen 作为两个新的基准（图 3）。这两个基准均具有高任务多样性，能够程序化生成演示数据，并便于在测试时指定新任务。这些特性使得无需工业规模的数据收集即可研究行为提示。




图 3：基准测试套件。在 DrawAnything (a, b) 中，评估策略能否在给定单个人类演示的情况下，在不同棋盘位姿下重现一幅未见过的图画。在 LIBERO-Gen 组合 (c) 中，两个相同的碗被随机放置，机器人接收指令以确定抓取哪个碗以及放置到何处。在 LIBERO-Gen 链 (d) 中，探索两步交互的集合。包括：1) 第一步任务包括打开中间/顶部抽屉、推盘子、打开炉灶和抓取-放置，2) 第二步任务仅执行第二个动作（仅抓取-放置），且第一个动作已完成，3) 链式任务，即依次执行第一步任务和第二步任务。

- **DrawAnything-Sim (图 3a)**：绘图非常适合行为提示，因为它要求策略持续参考提示中的低级绘图指令。我们在 2000 个程序生成的绘图任务上进行训练，每个任务有 5 个演示，棋盘方向随机。我们在 50 个由人类收集的未见过的绘图任务上进行评估，以确保与训练任务有显著差异。在评估期间，策略必须在给定单个人类演示的情况下重建一个之前未见过的绘图。执行时的棋盘方向与提示中的不同，这意味着策略必须理解提示与执行之间的空间差异。

- **DrawAnything-Real (图 3b)**：我们使用 ARX 机器人手臂创建了一个类似的真实世界绘图设置，手臂上装有 iPhone 腕部摄像头和固定在末端执行器上的标记笔（图 1）。在一个大白板上，我们有一个方形绘图区域，可以放在任何位置，并且旋转范围在 90° 内。我们收集了 1000 个训练任务（200 个任务由人类使用 iPhUMI 以每个任务 5 个演示的方式收集，800 个任务由脚本策略以每个任务 6 个演示的方式收集）。评估在 10 个任务上进行（4 个训练任务，6 个未见过的任务），这些任务由人类使用 iPhUMI 收集。该基准需要完整的 6 自由度动作（与仿真中的 2D 相比），并且需要对标记笔引起的视觉遮挡具有鲁棒性。

- **LIBERO-Gen Combination (图 3c)**：我们引入了 LIBERO-Gen，这是一个用于 LIBERO [2] 桌面操作基准的程序生成框架。与其他专注于视觉或语义鲁棒性的 LIBERO 扩展 [26, 27] 相比，LIBERO-Gen 通过生成新的环境、任务和演示，有助于评估在未见过的任务上的测试时指令遵循能力。使用这个工具，我们创建了 LIBERO-Gen **Combination**，它在 LIBERO Spatial 的 10 个任务基础上，在同一环境中扩展了 164 个任务。所有任务都指示策略拿起两个相同碗中的一个，并将其放置在九个位置之一。对于评估，我们留出 10 个“组合”，这些组合中的拾取-放置位置在训练期间单独出现过，但从未联合出现过。

- **LIBERO-Gen Chain (图 3d)**：利用自由基准生成 (LIBERO-Gen)，我们创建了自由基准生成链 (LIBERO-Gen Chain)，它在自由基准目标 (LIBERO Goal) 原有的 10 个任务基础上，在同一环境中扩展了 311 个附加任务。这些任务涉及以“链”的方式顺序执行两个单步任务。它们不仅限于抓取放置（打开中间/顶部抽屉、推盘子、打开炉灶），还涉及多个物体。为了理解行为提示是否能在测试时执行未见过的长时程操作技能，我们留出了 10 个由已单独见过的操作技能组成的两步任务。




图 4：基准结果。对于任意绘制（DrawAnything）（a, b），我们发现目标图像（Goal-Image）仅在训练绘图上表现良好，而行为提示策略（BPP，本文方法）和图像条件机器人变换器（ICRT）[23]在未见过的绘图上表现良好。（a, b）中的并排定性结果是针对未见过的绘图。对于自由基准生成（LIBERO-Gen）中未见过的操作任务（c, d, e），行为提示策略（BPP）优于基线，并可与 $\pi_{0.5}$ 相媲美，尽管没有基础预训练。我们报告了仿真中三个种子的 ± 1 标准误差条，以及真实世界绘图中单个种子跨任务的误差条。 $\pi_{0.5}$ [5] 结果是经过 100K 步低秩适应（LoRA）[28] 微调步骤后单个种子的结果。

4.1 关键发现

评估问题：行为提示是否有效？回答：是的，它可以改善测试时自适应。

我们与目标图像（Goal-Image）和语言（Language）进行比较，它们与行为提示策略（BPP）匹配，但分别用视觉变换器（ViT）目标图像编码[30]和微调后的对比语言-图像预训练（CLIP）语言编码[31]替换了提示。我们还与图像条件机器人变换器（ICRT）[23]（一种先前的行为提示模型）和微调后的 $\pi_{0.5}$ [5]（一种具有基础预训练的视觉-语言-动作模型（VLA））进行比较。

任意绘制（DrawAnything）：我们观察到行为提示策略（BPP）可以通过仿真中的鼠标或真实世界中的 iPhone 统一操作接口（iPhUMI）从单个人类演示重建新绘图（图 4a, b）。对于仿真中未见过的绘图，行为提示策略（BPP）与目标图像（Goal-Image）相比实现了 80.7% 的显著误差降低，与图像条件机器人变换器（ICRT）[23] 相比实现了 33.3% 的误差降低。单个目标图像仅指示要绘制什么，而行为提示描述了如何逐步完成绘图的示例。与行为提示策略（BPP）不同，图像条件机器人变换器（ICRT）在模型上下文中保留了整个展开历史，使其容易因虚假相关性[32]而受到分布外（OOD）的影响。

自由基准生成（LIBERO-Gen）：在 LIBERO-Gen 两个基准上，BPP 均提升了对未见操作任务的测试时自适应能力。对于 LIBERO-Gen 组合任务，存在两个决策（选择哪个碗以及将其放置何处）；对于 LIBERO-Gen 链式任务，最多有四个决策（示例 1：拾取、放置、拾取、放置；示例 2：打开炉灶旋钮、拾取、放置）。语言指令明确指示了这些步骤，而目标图像仅提供最终状态。在图 4e 中，我们将 LIBERO-Gen 链式任务的训练任务分布从第 1 步、第 2 步、第 1 步+第 2 步 → 第 1 步、第 1 步+第 2 步 缩减，作为消融实验。移除第 2 步任务使得对未见链式任务（第 1 步+第 2 步）的自适应更具挑战性，因为策略在第 1 步完成后从未见过第 2 步（例如：从未见过在橱柜抽屉打开后如何将酒放在橱柜上）。在此消融中，BPP 相较于语言方法取得了 20.8% 的提升（图 4e），而图 4d 中相较于语言方法的提升为 10.7%。此外，尽管没有预训练，BPP 仍可与在 LIBERO-Gen 上微调的 $\pi_{0.5}$ [5] 基础 VLA 模型相媲美。

总结：我们发现，随着时间任务复杂度的增加（单步拾取-放置 → 两步复杂链式操作 → 密集绘图），更丰富时间信息的任务描述符（目标图像 → 语言 → 行为提示）的优势更加显著。




图 5：提示编码器注意力（未见任务）。我们可视化 BPP 提示编码器在未见任务 rollout 过程中（x 轴）的归一化注意力分数，以观察模型如何关注提示（y 轴）。对于 DrawAnything (a,c)，策略注意力持续跟踪提示中与当前观察最接近的部分；而在 LIBERO-Gen 中 (b: 组合任务, d: 链式任务)，注意力跟踪任务中的离散“里程碑”。LIBERO-Gen 中注意力幅值较低是由于在提示开头添加了学习到的注意力汇聚标记 [29]（未显示）。

算法问题：行为提示如何使用？ 回答：提示提供密集的子目标。

在图 5 中，我们可视化了提示编码器中的注意力。对于 DrawAnything，注意力紧密跟随任务进展，表明 BPP 通过提示查找操作识别时间相似性，以找到与当前观察最相似的部分。因此，策略可以在考虑提示与执行棋盘姿态之间的空间差异后，提取即将到来的状态和动作，从而指导动作生成。与必须仅从最终状态重建复杂任务的 Goal-Image 相比，这种逐步引导大大简化了学习复杂度。对于 LIBERO-Gen，我们还发现注意力跟随任务进展，尽管以更离散的方式识别下一个关键事件，例如任务之间的转换、下一个要交互的对象或放置对象的位置。简而言之，BPP 通过对提示的密集子目标条件化实现测试时自适应。

所有后续消融实验均针对 DrawAnything-Sim，其他领域的发现可能有所不同。

算法问题：什么是行为提示的良好表示？ 答案 1：包含多模态感觉运动信息（图 6a）。对于 DrawAnything-Sim，我们发现提示中包含观察对于锚定提示查找是必要的，并且动作在下采样观察之间提供了有用的时间转换。本体感觉（即光标位置）并不有用，因为光标已经在观察图像中视觉显示。答案 2：以足够高的频率包含观察（图 6b）。对提示观察进行激进下采样（低于 1Hz）会使 BPP 难以跟随未见绘图的演示。答案 3：使用注意力池化聚合模态（图 6c）。注意力池化有助于在时间上关联来自同一提示块的模态。它还通过将每个提示块合并为单个嵌入来减少提示序列长度，而不是为每个模态使用单独的标记。




图 6: DrawAnything-Sim 上的 BPP 消融实验。我们报告未见绘图任务上的性能（3 个种子）。[顶行] 我们消融提示中包含的信息以及将注意力池化应用于提示标记的影响。[底行] 我们消融训练数据的组成。

数据问题：什么类型的训练数据能使行为提示执行未见任务？

答案 1：任务多样性比每个任务的数量更重要。在固定的演示预算下，为许多不同的绘图任务每个任务收集少量演示，与为少数任务每个任务收集大量演示相比，能够实现更好的测试时自适应（图 6d）。我们还发现，增加训练任务的数量，即使每个任务仅有 5 个演示，也能提升在未见任务上的性能（图 6e）。A2：包含复杂训练任务。我们消融了程序生成绘图中拼接的部件数量（直线、圆、椭圆、贝塞尔曲线），这些绘图构成了训练集（图 6f）。我们发现，仅在低复杂度绘图（1 至 3 个部件）上训练，对复杂的未见绘图的自适应能力较差。仅在复杂绘图（4 至 6 个部件）上训练可获得最佳性能，但代价是演示数据集显著增大。

4.2 案例研究：叠衣

我们将行为提示应用于三个真实世界的叠衣任务（图 1）。人类能够通过向 BPP 提供一个单一的 iPhUMI 演示，命令双臂机器人完成训练集中的折叠任务。然而，我们观察到，在这种低任务多样性设置下，与语言条件相比，BPP 表现出较弱的任务条件。详情见附录 § A。

5 局限性

在许多情况下，目标图像或语言可能足以实现所需的测试时自适应水平，而无需收集完整的行为提示。因此，我们设想扩展 BPP 以灵活使用不同的任务描述符。另一个局限性是实现测试时自适应所需的大量训练数据多样性。对于桌面操作，我们尚未发现证据表明 BPP 能够在给定单个行为提示的情况下适应全新的动作原语。我们还发现，在训练任务多样性较低的设置中，与语言条件相比，任务条件较弱。在我们的实验中，行为提示发生在与部署不同的物体配置下，但仍处于相同的环境中；未来工作可以研究提示与执行环境存在显著差异时的性能。未来工作还可以研究用于灵巧手的行为提示硬件接口、利用仿真中的行为提示来提示真实世界执行，以及将行为提示应用于具有基础级预训练的模型。

6 结论

我们希望行为提示能够广泛地提供一种途径，在测试时通过演示（例如折叠衣物的首选方式）向机器人指定人类偏好。我们还设想行为提示作为一种手段，通过目标任务的单次演示，将预训练知识（即大型基础行为提示模型）适应到新环境（例如某人的家）；演示提供了关于目标环境和期望操作策略的丰富信息，从而简化了适应问题。

致谢

我们要感谢 REAL 实验室对项目的持续支持，特别是 Huy Ha 提供的富有洞察力的项目指导，Yihuai Gao 在机器人部署设置方面的帮助，以及 Max Du 在数据收集方面的帮助。关于 iPhUMI 的开发，Yihuai Gao 贡献了 USB 流媒体支持，Xiaomeng Xu 扩展了双手数据收集功能以支持头戴式 iPhone 数据收集。我们还要感谢 Chen Chen、Benoit Landry、Walter Talbott 和 Jian Zhang 的反馈和讨论。这项工作部分得到了 NSF 研究生奖学金、NSF 奖项#2143601、#2037101 和#2132519 以及 Apple 的支持。本文所包含的观点和结论仅代表作者本人，不应被解释为必然代表资助方的官方政策，无论是明示还是暗示。

参考文献

- [1] C. Chi, Z. Xu, C. Pan, E. Cousineau, B. Burchfiel, S. Feng, R. Tedrake, and S. Song. Universal manipulation interface: In-the-wild robot teaching without in-the-wild robots. In *Proceedings of Robotics: Science and Systems (RSS)*, 2024. URL <https://arxiv.org/abs/2402.10329>.
- [2] B. Liu, Y. Zhu, C. Gao, Y. Feng, Q. Liu, Y. Zhu, and P. Stone. LIBERO: Benchmarking knowledge transfer for lifelong robot learning. *Advances in Neural Information Processing Systems*, 36:44776–44791, 2023.
- [3] T. L. Team, J. Barreiros, A. Beaulieu, A. Bhat, R. Cory, E. Cousineau, H. Dai, C.-H. Fang, K. Hashimoto, M. Z. Irshad, M. Itkina, N. Kuppuswamy, K.-H. Lee, K. Liu, D. McConachie, I. McMahon, H. Nishimura, C. Phillips-Grafflin, C. Richter, P. Shah, K. Srinivasan, B. Wulfe, C. Xu, M. Zhang, A. Alspach, M. Angeles, K. Arora, V. C. Guizilini, A. Castro, D. Chen, T.-S. Chu, S. Creasey, S. Curtis, R. Denitto, E. Dixon, E. Dusel, M. Ferreira, A. Goncalves, G. Gould, D. Guoy, S. Gupta, X. Han, K. Hatch, B. Hathaway, A. Henry, H. Hochsztein, P. Horgan, S. Iwase, D. Jackson, S. Karamcheti, S. Keh, J. Masterjohn, J. Mercat, P. Miller, P. Mitiguy, T. Nguyen, J. Nimmer, Y. Noguchi, R. Ong, A. Onol, O. Pfannenstiehl, R. Poyner, L. P. M. Rocha, G. Richardson, C. Rodriguez, D. Seale, M. Sherman, M. Smith-Jones, D. Tago, P. Tokmakov, M. Tran, B. V. Hoorick, I. Vasiljevic, S. Zakharov, M. Zolotas, R. Ambrus, K. Fetzner-Borelli, B. Burchfiel, H. Kress-Gazit, S. Feng, S. Ford, and R. Tedrake. A careful examination of large behavior models for multitask dexterous manipulation. *Science Robotics*, 11(113):eaea6201, 2026. doi:10.1126/scirobotics.aea6201.
- [4] E. Jang, A. Irpan, M. Khansari, D. Kappler, F. Ebert, C. Lynch, S. Levine, and C. Finn. BC-Z: Zero-shot task generalization with robotic imitation learning. In *5th Annual Conference on Robot Learning*, 2021. URL <https://openreview.net/forum?id=8kbp23tSGYv>.
- [5] P. Intelligence, K. Black, N. Brown, J. Darpinian, K. Dhabalia, D. Driess, A. Esmail, M. Equi, C. Finn, N. Fusai, M. Y. Galliker, D. Ghosh, L. Groom, K. Hausman, B. Ichter, S. Jakubczak, T. Jones, L. Ke, D. LeBlanc, S. Levine, A. Li-Bell, M. Mothukuri, S. Nair, K. Pertsch, A. Z. Ren, L. X. Shi, L. Smith, J. T. Springenberg, K. Stachowicz, J. Tanner, Q. Vuong, H. Walke, A. Walling, H. Wang, L. Yu, and U. Zhilinsky. $\pi_{0.5}$: a vision-language-action model with open-world generalization. In *9th Annual Conference on Robot Learning*, 2025.
- [6] Octo Model Team, D. Ghosh, H. Walke, K. Pertsch, K. Black, O. Mees, S. Dasari, J. Hejna, C. Xu, J. Luo, T. Kreiman, Y. Tan, L. Y. Chen, P. Sanketi, Q. Vuong, T. Xiao, D. Sadigh, C. Finn, and S. Levine. Octo: An open-source generalist robot policy. In *Proceedings of Robotics: Science and Systems*, Delft, Netherlands, 2024.
- [7] M. J. Kim, C. Finn, and P. Liang. Fine-tuning vision-language-action models: Optimizing speed and success. *arXiv preprint arXiv:2502.19645*, 2025.

- [8] M. Kim, K. Pertsch, S. Karamcheti, T. Xiao, A. Balakrishna, S. Nair, R. Rafailov, E. Foster, G. Lam, P. Sanketi, Q. Vuong, T. Kollar, B. Burchfiel, R. Tedrake, D. Sadigh, S. Levine, P. Liang, and C. Finn. OpenVLA: An open-source vision-language-action model. *arXiv preprint arXiv:2406.09246*, 2024.
- [9] B. Zitkovich, T. Yu, S. Xu, P. Xu, T. Xiao, F. Xia, J. Wu, P. Wohlhart, S. Welker, A. Wahid, Q. Vuong, V. Vanhoucke, H. Tran, R. Soricut, A. Singh, J. Singh, P. Sermanet, P. R. Sanketi, G. Salazar, M. S. Ryoo, K. Reymann, K. Rao, K. Pertsch, I. Mordatch, H. Michalewski, Y. Lu, S. Levine, L. Lee, T.-W. E. Lee, I. Leal, Y. Kuang, D. Kalashnikov, R. Julian, N. J. Joshi, A. Irpan, B. Ichter, J. Hsu, A. Herzog, K. Hausman, K. Gopalakrishnan, C. Fu, P. Florence, C. Finn, K. A. Dubey, D. Driess, T. Ding, K. M. Choromanski, X. Chen, Y. Chebotar, J. Carbajal, N. Brown, A. Brohan, M. G. Arenas, and K. Han. RT-2: Vision-language-action models transfer web knowledge to robotic control. In J. Tan, M. Toussaint, and K. Darvish, editors, *Proceedings of The 7th Conference on Robot Learning*, volume 229 of *Proceedings of Machine Learning Research*, pages 2165–2183. PMLR, 06–09 Nov 2023. URL <https://proceedings.mlr.press/v229/zitkovich23a.html>.
- [10] K. Black, N. Brown, D. Driess, A. Esmail, M. Equi, C. Finn, N. Fusai, L. Groom, K. Hausman, B. Ichter, S. Jakubczak, T. Jones, L. Ke, S. Levine, A. Li-Bell, M. Mothukuri, S. Nair, K. Pertsch, L. X. Shi, J. Tanner, Q. Vuong, A. Walling, H. Wang, and U. Zhilinsky. π_0 : A vision-language-action flow model for general robot control. *arXiv preprint arXiv:2410.24164*, 2024.
- [11] C. Finn, T. Yu, T. Zhang, P. Abbeel, and S. Levine. One-shot visual imitation learning via meta-learning. In *Conference on Robot Learning*, pages 357–368. PMLR, 2017.
- [12] S. Calinon. A tutorial on task-parameterized movement learning and retrieval. *Intelligent Service Robotics*, 9(1):1–29, 2016. ISSN 1861-2776. doi:10.1007/s11370-015-0187-9.
- [13] X. Zhang and A. Boularias. One-shot imitation learning with invariance matching for robotic manipulation. *arXiv preprint arXiv:2405.13178*, 2024.
- [14] E. Valassakis, G. Papagiannis, N. D. Palo, and E. Johns. Demonstrate once, imitate immediately (DOME): Learning visual servoing for one-shot imitation learning. In *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, 2022.
- [15] Y. Duan, M. Andrychowicz, B. Stadie, O. Jonathan Ho, J. Schneider, I. Sutskever, P. Abbeel, and W. Zaremba. One-shot imitation learning. *Advances in Neural Information Processing Systems*, 30, 2017.
- [16] G. Papagiannis, N. D. Palo, P. Vitiello, and E. Johns. R+x: Retrieval and execution from everyday human videos. In *IEEE International Conference on Robotics and Automation (ICRA)*, 2025.
- [17] Y. Jiang, A. Gupta, Z. Zhang, G. Wang, Y. Dou, Y. Chen, L. Fei-Fei, A. Anandkumar, Y. Zhu, and L. Fan. VIMA: General robot manipulation with multimodal prompts. In *Fortieth International Conference on Machine Learning*, 2023.
- [18] V. Jain, M. Attarian, N. J. Joshi, A. Wahid, D. Driess, Q. Vuong, P. R. Sanketi, P. Sermanet, S. Welker, C. Chan, I. Gilitschenski, Y. Bisk, and D. Dwibedi. Vid2Robot: End-to-end video-conditioned policy learning with cross-attention transformers. In *Proceedings of (RSS) Robotics Science and Systems*. Proceedings of Robotics: Science and Systems, May 2024.
- [19] Z. Mandi, F. Liu, K. Lee, and P. Abbeel. Towards more generalizable one-shot visual imitation learning. In *2022 International Conference on Robotics and Automation (ICRA)*, pages 2434–2444, 2022. doi:10.1109/ICRA46639.2022.9812450.

- [20] M. Xu, Y. Shen, S. Zhang, Y. Lu, D. Zhao, B. J. Tenenbaum, and C. Gan. Prompting decision transformer for few-shot policy generalization. In *Thirty-ninth International Conference on Machine Learning*, 2022.
- [21] R. Shah, S. Liu, Q. Wang, Z. Jiang, S. Kumar, M. Seo, R. Martín-Martín, and Y. Zhu. MimicDroid: In-context learning for humanoid manipulation from human play videos. *2026 IEEE International Conference on Robotics and Automation (ICRA)*, 2026.
- [22] K. Dreczkowski, P. Vitiello, V. Vosylius, and E. Johns. Learning a thousand tasks in a day. *Science Robotics*, 10(108):eadv7594, 2025. doi:10.1126/scirobotics.adv7594. URL <https://www.science.org/doi/abs/10.1126/scirobotics.adv7594>.
- [23] L. Fu, H. Huang, G. Datta, L. Y. Chen, W. C.-H. Panitch, F. Liu, H. Li, and K. Goldberg. In-context imitation learning via next-token prediction. *International Conference on Robotics and Automation (ICRA)*, 2025. URL <https://arxiv.org/abs/2408.15980>.
- [24] E. Perez, F. Strub, H. De Vries, V. Dumoulin, and A. Courville. FiLM: Visual reasoning with a general conditioning layer. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 32, 2018.
- [25] C. Chi, S. Feng, Y. Du, Z. Xu, E. Cousineau, B. Burchfiel, and S. Song. Diffusion Policy: Visuomotor policy learning via action diffusion. In *Proceedings of Robotics: Science and Systems (RSS)*, 2023.
- [26] S. Fei, S. Wang, J. Shi, Z. Dai, J. Cai, P. Qian, L. Ji, X. He, S. Zhang, Z. Fei, J. Fu, J. Gong, and X. Qiu. LIBERO-Plus: In-depth robustness analysis of vision-language-action models. *arXiv preprint arXiv:2510.13626*, 2025.
- [27] X. Zhou, Y. Xu, G. Tie, Y. Chen, G. Zhang, D. Chu, P. Zhou, and L. Sun. LIBERO-PRO: Towards robust and fair evaluation of vision-language-action models beyond memorization. *arXiv preprint arXiv:2510.03827*, 2025.
- [28] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, W. Chen, et al. LoRA: Low-rank adaptation of large language models. *ICLR*, 1(2):3, 2022.
- [29] G. Xiao, Y. Tian, B. Chen, S. Han, and M. Lewis. Efficient streaming language models with attention sinks. In *International Conference on Learning Representations*, volume 2024, pages 21875–21895, 2024.
- [30] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, and N. Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. *ICLR*, 2021.
- [31] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, et al. Learning transferable visual models from natural language supervision. In *International Conference on Machine Learning*, pages 8748–8763. PMLR, 2021.
- [32] M. Torne, A. Tang, Y. Liu, and C. Finn. Learning long-context diffusion policies via past-token prediction. In *9th Annual Conference on Robot Learning*, 2025.
- [33] J. Fang, W. Chen, H. Xue, F. Zhou, T. Le, Y. Wang, Y. Zhang, J. Lv, C. Wen, and C. Lu. RoboPocket: Improve robot policies instantly with your phone. *arXiv preprint arXiv:2603.05504*, 2026. URL <https://arxiv.org/abs/2603.05504>.
- [34] H. Etukuru, N. Naka, Z. Hu, S. Lee, J. Mehu, A. Edsinger, C. Paxton, S. Chintala, L. Pinto, and N. M. M. Shafiullah. Robot utility models: General policies for zero-shot deployment in new environments. In *2025 IEEE International Conference on Robotics and Automation (ICRA)*, pages 8275–8283. IEEE, 2025.

- [35] X. Xu, J. Park, H. Zhang, E. Cousineau, A. Bhat, J. Barreiros, D. Wang, J. Bohg, and S. Song. HoMMI: Learning whole-body mobile manipulation from human demonstrations. *arXiv preprint arXiv:2603.03243*, 2026.
- [36] Z. Liu, C. Chi, E. Cousineau, N. Kuppuswamy, B. Burchfiel, and S. Song. Maniwav: Learning robot manipulation from in-the-wild audio-visual data. In *Conference on Robot Learning*, pages 947–962. PMLR, 2025.
- [37] Y. Gao, J. Liu, S. Li, and S. Song. Gated memory policy. *arXiv preprint arXiv:2604.18933*, 2026. URL <https://arxiv.org/abs/2604.18933>.

附录

A 案例研究：衣物折叠

行为提示是一种比固定长度语言嵌入复杂得多的任务表示，我们想了解当任务多样性较低时，这种复杂性是否会带来挑战。为了研究这一点，我们使用双手 iPhUMI 收集了三个毛衣折叠任务（图 1）进行案例研究：折叠左臂（仅需要左机器人手臂）、折叠右臂（仅需要右机器人手臂）以及从底部向上折叠（需要双臂分别抓住毛衣底部，然后共同将其折叠到顶部）。所有任务开始时毛衣完全展开，因此策略必须利用任务描述符来识别正确的任务。我们将行为提示（策略必须从大量的时间和空间提示信息中识别任务）与 CLIP [31] 语言条件（微调后的语言编码简单地识别任务）进行比较。

我们在表 1 中展示了结果。我们发现语言模型以高成功率完成了所有任务，而行为原语策略（BPP）偶尔会完成与指令不同的任务（图 7）。在本实验中，空间和时间提示信息并未进一步明确这些任务，反而引入了复杂性和变化（即提示在持续时间和物体的空间配置上有所不同），我们推测这导致 BPP 在训练任务多样性较低时任务条件化能力较弱。

训练任务多样性。这种间接性可能使 BPP 对训练数据中的虚假任务线索（例如，特定任务更常出现的背景变化）过拟合敏感。

Task	Result	Language	BPP (Ours)
<i>Fold left arm</i>	Success	24 (96%)	19 (76%)
	Failure (dropped left sleeve)	1 (4%)	4 (16%)
	Failure (did <i>fold right arm</i>)		1 (4%)
	Failure (did <i>fold bottom up</i>)		1 (4%)
<i>Fold right arm</i>	Success	25 (100%)	25 (100%)
<i>Fold bottom up</i>	Success	25 (100%)	15 (60%)
	Failure (did <i>fold right arm</i>)		6 (24%)
	Failure (right: grabs bottom ✓, left: <i>fold left arm</i> ✗)		4 (16%)

表 1：叠衣结果。我们观察到与语言条件化相比，BPP 的成功率较低，因为策略偶尔会完成错误的任务。成功率为单一种子下每个任务 25 次展开的结果。语言基线详见 § F。使用 iPhUMI，我们收集了每个任务 ~ 150 个完整演示和 ~ 1000 个总错误纠正演示。我们为每个任务额外收集了五个行为提示，因此这些评估针对的是已见任务的未见提示。自下而上折叠任务先用右臂抓住底部，再用左臂抓住底部；我们经常观察到 BPP 正确用右臂抓住底部，但左臂却决定折叠左袖而不是也抓住底部的失败情况。

虽然 BPP 在这种低任务多样性情况下面临挑战，但我们设想行为提示在训练数据涵盖多种服装的多种折叠风格时具有显著优势。特别是，行为提示捕捉了折叠过程中的时间步骤以及空间交互点，这两者在高任务多样性设置中都能明确并指导期望的执行。这些信息还可以帮助对未见服装的视觉适应和对未见折叠顺序的时间适应。实际上，用户可能也会发现通过单个演示来描述他们期望的折叠偏好比通过语言更自然。




图 7：BPP 在低任务多样性下表现出弱任务条件化。绿色表示期望动作，红色表示实际执行。

B DrawAnything-Real 实现

B.1 脚本化数据生成

对于我们的真实绘画任务，我们在通过 iPhUMI 和脚本策略收集的数据混合上进行训练。具体来说，我们使用 iPhUMI 从人类收集了 200 个任务，每个任务 5 个演示。我们还使用脚本策略收集了 800 个任务，每个任务 6 个演示。脚本策略将 DrawAnything-Sim 中使用的程序生成绘图映射到 6 自由度机器人末端执行器空间中的开环命令。在训练期间使用 iPhUMI 数据使策略能够在测试时很好地处理来自人类的 iPhUMI 提示，而脚本策略有助于达到在测试时适应新任务所需的任务多样性。

对于每个脚本演示，人类操作员将绘图画布以随机位置和方向放置在白板上。我们通过在 iPhone 主后置摄像头的 RGB 图像上运行分割模型来定位绘图画布上的四个红色角标记，从而在相机坐标系中产生 2D 关键点，我们使用这些关键点来估计画布姿态。然后，我们使用固定的相机到机器人外参标定将得到的姿态转换到机器人基坐标系中。机器人首先移动到白板前的随机姿态，开始记录，然后移动到估计的画布姿态，并将其末端执行器方向与画布对齐。它执行任务的脚本化绘图轨迹，最后返回到随机姿态。这在任务和演示中重复进行。

B.2 评估程序

BPP 在一些未见过的绘图上的定性结果如图 8 所示。用于评估的训练和测试任务如图 9 所示。对于每次评估试验，绘图画布以随机位置和方向放置在白板上。我们采样一个演示来定义一个匹配的条件对：完整演示用作提示策略的行为提示，从同一演示中提取的相应目标图像用于目标图像策略。

为了控制初始条件，我们执行提示策略，将机器人和环境重置为相同的初始状态，然后使用匹配的目标图像执行目标图像策略。我们在将画布移动到新的随机位置并采样新的提示/目标图像对后重复此过程。

对于训练任务的评估，条件对从四个程序性训练任务中收集的六组演示中采样。对于未见过的测试任务的评估，条件对从为六个未见过的评估任务中的每一个收集的三组 iPhUMI 演示中采样。每个任务进行十次评估展开。




图 8: BPP 在 DrawAnything-Real 中未见任务上的定性结果。我们发现，给定单个 iPhUMI 演示，BPP 能够重建未见过的绘图。我们展示了成功的绘图（绿色）和一个失败案例（红色）。




图 9: DrawAnything-Real 评估任务及机器人执行的典型示例。绿色：策略执行的绘图。红色：作为参考叠加渲染的目标图像输入。我们观察到，目标图像能够大致匹配训练绘图的结构，但无法复制未见过的绘图。BPP 能够在给定单个演示的情况下重建训练和未见过的绘图。

B.3 定性比较：目标图像与行为提示

图 9 展示了在训练和未见绘图任务上比较 BPP 与目标图像的典型示例。在 DrawAnything-Sim 中，我们观察到目标图像在训练任务上表现良好（图 4a）。然而，在 DrawAnything-Real 中，我们发现目标图像在训练任务上定量表现不佳（图 4b）。然而，对图 9a 的定性检查表明存在一致的失败模式：策略通常产生预期形状的可识别再现（或部分再现），但存在空间错位或局部几何误差，导致较大的 Chamfer 距离。

对于未见过的任务，目标图像经常退化为近似随机的笔画，与目标形状不相似，而 BPP 产生与演示行为一致的连贯绘图。有趣的是，我们发现目标图像在训练和未见任务之间的定量错误率相似（图 4b）。然而，我们看到与训练任务不同，目标图像在这些测试任务上的定性保真度较差（图 9b）。我们认为这是因为目标图像在测试任务上产生的难以理解的绘图可以通过大致覆盖目标绘图区域而不重现预期结构来达到中等水平的 Chamfer 误差。

C DrawAnything-Sim 任务

我们可视化 DrawAnything-Sim 的训练（图 10）和评估数据集（图 11）。




图 10: DrawAnything-Sim 训练任务。我们展示了 2000 个程序生成任务中的 100 个子集（每个任务有 5 次演示），这些任务由 1 到 6 个部件组合而成。部件包括直线、贝塞尔曲线、部分/完整椭圆以及自由空间（抬笔）移动。每个部件的参数（如起点/终点位置、贝塞尔控制点、椭圆比例、顺时针/逆时针方向等）均随机采样。以指定概率，部件会连接回先前部件的起点/终点位置。每次演示包含不同的白板旋转（从 $-\frac{\pi}{4}$ 到 $\frac{\pi}{4}$ ），速度各异，并在轨迹中加入了噪声。




图 11: DrawAnything-Sim 评估任务。我们手工收集了 50 个训练中未出现的评估任务，每个任务有 5 次演示，白板旋转角度各不相同。任务复杂度和持续时间各异。

D 原始 LIBERO 数据集上的结果

我们报告在原始 LIBERO[2] 数据集上的结果。原始 LIBERO 任务可由语言充分描述，且原始基准划分未评估对未见任务的测试时自适应。正如预期，我们发现使用行为提示可获得与语言条件扩散策略相似的性能。我们通过实验发现，微调 CLIP 语言编码器相比某些先前扩散策略 LIBERO 评估中使用的冻结语言嵌入 [8]，能显著提升性能。现代策略也已开始使原始 LIBERO 基准的性能趋于饱和 [10, 7]，这凸显了 LIBERO-Gen 的重要性，该数据集扩展了原始数据，用于评估对未见任务的测试时自适应。

Split	Language Diffusion Policy	Behavior Prompting Policy (Ours)	$\pi_{0.5}$
LIBERO Spatial	97.80 $\pm$ 0.71	97.40 $\pm$ 1.02	97.8
LIBERO Object	97.80 $\pm$ 0.49	98.93 $\pm$ 0.52	97.4
LIBERO Goal	95.60 $\pm$ 1.07	98.33 $\pm$ 0.38	97.8
LIBERO 10	93.73 $\pm$ 2.07	95.27 $\pm$ 0.66	95.6
Average	96.23 $\pm$ 0.55	97.48 $\pm$ 0.33	97.15

表 2：原始 LIBERO 数据集结果。模型在原始 LIBERO[2] 数据集上按套件划分的成功率（%），基于 3 个种子（均值 $\pm$ 标准差）。语言细节见 § F。我们使用 openpi 对 $\pi_{0.5}$ [5] 进行了 30K 步 LoRA[28] 微调，并报告一个种子的结果。 $\pi_{0.5}$ 训练在微调混合中不包含 LIBERO-90，而其他展示的模型在训练数据中包含 LIBERO-90 划分。由于这一差异，我们将 $\pi_{0.5}$ 结果放在单独一列中。对于列出的三种策略架构，我们为每个种子在所有列出的 LIBERO 划分上训练一个检查点，而不是为每个划分单独训练和评估检查点。

E LIBERO-Gen 实现细节

LIBERO-Gen 程序化地生成新的任务定义，包括环境定义和执行步骤（§ E.1）。它还为此任务生成相应的演示（§ E.2）。随后，我们讨论 LIBERO-Gen 组合（§ E.3）和 LIBERO-Gen 链（§ E.4）的细节，这两个基准是利用该工具创建的。

E.1 程序化任务生成

LIBERO 数据集中的 130 个原始任务使用 BDDL 定义，该语言同时定义了环境和预期的机器人任务。环境由基础场景、场景中存在的物体以及这些物体的初始位置定义。任务通过一组谓词定义，这些谓词指定了场景中物体期望的最终状态。LIBERO-Gen 获取这些 BDDL 文件，并枚举可能的初始物体位置和期望的最终物体状态，以生成新的任务定义。用户指定希望发生的一组程序化操作，以生成所需的任务变化集，例如：1) 生成目标相同但盘子初始化在所有可能起始位置的环境，或 2) 生成初始物体配置保持不变但目标状态为奶油奶酪可放置的所有位置的环境。LIBERO-Gen 还支持生成链式任务，其中目标状态由多个顺序应用的动作原语组成（例如，打开炉子，然后将碗放在炉子上）。

在实践中，我们为每个物体手动定义一组有效的操作符（例如，碗可以被抓取，或者你可以将物体放入碗中）。我们还从现有 LIBERO 任务的基础环境集开始，在其上应用变化。这样做通常会创建一个庞大的任务组合空间，这些任务可能 1) 超出针对特定科学实验所需的任务集，或 2) 需要划分为训练集和测试集。我们通过使用视图来解决这个问题，视图包含过滤器，用于选择生成任务的所需部分放入训练或测试划分中。

E.2 程序化演示生成

鉴于程序化生成的任务定义，我们需要为这些任务程序化生成演示数据。我们通过一个脚本化策略来实现，该策略利用地面模拟器物体状态以及 130 个原始 LIBERO 任务的现有演示数据。从现有的遥操作数据中，我们为每个目标物体提取物体相对抓取姿态。许多任务还涉及回放一部分遥操作数据，然后切换到脚本化策略以完成任务的新部分。我们在多个环节引入变化，以模拟遥操作演示中存在的差异：抓取位置、放置位置、每个动作原语往返过程中的中间姿态，以及初始机器人和物体状态。我们使用 LIBERO 中现有的谓词检查机制来验证每个演示的成功。对于链式任务，BDDL 并未编码每个动作原语的顺序，因此我们在单独的配置文件中编码所需的顺序。

E.3 LIBERO-Gen 组合测试任务

这里我们扩展 § 4 中关于 LIBERO-Gen 组合的讨论。我们修改 LIBERO 空间环境，增加额外的起始碗位置，如图 12 所示。




图 12: LIBERO-Gen 组合的初始环境。每个环境中都有两个相同的碗。任务涉及将指定的碗移动到指定的目标位置。

从每个起始初始化出发，我们生成所有可能的碗拾取位置和放置位置的组合空间，以生成任务分布。我们保留十个任务（拾取-放置位置的组合）作为评估任务。我们在下面记录每个未见过的任务，包括具有相同拾取位置的训练任务数量和具有相同放置位置的训练任务数量；这表明拾取和放置位置在训练期间分别被见过，但从未联合出现过。该实验设计评估策略在测试时适应未见指令的能力，而不评估未见过的动作原语。

LIBERO-Gen 组合的未见训练任务及相关训练任务：

```
Unseen: Pick the bowl from table center and place it on the cookies box
Training: Same pick (bowl table center), different place [9 tasks]
Training: Different pick, same place (bowl on the cookies box) [8 tasks]

Unseen: Pick the bowl in the top layer of the wooden cabinet and place it on the plate
Training: Same pick (bowl wooden cabinet top), different place [7 tasks]
Training: Different pick, same place (bowl on the plate) [9 tasks]

Unseen: Pick the bowl next to the cookies box and place it on the bowl next to the ramekin
Training: Same pick (bowl next to box), different place [9 tasks]
Training: Different pick, same place (bowl on the bowl next to the ramekin) [4 tasks]

Unseen: Pick the bowl next to the plate and place it on the stove
Training: Same pick (bowl next to plate), different place [9 tasks]
Training: Different pick, same place (bowl on the stove) [9 tasks]
```

Unseen: Pick the bowl on the cookies box and place it on the bowl on the wooden cabinet
 Training: Same pick (bowl cookies), different place [9 tasks]
 Training: Different pick, same place (bowl on the bowl on the wooden cabinet) [8 tasks]

Unseen: Pick the bowl on the cookies box and place it on the wooden cabinet
 Training: Same pick (bowl cookies), different place [9 tasks]
 Training: Different pick, same place (bowl on the wooden cabinet) [8 tasks]

Unseen: Pick the bowl on the plate and place it on the bowl on the table center
 Training: Same pick (bowl plate), different place [9 tasks]
 Training: Different pick, same place (bowl on the bowl on the table center) [4 tasks]

Unseen: Pick the bowl on the plate and place it on the table center
 Training: Same pick (bowl plate), different place [9 tasks]
 Training: Different pick, same place (bowl on the table center) [7 tasks]

Unseen: Pick the bowl on the stove and place it on the ramekin
 Training: Same pick (bowl stove), different place [9 tasks]
 Training: Different pick, same place (bowl on the ramekin) [9 tasks]

Unseen: Pick the bowl on the wooden cabinet and place it between the plate and the ramekin
 Training: Same pick (bowl wooden cabinet top side), different place [8 tasks]
 Training: Different pick, same place (bowl between the plate and the ramekin) [9 tasks]

E.4 LIBERO-Gen 链式测试任务

这里我们扩展 § 4 中关于 LIBERO-Gen 链式的讨论。在 LIBERO-Gen 链式中，我们有一个环境初始化，并枚举所有两步序列的集合，其中我们按顺序链接两个动作原语（见图 13）。




图 13: LIBERO-Gen Chain 的初始环境。本实验中所有两步链式任务均从单一的第一步状态（蓝色）开始。我们还包含从第一步状态（蓝色）开始的一步动作，以及假设一个动作原语已完成时开始的第二步动作（红色）。无第二步的消融实验排除了从第二步初始化（红色）开始的单步任务。

在测试时，我们评估对由已知原语组成的未见顺序链的适应能力。目的不是在测试时适应一个训练期间未见过的全新动作原语，而是适应这些原语的新序列。该设置评估模型遵循先前未见指令的能力。此处我们列举所有十个未见评估任务，并为每个任务包含模型在训练期间见过的相似任务计数。简言之，该列表表明每个未见任务的原语在训练期间已被单独见过，但从未按顺序链接。我们移除训练混合中第二步任务的消融实验，移除了链中第二步任务在完全相同的环境初始化下已被见过的保证（见图 13）。

LIBERO-Gen Chain 的未见训练任务及相关训练任务：

```
Unseen: [1st] Open the middle layer of the drawer and then [2nd] put the cream cheese on the stove
Training: similar chain (same 1st, different 2nd) [3 tasks]:
- Open the middle layer of the drawer and put the cream cheese inside
- Open the middle layer of the drawer and then put the cream cheese in front of the stove
- Open the middle layer of the drawer and then put the cream cheese on the top of the drawer
Training: similar single-step (2nd step match with wooden cabinet middle open): not present
Training: similar single-step (2nd step match with diff background object config): present

Unseen: [1st] Open the top layer of the drawer and then [2nd] put the wine bottle on the top of the drawer
Training: similar chain (same 1st, different 2nd) [5 tasks]:
- Open the top layer of the drawer and put the wine bottle inside
- Open the top layer of the drawer and then put the wine bottle in front of the stove
- Open the top layer of the drawer and then put the wine bottle on the bowl
- Open the top layer of the drawer and then put the wine bottle on the cream cheese
- Open the top layer of the drawer and then put the wine bottle on the stove
Training: similar single-step (2nd step match with wooden cabinet top open): present
Training: similar single-step (2nd step match with diff background object config): present

Unseen: [1st] Push the plate to the front of the stove and then [2nd] put the bowl on the plate
Training: similar chain (same 1st, different 2nd) [3 tasks]:
- Push the plate to the front of the stove and then put the bowl on the cream cheese
- Push the plate to the front of the stove and then put the bowl on the stove
- Push the plate to the front of the stove and then put the bowl on the top of the drawer
Training: similar single-step (2nd step match with plate on stove front): present
Training: similar single-step (2nd step match with diff background object config): present

Unseen: [1st] Put the bowl on the plate and then [2nd] put the cream cheese on the bowl
Training: similar chain (same 1st, different 2nd) [4 tasks]:
- Put the bowl on the plate and then put the cream cheese in front of the stove
- Put the bowl on the plate and then put the cream cheese on the bowl region
- Put the bowl on the plate and then put the cream cheese on the stove
- Put the bowl on the plate and then put the cream cheese on the top of the drawer
Training: similar single-step (2nd step match with bowl on plate): present
Training: similar single-step (2nd step match with diff background object config): present

Unseen: [1st] Put the bowl on the top of the drawer and then [2nd] put the cream cheese on the plate
Training: similar chain (same 1st, different 2nd) [4 tasks]:
- Put the bowl on the top of the drawer and then put the cream cheese in front of the stove
- Put the bowl on the top of the drawer and then put the cream cheese on the bowl
- Put the bowl on the top of the drawer and then put the cream cheese on the bowl region
- Put the bowl on the top of the drawer and then put the cream cheese on the stove
Training: similar single-step (2nd step match with bowl on wooden cabinet top side): present
Training: similar single-step (2nd step match with diff background object config): present

Unseen: [1st] Put the cream cheese on the plate and then [2nd] put the bowl on the cream cheese
Training: similar chain (same 1st, different 2nd) [4 tasks]:
- Put the cream cheese on the plate and then put the bowl in front of the stove
- Put the cream cheese on the plate and then put the bowl on the cream cheese region
- Put the cream cheese on the plate and then put the bowl on the stove
- Put the cream cheese on the plate and then put the bowl on the top of the drawer
Training: similar single-step (2nd step match with cream cheese on plate): present
Training: similar single-step (2nd step match with diff background object config): present

Unseen: [1st] Put the cream cheese on the top of the drawer and then [2nd] put the wine bottle on the bowl
Training: similar chain (same 1st, different 2nd) [5 tasks]:
- Put the cream cheese on the top of the drawer and then put the wine bottle in front of the stove
- Put the cream cheese on the top of the drawer and then put the wine bottle on the cream cheese
- Put the cream cheese on the top of the drawer and then put the wine bottle on the cream cheese region
- Put the cream cheese on the top of the drawer and then put the wine bottle on the plate
- Put the cream cheese on the top of the drawer and then put the wine bottle on the stove
Training: similar single-step (2nd step match with cream cheese on wooden cabinet top side): present
Training: similar single-step (2nd step match with diff background object config): present

Unseen: [1st] Put the wine bottle in front of the stove and then [2nd] put the bowl on the stove
Training: similar chain (same 1st, different 2nd) [3 tasks]:
- Put the wine bottle in front of the stove and then put the bowl on the plate
```

- Put the wine bottle in front of the stove and then put the bowl on the wine bottle region
- Put the wine bottle in front of the stove and then put the bowl on the top of the drawer

Training: similar single-step (2nd step match with wine bottle on stove front): present
 Training: similar single-step (2nd step match with diff background object config): present

Unseen: [1st] Put the wine bottle on the rack and then [2nd] put the bowl on the top of the drawer
 Training: similar chain (same 1st, different 2nd) [5 tasks]:

- Put the wine bottle on the rack and then put the bowl in front of the stove
- Put the wine bottle on the rack and then put the bowl on the cream cheese
- Put the wine bottle on the rack and then put the bowl on the plate
- Put the wine bottle on the rack and then put the bowl on the stove
- Put the wine bottle on the rack and then put the bowl on the wine bottle region

Training: similar single-step (2nd step match with wine bottle on wine rack top): not present
 Training: similar single-step (2nd step match with diff background object config): present

Unseen: [1st] Turn on the stove and then [2nd] put the bowl on the stove
 Training: similar chain (same 1st, different 2nd) [4 tasks]:

- Turn on the stove and then put the bowl in front of the stove
- Turn on the stove and then put the bowl on the cream cheese
- Turn on the stove and then put the bowl on the plate
- Turn on the stove and then put the bowl on the top of the drawer

Training: similar single-step (2nd step match with flat stove turned on): present
 Training: similar single-step (2nd step match with diff background object config): present

F 基线细节

我们的语言与目标图像基线模型遵循 Chi 等人 [25] 的扩散 CNN U-Net 架构，该架构也与 BPP 动作解码器的架构一致。BPP 与基线之间的区别在于观测编码；语言基线使用微调的 CLIP[31] 语言编码器替代提示编码器，目标图像基线与相应图像输入共享微调的 CLIP 视觉编码器。

LIBERO:

- 语言基线使用微调的 CLIP 编码，我们发现其性能显著优于冻结的语言嵌入。对于无法使用初始环境状态推断任务的特定 LIBERO 划分（如 LIBERO Goal），我们观察到冻结语言编码通常会导致策略完成错误的任务。
- 目标图像（Goal-Image）与第三人称相机使用的微调视觉编码器相同。目标图像是第三人称相机演示的最后一帧。在原始 LIBERO 数据集中，使用目标图像对某些任务存在歧义，因此我们仅对 LIBERO-Gen Combination 和 LIBERO-Gen Chain 提供该基线的结果，这些数据集不包含目标图像对最终状态有歧义的任务。对于 LIBERO-Gen Chain，目标图像存在歧义，因为它们不指示两个链式操作应发生的顺序。
- $\pi_{0.5}$ 使用 LoRA[28] 进行微调。对于训练 $\pi_{0.5}$ ，我们遵循 [8] 中的 LIBERO 预处理步骤，以更高分辨率重新生成我们的 LIBERO-Gen 数据集，但不过滤无操作步骤。我们为 LIBERO-Gen 实验微调 100K 步（图 4），为原始 LIBERO 数据集上的结果微调 30K 步（表 2）。

DrawAnything-Sim:

- 目标图像与主图像编码器共享微调后的视觉编码器。
- ICRT 扩展了 Fu 等人 [23] 提供的实现，在令牌输入级别支持动作分块；这意味着 1) 每个输入动作令牌包含 N 个连续动作步骤，而不是单个步骤；2) 我们不再在每个步骤后编码观察令牌，而是仅在每 N 个动作步骤后编码。此外，在测试时，我们仅在上下文中提供一个完整的演示。这两项更改使得与 BPP 进行更直接的比较成为可能，BPP 在提示中将动作分块，并在部署期间使用单个行为提示。

DrawAnything-Real:

- 目标图像与现实中 iPhone 主 RGB 相机共享视觉编码器。由于移动的腕部相机和夹爪遮挡，演示的某些帧中绘图并未完全可见。因此，为确保公平比较，我们从演示结束向后搜索，选择完全显示绘图区域的第一帧作为目标图像。

衣物折叠:

- 语言采用微调后的 CLIP 语言编码。

G BPP 与 ICRT 的架构比较

模型架构。 ICRT [23] 是一种先验行为提示架构，我们将其作为基线。ICRT 是因果变换器解码器，而 BPP 具有独立的提示理解与动作生成模块（详见 § 3.3）。BPP 利用交叉注意力对提示内容进行推理，而 ICRT 利用因果自注意力。此外，BPP 利用动作扩散 [25]，而 ICRT 使用 L1 动作损失。

训练。 在每一步训练中，ICRT 采样一系列提示和完整轨迹，沿时间维度拼接成单一序列以填充变换器上下文长度。损失通过使用教师强制预测轨迹序列每一步的动作损失来计算。相比之下，对于 BPP 的每一步训练，我们采样单个行为提示以及从多个演示中随机采样的一批观测-动作对。动作损失针对这些随机采样的观测-动作对计算。两种模型每个批次都使用来自单一任务的提示和轨迹。在实践中，由于跨多个 GPU 的 DDP 训练或梯度累积的使用，每次梯度更新将考虑多个任务的损失。

推理。 BPP 具有固定长度的历史，这在其他视觉运动策略中很常见 [25]。相比之下，ICRT 在模型上下文中保留完整的轨迹历史，这可能在部署期间由于训练中的虚假相关性而容易受到分布外问题的影响 [32]。这也意味着 ICRT 只能滚动固定时长，之后就会达到变换器上下文极限。

BPP 中提示理解与动作生成的分离模块使我们能够在每次展开中仅预处理一次提示，每次推理调用时利用提示编码器提取相关提示信息，并执行多步动作去噪而无需每次引用整个提示。另一方面，ICRT 的每次前向传播都会引用整个提示以及自展开开始以来的整个观测-动作历史，但利用 KV 缓存来减少因果注意力计算。

H BPP 训练细节

Benchmark	Duration (hrs)	GPUs
LIBERO-Gen Combination	28	4× NVIDIA RTX A6000
LIBERO-Gen Chain	34	4× NVIDIA L40S
DrawAnything-Sim	27	4× NVIDIA L40S
DrawAnything-Real	42	4× NVIDIA L40S
Laundry Folding	24	4× NVIDIA L40S

表 3：为每个训练基准训练 BPP 所需的计算资源。仿真

experiments include time for intermediary and final rollout evaluations. We train using DDP.

Layers	Hidden size D	MLP size	Heads	Params
6	768	3072	8	57M

表 4：BPP 提示编码器架构（变换器解码器）。

Structure	Step emb dim	Down dims	Kernel	Params
U-Net	128	[256, 512, 1024]	5	151M

表 5：动作解码器模型架构细节。我们使用 CNN U-Net 动作扩散

architecture from Chi et al. [25]. BPP, Language, and Goal-Image models use this for action diffusion.

I iPhUMI




图 14: iPhUMI 手持数据采集夹爪。iPhUMI 在新环境中实现实时定位，与原始 UMI [1] 相比，大幅减少了采集演示数据所需的设置时间。它配备了一个定制应用程序，便于数据采集和策略部署。借助 iPhUMI，用户还可以在测试时指定行为提示，以立即调节行为提示策略。我们展示了 iPhUMI 的两种不同实例：a) 带手指用于标准操作任务，b) 带标记附件和弹簧用于顺应性绘图。




图 15: iPhUMI 采集的模式。使用双手 iPhUMI 采集的数据，用于 a) 叠衣服和 b) 绘图，图中展示了用户绘制字母 A 过程中的部分可视化。对于 DrawAnything-Real，我们不使用超广角或深度相机作为策略输入，但将其包含以供参考。

iPhUMI 是一种手持数据采集接口，旨在实现跨新任务和新环境的快速数据采集。我们修改了原始 UMI 夹爪设计 [1]，将 GoPro 替换为定制的 3D 打印支架以固定 iPhone（图 14a）。对于绘图任务，UMI 夹爪进一步修改为附接带弹簧的标记笔，以提供顺应性，无需力-力矩传感器即可绘图（图 14b）。我们开源了一款适用于 iPhUMI 的定制 iOS 应用程序，该应用程序提供直观的应用接口，用于记录演示数据，并在策略部署期间将 iPhone 用作机器人上的摄像头。

I.1 iPhUMI 数据采集




图 16: iPhUMI 数据采集界面。我们提供了一个界面，用于执行夹爪校准、收集演示以及设置数据采集的适当参数。

iPhUMI 能够同时从 iPhone 采集五种类型的数据：主摄像头（1920x1440，60Hz）、超广角摄像头（640x480，10Hz）、激光雷达深度（256x192，60Hz）、夹爪位姿（60Hz）和夹爪宽度（10Hz）（图 15）。请注意，本文中提出的任何模型或实验均未使用深度数据。与之前基于 iPhone 的夹爪不同，它们要么依赖外部鱼眼摄像头 [33]，要么不采集超广角摄像头 [34]，我们的 iPhUMI 应用能够采集超广角摄像头输入。这为策略提供了更丰富的视觉上下文，已发现可提升性能 [1]。

主要数据采集界面如图 16 所示。启动应用后，ARKit 初始化世界坐标系，然后通过 SLAM 持续估计 iPhone 位姿。iPhone 在世界坐标系中的六自由度位姿在每个演示过程中实时记录。该应用还支持同时从多个夹爪录制。最多三台设备（双手 iPhUMI 和头戴式 iPhone）可连接到共享的 ARKit 会话中，以共享同一个世界坐标系。三台 iPhone 的设置是与 Xu 等人共同开发的 [35]。一旦检测到共同的世界特征，iPhone 将连接到共享会话中。

在采集演示之前，用户需执行一次性的夹爪宽度校准：在校准模式下录制一段 ~ 10 秒的视频，同时多次开合夹爪。iPhUMI 使用超广角摄像头检测手指上的 ArUco 标签，以确定特定硬件的最小和最大夹爪宽度。

采集数据时，用户可以指定与演示关联的任务名称，并在任务变化时在线切换标签。或者，用户可以在演示任务时口述任务，iPhUMI 使用语音转文字将片段标记为当前活动任务。我们还支持通过 iPhone 上的 USB-C 接口连接 [36] 使用的接触式麦克风，以采集同步音频数据。

录制的演示可通过图 17 所示界面进行查看。选择某一演示后，将显示主摄像头、超广角摄像头和深度视频，而向左滑动可删除该演示。点击导出按钮可将演示数据保存至外部位置，例如通过 USB C 适配器连接的 SD 卡。




图 17: iPhUMI 演示管理界面。该界面允许用户查看和管理收集的演示数据。数据还可导出至通过 USB C 适配器连接的外部 SD 卡。

I.2 iPhUMI 策略部署




图 18: iPhUMI 部署界面。支持 USB 和以太网流式传输，以在机器人部署期间流式传输主摄像头、超广角摄像头和 LiDAR 深度数据。

部署界面（图 18）可用于在机器人上部署策略，使用 iPhone 作为摄像头。iPhone 通过 USB 或以太网连接流式传输其摄像头画面和深度数据。主摄像头和超广角摄像头画面均以 960x720 分辨率、60Hz 频率流式传输。深度数据以 320x240 分辨率、30Hz 频率流式传输。我们的机器人部署基础设施基于 [37] 的代码构建。

I.3 iPhUMI 用于测试时行为提示

iPhUMI 应用支持将行为提示从 iPhone 无线传输至与机器人相连的部署桌面。这使得能够快速收集行为提示，并通过 BPP 对机器人执行进行条件化。在行为提示模式下，用户使用 iPhUMI 收集单个演示，该演示随后被无线传输至与机器人相连的桌面。桌面将原始 iPhone 数据处理成行为提示，用于对 BPP 进行条件化。这实现了一种快速流程，可在测试时实际利用行为提示来指定新任务。