

ConRFT: 一种基于一致性策略的视觉-语言-动作模型强化微调方法

Yuhui Chen¹², Shuai Tian¹², Shugao Liu¹², Yingting Zhou¹², Haoran Li¹², and Dongbin Zhao¹²

¹SKL-MAIS, Institute of Automation, Chinese Academy of Sciences, Beijing, China

²School of Artificial Intelligence, University of Chinese Academy of Sciences, Beijing, China

Email: {chenyuhui2022, tianshuai2023, liushugao2023, zhouyingting2025, lihaoran2015, dongbin.zhao}@ia.ac.cn

摘要——视觉-语言-动作 (Vision-Language-Action, VLA) 模型在真实世界机器人操作中展现出巨大潜力。然而, 由于演示数据有限且不一致, 通过监督学习微调这些模型难以实现稳健的性能, 尤其是在接触密集型环境中。本文提出一种针对 VLA 模型的强化微调方法, 命名为 ConRFT, 该方法包含离线与在线微调阶段, 并采用统一的基于一致性的训练目标, 以应对上述挑战。在离线阶段, 本方法结合行为克隆与 Q 学习, 从少量演示中有效提取策略并稳定价值估计。在在线阶段, VLA 模型通过一致性策略进一步微调, 并借助人工干预确保安全探索和高样本效率。我们在八个不同的真实世界操作任务上评估了所提方法。在 45 至 90 分钟的在线微调内, 该方法平均成功率达到 96.3%, 相比先前的监督方法, 成功率提升了 144%, 回合长度缩短了 1.9 倍。本工作凸显了将强化学习融入 VLA 模型以提升其在真实机器人应用中性能的潜力。视频与代码可在项目网站 <https://cccedric.github.io/conrft/> 获取。

I. 引言

利用视觉-语言-动作 (Vision-Language-Action, VLA) 模型训练通用机器人策略的最新进展, 已在理解和执行各类操作任务方面展现出卓越能力。这些成功主要归功于大规模模仿式预训练以及与机器人动作的接地 [1, 2, 3]。尽管预训练策略捕获了强大的表征, 但在处理现实场景的复杂性时往往力不从心 [4]。利用领域特定数据进行微调对于优化下游任务的模型性能至关重要 [3, 5]。虽然使用人类遥操作数据对 VLA 模型进行监督微调 (Supervised Fine-Tuning, SFT) 仍是主要的适应方法, 但这一过程面临重大挑战: 模型性能高度依赖任务特定数据的质量和数量。然而, 这些人工收集的数据集可能因次优数据和不一致动作等固有问题, 无法始终提供最优轨迹 [6]。大语言模型 (Large-Language-Models, LLMs) 和视觉-语言模型 (Vision-Language-Models, VLMs) 的重大进展凸显了强化学习作为弥合策略能力与人类偏好之间差距 [7, 8, 9] 或提升模型推理能力 [10] 的强大工具的价值。此外, 部署带有任务特定奖励的强化学习 (reinforcement learning, RL)

从在线交互数据中学习奖励函数同样是一个有前景的方向 [11, 12, 13]。然而, 将这些洞见扩展到视觉-语言-动作 (VLA) 模型面临独特挑战, 因为与大型语言模型 (LLM) 不同, VLA 模型需要在真实世界机器人任务中进行直接物理交互。在接触密集环境中收集数据的安全性和成本约束要求高样本效率和风险感知探索, 这使得直接实现强化学习 (RL) 不可行。近期工作尝试利用 RL 来解决监督微调 (SFT) 中面临的挑战 [6, 14], 但这些方法主要侧重于利用 RL 进行数据增强或质量提升, 而非通过 RL 目标直接优化 VLA 模型。这限制了策略探索演示数据集之外状态的能力, 从而削弱了基于 RL 的微调在真实世界环境中的潜在优势。为了利用基于 RL 的技术优势, 通过在线交互数据高效微调 VLA 模型, 本文提出一种强化微调 (RFT) 方法, 包含离线与在线阶段, 并采用统一的基于一致性的训练目标。尽管该设计与离线到在线方法类似 [15, 16, 17], 但本文发现专家演示的稀缺性制约了其离线训练性能。受 CPQL [18] 洞见的启发, 本文提出一种统一的训练目标, 在离线阶段将监督学习与 Q 学习相结合, 并在在线阶段通过一致性策略进一步微调 VLA 模型。在离线训练期间, 本文方法利用先验演示并处理分布外 (OOD) 状态, 在与真实环境交互前有效提取策略和价值函数。在随后的在线阶段, 本文通过人在回路 (HIL) 学习 [19, 20] 中的人类干预, 利用任务特定奖励与 CPQL [18], 解决样本效率和真实世界安全要求这两个挑战。本文贡献总结如下: 1) 提出基于一致性的强化微调 (ConRFT) 方法, 这是一种新颖的流程, 在离线和在线微调中采用统一的训练目标。2) 通过将离线 RL 与基于一致性的行为克隆 (BC) 损失相结合, 提出 Cal-ConRFT, 专注于提取高效的策略和价值函数, 以在少量演示下提供稳定的初始化。

3) 在在线微调阶段, 本文提出 HIL-ConRFT, 该方法保留离线阶段的相同损失结构以实现策略的快速适应, 同时利用人类干预确保真实环境中的安全探索和高样本效率。

我们在八个真实世界操作任务上评估了所提方法, 证明其能够超越最先进 (SOTA) 方法。我们的框架在 45 – 90 分钟的在线微调后平均成功率达到 96.3%, 展现出高样本效率。此外, 它优于仅使用人类数据或强化学习策略数据训练的 SFT 方法, 平均成功率提升 144%, 回合长度缩短 1.9 倍。

II. 相关工作

A. 大模型的强化微调

强化学习已被广泛用于微调大语言模型和视觉语言模型。早期工作主要关注结合人类反馈的强化学习 [7, 8, 9, 21, 22], 通过从人类偏好中学习或整合任务特定奖励而不依赖显式人类偏好 [11, 12, 13, 23]。虽然其中许多方法采用在线策略算法 (如 PPO [24]) 来微调预训练策略 [12, 25, 26], 但它们通常需要大量交互数据才能达到理想性能 [27, 28]。尽管强化学习在许多领域取得了成功, 但它通常在自生成的合成环境中学习, 而非真实世界环境。这一差距阻碍了需要真实世界交互的 VLA 模型的直接迁移。本文通过开发针对高效真实世界 VLA 微调的强化学习框架来解决这一差异。

B. 真实世界强化学习系统

现实世界的机器人强化学习系统要求算法既能高效处理高维输入, 又能灵活适应奖励设定和环境重置等实际考量 [20]。此前已有多种方法直接在物理环境中有效演示了策略学习 [29, 30, 31, 20], 包括离线策略 [32, 33, 34, 35]、在线策略 [36, 37], 或将“强化学习视为监督学习”[14, 38]。尽管取得了这些进展, 许多现实世界的强化学习系统仍需要长时间训练或大量交互数据 [39], 这在接触密集型任务中既不实用又存在风险。与以往从零开始训练的方法不同, 本文专注于利用预训练的视觉-语言-动作模型提供高质量的策略初始化。该方法有效减少了强化学习早期阶段不必要的探索行为, 从而同时优化了策略学习效率 and 训练过程中的操作安全性。

C. 离线到在线方法

离线到在线强化学习旨在利用离线数据集初始化策略, 随后通过在线交互进行微调, 以提升样本效率 [15]。现有工作通常采用离线预训练阶段, 随后进行

在线微调阶段 [15, 40, 41, 16], 随着训练进行混合离线和在线数据。这种离线到在线的流程类似于本文提出的两阶段微调方法, 该方法利用预先收集的数据引导策略训练, 然后在现实任务中微调策略 [32]。大多数离线到在线方法假设存在大规模、多样化且具有足够状态覆盖的数据集 [42, 43], 这一条件在实际部署中很少满足。本文探索利用预训练的视觉-语言-动作模型作为基础策略, 以实现样本高效策略优化, 即使在严格的演示数据约束下也能达到卓越的微调性能。

三、问题设定与预备知识

我们专注于为下游任务微调预训练的视觉-语言-动作 (VLA) 模型。具体而言, 我们假设可以访问一个预训练的 VLA 模型 $\pi_{\phi_{\text{pre}}}$, 该模型从视觉输入 (例如 RGB 图像) 和语言指令中编码高层表示。在监督微调 (SFT) 中, 我们旨在使用少量带标签的演示将 ϕ_{pre} 适配到目标任务上的 ϕ , 同时保留模型的一般特征提取能力。形式上, 设 $\tau = (s_0, a_0, \dots, s_H)$ be a 为目标任务的轨迹, 则 VLA 模型微调旨在求解 $\min_{\phi} \mathcal{L}(\tau, \phi)$, 其中 $\mathcal{L}$ 可以是负对数似然 (NLL) 或均方误差 (MSE), 用于衡量预测动作与演示中动作之间的差异。该过程使我们能够有效利用机器人任务中的压缩知识, 同时将 VLA 模型引导至下游环境。由于演示通常有限、不一致且次优, 无法使策略覆盖多样状态, SFT 在现实世界中接触丰富的机器人任务中表现不佳。为解决这些问题, 我们将每个机器人任务建模为马尔可夫决策过程 (MDP), 其中强化学习 (RL) 的目标是在 MDP 中找到最优策略, $\mathcal{M} = (\mathcal{S}, \mathcal{A}, \mathcal{P}, r, \rho, \gamma)$, 其中 $s \in \mathcal{S}$ 表示状态空间, $a \in \mathcal{A}$ 表示动作空间。 $\mathcal{P}(s'|s, a)$ 是依赖于系统动力学的环境转移概率, $\rho(s)$ 表示初始状态分布。 $r(s, a)$ 和 $\gamma \in (0, 1)$ 分别是奖励函数和奖励折扣因子。策略 π 通过最大化奖励的累积期望值来估计, 记为 $V^{\pi}(s) = \mathbb{E}_{\pi}[\sum_{t=0}^H \gamma^t r(s_t, a_t) | s_0 = s, a_t \sim \pi(s_t), s_{t+1} \sim p(\cdot | s_t, a_t)]$ 。给定策略 π 的 Q 函数记为 $Q^{\pi}(s, a) = \mathbb{E}_{\pi}[\sum_{t=0}^H \gamma^t r(s_t, a_t) | s_0 = s, a_0 = a, s_{t+1} \sim p(\cdot | s_t, a_t)]$ 。 H 表示轨迹的最大回合步数。通过将 VLA 策略与学习到的 Q 函数相结合, 强化微调 (RFT) 使 VLA 模型能够基于试错交互和任务特定反馈来优化其行为。

四、方法

所提出的流程 ConRFT 包括两个阶段: 离线微调后进行在线微调, 以优化机器人策略, 如图 1 所示。在以下章节中, 我们将详细描述这两个阶段, 流程图示见附录 A。




图 1: ConRFT 概览。该图展示了针对预训练视觉-语言-动作（VLA）模型的强化微调方法架构，包含两个阶段：离线校准一致性强化微调（Cal-ConRFT）与在线人在回路一致性强化微调（HIL-ConRFT）。两个阶段均采用统一的一致性训练目标。离线阶段仅使用预先收集的演示数据进行微调。在线阶段，人类操作员可通过遥操作工具（如空间鼠标）干预机器人策略。微调时同时使用预先收集的演示数据、策略转移样本及人类干预数据。

A. 阶段一：基于校准约束强化微调的离线微调

由于预训练的视觉-语言-动作（VLA）模型通常缺乏对新机器人配置的零样本泛化能力，在离线阶段，我们专注于使用一个小、预先收集的离线数据集（20–30 次演示）来训练策略，然后再过渡到在线强化学习。我们用预训练的 VLA 模型初始化策略进行强化学习，从而减少探索负担和整体在线训练时间。考虑到有效利用离线数据的能力，我们选择校准 Q 学习（Calibrated Q-Learning, Cal-QL）[16] 作为基础离线强化学习方法，因为我们希望 Q 函数对分布外（OOD）动作具有鲁棒性。具体来说，Cal-QL 通过降低时序差分（TD）误差和一个额外的正则化项，在预先收集的数据集上训练 Q 函数。该正则化项在 OOD 动作的 Q 值超过参考策略 $V^\mu(s)$ 的值时对其进行惩罚，同时对离线数据集中观察到的动作进行补偿。Cal-QL 对评论家的训练目标如下：

$$\begin{aligned} \mathcal{L}_Q^{offline}(\theta) = & \alpha(\mathbb{E}_{s \sim \mathcal{D}, a \sim \pi(\cdot|s)}[\max(Q_\theta(s, a), V^\mu(s))] \\ & - \mathbb{E}_{s, a \sim \mathcal{D}}[Q_\theta(s, a)]) \\ & + \frac{1}{2} \mathbb{E}_{(s, a, s') \sim \mathcal{D}}[(Q_\theta(s, a) - \mathcal{B}^\pi \bar{Q}_\theta(s, a))^2] \end{aligned} \quad (1)$$

其中 Q_θ 是由 θ 参数化的学习 Q 函数， $\bar{Q}_\theta$ 是由 $\bar{\theta}$ 参数化的延迟目标 Q 函数，是贝尔曼人工备份操作员。 α 是控 $\mathcal{B}^\pi \bar{Q}(s, a) = r(s, a) + \gamma \mathbb{E}_{a' \sim \pi(\cdot|s')}(\bar{Q}(s', a'))$ 制保守惩罚的超参数。而 $\mathcal{D}$ 是存储演示数据的缓冲区

演示。

然而，尽管 Cal-QL 通常能高效利用离线数据集，但当仅有少量演示（例如 20–30 个）可用时，它难以训练出有效的策略。在这种情况下，有限的状态覆盖导致价值估计不佳，使策略难以泛化到未见过的状态。相比之下，典型的离线强化学习数据集通常从多个行为策略中收集，提供广泛的状态覆盖以减少分布偏移。缺乏这种广度，仅靠 Cal-QL 损失可能无法充分指导学习过程，导致性能不佳。

为了解决这个问题，我们提出通过引入行为克隆（BC）损失来增强离线训练过程。BC 损失直接最小化策略生成的动作与演示中的动作之间的差异。通过引入 BC 损失，我们鼓励模型模仿演示中的行为，在离线阶段提供额外的监督信号。这有助于视觉-语言-动作（VLA）模型在少量演示的情况下学习更有效的策略并初始化稳定的 Q 函数，尤其是在控制精度至关重要的接触丰富操作任务中。

受在基于一致性的目标 [18] 下结合 BC 损失与 Q 指导的启发，我们在离线阶段引入了 Cal-ConRFT。该方法采用一致性策略作为动作头来微调 VLA 模型，解决两个关键问题：1) 它有助于利用预收集数据中经常出现的 inconsist 和次优演示；2) 与基于扩散的动作头相比，




图 2：所有真实世界实验任务概览。真实世界任务包括拾取和放置 (a) 香蕉、(b) 勺子、(d) 和 (f) 面包，操作 (c) 抽屉和 (e) 烤面包机，组装复杂物体如 (g) 椅子轮和 (h) 中国结。

基于一致性的动作头在计算上保持轻量，以实现高效推理 [18, 44, 45]。一致性策略是一种基于扩散模型的策略 [46]，它学习将从单位高斯分布中采样的随机动作映射为以当前状态为条件、从专家动作分布中生成的动作。对于一致性策略，我们将扩散时间范围 $[\epsilon, K]$ 离散化为 M 个子区间，边界为 $k_1 = \epsilon \leq k_2 \leq \dots \leq k_m = K$ 和 $\epsilon = 0.002$ 。具体而言，以一致性策略作为动作头的 VLA 模型由下式给出：

$$\pi_\psi(a|s) = f_\psi(a^k, k|E_\phi(s)) \quad (2)$$

其中 f 表示以 ψ 为参数的一致性策略，下标 k 表示扩散步骤， $a^k \sim \mathcal{N}(0, kI)$ 和 $E_\phi(s)$ 表示以 ϕ 为参数的预训练 VLA 模型的编码状态。用于 VLA 模型微调的一致性训练目标为：

$$\mathcal{L}_\pi^{\text{offline}}(\psi) = \beta \mathcal{L}_\pi^{BC} + \eta \mathcal{L}_\pi^Q \quad (3)$$

其中 BC 损失 $\mathcal{L}_\pi^{BC} = \mathbb{E}_{(s,a) \sim \mathcal{D}, m \sim \mathcal{U}[1, M-1]}[d(f_\psi(a + k_m z, k_m|E(s)), a)]$ ， $z \sim \mathcal{N}(0, I)$ ， d 表示欧氏距离 $d(x, y) = \|x - y\|_2$ ，Q 损失 $\mathcal{L}_\pi^Q = -\mathbb{E}_{s \sim \mathcal{D}, a \sim \pi_\psi}[Q(s, a)]$ 。 β 和 η 是用于平衡 BC 损失和 Q 损失的两个超参数。这种组合通过将价值估计与专家动作对齐，即使在少量演示数据下也能实现高效的策略学习和稳定的价值估计，并在离线训练期间提升策略性能。此外，它为在线阶段提供了可靠的初始化，有助于安全有效的探索。

B. 第二阶段：基于 HIL-ConRFT 的在线微调

虽然离线阶段从少量演示数据中提供了初始策略，但其性能受限于预收集演示的范围和质量。因此，我们设计了基于 HIL-ConRFT 的在线阶段。在该阶段 VLA 模型通过一致性策略与真实环境交互进行在线微调。在线训练过程中，离线阶段的演示缓冲区 $\mathcal{D}$ 被保留。此外，我们使用回放缓冲区 $\mathcal{R}$ 存储在线数据，然后实施对称采样 [27]，即每个批次从这两个缓冲区中等量采样以形成训练批次。由于 VLA 模型根据其当前策略持续收集新的转移样本，数据分布自然随策略演化。这种持续交互减少了离线阶段面临的分布偏移问题。因此，我们使用标准 Q 损失进行在线评论家更新：

$$\mathcal{L}_Q^{\text{online}}(\theta) = \mathbb{E}_{(s,a,s') \sim (\mathcal{D} \cup \mathcal{R})}[(Q_\theta(s, a) - \mathcal{B}^\pi \bar{Q}(s, a))^2] \quad (4)$$

用于 VLA 模型微调的一致性训练目标为：

$$\mathcal{L}_\pi^{\text{online}}(\psi) = \beta \mathcal{L}_\pi^{BC} + \eta \mathcal{L}_\pi^Q \quad (5)$$

其中 BC 损失 $\mathcal{L}_\pi^{BC} = \mathbb{E}_{(s,a) \sim (\mathcal{D} \cup \mathcal{R}), m \sim \mathcal{U}[1, M-1]}[d(f_\psi(a + k_m z, k_m|E(s)), a)]$ ， $z \sim \mathcal{N}(0, I)$ ， d 表示欧氏距离 $d(x, y) = \|x - y\|_2$ ，Q 损失 $\mathcal{L}_\pi^Q = -\mathbb{E}_{s \sim (\mathcal{D} \cup \mathcal{R}), a \sim \pi_\psi}[Q(s, a)]$ 。注意，该目标与离线阶段的公式 3 非常相似，能够快速适应在线微调。通常，在在线阶段我们降低 BC 损失权重 β ，同时增加 Q 损失权重 η ，但我们保持

Task	Training Time (mins)	Success Rate (%)					Episode length				
		SFT[47]	Cal-ConRFT	HG-Dagger[19]	PA-RL[14]	HIL-ConRFT	SFT[47]	Cal-ConRFT	HG-Dagger[19]	PA-RL[14]	HIL-ConRFT
Pick Banana	45	40	50	60 (+50%)	80 (+100%)	90 (+80%)	63.7	57.8	67.5 (0.9x)	56.1 (1.1x)	51.2 (1.1x)
Put Spoon	45	50	55	90 (+80%)	80 (+60%)	100 (+82%)	49.9	57.2	50.9 (1.0x)	45.3 (1.1x)	22.6 (2.5x)
Open Drawer	15	35	30	80 (+129%)	60 (+71%)	100 (+233%)	63.6	61.7	48.4 (1.3x)	57.1 (1.1x)	32.4 (1.8x)
Pick Bread	45	65	55	65 (+0%)	80 (+23%)	100 (+82%)	53.2	49.1	65.6 (0.8x)	51.7 (1.0x)	31.6 (1.6x)
Open Toaster	30	30	30	75 (+116%)	100 (+233%)	100 (+233%)	51.2	50.7	43.4 (1.2x)	34.3 (1.5x)	22.1 (2.3x)
Put Bread	60	5	20	60 (+1100%)	75 (+1400%)	100 (+400%)	102	84.8	74.2 (1.4x)	72.1 (1.4x)	36.6 (2.3x)
Insert Wheel	60	35	35	40 (+14%)	30 (-14%)	80 (+129%)	42.7	43.4	53.0 (0.8x)	47.4 (0.9x)	21.9 (2.0x)
Hang Chinese Knot	90	55	40	50 (-10%)	65 (+18%)	100 (+150%)	52.6	54.9	47.5 (1.1x)	44.4 (1.3x)	26.8 (2.0x)
Average	48.8	39.4	39.4	65 (+65%)	71.3 (+81%)	96.3 (+144%)	59.9	57.5	56.3 (1.1x)	51.1 (1.2x)	30.7 (1.9x)

表一：各种离线与在线微调方法的全部实验结果。本文报告了离线微调（SFT [47] 与 Cal-ConRFT）以及在线微调（HG-Dagger [19]、PA-RL [14] 与 HIL-ConRFT）后策略相对于各基线的性能，包括各任务的成功率与平均回合长度。具体而言，对于在线微调，HG-Dagger 与 PA-RL 的训练从 SFT 基线开始，而 HIL-ConRFT 的训练从 Cal-ConRFT 基线开始。性能提升是相对于相应离线结果而言的。所有方法均使用相同数量的带人工干预的在线回合来训练策略。所有度量均在每个任务 20 次试验中报告。

行为克隆损失（BC Loss）的引入基于两个主要原因。1）首先，它确保策略持续与演示数据保持一致，防止可能引发性能崩溃的剧烈偏离。这对于保持接触丰富操作任务中的动作质量至关重要，因为策略的突然变化可能导致不安全或低效的行为。2）其次，由于强化学习本质上涉及探索，在高维状态-动作空间中可能变得不稳定。通过为探索提供稳定化效应 [48]，行为克隆损失防止策略偏离其离线基线过远，从而降低低效或不安全行为的风险。这一方面在真实世界机器人训练中尤为重要，尤其是在物理环境中，不安全动作可能导致损坏或其他危险。此外，我们通过人在回路（Human-in-the-Loop）学习将人类干预整合到在线阶段。具体而言，人在回路学习允许人类操作员在探索过程中及时干预，提供纠正性动作，随后接管机器人的控制权。这些人类纠正被添加到演示缓冲区 $\mathcal{D}$ 中，提供高层指导，引导探索朝着更安全、更高效的方向发展 [49]。当机器人出现破坏性行为时，例如与障碍物碰撞、施加过大力量或损坏环境，人类干预至关重要。除了确保安全探索外，人类干预还加速策略收敛。在策略将机器人引入不可恢复或不良状态，或机器人陷入局部最优、若无外部协助将需要大量时间和步骤才能摆脱的情况下，人类操作员可以介入纠正机器人的动作，引导其走向更安全、更有效的行为。这带来了稳定的学习过程，使视觉-语言-动作（VLA）模型比仅靠自主探索更快、更安全地完成微调。

五、实验与结果

在本节中，我们通过真实世界实验验证所提出的微调框架。我们首先呈现

实验设置以及各种基线的结果，然后讨论这些结果及其启示。

A. 实验概述

我们的实验旨在评估所提方法在真实场景中微调视觉-语言-动作模型的有效性 & 效率。为此，我们在八个不同的操作任务上进行了真实世界实验，如图 2 所示。这些任务旨在反映多种操作挑战，包括物体放置任务（例如将面包放入烤面包机、将面包放在白色盘子上）、精确且接触丰富的操作（例如将轮子对准并插入椅子底座）以及动态物体处理（例如悬挂中国结）。为验证微调方法，我们选择八爪鱼小型模型（Octo-small）[47]，因其在性能与推理效率之间取得平衡，并在七自由度弗兰卡·艾米卡（Franka Emika）机械臂上采用一致性策略（Consistency Policy）[45] 作为动作头。对于所有任务，状态观测包括来自腕部摄像头（128×128）和侧面摄像头（256×256）的两幅 RGB 图像，以及机械臂的本体感受状态，包括末端执行器位姿、扭转、力/力矩和夹爪状态。动作空间定义为六维末端执行器增量位姿，用于下游阻抗控制器；或七维目标，额外包含一维二值夹爪动作，用于涉及抓取的任务。数据采集与策略以 10 赫兹频率发出动作。训练前，由人类操作员采集正样本与负样本演示，以训练一个二值分类器，该分类器针对每个任务给出二值反馈，判断对应任务是否成功完成。此外，每个任务的初始状态通过脚本化机器人运动或人类操作员手动重置进行随机化。我们在附录 B 中给出了真实世界实验中各任务的描述，以及实验任务、训练和评估流程的更多细节。




图 3：在线训练过程中的学习曲线。本图展示了 HIL-SERL[20]、HG-DAGger[19]、PA-RL[14] 以及本文方法在五个代表性真实世界任务上的成功率、干预率和回合长度，以 20 个回合的滑动平均显示。PA-RL 在实现时未加入人类干预。注意，人类干预可能引导策略走向成功结果，因此当存在干预时，实际策略成功率可能低于曲线所示。

B. 实验结果

本节给出了所有任务的实验结果，如图 2 所示。对于每个任务，我们报告了结果度量，包括成功率、回合长度和总训练时间，见表 I。训练时间包括脚本动作、策略推演和机载计算的持续时间，所有这些均使用 NVIDIA RTX A6000 GPU 进行。在离线阶段，我们比较了 Cal-ConRFT 和 SFT，其中 SFT 使用 NLL 损失进行行为克隆 [47]。在在线阶段，我们将 HIL-ConRFT 与多个基线进行了比较，包括 HG-DAGger[19]，它结合人类纠正通过监督学习微调策略；PA-RL[14]，它通过策略无关的 Q 函数优化动作，并使用优化后的动作通过监督学习微调策略。我们还比较了 HIL-SERL[20]，它从头开始使用人类干预训练 RL 策略；以及 RLDG[6]，它使用 RL 策略收集的演示通过 SFT[47] 微调 VLA 模型。

在所有任务中，经过 45 至 90 分钟的真实世界训练后，成功率达到 96.3%，相较于监督学习基线提升了 144%。该方法超越了 HG-DAGger 和 PA-RL 等最先进方法，后两者的平均成功率分别为 65% 和 71.3%。HG-DAGger 虽然利用人类纠正通过监督学习对视觉-语言-动作模型进行微调，但未能实现显著的策略改进，甚至在某些任务上出现性能下降，原因在于人类纠正的次优性和不一致性。例如，我们观察到，对于需要精确、细致操作的接触密集型任务，如插入轮子和挂中国结，HG-DAGger 在在线微调后的策略改进有限。具体而言，在挂中国结任务中，对柔软物体的细致处理要求一致且精确的控制。人类纠正中固有的变异性，例如插入角度的差异，会给训练过程引入噪声和冲突信息。这种不一致性阻碍了策略学习精确和灵巧行为的能力。此外，接触动力学的复杂性意味着策略中的微小偏差可能导致显著的性能下降，进一步加剧了由不一致的人类纠正所带来的挑战。

1) ConRFT 优于监督方法：本文比较了监督方法与强化方法的不同途径

表 I，并在图 3 中呈现相应的在线学习曲线。本文方法 ConRFT 达到了最高的平均值

在缺乏人类纠正的情况下，PA-RL 提供了一种直接

Task	Training Time (mins)	Success Rate (%)		Episode length	
		HIL-SERL[20]	HIL-ConRFT	HIL-SERL[20]	HIL-ConRFT
Pick Banana	45	0 → 15	50 → 90	30.6	51.2
Put Spoon	45	0 → 60	55 → 100	56.1	22.6
Open Drawer	15	0 → 10	30 → 100	67.5	32.4
Pick Bread	45	0 → 45	55 → 100	22.0	31.6
Open Toaster	30	0 → 100	30 → 100	28.1	22.1
Put Bread	60	0 → 5	20 → 100	62.0	36.6
Insert Wheel	60	0 → 5	35 → 80	42.0	21.9
Hang Chinese Knot	90	0 → 15	40 → 100	57.3	26.8
Average	48.8	0 → 31.9	39.4 → 96.3	45.7	30.7

表 II：从零开始训练（HIL-SERL [20]）与微调视觉-语言-动作模型（HIL-ConRFT）的实验结果。策略在相同数量的干预回合下进行训练。所有指标均基于每个任务 20 次试验报告。

使用通过 Cal-QL 训练的策略无关 Q 函数进行动作优化。通过基于奖励信号优化动作，PA-RL 克服了人类修正的次优性，并在 Pick Banana 和 Put Spoon 等较简单任务中表现出更稳定的策略改进。然而，在需要精确、细致操作的接触丰富任务（如 Insert Wheel）中，它未能提升策略性能。在 Insert Wheel 任务中，精确对齐和受控插入力至关重要。然而，由于演示缓冲区和回放缓冲区中的状态覆盖有限，策略无关的 Q 函数无法有效泛化到不同的轮子和槽位位置。这限制了策略处理成功插入所需的细微状态转移变化的能力，导致在复杂操作场景中性能次优。因此，尽管 PA-RL 在简单环境中显示出潜力，但它难以扩展到要求高精度和灵巧性的复杂任务。这些观察结果凸显了我们所提出方法的优势，该方法有效缓解了不一致人类修正和强化学习状态覆盖有限所带来的问题。我们的方法 ConRFT 有效且安全地探索广泛的状态范围，并直接使用任务特定奖励优化策略，从而展示了高样本效率并减轻了不一致人类修正的影响。这种稳定性和性能凸显了我们的方法在克服现有微调方法在真实世界机器人应用中的局限性方面的有效性。评估策略性能的另一个关键度量是回合长度，它表示策略完成任务所需的总步数。如表 I 所示，使用 HIL-ConRFT 微调的 VLA 模型实现了平均回合长度 30.7 步，比离线基线短 1.9 倍。相比之下，HG-DAGger 实现了平均回合长度 56.3 步，仅比离线基线短 1.1 倍。类似地，PA-RL 实现了平均回合长度 51.1 步。由于策略无关 Q 函数的保守性，它缺乏策略探索，无法有效优化如何更快完成任务或尝试更高效的行为。这些结果表明 ConRFT 能够有效利用

马尔可夫决策过程（MDP）的动态特性，通过一致性策略优化视觉-语言-动作（VLA）模型，以最大化折扣累积奖励。他们还指出了监督方法在处理次优数据和高效策略探索方面的局限性。通过鼓励策略更快地获得奖励，我们的方法比仅依赖模仿演示的监督方法产生更短的回合长度。这种增强的样本效率和缩短的回合长度凸显了 ConRFT 在现实世界机器人应用中微调 VLA 模型的优势。2) 微调 VLA 优于从头训练：从头开始的强化学习通常需要与环境进行大量交互和频繁的人工干预，这可能导致漫长的训练过程和高安全风险。例如，HIL-SERL [20] 是一种通过强化学习从头训练策略并辅以人工干预的方法，在与我们的方法相同的训练时长内未能收敛到有效策略，如表 II 所示，平均成功率仅为 31.9%。图 3 中的学习曲线表明，HIL-ConRFT 在在线阶段持续提升策略性能。虽然 HIL-SERL 最终能够获得最优策略，但通常需要超过两个小时的在线训练，且每个任务的干预率更高，导致探索过程中出现更多破坏性行为（例如与环境碰撞），尤其是在训练早期。相比之下，从预训练的 VLA 模型开始并进行离线微调，可以减少在线训练时间并提高样本效率。基于离线初始化的策略，ConRFT 加速了策略收敛并提升了最终性能。因此，通过一致性策略微调 VLA 模型，使其能够以更少的干预更快地达到更高的成功率，这证明了在现实世界机器人应用中利用预训练 VLA 模型的优势。3) 分析：a) 为什么从 Cal-ConRFT 微调而不是 SFT 或 Cal-QL?：如表 I 所示，我们观察到在离线阶段，Cal-ConRFT 的性能与 SFT 基线相似。这一观察结果引出了一个问题：为什么在离线阶段引入 Q 损失？原因是当离线阶段仅依赖 SFT 时，微调后的策略受益于模仿学习，但可能需要大量的在线微调来处理离线数据集中未涵盖的状态和动作。相比之下，在离线阶段引入 Q 损失，可以使早期的 Q 值估计为策略改进提供初始化，从而促进在线微调时的快速适应。这种方法有助于解决潜在的偏差并确保更稳定的学习。此外，在演示数据较少的场景中，我们发现仅依赖 Cal-QL 不足以训练出有效的策略，导致所有任务的成功率为 0%。数据不足影响了策略准确估计 Q 值的能力，导致离线阶段后性能较弱且训练时间更长




图 4: HIL-ConRFT 从 SFT [47] 和 Cal-ConRFT 基线进行在线微调的学习曲线。本图展示了两个代表性任务的成功率和干预率，以 20 个回合的滑动平均值显示。

Task	Success Rate (%)				
	DP[50]	SFT[47]	RLDG[6]	Cal-ConRFT	HIL-ConRFT
Put Spoon	60	70	100	55	100
Put Bread	30	65	100	20	100
Insert Wheel	35	40	50	35	80
Average	41.7	58.3	83.3	36.7	93.3

表 III: 与不同演示数据的实验比较。扩散策略 (DP) [50] 和 SFT [47] 使用人类遥操作收集的 150 个演示进行训练，而 RLDG [6] 使用强化学习策略收集的 150 个演示进行训练。Cal-ConRFT 使用人类遥操作收集的 20 个演示进行训练，HIL-ConRFT 则使用 20 个演示以及 80-120 条策略生成的展开轨迹进行训练。所有度量均在每个任务 20 次试验中报告。

在线阶段的时间。我们比较了从 Cal-ConRFT 和 SFT 基线开始的在线微调曲线，在两个代表性任务上进一步研究引入 Q 损失的影响，如图 4 所示。尽管两条曲线初始成功率相近，但从 SFT 基线训练时观察到的较高干预率表明，SFT 训练的策略在在线训练早期经历了严重的策略遗忘。这表明 Cal-ConRFT 通过在离线阶段利用 Q 损失，能够更快地适应在线学习过程，从而在少量演示数据下实现更有效和稳定的策略改进。b) 增加演示数量是否能提升 SFT 的策略性能? : 通常，在

Task	Success Rate (%)	
	Kosmos-2(1.6B)	PaliGemma(3B)
Pick Banana	60→100	65→100
Put Spoon	55→100	30→100
Hang Chinese Knot	45→100	60→100
Average	53.3→100	51.7→100

表 IV: ConRFT 在不同 VLA 模型上的实验结果。我们使用两个 VLM 骨干网络对 RoboVLM [51] 进行微调。具体而言，我们仅微调动作头，同时保持视觉编码器和变换器骨干网络冻结。所有度量均在每个任务 20 次试验中报告。

在 45 至 60 分钟的在线微调阶段，策略收集约 80 至 120 条成功与失败轨迹。为确保本文方法与监督训练方法之间的公平比较，进一步在三个代表性任务上使用 150 条演示比较训练扩散策略 (Diffusion Policy, DP) [50] 与监督微调视觉语言动作模型 (VLA) [47]，这与本文方法所使用的演示总数一致。此外，将强化学习扩散策略 (RLDG) [6] 与使用强化学习策略收集的 150 条演示进行微调比较。如表 III 所示，尽管 DP 与监督微调受益于更多演示，其成功率仍未能达到本文方法的性能，尤其在接触密集任务（如插入轮毂）上。这表明，由于人类收集数据中固有的不一致与次优动作，仅通过监督学习增加更多人类收集的演示并不一定保证更高性能。同时，RLDG 利用强化学习策略收集的最优数据取得更高成功率，表明这些强化学习收集数据的一致性能够提升最终性能。另一方面，本文方法通过优化基于一致性的训练目标直接微调策略，取得最高成功率。c) ConRFT 在各种 VLA 模型上的实用性: ConRFT 具有高度通用性，可应用于任何基于视觉语言模型 (VLM) 且带动作头的架构。这种灵活性源于其能够独立于底层视觉编码器优化动作生成过程，使其适应各种 VLA 框架。为进一步验证其适用性泛化能力，在微调 RoboVLM [51] 时测试了本文方法，使用两种不同的 VLM 骨干网络。如表 IV 所示，结果表明 ConRFT 能够有效提升各种 VLA 的性能，提高多项机器人任务的成功率。这种在利用预训练视觉组件的同时微调动作生成的能力，凸显了 ConRFT 的广泛适用性。

六、局限性

尽管本文方法在真实世界操作任务中微调 VLA 模型时展现出强大的性能与样本效率，仍存在若干局限性。

A. 对奖励工程的敏感性

本文实现了一个任务特定的二分类器来计算强化学习的奖励。然而，分类器训练数据与强化学习探索过程中生成的状态-动作分布之间固有的分布偏移造成了一个关键漏洞，因为它可能导致学习到的策略进行奖励黑客行为，利用分类器提供不准确奖励的意外行为。例如，机器人可能将其末端执行器定位在触发假阳性的特定位置，导致策略收敛到错误的行为。由于这些奖励分类器通常只提供稀疏反馈，即使有人类干预，策略也可能学习缓慢。另一方面，这种奖励驱动的方法产生了高度专门化的策略，这些策略与任务的特定条件紧密相关，限制了它们泛化到新环境的能力。虽然引入多任务密集奖励信号可以提高样本效率并加速策略收敛，但它也需要为现实世界应用进行更复杂的奖励工程。

B. 冻结编码器与变换器主干网络

我们当前的实现将交互与策略学习过程运行于独立线程中，仅对动作头网络进行一致性策略微调，同时保持视觉编码器与变换器主干网络冻结。尽管该设计选择提升了实时性能，却限制了策略在在线训练期间优化其感知与表示模块的能力，尤其是在未见场景下。允许这些冻结组件进行部分或完全更新，并可能采用参数高效微调（如低秩适配 [52]）等高效技术，有望在不牺牲安全性或速度的前提下，提升最终任务性能与适应性。

七、结论

我们提出了一种两阶段方法 ConRFT，用于在真实世界机器人应用中强化微调视觉-语言-动作（VLA）模型。首先，通过少量演示进行离线微调（Cal-ConRFT），在基于一致性的框架中，利用整合 Q 损失与行为克隆（BC）损失的统一训练目标，初始化可靠的策略与价值函数。随后，在在线微调阶段（HIL-ConRFT），利用任务特定奖励与人类干预，通过一致性策略对 VLA 模型进行微调。在八个多样化的真实世界任务上的实验表明，我们的方法在成功率、样本效率和回合长度方面均优于最先进的方法。总体而言，本工作展示了一种利用强化学习实现安全高效 VLA 模型微调的实用途径。

致谢

本工作得到国家自然科学基金（NSFC）项目 62136008 的资助，并部分得到中国科学院国际合作计划项目 104GJHZ2022013GC 的资助。

参考文献

- [1] Abby O'Neill, Abdul Rehman, Abhinav Gupta, Abhiram Maddukuri, Abhishek Gupta, Abhishek Padalkar, Abraham Lee, Acorn Pooley, Agrim Gupta, Ajay Mandlekar, et al. Open X-Embodiment: robotic learning datasets and RT-X models. In *International Conference on Robotics and Automation, ICRA*, 2024.
- [2] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Xi Chen, Krzysztof Choromanski, Tianli Ding, Danny Driess, Avinava Dubey, Chelsea Finn, et al. RT-2: vision-language-action models transfer web knowledge to robotic control. *Conference on Robot Learning, CoRL*, 2023.
- [3] Kevin Black, Noah Brown, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Lachy Groom, Karol Hausman, Brian Ichter, et al. π_0 : A vision-language-action flow model for general robot control. *arXiv preprint arXiv:2410.24164*, 2024.
- [4] Joshua Jones, Oier Mees, Carmelo Sferrazza, Kyle Stachowicz, Pieter Abbeel, and Sergey Levine. Beyond sight: Finetuning generalist robot policies with heterogeneous sensors via language grounding. *arXiv preprint arXiv:2501.04693*, 2025.
- [5] Lirui Wang, Xinlei Chen, Jialiang Zhao, and Kaiming He. Scaling proprioceptive-visual learning with heterogeneous pre-trained transformers. In *Neural Information Processing Systems, NeurIPS*, 2024.
- [6] Charles Xu, Qiyang Li, Jianlan Luo, and Sergey Levine. RLDG: robotic generalist policy distillation via reinforcement learning. *arXiv preprint arXiv:2412.09858*, 2024.
- [7] Paul F. Christiano, Jan Leike, Tom B. Brown, Miljan Martic, Shane Legg, and Dario Amodei. Deep reinforcement learning from human preferences. In *Neural Information Processing Systems, NeurIPS*, 2017.
- [8] Long Ouyang, Jeffrey Wu, Xu Jiang, Diogo Almeida, Carroll Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, and other. Training language models to follow instructions with human feedback. In *Neural Information Processing Systems, NeurIPS*, 2022.
- [9] Luong Quoc Trung, Xinbo Zhang, Zhanming Jie, Peng Sun, Xiaoran Jin, and Hang Li. ReFT: reasoning with reinforced fine-tuning. In *Association for Computational Linguistics, ACL*, 2024.
- [10] Richard Yuanzhe Pang, Weizhe Yuan, Kyunghyun Cho, He He, Sainbayar Sukhbaatar, and Jason Weston. Iterative reasoning preference optimization. In *Neural Information Processing Systems, NeurIPS*, 2024.
- [11] Rajkumar Ramamurthy, Prithviraj Ammanabrolu, Kianté Brantley, Jack Hessel, Rafet Sifa, Christian Bauckhage, Hannaneh Hajishirzi, and Yejin Choi. Is reinforcement learning (not) for natural language processing: Benchmarks, baselines, and building blocks for natural language policy optimization. In *International Conference on Learning Representations, ICLR*, 2023.

- [12] Hao Bai, Yifei Zhou, Mert Cemri, Jiayi Pan, Alane Suhr, Sergey Levine, and Aviral Kumar. DigiRL: training in-the-wild device-control agents with autonomous reinforcement learning. In *Neural Information Processing Systems, NeurIPS*, 2024.
- [13] Thomas Carta, Clément Romac, Thomas Wolf, Sylvain Lamprier, Olivier Sigaud, and Pierre-Yves Oudeyer. Grounding large language models in interactive environments with online reinforcement learning. In *International Conference on Machine Learning, ICML*, 2023.
- [14] Max Sobol Mark, Tian Gao, Georgia Gabriela Sampaio, Mohan Kumar Srirama, Archit Sharma, Chelsea Finn, and Aviral Kumar. Policy agnostic RL: offline RL and online RL fine-tuning of any class and backbone. *arXiv preprint arXiv:2412.06685*, 2024.
- [15] Seunghyun Lee, Younggyo Seo, Kimin Lee, Pieter Abbeel, and Jinwoo Shin. Offline-to-online reinforcement learning via balanced replay and pessimistic q-ensemble. In *Conference on Robot Learning, CoRL*, 2021.
- [16] Mitsuhiro Nakamoto, Simon Zhai, Anikait Singh, Max Sobol Mark, Yi Ma, Chelsea Finn, Aviral Kumar, and Sergey Levine. Cal-QL: Calibrated offline RL pre-training for efficient online fine-tuning. In *Neural Information Processing Systems, NeurIPS*, 2023.
- [17] Zhiyuan Zhou, Andy Peng, Qiyang Li, Sergey Levine, and Aviral Kumar. Efficient online reinforcement learning fine-tuning need not retain offline data. *arXiv preprint arXiv:2412.07762*, 2024.
- [18] Yuhui Chen, Haoran Li, and Dongbin Zhao. Boosting continuous control with consistency policy. In *International Conference on Autonomous Agents and Multiagent Systems, AAMAS*, 2024.
- [19] Michael Kelly, Chelsea Sidrane, Katherine Rose Driggs-Campbell, and Mykel J. Kochenderfer. HG-Dagger: interactive imitation learning with human experts. In *International Conference on Robotics and Automation, ICRA*, 2019.
- [20] Jianlan Luo, Charles Xu, Jeffrey Wu, and Sergey Levine. Precise and dexterous robotic manipulation via human-in-the-loop reinforcement learning. *arXiv preprint arXiv:2410.21845*, 2024.
- [21] Stephen Casper, Xander Davies, Claudia Shi, Thomas Krendl Gilbert, Jérémy Scheurer, Javier Rando, Rachel Freedman, Tomasz Korbak, David Lindner, Pedro Freire, et al. Open problems and fundamental limitations of reinforcement learning from human feedback. *Transactions on Machine Learning Research*, 2023.
- [22] Yuexiang Zhai, Hao Bai, Zipeng Lin, Jiayi Pan, Shengbang Tong, Yifei Zhou, Alane Suhr, Saining Xie, Yann LeCun, Yi Ma, et al. Fine-tuning large vision-language models as decision-making agents via reinforcement learning. In *Neural Information Processing Systems, NeurIPS*, 2024.
- [23] Kimin Lee, Laura M. Smith, and Pieter Abbeel. PEBL: feedback-efficient interactive reinforcement learning via relabeling experience and unsupervised pre-training. In *International Conference on Machine Learning, ICML*, 2021.
- [24] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017.
- [25] Abhishek Gupta, Vikash Kumar, Corey Lynch, Sergey Levine, and Karol Hausman. Relay policy learning: Solving long-horizon tasks via imitation and reinforcement learning. In *Conference on Robot Learning, CoRL*, 2019.
- [26] Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Xiao Bi, Haowei Zhang, Mingchuan Zhang, YK Li, Y Wu, et al. DeepSeekMath: pushing the limits of mathematical reasoning in open language models. *arXiv preprint arXiv:2402.03300*, 2024.
- [27] Philip J Ball, Laura Smith, Ilya Kostrikov, and Sergey Levine. Efficient online reinforcement learning with offline data. In *International Conference on Machine Learning, ICML*, 2023.
- [28] Boyu Li, Haobin Jiang, Ziluo Ding, Xinrun Xu, Haoran Li, Dongbin Zhao, and Zongqing Lu. SELU: self-learning embodied mllms in unknown environments. *arXiv preprint arXiv:2410.03303*, 2024.
- [29] Martin A. Riedmiller, Thomas Gabel, Roland Hafner, and Sascha Lange. Reinforcement learning for robot soccer. *Autonomous Robots*, 27(1):55–73, 2009.
- [30] Tobias Johannink, Shikhar Bahl, Ashvin Nair, Jianlan Luo, Avinash Kumar, Matthias Loskyll, Juan Aparicio Ojea, Eugen Solowjow, and Sergey Levine. Residual reinforcement learning for robot control. In *International Conference on Robotics and Automation, ICRA*, 2019.
- [31] Jianlan Luo, Zheyuan Hu, Charles Xu, You Liang Tan, Jacob Berg, Archit Sharma, Stefan Schaal, Chelsea Finn, Abhishek Gupta, and Sergey Levine. SERL: A software suite for sample-efficient robotic reinforcement learning. In *International Conference on Robotics and Automation, ICRA*, 2024.
- [32] Tony Z. Zhao, Jianlan Luo, Oleg Sushkov, Rugile Pevceviciute, Nicolas Heess, Jon Scholz, Stefan Schaal, and Sergey Levine. Offline meta-reinforcement learning for industrial insertion. In *International Conference on Robotics and Automation, ICRA*, 2022.
- [33] Jianlan Luo, Perry Dong, Yuexiang Zhai, Yi Ma, and Sergey Levine. RLIF: interactive imitation learning as reinforcement learning. In *International Conference on Learning Representations, ICLR*, 2024.
- [34] Zheyuan Hu, Aaron Rovinsky, Jianlan Luo, Vikash Kumar, Abhishek Gupta, and Sergey Levine. REBOOT: reuse data for bootstrapping efficient real-world dexterous manipulation. In *Conference on Robot Learning, CoRL*, 2023.
- [35] Russell Mendonca, Emmanuel Panov, Bernadette Bucher, Jiuguang Wang, and Deepak Pathak. Continuously improving mobile manipulation with autonomous real-world RL. In *Conference on Robot Learning, CoRL*,

- 2024.
- [36] Henry Zhu, Abhishek Gupta, Aravind Rajeswaran, Sergey Levine, and Vikash Kumar. Dexterous manipulation with deep reinforcement learning: Efficient, general, and low-cost. In *International Conference on Robotics and Automation, ICRA*, 2019.
 - [37] Ziwen Zhuang, Zipeng Fu, Jianren Wang, Christopher G. Atkeson, Sören Schwertfeger, Chelsea Finn, and Hang Zhao. Robot parkour learning. In *Conference on Robot Learning, CoRL*, 2023.
 - [38] Jan Peters and Stefan Schaal. Reinforcement learning by reward-weighted regression for operational space control. In *International Conference on Machine Learning, ICML*, 2007.
 - [39] Henry Zhu, Justin Yu, Abhishek Gupta, Dhruv Shah, Kristian Hartikainen, Avi Singh, Vikash Kumar, and Sergey Levine. The ingredients of real world robotic reinforcement learning. In *International Conference on Learning Representations, ICLR*, 2020.
 - [40] Rishabh Agarwal, Max Schwarzer, Pablo Samuel Castro, Aaron C. Courville, and Marc G. Bellemare. Reincarnating reinforcement learning: Reusing prior computation to accelerate progress. In *Neural Information Processing Systems, NeurIPS*, 2022.
 - [41] Rafael Rafailov, Kyle Beltran Hatch, Victor Kolev, John D. Martin, Mariano Phielipp, and Chelsea Finn. MOTO: offline pre-training to online fine-tuning for model-based robot learning. In *Conference on Robot Learning, CoRL*, 2023.
 - [42] Aravind Rajeswaran, Vikash Kumar, Abhishek Gupta, Giulia Vezzani, John Schulman, Emanuel Todorov, and Sergey Levine. Learning complex dexterous manipulation with deep reinforcement learning and demonstrations. In *Robotics: Science and Systems, RSS*, 2018.
 - [43] Ashvin Nair, Bob McGrew, Marcin Andrychowicz, Wojciech Zaremba, and Pieter Abbeel. Overcoming exploration in reinforcement learning with demonstrations. In *International Conference on Robotics and Automation, ICRA*, 2018.
 - [44] Xing Fang, Qichao Zhang, Haoran Li, and Dongbin Zhao. Consistency policy with categorical critic for autonomous driving. In *International Conference on Autonomous Agents and Multiagent Systems, AAMAS*, 2025.
 - [45] Aaditya Prasad, Kevin Lin, Jimmy Wu, Linqi Zhou, and Jeannette Bohg. Consistency policy: Accelerated visuomotor policies via consistency distillation. In *Robotics: Science and Systems, RSS*, 2024.
 - [46] Haoran Li, Yaocheng Zhang, Haowei Wen, Yuanheng Zhu, and Dongbin Zhao. Stabilizing diffusion model for robotic control with dynamic programming and transition feasibility. *IEEE Transactions on Artificial Intelligence*, 5(9):4585–4594, 2024.
 - [47] Dibya Ghosh, Homer Rich Walke, Karl Pertsch, Kevin Black, Oier Mees, Sudeep Dasari, Joey Hejna, Tobias Kreiman, Charles Xu, Jianlan Luo, You Liang Tan, Lawrence Yunliang Chen, Quan Vuong, Ted Xiao, Panag R. Sanketi, Dorsa Sadigh, Chelsea Finn, and Sergey Levine. Octo: an open-source generalist robot policy. In *Robotics: Science and Systems, RSS*, 2024.
 - [48] Haoran Li, Zhennan Jiang, Yuhui Chen, and Dongbin Zhao. Generalizing consistency policy to visual RL with prioritized proximal experience regularization. In *Neural Information Processing Systems, NeurIPS*, 2024.
 - [49] Huihan Liu, Soroush Nasiriany, Lance Zhang, Zhiyao Bao, and Yuke Zhu. Robot learning on the job: Human-in-the-loop autonomy and learning during deployment. In *Robotics: Science and Systems, RSS*, 2023.
 - [50] Cheng Chi, Siyuan Feng, Yilun Du, Zhenjia Xu, Eric Cousineau, Benjamin Burchfiel, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. In *Robotics: Science and Systems, RSS*, 2023.
 - [51] Xinghang Li, Peiyan Li, Minghuan Liu, Dong Wang, Jirong Liu, Bingyi Kang, Xiao Ma, Tao Kong, Hanbo Zhang, and Huaping Liu. Towards generalist robot policies: What matters in building vision-language-action models. *arXiv preprint arXiv:2412.14058*, 2024.
 - [52] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. LoRA: low-rank adaptation of large language models. In *International Conference on Learning Representations, ICLR*, 2022.

附录

A. 算法说明

ConRFT 的完整流程如算法 1 所示。

Algorithm 1 Procedure of ConRFT

Require: A pre-trained VLA model $\pi_{\theta,\psi}$ with VLA parameter ϕ and a consistency head parameter ψ . A critic model Q with parameter θ . A pre-collected dataset $\mathcal{D}$ including 20-30 demonstrations. Initialize batch size B . Randomly initialize the action head ψ and the critic model θ

Stage I: Offline fine-tuning with Cal-ConRFT

for each offline training step **do**

 Sample (s_t, a_t, r_t, s_{t+1}) of $batch_size$ from $\mathcal{D}$

 Update the action head ψ and the critic model θ by Equation 1 and Equation 3.

end for

Stage II: Online fine-tuning with HIL-ConRFT

Start Policy Learning Thread:

Wait until The number of transitions in $\mathcal{R}$ is at least 100

for each online training step **do**

 Sample (s_t, a_t, r_t, s_{t+1}) of $\frac{B}{2}$ from $\mathcal{D}$ and $\mathcal{R}$

 Combine both minibatches to form batch of size B

 Update the action head ψ and the critic model θ by Equation 4 and Equation 5.

end for

Start Interaction Thread:

for each interaction step **do**

if no human intervention **then**

 Take action $a_t \sim \pi_{\psi}(\cdot|s_t)$

 Store transition (s_t, a_t, r_t, s_{t+1}) in $\mathcal{R}$

else

 Take action a_{intv}

 Store transition $(s_t, a_{intv}, r_t, s_{t+1})$ in $\mathcal{D}$

end if

end for

B. 任务描述、设置与策略训练细节

本节中，我们提供每个任务的硬件设置和训练细节。6 维动作空间指 6 维末端执行器增量位姿，7 维动作空间包括 6 维末端执行器增量位姿和 1 维夹爪控制动作。所有任务的学习率为 $3e-4$ ，批大小为 256。对于用于微调 VLA 模型的一致性策略，我们设置 $k \in [0.002, 80.0]$ 和子区间数量 $M = 40$ ，其中子区间边界由公式 $k_i = (\epsilon 1^{-\rho} + \frac{i-1}{M-1}(T 1^{-\rho} - \epsilon 1^{-\rho}))^{\rho}$ ，确定，其中 $\rho = 7$ 。网络基于 2 层多层感知机 (MLP)，隐藏层大小为 256，使用 Mish 函数作为激活函数。对于扩散策略，我们使用扩散步数 $K = 5$ ，a 余弦贝塔调度、Resnet 18 和 LN_{Resnet} 架构，隐藏层大小为 256， $n = 3$ 个块。

对于所有任务的奖励，当任务完成时给予 +10 奖励，每一步给予 -0.05 奖励。对于使用 DQN 网络进行夹爪控制的 HIL-SERL，每当策略打开/关闭夹爪时给予 a -0.2 奖励。a) 拾取香蕉：该任务涉及拾取篮子中的香蕉并将其放在绿色盘子上，需要控制夹爪移动水果，如图 5 所示。它要求策略抓取并放置香蕉，确保其完好无损，同时避免与周围环境（如篮子）发生碰撞。我们在表 V 中报告了该任务策略训练的更多具体细节。VLA 模型的任务描述为“将黄色香蕉放在绿色盘子上。”

Parameter	Value
Action space	7-dimensional
Initial offline demonstrations	20
Max episode length	100
Reset method	Human reset
Randomization range	3 cm in x and y
(α, β, η) for offline fine-tuning	(0.01, 1.0, 0.1)
(β, η) for online fine-tuning	(0.5, 1.0)

表 V：拾取香蕉任务的策略训练细节。

b) 放置勺子：该任务涉及拾取勺子并将其放在蓝色桌布上，需要夹爪抓取并放置勺子，如图 5 所示。挑战在于抓取勺子所需的控制。我们在表 VI 中报告了该任务策略训练的更多具体细节。

VLA 模型的任务描述为“将勺子放在蓝色毛巾上。”

Parameter	Value
Action space	7-dimensional
Initial offline demonstrations	20
Max episode length	100
Reset method	Human reset
Randomization range	3 cm in x and y
(α, β, η) for offline fine-tuning	(0.01, 1.0, 0.1)
(β, η) for online fine-tuning	(0.5, 1.0)

表 VI：放置勺子任务的策略训练细节。

c) 打开抽屉：该任务涉及通过抓取把手并向外拉动来打开抽屉，如图 5 所示。它要求策略能够牢固地握住把手，并施加正确的力来打开抽屉，同时不损坏铰链或周围区域。我们在表 VII 中报告了该任务策略训练的更多具体细节。VLA 模型的任务描述为“打开抽屉。”

Parameter	Value
Action space	6-dimensional
Initial offline demonstrations	20
Max episode length	100
Reset method	Script reset
Randomization range	3 cm in y and x
(α, β, η) for offline fine-tuning	(0.01, 1.0, 0.1)
(β, η) for online fine-tuning	(0.5, 1.0)

表 VII：打开抽屉任务的策略训练细节。

d) 拾取面包：该任务涉及拾取一片面包并将其放入烤面包机中，这需要控制夹爪以准确定位面包而不损坏它，如图 5 所示。挑战在于将面包与烤面包机的插槽对齐并降低它，避免与烤面包机或周围环境发生碰撞。我们在表 VIII 中报告了该任务策略训练的更多具体细节。

VLA 模型的任务描述为“将面包放入灰色烤面包机中。”

Parameter	Value
Action space	7-dimensional
Initial offline demonstrations	30
Max episode length	100
Reset method	Human reset
Randomization range	2 cm in x and y
(α, β, η) for offline fine-tuning	(0.01, 1.0, 0.1)
(β, η) for online fine-tuning	(0.5, 1.0)

表 VIII：拾取面包任务的策略训练细节。

e) 打开烤面包机：该任务涉及按下烤面包机上的按钮以启动烘烤过程，如图 5 所示。它要求精确控制夹爪以避免滑动或施加过大的力，同时确保以受控且一致的方式按下按钮。我们在表 IX 中报告了该任务策略训练的更多具体细节。

VLA 模型的任务描述为“按下黑色按钮并打开烤面包机。”

Parameter	Value
Action space	6-dimensional
Initial offline demonstrations	20
Max episode length	100
Reset method	Script reset
Randomization range	2 cm in y and z
(α, β, η) for offline fine-tuning	(0.01, 1.0, 0.1)
(β, η) for online fine-tuning	(0.5, 1.0)

表 IX：打开烤面包机任务的策略训练细节。

f) 放置面包：该任务涉及从烤面包机中取出一片烤好的面包，并将其放置在一个白色盘子上，如图 5 所示。挑战在于抓取面包时需要精确控制，以避免压碎或损坏面包。

夹爪必须小心地将面包从烤面包机槽中移出，同时避免接触烤面包机的边缘或附近其他物体。我们在表 X 中报告了该任务策略训练的更多具体细节。视觉语言动作模型的任务描述为“将面包放在白色盘子上。”

Parameter	Value
Action space	7-dimensional
Initial offline demonstrations	30
Max episode length	120
Reset method	Human reset
Randomization range	2 cm in x and y
(α, β, η) for offline fine-tuning	(0.01, 1.0, 0.1)
(β, η) for online fine-tuning	(0.5, 1.0)

表 X：放置面包任务的策略训练细节。

g) 插入轮子：该任务涉及通过将销钉插入相应槽孔来为椅座安装轮子，如图 5 所示。这是一个接触密集型任务，需要精确控制以确保销钉与槽孔正确对齐。由于销钉与槽孔之间的公差很小且接触动力学复杂，该任务的复杂度增加，使其成为一个对精度和控制要求极高的任务。我们在表 XI 中报告了该任务策略训练的更多具体细节。视觉语言动作模型的任务描述为“将黑色轮子插入灰色椅座。”

Parameter	Value
Action space	7-dimensional
Initial offline demonstrations	30
Max episode length	100
Reset method	Human reset
Randomization range	2 cm in x and y
(α, β, η) for offline fine-tuning	(0.01, 1.0, 0.1)
(β, η) for online fine-tuning	(0.5, 1.0)

表 XI：插入轮子任务的策略训练细节。

h) 悬挂中国结：该任务涉及将一个中国结挂在钩子上，这需要对柔软且具有动态特性的物体进行精细操作，如图 5 所示。该任务需要精细的灵巧性来处理中国结的柔软主体，并在将其挂到钩子上的过程中保持其结构。

该任务涉及处理柔软物体操作的动力学问题，其中保持一致的接触和适当的张力是成功的关键。我们在表 XII 中报告了该任务策略训练的更多具体细节。视觉语言动作模型的任务描述为“将中国结挂在钩子上。”

Parameter	Value
Action space	7-dimensional
Initial offline demonstrations	30
Max episode length	100
Reset method	Human reset
Randomization range	3 cm in y and z
(α, β, η) for offline fine-tuning	(0.01, 1.0, 0.1)
(β, η) for online fine-tuning	(0.5, 1.0)

表 XII：悬挂中国结任务的策略训练细节。

C. 更多实验结果 本节中，我们提供 HIL-ConRFT 在所有任务上的全部策略学习曲线，如图 6 所示。



图 5：硬件设置与相机视角示意图。我们给出了本文所有真实世界任务的硬件设置及对应相机视角的图示，包括：a) 拾取香蕉，b) 放置勺子，c) 打开抽屉，d) 拾取面包，e) 打开烤面包机，f) 放置面包，g) 插入轮子，h) 手持中国结。




图 6：所有任务在线训练期间的学习曲线。本图展示了成功率、干预率和回合长度，以超过 20 个回合的滑动平均值显示。