

扩散策略：通过动作扩散的视觉运动策略学习

Cheng Chi^{*1}, Zhenjia Xu^{*1}, Siyuan Feng², Eric Cousineau², Yilun Du³, Benjamin Burchfiel², Russ Tedrake^{2,3}, Shuran Song^{1,4}

摘要

本文提出扩散策略，一种通过将机器人的视觉运动策略表示为条件去噪扩散过程来生成机器人行为的新方法。我们在来自 4 个不同机器人操作基准的 15 项任务上对扩散策略进行基准测试，发现其始终优于现有最先进的机器人学习方法，平均提升 46.9%。扩散策略学习动作分布得分函数的梯度，并在推理过程中通过一系列随机朗之万动力学步骤对该梯度场进行迭代优化。我们发现，扩散公式在用于机器人策略时具有强大的优势，包括优雅地处理多模态动作分布、适用于高维动作空间以及展现出令人印象深刻的训练稳定性。为了充分释放扩散模型在物理机器人视觉运动策略学习中的潜力，本文提出了一系列关键技术贡献，包括引入滚动时域控制、视觉条件化和时间序列扩散变换器。我们希望这项工作能够激发新一代策略学习技术，使其能够利用扩散模型强大的生成建模能力。代码、数据和训练细节可在 diffusion-policy.cs.columbia.edu 获取。

关键词

模仿学习，视觉运动策略，操作




图 1. 策略表示。a) 具有不同类型动作表示的显式策略。b) 隐式策略学习以动作和观测为条件的能量函数，并优化动作以最小化能量景观。c) 扩散策略通过学习的梯度场将噪声细化为动作。该公式提供稳定的训练，使学习到的策略能够准确建模多模态动作分布，并适应高维动作序列。

1 引言

从演示中学习策略，在其最简单的形式下，可以表述为学习将观测映射到动作的监督回归任务。然而在实践中，预测机器人动作的独特性质——例如多模态分布的存在、序列相关性以及高精度的要求——使得该任务与其他监督学习问题相比具有独特性和挑战性。先前的工作试图通过探索不同的动作表示（图 1a）来应对这一挑战——使用高斯混合模型（Mandlekar 等人，2021 年）、量化动作的类别表示（Shafiuallah 等人，2022 年），或者通过切换策略表示（图 1b）——从显式到隐式以更好地捕捉多模态分布（Florence 等人，2021 年；Wu 等人，2020 年）。在这项工作中，我们试图通过引入一种新形式的机器人视觉运动策略来应对这一挑战，该策略

通过“机器人动作空间上的条件去噪扩散过程（Ho 等人，2020 年）”生成行为，即扩散策略。在这种表述中，策略不是直接输出动作，而是以视觉观测为条件，在 K 次去噪迭代中推断动作得分梯度（图 1c）。这种表述使机器人策略能够继承扩散模型的几个关键特性——显著提升性能。

- 表达多模态动作分布。通过学习动作得分函数的梯度（Song 和 Ermon，2019 年）并在该梯度场上执行随机朗之万动力学采样，扩散策略可以表达任意可归一化的分布（Neal 等人，2011 年），其中包括多模态动作分布，这是策略学习中的一个众所周知的挑战。

- **高维输出空间。**正如其令人印象深刻的图像生成结果所证明的，扩散模型在高维输出空间上表现出极佳的可扩展性。这一特性使策略能够联合推断一系列未来动作，而非单步动作，这对于鼓励时间动作一致性和避免短视规划至关重要。

- **稳定的训练。**训练基于能量的策略通常需要负采样来估计难以处理的归一化常数，这已知会导致训练不稳定 (Du 等人, 2020; Florence 等人, 2021)。扩散策略通过学习能量函数的梯度绕过了这一要求，从而在保持分布表达力的同时实现稳定训练。

我们的主要贡献是将上述优势引入机器人领域，并展示其在复杂的真实世界机器人操作任务上的有效性。为了成功地扩散模型用于视觉运动策略学习，我们提出以下技术贡献，以提升扩散策略的性能并释放其在物理机器人上的全部潜力：

- **闭环动作序列。**我们将策略预测高维动作序列的能力与滚动时域控制相结合，以实现稳健执行。这种设计允许策略以闭环方式持续重新规划其动作，同时保持时间动作一致性——在长时域规划与响应性之间取得平衡。

- **视觉条件化。条件扩散** We introduce a vision-policy, 其中视觉观测被视为条件而非联合数据分布的一部分。在这种表述下，策略只需提取一次视觉表示，而无需考虑去噪迭代次数，这大幅减少了计算量并实现了实时动作推理。

- **时间序列扩散 Transformer。**我们提出一种新的基于 Transformer 的扩散网络，该网络最小化了典型基于 CNN 模型的过度平滑效应，并在需要高频动作变化和速度控制的任務上达到了最先进的性能。

我们在行为克隆范式下，系统地评估了扩散策略在来自 4 个不同基准 (Florence 等人, 2021; Gupta 等人, 2019; Mandlkar 等人, 2021; Shafiullah 等人, 2022) 的 15 个任务上的表现。评估包括模拟和真实环境、2 自由度到 6 自由度的动作、单任务和多任务基准、全驱动和欠驱动系统、刚性和流体物体，以及由单个和多个用户收集的演示数据。经验上，我们发现所有基准上性能一致提升，平均改进 46.9%，

为扩散策略 (Diffusion Policy) 的有效性提供了有力证据。我们还进行了详细分析，以仔细考察所提算法的特性及关键设计决策的影响。本文是会议论文 Chi 等人 (2023) 的扩展版本。我们从以下几个方面扩展了本文内容：

- 新增一节讨论扩散策略与控制理论之间联系的讨论部分。见第 4.5 节。

- 在仿真中增加了关于替代网络架构设计以及不同预训练和微调范式的消融研究，见第 5.4 节。

- 在第 7 节中扩展了真实世界实验结果，增加了三个双手操作任务，包括打蛋器、垫子展开和叠衬衫。

代码、数据和训练细节已公开，以便复现我们的结果：
diffusion-policy.cs.columbia.edu。

2 扩散策略公式化

我们将视觉运动机器人策略公式化为去噪扩散概率模型 (Denoising Diffusion Probabilistic Models, DDPMs)，参见 Ho 等人 (2020)。关键的是，扩散策略能够表达复杂的多模态动作分布，并具有稳定的训练行为——几乎不需要针对特定任务的超参数调整。以下各节将更详细地描述 DDPMs，并解释如何将其适配以表示视觉运动策略。

2.1 去噪扩散概率模型

去噪扩散概率模型 (DDPM) 是一类生成模型，其输出生成过程被建模为去噪过程，通常称为随机朗之万动力学 (Stochastic Langevin Dynamics) Welling and Teh (2011)。从 高斯噪声中采样的 $\mathbf{x}^K$ 开始，DDPM 执行 K 次去噪迭代，产生一系列噪声水平递减的中间动作 $\mathbf{x}^k, \mathbf{x}^{k-1} \dots \mathbf{x}^0$ ，直到形成期望的无噪声输出 $\mathbf{x}^0$ 。该过程遵循方程

$$\mathbf{x}^{k-1} = \alpha(\mathbf{x}^k - \gamma \epsilon_\theta(\mathbf{x}^k, k) + \mathcal{N}(0, \sigma^2 I)), \quad (1)$$

其中 ϵ_θ 是噪声预测网络，其参数 θ 将通过学习进行优化， $\mathcal{N}(0, \sigma^2 I)$ 是每次迭代添加的高斯噪声。上述方程 1 也可以解释为单个含噪梯度下降步骤：

$$\mathbf{x}' = \mathbf{x} - \gamma \nabla E(\mathbf{x}), \quad (2)$$

其中噪声预测网络 $\epsilon_\theta(\mathbf{x}, k)$ 有效地预测梯度场 $\nabla E(\mathbf{x})$ ， γ 是学习率。选择 α, γ, σ 作为迭代步 k 的函数，也称为噪声调度，可以解释为梯度下降过程中的学习率调度。已证明略小于 1 的 α 可提高稳定性 Ho et al. (2020)。关于噪声调度的细节将在第 3.3 节讨论。




图 2. 扩散策略概述 a) 通用公式。在时间步 t ，策略以最新的 T_o 步观测数据 O_t 作为输入，并输出 T_a 步动作 A_t 。b) 在基于卷积神经网络 (CNN) 的扩散策略中，观测特征 O_t 的 FiLM (特征级线性调制) Perez et al. (2018) 条件化被逐通道应用于每个卷积层。从高斯噪声中采样的 A_t^K 开始，减去噪声预测网络 ϵ_θ 的输出，重复 K 次得到 A_t^1 ，即去噪后的动作序列。c) 在基于变换器 (Transformer) Vaswani et al. (2017) 的扩散策略中，观测 O_t 的嵌入被传递到每个变换器解码器块的多头交叉注意力层。每个动作嵌入被限制为仅关注自身及之前的动作嵌入 (因果注意力)，使用图示的注意力掩码。

2.2 DDPM 训练

训练过程从数据集中随机抽取未修改的样本 $\mathbf{x}^0$ 开始。对于每个样本，随机选择一个去噪迭代 k ，然后采样一个具有适当方差的随机噪声 ϵ^k 用于迭代 k 。噪声预测网络被要求从添加了噪声的数据样本中预测噪声。

$$\mathcal{L} = \text{MSE}(\epsilon^k, \epsilon_\theta(\mathbf{x}^0 + \epsilon^k, k)) \quad (3)$$

如 Ho 等人 (2020) 所示，最小化式 3 中的损失函数同时也最小化了数据分布 $p(\mathbf{x}^0)$ 与利用式 1 从去噪扩散概率模型 (DDPM) $q(\mathbf{x}^0)$ 采样所得分布之间 KL 散度的变分下界。

2.3 面向视觉运动策略学习的扩散模型

尽管去噪扩散概率模型通常用于图像生成 (其中 $\mathbf{x}$ 为图像)，本文利用去噪扩散概率模型学习机器人视觉运动策略。这需要对公式进行两处主要修改：1. 将输出 $\mathbf{x}$ 改为表示机器人动作。2. 使去噪过程以输入观测 O_t 为条件。以下段落分别讨论这些修改，图 2 展示了总体框架。闭环动作序列预测：有效的动作表示应鼓励长时域规划中的时序一致性与平滑性，同时允许对意外观测做出快速反应。为实现这一目标，本文在重新规划前，固定时长内执行扩散模型生成的动作序列预测。具体而言，在时间步 t ，策略以最近 T_o 步观测数据 O_t 作为输入，预测 T_p 步动作，其中 T_a 步动作在机器人上执行且不重新规划。此处定义 T_o 为观测时域， T_p 为动作预测时域， T_a 为动作执行时域。这既鼓励了时序动作一致性，又保持了响应能力。关于 T_a 影响的更多细节将在第 4.3 节讨论。本文的公式还允许采用滚动时域控制 (Mayne 和 Michalska, 1988)，通过将上一动作序列预测作为下一次推理的初始值，进一步提升动作平滑性。

视觉观测条件化： 本文利用去噪扩散概率模型近似条件分布 $p(A_t|O_t)$ ，而非 Janner 等人 (2022a) 在规划中使用的联合分布 $p(A_t, O_t)$ 。该公式使模型能够根据观测预测动作，无需推断未来状态，从而加快扩散过程并提高生成动作的准确率。为捕捉条件分布 $p(A_t|O_t)$ ，将式 1 修改为：

$$A_t^{k-1} = \alpha(A_t^k - \gamma \epsilon_\theta(O_t, A_t^k, k) + \mathcal{N}(0, \sigma^2 I)) \quad (4)$$

训练损失由式 3 修改为：

$$\mathcal{L} = \text{MSE}(\epsilon^k, \epsilon_\theta(O_t, A_t^0 + \epsilon^k, k)) \quad (5)$$

从去噪过程输出中排除观测特征 O_t 显著提高了推理速度，并更好地适应实时控制。这也有助于实现视觉编码器的端到端训练。视觉编码器的细节将在第 3.2 节描述。

3 关键设计决策

在本节中，我们描述了扩散策略的关键设计决策及其使用神经网络架构对 ϵ_θ 的具体实现。

3.1 网络架构选项

第一个设计决策是为 ϵ_θ 选择神经网络架构。在这项工作中，我们考察了两种常见的网络架构类型，卷积神经网络 (CNNs) Ronneberger 等人 (2015) 和变换器 (Transformers) Vaswani 等人 (2017)，并比较了它们的性能和训练特性。请注意，噪声预测网络 ϵ_θ 的选择独立于视觉编码器，视觉编码器将在第 3.2 节中描述。基于 CNN 的扩散策略我们采用了 Janner 等人 (2022b) 的一维时间 CNN，并做了一些修改：首先，我们仅通过特征线性调制 (FiLM) 以观测特征 O_t 为条件来建模条件分布 $p(A_t|O_t)$ ，从而生成动作。

Perez et al. (2018) as well as denoising iteration k , shown in Fig 2 (b). Second, we only predict the action trajectory instead of the concatenated observation action trajectory. Third, we removed inpainting-based goal state conditioning due to incompatibility with our framework utilizing a receding prediction horizon. However, goal conditioning is still possible with the same FiLM conditioning method used for observations.

在实践中，我们发现基于 CNN 的主干网络在大多数任务上开箱即用，无需太多超参数调整。然而，当期望的动作序列随时间快速且剧烈变化时（例如速度指令动作空间），其表现不佳，这可能是由于时间卷积的归纳偏置倾向于低频信号 Tancik 等人 (2020)。

时间序列扩散变换器 为了减少 CNN 模型中的过度平滑效应 Tancik 等人 (2020)，我们引入了一种新颖的基于变换器的 DDPM，它采用了 minGPT Shafiullah 等人 (2022) 的变换器架构进行动作预测。带噪声的动作 A_t^k 作为输入令牌传递给变换器解码器块，扩散迭代 k 的正弦嵌入作为第一个令牌前置。观测 O_t 通过共享 MLP 转换为观测嵌入序列，然后作为输入特征传递给变换器解码器堆栈。“梯度” $\epsilon_\theta(O_t, A_t^k, k)$ 由解码器堆栈的每个对应输出令牌预测。

在我们基于状态的实验中，大多数性能最佳的策略都是通过变换器主干网络实现的，尤其是在任务复杂度和动作变化率较高的情况下。然而，我们发现变换器对超参数更敏感。变换器训练的难度 Liu 等人 (2020) 并非扩散策略所独有，未来可能通过改进的变换器训练技术或增加数据规模来解决。

建议。一般来说，我们建议在新任务中首先尝试基于卷积神经网络的扩散策略实现。如果由于任务复杂度高或动作变化速率快而导致性能不佳，则可以考虑使用时序扩散 Transformer 公式，以在增加额外调参成本的情况下潜在地提升性能。

3.2 视觉编码器

视觉编码器将原始图像序列映射为潜在嵌入 O_t ，并与扩散策略端到端联合训练。不同相机视角使用独立的编码器，每个时间步的图像独立编码后拼接形成 O_t 。我们采用标准的 ResNet-18（无预训练）作为编码器，并做如下修改：1) 将全局平均池化替换为空间 Softmax 池化以保留空间信息 Mandlekar 等人 (2021)。2) 将批归一化替换为组归一化 Wu 和 He (2018) 以保证训练稳定。当归一化层与指数移动平均 He 等人 (2020)（常用于去噪扩散概率模型）结合使用时，这一点尤为重要。

3.3 噪声调度

噪声调度由 σ, α, γ 和加性高斯噪声 ϵ^k 作为 k 的函数定义，已被广泛研究 Ho 等人 (2020)；Nichol 和 Dhariwal (2021)。底层噪声调度控制扩散策略捕获动作信号高频和低频特征的程度。在我们的控制任务中，我们通过实验发现 iDDPM Nichol 和 Dhariwal (2021) 中提出的平方余弦调度最适合我们的任务。

3.4 加速推理以实现实时控制

我们将扩散过程用作机器人的策略，因此快速推理速度对于闭环实时控制至关重要。去噪扩散隐式模型 (DDIM) 方法 Song 等人 (2021) 解耦了训练和推理中的去噪迭代次数，从而使算法可以在推理时使用更少的迭代来加速过程。在我们的真实世界实验中，使用 DDIM 进行 100 次训练迭代和 10 次推理迭代，在 Nvidia 3080 GPU 上实现了 0.1 秒的推理延迟。

4 扩散策略的有趣特性

在本节中，我们提供关于扩散策略及其相对于其他策略表示形式的优势的一些洞见和直觉。

4.1 建模多模态动作分布

在人类演示中建模多模态分布的挑战已在行为克隆文献中被广泛讨论 Florence et al. (2021); Shafiullah et al. (2022); Mandlekar et al. (2021)。扩散策略能够自然且精确地表达多模态分布，这是其关键优势之一。直观上，扩散策略动作生成中的多模态性来源于两个方面——底层的随机采样过程和随机初始化。在随机朗之万动力学中，每次采样过程开始时从标准高斯分布中抽取初始样本 A_t^K ，这有助于为最终动作预测 A_t^0 指定不同的可能收敛盆地。随后，该动作被进一步随机优化，在大量迭代中加入高斯扰动，使得单个动作样本能够收敛并在不同的多模态动作盆地之间移动。图 3 展示了扩散策略在平面推动任务（Push T，下文介绍）中的多模态行为示例，该测试场景没有显式演示。

4.2 与位置控制的协同作用

我们发现，采用位置控制动作空间的扩散策略始终优于采用速度控制的扩散策略，如图 4 所示。这一令人惊讶的结果与近期大多数行为克隆工作形成对比，后者通常依赖速度控制 Mandlekar et al. (2021); Shafiullah et al. (2022); Zhang et al. (2018); Florence et al. (2019); Mandlekar et al. (2020b,a)。我们




图 3. 多模态行为。在给定状态下，末端执行器（蓝色）可以向左或向右推动方块。扩散策略学习两种模式，并在每次展开中只承诺一种模式。相比之下，LSTM-GMM Mandelkar et al. (2021) 和 IBC Florence et al. (2021) 偏向于一种模式，而 BET Shafiullah et al. (2022) 由于缺乏时间动作一致性而未能承诺单一模式。动作由最佳检查点展开 40 步生成。

推测造成这种差异的主要原因有两个：首先，位置控制模式下动作多模态性比速度控制时更为显著。由于扩散策略（Diffusion Policy）比现有方法更能表达动作多模态性，我们推测它本质上受此缺点的影响比现有方法更小。此外，位置控制受复合误差效应的影响小于速度控制，因此更适合动作序列预测（如下一节所述）。因此，扩散策略既较少受到位置控制主要缺点的影响，又能更好地利用位置控制的优势。




图 4. 速度控制与位置控制对比。从速度控制切换到位置控制时的性能差异。虽然 BCRNN 和 BET 的性能均下降，但扩散策略能够利用位置控制的优势并提升其性能。

4.3 动作序列预测的优势

大多数策略学习方法通常避免序列预测，因为难以从高维输出空间中有效采样。例如，IBC 在非平滑能量景观下难以有效采样高维动作空间。同样，BC-RNN 和 BET 难以确定动作分布中存在的模式数量（GMM 或 k-means 步骤所需）。相比之下，去噪扩散概率模型（DDPM）在输出维度上具有良好的可扩展性，同时不牺牲模型的表达能力，这一点已在许多图像生成应用中得到证明。利用这一能力，扩散策略以高维动作序列的形式表示动作，从而自然地解决了以下问题：

• 时间动作一致性：以图 3 为例。

为了将 T 形块从底部推入目标，策略可以从左侧或右侧绕过 T 形块。然而，假设序列中的每个动作被预测为独立的多模态分布（如 BC-RNN 和 BET 中所做），那么连续动作可能来自不同的模式，导致动作在两条有效轨迹之间交替抖动。

• 对空闲动作的鲁棒性：当演示暂停时会出现空闲动作，导致产生一系列相同的位置动作或接近零速度的动作。这在遥操作中很常见，有时对于倒液体等任务是必需的。然而，单步策略很容易过拟合这种暂停行为。例如，当训练中没有明确移除空闲动作时，BC-RNN 和 IBC 在真实世界实验中经常卡住。




图 5. 扩散策略消融实验。Y 轴显示每个任务相对于最大值的成功率变化（差值）。左图：选择动作视野时在时序一致性和响应性之间的权衡。右图：采用位置控制的扩散策略对延迟具有鲁棒性。延迟定义为从最后一帧观测到第一个可执行动作之间的步数。

4.4 训练稳定性

虽然理论上 IBC 应该具有与扩散策略类似的优势，但由于 IBC 固有的训练不稳定性（Tα 等人，2022），在实践中实现可靠且高性能的结果具有挑战性。图 6 显示了训练过程中的误差尖峰和评估性能不稳定，这使得超参数调整至关重要，检查点选择也变得困难。因此，Florence 等人（2021）评估每个检查点并报告性能最佳检查点的结果。在真实世界环境中，这种工作流程需要在硬件上评估许多策略才能选择最终策略。在此，我们讨论为什么扩散策略的训练似乎显著更稳定。隐式策略使用基于能量的模型（EBM）来表示动作分布：

$$p_{\theta}(\mathbf{a}|\mathbf{o}) = \frac{e^{-E_{\theta}(\mathbf{o}, \mathbf{a})}}{Z(\mathbf{o}, \theta)} \quad (6)$$

其中 $Z(\mathbf{o}, \theta)$ 是一个难以处理的归一化常数（关于 $\mathbf{a}$ ）。

为了训练隐式策略的 EBM，使用了 InfoNCE 风格的损失函数，这等同于公式 6 的负对数似然：

$$\mathcal{L}_{\text{InfoNCE}} = -\log\left(\frac{e^{-E_\theta(\mathbf{o}, \mathbf{a})}}{e^{-E_\theta(\mathbf{o}, \mathbf{a})} + \sum_{j=1}^{N_{\text{neg}}} e^{-E_\theta(\mathbf{o}, \tilde{\mathbf{a}}^j)}\right) \quad (7)$$

其中一组负样本 $\{\tilde{\mathbf{a}}^j\}_{j=1}^{N_{\text{neg}}}$ 用于估计难以处理的归一化常数 $Z(\mathbf{o}, \theta)$ 。在实践中，负采样的不准确性已知会导致 EBM 的训练不稳定 (Du 等人, 2020; Ta 等人, 2022)。扩散策略和 DDPM 通过建模公式 6 中相同动作分布的得分函数 (Song 和 Ermon, 2019)，完全回避了估计 $Z(\mathbf{a}, \theta)$ 的问题：

$$\nabla_{\mathbf{a}} \log p(\mathbf{a}|\mathbf{o}) = -\nabla_{\mathbf{a}} E_\theta(\mathbf{a}, \mathbf{o}) - \underbrace{\nabla_{\mathbf{a}} \log Z(\mathbf{o}, \theta)}_{=0} \approx -\varepsilon_\theta(\mathbf{a}, \mathbf{o}) \quad (8)$$

其中噪声预测网络 $\varepsilon_\theta(\mathbf{a}, \mathbf{o})$ 近似于得分函数的负值 $-\nabla_{\mathbf{a}} \log p(\mathbf{a}|\mathbf{o})$ Liu 等人 (2022)，该函数与归一化常数 $Z(\mathbf{o}, \theta)$ 无关。因此，扩散策略的推理 (公式 4) 和训练 (公式 5) 过程均不涉及对 $Z(\mathbf{o}, \theta)$ 的评估，从而使扩散策略的训练更加稳定。




图 6. 训练稳定性。左图：尽管能量函数的训练损失平稳下降，IBC 仍无法以不断提高的准确率推断训练动作。右图：IBC 的评估成功率出现振荡，导致难以选择检查点（使用仿真中的策略展开进行评估）。

4.5 与控制理论的联系

当任务非常简单时，扩散策略具有简单的极限行为；这可能使我们能够借助控制理论中的一些严谨理解。考虑我们希望控制的标准状态空间形式的线性动力系统：

$$\mathbf{s}_{t+1} = \mathbf{A}_t \mathbf{s}_t + \mathbf{B}_t \mathbf{a}_t + \mathbf{w}_t, \quad \mathbf{w}_t \sim \mathcal{N}(\mathbf{0}, \Sigma_w).$$

现在设想我们从线性反馈策略中获得演示（展开）：

$\mathbf{a}_t = -\mathbf{K}\mathbf{s}_t$ 。该策略可以通过求解线性最优控制问题（如线性二次调节器）获得。模仿该策略并不需要扩散的建模能力，但作为合理性检验，我们可以看到扩散策略确实做了正确的事情。

特别地，当预测时域为一个时间步时， $T_p = 1$ ，可以看出最小化以下目标的最优去噪器

$$\mathcal{L} = \text{MSE}(\varepsilon^k, \varepsilon_\theta(\mathbf{s}_t, -\mathbf{K}\mathbf{s}_t + \varepsilon^k, k)) \quad (9)$$

由下式给出

$$\varepsilon_\theta(\mathbf{s}, \mathbf{a}, k) = \frac{1}{\sigma_k} [\mathbf{a} + \mathbf{K}\mathbf{s}],$$

其中 σ_k 是去噪迭代 k 上的方差。此外，在推理时，DDIM 采样将收敛到 $\mathbf{a} = -\mathbf{K}\mathbf{s}$ 处的全局最小值。轨迹预测 ($T_p > 1$) 自然随之而来。为了将 $\mathbf{a}_{t+t'}$ 预测为 $\mathbf{s}_t$ 的函数，最优去噪器将产生 $\mathbf{a}_{t+t'} = -\mathbf{K}(\mathbf{A} - \mathbf{B}\mathbf{K})^{t'} \mathbf{s}_t$ ；所有涉及 $\mathbf{w}_t$ 的项在期望上为零。这表明，为了完美克隆依赖于状态的行为，学习者必须隐式学习一个（与任务相关的）动力学模型 Subramanian 和 Mahajan (2019)；Zhang 等人 (2020)。注意，如果被控对象或策略是非线性的，那么预测未来动作可能会变得显著更具挑战性，并再次涉及多模态预测。

5 评估


我们在来自 4 个基准的 15 个任务上系统地评估了扩散策略 Florence 等人 (2021)；Gupta 等人 (2019)；Mandlekar 等人 (2021)；Shafiullah 等人 (2022)。该评估套件包括仿真环境和真实环境、单任务和多任务基准、全驱动和欠驱动系统，以及刚性和流体对象。我们发现扩散策略在所有测试基准上一致地优于先前的最先进方法，平均成功率提升 46.9%。在以下各节中，我们概述每个任务、我们在该任务上的评估方法以及我们的关键结论。

5.1 仿真环境与数据集

Robomimic Mandlekar et al. (2021) is a large-scale robotic manipulation benchmark designed to study imitation learning and offline RL. The benchmark consists of 5 tasks with a proficient human (PH) teleoperated demonstration dataset for each and mixed proficient/non-proficient human (MH) 为其中 4 个任务（共 9 个变体）提供了演示数据集。对于每个变体，我们报告基于状态和基于图像的观测结果。每个任务的属性总结在表 3 中。**Push-T** 改编自 IBC Florence 等人 (2021)，要求用圆形末端执行器（蓝色）将 T 形块（灰色）推到固定目标（红色）。通过 T 形块和末端执行器的随机初始条件引入变化。该任务要求利用复杂且接触丰富的物体动力学，通过点接触精确推动 T 形块。

有两个变体：一个使用 RGB 图像观测，另一个使用从 T 形块真实姿态获得的 9 个二维关键点，两者都带有末端执行器位置的本体感知。

多模态推块 改编自 BET Shafiullah 等人 (2022)，该任务通过推动两个块来测试策略建模多模态动作分布的能力



	Lift		Can		Square		Transport		ToolHang	Push-T
	ph	mh	ph	mh	ph	mh	ph	mh	ph	ph
LSTM-GMM	1.00/0.96	1.00/0.93	1.00/0.91	1.00/0.81	0.95/0.73	0.86/0.59	0.76/0.47	0.62/0.20	0.67/0.31	0.67/0.61
IBC	0.79/0.41	0.15/0.02	0.00/0.00	0.01/0.01	0.00/0.00	0.00/0.00	0.00/0.00	0.00/0.00	0.00/0.00	0.90/0.84
BET	1.00/0.96	1.00/0.99	1.00/0.89	1.00/0.90	0.76/0.52	0.68/0.43	0.38/0.14	0.21/0.06	0.58/0.20	0.79/0.70
DiffusionPolicy-C	1.00/0.98	1.00/0.97	1.00/0.96	1.00/0.96	1.00/0.93	0.97/0.82	0.94/0.82	0.68/0.46	0.50/0.30	0.95/0.91
DiffusionPolicy-T	1.00/1.00	1.00/1.00	1.00/1.00	1.00/0.94	1.00/0.89	0.95/0.81	1.00/0.84	0.62/0.35	1.00/0.87	0.95/0.79

表 1. 行为克隆基准（状态策略）我们以（最大性能）/（最后 10 个检查点的平均值）的格式展示不同检查点选择方法的成功率，每个结果均在 3 个训练种子和 50 种不同环境初始条件（共 150 次）上取平均。LSTM-GMM 对应于 RoboMimic Mandlekar 等人（2021）中的 BC-RNN，我们复现后获得了略优于原论文的结果。我们的结果表明，扩散策略显著提升了全领域的最先进性能。

	Lift		Can		Square		Transport		ToolHang	Push-T
	ph	mh	ph	mh	ph	mh	ph	mh	ph	ph
LSTM-GMM	1.00/0.96	1.00/0.95	1.00/0.88	0.98/0.90	0.82/0.59	0.64/0.38	0.88/0.62	0.44/0.24	0.68/0.49	0.69/0.54
IBC	0.94/0.73	0.39/0.05	0.08/0.01	0.00/0.00	0.03/0.00	0.00/0.00	0.00/0.00	0.00/0.00	0.00/0.00	0.75/0.64
DiffusionPolicy-C	1.00/1.00	1.00/1.00	1.00/0.97	1.00/0.96	0.98/0.92	0.98/0.84	1.00/0.93	0.89/0.69	0.95/0.73	0.91/0.84
DiffusionPolicy-T	1.00/1.00	1.00/0.99	1.00/0.98	1.00/0.98	1.00/0.90	0.94/0.80	0.98/0.81	0.73/0.50	0.76/0.47	0.78/0.66

表 2. 行为克隆基准（视觉策略）性能报告格式与表 1 相同。除报告的最佳检查点性能外，我们还复现了 LSTM-GMM 的数值以获得完整评估。扩散策略表现出一致的性能提升，尤其是在 Transport 和 ToolHang 等复杂任务上。

Task	# Rob	# Obj	ActD	#PH	#MH	Steps	Img?	HiPrec
Simulation Benchmark								
Lift	1	1	7	200	300	400	Yes	No
Can	1	1	7	200	300	400	Yes	No
Square	1	1	7	200	300	400	Yes	Yes
Transport	2	3	14	200	300	700	Yes	No
ToolHang	1	2	7	200	0	700	Yes	Yes
Push-T	1	1	2	200	0	300	Yes	Yes
BlockPush	1	2	2	0	0	350	No	No
Kitchen	1	7	9	656	0	280	No	No
Realworld Benchmark								
Push-T	1	1	2	136	0	600	Yes	Yes
6DoF Pour	1	liquid	6	90	0	600	Yes	No
Peri Spread	1	liquid	6	90	0	600	Yes	No
Mug Flip	1	1	7	250	0	600	Yes	No

表 3. 任务总结。 # Rob: 机器人数量, #Obj: 物体数量, ActD: 动作维度, PH: 熟练人类演示, MH: 多人演示, Steps: 最大推演步数, HiPrec: 任务是否具有高精度要求。BlockPush 使用 1000 个脚本演示回合。

以任意顺序分成两个方块。演示数据由可访问真实状态信息的脚本预言机生成。该预言机随机选择一个初始方块进行推动，并将其移动到随机选择的方块中。然后将剩余的方块推入剩余的方块中。该任务包含无法由从观测到动作的单一函数映射建模的长时程多模态性。


无法由从观测到动作的单一函数映射建模。

Franka Kitchen 是评估模仿学习和离线强化学习方法学习多个长时程任务能力的常用环境。该环境由 Relay Policy Learning Gupta 等人（2019）提出，包含 7 个可交互物体，并附带一个包含 566 个演示的人类演示数据集，每个演示以任意顺序完成 4 个任务。目标是在不考虑顺序的情况下执行尽可能多的演示任务，展示短时程和长时程多模态性。


5.2 评估方法论

我们为每个基准上的每个基线方法呈现了所有可能来源中的最佳表现——我们复现的结果（LSTM-GMM）或论文中报告的原始数字（BET、IBC）。我们报告了最后 10 个检查点（每 50 个训练轮次保存一次）在 3 个训练种子和 50 个环境初始化 * 下的平均结果（总共平均 1500 次实验）。大多数任务的度量是成功率，除了 Push-T 任务使用目标区域覆盖率。此外，我们报告了

* 由于我们评估代码中的一个错误，robomimic 任务仅使用了 22 个环境初始化。这不会改变我们的结论，因为所有基线方法都以相同方式评估。



Block Push



Kitchen

	BlockPush		Kitchen			
	p1	p2	p1	p2	p3	p4
LSTM-GMM	0.03	0.01	1.00	0.90	0.74	0.34
IBC	0.01	0.00	0.99	0.87	0.61	0.24
BET	0.96	0.71	0.99	0.93	0.71	0.44
DiffusionPolicy-C	0.36	0.11	1.00	1.00	1.00	0.99
DiffusionPolicy-T	0.99	0.94	1.00	0.99	0.99	0.96

表 4. 多阶段任务（状态观测）。对于 PushBlock, px 是将 x 个方块推入目标的频率。对于 Kitchen, px 是与 x 个或更多物体（例如底部燃烧器）交互的频率。扩散策略表现更好，尤其是在困难度量上，如方块推动的 p2 和 Kitchen 的 p4，正如我们的结果所示。

对于 robomimic 和 Push-T 任务，报告最佳检查点的平均值，以与各自原始论文 Mandlekar 等人（2021）；Florence 等人（2021）的评估方法保持一致。所有基于状态的任务训练 4500 个训练轮次，基于图像的任务训练 3000 个训练轮次。每种方法使用其最佳动作空间进行评估：扩散策略使用位置控制，基线使用速度控制（动作空间的影响将在第 5.3 节详细讨论）。这些仿真基准的结果总结在表 1 和表 2 中。

5.3 关键发现

在我们的仿真基准研究中（表 1、2 和 4），扩散策略在状态和视觉观测下，在所有任务和变体上均优于替代方法，平均改进 46.9%。以下段落总结了关键点。扩散策略可以表达短时程多

模态。我们将短视界动作多模态定义为实现同一即时目标的多种方式，这在人类演示数据中普遍存在（Mandlekar 等人，2021）。在图 3 中，我们展示了推 T 任务中此类短视界多模态的案例研究。扩散策略学习以相等的概率从左侧或右侧接近接触点，而 LSTM-GMM（Mandlekar 等人，2021）和 IBC（Florence 等人，2021）表现出偏向一侧，BET（Shafiullah 等人，2022）则无法确定单一模式。扩散策略能够表达长视界多模态

性。长视界多模态是指以不一致的顺序完成不同的子目标。例如，在推块任务中推动特定块的顺序，或在厨房任务中与 7 个可能物体交互的顺序都是任意的。我们发现扩散策略能很好地应对此类多模态；它在两个任务上均大幅超越基线：推块任务的 p2 指标提升 32%，厨房任务的 p4 指标提升 213%。扩散策略能更好地利用位置控制。我们的消融实验（图 4）表明，选择位置

控制作为扩散策略的动作空间显著优于速度控制。然而，我们评估的基线方法在速度控制下表现最佳（这也反映在文献中，大多数现有工作报告使用速度控制动作空间（Mandlekar 等人，2021；Shafiullah 等人，2022；Zhang 等人，2018；Florence 等人，2019；Mandlekar 等人，2020b,a））。

动作视界的权衡。如第 4.3 节所述，动作视界大于 1 有助于策略预测一致的动作并补偿演示中的空闲部分，但视界过长会因反应时间变慢而降低性能。我们的实验证实了这一权衡（图 5 左），并发现 8 步的动作视界对我们测试的大多数任务是最佳的。

对延迟的鲁棒性。扩散策略采用滚动视界位置控制来预测未来的一系列动作。这种设计有助于解决由图像处理、策略推理和网络延迟引起的延迟差距。我们通过模拟延迟的消融实验表明，扩散策略在延迟高达 4 步时仍能保持峰值性能（图 5）。我们还发现速度控制比位置控制更易受延迟影响，这可能是由于误差累积效应。

扩散策略训练稳定。我们发现扩散策略的最优超参数在多数任务中基本一致。相比之下，IBC Florence 等人（2021）容易出现训练不稳定。该特性将在第 4.4 节讨论。


5.4 消融实验

我们在模拟 robomimic 方形任务上探索了替代视觉编码器设计决策。具体而言，我们评估了 3 种不同架构：ResNet-18、ResNet-34 He 等人（2016）和 ViT-B/16 Dosovitskiy 等人（2020）。对于每种架构，我们评估了 3 种不同训练策略：端到端从头训练、使用冻结的预训练视觉编码器、以及微调预训练视觉编码器（学习率相对于策略网络降低 10 倍）。我们使用 ImageNet-21k Ridnik 等人（2021）预训练 ResNet，使用 CLIP Radford 等人（2021）预训练 ViT-B/16。在 proficient-human（PH）数据集上的方形任务定量比较见表 5。

我们发现从头训练 ViT 具有挑战性（成功率仅 22%），可能由于数据量有限。我们还发现使用冻结的预训练视觉编码器训练性能较差，这表明扩散策略偏好的视觉表示不同于流行预训练方法所提供的表示。然而，我们发现以较小学习率（比扩散策略网络小 10 倍）微调预训练视觉编码器可获得最佳整体性能。对于 CLIP 训练的 ViT-B/16 尤其如此，仅训练 50 个轮次即达到 98% 成功率。总体而言，不同架构之间的最佳性能差异不大，尽管它们在理论容量上存在显著差距。我们预计在复杂任务上性能差距可能更加明显。

Architecture & Prertain Dataset	From Scratch	Pretrained	
		frozen	finetuning
Resnet18 (in21)	0.94	0.58	0.92
Resnet34 (in21)	0.92	0.40	0.94
ViT-base (clip)	0.22	0.70	0.98

表 5. 视觉编码器比较 所有模型均使用基于 CNN 的扩散策略在 robomimic 方形 (ph) 任务上训练。每个模型训练 500 个轮次，每 50 个轮次在 50 种不同环境初始条件下评估一次。



	人类	IBC	LSTM-GMM	扩散策略	演示	位置	速度	位置	速度
	T-E2E	ImgNet	R3M	E2E					
交并比	0.84	0.14	0.19	0.24	0.25	0.53	0.24	0.66	0.80
成功率%	1.00	0.00	0.20	0.10	0.65	0.15	0.80	0.95	时长
	55.8	31.7	22.9			20.3	56.3	41.6	47.3
						51.7	57.5		

表 6. 真实世界推 T 形块实验。a) 硬件设置。b) 任务示意图。机器人需要 1 ① 精确地将 T 形块推入目标区域，并 ② 将末端执行器移动到终点区域。c) 用于计算本表中交并比度量的真实最终状态。表：成功定义为最终状态交并比大于演示数据集中的最小交并比。平均回合时长以秒为单位。T-E2E 代表端到端训练的基于变换器的扩散策略。

6 真实世界评估

我们在两种硬件设置下的四个任务中评估了扩散策略 (Diffusion Policy) 的真实世界性能，每种设置的训练数据来自不同的演示者。在真实世界推压任务 (Push-T) 中，我们进行了消融实验，考察了扩散策略在两种架构选项和三种视觉编码器选项下的表现；同时，我们还与两种基线方法进行了基准对比，涵盖了位置控制和速度控制两种动作空间。在所有任务中，同时采用卷积神经网络 (CNN) 骨干和端到端训练的视觉编码器的扩散策略变体均取得了最佳性能。有关任务设置和参数的更多细节，请参见补充材料。

6.1 真实世界推物任务

现实世界中的推 T 任务 (Push-T) 比仿真版本显著更难，原因有三处修改：1. 现实世界的推 T 任务是多阶段的。它要求机器人首先 ① 将 T 形块推入目标区域，然后 ② 将末端执行器移动到指定的终点区域以避免遮挡。2. 策略需要进行精细调整，以确保 T 形块在前往终点区域之前完全进入目标区域，这带来了额外的短期多模态性。3. 交并比 (IoU) 度量是

在最后一步测量，而不是在所有步骤中取最大值。我们根据人类演示数据集中的最小交并比 (IoU) 度量来设定成功率阈值。基于 UR5 的实验设置如图 6 所示。扩散策略以 10 赫兹的频率预测机器人指令，然后将这些指令线性插值到 125 赫兹以供机器人执行。

结果分析。扩散策略 (Diffusion Policy) 的表现接近人类水平，成功率达 95%，平均交并比 (IoU) 为 0.8，而表现最佳的 IBC 和 LSTM-GMM 变体的成功率分别为 0% 和 20%，平均交并比为 0.84。图 7 从相同的初始条件出发，定性展示了每种方法的行为。我们观察到，阶段转换期间表现不佳是基线方法最常见的失败案例，原因在于这些阶段存在高度多模态性和模糊的决策边界。LSTM-GMM 在 20 次评估中有 8 次卡在 T 形块附近（第三行），而 IBC 在 20 次评估中有 6 次过早离开 T 形块（第四行）。由于任务要求，我们没有遵循从训练数据中移除空闲动作的常见做法，这也导致 LSTM 和 IBC 倾向于对小动作过拟合并在该任务中卡住。结果最好通过补充材料中的视频来欣赏。端到端与预训练视觉编码器我们测试了使用预训练视觉编码器 (ImageNet Deng 等人 (2009) 和 R3M Nair 等人 (2022)) 的扩散策略，结果见表 6。使用 R3M 的扩散策略成功率达到 80%，但与端到端训练的版本相比，预测的动作存在抖动，并且更容易卡住。使用 ImageNet 的扩散策略结果不太理想，动作突然且性能较差。我们发现，端到端训练仍然是将视觉观察融入扩散策略的最有效方式，我们表现最佳的模型均为端到端训练。对抗扰动的鲁棒性 扩散策略对视觉和物理扰动的鲁棒性在与表 6 实验分开的回合中进行了评估。如图 8 所示，施加了三种类型的扰动。1) 前置摄像头被挥动的手遮挡了 3 秒（左列），但扩散策略尽管出现一些抖动，仍保持在航线上并将 T 形块推到位。2) 在扩散策略对 T 形块位置进行微调时，我们移动了 T 形块。扩散策略立即重新规划，从相反方向推动，抵消了扰动的影响。3) 在第一阶段完成后机器人前往终点区的途中，我们移动了 T 形块。扩散策略立即改变路线，将 T 形块调整回目标位置，然后继续前往终点区。该实验表明，扩散策略可能能够针对未见过的观察结果合成新颖的行为。

6.2 马克杯翻转任务

马克杯翻转任务旨在测试扩散策略在接近硬件运动学极限的情况下处理复杂三维旋转的能力。目标是将随机放置的马克杯重新定向，使 1 ① 杯口朝下 2 ② 手柄指向左侧，如图 9 所示。根据马克杯的初始姿态，演示者可能直接将马克杯放置在期望方向，也可能需要额外推动




图 7. 真实世界推压任务对比。第 1 至 4 列展示了基于关键事件的动作轨迹。最后一列显示了最终状态的平均图像。**A**: 扩散策略（端到端）实现了更准确和一致的最终状态。**B**: 扩散策略（R3M）最初卡住，但后来恢复并完成任务。**C**: LSTM-GMM 在调整 T 形块时未能到达终点区域，遮挡了评估相机视野。**D**: IBC 过早结束了推动阶段。





图 8. 扩散策略的鲁棒性测试。左：在相机前挥手 3 秒会导致轻微抖动，但预测的动作仍按预期工作。中：扩散策略在推动阶段立即将偏移的块位置纠正到目标状态。右：策略在检测到块偏移时立即中止前往终点区域，将块返回到目标状态。这种新颖行为从未被演示过。请查看补充材料中的视频。



	Human	LSTM-GMM	Diffusion Policy
Succ %	1.0	0.0	0.9


图 9. 六自由度马克杯翻转任务。机器人需要 1 ① 拾取随机放置的马克杯并将其杯口朝下放置（标记为橙色）。2 ② 旋转马克杯使其手柄指向左侧。

6.3 酱汁倾倒与涂抹

手柄来旋转马克杯。因此，演示数据集高度多模态：抓取与推动、不同类型的抓取（正手与反手）或局部抓取调整（绕马克杯主轴旋转），这对基线方法来说尤其难以捕捉。

结果分析。扩散策略能够在 20 次试验中以 90% 的成功率完成此任务。捕捉到的行为丰富性最好通过视频来欣赏。尽管从未被演示过，该策略还能够在必要时对多个推动进行排序以对齐手柄，或在马克杯掉落时重新抓取。为了比较，我们还使用相同数据的子集训练了一个 LSTM-GMM 策略。对于 20 个分布内初始条件，LSTM-GMM 策略从未相对于马克杯正确对齐，并且在所有试验中都未能抓取。

酱汁倾倒与涂抹任务旨在测试扩散策略（Diffusion Policy）在真实环境中处理非刚性物体、六自由度动作空间以及周期性动作的能力。我们的 Franka Panda 平台与任务如图 10 所示。六自由度倾倒任务的目标是将满满一勺酱汁倒在披萨面饼的中心，性能通过倾倒酱汁掩码与面饼中心标称圆（图 10 中绿色圆圈所示）之间的交并比（IoU）来衡量。周期性涂抹任务的目标是在披萨面饼上涂抹酱汁，性能通过酱汁覆盖率来衡量。评估回合中的变化来自面饼和酱碗的随机位置。成功率通过以最低人类表现为阈值来计算。结果最好在补充视频中查看。两个任务均经过训练



	Pour		Spread	
	IoU	Succ	Coverage	Succ %
Human	0.79	1.00	0.79	1.00
LSTM-GMM	0.06	0.00	0.27	0.00
Diffusion Policy	0.74	0.79	0.77	1.00

图 10. 真实世界酱汁操作。[左] 六自由度倾倒任务。机器人需要 1 ① 将长柄勺浸入碗中舀取酱汁, 2 ② 接近披萨面饼中心, 3 ③ 倾倒酱汁, 4 ④ 提起长柄勺完成任务。[右] 周期性涂抹任务。机器人需要 1 ① 用握住的勺子接近酱汁中心, 2 ② 以螺旋方式涂抹酱汁覆盖披萨, 3 ③ 提起勺子完成任务。

使用相同的 Push-T 超参数, 首次尝试即获得了成功的策略。酱汁倾倒任务要求机器人保持静止一段时间, 以便用粘稠的番茄酱填满长柄勺。由此产生的空闲动作对于行为克隆算法而言具有挑战性, 因此通常被避免或过滤掉。在酱汁倾倒过程中需要进行精细调整, 以确保覆盖并达到所需形状。演示的酱汁涂抹策略灵感来自人类厨师技巧, 既需要长周期循环模式以最大化覆盖, 也需要短周期反馈以实现均匀分布 (因为所用的番茄酱常以不可预测大小的块状滴落)。周期性运动被认为难以学习, 因此通常通过专门的动作表示来解决 (Yang 等人, 2022)。两个任务都要求策略通过提起长柄勺或勺子来自我终止。

结果分析。扩散策略在两个任务上均达到接近人类的表现, 倒酱任务的覆盖率分别为 0.74 与 0.79, 抹酱任务为 0.77 与 0.79。扩散策略对外部扰动 (如在倒酱和抹酱过程中手动移动披萨面团) 反应平稳。结果最好通过补充材料中的视频观看。LSTM-GMM 在倒酱和抹酱两个任务上表现不佳。在 20 次倒酱试验中, 有 15 次在成功舀起酱料后未能提起长柄勺。即使成功提起长柄勺, 酱料也倒偏了。LSTM-GMM 在所有试验中均未能自行终止。我们推测 LSTM-GMM 的隐藏状态未能捕获足够长的历史信息, 以区分任务中的浸勺和提勺阶段。在抹酱任务中, LSTM-GMM 总是在开始后立即提起勺子, 在全部 20 次实验中均未能接触酱料。

7 真实世界双手任务

除了单臂设置外, 我们进一步在多个具有挑战性的双手任务上演示了扩散策略。为实现双手任务, 主要工作集中在扩展机器人软件栈以支持多臂遥操作和控制。扩散策略在这些任务上开箱即用, 无需调整超参数。

7.1 观测与动作空间

本体感觉观测空间扩展为包含两个末端执行器的位姿以及两个夹爪的宽度。观测空间还扩展为包含这些量的实际值和期望值。图像观测空间由两个场景相机和两个腕部相机组成, 每个手臂各附一个。动作空间扩展为包含两个末端执行器的期望位姿以及两个夹爪的期望宽度。

7.2 遥操作

对于这些协调的双手任务, 我们发现演示者同时使用两个 SpaceMouse 相当困难。因此, 我们实现了两种新的遥操作模式: 使用带有两个手部控制器的 Meta Quest Pro 虚拟现实设备, 或使用两个 Haption Virtuouse™ 6D HF TAO 设备进行带力反馈的控制, 采用双边位置-位置耦合, 如 Siciliano 等人 (2008) 触觉部分所述。该耦合在 Haption 设备与 Franka Panda 手臂之间进行。关于控制器本身的更多细节见第 D.1 节。以下提供每个任务和策略性能的更多细节。

7.3 双手打蛋器

图 11 展示并描述了双手打蛋器任务, 使用 OXO™ 打蛋器和 Room Essentials™ 塑料碗。我们选择此任务是为了说明触觉反馈对于遥操作双手操作的重要性, 即使对于协调工具使用等常见日常生活任务也是如此。没有触觉反馈时, 专家在 10 次试验中无法成功完成任何一次演示。5 次失败是由于机器人将曲柄手柄从打蛋器上拉脱; 3 次失败是由于机器人失去对手柄的抓握; 2 次失败是由于机器人触发了扭矩极限。相比之下, 同一操作员在有触觉反馈的情况下可以轻松完成 10 次中的 10 次。使用触觉反馈使得演示比没有反馈时更快且质量更高。

结果分析。扩散策略使用 210 次演示训练, 在 20 次试验中能够以 55% 的成功率完成此任务。主要失败模式是打蛋器初始位置超出分布范围, 或未抓住打蛋器曲柄手柄或失去对其的抓握。所有推演的初始和最终状态在图 18 和 19 中可视化。

7.4 双手垫子展开

图 12 展示并描述了垫子展开任务, 使用 XXL Dog Buddy™ 狗垫。该任务使用 VR 装置进行遥操作, 因为它不需要丰富的




图 11. 双手打蛋器操作。机器人需要 1 ① 将碗推到位（仅当碗离左臂太近时），2 ② 用右臂接近并拿起打蛋器，3 ③ 将打蛋器放入碗中，4 ④ 接近并抓住打蛋器曲柄手柄，5 ⑤ 转动曲柄手柄 3 次或更多次。




图 12. 双手垫子展开。机器人需要 1 ① 用左臂或右臂拿起垫子的一侧（如果需要），2 ② 提起并展开垫子（如果需要），3 ③ 确保垫子的两侧都被抓住，4 ④ 提起垫子，5 ⑤ 将垫子放置为与桌子方向一致，大致居中，6 ⑥ 释放垫子。

触觉反馈来执行任务。我们将此技能教授为双手通用，意味着它可以根据初始条件向左或向右展开。

结果分析。扩散策略（Diffusion Policy）在 20 次试验中能以 75% 的成功率完成该任务，训练使用了 162 个演示。主要失败模式是在初始抓取垫子时漏抓，策略难以自我纠正，因此陷入重复相同行为的困境。所有回放的初始和最终状态如图 16 和图 17 所示。

7.5 双臂衬衫折叠

衬衫折叠任务在图 13 中进行了描述和展示，使用一件短袖 T 恤。该任务也通过虚拟现实（VR）设置进行遥操作，因为执行该任务不需要丰富的反馈。由于运动学和作业空间约束，该任务明显更长，最多可能需要九个离散步骤。最后几步要求两个夹爪非常靠近彼此。中级控制器显式处理碰撞避免对于遥操作和策略回放都尤为重要。

结果分析。扩散策略在 20 次试验中能以 75% 的成功率完成该任务，训练使用了 284 个演示。主要失败模式是初始折叠（袖子和颜色）时漏抓，以及策略在结束时无法停止调整衬衫。所有回放的初始和最终状态如图 20 和图 21 所示。

8 相关工作

无需显式编程行为即可创建有能力的机器人是该领域长期存在的挑战（Atkeson 和 Schaal, 1997；Argall 等人, 2009；Ravichandar




图 13. 双臂衬衫折叠。机器人需要 1 ① 用双臂接近并抓住最近的袖子，2 ② 折叠袖子并松开，3 ③ 将衬衫拉近（如果需要），4 ④ 用双臂接近并抓住另一只袖子，5 ⑤ 折叠袖子并松开，6 ⑥ 将衬衫拖到适合折叠的方向，7 ⑦ 抓住衬衫并沿领口对折，8 ⑧ 将衬衫拖到中央，9 ⑨ 抚平衬衫并移开手臂。

等人, 2020)。虽然概念上简单，但行为克隆在一系列真实世界机器人任务中表现出惊人的潜力，包括操作（Zhang 等人, 2018；Florence 等人, 2019；Mandlekar 等人, 2020b,a；Zeng 等人, 2021；Rahmatizadeh 等人, 2018；Avigal 等人, 2022）和自动驾驶（Pomerleau, 1988；Bojarski 等人, 2016）。当前的行为克隆方法根据策略结构可分为两类。

显式策略。显式策略的最简单形式直接将世界状态或观测映射到动作 Pomerleau (1988); Zhang et al. (2018); Florence et al. (2019); Ross et al. (2011); Toyer et al. (2020); Rahmatizadeh et al. (2018); Bojarski et al. (2016)。它们可以通过直接的回归损失进行监督，并且只需一次前向传播即可高效推理。然而，这类策略不适合建模多模态演示行为，并且在处理高精度任务时表现不佳 Florence et al. (2021)。一种流行的方法是在保持直接动作映射简单性的同时，通过离散化动作空间将回归任务转化为分类任务，以建模多模态动作分布 Zeng et al. (2021); Wu et al. (2020); Avigal et al. (2022)。然而，近似连续动作空间所需的区间数量会随着维度的增加而呈指数增长。另一种方法是结合分类分布和高斯分布，通过使用混合密度网络（MDN）Bishop (1994); Mandlekar et al. (2021) 或带偏移预测的聚类 Shafiuallah et al. (2022); Sharma et al. (2018) 来表示连续多模态分布。然而，这些模型往往对超参数调整敏感，容易出现模式崩塌，并且在表达高精度行为方面仍然有限 Florence et al. (2021)。

Implicit Policy. Implicit policies (Florence et al. 2021; Jarrett et al. 2020) define distributions over actions by using Energy-Based Models (EBMs) (LeCun et al. 2006; Du and Mordatch 2019; Dai et al. 2019; Grathwohl et al. 2020;

Du et al. 2020)。在此设定下，每个动作被赋予一个能量值，动作预测对应于寻找最小能量动作的优化问题。由于不同的动作可能被赋予较低的能量，隐式策略自然地表示多模态分布。然而，现有的隐式策略 (Florence et al. 2021) 由于在计算底层 Info-NCE 损失时需要抽取负样本，训练过程不稳定。

扩散模型。扩散模型 (Diffusion Model) 是一类概率生成模型，通过迭代地将随机采样的噪声细化为来自底层分布的样本。从概念上也可将其理解为学习隐式动作分数的梯度场，并在推理过程中对该梯度进行优化。扩散模型 (Sohl-Dickstein 等, 2015; Ho 等, 2020) 近期已被应用于解决多种不同的控制任务 (Janner 等, 2022a; Uraïn 等, 2022; Ajay 等, 2022)。特别是, Janner 等 (2022a) 与 Huang 等 (2023) 探索了扩散模型在规划场景中的应用, 并推断出可在给定环境中执行的动作轨迹。在强化学习 (Reinforcement Learning) 背景下, Wang 等 (2022) 利用扩散模型进行策略表示, 并基于状态观测进行正则化。相比之下, 本文探索了扩散模型如何在行为克隆 (Behavioral Cloning) 场景中有效应用于视觉运动控制策略。为构建有效的视觉运动控制策略, 本文提出将去噪扩散概率模型 (DDPM) 预测高维动作序列的能力与闭环控制相结合, 同时提出一种用于动作扩散的新型变换器 (Transformer) 架构, 以及一种将视觉输入整合到动作扩散模型中的方法。

Wang 等 (2023) 探索了从专家演示中学习到的扩散模型如何用于增强经典显式策略, 而并未直接将扩散模型用作策略表示。与本文工作同期, Pearce 等 (2023)、Reuss 等 (2023) 以及 Hansen-Estruch 等 (2023) 在模拟环境中对基于扩散的策略进行了互补性分析。他们更侧重于有效的采样策略、利用无分类器引导 (Classifier-Free Guidance) 实现目标条件化以及在强化学习中的应用, 而本文则聚焦于有效的动作空间; 在模拟环境下, 双方的实证发现大体一致。此外, 本文大量真实世界实验为以下设计决策提供了有力证据: 滚动时域预测方案的重要性、速度控制与位置控制之间的谨慎选择、面向实时推理的优化必要性, 以及物理机器人系统的其他关键设计决策。

9 局限性与未来工作

尽管本文已在仿真和真实系统中验证了扩散策略的有效性, 但仍存在未来工作可改进的局限性。首先, 本文的实现继承了行为克隆的局限性, 例如在演示数据不足时性能欠佳。扩散策略可应用于其他范式, 如强化学习 Wang 等人。

(2023 年); Hansen-Estruch 等人 (2023 年), 以利用次优和负面数据。其次, 与 LSTM-GMM 等更简单的方法相比, 扩散策略具有更高的计算成本和推理延迟。我们的动作序列预测方法部分缓解了这一问题, 但对于需要高速率控制的任务可能仍不足够。未来工作可以利用扩散模型加速方法的最新进展来减少所需的推理步骤数, 例如新的噪声调度 Chen (2023 年)、推理求解器 Karras 等人 (2022 年) 以及一致性模型 Song 等人 (2023 年)。

10 结论

本文评估了基于扩散的策略在机器人行为中的可行性。通过在仿真和真实世界中对 15 项任务的全面评估, 我们证明基于扩散的视觉运动策略在一致性和确定性上均优于现有方法, 同时具有稳定性和易于训练的特点。我们的结果还揭示了关键设计因素, 包括滚动时域动作预测、末端执行器位置控制以及高效的视觉条件化, 这些因素对于充分发挥基于扩散策略的潜力至关重要。尽管许多因素会影响行为克隆策略的最终质量——包括演示的质量和数量、机器人的物理能力、策略架构以及所使用的预训练机制——我们的实验结果强烈表明, 策略结构在行为克隆过程中构成了显著的性能瓶颈。我们希望这项工作能推动该领域对基于扩散策略的进一步探索, 并强调在行为克隆过程中考虑所有方面的重要性, 而不仅仅是用于策略训练的数据。

11 致谢

我们感谢 Naveen Kuppaswamy、Hongkai Dai、Aykut Önel、Terry Suh、Tao Pang、Huy Ha、Samir Gadre、Kevin Zakka 和 Brandon Amos 的深入讨论。感谢 Jarod Wilson 提供 3D 打印支持, 感谢 Huy Ha 提供摄影和灯光建议。感谢 Xiang Li 在 GitHub 上发现我们评估代码中的错误。

资助

本研究由丰田研究所、NSF CMMI-2037101 和 NSF IIS-2132519 资助。感谢 Google 提供 UR5 机器人硬件。本文所表达的观点和结论仅代表作者本人, 不应被解释为必然代表资助方的官方政策, 无论是明示还是暗示。

参考文献

- Ajay A, Du Y, Gupta A, Tenenbaum J, Jaakkola T and Agrawal P (2022) Is conditional generative modeling all you need for decision-making? *arXiv preprint arXiv:2211.15657*.
- Argall BD, Chernova S, Veloso M and Browning B (2009) A survey of robot learning from demonstration. *Robotics and autonomous systems* 57(5): 469–483.

- Atkeson CG and Schaal S (1997) Robot learning from demonstration. In: *ICML*, volume 97. pp. 12–20.
- Avigal Y, Berscheid L, Asfour T, Kröger T and Goldberg K (2022) Speedfolding: Learning efficient bimanual folding of garments. In: *2022 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*. IEEE, pp. 1–8.
- Bishop CM (1994) *Mixture density networks*. Aston University.
- Bojarski M, Del Testa D, Dworakowski D, Firner B, Flepp B, Goyal P, Jackel LD, Monfort M, Muller U, Zhang J et al. (2016) End to end learning for self-driving cars. *arXiv preprint arXiv:1604.07316*.
- Chen T (2023) On the importance of noise scheduling for diffusion models. *arXiv preprint arXiv:2301.10972*.
- Chi C, Feng S, Du Y, Xu Z, Cousineau E, Burchfiel B and Song S (2023) Diffusion policy: Visuomotor policy learning via action diffusion. In: *Proceedings of Robotics: Science and Systems (RSS)*.
- Dai B, Liu Z, Dai H, He N, Gretton A, Song L and Schuurmans D (2019) Exponential family estimation via adversarial dynamics embedding. *Advances in Neural Information Processing Systems* 32.
- Deng J, Dong W, Socher R, Li LJ, Li K and Fei-Fei L (2009) Imagenet: A large-scale hierarchical image database. In: *2009 IEEE conference on computer vision and pattern recognition*. Ieee, pp. 248–255.
- Dosovitskiy A, Beyer L, Kolesnikov A, Weissenborn D, Zhai X, Unterthiner T, Dehghani M, Minderer M, Heigold G, Gelly S et al. (2020) An image is worth 16x16 words: Transformers for image recognition at scale. *arXiv preprint arXiv:2010.11929*.
- Du Y, Li S, Tenenbaum J and Mordatch I (2020) Improved contrastive divergence training of energy based models. *arXiv preprint arXiv:2012.01316*.
- Du Y and Mordatch I (2019) Implicit generation and generalization in energy-based models. *arXiv preprint arXiv:1903.08689*.
- Florence P, Lynch C, Zeng A, Ramirez OA, Wahid A, Downs L, Wong A, Lee J, Mordatch I and Tompson J (2021) Implicit behavioral cloning. In: *5th Annual Conference on Robot Learning*.
- Florence P, Manuelli L and Tedrake R (2019) Self-supervised correspondence in visuomotor policy learning. *IEEE Robotics and Automation Letters* 5(2): 492–499.
- Grathwohl W, Wang KC, Jacobsen JH, Duvenaud D and Zemel R (2020) Learning the stein discrepancy for training and evaluating energy-based models without sampling. In: *International Conference on Machine Learning*.
- Gupta A, Kumar V, Lynch C, Levine S and Hausman K (2019) Relay policy learning: Solving long-horizon tasks via imitation and reinforcement learning. *arXiv preprint arXiv:1910.11956*.
- Hansen-Estruch P, Kostrikov I, Janner M, Kuba JG and Levine S (2023) Idql: Implicit q-learning as an actor-critic method with diffusion policies. *arXiv preprint arXiv:2304.10573*.
- He K, Fan H, Wu Y, Xie S and Girshick R (2020) Momentum contrast for unsupervised visual representation learning. In: *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. pp. 9729–9738.
- He K, Zhang X, Ren S and Sun J (2016) Deep residual learning for image recognition. In: *Proceedings of the IEEE conference on computer vision and pattern recognition*. pp. 770–778.
- Ho J, Jain A and Abbeel P (2020) Denoising diffusion probabilistic models. *arXiv preprint arXiv:2006.11239*.
- Huang S, Wang Z, Li P, Jia B, Liu T, Zhu Y, Liang W and Zhu SC (2023) Diffusion-based generation, optimization, and planning in 3d scenes. *arXiv preprint arXiv:2301.06015*.
- Janner M, Du Y, Tenenbaum J and Levine S (2022a) Planning with diffusion for flexible behavior synthesis. In: *International Conference on Machine Learning*.
- Janner M, Du Y, Tenenbaum J and Levine S (2022b) Planning with diffusion for flexible behavior synthesis. In: Chaudhuri K, Jegelka S, Song L, Szepesvari C, Niu G and Sabato S (eds.) *Proceedings of the 39th International Conference on Machine Learning*, Proceedings of Machine Learning Research. PMLR.
- Jarrett D, Bica I and van der Schaar M (2020) Strictly batch imitation learning by energy-based distribution matching. *Advances in Neural Information Processing Systems* 33: 7354–7365.
- Karras T, Aittala M, Aila T and Laine S (2022) Elucidating the design space of diffusion-based generative models. *arXiv preprint arXiv:2206.00364*.
- Khatib O (1987) A unified approach for motion and force control of robot manipulators: The operational space formulation. *IEEE Journal on Robotics and Automation* 3(1): 43–53. DOI:10.1109/JRA.1987.1087068. Conference Name: IEEE Journal on Robotics and Automation.
- LeCun Y, Chopra S, Hadsell R, Huang FJ and et al (2006) A tutorial on energy-based learning. In: *Predicting Structured Data*. MIT Press.
- Liu L, Liu X, Gao J, Chen W and Han J (2020) Understanding the difficulty of training transformers. *arXiv preprint arXiv:2004.08249*.
- Liu N, Li S, Du Y, Torralba A and Tenenbaum JB (2022) Compositional visual generation with composable diffusion models. *arXiv preprint arXiv:2206.01714*.
- Mandlekar A, Ramos F, Boots B, Savarese S, Fei-Fei L, Garg A and Fox D (2020a) Iris: Implicit reinforcement without interaction at scale for learning control from offline robot manipulation data. In: *2020 IEEE International Conference on Robotics and Automation (ICRA)*. IEEE.
- Mandlekar A, Xu D, Martín-Martín R, Savarese S and Fei-Fei L (2020b) Learning to generalize across long-horizon tasks from human demonstrations. *arXiv preprint arXiv:2003.06085*.
- Mandlekar A, Xu D, Wong J, Nasiriany S, Wang C, Kulkarni R, Fei-Fei L, Savarese S, Zhu Y and Martín-Martín R (2021) What matters in learning from offline human demonstrations for robot manipulation. In: *5th Annual Conference on Robot Learning*.
- Mayne DQ and Michalska H (1988) Receding horizon control of nonlinear systems. In: *Proceedings of the 27th IEEE Conference on Decision and Control*. IEEE, pp. 464–465.
- Nair S, Rajeswaran A, Kumar V, Finn C and Gupta A (2022) R3m: A universal visual representation for robot manipulation. In: *6th Annual Conference on Robot Learning*.
- Neal RM et al. (2011) Mcmc using hamiltonian dynamics. *Handbook of markov chain monte carlo*.
- Nichol AQ and Dhariwal P (2021) Improved denoising diffusion probabilistic models. In: *International Conference on Machine Learning*. PMLR, pp. 8162–8171.

- Pearce T, Rashid T, Kanervisto A, Bignell D, Sun M, Georgescu R, Macua SV, Tan SZ, Momennejad I, Hofmann K et al. (2023) Imitating human behaviour with diffusion models. *arXiv preprint arXiv:2301.10677*.
- Perez E, Strub F, De Vries H, Dumoulin V and Courville A (2018) Film: Visual reasoning with a general conditioning layer. In: *Proceedings of the AAAI Conference on Artificial Intelligence*.
- Pomerleau DA (1988) Alvin: An autonomous land vehicle in a neural network. *Advances in neural information processing systems* 1.
- Radford A, Kim JW, Hallacy C, Ramesh A, Goh G, Agarwal S, Sastry G, Askell A, Mishkin P, Clark J et al. (2021) Learning transferable visual models from natural language supervision. In: *International conference on machine learning*. PMLR, pp. 8748–8763.
- Rahmatizadeh R, Abolghasemi P, Bölöni L and Levine S (2018) Vision-based multi-task manipulation for inexpensive robots using end-to-end learning from demonstration. In: *2018 IEEE international conference on robotics and automation (ICRA)*. IEEE, pp. 3758–3765.
- Ravichandar H, Polydoros AS, Chernova S and Billard A (2020) Recent advances in robot learning from demonstration. *Annual review of control, robotics, and autonomous systems* 3: 297–330.
- Reuss M, Li M, Jia X and Lioutikov R (2023) Goal-conditioned imitation learning using score-based diffusion policies. In: *Proceedings of Robotics: Science and Systems (RSS)*.
- Ridnik T, Ben-Baruch E, Noy A and Zelnik-Manor L (2021) Imagenet-21k pretraining for the masses.
- Ronneberger O, Fischer P and Brox T (2015) U-net: Convolutional networks for biomedical image segmentation. In: *Medical Image Computing and Computer-Assisted Intervention—MICCAI 2015: 18th International Conference, Munich, Germany, October 5–9, 2015, Proceedings, Part III* 18. Springer, pp. 234–241.
- Ross S, Gordon G and Bagnell D (2011) A reduction of imitation learning and structured prediction to no-regret online learning. In: *Proceedings of the fourteenth international conference on artificial intelligence and statistics*. JMLR Workshop and Conference Proceedings, pp. 627–635.
- Shafiullah NMM, Cui ZJ, Altanzaya A and Pinto L (2022) Behavior transformers: Cloning π modes with one stone. In: Oh AH, Agarwal A, Belgrave D and Cho K (eds.) *Advances in Neural Information Processing Systems*.
- Sharma P, Mohan L, Pinto L and Gupta A (2018) Multiple interactions made easy (mime): Large scale demonstrations data for imitation. In: *Conference on robot learning*. PMLR.
- Siciliano B, Khatib O and Kröger T (2008) *Springer handbook of robotics*, volume 200. Springer.
- Sohl-Dickstein J, Weiss E, Maheswaranathan N and Ganguli S (2015) Deep unsupervised learning using nonequilibrium thermodynamics. In: *International Conference on Machine Learning*.
- Song J, Meng C and Ermon S (2021) Denoising diffusion implicit models. In: *International Conference on Learning Representations*.
- Song Y, Dhariwal P, Chen M and Sutskever I (2023) Consistency models. *arXiv preprint arXiv:2303.01469*.
- Song Y and Ermon S (2019) Generative modeling by estimating gradients of the data distribution. *Advances in neural information processing systems* 32.
- Subramanian J and Mahajan A (2019) Approximate information state for partially observed systems. In: *2019 IEEE 58th Conference on Decision and Control (CDC)*. IEEE, pp. 1629–1636.
- Ta DN, Cousineau E, Zhao H and Feng S (2022) Conditional energy-based models for implicit policies: The gap between theory and practice. *arXiv preprint arXiv:2207.05824*.
- Tancik M, Srinivasan P, Mildenhall B, Fridovich-Keil S, Raghavan N, Singhal U, Ramamoorthi R, Barron J and Ng R (2020) Fourier features let networks learn high frequency functions in low dimensional domains. *Advances in Neural Information Processing Systems* 33: 7537–7547.
- Toyer S, Shah R, Critch A and Russell S (2020) The magical benchmark for robust imitation. *Advances in Neural Information Processing Systems* 33: 18284–18295.
- Urain J, Funk N, Chalvatzaki G and Peters J (2022) Se (3)-diffusionfields: Learning cost functions for joint grasp and motion optimization through diffusion. *arXiv preprint arXiv:2209.03855*.
- Vaswani A, Shazeer N, Parmar N, Uszkoreit J, Jones L, Gomez AN, Kaiser Ł and Polosukhin I (2017) Attention is all you need. *Advances in neural information processing systems* 30.
- Wang Z, Hunt JJ and Zhou M (2022) Diffusion policies as an expressive policy class for offline reinforcement learning. *arXiv preprint arXiv:2208.06193*.
- Wang Z, Hunt JJ and Zhou M (2023) Diffusion policies as an expressive policy class for offline reinforcement learning. In: *The Eleventh International Conference on Learning Representations*. URL <https://openreview.net/forum?id=AHvFDPi-FA>.
- Welling M and Teh YW (2011) Bayesian learning via stochastic gradient langevin dynamics. In: *Proceedings of the 28th international conference on machine learning (ICML-11)*. pp. 681–688.
- Wu J, Sun X, Zeng A, Song S, Lee J, Rusinkiewicz S and Funkhouser T (2020) Spatial action maps for mobile manipulation. In: *Proceedings of Robotics: Science and Systems (RSS)*.
- Wu Y and He K (2018) Group normalization. In: *Proceedings of the European conference on computer vision (ECCV)*. pp. 3–19.
- Yang J, Zhang J, Settle C, Rai A, Antonova R and Bohg J (2022) Learning periodic tasks from human demonstrations. In: *2022 International Conference on Robotics and Automation (ICRA)*. IEEE, pp. 8658–8665.
- Zeng A, Florence P, Tompson J, Welker S, Chien J, Attarian M, Armstrong T, Krasin I, Duong D, Sindhwani V et al. (2021) Transporter networks: Rearranging the visual world for robotic manipulation. In: *Conference on Robot Learning*. PMLR, pp. 726–747.
- Zhang A, McAllister RT, Calandra R, Gal Y and Levine S (2020) Learning invariant representations for reinforcement learning without reconstruction. In: *International Conference on Learning Representations*.
- Zhang T, McCarthy Z, Jow O, Lee D, Chen X, Goldberg K and Abbeel P (2018) Deep imitation learning for complex manipulation tasks from virtual reality teleoperation. In: *2018 IEEE International Conference on Robotics and Automation (ICRA)*. IEEE, pp. 5628–5635.

Zhou Y, Barnes C, Lu J, Yang J and Li H (2019) On the continuity of rotation representations in neural networks. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. pp. 5745–5753.

A 扩散策略实现细节

A.1 归一化

正确归一化动作数据对于实现扩散策略的最佳性能至关重要。将每个动作维度的最小值和最大值独立缩放到 $[-1, 1]$ 对大多数任务都有效。由于 DDPM 在每次迭代中将预测裁剪到 $[-1, 1]$ 以确保稳定性，常见的零均值单位方差归一化会导致动作空间的某些区域无法访问。当数据方差很小（例如接近常数值）时，将数据平移至零均值而不进行缩放，以防止数值问题。我们保持与旋转表示（例如四元数）对应的动作维度不变。

A.2 旋转表示

对于所有具有速度控制动作空间的环境，我们遵循 Mandlekar 等人（2021）的标准做法，使用三维轴角表示动作的旋转分量。由于速度动作指令通常接近零，轴角表示的奇异性和不连续性通常不会造成问题。对于所有具有位置控制动作空间的环境（真实世界和仿真），我们采用 Zhou 等人（2019）提出的六维旋转表示。

A.3 图像增强

遵循 Mandlekar 等人（2021）的做法，我们在训练期间采用随机裁剪增强。每个任务的裁剪尺寸见表 7。在推理期间，我们采用相同尺寸的静态中心裁剪。

A.4 超参数

用于仿真和真实世界基准的扩散策略超参数见表 7 和表 8。由于推块任务使用马尔可夫脚本预言策略生成演示数据，我们发现其观测和动作时域的最优超参数与其他使用人类遥控操作演示的任务差异很大。我们发现基于卷积神经网络的扩散策略的最优超参数在不同任务间保持一致。相比之下，基于变换器的扩散策略的最优注意力随机失活率和权重衰减在不同任务间差异很大。在调参过程中，我们发现增加基于卷积神经网络的扩散策略的参数数量总能提升性能，因此最优模型规模受限于可用的计算和内存容量。另一方面，增加基于变换器的扩散策略的模型规模（尤其是层数）有时会损害性能。对于基于卷积神经网络的扩散策略，我们发现使用 FiLM 条件化传入观测在所有任务上优于图像修补。




图 14. 观测时域消融实验。基于状态的扩散策略对观测时域不敏感。基于视觉的扩散策略偏好较低的 > 1 观测时域，其中 2 是大多数任务的良好折衷。




图 15. 数据效率消融实验。扩散策略在每个训练数据集规模上均优于 LSTM-GMM Mandlekar 等人（2021）。

除推压任务（Push-T）外。表 1 中报告的推压任务上扩散策略卷积网络（DiffusionPolicy-C）的性能使用了图像修补而非特征线性调制（FiLM）。在仿真基准上，我们采用了改进的去噪扩散概率模型（iDDPM）算法（Nichol 和 Dhariwal, 2021），训练和推理均使用相同的 100 次去噪扩散迭代。在真实世界基准上，我们使用了去噪扩散隐式模型（DDIM）（Song 等, 2021），将推理去噪迭代次数减少到 16 次，从而降低了推理延迟。所有基于状态的实验使用批大小为 256，所有基于图像的实验使用批大小为 64。学习率调度采用带线性预热的余弦调度。基于卷积神经网络（CNN）的扩散策略预热 500 步，而基于变换器（Transformer）的扩散策略预热 1000 步。

A.5 数据效率

我们发现扩散策略在每个训练数据集规模下均优于长短期记忆网络-高斯混合模型（LSTM-GMM）（Mandlekar 等, 2021），如图 15 所示。

B 附加消融结果

B.1 观测时域

我们发现基于状态的扩散策略对观测时域不敏感，如图 14 所示。然而，基于视觉的扩散策略，特别是具有 CNN 骨干的变体，随着观测时域的增加性能下降。在实践中，我们发现观测时域为 2 对大多数状态和图像观测任务都表现良好。

H-Param	Ctrl	To	Ta	Tp	ImgRes	CropRes	#D-Params	#V-Params	Lr	WDecay	D-Iters Train	D-Iters Eval
Lift	Pos	2	8	16	2x84x84	2x76x76	256	22	1e-4	1e-6	100	100
Can	Pos	2	8	16	2x84x84	2x76x76	256	22	1e-4	1e-6	100	100
Square	Pos	2	8	16	2x84x84	2x76x76	256	22	1e-4	1e-6	100	100
Transport	Pos	2	8	16	4x84x85	4x76x76	264	45	1e-4	1e-6	100	100
ToolHang	Pos	2	8	16	2x240x240	2x216x216	256	22	1e-4	1e-6	100	100
Push-T	Pos	2	8	16	1x96x96	1x84x84	256	22	1e-4	1e-6	100	100
Block Push	Pos	3	1	12	N/A	N/A	256	0	1e-4	1e-6	100	100
Kitchen	Pos	2	8	16	N/A	N/A	256	0	1e-4	1e-6	100	100
Real Push-T	Pos	2	6	16	2x320x240	2x288x216	67	22	1e-4	1e-6	100	16
Real Pour	Pos	2	8	16	2x320x240	2x288x216	67	22	1e-4	1e-6	100	16
Real Spread	Pos	2	8	16	2x320x240	2x288x216	67	22	1e-4	1e-6	100	16
Real Mug Flip	Pos	2	8	16	2x320x240	2x288x216	67	22	1e-4	1e-6	100	16

表 7. 基于 CNN 的扩散策略超参数 控制: 位置或速度控制 观测时域: 观测时域 动作时域: 动作时域 动作预测时域: 动作预测时域 图像分辨率: 环境观测分辨率 (相机视图数 $\times$ 宽 $\times$ 高) 裁剪分辨率: 随机裁剪分辨率 扩散网络参数量: 扩散网络参数量 (百万) 视觉编码器参数量: 视觉编码器参数量 (百万) 学习率: 学习率 权重衰减: 权重衰减 训练扩散迭代次数: 训练去噪扩散迭代次数 评估扩散迭代次数: 推理去噪扩散迭代次数 (由 DDIM 启用 (Song 等, 2021))

H-Param	Ctrl	To	Ta	Tp	#D-params	#V-params	#Layers	Emb Dim	Attn Drp	Lr	WDecay	D-Iters Train	D-Iters Eval
Lift	Pos	2	8	10	9	22	8	256	0.3	1e-4	1e-3	100	100
Can	Pos	2	8	10	9	22	8	256	0.3	1e-4	1e-3	100	100
Square	Pos	2	8	10	9	22	8	256	0.3	1e-4	1e-3	100	100
Transport	Pos	2	8	10	9	45	8	256	0.3	1e-4	1e-3	100	100
ToolHang	Pos	2	8	10	9	22	8	256	0.3	1e-4	1e-3	100	100
Push-T	Pos	2	8	16	9	22	8	256	0.01	1e-4	1e-1	100	100
Block Push	Vel	3	1	5	9	0	8	256	0.3	1e-4	1e-3	100	100
Kitchen	Pos	4	8	16	80	0	8	768	0.1	1e-4	1e-3	100	100
Real Push-T	Pos	2	6	16	80	22	8	768	0.3	1e-4	1e-3	100	16

表 8. 基于变换器的扩散策略超参数 Ctrl: 位置或速度控制 To: 观测时域 Ta: 动作时域 Tp: 动作预测时域 #D-Params: 扩散网络参数量 (百万) #V-Params: 视觉编码器参数量 (百万) Emb Dim: 变换器令牌嵌入维度 Attn Drp: 变换器注意力随机失活概率 Lr: 学习率 WDecay: 权重衰减 (仅变换器) D-Iters Train: 训练扩散迭代次数 D-Iters Eval: 推理扩散迭代次数 (由 DDIM Song 等人 (2021) 启用)

B.2 性能提升计算

对于表 1、表 2 和表 4 中报告的每个任务 i (列) (忽略 mh 结果), 我们找到基线方法的最大性能 $\max \text{baseline}$ 和扩散策略变体 (CNN 与 Transformer) 的最大性能 $\max \text{ours}_i$ 。对于每个任务, 性能提升计算为 $\text{improvement}_i = \max \text{ours}_i - \max \text{baseline}_i$ (所有任务均为正值)。最后, 平均提升计算为 $\text{avg improvement} = \frac{1}{N} \sum_N^i \text{improvement}_i = 0.46858 \approx 46.9\%$ 。

C 真实世界任务细节

C.1 Push-T

C.1.1 演示 收集了 136 个演示并用于训练。初始条件通过随机推动或抛掷 T 形块到桌面上来变化。在本次数据收集之前, 操作员已执行此任务数小时, 应被视为熟练。

C.1.2 评估 我们对每种方法使用固定的 12 小时训练时间, 并选择每个方法的最后一个检查点, 但 IBC 除外, 由于 IBC 的训练稳定性问题, 选择训练集动作预测 MSE 误差最小的检查点。IBC 的训练和检查点选择难度在主

文图 7 中展示。每种方法评估 20 个回合, 均从相同的初始条件集开始。为确保初始条件的一致性, 我们根据俯视相机叠加图像仔细调整 T 形块和机器人的姿态。每个评估回合在末端执行器保持在终点区域内超过 0.5 秒或达到 60 秒时间限制时终止。IoU 度量直接在俯视相机像素空间中计算。

C.2 酱料倾倒与涂抹

C.2.1 演示 每个任务收集 50 个演示, 其中 90% 用于训练。对于倾倒任务, 披萨面团和酱料碗的初始位置会变化。每次演示后, 酱料被倒回碗中, 面团被擦拭干净。对于涂抹任务, 披萨面团的位置以及倾倒的酱料形状会变化。重置时, 我们手动将酱料向面团中心聚拢, 并将剩余面团擦拭干净。在涂抹和酱料转移过程中, 遥操作命令的旋转分量被丢弃, 以避免意外舀起或洒出酱料。

C.2.2 评估 扩散策略 (Diffusion Policy) 和 LSTM-GMM

均训练 1000 个训练轮次 (epoch)。使用最后一个检查点进行评估。每种方法从相同的随机初始条件集进行评估, 其中披萨面团和

酱料碗的位置会变化。我们使用与 **Push-T** 类似的协议来设置初始条件。我们不尝试匹配涂抹时倾倒酱料的初始形状。相反，我们确保所有实验中酱料量固定。评估回合通过将勺子向上移动（远离面团）0.5 秒来终止，或当操作员认为策略行为不安全时终止。覆盖率度量通过单应性将左右相机的 RGB 图像投影到桌面空间，然后计算每个投影图像中的覆盖率。报告左右相机之间的最大覆盖率。

D 真实世界设置详情

D.0.1 UR5 机器人工作站 **Push-T** 任务的实验在 UR5 机器人工作站上进行。UR5 机器人以 125Hz 接受末端执行器空间位置命令，该命令由人类演示或策略的 10Hz 命令线性插值得到。插值控制器将末端执行器速度限制在 0.43 m/s 以下，并将其位置限制在桌面上方 1cm 的区域内以确保安全。位置控制策略直接预测期望的末端执行器位姿，而速度控制策略预测当前位置设定点与先前设定点之间的差异。UR5 机器人工作站配备 5 个 RealSense D415 深度相机，以 30fps 录制 720p RGB 视频。仅使用其中 2 个相机进行策略观察，降采样至 320x240、10fps。演示期间，操作员通过 3Dconnexion SpaceMouse 以 10Hz 遥操作机器人。

D.1 弗兰卡机器人工作站

酱汁倾倒与涂抹、双臂打蛋器、双臂垫子展开以及双臂

叠衣 任务均在弗兰卡机器人工作站上执行。对于非触觉控制，实现了一个定制的中间层控制器，根据学习策略给出的期望末端执行器位姿生成期望关节位置。在每个时间步，我们求解一个微分运动学问题（表述为二次规划）来计算期望关节速度，以跟踪期望末端执行器速度。所得关节速度经欧拉积分得到关节位置，由机器人上的关节级控制器进行跟踪。该公式允许我们施加约束，例如双臂与桌面的碰撞避免、末端执行器安全区域以及关节极限。它还支持在末端执行器指令的零空间中调节冗余自由度。该中间层控制器在硬件部署期间对于保护学习策略尤为有价值。对于触觉遥操作控制，实现了另一个定制的中间层控制器，但表述为纯力矩控制器。该控制器采用 Khatib (1987) 的操作空间控制，表述为以 200 Hz 运行的二次规划，其中位置、速度和力矩极限作为约束添加，主要空间目标和次要零空间姿态目标作为




图 16. 垫子展开的初始状态




图 17. 垫子展开的最终状态

成本。结合弗兰卡熊猫臂的良好模型（包括反射转子惯量），使我们能够仅通过纯空间反馈实现良好跟踪，并通过前馈空间加速度实现更好的跟踪。该控制模式尚未启用碰撞避免。注意，在推理时我们使用非触觉控制。未来工作旨在简化该控制策略，并仅使用单一控制器来实现给定目标。操作员使用 SpaceMouse 或 VR 控制器输入设备来控制机器人的末端执行器，夹爪由相应设备上的触发按钮控制。遥操作和学习策略以 10Hz 运行，中间层控制器以约 1kHz 运行。期望末端执行器位姿命令由中间层控制器进行插值。该工作站配备 2 个 RealSense D415 RGBD 相机，以 30fps 传输 VGA RGB 图像，这些图像被下采样到 320x240 并以 10fps 作为学习策略的输入。

D.2 双手任务的初始与最终状态

以下各图展示了四个双手任务的初始与最终状态。绿色和红色方框分别表示成功和失败的轨迹。由于垫子和衬衫是非常扁平的物体，我们使用了单应性投影以更好地可视化初始与最终状态。




图 18. 打蛋器的初始状态




图 19. 打蛋器的最终状态




图 20. 叠衬衫的初始状态




图 21. 叠衬衫的最终状态