

世界动作模型是零样本策略

Seonghyeon Ye[†] Yunhao Ge^{*} Kaiyuan Zheng^{*} Shenyuan Gao^{*} Sihyun Yu^{*} George Kurian^{*}
Suneel Indupuru^{*} You Liang Tan^{*} Chuning Zhu Jiannan Xiang Ayaan Malik Kyungmin Lee
William Liang Nadun Ranawaka Jiasheng Gu Yinzhen Xu Guanzhi Wang Fengyuan Hu
Avnish Narayan Johan Bjorck Jing Wang Gwanghyun Kim Dantong Niu Ruijie Zheng Yuqi Xie
Jimmy Wu Qi Wang Ryan Julian Danfei Xu Yilun Du Yevgen Chebotar Scott Reed Jan Kautz
Yuke Zhu[†] Linxi “Jim” Fan[†] Joel Jang[†]

NVIDIA

[†]Project Leads ^{*}Core Contributors

<https://dreamzero0.github.io>



图 1：概览。通过联合预测视频和动作，世界动作模型（World Action Models, WAMs）继承了世界物理先验，从而能够 1) 从多样、非重复的数据中有效学习，2) 实现开放世界泛化，3) 从纯视频数据中进行跨具身学习，4) 对新机器人进行少样本适应。

摘要

最先进的视觉-语言-动作（Vision-Language-Action, VLA）模型在语义泛化方面表现出色，但在新环境中泛化到未见过的物理运动方面存在困难。我们提出了 DreamZero，一种基于预训练视频扩散主干的世界动作模型（World Action Model, WAM）。与 VLA 不同，WAM 通过预测未来世界状态和动作来学习物理动力学，将视频作为世界如何演变的密集表示。通过联合建模视频和动作，DreamZero 从异构机器人数据中有效学习多样技能，而无需依赖重复演示。在真实机器人实验中，与最先进的 VLA 相比，这在新任务和新环境上的泛化性能提升了超过 $2 \times$ 。关键在于，通过模型和系统优化，我们使一个 14B 的自回归视频扩散模型能够以 7Hz 的频率进行实时闭环控制。最后，我们展示了两种形式的跨具身迁移：来自其他机器人或人类的纯视频演示，仅用 10 - 20 分钟的数据，就在未见任务性能上带来了超过 42% 的相对提升。更令人惊讶的是，DreamZero 实现了少样本具身适应，仅用 30 分钟的玩耍数据就迁移到新具身，同时保持零样本泛化。

1. 引言

近期机器人基础模型，称为视觉-语言-动作模型（Vision-Language Action models, VLAs），扩展了预训练的视觉-语言模型（Vision-Language Models, VLMs）以预测电机动作（Bjorck et al., 2025; Black et al., 2024; Brohan et al., 2023; Gemini Robotics Team, 2025; Kim et al., 2024）。虽然 VLAs 成功继承了语言先验，以泛化到多样的语言指令，尤其是操纵多样物体（Brohan et al., 2023），但它们对新环境的泛化，以及更关键的是对新动作或技能的泛化仍然有限（Guruprasad et al., 2025; Zhou et al., 2025）。例如，VLAs 可以通过利用 VLM 预训练期间获得的网络知识来识别目标位置，并将其连接到从机器人数据中学到的移动技能，从而成功执行“将可乐罐移到泰勒·斯威夫特处”（Brohan et al., 2023）。然而，如果特定技能不在机器人训练数据中，它们就无法完成“解开鞋带”这样的任务。尽管 VLM 先验在语义层面编码了要做什么，但它们缺乏如何以精确的空间感知执行动作的表示，这些表示需要与几何、动力学和运动控制对齐（Chen et al., 2024; Feng et al., 2025）。因此，VLAs 往往难以适应新环境或泛化到超出专家演示分布的新任务，除非明确收集大规模的任务和特定环境的动作数据。

在本文中，我们提出了 DreamZero，一个基于预训练图像到视频扩散主干（Team Wan, 2025）的 14B 机器人基础模型。我们将这种架构称为世界动作模型（World Action Model, WAM）——一种旨在以对齐方式预测动作和视觉未来状态的基础模型。WAMs 从在大规模网络视频数据上训练的视频扩散模型初始化，利用丰富的时空先验，在语言指令和观测的条件下联合生成未来帧和动作。这将动作学习从密集的状态-动作模仿转变为逆动力学——将运动命令与预测的视觉未来对齐。因此，我们观察到这实现了（1）从异构轨迹的机器人数据中有效学习，这些轨迹是在真实世界环境中执行有用行为时收集的，而不是仅仅依赖精心重复的演示；（2）对新环境中的新任务的零样本泛化；以及（3）高效的跨具身迁移。

该方法带来了三项核心进展，使 DreamZero 区别于先前的工作，包括其他世界行动模型（WAM）（Kim 等, 2026; Liang 等, 2025; Pai 等, 2025）。首先，DreamZero 解锁了超越传统视觉语言行动模型（VLA）和先前 WAM 的新泛化能力——跨环境、跨任务和跨具身（图 2 和图 3）。与最先进的预训练 VLA 相比，我们观察到在环境和任务泛化基准上的平均任务进度提升了超过 $2 \times$ 。其次，DreamZero 证明了通用策略可以从多样、异构的数据中有效学习，打破了通用机器人策略需要多次重复的常规认知




图 2：视频与动作联合预测。DreamZero 联合生成视频和动作。我们观察到预测的动作与生成的视频高度一致。示例来自完全未见过的任务。

每个任务的演示次数。尽管其他世界-动作模型（World-Action Models, WAMs）表明，与视觉-语言-动作模型（Vision-Language-Action Models, VLAs）相比，从视频预测中学习到的先验能够提升动作学习的样本效率（Liao 等, 2025; Pai 等, 2025），但大多数工作仍聚焦于重复演示。此外，DreamZero 的环境泛化能力在任务特定的后训练之后依然得以保持，在平均任务进度上比最先进的 VLAs 高出 10%。最后，本文展示了两种形式的跨具身迁移。第一种是来自另一台机器人的纯视频演示

（YAM）或人类在目标机器人（AgiBot G1）上仅用 10 – 20 分钟数据，即可在未见任务性能上带来超过 42% 的相对提升。其次，更令人惊讶的是，我们证明了 DreamZero 能够实现少样本具身适应：一个在 AgiBot G1 上预训练的模型能够适应一个全新的机器人

（YAM）仅使用 30 分钟的游玩数据，保持了零样本泛化能力。据我们所知，这为数据高效的具体化适应设立了新的基准。

DreamZero 是一个 14B 的自回归扩散 Transformer，采用教师强制分块视频去噪目标进行训练。我们的架构分析表明，更大的预训练视频扩散模型能产生更高质量的视频预测，这直接转化为更优的下游动作执行——表明策略性能从根本上与视频生成质量相关。我们进一步发现，训练数据的多样性分布对于泛化至关重要，在相同数据量下优于多任务重复数据。此外，我们观察到自回归架构能带来更平滑的机器人运动，并提高预测视频与执行动作之间的模态对齐度。

为了解决视频扩散模型固有的计算开销，我们引入了一套涵盖三个类别的优化方案：（1）算法改进，包括解耦视频和动作去噪调度（DreamZero-Flash）；（2）系统级并行和缓存策略；（3）底层优化，如量化和 CUDA 核函数调优。这些技术共同实现了 $38\times$ 的推理加速，且不降低性能，使 DreamZero 能够以约 7Hz 的频率生成动作块，实现平滑的实时机器人控制。

我们的主要贡献如下：

- 我们提出了 DreamZero，一个 14B 的世界-动作模型（WAM），联合预测视频和动作，能够从多样、非重复的机器人数据中有效学习。
- 我们展示了与最先进的视觉-语言-动作模型（VLA）相比，在未见动词和动作的零样本泛化方面有超过 $2\times$ 的提升，同时保持对物体和环境的泛化能力。
- 我们提出了模型和系统优化，实现了 $38\times$ 的推理加速，支持 **7Hz** 的实时闭环控制。
- 我们展示了跨具身迁移：仅使用人类视频数据（12 分钟）或其他机器人视频数据（20 分钟），在未见任务上相对提升超过 42%，并引入了少样本具身适应——在 AgiBot G1 上预训练的 DreamZero 仅用 30 分钟的演示数据即可适应全新机器人（YAM），实现零样本泛化。
- 我们开源了模型权重、推理代码，以及运行公开真实世界基准（RoboArena）的代码。



图 3：自由形式评估。DreamZero 在自然语言指令条件下执行多种任务，包括物体操作、工具使用和人机交互。

以及仿真基准（Polaris 和 Genie Sim 3.0）¹ 在 <https://github.com/dreamzero0/dreamzero> 处。

2. 相关工作

2.1. 视觉语言动作模型

利用基础模型进行机器人技术研究。为物理人工智能开发基础模型（Bommasani 等人，2021）已成为一个重要的研究前沿。其中一条工作路线涉及使用现有的、预训练的基础模型作为“黑盒”推理器来处理高层任务规划。这些工作通常涉及模块化系统，其中基础模型生成指令序列、视觉迹或可供性，随后由专门的低层机器人策略或控制器执行（Brohan 等人，2023；Driess 等人，2023；Huang 等人，2023；Kumar 等人，2026；Singh 等人，2023）。虽然这种模块化简化了复杂规划并实现了更强的泛化（Kaelbling 和 Lozano-Pérez；Lee 等人，2025；Li 等人，2025）和效率（Drechkowski 等人，2025），但它依赖于预先存在的低层技能库和稳健的接口来弥合抽象推理与物理执行之间的差距。此外，这些解耦系统面临跨模块误差累积的风险。

视觉语言动作模型。另一方面，端到端模型如视觉语言动作模型（VLAs）（Bjorck 等人，2025；Black 等人，2024；Brohan 等人，2022，2023；Bu 等人，2025；Gemini Robotics Team，2025；Kim 等人，2024；Physical Intelligence，2025；Yang 等人，2025；Ye 等人，2025；Zheng 等人，2025）通过摆脱规划与控制的严格层级结构，在同一模型内结合语言条件语义和低层机器人动作，从而获得普及。视觉语言动作模型通常从在大规模网络数据集上预训练的大型视觉语言模型初始化。虽然这些模型推动了视觉语义知识迁移的前沿，但它们是在静态图像文本数据集上预训练的，这限制了它们继承时空先验的能力，而这些先验是将知识迁移到新物理技能所必需的。

视觉语言动作模型中的泛化。视觉语言动作模型（VLA）的泛化能力主要在物体和语义层面得到验证（Brohan 等，2023；Gao 等，2025），而对全新技能和环境的泛化仍然有限。尽管仅使用 ~ 500 小时的真实世界数据进行训练，DreamZero 在 Genie Sim 3.0 上仍表现出不俗的性能，该仿真基准包含 100 个不同任务，且未显式使用 1 万小时的仿真训练数据。

具体而言，现有利用视觉语言动作模型的工作通过为特定任务收集数百个不同环境中的人类遥操作数据来实现环境泛化（Physical Intelligence, 2025）。此外，虽然当前视觉语言动作模型试图通过覆盖大量语言条件运动原语库来实现任务泛化（Gemini Robotics Team, 2025），但这种方法从根本上受限于用固定的回合级语言条件任务集来捕捉海量可能的物理交互和运动的不切实际性。相比之下，基于视频的世界模型从数据中的每一对连续帧中学习，同时利用大规模视频预训练来理解物理动力学。

2.2. 基于视频模型的机器人策略

机器人学中的视频生成。先前工作表明，视频生成模型可用于合成机器人轨迹，并在测试时通过多种方法提取可执行动作：逆动力学模型（Du 等, 2023; Zhou 等, 2024）、作为稠密对应的光流（Ko 等, 2024），或作为高层规划的轨迹预测（Du 等, 2024; Yang 等, 2024）。其他工作生成人类视频——无论是使用三维跟踪（Liang 等, 2024）还是针对新场景和新动作（Bharadhwaj 等, 2024; Chen 等, 2025）——并使用点跟踪目标训练策略。最近，（Jang 等, 2025; Luo 等, 2025）证明视频生成模型能够利用其强大的泛化能力，为新环境中的未见行为生成合成机器人数据。

视频与动作联合生成。另一条工作线将视频与动作生成相结合，用于端到端学习。这些方法表明，在动作预测的同时引入世界建模目标，能够提升多任务性能、样本效率以及对新场景和新物体的泛化能力。先前的工作（Cheang 等人, 2024; Li 等人, 2025; Won 等人, 2025; Wu 等人, 2024; Zhao 等人, 2025; Zheng 等人, 2025; Zhu 等人, 2025）从零开始或基于视觉语言动作模型（VLA）学习联合世界建模与动作预测，而更近期的工作（Hu 等人, 2024; Kim 等人, 2026; Liang 等人, 2025; Liao 等人, 2025; Pai 等人, 2025）利用预训练的视频扩散模型来继承丰富的视觉动态先验。我们将这些模型统称为世界动作模型（World Action Models, WAMs），因为它们利用世界建模能力（预测未来状态）来进行动作预测。我们使用“世界动作模型（WAMs）”而非“视频动作模型（VAMs）”这一术语，以反映视频只是可能的世界建模目标之一——未来的 WAMs 可能将动作与其他预测模态对齐，例如触觉感知、力反馈或学习到的潜在表示。与先前的 WAMs 相比，DreamZero 系统地探索了数据多样性和规模，以充分展现 WAMs 的泛化潜力；采用了更适合长时程世界-动作建模的自回归架构；在新任务和新环境中均达到了最先进的泛化性能；并实现了最先进的跨具身迁移，包括从不同具身（仅视频）学习以及对新具身的少样本适应。

为什么选择世界动作模型（WAMs）构建于视频扩散主干之上的世界行动模型（World Action Models, WAMs）继承了来自网络规模数据的丰富时空先验，兼具两种范式优势：端到端视觉语言行动模型（Vision-Language-Action Models, VLAs）的无缝梯度流与用于规划的密集世界建模监督。与在紧凑潜空间中从头学习动力学的潜空间世界模型（Assran et al., 2025; Hafner et al., 2019, 2020, 2023）不同，WAMs 利用预训练的视频表示，这些表示已从互联网规模数据中编码了物理动力学。该方法的核心是学习视频与动作的联合分布——DreamZero 同时学习两种模态，视频预测作为隐式视觉规划器指导动作生成。这种表述不仅意味着提升机器人能力可归结为提升视频生成，还实现了当前 VLAs 难以企及的三项能力：对新任务的零样本泛化、从异构机器人数据中有效学习，以及从视频中极其高效的跨具身迁移。我们在附录 A 中进一步讨论了 WAMs 与替代世界模型架构（如潜空间、三维点云）之间的差异。




图 4：DreamZero 的模型架构。模型接收三种输入：视觉上下文（通过变分自编码器（VAE）编码）、语言指令（通过文本编码器）和本体感受状态（通过状态编码器）。这些输入由自回归扩散变换器（DiT）主干使用流匹配进行处理，通过独立的解码器联合预测未来视频帧和动作。在训练阶段（左），对于每个数据块，模型以干净视频上下文为条件对带噪视频和动作潜变量进行去噪。在推理阶段（右），预测在真实世界中异步执行，真实观测被反馈到键值缓存（KV cache）中以防止误差累积。

3. DreamZero

预训练视频扩散模型从网络规模数据中提供了丰富的时空先验，使其成为机器人策略的有吸引力的骨干。然而，将这些模型转化为有效的世界行动模型（World Action Models, WAMs）面临三个关键挑战：（1）视频-行动对齐：联合预测视频和行动需要视觉未来与运动指令之间的紧密耦合，但天真地组合独立的视频和行动头可能导致错位；（2）架构设计：双向还是自回归架构更适合 WAMs 仍不清楚，这涉及模态对齐、误差累积和推理效率的影响；（3）实时推理：视频扩散模型需要在高维潜空间中进行迭代去噪，使其对于闭环控制来说过于缓慢。

DreamZero 通过三个设计选择应对这些挑战。首先，我们训练一个单一的端到端模型，以共享目标联合去噪视频和行动，确保模态之间的深度整合。其次，我们采用自回归架构并利用闭环设置：在每个行动块执行后，我们在 KV 缓存中用真实观测替换预测帧，消除累积误差，同时通过 KV 缓存实现高效推理，并保持原生帧率以实现精确的模态对齐（见图 4 右侧）。第三，我们引入一套系统级、实现级和模型级的优化，实现了 $38 \times$ 倍的推理加速，使得在 7Hz 下实现实时控制。我们在第 3.1 节详细说明模型架构，在第 3.2 节说明实时执行。

3.1. 模型架构

问题表述。 DreamZero 联合预测视频 $\mathbf{o}_{l:l+H}$ 和行动 $\mathbf{a}_{l:l+H}$ ，条件为语言指令 $\mathbf{c}$ 、本体感觉状态 $\mathbf{q}_l$ 以及包括当前和过去历史的视觉观察 $\mathbf{o}_{0:l}$ ，其中 $H > 0$ 是固定时间范围， l 是从轨迹中采样的随机索引。注意，视频和行动的联合预测是（1）自回归视频预测和（2）从逆动力学模型（IDM）进行行动预测的分解：

$$\underbrace{\pi_0(\mathbf{o}_{l:l+H}, \mathbf{a}_{l:l+H} \mid \mathbf{o}_{0:l}, \mathbf{c}, \mathbf{q}_l)}_{\text{DREAMZERO}} = \underbrace{\pi_0(\mathbf{o}_{l:l+H} \mid \mathbf{o}_{0:l}, \mathbf{c}, \mathbf{q}_l)}_{\text{video prediction}} \underbrace{\pi_0(\mathbf{a}_{l:l+H} \mid \mathbf{o}_{0:l+H}, \mathbf{q}_l)}_{\text{IDM}} \quad (1)$$

与使用两个独立模型（视频预测模型和逆动力学模型）来建模分解目标不同（Li 等人, 2026; Pai 等人, 2025），我们训练一个端到端的单一模型，采用联合预测目标。我们认为，这种端到端设计通过两种模态之间的深度集成，能够实现更好的视频-动作对齐。由于预训练视频模型已经在多样化的网络规模视频数据上针对视频预测目标进行了优化，DreamZero 只需额外学习为机器人具身视频预测视频，并从生成的视频中提取相应的动作。我们进一步假设，这比从视觉语言模型（VLM）训练视觉语言动作模型（VLA）的传统做法更能促进泛化，因为我们的方法显式地从视频帧中学习时间动态，这些视频帧既用作条件输入，也用作预测目标。

模型架构。模型架构如图 4 所示。为了保留视频模型的泛化能力，我们引入了最少的额外参数：状态编码器、动作编码器和解码器。对于包含多个视角的机器人训练数据，我们将所有视角拼接成单个帧，而不是对骨干模型进行架构更改。

具体而言，DreamZero 被训练为自回归地预测视频帧和相应的动作。自回归生成具有以下优势：（1）通过利用键值缓存（KV-cache）实现更快的推理速度；（2）策略模型可以利用视觉观察历史作为下一步生成的指导；（3）避免了双向模型固有的模态对齐挑战（视频、动作和语言对齐）。具体来说，双向扩散通常需要处理固定长度的序列，这往往需要进行视频子采样，从而扭曲原生帧率，可能损害视频-动作对齐。另一方面，自回归生成利用键值缓存，在单次前向传递中支持任意长的上下文。这保留了原生帧率，确保视频帧与机器人动作之间的精确对齐。关于这一差异的一些细节说明在附录 B 中提供。

我们仅对视频模态引入自回归建模，以避免闭环动作预测带来的误差传播。DreamZero 以分块方式预测视频帧；每个块包含固定数量的潜在帧 K 以匹配动作时域。分块生成使得模型能够在可变长度的视频上进行训练，类似于大语言模型在可变长度的语言标记上进行训练的方式。我们在附录 C 中提供了不同模态的 QKV 注意力掩码策略的更多细节。

训练目标。与近期的视频扩散模型和视觉语言动作模型类似，我们采用流匹配（Flow Matching）作为训练目标（Albergo 等人, 2023; Lipman 等人, 2022; Liu 等人, 2022）（Ali 等人, 2025; Team Wan, 2025; Teng 等人, 2025）。与近期的世界动作模型（WAM）不同（Kim 等人, 2026; Li 等人, 2025; Liao 等人, 2025; Zhu 等人, 2025），DreamZero 在视频和动作模态之间共享去噪时间步，以在训练初期实现更快的收敛。此外，我们采用教师强制（Teacher Forcing）作为训练目标；模型被训练为在给定干净的前序块条件下对当前噪声块进行去噪。

形式上，给定块索引 $k > 0$ 和去噪时间步 $t_k \in [0, 1]$ ，我们将原始视频 $\mathbf{o}^k$ 对应的噪声视频潜在向量表示为 $\mathbf{z}_{t_k}^k$ ，将噪声归一化动作表示为 $\mathbf{a}_{t_k}^k$ 。同一块内的所有帧共享相同的时间步 t_k ，而不同块被分配独立的时间步。我们的模型对 $\mathbf{z}_{t_k}^k$ 和 $\mathbf{a}_{t_k}^k$ 进行去噪，它们被定义为干净向量与随机高斯噪声之间的线性插值：

$$\mathbf{z}_{t_k}^k = t_k \mathbf{z}_1^k + (1 - t_k) \mathbf{z}_0^k, \quad \mathbf{a}_{t_k}^k = t_k \mathbf{a}_1^k + (1 - t_k) \mathbf{a}_0^k, \quad (2)$$

其中 $\mathbf{z}_0^k \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$, $\mathbf{a}_0^k \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ ，且 $\mathbf{z}_1^k$ 和 $\mathbf{a}_1^k$ 分别是干净的视频潜在向量和归一化动作。因此，来自前序块的干净上下文可以表示为 $\mathcal{C}_k = \{(\mathbf{z}_1^j, \mathbf{a}_1^j)\}_{j=1}^{k-1}$ 。

我们训练模型 $\mathbf{u}_\theta$ 使用以下流匹配目标来预测两种模态的联合速度：

$$\mathcal{L}(\theta) = \mathbb{E}_{\mathbf{z}, \mathbf{a}, \{t_k\}} \left[\frac{1}{K} \sum_{k=1}^K w(t_k) \left\| \mathbf{u}_\theta([\mathbf{z}_{t_k}^k, \mathbf{a}_{t_k}^k]; \mathcal{C}_k, \mathbf{c}, \mathbf{q}_k, t_k) - \mathbf{v}^k \right\|^2 \right], \quad (3)$$

其中 $w(t_k) > 0$ 是预定义的权重函数， $t_k, \mathbf{c}$ 是文本条件， $\mathbf{q}_k$ 是第 k 块的本体感受状态，速度为 $\mathbf{v}^k := [\mathbf{z}_1^k, \mathbf{a}_1^k] - [\mathbf{z}_0^k, \mathbf{a}_0^k]$ 。为了实现高效训练，我们执行轨迹级更新并应用注意力掩码（例如，详见图 14），使得当前噪声块能够关注前序块的干净上下文。我们在算法 1 中提供了伪代码。

模型推理。如图 4 所示，在推理过程中，DreamZero 联合去噪视频和动作块，利用键值缓存（KV caching）提升效率（Huang 等，2025；Teng 等，2025；Yin 等，2025）。与纯视频生成不同，我们的闭环设置允许在每个动作执行后用真实观测替换键值缓存中的生成帧（见图 14）。这消除了自回归视频生成固有的复合误差问题——这是世界-动作模型（WAM）独有的关键优势。此外，作为有状态策略，DreamZero 可以利用视觉历史完成需要记忆的任务。²。我们在算法 2 中提供了推理的伪代码。

3.2. DreamZero 的实时执行

基于扩散的世界-动作模型继承了视频基础模型的强大泛化能力，但其迭代去噪过程与反应式机器人控制之间存在根本性矛盾。我们解决两个问题：（1）是什么阻碍了世界-动作模型成为反应式策略？（2）我们如何解决这一问题以实现实时控制？

3.2.1. 反应性差距

反应式策略必须在几十毫秒内对环境变化做出响应。在单个 GPU 上直接实现 DreamZero，每个动作块大约需要 5.7 秒，原因有三个瓶颈：（1）为获得平滑动作所需的 16 个扩散步骤的迭代去噪，（2）140 亿参数 DiT 骨干网络的计算成本，以及（3）推理期间阻塞机器人运动的顺序执行。这种延迟使得闭环控制不可行。³

3.2.2. 异步闭环执行

我们解决这一问题的第一步是通过异步执行将推理与动作执行解耦。运动控制器持续执行最新的动作块，而推理则基于最新观测并发运行，而不是等待每次推理完成。这种结构将延迟约束从“推理必须在机器人移动前完成”转变为“推理必须在当前动作块过期前完成”。在我们的实验中，我们以 48 步的动作视界和 30Hz 的控制频率（每个块 1.6 秒）为双臂操作机器人部署策略。因此，我们将目标推理延迟设定在约 200 毫秒以下，以确保有足够的重叠时间实现平滑、反应式的控制。

3.2.3. 系统级优化

鉴于异步执行结构，我们通过并行与缓存优化推理吞吐量。

- **无分类器引导并行。**无分类器引导（Ho 和 Salimans，2022）需要两次前向传播（条件与无条件）。我们将这两次前向传播分配到两块图形处理器上，使每步延迟降低 47%。
- **扩散变换器缓存。**我们利用流匹配过程中速度预测的方向一致性。当连续速度之间的余弦相似度超过阈值时，我们复用缓存的速度，将有效扩散变换器步数从 16 步减少到 4 步，对动作预测的质量损失极小。

3.2.4. 实现层面的优化

我们通过编译器与核函数增强进一步降低延迟。

² 在本文中，我们未明确评估或后训练 DreamZero 在仅依赖记忆才能成功的任务上的表现。我们将其留待未来工作。³ 有人可能认为仅生成动作（而非视频）会加速推理，但在 140 亿参数规模下，我们通过实验发现速度提升微乎其微——扩散步数与扩散变换器块的数量主导了延迟。此外，由于视频与动作是联合训练以实现强跨模态对齐，单纯减少动作去噪步数会降低质量。这促使我们提出 DreamZero-Flash。

- **火炬编译与计算统一设备架构图。**本文应用带计算统一设备架构图的火炬编译以消除中央处理器开销并融合算子。静态形状仅在首条轨迹期间引发重新编译。
- **训练后量化。**在布莱克韦尔架构上，本文将权重与激活量化为 NVFP4，同时将敏感操作（查询键值、Softmax 函数）保留为 FP8，非线性操作保留为 FP16。
- **核函数与调度器增强。**本文采用 cuDNN 后端处理注意力，并将调度器操作迁移至图形处理器以消除中央处理器-图形处理器同步停顿。




图 5：解耦噪声调度。DreamZero（蓝色）对视频与动作使用耦合噪声（均为均匀分布）。DreamZero-Flash（红色）通过贝塔分布使视频偏向高噪声状态，同时保持动作噪声均匀，训练模型从噪声视觉上下文中预测干净动作。

3.2.5. 模型级优化：DreamZero-Flash

即使进行了系统优化，扩散步骤的数量仍然是主要的延迟瓶颈。然而，简单地减少步骤会降低动作质量，因为残留的视觉噪声会传播到动作预测中。

DreamZero-Flash 通过在训练期间解耦视频和动作的噪声调度来解决这个问题。关键的洞见是，在推理时，动作应该去噪到它们的最终值，同时以当前块内仍然带有噪声的视频表示为条件，因为在去噪步骤非常少（例如少于 4 步）的情况下，生成的视频标记可能仍然不准确，从而提供了一个带有噪声的条件信号。标准的 DreamZero 为两种模态采样一个共享的时间步 $t_k \sim \mathcal{U}(0, 1)$ 。这造成了训练与测试的不匹配：在训练期间，模型学习在视频和动作处于相同噪声水平时预测动作，但少步或单步推理需要预测干净的动作，而视频仍然部分带有噪声。

DreamZero-Flash 通过将视频时间步偏向高噪声状态来缩小这一差距，即通过 $t_k^{\text{video}} = 1 - \eta$ ，其中 $\eta \sim \text{Beta}(\alpha, \beta)$ 且 $\alpha > \beta$ 。在实践中，我们使用 Beta (7, 1) 作为示例配置，得到 $\mathbb{E}[t_k^{\text{video}}] = 0.125$ （主要是噪声），而动作时间步保持均匀（图 5）。在训练期间，这使模型暴露于必须从带有噪声的视觉上下文中预测干净动作的配置，直接匹配少步或单步推理机制。因此，我们将扩散步骤从四步减少到一步，将推理时间从 $\sim 350\text{ms}$ 到 ~ 150 毫秒缩短，同时性能损失最小（表 3）。此外，Flash 公式支持灵活的训练配置——例如改变视频和动作的噪声采样比例——以更好地使训练与不同的少步或单步推理机制对齐。在实践中，我们主要将 Flash 训练作为主 DreamZero 模型训练之后的最后阶段应用。

动作块平滑。为了抑制生成动作中的高频噪声，我们将块上采样到 $2\times$ 分辨率，应用 Savitzky-Golay 滤波器，然后下采样到原始分辨率。

3.2.6. 总结

表 1 总结了累积加速效果。系统和实现优化在 H100 上实现了 $\sim 9\times$ 的加速，在 GB200 上实现了 $\sim 16\times$ 的加速；加入 DreamZero-Flash 后在 GB200 上实现了 $38\times$ 的加速，将延迟从 5.7 秒降低到

150 毫秒。除了 DiT 缓存和量化之外，所有系统和实现层面的优化在数学上都与基线等价，并且没有显示出可测量的性能下降。

Optimization	H100	GB200
Baseline	1×	1.1×
<i>System-level</i>		
+ CFG Parallelism	1.9×	1.8×
+ DiT Caching	5.5×	5.4×
<i>Implementation-level</i>		
+ Torch Compile + CUDA Graphs	8.9×	10.9×
+ Kernel & Scheduler Opts.	9.6×	14.8×
+ Quantization (NVFP4)	—	16.6×
<i>Model-level</i>		
+ DREAMZERO-Flash	—	38×

表 1：累积推理加速比。每一行包含其上方的所有优化。标记为“—”的条目表示该特性不适用于该硬件。

4. 实验设置

我们在两种机器人实体上验证了关于从多样化数据中学习的主要假设：AgiBot G1 移动双臂操作机器人和 Franka 单臂机器人。我们分别对每种实体进行预训练，将多实体训练留作未来工作。对于跨实体实验，我们同时利用 YAM 机器人和人类第一视角数据。AgiBot G1 的实验设置如图 7 所示。

我们与两种最先进的视觉-语言-动作模型（VLA）进行比较：GR00T N1.6（Bjorck 等人，2025）和 $\pi_{0.5}$ （Physical Intelligence，2025）。对于每个基线，我们评估两种初始化策略：（1）从头开始，使用预训练的 VLM 权重，不包含先前的机器人数据训练，以便与 DreamZero 进行公平的同类比较；（2）从预训练开始，使用在数千小时跨实体机器人数据上预训练的官方检查点。然后，两种变体在与 DreamZero 相同的数据上进行训练：^{~500} 我们为 AgiBot G1 收集的遥操作数据小时数，以及用于 Franka 的 DROID（Khazatsky 等人，2024）。我们通过匹配总批大小和梯度步数，使所有方法的计算预算保持可比。⁴

4.1. 预训练

数据。我们的数据收集理念与现有 VLA 不同。虽然近期工作表明 VLA 可以从中等规模的数据集中学习有效策略，但这些方法通常依赖于结构化的、以任务为中心的演示来确保行为一致性。我们假设，仅学习预测动作而不编码关于未来世界状态的知识，使得有效利用高度异构、非重复的数据变得困难，因为模型必须从嘈杂的状态-动作对中隐式推断动态。相比之下，我们假设 DreamZero 的世界建模目标能够从多样化演示中有效学习，使我们能够在数据收集过程中优先考虑广度和实用性，而非重复性。

利用 AgiBot G1，我们在 22 个独特环境中收集了约 500 小时的遥操作数据（见图 15），包括家庭、餐厅、超市、咖啡店和办公室——优先考虑任务多样性和现实世界实用性，而非任务特定重复。如图 6 所示，每个回合平均约 4.4 分钟，包含约 42 个子任务——比典型机器人操作数据集（Khazatsky 等人，2024；Walke 等人，2023）的时域显著更长。技能分布反映了现实世界部署需求：导航实现工作空间之间的移动，而躯干调整允许

⁴ 对于从预训练基线，这构成在官方权重之上的持续训练。




图 6: AgiBot 预训练语料库的分布统计: 7.2K 个回合 (~ 500 小时) 的回合时长、子任务密度和技能覆盖。

与不同高度（架子、橱柜）的物体交互。数据收集流程的更多细节见附录 E.⁵

我们还使用 DROID (Khazatsky 等人, 2024) 在 Franka 单臂机器人上验证了 DreamZero, DROID 是公开可用的最异构机器人数据集之一, 以证明 WAM 在多样化开源数据上的有效性, 并在发布我们内部 AgiBot 数据集之前实现可复现性。我们开源了检查点和推理代码, 以在 PolarIS (Jain 等人, 2025).⁶

训练。我们使用 Wan2.1-I2V-14B-480P (Team Wan, 2025), 一个 14B 图像到视频扩散模型, 作为 DreamZero 的主干。我们训练 100K 步, 全局批大小为 128, 用于 AgiBot 数据集; 训练 100K 步, 全局批大小为 128, 用于 DROID 数据集。我们更新所有 DiT 块、状态编码器、动作编码器和动作解码器, 同时冻结文本编码器、图像编码器和 VAE。⁷ 对于两个数据集, 我们过滤掉空闲动作, 并使用相对关节位置作为默认动作表示。我们还进行了一些消融实验 (第 5.2 节), 其中从 Wan2.1-I2V-5B-480P 初始化, 以观察模型大小 (5B 与 14B) 的影响。

评估协议。我们在预训练后直接对模型进行评估。默认评估设置为未见环境和未见物体——由于预训练与后训练数据采集地点与评估地点不同, 每个基准本质上测试的是分布外泛化能力, 而非训练分布内的插值。我们从两个类别进行评估: 已知任务与未见任务。我们将任务的粒度定义为任务所需动作与

⁵ 我们计划在后续版本中开源该数据集。部分样本可在 https://dreamzero0.github.io/training_data_gallery 查看。⁶ 可在 <https://github.com/dreamzero0/dreamzero> 获取。⁷ 我们尝试了低秩适应 (LoRA) (Hu 等人, 2022), 但发现其导致次优结果。




图 7: AgiBot 评估设置。我们是泛化评估的先行者，默认设置为未见环境和未见物体。

物体类型的组合。例如，若训练数据包含折叠红色衬衫，而评估模型折叠不同尺寸的黑色衬衫，则视为已见任务。另一方面，若评估模型折叠袜子，则视为未见任务，因为折叠袜子所需的动作与折叠衬衫不同（见图 7 中的样本）。

AgiBot 评估协议。对于已见任务，我们从预训练分布中选取 10 项任务，包括拾放变体、堆叠、擦拭和折叠；在 4 台机器人上每项任务执行 8 次展开，每次处于不同环境和不同物体（每个检查点共 80 次展开）。我们将 10 项已见任务分为三类：拾放-简单（拾放水果、擦拭污渍、从袋中取出水果）、拾放-困难（拾放叉子/勺子、将笔放入笔筒、将杯子放在杯垫上、将碗/杯子排成一列堆叠）以及接触丰富操作（折叠衬衫、折叠短裤、堆叠衣物）。对于未见任务，我们评估 10 项训练中不存在的任务——如熨烫、绘画、拉车、立方体堆叠、从人体模型上取下帽子以及解开鞋带——在 4 台机器人上每项任务执行 8 次展开（每个检查点共 80 次展开）。每次评估展开的初始帧和提示的完整列表见附录 F，部分评估展开可在此处查看。⁸

DROID 评估协议。我们在 20 个已见任务和 20 个未见任务（动词不在 DROID 中）上进行评估，每个任务执行 2 次展开，每个检查点在 40 个任务上共进行 80 次评估展开。我们将 DreamZero 与公开发布的 $\pi_{0.5}$ -DROID 以及内部训练的 GR00T N1.6-DROID 检查点进行比较。物体位置在所有检查点中固定以确保公平性。每次展开根据部分任务完成情况从 0 到 1.0 评分；完整细节见附录 G。

4.2. 后训练

除了预训练，我们还评估 WAM 是否在使用 AgiBot 机器人的任务特定数据上改善微调性能。

数据。我们在三个下游任务上收集后训练数据：

- 叠衬衫（33 小时）：通过 5 个连续阶段折叠一件平铺的 T 恤。我们在 2 种衬衫类型中随机化初始衬衫位置。⁸
<https://dreamzero0.github.io> 用于主要评估展开，https://dreamzero0.github.io/evals_gallery 用于累积唯一评估展开。

- 水果包装（12 小时）：将 10 个水果从桌子装入袋子。我们随机化水果组合以及水果和袋子的位置。
- 清理餐桌（40 小时）：将 5 件垃圾放入垃圾桶，将 5 件餐具（盘子、碗、叉子和勺子）放入餐具箱。我们随机化物体类型、组合和位置。

训练。我们为每个任务后训练 50K 步。与预训练一样，我们更新除文本编码器、图像编码器和 VAE 之外的所有参数。

评估协议。我们测量每个任务在 10 次执行中的平均任务进度。任务进度定义为：

（1）衬衫折叠完成 5 个折叠阶段中的阶段数，（2）水果包装成功装入 10 个水果中的数量，（3）餐桌清理清除的物品数量。遵循 Barreiros 等人（2025）的方法，我们对初始场景应用图像叠加以减少方差。

5. 实验结果

5.1. 主要结果




图 8：已见任务评估。DreamZero 有效地从多样化数据中学习并泛化到新环境，在所有任务类别上均优于视觉语言动作模型。从头训练的视觉语言动作模型成功率接近零，而预训练的视觉语言动作模型表现出适度的性能——可能受益于预训练期间通过重复演示获得的具身特定知识。

我们评估 DreamZero 与基线模型相比的零样本泛化性能，并研究以下研究问题：

问题 1. 世界动作模型是否从多样化、非重复性数据中学习得更好？我们在预训练数据中存在的任务上直接评估预训练模型，但在具有未见物体的零样本环境中进行。结果如图 8 所示。

在 AgiBot G1 上，从零开始训练的视觉-语言-动作模型（VLA）在所有类别上的任务进度得分几乎为零。即使在简单的抓取放置任务（PnP Easy）中，VLA 偶尔会朝正确的物体伸手，但无法在新环境中与未见过的物体进行准确交互。相比之下，DreamZero 成功地从异构数据中学习，实现了 62.2% 的平均任务进度——比最佳预训练 VLA 基线（27.4%）高出 $2\times$ 以上，尽管这些基线在继续训练于我们的数据混合之前，已经在数千小时的跨具身机器人数据上进行了预训练。在 DROID-Franka 上，我们也展示了类似的结果；仅使用 DROID 数据集训练的 DreamZero 优于在多种机器人具身数据上训练的预训练基线模型。

我们将这一差距归因于联合视频-动作公式：VLA 需要大量机器人数据来学习直接的观察到动作映射，而世界-动作模型（WAM）利用视频生成作为动作预测的强先验，从而能够有效地学习多样化的数据并泛化到未见过的环境。值得注意的是，我们观察到紧密的




图 9：对未见任务的零样本泛化。DreamZero 在训练中缺失的 10 个任务上取得了非平凡的任务进度，而 VLA 在两种具身上都表现挣扎。

生成视频与实际执行之间的对齐，即使对于次优行为也是如此（图 16）。DreamZero 的大多数失败源于视频生成错误而非动作预测——策略忠实地执行视频预测的任何轨迹。这表明视频骨干的改进将直接转化为更好的 WAM 性能。

问题 2：WAM 能否泛化到未见过的任务？ 图 9 评估了对 10 个完全不在预训练分布中的任务的泛化能力，包括解鞋带、熨烫、用刷子绘画和握手。

在 AgiBot G1 上，从零开始训练的 VLA 实现了几乎为零的任务进度（ $< 1\%$ ），而 DreamZero 平均达到 39.5%——在“从人体模型上摘帽子”（85.7%）和“握手”（59.2%）等任务上表现强劲。DreamZero 还显著优于预训练的 VLA 基线（39.5% 对 16.3%），尽管这些基线在跨具身预训练期间可能已经遇到过其中一些任务。同样在 DROID-Franka 设置中，DreamZero 显著优于（49% 任务进度，22.5% 成功率）其他预训练基线（GROOT N1.6 为 31% 任务进度，12.5% 成功率； $\pi_{0.5}$ 为 33% 任务进度，7.5% 成功率）。

定性观察表明，预训练的视觉-语言-动作模型（VLA）往往无视指令而趋向物体并尝试抓取，这表明它们过度拟合了主导性的训练行为（例如抓取-放置），而非理解新颖的任务语义，这解释了它们尽管未能完成预期任务却仍取得部分任务进展的原因。相比之下，DreamZero 对未见任务进行视觉规划并成功执行，生成的视频与真实世界动作之间具有强对齐性。

除结构化评估外，我们还对超过 100 个额外任务进行了自由形式测试，包括“戳破气球”和“按电梯按钮”，通过口头指令进行自由形式提示。这些任务的执行过程见 https://dreamzero0.github.io/evals_gallery/。




图 10：后训练结果。WAM 在三个任务上实现了更强的后训练结果，表明 DreamZero 的环境泛化能力在后训练后得以保留。

问题 3：WAM 是否提升后训练性能？我们研究了 WAM 在针对特定任务数据进行微调后是否仍保持其泛化能力。图 10 展示了三个具有不同分布多样性的任务的结果。

DreamZero 在所有任务上与 VLA 基线持平或更优：在叠衬衫和清理桌面上性能相当，而在水果包装上显著优于基线。与图 8 和图 9 的发现类似，从头训练的基线未能学习到准确抓取目标物体的动作；这意味着从头训练的 VLA 倾向于过度拟合训练数据，无法泛化到改变桌面高度、桌面距离、物体及物体摆放位置的场景，这主要是由于评估地点位于不同的地理位置（样本见图 7）。尽管在多个机器人形态上进行重复数据的预训练大幅提升了预训练基线的后训练泛化性能，DreamZero 仍在不进行跨形态预训练的情况下与预训练 VLA 基线持平或更优。由于我们仍在未见环境中进行后训练评估，这表明 DreamZero 的环境泛化能力在后训练后得以保留。

问题 4：WAM 是否能够实现强大的跨形态迁移至未见任务？在展示世界模型（World Model）能够泛化到未见任务之后（图 9），本文进一步探究是否可以通过利用不同具身形态执行相同任务的视频数据来增强这种泛化能力。关键之处在于，对于跨具身数据，本文仅使用视频预测目标（不含动作），同时保持 AgiBot 预训练数据的联合视频-动作目标；因此，跨具身数据作为额外的视觉经验，用于强化世界模型对任务动态和预期行为的理解。




图 11：跨具身迁移。本文探索机器人到机器人（YAM → AgiBot）以及人到机器人的具身迁移，以处理未见任务。

本文探索两种设置（图 11）：（1）使用双臂 YAM 机器人进行机器人到机器人的迁移；（2）使用以自我为中心的人类演示进行人到机器人的迁移。对于每种设置，本文收集 9 个未见任务的 72 条多视角轨迹（每个任务 8 条演示，YAM 用时 20 分钟，人类用时 12 分钟）。¹⁰ 随后，本文从 DreamZero-AgiBot 检查点出发，以 1:1 的比例与预训练数据混合，进行 10K 步的联合训练。

在 9 个未见任务上的结果（表 2）表明，两种迁移设置均优于基线 DreamZero。机器人到机器人的迁移带来最大提升（38.3% $\rightarrow$ 55.4%），这可能是由于具身差距较小；YAM 和 AgiBot 均为双臂平行夹爪。人到机器人的迁移同样提升了性能（38.3% $\rightarrow$ 54.3%），尽管形态差异更大且视角为动态的以自我为中心。

Method	Task Progress
DREAMZERO	38.3% $\pm$ 7.6%
DREAMZERO + Human2Robot Transfer	54.3% $\pm$ 10.4%
DREAMZERO + Robot2Robot Transfer	55.4% $\pm$ 9.5%

表 2：跨具身迁移结果。未见任务上的平均任务进度（ $\pm$ 标准误）。仅使用 10–20 分钟的无动作视频演示数据，两种迁移设置均优于基线（结果来自表 9）。

这些结果揭示了世界模型的一个有前景的特性：与近期用于具身迁移的视觉-语言-动作（VLA）方法不同（Kareer 等，2025；Team，2025），本文方法仅依赖视觉信息，无需动作标签。尽管当前成功率仍属中等，但仅 10–20 分钟的无动作视频数据带来的持续提升，初步表明跨具身视觉经验能够有效迁移。这开辟了一条潜在的扩展路径：海量的人类视频数据——其规模比机器人数据集大数个数量级——有望使世界模型在无需动作标注的情况下习得多样技能，但还需进一步研究以强化迁移机制。

Q5. Do WAMs enable few-shot new embodiment adaptation?




图 12：少样本具身适配。我们在新具身操作数据上进行 30 分钟的后训练，并在需要强语言遵循的抓取-放置变体任务上进行评估，探索少样本具身适配。

我们在新的双臂机械臂（YAM 机器人）上对 DreamZero-AgiBot 检查点进行后训练，仅使用 55 条轨迹，覆盖 11 个独特任务（ $\sim$ 30 分钟数据）。¹¹ 如图 12 所示，尽管数据和多样性有限，后训练策略仍保持强大的语言遵循能力，甚至能泛化到训练中未见的新物体，包括南瓜、泰迪熊、笔、杯面和纸袋。¹⁰ 我们排除了拉车任务，因为使用我们的双臂 YAM 机器人设置通过遥操作收集数据不可行。¹¹ 我们可视化了全部 30 分钟的操作数据 https://dreamzero0.github.io/yam_gallery/

即使在数据极少的情况下，我们观察到视频-动作对齐紧密，证明了非常高效的跨具身迁移。

我们假设有两个因素促成了这种高效性：（1）AgiBot G1 和 YAM 具身的视觉相似性（两者都配备双臂平行夹具），以及（2）更根本的是，从预测视频中学习隐式逆动力学模型可能本质上比直接策略学习更具样本效率——模型只需学习从视觉未来到动作的映射，同时利用预训练视频模型对物理动力学的现有理解。与我们在 AgiBot 上的发现一致，失败主要源于视频预测错误而非动作提取，这表明在后训练期间增加任务多样性可以进一步提高性能。¹²

问题 6: DreamZero-Flash 在更少的去噪步骤下是否保持性能？ 我们评估 DreamZero-Flash 在激进的单步去噪下是否能保持任务性能。如表 3 所示，将 DreamZero 从 4 个去噪步骤减少到 1 步，在桌面清理任务上任务进度大幅下降（83% $\rightarrow$ 52%）。相比之下，DreamZero-Flash 在单步推理下实现了更高的平均成功率（74%），仅比 4 步基线低 9%，同时速度 $\sim 2\times$ 更快。这表明解耦噪声调度为实时部署提供了更有效的速度-精度权衡。

Method	Denoising steps	Task Progress	Inference speed	$\times$ Speed up
DREAMZERO	4	83% $\pm$ 6.1%	350ms	1
DREAMZERO	1	52% $\pm$ 10.2%	150ms	2.33 $\times$
DREAMZERO-Flash	1	74% $\pm$ 10.1%	150ms	2.33 $\times$

表 3: DreamZero-Flash 评估。 在不同去噪步骤下桌面清理任务的任务进度（ $\pm$ 标准误）。DreamZero-Flash 仅用 1 个去噪步骤就恢复了大部分 4 步性能。

5.2 模型与数据消融

我们进行消融实验，以分离数据多样性、模型规模和架构的贡献。由于计算约束，所有消融模型均以 5 万步和批大小 32 进行训练，并在 PnP Easy 任务上进行评估以进行一致比较。

Architecture	Model Size	Data	Task Progress
<i>Q1. Data Diversity</i>			
DREAMZERO (AR)	14B	Repetitive	33% $\pm$ 4.2%
DREAMZERO (AR)	14B	Diverse	50% $\pm$ 6.3%
<i>Q2. Model Scale</i>			
DREAMZERO (AR)	5B	Diverse	21% $\pm$ 4.2%
DREAMZERO (AR)	14B	Diverse	50% $\pm$ 6.3%
VLA	5B	Diverse	0% $\pm$ 0.0%
VLA	14B	Diverse	0% $\pm$ 0.0%
<i>Q3. Architecture (Bidirectional vs. AR)</i>			
DREAMZERO (BD)	14B	Diverse	50% $\pm$ 14.4%
DREAMZERO (AR)	14B	Diverse	50% $\pm$ 6.3%

表 4: 模型与数据消融。 PnP Easy 任务上的任务进度（ $\pm$ 标准误）。AR = 自回归，BD = 双向。所有模型均以 5 万步和批大小 32 进行训练。

¹² 在此特定后训练实验中，我们仅利用了 11 条针对每个任务独特的简短全局语言标注。我们假设语言多样化也能实现更强的迁移，但将进一步的调查留待未来工作。

问题 1：数据多样性是否提升泛化能力？ 我们将 DreamZero 在 500 小时多样化数据与 500 小时重复数据上的训练进行比较，后者包含 70 个任务，每个任务使用相似物体位置和配置进行多次重复演示。如表 4 所示，多样化数据显著提升泛化能力（即使在简单的拾放任务上也达到 33% $\rightarrow$ 50%）。我们假设这反映了 WAM 的学习动态：由于视频预测大部分继承自预训练，关键挑战在于学习逆动力学。鲁棒的 IDM 需要跨不同上下文的多样化状态-动作对应关系，而重复数据本质上缺乏这一点。

问题 2：世界动作模型（WAM）的性能是否随模型规模扩展？ 对于 VLA，扩大模型规模可提升语义推理能力，但不一定提升动作预测能力。我们发现 WAM 表现出更清晰的扩展行为：14B 模型显著优于 5B 模型（50% 对 21%），较小的模型容易出现视觉幻觉，进而传播到错误动作。

为确保公平比较，我们还将 VLA 基线扩展到与 DreamZero 相同规模，方法是从 8B 和 32B 预训练 VLM（Yang 等，2025）初始化，截断到变换器块的前半部分，并按照 Bjorck 等（2025）附加基于 DiT 的动作模块。如表 4 所示，更大的 VLA 仍然无法从多样化数据中学习（任务进度为 0%），通常徘徊在物体附近而不进行接触。这表明仅扩展模型容量并不能解决 VLA 在多样化数据分布上的困难。

问题 3：自回归架构是否优于双向架构？ 我们将 DreamZero 的自回归（AR）架构与双向（BD）变体进行了比较。虽然任务进度相似（表 4），但 AR 模型产生的运动明显更平滑——通过整个动作序列进行反向传播能够实现更好的时序一致性。此外，由于键值缓存，AR 推理速度提高了 $3-4 \times$ 倍。

6. 讨论与未来工作

世界动作模型的缩放定律。 我们已在表 4 中确认，利用更大的视频骨干网络并在多样化数据上训练可提升下游性能。然而，对于机器人基础模型，特别是世界动作模型（WAM），我们仍缺乏缩放定律的证据。类似于语言模型的缩放定律（Kaplan 等，2020），需要探索依赖于模型大小、数据集大小和训练计算的 WAM 缩放定律，以确定提取 WAM 最大能力的最优配置。我们预计 WAM 的缩放趋势将不同于视觉-语言-动作模型（VLA），展现出更直接的动作缩放定律。我们将 WAM 缩放定律的深入研究留作未来工作。

从野外人类数据中学习。 尽管我们已研究利用以自我为中心的人类数据来提升在未见任务上的性能（第 5 节），但我们的实验仍局限于小规模实验室内数据（仅 12 分钟）。最近，大量人类视频数据已发布，其分布比机器人数据更加多样化（Chen 等，2026；Grauman 等，2022；Hoque 等，2025）。由于 WAM 在多样化的互联网视频数据上进行了预训练，我们假设利用与机器人操作任务相关的大规模以自我为中心的人类视频数据，将比当前的 VLA 带来更强的下游机器人任务迁移。我们将此方向留作未来工作。

更快的推理。 通过模型与系统优化，本文使 DreamZero 能够在 2 块 GB200 上以 7Hz 运行。然而，与当前在消费级 GPU 上运行速度可达 20Hz 以上的视觉语言动作模型相比，DreamZero 由于参数量大以及视频模型迭代去噪的特性，计算成本仍然较高。未来，若更小的视频骨干模型也具备强大的泛化能力，世界动作模型有望在轻量级边缘设备上作为实时系统 1 模型使用。

长程推理。 当前 DreamZero 架构主要作为系统 1 模型运行。尽管 DreamZero 具有视觉记忆的概念，但目前仅支持短程（6 秒）。稳健的长程执行需要系统 2 规划器或具有显著扩展上下文窗口的世界动作模型。

对于前者，模块化双系统架构（Shi 等人，2025）与统一方法（Deng 等人，2025）均提供了有前景的方向。对于后者，可借鉴基于视频的世界模型中在扩展时间范围内保持连贯生成的技术（Ball 等人，2025；HunyuanWorld，2025），以扩展世界动作模型的上下文长度。

高精度任务。尽管 DreamZero 在任务与环境间具有广泛泛化能力，但在需要亚厘米级精度的任务（如钥匙插入或精细装配）上，它继承了行为克隆常见的局限性。本文的多样化预训练策略优先考虑广度，可能不足以覆盖这些高精度操作所需的密集演示。尽管如此，近期研究（Kim 等人，2026）显示，世界动作模型在毫米级容差的高精度操作任务中可能具有优势，这是一个令人鼓舞的信号，表明广泛泛化与精细灵巧性之间的权衡有望通过进一步研究得到调和。

面向世界动作模型的具身设计。我们假设两个关键因素将塑造未来世界行动模型（WAM）发展的最佳机器人形态：

（1）自由度：更高自由度的机器人将需要更多操作数据来学习准确的隐式逆动力学模型（IDM），因为从视觉未来到运动命令的映射随运动学复杂度呈组合式增长。量化隐式逆动力学模型的准确率仍是一项挑战。（2）人类相似性：与人类更相似的形态——特别是具备灵巧操作能力的人形机器人——尽管自由度更高，但可能更高效地迁移，因为它们既能利用视频预训练中的运动先验，也能利用海量的人类第一视角视频。这些因素方向相反——然而类人形态可能通过以机械简单性换取对网络规模人类数据的访问而胜出——这是下一代机器人基础模型的燃料。

7. 致谢

这项工作离不开我们出色的机器人操作员：Alec Nagal、Inho Rha、Ava Yazdanfar、Sally Huynh、Rachit Deo、Alaa Eltayeb、Andres Rocha、Brian Dang、Cher Choi、Cristaldo Campos、Ethan Sushil Dhillon、Jeremy Chimienti、Leilee Naderi、Manish Shah、Manoj Hallegere、Nick Aguilar、Paul Truong、Rahul Sampagaon、Shreya Raj、Nadia Laswi、Amitoj Sandhu、Omkaar Buddhikot 和 Wesley Durbano。我们还感谢 Pranav Atreya 在将 DreamZero-Droid 集成到 RoboArena 基准中的支持。我们也感谢 Danyi Chen、Ming-Yu Liu 和 Spencer Huang 的持续支持，以及 Nishanth Kumar、KR Zentner、Fernando Castaneda Garcia-Rozas、Zhengyi Luo、Yunfan Jiang 和 Max Li 的富有成效的讨论。

A. 与替代世界模型架构的比较

“世界模型”一词涵盖了超越基于视频预测的广泛方法家族。这里我们讨论世界行动模型与这些替代方案的区别。

潜空间世界模型。联合嵌入预测架构（Joint Embedding Predictive Architectures, JEPAs）（Assran 等，2023，2025；Bardes 等，2024；LeCun，2022）在抽象潜空间而非像素空间中预测未来状态，提供了计算效率并能够丢弃不可预测的细节。V-JEPA 2（Assran 等，2025）在机器人领域展示了这一方法，在 62 小时机器人数据上训练后，在操作任务上实现了零样本规划。类似地，Dreamer 系列（Hafner 等，2019，2020，2023，2025）为基于模型的强化学习学习紧凑的潜动力学模型。然而，这些方法将动力学建模为 $p(s_{t+1}|s_t, a_t)$ ——基于当前状态和动作预测下一状态——因此在测试时需要目标条件规划或搜索来生成轨迹。

三维点云世界模型。PointWorld（Huang 等，2025）将状态和动作统一在共享的三维空间域中，以机器人动作为条件将场景动力学预测为三维点流。该公式实现了与具体形态无关的学习，并能够与模型预测控制（MPC）实时集成。然而，与潜世界模型一样，它在推理时需要显式优化（例如，MPPI 采样）来生成动作轨迹。

关键区别。这些替代方法具有一个共同特征：它们建模前向动力学，并在部署时需要单独的反向动力学模型或显式的规划/搜索过程。相比之下，WAM 联合建模 $p(\mathbf{o}_{t:t+H}, \mathbf{a}_{t:t+H} | \mathbf{o}_{0:t}, \mathbf{c})$ ，直接生成与预测的视觉未来对齐的动作轨迹，无需测试时优化。这使得能够以 7Hz 的频率进行实时闭环控制——这一频率对于基于搜索的方法来说将具有挑战性——同时继承视频预训练中丰富的时空先验。

B. 双向与自回归 WAM




图 13：双向与自回归 WAM。当采样点落在任务中途时 ($T=20$)，双向 WAM 必须对视频进行子采样以与语言图注对齐，从而扭曲原生帧率并降低视频-动作对齐度。自回归 WAM 通过以视频上下文为条件避免了这一权衡，同时保留了语言-视频对应关系和原生帧率。

图 13 展示了双向世界行动模型在训练闭环系统时面临的一个关键挑战。给定长时程演示中的语言标注，模型必须学习该指令对应特定的视频区间。在双向架构中，若不进行下采样，模型接收到语言指令（例如“将黑色物体放入抽屉”），但通常生成的视频仅覆盖任务区间的一小部分，导致语言描述的动作尚未出现在预测帧中。这种不匹配导致语言跟随性能显著下降，这通过内部视频预测基准测得。

一种自然的解决方案是对视频进行下采样以匹配任务图注区间。然而，这给闭环训练带来了新问题：我们需要模型能够接收任务中任意时间点的观测，而不仅仅是起始点。当采样点落在任务中途时（例如图 13 中的 $T=20$ ），下采样会扭曲原生帧率，使视频-动作对齐的学习难度大幅增加。

自回归世界行动模型可以规避这一困境。通过以视频上下文为条件而非下采样，它们同时保留了语言-视频对应关系和原生帧率，从而在语言、视频和动作三种模态之间实现紧密对齐。

C. 模型与训练细节




图 14: DreamZero 的注意力策略。(a) DreamZero 训练所用的 QKV 自注意力掩码。Y 轴表示查询，X 轴表示键/值。给定条件帧（C0、C1、C2），我们训练模型预测后续帧的速度（Z1、Z2、Z3）和动作（Y1、Y2、Y3）。(b) 在推理过程中，我们计算条件帧的键值缓存并将其拼接，以预测动作和帧。例如，Y3（动作）能够关注 C0、C1 和 C2，在训练和推理过程中均将先前的视觉观测作为历史信息来预测当前动作。注意，推理时的 C0、C1 和 C2 被替换为真实观测。

我们在图 14 中可视化了训练和推理的注意力掩码。对于 DreamZero，我们将每个块设置为 $K = 2$ 个潜在帧。根据初步结果，我们观察到 $K = 2$ 在经验上优于 $K = 1$ 。默认情况下，我们将块的数量设置为 $M = 4$ 。如果轨迹长度短于 $M = 4$ ， M ，则可以小于 4。对于 AgiBot 训练数据，视频以 5FPS 的比率采样，动作以 30Hz 采样。我们使用 $H = 48$ 的动作范围。因此，视频和动作每个块跨越 1.6 秒。对于 DROID 训练，视频以 5FPS 的比率采样，动作以 15Hz 采样。我们使用 $H = 24$ 的动作范围。因此，与 AgiBot 相同，视频和动作每个块跨越 1.6 秒。最大上下文长度为 8 个潜在帧（ 4×2 ），相当于 33 个原始帧，跨越 6.6 秒。我们将增加 WAM 的视觉上下文作为未来工作。

Algorithm 1 DREAMZERO Training (Flow Matching)

```

1: Input: Dataset  $\mathcal{D}$ , Text condition  $\mathbf{c}$ 
2: Hyperparams: Number of chunks  $M$ 
3: Model:  $\mathbf{u}_\theta$  (Joint Video-Action DiT)
4: while not converged do
5:   Sample trajectory  $\tau \sim \mathcal{D}$ 
6:   Encode video to clean latents  $\mathbf{z}_1^{1:M}$ , normalize
   actions  $\mathbf{a}_1^{1:M}$ 
7:   Split  $\tau$  into  $M$  chunks
8:   for  $k = 1, \dots, M$  do  $\triangleright$  Chunk-wise Training
9:     Define clean context  $\mathcal{C}_k \leftarrow \{(\mathbf{z}_1^j, \mathbf{a}_1^j)\}_{j=1}^{k-1} \triangleright$ 
     TF History
10:    Sample timestep  $t_k \sim \mathcal{U}(0, 1)$ 
11:    // Optional: DreamZero-Flash Decoupling
12:    if Flash Mode then
13:       $t_{vid} \sim \text{Beta}(7, 1)$ ,  $t_{act} \sim \mathcal{U}(0, 1)$ 
14:    else
15:       $t_{vid} \leftarrow t_k$ ,  $t_{act} \leftarrow t_k$ 
16:    end if
17:    Sample noise  $\mathbf{z}_0^k, \mathbf{a}_0^k \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 
18:    Interpolate (Eq. 2):
19:       $\mathbf{z}_t^k \leftarrow t_{vid}\mathbf{z}_1^k + (1 - t_{vid})\mathbf{z}_0^k$ 
20:       $\mathbf{a}_t^k \leftarrow t_{act}\mathbf{a}_1^k + (1 - t_{act})\mathbf{a}_0^k$ 
21:    Predict velocity:
22:       $\mathbf{v}_{pred} \leftarrow \mathbf{u}_\theta([\mathbf{z}_t^k, \mathbf{a}_t^k]; \mathcal{C}_k, \mathbf{c}, \mathbf{q}_k, t_k)$ 
23:    Target vel.  $\mathbf{v}^k := [\mathbf{z}_1^k, \mathbf{a}_1^k] - [\mathbf{z}_0^k, \mathbf{a}_0^k]$ 
24:    Loss  $\mathcal{L} \leftarrow \|\mathbf{v}_{pred} - \mathbf{v}^k\|^2 \triangleright$  Eq. 3
25:    Update  $\theta \leftarrow \theta - \eta \nabla \mathcal{L}$ 
26:  end for
27: end while

```

Algorithm 2 DREAMZERO Inference (Closed-Loop Control)

```

1: Input: Instruction  $\mathbf{c}$ , Initial Image  $\mathbf{o}_{init}$ , State  $\mathbf{q}_{init}$ 
2: Hyperparams: Steps  $N$ , Cache Thresh  $\epsilon$ 
3: Init:  $\mathcal{KV} \leftarrow \emptyset$ ,  $\mathbf{v}_{prev} \leftarrow \emptyset$ ,  $\mathbf{q}_{curr} \leftarrow \mathbf{q}_{init}$ 
4: // 1. Prefill Cache (Context Phase,  $t = 0$ )
5:  $\mathbf{z}_{init} \leftarrow \text{VAE}(\mathbf{o}_{init})$ 
6: // Pass clean video, no action/state
7:  $(\cdot, \cdot, \mathcal{KV}) \leftarrow \mathbf{u}_\theta([\mathbf{z}_{init}, \emptyset]; \mathcal{KV}, \mathbf{c}, \emptyset,$ 
    $t = 0, \text{update}=\text{True})$ 
8: // 2. Autoregressive Loop
9: while task not done do
10:  Sample  $\mathbf{x}_0 = [\mathbf{z}_0, \mathbf{a}_0] \sim \mathcal{N}(\mathbf{0}, \mathbf{I}) \triangleright$  Noise at
    $t = 0$ 
11:  // Joint Denoising (Flow Matching  $t : 0 \rightarrow 1$ )
12:  for  $i = 0 \dots N - 1$  do
13:     $t_i, t_{i+1} \leftarrow \text{Scheduler}(i, N)$ 
14:    // Optimization: DiT Caching
15:    if  $\mathbf{v}_{prev} \neq \emptyset$  and  $\text{CosSim}(\mathbf{v}_{prev}, \mathbf{v}_{last}) > \epsilon$ 
   then
16:       $\mathbf{v}_i \leftarrow \mathbf{v}_{prev}$ 
17:    else
18:       $(\mathbf{v}_i^{vid}, \mathbf{v}_i^{act}, \cdot) \leftarrow \mathbf{u}_\theta(\mathbf{x}_{t_i}; \mathcal{KV}, \mathbf{c}, \mathbf{q}_{curr},$ 
    $t_i, \text{update}=\text{False})$ 
19:       $\mathbf{v}_i \leftarrow [\mathbf{v}_i^{vid}, \mathbf{v}_i^{act}]$ 
20:       $\mathbf{v}_{prev} \leftarrow \mathbf{v}_i$ 
21:    end if
22:    // Solver Step
23:     $\mathbf{x}_{t_{i+1}} \leftarrow \mathbf{x}_{t_i} + \text{Step}(\mathbf{v}_i, t_i, t_{i+1})$ 
24:  end for
25:  // 3. Execution & Cache Update
26:   $\hat{\mathbf{a}} \leftarrow \text{Filter}(\mathbf{x}_1^{\text{action}}) \triangleright$  Clean Action  $t = 1$ 
27:  Async Execute  $\hat{\mathbf{a}}$  on Robot
28:  // Critical: Inject Ground Truth ( $t = 0$ )
29:  Real observation  $\mathbf{o}_{real}, \mathbf{q}_{real}$ 
30:   $\mathbf{q}_{curr} \leftarrow \mathbf{q}_{real}$ ,  $\mathbf{z}_{real} \leftarrow \text{VAE}(\mathbf{o}_{real})$ 
31:   $(\cdot, \cdot, \mathcal{KV}) \leftarrow \mathbf{u}_\theta([\mathbf{z}_{real}, \emptyset]; \mathcal{KV}, \mathbf{c}, \emptyset,$ 
    $t = 0, \text{update}=\text{True})$ 
32:  *Discard predicted video latent from  $\mathbf{x}_1$ 
33: end while

```

D. 实时执行细节

本附录提供了第 3.2 节中介绍的系统级、实现级和模型级优化的额外细节。

D.1. 系统级优化

无分类器引导并行。为了解决 DiT 固有的计算瓶颈，我们采用了无分类器引导

(CFG) 并行。标准 CFG 需要两次不同的模型评估——条件前向传播和无条件前向传播——通常按顺序执行。我们通过将条件评分估计和空条件评分估计分布到两个独立的 GPU 上来并行化这些操作。这有效地将每个扩散步骤的延迟降低了近一半，且对整体模型质量没有影响。

DiT 缓存。DiT 推理的迭代特性为实时应用带来了显著的计算瓶颈。以往的工作主要集中在利用扩散步骤间时间冗余的无训练缓存技术上。TeaCache (Liu 等人, 2024 年) 利用时间步嵌入调制输入之间的相对 L_1 差异作为启发式方法, 来估计输出方差并跳过冗余计算, 而 TaylorSeer (Liu 等人, 2025 年) 则采用高阶泰勒展开, 从历史导数外推未来的潜在状态。在 DreamZero 中, 我们实现了一种缓存机制, 该机制利用了流匹配过程中学习到的速度向量的方向一致性。

在推理过程中, 模型跟踪连续速度预测之间的余弦相似度。当该度量超过预定义阈值 (τ) 时, 模型通过重用缓存的速度向量, 在几个步骤的窗口内绕过 DiT 前向传递。这种自适应调度将计算资源集中在关键的轨迹更新上, 将 DiT 的平均步骤数从 16 步减少到 4 步, 同时对预测的视频和动作保真度的影响最小。

异步执行。动作块的顺序执行会在等待上游模型生成下一个块时引入停顿, 使机器人更加开环, 对实时状态变化的反应能力降低, 尤其是在块大小较大的情况下。我们使用一种异步执行机制, 将模型推理与动作执行解耦, 使两个阶段能够并发运行。运动控制器始终执行针对当前时间戳安排的最新动作, 而推理模块始终使用最新的观测。

D.2. 实现级优化

Torch 编译与 CUDA 图。由于核函数启动开销和 Python 执行, 推理主要受 CPU 限制。我们采用 torch.compile 与 CUDA 图 (mode="reduce-overhead"), 并强制完整图捕获 (fullgraph=True) 以消除图断裂。除了降低 CPU 开销, torch.compile 还通过算子融合减少内存带宽需求。我们将编译应用于五个模型组件: 扩散 Transformer、调度器、文本编码器、图像编码器和 VAE。我们强制静态形状 (dynamic=False), 这导致在首次推理轨迹中由于 KV 缓存形状变化而多次重新编译。从第二次轨迹开始, 推理无需重新编译。为了实现无错误编译, 我们重构模型以遵循函数式编程范式: KV 缓存作为输入显式传递, 并作为编译函数的输出返回。

训练后量化。我们在 Blackwell (SM100) 架构上使用 NVIDIA 模型优化器 (NVIDIA Corporation, 2024) 实现混合精度策略。我们将模型权重和激活量化为 NVFP4 (E2M1), 同时将敏感的 QKV 投影和 Softmax 操作保持在 FP8 (E4M3)。为了保持数值稳定性, 我们对包括 LayerNorm 和 RoPE 在内的非线性操作采用 FP16 累加。该配置改善了延迟, 对生成的视频和动作质量影响可忽略不计。

核函数级增强。我们通过 PyTorch 缩放点积注意力 (SDPA) 使用 cuDNN 后端进行点积注意力, 需要 PyTorch 版本 ≥ 2.9 。早期版本的 Transformer Engine 库也可以访问这些高效的 cuDNN 核函数。

调度器优化。最初的 Flow UniPC 调度器 (Zhao 等人, 2023) 实现需要 CPU 执行若干操作, 导致频繁的 CPU-GPU 同步和 GPU 停顿。我们将这些操作迁移到 GPU, 消除了不必要的 CPU 开销。

D.3. 模型级优化 — DreamZero-Flash

在标准 DreamZero 公式中, 视频与动作模态共享相同的去噪时间步 t_k :

$$t_k^{\text{video}} = t_k^{\text{action}} = t_k, \quad t_k \sim \mathcal{U}(0, 1) \quad (4)$$

DreamZero-Flash 通过将视频时间步偏向较低值（更高噪声）同时保持动作时间步均匀来解耦这些调度：

$$t_k^{\text{video}} = 1 - \eta, \quad \eta \sim \text{Beta}(\alpha, \beta), \quad t_k^{\text{action}} \sim \mathcal{U}(0, 1) \quad (5)$$

其中 $\alpha > \beta$ (e.g., $\alpha = 7, \beta = 1$)。由于 $\text{Beta}(\alpha, \beta)$ 且 $\alpha > \beta$ 将质量集中在 $\eta \approx 1$ 附近，变换后的 t_k^{video} 变量 $= 1 - \eta$ 偏向于 0，对应于高噪声视频状态。噪声样本变为：

$$\mathbf{z}_{t_k^{\text{video}}}^k = t_k^{\text{video}} \mathbf{z}_1^k + (1 - t_k^{\text{video}}) \mathbf{z}_0^k, \quad \mathbf{a}_{t_k^{\text{action}}}^k = t_k^{\text{action}} \mathbf{a}_1^k + (1 - t_k^{\text{action}}) \mathbf{a}_0^k \quad (6)$$

对于 $\text{Beta}(7, 1)$, $\mathbb{E}[\eta] = 0.875$ $\mathbb{E}[t_k^{\text{video}}, \text{产生}] = 0.125$ ，与耦合设置中的 0.5 相比。这使得模型在训练期间暴露于必须从主要噪声视觉上下文中预测动作的配置（图 5），使训练与快速动作去噪推理对齐，其中动作从噪声水平 $1 \rightarrow 0$ 一步去噪，而视频保持部分噪声。

动作块平滑。生成的动作块可能包含来自去噪的高频噪声。我们应用滤波以确保稳定的现实世界行为：首先通过三次插值将动作块上采样到 $2\times$ 分辨率，然后应用 Savitzky-Golay 滤波器（窗口大小 21，多项式阶数 3）以抑制噪声同时保留轨迹形状，最后下采样到原始分辨率。

E. AgiBot 多样化数据收集策略

我们的数据收集理念优先考虑多样性而非重复性。与在受控实验室环境中为每项任务收集数百次演示的传统方法不同，我们在 22 个真实世界环境中收集数据，涵盖家庭、餐厅、超市、咖啡店、办公室、仓库、实验室和酒店（图 15）。

E.1. 日常收集工作流程

每天，遥操作员会收到一份打印的任务清单，列出其分配区域（例如厨房区、收银台）可执行的任务。对于每个片段，他们从清单中选择三项任务（通常非常粗粒度，如“整理”），并连续执行。每项任务通常需要 1–2 分钟，因此每个片段大约持续 5 分钟。

每天结束时，遥操作员记录每项任务的执行频次。一旦某项任务被收集了 50 个片段，它就会被弃用并从任务清单中移除。我们鼓励遥操作员提出新任务，随着现有任务被弃用，他们不可避免地需要这样做。这一机制在数据收集过程中不断扩展任务分布，产生了多样行为的重尾分布。

由于我们优先考虑实用性而非重复性，我们的任务自然比典型的机器人学习数据集更粗粒度。示例包括整理物品、地面垃圾清理、购物篮归还、玩具箱整理、桌面整理和挂衣服——但完整集合会随着收集的进行而有机增长。

E.2. 多任务片段结构

三任务片段结构有两个目的：最大化每个片段内的多样性，并鼓励模型学习平滑的任务转换。例如，一个片段可能包括（1）清理桌上的餐具，（2）擦拭桌面，以及（3）整理调味品。这种设计使每个片段平均包含 42 个子任务（图 6），显著多于典型的单任务数据集。

环境多样性、任务弃用与强制扩展以及多任务片段的结合，产生了一个与常规机器人学习语料库显著不同的异构数据集。相反




图 15: 数据采集环境。我们在 22 个多样化的真实世界环境中采集遥操作数据，包括办公室、实验室、餐厅、超市、咖啡店、仓库、家庭、酒店和零售商店。这种多样性使 DreamZero 能够泛化到未见过的环境，而无需针对特定任务进行微调。

DreamZero 不是学习狭窄的特定任务策略，而是学习可跨环境和任务迁移的通用技能。有关这些粗粒度任务的示例，请参见 https://dreamzero0.github.io/training_data_gallery/（网站中展示的视频将每个粗粒度任务进行了拼接）。

F. AgiBot 评估细节

我们为 AgiBot 在表 5 中的已见任务和表 6 中的未见任务提供了评估设置。每一行显示了 4 台机器人的初始帧和指令。我们通过改变物体、位置以及用于任务的机械臂（当前表格主要展示使用左臂的评估），对每个任务每台机器人进行 2 次展开。

G. DROID 评估细节

我们为 DROID 在表 7a 和 7b 中的已见和未见任务提供了评估设置。我们通过改变物体的位置，对每个任务进行 2 次展开。

表 5: AgiBot G1 已见任务评估设置

































Category	#	Task	Image	Instruction	Image	Instruction	Image	Instruction	Image	Instruction
拾取与放置 (简单)	1	抓放水果		左臂抬起桌上的香蕉，并将其放入蓝色盘子中。		左臂抬起桌上的青柠，并将其放在浅绿色盘子上。		左臂抬起桌上的桃子，并将其放在浅盘上。		左臂抬起桌上的绿色梨子，并将其放在蓝色方格碗上。
	2	Taking out Fruit		The left arm picks up the Mango from the plastic bag and places it into the Wooden Basket		The left arm picks up the yellow pear from the plastic bag and places it onto the blue tray.		The left arm picks up the purple grapes from the plastic bag and places it into the brown basket.		The left arm picks up the watermelon from the plastic bag and places it onto the Blue Plate.
	3	Wipe the Mess		The left arm uses a sponge to wipe the coffee spill off the table.		The left arm used a black cloth to wipe the white powder off the table.		The left arm uses a napkin to wipe the creamer spill off the table.		The left arm used a paper towel to wipe the water off the table.
PnP Hard	4	PnP Fork/Spoon		The left arm picks up the Pink Fork from the table and places it onto the blue plate.		The left arm picks up the orange fork from the table and places it into the glass cup		The left arm picks up the light blue fork from the table and places it onto the orange plate		The left arm picks up the green fork from the table and places it into the blue plate.
	5	Put Pen in Holder		The left arm picks up the Red Marker pen from the table and placed it into the pen holder.		The left arm picked up the black marker from the table and placed it into the pen holder.		The left arm picked up the white marker pen from the table and placed it into the pen holder.		The left arm picked up the mechanical pencil from the table and placed it into the pen holder.
	6	Put Cup on Coaster		The left arm picks up the clear cup from the table and places it on the grey coaster.		The left arm picks up the plastic cup from the table and places it on the blue coaster.		The left arm picks up the plastic cup from the table and places it on the white coaster.		The left arm picks up the pink cup from the table and places it on the gray coaster.
	7	Stack Bowls/Cups		The robot reaches to grip the green bowl, moves it to the middle wooden bowl, and releases it to stack. It then reaches to grip the white bowl, moves it to the same location, and releases it onto the stack.		The robot reaches its left arm to grip the blue plate, moves it to the middle light green plate, and releases it to stack. It then reaches its right arm to grip the red plate, moves it over the middle stack of plates, and releases it to finish the task.		The robot reaches its left arm to grip the paper bowl, moves it over the middle white bowl, and releases it to stack. It then reaches its left arm to grip the blue checkered bowl, moves it over the stack, and releases it to finish the task.		The robot reaches its left arm to grip the pink bowl, moves it over the middle beige bowl, and releases it to stack. It then reaches its left arm to grip the white bowl, moves it over the stack, and releases it onto the stack.
Contact Rich	8	Folding Shirts		Both arms grip the bottom of the light grey short sleeve and fold it toward the middle. They then pull the short sleeve across the table to the edge. Next, both arms grasp the top of the shirt and fold it down to the middle. Finally, the right arm grips the collar and folds it down to complete the task.		Both arms fold the bottom of the green short sleeve to the middle. They then pull the shirt toward the edge of the table. Next, both arms fold the top of the shirt down to the middle. Finally, the right arm grasps the collar and folds it down to complete the task.		Both arms fold the bottom of the logo short sleeve to the middle. They then pull the shirt toward the edge of the table. Next, both arms fold the top of the shirt down to the middle. Finally, the right arm grasps the collar and folds it down to complete the task.		Both arms fold the bottom of the grey short sleeve to the middle. They then pull the shirt toward the edge of the table. Next, both arms fold the top of the shirt down to the middle. Finally, the left arm grasps the collar and folds it down to finish.
	9	Folding Shorts		Both arms fold the bottom of the tan shorts toward the middle. Then, the right arm folds the shorts in half from right to left to complete the fold.		Both arms fold the bottom of the grey shorts toward the middle. Then, the right arm folds the shorts in half from right to left to complete the fold.		Both arms fold the bottom of the white shorts toward the middle. Then, the right arm folds the shorts in half from right to left to complete the task.		Both arms fold the bottom of the green shorts toward the middle. Then, the right arm folds the shorts in half from right to left to complete the fold.
	10	件叠放衣物		双臂抬起黑色衬衫，并将其放在衣物堆上。		双臂抬起白色衬衫，并将其放在灰色毛巾上。		双臂拿起黑色连帽衫，并将其放在衣物堆上。		双臂拿起深灰色衬衫，并将其放在衣物堆上。





表 6: AgiBot G1 未见任务评估设置

#	Task	Image	Instruction	Image	Instruction	Image	Instruction	Image	Instruction
1	Untie Shoelaces		The robot coordinates both arms to simultaneously grasp the two loops of the shoelace. It then moves both arms outward in synchronized, opposing directions until the shoelace is fully untied.		The robot reaches its left arm to grasp the blue box and hold it steady. It then reaches its right arm toward the blue ribbon and moves it to untie the knot.		The robot coordinates both arms to simultaneously grasp the two loops of the knot of the box. It then moves both arms outward in synchronized, opposing directions until the knot of the box is fully untied.		The robot coordinates both arms to simultaneously grasp the two loops of the knot of the package. It then moves both arms outward in synchronized, opposing directions until the knot of the package is fully untied.
2	Remove /Put Hat		The robot reaches its right arm to grasp the crown and lifts it to remove it from the mannequin's head.		The robot reaches its left arm to grasp the hat and lifts it to remove it from the mannequin's head.		The robot reaches its left arm to grasp the hat and lifts it to remove it from the mannequin's head.		The robot reaches its left arm to grasp the hat and lifts it to remove it from the mannequin's head.
3	Draw Circle		The robot reaches its left arm to pick up the red marker and the left arm moves the marker to draw a circle on the book.		The robot reaches its right arm to pick up the marker and the right arm draws a circle on the whiteboard with the marker.		The robot reaches its left arm to pick up the black marker and the left arm moves the marker to draw a circle on the paper.		The robot reaches its right arm to pick up the marker and the right arm moves the marker to draw a line on the whiteboard.
4	Take out Straw		The left arm holds the cup on the table. Then the right arm pulls the straw out of the cup.		The left arm holds the cup on the table. Then the right arm pulls the straw out of the cup.		The left arm holds the cup on the table. Then the right arm pulls the straw out of the cup.		The right arm holds the cup on the table. Then the left arm pulls the straw out of the cup.
5	Cube Stacking		The robot reaches its right arm to pick up the green cube, moves it over the red cube, and releases it to stack. It then reaches its right arm to pick up the yellow cube, moves it over the stack, and releases it onto the green cube to finish the task.		The robot reaches its right arm to pick up the red cube, moves it over the colorful cube, and releases it to stack. It then reaches its right arm to pick up the green cube, moves it over the red cube, and releases it to finish the tower.		The robot reaches its right arm to pick up the white cube, moves it over the green cube, and releases it to stack. It then reaches its left arm to pick up the blue cube, moves it over the stack, and releases it onto the white cube to finish the task.		The robot reaches its right arm to pick up the red cube, moves it over the blue cube, and releases it to begin the stack. It then reaches its left arm to pick up the orange cube, moves it over the stack, and releases it onto the red cube to complete the three-tier structure.
6	Painting		The left arm grabs the brush. Then left arm paints with the brush on the notebook		The right arm grabs the brush. Then right arm paints with the brush on the paper		The left arm grabs the brush. Then left arm paints with the brush on the notebook		The right arm grabs the brush. Then right arm paints with the brush on the notebook
7	Ironing		The robot reaches its left arm to grasp the iron and moves it across the shorts to iron it.		The robot reaches its right arm to grasp the iron and moves it across the shirt to iron it.		The robot reaches its left arm to grasp the iron and moves it across the shirt to iron it.		The robot reaches its left arm to grasp the iron and moves it across the shirt to iron it.
8	Shake Hands		The right arm of the robot grasp the human hand to shake hands. It then initiates a rhythmic up-and-down motion to perform the handshake.		The left arm shakes the hand of the human up and down		The right arm shakes the hand of the human up and down		The left arm of the robot grasp the human hand to shake hands. It then initiates a rhythmic up-and-down motion to perform the handshake.
9	Folding (Map)		The left arm grabs the left side of the map. The right arm folds the right side of the map. The left arm folds the left side of the map.		The left arm grabs the left side of the map. The right arm folds the right side of the map. The left arm folds the left side of the map.		The right arm grabs the right side of the map. The left arm folds the left side of the map. The right arm folds the right side of the map.		The right arm grabs the right side of the map. The left arm folds the left side of the map. The right arm folds the right side of the map.
10	Pulling Cart		The robot reaches its right arm to grasp the cart and pulls it.		The robot reaches its left arm to grasp the cart and pulls it.		The robot reaches its right arm to grasp the cart and pulls it.		The robot reaches its left arm to grasp the cart and pulls it forward.

(a) DROID 上的已见任务

#	Image	Instruction	#	Image	Instruction
1		将杯子向前移动，然后将记号笔放入杯中 11			将左侧的碗移到桌子右侧。
2		将记号笔放入蓝色盒子中 12			拿起铅笔并将其放在碗上
3		从打开的抽屉中取出手套，并将其放在 13 号桌上			从桌上拿起记号笔，放入碗中
4		将记号笔放在 14 号桌上			将碗放在记号笔旁边
5		拿起苹果，放入 15 号篮子中			从碗中取出一个柠檬
6		将毛巾放在白色杯子上 (16)			将葡萄移到左侧
7		将毛巾放入平底锅 17			向后移动绿色的葡萄
8		将帽子放在桌子上 18			将面包放入烤面包机内
9		将剪刀放入抽屉 19			向下推动面包烤面包机上的控制杆
10		将毛巾放入篮子 20			从碗中拿起杯子，并将其放入其他杯子中

(b) DROID 上包含未见动词的任务

#	Image	Instruction	#	Image	Instruction
1		调整 将杯子把手朝向右侧 11			把帽子挂到三脚架上
2		扇动汉堡 12			捏开长尾夹以松开纸张
3		用刀切面包 13			撤回 从烤面包机中取出面包并放在盘子上
4		在键盘上输入“hi”14			拉紧袋子的抽绳
5		取出 从杯子中取出吸管 15			挤出 将芥末挤在面包上
6		揭示 杯子下方的物体 16			在烤箱中烘烤羊角面包
7		将物体与对应的碗匹配 17			用锅铲在平底锅中翻炒蔬菜
8		操纵 积木穿过匹配的孔洞 18			按下 烤面包机上的杠杆
9		非洲 将磁铁固定到托盘 19 上			提升 将黄色积木升至最高平台
10		组合 螺母与电池 20			将电线穿过盒子的孔洞

H. 失败案例分析

在图 16 中，我们展示了 DreamZero 生成的视频以及 AgiBot 和 DROID 的执行轨迹。总体而言，机器人执行遵循了视频模式侧生成的视觉规划。对于 DreamZero 为 AgiBot 生成的视频，机器人用左臂拿起记号笔并将其传递给右臂。与生成的视频一致，在执行轨迹中，机器人拿起记号笔的顶部，但左臂没有在白板上画线，而是将记号笔传递给了右臂。对于 DreamZero 为 DROID 生成的视频，机器人先拿起面包，而不是先打开烤箱。与生成的视频一致，在执行轨迹中，机器人先拿起面包，而不是先打开烤箱，导致机器人在拿着面包到达烤箱后轨迹陷入停滞。这意味着提升世界行动模型（WAMs）的语言遵循和视觉规划能力可能带来更好的动作执行。




图 16：生成与执行配对的示意图。我们展示了生成的视频与动作执行配对。这两个例子展示了视频预测失败且机器人遵循了失败计划的场景。DreamZero 未能生成 AgiBot G1 机器人在白板上画线的视频，也未能生成 Franka 机器人先打开烤箱的视频。

参考文献

- [1] Michael S Albergo, Nicholas M Boffi, and Eric Vanden-Eijnden. Stochastic interpolants: A unifying framework for flows and diffusions. *arXiv preprint arXiv:2303.08797*, 2023. 7
- [2] Arslan Ali, Junjie Bai, Maciej Bala, Yogesh Balaji, Aaron Blakeman, Tiffany Cai, Jiaxin Cao, Tianshi Cao, Elizabeth Cha, Yu-Wei Chao, et al. World simulation with video foundation models for physical ai. *arXiv preprint arXiv:2511.00062*, 2025. 7
- [3] Mahmoud Assran, Quentin Duval, Ishan Misra, Piotr Bojanowski, Pascal Vincent, Michael Rabbat, Yann LeCun, and Nicolas Ballas. Self-supervised learning from images with a joint-embedding predictive architecture. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2023. 20
- [4] Mido Assran, Adrien Bardes, David Fan, Quentin Garrido, Russell Howes, Mojtaba Komeili, Matthew Muckley, Ammar Rizvi, Claire Roberts, Koustuv Sinha, et al. V-JEPA 2: Self-supervised video models enable understanding, prediction and planning. *arXiv preprint arXiv:2506.09985*, 2025. 5, 20
- [5] Philip J. Ball, Jakob Bauer, Frank Belletti, Bethanie Brownfield, Ariel Ephrat, Shlomi Fruchter, Agrim Gupta, Kristian Holsheimer, Aleksander Holynski, Jiri Hron, Christos Kaplanis, Marjorie Limont, Matt McGill, Yanko Oliveira, Jack Parker-Holder, Frank Perbet, Guy Scully, Jeremy Shar, Stephen Spencer, Omer Tov, Ruben Villegas, Emma Wang, Jessica Yung, Cip Baetu, Jordi Berbel, David Bridson, Jake Bruce, Gavin Buttimore, Sarah Chakera, Bilva Chandra, Paul Collins, Alex Cullum, Bogdan Damoc, Vibha Dasagi, Maxime Gazeau, Charles Gbadamosi, Woohyun Han, Ed Hirst, Ashyana Kachra, Lucie Kerley, Kristian Kjems, Eva Knoepfel, Vika Koriakin, Jessica Lo, Cong Lu, Zeb Mehring, Alex Moufarek, Henna Nandwani, Valeria Oliveira, Fabio Pardo, Jane Park, Andrew Pierson, Ben Poole, Helen Ran, Tim Salimans, Manuel Sanchez, Igor Saprykin, Amy Shen, Sailesh Sidhwani, Duncan Smith, Joe Stanton, Hamish Tomlinson, Dimple Vijaykumar, Luyu Wang, Piers Wingfield, Nat Wong, Keyang Xu, Christopher Yew, Nick Young, Vadim Zubov, Douglas Eck, Dumitru Erhan, Koray Kavukcuoglu, Demis Hassabis, Zoubin Ghahramani, Raia Hadsell, Aäron van den Oord, Inbar Mosseri, Adrian Bolton, Satinder Singh, and Tim Rocktäschel. Genie 3: A new frontier for world models. 2025. URL <https://deepmind.google/discover/blog/genie-3-a-new-frontier-for-world-models/>. 19
- [6] Adrien Bardes, Quentin Garrido, Jean Ponce, Michael Rabbat, Yann LeCun, Mahmoud Assran, and Nicolas Ballas. V-JEPA: Video joint embedding predictive architecture. *arXiv preprint arXiv:2402.05065*, 2024. 20
- [7] Jose Barreiros, Andrew Beaulieu, Aditya Bhat, Rick Cory, Eric Cousineau, Hongkai Dai, Ching-Hsin Fang, Kunimatsu Hashimoto, Muhammad Zubair Irshad, Masha Itkina, et al. A careful examination of large behavior models for multitask dexterous manipulation. *arXiv preprint arXiv:2507.05331*, 2025. 13
- [8] Homanga Bharadhwaj, Debidatta Dwibedi, Abhinav Gupta, Shubham Tulsiani, Carl Doersch, Ted Xiao, Dhruv Shah, Fei Xia, Dorsa Sadigh, and Sean Kirmani. Gen2act: Human video generation in novel scenarios enables generalizable robot manipulation. *arXiv preprint arXiv:2409.16283*, 2024. 5
- [9] Johan Bjorck, Fernando Castañeda, Nikita Cherniadev, Xingye Da, Runyu Ding, Linxi Fan, Yu Fang, Dieter Fox, Fengyuan Hu, Spencer Huang, et al. Gr00t n1: An open foundation model for generalist humanoid robots. *arXiv preprint arXiv:2503.14734*, 2025. 2, 4, 10, 18
- [10] Kevin Black, Noah Brown, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Lachy Groom, Karol Hausman, Brian Ichter, et al. π_0 : A vision-language-action flow model for general robot control. *arXiv preprint arXiv:2410.24164*, 2024. 4
- [11] Kevin Black, Noah Brown, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Lachy Groom, Karol Hausman, Brian Ichter, et al. π_0 : A vision-language-action flow model for general robot control. URL <https://arxiv.org/abs/2410.24164>, 2024. 2

-
- [12] Rishi Bommasani, Drew A Hudson, Ehsan Adeli, Russ Altman, Simran Arora, Sydney von Arx, Michael S Bernstein, Jeannette Bohg, Antoine Bosselut, Emma Brunskill, et al. On the opportunities and risks of foundation models. *arXiv preprint arXiv:2108.07258*, 2021. 4
- [13] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Joseph Dabis, Chelsea Finn, Keerthana Gopalakrishnan, Karol Hausman, Alex Herzog, Jasmine Hsu, Julian Ibarz, Brian Ichter, Alex Irpan, Tomas Jackson, Sally Jesmonth, Nikhil Joshi, Ryan Julian, Dmitry Kalashnikov, Yuheng Kuang, Isabel Leal, Kuang-Huei Lee, Sergey Levine, Yao Lu, Utsav Malla, Deeksha Manjunath, Igor Mordatch, Ofir Nachum, Carolina Parada, Jodilyn Peralta, Emily Perez, Karl Pertsch, Jornell Quiambao, Kanishka Rao, Michael Ryoo, Grecia Salazar, Pannag Sanketi, Kevin Sayed, Jaspiar Singh, Sumedh Sontakke, Austin Stone, Clayton Tan, Huong Tran, Vincent Vanhoucke, Steve Vega, Quan Vuong, Fei Xia, Ted Xiao, Peng Xu, Sichun Xu, Tianhe Yu, and Brianna Zitkovich. Rt-1: Robotics transformer for real-world control at scale. In *arXiv preprint arXiv:2212.06817*, 2022. 4
- [14] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Xi Chen, Krzysztof Choromanski, Tianli Ding, Danny Driess, Avinava Dubey, Chelsea Finn, Pete Florence, Chuyuan Fu, Montse Gonzalez Arenas, Keerthana Gopalakrishnan, Kehang Han, Karol Hausman, Alex Herzog, Jasmine Hsu, Brian Ichter, Alex Irpan, Nikhil Joshi, Ryan Julian, Dmitry Kalashnikov, Yuheng Kuang, Isabel Leal, Lisa Lee, Tsang-Wei Edward Lee, Sergey Levine, Yao Lu, Henryk Michalewski, Igor Mordatch, Karl Pertsch, Kanishka Rao, Krista Reymann, Michael Ryoo, Grecia Salazar, Pannag Sanketi, Pierre Sermanet, Jaspiar Singh, Anikait Singh, Radu Soricut, Huong Tran, Vincent Vanhoucke, Quan Vuong, Ayzaan Wahid, Stefan Welker, Paul Wohlhart, Jialin Wu, Fei Xia, Ted Xiao, Peng Xu, Sichun Xu, Tianhe Yu, and Brianna Zitkovich. Rt-2: Vision-language-action models transfer web knowledge to robotic control. In *arXiv preprint arXiv:2307.15818*, 2023. 2, 4
- [15] Anthony Brohan, Yevgen Chebotar, Chelsea Finn, Karol Hausman, Alexander Herzog, Daniel Ho, Julian Ibarz, Alex Irpan, Eric Jang, Ryan Julian, et al. Do as i can, not as i say: Grounding language in robotic affordances. In *Conference on robot learning*, pages 287–318. PMLR, 2023. 4
- [16] Qingwen Bu, Yanting Yang, Jisong Cai, Shenyuan Gao, Guanghui Ren, Maoqing Yao, Ping Luo, and Hongyang Li. Univla: Learning to act anywhere with task-centric latent actions. *arXiv preprint arXiv:2505.06111*, 2025. 4
- [17] Chi-Lam Cheang, Guangzeng Chen, Ya Jing, Tao Kong, Hang Li, Yifeng Li, Yuxiao Liu, Hongtao Wu, Jiafeng Xu, Yichu Yang, et al. Gr-2: A generative video-language-action model with web-scale knowledge for robot manipulation. *arXiv preprint arXiv:2410.06158*, 2024. 5
- [18] Boyuan Chen, Zhuo Xu, Sean Kirmani, Brian Ichter, Dorsa Sadigh, Leonidas Guibas, and Fei Xia. Spatialvml: Endowing vision-language models with spatial reasoning capabilities. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 14455–14465, 2024. 2
- [19] Boyuan Chen, Tianyuan Zhang, Haoran Geng, Kiwhan Song, Caiyi Zhang, Peihao Li, William T Freeman, Jitendra Malik, Pieter Abbeel, Russ Tedrake, et al. Large video planner enables generalizable robot control. *arXiv preprint arXiv:2512.15840*, 2025. 5
- [20] Delong Chen, Tejaswi Kasarla, Yejin Bang, Mustafa Shukor, Willy Chung, Jade Yu, Allen Bolourchi, Theo Moutakanni, and Pascale Fung. Action100m: A large-scale video action dataset. *arXiv preprint arXiv:2601.10592*, 2026. 18
- [21] Chaorui Deng, Deyao Zhu, Kunchang Li, Chenhui Gou, Feng Li, Zeyu Wang, Shu Zhong, Weihao Yu, Xiaonan Nie, Ziang Song, et al. Emerging properties in unified multimodal pretraining. *arXiv preprint arXiv:2505.14683*, 2025. 19
-

-
- [22] Kamil Dreczkowski, Pietro Vitiello, Vitalis Vosylius, and Edward Johns. Learning a thousand tasks in a day. *Science Robotics*, 10(108):eadv7594, 2025. 4
 - [23] Danny Driess, Fei Xia, Mehdi SM Sajjadi, Corey Lynch, Aakanksha Chowdhery, Brian Ichter, Ayzaan Wahid, Jonathan Tompson, Quan Vuong, Tianhe Yu, et al. Palm-e: An embodied multimodal language model. *arXiv preprint arXiv:2303.03378*, 2023. 4
 - [24] Yilun Du, Sherry Yang, Bo Dai, Hanjun Dai, Ofir Nachum, Josh Tenenbaum, Dale Schuurmans, and Pieter Abbeel. Learning universal policies via text-guided video generation. *Advances in neural information processing systems*, 36:9156–9172, 2023. 5
 - [25] Yilun Du, Sherry Yang, Pete Florence, Fei Xia, Ayzaan Wahid, brian ichter, Pierre Sermanet, Tianhe Yu, Pieter Abbeel, Joshua B. Tenenbaum, Leslie Pack Kaelbling, Andy Zeng, and Jonathan Tompson. Video language planning. In *The Twelfth International Conference on Learning Representations*, 2024. URL <https://openreview.net/forum?id=9pKtcJcMP3>. 5
 - [26] Zhiyuan Feng, Zhaolu Kang, Qijie Wang, Zhiying Du, Jiongrui Yan, Shubin Shi, Chengbo Yuan, Huizhi Liang, Yu Deng, Qixiu Li, et al. Seeing across views: Benchmarking spatial reasoning of vision-language models in robotic scenes. *arXiv preprint arXiv:2510.19400*, 2025. 2
 - [27] Jensen Gao, Suneel Belkhale, Sudeep Dasari, Ashwin Balakrishna, Dhruv Shah, and Dorsa Sadigh. A taxonomy for evaluating generalist robot policies. *arXiv preprint arXiv:2503.01238*, 2025. 4
 - [28] Kaifeng Gao, Jiaxin Shi, Hanwang Zhang, Chunping Wang, Jun Xiao, and Long Chen. Ca2-vdm: Efficient autoregressive video diffusion model with causal generation and cache sharing. *arXiv preprint arXiv:2411.16375*, 2024. 7
 - [29] Gemini Robotics Team. Gemini robotics: Bringing ai into the physical world. *arXiv preprint arXiv:2503.20020*, 2025. 2, 4, 5
 - [30] Kristen Grauman, Andrew Westbury, Eugene Byrne, Zachary Chavis, Antonino Furnari, Rohit Girdhar, Jackson Hamburger, Hao Jiang, Miao Liu, Xingyu Liu, et al. Ego4d: Around the world in 3,000 hours of egocentric video. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2022. 18
 - [31] Pranav Guruprasad, Yangyue Wang, Sudipta Chowdhury, Harshvardhan Sikka, and Paul Pu Liang. Benchmarking vision, language, & action models in procedurally generated, open ended action environments. *arXiv preprint arXiv:2505.05540*, 2025. 2
 - [32] Danijar Hafner, Timothy Lillicrap, Jimmy Ba, and Mohammad Norouzi. Dream to control: Learning behaviors by latent imagination. *arXiv preprint arXiv:1912.01603*, 2019. 5, 20
 - [33] Danijar Hafner, Timothy Lillicrap, Mohammad Norouzi, and Jimmy Ba. Mastering atari with discrete world models. *arXiv preprint arXiv:2010.02193*, 2020. 5, 20
 - [34] Danijar Hafner, Jurgis Pasukonis, Jimmy Ba, and Timothy Lillicrap. Mastering diverse domains through world models. *arXiv preprint arXiv:2301.04104*, 2023. 5, 20
 - [35] Danijar Hafner, Wilson Yan, and Timothy Lillicrap. Training agents inside of scalable world models, 2025. URL <https://arxiv.org/abs/2509.24527>. 20
 - [36] Jonathan Ho and Tim Salimans. Classifier-free diffusion guidance. *arXiv preprint arXiv:2207.12598*, 2022. 8
 - [37] Ryan Hoque, Peide Huang, David J Yoon, Mouli Sivapurapu, and Jian Zhang. Egodex: Learning dexterous manipulation from large-scale egocentric video. *arXiv preprint arXiv:2505.11709*, 2025. 18
-

-
- [38] Edward J Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuezhi Li, Shean Wang, Lu Wang, Weizhu Chen, et al. Lora: Low-rank adaptation of large language models. *ICLR*, 1(2):3, 2022. 11
 - [39] Yucheng Hu, Yanjiang Guo, Pengchao Wang, Xiaoyu Chen, Yen-Jen Wang, Jianke Zhang, Koushil Sreenath, Chaochao Lu, and Jianyu Chen. Video prediction policy: A generalist robot policy with predictive visual representations. *arXiv preprint arXiv:2412.14803*, 2024. 5
 - [40] Wenlong Huang, Fei Xia, Ted Xiao, Harris Chan, Jacky Liang, Pete Florence, Andy Zeng, Jonathan Tompson, Igor Mordatch, Yevgen Chebotar, et al. Inner monologue: Embodied reasoning through planning with language models. In *6th Annual Conference on Robot Learning*. 4
 - [41] Wenlong Huang, Chen Wang, Ruohan Zhang, Yunzhu Li, Jiajun Wu, and Li Fei-Fei. Voxposer: Composable 3d value maps for robotic manipulation with language models. *arXiv preprint arXiv:2307.05973*, 2023. 4
 - [42] Wenlong Huang, Yu-Wei Chao, Arsalan Mousavian, Ming-Yu Liu, Dieter Fox, Kaichun Mo, and Li Fei-Fei. Pointworld: Scaling 3d world models for in-the-wild robotic manipulation. *arXiv preprint arXiv:2601.03782*, 2025. 20
 - [43] Xun Huang, Zhengqi Li, Guande He, Mingyuan Zhou, and Eli Shechtman. Self forcing: Bridging the train-test gap in autoregressive video diffusion. *arXiv preprint arXiv:2506.08009*, 2025. 8
 - [44] Team HunyuanWorld. Hy-world 1.5: A systematic framework for interactive world modeling with real-time latency and geometric consistency. *arXiv preprint*, 2025. 19
 - [45] Arhan Jain, Mingtong Zhang, Kanav Arora, William Chen, Marcel Torne, Muhammad Zubair Irshad, Sergey Zakharov, Yue Wang, Sergey Levine, Chelsea Finn, et al. Polaris: Scalable real-to-sim evaluations for generalist robot policies. *arXiv preprint arXiv:2512.16881*, 2025. 11
 - [46] Joel Jang, Seonghyeon Ye, Zongyu Lin, Jiannan Xiang, Johan Bjorck, Yu Fang, Fengyuan Hu, Spencer Huang, Kaushil Kundalia, Yen-Chen Lin, Loïc Magne, Ajay Mandlekar, Avnish Narayan, You Liang Tan, Guanzhi Wang, Jing Wang, Qi Wang, Yinzhen Xu, Xiaohui Zeng, Kaiyuan Zheng, Ruijie Zheng, Ming-Yu Liu, Luke Zettlemoyer, Dieter Fox, Jan Kautz, Scott Reed, Yuke Zhu, and Linxi Fan. Dreamgen: Unlocking generalization in robot learning through video world models. In *9th Annual Conference on Robot Learning*, 2025. URL <https://openreview.net/forum?id=3CnxNqmk1v>. 5
 - [47] Yang Jin, Zhicheng Sun, Ningyuan Li, Kun Xu, Hao Jiang, Nan Zhuang, Quzhe Huang, Yang Song, Yadong Mu, and Zhouchen Lin. Pyramidal flow matching for efficient video generative modeling. *arXiv preprint arXiv:2410.05954*, 2024. 7
 - [48] Leslie Pack Kaelbling and Tomás Lozano-Pérez. 1 rationally engineering rational robots. 4
 - [49] Jared Kaplan, Sam McCandlish, Tom Henighan, Tom B Brown, Benjamin Chess, Rewon Child, Scott Gray, Alec Radford, Jeffrey Wu, and Dario Amodei. Scaling laws for neural language models. *arXiv preprint arXiv:2001.08361*, 2020. 18
 - [50] Simar Kareer, Karl Pertsch, James Darpinian, Judy Hoffman, Danfei Xu, Sergey Levine, Chelsea Finn, and Suraj Nair. Emergence of human to robot transfer in vision-language-action models. *arXiv preprint arXiv:2512.22414*, 2025. 16
 - [51] Alexander Khazatsky, Karl Pertsch, Suraj Nair, Ashwin Balakrishna, Sudeep Dasari, Siddharth Karamcheti, Soroush Nasiriany, Mohan Kumar Srirama, Lawrence Yunliang Chen, Kirsty Ellis, et al. Droid: A large-scale in-the-wild robot manipulation dataset. *arXiv preprint arXiv:2403.12945*, 2024. 10, 11
-

-
- [52] Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, Ted Xiao, Ashwin Balakrishna, Suraj Nair, Rafael Rafailov, Ethan Foster, Grace Lam, Pannag Sanketi, Quan Vuong, Thomas Kollar, Benjamin Burchfiel, Russ Tedrake, Dorsa Sadigh, Sergey Levine, Percy Liang, and Chelsea Finn. Openvla: An open-source vision-language-action model. *arXiv preprint arXiv:2406.09246*, 2024. 4
 - [53] Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, Ted Xiao, Ashwin Balakrishna, Suraj Nair, Rafael Rafailov, Ethan Foster, Grace Lam, Pannag Sanketi, et al. Openvla: An open-source vision-language-action model. *arXiv preprint arXiv:2406.09246*, 2024. 2
 - [54] Moo Jin Kim, Yihuai Gao, Tsung-Yi Lin, Yen-Chen Lin, Yunhao Ge, Grace Lam, Percy Liang, Shuran Song, Ming-Yu Liu, Chelsea Finn, et al. Cosmos policy: Fine-tuning video models for visuomotor control and planning. *arXiv preprint arXiv:2601.16163*, 2026. 2, 5, 7, 19
 - [55] Po-Chen Ko, Jiayuan Mao, Yilun Du, Shao-Hua Sun, and Joshua B. Tenenbaum. Learning to act from actionless videos through dense correspondences. In *The Twelfth International Conference on Learning Representations*, 2024. URL <https://openreview.net/forum?id=Mhb5fpA1T0>. 5
 - [56] Nishanth Kumar, William Shen, Fabio Ramos, Dieter Fox, Tomás Lozano-Pérez, Leslie Pack Kaelbling, and Caelan Reed Garrett. Open-world task and motion planning via vision-language model generated constraints. *IEEE Robotics and Automation Letters*, pages 1–8, 2026. doi: 10.1109/LRA.2026.3656799. 4
 - [57] Yann LeCun. A path towards autonomous machine intelligence. *Open Review*, 2022. 20
 - [58] Jason Lee, Jiafei Duan, Haoquan Fang, Yuquan Deng, Shuo Liu, Boyang Li, Bohan Fang, Jieyu Zhang, Yi Ru Wang, Sangho Lee, et al. Molmoact: Action reasoning models that can reason in space. *arXiv preprint arXiv:2508.07917*, 2025. 4
 - [59] Lin Li, Qihang Zhang, Yiming Luo, Shuai Yang, Ruilin Wang, Fei Han, Mingrui Yu, Zelin Gao, Nan Xue, Xing Zhu, Yujun Shen, and Yinghao Xu. Causal world modeling for robot control. *arXiv preprint arXiv:2601.21998*, 2026. 7
 - [60] Shuang Li, Yihuai Gao, Dorsa Sadigh, and Shuran Song. Unified video action model. *arXiv preprint arXiv:2503.00200*, 2025. 5, 7
 - [61] Yi Li, Yuquan Deng, Jesse Zhang, Joel Jang, Marius Memmel, Raymond Yu, Caelan Reed Garrett, Fabio Ramos, Dieter Fox, Anqi Li, et al. Hamster: Hierarchical action models for open-world robot manipulation. *arXiv preprint arXiv:2502.05485*, 2025. 4
 - [62] Junbang Liang, Ruoshi Liu, Ege Ozguroglu, Sruthi Sudhakar, Achal Dave, Pavel Tokmakov, Shuran Song, and Carl Vondrick. Dreamitate: Real-world visuomotor policy learning via video generation. In *8th Annual Conference on Robot Learning*, 2024. URL <https://openreview.net/forum?id=InT87E5sr4>. 5
 - [63] Junbang Liang, Pavel Tokmakov, Ruoshi Liu, Sruthi Sudhakar, Paarth Shah, Rares Ambrus, and Carl Vondrick. Video generators are robot policies. *arXiv preprint arXiv:2508.00795*, 2025. 2, 5
 - [64] Yue Liao, Pengfei Zhou, Siyuan Huang, Donglin Yang, Shengcong Chen, Yuxin Jiang, Yue Hu, Jingbin Cai, Si Liu, Jianlan Luo, et al. Genie envisioner: A unified world foundation platform for robotic manipulation. *arXiv preprint arXiv:2508.05635*, 2025. 3, 5, 7
 - [65] Yaron Lipman, Ricky TQ Chen, Heli Ben-Hamu, Maximilian Nickel, and Matt Le. Flow matching for generative modeling. *arXiv preprint arXiv:2210.02747*, 2022. 7
 - [66] Feng Liu, Shiwei Zhang, Xiaofeng Wang, Yujie Wei, Haonan Qiu, Yuzhong Zhao, Yingya Zhang, Qixiang Ye, and Fang Wan. Timestep embedding tells: It’s time to cache for video diffusion model. *arXiv preprint arXiv:2411.19108*, 2024. 23
-

-
- [67] Jiacheng Liu, Chang Zou, Yuanhuiyi Lyu, Junjie Chen, and Linfeng Zhang. From reusing to forecasting: Accelerating diffusion models with taylorseers. *arXiv preprint arXiv:2503.06923*, 2025. 23
 - [68] Xingchao Liu, Chengyue Gong, and Qiang Liu. Flow straight and fast: Learning to generate and transfer data with rectified flow. *arXiv preprint arXiv:2209.03003*, 2022. 7
 - [69] Calvin Luo, Zilai Zeng, Yilun Du, and Chen Sun. Solving new tasks by adapting internet video knowledge. In *The Thirteenth International Conference on Learning Representations*, 2025. 5
 - [70] NVIDIA Corporation. Nvidia model-optimizer, 2024. URL <https://github.com/NVIDIA/Model-Optimizer>. 23
 - [71] Jonas Pai, Liam Achenbach, Victoriano Montesinos, Benedek Forrai, Oier Mees, and Elvis Nava. mimic-video: Video-action models for generalizable robot control beyond vlas. *arXiv preprint arXiv:2512.15692*, 2025. 2, 3, 5, 7
 - [72] Physical Intelligence. $\pi_{0.5}$: a vision-language-action model with open-world generalization. *arXiv preprint arXiv:2504.16054*, 2025. 4, 5, 10
 - [73] Lucy Xiaoyang Shi, Brian Ichter, Michael Equi, Liyiming Ke, Karl Pertsch, Quan Vuong, James Tanner, Anna Walling, Haohuan Wang, Niccolo Fusai, et al. Hi robot: Open-ended instruction following with hierarchical vision-language-action models. *arXiv preprint arXiv:2502.19417*, 2025. 19
 - [74] Ishika Singh, Valts Blukis, Arsalan Mousavian, Ankit Goyal, Danfei Xu, Jonathan Tremblay, Dieter Fox, Jesse Thomason, and Animesh Garg. Progprompt: Generating situated robot task plans using large language models. In *2023 IEEE International Conference on Robotics and Automation (ICRA)*, 2023. 4
 - [75] Generalist AI Team. Gen-0: Embodied foundation models that scale with physical interaction. *Generalist AI Blog*, 2025. <https://generalistai.com/blog/preview-uqlxvb-bb.html>. 16
 - [76] Team Wan. Wan: Open and advanced large-scale video generative models. 2025. 2, 7, 11
 - [77] Hansi Teng, Hongyu Jia, Lei Sun, Lingzhi Li, Maolin Li, Mingqiu Tang, Shuai Han, Tianning Zhang, WQ Zhang, Weifeng Luo, et al. Magi-1: Autoregressive video generation at scale. *arXiv preprint arXiv:2505.13211*, 2025. 7, 8
 - [78] Homer Walke, Kevin Black, Abraham Lee, Moo Jin Kim, Max Du, Chongyi Zheng, Tony Zhao, Philippe Hansen-Estruch, Quan Vuong, Andre He, Vivek Myers, Kuan Fang, Chelsea Finn, and Sergey Levine. Bridgedata v2: A dataset for robot learning at scale. In *Conference on Robot Learning (CoRL)*, 2023. 10
 - [79] John Won, Kyungmin Lee, Huiwon Jang, Dongyoung Kim, and Jinwoo Shin. Dual-stream diffusion for world-model augmented vision-language-action model. *arXiv preprint arXiv:2510.27607*, 2025. 5
 - [80] Hongtao Wu, Ya Jing, Chilam Cheang, Guangzeng Chen, Jiafeng Xu, Xinghang Li, Minghuan Liu, Hang Li, and Tao Kong. Unleashing large-scale video generative pre-training for visual robot manipulation. In *The Twelfth International Conference on Learning Representations*, 2024. URL <https://openreview.net/forum?id=NxoFmGgWC9>. 5
 - [81] An Yang, Anfeng Li, Baosong Yang, Beichen Zhang, Binyuan Hui, Bo Zheng, Bowen Yu, Chang Gao, Chengen Huang, Chenxu Lv, et al. Qwen3 technical report. *arXiv preprint arXiv:2505.09388*, 2025. 18
 - [82] Jianwei Yang, Reuben Tan, Qianhui Wu, Ruijie Zheng, Baolin Peng, Yongyuan Liang, Yu Gu, Mu Cai, Seonghyeon Ye, Joel Jang, Yuquan Deng, Lars Liden, and Jianfeng Gao. Magma: A foundation model for multimodal AI agents, 2025. 4
-

-
- [83] Sherry Yang, Yilun Du, Seyed Kamyar Seyed Ghasemipour, Jonathan Tompson, Leslie Pack Kaelbling, Dale Schuurmans, and Pieter Abbeel. Learning interactive real-world simulators. In *The Twelfth International Conference on Learning Representations*, 2024. URL <https://openreview.net/forum?id=sFyTZEqmUY.5>. 5
- [84] Seonghyeon Ye, Joel Jang, Byeongguk Jeon, Se June Joo, Jianwei Yang, Baolin Peng, Ajay Mandlekar, Reuben Tan, Yu-Wei Chao, Bill Yuchen Lin, Lars Liden, Kimin Lee, Jianfeng Gao, Luke Zettlemoyer, Dieter Fox, and Minjoon Seo. Latent action pretraining from videos. In *The Thirteenth International Conference on Learning Representations*, 2025. URL <https://openreview.net/forum?id=VY0e2eBQeh.4>. 4
- [85] Tianwei Yin, Qiang Zhang, Richard Zhang, William T Freeman, Fredo Durand, Eli Shechtman, and Xun Huang. From slow bidirectional to fast autoregressive video diffusion models. In *Proceedings of the Computer Vision and Pattern Recognition Conference*, pages 22963–22974, 2025. 8
- [86] Qingqing Zhao, Yao Lu, Moo Jin Kim, Zipeng Fu, Zhuoyang Zhang, Yecheng Wu, Zhaoshuo Li, Qianli Ma, Song Han, Chelsea Finn, et al. Cot-vla: Visual chain-of-thought reasoning for vision-language-action models. *arXiv preprint arXiv:2503.22020*, 2025. 5
- [87] Wenliang Zhao, Lujia Bai, Yongming Rao, Jie Zhou, and Jiwen Lu. UniPC: A unified predictor-corrector framework for fast sampling of diffusion models. In *Thirty-seventh Conference on Neural Information Processing Systems*, 2023. URL <https://openreview.net/forum?id=hrkmlPhp1u.23>. 23
- [88] Ruijie Zheng, Yongyuan Liang, Shuaiyi Huang, Jianfeng Gao, Hal Daumé III, Andrey Kolobov, Furong Huang, and Jianwei Yang. TraceVLA: Visual trace prompting enhances spatial-temporal awareness for generalist robotic policies. In *The Thirteenth International Conference on Learning Representations*, 2025. 4
- [89] Ruijie Zheng, Jing Wang, Scott Reed, Johan Bjorck, Yu Fang, Fengyuan Hu, Joel Jang, Kaushil Kundalia, Zongyu Lin, Loic Magne, et al. Flare: Robot learning with implicit world modeling. *arXiv preprint arXiv:2505.15659*, 2025. 5
- [90] Jiaming Zhou, Ke Ye, Jiayi Liu, Teli Ma, Zifan Wang, Ronghe Qiu, Kun-Yu Lin, Zhilin Zhao, and Junwei Liang. Exploring the limits of vision-language-action manipulations in cross-task generalization. *arXiv preprint arXiv:2505.15660*, 2025. 2
- [91] Siyuan Zhou, Yilun Du, Jiaben Chen, Yandong Li, Dit-Yan Yeung, and Chuang Gan. Robodreamer: Learning compositional world models for robot imagination. *arXiv preprint arXiv:2404.12377*, 2024. 5
- [92] Chuning Zhu, Raymond Yu, Siyuan Feng, Benjamin Burchfiel, Paarth Shah, and Abhishek Gupta. Unified world models: Coupling video and action diffusion for pretraining on large robotic datasets. *arXiv preprint arXiv:2504.02792*, 2025. 5, 7
-