

Ego2Robot: 从以自我为中心的人类数据中实现可扩展的机器人数据综合

Ye Wang^{1,2,*}, Pei Lin^{2,3,4,*}, Xiong-Hui Chen^{2,*}, Haoqi Yuan², Zhixuan Liang²,
Yiyang Huang², Anzhe Chen², Zixing Lei², Jie Zhang², Tao Zhang¹, Haoyang Li²,
Tong Zhang², Chenxi Xiao³, Ziyuan Jiao^{4,5}, Qin Jin^{1,†}

¹AIM3 Lab, Renmin University of China ²Qwen Team, Alibaba Inc.

³ShanghaiTech University ⁴Beijing Institute for General Artificial Intelligence (BIGAI)

⁵Beijing University of Aeronautics and Astronautics

*Equal contribution †Corresponding author

摘要: 学习可泛化的机器人操作策略需要大规模且多样化的演示数据。以自我为中心的人类操作视频提供了丰富的场景和任务多样性, 先前工作表明, 将此类视频重定向并渲染为机器人格式数据, 可在小规模下产生有效的单任务策略。然而, 这种方法能否在大规模下为视觉-语言-动作模型提供预训练收益, 仍未得到探索。我们提出 **Ego2Robot**, 一个可扩展的流水线, 通过动作重定向、机器人手臂视觉综合和多层次质量筛选, 将以自我为中心的人类操作视频转换为机器人训练数据。**Ego2Robot** 同时支持精选数据集和自然场景视频, 生成了 18,561 小时的机器人训练数据, 涵盖 15 种机器人形态, 成为迄今为止最大的自我中心到机器人数据集。为评估泛化性, 我们扩展了 RoboTwin2.0, 引入解耦的扰动轴, 涵盖视觉外观、场景布局、具身形态和任务语义。实验表明, 在 **Ego2Robot** 综合数据与机器人数据上进行联合预训练, 能够持续提升多种扰动类型下的分布外泛化能力, 其收益在真实机器人部署中得到验证。项目页面: https://www-ye.github.io/ego2robot_blog/

关键词: 机器人数据综合, 自我中心数据, 泛化评估

1 引言

近期视觉-语言-动作 (VLA) 模型 [1, 2, 3, 4, 5] 通过大规模机器人演示预训练, 在机器人操作方面取得了令人瞩目的进展。然而, 这些系统的泛化能力仍从根本上受限于可用机器人数据的规模和多样性。尽管有 Open X-Embodiment[6]、DROID[7] 和 AgibotWorld[8] 等重大努力, 收集机器人演示仍然成本高昂、劳动密集, 并受硬件可用性、遥操作成本和交互多样性受限的制约 [9, 10, 11]。

以自我为中心的人类视频提供了一种引人注目的替代方案。与机器人遥操作相比, 人类手部交互可以在不同物体、环境和任务变化中以大规模方式收集 [12, 13]。这些视频捕获了仅靠机器人难以获得的丰富操作先验。然而, 由于人类与机器人具身之间的巨大差距, 直接将自我中心视频转换为机器人训练数据仍然具有挑战性。一个有前景的方向是将手部运动重定向到机器人运动学, 并用渲染的机器人具身视觉替换人类手臂, 这在小规模上已显示出强大的单任务结果 [14, 15]。大规模自我到机器人合成数据能否作为机器人策略的有效预训练数据, 特别是用于改善分布外泛化, 在很大程度上仍未得到探索。

在这项工作中, 我们研究了自我到机器人合成作为机器人策略预训练的可扩展范式。我们的关键假设是, 尽管具身存在差异, 自我中心操作视频




图 1: Ego2Robot 流程。通过动作对齐、视觉对齐和质量筛选，将自我中心视频转换为跨 15 种形态的 18,561 小时机器人训练数据。

包含可迁移的交互规律，如果正确对齐，可以补充机器人数据。基于这一观察，我们提出了 **Ego2Robot**，这是一个端到端流程，通过动作对齐、视觉对齐和多级质量筛选，将自我中心人类操作数据转换为具身特定的机器人训练数据（图 1）。该流程支持带标注的自我数据集和纯自我视频，并处理来自四个不同来源的约 1,940 小时自我中心视频，跨 15 种机器人形态，产生 18,561 小时的有效机器人训练数据，据我们所知，这是迄今为止最大的自我到机器人数据集。

为评估自我中心到机器人合成数据是否提升机器人泛化能力，本文进一步引入基于机器人孪生 2.0 (RoboTwin2.0) [16] 的解耦评估协议。与以往将多种分布偏移聚合为单一分数的评估不同，该协议将扰动解耦为四个轴：视觉外观、场景布局、具身形态和任务语义。这使得能够精细分析结合机器人与自我中心到机器人合成数据进行预训练在哪些方面带来益处，以及这些增益是源于视觉鲁棒性、具身迁移还是语义泛化。大量实验表明，自我中心到机器人合成数据持续提升分布外性能，并为机器人数据提供互补价值。特别是，在视觉、具身和语义扰动下增益最为显著，这表明大规模自我中心到机器人合成数据主要提升不变性和跨分布鲁棒性，而非仅仅增加轨迹覆盖。

本文的贡献如下：（1）提出自我中心到机器人（Ego2Robot）的完整综合流程，包含动作对齐、视觉对齐和多层次质量筛选，支持 15 种机器人形态。（2）构建了迄今最大的自我中心到机器人数据集，包含从多样化的自我中心视频源生成的 18,561 小时合成机器人训练数据。（3）引入解耦泛化基准，将视觉、场景、具身和语义扰动分离，用于细粒度评估机器人策略的鲁棒性。（4）证明将自我中心到机器人合成数据与纯机器人数据结合可提升泛化性能，尤其在分布外偏移下。

2 相关工作

机器人数据规模化与从人类数据中学习 扩展机器人演示数据对于实现可泛化的操作至关重要。大规模机器人数据集 [6, 7, 8] 与便携式采集系统

系统 (tems) [10, 11, 9, 17, 18] 已扩展了可用的演示, 但多样性仍受采集成本和硬件可扩展性的制约。人类操作视频提供了更广泛的替代方案, 推动了视觉预训练 [19, 20, 21]、奖励学习 [22]、运动先验 [23] 和点跟踪 [24, 25] 的研究, 但这些方法仍依赖机器人数据来弥合具身差异。

更直接的方法利用人类数据进行机器人策略学习。一类工作将第一人称或人类视频与机器人数据共同训练 [15, 26, 27, 28, 29], 另一类则通过重定向与渲染 [14, 30] 或具身掩码 [15] 将人类演示转换为机器人格式数据。然而, 重定向-渲染方法仅在有限规模或单个任务上进行了研究。本文将其扩展到 18,561 小时、覆盖 15 种机器人形态, 并系统评估其对视觉-语言-动作模型预训练和分布外泛化的益处。

机器人学习的数据增强 数据增强无需额外机器人采集即可扩展训练多样性。基于仿真的方法 [31, 32] 在数字孪生中生成合成演示, 而跨具身方法 (包括 RoviAug [33]、Mirage [34] 和 OXE-AugE [35]) 通过修复和图像编辑弥合机器人之间的视觉差距。与这些方法不同, 本文将增强扩展到显著更大的自我中心到机器人的领域差距, 利用第一人称人类视频为 15 种机器人形态合成训练数据, 并在多个扰动轴上系统评估泛化能力。

机器人泛化基准 现有的操作基准 (如 RoboTwin [36, 16]、LIBERO [37]、CALVIN [38]、RLBench [39] 和 SIMPLER [40]) 在捆绑扰动下评估策略泛化, 难以将失败归因于特定因素。ManiSkill2/3 [41, 42] 和 RoboCasa [32] 支持多种机器人配置, 但缺乏标准化的跨具身评估。最近的分解基准 (包括 Colosseum [43]、LIBERO-Plus [44] 和 LIBERO-PRO [45]) 分离扰动轴, 并表明视觉-语言-动作模型在单个偏移下性能大幅下降, 但仍局限于单臂设置。RoboTwin 2.0 [16] 和 EBench [46] 评估双臂操作, 但仍主要报告捆绑结果。本文扩展 RoboTwin2.0, 引入独立的扰动轴, 涵盖视觉外观、场景布局、具身和任务语义, 同时支持双臂和跨具身评估。

3 Ego2Robot 流程

给定以自我为中心的视频, 描绘人手操作过程, 本文的流程通过三个阶段生成特定于机器人形态的训练数据: 动作对齐、视觉对齐和质量筛选 (图 1)。动作对齐通过重定向和时间平滑将手部姿态转换为机器人末端执行器轨迹。视觉对齐通过手臂分割、手部移除、带逆运动学求解的机器人基座姿态搜索以及深度感知渲染, 将人类手臂替换为渲染的机器人手臂。质量筛选随后在轨迹、帧和片段三个层面过滤样本。该流程支持两种输入路径: 路径 A 接受已有手部姿态标注的自我中心数据集, 而路径 B 处理未标注视频, 首先通过 WiLoR[47, 48] 逐帧重建和 DynHaMR[49] 时间优化来估计手部姿态。对于长视频, 本文采用 Qwen3.5[50] 将连续记录分割为离散子任务, 并附有自然语言描述。在手部姿态估计之后, 两条路径共享统一的流程, 可并行生成 15 种受支持机器人形态中任意一种的训练数据。

1. 动作对齐 动作对齐阶段通过重定向和时间平滑将手部姿态转换为平行夹爪末端执行器轨迹。

手到夹爪重定向。 对于每个检测到手的帧, 本文从 21 个手部关键点中提取紧凑的夹爪表示。本文定义虚拟指尖为食指和中指指尖的加权混合:

$$\mathbf{p}_{vf} = 0.7 \cdot \mathbf{p}_{index} + 0.3 \cdot \mathbf{p}_{middle} \quad (1)$$

工具中心点 (TCP) 和夹爪张开宽度为:

$$\mathbf{p}_{\text{tcp}} = \frac{\mathbf{p}_{\text{thumb}} + \mathbf{p}_{\text{vf}}}{2}, \quad w = \|\mathbf{p}_{\text{thumb}} - \mathbf{p}_{\text{vf}}\| \quad (2)$$

抓取姿态是一个右手正交坐标系 $\mathbf{R} = [\mathbf{x} \ \mathbf{y} \ \mathbf{z}]$ 。抓取轴 $\mathbf{z}$ 沿夹爪线 (拇指尖到虚拟指尖) 方向; 它与手腕到指尖方向 $\mathbf{d} = \mathbf{p}_{\text{vf}} - \mathbf{p}_{\text{wrist}}$ 共同张成夹爪平面, 该平面的法线为夹爪法线轴 $\mathbf{y}$; 接近轴 $\mathbf{x}$ 补全该坐标系:

$$\mathbf{z} = \frac{s(\mathbf{p}_{\text{thumb}} - \mathbf{p}_{\text{vf}})}{w}, \quad \mathbf{y} = \frac{\mathbf{z} \times \mathbf{d}}{\|\mathbf{z} \times \mathbf{d}\|}, \quad \mathbf{x} = \mathbf{y} \times \mathbf{z} \quad (3)$$

其中 $s = +1$ 用于右手, $s = -1$ 用于左手, 使得 $\mathbf{z}$ 轴方向一致, 不受惯用手影响, 且双手映射到相同的夹爪坐标系。三个轴分别为: $\mathbf{x}$ ——接近方向, $\mathbf{y}$ ——夹爪法线 (垂直于夹爪平面), $\mathbf{z}$ ——抓取轴 (沿夹爪线)。

时间平滑。逐帧手部检测会引入高频噪声。本文对位置和宽度应用萨维茨基-戈莱滤波, 对朝向应用高斯加权球面线性插值, 从而生成平滑轨迹, 同时保留运动结构。

动作速度对齐。以自我为中心的手部操作所表现出的动作速度显著高于机器人遥操作数据。为对齐速度分布, 本文在训练期间对每个来源进行逐帧下采样: ANT 和 EgoDex 下采样至原始帧率的 60% ($\sim 1.7\times$ 更慢), EgoVerse 下采样至 45% ($\sim 2.2\times$ 更慢), ViTRA 下采样至 25% ($\sim 4\times$ 更慢)。

2. 视觉对齐 视觉对齐将自我视角视频从描绘人手转变为展示在同一场景中操作的机器人手臂。

手臂分割。本文采用 SAM 3 [51] 对每帧中的人体手臂区域进行分割, 从而在帧间提供时间一致的掩码。

手部移除。利用手臂掩码, ProPainter [52] 执行时间一致的视频修复, 以移除人类手臂并重建背景。

机器人基座位姿搜索。将自我视角视频转换为机器人数据的一个根本性挑战是确定机器人基座的放置位置。与机器人到机器人的迁移不同, 后者有源基座位置可用, 而自我中心的手部轨迹是无实体的: 没有物理机器人基座可供参考。我们必须找到一个基座位姿 $\mathbf{T}_{\text{base}} = (\mathbf{t}, \mathbf{R}) \in SE(3)$, 使得重定向后的轨迹在目标机器人形态下保持运动学可行性。

我们将此问题形式化为对基座放置的优化。给定一条由 N 个目标末端执行器位姿 $\{\mathbf{T}_i^{\text{ee}}\}_{i=1}^N$ 组成的轨迹, 以及一个最大可达距离为 r_{max} 的机器人, 我们寻求:

$$\mathbf{T}_{\text{base}}^* = \arg \max_{\mathbf{T}_{\text{base}}} \frac{1}{|\mathcal{K}|} \sum_{k \in \mathcal{K}} \mathbb{1}[\text{IK}(\mathbf{T}_{\text{base}}^{-1} \mathbf{T}_k^{\text{ee}}) \text{ is feasible}] \quad (4)$$

其中 $\mathcal{K} \subset \{1, \dots, N\}$ 是一组代表性关键帧, 选择这些关键帧以覆盖轨迹的空间极值 (位移或方向变化最大的位置), 而 $\text{IK}(\cdot)$ 表示 MuJoCo [53, 54] 中的逆运动学求解器。候选基座放置通过围绕轨迹质心的网格搜索生成, 并受每种形态的运动学可达范围 r_{max} 约束。每个候选放置通过在所有关键帧上求解 IK 进行验证, 并选择可行性率最高的放置。该搜索针对 15 种机器人形态分别独立执行, 因为不同的臂长和关节配置需要为同一轨迹选择不同的基座放置。

逆运动学与渲染。给定优化后的基座放置, 在 MuJoCo 中逐帧求解 IK。机器人从原始相机视角进行渲染。

深度感知合成。机器人从相机视角渲染, 并利用深度排序合成到修复后的场景中:

$$I_{\text{final}}(u, v) = \begin{cases} I_{\text{robot}}(u, v) & \text{if } D_{\text{robot}}(u, v) < D_{\text{scene}}(u, v) \wedge M_{\text{robot}}(u, v) = 1 \\ I_{\text{inpaint}}(u, v) & \text{otherwise} \end{cases} \quad (5)$$




图 2：评估框架。四个泛化维度，共 12 种评估设置。虚线边框：与捆绑随机化解耦的设置，用于独立测试。实线边框：新引入的评估轴。灰色边框：外部基准（EBench）。

其中 D_{scene} 从深度传感器获取或通过单目深度估计得到。该过程独立应用于 15 种机器人形态（Panda、UR5e、ARX-L5、xArm7、Sawyer、Kinova Gen3、IIWA、Jaco、FR3、UR10e、ViperX、WidowX、Piper、YAM、Aloha-Agilex），从每个自我视频生成并行训练流。

3. 质量筛选 本文采用三级质量过滤。L1（流程内部）：处理过程中标记存在逆运动学失败、自碰撞、动作异常值或工作空间覆盖不足的帧。L2（统计）：移除动作值极端、突然不连续或无效帧比例过高的轨迹。L3（视觉语言模型一致性）：视觉语言模型 [50] 审核合成视频，检查渲染的机器人动作与原始操作意图之间的语义一致性。

本文将流程应用于四个自我中心数据源：ANT（7 小时，本文自建的带手部姿态标注的拾放数据集）、EgoDex[12]（732 小时）、ViTRA[29]（249 小时）和 EgoVerse[13]（954 小时），总计 ~ 1,940 小时标注自我数据。由于自我中心手部操作速度远快于机器人遥操作，训练时对每个数据源进行帧下采样以匹配机器人速度分布：ANT 和 EgoDex 降至原始帧率的 60%（~1.7× 更慢），EgoVerse 降至 45%（~2.2× 更慢），ViTRA 降至 25%（~4× 更慢）。

经过 15 种机器人形态的处理和质量筛选后，得到 18,561 小时合成机器人训练数据。每个样本包含机器人合成视频帧、对应的相机坐标系末端执行器动作、相机参数和文本指令。由于自我中心视频以多样且未知的相机位置拍摄，世界坐标系动作表示需要逐视频校准，并导致不同数据源之间的动作空间不兼容。相机坐标系相对末端执行器动作在观察者坐标系中表达末端执行器位移，自然统一了来自不同相机设置和机器人形态的数据。

4 评估框架

理解哪些泛化维度受益于自我中心到机器人合成数据——以及哪些受限于领域差距——需要现有基准无法提供的评估粒度。当前协议如 RoboTwin 2.0 [16] 同时应用多个扰动因素，产生一个单一的聚合分布外度量，混淆了视觉、空间、具身和语义偏移。

我们扩展了 RoboTwin 2.0，增加了 11 个独立扰动设置和相机坐标系相对末端执行器支持，并辅以 EBench [46]，它在 Isaac Sim 中提供了 7 个精密桌面任务，使用更高安装的头相机，更接近自我中心视角。该扩展涵盖了如图 2 所示的四个泛化维度：

(1) 视觉外观——独立控制背景纹理、光照和机器人颜色。背景和光照从原始捆绑随机化中解耦，用于隔离测试。机器人颜色对所有机器人连杆应用随机色调偏移，测试对训练中未见过的具身外观变化的视觉不变性。**(2) 场景布局**——桌面高度变化（ $\pm 4\text{cm}$ ），干扰物体，以及相机视点偏移（ ± 5 厘米），全部解耦用于独立评估。这些空间扰动探测对现实部署中常见的物理排列变化的鲁棒性。**(3) 具身**——将默认的 Aloha-Agilex 替换为 UR5-WSG、ARX-X5 和 Franka Panda 进行零样本跨具身评估，初始末端执行器姿态通过逆运动学对齐以确保一致的起始条件。这测试了相机坐标系动作表示是否能在形态不同的机器人之间泛化，而无需具身特定的微调。

(4) 任务语义——50 个任务使用该任务训练期间未见过的物体实例进行评估，以及 505 条以口语形式重新表述命令的改写自然语言指令。这探测了对新物体外观的泛化和对语言变化的鲁棒性。这种分解能够将泛化增益精确归因于特定的扰动类型。更多细节见附录。

5 实验

5.1 实验设置

模型架构。本文采用以千问 3.5-4B（Qwen3.5-4B）为视觉语言骨干、以扩散变换器（Diffusion Transformer, DiT）为动作头的视觉语言动作（VLA）架构。模型以相机坐标系下的相对末端执行器表示预测 32 步动作块，扩散步数为 8。

训练协议。所有预训练运行均采用相同超参数：8 块图形处理器（GPU），每块批大小 12，学习率 $1\text{e-}5 \rightarrow 1\text{e-}6$ 并采用余弦衰减，使用 bf16 精度，训练 20 万步。由于所有配置在相同步数下以相同批大小训练，每种设置处理的训练样本数完全相同（ ~ 1920 万帧），从而确保无论数据集大小如何，比较均公平。微调阶段加载预训练权重，并采用颜色抖动（ColorJitter）增强，训练 5 万步。

预训练数据。本文比较四种配置：(i) 仅机器人数据（DROID [7] + AgibotWorld [8] + InternData [55], $\sim 6,565$ 小时），以及 (ii - iv) 自我中心到机器人合成数据（简称 Ego2R）与机器人数据按 1:3、3:1 和 1:1 比例混合。微调与评估。所有模型均在 RoboTwin 的 50 个干净设置任务（每任务 50 次演示）上微调，并在每种扰动设置下以每任务 50 回合进行评估。EBench 模型则在其训练集上单独微调。对于真实机器人评估，本文在 ARX ACone 平台上测试 5 个长时程操作任务。更多细节见附录。

5.2 主要结果

表 1 展示了使用不同 Ego2Robot 数据与真实机器人数据混合比例预训练模型的成功率。表 2 进一步在扩展基准上比较了这些模型，其中测试条件沿三个维度分解：视觉外观、场景和具身。从这些结果中，我们得出以下结论：

协同训练提升了分布外泛化能力。Ego2R+Robot (1:1) 在七列中的五列领先，在 RoboTwin 随机化上达到 53.5%（比仅机器人高 2.6），同时在干净条件下保持 68.1%。1:3 比例带来边际收益，而 3:1 和 1:1 产生显著改进。

视觉外观受益最大。表 2 显示 1:1 在三个视觉因素上均有改善：背景（+4）和光照（+8）来自自我中心视频中的场景多样性，机器人颜色（+6）来自 15 种配置下的多形态渲染。

表 1：主要结果。 RoboTwin2.0 和 EBench 上的成功率（%）。绿色=增益 >5% vs. 仅机器人。

Pretraining	RoboTwin		Per-Dimension (RoboTwin)				EBench
	Clean	Rand	Visual	Scene	Embodiment	Task	Avg
Robot-only	62.2	50.9	61.4	52.9	23.8	46.2	39.6
Ego2R+Robot (1:3)	61.4 -0.8	51.0 +0.1	61.2 -0.2	52.5 -0.4	21.9 -1.9	49.5 +3.3	47.4 +7.8
Ego2R+Robot (3:1)	64.1 +1.9	49.2 -1.7	62.7 +1.3	54.3 +1.4	28.2 +4.4	51.6 +5.4	51.7 +12.1
Ego2R+Robot (1:1)	68.1 +5.9	53.5 +2.6	67.3 +5.9	56.9 +4.0	27.2 +3.4	54.1 +7.9	49.8 +10.2

表 2：逐扰动分解。 与仅机器人相比的变化。绿色 = 增益 >5 %。

Pretraining	Visual			Scene			Embodiment			Task	
	BG	Light	Color	Height	Clutter	Camera	ARX	UR5	Franka	Obj	Lang
Robot-only	66.6	58.2	59.4	60.1	48.3	50.4	44.1	20.2	7.0	29.3	63.1
Ego2R+Robot (1:3)	65.0 -1.6	58.3 +0.1	60.3 +0.9	58.6 -1.5	49.3 +1.0	49.6 -0.8	43.7 -0.4	17.6 -2.6	4.5 -2.5	36.8 +7.5	62.2 -0.9
Ego2R+Robot (3:1)	65.5 -1.1	60.9 +2.7	61.8 +2.4	62.0 +1.9	49.2 +0.9	51.6 +1.2	47.6 +3.5	31.4 +11.2	5.6 -1.4	40.0 +10.7	63.1 +0.0
Ego2R+Robot (1:1)	70.3 +3.7	65.8 +7.6	65.8 +6.4	62.4 +2.3	52.0 +3.7	56.3 +5.9	51.2 +7.1	25.0 +4.8	5.3 -1.7	39.6 +10.3	68.5 +5.4

场景布局显示出中等增益。 相机偏移鲁棒性在 1:1 比例下提升 6 分，因为以自我为中心的视频天然呈现多样的头部姿态和视角。

具身迁移受益于多形态数据。 ARX 从 44 提升至 51（1:1），UR5 在 3:1 时达到峰值 31，直接受益于预训练期间接触 15 种形态。Franka 仍低于 7%，反映其与训练具身之间存在较大运动学差距。

任务语义持续改善。 未见物体泛化从 29% 提升至 40%（3:1 时+11），得益于以自我为中心视频中多样的物体交互。改写指令鲁棒性在 1:1 时达到 69%，受益于更广泛的指令多样性。

EBench 证实了在更高视角下的增益。 EBench 中安装位置更高的相机更接近以自我为中心的视角。3:1 比例取得最佳 EBench 分数（51.7，较仅机器人数据提升 12.1），表明当视角偏差部分匹配时，协同训练收益被放大。

5.3 消融研究

图 3 通过仅使用自我中心预训练（不含任何机器人数据）来分离流水线的贡献。

流水线对齐至关重要。 原始自我中心联合训练在 RoboTwin 随机化任务上仅达到 28.1%。通过我们的流水线（Ego2R，单一形态）处理后，性能提升至 31.7%，+3.6 的增益验证了视觉与动作对齐阶段的有效性。

更多形态带来帮助。 将形态数量从 1 增加到 15，性能稳步提升（31.7→33.5）。在添加原始自我中心数据的同时




图 3：流水线价值与形态扩展。 RoboTwin 随机化任务上的成功率。




图 4：真实机器人结果。ARX ACone 平台上五项任务的成功率（%）。




图 5：真实机器人执行过程。ARX ACone 平台上五项评估任务的关键帧。

15 种形态的 Ego2R 数据进一步跃升至 37.3%——原始自我中心数据实际上充当了第 16 种“形态”，其视觉外观和动作分布略有不同，进一步丰富了预训练的多样性。

5.4 真实机器人实验

我们在 ARX ACone 平台上评估了五项长程任务（图 5）：将水果放入篮子、将积木放入抽屉、折叠毛巾、将垃圾扫入垃圾桶以及拧入螺丝。每项任务收集 20 个遥操作演示。此外，我们记录手部操作的自我中心玩耍视频（每个场景约 7 分钟），并通过我们的 Ego2Robot 流程处理，生成 ACone 特定的合成演示。我们比较了三种配置（图 4）：仅机器人（**Robot-only**）仅使用机器人预训练并在遥操作演示上微调；混合（**Mix**）使用 Ego2R+机器人（1:1）预训练，并使用相同的演示；混合+

Ego2R 玩耍 在遥操作演示与流程转换的自我中心玩耍（Ego2R）数据按 1:1 混合的数据上微调。

混合+Ego2R 玩耍在所有五项任务中均取得最佳结果，其中在放积木（较仅机器人提升 14）和拧螺丝（提升 13）任务上增益最大，表明随意记录自我中心视频可通过我们的流程转化为有效的训练信号。仅混合预训练已优于仅机器人，而 Ego2R 玩耍数据进一步带来一致的增益。

6 局限性

我们的工作存在若干局限性，这些局限性指明了未来的研究方向。首先，重定向将手部姿态映射到平行夹爪，丢弃了精细的手指关节运动。扩展到灵巧多指手可以拓宽可迁移技能的范围。其次，视觉对齐依赖于修复和深度感知合成，在严重遮挡或复杂光照下可能引入伪影。提高渲染保真度（例如使用生成模型）可以进一步缩小视觉域差距。最后，我们的评估仅限于 RoboTwin2.0 的任务范围 [16]。扩展到更广泛的任务和具身配置将增强通用性。

7 结论

本文提出了自我中心到机器人（Ego2Robot）框架，这是一种可扩展的流水线，能够将自我中心的手部操作视频转换为适用于 15 种形态的机器人训练数据。我们构建的解耦评估表明，由自我中心到机器人框架合成的数据能够补充机器人数据，其增益在视觉、具身和语义扰动下最为显著。在真实机器人上，将自我中心到机器人框架合成的数据与少量演示相结合，能够实现有效的多任务部署。我们希望这项工作能够鼓励利用海量的人类操作视频进行可扩展的机器人学习。

参考文献

- [1] B. Zitkovich, T. Yu, S. Xu, P. Xu, T. Xiao, F. Xia, J. Wu, P. Wohlhart, S. Welker, A. Wahid, et al. Rt-2: Vision-language-action models transfer web knowledge to robotic control. In *Conference on Robot Learning*, pages 2165–2183. PMLR, 2023.
- [2] M. J. Kim, K. Pertsch, S. Karamcheti, T. Xiao, A. Balakrishna, S. Nair, R. Rafailov, E. Foster, G. Lam, P. Sanketi, et al. Openvla: An open-source vision-language-action model. *arXiv preprint arXiv:2406.09246*, 2024.
- [3] K. Black, N. Brown, D. Driess, A. Esmail, M. Equi, C. Finn, N. Fusai, L. Groom, K. Hausman, B. Ichter, et al. *pi*-0: A vision-language-action flow model for general robot control. *arXiv preprint arXiv:2410.24164*, 2024.
- [4] P. Intelligence, K. Black, N. Brown, J. Darpinian, K. Dhabalia, D. Driess, A. Esmail, M. Equi, C. Finn, N. Fusai, et al. *pi*-{0.5}: a vision-language-action model with open-world generalization. *arXiv preprint arXiv:2504.16054*, 2025.
- [5] J. Bjorck, F. Castañeda, N. Cherniadev, X. Da, R. Ding, L. Fan, Y. Fang, D. Fox, F. Hu, S. Huang, et al. Gr00t n1: An open foundation model for generalist humanoid robots. *arXiv preprint arXiv:2503.14734*, 2025.
- [6] A. O’Neill, A. Rehman, A. Maddukuri, A. Gupta, A. Padalkar, A. Lee, A. Pooley, A. Gupta, A. Mandlekar, A. Jain, et al. Open x-embodiment: Robotic learning datasets and rt-x models: Open x-embodiment collaboration 0. In *2024 IEEE International Conference on Robotics and Automation (ICRA)*, pages 6892–6903. IEEE, 2024.
- [7] A. Khazatsky, K. Pertsch, S. Nair, A. Balakrishna, S. Dasari, S. Karamcheti, S. Nasiriany, M. K. Srirama, L. Y. Chen, K. Ellis, et al. Droid: A large-scale in-the-wild robot manipulation dataset. *arXiv preprint arXiv:2403.12945*, 2024.
- [8] Q. Bu, J. Cai, L. Chen, X. Cui, Y. Ding, S. Feng, S. Gao, X. He, X. Hu, X. Huang, et al. Agibot world colosseum: A large-scale manipulation platform for scalable and intelligent embodied systems. *arXiv preprint arXiv:2503.06669*, 2025.
- [9] C. Chi, Z. Xu, C. Pan, E. Cousineau, B. Burchfiel, S. Feng, R. Tedrake, and S. Song. Universal manipulation interface: In-the-wild robot teaching without in-the-wild robots. *arXiv preprint arXiv:2402.10329*, 2024.
- [10] T. Z. Zhao, V. Kumar, S. Levine, and C. Finn. Learning fine-grained bimanual manipulation with low-cost hardware. *arXiv preprint arXiv:2304.13705*, 2023.
- [11] P. Wu, Y. Shentu, Z. Yi, X. Lin, and P. Abbeel. Gello: A general, low-cost, and intuitive teleoperation framework for robot manipulators. In *2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 12156–12163. IEEE, 2024.
- [12] R. Hoque, P. Huang, D. J. Yoon, M. Sivapurapu, and J. Zhang. Egodex: Learning dexterous manipulation from large-scale egocentric video. *arXiv preprint arXiv:2505.11709*, 2025.
- [13] R. Punamiya, S. Kareer, Z. Liu, J. Citron, R.-Z. Qiu, X. Cai, A. Gavryushin, J. Chen, D. Li-conti, L. Y. Zhu, et al. Egoverse: An egocentric human dataset for robot learning from around the world. *arXiv preprint arXiv:2604.07607*, 2026.
- [14] M. Lepert, J. Fang, and J. Bohg. Phantom: Training robots without robots using only human videos. In *Conference on Robot Learning*, pages 4545–4565. PMLR, 2025.
- [15] S. Kareer, D. Patel, R. Punamiya, P. Mathur, S. Cheng, C. Wang, J. Hoffman, and D. Xu. Egomimic: Scaling imitation learning via egocentric video. In *2025 IEEE International Conference on Robotics and Automation (ICRA)*, pages 13226–13233. IEEE, 2025.

- [16] T. Chen, Z. Chen, B. Chen, Z. Cai, Y. Liu, Z. Li, Q. Liang, X. Lin, Y. Ge, Z. Gu, et al. Robotwin 2.0: A scalable data generator and benchmark with strong domain randomization for robust bimanual robotic manipulation. *arXiv preprint arXiv:2506.18088*, 2025.
- [17] N. M. M. Shafiullah, A. Rai, H. Etukuru, Y. Liu, I. Misra, S. Chintala, and L. Pinto. On bringing robots home. *arXiv preprint arXiv:2311.16098*, 2023.
- [18] L. Pei, H. Yuzhe, L. Wanlin, X. Chenxi, and J. Ziyuan. Dexmove: Learning tactile-guided non-prehensile manipulation with dexterous hands. In *The Fourteenth International Conference on Learning Representations*, 2026. URL <https://openreview.net/forum?id=dT3ZciXvNX>.
- [19] S. Nair, A. Rajeswaran, V. Kumar, C. Finn, and A. Gupta. R3m: A universal visual representation for robot manipulation. *arXiv preprint arXiv:2203.12601*, 2022.
- [20] I. Radosavovic, T. Xiao, S. James, P. Abbeel, J. Malik, and T. Darrell. Real-world robot learning with masked visual pre-training. In *Conference on Robot Learning*, pages 416–426. PMLR, 2023.
- [21] Y. J. Ma, S. Sodhani, D. Jayaraman, O. Bastani, V. Kumar, and A. Zhang. Vip: Towards universal visual reward and representation via value-implicit pre-training. *arXiv preprint arXiv:2210.00030*, 2022.
- [22] A. S. Chen, S. Nair, and C. Finn. Learning generalizable robotic reward functions from” in-the-wild” human videos. *arXiv preprint arXiv:2103.16817*, 2021.
- [23] C. Wang, L. Fan, J. Sun, R. Zhang, L. Fei-Fei, D. Xu, Y. Zhu, and A. Anandkumar. Mimicplay: Long-horizon imitation learning by watching human play. *arXiv preprint arXiv:2302.12422*, 2023.
- [24] M. Xu, Z. Xu, Y. Xu, C. Chi, G. Wetzstein, M. Veloso, and S. Song. Flow as the cross-domain manipulation interface. *arXiv preprint arXiv:2407.15208*, 2024.
- [25] J. Ren, P. Sundaresan, D. Sadigh, S. Choudhury, and J. Bohg. Motion tracks: A unified representation for human-robot transfer in few-shot imitation learning. In *2025 IEEE International Conference on Robotics and Automation (ICRA)*, pages 8802–8810. IEEE, 2025.
- [26] R. Zheng, D. Niu, Y. Xie, J. Wang, M. Xu, Y. Jiang, F. Castañeda, F. Hu, Y. L. Tan, L. Fu, et al. Egoscale: Scaling dexterous manipulation with diverse egocentric human data. *arXiv preprint arXiv:2602.16710*, 2026.
- [27] H. Luo, Y. Feng, W. Zhang, S. Zheng, Y. Wang, H. Yuan, J. Liu, C. Xu, Q. Jin, and Z. Lu. Being-h0: vision-language-action pretraining from large-scale human videos. *arXiv preprint arXiv:2507.15597*, 2025.
- [28] H. Luo, Y. Wang, W. Zhang, S. Zheng, Z. Xi, C. Xu, H. Xu, H. Yuan, C. Zhang, Y. Wang, et al. Being-h0. 5: Scaling human-centric robot learning for cross-embodiment generalization. *arXiv preprint arXiv:2601.12993*, 2026.
- [29] Q. Li, Y. Deng, Y. Liang, L. Luo, L. Zhou, C. Yao, L. Zeng, Z. Feng, H. Liang, S. Xu, et al. Scalable vision-language-action model pretraining for robotic manipulation with real-life human activity videos. *arXiv preprint arXiv:2510.21571*, 2025.
- [30] T. Zhang, S. Xia, Y. Wang, and Q. Jin. Easymimic: A low-cost framework for robot imitation learning from human videos. *arXiv preprint arXiv:2602.11464*, 2026.
- [31] A. Mandlekar, S. Nasiriany, B. Wen, I. Akinola, Y. Narang, L. Fan, Y. Zhu, and D. Fox. Mimicgen: A data generation system for scalable robot learning using human demonstrations. *arXiv preprint arXiv:2310.17596*, 2023.

- [32] S. Nasiriany, A. Maddukuri, L. Zhang, A. Parikh, A. Lo, A. Joshi, A. Mandlekar, and Y. Zhu. Robocasa: Large-scale simulation of everyday tasks for generalist robots. *arXiv preprint arXiv:2406.02523*, 2024.
- [33] L. Y. Chen, C. Xu, K. Dharmarajan, M. Z. Irshad, R. Cheng, K. Keutzer, M. Tomizuka, Q. Vuong, and K. Goldberg. Rovi-aug: Robot and viewpoint augmentation for cross-embodiment robot learning. *arXiv preprint arXiv:2409.03403*, 2024.
- [34] L. Y. Chen, K. Hari, K. Dharmarajan, C. Xu, Q. Vuong, and K. Goldberg. Mirage: Cross-embodiment zero-shot policy transfer with cross-painting. *arXiv preprint arXiv:2402.19249*, 2024.
- [35] G. Ji, H. Polavaram, L. Y. Chen, S. Bajamahal, Z. Ma, S. Adebola, C. Xu, and K. Goldberg. Oxe-aug: A large-scale robot augmentation of oxe for scaling cross-embodiment policy learning. *arXiv preprint arXiv:2512.13100*, 2025.
- [36] Y. Mu, T. Chen, Z. Chen, S. Peng, Z. Lan, Z. Gao, Z. Liang, Q. Yu, Y. Zou, M. Xu, et al. Robotwin: Dual-arm robot benchmark with generative digital twins. In *Proceedings of the computer vision and pattern recognition conference*, pages 27649–27660, 2025.
- [37] B. Liu, Y. Zhu, C. Gao, Y. Feng, Q. Liu, Y. Zhu, and P. Stone. Libero: Benchmarking knowledge transfer for lifelong robot learning. *Advances in Neural Information Processing Systems*, 36:44776–44791, 2023.
- [38] O. Mees, L. Hermann, E. Rosete-Beas, and W. Burgard. Calvin: A benchmark for language-conditioned policy learning for long-horizon robot manipulation tasks. *IEEE Robotics and Automation Letters*, 7(3):7327–7334, 2022.
- [39] S. James, Z. Ma, D. R. Arrojo, and A. J. Davison. Rlbench: The robot learning benchmark & learning environment. *IEEE Robotics and Automation Letters*, 5(2):3019–3026, 2020.
- [40] X. Li, K. Hsu, J. Gu, K. Pertsch, O. Mees, H. R. Walke, C. Fu, I. Lunawat, I. Sieh, S. Kirmani, et al. Evaluating real-world robot manipulation policies in simulation. *arXiv preprint arXiv:2405.05941*, 2024.
- [41] J. Gu, F. Xiang, X. Li, Z. Ling, X. Liu, T. Mu, Y. Tang, S. Tao, X. Wei, Y. Yao, et al. Maniskill2: A unified benchmark for generalizable manipulation skills. *arXiv preprint arXiv:2302.04659*, 2023.
- [42] S. Tao, F. Xiang, A. Shukla, Y. Qin, X. Hinrichsen, X. Yuan, C. Bao, X. Lin, Y. Liu, T.-k. Chan, et al. Maniskill3: Gpu parallelized robotics simulation and rendering for generalizable embodied ai. *arXiv preprint arXiv:2410.00425*, 2024.
- [43] W. Pumacay, I. Singh, J. Duan, R. Krishna, J. Thomason, and D. Fox. The colosseum: A benchmark for evaluating generalization for robotic manipulation. *arXiv preprint arXiv:2402.08191*, 2024.
- [44] S. Fei, S. Wang, J. Shi, Z. Dai, J. Cai, P. Qian, L. Ji, X. He, S. Zhang, Z. Fei, et al. Libero-plus: In-depth robustness analysis of vision-language-action models. *arXiv preprint arXiv:2510.13626*, 2025.
- [45] X. Zhou, Y. Xu, G. Tie, Y. Chen, G. Zhang, D. Chu, P. Zhou, and L. Sun. Libero-pro: Towards robust and fair evaluation of vision-language-action models beyond memorization. *arXiv preprint arXiv:2510.03827*, 2025.
- [46] S. A. Laboratory. EBench: Elemental mobile manipulation benchmark, 2026. URL <https://internrobotics.github.io/EBench-doc/>. Preprint coming soon.

- [47] R. A. Potamias, J. Zhang, J. Deng, and S. Zafeiriou. Wilor: End-to-end 3d hand localization and reconstruction in-the-wild. In *Proceedings of the Computer Vision and Pattern Recognition Conference*, pages 12242–12254, 2025.
- [48] C. Si, Y. Liu, B. Ai, J. Xie, R. A. Potamias, C. Zheng, and H. Su. Anyhand: A large-scale synthetic dataset for rgb (-d) hand pose estimation. *arXiv preprint arXiv:2603.25726*, 2026.
- [49] Z. Yu, S. Zafeiriou, and T. Birdal. Dyn-hamr: Recovering 4d interacting hand motion from a dynamic camera. In *Proceedings of the Computer Vision and Pattern Recognition Conference*, pages 27716–27726, 2025.
- [50] Q. Team. Qwen3. 5: Accelerating productivity with native multimodal agents, february 2026. URL <https://qwen.ai/blog>.
- [51] N. Carion, L. Gustafson, Y.-T. Hu, S. Debnath, R. Hu, D. Suris, C. Ryali, K. V. Alwala, H. Khedr, A. Huang, et al. Sam 3: Segment anything with concepts. *arXiv preprint arXiv:2511.16719*, 2025.
- [52] S. Zhou, C. Li, K. C. Chan, and C. C. Loy. Propainter: Improving propagation and transformer for video inpainting. In *Proceedings of the IEEE/CVF international conference on computer vision*, pages 10477–10486, 2023.
- [53] E. Todorov, T. Erez, and Y. Tassa. Mujoco: A physics engine for model-based control. In *2012 IEEE/RSJ international conference on intelligent robots and systems*, pages 5026–5033. IEEE, 2012.
- [54] K. Zakka. Mink: Python inverse kinematics based on MuJoCo, Feb. 2026. URL <https://github.com/kevinzakka/mink>.
- [55] Y. Tian, Y. Yang, Y. Xie, Z. Cai, X. Shi, N. Gao, H. Liu, X. Jiang, Z. Qiu, F. Yuan, et al. Interndata-al: Pioneering high-fidelity synthetic data for pre-training generalist policy. *arXiv preprint arXiv:2511.16651*, 2025.

自我中心到机器人附录

A 自我中心到机器人流水线细节 14

B 评估框架细节 17

C 模型架构细节 19

D 训练细节 19

E 真实机器人实验细节 20

F 附加实验结果 21

A Ego2Robot 流程细节

A.1 手部姿态估计（路径 B）。

逐帧重建。 WiLoR [47] 执行逐帧手部检测并回归 MANO 参数 $(\theta, \beta, \mathbf{t})$ ，生成每帧 21 个关键点 $\{\mathbf{p}_j\}_{j=0}^{20}$ 和手部网格。检测结果通过 SAM 3 生成的手部掩码进行过滤：若超过 80% 的投影关键点落在掩码之外，则丢弃该帧。

跨帧关联。 WiLoR 使用基于 YOLO 的手部检测器，输出边界框和初始左/右手标签。为构建时间一致的轨迹，以左右手检测分数总和最高的帧作为种子帧。从种子帧开始，双向传播：在每一帧，每个新检测被分配给图像空间中距离其上一帧手腕位置最近的手（ ℓ_2 距离）。当多个检测竞争同一只手时，保留得分最高的检测。关联完成后，跳跃滤波器移除三维手腕速度超过 $\max(4 \times \text{中位速度}, 0.003 \text{ 米/帧})$ 的帧，以剔除误检测。

时间优化。 DynHaMR [49] 通过在整个序列上联合优化 MANO 姿态和形状参数来细化轨迹，最小化：

$$\mathcal{L}_{\text{dyn}} = \mathcal{L}_{\text{data}} + \lambda_{\text{smooth}} \mathcal{L}_{\text{smooth}} + \lambda_{\text{bio}} \mathcal{L}_{\text{bio}} \quad (6)$$

其中 $\mathcal{L}_{\text{data}}$ 强制与逐帧 WiLoR 估计的一致性， $\mathcal{L}_{\text{smooth}}$ 惩罚手腕位置和手指关节角度的加速度， $\mathcal{L}_{\text{bio}}$ 强制生物力学关节极限。重建手部的深度被限制在距离相机 $[0.05, 0.4]$ 米以内。

间隙处理。 当连续帧缺少手部检测时，我们采用间隙特定的插值方法。大间隙（ > 10 帧）用机器人的初始配置填充，并在间隙边界处进行平滑混合过渡。混合长度为 $n = \max(5, \min(90, \lceil 0.6n_{\text{pos}} + 0.4n_{\text{rot}} \rceil))$ 帧，其中 $n_{\text{pos}} = \Delta p / 3.25$ 毫米和 $n_{\text{rot}} = \Delta \theta / 1.08^\circ$ 是在固定混合速度下覆盖位移所需的帧数。小间隙（ ≤ 10 帧）使用线性位置插值加球面线性插值。

A.2 子任务分割（路径 B）。

对于长时间连续录制，我们在 60 秒边界处预分割视频。每个片段连同以下提示模板一起发送给视觉语言模型（Qwen3.5 [50]）：

```
You are watching a first-person manipulation video ({duration}s).
Task: "{task_desc}"
Segment this video by complete task goals. Each subtask should be
```

an independent, complete objective.
 Write a SHORT English action instruction (5--12 words) for each subtask.
 Output ONLY a JSON array: [{"description":..., "start_time":..., "end_time":...}, ...]

视觉语言模型返回子任务边界和自然语言描述，作为训练指令。

A.3 动作对齐细节。

手性符号。 抓取轴定义（方程 3）中的符号 s 由手的左右身份决定：右手为 $s = +1$ ，左手为 $s = -1$ ，使得抓取轴 $\mathbf{z}$ 始终一致地指向，无论手性如何，并且双手映射到相同的夹爪坐标系。构成夹爪法线轴 $\mathbf{y}$ 的腕部到指尖向量 $\mathbf{d} = \mathbf{p}_{\text{vf}} - \mathbf{p}_{\text{wrist}}$ 直接取自 MANO 关键点。

退化姿态。 当拇指指尖和虚拟指尖几乎重合（夹爪宽度 $w < 0.01$ 米）时，抓取姿态退化；我们将其冻结为上一个有效估计。当 $\mathbf{z}$ 和 $\mathbf{d}$ 几乎平行时（ $\|\mathbf{z} \times \mathbf{d}\| \approx 0$ ），也应用相同的回退策略。

速度滤波。 逐帧检测跳变通过速度滤波器去除。对于位置速度 $v_t = \|\mathbf{p}_t - \mathbf{p}_{t-1}\|$ ，阈值为：

$$\tau_t = \max(5 \cdot \text{median}(\{v_s\}_s), 0.9/\text{fps}) \quad (7)$$

对于旋转速度，使用带有下限 10.0/ 帧每秒弧度的类似阈值。超过 τ_t 的帧通过相邻帧插值替换。该过程迭代 2 轮。

时间平滑。 位置与夹爪宽度：萨维茨基-戈莱滤波器，窗口 $\min(21, n)$ ，多项式阶数 $\min(3, \text{窗口} - 1)$ 。姿态：高斯加权球面线性插值， $\sigma=10$ 帧，核大小 21。相邻四元数在插值前进行半球校正（当 $q_t \cdot q_{t-1} < 0$ 时 $q_t \rightarrow -q_t$ ）。

A.4 视觉对齐细节。

手臂分割。 SAM 3 [51] 使用文本提示“人”，以中间帧作为提示锚点进行时间传播。长视频按 400 帧分块处理，块间重叠 50 帧；重叠区域的掩码通过按位或运算合并。后处理：（i）间隙 ≤ 3 帧通过插值相邻掩码填充；（ii）掩码面积 $< 50\%$ 局部中位数（窗口 11）的帧由最近的有效掩码替换；（iii）使用 5×5 椭圆核进行形态学闭运算。

手部移除。 ProPainter [52] 以 fp16 精度运行，邻居长度 = 为 10，参考步长 = 为 10，子视频长度 = 为 80，掩码膨胀 = 为 4，RAFT 迭代次数 = 20。

基础姿态搜索。 优化目标定义于方程 4。此处详述候选生成与评分。候选在相机坐标系中生成，偏移量按可达距离 r ：缩放 · 横向（左右）： $r \times \{0.3, 0.4, 0.5, 0.6, 0.8, 1.0, 1.2\}$ （7 个层级，每臂符号翻转） · 前后： $r \times \{-0.1, 0.0, 0.1, 0.3, 0.5, 0.7, 0.9\}$ （7 个层级） · 垂直： $r \times \{0.4, 0.2, 0.0, -0.2, -0.4\}$ （5 个层级） · 姿态：俯仰 $\{30^\circ, 45^\circ, 60^\circ\} \times$ 偏航 $\{-45^\circ, -20^\circ, 0^\circ, 20^\circ, 45^\circ\} \times$ 滚转 $\{-15^\circ, 0^\circ, 15^\circ\}$ 相机距离 < 0.20 米，或轨迹点超出基础 $0.9r$ 或距基础小于 0.08 米的候选被丢弃。存活的候选按以下方式评分：

$$S = \text{FR}(\mathbf{T}_{\text{base}}) - 5.0 \cdot |\bar{\rho} - 0.65| \quad (8)$$

其中 FR 为最多 20 个关键帧上的逆运动学可行性率（使用 mink 逆运动学求解器，quadprog 后端，100 次迭代， 10^{-5} 阈值）。第二项为可达性惩罚：

$$\bar{\rho} = \frac{1}{|\mathcal{K}|} \sum$$

$$_k \|\mathbf{T}_{\text{base}}^{-1} \mathbf{p}_k^{\text{ce}}\|/r$$

是末端执行器距基础的平均距离，按运动学可达距离 r 归一化，当 $\bar{\rho} = 0.65$ 时惩罚最小，鼓励机器人在其最大可达距离的 65% 处操作，以保留操作的运动学裕度。我们独立筛选每臂前 5 名候选，然后联合验证所有 25 种左右组合，以选择最终的基础放置。

深度感知合成。主文（方程 5）提出了一种统一的深度排序规则。在实践中，我们使用 MuJoCo 的逐几何体分割掩码将机器人分为手臂主体和夹爪区域。手臂主体掩码（机器人掩码 $= 1 \wedge$ 夹爪掩码 $= 0$ ）始终合成到修复后的场景上，因为手臂位于相机与工作空间之间，且从未被场景物体遮挡。夹爪掩码（夹爪掩码 $= 1$ ）进行逐像素深度比较：当场景深度 $D_{\text{scene}}(u, v) < D_{\text{sim}}(u, v)$ 且该像素不在膨胀后的手部掩码区域内时，位于 (u, v) 处的夹爪像素被隐藏，其中 D_{scene} 由深度任意物体 V3 估计， D_{sim} 由 MuJoCo 渲染。在合成前，手部掩码使用 5×5 核函数（1 次迭代）进行膨胀，以防止沿原始手臂轮廓暴露修复边界。最终叠加结果为：

$$I_{\text{out}}(u, v) = \begin{cases} I_{\text{sim}}(u, v) & \text{if } (u, v) \in M_{\text{arm}} \cup M_{\text{gripper.vis}} \\ I_{\text{inpaint}}(u, v) & \text{otherwise} \end{cases} \quad (9)$$

其中 $M_{\text{夹爪可见性}} = M_{\text{gripper}} \setminus \{(u, v) : D_{\text{scene}} < D_{\text{sim}} \wedge (u, v) \notin M_{\text{hand}}\}$ 。

A.5 质量筛选细节。

L1（流水线内部）。一帧有效需满足：(i) 检测到手部，(ii) 逆运动学跟踪误差 $< 0.05 \text{ m}$ ，(iii) 渲染的机器人可见（ > 0 像素），(iv) 无自碰撞（MuJoCo 接触检查）。额外无效条件：双臂交叉接触 > 1 或机器人掩码 $> 70\%$ 占图像面积。

稳定性侵蚀。夹在无效区域之间的短有效片段（ $< \lfloor 0.3 \times \text{帧每秒} \rfloor$ 帧）被侵蚀为无效。

L2（统计）。应用两个事后统计过滤器：(i) Q1/Q99 过滤器：对于每个动作维度，计算每个数据集的 Q1 和 Q99 统计量（排除先前已失效的帧）。超出

$[Q1 - 3(Q99 - Q1), Q99 + 3(Q99 - Q1)]$ 范围的帧被标记。(ii) 突变过滤器：对于每个步骤，在状态/动作轨迹上计算残差、加速度和加加速度。超过每个维度阈值（根据数据集分布计算）的步骤被标记。经过两个过滤器后，总无效帧比例超过 60% 的回合被完全丢弃。

L3（视觉语言模型一致性）。一个视觉语言模型（Qwen3.5）审核每个合成视频的语义一致性。视频以 4 帧每秒采样，并与子任务描述一起发送。提示词为：

```
You are evaluating whether a manipulation video matches its text
description.

This is a ROBOT manipulation dataset. "Hand" refers to the robot's
gripper/end-effector.
Many tasks use FAKE or SIMULATED objects as stand-ins for real
objects. This is EXPECTED.
Task Description: {description}
Determine if the robot's actions match the described task.
Flag MAJOR MISMATCHES: wrong action type, wrong object category,
wrong target location, or failed execution.
Be tolerant of: fake/toy objects, minor appearance variations,
small spatial deviations, different grasping approaches.
Respond in JSON: {"is_consistent": true/false, "confidence":
0.0-1.0, "reasoning": "..."}

```

被判定为不一致的回合被丢弃。

A.6 颜色随机化。

每个渲染的机器人在 HSV 空间中进行确定性颜色随机化： $H \sim U(0, 1)$ ， $S \sim U(0.3, 1)$ ， $V \sim U(0.4, 1)$ ，均匀应用于所有连杆。

表 3：支持的机器人形态。

Robot	DOF	Gripper (mm)	Reach (m)
Panda	7	0–80	1.272
Kinova Gen3	7	0–85	1.337
IIWA	7	0–85	1.411
Sawyer	7	14–79	1.420
FR3	7	0–80	1.272
xArm7	7	0–85	1.290
UR5e	6	0–85	1.236
UR10e	6	0–85	1.627
Jaco	6	0–125	1.200
ViperX	6	15–87	0.911
WidowX	6	11–55	0.787
ARX-L5	6	0–88	0.855
Piper	6	0–70	0.883
YAM	6	4–75	0.866
Aloha-Agilex	6	7–102	0.853



图 6：15 种支持的机器人形态。所有 15 个机器人的三维模型。

A.7 支持的机器人形态。

表 3 列出了 15 种形态。图 6 展示了所有 15 个机器人的三维模型。

B 评估框架细节

B.1 扰动参数。

随机化（标准分布外）。原始的 RoboTwin 2.0 设置同时应用背景纹理替换、光照随机化、桌面高度偏移和杂物。我们在下面将这些解耦为独立的轴，并额外引入相机偏移、机器人颜色、改写指令和未见物体作为新的评估维度。

视觉外观：背景。桌面和地板纹理替换为从库中随机采样的纹理。光照。光源位置和强度随机化。机器人颜色。对所有机器人连杆应用从 $[0^\circ, 360^\circ)$ 开始的均匀色相偏移。

场景布局：桌面高度。垂直偏移 ± 4 cm. 杂乱。3–5 个干扰物体，随机姿态。相机偏移。头部相机每轴位移最多 5 厘米。

任务语义：改写指令。505 条口语化改写命令（人工与大语言模型生成）。未见物体。50 个新任务，物体实例未出现在微调演示中（类别相同，外观/几何不同），涵盖七个操作族：

- 移动到垫子/锅（10）：移动瓶子到垫子，移动杯子到垫子，移动碗到垫子，移动杯子到锅，移动瓶子到锅，移动马克杯到锅，移动苹果到锅，移动海豹到锅，移动药瓶到锅，移动碗到锅
- 放入篮子（11）：放置肥皂到篮子，放置马克杯到篮子，放置香水到篮子，放置茶盒到篮子，放置玩具车到篮子，放置苹果到篮子，放置瓶子到篮子，放置杯子到篮子，放置咖啡盒到篮子，放置酱料罐到篮子，放置汉堡到篮子
- 放置在支架上（4）：放置杯子到支架，放置马克杯到支架，放置瓶子到支架，放置苹果到支架
- 放置在秤上（3）：放置瓶子到秤，放置杯子到秤，放置马克杯到秤
- 放入柜子（3）：放入苹果到柜子，放入海豹到柜子，放入碗到柜子
- 双手将 A 放到 B（12）：放置杯子到左侧瓶子，放置马克杯到右侧苹果，放置瓶子到左侧杯子，放置海豹到右侧马克杯，放置马克杯到左侧杯子，放置苹果到左侧马克杯，放置瓶子到右侧苹果，放置海豹到左侧杯子，放置马克杯到左侧瓶子，放置苹果到右侧杯子，放置杯子到右侧海豹，放置瓶子到左侧苹果
- 移开（7）：移开杯子、移开瓶子、移开苹果、移开马克杯、移开海豹、移开碗、移开药瓶

具身：跨具身迁移。默认具身为 Aloha-Agilex，以单个双臂 URDF 加载。对于零样本跨具身评估，我们将其替换为 ARX-X5、UR5-WSG 或 Franka Panda。每种替代具身均以两个独立的单臂 URDF 加载，对称放置在工作空间中心两侧，臂间基座距离分别为 0.6 米（ARX-X5）、0.59 米（UR5-WSG）和 0.65 米（Franka），以适应不同的臂长。初始末端执行器位姿通过逆运动学对齐，且所有三个相机外参（头部相机 + 两个腕部相机）在不同具身间对齐，以确保相机帧动作空间中起始条件一致。

B.2 任务列表。

50 个任务：调整瓶子、敲击积木锤、积木按 RGB 排序、积木按大小排序、点击闹钟、点击铃铛、倾倒大垃圾桶、抓取滚筒、传递积木、传递麦克风、悬挂马克杯、提起锅、移动罐子到锅、移动药瓶到垫子、移开扑克牌、移动订书机到垫子、打开笔记本电脑、打开微波炉、拾取不同瓶子、拾取双瓶、从左到右放置、从右到左放置、放置面包到篮子、放置面包到煎锅、放置汉堡和薯条、放置罐子到篮子、放置罐子到塑料盒、放置容器到盘子、放置双鞋、放置空杯子、放置风扇、放置鼠标垫、放置物体到篮子、放置物体到秤、放置物体到支架、放置手机支架、放置鞋子、按压订书机、将瓶子放入垃圾桶、将物体放入柜子、旋转二维码、扫描物体、摇晃瓶子、水平摇晃瓶子、堆叠三块积木、堆叠两块积木、堆叠三个碗、堆叠两个碗、盖章、转动开关。

每个任务的步数限制从 400（例如点击铃铛、调整瓶子）到 1700（将瓶子放入垃圾桶）不等，大多数任务为 400。复杂的多步任务使用更高的限制：打开微波炉 1500、积木排序 1200、堆叠三块积木 1200、堆叠碗 900 - 1200、悬挂马克杯 900、堆叠两块积木 / 传递积木 800、放置罐子到塑料盒 800。新任务/未见任务默认为 1000 步。

B.3 协议。

每个任务 50 个回合，二元成功。聚合：视觉 = 均值（背景、光照、机器人颜色）；场景 = 均值（高度、杂乱度、相机）；具身 = 均值（ARX、UR5、Franka）；任务 = 均值（物体、语言）。

B.4 EBench 桌面。

EBench [46] 在 Isaac Sim 中提供了 7 个桌面任务：收集咖啡豆、翻转杯子并收集饼干、将框架对准笔筒、安装齿轮、将销钉插入孔中、将玻璃杯放入玻璃盒、拧紧螺母。相机高度高于 RoboTwin，更接近以自我为中心的视角。

C 模型架构细节

Qwen3.5-4B 视觉语言骨干网络处理多视角 RGB 图像（每个时间步 2–3 个视角）和结构化文本提示，生成一系列隐藏状态 $\mathbf{H} \in \mathbb{R}^{L \times d}$ ，这些状态联合编码视觉和语言信息。相机内参 $\mathbf{K} \in \mathbb{R}^{3 \times 3}$ 和外参 $\mathbf{T}_{wc} \in SE(3)$ 通过 mRoPE 位置编码注入视觉特征，使模型能够推理相机与场景之间的三维空间关系。DiT 动作头通过交叉注意力以 $\mathbf{H}$ 为条件：上下文生成器使用 8 个可学习查询令牌将 $\mathbf{H}$ 压缩为条件特征 $\mathbf{C}$ ，DiT 层在通过流匹配（8 个训练步骤 / 4 个推理步骤）预测 32 步动作块时关注 $\mathbf{C}$ 。

C.1 结构化提示。

文本输入遵循双字段格式：

```
embodiment: {type}_{model}
instruction: {task description}
```

embodiment 编码数据源和机器人模型：robot aloha（真实机器人）、h2r arx（Ego2R 与 ARX）、human ego（原始自我）。训练期间以 15% 的概率丢弃为“None”。instruction 从不丢弃。

C.2 相机坐标系下的相对末端执行器。

每个动作步骤为 7 维：3D 位置增量 $\Delta \mathbf{p}$ ，3D 旋转增量 $\Delta \boldsymbol{\omega}$ （旋转向量），1D 夹爪。给定末端执行器到相机的变换 $\mathbf{T}_{ce} = \mathbf{T}_{wc}^{-1} \mathbf{T}_{we}$ 及其旋转分量 $\mathbf{R}_{ce}$ ，基坐标系增量变换为：

$$\Delta \mathbf{p}_{cc} = \mathbf{R}_{ce} \Delta \mathbf{p}_{ee}, \quad \Delta \mathbf{R}_{cc} = \mathbf{R}_{ce} \Delta \mathbf{R}_{ee} \mathbf{R}_{ce}^T \quad (10)$$

这自然地统一了来自不同相机设置和机器人形态的数据，无需显式外参校准，如第 3 节所述。

C.3 流匹配。

给定干净动作 $\mathbf{a}_0$ 和噪声 $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ ，在 $t \in [0, 1]$ 处的加噪样本：

$$\mathbf{a}_t = (1 - t) \mathbf{a}_0 + t \boldsymbol{\epsilon} \quad (11)$$

训练目标：

$$\mathcal{L} = \mathbb{E}_{t, \mathbf{a}_0, \boldsymbol{\epsilon}} \|\mathbf{v}_\theta(\mathbf{a}_t, t, \mathbf{c}) - (\boldsymbol{\epsilon} - \mathbf{a}_0)\|^2 \quad (12)$$

其中 $\mathbf{c}$ 是视觉-语言条件。推理使用 4 个欧拉步长 ($\Delta t=1/4$)。

D 训练细节

D.1 预训练。

$8 \times \text{A100 GPU}$ ，每 GPU 批量 12，骨干网络 $10^{-5} \rightarrow 10^{-6}$ 学习率余弦（5K 预热），动作头学 $10 \times$ 习率 ($10^{-4} \rightarrow 10^{-5}$)，AdamW ($\beta_1=0.9, \beta_2=0.95$)，bf16、ZeRO-1、200K 步（ ~ 1920 万帧）、每次前向 8 个扩散步骤。无图像增强。

D.2 预训练数据。

机器人数据包含三个来源：DROID [7] (~ 511 小时) 提供使用 Franka 机械臂在多样物体和场景中的真实世界遥操作演示。AgibotWorld [8] ($\sim 2,404$ h) is a 大规模真实遥操作数据集，覆盖人形平台上的 180 个操作任务。InternData [55] (~ 3650 小时) 提供跨 Franka、人形和 Aloha 本体的仿真生成演示。这些总计 ~ 6565 小时。Ego2R 数据来源于四个以自我为中心的




图 7：预训练数据组成。 扇形图显示每个来源的采样权重（训练混合比例）；面板标题给出总数据量。（a）机器人（~6565 小时）。（b）Ego2R（~18,561 h）。

来源（ANT 7 小时、EgoDex 732 小时、ViTRA 249 小时、EgoVerse 954 小时，处理前总计 ~ 1940 小时）在 15 种形态上渲染，经过流水线处理和质量筛选后得到 18561 小时。混合比例（Ego2R 与机器人 1:3、3:1、1:1）通过每个来源的采样权重实现；所有配置处理相同总帧数。图 7 显示了每组内使用的每个来源采样权重。

D.3 微调。

所有微调运行加载预训练权重。8× A100 GPU，每 GPU 批量 12，骨干学习率 $10^{-5} \rightarrow 10^{-6}$ 余弦（5K 预热），动作头学习率 $10 \times (10^{-4} \rightarrow 10^{-5})$ 、AdamW（ $\beta_1=0.9, \beta_2=0.95$ ）、bf16、ZeRO-2、ColorJitter、每次前向 8 个扩散步骤。

RoboTwin Clean。50 个任务 × 50 个演示（2500 个回合），50K 步，块 20，每 16 步重新规划。

EBench 桌面任务。7 项桌面任务 × 400 个演示（2,800 个回合），50K 步，块大小 32。

真实机器人。数据详情见第 E 节。1:1 遥操作与 Ego2R 混合比例，50K 步，块大小 32。

D.4 消融配置。

消融实验（图 3）仅使用自我中心来源的数据（原始自我中心数据或 Ego2R）进行预训练，排除真实机器人数据，以隔离该流程的贡献：• 原始自我中心数据（~ 1,940 小时）：经过流程质量过滤但未进行机器人渲染的自我中心视频。• Ego2R，1 种形态（~ 1,237 小时）：流程处理后的数据，仅 ARX-L5。• Ego2R，5 种形态（~ 6,187 小时）：Aloha-Agilex、ARX-L5、FR3、ViperX、xArm7。• Ego2R，10 种形态（~ 12,374 小时）：Aloha-Agilex、ARX-L5、FR3、IIWA、Jaco、Piper、UR5e、ViperX、YAM、xArm7。• Ego2R，15 种形态（~ 18,561 小时）：全部 15 种。• Ego2R（15 种）+ 原始自我中心数据（~ 20,501 小时）：15 种形态的 Ego2R 加上原始自我中心数据。

所有消融模型仅在指定的自我来源数据上进行预训练（无真实机器人数据），然后在 RoboTwin Clean 上进行微调。

E 真实机器人实验细节

E.1 平台与任务。

ARX ACone 双臂机器人（每臂 6 自由度，平行夹爪，头部及双腕部 RGB 相机，15 赫兹控制频率，每 32 步重新规划）。

- **放置水果**（3 步）：将 3 个水果放入篮子中。



图 8: 自我中心演示 → Ego2R 在真实场景上的综合。上: 原始自我中心人类操作。下: Ego2R 流程输出, 叠加 ACone 机器人。

表 4: 真实机器人评分。

Task	Step 1	Step 2	Step 3	Step 4
Put Fruits	33.3	33.3	33.3	—
Put Blocks	25	25	25	25
Fold Towel	50	50	—	—
Sweep Trash	25	25	25	25
Insert Screw	25	25	25	25

- **放置积木** (4 步): 打开抽屉, 放置 2 块积木, 关闭抽屉。
- **折叠毛巾** (2 步): 两次连续折叠。
- **清扫垃圾** (4 个步骤): 拿起扫帚、清扫、倾倒、放回扫帚。
- **插入螺丝** (4 个步骤): 双手传递并插入 2 颗螺丝。

E.2 数据。

每个任务 20 个遥操作演示 (共 100 个) + ~ 35 分钟跨 5 个场景的自我视角视频。自我视角视频通过路径 B (WiLoR、DynHaMR、Qwen3.5、Ego2R) 处理, 生成 675 个 ACone 合成片段。遥操作和 Ego2R 数据在微调时以 1:1 的比例混合。

E.3 自我视角视频到 Ego2R 的可视化。

图 8 展示了自我视角数据中的代表性帧以及对应的 Ego2R 合成结果。顶行显示原始的第一人称人类操作; 底行显示管道输出, 其中机器人 (ACone) 叠加在修复后的场景上。

E.4 评分。

子步骤部分评分 (表 4), 每项任务 100 分, 共 20 次试验。

F 补充实验结果

F.1 与 Pi0.5 的比较。

Pi0.5 [4] 在相同的 RoboTwin 末端执行器设置 (OpenPI 框架, 相机坐标系相对末端执行器) 下进行评估。Pi0.5 使用了不同的骨干网络和预训练数据。图 9 报告了结果。Ego2R+Robot (1:1) 在几乎所有设置下均优于仅使用机器人的基线。




图 9: 在 RoboTwin 设置下与 Pi0.5 的比较。

F.2 逐任务结果。

表 5 报告了在 Clean 和 Randomized 设置下，五个模型（Pi0.5 和我们的四个模型）在所有 50 个 RoboTwin 任务上的逐任务成功率。

表 5: RoboTwin 上各任务结果, 包含 Pi0.5 (成功率%)。

Task	Pi0.5		Robot-only		Ego2R (1:3)		Ego2R (3:1)		Ego2R (1:1)	
	Clean	Rand	Clean	Rand	Clean	Rand	Clean	Rand	Clean	Rand
adjust_bottle	62.0	18.0	94.0	77.0	92.0	79.0	100.0	72.0	89.0	91.0
beat_block_hammer	48.0	16.0	63.0	27.0	64.0	56.0	57.0	18.0	65.0	71.0
blocks_ranking_rgb	74.0	16.0	56.0	60.0	64.0	63.0	49.0	43.0	78.0	60.0
blocks_ranking_size	32.0	0.0	30.0	22.0	46.0	21.0	43.0	7.0	52.0	16.0
click_alarmclock	44.0	56.0	96.0	93.0	100.0	87.0	100.0	85.0	100.0	100.0
click_bell	32.0	40.0	100.0	95.0	100.0	94.0	100.0	93.0	100.0	100.0
dump_bin_bigbin	72.0	70.0	54.0	73.0	72.0	69.0	81.0	76.0	86.0	72.0
grab_roller	94.0	46.0	98.0	71.0	68.0	48.0	91.0	64.0	89.0	63.0
handover_block	16.0	0.0	5.0	2.0	18.0	4.0	39.0	9.0	36.0	9.0
handover_mic	26.0	4.0	69.0	13.0	86.0	34.0	83.0	17.0	97.0	23.0
hanging_mug	10.0	4.0	14.0	16.0	14.0	9.0	12.0	9.0	10.0	10.0
lift_pot	8.0	2.0	93.0	28.0	84.0	14.0	95.0	44.0	93.0	44.0
move_can_pot	28.0	0.0	47.0	50.0	30.0	40.0	42.0	85.0	47.0	65.0
move_pillbottle_pad	60.0	44.0	63.0	60.0	68.0	69.0	41.0	67.0	74.0	82.0
move_playingcard_away	90.0	52.0	74.0	58.0	88.0	92.0	88.0	42.0	92.0	63.0
move_stapler_pad	22.0	6.0	23.0	19.0	34.0	21.0	30.0	13.0	43.0	31.0
open_laptop	68.0	20.0	77.0	61.0	74.0	56.0	64.0	46.0	75.0	58.0
open_microwave	26.0	8.0	77.0	59.0	42.0	29.0	37.0	32.0	50.0	25.0
pick_diverse_bottles	56.0	18.0	60.0	37.0	58.0	53.0	71.0	50.0	70.0	50.0
pick_dual_bottles	82.0	14.0	91.0	59.0	80.0	77.0	83.0	55.0	97.0	54.0
place_a2b_left	60.0	10.0	40.0	55.0	58.0	42.0	54.0	48.0	73.0	44.0
place_a2b_right	58.0	14.0	42.0	49.0	52.0	41.0	53.0	51.0	64.0	53.0
place_bread_basket	68.0	44.0	75.0	55.0	72.0	64.0	76.0	59.0	79.0	62.0
place_bread_skillet	86.0	46.0	76.0	41.0	76.0	50.0	80.0	61.0	87.0	53.0
place_burger_fries	90.0	78.0	96.0	83.0	98.0	81.0	97.0	88.0	96.0	88.0
place_can_basket	40.0	0.0	49.0	25.0	38.0	9.0	34.0	15.0	34.0	16.0
place_cans_plasticbox	94.0	74.0	90.0	68.0	54.0	68.0	97.0	59.0	70.0	59.0
place_container_plate	96.0	58.0	86.0	76.0	92.0	79.0	93.0	73.0	93.0	81.0
place_dual_shoes	54.0	12.0	50.0	30.0	34.0	27.0	35.0	17.0	35.0	19.0
place_empty_cup	74.0	56.0	73.0	74.0	86.0	83.0	88.0	78.0	88.0	66.0
place_fan	36.0	30.0	48.0	54.0	48.0	24.0	41.0	50.0	39.0	46.0
place_mouse_pad	18.0	0.0	41.0	34.0	22.0	36.0	30.0	25.0	29.0	33.0
place_object_basket	24.0	4.0	65.0	50.0	76.0	28.0	77.0	51.0	69.0	48.0
place_object_scale	58.0	44.0	38.0	46.0	40.0	33.0	52.0	45.0	40.0	47.0
place_object_stand	94.0	40.0	70.0	75.0	80.0	77.0	87.0	71.0	82.0	82.0
place_phone_stand	40.0	4.0	65.0	49.0	48.0	63.0	70.0	61.0	75.0	45.0
place_shoe	64.0	24.0	84.0	84.0	78.0	84.0	63.0	58.0	75.0	76.0
press_stapler	42.0	32.0	86.0	71.0	82.0	62.0	76.0	70.0	83.0	62.0
put_bottles_dustbin	14.0	2.0	25.0	20.0	42.0	32.0	41.0	19.0	50.0	39.0
put_object_cabinet	22.0	0.0	41.0	20.0	30.0	19.0	39.0	36.0	43.0	29.0
rotate_qrcode	50.0	2.0	31.0	17.0	54.0	16.0	54.0	36.0	69.0	37.0
scan_object	62.0	38.0	62.0	37.0	66.0	46.0	66.0	46.0	56.0	33.0
shake_bottle	96.0	72.0	91.0	75.0	88.0	89.0	99.0	75.0	96.0	87.0
shake_bottle_horizontally	98.0	74.0	98.0	81.0	84.0	87.0	99.0	84.0	97.0	92.0
stack_blocks_three	68.0	16.0	14.0	23.0	14.0	28.0	10.0	13.0	28.0	23.0
stack_blocks_two	80.0	56.0	75.0	70.0	82.0	75.0	77.0	56.0	95.0	61.0
stack_bowls_three	38.0	36.0	50.0	41.0	40.0	43.0	48.0	50.0	47.0	45.0
stack_bowls_two	82.0	44.0	76.0	78.0	66.0	73.0	73.0	67.0	72.0	72.0
stamp_seal	32.0	2.0	35.0	42.0	46.0	30.0	34.0	30.0	44.0	42.0
turn_switch	56.0	40.0	55.0	42.0	40.0	42.0	53.0	41.0	50.0	48.0
Average	54.9	27.7	62.2	50.9	61.4	51.0	64.1	49.2	68.1	53.5