

EgoMimic: 通过第一人称视频扩展模仿学习

Simar Kareer¹, Dhruv Patel^{1*}, Ryan Punamiya^{1*}, Pranay Mathur^{1*}, Shuo Cheng¹
陈旺², 朱迪·霍夫曼^{1†}, 徐丹飞^{1†}




图 1: EgoMimic 将人类具身数据——与三维手部轨迹配对的第一人称视频——解锁为模仿学习的新型可扩展数据源。我们无需机器人，只需佩戴 Project Aria 眼镜，用自己的双手执行操作任务，即可在任何地方采集此类数据。EgoMimic 弥合了人类具身数据（左）与传统机器人遥操作数据（右）在运动学、分布和外观上的差异，以学习统一策略。我们发现，与仅使用机器人数据相比，人类具身数据可将任务性能提升 34-228%，并实现对新物体乃至新场景的泛化。

摘要——模仿学习所需演示数据的规模与多样性是一项重大挑战。我们提出 EgoMimic，一个通过人类具身数据（特别是与三维手部跟踪配对的第一人称人类视频）扩展操作能力的全栈框架。EgoMimic 通过以下方式实现这一目标：（1）利用符合人体工学的项目 Aria 眼镜采集人类具身数据的系统，（2）最大限度缩小与人类数据运动学差距的低成本双臂机械手，（3）跨域数据对齐技术，以及

（4）在人类与机器人数据上联合训练的模仿学习架构。与先前仅从人类视频中提取高层意图的工作相比，我们的方法将人类与机器人数据平等地视为具身演示数据，并从两种数据源中学习统一策略。

EgoMimic 在多种长时程、单臂和双臂操作任务上，相较于最先进的模仿学习方法取得了显著提升，并实现了对全新场景的泛化。最后，我们展示了 EgoMimic 有利的扩展趋势：增加 1 小时额外手部数据比增加 1 小时额外机器人数据更有价值。视频和更多信息可在 <https://egomimic.github.io/> 找到。

一、引言

端到端模仿学习在学习复杂操作任务方面表现出色，但在面对新场景和新任务时仍显脆弱。借鉴计算机视觉和自然语言处理近期的成功经验，我们假设，要使学习到的策略实现广泛泛化，必须大幅扩展训练数据规模。这些邻近领域受益于互联网来源的数据，而机器人学缺乏同等的数据来源。

为了扩大机器人领域的数据规模，数据采集系统近期取得了进展。例如，ALPHA [1]、[2] 和 GELLO [3] 是用于采集遥操作数据的直观主从控制系统。其他工作则选择开发手持式夹具，无需机器人即可采集数据 [4]。尽管取得了这些进展，通过这些系统采集的数据仍需要专用硬件，并且提供演示需要主动投入。我们假设实现互联网规模机器人数据的关键一步是被动数据采集。正如互联网并非为整理训练大型视觉和语言模型的数据而构建，理想的机器人数据系统应允许用户在无意中生成感觉运动行为数据。人类视频，尤其是以第一人称视角拍摄的视频，为被动数据可扩展性提供了理想的数据来源。这类数据与机器人数据高度一致，因为它提供了用于视觉的第一人称相机、用于动作的三维手部跟踪以及用于定位的机载 SLAM。能够采集此类数据的消费级设备的出现，包括扩展现实（Extended Reality, XR）设备和配备摄像头的“智能眼镜”，为大规模被动数据采集带来了前所未有的机遇。虽然近期工作已开始利用人类视频数据，但其方法仅限于从视频中提取高层意图信息，以构建指导低层条件策略的规划器 [5]、[6]。因此，这些系统仍受限于低层策略的性能，而低层策略通常仅在遥操作数据上训练。我们认为，要真正利用人类数据扩展机器人性能，不应将人类视频视为需要单独处理的辅助数据源。相反，我们应利用第一人称

人类数据与机器人数据之间的固有相似性，将它们视为具身数据源连续谱系中的平等组成部分。从两种数据源无缝学习需要全栈创新，从统一两种数据源的数据采集系统，到能够实现此类跨具身策略学习的模仿学习架构。

为此，本文将人类数据视为机器人操作的一等数据源。我们相信，该系统是利用可穿戴智能眼镜的被动数据训练操作策略的关键一步。本文提出 EgoMimic（图 1），一个从人类第一视角视频和遥操作机器人数据中收集数据并联合训练操作策略的框架，包括：

（一） 基于 Project Aria 眼镜 [7] 构建的人类数据采集系统，可捕获第一视角视频、三维手部跟踪和设备同步定位与建图（SLAM）。这些丰富信息使我们能够将人类第一视角数据转换为与机器人模仿学习兼容的格式。**（二）** 一种功能强大且低成本的双臂机器人，最小化与人类具身数据在运动学和相机到相机方面的差距。特别是，我们通过使用 Project Aria 眼镜作为机器人主传感器，最小化人类与机器人数据之间的相机到相机设备差距（视场角、动态范围等）。**（三）** 为缓解数据分布差异，我们对人类与机器人的动作分布进行归一化和对齐。此外，通过视觉掩码最小化人类手臂与机器人机械臂之间的外观差距。**（四）** 一种统一的模仿学习架构，使用共同的视觉编码器和策略网络在人类手部数据和机器人数据上进行联合训练。尽管人类与机器人的动作空间不同，我们的模型强制共享表示，以实现性能随人类具身数据扩展，优于现有将人类与机器人数据分开处理的方法。我们在真实世界的三个具有挑战性的长时程操作任务上对 EgoMimic 进行了实证评估：连续物体入碗、叠衣服和杂货装箱（图 5）。结果表明，EgoMimic 在所有场景中显著提升了任务性能，相对提升最高达 200%。值得注意的是，我们观察到 EgoMimic 对仅在人类数据中出现的物体和场景表现出泛化能力。最后，我们分析了 EgoMimic 的扩展特性，发现从额外一小时的手部数据中学习显著优于从额外一小时的机器人数据中训练。

二、相关工作

模仿学习：模仿学习（Imitation Learning, IL）已被用于执行多样且接触丰富的操作任务 [8]、[9]、[10]。近年来，模仿学习领域的进展推动了像素到动作模仿学习模型的发展，这类模型直接将原始视觉输入映射为底层机器人控制 [1]、[11]。这些视觉模仿学习模型已展现出令人印象深刻的反应式策略 [12]、[5]。在 RT1 和 RT2 等工作中，扩展这些模型已显示出强大的泛化能力 [13]、[14]。然而，这些方法仍然耗费大量人力和资源，

例如，RT1 需要 17 个月的数据采集和 13 台机器人 [13]。本文提出一种学习框架，利用可扩展的人类具身演示，其规模与多样性有望超越任何仅由机器人演示构成的数据集。

从视频演示中学习：为满足像素到动作模仿学习算法的数据需求，许多近期工作利用人类数据，因为其具有高度可扩展性。人类数据在不同抽象层次上被使用：一些工作使用互联网规模数据集中的人类视频来预训练视觉表征 [15]、[16]、[17]；另一些工作则通过点轨迹预测、像素空间中的中间状态幻觉或可供性预测，更明确地利用人类视频理解场景动态 [18]、[19]、[6]、[20]、[21]；最后，近期工作使用手部轨迹预测作为预测机器人动作的代理 [5]。尽管这些方法利用了手部数据，但它们通常采用独立模块分别处理手部数据和机器人数据。相比之下，本文方法充分利用 Aria 眼镜提供的丰富信息（包括机载同步定位与建图），能够统一并平等对待人类数据与机器人数据，通过单一端到端策略从两种数据源联合训练。

数据采集系统：已有多种方法用于扩展机器人数据。低成本设备如太空鼠标（Space Mouse）能够对机器人机械臂进行灵敏且精细的遥操作 [22]、[10]、[23]、[11]、[24]。进一步的工作通过虚拟现实系统（如虚拟现实头戴设备）提升直观控制 [25]、[26]、[27]、[28]、[29]。近期系统如 ALOHA 和 GELLO 通过主从式遥操作接口 [1]、[3] 或外骨骼 [30]、[31] 提高了低成本精细双手操作任务的人机工效。其他工作尝试采集具有丰富信息（如三维动作跟踪）的人类具身数据，但现有系统面临权衡。利用丰富信息的系统要么不便携（例如静态相机 [32]、[5]、[33]、[34]），要么不符合人机工效（例如需要手持夹爪 [4]、[35] 或佩戴式相机 [36]、[37]），这阻碍了数据采集系统的被动可扩展性。沿着这一思路，本文方法通过 Project Aria 眼镜 [7] 的人机工效外形采集第一人称视频和三维手部跟踪数据。虽然其他可穿戴数据采集方法（如虚拟现实头戴设备）采集手部位置以遥操作机器人，但本文系统完全不需要机器人。随着类似消费级设备的普及率持续上升，该系统具有被动扩展的潜力 [38]。

跨具身策略学习：跨具身学习的进展表明，在具有多样化机器人具身的数据集上训练的大型模型更具泛化能力 [39]。一些方法旨在通过观测重投影 [40]、动作抽象 [41] 以及以具身为条件的策略 [42] 来弥合具身差距。近期工作将跨具身学习视为领域自适应问题 [43]。本文认为，在迁移学习中，人类数据应被视为另一种具身。




图 2: 本文人类数据系统使用 Aria 眼镜采集第一人称 RGB 图像, 并利用其侧面 SLAM 相机进行设备定位和手部跟踪。机器人由两个 ViperX 从臂组成, 配备 Intel RealSense D405 腕部相机, 由两个 WidowX 主臂控制。本文机器人使用相同的 Aria 眼镜作为主视觉传感器, 以最小化相机间差距。

III. 自我模仿

EgoMimic 是一个全栈框架, 能够同时从以自我为中心的人类具身数据和机器人数据中捕获并学习。我们在下文详细介绍了流程的每个组成部分, 首先是我们用于人类和机器人数据收集的硬件设置 (第 III-A 节), 接着是我们处理和配准两种来源数据的方法 (第 III-B 节), 最后是我们的统一策略架构 (第 III-C 节)。我们整个过程中的设计选择都旨在使人类具身数据像遥操作机器人数据一样适用于机器人学习。

A. 数据采集系统与硬件设计

用于以自我为中心演示采集的 Aria 眼镜。一个理想的人类数据采集系统需要捕获丰富的场景信息, 同时保持被动可扩展性。这样的系统应当可穿戴、符合人体工程学、具有宽广的视场角, 并能够跟踪手部位置、设备姿态等。EgoMimic 通过构建在 Project Aria 眼镜 [7] 之上填补了这一空白。Aria 眼镜是用于捕获多模态以自我为中心数据的头戴设备。该设备采用符合人体工程学的眼镜形态, 重量仅为 75 克, 允许长时间佩戴和被动数据采集。我们的工作利用前置广角 RGB 相机进行视觉观测, 并利用两个单色场景相机进行设备姿态和手部跟踪 (示例数据见图 2)。特别是, 侧向场景相机即使手部移出主 RGB 相机视野也能跟踪手部姿态, 显著缓解了人类在顺序操作任务中头部和视线自然先于手部移动所带来的挑战。此外, Project Aria[44]、[45] 正在进行大规模数据采集工作, 并且这些设备通过积极的研究合作计划广泛提供给学术界。未来, 我们的系统可以使用户将他们采集的数据与这些大型数据集无缝合并。最终, 我们提出了一种能够实现被动但特征丰富的人类数据采集系统, 以帮助扩展机器人操作。

低成本双臂机械臂。为了有效利用以自我为中心的人类具身数据, 机器人机械臂应当能够以类似于人类手臂的方式运动

运动。以往的工作通常依赖桌面安装的机械臂, 例如 Franka Emika Panda [46]。尽管这些系统能力强大, 但在运动学上与人类手臂存在显著差异。此外, 其较大的重量和惯性出于安全考虑要求缓慢、谨慎的运动, 这在很大程度上使其无法以与人类相当的速度执行操作任务。针对这些局限性, 我们专门构建了一款轻量、敏捷且成本效益高的双臂机械臂。受 ALOHA 系统 [1] 的启发, 我们的机器人装置由两个 6 自由度 ViperX 300 S 手臂组成, 配备 Intel Realsense D405 腕部摄像头, 以倒置配置安装在一个高度可调的支架上作为躯干 (图 2), 在运动学上模仿人类上半身。ViperX 手臂纤细且尺寸与人类手臂相对接近, 这有助于提升其敏捷性。整个支架 (不包括 ViperX 手臂) 的组装成本低于 1000 美元 (物料清单将公开提供)。我们还构建了一个主机器人支架用于采集遥操作数据, 与 ALOHA [1] 类似。此外, 由于我们的方法联合从以自我为中心的人类和机器人数据中学习视觉策略, 对齐视觉观察空间至关重要。因此, 除了通过数据后处理进行对齐 (第 III-B 节) 外, 我们还通过使用第二副 Aria 眼镜作为机器人的主传感器来直接匹配摄像头硬件, 将其直接安装在躯干顶部, 位置类似于人眼的位置 (图 2)。这使我们能够减轻与摄像头设备相关的观察域差距, 包括视场角、曝光水平和动态范围。

B. 数据处理与域对齐

为了从人类和机器人数据中训练统一策略, EgoMimic 弥合了三个关键的人机差距: (1) 统一动作坐标系, (2) 对齐动作分布, 以及 (3) 减轻视觉外观差距。

原始数据流。我们按照第 III-A 节所述从硬件装置中流式传输原始传感器数据。人类和机器人佩戴的 Aria 眼镜生成以自我为中心的 RGB 图像流。此外, 机器人还生成两个腕部摄像头流。对于本体感觉, 我们利用 Aria 机器感知服务 (MPS) [47] 来估计两者的 3D 姿态

Source	Type	Data
Human $\mathcal{D}_H$	Image	Egocentric view
	Proprio	3D hand poses ($^H p$)
	Action	Normalized hand tracks ($^H a^p$)
Robot $\mathcal{D}_R$	Image	Egocentric + wrist views
	Proprio	EEF poses ($^R p$), Joint positions ($^R q$)
	Action	EEF actions ($^R a^p$), Joint actions ($^R a^q$)

表 1: 人类与机器人数据流比较

手部 $^H p \in \mathbb{S}^3(3) \times \mathbb{S}^3(3)$ 。机器人本体感知数据包括其末端执行器位姿 $^R p \in \mathbb{S}^3(3) \times \mathbb{S}^3(3)$ 和关节位置 $^R q \in \mathbb{R}^{2 \times 7}$ (包括夹爪关节位置)。此外,我们还收集了遥操作机器人数据的关节空间动作 $^R a^q \in \mathbb{R}^{2 \times 7}$ 。统一人机数据坐标框架。机器人动作和本体感知数据通常使用固定参考系(例如相机或机器人基座坐标系)。然而,来自移动相机的以自我为中心的手部数据打破了这一假设。为了统一关节策略学习的参考系,我们将人数据和机器人末端执行器轨迹都转换到以相机为中心的固定参考系中。遵循预测动作块 [11]、[1] 的思想,我们旨在为人手和机器人末端执行器构建动作块 $a_{t:t+h}^p$ 。为简化符号,我们描述可推广到双臂的单臂情况。原始轨迹是一系列三维位姿

$[p_t^{F_t}, p_{t+1}^{F_{t+1}}, \dots, p_{t+h}^{F_{t+h}}]$, 其中 F_i 表示估计 p_i 。 F_i 时相机的坐标系,对于机器人该坐标系保持固定,而对于人类以自我为中心的数据则不断变化。我们的目标是通过将轨迹中的每个位置转换到观测相机坐标系 F_t 来构建 $a_{t:t+h}^p$ 。这使得策略能够在不考虑未来相机运动的情况下预测动作。对于人类数据,我们使用 MPS 视觉惯性 SLAM 获取世界坐标系中的 Aria 眼镜位姿 $T_{F_t}^W \in \mathbb{S}^3(3)$, 并转换动作轨迹:

$$^H a_i^p = [(T_{F_t}^W)^{-1} T_{F_i}^W p_i^{F_i}] \quad \text{对 } i \in [t, t+1, \dots, t+h]$$

示例轨迹如图 2 (左上) 所示。机器人数据使用手眼标定估计的固定相机坐标系进行类似转换。通过创建统一的参考系,我们使策略能够从动作监督中学习,无论这些监督来自人类视频还是遥操作演示。

对齐人机位姿分布。 尽管通过硬件设计和数据处理对齐了手部和机器人数据,我们仍然观察到收集的演示中手部和机器人末端执行器位姿分布存在差异。这些差异源于生物力学差异、任务执行变化以及人与机器人系统之间的测量精度差异。若不缩小这一差距,策略往往会为两种数据源学习独立的表示 [48]、[49], 从而阻碍性能随人类数据扩展。为解决这一问题,我们对每个数据源的末端执行器(手部)位姿和动作分别应用高斯归一化,如图所示

图 3. 与 [49] 相呼应,我们发现这一简单技术




图 3: a) 动作归一化: 手部与机器人数据之间的姿态分布存在差异,特别是在 y (左右) 维度上。我们在将手部和机器人姿态数据输入模型之前,分别对其应用高斯归一化。b) 视觉掩码: 为了弥合人手与机器人手臂的外观差距,我们通过 SAM 对手部和机器人应用黑色掩码,然后在图像上叠加一条红线。




图 4: 人机联合策略学习框架的架构。该模型通过共享的视觉和 ACT 编码器处理归一化的手部和机器人数据,输出手部和机器人数据的姿态预测,以及机器人数据的联合动作。该框架使用掩码图像来缓解人机外观差距,并为机器人引入腕部相机视图。

经验上有效(第 IV-B 节), 尽管我们计划在未来探索替代方案,如动作量化 [13]。

弥合视觉外观差距。 尽管对齐了用于采集机器人和人类数据的传感器硬件,人手与机器人之间仍存在一定的视觉外观差距。先前的工作已认识到这一差距,并尝试在视觉观察中遮挡或移除机械臂 [50], [51]。我们遵循类似思路,通过 SAM[52] 掩码手部和机器人,并叠加一条红线以指示末端执行器方向(图 3)。SAM 点提示由转换到图像帧的机器人末端执行器和人手姿态生成。

C. 训练人机联合策略

现有方法通常采用分层架构,其中在人类数据上训练的高层策略为输出机器人动作的低层策略提供条件 [5], [6]。然而,这种方法本质上受限于低层策略的性能,而低层策略并未直接受益




图 5: 我们在三个真实世界的长时程操作任务上评估了 EgoMimic。任务描述见第 IV-A 节。

Algorithm 1 Joint Human-Robot Policy Learning

Require: Human dataset $\mathcal{D}_H$, Robot dataset $\mathcal{D}_R$

```

1: Initialize shared transformer encoder  $f_{enc}(\cdot)$ , pose de-
   coder  $f^p(f_{enc}(\cdot))$ , and joint decoder  $f^q(f_{enc}(\cdot))$ 
2: for iteration  $n = 1, 2, \dots$  do
3:   // Human data
4:   Sample  $(I_t, p_t, a_{t:t+h}^p)$  from  $\mathcal{D}_H$ 
5:   Predict  $\hat{a}_{t:t+h}^p$  from  $f_p(f_{enc}(I_t, p_t))$ 
6:    $\mathcal{L}_p^H = \text{MSE}(\hat{a}_{t:t+h}^p, a_{t:t+h}^p)$ 
7:   // Robot data
8:   Sample  $(I_t, p_t, q_t, a_{t:t+h}^p, a_{t:t+h}^q)$  from  $\mathcal{D}_R$ 
9:   Predict  $\hat{a}_{t:t+h}^q$  from  $f_q(f_{enc}(I_t, p_t, q_t))$ 
10:  Predict  $\hat{a}_{t:t+h}^p$  from  $f_p(f_{enc}(I_t, p_t, q_t))$ 
11:   $\mathcal{L}_p^R = \text{MSE}(\hat{a}_{t:t+h}^p, a_{t:t+h}^p)$ 
12:   $\mathcal{L}_q^R = \text{MSE}(\hat{a}_{t:t+h}^q, a_{t:t+h}^q)$ 
13:  // Joint policy update
14:  Update  $f_{enc}, f^p, f^q$  with  $\mathcal{L}_p^H + \mathcal{L}_p^R + \mathcal{L}_q^R$ 
15: end for

```

从大规模人类数据中学习。为解决这一局限性，本文提出一种简单架构（如图 4 所示），该架构从统一数据中学习并促进共享表示。本文模型基于 ACT[1] 构建，但设计具有通用性，可应用于其他基于变换器的模仿学习算法。该统一方法中的一个关键挑战是机器人动作空间的选择。虽然机器人末端执行器位姿在语义上比机器人关节位置更接近人手位姿，但由于 6 自由度 ViperX 机械臂提供的解冗余度较低，通过基于笛卡尔坐标的控制器（例如微分逆运动学）控制机器人末端执行器位姿较为困难。经验表明，机器人在轨迹中常遇到奇异性或非平滑解。因此，本文选择关节空间控制（即使用预测的关节动作 $\hat{a}_{t:t+h}^q$ 来控制机器人），同时利用位姿空间预测来学习人机联合表示。需要注意的是，同时需要位姿和关节空间预测是由本文机器人硬件特性决定的，对于更支持末端执行器空间控制的高性能机器人，可以消除对关节空间动作预测的需求。具体而言，策略中除两个浅层输入和输出头外，所有参数均共享。输入头

表 II: 人类 (H) 和机器人 (R) 数据收集概览。报告了总任务演示的数量 (#) 和收集所需时间 (分钟)。

Task	H #	H min	H #/min	R #	R min	R #/min
Object-in-Bowl	1400	60	23	270	120	2
Groceries	160	80	2	300	300	1
Laundry	590	100	6	430	300	1

在传入策略变换器之前，对视觉和本体感觉嵌入进行变换。策略变换器处理这些特征，两个输出头将变换器的潜在输出转换为位姿或关节空间预测。位姿损失通过 $^H a^p$ 和 $^R a^p$ 同时监督人类和机器人数据，而关节动作损失仅监督机器人数据 $^R a^q$ 。由于两个分支仅由一个线性层分隔，本文有效地迫使模型为两个域学习联合表示。算法总结见算法 1。表 I 总结了训练所用数据。

IV. 实验

本文旨在验证三个关键假设。假设一：EgoMimic 能够利用人类具身数据提升复杂操作任务的域内性能。假设二：人类数据有助于 EgoMimic 泛化到新物体和新场景。假设三：在已有足够初始机器人数据的情况下，收集额外的人类数据比收集额外的机器人数据更有价值。

A. 实验设置

任务。我们选取一组长时程真实世界任务来评估上述主张。这些任务要求精确对齐、复杂运动以及双臂协调（图 5）。连续物体入碗：机器人拾取一个小毛绒玩具（约 6 厘米长），将其放入碗中，再拿起碗将物体倒到桌面上，如此连续重复 40 秒。我们从 3 个碗和 5 个玩具中随机选择，它们随机摆放在桌面 45 厘米 $\times$ 60 厘米的范围内。该任务对精确操作、空间泛化以及长时程执行中的鲁棒性进行了压力测试。每当玩具被放入碗中或碗被清空时，我们给予分数。我们在 9 种碗-玩具-位置组合上共进行 45 次评估运行。

表三：三项真实世界任务的定量结果。我们报告所有任务的任务成功率（%）和性能得分（分），以及杂货任务的抓袋率。

Method	Bowl		Laundry		Groceries		
	Pts		Pts	SR	Pts	SR	Open Bag
ACT [1]	39		82	55%	82	22%	54%
Mimicplay [5]	71		78	50%	53	8%	40%
EgoMimic (w/o human)	68		104	73%	92	28%	60%
EgoMimic	128		114	88%	110	30%	70%

洗衣：一项双臂任务，要求机器人折叠一件随机摆放在 90 厘米 × 60 厘米范围内、旋转范围为 ± 30 度的 T 恤。机器人必须使用双臂依次折叠右侧袖子、左侧袖子，然后将整件衬衫对折。我们为每个阶段给予分数，并根据所有阶段均成功的运行次数百分比计算成功率。我们在 8 种衬衫位置组合上共进行 40 次评估运行。杂货：机器人将 3 包薯片装入购物袋。它用左臂抓住袋柄顶部以撑开袋口，然后用右臂拾取薯片包并将其放入袋中。该任务要求高精度操作（拾取可变形袋柄）以及长时程执行中的鲁棒性。我们为抓住袋柄和每包放入购物袋的薯片给予分数。我们将成功率报告为三包薯片均成功放入袋中的运行次数百分比，以及

开袋 以抓取袋柄的运行次数百分比衡量，这是该任务中较困难的阶段。我们在 10 个袋位上进行 50 次评估。我们详细说明了每个任务收集的数据量，见

表 II。特别是在收集机器人数据时，我们确保随机扰动机器人的位置，经验表明这能提高鲁棒性。对于人类数据，我们注意到像连续物体入碗这样的任务特别容易扩展，而像杂货这样的任务由于重置时间较长而进展较慢。

基线。为了评估 EgoMimic 能否通过利用人类数据提高域内成功率，我们以 ACT [1] 为基准，这是一种最新的模仿学习算法。此外，我们与 Mimicplay [5] 进行比较，这是一种近期最先进的方法，它从人类数据中学习规划器来指导低级策略，以表明我们的统一架构能更有效地从人类和机器人数据中学习。为了公平比较，我们使用与我们的方法相同的 Transformer 骨干实现 Mimicplay，并移除了目标条件，因为 EgoMimic 是为单任务策略设计的。由于 EgoMimic 包含对 ACT 的架构更改，即同时预测关节和姿态动作，我们还以 EgoMimic（0% 人类数据）为基准。这有助于我们得出结论：性能提升来自利用人类数据，而非架构本身。

B. 结果

EgoMimic 提高了域内任务性能。在所有任务中，我们观察到得分相对提升 34-228%，绝对任务成功率从

表 IV：消融实验 - 我们对方法进行消融，并报告物体入碗任务的最终任务性能。

Method	Cotrained (Points)
EgoMimic	128
EgoMimic w/o Line	112
EgoMimic w/o Line and Mask	95
EgoMimic w/o Action Norm	79
EgoMimic w/o Hand Data	68




图 6：我们重点展示了 EgoMimic 的成功案例以及失败模式，例如 (e) 未能正确对准玩具，(f) 未能抓住包的手柄，或 (g) 策略仅抓住衬衫的一侧。EgoMimic 降低了这些失败模式的发生频率，将成功率较基线提升了 8-33%。

较 ACT 提升 8-33%。我们最大的改进体现在连续物体入碗任务上，任务得分较 ACT 提升了 228%。我们观察到基线方法常常偏离玩具或碗几英寸，这表明利用手部数据有助于策略精确到达玩具。定性结果如图 6 所示。为确保这一提升源于利用手部数据而非架构变化，我们与 EgoMimic（0% 人类数据）进行了对比。我们观察到得分提升 10-88%，成功率提升 2-15%。EgoMimic 能够泛化到新物体和

甚至新场景。我们在两种域偏移上评估了我们的方法：尝试折叠未见颜色的衬衫，以及在完全不同的场景中执行连续物体入碗任务。如图 7 所示，我们观察到 ACT 在未见颜色的衬衫上表现不佳（成功率 25%），而 EgoMimic 完全保持了其性能（成功率 85%）。令人惊讶的是，通过在新场景（未见背景和光照）中学习人类数据，EgoMimic 能够在没有任何额外机器人数据的情况下泛化到这个新环境，得分为 63 分。相比之下，Mimicplay 虽然获得了相同的信息，但采用了分层框架来利用手部数据，仅得 4 分。这表明我们的架构促进了手-机器人联合表示，而分层架构则构成了泛化瓶颈。

人类数据与机器人数据的扩展性。为了研究人类和机器人数据源对性能的扩展效应，我们为连续物体入碗任务进行了额外的数据收集。如图 7 所示，使用 2 小时机器人数据和 1 小时人类数据训练的 EgoMimic 显著优于使用 3 小时机器人数据训练的 ACT（128 分对 74 分）。




图 7：策略泛化评估结果。(a) 我们在洗衣任务中使用未见布料颜色评估策略，并报告每种方法的成功率。(b) 我们在未见场景中测试物体入碗任务上的策略。




图 8：机器人数据与人类数据的扩展性。使用 2 小时机器人数据+1 小时手部数据训练的 EgoMimic（蓝色）显著优于使用 3 小时机器人数据训练的 ACT[1]（橙色）。

分)。值得注意的是，一小时人类数据可产生 1400 个演示，而一小时机器人数据仅产生 135 个演示。这些结果表明，EgoMimic 能够有效利用人类具身数据收集的效率优势，从而产生更显著的扩展效应，大幅提升任务性能，超越仅使用机器人数据所能达到的水平。我们注意到，在 2 小时机器人数据条件下，EgoMimic 的表现优于 ACT，因此部分改进可归因于架构设计。

消融研究。我们对方法进行消融实验，以证明每个设计决策在碗中物体任务中的重要性（表 IV）。首先，移除动作归一化导致任务得分下降 38%。这凸显了动作分布对齐对于协同训练的重要性。接下来，我们消融视觉技术，具体包括遮挡手部和机器人，以及在图像上绘制红色叠层。移除这些组件分别导致 13% 和 26% 的性能下降。最后，在没有任何手部数据的情况下训练 EgoMimic，性能大幅下降 47%，这凸显了手-机器人协同训练在我们框架中的有效性。

五、结论

我们提出了 EgoMimic，一个利用人类第一视角视频和遥操作机器人数据协同训练操作策略的框架。通过利用 Project Aria 眼镜、低成本双臂机器人设置、跨域对齐技术以及统一的策略学习架构，EgoMimic 在三个具有挑战性的真实世界任务上超越了最先进的基线方法，并展现出对新场景的泛化能力以及良好的扩展特性。对于未来工作，我们计划探索泛化到新机器人形态以及仅在人类数据中展示的全新行为的可能性，例如折叠裤子而非衬衫。总体而言，我们相信我们的工作为通过被动数据收集扩展机器人数据开辟了令人兴奋的新研究方向。

参考文献

- [1] T. Z. Zhao, V. Kumar, S. Levine, and C. Finn, “Learning fine-grained bimanual manipulation with low-cost hardware,” 2023. [Online]. Available: <https://arxiv.org/abs/2304.13705>
- [2] A. Team, J. Aldaco, T. Armstrong, R. Baruch, J. Bingham, S. Chan, K. Draper, D. Dwibedi, C. Finn, P. Florence, S. Goodrich, W. Gramlich, T. Hage, A. Herzog, J. Hoeft, T. Nguyen, I. Storz, B. Tabanpour, L. Takayama, J. Tompson, A. Wahid, T. Wahrburg, S. Xu, S. Yaroshenko, K. Zakka, and T. Z. Zhao, “Aloha 2: An enhanced low-cost hardware for bimanual teleoperation,” 2024. [Online]. Available: <https://arxiv.org/abs/2405.02292>
- [3] P. Wu, Y. Shentu, Z. Yi, X. Lin, and P. Abbeel, “Gello: A general, low-cost, and intuitive teleoperation framework for robot manipulators,” 2024. [Online]. Available: <https://arxiv.org/abs/2309.13037>
- [4] C. Chi, Z. Xu, C. Pan, E. Cousineau, B. Burchfiel, S. Feng, R. Tedrake, and S. Song, “Universal manipulation interface: In-the-wild robot teaching without in-the-wild robots,” 2024. [Online]. Available: <https://arxiv.org/abs/2402.10329>
- [5] C. Wang, L. Fan, J. Sun, R. Zhang, L. Fei-Fei, D. Xu, Y. Zhu, and A. Anandkumar, “Mimicplay: Long-horizon imitation learning by watching human play,” 2023. [Online]. Available: <https://arxiv.org/abs/2302.12422>
- [6] H. Bharadhwaj, A. Gupta, V. Kumar, and S. Tulsiani, “Towards generalizable zero-shot manipulation via translating human interaction plans,” 2023. [Online]. Available: <https://arxiv.org/abs/2312.00775>
- [7] J. Engel, K. Somasundaram, M. Goesele, A. Sun, A. Gaminio, A. Turner, A. Talattof, A. Yuan, B. Souti, B. Meredith, C. Peng, C. Sweeney, C. Wilson, D. Barnes, D. DeTone, D. Caruso, D. Valleroy, D. Gijunpalli, D. Frost, E. Miller, E. Mueggler, E. Oleinik, F. Zhang, G. Somasundaram, G. Solaira, H. Lanaras, H. Howard-Jenkins, H. Tang, H. J. Kim, J. Rivera, J. Luo, J. Dong, J. Straub, K. Bailey, K. Eckenhoff, L. Ma, L. Pesqueira, M. Schwesinger, M. Monge, N. Yang, N. Charron, N. Raina, O. Parkhi, P. Borschowa, P. Moulon, P. Gupta, R. Mur-Artal, R. Pennington, S. Kulkarni, S. Miglani, S. Gondi, S. Solanki, S. Diener, S. Cheng, S. Green, S. Saarinen, S. Patra, T. Mourikis, T. Whelan, T. Singh, V. Balntas, V. Baiyya, W. Dreewes, X. Pan, Y. Lou, Y. Zhao, Y. Mansour, Y. Zou, Z. Lv, Z. Wang, M. Yan, C. Ren, R. D. Nardi, and R. Newcombe, “Project aria: A new tool for egocentric multi-modal ai research,” 2023. [Online]. Available: <https://arxiv.org/abs/2308.13561>
- [8] A. Paraschos, C. Daniel, J. R. Peters, and G. Neumann, “Probabilistic movement primitives,” in *Advances in Neural Information Processing Systems*, C. Burges, L. Bottou, M. Welling, Z. Ghahramani, and K. Weinberger, Eds., vol. 26. Curran Associates, Inc., 2013.
- [9] C. Finn, T. Yu, T. Zhang, P. Abbeel, and S. Levine, “One-shot visual imitation learning via meta-learning,” 2017. [Online]. Available: <https://arxiv.org/abs/1709.04905>
- [10] A. Mandlekar, D. Xu, J. Wong, S. Nasiriany, C. Wang, R. Kulkarni, L. Fei-Fei, S. Savarese, Y. Zhu, and R. Martín-Martín, “What matters in learning from offline human demonstrations for robot manipulation,” in *arXiv preprint arXiv:2108.03298*, 2021.
- [11] C. Chi, Z. Xu, S. Feng, E. Cousineau, Y. Du, B. Burchfiel, R. Tedrake, and S. Song, “Diffusion policy: Visuomotor policy learning via action diffusion,” 2024. [Online]. Available: <https://arxiv.org/abs/2303.04137>

- [12] S. Young, D. Gandhi, S. Tulsiani, A. Gupta, P. Abbeel, and L. Pinto, "Visual imitation made easy," 2020. [Online]. Available: <https://arxiv.org/abs/2008.04899>
- [13] A. Brohan, N. Brown, J. Carbajal, Y. Chebotar, J. Dabis, C. Finn, K. Gopalakrishnan, K. Hausman, A. Herzog, J. Hsu, J. Ibarz, B. Ichter, A. Irpan, T. Jackson, S. Jesmonth, N. J. Joshi, R. Julian, D. Kalashnikov, Y. Kuang, I. Leal, K.-H. Lee, S. Levine, Y. Lu, U. Malla, D. Manjunath, I. Mordatch, O. Nachum, C. Parada, J. Peralta, E. Perez, K. Pertsch, J. Quiambao, K. Rao, M. Ryoo, G. Salazar, P. Sanketi, K. Sayed, J. Singh, S. Sontakke, A. Stone, C. Tan, H. Tran, V. Vanhoucke, S. Vega, Q. Vuong, F. Xia, T. Xiao, P. Xu, S. Xu, T. Yu, and B. Zitkovich, "Rt-1: Robotics transformer for real-world control at scale," 2023. [Online]. Available: <https://arxiv.org/abs/2212.06817>
- [14] A. Brohan, N. Brown, J. Carbajal, Y. Chebotar, X. Chen, K. Choromanski, T. Ding, D. Driess, A. Dubey, C. Finn, P. Florence, C. Fu, M. G. Arenas, K. Gopalakrishnan, K. Han, K. Hausman, A. Herzog, J. Hsu, B. Ichter, A. Irpan, N. Joshi, R. Julian, D. Kalashnikov, Y. Kuang, I. Leal, L. Lee, T.-W. E. Lee, S. Levine, Y. Lu, H. Michalewski, I. Mordatch, K. Pertsch, K. Rao, K. Reymann, M. Ryoo, G. Salazar, P. Sanketi, P. Sermanet, J. Singh, A. Singh, R. Soricut, H. Tran, V. Vanhoucke, Q. Vuong, A. Wahid, S. Welker, P. Wohlhart, J. Wu, F. Xia, T. Xiao, P. Xu, S. Xu, T. Yu, and B. Zitkovich, "Rt-2: Vision-language-action models transfer web knowledge to robotic control," 2023. [Online]. Available: <https://arxiv.org/abs/2307.15818>
- [15] S. Nair, A. Rajeswaran, V. Kumar, C. Finn, and A. Gupta, "R3m: A universal visual representation for robot manipulation," 2022. [Online]. Available: <https://arxiv.org/abs/2203.12601>
- [16] I. Radosavovic, T. Xiao, S. James, P. Abbeel, J. Malik, and T. Darrell, "Real-world robot learning with masked visual pre-training," in *Conference on Robot Learning*. PMLR, 2023, pp. 416–426.
- [17] Y. J. Ma, S. Sodhani, D. Jayaraman, O. Bastani, V. Kumar, and A. Zhang, "Vip: Towards universal visual reward and representation via value-implicit pre-training," *arXiv preprint arXiv:2210.00030*, 2022.
- [18] H. Xiong, Q. Li, Y.-C. Chen, H. Bharadhwaj, S. Sinha, and A. Garg, "Learning by watching: Physical imitation of manipulation skills from human videos," 2021. [Online]. Available: <https://arxiv.org/abs/2101.07241>
- [19] C. Wen, X. Lin, J. So, K. Chen, Q. Dou, Y. Gao, and P. Abbeel, "Any-point trajectory modeling for policy learning," 2024. [Online]. Available: <https://arxiv.org/abs/2401.00025>
- [20] H. Bharadhwaj, R. Mottaghi, A. Gupta, and S. Tulsiani, "Track2act: Predicting point tracks from internet videos enables generalizable robot manipulation," 2024. [Online]. Available: <https://arxiv.org/abs/2405.01527>
- [21] S. Bahl, R. Mendonca, L. Chen, U. Jain, and D. Pathak, "Affordances from human videos as a versatile representation for robotics," 2023. [Online]. Available: <https://arxiv.org/abs/2304.08488>
- [22] A. Mandlekar, D. Xu, R. Martín-Martín, S. Savarese, and L. Fei-Fei, "Learning to generalize across long-horizon tasks from human demonstrations," *arXiv preprint arXiv:2003.06085*, 2020.
- [23] V. Dhat, N. Walker, and M. Cakmak, "Using 3d mice to control robot manipulators," *Proceedings of the 2024 ACM/IEEE International Conference on Human-Robot Interaction*, 2024. [Online]. Available: <https://api.semanticscholar.org/CorpusID:267322988>
- [24] Y. Zhu, A. Joshi, P. Stone, and Y. Zhu, "Viola: Imitation learning for vision-based manipulation with object proposal priors," 2023. [Online]. Available: <https://arxiv.org/abs/2210.11339>
- [25] S. P. Arunachalam, I. Güzey, S. Chintala, and L. Pinto, "Holo-dex: Teaching dexterity with immersive mixed reality," in *2023 IEEE International Conference on Robotics and Automation (ICRA)*. IEEE, 2023, pp. 5962–5969.
- [26] A. George, A. Bartsch, and A. B. Farimani, "Openvr: Teleoperation for manipulation," 2023. [Online]. Available: <https://arxiv.org/abs/2305.09765>
- [27] I. A. Tsokalio, D. Kuss, I. Kharabet, F. H. P. Fitzek, and M. Reisslein, "Remote robot control with human-in-the-loop over long distances using digital twins," in *2019 IEEE Global Communications Conference (GLOBECOM)*, 2019, pp. 1–6.
- [28] X. Cheng, J. Li, S. Yang, G. Yang, and X. Wang, "Open-television: teleoperation with immersive active visual feedback," *arXiv preprint arXiv:2407.01512*, 2024.
- [29] T. He, Z. Luo, X. He, W. Xiao, C. Zhang, W. Zhang, K. Kitani, C. Liu, and G. Shi, "Omnih2o: Universal and dexterous human-to-humanoid whole-body teleoperation and learning," *arXiv preprint arXiv:2406.08858*, 2024.
- [30] H. Fang, H.-S. Fang, Y. Wang, J. Ren, J. Chen, R. Zhang, W. Wang, and C. Lu, "Airexo: Low-cost exoskeletons for learning whole-arm manipulation in the wild," *arXiv preprint arXiv:2309.14975*, 2023.
- [31] S. Yang, M. Liu, Y. Qin, R. Ding, J. Li, X. Cheng, R. Yang, S. Yi, and X. Wang, "Ace: A cross-platform visual-exoskeletons system for low-cost dexterous teleoperation," *arXiv preprint arXiv:2408.11805*, 2024.
- [32] A. Sivakumar, K. Shaw, and D. Pathak, "Robotic telekinesis: Learning a robotic hand imitator by watching humans on youtube," *arXiv preprint arXiv:2202.10448*, 2022.
- [33] V. Jain, M. Attarian, N. J. Joshi, A. Wahid, D. Driess, Q. Vuong, P. R. Sanketi, P. Sermanet, S. Welker, C. Chan, *et al.*, "Vid2robot: End-to-end video-conditioned policy learning with cross-attention transformers," *arXiv preprint arXiv:2403.12943*, 2024.
- [34] Z. Fu, Q. Zhao, Q. Wu, G. Wetzstein, and C. Finn, "Humanplus: Humanoid shadowing and imitation from humans," in *Conference on Robot Learning (CoRL)*, 2024.
- [35] N. M. M. Shafullah, A. Rai, H. Etukuru, Y. Liu, I. Misra, S. Chintala, and L. Pinto, "On bringing robots home," *arXiv preprint arXiv:2311.16098*, 2023.
- [36] C. Wang, H. Shi, W. Wang, R. Zhang, L. Fei-Fei, and C. K. Liu, "Dexcap: Scalable and portable mocap data collection system for dexterous manipulation," 2024. [Online]. Available: <https://arxiv.org/abs/2403.07788>
- [37] G. Papagiannis, N. Di Palo, P. Vitiello, and E. Johns, "R+ x: Retrieval and execution from everyday human videos," *arXiv preprint arXiv:2407.12957*, 2024.
- [38] K. Grauman, A. Westbury, L. Torresani, K. Kitani, J. Malik, T. Afouras, K. Ashutosh, V. Baiyya, S. Bansal, B. Boote, *et al.*, "Ego-exo4d: Understanding skilled human activity from first-and third-person perspectives," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024, pp. 19 383–19 400.
- [39] E. Collaboration, A. O'Neill, A. Rehman, A. Gupta, A. Maddukuri, A. Gupta, A. Padalkar, A. Lee, A. Pooley, A. Gupta, A. Mandlekar, A. Jain, A. Tung, A. Bewley, A. Herzog, A. Irpan, A. Khazatsky, A. Rai, A. Gupta, A. Wang, A. Kolobov, A. Singh, A. Garg, A. Kembhavi, A. Xie, A. Brohan, A. Raffin, A. Sharma, A. Yavary, A. Jain, A. Balakrishna, A. Wahid, B. Burgess-Limerick, B. Kim, B. Schölkopf, B. Wulfe, B. Ichter, C. Lu, C. Xu, C. Le, C. Finn, C. Wang, C. Xu, C. Chi, C. Huang, C. Chan, C. Agia, C. Pan, C. Fu, C. Devin, D. Xu, D. Morton, D. Driess, D. Chen, D. Pathak, D. Shah, D. Büchler, D. Jayaraman, D. Kalashnikov, D. Sadigh, E. Johns, E. Foster, F. Liu, F. Ceola, F. Xia, F. Zhao, F. V. Frujeri, F. Stulp, G. Zhou, G. S. Sukhatme, G. Salhotra, G. Yan, G. Feng, G. Schiavi, G. Berseth, G. Kahn, G. Yang, G. Wang, H. Su, H.-S. Fang, H. Shi, H. Bao, H. B. Amor, H. I. Christensen, H. Furuta, H. Bharadhwaj, H. Walke, H. Fang, H. Ha, I. Mordatch, I. Radosavovic, I. Leal, J. Liang, J. Abou-Chakra, J. Kim, J. Drake, J. Peters, J. Schneider, J. Hsu, J. Vakil, J. Bohg, J. Bingham, J. Wu, J. Gao, J. Hu, J. Wu, J. Wu, J. Sun, J. Luo, J. Gu, J. Tan, J. Oh, J. Wu, J. Lu, J. Yang, J. Malik, J. Silvério, J. Hejna, J. Booher, J. Tompson, J. Yang, J. Salvador, J. J. Lim, J. Han, K. Wang, K. Rao, K. Pertsch, K. Hausman, K. Go, K. Gopalakrishnan, K. Goldberg, K. Byrne, K. Oslund, K. Kawaharazuka, K. Black, K. Lin, K. Zhang, K. Ehsani, K. Lekkala, K. Ellis, K. Rana, K. Srinivasan, K. Fang, K. P. Singh, K.-H. Zeng, K. Hatch, K. Hsu, L. Itti, L. Y. Chen, L. Pinto, L. Fei-Fei, L. Tan, L. J. Fan, L. Ott, L. Lee, L. Weihs, M. Chen, M. Lepert, M. Memmel, M. Tomizuka, M. Itkina, M. G. Castro, M. Spero, M. Du, M. Ahn, M. C. Yip, M. Zhang, M. Ding, M. Heo, M. K. Srirama, M. Sharma, M. J. Kim, N. Kanazawa, N. Hansen, N. Heess, N. J. Joshi, N. Suenderhauf, N. Liu, N. D. Palo, N. M. M. Shafullah, O. Mees, O. Kroemer, O. Bastani, P. R. Sanketi, P. T. Miller, P. Yin, P. Wohlhart, P. Xu, P. D. Fagan, P. Mitrano, P. Sermanet, P. Abbeel, P. Sundaresan, Q. Chen, Q. Vuong, R. Rafailov, R. Tian, R. Doshi, R. Mart'in-Mart'in, R. Bajjal, R. Scalise, R. Hendrix, R. Lin, R. Qian, R. Zhang, R. Mendonca, R. Shah, R. Hoque, R. Julian, S. Bustamante, S. Kirmani, S. Levine, S. Lin, S. Moore, S. Bahl, S. Dass, S. Sonawani, S. Tulsiani, S. Song, S. Xu, S. Haldar, S. Karamcheti, S. Adebola, S. Guist, S. Nasiriany, S. Schaal, S. Welker, S. Tian, S. Ramamoorthy, S. Dasari, S. Belkale, S. Park, S. Nair, S. Mirchandani, T. Osa, T. Gupta, T. Harada, T. Matsushima,

- T. Xiao, T. Kollar, T. Yu, T. Ding, T. Davchev, T. Z. Zhao, T. Armstrong, T. Darrell, T. Chung, V. Jain, V. Kumar, V. Vanhoucke, W. Zhan, W. Zhou, W. Burgard, X. Chen, X. Chen, X. Wang, X. Zhu, X. Geng, X. Liu, X. Liangwei, X. Li, Y. Pang, Y. Lu, Y. J. Ma, Y. Kim, Y. Chebotar, Y. Zhou, Y. Zhu, Y. Wu, Y. Xu, Y. Wang, Y. Bisk, Y. Dou, Y. Cho, Y. Lee, Y. Cui, Y. Cao, Y.-H. Wu, Y. Tang, Y. Zhu, Y. Zhang, Y. Jiang, Y. Li, Y. Li, Y. Iwasawa, Y. Matsuo, Z. Ma, Z. Xu, Z. J. Cui, Z. Zhang, Z. Fu, and Z. Lin, “Open x-embodiment: Robotic learning datasets and rt-x models,” 2024. [Online]. Available: <https://arxiv.org/abs/2310.08864>
- [40] L. Y. Chen, K. Hari, K. Dharmarajan, C. Xu, Q. Vuong, and K. Goldberg, “Mirage: Cross-embodiment zero-shot policy transfer with cross-painting,” 2024. [Online]. Available: <https://arxiv.org/abs/2402.19249>
- [41] W. Huang, I. Mordatch, and D. Pathak, “One policy to control them all: Shared modular policies for agent-agnostic control,” 2020. [Online]. Available: <https://arxiv.org/abs/2007.04976>
- [42] J. Yang, C. Glossop, A. Bhorkar, D. Shah, Q. Vuong, C. Finn, D. Sadigh, and S. Levine, “Pushing the limits of cross-embodiment learning for manipulation and navigation,” 2024. [Online]. Available: <https://arxiv.org/abs/2402.19432>
- [43] J. Yang, D. Sadigh, and C. Finn, “Polybot: Training one policy across robots while embracing variability,” 2023. [Online]. Available: <https://arxiv.org/abs/2307.03719>
- [44] K. Grauman, A. Westbury, E. Byrne, Z. Chavis, A. Furnari, R. Girdhar, J. Hamburger, H. Jiang, M. Liu, X. Liu, M. Martin, T. Nagarajan, I. Radosavovic, S. K. Ramakrishnan, F. Ryan, J. Sharma, M. Wray, M. Xu, E. Z. Xu, C. Zhao, S. Bansal, D. Batra, V. Cartillier, S. Crane, T. Do, M. Doulaty, A. Erapalli, C. Feichtenhofer, A. Fragomeni, Q. Fu, A. Gebreselasie, C. Gonzalez, J. Hillis, X. Huang, Y. Huang, W. Jia, W. Khoo, J. Kolar, S. Kottur, A. Kumar, F. Landini, C. Li, Y. Li, Z. Li, K. Mangalam, R. Modhugu, J. Munro, T. Murrell, T. Nishiyasu, W. Price, P. R. Puentes, M. Ramazanov, L. Sari, K. Somasundaram, A. Southerland, Y. Sugano, R. Tao, M. Vo, Y. Wang, X. Wu, T. Yagi, Z. Zhao, Y. Zhu, P. Arbelaez, D. Crandall, D. Damen, G. M. Farinella, C. Fuegen, B. Ghanem, V. K. Ithapu, C. V. Jawahar, H. Joo, K. Kitani, H. Li, R. Newcombe, A. Oliva, H. S. Park, J. M. Rehg, Y. Sato, J. Shi, M. Z. Shou, A. Torralba, L. Torresani, M. Yan, and J. Malik, “Ego4d: Around the world in 3,000 hours of egocentric video,” 2022. [Online]. Available: <https://arxiv.org/abs/2110.07058>
- [45] L. Ma, Y. Ye, F. Hong, V. Guzov, Y. Jiang, R. Postyeni, L. Pesqueira, A. Gamino, V. Baiyya, H. J. Kim, K. Bailey, D. S. Fosas, C. K. Liu, Z. Liu, J. Engel, R. D. Nardi, and R. Newcombe, “Nymeria: A massive collection of multimodal egocentric daily motion in the wild,” 2024. [Online]. Available: <https://arxiv.org/abs/2406.09905>
- [46] S. Haddadin, S. Parusel, L. Johannsmeier, S. Golz, S. Gabl, F. Walch, M. Sabaghian, C. Jähne, L. Hausperger, and S. Haddadin, “The franka emika robot: A reference platform for robotics research and education,” *IEEE Robotics and Automation Magazine*, vol. 29, no. 2, pp. 46–64, 2022.
- [47] Meta Research, “Basics — project aria docs,” https://facebookresearch.github.io/projectaria_tools/docs/data_formats/mps/mps_summary, 2024, accessed: September 15, 2024.
- [48] J. Yang, C. Glossop, A. Bhorkar, D. Shah, Q. Vuong, C. Finn, D. Sadigh, and S. Levine, “Pushing the limits of cross-embodiment learning for manipulation and navigation,” *arXiv preprint arXiv:2402.19432*, 2024.
- [49] J. Hejna, C. Bhateja, Y. Jian, K. Pertsch, and D. Sadigh, “Re-mix: Optimizing data mixtures for large scale imitation learning,” *arXiv preprint arXiv:2408.14037*, 2024.
- [50] Y. Zhou, Y. Aytar, and K. Bousmalis, “Manipulator-independent representations for visual imitation,” 2021. [Online]. Available: <https://arxiv.org/abs/2103.09016>
- [51] S. Bahl, A. Gupta, and D. Pathak, “Human-to-robot imitation in the wild,” 2022. [Online]. Available: <https://arxiv.org/abs/2207.09450>
- [52] N. Ravi, V. Gabeur, Y.-T. Hu, R. Hu, C. Ryali, T. Ma, H. Khedr, R. Rädle, C. Rolland, L. Gustafson, E. Mintun, J. Pan, K. V. Alwala, N. Carion, C.-Y. Wu, R. Girshick, P. Dollár, and C. Feichtenhofer, “Sam 2: Segment anything in images and videos,” 2024. [Online]. Available: <https://arxiv.org/abs/2408.00714>
- [53] L. Wang, X. Chen, J. Zhao, and K. He, “Scaling proprioceptive-visual learning with heterogeneous pre-trained transformers,” in *NeurIPS*, 2024.

Hand vs Robot Alignment (Continuous Object in Bowl)




图 9: 这里我们并排可视化数据集中手部和机器人数据, 并叠加了真实动作 (紫色)。注意, 尽管手部移动速度远快于机器人, 但动作长度相似。

VI. APPENDIX

A. Data Processing and Domain Alignment

Humans and teleoperated robots complete tasks at different speeds. To enable joint training of human and robot data, we must align these two sources of data temporally. Following Mimicplay [5], we “slow down” the human data, and we found empirically that a factor of 4 sufficiently aligned both domains. Specifically, for robot data we construct joint and pose based actions over a four second horizon but for human data we use a 1 second horizon. For both domains, our action chunk size is 100, meaning we construct 100 future actions spaced evenly over the horizon. This alignment is independent of data recording frequencies, where human data is recorded at 30hz and robot data is recorded at 50 hz.

To co-train on both human and robot data, we individually normalize the proprioception and actions for both embodiments (as shown in Fig. 3). Given proprioception $p_t \in \mathbb{R}^d$ where d depends on embodiment, we normalize by subtracting the dataset mean and dividing by standard deviation

$$\text{norm}(p_t) = (p_t - \mu_p) / \sigma_p.$$

We perform the identical calculation to normalize actions $a_{t:t+h} \in \mathbb{R}^{d \times 100}$.

To bridge the appearance gap between human hand and robot arm, we visually mask each embodiment via SAM2 [52], and overlay a red line on these masks to enhance alignment (Fig. 3). For the robot, we first use forward kinematics to compute the 3D coordinates of key joints in robot frame

$$p_t^R = FK(q_t) \in \mathbb{R}^{3 \times 3},$$

including the wrist, gripper and the forearm. These 3D coordinates are then projected onto the image frame via camera intrinsics (I_{cam}^{pixels}) and extrinsics (T_R^{cam}) to obtain 2D keypoints in pixel space

$$p_t^{pixel} = I_{cam}^{pixels} T_R^{cam} p_t^R \in \mathbb{R}^{3 \times 2},$$

which are used to prompt SAM2 [52] to generate a mask of the robot arm. After obtaining the mask, we draw a red line on the masked area from the gripper to the elbow in the RGB image. For the human data, a similar process is followed, where SAM2 is prompted using the 3D coordinates of the human hand to generate a mask. A red line is then drawn along the hand’s contour, from the bottom right to top left corner of the contour’s bounding box.

During training, both the robot arm and human hand are masked to align their visual representations. During evaluation, SAM2 is run in real time on a desktop to mask the robot arm and apply the same red line overlay. This approach enables better visual alignment between the robot and human hand, facilitating more effective model generalization across human and robotic tasks.

B. Aria Machine Perception Services (MPS)

We leveraged MPS to process human data from the Aria glasses. The raw data from Aria contains timestamped sensor information from the glasses, namely RGB camera, SLAM cameras, IMU, eye tracking cameras, microphone, and more. The raw data is uploaded to the MPS server, where the cloud-hosted service estimates device pose via SLAM, a semi-dense pointcloud of the environment, hand tracking relative to the device frame, and even eye gaze. The MPS returns SLAM as a timestamped CSV of device poses in world frame and hand tracking as a timestamped CSV of cartesian positions in the time-aligned device frame. These hand positions are each in a distinct reference frame due to head movements, so we project future actions to the current device coordinate frame (described in Sec. III-B). We use the undistorted Aria RGB camera data paired with the hand tracking and SLAM information to construct an hdf5 file compatible for training in robomimic [10].

C. Training Human-Robot Joint Policies

We depict our algorithm in detail in Fig. 10. At each step we sample a batch of hand data as well as a batch of




图 10: EgoMimic 的详细架构。

robot data, and pass each through our unified architecture. EgoMimic performs Z-score normalization to hand and robot proprioception and actions individually. The normalized proprioception is passed through a linear layer to produce a proprioception token. Alongside the proprioception, the top down views from hand and robot are passed through a SAM based masking module. These images, along with the robot wrist views are passed through a shared Resnet18 visual encoder which produces visual tokens. Finally, we add an additional style token z from our CVAE encoder which is not depicted, but directly follows ACT [1]. All these tokens, are passed through a transformer encoder decoder architecture. The transformer decoder’s hidden output is passed through a linear decoder depending on the output type, producing pose actions $\hat{a}^p$ or joint based actions $\hat{a}^j$.

For batches of robot data, we calculate

$$L_{robot} = L_1(R\hat{a}^p, R a^p) + L_1(R\hat{a}^j, R a^j) + KL$$

and for hand data we have

$$L_{hand} = L_1(H\hat{a}^p, H a^p) + KL$$

where KL is the CVAE latent regularizer as in ACT [1]. This yields $L = L_{robot} + L_{hand}$ which we optimize at each step.

We leverage the transformer’s flexible input sequence to account for differences in the number of visual observations based on the modality; specifically we have wrist images in robot data but not hand data. When the wrist images are present, we concatenate additional tokens to our transformers input sequence as in ACT [1]. In our experiments, we found that this strategy was sufficient to effectively co-train on both hand and robot data, although we plan to experiment with more sophisticated cross-embodiment learning techniques like HPTs [53].

We note that the human data lacks information for the grasping action, since Aria only records hand pose. Thus, the

表五: 训练细节——EgoMimic

Policy	ACT
Batch Size	128
Optimizer	adamw
Learning rate (initial)	5e-5
Decay factor	1
Scheduler	Linear
Encoder layers	4
Decoder layers	7
Hidden dim	512
Feedforward dim	3200
No. of heads	8
Data Augmentations	Color Jitter

grasping action is supervised only via the robot joint prediction loss $L_1(R\hat{a}^j, R a^j)$, where the gripper is represented as another joint.


D. 训练细节

我们在表五中列出了 EgoMimic 的超参数。所有模型均训练 120000 次迭代，全局批大小为 128，使用 4 块 A40 GPU，耗时约 24 小时。我们的代码在 robomimic 框架 [10] 中实现。更多细节见表五。


E. Mimicplay 实现

对于 MimicPlay[5] 的实现，我们严格遵循原始设置，分别训练高层规划器和低层控制策略。首先，我们训练一个基于 ResNet-18 的高层编码器，使用高斯混合模型 (GMM) 生成三维轨迹，如原始工作所述。高层编码器在人类和机器人数据上训练，以预测三维轨迹。高层编码器训练完成后，我们从 ResNet-18 编码器（即高层规划器）中提取潜在表示，并将其用作风格变量 z ，该变量

a) Continuous Object in Bowl



b) Laundry



c) Groceries




图 11: EgoMimic 在三个任务上的定性成功案例。

表六: 训练细节——Mimicplay

High-level	Resnet18
Learning rate (initial)	0.0001
Decay factor	0.1
Batch size	50
GMM modes	5
Low-level	ACT
Learning rate (initial)	5e-5
Optimizer	adamw
Decay factor	1
Scheduler	Linear

表七: 人类与机器人数据的数据记录与部署速率。本文将人类数据“放慢”至 0.25 倍, 以补偿任务执行速度的差异。

Type	Human (Hz)	Robot (Hz)
Recording	30	50
Rollout (Inference)	-	1
Rollout (Control)	-	25

Aria 相机, 其数据流帧率为 30 帧每秒。

传递给变换器编码器-解码器 (图 10)。随后, 低层 ACT 策略仅在机器人数据上训练, 并以来自高层策略的额外输入作为引导。

F. 策略部署

本文在一台配备英伟达 RTX 4090 图形处理器的台式机上部署策略, 推理频率为 1 赫兹, 控制频率为 25 赫兹。预测动作时长为 4 秒, 其中预测动作的第一秒以滚动时域方式执行。机器人的所有传感器更新频率均为 50 赫兹, 唯一的例外是