

EgoScale: 利用多样化第一人称人类数据实现灵巧操作缩放

Ruijie Zheng^{1*}, Dantong Niu^{1,2*}, Yuqi Xie^{1*}, Jing Wang¹, Mengda Xu¹, Yunfan Jiang¹, 费尔南多·卡斯塔涅达¹,
Fengyuan Hu¹, You Liang Tan¹, Letian Fu^{1,2}, Trevor Darrell², Furong Huang³, Yuke Zhu^{1†},

¹NVIDIA ²加利福尼亚大学伯克利分校 ³马里兰大学

*Equal Contribution [†]Project Lead

<https://research.nvidia.com/labs/gear/egoscale/>

摘要

人类行为是学习物理智能最具可扩展性的数据来源之一，但如何有效利用它进行灵巧操作仍不清楚。尽管先前工作展示了在受限环境中从人到机器人的迁移，但大规模人类数据能否支持细粒度、高自由度的灵巧操作尚不明确。我们提出了 EgoScale，一个基于大规模以自我为中心的人类数据构建的人到灵巧操作迁移框架。我们在超过 20,854 小时的动作标记以自我为中心的人类视频上训练了一个视觉-语言-动作（VLA）模型——比先前工作大 $20\times$ 倍——并揭示了人类数据规模与验证损失之间的对数线性缩放定律。该验证损失与下游真实机器人性能强相关，确立了大规模人类数据作为可预测监督来源的地位。除了规模之外，我们引入了一种简单的两阶段迁移方案：大规模人类预训练，随后进行轻量级对齐的人-机器人中期训练。这使得在极少机器人监督的情况下实现强大的长时程灵巧操作和一次性任务适应。我们的最终策略在使用 22 自由度灵巧机器人手时，相比无预训练基线平均成功率提高了 54%，并且能有效迁移到具有较低自由度手的机器人，表明大规模人类运动提供了一种可重用、与具体形态无关的运动先验。

1. 引言

人类行为是学习物理智能最具可扩展性的数据来源之一。人类在日常中跨各种物体、环境和任务变化执行灵巧操作，其规模远超过通过机器人遥操作所能收集的数据。随着机器人硬件不断向更接近人类的运动学和灵巧性发展，一个自然的问题出现了：人类数据能否作为灵巧机器人操作的主要训练信号？

近期研究表明，通过跨具身对齐观测或动作，可以实现从人类数据到机器人的迁移 [12, 42, 25, 24, 30]。然而，现有成果仍存在两方面局限。首先，大多数方法依赖相对较小的人类数据集，通常仅有数十至数百小时规模。其次，许多研究聚焦于夹爪或低自由度手部，缺乏精细的手指关节运动。因此，人类数据能否在大规模上有效支持复杂灵巧操作仍不明确。本文表明，面向灵巧操作的人机迁移本质上是一种缩放现象，并提出 EgoScale，一个基于大规模第一人称人类数据的可扩展人机灵巧操作迁移框架。我们在 20,854 小时的第一人称人类操作数据上进行预训练，数据量较先前人机策略迁移研究使用的数据集大 $20\times$ 倍以上，并揭示出清晰的缩放定律：人类手腕与手部动作预测的验证损失与数据量呈对数线性关系。据此可外推：随着人类数据规模扩大，验证损失持续下降，所学表征的泛化能力不断增强。关键的是，该损失与真实机器人表现高度相关




图 1: EgoScale: 两阶段人机学习框架。基于流的视觉-语言-动作 (VLA) 策略首先在 20,854 小时的第一人称人类视频上预训练, 使用手腕运动与重定向的灵巧手部动作。随后, 一个轻量级的中期训练阶段利用对齐的人机演示数据 (绿色与灰色边界高亮的数据对) 将表征适配至机器人感知与控制。最终策略在下游任务上进行后训练, 实现灵巧操作的高效学习及对未见技能的一次性泛化。

在长时程、复杂操作任务上的性能。综合而言, 这些结果确立了大规模人类数据作为学习灵巧操作策略的可扩展且可预测的监督来源。除规模之外, 我们识别出一种简单而有效的训练方案, 该方案带来了新的泛化能力。我们使用以相对腕部运动和重定向的高自由度手部关节动作表示的人类操作行为来监督模型。这种对齐的动作空间促使模型提取对操作直接有用的信息, 而非学习与任务无关的视觉特征。在预训练之后, 我们通过协同训练引入少量对齐的人机中期训练数据。中期训练数据包括人类和机器人在匹配的桌面场景中以可比的视觉视角执行类似的操作任务。这种对齐为将预训练表示锚定在机器人的感知与控制空间中提供了监督。重要的是, 这一中期训练阶段催生了涌现的一次性和少次泛化能力。仅需一个或少数几个机器人演示, 策略即可适应新的灵巧任务, 而无需大量任务特定的数据收集。例如, 使用单个机器人演示, 训练后的策略在叠衣任务上平均成功率高达 88%, 尽管中期训练数据仅包含折叠行为。此外, 尽管人类动作是在高自由度灵巧手空间中进行监督的, 学习到的表示仍能泛化到显著不同的机器人形态上。在配备三指手的宇树 G1 机器人上, 与未进行人类预训练的基线相比, 人类预训练策略在两个评估任务上的成功率均实现了超过 30% 的绝对提升。综合来看, 我们的结果表明, 有效的灵巧人机迁移需要规模、显式运动监督以及少量精确的人机对齐。大规模人类演示并非取代机器人数据, 而是极大地增强了其有效性, 指向一个人类可被视为机器人学习中另一种可扩展具身形态的未来。我们将贡献总结如下:

- **人类数据预训练缩放定律。**在超过 2 万小时人类数据规模下，我们揭示了数据规模与手部动作预测损失之间清晰的线性对数关系，并表明该损失与真实机器人灵巧操作性能强相关。
- **一种有效的人到机器人迁移方案。**我们将高自由度人类手部动作监督与少量对齐的人机中期训练相结合，以极少的机器人数据实现强大的后期训练性能。
- **涌现的一次性迁移与泛化。**我们的方法能够一次性迁移到此前未见过的 22 自由度手部灵巧任务。预训练策略还能有效泛化到自由度较低的手部机器人，表明丰富的人类运动提供了可复用的运动先验。

2. 方法

我们旨在从大规模第一人称人类视频中学习直接可用于灵巧机器人控制的表征。该设定带来两个核心挑战。首先，人类演示存在噪声且缺乏配对的机器人动作。其次，人类与机器人在运动学和控制接口上存在显著差异。我们的方法（图 1）通过两项设计选择应对这些挑战。我们首先利用从第一人称视频中提取的手腕运动和手部关节的显式监督在人类数据上进行预训练，迫使模型学习物理基础的动作表征。随后，我们引入少量对齐的人机数据进行中期训练，使这些表征落地为可执行的机器人控制，而无需大规模配对演示。两阶段设计共同将数据规模与具身对齐解耦，从而实现从大规模人类数据集到灵巧机器人操作的有效迁移。

2.1. 人类动作表征

原始传感器数据流。每个人类演示包含从头戴式相机捕获的以自我为中心的红绿蓝（RGB）观测，以及从现成感知流程中获得的估计相机运动和人类手部姿态。我们将这些原始感官信号转换为统一的动作表示，适用于大规模预训练和下游机器人执行。设 $\mathcal{F}_w$ 表示世界坐标系， $\mathcal{F}_c^t$

表示时间 t 处的相机坐标系。估计的相机姿态表示为 $\mathbf{T}_{w \leftarrow c}^t \in \mathbb{SE}(3)$ 。人类手部姿态由 21 个关键点建模，每个关键点表示为相机坐标系中的刚体变换 $\mathbf{H}_{c,i}^t \in \mathbb{SE}(3)$ ，其中 $i = 1$ 对应于手腕。世界坐标系中的手腕姿态由 $\mathbf{W}_w^t = \mathbf{T}_{w \leftarrow c}^t \mathbf{H}_{c,1}^t$ 给出。

手腕级手臂运动。为了获得对全局相机运动不变的运动命令，我们使用连续时间步之间的相对手腕运动来表示手臂运动。给定时间步 t 在一个动作中。这种相对末端执行器公式消除了对绝对相机的依赖姿态， $\text{chunk}, \Delta \mathbf{W}^t = (\mathbf{W}_w^0)^{-1} \mathbf{W}_w^t$ 并以物理上有意义的方式捕获局部手臂运动。相同的表示在人类演示和机器人执行之间共享，作为跨实体学习的主要手臂级动作抽象。

手部关节。对于手指级控制，我们使用基于优化的程序将 21 个人类手部关键点重定向到灵巧机器人手部关节空间，该程序强制执行关节极限和运动学约束。我们的默认选择是 Sharpa 手 [29] 的 22 自由度手部动作空间，它在预训练期间保留人类手指关节，同时与我们目标机器人的控制接口对齐。尽管该表示使用高自由度手定义，但我们后来表明，学习到的模型能有效迁移到具有较低自由度手的机器人。

2.2. 人类数据来源与处理

第一阶段：大规模以自我为中心的人类预训练数据。我们在大规模以自我为中心的人类活动数据集混合体上预训练模型，总计 20,854 小时视频。其中大部分由野外自我中心记录组成，涵盖多样化的真实世界环境（例如家庭、工业、零售和教育场景），覆盖 9,869 个场景、6,015 项任务和 43,237 个物体，并提供了对长尾分布的广泛覆盖。

操纵行为。




图 2：人类数据采集与模型架构。（左）使用与机器人相同的传感装置采集对齐的人机训练中期数据。Vive 追踪器与 Manus 手套捕捉手臂和手部运动，一个头戴式摄像头和两个腕戴式摄像头记录第一人称视角和腕部视角，实现一致的感知-动作对齐。（右）基于流的视觉-语言-动作策略，采用视觉-语言模型骨干和扩散 Transformer 动作专家。人类与机器人数据通过腕部级动作表示统一，并配备轻量级具身特定适配器用于本体感觉和手部动作。

所有录制均使用以自我为中心的红绿蓝（RGB）相机以每秒 30 帧的速率捕获。我们应用现成的同步定位与建图（SLAM）和手部姿态估计流程来恢复相机运动与人类手部轨迹。尽管由于无约束的数据采集，这些估计存在噪声，但数据的规模与多样性为学习可迁移的动作表征提供了有效的监督，随着数据量的增加，这些表征持续提升下游性能。为了补充这种大规模但有噪声的监督，我们额外纳入了 829 小时的 EgoDex 数据集 [8]，该数据集使用苹果视觉专业版（Apple Vision Pro）采集，具有精确的手腕与手部跟踪。EgoDex 涵盖了 194 项涉及日常物品的桌面操作任务，提供了更高精度的运动学信号，有助于锚定预训练，同时保持可扩展性。

第二阶段：对齐的人机中期训练数据。为了进一步弥合人类演示与机器人执行之间的具身差距，我们引入了一个同时包含人类和遥操作机器人数据的较小数据集。我们后续表明，该数据集对于将预训练表示锚定到机器人的感知和动作空间至关重要。该数据集包含 344 个桌面操作任务，每个任务大约采集 30 条人类轨迹和 5 条机器人轨迹，总计约 50 小时人类数据和仅 4 小时机器人数据。如图 2a 所示，人类演示使用与机器人相同的相机配置采集，具有匹配的视角和标定的内参，确保视觉观测在不同域之间可直接比较。人类手部运动使用与机器人遥操作相同的动作捕捉栈捕获：Vive 追踪器提供手腕位姿（三维位置和方向），而 Manus 手套以 25 个关节变换记录完整的手内位姿。所有运动信号与视频流同步。与第一阶段使用的大规模但无约束的数据相比，该数据集显著更小，但明确实现了具身对齐。它专注于与机器人工作空间和运动学匹配的桌面任务，使预训练期间学到的抽象人类动作能够落地为可执行的机器人控制。第一阶段和第二阶段共同解耦了规模与对齐：第一阶段提供多样性和语义基础，第二阶段为下游部署提供精确的人机对应。

2.3. 模型架构

如图 2b 所示，我们的模型遵循与 GR00T N1 [19] 类似的基于流的 VLA 架构。在每个时间步 t ，模型以观测 $o_t = (I_t, l_t)$ 为条件，该观测由图像和语言指令组成，并被编码为视觉-语言嵌入 ϕ_t 。然后，模型使用流匹配目标预测未来动作块。

对于机器人数据，模型以机器人本体感知状态 q_t 为条件，而人类演示不提供此类信号。在缺少本体感知的情况下，我们将 q_t 替换为可学习的占位符标记，从而在不改变架构的情况下实现统一的模型表述。为适应具有不同状态和手部动作空间的多种机器人本体，遵循 GR00T N1[19]，我们在输入和输出接口使用轻量级本体条件多层感知机适配器。具体而言，这些适配器编码本体特定的本体感知状态并解码手部动作，而相对腕部运动预测、视觉语言骨干和扩散变换器动作专家完全共享。在实践中，该机制仅用于少量额外本体（例如，配备三指手的 G1）。

2.4. 训练方案

我们采用三阶段训练流程。在第一阶段（人类预训练），我们在 20K 小时的第一人称人类数据上训练 100K 步，使用 256 块 GB200 图形处理器，全局批大小为 8192，学习率为 5×10^{-5} ，完全解冻视觉语言动作模型的每个参数以吸收大规模数据。随后在第二阶段（对齐中期训练），我们在对齐的人类-机器人操作数据集上训练 50K 步，批大小为 2048，学习率为 3×10^{-5} ，冻结视觉语言骨干，仅更新视觉编码器和扩散变换器动作专家，以将表示锚定到机器人感知与控制。在第三阶段（后训练），我们在任务特定的机器人演示上微调 10K 步，批大小为 512，学习率为 3×10^{-5} 。在后训练期间，若使用中期训练则冻结视觉编码器，否则解冻，以便在需要时适应新本体。

2.5. 机器人系统与控制

真实世界实验在配备 22 自由度 Sharpa 灵巧机器人手的 Galaxea R1Pro 人形机器人上进行。我们请读者参阅附录 B 获取系统图。

双机械臂轮式人形系统 Galaxea R1Pro。我们固定基座和躯干，专注于双臂操作，在相对末端执行器空间中控制两个 7 自由度机械臂，其中动作指定增量位置和姿态变化，与人类演示中使用的腕部姿态表示相匹配，以实现直接的人机对齐。

22 自由度灵巧手。我们为机器人配备了具有 22 个自由度和关节空间控制的 Sharpa Wave 手，其中动作直接指定目标关节角度，从而实现精确的关节运动，并保留重定向的人类手部动作的细粒度结构。

感知系统。我们使用三个 RGB 相机：一个头戴式相机，提供与人类视频一致的第一人称视角；两个腕部相机，安装在每个手腕内侧朝向手掌，捕捉近距离的手物交互，并提供对细粒度灵巧操作至关重要的详细视觉反馈。

3. 实验

在本节中，我们旨在通过实验回答以下研究问题：**RQ1**：与从头训练或仅使用实施例对齐数据相比，大规模以自我为中心的人类预训练是否提高了下游灵巧操作性能？**RQ2**：人类预训练数据的规模如何影响表示质量和真实机器人性能？**RQ3**：中期训练在实现少样本适应和泛化到新任务方面发挥了什么作用？

RQ4: 人类预训练的表示是否能在运动学和控制系统显著不同的机器人实施例之间迁移? **RQ5:** 预训练期间人类动作表示的选择如何影响下游灵巧操作?

3.1. 实验设置




图 3: 训练后评估任务。用于评估训练后性能的五项灵巧操作任务

Tasks. To evaluate policy performance, we design five highly dexterous manipulation tasks shown in Figure 3.

每项任务提供 100 个遥操作机器人演示，除衬衫卷叠外，该可变形操作任务对精度控制要求较低，因此仅使用 20 个演示。

(任务一) (衬衫) 衬衫卷叠。机器人协调双手交替折叠并卷起一件 T 恤成圆柱形，然后将其放入篮子中。

(任务二) (卡片) 卡片分类。机器人用手指摩擦并分离紧密堆叠牌组中的单张卡片，然后根据颜色将其精确插入正确的卡槽中。

(任务三) (夹子) 灵巧工具使用：用夹子转移水果。机器人首先从工具箱中抓取一把夹子，然后用它夹起水果并将其放置在目标位置。

(任务四) (瓶子) 旋开瓶盖。机器人抓取并连续旋转一个小瓶盖，将其从瓶子上取下。我们在四个不同尺寸的瓶子上收集演示，每个瓶子 25 条轨迹。




图 4：主要实验结果。在两种评估度量下，比较人类预训练加中期训练、人类预训练和无预训练在五个灵巧操作任务上的表现。

（任务五）（注射器）注射器液体转移。这是最具挑战性的任务，要求机器人拿起注射器，从试管 A 中抽取液体，注入试管 B，然后将注射器丢弃到垃圾桶中。该任务涉及长时程、多步推理，液体抽取和注入需要精确的空间对齐，以及注射器活塞的灵巧操作。

评估度量。为评估策略性能，我们使用两个随机训练种子训练每种方法。然后，对于每个训练好的策略检查点，我们在 10 次试验中评估性能，任务三除外，该任务在四个瓶子实例上每个瓶子进行 4 次试验，共 16 次评估试验。为确保评估运行之间的一致性，我们采用基于图像叠加的初始化程序，为机器人评估器提供目标初始场景配置的视觉叠加，以减少初始条件的变异性。对于每个任务，我们记录绝对任务成功率和细粒度任务完成分数。

3.2. 大规模人类预训练是获得强灵巧操作策略的关键性能

为评估大规模人类预训练与对齐的中期训练对策略学习效率的影响，本文比较了四个检查点：（1）从头训练的模型，（2）仅在中期训练对齐的人机交互数据集上预训练的模型，（3）在大规模人类数据上预训练的模型，以及（4）在人类预训练基础上进一步在人类-机器人对齐数据上进行中期训练的模型。对于每个检查点，本文报告任务完成分数和绝对成功率。结果总结于图 4。在所有任务中，人类预训练始终比从头训练带来显著的性能提升，平均任务完成度提高超过 55%。值得注意的是，大规模人类预训练尽管存在噪声、无约束且未进行任务或传感器对齐，但在大多数任务上已经优于仅进行中期训练的基线。这提供了证据，表明人类演示的规模和多样性为灵巧操作提供了强大的归纳偏置，即使在没有精确的实体对齐的情况下也是如此。最后，将人类预训练与少量对齐的中期训练相结合可获得最佳整体性能，这表明存在互补效应：大规模人类数据提供通用的操作结构，而中期训练将这些表示锚定到可执行的机器人控制上。

3.3. 策略性能随预训练数据规模扩展

本文研究以自我为中心的人类预训练数据规模如何影响下游真实机器人操作性能，并分析这种行为如何在离线人类动作预测度量中得到反映。本文使用 1 千、2 千、4 千、10 千和 20 千小时的人类数据预训练模型。为隔离第二阶段中期训练的影响，本文直接在每个检查点上对下游任务进行后训练并评估其性能。




图 5：人类预训练的缩放行为。左图：使用不同规模以自我为中心的人类数据（1 千至 2 万小时）预训练的模型，其人类验证损失随训练步数的变化。较大数据集带来稳定且单调的改进，而较小数据集则表现出早期过拟合。中图：收敛时的最优验证损失随人类数据规模的变化，揭示出近乎完美的对数线性缩放定律（ $R^2 = 0.9983$ ）。右图：后训练后的下游机器人性能，以平均任务完成分数衡量，随着人类数据规模的增加而持续提升。综合来看，这些结果证明了所学动作表示的可预测缩放及其直接转化为更优灵巧操作性能的能力。

如图 5（右）所示，增加人类预训练数据量会带来下游机器人性能的一致且显著提升。平均任务完成率从 1 千小时时的 0.30 单调上升至 2 万小时时的 0.71，在所探索的范围内未出现饱和迹象。这些结果表明，大规模人类数据为灵巧操作提供了越来越强的先验，尽管人类演示存在噪声、不受约束且与任务不对齐。为了更好地理解这一趋势，我们研究了预训练数据规模如何影响所学动作表示的质量。我们在一个包含 2000 个以自我为中心片段的留出人类视频验证集上评估每个预训练模型。评估时，我们从每条轨迹中随机采样 20 个时间步；在每个时间步，从流匹配策略中抽取 16 个样本，对预测的动作块取平均，并计算与真实手腕和手部动作之间的均方误差。

图 5（左）展示了不同数据规模下人类验证损失随训练步数的变化。使用较小数据集（1 千至 2 千小时）训练的模型最初降低了验证损失，但随后趋于平稳或恶化，表明对有限行为多样性的过拟合。相比之下，使用较大数据集（1 万至 2 万小时）训练的模型在整个训练过程中表现出稳定且单调的改进，没有过拟合迹象。

引人注目的是，当我们将收敛时达到的最优验证损失与数据规模作图（图 5，中）时，观察到一条非常干净的对数线性缩放定律：

$$L = 0.024 - 0.003 \cdot \ln(D), \quad (1)$$

其中 D 表示人类预训练数据的小时数。拟合曲线达到 R^2 为 **0.9983**，表明在对数空间中几乎完美的线性关系。关键的是，这种离线扩展行为对真实机器人性能具有很强的预测性。人类验证损失在不同数据规模下紧密跟踪下游任务完成情况，使其成为具身控制能力的有意义指标，而非纯粹的离线度量。综合来看，这些结果表明，面向灵巧操作的有效人机迁移本质上是一种扩展现象。在所探索的范围内，增加人类数据会带来验证损失的可预测降低以及机器人性能的相应提升，且没有收益递减的迹象。

虽然我们不外推超出测量范围，但这一趋势表明，随着人类数据规模和模型容量的持续增加，进一步增益仍有相当大的空间。

3.4. 对齐的人机中期训练实现一次性迁移




图 6：对齐的中期训练实现涌现式一次性迁移。在后训练阶段，策略仅使用每个任务单个机器人演示以及对齐的人类演示（每个物体 100 条轨迹）进行训练。

我们评估了在机器人监督极为有限的情况下，对齐的人机中期训练是否能够学习此前未见过的技能。从人类预训练模型出发，我们在对齐的游戏数据集上进行中期训练，并仅使用一次机器人演示，辅以对齐的人类演示，对新任务进行后训练。我们考虑了两个任务：叠衬衫和拧开水瓶，这两个任务均未出现在中期训练数据中。对于叠衬衫任务，我们提供一次机器人演示和 100 次对齐的人类演示。对于拧开水瓶任务，我们使用三个不同几何形状的瓶子评估跨物体变化的泛化能力，每个瓶子提供一次机器人演示和 100 次对齐的人类演示。如图 6 所示，省略大规模人类预训练或对齐中期训练的模型在此一次性设置中均失败。相比之下，预训练+中期训练模型在叠衬衫任务上达到 0.88 的成功率，在拧开水瓶任务上达到 0.55 的成功率，展现出强大的少样本泛化能力。失败通常是部分性的：衬衫折叠不完整，或瓶子拧开盖子后抓取保持稳定。这些结果表明，对齐的中期训练实现了一种仅靠人类预训练或具身特定数据无法产生的迁移形式。这种泛化能力源于中期训练与评估任务之间共享的运动结构。尽管物体和任务实例差异显著，中期训练数据使模型接触到常见的运动基元，从而仅需一次目标机器人演示即可迁移这些行为。

3.5. 人类预训练实现跨具身迁移

除了高自由度灵巧手的双臂桌面操作外，我们还证明了人类预训练能够学习到可迁移的动作表征，这些表征可以泛化到新的机器人形态。我们的人类预训练将动作表示为相对 $\mathbb{S}^3(3)$ 末端执行器运动，并结合由 Sharpa 手定义的 22 自由度灵巧手关节空间。尽管该动作空间是基于特定机器人手实例化的，但它也可以作为一种运动先验，编码可复用的抓取和操作原语，例如手部张开、闭合以及协调的手指关节运动，这些原语可以迁移到其他机器人手。为了评估跨形态泛化能力，我们引入了一个显著不同的机器人平台：宇树 G1，其特点是手臂更短、可达工作空间更小，并配备 7 自由度三指手，导致运动学特性明显不同。我们在两个任务上评估了训练后策略的性能。在第一个任务“笔入垃圾桶”中，G1 机器人使用左臂打开垃圾桶，然后使用右手拾起一支笔并将其放入垃圾桶。在




图 7：中期训练实现向 G1 任务的跨形态泛化。在中期训练阶段融入少量 G1 演示数据，能够实现向低自由度三指手的强迁移，其效果优于仅进行中期训练或仅进行预训练。

第二个任务，架中盘（Dish in Rack），机器人面对桌上的三个盘子，必须执行从右到左的交接，将盘子放到架子上。在执行过程中，策略预测上半身目标指令，而下半身平衡和移动由单独训练的 Homie [2] 策略处理，该策略输出下半身关节指令。与之前的实验相同，我们使用两个随机种子训练每种方法。对于每个种子，我们在 10 次试验中评估所得策略，并报告两个种子上的平均策略得分和成功率。如图 7 所示，与仅在相同 G1 实施例特定数据上训练的检查点相比，在包含 G1 实施例操作数据的数据混合上进行中期训练，也能在两个 G1 操作任务上带来显著的性能提升。至关重要是，这种改进不能仅仅归因于增加了对 G1 轨迹的接触：在没有先前人类预训练的情况下，直接在相同 G1 数据集上预训练和微调的策略未能达到可比的成功率。从经验上看，我们还观察到在人类数据上预训练的策略表现出质量上更平滑的行为。这些结果表明，EgoScale 预训练学习了一种可跨实施例迁移的可重用操作结构，而中期训练使该结构适应 G1 的感知和控制接口。

3.6. 用于人类预训练的手部动作空间设计




图 8：不同人类预训练动作表示下各任务的任务完成得分。

本文研究预训练阶段人类手部动作表征的选择如何影响下游灵巧操作。默认设置使用 22 自由度灵巧关节动作空间表征人类手部运动，并与两种替代方案进行对比：（i）仅腕部表征，移除所有手指级监督；（ii）基于指尖的表征 [42]，预测 $\mathbb{S}^2(3)$ 腕部和指尖的轨迹，随后通过多层感知机映射到机器人关节指令。如图 8 所示，动作表征显著影响任务性能。仅腕部表征在所有任务上表现不佳，尤其是需要精确手指关节运动和接触时机的任务（如夹钳、卡片）。在这些情况下，策略经常抓握工具过弱或处于不稳定高度，或过早闭合手部，导致接触失败或脆弱。基于指尖的表征提供更丰富的几何监督，并在某些任务上提升性能，但仍不稳定。指尖姿态的微小误差在映射后往往导致不合理的关节构型，造成抓握不稳定或在接触敏感任务（如卡片和瓶子）中失去接触。相比之下，使用重定向关节空间手部动作进行预训练在所有任务上取得最一致的性能。因此，本文采用重定向关节空间手部动作作为大规模人类预训练的实用且有效的选择。

4. 相关工作

从人类数据中学习机器人操作。人类演示已被广泛用于扩展机器人学习，早期工作主要利用人类视频进行表示学习或意图推断 [17, 36, 15, 14, 45]。后续方法使用人类数据指导规划或高层控制，同时依赖机器人演示进行低层执行 [34, 43, 44, 18, 38, 39]。近期方法利用以自我为中心感知和三维手部跟踪的进展，将人类视频视为密集动作监督。EgoMimic [12]、Qiu 等人 [25] 和 DexWild [30] 通过显式对齐在人类和机器人演示上联合训练统一的模仿策略，而 EgoVLA [42] 在人类手部运动上预训练视觉-语言-动作模型，并通过逆运动学和重定向将其迁移到机器人。同期工作 [13] 表明，在大规模多样化跨具身数据上预训练的视觉-语言-动作模型可以解锁人类到机器人的迁移能力。与这些工作相比，本文专注于纯大规模人类预训练与极少量机器人监督，目标是从多样化的以自我为中心人类视频中直接学习腕部运动和灵巧手部关节运动。与主要迁移腕部运动用于夹爪平台的方法相比，本文的设置保留了丰富的手部运动信息，这对灵巧操作至关重要。与近期同样利用手部级监督的方法相比，本文在更大规模的人类数据上进行预训练，并系统地表明扩展人类视频在人类验证指标和下游机器人性能上均带来一致的改进，从而在先进的多自由度机器人手上实现强大的灵巧操作性能。

机器人学习中的扩展特性。受语言与视觉领域所观察到的缩放定律启发，近期研究开始探讨类似原理是否同样支配机器人学习。实证表明，大规模机器人数据集与基础式策略显示，提升数据多样性与覆盖范围可增强跨任务与环境的鲁棒性及泛化能力 [11, 46, 20, 33, 31, 4]。胡等人 [9] 指出，策略泛化随环境与物体多样性近似遵循幂律增长，而额外演示迅速趋于饱和，凸显多样性比原始数据量更为关键。这与先前强调通过组合多样性实现高效数据采集的工作一致 [7, 37]。相较于以往主要扩展机器人采集数据的研究，本文证明扩展多样化的真实世界人类自我中心数据可系统提升灵巧操作能力，从而确立人类视频作为一种高效且可扩展的监督来源。

学习灵巧操作。灵巧操作已从基于解析与控制的方法演进，这些方法对力闭合、接触稳定性及手部运动学进行建模 [21, 22, 26, 27, 23, 6]

转向基于学习的方法，从数据中获取接触丰富的行为 [1, 16, 40]。后续工作引入了结构化表示，如抓取可供性、接触图和手-物体交互场，以更好地捕捉灵巧几何与物理 [3, 5, 10, 41, 32]。更近期的方法旨在通过统一的感知与控制学习可泛化的多指操作策略 [28, 35]。然而，由于高维动作空间、机器人数据采集成本以及当前灵巧手硬件的有限能力，扩展灵巧操作仍然具有挑战性。我们的工作利用带有密集手部跟踪的以自我为中心的人类视频作为替代监督来源，表明人类手部运动为改进机器人灵巧操作提供了可迁移的信号。

5. 致谢

这项工作离不开我们机器人操作员的奉献精神和专业知识：Ivy Tam、Ashley Kim、Aly Khater、Rhea Alve、Noah Huang、Ty Seligman、Mahnoor Kareem、Christian Soto、Chaitanya Kothapalli、Kendra Shu、Rex Asato、Eley Barba Preciados 和 April Zitkovich，他们在大规模数据收集和评估中提供了宝贵的支持。我们还要感谢 Johan Bjorck、Scott Reed、Runyu Ding 和 Joel Jang 在整个项目期间提出的深刻讨论和反馈。

6. 结论

在这项工作中，我们证明了有效的人到机器人迁移用于灵巧操作本质上是一种缩放现象。通过在超过 2 万小时的以自我为中心的人类操作数据上预训练视觉-语言-动作策略，EgoScale 揭示了人类动作预测损失与数据规模之间清晰的线性对数缩放定律，并证明该损失能强烈预测下游真实机器人的性能。除了规模之外，我们还确定了一种简单有效的迁移配方：将大规模人类预训练与少量对齐的人-机器人中期训练相结合，能够实现强大的长时程灵巧操作、涌现的一次性适应，以及跨具有显著不同运动学和手部设计的机器人实体的稳健迁移。展望未来，仍有几个方向有待探索。虽然我们在探索的范围内未观察到饱和现象，但联合扩展人类数据和模型容量可能会带来进一步的收益，包括改进的长时程规划和组合泛化。随着以自我为中心的人类数据持续增长，通过自监督目标纳入较弱或无标签的视频可能会进一步放大这些益处。最后，随着机器人硬件在运动学和灵巧性上变得更像人类，实体差距将自然缩小，从而实现更强的迁移，并可能在新任务上实现零样本执行。总之，这些结果指向了一个未来，在这个未来中，人类可以被视为学习通用具身智能的真正可扩展的实体。

A. 机器人系统细节




图 9: Galaxea R1 Pro 和 Unitree G1 平台上机器人系统设置的可视化。Galaxea R1 Pro 配备了 22 自由度的 Sharpa 灵巧手，而 Unitree G1 则安装了 7 自由度的三指手。两台机器人都配有两个 OAK-1-Wide 摄像头用于腕部视角，以及一个 OAK-D-Wide 头戴式摄像头以提供以自我为中心的视觉观察。

B. 任务描述与评估标准

在本节中，我们详细描述了第 3 节中引入的训练后评估任务，以及相应的评估标准。每个任务由自然语言指令指定，并使用 $[0, 1]$ 范围内的任务完成分数进行评估，旨在除了二元成功之外还捕捉部分进展。根据任务的结构，我们采用两种评分策略之一。对于自然分解为一系列独立、定义明确的子技能（例如，工具抓取、放置或离散操作步骤）的任务，我们使用加性评分标准，其中最终分数是已实现子分数的总和。对于涉及可变形物体或紧密耦合操作阶段的任务，其中间状态难以独立定义，我们改用基于进度的评分标准，其中分数反映达到的最远任务里程碑。两种设计都旨在提供细粒度、可解释的反馈，同时忠实于底层任务结构。对于每个任务，除非特别说明，我们对每个检查点进行 10 次试验评估。

R1 Pro Sharpa

- **任务一：衬衫卷叠。**文本指令：“将 T 恤卷起并放入篮子中。”机器人必须协调双手，逐步折叠、卷起并将可变形 T 恤放入篮子中。评分标准（基于进度）：
 - 0.0：无折叠行为。
 - 0.3：执行初始折叠。
 - 0.5：执行多次折叠或部分卷叠。
 - 0.8：完成连续卷叠动作，形成紧凑形状。

- 1.0 : 将卷好的衬衫放入篮子中。评估试验:
10 次试验。
- **任务二：卡片分类。**文本指令：“拿起卡片并将其分类到正确的卡槽中。”机器人必须从紧密堆叠的牌堆中分离出一张卡片，并将其插入正确的卡槽中。评分标准（基于进度）：
 - 0.0 : 未成功拾取；整个牌堆被扰动或抬起。
 - 0.3 : 抓取不佳；无意中抬起多张卡片。
 - 0.5 : 成功拾取单张卡片。
 - 0.7 : 卡片放置时有明显扰动或插入错误。
 - 0.9 : 正确卡片放置正确，但有轻微扰动。
 - 1.0 : 单张正确卡片干净地放入正确卡槽中。

- **任务三：夹取水果转移。**文本指令：“使用夹子拾取水果并将其放入篮子中。”机器人必须首先抓取夹子，然后使用该工具拾取目标物体并将其放入容器中。该任务使用 2 种随机水果（柠檬和李子）进行评估，每种水果进行 5 次评估试验。评分标准（累加）：
 - +0.4 : 成功抓取夹子。
 - +0.2 : 使用夹子拾取水果。
 - +0.2 : 将水果放入篮子中。
 - +0.2 : 将夹子放回桌面。

- **任务四：瓶盖旋开。**文本指令：“从瓶子上旋开瓶盖。”机器人必须抓取瓶子，多次旋转瓶盖，将其取下并放置在桌面上。为了测试跨物体变化的泛化能力，我们评估了 4 种不同高度和瓶盖尺寸的瓶子配置。性能在总共 12 次试验中测量，每个瓶子进行 4 次试验。评分标准（累加）：
 - +0.1 : 抓取瓶子。
 - +0.5 : 以至少三次连续旋转旋开瓶盖。
 - +0.2 : 完全取下瓶盖。
 - +0.2 : 将瓶盖放置在桌面上。

- **任务五：注射器液体转移。**文本指令：“拿起注射器，从试管 A 中抽取液体，将其注入试管 B，然后将注射器扔进垃圾桶。”该任务需要精确的工具操作、空间对齐和长时程序列规划。评分标准（累加）：
 - +0.1 : 拿起注射器。
 - +0.1 : 正确对准试管 A。
 - +0.2 : 拉动活塞以抽取液体。
 - +0.1 : 重新对准试管 B。
 - +0.2 : 推动活塞以注入液体。
 - +0.2 : 交出或释放注射器。
 - +0.1 : 将注射器丢弃到垃圾桶中。为了评估一次性适应能力，我们在 R1 Pro Sharpa 平台上考虑了另外两个操作任务。对于每个任务，策略使用单个机器人演示进行后训练，性能使用 [0, 1] 中的任务特定完成分数进行评估。

- **任务八：一次性 T 恤折叠。**文本指令：“折叠 T 恤。”评分标准（累加）：
 - +0.4 : 成功折叠至少一只袖子。
 - +0.4 : 成功折叠两只袖子。
 - +0.3 : 执行底部折叠。在评估过程中，如果完成某个折叠但折叠凌乱，我们还会扣除 0.1 分。

• **任务九：一次性瓶盖旋开。**文本指令：“拧开水瓶瓶盖。”该任务自然分解为离散、定义明确的操作步骤，并采用累加评分进行评估。评分标准（累加制）：- +0.1：抓住水瓶。- +0.2：完成一到两次成功的旋松旋转。- +0.5：完成至少三次连续的旋松旋转。- +0.2：完全取下瓶盖。- +0.2：将瓶盖放在桌面上。对于所有任务，我们还报告二元任务成功率，即仅当试验根据指令端到端完成时，才视为成功。

G1 任务

除了 R1 Pro Sharpa 评估之外，我们还在 Unitree G1 平台上使用两个操作任务评估跨具身泛化能力。两个任务均采用累加评分进行评估，以反映其分解为离散、定义明确的子技能。

• **笔入桶。**文本指令：“马克笔罐任务。”机器人必须打开罐子，拿起一支马克笔，并将马克笔放入罐中。评分标准（累加制）：- +0.25：拿起或打开罐子。- +0.25：将罐子稳定放下。- +0.25：拿起马克笔。- +0.25：将马克笔放入罐中。

• **碗架中的盘子交接** 文本指令：“将盘子放在碗架上。”机器人面前有三只盘子放在桌子上，必须转移它们（可能在双手之间），并将它们竖直放入碗架中。评分标准（累加制，按盘子计）：对于每只盘子，我们分配：- 0.11：拿起盘子。- 0.11：在双手之间转移盘子。- 0.11：将盘子竖直放入碗架中。最终任务完成得分通过将三只盘子的得分相加计算，每次试验最高得分为 1.0。

C. 野外人类数据策展的细节

C.1. 数据集统计与分析

本节对用于第一阶段预训练的大规模以自我为中心的人类活动数据进行了详细分析。图 10 从多个互补视角总结了该数据集，包括顶行展示的统计分布和底行展示的定性以自我为中心示例。具体而言，左上方面板可视化对象词汇表，上中面板展示类别分布，右上方面板呈现环境分布，第二行最右侧面板说明任务分布。这些统计共同揭示了类别、环境、任务和对象的长尾分布，突显了数据集中捕获的真实世界操作行为的规模和多样性。

C.2. 类别分布

总视频时长的类别级分布（图中仅统计超过 50 小时的类别）如图 10 上中面板所示。数据集以零售和消费品为主




图 10: 以自我为中心的人类活动数据集的统计分布和定性示例, 展示了类别、环境、任务和对象的长尾覆盖。

(20.1%)，其次是时尚 (11.8%)、维修服务 (11.5%) 以及食品和饮料 (11.5%)。其他重要部分来自家庭环境 (9.5%)、建筑和五金 (7.7%)、食品加工 (6.7%) 以及印刷和设计 (4.4%)，而其余类别形成长尾，涵盖酒店、汽车和交通、体育和娱乐、教育、医疗保健、能源和工业领域。

C.3. 环境多样性

超过 50 小时记录的环境数据分布如图 10 左下条形图所示。最常见的环境包括家庭、花店、电子维修店、家具维修店、木工车间和服装店。除了这些主要场景外，数十个其他环境——如杂货店、面包店、车间、工厂、工作室、图书馆和其他服务型空间——贡献了较小但不可忽略的数据量，形成了长尾环境分布。

C.4. 任务覆盖范围

任务级统计信息展示于图 10 右下方的柱状图中。高频任务包括叠衣服、擦鞋、盆栽、熨烫、组装箱子、插花、打磨木材以及备餐。此外，广泛的中频和低频任务涵盖打包、分拣、修理、装饰、切割、装瓶、充气 and 拆卸。许多任务涉及多步骤流程和持续的物理交互，反映了真实的长时程操作行为，而非孤立的抓取-放置动作。

C.5. 物体词汇表

物体词汇表通过图 10 左上方的词云进行可视化。频繁出现的物体包括纸板箱、塑料袋、碗、托盘、胶带、衣物、面团、电池和电路板，以及大量低频物体的长尾分布。物体实例的多样性及其与广泛任务的共现表明存在强组合结构，支持跨物体、任务和环境学习可迁移的动作表示。

D. 手部动作重定向算法

本文采用基于逐帧优化的方法，将 21 个人体手部关键点（每只手表示为 25 个具有三维位置和朝向的关键点）重定向到 Sharpa Hand 的 22 自由度关节空间中 [29]。机器人手部使用基于 URDF 的正向运动学建模，将关节角度映射到 20 个机器人关键点姿态（位置和四元数）。对于每只手和每个时间步，本文在 22 个关节角度上求解一个非线性规划问题，仅受 URDF 中的关节极限约束，并最小化不同目标的加权组合。该优化在 CasADi 中实现，并使用 IPOPT 求解，以上一帧的解作为热启动。所得关节角度进一步通过一阶指数滤波器进行平滑，以减少时间抖动。该设计在保持手指关节运动和捏/拳语义的同时，强制关节极限和运动学一致性，并产生用于预训练和与目标机器人交互的 22 自由度动作空间。

D.1. 跨具身迁移至 G1 的补充细节

本小节提供了关于如何将人体预训练策略适配到 Unitree G1 机器人的额外实现细节。该机器人在运动学和手部驱动方面与主要的 Galaxea R1 Pro 平台存在显著差异。

共享腕部动作。在所有实施例中，我们使用 $SE(3)$ 中的相对末端执行器位姿来表示手臂运动，该位姿由帧间腕部变换定义。这种表示在人类演示与机器人执行之间共享，并且对绝对工作空间、相机位置和手臂运动学的差异保持不变。

执行，并且对绝对工作空间、相机位置和手臂运动学的差异保持不变。

手部动作适配。人类预训练是在通过重定向的人类手部运动获得的 22 自由度灵巧手关节空间中进行的。为了支持不同实施例的机器人，例如配备 7 自由度三指手的宇树 G1，我们在 DiT 动作模块的输入和输出接口处引入了轻量级的实施例条件多层感知机适配器，遵循 GR00T-N1 和 N1.5 的设计 [19]。具体而言，实施例特定的编码器将机器人本体感觉状态和带噪动作输入映射到共享的潜在动作空间，而实施例特定的解码器将 DiT 输出映射回相应的关节动作空间。视觉-语言骨干网络和 DiT 动作专家在所有实施例之间完全共享。

实施例特定的中期训练。为了将人类预训练的表达锚定在 G1 控制空间中，我们在对齐的中期训练阶段纳入了 G1 机器人操作数据。在此阶段，仅更新视觉编码器、DiT 动作专家以及状态-动作编码器和解码器，而视觉-语言骨干网络保持冻结。这种设计使模型能够保留源自人类的操作结构，同时适应 G1 的传感和驱动接口。

讨论。重要的是，G1 从未从头开始训练。相反，中期训练用于将已学习的人类操作表征与新本体对齐。如第 3 节所示，该方法比仅使用 G1 数据直接训练的性能显著更高，表明大规模人类预训练提供了可复用且与本体无关的运动先验，能够高效地适应具有不同运动学和手部设计的机器人。

参考文献

- [1] OpenAI: Marcin Andrychowicz, Bowen Baker, Maciek Chociej, Rafal Jozefowicz, Bob McGrew, Jakub Pachocki, Arthur Petron, Matthias Plappert, Glenn Powell, Alex Ray, et al. Learning dexterous in-hand manipulation. *The International Journal of Robotics Research*, 39(1):3–20, 2020. 12
- [2] Qingwei Ben, Feiyu Jia, Jia Zeng, Juntao Dong, Dahua Lin, and Jiangmiao Pang. Homie: Humanoid loco-manipulation with isomorphic exoskeleton cockpit, 2025. URL <https://arxiv.org/abs/2502.13013>. 10
- [3] Samarth Brahmabhatt, Ankur Handa, James Hays, and Dieter Fox. Contactgrasp: Functional multi-finger grasp synthesis from contact. in 2019 iee. In *RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 2386–2393, 2019. 12
- [4] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Joseph Dabis, Chelsea Finn, Keerthana Gopalakrishnan, Karol Hausman, Alex Herzog, Jasmine Hsu, et al. Rt-1: Robotics transformer for real-world control at scale. *arXiv preprint arXiv:2212.06817*, 2022. 11
- [5] Enric Corona, Albert Pumarola, Guillem Alenya, Francesc Moreno-Noguer, and Grégory Rogez. Ganhand: Predicting human grasp affordances in multi-object scenes. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 5031–5041, 2020. 12
- [6] Hongkai Dai, Anirudha Majumdar, and Russ Tedrake. Synthesis and optimization of force closure grasps via sequential semidefinite programming. In *Robotics Research: Volume 1*, pages 285–305. Springer, 2017. 11
- [7] Jensen Gao, Annie Xie, Ted Xiao, Chelsea Finn, and Dorsa Sadigh. Efficient data collection for robotic manipulation via compositional generalization. *arXiv preprint arXiv:2403.05110*, 2024. 11
- [8] Ryan Hoque, Peide Huang, David J. Yoon, Mouli Sivapurapu, and Jian Zhang. Egodex: Learning dexterous manipulation from large-scale egocentric video, 2025. URL <https://arxiv.org/abs/2505.11709>. 4
- [9] Yingdong Hu, Fanqi Lin, Pingyue Sheng, Chuan Wen, Jiacheng You, and Yang Gao. Data scaling laws in imitation learning for robotic manipulation. *arXiv preprint arXiv:2410.18647*, 2024. 11
- [10] Hanwen Jiang, Shaowei Liu, Jiashun Wang, and Xiaolong Wang. Hand-object contact consistency reasoning for human grasps generation. In *Proceedings of the IEEE/CVF international conference on computer vision*, pages 11107–11116, 2021. 12
- [11] Dmitry Kalashnikov, Alex Irpan, Peter Pastor, Julian Ibarz, Alexander Herzog, Eric Jang, Deirdre Quillen, Ethan Holly, Mrinal Kalakrishnan, Vincent Vanhoucke, et al. Scalable deep reinforcement learning for vision-based robotic manipulation. In *Conference on robot learning*, pages 651–673. PMLR, 2018. 11
- [12] Simar Kareer, Dhruv Patel, Ryan Punamiya, Pranay Mathur, Shuo Cheng, Chen Wang, Judy Hoffman, and Danfei Xu. Egomimic: Scaling imitation learning via egocentric video, 2024. URL <https://arxiv.org/abs/2410.24221>. 1, 11
- [13] Simar Kareer, Karl Pertsch, James Darpinian, Judy Hoffman, Danfei Xu, Sergey Levine, Chelsea Finn, and Suraj Nair. Emergence of human to robot transfer in vision-language-action models, 2025. URL <https://arxiv.org/abs/2512.22414>. 11
- [14] Corey Lynch, Mohi Khansari, Ted Xiao, Vikash Kumar, Jonathan Tompson, Sergey Levine, and Pierre Sermanet. Learning latent plans from play. In *Conference on robot learning*, pages 1113–1132. Pmlr, 2020. 11

-
- [15] Arjun Majumdar, Karmesh Yadav, Sergio Arnaud, Jason Ma, Claire Chen, Sneha Silwal, Aryan Jain, Vincent-Pierre Berges, Tingfan Wu, Jay Vakil, et al. Where are we in the search for an artificial visual cortex for embodied intelligence? *Advances in Neural Information Processing Systems*, 36:655–677, 2023. 11
 - [16] Anusha Nagabandi, Kurt Konolige, Sergey Levine, and Vikash Kumar. Deep dynamics models for learning dexterous manipulation. In *Conference on robot learning*, pages 1101–1112. PMLR, 2020. 12
 - [17] Suraj Nair, Aravind Rajeswaran, Vikash Kumar, Chelsea Finn, and Abhinav Gupta. R3m: A universal visual representation for robot manipulation. *arXiv preprint arXiv:2203.12601*, 2022. 11
 - [18] Dantong Niu, Yuvan Sharma, Giscard Biamby, Jerome Quenum, Yutong Bai, Baifeng Shi, Trevor Darrell, and Roei Herzig. Llarva: Vision-action instruction tuning enhances robot learning. *arXiv preprint arXiv:2406.11815*, 2024. 11
 - [19] NVIDIA, :, Johan Bjorck, Fernando Castañeda, Nikita Cherniadev, Xingye Da, Runyu Ding, Linxi "Jim" Fan, Yu Fang, Dieter Fox, Fengyuan Hu, Spencer Huang, Joel Jang, Zhenyu Jiang, Jan Kautz, Kaushil Kundalia, Lawrence Lao, Zhiqi Li, Zongyu Lin, Kevin Lin, Guilin Liu, Edith Llontop, Loic Magne, Ajay Mandlekar, Avnish Narayan, Soroush Nasiriany, Scott Reed, You Liang Tan, Guanzhi Wang, Zu Wang, Jing Wang, Qi Wang, Jiannan Xiang, Yuqi Xie, Yinzhen Xu, Zhenjia Xu, Seonghyeon Ye, Zhiding Yu, Ao Zhang, Hao Zhang, Yizhou Zhao, Ruijie Zheng, and Yuke Zhu. Gr00t n1: An open foundation model for generalist humanoid robots, 2025. URL <https://arxiv.org/abs/2503.14734>. 5, 18
 - [20] Open X-Embodiment Collaboration et al. Open X-Embodiment: Robotic learning datasets and RT-X models. *International Conference on Robotics and Automation*, 2024. 11
 - [21] Jean Ponce, Steve Sullivan, J-D Boissonnat, and J-P Merlet. On characterizing and computing three-and four-finger force-closure grasps of polyhedral objects. In *[1993] Proceedings IEEE International Conference on Robotics and Automation*, pages 821–827. IEEE, 1993. 11
 - [22] Jean Ponce, Steve Sullivan, Attawith Sudsang, Jean-Daniel Boissonnat, and Jean-Pierre Merlet. On computing four-finger equilibrium and force-closure grasps of polyhedral objects. *The International Journal of Robotics Research*, 16(1):11–35, 1997. 11
 - [23] Domenico Prattichizzo, Monica Malvezzi, Marco Gabiccini, and Antonio Bicchi. On the manipulability ellipsoids of underactuated robotic hands with compliance. *Robotics and Autonomous Systems*, 60(3): 337–346, 2012. 11
 - [24] Ryan Punamiya, Dhruv Patel, Patcharapong Aphiwetsa, Pranav Kuppili, Lawrence Y Zhu, Simar Kareer, Judy Hoffman, and Danfei Xu. Egobridge: Domain adaptation for generalizable imitation from egocentric human data. In *The Thirty-ninth Annual Conference on Neural Information Processing Systems*. 1
 - [25] Ri-Zhao Qiu, Shiqi Yang, Xuxin Cheng, Chaitanya Chawla, Jialong Li, Tairan He, Ge Yan, David J. Yoon, Ryan Hoque, Lars Paulsen, Ge Yang, Jian Zhang, Sha Yi, Guanya Shi, and Xiaolong Wang. Humanoid policy ~ human policy. In *9th Annual Conference on Robot Learning*, 2025. URL <https://openreview.net/forum?id=Tx54fkQ3Cq>. 1, 11
 - [26] Alberto Rodriguez, Matthew T Mason, and Steve Ferry. From caging to grasping. *The International Journal of Robotics Research*, 31(7):886–900, 2012. 11
 - [27] Carlos Rosales, Raúl Suárez, Marco Gabiccini, and Antonio Bicchi. On the synthesis of feasible and prehensile robotic grasps. In *2012 IEEE international conference on robotics and automation*, pages 550–556. IEEE, 2012. 11
-

-
- [28] Lin Shao, Fabio Ferreira, Mikael Jorda, Varun Nambiar, Jianlan Luo, Eugen Solowjow, Juan Aparicio Ojea, Oussama Khatib, and Jeannette Bohg. Unigrasp: Learning a unified model to grasp with multifingered robotic hands. *IEEE Robotics and Automation Letters*, 5(2):2286–2293, 2020. 12
 - [29] Sharpa Robotics. Sharpa wave. <https://www.sharpa.com/pages/wave>, 2024. Accessed: 2026-01-31. 3, 17
 - [30] Tony Tao, Mohan Kumar Srirama, Jason Jingzhou Liu, Kenneth Shaw, and Deepak Pathak. Dexwild: Dexterous human interactions for in-the-wild robot policies, 2025. URL <https://arxiv.org/abs/2505.07813>. 1, 11
 - [31] Octo Model Team, Dibya Ghosh, Homer Walke, Karl Pertsch, Kevin Black, Oier Mees, Sudeep Dasari, Joey Hejna, Tobias Kreiman, Charles Xu, et al. Octo: An open-source generalist robot policy. *arXiv preprint arXiv:2405.12213*, 2024. 11
 - [32] Dylan Turpin, Liquan Wang, Eric Heiden, Yun-Chun Chen, Miles Macklin, Stavros Tsogkas, Sven Dickinson, and Animesh Garg. Grasp’d: Differentiable contact-rich grasp synthesis for multi-fingered hands. In *European Conference on Computer Vision*, pages 201–221. Springer, 2022. 12
 - [33] Homer Walke, Kevin Black, Abraham Lee, Moo Jin Kim, Max Du, Chongyi Zheng, Tony Zhao, Philippe Hansen-Estruch, Quan Vuong, Andre He, Vivek Myers, Kuan Fang, Chelsea Finn, and Sergey Levine. Bridgedata v2: A dataset for robot learning at scale. In *Conference on Robot Learning (CoRL)*, 2023. 11
 - [34] Chen Wang, Linxi Fan, Jiankai Sun, Ruohan Zhang, Li Fei-Fei, Danfei Xu, Yuke Zhu, and Anima Anandkumar. Mimicplay: Long-horizon imitation learning by watching human play. *arXiv preprint arXiv:2302.12422*, 2023. 11
 - [35] Albert Wu, Michelle Guo, and C Karen Liu. Learning diverse and physically feasible dexterous grasps with generative model and bilevel optimization. *arXiv preprint arXiv:2207.00195*, 2022. 12
 - [36] Tete Xiao, Ilija Radosavovic, Trevor Darrell, and Jitendra Malik. Masked visual pre-training for motor control. *arXiv preprint arXiv:2203.06173*, 2022. 11
 - [37] Annie Xie, Lisa Lee, Ted Xiao, and Chelsea Finn. Decomposing the generalization gap in imitation learning for visual robotic manipulation. In *2024 IEEE International Conference on Robotics and Automation (ICRA)*, pages 3153–3160. IEEE, 2024. 11
 - [38] Mengda Xu, Zhenjia Xu, Cheng Chi, Manuela Veloso, and Shuran Song. Xskill: Cross embodiment skill discovery. In *Conference on robot learning*, pages 3536–3555. PMLR, 2023. 11
 - [39] Mengda Xu, Zhenjia Xu, Yinghao Xu, Cheng Chi, Gordon Wetzstein, Manuela Veloso, and Shuran Song. Flow as the cross-domain manipulation interface. *arXiv preprint arXiv:2407.15208*, 2024. 11
 - [40] Mengda Xu, Han Zhang, Yifan Hou, Zhenjia Xu, Linxi Fan, Manuela Veloso, and Shuran Song. Dexumi: Using human hand as the universal manipulation interface for dexterous manipulation, 2025. URL <https://arxiv.org/abs/2505.21864>. 12
 - [41] Lixin Yang, Xinyu Zhan, Kailin Li, Wenqiang Xu, Jiefeng Li, and Cewu Lu. Cpf: Learning a contact potential field to model the hand-object interaction. In *Proceedings of the IEEE/CVF international conference on computer vision*, pages 11097–11106, 2021. 12
 - [42] Ruihan Yang, Qinxu Yu, Yecheng Wu, Rui Yan, Borui Li, An-Chieh Cheng, Xueyan Zou, Yunhao Fang, Xuxin Cheng, Ri-Zhao Qiu, et al. Egovla: Learning vision-language-action models from egocentric human videos. *arXiv preprint arXiv:2507.12440*, 2025. 1, 11
-

- [43] Sarah Young, Dhiraj Gandhi, Shubham Tulsiani, Abhinav Gupta, Pieter Abbeel, and Lerrel Pinto. Visual imitation made easy. In *Conference on Robot learning*, pages 1992–2005. PMLR, 2021. [11](#)
- [44] Ruijie Zheng, Yongyuan Liang, Shuaiyi Huang, Jianfeng Gao, Hal Daumé III, Andrey Kolobov, Furong Huang, and Jianwei Yang. Tracevla: Visual trace prompting enhances spatial-temporal awareness for generalist robotic policies. *arXiv preprint arXiv:2412.10345*, 2024. [11](#)
- [45] Ruijie Zheng, Jing Wang, Scott Reed, Johan Bjorck, Yu Fang, Fengyuan Hu, Joel Jang, Kaushil Kundalia, Zongyu Lin, Loïc Magne, Avnish Narayan, You Liang Tan, Guanzhi Wang, Qi Wang, Jiannan Xiang, Yinzhen Xu, Seonghyeon Ye, Jan Kautz, Furong Huang, Yuke Zhu, and Linxi Fan. FLARE: Robot learning with implicit world modeling. In *9th Annual Conference on Robot Learning*, 2025. URL <https://openreview.net/forum?id=HXJ6pUSn1L>. [11](#)
- [46] Brianna Zitkovich, Tianhe Yu, Sichun Xu, Peng Xu, Ted Xiao, Fei Xia, Jialin Wu, Paul Wohlhart, Stefan Welker, Ayzaan Wahid, et al. Rt-2: Vision-language-action models transfer web knowledge to robotic control. In *Conference on Robot Learning*, pages 2165–2183. PMLR, 2023. [11](#)