

Fast-WAM: 世界动作模型 是否需要测试时未来想象？

Tianyuan Yuan^{1,2}, Zibin Dong^{1,2}, Yicheng Liu^{1,2}, Hang Zhao^{1,2}

¹IIIS, Tsinghua University ²Galaxea AI

<https://yuantianyuan01.github.io/FastWAM/>

摘要

世界动作模型（World Action Models, WAMs）已成为具身控制中视觉-语言-动作（Vision-Language-Action, VLA）模型的一种有前景的替代方案，因为它们显式地建模视觉观测在动作作用下如何演化。现有的大多数 WAM 遵循先想象后执行的范式，因迭代视频去噪而产生显著的测试时延迟，但显式未来想象是否真的对强动作性能必要仍不清楚。本文探讨 WAM 在测试时是否需要显式未来想象，还是其优势主要来自训练期间的视频建模。我们通过提出 **Fast-WAM** 来解耦训练期间视频建模与推理期间显式未来生成的作用，**Fast-WAM** 是一种在训练期间保留视频协同训练但在测试时跳过未来预测的 WAM 架构。我们进一步实例化多个 **Fast-WAM** 变体，以对这两个因素进行受控比较。在这些变体中，我们发现 **Fast-WAM** 仍能与先想象后执行的变体相竞争，而去除视频协同训练会导致更大的性能下降。实验上，**Fast-WAM** 在仿真基准（LIBERO 和 RoboTwin）和真实世界任务上均取得了与最先进方法相当的结果，且无需具身预训练。它以 190 毫秒的延迟实时运行，比现有的先想象后执行 WAM 快 $4 \times$ 倍以上。这些结果表明，WAM 中视频预测的主要价值可能在于训练期间改进世界表征，而非测试时生成未来观测。

1 引言

构建通用具身智能体需要不仅能将视觉观测映射到动作，还能推理物理世界在交互下如何演化的策略。这激发了人们对世界动作模型（World Action Models, WAMs）日益增长的兴趣，WAM 将未来视觉预测和动作建模统一在一个框架中。与标准的视觉-语言-动作（VLA）模型相比，WAM 具有吸引力，因为建模未来观测可能有助于捕捉物理动态和任务相关的时间结构。

现有的大多数世界-行动模型（World-Action Model, WAM）遵循先想象后执行的范式：首先生成未来观测，然后基于想象的未来预测动作。尽管直观，但这种设计由于迭代视频去噪 [1, 2, 3, 4, 5] 导致显著的测试时延迟。更根本的是，显式的未来想象是否真的对强大的动作性能必要，目前仍不清楚。WAM 的有效性可能源于两个不同的来源：（1）训练期间的视频预测目标，这可能帮助模型获得更强的物理先验和动作条件表示；（2）推理期间的显式未来生成，这可能为动作预测提供额外的预见。现有的 WAM 系统通常将这两个因素纠缠在一起，使得难以确定哪一个实际上对观察到的增益负责。




图 1: 三种代表性的 WAM 范式。(A) 联合建模 WAM 同时去噪未来视频和动作标记。(B) 因果 WAM 首先生成未来观测, 然后基于生成的未来表示条件化动作预测。(C) 快速 WAM 在训练期间保留视频协同训练, 但在推理时移除显式未来生成, 直接从潜在世界表示中单次前向传递预测动作。

在本文中, 我们重新审视这一设计选择, 并提出一个简单的问题: WAM 是否需要在测试时想象未来观测, 还是主要从训练期间学习建模它们中获益? 我们的核心思想是将 WAM 训练中使用的视频预测目标与推理时的显式未来生成解耦。如果世界建模的主要价值在于训练期间塑造更好的潜在表示, 那么 WAM 应该能够保留这一益处, 而无需承担未来视频合成的测试时成本。

基于这一视角, 本文提出快速世界-动作模型 (**Fast-WAM**), 这是一种在训练阶段保留视频协同训练、但在测试阶段跳过未来预测的世界-动作模型架构。**Fast-WAM** 不再使用预训练视频生成模型在推理过程中迭代合成未来帧, 而是将预训练视频扩散 Transformer (Diffusion Transformer, DiT) 重新用作单次前向的世界编码器以生成动作。具体而言, 如图 1(C) 所示, 本文采用具有共享注意力的混合 Transformer (Mixture-of-Transformer, MoT) 架构构建 **Fast-WAM**, 该架构由一个视频 DiT 和一个动作专家 DiT 组成。在训练阶段, 视频预测目标促使视频 DiT 编码具有物理意义的运动和交互结构。在推理阶段, 视频 DiT 通过单次前向传播处理观测上下文, 并为动作去噪提供潜在世界表征, 从而避免显式的未来视频去噪, 实现高效的实时控制。

为以受控方式研究核心问题, 本文将 Fast-WAM 实例化为多个变体, 以对应具有代表性的“先想象后执行”世界-动作模型设计。为简化起见, 本文聚焦于单动作块生成, 并省略外部自回归循环。如图 1 所示, 现有世界-动作模型可大致分为两种代表性范式: (A) 未来视频与动作通过共享注意力联合去噪 [4, 6, 5]; (B) 在生成未来视频之后, 以其为条件预测动作 [3, 7, 8]。本文还实现了一个无视频协同训练的变体, 作为对训练目标本身作用的直接对照。这些受控比较共同使本文能够将测试时未来想象的作用与训练期间视频协同训练的作用分离开来。

在仿真基准 (LIBERO 和 RoboTwin) 上的实验表明, Fast-WAM 在没有任何具身预训练的情况下取得了优异结果, 展现出强大的数据效率。在真实世界机器人任务中, Fast-WAM 依然表现出色, 且运行延迟仅为 190 毫秒, 比现有“先想象后执行”世界-动作模型方法快 $4 \times$ 倍以上。更重要的是, 受控比较显示, Fast-WAM 的性能接近“先想象后执行”变体, 而去除视频协同训练目标会导致更大的性能下降。这些结果

表明，视频预测在世界-动作模型中的主要价值可能在于训练期间改进世界表征，而非在测试时显式生成未来观测。

本文的贡献有三方面：

- 本文识别并研究了一个关于世界行动模型（World Action Models, WAMs）的基本问题：其性能提升主要来源于训练期间的视频建模，还是推理期间的显式未来想象。
- 本文提出快速世界行动模型（Fast-WAM），该架构在训练期间保留视频协同训练，同时在测试时消除未来预测，从而实现实时推理。
- 通过在仿真和真实世界基准上的受控比较，包括有视频协同训练和无视频协同训练的变体，本文表明世界行动模型的大部分收益来自视频协同训练目标本身，而推理时的显式未来生成似乎不如先前假设的那样关键。

2 相关工作

视觉-语言-动作策略。具身基础模型的最新进展由视觉-语言-动作（Vision-Language-Action, VLA）策略驱动，这些策略利用大规模预训练的视觉-语言骨干网络直接将视觉观察和语言指令映射为机器人动作 [9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19]。通过继承网络规模预训练的强大语义先验，这些模型在物体、场景和语言指令方面表现出强大的泛化能力。然而，正如最近的世界行动模型工作所指出的，标准视觉-语言-动作预训练主要基于静态图像-文本数据，并未显式建模物理世界在动作作用下的演化过程 [3, 4]。本文的工作与这一方向互补：快速世界行动模型在测试时保留了与视觉-语言-动作模型类似的直接策略接口，但在额外的基于未来视觉预测的世界建模目标下学习该接口。

世界行动模型与基于视频的机器人策略。另一条并行的工作线通过未来视觉预测研究机器人控制，利用视频生成作为建模环境动态和推断动作的方式 [8, 20, 21, 7, 22, 23, 24, 25, 26, 27, 28, 29, 30, 31]。近期方法进一步扩展这一思想，在统一框架中联合建模未来视频和机器人动作 [6, 2, 32, 33, 1, 3, 5, 4]。我们沿用 [4] 的提法，将这些模型称为世界动作模型（World Action Models, WAMs），因为它们利用世界建模，即预测未来视觉状态，来支持下游动作预测。现有的大多数世界动作模型要么遵循先想象后执行的范式，即首先生成未来视觉轨迹，然后用于动作预测，要么在共享生成过程中联合建模未来视频和动作。我们的工作与这一方向最为接近，但关注点不同：我们并非提出另一种先想象后执行的世界动作模型，而是研究世界动作模型的收益主要来自训练期间的视频协同训练，还是来自推理期间的显式未来想象。

我们的工作也与近期利用视频建模进行动作预测、同时减少或绕过显式测试时视频合成的工作相关。VPP[34] 将机器人策略条件化于从视频扩散模型中提取的预测性视觉表示，而 UVA[35] 联合建模视频和动作，并在测试时跳过视频解码以加快推理速度。与这些工作相比，我们的重点是在共享框架下通过受控变体，厘清训练时视频协同训练与测试时未来想象各自的相对作用。

3 方法

3.1 问题表述

我们考虑从视觉观察和语言指令中进行具身策略学习。设 o 表示当前观察， l 表示任务指令， $a_{1:H}$ 表示长度为 H 的动作块。标准视觉运动策略建模条件分布

$$p(a_{1:H} \mid o, l), \quad (1)$$

该分布直接将当前感知上下文映射到动作序列。世界动作模型（World Action Models, WAMs）通过引入未来视觉观察作为中间变量来增强这一表述。

变量。设 $v_{1:T}$ 表示预测时域 T 内的未来视觉观察。许多现有的世界动作模型遵循先想象后执行的分解方式：

$$p(a_{1:H} | o, l) = \int p(v_{1:T} | o, l) p(a_{1:H} | o, l, v_{1:T}) dv_{1:T}, \quad (2)$$

其中模型首先预测未来观测，然后以想象的未来为条件生成动作。在实践中，这通常通过两种方式实现：在共享模型中联合去噪未来视频和动作，或者先生成未来视频，再将其输入逆动力学或动作预测模块。一些先前的工作进一步将这种形式包裹在外层自回归展开中，为简洁和受控比较起见，本文省略这一部分。

本文的出发点是观察到世界-动作模型的有效性可能源于两个不同因素：（i）训练中使用的视频预测目标，可促使模型学习具有物理意义的潜在表示；（ii）推理时显式生成未来，可为动作预测提供额外预见。现有的世界-动作模型通常将这两个因素耦合在一起，因为同一模型既从未来视频预测中学习，又在测试时显式合成未来观测。本文设计快速世界-动作模型以解耦这两个因素。训练期间，它保留世界建模作为协同训练信号；然而推理期间，它不显式生成未来观测。相反，快速世界-动作模型直接从当前观测和指令预测动作，

$$p_{\theta}(a_{1:H} | o, l), \quad (3)$$

同时使用由视频协同训练塑造的潜在世界表示。从这个意义上说，快速世界-动作模型在测试时具有直接策略接口，类似于标准视觉-语言-动作策略，而其表示学习在训练期间仍以世界-动作模型风格的视频建模为基础。形式上，令 $z(o, l)$ 表示由视频骨干网络以当前上下文为条件产生的潜在世界表示。快速世界-动作模型使用该表示来参数化动作分布，

$$p_{\theta}(a_{1:H} | o, l) = p_{\theta}(a_{1:H} | z(o, l)). \quad (4)$$

与先想象后执行的世界-动作模型的关键区别在于， $z(o, l)$ 是通过单次前向编码获得，而不是在推理时显式采样或去噪未来观测 $v_{1:T}$ 。

3.2 模型架构

概述。Fast-WAM 旨在保留世界模型在训练中的优势，同时消除推理时显式未来想象的计算成本。在训练阶段，它联合学习动作预测与视频建模，促使视觉骨干网络捕捉具有物理意义的运动与交互结构。在推理阶段，Fast-WAM 不显式生成未来观测。相反，它仅保留第一帧观测的干净潜在令牌，通过视频模型单次前向传播处理这些令牌，并利用得到的潜在世界表征直接生成动作。这使得 Fast-WAM 在测试时具备直接策略接口，同时在训练期间保留 WAM 风格的视频监督。

架构。Fast-WAM 构建于 Wan2.2-5B [36] 的视频扩散 Transformer (DiT) 之上，该模型作为世界建模骨干。我们同时复用其预训练的文本编码器和视频 VAE：任务语言由内置的 T5 编码器编码，并通过交叉注意力提供给所有令牌；视觉观测则由预训练的 VAE 映射为潜在视频令牌。在此骨干之上，我们引入一个动作专家 DiT 用于动作块生成。整个模型组织为 Transformer 混合 (Mixture-of-Transformer, MoT) 架构，视频分支与动作分支之间共享注意力，如图 2a 所示。

我们将输入令牌分为三组：第一帧观测的干净潜在令牌，作为共享的视觉锚点；未来视频帧的噪声潜在令牌，仅在训练期间用于视频建模；以及动作令牌，由动作专家处理以生成动作。所有令牌组通过交叉注意力关注语言嵌入。结构化注意力掩码控制这些组之间的信息流。在训练期间，未来噪声视频令牌在视频分支内双向关注，并可访问干净的第一帧令牌；动作令牌在动作分支内双向关注，也可访问干净的第一帧令牌。关键的是，动作令牌不能关注未来视频令牌，并且




图 2: Fast-WAM 架构及用于将视频协同训练与动作生成解耦的结构化注意力掩码。

干净的首帧令牌不关注任何其他令牌。这确保了视频建模和动作预测都基于相同的视觉上下文，同时防止未来信息泄漏到动作分支中。我们在图 2b 中提供了完整的训练和推理掩码。

在推理时，Fast-WAM 完全移除了未来视频分支：仅保留干净的首帧潜在令牌，并通过视频骨干网络一次以生成供动作专家使用的潜在世界特征。由于没有实例化未来噪声视频令牌，也没有执行显式的未来视频去噪，Fast-WAM 的推理成本显著低于标准的先想象后执行的世界-动作模型。

训练目标。 Fast-WAM 采用动作令牌和未来视频潜在变量的联合流匹配目标进行训练。给定目标变量 y （动作块 $a_{1:H}$ 或未来视频潜在变量 $z_{1:T}$ ），我们采样高斯噪声 $\epsilon \sim \mathcal{N}(0, I)$ 和时间步 $t \in (0, 1)$ ，并构造插值样本

$$y_t = (1 - t)y + t\epsilon. \quad (5)$$

模型通过标准流匹配目标来预测相应的速度场

$$\mathcal{L}_{\text{FM}}(y) = \mathbb{E}_{y, \epsilon, t} \left[\|f_{\theta}(y_t, t, o, l) - (\epsilon - y)\|_2^2 \right]. \quad (6)$$

我们为动作生成和视频协同训练实例化该目标。对于动作预测，我们设置 $y = a_{1:H}$ 并进行优化

$$\mathcal{L}_{\text{act}} = \mathcal{L}_{\text{FM}}(a_{1:H}). \quad (7)$$

对于视频协同训练，我们设置 $y = z_{1:T}$ ，其中 $z_{1:T}$ 表示由预训练变分自编码器产生的未来视频帧的潜在令牌，并进行优化

$$\mathcal{L}_{\text{vid}} = \mathcal{L}_{\text{FM}}(z_{1:T}). \quad (8)$$

总体训练目标为

$$\mathcal{L} = \mathcal{L}_{\text{act}} + \lambda \mathcal{L}_{\text{vid}}, \quad (9)$$

其中 λ 平衡了动作学习与视频协同训练。

3.3 用于解耦世界-动作模型设计的受控变体

为了回答我们的核心问题，即世界-动作模型的优势主要来自训练期间的视频协同训练，还是来自推理期间的显式未来想象，我们在一个共享的实现框架下设计了一组受控变体。我们实例化了具有代表性的

近期世界-动作模型中的“先想象后执行”设计模式，同时尽可能保持骨干网络、分词和训练方案一致。这种受控设置使我们能够将测试时未来生成的贡献与视频协同训练目标本身的贡献分离开来。

如图 1(A) 和 (B) 所示，我们考虑了两种具有代表性的“先想象后执行”变体，它们捕捉了近期世界-动作模型中的主流设计模式。第一种变体名为 Fast-WAM-Joint，遵循联合生成范式，其中未来视频令牌和动作令牌在共享模型内一起去噪，因此动作生成在整个去噪过程中始终与未来视频建模耦合 [4, 6, 5]。第二种变体名为 Fast-WAM-IDM，遵循“先视频后动作”范式，其中首先从当前观测和语言上下文生成未来视频令牌，然后基于得到的未来表示进行动作预测 [3, 7, 8]。在这两种情况下，我们都保留了相应范式的定义性推理结构，以及近期世界-动作模型中使用的关键训练选择，同时在我们的共享框架内实现它们，以便与 Fast-WAM 进行受控比较。

我们进一步构建了一个没有视频协同训练的 Fast-WAM 变体。该变体保持架构和推理过程不变，仅在训练期间移除视频建模目标。因此，它作为视频协同训练本身作用的直接对照。这些受控变体共同分离了先前世界-动作模型中通常纠缠在一起的两个因素：训练期间的视频协同训练和推理期间的显式未来想象。

4 实验

4.1 实现细节

我们采用预训练的万 2.2-5B 模型 [36] 作为骨干网络，包括其视频扩散变换器、文本编码器和视频变分自编码器。动作专家与视频分支共享相同的架构，但使用缩减的隐藏维度 $d_a = 1024$ ，从而得到 10 亿参数的动作专家，总模型规模为 60 亿参数。我们将动作预测范围设置为 $h = 32$ 。视频帧在时间维度上进行 $4\times$ 倍下采样，每个块得到 9 帧视频。来自多个摄像头的图像在输入变分自编码器之前被拼接成单张图像。

我们对视频和动作分支采用相同的流匹配公式。遵循 [36]，在训练和推理过程中，我们采用对数正态分布作为 t 上的噪声调度。在推理过程中，我们使用 10 步去噪，无分类器引导 (Classifier-Free Guidance) 尺度设为 1.0。所有训练设置均使用 AdamW 优化器，学习率为 1×10^{-4} ，权重衰减为 0.01，并采用余弦退火调度。训练以混合精度进行，梯度裁剪阈值为 1.0。所有延迟数据均在单块 NVIDIA RTX 5090D V2 32GB GPU 上测量。

我们通过允许视频和动作标记之间的注意力来构建快速 WAM 联合模型。对于快速 WAM-IDM，我们遵循 [3]，以概率对真实 $p = 0.5$ 。视频标记应用噪声增强

4.2 实验设置

我们在仿真基准上评估快速 WAM 及其变体，包括 LIBERO[37] 和 RoboTwin 2.0[38]，以及一个真实世界的操作任务。

LIBERO. We follow the standard benchmarking protocol and train our models on the four LIBERO suites: LIBERO-Spatial, LIBERO-Object, LIBERO-Goal, and LIBERO-Long. Each suite contains 500 demonstrations spanning 10 tasks. All models are trained for 20k steps. We report success rates for each suite, evaluated over a total of 2000 trials across 40 tasks with different random seeds.

RoboTwin 2.0. RoboTwin 2.0 是一个具有挑战性的双臂操作基准，包含 50 多个需要协调双臂控制的任务。我们遵循 [5, 3] 的多任务训练设置，模型在干净场景中收集的 2500 条演示和重度场景随机化下收集的 25000 条演示的混合数据上进行训练，覆盖 50 多个任务。所有模型训练 30000 步。我们报告在干净和随机化设置下每个任务 100 次试验的平均成功率。




图 3: 在 Galaxea R1 Lite 平台上的真实世界毛巾折叠任务。折叠可变形物体需要长时程规划和精确的闭环操作, 使其成为评估任务成功率和执行效率的具有挑战性的基准。

表 1: RoboTwin 上的结果。Fast-WAM 在不使用具身预训练的情况下, 与强大的预训练 WAM 基线相当, 而两种先想象后执行的变体仍高度可比, 移除视频协同训练则导致性能显著下降。

Method	Embodied PT.	Clean	Rand.	Average
π_0 [10]	✓	65.92	58.40	62.2
$\pi_{0.5}$ [11]	✓	82.74	76.76	79.8
Motus [5]	✓	88.66	87.02	87.8
Motus from WAN2.2	✗	77.56	77.00	77.3
LingBot-VA [3]	✓	92.90	91.50	92.2
LingBot-VA from WAN2.2	✗	80.60	–	80.6
Fast-WAM (Ours)	✗	91.88	91.78	<u>91.8</u>
<i>Fast-WAM Variants</i>				
Fast-WAM	✗	91.88	91.78	91.8
Fast-WAM-Joint	✗	90.84	90.32	90.6
Fast-WAM-IDM	✗	91.16	91.34	<u>91.3</u>
Fast-WAM w.o. video co-train	✗	82.76	84.80	83.8

真实世界评估。我们在毛巾折叠这一长时程且具有挑战性的任务上进行真实世界评估, 该任务要求策略推理可变形物体的动力学, 如图 3 所示。我们在 Galaxea R1 Lite 平台上收集了 60 小时的遥操作演示。所有模型均训练 30k 步。我们报告平均成功率和平均完成时间。前者衡量策略在给定充足时间的情况下是否最终能完成折叠任务, 后者反映策略是否学习到高效的执行策略, 而非依赖反复试错修正。因此, 对于该任务, 完成时间与成功率在评估策略质量时同等重要。

4.3 主要结果

4.3.1 仿真基准上的总体比较

表 1 和表 2 分别总结了 RoboTwin 和 LIBERO 上的结果。总体而言, Fast-WAM 在不使用具身预训练的情况下, 在两个基准上均达到了与最先进方法相当的性能。RoboTwin 上的各项任务结果列于附录 3。

在 RoboTwin 上, Fast-WAM 达到了 91.8% 的成功率, 超过了所有不使用具身预训练的基线, 并与最强的预训练 WAM 保持高度竞争力。特别是, Fast-WAM 显著优于 Motus [5] (预训练 87.8%, 无预训练 77.3%) 以及无预训练的 LingBot-VA [3] (80.6%), 同时与预训练的 LingBot-VA (92.2%) 保持可比。这些结果表明, Fast-WAM 能够在不依赖具身预训练的情况下, 恢复先前 WAM 流程的大部分优势。

表 2: LIBERO 上的结果。Fast-WAM 在不使用具身预训练的情况下实现了具有竞争力的总体性能，与两种先想象后执行的变体保持接近，并以明显优势超越了无视频协同训练的消融实验。

Method	Embodied PT.	Spatial	Object	Goal	Long	Average
OpenVLA [9]	✓	84.7	88.4	79.2	53.7	76.5
π_0 [10]	✓	96.8	98.8	95.8	85.2	94.1
$\pi_{0.5}$ [11]	✓	98.8	98.2	98.0	92.4	96.9
LingBot-VA [3]	✓	98.5	99.6	97.2	98.5	98.5
Motus [5]	✓	96.8	99.8	96.6	97.6	97.7
Fast-WAM (Ours)	✗	98.2	100.0	97.0	95.2	97.6
<i>Fast-WAM Variants</i>						
Fast-WAM	✗	98.2	100.0	97.0	95.2	97.6
Fast-WAM-Joint	✗	99.6	99.4	98.2	96.8	98.5
Fast-WAM-IDM	✗	98.8	97.8	97.8	97.6	98.0
Fast-WAM w.o. video co-train	✗	89.2	99.2	95.4	90.0	93.5

在 LIBERO 上，Fast-WAM 同样展现出强劲的整体性能，在未使用具身预训练的情况下平均成功率达到 97.6%。它超越了强大的 VLA 基线 $\pi_{0.5}$ ，并与经过预训练的 WAM 基线（如 LingBot-VA 的 98.5% 和 Motus 的 97.7%）保持竞争力。这些结果表明，Fast-WAM 在多种仿真基准上始终有效，即使没有采用大多数先前 WAM 和 VLA 基线所使用的具身预训练。

4.3.2 与 Fast-WAM 变体的受控比较

接下来，我们将 Fast-WAM 与第 3.3 节中引入的受控变体进行比较，以区分推理时显式未来想象与训练时视频协同训练的作用。在两个仿真基准上，整体模式一致：Fast-WAM 与两种先想象后执行的变体保持可比性，而去除视频协同训练会导致更大的性能下降。

在 RoboTwin 上，Fast-WAM 的成功率达到 91.8%，与 Fast-WAM-Joint (90.6%) 和 Fast-WAM-IDM (91.3%) 高度可比。相比之下，去除视频协同训练后性能降至 83.8%，与所有三个采用视频协同训练的变体之间存在显著差距。这一结果表明，在该基准上，训练期间保留视频建模目标远比在测试时显式生成未来观测更为重要。LIBERO 上也呈现类似趋势。Fast-WAM 的平均成功率达到 97.6%，与 Fast-WAM-Joint (98.5%) 和 Fast-WAM-IDM (98.0%) 接近。相比之下，去除视频协同训练的 Fast-WAM 降至 93.5%，在 Spatial 和 Long 子集上退化尤为明显。同样，去除视频协同训练造成的差距明显大于 Fast-WAM 与先想象后执行变体之间的差距。

这一模式表明，WAM 式训练的主要收益可能不在于测试时是否或如何进行未来想象，而更多在于训练期间用于塑造世界基础表征的视频预测目标。

4.3.3 真实世界性能与效率

我们进一步在长时程真实世界毛巾折叠任务上评估 Fast-WAM。我们同时报告平均成功率和平均完成时间，因为它们反映了策略质量的两个同等重要的方面：策略是否最终能完成任务，以及是否高效完成而非通过反复试错修正。结果如图 4 所示。

在该任务上，预训练 $\pi_{0.5}$ 仍是最强方法，同时取得最高成功率和最短完成时间。在快速加权平均 (Fast-WAM) 系列中，整体性能相当，其中快速加权平均-逆动力学模型 (Fast-WAM-IDM) 取得最高成功率，而快速加权平均 (Fast-WAM) 获得更好的完成时间。重要的是，所有带视频协同训练的快速加权平均变体在没有预训练的情况下均大幅超越 $\pi_{0.5}$ ，表明加权平均风格的视频协同训练即使没有具身预训练也能提供强大的数据效率。




图 4: 长时程毛巾折叠任务的真实世界结果。左图绘制成功率与平均完成时间的关系，左上角为更优。右图比较推理延迟。快速加权平均（Fast-WAM）以显著低于想象后执行变体的延迟实现强大的真实世界性能，而去除视频协同训练会同时降低成功率和完成时间。

相比之下，去除视频协同训练会导致两项指标急剧下降：无视频协同训练的快速加权平均（Fast-WAM）成功率降至仅 10%，且在所有方法中完成时间最长。这一差距远大于快速加权平均变体之间的差异，表明视频协同训练是强大真实世界性能的主导因素，而测试时未来想象的影响相对有限。

在运行时间方面，快速加权平均（Fast-WAM）保持低推理延迟（190 毫秒），而想象后执行变体明显更慢，尤其是快速加权平均-逆动力学模型（Fast-WAM-IDM）达到 810 毫秒。这使得快速加权平均（Fast-WAM）成为真实世界部署中更有利的设计选择，在提供强大任务性能的同时大幅降低推理成本。

5 结论

本文重新审视了世界动作模型中的一个基本问题：其性能提升主要源于测试时的显式未来想象，还是训练期间的视频建模。为研究这一问题，本文提出了快速世界动作模型，该架构在训练期间保留视频协同训练，而在推理时跳过未来预测，从而能够直接从基于世界的潜在表示生成动作。在仿真基准和真实机器人任务中，快速世界动作模型无需具身预训练即可实现实时运行下的优异性能。更重要的是，受控比较表明，快速世界动作模型与先想象后执行变体相比仍具竞争力，而去除视频协同训练则会导致性能大幅下降。这些结果表明，视频预测在世界动作模型中的主要价值可能更多在于训练期间学习更好的世界表示，而非测试时生成未来观测。未来工作的一个重要方向是研究更大规模的预训练数据和模型扩展对该设计的影响。

参考文献

- [1] Jonas Pai, Liam Achenbach, Victoriano Montesinos, Benedek Forrai, Oier Mees, and Elvis Nava. mimic-video: Video-action models for generalizable robot control beyond vlas. *arXiv preprint 2512.15692*, 2025.
- [2] Junbang Liang, Pavel Tokmakov, Ruoshi Liu, Sruthi Sudhakar, Paarth Shah, Rares Ambrus, and Carl Vondrick. Video generators are robot policies. *arXiv preprint arXiv:2508.00795*, 2025.
- [3] Lin Li, Qihang Zhang, Yiming Luo, Shuai Yang, Ruilin Wang, Fei Han, Mingrui Yu, Zelin Gao, Nan Xue, Xing Zhu, Yujun Shen, and Yinghao Xu. Causal world modeling for robot control. *arXiv preprint arXiv:2601.21998*, 2026.
- [4] Seonghyeon Ye, Yunhao Ge, Kaiyuan Zheng, Shenyuan Gao, Sihyun Yu, George Kurian, Suneel Indupuru, You Liang Tan, Chuning Zhu, Jiannan Xiang, Ayaan Malik, Kyungmin Lee, William Liang, Nadun Ranawaka, Jiasheng Gu, Yinzhen Xu, Guanzhi Wang, Fengyuan Hu, Avnish Narayan, Johan Bjorck, Jing Wang, Gwanghyun Kim, Dantong Niu, Ruijie Zheng, Yuqi Xie, Jimmy Wu, Qi Wang, Ryan Julian, Danfei Xu, Yilun Du, Yevgen Chebotar, Scott Reed, Jan Kautz, Yuke Zhu, Linxi "Jim" Fan, and Joel Jang. World action models are zero-shot policies, 2026. URL <https://arxiv.org/abs/2602.15922>.
- [5] Hongzhe Bi, Hengkai Tan, Shenghao Xie, Zeyuan Wang, Shuhe Huang, Haitian Liu, Ruowen Zhao, Yao Feng, Chendong Xiang, Yinze Rong, Hongyan Zhao, Hanyu Liu, Zhizhong Su, Lei Ma, Hang Su, and Jun Zhu. Motus: A unified latent action world model, 2025. URL <https://arxiv.org/abs/2512.13030>.
- [6] Chuning Zhu, Raymond Yu, Siyuan Feng, Benjamin Burchfiel, Paarth Shah, and Abhishek Gupta. Unified world models: Coupling video and action diffusion for pretraining on large robotic datasets, 2025. URL <https://arxiv.org/abs/2504.02792>.
- [7] Yao Feng, Hengkai Tan, Xinyi Mao, Chendong Xiang, Guodong Liu, Shuhe Huang, Hang Su, and Jun Zhu. Vidar: Embodied video diffusion model for generalist manipulation, 2025. URL <https://arxiv.org/abs/2507.12898>.
- [8] Yilun Du, Mengjiao Yang, Bo Dai, Hanjun Dai, Ofir Nachum, Joshua B. Tenenbaum, Dale Schuurmans, and Pieter Abbeel. Learning universal policies via text-guided video generation, 2023. URL <https://arxiv.org/abs/2302.00111>.
- [9] Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, Ted Xiao, Ashwin Balakrishna, Suraj Nair, Rafael Rafailov, Ethan Foster, Grace Lam, Pannag Sanketi, et al. Openvla: An open-source vision-language-action model. *arXiv preprint arXiv:2406.09246*, 2024.
- [10] Kevin Black, Noah Brown, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Lachy Groom, Karol Hausman, Brian Ichter, et al. π_0 : A vision-language-action flow model for general robot control. *arXiv preprint arXiv:2410.24164*, 2024.
- [11] Physical Intelligence, Kevin Black, Noah Brown, James Darpinian, Karan Dhabalia, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, et al. $\pi_{0.5}$: a vision-language-action model with open-world generalization. *arXiv preprint arXiv:2504.16054*, 2025.
- [12] Johan Bjorck, Fernando Castañeda, Nikita Cherniadev, Xingye Da, Runyu Ding, Linxi Fan, Yu Fang, Dieter Fox, Fengyuan Hu, Spencer Huang, et al. Gr00t n1: An open foundation model for generalist humanoid robots. *arXiv preprint arXiv:2503.14734*, 2025.
- [13] Brianna Zitkovich, Tianhe Yu, Sichun Xu, Peng Xu, Ted Xiao, Fei Xia, Jialin Wu, Paul Wohlhart, Stefan Welker, Ayzaan Wahid, et al. Rt-2: Vision-language-action models transfer web knowledge to robotic control. In *Conference on Robot Learning*, pages 2165–2183. PMLR, 2023.
- [14] Songming Liu, Lingxuan Wu, Bangguo Li, Hengkai Tan, Huayu Chen, Zhengyi Wang, Ke Xu, Hang Su, and Jun Zhu. Rdt-1b: a diffusion foundation model for bimanual manipulation. *arXiv preprint arXiv:2410.07864*, 2024.

- [15] Qingwen Bu, Jisong Cai, Li Chen, Xiuqi Cui, Yan Ding, Siyuan Feng, Shenyuan Gao, Xindong He, Xuan Hu, Xu Huang, et al. Agibot world colosseum: A large-scale manipulation platform for scalable and intelligent embodied systems. *arXiv preprint arXiv:2503.06669*, 2025.
- [16] Mustafa Shukor, Dana Aubakirova, Francesco Capuano, Pepijn Kooijmans, Steven Palma, Adil Zouitine, Michel Aractingi, Caroline Pascal, Martino Russi, Andres Marafioti, et al. Smolvla: A vision-language-action model for affordable and efficient robotics. *arXiv preprint arXiv:2506.01844*, 2025.
- [17] Gemini Robotics Team, Saminda Abeyruwan, Joshua Ainslie, Jean-Baptiste Alayrac, Montserrat Gonzalez Arenas, Travis Armstrong, Ashwin Balakrishna, Robert Baruch, Maria Bauza, Michiel Blokzijl, et al. Gemini robotics: Bringing ai into the physical world. *arXiv preprint arXiv:2503.20020*, 2025.
- [18] Galaxea Team. Galaxea g0: Open-world dataset and dual-system vla model. *arXiv preprint arXiv:2509.00576v1*, 2025.
- [19] Junjie Wen, Yichen Zhu, Jinming Li, Zhibin Tang, Chaomin Shen, and Feifei Feng. Dexvla: Vision-language model with plug-in diffusion expert for general robot control. *arXiv preprint arXiv:2502.05855*, 2025.
- [20] Hongtao Wu, Ya Jing, Chilam Cheang, Guangzeng Chen, Jiafeng Xu, Xinghang Li, Minghuan Liu, Hang Li, and Tao Kong. Unleashing large-scale video generative pre-training for visual robot manipulation, 2023.
- [21] Siyuan Zhou, Yilun Du, Jiaben Chen, Yandong Li, Dit-Yan Yeung, and Chuang Gan. Robodreamer: Learning compositional world models for robot imagination. *arXiv preprint arXiv:2404.12377*, 2024.
- [22] Homanga Bharadhwaj, Debidatta Dwibedi, Abhinav Gupta, Shubham Tulsiani, Carl Doersch, Ted Xiao, Dhruv Shah, Fei Xia, Dorsa Sadigh, and Sean Kirmani. Gen2act: Human video generation in novel scenarios enables generalizable robot manipulation. *arXiv preprint arXiv:2409.16283*, 2024.
- [23] John Won, Kyungmin Lee, Huiwon Jang, Dongyoung Kim, and Jinwoo Shin. Dual-stream diffusion for world-model augmented vision-language-action model, 2025. URL <https://arxiv.org/abs/2510.27607>.
- [24] Chi-Lam Cheang, Guangzeng Chen, Ya Jing, Tao Kong, Hang Li, Yifeng Li, Yuxiao Liu, Hongtao Wu, Jiafeng Xu, Yichu Yang, Hanbo Zhang, and Minzhao Zhu. Gr-2: A generative video-language-action model with web-scale knowledge for robot manipulation. *arXiv preprint arXiv:2410.06158*, 2024.
- [25] Joel Jang, Seonghyeon Ye, Zongyu Lin, Jiannan Xiang, Johan Bjorck, Yu Fang, Fengyuan Hu, Spencer Huang, Kaushil Kundalia, Yen-Chen Lin, Loic Magne, Ajay Mandlekar, Avnish Narayan, You Liang Tan, Guanzhi Wang, Jing Wang, Qi Wang, Yinzhen Xu, Xiaohui Zeng, Kaiyuan Zheng, Ruijie Zheng, Ming-Yu Liu, Luke Zettlemoyer, Dieter Fox, Jan Kautz, Scott Reed, Yuke Zhu, and Linxi Fan. Dreamgen: Unlocking generalization in robot learning through video world models, 2025. URL <https://arxiv.org/abs/2505.12705>.
- [26] Qingqing Zhao, Yao Lu, Moo Jin Kim, Zipeng Fu, Zhuoyang Zhang, Yecheng Wu, Zhaoshuo Li, Qianli Ma, Song Han, Chelsea Finn, Ankur Handa, Ming-Yu Liu, Donglai Xiang, Gordon Wetzstein, and Tsung-Yi Lin. Cot-vla: Visual chain-of-thought reasoning for vision-language-action models, 2025. URL <https://arxiv.org/abs/2503.22020>.
- [27] Jun Cen, Siteng Huang, Yuqian Yuan, Kehan Li, Hangjie Yuan, Chaohui Yu, Yuming Jiang, Jiayan Guo, Xin Li, Hao Luo, Fan Wang, Fan Wang, and Deli Zhao. Rynnvla-002: A unified vision-language-action and world model. *arXiv preprint arXiv:2511.17502*, 2025.
- [28] Jun Cen, Chaohui Yu, Hangjie Yuan, Yuming Jiang, Siteng Huang, Jiayan Guo, Xin Li, Yibing Song, Hao Luo, Fan Wang, Deli Zhao, and Hao Chen. Worldvla: Towards autoregressive action world model. *arXiv preprint arXiv:*, 2025.

- [29] Pengfei Zhou, Liliang Chen, Shengcong Chen, Di Chen, Wenzhi Zhao, Rongjun Jin, Guanghui Ren, and Jianlan Luo. Act2goal: From world model to general goal-conditioned policy, 2025. URL <https://arxiv.org/abs/2512.23541>.
- [30] Ruijie Zheng, Jing Wang, Scott Reed, Johan Bjorck, Yu Fang, Fengyuan Hu, Joel Jang, Kaushil Kundalia, Zongyu Lin, Loic Magne, Avnish Narayan, You Liang Tan, Guanzhi Wang, Qi Wang, Jiannan Xiang, Yinzhen Xu, Seonghyeon Ye, Jan Kautz, Furong Huang, Yuke Zhu, and Linxi Fan. Flare: Robot learning with implicit world modeling, 2025. URL <https://arxiv.org/abs/2505.15659>.
- [31] Wen Yao Zhang, Hongsi Liu, Zekun Qi, Yunan Wang, Xinqiang Yu, Jiazhao Zhang, Runpei Dong, Jiawei He, He Wang, Zhizheng Zhang, Li Yi, Wenjun Zeng, and Xin Jin. Dreamvla: A vision-language-action model dreamed with comprehensive world knowledge. *CoRR*, abs/2507.04447, 2025. doi: 10.48550/ARXIV.2507.04447. URL <https://doi.org/10.48550/arXiv.2507.04447>.
- [32] Moo Jin Kim, Yihuai Gao, Tsung-Yi Lin, Yen-Chen Lin, Yunhao Ge, Grace Lam, Percy Liang, Shuran Song, Ming-Yu Liu, Chelsea Finn, and Jinwei Gu. Cosmos policy: Fine-tuning video models for visuomotor control and planning. *arXiv preprint arXiv:2601.16163*, 2026.
- [33] Yue Liao, Pengfei Zhou, Siyuan Huang, Donglin Yang, Shengcong Chen, Yuxin Jiang, Yue Hu, Jingbin Cai, Si Liu, Jianlan Luo, Liliang Chen, Shuicheng Yan, Maoqing Yao, and Guanghui Ren. Genie envisioner: A unified world foundation platform for robotic manipulation. *arXiv preprint arXiv:2508.05635*, 2025.
- [34] Yucheng Hu, Yanjiang Guo, Pengchao Wang, Xiaoyu Chen, Yen-Jen Wang, Jianke Zhang, Koushil Sreenath, Chaochao Lu, and Jianyu Chen. Video prediction policy: A generalist robot policy with predictive visual representations. *arXiv preprint arXiv:2412.14803*, 2024.
- [35] Shuang Li, Yihuai Gao, Dorsa Sadigh, and Shuran Song. Unified video action model. *arXiv preprint arXiv:2503.00200*, 2025.
- [36] Team Wan, Ang Wang, Baole Ai, Bin Wen, Chaojie Mao, Chen-Wei Xie, Di Chen, Fei Wu Yu, Haiming Zhao, Jianxiao Yang, Jianyuan Zeng, Jiayu Wang, Jingfeng Zhang, Jingren Zhou, Jinkai Wang, Jixuan Chen, Kai Zhu, Kang Zhao, Keyu Yan, Lianghua Huang, Mengyang Feng, Ningyi Zhang, Pandeng Li, Pingyu Wu, Ruihang Chu, Ruili Feng, Shiwei Zhang, Siyang Sun, Tao Fang, Tianxing Wang, Tianyi Gui, Tingyu Weng, Tong Shen, Wei Lin, Wei Wang, Wei Wang, Wenmeng Zhou, Wenten Wang, Wenting Shen, Wenyuan Yu, Xianzhong Shi, Xiaoming Huang, Xin Xu, Yan Kou, Yangyu Lv, Yifei Li, Yijing Liu, Yiming Wang, Yingya Zhang, Yitong Huang, Yong Li, You Wu, Yu Liu, Yulin Pan, Yun Zheng, Yuntao Hong, Yupeng Shi, Yutong Feng, Zeyinzi Jiang, Zhen Han, Zhi-Fan Wu, and Ziyu Liu. Wan: Open and advanced large-scale video generative models. *arXiv preprint arXiv:2503.20314*, 2025.
- [37] Bo Liu, Yifeng Zhu, Chongkai Gao, Yihao Feng, Qiang Liu, Yuke Zhu, and Peter Stone. Libero: Benchmarking knowledge transfer for lifelong robot learning. *arXiv preprint arXiv:2306.03310*, 2023.
- [38] Tianxing Chen, Zhanxin Chen, Baijun Chen, Zijian Cai, Yibin Liu, Zixuan Li, Qiwei Liang, Xianliang Lin, Yiheng Ge, Zhenyu Gu, et al. Robotwin 2.0: A scalable data generator and benchmark with strong domain randomization for robust bimanual robotic manipulation. *arXiv preprint arXiv:2506.18088*, 2025.

A 附录

A.1 机器人孪生详细结果

表 3 展示了机器人孪生评估中每个任务的结果。

表 3: 在干净和随机化评估设置下机器人孪生的每任务成功率。

Task	Fast-WAM (Ours)		Fast-WAM-Joint		Fast-WAM-IDM		Fast-WAM w.o. co-train		LingBot-VA		$\pi_{0.5}$		Motus	
	Clean	Rand.	Clean	Rand.	Clean	Rand.	Clean	Rand.	Clean	Rand.	Clean	Rand.	Clean	Rand.
Adjust Bottle	100	100	98	99	94	99	98	100	90	94	100	99	89	93
Beat Block Hammer	99	97	100	98	98	98	80	92	96	98	96	93	95	88
Blocks Ranking RGB	100	100	100	100	100	99	88	86	99	98	92	85	99	97
Blocks Ranking Size	94	98	83	91	79	90	56	62	94	96	49	26	75	63
Click Alarmclock	100	100	100	100	98	100	100	98	99	100	98	89	100	100
Click Bell	100	100	100	98	100	96	100	100	100	100	99	66	100	100
Dump Bin Bigbin	97	96	95	95	93	98	92	94	89	96	92	97	95	91
Grab Roller	100	100	100	100	100	100	100	100	100	100	100	100	100	100
Handover Block	95	81	93	91	97	94	58	46	99	78	66	57	86	73
Handover Mic	99	100	100	100	98	99	100	100	94	96	98	97	78	63
Hanging Mug	58	62	71	56	66	62	28	40	40	28	18	17	38	38
Lift Pot	100	100	100	100	100	100	92	90	100	99	96	85	96	99
Move Can Pot	90	88	97	99	97	100	80	68	94	97	51	55	34	74
Move Pillbottle Pad	100	99	99	100	98	100	88	96	99	99	84	61	93	96
Move Playingcard Away	100	100	100	100	99	100	94	96	100	99	96	84	100	96
Move Stapler Pad	77	64	85	81	89	85	64	78	91	79	56	42	83	85
Open Laptop	98	100	89	92	92	92	100	98	92	94	90	96	95	91
Open Microwave	62	45	3	14	54	53	46	52	82	86	34	77	95	91
Pick Diverse Bottles	80	85	86	87	87	89	58	62	89	82	81	71	90	91
Pick Dual Bottles	100	96	98	99	100	98	80	74	100	99	93	63	96	90
Place A2B Left	95	93	96	96	97	96	84	92	97	93	87	82	88	79
Place A2B Right	93	99	95	95	94	98	88	84	97	95	87	84	91	87
Place Bread Basket	91	93	89	94	91	97	74	76	97	95	77	64	91	94
Place Bread Skillet	90	93	90	93	90	95	98	84	95	90	85	66	86	83
Place Burger Fries	96	99	100	100	97	99	94	96	97	95	94	87	98	98
Place Can Basket	71	69	50	23	37	28	72	72	81	84	62	62	81	76
Place Cans Plasticbox	99	96	98	98	98	96	98	96	100	99	94	84	98	94
Place Container Plate	96	100	99	98	100	96	94	98	99	97	99	95	98	99
Place Dual Shoes	94	88	93	89	85	87	80	74	94	89	75	75	93	87
Place Empty Cup	100	100	100	100	100	100	100	100	100	100	100	99	99	98
Place Fan	96	96	99	96	97	95	80	88	99	93	87	85	91	87
Place Mouse Pad	83	89	96	91	97	93	64	76	93	96	60	39	66	68
Place Object Basket	89	88	86	81	87	82	82	90	91	88	80	76	81	87
Place Object Scale	90	97	96	99	99	99	86	80	96	95	86	80	88	85
Place Object Stand	90	94	92	98	96	100	82	92	99	96	91	85	98	97
Place Phone Stand	97	99	100	100	99	99	90	92	97	97	81	81	87	86
Place Shoe	96	99	95	97	95	98	92	90	98	98	92	93	99	97
Press Stapler	90	97	52	50	50	57	80	80	85	82	87	83	93	98
Put Bottles Dustbin	95	90	93	95	97	92	78	88	87	91	84	79	81	79
Put Object Cabinet	94	89	95	90	93	90	88	84	85	87	80	79	88	71
Rotate QRcode	93	89	91	92	91	86	82	78	96	91	89	87	89	73
Scan Object	89	92	92	92	93	90	78	86	96	91	72	65	67	66
Shake Bottle	100	100	100	100	100	100	100	100	100	97	99	97	100	97
Shake Bottle Horizontally	100	100	100	100	100	100	100	100	100	99	99	99	100	98
Stack Blocks Three	95	97	98	97	99	95	90	90	99	98	91	76	91	95
Stack Blocks Two	100	100	100	100	100	100	100	98	100	98	97	100	100	98
Stack Bowls Three	80	81	84	86	85	83	66	82	86	83	77	71	79	87
Stack Bowls Two	92	98	97	95	94	96	90	98	94	98	95	96	98	98
Stamp Seal	90	94	96	99	99	94	60	78	96	97	79	55	93	92
Turn Switch	61	59	73	72	59	74	66	66	44	45	62	54	84	78
Average	91.88	91.78	90.84	90.32	91.16	91.34	82.76	84.80	92.90	91.50	82.74	76.76	88.66	87.02