

GR-3 技术报告

字节跳动种子团队

完整作者列表见贡献与致谢部分

Abstract

本文报告了我们在构建通用机器人策略方面的最新进展，即 GR-3 的开发。GR-3 是一个大规模视觉-语言-动作（VLA）模型。它在泛化到新物体、新环境以及涉及抽象概念的指令方面展现出卓越的能力。此外，它能够利用极少的人类轨迹数据进行高效微调，从而快速且低成本地适应新场景。GR-3 还擅长处理长时程和灵巧操作任务，包括需要双臂操作和移动的任务，展现出稳健可靠的性能。这些能力通过多方面的训练方案实现，包括与网络规模视觉-语言数据的联合训练、利用虚拟现实设备采集的人类轨迹数据进行高效微调，以及利用机器人轨迹数据进行有效的模仿学习。此外，我们推出了 ByteMini，一款多功能双臂移动机器人，具有出色的灵活性和可靠性，与 GR-3 集成后能够完成广泛的任務。通过大量真实世界实验，我们证明 GR-3 在多种具有挑战性的任务上超越了最先进的基线方法 π_0 。我们希望 GR-3 能够成为构建能够协助人类日常生活的通用机器人的一步。

Date: July 23, 2025

Correspondence: wuhongtao.123@bytedance.com

Project Page: <https://seed.bytedance.com/GR3>

1 引言

追求能够协助人类完成日常任务的智能通用机器人一直是机器人研究的长期目标 [3, 7, 9 – 11, 13, 67]。一个关键挑战源于现实世界的巨大多样性，这要求机器人策略具备强大的泛化能力以处理各种新场景。此外，许多日常任务本质上是长时程的，需要复杂的灵巧操作，这要求机器人策略高度稳健可靠。

视觉-语言-动作（Vision-Language-Action, VLA）模型的最新进展 [9, 11, 29, 37, 67] 为开发智能通用机器人策略铺平了一条有前景的道路。这些模型建立在预训练的视觉语言模型（VLM）[4, 14, 19, 39] 之上，并整合了动作预测能力，使机器人能够按照自然语言指令执行广泛的任務。尽管取得了这些进展，指令遵循仍然是一个重大挑战，尤其是对于分布外指令，这些指令涉及机器人轨迹数据中未见的新物体类别和/或需要复杂推理的复杂概念 [11, 49]。此外，VLA 模型通常需要大量演示来进行策略训练，这给高效适应新环境带来了巨大挑战。最后，由于累积误差，确保复杂长程任务中的鲁棒性仍然具有挑战性，特别是对于涉及灵巧技能的任务，例如操纵可变形物体。



图 1 概述。GR-3 能够从三种类型的数据中学习：视觉-语言数据、机器人轨迹数据和人类轨迹数据。它能够以卓越的鲁棒性执行灵巧和长程任务，并很好地泛化到新物体、环境和指令。

在本报告中，我们介绍了 GR-3，一个大规模视觉-语言-动作（VLA）模型，它 1) 严格遵循语言并能很好地泛化到新物体、环境和指令，2) 从少量人类轨迹数据中高效学习，以快速适应新场景，3) 以高鲁棒性和可靠性执行长时程和灵巧任务（图 1）。GR-3 以自然语言指令、环境观测和机器人状态作为输入，输出动作块，以端到端方式控制双臂移动机器人。具体而言，GR-3 基于预训练的 VLM[2] 构建，并通过流匹配 [47, 48] 预测动作。我们对模型架构进行了细致研究，并引入了一组精心选择的设计选择，我们发现这些选择对于指令遵循能力和长时程任务性能至关重要。为了增强泛化能力，我们在机器人轨迹数据和覆盖各种视觉-语言任务的大规模视觉-语言数据上共同训练 GR-3。这种训练方案使 GR-3 不仅能处理新类别的物体，还能理解与尺寸、空间关系和常识相关的抽象概念（图 2），这些在机器人轨迹数据中是不可见的。此外，我们展示了 GR-3 可以通过 VR 设备收集的最少人类轨迹数据进行高效微调，实现对新场景的快速且经济高效的适应。与 GR-3 一起，我们介绍了 ByteMini，一个多功能双臂移动机器人，设计具有高灵活性和可靠性，能够在现实世界中完成各种具有挑战性的任务。

我们在三个具有挑战性的任务上进行了大量真实世界实验：1) 可泛化的抓取与放置，2) 长时程桌面清理，3) 灵巧布料操作。GR-3 在所有任务上始终优于最先进的基线 π_0 。它展示了强大的泛化能力，能够泛化到新类别的物体并理解复杂语义。此外，它仅需每个物体 10 条人类轨迹即可高效适应新物体。最后，GR-3 在执行长时程和灵巧任务方面表现出色，具有显著的鲁棒性，在桌面清理和布料操作等具有挑战性的任务中取得了较高的平均任务进度。




图 2 能力展示。GR-3 严格遵循指令，能够理解包含抽象概念的未见指令。在长时程桌面清理和灵巧布料操作中表现稳健可靠。




图 3 GR-3 模型。GR-3 在机器人轨迹和视觉语言数据上联合训练，分别采用流匹配目标（左）和下一词元预测目标（右）。

2 GR-3 模型

GR-3 是一个端到端的视觉-语言-动作（VLA）模型 π_θ 。它通过生成 k 长度的动作块 $\mathbf{a}_t = a_{t:t+k}$ 来控制带移动底座的双手机器人，该动作块以输入语言指令 l 、观测 $\mathbf{o}_t$ 和机器人状态 $\mathbf{s}_t$ ，*i.e.*, $\mathbf{a}_t = \pi_\theta(l, \mathbf{o}_t, \mathbf{s}_t)$ 为条件。GR-3 采用混合变换器架构 [45]。它使用预训练的视觉语言模型（VLM），即 Qwen2.5-VL-3B-Instruct[2]，处理多相机视角的观测图像和语言指令，并通过动作扩散变换器（DiT）[56] 预测动作块。

具体而言，GR-3 采用流匹配进行动作预测 [9, 47, 48]。流预测以当前机器人状态 $\mathbf{s}_t$ 和 VLM 骨干网络输出的 KV 缓存为条件。 k 长度的动作块 $\mathbf{a}_t$ 被表示为 k 个词元，并与机器人状态词元拼接，构成动作 DiT 的输入词元序列。流匹配时间步通过自适应层归一化（AdaLN）[57] 注入。我们在动作 DiT 中应用因果注意力掩码来建模动作块内部的时间依赖关系。为确保快速推理，动作 DiT 的层数仅为 VLM 骨干网络的一半，并且仅利用 VLM 后半半层的 KV 缓存。GR-3 总共包含 40 亿参数。

在早期探索中，我们观察到训练过程中频繁出现不稳定现象。受 QK 范数 [26] 启发，我们在 DiT 块内的注意力和前馈网络（FFN）的线性层之后额外应用 RMSNorm[78]。这一设计选择显著提升了整个训练过程的稳定性。此外，我们发现它在下游实验中显著改善了语言遵循能力，如第 5 节所示。

3 训练方案

我们在混合数据源上训练 GR-3 模型，包括用于模仿学习的机器人轨迹数据、用于协同训练的网页级视觉语言数据，以及用于少样本泛化的人类轨迹数据。该训练方案使 GR-3 能够：1) 泛化到新物体、环境和指令；2) 以低成本高效适应未见过的场景；3) 稳健地执行长时程和灵巧任务。

3.1 基于机器人轨迹数据的模仿学习

本文通过最大化策略在一组专家演示上的对数似然，以模仿学习目标训练 GR-3 $\mathcal{D}$ ：

$$\max_{\theta} \mathbb{E}_{\{\mathbf{a}_t, \mathbf{o}_t, \mathbf{s}_t, l\} \sim \mathcal{D}} [\log \pi_{\theta}(\mathbf{a}_t | \mathbf{o}_t, \mathbf{s}_t, l)]. \quad (1)$$

具体而言，我们在训练期间使用流匹配损失对动作预测进行监督：

$$L_{\text{action}}(\theta) = \mathbb{E}_{\{\mathbf{a}_t, \mathbf{o}_t, \mathbf{s}_t, l\} \sim \mathcal{D}} [\| \mathbf{v}_{\theta}(l, \mathbf{o}_t, \mathbf{s}_t, \mathbf{a}_t^{\tau}) - \mathbf{u}(\mathbf{a}_t^{\tau} | \mathbf{a}_t) \|^2]. \quad (2)$$

其中 $\tau \sim \mathcal{U}(0, 1)$ 为流匹配时间步， t 表示回合时间步。 $\mathbf{a}_t^{\tau} = (1 - \tau)\epsilon + \tau\mathbf{a}_t$ 为含噪动作块， $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 为随机噪声， $\mathbf{u}(\mathbf{a}_t^{\tau} | \mathbf{a}_t) = \mathbf{a}_t - \epsilon$ 为真值

用于流预测的标签。为加速训练，我们在视觉语言模型骨干网络的一次前向传播中，对多个采样的流匹配时间步计算流匹配损失 [42]。在推理过程中，动作块从随机噪声 $\mathbf{a}_t^{\tau=0} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 初始化，并使用欧拉方法从 $\tau = 0$ 积分到 $\tau = 1$ ，*i.e.*, $\mathbf{a}_t^{\tau+\Delta\tau} = \mathbf{a}_t^{\tau} + \mathbf{v}_{\theta}(l, \mathbf{o}_t, \mathbf{s}_t, \mathbf{a}_t^{\tau})\Delta\tau$ 。我们在实验中设置 $\Delta\tau = 0.2$ 。

我们通过遥操作采集真实机器人轨迹。为使采集过程更可控并最大化数据多样性，我们开发了一个数据采集调度器（图 4），用于告知遥操作员：1) 要执行的动作，2) 物体组合，以及 3) 背景设置。在每次轨迹采集开始时，系统会生成新的配置，供遥操作员据此布置环境。该调度器的实现使我们能够有效管理整体数据分布，并彻底随机化采集的数据，从而大幅增强数据集的丰富性和可变性。此外，采集后进行质量检查，通过过滤无效和低质量数据来精炼数据集。

先前工作 [38] 表明，策略在动作预测中可能利用来自多个视角的虚假相关性，而非恰当地关注语言条件。为解决此问题，本文引入“任务状态”作为额外的动作维度进行辅助监督。任务状态可为以下之一：进行中（0）、已终止（1）、无效（-1）。进行中状态表示机器人正在执行任务，已终止状态表示机器人已成功完成任务。无效状态表示给定指令在当前观测下无效。例如，若桌上没有刀具，则“将刀放入编织篮”被视为无效。训练期间，本文随机将语言指令替换为无效指令，并训练模型预测无效状态，同时不对动作块的其他维度进行监督。此设计迫使动作扩散变换器（Action DiT）关注语言指令并估计任务状态，显著提升了语言遵循能力，如第 5.2 节所示。

3.2 与视觉-语言数据联合训练

为使 GR-3 具备遵循分布外（OOD）指令的泛化能力，本文在机器人轨迹和视觉-语言数据上联合训练 GR-3（图 3）[11]。机器人轨迹数据以流匹配目标同时训练视觉-语言模型（VLM）骨干和动作扩散变换器。视觉-语言数据仅以下一词元预测目标训练 VLM 骨干。为简化起见，本文在小批量中动态混合视觉-语言数据与机器人轨迹，权重相等。因此，联合训练目标为下一词元预测损失与流匹配损失之和。

通过与视觉语言数据的协同训练，GR-3 能够以零样本方式有效泛化到未见过的物体，并理解复杂概念的新颖语义。我们从多种数据源中整理了一个大规模视觉语言数据集 [25, 30, 39, 62, 75]。该整理后的数据集覆盖了广泛的任务（图 4），包括图像描述生成、视觉问答、图像定位以及交错式接地图像描述生成。我们还开发了一个过滤和重新标注流程，以提高数据集的质量，从而实现有效的协同训练。协同训练不仅帮助 GR-3 保持预训练视觉语言模型的强大视觉语言能力，还使动作 DiT 能够在动作预测中利用这些能力，有效提升下游操作任务的泛化能力。

3.3 利用人类轨迹数据的小样本泛化

GR-3 是一个多功能的视觉语言动作模型，可以轻松微调以适应新场景。然而，收集真实机器人轨迹既耗时又昂贵。虚拟现实设备和手部追踪技术的最新进展为直接从人类轨迹数据中学习动作创造了有前景的机遇 [27, 34, 59]。在本报告中，我们将 GR-3 的高效微调能力扩展到从最少人类轨迹中进行小样本学习的挑战性场景。具体来说，给定一个新场景，我们使用 PICO 4 Ultra Enterprise 收集少量人类轨迹数据。使用虚拟现实设备可以高效地收集人类轨迹，速度约为每小时 450 条轨迹，显著超过遥操作机器人轨迹收集的速度（每小时约 250 条轨迹）。这种效率有助于快速且经济高效地适应新场景。




图 4 GR-3 数据。我们在训练过程中利用三种类型的数据：机器人轨迹数据（顶部）、人类轨迹数据（中部）和视觉语言数据（底部）。

具体而言，所采集的人类轨迹数据包含第一人称视频和人类手部轨迹。我们采用与机器人轨迹相同的标注流程，为人类轨迹数据标注语言。在完成第一阶段基于视觉语言数据和机器人轨迹的训练后，我们引入人类轨迹数据，并对这三类数据进行联合训练。与机器人轨迹不同，人类轨迹数据仅包含第一人称视角和手部轨迹，没有手臂关节状态或夹爪状态。因此，我们为缺失的腕部视角填充空白图像，并仅使用手部轨迹对人类轨迹数据进行训练。

4 硬件与系统

4.1 ByteMini 机器人

ByteMini 机器人（图 5）用于数据采集和策略执行。这款 22 自由度的双臂移动机器人专为三个核心目标而设计：灵活操作、高可靠性和用户友好性。

灵活操作。 7 自由度无偏置机械臂采用独特的球形腕关节构型 [22]，实现了类人的灵巧性。紧凑的球形腕部设计（图 5）克服了传统 SRS 构型机械臂的关键局限性 [54]，后者非紧凑的腕部尺寸阻碍了在狭小空间内的灵活操作。机械臂肘部经过专门设计，可实现高达 2.53 弧度的大幅内收，使双臂能够在机器人胸部区域内执行精细操作。




图 5 ByteMini 机器人。我们展示了机器人规格、多相机视角以及独特的腕部球形关节的运动范围。

高可靠性。数据采集与策略部署期间的高强度工作负载要求字节迷你（ByteMini）具备极高的稳定性与一致性。本文采用集成升降机构的全向移动平台，以实现稳定的空间移动与垂直高度调节。为进一步增强可靠性并确保运动一致性，机械臂中的执行器基于准直驱（Quasi Direct Drive, QDD）原理设计 [35]，该原理以其稳定性和高透明度而闻名。

用户友好性。为提升易用性，本文在机器人上集成了便携式屏幕与迷你电脑（NUC），并配备双锂电池，可在多种场景下提供超过 10 小时的持久续航。此外，字节迷你配备了无线急停装置，能够对紧急情况做出快速响应。

本文在头部和两个手腕上安装了红绿蓝深度（RGBD）相机。腕部相机能够实现近距离观察，以支持精细操作。

4.2 系统与控制

全身柔顺控制。全身柔顺控制框架 [65] 将所有自由度（DoFs）视为一个整体结构，将任意遥操作的人类运动重新定向到可行的机器人运动。可操作性优化、奇异性规避和物理关节极限在实时最优控制问题中同时得到处理，以最大化机器人灵巧性。这在大工作空间内为各种长时程操作任务生成流畅连续的运动，从而为策略训练产生高质量的专家轨迹。柔顺力控制器支持高动态运动及与环境的物理交互，提升了安全性和数据采集效率。

全身遥操作。在遥操作数据采集过程中，通过 Meta VR Quest 进行的全身重新定向提供了直观且用户友好的控制方式，能够直接将人类动作映射到机器人末端执行器。遥操作员可以同时控制手臂、升降机构、夹爪和移动底盘的运动，从而为现实世界中复杂的长期任务实现无缝的数据采集。

用于策略执行的轨迹优化。我们使用预测的动作块来控制机器人的 19 个自由度（不包括升降机构和头部的 3 个自由度）进行策略执行。我们结合纯追踪 [15] 和轨迹优化来增强 GR-3 在策略执行过程中生成轨迹的稳定性和平滑性。实时参数化优化最小化加加速度，并确保航点之间以及跨轨迹的无缝过渡。



图 6 可泛化抓取放置的实验设置。(a) 训练期间见过的测试物体。(b) 训练期间未见过的测试物体。(c) 基础环境在训练期间可见。其他环境是训练期间未见过的分布外环境。

5 实验

我们进行了大量真实世界实验，以全面评估 GR-3 的性能。在整个实验过程中，我们旨在回答四个问题：

- GR-3 是否严格遵循指令，包括训练期间未见过的指令？
- GR-3 能否泛化到分布外设置，包括新物体、环境和指令？
- GR-3 能否从人类轨迹数据中执行小样本学习，并迁移到机器人本体？
- GR-3 能否有效学习一个鲁棒的策略，以执行长时程和灵巧的任务？

我们考虑三个任务：可泛化的拾取放置、长时程桌面清理和灵巧挂衣。请访问项目页面观看视频演示。我们将我们的方法与最先进的方法 π_0 [9] 进行比较。我们遵循官方 GitHub 仓库 ¹ 中的说明，并从提供的基座模型（该模型在大规模机器人数据上预训练）对三个任务分别进行微调 π_0 。

5.1 可泛化的拾取放置

为了评估 GR-3 在分布外设置下的泛化能力，我们在一个以泛化为重点的拾取放置任务上进行评估。我们总共收集了 35k 条机器人轨迹，覆盖 101 个物体，该任务总计 69 小时。我们用“将 A 放入 B”的指令标注机器人轨迹，其中 A 是物体类别，B 是容器。对于基线模型，我们用这些机器人轨迹数据微调 π_0 。对于 GR-3，我们用机器人轨迹数据和视觉语言数据共同训练模型。在训练期间，我们对机器人轨迹的图像应用光度增强，以提高对环境变化的鲁棒性。我们还将我们的方法与一个变体 GR-3 w/o Co-Training 进行比较，该变体仅用机器人轨迹训练模型。这个消融实验帮助我们 ¹ <https://github.com/Physical-Intelligence/openpi>




图 7 可泛化拾取放置的实验结果。(a) 四种不同设置下可泛化拾取放置的结果。(b) 使用人类轨迹的小样本泛化结果。

评估视觉语言共同训练的影响，并确定其对模型性能的具体贡献。

设置。我们在四种不同设置下进行评估：1) 基础设置，2) 未见环境，3) 未见指令，4) 未见物体。在基础设置中，我们在训练期间见过的环境中进行评估。我们使用训练期间见过的 54 个物体进行评估（图 6(a)），以测试基本的指令遵循能力。在未见环境中，我们在四个训练期间未见的真实世界环境中使用同一组物体进行评估：收银台、会议室、办公桌和休息室（图 6(c)）。物体布局与基础设置保持一致。在未见指令中，我们向模型提供需要复杂概念理解的指令，例如“将左边的可乐放入纸箱”和“将有触手的动物放入纸箱”。在未见物体中，我们使用机器人轨迹数据中未见的 45 个物体进行评估（图 6(b)）。

我们使用指令遵循率和成功率来评估模型性能，它们分别衡量模型遵循指令的能力和任务完成的整体表现。对于指令遵循率，如果机器人正确接近给定指令指定的物体，则该次试验视为成功。对于成功率，如果机器人将目标物体放入容器中，则该次试验视为成功。对于这两个度量，分数越高表示能力越强。

基础指令遵循。在基础设置和未见环境中，我们将 54 个见过的物体分成九个小批次，每批六个物体。在每次执行中，我们提示模型根据给定指令从六个物体中挑选一个。为了保证不同模型之间结果的可比性，我们根据预先捕获的掩码放置物体，确保小批次的物体布局在评估期间尽可能保持一致。

如图 7(a) 所示，GR-3 在基础设置和未见环境中的指令遵循率和成功率均超过 π_0 。基础设置与未见环境之间适度的性能下降凸显了 GR-3 对环境变化的鲁棒性。此外，我们观察到在这两种设置下，GR-3 与无协同训练的 GR-3 之间没有显著性能差异，这表明协同训练不影响模型在见过物体上的性能。

可泛化的指令遵循。在未见指令（Unseen Instructions）中，我们旨在测试理解与尺寸、空间关系和常识相关的抽象概念的能力。示例指令包括“将可乐旁边的雪碧放入纸箱”、“将最大的物体放入纸箱”以及“将

将海洋动物放入纸箱”。这些指令在机器人轨迹数据中未曾出现，要求模型对指令中的复杂语义进行推理。在未见物体设置中，我们将 45 个未见物体分为九个小批次，每批五个物体，即模型每次执行需从五个物体中选择一个。该设置尤为困难，因为在 45 个物体中，超过 70% 来自机器人轨迹数据中未见的类别。

如图 7(a) 所示，GR-3 在两种设置下均大幅超越 π_0 ，凸显其卓越的泛化能力。在未见指令设置下，成功率从 40% 提升至 77.1%；在未见物体设置下，成功率从 40% 提升至 57.8%。GR-3 在两种设置下也显著优于未使用协同训练的 GR-3，表明与视觉-语言（VL）数据的协同训练有助于增强泛化能力。该视觉-语言-动作（VLA）模型有效地将大规模视觉-语言数据中的丰富知识迁移到策略学习中，并在新场景下实现了强大的零样本能力。我们还观察到，仅使用机器人轨迹训练 GR-3 的性能不如 π_0 基线。我们推测 π_0 的性能优势源于其大规模跨具身预训练 [9]。

基于人类轨迹数据的少样本泛化。我们还利用虚拟现实设备采集的人类轨迹评估了少样本泛化能力 [31, 71]。这具有挑战性，原因在于

1) 模型需要从跨具身数据中学习，且 2) 数据稀缺。具体而言，在未见物体设置中，我们为 45 个未见物体各收集了最多 10 条人类轨迹（图 6(b)）。

450 条人类轨迹的总时长约为 30 分钟。我们在基于机器人轨迹和视觉语言数据训练的检查点基础上，对 GR-3 进行增量训练。通过进一步将人类轨迹数据与机器人轨迹和视觉语言数据结合，我们进行了额外 2 万步的联合训练。

我们在不同少样本设置（1 样本、5 样本和 10 样本）下，对已见和未见物体上的性能进行了评估（图 7(b)）。与基础模型的零样本性能相比，我们能够利用更多未见物体上的人类轨迹数据持续提升指令遵循率和成功率，并且仅需每个物体 10 条人类轨迹，就将成功率从 57.8% 提升至 86.7%。此外，我们注意到已见物体上的性能没有明显下降，这表明一种有前景的样本高效且成本效益高的微调策略，可将预训练的视觉-语言-动作模型适配到下游新场景。

5.2 长时程桌面清理

我们在桌面清理任务上进行了实验，以评估 GR-3 在处理长时程操作方面的鲁棒性（图 8）。在该任务中，机器人需要清理一张摆满杂乱餐具、食物、外卖盒和塑料清理箱的桌子。为完成任务，机器人需要：1) 将食物装入外卖盒，

2) 将所有餐具放入清理箱，以及 3) 将所有垃圾扔进垃圾桶。由于工作空间较大，机器人需要将其移动底座从外卖盒移动到清理箱，以完成整个任务（图 8(a)）。我们在平坦设置和指令遵循设置下对模型进行了评估。

平坦设置。在该设置下，我们向机器人给出一个通用任务指令“清理餐桌”，使其在单次运行中自主完成整个任务（图 8(a)）。平坦设置有助于我们评估模型在处理长时程任务方面的鲁棒性。我们使用平均任务进度作为评估指标，该指标计算成功完成的子任务数与子任务总数的比值。值为 1.0 表示完全成功，分数值对应部分成功。在该设置下，我们总共在五组不同的物体上进行了评估。

指令遵循设置。在该设置下，我们进一步评估模型如何遵循指令。我们依次向机器人给出多个子任务描述，例如“将纸杯扔进垃圾桶”，以清理桌面。机器人从初始位置开始执行每个子任务。我们使用平均子任务成功率作为评估指标。指令遵循设置总共涵盖六组不同的指令（图 8(b)）：

- **基础：物体布局与训练数据中的布局高度相似。**
- **多物体：**我们在场景中添加了部分物体类别的多个实例。我们加入指令，命令机器人将这些类别的所有实例放入清理箱或垃圾桶中。




图 8 桌面清理任务的实验设置与结果。(a) 平坦：要求机器人在单次运行中执行长程桌面清理。(b) 指令遵循 (IF)：机器人被连续提示多个子任务描述。(c) 测试物体。(d) 平坦与指令遵循 (IF) 设置下的结果。

- **多目的地**：我们在场景中添加一个编织篮，并命令机器人将餐具放入编织篮或清理箱中。
- **多物体与多目的地**：我们结合上述两种设置，并指示机器人将某一物体类别的所有实例移动到两个目的地之一。
- **新颖目的地**：要求机器人将物体移动到训练数据中未与该物体一同出现的目的地，例如“将叉子放入垃圾桶”。
- **无效任务**：在实际应用中，机器人需要处理复杂指令，其中部分指令可能无效。例如，若桌上没有蓝色碗，则“将蓝色碗放入塑料盒”应视为无效。在此场景下，我们希望策略能够拒绝执行错误的有效任务 [52]。在该设置中，我们向模型提供在给定观测下无法完成的任务。仅当模型在 10 秒内未操纵任何物体时，该次试验才被视为成功。

实现细节。我们总共为该任务收集了约 101 小时的机器人轨迹。对于基线方法，我们在这些机器人轨迹上微调 π_0 。对于 GR-3，我们在机器人轨迹和视觉-语言 (VL) 数据上联合训练。我们还对方法的两个变体进行了消融研究：GR-3 w/o Norm 和 GR-3 w/o Task Status (TS)。GR-3 w/o Norm 移除了 DiT 块中注意力和 FFN 中引入的 RMSNorm。GR-3 w/o TS 在训练期间不纳入任务状态。对于所有方法，我们分别训练两个独立的模型，即平坦版本和 IF 版本，分别用于两种设置。



图 9 灵巧布料操作实验设置。(a) 测试集中已见和未见的布料。(b) 基本设置和位置设置。

对于平坦版本，我们在通用任务和子任务之间随机采样作为语言指令。对于 IF 版本，我们在训练期间仅使用子任务作为指令。

结果。如图 8(d) 所示，GR-3 在两种设置下均优于 π_0 ，尤其是在指令遵循设置下（成功率分别为 53.8% 对 97.5%）。虽然 π_0 能够执行长程桌面清理任务，但在指令遵循方面存在困难，尤其是在分布外场景中。它无法区分叉子和勺子。在新目的地设置中，它将物体放入训练数据中与物体同时出现的容器中，而不是遵循给定的指令。另一方面，GR-3 在所有六个测试集中都严格遵循指令。它能够很好地泛化到多个物体和目的地，并且能够在无效任务中避免执行错误任务。

移除均方根层归一化（RMSNORM）会损害两种设置下的性能，尤其是在指令遵循设置中。没有范数的 GR-3 无法很好地遵循指令。特别是，它无法泛化到新目的地。这些结果强调了均方根层归一化在增强指令遵循能力方面的关键作用。没有任务状态时，指令遵循能力也会下降，这凸显了任务状态在帮助视觉-语言-动作模型遵循指令方面的有效性。

5.3 灵巧布料操作

在本实验中，我们评估 GR-3 在可变形物体的灵巧操作上的表现。具体来说，我们挑战模型将衣物用衣架挂到晾衣架上（图 2）。在此任务中，机器人需要：1) 拿起衣架，2) 将衣物放到衣架上，3) 将衣物挂到晾衣架上。在最后一步，机器人需要将其移动底座从桌子旋转到晾衣架以挂起衣物。我们总共为此任务收集了 116 小时的机器人轨迹数据。我们在这些数据上训练 π_0 。对于 GR-3，我们在这些机器人轨迹和视觉-语言数据上进行联合训练。我们在三种不同设置下进行评估：基础设置、位置设置和未见实例设置。

设置。在基础（Basic）设置中，我们在训练期间见过的六件衣服上进行评估。衣服的摆放方式与训练数据中的相似。在位置（Position）设置中，我们如图 9(b) 所示旋转并揉皱衣服。位置设置评估模型在处理具有挑战性的衣服布局时的鲁棒性。在未见实例（Unseen Instances）设置中，我们评估模型对训练期间未见过衣服的泛化能力。具体来说，我们用四件未见过的衣服进行评估（图 9(a)）。虽然训练数据中所有衣服都是长袖的，但测试集中有两件未见过的衣服是短袖的。我们使用平均任务进度作为评估度量，其中完全成功——将衬衫挂在晾衣架上——对应 1.0。整个过程分为四个关键里程碑：1) 拿起衣架，2) 将右肩放在衣架上，3) 将左肩放在衣架上，4) 将衬衫挂在晾衣架上（图 10(a)）。每个里程碑对整体任务进度贡献一个分数。




图 10 灵巧衣物操作实验结果。(a) 基础设置下整个执行过程中成功（实线）和失败（阴影线）的桑基图。(b) π_0 和 GR-3 在三种评估设置下的平均任务进度。

结果。结果如图 10 所示。GR-3 在所有三种评估设置中均优于 π_0 。它在基础设置和位置设置中分别达到了 86.7% 和 83.9% 的平均任务进度，展示了其在处理复杂灵巧任务方面的熟练度以及对位置变化的鲁棒性。此外，GR-3 能够泛化到具有新颖图案和袖长的未见衣服，达到了 75.8% 的平均任务进度。为了深入探究执行过程，我们在图 10(a) 中展示了基础设置下四个里程碑的成功与失败桑基图。对于两个模型来说，最具挑战性的部分是在右肩之后将左肩放在衣架上。这是因为机器人需要在握住衣架的同时拉出左领口，而左领口通常折叠在衣架后面，以便抓取。另一种失败模式发生在将左肩放在衣架上的过程中，衣架从夹爪中滑落，导致最后一步失败。

6 相关工作

通用操作策略。构建能够遵循指令、有效与物理世界交互的通用操作策略，一直是机器人研究中的长期挑战 [3, 6, 7, 9 – 11, 29, 37, 43, 44, 64, 66, 68]。先前工作 [33, 53, 61, 74] 提出从大规模数据中学习表征以用于下游策略学习，从而在复杂任务中实现更鲁棒的机器人行为。视觉-语言-动作 (VLA) 模型的最新进展采用了多种方法来增强策略泛化能力并提升操作能力。一类流行的工作 [9, 18, 29, 37, 41, 49, 55, 58, 60, 68, 70] 使用跨具身数据训练策略，这些数据包含来自不同机器人本体的轨迹 [17, 21, 36, 55, 69]。除了真实世界机器人轨迹之外，其他工作 [9, 11, 29] 利用预训练的视觉语言模型来开发机器人策略，展现出对未见环境的强大泛化能力。另一种提升泛化能力的方法是在网络规模视频数据集上进行未来预测 [8, 13, 20, 28, 40, 73]，或从无动作视频中学习潜在动作 [7, 12, 77]。在本文中，我们提出 GR-3，这是一种在机器人轨迹和视觉语言数据上联合训练的 VLA 模型，并且可以通过少量人类轨迹进行高效微调。通过大量实验，我们表明 GR-3 能够：1) 严格遵循指令并泛化到新物体、新环境和新指令；2) 从少量人类轨迹数据中高效适应新环境；3) 以高鲁棒性执行长时程和灵巧任务。

面向机器人操作的多模态协同训练。收集真实世界机器人轨迹成本高昂且耗时。因此，在扩大策略训练规模时，拓宽数据来源变得至关重要 [32, 46]。一种流行的方法是从预训练的视觉编码器 [33, 50, 53, 61, 74] 初始化策略，或最近从预训练的视觉语言模型 [7, 9, 11, 29] 初始化策略。基于这一框架，很自然地

在训练过程中除机器人轨迹外融入多模态数据 [11, 29, 58, 63, 76]。特别是, GATO[63] 构建了一个通用智能体, 能够执行广泛的任務, 包括图像描述生成和用真实机器人进行积木堆叠。它将不同模态的数据转换为标记序列, 并训练一个大型变换器进行下一标记预测。RT-2[11] 表明, 在机器人轨迹和视觉语言数据上共同微调大型视觉语言模型能显著提升泛化能力。通过在异构数据上进行联合训练, $\pi_{0.5}$ [29] 展示了跨环境和物体的卓越泛化能力, 使其能够在真实世界未见场景中有效部署。在本工作中, GR-3 采用了类似的联合训练策略。我们从多个数据源精心构建了一个网络规模的视觉语言数据集, 并在广泛的视觉语言任务上进行了大规模联合训练。通过大规模联合训练, GR-3 在零样本泛化到未见物体和需要抽象概念理解的复杂指令方面展现出强大的能力。

利用人类数据进行策略训练。为了提高数据效率, 将人类数据融入策略训练已成为机器人研究中一种流行的方法。一系列工作 [1, 5, 51, 72] 从人类视频中提取不同类型的表示以增强策略训练。Wu 等人 [73] 和 Cheang 等人 [13] 提出利用大规模人类视频 [16, 23, 24] 进行生成式视频预训练。最近, 随着手部追踪和虚拟现实设备的发展, Qiu 等人 [59] 和 Kareer 等人 [34] 表明, 带有手部轨迹的人类视频可以通过与少量机器人数据联合训练来提升策略在机器人本体上的性能。在本报告中, 我们遵循这一研究方向, 并展示 GR-3 能够通过从人类轨迹中进行小样本学习有效适应新场景。

7 局限性与结论

局限性与未来工作。尽管在挑战性任务中表现出强大的性能, GR-3 仍存在局限性。虽然它展示了强大的泛化能力, 但在遵循涉及新颖概念和物体的未见指令时会出错, 并且在抓取具有未见形状的物体时存在困难。我们计划扩大模型和训练数据的规模, 以持续提升模型在处理新颖场景方面的性能。此外, 与所有模仿学习方法类似, GR-3 在推演过程中可能陷入分布外状态, 并且无法从失败中恢复。未来, 我们计划引入强化学习 (Reinforcement Learning, RL) 来增强在复杂和灵巧任务上的鲁棒性, 并突破模仿学习的局限来优化性能。

结论。在本报告中, 我们介绍了 GR-3, 这是一个强大的视觉-语言-动作 (Vision-Language-Action, VLA) 模型, 它输出动作来控制双臂移动机器人。我们仔细研究了模型架构, 并开发了一套全面的训练方案, 该方案结合了大规模视觉-语言数据的协同训练、从人类轨迹中高效的小样本学习, 以及从机器人轨迹中有效的模仿学习。在三个挑战性任务上进行的大量真实世界实验表明, GR-3 在理解包含抽象概念的复杂指令方面表现出色, 能够有效地泛化到新颖的物体和环境, 从最少的人类轨迹中高效学习, 并以卓越的鲁棒性和可靠性执行长时程和灵巧的任务。我们希望 GR-3 能够成为迈向创造通用机器人、协助人类完成现实世界中多样化任务的一步。

8 贡献与致谢

作者按字母顺序在以下领域做出了贡献。

- **数据:** Chilam Cheang, Sijin Chen, Yifeng Li, Yuxiao Liu, Haixin Shi, Yuyang Xiao
- **模型架构:** Hongtao Wu, Xin Xiao
- **训练:** 陈思进、马晓、吴宏涛、肖欣、徐佳峰、杨一初
- **评估:** 张智霖、陈思进、胡英东、欧文轩、石海欣、吴宏涛、肖欣、杨一初
- **机器人开发:** 崔中仁、黄立群、牛浩、任泽宇、田嘉文、徐佳峰
- **机器人系统:** 刘宇霄、欧文轩、彭万里
- **撰写:** 陈思进、刘宇霄、马骁、任泽宇、吴宏涛、杨一初
- **团队负责人:** 孔涛、李航 我们感谢郭金明、胡雪阳、李泽天、魏旭光、肖兆浩、杨德功、杨一帆、杨周其可、周逸飞在数据策展方面的帮助。我们感谢龙泽宇、严廷帅在模型部署方面的帮助。我们感谢刘洋、赵明在机器人开发与维护方面的帮助。我们衷心感谢所有遥操作员和标注人员在数据收集与标注方面的辛勤付出。

参考文献

- [1] Shikhar Bahl, Russell Mendonca, Lili Chen, Unnat Jain, and Deepak Pathak. Affordances from human videos as a versatile representation for robotics. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 13778–13790, 2023.
- [2] Shuai Bai, Keqin Chen, Xuejing Liu, Jialin Wang, Wenbin Ge, Sibao Song, Kai Dang, Peng Wang, Shijie Wang, Jun Tang, et al. Qwen2.5-vl technical report. *arXiv preprint arXiv:2502.13923*, 2025.
- [3] Jose Barreiros, Andrew Beaulieu, Aditya Bhat, Rick Cory, Eric Cousineau, Hongkai Dai, Ching-Hsin Fang, Kunimatsu Hashimoto, Muhammad Zubair Irshad, Masha Itkina, et al. A careful examination of large behavior models for multitask dexterous manipulation. *arXiv preprint arXiv:2507.05331*, 2025.
- [4] Lucas Beyer, Andreas Steiner, André Susano Pinto, Alexander Kolesnikov, Xiao Wang, Daniel Salz, Maxim Neumann, Ibrahim Alabdulmohsin, Michael Tschannen, Emanuele Bugliarello, et al. Paligemma: A versatile 3b vlm for transfer. *arXiv preprint arXiv:2407.07726*, 2024.
- [5] Homanga Bharadhwaj, Roozbeh Mottaghi, Abhinav Gupta, and Shubham Tulsiani. Track2act: Predicting point tracks from internet videos enables diverse zero-shot robot manipulation. *arXiv preprint arXiv:2405.01527*, 2024.
- [6] Homanga Bharadhwaj, Jay Vakil, Mohit Sharma, Abhinav Gupta, Shubham Tulsiani, and Vikash Kumar. Roboagent: Generalization and efficiency in robot manipulation via semantic augmentations and action chunking. In *2024 IEEE International Conference on Robotics and Automation (ICRA)*, pages 4788–4795. IEEE, 2024.
- [7] Johan Bjorck, Fernando Castañeda, Nikita Cherniadev, Xingye Da, Runyu Ding, Linxi Fan, Yu Fang, Dieter Fox, Fengyuan Hu, Spencer Huang, et al. Gr00t n1: An open foundation model for generalist humanoid robots. *arXiv preprint arXiv:2503.14734*, 2025.
- [8] Kevin Black, Mitsuhiro Nakamoto, Pranav Atreya, Homer Walke, Chelsea Finn, Aviral Kumar, and Sergey Levine. Zero-shot robotic manipulation with pretrained image-editing diffusion models. *arXiv preprint arXiv:2310.10639*, 2023.
- [9] Kevin Black, Noah Brown, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Lachy Groom, Karol Hausman, Brian Ichter, et al. $\pi 0$: A vision-language-action flow model for general robot control. *arXiv preprint arXiv:2410.24164*, 2024.
- [10] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Joseph Dabis, Chelsea Finn, Keerthana Gopalakrishnan, Karol Hausman, Alex Herzog, Jasmine Hsu, et al. Rt-1: Robotics transformer for real-world control at scale. *arXiv preprint arXiv:2212.06817*, 2022.
- [11] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Xi Chen, Krzysztof Choromanski, Tianli Ding, Danny Driess, Avinava Dubey, Chelsea Finn, et al. Rt-2: Vision-language-action models transfer web knowledge to robotic control. *arXiv preprint arXiv:2307.15818*, 2023.
- [12] Qingwen Bu, Jisong Cai, Li Chen, Xiuqi Cui, Yan Ding, Siyuan Feng, Shenyuan Gao, Xindong He, Xuan Hu, Xu Huang, et al. Agibot world colosseum: A large-scale manipulation platform for scalable and intelligent embodied systems. *arXiv preprint arXiv:2503.06669*, 2025.
- [13] Chi-Lam Cheang, Guangzeng Chen, Ya Jing, Tao Kong, Hang Li, Yifeng Li, Yuxiao Liu, Hongtao Wu, Jiafeng Xu, Yichu Yang, et al. Gr-2: A generative video-language-action model with web-scale knowledge for robot manipulation. *arXiv preprint arXiv:2410.06158*, 2024.
- [14] Xi Chen, Josip Djolonga, Piotr Padlewski, Basil Mustafa, Soravit Changpinyo, Jialin Wu, Carlos Riquelme Ruiz, Sebastian Goodman, Xiao Wang, Yi Tay, et al. Pali-x: On scaling up a multilingual vision and language model. *arXiv preprint arXiv:2305.18565*, 2023.
- [15] R Craig Coulter. Implementation of the pure pursuit path tracking algorithm. Technical report, 1992.
- [16] Dima Damen, Hazel Doughty, Giovanni Maria Farinella, Sanja Fidler, Antonino Furnari, Evangelos Kazakos, Davide Moltisanti, Jonathan Munro, Toby Perrett, Will Price, et al. Scaling egocentric vision: The epic-kitchens dataset. In *Proceedings of the European conference on computer vision (ECCV)*, pages 720–736, 2018.
- [17] Sudeep Dasari, Frederik Ebert, Stephen Tian, Suraj Nair, Bernadette Bucher, Karl Schmeckpeper, Siddharth Singh, Sergey Levine, and Chelsea Finn. Robonet: Large-scale multi-robot learning. *arXiv preprint arXiv:1910.11215*, 2019.

- [18] Ria Doshi, Homer Walke, Oier Mees, Sudeep Dasari, and Sergey Levine. Scaling cross-embodied learning: One policy for manipulation, navigation, locomotion and aviation. *arXiv preprint arXiv:2408.11812*, 2024.
- [19] Danny Driess, Fei Xia, Mehdi SM Sajjadi, Corey Lynch, Aakanksha Chowdhery, Ayzaan Wahid, Jonathan Tompson, Quan Vuong, Tianhe Yu, Wenlong Huang, et al. Palm-e: An embodied multimodal language model. *arXiv preprint arXiv:2303.03378*, 2023.
- [20] Yilun Du, Sherry Yang, Bo Dai, Hanjun Dai, Ofir Nachum, Josh Tenenbaum, Dale Schuurmans, and Pieter Abbeel. Learning universal policies via text-guided video generation. *Advances in neural information processing systems*, 36:9156–9172, 2023.
- [21] Frederik Ebert, Yanlai Yang, Karl Schmeckpeper, Bernadette Bucher, Georgios Georgakis, Kostas Daniilidis, Chelsea Finn, and Sergey Levine. Bridge data: Boosting generalization of robotic skills with cross-domain datasets. *arXiv preprint arXiv:2109.13396*, 2021.
- [22] Clément M Gosselin and Eric Lavoie. On the kinematic design of spherical three-degree-of-freedom parallel manipulators. *The International Journal of Robotics Research*, 12(4):394–402, 1993.
- [23] Raghav Goyal, Samira Ebrahimi Kahou, Vincent Michalski, Joanna Materzynska, Susanne Westphal, Heuna Kim, Valentin Haenel, Ingo Fruend, Peter Yianilos, Moritz Mueller-Freitag, et al. The "something something" video database for learning and evaluating visual common sense. In *Proceedings of the IEEE international conference on computer vision*, pages 5842–5850, 2017.
- [24] Kristen Grauman, Andrew Westbury, Eugene Byrne, Zachary Chavis, Antonino Furnari, Rohit Girdhar, Jackson Hamburger, Hao Jiang, Miao Liu, Xingyu Liu, et al. Ego4d: Around the world in 3,000 hours of egocentric video. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 18995–19012, 2022.
- [25] Dong Guo, Faming Wu, Feida Zhu, Fuxing Leng, Guang Shi, Haobin Chen, Haoqi Fan, Jian Wang, Jianyu Jiang, Jiawei Wang, et al. Seed1.5-vl technical report. *arXiv preprint arXiv:2505.07062*, 2025.
- [26] Alex Henry, Prudhvi Raj Dachapally, Shubham Pawar, and Yuxuan Chen. Query-key normalization for transformers. *arXiv preprint arXiv:2010.04245*, 2020.
- [27] Ryan Hoque, Peide Huang, David J Yoon, Mouli Sivapurapu, and Jian Zhang. Egodex: Learning dexterous manipulation from large-scale egocentric video. *arXiv preprint arXiv:2505.11709*, 2025.
- [28] Yucheng Hu, Yanjiang Guo, Pengchao Wang, Xiaoyu Chen, Yen-Jen Wang, Jianke Zhang, Koushil Sreenath, Chaochao Lu, and Jianyu Chen. Video prediction policy: A generalist robot policy with predictive visual representations. *arXiv preprint arXiv:2412.14803*, 2024.
- [29] Physical Intelligence, Kevin Black, Noah Brown, James Darpinian, Karan Dhabalia, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, et al. $\pi 0.5$: a vision-language-action model with open-world generalization. *arXiv preprint arXiv:2504.16054*, 2025.
- [30] Justin Johnson, Bharath Hariharan, Laurens Van Der Maaten, Li Fei-Fei, C Lawrence Zitnick, and Ross Girshick. Clevr: A diagnostic dataset for compositional language and elementary visual reasoning. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 2901–2910, 2017.
- [31] Bingyi Kang, Zhuang Liu, Xin Wang, Fisher Yu, Jiashi Feng, and Trevor Darrell. Few-shot object detection via feature reweighting. In *Proceedings of the IEEE/CVF international conference on computer vision*, pages 8420–8429, 2019.
- [32] Jared Kaplan, Sam McCandlish, Tom Henighan, Tom B Brown, Benjamin Chess, Rewon Child, Scott Gray, Alec Radford, Jeffrey Wu, and Dario Amodei. Scaling laws for neural language models. *arXiv preprint arXiv:2001.08361*, 2020.
- [33] Siddharth Karamcheti, Suraj Nair, Annie S Chen, Thomas Kollar, Chelsea Finn, Dorsa Sadigh, and Percy Liang. Language-driven representation learning for robotics. *arXiv preprint arXiv:2302.12766*, 2023.
- [34] Simar Kareer, Dhruv Patel, Ryan Punamiya, Pranay Mathur, Shuo Cheng, Chen Wang, Judy Hoffman, and Danfei Xu. Egomimic: Scaling imitation learning via egocentric video. *arXiv preprint arXiv:2410.24221*, 2024.
- [35] Benjamin Katz, Jared Di Carlo, and Sangbae Kim. Mini cheetah: A platform for pushing the limits of dynamic quadruped control. In *2019 international conference on robotics and automation (ICRA)*, pages 6295–6301. IEEE, 2019.

- [36] Alexander Khazatsky, Karl Pertsch, Suraj Nair, Ashwin Balakrishna, Sudeep Dasari, Siddharth Karamcheti, Soroush Nasiriany, Mohan Kumar Srirama, Lawrence Yunliang Chen, Kirsty Ellis, et al. Droid: A large-scale in-the-wild robot manipulation dataset. [arXiv preprint arXiv:2403.12945](#), 2024.
- [37] Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, Ted Xiao, Ashwin Balakrishna, Suraj Nair, Rafael Rafailov, Ethan Foster, Grace Lam, Pannag Sanketi, et al. Openvla: An open-source vision-language-action model. [arXiv preprint arXiv:2406.09246](#), 2024.
- [38] Moo Jin Kim, Chelsea Finn, and Percy Liang. Fine-tuning vision-language-action models: Optimizing speed and success. [arXiv preprint arXiv:2502.19645](#), 2025.
- [39] Feng Li, Renrui Zhang, Hao Zhang, Yuanhan Zhang, Bo Li, Wei Li, Zejun Ma, and Chunyuan Li. Llava-next-interleave: Tackling multi-image, video, and 3d in large multimodal models. [arXiv preprint arXiv:2407.07895](#), 2024.
- [40] Peiyan Li, Hongtao Wu, Yan Huang, Chilam Cheang, Liang Wang, and Tao Kong. Gr-mg: Leveraging partially-annotated data via multi-modal goal-conditioned policy. [IEEE Robotics and Automation Letters](#), 2025.
- [41] Qixiu Li, Yaobo Liang, Zeyu Wang, Lin Luo, Xi Chen, Mozheng Liao, Fangyun Wei, Yu Deng, Sicheng Xu, Yizhong Zhang, et al. Cogact: A foundational vision-language-action model for synergizing cognition and action in robotic manipulation. [arXiv preprint arXiv:2411.19650](#), 2024.
- [42] Tianhong Li, Yonglong Tian, He Li, Mingyang Deng, and Kaiming He. Autoregressive image generation without vector quantization. [Advances in Neural Information Processing Systems](#), 37:56424–56445, 2024.
- [43] Xinghang Li, Minghuan Liu, Hanbo Zhang, Cunjun Yu, Jie Xu, Hongtao Wu, Chilam Cheang, Ya Jing, Weinan Zhang, Huaping Liu, et al. Vision-language foundation models as effective robot imitators. [arXiv preprint arXiv:2311.01378](#), 2023.
- [44] Xinghang Li, Peiyan Li, Minghuan Liu, Dong Wang, Jirong Liu, Bingyi Kang, Xiao Ma, Tao Kong, Hanbo Zhang, and Huaping Liu. Towards generalist robot policies: What matters in building vision-language-action models. [arXiv preprint arXiv:2412.14058](#), 2024.
- [45] Weixin Liang, Lili Yu, Liang Luo, Srinivasan Iyer, Ning Dong, Chunting Zhou, Gargi Ghosh, Mike Lewis, Wen-tau Yih, Luke Zettlemoyer, et al. Mixture-of-transformers: A sparse and scalable architecture for multi-modal foundation models. [arXiv preprint arXiv:2411.04996](#), 2024.
- [46] Fanqi Lin, Yingdong Hu, Pingyue Sheng, Chuan Wen, Jiacheng You, and Yang Gao. Data scaling laws in imitation learning for robotic manipulation. [arXiv preprint arXiv:2410.18647](#), 2024.
- [47] Yaron Lipman, Ricky TQ Chen, Heli Ben-Hamu, Maximilian Nickel, and Matt Le. Flow matching for generative modeling. [arXiv preprint arXiv:2210.02747](#), 2022.
- [48] Qiang Liu. Rectified flow: A marginal preserving approach to optimal transport. [arXiv preprint arXiv:2209.14577](#), 2022.
- [49] Songming Liu, Lingxuan Wu, Bangguo Li, Hengkai Tan, Huayu Chen, Zhengyi Wang, Ke Xu, Hang Su, and Jun Zhu. Rdt-1b: a diffusion foundation model for bimanual manipulation. [arXiv preprint arXiv:2410.07864](#), 2024.
- [50] Arjun Majumdar, Karmesh Yadav, Sergio Arnaud, Jason Ma, Claire Chen, Sneha Silwal, Aryan Jain, Vincent-Pierre Berges, Tingfan Wu, Jay Vakil, et al. Where are we in the search for an artificial visual cortex for embodied intelligence? [Advances in Neural Information Processing Systems](#), 36:655–677, 2023.
- [51] Russell Mendonca, Shikhar Bahl, and Deepak Pathak. Structured world models from human videos. [arXiv preprint arXiv:2308.10901](#), 2023.
- [52] Smitha Milli, Dylan Hadfield-Menell, Anca Dragan, and Stuart Russell. Should robots be obedient? [arXiv preprint arXiv:1705.09990](#), 2017.
- [53] Suraj Nair, Aravind Rajeswaran, Vikash Kumar, Chelsea Finn, and Abhinav Gupta. R3m: A universal visual representation for robot manipulation. [arXiv preprint arXiv:2203.12601](#), 2022.
- [54] Dragomir N Nenchev, Yuichi Tsumaki, and Mitsugu Takahashi. Singularity-consistent kinematic redundancy resolution for the srs manipulator. In [2004 IEEE/RSJ International Conference on Intelligent Robots and Systems \(IROS\)](#), volume 4, pages 3607–3612. IEEE, 2004.

- [55] Abby O’Neill, Abdul Rehman, Abhiram Maddukuri, Abhishek Gupta, Abhishek Padalkar, Abraham Lee, Acorn Pooley, Agrim Gupta, Ajay Mandlekar, Ajinkya Jain, et al. Open x-embodiment: Robotic learning datasets and rt-x models: Open x-embodiment collaboration 0. In 2024 IEEE International Conference on Robotics and Automation (ICRA), pages 6892–6903. IEEE, 2024.
- [56] William Peebles and Saining Xie. Scalable diffusion models with transformers. In Proceedings of the IEEE/CVF international conference on computer vision, pages 4195–4205, 2023.
- [57] Ethan Perez, Florian Strub, Harm De Vries, Vincent Dumoulin, and Aaron Courville. Film: Visual reasoning with a general conditioning layer. In Proceedings of the AAAI conference on artificial intelligence, volume 32, 2018.
- [58] Karl Pertsch, Kyle Stachowicz, Brian Ichter, Danny Driess, Suraj Nair, Quan Vuong, Oier Mees, Chelsea Finn, and Sergey Levine. Fast: Efficient action tokenization for vision-language-action models. arXiv preprint arXiv:2501.09747, 2025.
- [59] Ri-Zhao Qiu, Shiqi Yang, Xuxin Cheng, Chaitanya Chawla, Jialong Li, Tairan He, Ge Yan, David J Yoon, Ryan Hoque, Lars Paulsen, et al. Humanoid policy~ human policy. arXiv preprint arXiv:2503.13441, 2025.
- [60] Delin Qu, Haoming Song, Qizhi Chen, Yuanqi Yao, Xinyi Ye, Yan Ding, Zhigang Wang, JiaYuan Gu, Bin Zhao, Dong Wang, et al. Spatialvla: Exploring spatial representations for visual-language-action model. arXiv preprint arXiv:2501.15830, 2025.
- [61] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, et al. Learning transferable visual models from natural language supervision. In International conference on machine learning, pages 8748–8763. PmLR, 2021.
- [62] Hanoona Rasheed, Muhammad Maaz, Sahal Shaji, Abdelrahman Shaker, Salman Khan, Hisham Cholakkal, Rao M Anwer, Eric Xing, Ming-Hsuan Yang, and Fahad S Khan. Glamm: Pixel grounding large multimodal model. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 13009–13018, 2024.
- [63] Scott Reed, Konrad Zolna, Emilio Parisotto, Sergio Gomez Colmenarejo, Alexander Novikov, Gabriel Barth-Maron, Mai Gimenez, Yury Sulsky, Jackie Kay, Jost Tobias Springenberg, et al. A generalist agent. arXiv preprint arXiv:2205.06175, 2022.
- [64] Moritz Reuss, Ömer Erdiñç Yağmurlu, Fabian Wenzel, and Rudolf Lioutikov. Multimodal diffusion transformer: Learning versatile behavior from multimodal goals. arXiv preprint arXiv:2407.05996, 2024.
- [65] Luis Sentis and Oussama Khatib. A whole-body control framework for humanoids operating in human environments. In 2006 IEEE International Conference on Robotics and Automation (ICRA), pages 2641–2648. IEEE, 2006.
- [66] Mustafa Shukor, Dana Aubakirova, Francesco Capuano, Pepijn Kooijmans, Steven Palma, Adil Zouitine, Michel Aractingi, Caroline Pascal, Martino Russi, Andres Marafioti, et al. Smolvla: A vision-language-action model for affordable and efficient robotics. arXiv preprint arXiv:2506.01844, 2025.
- [67] Gemini Robotics Team, Saminda Abeyruwan, Joshua Ainslie, Jean-Baptiste Alayrac, Montserrat Gonzalez Arenas, Travis Armstrong, Ashwin Balakrishna, Robert Baruch, Maria Bauza, Michiel Blokzijl, et al. Gemini robotics: Bringing ai into the physical world. arXiv preprint arXiv:2503.20020, 2025.
- [68] Octo Model Team, Dibya Ghosh, Homer Walke, Karl Pertsch, Kevin Black, Oier Mees, Sudeep Dasari, Joey Hejna, Tobias Kreiman, Charles Xu, et al. Octo: An open-source generalist robot policy. arXiv preprint arXiv:2405.12213, 2024.
- [69] Homer Rich Walke, Kevin Black, Tony Z Zhao, Quan Vuong, Chongyi Zheng, Philippe Hansen-Estruch, Andre Wang He, Vivek Myers, Moo Jin Kim, Max Du, et al. Bridgedata v2: A dataset for robot learning at scale. In Conference on Robot Learning, pages 1723–1736. PMLR, 2023.
- [70] Lirui Wang, Xinlei Chen, Jialiang Zhao, and Kaiming He. Scaling proprioceptive-visual learning with heterogeneous pre-trained transformers. Advances in neural information processing systems, 37:124420–124450, 2024.
- [71] Yaqing Wang, Quanming Yao, James T Kwok, and Lionel M Ni. Generalizing from a few examples: A survey on few-shot learning. ACM computing surveys (csur), 53(3):1–34, 2020.
- [72] Chuan Wen, Xingyu Lin, John So, Kai Chen, Qi Dou, Yang Gao, and Pieter Abbeel. Any-point trajectory modeling for policy learning. arXiv preprint arXiv:2401.00025, 2023.

- [73] Hongtao Wu, Ya Jing, Chilam Cheang, Guangzeng Chen, Jiafeng Xu, Xinghang Li, Minghuan Liu, Hang Li, and Tao Kong. Unleashing large-scale video generative pre-training for visual robot manipulation. In International Conference on Learning Representations, 2024.
- [74] Tete Xiao, Ilija Radosavovic, Trevor Darrell, and Jitendra Malik. Masked visual pre-training for motor control. arXiv preprint arXiv:2203.06173, 2022.
- [75] Le Xue, Manli Shu, Anas Awadalla, Jun Wang, An Yan, Senthil Purushwalkam, Honglu Zhou, Viraj Prabhu, Yutong Dai, Michael S Ryoo, et al. xgen-mm (blip-3): A family of open large multimodal models. arXiv preprint arXiv:2408.08872, 2024.
- [76] Jianwei Yang, Reuben Tan, Qianhui Wu, Ruijie Zheng, Baolin Peng, Yongyuan Liang, Yu Gu, Mu Cai, Seonghyeon Ye, Joel Jang, et al. Magma: A foundation model for multimodal ai agents. In Proceedings of the Computer Vision and Pattern Recognition Conference, pages 14203–14214, 2025.
- [77] Seonghyeon Ye, Joel Jang, Byeongguk Jeon, Sejune Joo, Jianwei Yang, Baolin Peng, Ajay Mandlekar, Reuben Tan, Yu-Wei Chao, Bill Yuchen Lin, et al. Latent action pretraining from videos. arXiv preprint arXiv:2410.11758, 2024.
- [78] Biao Zhang and Rico Sennrich. Root mean square layer normalization. Advances in Neural Information Processing Systems, 32, 2019.