

通过下一词元预测的上下文模仿学习

傅乐天 (Max (Letian) Fu)^{1*}, 黄煌 (Huang Huang)^{1*}, 高拉夫·达塔 (Gaurav Datta)^{1*}, 劳伦斯·云亮·陈 (Lawrence Yunliang Chen)¹

Will Panitch¹, Fangchen Liu¹, Hui Li², Ken Goldberg¹




图 1：上下文机器人变换器 (ICRT)：具备上下文模仿学习能力的机器人基础模型。ICRT 在大规模感觉运动轨迹上进行下一词元预测。在推理时，它以人类遥操作演示的原始感觉运动轨迹作为提示，使模型能够实时连续控制执行新任务，无需微调。

摘要——我们探索如何为机器人赋予下一词元预测模型的上下文学习能力，使模型能够通过人类遥操作演示示例作为提示来执行新任务，而无需微调。我们提出上下文机器人变换器 (ICRT)，这是一种因果变换器，对包含图像、本体感受状态和动作的感觉运动轨迹进行自回归预测。该方法允许在测试时灵活且无需训练地执行新任务，通过向模型提示新任务的演示轨迹来实现。使用 Franka Emika 机器人的实验表明，ICRT 能够适应由提示指定的新任务，即使在环境配置与提示和训练数据均不同的情况下也是如此。在多任务环境设置中，ICRT 在泛化到未见任务方面显著优于当前最先进的机器人基础模型。代码、检查点和数据可在 <https://icrt.dev> 获取。

I. 引言

基于学习的单任务和多任务机器人策略已变得越来越强大 [1 – 10]。机器人能力的提升在很大程度上归功于相关领域的进展，尤其是视觉和语言建模。受大语言模型 (LLMs) 和大视觉模型 (LVMs) [11 – 13] 近期发展的启发，这些模型将自然语言处理和视觉问题均表述为下一词元预测，近期工作也将机器人学习表述为下一词元预测问题，并取得了最先进的性能 [7, 8, 14, 15]。与此同时，大规模机器人数据集的收集 [16 – 23] 以及在这些数据集上预训练模型 [15, 24 – 27] 也出现了激增。

尽管这些模型在大规模数据集上进行了预训练并展现出一定的泛化能力，但在不进行额外训练的情况下，让它们在不同环境中执行未见过的任务仍然具有挑战性。通常需要借助遥操作获取新的人类演示，或从手工设计的运动基元中收集新数据，并进行另一轮模型微调，

才能完成新任务。这一过程增加了工作流程的复杂度，使得这些方法难以应用于真实环境。理想情况下，给定一个或少数几个演示，机器人应能立即执行任务。在各自领域中，大语言模型 (LLMs) 和大视觉模型 (LVMs) [11 – 13] 已展现出类似的能力，称为上下文学习：一种使模型在推理时无需额外训练即可快速适应并识别提示所对应任务的能力。

下一词元预测模型的上下文学习能力是否仅限于视觉和语言领域？本文提出上下文机器人变换器 (In-Context Robot Transformer, ICRT)，探索如何将下一词元预测模型扩展至真实机器人的上下文学习。对于 ICRT，上下文以与新任务对应的一系列机器人轨迹形式提供。模型从该上下文中学习，在不同环境配置下执行任务，无需额外训练。机器人轨迹是图像观测、机器人本体感受状态和动作的序列。该轨迹隐式编码了任务基元及机器人需要交互的物体。模型从提示中提取这些信息，然后在当前环境中按照相似模式执行动作。

与现有的少样本模仿学习方法相比，ICRT 提供了一个简单的框架，避免了复杂的损失函数、先验知识以及识别关键点或关键帧的需要，并直接对原始机器人轨迹进行操作以实现连续控制。此外，与现有的用于机器人学习的下一标记预测模型不同，ICRT 具有长上下文窗口，使其能够在同一任务的多个感觉运动轨迹上进行训练，并在推理过程中使用一个或多个感觉运动轨迹作为提示。重要的是，我们观察到数据集的某些属性对于在真实机器人上实现上下文学习至关重要。具体而言，允许从同一初始观察执行多个任务的数据集特别有益。与现有的单任务数据集或许多多任务数据集不同，

*同等贡献，¹ 加利福尼亚大学伯克利分校，² 欧特克研究院

任务数据集，其中每个环境都有一个独特的物体供机器人交互，这些场景要求模型依靠提示来正确识别任务并确定合适的交互物体。我们做出以下贡献：

- 1) 本文提出 ICRT，一种在真实机器人上执行上下文学习的机器人基础模型，能够有效地从上下文轨迹中学习，并在无需训练的情况下执行未见过的任务。
- 2) 本文提供了一个新的多任务机器人数据集和一种训练范式，以在推理时培养多任务和上下文能力。
- 3) 在 Franka Emika 机器人上的物理实验表明，ICRT 能够从提供的上下文中学习，并在不同泛化水平上执行提示所指定的未见任务。

II. 相关工作

A. 面向机器人的多任务模仿学习

模仿学习是赋予机器人各种技能的有效范式。该领域中最简单的算法——行为克隆，已在广泛任务中取得成功 [28–30]。近年来，也提出了基于能量的模型 [31] 和扩散模型 [1] 等替代架构。通常，这些方法需要为每个任务训练单独的模型，尽管多任务策略可以在训练后从这些任务特定模型中蒸馏得到 [32]。最新进展表明，在序列建模中使用变换器进行下一词元预测在语言和视觉领域都特别有效，尤其是对于多任务学习 [12, 33, 34]。为了开发通用智能体和多任务机器人策略，机器人动作规划被构建为基于变换器架构的下一词元预测任务，并在大型多任务机器人数据集上进行训练 [5, 7, 8, 14, 15, 35–40]。Octo [15] 和 OpenVLA [14] 代表了多任务机器人策略的最先进水平。Octo [15] 同时以目标图像和语言指令为条件，利用带有扩散头的变换器架构，将这些输入与当前图像观测融合以预测机器人动作。OpenVLA [14] 仅以语言指令为条件，微调预训练的视觉语言模型，根据视觉观测和语言输入预测机器人动作。

B. 上下文学习

尽管在大型数据集上进行了训练，多任务策略在面对新物体、任务或环境时往往表现不佳，通常需要微调。元学习已被证明可以提高微调效率，从而泛化到新任务 [41–43]，这推动了少样本模仿学习的进展。为了简化学习策略在现实世界中的应用，近期方法侧重于避免微调模型参数以实现任务泛化。相反，这些方法通过提供任务演示来教导模型 [44, 45]。Brown 等人 [33]

将其称为“上下文学习”，以区别于依赖参数微调的方法。许多上下文学习方法通常采用对比学习来训练上下文编码器，在潜空间中识别与测试任务最相似的训练任务 [37, 46]。然而，如何将这些方法有效整合到下一词元预测框架中仍不明确。Valassakis 等人 [47] 通过训练视觉伺服网络，在演示过程中使机器人末端执行器与物体的相对位姿对齐，实现了一次性上下文学习，但该方法需要额外的物体分割模型。Di Palo 等人 [44] 提出了关键点动作词元，通过将演示轨迹表示为三维坐标并进行少样本提示，展示了使用大语言模型的上下文模仿学习。与这些方法不同，ICRT 无需额外的感知模块，直接处理原始图像观测。此外，Vid2Robot[45] 开发了一种编码器-解码器变换器，使用人类演示视频和当前机器人状态作为提示来生成机器人动作。然而，该方法需要许多辅助损失，而 ICRT 仅使用简单的下一词元预测损失。本文重点增强下一词元预测模型，以实现机器人在真实环境中的上下文模仿学习。ICRT 通过直接使用新任务的机器人感觉运动轨迹作为基于变换器模型的提示，绕过了对额外上下文编码器的需求。ICRT 与开创性工作一次性模仿学习 [48] 和提示决策变换器 [49] 密切相关。[48] 通过在新任务的演示序列与当前环境状态之间应用交叉注意力来预测下一动作，而 [49] 使用短轨迹提示编码任务特定信息，以指导离线强化学习中的策略生成，使用完整状态信息和已知奖励函数。虽然这两种方法在仿真中展示了有效性，但很难为所有真实世界机器人操作任务获得完整状态信息和已知奖励函数。为应对这些挑战，ICRT 不建模奖励，利用显著更长的上下文窗口，并在图像观测的物理实验中展示了上下文学习能力。

III. 问题陈述

我们考虑在真实机器人操作环境下的上下文模仿学习。目标是利用多任务机器人数据集训练一个具备上下文学习能力的模型。在测试时，模型通过使用少量新的人类遥操作机器人演示作为提示，即可处理新环境配置下的未见任务。这里，环境配置指场景中存在的物体及其空间布局。值得注意的是，这一过程无需对新演示进行任何额外训练。我们将运动原语定义为用于完成各种任务的不同机器人动作。每个任务的特征




图 2: 我们的物理实验装置, 包括 Franka Emika 机器人、腕部相机和侧面相机, 以及训练和评估中使用的物体。我们考虑 6 种原语用于训练, 并选择“拾取并放置”和“戳”作为评估原语 (深绿色)。

由 1) 特定的运动原语和 2) 机器人使用该原语交互的物体集合来表征。通过在测试时改变环境配置 (与提示中的配置相比), 我们评估模型选择合适运动原语并识别正确交互物体的能力。在这项工作中, 我们将新任务定义为涉及未见物体但使用训练数据中运动原语的任务 (例如, 训练时拾取老虎玩具, 测试时拾取立方体)。我们对 ICRT 实验做出以下假设: 1) 模型在多样化的多任务演示数据集上训练。每条轨迹包含来自固定相机和腕部相机的 RGB 观测、本体感知和动作。

2) 在机器人上测试的任务位于机器人可达工作空间内。

四、方法

在本节中, 我们首先介绍促进上下文模仿学习的数据构成。然后, 我们介绍基于变换器的策略的架构和训练目标, 以有效利用数据。

A. 数据公式化

对于模型训练, 我们考虑一个数据集 $\mathcal{D}$ 视觉运动轨迹 $\mathcal{T}$ 。每条长度为 t 是一系列相机图像 i_t , 本体感受机器人状态 s_t , 与行动 a_t : $\mathcal{T} = (i_1, s_1, a_1, \dots, i_t, s_t, a_t)$ 我们采用末端执行器的绝对位姿作为机器人的本体感知状态, 并将时间步之间的并联机器人末端执行器位姿变化作为动作, 该动作由平移增量、旋转增量以及连续的夹爪动作组成。我们假设轨迹分组已知, 从而可将数据集划分为互不相交的任务集合 $\mathcal{D} = \bigcup^K \mathcal{D}_k$, 其中 $\mathcal{D}_k = \{\mathcal{T}_{k_1}, \dots, \mathcal{T}_{k_n}\}$ 。在实际中, 可以从数据集的语义标签中获取这种分组。在这项工作中, 我们利用现有的大型机器人数据集 DROID[50] 以及在我们的机器人平台上手动收集的多任务数据集, 我们将其命名为 ICRT-Multi-Task (ICRT-MT)。DROID[50] 是不同组织的联合成果, 包含 76k 个真实世界演示。在过滤掉短于 30 步和长于 450 步的演示后, 我们从 DROID 中随机抽取 10k 个演示。DROID 数据集通过人工指定的语言指令来标记任务, 对于

同一任务, 这些指令可能不同。我们通过基于语言指令的 CLIP 文本嵌入余弦相似度对演示进行分组来组织 DROID 数据。具体来说, 我们使用 0.9 的阈值对演示进行分组。为了进一步促进上下文学习, 我们确保每个任务组至少包含 4 条轨迹, 以便有足够的轨迹相互作为提示。这产生了大约 2k 条轨迹, 用于预训练 ICRT。

DROID 数据集集中的许多轨迹是在单任务设置下采集的, 即一个场景中只能完成一个任务 (例如只呈现一个物体)。在这种设置下, 模型可以学习一种捷径解决方案来执行任务, 即只关注当前观测而不关注提示。因此, 多任务数据对于模型从提示中学习至关重要。我们使用 DROID 设置手动采集了一个多任务数据集 ICRT-Multi-Task (ICRT-MT) (图 2)。该数据集共有 1098 条轨迹, 包含 29 个任务和 6 种基本操作: 抓取、抓取放置、堆叠、推动、戳动、开关抽屉。数据采集所用的物体和基本操作示例见图 2。在 ICRT-MT 中, 每个环境都设置为当前观测存在超过 2 个可能任务, 因此模型必须从提示中区分并学习运动。

在训练过程中, 对于每条轨迹, 我们独立地对图像观测应用视觉增强, 包括调整亮度和对比度。此外, 我们对侧面相机观测应用随机裁剪和缩放。我们还施加从正态高斯分布 $\mathcal{N}(0, 0.005)$ 采样的本体感觉噪声。对于每个训练轮次, 我们随机打乱每个任务的轨迹顺序, 并将它们连接起来形成训练序列。对于每个批次, 我们采样长度为 $L = 512$ 的子序列作为模型输入, 其中 L 是序列长度, 定义为观测、状态和动作元组的数量。实际上, 512 步通常包含来自同一任务的最多 5 条轨迹。我们随机选择前 k 条轨迹, 并将它们标记为序列内的提示。提示中至少包含一条完整轨迹。这种数据分组旨在捕捉轨迹间模式, 鼓励模型根据提示轨迹生成动作。这种方法不同于传统的行为克隆方法, 后者通常使用短输入序列, 侧重于建模轨迹内行为。




图 3：方法概览：（左）我们使用预训练的视觉变换器对相机观测进行编码。此外，我们使用多层感知机对本体感知进行编码。我们将视觉潜变量与本体感知潜变量拼接，并使用注意力池化提取特征 f_s 作为当前状态表示。我们使用多层感知机对当前动作进行编码，得到 f_a 。（右）我们将同一任务的多个轨迹拼接，并随机采样前 k 条轨迹作为提示。因果变换器自回归地预测下一系列标记。我们解码位于状态特征位置的标记，通过多层感知机生成下一个 $h = 16$ 动作。

B. 模型架构

我们构建的 ICRT 模型由三部分组成：预训练视觉编码器、针对每种输入模态的一系列投影器，以及因果变换器主干网络（图 3）。

视觉编码器 模型通过预训练的视觉变换器处理多视角图像观测。然而，大多数视觉预训练网络是在 ImageNet 或人类视频 [24, 27, 51, 52] 上训练的，与机器人数据集的典型图像相比存在显著的领域差距，后者图像中经常包含机器人或夹爪。为最小化领域差距，我们在 ImageNet[54] 和 Open X-Embodiment[40] 数据的等量混合上预训练视觉变换器 [53]（ViT-Base），使用 CrossMAE 作为高效的预训练方法 [55]。在训练 ICRT 模型期间，我们冻结视觉编码器以提高效率。视觉编码器输出每个相机的完整特征图，然后输入到本体感知投影器（图 3 左）。

模态特定投影器 为将图像观测、机器人本体感知状态和动作投影到共享潜空间以进行序列建模，我们设计了模态特定的投影器。在每个时间步，模型接收一个表示观测或动作的标记。为生成一个能捕获细粒度视觉信息和机器人本体感知状态的单一状态标记，我们在单个相机观测的所有视觉标记与由多层感知机（MLP）生成的本体感知嵌入之间使用注意力池化 [56]。每个相机得到的嵌入被拼接，生成一个维度等于变换器的单一状态标记 f_s^t 潜在维度。与本体感知类似，动作通过多层感知机嵌入为动作令牌 f_a^t 。该过程生成状态与动作令牌序列，并输入至变换器。

变换器模型 编码后的状态与动作序列输入至变换器模型 [57]，遵循 Llama2 的设计 [12]。变换器以模态特定投影器生成的状态与动作特征序列 $(f_s^1, f_a^1, \dots, f_s^t, f_a^t)$ 作为输入。我们添加多层感知机解码器，在适当位置从变换器最后一层生成状态与动作输出。我们将带有解码器头的变换器表示为

g_θ 。

因此，期望输出为本体感知状态与动作的移位序列 $(a^1, s^2, a^2, \dots, a^t, s^{t+1})$ 。这自然构成下一个令牌预测问

$g_\theta(f_s^1) \quad a^1 \quad g_\theta(f_s^1, f_a^1, \dots, f_s^n) \quad a^{n+1}$ 。In 题，因为预测和预测实践表明，在每个时间步预测下一个 h 动作并使用时间集成 [2] 执行最终动作是有益的。

受 Octo[15] 与视觉变换器 [53] 启发，我们考虑一个随机初始化的 12 层 Llama2 模型，潜在维度为 768，命名为 Llama2-Base。此外，多项工作表明多模态输入可与大语言模型对齐 [8, 34, 58 – 60]。多模态语言模型 Palm-E[10] 在直接融入机器人控制时展现出增强泛化能力的成功 [8]。因此，我们还研究了使用大语言模型进行上下文机器人学习的有效性，通过用预训练的 Llama2-7B 初始化变换器。由于自然语言与机器人轨迹之间存在巨大领域差距，冻结的语言模型可能不足。因此，与先前多模态对齐工作类似，我们使用秩为 32 的 LoRA[61] 微调语言模型。由于计算资源限制，我们无法完全微调模型。

损失函数 为了提供更多的监督信号，使模型能够更好地响应我们在测试时提供的轨迹“提示”，我们参考了训练多轮对话聊天机器人的工作 [34, 62]，其中他们只计算聊天机器人生成的回复的损失，而不是提示的损失。回顾在第四节 A 部分，我们随机采样拼接轨迹的子序列作为提示轨迹。类似地，我们只对提示轨迹之后的动作计算 L1 损失的动作预测。推理下一个标记预测目标的简单性使得在测试时使用 ICRT 进行推理变得直接。如图 4 所示，我们提供一个或多个个人类遥操作演示，形式为机器人感觉运动轨迹（格式与训练数据相同），以及当前图像观测和机器人本体感受状态作为输入。然后模型预测下一个动作，由机器人执行。在每个动作之后，策略接收更新的图像观测和本体感受状态，使其能够迭代地预测和执行后续动作。




图 4: ICRT 在拾取萝卜并放入灰色碗任务上的示例推理流程。一个由图像观测、本体感受和动作组成的人类遥操作演示轨迹作为提示提供。ICRT 接收提示和不同环境中的当前观测以完成任务。

该框架的一个关键优势在于利用了变换器的顺序处理能力。与之前工作中每次模型评估都重新处理整个序列历史不同 [7, 8, 14, 15], 模型采用了键值 (KV) 缓存机制, 如 [12] 中所述。该机制存储先前的输出, 使模型只需计算新标记的输出。这种方法显著降低了计算开销, 将复杂度从相对于序列长度的二次方降低到线性。经验上, ICRT 可以以 39.6 Hz 的频率进行推理, 使其能够执行实时闭环控制。

五、实验

在本节中, 我们设计了一个实验设置来评估所提出模型的上下文学习能力, 并将其与几个基线进行比较。我们不是专注于学习特定任务原语的难度, 而是设计实验来评估策略基于提供的提示轨迹完成新任务的能力。

实验设计 本文考虑两种动作基元: 抓取-放置基元与拨动基元。针对每种动作基元, 设计了六个未见任务 (定义见第三节), 其中三个任务评估域内物体泛化 (从黄色立方体、红色立方体、黑色立方体、粉色碗和蓝色熊中选取), 另外三个任务使用训练期间未见过的物体 (从萝卜、蓝色海绵、灰色狗和黑色狗中选取)。每个任务包含五个难度层级。在抓取-放置任务中, 模型必须在多物体或多放置位置场景中识别正确的抓取物体及其放置位置。层级包括: 1) 无干扰物, 2) 一个干扰物, 3) 两个干扰物, 4) 三个干扰物, 5) 一个干扰放置位置。在拨动任务中, 机器人闭合夹爪, 拨动物体, 抬起末端执行器, 然后打开夹爪, 层级涉及 0 至 4 个干扰物体。抓取-放置任务的评分规则为: 正确抓取得 0.5 分, 成功放置得 1 分。拨动任务中, 若拨错物体则判定失败。模型有 25 秒 (375 步) 的重试时间。每个难度层级仅尝试一次, 报告每个任务的平均成功率, 以及每种动作基元在六个任务上的平均成功率和标准差。

	Pick and Place	Poke	Average
Goal Condition	33.3 (± 6.5)	6.7 (± 4.6)	20.0 (± 4.3)
Octo [15]	5.0 (± 2.7)	13.3 (± 6.2)	9.2 (± 3.5)
OpenVLA [14]	11.7 (± 4.6)	3.3 (± 3.3)	7.5 (± 2.9)
ICRT	65.0 (± 7.3)	93.3 (± 4.6)	79.2 (± 4.6)

表一: 主要结果。ICRT 在抓取-放置和拨动任务中均优于两种以目标或语言为条件的最先进机器人基础模型。针对每种任务基元, 使用六个训练期间未见过的任务进行评估, 每个任务进行五次试验, 每种基元共 30 次试验, 总计 60 次试验以计算平均性能。对于每个模型, 报告每个任务的平均成功率、总体成功率以及括号中的相应标准误。

模型 默认的 ICRT 是一个随机初始化的 Llama2-Base 模型, 在 DROID 上预训练, 并在 ICRT-MT 上完全微调。通过引入以下三种变体, 评估模型初始化和训练数据集的影响:

1) 上下文机器人变换器 (ICRT) -Llama2, 一个预训练的 Llama2-7B 语言模型, 使用 LoRA 在 ICRT-MT 上微调; 2) ICRT (DROID), 一个随机初始化的 Llama2-Base 模型, 仅在 DROID 数据集上训练; 3) ICRT (MT), 一个随机初始化的 Llama2-Base 模型, 仅在 ICRT-MT 数据集上训练。

我们考虑了 3 个基线模型。我们训练了一个目标条件策略, 其中目标观测始终被前置到序列中, 且每个序列来自一条轨迹。这类似于常规的目标条件模仿学习设置。此外, 我们微调了 Octo [15], 这是最先进的目标图像和语言条件策略, 以及 OpenVLA [14], 这是最先进的语言条件多任务模仿学习策略。Octo 使用其官方微调配方进行微调。我们将动作分块引入 OpenVLA, 要求其预测接下来的 16 个动作, 这比仅预测下一步的原始 OpenVLA 表现更好。这两种方法都代表了使用下一标记预测目标的机器人策略。

提示生成 对于每个任务, 我们在运行实验前总共收集 3 个演示 (对于抓取放置任务, 包含零个、一个干扰物、一个干扰物放置位置, 或对于戳刺任务包含两个干扰物) 作为提示。请参阅网站获取可视化示例。在测试期间, 随机抽取一个演示作为提示, 以评估模型对不同提示的泛化能力。需要注意的是, 策略执行期间的环境设置与提示的设置不同, 这确保了评估衡量的是模型从提示中理解任务相关信息的能力, 而不是简单地复制其中的动作。结果我们在表 I 中呈现结果。对于抓取放置原语, 我们观察到当没有干扰物存在时, 目标条件策略通常能够成功识别要抓取的正确物体。然而, 随着干扰物数量的增加, 其性能显著下降。当目标图像仅指定任务而未指定在当前环境中实现任务的具体方式时, 目标条件策略往往无法有效执行任务。Octo 在确定与哪个物体交互以及应将其放置在何处方面存在困难, 这凸显了我们的实验设置对多任务策略带来的挑战。OpenVLA 虽然经常朝正确的方向移动

抓取 放置 戳刺 平均			
ICRT-Llama2 ICRT	43.3 (± 7.9)	73.3 (± 8.2)	58.3 (± 6.0)
(DROID) ICRT (MT)	0.0 (± 0.0)	0.0 (± 0.0)	0.0 (± 0.0)
ICRT +提示损失	76.7 (± 7.1)	70.0 (± 8.5)	73.3 (± 5.5)
	21.7 (± 7.9)	23.9 (± 7.9)	22.5 (± 5.0)
	65.0 (± 7.3)	93.3 (± 4.6)	79.2 (± 4.6)

表 II：消融实验。本文消融了三个关键设计选择：使用语言模型微调 ICRT、仅在相关数据集或微调数据集上训练，以及在训练过程中加入提示损失的影响。本文报告了拾取放置和戳刺任务的平均成功率及其对应的标准误，以及整体平均性能。

物体，经常无法抓住物体或错误地执行任务（例如，抓取而非戳刺，反之亦然）。这表明 OpenVLA 可能需要每个任务更多的演示（超过 50 次）才能达到更好的性能，并且仅依赖语言条件可能不足以泛化到新任务。结果表明，ICRT 在识别正确拾取物体和适当放置位置方面优于目标条件策略。戳刺任务对目标条件策略构成重大挑战，因为目标位置通常与起始配置非常相似。然而，在以提示轨迹为条件后，ICRT 能够正确识别任务为戳刺，结果表明它始终到达正确的目标物体，同时忽略干扰物。尽管如此，我们确实观察到 ICRT 的一些失败模式，例如错过目标物体的抓取、抓错物体或将物体放置在错误位置。具体来说，当干扰物与目标物体颜色相同但形状不同时，模型难以准确确定要抓取哪个物体。这意味着可能需要对视觉编码器进行额外的微调以增强模型性能，OpenVLA 也得出了这一结论 [14]。

六、消融实验

在本节中，我们提供了额外的实验表二对若干核心设计选择进行了消融。更多消融研究详见官方网站。

A. 模型初始化

我们进行了消融研究，以检验使用在语言数据上预训练的 Llama2 并针对机器人感觉运动序列建模进行微调的影响。表 II 中呈现的结果表明，尽管 ICRT-Llama2-7B 实现了更低的训练损失，但其性能相较于更小的模型更差。这种差异可能归因于 ICRT-Llama2 较低的推理频率（10.7 Hz 对 39.6 Hz）。未来工作可以专注于优化 ICRT-Llama2 的推理速度以提升性能。

B. 训练数据集

我们发现，在 DROID 子集上进行训练（见第 IV-A 节）不足以完成任何测试任务；策略（ICRT（DROID））在所有任务上均无进展。这表明，尽管 DROID 子集可能

提供更大的视觉多样性，但 ICRT-MT 的独特结构——即多个任务从同一初始观测执行——对于发展下一词元预测机器人模型的上下文学习能力尤为有益。

ICRT（MT）与在 DROID 上预训练的 ICRT 表现出相似的性能，尤其是在拾取和放置基元上，甚至在将萝卜放入灰色碗的任务上超越了 ICRT。然而，ICRT（MT）在戳刺基元上表现不佳。结果表明，在大规模数据集上预训练自回归模型可能是有益的，因为多样化的数据集可能有助于变换器在视觉特征与控制之间实现更好的对齐。

C. 无提示损失

遵循许多多轮对话大语言模型或视觉语言模型微调工作的设计 [34, 62 – 64]，我们不对提示轨迹中的预测动作计算损失，而仅对提示轨迹之后的预测计算损失。我们将对提示计算损失的模型标记为 ICRT +提示损失，默认模型标记为 ICRT。结果见表 II。我们发现，仅在指定提示轨迹之后预测轨迹可以显著提升模型性能。我们假设，在提示轨迹存在损失的情况下，模型被迫基于当前观测对这些提示进行无条件生成。这可能导致模型停止关注提示，尤其是在存在多个可能任务的情况下。

VII. 局限性与结论

虽然结果表明，ICRT 能从提示轨迹中学习，并泛化到未见过的物体、任务以及某些与训练中相似的基元¹，但如何泛化到完全未见过的动作基元仍不清楚。未来的工作应研究如何通过扩大模型容量和数据集规模来帮助实现基元级别的泛化。此外，ICRT 假设机器人形态固定且阻抗控制器固定。未来的工作还可以研究如何通过不同机器人上学习统一策略来促进不同机器人形态之间的迁移。ICRT-Llama2 的推理频率较低，这可能是其性能较低的原因之一。我们希望未来能加快 ICRT-Llama2 的推理速度。

总之，我们提出了 ICRT，在其中我们研究了在真实机器人上的上下文内、

多任务模仿学习。我们通过在机器人轨迹序列上训练因果变换器模型来实现这一点，其中来自同一任务的轨迹被组合起来为任务执行提供上下文。此外，我们引入了一个多任务数据集来促进这种上下文学习方法。我们的实验表明，通过使用机器人感觉运动轨迹作为上下文，模型可以将学习到的运动基元泛化到未见过的物体和新颖的环境配置中，特别是在存在多个任务的场景中。

¹ 更多细节请参阅附录和网站上的视频。

VIII. 致谢

本研究在加州大学伯克利分校 AUTOLAB 进行, 隶属于伯克利人工智能研究 (BAIR) 实验室和 CITRIS “人与机器人” (CPAR) 倡议。在加州大学伯克利分校的学术职务中, Letian Fu、Huang Huang、Gaurav Datta、Lawrence Yunliang Chen、William Chung-Ho Panitch、Fangchen Liu 和 Ken Goldberg 部分得到了 Autodesk、Meta、Google、Siemens、Toyota Research Institute、Bosch 的捐赠支持, 以及 PhotoNeo、Nvidia、NSF AI4OPT 中心和 Intuitive Surgical 的设备资助。L.Y. Chen 还得到了美国国家科学基金会 (NSF) 研究生研究奖学金计划的支持, 资助号为 2146752。我们感谢 Jiayi Pan、Xinyang Geng、Dantong Niu 和 Chung Min Kim 的有益讨论和反馈。

参考文献

- [1] C. Chi *et al.*, “Diffusion policy: Visuomotor policy learning via action diffusion,” *arXiv preprint arXiv:2303.04137*, 2023.
- [2] T. Z. Zhao, V. Kumar, S. Levine, and C. Finn, “Learning fine-grained bimanual manipulation with low-cost hardware,” *arXiv preprint arXiv:2304.13705*, 2023.
- [3] C. Lynch *et al.*, “Interactive language: Talking to robots in real time,” *IEEE Robotics and Automation Letters*, 2023.
- [4] S. Reed *et al.*, “A generalist agent,” *arXiv:2205.06175*, 2022.
- [5] D. Shah *et al.*, “ViNT: A Foundation Model for Visual Navigation,” in *7th Annual Conference on Robot Learning (CoRL)*, 2023.
- [6] H. Bharadhwaj, J. Vakil, M. Sharma, A. Gupta, S. Tulsiani, and V. Kumar, “RoboAgent: Towards sample efficient robot manipulation with semantic augmentations and action chunking,” *arxiv*, 2023.
- [7] A. Brohan *et al.*, “Rt-1: Robotics transformer for real-world control at scale,” *arXiv:2212.06817*, 2022.
- [8] A. Brohan *et al.*, “RT-2: Vision-language-action models transfer web knowledge to robotic control,” *arXiv preprint arXiv:2307.15818*, 2023.
- [9] X. Chen *et al.*, *Pali-x: On scaling up a multilingual vision and language model*, 2023. arXiv: 2305.18565 [cs.CV].
- [10] D. Driess *et al.*, “Palm-e: An embodied multimodal language model,” *arXiv:2303.03378*, 2023.
- [11] J. Achiam *et al.*, “Gpt-4 technical report,” *arXiv preprint arXiv:2303.08774*, 2023.
- [12] H. Touvron *et al.*, “Llama 2: Open foundation and fine-tuned chat models,” *arXiv preprint arXiv:2307.09288*, 2023.
- [13] Y. Bai *et al.*, “Sequential modeling enables scalable learning for large vision models,” *arXiv preprint arXiv:2312.00785*, 2023.
- [14] M. J. Kim *et al.*, *Openvla: An open-source vision-language-action model*, 2024. arXiv: 2406.09246 [cs.RO].
- [15] Octo Model Team *et al.*, “Octo: An open-source generalist robot policy,” in *Proceedings of Robotics: Science and Systems*, Delft, Netherlands, 2024.
- [16] A. Depierre, E. Dellandréa, and L. Chen, “Jacquard: A large scale dataset for robotic grasp detection,” in *2018 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, IEEE, 2018, pp. 3511–3516.
- [17] D. Kalashnikov *et al.*, “Scalable deep reinforcement learning for vision-based robotic manipulation,” in *CoRL*, 2018.
- [18] S. Levine, P. Pastor, A. Krizhevsky, J. Ibarz, and D. Quillen, “Learning hand-eye coordination for robotic grasping with deep learning and large-scale data collection,” *IJRR*, 2018.
- [19] C. Eppner, A. Mousavian, and D. Fox, “ACRONYM: A large-scale grasp dataset based on simulation,” in *2021 IEEE Int. Conf. on Robotics and Automation, ICRA*, 2020.
- [20] N. M. M. Shafullah *et al.*, *On bringing robots home*, 2023. arXiv: 2311.16098 [cs.RO].
- [21] H.-S. Fang *et al.*, “RH20T: A robotic dataset for learning diverse skills in one-shot,” in *RSS 2023 Workshop on Learning for Task and Motion Planning*, 2023.
- [22] F. Ebert *et al.*, “Bridge data: Boosting generalization of robotic skills with cross-domain datasets,” *arXiv:2109.13396*, 2021.
- [23] H. Walke *et al.*, *Bridgedata v2: A dataset for robot learning at scale*, 2023. arXiv: 2308.12952 [cs.RO].
- [24] S. Nair, A. Rajeswaran, V. Kumar, C. Finn, and A. Gupta, “R3m: A universal visual representation for robot manipulation,” *arXiv:2203.12601*, 2022.
- [25] T. Xiao, I. Radosavovic, T. Darrell, and J. Malik, “Masked visual pre-training for motor control,” *arXiv:2203.06173*, 2022.
- [26] Y. J. Ma, S. Sodhani, D. Jayaraman, O. Bastani, V. Kumar, and A. Zhang, “Vip: Towards universal visual reward and representation via value-implicit pre-training,” *arXiv preprint arXiv:2210.00030*, 2022.
- [27] I. Radosavovic, T. Xiao, S. James, P. Abbeel, J. Malik, and T. Darrell, “Real-world robot learning with masked visual pre-training,” *arXiv:2210.03109*, 2022.
- [28] D. A. Pomerleau, “Alvin: An autonomous land vehicle in a neural network,” in *NeurIPS*, D. Touretzky, Ed., vol. 1, Morgan-Kaufmann, 1988.
- [29] B. D. Argall, S. Chernova, M. Veloso, and B. Browning, “A survey of robot learning from demonstration,” *Robotics and autonomous systems*, vol. 57, no. 5, pp. 469–483, 2009.
- [30] S. Levine, C. Finn, T. Darrell, and P. Abbeel, “End-to-end training of deep visuomotor policies,” *JMLR*, 2016.
- [31] P. R. Florence *et al.*, “Implicit behavioral cloning,” in *CoRL*, 2021.
- [32] H. Ha, P. Florence, and S. Song, “Scaling up and distilling down: Language-guided robot skill acquisition,” in *Conference on Robot Learning*, PMLR, 2023, pp. 3766–3777.
- [33] T. B. Brown *et al.*, “Language models are few-shot learners,” *NeurIPS*, 2020.
- [34] H. Liu, C. Li, Q. Wu, and Y. J. Lee, “Visual instruction tuning,” in *NeurIPS*, 2023.
- [35] I. Radosavovic, B. Shi, L. Fu, K. Goldberg, T. Darrell, and J. Malik, “Robot learning with sensorimotor pre-training,” *arXiv:2306.10007*, 2023.
- [36] I. Radosavovic *et al.*, *Humanoid locomotion as next token prediction*, 2024. arXiv: 2402.19469 [cs.RO].
- [37] E. Jang *et al.*, “Bc-z: Zero-shot task generalization with robotic imitation learning,” in *Conference on Robot Learning*, 2022.
- [38] Y. Jiang *et al.*, “VIMA: General robot manipulation with multimodal prompts,” *International Conference on Machine Learning (ICML)*, 2023.
- [39] S. Reed *et al.*, “A generalist agent,” *arXiv preprint arXiv:2205.06175*, 2022.
- [40] E. Collaboration *et al.*, *Open x-embodiment: Robotic learning datasets and rt-x models*, 2024. arXiv: 2310.08864 [cs.RO].
- [41] C. Finn, P. Abbeel, and S. Levine, “Model-agnostic meta-learning for fast adaptation of deep networks,” in *International conference on machine learning*, PMLR, 2017, pp. 1126–1135.
- [42] C. Finn, T. Yu, T. Zhang, P. Abbeel, and S. Levine, “One-shot visual imitation learning via meta-learning,” in *Conference on robot learning*, PMLR, 2017, pp. 357–368.
- [43] M. Xu, Y. Lu, Y. Shen, S. Zhang, D. Zhao, and C. Gan, “Hyperdecision transformer for efficient online policy adaptation,” *arXiv preprint arXiv:2304.08487*, 2023.
- [44] N. Di Palo and E. Johns, “Keypoint action tokens enable in-context imitation learning in robotics,” *arXiv preprint arXiv:2403.19578*, 2024.
- [45] V. Jain *et al.*, “Vid2robot: End-to-end video-conditioned policy learning with cross-attention transformers,” *arXiv preprint arXiv:2403.12943*, 2024.
- [46] Z. Mandi, F. Liu, K. Lee, and P. Abbeel, *Towards more generalizable one-shot visual imitation learning*, 2022. arXiv: 2110.13423 [cs.RO].
- [47] E. Valassakis, G. Papagiannis, N. Di Palo, and E. Johns, “Demonstrate once, imitate immediately (dome): Learning visual servoing for one-shot imitation learning,” in *2022 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, IEEE, 2022, pp. 8614–8621.
- [48] Y. Duan *et al.*, “One-shot imitation learning,” *Advances in neural information processing systems*, vol. 30, 2017.
- [49] M. Xu *et al.*, “Prompting decision transformer for few-shot policy generalization,” in *international conference on machine learning*, PMLR, 2022, pp. 24 631–24 645.
- [50] A. Khazatsky *et al.*, *Droid: A large-scale in-the-wild robot manipulation dataset*, 2024. arXiv: 2403.12945 [cs.RO].

- [51] A. Majumdar *et al.*, “Where are we in the search for an artificial visual cortex for embodied intelligence?” *arXiv preprint arXiv:2303.18240*, 2023. arXiv: 2303.18240 [cs.CV].
- [52] S. Chen, R. Garcia, I. Laptev, and C. Schmid, “Sugar: Pre-training 3d visual representations for robotics,” *arXiv preprint arXiv:2404.01491*, 2024.
- [53] A. Dosovitskiy *et al.*, “An image is worth 16x16 words: Transformers for image recognition at scale,” in *ICLR*, 2020.
- [54] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei, “Imagenet: A large-scale hierarchical image database,” in *CVPR*, 2009.
- [55] L. Fu *et al.*, “Rethinking patch dependence for masked autoencoders,” *arXiv preprint arXiv:2401.14391*, 2024.
- [56] J. Lee, Y. Lee, J. Kim, A. Kosiorek, S. Choi, and Y. W. Teh, “Set transformer: A framework for attention-based permutation-invariant neural networks,” in *International conference on machine learning*, PMLR, 2019, pp. 3744–3753.
- [57] A. Vaswani *et al.*, “Attention is all you need,” in *NeurIPS*, 2017.
- [58] J. Han *et al.*, *Imagebind-llm: Multi-modality instruction tuning*, 2023. arXiv: 2309.03905 [cs.MM].
- [59] L. Fu *et al.*, “A touch, vision, and language dataset for multimodal alignment,” *arXiv preprint arXiv:2402.13232*, 2024.
- [60] S. Mirchandani *et al.*, *Large language models as general pattern machines*, 2023. arXiv: 2307.04721 [cs.AI].
- [61] E. J. Hu *et al.*, “Lora: Low-rank adaptation of large language models,” *arXiv preprint arXiv:2106.09685*, 2021.
- [62] W.-L. Chiang *et al.*, “Vicuna: An open-source chatbot impressing gpt-4 with 90%* chatgpt quality,” See <https://vicuna.lmsys.org> (accessed 14 April 2023), vol. 2, no. 3, p. 6, 2023.
- [63] H. Liu, C. Li, Y. Li, and Y. J. Lee, *Improved baselines with visual instruction tuning*, 2023.
- [64] W. Dai *et al.*, “Instructblip: Towards general-purpose vision-language models with instruction tuning,” *Advances in Neural Information Processing Systems*, vol. 36, 2024.

IX. SUPPLEMENTARY MATERIAL

A. 场景插图

我们在图 5 中展示了“捡起黑狗并放入粉色碗中”任务的提示轨迹和测试场景的图示。如第五节所述，我们收集了 3 种类型的提示轨迹，并在 5 个与提示轨迹场景不同的场景层级上测试了 ICRT。




图 5：“捡起黑狗并放入粉色碗中”任务的提示轨迹（上）和测试场景（下）图示。收集了三种不同类型的提示轨迹。测试场景与所有提示轨迹不同，并考虑了具有不同干扰物数量的 5 个场景层级。

B. 消融研究

在本节中，我们针对几个核心设计选择和不同的提示策略提供了额外的消融实验。

1) 可重复性实验：我们进行实验以评估 ICRT 性能的可重复性。我们执行“捡起黑狗并放入粉色碗中”任务和“戳蓝色海绵”任务，各进行 5 次 rollout，每次 rollout 包含如第五节所述的 5 次试验，总计 25 次试验。我们计算成功率的平均值和标准差。结果如表 III 所示。表 III 中的低标准差表明 ICRT 能够可靠地完成任

Task	Pick and Place Block Dog in Pink Bowl	Poke Blue Sponge
Success Rate Ave. $\pm$ Std.	60% $\pm$ 0.5%	88% $\pm$ 3.2%

表 III：拾取放置任务和戳刺任务的可重复性实验。每个任务进行 5 次 rollout，每次 rollout 包含 5 次试验，总计 25 次试验。

Prompt Type	No Distractor	One Distractor	Distractor Placement	Two Prompts	Three Prompts
Success Rate	60%	80%	70%	80%	80%

表 IV：在“捡起黑狗并放入粉色碗中”任务上不同提示类型的实验。前三列是单一不同类型提示轨迹的结果，后两列是使用两个和三个提示的结果。每个实验的成功率基于 5 次试验计算。

2) 提示轨迹: 本文针对不同提示类型开展实验, 以评估不同提示轨迹对任务性能的影响。所考虑的任务为拾取黑色狗并放置于粉色碗中。本文设计了三种不同类型的提示轨迹: 一种无干扰物, 一种含一个干扰物, 另一种含一个干扰物放置位置, 如附录图 5 顶部所示。所有三种提示轨迹均由人类遥操作机器人采集。测试时的物体位置与放置位置均不同于三种提示中的位置。如第五节所述, 针对每种提示类型, 本文以 5 次试验执行任务, 如附录图 5 底部所示。平均成功率报告于表四。本文分别采用一条不同类型提示轨迹 (表四前三列)、两条提示轨迹及三条提示轨迹进行实验。所有提示类型均取得相近性能, 表明 ICRT 对提示轨迹类型不敏感。本文推测原因在于训练过程中 ICRT 已见过不同类型与数量的提示。

—任务 抓取并放下玩具老虎 抓取并放下蓝色海绵 将蓝色海绵置于玩具老虎右侧 成功率 40% 80% 80%—

表五: 使用两种未见原语的三项任务实验。成功率基于每项实验 5 次试验计算。

3) 未见原语: 本文评估 ICRT 在训练期间未见但类似于训练原语的原语上的泛化能力。本文考虑两种此类未见原语: 抓取并放下物体, 以及将物体 A 置于物体 B 右侧。本文考虑三项任务: 抓取并放下玩具老虎、抓取并放下蓝色海绵 (训练期间未见物体) 以及将蓝色海绵置于玩具老虎右侧。如第五节所述, 每项任务进行 5 次试验。

实验结果汇总于表五, ICRT 在三项任务上均表现出可观的成功率, 表明 ICRT 能够泛化至某些类似于训练原语的未见原语。

4) 协同训练: 为训练 ICRT, 我们选择将训练分为两个阶段: 预训练阶段, 模型在 DROID 数据集 [50] 上进行预训练; 微调阶段, 模型在 ICIL-MT 数据集上进行训练。在本消融实验中, 我们尝试将这两个阶段合并为单一阶段, 即策略使用 DROID 和 ICIL-MT 进行端到端训练。为平衡两个数据集, 我们首先计算两个数据集中每个任务轨迹数的中位数, 然后在每个训练轮次中, 按中位数轨迹数对每个任务进行采样。这样每个任务在每个训练轮次中都能得到同等表示。我们使用与 ICRT 微调相同的训练轮次数训练模型, 结果见表 VI。结果表明, 在合并阶段模型收敛速度较慢, 无法有效响应提示并完成任务。我们推测有两个原因: 首先, 数据集严重偏向 DROID, DROID 包含 200 个任务, 而 ICIL-MT 仅有 29 个任务, 这使得模型难以像分阶段训练那样有效地学习任务。未来工作可以分析数据混合以及如何更有效地利用大规模数据集进行训练。

	Pick and Place	Poke	Average
ICRT (Co-train)	13.3 (± 5.8)	0.0 (± 0.0)	6.7 (± 3.0)
ICRT	65.0 (± 7.3)	93.3 (± 4.6)	79.2 (± 4.6)

表 VI: 与 DROID[50] 协同训练的消融实验。在单一阶段同时训练 DROID 和 ICRT-MT 数据集会导致拾取放置和戳刺任务的性能均下降。与表 I 相同, 我们使用训练期间未见过的六个任务评估每个动作基元, 每个任务进行五次试验, 每个基元共 30 次试验, 总计 60 次试验以计算平均性能。对于每个模型, 我们报告每个任务的平均成功率、总体成功率以及括号中的相应标准误。

C. 详细结果

在本节中, 我们展示拾取放置基元 (表 VII) 和戳刺基元 (表 VIII) 的逐任务性能。对于每个动作基元, 我们设计了六个未见过的任务 (如第三节所定义), 其中三个任务评估域内物体泛化 (从黄色立方体、红色立方体、黑色立方体、粉色碗和蓝色熊中选择), 另外三个物体在训练期间未见 (从萝卜、蓝色海绵、灰色狗和黑色狗中选择)。

D. 超参数

我们在表 IX 和表 X 中提供预训练和微调阶段的超参数。

E. 参数化

本体感觉 本体感觉空间由绝对末端执行器平移 (x, y, z) 、六自由度旋转向量以及连续的末端执行器夹爪状态参数化。这构成了一个十维的本体感觉表示。六自由度旋转向量由特殊正交群 ($SO(3)$) 旋转矩阵的前两行展平得到。动作 本文采用末端执行器位姿增量作为动作参数化。在每个预测步骤中, 模型预测 t 个动作。给定轨迹中 $T_1, T_2, \dots, T_t$ 内的绝对末端执行器动作变换以及当前末端执行器位姿 T_{ee} , 本文

Pick Object Place Location	Yellow Cube Black Bowl	Yellow Cube Grey Bowl	Blue Bear Pink Bowl	Radish Grey Bowl	Black Dog Pink Bowl	Blue Sponge Silver Pot	Average Success ($\pm$ Std Err.)
Goal Conditioned	40%	30%	20%	40%	40%	30%	33.3% ($\pm 6.5\%$)
Octo	10%	0%	10%	10%	0%	0%	5.0% ($\pm 2.7\%$)
OpenVLA	0%	0%	0%	50%	20%	0%	11.7% ($\pm 4.6\%$)
ICRT-Llama2	40%	40%	40%	60%	40%	40%	43.3% ($\pm 7.9\%$)
ICRT (DROID)	0%	0%	0%	0%	0%	0%	0.0% ($\pm 0.0\%$)
ICRT (MT)	90%	50%	80%	90%	60%	90%	76.7% ($\pm 7.1\%$)
ICRT +Prompt Loss	20%	10%	20%	40%	30%	10%	21.7% ($\pm 6.2\%$)
ICRT (Co-train)	10%	0%	10%	0%	40%	20%	13.3% ($\pm 5.8\%$)
ICRT	60%	50%	80%	50%	60%	90%	65.0% ($\pm 7.3\%$)

表七：拾取与放置原语的实验结果。此处列出所评估的六项任务及其对应的 success rate. For each model, we also report the mean success rate and the standard error.

Poke Object	Radish	Red Cube	Grey Dog	Black Cube	Pink Bowl	Blue Sponge	Average Success ($\pm$ Std Err.)
Goal Conditioned	0%	0%	0%	0%	40%	0%	6.7% ($\pm 4.6\%$)
Octo	20%	0%	60%	0%	0%	0%	13.3% ($\pm 6.2\%$)
OpenVLA	20%	0%	0%	0%	0%	0%	3.3% ($\pm 3.3\%$)
ICRT-Llama2	60%	100%	80%	60%	60%	80%	73.3% ($\pm 8.2\%$)
ICRT (DROID)	0%	0%	0%	0%	0%	0%	0.0% ($\pm 0.0\%$)
ICRT (MT)	100%	100%	40%	60%	60%	60%	70.0% ($\pm 8.5\%$)
ICRT +Prompt Loss	0%	20%	20%	80%	0%	20%	23.3% ($\pm 7.9\%$)
ICRT (Co-train)	0%	0%	0%	0%	0%	0%	0.0% ($\pm 0.0\%$)
ICRT	100%	100%	80%	80%	100%	100%	93.3% ($\pm 4.6\%$)

表八：戳刺原语的实验结果。此处列出所评估的六项任务及其对应的成功率 rate. For each model, we also report the mean success rate and the standard error.

Config	Value
optimizer	AdamW
base learning rate	1e-3
learning rate schedule	cosine decay
batch size	64
weight decay	0.05
optimizer momentum	$\beta_1, \beta_2 = 0.9, 0.999$
warm up epoch	0.5
total epochs	4
proprioception noise	0.005
action noise	0
sequence length	512
brightness augmentation	0.1
contrast augmentation	0.2
num action prediction	16

表九：预训练超参数

Config	Value
optimizer	AdamW
base learning rate	5e-4
learning rate schedule	cosine decay
batch size	64
weight decay	0.01
optimizer momentum	$\beta_1, \beta_2 = 0.9, 0.999$
warm up epoch	1.25
total epochs	125
proprioception noise	0.005
action noise	0
sequence length	512
brightness augmentation	0.1
contrast augmentation	0.2
num action prediction	16

表十：微调超参数

将模型需要预测的相对变换定义为 $T_{ee}^{-1}T_1, T_{ee}^{-1}T_2, \dots, T_{ee}^{-1}T_t$ 。随后，将连续的绝对夹爪位置附加到每个增量动作上。与本体感觉类似，本文通过相对末端执行器平移和六自由度旋转来表示增量动作。这构成了一个十维的动作表示。在执行预测动作时，除了时间集成 [2] 之外，本文还采用滚动时域控制 [1]，并选择动作时域为 10

步。

F. 系统信息

所有模型均在 4 块英伟达 A100 80GB 图形处理器（GPU）上训练。在 DROID 数据集上的 ICRT 预训练耗时 56 分钟，在 ICRT-MT 上的微调耗时 18 小时。ICRT-Llama7B 的微调大约需要 28 小时。我们在表 XI 中报告了 ICRT 和 ICRT-Llama2 的推理速度，该速度是 100 个步骤的平均值。所有测试均在一台配备英伟达 RTX 3090Ti 和英特尔 i5-12400F 处理器、64GB 内存的工作站上进行。我们发现，采用所提出的公式，可以利用键值缓存（KV cache），从而能够以 10Hz 的频率直接运行 ICRT-Llama2。

Inference Frequency	
ICRT	39.6 Hz
ICRT-Llama2	10.7 Hz

表 XI: ICRT 的推理频率，100 个步骤的平均值。