

流作为跨域操作接口

Mengda Xu^{1, 2, 3} Zhenjia Xu^{1, 2} Yinghao Xu¹ Cheng Chi^{1, 2}
 Gordon Wetzstein¹ Manuela Veloso^{3, 4} Shuran Song^{1, 2}
¹ Stanford University, ² Columbia University,
³ J.P. Morgan AI Research, ⁴ Carnegie Mellon University
<https://im-flow-act.github.io>

摘要：我们提出 Im2Flow2Act，一个可扩展的学习框架，使机器人无需真实世界机器人训练数据即可获得真实世界操作技能。Im2Flow2Act 的核心思想是使用物体流作为操作接口，弥合不同实体（即人类与机器人）和训练环境（即真实世界与仿真）之间的域差距。Im2Flow2Act 包含两个组件：流生成网络和流条件策略。流生成网络在人类演示视频上训练，根据初始场景图像生成物体流，并以任务描述为条件。流条件策略在仿真机器人操作数据上训练，将生成的物体流映射为机器人动作，以实现期望的物体运动。通过使用流作为输入，该策略可以直接部署在真实世界中，仿真到真实的差距极小。通过利用真实世界人类视频和仿真机器人操作数据，我们绕过了在真实世界中遥操作物理机器人的挑战，从而得到一个适用于多种任务的可扩展系统。我们展示了 Im2Flow2Act 在各种真实世界任务中的能力，包括刚性、铰接和可变形物体的操作。

关键词：机器人，学习，跨域，跨实体




图 1：流作为跨域操作接口。在 Im2Flow2Act 中，我们利用物体流来弥合实体（人类与机器人）和训练环境（真实与仿真）之间的域差距。我们的最终系统能够同时利用 **a)** 无动作的人类视频进行任务条件流生成和 **b)** 无任务的仿真机器人数据进行流条件动作生成，从而得到 **c)** 一个语言条件的多任务系统，用于真实世界操作任务，但无需真实机器人训练数据。

1 引言

扩展机器人学习的一个关键步骤是让机器人能够从昂贵的真实世界机器人数据之外的各种数据源中学习 [1, 2, 3, 4, 5]。先前的工作从以下方面探讨了这个问题

两个主要方向：从跨具身视频 [6, 7, 8, 9, 10, 11, 12, 13] 和模拟机器人数据中学习。尽管这两种方法都显示出有前景的进展，但它们各自面临重大挑战。从跨具身数据中学习受到巨大具身差距的阻碍，而模拟数据则面临显著的仿真到现实差距以及构建任务特定环境的复杂性，尤其是对于接触丰富的操作任务。

在本文中，我们介绍了 **Im2Flow2Act**，这是一个新颖的框架，用于学习现实世界的操作技能，但无需现实世界的机器人训练数据。我们的核心思想是使用物体流——被操作物体的专属运动，排除任何背景或具身——作为连接人类视频和模拟数据的统一接口，并在现实世界中实现新技能的一次性泛化。我们的框架（图 1）由两个主要组件组成：一个在跨具身演示视频上训练的流生成网络（图 1-a）和一个在具身特定的跨环境模拟数据上训练的流条件策略（图 1-b）。在推理过程中，流生成模型根据初始视觉观察和任务描述生成完整的任务特定物体流（图 1-c）。生成完整的物体流有助于在从跨具身演示中学习时最小化训练和推理之间的视觉外观差距。以生成的流为条件，我们的任务无关策略生成动作来执行任务。我们概述了使用物体流作为统一接口的好处：

- **表达性任务描述**：物体流不仅捕捉物体姿态的变化，还考虑了关节和变形。其多功能性使其能够表示广泛的物体和任务，包括刚体、关节体和可变形物体。在 Im2Flow2Act 中，我们利用这种多功能性，为多样化的任务训练单一操作策略。
- **具身无关**：物体流描述的是由动作引起的物体状态变化，而不是动作本身，因此它独立于智能体的具身。与先前利用均匀网格流并同时跟踪具身运动的工作 [14] 相比，我们的方法使用物体流，使我们的框架在跨具身学习中更有效。
- **最小的仿真到现实差距**：与基于图像的表达相比，流更关注运动而非外观，从而缩小了仿真到现实的差距并有助于泛化。不同于先前利用流进行操控的工作依赖于启发式策略 [15]、真实世界遥操作数据 [14, 16] 或两者兼有 [17]，本文的闭环策略完全从由一组预定义动作原语生成的仿真机器人探索数据中学习得到。
- **可解释性**：与基于向量的状态表示不同，基于流的表示具有直观的物理意义。这使其成为人机交互的良好接口。例如，当一项任务存在多个流时，用户可以轻松理解并选择其中一个流。

为了利用物体流作为接口从多样化数据中学习，本文系统包含两个组件：

- **流生成网络**：流生成网络（图 1-a）的目标是通过跨具身视频（包括不同类型机器人和人类演示的视频）学习高层任务规划。本文开发了一种基于视频生成模型 Animatediff[18] 的语言条件流生成网络。与先前在原始流空间上训练的方法 [14, 15, 17] 相比，本文利用 Stable Diffusion[19] 中的自编码器（AE）首先将流压缩到潜空间，然后在该压缩表示上训练模型，从而使训练过程更加高效。
- **流条件策略**：流条件模仿学习策略（图 1-b）的目标是实现流生成网络生成的流，专注于底层执行。该策略完全从仿真数据中学习，以建立动作与流之间的映射。与大多数需要构建任务特定仿真的仿真到现实工作不同，本文的策略完全从由一组预定义动作原语生成的探索数据中学习，这些数据更易收集且更具多样性。由于流表示运动，这是真实世界与仿真中共有的概念，因此本文的策略可以无缝部署到真实世界环境中。

流生成网络与流条件策略共同构成一个统一的系统。本文最终系统通过物体流作为接口，桥接跨形态演示视频与低成本的仿真机器人数据，为机器人操作技能的获取提供了一个可扩展的框架。




图 2: Im2Flow2Act 概览。给定任务描述和初始帧，流生成器 (a) 生成该任务的完整物物流（即任务流）。闭环操作策略 (c) 接收任务流和当前帧的关键点位置，以推断机器人动作。在操作策略内部，时序对齐模块 (c-1) 用于比较任务流与当前帧的关键点位置，推断剩余任务流（彩色流），供扩散头 (c-3) 生成动作。我们在四个真实世界任务中达到了 81% 的平均成功率，这些任务涉及刚体、关节体和可变形物体，且训练过程中未使用任何真实世界机器人数据。2 相关工作

基于流的操作。利用流的机器人策略在操作关节物体 [20, 21] 和工具 [22] 方面已展现出有前景的结果。然而，这些方法仅限于特定任务。随着计算机视觉中点跟踪算法的最新进展，可以通过基于学习的方法在视频序列中估计流。Vecerik 等人 [16] 通过跟踪流实现了小样本学习，但需要显式姿态估计，且仍局限于刚体。为了使流适用于更通用的操作任务，ATM[14] 学习了一种流条件行为克隆策略，可应用于关节体和可变形物体。然而，ATM 仍需要在真实世界中通过遥操作收集域内机器人数据。Yuan 等人 [15] 提出了一种启发式基于流的策略，但需要手动将机器人夹爪定位在物体上，使整个系统自主性较低。最近，Bharadhwaj 等人 [17] 提出在启发式策略之上学习残差策略，但仍需收集真实世界机器人数据。在 Im2Flow2Act 中，我们从无任务仿真数据集中训练了一种数据高效且完全自主的流条件策略，无需昂贵的域内机器人数据收集，并可一次性迁移到真实世界。

从跨形态数据中学习。大量工作 [10, 23, 24, 25] 研究了利用跨具身数据学习机器人策略。先前工作探索了不同方向，包括视觉预训练 [8, 26, 27]、学习奖励函数 [7, 28, 29, 30]、提取可供性 [31, 9, 32, 33]、手部姿态检测 [6, 34, 35] 和域迁移 [36, 37, 38, 39, 40, 41, 42]。由于大多数跨具身数据缺乏显式动作，或动作因具身差异难以迁移，许多先前工作仍需收集域内机器人数据 [43, 41, 12, 11, 44] 以缓解较大的具身差距。多项工作 [45, 14, 15] 通过跨具身数据学习视频生成或流生成模型。ATM[14] 在从人类演示中学习流生成方面展示了有前景的结果。然而，由于 ATM 生成的网格流不可避免地捕捉到具身运动，它需要昂贵的真实世界机器人数据与人类演示数据一同训练。这确保了生成的流与机器人操作策略所需的分布对齐。Im2Flow2Act 仅预测物体的流，与具身无关。这种方法使我们能够无缝地从人类视频中学习，无需任何域内机器人数据。更多相关工作请参见附录 A。

3 方法

我们旨在构建一个框架，利用物物流作为统一接口，使机器人能够获取真实世界的操作技能，而无需昂贵的真实世界域内机器人数据。我们的核心思想是使用物物流作为通用且富有表现力的接口来桥接：




图 3：流生成网络。流生成网络以初始帧和任务描述为条件，输出完整任务的物物流。首先使用 Grounding DINO (a) 检测感兴趣物体，然后在边界框内采样网格点作为初始关键点。**AnimateDiff** (b) 接收关键点和任务描述，生成未来流。我们通过运动滤波器对生成的流进行后处理，以获得以物体为中心的任务流。

跨具身数据：在不同具身之间迁移动作通常受到具身差距的阻碍。然而，物物流封装了可迁移的任务知识，与具身特定动作无关。为利用这一点，我们开发了一个流生成网络，专注于从跨具身视频中提取物物流。

跨环境数据：在本工作中，跨环境指的是仿真环境与真实世界环境。视觉不一致性，例如场景背景和物体纹理的差异，给将学习到的策略从仿真迁移到真实世界带来了挑战。相反，物物流捕捉了运动动态——物体姿态、关节运动和形变的变化——在仿真和真实世界中保持一致，为策略学习提供了理想的接口。我们的流条件模仿学习策略完全从一组预定义原始动作生成的多样化仿真探索数据中学习，这促进了对动作与结果物物流之间关系的理解，进一步减少了对任务特定环境的需求。

在推理过程中，流生成网络首先在任务开始时生成完整的任务流，然后策略执行动作以复现生成的流。

3.1 流生成网络 我们的主要思想是将置换不变的物物流组织成结构化矩形流图像序列。这种方法使我们能够更好地利用预训练的图像和视频生成模型，以实现更高效的训练。具体来说，我们使用 Grounding DINO [46] 从初始 RGB 帧中获取感兴趣物体的边界框，然后在框内进行均匀采样，得到矩形流 $\mathcal{F}_0 \in \mathbb{R}^{3 \times H \times W}$ 。前两个通道表示物体关键点在图像空间中的 u, v 坐标，第三个通道表示其可见性。对于涉及多个物体的任务，我们首先获取所有相关物体的边界框，并在每个框内进行均匀采样。采样的关键点数量与每个边界框的面积成正比。然后，我们将 TAPIR [47] 应用于视频，生成具有 T 个时间步的矩形流序列 $\mathcal{F}_1 \in \mathbb{R}^{3 \times T \times H \times W}$ 。利用这种流表示，我们采用基于扩散的视频生成架构 AnimateDiff [18] 作为流生成器网络，以初始 RGB 帧和任务描述为条件生成物物流。生成的流经过运动滤波器处理，仅保留物体上的关键点，从而产生完整的以物体为中心的任务流。流生成流程如图 3 所示。

完整的以物体为中心的任务流 Im2Flow2Act 生成完整的以物体为中心的任务流，与 ATM 中即时下一步网格流形成对比 [14]。该设计最小化了人类演示与机器人执行之间的具身差距。首先，以物体为中心的流减少了智能体运动带来的干扰。网格流主要捕捉具身的运动（例如人类手臂），导致为机器人策略生成分布外流，而该策略是用机器人特定流训练的。因此，ATM 需要额外的真实世界机器人数据来弥合这一差距，而我们的方法直接从人类演示中学习流生成。其次，从初始帧生成完整流避免了执行过程中的视觉差距。即时下一步流受到具身差距的负面影响，因为人类在演示过程中经常接触并遮挡物体。这使得模型以具身与物体紧密相连的视觉输入为条件。然而，在机器人部署期间，夹爪会接触物体，导致

分布外视觉输入。从初始帧生成完整流避免了这一点，因为具身无需与物体接触。

将流压缩到潜空间。高精度流对于使机器人实现对物体的精细控制至关重要。然而，以高分辨率生成物体会引入显著的计算复杂度，并导致生成速度低下。受先前工作 [19] 的启发，我们提出将物体流压缩到具有较低空间维度的紧凑潜空间中，然后在该潜空间内训练生成模型。StableDiffusion (SD) [19] 使用 VQGAN [48] 中提出的自编码器 (AE) 压缩输入图像，通过在大量 RGB 图像上训练得到分布良好的潜空间。在这项工作中，我们探索了使用 AE 对流进行编码的想法。为了利用这个结构良好的潜空间，我们固定 AE 的编码器 $E_\phi(\cdot)$ ，并微调预训练的解码器 $D_\theta(\cdot)$ 以更好地适应流图像。输入流的潜变量 $x_{1:T} \in \mathbb{R}^{C \times T \times H_x \times W_x}$ 可以通过 $x_{1:T} = E_\phi(\mathcal{F}_i) | i \in [1, T]$ 获得，其中 H_x 和 W_x 表示空间维度，与输入流空间维度 H 和 W 相比，下采样了 8 倍。

用于流生成的视频扩散模型 由于我们与稳定扩散 (StableDiffusion, SD) 共享相同的潜空间，因此可以利用预训练的 SD 为流生成提供强大的内容先验。因此，我们选择沿时间轴扩展 SD 网络以进行流生成，而非从头训练模型。随后，我们将 Animatediff 提出的运动模块层 [18] 插入 SD 中，以建模流生成的时间动态。运动模块对每个空间特征沿时间维度执行自注意力，以融入时间信息。带有运动模块的 SD 模型学习捕捉图像空间中关键点位置 (u, v) 的时间变化。我们从头训练运动模块层，但仅在 SD 模型中插入低秩适配 (Low-Rank Adaptation, LoRA) 层 [49]。

3.2 流条件模仿学习策略

我们的模仿学习策略 $p(\mathbf{a}_t | \mathcal{F}_{0:T}, s_t, \rho_t)$ 以完整任务的对象流 $\mathcal{F}_{0:T}$ (即任务流)、当前状态表示 s_t 和机器人本体感知 ρ_t 作为输入。输出是从当前时间 t 开始、长度为 L 的动作序列 $\mathbf{a}_t = \{a_t, \dots, a_{t+L}\}$ ，记为。机器人动作 a_t 包括笛卡尔空间中 6 自由度的末端执行器位置和 1 自由度的夹爪开合状态。状态表示 s_t 由当前帧的关键点位置构成，记为 f_t ，包含时间 t 时图像空间中 N 个关键点的位置 $\{(u_n^t, v_n^t)\}_{n=1}^N$ 以及初始帧中 N 个关键点 $x_0 \in \mathbb{R}^{N \times 3}$ 的三维坐标。

在推理过程中，任务流 $\mathcal{F}$ 在任务开始时由流生成网络一次性生成，如第 3.1 节所述。我们利用在线点跟踪算法在机器人操作过程中获取同一组关键点的 f_t 。该策略由以下组件组成：状态编码器 ϕ 以 N 个关键点 (封装在 f_t 中) 及其对应的初始三维坐标 x_0 作为输入，生成状态表示 s_t ；时间对齐模块 ψ 比较任务流与当前关键点位置 f_t 以推断剩余任务流；最后，扩散动作头 [50] 输出机器人动作。

训练数据：我们简要描述了训练数据的构建方式以及一些决策选择 (更多细节见补充材料)。对于时长为 T' 的片段，我们运行点跟踪算法，在每一步获取被操作物体上关键点的位置，即 $f_{0:T'}$ 。我们可以得到形式为轨迹 $\tau_k = \{(\rho_0, f_0, a_0), \dots, (\rho_{T'}, f_{T'}, a_{T'})\}$ 的数据集 $\mathcal{D}$ 。在训练过程中，我们从 $f_{0:T'}$ 中随机采样 T 帧，将其视为任务流 $\mathcal{F}_{0:T}$ 。

状态编码器：状态编码器 $\phi(f_t, x_0)$ 是一个基于变换器 (Transformer) 的 [51] 网络，它处理 f_t 中的所有 N 个关键点以及对应的初始三维坐标 x_0 ，输出当前状态表示 s_t ，i.e., $s_t = \phi(f_t, x_0)$ 。对于每个关键点，其在时间 t 的位置 (u_n^t, v_n^t) 首先使用二维正弦位置编码进行编码，初始三维坐标 $x_{0,n}$ 通过一个线性投影头。然后将它们拼接在一起，为每个点形成一个唯一的描述符 ϵ 。所有 N 个点的描述符被传入状态编码器，我们使用一个 CLS 标记 [52] 来总结当前状态。由于点具有置换不变性，我们不添加任何位置嵌入，只为 CLS 标记添加一个可学习的嵌入。

时间对齐：在推理过程中，策略应定位当前任务进度，并以剩余任务流而非完整任务流为条件，以预测精确的动作。为此，我们引入了一个时间对齐模块 ψ ，在给定当前关键点位置和完整任务流的情况下预测剩余任务流。此外，对齐模块使我们的方法能够将人类演示作为策略输入，并在推理过程中从中学习（即演示条件执行），这是 ATM[14] 所不具备的能力。该思想类似于 XSkill[44] 中的技能对齐，但我们将其扩展到更复杂的流领域。

我们不在原始空间中预测剩余任务流，而是在潜空间 $\mathcal{Z}$ 中进行，以提高训练效率。我们构建了一个基于变换器的时间对齐模型 $\psi(\mathcal{F}_{0:T}, s_t, \rho_t)$ ，根据完整任务流 $\mathcal{F}_{0:T}$ 、当前状态 s_t 和机器人本体感知 ρ_t 来预测剩余任务流的潜在表示 z_t 。对于对齐模块的监督 $\hat{z}_t$ ，我们使用另一个变换器编码器 ξ 将真实剩余任务流 $f_{t:T'}$ 编码到潜空间中，该真实剩余任务流在训练数据集 $\mathcal{D}$ 中是可获取的。我们使用 z_t 与 $\hat{z}_t$ ，i.e., $\|\hat{z}_t - z_t\|^2$ 之间的 L_2 损失来监督对齐学习。

扩散动作头：在推理过程中，策略可以直接以 z_t ，i.e., $p(\mathbf{a}_t|z_t, s_t, \rho_t)$ 为条件来预测未来动作。在训练过程中，策略以 $\hat{z}_t$ 为条件，使得编码器 ξ 获得监督。尽管整个系统可以端到端训练，但在计算对齐损失时，我们分离 $\hat{z}_t$ ，即 $\|\hat{z}_t^{\text{detach}} - z_t\|^2$ ，以获得更稳定的训练。

4 评估

我们展示了 Im2Flow2Act 在 4 项任务上的能力，涵盖刚体、关节体和可变形物体，包括抓取放置、倒水、打开抽屉和折叠布料。任务描述见图 4 最左列。

4.1 实验细节

训练数据：我们在仿真中收集机器人探索数据，并在真实世界中收集人类手部演示数据。（i）在仿真中，我们使用 UR5e 机器人通过一组预定义的随机启发式动作进行探索，收集刚体、关节体和可变形物体的数据。每种探索策略的细节见补充材料。我们使用所有探索数据训练了一个模仿学习策略。（ii）在真实世界中，我们为每项任务收集人类手部演示数据。我们将数据混合在一起训练流生成模型。

比较。我们将我们的方法与以下基线进行比较：1) ATM：ATM[14] 训练一个闭环流生成模型，输出网格流，操作策略接收接下来几步的流预测。该比较测试了在跨实体演示中学习时生成完整任务物体流的优势。2) 启发式：启发式动作策略选择物体接触点，并在未来物物流（需要 3D 流）上应用姿态估计方法（如 RANSAC）来推断机器人动作，该方法在 General Flow 和 Track2Act[15, 17] 中实现。我们提供真实 3D 流作为启发式方法的输入。该基线检验了使用基于学习的策略将流转换为动作的必要性。3) 网格流：与 ATM 类似，我们将 Im2Flow2Act 中的初始物体关键点替换为一组均匀采样的关键点。4) 无对齐：为了消融我们的对齐模块设计，我们移除了对齐模型 ψ 以及以完整任务流为条件的策略。

评估设置。我们在两种场景下评估 Im2Flow2Act 和基线模型：（1）演示条件执行和（2）语言条件执行，分别在真实环境和仿真环境中进行。在仿真中，我们利用球形机器人创建跨形态演示。在演示条件设置中，我们使用从单个人类演示视频（或仿真中的球形演示）提取的物体流作为操作策略的输入。该设置评估低级动作生成的鲁棒性，独立于流生成准确性。在语言条件执行中，我们通过首先使用基于任务描述和初始帧条件的学习流生成网络生成流来评估完整系统。然后，操作策略使用该生成的流进行动作推理。




图 4：任务与结果：我们在涉及刚性、关节和可变形物体的四个任务上进行了评估。初始场景、流生成可视觉化和推理过程中的在线点跟踪均使用 RealSense 相机捕获。机器人执行的可视化从不同角度录制，以提供更清晰的机器人执行视图。

表 1：仿真结果 (%)

	演示条件执行 布料	语言条件执行	抓取与放置	倾倒	抽屉	布料	抓取与放置	倾倒	抽屉
Im2Flow2Act	100	95	95	90	90	85	90	35	
ATM[14]	/	/	/	/	50	30	85	30	
Heuristic[15, 17]	70	50	30	0	/	/	/	/	
GridFlow	30	25	35	45	/	/	/	/	
No alignment	80	85	90	90	/	/	/	/	

4.2 关键发现

流能有效桥接不同数据源： Im2Flow2Act 在所有基线中实现了最佳性能，在仿真和真实环境中均如此，如表 1 和表 2 所示。此外，与仿真相比，真实环境中的性能平均仅下降 15%。如图 4 所示，我们学习的策略能够很大程度上遵循生成的流，在刚性、关节和可变形物体上完成所需任务。这表明物体流是连接跨形态和跨环境数据源的良好接口。

基于学习的策略对于将流转换为动作是必要的： 为了将生成的流映射到机器人动作，我们使用了学习到的策略和对齐网络。相比之下，先前的工作 [17, 15] 使用基于启发式的策略从流中计算机器人动作。与它们相比，我们提供了真实的三维流和最优抓取姿态，而我们的方法并不需要这些。如表 1 所示，基于启发式的策略在刚体物体上表现良好，例如仿真中的抓取放置和倾倒。然而，在处理可变形和关节式物体时，无论是在仿真还是真实环境中，它都表现不佳，因为启发式方法的性能在很大程度上依赖于相机视角。例如，在打开抽屉的任务中，如果相机视角下点云的中心不是一个好的接触点，它就会将抽屉推回（图 5）。在真实世界中（表 2），我们注意到基于启发式的方法经常触发 UR5e 的紧急停止，因为 UR5e 没有阻抗控制，因此姿态估计中的小误差就可能导致任务失败。这表明基于学习的策略对于将流转换为准确且安全的动作是必要的。

表 2：真实世界结果 (%)

	演示条件执行 布料	语言条件执行	抓取与放置	倾倒 抽屉 布料	抓取与放置	倾倒 抽屉		
Im2Flow2Act	95	80	90	70	90	80	85	70
Heuristic[15, 17]	70	50	30	0	/	/	/	/
No alignment	55	0	80	60	/	/	/	/

在跨具身演示中学习时，物流至关重要：我们通过将所提方法与任意点跟踪模型（ATM）进行对比，评估了以物体为中心的流设计。如表 1 所示，Im2Flow2Act 在四项任务上平均优于 ATM 30%。ATM 在跨具身演示中学习时表现不佳的关键原因在于，机器人部署阶段视觉输入会变为分布外数据。训练期间，ATM 接收跨具身演示（真实世界中的人类手臂和仿真中的球体）的视觉输入并做出预测，其中大部分预测与具身流相关。然而，在推理阶段，视觉输入包含的是机器人手臂，而非人类手臂或球体。由于模型同时生成具身流，未见过的具身会导致模型处于分布外状态。相比之下，Im2Flow2Act 仅生成物流，不关注具身。初始物体关键点也为模型生成以物体为中心的流提供了强条件。因此，我们的模型对机器人部署过程中不同具身的存在具有鲁棒性。我们进一步通过将所提方法中的物流替换为均匀网格流，比较了初始关键点采样的设计决策。在表 1 中，我们观察到其性能显著下降，因为均匀流同样会捕获来自具身本身的运动，这与 ATM 类似。这凸显了物流相对于网格流在跨具身学习中的优越性。

对齐模块是必要的 利用非结构化探索数据：在表 1 中，未对齐的 Im2Flow2Act 在仿真中的性能仅略有下降。然而，我们观察到机器人的执行变得不流畅，涉及许多不必要的动作，如突然旋转。这表明策略无法根据任务进度将其行为与任务流对齐，只能尝试在探索数据中找到最接近的轨迹。此外，在真实世界中，其性能显著下降（表 2），尤其是在拾放和倾倒任务中，因为人类产生的物流可能与仿真中的流不同。策略很难在潜空间中找到相似的轨迹，导致如图 5 所示的随机轨迹。具有对齐的 Im2Flow2Act 不会遇到此问题，因为潜空间在额外的对齐监督下具有更细的粒度，从而实现平滑插值。




图 5：基线的典型失败案例。即使给定人类产生的真实流，启发式策略也可能产生不准确的动作，例如先将抽屉推回。对于无对齐模型，杯子可能会沿轨迹随机旋转，这与随机探索数据的行为相同。

4.3 局限性与未来工作

我们的系统使用二维流作为操作接口，使我们能够利用大规模二维视频。然而，这种方法在表示三维动作时本质上存在歧义。例如，倾倒任务中常见的失败源于机器人 z 轴运动（在相机坐标系中）缺乏精度。此外，二维流难以处理涉及平面外旋转的任务（例如拧紧），这一局限性可能通过三维流 [53, 15] 来解决。我们的框架还假设仿真与真实世界之间的物体动力学一致，但模拟可变形物体仍然具有挑战性。因此，我们观察到在真实世界中部署策略时，折叠任务的性能显著下降。更多讨论请参见附录 I。

5 结论

我们介绍了 Im2Flow2Act，这是一个可扩展的学习框架，使机器人能够利用物流作为统一接口，从成本效益高的跨域数据中获取多样化的操作技能。我们的最终系统在各种类型的操作任务中超越了所有基线，展示了强大的真实世界操作能力。我们的工作为未来研究从多样数据源扩展机器人操作技能铺平了道路。

致谢

我们感谢 Yifan Hou、Zeyi Liu、Huy Ha、Mandi Zhao、Chuer Pan、Xiaomeng Xu、Yihuai Gao、Austin Patel、Haochen Shi、John So、Yuwei Guo、Haoyu Xiong、Litian Liang、Dominik Bauer、Samir Yitzhak Gadre 的有益反馈和富有成效的讨论。

徐梦达的工作由摩根大通公司支持。本文部分由摩根大通公司及其关联方（“摩根大通”）的人工智能研究组为信息目的编写，并非摩根大通研究部门的产品。摩根大通对本文所含信息的完整性、准确性或可靠性不作任何陈述和保证，并否认所有责任。本文档无意作为投资研究或投资建议，或作为购买或出售任何证券、金融工具、金融产品或服务的推荐、要约或招揽，也不得以任何方式用于评估参与任何交易的优劣，且在任何司法管辖区或向任何人构成招揽，如果此类招揽在该司法管辖区或向该人进行将是非法的。本工作部分由国家自然科学基金会奖项 #2143601、#2037101 和 #2132519 支持。本文所含观点和结论为作者所有，不应被解释为必然代表赞助方的官方政策，无论是明示还是暗示。

参考文献

- [1] Y. Zhu and A. Joshi. Viola: Imitation learning for vision-based manipulation with object proposal priors. In *Conference on Robot Learning*, 2022.
- [2] M. Seo, S. Han, K. Sim, S. H. Bang, C. Gonzalez, L. Sentis, and Y. Zhu. Deep imitation learning for humanoid loco-manipulation through human teleoperation. In *2023 IEEE-RAS 22nd International Conference on Humanoid Robots (Humanoids)*, pages 1–8. IEEE, 2023.
- [3] A. Toedtheide, X. Chen, H. Sadeghian, A. Naciri, and S. Haddadin. A force-sensitive exoskeleton for teleoperation: An application in elderly care robotics. In *2023 IEEE International Conference on Robotics and Automation (ICRA)*, pages 12624–12630. IEEE, 2023.
- [4] F. Ebert, Y. Yang, K. Schmeckpeper, B. Bucher, G. Georgakis, K. Daniilidis, C. Finn, and S. Levine. Bridge data: Boosting generalization of robotic skills with cross-domain datasets.
- [5] A. Brohan, N. Brown, J. Carbajal, Y. Chebotar, J. Dabis, C. Finn, K. Gopalakrishnan, K. Hausman, A. Herzog, J. Hsu, et al. Rt-1: Robotics transformer for real-world control at scale. *arXiv preprint arXiv:2212.06817*, 2022.
- [6] S. Bahl, A. Gupta, and D. Pathak. Human-to-robot imitation in the wild. 2022.
- [7] A. S. Chen, S. Nair, and C. Finn. Learning Generalizable Robotic Reward Functions from “In-The-Wild” Human Videos. In *Proceedings of Robotics: Science and Systems*, Virtual, July 2021. doi:[10.15607/RSS.2021.XVII.012](https://doi.org/10.15607/RSS.2021.XVII.012).
- [8] Y. J. Ma, S. Sodhani, D. Jayaraman, O. Bastani, V. Kumar, and A. Zhang. Vip: Towards universal visual reward and representation via value-implicit pre-training. In *The Eleventh International Conference on Learning Representations*, 2022.
- [9] S. Bahl, R. Mendonca, L. Chen, U. Jain, and D. Pathak. Affordances from human videos as a versatile representation for robotics. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 13778–13790, 2023.
- [10] C. Pan, B. Okorn, H. Zhang, B. Eisner, and D. Held. Tax-pose: Task-specific cross-pose estimation for robot manipulation. In *Conference on Robot Learning*, pages 1783–1792. PMLR, 2023.

- [11] K. Schmeckpeper, A. Xie, O. Rybkin, S. Tian, K. Daniilidis, S. Levine, and C. Finn. Learning predictive models from observation and interaction. In *European Conference on Computer Vision*, pages 708–725. Springer, 2020.
- [12] Y. Qin, Y.-H. Wu, S. Liu, H. Jiang, R. Yang, Y. Fu, and X. Wang. Dexmv: Imitation learning for dexterous manipulation from human videos. In *European Conference on Computer Vision*, pages 570–587. Springer, 2022.
- [13] Y. Zhu, A. Lim, P. Stone, and Y. Zhu. Vision-based manipulation from single human video with open-world object graphs, 2024. URL <https://arxiv.org/abs/2405.20321>.
- [14] C. Wen, X. Lin, J. So, K. Chen, Q. Dou, Y. Gao, and P. Abbeel. Any-point trajectory modeling for policy learning. *arXiv preprint arXiv:2401.00025*, 2023.
- [15] C. Yuan, C. Wen, T. Zhang, and Y. Gao. General flow as foundation affordance for scalable robot learning. *arXiv preprint arXiv:2401.11439*, 2024.
- [16] M. Vecerik, C. Doersch, Y. Yang, T. Davchev, Y. Aytar, G. Zhou, R. Hadsell, L. Agapito, and J. Scholz. Robotap: Tracking arbitrary points for few-shot visual imitation. *arXiv preprint arXiv:2308.15975*, 2023.
- [17] H. Bharadhwaj, R. Mottaghi, A. Gupta, and S. Tulsiani. Track2act: Predicting point tracks from internet videos enables diverse zero-shot robot manipulation, 2024.
- [18] Y. Guo, C. Yang, A. Rao, Z. Liang, Y. Wang, Y. Qiao, M. Agrawala, D. Lin, and B. Dai. AnimateDiff: Animate your personalized text-to-image diffusion models without specific tuning. In *The Twelfth International Conference on Learning Representations*, 2023.
- [19] R. Rombach, A. Blattmann, D. Lorenz, P. Esser, and B. Ommer. High-resolution image synthesis with latent diffusion models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 10684–10695, 2022.
- [20] B. Eisner, H. Zhang, and D. Held. Flowbot3d: Learning 3d articulation flow to manipulate articulated objects. In *Robotics: Science and Systems (RSS)*, 2022.
- [21] H. Zhang, B. Eisner, and D. Held. Flowbot++: Learning generalized articulated objects manipulation via articulation projection. In *Conference on Robot Learning*, pages 1222–1241. PMLR, 2023.
- [22] D. Seita, Y. Wang, S. J. Shetty, E. Y. Li, Z. Erickson, and D. Held. Toolflownet: Robotic manipulation with tools via predicting tool flow from point clouds. In *Conference on Robot Learning*, pages 1038–1049. PMLR, 2023.
- [23] A. Majumdar, K. Yadav, S. Arnaud, J. Ma, C. Chen, S. Silwal, A. Jain, V.-P. Berges, T. Wu, J. Vakil, et al. Where are we in the search for an artificial visual cortex for embodied intelligence? *Advances in Neural Information Processing Systems*, 36, 2024.
- [24] H. Niu, J. Hu, G. Zhou, and X. Zhan. A comprehensive survey of cross-domain policy transfer for embodied agents, 2024.
- [25] R. McCarthy, D. C. H. Tan, D. Schmidt, F. Acero, N. Herr, Y. Du, T. G. Thuruthel, and Z. Li. Towards generalist robot learning from internet video: A survey, 2024.
- [26] T. Xiao, I. Radosavovic, T. Darrell, and J. Malik. Masked visual pre-training for motor control. *arXiv preprint arXiv:2203.06173*, 2022.
- [27] S. Nair, A. Rajeswaran, V. Kumar, C. Finn, and A. Gupta. R3m: A universal visual representation for robot manipulation. In *Conference on Robot Learning*, pages 892–909. PMLR, 2023.

- [28] L. Shao, T. Migimatsu, Q. Zhang, K. Yang, and J. Bohg. Concept2robot: Learning manipulation concepts from instructions and human demonstrations. *The International Journal of Robotics Research*, 40(12-14):1419–1434, 2021.
- [29] K. Zakka, A. Zeng, P. Florence, J. Tompson, J. Bohg, and D. Dwibedi. Xirl: Cross-embodiment inverse reinforcement learning. In *Conference on Robot Learning*, pages 537–546. PMLR, 2022.
- [30] C. Ying, Z. Hao, X. Zhou, X. Xu, H. Su, X. Zhang, and J. Zhu. Peac: Unsupervised pre-training for cross-embodiment reinforcement learning, 2024.
- [31] R. Mendonca, S. Bahl, and D. Pathak. Structured world models from human videos.
- [32] M. Goyal, S. Modi, R. Goyal, and S. Gupta. Human hands as probes for interactive object understanding. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 3293–3303, 2022.
- [33] S. Liu, S. Tripathi, S. Majumdar, and X. Wang. Joint hand motion and interaction hotspots prediction from egocentric videos. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 3282–3292, 2022.
- [34] K. Shaw, S. Bahl, and D. Pathak. Videodex: Learning dexterity from internet videos. In *Conference on Robot Learning*, pages 654–665. PMLR, 2023.
- [35] C. Wang, H. Shi, W. Wang, R. Zhang, L. Fei-Fei, and C. K. Liu. Dexcap: Scalable and portable mocap data collection system for dexterous manipulation. *arXiv preprint arXiv:2403.07788*, 2024.
- [36] K. Schmeckpeper, O. Rybkin, K. Daniilidis, S. Levine, and C. Finn. Reinforcement learning with videos: Combining offline observations with interaction. In *Conference on Robot Learning*, pages 339–354. PMLR, 2021.
- [37] P. Sharma, D. Pathak, and A. Gupta. Third-person visual imitation learning via decoupled hierarchical controller. *Advances in Neural Information Processing Systems*, 32, 2019.
- [38] Y. Liu, A. Gupta, P. Abbeel, and S. Levine. Imitation from observation: Learning to imitate behaviors from raw video via context translation. In *2018 IEEE international conference on robotics and automation (ICRA)*, pages 1118–1125. IEEE, 2018.
- [39] L. Smith, N. Dhawan, M. Zhang, P. Abbeel, and S. Levine. Avid: Learning multi-stage tasks via pixel-level translation of human videos. *arXiv preprint arXiv:1912.04443*, 2019.
- [40] H. Xiong, Q. Li, Y.-C. Chen, H. Bharadhwaj, S. Sinha, and A. Garg. Learning by watching: Physical imitation of manipulation skills from human videos. In *2021 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 7827–7834. IEEE, 2021.
- [41] M. J. Kim, J. Wu, and C. Finn. Giving robots a hand: Broadening generalization via hand-centric human video demonstrations. In *Deep Reinforcement Learning Workshop NeurIPS 2022*, 2022.
- [42] L. Y. Chen, K. Hari, K. Dharmarajan, C. Xu, Q. Vuong, and K. Goldberg. Mirage: Cross-embodiment zero-shot policy transfer with cross-painting, 2024.
- [43] C. Wang, L. Fan, J. Sun, R. Zhang, L. Fei-Fei, D. Xu, Y. Zhu, and A. Anandkumar. Mimicplay: Long-horizon imitation learning by watching human play. In *7th Annual Conference on Robot Learning*, 2023.
- [44] M. Xu, Z. Xu, C. Chi, M. Veloso, and S. Song. Xskill: Cross embodiment skill discovery. In *7th Annual Conference on Robot Learning*, 2023.

- [45] Y. Du, S. Yang, B. Dai, H. Dai, O. Nachum, J. Tenenbaum, D. Schuurmans, and P. Abbeel. Learning universal policies via text-guided video generation. *Advances in Neural Information Processing Systems*, 36, 2024.
- [46] S. Liu, Z. Zeng, T. Ren, F. Li, H. Zhang, J. Yang, C. Li, J. Yang, H. Su, J. Zhu, et al. Grounding dino: Marrying dino with grounded pre-training for open-set object detection. *arXiv preprint arXiv:2303.05499*, 2023.
- [47] C. Doersch, Y. Yang, M. Vecerik, D. Gokay, A. Gupta, Y. Aytar, J. Carreira, and A. Zisserman. Tapir: Tracking any point with per-frame initialization and temporal refinement. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 10061–10072, 2023.
- [48] P. Esser, R. Rombach, and B. Ommer. Taming transformers for high-resolution image synthesis, 2021.
- [49] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, and W. Chen. Lora: Low-rank adaptation of large language models, 2021.
- [50] C. Chi, S. Feng, Y. Du, Z. Xu, E. Cousineau, B. C. Burchfiel, and S. Song. Diffusion Policy: Visuomotor Policy Learning via Action Diffusion. In *Proceedings of Robotics: Science and Systems*, Daegu, Republic of Korea, July 2023. doi:10.15607/RSS.2023.XIX.026.
- [51] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin. Attention is all you need, 2023.
- [52] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. *arXiv preprint arXiv:1810.04805*, 2018.
- [53] S. Koppula, I. Rocco, Y. Yang, J. Heyward, J. Carreira, A. Zisserman, G. Brostow, and C. Doersch. Tapvid-3d: A benchmark for tracking any point in 3d, 2024. URL <https://arxiv.org/abs/2407.05921>.
- [54] X. Zhang, R. Chen, A. Li, F. Xiang, Y. Qin, J. Gu, Z. Ling, M. Liu, P. Zeng, S. Han, et al. Close the optical sensing domain gap by physics-grounded active stereo sensor simulation. *IEEE Transactions on Robotics*, 2023.
- [55] Y. Qin, B. Huang, Z.-H. Yin, H. Su, and X. Wang. Dexpoint: Generalizable point cloud reinforcement learning for sim-to-real dexterous manipulation. In *Conference on Robot Learning*, pages 594–605. PMLR, 2023.
- [56] C. Wu, X. Bi, J. Pfommer, A. Cebulla, S. Mangold, and J. Beyerer. Sim2real transfer learning for point cloud segmentation: An industrial application case on autonomous disassembly. In *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*, pages 4531–4540, 2023.
- [57] Y. Huang, J. Yuan, C. Kim, P. Pradhan, B. Chen, L. Fuxin, and T. Hermans. Out of sight, still in mind: Reasoning and planning about unobserved objects with video tracking enabled memory models. *arXiv preprint arXiv:2309.15278*, 2023.
- [58] J. Tobin, R. Fong, A. Ray, J. Schneider, W. Zaremba, and P. Abbeel. Domain randomization for transferring deep neural networks from simulation to the real world. In *2017 IEEE/RSJ international conference on intelligent robots and systems (IROS)*, pages 23–30. IEEE, 2017.
- [59] J. Tremblay, A. Prakash, D. Acuna, M. Brophy, V. Jampani, C. Anil, T. To, E. Cameracci, S. Boochoon, and S. Birchfield. Training deep networks with synthetic data: Bridging the reality gap by domain randomization. In *Proceedings of the IEEE conference on computer vision and pattern recognition workshops*, pages 969–977, 2018.

- [60] J. Tobin. Real-world robotic perception and control using synthetic data. 2019. URL <https://api.semanticscholar.org/CorpusID:198118904>.
- [61] M. Sundermeyer, Z.-C. Marton, M. Durner, M. Brucker, and R. Triebel. Implicit 3d orientation learning for 6d object detection from rgb images. In *Proceedings of the european conference on computer vision (ECCV)*, pages 699–715, 2018.
- [62] M. Kaspar, J. D. M. Osorio, and J. Bock. Sim2real transfer for reinforcement learning without dynamics randomization. In *2020 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 4383–4388. IEEE, 2020.
- [63] X. Yue, Y. Zhang, S. Zhao, A. Sangiovanni-Vincentelli, K. Keutzer, and B. Gong. Domain randomization and pyramid consistency: Simulation-to-real generalization without accessing target domain data. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 2100–2110, 2019.
- [64] R. Traoré, H. Caselles-Dupré, T. Lesort, T. Sun, N. Díaz-Rodríguez, and D. Filliat. Continual reinforcement learning deployed in real-life using policy distillation and sim2real transfer. In *ICML Workshop on “Multi-Task and Lifelong Reinforcement Learning”*, 2019.
- [65] A. A. Rusu, S. G. Colmenarejo, C. Gulcehre, G. Desjardins, J. Kirkpatrick, R. Pascanu, V. Mnih, K. Kavukcuoglu, and R. Hadsell. Policy distillation, 2016.
- [66] K. Kristinsson and G. Dumont. System identification and control using genetic algorithms. *IEEE Transactions on Systems, Man, and Cybernetics*, 22(5):1033–1046, 1992. doi:10.1109/21.179842.
- [67] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, G. Krueger, and I. Sutskever. Learning transferable visual models from natural language supervision, 2021.
- [68] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, and N. Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale, 2021.
- [69] I. Loshchilov and F. Hutter. Decoupled weight decay regularization, 2019.
- [70] A. Kirillov, E. Mintun, N. Ravi, H. Mao, C. Rolland, L. Gustafson, T. Xiao, S. Whitehead, A. C. Berg, W.-Y. Lo, P. Dollár, and R. Girshick. Segment anything. *arXiv:2304.02643*, 2023.
- [71] N. Ravi, V. Gabeur, Y.-T. Hu, R. Hu, C. Ryali, T. Ma, H. Khedr, R. Rädle, C. Rolland, L. Gustafson, et al. Sam 2: Segment anything in images and videos. *arXiv preprint arXiv:2408.00714*, 2024.

附录

A 附加相关工作

仿真到现实迁移。为克服现实世界中的数据收集挑战，一种理想的方法是在仿真中训练机器人策略并将其部署到现实世界。由于仿真到现实的差距，已采用多种技术来弥合这一差距，包括但不限于使用深度观测 [54, 55, 56, 57]、领域随机化 [58, 59, 60, 61, 62, 63]、知识蒸馏 [64, 65] 和系统辨识 [66]。学习仿真到现实策略通常需要特定任务的环境构建，例如奖励函数设计。相比之下，Im2Flow2Act通过学习流生成网络从现实世界的人类视频中学习任务信息。我们的策略从完全由一组预定义原始动作生成的仿真探索数据中学习，这些数据更容易收集，并进一步减少了对特定任务环境构建的需求。

B 附加实验



图 6：机器人部署过程中的流生成比较。我们在倒水任务中并排比较 **Im2Flow2Act** 和 **ATM**。**Im2Flow2Act** (a) 在视觉输入中存在 UR5 的情况下展示了其鲁棒性，生成高质量的对象中心任务流。相比之下，**ATM** 在从球体演示学习时生成嘈杂的流 (c)，并且仅在从同具身演示学习时表现良好 (b)。请注意，我们仅可视化 **ATM** 中具有高方差的查询点。由于 **ATM** 仅预测未来 N 步，并且杯子在预测范围内不会移动，因此子图 b 中杯子上没有流。请参考图 10 了解机器人更靠近对象的情况。我们可视化对象移动时的完整网格流。

在本节中，我们提供了与基线 ATM [14] 在抓取放置、倒水和抽屉任务中的额外定性和定量比较。我们使用官方 ATM 仓库训练其流生成模型，并将其操作策略适配为扩散动作头。我们移除了操作策略中的 RGB 输入，与 Im2Flow2Act 类似。我们额外提供与 Im2Flow2Act 相同的初始深度输入，以确保公平比较。我们没有像 Im2Flow2Act 那样在更具挑战性的探索数据集上训练，而是直接提供任务特定数据来训练 ATM 操作策略。对于 ATM，我们训练了两个版本的流生成模型：一个使用 UR5 演示（即同具身），另一个使用球体代理演示（即跨具身演示）。请注意，我们的方法始终使用跨具身演示进行训练。

	Demonstration-conditioned execution			Language-conditioned execution		
	Pick&Place	Pouring	Drawer	Pick&Place	Pouring	Drawer
Im2Flow2Act	100	95	95	90	85	90
ATM cross embodiment	/	/	/	50	30	85
ATM same embodiment	/	/	/	90	90	95

表 3：与 ATM 结果的比较 (%)

在图 6 中，我们首先在机器人部署期间并排比较 Im2Flow2Act 和 ATM 生成的流。如图 6.a 所示，由于选择使用完整的对象中心流，Im2Flow2Act 对视觉输入中 UR5 的存在具有鲁棒性，并生成高质量的流。相比之下，ATM 仅在以同具身方式训练（即用 UR5 训练并用 UR5 推理）时才能生成高质量的流（见图 6.b）。当以跨具身演示训练（即用球体代理训练并用 UR5 推理）时，它生成低质量和嘈杂的流（见图 6.c）。

如更新版主论文第 3.1 节所述，ATM 在跨实体演示中学习时表现不佳的关键原因是，在机器人部署期间视觉输入变得分布外。与 Im2Flow2Act 的以物体为中心的流相比，ATM 生成网格流。这一设计选择导致生成的大部分流是针对实体的。在训练期间，ATM 的流生成模型接收跨实体演示（真实世界中的人臂和仿真中的球体）的视觉输入并进行预测，其中大部分与实体流相关。

然而，在机器人部署期间，视觉输入包含机器人手臂和夹爪，而不是人臂或球体。由于模型也生成实体流，未见过的实体导致模型处于分布外状态。

相比之下，Im2Flow2Act 仅生成物流，不关注实体。初始物体关键点也为模型生成以物体为中心的流提供了强初始条件。因此，我们的模型在机器人部署期间对不同实体的存在具有鲁棒性。

我们进一步评估了具有两种流生成模型版本的 ATM 完整系统，并将其与 Im2Flow2Act 进行比较。注意，ATM 系统缺乏以完整演示为条件的能力。如表 3 所示，当流生成模型从跨实体演示中学习时，与从同实体演示中学习相比，ATM 的性能显著下降。相比之下，我们的系统在从跨实体演示中学习时表现出强大的能力。

B.1 多物体长时程任务




图 7：多物体长时程任务：Im2Flow2Act 能够为涉及多个物体的长时程任务生成流 (a)。我们的流程首先获取感兴趣物体的多个边界框，并根据边界框面积按比例动态采样初始关键点。采样后的关键点被拼接成一个 $H \times W$ 矩形流图像，作为流生成模型的条件。我们的操作策略 (b) 有效地遵循生成的流，成功完成任务。视频请访问我们的匿名网站：<https://im2flow2act.github.io/>

我们进行了额外的实验，以评估 Im2Flow2Act 在涉及多个物体的长时程任务上的性能。在该任务中，机器人需要执行一系列动作：首先打开抽屉，然后从桌上拿起蓝色方块并将其放入抽屉，最后关闭抽屉。抽屉和方块的位置在每个回合开始时随机初始化。我们收集了 150 条跨具身演示轨迹（即使用球形智能体），并据此训练了流生成模型，同时收集了 100 条 UR5 演示用于训练操作策略。

对于涉及多个物体的流生成任务，我们同样使用 Grounding DINO 获取所有相关物体的边界框。然后在每个边界框内进行均匀采样。每个边界框内采样的关键点数量与其面积成正比。为了

确保总共有 $H \times W$ 个关键点，我们根据需要填充最终采样的关键点。核心思想仍然是从置换不变的关键点构建结构流图像。

Im2Flow2Act 能够生长时程流的关键原因在于，我们的流生成模型以时间子采样的方式生成流，而不是以原始流速生成。这种设计使网络能够轻松地处长时程任务生成紧凑的流。此外，当跨具身演示的速度与机器人的速度差异显著时，它使系统更加鲁棒。

流生成网络和操作策略的训练与推理均使用了与其他任务相同的参数，更多细节见附录 F.1 节和 F.2 节。

	Demonstration-conditioned execution	Language-conditioned execution
Im2Flow2Act	90	85
ATM	/	45

表 4: 涉及多个物体的长时程任务结果 (%)

我们将 Im2Flow2Act 的性能与 ATM 进行了比较，使用与 Im2Flow2Act 相同的训练数据来生成流和操作策略。如表 4 所示，Im2Flow2Act 在演示条件执行设置下以 90% 的成功率成功完成长时程任务，在语言条件执行设置下以 85% 的成功率成功完成长时程任务。在语言条件执行设置下，我们在图 7 中可视化了生成的流和机器人执行过程。如图 7 所示，Im2Flow2Act 能够为具有多个对象的长时程任务生成完整的以对象为中心的任务流，并且机器人执行与生成的流紧密对齐。ATM 的性能受到流生成模型中的分布外视觉输入的影响，正如我们在上一节和更新后的主论文第 3.1 节中所讨论的。

B.2 初始三维关键点的消融实验

	Demonstration-conditioned execution			Language-conditioned execution		
	Pick&Place	Pouring	Drawer	Pick&Place	Pouring	Drawer
Im2Flow2Act	100	95	95	90	85	90
Im2Flow2Act w.o. 3D	100	90	90	85	85	80

表 5: Im2Flow2Act 有无初始三维关键点的消融实验结果 (%)

我们进行了额外的实验来证明初始三维关键点的必要性。我们的实验（见表 5）表明，当以生成的流作为输入（即语言条件执行）时，初始三维关键点提高了策略性能。生成的流通常包含一些噪声关键点运动，尤其是物体周围的关键点。额外的三维关键点有助于网络区分噪声关键点和实际位于物体上的关键点，例如抽屉把手。

一旦确定了初始三维关键点，所有剩余的运动都相对于这些初始三维关键点。因此，我们的系统不需要所有帧的三维关键点。此外，在现实世界中为每一帧获取三维关键点涉及额外的操作，因此我们旨在保持系统简单高效。

B.3 仿真中的生成流

在仿真中，我们通过用球体代理替换 UR5 来收集跨具身演示，并使用这些演示来训练流生成模型。学习到的流生成




图 8：仿真中的生成流：我们可视化了仿真中四个任务的高方差生成流。我们使用运动滤波器来过滤高方差的流。有关运动滤波器的更多细节可以在附录 G.2 中找到。关键点已进行下采样以提供更好的可视化效果。请注意，在现实世界中，我们使用人类演示来训练流生成模型。

模型用于在语言条件执行设置下评估 Im2Flow2Act 在仿真中的性能（见表 1）。

B.4 预训练稳定扩散的消融研究

是否使用预训练的稳定扩散模型来训练流生成模型的定量结果见附录 D 节。本节中，我们可视化两种方法的训练损失。如图 9 所示，利用稳定扩散中预训练的 U-Net 可以实现更快的收敛和更低的损失。这表明在预训练 U-Net 上进行微调有利于流生成。




图 9：预训练 U-Net 与从头训练：预训练 U-Net 的训练损失收敛速度明显更快。可视化损失未经平滑处理。

B.5 ATM 流生成的额外可视化

本节中，我们提供了 ATM 完整网格流预测的可视化，以及从预测网格流中过滤出的物体流（见图 10）。ATM 基于当前状态预测未来 16 步的网格流。我们用于过滤物体流的边界框与 Im2Flow2Act 中使用的相同。与图 6 相比，图 10 中机器人更靠近物体。从图 10 的 **b1** 和 **b2** 可以看出，如果从相同形态的演示中学习，ATM 可以生成高质量的流。然而，如果从跨形态演示中学习，生成的流完全是噪声（见图 10 的 **c1** 和 **c2**）。相比之下，即使从跨形态演示中学习，Im2Flow2Act 也能生成高质量的流。注意，我们

将原始 ATM 论文中的网格关键点数量从 32 增加到 400，以确保公平比较。ATM 策略也以 400 个网格关键点的完整流作为输入，这显著大于我们方法中的 128 个物体关键点。




图 10: 机器人部署过程中的流生成比较（网格流及用物体边界框过滤后的流）我们在倒水任务中并排比较 **Im2Flow2Act** 和 **ATM**。当从跨形态演示中学习时，**ATM** 生成噪声流（c1、c2）。相比之下，即使从跨形态演示中学习，**Im2Flow2Act** 也生成了高质量的流（a）。注意，**Im2Flow2Act** 的可视化流是经过运动滤波器处理后的。初始关键点从边界框中均匀采样，我们不手动选择初始点。

C 数据收集

在 Im2Flow2Act 中，我们收集两类数据：仿真机器人探索数据集和真实世界人类演示视频。注意，我们不收集任何真实世界机器人数据。下面详细介绍数据收集过程。

C.1 仿真探索数据

我们使用 MuJoCo 作为仿真引擎，构建了三种类型的探索环境，分别包含刚体、关节体和可变形物体。UR5e 机器人通过一组预定义的随机启发式动作在这些环境中进行探索。

刚体: 在刚体环境中，机器人可以与五种不同物体交互，包括玩具车、鞋子、迷你灯、煎锅和马克杯。每个回合开始时，随机选择一个物体放置在桌面上。机器人首先抓取物体，然后开始执行六自由度随机轨迹。随机轨迹构造为一条三维三次贝塞尔曲线，包含四个关键路径点：起点 p_0 、两个控制点 p_1 和 p_2 以及终点 p_3 。起点是机器人首次抓取物体的位置，终点在机器人可达的世界坐标范围内随机选择。两个控制点通过向由 p_0 和 p_3 定义的直线添加曲率得到。具体来说，对于第一个控制点 p_1 ，我们首先计算三分之一处和

然后我们在三维空间中扭转 $m_1 = \frac{(p_3 - p_0)}{3}$ 通过添加随机偏移（曲率）得到第一个控制点，即 $p_1 = m_1 + \epsilon$ ，其中 $\epsilon \in \mathbb{R}^3$ 。我们设置 ϵ 的每个维度从 $(-0.05, 0.05)$ 中均匀采样。类似地，我们通过计算三分之二处并添加一些随机偏移来得到第二个

控制点。一旦得到点 p_0, p_1, p_2 和 p_3 ，我们通过 $(1-t)^3P_0 + 3(1-t)^2tP_1 + 3(1-t)t^2P_2 + t^3P_3$ 定义三次贝塞尔曲线，其中 $t \in [0, 1]$ 。我们沿该曲线等距采样 k ($k = 16$) 个路径点，这些路径点定义了机器人探索轨迹的平移。当物体到达最终点 p_3 时，我们添加目标物体朝向（每个维度从 $(-\frac{\pi}{8}, \frac{\pi}{8})$ 随机采样）。我们在 p_0 处的初始朝向和 p_3 处的目标朝向之间进行插值，并将它们附加到 k 个路径点上。对于每个回合，我们采样两条连续的三维三次贝塞尔曲线，使机器人能够与随机物体交互，并建立流与动作之间的对应关系。轨迹以随机旋转或放置动作结束。

铰接式：我们构建了多种类型的抽屉，这些抽屉均不同于真实世界中测试的抽屉。在每个回合中，随机选择一个抽屉放置在桌面上。机器人通过将抽屉打开到不同程度（不一定是完全打开）来探索这些铰接物体。为了打开抽屉，在抽屉把手上随机选择一个接触点，该接触点位于把手中心 $(-0.07, 0.07)$ 范围内。然后将该接触点传递给预定义的开抽屉原语。该原语将夹爪放置在接触点上，并通过垂直于抽屉表面拉动来启动抽屉的打开。每个回合随机采样一个阈值，范围从 $(0.07, 0.12)$ ，用于定义成功标准。一旦抽屉把手移动超过该阈值，机器人就停止执行，表示成功打开。

可变形：在回合开始时，一块布料随机放置在桌面上。机器人可以选择抓取布料的左角或右角。我们使用预定义的抓取原语来实现这一行为，该原语接收抓取姿态作为输入，类似于我们在刚性数据集生成中使用的原语。一旦抓取，机器人开始随机折叠（不一定是沿对角线折叠）。我们定义了九个不同的折叠目标，机器人随机选择一个开始折叠。这九个不同的折叠目标由抓取点坐标在 x 轴和 y 轴上的 $(0.08, 0.15, 0.28)$ 组合而成。在此过程中，我们还通过将布料提升到不同高度来改变折叠轨迹。我们使用预定义的移动启发式方法将末端执行器移动到随机高度。我们首先计算折叠角与折叠目标之间的距离 d 。然后我们在 $(d/4, d)$ 之间随机采样提升高度。最后，我们将末端执行器移向折叠目标并打开夹爪。

总体而言，我们收集了 4800 条随机探索轨迹。数据收集完成后，我们采用迭代流程获取物体流。对于每个采集的片段，我们首先在初始帧上采样均匀网格 (30×30) 关键点，并使用塔皮尔 (Tapir) [47] 跟踪所有点，方法与 ATM [14] 中的类似。随后，我们应用移动滤波器和万物分割模型 (Segment Anything Model, SAM) 滤波器，详细说明见第 G 节，以获取物体上的关键点。然而，由于初始采样是均匀的，位于物体上的点可能较少。为解决这一问题，我们根据 SAM 输出在现有关键点周围采样额外点，以实现物体关键点的更密集分布。具体而言，对于滤波后包含关键点的分割区域，我们根据该区域内滤波后关键点的数量按比例采样。每个物体上总共采样 900 个点。最后，我们再次对新采样的物体关键点运行点跟踪算法，以获得密集的物体流。

C.2 真实世界人类演示视频：

我们为四项任务收集了域内人类演示视频：抓取与放置、倾倒、打开抽屉和折叠布料。我们使用实感 (RealSense) 相机以 30 帧每秒录制演示。以下描述同时作为详细的任务说明。在 Im2Flow2Act 中，我们利用人类视频为系统提供任务信息。我们将机器人基座定义为世界坐标系的原点，并使用右手坐标系。

- **抓取与放置：**拿起一个绿色杯子并将其放入一个红色盘子中。红色盘子随机放置在桌子的一侧，而杯子随机放置在桌子中间。
- **倾倒：**拿起一个绿色杯子，将其悬停在红色碗上方，然后朝碗的方向旋转杯子。杯子和碗的初始摆放位置与抓取与放置任务相同。

- **打开抽屉：**完全打开一个随机放置在桌子一侧的抽屉。抽屉的位姿（包括位置和朝向）可以变化。抽屉并未刚性固定在桌子上。
- **布料折叠：**将一块 33 厘米×33 厘米的布料从一个角（左下角或右下角）折叠到对角。布料随机放置在桌子中央。

在收集人类演示后，对于每个回合，我们使用 Grounding DINO 在初始帧获取物体边界框，并在内部均匀采样关键点，其中设置 $H = W = 32$ 作为采样参数。然后运行点跟踪算法在回合中跨帧跟踪关键点。为构建训练数据集，我们从每个回合均匀采样 32 帧以形成任务流。

D 消融实验

我们在仿真中进行了消融实验，以评估使用预训练 StableDiffusion (SD) 与从头训练对流生成模型的影响。在该消融实验中，我们仍使用 SD 的预训练 AE（自动编码器），但从头训练 U-Net，而不是加入 LoRA 层。为确保公平比较，我们部署相同的流条件

表 6：消融实验结果（%）拾放 倾倒 抽屉 布料

	Pick&Place	Pour	Drawer	Cloth
Pretrain U-Net	90	85	90	35
U-Net From Scratch	90	90	95	30

策略，用于预训练 SD 和从头训练作为操作策略。我们在仿真中为四个任务收集数据，将 UR5e 机器人替换为球形机器人以创建跨具身场景。两个网络训练相同轮次，并在相同初始状态下评估。根据表 6 所示结果，预训练的选择对 Im2Flow2Act 的最终性能影响较小。这表明：i. 尽管 StableDiffusion 最初为图像生成设计，直接使用其预训练权重进行流生成不会影响性能。利用 LoRA 相比从头训练可获得更好的训练效率。ii. 预训练 SD 的 AE 编码的潜空间可能有利于扩散模型的学习过程。

与仿真中使用真实流的结果相比，我们观察到对于抓取与放置、倾倒和抽屉开启等任务，以生成流作为输入的成功率非常接近。这进一步证明了流生成网络的能力。然而，布料折叠的成功率显著下降。我们将此归因于布料折叠仿真环境的构建方式。抓取布料等可变形物体具有挑战性，因此我们在布料角落附加了一个立方体（见图 11），以帮助机器人通过抓取立方体来提起角落。在数据生成和推理过程中，我们仅渲染布料而不渲染立方体，以模拟真实的布料折叠行为。我们将立方体在 xy 平面上的尺寸设置得非常小（1 厘米×1 厘米），以模拟夹爪抓取实际布料时的宽度。由于扩散模型的输出通常呈现多模态分布，且我们的训练数据集包含相当大的随机性，学习到的流生成模型为折叠任务生成了合理的流，但可能无法引导策略精确抓取立方体。此外，经过运动滤波后的流加剧了这一问题。我们发现，在大多数情况下，机器人能够到达角落并尝试抓取（见图 11），但无法准确抓住立方体。相比之下，我们在真实世界实验中观察到了合理的成功率，因为在实际操作中，机器人可以沿角落任意位置抓取布料来执行折叠。




图 11：可变环境中的策略执行。我们附加了一个微小立方体（1 厘米×1 厘米×9 厘米），使机器人能够抓取可变形物体。生成的流引导策略到达合适的抓取点；然而，它未能抓住微小立方体，导致任务失败。

E 实验细节

E.1 真实世界设置

我们使用配备 WSG-50 夹爪的 UR5e 机器人。在推理过程中，UR5e 接收来自 2.5 Hz 策略的末端执行器空间位置指令。我们将末端执行器的速度限制在 0.2 m/s 以下，并将其位置限制在桌面上方至少 1 cm 处以确保安全执行。RealSense D415 深度相机安装在桌面上，用于捕获策略观测，包括用于初始点云的初始深度图像 x_0 以及用于在线点跟踪的实时 RGB 图像。RealSense 相机以 720p 和 30 Hz 录制。我们将分辨率降采样至 256x256 并以 5 Hz 供在线点跟踪算法处理。此外，我们使用一部智能手机从不同角度更好地记录机器人执行过程。一台配备 24 GB NVIDIA RTX 4090 的台式机运行流生成网络、流条件模仿学习策略推理和在线点跟踪算法。

E.2 真实世界评估协议

在本节中，我们描述真实世界评估协议的细节。

1) 初始状态：在评估我们的系统时，我们不将背景场景设置与人类演示中记录的相匹配，以便同时测试流生成网络的泛化能力。对于物体的初始位置，它们以与人类视频演示中大致相同的分布放置。

2) 成功度量：以下是所有四个任务的真实世界成功度量的细节：

- **抓取与放置：**机器人需要拿起杯子并将其放入红色盘子中。我们不要求杯子位于盘子中心。如果满足以下条件，则认为一个回合成功：i. 机器人能够稳定地将杯子放到红色盘子上；ii. 在机器人操作过程中，盘子在桌面上的移动不超过 5 cm。
- **倾倒：**机器人需要拿起杯子，将其悬停在碗附近，并执行倾倒动作。若满足以下条件，则认为一个回合成功：i. 机器人通过将杯子旋转超过 30 度来展示完整的倾倒行为；ii. 在世界坐标中，杯子至少有一半在 x 轴上与红色碗重叠。
- **打开抽屉：**机器人需要完全打开抽屉，且不与抽屉表面发生碰撞。由于抽屉未刚性固定在桌子上，在机器人执行过程中可能会轻微滑动。若满足以下条件，则认为一个回合成功：i. 机器人夹爪未与抽屉表面发生严重碰撞，且未将抽屉推回超过 5 厘米；ii. 抽屉被完全打开。
- **布料折叠：**机器人需要将布料从一个角折叠到对角相对的角。若满足以下条件，则认为一个回合成功：i. 机器人按照生成的流所指示的方式折叠该角；ii. 机器人完成执行后，两个角之间的距离在阈值以内。由于可变形仿真存在较大的仿真到现实差距，我们将该阈值设为 7 厘米。

E.3 评估流程

Im2Flow2Act 有/无对齐：对于每个任务，我们首先在 20 个评估回合中记录不同初始状态下的初始帧。然后，我们使用 Grounding DINO 查询感兴趣物体，以获取所有初始帧中的边界框。利用边界框、初始帧和任务描述，我们为所有回合生成物流（任务流），并将其作为缓冲区存储在磁盘上。在策略推理所需的所有要素准备就绪后，我们开始对每个回合进行策略评估，通过手动匹配初始状态，使其在安装的 RealSense 相机中接近像素级完美，并从先前保存的流缓冲区中加载对应的生成流。

基于启发式的策略：为了获得物体的真实未来点云，我们首先为 20 个评估回合记录人类演示。在此过程中，我们同时存储 RGB 和深度图像。对于每个评估回合，我们手动匹配初始状态使其接近像素完美，并通过估计人类演示中每个时间步初始帧与未来帧之间的物体姿态变换来获得开环动作序列。我们使用与 Im2Flow2Act 相同的运动滤波器以确保公平评估。此外，我们提供任务流中最大可用点数（不进行下采样）。我们通过将变换后的初始帧点云与未来帧点云重叠来手动检查变换后的点云，以确保在真实世界深度相机的噪声条件下变换基本正确。

F 训练细节

F.1 流生成网络

条件注入。文本条件被传入 CLIP[67] 文本编码器以获得文本嵌入。我们还将初始帧和初始物体关键点 $\mathcal{F}_0$ 输入模型，以确保生成过程考虑物体与场景之间的空间关系。我们使用 CLIP 图像编码器对初始帧进行编码，从最后一个 ViT[68] 层为每个图像块生成一个 P^2 嵌入。初始关键点 $\mathcal{F}_0$ 使用固定的二维正弦位置编码进行编码。所有条件通过交叉注意力注入到去噪过程中。

训练细节。对于矩形流图像，我们将空间分辨率设置为 $H = W = 32$ 和 $T = 32$ ，在 32 个步骤中为 1024 个关键点生成流。我们从 StableDiffusion 微调解码器，训练 400 个训练轮次，学习率为 $5e-5$ 。为了获得这些关键点，我们从 Grounding DINO 提供的边界框中均匀采样。对于训练 AnimateDiff，我们将秩为 128 的低秩适配 (LoRA) 插入到 StableDiffusion 的 Unet 中，并使用 AdamW 从头训练运动模块层，学习率为 1×10^{-4} ，训练 4000 个训练轮次

[69] 优化器，权重衰减 1×10^{-2} ，betas (0.9, 0.999) 和 epsilon 1×10^{-8} 。我们加载来自 CLIP[67] 的预训练 (openai/clip-vit-large-patch14) 权重来处理初始帧，并在整个训练过程中冻结它们。在将条件传入交叉注意力层之前，使用零初始化的线性层处理图像块嵌入和初始关键点嵌入。

F.2 流条件模仿学习策略

训练数据格式：一个训练样本由 $(\rho_t, f_t, \mathbf{a}_t, F_{0:T})$ 组成，其中 ρ_t 是本体感知数据， $\mathbf{a}_t$ 是长度为 L 的动作序列 $a_t, \dots, a_{t+L}$ ， f_t 包含时间 t 时图像空间中 $N = 128$ 个物体关键点的位置 (u, v) 。我们将物体流（即任务流）的时域范围设为 $T = 32$ ，与流生成网络的输出相匹配。动作序列长度设为 16。在训练过程中，每个训练样本的 N 个关键点从所有可用关键点中随机选取。为构建任务流 $F_{0:T}$ ，我们从训练样本所属的回合长度 T' 中随机选取 T 帧。这使得策略能够使用多样化的任务流进行训练，因为流生成模型是用人类数据训练的，而人类数据的执行节奏通常与机器人不同。此外，我们约束任务流长度 $F_{0:T}$ 远短于回合长度 T' ，以降低流生成模型的训练难度，否则它需要生成成长时域任务流。为确保任务流完整，我们将回合的第一帧和最后一帧都包含在任务流中。

状态编码器：我们使用线性层将关键点的初始三维坐标 X_0 投影为 192 维向量。我们还使用固定的二维正弦位置编码将关键点在图像空间中的位置 (u, v) 编码为另一个 192 维向量。这两个向量拼接形成描述符 ϵ ，总维度为 384。然后将所有关键点的描述符输入状态编码器 ϕ ，该编码器是一个具有 4 个编码器层的变换器。它使用 CLS 标记输出维度为 384 的状态表示。

时间对齐：如正文所述，在训练过程中，我们首先将剩余任务流 $f_{t:T'}$ 编码为 $z_t \in \mathcal{Z}$ 。该过程涉及通过状态编码器将每个时间步 $f_{t:T'}$ 的关键点编码为 $s_{t:T}$ 。接下来，我们通过编码器 ξ 将未来状态表示 $s_{t:T}$ 编码到潜空间中，该编码器实现为一个具有 4 个编码器层的变换器。在将状态表示 $s_{t:T}$ 输入 ξ 之前，我们使用固定的一维正弦位置编码来保留时间信息。时间对齐模型实现为一个具有 8 个编码器层的变换器。我们还为所有输入添加固定的一维正弦位置编码，并使用 CLS 标记进行预测。

扩散动作头：本文采用扩散策略 (Diffusion Policy) [50] 作为动作头。使用 DDIM 调度器，训练扩散步数为 50，推理步数为 16。

策略训练 500 个训练轮次，学习率为 $1e-4$ ，使用 AdamW betas (0.9, 0.999) 1×10^{-8} 优化器，权重衰减 1×10^{-2} ，及 epsilon 参数。

G 推理细节

本节描述推理过程的细节，包括 Grounding DINO、运动滤波器以及在线点跟踪。

G.1 Grounding DINO

对于每项任务，首先使用 Grounding DINO 识别感兴趣的对象。关键词由人工提供给模型；然而，该过程可借助大语言模型 (Large Language Model) 自动从任务描述中查找目标对象。具体而言，采用 grounding-dino-base 模型提取对象的边界框。抓取与放置及倾倒任务使用的关键词为“绿色杯子”。抽屉开启任务的关键词为“黄色抽屉”，布料折叠任务的关键词为“方格布”。输入图像以 480x640 分辨率处理。

G.2 运动滤波器

使用运动滤波器处理由流生成模型生成的对象流（即任务流）。如正文所述，初始关键点通过在边界框内均匀采样构建。该方法不可避免地产生不在对象上的关键点，即落在背景上的关键点。为解决此问题，同时部署多个滤波器以移除这些背景关键点。此外，实施深度滤波器以剔除来自噪声真实世界深度图像中缺乏深度数据的关键点。

移动滤波器：在训练集中，采样于背景上的关键点在图像空间中保持静止，因为只有物体在运动。因此，我们在推理阶段部署一个移动滤波器，以移除在图像空间（ 256×256 ）中移动量低于特定阈值的关键点。我们发现该滤波器能有效消除大部分背景关键点。在实际实验中，我们将拾取与放置、倾倒和抽屉开启任务的阈值设为 20，将布料折叠任务的阈值设为 10。

万物分割模型（Segment Anything Model, SAM）滤波器：为了在应用移动滤波器后进一步移除点，我们部署了万物分割模型（Segment Anything Model, SAM）[70]。具体而言，我们首先将初始帧调整为 256×256 ，并将其输入 SAM 以获得最精细的分割。然后遍历关键点，过滤掉所在分割区域面积超过阈值的关键点。我们对所有任务使用较高的阈值 10,000，以防止过滤掉纹理丰富物体上的关键点。

深度滤波器：真实世界的深度图像通常含有噪声并存在许多“空洞”。我们过滤掉深度值缺失（即值为零）的关键点。

在应用运动滤波器后，我们随机选择 $N=128$ 个关键点，其数量与训练时使用的数量相同，作为策略输入。

G.3 在线点跟踪：

我们利用来自 Tapir 的在线点跟踪功能 [47] 在推理过程中跟踪筛选后的关键点。我们将视觉观测调整为 256×256 ，并以 5Hz 的频率运行在线点跟踪。

H 仿真跨具身演示细节

如主论文所述，我们收集球体智能体演示以模拟真实世界中的人类演示。本节提供收集过程的细节。我们使用同一组预定义的启发式动作原语来收集球体演示。详情请参阅附录 C 节。

拾放任务：每个回合开始时，杯子和目标盘子随机放置在桌面上。杯子的初始位置沿 x 轴在 $(0.42, 0.76)$ 之间随机采样，沿 y 轴在 $(-0.1, 0.02)$ 之间随机采样。目标盘子的初始位置沿 x 轴在 $(0.42, 0.65)$ 之间随机采样，沿 y 轴在 $(0.24, 0.32)$ 之间随机采样。机器人首先执行抓取原语，将杯子提升到桌面上方随机选择的高度，高度在 $(0.15, 0.20)$ 米之间。提起杯子后，机器人执行移动原语，将杯子定位在目标盘子上方。悬停位置从 $(0.1, 0.25)$ 中随机采样。最后，机器人将杯子放到盘子上并打开夹爪。

倾倒任务：杯子的初始位置分布与拾放任务相同。目标碗的初始分布与拾放任务中目标盘子的分布相同。机器人在移动杯子之前遵循与拾放任务相同的程序，包括使用的原语和采样的随机参数。提起杯子后，机器人将其移动到目标碗附近，并在与目标碗共享相同 x 轴值的位置悬停杯子。然后机器人执行倾倒原语，使杯子绕 y 轴顺时针旋转。旋转角度从 $(\frac{5\pi}{16}, \frac{7\pi}{16})$ 中随机采样

$$(\frac{5\pi}{16}, \frac{7\pi}{16}).$$

抽屉任务： 抽屉的初始姿态在每个回合开始时随机采样。其初始位置在 x 轴上从 $(0.45, 0.62)$ 随机采样，在 y 轴上从 $(-0.4, -0.32)$ 随机采样，在 z 轴上从 $(0.05, 0.18)$ 随机采样。抽屉的初始旋转从以下范围采样： $(\frac{3\pi}{8}, \frac{\pi}{2})$ 。The robot executes the open primitive as described in Appendix Sec. C.

折叠： 布料在每个回合开始时随机放置在桌面上。我们使用被立方体固定的角来描述初始位置。该角在 x 轴上随机放置在 $(0.32, 0.44)$ 之间，在 y 轴上随机放置在 $(-0.32, 0.32)$ 之间。由于逆运动学误差， x 轴上超过 0.44 的值通常会导致仿真不稳定。布料在 $(-\frac{\pi}{8}, \frac{\pi}{8})$ 之间随机旋转。与附录 C 节中描述的从九个预定义折叠点随机采样的方式不同，机器人将仅沿对角线折叠布料。

长时程： 抽屉的初始位置分布与抽屉任务相同。然而， z 轴上的采样范围被修改为 $(0.05, 0.12)$ ，以确保立方体放入抽屉时保持在相机视野内。立方体的初始位置分布与拾取放置任务中杯子的分布相同。机器人执行打开原语以打开抽屉，执行抓取原语以抓取立方体，最后将立方体放入抽屉。所有原语的输入参数与拾取放置任务中使用的相同，但放置前悬停位置的采样范围被修改为 $(0.1, 0.15)$ ，以保持立方体在相机视野内。

I 额外局限性

系统假设相机视角在仿真和测试环境之间已校准，且动作在相机中可见。此外，使用流作为动作抽象会忽略一些动作细节，限制了在灵巧操作任务（如手中操作）中的性能。我们的流生成模型依赖于准确的目标检测，这可以通过先进的目标检测/分割模型 [71] 来改进。最后，我们专注于“操作任务”而非移动任务，其中操作被定义为通过交互改变物体状态。然而，在物体状态变化未反映在物体运动中的场景（例如，“触摸触摸屏上的按钮”），我们的方法可能不适用。