

基于不变性匹配的一次性模仿学习用于机器人操作

Xinyu Zhang and Abdeslam Boularias

Rutgers University

Email: {xz653, ab1544}@rutgers.edu

摘要——学习一个能够执行多种操作任务的单一通用策略是机器人学中一个有前景的新方向。然而，现有技术仅限于学习在训练期间遇到的任务的策略，并且需要大量演示来学习新任务。相比之下，人类通常可以从单个未标注的演示中学习新任务。在这项工作中，我们提出了不变性匹配一次性策略学习（IMOP）算法。与直接学习末端执行器姿态的标准做法不同，IMOP 首先为给定任务学习状态空间中的不变区域，然后通过匹配演示和测试场景之间的不变区域来计算末端执行器的姿态。在 18 个 RLBench 任务上训练后，IMOP 的成功率持续优于最先进的方法，在 18 个任务上平均高出 4.5%。更重要的是，IMOP 可以从单个未标注的演示中学习新任务，无需任何微调，并在从九个类别中选出的 22 个新任务上，相比最先进的方法实现了平均成功率提升 11.5%。IMOP 可以泛化到与演示中不同的新形状和物体。此外，IMOP 可以使用单个真实机器人演示执行一次性仿真到现实迁移。

I. 引言

多任务学习（Multi-Task Learning, MTL）是一种较新的学习技术，其中单一策略被训练以执行多种任务。随着计算机视觉架构的最新进展 [20]，机器人学中一种流行的多任务学习策略是通过视觉演示的模仿学习来获取多任务控制策略 [16, 17, 38, 41]。这些方法在非结构化三维环境（如 RLBench[24]）中执行具有挑战性的操作任务方面取得了令人瞩目的成果。然而，这些方法依赖于训练和测试共享相同任务集的假设。此外，在新任务上训练此类策略需要数百个演示 [17]，这会导致对旧任务的灾难性遗忘 [26]。为了解决这些问题，一次性模仿学习旨在学习一组基础任务，并在仅给定每个新任务一个演示且无需重新训练的情况下泛化到新任务。然而，现有方法依赖于强假设，例如要求新任务是相同基础任务的有限变体 [42]，要求基础任务和新任务具有相同的物体设置 [11]，仅在具有已知三维模型的特定物体类别上泛化特定动作 [2]，或在简单的二维平面环境中操作 [13]。此外，最近的大多数工作集中于应用通用的流行

技术，例如变换器和扩散模型，应用于单次模仿设置，而未利用机器人操作任务特定结构的优势 [11, 32, 42, 43]。因此，这里的关键问题是：机器人能否学习一种操作策略，不仅能在基础任务上表现良好，还能仅凭单次演示且无需任何微调就泛化到新颖的未见任务？为此，我们提出 **IMOP**（不变性匹配单次策略学习），这是一种新算法，不仅在 RLBench 的标准 18 项任务上超越了最先进水平（平均总成功率 69.6%，对比最先进方法的 65.1% [16]），还能仅凭单次演示且无需任何微调就泛化到 22 项新颖任务（平均成功率 41.3%，对比最先进方法的 29.8%）。这 22 项新颖任务选自九个类别，在物体和任务目标方面与基础任务有显著差异 [19, 24]。此外，我们发现 **IMOP** 还能泛化到显著的形状变化，并能操作与演示中不同的新物体。**IMOP** 不直接学习期望的末端执行器姿态，而是学习每个任务的关键不变区域，并在单次演示和给定测试场景中的不变区域之间找到成对对应关系。这些成对对应关系用于通过点集配准问题的最小二乘解，解析地计算测试场景中期望的末端执行器姿态。不变区域定义为一组 3D 点，当在末端执行器坐标系中观察时，其坐标在共享相同语义动作的状态之间保持不变。我们设计了一个基于图的不变区域匹配网络。不变区域通过邻居注意力 [48] 从连接演示和测试场景点云的 KNN 图中定位。真实不变区域在基础任务的离线未标注演示中发现。总之，我们的贡献有三方面。（1）我们提出 **IMOP**，一种用于机器人操作的单次模仿学习算法，学习一种通用策略，不仅在基础任务上成功，还能仅凭单次未标注演示泛化到新颖任务。（2）我们提出一种基于对应关系的姿态回归方法用于操作任务，通过匹配关键视觉元素来预测机器人动作，以及一个在连接演示和测试场景的 KNN 图上的基于图的不变区域匹配网络。（3）我们对 **IMOP** 在多样化任务集上的性能和泛化能力进行了全面的实证研究。

II. 相关工作

从演示中学习机器人操作。随着视觉模型的快速改进，从离线视觉演示中学习操作策略受到越来越多的关注 [12, 28, 29, 3, 4, 36]。先前的工作如传输网络 [45] 和 CLIPort[37] 在二维平面环境中学习了简单的拾取和放置任务。C2F-ARM[25] 和 PerAct[38] 将控制能力扩展到具有 6 自由度的三维空间，但为每个单一任务学习单独的策略。最近，RVT[17]、Hiveformer[19]、Act3D[16] 和 ChainedDiffuser[41] 从多个任务的演示中学习了多任务策略。然而，这些先前的方法只能执行训练期间见过的任务，无法在推理时泛化到新任务。训练这些模型还需要每个任务数百个演示。相比之下，本文旨在开发一种多任务策略，不仅在已见任务上表现良好，还能在给定单个演示的情况下泛化到新任务。

单样本模仿学习。传统的模仿学习考虑为单个任务学习策略，并为该特定任务提供许多专家轨迹。单样本模仿学习旨在从一组基础任务的演示中学习，并在每个新任务仅使用一条轨迹的情况下泛化到新任务，无需进一步训练。Duan 等人 [13] 训练了一个单样本模仿器，可在二维堆叠环境中泛化到简单的任务变体。Finn 等人 [14] 在元学习的背景下使用了相同的设置。Dasari 和 Gupta[11]、Xu 等人 [42] 以及 Mandi 等人 [32] 训练了基于变换器的单样本模仿器，例如将专家轨迹编码为提示。Biza 等人 [2] 在可获得物体三维模型的情况下实现了抓取任务的单样本泛化。Xu 等人 [43] 通过超网络训练了适应层。然而，这些先前的工作都没有在单样本学习的背景下考虑 6 自由度操作任务。此外，最近的工作侧重于将现有技术（如变换器和适应层）应用于单样本模仿设置，但没有研究机器人操作的内在任务结构。相比之下，本文通过发现每个任务的不变区域，提出了一种用于 6 自由度操作的单样本模仿学习器。

操作中的不变性与可供性。将不变性融入深度学习模型已被证明能大幅提升数据效率和泛化能力 [5, 7, 8, 31, 39]。格拉夫等人 [18] 设计了图像增强方法，以学习用于操作任务的视点不变特征。视觉可供性是对动作可能性的区域表示 [1, 34]。例如，Where2Act 为每个像素学习推拉动作的概率图 [35]。本文提出不变区域的概念。不同于相机视点不变性，我们训练神经网络预测在给定任务中位置相对于机器人末端执行器保持不变的区域。与可供性不同，所提出的不变区域不用于表示动作概率，而是用于将动作从演示迁移到测试场景。




图 1：真实库卡机器人在观察单次演示且无需重新训练后执行拾取倾倒任务的示例。演示与测试场景中三维点云估计不变区域之间的对应关系以红线可视化。不变区域由离线训练的神经网络预测并匹配。

三、基于不变性匹配的单次模仿

A. 一个启发性示例

图 1 展示了我们实验中的一个示例：库卡机器人利用单次演示（拾取并倾倒一个不同位置的不同杯子）完成拾取杯子并倒入碗中的任务。IMOP 的核心在于估计并匹配给定任务的不变区域。通过找到演示与测试场景中不变区域的对应关系，演示动作可迁移至测试场景。在该示例中，不变区域为：（1）杯子表面与指尖接触的三维点集；（2）碗点云中捕捉其球形四面形状的三维点集。三维点云的不变区域通过离线学习获得，无需标注演示，且适用于多种物体和任务。

B. 单次操作学习问题的形式化

我们用 $\mathbf{T}$ 表示一组操作任务， $\mathbf{T} = \{\text{任务}_1, \text{任务}_2, \dots, \text{任务}_{N_{\text{tasks}}}\}$ 。每个操作任务 $\text{Task}_i \in \mathbf{T}$ 在一个由 5 元组 $\mathcal{M}_i = (\mathcal{S}, \mathcal{A}, \mathbf{P}, R_i, \mu_i)$ 表示的马尔可夫决策过程（MDP）中执行，其中 $\mathcal{S}$ 和 $\mathcal{A}$ 是状态空间和动作空间， $\mathbf{P} : \mathcal{S} \times \mathcal{A} \mapsto \mathcal{S}$ 是状态转移概率， $R_i : \mathcal{S} \mapsto \mathbb{R}$ 表示与任务 Task_i 相关的奖励函数， μ_i 是 Task_i 的初始状态分布，由一组基础任务（记为 $\mathbf{T}^{\text{base}}$ ）和一组新任务（记为 $\mathbf{T}^{\text{novel}}$ ）组成。因此， $\mathbf{T} = \mathbf{T}^{\text{base}} \cup \mathbf{T}^{\text{novel}}$ 。在训练期间，为基础任务提供了大量离线演示。每个任务的底层奖励函数是未知的，本工作中不使用。在测试期间，只提供一个成功的




图 2: 任务示例及不同试验中的对象级泛化。在基础任务上训练后, IMOP 在与基础任务显著不同的新任务上进行评估。每个学习到的任务在多个试验中进行评估, 每个试验具有不同的对象布局 and 方向。对于每个新任务, 仅提供一条记录轨迹作为演示。我们在第 IV-A 和 IV-B 节中总结了 IMOP 在基础任务和新任务上的性能。此外, 我们在第 IV-C 节中研究了 IMOP 泛化到演示之外的新对象的能力。

轨迹 $\tau_i = \{(s_i, a_i, s'_i)\}^{|\tau_i|}$ 被提供给机器人用于新任务 $\text{Task}_i \in \mathbf{T}^{\text{novel}}$, 其中 $|\tau_i|$ 表示转移次数, a_i 是状态 s_i 中的演示动作, s'_i 是结果的下一个状态。目标是学习一个一次性通用策略 $\pi(s, \tau_i)$, 这是一个多任务策略, 在给定所需新技能的单个演示轨迹 τ_i 的情况下, 在新状态 s 中返回动作 a 。 τ_i 在与 π 测试环境不同的环境中提供。状态 $s \in \mathcal{S}$ 是整个场景的原始 3D 点云, 包括机器人。状态 s 中的每个点用齐次坐标表示。动作 $a \in \mathcal{A}$ 是机器人末端执行器的期望 (即目标) 6D 位姿, 以及夹爪的期望状态。为了执行动作, 使用现成的运动规划器生成低级机器人运动。更准确地说, 我们将动作定义为 18 维向量 $a = (T, \lambda)$, 其中 $T \in \mathbb{R}^{4 \times 4}$ 表示目标末端执行器位姿作为齐次矩阵, 称为动作位姿, λ 表示两个二进制值, 指示夹爪是否打开以及是否允许碰撞。

C. 提出的方法

1) 不变区域匹配网络: 我们首先考虑以下问题。给定任务 $\text{Task}_k \in \mathbf{T}$ 、演示轨迹中的观测转移 (s_i, a_i, s'_i) , 以及新状态 s_j , 使得 $s_i \equiv s_j$, 如何将状态 s_i 中的动作位姿 T_i 转换为在新状态 s_j 中执行的新动作位姿 T_j ? 我们使用 $s_i \equiv s_j$ 来表示 s_i 和 s_j 共享相同的最优操作动作。例如, 任务“开门”的第一个操作动作是“到达门把手”。因此, 描述不同关门场景的状态都共享最优动作“到达门把手”。我们将 s_i 称为支持状态, 将新状态 s_j 称为

查询状态。为了回答这个问题, 我们在下文中定义了不变区域的概念。

定义 III.1. 状态 s_i 在任务 k 中的不变区域定义为 $\mathcal{I}(s_i | \text{Task}_k) = \{p \in s_i | \forall s_j \in \mathcal{S} \text{ s.t. } s_i \equiv s_j, \exists q \in s_j : \|T_i^{-1} p - T_j^{-1} q\| < \epsilon\}$, 其中 $(T_i, \lambda_i) = \pi^*(s_i | \text{Task}_k)$ 和 $(T_j, \lambda_j) = \pi^*(s_j | \text{Task}_k)$ 。

在该定义中, s_i 是场景点云, $\mathcal{I}(s_i | \text{Task}_k)$ 是 s_i 中所有三维点的集合, 这些点在帧 T_i 中的坐标在所有与 s_i 的最优动作相同的场景 s_j 中保持不变。帧 T_i 是在场景 s_i 中执行最优操作动作时末端执行器预接触位姿的坐标系。例如, 对于拿起杯子的任务, 最优动作是抓住杯子的把手, 无论杯子的位置、方向或样式如何。学习到的不变区域很可能是杯子的把手。为了简化符号, 我们省略任务 k , 将不变区域简称为 $\mathcal{I}(s_i)$, 同时隐含 $\mathcal{I}(s_i)$ 是给定任务 k 中 s_i 的不变区域。查询场景 s_j 的最优动作位姿 T_j 可以通过以下方式计算: 首先预测 s_i 和支持场景 s_j 的不变区域 $\mathcal{I}(s_i)$ 和 $\mathcal{I}(s_j)$, 然后根据 $\mathcal{I}(s_i)$ 和 $\mathcal{I}(s_j)$ 之间的匹配对 T_i 进行变换。我们提出的不变区域预测与匹配网络的整体框架如图 3 所示。我们首先为每个场景点云构建一个 KNN 图, 将每个点连接到同一场景内其 k 个最近邻点。接下来, 我们在每个支持场景 s_i 内应用图自注意力, 并在同一支持演示中连续帧对 s_i 和 s'_i 的 KNN 图之间应用交叉注意力。与在所有点上全局计算的传统注意力不同,

Invariant Region Matching Network

Correspondence-based Pose Regression




图 3: 所提出的不变区域匹配网络及基于对应关系的位姿回归概览。给定支撑状态 s_i 的观测转移, 我们从场景点云构建 K 近邻图, 并应用图自注意力 (在 s_i 和 s'_i 内部) 与交叉注意力 (在 s_i 和 s'_i 之间) 层。不变区域 $\mathcal{I}(s_i)$ 通过对支撑状态 s_i 进行逐点 Sigmoid 函数预测为激活点集合。接着, 我们在 $\mathcal{I}(s_i)$ 的 K 近邻图与查询状态 s_j 之间应用图交叉注意力层。对应矩阵 C 通过匹配逐点特征 $h_{\mathcal{I}(s_i)}$ 和 h_{s_j} 来预测。查询状态 s_j 的动作位姿 T_j 由支撑状态 s_i 的动作位姿 T_i 、对应矩阵 C 、 $P_{\mathcal{I}(s_i)}$ 以及 P_{s_j} ($\mathcal{I}(s_i)$ 和 s_j 中的点) 解析求解, 详见第 III-C2 节。

图注意力在每个给定点的局部邻域内操作。我们使用点变换器层 [40] 作为图注意力算子。不变区域 $\mathcal{I}(s_i)$ 通过对 s_i 进行逐点 Sigmoid 函数预测为激活点集合。然后, 我们在 $\mathcal{I}(s_i)$ 的 K 近邻图与查询状态 s_j 之间应用图交叉注意力层以提取逐点特征, 其中 D 表示特征维度的大小。最后, 我们在 $h_{\mathcal{I}(s_i)}$ 和 h_{s_j} 之间执行双重 $h_{\mathcal{I}(s_i)} \in \mathbb{R}^{|\mathcal{I}(s_i)| \times D}$ $h_{s_j} \in \mathbb{R}^{|s_j| \times D}$, Softmax 匹配 [27]

以获得对应矩阵 $C \in [0, 1]^{|\mathcal{I}(s_i)| \times |s_j|}$:

$$C = \text{softmax}(h_{\mathcal{I}(s_i)} \cdot h_{s_j}^\top) \cdot \text{softmax}(h_{s_j} \cdot h_{\mathcal{I}(s_i)}^\top)^\top$$

其中 Softmax 函数应用于每一行。对应矩阵 C 将不变区域 $\mathcal{I}(s_i)$ 中的每个点映射到查询状态 s_j 。 s_j 中的匹配点构成 $\mathcal{I}(s_j)$, 但我们只需要 C 来预测查询状态 s_j 的动作位姿 T_j , 如第 III-C2 节所述。我们在第 III-C4 节中详细说明不变区域匹配网络的训练。

2) 基于对应关系的位姿回归: 六自由度位姿回归的标准做法是通过神经网络获得动作位姿 T 。然而, 如第 IV-B 节所示, 这种方法对新任务的泛化能力不佳。相反, 本文提出通过使用标准最小二乘算法 [21] 求解方程 1 中的优化问题, 来解析计算查询状态 s_j 的动作位姿 T_j , 如下所示,

$$T_j = \arg \min_{T \in \text{SE}(3)} \|T T_i^{-1} P_{\mathcal{I}(s_i)} C - P_{s_j}\|, \quad (1)$$

其中 T_i 是支撑状态的演示动作姿态, s_i 、 $P_{\mathcal{I}(s_i)}$ 和 P_{s_j} 是 $\mathcal{I}(s_i)$ 中的点, s_j , C 是预测的对应矩阵。 C 可解释为一个分配矩阵, 将 $\mathcal{I}(s_i)$ 中的每个点映射到 s_j 中的一个点。根据定义 III.1, 最优动作姿态 T_j 是方程 1 的解, 当对应矩阵 C 中的点映射在应用变换 $T_j T_i^{-1}$ 后产生最小的总体成对距离时。因此, 姿态回归

问题可以通过学习用方程 1 匹配视觉元素来解决。我们使用 Lepard[27] 中的可微 Procrustes 算子来求解最小二乘问题。如第 IV-E 节所示, 我们基于对应的姿态回归显著提升了泛化性能。值得注意的是, 我们基于对应的姿态回归与点云配准

(PCR) 问题 [22] 有相似之处。然而, 存在三个主要区别。

首先, PCR 假设点云是从同一场景的不同相机视角捕获的, 而我们的方法对齐来自不同场景和物体的点云。其次, PCR 对齐两个点云的整体或大部分, 而我们的方法仅在给定任务的某些不变区域之间找到更稀疏的匹配。第三, PCR 寻找最佳匹配, 而我们的方法将匹配作为中间步骤, 以在新场景中找到机器人末端执行器的最优姿态。

3) 状态路由网络: 本文设计了状态路由网络 (如图 4 所示), 用于在给定查询场景 s_j 的情况下, 从单次演示 τ 中选择支持帧 s_i 。首先, 利用 **PTv2** 骨干网络 [10] 提取查询状态 s_j 以及 τ 中每个状态的场景级特征。接着, 遵循现有工作 [17] 的惯例, 将场景级特征与低维内部机器人状态 (包括关节位置和时间步) 拼接。然后, 对多个状态的特征应用交叉注意力。与不变区域匹配网络不同, 这里使用经典注意力层而非图注意力。最后, 选择对查询状态 s_j 注意力最强的状态作为支持状态 s_i 。上述三种技术共同构成了不变性匹配单次策略学习 (**IMOP**) 算法。对于每个新的查询状态 s_j , 支持状态 s_i 由状态路由网络从单次演示轨迹 τ 中确定。接着, 不变区域匹配网络预测 $\mathcal{I}(s_i)$ 与 s_j 之间的对应矩阵 C 。最后, 动作位姿 T_j 由方程 1 推导得出。




图 4: 所提出的状态路由网络概览。给定查询状态 s_j 和单次演示轨迹 τ , 提取 s_j 及 τ 中每个状态的场景级特征。场景特征与相应的低维机器人状态拼接, 并应用交叉注意力层。对查询状态 s_j 注意力最强的状态被选为支持状态 s_i 。

直接使用支持状态 s_i 的夹爪值 λ_i 作为 s_j 的 λ_j 值。通过调整演示轨迹 τ , IMOP 在新任务上实现了单次泛化。

4) 训练: 为训练 IMOP, 本文假设实例分割结果可用。本文使用 RLBench 提供的分割掩码 [24]。注意, IMOP 在推理阶段不需要任何分割。遵循 RVT[17] 和 PerAct[38] 的惯例, 本文使用 C2F-ARM[25] 的关键帧提取过程将每个状态表示为一个宏步骤。在每次训练迭代中, 若 $|\tau_i| = |\tau_j|$, 则采样两条轨迹 τ_i 和 τ_j 。状态路由网络使用焦点损失 [30] 进行训练, 以预测若 s_i 和 s_j 具有相同时间步, 则 $s_i \equiv s_j$ (i.e., s_i 和 s_j 共享相同的操作动作, 反之亦然。令 $\{c_{i,n}\}_{n=1}^N$ 表示 N 个实例分割段, 其中每个分割段 $c_{i,n} \in s_i$ 是 s_i 中一个对象实例的三维点集。为训练不变区域匹配网络, 本文按如下方式估计方程 2 中的真实值 $\mathcal{I}(s_i)$:

$$\mathcal{I}(s_i) = \arg \min_{c_{i,n}} \mathbf{E}_{p \in c_{i,n}} \left[\min_{\substack{q \in c_{j,m} \\ \text{cls}(c_{i,n}) = \text{cls}(c_{j,m})}} \|T_i^{-1}p - T_j^{-1}q\| \right], \quad (2)$$

其中 $\text{cls}(c_{i,n})$ 表示实例分割段的对象类别。真实值 $c_{i,n} \in \mathcal{I}(s_i)$ 是在动作姿态 T 坐标系中位移最小的实例分割段。

s_i 与 s_j 之间的真实对应关系是点映射集合 $\{(p, q) \in \mathcal{I}(s_i) \times \mathcal{I}(s_j) | q = \arg \min_{q \in \mathcal{I}(s_j)} \|T_i^{-1}p - T_j^{-1}q\|\}$ 使得逐点位 $T_i^{-1}p - T_j^{-1}q$ 在动作姿态坐标系中最小。

四、实验

本文在 RLBench[24] 的视觉机器人操作任务上评估 IMOP, RLBench 是多任务学习中使用的标准基准 [23]。本文首先在标准的 18 个 RLBench 任务上训练和评估算法, 然后在来自 9 个类别的 22 个新任务上衡量其单次泛化能力 [19]。此外, 本文通过单次仿真到现实迁移在真实机器人实验中评估方法。具体而言, 本文旨在回答以下问题: • IMOP 能否在基础任务上达到高成功率? • IMOP 能否在仅给定一次演示且无需微调的情况下泛化到新任务? • IMOP 能否泛化到形状变化较大的对象? • IMOP 能否从新任务的演示中估计出有意义的不变区域? • IMOP 能否在仿真中训练并迁移以解决真实机器人操作任务?

环境。按照惯例 [17], 我们从正面、左/右肩和腕部相机记录 128×128 张 RGB-D 图像。在训练期间, 每个基础任务使用 100 条记录轨迹。RLBench 包含各种任务类别, 如拾取放置、工具使用、高精度操作、拧紧、具有视觉遮挡的任务以及长期操作。根据 Hiveformer[19] 的任务分类, 我们选择了 22 个与基础任务具有不同物体设置和任务目标的新颖任务。对于每个新颖任务, 仅提供一条成功轨迹, 作为一次性演示。每个任务在 25 次独立试验上进行评估, 我们报告平均成功率。RLBench 在同一任务的不同试验中生成不同的物体布局 and 方向。对于基础任务, 我们使用与 [23] 中相同的测试场景。对于新颖任务, 我们为每个任务生成 25 个测试场景。图 2 展示了 IMOP 在 RLBench 环境中的任务和物体级泛化。更多细节见补充材料。

A. 基础任务上的性能比较

基线。为了评估 IMOP 在基础任务上的性能, 我们测试从离线演示中学习的策略, 而不使用一次性演示。具体来说, 我们考虑 C2F-ARM[25]、PerAct[38]、RVT[17] 和 Act3D[16]。C2F-ARM 和 PerAct 为每个任务学习单独的策略。与我们的 IMOP 类似, RVT 和 Act3D 学习单一的多任务策略。

结果。表 I 比较了 IMOP 和其他基线在基础任务上的成功率。C2F-ARM 和 PerAct 使用 3D 体素表示。RVT 将点云渲染为虚拟图像。与 IMOP 类似, Act3D 使用原始点云作为状态。总体而言, 当所有任务的最佳秩和成功率取平均时, IMOP 优于所有基线 (+4.5% 平均成功率)。IMOP 在 18 个任务中有 10 个任务上获得最高秩。值得注意的是, IMOP 在“放置杯子”任务上达到了 52.8% 的成功率, 而现有工作仅达到 2% 至 4%。此外, IMOP 不仅优于现有技术, 还能泛化到新颖任务, 而基线只能用于它们训练过的任务。

表一：RLBench 上的基础任务性能。本文报告了每个任务的成功率，并测量了所有任务的平均成功率和排名。IMOP 具有最佳的整体成功率和排名。IMOP 的成功率是 5 次运行的平均值。基线的成功率来自各自的论文。

Method	Avg. Success	Avg. Rank	Close Jar	Drag Stick	Insert Peg	Meat off Grill	Open Drawer	Place Cups	Place Wine	Push Buttons
C2F-ARM [25]	20.1	4.9	24	24	4	20	20	0	8	72
PerAct [38]	49.4	3.6	55.2	89.6	5.6	70.4	88	2.4	44.8	92.8
RVT [17]	62.9	2.3	52	99.2	11.2	88	71.2	4	91	100
Act3D [16]	65.1	2.2	92	92	27	94	93	3	80	99
IMOP (Ours)	69.6	1.9	39.2	98.4	12.0	92.0	100.0	52.8	96.0	96.0
	Put in Cupboard	Put in Drawer	Put in Safe	Screw Bulb	Slide Block	Sort Shape	Stack Blocks	Stack Cups	Sweep to Dustpan	Turn Tap
C2F-ARM [25]	0	4	12	8	16	8	0	0	0	68
PerAct [38]	28	51.2	84	17.6	74	16.8	26.4	2.4	52	88
RVT [17]	49.6	88.0	91.2	48	81.6	36	28.8	26.4	72	93.6
Act3D [16]	51	90	95	47	93	8	12	9	92	94
IMOP (Ours)	46.4	100.0	96.0	82.0	58.4	37.6	40.0	56.8	100.0	51.2




图 5：由本文的不变区域匹配网络在选定的基础任务和新任务上估计的不变区域 $\mathcal{I}(s_i)$ 的可视化。 s_i 上的不变区域用绿色掩码和黄色边界框突出显示。末端执行器位置用红点标记。 $\mathcal{I}(s_i)$ 通常覆盖机器人施加动作的目标对象，该动作用于从状态 s_i 过渡到下一状态 s'_i 。例如，“打开台灯”的不变区域覆盖了“灯开关”区域。“拉直绳子”的不变区域覆盖了绳子的一侧和绳子目标。值得注意的是，IMOP 仅以点云作为输入，无法访问分割掩码。

B. 对新任务的泛化

基线。为了评估 IMOP 的一次性学习能力，并且由于文献中没有在 RLBench 上评估过的现有一次性学习方法，本文将最先进的技术 RVT 扩展为两个基线，称为 RVT+FT 和 RVT+HDT，可用于一次性学习。具体来说，由于微调是将模型迁移到新领域的最常见策略 [44]，本文使用新任务的演示对在基础任务上预训练的 RVT 模型进行微调，并将该基线表示为 RVT+FT。HDT[43] 是最近的一项工作，通过为新任务训练额外的适应层同时冻结原始参数来实现一次性策略泛化。本文在 RVT 中实现了 HDT 适应层，并将该基线模型表示为 RVT+HDT。RVT 和 Act3D 都是学习多任务机器人控制策略的最新方法，并且具有相似的性能，如表一所示。本文选择 RVT 而不是 Act3D，因为后者的预训练模型尚不可用。对于

RVT+FT 和 RVT+HDT，本文使用新任务的一次性演示训练相应的网络参数直到收敛，并采用来自 RVT 和 PerAct 的采样和 3D 扰动增强策略。

结果。表二比较了 IMOP、RVT+FT 和 RVT+HDT 在新任务上的成功率。IMOP 在所有基线中表现最佳，平均成功率和秩均最优（较 RVT+FT 提升 +11.5%）。在 22 个任务中，IMOP 在 15 个任务上取得最佳秩。尽管采用简单的微调策略，RVT+FT 在新任务上的表现优于 RVT+HDT。然而，我们观察到 RVT+FT 中存在灾难性遗忘现象 [26]，其基任务平均成功率在微调新任务后从 62.9% 骤降至 4.6%。RVT-HDT 通过冻结原始参数来保持基任务性能，但代价是适配层中参数数量增加。参数规模比较见表三。

与基线相比，IMOP 能够泛化到新任务

表二：RLBench 上的新任务性能。我们报告每个任务的成功率，并衡量所有任务的平均成功率和秩。IMOP 具有最佳的整体成功率和秩。RVT+FT 和 RVT+HDT 都需要微调，而 IMOP 不需要。直接使用 RVT 而不进行微调的平均成功率为 0，我们未将其列入表中。所有成功率均为 5 次运行的平均值。

Method	Avg. Success	Avg. Rank	Ball in Hoop	Rubbish in Bin	Scoop Spatula	Place Hanger	Hit Ball	Block Pyramid	Slide Place	Phone on Base	Open Box	Close Lid
RVT+FT	29.8	2	42.4	50	7.2	4	1.6	0	0	20.4	28	100
RVT+HDT	26.9	2.4	87.6	40.4	0	0	0	0	0	0	24.8	91.2
IMOP (Ours)	41.3	1.5	80.0	94.0	52.0	24.4	32.0	5.2	6.8	22.8	8.0	71.2
	Lid off Pan	Lamp On	Beat Buzz	Remove Cups	Play Jenga	Knife on Board	Straighten Rope	Change Clock	Open Bottle	Open Door	Money out Safe	Close Microwave
RVT+FT	78.8	65.2	19.2	4	40.8	14	0	10.4	34.4	68	22.4	44
RVT+HDT	80.4	72	16.4	0	27.6	8	0	36	23.2	12	12	59.6
IMOP (Ours)	100.0	12.0	20.0	36.0	100.0	20.0	16.8	24.0	81.6	41.2	42.8	21.6




图 6：IMOP 通过一次性仿真到现实迁移的真实机器人操作示例。演示场景与测试场景之间的对应关系以红线显示。不变区域与下一个待交互物体紧密重叠。我们观察到，IMOP 的一次性泛化能力（通过仿真数据训练）使得仅使用单个真实世界演示即可实现仿真到现实迁移，无需任何重新训练。

表三：IMOP 与一次性基线之间的网络参数规模比较。

Method	Success Rate (%)		Params Size
	Base	Novel	
RVT+FT	4.7	29.8	104M
RVT+HDT	62.9	26.9	131M
Ours	69.6	41.3	80.8M

通过匹配一次性演示与测试过程中遇到的状态之间的不变区域，无需进一步训练。因此，IMOP 不会遭受灾难性遗忘或参数规模增加的问题。值得注意的是，RVT+FT 和 RVT+HDT 在某些任务上完全失败，例如“积木金字塔”、“滑放”和“拉直绳索”，而 IMOP 在这些任务上仍能提供非凡的性能。“积木金字塔”和“滑放”均属于长时程任务，分别需要超过 30 和 10 个宏步骤才能完成 [19]。“拉直绳索”任务需要对绳索进行操作，这与基任务中的物体截然不同。这进一步表明了局限性

现有的一次性策略泛化策略以及我们提出的基于不变性匹配策略的优势。图 5 可视化了选定的基础任务和新任务上的不变区域。可以看出，不变区域通常覆盖了机器人动作的目标物体。补充材料中提供了更多的可视化结果。

表现不佳任务的分析。尽管 IMOP 整体上具有优越性，但在特定任务上的表现仍值得讨论。如表 II 所示，与 RVT+FT 和 RVT+HDT 相比，IMOP 在“打开盒子”、“关闭微波炉”和“关闭盖子”任务上的成功率较低。这些任务涉及操作平面表面，如盖子和盒盖，如图 5 中“打开盒子”的不变区域所示。挑战源于在缺乏丰富几何特征的平面上识别不变区域或对应关系时可能存在的模糊性。IMOP 在“开灯”任务上的表现也逊于基线方法，如图 5 前两列所示。尽管该任务的不变区域估计良好，但开关面积较小，因此与整个场景相比对应关系稀疏，导致方程 1 中的最小二乘问题解不稳定。




图 7: 抓取动作中不同物体之间对应关系的可视化。“Spam” → “Crackers”表示在测试时使用“Spam”作为演示来对应“Crackers”。尽管形状变化很大，IMOP 仍能估计出有效传递动作的对应关系，如图 8 中的成功率所示。

方程 1 中的问题。IMOP 在长期任务（即“积木金字塔”和“滑动放置”）上的成功率优于基线方法，但仍有很大的改进空间。IMOP 将测试场景中的新状态路由到演示的机制简单，但缺乏失败恢复能力，因为演示仅包含成功轨迹。失败案例的更详细分析见补充材料。

C. 对大幅形状变化的泛化

实验设置。先前实验评估了 IMOP 在新任务上的单次泛化能力，每个任务仅提供一个演示轨迹。尽管基础任务与新任务在物体形状和类别上存在较大差异，但每个新任务内部的差异有限。例如，新任务“将刀放在砧板上”包含刀、刀架和砧板等物体。这些物体在训练期间均未出现，每次试验中随机放置，有时伴有颜色变化，但物体类别和形状在各次试验中保持不变，如图 2 所示。我们关注 IMOP 能否泛化到形状差异较大的物体。为此，我们在与演示中不同的物体上评估 IMOP，这些物体自然具有不同的形状。具体而言，我们考虑一个抓取-放置场景，目标是将杂货抓起并放入橱柜。演示针对某一特定物体进行，但测试时要求抓取并放置另一个不同的物体。为简化研究，我们假设测试时可获得所需物体的分割掩码。因此，不同物体之间的对应关系可通过屏蔽其他区域获得。为避免记忆化，我们从训练数据中移除了相应的状态对。

结果。图 8 展示了抓取-放置任务的成功率




图 8: 使用形状差异较大的不同物体作为演示时，抓取-放置任务的成功率。例如，右上角的条目“浆果果冻盒、金枪鱼罐头”表示以“浆果果冻盒”为演示时，抓取并放置“金枪鱼罐头”的成功率为 30%。

在不同物体上进行演示。例如，条目“芥末，咖啡”表示以芥末瓶为演示时，拾取并放置咖啡罐的成功率。共有 9 个物体，所有成功率均为 10 次试验的平均值。可以看出，当使用不同物体作为演示时，IMOP 表现出具有竞争力的性能，除了芥末瓶的某些情况，其形状与其他物体差异显著。使用浆果果冻和巧克力果冻作为演示，在测试中对许多物体（如汤、午餐肉、糖和金枪鱼）取得了相同甚至更好的结果。这两个果冻盒是该设置中最小的物体。图 7 可视化了不同物体不变区域之间的对应关系。对应点以绿色圆点显示，与基于关键点的方法 [15, 33] 相似。kPAM[33] 和 kPAM-SC[15] 利用物体关键点在基于优化的规划中组合目标和约束，用于操作，并在拾取放置场景中展示了对大形状变化的泛化能力。然而，这些方法需要为每个物体类别手动设计关键点。我们的方法 IMOP 不需要任何关键点规格或其他形式的标注。可视化连接仅通过对对应矩阵进行阈值处理获得。

D. 通过一次性仿真到现实迁移实现真实机器人操作

设置。本文利用基础任务的仿真演示评估 IMOP 的一次性仿真到现实性能，并以真实世界记录的轨迹作为新任务的一次性演示。本文采用五项新任务：将玩具放入碗中、堆叠积木、将物品放入架子、打开瓶子和倒杯子。与现有工作每项任务需要超过 10 次演示进行重新训练 [17] 不同，本文的一次性方法

IMOP 的泛化能力使得仅使用一次演示且无需重新训练即可实现仿真到现实迁移。我们将模型部署在 Kuka LBR iiwa 机器人上。我们使用来自两个 RealSense D415 相机的 RGB-D 观测。我们使用 MoveIt [9] 来规划将机械臂移动到 IMOP 预测的夹爪姿势的路径。

表四：IMOP 在解决现实世界操作任务中的一次性仿真到现实迁移性能。

Task	Success	
	One-shot RVT	IMOP (Ours)
Put toys in bowl	3/10	8/10
Stack blocks	1/10	4/10
Put item in shelf	2/10	5/10
Open bottle	2/10	4/10
Pour cup	2/10	5/10

结果。表四展示了 IMOP 在五个真实世界任务上的成功率。每个任务的成功率是独立进行 10 次不同物体布局实验的平均值。图 6 可视化了演示场景与测试场景之间的对应关系。对于单次演示的 RVT，我们使用每个任务的单个演示对预训练的 RVT 模型进行微调。仿真到现实的差距被普遍认为是部署使用仿真数据训练的控制策略时的一个挑战性问题 [49]。在我们的研究中，我们发现区域匹配对这一领域偏移具有鲁棒性。然而，不变区域预测的 Sigmoid 函数输出值远小于仿真数据中的值。我们通过使用一个更小的阈值对 Sigmoid 函数输出进行阈值化来规避这一问题，0.1。这表明 IMOP 具有单次仿真到现实的能力，但在不变区域估计方面仍受到仿真到现实差距的影响。这一问题可以通过使用真实机器人演示进行微调或使用更多摄像头来提高点云质量来潜在解决。

E. 消融研究

我们在表五中研究了 IMOP 的组件效应。对于状态路由网络，我们发现低维机器人状态（即关节位置和时间步）对路由准确率和成功率有贡献。这一做法也被许多现有工作采用 [38, 17, 16]。对于不变区域匹配网络，我们研究了注意力类型、匹配策略以及点云 KNN 图的度数（K）。表五显示，度数更大的 KNN 图提供了更强的性能。然而，使用传统注意力代替图注意力（将所有点全局连接）会显著降低性能。注意，我们仅在区域匹配中应用传统注意力，而在不变区域估计中仍保留图注意力。这表明局部注意力和通过 KNN 图传播信息是 3D 区域匹配的有效归纳偏置。与图 3 中先估计 $\mathcal{I}(s_i)$ 再匹配 $\mathcal{I}(s_i)$ 和 s_j 的框架相比，我们研究了直接匹配 s_i 和 s_j 并预测对应矩阵的策略。然而，模型未能预测

表五：IMOP 组件的消融研究。

Configurations		Success Rate (%)	
		Base	Novel
<i>State Routing Network</i>			
Using Low-dim robot states	Y	69.6	41.3
	N	63.2	33.0
<i>Invariant Region Matching Network</i>			
Attention Type	Graph Attention	69.6	41.3
	Traditional Attention	52.8	16.4
Matching Strategy	Estimate $\mathcal{I}(s_i)$, then match $\mathcal{I}(s_i)$ and s_j	69.6	41.3
	Directly match s_i and s_j	6.7	-
KNN-Graph (K)	4	58.7	32.4
	8	64.5	38.6
	16	69.6	41.3
<i>Regression Method</i>			
Correspondence-based Regression (Equation 1)		69.6	41.3
Regression from matched points		58.2	29.4
Conventional pose regression		65.1	-

对所有任务执行操作。这表明估计不变区域的重要性。我们将基于对应关系的姿态回归与两种替代方案进行了比较。“从匹配点回归”训练额外层，从对应矩阵 C 中的匹配点预测姿态，而不是用方程 1 推导动作姿态 T_j 。“传统姿态回归”采用 Act3D[16] 的标准三维回归头，同时完全舍弃区域匹配机制。表 V 显示，传统回归在基础任务上性能相当，但无法泛化到新任务，而用方程 1 推导动作姿态比用额外回归头从匹配点预测姿态表现更好。

五、讨论与结论

我们已经证明，通过学习估计并匹配演示和测试场景中的关键不变区域，可以实现一次性新任务泛化。通过找到不变区域之间的对应关系，可以传递目标末端执行器姿态。然而，仍有一些开放问题值得讨论。IMOP 在 RLBench 仿真环境中训练，该环境提供分割掩码和经过验证的关键帧提取流程。对于真实世界数据，可能需要更复杂的关键帧提取方法以及使用开放集目标检测器 [46, 47, 50]。通过匹配关键视觉元素来传递动作的提出思想具有通用性，但目前不变区域的定义仍与刚体变换紧密相关。这表明有潜力基于更一般的运动描述符（如扭曲或光流 [27]）扩展不变区域的表述，以提高对非刚体对象和无法由姿态调节的复杂动态任务的操控准确率。

随着可扩展到互联网规模数据的神经架构 [6] 的出现, 从广泛可用的无标签二维视频中学习不变区域的可能性尚未被充分探索。除了仅利用单个演示之外, 还可以维护一个演示池, 并从最相关的状态传递动作, 以提高操控性能, 并在场景变化大或需要故障恢复的情况下减少误差累积。

参考文献

- [1] Paola Ardón, Èric Pairet, Katrin S Lohan, Subramanian Ramamoorthy, and Ronald Petrick. Affordances in robotic tasks—a survey. *arXiv preprint arXiv:2004.07400*, 2020.
- [2] Ondrej Biza, Skye Thompson, Kishore Reddy Pagidi, Abhinav Kumar, Elise van der Pol, Robin Walters, Thomas Kipf, Jan-Willem van de Meent, Lawson LS Wong, and Robert Platt. One-shot imitation learning via interaction warping. *arXiv preprint arXiv:2306.12392*, 2023.
- [3] Abdeslam Boularias, Jens Kober, and Jan Peters. Relative entropy inverse reinforcement learning. In *Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics, AISTATS*, pages 182–189, 2011.
- [4] Abdeslam Boularias, Oliver Kroemer, and Jan Peters. Learning robot grasping from 3-d images with markov random fields. In *2011 IEEE/RSJ International Conference on Intelligent Robots and Systems, IROS*, pages 1548–1553, 2011.
- [5] Johannes Brandstetter, Rob Hesselink, Elise van der Pol, Erik J Bekkers, and Max Welling. Geometric and physical quantities improve e (3) equivariant message passing. *arXiv preprint arXiv:2110.02905*, 2021.
- [6] Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, et al. Language models are few-shot learners. *Advances in neural information processing systems*, 33: 1877–1901, 2020.
- [7] Taco Cohen and Max Welling. Group equivariant convolutional networks. In *International conference on machine learning*, pages 2990–2999. PMLR, 2016.
- [8] Taco S Cohen, Mario Geiger, Jonas Köhler, and Max Welling. Spherical cnns. *arXiv preprint arXiv:1801.10130*, 2018.
- [9] David Coleman, Ioan Sucan, Sachin Chitta, and Nikolaus Correll. Reducing the barrier to entry of complex robotic software: a moveit! case study. *arXiv preprint arXiv:1404.3785*, 2014.
- [10] Pointcept Contributors. Pointcept: A codebase for point cloud perception research. <https://github.com/Pointcept/Pointcept>, 2023.
- [11] Sudeep Dasari and Abhinav Gupta. Transformers for one-shot visual imitation. In *Conference on Robot Learning*, pages 2071–2084. PMLR, 2021.
- [12] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, et al. An image is worth 16x16 words: Transformers for image recognition at scale. *arXiv preprint arXiv:2010.11929*, 2020.
- [13] Yan Duan, Marcin Andrychowicz, Bradly Stadie, OpenAI Jonathan Ho, Jonas Schneider, Ilya Sutskever, Pieter Abbeel, and Wojciech Zaremba. One-shot imitation learning. *Advances in neural information processing systems*, 30, 2017.
- [14] Chelsea Finn, Tianhe Yu, Tianhao Zhang, Pieter Abbeel, and Sergey Levine. One-shot visual imitation learning via meta-learning. In *Conference on robot learning*, pages 357–368. PMLR, 2017.
- [15] Wei Gao and Russ Tedrake. kpm-sc: Generalizable manipulation planning using keypoint affordance and shape completion. In *2021 IEEE International Conference on Robotics and Automation (ICRA)*, pages 6527–6533. IEEE, 2021.
- [16] Theophile Gervet, Zhou Xian, Nikolaos Gkanatsios, and Katerina Fragkiadaki. Act3d: 3d feature field transformers for multi-task robotic manipulation. In *Conference on Robot Learning*, pages 3949–3965. PMLR, 2023.
- [17] Ankit Goyal, Jie Xu, Yijie Guo, Valts Blukis, Yu-Wei Chao, and Dieter Fox. Rvt: Robotic view transformer for 3d object manipulation. *arXiv preprint arXiv:2306.14896*, 2023.
- [18] Christian Graf, David B Adrian, Joshua Weil, Miroslav Gabriel, Philipp Schillinger, Markus Spies, Heiko Neumann, and Andras Gabor Kupcsik. Learning dense visual descriptors using image augmentations for robot manipulation tasks. In *Conference on Robot Learning*, pages 871–880. PMLR, 2023.
- [19] Pierre-Louis Guhur, Shizhe Chen, Ricardo Garcia Pinel, Makarand Tapaswi, Ivan Laptev, and Cordelia Schmid. Instruction-driven history-aware policies for robotic manipulations. In *Conference on Robot Learning*, pages 175–187. PMLR, 2023.
- [20] Kai Han, Yunhe Wang, Hanting Chen, Xinghao Chen, Jianyuan Guo, Zhenhua Liu, Yehui Tang, An Xiao, Chunjing Xu, Yixing Xu, et al. A survey on vision transformer. *IEEE transactions on pattern analysis and machine intelligence*, 45(1):87–110, 2022.
- [21] TS Huang, SD Blostein, and EA Margerum. Least-squares estimation of motion parameters from 3-d point correspondences. In *Proc. IEEE Conf. Computer Vision and Pattern Recognition*, volume 10, pages 112–115. IEEE Computer Soc. Press Washington DC, 1986.
- [22] Xiaoshui Huang, Guofeng Mei, Jian Zhang, and Rana Abbas. A comprehensive survey on point cloud registration. *arXiv preprint arXiv:2103.02690*, 2021.
- [23] Stephen James and Andrew J Davison. Q-attention: Enabling efficient learning for vision-based robotic manipulation. *IEEE Robotics and Automation Letters*, 7(2): 1612–1619, 2022.
- [24] Stephen James, Zicong Ma, David Rovick Arrojo, and An-

- drew J Davison. Rlbench: The robot learning benchmark & learning environment. *IEEE Robotics and Automation Letters*, 5(2):3019–3026, 2020.
- [25] Stephen James, Kentaro Wada, Tristan Laidlow, and Andrew J Davison. Coarse-to-fine q-attention: Efficient learning for visual robotic manipulation via discretisation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 13739–13748, 2022.
- [26] James Kirkpatrick, Razvan Pascanu, Neil Rabinowitz, Joel Veness, Guillaume Desjardins, Andrei A Rusu, Kieran Milan, John Quan, Tiago Ramalho, Agnieszka Grabska-Barwinska, et al. Overcoming catastrophic forgetting in neural networks. *Proceedings of the national academy of sciences*, 114(13):3521–3526, 2017.
- [27] Yang Li and Tatsuya Harada. Leopard: Learning partial point cloud matching in rigid and deformable scenes. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 5554–5564, 2022.
- [28] Junchi Liang and Abdeslam Boularias. Learning category-level manipulation tasks from point clouds with dynamic graph cnns. In *Proceedings of the 2023 International Conference on Robotics and Automation (ICRA)*, 2023.
- [29] Junchi Liang, Bowen Wen, Kostas E. Bekris, and Abdeslam Boularias. Learning sensorimotor primitives of sequential manipulation tasks from visual demonstrations. In *Proceedings of the 2022 International Conference on Robotics and Automation (ICRA)*, 2022.
- [30] Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, and Piotr Dollár. Focal loss for dense object detection. In *Proceedings of the IEEE international conference on computer vision*, pages 2980–2988, 2017.
- [31] Clare Lyle, Mark van der Wilk, Marta Kwiatkowska, Yarin Gal, and Benjamin Bloem-Reddy. On the benefits of invariance in neural networks. *arXiv preprint arXiv:2005.00178*, 2020.
- [32] Zhao Mandi, Fangchen Liu, Kimin Lee, and Pieter Abbeel. Towards more generalizable one-shot visual imitation learning. In *2022 International Conference on Robotics and Automation (ICRA)*, pages 2434–2444. IEEE, 2022.
- [33] Lucas Manuelli, Wei Gao, Peter Florence, and Russ Tedrake. kpm: Keypoint affordances for category-level robotic manipulation. In *The International Symposium of Robotics Research*, pages 132–157. Springer, 2019.
- [34] Russell Mendonca, Shikhar Bahl, and Deepak Pathak. Structured world models from human videos. *arXiv preprint arXiv:2308.10901*, 2023.
- [35] Kaichun Mo, Leonidas J Guibas, Mustafa Mukadam, Abhinav Gupta, and Shubham Tulsiani. Where2act: From pixels to actions for articulated 3d objects. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 6813–6823, 2021.
- [36] Katharina Muelling, Abdeslam Boularias, Betty Mohler, Bernhard Schölkopf, and Jan Peters. Learning strategies in table tennis using inverse reinforcement learning. *Biological Cybernetics*, pages 1–17, 2014. ISSN 0340-1200. doi: 10.1007/s00422-014-0599-1.
- [37] Mohit Shridhar, Lucas Manuelli, and Dieter Fox. Cliport: What and where pathways for robotic manipulation. In *Conference on Robot Learning*, pages 894–906. PMLR, 2022.
- [38] Mohit Shridhar, Lucas Manuelli, and Dieter Fox. Perceiver-actor: A multi-task transformer for robotic manipulation. In *Conference on Robot Learning*, pages 785–799. PMLR, 2023.
- [39] Elise Van der Pol, Daniel Worrall, Herke van Hoof, Frans Oliehoek, and Max Welling. Mdp homomorphic networks: Group symmetries in reinforcement learning. *Advances in Neural Information Processing Systems*, 33:4199–4210, 2020.
- [40] Xiaoyang Wu, Yixing Lao, Li Jiang, Xihui Liu, and Hengshuang Zhao. Point transformer v2: Grouped vector attention and partition-based pooling. *Advances in Neural Information Processing Systems*, 35:33330–33342, 2022.
- [41] Zhou Xian, Nikolaos Gkanatsios, Theophile Gervet, Tsung-Wei Ke, and Katerina Fragkiadaki. Chaineddiffuser: Unifying trajectory diffusion and keypose prediction for robotic manipulation. In *Conference on Robot Learning*, pages 2323–2339. PMLR, 2023.
- [42] Mengdi Xu, Yikang Shen, Shun Zhang, Yuchen Lu, Ding Zhao, Joshua Tenenbaum, and Chuang Gan. Prompting decision transformer for few-shot policy generalization. In *international conference on machine learning*, pages 24631–24645. PMLR, 2022.
- [43] Mengdi Xu, Yuchen Lu, Yikang Shen, Shun Zhang, Ding Zhao, and Chuang Gan. Hyper-decision transformer for efficient online policy adaptation. *arXiv preprint arXiv:2304.08487*, 2023.
- [44] Fuchao Yu, Xianchao Xiu, and Yunhui Li. A survey on deep transfer learning and beyond. *Mathematics*, 10(19): 3619, 2022.
- [45] Andy Zeng, Pete Florence, Jonathan Tompson, Stefan Welker, Jonathan Chien, Maria Attarian, Travis Armstrong, Ivan Krasin, Dan Duong, Vikas Sindhwani, et al. Transporter networks: Rearranging the visual world for robotic manipulation. In *Conference on Robot Learning*, pages 726–747. PMLR, 2021.
- [46] Xinyu Zhang and Abdeslam Boularias. Optical flow boosts unsupervised localization and segmentation. In *2023 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 7635–7642. IEEE, 2023.
- [47] Xinyu Zhang, Yuting Wang, and Abdeslam Boularias. Detect every thing with few examples, 2023.
- [48] Hengshuang Zhao, Li Jiang, Jiaya Jia, Philip HS Torr, and Vladlen Koltun. Point transformer. In *Proceedings of the IEEE/CVF international conference on computer vision*, pages 16259–16268, 2021.
- [49] Wenshuai Zhao, Jorge Peña Queraltá, and Tomi Westerlund. Sim-to-real transfer in deep reinforcement learning for robotics: a survey. In *2020 IEEE symposium series on computational intelligence (SSCI)*, pages 737–744. IEEE,

2020.

- [50] Yiwu Zhong, Jianwei Yang, Pengchuan Zhang, Chunyuan Li, Noel Codella, Liunian Harold Li, Luowei Zhou, Xiyang Dai, Lu Yuan, Yin Li, et al. Regionclip: Region-based language-image pretraining. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 16793–16803, 2022.