

即时策略：基于图扩散的上下文模仿学习

Vitalis Vosylius and Edward Johns

The Robot Learning Lab at Imperial College London

vitalis.vosylius19@imperial.ac.uk

摘要

Following the impressive capabilities of in-context learning with large transformers, In-Context Imitation Learning (ICIL) is a promising opportunity for robotics. We introduce *Instant Policy*, which learns new tasks instantly (without further training) from just one or two demonstrations, achieving ICIL through two key components. First, we introduce inductive biases through a graph representation and model ICIL as a graph generation problem with a learned diffusion process, enabling structured reasoning over demonstrations, observations, and actions. Second, we show that such a model can be trained using pseudo-demonstrations——仿真中生成的任意轨迹——作为几乎无限的训练数据池。仿真与真实实验表明，即时策略能够快速学习各种日常机器人任务。我们还展示了它如何作为跨具身和零样本迁移到语言定义任务的基础。

代码和视频可在 <https://www.robot-learning.uk/instant-policy> 获取。




图 1：即时策略在测试时提供演示后立即获得技能。我们将上下文模仿学习建模为基于图的扩散过程，并使用伪演示进行训练。

1 引言

通过模仿学习 (Imitation Learning, IL) 获得的机器人策略最近展现出令人印象深刻的能力，但当今的行为克隆 (Behavioural Cloning, BC) 方法仍需要每个任务数百或数千次演示 (Zhao 等人)。与此同时，语言和视觉领域已经表明，当大型变换器 (Transformer) 在足够大且多样化的数据集上训练时，会出现上下文学习 (In-Context Learning, ICL) 现象 (Brown, 2020)。在这种情况下，训练好的模型可以利用新任务的测试时示例 (上下文)，并立即泛化到该任务的新实例，而无需更新模型权重。这为机器人领域的上下文模仿学习 (In-Context Imitation Learning, ICIL) 提供了一个有前景的机遇。为此，我们提出了即时策略 (Instant Policy)，它使新任务能够被即时学习：只需提供一两个演示，该任务的新配置就能立即执行，无需任何进一步训练。这比需要大量演示和每个新任务数小时网络训练的 BC 方法更加省时和便捷。

语言和视觉中的上下文学习受益于海量且易于获取的数据集，而这些数据集在机器人领域并不存在。因此，我们面临两个主要挑战。1) 鉴于可用数据有限，我们需要在观察和动作表示中引入适当的归纳偏置 (Inductive Bias)，以实现高效学习

三维空间；**2**) 鉴于人工采集机器人数据效率低下且成本高昂，我们需要一种能够以可扩展方式便捷收集训练数据的方法。本文针对这两方面提出了解决方案。

针对第一个挑战，我们提出了一种新颖的基于图的表示方法，将演示、当前点云观测和机器人动作整合到统一的图空间中。随后，我们将上下文模仿学习 (ICIL) 建模为基于扩散的图生成问题，从而有效解读演示与观测信息，以预测机器人动作。针对第二个挑战，我们观察到在传统行为克隆 (BC) 中，模型权重直接编码特定任务集的策略；而在上下文模仿学习中，模型权重应编码一种更通用、与任务无关的能力，即解读并依据给定上下文采取行动。基于此，我们发现可以利用伪演示来训练模型——即程序化生成的机器人轨迹集合，其中每个任务的演示集在语义上保持一致。该方法使我们能够通过扩展仿真数据来生成几乎无限的训练数据。

我们在仿真和真实世界任务中的实验表明，即时策略 (Instant Policy) 能够学习多种日常任务，并在相同数据训练下取得比最先进基线更高的任务成功率。作为一种涌现能力，我们还观察到模型对测试时演示中未见过的物体几何形状具有泛化能力。重要的是，我们发现随着生成并用于同时训练的数据量增加，性能持续提升，这为利用丰富的仿真数据提供了可扩展的机会。在下游应用的进一步实验中，即时策略还实现了从人手演示到机器人策略的跨具身迁移，以及无需大型语言标注数据集即可零样本迁移到语言定义的任务。

本文贡献如下：**1**) 我们将上下文模仿学习建模为基于扩散的图生成问题；**2**) 我们证明该模型可以利用程序化生成的伪演示进行训练；**3**) 我们在仿真和真实世界中针对多种日常任务进行了评估，展示了强大的性能、令人鼓舞的扩展趋势以及有前景的下游应用。

2 相关工作

上下文学习 (In Context Learning, ICL)。上下文学习 (In-Context Learning, ICL) 是机器学习中一种新兴的范式，它允许模型利用少量示例适应新任务，无需显式更新权重或重新训练。ICL 最初在自然语言处理领域因 GPT-3 等模型而流行 (Brown, 2020)，现已应用于使机器人能够利用基础模型快速适应新任务 (Di Palo & Johns, 2024)，寻找一致的对象对齐 (Vosylius & Johns, 2023a)，识别状态空间中的不变区域 (Zhang & Boularias, 2024)，以及直接训练旨在实现任务泛化 (Duan et al., 2017; Fu et al., 2024) 或跨具身迁移 (Jang et al., 2022; Jain et al., 2024; Vogt et al., 2017) 的策略。尽管取得了这些进展，在实现训练期间未见任务和新颖物体几何形状的泛化方面仍存在挑战。即时策略 (Instant Policy) 通过利用模拟伪演示生成丰富多样的数据来应对这一挑战，同时其结构化图表示确保这些数据得到高效利用。

扩散模型。扩散模型 (Ho et al., 2020) 因其能够通过学习的去噪过程迭代细化随机采样的噪声，最终从底层分布生成高质量样本，而在各个领域引起了广泛关注。扩散模型最初在图像生成领域流行 (Ramesh et al., 2021)，最近已应用于机器人技术。它们被用于创建图像增强 (Yu et al., 2023; Mandlekar et al., 2023) 以帮助机器人适应多样化环境，生成“想象”的目标 (Kapelyukh et al., 2023) 或子目标 (Black et al., 2023) 以引导机器人策略，以及学习精确的控制策略 (Chi et al., 2023; Vosylius et al., 2024)。相比之下，本文提出了一种新颖的扩散模型用于图生成的方法，能够对复杂分布进行结构化学习。

图神经网络 (Graph Neural Networks, GNNs)。图神经网络 (Graph Neural Networks, GNNs) 允许使用消息传递或基于注意力的策略在结构化数据上进行学习。这些能力已被应用于广泛的领域，包括分子化学 (Jha et al., 2022)、社交网络分析 (Hu et al., 2021) 和推荐系统 (Shi et al., 2018)。在机器人学中，图神经网络已被用于获取强化学习 (Reinforcement Learning, RL) 策略 (Wang et al., 2018; Sferrazza et al., 2024)、管理物体重排任务 (Kapelyukh & Johns, 2022)，以及学习用于技能迁移的可供性模型 (Vosylius & Johns, 2023b)。在我们的工作中，我们基于这些基础，研究用于上下文模仿学习的结构化图表示，从而能够学习演示、观察和动作之间的关系。

3 即时策略

3.1 概述与问题表述

概述。我们解决上下文模仿学习 (In-Context Imitation Learning) 问题，其目标是机器人在提供演示后立即完成新任务。在测试时，提供一个或几个新任务的演示来定义上下文，我们训练好的即时策略网络将其与当前点云观测一起解释，并推断适合闭环反应控制的机器人动作（见图 1）。这实现了即时策略获取，无需大量真实世界数据收集或训练。我们通过结构化图表示（第 3.2 节）、学习到的扩散过程（第 3.3 节）以及丰富的多样化模拟伪演示来源（第 3.4 节）来实现这一目标。

问题表述。我们将机器人动作 $\mathbf{a}$ 表示为末端执行器位移 $\mathbf{T}_{EA} \in \mathbb{SE}(3)$ （经过时间缩放后对应于速度），以及夹爪的二进制开合命令 $a_g \in \{0, 1\}$ 。这些动作将机器人的夹爪从坐标系 E 移动到新坐标系 A ，并相应地改变其二进制状态。我们的观测 o_t 在时间步 t 由分割的点云 P^t 、世界坐标系中当前末端执行器位姿 $\mathbf{W}, \mathbf{T}_{WE}^t \in \mathbb{SE}(3)$ ，以及二值夹爪状态 $s_g^t \in \{0, 1\}$ 组成。形式上，我们的目标是找到一个概率分布 $p(\mathbf{a}^{t:t+T} | o_t, \{(o_{ij}, \mathbf{a}_{ij})_{i=1}^L\}_{j=1}^N)$ ，从中可以采样并执行机器人动作。这里， T 表示动作预测时域，而 L 和 N 分别表示演示长度和演示数量。为简洁起见，从现在起我们将演示称为上下文 C ，将动作预测称为 $\mathbf{a}$ ，这些演示在测试时定义任务，在训练时不使用。解析地定义这样的分布是不可行的，因此我们旨在使用一种新颖的基于图的扩散过程从模拟伪演示中学习它。

3.2 图表示

为了学习所述的动作条件概率，我们首先需要选择一种合适的表示，以捕捉问题的关键要素并引入适当的归纳偏置。我们提出一种异构图，联合表达上下文、当前观测和未来动作，捕捉机器人与环境之间的复杂关系，并确保相关信息以有意义的方式聚合和传播。该图使用分割的点云观测构建，如图 2 所示。




图 2: (左) 一个局部图 G_t ，表示机器人的状态（蓝色节点）和物体的局部几何（绿色节点）。(右) 一个表示 2 个演示（每个 3 个路径点）、当前状态和 2 个未来动作的图。边颜色表示异构图中的不同边类型。

局部表示。我们表示的核心构建块是时间步 t 的观测，我们将其表示为局部图 $G_t^t(P^t, \mathbf{T}_{WE}^t, s_g)$ （图 2，左）。首先，我们使用最远点采样算法从稠密点云 P^t 中采样 M 个点，并用集合抽象 (SA) 层 (Qi 等人, 2017) 编码它们周围的局部几何，得到特征向量 $\mathcal{F}$ 和位置 p 作为 $\{\mathcal{F}^i, p^i\}^M$ 。单独预训练的 ϕ ， $\mathbf{z}_1 = \phi(P^t)$ 个隐式占

据网络 (Mescheder 等人, 2019), 确保这些特征描述局部几何 (详见附录 A)。然后, 我们以相同的格式表示夹爪的状态, $\{\mathcal{F}_q^i, p_q^i\}_{i=1}^6$, 通过刚性变换末端执行器上的关键点 p_{kp} , $p_g = \mathbf{T}_{WE} \times p_{kp}$, 并为它们分配编码节点区分和夹爪状态信息的嵌入 $\phi_g(s_q)^T$ 入 $\mathcal{F}_q^i = [\mathcal{F}_a^i$ 最后, 我们通过有向边连接场景节点与夹爪节点, 并赋予边属性 e , 表示笛卡尔空间中的相对位置。为提高精确率并捕捉所述节点位置的高频变化, 我们将边表示为 $e_{ij} = (\sin(2^0\pi(p_j - p_i)), \cos(2^0\pi(p_j - p_i)), \dots, \sin(2^{D-1}\pi(p_j - p_i)), \cos(2^{D-1}\pi(p_j - p_i)))$, 与 Zhou 等人 (2023) 的方法类似。

上下文表示。虽然 $\mathcal{G}_i^t$ 捕捉了环境状态, 但一系列此类图与动作交错, 定义了上下文 C 中的轨迹 (图 2, 中部)。我们通过跨时间连接夹爪节点来表示其相对运动 (红色边), 并将所有演示夹爪节点连接到当前节点以传播相关信息 (灰色边), 从而实现这种交错。这使得图能够高效处理任意数量的演示, 无论其长度如何, 同时确保边的数量线性增长。结果 $\mathcal{G}_c(\mathcal{G}_i^t, \{\mathcal{G}_i^{1:L}\}_1^N)$ 实现了上下文与当前观测之间结构化的信息流动。

动作表示。为了在图表示中表达未来动作 $\mathbf{a} = (\mathbf{T}_{EA}, a_g)$, 我们构建局部图, 仿佛动作已执行且夹爪已移动: $\mathcal{G}_i^a(P^t, \mathbf{T}_{WE}^t \times \mathbf{T}_{EA}, a_g)$ 。这允许“想象”动作的空间启示。因此, 动作完全由这些局部图的节点位置和特征描述。为了将动作表示为相对于当前夹爪位姿的相对运动, 我们在当前与未来夹爪节点之间添加边, 并使用基于位置的嵌入来表示后续时间步之间的相对运动。这些边将信息从当前观测 (并间接从上下文) 传播到表示动作的节点。最终图 $\mathcal{G}(\mathcal{G}_i^a(\mathbf{a}), \mathcal{G}_c(\mathcal{G}_i^t, \{\mathcal{G}_i^{1:L}\}_1^N))$ 聚合了来自上下文和当前观测的相关信息, 并将其传播到表示动作的节点, 通过确保观测和动作在同一图空间中表达, 实现了对机器人动作的有效推理。

3.3 通过图扩散学习机器人动作

为了有效利用我们的图表示, 我们将 ICIL 框架化为图生成问题, 并使用扩散模型学习先前描述的图 $p_\theta(\mathcal{G})$ 上的分布, 如图中所示

图 3. 该方法涉及前向与后向马尔可夫链过程, 其中图在每个阶段被改变和重建。在测试时, 模型仅迭代更新图中表示机器人动作的部分, 隐式地建模期望的条件动作概率。




图 3: (左) 用于训练基于图的扩散模型的网络高层结构。(右) 在去噪过程中, 针对其中一个预测动作的夹爪动作节点位置。

训练。训练我们的扩散模型首先包括前向过程, 在该过程中, 噪声被迭代地添加到从底层数据分布 $q(\mathcal{G})$ 中抽取的样本上。在此阶段, 我们根据 Ho 等人 (2020) 的方法, 通过向机器人动作添加噪声来构建一个受噪声扰动的图:

$$q(\mathcal{G}^k | \mathcal{G}^{k-1}) = \mathcal{G}(\mathcal{G}_i^a(\mathcal{N}(\mathbf{a}^k; \sqrt{1 - \beta_k} \mathbf{a}^{k-1}, \beta_k \mathbf{I}), \mathcal{G}_c)), \quad k = 1, \dots, K \quad (1)$$

这里， $\mathcal{N}$ 表示正态分布， β_k 表示方差调度， K 表示扩散步骤的总数。该过程逐渐将真实图表示转变为使用从高斯分布采样的动作构建的图。

相反，在反向扩散过程中，目标是利用参数化模型 $p_\theta(\mathcal{G}^{k-1} | \mathcal{G}^k)$ ，从其受噪声扰动的状态重建原始数据样本（在我们的情况下是图）。直观上，这样的模型需要学习如何调整表示机器人动作的夹爪节点，使得整个图更接近真实数据分布 $q(\mathcal{G})$ 。形式上，参数化模型使用我们的图表示 $\mathcal{G}(\mathbf{a})$ 学习动作的去噪过程，如下所示：

$$\mathcal{G}^{k-1} = \mathcal{G}(\mathcal{G}_l^a(\alpha(\mathbf{a}^k - \gamma \varepsilon_\theta(\mathcal{G}^k, k)) + \mathcal{N}(0, \sigma^2 \mathbf{I})), \mathcal{G}_c) \quad (2)$$

此处， $\varepsilon_\theta(\cdot)$ 可被解释为对梯度场的有效预测，基于该梯度场执行单步含噪梯度下降（Chi 等人，2023）。由于我们将动作表示为节点集合，其关联位置 p 与特征依赖于二值夹爪动作 a_g ，因此该梯度场具有两个分量 $\varepsilon_\theta = [\nabla p, \nabla a_g]^T$ 。正如后文将讨论的， ∇a_g 可直接用于扩散过程，而一组 ∇p 预测则是 $\mathbb{SE}(3)$ 流形上梯度方向的过参数化，需要额外步骤来计算精确的去噪更新。然而，这可能导致较大平移主导较小旋转，反之亦然，从而难以精确学习两个分量。为解决此问题，我们将去噪方向表示为质心运动与绕质心旋转的组合，在保持笛卡尔空间的同时有效解耦平移与旋转预测，即，其中表示流（图 3 左中的红色箭头）。此处， $\mathbf{t}_{EA} \in \mathbb{R}^3$ 与 $\mathbf{R}_{EA} \in \mathbb{SO}(3)$ 定义了表示动作 $\mathbf{T}_{EA}$ 的 $\mathbb{SE}(3)$ 变换。因此，我们通过逐节点预测 $\varepsilon^k \in \mathbb{R}^7$ 学习 ε_θ ，并优化数据似然 $[\nabla \hat{p}_t, \nabla \hat{p}_r]^T = [\mathbf{t}_{EA}^0 - \mathbf{t}_{EA}^k, \mathbf{R}_{EA}^0 \times p - \mathbf{R}_{EA}^k \times p_k]^T$ $\nabla \hat{p} = \nabla \hat{p}_t + \nabla \hat{p}_r$ 的变分下界，该下界已被证明（Ho 等人，2020）等价于最小化 $MSE(\varepsilon^k - \varepsilon_\theta(\mathcal{G}^k))$ 。作为参数化模型，我们采用异构图 Transformer，其更新图中每个节点的特征 $\mathcal{F}_i$ ，如下（Shi 等人，2020）：

$$\mathcal{F}'_i = \mathbf{W}_1 \mathcal{F}_i + \sum_{j \in \mathcal{N}(i)} \text{att}_{i,j} (\mathbf{W}_2 \mathcal{F}_j + \mathbf{W}_5 e_{ij}); \quad \text{att}_{i,j} = \text{softmax} \left(\frac{(\mathbf{W}_3 \mathcal{F}_i)^T (\mathbf{W}_4 \mathcal{F}_j + \mathbf{W}_5 e_{ij})}{\sqrt{d}} \right) \quad (3)$$

此处， $\mathbf{W}_i$ 表示可学习权重。为模型配备这种结构化注意力机制，可实现选择性和信息性的信息聚合，并以有意义的方式在图内传播，同时确保内存和计算复杂度随上下文长度线性增长（ N 与 L 均如此）。更多细节见附录 C。

部署。在测试阶段，我们使用从正态分布采样的动作、当前观测以及作为上下文的演示来构建图表示。随后，我们预测夹爪节点应如何调整，并根据 DDIM（Song 等人，2020）执行去噪步骤来更新这些节点的位置：

$$p_g^{k-1} = \sqrt{\alpha_{k-1}} \hat{p}_g^0 + \sqrt{\frac{1 - \alpha_{k-1}}{1 - \alpha_k}} (p_g^k - \sqrt{\alpha_k} \hat{p}_g^0). \quad (4)$$

此处， $\hat{p}_g^0 = p_g^k + \Delta p_t + \Delta p_r$ 。这为我们留下了两组点 p_q^{k-1} 和 p_q^k ，它们隐式地表示了去噪时间步 $k-1$ 和 k 处的夹爪姿态。由于我们知道它们之间的真实对应关系，因此可以利用奇异值分解（Singular Value Decomposition, SVD）（Arun 等人，1987）提取一个 $\mathbb{SE}(3)$ 变换来对齐它们，如下所示：

$$\mathbf{T}_{k-1,k} = \arg \min_{\mathbf{T}_{k-1,k} \in \mathbb{SE}(3)} \|\mathbf{p}^{k-1} - \mathbf{T}_{k-1,k} \times \mathbf{p}^k\|^2 \quad (5)$$

最后，通过将计算得到的变换 $\mathbf{T}_{k-1,k}$ 应用于 $\mathbf{a}^k$ 来计算 $\mathbf{a}^{k-1}$ 。注意，对于夹爪开合动作，直接利用方程 4 即可。此过程重复 K 次，直到生成符合分布的图，并作为副产品提取最终的 $\mathbf{a}^0$ 动作，从而允许我们从最初描述分布 $p(\mathbf{a} | o_t, C)$ 中进行采样。

3.4 无限数据池

既然我们能够学习动作的条件分布，就需要回答一个问题：一个足够大且多样化的数据集将从何而来，以确保学习到的模型能够用于广泛的现实世界任务。借助上下文学习（In-Context Learning），模型无需将任务特定的策略编码到其权重中。因此，可以模拟“任意但一致”的轨迹作为训练数据。这里，一致意味着虽然轨迹不同，但它们在语义层面上“执行”相同类型的伪任务。我们将此类轨迹称为伪演示。

数据生成。首先，为确保跨物体几何形状的泛化性，我们使用来自 ShapeNet 数据集（Chang 等人，2015）的多样化物体填充模拟环境。然后，通过在物体附近或物体上随机采样以物体为中心的路线来创建伪任务，机器人需要按顺序到达这些路点。最后，通过在它们之间虚拟移动机器人夹爪，并偶尔通过将物体附着到夹爪上来模拟刚性抓取，我们创建了伪演示——即类似于各种操作任务的轨迹。此外，随机化物体和夹爪的位姿，使我们能够创建许多执行相同伪任务的伪演示，从而得到用于训练上下文模型的数据。




图 4：模拟轨迹示例——2 个伪任务的 3 条伪演示。

在实践中，为了更高效地学习通用技能，我们使采样偏向于类似抓取或取放等任务的路径点。需要注意的是，由于环境动态和任务规范（例如可行的抓取）在推理时被定义为上下文，我们无需确保这些轨迹在动力学甚至运动学上是可行的。理论上，通过充分的随机化，生成轨迹的凸包将涵盖所有可能的测试时任务。关于数据生成过程的更多信息可在附录 D 中找到。

数据使用。在训练过程中，我们为给定的伪任务采样 N 个伪演示，使用 $N-1$ 来定义上下文，同时模型学习预测第 N 个动作。尽管伪演示是主要的训练数据，但我们的方法可以以相同格式整合额外的数据源，使模型能够适应特定设置或处理噪声更大的观测。

4 实验

我们在两种不同的设置下进行了实验：1）使用 RLBench（James 等人，2020 年）和真实分割的仿真，以及 2）真实世界的日常任务。我们的实验研究了相对于基线的性能，以理解不同设计选择的影响，揭示扩展趋势，并展示在跨具身和模态迁移中的适用性。视频可在我们的匿名网页 <https://www.robot-learning.uk/instant-policy> 上查看。

实验设置。在我们所有的实验中，除非另有明确说明，我们使用单一模型通过提供 $N=2$ 个演示（表示为 $L=10$ 个路径点作为上下文）来执行各种操作任务，并预测 $T=8$ 个未来动作。我们使用并行持续生成的伪演示对该模型进行 250 万优化步的训练，这大致相当于使用 70 万条独特轨迹。在训练期间，我们将上下文中的演示数量随机化在 1 到 5 之间。当我们讨论整合伪演示之外的额外训练数据时，我们指的是使用伪演示和新数据各占 50% 的混合数据，再对模型进行额外 10 万优化步的微调。更多信息请参考附录 E。

基线。我们将即时策略与三种同样支持上下文模仿学习的基线方法进行了比较，即：BC-Z（Jang 等人，2022 年）、Vid2Robot（Jain 等人，2024 年）以及一种 GPT2 风格模型（Radford 等人，2019 年）。BC-Z 将演示的潜在嵌入与当前观测相结合，并使用基于多层感知机的模型来预测机器人动作；Vid2Robot 利用感知器重采样器（Jaegle 等人，2021 年）和交叉注意力来整合来自上下文和当前观测的信息；

而 GPT2 则使用因果自注意力来预测序列中的下一个标记，在我们的场景中即机器人动作。为了公平比较，我们通过使用相同的预训练编码器使所有基线方法适配点云观测，并且所有方法的可训练参数数量大致相同。此外，由于我们生成的伪演示不包含语言标注信息，所有依赖语言标注数据的组件（如辅助损失）均被移除。为了强调这一点，在讨论结果时我们在这些方法名称后添加星号。

4.1 仿真实验

我们第一组实验的目的有两个：1) 通过与最先进的基线方法比较，评估即时策略在执行各种操作任务中的有效性；2) 探究训练数据在泛化到未见场景中的作用。我们使用标准的 RLBench 设置，采用 Franka Emika Panda 机器人，在 24 个任务上测试即时策略和基线方法，每个任务进行 100 次 rollout，每次随机化环境中物体的位姿。此外，我们还测试了仅使用伪演示训练的模型，以及在 24 个 RLBench 任务中的 12 个任务上使用伪演示与 20 个演示组合训练的模型。

结果与讨论。表 1 所示结果中第一个值得注意的发现是，仅使用伪演示时，所有方法均达到非零成功率，且至少在较简单任务上表现良好。这表明这些伪演示为上下文模仿学习提供了强大的无限数据来源。第二个发现是，融入来自同一领域的额外演示可显著提升性能，有助于泛化至未见任务和新颖物体姿态。第三个发现是，即时策略的成功率显著高于基线方法，证明了本文图表示的重要性及其解读上下文的能力。本文进一步通过可视化注意力权重（图 5）加以论证，揭示了模型理解任务当前阶段并识别上下文中相关信息的能力。失败案例在附录 G 中讨论。

Tasks	Instant Policy	BC-Z*	Vid2Robot*	GPT2*	Tasks	Instant Policy	BC-Z*	Vid2Robot*	GPT2*
Open box	0.94 / 0.99	0.22 / 0.98	0.30 / 0.97	0.25 / 0.95	Slide buzzer	0.35 / 0.94	0.04 / 0.26	0.05 / 0.19	0.00 / 0.00
Close jar	0.58 / 0.93	0.00 / 0.06	0.00 / 0.11	0.00 / 0.22	Plate out	0.81 / 0.97	0.26 / 0.55	0.11 / 0.52	0.31 / 0.40
Toilet seat down	0.85 / 0.93	0.40 / 0.88	0.54 / 0.85	0.38 / 0.83	Close laptop	0.91 / 0.95	0.64 / 0.65	0.45 / 0.57	0.53 / 0.72
Close microwave	1.00 / 1.00	0.55 / 0.60	0.72 / 0.87	0.76 / 1.00	Close box	0.77 / 0.99	0.81 / 1.00	0.89 / 0.88	0.42 / 0.41
Phone on base	0.98 / 1.00	0.51 / 0.50	0.48 / 0.51	0.28 / 0.55	Open jar	0.52 / 0.78	0.12 / 0.28	0.15 / 0.30	0.22 / 0.51
Lift lid	1.00 / 1.00	0.82 / 0.82	0.90 / 0.91	0.88 / 0.94	Toilet seat up	0.94 / 1.00	0.62 / 0.63	0.58 / 0.64	0.31 / 0.34
Take umbrella out	0.88 / 0.91	0.42 / 0.64	0.90 / 0.90	0.75 / 0.89	Meat off grill	0.77 / 0.9	0.75 / 0.64	0.76 / 0.33	0.80 / 0.30
Slide block	0.75 / 1.00	0.10 / 0.14	0.12 / 0.16	0.08 / 0.16	Open microwave	0.23 / 0.56	0.00 / 0.13	0.00 / 0.02	0.00 / 0.00
Push button	0.60 / 1.00	0.75 / 0.81	0.85 / 0.88	0.80 / 0.91	Paper roll off	0.70 / 0.95	0.32 / 0.53	0.29 / 0.55	0.26 / 0.48
Basketball in hoop	0.66 / 0.97	0.02 / 0.09	0.00 / 0.06	0.03 / 0.07	Put rubbish in bin	0.97 / 0.99	0.11 / 0.11	0.12 / 0.14	0.18 / 0.17
Meat on grill	0.78 / 1.00	0.64 / 0.88	0.51 / 0.77	0.53 / 0.81	Put umbrella	0.31 / 0.37	0.35 / 0.34	0.41 / 0.28	0.28 / 0.39
Flip switch	0.40 / 0.94	0.15 / 0.63	0.05 / 0.16	0.11 / 0.42	Lamp on	0.42 / 0.41	0.00 / 0.00	0.00 / 0.00	0.00 / 0.00
Average (PD++) Seen	0.97	0.59	0.60	0.65	Average (PD++) Unseen	0.82	0.43	0.37	0.31
Average (PD only) All	0.71	0.36	0.38	0.34					

表 1：即时策略与基线在 24 项任务上的成功率。每项任务进行 100 次测试（仅使用伪演示训练 / 额外使用左侧 12 项 RLBench 任务的演示训练）。




图 5：在基于电话的任务中，两个不同时间步的子图边上可视化的注意力权重，展示了模型跟踪任务进度并聚合相关信息的能力。

4.2 即时策略设计选择与扩展趋势

下一组实验探究了各类超参数对本文方法性能的影响，重点关注需要重新训练模型的设计选择以及推理参数

在测试时改变模型行为，以及随着模型容量和训练时间增加的扩展趋势。对于设计选择和推理参数，我们计算了在 24 个未见过的 RLBench 任务上成功率相对于前一组实验中使用的基准模型的平均变化，而对于扩展趋势，我们报告了在留出的伪演示集上的验证损失，以观察其捕捉底层数据分布的能力。

Design Choices						Inference Parameters					
Action Mode	$\Delta\%$	Diffusion Mode	$\Delta\%$	Prediction Horizon (T)	$\Delta\%$	# Diffusion Steps (K)	$\Delta\%$	Demo Length (L)	$\Delta\%$	# Demos (N)	$\Delta\%$
Δp	-15	Flow	0	1	-52	1	-16	1	-71	1	-12
$(\Delta p_t, \Delta p_r)$	0	Sample	-6	4	-13	2	-2	5	-26	2	0
$(\Delta t, \Delta q)$	-37	Noise	-7	8	0	4	0	10	0	3	2
$(\Delta t, \Delta \theta)$	-21	No Diff	-29	16	-4	8	0	15	1	4	-1

表 2: 与基础模型相比，消融变体的性能变化。

设计选择。我们现在考察以下方面：动作模式、扩散模式以及预测时域。对于动作模式，我们将所提出的解耦平移与旋转的参数化方法，与未进行此类解耦的方法，以及将平移与四元数或轴角表示相结合等更常规的方法进行了比较。对于扩散模式，我们评估了预测流与添加噪声、直接采样以及省略扩散直接回归动作的效果。最后，我们评估了预测不同数量动作的影响。表 2（左）所示的结果表明，这些选择极大地影响了性能。在笛卡尔空间中解耦平移与旋转，能够实现精确的低层动作学习。扩散过程对于捕捉复杂的动作分布至关重要，其中预测流表现最佳。最后，预测多个动作是有帮助的，但这也增加计算复杂度。关于其他设计选择（包括不成功的选择）的详细讨论，请参阅附录 H。

推理参数。使用具有灵活表示、能够处理任意上下文长度的扩散模型，使我们能够在推理时调整模型性能。我们研究了扩散步数、演示长度以及上下文中演示数量的影响，如表 2（右）所示。结果表明，即使仅使用两个去噪步骤，也能获得良好的性能。演示长度至关重要：它必须足够密集，以传达任务应如何解决，因为这些信息并未编码在模型权重中。当仅提供最终目标（演示长度=1）时，这一点尤为明显，导致性能不佳。然而，将其延长到一定程度以上后，改进甚微，因为 RLBench 任务通常只需几个路径点即可描述。对于更复杂的任务，密集的演示将至关重要。最后，性能随着多个演示而提高，但使用超过两个似乎没有必要。这是因为在仅对物体姿态进行泛化时，两个演示足以消除任务歧义。然而，正如我们将在其他实验中展示的那样，当测试物体在几何形状上与演示中的物体不同时，这一结论并不成立。

扩展趋势。在仿真中持续生成训练数据的能力使得本文模型的性能仅受限于可用算力（训练时间）和模型容量（可训练参数量）。为评估这些因素对本文方法的影响，本文训练了三种参数量不同的模型变体，并在不同优化步数后对其进行评估（图 6）。结果表明，模型捕捉数据分布的能力（表现为验证损失的下降）随训练时间和模型复杂度的增加而良好扩展。这为仅通过扩展算力即可开发高性能机器人操作模型提供了一定前景。在定性层面，本文在未见过的 RLBench 任务上观察到类似的性能趋势。随着训练增加，性能有所提升，但最终趋于平稳。类似地，将模型容量从 69M 增加到 117M 后，达到平稳前的成功率也有所提高。




图 6: 三种不同模型规模的验证损失曲线。

性能显著提升。然而，进一步将可训练参数数量增加到 1.78 亿，仅带来微小的、不显著的性能改善。这表明需要更多样化且具有代表性的数据。此类数据可来源于现有的机器人数据集，或生成更接近真实任务的伪演示。

4.3 真实世界实验

在真实世界实验中，我们评估了该方法学习日常任务的能力，以及泛化到训练数据和上下文中均未出现的新物体的能力。我们使用一台配备 Robotiq 2F-85 夹爪和两台外部 RealSense D415 深度相机的 Sawyer 机器人。我们通过以 SAM (Kirillov 等, 2023) 的初始结果作为种子，运行 XMem++ (Bekuzarov 等, 2023) 物体跟踪器来获得分割结果，并通过动觉示教提供演示。为了帮助模型更有效地处理不完美的分割和带噪声的点云，我们进一步使用来自 5 个未包含在评估中的任务的 5 个演示，对之前实验中使用的模型进行了联合微调。



图 7: 本文实际评估中使用的 16 项任务。

现实世界任务。为了评估我们的模型在现实世界中处理各种任务的能力，我们对其及基线方法在 16 项日常任务上进行了测试（图 7）。我们使用 10 次执行对所有方法进行评估，每次随机化环境中物体的姿态。从结果（表 3）可以看出，即时策略仅通过少量演示就能以高成功率完成各种日常任务，大幅超越基线方法。

	Insert Paper Roll	Open Airfryer	Flip Bottle	Stack Bowls	Knock over Creeper	Kettle on Stove	Close Coffee Machine	Hang Cable	
Instant Policy	9 / 10	9 / 10	7 / 10	10 / 10	8 / 10	10 / 10	10 / 10	7 / 10	
BC-Z*	1 / 10	5 / 10	0 / 10	2 / 10	5 / 10	1 / 10	1 / 10	0 / 10	
Vid2Robot*	3 / 10	6 / 10	0 / 10	1 / 10	7 / 10	3 / 10	4 / 10	1 / 10	
GPT2*	1 / 10	6 / 10	0 / 10	4 / 10	5 / 10	5 / 10	5 / 10	1 / 10	
	Open Box	Turn Tap Right	Turn Tap Left	Take Rose Out	Push Cans Together	Pick up Kettle	Close Box	Open Register	Average, %
Instant Policy	8 / 10	10 / 10	10 / 10	9 / 10	5 / 10	10 / 10	10 / 10	10 / 10	88.75
BC-Z*	8 / 10	2 / 10	3 / 10	0 / 10	2 / 10	10 / 10	7 / 10	8 / 10	34.38
Vid2Robot*	9 / 10	4 / 10	3 / 10	0 / 10	1 / 10	10 / 10	7 / 10	6 / 10	40.63
GPT2*	0 / 10	5 / 10	5 / 10	0 / 10	0 / 10	10 / 10	5 / 10	7 / 10	36.88

表 3: 即时策略与基线方法在现实世界中的成功率，各执行 10 次。

对新物体的泛化。此前所有实验均侧重于评估方法在演示所用相同物体上的性能，而此处旨在测试其在新物体几何形状的泛化能力。我们通过提供同一语义类别中不同物体集合的演示（即定义上下文），并在该类别中的不同物体上进行测试来实现这一目标。评估中，我们使用四项不同任务（图 8），每项任务包含六组物体（四组用于演示/上下文，两组用于评估）。我们使用不同数量的演示




图 8: 泛化实验中使用的物体（数字表示其使用阶段）。

在上下文中评估方法，每次执行时随机化测试物体的姿态（每个未见物体集合执行 5 次）。结果如表 4 所示，随着跨不同物体的演示数量增加，对全新物体几何形状的性能也随之提升。这表明即时策略能够选择性地聚合和插值上下文中的信息，以消除任务歧义并识别与任务相关的物体部分。值得注意的是，这是一种涌现行为，因为我们从未在上下文中使用不同几何形状的物体训练模型，而这一能力得益于图表示和结构化交叉注意力机制。

4.3.1 下游应用

跨具身迁移。由于本文模型使用分割后的点云，并通过末端执行器位姿和夹爪状态定义机器人状态，因此只要不同具身之间的映射关系已知，即可用其定义上下文并执行策略。本文通过使用人手演示，并采用手工设计的映射到夹爪状态，展示了这一能力，从而能够将策略直接迁移到机器人上。在定性实验中，对于简单任务（如抓取与放置），本文达到了与动觉示教相近的成功率。然而，对于更复杂的任务，该方法受限于手工设计的映射。视频示例见项目网页，关于该映射的更多信息参见附录 I。

N	Open Box	Fold in Half	Mug on Plate	Unplug Charger	Average, %
1	2 / 10	7 / 10	7 / 10	0 / 10	40
2	5 / 10	8 / 10	8 / 10	0 / 10	52.5
3	10 / 10	10 / 10	9 / 10	5 / 10	85
4	10 / 10	10 / 10	9 / 10	7 / 10	90

表 4：即时策略在不同演示数量（N）下的成功率，展示了对新物体几何形状的泛化能力。

模态转换。虽然在演示后立即获得策略是一种强大且高效的工具，但仍需人类提供演示。本文可以通过利用训练模型的瓶颈来规避这一问题，该瓶颈包含了预测动作所需的上下文和当前观测信息。这些信息聚合在当前观测的夹爪节点中。如果使用不同模态（如语言）来近似该瓶颈表示，则可以完全绕过使用演示作为上下文。这可以通过一个较小的、带有语言标注的数据集和一个对比目标来实现。利用来自 RLBench 的语言标注轨迹和先前实验的 rollout 数据，本文定性展示了仅基于语言命令的零样本任务完成能力。更多细节参见附录 J，视频见项目网页 <https://www.robot-learning.uk/instant-policy>。

5 讨论

局限性。尽管即时策略（Instant Policy）展现出强大的性能，但仍存在若干局限性。首先，与许多类似方法一样，本文假设可获得分割后的点云以保证足够的可观测性。其次，点云观测缺乏颜色或其他语义丰富的信息。第三，本文方法侧重于马尔可夫假设成立的相对短时程任务。第四，即时策略对推理时演示的质量与降采样较为敏感。第五，该方法未处理碰撞避免，也未提供机器人手臂完整配置空间的端到端控制。最后，对于公差极低或接触动力学丰富的任务，该方法缺乏所需精度。然而，本文认为其中许多局限性可通过改进伪演示的生成来主要解决，例如考虑碰撞、纳入长时程任务，以及通过引入视觉模型、力信息或历史观测的额外特征来改进图表示。

结论。本文提出了即时策略，这是一种用于上下文模仿学习（In-Context Imitation Learning）的新颖框架，能够在一次或两次测试时演示后立即习得机器人技能。这是对当前广泛采用的行为克隆方法的一种引人注目的替代范式，后者需要数百或数千次演示。本文表明，所提出的新颖图结构能够通过一种新颖的图扩散过程，有效传播来自演示、当前观测和未来动作的数据。重要的是，即时策略仅需使用仿真中生成的伪演示进行训练，从而提供了几乎无限的数据源，仅受可用计算资源的限制。实验表明，该方法相对于基线具有较强性能，能够学习日常真实世界操作任务，泛化到新颖物体几何形状，并展现出进一步下游应用的潜力。

参考文献

- K Somani Arun, Thomas S Huang, and Steven D Blostein. Least-squares fitting of two 3-d point sets. *IEEE Transactions on pattern analysis and machine intelligence*, (5):698–700, 1987.
- Jimmy Lei Ba. Layer normalization. *arXiv preprint arXiv:1607.06450*, 2016.
- Maksym Bekuzarov, Ariana Bermudez, Joon-Young Lee, and Hao Li. Xmem++: Production-level video segmentation from few annotated frames. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pp. 635–644, 2023.
- Kevin Black, Mitsuhiko Nakamoto, Pranav Atreya, Homer Walke, Chelsea Finn, Aviral Kumar, and Sergey Levine. Zero-shot robotic manipulation with pretrained image-editing diffusion models. *arXiv preprint arXiv:2310.10639*, 2023.
- Tom B Brown. Language models are few-shot learners. *arXiv preprint arXiv:2005.14165*, 2020.
- Angel X Chang, Thomas Funkhouser, Leonidas Guibas, Pat Hanrahan, Qixing Huang, Zimo Li, Silvio Savarese, Manolis Savva, Shuran Song, Hao Su, et al. Shapenet: An information-rich 3d model repository. *arXiv preprint arXiv:1512.03012*, 2015.
- Cheng Chi, Siyuan Feng, Yilun Du, Zhenjia Xu, Eric Cousineau, Benjamin Burchfiel, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. *arXiv preprint arXiv:2303.04137*, 2023.
- Norman Di Palo and Edward Johns. Keypoint action tokens enable in-context imitation learning in robotics. *arXiv preprint arXiv:2403.19578*, 2024.
- Yan Duan, Marcin Andrychowicz, Bradly Stadie, OpenAI Jonathan Ho, Jonas Schneider, Ilya Sutskever, Pieter Abbeel, and Wojciech Zaremba. One-shot imitation learning. *Advances in neural information processing systems*, 30, 2017.
- Letian Fu, Huang Huang, Gaurav Datta, Lawrence Yunliang Chen, William Chung-Ho Panitch, Fangchen Liu, Hui Li, and Ken Goldberg. In-context imitation learning via next-token prediction. *arXiv preprint arXiv:2408.15980*, 2024.
- Dan Hendrycks and Kevin Gimpel. Gaussian error linear units (gelus). *arXiv preprint arXiv:1606.08415*, 2016.
- Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. *Advances in neural information processing systems*, 33:6840–6851, 2020.
- Weihua Hu, Matthias Fey, Hongyu Ren, Maho Nakata, Yuxiao Dong, and Jure Leskovec. Ogb-lsc: A large-scale challenge for machine learning on graphs. *arXiv preprint arXiv:2103.09430*, 2021.
- Andrew Jaegle, Sebastian Borgeaud, Jean-Baptiste Alayrac, Carl Doersch, Catalin Ionescu, David Ding, Skanda Koppula, Daniel Zoran, Andrew Brock, Evan Shelhamer, et al. Perceiver io: A general architecture for structured inputs & outputs. *arXiv preprint arXiv:2107.14795*, 2021.
- Vidhi Jain, Maria Attarian, Nikhil J Joshi, Ayzaan Wahid, Danny Driess, Quan Vuong, Pannag R Sanketi, Pierre Sermanet, Stefan Welker, Christine Chan, et al. Vid2robot: End-to-end video-conditioned policy learning with cross-attention transformers. *arXiv preprint arXiv:2403.12943*, 2024.
- Stephen James, Zicong Ma, David Rovick Arrojo, and Andrew J Davison. Rlbench: The robot learning benchmark & learning environment. *IEEE Robotics and Automation Letters*, 5(2):3019–3026, 2020.
- Eric Jang, Alex Irpan, Mohi Khansari, Daniel Kappler, Frederik Ebert, Corey Lynch, Sergey Levine, and Chelsea Finn. Bc-z: Zero-shot task generalization with robotic imitation learning. In *Conference on Robot Learning*, pp. 991–1002. PMLR, 2022.
- Kanchan Jha, Sriparna Saha, and Hiteshi Singh. Prediction of protein–protein interaction using graph neural networks. *Scientific Reports*, 12(1):8360, 2022.

-
- Ivan Kapelyukh and Edward Johns. My house, my rules: Learning tidying preferences with graph neural networks. In *Conference on robot learning*, pp. 740–749. PMLR, 2022.
- Ivan Kapelyukh, Vitalis Vosylius, and Edward Johns. Dall-e-bot: Introducing web-scale diffusion models to robotics. *IEEE Robotics and Automation Letters*, 8(7):3956–3963, 2023.
- Alexander Kirillov, Eric Mintun, Nikhila Ravi, Hanzi Mao, Chloe Rolland, Laura Gustafson, Tete Xiao, Spencer Whitehead, Alexander C Berg, Wan-Yen Lo, et al. Segment anything. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pp. 4015–4026, 2023.
- James J Kuffner and Steven M LaValle. Rrt-connect: An efficient approach to single-query path planning. In *Proceedings 2000 ICRA. Millennium Conference. IEEE International Conference on Robotics and Automation. Symposia Proceedings (Cat. No. 00CH37065)*, volume 2, pp. 995–1001. IEEE, 2000.
- I Loshchilov. Decoupled weight decay regularization. *arXiv preprint arXiv:1711.05101*, 2017.
- Camillo Lugaresi, Jiuqiang Tang, Hadon Nash, Chris McClanahan, Esha Uboweja, Michael Hays, Fan Zhang, Chuo-Ling Chang, Ming Guang Yong, Juhyun Lee, et al. Mediapipe: A framework for building perception pipelines. *arXiv preprint arXiv:1906.08172*, 2019.
- Ajay Mandlekar, Soroush Nasiriany, Bowen Wen, Ireaiyo Akinola, Yashraj Narang, Linxi Fan, Yuke Zhu, and Dieter Fox. Mimicgen: A data generation system for scalable robot learning using human demonstrations. *arXiv preprint arXiv:2310.17596*, 2023.
- Matthew Matl. Pyrender. <https://github.com/mmatl/pyrender>, 2019.
- Lars Mescheder, Michael Oechsle, Michael Niemeyer, Sebastian Nowozin, and Andreas Geiger. Occupancy networks: Learning 3d reconstruction in function space. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pp. 4460–4470, 2019.
- Ben Mildenhall, Pratul P Srinivasan, Matthew Tancik, Jonathan T Barron, Ravi Ramamoorthi, and Ren Ng. Nerf: Representing scenes as neural radiance fields for view synthesis. *Communications of the ACM*, 65(1):99–106, 2021.
- Georgios Papagiannis, Norman Di Palo, Pietro Vitiello, and Edward Johns. R+ x: Retrieval and execution from everyday human videos. *arXiv preprint arXiv:2407.12957*, 2024.
- Adam Paszke, Sam Gross, Francisco Massa, Adam Lerer, James Bradbury, Gregory Chanan, Trevor Killeen, Zeming Lin, Natalia Gimelshein, Luca Antiga, Alban Desmaison, Andreas Kopf, Edward Yang, Zachary DeVito, Martin Raison, Alykhan Tejani, Sasank Chilamkurthy, Benoit Steiner, Lu Fang, Junjie Bai, and Soumith Chintala. Pytorch: An imperative style, high-performance deep learning library. In *Advances in Neural Information Processing Systems* 32, pp. 8024–8035. Curran Associates, Inc., 2019. URL <http://papers.neurips.cc/paper/9015-pytorch-an-imperative-style-high-performance-deep-learning-library.pdf>.
- Charles Ruizhongtai Qi, Li Yi, Hao Su, and Leonidas J Guibas. Pointnet++: Deep hierarchical feature learning on point sets in a metric space. *Advances in neural information processing systems*, 30, 2017.
- Alec Radford, Jeffrey Wu, Rewon Child, David Luan, Dario Amodei, Ilya Sutskever, et al. Language models are unsupervised multitask learners. *OpenAI blog*, 1(8):9, 2019.
- Aditya Ramesh, Mikhail Pavlov, Gabriel Goh, Scott Gray, Chelsea Voss, Alec Radford, Mark Chen, and Ilya Sutskever. Zero-shot text-to-image generation. In *International conference on machine learning*, pp. 8821–8831. Pmlr, 2021.
- N Reimers. Sentence-bert: Sentence embeddings using siamese bert-networks. *arXiv preprint arXiv:1908.10084*, 2019.
- Carmelo Sferrazza, Dun-Ming Huang, Fangchen Liu, Jongmin Lee, and Pieter Abbeel. Body transformer: Leveraging robot embodiment for policy learning. *arXiv preprint arXiv:2408.06316*, 2024.

-
- Chuan Shi, Binbin Hu, Wayne Xin Zhao, and S Yu Philip. Heterogeneous information network embedding for recommendation. *IEEE transactions on knowledge and data engineering*, 31(2): 357–370, 2018.
- Yunsheng Shi, Zhengjie Huang, Shikun Feng, Hui Zhong, Wenjin Wang, and Yu Sun. Masked label prediction: Unified message passing model for semi-supervised classification. *arXiv preprint arXiv:2009.03509*, 2020.
- Mohit Shridhar, Lucas Manuelli, and Dieter Fox. Perceiver-actor: A multi-task transformer for robotic manipulation. In *Conference on Robot Learning*, pp. 785–799. PMLR, 2023.
- Jiaming Song, Chenlin Meng, and Stefano Ermon. Denoising diffusion implicit models. *arXiv preprint arXiv:2010.02502*, 2020.
- Julen Urain, Niklas Funk, Jan Peters, and Georgia Chalvatzaki. Se (3)-diffusionfields: Learning smooth cost functions for joint grasp and motion optimization through diffusion. In *2023 IEEE International Conference on Robotics and Automation (ICRA)*, pp. 5923–5930. IEEE, 2023.
- David Vogt, Simon Stepputtis, Steve Grehl, Bernhard Jung, and Heni Ben Amor. A system for learning continuous human-robot interactions from human-human demonstrations. In *2017 IEEE International Conference on Robotics and Automation (ICRA)*, pp. 2882–2889. IEEE, 2017.
- Vitalis Vosylius and Edward Johns. Few-shot in-context imitation learning via implicit graph alignment. *arXiv preprint arXiv:2310.12238*, 2023a.
- Vitalis Vosylius and Edward Johns. Where to start? transferring simple skills to complex environments. In *Conference on Robot Learning*, pp. 471–481. PMLR, 2023b.
- Vitalis Vosylius, Younggyo Seo, Jafar Uruç, and Stephen James. Render and diffuse: Aligning image and action spaces for diffusion-based behaviour cloning. *arXiv preprint arXiv:2405.18196*, 2024.
- Tingwu Wang, Renjie Liao, Jimmy Ba, and Sanja Fidler. Nervenet: Learning structured policy with graph neural networks. In *International conference on learning representations*, 2018.
- Tianhe Yu, Ted Xiao, Austin Stone, Jonathan Tompson, Anthony Brohan, Su Wang, Jaspier Singh, Clayton Tan, Jodilyn Peralta, Brian Ichter, et al. Scaling robot learning with semantically imagined experience. *arXiv preprint arXiv:2302.11550*, 2023.
- Xinyu Zhang and Abdeslam Boularias. One-shot imitation learning with invariance matching for robotic manipulation. *arXiv preprint arXiv:2405.13178*, 2024.
- Tony Z Zhao, Jonathan Tompson, Danny Driess, Pete Florence, Seyed Kamyar Seyed Ghasemipour, Chelsea Finn, and Ayzaan Wahid. Aloha unleashed: A simple recipe for robot dexterity. In *8th Annual Conference on Robot Learning*.
- Allan Zhou, Moo Jin Kim, Lirui Wang, Pete Florence, and Chelsea Finn. Nerf in the palm of your hand: Corrective augmentation for robotics via novel-view synthesis. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 17907–17917, 2023.

附录

A 几何编码器

此处，我们描述用于将环境观测表示为一组节点的局部几何编码器。形式上，局部编码器将稠密点云编码为一组特征向量及其关联位置，如下所示： $\{\mathcal{F}^i, p^i\}_{i=1}^M = \phi(P)$ 。此处，每个特征 $\mathcal{F}^i$ 描述点 p^i 周围的局部几何。我们通过预训练一个占据网络（Mescheder 等人，2019）来确保这一点，该网络由一个编码器 ϕ_e 和一个解码器 ψ_e 组成，编码器嵌入局部点云，解码器在给定该嵌入和一个查询点的情况下，负责判断该查询点是否位于物体表面上： $\psi_e(\phi_e(P), q) \rightarrow [0, 1]$ 。我们占据网络的高层结构如图 9 所示。注意，每个局部嵌入仅用于重建物体的一部分，从而降低问题的复杂度，使其更容易泛化。




图 9：占据网络的高层结构。

我们将 ϕ_e 参数化为一个由 2 个集合抽象层（Qi 等人，2017）组成的网络，并增强了类似神经辐射场的正弦/余弦嵌入（Mildenhall 等人，2021）。它从稠密点云中采样 M 个质心，并将质心周围的局部几何嵌入为大小为 512 的特征向量。我们没有将点相对于采样质心 p^i 的位置表示为 $(\sin(2^0\pi(p_j - p_i)), \cos(2^0\pi(p_j - p_i)), \dots, \sin(2^9\pi(p_j - p_i)), \cos(2^9\pi(p_j - p_i)))$ ，而是将其表示为 p_i ，使模型能够捕捉稠密点位置的高频变化，并更精确地捕捉局部几何。我们将 ψ_e 参数化为一个具有残差连接的八层多层感知机，并使用相同的类似神经辐射场的嵌入来表示查询点的位置。

我们使用来自多样化 ShapeNet（Chang 等人，2015）数据集的物体来生成训练占据网络所需的训练数据。对于训练即时策略，我们不使用解码器，并保持编码器冻结。

B 训练

训练我们的扩散模型涉及一个前向和后向的马尔可夫链扩散过程，该过程在方程 1 和方程 2 中概述。直观上，我们向真实机器人动作添加噪声，并学习如何在图空间中去除这些噪声（见图 10）。

在实践中，训练包括四个主要步骤：1) 向真实动作添加噪声；2) 利用含噪动作构建图表示；3) 网络预测表示机器人动作的节点需要如何调整以有效去除所添加的噪声；4) 利用预测结果和真实标签计算损失函数，并据此更新网络权重。

为了向表示为 $(\mathbf{T}_{EA} \in \mathbb{SE}(3), a_g \in \mathbb{R})$ 的动作添加噪声，我们首先使用对数映射将 $\mathbf{T}_{EA}$ 投影到 $\mathfrak{se}(3)$ ，对所得向量进行归一化，按照 Ho 等人（2020）所述方法添加噪声，对结果进行反归一化，并使用指数映射提取含噪末端执行器变换 $\mathbf{T}_{EA}^k$ 。这一过程可以理解在 $\mathbb{SE}(3)$ 变换的切空间中添加噪声。我们




图 10: 训练过程的高层概览。(左) 从数据集中采样一个数据点。(中) 向真实动作添加噪声。(右) 利用演示、当前观测和含噪动作构建图表示, 该图表示用于预测如何在图空间中去所添加的噪声。

之所以可以这样做, 是因为动作 (末端执行器位移) 周围的区域足够小。对于较大的位移, 应将未归一化的噪声直接投影到 $\mathbb{SE}(3)$ 流形上, 如 Vosylius 和 Johns (2023a) 以及 Urain 等人 (2023) 所做的那样。向实值夹爪动作添加噪声可以直接使用 Ho 等人 (2020) 描述的过程完成。

C 网络架构

这里我们描述用于学习图上噪声去除过程的神经网络, 该网络使我们能够生成图 $\mathcal{G}$ 并隐式建模条件动作概率。我们的参数化神经网络以构建的图表示作为输入, 为每个表示动作的夹爪节点预测梯度场: $\varepsilon_\theta(\mathcal{G}^k)$ 。这些预测随后用于扩散过程, 从而能够迭代更新图并最终提取所需的底层机器人动作。在实践中, 为了计算效率和更可控的信息传播, 我们使用三个独立的网络 σ, ϕ 和 ψ , 按顺序更新图的相关部分:

$$\varepsilon_\theta(\mathcal{G}^k) = \psi(\mathcal{G}(\sigma(\mathcal{G}_l^a), \phi(\mathcal{G}_c(\sigma(\mathcal{G}_l^t), \{\sigma(\mathcal{G}_l^{1:L})\}_1^N))) \quad (6)$$

此处, σ 作用于局部子图 $\mathcal{G}_l$, 并将点云观测的初始信息传播到夹爪节点, ϕ 进一步通过演示轨迹传播信息, 使上下文中的所有相关信息汇聚到当前子图的夹爪节点。最后, ψ 将信息传播到图中表示动作的节点。利用这种结构化且受控的图信息传播方式, 结合方程 3 中描述的可学习注意力机制, 模型能够持续聚合上下文中的相关信息, 并对动作做出准确预测。此外, 这还在网络中形成了一个清晰且有意义的瓶颈, 所有来自上下文的相关信息都聚合在一组特定节点中 ($\phi(\mathcal{G}_c(\sigma(\mathcal{G}_l^t), \{\sigma(\mathcal{G}_l^{1:L})\}_1^N)))$ 。该瓶颈表示可用于检索, 或如我们的实验所示, 通过较小的标注数据集和对比目标切换到其他模态, 例如语言。

三个独立网络中的每一个都是一个异构图 Transformer (方程 3), 具有 2 层和隐藏维度 1024 (16 个头, 每个头 64 维)。由于我们使用异构图, 每个节点和边类型都通过单独的可学习权重进行处理, 并通过求和聚合以产生所有节点级嵌入。这可以理解为一组交叉注意力机制, 每个机制负责处理图表示的不同部分。我们在每个注意力层之间使用层归一化层 (Ba, 2016), 并添加额外的

残差连接以确保梯度在整个网络中的良好传播。最后，表示机器人动作的节点特征通过一个配备 GeLU 激活函数 (Hendrycks & Gimpel, 2016) 的 2 层 MLP 进行处理，以产生每个节点的去噪方向。

D 数据生成

我们的数据生成过程首先包括在场景中放置机器人将要交互的物体。我们从 ShapeNet 数据集中采样两个物体，并将它们随机放置在一个平面上。接下来，我们通过这些物体上或附近采样一系列路径点来定义一个伪任务。这些路径点的数量也在 2 到 6 之间随机选择，从而自然地建模各种操作任务。我们分配一个或多个路径点来改变夹爪状态，模拟刚性机器人抓取和释放。然后，我们为夹爪采样一个起始位姿，并在该位姿初始化 Robotiq 2F-85 夹爪的网格模型。通过在上述路径点之间移动夹爪，并在夹爪状态改变时将最近的物体附着或分离，我们创建了一个伪演示。为了进一步增加伪任务的多样性，我们在路径点之间使用不同的插值策略（例如线性、三次或在球面流形上保持插值）。我们使用 PyRender (Matl, 2019) 和三个模拟深度相机记录夹爪位姿和分割的点云观测。我们确保后续间隔之间的间距恒定且均匀（1 厘米和 3 度，与动作归一化使用的相同）。将物体移动到不同位姿、选择不同的起始夹爪位姿并重复该过程，会为同一伪任务生成多个伪演示，我们使用这些伪演示来训练我们的上下文模型。如第 3.4 节所述，我们不需要确保这些生成的轨迹在动力学甚至运动学上是可行的，因为环境动力学和任务规范（例如可行抓取）在推理时被定义为上下文。

偏差采样。为了更高效地学习通用技能，我们对采样过程进行偏置，使其更倾向于生成类似于抓取或拾放等常见任务的路径点。这并不要求创建动力学上可行的轨迹，而是需要设计针对路径点的采样策略，使其大致近似这些任务。例如，通过选择物体的特定部位，将仿真中的夹爪移动到该位置并闭合夹爪，即使抓取本身在物理上不可行，我们也能模拟抓取任务。我们为抓取、拾放、打开或关闭等常见任务设计了此类采样策略。一半的样本使用这些策略生成伪演示，其余样本则使用完全随机的路径点。

数据增强。为了促进所学策略涌现恢复行为，我们进一步对生成的轨迹进行增强。首先，对于 30% 的轨迹，我们添加与使机器人回到参考轨迹的动作相关的局部扰动，方式与 Zhou 等人 (2023) 类似。其次，对于 10% 的数据点，我们有意改变夹爪的开合状态。我们发现这一点至关重要，因为如果没有这种扰动，策略在初始闭合夹爪后将永远不会尝试重新抓取物体。

E 实现细节

这里我们讨论即时策略 (Instant Policy) 的实现细节，我们发现这些细节对于使方法表现良好至关重要。

演示处理。尽管我们的网络可以处理任意数量、任意长度的演示，但我们将演示轨迹下采样到固定长度（实验中为 $L = 10$ ）。首先，我们在仿真和真实世界中分别以 25Hz 和 10Hz 的速率记录演示。真实世界中速率较低是由于 Xmem++ (Bekuzarov 等人, 2023) 同时对感兴趣物体进行分割。然后，我们包含轨迹的起点和终点，以及所有夹爪开合状态发生变化的路径点。接着，我们包含轨迹中夹爪充分减速的路径点，这些点指示了重要的轨迹阶段（类似于 Shridhar 等人 (2023)）。最后，如果当前轨迹路径点的数量少于 L ，我们在已提取的路径点之间添加中间路径点。

数据增强。为了实现稳健的策略，我们发现训练期间对当前观测和后续动作进行随机化至关重要。网络容易对二值夹爪过拟合

状态（若为开启则保持开启，若为关闭则保持关闭）。为解决此问题，我们以 10% 的概率翻转当前用作模型输入的夹爪状态。这显著提升了所得策略的鲁棒性。此外，在伪演示生成过程中，我们对夹爪姿态添加了局部扰动（相应地调整点云观测与动作），进一步增强了鲁棒性并实现了恢复行为。

归一化。 我们将模型的所有输出归一化为 $[-1, 1]$ ，这一步骤被证明至关重要。为此，我们手动定义后续动作预测之间的最大末端执行器位移在平移上不超过 1cm ，旋转上不超过 3° ，并将噪声动作限制在此范围内。因此，流预测的上限至多为该范围的两倍。基于此，我们独立地将 $\nabla \hat{p}_t$ 和 $\nabla \hat{p}_r$ 归一化到 -1 与 1 之间，从而实现高效的网络训练。对于夹爪开合动作，这很容易实现，因为它们表示为二元状态 $\{0, 1\}$ 。我们不对点云观测的位置进行归一化，而是依赖正弦/余弦嵌入，这一策略被证明是足够的。

点云表示。 本文采用环境中感兴趣物体的分割点云观测作为观测数据。这些分割点云不包含机器人或其他静态物体（如桌面或干扰物）上的点。实际应用中，我们将点云下采样至 2048 个点，并在末端执行器坐标系中表示为 $T_{EW} \times F$ ，以获得更强的空间泛化能力。随后，这些点云通过几何编码器（详见第 A 节）处理，生成 $M = 16$ 个节点，用于构建本文设计的图表示。

动作去噪。 在去噪过程中更新 T_{EA} 时，我们使用计算得到的 $T_{k,k-1}$ （如第 3.3 节所述），并计算表示去噪过程中末端执行器动作的变换 T^{k-1} 。这些动作随后用于构建图表示，供下一步去噪使用。实际上，由于我们在末端执行器坐标系中表示点云观测，因此将这些动作的逆应用于表示场景的 M 点，并构建动作的局部图 G^a 。由于图中没有绝对位置， $l(T_{EA}^{-1} \times P, T_{WE}, a_g)$ 这等于将动作应用于夹爪姿态 T^t 但这允许我们在点云的新姿态下重新计算其几何嵌入，从而更好地匹配演示中的嵌入。

训练。 我们使用 AdamW (Loshchilov, 2017) 优化器训练模型，学习率为 $1e^{-5}$ ，共进行 250 万优化步（约在单张 NVIDIA GeForce RTX 3080-ti 上训练 5 天），随后进行 5 万步的学习率冷却期。为高效训练，我们使用 float16 精度，并利用 torch 编译功能编译模型 (Paszke et al., 2019)。训练数据以伪演示的形式在训练过程中持续生成，替换旧样本，确保模型不会多次看到同一数据点，从而防止过拟合。

F 仿真实验设置

在此，我们描述在标准 RLBench 设置 (James et al., 2020) 上进行实验时所做的两处修改。**1)** 我们仅使用笛卡尔空间规划生成所有演示（包括上下文演示和训练中使用的演示，如第 4 节所述），并舍弃了所有使用基于 RRT 的运动规划器 (Kuffner & LaValle, 2000) 生成的演示。这样做是为了确保演示中不包含任意运动，这些运动无法通过分割点云和末端执行器姿态的观测来捕捉。**2)** 我们将环境中物体的朝向限制在 $[-\pi/3, \pi/3]$ 范围内。这样做是为了使物体姿态分布与生成的伪演示中的分布相匹配，同时确保大多数任务无需依赖运动规划器的复杂运动即可完成。

G 失败案例

在此，我们讨论实验期间观察到的 Instant Policy 失败模式。鉴于设置和假设不同，我们分别对每个实验进行讨论。然而，所讨论的失败模式在各实验间是共通的。

模拟实验。在使用 RLBench (James 等人, 2020) 进行的模拟实验中, 我们观察到即时策略 (Instant Policy) 的几种常见失败模式。首先, 诸如打开微波炉或将雨伞放入架子等任务要求动作预测具有极高的精确率, 否则模拟器不精确的动力学特性将导致任务无法完成。因此, 有时微波炉的把手会从夹爪中滑落, 或者雨伞在与机器人接触时会飞走。其次, 诸如拨动开关或按下按钮等任务在任务条件满足后立即终止。由于我们在轨迹末端预测了不执行任何动作, 这导致策略在任务完全完成之前就停止了, 而停止时的状态与期望状态几乎相同。此外, 我们生成的伪演示不包含任何避碰机制, 这在诸如打开台灯等任务中已被证明是一个问题, 因为机器人有时会沿直线朝按钮移动而与台灯发生碰撞。最后, 其他失败模式通常包括策略在某个点停滞或在两个构型之间振荡。我们假设这种行为是由所提供的演示中的冲突信息以及违反马尔可夫假设引起的。未来, 可以通过将过去观测纳入图表示来解决这一问题。

现实世界任务。到目前为止, 在我们真实世界实验中最常见的失败模式是由多种遮挡引起的分割失败。此外, 不完美的分割有时会包含机器人或桌子的部分, 导致策略执行无关动作。这有时也会因包含无关点 (从而在构建的图中产生无关节点) 而降低演示的质量。此外, 我们观察到演示的整体质量 (在平滑性和明确指向的运动方面) 对即时策略的性能有重大影响。如果录制的演示包含不一致和任意的运动, 上下文中的信息就会相互冲突, 导致策略停滞或振荡。最后, 其他观察到的失败案例主要涉及由于缺乏精确率而导致策略未能完成任务。

对新几何形状的泛化。在推理阶段使用训练和演示中均未出现过的物体评估即时策略时, 策略有时仅模仿演示中观察到的动作, 而未达成预期结果。随着上下文中多样性演示数量的增加, 此类行为有所减少。然而, 某些任务 (例如将杯子放在盘子上) 的完成主要归因于任务本身的高容错性, 而非真正的泛化能力。

跨具身迁移。跨具身迁移实验中的主要失败案例源于手部姿态到末端执行器姿态的错误映射, 以及观测中视野不足。这导致机器人偶尔错过精确的抓取位置, 在非预期阶段闭合夹爪, 并总体上产生质量较差的演示。

模态迁移。在定性实验中, 用任务的语言描述替代演示取得了有前景的结果。然而, 观察到的行为有时与环境中的物体几何形状不匹配。例如, 策略会执行适当的动作 (如推动或关闭), 但相对于物体的位置不正确。此问题可能源于物体特征仅包含几何信息而缺乏语义上下文。将视觉基础模型的额外特征融入点云观测, 并扩展语言标注数据集, 有助于解决这一局限性。

未奏效的方法

此处讨论在确定第 3 节所述方法之前考虑过的各种设计选择。

全连接图。最初, 我们尝试了全连接图, 这实际上相当于具有密集自注意力的变换器。虽然注意力机制理论上应该能学习与任务相关的结构, 但这种方法即使在简单任务上也未能产生良好结果。

一个大网络。我们没有按顺序使用三个独立的网络 (如第 C 节所述), 而是尝试了一个更大的单一网络, 这导致性能显著下降。我们推测这是因为在早期, 节点缺乏足够的信息来推理动作, 导致大量计算被浪费, 并可能产生相互冲突的学习信号。

动作，导致大量计算被浪费，并可能产生相互冲突的学习信号。

更多夹爪节点。我们将机器人状态表示为图中的六个节点。理论上，我们可以使用任意数量（ > 3 ）的此类节点，从而更灵活地聚合相关信息。我们尝试了不同数量的此类节点，观察到性能变化极小，而计算需求显著增加。

无预训练几何编码器。在训练即时策略期间，我们保持几何编码器冻结。我们尝试从头端到端训练该模型，以及对其进行微调。从头训练完全无效，而微调导致性能显著下降。我们还尝试了更大尺寸的编码器，未见改进，这表明几何信息已经得到了很好的表示。

同构图。我们没有使用异构图 Transformer（Heterogeneous Graph Transformer）——它用不同的可学习权重集处理不同类型的节点和边——而是尝试了一种同构变体，在节点和边上添加不同的嵌入。在可训练参数数量相同的情况下，这种方法导致性能显著下降。这表明，通过不共享相同的权重，网络的不同部分可以更好地专注于聚合和解释相关信息，从而实现更高效的学习。

预测路径点。最初，我们尝试预测稀疏路径点，而不是低级动作（例如速度）来推进任务执行。我们发现，由于这些路径点代表较大的末端执行器位移，因此高精度地预测它们具有挑战性。直观地说，这是动作空间增大的结果，当归一化时，需要在区间 $[-1, 1]$ 中表示。

更大的学习率。在我们的实验中，我们使用了相对较小的学习率 $1e^{-5}$ 。为了加快训练过程，我们尝试增大学习率。然而，我们发现增大学习率后训练过程不稳定，导致梯度较大且训练损失增加。我们还尝试了几种不同的优化器，其中 AdamW（Loshchilov, 2017）带来了最佳性能。

I 跨具身迁移

如第 4.3.1 节所述，我们的方法允许使用一种具身（例如人手）提供演示，并在已知不同具身之间映射的情况下，立即在机器人上部署策略。这是因为我们的观测由分割的点云组成，不包含机器人及其末端执行器姿态上的点。因此，通过将人手姿态映射到机器人末端执行器姿态，我们可以有效地获得相同的观测。在我们的实验中，我们使用 Mediapipe（Lugaresi 等人, 2019）的手部关键点检测器实现这一映射，并手动设计这些关键点与相应机器人末端执行器姿态之间的映射。我们将末端执行器的位置建模为食指与拇指之间的中点位置，并利用手掌上的一个额外点估计方向。通过这种方式，我们有效地对 $\mathbb{S}^3(3)$ 手部姿态进行了过参数化，将其建模为平行夹爪，使用一组位置。这使我们能够完成简单任务，如抓取或拾放。然而，对于更精确的任务，这种粗略的映射可能不够。可以通过使用人手与机器人夹爪之间更精细的映射来解决，例如 Papagiannis 等人（2024）所做的工作。

J 模态迁移

使用我们的图表示以及第 C 节讨论的网络架构，会产生一个清晰的信息瓶颈，所有来自上下文的相关信息都聚合在一组特定的节点中（ $\phi(\mathcal{G}_c(\sigma(\mathcal{G}_t^t), \{\sigma(\mathcal{G}_t^{1:L})\}_1^N))$ ）。表示当前信息的图节点中所包含的信息，包含了计算适合当前情况的精确机器人动作所需的所有必要信息，而训练好的 $\psi(\cdot)$ 有能力做到这一点。我们利用这一瓶颈，并学习使用当前观测和任务的语言描述来近似它，同时利用冻结的 $\psi(\cdot)$ 以与上下文包含演示时相同的方式计算所需的机器人动作。我们使用局部图表示来学习这种近似。

当前观测的表示 G_t^t 以及由句向量模型 (Sentence-BERT) 生成的任务描述语言嵌入 f_{lang} , (Reimers, 2019)。本文采用图 Transformer 架构, 与用于学习 σ 的架构相似, 并将 f_{lang} 作为图中一种额外的节点类型纳入。本文利用一个语言标注数据集训练该网络, 该数据集包含来自 RLBench 的演示和本文实验中的轨迹, 并采用对比目标。在推理阶段, 本文提供任务的语言描述, 并根据当前观测计算上述瓶颈的嵌入。随后利用该嵌入计算机器人动作, 并以闭环方式执行, 从而实现对语言描述任务的零样本泛化。尽管仅使用小型语言标注数据集便展现出有前景的性能, 但通过将语义信息融入观测、采用变分学习框架以及扩大数据集规模, 仍可进一步提升性能。本文将这些研究留待未来工作。