

基于视频的潜在动作预训练

Seonghyeon Ye^{1*} Joel Jang^{2,†}
 Byeongguk Jeon¹ Sejune Joo¹ Jianwei Yang³ Baolin Peng³ Ajay Mandlekar⁴
 Reuben Tan³ Yu-Wei Chao⁴ Yuchen Lin⁵ Lars Liden³
 Kimin Lee^{1,§} Jianfeng Gao^{3,§} Luke Zettlemoyer^{2,§} Dieter Fox^{2,4,§} Minjoon Seo^{1,§}

¹ 韩国科学技术院 ² 华盛顿大学 ³ 微软研究院

⁴ NVIDIA ⁵ Allen Institute for AI

摘要

本文提出潜在动作预训练 (Latent Action Pretraining)，这是首个无需真实机器人动作标签即可预训练视觉-语言-动作 (VLA) 模型的无监督方法。现有的视觉-语言-动作模型在预训练阶段通常需要由人类遥操作员采集的动作标签，这极大地限制了数据来源与规模。本文提出一种从互联网规模视频中学习的方法，这些视频不包含机器人动作标签。首先训练一个基于 VQ-VAE 目标函数的动作量化模型，以学习图像帧之间的离散潜在动作；然后预训练一个潜在 VLA 模型，使其根据观测和任务描述预测这些潜在动作；最后在小规模机器人操作数据上微调 VLA，实现从潜在动作到机器人动作的映射。实验结果表明，本文方法显著优于现有利用大规模视频训练机器人操作策略的技术。此外，在需要语言条件、对未见物体的泛化以及对未见指令的语义泛化的真实世界操作任务上，本文方法超越了使用机器人动作标签训练的最先进 VLA 模型。仅在人类操作视频上训练也显示出正向迁移，为利用网络规模数据构建机器人基础模型开辟了潜力。我们将在 latentactionpretraining.github.io 开源模型检查点和代码。

1 引言

用于机器人技术的视觉-语言-动作模型 (VLA) (Brohan 等, 2023; Kim 等, 2024) 通过将大语言模型与视觉编码器对齐，然后在多样化的机器人数据集上进行微调来训练 (Collaboration 等, 2023)；这使得模型能够泛化到新颖指令、未见过的物体以及分布偏移 (Michał 等, 2024)。然而，多样化的真实世界机器人数据集大多需要人类遥操作，这使得规模化变得困难。另一方面，互联网视频数据提供了丰富的人类行为和物理交互示例，为克服小型、专用机器人数据集的局限性提供了一种有前景的方法 (Yang 等, 2024c)。然而，从互联网视频数据中学习面临两大挑战：首先，网络上的大量原始数据缺乏明确的动作标签；其次，网络数据分布与典型机器人系统的本体和环境存在根本性差异 (McCarthy 等, 2024)。我们提出潜在动作预训练 (Latent Action Pretraining)，这是一种无需真实机器人动作标签即可预训练机器人基础模型的无监督方法 (图 1)。

潜在动作预训练由两个顺序学习的模型组成，随后通过微调阶段将潜在动作映射到真实机器人动作。在第一个预训练阶段，我们使用

* 表示同等贡献。† 工作于微软研究院实习期间完成。

‡ 工作于英伟达实习期间完成。§ 表示同等指导。




图 1：问题表述。我们研究如何在没有动作标签的情况下，从人类运动视频构建通用机器人基础模型。

基于 VQ-VAE 的目标 (Van Den Oord 等, 2017) 来学习原始图像帧之间的量化潜在动作。类似于用于语言建模的字节对编码 (Sennrich 等, 2016)，这可以看作是在无需预定义动作先验 (例如末端执行器位置、关节位置) 的情况下学习对原子动作进行分词。在第二阶段，我们通过预训练视觉语言模型来执行行为克隆，该模型基于视频观察和任务描述预测第一阶段得到的潜在动作。最后，我们在一个小规模机器人操作数据集上使用机器人动作对模型进行微调，以学习从潜在动作到机器人动作的映射。在这项工作中，我们将得到的 VLA 模型称为 LAPA。

我们在多样化的操作视频上测量性能，包括现有的机器人视频数据集 (不使用真实动作) 和人类操作数据集。结果表明，所提方法显著优于不使用真实动作标签训练操作策略的基线方法，尤其是在跨环境和跨具身场景中。此外，在真实世界操作任务上，我们的方法催生了一个新的单体视觉语言动作模型，超越了当前最先进的视觉语言动作模型 OPENVLA，后者是在带有真实动作的多样化数据混合上训练的。这些结果证明了在不同具身机器人数据集上学习统一量化潜在动作表示的有效性 (见第 5.2 节)。我们进一步证明，即使仅在人类操作视频上预训练，潜在动作预训练仍然有效，优于在 Bridgev2 (Walke 等人, 2023) 上预训练的模型，Bridgev2 是最大的开源机器人数据集之一。我们观察到潜在动作预训练有效捕捉了以环境为中心的动作，包括物体和相机运动，这可能有利于下游任务，如导航或动态非准静态任务。我们期望我们的方法通过在更大规模的网络视频数据上预训练，为构建机器人基础模型开辟了潜力。

我们将主要贡献和发现总结如下：

- 我们提出潜在动作预训练，这是一种无监督方法，用于预训练机器人基础模型，以从网络规模视频数据中编码机器人技能。
- 在仿真和真实世界机器人任务上的实验表明，我们的方法不仅显著优于不使用真实动作标签预训练的机器人操作策略基线方法，而且还催生了一个视觉语言动作模型，其性能超越了当前使用真实动作训练的最先进视觉语言动作模型 (提升+6.22%)，同时实现了超过 30 倍的预训练效率提升。
- 我们定性证明，可以将潜在动作预训练用作动作预测模型，并将潜在动作量化模型的解码器用作世界模型，通过以当前观测和潜在动作预训练预测的潜在动作为条件预测未来帧，有效地构建一个完全通过神经推理执行闭环评估的神经仿真。

2 相关工作

视觉-语言-动作模型 视觉语言模型 (Vision-Language Models, VLMs) 在大规模互联网文本、图像和视频数据集上训练，已展现出强大的理解和生成文本及多模态数据的能力 (Liu et al., 2023; Team, 2024; Liu et al., 2024; Abdin et al., 2024)。利用这一优势，近期进展引入了单体视觉-语言-动作模型 (Vision-Language-Action Models, VLAs)，通过使用机器人动作数据对 VLMs 进行微调以增强物理基础 (Brohan et al., 2023; Kim et al., 2024; Team et al., 2024; Collaboration et al.,




图 2：潜动作预训练概述。（1）**潜动作量化**：我们首先使用 VQ-VAE 目标以完全无监督的方式学习离散潜动作（详见图 8）。（2）**潜预训练**：VLM 被训练来预测潜动作，本质上执行行为克隆。预训练后，我们在少量带动作标签的轨迹上微调 LAPA，将潜空间映射到末端执行器增量动作空间。

2023)。引入辅助目标，如视觉迹（Niu et al., 2024）、语言推理路径（Michał et al., 2024），或从机器人轨迹创建对话式指令数据集（Li et al., 2024a），进一步提升了 VLA 性能。然而，这些方法仍依赖于带标签的动作数据，限制了可扩展性。相比之下，本文方法通过仅在微调时需要带标签的动作，减少了对人类遥操作数据的依赖。

从视频训练机器人策略 视频为机器人学习提供了丰富的数据，但大多数缺乏动作标签（McCarthy 等, 2024）。相关工作在自我中心的人类视频上预训练视觉编码器（Grauman 等, 2022）以改进视觉表征（Nair 等, 2022; Dasari 等, 2023），或预训练视频生成模型以生成未来机器人轨迹（Wu 等, 2024; Liang 等, 2024; He 等, 2024）。方法还从人类视频中提取多样特征，如交互（Zeng 等, 2024）、可供性（Bahl 等, 2023; Kannan 等, 2023; Srirama 等, 2024; Shaw 等, 2023）或视觉轨迹（Wen 等, 2023; Bharadhwaj 等, 2024b）。一些工作将人类运动重定向到机器人动作，以创建涉及手部姿态估计器（Wang 等, 2023; Zhu 等, 2024; Shaw 等, 2023; Bharadhwaj 等, 2023; Ye 等, 2023; Qin 等, 2022）或运动捕捉系统（Yang 等, 2024a）的机器人策略；这些策略通常针对特定任务，或需要在同一环境中对齐人类与机器人数据。最后，一些工作训练逆动力学模型（IDM）、光流或强化学习模型，从世界模型生成的未来状态推演中预测动作（Du 等, 2023; Ko 等, 2024; Yang 等, 2024b; Bharadhwaj 等, 2024a），或使用 IDM 进行主动学习（Baker 等, 2022）。

潜动作 先前工作已在多种场景中采用潜动作。GENIE（Bruce 等, 2024）将用户输入（真实动作）映射到潜空间，使生成模型能够创建交互式环境。我们采用类似的潜动作模型，但将其应用于为无动作数据打标签，以训练一个统一的视觉-语言-动作模型来解决机器人任务。类似地，Edwards 等（2018）和 Schmidt 与 Jiang（2024）使用潜动作来预训练和微调视频游戏的策略（Cobbe 等, 2019）。相比之下，我们专注于从真实世界人类运动中学习潜动作，以应对更复杂、连续的机器人任务。与其他利用潜动作的工作不同——那些工作将真实动作转换为潜动作以更好地捕捉多模态性和任务语义（Lynch 等, 2020; Jiang 等, 2023; Lee 等, 2024; Mete 等, 2024）——我们的方法直接从观测中推导潜动作，而非从真实动作。

3 LAPA：面向通用动作模型的潜动作预训练

潜在动作预训练由两个顺序学习的模型组成：潜在动作量化和潜在预训练。整体流程如图 2 所示。注意，潜在动作量化和潜在预训练使用相同的预训练数据集。

3.1 潜在动作量化

为了以完全无监督的方式学习潜在动作，我们训练了一个潜在动作量化模型，该模型遵循 Bruce 等人 (2024) 的方法并做了一些修改。我们的潜在动作量化模型采用编码器-解码器架构，其中编码器接收视频中固定窗口大小 H 的当前帧 x_t 和未来帧 x_{t+H} ，并输出潜在动作 z_t^1 。解码器经过训练，接收潜在动作 z_t 和 x_t ，并重建 x_{t+H} 。与 Bruce 等人 (2024) 不同，我们使用交叉注意力在给定 x_t 的情况下关注 z_t ，而不是使用加性嵌入，经验表明这能捕获更具语义意义的潜在动作。我们的量化模型是 C-ViT 分词器 (Villegas 等人, 2023) 的一种变体，其中编码器同时包含空间和时间变换器，而解码器仅包含空间变换器，因为我们的模型仅使用两个图像帧作为输入。

我们的潜在动作量化训练模型基于 VQ-VAE 目标 (van den Oord 等人, 2017)，其中从连续嵌入中检索最近的量化表示，该嵌入空间中的每个嵌入对应一个码本。VQ-VAE 目标使潜在动作 z_t 成为离散标记 (码本)，便于视觉语言模型预测 z_t 。潜在动作使用来自 $|C|$ 码本词汇空间的 s 序列表示。序列长度 s 由 CNN 网络的核大小、步幅和填充值决定，该网络在向量量化过程之前使用。为避免 VQ-VAE 中常见的梯度崩溃，我们利用 NSVQ (Vali & Bäckström, 2022)，将向量量化误差替换为原始误差与归一化噪声向量的乘积。在解码过程中，我们还对帧 x_t 的补丁嵌入应用停止梯度，以避免表示崩溃。在早期训练步骤中应用 NSVQ 的码本替换技术，以最大化码本利用率。更多模型和训练细节见附录 A。

我们利用潜在动作量化模型的编码器作为潜在预训练中的逆动力学模型，并利用解码器生成基于神经网络的闭环推演。与先前工作 (Bruce et al., 2024; Valevski et al., 2024) 不同，本文方法通过潜在预训练同时训练一个从潜在动作生成推演的世界模型和一个产生这些潜在动作的策略模型。

3.2 潜在预训练

我们使用潜在动作量化模型的编码器作为逆动力学模型，为所有帧 x_t 标注潜在动作 z_t ，给定帧 x_{t+1} 。然后，我们进行动作预训练，使用预训练的视觉语言模型 (VLM) 根据视频片段的语言指令和当前图像 x_t 预测 z_t 。我们没有使用 VLM 现有的语言模型头，而是附加了一个独立的潜在动作头 (单层多层感知机)，其词汇表大小为 $|C|$ 。默认情况下，训练时仅冻结视觉编码器，解冻语言模型。由于潜在预训练不依赖真实动作，因此可以使用任何类型的原始视频与语言指令配对。此外，与机器人学中使用的传统动作粒度 (例如末端执行器位置、关节位置、关节力矩等) 相比，本文方法不需要任何关于动作层次/粒度的先验知识，而是通过优化以最佳捕捉给定视频数据集中连续观测的“增量”来端到端地学习。我们将经过潜在预训练的模型统称为 LAPA。

3.3 动作微调

预训练用于预测潜在动作的视觉语言动作模型 (VLA) 不能直接在真实机器人上执行，因为潜在动作不是实际的末端执行器增量动作或关节动作。为了将潜在动作映射到实际机器人动作，我们在包含真实动作 (末端执行器增量) 的少量标注轨迹上微调 LAPA。对于动作预测，我们按照 Kim et al. (2024); Brohan et al. (2023) 的方法，对机器人每个维度的连续动作空间进行离散化，使得每个区间分配的数据点数量相等。我们丢弃潜在动作头 (单层多层感知机)，并且

¹ 尽管 Bruce et al. (2024) 以多个过去观测为条件，但由于计算约束，我们排除了先前帧。我们将前置过去观测留作未来工作。

将其替换为一个新的动作头以生成真实动作。²。与潜在预训练相同，我们冻结视觉编码器并解冻底层语言模型的所有参数。³

4 实验

在本节中，我们展示了潜在动作预训练作为一种通用预训练方法的有效性。具体而言，我们重点回答以下问题：问题 1. 当预训练与微调之间存在跨任务、跨环境和跨具身差异时，潜在动作预训练的表现如何？问题 2. 在多具身设置下，与在预训练期间使用真实动作相比，潜在动作预训练能否学习到更优的先验？问题 3. 我们能否仅从原始人类操作视频中创建一个高性能的潜在动作预训练模型？

4.1 基准与环境

我们在 2 个不同的仿真环境和 3 个不同的真实世界机器人任务中，对 9 个不同任务类别评估了潜在动作预训练的有效性。表 3 展示了每种设置下预训练和微调数据集的概览，附录 B 中的图 9 可视化了仿真基准和真实世界设置。每个评估设置的更多细节见附录 B。

语言表 (Language Table) (Lynch 等人, 2023) 是一个仿真环境，其中机器人执行 2 自由度动作来推动方块（见图 9 (a)）。它包含 5 个子任务类别：方块到方块、方块到绝对位置、方块到方块相对位置、方块到相对位置以及分离。在评估期间，我们对已见和未见场景均评估模型，其中未见场景包括新物体（颜色和形状）以及已见物体的未见组合。

SIMPLER (Li 等人, 2024b) 是一组用于评估通用机器人操作策略的模拟环境。我们使用 7 自由度 WidowX 机械臂在 4 项任务上评估模型（图 9 (b)）。由于 SIMPLER 缺乏微调轨迹，我们利用在 BridgeV2 数据上训练成功的视觉语言动作模型 (VLA) 的部署结果，收集了 100 条多任务轨迹 (Walke 等, 2023)。

真实世界桌面操作 实验使用 7 自由度 Franka Emika Panda 机械臂在三个环境中进行（如图 9 (c) 所示）。我们利用三个预训练数据源：BridgeV2 (Walke 等, 2023)、Open-X (Collaboration 等, 2023) 和 Something Something v2 (Goyal 等, 2017)。遵循 Kim 等 (2024) 的方法，我们在三个多指令任务上进行微调：(1) ‘将 < 物体 > 放入水槽’，(2) ‘用毛巾盖住 < 物体 >’，以及 (3) ‘撞倒 < 物体 >’。每个任务涉及 15 个物体，共 150 条轨迹。我们使用任务特定的部分成功标准进行评估，遵循 Kim 等 (2024) 的方法。

4.2 基线

对于底层视觉语言模型，我们使用 7B 大型世界模型 (LWM-Chat-1M) (Liu 等, 2024)。

S CRATCH 表示基线模型，我们仅在下游任务上微调骨干视觉语言模型，以量化预训练阶段带来的增益。

U NIPI (Du 等人, 2023) 在预训练期间使用视频扩散模型，根据语言指令生成视频推演，这与我们的方法类似，在预训练期间不需要任何动作标签。在微调阶段，训练一个逆动力学模型 (IDM) 来提取给定相邻帧的真实动作。⁴ 我们还在下游任务上微调扩散模型，以匹配目标分布。

V PT (Baker 等人, 2022) 在带有动作标签的数据上训练一个 IDM，并使用该 IDM 模型在原始视频上提取伪动作。然后，我们使用 IDM 标注的伪动作在预训练数据上预训练我们的骨干 **VLM**，这与 LAPA 的潜在预训练相同。

² 我们还尝试保留潜在动作头，并添加额外的头来将潜在动作解码为真实动作，遵循 Schmidt 和 Jiang (2024) 的方法。然而，我们通过实验发现，重新初始化动作头能带来更优的下游任务性能，这可能是由于底层策略模型的规模 (7B) 所致。³ 我们将参数高效微调方法留作未来微调工作 (Hu 等人, 2022)。⁴ 我们不与 Yang 等人 (2024b) 进行比较，因为该模型未开源；也不与 Ko 等人 (2024) 进行比较，因为它不是行为克隆基线。

ACTIONVLA 表示在预训练期间使用真实机器人动作标签、并采用相同骨干 VLM 的基线。这可以视为上限，因为它利用了真实的标签。

OPENVLA (Kim 等人, 2024) 是一个最先进的 VLA 模型，在来自 **Open X-Embodiment** 数据集 (Collaboration 等人, 2023) 的 97 万个真实世界机器人演示上进行了预训练，这些演示主要通过人类遥操作收集。该模型的参数量与 LAPA (7B) 相当。我们通过在下游任务上微调预训练的 **OPENVLA**，将其与 **OPENVLA** 进行真实世界机器人实验的比较。

基线模型的更多细节见附录 C。

4.3 语言表结果

表 1：语言表结果。 平均成功率 (%) $\pm$ 标准误差，来自语言表基准中三种不同的预训练-微调组合，如表 3 所述。我们还注明了每个类别用于微调的轨迹数量。

	In-domain (1k)		Cross-task (7k)		Cross-env (1k)	
	Seen	Unseen	Seen	Unseen	Seen	Unseen
SCRATCH	15.6 $\pm$ 9.2	15.2 $\pm$ 8.3	27.2 $\pm$ 13.6	22.4 $\pm$ 11.0	15.6 $\pm$ 9.2	15.2 $\pm$ 8.3
UNIPI	22.0 $\pm$ 12.5	13.2 $\pm$ 7.7	20.8 $\pm$ 12.0	16.0 $\pm$ 9.1	13.6 $\pm$ 8.6	12.0 $\pm$ 7.5
VPT	44.0 $\pm$ 7.5	32.8 $\pm$ 4.6	72.0 $\pm$ 6.8	60.8 $\pm$ 6.6	18.0 $\pm$ 7.7	18.4 $\pm$ 9.7
LAPA	62.0 $\pm$ 8.7	49.6 $\pm$ 9.5	73.2 $\pm$ 6.8	54.8 $\pm$ 9.1	33.6 $\pm$ 12.7	29.6 $\pm$ 12.0
ACTIONVLA	77.0 $\pm$ 3.5	58.8 $\pm$ 6.6	77.0 $\pm$ 3.5	58.8 $\pm$ 6.6	64.8 $\pm$ 5.2	54.0 $\pm$ 7.0

域内性能 首先，我们评估 LAPA 从少量域内动作标签数据中学习的能力，通过在 181k 条轨迹上预训练并在 1k 条动作标记轨迹 (0.5%) 上微调。如表 1 所示，LAPA 大幅优于 SCRATCH，并缩小了与 ACTIONVLA 的差距，尽管在预训练期间未使用动作标签。此外，LAPA 超越了 UNIPI 和 VPT。值得注意的是，虽然 UNIPI 能很好地处理简单任务，但其扩散模型经常为长时程任务生成错误计划，这与 Du 等人 (2024) 的研究一致 (见附录 G.1 的图 17)。VPT 使用与 LAPA 相同的主干视觉语言模型，其表现优于 UNIPI，显示了视觉语言动作模型的优越性，但仍不及 LAPA，这凸显了潜在动作的有效性。

跨任务性能 我们研究 LAPA 在特定任务上微调后能否保留其广泛技能。在 181k 条轨迹上预训练 LAPA，并仅在单独任务 (7k) 上微调，我们评估所有 5 个任务类别，与域内设置类似，以评估潜在预训练对未见任务的益处。在表 1 和附录 G.1 的表 7、8 中比较 LAPA 和 SCRATCH 时，潜在预训练显著有益于单独任务以及其他 4 个任务类别，从而在已见和未见设置中均带来显著提升。与之前一样，UNIPI 受限于其扩散模型的规划局限性，而 VPT 表现强劲，甚至在未见设置中超越了 ACTIONVLA。这可能是由于使用了更多标记数据 (7k 对比 1k)，帮助逆动力学模型生成更准确的伪标签。

跨环境性能 我们进一步研究当预训练与微调环境不同时，潜在动作预训练是否有利于下游性能。我们在 44 万条真实世界轨迹上预训练潜在动作预训练模型，然后在 1 千条仿真轨迹上微调，这可以看作是在存在真实到仿真差距的设置下进行测试 (图 9 (a))。从表 1 中，我们观察到潜在动作预训练模型仍然显著优于从头训练模型，表明潜在预训练即使在跨环境设置下也能带来正向迁移。值得注意的是，统一策略推理模型和视频预训练模型均显著不如潜在动作预训练模型，表明学习预测潜在动作对跨环境迁移更为鲁棒。视频预训练模型仅带来轻微的正向迁移，表明逆动力学模型对环境变化不够鲁棒。

4.4 真实世界结果

我们在 (1) Bridgev2 (Walke 等, 2023) 上预训练模型，以衡量跨具身性能 (预训练使用 WidowX 具身，微调使用 Franka 具身)，并在 (2) Open X-Embodiment Dataset (Collaboration 等, 2023) 上预训练，以衡量在




图 3: 真实世界桌面操作结果。我们对每个模型共评估 54 次运行, 涵盖未见过的物体组合、未见过的物体和未见过的指令。显示平均成功率 (%) ± 标准误差 (详细结果见附录 G.3)。

表 2: 按评估类型划分的评估结果。我们根据要量化的能力, 对 3 个任务的成功率取平均: (1) 已见物体但未见组合, (2) 未见物体, 以及需要语义推理的新指令。最佳结果加粗, 次佳结果加下划线。

	Seen Obj. Unseen Combo	Unseen Obj.	Seen Obj. Unseen Instr.	AVG
SCRATCH	18.0	20.3	25.4	21.2
ACTIONVLA (Bridge)	38.3	31.8	27.7	32.6
OPENVLA (Bridge)	35.6	34.6	22.1	30.8
LAPA (Bridge)	43.4	31.4	35.6	36.8
OPENVLA (Open-X)	46.2	42.1	43.4	43.9
LAPA (Open-X)	57.8	43.9	48.5	50.1
LAPA (Human Videos)	36.5	37.4	28.1	34.0

多具身 设置。图 3 显示了 3 个任务的平均成功率, 每个任务涵盖未见物体组合、未见物体和未见指令设置。我们在表 2 中提供了按泛化类型划分的详细结果。

Bridgev2 预训练 我们比较了在 Bridgev2 数据集上预训练的模型。与之前的结果类似, 所有在 Bridgev2 上预训练的模型相比从头训练 (SCRATCH) 都带来了显著的性能提升。此外, 通过比较在预训练期间不利用动作标签轨迹的 LAPA 与在预训练期间使用动作标签轨迹的模型 (ACTIONVLA 和 OPENVLA), 我们发现了一个有趣的现象: 与之前以真实动作预训练的 VLA 作为性能上限的情况不同, LAPA 在 3 个任务的平均成功率上优于使用动作标签预训练数据的 VLA。LAPA 在抓取-放置任务中显著优于其他模型; 鉴于 Bridgev2 中的大多数任务都是抓取-放置任务, 我们假设在真实动作标签上预训练的 VLA 模型已经过拟合了 Bridgev2 数据集中 WidowX 的动作空间, 从而在微调期间阻碍了跨具身设置对动作分布偏移的适应性。相比之下, LAPA 通过在预训练期间不依赖真实动作标签来避免这个问题。

Open-X 预训练 从图 3 中, 我们看到在 Open-X 数据集上预训练的 VLA 优于在 Bridgev2 数据集上预训练的 VLA, 表明预训练期间的数据扩展对下游任务表现出正向迁移 (Collaboration et al., 2023)。这也表明, 当扩大预训练数据的多样性和规模时, 尤其是使用大规模网络视频数据, 可能会有显著的进一步改进。

当比较 LAPA 与 OPENVLA 时, 我们看到 LAPA 在 3 个任务中的 2 个上显著优于 OPENVLA (图 3)。此外, 如表 2 所示, LAPA (Open-X) 在所有类型的泛化设置上都优于 OpenVLA (Open-X)。这突显了 LAPA 在多具身设置中的有效性, 展示了其在预训练期间利用共享潜在动作空间的能力, 类似于语言和图像表征的利用方式。相比之下, 当代的动作预训练方法可能由于不同具身设置和数据集之间动作表征空间的可变性, 而在数据集之间遭受正向迁移的减少。

然而, 对于抓取-放置任务, LAPA 的表现不如 OPENVLA。我们观察到 LAPA 的大多数失败是由于过早抓取。实际上, LAPA 在到达性能上优于 OPENVLA (83.33% 对 66.67%) (每个任务的到达性能在附录 G.3 中单独提供)。

这表明，尽管潜在动作预训练（LAPA）具备更强的语言条件能力和粗粒度规划能力，但在抓取等技能方面仍有改进空间。由于抓取动作在每条轨迹中仅出现一两次，150 条带标签轨迹可能不足以让 LAPA 根据多样物体的物理特性准确预测抓取动作。

4.5 从人类操作视频中学习




图 4：从人类视频预训练的结果。在人类操作视频上预训练的 LAPA 与基线的平均成功率 (%) $\pm$ 标准误差，其中具身与环境差距极大。我们在仿真（左）和真实机器人设置（右）上进行评估。

本节展示将潜在动作预训练扩展到人类操作视频的结果，这与本工作的主要动机一致。与机器人轨迹不同，人类视频面临两个挑战：人类视频不包含动作标签，且人类视频的分布与机器人具身不同（McCarthy 等，2024）。我们尝试通过在 Something-Something V2 数据集（Goyal 等，2017）上预训练来探究我们的方法及基线方法能否应对这些挑战，该数据集包含 22 万段人类使用日常物品执行动作的视频。

我们首先在 SIMPLER 上评估在人类视频上预训练的 LAPA 的性能。除 SCRATCH 外，我们还与使用相同人类视频数据集预训练的 UNIFI 和 VPT 进行比较。如图 4a 所示，LAPA 优于 SCRATCH，表明尽管预训练数据的分布与部署设置不同，利用人类视频进行潜在动作预训练仍能带来正向迁移。此外，LAPA 通过超越 UNIFI 和 VPT 取得最佳性能，意味着潜在动作预训练对人类到机器人的具身变化具有鲁棒性。注意，由于人类视频不包含任何机器人动作标签，无法训练 ACTIONVLA。

我们在图 4b 中报告了真实世界机器人实验。令人惊讶的是，我们可以看到使用人类视频训练的 LAPA 平均性能优于 OPENVLA（Bridge）。尽管 LAPA 的具身差距更大（人类到机器人对比机器人到机器人），但它学到了更好的机器人操作先验。此外，如表 2 所示，LAPA（人类视频）展示了良好的泛化性能，尤其是对于未见过的物体。我们推测这是因为 Something Something V2 数据集与 Bridgev2 相比，交互的物体更加多样化。这一结果突显了来自网络的原始人类操作视频相对于昂贵的机器人操作数据（需要耗时的遥操作来收集）的潜力。我们期望将我们的方法应用于大规模互联网视频（例如 YouTube 视频）可以解锁通用动作基础模型的大规模预训练潜力，类似于自然语言处理或计算机视觉中的基础模型。

4.6 预训练效率

LAPA 的优势不仅限于下游任务性能，还包括预训练效率。对于预训练性能最佳的模型 LAPA（Open-X），我们使用 8 块 H100 GPU 训练 34 小时，批大小为 128（总计 272 H100 小时）。相比之下，OPENVLA 需要总计 21,500 A100 小时，批大小为 2048。尽管预训练效率大约高出 30-40 倍，LAPA 仍然优于 OPENVLA⁵。

⁵ 我们基于 H100 GPU 训练速度比 A100 GPU 快 2-3 倍这一事实进行计算。

我们认为这种效率源于两个因素：（1）使用大世界模型（Large World Model, Liu et al., 2024）作为骨干视觉语言模型（VLM），以及（2）与传统的动作预训练相比，LAPA 的粗粒度动作。首先，LWM 预训练期间的训练目标包括生成下一个状态，这对应于视频中的下一帧。我们假设这一目标使模型能够隐式理解视频中的高层动作。值得注意的是，使用 LWM 作为骨干的 ACTIONVLA（Bridge）和使用 Prismatic 作为骨干的 OPENVLA（Bridge）在相同的数据和目标上进行训练。然而，ACTIONVLA 在显著更少的训练轮次（3 轮）内达到最佳性能（就动作标记准确率而言），而 OPENVLA 需要 30 轮。其次，LAPA 的动作空间远小于 OPENVLA（ 8^4 vs. 256^7 ），这使得学习感知和语言到动作生成问题更容易学习。对于所有 LAPA 模型（BridgeV2、Open-X、人类视频），我们观察到单个训练轮次就足以达到最佳性能。

5 消融与分析

5.1 模型、数据与潜在动作规模的缩放




图 5: LAPA 的缩放消融结果。我们缩放 LAPA 的 4 个维度：模型参数量（以百万计）、数据规模（BridgeV2 中的比例）、潜在动作序列长度和词汇表大小，并展示在 SIMPLER 微调任务上的下游平均成功率（%）。

大语言模型（Large Language Models, LLMs）已展现出缩放定律（Kaplan et al., 2020），即性能随着模型规模、数据集规模和训练所用计算资源的增加而提升。类似地，我们尝试分析 LAPA 是否在三个维度上受益于缩放：潜在动作量化模型规模、数据规模和潜在动作表示空间。为了进行受控设置，我们将方法应用于 BridgeV2，然后在 SIMPLER 上进行微调，图 5c 中的语言表结果除外。

如图 5 所示，扩展规模在三个维度上均有益于 LAPA。有趣的是，我们观察到潜在动作空间的最优规模取决于预训练数据集所包含动作维度的复杂度。例如，对于语言表（Language Table），增加潜在动作序列长度相比增加词汇量效果较差（图 16）。除语言表外，我们在所有主要实验中均将 LAPA 的生成空间维持在 8^4 。这些结果表明，当将预训练扩展到超越操作视频的互联网规模视频时，在模型、数据集和潜在动作空间方面扩展 LAPA 可以提升性能，尤其是在捕捉更高动作维度（如全身控制）方面。

5.2 潜在动作分析

我们定性分析了量化潜在动作与真实连续动作的对齐情况。为了进行解释，我们将当前图像观测 x_1 和每个潜在动作输入到潜在动作量化模型的解码器中，并展示重建图像。

在语言表中，我们观察到每个潜在动作对应机器人手臂的一种独特运动，且潜在动作的分布在真实二维动作空间中聚类良好（见附录 E 的图 12、图 13）。接下来，对于人类操作视频，我们观察到相机视角也对应一个潜在动作，因为视频内的视角会发生变化（见附录 E 的图 14）。我们还分析了从 Open-X 实体学到的潜在动作，该实体包含多种实体、任务和环境。如图 6 所示，即使实体和环境不同，以相同的潜在




图 6：潜在动作分析。我们将当前观测 x_1 和量化潜在动作输入到潜在动作量化模型的解码器中。我们观察到每个潜在动作都可以映射到一个语义动作。例如，潜在动作 $[1,1,3,2]$ 对应向下和向左移动，而 $[3,2,0,1]$ 对应稍微向上移动。

动作进行条件化，重建图像中也会产生相似的动作。这支持了我们之前的观点，即潜在动作是在共享表示空间中学习的，无论实体或数据集如何，从而促进跨不同数据集的更强正迁移。




图 7：LAPA 的闭环展开。LAPA 以当前图像 x_1 和语言指令“将西兰花从锅中取出”为条件。我们通过以 LAPA 生成的潜在动作为条件，对潜在动作量化模型的解码器进行条件化，从而生成展开图像。我们还通过闭环展开对 LAPA 的粗粒度规划能力进行了定性分析。我们使用仅经过预训练、未进行任何动作微调的 LAPA 模型。由于该模型生成的潜在动作无法直接在现实世界中执行，我们以当前观测 x_1 和 LAPA 预测的潜在动作为条件，对潜在动作量化模型的解码器进行条件化。如图 7 所示，当以当前观测和指令“将西兰花从锅中取出”为条件时，LAPA 生成的机器人轨迹能够成功伸向西兰花，向下移动以抓取它，并且当机械臂远离锅时，西兰花消失。这表明 LAPA 具有作为通用机器人世界模型的潜力，不仅能预测动作，还能预测动作的结果。例如，这可以促使 LAPA 扩展为任务与运动规划系统，在该系统中，它首先根据自然语言任务指令生成多个计划，基于量化多个轨迹候选中成功率的方法选择最优轨迹（Hwang 等人，2024；Duan 等人，2024），并执行开环/闭环推理。这可以引领一种范式，即我们旨在通过扩展测试时计算来提升性能，如同大语言模型（Snell 等人，2024）那样。

6 局限性与结论

在本文中，我们介绍了潜在动作预训练，这是一种可扩展的预训练方法，用于在不使用真实动作标签的情况下构建视觉语言动作模型。在涵盖仿真和真实世界机器人实验的三个基准上，我们表明与现有方法相比，我们的方法显著提升了对下游任务的迁移能力。我们还提出了一个最先进的视觉语言动作模型，该模型超越了当前在 97 万条动作标注轨迹上训练的模型。此外，我们证明了我们的方法可以纯粹应用于人类操作视频，在这些视频中显式动作信息缺失，且具身差距显著。

本文仍面临若干局限性。首先，在细粒度运动生成任务（如抓取）方面，潜在动作预训练（LAPA）的表现不及动作预训练。我们认为，扩大潜在动作生成空间可能有助于解决这一问题。其次，与先前视觉-语言-动作模型（VLA）类似，LAPA 在实时推理过程中也面临延迟挑战。采用分层架构，由较小的头部以更高频率预测动作。最后，尽管我们定性展示了潜在动作空间能够捕捉相机运动（图 14），但尚未探索 LAPA 在操作视频之外的应用，例如自动驾驶汽车、导航或风景场景。我们将这些探索留待未来工作。

致谢

我们感谢 Arhan Jain 和 Marius Memmel 在机器人硬件与遥操作设置方面提供的帮助。同时, 感谢 Minyoung Hwang、Jiafei Duan、Junsu Kim 和 Changyeon Kim 给予的有益讨论与建设性反馈。本工作部分由韩国科学技术院 (KAIST) 先进城市系统中心 (CAUS) 资助, 该中心由 GS E&C 提供支持 (40%); 并受韩国政府 (MSIT) 资助的信息与通信技术规划与评估研究院 (IITP) 拨款支持 (RS-2024-00397966, 开发用于抑制生成式人工智能故障的网络安全专用 RAG 型小语言模型及公共演示平台建设, 30%; No.RS-2022-II220264, 基于知识的深度逻辑神经网络的综合视频理解与生成, 20%; No.RS-2021-II212068, 人工智能创新中心, 10%)。

参考文献

- Marah Abidin, Sam Ade Jacobs, Ammar Ahmad Awan, Jyoti Aneja, Ahmed Awadallah, Hany Awadalla, Nguyen Bach, Amit Bahree, Arash Bakhtiari, Harkirat Behl, et al. Phi-3 technical report: A highly capable language model locally on your phone. *arXiv preprint arXiv:2404.14219*, 2024.
- Shikhar Bahl, Russell Mendonca, Lili Chen, Unnat Jain, and Deepak Pathak. Affordances from human videos as a versatile representation for robotics. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2023.
- Bowen Baker, Ilge Akkaya, Peter Zhokov, Joost Huizinga, Jie Tang, Adrien Ecoffet, Brandon Houghton, Raul Sampedro, and Jeff Clune. Video pretraining (vpt): Learning to act by watching unlabeled online videos. In *Advances in Neural Information Processing Systems*, 2022.
- Suneel Belkhal, Tianli Ding, Ted Xiao, Pierre Sermanet, Quon Vuong, Jonathan Tompson, Yevgen Chebotar, Debidatta Dwibedi, and Dorsa Sadigh. Rt-h: Action hierarchies using language. *arXiv preprint arXiv:2403.01823*, 2024.
- Homanga Bharadhwaj, Abhinav Gupta, Shubham Tulsiani, and Vikash Kumar. Zero-shot robot manipulation from passive human videos. *arXiv preprint arXiv:2302.02011*, 2023.
- Homanga Bharadhwaj, Debidatta Dwibedi, Abhinav Gupta, Shubham Tulsiani, Carl Doersch, Ted Xiao, Dhruv Shah, Fei Xia, Dorsa Sadigh, and Sean Kirmani. Gen2act: Human video generation in novel scenarios enables generalizable robot manipulation. *arXiv preprint arXiv:2409.16283*, 2024a.
- Homanga Bharadhwaj, Roozbeh Mottaghi, Abhinav Gupta, and Shubham Tulsiani. Track2act: Predicting point tracks from internet videos enables diverse zero-shot robot manipulation. *arXiv preprint arXiv:2405.01527*, 2024b.
- Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Xi Chen, Krzysztof Choromanski, Tianli Ding, Danny Driess, Avinava Dubey, Chelsea Finn, et al. Rt-2: Vision-language-action models transfer web knowledge to robotic control. *arXiv preprint arXiv:2307.15818*, 2023.
- Jake Bruce, Michael D Dennis, Ashley Edwards, Jack Parker-Holder, Yuge Shi, Edward Hughes, Matthew Lai, Aditi Mavalankar, Richie Steigerwald, Chris Apps, et al. Genie: Generative interactive environments. In *Forty-first International Conference on Machine Learning*, 2024.
- Karl Cobbe, Christopher Hesse, Jacob Hilton, and John Schulman. Leveraging procedural generation to benchmark reinforcement learning. *arXiv preprint arXiv:1912.01588*, 2019.
- OX-Embodiment Collaboration, A Padalkar, A Pooley, A Jain, A Bewley, A Herzog, A Irpan, A Khazatsky, A Rai, A Singh, et al. Open x-embodiment: Robotic learning datasets and rt-x models. *arXiv preprint arXiv:2310.08864*, 2023.
- Sudeep Dasari, Mohan Kumar Srirama, Unnat Jain, and Abhinav Gupta. An unbiased look at datasets for visuo-motor pre-training. In *Conference on Robot Learning*, 2023.

- Yilun Du, Sherry Yang, Bo Dai, Hanjun Dai, Ofir Nachum, Joshua B. Tenenbaum, Dale Schuurmans, and Pieter Abbeel. Learning universal policies via text-guided video generation. In *Thirty-seventh Conference on Neural Information Processing Systems*, 2023.
- Yilun Du, Sherry Yang, Pete Florence, Fei Xia, Ayzaan Wahid, brian ichter, Pierre Sermanet, Tianhe Yu, Pieter Abbeel, Joshua B. Tenenbaum, Leslie Pack Kaelbling, Andy Zeng, and Jonathan Tompson. Video language planning. In *The Twelfth International Conference on Learning Representations*, 2024.
- Jiafei Duan, Wilbert Pumacay, Nishanth Kumar, Yi Ru Wang, Shulin Tian, Wentao Yuan, Ranjay Krishna, Dieter Fox, Ajay Mandlekar, and Yijie Guo. Aha: A vision-language-model for detecting and reasoning over failures in robotic manipulation, 2024.
- Ashley D Edwards, Himanshu Sahni, Yannick Schroecker, and Charles L Isbell. Imitating latent policies from observation. *arXiv preprint arXiv:1805.07914*, 2018.
- Raghav Goyal, Samira Ebrahimi Kahou, Vincent Michalski, Joanna Materzynska, Susanne Westphal, Heuna Kim, Valentin Haenel, Ingo Fruend, Peter Yianilos, Moritz Mueller-Freitag, et al. The” something something” video database for learning and evaluating visual common sense. In *Proceedings of the IEEE international conference on computer vision*, 2017.
- Kristen Grauman, Andrew Westbury, Eugene Byrne, Zachary Chavis, Antonino Furnari, Rohit Girdhar, Jackson Hamburger, Hao Jiang, Miao Liu, Xingyu Liu, et al. Ego4d: Around the world in 3,000 hours of egocentric video. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2022.
- Haoran He, Chenjia Bai, Ling Pan, Weinan Zhang, Bin Zhao, and Xuelong Li. Learning an actionable discrete diffusion policy via large-scale actionless video pre-training. In *Advances in Neural Information Processing Systems*, 2024.
- Edward J Hu, yelong shen, Phillip Wallis, Zeyuan Allen-Zhu, Yanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. LoRA: Low-rank adaptation of large language models. In *International Conference on Learning Representations*, 2022.
- Minyoung Hwang, Joey Hejna, Dorsa Sadigh, and Yonatan Bisk. Motif: Motion instruction fine-tuning. *arXiv preprint arXiv:2409.10683*, 2024.
- Zhengyao Jiang, Yingchen Xu, Nolan Wagener, Yicheng Luo, Michael Janner, Edward Grefenstette, Tim Rocktäschel, and Yuandong Tian. H-gap: Humanoid control with a generalist planner. *arXiv preprint arXiv:2312.02682*, 2023.
- Aditya Kannan, Kenneth Shaw, Shikhar Bahl, Pragna Mannam, and Deepak Pathak. Deft: Dexterous fine-tuning for real-world hand policies. *arXiv preprint arXiv:2310.19797*, 2023.
- Jared Kaplan, Sam McCandlish, Tom Henighan, Tom B Brown, Benjamin Chess, Rewon Child, Scott Gray, Alec Radford, Jeffrey Wu, and Dario Amodei. Scaling laws for neural language models. *arXiv preprint arXiv:2001.08361*, 2020.
- Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, Ted Xiao, Ashwin Balakrishna, Suraj Nair, Rafael Rafailov, Ethan Foster, Grace Lam, Pannag Sanketi, et al. Openvla: An open-source vision-language-action model. *arXiv preprint arXiv:2406.09246*, 2024.
- Po-Chen Ko, Jiayuan Mao, Yilun Du, Shao-Hua Sun, and Joshua B. Tenenbaum. Learning to act from actionless videos through dense correspondences. In *The Twelfth International Conference on Learning Representations*, 2024.
- Hadas Kress-Gazit, Kunimatsu Hashimoto, Naveen Kuppaswamy, Paarth Shah, Phoebe Horgan, Gordon Richardson, Siyuan Feng, and Benjamin Burchfiel. Robot learning as an empirical science: Best practices for policy evaluation. *arXiv preprint arXiv:2409.09491*, 2024.
- Seungjae Lee, Yibin Wang, Haritheja Etukuru, H Jin Kim, Nur Muhammad Mahi Shafiullah, and Lerrel Pinto. Behavior generation with latent actions. *arXiv preprint arXiv:2403.03181*, 2024.

- Xiang Li, Cristina Mata, Jongwoo Park, Kumara Kahatapitiya, Yoo Sung Jang, Jinghuan Shang, Kanchana Ranasinghe, Ryan Burgert, Mu Cai, Yong Jae Lee, et al. Llara: Supercharging robot learning data for vision-language policy. *arXiv preprint arXiv:2406.20095*, 2024a.
- Xuanlin Li, Kyle Hsu, Jiayuan Gu, Karl Pertsch, Oier Mees, Homer Rich Walke, Chuyuan Fu, Ishikaa Lunawat, Isabel Sieh, Sean Kirmani, et al. Evaluating real-world robot manipulation policies in simulation. *arXiv preprint arXiv:2405.05941*, 2024b.
- Junbang Liang, Ruoshi Liu, Ege Ozguroglu, Sruthi Sudhakar, Achal Dave, Pavel Tokmakov, Shuran Song, and Carl Vondrick. Dreamitate: Real-world visuomotor policy learning via video generation. *arXiv preprint arXiv:2406.16862*, 2024.
- Hao Liu, Wilson Yan, Matei Zaharia, and Pieter Abbeel. World model on million-length video and language with ringattention. *arXiv preprint arXiv:2402.08268*, 2024.
- Haotian Liu, Chunyuan Li, Qingyang Wu, and Yong Jae Lee. Visual instruction tuning. In *Thirty-seventh Conference on Neural Information Processing Systems*, 2023.
- Corey Lynch, Mohi Khansari, Ted Xiao, Vikash Kumar, Jonathan Tompson, Sergey Levine, and Pierre Sermanet. Learning latent plans from play. In *Conference on robot learning*, pp. 1113–1132. PMLR, 2020.
- Corey Lynch, Ayzaan Wahid, Jonathan Tompson, Tianli Ding, James Betker, Robert Baruch, Travis Armstrong, and Pete Florence. Interactive language: Talking to robots in real time. *IEEE Robotics and Automation Letters*, pp. 1–8, 2023. doi: 10.1109/LRA.2023.3295255.
- Robert McCarthy, Daniel CH Tan, Dominik Schmidt, Fernando Acero, Nathan Herr, Yilun Du, Thomas G Thuruthel, and Zhibin Li. Towards generalist robot learning from internet video: A survey. *arXiv preprint arXiv:2404.19664*, 2024.
- Atharva Mete, Haotian Xue, Albert Wilcox, Yongxin Chen, and Animesh Garg. Quest: Self-supervised skill abstractions for learning continuous control. *arXiv preprint arXiv:2407.15840*, 2024.
- Zawalski Michał, Chen William, Pertsch Karl, Mees Oier, Finn Chelsea, and Levine Sergey. Robotic control via embodied chain-of-thought reasoning. *arXiv preprint arXiv:2407.08693*, 2024.
- Suraj Nair, Aravind Rajeswaran, Vikash Kumar, Chelsea Finn, and Abhinav Gupta. R3m: A universal visual representation for robot manipulation. *arXiv preprint arXiv:2203.12601*, 2022.
- Dantong Niu, Yuvan Sharma, Giscard Biamby, Jerome Quenum, Yutong Bai, Baifeng Shi, Trevor Darrell, and Roei Herzig. Llarva: Vision-action instruction tuning enhances robot learning. *arXiv preprint arXiv:2406.11815*, 2024.
- Yuzhe Qin, Yueh-Hua Wu, Shaowei Liu, Hanwen Jiang, Ruihan Yang, Yang Fu, and Xiaolong Wang. Dexmv: Imitation learning for dexterous manipulation from human videos. In *European Conference on Computer Vision*, 2022.
- Dominik Schmidt and Minqi Jiang. Learning to act without actions. In *The Twelfth International Conference on Learning Representations*, 2024.
- Rico Sennrich, Barry Haddow, and Alexandra Birch. Neural machine translation of rare words with subword units. In *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 2016.
- Kenneth Shaw, Shikhar Bahl, and Deepak Pathak. Videodex: Learning dexterity from internet videos. In *Conference on Robot Learning*, 2023.
- Charlie Snell, Jaehoon Lee, Kelvin Xu, and Aviral Kumar. Scaling llm test-time compute optimally can be more effective than scaling model parameters. *arXiv preprint arXiv:2408.03314*, 2024.
- Mohan Kumar Srirama, Sudeep Dasari, Shikhar Bahl, and Abhinav Gupta. Hrp: Human affordances for robotic pre-training. *arXiv preprint arXiv:2407.18911*, 2024.

- Chameleon Team. Chameleon: Mixed-modal early-fusion foundation models. *arXiv preprint arXiv:2405.09818*, 2024.
- Octo Model Team, Dibya Ghosh, Homer Walke, Karl Pertsch, Kevin Black, Oier Mees, Sudeep Dasari, Joey Hejna, Tobias Kreiman, Charles Xu, et al. Octo: An open-source generalist robot policy. *arXiv preprint arXiv:2405.12213*, 2024.
- Dani Valevski, Yaniv Leviathan, Moab Arar, and Shlomi Fruchter. Diffusion models are real-time game engines. *arXiv preprint arXiv:2408.14837*, 2024.
- Mohammad Hassan Vali and Tom Bäckström. Nsvq: Noise substitution in vector quantization for machine learning. *IEEE Access*, 10:13598–13610, 2022. doi: 10.1109/ACCESS.2022.3147670.
- Aaron van den Oord, Oriol Vinyals, and koray kavukcuoglu. Neural discrete representation learning. In *Advances in Neural Information Processing Systems*, 2017.
- Aaron Van Den Oord, Oriol Vinyals, et al. Neural discrete representation learning. *Advances in neural information processing systems*, 30, 2017.
- Ruben Villegas, Mohammad Babaeizadeh, Pieter-Jan Kindermans, Hernan Moraldo, Han Zhang, Mohammad Taghi Saffar, Santiago Castro, Julius Kunze, and Dumitru Erhan. Phenaki: Variable length video generation from open domain textual descriptions. In *International Conference on Learning Representations*, 2022.
- Ruben Villegas, Mohammad Babaeizadeh, Pieter-Jan Kindermans, Hernan Moraldo, Han Zhang, Mohammad Taghi Saffar, Santiago Castro, Julius Kunze, and Dumitru Erhan. Phenaki: Variable length video generation from open domain textual descriptions. In *International Conference on Learning Representations*, 2023.
- Homer Rich Walke, Kevin Black, Tony Z Zhao, Quan Vuong, Chongyi Zheng, Philippe Hansen-Estruch, Andre Wang He, Vivek Myers, Moo Jin Kim, Max Du, et al. Bridgedata v2: A dataset for robot learning at scale. In *Conference on Robot Learning*, 2023.
- Chen Wang, Linxi Fan, Jiankai Sun, Ruohan Zhang, Li Fei-Fei, Danfei Xu, Yuke Zhu, and Anima Anandkumar. Mimicplay: Long-horizon imitation learning by watching human play. *arXiv preprint arXiv:2302.12422*, 2023.
- Chuan Wen, Xingyu Lin, John So, Kai Chen, Qi Dou, Yang Gao, and Pieter Abbeel. Any-point trajectory modeling for policy learning. *arXiv preprint arXiv:2401.00025*, 2023.
- Hongtao Wu, Ya Jing, Chilam Cheang, Guangzeng Chen, Jiafeng Xu, Xinghang Li, Minghuan Liu, Hang Li, and Tao Kong. Unleashing large-scale video generative pre-training for visual robot manipulation. In *The Twelfth International Conference on Learning Representations*, 2024.
- Jingyun Yang, Zi-ang Cao, Congyue Deng, Rika Antonova, Shuran Song, and Jeannette Bohg. Equibot: Sim (3)-equivariant diffusion policy for generalizable and data efficient learning. *arXiv preprint arXiv:2407.01479*, 2024a.
- Sherry Yang, Yilun Du, Seyed Kamyar Seyed Ghasemipour, Jonathan Tompson, Leslie Pack Kaelbling, Dale Schuurmans, and Pieter Abbeel. Learning interactive real-world simulators. In *The Twelfth International Conference on Learning Representations*, 2024b.
- Sherry Yang, Jacob C Walker, Jack Parker-Holder, Yilun Du, Jake Bruce, Andre Barreto, Pieter Abbeel, and Dale Schuurmans. Position: Video as the new language for real-world decision making. In *Proceedings of the 41st International Conference on Machine Learning*, 2024c.
- Jianglong Ye, Jiashun Wang, Binghao Huang, Yuzhe Qin, and Xiaolong Wang. Learning continuous grasping function with a dexterous hand from human demonstrations. *IEEE Robotics and Automation Letters*, 8(5):2882–2889, 2023.
- Jia Zeng, Qingwen Bu, Bangjun Wang, Wenke Xia, Li Chen, Hao Dong, Haoming Song, Dong Wang, Di Hu, Ping Luo, et al. Learning manipulation by predicting interaction. *arXiv preprint arXiv:2406.00439*, 2024.
- Yifeng Zhu, Arisrei Lim, Peter Stone, and Yuke Zhu. Vision-based manipulation from single human video with open-world object graphs. *arXiv preprint arXiv:2405.20321*, 2024.

A 潜在动作量化细节




图 8: 潜在动作量化模型的模型架构。

我们在图 8 中展示了潜在动作量化模型的架构细节。我们利用 Villegas 等人 (2022) 提出的 C-ViViT 模型架构来复现 GENIE (Bruce 等人, 2024) 中的潜在动作模型。在编码过程中, x_1 和 x_2 都经过块嵌入得到 p_1 和 p_2 , 并经过空间变换器。为了传递时间信息, 空间变换器两个输出的表示被传入因果变换器 (带有因果位置编码的变换器), 得到 e_1 和 e_2 连续嵌入。然后我们定义 $d_1 = e_2 - e_1$, 并通过从码本 z 中寻找最接近的嵌入来离散化 d_1 , 其中码本大小作为超参数确定。

$$z_1 = \arg \min_{z_k} |d_1 - z_k|^2 \quad (1)$$

在获取 e_1 和 e_2 时, 我们经过一个卷积神经网络。序列长度由卷积神经网络的核大小、步长和填充值决定。量化后, 我们在解码前应用 NSVQ 技术。

$$\hat{d}_1 = d_1 + \frac{\|d_1 - z_1\|}{\|v\|} v \quad (2)$$

其中 $v \sim \mathcal{N}(0, 1)$ 。对于解码, 我们经过以下方程:

$$\hat{x}_2 = D(\text{Attn}(sg[p_1], \hat{d}_1, \hat{d}_1)) \quad (3)$$

其中停止梯度 (sg) 应用于 p_1 以避免表示坍塌, 并使用交叉注意力在给定 p_1 的情况下关注 $\hat{d}_1$ 。与编码器不同, 解码器 D 仅包含空间变换器。训练目标是 L2 重建损失。

$$L = \|x_2 - \hat{x}_2\|_2^2 \quad (4)$$

表 3：每个环境的预训练和微调数据集。 Cross-Env 表示跨环境，Cross-Emb 表示跨具身，Multi-Emb 表示多具身。对于微调，MT 表示多任务训练，MI 表示具有多样化多指令的任务。类别表示我们试图量化的主要能力。

Environment	Category	Pretraining		Fine-tuning	
		Dataset	# Trajs	Dataset	# Trajs
LangTable	In-Domain	Sim (All 5 tasks)	181k	5 Tasks (MT, MI)	1k
	Cross-Task	Sim (All 5 tasks)	181k	1 Task (MI)	7k
	Cross-Env	Real (All 5 tasks)	442k	5 tasks (MT, MI)	1k
SIMPLER	In-Domain	Bridgev2	60k	4 Tasks (MT)	100
	Cross-Emb	Something v2	200k	4 Tasks (MT)	100
Real-World	Cross-Emb	Bridgev2	60k	3 tasks (MI)	450
	Multi-Emb	Open-X	970k	3 tasks (MI)	450
	Cross-Emb	Something v2	200k	3 tasks (MI)	450

潜在模型训练后，我们利用 z_1 作为 x_1 的潜在动作标签。编码器可视作逆动力学模型，解码器可视为世界模型。

B 实验设置细节




图 9：实验设置。 (a) 展示了来自语言表基准的 44 万条真实世界轨迹（上）和 18.1 万条仿真轨迹（下）的示例。(b) 展示了我们在 SIMPLER 环境中使用的 4 个不同评估任务。(c) 展示了我们在真实世界中执行的三个不同任务。

语言表实验设置 语言桌面（Language Table）设置的示例。对于语言桌面实验，我们训练基于视觉-语言-动作（VLA）的模型，在生成实际动作之前先产生语言方向（如“向上移动”），遵循贝尔哈勒等人（Belkhale et al., 2024）的方法，这显著提升了性能⁶。在评估方面，我们对每个子任务类别进行 50 次评估回放，每次评估中物体的初始位置均随机化。更多细节见 <https://github.com/google-research/language-table>。

SIMPLER 实验设置 SIMPLER 设置的示例。SIMPLER 环境未为其评估流程提供任何微调数据，因此，本文首先在 Bridgev2 数据集上训练底层视觉语言模型，并在 SIMPLER 的 4 个任务上执行零样本推演。注意，本文使用的保留轨迹在物体朝向和位置上与评估设置不同。本文为每个任务筛选 25 条成功轨迹（共 100 条），并将其作为所有实验的微调数据集。评估时，本文在 24 次推演上进行评估。⁶ 对于 7 自由度机器人实验，本文发现生成语言方向的收益相较于增加的推理成本而言较为有限。因此，本文仅在其他实验中生成末端执行器增量动作。

每个任务随机化初始物体位置。我们认为桥接版本 2 (Bridgev2) 和简化环境 (SIMPLER) 属于域内，因为它们的仿真基准显示真实世界与仿真结果之间具有高度相关性。更多细节见 <https://github.com/simpler-env/SimplerEnv>。

真实世界桌面操作实验设置。桌面操作实验设置的示例。对于遥操作，我们使用多金属机器人栈⁷为每个任务收集 150 条轨迹。所有任务都需要多指令跟随能力，因为场景中有 3 个物体，模型必须根据任务描述推断出要与哪个物体交互。图 10 展示了每个任务的样本。对于每个任务，我们旨在量化 3 种不同的能力：（1）测试在微调期间见过的物体的未见组合中，根据任务描述推断正确物体的能力；（2）测试在微调期间完全未见过的物体中推断正确物体的能力，这些物体可能在预训练期间被观察到，也可能没有。具体来说，敲击任务使用了真实世界物体，这些物体极不可能出现在任何预训练数据集中。（3）测试从完全未见过的指令中推断正确物体（在见过的物体、未见组合中）的能力，该指令需要语义推理（例如，拿起一个辣的物体）。对于每个评估标准，每个模型执行 6 次推出，每个任务类别总共 18 次推出。由于有三个任务，每个模型在真实世界中共评估 54 次推出。我们在表 13、14、15 中提供了每次推出使用的所有见过和未见物体的完整列表，并在表 16 中提供了总平均成功率。

此外，为了公平比较，我们在训练所有模型时匹配图像分辨率，并在所有评估中使用完全相同的物体初始位置，大多在同一天进行以最小化变异性。对于评估度量，我们采用部分成功标准进行细粒度评估，遵循 Kim 等人 (2024) 的方法，下面详细描述。

Knock down the <object>.

对于敲击任务，如果机器人到达正确物体，我们给 0.5 分；如果机器人击倒正确物体，给 1 分。

用毛巾盖住 <物体>。

对于覆盖任务，如果机器人正确拿起毛巾，我们给 0.33 分；如果机器人到达正确物体或毛巾部分覆盖物体，给 0.66 分；如果正确物体被毛巾完全覆盖，给 1 分。

拿起 <物体> 并放入水槽中。

对于抓取与放置任务，若机器人到达正确物体则给予 0.25 分，抓取物体给予 0.5 分，抓取并朝水槽移动物体但未能放入水槽给予 0.75 分，将正确物体放入水槽则给予 1 分。

C 基线细节

对于 UNIPi，我们使用来自 (Ko 等人, 2024) 的扩散模型，该模型可在 4 块 A100 GPU 上训练。所有实验均以 128 的批大小进行训练。推理时使用与 VPT 相同的逆动力学模型。为缓解预测视频计划与执行动作之间的估计误差累积，我们每执行两个动作后重新生成新的视频计划进行周期性重规划。对于 VPT，逆动力学模型 (IDM) 采用 ResNet18 后接一个 MLP 层。IDM 在单块 A6000 GPU 上使用 Adam 优化器以 $1e-4$ 的学习率训练，输入两帧图像预测动作。对于 OpenVLA (Bridge)，我们在 Bridgev2 上以 1024 的批大小预训练 30 个训练轮次。对于 OpenVLA (Open-X)，我们使用 Kim 等人 (2024) 的预训练检查点。微调采用 LoRA 微调 (Hu 等人, 2022)，批大小为 32。我们观察到全量微调与 LoRA 微调性能相近，因此默认使用 LoRA 微调以实现高效微调。微调持续至训练动作准确率达到 95%。对于 ACTIONVLA 和 LAPA，我们以 128 的批大小训练，并在真实世界微调中使用图像增强。

⁷<https://github.com/facebookresearch/polymetis>

D 实验结果分析

表 4：下游任务的预训练轨迹统计。各预训练数据集（Bridgev2、Open-X 和 Something Something V2（Sthv2）数据集）中与评估任务相同的轨迹数量。

Task	Bridgev2	Open-X	Sthv2
Knocking	2	7,969	6,655
Covering	898	5,026	6,824
Pick & Place	10,892	911,166	3,272

我们进一步分析图 3 和图 4b 所示的真实世界机器人结果，重点关注预训练数据中的任务分布如何影响下游性能。表 4 展示了通过词汇匹配确定的各评估任务（敲击、覆盖和抓取与放置）在各预训练数据集（Bridgev2、Open-X 和 Something Something V2（Sthv2））中的轨迹数量。我们期望未来工作采用其他方法分析预训练与微调任务分布之间的关系，以捕捉任务语义而非简单的词汇匹配。进行此分析旨在了解预训练数据中的任务分布如何影响下游任务性能。

敲击 桥接数据集 v2（Bridgev2）中几乎没有与敲击相关的轨迹。这种稀缺性或许可以解释为何在桥接数据集 v2 上训练的模型表现不如在 Sthv2 上训练的模型，尽管 Sthv2 数据集的实体差距更大（图 4b）。

覆盖 覆盖任务也观察到类似趋势。鉴于桥接数据集 v2 中覆盖轨迹的数量相对少于 Sthv2 数据集，在桥接数据集 v2 上训练的模型偶尔会不如在 Sthv2 上训练的 LAPA。

抓取与放置 对于抓取与放置任务，趋势则相反。Sthv2 中抓取与放置任务的数量相对少于桥接数据集 v2 和 Open-X，这或许可以解释为何在 Sthv2 上训练的 LAPA 显著不如在桥接数据集 v2 或 Open-X 上训练的模型。基于这些结果，我们预期在涵盖广泛技能的视频上进行预训练，相比在技能范围较窄的机器人视频上训练，将产生更稳健的通用策略。我们还期望未来研究能更深入地分析预训练数据中的任务分布与下游任务性能之间的关系。

我们还展示了 LAPA（Open-X）相对于 OpenVLA（Open-X）的胜率。如图 11 所示，在不考虑平局的情况下，LAPA 在 65.4% 的情况下优于 OpenVLA。考虑平局时，LAPA 在 31.5% 的情况下优于 OpenVLA，而 OpenVLA 仅在 16.7% 的情况下胜出。有趣的是，它们在 51.9% 的试验中打成平手，这表明在大约一半的实例中，两个模型要么都失败，要么获得相似的部分成功分数。请注意，这些评估是在确保评估期间目标和干扰物处于相同初始位置的情况下进行的，并在评估期间交替使用模型。这些结果为比较的统计显著性提供了洞见，支持使用多种度量来确保对真实场景中物理机器人性能进行更全面的评估（Kress-Gazit 等人，2024），而不仅仅是所有评估运行的平均成功率。

E 详细的潜在动作分析

本文对 LAPA 进行了进一步的定性分析。首先，我们分析了从词汇量为 8、序列长度为 1 的 Language Table 中学习到的潜在动作。在图 12 中，我们展示了每个潜在动作对应一个语义动作（0：向左前方移动，1：向左后方移动，2：向右后方移动，3：轻微向右移动，4：向右移动，5：向后移动，6：不移动，7：向前移动）。我们观察到，增加潜在动作词汇量能够捕获更细粒度的信息。我们通过将每个实例映射到潜在动作空间，分析了潜在动作与真实 2 自由度动作之间的关系。如图 13 所示，

我们观察到潜在动作在实际二维动作空间中聚类良好，这表明潜在动作是有意义的表示，与实际连续动作高度相关。

我们进一步使用 Something-Something V2 数据集分析了从人类操作视频中学习到的潜在动作。如图 14 所示，这些潜在动作不仅捕获了手部运动，还捕获了相机运动。由于 Something-Something V2 数据集中的视频是以自我为中心的，相机视角在整个视频中不断变化，因此我们的潜在动作量化模型也学会了表示相机运动。例如，潜在动作 [3,5,2,7] 和 [5,6,7,6] 对应轻微的向下相机运动，[4,0,0,4] 和 [2,3,6,6] 表示向右运动，[4,2,0,0] 和 [5,7,0,5] 表示细微的向上相机移动。

F 附加消融结果

我们首先分析了窗口大小 H 对潜在动作量化过程的影响。对于所有机器人操作视频，我们根据视频的帧率确定窗口大小，使得下一帧模拟当前帧之后 0.6 秒的状态。对于人类操作视频，我们将下一帧设置为 2.4 秒之后，因为我们定性观察到，与机器人视频相比，人类视频的许多帧包含的动态动作要少得多。（然而，我们认为过滤这些帧可以使窗口大小与机器人视频相同，这留作未来工作。）我们通过在 SIMPLER 上评估，为机器人视频（Bridgev2）添加了关于窗口大小的消融实验，如图 15a 所示。注意，默认值为 $H = 3$ ，因为 Bridgev2 以 5 赫兹采集。结果表明，LAPA 对不同窗口大小相当鲁棒。然而，如果窗口大小极大，会观察到性能下降。这是预期的，因为我们的量化模型相对较小（3 亿参数），当视觉差异显著时，它在建模潜在信息方面面临困难。

我们还通过与 SCRATCH 比较，分析了微调数据方面的数据扩展。我们在 SIMPLER 上评估。如图 15b 所示，即使微调数据实例较少，LAPA（Bridge）也始终优于 SCRATCH，而绝对性能随着微调数据的增加而提高。

对于数据扩展，我们还分析了人类视频的数据扩展。我们将使用 10% 的 Sthv2 人类视频数据集训练的 LAPA 与使用整个 Sthv2 人类视频数据集训练的 LAPA 进行比较。表 12 中的结果表明，扩展人类视频数据集不仅提高了所有子任务的最终成功率，还提升了 SIMPLER 基准的性能。我们将更广泛地探索人类视频的缩放定律留作未来工作，因为展示缩放定律需要密集的计算资源来进行模型大小、数据大小和计算资源的不同消融。

最后，我们在语言表（Language Table）中改变潜在动作长度和词汇表大小，扩展了图 5 中在桥接 v2（Bridgev2）数据上分析的结果。如图 16 所示，增加序列长度和词汇表大小均能提升性能。然而，与简化器（SIMPLER）不同，我们观察到在绝对性能方面，增加潜在动作词汇表大小比增加潜在动作序列长度更为有效。这意味着对于视觉上简单的环境，增加潜在动作词汇表可能比增加序列长度更有效。

G 详细实验结果

G.1 语言表

我们在表 5、6、7、8、9、10 中提供了在语言表基准上进行的实验的详细结果。对于附录中的所有表格，我们将比较中的最佳结果加粗，次佳结果加下划线。每个值表示成功率（%）。每个任务类别执行 50 次评估回滚，因此每个模型在每个表格中共执行 250 次评估回滚。

我们还展示了统一规划器（UNIPi）的定性结果，其中扩散模型为简单和短视界任务（例如分离任务）生成了正确的计划。然而，当任务需要更长视界规划时，扩散模型生成了与指令不符的错误计划（图 17）。

表 5：语言表域内已见结果。

	SCRATCH	UNIPI	VPT	LAPA	ACTIONVLA
Block2Block	4.0	14.0	36.0	<u>58.0</u>	76.0
Block2Absolute	6.0	4.0	38.0	<u>56.0</u>	72.0
Block2BlockRelative	10.0	12.0	48.0	<u>52.0</u>	76.0
Block2Relative	6.0	10.0	26.0	<u>48.0</u>	70.0
Separate	52.0	72.0	70.0	96.0	<u>90.0</u>
AVG	15.6	22.4	43.6	<u>62.0</u>	76.8

表 6：语言表域内未见结果。

	SCRATCH	UNIPI	VPT	LAPA	ACTIONVLA
Block2Block	8.0	4.0	26.0	<u>50.0</u>	62.0
Block2Absolute	10.0	6.0	42.0	<u>48.0</u>	58.0
Block2BlockRelative	2.0	6.0	20.0	<u>28.0</u>	48.0
Block2Relative	8.0	6.0	32.0	<u>38.0</u>	44.0
Separate	48.0	44.0	44.0	84.0	<u>82.0</u>
AVG	15.2	13.2	32.8	<u>49.6</u>	58.8

表 7：语言表跨任务已见结果。

	SCRATCH	UNIPI	VPT	LAPA	ACTIONVLA
Block2Block	18.0	12.0	<u>74.0</u>	<u>74.0</u>	76.0
Block2Absolute	8.0	6.0	56.0	<u>62.0</u>	72.0
Block2BlockRelative	6.0	2.0	62.0	<u>72.0</u>	76.0
Block2Relative	24.0	16.0	72.0	60.0	<u>70.0</u>
Separate	80.0	68.0	<u>96.0</u>	98.0	90.0
AVG	27.2	20.8	72.0	<u>73.2</u>	76.8

表 8：语言表跨任务未见结果。

	SCRATCH	UNIPI	VPT	LAPA	ACTIONVLA
Block2Block	16.0	4.0	66.0	46.0	62.0
Block2Absolute	10.0	10.0	<u>56.0</u>	52.0	58.0
Block2BlockRelative	8.0	10.0	<u>46.0</u>	48.0	48.0
Block2Relative	12.0	4.0	52.0	38.0	<u>44.0</u>
Separate	66.0	52.0	<u>84.0</u>	90.0	82.0
AVG	22.4	16.0	60.8	54.8	<u>58.8</u>

表 9：语言表跨环境已见结果。

	SCRATCH	UNIPI	VPT	LAPA	ACTIONVLA
Block2Block	4.0	4.0	16.0	<u>26.0</u>	66.0
Block2Absolute	6.0	4.0	8.0	<u>16.0</u>	58.0
Block2BlockRelative	10.0	8.0	6.0	<u>20.0</u>	62.0
Block2Relative	6.0	4.0	12.0	<u>22.0</u>	54.0
Separate	<u>52.0</u>	48.0	48.0	84.0	84.0
AVG	15.6	13.6	18.0	<u>33.6</u>	64.8

G.2 简化器

本文提供在简化器（SIMPLER）环境中评估的各种模型的结果。表 11 展示了基线模型在桥接数据集 v2（Bridgev2）上预训练，然后在简化器回放（100 个视频）上微调的设置。结果显示了每个任务（将绿色方块堆叠到黄色方块上、将胡萝卜放在盘子上、将勺子放在毛巾上、将茄子放入篮子中）和子任务（抓取和移动）的详细结果。如表 11 所示，统一规划器（UNIPI）在简化器环境中的表现显著低于所有其他基线。本文观察到，尽管扩散模型生成的计划相当准确，但逆动力学模型（IDM）在仅给定 100 条动作标记轨迹时，缺乏准确预测 7 自由度连续动作的能力。具体而言，本文观察到统一规划器经常未能在最大步数限制内抓取物体。这意味着在动作标记数据不足的场景中使用视觉语言动作模型（VLA）的有效性。与第 4.3 节的结果类似，潜在动作预训练（LAPA）优于未使用真实动作标签预训练的基线模型（统一规划器和视频预训练（VPT）），并缩小了与动作视觉语言动作模型（ACTIONVLA）的性能差距，后者在桥接数据集 v2 的全部 6 万条动作标记轨迹上进行了预训练。这凸显了即使动作空间的复杂度增加，潜在动作预训练的有效性。本文还评估了在简化器轨迹上微调的开源视觉语言动作模型（OPENVLA）的性能以供参考。开源视觉语言动作模型的性能（36.4）与从头训练（Scratch）相似。开源视觉语言动作模型在简化器上表现不佳是一个众所周知的问题，原因是开源视觉语言动作模型对简化器的真实到模拟迁移不够鲁棒。

表 10: 语言表跨环境未见结果。

	SCRATCH	UNIPi	VPT	LAPA	ACTIONVLA
Block2Block	8.0	2.0	2.0	<u>30.0</u>	38.0
Block2Absolute	10.0	6.0	4.0	<u>14.0</u>	48.0
Block2BlockRelative	2.0	6.0	2.0	<u>10.0</u>	50.0
Block2Relative	8.0	4.0	<u>40.0</u>	18.0	54.0
Separate	48.0	42.0	44.0	<u>76.0</u>	80.0
AVG	15.2	12.0	18.4	<u>29.6</u>	54.0

准确的，逆动力学模型在仅给定 100 条动作标记轨迹时，缺乏准确预测 7 自由度连续动作的能力。具体而言，本文观察到统一规划器经常未能在最大步数限制内抓取物体。这意味着在动作标记数据不足的场景中使用视觉语言动作模型的有效性。与第 4.3 节的结果类似，潜在动作预训练优于未使用真实动作标签预训练的基线模型（统一规划器和视频预训练），并缩小了与动作视觉语言动作模型的性能差距，后者在桥接数据集 v2 的全部 6 万条动作标记轨迹上进行了预训练。这凸显了即使动作空间的复杂度增加，潜在动作预训练的有效性。本文还评估了在简化器轨迹上微调的开源视觉语言动作模型的性能以供参考。开源视觉语言动作模型的性能（36.4）与从头训练相似。开源视觉语言动作模型在简化器上表现不佳是一个众所周知的问题，原因是开源视觉语言动作模型对简化器的真实到模拟迁移不够鲁棒。

本文还在表 12 中提供了基线模型在人类操作视频（某事物某事物 v2 数据集）上预训练，然后在简化器回放（100 个视频）上微调的设置的结果。本文仅与统一规划器、视频预训练和潜在动作预训练进行比较，因为动作视觉语言动作模型在没有真实动作标签的情况下无法训练。

表 11: Bridgev2 预训练的 SIMPLER 结果。在 SIMPLER 环境中的成功率、抓取率和移动率（%）。我们在 Bridgev2 数据集上预训练 UNIPi、VPT 和 LAPA，不使用真实动作标签；ACTIONVLA 在 Bridgev2 上使用动作标签进行预训练。我们还添加了在 SIMPLER 轨迹上微调的 OPENVLA 结果作为参考。主要 4 个任务为：将绿色方块堆叠到黄色方块上、将胡萝卜放在盘子上、将勺子放在毛巾上、将茄子放入篮子中。最佳结果加粗，次佳结果加下划线。

Success Rate	SCRATCH	UNIPi	VPT	LAPA	ACTIONVLA	OPENVLA
Stack G2Y	29.2	2.7	45.8	<u>54.2</u>	75.0	41.6
Carrot2Plate	29.2	2.7	37.5	45.8	58.0	<u>50.0</u>
Spoon2Towel	50.0	0.0	70.8	70.8	70.8	37.5
Eggplant2Bask	29.2	0.0	<u>50.0</u>	58.3	<u>50.0</u>	16.7
AVG	34.4	1.3	51.0	<u>57.3</u>	63.5	36.4
Grasping Rate						
Grasp Green Block	<u>66.6</u>	20.8	62.5	62.5	87.5	50.0
Grasp Carrot	45.8	33.2	54.1	58.3	75.0	<u>66.6</u>
Grasp Spoon	70.8	22.2	<u>79.2</u>	83.3	83.3	45.8
Grasp Eggplant	62.5	16.0	70.8	83.3	<u>75.0</u>	37.5
AVG	61.4	23.1	66.7	<u>71.9</u>	80.2	50.0
Moving Rate						
Move Green Block	58.3	29.1	58.3	66.6	91.6	<u>70.8</u>
Move Carrot	45.8	48.6	66.6	70.8	91.6	<u>75.0</u>
Move Spoon	70.8	34.6	<u>79.2</u>	83.3	<u>79.2</u>	75.0
Move Eggplant	<u>87.5</u>	58.0	<u>70.8</u>	<u>87.5</u>	91.6	50.0
AVG	65.6	42.6	68.7	<u>77.1</u>	88.5	67.7

G.3 真实世界

我们还提供了完整的物体列表以及每次评估运行记录的部分成功情况：敲击（表 13）、覆盖（表 14）和拾取与放置（表 15）。总平均成功率见表 16。

表 12: 人类操作视频预训练的 SIMPLER 结果。在 SIMPLER 环境中的成功率、抓取率和移动率 (%)。我们在 Something-Something V2 数据集上预训练 UNIPI、VPT 和 LAPA, 不使用真实动作标签。主要 4 个任务为: 将绿色方块堆叠到黄色方块上、将胡萝卜放在盘子上、将勺子放在毛巾上、将茄子放入篮子中。最佳结果加粗, 次佳结果加下划线。

Success Rate	VPT	UNIPI	LAPA	LAPA (10%)
StackG2Y	50.0	0.0	50.0	<u>45.8</u>
Carrot2Plate	29.1	1.3	50.0	<u>41.6</u>
Spoon2Towel	37.5	1.3	<u>50.0</u>	66.6
Eggplant2Basket	66.6	0.0	<u>58.3</u>	45.8
AVG	45.8	0.7	52.1	<u>50.0</u>
Grasping Rate				
Grasp Green Block	66.6	2.7	<u>58.3</u>	50.0
Grasp Carrot	<u>45.8</u>	31.7	62.5	41.6
Grasp Spoon	<u>70.8</u>	21.7	75.0	<u>70.8</u>
Grasp Eggplant	91.6	6.8	<u>70.8</u>	62.5
AVG	68.7	15.7	<u>66.7</u>	56.2
Moving Rate				
Move Green Block	62.5	2.7	62.5	<u>50.0</u>
Move Carrot	<u>58.3</u>	37.5	70.8	<u>58.3</u>
Move Spoon	54.1	18.1	<u>75.0</u>	79.2
Move Eggplant	91.6	50.3	<u>83.3</u>	62.5
AVG	<u>66.6</u>	27.1	72.9	62.5

表 13: 敲击任务结果

	OpenVLA (OpenX)	LAPA (OpenX)	OpenVLA (Bridge)	LAPA (Bridge)	ActionVLA (Bridge)	Scratch	LAPA (Sthv2)
Seen Objects, Unseen Object Combinations							
flamingo	0	0.5	0.5	0.5	0	0	0.5
pistachios	0.5	1	0.5	0	1	0	1
soft scrub	0	0	0	0	0.5	0	0.5
white cup	1	0	0	0.5	0.5	0.5	0
mustard	0	1	0	0	0	0	0
water bottle	1	1	0.5	0	0	0.5	0
SUM	2.5	3.5	1.5	1	2	1	2
Unseen Objects							
pringles	0.5	0.5	0.5	0	0	0	0
hersey's chocolate syrup	0	0	0	0	0	0	0
popcorn	0	1	1	1	1	0	1
skittles	0	0	0	0	0	0	0
green board marker	0.5	0.5	0.5	0.5	0.5	0.5	0.5
paper towel	0	0	0	0	0	0	0
SUM	1	2	2	1.5	1.5	0.5	1.5
Seen Objects, Unseen Instructions							
a drink that contains orange	0	0	0	0	0	0	0
food to eat with milk	0.5	0	0	0	0	0	0
a object used for cleaning	0	1	0	0	0	0	0
something to wash dishes	1	1	0	0.5	1	0.5	0
the nuts	1	1	0.5	1	1	0.5	1
rectangle object	1	1	0.5	0.5	0.5	0	1
SUM	3.5	4	1	2	2.5	1	2
Success Rate (Strict)	<u>27.78%</u>	44.44%	5.56%	11.11%	22.22%	0.00%	22.22%
Success Rate	<u>38.89%</u>	52.78%	25.00%	25.00%	33.33%	13.89%	30.56%
Reaching Success Rate	<u>50.00%</u>	61.11%	44.44%	38.89%	44.44%	27.78%	38.89%




图 10: 真实世界桌面操作示例。




图 11：成对胜率 (%)。我们比较了 OpenVLA 和 LAPA 在真实世界 54 次评估运行中的成对胜率。(a) 显示忽略平局时的胜率，(b) 显示平局以及各自的胜场。




图 12：语言表中的潜在动作分析。我们将当前观测 x_1 和量化后的潜在动作输入到潜在动作量化模型的解码器中。我们观察到每个潜在动作都可以映射到一个语义动作。例如，潜在动作 0 对应向左前方移动一点，而另一个潜在动作对应向左后方移动一点。




图 13：潜在动作与真实动作的相关性。当我们将潜在动作映射到语言桌（Language Table）的真实二自由度动作时，观察到潜在动作在实际二维动作空间中聚类良好。




图 14：人类操作视频中的潜在动作分析。我们将当前观测 x_1 和量化后的潜在动作输入到潜在动作量化模型的解码器中。观察到每个潜在动作都可以映射到一个包含相机运动的语义动作。例如，潜在动作 [3,5,2,7] 对应将相机稍微向下移动，而 [4,2,0,0] 对应将相机稍微向上移动。




图 15：LAPA 的额外消融结果。我们通过改变潜在动作量化的窗口大小和微调数据规模，进一步分析了 LAPA 的性能。报告了在 SIMPLER 中的平均成功率。




图 16：LAPA 在语言桌任务中的消融结果。我们尝试了 LAPA 的不同潜在动作词汇表和序列，并展示了在语言桌微调任务中的下游平均成功率（%）。




图 17：UNIPI 的成功与失败案例。（上）给定指令“将绿色方块移离红色立方体和红色五边形”，UNIPI 的扩散模型成功生成了计划。（下）给定指令“将蓝色月亮朝向黄色方块放置”，扩散模型未能生成正确的计划。

表 14: 覆盖任务结果

	OpenVLA (OpenX)	LAPA (OpenX)	OpenVLA (Bridge)	LAPA (Bridge)	ActionVLA (Bridge)	Scratch	LAPA (Sthv2)
Seen Objects, Unseen Object Combinations							
icecream	0.33	0.33	0.33	0.33	0.33	0.33	0
strawberry	0.33	1	0.33	1	0.33	1	1
pepper	0.33	0	0.33	0.33	0.33	0.33	0.33
watermelon	0.33	0.33	0.33	0.33	0.33	0	0.33
blue lego block	0.66	1	1	1	1	0.33	0.33
pink duck	0.33	1	0.33	0.33	0.33	0	0.33
SUM	2.31	3.66	2.65	3.32	2.65	1.99	2.32
Unseen Objects							
donut	0.33	1	0.66	1	0.66	0.66	0.33
orange	0.33	0.33	1	0	0.33	1	1
mushroom	0.33	0.33	0.33	0.33	0.33	0.33	0.33
yellow lego block	0.33	1	1	0.33	0	0.33	0.33
peas	1	0	0.66	1	1	0.33	1
egg	0	1	0.33	0	0.66	0	1
SUM	2.32	3.66	3.98	2.66	2.98	2.65	3.99
Seen Objects, Unseen Instructions							
drink	0.33	0	0.66	1	0.33	0.33	0.66
yellow object	0.66	0.66	0	0	0.33	0	0.33
fruit	0.33	0.33	0.33	0.33	0.33	0.33	0.33
vegetable	0.33	0.33	0	0.33	0.33	0.33	0.33
edible object	0.33	0.33	0.66	0	0.33	1	0.33
condiment	0.33	0.33	0.33	0	0.33	0.33	0.33
SUM	2.31	1.98	1.98	1.66	1.98	2.32	2.31
Success Rate (Strict)	5.56%	33.33%	16.67%	<u>27.78%</u>	11.11%	16.67%	22.22%
Success Rate	38.56%	51.67%	47.83%	42.44%	42.28%	38.67%	<u>47.89%</u>
Reaching Success Rate	16.66%	38.89%	38.89%	<u>27.78%</u>	22.22%	22.22%	<u>27.78%</u>

表 15: 拾取与放置水槽任务结果

	OpenVLA (OpenX)	LAPA (OpenX)	OpenVLA (Bridge)	LAPA (Bridge)	ActionVLA (Bridge)	Scratch	LAPA (Sthv2)
Seen Objects, Unseen Object Combinations							
milk	1	1	1	1	1	0	1
orange lego block	1	1	0	1	0	0	0
ketchup	0.25	0.25	0.25	0.25	0	0	0
corn	1	0.75	1	0.25	0.25	0.25	0.25
icecream	0.25	0	0	0	1	0	1
salt	0	0.25	0	1	0	0	0
SUM	3.5	3.25	2.25	3.5	2.25	0.25	2.25
Unseen Objects							
carrot	1	0.25	0	0.25	1	0.25	0.25
yellow paprika	1	1	0	0.25	0.25	0	1
yellow cube	1	0.5	0.25	0.5	0	0	0
salmon sushi	0	0.25	0	0.5	0	0	0
orange	1	0	0	0	0	0.25	0
blue cube	0.25	0.25	0	0	0	0	0
SUM	4.25	2.25	0.25	1.5	1.25	0.5	1.25
Seen Objects, Unseen Instructions							
an object that is yellow	1	1	0	1	0.25	0	0
an object that is round	0	0.25	0	0	0	0.25	0
an object that is a fruit	1	1	1	1	0	1	0.75
an object that you can drink	0	0.25	0	0.5	0	0	0
an object that is a vegetable	0	0	0	0	0	0	0
an object that is an animal	0	0.25	0	0.25	0.25	0	0
SUM	2	2.75	1	2.75	0.5	1.25	0.75
Success Rate (Strict)	50.00%	<u>27.78%</u>	16.67%	27.78%	16.67%	5.56%	16.67%
Success Rate	54.17%	<u>45.83%</u>	19.44%	43.06%	22.22%	11.11%	23.61%
Reaching Success Rate	66.67%	83.33%	27.78%	<u>72.22%</u>	38.89%	27.78%	33.33%

表 16: 总成功率汇总 (%)

	OpenVLA (OpenX)	LAPA (OpenX)	OpenVLA (Bridge)	LAPA (Bridge)	ActionVLA (Bridge)	Scratch	LAPA (Sthv2)
Total Success Rate	43.87%	50.09%	30.76%	36.83%	32.61%	21.22%	34.02%
Total Success Rate (Strict)	<u>27.78%</u>	35.19%	12.96%	22.22%	16.67%	7.41%	20.37%