

面向可泛化机器人控制 的原生视频-动作预训练

Qihang Zhang, Lin Li, Luyao Zhang, Shuai Yang, Yiming Luo, Shuaiting Li, Ruilin Wang, Junke Wang,
Jiahao Shao, Gangwei Xu, Jiaming Zhou, Yishu Shen, Yudong Jin, Fangyi Xu, Shuailei Ma, Jiaqi Liao,
Guanxing Lu, Zifan Shi, Yongkun Wen, Yujie Zhao, Weixuan Tang, Xinyang Wang, Chaojian Li,
Jiapeng Zhu, Ka Leong Cheng, Nan Xue, Xing Zhu, Yujun Shen, Yinghao Xu[†]

[†]Project Lead

视频-动作模型的出现为机器人控制提供了一条有前景的路径。然而，本文认为，将面向数字内容创作设计的视频生成模型直接复用于物理环境存在固有不足。为弥合这一差距，本文提出 **LingBot-VA 2.0**，一个从零开始为具身智能构建的视频-动作基础模型。四项核心设计原则展示了其相对于 **LingBot-VA** 的演进。（1）摒弃传统以重建为中心的变分自编码器，本文引入语义视觉-动作分词器，使视觉表征与语义和动作对齐，从而提升后续策略学习中的指令遵循与动作精确率。（2）鉴于时间动态的严格因果性，本文采用因果预训练范式，从零开始训练，以避免在适配双向架构时频繁出现的灾难性遗忘。（3）为满足高频推理需求，模型采用稀疏混合专家主干，在不牺牲效率的前提下扩展模型容量。（4）通过增强的异步推理方案实现实时闭环控制，该方案在动作执行的同时并行预测未来潜在状态，并利用学习到的前向动态将每次展开重新锚定到最新观测。真实世界部署验证了 **LingBot-VA 2.0** 作为稳健基础模型的有效性，其在复杂操作任务中的少样本泛化能力即为明证。

Website: <https://technology.robbyant.com/lingbot-va-v2>

 Robbyant

1 引言

视频-动作模型，如 LingBot-VA [50] 和 DreamZero [116]，近期已成为通用机器人操作的一种强大范式。与将观测直接映射为动作的反应式视觉-语言-动作策略不同 [9, 11, 43]，它们联合预测场景将如何演变以及如何在其中行动，将控制建立在物理动态之上，从而提升样本效率和泛化能力 [35, 54, 133]。然而，这种能力在很大程度上继承自其视频预训练主干，这表明通用机器人控制既依赖于预训练基础，也依赖于在其上学习的策略。

当前的视频-动作模型仍主要基于为通用视频生成设计的组件构建——一个面向重建的变分自编码器和一个双向视频扩散骨干网络——之后才为机器人应用附加动作模块。这一出发点带来了三个具体的局限性。首先，表征针对外观而非动态进行优化：像素重建潜变量保留了视觉细节，但携带的语义和物理结构有限，且单独附加的动作模块使世界状态与动作处于对齐不佳的空间中。其次，推理速度过慢，无法满足闭环控制需求：高维视频令牌和迭代去噪使得第一代视频-动作模型难以在真实机器人所需的频率下运行。第三，预训练信号无法向控制方向扩展：网络规模的视频数据虽然丰富，但通用视频目标并未教会模型动作如何重塑世界，因此动作信号仍依赖于昂贵的机器人数据，限制了下游适应之前所学到的控制知识。

这些局限性还因结构上的不匹配而加剧：骨干网络使用双向注意力进行预训练，

而闭环控制严格按时间向前展开。LingBot-VA 通过将整个堆栈微调为因果视频-动作模型来解决这一不匹配，但这种改造依赖于稀缺的机器人数据，并可能削弱从网络规模预训练中获得的广泛先验。因此，我们追求一种原生路径：在网络规模的图像和视频数据上，为机器人控制预训练整个堆栈，包括语义视觉-动作分词器和因果 DiT，从而使广泛先验以因果形式原生获得，而非继承后再被侵蚀。

我们提出 LingBot-VA 2.0，它通过一种设计实例化了这条原生路径，消除了上述三个局限性。LingBot-VA 2.0 并非将动作附加到现成的视频生成器上，而是首先为观测和动作构建一个共享的语义潜空间，然后在该空间之上学习因果动态。第一阶段是一个语义视觉-动作分词器 [99]：除了重建之外，它将视频潜变量与一个冻结的视觉基础模型对齐，产生比像素重建潜变量更具语义性的紧凑表示。它进一步通过自监督学习潜动作，将世界状态和动作置于同一空间中，使得即使是未标注的网络视频也携带与动作相关的监督信号。第二阶段是一个因果扩散 Transformer，它预测未来的视觉潜变量以及连接它们的潜动作，并通过交叉注意力以冻结的预训练语言模型为条件，受语言指令约束。其因果下一潜变量目标提供了一种自监督信号，可扩展到网络视频，同时匹配闭环控制的时间结构，避免了可能侵蚀预训练先验的双向到因果的改造；其前馈层被实例化为稀疏专家混合，在保持模型容量的同时减少了高频控制中每步的活跃计算量。由于相邻块通常在视觉上足够相似，仅靠下一块监督会奖励外观复制，因此我们额外使用多块预测（MCP）进行训练，它同时监督多个未来块，使学习到的潜变量编码轨迹级动态，而非短期视觉连续性。

然而，即使具备语义潜空间和稀疏主干网络，在真实硬件上的部署仍面临串行瓶颈：机器人必须在世界模型更新预测的同时持续执行动作；否则，模型延迟将直接转化为控制延迟。本文通过前瞻推理（Foresight Reasoning）解决这个问题，这是一种异步推理方案，在动作执行的同时并行预测未来的视觉潜变量。朴素的异步方案可能因依赖过时的想象潜变量而产生漂移。LingBot-VA 2.0 则通过策略自身学习的前向动力学步骤，将每次预测重新锚定到最新的真实观测上。这与 GEN-0 [31] 中谐波推理（Harmonic Reasoning）的并发推理动机相同，但将前瞻建立在学习到的世界模型之上，并通过每次真实观测进行校正。

由于动作信号不再依赖于稀缺的机器人演示，LingBot-VA 2.0 以网络视频的规模而非机器人数据集的规模获取控制知识。由此产生的视频-动作表示提升了泛化能力：仅需 10 – 15 次演示即可适应，无需大规模重新采集即可跨具身迁移，并且在某些场景下能够零样本执行新任务。在部署阶段，稀疏混合专家（MoE）推理、少步一致性蒸馏、前瞻推理以及量化执行使 LingBot-VA 2.0 能够在真实机器人上实现实时闭环控制，峰值异步执行频率达到 225 Hz。结合将长程目标分解为子任务的分层视觉语言模型（VLM）规划器（第 2 节），这些提升转化为更一致的长程行为和高精度操作，在仿真和真实世界评估中大幅超越 $\pi_{0.5}$ [77]、LingBot-VA [50] 等强基线。

综上所述，本文的贡献如下：

- **面向机器人控制的原生视频-动作预训练。**本文预训练完整的视频-动作栈，包括语义视觉-动作分词器和因果扩散变换器（DiT），采用可扩展的自监督方式，而非适配为通用视频生成而预训练的组件。
- **共享的语义视频-动作表示。**LingBot-VA 2.0 将世界状态和潜动作置于统一的语义潜空间中，该空间锚定于语言对齐的视觉基础模型，从而加强视觉-语言-动作对齐，提升指令遵循能力和动作精确度。
- **通用、快速且精确的机器人控制。**预训练的视频-动作表示支持少样本和零样本泛化；稀疏专家混合推理、少步蒸馏、前瞻推理和量化部署实现实时闭环执行；结合分层规划的闭环重接地维持细粒度、长时程操作。




图 1. LingBot-VA 2.0 概览。规划器（第 2.3.1 节）将长时程目标分解为结构化子任务上下文。语义视觉-动作分词器（第 2.2 节）将图像观测和人类视频提示（第 2.3.4 节）编码为视觉潜变量。带有专家混合的视频模型（第 2.3.2 节）和动作模型自回归地预测未来视觉潜变量和机器人动作。多块预测（第 2.3.3 节）添加未来块监督，自回归展开连接到异步执行以实现实时机器人控制（第 2.3.7 节）。

2 原生视频-动作模型

本节介绍完整的 LingBot-VA 2.0 技术栈（图 1）。在回顾先前视频-动作模型如何将通用视频生成器重新用于控制之后（第 2.1 节），我们分两个阶段原生构建该技术栈。第一阶段训练语义视觉-动作分词器，将视觉潜变量与冻结的基础模型对齐，并从无标签视频中提取潜动作，从而产生共享的视觉-动作潜空间（第 2.2 节）。第二阶段在该空间上预训练因果视频-动作模型（第 2.3 节）：高层视觉语言模型规划器将长时程目标分解为结构化子任务上下文（第 2.3.1 节）；低层策略通过稀疏专家混合扩散变换器扩展其视频流（第 2.3.2 节）；多块预测监督多个未来块，使表示捕获轨迹级动态（第 2.3.3 节）；上下文学习将人类演示视频作为视觉任务提示（第 2.3.4 节）；人机协同训练将第一人称人类视频引入共享世界模型（第 2.3.5 节），遵循第 2.3.6 节的多任务配方。在推理时，前瞻推理将预测与执行重叠，并将每次展开重新接地到最新真实观测（第 2.3.7 节）；后训练进一步将两个专家蒸馏为少步采样器，并应用推理加速以实现实时控制（第 2.4 节）。

2.1 预备知识

我们简要回顾近期视频-动作模型所基于的视频生成模型，以及将它们重新用于控制的公式化方法。

2.1.1 视频生成模型

现代视频生成器包含两个组件。首先，变分自编码器（VAE） $(\mathcal{E}, \mathcal{D})$ 将原始视频 $o \in \mathbb{R}^{T \times H \times W \times 3}$ 压缩为紧凑潜表示并重建，

$$z = \mathcal{E}(o) \in \mathbb{R}^{T' \times h \times w \times c}, \quad \hat{o} = \mathcal{D}(z) \approx o, \quad (1)$$

具有时间和空间下采样因子 $f_t = T/T'$ 和 $f_s = H/h = W/w$ 。关键的是，该变分自编码器（VAE）仅针对视频压缩进行训练：其目标是重建保真度，不涉及动作或控制的概念。其次，一个视频生成器——通常是流匹配变换器 [61, 94]——在该潜空间中训练，以从 z 合成

噪声 $\epsilon \sim \mathcal{N}(0, I)$ 以文本提示 c_{text} 为条件。具体而言，它沿插值路径回归速度场 path $z^{(s)} = (1-s)\epsilon + sz$:

$$\mathcal{L}_{\text{gen}} = \mathbb{E}_{s, \epsilon, z} \left[\left\| v_{\theta}(z^{(s)}, s \mid c_{\text{text}}) - (z - \epsilon) \right\|^2 \right], \quad (2)$$

其中注意力在所有 T' 个潜帧 [32, 74, 96] 上为双向。

2.1.2 将视频生成模型重新用于机器人控制

先前的视频-动作模型 [50, 116] 通过在机器人数据上继续训练，将这一预训练堆栈适配到机器人领域。由于视频分词器对观测流进行时间下采样，而机器人动作以原始控制频率记录，因此一个潜过渡对应于 f_t 个底层动作的块。我们将 T' 个视觉潜变量索引为 $z_{0:N}$ ，其中 $N = T' - 1$ ，并将原始动作序列写为 $u_{0:f_t N - 1}$ 。我们将两个连续视觉潜变量之间的原始动作分组为一个动作块

$$a_t = u_{tf_t:(t+1)f_t-1}, \quad t = 0, \dots, N-1, \quad (3)$$

与过渡 $z_t \rightarrow z_{t+1}$ 对齐。在整个视频-动作模型中， a_t 表示该动作块，而非单个底层控制命令。进行了两项修改。

(i) 视频因果性。式 (2) 的双向注意力被因果掩码替代，使得每个潜帧仅依赖于过去，与闭环控制中当前无法关注未来的特性一致：

$$p_{\theta}(z_{1:N} \mid z_0) = \prod_{t=0}^{N-1} p_{\theta}(z_{t+1} \mid z_{\leq t}). \quad (4)$$

(ii) 动作注入。视频-动作模型将式 (4) 的仅视频分解扩展为给定初始视觉上下文的未来潜变量和动作的条件分布：

$$p_{\theta}(z_{1:N}, a_{0:N-1} \mid z_0) = \prod_{t=0}^{N-1} \underbrace{p_{\theta}(z_{t+1} \mid z_{\leq t}, a_{<t})}_{\text{video generation: } (z_{\leq t}, a_{<t}) \rightarrow z_{t+1}} \underbrace{p_{\theta}(a_t \mid z_{\leq t}, a_{<t}, z_{t+1})}_{\text{inverse dynamics: } (z_{\leq t}, a_{<t}, z_{t+1}) \rightarrow a_t}. \quad (5)$$

现有方法在参数化式 (5) 的方式上存在差异。联合预测，如梦幻零 (DreamZero) [116]，将视频与动作令牌拼接，并在单一共享流中对每个转移进行去噪。为使转移监督显式化，我们将视频-动作目标写为独立的视频与动作流匹配损失。令 $z_{t+1}^{(s)} = (1-s)\epsilon_t^z + sz_{t+1}$ 与 $a_t^{(s)} = (1-s)\epsilon_t^a + sa_t$ 表示其插值后的噪声目标：

$$\mathcal{L}_{\text{vid}} = \mathbb{E}_{t, s, \epsilon_t^z} \left[\left\| v_{\theta}^{\text{vid}}(z_{t+1}^{(s)}, s \mid z_{\leq t}, a_{<t}) - (z_{t+1} - \epsilon_t^z) \right\|^2 \right], \quad (6)$$

$$\mathcal{L}_{\text{act}} = \mathbb{E}_{t, s, \epsilon_t^a} \left[\left\| v_{\theta}^{\text{act}}(a_t^{(s)}, s \mid z_{\leq t}, a_{<t}, z_{t+1}) - (a_t - \epsilon_t^a) \right\|^2 \right]. \quad (7)$$

完整的视频-动作目标为 $\mathcal{L}_{\text{VA}} = \mathcal{L}_{\text{vid}} + \lambda_{\text{act}} \mathcal{L}_{\text{act}}$ 。灵机机器人-视觉动作 (LingBot-VA) [50, 58] 的变换器混合 (Mixture-of-Transformers, MoT) 将两种模态分配给独立的专家网络 $\{v_{\theta}^{\text{vid}}, v_{\theta}^{\text{act}}\}$ ，这些网络共享因果注意力：视频专家预测下一个视觉潜在变量，动作专家通过预测转移上的逆动力学解码动作，

$$\hat{z}_{t+1} = v_{\theta}^{\text{vid}}(z_{\leq t}, a_{<t}), \quad \hat{a}_t = v_{\theta}^{\text{act}}(z_{\leq t}, a_{<t}, \hat{z}_{t+1}). \quad (8)$$

在轻微符号滥用下， v_{θ}^{vid} 与 v_{θ}^{act} 表示通过积分各自流匹配速度场得到的潜在变量与动作，而非速度场本身。

2.2 语义视觉-动作分词器

第 2.1.1 节中仅压缩的变分自编码器 (VAE) $(\mathcal{E}, \mathcal{D})$ 是标准的像素重建分词器 [44, 96]：其潜在变量仅针对重建进行优化，缺乏语义对齐或动作监督。因此，我们遵循重参数化世界-动作模型 (RepWAM) [99]，将分词器构建为灵机机器人-视觉动作 2.0 (LingBot-VA 2.0) 的第一阶段，通过两个目标增强重建：(1) 语义对齐目标，将视觉潜在变量拉向基础模型特征；(2) 潜在动作目标，从连续潜在变量中提取紧凑的转移变量。




图 2. 语义视觉-动作分词器。视觉分词器将面向重建的潜在变量与视觉基础模型特征对齐，而潜在动作分词器通过逆动力学与前向动力学学习紧凑的转移变量。改编自重参数化世界-动作模型 (RepWAM) [99]。

2.2.1 带语义对齐的视觉分词

我们采用视觉变换器 (Vision Transformer, ViT) 自编码器进行视觉分词 [25, 98]。给定视频片段 $o_{1:T}$ ，我们的分词器分两部分编码该片段。第一帧编码为 16×16 个空间块，后续帧编码为 $4 \times 16 \times 16$ 个时空管块。所得令牌沿序列维度拼接，并输入编码器 $\mathcal{E}$ ，输出视觉潜在变量 $z = \mathcal{E}(o)$ 。我们的编码器在每帧内使用全空间注意力，跨帧使用因果注意力。对称解码器 $\mathcal{D}$ 随后将潜在变量解码回像素空间， $\hat{o} = \mathcal{D}(z)$ 。

重建损失结合了像素、感知和对抗项：

$$\mathcal{L}_{\text{rec}} = \lambda_1 \|o - \hat{o}\|_1 + \lambda_{\text{perc}} \mathcal{L}_{\text{perc}}(o, \hat{o}) + \lambda_{\text{gan}} \mathcal{L}_{\text{gan}}(\hat{o}). \quad (9)$$

为了实现语义对齐，我们使用一个冻结的感知编码器 [10] 作为教师模型 G 。由于分词器潜在表示和教师特征可能具有不同的维度，一个可学习的投影 W_{align} 将 z 映射到教师特征维度。然后我们匹配时间池化后的表示：

$$\mathcal{L}_{\text{align}} = \|\text{avg}(W_{\text{align}} z) - \text{avg}(G(o))\|_2^2, \quad (10)$$

其中平均表示时间平均池化。这在保留每帧信息用于重建的同时，匹配了 G 的片段级语义。总体而言，视觉分词的目标是：

$$\mathcal{L}_{\text{vis}} = \mathcal{L}_{\text{rec}} + \lambda_{\text{align}} \mathcal{L}_{\text{align}}, \quad (11)$$

其中 λ_{align} 控制语义对齐的强度。

2.2.2 潜在动作分词

接下来，我们在这些语义视觉潜在表示之上构建一个潜在动作分词器，而不使用动作标签。遵循从观察转换中推断动作的潜在动作模型 [13, 14, 20]，每个潜在动作被定义为两个视觉潜在表示之间的紧凑变换。我们冻结视觉分词器，并训练一个逆动力学模型 (IDM) q_ϕ 以及一个前向动力学模型 (FDM) f_ψ 。对于两个连续的视觉潜在表示，IDM 预测：

$$\ell_t = q_\phi(z_t, z_{t+1}) \in \mathbb{R}^{d_\ell}, \quad d_\ell \ll \dim(z_t). \quad (12)$$

FDM 将 ℓ_t 解码为传输映射和残差，并重建下一个潜在表示：

$$\hat{z}_{t+1} = f_\psi(z_t, \ell_t) = K_t z_t + \delta_t, \quad (13)$$




图 3. 双系统分层策略。高层视觉语言模型规划器接收任务目标和稀疏的近期观察，生成结构化的子任务上下文，该上下文与机器人状态一起条件化低层视频-动作策略，以产生闭环动作。

其中 (K_t, δ_t) 由 ℓ_t 预测得到。传输 K_t 在空间潜在标记之间传递信息，而 δ_t 则用于解释仅靠传输无法说明的变化。反向传输 f_ψ 根据 (z_{t+1}, ℓ_t) 预测前一个潜在状态，即 $\hat{z}_t = \bar{f}_\psi(z_{t+1}, \ell_t)$ 。训练过程利用未标注视频进行前向预测和后向一致性约束：

$$\mathcal{L}_\ell = \sum_t \|\hat{z}_{t+1} - z_{t+1}\|_2^2 + \|\hat{z}_t - z_t\|_2^2. \quad (14)$$

ℓ_t 上的瓶颈阻止其复制完整的视觉状态，并促使其捕捉与控制相关的变化。因此，它为在视频-动作模型中建模从 z_t 到 z_{t+1} 的转变提供了一个动作潜在变量。因此，我们的分词器为每个视频片段返回成对的视觉-动作潜在变量 $(z_{0:N}, \ell_{0:N-1})$ ，这些潜在变量作为第二阶段视频-动作模型的训练目标，在该模型中，我们将学习到的潜在动作标记写为 $a_t \equiv \ell_t$ ，以匹配公式 (5) 中的符号。

2.3 视频-动作模型预训练与推理

在语义视觉-动作分词器的基础上，第二阶段在共享的视频-动作潜空间上预训练一个因果视频-动作模型。我们将其组织为两个层级：高层规划器将语言目标分解为子任务并跟踪其进展，低层视频-动作策略通过预测未来视觉潜变量及连接它们的潜动作来实现每个子任务。该策略以块为粒度运行，因此在本小节中，索引 t 遍历的是块而非单个帧。

2.3.1 分层规划

虽然视频动作策略处理单个子任务内的连续控制，但长时程任务需要将高层目标分解为子任务，跟踪当前活跃的子任务，并决定何时过渡到下一个子任务。我们将规划器实现为预训练的视觉语言模型（VLM），该模型经过微调，为策略生成结构化的子任务上下文。VLM 骨干网络开箱即用提供了视觉语言基础，使规划器能够从稀疏的视觉观察中评估任务状态，而无需从头学习场景理解。

规划器与策略以不同频率运行，并通过异步共享缓冲区解耦。规划器在后台以 ~ 2 赫兹的频率运行，并将结构化的子任务上下文写入缓冲区；策略在每个动作块边界读取最新的上下文作为其条件信号。这确保了规划器的推理延迟不会阻塞策略的执行循环。

规划器输出模式。规划器的输出格式必须与视频-动作策略在训练期间所见的条件字段完全一致；任何不匹配都会导致策略在推理时接收到分布外条件。在此约束下，我们将规划器输出定义为一个包含四个字段的结构化JSON：

- 完成：一个完成信号，指示当前子任务应继续执行还是规划器应切换到下一个子任务。
- 指令：针对当前或下一个子任务的紧凑执行指令，例如“拿起桌上的红色瓶子。”这是策略在训练期间使用的主要条件字段。
- generation_instruction: 对子任务内预期机器人运动和物体交互的更丰富描述，为策略提供更具体的执行线索。
- local_scene_description: 基于观察的空间布局和物体状态描述，为策略提供局部上下文。

完成字段仅由高层调度器使用，以决定是保持还是刷新当前子任务。低层策略以三个文本字段为条件：指令提供紧凑命令，而 generation_instruction 和 local_scene_description 在可用时提供更详细的行动和场景上下文。

规划器数据构建。规划器的训练数据由带有片段级标注的机器人演示视频构建。每个视频包含一个回合级任务目标和一段时序片段序列 $[g_0, g_1, \dots, g_N]$ ，其中每个片段都标注了上述四个字段。

核心构建方法是跨边界采样，旨在直接对齐规划器的在线部署场景。在每个片段边界处，我们生成两种类型的训练样本：

- **完成 = 为假**：观测时间 t^* 落在当前片段 g_i 内；目标是 g_i 的四个字段（回应当前子任务）。
- **完成 = 为真**：观测时间 t^* 刚刚越过 $g_i \rightarrow g_{i+1}$ 边界；目标是 g_{i+1} 的四个字段（预测下一步）。

每个样本的输入包括：（i）在 t^*-2s, t^*-1 秒和 t^* 处的三个关键帧，提供短期时间上下文；（ii）片段级任务目标；（iii）所有已完成先前片段的完整文本历史 $g_0, \dots, g_{i-1}$ ；以及（iv）当前子任务描述（仅适用于完成=为假的样本）。因此，完成=为真的样本要求规划器根据视觉观测和任务历史预测即将到来的子任务，而不是仅仅回应当前子任务。

训练集经过任务平衡处理，以防止高频任务占据主导地位。

规划器训练。规划器通过低秩适配（LoRA）微调预训练的视觉语言模型（VLM）主干网络，并冻结视觉塔。这保持了预训练的视觉定位能力，同时使语言头适应结构化子任务模式。因此，规划器被视为一个接口模块，为视频动作策略提供局部语言上下文，而不是作为单独优化的策略组件。

2.3.2 架构：专家混合视频流

低级视频-动作策略保持公式（8）中的变换器混合（Mixture-of-Transformers, MoT）结构：视频和动作模态由两个专家 $\{v_\theta^{\text{vid}}, v_\theta^{\text{act}}\}$ 处理，它们共享一个因果自注意力，但拥有各自独立的前馈通路。由于视觉动态承担了大部分建模负担，我们对两个流进行非对称缩放：视频专家将每个因果 DiT 块中的稠密前馈网络替换为稀疏专家混合（Mixture-of-Experts, MoE）路由层，而动作专家保持稠密。MoE 设计遵循 DeepSeekMoE 和 DeepSeek-V3 的稀疏缩放原则 [23, 24]，在我们的因果视频-动作 DiT 内部实例化。自注意力在视觉-动作历史上保持因果性，交叉注意力仍以语言为条件。由于路由在因果自注意力之后作为逐令牌的前馈操作应用，增加专家数量可提升视频流的容量，同时保持公式（5）中描述的不同因果依赖结构。

对于隐藏令牌 $h \in \mathbb{R}^d$ ，路由器使用门控矩阵 $W_g = [g_1, \dots, g_{N_e}]^\top \in \mathbb{R}^{N_e \times d}$ 计算专家得分 $r(h) \in \mathbb{R}^{N_e}$,

$$r_i(h) = \sigma(g_i^\top h), \quad i = 1, \dots, N_e, \quad (15)$$




图 4. MoE-13B-A1.9B 视频流模型与稠密 5B 基线的训练损失比较。左：按优化步数对齐的损失，两个模型保持接近，稠密基线略低。右：按实际训练时间对齐的损失，最终损失几乎重合。

其中 $\sigma(\cdot)$ 是 Sigmoid 函数， N_e 是路由专家的数量。我们使用组限制的 top- k 路由。专家被划分为若干组；首先根据最强的路由器得分选择少量组，然后在这些组内选择最终的 k 个专家。所选集合为

$$\mathcal{R}(h) = \text{TopK}_{\text{group}}(r(h) + b, k), \quad \mathcal{R}(h) \subset \{1, \dots, N_e\}, |\mathcal{R}(h)| = k, \quad (16)$$

其中 $b \in \mathbb{R}^{N_e}$ 是仅用于专家选择的专家级校正偏差。top- k 得分被归一化并缩放为

$$\alpha_i(h) = \gamma \frac{r_i(h)}{\sum_{j \in \mathcal{R}(h)} r_j(h)}, \quad i \in \mathcal{R}(h), \quad (17)$$

其中 $\alpha_i(h)$ 是标量路由权重， γ 是路由缩放因子。MoE 输出为

$$\text{MoE}(h) = E_{\text{shared}}(h) + \sum_{i \in \mathcal{R}(h)} \alpha_i(h) E_i(h), \quad (18)$$

其中 $E_{\text{shared}} : \mathbb{R}^d \rightarrow \mathbb{R}^d$ 捕获所有令牌共享的通用变换， $E_i : \mathbb{R}^d \rightarrow \mathbb{R}^d$ 是路由的 SwiGLU 专家。在我们的主要配置中， $N_e=128$ 和 $k=8$ ，因此每个令牌仅激活路由专家池的一小部分，而完整参数集在整个序列中保持可用。

稳定的混合专家（MoE）训练需要均衡的专家利用率。因此，本文采用无辅助损失负载均衡策略（Loss-Free Balancing）[100]，该策略同样被深度求索 V3（DeepSeek-V3）[24] 所采用，并遵循月光（Moonlight）[64] 中使用的无辅助偏差更新方法。在每个优化步骤之后，根据分配给每个专家的观测令牌计数 c_i 更新校正偏差，

$$v_i = \text{sign}(c_i - \bar{c}), \quad b_i \leftarrow b_i - \eta_{\text{lb}} \left(v_i - \frac{1}{N_e} \sum_{j=1}^{N_e} v_j \right), \quad (19)$$

其中 $\bar{c} = \frac{1}{N_e} \sum_{i=1}^{N_e} c_i$ 为平均专家负载， η_{lb} 为均衡更新率。该机制抑制过载专家并促进欠利用专家，而无需向视频-动作扩散目标注入较大的均衡梯度。本文保留轻量级序列级路由器正则化器和专家利用率统计信息用于监控。前向计算采用分组专家矩阵乘法执行，以实现高效的长序列训练。

作为对该稀疏视频流设计优化行为的最终检验，本文在相同训练设置下比较了 MoE-13B-A1.9B 模型与稠密 5B 基线的训练损失。如图 4 所示，在相同优化步骤数下比较时，两个模型遵循非常相似的损失轨迹，稠密基线略低。在匹配的墙钟训练时间下比较时，它们的最终损失几乎重合。这表明所提出的 MoE 视频流在考虑的训练预算下增加了总模型容量，而未引入明显的优化惩罚。

2.3.3 多块预测

遵循灵犀机器人 VA（LingBot-VA）[50]，本文使用教师强制训练视频-动作模型，从真实历史预测每个块。然而，标准的教师强制视频-动作训练仅在当前




图 5. 多块预测 (MCP)。轻量级辅助模块从主模型表示中预测多个未来潜在块，预测范围逐渐增加，在训练期间提供密集的时间监督。改编自下一强制 (Next Forcing) [112]。

块上监督模型，造成短视监督问题，其中学习信号变得过于局部：相邻块，尤其是在高帧率下，通常在视觉上足够相似，以至于模型可以通过复制外观而非学习底层动态来降低损失。

这与灵博视频动作 2.0 (LingBot-VA 2.0) 的目标不一致，该目标旨在预训练一个原生视频动作基础模型，其表示能够捕捉物理世界在动作作用下如何演化，而不仅仅是保持短期的视觉连续性。基于我们的分词器产生的语义视觉动作潜空间，我们因此采用多块预测 (Multi-Chunk Prediction, MCP)，受下一强迫 [112] 的启发，作为辅助训练目标，使因果视频动作策略的视觉表示能够预测未来的状态转移。

教师强迫仅监督视觉流的下一个块条件，

$$p_{\theta}(z_{t+1} \mid z_{\leq t}, a_{< t}), \quad (20)$$

将每个预测与真实视觉动作前缀下的直接下一个块进行匹配 ($z_{\leq t}, a_{< t}$)。MCP 则从该上下文预测接下来 K 个块的整体组，监督跨时间范围的未来条件

$$p_{\theta}(z_{t+1:t+K} \mid z_{\leq t}, a_{< t}) \approx \prod_{k=1}^K p_{\theta,k}(z_{t+k} \mid h_t^{(k-1)}), \quad h_t^{(0)} = f_{\theta}(z_{\leq t}, a_{< t}), \quad (21)$$

因此步骤 t 处的表示必须编码场景在接下来 K 个块内如何演化，而不仅仅是下一个块。这里 f_{θ} 表示主扩散变换器 (DiT) 在真实前缀上的特征提取， $h_t^{(k-1)}$ 是通过堆叠的 MCP 模块传递的内部特征状态，而不是干净或预测的未来观测。因此，时间范围 $t+k$ 的预测器重用先前的 MCP 特征，而不是以 $z_{t+1:t+k-1}$ 为条件。每个时间范围 k 使用与主模型相同的流匹配目标进行训练。具体来说，对于 $z_{t+k}^{(s)} = (1-s)\epsilon_t^k + sz_{t+k}$ ，MCP 损失为

$$\mathcal{L}_k^{\text{MCP}} = \mathbb{E}_{t,s,\epsilon_t^k} \left[\left\| v_{\theta,k}^{\text{MCP}}(z_{t+k}^{(s)}, s \mid h_t^{(k-1)}) - (z_{t+k} - \epsilon_t^k) \right\|^2 \right], \quad (22)$$

where $\mathbf{P}_{\theta,k}$ 是第 k 个 MCP 模块的速度场。

本文通过附加到主扩散变换器 (DiT) 上的轻量级多条件预测 (MCP) 模块实现公式 (21) 中的每个条件 (图 5)，每个预测范围对应一个模块。遵循下一帧强制预测 [112]，本文使用三个未来块 ($K = 3$ ；下一₁、下一₂、下一₃)。每个模块在相同的流匹配公式下对时间平移的视觉潜在目标进行去噪，但采用更大的时间步平移，因此无法仅凭自身噪声输入完成任务，必须依赖主模型的表示。这些模块形成因果链：第一个模块消耗来自多个扩散变换器层的融合中间特征，每个更深层的模块还以前一个模块为条件，使近未来预测能够为更远未来预测提供信息。因此，未来块去噪的梯度作为密集的时间监督回传到主干网络，促使其围绕轨迹级动态而非局部外观来组织潜在表示。多条件预测仅作用于视觉流，但更具预测性的视觉状态也通过共享的视频-动作注意力和逆动力学通路改善动作解码。

多条件预测辅助目标以与下一帧强制预测相同的权重组合各预测范围的损失， $(w_1, w_2, w_3) = (0.5, 0.2, 0.1)$ ：

$$\mathcal{L}_{\text{MCP}} = \sum_{k=1}^K w_k \mathcal{L}_k^{\text{MCP}}. \quad (23)$$

在部署时，同一训练检查点支持两种模式：可以丢弃多条件预测模块以实现零开销推理，使主策略仅通过训练时监督得到改进；或者保留这些模块以与当前块并行预测下一个视觉块，从而降低闭环控制的展开延迟。

2.3.4 上下文学习

现有的视频-动作模型依赖语言指令作为主要任务规范。机器人接收文本命令，并期望仅从语言中推断出预期的操作过程。然而，对于稀有物体操作、复杂多物体交互和长时程任务，语言描述很少是详尽的，可能无法指定操作的细粒度时间结构。

为了提供更丰富的任务描述，遵循零样本世界模型 (Zero-WAM) [60] 和动态视觉对齐 (DVA) [90]，我们引入了视频上下文学习 (ICL)。在每个上下文学习样本中，机器人视频与语义对齐的人类演示视频配对。人类视频无需与机器人视频共享相同的物体实例、视角或场景布局。相反，它作为一个动态视觉示例，展示操作任务应如何展开。与仅语言指令相比，这种视觉上下文提供了明确的时间和程序性指导，帮助模型遵循复杂的任务语义并泛化到未见过的开放世界任务 [130]。

给定一个人类演示视频，我们使用语义分词器将其编码为上下文潜在表示 z_{icl} 。遵循公式 (5) 中的教师强制视频-动作预训练目标，上下文学习人类视频通过将每个机器人块条件化于 z_{icl} 来增强机器人预测。对于具有视觉块 $z_{0:N}$ 和动作块 $a_{0:N-1}$ ，的配对机器人轨迹，上下文视频-动作目标为：

$$p_{\theta}(z_{1:N}, a_{0:N-1} \mid z_0, z_{\text{icl}}) = \prod_{t=0}^{N-1} p_{\theta}(z_{t+1} \mid z_{\leq t}, a_{\leq t}, z_{\text{icl}}) p_{\theta}(a_t \mid z_{\leq t}, a_{\leq t}, z_{t+1}, z_{\text{icl}}). \quad (24)$$

这里，上下文潜在表示 z_{icl} 被视为外部任务提示，可用于所有机器人预测步骤，而机器人侧的因果掩码防止每个块 z_t 关注未来的机器人块。由于 z_{icl} 来自独立的人类演示而非机器人轨迹的未来，关注完整演示并不违反机器人侧的因果性。相同的条件信号同时指导未来的机器人视频预测和相应的动作预测。

2.3.5 人机数据协同训练

机器人操作数据收集成本高且多样性有限，而以自我为中心的人类操作视频易于扩展并覆盖更广泛的任务和场景。由于先前工作表明人类数据可以迁移到机器人策略，尤其是在机器人数据稀缺的情况下 [40, 52, 97, 129]，我们同时使用人类和机器人数据进行协同训练，而不是先在人类视频上预训练然后再适应 [66, 67]，从而使共享的视频-动作模型在整个训练过程中持续改进真实机器人控制。

朴素联合训练面临两个差距：人手与机器人夹爪之间的动作空间不匹配，以及自然人运动与机器人运动学之间的运动差距 [52]。这些差距对视频-动作世界模型尤为有害，因为过去的动作会反馈到预测上下文中（式（5）），而错位的人体动作可能破坏共享动力学。我们通过将人手姿态映射到机器人动作空间来解决这些问题，同时在共享世界模型周围保留特定于具身的动作编码器和解码器。遵循 [52]，我们进一步将手映射到功能性夹爪开度而非占位符，从而使人体动作也能监督何时抓取。

我们联合训练两个共享观测 o 但原生动作不同的语料库：机器人集 $\mathcal{D}_R = \{(o, a^R)\}$ 和人体集 $\mathcal{D}_H = \{(o, \tilde{a}^H)\}$ 。所有动作均以统一的跨具身动作布局表示，其中某具身缺失的通道被零填充并掩码；其 d_a 维双手末端执行器切片 $\mathcal{A}$ 为每只手保存一个 6 自由度根姿态以及一个标量夹爪开度。人手标签通过映射 Φ 精确重定向到该切片，其余通道像其他具身一样被填充和掩码：

$$a^H = \Phi(\tilde{a}^H) \in \mathcal{A}. \quad (25)$$

此处 Φ 保留两个 6 自由度手根姿态，并将每只手的手指配置 q 映射为单个标量夹爪开度 $\varphi(q)$ ，完全按照机器人动作的方式填充 $\mathcal{A}$ 。这种功能性开度取代了先前联合训练中使用的无操作夹爪占位符 [52]。重定向后，两个领域共享相同的动作表示；剩下的运动差距——同一元组对手和机器人末端执行器具有不同的分布和物理含义——由各领域的动作头吸收。

两个领域都通过一个共享世界模型，仅在特定领域的动作编码器 E_d 和解码器 P_d ($d \in \{R, H\}$) 上有所不同；视频专家 v^{vid} 、动作专家 v^{act} 以及式（8）的因果注意力均为共享：

$$\hat{a}_t^{(d)} = P_d(v^{\text{act}}(z_{\leq t}, E_d(a_{<t}), \hat{z}_{t+1})). \quad (26)$$

目标函数对两个领域求和，每个领域通过其自身的动作头解码：

$$\mathcal{L}_{\text{co-train}} = \mathbb{E}_{\mathcal{D}_R}[\mathcal{L}_{\text{vid}} + \mathcal{L}_{\text{act}}^R] + \mathbb{E}_{\mathcal{D}_H}[\mathcal{L}_{\text{vid}} + \mathcal{L}_{\text{act}}^H]. \quad (27)$$

此处 $\mathcal{L}_{\text{vid}}$ 和 $\mathcal{L}_{\text{act}}^d$ 是模型的流匹配视频和动作损失，动作项通过领域头 P_d 解码。共享的视频和动作专家看到两个领域，并从人体数据中学习跨领域动力学；特定领域的头 E_d, P_d 仅将每个具身的低级动作参数化与共享表示隔离开来。部署时我们仅使用机器人分支 (E_R, P_R) ，因此联合训练不增加推理成本。

具体而言，手到夹爪映射 φ 将手视为一个虚拟平行夹爪，拇指作为一侧夹爪，其余四指作为另一侧。根据捕获的手指关节，我们通过正向运动学恢复三维指尖位置，并将开度定义为两侧沿闭合方向的距离，从而得到一个度量孔径，该孔径按数据集以与机器人夹爪通道相同的方式进行分位数归一化。在整个手指包络上测量该值，而非仅测量拇指到食指的单一距离，可在某个手指被错误跟踪时保持稳定。六自由度手部根部位姿保持不变，不进行任何转换。语料库和数据管线在第 3.3 节中描述。在训练期间，根据每个样本的具身类型选择公式（26）中的机器人动作头或人类动作头，而共享的视频-动作骨干网络则由两个领域共同更新。我们将人类动作头初始化为机器人动作头的参数，为协同训练提供一个稳定的起点。

2.3.6 训练方案

通用视频生成器（如 Wan[96]）通常针对综合任务进行预训练，而非具身交互，其双向注意力机制与闭环控制的因果机制（公式（4））相冲突；此外，我们专门构建的分词器其语义潜空间与任何现成生成器均不同，因此我们选择从零开始构建预训练方案，而非在借用骨干网络上继续训练。

我们没有采用完全分离、顺序分阶段的视频-动作模型训练方式，而是采用多任务协同训练方案，在整个预训练过程中联合优化所有目标，仅随时间改变它们的相对混合权重。严格分阶段的课程——先文生图，再文生视频，最后视频-动作——在训练收窄到稀缺的具身数据后，可能会灾难性地遗忘先前获得的广泛外观和动力学先验。协同训练则始终保持每个目标的存在，使模型在逐步专精于控制的同时保留通用世界知识。

所有五个任务均实例化在我们分词器的共享语义潜空间和相同的因果 DiT 骨干网络上，仅在条件输入和监督信号上有所不同：

- 文生图 (**T2I**)：单帧文本条件生成，建立视觉-语义对齐，并使潜空间与语言对齐。
- 文本到视频 (**T2V**)：以文本为条件的多帧生成，从网络规模视频中学习通用时序动态与运动先验。
- 文本图像到视频动作 (**TI2VA**)：核心控制任务，将未来潜视频预测与连接连续状态的潜动作的逆向动力学建模相结合（式 (5)），并以语言指令和观测历史为条件。
- 上下文学习 (ICL)：给定一段演示视频作为额外上下文，模型为同一任务的新实例生成视频动作推演，实现无需权重更新的少样本适应。
- 人机协同训练 (HCT)：通过共享世界模型及具身特定的动作编码器与解码器（第 2.3.5 节），在自我中心人类视频与机器人数据上进行联合训练，将低成本、多样化的人类演示迁移至机器人控制。

所有任务共享参数，并在单一混合目标下联合优化。设 $\mathcal{T}$ 表示包含 T2I、T2V、TI2VA、ICL 和 HCT 的任务集，每个任务 $i \in \mathcal{T}$ 在共享潜空间和 DiT 骨干上贡献损失 $\mathcal{L}_i$ 。在训练进度 $\tau \in [0, 1]$ 处，我们从 $\mathcal{T}$ 上的分布 $\pi(\tau)$ 中采样任务，并最小化加权目标

$$\mathcal{L}(\tau) = \sum_{i \in \mathcal{T}} \pi_i(\tau) \mathcal{L}_i, \quad \pi_i(\tau) \geq 0, \quad \sum_{i \in \mathcal{T}} \pi_i(\tau) = 1. \quad (28)$$

此处 $\mathcal{L}_{T2I}$ 和 $\mathcal{L}_{T2V}$ 为流匹配生成损失（式 (2)）； $\mathcal{L}_{TI2VA}$ 将式 (5) 的视频预测项与逆向动力学项结合，并采用多块目标 $\mathcal{L}_{MCP}$ (Eq. (23))； $\mathcal{L}_{ICL}$ 为式 (24) 的上下文目标； $\mathcal{L}_{HCT}$ 为第 2.3.5 节的人机协同训练损失。

采样分布 $\pi(\tau)$ 遵循由粗到细的调度。训练早期（ $\tau \rightarrow 0$ ）将大部分质量置于 T2I 上，以建立外观与语义对齐；随后质量转向 T2V 以巩固时序动态；训练后期（ $\tau \rightarrow 1$ ）集中于视频动作任务（TI2VA、ICL、HCT），使共享表示专精于动作相关控制。由于所有任务共享参数，早期强调的目标在后期阶段仍提供微小但非零的正则化信号，在模型适应具身控制的同时保留广泛的图像与视频先验。

2.3.7 前瞻推理

在多流大语言模型（Multi-Stream LLMs）的多流视角 [87] 中，单一串行计算流是自阻塞的：模型必须完成计算后机器人才能行动，机器人必须完成行动后新的观测才会返回。因此，我们将闭环推演组织为两个因果耦合、以不同速率推进的流：预测流，模型在其中预测未来视觉潜变量及由其解码的动作；执行流，机器人在其中于真实世界执行当前动作块。同步运行时，两个流相互阻塞：执行完块 a_t 后，机器人空闲等待模型去噪下一块，从而将模型延迟转化为控制延迟。

前瞻推理（Foresight Reasoning）异步运行这两个流。当机器人执行动作块 a_t 时，预测流在 a_t 的真实观测返回之前准备下一个动作块 a_{t+1} 。它首先将当前正在执行的动作块 a_t 追加到最新的反馈接地缓存 C_t ——即总结接地历史 $(z_{\leq t}, a_{< t})$ 的键值缓存条目——得到临时上下文 $C_{\text{tmp}} = C_t \cup \{a_t\}$ 。随后，策略的视频专家运行一次前向动力学传递，该传递由策略本身在线执行，而非由分词器的冻结前向动力学模型（FDM） f_ψ 执行，以想象当前块的视觉结果，

$$\hat{z}_{t+1} = \text{FDM}_\theta(C_t \cup \{a_t\}) = v_\theta^{\text{vid}}(z_{\leq t}, a_{\leq t}), \quad (29)$$

动作专家从 $C_{\text{tmp}} \cup \{\hat{z}_{t+1}\}$ 解码下一个动作块。因此，当 a_t 执行完成时 a_{t+1} 已准备就绪，从而将预测延迟隐藏在运动之后。然而，超前运行并非没有代价：如果预测流不断将自身的 $\hat{z}_{t+1}$ 反馈回上下文，推演将变为开环；由于视频骨干网络偏好时间




图 6. 前瞻推理作为异步推理/执行流程。冷启动初始化键值缓存并预计算第一个动作块。循环期间，执行器运行当前块，同时真实观测进入观测队列（OBSQUEUE）；推理分支用这些观测重新接地键值缓存，追加当前正在执行的动作，利用前向动力学模型接地想象其视觉结果，并在执行停顿前预测下一个动作块。

平滑性，它会延续这条幻觉轨迹，忽略物理反馈，并漂移直至策略无法再做出反应。

因此，每当真实观测到达时，我们都会重新锚定展开过程。当块 a_t 完成后，返回的观测被编码为真实潜在状态 z_{t+1} ，并与已执行的动作块 a_t 一起覆盖键值缓存中过时的预测上下文 $\hat{z}_{t+1}$ 。因此，下一步预测从反馈锚定的缓存 C_{t+1} 开始，而非从未经验证的想象潜在状态开始。异步展开因此保持闭环——这是一个先预测后校正的步骤，其中快速预测流先行起草，而每个真实观测将其拉回。为了训练视频专家胜任这一角色，后训练阶段增加了一个前向动力学锚定损失，监督其根据反馈锚定的上下文和已执行的动作预测下一个视觉潜在状态，遵循公式（2）的流匹配目标：

$$\mathcal{L}_{\text{FDM}} = \mathbb{E}_{t, s, \epsilon} \left[\left\| v_{\theta}^{\text{vid}}(z_{t+1}^{(s)} | z_{\leq t}, a_{\leq t}) - (z_{t+1} - \epsilon) \right\|^2 \right], \quad (30)$$

与异步推理期间使用的公式（29）的条件设定相匹配。与仅以过去动作 $a_{<t}$ 为条件的视频损失 $\mathcal{L}_{\text{vid}}$ (Eq. 6) 不同，该目标额外输入已执行的动作 a_t (i.e. $a_{\leq t}$)，将视频专家转变为当前转移的真正前向动力学预测器。与多流大语言模型 [87] 不同，后者的流承载输入/输出角色，而我们的流承载预测的未来世界状态，因此闭环控制依赖于根据真实观测重新锚定它们——这一步骤在语言设置中没有对应物。前瞻推理是一种独立于第 2.3.3 节多上下文预测模块的推理时方案：两者可以分别启用。

与跳跃推理的关系。直接视频-动作（DVA）提出跳跃推理作为一种相关方法，将模型延迟隐藏在机器人执行之后 [90]。在两种情况下，策略都不会等待当前运动完成才准备下一个运动：预测在执行仍在进行时提前推进。关键区别在于异步流所携带的状态。跳跃推理将因果视频-动作推演推进到足够远的未来，使得下一个动作可以在当前动作完成后解码。前瞻推理则将预测的未来潜在状态视为基于前向动力学模型（FDM）的缓存更新。在每个块中，流从基于观测的键值（KV）缓存开始，以当前正在执行的动作作为条件，并使用策略的前向动力学模型（FDM）预测下一个视觉潜在状态。该预测潜在状态被插入缓存，以便动作专家能够在执行停滞之前解码未来动作。一旦真实观测到达，它通过覆盖草拟的潜在状态来重新校准缓存，

之后下一个 FDM 预测从校正后的状态开始。因此，我们的异步执行在每个块上都是显式动作条件化的且闭环的，同时仍然隐藏了大部分下一块预测延迟。

2.4 后训练

2.4.1 扩散蒸馏

后训练策略通过沿概率流（PF）常微分方程（ODE）积分流匹配速度场来采样每个块；在 LingBot-VA 中，视频专家默认使用 5 个去噪步骤，动作专家使用 10 个。为了使策略实时化，我们将其蒸馏为少步一致性模型 [85]。一致性模型 $f_\xi(x^{(s)}, s)$ 将 PF-ODE 轨迹上的任意点直接映射到其干净端点，满足自治性属性 $f_\xi(x^{(s)}, s) = f_\xi(x^{(s')}, s')$ ，对于同一轨迹上的任意 s, s' 以及数据端的边界条件 $f_\xi(x^{(1)}, 1) = x^{(1)}$ 。为了简化符号， x, v_θ 和 f_ξ 代表任一专家——视频专家作用于视觉潜在状态 z 或动作专家作用于动作块 a ——每个都保留其通常的因果上下文条件 $(z_{\leq t}, a_{< t}, \dots)$ ，此处省略。

我们将后训练模型 v_θ 作为冻结教师，并将 $s \in [0, 1]$ 离散化为网格 $s_0 < \dots < s_M = 1$ 。对于干净目标 x ——视频专家的视觉潜在状态 z_{t+1} 或动作专家的动作块 a_t ——以及噪声 ϵ ，我们形成噪声点 $x^{(s_n)} = (1 - s_n)\epsilon + s_n x$ ，并朝数据端执行一步教师欧拉步骤，

$$\hat{x}^{(s_{n+1})} = x^{(s_n)} + (s_{n+1} - s_n) v_\theta(x^{(s_n)}, s_n). \quad (31)$$

然后训练学生在两个相邻点上给出一致的预测，

$$\mathcal{L}_{CD} = \mathbb{E}_{x, \epsilon, n} \left[d(f_\xi(x^{(s_n)}, s_n), f_{\xi^-}(\hat{x}^{(s_{n+1})}, s_{n+1})) \right], \quad (32)$$

其中 ξ^- = 停止梯度（stopgrad）（ ξ ）是一个指数移动平均目标网络， $d(\cdot, \cdot)$ 是一个距离度量（我们使用平方 ℓ_2 ）。我们对两个专家模型都进行蒸馏，将视频和动作采样器分别从 5 步和 10 步减少到各 2 步，因此部署的策略在两次函数评估中即可生成每个块。

2.4.2 推理加速

我们将推理加速组织为三个层次：模型级编译、序列级注意力优化和系统级运行时摊销。这些层次对应于推理栈的不同部分。在模型执行层面，我们降低每次 DiT 前向传播的成本。在自回归序列层面，我们优化长时程推演过程中历史状态的存储、更新和注意力计算方式。在运行时系统层面，我们消除模型调用周围重复的主机端准备、冗余内存分配和不必要的同步。

模型级：低精度编译执行。每个推理步骤中的主要计算是视频和动作分支的 DiT 前向传播。我们通过基于 ONNX 的 TensorRT 构建流水线部署 DiT。TensorRT 将 PyTorch 计算图转换为优化的执行计划，执行硬件特定的核函数选择，并在后端支持时融合兼容操作。为满足 TensorRT 所需的静态接口，诸如 KV 缓存之类的运行时状态被表示为显式的引擎输入和输出，而非隐式的 Python 端模块状态。该接口在引擎构建期间暴露缓存容量，并支持固定的执行配置。FP8 量化节点通过 NVIDIA 模型优化器插入。实践中，头部和尾部层保持 BF16 精度，而变换器块内部的线性层以 FP8 执行。

序列层面：长时程注意力优化。尽管编译执行加速了单次 DiT 调用，自回归展开仍面临随交互时程增长而增加的注意力成本。因此，本文联合优化缓存布局与注意力算子。在运行时，采用分页/非规则键值缓存管理，以避免历史词元的重复填充与重打包。缓冲区容量由滑动窗口长度决定。缓存更新在预分配缓冲区内原地执行，同时显式跟踪有效长度、缓存位置与页面元数据。为直接消费这一紧凑表示，本文将通用 TensorRT 注意力子图替换为基于 FlashInfer 的注意力插件，该插件在分页/非规则缓存上执行注意力，无需物化填充的稠密张量。

系统层面：运行时开销削减。除 DiT 计算与键值缓存管理外，异步推理循环还包含重复的主机端准备工作。尽管每项操作单独开销较小，但在大量展开块与去噪步骤中累积成本不可忽视。本文通过缓存可复用的运行时对象并在执行状态不变时跳过冗余工作来摊销这些成本。具体而言，缓存已接受的 TensorRT 绑定与形状配置，复用运行时张量与层视图，预计算交叉注意力键值状态，缓存帧标识与调度器步骤元数据，并在引导后避免冗余的缓存更新路径。同时，从推理路径中移除不必要的 CPU-GPU 同步点。

综上，这三个层面分别解决了推理栈中的互补瓶颈：变换器前向计算、历史状态上的长时程注意力，以及模型执行周围的重复运行时开销。

3 数据配方

LingBot-VA 2.0 采用遵循第 2 节多任务课程的数据配方进行训练：通用文本到图像预训练、通用文本到视频预训练，最后在具身数据上进行视频-动作适配。

3.1 通用图像/视频数据

对于通用文本到图像与文本到视频预训练阶段，本文复用为 LingBot-Video [70] 整理的图像与视频语料库。这些网络规模的图像与视频数据在视频-动作适配之前提供了广泛的外观与动力学先验。

3.2 机器人数据

与第一代灵博-VA 机器人语料库 [50] 相比，后者包含数千小时的操作数据，灵博-VA 2.0 中的机器人阶段保留了同样广泛的公开、半公开和内部收集轨迹的混合，同时增加了数千小时的内部机器人演示。保留的来源包括 AgiBot[2]、RoboMind[108]、InternData-A1[93]、Open X-Embodiment/OXE[73]（包括 DROID[41]）、UMI 风格数据集 [22, 78, 126] 和 RoboCOIN[110]。

所有机器人数据均通过统一的标注流程重新处理。每条长轨迹被分割为原子动作片段，每个片段使用 Qwen3.5-397B 分配一个语言提示和一个全局任务指令。这一重新标注步骤修复了早期版本中缺失或过于笼统的提示，并使语言监督在不同实施例和数据集之间更加一致。

3.3 以自我为中心的人类数据 除了机器人数据外，我们还包括一个内部的以自我为中心的人类操作语料库，作为具身交互数据的可扩展来源。该语料库包含数千小时的第一人称操作视频，跨越 65.4 k 个片段。数据在五个主要的桌面导向环境类别中保持平衡：厨房、餐桌、梳妆台、办公桌和工具台。在这些类别中，语料库涉及 600 多名操作员和超过 3.0k 个场景-任务组合，涵盖日常操作技能，如物体放置、清洁、补充、组装、包装、文具使用、工具使用和化妆品整理。

每个片段以单一自我中心 RGB 流捕获，并逐帧标注双手在世界坐标系中的 6 自由度根位姿以及每只手 22 个手指关节角度。对于自我中心数据，关键额外步骤是这些手部位姿与机器人夹爪动作空间对齐。我们保留两条 6 自由度手部根轨迹，并将高维手指关节轨迹转换为左/右标量平行夹爪开度。这产生了一种紧凑的机器人兼容动作表示，同时保留了双手的全局运动。转换后的片段随后被纳入与机器人语料库相同的统一标注和过滤流程，然后用于第 2.3.5 节的人机协同训练。

3.4 上下文学习数据

为支持第 2.3.4 节中的人类视频上下文学习，本文利用 Zero-WAM [60] 中的数据流水线，将机器人视频转换为具有一致任务语义的人类视频。为确保上下文学习在少样本或未见任务上的稳健泛化，




图 7. 上下文人类-机器人数据策展流水线。机器人视频按任务语义采样，经视觉语言模型转换为人类演示提示，合成为人类视频，并在与原始机器人轨迹配对为上下文学习样本前进行筛选。

本文依据任务分类法从大规模机器人视频数据集中采样视频，从而构建具有丰富多样任务语义的大规模上下文人类-机器人数据集。对于每个采样的机器人视频，首先采用视觉语言模型（如 Gemini-3.1-Pro [91]）进行任务分析，并生成图像编辑提示，将机器人首帧转换为人类操作的初始观察。该编辑过程对视点、场景或物体实例不施加任何约束，仅要求保留原始机器人任务语义。随后，给定编辑后的初始观察图像，再次利用视觉语言模型为相应操作任务生成人类视频生成提示，驱动视频生成模型（如 WAN-2.6 [95] 或 Kling-V3 [45]）合成人类操作视频。最后，利用视觉语言模型对生成视频进行评估，分别对任务语义保持度和物理合理性进行评分。合格的人类视频随后与其原始机器人对应视频配对，形成独立的上下文学习样本。由此产生的上下文学习数据集涵盖超过 10 个机器人视频预训练数据集（如 AgiBot [2]、OXE [73]）的数据，包含超过 5,000 个任务和超过 50,000 个样本。

4 实验

4.1 实现与训练细节

4.1.1 网络架构

骨干网络。我们的模型是一个从头训练的扩散 Transformer (DiT)，运行在我们的语义视觉-动作分词器（96 个潜通道）的潜空间上。视频潜变量通过 $1 \times 2 \times 2 (T \times H \times W)$ 线性块嵌入被分块为视觉令牌流。视频骨干由 30 个 Transformer 块组成，视频隐藏维度为 2048；联合自注意力在 3072 维注意力空间（24 个注意力头 $\times$ 128 头维度）中执行。其前馈通路实现为稀疏 MoE 路由层，包含 128 个路由由 SwiGLU 专家、top-8 路由、一个共享专家，每个专家的中间维度为 512，而动作流使用如下所述的密集 FFN。

MoT 架构。动作令牌在每个块内由并行的、更窄的专家流处理。原始动作具有统一的 30 维动作空间（按数据集分位数归一化；缺失维度零填充并掩码），并通过单个无偏置线性层嵌入到 768 的动作隐藏维度（共享注意力宽度的四分之一）。动作 FFN 维度按比例缩放至 3072。视频和动作令牌通过共享的 3072 维注意力空间中的联合自注意力进行交互：视频查询/键/值被投影 $2048 \rightarrow 3072$ ，动作查询/键/值被提升 $768 \rightarrow 3072$ ，注意力输出被投影回各自流的宽度。在交叉注意力中，动作流具有自己的查询和输出投影，但与视频流共享文本键/值投影。

所有其余组件都是模态特定的：视频的稀疏 MoE 层、动作的密集 FFN、LayerNorm、AdaLN 表、时间步/文本条件嵌入器（768 维副本），以及输出头（视频的 LayerNorm + 线性到 $96 \cdot 4$ 每个块的潜通道；动作的 LayerNorm + 线性 $768 \rightarrow 30$ ）。

因果分块生成。模型在分块级别上自回归地生成视频：帧被分组为时间块，自注意力是块因果的，并在过去块上使用滑动窗口。在训练期间，块大小在每个步骤从 1 - 4 个潜在帧中均匀重采样，注意力窗口从 1 - 64 个块中均匀重采样，因此单个模型在推理时支持可变的块大小和历史长度（我们在评估中使用块大小 2 和 64 块窗口）。为了减少自回归展开过程中的曝光偏差，我们应用扩散强制风格的上下文噪声增强：以 0.5 的概率，将干净的历史帧替换为在随机采样的（小）噪声级别下的加噪版本。

多块预测（MCP）。作为辅助训练目标，轻量级 MCP 头预测下一个块之外的 1 - 3 个块。隐藏状态从骨干层 {3, 11, 19, 29} 收集，通过两层 SiLU MLP ($4 \times 2048 \rightarrow 2048 \rightarrow 2048$ 融合，并馈送到 3 个深度组，每组包含 3 个额外的变换器块（配置与骨干块相同，包括动作专家）；每个深度 d 还通过每个深度的线性投影（拼接 $\rightarrow 2048$ ）接收第 $(d+1)$ 个未来块的加噪潜在变量。三个深度以损失权重 0.5 / 0.2 / 0.1 进行监督。MCP 头仅用于训练时监督；标准推理仅运行骨干网络。

条件注入。文本提示由密集 UMT 文本编码器编码为 4096 维令牌嵌入（最多 512 个令牌），经过两层 MLP 投影后通过交叉注意力注入。扩散时间步通过正弦嵌入（256 维）进入，随后通过 MLP 产生 AdaLN 调制信号；视频流和动作流携带独立的时间步条件，允许两种模态具有解耦的噪声级别。

参数数量（约）。视频骨干 ≈ 13.0 B 总计 / ≈ 1.9 B 活跃；动作专家 ≈ 0.6 B；MCP 头 ≈ 1.7 B；总计 ≈ 15.3 B 训练参数（其中推理时每个令牌活跃 ≈ 2.5 B）。

4.1.2 训练方案

目标。所有阶段均采用整流流（流匹配）目标进行训练：网络预测噪声与数据之间的速度，并通过调度器的时间步相关损失重加权以均方误差进行监督。时间步按均匀分布采样，并施加模态特定的时间步偏移：图像为 2，网络/视频数据为 2，机器人视频-动作数据为 5，多模态控制协议分支为 10，动作模态为 1（无偏移），其时间步独立于视频时间步采样。文本嵌入以 0.1 的概率被丢弃，用于无分类器引导。

优化。我们采用混合的 Muon 与 AdamW 优化器。变换器块内部的所有二维权重矩阵（注意力投影、密集动作前馈网络投影以及路由的专家混合专家投影）使用 Muon 更新（学习率 2×10^{-3} ，动量 0.95，权重衰减 0.1）；其余所有参数——嵌入器、归一化/自适应层归一化参数、偏差以及输出头——使用 AdamW 更新（学习率 1×10^{-4} ， $\beta = (0.9, 0.95)$ ， $\epsilon = 10^{-8}$ ，权重衰减 0.01）。学习率在前 2000 步线性预热，之后保持不变。梯度裁剪至全局范数 1.0。

系统。训练采用全分片数据并行（FSDP）全参数分片（无张量/流水线/上下文并行），bf16 混合精度与 FP32 梯度归约，全激活检查点，以及弹性多节点启动器。每个秩每步处理一个打包序列（本地批大小 1）。我们保留 1% 的数据用于验证。

4.2 真实世界部署

4.2.1 真实世界评估

我们在一个内部机器人基准上评估真实世界操作，该基准涵盖多种日常操作任务。我们报告四项任务的结果：i) 水果分拣，机器人将苹果、梨和橙子放入篮子；ii) 笔收集，机器人依次将桌上的三支笔放入杯子；iii) 抽屉整理，机器人打开抽屉并将桌面上的物体放入其中；iv) 盘子交接，机器人将盘子推到中央，拿起纸垫放在盘子上，然后将目标物体放在纸垫上。




图 8. 真实世界部署结果。跨真实世界任务的成功率和任务进度率，比较 LingBot-VA 2.0 与代表性基线。

对于每项任务，我们收集 20 个遥操作演示，并通过多任务监督微调训练一个通用策略，而非为每项任务单独训练模型。在评估阶段，同一检查点被部署到所有任务上，我们报告每项任务的成功率以及多次重复执行的平均任务进度得分。

我们将所提方法与视觉-语言-动作（VLA）和视频-动作（VA）模型家族中的代表性基线进行比较。对于 VLA 模型，我们使用 $\pi_{0.5}$ [77] 作为主要基线。对于 VA 模型，我们与 LingBot-VA[50] 进行比较，该模型同样对未来视觉动态进行建模以生成动作。如图 8 所示，LingBot-VA 2.0 在真实世界任务中取得了最强的整体性能，在成功率和任务进度上均优于 VLA 基线和先前的 VA 基线。与 $\pi_{0.5}$ 相比，在需要更长时域视觉定位的连续操作任务上，改进尤为明显。通过显式预测未来视觉状态，LingBot-VA 2.0 能够在多个交互步骤中保持任务级上下文，同时其视频定位也提高了局部操作的精确率。与 LingBot-VA 相比，性能提升源于因果视频-动作预训练，该预训练使模型在下游策略微调之前接触到更具泛化性的视频-动作对应关系。这种更广泛的预训练在更具挑战性的多任务设置中尤为有益，因为策略必须跨不同物体、场景和任务流程进行泛化。

4.2.2 上下文学习演示

为了定性检验 LingBot-VA 2.0 能否将视觉演示而非文本指令作为任务上下文，我们在上述真实世界评估之外单独进行了一项上下文学习（ICL）研究。如图 9 所示，桌面场景包含三个盘子（绿色、白色和银色）和七个物体：一个银色马克杯、两个绿色梨、一个葫芦、一个银色咖啡杯、一个黄色梨和一个白色纸杯。在数据收集阶段，我们仅收集四项训练任务：i) 将白色纸杯放入白色盘子；ii) 将银色咖啡杯放入银色盘子；iii) 将中间的绿色梨放入绿色盘子；iv) 将左侧的银色马克杯放入白色盘子，每项任务包含 15 个演示。我们在这四项已见任务上对预训练模型进行微调。

在测试阶段，我们在训练集中未出现的新任务组合上进行评估。策略接收一段人类参考视频作为演示上下文，以及当前的机器人观测，然后在不更新模型参数的情况下执行任务。图 9 展示了四个未见任务的可视化示例：i) 将葫芦放入绿色盘子中，ii) 将白色纸杯放入银色盘子中，iii) 将银色咖啡杯放入白色盘子中，以及 iv) 将银色马克杯旁的绿色梨放入白色盘子中，所有这些任务均未出现在训练任务中。该设置




图 9. 上下文学习演示。我们展示了在四个未见任务上的上下文学习（In-Context Learning）执行过程。对于每次执行，给定一段参考视频演示作为任务指令以及机器人观测，LingBot-VA 2.0 在不更新参数的情况下将相同的动作流程迁移到机器人操作中。

表 1. RoboTwin 2.0。在干净和域随机化设置下的双手操作成功率（%）。干净/随机化分别对应 LingBot-VA [50] 中报告的简单/困难设置。

Method	Clean	Randomized	Avg.
X-VLA [128]	72.9	72.8	72.9
$\pi_{0.5}$ [77]	82.7	76.8	79.8
Motus [8]	88.7	87.0	87.9
LingBot-VA [50]	92.9	91.6	92.2
LingBot-VA 2.0 (Ours)	93.8	93.4	93.6

评估视频-动作骨干网络是否能够从上下文视频中提取程序性线索，并将其迁移到新的任务组合、物体排列和物体实例上。

4.3 仿真

我们在 RoboTwin [19] 上评估 LingBot-VA 2.0，这是一个包含干净和域随机化设置的双手操作基准，并报告与代表性基线相比的任务成功率（%）。遵循 LingBot-VA [50] 的做法，我们采用多任务训练设置，所有模型均在干净场景中收集的 2,500 条演示（每个任务 50 条）以及来自重度随机化场景的 25,000 条演示（每个任务 500 条）上进行训练。

结果。如表 1 所示，LingBot-VA 2.0 在干净和域随机化的 RoboTwin 设置上均取得了最佳性能。与视觉-语言-动作（VLA）基线 $\pi_{0.5}$ 相比，LingBot-VA 2.0 将平均成功率提高了 14.0 个百分点，表明原生视频-动作预训练为双手操作提供了更强的物理基础。在已有的视频-动作（VA）方法中，LingBot-VA 是最强的基线，平均成功率为 92.2%，而 LingBot-VA 2.0 进一步将平均结果提升至 93.6%。LingBot-VA 2.0 在干净与随机化评估之间的差距也很小（0.6 个百分点），表明该模型在视觉和物理域变化下仍能保持鲁棒控制。

表 2. RoboTwin 2.0 上的分词器消融实验。在 50 个任务的简单与困难划分上，采用不同视觉分词器的 1.3B 视频-动作模型的成功率 (%)。

Metric	WAN2.2 VAE		Our tokenizer	
	Easy	Hard	Easy	Hard
Average _{hor=1}	81.1	78.4	86.2	83.1
Average _{hor=2}	75.5	73.9	85.7	84.0
Average _{hor=3}	67.2	68.0	92.0	85.4
Average _{50 Tasks}	78.0	76.0	86.6	83.1




图 10. 多块预测消融实验。在 RoboTwin 上，任务成功率 (%) 随训练步数的变化。与基线相比，多块预测在 12 和 50 帧每秒下均收敛更快，并达到更高的最终准确率。

4.4 消融实验

语义视觉-动作分词器。为隔离分词器的影响，我们为每个变体从头训练一个 1.3B 视频-动作模型。WAN2.2 VAE 基线与我们分词器使用相同数量的标记进行训练，并用于初始化相同的下游架构。随后，我们应用相同的 RoboTwin 后训练，并在官方的简单与困难划分上评估成功率。表 2 中的分词器消融实验表明，用我们的分词器替换面向重建的 WAN2.2 VAE，在不同预测时域上均一致地提升了 RoboTwin 的性能。时域越长，增益越大，这表明语义视觉-动作分词保留了对于世界-动作建模和下游控制更有用的状态信息。

多块预测。图 10 比较了有无多块预测目标时的后训练动态。我们首先训练一个 5B 视频-动作基线，然后在相同的数据和优化设置下进行 RoboTwin 后训练，仅在两个变体之一中启用多块预测。多块预测一致地提升了优化效率，在 12 和 50 帧每秒下均收敛更快，并达到更高的最终任务成功率。这一优势在 50 帧每秒时最为显著：训练 5k 步后，多块预测变体在随机化设置下已比基线高出 29.7 个百分点，并且仅用 20k 步就达到了基线 45k 步的准确率，相当于 a $2.3\times$ 的训练加速。

加速。表 3 报告了本文推理加速流水线的累积效果。异步赫兹值按 $(1000/t_{\text{chunk}}) \times K$ 计算，其中 t_{chunk} 为实测推理时间（毫秒）， K 为每个生成块中的底层控制步数；本文实验中设置 $K = 32$ 。从 BF16 PyTorch 异步推演基线出发，一致性蒸馏首先减少每个块所需的去噪步数，将每块推理时间从 927 毫秒降至 466 毫秒。随后应用第 2.4.2 节所述的三项推理优化。低精度编译执行通过以 FP8 TensorRT 引擎替代即时 DiT 前向传播来加速模型执行层，将延迟降至每块 369 毫秒。长时程注意力优化进一步改进自回归序列层，采用分页/不规则 KV 缓存执行与 FlashInfer 注意力插件，将延迟降至每块 272 毫秒。最后，运行时开销削减摊薄了重复的主机端准备、内存分配与同步成本，使端到端推理时间达到每块 142 毫秒。总体而言，这些优化将异步控制频率从 35 赫兹提升至 225 赫兹，实现 $6.5\times$ 的端到端加速。

表 3. 推理加速。不同加速技术下的推理时间与异步控制频率。

Acceleration technique	Inference time (ms/chunk) ↓	Async Hz ↑
BF16 PyTorch async rollout baseline	927	35
+ Consistency distillation	466	69
+ Low-precision compiled execution	369	87
+ Long-horizon attention optimization	272	118
+ Runtime overhead reduction	142	225




图 11. 真实世界演示。LingBot-VA 2.0 在四项代表性任务上的定性推演，涵盖长时程桌面整理、与移动物体交互、精细抓取及反应式视觉控制。

4.5 演示

图 11 展示了四项真实世界演示，分别检验视频-动作建模的不同方面。桌面整理强调长时程规划，要求策略解析杂乱的桌面场景、随时间保持物体状态并编排多步清理行为。传送带测试时间定位与动态预测，模型须预判移动物体并使每个动作块与传送带运动同步。芯片拾取考验无触觉传感器条件下的精细操作与控制，需视觉引导下轻柔抓取薄片物体。空气曲棍球评估动态游戏场景中的快速推理与反应式控制，策略须迅速预测冰球轨迹并根据近期观测闭环。

5 相关工作

5.1 通用机器人策略与视觉-语言-动作模型

视觉-语言-动作（VLA）模型直接将视觉观测和语言指令映射为动作，继承了互联网规模预训练带来的广泛语义先验 [6, 9, 11, 12, 30, 38, 43, 49, 51, 55, 63, 65, 71, 72, 76, 77, 104,

114, 128]。工业基础模型如 LingBot-VLA [111]、Qwen-RobotManip [119] 和 WALL-OSS 变体 [118, 121] 进一步推动这些策略走向真实世界部署。一条密切相关的研究路线学习视觉运动策略，从演示中回归动作序列，例如 ACT [125] 和扩散策略 [21]，而其他方法则加入视觉思维链或指令推理 [69, 84, 115, 124]，并通过显式记忆模块注入时间上下文 [48, 82, 86]。这些策略是反应式的：它们学习直接的观测到动作映射，而不建模场景如何演化，这限制了长时程一致性和样本效率。相比之下，LingBot-VA 2.0 将控制建立在预测的物理动力学之上。

5.2 用于控制的视频生成与世界-动作模型

世界-动作模型将视觉世界建模扩展到机器人控制，利用预测的场景演化作为动作生成的中间表示 [5, 15, 17, 28, 36, 39, 50, 53, 59, 92, 105 – 107, 116, 120, 127, 134]。DreamZero[116] 适配了一个大型预训练视频扩散模型用于联合视频-动作建模，而 LingBot-VA[50] 将训练形式化为因果世界建模，联合学习帧预测与策略执行。更广泛的工作从互补角度将视频预测与策略学习相结合，包括视频生成即策略和视频条件策略 [7, 26, 35, 46, 57] 以及联合视频-动作建模 [54, 133]。相关努力将交互式或可控视频生成视为动力学模型 [1, 16, 29, 75, 79]，并使用生成的推演作为模拟器或想象计划用于策略学习与评估 [27, 42, 62, 89, 102, 131, 132]。除了像素空间预测，用于控制的世界模型也在紧凑潜空间中运行 [33, 34, 56, 68, 81, 103, 109]，或在结构化三维和粒子状态上运行 [47, 83, 88, 101, 113, 122, 123]。训练此类因果视频模型还建立在自回归视频生成技术之上，这些技术缩小了训练-测试差距，例如扩散强制 [18] 和自强制 [37]；灵活的多模态扩散框架 [4] 提供了互补的条件机制。关键的是，这些方法通过持续训练适配现成的双向视频生成器 [32, 74, 96]，而 LingBot-VA 2.0 则从头预训练一个原生因果视频-动作堆栈。直接视频-动作 (DVA) [90] 与 LingBot-VA 2.0 高度一致，主张原生因果视频-动作预训练，而非为控制改造双向视频生成器。两种方法都将动作生成视为因果视觉动力学模型的一部分，因此策略学习在产生控制的同时预测场景将如何演化。我们的设计在两个核心组件上有所不同。首先，我们将视频-动作堆栈构建在语义视觉-动作分词器之上，其变分自编码器明确为控制对齐，将视觉状态和潜在动作绑定在共享表示中，而非依赖通用的面向重建的视频潜变量。其次，我们为视频流设计了稀疏专家混合架构，提高动力学建模容量，同时保持动作流密集且稳定以用于控制。结合我们的推理加速和重新接地的异步推演，这些选择使原生因果预训练更匹配长时程机器人操作，同时实现更快的推理和更灵敏的闭环控制。

5.3 面向控制的表征：语义分词器与潜动作

另一条研究路线直接从观测序列中恢复类动作变量，使未标注视频可用于控制 [3]。Genie [13] 通过潜动作使视频动态可控；LAPO [80] 仅从视频中恢复潜动作策略、世界模型和逆动力学；LAPA [117] 将离散潜动作扩展到机器人操作；Moto [20] 和 UniVLA [14] 将抽象转向运动分词。RepWAM [99] 和 Motus [8] 将此类潜动作与面向表征的分词器配对。LingBot-VA 2.0 基于这一方向构建，但将世界状态和动作置于单一语义潜空间中——将视觉潜变量对齐到基础模型并联合学习潜动作——而非依赖仅重建的变分自编码器并单独附加动作模块。

6 结论

本文提出了 LingBot-VA 2.0，一个原生为机器人控制构建的视频-动作基础模型，而非从通用视频生成改编而来。其设计始终遵循一个原则：从表征到推理的每个组件都由具身控制的需求塑造。语义视觉-动作分词器将世界状态和潜动作置于与视觉基础模型对齐的单一潜空间中；因果 DiT 与稀疏专家混合视频流在该空间上从零开始预训练，多块预测、上下文学习和人机协同训练丰富了训练信号；前瞻推理与少步蒸馏和系统级加速相结合，将预训练模型转变为实时闭环控制器。在仿真和真实世界评估中，LingBot-VA 2.0 相较于强大的视觉-语言-动作和视频-动作基线均有提升，

仅通过少量演示即可适应新任务，并通过闭环重定位和分层规划维持长时程操作。

若干方向仍有待探索。规划器与策略目前分别训练，并通过固定接口耦合；更紧密的联合训练可能进一步提升长程一致性。潜在动作空间从被动视频中学习，交互或强化信号可使其更聚焦于控制。最后，进一步扩展预训练语料库与稀疏骨干网络，并将具身覆盖范围扩展到双手操作之外，是迈向通用具身基础模型的自然后续步骤。

7 贡献者

核心贡献者

预训练: 张启航、李林、王俊科、邵佳豪、徐刚伟、张璐瑶、周佳明、金字东、马帅磊、廖佳琪、郑嘉龙

预训练数据: 李林、张璐瑶、张启航、周佳明、金字东、王新阳

后训练: 张璐瑶*、杨帅*、李琳、张启航、徐刚伟、朱佳鹏、赵玉洁、唐伟轩

加速: 李帅廷、李超健

部署与演示: 罗一鸣*、杨帅*、王瑞林、沈一树、邵佳豪、徐方毅、李帅廷、卢冠兴、石梓帆、温永坤

项目监督: 沈宇军、朱星、薛楠 项目负责人: 徐英豪

贡献者

高泽林、吴伟、郑克成、张若楠、张涵、赵静梅、黄永涛、王海涛、王晶晶、宋晨

*Equal contribution

参考文献

- [1] 1X Technologies. 1x world model: From video to action. <https://www.1x.tech/discover/world-model-self-learning>, 2025. Accessed 2026-01-18.
- [2] AgiBot-World-Contributors, Qingwen Bu, Jisong Cai, Li Chen, Xiuqi Cui, Yan Ding, Siyuan Feng, Shenyuan Gao, Xindong He, Xuan Hu, Xu Huang, Shu Jiang, Yuxin Jiang, Cheng Jing, Hongyang Li, et al. Agibot world colosseo: A large-scale manipulation platform for scalable and intelligent embodied systems. *arXiv preprint arXiv:2503.06669*, 2025.
- [3] Bowen Baker, Ilge Akkaya, Peter Zhokov, Joost Huizinga, Jie Tang, Adrien Ecoffet, Brandon Houghton, Raul Sampedro, and Jeff Clune. Video pretraining (vpt): Learning to act by watching unlabeled online videos. In *Adv. Neural Inform. Process. Syst.*, 2022.
- [4] Fan Bao, Shen Nie, Kaiwen Xue, Chongxuan Li, Shi Pu, Yaole Wang, Gang Yue, Yue Cao, Hang Su, and Jun Zhu. One transformer fits all distributions in multi-modal diffusion at scale. In *Int. Conf. Mach. Learn.*, 2023.
- [5] Amir Bar, Gaoyue Zhou, Danny Tran, Trevor Darrell, and Yann LeCun. Navigation world models. In *IEEE Conf. Comput. Vis. Pattern Recog.*, 2025.
- [6] Jose Barreiros, Andrew Beaulieu, Aditya Bhat, Rick Cory, Eric Cousineau, Hongkai Dai, Ching-Hsin Fang, Kunimatsu Hashimoto, Muhammad Zubair Irshad, Masha Itkina, et al. A careful examination of large behavior models for multitask dexterous manipulation. *arXiv preprint arXiv:2507.05331*, 2025.
- [7] Homanga Bharadhwaj, Debidatta Dwibedi, Abhinav Gupta, Shubham Tulsiani, Carl Doersch, Ted Xiao, Dhruv Shah, Fei Xia, Dorsa Sadigh, and Sean Kirmani. Gen2act: Human video generation in novel scenarios enables generalizable robot manipulation. In *Conference on Robot Learning (CoRL)*, 2024.

- [8] Hongzhe Bi, Hengkai Tan, Shenghao Xie, Zeyuan Wang, Shuhe Huang, Haitian Liu, Ruowen Zhao, Yao Feng, Chendong Xiang, Yinze Rong, Hongyan Zhao, Hanyu Liu, Zhizhong Su, Lei Ma, Hang Su, et al. Motus: A unified latent action world model. *arXiv preprint arXiv:2512.13030*, 2025.
- [9] Kevin Black, Noah Brown, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Lachy Groom, Karol Hausman, Brian Ichter, Szymon Jakubczak, Tim Jones, Liyiming Ke, Sergey Levine, Adrian Li-Bell, et al. π_0 : A vision-language-action flow model for general robot control. In *Robotics: Science and Systems*, 2025.
- [10] Daniel Bolya, Po-Yao Huang, Peize Sun, Jang Hyun Cho, Andrea Madotto, Chen Wei, Tengyu Ma, Jiale Zhi, Jathushan Rajasegaran, Hanoona Bangalath, et al. Perception encoder: The best visual embeddings are not at the output of the network. In *NeurIPS*, 2025.
- [11] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Xi Chen, Krzysztof Choromanski, Tianli Ding, Danny Driess, Avinava Dubey, Chelsea Finn, Pete Florence, Chuyuan Fu, Montse Gonzalez Arenas, Keerthana Gopalakrishnan, Kehang Han, et al. Rt-2: Vision-language-action models transfer web knowledge to robotic control. In *Conference on Robot Learning (CoRL)*, 2023.
- [12] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Joseph Dabis, Chelsea Finn, Keerthana Gopalakrishnan, Karol Hausman, Alex Herzog, Jasmine Hsu, Julian Ibarz, Brian Ichter, Alex Irpan, Tomas Jackson, Sally Jesmonth, et al. Rt-1: Robotics transformer for real-world control at scale. In *Robotics: Science and Systems*, 2023.
- [13] Jake Bruce, Michael Dennis, Ashley Edwards, Jack Parker-Holder, Yuge Shi, Edward Hughes, Matthew Lai, Aditi Mavalankar, Richie Steigerwald, Chris Apps, Yusuf Aytar, Sarah Bechtle, Feryal Behbahani, Stephanie Chan, Nicolas Heess, et al. Genie: Generative interactive environments. In *Int. Conf. Mach. Learn.*, 2024.
- [14] Qingwen Bu, Yanting Yang, Jisong Cai, Shenyuan Gao, Guanghui Ren, Maoqing Yao, Ping Luo, and Hongyang Li. Univla: Learning to act anywhere with task-centric latent actions. In *Robotics: Science and Systems*, 2025.
- [15] Jun Cen, Chaohui Yu, Hangjie Yuan, Yuming Jiang, Siteng Huang, Jiayan Guo, Xin Li, Yibing Song, Hao Luo, Fan Wang, Deli Zhao, and Hao Chen. Worldvla: Towards autoregressive action world model. *arXiv preprint arXiv:2506.21539*, 2025.
- [16] Haoxuan Che, Xuanhua He, Quande Liu, Cheng Jin, and Hao Chen. Gamegen-x: Interactive open-world game video generation. In *Int. Conf. Learn. Represent.*, 2025.
- [17] Chi-Lam Cheang, Guangzeng Chen, Ya Jing, Tao Kong, Hang Li, Yifeng Li, Yuxiao Liu, Hongtao Wu, Jiafeng Xu, Yichu Yang, Hanbo Zhang, and Minzhao Zhu. Gr-2: A generative video-language-action model with web-scale knowledge for robot manipulation. *arXiv preprint arXiv:2410.06158*, 2024.
- [18] Boyuan Chen, Diego Marti Monso, Yilun Du, Max Simchowitz, Russ Tedrake, and Vincent Sitzmann. Diffusion forcing: Next-token prediction meets full-sequence diffusion. In *Adv. Neural Inform. Process. Syst.*, 2024.
- [19] Tianxing Chen, Zhanxin Chen, Baijun Chen, Zijian Cai, Yibin Liu, Zixuan Li, Qiwei Liang, Xianliang Lin, Yiheng Ge, Zhenyu Gu, Weiliang Deng, Yubin Guo, Tian Nian, Xuanbing Xie, Qiangyu Chen, et al. Robotwin 2.0: A scalable data generator and benchmark with strong domain randomization for robust bimanual robotic manipulation. *arXiv preprint arXiv:2506.18088*, 2025.
- [20] Yi Chen, Yuying Ge, Weiliang Tang, Yizhuo Li, Yixiao Ge, Mingyu Ding, Ying Shan, and Xihui Liu. Moto: Latent motion token as the bridging language for learning robot manipulation from videos. In *Int. Conf. Comput. Vis.*, 2025.
- [21] Cheng Chi, Siyuan Feng, Yilun Du, Zhenjia Xu, Eric Cousineau, Benjamin Burchfiel, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. In *Robotics: Science and Systems*, 2023.
- [22] Cheng Chi, Zhenjia Xu, Chuer Pan, Eric Cousineau, Benjamin Burchfiel, Siyuan Feng, Russ Tedrake, and Shuran Song. Universal manipulation interface: In-the-wild robot teaching without in-the-wild robots. In *Robotics: Science and Systems*, 2024.
- [23] Damai Dai, Chengqi Deng, Chenggang Zhao, R. X. Xu, Huazuo Gao, Deli Chen, Jia Shi Li, Wangding Zeng, Xingkai Yu, Y. Wu, Zhenda Xie, Y. K. Li, Panpan Huang, Fuli Luo, Chong Ruan, Zhifang Sui, and Wenfeng Liang. DeepSeekMoE: Towards ultimate expert specialization in mixture-of-experts language models. In *Proceedings of the Annual Meeting of the Association for Computational Linguistics*, 2024.
- [24] DeepSeek-AI. DeepSeek-V3 technical report. *arXiv preprint arXiv:2412.19437*, 2024.
- [25] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. In *Int. Conf. Learn. Represent.*, 2021.

- [26] Yilun Du, Mengjiao Yang, Bo Dai, Hanjun Dai, Ofir Nachum, Joshua B. Tenenbaum, Dale Schuurmans, and Pieter Abbeel. Learning universal policies via text-guided video generation. In *Adv. Neural Inform. Process. Syst.*, 2023.
- [27] Yilun Du, Sherry Yang, Bo Dai, Hanjun Dai, Ofir Nachum, Josh Tenenbaum, Dale Schuurmans, and Pieter Abbeel. Learning universal policies via text-guided video generation. *Advances in neural information processing systems*, 36:9156–9172, 2023.
- [28] Shenyuan Gao, Siyuan Zhou, Yilun Du, Jun Zhang, and Chuang Gan. Adaworld: Learning adaptable world models with latent actions. In *Int. Conf. Mach. Learn.*, 2025.
- [29] Zelin Gao, Qiuyu Wang, Jiapeng Zhu, Jingye Chen, Zichen Liu, Qingyan Bai, et al. Infinite worlds with versatile interactions. *arXiv preprint arXiv:2607.07534*, 2026.
- [30] Gemini Robotics Team. Gemini robotics: Bringing ai into the physical world. *arXiv preprint arXiv:2503.20020*, 2025.
- [31] Generalist AI. Gen-0: Embodied foundation models that scale with physical interaction. <https://generalistai.com/blog/nov-04-2025-GEN-0>, 2025. Built on Harmonic Reasoning.
- [32] Google DeepMind. Veo: A text-to-video generation system. *Google DeepMind Technical Report*, 2025.
- [33] Danijar Hafner, Jurgis Pasukonis, Jimmy Ba, and Timothy Lillicrap. Mastering diverse control tasks through world models. *Nature*, 2025.
- [34] Nicklas Hansen, Hao Su, and Xiaolong Wang. Td-mpc2: Scalable, robust world models for continuous control. In *Int. Conf. Learn. Represent.*, 2024.
- [35] Yucheng Hu, Yanjiang Guo, Pengchao Wang, Xiaoyu Chen, Yen-Jen Wang, Jianke Zhang, Koushil Sreenath, Chaochao Lu, and Jianyu Chen. Video prediction policy: A generalist robot policy with predictive visual representations. In *Int. Conf. Mach. Learn.*, 2025.
- [36] Siyuan Huang, Liliang Chen, Pengfei Liu, Yue Hu, Shengyu Zhang, Peng Gao, Hongsheng Li, Maoqing Yao, and Guanghui Ren. Enerverse: Envisioning embodied future space for robotics manipulation. *arXiv preprint arXiv:2501.01895*, 2025.
- [37] Xun Huang, Zhengqi Li, Guande He, Mingyuan Zhou, and Eli Shechtman. Self forcing: Bridging the train-test gap in autoregressive video diffusion. *arXiv preprint arXiv:2506.08009*, 2025.
- [38] Chia-Yu Hung, Qi Sun, Pengfei Hong, Amir Zadeh, Chuan Li, U-Xuan Tan, Navonil Majumder, and Soujanya Poria. Nora: A small open-sourced generalist vision language action model for embodied tasks. *arXiv preprint arXiv:2504.19854*, 2025.
- [39] Joel Jang, Seonghyeon Ye, Zongyu Lin, et al. Dreamgen: Unlocking generalization in robot learning through video world models. In *Conference on Robot Learning (CoRL)*, 2025.
- [40] Simar Kareer, Dhruv Patel, Ryan Punamiya, Pranay Mathur, Shuo Cheng, Chen Wang, Judy Hoffman, and Danfei Xu. Egomimic: Scaling imitation learning via egocentric video. *arXiv preprint arXiv:2410.24221*, 2024.
- [41] Alexander Khazatsky, Karl Pertsch, Suraj Nair, Ashwin Balakrishna, Sudeep Dasari, Siddharth Karamcheti, Soroush Nasiriany, Mohan Kumar Srirama, Lawrence Yunliang Chen, Kirsty Ellis, Peter David Fagan, Joey Hejna, Masha Itkina, Marion Lepert, Yecheng Jason Ma, et al. Droid: A large-scale in-the-wild robot manipulation dataset. In *Robotics: Science and Systems*, 2024.
- [42] Moo Jin Kim, Yihuai Gao, Tsung-Yi Lin, Yen-Chen Lin, Yunhao Ge, Grace Lam, Percy Liang, Shuran Song, Ming-Yu Liu, Chelsea Finn, et al. Cosmos policy: Fine-tuning video models for visuomotor control and planning. *arXiv preprint arXiv:2601.16163*, 2026.
- [43] Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, Ted Xiao, Ashwin Balakrishna, Suraj Nair, Rafael Rafailov, Ethan Foster, Grace Lam, Pannag Sanketi, Quan Vuong, Thomas Kollar, Benjamin Burchfiel, Russ Tedrake, Dorsa Sadigh, et al. Openvla: An open-source vision-language-action model. In *Conference on Robot Learning (CoRL)*, 2024.
- [44] Diederik P Kingma and Max Welling. Auto-encoding variational bayes. *arXiv preprint arXiv:1312.6114*, 2013.
- [45] KlingAI Team. Kling-v3. <https://kling.ai/>, 2026.
- [46] Po-Chen Ko, Jiayuan Mao, Yilun Du, Shao-Hua Sun, and Joshua B. Tenenbaum. Learning to act from actionless videos through dense correspondences. In *Int. Conf. Learn. Represent.*, 2024.
- [47] Chenchang Li, Zihao Ai, Tong Wu, Xiaosa Li, Wenbo Ding, and Huazhe Xu. Deformnet: Latent space modeling and dynamics prediction for deformable object manipulation. In *2024 IEEE International Conference on Robotics and Automation (ICRA)*, pages 14770–14776. IEEE, 2024.

- [48] Hao Li, Shuai Yang, Yilun Chen, Yang Tian, Xiaoda Yang, Xinyi Chen, Hanqing Wang, Tai Wang, Feng Zhao, Dahua Lin, et al. Cronusvla: Transferring latent motion across time for multi-frame prediction in manipulation. *arXiv preprint arXiv:2506.19816*, 2025.
- [49] Jiacheng Li, Mengzhou Sun, Bowen Zhang, Zhe Zhao, Xiu Liu, et al. Gr-3 technical report. *arXiv preprint arXiv:2507.15493*, 2025.
- [50] Lin Li, Qihang Zhang, Yiming Luo, Shuai Yang, Ruilin Wang, Fei Han, Mingrui Yu, Zelin Gao, Nan Xue, Xing Zhu, Yujun Shen, and Yinghao Xu. Causal world modeling for robot control. *arXiv preprint arXiv:2601.21998*, 2026.
- [51] Qixiu Li, Yaobo Liang, Zeyu Wang, Lin Luo, Xi Chen, Mozheng Liao, Fangyun Wei, Yu Deng, Sicheng Xu, Yizhong Zhang, Xiaofan Wang, Bei Liu, Jianlong Fu, Jianmin Bao, Dong Chen, Yuanchun Shi, Jiaolong Yang, and Baining Guo. Cogact: A foundational vision-language-action model for synergizing cognition and action in robotic manipulation. *arXiv preprint arXiv:2411.19650*, 2024.
- [52] Richard Li, Aditya Prakash, Andrew Wen, Saurabh Gupta, Yilun Du, and Pulkit Agrawal. What matters when cotraining robot manipulation policies on everyday human videos? *arXiv preprint arXiv:2606.06627*, 2026.
- [53] Shalfun Li, Victor Yao, Charles Yang, Truth Qu, Regis Cheng, Ryan Yu, Howard Lu, Newton Von, Vincent Chen, Yohann Tang, et al. Wall-wm: Carving world action modeling at the event joints. *arXiv preprint arXiv:2606.01955*, 2026.
- [54] Shuang Li, Yihuai Gao, Dorsa Sadigh, and Shuran Song. Unified video action model. In *Robotics: Science and Systems*, 2025.
- [55] Xinghang Li, Minghuan Liu, Hanbo Zhang, Cunjun Yu, Jie Xu, Hongtao Wu, Chilam Cheang, Ya Jing, Weinan Zhang, Huaping Liu, Hang Li, and Tao Kong. Vision-language foundation models as effective robot imitators. In *Int. Conf. Learn. Represent.*, 2024.
- [56] Yunzhu Li, Jiajun Wu, Jun-Yan Zhu, Joshua B Tenenbaum, Antonio Torralba, and Russ Tedrake. Propagation networks for model-based control under partial observation. In *2019 International Conference on Robotics and Automation (ICRA)*, pages 1205–1211. IEEE, 2019.
- [57] Junbang Liang, Ruoshi Liu, Ege Ozguroglu, Sruthi Sudhakar, Achal Dave, Pavel Tokmakov, Shuran Song, and Carl Vondrick. Dreamitate: Real-world visuomotor policy learning via video generation. In *Conference on Robot Learning (CoRL)*, 2024.
- [58] Weixin Liang, LILI YU, Liang Luo, Srini Iyer, Ning Dong, Chunting Zhou, Gargi Ghosh, Mike Lewis, Wen tau Yih, Luke Zettlemoyer, and Xi Victoria Lin. Mixture-of-transformers: A sparse and scalable architecture for multi-modal foundation models. *Transactions on Machine Learning Research*, 2025.
- [59] Yue Liao, Pengfei Zhou, Siyuan Huang, Donglin Yang, Shengcong Chen, Yuxin Jiang, Yue Hu, Jingbin Cai, Si Liu, Jianlan Luo, Liliang Chen, Shuicheng Yan, Maoqing Yao, and Guanghui Ren. Genie envisioner: A unified world foundation platform for robotic manipulation. *arXiv preprint arXiv:2508.05635*, 2025.
- [60] LingBot-VA Team, RobbyAnt. Zero-wam: In-context world modeling for zero-shot task generalization. <https://github.com/jiaming-zhou/Zero-WAM>, 2026.
- [61] Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matt Le. Flow matching for generative modeling. In *Int. Conf. Learn. Represent.*, 2023.
- [62] Dongxiu Liu, Haoyi Niu, Zhihao Wang, Jinliang Zheng, Yinan Zheng, Zhonghong Ou, Jianming Hu, Jianxiong Li, and Xianyu Zhan. Efficient robotic policy learning via latent space backward planning. In *Int. Conf. Mach. Learn.*, 2025.
- [63] Jiaming Liu, Hao Chen, Pengju An, Zhuoyang Liu, Renrui Zhang, Chenyang Gu, Xiaoqi Li, Ziyu Guo, Sixiang Chen, Mengzhen Liu, Chengkai Hou, Mengdi Zhao, KC alex Zhou, Pheng-Ann Heng, and Shanghang Zhang. Hybridvla: Collaborative diffusion and autoregression in a unified vision-language-action model. *arXiv preprint arXiv:2503.10631*, 2025.
- [64] Jingyuan Liu, Jianlin Su, Xingcheng Yao, Zhejun Jiang, Guokun Lai, Yulun Du, Yidao Qin, Weixin Xu, Enzhe Lu, Junjie Yan, Yanru Chen, Huabin Zheng, Yibo Liu, Shaowei Liu, Bohong Yin, Weiran He, Han Zhu, Yuzhi Wang, Jianzhou Wang, Mengnan Dong, Zheng Zhang, Yongsheng Kang, Hao Zhang, Xinran Xu, Yutao Zhang, Yuxin Wu, Xinyu Zhou, and Zhilin Yang. Muon is scalable for LLM training. *arXiv preprint arXiv:2502.16982*, 2025.
- [65] Songming Liu, Lingxuan Wu, Bangguo Li, Hengkai Tan, Huayu Chen, Zhengyi Wang, Ke Xu, Hang Su, and Jun Zhu. Rdt-1b: a diffusion foundation model for bimanual manipulation. In *Int. Conf. Learn. Represent.*, 2025.
- [66] Hao Luo, Yicheng Feng, Wanpeng Zhang, Sipeng Zheng, Ye Wang, Haoqi Yuan, Jiazheng Liu, Chaoyi Xu, Qin Jin, and Zongqing Lu. Being-h0: Vision-language-action pretraining from large-scale human videos. *arXiv preprint arXiv:2507.15597*, 2025.

- [67] Hao Luo, Wanpeng Zhang, Yicheng Feng, Sipeng Zheng, Haiweng Xu, Chaoyi Xu, Ziheng Xi, Yuhui Fu, and Zongqing Lu. Being-h0.7: A latent world-action model from egocentric videos. *arXiv preprint arXiv:2605.00078*, 2026.
- [68] Bethany Lusch, J Nathan Kutz, and Steven L Brunton. Deep learning for universal linear embeddings of nonlinear dynamics. *Nature communications*, 9(1):4950, 2018.
- [69] Qi Lv, Weijie Kong, Hao Li, Jia Zeng, Zherui Qiu, Delin Qu, Haoming Song, Qizhi Chen, Xiang Deng, and Jiangmiao Pang. F1: A vision-language-action model bridging understanding and generation to actions. *arXiv preprint arXiv:2509.06951*, 2025.
- [70] Shuailei Ma, Jiaqi Liao, Xinyang Wang, Jingjing Wang, Chaoran Feng, Zijing Hu, Chong Bao, Zichen Xi, Yuqi Gan, Weisen Wang, Yanhong Zeng, Qin Zhao, Zifan Shi, Wei Wu, Hao Ouyang, Qiuyu Wang, Shangzhan Zhang, Jiahao Shao, Yipengjing Sun, Liangxiao Hu, Lunke Pan, Nan Xue, Kecheng Zheng, Yinghao Xu, Xing Zhu, Yujun Shen, and Ka Leong Cheng. Scaling mixture-of-experts video pretraining for embodied intelligence. *arXiv preprint arXiv:2607.07675*, 2026.
- [71] NVIDIA. Gr00t n1: An open foundation model for generalist humanoid robots. *arXiv preprint arXiv:2503.14734*, 2025.
- [72] Octo Model Team, Dibya Ghosh, Homer Walke, Karl Pertsch, et al. Octo: An open-source generalist robot policy. In *Conference on Robot Learning (CoRL)*, 2024.
- [73] Open X-Embodiment Collaboration. Open x-embodiment: Robotic learning datasets and rt-x models. In *IEEE International Conference on Robotics and Automation (ICRA)*, 2024.
- [74] OpenAI. Video generation models as world simulators. *OpenAI Technical Report*, 2024.
- [75] Jack Parker-Holder, Philip Ball, Jake Bruce, Vibhavari Dasagi, Kristian Holsheimer, Christos Kaplanis, Alexandre Moufarek, Guy Scully, Jeremy Shar, Jimmy Shi, Stephen Spencer, Jessica Yung, Michael Dennis, Sultan Kenjeyev, Shangbang Long, et al. Genie 2: A large-scale foundation world model. <https://deepmind.google/discover/blog/genie-2-a-large-scale-foundation-world-model/>, 2024.
- [76] Physical Intelligence. $\pi_{0.7}$: a steerable generalist robotic foundation model with emergent capabilities. *arXiv preprint arXiv:2604.15483*, 2026.
- [77] Physical Intelligence, Kevin Black, Noah Brown, James Darpinian, Karan Dhabalia, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Manuel Y. Galliker, Dibya Ghosh, Lachy Groom, Karol Hausman, Brian Ichter, Szymon Jakubczak, Tim Jones, Liyiming Ke, Devin LeBlanc, Sergey Levine, Adrian Li-Bell, Mohith Mothukuri, Suraj Nair, Karl Pertsch, Allen Z. Ren, Lucy Xiaoyang Shi, Laura Smith, Jost Tobias Springenberg, Kyle Stachowicz, James Tanner, Quan Vuong, Homer Walke, Anna Walling, Haohuan Wang, Lili Yu, and Ury Zhilinsky. $\pi_{0.5}$: A vision-language-action model with open-world generalization. In *Conference on Robot Learning (CoRL)*, 2025.
- [78] Omar Rayyan, John Abanes, Mahmoud Hafez, Anthony Tzes, and Fares Abu-Dakka. Mv-umi: A scalable multi-view interface for cross-embodiment learning. *arXiv preprint arXiv:2509.18757*, 2025.
- [79] Robbyant Team, Zelin Gao, Qiuyu Wang, Yanhong Zeng, Jiapeng Zhu, Ka Leong Cheng, et al. Advancing open-source world models. *arXiv preprint arXiv:2601.20540*, 2026.
- [80] Dominik Schmidt and Mingqi Jiang. Learning to act without actions. In *Int. Conf. Learn. Represent.*, 2024.
- [81] Bokui Shen, Zhenyu Jiang, Christopher Choy, Silvio Savarese, Leonidas J Guibas, Anima Anandkumar, and Yuke Zhu. Action-conditional implicit visual dynamics for deformable object manipulation. *The International Journal of Robotics Research*, 43(4):437–455, 2024.
- [82] Hao Shi, Bin Xie, Yingfei Liu, Lin Sun, Fengrong Liu, Tiancai Wang, Erjin Zhou, Haoqiang Fan, Xiangyu Zhang, and Gao Huang. Memoryvla: Perceptual-cognitive memory in vision-language-action models for robotic manipulation. *arXiv preprint arXiv:2508.19236*, 2025.
- [83] Haochen Shi, Huazhe Xu, Zhiao Huang, Yunzhu Li, and Jiajun Wu. Robocraft: Learning to see, simulate, and shape elasto-plastic objects in 3d with graph networks. *The International Journal of Robotics Research*, 43(4):533–549, 2024.
- [84] Lucy Xiaoyang Shi, Brian Ichter, Michael Equi, Liyiming Ke, Karl Pertsch, Quan Vuong, James Tanner, Anna Walling, Haohuan Wang, Niccolo Fusai, et al. Hi robot: Open-ended instruction following with hierarchical vision-language-action models. *arXiv preprint arXiv:2502.19417*, 2025.
- [85] Yang Song, Prafulla Dhariwal, Mark Chen, and Ilya Sutskever. Consistency models. In *Int. Conf. Mach. Learn.*, 2023.
- [86] Ajay Sridhar, Jennifer Pan, Satvik Sharma, and Chelsea Finn. Memer: Scaling up memory for robot control via experience retrieval. *arXiv preprint arXiv:2510.20328*, 2025.

- [87] Guinan Su, Yanwu Yang, Xueyan Li, and Jonas Geiping. Multi-stream llms: Unblocking language models with parallel streams of thoughts, inputs and outputs. *arXiv preprint arXiv:2605.12460*, 2026.
- [88] Deborah Sulsky, Shi-Jian Zhou, and Howard L Schreyer. Application of a particle-in-cell method to solid mechanics. *Computer physics communications*, 87(1-2):236–252, 1995.
- [89] Gemini Robotics Team, Coline Devin, Yilun Du, Debidatta Dwibedi, Ruiqi Gao, Abhishek Jindal, Thomas Kipf, Sean Kirmani, Fangchen Liu, Anirudha Majumdar, et al. Evaluating gemini robotics policies in a veo world simulator. *arXiv preprint arXiv:2512.10675*, 2025.
- [90] Rhoda AI Team. Causal video models are data-efficient robot policy learners. *Rhoda AI Blog*, 2026.
- [91] The Gemini Team, Google. Gemini 3.1 pro: A smarter model for your most complex tasks. <https://blog.google/innovation-and-ai/models-and-research/gemini-models/gemini-3-1-pro/>, 2026.
- [92] Yang Tian, Sizhe Yang, Jia Zeng, Ping Wang, Dahua Lin, Hao Dong, and Jiangmiao Pang. Predictive inverse dynamics models are scalable learners for robotic manipulation. In *Int. Conf. Learn. Represent.*, 2025.
- [93] Yang Tian, Yuyin Yang, Yiman Xie, Zetao Cai, Xu Shi, Ning Gao, Hangxu Liu, Xuekun Jiang, Zherui Qiu, Feng Yuan, Yaping Li, Ping Wang, Junhao Cai, Jia Zeng, Hao Dong, et al. Interndata-a1: Pioneering high-fidelity synthetic data for pre-training generalist policy. *arXiv preprint arXiv:2511.16651*, 2025.
- [94] Alexander Tong, Kilian Fatras, Nikolay Malkin, Guillaume Huguette, Yanlei Zhang, Jarrid Rector-Brooks, Guy Wolf, and Yoshua Bengio. Improving and generalizing flow-based generative models with minibatch optimal transport. *Transactions on Machine Learning Research*, 2024.
- [95] WAN AI Team. Wan-2.6. <https://wan.video/introduction/wan2.6>, 2026.
- [96] Wan Team. Wan: Open and advanced large-scale video generative models. *arXiv preprint arXiv:2503.20314*, 2025.
- [97] Chen Wang, Linxi Fan, Jiankai Sun, Ruohan Zhang, Li Fei-Fei, Danfei Xu, Yuke Zhu, and Animashree Anandkumar. Mimicplay: Long-horizon imitation learning by watching human play. In *Conference on Robot Learning (CoRL)*, 2023.
- [98] Junke Wang, Yi Jiang, Zehuan Yuan, Binyue Peng, Zuxuan Wu, and Yu-Gang Jiang. Omnitokenizer: A joint image-video tokenizer for visual generation. In *NeurIPS*, 2024.
- [99] Junke Wang, Qihang Zhang, Shuai Yang, Yiming Luo, Yujun Shen, Zuxuan Wu, Yu-Gang Jiang, and Yinghao Xu. Repwam: World action modeling with representation visual-action tokenizers. *arXiv preprint arXiv:2606.13674*, 2026.
- [100] Lean Wang, Huazuo Gao, Chenggang Zhao, Xu Sun, and Damai Dai. Auxiliary-loss-free load balancing strategy for mixture-of-experts. *arXiv preprint arXiv:2408.15664*, 2024.
- [101] Yixuan Wang, Yunzhu Li, Katherine Driggs-Campbell, Li Fei-Fei, and Jiajun Wu. Dynamic-resolution model learning for object pile manipulation. *arXiv preprint arXiv:2306.16700*, 2023.
- [102] Yuqi Wang, Xinghang Li, Wenxuan Wang, Junbo Zhang, Yingyan Li, Yuntao Chen, Xinlong Wang, and Zhaoxiang Zhang. Unified vision-language-action model. *arXiv preprint arXiv:2506.19850*, 2025.
- [103] Manuel Watter, Jost Springenberg, Joschka Boedecker, and Martin Riedmiller. Embed to control: A locally linear latent dynamics model for control from raw images. *Advances in neural information processing systems*, 28, 2015.
- [104] Junjie Wen, Yichen Zhu, Jinming Li, Zhibin Tang, Chaomin Shen, and Feifei Feng. Dexvla: Vision-language model with plug-in diffusion expert for general robot control. *arXiv preprint arXiv:2502.05855*, 2025.
- [105] Youpeng Wen, Junfan Lin, Yi Zhu, Jianhua Han, Hang Xu, Shen Zhao, and Xiaodan Liang. Vidman: Exploiting implicit dynamics from video diffusion model for effective robot manipulation. *arXiv preprint arXiv:2411.09153*, 2024.
- [106] Hongtao Wu, Ya Jing, Chilam Cheang, Guangzeng Chen, Jiafeng Xu, Xinghang Li, Minghuan Liu, Hang Li, and Tao Kong. Unleashing large-scale video generative pre-training for visual robot manipulation. In *Int. Conf. Learn. Represent.*, 2024.
- [107] Jialong Wu, Shaofeng Yin, Ningya Feng, Xu He, Dong Li, Jianye Hao, and Mingsheng Long. ivideoqpt: Interactive videoqpts are scalable world models. In *Adv. Neural Inform. Process. Syst.*, 2024.
- [108] Kun Wu, Chengkai Hou, Jiaming Liu, Zhengping Che, Xiaozhu Ju, Zhuqin Yang, Meng Li, YINUO Zhao, Zhiyuan Xu, Guang Yang, Shichao Fan, Xinhua Wang, Fei Liao, Zhen Zhao, Guangyu Li, et al. Robomind: Benchmark on multi-embodiment intelligence normative data for robot manipulation. In *Robotics: Science and Systems*, 2025.
- [109] Philipp Wu, Alejandro Escontrela, Danijar Hafner, Pieter Abbeel, and Ken Goldberg. Daydreamer: World models for physical robot learning. In *Conference on Robot Learning (CoRL)*, 2022.

- [110] Shihan Wu, Xuecheng Liu, Shaoxuan Xie, Pengwei Wang, Xinghang Li, Bowen Yang, Zhe Li, Kai Zhu, Hongyu Wu, Yiheng Liu, Zhaoye Long, Yue Wang, Chong Liu, Dihan Wang, Ziqiang Ni, et al. Robocoin: An open-sourced bimanual robotic data collection for integrated manipulation. *arXiv preprint arXiv:2511.17441*, 2025.
- [111] Wei Wu, Fan Lu, Yunnan Wang, Shuai Yang, Shi Liu, Fangjing Wang, et al. A pragmatic vla foundation model. *arXiv preprint arXiv:2601.18692*, 2026.
- [112] Gangwei Xu, Qihang Zhang, Jiaming Zhou, Xing Zhu, Yujun Shen, Xin Yang, and Yinghao Xu. Next forcing: Causal world modeling with multi-chunk prediction. *arXiv preprint arXiv:2606.11187*, 2026.
- [113] Zhenjia Xu, Jiajun Wu, Andy Zeng, Joshua B Tenenbaum, and Shuran Song. Densephysnet: Learning dense physical object representations via multi-step dynamic interactions. *arXiv preprint arXiv:1906.03853*, 2019.
- [114] Jianwei Yang, Reuben Tan, Qianhui Wu, Ruijie Zheng, Baolin Peng, Yongyuan Liang, Yu Gu, Mu Cai, Seonghyeon Ye, Joel Jang, Yuquan Deng, Lars Lidén, and Jianfeng Gao. Magma: A foundation model for multimodal ai agents. In *IEEE Conf. Comput. Vis. Pattern Recog.*, 2025.
- [115] Shuai Yang, Hao Li, Yilun Chen, Bin Wang, Yang Tian, Tai Wang, Hanqing Wang, Feng Zhao, Yiyi Liao, and Jiangmiao Pang. Instructvla: Vision-language-action instruction tuning from understanding to manipulation. *arXiv preprint arXiv:2507.17520*, 2025.
- [116] Seonghyeon Ye, Yunhao Ge, Kaiyuan Zheng, Shenyuan Gao, Sihyun Yu, George Kurian, Suneel Indupuru, You Liang Tan, Chuning Zhu, Jiannan Xiang, Ayaan Malik, Kyungmin Lee, William Liang, Nadun Ranawaka, Jiasheng Gu, Yinzhen Xu, Guanzhi Wang, Fengyuan Hu, Avnish Narayan, Johan Bjorck, Jing Wang, Gwanghyun Kim, Dantong Niu, Ruijie Zheng, Yuqi Xie, Jimmy Wu, Qi Wang, Ryan Julian, Danfei Xu, Yilun Du, Yevgen Chebotar, Scott Reed, Jan Kautz, Yuke Zhu, Linxi Jim Fan, and Joel Jang. World action models are zero-shot policies. *arXiv preprint arXiv:2602.15922*, 2026.
- [117] Seonghyeon Ye, Joel Jang, Byeongguk Jeon, Sejun Joo, Jianwei Yang, Baolin Peng, Ajay Mandlekar, Reuben Tan, Yu-Wei Chao, Bill Yuchen Lin, Lars Liden, Kimin Lee, Jianfeng Gao, Luke Zettlemoyer, Dieter Fox, and Minjoon Seo. Latent action pretraining from videos. In *Int. Conf. Learn. Represent.*, 2025.
- [118] Ryan Yu, Pushi Zhang, Starrick Liu, Brae Liu, Miracle Kang, Shalfun Li, Lights Shi, Ellie Ma, Ping Yang, Chris Pan, et al. Wall-oss-0.5 technical report. *arXiv preprint arXiv:2605.30877*, 2026.
- [119] Haoqi Yuan, Zhixuan Liang, Anzhe Chen, Ye Wang, Haoyang Li, Pei Lin, Yiyang Huang, Zixing Lei, Tong Zhang, Jiazhao Zhang, et al. Qwen-robotmanip technical report: Alignment unlocks scale for robotic manipulation foundation models. *arXiv preprint arXiv:2606.17846*, 2026.
- [120] Tianyuan Yuan, Zibin Dong, Yicheng Liu, and Hang Zhao. Fast-wam: Do world action models need test-time future imagination? *arXiv preprint arXiv:2603.16666*, 2026.
- [121] Andy Zhai, Brae Liu, Bruno Fang, Chalse Cai, Ellie Ma, et al. Igniting vlms toward the embodied space. *arXiv preprint arXiv:2509.11766*, 2025.
- [122] Kaifeng Zhang, Baoyu Li, Kris Hauser, and Yunzhu Li. Adaptigraph: Material-adaptive graph-based neural dynamics for robotic manipulation. *arXiv preprint arXiv:2407.07889*, 2024.
- [123] Kaifeng Zhang, Baoyu Li, Kris Hauser, and Yunzhu Li. Particle-grid neural dynamics for learning deformable object models from rgb-d videos. *arXiv preprint arXiv:2506.15680*, 2025.
- [124] Qingqing Zhao, Yao Lu, Moo Jin Kim, Zipeng Fu, Zhuoyang Zhang, Yecheng Wu, Zhaoshuo Li, Qianli Ma, Song Han, Chelsea Finn, et al. Cot-vla: Visual chain-of-thought reasoning for vision-language-action models. In *Proceedings of the Computer Vision and Pattern Recognition Conference*, pages 1702–1713, 2025.
- [125] Tony Z. Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware. In *Robotics: Science and Systems*, 2023.
- [126] Zhaxizhuoma, Kehui Liu, Chuyue Guan, Zhongjie Jia, Ziniu Wu, Xin Liu, Tianyu Wang, Shuai Liang, Pengan Chen, Pingrui Zhang, Haoming Song, Delin Qu, Dong Wang, Zhigang Wang, Nieqing Cao, et al. Fastumi: A scalable and hardware-independent universal manipulation interface. *arXiv preprint arXiv:2409.19499*, 2024.
- [127] Haoyu Zhen, Xiaowen Qiu, Peihao Chen, Jincheng Yang, Xin Yan, Yilun Du, Yining Hong, and Chuang Gan. 3d-vla: A 3d vision-language-action generative world model. In *Int. Conf. Mach. Learn.*, 2024.
- [128] Jinliang Zheng, Jianxiong Li, Zhihao Wang, Dongxiu Liu, Xirui Kang, Yuchun Feng, Yinan Zheng, Jiayin Zou, Yilun Chen, Jia Zeng, Ya-Qin Zhang, Jiangmiao Pang, Jingjing Liu, Tai Wang, and Xianyu Zhan. X-vla: Soft-prompted transformer as scalable cross-embodiment vision-language-action model. *arXiv preprint arXiv:2510.10274*, 2025.

- [129] Jiaming Zhou, Teli Ma, Kun-Yu Lin, Zifan Wang, Ronghe Qiu, and Junwei Liang. Mitigating the human-robot domain discrepancy in visual pre-training for robotic manipulation. *arXiv preprint arXiv:2406.14235*, 2024.
- [130] Jiaming Zhou, Ke Ye, Jiayi Liu, Teli Ma, Zifan Wang, Ronghe Qiu, Kun-Yu Lin, Zhilin Zhao, and Junwei Liang. Exploring the limits of vision-language-action manipulation in cross-task generalization. In *The Thirty-ninth Annual Conference on Neural Information Processing Systems*, 2025.
- [131] Pengfei Zhou, Liliang Chen, Shengcong Chen, Di Chen, Wenzhi Zhao, Rongjun Jin, Guanghui Ren, and Jianlan Luo. Act2goal: From world model to general goal-conditioned policy. *arXiv preprint arXiv:2512.23541*, 2025.
- [132] Siyuan Zhou, Yilun Du, Jiaben Chen, Yandong Li, Dit-Yan Yeung, and Chuang Gan. Robodreamer: Learning compositional world models for robot imagination. *arXiv preprint arXiv:2404.12377*, 2024.
- [133] Chuning Zhu, Raymond Yu, Siyuan Feng, Benjamin Burchfiel, Paarth Shah, and Abhishek Gupta. Unified world models: Coupling video and action diffusion for pretraining on large robotic datasets. In *Robotics: Science and Systems*, 2025.
- [134] Fangqi Zhu, Hongtao Wu, Song Guo, Yuxiao Liu, Chilam Cheang, and Tao Kong. Irasim: Learning interactive real-robot action simulators. *arXiv preprint arXiv:2406.14540*, 2024.