

面向机器人控制的因果世界建模

Lin Li* Qihang Zhang*[†] Yiming Luo* Shuai Yang Ruilin Wang Fei Han
Mingrui Yu Zelin Gao Nan Xue Xing Zhu Yujun Shen Yinghao Xu[‡]

*Equal Contribution

[†]Project Lead

[‡]Corresponding Author

本工作强调，视频世界建模与视觉-语言预训练共同为机器人学习奠定了全新且独立的基础。直观而言，视频世界模型通过理解动作与视觉动态之间的因果关系，提供了“想象”近未来的能力。受此启发，我们提出 LingBot-VA，一种自回归扩散框架，能够同时学习帧预测与策略执行。该模型具有三项精心设计：（1）共享潜空间，融合视觉与动作令牌，由混合变换器（Mixture-of-Transformers, MoT）架构驱动；（2）闭环推演机制，允许利用真实观测持续获取环境反馈；（3）异步推理流水线，并行化动作预测与电机执行，以支持高效控制。我们在仿真基准和真实场景中对模型进行了评估，结果表明其在长时程操作、后训练数据效率以及对新配置的强泛化能力方面展现出显著潜力。代码与模型已公开发布，以促进社区发展。

Website: <https://technology.robbyant.com/lingbot-va>

Github: <https://github.com/robbyant/lingbot-va>

Checkpoints: <https://huggingface.co/robbyant/lingbot-va>

 Robbyant

1 引言

视觉-语言-动作（Vision-Language-Action, VLA）模型已成为通用机器人操作的一种有前景的范式 [7, 11, 12, 34]，在将语言指令落实到多样化物体和非结构化环境中的视觉感知方面展现出令人印象深刻的能力。然而，在其表面成功之下隐藏着一个重大挑战：表征纠缠。现有大多数 VLA 采用前馈范式，将当前观测映射到动作序列 [17, 91]，要求单一神经网络从统一的监督信号中同时学习视觉场景理解、物理动力学和运动控制。这种纠缠可能形成瓶颈——模型必须将异构知识（从高维视觉语义到低维运动指令）压缩到共享表征空间中。这往往导致样本效率有限和泛化性能欠佳。在缺乏对环境演化的显式建模 [25, 26, 82] 的情况下，反应式策略可能依赖模式匹配，而非对物理动力学的原理性理解。

近年来，将世界建模引入机器人策略的尝试涵盖了交互式神经仿真器（例如 UniSim [86]）、基于分块的视频-动作扩散模型（例如 UVA [40] 和 UWM [97]），以及用于子目标综合的离线视频生成器（例如 Gen2Act [4]、Act2Goal [95]）。尽管这些方法在概念上具有吸引力，但在实现有效的闭环控制方面面临三个主要局限性。首先，反应性差距：分块或开环生成通常在不纳入实时反馈的情况下展开长序列，导致难以适应扰动。其次，长期记忆有限：当历史信息未被持续缓存时，分块生成可能在长时间跨度内引入不一致性。第三，因果性：段内的双向注意力允许未来标记影响过去的预测，这与物理现实的因果本质相悖，即当前仅依赖于过去。这些观察结果促使我们采用自回归公式以实现稳健的闭环推理。

本文提出 LingBot-VA，一种自回归扩散世界模型，通过统一的

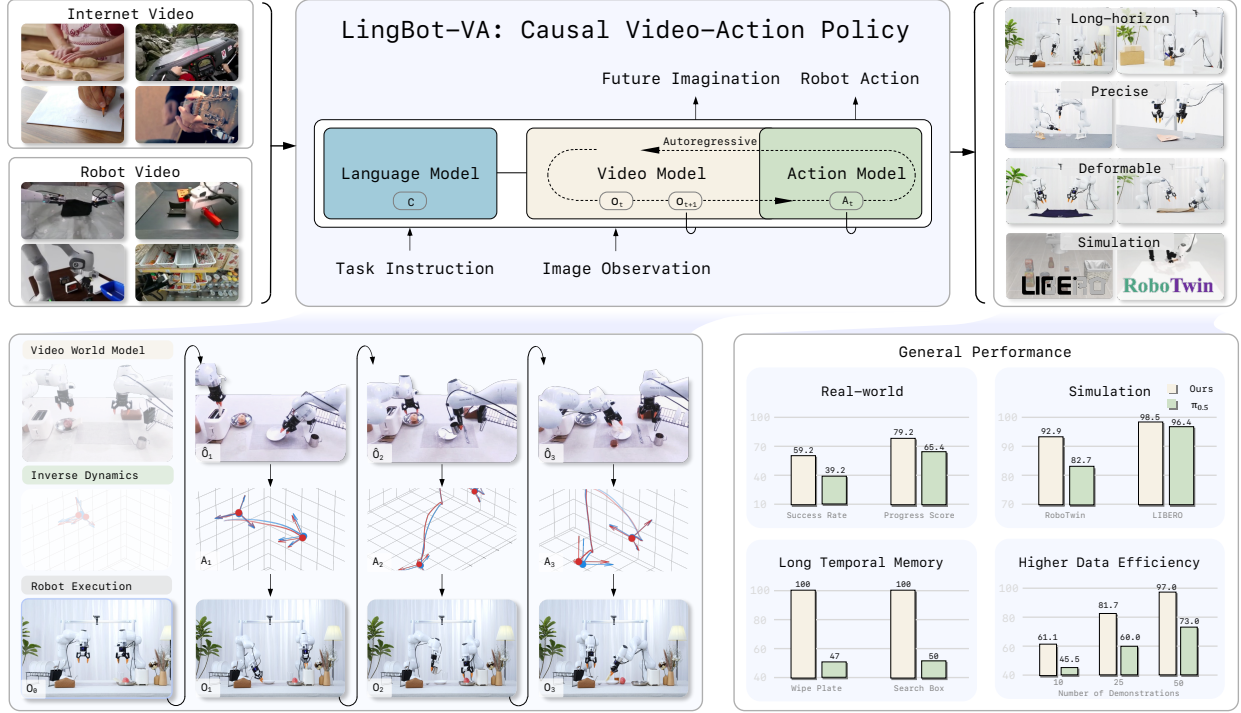


图 1. LingBot-VA: 一种用于机器人操作的自回归世界模型。 (1) 预训练: LingBot-VA 在多样化的自然场景视频和机器人动作数据上进行预训练, 从而在场景和物体之间实现强大的泛化能力。 (2) 综合评估: 我们在现实世界任务 (长时程、可变形物体和精密操作) 以及仿真基准上进行了大量实验, 显著优于最先进的方法, 包括 $\pi_{0.5}$ 。 (3) 多功能能力: 除了策略学习之外, 我们的模型还支持从机器人视频中进行视觉动力学预测和逆动力学推断。 (4) 涌现特性: 我们的因果世界建模方法展现出长程时间记忆和强大的少样本适应能力。

视频-动作框架。与预测离散词元的自回归语言模型不同, 本文模型通过流匹配 [46, 50] 在连续潜空间中运行, 通过迭代去噪自回归地生成视频和动作表示的块。虽然本文方法在概念上分离了视觉动态预测和动作解码 [22, 27], 但关键的架构洞见是将视频和动作词元交织成单一的自回归序列。两种模态通过具有共享注意力的变换器混合 (MoT) 架构 [43] 联合处理。在这个统一的自回归生成过程中, 潜想象和动作推理联合发生: 在每个自回归步骤中, 模型通过迭代去噪生成预测的未来视觉状态, 同时解码相应的动作, 使两个流相互条件化。这种集成建立在大规模预训练视频扩散骨干 [79] 之上, 提供了几个优势: (i) 反应式自回归循环: 由于视频和动作词元形成统一序列, 每个自回归步骤允许系统根据最新的真实世界观测进行重新校准, 从而及时调整预测的未来和运动命令; (ii) 通过键值缓存保持持久上下文: 缓存的键值对保留了交织的视频-动作轨迹, 提供了丰富的上下文, 有助于减轻时间漂移; (iii) 因果一致性: 对统一序列的因果注意力掩码确保预测的视觉状态和动作命令都受先前状态支配, 尊重物理动力学的时间箭头。通过在每个步骤纳入真实世界观测, 这种表述有助于减轻在长时程任务中经常影响开环方法的分布漂移。

部署大规模自回归视频-动作模型的一个主要挑战是推理延迟; 通过迭代去噪生成高保真视频令牌计算开销很大。我们通过两种互补策略来解决这一问题。首先, 我们引入了噪声历史增强, 这是一种在推理时支持部分去噪的训练方案。关键洞见在于动作解码并不总是需要像素级完美重建; 相反, 它可以依赖稳健的语义结构。通过训练动作解码器从部分含噪的潜在表示中进行预测, 我们显著降低了计算开销, 同时保持了精确的动作预测。其次, 我们设计了一种异步协调流水线, 使计算与执行重叠: 当

机器人执行当前动作时，世界模型预测未来的视觉状态并规划后续序列。这种并行化架构与可变块大小训练相结合，有助于实现高频闭环控制，而不会影响预测质量。

我们在仿真和真实环境中的多种操作任务上评估了 LingBot-VA。与最先进的视觉-语言-动作策略相比，我们的方法表现出具有竞争力的性能，特别是在需要时序一致性的长程任务中。我们的贡献总结如下：

- **自回归视频-动作世界建模：**我们引入了一种自回归扩散框架，在架构上将视觉动态预测和动作推理统一在单个交错序列中，同时保持它们的概念区分。该公式通过键值缓存支持持久记忆，并通过注意力掩码支持因果一致性。
- **混合变换器架构与异步执行：**我们设计了一种具有非对称容量的双流混合变换器架构，并引入了部分去噪策略与异步协调相结合，以实现高效的机器人控制。
- **卓越的长程与精确性能：**大量真实世界与仿真实验一致表明，所提方法达到了最先进的性能，尤其在长时程和高精度操作任务上提升显著。本文方法还实现了显著提升的样本效率，并对新场景和物体配置表现出强泛化能力。

2 预备知识

2.1 流匹配

流匹配 (Flow Matching) [46, 50, 75] 是一种连续时间生成建模框架，通过学习连续流将简单源分布（如高斯噪声）变换为目标数据分布。给定数据样本 x_1 和噪声样本 $\epsilon \sim \mathcal{N}(0, I)$ ，流匹配定义了一个时间相关向量场 $v_s: \mathbb{R}^d \times [0, 1] \rightarrow \mathbb{R}^d$ ，描述粒子从 ϵ 流向 x_1 的瞬时速度。轨迹 $x^{(s)}$ 按照常微分方程 (ODE) 演化： $dx^{(s)}$

$$\frac{dx^{(s)}}{ds} = v_s(x^{(s)}), \quad x^{(0)} = \epsilon \sim \mathcal{N}(0, I), \quad (1)$$

其中 $s \in [0, 1]$ 表示流动时间。

模型通过最小化以下目标来训练预测该向量场：

$$\mathcal{L}_{\text{FM}} = \mathbb{E}_{s, \epsilon, x_1} \left[\|v_\theta(x^{(s)}, s) - \dot{x}^{(s)}\|^2 \right], \quad (2)$$

其中 $\dot{x}^{(s)}$ 是插值路径上的真实速度，通常定义为 $x^{(s)} = (1-s)\epsilon + sx_1$ ，得到 $\dot{x}^{(s)} = x_1 - \epsilon$ 。

在推理时，通过从 $s = 0$ 到 $s = 1$ 求解学习到的常微分方程来生成样本：

$$x_1 = \epsilon + \int_0^1 v_\theta(x^{(s)}, s) ds. \quad (3)$$

2.2 基于条件流匹配的视频生成

近期视频生成模型 [23, 35, 54, 79] 利用流匹配技术，根据文本或图像条件生成视频。这些模型在预训练视频自编码器的潜空间中运行，其中视觉观测通过编码器 E （例如来自视频扩散模型）被编码为潜表示 $z_t = E(o_t)$ 。

给定条件信号 c （文本提示或初始图像），流匹配模型通过预测向量场来学习生成潜视频帧序列 $\mathbf{z} = \{z_1, \dots, z_T\}$ ：

$$v_\theta(\mathbf{z}^{(s)}, s | c) = \frac{d}{ds} \mathbf{z}^{(s)}, \quad (4)$$




图 2. 框架总览：LingBot-VA 以自回归扩散为条件，实现统一的视频-动作世界建模。我们采用双流混合变换器（MoT）架构，在单一序列中交错排列视频与动作令牌。在每个自回归步骤中，视频流（由 Wan2.2-5B 初始化）首先通过流匹配预测未来潜视觉状态。随后，动作流基于预测的视觉转移，通过逆动力学条件解码相应动作。

其中 $s \in [0, 1]$ 为流时间， $\mathbf{z}^{(s)}$ 表示流步骤 s 处的潜视频。生成过程从噪声 $\mathbf{z}^{(0)} = \epsilon \sim \mathcal{N}(0, I)$ 开始，对学习到的向量场进行积分以获得最终潜视频 $\mathbf{z}^{(1)}$ ，随后将其解码至像素空间。该双向生成框架支持从文本描述或种子图像进行灵活合成。

3 方法

3.1 问题陈述与方法概述

我们将机器人操作视为部分可观测条件下的序贯决策问题。在每个时间步 t ，智能体接收视觉观测 $o_t \in \mathcal{O}$ 并执行动作 $a_t \in \mathcal{A}$ ，该动作引发底层物理世界的转移并产生下一观测 o_{t+1} 。

视觉-语言-动作（视觉语言动作（VLA））策略。 现有的大多数 VLA 策略学习从观测历史到动作的直接、反应式映射：

$$a_t \sim \pi_{\theta}(\cdot | o_t), \quad (5)$$

通过对机器人演示数据进行模仿学习。尽管这种端到端方法已展现出令人瞩目的成果，但它存在一个根本性的耦合问题：模型必须从成对的观测与动作这一单一监督信号中同时学习视觉场景理解、物理动力学和运动控制。这种纠缠导致样本效率低下和泛化能力有限，因为模型在没有显式动力学建模的情况下难以将视觉推理与动作预测解耦。

我们的方法。 与直接学习动作分布的 VLA 策略不同，我们采用世界建模的视角：不是学习 $\pi(a_t | o_t)$ ，而是预测视觉世界将如何演变，然后基于这些预测推断动作。我们的方法分两个阶段进行：

$$\begin{aligned} \text{(Stage 1) Visual dynamics prediction:} \quad & o_{t+1} \sim p_{\theta}(\cdot | o_{\leq t}), \\ \text{(Stage 2) Inverse dynamics:} \quad & a_t \sim g_{\psi}(\cdot | o_t, o_{t+1}). \end{aligned} \quad (6)$$

第一阶段学习在给定观测历史的情况下预测未来的视觉观测。第二阶段使用逆动力学模型从期望的视觉转变中解码动作。这种分解使第一阶段能够利用大规模视频数据学习物理先验，而第二阶段仅需机器人演示即可将视觉预测落地为可执行动作。

方法概述。图 2 展示了我们框架的细节。我们的方法由三个关键组件组成，在以下小节中详细说明：（§ 3.2）自回归视频-动作世界建模描述了我们如何在潜空间中建模视觉动力学并从预测的状态转变中解码动作——这是我们方法的核心表述；（§ 3.3）LingBot-VA：统一架构与训练介绍了我们用于视频-动作预训练的统一模型，包括架构设计和训练目标——这是我们表述的具体实现；（§ 3.4）实时部署与异步推理介绍了我们的部署策略，通过并行化预测与执行实现实时控制——这是机器人控制的实用实现。

3.2 自回归视频-动作世界建模

以往的视频世界模型要么专注于开放式视频预测 [54]，要么主要针对游戏或仿真领域学习动作条件下的交互环境 [13, 56]，这些可能无法直接迁移到精确的机器人操作。为了利用视频数据中丰富的视觉动态先验进行机器人操作，我们提出了一种统一的视频-动作世界建模框架，在单一自回归过程中联合建模视觉观测和机器人动作。与以往将视频预测与动作推断解耦 [16, 27] 或依赖分段内双向扩散 [97] 的方法不同，我们的方法在单一因果自回归框架内统一了视频和动作，通过键值缓存实现持久记忆，并无缝集成实时观测。

基于自回归建模的世界动力学。近年来用于机器人的世界模型通常采用双向视频生成方法 [4, 20, 24, 42] 或学习交互式仿真器 [86]，这些方法在闭环控制方面面临根本性局限。一次性生成整个长序列的开环方法计算成本过高，且无法纳入实时反馈进行误差校正。基于分块扩散的顺序生成视频片段的方法 [22, 97] 存在两个关键问题：（1）它们缺乏跨分块的持久记忆，因为每个分块独立生成，无法访问完整历史，导致长时间范围内的时序不一致和漂移；（2）每个分块内的双向注意力违反了因果性，阻碍了在执行过程中与实时观测的无缝集成。

然而，物理世界本质上是因果且自回归的：当前状态仅依赖于过去，我们无法在事件发生之前观测到未来。这一根本特性促使我们采用自回归世界建模方法，相较于基于分块的扩散方法，该方法在机器人控制方面具有三项关键优势：

（1）持久记忆：通过因果注意力和键值缓存显式地以完整观测历史为条件，模型能够在整个轨迹上保持长期上下文和时间一致性，避免了基于分块方法的“遗忘”问题；（2）因果一致性：单向依赖结构天然契合闭环执行，新观测到达时可无缝融入；（3）效率：分块预测与块内并行生成在计算效率与自回归灵活性之间取得平衡，支持高频控制与实时误差校正。

我们将此形式化为一个自回归过程：在每一步，世界模型利用条件流匹配预测下一块 K 视频帧：

$$o_{t+1:t+K} \sim p_{\theta}(\cdot \mid o_{\leq t}), \quad (7)$$

其中每个块内的标记通过双向注意力并行生成，同时保持块间的因果结构。这种分块式表述在生成效率与用于闭环校正的自回归灵活性之间取得了平衡。

视频-动作状态编码。直接在像素级视频观测上操作在计算上不可行，因为原始视觉数据具有高维度和冗余性。我们利用因果视频变分自编码器 [79] 将视觉观测压缩为紧凑的潜在标记 $z_t = E(o_t \mid o_{<t}) \in \mathbb{R}^{N \times C}$ ，其中 N 是经过视频变分自编码器后的空间标记数量， C 是通道数。通过以先前的潜在状态为条件，编码器在顺序处理观测时保持一致性，自然契合我们的自回归世界建模框架。为了将机器人动作与视觉标记对齐，我们通过轻量级多层感知机 $\phi(\cdot)$ 将动作向量投影为标记嵌入 $a_t \in \mathbb{R}^D$ ，其中 D 是视频标记分块化后的维度，从而能够像先前方法 [5, 22] 那样统一交错视觉与动作标记。

潜在视频状态转移。虽然标准视频生成模型仅基于视觉历史预测未来帧，但机器人操作需要考虑本体的物理状态及其与环境的交互。

环境。在部署过程中，机器人的状态通过持续交互不断演化：每个动作都会改变本体的构型（例如夹爪位置、关节角度），进而影响场景的演变方式。

在许多操作场景中，动作编码了绝对位姿信息（例如世界坐标系下的末端执行器位姿），因此动作历史 $a_{<t}$ 有效地捕捉了本体构型的轨迹。以动作历史为条件，从而提供了机器人如何移动并与物体交互的知识，这与先前以动作为条件的视频/世界模型 [22, 86, 97] 一致。我们将自回归公式扩展为同时以观测历史和动作历史为条件：

$$z_{t+1:t+K} \sim p_\theta(\cdot \mid z_{\leq t}, a_{<t}), \quad (8)$$

其中 z_t 是潜在视觉状态， a_t 是动作标记。这使得世界模型能够将预测建立在本体状态的基础上，确保预测的观测结果反映机器人与场景的物理交互。

用于动作解码的逆动力学。一旦世界模型预测出未来的视觉状态，我们便利用这些预测来规划动作。我们并非直接从当前观测预测动作，而是采用逆动力学模型，通过以期望的未来观测为条件来推断动作，从而使策略能够推理出何种动作能导致期望的视觉结果。

然而，仅以当前状态和下一状态 (z_t, z_{t+1}) 为条件不足以准确预测动作。动作历史 $a_{<t}$ 编码了本体的状态轨迹，用于确定可行的动作，而观测历史 $z_{<t}$ 则为多步交互（例如物体之前是否被抓取过）提供了时间上下文。因此，我们将逆动力学公式化为：

$$a_{t:t+K-1} \sim g_\psi(\cdot \mid \hat{z}_{t+1:t+K}, z_{\leq t}, a_{<t}), \quad (9)$$

其中逆动力学模型 g_ψ 以公式 8 推断出的预测视觉状态块 $\hat{z}_{t+1:t+K}$ 、观测历史 $z_{\leq t}$ 和动作历史 $a_{<t}$ 作为输入。这与近期基于逆动力学模型的策略 [1, 20, 22, 55, 73] 相呼应，这些策略利用未来目标来推断可行动作，同时保持与本体动力学的一致性。

3.3 LingBot-VA：统一架构与训练

架构。为联合建模视频与动作生成，本文采用双流扩散 Transformer 架构，通过条件流匹配实现自回归预测。模型由两个并行的 Transformer 主干组成：视频流由 Wan2.2-5B（一个大规模预训练视频生成模型，维度为 d_v [79]）初始化，动作流具有相同深度但宽度显著更小 $d_a \ll d_v$ 。这种非对称设计源于以下观察：动作分布本质上比视觉数据更简单，因此需要更少的参数即可有效建模，同时保持对视觉动态的表达能力。

视频稀疏化。视频帧存在显著的时间冗余，尤其是在机器人操作场景中，场景变化较为缓慢。本文通过将帧按因子 $\tau = 4$ ，进行时间下采样来稀疏化视频序列，从而减少视觉令牌数量并提高效率 [5]。由于动作的演化频率高于视觉变化，本文将下采样后的视频令牌与动作令牌按时间顺序交错排列：对于每个视频帧 o_t ，关联

$$\tau \text{ 连续动作 } \{a_{t,1}, a_{t,2}, \dots, a_{t,\tau}\}, \text{ 形成统一序列 } [z_t, a_{t,1}, a_{t,2}, \dots, a_{t,\tau}, z_{t+1}, \dots]$$

以进行联合建模。该设计意味着预测 K 个视频帧对应于生成 τK 个动作，从而在保持高效视频生成的同时实现高频控制。

混合 Transformer 模块。为实现模态间交互并保留各模态特定的特征空间，本文采用混合 Transformer (MOT) 架构 [5, 19, 43]，其中视频令牌和动作令牌在每一层由独立的 Transformer 模块处理，随后通过跨模态注意力进行融合 [5]。在每一层，视频流和动作流分别使用独立的 QKV 投影矩阵计算查询、键和值矩阵，从而为每种模态保持不同的特征空间。为对齐跨模态融合的维度，动作令牌首先通过线性层投影到视频维度，参与联合自注意力，然后通过残差连接投影回原始维度，以保留动作特定的表示。该 MOT 设计使视频和动作能够通过注意力相互影响，同时保持独立的参数化，防止模态特定特征表示之间的干扰。对于动作解码，最终的动作流输出通过线性投影头映射到低维动作向量。

动作网络初始化。动作流的恰当初始化对于训练稳定性和收敛至关重要。我们发现，从头训练动作网络会导致优化不稳定和收敛缓慢，因为动作

标记的输出分布最初与视频分布存在显著差异，从而干扰了联合注意力机制。为解决这一问题，我们通过根据动作维度对预训练的视频权重进行插值来初始化动作网络权重，然后应用缩放因子 $\alpha = \sqrt{d_v/d_a}$ 以保持输出方差，其中 d_v 和 d_a 分别是视频维度和动作维度。这种初始化策略确保动作标记初始时的输出分布与视频标记相当，从而稳定早期训练并加速收敛。

可变块大小训练。为了实现灵活部署，我们在训练期间从预定义范围中随机采样块大小 K 。通过使用可变块大小（例如， $K \in [1, 8]$ ）进行训练，模型学会在不同时间跨度上生成连贯的预测。在推理时，这允许自由选择块大小以平衡计算效率和规划时域——较大的块减少了自回归步骤的数量，但需要更长的每步计算时间，而较小的块则能实现更频繁的闭环校正。在我们的实验中，我们使用 $K = 4$ 进行部署，作为一种实用的折衷方案。

用于统一视频-动作训练的教师强制。在第 3.2 节中，我们将视觉动态预测（公式 7）和逆动态（公式 8）都表述为自回归建模问题，其中每个预测都以观测和动作的历史为条件。这种统一的自回归表述提供了一种自然的训练策略：我们可以将交错的视频-动作序列视为一个统一的序列，并使用标准的下一标记预测来训练模型，类似于自然语言处理中的语言建模 [76]。

具体而言，给定一个包含交错标记的片段，我们训练模型以序列中所有先前标记为条件来预测每个标记。这通过教师强制实现：在训练期间，我们使用数据集中的真实标记作为预测后续标记的上下文，而非模型生成的预测。因果依赖结构通过注意力掩码（图 3）强制执行——每个标记只能关注时间序列中较早出现的标记。

重要的是，教师强制特别适用于机器人操作：与纯生成建模中导致训练-测试分布不匹配不同，机器人策略在部署期间自然检索真实世界观测，直接匹配训练机制。该公式提供了两个关键优势：（1）在单一训练目标下统一视频和动作预测，实现世界动态和动作推理的端到端学习；

（2）通过因果注意力掩码并行处理片段，我们在单次前向传播中高效地优化所有时间步的两个组件。

噪声历史增强。推理期间的主要瓶颈仍然是视频标记生成——视频标记的数量远大于动作标记，且每个都需要通过流匹配过程进行多次去噪步骤。为了解决这个问题，我们在训练期间引入一种噪声增强策略，使得测试时能够进行部分去噪。关键洞见是动作预测不需要完全去噪的视频表示；逆动力学模型可以学习从部分带噪的视频状态中提取与动作相关的信息。具体而言，在训练期间，我们随机使用与流匹配相同的插值方案对视频历史 $z_{\leq t}$ 进行噪声增强：

$$\tilde{z}_{\leq t} = \begin{cases} (1 - s_{\text{aug}})\epsilon + s_{\text{aug}}z_{\leq t}, & p = 0.5, \quad s_{\text{aug}} \in [0.5, 1], \quad \epsilon \sim \mathcal{N}(0, I) \\ z_{\leq t}, & 1 - p = 0.5 \end{cases} \quad (10)$$

这种增强训练动作解码器从部分带噪的视频表示中预测动作。

在推理时，这带来了显著的加速：无需将视频标记从 $s = 0$ 完全去噪到 $s = 1$ ，我们只需去噪到 $s = 0.5$ ，将视频生成的去噪步骤减半，同时保持动作预测质量。




图 3. 教师强制注意力掩码：用于统一视频-动作预训练的因果注意力掩码。每个标记只能关注时间序列中位于其前面的标记。

Algorithm 1 KV Cache Inference

Require: Initial observation o_0 , chunk size K , KV cache $\mathcal{C}$

```
1:  $z_0 \leftarrow E(o_0), \mathcal{C} \leftarrow \{z_0\}$ 
2:  $t \leftarrow 0$ 
3: loop
4:   Sample  $\epsilon \sim \mathcal{N}(0, I)$  ▷ Generate video chunk (integrate to  $s = 0.5$ )
5:    $\tilde{z}_{t+1:t+K} \leftarrow \epsilon + \int_0^{0.5} v_\theta(z_{t+1:t+K}^{(s)}, s | \mathcal{C}) ds$ 
6:   Sample  $\epsilon \sim \mathcal{N}(0, I)$  ▷ Generate action chunk (integrate to  $s = 1$ )
7:    $a_{t:t+K-1} \leftarrow \epsilon + \int_0^1 v_\psi(a_{t:t+K-1}^{(s)}, s | \tilde{z}_{t:t+K}, \mathcal{C}) ds$ 
8:   for  $i = t$  to  $t + K - 1$  do
9:     Execute  $a_i$ , receive  $o_{i+1}$  ▷ Execute and collect observations
10:     $z_{i+1} \leftarrow E(o_{i+1})$ 
11:   end for
12:    $\mathcal{C} \leftarrow \mathcal{C} \cup \{z_{t+1:t+K}, a_{t:t+K-1}\}$  ▷ Update KV cache
13:    $t \leftarrow t + K$ 
14: end loop
```

训练目标。我们使用上述噪声历史增强的流匹配联合优化视频和动作。对于视频标记 z_t ，动力学损失监督以（可能带噪的）历史为条件的速度场预测：

$$\mathcal{L}_{\text{dyn}} = \mathbb{E}_{t,s,z_{t+1},\epsilon} \left[\|v_\theta(z_{t+1}^{(s)}, s, \tilde{z}_{\leq t}, a_{<t}|c) - \dot{z}_{t+1}^{(s)}\|^2 \right], \quad (11)$$

其中 $s \in [0, 1]$ 为流动时间， $z_{t+1}^{(s)} = (1-s)\epsilon + sz_{t+1}$ ， $\epsilon \sim \mathcal{N}(0, I)$ ， $\dot{z}_{t+1}^{(s)} = z_{t+1} - \epsilon$ ， $\tilde{z}_{\leq t}$

且 c 为语言指令。对于动作标记 a_t ，逆动力学损失以当前观测和下一观测为条件：

$$\mathcal{L}_{\text{inv}} = \mathbb{E}_{t,s,a_t,\epsilon} \left[\|v_\psi(a_t^{(s)}, s, \tilde{z}_{\leq t+1}, a_{<t}|c) - \dot{a}_t^{(s)}\|^2 \right], \quad (12)$$

其中 $a_t^{(s)} = (1-s)\epsilon + sa_t$ ， $\epsilon \sim \mathcal{N}(0, I)$ ， $\tilde{z}_t, \tilde{z}_{t+1}$ 为（可能含噪的）当前和下一视频标记， c 为语言指令。完整目标为 $\mathcal{L} = \mathcal{L}_{\text{dyn}} + \lambda \mathcal{L}_{\text{inv}}$ 。

3.4 实时部署与异步推理

用于高效自回归推理的键值缓存。本文的自回归公式天然支持推理过程中的键值缓存加速。由于每个预测步骤以观测和动作的历史为条件，我们缓存先前标记的键值对以避免冗余计算。在每个自回归步骤中，仅新标记（当前观测和预测动作）需要完整注意力计算，而缓存的历史标记被复用。算法 1 描述了带键值缓存的完整推理过程。

异步预测与执行。尽管键值缓存（KV Cache）和部分去噪带来了效率提升，自回归预测仍会产生不可忽视的延迟，可能违反实时控制要求。为解决这一问题，本文引入一种异步推理策略，将动作预测与执行流水线化，从而有效隐藏预测延迟。图 4 展示了同步与异步推理之间的差异。

核心洞见在于将计算与执行重叠（图 4B）：当机器人执行当前动作块 a_t 时，模型同时基于最近的真实观测 z_{t-1} （在 a_{t-1} 执行后接收）预测后续动作块 a_{t+1} 。为简化起见，本节使用 z_t 表示潜在观测（忽略视频变分自编码器压缩），而非 o_t 。我们丢弃时间戳 $t-1$ 之前的所有历史数据，并使用上标符号^{*}标记预测的视觉内容。因此，模型的活跃上下文仅限于已执行的动作块 a_{t-1} 、最近的真实观测 z_{t-1} 、当前正在执行的动作 a_t 及其对应的视觉预测 $\hat{z}_t$ 。一种朴素的自回归实现（图 4B-1）是将这些标记存储到键值缓存中并预测 $\hat{z}_{t+1}$ 。然而，我们观察到这种设计经常导致开环退化和轨迹漂移。由于视频生成模型本质上倾向于时间平滑性，它倾向于“延续”幻觉视频 $\hat{z}_t$ ，而忽略真实观测 z_{t-1} 提供的关键物理反馈，最终导致模型丧失对环境做出反应的能力。




图 4. 异步流水线设计概览：传统同步流水线（A）因阻塞计算而产生延迟，而异步流水线（B）通过支持并行计算与执行来解决这一问题。然而，朴素的异步实现（B-1）依赖于过时的视觉预测。相比之下，本文通过前向动态预测（B-2）改进并优化异步预测，利用最新的真实世界观测更新陈旧预测。

Algorithm 2 Asynchronous Inference and Execution

Require: Initial observation o_0 , chunk size K , KV cache $\mathcal{C}$

- 1: $z_0 \leftarrow E(o_0); \mathcal{C} \leftarrow \{z_0\}$
 - 2: $\tilde{z}_{1:K}, a_{0:K-1} \leftarrow \text{PREDICT}(\mathcal{C})$ ▷ Cold Start
 - 3: $\text{ObsQueue} \leftarrow \emptyset$ ▷ Thread-safe queue for incoming real observations
 - 4: $t \leftarrow 0$
 - 5: **loop**
 - 6: **parallel:**
 - 7: **Branch A: Robot Execution**
 - 7: **async EXECUTOR**($a_{t:t+K-1}, \text{ObsQueue}$) ▷ Execute pre-computed actions
 - 8: **Branch B: Inference with FDM Grounding**
 - 8: **if** $t > 0$ **then**
 - 8: $o_{t-K+1:t} \leftarrow \text{ObsQueue.dequeue}()$ ▷ Get real observation
 - 8: $z_{t-K+1:t} \leftarrow E(o_{t-K+1:t})$
 - 8: $\mathcal{C} \leftarrow \mathcal{C} \cup \{z_{t-K+1:t}, a_{t-K:t-1}\}$ ▷ Cache feedback
 - 8: **end if**
 - 8: $\mathcal{C}_{\text{tmp}} \leftarrow \mathcal{C} \cup \{a_{t:t+K-1}\}$ ▷ Cache action being executed
 - 8: $z_{t+1:t+K} \leftarrow \text{FDM}(\mathcal{C}_{\text{tmp}})$ ▷ Imagine visual outcome
 - 8: $\mathcal{C}_{\text{tmp}} \leftarrow \mathcal{C}_{\text{tmp}} \cup \{z_{t+1:t+K}\}$ ▷ Update cache
 - 8: $\tilde{z}_{t+K+1:t+2K}, a_{t+K:t+2K-1} \leftarrow \text{PREDICT}(\mathcal{C}_{\text{tmp}})$
 - 8: $t \leftarrow t + K$
 - 9: **end loop**
-

为缓解这一问题，我们在推理流程中引入前向动力学模型（Forward Dynamics Model, FDM）接地步骤（图 4B-2）。不再依赖过时的预测，而是通过执行前向动力学传递来替代：模型利用最近的反馈 z_{t-1} ，并“想象”在施加动作 a_t 后产生的视觉状态 z_t 。通过缓存这种基于反馈接地的预测而非过时的预测，我们迫使模型在预测 z_{t+1} 之前重新与环境反馈对齐。该设计将我们的异步算法增强为鲁棒的闭环系统，使机器人能够有效感知并响应现实世界的变化。

Algorithm 2 formalizes this asynchronous pipeline. During post training, we additionally incorporate a forward dynamics prediction loss:

$$\mathcal{L}_{\text{fdm}} = \mathbb{E}_{t,s,\tilde{z}_{t+1},\epsilon} \left[\|v_\psi(\tilde{z}_{t+1}, s, z_t, a_t, \tilde{z}_{<t}, \hat{a}_{<t}|c) - \dot{z}_{t+1}^{(s)}\|^2 \right], \quad (13)$$

4 实验

4.1 数据集整理与预处理

我们通过聚合现有的公开机器人操作数据集来构建大规模训练语料库。所有数据集均经过预处理，以确保数据格式和标注质量的一致性，并按每个数据集划分为 90% 训练集和 10% 验证集，用于监控训练动态。

统一动作表示。为实现跨具身泛化，我们定义了一个通用动作接口以适应不同数据集。我们采用双臂表示，其中每个机械臂由末端执行器位姿（EEF）和关节角度共同表征。末端执行器位姿包含 XYZ 坐标和旋转四元数（7 维）。对于关节角度，我们支持单臂具身最多 7 个自由度；若机器人关节维度少于 7，则用零填充缺失维度以保持统一的 7 维表示。每个手臂还有一个夹爪动作维度。因此，双臂系统的总动作维度为：每臂 $7_{\text{EEF}} + 7_{\text{joints}} + 1_{\text{gripper}}$ ，总计 $(7 + 7 + 1) \times 2 = 30$ 维。

训练数据构成。我们聚合了来自六个来源的数据，涵盖多样的具身、环境和任务类别：

- 智元 [2]：来自移动操作机器人的大规模数据集，包含多样操作任务。
- RoboMind[81]：多具身操作演示。
- InternData-A1 [74]：用于仿真到现实迁移的大规模仿真数据集。
- OXE [53]：多具身数据集；本文使用 OpenVLA 子集。
- UMI 数据 [18, 45, 48, 51, 60, 92]：通过通用操作接口¹，（不含 DexUMI）采集的人类演示数据集。
- RoboCOIN [84]：跨具身双臂机器人数据。

总体而言，本文训练语料库包含约 **16K** 小时的机器人操作数据，涵盖多样任务与环境，其中包括内部采集的演示数据。

4.2 实现与训练细节

实现细节。本文采用 Wan2.2-5B 作为视频流的主干网络，隐藏维度为 $d_v = 3072$ ，包含 30 层变换器（Transformer）。动作流与视频流深度相同，但使用缩减的隐藏维度 $d_a = 768$ （缩小 $(4\times)$ ），因此额外增加约 350M 参数，模型总参数量为 5.3B。两条流均采用 RoPE 位置编码，并通过第 3.3 节所述的 MoT 架构连接。本文采用 Wan2.2 因果变分自编码器（VAE）进行分词，压缩比为 $4 \times 16 \times 16$ （时间 $\times$ 、高度 $\times$ 、宽度），并结合补丁化操作将空间维度进一步缩减 2 倍。编码后的视图沿宽度维度拼接，每帧共产生 $N = 192$ 个空间标记。动作编码器 ϕ 和解码器实现为单层多层感知机（MLP），隐藏维度为 256。本文使用训练集计算的分维度分位数归一化统计量对动作进行归一化。任务指令通过冻结的 T5 文本编码器 [59] 编码，并经交叉注意力注入。训练期间，块大小 K 从 $[1, 4]$ 中随机采样。

在推理阶段，视频令牌采用欧拉求解器以 3 步积分至 $s = 0.6$ ，动作令牌则以 10 步积分至 $s = 1.0$ 。视频无分类器引导尺度设为 5.0，动作无分类器引导尺度设为 1.0。训练期间，以概率 $p = 0.5$ 施加噪声增强，且 $s_{\text{aug}} \sim$ 均匀分布 $[0.5, 1.0]$ 。遵循大语言模型实践，我们将多个回合打包为长序列（最多 10K 令牌）并配合注意力掩码。¹

<https://umi-data.github.io/>




图 5. 真实世界部署结果。我们在六个操作任务上评估 LingBot-VA，涵盖三类：长程任务（制作早餐、拾取螺丝）、精细任务（插入管件、拆包配送）以及可变形与关节物体操作（叠衣服、叠裤子）。本文方法在两个度量上均达到最先进性能。

预训练细节。我们在精选数据集上对 LingBot-VA 进行 1.4T 令牌的预训练。采用 AdamW 优化器，峰值学习率 1×10^{-4} ，权重衰减 0.01，余弦退火调度配合线性预热。训练以 bfloat16 混合精度进行，梯度裁剪阈值为 2.0。应用无分类器引导，文本随机失活率为 0.1。逆动力学的损失权重 λ 设为 1。数据集在所有来源间均匀采样以确保均衡学习。我们通过验证集上的流匹配损失监控收敛。视频模型使用均匀信噪比采样器。视频与动作模型均采用均匀信噪比采样器。

后训练细节。尽管预训练模型对已见本体展现出零样本泛化能力，但适应新型机器人平台需要少量任务特定数据。我们发现仅需 50 条演示的后训练即可实现有效部署。采用降低的学习率 1×10^{-5} 并训练 3K 步，可获得稳健性能。或者，以较高学习率 1×10^{-4} 训练 1K 步也能产生合理结果，虽略逊一筹，但在计算资源受限时提供了更快的适应选项。

4.3 主要结果

4.3.1 真实世界部署

实验设置。为验证 LingBot-VA 的真实世界有效性，我们在实体机器人平台上部署模型，并在六个多样化操作任务上进行评估，涵盖三个具有挑战性的类别。（1）长程

任务：我们在制作早餐和拆包配送任务上进行评估，这些任务需要顺序的多步推理以及在长时间跨度上持续执行任务。











1 MAKE BREAKFAST	Evaluation Criterion		Grasp Plate	Grasp Bread	Insert Bread	Grasp Fork	Press Toaster	
	Robot Execution							
	Evaluation Criterion	Grasp Cup	Grasp Kettle	Place Apple	Pour Water	Serve Bread		
	Robot Execution							
2 UNPACK DELIVERY	EVALUATION CRITERION		Grab Knife	Push Blade	Handover			
	ROBOT EXECUTION							
	EVALUATION CRITERION	Cut Seal	Open Lid					
	ROBOT EXECUTION							
3 INSERT TUBES	EVALUATION CRITERION		Grasp & Insert 1 st Tube	Grasp & Insert 2 nd Tube	Grasp & Insert 3 rd Tube			
	ROBOT EXECUTION							
4 PICK SCREWS	EVALUATION CRITERION		Grab Paper	Pour Screws	Pick 1 st Screw	Pick 2 nd Screw	Pick 3 rd Screw	
	ROBOT EXECUTION							
5 FOLD CLOTH	EVALUATION CRITERION		Fold Half	Left Sleeve	Right Sleeve	Fold Again	Flatten	Place
	ROBOT EXECUTION							
6 FOLD PANTS	EVALUATION CRITERION		Fold at Waist	Fold Legs	Place			
	ROBOT EXECUTION							

图 6. 六项真实世界任务的详细任务进程与关键执行步骤。每项任务涉及一系列操作原语，评分标准详见表 S2 至 S4。

(2) 精密任务：我们在插入管件和拾取螺丝任务上进行测试，这些任务要求精确定位和精细的运动控制才能成功完成。(3) 可变形物体：我们纳入了叠衣服和叠裤子任务，这些任务涉及操纵非刚性材料，带来了独特的控制挑战。详细的任务流程总结于图 6 中。这些任务仅使用 50 个真实世界演示进行模型训练。我们以 1×10^{-4} 的学习率和 150,000 的序列长度对模型进行 500 步微调。

结果。如图 5 所示，LingBot-VA 在所有六项任务和两项评估指标（成功率和进度得分）上均持续取得最先进的性能，大幅超越了强大的基线 $\pi_{0.5}$ 。

我们强调几个验证我们设计选择的关键观察结果：(1) 在长跨度任务上的卓越性能表明，我们的视频-动作世界模型具有强大的时序记忆能力。通过联合建模视频和动作序列，模型能够在长时间跨度内有效保持任务上下文，实现连贯的多步推理，而不会丢失中间目标。(2) 在精密任务上的强劲结果验证了我们统一潜空间设计的有效性。通过在共享嵌入空间中对齐视频和动作表示，我们的模型实现了视觉感知与运动控制之间更紧密的耦合，从而产生更准确、更精细的动作预测。(3) 在可变形物体上的稳健性能凸显了视频生成作为隐式引导的价值。生成的视频未来提供了关于物体动力学和状态转换的丰富预测信号，这些信号指导动作模型为具有挑战性的非刚性材料生成更符合物理规律的操作轨迹。

这些结果共同表明，我们的视频-动作世界模型能够有效迁移到真实世界部署中，在多样化的操作场景中展现出稳健的性能。

4.3.2 仿真评估

实验设置。我们在两个广泛使用的仿真基准上评估 LingBot-VA：RoboTwin 2.0 [15] 和 LIBERO [47]，涵盖不同机器人本体的多种操作任务。

(1) 在 RoboTwin 2.0 中，我们采用多任务训练设置 [5]，所有模型在干净场景中收集的 2,500 条演示（每个任务 50 条）加上来自高度随机化场景的 25,000 条演示（每个任务 500 条）上进行训练。我们将原始 50 Hz 视频下采样至 12.5 Hz，同时保持动作频率为 50 Hz。模型训练 50K 步，学习率为 1×10^{-5} 。为了更清晰地比较性能，我们根据任务的时间跨度对 50 个 RoboTwin 任务进行分类（例如，Place Dual Shoes 有两步，Stack Blocks Three 有三步）。详细的时间跨度列于表 S1。

(2) 在 LIBERO 中，我们在四个 LIBERO 套件上训练模型：LIBERO-Spatial、LIBERO-Object、LIBERO-Goal 和 LIBERO-Long。每个套件包含 10 个任务，每个任务 50 条演示（共 500 条）。遵循 OpenVLA [34]，我们在训练前过滤掉不成功的演示。模型微调 4K 步，学习率为 1×10^{-5} ，序列长度为 1×10^5 。具体来说，我们报告三个随机种子上的平均成功率，每个种子包含 500 次评估试验（总共 $3 \times 500 = 1500$ ）用于每个任务套件。

结果 RoboTwin 2.0 是一个具有挑战性的双手操作基准，包含 50 多个需要协调双臂控制的任务。与单臂基准不同，RoboTwin 任务要求精确同步

表 1. RoboTwin 2.0 仿真评估（简单与困难，50 个任务）。RoboTwin 2.0 是一个具有挑战性的双手操作基准，需要协调的双臂控制。简单模式使用固定的初始配置，而困难模式涉及随机化的物体姿态和场景布局。* X-VLA 的结果引自 Motus [5]。括号中的改进表示相对于第二好方法（下划线标出）的提升。

Metric	X-VLA* [93]		π_0 [7]		$\pi_{0.5}$ [29]		Motus [5]		LingBot-VA (Ours)	
	Easy	Hard	Easy	Hard	Easy	Hard	Easy	Hard	Easy	Hard
Average _{Horizon = 1}	81.6	82.5	66.5	61.6	85.1	80.2	<u>91.0</u>	<u>90.6</u>	94.18 (+3.2)	93.56 (+3.0)
Average _{Horizon = 2}	59.3	55.9	66.1	54.7	79.3	73.0	<u>85.2</u>	<u>80.9</u>	90.35 (+5.2)	86.95 (+6.1)
Average _{Horizon = 3}	61.2	66.0	61.6	50.2	78.6	67.4	<u>85.0</u>	<u>84.2</u>	93.22 (+8.2)	93.28 (+9.1)
Average _{50 Tasks}	72.9	72.8	65.9	58.4	82.7	76.8	<u>88.7</u>	<u>87.0</u>	92.93 (+4.2)	91.55 (+4.6)

表 2. LIBERO 基准评估。LIBERO 在四个任务套件上测试操作能力：Spatial、Object、Goal 和 Long-horizon。我们的方法在 LIBERO-Object (99.6%)、LIBERO-Long (98.5%)、LIBERO-Spatial (98.5%) 以及总体平均 (98.5%) 上达到了新的最先进水平。基线结果引自 [93]。

Methods	LIBERO				
	Spatial	Object	Goal	Long	Avg
Octo [72]	78.9	85.7	84.6	51.1	75.1
Seer [73]	-	-	-	87.7	-
MoDE [61]	-	-	-	94.0	-
SuSIE [9]	-	-	-	76.3	-
SpatialVLA [58]	88.2	89.9	78.6	55.5	78.1
TraceVLA [94]	84.6	85.2	75.1	54.1	74.8
CoT-VLA [90]	87.5	91.6	87.6	69.0	81.1
ThinkAct [28]	88.3	91.4	87.1	70.9	84.4
SmolVLA [67]	93.0	94.0	91.0	77.0	88.8
CronusVLA [37]	97.3	99.6	96.9	94.0	97.0
FLOWER [62]	97.1	96.7	95.6	93.5	95.7
GR00T-N1 [6]	94.4	97.6	93.0	90.6	93.9
π_0 [7]	96.8	98.8	95.8	85.2	94.1
π_0 +FAST [57]	96.4	96.8	88.6	60.2	85.5
OpenVLA [34]	84.7	88.4	79.2	53.7	76.5
OpenVLA-OFT [32]	97.6	98.4	97.9	94.5	97.1
DD-VLA [44]	97.2	98.6	97.4	92.0	96.3
UniVLA [78]	95.4	98.8	93.6	94.0	95.4
X-VLA [93]	98.2	98.6	97.8	97.6	98.1
LingBot-VA (Ours)	98.5 $\pm$ 0.3	99.6 $\pm$ 0.3	97.2 $\pm$ 0.2	98.5 $\pm$ 0.5	98.5

两个机械臂，这显著增加了策略学习的难度。我们在简单（固定初始配置）和困难（物体姿态与场景布局变化）两种设置下进行评估。如表 1 所示，LingBot-VA 在简单设置下平均成功率达到 92.9%，困难设置下为 91.6%，大幅超越先前方法，包括 π_0 、 $\pi_{0.5}$ 、X-VLA 和 Motus。值得注意的是，在更长时域的任务中，改进更为显著：在时域=3 时，我们的方法相比次优方法分别提升了 +8.2%（简单）和 +9.1%（困难）。这表明我们的自回归机制能够有效维持长时间记忆，从而在任务复杂度增加时实现更稳健的性能。

我们进一步在 LIBERO 基准上进行了评估（表 2）。在 LIBERO 上，我们取得了 98.5% 的平均成功率，尤其在 LIBERO-Long 上表现突出（98.5%）。这些结果在基础视觉-语言-动作模型（VLA）的平均成功率方面树立了新的最先进水平，证明了我们的视频-动作世界模型在通用机器人控制中的有效性。

4.4 消融实验

异步与同步对比。我们在 RoboTwin 任务上将异步视频-动作生成与同步基线进行了比较。如表 3 所示，两种方法取得了相当的成功率，但我们的异步方法通过在执行当前动作的同时预测未来视频和动作序列，完成任务的速度提升了 $2\times$ 。这验证了异步生成在保持任务性能的同时显著提高了推理效率。

预训练 LingBot-VA 与 WAN 对比。为验证视频-动作架构中的设计选择，我们进行了一项受控消融实验，将预训练的 LingBot-VA 模型与 WAN (Wan2.2-5B) 作为微调初始化基线，在 RoboTwin 任务上进行比较。两个模型均使用相同的 RoboTwin 数据集和相同的后训练流程（50 个任务特定演示，学习率 1×10^{-5} ，3000 步）进行微调。

如表 3 所示，我们的预训练 LingBot-VA 模型在简单和困难设置下均大幅优于 WAN 微调。具体而言，LingBot-VA 的平均成功率为 92.10%（简单）和 91.12%（困难），而 WAN 微调的性能显著较低。这一性能差距凸显了我们联合视频-动作预训练策略的有效性，该策略赋予模型丰富的视觉-运动先验，从而促进了快速

表 3. RoboTwin 2.0（简易）上的消融研究。我们消融了三个设计选择：世界建模（自回归与双向）、部署模式（异步与同步）以及预训练（本文方法与 WAN）。

Ablation	Setting	Easy _{all}	Easy Horizon = 1	Easy Horizon = 2	Easy Horizon = 3
Baseline	LingBot-VA (Ours)	92.9	94.2	90.4	93.2
Deployment	FDM-grounded Async	90.4	92.5	87.7	85.6
	Naive Async	74.3	83.3	70.3	32.9
Pretrain	WAN	80.6	84.9	76.3	67.6




图 7. 不同动作网络初始化策略的训练动态比较：随机初始化导致优化不稳定（高梯度范数）和收敛缓慢。尽管重用视频网络权重可以稳定训练，但最终性能并非最优。本文方法通过复制预训练视频权重并进行适当缩放来初始化，被证明是最有效的，确保了平滑的训练动态和更快的收敛。

适应复杂的双手操作任务。

动作网络初始化. 动作流的适当初始化对于训练稳定性和收敛至关重要。我们将精心设计的初始化策略（第 3.3 节）与朴素的随机初始化进行比较。

如图 7 所示，从头开始的随机初始化表现出不稳定的训练动态，收敛速度显著较慢。这种不稳定性产生的原因是动作标记的输出分布最初与视频分布存在显著差异，从而破坏了我们统一架构中的联合注意力机制。相比之下，我们精心设计的初始化策略——通过使用缩放因子 $\alpha = \sqrt{d_v/d_a}$ 对预训练视频权重进行插值来初始化动作网络权重——产生了平滑的收敛和显著更低的损失。

4.5 分析

4.5.1 样本效率

本文通过探究灵语机器人视觉助手（LingBot-VA）在有限训练数据下的表现，考察其数据效率，并与我们在真 $\pi_{0.5}$ 实世界和仿真环境中进行了评估：“制作早餐”长时程任务和 RoboTwin 2.0 Easy 基准，使我们能够评估不同操作场景下的数据效率。

如图 8 所示，在真实世界和仿真任务的所有数据规模下，我们的方法始终优于 $\pi_{0.5}$ 。在低数据规模（10 个演示）下，LingBot-VA 在“制作早餐”任务上的进度得分比 $\pi_{0.5}$ 高 15.6%，在 RoboTwin 2.0 Easy 上高 10.3%，展示了卓越的样本效率。这些结果表明，我们的方法在多样化的操作场景中能从有限数据中更有效地学习。

我们将这种卓越的数据效率归因于我们的视频-动作世界模型设计。联合预训练的视频生成骨干网络提供了关于物理动力学和物体交互的丰富视觉先验，这些先验在后训练期间充当隐式正则化。这使得动作模型能够利用视频流中编码的世界知识，有效降低适应新任务所需的样本复杂度。相比之下，像 $\pi_{0.5}$ 这样的 VLA 模型缺乏对视觉动力学的显式建模，因此没有结构化的动力学先验来指导学习，需要




图 8. 样本效率比较。LingBot-VA 在“制作早餐”任务的各种数据规模下始终优于 $\pi_{0.5}$ ，展示了后训练阶段卓越的数据效率。




图 9. 时间记忆评估。左：两个记忆任务（擦盘子和搜索盒子）的成功率。LingBot-VA 在两个任务上均显著优于 $\pi_{0.5}$ ，展示了卓越的时间状态跟踪能力。右：评估环境的可视化。

更多的演示来从头学习任务特定行为。

4.5.2 时间记忆

我们设计了以下任务，这些任务明确要求跨时间维护状态信息，以评估模型的时间记忆能力，如图 9 所示。

1. 擦拭盘子——机器人必须恰好擦拭盘子六次，这要求它计数并记住重复的动作。
2. 搜索盒子——场景中有两个盒子（左和右），只有一个盒子中装有积木。机器人从右到左依次打开它们。在数据收集阶段，积木出现在任一盒子中的概率相等；在测试阶段，积木始终位于左侧盒子中。如果没有记忆，在发现右侧盒子为空后，模型有 50% 的概率会重新打开它。有了记忆，模型就会继续搜索左侧盒子。

如图 9(a) 所示，LingBot-VA 在两个记忆任务上均显著优于 $\pi_{0.5}$ 。我们将此归因于世界模型的自回归特性：在训练期间，教师强制将预测条件建立在完整历史上；在推理期间，键值缓存自然保留所有历史信息以实现持久记忆。




图 10. 新物体与空间泛化。LingBot-VA 成功泛化到具有不同形状、纹理和位置的物体。

4.5.3 泛化

我们从两个维度评估泛化能力：

1. 新物体泛化——在单一物体的抓取与放置任务上训练，在不同形状和纹理的物体上进行测试；
2. 空间泛化——在局部区域内以固定物体位置进行训练（记为分布内（ID）），在随机放置尤其是分布外（OOD）区域进行测试。

如图 10 所示，本文方法在新物体和分布外位置两方面均展现出更强的泛化能力。世界模型通过视频预测学习可迁移的视觉表征，捕捉与物体无关的物理先验，并将其迁移至新场景。

5 相关工作

视觉-语言-动作策略。 具身智能（Embodied AI）的最新进展见证了向大规模视觉-语言-动作（VLA）策略的范式转变。通过利用网络规模的知识 and 多样化的机器人演示，诸如 $\pi_{0.5}$ [29]、GR-3 [39] 和 GR00T-N1 [6] 等模型在各种操作任务中实现了显著的泛化能力，而无需依赖手工设计的规则、模块化先验或受限的动作抽象，从而实现了从感知到控制的更直接、更具表达力的端到端映射。这些策略通常采用预训练的视觉-语言模型（VLM）作为基础骨干 [6, 7, 11, 29, 34, 39, 87, 93]，与 ACT [91] 或扩散策略（Diffusion Policy）[17] 等任务特定的模仿策略相比，提供了更优越的跨模态理解和更泛化的动作分布。此外，人们还致力于通过轻量级骨干 [49, 62, 67]、高效分词 [57]、实时推理 [8, 10, 70] 或微调方案 [30, 32, 38] 来提高可部署性。然而，尽管它们在语义推理方面表现出色，一个根本性的局限性仍然存在：标准 VLM 的预训练目标和数据分布在很大程度上忽略了精确操作所必需的细粒度系统动力学和底层轨迹。虽然通过在昂贵收集的大规模机器人数据集上进行监督微调，这些模型能够近似边缘动作分布 [3, 31, 53]，但它们在捕捉底层转移动力学方面仍然不足——具体来说，即环境的物理状态应该如何演变以及将会如何演变。此外，当前大多数 VLA 方法将控制表述为从瞬时观测到动作的纯反应性映射。这种方法本质上无法考虑解决非马尔可夫环境中歧义所需的历史上下文。另外，VLM 固有的静态图像-文本预训练未能灌输必要的时间先验。即使通过记忆模块 [37, 65, 68] 进行增强，此类模型仍然无法推理物理交互的因果和顺序性质。为了解决这些不足，最近的研究转向了基于世界模型和生成式视频建模的通用机器人策略 [1, 5, 40, 64, 97]。然而，这些方法通常使用双向注意力生成预测，这违反了物理动力学的因果结构，并且在整个执行历史中缺乏持久的长期记忆。我们的 LingBot-VA 统一了自回归视频

在严格的因果时序结构下，通过动作解码进行预测，其中每一步预测仅基于过去的观测和动作。通过在完整交互历史上维护持久的键值缓存，LingBot-VA 确保了长程时序一致性，并使策略能够将物理执行与预测的环境视觉演化同步。

面向机器人控制的世界模型 受人类依赖直觉物理来预测环境变化的启发，世界模型旨在通过预测未来动态来促进有效规划。现有方法根据其状态表示大致分为三类。第一类在潜空间（Latent Space）中运行 [36, 41, 63, 80]，将任务相关特征编码为紧凑向量，通过概率 [36, 52, 83] 或确定性方法 [63, 85] 预测演化。第二类利用三维点云（Point Cloud）[66, 69, 77]，借助图神经网络（Graph Neural Network, GNN）预测几何演化 [88, 89]，这对于操纵可变形物体尤为有效 [77, 89]。第三类专注于二维像素空间，直接预测未来关键帧或视频序列 [21, 33, 95, 96]。本文工作属于第三类。在该领域中，方法范围从与视频生成联合训练以进行表示学习 [14, 40, 97]，到作为策略学习或评估的模拟器 [71]。本文研究特别针对在执行过程中预测未来帧以条件化动作生成的方法。然而，先前的视频条件化方法主要依赖开环生成 [21, 95]，带来两个显著挑战。首先，生成视频与真实世界动态之间的错位，加上执行误差的累积漂移，往往导致次优性能。其次，视频生成的计算强度带来高延迟，严重阻碍实时推理。本文方法利用键值缓存和因果掩码，持续用真实世界观测更新模型记忆。这有效地将系统转变为闭环控制机制，缓解长程任务中的误差累积。此外，本文引入部分去噪策略，使动作生成能够基于中间表示进行，而无需等待完全去噪的帧。

6 结论

本文提出灵巧机器人视频动作模型（LingBot-VA），一种自回归扩散框架，统一了机器人操作中的视频动态预测与动作推理。通过在变换器混合架构中交错视频与动作令牌，该模型捕捉物理交互的因果结构，同时通过持续整合真实世界观测实现闭环控制。广泛评估表明，该模型在仿真基准（机器人孪生 2.0 上 92.0%，自由机器人基准上 98.5%）和真实世界部署中均表现出强劲性能，在具有挑战性的任务上相比 $\pi_{0.5}$ 提升超过 20%，且仅需 50 次演示即可完成适应。这些结果表明，自回归视频-动作世界建模为学习可泛化的操作策略提供了原则性基础，为反应式视觉-语言-动作范式提供了有力替代方案。

未来工作。 未来方向包括开发更高效的视频压缩方案以降低计算开销，以及融合多模态传感输入（触觉、力觉、音频），从而在具有复杂接触动力学的任务中实现更稳健的操作。

致谢。 感谢郑克成富有洞见的讨论，以及吴伟在数据集准备方面的宝贵协助。同时感谢徐芳怡和沈一姝在训练后数据收集集中的帮助。

参考文献

- [1] 1X Technologies. 1x world model: From video to action. <https://www.1x.tech/discover/world-model-self-learning>, 2025. Accessed 2026-01-18.
- [2] AgiBot-World-Contributors, Qingwen Bu, Jisong Cai, Li Chen, Xiuqi Cui, Yan Ding, Siyuan Feng, Shenyuan Gao, Xindong He, Xuan Hu, Xu Huang, Shu Jiang, Yuxin Jiang, Cheng Jing, Hongyang Li, et al. Agibot world colosseum: A large-scale manipulation platform for scalable and intelligent embodied systems. *arXiv preprint arXiv:2503.06669*, 2025.
- [3] Jose Barreiros, Andrew Beaulieu, Aditya Bhat, Rick Cory, Eric Cousineau, Hongkai Dai, Ching-Hsin Fang, Kunimatsu Hashimoto, Muhammad Zubair Irshad, Masha Itkina, et al. A careful examination of large behavior models for multitask dexterous manipulation. *arXiv preprint arXiv:2507.05331*, 2025.
- [4] Homanga Bharadhwaj, Debidatta Dwibedi, Abhinav Gupta, Shubham Tulsiani, Carl Doersch, Ted Xiao, Dhruv Shah, Fei

- Xia, Dorsa Sadigh, and Sean Kirmani. Gen2act: Human video generation in novel scenarios enables generalizable robot manipulation. In *Conference on Robot Learning (CoRL)*, 2024.
- [5] Hongzhe Bi, Hengkai Tan, Shenghao Xie, Zeyuan Wang, Shuhe Huang, Haitian Liu, Ruowen Zhao, Yao Feng, Chendong Xiang, Yinze Rong, Hongyan Zhao, Hanyu Liu, Zhizhong Su, Lei Ma, Hang Su, et al. Motus: A unified latent action world model. *arXiv preprint arXiv:2512.13030*, 2025.
 - [6] Johan Bjorck, Fernando Castañeda, Nikita Cherniadev, Xingye Da, Runyu Ding, Linxi Jim Fan, Yu Fang, Dieter Fox, Fengyuan Hu, Spencer Huang, Joel Jang, Zhenyu Jiang, Jan Kautz, Kaushil Kundalia, Lawrence Lao, et al. Gr00t n1: An open foundation model for generalist humanoid robots. *arXiv preprint arXiv:2503.14734*, 2025.
 - [7] Kevin Black, Noah Brown, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Lachy Groom, Karol Hausman, Brian Ichter, Szymon Jakubczak, Tim Jones, Liyiming Ke, Sergey Levine, Adrian Li-Bell, et al. π_0 : A vision-language-action flow model for general robot control. In *Robotics: Science and Systems*, 2025.
 - [8] Kevin Black, Manuel Y. Galliker, and Sergey Levine. Real-time execution of action chunking flow policies. *arXiv preprint arXiv:2506.07339*, 2025.
 - [9] Kevin Black, Mitsuhiko Nakamoto, Pranav Atreya, Homer Walke, Chelsea Finn, Aviral Kumar, and Sergey Levine. Zero-shot robotic manipulation with pretrained image-editing diffusion models. In *Int. Conf. Learn. Represent.*, 2024.
 - [10] Kevin Black, Allen Z Ren, Michael Equi, and Sergey Levine. Training-time action conditioning for efficient real-time chunking. *arXiv preprint arXiv:2512.05964*, 2025.
 - [11] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Xi Chen, Krzysztof Choromanski, Tianli Ding, Danny Driess, Avinava Dubey, Chelsea Finn, Pete Florence, Chuyuan Fu, Montse Gonzalez Arenas, Keerthana Gopalakrishnan, Kehang Han, et al. Rt-2: Vision-language-action models transfer web knowledge to robotic control. In *Conference on Robot Learning (CoRL)*, 2023.
 - [12] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Joseph Dabis, Chelsea Finn, Keerthana Gopalakrishnan, Karol Hausman, Alex Herzog, Jasmine Hsu, Julian Ibarz, Brian Ichter, Alex Irpan, Tomas Jackson, Sally Jesmonth, et al. Rt-1: Robotics transformer for real-world control at scale. In *Robotics: Science and Systems*, 2023.
 - [13] Jake Bruce, Michael Dennis, Ashley Edwards, Jack Parker-Holder, Yuge Shi, Edward Hughes, Matthew Lai, Aditi Mavalankar, Richie Steigerwald, Chris Apps, Yusuf Aytar, Sarah Bechtle, Feryal Behbahani, Stephanie Chan, Nicolas Heess, et al. Genie: Generative interactive environments. In *Int. Conf. Mach. Learn.*, 2024.
 - [14] Qingwen Bu, Yanting Yang, Jisong Cai, Shenyan Gao, Guanghui Ren, Maoqing Yao, Ping Luo, and Hongyang Li. Learning to act anywhere with task-centric latent actions. *arXiv preprint arXiv:2502.14420*, 2025.
 - [15] Tianxing Chen, Zanzin Chen, Baijun Chen, Zijian Cai, Yibin Liu, Zixuan Li, Qiwei Liang, Xianliang Lin, Yiheng Ge, Zhenyu Gu, Weiliang Deng, Yubin Guo, Tian Nian, Xuanbing Xie, Qiangyu Chen, et al. Robotwin 2.0: A scalable data generator and benchmark with strong domain randomization for robust bimanual robotic manipulation. *arXiv preprint arXiv:2506.18088*, 2025.
 - [16] Yi Chen, Yuying Ge, Weiliang Tang, Yizhuo Li, Yixiao Ge, Mingyu Ding, Ying Shan, and Xihui Liu. Moto: Latent motion token as the bridging language for robot manipulation. In *Int. Conf. Comput. Vis.*, 2025.
 - [17] Cheng Chi, Siyuan Feng, Yilun Du, Zhenjia Xu, Eric Cousineau, Benjamin Burchfiel, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. In *Robotics: Science and Systems*, 2023.
 - [18] Cheng Chi, Zhenjia Xu, Chuer Pan, Eric Cousineau, Benjamin Burchfiel, Siyuan Feng, Russ Tedrake, and Shuran Song. Universal manipulation interface: In-the-wild robot teaching without in-the-wild robots. In *Robotics: Science and Systems*, 2024.
 - [19] Chaorui Deng, Deyao Zhu, Kunchang Li, Chenhui Gou, Feng Li, Zeyu Wang, Shu Zhong, Weihao Yu, Xiaonan Nie, Ziang Song, Guang Shi, and Haoqi Fan. Emerging properties in unified multimodal pretraining. *arXiv preprint arXiv:2505.14683*, 2025.
 - [20] Yilun Du, Mengjiao Yang, Bo Dai, Hanjun Dai, Ofir Nachum, Joshua B. Tenenbaum, Dale Schuurmans, and Pieter Abbeel. Learning universal policies via text-guided video generation. In *Adv. Neural Inform. Process. Syst.*, 2023.
 - [21] Yilun Du, Sherry Yang, Bo Dai, Hanjun Dai, Ofir Nachum, Josh Tenenbaum, Dale Schuurmans, and Pieter Abbeel. Learning universal policies via text-guided video generation. *Advances in neural information processing systems*, 36:9156–9172, 2023.
 - [22] Yao Feng, Hengkai Tan, Xinyi Mao, Guodong Liu, Shuhe Huang, Chendong Xiang, Hang Su, and Jun Zhu. Vidar: Embodied video diffusion model for generalist bimanual manipulation. *arXiv preprint arXiv:2507.12898*, 2025.

- [23] Google DeepMind. Veo: A text-to-video generation system. *Google DeepMind Technical Report*, 2025.
- [24] Yanjiang Guo, Yucheng Hu, Jianke Zhang, Yen-Jen Wang, Xiaoyu Chen, Chaochao Lu, and Jianyu Chen. Prediction with action: Visual policy learning via joint denoising process. In *Adv. Neural Inform. Process. Syst.*, 2024.
- [25] Danijar Hafner, Jurgis Pasukonis, Jimmy Ba, and Timothy Lillicrap. Mastering diverse control tasks through world models. *Nature*, 2025.
- [26] Nicklas Hansen, Hao Su, and Xiaolong Wang. Td-mpc2: Scalable, robust world models for continuous control. In *Int. Conf. Learn. Represent.*, 2024.
- [27] Yucheng Hu, Yanjiang Guo, Pengchao Wang, Xiaoyu Chen, Yen-Jen Wang, Jianke Zhang, Koushil Sreenath, Chaochao Lu, and Jianyu Chen. Video prediction policy: A generalist robot policy with predictive visual representations. In *Int. Conf. Mach. Learn.*, 2025.
- [28] Chi-Pin Huang, Yueh-Hua Wu, Min-Hung Chen, Yu-Chiang Frank Wang, and Fu-En Yang. Thinkact: Vision-language-action reasoning via reinforced visual latent planning. In *Adv. Neural Inform. Process. Syst.*, 2025.
- [29] Physical Intelligence et al. $\pi_{0.5}$: A generalist robot policy with flow matching and world models. In *Conference on Robot Learning (CoRL)*, 2025.
- [30] Dong Jing, Gang Wang, Jiaqi Liu, Weiliang Tang, Zelong Sun, Yunchao Yao, Zhenyu Wei, Yunhui Liu, Zhiwu Lu, and Mingyu Ding. Mixture of horizons in action chunking. *arXiv preprint arXiv:2511.19433*, 2025.
- [31] Alexander Khazatsky, Karl Pertsch, Suraj Nair, Ashwin Balakrishna, Sudeep Dasari, Siddharth Karamcheti, Soroush Nasiriany, Mohan Kumar Srirama, Lawrence Yunliang Chen, Kirsty Ellis, Peter David Fagan, Joey Hejna, Masha Itkina, Marion Lepert, Yecheng Jason Ma, et al. Droid: A large-scale in-the-wild robot manipulation dataset. In *Robotics: Science and Systems*, 2024.
- [32] Moo Jin Kim, Chelsea Finn, and Percy Liang. Fine-tuning vision-language-action models: Optimizing speed and success. *arXiv preprint arXiv:2502.19645*, 2025.
- [33] Moo Jin Kim, Yihuai Gao, Tsung-Yi Lin, Yen-Chen Lin, Yunhao Ge, Grace Lam, Percy Liang, Shuran Song, Ming-Yu Liu, Chelsea Finn, et al. Cosmos policy: Fine-tuning video models for visuomotor control and planning. *arXiv preprint arXiv:2601.16163*, 2026.
- [34] Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, Ted Xiao, Ashwin Balakrishna, Suraj Nair, Rafael Rafailov, Ethan Foster, Grace Lam, Pannag Sanketi, Quan Vuong, Thomas Kollar, Benjamin Burchfiel, Russ Tedrake, Dorsa Sadigh, et al. Openvla: An open-source vision-language-action model. In *Conference on Robot Learning (CoRL)*, 2024.
- [35] Kuaishou. Kling ai. <https://klingai.kuaishou.com/>, 2024.
- [36] Chenchang Li, Zihao Ai, Tong Wu, Xiaosa Li, Wenbo Ding, and Huazhe Xu. Deformnet: Latent space modeling and dynamics prediction for deformable object manipulation. In *2024 IEEE International Conference on Robotics and Automation (ICRA)*, pages 14770–14776. IEEE, 2024.
- [37] Hao Li, Shuai Yang, Yilun Chen, Yang Tian, Xiaoda Yang, Xinyi Chen, Hanqing Wang, Tai Wang, Feng Zhao, Dahua Lin, et al. Cronusvla: Transferring latent motion across time for multi-frame prediction in manipulation. *arXiv preprint arXiv:2506.19816*, 2025.
- [38] Haozhan Li, Yuxin Zuo, Jiale Yu, Yuhao Zhang, Zhaohui Yang, Kaiyan Zhang, Xuekai Zhu, Yuchen Zhang, Tianxing Chen, Ganqu Cui, et al. Simplevla-rl: Scaling vla training via reinforcement learning. *arXiv preprint arXiv:2509.09674*, 2025.
- [39] Jiacheng Li, Mengzhou Sun, Bowen Zhang, Zhe Zhao, Xiu Liu, et al. Gr-3 technical report. *arXiv preprint arXiv:2507.15493*, 2025.
- [40] Shuang Li, Yihuai Gao, Dorsa Sadigh, and Shuran Song. Unified video action model. In *Robotics: Science and Systems*, 2025.
- [41] Yunzhu Li, Jiajun Wu, Jun-Yan Zhu, Joshua B Tenenbaum, Antonio Torralba, and Russ Tedrake. Propagation networks for model-based control under partial observation. In *2019 International Conference on Robotics and Automation (ICRA)*, pages 1205–1211. IEEE, 2019.
- [42] Junbang Liang, Ruoshi Liu, Ege Ozguroglu, Sruthi Sudhakar, Achal Dave, Pavel Tokmakov, Shuran Song, and Carl Vondrick. Dreamitate: Real-world visuomotor policy learning via video generation. In *Conference on Robot Learning (CoRL)*, 2024.
- [43] Weixin Liang, LILI YU, Liang Luo, Srinu Iyer, Ning Dong, Chunting Zhou, Gargi Ghosh, Mike Lewis, Wen tau Yih, Luke Zettlemoyer, and Xi Victoria Lin. Mixture-of-transformers: A sparse and scalable architecture for multi-modal foundation models. *Transactions on Machine Learning Research*, 2025.

- [44] Zhixuan Liang, Yizhuo Li, Tianshuo Yang, Chengyue Wu, Sitong Mao, Tian Nian, Liua Pei, Shunbo Zhou, Xiaokang Yang, Jiangmiao Pang, Yao Mu, and Ping Luo. Discrete diffusion vla: Bringing discrete diffusion to action decoding in vision-language-action policies. *arXiv preprint arXiv:2508.20072*, 2025.
- [45] Fanqi Lin, Yingdong Hu, Pingyue Sheng, Chuan Wen, Jiacheng You, and Yang Gao. Data scaling laws in imitation learning for robotic manipulation. In *Int. Conf. Learn. Represent.*, 2025.
- [46] Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matt Le. Flow matching for generative modeling. In *Int. Conf. Learn. Represent.*, 2023.
- [47] Bo Liu, Yifeng Zhu, Chongkai Gao, Yihao Feng, Qiang Liu, Yuke Zhu, and Peter Stone. Libero: Benchmarking knowledge transfer for lifelong robot learning. In *Adv. Neural Inform. Process. Syst.*, 2023.
- [48] Fangchen Liu, Chuanyu Li, Yihua Qin, Austin Shaw, Jing Xu, Pieter Abbeel, and Rui Chen. Vitamin: Learning contact-rich tasks through robot-free visuo-tactile manipulation interface. *arXiv preprint arXiv:2504.06156*, 2025.
- [49] Songming Liu, Lingxuan Wu, Bangguo Li, Hengkai Tan, Huayu Chen, Zhengyi Wang, Ke Xu, Hang Su, and Jun Zhu. Rdt-1b: A diffusion foundation model for bimanual manipulation. In *Int. Conf. Learn. Represent.*, 2025.
- [50] Xingchao Liu, Chengyue Gong, and Qiang Liu. Flow straight and fast: Learning to generate and transfer data with rectified flow. In *Int. Conf. Learn. Represent.*, 2023.
- [51] Zeyi Liu, Cheng Chi, Eric Cousineau, Naveen Kuppaswamy, Benjamin Burchfiel, and Shuran Song. Maniway: Learning robot manipulation from in-the-wild audio-visual data. *arXiv preprint arXiv:2406.19464*, 2024.
- [52] Bethany Lusch, J Nathan Kutz, and Steven L Brunton. Deep learning for universal linear embeddings of nonlinear dynamics. *Nature communications*, 9(1):4950, 2018.
- [53] Open X-Embodiment Collaboration. Open x-embodiment: Robotic learning datasets and rt-x models. In *IEEE International Conference on Robotics and Automation (ICRA)*, 2024.
- [54] OpenAI. Video generation models as world simulators. *OpenAI Technical Report*, 2024.
- [55] Jonas Pai, Liam Achenbach, Victoriano Montesinos, Benedek Forrai, Oier Mees, and Elvis Nava. mimic-video: Video-action models for generalizable robot control beyond vlcs. *arXiv preprint 2512.15692*, 2025.
- [56] Jack Parker-Holder, Philip Ball, Jake Bruce, Vibhavari Dasagi, Kristian Holsheimer, Christos Kaplanis, Alexandre Moufaret, Guy Scully, Jeremy Shar, Jimmy Shi, Stephen Spencer, Jessica Yung, Michael Dennis, Sultan Kenjeyev, Shangbang Long, et al. Genie 2: A large-scale foundation world model. <https://deepmind.google/discover/blog/genie-2-a-large-scale-foundation-world-model/>, 2024.
- [57] Karl Pertsch, Kyle Stachowicz, Brian Ichter, Danny Driess, Suraj Nair, Quan Vuong, Oier Mees, Chelsea Finn, and Sergey Levine. Fast: Efficient action tokenization for vision-language-action models. In *Robotics: Science and Systems*, 2025.
- [58] Delin Qu, Haoming Song, Qizhi Chen, Yuanqi Yao, Xinyi Ye, Yan Ding, Zhigang Wang, JiaYuan Gu, Bin Zhao, Dong Wang, and Xuelong Li. Spatialvla: Exploring spatial representations for visual-language-action model. In *Robotics: Science and Systems*, 2025.
- [59] Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li, and Peter J. Liu. Exploring the limits of transfer learning with a unified text-to-text transformer. *Journal of Machine Learning Research*, 21(140):1–67, 2020.
- [60] Omar Rayyan, John Abanes, Mahmoud Hafez, Anthony Tzes, and Fares Abu-Dakka. Mv-umi: A scalable multi-view interface for cross-embodiment learning. *arXiv preprint arXiv:2509.18757*, 2025.
- [61] Moritz Reuss, Jyothish Pari, Pulkit Agrawal, and Rudolf Lioutikov. Efficient diffusion transformer policies with mixture of expert denoisers for multitask learning. In *Int. Conf. Learn. Represent.*, 2025.
- [62] Moritz Reuss, Hongyi Zhou, Marcel Rühle, Ömer Erdiñç Yağmurlu, Fabian Otto, and Rudolf Lioutikov. Flower: Democratizing generalist robot policies with efficient vision-language-action flow policies. In *Conference on Robot Learning (CoRL)*, 2025.
- [63] Bokui Shen, Zhenyu Jiang, Christopher Choy, Silvio Savarese, Leonidas J Guibas, Anima Anandkumar, and Yuke Zhu. Action-conditional implicit visual dynamics for deformable object manipulation. *The International Journal of Robotics Research*, 43(4):437–455, 2024.
- [64] Yichao Shen, Fangyun Wei, Zhiying Du, Yaobo Liang, Yan Lu, Jiaolong Yang, Nanning Zheng, and Baining Guo. Videovla: Video generators can be generalizable robot manipulators. *arXiv preprint arXiv:2512.06963*, 2025.

- [65] Hao Shi, Bin Xie, Yingfei Liu, Lin Sun, Fengrong Liu, Tiancai Wang, Erjin Zhou, Haoqiang Fan, Xiangyu Zhang, and Gao Huang. Memoryvla: Perceptual-cognitive memory in vision-language-action models for robotic manipulation. *arXiv preprint arXiv:2508.19236*, 2025.
- [66] Haochen Shi, Huazhe Xu, Zhiao Huang, Yunzhu Li, and Jiajun Wu. Robocraft: Learning to see, simulate, and shape elastoplastic objects in 3d with graph networks. *The International Journal of Robotics Research*, 43(4):533–549, 2024.
- [67] Mustafa Shukor, Dana Aubakirova, Francesco Capuano, Pepijn Kooijmans, Steven Palma, Adil Zouitine, Michel Aractingi, Caroline Pascal, Martino Russi, Andres Marafioti, Simon Alibert, Matthieu Cord, Thomas Wolf, and Remi Cadene. Smolvla: A vision-language-action model for affordable and efficient robotics. *arXiv preprint arXiv:2506.01844*, 2025.
- [68] Ajay Sridhar, Jennifer Pan, Satvik Sharma, and Chelsea Finn. Memer: Scaling up memory for robot control via experience retrieval. *arXiv preprint arXiv:2510.20328*, 2025.
- [69] Deborah Sulsky, Shi-Jian Zhou, and Howard L Schreyer. Application of a particle-in-cell method to solid mechanics. *Computer physics communications*, 87(1-2):236–252, 1995.
- [70] Jiaming Tang, Yufei Sun, Yilong Zhao, Shang Yang, Yujun Lin, Zhuoyang Zhang, James Hou, Yao Lu, Zhijian Liu, and Song Han. Vlash: Real-time vlas via future-state-aware asynchronous inference. *arXiv preprint arXiv:2512.01031*, 2025.
- [71] Gemini Robotics Team, Coline Devin, Yilun Du, Debidatta Dwibedi, Ruiqi Gao, Abhishek Jindal, Thomas Kipf, Sean Kirmani, Fangchen Liu, Anirudha Majumdar, et al. Evaluating gemini robotics policies in a veo world simulator. *arXiv preprint arXiv:2512.10675*, 2025.
- [72] Octo Model Team, Dibya Ghosh, Homer Walke, Karl Pertsch, Kevin Black, Oier Mees, Sudeep Dasari, Joey Hejna, Tobias Kreiman, Charles Xu, Jianlan Luo, You Liang Tan, Lawrence Yunliang Chen, Pannag Sanketi, Quan Vuong, et al. Octo: An open-source generalist robot policy. In *Robotics: Science and Systems*, 2024.
- [73] Yang Tian, Sizhe Yang, Jia Zeng, Ping Wang, Dahua Lin, Hao Dong, and Jiangmiao Pang. Seer: Predictive inverse dynamics models are scalable learners for robotic manipulation. In *Int. Conf. Learn. Represent.*, 2025.
- [74] Yang Tian, Yuyin Yang, Yiman Xie, Zetao Cai, Xu Shi, Ning Gao, Hangxu Liu, Xuekun Jiang, Zherui Qiu, Feng Yuan, Yaping Li, Ping Wang, Junhao Cai, Jia Zeng, Hao Dong, et al. Interndata-a1: Pioneering high-fidelity synthetic data for pre-training generalist policy. *arXiv preprint arXiv:2511.16651*, 2025.
- [75] Alexander Tong, Kilian Fatras, Nikolay Malkin, Guillaume Huguette, Yanlei Zhang, Jarrod Rector-Brooks, Guy Wolf, and Yoshua Bengio. Improving and generalizing flow-based generative models with minibatch optimal transport. *Transactions on Machine Learning Research*, 2024.
- [76] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Adv. Neural Inform. Process. Syst.*, 2017.
- [77] Yixuan Wang, Yunzhu Li, Katherine Driggs-Campbell, Li Fei-Fei, and Jiajun Wu. Dynamic-resolution model learning for object pile manipulation. *arXiv preprint arXiv:2306.16700*, 2023.
- [78] Yuqi Wang, Xinghang Li, Wenxuan Wang, Junbo Zhang, Yingyan Li, Yuntao Chen, Xinlong Wang, and Zhaoxiang Zhang. Unified vision-language-action model. *arXiv preprint arXiv:2506.19850*, 2025.
- [79] WanTeam. Wan: Open and advanced large-scale video generative models. *arXiv preprint arXiv:2503.20314*, 2025.
- [80] Manuel Watter, Jost Springenberg, Joschka Boedecker, and Martin Riedmiller. Embed to control: A locally linear latent dynamics model for control from raw images. *Advances in neural information processing systems*, 28, 2015.
- [81] Kun Wu, Chengkai Hou, Jiaming Liu, Zhengping Che, Xiaozhu Ju, Zhuqin Yang, Meng Li, YINUO Zhao, Zhiyuan Xu, Guang Yang, Shichao Fan, Xinhua Wang, Fei Liao, Zhen Zhao, Guangyu Li, et al. Robomind: Benchmark on multi-embodiment intelligence normative data for robot manipulation. In *Robotics: Science and Systems*, 2025.
- [82] Philipp Wu, Alejandro Escontrela, Danijar Hafner, Pieter Abbeel, and Ken Goldberg. Daydreamer: World models for physical robot learning. In *Conference on Robot Learning (CoRL)*, 2022.
- [83] Philipp Wu, Alejandro Escontrela, Danijar Hafner, Pieter Abbeel, and Ken Goldberg. Daydreamer: World models for physical robot learning. In *Conference on robot learning*, pages 2226–2240. PMLR, 2023.
- [84] Shihan Wu, Xuecheng Liu, Shaoxuan Xie, Pengwei Wang, Xinghang Li, Bowen Yang, Zhe Li, Kai Zhu, Hongyu Wu, Yiheng Liu, Zhaoye Long, Yue Wang, Chong Liu, Dihan Wang, Ziqiang Ni, et al. Robocoin: An open-sourced bimanual robotic data collection for integrated manipulation. *arXiv preprint arXiv:2511.17441*, 2025.

- [85] Zhenjia Xu, Jiajun Wu, Andy Zeng, Joshua B Tenenbaum, and Shuran Song. Densephysnet: Learning dense physical object representations via multi-step dynamic interactions. *arXiv preprint arXiv:1906.03853*, 2019.
- [86] Mengjiao Yang, Yilun Du, Kamyar Ghasemipour, Jonathan Tompson, Leslie Pack Kaelbling, Dale Schuurmans, and Pieter Abbeel. Unisim: Learning interactive real-world simulators. In *Int. Conf. Learn. Represent.*, 2024.
- [87] Shuai Yang, Hao Li, Yilun Chen, Bin Wang, Yang Tian, Tai Wang, Hanqing Wang, Feng Zhao, Yiyi Liao, and Jiangmiao Pang. Instructvla: Vision-language-action instruction tuning from understanding to manipulation. *arXiv preprint arXiv:2507.17520*, 2025.
- [88] Kaifeng Zhang, Baoyu Li, Kris Hauser, and Yunzhu Li. Adaptigraph: Material-adaptive graph-based neural dynamics for robotic manipulation. *arXiv preprint arXiv:2407.07889*, 2024.
- [89] Kaifeng Zhang, Baoyu Li, Kris Hauser, and Yunzhu Li. Particle-grid neural dynamics for learning deformable object models from rgb-d videos. *arXiv preprint arXiv:2506.15680*, 2025.
- [90] Qingqing Zhao, Yao Lu, Moo Jin Kim, Zipeng Fu, Zhuoyang Zhang, Yecheng Wu, Zhaoshuo Li, Qianli Ma, Song Han, Chelsea Finn, et al. Cot-vla: Visual chain-of-thought reasoning for vision-language-action models. In *Proceedings of the Computer Vision and Pattern Recognition Conference*, pages 1702–1713, 2025.
- [91] Tony Z. Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware. In *Robotics: Science and Systems*, 2023.
- [92] Zhaxizhuoma, Kehui Liu, Chuyue Guan, Zhongjie Jia, Ziniu Wu, Xin Liu, Tianyu Wang, Shuai Liang, Peng Chen, Pingrui Zhang, Haoming Song, Delin Qu, Dong Wang, Zhigang Wang, Nieqing Cao, et al. Fastumi: A scalable and hardware-independent universal manipulation interface. *arXiv preprint arXiv:2409.19499*, 2024.
- [93] Jinliang Zheng, Jianxiong Li, Zhihao Wang, Dongxiu Liu, Xirui Kang, Yuchun Feng, Yinan Zheng, Jiayin Zou, Yilun Chen, Jia Zeng, Ya-Qin Zhang, Jiangmiao Pang, Jingjing Liu, Tai Wang, and Xianyu Zhan. X-vla: Soft-prompted transformer as scalable cross-embodiment vision-language-action model. *arXiv preprint arXiv:2510.10274*, 2025.
- [94] Ruijie Zheng, Yongyuan Liang, Shuaiyi Huang, Jianfeng Gao, Hal Daumé III, Andrey Kolobov, Furong Huang, and Jianwei Yang. Tracevla: Visual trace prompting enhances spatial-temporal awareness for generalist robotic policies. *arXiv preprint arXiv:2412.10345*, 2024.
- [95] Pengfei Zhou, Liliang Chen, Shengcong Chen, Di Chen, Wenzhi Zhao, Rongjun Jin, Guanghui Ren, and Jianlan Luo. Act2goal: From world model to general goal-conditioned policy. *arXiv preprint arXiv:2512.23541*, 2025.
- [96] Siyuan Zhou, Yilun Du, Jiaben Chen, Yandong Li, Dit-Yan Yeung, and Chuang Gan. Robodreamer: Learning compositional world models for robot imagination. *arXiv preprint arXiv:2404.12377*, 2024.
- [97] Chuning Zhu, Raymond Yu, Siyuan Feng, Benjamin Burchfiel, Paarth Shah, and Abhishek Gupta. Unified world models: Coupling video and action diffusion for pretraining on large robotic datasets. In *Robotics: Science and Systems*, 2025.

附录

A 真实世界评估细节

本文给出了所有真实世界操作任务的详细评估结果。每个任务均对本文方法和基线（ $\pi_{0.5}$ ）进行 20 次试验评估。为确保公平比较，采用交替评估协议：一次试验使用 $\pi_{0.5}$ ，随后一次试验使用本文方法，依此类推。

对于每次试验，我们记录每个中间步骤的成功状态。若某步骤需重试方能成功，则记 0.5 分；若失败，记 0 分；若首次尝试即成功，记 1 分。仅当所有步骤均完成（即总分等于最大可能得分）时，该试验方被标记为成功。

本文报告两项度量：

- **进度得分 (Progress Score, PS)**：所有试验的平均得分除以最大可能得分，以百分比表示
百分比：PS = $\frac{\text{Average Progress}}{\text{Max Steps}} \times 100\%$.
- **成功率 (Success Rate, SR)**：成功试验次数除以试验总次数，以百分比表示：
SR = $\frac{\# \text{ Successful Trials}}{N} \times 100\%$.

我们在六项多样化的真实世界任务上进行评估：制作早餐（10 步：准备一份完整的早餐，包括烤面包、倒水和摆盘）、拾取螺丝（5 步：拿起纸张、倒出螺丝并插入三颗螺丝）、叠衣服（6 步：折叠一件衬衫，包括袖子和抚平）、拆快递（5 步：使用美工刀打开包裹）、插管（2 类：抓取并插入 3 根管子）以及叠裤子（3 步：折叠裤子并放置）。这些任务涵盖了长时程顺序操作、精确控制以及可变形物体处理。以下表格展示了每项任务的逐次试验结果。

表 S1. 在 RoboTwin 2.0 仿真环境上的评估（简单与困难，50 项任务）。RoboTwin 2.0 是一个具有挑战性的双臂操作基准，要求协调的双臂控制。简单模式使用固定的初始配置，而困难模式涉及随机化的物体位姿和场景布局。

Simulation Task	Horizon	Ours		π_0 [7]		$\pi_{0.5}$ [7]		X-VLA [93]		Motus [5]	
		Easy	Hard	Easy	Hard	Easy	Hard	Easy	Hard	Easy	Hard
Adjust Bottle	1	90%	94%	99%	95%	100%	99%	100%	99%	89%	93%
Beat Block Hammer	1	96%	98%	79%	84%	96%	93%	92%	88%	95%	88%
Blocks Ranking RGB	3	99%	98%	80%	63%	92%	85%	83%	83%	99%	97%
Blocks Ranking Size	3	94%	96%	14%	5%	49%	26%	67%	74%	75%	63%
Click Alarmclock	1	99%	100%	77%	68%	98%	89%	99%	99%	100%	100%
Click Bell	1	100%	100%	71%	48%	99%	66%	100%	100%	100%	100%
Dump Bin Bigbin	1	89%	96%	88%	83%	92%	97%	79%	77%	95%	91%
Grab Roller	1	100%	100%	98%	94%	100%	100%	100%	100%	100%	100%
Handover Block	2	99%	78%	47%	31%	66%	57%	73%	37%	86%	73%
Handover Mic	2	94%	96%	97%	97%	98%	97%	0%	0%	78%	63%
Hanging Mug	2	40%	28%	14%	11%	18%	17%	23%	27%	38%	38%
Lift Pot	1	100%	99%	80%	72%	96%	85%	99%	100%	96%	99%
Move Can Pot	1	94%	97%	68%	48%	51%	55%	89%	86%	34%	74%
Move Pillbottle Pad	1	99%	99%	67%	46%	84%	61%	73%	71%	93%	96%
Move Playingcard Away	1	100%	99%	74%	65%	96%	84%	93%	98%	100%	96%
Move Stapler Pad	1	91%	79%	41%	24%	56%	42%	78%	73%	83%	85%
Open Laptop	1	92%	94%	71%	81%	90%	96%	93%	100%	95%	91%
Open Microwave	1	82%	86%	4%	32%	34%	77%	79%	71%	95%	91%
Pick Diverse Bottles	2	89%	82%	69%	31%	81%	71%	58%	36%	90%	91%
Pick Dual Bottles	2	100%	99%	59%	37%	93%	63%	47%	36%	96%	90%
Place A2B Left	1	97%	93%	43%	47%	87%	82%	48%	49%	82%	79%
Place A2B Right	1	97%	95%	39%	34%	87%	84%	36%	36%	90%	87%
Place Bread Basket	1	97%	95%	62%	46%	77%	64%	81%	71%	91%	94%
Place Bread Skillet	2	95%	90%	66%	49%	85%	66%	77%	67%	86%	83%
Place Burger Fries	2	97%	95%	81%	76%	94%	87%	94%	94%	98%	98%
Place Can Basket	2	81%	84%	55%	46%	62%	49%	52%	52%	81%	76%
Place Cans Plasticbox	2	100%	99%	63%	45%	94%	84%	97%	98%	98%	94%
Place Container Plate	1	99%	97%	97%	92%	99%	95%	97%	95%	98%	99%
Place Dual Shoes	2	94%	89%	59%	51%	75%	75%	79%	88%	93%	87%
Place Empty Cup	1	100%	100%	91%	85%	100%	99%	100%	98%	99%	98%
Place Fan	1	99%	93%	66%	71%	87%	85%	80%	75%	91%	87%
Place Mouse Pad	1	93%	96%	20%	20%	60%	39%	70%	70%	66%	68%
Place Object Basket	2	91%	88%	67%	70%	80%	76%	44%	39%	81%	87%
Place Object Scale	1	96%	95%	57%	52%	86%	80%	52%	74%	88%	85%
Place Object Stand	1	99%	96%	82%	68%	91%	85%	86%	88%	98%	97%
Place Phone Stand	1	97%	97%	49%	53%	81%	81%	88%	87%	87%	86%
Place Shoe	1	98%	98%	76%	76%	92%	93%	96%	95%	99%	97%
Press Stapler	1	85%	82%	44%	37%	87%	83%	92%	98%	93%	98%
Put Bottles Dustbin	3	87%	91%	65%	56%	84%	79%	74%	77%	81%	79%
Put Object Cabinet	2	85%	87%	73%	60%	80%	79%	46%	48%	88%	71%
Rotate QRcode	1	96%	91%	74%	70%	89%	87%	34%	33%	89%	73%
Scan Object	2	96%	91%	55%	42%	72%	65%	14%	36%	67%	66%
Shake Bottle Horizontally	1	100%	99%	98%	92%	99%	99%	100%	100%	100%	98%
Shake Bottle	1	100%	97%	94%	91%	99%	97%	99%	100%	100%	97%
Stack Blocks Three	3	99%	98%	72%	52%	91%	76%	6%	10%	91%	95%
Stack Blocks Two	2	100%	98%	93%	79%	97%	100%	92%	87%	100%	98%
Stack Bowls Three	3	86%	83%	77%	75%	77%	71%	76%	86%	79%	87%
Stack Bowls Two	2	94%	98%	94%	95%	95%	96%	96%	93%	98%	98%
Stamp Seal	1	96%	97%	46%	33%	79%	55%	76%	82%	93%	92%
Turn Switch	1	44%	45%	41%	42%	62%	54%	40%	61%	84%	78%
Average (%)	–	92.93	91.55	65.92	58.40	82.74	76.76	72.80	72.84	88.66	87.02

Table S2. Detailed evaluation results for Make Breakfast task (10 steps, max score 10).

Trial	Succ.	Grasp Plate	Grasp Bread	Grasp Fork	Place Bread	Press Toaster	Grasp Cup	Grasp Kettle	Pour	Grasp Apple	Serve	Prog.
Ours												
1	0	1	1	1	1	1	1	1	0	1	1	9
2	1	1	1	1	1	1	1	1	1	1	1	10
3	1	1	1	1	1	1	1	1	1	1	1	10
4	1	1	1	1	1	1	1	1	1	1	1	10
5	1	1	1	1	1	1	1	1	1	1	1	10
6	1	1	1	1	1	1	1	1	1	1	1	10
7	0	1	1	1	1	1	1	1	1	1	0	9
8	1	1	1	1	1	1	1	1	1	0.5	1	9.5
9	0	1	1	1	0	1	1	1	1	1	1	9
10	1	1	1	1	1	1	1	1	1	1	1	10
11	0	1	1	1	1	1	1	1	0	1	1	9
12	1	1	1	1	1	1	1	1	1	1	1	10
13	0	1	1	1	0	1	1	1	1	1	1	9
14	1	1	1	1	1	1	1	1	1	1	1	10
15	1	1	1	1	1	1	1	1	1	1	1	10
16	1	1	1	1	1	1	1	1	1	1	1	10
17	1	1	1	1	1	1	1	1	1	0.5	1	9.5
18	1	1	1	1	1	1	1	1	1	1	1	10
19	1	1	1	1	1	1	1	1	1	1	1	10
20	1	1	1	1	1	1	1	1	1	1	1	10
Avg Progress Score	0.75	1.00	1.00	1.00	0.90	1.00	1.00	1.00	0.90	0.95	0.95	9.70
Success Rate						97.0% (= 9.70/10 × 100%)						75.0% (= 15/20 × 100%)
$\pi_{0.5}$												
1	0	1	1	1	1	0	0	0	0	0	0	4
2	1	1	1	1	1	1	1	1	0	1	1	9
3	1	1	1	1	1	1	1	1	0	1	1	9
4	1	1	1	1	1	0	0	1	1	1	1	8
5	0	1	1	1	0	1	0	1	1	0	1	7
6	1	1	1	1	1	1	1	1	0	1	1	9
7	1	1	1	0	1	1	1	1	0	1	1	8
8	0	1	1	1	1	1	1	1	1	1	0	9
9	0	1	1	0	1	0	1	1	0	0	0	5
10	0	1	1	1	1	0	0	0	0	0	0	4
11	1	1	1	1	1	0	0	1	1	1	1	8
12	1	1	1	1	0	0	0	1	1	1	1	7
13	1	1	1	0	1	0	0	1	1	1	1	7
14	1	1	1	1	0	1	0	1	1	1	1	8
15	1	1	1	1	1	0	0	1	1	1	1	8
16	1	1	1	1	0	1	0	1	1	1	1	8
17	1	1	1	1	1	1	0	1	1	1	1	9
18	1	1	1	1	1	1	1	0	0	1	1	8
19	1	1	1	0	1	0	0	1	0	1	1	6
20	0	1	1	1	0	1	0	0	0	1	0	5
Avg Progress Score	0.70	1.00	1.00	0.80	0.75	0.55	0.35	0.80	0.50	0.80	0.75	7.30
Success Rate						73.0% (= 7.30/10 × 100%)						70.0% (= 14/20 × 100%)

Table S3. Detailed evaluation results for Pick Screws task (5 steps, max score 5).

Trial	Success	Grab Paper	Pour Screws	Screw 1	Screw 2	Screw 3	Progress
Ours							
1	1	1	1	0.5	0.5	1	4
2	0	1	0	1	1	0.5	3.5
3	1	1	1	1	0.5	0.5	4
4	1	1	1	1	1	1	5
5	1	1	1	1	1	0.5	4.5
6	1	1	1	0.5	1	0.5	4
7	1	1	1	1	1	1	5
8	1	1	1	1	1	1	5
9	0	1	0	0	0	0	1
10	1	1	1	1	1	1	5
11	1	1	1	1	1	1	5
12	0	1	0	1	1	1	4
13	0	1	0	1	1	1	4
14	1	1	1	1	0.5	0.5	4
15	0	1	0	0	0.5	1	2.5
16	1	1	1	1	1	1	5
17	1	1	1	1	1	0.5	4.5
18	1	1	1	0.5	0.5	1	4
19	0	1	1	0	1	0.5	3.5
20	1	1	1	1	1	1	5
Avg Progress Score	0.70	1.00	0.75	0.78	0.83	0.78	4.13
Success Rate			82.5% ($= 4.13/5 \times 100\%$)				
			70.0% ($= 14/20 \times 100\%$)				
$\pi_{0.5}$							
1	0	1	0	1	1	1	4
2	0	0.5	0	1	1	0.5	3
3	1	1	1	1	1	1	5
4	0	1	0	1	0.5	0.5	3
5	1	1	1	0.5	1	0.5	4
6	1	1	1	1	0.5	1	4.5
7	1	1	1	1	1	1	5
8	1	1	1	0.5	0.5	1	4
9	0	1	0	0.5	0.5	0	2
10	1	1	1	1	1	1	5
11	1	1	1	0.5	1	1	4.5
12	0	1	0	1	1	0.5	3.5
13	0	1	1	1	0	0.5	3.5
14	1	1	1	0.5	1	1	4.5
15	0	1	1	1	1	0	4
16	1	1	1	1	1	1	5
17	0	0	0	1	0.5	0.5	2
18	0	0	0	0	0	0	0
19	0	1	0	1	0.5	0.5	3
20	1	1	1	1	1	0.5	4.5
Avg Progress Score	0.50	0.88	0.60	0.83	0.75	0.65	3.70
Success Rate			74.0% ($= 3.70/5 \times 100\%$)				
			50.0% ($= 10/20 \times 100\%$)				

Table S4. Detailed evaluation results for Fold Clothes task (6 steps, max score 6).

Trial	Success	Fold Half	Left Sleeve	Right Sleeve	Fold Again	Flatten	Place	Progress
Ours								
1	1	1	1	1	1	1	1	6
2	0	1	1	0	0	0	0	2
3	1	1	1	1	1	0.5	0.5	5
4	1	1	1	1	1	1	1	6
5	0	0.5	0	0	0	0	0	0.5
6	0	0	0	0	0	0	0	0
7	0	0.5	0	0	0	0	0	0.5
8	1	1	1	1	1	0.5	0.5	5
9	1	1	1	1	1	1	1	6
10	1	1	1	1	1	1	1	6
11	0	0.5	0	0	0	0	0	0.5
12	0	0.5	0	0	0	0	0	0.5
13	0	0.5	0	0	0	0	0	0.5
14	0	1	1	1	1	1	0	5
15	0	0.5	0	0	0	0	0	0.5
16	0	1	1	1	1	0.5	0	4.5
17	0	0	0	0	0	0	0	0
18	0	1	1	1	0.5	0	0	3.5
19	0	0.5	0	0	0	0	0	0.5
20	1	1	1	1	1	1	1	6
Avg Progress Score	0.35	0.73	0.55	0.50	0.48	0.38	0.30	2.93
Success Rate				48.8% ($= 2.93/6 \times 100\%$)				35.0% ($= 7/20 \times 100\%$)
$\pi_{0.5}$								
1	1	1	1	1	1	1	1	6
2	1	1	1	1	1	1	1	6
3	1	1	1	1	0.5	1	0.5	5
4	0	1	1	1	0.5	1	0	4.5
5	0	0.5	1	1	0.5	1	0	4
6	0	1	1	0.5	1	1	0	4.5
7	0	0.5	0	0	0	0	0	0.5
8	0	0.5	0	0	0	0	0	0.5
9	0	1	1	1	1	1	0	5
10	0	0.5	1	1	0.5	0	0	3
11	0	0.5	0	0	0	0	0	0.5
12	0	1	1	1	1	1	0	5
13	0	1	1	0.5	0	0	0	2.5
14	1	1	1	1	1	1	1	6
15	1	1	1	1	0.5	1	1	5.5
16	0	1	1	1	0.5	0	0	3.5
17	1	1	1	1	1	1	1	6
18	0	1	1	1	0.5	1	0	4.5
19	0	0	0	0	0	0	0	0
20	0	1	1	1	0	0	0	3
Avg Progress Score	0.30	0.83	0.80	0.75	0.53	0.60	0.28	3.78
Success Rate				62.9% ($= 3.78/6 \times 100\%$)				30.0% ($= 6/20 \times 100\%$)

Table S5. Detailed evaluation results for Unpack Delivery task (5 steps, max score 5).

Trial	Success	Grab Knife	Push Blade	Handover	Cut Seal	Open Lid	Progress
Ours							
1	1	1	1	1	1	1	5
2	1	1	1	1	1	1	5
3	1	1	1	1	1	1	5
4	0	1	0	0	0	0	1
5	0	1	1	1	0.5	0	3.5
6	0	1	1	1	0	0	3
7	1	1	1	1	1	1	5
8	0	1	1	1	0	0	3
9	1	1	1	1	1	1	5
10	1	1	1	1	1	1	5
11	1	1	1	1	1	1	5
12	1	1	1	1	1	1	5
13	0	1	1	1	0	0	3
14	1	1	1	1	1	1	5
15	1	1	1	1	1	1	5
16	0	1	1	1	0	0	3
17	1	1	1	1	0.5	1	4.5
18	1	1	1	1	1	1	5
19	0	1	1	1	0.5	0	3.5
20	1	1	1	1	1	1	5
Avg Progress Score	0.65	1.00	0.95	0.95	0.68	0.65	4.23
Success Rate	84.5% (= 4.23/5 × 100%) 65.0% (= 13/20 × 100%)						
π _{0.5}							
1	0	1	1	0.5	0.5	0	3
2	0	1	1	1	0	0	3
3	0	1	1	1	0.5	0	3.5
4	0	1	1	1	0.5	0	3.5
5	0	1	1	1	0.5	0	3.5
6	0	1	1	1	0	0	3
7	0	1	1	1	0	0	3
8	1	1	1	1	0.5	1	4.5
9	0	1	1	1	0.5	0	3.5
10	1	1	1	1	1	1	5
11	0	1	1	1	0.5	0	3.5
12	0	1	1	1	0.5	0	3.5
13	1	1	1	1	1	1	5
14	0	1	1	1	0.5	0	3.5
15	1	1	1	1	0.5	1	4.5
16	0	1	1	1	0	0	3
17	0	1	1	1	0	0	3
18	0	1	1	1	0	0	3
19	0	1	1	1	0.5	0	3.5
20	1	1	1	1	1	1	5
Avg Progress Score	0.25	1.00	1.00	0.98	0.43	0.25	3.65
Success Rate	73.0% (= 3.65/5 × 100%) 25.0% (= 5/20 × 100%)						

Table S6. Detailed evaluation results for Insert Tubes task (2 categories: Grasp and Insert, max score 6).

Trial	Success	Grasp (3)	Insert (3)	Progress
Ours				
1	0	3	2	5
2	1	3	3	6
3	0	3	2	5
4	0	2	2	4
5	1	3	3	6
6	1	3	3	6
7	0	3	2	5
8	1	3	3	6
9	0	3	2	5
10	0	3	2	5
11	1	3	3	6
12	0	3	2	5
13	1	3	3	6
14	0	3	2	5
15	0	3	1	4
16	1	3	3	6
17	0	2	2	4
18	0	2	2	4
19	1	3	3	6
20	0	2	2	4
Avg Progress Score	0.40	2.80	2.35	5.15
Success Rate		85.8% ($= 5.15/6 \times 100\%$)	40.0% ($= 8/20 \times 100\%$)	
$\pi_{0.5}$				
1	0	3	1	4
2	0	3	1	4
3	0	3	1	4
4	0	3	1	4
5	0	3	1	4
6	0	3	1	4
7	0	3	1	4
8	0	3	2	5
9	1	3	3	6
10	1	3	3	6
11	1	3	3	6
12	0	2	1	3
13	0	3	2	5
14	0	2	2	4
15	1	3	3	6
16	1	3	3	6
17	0	3	2	5
18	0	2	2	4
19	1	3	3	6
20	0	3	2	5
Avg Progress Score	0.30	2.85	1.90	4.75
Success Rate		79.2% ($= 4.75/6 \times 100\%$)	30.0% ($= 6/20 \times 100\%$)	

Table S7. Detailed evaluation results for Fold Pants task (3 steps, max score 3).

Trial	Success	Fold 1	Fold 2	Place	Progress
Ours					
1	1	1	1	1	3
2	1	1	1	1	3
3	1	1	1	1	3
4	0	0	0	0	0
5	0	1	0	0	1
6	0	1	0	0	1
7	1	1	1	1	3
8	1	1	1	1	3
9	1	1	1	1	3
10	1	1	1	1	3
11	1	1	1	1	3
12	1	1	1	1	3
13	1	1	1	1	3
14	1	1	1	1	3
15	1	1	1	1	3
16	1	1	1	1	3
17	1	1	1	1	3
18	0	1	0	0	1
19	0	1	0	0	1
20	0	0	0	0	0
Avg Progress Score	0.70	0.90	0.70	0.70	2.30
Success Rate		76.7% (= 2.30/3 × 100%)			
		70.0% (= 14/20 × 100%)			
π _{0.5}					
1	1	1	1	1	3
2	1	1	1	1	3
3	1	1	1	1	3
4	0	0	0	0	0
5	0	0	0	0	0
6	0	0	0	0	0
7	0	0	0	0	0
8	0	0	0	0	0
9	0	0	0	0	0
10	0	0	0	0	0
11	1	1	1	1	3
12	1	1	1	1	3
13	1	1	1	1	3
14	0	0	0	0	0
15	0	0	0	0	0
16	0	0	0	0	0
17	0	0	0	0	0
18	0	0	0	0	0
19	0	0	0	0	0
20	0	0	0	0	0
Avg Progress Score	0.30	0.30	0.30	0.30	0.90
Success Rate		30.0% (= 0.90/3 × 100%)			
		30.0% (= 6/20 × 100%)			