

ManiLong-Shot: 面向长时程操作、交互感知的一次性模仿学习

Zixuan Chen^{1*}, Chongkai Gao², Lin Shao^{2†}, Jieqi Shi^{1,3}, Jing Huo^{1†}, Yang Gao^{4,1,3}

¹State Key Laboratory for Novel Software Technology, Nanjing University, Nanjing, China

²School of Computing, National University of Singapore, Singapore

³School of Intelligence Science and Technology, Nanjing University, Suzhou, China

⁴School of Network Security and Information Technology, YiLi Normal University, Xinjiang, China
chenzx@nju.edu.cn, linshao@nus.edu.sg, huojing@nju.edu.cn

摘要

一次性模仿学习 (OSIL) 为机器人学习新技能提供了一种有前景的途径, 无需大规模数据收集。然而, 当前的一次性模仿学习方法主要局限于短时程任务, 从而限制了其在复杂、长时程操作中的适用性。为解决这一局限性, 本文提出 ManiLong-Shot, 一种新颖的框架, 能够对长时程抓取操作任务实现有效的一次性模仿学习。ManiLong-Shot 围绕物理交互事件构建长时程任务, 将问题重新表述为对交互感知原语进行排序, 而非直接模仿连续轨迹。这种原语分解可由视觉语言模型 (VLM) 的高层推理驱动, 或由源自机器人状态变化的基于规则的启发式方法驱动。对于每个原语, ManiLong-Shot 预测对交互至关重要的不变区域, 建立演示与当前观测之间的对应关系, 并计算目标末端执行器位姿, 从而实现有效的任务执行。大量仿真实验表明, 仅在 10 个短时程任务上训练的 ManiLong-Shot, 通过一次性模仿泛化到三个难度级别的 20 个未见过的长时程任务, 相对于最先进方法实现了 **22.8%** 的相对提升。此外, 真实机器人实验验证了 ManiLong-Shot 通过一次性模仿学习稳健执行三个长时程操作任务的能力, 证实了其实际适用性。

Website — <https://sites.google.com/view/manilong-shot>

1 引言

为使机器人有效融入日常生活, 它们必须快速学习并执行多样化的长时程操作任务。诸如“摆放餐具”或“整理厨房”等日常家务体现了这些挑战, 因为它们通常涉及与多个物体的顺序交互, 并包含一系列子任务。一次性模仿学习 (OSIL) (Duan 等人, 2017; Finn 等人, 2017; Valassakis

* 本工作部分在陈子轩访问新加坡国立大学期间完成。† 通讯作者: 邵林, 霍静 版权所有 © 2026, 国际人工智能促进协会 (www.aaii.org)。保留所有权利。




图 1: 本文提出 ManiLong-Shot, 一种用于长时程抓取操作中有效一次性模仿学习的新颖框架。

等人, 2022) 是实现这一目标的关键技术, 使机器人能够从单次演示中获取新技能, 同时避免昂贵的重新训练。然而, 尽管前景广阔, 现有的单样本模仿学习方法往往难以扩展到长时程任务。许多方法仅限于短时程技能 (Zhang 和 Boularias, 2024; Vosylius 和 Johns, 2025), 要求新任务与训练任务仅有细微差异 (Xu 等人, 2022), 或依赖已知的三维物体模型 (Biza 等人, 2023)。这些局限性严重阻碍了它们在复杂的、多阶段的真实世界操作场景中的应用。我们从人类学习中汲取灵感: 当面对诸如摆放餐具这样的未见任务时, 人们会自然地将其分解为短时程原语, 并推断每个原语的关键交互区域。例如: 1) 拿起盘子 (边缘); 2) 放置盘子 (桌面上的目标位置); 3) 拿起叉子 (手柄)。每个原语都由物理交互 (如接触或释放) 界定, 模仿则是通过在这些区域上复现动作来实现的。这引出一个问题: 机器人能否从未标注的未见长时程任务演示中推断出子任务边界和关键交互区域, 从而实现其原语的高效单样本模仿学习? 为此, 我们提出了一种新颖的交互感知单样本模仿学习框架——**ManiLong-Shot**, 其灵感来源于人类在执行长时程操作单样本模仿学习时的策略和认知模式。

ManiLong-Shot 将长时程操作任务构建为一系列离散原语，每个原语对应机器人末端执行器与环境之间物理交互的不同阶段，即：接触前、抓取和接触后，如图 1 所示。该阶段分解设计建立在先前关于操作子任务分解的工作基础之上（James 和 Davison, 2022; Chen 等人, 2025b, e），并基于一个关键假设：子任务边界可以通过这些交互阶段可靠地识别。因此，我们的框架主要关注抓取类操作任务，如拾取和放置，而不涉及纯粹的非抓取行为。

ManiLong-Shot 包含三个核心模块：首先，它能够从单次演示中灵活分解长时程任务，利用基于夹爪状态和关节速度的简单启发式方法，或视觉语言模型（Vision-Language Model, VLM）的语义推理能力。两种策略均在我们的框架中实现并系统评估。其次，在将单次演示分解为基元后，ManiLong-Shot 专注于稳健地模仿每个基元。它采用交互感知区域预测网络，识别每次交互中关键物体表面区域。例如，在图 1 所示的抓杯任务中，关键动作涉及抓取杯沿——该区域在接触前阶段始终发挥此功能，无论杯子的姿态如何。此类区域被称为不变区域（Zhang and Boularias 2024），定义为在多样化任务场景中具有语义和功能稳定性的交互表面。最后，ManiLong-Shot 引入交互感知区域匹配网络，在执行过程中将演示中预测的不变区域与当前场景中的对应区域对齐。该匹配为机器人末端执行器提供目标姿态，实现每个基元的稳健顺序执行。因此，机器人能够以单次、完全端到端的单样本模仿学习（OSIL）方式高效可靠地完成长时程任务。

总之，我们的贡献如下：（1）我们提出

提出 **ManiLong-Shot**，一种新颖的一次性模仿学习框架，专为长时程抓取操作任务设计，将任务结构化为顺序交互原语，并通过交互感知流水线实现有效的端到端一次性模仿学习执行。（2）引入交互感知任务分解机制，利用视觉语言模型或基于规则的机器人状态转换，从单个未标注的长时程演示中推导交互原语。每个原语经过两阶段处理，预测功能不变区域并进行区域匹配以获得准确的目标位姿，确保稳健的任务执行。（3）构建 **RLBench-Oneshot** 基准，从操作基准 RLBench（James 等人, 2020）中选取 30 个任务，用于系统评估我们的框架。此外，我们在三个真实世界长时程操作任务上展示了 **ManiLong-Shot** 的一次性模仿学习能力的有效性，验证了其实际适用性。

2 相关工作

面向操作的一次性模仿学习。一次性模仿学习旨在从训练任务的演示中学习，并仅利用每个新任务的单条轨迹泛化到新任务，无需额外训练（Duan 等人, 2017; Finn 等人, 2017; Yu 等人, 2018; Biza 等人, 2023; Zhang 和 Boularias, 2024; Bonardi, James 和 Davison, 2020）。它是实现操作任务泛化的关键技术。早期工作采用元学习在不同机器人任务间迁移知识（Finn 等人, 2017; Gao, Jiang 和 Chen, 2023; Yu 等人, 2018），或利用专家轨迹训练基于变换器的策略（Mandi 等人, 2022）。Wen 等人（Wen 等人, 2022b,a）采用“预训练与适应”策略学习规范表示，而其他研究则探索基于图的任务结构或场景几何表示（Zhang 和 Boularias, 2024; Kumar 等人, 2023; Huang 等人, 2019）。然而，现有方法大多局限于简单的短时程任务。Wu 等人（2024a）通过组合短时程、目标条件原语，将一次性模仿学习扩展到长时程外在操作。相比之下，我们的工作消除了对预定义原语库的依赖，直接从单个演示中推断交互过程，为长时程抓取操作提供了更实用且可扩展的解决方案。

长时程任务的任务分解。长程操作的一种常见方法是“分而治之”策略，将复杂任务分解为较短且相对独立的子任务。这些子任务可以手动定义（Dalal, Pathak, and Salakhutdinov 2021; Gao et al. 2023），由环境预定义（Chen et al. 2025d; Zhu et al. 2021），或自动学习（Masson, Ranchod, and Konidaris 2016; Gao et al. 2025）。然而，确保其可重用性仍然是一个挑战——任务目标或环境的变化可能使预定义边界失效，阻碍泛化和鲁棒性（Wu et al. 2024a）。近期研究提出了基于机器人夹爪与环境之间物理交互的分解方法，展现出强大的鲁棒性和可迁移性（Chen et al. 2025b,e,a）。随着视觉语言模型（VLMs）的兴起，研究越来越多地探索其推理和生成能力用于子任务规划（Huang et al. 2025; Ding et al. 2025）。VLMs 已被用于生成子目标序列（Myers et al. 2024; Curtis et al. 2024; Zhu et al. 2025），合成可执行的操作代码（Liang et al. 2023; Huang et al. 2023; Chen et al. 2025c），以及识别跨实例的一致关键点（Fang et al. 2024），增强了任务分解的灵活性和泛化能力。我们的工作建立在利用机器人-物体交互的方法之上（Chen et al. 2025b,e），提出了一个交互感知的子任务分割框架。该方法整合了夹爪状态的启发式变化和 VLMs 来识别子任务边界，为长程抓取操作任务提供了一种鲁棒的分解策略。

操作中的不变对应。建立已见与未见场景之间的对应关系（Zhang et al. 2024）并引入不变性（Brand-

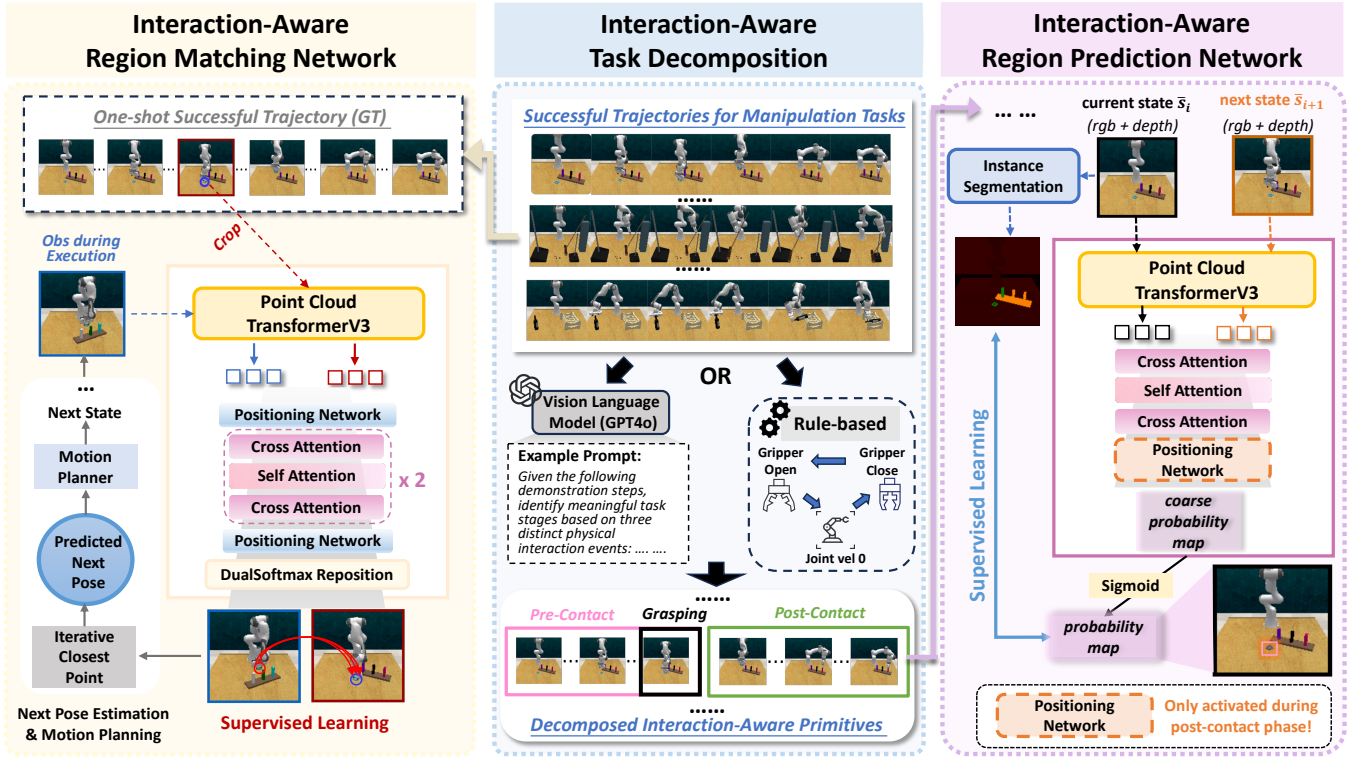


图 2: ManiLong-Shot 的整体训练流程。放大查看效果最佳。

Stetter 等人 (2021)、Lyle 等人 (2020)、Gao 等人 (2024) 的研究对于机器人系统中的泛化至关重要。在机器人操作领域, 先前的工作利用自监督学习构建密集视觉对应 (Florence, Manuelli 和 Tedrake 2018) 或在物体类别内建立形状对应 (Wen 等人 2022c), 从而实现跨相似物体的抓取迁移。其他方法侧重于学习视角不变表示, 以促进从不同视角进行动作迁移 (Graf 等人 2023)。最近, Zhang 和 Boularias (2024) 提出训练神经网络来识别与机器人末端执行器相关的语义不变区域, 从而实现一次性动作迁移。我们的工作在此基础上, 通过预测和匹配交互感知原语的多个阶段中的不变区域, 支持即使在复杂的长期操作任务中也能有效的一次性泛化。

3 问题表述 我们的工作解决的是使机器人能够仅凭一次未标注的成功演示, 就对新颖的长期抓取操作任务实现一次性泛化的问题。我们关注一类代表性任务, 其中机器人操作平行夹爪来抓取物体, 并在桌面环境中与多个物体进行拾放交互。在此设定下, 我们正式定义本文所考虑的短期和长期操作任务如下: 基于夹爪与单个物体之间的三个物理交互阶段——接触前、抓取

抓取中与接触后——若夹爪与物体的交互不超过一次, 即此类交互总数至多三次, 则任务定义为短时程 (SH)。否则, 若夹爪与物体的交互次数超过三次, 例如操作多个物体时, 任务视为长时程 (LH)。形式上, 本文中的操作任务分为两个子集: SH 集合 $\mathcal{T}^{\text{sh}}$, 为训练提供丰富的离线演示; LH 集合 $\mathcal{T}^{\text{lh}}$, 训练期间不可见, 需要一次性泛化。训练期间, 机器人从演示数据集 $\mathcal{D} = \{\tau_{\text{sh}}^{(k)} = \{(\hat{s}_t^{(k)}, \hat{a}_t^{(k)}, \hat{s}_{t+1}^{(k)})\}_{t=1}^{T_k}\}_{k=1}^K$ 中学习, 该数据集采样自 $\mathcal{T}^{\text{sh}}$, 其中每个 $\tau^{(k)}$ 是状态-动作对的序列。测试时, 为 $\mathcal{T}^{\text{lh}}$ 中的每个新任务提供单个成功演示, 记为 $\tau^{\text{lh}} = \{(\hat{s}_t, \hat{a}_t, \hat{s}_{t+1})\}_{t=0}^H$, 其中 $\hat{a}_t$ 将系统从 $\hat{s}_t$ 转移到 $\hat{s}_{t+1}$ 。在执行新 LH 任务期间遇到的任意状态 s 下, 机器人旨在基于 τ^{lh} 预测 18 维动作 $a = (\mathbf{T}, \lambda)$, 其中 $\mathbf{T} \in \mathbb{R}^{4 \times 4}$ 指定 $SE(3)$ 中期望的末端执行器位姿, $\lambda \in \{0, 1\}^2$ 编码夹爪命令和碰撞标志。 $\mathbf{T}$ 的低层运动执行由标准运动规划器处理。机器人迭代预测动作并规划运动, 直至整个任务完成。

4 方法

框架概述。我们提出 ManiLong-Shot, 一种交互感知的一次性模仿学习 (OSIL) 框架,




图 3: 三个物理交互阶段的可视化。

用于长时程抓取操作。它由三个模块组成：（1）交互感知任务分解，基于三个物理交互事件将演示分解为基元；（2）交互感知区域预测网络，为每个子任务预测功能和语义不变的区域；（3）交互感知区域匹配网络，将这些区域与新场景观测对齐，以确保空间对应。匹配后，系统通过运动规划估计并执行下一个末端执行器位姿，实现顺序任务执行。ManiLong-Shot 实现了对复杂长时程操作任务的有效一次性泛化。图 2 展示了 ManiLong-Shot 的训练流程。

交互感知任务分解。该过程根据物理交互阶段，将成功的演示轨迹组织为一系列交互感知原语。本文聚焦于使用夹爪的抓取操作任务，从长时程任务中人类策略的启发出发。遵循现有的子任务分解方案（James 和 Davison 2022；Chen 等人 2025b,e），本文将机器人-物体交互分为三个阶段：接触前、抓取和接触后。图 3 展示了在真实机器人执行“将杯子放置到杯架”任务中这些阶段，突出了它们与人类对操作认知理解的一致性。演示轨迹可以通过两种方式分解。一种方法使用为视觉语言模型（VLM）定制的提示和轨迹的结构化表示，引导自动识别交互阶段。在 ManiLong-Shot 中，本文采用 GPT-4o（Hurst 等人 2024）作为底层视觉语言模型。另一种基于规则的方法分析关节速度和夹爪状态变化，以推断整个轨迹中的阶段边界。接触前阶段包括夹爪保持张开并接近物体的帧，当关节速度在闭合前降为零时结束，表明精确对齐。抓取阶段捕捉夹爪从张开到闭合以固定物体的过渡。接触后阶段在成功抓取之后，涉及夹爪从闭合到张开，同时放置物体或其他物体交互。短时程任务通常涉及这些阶段的一个循环，而长时程任务则重复这些阶段直至完成。两种分解方法在本文框架中可以互换：基于规则的方法提供稳定性，而基于视觉语言模型的方法能够学习语义感知的交互模式。

交互感知区域预测网络。在从演示中提取交互感知子任务原语之后

分层策略，ManiLong-Shot 预测跨交互阶段功能上交互不变的区域。为实现这一目标，本文仅使用成功的短视界（SH）演示来训练交互感知区域预测网络（图 2 右），突显了系统的数据效率。该网络基于 Zhang 和 Boularias（2024）提出的不变区域概念，其中三维几何子集若在具有相同最优策略的状态下保持结构对 $SE(3)$ 变换等变，则视为不变。例如，在“插入方形柱”任务（图 2）中，接触前阶段的“方形环”尽管姿态变化，仍始终与抓取面的主轴对齐，展现出强不变特性。交互感知区域预测网络的训练利用来自短视界任务集的演示 $\mathcal{T}^{sh}$ 。对于每个任务 $\mathcal{T}_i^{sh}$ ，一条演示被划分为三段： τ_{pre}^{sh} ， τ_{grasp}^{sh} ，以及 τ_{post}^{sh} 。对于每对连续状态 $\{\bar{s}_i, \bar{s}_{i+1}\}$ ，从 RGB-D 观测生成稠密点云，并由点云变换器 V3（PTV3）（Wu 等，2024b）处理。这涉及跨场景（ $\bar{s}_i$ 和 $\bar{s}_{i+1}$ ）的渐进下采样与交叉注意力，以及每个场景内的自注意力，从而增强状态间对应关系和状态内特征表示。定位网络仅在接触后阶段激活，此时机器人利用注意力机制将抓取物体与目标区域对齐。由于接触前阶段和抓取阶段的不变区域在功能上相似，本文联合训练它们的预测网络。该网络从学习的空间先验生成粗略显著性图，通过逐点 Sigmoid 参数化进行细化，并输出交互概率分布以激活相关区域 $\mathcal{I}(\bar{s}_i)$ ，从而得到预测的不变区域（图 2 中的方形环）。该流程使用仿真中的真实实例掩码进行监督学习训练，以实现精确监督。

交互感知区域匹配网络。ManiLong-Shot 的另一个关键模块是交互感知区域匹配网络。交互感知区域预测网络在演示中识别跨交互原语的不变区域，而该模块使机器人能够将这些区域与其当前执行状态进行匹配，从而无需额外训练即可复现动作。网络架构基于先前工作（Zhang 和 Boularias 2024），如图 2（左）所示。该网络在多个 SH 任务演示上进行训练，无需显式任务分解，每个状态都标注了由实例分割掩码和 RGB-D 数据导出的真实不变区域。对于给定的 SH 任务，考虑一条与演示 τ_i^{sh} 不同的执行轨迹 τ_j^{sh} 。对于 τ_j^{sh} 中的每个状态 $\bar{s}_j$ ，状态路由网络（Zhang 和 Boularias 2024）基于特征相似性在 τ_i^{sh} 中选择最相似的状态 $\bar{s}_i$ 。不变区域 $\mathcal{I}(\bar{s}_i)$ 从其点云中裁剪出来，并与 $\bar{s}_j$ 的全场景点云融合，由 PTV3 模型联合下采样。定位网络首先应用初始注意力步骤，然后采用两阶段交叉-自-交叉注意力模块，以增强两个点云之间的空间和几何特征对齐。

在 $\bar{s}_j$ 上生成逐点特征。基于这些特征，采用双 Softmax 匹配算法 (Li 和 Harada, 2022) 计算 $\bar{s}_j$ 的场景点云与 $\bar{s}_i$ 的不变区域点云之间的对应矩阵 $\mathbf{C}$ 。网络使用每个时间步 τ_i^{sh} 与 τ_j^{sh} 之间的真值对应矩阵和物体位置标签进行训练。在获得演示状态的不变区域 $\mathcal{I}(\bar{s}_i)$ 与当前执行状态 $\bar{s}_j$ 之间的对应矩阵 $\mathbf{C}$ 后，本文应用基于对应的位姿回归算法 (Zhang 和 Boularias, 2024) 估计机器人在 $\bar{s}_j$ 处的动作位姿 $\mathbf{T}_j$ 。优化目标为： $\mathbf{T}_j = \arg \min_{\mathbf{T} \in \text{SE}(3)} \mathbf{T} \mathbf{T}_i^{-1} P_{\mathcal{I}(\bar{s}_i)} \mathbf{C} - P_{\bar{s}_j}$ ，其中 $\mathbf{T}_i$ 表示在 $\bar{s}_i, P_{\mathcal{I}(\bar{s}_i)}$ 处的演示动作位姿， $P_{\bar{s}_j}$ 分别表示 $\bar{s}_i$ 中不变区域的点云和 $\bar{s}_j$ 中完整场景的点云。一旦确定下一个位姿 $\mathbf{T}_j$ ，本文使用 **RRT-Connect** 算法 (LaValle 和 Kuffner Jr, 2001) 进行路径规划，计算从当前状态到目标状态的无碰撞轨迹，并在执行预测位姿后确定下一个状态观测。该观测随后被输入状态路由网络，与演示轨迹中的帧进行比较，启动下一轮不变区域匹配。此迭代过程持续进行，直至整个任务完成。更多训练细节见附录 A.2。

ManiLong-Shot 的评估 这三个关键模块共同构成 ManiLong-Shot 框架。在评估未见过的长时程 (LH) 任务时，ManiLong-Shot 首先利用交互感知任务分解模块将一次成功演示分解为一系列交互感知原语。对于每个交互阶段，交互感知区域预测网络预测相应的不变区域。在执行过程中，系统捕获实时观测，并采用交互感知区域匹配网络将预测区域与当前观测对齐。基于对应矩阵，系统执行位姿预测和运动规划。此迭代过程通过区域匹配不断细化位姿和动作，直至整个长时程任务完成。评估细节见附录 B。

5 实验

我们在仿真环境和真实场景中进行了大量实验，以解决以下问题：1) 在不同的初始条件下，ManiLong-Shot 能否在训练期间遇到的 SH 任务上取得较高的成功率？2) 给定一次成功的演示，ManiLong-Shot 能否在没有任何微调的情况下，有效地一次性泛化到未见过的 LH 操作任务？3) ManiLong-Shot 能否通过仿真到现实迁移，在真实世界的 LH 任务中有效地执行 OSIL？4) 关键模块的启发式设计如何影响 ManiLong-Shot 在未见过的 LH 任务上的一次性泛化性能？

5.1 实验设置

仿真基准。我们从机器人操作仿真基准 (RL-) 的 100 项任务中选取 30 项任务




图 4: RL Bench-Oneshot 中 20 个长程操作任务的可视化，包含 3 个难度等级。

基准 (詹姆斯等人, 2020 年) 以创建专用基准

RLBench-Oneshot 用于评估机器人操作模型的一次性模仿学习能力。基于第 3 节中的短时程和长时程任务定义，该基准包含 10 个短时程任务和 20 个长时程任务。短时程任务涉及单轮预接触、抓取和接触后交互，每个任务包含 100 条成功演示轨迹，使用 RGB-D 观测从前置、左/右肩和腕部摄像头录制。长时程任务根据任务时程长度分为三个难度等级，如图 4 所示：等级 1 包含 13 个任务，每个任务有 6 次物理交互；等级 2 包含 4 个任务，每个任务有 9 次交互；等级 3 包含 3 个任务，每个任务有 12 次交互。这些等级全面评估模型在各种长时程任务上的一次性模仿学习能力，每个长时程任务附带一条成功轨迹作为单样本演示。关于 **RLBench-Oneshot** 基准任务的更多细节见附录 C.1。

真实世界设置。我们使用 UFactory xArm7 机器人验证 ManiLong-Shot，利用 RealSense D435 和 D415 相机提供的 RGB-D 观测。对于运动规划，我们集成 MoveIt (Coleman 等人, 2014) 来引导机械臂到达末端执行器位姿。我们在真实世界中设置了三个长时程操作任务：堆叠积木、堆叠杯子和放置杯子，每个任务包含六个物理交互阶段。对于每个任务，我们通过人类遥操作收集一条成功轨迹，并进行 5 次单样本泛化试验。在每次试验中，物体位置相对于演示中的位置略有扰动。该设置用于评估在仿真中预训练的 ManiLong-Shot 模型的仿真到现实迁移能力，验证其在真实世界场景中的有效性和鲁棒性。

基线模型与评估指标。我们选择 ARP (Zhang 等人, 2025)、3DDA (Ke, Gkanatsios 和 Fragkiadaki, 2024)、RVT2 (Goyal 等人, 2024) 和 IMOP (Zhang 和 Boularias, 2024) 作为基线模型进行比较。前三个是 RLBench 基准上最先进的基于模仿学习的多任务模型，用于评估 ManiLong-Shot 在短时程任务上的性能以及其在长时程任务上无需微调的单样本泛化能力。

Models	Avg. Success (%) ↑	Avg. Rank ↓	Turn Tap	Open Drawer	Put Groceries in Cupboard	Place Shape in Shape Sorter	Put Money in Safe	Close Jar	Place Wine	Light Bulb In	Insert Peg	Meat off Grill
RVT2	79.2	3.1	99.0 ± 1.5	74.0 ± 4.5	66.0 ± 5.6	35.0 ± 6.8	96.0 ± 2.0	100.0 ± 0.0	95.0 ± 2.4	88.0 ± 3.2	40.0 ± 6.2	99.0 ± 1.2
3DDA	85.0	2.9	99.2 ± 1.6	89.6 ± 4.1	85.6 ± 4.1	44.0 ± 4.4	97.6 ± 2.0	96.0 ± 3.6	93.6 ± 4.8	82.4 ± 2.0	65.6 ± 4.1	96.8 ± 1.6
ARP	86.6	2.7	100.0 ± 0.0	92.8 ± 2.2	69.6 ± 5.2	46.4 ± 6.3	94.4 ± 2.5	97.6 ± 1.5	92.0 ± 2.1	94.4 ± 1.8	78.4 ± 3.9	96.0 ± 1.7
IMOP	65.24	3.9	51.2 ± 5.9	100.0 ± 0.0	46.4 ± 6.5	37.6 ± 7.0	96.0 ± 2.4	39.2 ± 6.7	96.0 ± 2.3	82.0 ± 4.1	12.0 ± 9.5	92.0 ± 2.7
ManiLong-Shot	90.4 (3.8% ↑)	1.9	95.4 ± 2.1	100.0 ± 0.0	82.0 ± 4.2	48.0 ± 6.3	100.0 ± 0.0	96.8 ± 1.9	100.0 ± 0.0	88.0 ± 2.8	44.0 ± 6.5	100.0 ± 0.0

表 1：10 个训练短时程任务上的性能。我们报告每个任务在 5 个随机种子上的成功率均值和标准差，以及所有任务的平均成功率和平均秩。

Models	Avg. Success (%) ↑	Avg. Rank ↓	Empty Container	Empty Dishwasher	Tray off Oven	Tray in Oven	Bottle in Fridge	Place 2 Cups	Remove 2 Cups	Straighten Rope	Slide & Place
RVT2+FT	4.1	3.7	1.6 ± 0.4	0.0 ± 0.0	0.0 ± 0.0	1.2 ± 0.3	4.0 ± 0.7	1.3 ± 0.5	2.7 ± 0.8	2.7 ± 0.8	2.7 ± 0.7
3DDA+FT	4.5	3.3	1.6 ± 0.5	1.3 ± 0.6	1.6 ± 0.7	1.2 ± 0.5	4.3 ± 0.9	1.3 ± 0.5	5.3 ± 1.0	5.3 ± 1.1	0.0 ± 0.0
ARP+FT	4.7	3.3	1.3 ± 0.6	2.7 ± 0.9	5.3 ± 1.1	0.0 ± 0.0	2.7 ± 0.7	0.0 ± 0.0	4.0 ± 0.9	4.0 ± 0.8	5.3 ± 1.2
IMOP	7.4	2.6	4.0 ± 0.8	1.3 ± 0.6	2.7 ± 0.9	5.3 ± 0.7	1.3 ± 0.5	2.7 ± 0.7	4.0 ± 0.8	4.0 ± 0.9	5.3 ± 1.0
ManiLong-Shot	30.2 (22.8% ↑)	1.0	28.0 ± 3.2	42.7 ± 2.8	37.3 ± 3.5	48.0 ± 2.1	18.7 ± 4.3	14.7 ± 3.9	24.0 ± 2.7	30.7 ± 2.5	26.7 ± 3.0

Models	Put Item	Take Item	Stack Cups	Stack Cups Blocks	Put 3 Books	Put Shoes	Take Shoes	Setup Chess	Set Table	Stack Blocks	Block Pyramid
RVT2+FT	28.0 ± 1.9	29.3 ± 2.1	2.7 ± 0.6	0.0 ± 0.0	2.7 ± 0.7	0.0 ± 0.0	0.0 ± 0.0	0.0 ± 0.0	1.3 ± 0.5	0.0 ± 0.0	0.0 ± 0.0
3DDA+FT	29.3 ± 2.0	30.7 ± 1.9	0.0 ± 0.0	0.0 ± 0.0	0.0 ± 0.0	1.3 ± 0.5	4.0 ± 0.8	1.3 ± 0.5	0.0 ± 0.0	0.0 ± 0.0	0.0 ± 0.0
ARP+FT	18.7 ± 1.5	37.3 ± 2.4	8.0 ± 1.2	0.0 ± 0.0	0.0 ± 0.0	2.7 ± 0.6	0.0 ± 0.0	1.3 ± 0.5	0.0 ± 0.0	0.0 ± 0.0	0.0 ± 0.0
IMOP	40.0 ± 2.0	38.7 ± 2.1	4.0 ± 1.0	1.3 ± 0.6	9.3 ± 1.4	1.3 ± 0.5	1.3 ± 0.5	1.3 ± 0.5	2.7 ± 0.6	1.3 ± 0.5	1.3 ± 0.5
ManiLong-Shot	65.3 ± 2.4	76.0 ± 1.8	28.0 ± 3.1	18.7 ± 4.0	42.7 ± 2.7	29.3 ± 2.9	12.0 ± 4.6	9.3 ± 4.8	17.3 ± 3.5	8.0 ± 4.9	8.0 ± 4.9

表 2：20 个未见长时程任务上的单样本模仿学习性能。我们报告每个任务在 5 个随机种子上的成功率均值和标准差，以及所有任务的平均成功率和平均秩。“FT”表示“使用 5 个演示进行微调”。

IMOP 是 RL Bench 任务上领先的单样本模仿学习方法，作为评估 ManiLong-Shot 在未见长时程任务上单样本模仿学习性能的关键基线。仿真评估指标包括平均成功率和平均秩。每个任务的成功率是 25 次试验（使用 5 个随机种子）的均值和标准差，因为 RL Bench-Oneshot 在不同试验中生成不同的物体布局。平均成功率是所有任务的均值，而平均秩通过在所有任务上对排名取平均来反映整体性能。对于真实世界机器人实验，我们报告 5 次试验的平均成功率。

5.2 主要结果

SH 任务上的性能比较 为评估 ManiLong-Shot 在训练 SH 任务上的表现，本文仅基于离线演示学习策略，不访问任何单样本示例。表 1 报告了 ManiLong-Shot 与多个基线在 RL Bench-Oneshot 基准中 10 个 SH 任务上的性能比较，这些任务也用于训练。在主要实验中，交互感知任务分解模块采用基于规则的方法实现。评估期间，交互感知区域预测网络通过监控机器人当前状态的变化来识别不同的交互阶段。实验结果表明，ManiLong-Shot 实现了强大的模仿学习性能，显著优于三个最先进的基线。其平均成功率达到 90.4%，比最佳基线提升了 3.8%。

3DDA。ManiLong-Shot 在 10 个任务中的 6 个上取得了最高成功率，包括精确操作（打开抽屉，100% 对比 ARP 的 92.8%）和多步协调（将钱放入保险箱，100% 对比 3DDA 的 97.6%）。这些结果凸显了 ManiLong-Shot 交互感知机制在不同交互阶段保持一致的模仿学习性能的有效性。

新颖 LH 任务上的 OSIL 性能 表 2 展示了 ManiLong-Shot 和基线在 RL Bench-Oneshot 中 20 个新颖 LH 任务上的 OSIL 性能。RVT2+FT、3DDA+FT 和 ARP+FT 表示使用五个成功演示对每个任务进行微调的模型。尽管进行了这种少样本适应，这些模型仍难以泛化，特别是在涉及新颖场景和交互的任务上。相比之下，对于与训练时 SH 任务共享场景的任务（例如，将物品放入抽屉和从抽屉取出物品，它们与打开抽屉共享场景），微调模型实现了中等程度的泛化。值得注意的是，ManiLong-Shot 在所有未见 LH 任务上无需任务特定微调即达到 30.2% 的平均成功率，比 IMOP 高出 **22.8%**。在最具挑战性的未见 LH 任务上，ManiLong-Shot 无需微调即取得了显著成果，例如摆桌子（17.4% 对比 IMOP 的 0.0%）、堆叠积木（8.0% 对比 IMOP 的 0.0%）和积木金字塔（8.0% 对比 IMOP 的 0.0%）。值得注意的是，堆叠积木和积木金字塔涉及长交互序列且需要精确操作。这些结果强调了 ManiLong-Shot 三个核心模块的有效性。对于复杂的 LH 任务，ManiLong-Shot 将任务分解为




图 5：三个真实世界长程任务及其物理交互可视化。

Task	Success Rate	
	IMOP	ManiLong-Shot
Stack Blocks	60%	80%
Stack Cups	20%	60%
Place Cups	20%	40%
Average	33.3%	60.0% (26.7% ↑)

表 3：OSIL 仿真到现实迁移性能。

与物理交互阶段对齐的交互感知原语，增强了对物体位姿和动力学变化的鲁棒性。通过在每个阶段执行区域预测和匹配，系统提高了执行稳定性和整体成功率。

真实世界实验 本文通过仿真到现实迁移，在三个代表性任务（堆叠积木、堆叠杯子和放置杯子，如图 5 所示）上评估了 ManiLong-Shot 在真实世界长程操作任务中的 OSIL 性能。对于每个任务，通过人类遥操作机械臂收集一条成功的演示轨迹，数据收集过程如图中所示。表 3 报告了 ManiLong-Shot 和 IMOP 在每个任务上五次 OSIL 试验的平均成功率，每次评估均在略有变化的物体布局下进行。结果表明，ManiLong-Shot 在真实世界长程操作任务上取得了有效的 OSIL 性能，平均成功率比 IMOP 提高了约 26.7%。

5.3 消融研究：基于 VLM 与基于规则。 本文研究了 ManiLong-Shot 交互感知任务分解模块中不同任务分解策略对未见长程任务 OSIL 性能的影响。如图 6（左）所示，基于 VLM 的分解在所有难度级别上始终不如基于规则的方法，主要原因是 VLM 推理的不稳定性。随着任务难度增加，需要识别和执行的原语增多，性能差距进一步扩大。尽管如此，采用基于 VLM 分解的 ManiLong-Shot 在未见长程任务上仍显著优于所有基线模型，验证了该框架在单样本泛化方面的有效性。VLM 的详细提示见附录 D。

有定位与无定位。 我们进一步研究了 ManiLong-Shot 中定位网络的效果，




图 6：ManiLong-Shot 关键模块的消融实验。在 RL-Bench-Oneshot 中三个难度级别的任务上平均成功率的比较。

特别是接触后阶段的不变区域预测。如图 6（右）所示，在所有三个难度级别中，移除该阶段的定位网络可能导致被抓取物体的放置不准确。这种错位往往会干扰后续子任务原语的执行，最终阻碍整体 LH 任务的成功完成，并导致系统在未见 LH 任务上的 OSIL 性能显著下降。图 6（顶部）可视化了 ManiLong-Shot 在 Block Pyramid 任务中将第一个块放置到目标区域时的性能差异，比较了有和没有定位网络的情况。

6 结论与局限性

我们提出了 ManiLong-Shot，一种专为长时程抓取操作任务设计的新型 OSIL 框架。ManiLong-Shot 利用机器人与物体之间的物理交互将任务分解为接触前、抓取和接触后原语，并为每个阶段预测交互感知的不变区域。利用这些预测，ManiLong-Shot 在单次学习阶段通过对应关系执行区域匹配和姿态预测。我们通过在仿真和真实机器人上的大量实验评估了 ManiLong-Shot 的性能，证明了其在长时程操作中有效且鲁棒的 OSIL 能力。

局限性与未来工作。 ManiLong-Shot 的一个主要局限性在于其分解策略，该策略根据物理接触将操作定义为三个离散阶段。虽然对许多长时程抓取任务有效，但这限制了其在接触后工具使用时间较长的任务（如擦拭或倾倒）中的适用性，因为这些任务的交互是连续的且难以分解。未来工作将侧重于扩展该框架，以处理更通用的长时程任务、跨具身场景以及复杂的、时间上连续的行为。

致谢

本工作部分得到国家自然科学基金（62192783、62276128）、江苏省自然科学基金（BK20243051）、江苏省科技重大专项（BG2024031）、中央高校基本科研业务费（14380128、KG202514）、新型软件技术与产业化协同创新中心以及国家留学基金管理委员会项目（批准号：202306190157）的资助。

参考文献

- Biza, O.; Thompson, S.; Pagidi, K. R.; Kumar, A.; van der Pol, E.; Walters, R.; Kipf, T.; van de Meent, J.-W.; Wong, L. L.; and Platt, R. 2023. One-shot imitation learning via interaction warping. *arXiv preprint arXiv:2306.12392*.
- Bonardi, A.; James, S.; and Davison, A. J. 2020. Learning one-shot imitation from humans without humans. *IEEE Robotics and Automation Letters*, 5(2): 3533–3539.
- Brandstetter, J.; Hesselink, R.; van der Pol, E.; Bekkers, E. J.; and Welling, M. 2021. Geometric and physical quantities improve e (3) equivariant message passing. *arXiv preprint arXiv:2110.02905*.
- Chen, Y.; Chen, Z.; Chan, N. T.; Chen, J.; Yin, J.; Shi, J.; Gao, Y.; Li, Y.-L.; and Huo, J. 2025a. RoboHiMan: A Hierarchical Evaluation Paradigm for Compositional Generalization in Long-Horizon Manipulation. *arXiv preprint arXiv:2510.13149*.
- Chen, Y.; Chen, Z.; Yin, J.; Huo, J.; Tian, P.; Shi, J.; and Gao, Y. 2025b. GravMAD: Grounded Spatial Value Maps Guided Action Diffusion for Generalized 3D Manipulation. In *Proceedings of the International Conference on Learning Representations (ICLR)*.
- Chen, Z.; Huo, J.; Chen, Y.; and Gao, Y. 2025c. RoboHorizon: An LLM-Assisted Multi-View World Model for Long-Horizon Robotic Manipulation. *arXiv preprint arXiv:2501.06605*.
- Chen, Z.; Ji, Z.; Huo, J.; and Gao, Y. 2025d. SCaR: Refining skill chaining for long-horizon robotic manipulation via dual regularization. *Advances in Neural Information Processing Systems*, 37: 111679–111714.
- Chen, Z.; Yin, J.; Chen, Y.; Huo, J.; Tian, P.; Shi, J.; Hou, Y.; Li, Y.; and Gao, Y. 2025e. DeCo: Task Decomposition and Skill Composition for Zero-Shot Generalization in Long-Horizon 3D Manipulation. *arXiv preprint arXiv:2505.00527*.
- Coleman, D.; Sucan, I.; Chitta, S.; and Correll, N. 2014. Reducing the barrier to entry of complex robotic software: a moveit! case study. *arXiv preprint arXiv:1404.3785*.
- Curtis, A.; Kumar, N.; Cao, J.; Lozano-Pérez, T.; and Kaelbling, L. P. 2024. Trust the PRoC3S: Solving Long-Horizon Robotics Problems with LLMs and Constraint Satisfaction. In *8th Annual Conference on Robot Learning*.
- Dalal, M.; Pathak, D.; and Salakhutdinov, R. R. 2021. Accelerating robotic reinforcement learning via parameterized action primitives. *Advances in Neural Information Processing Systems*, 34: 21847–21859.
- Ding, H.; Xu, Z.; Fang, Y.; Wu, Y.; Chen, Z.; Shi, J.; Huo, J.; Zhang, Y.; and Gao, Y. 2025. LaViRA: Language-Vision-Robot Actions Translation for Zero-Shot Vision Language Navigation in Continuous Environments. *arXiv preprint arXiv:2510.19655*.
- Duan, Y.; Andrychowicz, M.; Stadie, B.; Jonathan Ho, O.; Schneider, J.; Sutskever, I.; Abbeel, P.; and Zaremba, W. 2017. One-shot imitation learning. *Advances in neural information processing systems*, 30.
- Fang, X.; Huang, B.-R.; Mao, J.; Shone, J.; Tenenbaum, J. B.; Lozano-Pérez, T.; and Kaelbling, L. P. 2024. Key-point Abstraction using Large Models for Object-Relative Imitation Learning. *arXiv preprint arXiv:2410.23254*.
- Finn, C.; Yu, T.; Zhang, T.; Abbeel, P.; and Levine, S. 2017. One-shot visual imitation learning via meta-learning. In *Conference on robot learning*, 357–368. PMLR.
- Florence, P. R.; Manuelli, L.; and Tedrake, R. 2018. Dense Object Nets: Learning Dense Visual Object Descriptors By and For Robotic Manipulation. In *Conference on Robot Learning*, 373–385. PMLR.
- Gao, C.; Jiang, Y.; and Chen, F. 2023. Transferring hierarchical structures with dual meta imitation learning. In *Conference on Robot Learning*, 762–773. PMLR.
- Gao, C.; Li, Z.; Gao, H.; and Chen, F. 2023. Iterative interactive modeling for knotting plastic bags. In *Conference on Robot Learning*, 571–582. PMLR.
- Gao, C.; Xue, Z.; Deng, S.; Liang, T.; Yang, S.; Shao, L.; and Xu, H. 2024. RiEMann: Near real-time SE (3)-equivariant robot manipulation without point cloud segmentation. *arXiv preprint arXiv:2403.19460*.
- Gao, C.; Zhang, H.; Xu, Z.; Zhehao, C.; and Shao, L. 2025. FLIP: Flow-Centric Generative Planning as General-Purpose Manipulation World Model. In *The Thirteenth International Conference on Learning Representations*.
- Goyal, A.; Blukis, V.; Xu, J.; Guo, Y.; Chao, Y.-W.; and Fox, D. 2024. RVT2: Learning Precise Manipulation from Few Demonstrations. *RSS*.
- Graf, C.; Adrian, D. B.; Weil, J.; Gabriel, M.; Schillinger, P.; Spies, M.; Neumann, H.; and Kupcsik, A. G. 2023. Learning dense visual descriptors using image augmentations for robot manipulation tasks. In *conference on Robot Learning*, 871–880. PMLR.
- Huang, D.-A.; Nair, S.; Xu, D.; Zhu, Y.; Garg, A.; Fei-Fei, L.; Savarese, S.; and Niebles, J. C. 2019. Neural task graphs: Generalizing to unseen tasks from a single video demonstration. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 8565–8574.
- Huang, J.; Xu, Y.; Wang, Q.; Wang, Q. C.; Liang, X.; Wang, F.; Zhang, Z.; Wei, W.; Zhang, B.; Huang, L.; et al. 2025. Foundation models and intelligent decision-making: Progress, challenges, and perspectives. *The Innovation*.
- Huang, W.; Wang, C.; Zhang, R.; Li, Y.; Wu, J.; and Fei-Fei, L. 2023. VoxPoser: Composable 3D Value Maps for Robotic Manipulation with Language Models. In *Conference on Robot Learning*, 540–562. PMLR.

- Hurst, A.; Lerer, A.; Goucher, A. P.; Perelman, A.; Ramesh, A.; Clark, A.; Ostrow, A.; Welihinda, A.; Hayes, A.; Radford, A.; et al. 2024. Gpt-4o system card. *arXiv preprint arXiv:2410.21276*.
- James, S.; and Davison, A. J. 2022. Q-attention: Enabling efficient learning for vision-based robotic manipulation. *IEEE Robotics and Automation Letters*, 7(2): 1612–1619.
- James, S.; Ma, Z.; Arrojo, D. R.; and Davison, A. J. 2020. Rlbench: The robot learning benchmark & learning environment. *IEEE Robotics and Automation Letters*, 5(2): 3019–3026.
- James, S.; Wada, K.; Laidlow, T.; and Davison, A. J. 2022. Coarse-to-fine q-attention: Efficient learning for visual robotic manipulation via discretisation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 13739–13748.
- Ke, T.-W.; Gkanatsios, N.; and Fragkiadaki, K. 2024. 3d diffuser actor: Policy diffusion with 3d scene representations. *arXiv preprint arXiv:2402.10885*.
- Kumar, S.; Zamora, J.; Hansen, N.; Jangir, R.; and Wang, X. 2023. Graph inverse reinforcement learning from diverse videos. In *Conference on Robot Learning*, 55–66. PMLR.
- LaValle, S. M.; and Kuffner Jr, J. J. 2001. Randomized kinodynamic planning. *The international journal of robotics research*, 20(5): 378–400.
- Li, Y.; and Harada, T. 2022. Leopard: Learning partial point cloud matching in rigid and deformable scenes. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 5554–5564.
- Liang, J.; Huang, W.; Xia, F.; Xu, P.; Hausman, K.; Ichter, B.; Florence, P.; and Zeng, A. 2023. Code as policies: Language model programs for embodied control. In *2023 IEEE International Conference on Robotics and Automation (ICRA)*, 9493–9500. IEEE.
- Lin, T.-Y.; Goyal, P.; Girshick, R.; He, K.; and Dollár, P. 2017. Focal loss for dense object detection. In *Proceedings of the IEEE international conference on computer vision*, 2980–2988.
- Lyle, C.; van der Wilk, M.; Kwiatkowska, M.; Gal, Y.; and Bloem-Reddy, B. 2020. On the benefits of invariance in neural networks. *arXiv preprint arXiv:2005.00178*.
- Mandi, Z.; Liu, F.; Lee, K.; and Abbeel, P. 2022. Towards more generalizable one-shot visual imitation learning. In *2022 International conference on robotics and automation (ICRA)*, 2434–2444. IEEE.
- Masson, W.; Ranchod, P.; and Konidaris, G. 2016. Reinforcement learning with parameterized actions. In *Proceedings of the AAAI conference on artificial intelligence*, volume 30.
- Myers, V.; Zheng, C.; Mees, O.; Fang, K.; and Levine, S. 2024. Policy Adaptation via Language Optimization: Decomposing Tasks for Few-Shot Imitation. In *8th Annual Conference on Robot Learning*.
- Valassakis, E.; Papagiannis, G.; Di Palo, N.; and Johns, E. 2022. Demonstrate once, imitate immediately (dome): Learning visual servoing for one-shot imitation learning. In *2022 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, 8614–8621. IEEE.
- Vosylius, V.; and Johns, E. 2025. Instant Policy: In-Context Imitation Learning via Graph Diffusion. In *Proceedings of the International Conference on Learning Representations (ICLR)*.
- Wen, B.; Lian, W.; Bekris, K.; and Schaal, S. 2022a. Cat-grasp: Learning category-level task-relevant grasping in clutter from simulation. In *2022 International Conference on Robotics and Automation (ICRA)*, 6401–6408. IEEE.
- Wen, B.; Lian, W.; Bekris, K.; and Schaal, S. 2022b. You Only Demonstrate Once: Category-Level Manipulation from Single Visual Demonstration. *Robotics: Science and Systems 2022*.
- Wen, H.; Yan, J.; Peng, W.; and Sun, Y. 2022c. Transgrasp: Grasp pose estimation of a category of objects by transferring grasps from only one labeled instance. In *European Conference on Computer Vision*, 445–461. Springer.
- Wu, A.; Wang, R.; Chen, S.; Eppner, C.; and Liu, C. K. 2024a. One-shot transfer of long-horizon extrinsic manipulation through contact retargeting. In *2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, 13891–13898. IEEE.
- Wu, X.; Jiang, L.; Wang, P.-S.; Liu, Z.; Liu, X.; Qiao, Y.; Ouyang, W.; He, T.; and Zhao, H. 2024b. Point transformer v3: Simpler faster stronger. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 4840–4851.
- Xu, M.; Shen, Y.; Zhang, S.; Lu, Y.; Zhao, D.; Tenenbaum, J.; and Gan, C. 2022. Prompting decision transformer for few-shot policy generalization. In *international conference on machine learning*, 24631–24645. PMLR.
- Yu, T.; Finn, C.; Dasari, S.; Xie, A.; Zhang, T.; Abbeel, P.; and Levine, S. 2018. One-Shot Imitation from Observing Humans via Domain-Adaptive Meta-Learning. *Robotics: Science and Systems XIV*.
- Zhang, J.; Herrmann, C.; Hur, J.; Polania Cabrera, L.; Jampani, V.; Sun, D.; and Yang, M.-H. 2024. A tale of two features: Stable diffusion complements dino for zero-shot semantic correspondence. *Advances in Neural Information Processing Systems*, 36.
- Zhang, X.; and Boularias, A. 2024. One-Shot Imitation Learning with Invariance Matching for Robotic Manipulation. In *Proceedings of Robotics: Science and Systems*. Delft, Netherlands.
- Zhang, X.; Liu, Y.; Chang, H.; Schramm, L.; and Boularias, A. 2025. Autoregressive action sequence learning for robotic manipulation. *IEEE Robotics and Automation Letters*.
- Zhu, J.; Tie, C.; Cao, X.; Wang, Y.; Guo, J.; Chen, Z.; Chen, H.; Chen, J.; Xiao, Y.; Wu, R.; et al. 2025. AdaptPNP: Integrating Prehensile and Non-Prehensile Skills for Adaptive Robotic Manipulation. *arXiv preprint arXiv:2511.11052*.

Zhu, Y.; Tremblay, J.; Birchfield, S.; and Zhu, Y. 2021. Hierarchical planning for long-horizon manipulation with geometric and symbolic scene graphs. In *2021 IEEE International Conference on Robotics and Automation (ICRA)*, 6541–6548. Ieee.

技术附录

在本技术附录中，我们提供有关 ManiLong-Shot 框架的更多信息。首先，在第 A.1 节中，我们进一步阐述 ManiLong-Shot 所涉及的假设与网络架构。随后，在第 A.2 节中，我们详细说明交互感知不变区域匹配网络中所使用的状态路由网络的结构。第 A.3 节给出 ManiLong-Shot 的训练细节与目标。接下来，在第 B 节中，我们展示 ManiLong-Shot 在先前未见的长序列任务上进行单样本模仿学习 (OSIL) 的评估流程图，并对此过程进行更详细的描述。此外，我们在第 C 节中补充额外的实验细节，首先深入介绍 RL Bench-Oneshot 仿真基准所涉及的任务 (第 C.1 节)，并进一步阐述实验设计中使用的计算资源与相关代码库 (第 C.2 节)。最后，我们在第 D 节中提供基于视觉语言模型 (VLM) 的任务分解的详细提示，包括具体的提示模板。

A. ManiLong-Shot 的进一步训练细节

A.1. 更多理论细节

不变区域的定义。ManiLong-Shot 旨在从长时程任务中的单次成功演示中泛化动作策略 $\mathcal{T}_k \in \mathcal{T}^{\text{th}}$ 。给定该任务，从演示中观测到的状态转移 $(\hat{s}_t, \hat{a}_t, \hat{s}_{t+1})$ (其中 $\tau^{\text{th}} = \{(\hat{s}_t, \hat{a}_t, \hat{s}_{t+1})\}_{t=0}^H$) 以及执行过程中遇到的新实时状态 s_j ，目标是泛化操作策略。我们假设 $\hat{s}_i$ 和 s_j 应共享相同的最优操作动作。也就是说，尽管场景配置不同，它们应采用相同的操作策略。基于这一假设，ManiLong-Shot 能够将状态 $\hat{s}_i$ 下的动作位姿 $\mathbf{T}_i$ 映射到新的动作位姿 $\mathbf{T}_j$ ，以在状态 s_j 下完成任务。具体而言，给定任务 $\mathcal{T}_k \in \mathcal{T}^{\text{th}}$ ，状态 $\hat{s}_i$ 的不变区域定义为其点云中在所有共享相同最优操作策略的状态 s_j 下保持稳定的三维点集合。这些不变区域使机器人能够从演示状态泛化到实时状态，将动作位姿 $\mathbf{T}_i$ 映射到 $\mathbf{T}_j$ 并执行任务。根据 IMOP (Zhang 和 Boularias, 2024) 提出的定义，任务 $\mathcal{T}_k$ 中 $\hat{s}_i$ 的不变区域定义为：

$$\mathcal{I}(\hat{s}_i | \mathcal{T}_k) = \{p \in \hat{s}_i | \forall s_j \in \mathcal{S}, \hat{s}_i \equiv s_j, \exists q \in s_j : \|\mathbf{T}_i^{-1}p - \mathbf{T}_j^{-1}q\| < \epsilon\}, \quad (1)$$

其中 $(\mathbf{T}_i, \lambda_i) = \pi^*(\hat{s}_i | \mathcal{T}_k)$ ，且 $(\mathbf{T}_j, \lambda_j) = \pi^*(s_j | \mathcal{T}_k)$ 。在定义 1 中， $\hat{s}_i$ 表示长时程任务 $\mathcal{T}_k$ 中单次演示轨迹点云中的一个演示状态， $\hat{s}_i \equiv s_j$ 用于表明 s_i 和 s_j 共享

相同的最优操作动作。 $\mathcal{I}(\hat{s}_i | \mathcal{T}_k)$ 是其不变区域，即在 $\mathbf{T}_i$ 坐标系中在所有共享最优操作的状态 s_j 下保持稳定的三维点集合。 $\mathbf{T}_i$ 是在状态 $\hat{s}_i$ 下执行最优动作时的末端执行器位姿。

对应矩阵的定义。不变区域 $\mathcal{I}(\hat{s}_i)$ 通过逐点 Sigmoid 函数作用于 $\hat{s}_i$ ，被预测为激活点集。随后，本文遵循 IMOP (Zhang 和 Boularias 2024) 中的流程，在 $\mathcal{I}(\hat{s}_i)$ 的 K 近邻图与实时状态 s_j 之间应用图交叉注意力层，以提取逐点特征 $h_{\mathcal{I}}(\hat{s}_i) \in \mathbb{R}^{|\mathcal{I}(\hat{s}_i)| \times D}$ 和 $h_{s_j} \in \mathbb{R}^{|s_j| \times D}$ ，其中 D 表示特征维度的大小。最后，本文在 $h_{\mathcal{I}(\hat{s}_i)}$ 和 h_{s_j} 之间执行双重 Softmax 匹配 (Li 和 Harada 2022)，以获得对应矩阵 $\mathbf{C} \in \{0, 1\}^{|\mathcal{I}(\hat{s}_i)| \times |s_j|}$ ： $\mathbf{C} = \text{softmax}(h_{\mathcal{I}}(\hat{s}_i) \cdot h_{s_j}^\top) \cdot \text{softmax}(h_{s_j} \cdot h_{\mathcal{I}}^\top(\hat{s}_i))^\top$ ，其中 Softmax 应用于每一行。对应矩阵 $\mathbf{C}$ 将不变区域 $\mathcal{I}(\hat{s}_i)$ 中的每个点映射到实时状态 s_j 。 s_j 中的匹配点构成 $\mathcal{I}(s_j)$ 。

基于对应关系的位姿回归。如主论文第 3 节所述，我们直接采用基于对应关系的位姿回归算法 (Zhang and Boularias 2024) 来估计机器人在实时状态 s_j 下的动作位姿 $\mathbf{T}_j$ 。该算法的核心目标是求解一个优化问题，最小化参考位姿 $\mathbf{T}_i$ 与目标位姿 $\mathbf{T}_j$ 之间的变换，从而推断机器人在 s_j 中的位姿。优化目标定义为： $\mathbf{T}_j = \arg \min_{\mathbf{T} \in \text{SE}(3)} \|\mathbf{T}\mathbf{T}_i^{-1}P_{\mathcal{I}(\hat{s}_i)}\mathbf{C} - P_{s_j}\|$ ，其中 $\mathbf{T}_i$ 是状态 s_i 下的演示动作位姿，表示机器人的具体构型 (包括旋转和平移)。 $P_{\mathcal{I}(\hat{s}_i)}$ 和 P_{s_j} 分别表示状态 $\hat{s}_i$ 中不变区域的点云 (即局部环境中保持静态的部分) 和状态 s_j 中的完整场景点云。在该优化问题中， $\mathbf{T}$ 是待求解的变换矩阵，属于特殊欧氏群 $\text{SE}(3)$ ，表示包含三维空间中旋转和平移的变换。通过求解 $\mathbf{T}$ ，目标是使变换后的点云 $\mathbf{T}\mathbf{T}_i^{-1}P_{\mathcal{I}(\hat{s}_i)}$ 与目标场景 P_{s_j} 之间的差异最小化。具体而言， $P_{\mathcal{I}(\hat{s}_i)}$ 是由状态 $\hat{s}_i$ 中不变区域定义的一组三维点，表示固定物体或表面的空间分布，而 P_{s_j} 是状态 s_j 下的完整场景点云。矩阵 $\mathbf{C}$ 是对应关系矩阵，编码了 $P_{\mathcal{I}(\hat{s}_i)}$ 中每个点与 P_{s_j} 之间的最佳匹配关系。目标函数中的范数 $\|\cdot\|$ 计算变换后点云与目标点云之间的欧氏距离。通过选择合适的变换矩阵 $\mathbf{T}$ ，我们旨在使变换后的源点尽可能与目标场景对齐，从而确定与目标构型一致的位姿。从物理角度看，该过程可解释为利用不变区域的几何特性，通过调整来自状态 $\hat{s}_i$ 的先前位姿 $\mathbf{T}_i$ 来估计机器人在状态 s_j 下的新位姿 $\mathbf{T}_j$ 。通过利用先前的运动模式和当前的环境约束，

1 符号约定与正文一致，其中 $\hat{s}_i$ 和 $\hat{a}_i$ 表示测试任务中的状态和动作， $\mathbf{T}_i$ 表示动作位姿变换。

机器人能够准确预测新的动作姿态。最优姿态 $\mathbf{T}_j$ 对应于上述目标函数的解，此时在应用变换后， $\mathbf{C}$ 中的点对关系产生最小的整体成对距离。因此，姿态回归问题可以通过学习 $\mathbf{T}_j \mathbf{T}_i^{-1}$ 与该目标函数对齐的视觉特征来解决。遵循 IMOP 中的计算方法，我们采用 Leopard (Li 和 Harada 2022) 的可微 **Procrustes** 算子来求解最小二乘问题。




图 7：状态路由网络的架构，取自 IMOP。




图 8：ManiLong-Shot 的评估流程。

A.2. 更多架构细节

我们主要参考 Zhang 和 Boularias (2024) 提出的状态路由网络，该网络用于根据当前真实状态 s_j 从单个成功演示轨迹 τ^{lh} 中选择演示帧 $\hat{s}_i$ 。与 Zhang 等人提出的网络不同，我们首先使用 PTv3 骨干网络 (IMOP 中使用 PTv2) 为真实状态 s_j 和演示轨迹中的每个状态 τ^{lh} 提取场景级特征。然后，我们将场景级特征与低维内部机器人状态（包括关节位置和时间步）拼接。接下来，我们对多个状态的特征应用交叉注意力。对真实状态 s_j 注意力最强的状态被选为演示状态 $\hat{s}_i$ 。具体状态路由网络架构如图 7 所示。

A.3. 更多训练细节

ManiLong-Shot 的训练流程遵循 IMOP (Zhang 和 Boularias 2024) 的方法，假设在训练期间可以获取实例分割结果。我们利用 RLBench (James 等人 2020) 提供的分割掩码，但值得注意的是，ManiLong-Shot 在推理阶段不需要分割信息。与 IMOP 不同，IMOP 通过使用 C2F-ARM (James 等人 2022) 的关键帧提取方法压缩每个状态来生成宏步骤，而 ManiLong-Shot 采用了一种不同的时间抽象方法。具体来说，对于每个分解的交互阶段，它每 5 帧采样一帧（包括起始帧和结束帧）来定义宏步骤。如果最终帧与上一个宏步骤之间的间隔小于 5 帧，则放宽此约束，并将最终帧直接作为独立的宏步骤包含在内。在每次训练迭代中，采样一对轨迹 τ_i 和 τ_j ，使得 $|\tau_i^{sh}| = |\tau_j^{sh}|$ 。状态路由网络使用焦点损失 (Lin 等人 2017) 进行训练，以预测当 $\bar{s}_i \equiv \bar{s}_j$ (i.e., $\bar{s}_i$ 和 $\bar{s}_j$ 出现在同一时间步时它们共享相同的操作动作。为了训练交互感知的不变区域匹配网络，令 $\{c_{i,n}\}_{n=1}^N$ 表示 $\bar{s}_i$ 中的 N 个实例分割，其中每个 $c_{i,n}$ 是对应于一个对象实例的一组 3D 点。我们按如下方式估计真实匹配区域 $\mathcal{I}(\bar{s}_i)$ ：

$$\mathcal{I}(\bar{s}_i) = \arg \min_{c_{i,n}} \mathbb{E}_{p \in c_{i,n}} \left[\min_{\substack{q \in c_{j,m} \\ \text{cls}(c_{i,n}) = \text{cls}(c_{j,m})}} \|T_i^{-1}p - T_j^{-1}q\| \right], \quad (2)$$

其中 $\text{cls}(c_{i,n})$ 表示分割 $c_{i,n}$ 的对象类别。真实值 $\mathcal{I}(\bar{s}_i)$ 对应于 $\bar{s}_i$ 中在动作姿态 T 的坐标系下位移最小的实例分割。 $\bar{s}_i$ 和 $\bar{s}_j$ 之间的点对对应关系定义为集合：

$$\left\{ (p, q) \in \mathcal{I}(\bar{s}_i) \times \mathcal{I}(\bar{s}_j) \mid q = \arg \min_{q \in \mathcal{I}(\bar{s}_j)} \|T_i^{-1}p - T_j^{-1}q\| \right\}, \quad (3)$$

其中逐点位移在动作姿态坐标系下最小化。

B. ManiLong-Shot 的进一步评估细节

ManiLong-Shot 针对未见过的长程操作任务的评估流程如图 8 所示。在评估期间，ManiLong-Shot 以任务的一次成功演示作为输入，并遵循结构化流程在新场景上执行整个操作序列。该过程从交互感知任务分解模块开始，该模块分析演示轨迹并将其分割为一系列交互感知原语。每个原语代表一个机器人-物体物理上有意义的交互阶段，即接触前、抓取和接触后。这种分割由机器人状态的变化引导，使系统能够

10 个短视界任务——用于训练




图 9：RLBench-Oneshot 中 10 个短视界操作任务的可视化。

对时间局部化行为进行推理。对于每个分割出的交互阶段，交互感知区域预测网络预测环境中对该阶段执行至关重要的不变区域。这些不变区域被定义为场景中对实现相应子目标至关重要的空间区域，并预期在不同任务实例间保持一致。该预测同时利用环境的点云表示和机器人内部状态信息，如关节配置和时间戳。一旦任务被分解且不变区域被预测出来，框架便进入执行阶段。在此阶段，ManiLong-Shot 持续接收来自机器人的实时观测，如 RGB-D 图像和本体感觉输入。在每个时间步，它采用交互感知区域匹配网络来识别哪个预测的不变区域与当前观测最匹配。这是通过计算预测区域与观测场景之间的对应矩阵来实现的，从而有效地将演示与当前任务实例对齐。基于匹配结果，框架通过估计将演示姿态映射到当前上下文的最优变换来执行姿态预测。该姿态随后被运动规划模块用于为机器人生成可执行动作。执行以闭环方式进行：在执行每个运动基元后，系统更新其观测输入，重新评估与预测不变区域的匹配，并根据状态路由网络确定下一个基元。此循环持续迭代，直到机器人完成整个任务。得益于其模块化设计和对以交互为中心线索的依赖，ManiLong-Shot 能够仅从一次成功演示中稳健地适应新颖的任务布局、物体配置和环境条件。

C. 附加实验细节

C.1. RLBench-Oneshot 的细节

短视界任务。我们首先介绍 RLBench-Oneshot 中的 10 个短视界操作任务，如图所示

如图 9 所示。

(1) 关闭罐子 任务：将盖子盖在罐子上以密封罐子。

对象：1 个积木和 2 个彩色罐子。

成功度量：罐盖已成功放置在罐子上，由接近传感器检测确认。物理交互次数（接触前、抓取、接触后）：3

(2) 打开抽屉 任务：通过抓取把手并拉开抽屉来打开抽屉。对象：1 个抽屉。

成功度量：抽屉已成功打开至所需位置，由抽屉关节的关节条件检测确认。物理交互次数（接触前、抓取、接触后）：3

(3) 安装灯泡 任务：从灯座中取出灯泡并将其旋入灯具中。

对象：2 个灯泡、2 个灯座和 1 个灯架。

成功度量：灯泡已成功旋入灯具，由接近传感器检测确认。物理交互次数（接触前、抓取、接触后）：3

(4) 将肉从烤架上取下 任务：将指定的肉从烤架上取下，并放置在烤架旁边。

对象：1 块鸡肉、1 块牛排和 1 个烤架。

成功度量：指定的肉成功从烤架上取下，并由接近传感器检测到。物理交互次数（接触前、抓取、接触后）：3

(5) 插入方形环到方形柱上 任务：将方形环插入指定颜色的柱子上。

对象：1 个方形环和 1 个带有三根彩色柱子的柱台。

成功度量：方形环成功放置在正确颜色的柱子上。物理交互次数（接触前、抓取、接触后）：3

(6) 转动水龙头 任务：转动水龙头的左把手或右把手。左右方向是相对于水龙头朝向定义的。

对象：1 个带 2 个把手的水龙头。

成功度量：指定把手的旋转关节从起始位置至少转动 90° 。物理交互次数（接触前、抓取、接触后）：3

(7) 将杂货放入橱柜 任务：抓取指定物体并将其放入上方的橱柜中。

场景中始终包含 9 个随机放置在桌面上的 YCB 物体。

对象：9 个 YCB 物体，以及 1 个橱柜（像魔法一样悬浮在空中）。

成功度量：指定物体位于橱柜内。物理交互次数（接触前、抓取、接触后）：3

(8) 将形状放入形状分类器 任务：拾取指定形状并将其放入分类器中正确的孔内。场景中始终有 4 个干扰形状和 1 个正确形状。

对象：5 个形状和 1 个分类器。

成功度量：方形环成功放置在正确颜色的柱子上。物理交互次数（接触前、抓取、接触后）：3

(9) 将钱放入保险箱 任务：拾取一叠钱并将其放入指定搁板上的保险箱内。搁板有三个放置位置：顶部、中部、底部。

对象：1 叠钱和 1 个保险箱。

成功度量：方形环成功放置在正确颜色的柱子上。物理交互次数（接触前、抓取、接触后）：3

(10) 放置酒瓶 任务：拿起酒瓶，将其放在木架上三个指定位置之一：左侧、中间、右侧。这些位置是相对于木架的朝向来定义的。

对象：1 个酒瓶和 1 个木架。

成功度量：方形环成功放置在正确颜色的柱子上。物理交互次数（接触前、抓取、接触后）：3

长周期任务。接下来，我们详细介绍 RLBench-Oneshot 中的 20 个长时程操作任务，如图

图 10. (1) 空容器

任务：从大型中央容器中移除所有程序化生成的物体，并将它们放入指定颜色的小型目标容器中。

对象：1 个大容器，2 个小容器，2 个程序化物体。

成功度量：所有程序性物体均由接近传感器在正确的小容器内检测到。物理交互次数（接触前、抓取、接触后）：6

(2) 清空洗碗机 任务：打开洗碗机，拉出碗篮，从内部取出盘子。

对象：1 台洗碗机，1 个洗碗机用盘子。

成功度量：接近传感器不再检测到洗碗机内的盘子（即盘子已被取出




图 10: RLBench-Oneshot 中 20 个长程操作任务的可视化。

从洗碗机中取出）。物理交互次数（接触前、抓取、接触后）：6

(3) 取下烤箱托盘 任务：打开烤箱，抓住托盘，将其从烤箱中取出。

对象：1 个托盘，1 个烤箱。

成功度量：接近传感器不再检测到烤箱内的托盘，且机器人夹爪未抓取任何物体。物理交互次数（接触前、抓取、接触后）：6

(4) 放入烤箱 任务：打开烤箱门，拿起托盘，并将其放入烤箱内。

对象：1 个托盘，1 个烤箱。

成功度量：接近传感器检测到烤箱内的托盘，且机器人夹爪为空。物理交互次数（接触前、抓取、接触后）：6

(5) 瓶子放入冰箱 任务：打开冰箱门，拿起瓶子，并将其放入冰箱内。

对象：1 个瓶子，1 个冰箱。

成功度量：接近传感器检测到瓶子已成功放入冰箱，且机器人夹爪为空。物理交互次数（接触前、抓取、接触后）：6

(6) 叠放杯子 任务：根据指定杯子的颜色，将另外两个杯子叠放在其上方。

物体：3 个杯子。

成功度量：检测到指定杯子位于叠放中，且机器人夹爪为空。物理交互次数（接触前、抓取、接触后）：6

(7) 叠放杯子与积木 任务：将另外两个与特定积木颜色相同的杯子叠放在剩余杯子上方。物体：3 个杯子。

成功度量：检测到指定杯子位于叠放中，且机器人夹爪为空。物理交互次数（接触前、抓取、接触后）：6

(8) 放置 2 个杯子 任务：将两个杯子通过将其手柄滑到辐条上，放置在杯架上。

对象：3 个杯子，杯架上有 3 根辐条。

成功度量：两个杯子被成功放置在杯架上，并由接近传感器检测到，且机器人夹爪为空。物理交互次数（接触前、抓取、接触后）：6。

(9) 移除两个杯子 任务：从杯架上移除两个杯子，并将它们放在桌子上。

对象：3 个杯子，1 个杯架。

成功度量：指定数量的杯子被成功从杯架上移除，并由接近传感器检测到，且机器人夹爪为空。物理交互次数（接触前、抓取、接触后）：6

(10) 拉直绳索 任务：拉直绳子，拉动两端直至绷紧。

对象：1 根绳子（具有可识别的头部和尾部）。

成功度量：通过头部和尾部的接近传感器检测到绳子两端被拉直，表明绳子在桌面上绷紧。物理交互次数（接触前、抓取、接触后）：6

(11) 滑开柜门并放置杯子 任务：打开柜门，将杯子放入其中。

对象：1 个杯子，带两侧（左侧和右侧）的柜子。

成功度量：杯子成功放入柜内，由接近传感器检测到，且机器人夹爪为空。物理交互次数（接触前、抓取、接触后）：6

(12) 将物品放入抽屉 任务：将物品放入指定的抽屉之一。

对象：1 个物品，3 个抽屉（底部、中部、顶部）。

成功度量：物品被成功放入指定抽屉，由接近传感器检测到，且机器人夹爪为空。

物理交互次数（接触前、抓取、接触后）：6

(13) 从抽屉中取出物品 任务：从指定的抽屉之一取出物品。

对象：1 个物品，3 个抽屉（底部、中部、顶部）。

成功度量：物品被成功从指定抽屉取出，由接近传感器检测到，且机器人夹爪为空。物理交互次数（接触前、抓取、接触后）：6

(14) 将 3 本书放到书架上 任务：将 3 本书放到书架上。物体：3 本书。

成功度量：指定数量的书已成功放置在书架上，并由接近传感器检测到，且机器人夹爪为空。物理交互次数（接触前、抓取、接触后）：9

(15) 将鞋子放入盒子 任务：将鞋子放入盒子内。

对象：2 只鞋，1 个盒子。

成功度量：两只鞋均已成功放入盒子内，由接近传感器检测到，且机器人夹爪为空。物理交互次数（接触前、抓取、接触后）：9

(16) 将鞋子从盒子中取出 任务：从盒子中取出鞋子并放在桌子上。

对象：2 只鞋，1 个盒子。

成功度量：两只鞋均被成功从盒中取出并放置于桌面上，由接近传感器检测确认，且机器人夹爪为空。物理交互次数（接触前、抓取、接触后）：9

(17) 布置国际象棋 任务：将 3 枚棋子按初始位置摆放在棋盘上。

对象：多枚棋子（王、后、象、马、车、兵）及一个棋盘。

成功度量：指定数量的棋子被成功放置于棋盘上的初始位置，由接近传感器检测确认，且机器人夹爪为空。物理交互次数（接触前、抓取、接触后）：9

(18) 摆放餐具 任务：将餐具摆放在餐桌上，为用餐做准备。

对象：1 个盘子、1 把叉子、1 把刀、1 把勺子、1 个玻璃杯。

成功度量：盘子、叉子、刀、勺子和玻璃杯已成功放置在桌面上，由接近传感器检测到，且机器人夹爪为空。物理交互次数（接触前、抓取、

接触后) : 12

(19) 堆叠块 任务：将 4 个积木依次叠放在一起。

对象：最多 4 个目标块和 4 个干扰块。

成功度量：指定数量的目标积木被成功堆叠，由接近传感器检测到，且机器人夹爪为空。物理交互次数（接触前、抓取、接触后）：12

(20) 块金字塔 任务：堆叠积木以形成金字塔。

对象：6 个目标块和 6 个干扰块。

成功度量：三个目标块成功堆叠成金字塔形状，由接近传感器检测到，且机器人夹爪为空。物理交互次数（接触前、抓取、接触后）：12

C.2. 实验设置的更多细节

对于所有仿真实验，我们使用单块 NVIDIA GeForce RTX 4090 GPU (24GB 显存) 进行训练和测试。实验框架基于开源 IMOP 代码库 (<https://github.com/mlzxy/imop/tree/main>)，所有网络配置和超参数均遵循 IMOP 中的设置。数据集构建源自 RL-Bench 的任务代码，位于 <https://github.com/stepjam/RLBench/tree/master/rlbench/tasks>。

**D. 基于 VLM 任务的提示模板
Decomposition**

任务目标：请审查按时间顺序排列的数据序列，并识别其中的关键阶段或子任务。任务应分割为以下重复阶段：‘接触前’、‘抓取’、‘接触后’。继续识别并分割该序列中的阶段（接触前→grasping→post-contact→pre-contact→grasping→postcontact...）直到整个任务完成。

输入格式说明：您将收到一个包含多个时间步长的数据序列。每个时间步长将包含以下字段（可根据实际任务省略或替换）：

```
1  [
2    {
3      "t": 0,
4      "obs": "observation at timestep
5          0",
6      "action": "action taken at
7          timestep 0",
8      "event": "optional event log",
9      "sensor": {"gripper_state": ...,
10                "joint_velocity": ..., ...}
11    },
12    ...
13  ]
```

输出格式要求：请以 JSON 格式返回识别出的阶段。每个阶段应包含以下字段：

```
1  [
2    {
3      "stage": "name of the stage (e.g
4          ., pre-contact, grasping,
5          post-contact)",
6      "start": start_timestep,
7      "end": end_timestep,
8      "reason": "brief reason for
9          identifying this segment"
10    },
11    ...
12  ]
```

Please ensure:

- 所有阶段连续且不重叠。
- 每个阶段边界根据输入数据确定（例如，夹爪状态、关节速度、动作意图或状态转换的变化）。
- 阶段序列必须按以下顺序重复，直到整个任务完成：‘预接触 → 抓取 → post-contact → pre-contact → grasping → 后接触……’

可选任务说明（根据需要选择）：

- [任务类型 A]：物理交互阶段识别 根据物体接触、抓取、放置等信号分割物理交互阶段。
- [任务类型 B]：语言指令任务阶段分析

根据机器人按照语言指令执行的动作（例如，“打开抽屉并放置杯子”）分割子任务序列。• [任务类型 C]: 异常检测与阶段重标记 检测任何失败或中断的阶段，并相应地重新标记任务阶段。• [任务类型 D]: 多模态协同理解 基于图像 + 动作/传感器数据识别结构化语义阶段，以了解任务进度。

Example Output (for reference):

```
1  [
2    {
3      "stage": "pre-contact",
4      "start": 0,
5      "end": 14,
6      "reason": "The end-effector
                  朝目标物体移动，同时夹爪保持完全张
                  开。尽管运动过程中关节速度可能暂时降
                  为零，但夹爪姿态保持不变，并不表示准
                  备动作

                  for grasping. The phase ends
                  when the robot completes
                  positioning near the object
                  and the joint velocity
                  converges to zero, marking a
                  transition to a static pre-
                  grasp state."
7    },
8    {
9      "stage": "grasping",
10     "start": 15,
11     "end": 17,
12     "reason": "The gripper begins to
                  close, and a noticeable
                  change in joint velocity
                  suggests initiation of a
                  grasping action."
13   },
14   {
15     "stage": "post-contact",
16     "start": 18,
17     "end": 40,
18     "reason": "The object has been
                  grasped and is being moved
                  toward the target location."
19   },
20   {
21     "stage": "pre-contact",
22     "start": 41,
23     "end": 45,
24     "reason": "The robot moves the
                  抓取物体朝向下一个任务位置移动，夹
                  爪仍保持原位，维持一致的关节速度。"
```

```
25   },
26   {
27     "stage": "grasping",
28     "start": 46,
29     "end": 48,
30     "reason": "The gripper adjusts
                  to secure the object more
                  firmly as the robot
                  approaches the final target."
31   },
32   {
33     "stage": "post-contact",
34     "start": 49,
35     "end": 60,
36     "reason": "The object is now
                  placed at the target location
                  and the gripper releases it.
                  "
37   }
38 ]
```