

Motus: 一个统一的潜在动作世界模型

Hongzhe Bi ^{1*†}, Hengkai Tan ^{1*†}, Shenghao Xie ^{2,1*}, Zeyuan Wang ^{1*}, Shuhe Huang ^{1*}, Haitian Liu ^{1*}, Ruowen Zhao ¹, Yao Feng ¹, Chendong Xiang ¹, Yinze Rong ¹, Hongyan Zhao ¹, Hanyu Liu ², Zhizhong Su ³, Lei Ma ², Hang Su ¹, Jun Zhu ¹ 清华大学计算机科学与技术系, 人工智能研究院, 北京信息科学与技术国家研究中心, 清华-博世机器学习联合研究中心, 清华大学 ² 北京大学 ³ 地平线机器人 ^{*} 共同第一作者 [†] 共同项目负责人 {bhz24, thj23}@mails.tsinghua.edu.cn, dcszj@tsinghua.edu.cn

Project Page: <https://motus-robotics.github.io/motus>

摘要

尽管通用具身智能体必须作为一个统一系统运行, 但当前方法建立在相互孤立的模型之上, 分别用于理解、世界建模和控制。这种碎片化阻碍了多模态生成能力的统一, 也妨碍了从大规模异构数据中学习。本文提出 Motus, 一个统一的潜在动作世界模型, 利用现有通用预训练模型和丰富的可共享运动信息。Motus 引入混合变换器 (Mixture-of-Transformer, MoT) 架构, 集成三个专家 (即理解、视频生成和动作), 并采用 UniDiffuser 风格的调度器, 实现不同建模模式 (即世界模型、视觉-语言-动作模型、逆动力学模型、视频生成模型和视频-动作联合预测模型) 之间的灵活切换。Motus 进一步利用光流学习潜在动作, 并采用三阶段训练流程和六层数据金字塔的方案, 从而提取像素级“增量动作”并实现大规模动作预训练。实验表明, Motus 在仿真 (相较于 X-VLA 提升 α +15%, 相较于 $\pi_{0.5}$ 提升 α +45%) 和真实场景 (提升 +11 ~ 48%) 中均优于最先进方法, 证明所有功能和先验的统一建模显著有利于下游机器人任务。

1. 引言

统一模型对于具身智能体至关重要, 它能够将一系列认知功能——从理解场景和指令、想象可能的未来, 到

预测后果并生成动作——整合为一个统一的整体。然而, 现有方法孤立地建模这些能力: 一些依赖视觉-语言-动作模型 (VLA) [5, 8, 11, 26, 31, 36, 60, 65] 从视觉和语言中学习静态策略; 另一些使用基于预测

未来的世界模型或生成方法 [4, 7, 19, 21, 25, 28, 39, 41, 53, 56, 62]; 以及 $\mathcal{F}_1$ [32] 将视觉语言动作模型 (VLA) 与逆动力学模型 (IDM) 相结合, 通过显式想象未来视觉观测, 但未纳入世界模型或视频生成模型 (VGM), 导致统一不完整。这些方法将本应统一的系统割裂为 5 个独立的建模任务:

- VLA: $p(\mathbf{a}_{t+1:t+k} \mid \mathbf{o}_t, \ell)$.
- WM: $p(\mathbf{o}_{t+1:t+k} \mid \mathbf{o}_t, \mathbf{a}_{t+1:t+k})$.
- IDM: $p(\mathbf{a}_{t+1:t+k} \mid \mathbf{o}_{t:t+k})$.
- VGM: $p(\mathbf{o}_{t+1:t+k} \mid \mathbf{o}_t, \ell)$.
- 视频-动作联合预测模型:

$$p(\mathbf{o}_{t+1:t+k}, \mathbf{a}_{t+1:t+k} \mid \mathbf{o}_t, \ell).$$

两个根本性挑战 (详见第 3 节) 阻碍了这些能力的整合。首先, 在单一框架内统一此类多模态生成能力并非易事。尽管统一世界模型 (UWM) [64] 提供了理论原型, 但它们通常从零开始训练或仅使用有限先验, 缺乏来自视觉语言模型 (VLM) 的鲁棒视觉语言理解或来自视频生成模型 (VGM) 的丰富物理交互知识。其次, 具身智能要求能够从大规模异构数据中学习——包括互联网视频、以自我为中心的人类演示和多机器人轨迹——但不同具身之间的动作空间差异很大, 且大多数视频数据缺乏动作标签, 这使得用通用运动和交互先验预训练动作专家变得困难。为应对这些挑战, 本文提出 Motus, 一个统一的




图 1. Motus 架构。此处， $a_t \dots a_{t+k}$ 为动作， $z_t \dots z_{t+k}$ 为潜在动作， τ_v 和 τ_a 分别为视频生成模型和动作专家的修正流时间步。

潜在动作世界模型，在变换器混合（MoT）架构中集成预训练专家。本文方法通过共享多头自注意力层连接视频生成器（生成专家）、动作专家和视觉语言理解专家，统一了 5 个关键分布——这一设计称为三模型

联合注意力 ——在保留专业化功能的同时实现跨模态知识融合。为进一步协调多模态生成，Motus 采用类似 UniDiffuser 的调度器，为每种模态（如视频和动作）分配不同的时间步和噪声尺度。这为同时建模边缘分布、条件分布和联合分布以及在不同推理模式（如 VLA、WM、IDM、VGM、视频-动作联合预测模型）之间自适应切换提供了统一方式。

此外，为大规模利用异构数据，本文引入潜在动作，将光流中的运动模式编码为像素级“增量动作”。该表示将视觉动态与控制信号相连接，使动作专家能够在多样化的无标签视频和机器人轨迹上进行预训练。具体而言，采用预训练的深度压缩自编码器（DC-AE）并附加轻量级下采样模块来重建光流，

其编码的低维潜在变量则通过少量任务相关和任务无关的动作标签进行监督，从而将关注点引导至与机器人活动相关的模式。随后，Motus 在六层数据金字塔上执行三阶段预训练-微调流程（即视频预训练、潜在动作预训练和具体实施例动作微调），该金字塔涵盖网络规模数据、以自我为中心的人类数据、仿真数据、任务无关数据、多机器人数据和目标机器人数据。该方案在光流描述的运动空间内对齐不同实施例之间的行为，并将此类交互知识与目标实施例共享，以增强下游任务中的泛化能力，从而为动作专家提供与其他专家类似的预训练。总体而言，本文贡献可总结如下：• 提出统一的具身基础模型，融合五种主流范式（即世界模型、图像扩散模型、视觉-语言-动作模型、视频生成模型和视频-动作联合预测模型），且不损害通用多模态先验。• 提出可扩展的机器人训练方案，采用三阶段训练流程和六层数据金字塔，利用基于光流的潜在动作学习跨实施例

可迁移的运动知识。大量实验表明，Motus 在仿真和现实场景中均显著优于最先进的方法（a +15% 相较于 X-VLA 的提升 [60] 以及 +45% 相较于 $\pi_{0.5}$ [8]）和现实场景（提升 +11~48%），证明大规模通用先验与领域特定先验能够有效融合，从而增强策略学习的泛化能力。

2. 相关工作

2.1. 统一多模态模型

统一多模态模型在单一生成框架内联合建模各种模态和任务 [29, 40, 45, 47, 49, 52]，在多个领域展现出广泛的应用 [35, 54, 63]。特别是，Bagel[18] 通过专家混合 (MoT) [30] 实现统一，在理解专家和生成专家之间共享多头自注意力层。相比之下，现有的具身基础模型是独立开发的，衍生出多种不同的范式：一些利用视觉语言模型 (VLM) 的文本-图像理解能力来学习动作预测 [6, 8, 27]，而另一些则利用视频生成模型 (VGM) 生成视频序列并从连续帧中推断动作 [19, 21, 62]。最近， $\mathcal{F}_1$ [32] 将视觉-语言-动作模型 (VLA) 扩展为通过逆动力学模型 (IDM) 显式想象未来视觉状态并输出动作，从而合并了这两种模型。此外，统一世界模型 (UWM) [64] 在单一扩散骨干内统一了世界模型 (WM)、VLA、IDM、VGM 和视频-动作联合预测模型，对完整机器人模型进行了初步探索。与 UWM 不同，我们的方法超越了统一建模，进一步融合了互联网规模的通用多模态先验和来自海量机器人轨迹的专用先验。

2.2. 潜在动作模型

潜在动作通过捕捉视觉动态来缓解动作标签的稀缺性，通常通过将逆动力学模型 (IDM) 与前向动力学模型 (FDM) 耦合来推导，以基于前一帧重建下一帧 [9, 10, 20, 37]。最初，使用 RGB 图像进行监督，但这引入了与任务无关的外观信息 [58]。为了消除这种干扰，一种常见的方法是限制自编码器的容量以编码低维潜在变量 [15, 38, 55]，从而减少冗余的包含。AdaWorld[22] 尝试解耦表示，例如 β -变分自编码器 (VAE) [23]，以仅保留有用的因素。其他方法探索替代的重建目标，例如 DINOv2 特征 [11, 15, 50]、对象关键点 [17, 51, 57] 和语言指令 [16]，这些目标携带丰富的语义和空间特征。此外，潜在动作观测模型 (LAOM) [34] 使用少量动作标签来鼓励模型关注机器人活动。在这些进展的基础上，并受光流作为通用运动

表达 [12, 46, 61] 的启发，我们使用它来对齐跨具身行为并学习潜在动作，以促进大规模预训练。

3. 问题表述与挑战

具身策略 本文考虑语言条件机器人操作任务。对于每种机器人形态，任务定义动作 $a \in \mathcal{A}$ 、观测 $o \in \mathcal{O}$ （视觉输入）、语言指令 $\ell \in \mathcal{L}$ 以及机器人本体感知 p ，其中 $\mathcal{A}$ 、 $\mathcal{O}$ 和 $\mathcal{L}$ 分别表示动作空间、观测空间和语言指令空间。任务通常提供专家数据集

$D_{\text{expert}} = \{ \{ \ell, p_1, o_1, a_1, \dots, p_N, o_N, a_N \} \}$ ，其中包含专家在 N 个时间步内采集的机器人本体感知、视觉观测和动作，以及每条轨迹对应的语言标注。本文在 D_{expert} 上训练由 θ 参数化的策略。在每个时间步 t ，策略基于当前观测和本体感知预测接下来 k 个动作（动作分块 [59]），建模分布 $p_{\theta}(a_{t+1:t+k} | o_t, p_t, \ell)$ 或 $p_{\theta}(a_{t+1:t+k} | o_t, \ell)$ 。策略 p_{θ} 通过最大化似然目标进行训练：

$$\max_{\theta} \mathbb{E}_{(o_t, p_t, a_{t+1:t+k}, \ell) \sim D_{\text{expert}}} \log p_{\theta}(a_{t+1:t+k} | o_t, p_t, \ell). \quad (1)$$

此外，基于上述符号定义，可以推导出 5 种具身智能建模类型的概率分布，并将其整合到单一模型中进行训练：

- VLA: $p(a_{t+1:t+k} | o_t, \ell)$.
- WM: $p(o_{t+1:t+k} | o_t, a_{t+1:t+k})$.
- IDM: $p(a_{t+1:t+k} | o_{t:t+k})$.
- VGM: $p(o_{t+1:t+k} | o_t, \ell)$.
- 视频-动作联合预测模型：
 $p(o_{t+1:t+k}, a_{t+1:t+k} | o_t, \ell)$.

挑战一：统一多模态生成能力。一个具备能力的具身智能体必须整合一系列认知功能——从理解场景与指令、想象可能的未来，到预测后果并生成动作——从而以统一整体的形式具备类人能力。然而，现有模型是碎片化的，无法在单一系统内捕获全部必要能力。这提出了一个挑战：如何在一个框架内统一建模五种关键分布——视觉-语言-动作模型、世界模型、图像扩散模型、视频生成模型以及视频-动作联合预测模型。尽管先前工作（例如统一世界模型 [64]）已取得一定进展，但一个关键局限性依然存在：这些方法要么从零开始训练，要么基于较小的基础模型构建，或者——即便引入了一些先验知识——也始终缺乏完整的知识谱系，要么缺少来自视觉-语言模型的视觉理解先验，要么缺少物理交互先验。

来自视频生成模型（VGMs）。因此，它们缺乏鲁棒且可泛化的具身智能所需的全面世界知识。因此，在统一框架内联合建模视觉、语言和动作的各种分布这一不平凡挑战仍未解决，而这正是本文工作所填补的空白。

挑战二：异构数据的利用。具身智能的核心挑战在于如何有效利用大规模异构数据。不同具身形态之间的动作空间在维度、范围和语义上差异显著，机器人在形态结构、驱动方式和感知能力上也各不相同。因此，控制信号无法直接复用，策略难以学习到可跨具身形态迁移的通用先验。现有方法，包括 [8, 31, 43, 60]，试图通过使用通用骨干网络并注入具身特定信息，或构建高维动作向量来强行统一不同具身形态。然而，这些方法仍主要依赖带标注的机器人轨迹，无法将这些数据集与大规模互联网视频或以自我为中心的人类视频相结合，后者缺乏动作标注但包含丰富的运动和物理交互线索。这一局限性阻碍了动作专家的大规模预训练，并削弱了学习通用运动先验的能力。

4. 方法论

4.1. Motus

模型架构。为解决第 3 节中概述的统一多模态生成能力所面临的挑战，本文提出 Motus，一种统一的潜在动作世界模型。首先，Motus 被设计为一种通用生成模型，能够在异构多模态数据上进行联合学习，从而在单一网络内整合通用系统的多种能力（例如，建模 5 种分布）。其次，为避免需要不切实际的大量对齐多模态数据，Motus 利用现有基础模型丰富的预训练先验。它在一个变换器混合（Mixture-of-Transformers, MoT）架构中集成了预训练的视觉生成模型（生成专家）、带有预训练视觉语言模型的理解专家以及动作专家（如图 1 所示），有效融合了它们的互补优势——涵盖场景理解、指令解释、后果预测、未来视频想象和动作规划——而无需从头进行完整的端到端训练。与统一世界模型（Unified World Models, UWMs）[64] 不同，后者简单地将观测标记和动作标记拼接起来，并通过一系列 N UWM 块（包含自注意力和前馈网络层）进行处理，本文方法通过采用 MoT 结构来利用预训练的视觉语言模型和视觉生成模型。在本文模型中，每个专家都维护一个独立的变换器模块，同时

多头自注意力层被拼接，即三模态联合注意力（Tri-model Joint Attention）。这不仅保留了各专家之间不同的功能角色而不引起任务干扰，还实现了有效的跨模态特征融合，促使多样化的预训练知识相互补充。在训练过程中，Motus 使用基于修正流的联合目标来预测视频块和动作块：

$$l_{\text{action}}^{\theta} = \mathbb{E}_{(\mathbf{o}_{t:t+k}, \mathbf{a}_{t+1:t+k}, \ell) \sim \mathcal{D}} \left\| v_a^{\theta} - (\epsilon_a - \mathbf{a}_{t+1:t+k}) \right\|_2^2, \\ \tau_a \sim \mathcal{U}(0, T_{\tau}) \\ \epsilon_a \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$$

$$l_{\text{obs}}^{\theta} = \mathbb{E}_{(\mathbf{o}_{t:t+k}, \mathbf{a}_{t+1:t+k}, \ell) \sim \mathcal{D}} \left\| v_o^{\theta} - (\epsilon_o - \mathbf{o}_{t+1:t+k}) \right\|_2^2, \\ \tau_o \sim \mathcal{U}(0, T_{\tau}) \\ \epsilon_o \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$$

$$l^{\theta} = l_{\text{action}}^{\theta} + l_{\text{obs}}^{\theta}.$$

其中 $\mathbf{o}_t$ 是条件帧， $\mathbf{o}_{t+1:t+k}$, $\mathbf{a}_{t+1:t+k}$ 是后续的观测和动作， τ_a 和 τ_o 是分配的时间步， ϵ_a, ϵ_o 是采样的高斯噪声， $v_a^{\theta}, v_o^{\theta}$ 是由我们的统一模型预测的速度场， $l_{\text{action}}^{\theta}$, l_{obs}^{θ} 是观测和动作的损失。通过为视频和动作分别分配不同的时间步和噪声尺度，Motus 建立了一个类似 UniDiffuser 的调度器，以捕获异构数据分布，并在推理过程中自适应地在各种具身基础模型（例如 VLA、世界模型、IDM、VGM、联合预测）之间切换。由此产生的模型能够理解场景、遵循指令、预测结果、想象未来并输出动作——所有这些都在一个统一的多模态架构内完成。




图 2. 动作密集-视频稀疏预测。视频帧和动作的采样率不同。

动作密集-视频稀疏预测。由于我们的模型建立在广泛引用的动作分块技术之上，Motus 需要预测未来视频和动作序列的块 $\mathbf{o}_{t+1:t+k}$, $\mathbf{a}_{t+1:t+k}$ 。这导致了几个问题：（1）训练和推理效率低，（2）冗余的视频帧预测，以及（3）三模态联合注意力机制中的不平衡——视频令牌的数量显著超过动作令牌的数量。这种不平衡导致模型过度拟合视频预测，从而削弱了其动作预测能力。为了解决这些问题，我们提出了一种动作密集-视频稀疏预测策略，如图 2 所示。在训练和

推理过程中，我们对视频帧进行下采样，使视频令牌和动作令牌的数量保持平衡——例如，将视频帧率设置为动作帧率的六分之一。

专家详情。对于生成专家，我们采用万 2.2 5B [42] 作为视频基础模型，因其易于获取和使用。我们扩展其自注意力上下文，以创建跨模态的三模型联合注意力机制。对于动作专家，我们构建了一个与万相同深度的变换器块。每个块包含用于注入修正流时间步的自适应层归一化、前馈网络以及用于跨专家交互的三模型联合注意力。我们选择千问 3-VL-2B [2, 3, 44] 作为理解专家，因其在三维定位、空间理解和精确目标定位方面具有固有优势，这些能力对机器人操作至关重要。该专家的输入取自视觉语言模型最后一层对应的标记。理解专家本身由若干变换器块组成，每个块包含层归一化、前馈网络和三模型联合注意力。

4.2. 潜在动作

我们进一步应对挑战 2，通过直接从视觉动态中学习可泛化的动作模式，以利用大规模异构数据。具体而言，我们引入潜在动作，这些动作编码了直接从像素中学习的运动。这些潜在动作使模型能够从互联网视频、以自我为中心的人类演示和多机器人轨迹等多种来源吸收运动知识，从而即使在缺乏显式动作标签的数据上也能加强动作专家的预训练。

基于光流的表示。我们采用光流作为运动的自然表示，它捕捉连续帧之间的像素级位移。具体而言，光流由 DPFlow [33] 计算，然后转换为 RGB 图像。为了将这种高维表示压缩到控制级空间，我们采用深度卷积变分自编码器（DC-AE [13]），它在重建流的同时将其编码为四个 512 维标记。然后，一个轻量级编码器将这些拼接的 4×512 特征投影到一个 14 维向量，大致匹配典型机器人动作空间的尺度。整体架构如图 3 所示。这种维度对应确保了潜在表示能够与真实机器人控制自然对齐，并充当感知与动作之间的桥梁。

训练与分布对齐。

为使潜空间与真实动作空间对齐，本文引入遵循 AnyPos [39] 的任务无关数据。具体而言，任务无关数据利用 Curobo 以任务无关的方式随机采样目标机器人动作空间，收集图像-动作对。

该数据提供额外的真实动作监督，帮助变分自编码器学习反映可行运动行为的嵌入，并将潜动作锚定到真实控制分布。训练时，本文混合 90% 无标签数据用于自监督重建，10% 有标签轨迹用于弱动作监督，其中有标签部分包含任务无关数据和标准机器人演示。维度对应与弱动作监督共同驱动潜动作分布与真实动作分布对齐，使从视频中学习的运动先验能够自然映射到可执行控制。总损失结合重建、对齐与 KL 正则化：

$$\mathcal{L} = \mathcal{L}_{\text{recon}} + \lambda_a \|a_{\text{real}} - a_{\text{pred}}\|^2 + \beta \mathcal{L}_{\text{KL}}, \quad (2)$$

其中 $\mathcal{L}_{\text{recon}}$ 最小化流重建误差，第二项对齐潜动作与真实动作， $\mathcal{L}_{\text{KL}}$ 正则化潜空间； λ_a 和 β 为超参数。




图 3. 潜动作变分自编码器。

4.3. 模型训练与数据

Motus Training.

Motus 分三个结构化阶段训练（表 1），逐步将来自多样数据集的物理交互先验整合到可迁移至目标机器人的策略中。每个阶段解决一个关键挑战：

- **阶段 1：学习视觉动力学。**为使模型锚定于真实物理交互，本文首先利用多机器人轨迹和人类视频适配视频生成模型（VGM）。这使 VGM 能够

从语言指令和初始图像生成任务的可能未来视频序列。• 第二阶段：学习动作表示。为了将视觉预测与控制相连接，我们在视频、语言和潜在动作上对整个 Motus 模型（视觉语言模型冻结）进行预训练。该阶段通过将运动和交互知识嵌入潜在动作空间来初始化动作专家。• 第三阶段：针对目标机器人进行专门化。我们通过目标机器人数据上微调模型来完成最终步骤，确保所获得的先验知识完全适应特定实体的动力学和运动学。

表 1. Motus 训练。

Stage	Data	Training
Pretrained Foundation Models (Off-the-shelf)	Level 1: Web Data	VGM and VLM
Stage 1 (Video Generation)	Level 2: Egocentric Human Videos Level 3: Synthetic Data Level 5: Multi-Robot Task Trajectory Data	Only VGM
Stage 2 (Unified Training with Latent Actions)	Level 2: Egocentric Human Videos Level 3: Synthetic Data Level 4: Task-agnostic Data Level 5: Multi-Robot Task Trajectory Data	Motus (all 3 experts, with latent actions)
Stage 3 (SFT)	Level 6: Target-Robot Task Trajectory Data	Motus (all 3 experts, with actions)

数据。为了使机器人具备可泛化的操作技能，我们利用大规模多模态数据，这些数据封装了丰富的先验知识——从语义理解和物理推理到时空动态和决策制定。如第 3 节所述，具身数据本质上跨越多种模态：语言 ℓ 、图像 $\mathbf{o}$ 和动作 $\mathbf{a}$ ¹。通过考虑每种模态的存在与否，我们系统地识别出所有有意义的数据类型²：

- **语言 + 图像 + 动作**：机器人轨迹（例如，用于视觉语言动作模型）， $\{\ell, \mathbf{o}_1, \mathbf{a}_1, \dots, \mathbf{o}_N, \mathbf{a}_N\}$ 。
- **语言 + 图像**：视频序列 $\{\ell, \mathbf{o}_1, \dots, \mathbf{o}_N\}$ 或图像-文本对 $\{(\mathbf{o}, \ell)\}$ 。

¹ 在关节位置控制中，本体感觉与动作共享同一表示空间。² 语言可在事后进行标注，以支持面向任务的学习。

- **图像 + 动作**：任务无关的交互数据 $\{(\mathbf{o}_1, \mathbf{a}_1, \dots, \mathbf{o}_i, \mathbf{a}_i)\}$ 。
- **仅语言**：textual corpora $\{\ell\}$ 。

我们排除缺乏视觉模态的数据（例如，语言+动作），因为这类数据不适合视觉运动策略学习。其余类型构成了具身策略获取的完整有用来源谱系。为组织这种多样性，我们引入了具身数据金字塔（图 4），该金字塔根据丰富度和策略相关性对数据类型进行分层组织。我们的框架有效地整合并对齐了全部六个数据层级——从大规模但间接的网络来源到针对性的机器人演示——跨越定制的训练阶段（表 1），在单一、统一的模型架构内统一异构数据集 [1, 14, 24, 31, 48]。




图 4. 具身数据金字塔将数据分为六个层级，从底部的第 1 层到顶部的第 6 层。数据量自下而上递减，而数据质量递增。第 3 层和第 4 层的顺序有时可能变化。

5. 实验

我们进行了大量实验，以评估 Motus 在模拟和真实环境中的有效性。

5.1. 基线

我们将 Motus 与几种最先进的方法进行比较： $\pi_{0.5}$ [8] 和 X-VLA [60]。我们在仿真环境中评估所有模型，并进一步评估基线模型 $\pi_{0.5}$ 在真实世界任务中的性能。我们还比较了从头开始训练的模型和仅进行第一阶段训练的模型与我们的模型。

5.2. 仿真环境中的评估

我们在随机场景中评估了 RoboTwin 2.0 任务中 50 个代表性操作任务的单任务性能。为了探究我们方法的通用能力，我们进行了多任务训练：Motus 和所有基线模型都在

表 2. RoboTwin 2.0 仿真评估（干净场景 vs 随机场景，50+ 任务）。

Simulation Task	$\pi_{0.5}$		X-VLA		w/o Pretrain		Stage1		Motus	
	Clean	Rand.	Clean	Rand.	Clean	Rand.	Clean	Rand.	Clean	Rand.
<i>Place Dual Shoes</i>	12%	7%	79%	88%	78%	80%	94%	94%	93%	87%
<i>Move Stapler Pad</i>	16%	18%	78%	73%	49%	37%	75%	68%	83%	85%
<i>Stack Blocks Two</i>	48%	56%	92%	87%	96%	94%	99%	99%	100%	98%
<i>Scan Object</i>	42%	38%	14%	36%	42%	50%	56%	69%	67%	66%
<i>Place Object Stand</i>	74%	65%	86%	88%	91%	93%	93%	96%	98%	97%
<i>Place Fan</i>	25%	36%	80%	75%	77%	85%	77%	85%	91%	87%
<i>Move Pillbottle Pad</i>	33%	29%	73%	71%	83%	83%	96%	90%	93%	96%
<i>Pick Dual Bottles</i>	10%	6%	47%	36%	58%	68%	7%	17%	96%	90%
<i>Blocks Ranking Rgb</i>	43%	35%	83%	83%	92%	88%	97%	98%	99%	97%
.....(50 tasks)										
<i>Turn Switch</i>	5%	6%	40%	61%	69%	60%	59%	64%	84%	78%
<i>Pick Diverse Bottles</i>	5%	3%	58%	36%	53%	62%	18%	18%	90%	91%
<i>Place Bread Basket</i>	48%	56%	81%	71%	73%	83%	89%	87%	91%	94%
<i>Stack Blocks Three</i>	15%	16%	6%	10%	71%	76%	99%	95%	91%	95%
<i>Put Bottles Dustbin</i>	12%	9%	74%	77%	36%	33%	34%	24%	81%	79%
<i>Place Can Basket</i>	19%	25%	49%	52%	46%	62%	66%	55%	81%	76%
<i>Stamp Seal</i>	36%	23%	76%	82%	80%	88%	93%	95%	93%	92%
<i>Hanging Mug</i>	3%	3%	23%	27%	14%	10%	37%	25%	38%	38%
<i>Handover Block</i>	18%	19%	73%	37%	34%	15%	55%	55%	86%	73%
<i>Stack Bowls Three</i>	33%	35%	76%	86%	90%	74%	86%	83%	79%	87%
<i>Place Object Basket</i>	43%	36%	44%	39%	74%	75%	76%	80%	81%	87%
<i>Open Microwave</i>	35%	37%	79%	71%	83%	82%	82%	84%	95%	91%
Average (%)	42.98	43.84	72.80	72.84	72.8	77.00	82.86	81.86	88.66	87.02

在干净场景中收集的 2500 个演示（每个任务 50 个）加上在高度随机化场景中收集的 25000 个演示（每个任务 500 个）上进行训练。随机化包括随机背景、杂乱的桌面、桌面高度扰动和随机光照。所有模型都从预训练检查点开始，在 RoboTwin 数据集上微调 40k 步，我们通过测量每个任务在 100 次执行试验中的成功率来评估性能。

该基准特别具有挑战性和信息量，因为它包含大量不同的任务场景和随机指令，测试模型处理各种操作设置的能力。其强烈的背景和环境可变性进一步评估了分布偏移下的泛化能力。此外，所有模型只允许在预训练检查点的基础上进行 40k 步微调，这为不同预训练策略的有效性提供了严格而公平的评估。

如表 2 所示，Motus 在 RoboTwin 2.0 随机多任务设置中实现了最先进的性能，与 $\pi_{0.5}$ 模型相比，绝对性能提升了 45% 以上。通过使用统一的 MoT 模型，Motus 成功集成了视觉、语言和动作生成，解决了挑战 1。在挑战 2 中，潜在动作的引入使 Motus 能够有效利用标记数据和大量未标记数据，提高了跨具身的泛化能力并捕获了丰富的运动先验。这种技术组合使 Motus 克服了以往方法的局限性，并实现了卓越的

性能。

5.3. 真实世界实验

我们在两个不同的真实世界双臂机器人平台上评估了 Motus，即 AC-One 和 Agilex-Aloha-2，在一系列非平凡任务下，这些任务涵盖了策略能力的多个维度，包括：（1）空间理解（2）可变形物体操作（3）精确流体控制（4）视觉理解（5）长时程规划，例如折叠毛巾、使用滴滤咖啡机冲泡咖啡以及用研磨机研磨咖啡豆。对于每个任务，我们使用了 100 条轨迹进行训练。与模拟器一致，采用了多任务联合训练方案：每个机器人平台上的所有任务都在一个单一模型内共同训练，随后在每个单独任务上进行评估。这种方法对模型的鲁棒性和泛化能力进行了全面而严格的评估。我们选择 $\pi_{0.5}$ 作为基线。由于大多数任务涉及长时程推理且可分解，我们采用部分成功率进行评估。该度量通过将任务分解为子任务来量化性能，模型在实现特定子目标时获得部分分数，仅在整体成功时获得满分，从而更有力地展示其能力。示例见表 6 和表 5。结果报告在表 3 中。我们的结果表明，Motus 在两个机械臂上的所有任务中均显著优于基线 $\pi_{0.5}$ 。可视化结果




图 5. 任务定义与可视化。对于每个任务，我们描述其语言指令和每个子任务的定义。

表 3. 跨平台的机器人操作任务性能（部分成功率%）。

Task Description	$\pi_{0.5}$	w/o Pretrain	Motus
AC-One			
Fold Towel	4	1	14.5
Brew Coffee using Coffee Maker	0	0	62
Get Water from Water Dispenser	30	8	36
Place Cube into Plate	46	60	100
Place Cube into Plate(OOD)	28.125	18.75	75
Grind Coffee Beans with Grinder	8	0	92
Pour Water from Kettle to Flowers	5	5	65
Touch Instructed Keyboard	0	100	82.5
Put Bread into Oven	12	40	42
Average	14.79	25.86	63.22
Agilex-Aloha-2			
Fold Towel	27.5	0	39
Get Water from Water Dispenser	62	8	96
Pour Water from Kettle to Flowers	45	40	47.5
Touch Instructed Keyboard	72.5	85	80
Put Bread into Oven	36	0	34
Average	48.60	26.60	59.30

provided in Figure 5

5.4. 消融实验

我们进行了消融实验，以证明每个训练阶段的贡献。这涉及对没有预训练和仅进行第一阶段预训练的模型进行基准测试。评估在 RoboTwin 2.0 模拟器中进行，以测量准确率。在真实世界部署中，我们将 Motus 与其从头训练的对应模型进行比较。模拟器中的结果总结在图 6 中，真实世界中的结果

表 4. AC-One 平台上将面包放入烤箱任务及详细的子任务分解。每个子任务前的数字表示其成功完成所获得的分数。

Subgoal	$\pi_{0.5}$	w/o Pretrain	Motus
0.0: Complete Failure	6	4	5
0.2: Open the Oven	3	0	0
0.4: Grab the Bread	0	2	1
0.6: Put the Bread into the Oven	1	1	0
0.8: Close the Oven	0	2	1
1.0: Spin the Button	0	1	3
Partial Success Rate	12%	40%	42%

表 5. 在 Agilex-Aloha-2 平台上从饮水机取水任务及详细子任务分解。每个子任务前的数字表示成功完成该子任务所获得的分数。

Subgoal	$\pi_{0.5}$	w/o Pretrain	Motus
0.0: Complete Failure	0	8	0
0.4: Grab the cup	5	2	0
0.8: Fill the cup with water	4	0	2
1.0: Complete Success	1	0	8
Partial Success Rate	62%	8%	96%




图 6. RoboTwin 2.0 随机多任务设置中的消融实验。该图展示了原始 Motus（第二阶段预训练）及其两个变体（无预训练和第一阶段预训练）的总成功率（%）。

实验如表 3 所示。

6. 结论与局限性

本文提出莫图斯（Motus），一个统一的潜在动作世界模型，将具身基础模型的主流能力整合到单一生成框架中，即视觉语言理解、视频生成、逆动力学、世界建模以及视频动作联合预测。通过思维混合（MoT）连接预训练专家，利用统一扩散器（UniDiffuser）式调度器协调多模态建模，并引入潜在动作作为像素级“增量动作”和运动表示，莫图斯能够有效地从大规模异构数据中学习，并继承生成

eral 多模态先验和丰富的物理交互知识。在仿真和真实世界环境中的大量实验表明, Motus 始终优于现有最先进的具身模型(在仿真中提升 **+15~45%**, 在真实世界场景中提升 **+11~48%**), 验证了统一多模态生成能力和共享运动先验的重要性。我们希望 Motus 能启发未来关于统一架构、以运动为中心的表示学习以及大规模具身预训练的研究。未来, 我们将继续探索更先进的统一模型架构, 追求更通用的运动先验, 并从互联网规模的通用视频中学习潜在动作以用于具身智能。

参考文献

- [1] AgiBot-World-Contributors, Qingwen Bu, Jisong Cai, Li Chen, Xiuqi Cui, Yan Ding, Siyuan Feng, Shenyuan Gao, Xindong He, Xuan Hu, Xu Huang, Shu Jiang, Yuxin Jiang, Cheng Jing, Hongyang Li, Jialu Li, Chiming Liu, Yi Liu, Yuxiang Lu, Jianlan Luo, Ping Luo, Yao Mu, Yuehan Niu, Yixuan Pan, Jiangmiao Pang, Yu Qiao, Guanghui Ren, Cheng Ruan, Jiaqi Shan, Yongjian Shen, Chengshi Shi, Mingkang Shi, Modi Shi, Chonghao Sima, Jianheng Song, Huijie Wang, Wenhao Wang, Dafeng Wei, Chengen Xie, Guo Xu, Junchi Yan, Cunbiao Yang, Lei Yang, Shukai Yang, Maoqing Yao, Jia Zeng, Chi Zhang, Qinglin Zhang, Bin Zhao, Chengyue Zhao, Jiaqi Zhao, and Jianchao Zhu. Agibot world colosseum: A large-scale manipulation platform for scalable and intelligent embodied systems. *arXiv preprint arXiv:2503.06669*, 2025. 6, 5
- [2] Jinze Bai, Shuai Bai, Shusheng Yang, Shijie Wang, Sinan Tan, Peng Wang, Junyang Lin, Chang Zhou, and Jingren Zhou. Qwen-vl: A versatile vision-language model for understanding, localization, text reading, and beyond. *arXiv preprint arXiv:2308.12966*, 2023. 5
- [3] Shuai Bai, Keqin Chen, Xuejing Liu, Jialin Wang, Wenbin Ge, Sibao Song, Kai Dang, Peng Wang, Shijie Wang, Jun Tang, Humen Zhong, Yuanzhi Zhu, Mingkun Yang, Zhaohai Li, Jianqiang Wan, Pengfei Wang, Wei Ding, Zheren Fu, Yiheng Xu, Jiabo Ye, Xi Zhang, Tianbao Xie, Zesen Cheng, Hang Zhang, Zhibo Yang, Haiyang Xu, and Junyang Lin. Qwen2.5-vl technical report. *arXiv preprint arXiv:2502.13923*, 2025. 5
- [4] Homanga Bharadhwaj, Debidatta Dwibedi, Abhinav Gupta, Shubham Tulsiani, Carl Doersch, Ted Xiao, Dhruv Shah, Fei Xia, Dorsa Sadigh, and Sean Kirmani. Gen2act: Human video generation in novel scenarios enables generalizable robot manipulation. *CoRR*, abs/2409.16283, 2024. 1
- [5] Hongzhe Bi, Lingxuan Wu, Tianwei Lin, Hengkai Tan, Zhizhong Su, Hang Su, and Jun Zhu. H-rdt: Human manipulation enhanced bimanual robotic manipulation, 2025. 1
- [6] Johan Bjorck, Fernando Castañeda, Nikita Cherniadev, Xingye Da, Runyu Ding, Linxi Fan, Yu Fang, Dieter Fox, Fengyuan Hu, Spencer Huang, et al. Gr00t n1: An open foundation model for generalist humanoid robots. *arXiv preprint arXiv:2503.14734*, 2025. 3
- [7] Kevin Black, Mitsuhiko Nakamoto, Pranav Atreya, Homer Walke, Chelsea Finn, Aviral Kumar, and Sergey Levine. Zero-shot robotic manipulation with pretrained image-editing diffusion models. *CoRR*, abs/2310.10639, 2023. 1
- [8] Kevin Black, Noah Brown, James Darpinian, Karan Dhabalia, Danny Driess, Adnan Esmail, Michael Robert Equi, Chelsea Finn, Niccolo Fusai, Manuel Y Galliker, et al. $\pi_{0.5}$: a vision-language-action model with open-world generalization. In *9th Annual Conference on Robot Learning*, 2025. 1, 3, 4, 6
- [9] Jake Bruce, Michael D Dennis, Ashley Edwards, Jack Parker-Holder, Yuge Shi, Edward Hughes, Matthew Lai, Aditi Mavalankar, Richie Steigerwald, Chris Apps, Yusuf Aytar, Sarah Maria Elisabeth Bechtle, Feryal Behbahani, Stephanie C.Y. Chan, Nicolas Heess, Lucy Gonzalez, Simon Osindero, Sherjil Ozair, Scott Reed, Jingwei Zhang, Konrad Zolna, Jeff Clune, Nando de Freitas, Satinder Singh, and Tim Rocktäschel. Genie: Generative interactive environments. In *Forty-first International Conference on Machine Learning*, 2024. 3
- [10] Qingwen Bu, Jisong Cai, Li Chen, Xiuqi Cui, Yan Ding, Siyuan Feng, Shenyuan Gao, Xindong He, Xuan Hu, Xu Huang, et al. Agibot world colosseum: A large-scale manipulation platform for scalable and intelligent embodied systems. *arXiv preprint arXiv:2503.06669*, 2025. 3
- [11] Qingwen Bu, Yanting Yang, Jisong Cai, Shenyuan Gao, Guanghui Ren, Maoqing Yao, Ping Luo, and Hongyang Li. Univla: Learning to act anywhere with task-centric latent actions. *arXiv preprint arXiv:2505.06111*, 2025. 1, 3
- [12] Hila Chefer, Uriel Singer, Amit Zohar, Yuval Kirstain, Adam Polyak, Yaniv Taigman, Lior Wolf, and Shelly Sheynin. Videojam: Joint appearance-motion representations for enhanced motion generation in video models. *arXiv preprint arXiv:2502.02492*, 2025. 3
- [13] Junyu Chen, Han Cai, Junsong Chen, Enze Xie, Shang Yang, Haotian Tang, Muyang Li, and Song Han. Deep compression autoencoder for efficient high-resolution diffusion models. In *The Thirteenth International Conference on Learning Representations, ICLR 2025, Singapore, April 24-28, 2025*. OpenReview.net, 2025. 5
- [14] Tianxing Chen, Zhanxin Chen, Baijun Chen, Zijian Cai, Yibin Liu, Zixuan Li, Qiwei Liang, Xianliang Lin, Yiheng Ge, Zhenyu Gu, et al. Robotwin 2.0: A scalable data generator and benchmark with strong domain randomization for robust bimanual robotic manipulation. *arXiv preprint arXiv:2506.18088*, 2025. 6, 5
- [15] Yi Chen, Yuying Ge, Weiliang Tang, Yizhuo Li, Yixiao Ge, Mingyu Ding, Ying Shan, and Xihui Liu. Moto: Latent motion token as the bridging language for learning robot manipulation from videos. *arXiv preprint arXiv:2412.04445*, 2024. 3
- [16] Jaden Clark, Suvir Mirchandani, Dorsa Sadigh, and Suneel Belkale. Action-free reasoning for policy generalization. In *ICRA 2025 Workshop on Foundation Models and Neuro-Symbolic AI for Robotics*, 2025. 3
- [17] Jeremy A Collins, Loránd Cheng, Kunal Aneja, Albert Wilcox, Benjamin Joffe, and Animesh Garg. Amplify: Ac-

- tionless motion priors for robot learning from videos. *arXiv preprint arXiv:2506.14198*, 2025. 3
- [18] Chaorui Deng, Deyao Zhu, Kunchang Li, Chenhui Gou, Feng Li, Zeyu Wang, Shu Zhong, Weihao Yu, Xiaonan Nie, Ziang Song, et al. Emerging properties in unified multimodal pre-training. *arXiv preprint arXiv:2505.14683*, 2025. 3
- [19] Yilun Du, Sherry Yang, Bo Dai, Hanjun Dai, Ofir Nachum, Josh Tenenbaum, Dale Schuurmans, and Pieter Abbeel. Learning universal policies via text-guided video generation. *Advances in neural information processing systems*, 36:9156–9172, 2023. 1, 3
- [20] Ashley Edwards, Himanshu Sahni, Yannick Schroecker, and Charles Isbell. Imitating latent policies from observation. In *International conference on machine learning*, pages 1755–1763. PMLR, 2019. 3
- [21] Yao Feng, Hengkai Tan, Xinyi Mao, Chendong Xiang, Guodong Liu, Shuhe Huang, Hang Su, and Jun Zhu. Vidar: Embodied video diffusion model for generalist manipulation. *arXiv preprint arXiv:2507.12898*, 2025. 1, 3
- [22] Shen Yuan Gao, Siyuan Zhou, Yilun Du, Jun Zhang, and Chuang Gan. Adaworld: Learning adaptable world models with latent actions. In *Forty-second International Conference on Machine Learning*, 2025. 3
- [23] Irina Higgins, Loic Matthey, Arka Pal, Christopher Burgess, Xavier Glorot, Matthew Botvinick, Shakir Mohamed, and Alexander Lerchner. beta-VAE: Learning basic visual concepts with a constrained variational framework. In *International Conference on Learning Representations*, 2017. 3
- [24] Ryan Hoque, Peide Huang, David J Yoon, Mouli Sivapurapu, and Jian Zhang. Egodex: Learning dexterous manipulation from large-scale egocentric video. *arXiv preprint arXiv:2505.11709*, 2025. 6, 5
- [25] Yucheng Hu, Yanjiang Guo, Pengchao Wang, Xiaoyu Chen, Yen-Jen Wang, Jianke Zhang, Koushil Sreenath, Chaochao Lu, and Jianyu Chen. Video prediction policy: A generalist robot policy with predictive visual representations. *CoRR*, abs/2412.14803, 2024. 1
- [26] Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, Ted Xiao, Ashwin Balakrishna, Suraj Nair, Rafael Rafailov, Ethan P Foster, Pannag R Sanketi, Quan Vuong, et al. Openvla: An open-source vision-language-action model. In *8th Annual Conference on Robot Learning*. 1
- [27] Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, Ted Xiao, Ashwin Balakrishna, Suraj Nair, Rafael Rafailov, Ethan P Foster, Pannag R Sanketi, Quan Vuong, Thomas Kollar, Benjamin Burchfiel, Russ Tedrake, Dorsa Sadigh, Sergey Levine, Percy Liang, and Chelsea Finn. OpenVLA: An open-source vision-language-action model. In *8th Annual Conference on Robot Learning*, 2024. 3
- [28] Shuang Li, Yihuai Gao, Dorsa Sadigh, and Shuran Song. Unified video action model. *CoRR*, abs/2503.00200, 2025. 1
- [29] Zijie Li, Henry Li, Yichun Shi, Amir Barati Farimani, Yuval Kluger, Linjie Yang, and Peng Wang. Dual diffusion for unified image generation and understanding. In *Proceedings of the Computer Vision and Pattern Recognition Conference*, pages 2779–2790, 2025. 3
- [30] Weixin Liang, LILI YU, Liang Luo, Srini Iyer, Ning Dong, Chunting Zhou, Gargi Ghosh, Mike Lewis, Wen tau Yih, Luke Zettlemoyer, and Xi Victoria Lin. Mixture-of-transformers: A sparse and scalable architecture for multi-modal foundation models. In *ICLR 2025 Workshop on World Models: Understanding, Modelling and Scaling*, 2025. 3
- [31] Songming Liu, Lingxuan Wu, Bangguo Li, Hengkai Tan, Huayu Chen, Zhengyi Wang, Ke Xu, Hang Su, and Jun Zhu. Rdt-1b: a diffusion foundation model for bimanual manipulation. In *The Thirteenth International Conference on Learning Representations*. 1, 4, 6, 5
- [32] Qi Lv, Weijie Kong, Hao Li, Jia Zeng, Zherui Qiu, Delin Qu, Haoming Song, Qizhi Chen, Xiang Deng, and Jiangmiao Pang. FL: A vision-language-action model bridging understanding and generation to actions. *arXiv preprint arXiv:2509.06951*, 2025. 1, 3
- [33] Henrique Morimitsu, Xiaobin Zhu, Roberto M. Cesar, Xi-angyang Ji, and Xu-Cheng Yin. Dpflow: Adaptive optical flow estimation with a dual-pyramid framework. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition, CVPR 2025, Nashville, TN, USA, June 11-15, 2025*, pages 17810–17820. Computer Vision Foundation / IEEE, 2025. 5
- [34] Alexander Nikulin, Ilya Zisman, Denis Tarasov, Nikita Lyubaykin, Andrei Polubarov, Igor Kiselev, and Vladislav Kurenkov. Latent action learning requires supervision in the presence of distractors. *arXiv preprint arXiv:2502.00379*, 2025. 3
- [35] Junzhi Ning, Wei Li, Cheng Tang, Jiashi Lin, Chenglong Ma, Chaoyang Zhang, Jiyao Liu, Ying Chen, Shujian Gao, Lihao Liu, Yuandong Pu, Huihui Xu, Chenhui Gou, Ziyang Huang, Yi Xin, Qi Qin, Zhongying Deng, Diping Song, Bin Fu, Guang Yang, Yuanfeng Ji, Tianbin Li, Yanzhou Su, Jin Ye, Shixiang Tang, Ming Hu, and Junjun He. Unimedvl: Unifying medical multimodal understanding and generation through observation-knowledge-analysis, 2025. 3
- [36] Abby O’Neill, Abdul Rehman, Abhiram Maddukuri, Abhishek Gupta, Abhishek Padalkar, Abraham Lee, Acorn Pooley, Agrim Gupta, Ajay Mandlekar, Ajinkya Jain, Albert Tung, Alex Bewley, Alexander Herzog, Alex Irpan, Alexander Khazatsky, Anant Rai, Anchit Gupta, Andrew E. Wang, Anikait Singh, Animesh Garg, Aniruddha Kembhavi, Annie Xie, Anthony Brohan, Antonin Raffin, Archit Sharma, Arefeh Yavary, Arhan Jain, Ashwin Balakrishna, Ayzaan Wahid, Ben Burgess-Limerick, Beomjoon Kim, Bernhard Schölkopf, Blake Wulfe, Brian Ichter, Cewu Lu, Charles Xu, Charlotte Le, Chelsea Finn, Chen Wang, Chenfeng Xu, Cheng Chi, Chenguang Huang, Christine Chan, Christopher Agia, Chuer Pan, Chuyuan Fu, Coline Devin, Danfei Xu, Daniel Morton, Danny Driess, Daphne Chen, Deepak Pathak, Dhruv Shah, Dieter Buechler, Dinesh Jayaraman, Dmitry Kalashnikov, Dorsa Sadigh, Edward Johns, Ethan Paul Foster, Fangchen Liu, Federico Ceola, Fei Xia, Feiyu Zhao, Freek Stulp, Gaoyue Zhou, Gaurav S. Sukhatme, Gautam Salhotra, Ge Yan, Gilbert Feng, Giulio Schiavi, Glen Berseth, Gregory Kahn, Guanzhi Wang, Hao Su, Haoshu Fang, Haochen Shi, Henghui Bao, Heni Ben Amor, Henrik I. Christensen, Hiroki Furuta, Homer Walke, Hongjie Fang, Huy Ha, Igor Mordatch, Ilija Radosavovic, Isabel Leal, Jacky Liang, Jad Abou-Chakra, Jaehyung Kim, Jaimyn Drake, Jan Peters, Jan Schneider, Jas-

- mine Hsu, Jeannette Bohg, Jeffrey Bingham, Jeffrey Wu, Jensen Gao, Jiaheng Hu, Jiajun Wu, Jialin Wu, Jiankai Sun, Jianlan Luo, Jiayuan Gu, Jie Tan, Jihoon Oh, Jimmy Wu, Jingpei Lu, Jingyun Yang, Jitendra Malik, João Silvério, Joey Hejna, Jonathan Boohar, Jonathan Tompson, Jonathan Yang, Jordi Salvador, Joseph J. Lim, Junhyek Han, Kaiyuan Wang, Kanishka Rao, Karl Pertsch, Karol Hausman, Keegan Go, Keerthana Gopalakrishnan, Ken Goldberg, Kendra Byrne, Kenneth Oslund, Kento Kawaharazuka, Kevin Black, Kevin Lin, Kevin Zhang, Kiana Ehsani, Kiran Lekkala, Kirsty Ellis, Krishan Rana, Krishnan Srinivasan, Kuan Fang, Kunal Pratap Singh, Kuo-Hao Zeng, Kyle Hatch, Kyle Hsu, Laurent Itti, Lawrence Yunliang Chen, Lerrel Pinto, Li Fei-Fei, Liam Tan, Linxi Jim Fan, Lionel Ott, Lisa Lee, Luca Weihs, Magnum Chen, Marion Lepert, Marius Memmel, Masayoshi Tomizuka, Masha Itkina, Mateo Guaman Castro, Max Spero, Maximilian Du, Michael Ahn, Michael C. Yip, Mingtong Zhang, Mingyu Ding, Minh Ho, Mohan Kumar Srirama, Mohit Sharma, Moo Jin Kim, Naoaki Kanazawa, Nicklas Hansen, Nicolas Heess, Nikhil J. Joshi, Niko Sünderhauf, Ning Liu, Norman Di Palo, Nur Muhammad (Mahi) Shafiullah, Oier Mees, Oliver Kroemer, Osbert Bastani, Pannag R. Sanketi, Patrick Tree Miller, Patrick Yin, Paul Wohlhart, Peng Xu, Peter David Fagan, Peter Mitrano, Pierre Sermanet, Pieter Abbeel, Priya Sundareshan, Qiuyu Chen, Quan Vuong, Rafael Rafailov, Ran Tian, Ria Doshi, Roberto Martín-Martín, Rohan Bajjal, Rosario Scalise, Rose Hendrix, Roy Lin, Runjia Qian, Ruohan Zhang, Russell Mendonca, Rutav Shah, Ryan Hoque, Ryan Julian, Samuel Bustamante, Sean Kirmani, Sergey Levine, Shan Lin, Sherry Moore, Shikhar Bahl, Shivin Dass, Shubham D. Sonawani, Shuran Song, Sichun Xu, Siddhant Haldar, Siddharth Karamcheti, Simeon Adebola, Simon Guist, Soroush Nasiriany, Stefan Schaal, Stefan Welker, Stephen Tian, Subramanian Ramamoorthy, Sudeep Dasari, Suneel Belkhale, Sungjae Park, Suraj Nair, Suvir Mirchandani, Takayuki Osa, Tanmay Gupta, Tatsuya Harada, Tatsuya Matsushima, Ted Xiao, Thomas Kollar, Tianhe Yu, Tianli Ding, Todor Davchev, Tony Z. Zhao, Travis Armstrong, Trevor Darrell, Trinity Chung, Vidhi Jain, Vincent Vanhoucke, Wei Zhan, Wenxuan Zhou, Wolfram Burgard, Xi Chen, Xiaolong Wang, Xinghao Zhu, Xinyang Geng, Xiyuan Liu, Liangwei Xu, Xuanlin Li, Yao Lu, Yecheng Jason Ma, Yejin Kim, Yevgen Chebotar, Yifan Zhou, Yifeng Zhu, Yilin Wu, Ying Xu, Yixuan Wang, Yonatan Bisk, Yoonyoung Cho, Youngwoon Lee, Yuchen Cui, Yue Cao, Yueh-Hua Wu, Yujin Tang, Yuke Zhu, Yunchu Zhang, Yunfan Jiang, Yunshuang Li, Yunzhu Li, Yusuke Iwasawa, Yutaka Matsuo, Zehan Ma, Zhuo Xu, Zichen Jeff Cui, Zichen Zhang, and Zipeng Lin. Open x-embodiment: Robotic learning datasets and RT-X models : Open x-embodiment collaboration. In *IEEE International Conference on Robotics and Automation, ICRA 2024, Yokohama, Japan, May 13-17, 2024*, pages 6892–6903. IEEE, 2024. 1
- [37] Oleh Rybkin, Karl Pertsch, Andrew Jaegle, Konstantinos G. Derpanis, and Kostas Daniilidis. Learning what you can do before doing anything. In *International Conference on Learning Representations*, 2019. 3
- [38] Dominik Schmidt and Minqi Jiang. Learning to act without actions. In *The Twelfth International Conference on Learning Representations*, 2024. 3
- [39] Hengkai Tan, Yao Feng, Xinyi Mao, Shuhe Huang, Guodong Liu, Zhongkai Hao, Hang Su, and Jun Zhu. Anypos: Automated task-agnostic actions for bimanual manipulation, 2025. 1, 5
- [40] Chameleon Team. Chameleon: Mixed-modal early-fusion foundation models. *arXiv preprint arXiv:2405.09818*, 2024. 3
- [41] Yang Tian, Sizhe Yang, Jia Zeng, Ping Wang, Dahua Lin, Hao Dong, and Jiangmiao Pang. Predictive inverse dynamics models are scalable learners for robotic manipulation. *CoRR*, abs/2412.15109, 2024. 1
- [42] Team Wan, Ang Wang, Baole Ai, Bin Wen, Chaojie Mao, Chen-Wei Xie, Di Chen, Feiwu Yu, Haiming Zhao, Jianxiao Yang, Jianyuan Zeng, Jiayu Wang, Jingfeng Zhang, Jingren Zhou, Jinkai Wang, Jixuan Chen, Kai Zhu, Kang Zhao, Keyu Yan, Lianghua Huang, Mengyang Feng, Ningyi Zhang, Pandeng Li, Pingyu Wu, Ruihang Chu, Ruili Feng, Shiwei Zhang, Siyang Sun, Tao Fang, Tianxing Wang, Tianyi Gui, Tingyu Weng, Tong Shen, Wei Lin, Wei Wang, Wei Wang, Wenmeng Zhou, Wenten Wang, Wenting Shen, Wenyuan Yu, Xianzhong Shi, Xiaoming Huang, Xin Xu, Yan Kou, Yangyu Lv, Yifei Li, Yijing Liu, Yiming Wang, Yingya Zhang, Yitong Huang, Yong Li, You Wu, Yu Liu, Yulin Pan, Yun Zheng, Yuntao Hong, Yupeng Shi, Yutong Feng, Zeyinzi Jiang, Zhen Han, Zhi-Fan Wu, and Ziyu Liu. Wan: Open and advanced large-scale video generative models. *arXiv preprint arXiv:2503.20314*, 2025. 5
- [43] Lirui Wang, Xinlei Chen, Jialiang Zhao, and Kaiming He. Scaling proprioceptive-visual learning with heterogeneous pre-trained transformers. In *Advances in Neural Information Processing Systems 38: Annual Conference on Neural Information Processing Systems 2024, NeurIPS 2024, Vancouver, BC, Canada, December 10 - 15, 2024*, 2024. 4
- [44] Peng Wang, Shuai Bai, Sinan Tan, Shijie Wang, Zhihao Fan, Jinze Bai, Keqin Chen, Xuejing Liu, Jialin Wang, Wenbin Ge, Yang Fan, Kai Dang, Mengfei Du, Xuancheng Ren, Rui Men, Dayiheng Liu, Chang Zhou, Jingren Zhou, and Junyang Lin. Qwen2-vl: Enhancing vision-language model’s perception of the world at any resolution. *arXiv preprint arXiv:2409.12191*, 2024. 5
- [45] Xinlong Wang, Xiaosong Zhang, Zhengxiong Luo, Quan Sun, Yufeng Cui, Jinsheng Wang, Fan Zhang, Yueze Wang, Zhen Li, Qiyang Yu, et al. Emu3: Next-token prediction is all you need. *arXiv preprint arXiv:2409.18869*, 2024. 3
- [46] Yiqi Wang, Mrinal Verghese, and Jeff Schneider. Latent policy steering with embodiment-agnostic pretrained world models. *arXiv preprint arXiv:2507.13340*, 2025. 3
- [47] Chengyue Wu, Xiaokang Chen, Zhiyu Wu, Yiyang Ma, Xingchao Liu, Zizheng Pan, Wen Liu, Zhenda Xie, Xingkai Yu, Chong Ruan, et al. Janus: Decoupling visual encoding for unified multimodal understanding and generation. In *Proceedings of the Computer Vision and Pattern Recognition Conference*, pages 12966–12977, 2025. 3
- [48] Kun Wu, Chengkai Hou, Jiaming Liu, Zhengping Che, Xiaozhu Ju, Zhuqin Yang, Meng Li, Yinuo Zhao, Zhiyuan

- Xu, Guang Yang, et al. Robomind: Benchmark on multi-embodiment intelligence normative data for robot manipulation. *arXiv preprint arXiv:2412.13877*, 2024. 6, 5
- [49] Jinheng Xie, Zhenheng Yang, and Mike Zheng Shou. Show-o2: Improved native unified multimodal models. *arXiv preprint arXiv:2506.15564*, 2025. 3
- [50] Jiange Yang, Yansong Shi, Haoyi Zhu, Mingyu Liu, Kaijing Ma, Yating Wang, Gangshan Wu, Tong He, and Limin Wang. Como: Learning continuous latent motion from internet videos for scalable robot learning. *arXiv preprint arXiv:2505.17006*, 2025. 3
- [51] Jiange Yang, Haoyi Zhu, Yating Wang, Gangshan Wu, Tong He, and Limin Wang. Tra-moe: Learning trajectory prediction model from multiple domains for adaptive policy conditioning. In *Proceedings of the Computer Vision and Pattern Recognition Conference*, pages 6960–6970, 2025. 3
- [52] Ling Yang, Ye Tian, Bowen Li, Xinchun Zhang, Ke Shen, Yunhai Tong, and Mengdi Wang. Mmada: Multimodal large diffusion language models. *arXiv preprint arXiv:2505.15809*, 2025. 3
- [53] Sherry Yang, Yilun Du, Seyed Kamyar Seyed Ghasemipour, Jonathan Tompson, Leslie Pack Kaelbling, Dale Schuurmans, and Pieter Abbeel. Learning interactive real-world simulators. In *The Twelfth International Conference on Learning Representations, ICLR 2024, Vienna, Austria, May 7-11, 2024*. OpenReview.net, 2024. 1
- [54] Junliang Ye, Zhengyi Wang, Ruowen Zhao, Shenghao Xie, and Jun Zhu. Shapellm-omni: A native multimodal llm for 3d generation and understanding. *arXiv preprint arXiv:2506.01853*, 2025. 3
- [55] Seonghyeon Ye, Joel Jang, Byeongguk Jeon, Se June Joo, Jianwei Yang, Baolin Peng, Ajay Mandlekar, Reuben Tan, Yu-Wei Chao, Bill Yuchen Lin, Lars Liden, Kimin Lee, Jianfeng Gao, Luke Zettlemoyer, Dieter Fox, and Minjoon Seo. Latent action pretraining from videos. In *The Thirteenth International Conference on Learning Representations*, 2025. 3
- [56] Weirui Ye, Fangchen Liu, Zheng Ding, Yang Gao, Oleh Rybkin, and Pieter Abbeel. Video2policy: Scaling up manipulation tasks in simulation through internet videos. *CoRR*, abs/2502.09886, 2025. 1
- [57] Chengbo Yuan, Rui Zhou, Mengzhen Liu, Yingdong Hu, Shengjie Wang, Li Yi, Shanghang Zhang, Chuan Wen, and Yang Gao. Motiontrans: Human VR data enable motion-level learning for robotic manipulation policies. In *Human to Robot: Workshop on Sensorizing, Modeling, and Learning from Humans*, 2025. 3
- [58] Chuheng Zhang, Tim Pearce, Pushi Zhang, Kaixin Wang, Xiaoyu Chen, Wei Shen, Li Zhao, and Jiang Bian. What do latent action models actually learn? *arXiv preprint arXiv:2506.15691*, 2025. 3
- [59] Tony Z. Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware. In *Robotics: Science and Systems XIX, Daegu, Republic of Korea, July 10-14, 2023*, 2023. 3
- [60] Jinliang Zheng, Jianxiong Li, Zhihao Wang, Dongxiu Liu, Xirui Kang, Yuchun Feng, Yinan Zheng, Jiayin Zou, Yilun Chen, Jia Zeng, et al. X-vla: Soft-prompted transformer as scalable cross-embodiment vision-language-action model. *arXiv preprint arXiv:2510.10274*, 2025. 1, 3, 4, 6
- [61] Zhide Zhong, Haodong Yan, Junfeng Li, Xiangchen Liu, Xin Gong, Tianran Zhang, Wenxuan Song, Jiayi Chen, Xinhua Zheng, Hesheng Wang, et al. Flowvla: Visual chain of thought-based motion reasoning for vision-language-action models. *arXiv preprint arXiv:2508.18269*, 2025. 3
- [62] Siyuan Zhou, Yilun Du, Jiaben Chen, Yandong Li, Dit-Yan Yeung, and Chuang Gan. Robodreamer: Learning compositional world models for robot imagination. In *International Conference on Machine Learning*, pages 61885–61896. PMLR, 2024. 1, 3
- [63] Xin Zhou, Dingkan Liang, Sifan Tu, Xiwu Chen, Yikang Ding, Dingyuan Zhang, Feiyang Tan, Hengshuang Zhao, and Xiang Bai. Hermes: A unified self-driving world model for simultaneous 3d scene understanding and generation. *arXiv preprint arXiv:2501.14729*, 2025. 3
- [64] Chuning Zhu, Raymond Yu, Siyuan Feng, Benjamin Burchfiel, Paarth Shah, and Abhishek Gupta. Unified world models: Coupling video and action diffusion for pretraining on large robotic datasets. *arXiv preprint arXiv:2504.02792*, 2025. 1, 3, 4
- [65] Brianna Zitkovich, Tianhe Yu, Sichun Xu, Peng Xu, Ted Xiao, Fei Xia, Jialin Wu, Paul Wohlhart, Stefan Welker, Ayzaan Wahid, et al. Rt-2: Vision-language-action models transfer web knowledge to robotic control. In *Conference on Robot Learning*, pages 2165–2183. PMLR, 2023. 1

Motus: 一个统一的潜在动作世界模型

补充材料

7. 统一模型的训练与推理

本节从理论和实验两个角度分析统一模型的训练与推理过程。

7.1. 理论分析

在每次训练迭代中, 给定 $o_{t:t+k}^0$ 和 $a_{t:t+k}^0$, Motus 分别为它们采样不同的时间步 τ_o, τ_a 和噪声 ϵ_o, ϵ_a , 基于修正流构造插值轨迹 $o_{t+1:t+k}^{\tau_o}, a_{t+1:t+k}^{\tau_a}$, 并计算预测速度场 v_o^θ, v_a^θ 与其通过路径微分得到的真实值 v_o, v_a 之间的损失, 其中路径微分使用 t 。

Algorithm 1 Training

```

1: repeat
2:    $o_{t:t+k}^0, a_{t+1:t+k}^0, \ell \sim D_{expert}$ 
3:    $\tau_o, \tau_a \sim \text{Uniform}(\{1, 2, \dots, T_\tau\})$ 
4:    $\epsilon_o, \epsilon_a \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 
5:    $o_{t+1:t+k}^{\tau_o} = (1 - \tau_o)o_{t+1:t+k}^0 + \tau_o\epsilon_o$ 
6:    $a_{t+1:t+k}^{\tau_a} = (1 - \tau_a)a_{t+1:t+k}^0 + \tau_a\epsilon_a$ 
7:    $v_o^\theta, v_a^\theta = \text{Model}_\theta(o_t^0, o_{t+1:t+k}^{\tau_o}, a_{t+1:t+k}^{\tau_a}, \tau_o, \tau_a, \ell)$ 
8:    $l_{\text{action}}^\theta = \|v_a^\theta - (\epsilon_a - a_{t+1:t+k}^0)\|_2^2$ 
9:    $l_{\text{obs}}^\theta = \|v_o^\theta - (\epsilon_o - o_{t+1:t+k}^0)\|_2^2$ 
10:   $l^\theta = l_{\text{action}}^\theta + l_{\text{obs}}^\theta$ 
11:   $\theta \leftarrow \theta - \eta \nabla_\theta l^\theta$ 
12: until converged

```

在推理过程中, Motus 可以在以下五种不同模式之间切换。

VGM。为了启用 VGM $p(o_{t+1:t+k}^0 | o_t^0, \ell)$, 给定 o_t^0 和 ℓ 作为条件, 我们将观测和动作的起始时间步均设为 T_τ , 随机采样 $\epsilon_a, \epsilon_o \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$, 然后应用算法 2 从 ϵ_o 逐步推断 $o_{t+1:t+k}^0$, 同时保持 $a_{t+1:t+k}^{T_\tau}$ 始终为噪声, 如同 ϵ_a 。

Algorithm 2 VGM

```

Require:  $o_t^0, \ell, \theta$ 
1:  $\epsilon_o, \epsilon_a \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 
2:  $o_{t+1:t+k}^{T_\tau} \leftarrow \epsilon_o$ 
3:  $a_{t+1:t+k}^{T_\tau} \leftarrow \epsilon_a$ 
4: for  $\tau = T_\tau \dots 1$  do
5:    $v_o, v_a = \text{Model}_\theta(o_t^0, o_{t+1:t+k}^\tau, a_{t+1:t+k}^{T_\tau}, \tau, T_\tau, \ell)$ 
6:    $o_{t+1:t+k}^{\tau-1} = o_{t+1:t+k}^\tau + v_o d\tau$ 
7: end for
8: return  $o_{t+1:t+k}^0$ 

```

世界模型。为了实现世界模型 $p(o_{t+1:t+k}^0 | o_t^0, a_{t+1:t+k}^0)$, 给定 o_t^0 和 $a_{t+1:t+k}^0$ 作为条件, 我们将观测和动作的起始时间步分别设为 T_τ 和 0, 随机采样 $\epsilon_o \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$, 然后应用算法 3 逐步从 ϵ_o 推断 $o_{t+1:t+k}^0$, 同时始终保持 $a_{t+1:t+k}^0$ 干净。

Algorithm 3 World Model

```

Require:  $o_t^0, a_{t+1:t+k}^0, \ell, \theta$ 
1:  $\epsilon_o \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 
2:  $o_{t+1:t+k}^{T_\tau} \leftarrow \epsilon_o$ 
3: for  $\tau = T_\tau \dots 1$  do
4:    $v_o, v_a = \text{Model}_\theta(o_t^0, o_{t+1:t+k}^\tau, a_{t+1:t+k}^0, \tau, 0, \ell)$ 
5:    $o_{t+1:t+k}^{\tau-1} = o_{t+1:t+k}^\tau + v_o d\tau$ 
6: end for
7: return  $o_{t+1:t+k}^0$ 

```

IDM。为了实现 IDM $p(a_{t+1:t+k}^0 | o_{t:t+k}^0)$, 给定 $o_{t:t+k}^0$ 作为条件, 我们将观测和动作的起始时间步分别设为 0 和 T_τ , 随机采样 $\epsilon_a \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$, 然后应用算法 4 逐步从 ϵ_a 推断 $a_{t+1:t+k}^0$, 同时始终保持 $o_{t:t+k}^0$ 干净。

Algorithm 4 IDM

```

Require:  $o_{t:t+k}^0, \ell, \theta$ 
1:  $\epsilon_a \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 
2:  $a_{t+1:t+k}^{T_\tau} \leftarrow \epsilon_a$ 
3: for  $\tau = T_\tau \dots 1$  do
4:    $v_o, v_a = \text{Model}_\theta(o_{t:t+k}^0, a_{t+1:t+k}^\tau, 0, \tau, \ell)$ 
5:    $a_{t+1:t+k}^{\tau-1} = a_{t+1:t+k}^\tau + v_a d\tau$ 
6: end for
7: return  $a_{t+1:t+k}^0$ 

```

VLA。为了实现 VLA $p(a_{t+1:t+k}^0 | o_t^0, \ell)$ ，给定 o_t^0 和 ℓ 作为条件，我们将观测和动作的起始时间步均设为 T_τ ，随机采样 $\epsilon_a, \epsilon_o \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ ，然后应用算法 5 逐步从 ϵ_a 推断 $a_{t+1:t+k}^0$ ，同时始终保持 $o_{t+1:t+k}^{T_\tau}$ 如 ϵ_o 所示一致含噪。

Algorithm 5 VLA

Require: o_t^0, ℓ, θ

- 1: $\epsilon_o, \epsilon_a \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
- 2: $o_{t+1:t+k}^{T_\tau} \leftarrow \epsilon_o$
- 3: $a_{t+1:t+k}^{T_\tau} \leftarrow \epsilon_a$
- 4: **for** $\tau = T_\tau \dots 1$ **do**
- 5: $v_o, v_a = \text{Model}_\theta(o_t^0, o_{t+1:t+k}^{T_\tau}, a_{t+1:t+k}^\tau, T_\tau, \tau, \ell)$
- 6: $a_{t+1:t+k}^{\tau-1} = a_{t+1:t+k}^\tau + v_a d\tau$
- 7: **end for**
- 8: **return** $a_{t+1:t+k}^0$

视频-动作联合预测模型。为了实现视频-动作联合预测模型 $p(o_{t+1:t+k}^0, a_{t+1:t+k}^0 | o_t^0, \ell)$ ，给定 o_t 和 ℓ 作为条件，我们将观测和动作的起始时间步均设为 T_τ ，随机采样 $\epsilon_a, \epsilon_o \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ ，然后应用算法 2 逐步从 ϵ_a 推断 $a_{t+1:t+k}^0$ ，并从 ϵ_o 推断 $o_{t+1:t+k}^0$ 。

Algorithm 6 Video-Action Joint Prediction Model

Require: o_t^0, ℓ, θ

- 1: $\epsilon_o, \epsilon_a \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
- 2: $o_{t+1:t+k}^{T_\tau} \leftarrow \epsilon_o$
- 3: $a_{t+1:t+k}^{T_\tau} \leftarrow \epsilon_a$
- 4: **for** $\tau = T_\tau \dots 1$ **do**
- 5: $v_o, v_a = \text{Model}_\theta(o_t^0, o_{t+1:t+k}^{T_\tau}, a_{t+1:t+k}^\tau, \tau, \tau, \ell)$
- 6: $o_{t+1:t+k}^{\tau-1} = o_{t+1:t+k}^\tau + v_o d\tau$
- 7: $a_{t+1:t+k}^{\tau-1} = a_{t+1:t+k}^\tau + v_a d\tau$
- 8: **end for**
- 9: **return** $o_{t+1:t+k}^0, a_{t+1:t+k}^0$

7.2. 实验结果

VGM。如图 7 和图 9 所示，当 Motus 以 VGM 模式运行时，它在 Agilex-Aloha-2 和 AC-One 两种实体上均展现出高质量的可视化结果，证明了其强大的视频生成能力。

世界模型。如图 11、图 10 和表 6 所示，当 Motus 以世界模型模式运行时，它在真实机器人数据上针对两种实体均展现出高质量的视频生成结果，证明了其强大的未来预测能力。

表 6. Motus 在世界模型模式下的生成质量。这些度量在两个机器人平台上的真实世界机器人数据上进行了评估。

Platform	FID↓	FVD↓	SSIM↑	LPIPS↓	PSNR↑
Agilex-Aloha-2	9.4571	49.2848	0.88618	0.05449	26.1021
AC-One	12.9609	73.1325	0.84605	0.07280	24.0379
Avg.	11.209	61.20865	0.8661	0.063645	25.0700

逆动力学模型 (IDM)。为验证本文模型作为逆动力学模型的有效性，训练了两个基线逆动力学模型进行比较：一个基于预训练的 ResNet-18 骨干网络后接多层感知机 (MLP) 层，另一个使用 DINOv2 特征与多层感知机头。两个模型均在 RobotWin 2.0 随机数据集上使用 Agilex-Aloha-2 机器人平台进行训练。每个模型以当前观测为输入，预测未来动作序列，动作块大小为 16，与 Motus 在 RobotTwin 中的配置一致。训练目标是最小化预测动作与真实动作之间的均方误差 (MSE)。

如表 7 所示，当 Motus 以逆动力学模型模式运行时，其动作均方误差低于专门训练的逆动力学模型基线。这表明本文模型不仅能作为有效的策略，而且在逆动力学建模方面表现出色，甚至优于专门为此目的训练的模型。

表 7. 逆动力学模型的动作均方误差。模型在 RoboTwin 2.0 随机数据的 100 个样本上进行测试。

ResNet18+MLP	DINOv2+MLP	Motus
0.044	0.122	0.014

视觉-语言-动作模型 (VLA)。如表 8 所示，当 Motus 以视觉-语言-动作模型模式运行时，与视频-动作联合预测模型相比，在 RoboTwin 2.0 随机数据上也表现出具有竞争力的性能。

表 8. 视觉-语言-动作模型在 RoboTwin 2.0 随机数据上的平均成功率。

Motus (视觉-语言-动作模型)	Motus (联合)
83.90	87.02

视频-动作联合预测模型。如图 12 所示，当 Motus 以视频-动作联合预测模型模式运行时，它在同时生成视频和精确动作方面展现出强大的能力。



图 7. Motus 在 Agilex-Aloha-2 上的 VGM 模式可视化。

8. 更多实验结果

8.1. RoboTwin 2.0 仿真数据上的整体比较 与更多基线对比

表 14 展示了在 RoboTwin 2.0 仿真上的评估结果，呈现了 Motus 及其他基线在全部 50 个任务上、干净场景与随机场景下的性能。

8.2. 其他基准

LIBERO-Long. LIBERO-Long 是 LIBERO 基准中的长程子集，包含来自 LIBERO-100 的 10 个语言条件操作任务，这些任务需要多阶段决策、多样化的操作技能以及跨物体和场景的鲁棒知识迁移。在标准 LIBERO-Long 评估协议下，本文方法取得了 **97.6** 的平均成功率，与 X-VLA 的最佳报告性能持平，从而在该基准上达到了最先进的结果。

π_0	GR00T-N1	UniVLA	OpenVLA-OFT	X-VLA	Motus
85.2	90.6	94.0	94.5	97.6	97.6

表 9. LIBERO-Long 基准上的评估

VLABench. VLABench 是一个开源基准，用于评估通用语言条件操作任务学习，涵盖操作技能、视觉理解、语义理解、常识和推理等多个维度。单个 Motus 模型在多个任务上进行了微调，随后基于其在 VLABench 提供的 2 个赛道（分布内和跨类别）上的 3 个任务的成功率进行评估。结果如表 10 所示。 $\pi_{0.5}$ 的评估结果来源于其官方实现。

8.3. 更多真实世界结果

图 8 展示了表 3 中每个任务的 Motus 执行可视化。包含 AC-One 和 Agilex-Aloha-2 平台上真实世界任务子任务分解的详细结果见表 15 和

Model	Add Condiment	Select Toy	Select Fruit	Avg.
In Distribution				
$\pi_{0.5}$	0.56	0.3	0.42	0.43
Motus	0.63	0.47	0.33	0.48
Cross Category				
$\pi_{0.5}$	0.06	0.24	0.36	0.22
Motus	0.14	0.40	0.20	0.25

表 10. VLABench 上成功率的评估

Component	Configuration
Action Expert	
Hidden Size	1024
Layers	30
Attention Heads	24
Layer Norm Epsilon	1e-5
Activation Function	GELU
Understand Expert	
Hidden Size	512
Layers	30
Attention Heads	24
Layer Norm Epsilon	1e-5
Activation Function	GELU
Latent Action VAE	
λ_a (Action Alignment)	1.0
β (KL Regularization)	1×10^{-6}
Sampling Rate	
Video Frames	8 @ 5Hz
Action Chunk	48 @ 30Hz
Flow Matching	
Inference Steps	10
Sampling Strategy	Logit Normal
Model Scale	
VGM	5.00B
VLM	2.13B
Act. Expert	641.5M
Und. Expert	253.5M
Total	8B

表 11. Motus 架构超参数和关键配置设置。

表 16. 每个子任务前面的数字表示其成功完成所获得的分数。对于叠毛巾任务，我们对每种毛巾类型评估四次。对于抓取立方体任务，我们在域内和域外设置下对每种立方体类型评估五次。

9. 实现细节

9.1. 模型架构

表 11 给出了 Motus 模型架构的关键超参数设置。




图 8. Motus 在真实世界任务执行中的演示，包含 2 个机器人和 9 项任务。

9.2. 数据集

表 12 展示了 Motus 的训练数据。

9.3. 训练配置

表 13 给出了 Motus 三个阶段的详细训练配置。

表 12. 预训练与微调数据集的详细信息。

Dataset	Size	Embodiment	Data Level in the Pyramid
Egodex [24] 230,949 人类级别 2: 以自我为中心的人类视频 Agibot [1] 728,209 Genie-1 机器人级别 5: 多机器人任务轨迹数据 RDT [31] 6,083 Aloha 机器人级别 5: 多机器人任务轨迹数据 RoboMind Franka [48] 9,589 Franka 机器人级别 5: 多机器人任务轨迹数据 RoboMind Aloha [48] 7,272 Aloha 机器人级别 5: 多机器人任务轨迹数据 RoboTwin [14] 27,500 Aloha 机器人级别 3: 合成数据 任务无关数据 [39] 1,000 Aloha 机器人级别 4: 任务无关数据 内部数据 2,000 Aloha 机器人级别 6: 目标机器人任务轨迹数据			

表 13. 三个阶段的训练配置。

Stages	Stage 1	Stage 2	Stage 3
Batch Size	256	256	256
Learning Rate	8×10^{-5}	5×10^{-5}	$1 \sim 5 \times 10^{-5}$
Optimizer	AdamW	AdamW	AdamW
Weight Decay	0.01	0.01	0.01
GPU Hours	~8000	~10000	~400




图 9. Motus 在 AC-One 上的 VGM 模式可视化。

表 14. RoboTwin 2.0 仿真评估（干净与随机化，50+任务）。

Simulation Task	GO-1		$\pi_{0.5}$		X-VLA		w/o Pretrain		Stage1		Motus	
	Clean	Rand.	Clean	Rand.	Clean	Rand.	Clean	Rand.	Clean	Rand.	Clean	Rand.
Adjust Bottle	49%	62%	79%	83%	100%	99%	99%	97%	98%	94%	89%	93%
Beat Block Hammer	6%	10%	63%	50%	92%	88%	88%	90%	88%	82%	95%	88%
Blocks Ranking Rgb	7%	3%	43%	35%	83%	83%	92%	88%	97%	98%	99%	97%
Blocks Ranking Size	2%	2%	8%	14%	67%	74%	38%	50%	73%	68%	75%	63%
Click Alarmclock	95%	90%	97%	93%	99%	99%	100%	99%	100%	100%	100%	100%
Click Bell	98%	95%	75%	76%	100%	100%	100%	100%	100%	100%	100%	100%
Dump Bin Bigbin	57%	45%	30%	42%	79%	77%	94%	96%	98%	96%	95%	91%
Grab Roller	99%	99%	90%	89%	100%	100%	100%	100%	100%	100%	100%	100%
Handover Block	9%	12%	18%	19%	73%	37%	34%	15%	55%	55%	86%	73%
Handover Mic	12%	8%	28%	18%	0%	0%	98%	95%	80%	88%	78%	63%
Hanging Mug	0%	0%	3%	3%	23%	27%	14%	10%	37%	25%	38%	38%
Lift Pot	92%	92%	0%	0%	99%	100%	90%	87%	87%	84%	96%	99%
Move Can Pot	16%	4%	29%	27%	89%	86%	43%	53%	56%	65%	34%	74%
Move Pillbottle Pad	9%	11%	33%	29%	73%	71%	83%	83%	96%	90%	93%	96%
Move Playingcard Away	37%	24%	59%	67%	93%	98%	50%	47%	77%	84%	100%	96%
Move Stapler Pad	3%	4%	16%	18%	78%	73%	49%	37%	75%	68%	83%	85%
Open Laptop	65%	60%	19%	35%	93%	100%	89%	89%	91%	96%	95%	91%
Open Microwave	12%	14%	35%	37%	79%	71%	83%	82%	82%	84%	95%	91%
Pick Diverse Bottles	61%	56%	5%	3%	58%	36%	53%	62%	18%	18%	90%	91%
Pick Dual Bottles	81%	74%	10%	6%	47%	36%	58%	68%	7%	17%	96%	90%
Place A2b Left	33%	36%	62%	60%	48%	49%	78%	79%	93%	82%	88%	79%
Place A2b Right	31%	22%	62%	57%	36%	36%	86%	83%	94%	90%	91%	87%
Place Bread Basket	47%	52%	48%	56%	81%	71%	73%	83%	89%	87%	91%	94%
Place Bread Skillet	2%	1%	38%	46%	77%	67%	71%	71%	86%	87%	86%	83%
Place Burger Fries	88%	92%	66%	70%	94%	94%	95%	90%	97%	99%	98%	98%
Place Can Basket	29%	37%	19%	25%	49%	52%	46%	62%	66%	55%	81%	76%
Place Cans Plasticbox	68%	77%	40%	47%	97%	98%	96%	99%	97%	100%	98%	94%
Place Container Plate	73%	70%	71%	78%	97%	95%	97%	100%	98%	98%	98%	99%
Place Dual Shoes	6%	10%	12%	7%	79%	88%	78%	80%	94%	94%	93%	87%
Place Empty Cup	44%	39%	75%	86%	100%	98%	97%	97%	96%	97%	99%	98%
Place Fan	1%	0%	25%	36%	80%	75%	77%	85%	77%	85%	91%	87%
Place Mouse Pad	15%	10%	21%	26%	70%	70%	62%	68%	72%	69%	66%	68%
Place Object Basket	48%	49%	43%	36%	44%	39%	74%	75%	76%	80%	81%	87%
Place Object Scale	26%	27%	40%	49%	52%	74%	84%	83%	88%	93%	88%	85%
Place Object Stand	56%	63%	74%	65%	86%	88%	91%	93%	93%	96%	98%	97%
Place Phone Stand	30%	37%	49%	53%	88%	87%	80%	78%	76%	86%	87%	86%
Place Shoe	15%	13%	57%	61%	96%	95%	95%	92%	100%	99%	99%	97%
Press Stapler	66%	51%	80%	70%	92%	98%	97%	94%	96%	98%	93%	98%
Put Bottles Dustbin	7%	4%	12%	9%	74%	77%	36%	33%	34%	24%	81%	79%
Put Object Cabinet	60%	43%	24%	15%	46%	48%	84%	64%	97%	87%	88%	71%
Rotate Qrcode	22%	9%	47%	56%	34%	33%	80%	60%	91%	79%	89%	73%
Scan Object	1%	2%	42%	38%	14%	36%	42%	50%	56%	69%	67%	66%
Shake Bottle Horizontally	97%	92%	96%	100%	100%	100%	100%	97%	100%	96%	100%	98%
Shake Bottle	97%	93%	91%	100%	99%	100%	100%	96%	99%	97%	100%	97%
Stack Blocks Three	1%	1%	15%	16%	6%	10%	71%	76%	99%	95%	91%	95%
Stack Blocks Two	12%	22%	48%	56%	92%	87%	96%	94%	99%	99%	100%	98%
Stack Bowls Three	4%	7%	33%	35%	76%	86%	90%	74%	86%	83%	79%	87%
Stack Bowls Two	51%	45%	78%	66%	96%	93%	98%	98%	97%	98%	98%	98%
Stamp Seal	19%	13%	36%	23%	76%	82%	80%	88%	93%	95%	93%	92%
Turn Switch	34%	30%	5%	6%	40%	61%	69%	60%	59%	64%	84%	78%
Average (%)	37.8	36.24	42.98	43.84	72.8	72.84	77.56	77.00	82.26	81.86	88.66	87.02

表 15. AC-One 平台上的真实世界任务及详细子任务分解。

Subgoal	$\pi_{0.5}$	w/o Pretrain	Motus
Fold Towel			
类型：熊图案/蓝黄/紫/红蓝/粉			
0.0: Complete Failure	16	19	13
0.2: Grab both sides	4	1	3
0.5: One fold complete	-	-	3
0.8: Grab the right side	-	-	1
1.0: Two folds complete	-	-	-
Partial Success Rate	4%	1%	14.5%
Grab Cube			
Types: red/orange/green/yellow			
0.0: Complete Failure	7	8	-
0.5: Grab cube	3	-	-
1.0: Put cube into plate	10	12	20
Partial Success Rate	57.5%	60%	100%
Grab Cube			
OOD setting: cube placed outside training space			
0.0: Complete Failure	11	13	4
0.5: Grab cube	1	-	-
1.0: Put cube into plate	4	3	12
Partial Success Rate	28.125%	18.75%	75%
Brew Coffee using Drip Coffee Machine			
0.0: Complete Failure	10	10	2
0.2: Grab the blue cup	-	-	1
0.5: Pour coffee grounds	-	-	-
0.8: Close the lid	-	-	5
1.0: Turn on the switch	-	-	2
Partial Success Rate	0%	0%	62%
Get Water from Water Dispenser			
0.0: Complete Failure	4	9	4
0.4: Grab the orange cup	5	-	4
0.8: Fill the cup with water	-	1	-
1.0: Put down the cup	1	-	2
Partial Success Rate	30%	8%	36%
Grind Coffee Beans with Grinder			
0.0: Complete Failure	9	10	-
0.3: Grab the metal cup	-	-	-
0.8: Pour the coffee beans	1	-	4
1.0: Press the button	-	-	6
Partial Success Rate	8%	0%	92%
Pour Water from Kettle to Flowers			
0.0: Complete Failure	18	18	4
0.5: Grab the black cup	2	2	6
1.0: Pour water	-	-	10
Partial Success Rate	5%	5%	65%
Touch Keyboard with Hand for Multiple Choice Questions			
0.0: Complete Failure	20	-	3
0.5: Use the correct arm	-	-	1
1.0: Press the right key	-	20	16
Partial Success Rate	0%	100%	82.5%

表 16. Agilex-Aloha-2 平台上的真实世界任务及详细子任务分解。

Subgoal	$\pi_{0.5}$	w/o Pretrain	Motus
Fold Towel			
Types: bear-pattern/blue-yellow/purple/red-blue/pink			
0.0: Complete Failure	4	20	5
0.2: Grab both sides	11	-	1
0.5: One fold complete	3	-	12
0.8: Grab the right side	1	-	2
1.0: Two folds complete	1	-	-
Partial Success Rate	27.5%	0%	39%
Grab Cube			
Types: red/orange/green/yellow			
0.0: Complete Failure	2	8	-
0.5: Grab cube	1	8	-
1.0: Put cube into plate	17	4	20
Partial Success Rate	87.5%	40%	100%
Grab Cube			
OOD setting: cube placed outside training space			
0.0: Complete Failure	5	13	11
0.5: Grab cube	-	-	-
1.0: Put cube into plate	11	3	5
Partial Success Rate	68.75%	18.75%	31.25%
Put Bread into Oven			
0.0: Complete Failure	5	10	5
0.2: Open the oven	-	-	-
0.4: Grab the bread	1	-	-
0.6: Put the bread into the oven	-	-	3
0.8: Close the oven	4	-	2
1.0: Spin the button	-	-	-
Partial Success Rate	36%	0%	34%
Pour Water from Kettle to Flowers			
0.0: Complete Failure	2	4	3
0.5: Grab the black cup	18	16	15
1.0: Pour water	-	-	2
Partial Success Rate	45%	40%	47.5%
Touch Keyboard with Hand for Multiple Choice Questions			
0.0: Complete Failure	5	-	-
0.5: Use the correct arm	1	6	8
1.0: Press the right key	14	14	12
Partial Success Rate	72.5%	85%	80%




图 10. Motus 世界模型模式在 Agilex-Aloha-2 数据集上的可视化。




图 11. Motus 世界模型模式在 AC-One 数据集上的可视化。



图 12. Motus 视频-动作联合预测模型模式在真实世界推理中的可视化。