

基于元学习的一次性视觉模仿学习

Chelsea Finn^{*1}, Tianhe Yu^{*1}, Tianhao Zhang¹, Pieter Abbeel^{1,2}, Sergey Levine¹

¹University of California, Berkeley, ²OpenAI

cbfinn, tianhe.yu, tianhao.z, pabbeel, svlevine@berkeley.edu

摘要：为使机器人成为能够执行广泛任务的通用型智能体，它必须能够在复杂的非结构化环境中快速高效地获取多种技能。深度神经网络等高容量模型能够使机器人表示复杂技能，但若每种技能都从头学习则变得不可行。本文提出一种元模仿学习方法，使机器人学会如何更高效地学习，从而仅凭一次演示即可获取新技能。与先前的一次性模仿方法不同，本方法可扩展至原始像素输入，并且学习新技能所需先前任务的数据量显著减少。在仿真与真实机器人平台上的实验表明，机器人能够端到端地从单次视觉演示中学习新任务。

关键词：模仿学习，深度学习，一次性学习，元学习

1 引言

使机器人成为能够对多种物体执行各种任务的通用型智能体，是当前方法面临的一大挑战。基于学习的方法有望提供一种获取广泛技能的通用算法。然而，学习方法通常每个任务需要相当多的监督或经验，尤其是使用深度神经网络模型从原始感官输入学习复杂技能时。此外，大多数方法未提供利用先前任务经验以更快解决新任务的机制。因此，要学习多种技能，必须为每个任务独立收集训练数据。通过跨技能重用数据，机器人应能分摊经验并显著提高数据效率，使每个新技能所需的监督最小化。本文探讨的问题是：如何利用先前技能的信息来快速学习新行为？

本文提出将元学习与模仿相结合，使机器人能够复用过往经验，从而从单次演示中学习新技能。与以往将任务标识 [1, 2, 3, 4] 或演示 [5] 作为上下文策略输入的方法不同，本文方法学习一种参数化策略，可通过梯度更新适应不同任务，从而有效地学会模仿学习。因此，可学习的技能集合更加灵活，同时使用的总参数更少。本文首次证明，基于视觉的策略可以通过一次演示进行端到端微调，将元学习作为预训练过程，利用其他多种环境中的演示。

本文的主要贡献是展示一种从原始像素进行单次模仿学习的方法。我们在两个模拟平面到达任务、模拟推动任务以及真实机器人上的视觉放置任务中评估了该方法（见图 1）。本文方法能够学习视觉运动策略，仅通过一次视觉演示即可适应新的任务变体，包括仅有演示的原始视频而无法获取演示者施加的控制量的情况。




图 1：机器人通过单次演示学习将新物体放入新容器中。

^{*}表示同等贡献

通过采用参数高效的元学习方法，本文方法所需的元学习演示数量相对较少，并能扩展到原始像素输入。因此，该方法可成功应用于真实机器人系统。

2 相关工作

本文提出一种将模仿学习 (Imitation Learning) [6] 与元学习 (Meta-Learning) [7] 相结合的方法，用于从视觉演示中进行单样本学习。在环境状态 (如物体姿态) 已知的场景中，利用少量演示进行高效模仿已取得成功 [8, 9, 10, 11]。本文聚焦于环境状态未知的场景，此时必须从原始感官输入中学习。这消除了对预定义视觉系统的需求，同时使该方法适用于未知动态环境中基于视觉的非抓取操作。从原始像素进行模仿学习已在移动机器人领域得到广泛研究 [12, 13, 14, 15]。然而，当应用于现实世界场景时，从演示中学习面临两大挑战。第一个是广泛研究的复合误差问题 [16, 17, 15]，本文不予讨论。第二个是每个任务需要大量演示。后一局限性是开发能够通过模仿学习各种任务的通用机器人的主要障碍。逆强化学习 (Inverse Reinforcement Learning) [18] 可以通过推断一组演示背后的奖励函数来减少所需演示数量。然而，这需要额外的机器人经验来优化奖励 [19, 20, 21]。这些经验通常来自试错学习或用于学习模型的数据。

本文通过跨任务共享数据，大幅减少单个任务所需的演示数量。具体而言，本文的目标是利用其他众多任务的演示数据集进行元学习，从而仅凭新任务的一次演示即可学会该任务。跨任务共享信息并非新思路，例如利用任务间映射 [22]、门控机制 [23] 以及共享特征 [24]。这些多任务机器人学习方法考虑的是从任务的某种规范泛化到新任务的问题。一种常见方法 (通常称为上下文策略) 是将任务作为策略或价值函数的输入，其中任务被表示为目标或演示 [1, 2, 4, 3, 5]。另一种方法是针对多种任务训练控制器，并学习从任务表示到控制器参数的映射 [10, 25, 26]。本文则采用元学习，使机器人能够通过基于梯度的策略更新快速学习新任务。本质上，本文学习到的策略参数在仅用新任务的一次演示进行微调后，即可立即学会执行该任务。这使得机器人能够以极高的效率端到端地学习新任务，仅需一次演示，无需任何额外机制 (如上下文或学习到的更新函数)。

3 元模仿学习问题表述

本节介绍视觉元模仿学习问题，其中基于视觉的策略必须从单次演示中适应新任务。同时总结一种先前的元学习方法，将在第 4 节扩展为元模仿学习算法。

3.1 问题陈述

本文的目标是学习一种策略，能够从新任务的单次演示中快速适应。为消除对大量任务特定演示数据的需求，本文提出复用其他多个任务的演示数据，以实现新任务的高效学习。通过跨任务训练适应能力，元学习实际上将整个任务视为数据点。每个单独任务可用的数据量相对较小。在机器人学背景下，这正是开发通用机器人所需的能力——为机器人应执行的每个新任务提供少量监督。本节将正式定义单次模仿学习问题陈述并引入符号。

我们考虑一个策略 π ，它将观测 $\mathbf{o}$ 映射到预测动作 $\hat{\mathbf{a}}$ 。在元学习过程中，该策略被训练以适应大量任务。形式上，每个模仿任务 $\mathcal{T}_i = \{\tau = \{\mathbf{o}_1, \mathbf{a}_1, \dots, \mathbf{o}_T, \mathbf{a}_T\} \sim \pi_i^*, \mathcal{L}(\mathbf{a}_{1:T}, \hat{\mathbf{a}}_{1:T}), T\}$ 由演示数据 τ 组成，这些数据由

Algorithm 1 Meta-Imitation Learning with MAML

Require: $p(\mathcal{T})$: distribution over tasks

Require: α, β : step size hyperparameters

```
1: randomly initialize  $\theta$ 
2: while not done do
3:   Sample batch of tasks  $\mathcal{T}_i \sim p(\mathcal{T})$ 
4:   for all  $\mathcal{T}_i$  do
5:     Sample demonstration  $\tau = \{\mathbf{o}_1, \mathbf{a}_1, \dots, \mathbf{o}_T, \mathbf{a}_T\}$  from  $\mathcal{T}_i$ 
6:     Evaluate  $\nabla_{\theta} \mathcal{L}_{\mathcal{T}_i}(f_{\theta})$  using  $\tau$  and  $\mathcal{L}_{\mathcal{T}_i}$  in Equation (2)
7:     Compute adapted parameters with gradient descent:  $\theta'_i = \theta - \alpha \nabla_{\theta} \mathcal{L}_{\mathcal{T}_i}(f_{\theta})$ 
8:     Sample demonstration  $\tau'_i = \{\mathbf{o}'_1, \mathbf{a}'_1, \dots, \mathbf{o}'_T, \mathbf{a}'_T\}$  from  $\mathcal{T}_i$  for the meta-update
9:   end for
10:  Update  $\theta \leftarrow \theta - \beta \nabla_{\theta} \sum_{\mathcal{T}_i \sim p(\mathcal{T})} \mathcal{L}_{\mathcal{T}_i}(f_{\theta'_i})$  using each  $\tau'_i$  and  $\mathcal{L}_{\mathcal{T}_i}$  in Equation 2
11: end while
12: return parameters  $\theta$  that can be quickly adapted to new tasks through imitation.
```

专家策略 π_i^* 和用于模仿的损失函数 $\mathcal{L}$ 生成。反馈由损失函数 $\mathcal{L}(\mathbf{a}_1, \dots, \mathbf{a}_T, \hat{\mathbf{a}}_1, \dots, \hat{\mathbf{a}}_T) \rightarrow \mathbb{R}$ 提供，对于连续动作可能是均方误差，对于离散动作可能是交叉熵损失。

在我们的元学习场景中，我们考虑任务上的分布 $p(\mathcal{T})$ 。在单样本学习设置中，策略被训练以仅从 $\mathcal{T}_i$ 生成的一个演示中学习从 $p(\mathcal{T})$ 抽取的新任务 $\mathcal{T}_i$ 。在元训练期间，从 $p(\mathcal{T})$ 中采样任务 $\mathcal{T}_i$ ，使用来自专家 π_i^* 在 $\mathcal{T}_i$ 上的一个演示训练策略，然后根据损失 $\mathcal{L}$ 在来自 π_i^* 的新演示上测试，以确定其训练和测试误差。然后通过考虑新演示上的测试误差如何随参数变化来改进策略 π 。因此，来自 π_i^* 的采样演示上的测试误差作为元学习过程的训练误差。在元训练结束时，从 $p(\mathcal{T})$ 中采样新任务，元性能通过策略在从一个演示学习后的性能来衡量。用于元测试的任务在元训练期间被保留。

3.2 背景：模型无关元学习

在我们的视觉元模仿学习方法中，我们将使用元学习，通过将模型无关元学习（MAML）[27] 扩展到视觉输入的元模仿学习，来训练跨多个任务的快速适应。此前，MAML 已应用于少样本图像识别和强化学习。MAML 算法旨在学习模型 f_{θ} 的权重 θ ，使得标准梯度下降能够在从 $p(\mathcal{T})$ 抽取的新任务 $\mathcal{T}$ 上快速取得进展，而不会对少量示例过拟合。由于该方法使用梯度下降作为优化器，它不会引入任何额外参数，因此比其他元学习方法更具参数效率。当适应新任务 $\mathcal{T}_i$ 时，模型的参数 θ 变为 θ'_i 。在 MAML 中，更新后的参数向量 θ'_i 是通过在任务 $\mathcal{T}_i$, i.e. $\theta'_i = \theta - \alpha \nabla_{\theta} \mathcal{L}_{\mathcal{T}_i}(f_{\theta})$ 上执行一次或多次梯度下降更新来计算的。为了符号简洁，本节其余部分将考虑一次梯度更新，但使用多次梯度更新是直接的扩展。

模型参数通过优化 $f_{\theta'_i}$ 相对于 θ 的性能来训练，任务从 $p(\mathcal{T})$ 中采样，对应以下问题：

$$\min_{\theta} \sum_{\mathcal{T}_i \sim p(\mathcal{T})} \mathcal{L}_{\mathcal{T}_i}(f_{\theta'_i}) = \sum_{\mathcal{T}_i \sim p(\mathcal{T})} \mathcal{L}_{\mathcal{T}_i}(f_{\theta - \alpha \nabla_{\theta} \mathcal{L}_{\mathcal{T}_i}(f_{\theta})}) \quad (1)$$

注意，元优化是在参数 θ 上进行的，而目标函数使用更新后的参数 θ' 计算。实际上，MAML 旨在优化模型参数，使得在新任务上进行一个或少量梯度步骤就能在该任务上产生最大有效行为。跨任务的元优化使用随机梯度下降（SGD）。

4 基于 MAML 的元模仿学习

在本节中，我们描述如何将模型无关的元学习算法（MAML）扩展到模仿学习场景。模型的输入 $\mathbf{o}_t$ 是智能体在

时间 t ，例如图像，而输出 $\mathbf{a}_t$ 是在时间 t 采取的动作，例如施加到机器人关节的扭矩。我们将演示轨迹表示为 $\tau := \{\mathbf{o}_1, \mathbf{a}_1, \dots, \mathbf{o}_T, \mathbf{a}_T\}$ ，并使用均方误差损失作为策略参数 ϕ 的函数，如下所示：

$$\mathcal{L}_{\mathcal{T}_i}(f_\phi) = \sum_{\tau^{(j)} \sim \mathcal{T}_i} \sum_t \|f_\phi(\mathbf{o}_t^{(j)}) - \mathbf{a}_t^{(j)}\|_2^2. \quad (2)$$

我们主要考虑单样本情况，即仅使用单个演示 $\tau^{(j)}$ 进行梯度更新。然而，我们也可以使用多个演示来消除歧义。

对于元学习，我们假设一个演示数据集，每个任务至少有两个演示。这些数据仅在元训练期间使用；元测试时每个新任务仅假设一个演示。在元训练期间，每个元优化步骤包括以下内容：采样一批任务，每个任务采样两个演示。使用其中一个演示，通过方程 2 的梯度下降为每个任务 $\mathcal{T}_i$ 计算 θ'_i 。然后，使用每个任务的第二个演示，通过方程 1 和方程 2 中的损失计算元目标的梯度。最后，根据元目标的梯度更新 θ 。实际上，这对演示充当训练-验证对。算法总结在算法 1 中。

元训练的结果是一个可以使用单个演示适应新任务的策略。因此，在元测试时，采样一个新任务 $\mathcal{T}$ ，提供该任务的一个演示，并更新模型以获得该任务的策略。在元测试期间，新任务可能涉及新目标或操作新的、以前未见过的物体。

4.1 双头架构：元学习损失以实现快速适应

在之前概述的标准模型无关元学习 (MAML) 设置中，策略在梯度更新前后阶段保持一致。然而，我们可以进行修改，使网络最后几层的参数不共享，形成两个“头”，如图 2 所示。预更新头的参数不用于最终的更新后策略，而更新后头的参数不使用演示进行更新。但是，两组参数都经过元学习，以便在适应后实现有效性能。有趣的是，这种双头架构相当于在元优化中使用不同的内部目标，同时保持相同的外部目标。为了说明这一点，令 $\mathbf{y}_t^{(j)}$ 表示最后一个隐藏层的突触后激活集合， W 和 b 表示最后一层的权重矩阵和偏置。则内部损失函数由下式给出：

$$\mathcal{L}_{\mathcal{T}_i}^*(f_\phi) = \sum_{\tau^{(j)} \sim \mathcal{T}_i} \sum_t \|W\mathbf{y}_t^{(j)} + b - \mathbf{a}_t^{(j)}\|_2^2, \quad (3)$$

其中 W 和 b ，即最后一层的权重和偏置，实际上构成了元学习损失函数的参数。我们使用元学习损失函数 $\mathcal{L}_{\mathcal{T}_i}^*$ 通过梯度下降计算每个任务 $\mathcal{T}_i$ 的适应参数 θ'_i 。然后，元目标变为：

$$\min_{\theta, W, b} \sum_{\mathcal{T}_i \sim p(\mathcal{T})} \mathcal{L}_{\mathcal{T}_i}(f_{\theta'_i}) = \sum_{\mathcal{T}_i \sim p(\mathcal{T})} \mathcal{L}_{\mathcal{T}_i}(f_{\theta - \alpha \nabla_{\theta} \mathcal{L}_{\mathcal{T}_i}^*(f_{\theta})}). \quad (4)$$

这为算法在如何将策略参数适应到专家演示方面提供了更大的灵活性，我们发现这在一些实验中提高了性能（见附录 A.3）。然而，使用学习到的损失函数更有趣的启示是，我们可以在单次适应过程中省略动作，正如我们接下来讨论的那样。

4.2 无需专家动作的学习模仿

传统上，演示轨迹由观测和动作对组成，正如我们在第 4 节中讨论的那样。然而，在许多场景中，更实用的做法是仅提供任务执行的视频，例如由人类或另一台机器人执行。本文考虑的一个步骤是，在测试时消除对机器人手臂轨迹和动作的需求。¹ 不过，需要明确的是，我们假设在元训练期间可以访问专家动作。在测试时无法访问专家动作的情况下，单次适应的损失函数应该是什么并不明确。因此，我们将如前一节所述，元学习一个损失函数。我们可以简单地通过移除专家动作来修改方程 3 中的损失：

$$\mathcal{L}_{\mathcal{T}_i}^*(f_\phi) = \sum_{\tau^{(j)} \sim \mathcal{T}_i} \sum_t \|W\mathbf{y}_t^{(j)} + b\|_2^2,$$

¹ 我们将领域偏移问题（例如人类视频与机器人视角之间的差异）留待未来工作。




图 2: 带有偏差变换（顶部和底部）和两个头（底部）的策略架构示意图。绿色箭头和方框表示属于元学习策略参数 θ 的权重。

这对应于在最后一层激活上学习到的二次损失函数，其参数为 W 和 b 。然而，在实践中，损失函数可能更为复杂。利用该损失函数，我们可以通过方程 4 中的元优化目标，从演示的原始观测中学会学习，如第 6.2 节和第 6.3 节的实验所示。

5 元模仿学习的模型架构

我们使用卷积神经网络（CNN）来表示策略，类似于先前的基于视觉的模仿学习和元学习方法 [13, 27]。策略观测包括相机图像和机器人配置，例如关节角度和末端执行器位姿。本节概述策略架构，细节将在第 6 节讨论。该策略由若干步长卷积组成，后接修正线性单元（ReLU）非线性。最后一个卷积层通过空间软最大（spatial soft-argmax）[28, 29] 转换为空间特征点，并与机器人配置拼接。结果通过一组带修正线性单元（ReLU）非线性的全连接层。由于演示轨迹内的数据在时间上高度相关，批归一化效果不佳。因此，我们在每层之后使用层归一化 [30]。

尽管元模仿学习在标准策略架构（如上述架构）上表现良好，但元学习的最优架构并不一定等同于标准监督模仿学习的最优架构。我们发现，一种能提升元学习性能的特定修改是：将参数向量与突触后激活的隐藏层进行拼接，从而形成我们称之为偏差变换的结构。在元学习和测试时自适应过程中，该参数向量与策略中的其他参数同等对待。形式上，设参数向量为 $\mathbf{z}$ ，突触后激活为 $\mathbf{x}$ ，下一层的突触前激活为 $\mathbf{y}$ 。标准神经网络架构设定 $\mathbf{y} = W\mathbf{x} + b$ ，其中偏差为 b ，权重矩阵为 W 。相对于标准 $\frac{d\mathcal{L}}{db}$ 的误差梯度等于相对于 y ， $\frac{d\mathcal{L}}{dy}$ 的误差梯度 $\frac{d\mathcal{L}}{dy}$ 。因此，标准偏差的梯度更新与权重矩

阵 W 及网络前层参数的更新直接耦合。接下来描述的偏差变换通过消除这种耦合，为更新后的偏差提供了更强的控制能力。采用偏差变换后，我们设定 $\mathbf{y} = W_1\mathbf{x} + W_2\mathbf{z} + b$ ，其中 $W = [W_1, W_2]$ 和 b 分别为权重矩阵和偏差。首先，注意到包含 $\mathbf{z}$ 和 W_2 仅相当于对偏差进行重新参数化，即 $\tilde{b} = W_2\mathbf{z} + b$ ，因为 $W_2\mathbf{z}$ 和 b 均不依赖于输入。相对于 $\mathbf{z}$ 和 W_2 的误差梯度为： $\frac{d\mathcal{L}}{dW_2} = \frac{d\mathcal{L}}{dy}\mathbf{z}^T$ 以及 $\frac{d\mathcal{L}}{d\mathbf{z}} = W_2^T \frac{d\mathcal{L}}{dy}$ 。经过一步梯度更新后，更新后的变换偏差为： $\tilde{b}' = (W_2 - \alpha \frac{d\mathcal{L}}{dy}\mathbf{z}^T)(\mathbf{z} - \alpha W_2^T \frac{d\mathcal{L}}{dy}) + b - \alpha \frac{d\mathcal{L}}{dy}$ 。因此，对变换偏差的梯度更新可以更直接地由 W_2 和 $\mathbf{z}$ 的值控制，而这些值不会直接影响网络中其他参数的梯度。为了说明网络可能选择控制偏差的一种方式，考虑 $\mathbf{z}$ 和 b 均为零的情形。此时，更新后的偏差为： $\tilde{b}' = -\alpha W_2 W_2^T \frac{d\mathcal{L}}{dy} - \alpha \frac{d\mathcal{L}}{dy}$ 。总之，偏差变换在不影响网络本身表示能力的前提下，增强了梯度的表示能力。在我们的实验中，我们发现这一简单添加使得基于梯度的元学习显著更加稳定和有效。我们在图 2 中展示了带有偏差变换的策略架构示意图。




图 3: 从策略视角展示的示例任务。顶行中, 每对图像分别展示演示的起始场景与最终场景。底行则展示学习策略执行时对应的场景。左图: 在给定一次到达特定颜色目标的演示后, 策略必须学会在新环境中到达相同颜色的目标。中图: 机器人在观看不同场景中将同一物体推向目标的演示后, 将该目标物体推至目标位置。右图: 我们提供将物体放置在目标上的演示, 随后机器人必须在新环境中将物体放置在相同目标上。

6 实验

实验评估的目标是回答以下问题: (1) 我们的方法能否仅通过一次任务演示, 学会从图像像素到动作的策略映射? (2) 在不同数据集规模下, 我们的元模仿学习方法与先前的一次性模仿学习方法相比表现如何? (3) 我们能否在没有专家动作的情况下学会学习? (4) 我们的方法在真实图像的真实机器人任务中扩展性如何?

我们在三个实验领域评估一次性模仿学习方法。在每个设置中, 我们将所提出的方法与以下方法子集进行比较:

- **随机策略:** 一种从标准正态分布中输出随机动作的策略。
- **上下文策略:** 一种前馈策略, 以演示的最终图像作为输入以指示任务目标, 并结合当前图像, 输出当前动作。
- **长短期记忆网络 (LSTM):** 一种循环神经网络, 其接收所提供的演示和当前观测, 并输出当前动作, 由段等人提出。[5]。
- **长短期记忆网络 (LSTM) + 注意力机制:** 一种采用段等人提出的注意力架构的循环神经网络 [5]。该方法仅适用于非视觉任务。

上下文策略、长短期记忆网络 (LSTM) 策略以及本文所提方法均使用相同的数据集和相同的监督方式进行训练。所有策略, 包括本文所提方法, 均通过行为克隆目标 (均方误差) 进行元训练, 并使用专家动作作为监督, 采用默认超参数的 Adam 优化器 [31]。

6.1 模拟到达任务

第一个实验域是一系列平面到达任务, 如图 3 所示, 其中特定任务的目标是在两个不同颜色的干扰物中到达特定颜色的目标。该模拟域使我们能够严格评估本文方法, 并与先前方法和基线进行比较。我们考虑了该任务的视觉和非视觉变体, 以便能够直接与不适用于基于视觉策略的先前方法进行比较。有关实验设置和超参数选择的更多细节, 请参见附录 A.1。

我们在不同规模的元训练数据集上评估每种方法, 并在图 4 中展示了一次性模仿成功率。在视觉条件下, 我们发现元模仿学习能够处理原始像素输入, 而长短期记忆网络 (LSTM) 和上下文策略在使用中等规模的元学习数据集时难以学习新任务。在非视觉条件下, 由于涉及的参数少得多, 长短期记忆网络 (LSTM) 策略表现好得多, 尤其是在使用注意力机制时, 但仍不如元模仿学习 (MIL)。先前工作使用 10,000 个或更多演示来展示这些方法 [5]。因此, 这些方法在规模小得多的数据集上表现平庸并不令人意外。我们还提供了使用和不使用第 5 节讨论的偏置变换的比较。结果表明, 带有偏置变换 (bt) 的元模仿学习 (MIL) 在不同数据集规模下表现更为一致。




图 4: 模拟领域中单次成功率随元学习数据集规模的变化。我们的元模仿学习方法 (MIL) 在多种数据集规模下均表现良好, 且相比先前将目标图像 (上下文) 或演示 (LSTM) 作为输入的方法, 能更有效地学习新任务。随机策略达到 25.7% 的到达成功率和 0.45% 的推动成功率。策略视频见补充视频³。

6.2 模拟推动

第二组实验的目标是在具有挑战性的领域评估我们的方法, 该领域涉及 7 自由度力矩控制、3D 环境以及任务间显著更多的物理和视觉多样性。实验包含一系列模拟桌面推动任务, 如图 3 所示, 目标是在一个干扰物存在的情况下, 将随机起始位置的特定物体推到红色目标处。我们基于 OpenAI Gym PusherEnv 设计推动环境, 使用 MuJoCo 物理引擎 [32, 33]。我们修改环境以包含两个物体、视觉策略输入, 并在任务间涵盖广泛的物体形状、尺寸、纹理、摩擦和质量。我们从 thingiverse.com 选取了 116 个网格形状, 其中 105 个用于元训练, 11 个用于评估。这些网格包括棋子模型、泰迪熊和河豚等动物模型以及其他杂项形状。我们从超过 5000 张图像中随机采样纹理, 并使用留出纹理进行元测试。部分物体和纹理如图 5 所示。更多实验细节、超参数和消融研究见附录 A.2。


图 4 展示了留出物体上的单次推动性能, 表明 MIL 有效学会了学习推动新物体, 在最大数据集规模下达到 85.8% 的单次学习成功率。此外, MIL 在不同数据集规模下平均比基于 LSTM 的方法高出 6.5% 的成功率。上下文策略表现不佳, 可能是因为完整演示轨迹信息对于推断目标物体的摩擦和质量具有信息量。

在表 1 中, 我们使用最大数据集规模提供了两项额外评估。第一项评估考察每种方法如何处理信息较少的输入演示, 例如缺少动作和/或机器人手臂状态。为此, 我们训练每种方法使其能够处理此类演示, 如第 4.2 节所述。我们发现长短期记忆网络方法在没有专家动作的情况下学习困难。多实例学习也出现性能下降, 但下降幅度较小。第二项评估表明, 如果提供五个演示而非一个, 所有方法都能提升性能, 尽管所有策略都是为单次学习训练的。在这种情况下, 对于上下文方法和长短期记忆网络方法, 我们对五个输入演示的预测动作取平均, 对于多实例学习则对梯度取平均。

6.3 真实世界放置

我们最终实验的目标是评估真实机器人从单个视觉演示中学习如何与新未知物体交互的能力。处理未见过的物体对于基于学习和非基于学习的操作方法都是一个挑战, 但却是机器人在非结构化真实环境中执行多样化任务的必要条件。实际上, 大多数机器人学习方法关注的是更狭义的泛化概念, 例如

³For video results, see <https://sites.google.com/view/one-shot-imitation>



训练物体子集 测试物体子集 训练物体子集 测试物体子集 图 5: 模拟推动 (左) 和真实世界放置 (右) 实验中使用的训练和测试物体。注意, 我们仅展示了用于推动和放置实验的 ~ 100 训练物体的一个子集, 以及用于训练和测试机器人推动的纹理和物体尺度的一个子集。

变化的目标物体位置 [28] 或块堆叠顺序 [5]。基于这一目标, 我们设计了一个机器人放置实验, 使用 7 自由度 PR2 机器人手臂和 RGB 相机, 目标是将手持物品放入目标容器 (如杯子、盘子或碗) 中, 同时忽略两个干扰物。我们收集了约 1300 个演示用于元训练, 使用了多种物体, 并使用留出的未见过的物体评估单次学习 (见图 5)。策略被提供单个视觉演示, 展示将手持物品放置到目标上, 但目标和干扰物的位置有所变化, 如图 3 所示。演示通过人类遥操作使用运动控制器和虚拟现实头显收集, 每个演示包括相机视频、末端执行器姿态序列和动作序列——末端执行器的线速度和角速度。有关数据收集、评估和超参数的更多说明, 请参见附录 A.3。

表 2 中的结果表明, MIL 策略能够学习定位之前未见过的目标物体, 并以 90% 的成功率将手持物品成功放置到目标上, 仅使用一个

这些物体的单个视觉演示。我们发现 LSTM 和上下文策略无法定位正确的目标物体, 可能是由于元训练数据集规模适中, 而是放置到任意物体上, 达到 25% 的成功率。使用 4.2 节中描述的双头方法, 我们还尝试仅提供演示的视频, 省略机器人末端执行器轨迹和控制。MIL 也能学习处理这种设置, 尽管成功率较低, 这表明需要更多数据和/或进一步研究。我们在补充视频 4 中包含了所有放置策略的视频。

method	test performance
LSTM	25%
contextual	25%
MIL	90%
MIL, video only	68.33%

表 2: 使用真实 PR2 机器人, 将手持物品放入正确容器的单次成功率, 使用 29 个留出的测试物体。元训练使用了包含 ~ 100 个物体的数据集。仅使用视频的 MIL 只接收演示的视频部分, 而不接收手臂轨迹或动作。

7 讨论与未来工作

我们提出了一种单次视觉模仿学习方法, 能够仅通过一次演示的视觉输入学会执行任务。我们的方法将基于梯度的元学习扩展到模仿学习场景, 实验评估表明, 其性能显著优于先前基于循环神经网络的单次模仿学习方法。基于梯度的元学习使我们的方法在元训练阶段所需的演示数量上更加高效, 这种高效性也使我们能够使用原始像素输入并在真实机器人系统上对该方法进行评估。

元模仿学习的使用能够在不牺牲端到端训练的灵活性和通用性的前提下, 大幅提升机器人学习方法的效率, 这对于学习具有复杂感官输入 (如图像) 的技能尤其有价值。虽然我们的实验评估所使用的任务多样性有限 (除物体多样性外), 但我们预期随着元训练阶段提供更多样化的演示, 该方法的能力将显著增强。由于元学习算法能够整合所有可用任务的演示数据, 它们为在机器人学习场景中利用大规模数据集提供了一条自然途径, 使机器人不仅能在获得更多演示时学习更多技能, 而且能通过这一过程实际变得更快、更有效地学习新技能。

⁴For video results, see <https://sites.google.com/view/one-shot-imitation>

致谢

本研究得到了美国国家科学基金会（项目编号 IIS-1651843、IIS-1614653、IIS-1637443）及研究生研究奖学金、伯克利 DeepDrive、海军研究办公室 PECASE 奖（编号 N000141612723）以及海军研究办公室青年研究者计划奖的支持。作者感谢 Yan Duan 提供 [5] 的参考实现，并感谢匿名审稿人提供的反馈意见。

参考文献

- [1] M. P. Deisenroth, P. Englert, J. Peters, and D. Fox. Multi-task policy search for robotics. In *International Conference on Robotics and Automation (ICRA)*, 2014.
- [2] A. G. Kupcsik, M. P. Deisenroth, J. Peters, G. Neumann, et al. Data-efficient generalization of robot skills with contextual policy search. In *AAAI Conference on Artificial Intelligence*, 2013.
- [3] T. Schaul, D. Horgan, K. Gregor, and D. Silver. Universal value function approximators. In *International Conference on Machine Learning (ICML)*, 2015.
- [4] F. Stulp, G. Raiola, A. Hoarau, S. Ivaldi, and O. Sigaud. Learning compact parameterized skills with a single regression. In *International Conference on Humanoid Robots*, 2013.
- [5] Y. Duan, M. Andrychowicz, B. Stadie, J. Ho, J. Schneider, I. Sutskever, P. Abbeel, and W. Zaremba. One-shot imitation learning. *arXiv preprint arXiv:1703.07326*, 2017.
- [6] S. Schaal, A. Ijspeert, and A. Billard. Computational approaches to motor learning by imitation. *Philosophical Transactions of the Royal Society of London B: Biological Sciences*, 2003.
- [7] S. Thrun and L. Pratt. *Learning to learn*. Springer Science & Business Media, 1998.
- [8] A. Billard, Y. Epars, S. Calinon, S. Schaal, and G. Cheng. Discovering optimal imitation strategies. *Robotics and autonomous systems*, 2004.
- [9] S. Schaal, J. Peters, J. Nakanishi, and A. Ijspeert. Learning movement primitives. *Robotics Research*, 2005.
- [10] P. Pastor, H. Hoffmann, T. Asfour, and S. Schaal. Learning and generalization of motor skills by learning from demonstration. In *International Conference on Robotics and Automation (ICRA)*, 2009.
- [11] N. Ratliff, J. A. Bagnell, and S. S. Srinivasa. Imitation learning for locomotion and manipulation. In *International Conference on Humanoid Robots*, 2007.
- [12] D. Pomerleau. ALVINN: an autonomous land vehicle in a neural network. In *Advances in Neural Information Processing Systems (NIPS)*, 1989.
- [13] M. Bojarski, D. Del Testa, D. Dworakowski, B. Firner, B. Flepp, P. Goyal, L. Jackel, M. Monfort, U. Muller, J. Zhang, X. Zhang, J. Zhao, and K. Zieba. End to end learning for self-driving cars. *arXiv preprint arXiv:1604.07316*, 2016.
- [14] A. Giusti, J. Guzzi, D. C. Cireşan, F.-L. He, J. P. Rodríguez, F. Fontana, M. Faessler, C. Forster, J. Schmidhuber, G. Di Caro, et al. A machine learning approach to visual perception of forest trails for mobile robots. *IEEE Robotics and Automation Letters*, 2016.
- [15] J. Zhang and K. Cho. Query-efficient imitation learning for end-to-end simulated driving. In *AAAI Conference on Artificial Intelligence*, 2017.
- [16] S. Ross, G. J. Gordon, and D. Bagnell. A reduction of imitation learning and structured prediction to no-regret online learning. In *AISTATS*, 2011.
- [17] M. Laskey, S. Staszak, W. Y.-S. Hsieh, J. Mahler, F. T. Pokorny, A. D. Dragan, and K. Goldberg. Shiv: Reducing supervisor burden in dagger using support vectors for efficient learning from demonstrations in high dimensional state spaces. In *International Conference on Robotics and Automation (ICRA)*, 2016.

- [18] A. Y. Ng, S. J. Russell, et al. Algorithms for inverse reinforcement learning. In *International Conference on Machine Learning (ICML)*, 2000.
- [19] C. Finn, S. Levine, and P. Abbeel. Guided cost learning: Deep inverse optimal control via policy optimization. In *International Conference on Machine Learning (ICML)*, 2016.
- [20] A. Nair, P. Agarwal, D. Chen, P. Isola, P. Abbeel, and S. Levine. Combining self-supervised learning and imitation for vision-based rope manipulation. *International Conference on Robotics and Automation (ICRA)*, 2017.
- [21] P. Sermanet, K. Xu, and S. Levine. Unsupervised perceptual rewards for imitation learning. *Robotics: Science and Systems (RSS)*, 2017.
- [22] S. Barrett, M. E. Taylor, and P. Stone. Transfer learning for reinforcement learning on a physical robot. In *Ninth International Conference on Autonomous Agents and Multiagent Systems-Adaptive Learning Agents Workshop (AAMAS-ALA)*, 2010.
- [23] K. Mülling, J. Kober, O. Kroemer, and J. Peters. Learning to select and generalize striking movements in robot table tennis. *The International Journal of Robotics Research (IJRR)*, 2013.
- [24] A. Gupta, C. Devin, Y. Liu, P. Abbeel, and S. Levine. Learning invariant feature spaces to transfer skills with reinforcement learning. *International Conference on Learning Representations (ICLR)*, 2017.
- [25] J. Kober, A. Wilhelm, E. Oztop, and J. Peters. Reinforcement learning to adjust parametrized motor primitives to new situations. *Autonomous Robots*, 2012.
- [26] B. C. Da Silva, G. Konidaris, and A. G. Barto. Learning parameterized skills. In *International Conference of Machine Learning (ICML)*, 2012.
- [27] C. Finn, P. Abbeel, and S. Levine. Model-agnostic meta-learning for fast adaptation of deep networks. *International Conference on Machine Learning (ICML)*, 2017.
- [28] S. Levine, C. Finn, T. Darrell, and P. Abbeel. End-to-end learning of deep visuomotor policies. *Journal of Machine Learning Research (JMLR)*, 2016.
- [29] C. Finn, X. Y. Tan, Y. Duan, T. Darrell, S. Levine, and P. Abbeel. Deep spatial autoencoders for visuomotor learning. In *International Conference on Robotics and Automation (ICRA)*, 2016.
- [30] J. L. Ba, J. R. Kiros, and G. E. Hinton. Layer normalization. *arXiv preprint arXiv:1607.06450*, 2016.
- [31] D. Kingma and J. Ba. Adam: A method for stochastic optimization. *International Conference on Learning Representations (ICLR)*, 2015.
- [32] G. Brockman, V. Cheung, L. Pettersson, J. Schneider, J. Schulman, J. Tang, and W. Zaremba. Openai gym. *arXiv preprint arXiv:1606.01540*, 2016.
- [33] E. Todorov, T. Erez, and Y. Tassa. Mujoco: A physics engine for model-based control. In *International Conference on Intelligent Robots and Systems (IROS)*, 2012.

A 补充实验细节

在本节中，我们为所有实验提供补充实验细节，包括数据收集、评估和训练超参数的相关信息。

A.1 仿真抓取任务

实验设置：在本实验的视觉与无视觉两种情况下，策略的输入均包括机械臂关节角度和末端执行器位置。在视觉变体中， 80×64 RGB 图像也作为输入提供。在无视觉版本中，物体的二维位置被输入策略，但状态向量中目标物体的索引未知，必须从演示中推断。策略输出对应于施加在机械臂两个关节上的扭矩。若策略执行在最后 10 个时间步内到达目标 0.05 米范围内，则视为成功，其中场地大小为 0.6×0.6 米。

为获得该任务的专家策略，我们使用 iLQG 轨迹优化为每个任务生成解（利用目标知识），然后从所得策略中收集若干带注入高斯噪声的演示。在元测试时，我们在 150 个任务上评估策略，每个任务进行 10 次不同试验（共 1500 次试验），每个任务对应一种保留颜色。注意，元测试时提供的演示通常涉及与对应测试试验不同的目标和干扰物位置。因此，单样本学习策略必须利用演示定位目标并泛化到新位置，而元训练必须学会处理不同颜色。

超参数：对于所有基于视觉的策略，我们使用卷积神经网络策略，包含 3 个卷积层，每层有 403×3 个滤波器，随后是 4 个隐藏维度为 200 的全连接层。仅在此领域，我们直接将最终卷积图展平，而非将其转换为空间特征点。循环策略额外使用一个具有 512 个单元的 LSTM，其输入为最终层的特征。对于无视觉策略，我们使用相同架构但不含卷积层，将卷积层的输出替换为状态输入。所有方法均使用元批量大小为 5 个任务进行训练。使用元模仿学习训练的策略采用 1 次元梯度更新，步长为 0.001，并使用维度为 10 的偏差变换。我们还发现在应用元梯度前将其裁剪到区间 $[-20, 20]$ 内是有帮助的。我们使用如图 2 所示的常规单头架构进行 MIL。

A.2 模拟推动

实验设置：策略输入包括一个 125×125 RGB 图像以及机器人关节角度、关节速度和末端执行器位姿。若目标物体中心在 100 个时间步的回合内至少有 10 个时间步落在红色目标圆上，则视为一次推动成功。所报告的推动成功率是在 74 个任务上、每个任务 6 次试验（共 444 次试验）计算得到的。

我们使用信赖域策略优化（TRPO）算法为每个任务获取独立的演示策略。专家策略的输入包括目标和干扰物体的位姿，而非视觉输入。为鼓励专家策略采取相似策略，我们首先在单个任务上训练一个策略，然后用该策略的参数初始化所有其他策略的参数。在初始化策略参数时，我们增大了已收敛策略的方差以确保充分探索。

超参数：对于所有方法，我们使用一个神经网络策略，包含 4 个带 165×5 个滤波器的步长卷积层，随后是空间 Softmax 函数和 3 个隐藏维度为 200 的全连接层。对于每种方法的优化，使用元批大小为 15 个任务。MIL 使用 1 步内梯度下降，步长为 $\alpha = 0.01$ ，内梯度裁剪范围为 $[-10, 10]$ ，以及维度为 20 的偏差变换。LSTM 策略使用 512 个隐藏单元。

由于该领域比模拟到达领域更具挑战性，我们发现使用第 4.2 节所述的双头架构非常重要。我们在表 3 中给出了双头架构的消融实验，证明了这一选择的好处。

方法	单头	双头	MIL (1
样本)	80.63%	85.81%	MIL (5
样本)	82.63%	88.75%	

表 3: 针对图 2 所示模拟推动任务的单头与双头架构消融测试, 使用包含 9200 个演示的元学习数据集。在该领域中, 使用双头架构能显著提升性能。

A.3 真实世界放置

实验设置: 演示视频由机器人相机拍摄的 320×240 RGB 图像序列组成。我们通过将图像下采样 2 倍并裁剪为 100×90 尺寸来预处理演示。由于收集的视频长度可变, 我们对视频进行子采样, 使其具有固定的时间范围 30。

为了收集一个任务的演示数据, 我们从训练集物体中随机选择一个手持物体和三个放置容器 (见图 5 第三幅图像), 并将这三个物体以 8 种随机位置放置在机器人前方。通过这种方式, 我们收集了 1293 个演示, 其中 96 个用作验证集, 其余用作训练集。

在策略评估期间, 我们使用 18 个任务和每个任务 4 次试验 (共 72 次试验) 来评估策略, 其中每个任务使用测试集中的 1 个放置目标和 1 个手持物体。此外, 我们在轨迹末端手动编码一个“打开夹爪”动作, 使机器人放下手持物体。我们将成功定义为在夹爪打开后, 手持物体是否落在目标容器内或上。

超参数: 我们使用一个神经网络策略, 包含 3 个步长卷积层和 2 个非步长卷积层, 具有 $64 \times 3 \times 3$ 个滤波器, 随后是空间 Softmax 函数和 3 个隐藏维度为 100 的全连接层。我们从 VGG-19 初始化第一个卷积层, 并在元训练期间保持其固定。除了模仿目标外, 我们还添加了一个辅助损失, 该损失从第一个时间步的学习特征回归到目标容器的二维位置。此外, 我们还将预测的目标二维位置输入到全连接网络中。MIL 使用 12 个任务的元批大小, 5 个内部梯度下降步骤, 步长为 0.005, 内部梯度裁剪在 $[-30, 30]$ 范围内, 以及维度为 20 的偏差变换。我们还像模拟到达任务一样, 为 MIL 使用单头架构。LSTM 策略使用 512 个隐藏单元。