

OpenVLA: An Open-Source Vision-Language-Action Model

Moo Jin Kim^{*,1} Karl Pertsch^{*,1,2} Siddharth Karamcheti^{*,1,3}
 Ted Xiao⁴ Ashwin Balakrishna³ Suraj Nair³ Rafael Rafailov¹ Ethan Foster¹ Grace Lam
 Pannag Sanketi⁴ Quan Vuong^{5,†} Thomas Kollar³ Benjamin Burchfiel³ Russ Tedrake^{3,6} Dorsa Sadigh¹
 Sergey Levine² Percy Liang¹ Chelsea Finn¹

<https://openvla.github.io>




图 1: 我们提出了 OpenVLA, 一个 70 亿参数的开源视觉-语言-动作模型 (VLA), 在 Open X-Embodiment 数据集 [1] 的 97 万条机器人轨迹上训练而成。OpenVLA 为通用机器人操作策略设立了新的最新技术水平。它支持开箱即用控制多种机器人, 并可通过参数高效微调快速适应新的机器人领域。OpenVLA 检查点和 PyTorch 训练流水线完全开源, 模型可从 HuggingFace 下载和微调。

摘要: 在互联网规模的视觉-语言数据和多样化机器人演示上预训练的大型策略, 有潜力改变我们教授机器人新技能的方式: 无需从头训练新行为, 我们可以微调此类视觉-语言-动作 (VLA) 模型, 以获得用于视觉运动控制的稳健、可泛化的策略。然而, VLA 在机器人领域的广泛采用一直面临挑战, 因为 1) 现有 VLA 大多是封闭的, 公众无法访问, 2) 先前工作未能探索针对新任务高效微调 VLA 的方法, 而这是采用的关键组成部分。针对这些挑战, 我们提出了 OpenVLA, 一个 70 亿参数的开源 VLA, 在 97 万条真实世界机器人演示的多样化集合上训练而成。OpenVLA 基于 Llama 2 语言模型, 并结合了一个融合了 DINOv2 和 SigLIP 预训练特征的视觉编码器。得益于增加的数据多样性和新的模型组件, OpenVLA 在通用操作方面展示了强大的结果, 在 29 个任务和多种机器人形态上, 以少 7 倍的参数, 在绝对任务成功率上比封闭模型如 RT-2-X (55B) 高出 16.5%。我们进一步表明, 我们可以有效地针对新设置微调 OpenVLA, 尤其是

* : 表示同等贡献 通讯作者: moojink@stanford.edu, pertsch@berkeley.edu, skaramcheti@stanford.edu 1 斯坦福大学, 2 加州大学伯克利分校, 3 丰田研究所, 4 谷歌 Deepmind, 5 Physical Intelligence, 6 麻省理工学院, † 部分工作在谷歌 Deepmind 完成

在多任务环境中，涉及多个物体和强大的语言基础能力时，表现出强大的泛化结果，并且比从零开始训练的模仿学习方法（如扩散策略）性能高出 20.4%。我们还探索了计算效率；作为一项独立贡献，我们展示了 OpenVLA 可以通过现代低秩适配方法在消费级 GPU 上进行微调，并通过量化高效地提供服务，而不会影响下游成功率。最后，我们发布了模型检查点、微调笔记本以及我们的 PyTorch 代码库，该代码库内置了在 Open X-Embodiment 数据集上大规模训练视觉-语言-动作模型的支持。

1 引言

用于机器人操作的已学习策略的一个关键弱点是它们无法泛化到训练数据之外：虽然针对单个技能或语言指令训练的现有策略有能力将行为外推到新的初始条件，如物体位置或光照 [2, 3]，但它们对场景干扰物或新物体缺乏鲁棒性 [4, 5]，并且难以执行未见过的任务指令 [6, 7]。然而，在机器人学之外，现有的视觉和语言基础模型，如 CLIP[8]、SigLIP[9] 和 Llama 2[10]，能够实现这些类型的泛化甚至更多，这源于它们互联网规模预训练数据集所捕获的先验知识。虽然在机器人学中重现这种规模的预训练仍然是一个开放的挑战——即使是最大的机器人操作数据集 [1, 11] 也只有 10 万到 100 万个示例——但这种不平衡暗示了一个机遇：利用现有的视觉和语言基础模型作为核心构建块，来训练能够泛化到训练数据之外的物体、场景和任务的机器人策略。

为了实现这一目标，现有工作已探索将预训练的视觉和语言模型整合用于机器人表示学习 [12 – 14]，并作为任务规划与执行的模块化系统组件 [15, 16]。近期，这些模型被用于直接学习视觉语言动作模型（VLA；1, 7, 17, 18）以进行控制。VLA 为利用预训练视觉与语言基础模型于机器人领域提供了直接实例，即直接微调视觉条件语言模型（VLM），如 PaLI [19, 20]，以生成机器人控制动作。通过构建于互联网规模数据训练的强基础模型之上，诸如 RT-2 [7] 的 VLA 展示了令人印象深刻的鲁棒性结果，以及泛化到新物体和任务的能力，为通用机器人策略设立了新标准。然而，现有 VLA 的广泛应用受到两个关键因素阻碍：1）当前模型 [1, 7, 17, 18] 是封闭的，对模型架构、训练过程和数据混合的可见性有限；2）现有工作未提供将 VLA 部署和适配到新机器人、环境和任务的最佳实践——尤其是在消费级硬件（例如，消费级 GPU）上。我们认为，为了为未来研究与发展奠定丰富基础，机器人领域需要开源的、通用的 VLA，支持有效的微调和适配，类似于围绕开源语言模型的现有生态系统 [21 – 24]。

为此，我们推出了 OpenVLA，一个拥有 70 亿参数的开源视觉-语言-动作模型，为通用机器人操作策略树立了新的最先进水平。¹ OpenVLA 由一个预训练的视觉条件语言模型骨干组成，该骨干在多个粒度上捕捉视觉特征，并在来自 Open-X Embodiment [1] 数据集的大规模多样化 97 万条机器人操作轨迹上进行了微调——该数据集涵盖了广泛的机器人形态、任务和场景。作为数据多样性增加和新模型组件的成果，OpenVLA 在 WidowX 和 Google Robot 形态上的 29 项评估任务中，以 16.5% 的绝对成功率超越了拥有 550 亿参数的 RT-2-X 模型 [1, 7]（此前最先进的视觉-语言-动作模型）。此外，我们还研究了视觉-语言-动作模型的高效微调策略，这是先前工作未曾探索的新贡献，涉及 7 项多样化的操作任务，涵盖从物体拾取放置到清洁桌面的行为。我们发现，微调后的 OpenVLA 策略明显优于微调后的预训练策略（如 Octo [5]）。与使用扩散策略 [3] 的从零开始模仿学习相比，微调后的 OpenVLA 在涉及将语言与行为接地的任务上表现出显著改进，

¹OpenVLA 使用了多个预训练模型组件：SigLIP [9] 和 DinoV2 [25] 视觉编码器以及 Llama 2 [10] 语言模型骨干。对于这三个模型，权重是开放的，但其训练数据或代码并非开放。我们发布了训练数据、代码和模型权重，以便在这些组件之上复现 OpenVLA。

多任务设置与多个对象。基于这些结果，我们首次证明了利用低秩适配（LoRA）和模型量化 [27] 的计算高效微调方法的有效性，从而能够在消费级图形处理器（GPU）而非大型服务器节点上适配 OpenVLA 模型，且不牺牲性能。作为最终贡献，我们开源了所有模型、部署和微调笔记本以及用于大规模训练视觉语言动作模型（VLA）的 OpenVLA 代码库，希望这些资源能够推动未来探索和适配机器人视觉语言动作模型的工作。

2 相关工作 视觉条件语言模型 视觉条件语言模型（VLM）在大规模互联网数据上训练，能够根据输入图像和语言提示生成自然语言，已被广泛应用于从视觉问答 [28 – 31] 到目标定位 [32, 33] 的众多应用中。推动近期视觉条件语言模型发展的关键进展之一是模型架构，这些架构将预训练视觉编码器 [8, 9, 25] 的特征与预训练语言模型 [10, 23, 34 – 36] 相连接，直接建立在计算机视觉和自然语言建模的进展之上，从而创建强大的多模态模型。虽然早期工作探索了多种用于视觉和语言特征交叉注意力的架构 [37 – 41]，但新的开源视觉条件语言模型 [20, 42 – 44] 已收敛于一种更简单的“图像块即令牌”方法，其中来自预训练视觉变换器的图像块特征被视为令牌，然后被投影到语言模型的输入空间中。这种简单性使得重用现有的大规模语言模型训练工具来训练视觉条件语言模型变得容易。我们在工作中采用这些工具来扩展视觉-语言-动作模型的训练，并特别使用 Karamcheti 等人 [44] 的视觉条件语言模型作为我们的预训练骨干，因为它们基于多分辨率视觉特征进行训练，融合了来自 DINOv2 [25] 的低级空间信息和来自 SigLIP [9] 的高级语义，以帮助视觉泛化。

通用机器人策略 机器人学的一个近期趋势致力于在大型多样化机器人数据集 [1, 2, 6, 11, 45, 49 – 56] 上训练多任务“通用”机器人策略 [2, 6, 45 – 49]，涵盖许多不同的机器人形态 [1, 5, 53, 57 – 66]。值得注意的是，Octo [5] 训练了一个通用策略，可以开箱即用地控制多个机器人，并允许灵活微调以适应新的机器人设置。这些方法与 OpenVLA 之间的一个关键区别在于模型架构。像 Octo 这样的先前工作通常将预训练组件（如语言嵌入或视觉编码器）与从头初始化的额外模型组件组合在一起 [2, 5, 6]，在策略训练过程中学习将它们“拼接”在一起。与这些工作不同，OpenVLA 采用了一种更端到端的方法，直接微调视觉条件语言模型，通过将机器人动作视为语言模型词汇表中的令牌来生成动作。我们的实验评估表明，这种简单且可扩展的流程显著提升了性能和泛化能力，超越了先前的通用策略。

视觉-语言-动作模型 许多工作探索了视觉语言模型（VLM）在机器人领域的应用，例如用于视觉状态表示 [12, 13]、目标检测 [67]、高层规划 [16] 以及提供反馈信号 [68 – 71]。其他工作则将视觉语言模型直接集成到端到端的视觉运动操作策略中 [14, 15]，但在策略架构中引入了大量结构，或需要校准相机，这限制了其适用性。近期许多工作探索了与本文类似的方案，直接微调大型预训练视觉语言模型以预测机器人动作 [1, 7, 17, 18, 72 – 74]。此类模型通常被称为视觉-语言-动作模型（VLA），因为它们将机器人控制动作直接融合到视觉语言模型骨干中。这具有三个关键优势：（1）在互联网规模的大型视觉-语言数据集上对预训练的视觉和语言组件进行对齐；（2）使用通用架构而非为机器人控制定制的架构，使我们能够利用现代视觉语言模型训练的可扩展基础设施 [75 – 77]，并以最少的代码修改扩展到训练十亿参数策略；（3）为机器人技术从视觉语言模型的快速进步中受益提供了直接途径。现有的视觉-语言-动作模型工作要么专注于在单一机器人或仿真环境中进行训练和评估 [72 – 74, 78]，因此缺乏通用性；要么是封闭的，不支持对新机器人设置进行高效微调 [1, 7, 17, 18]。最相关的工作 RT-2-X [1] 在 Open X-Embodiment 数据集上训练了一个 550 亿参数的视觉-语言-动作模型策略，并展示了最先进的通用操作策略性能。然而，本文的工作在多个重要方面与 RT-2-X 不同：（1）通过结合强大的开源视觉语言模型




图 2: OpenVLA 模型架构。 给定图像观测和语言指令，模型预测 7 维机器人控制动作。该架构由三个关键组件组成：（1）视觉编码器，拼接 Dino V2[25] 和 SigLIP[79] 特征；（2）投影器，将视觉特征映射到语言嵌入空间；（3）大语言模型骨干，即 Llama 2 70 亿参数大语言模型 [10]。

采用更丰富的机器人预训练数据集作为骨干网络，OpenVLA 在我们的实验中优于 RT-2-X，同时模型规模小一个数量级；（2）我们深入研究了 OpenVLA 模型在新目标设置下的微调，而 RT-2-X 未研究微调设置；（3）我们首次证明了现代参数高效微调和量化方法对视觉语言动作模型的有效性；（4）OpenVLA 是首个开源的通用视觉语言动作模型，因此支持未来在视觉语言动作模型训练、数据混合、目标和推理方面的研究。

3 OpenVLA 模型 本文提出 OpenVLA 模型，这是一个基于 Open X-Embodiment 数据集 [1] 中 97 万条机器人演示数据训练而成的 70 亿参数视觉-语言-动作模型（VLA）。关于开发 VLA 模型的最佳实践，存在许多尚未充分探索的问题，例如，训练时应采用何种最优的模型骨干、数据集和超参数。下文将详述我们开发 OpenVLA 的方法，并总结关键经验。具体而言，我们首先简要概述构成 OpenVLA 骨干的现代视觉语言模型（第 3.1 节）；随后描述基础训练方案与数据集（第 3.2 节和第 3.3 节）；讨论关键设计决策（第 3.4 节）；最后提供训练与推理所用基础设施的细节（第 3.5 节）。**3.1 预备知识：视觉语言模型** 近期大多数视觉语言模型 [20, 42 – 44] 的架构包含三个主要部分（见图 2）：（1）视觉编码器，将图像输入映射为若干“图像块嵌入”；（2）投影器，接收视觉编码器的输出嵌入并将其映射到语言模型的输入空间；（3）大语言模型（LLM）骨干。在视觉语言模型训练期间，模型以配对或交错的视觉与语言数据为输入，通过下一文本标记预测目标进行端到端训练，这些数据来自各类互联网来源。本文工作基于 Prismatic-7B 视觉语言模型 [44] 构建。Prismatic 遵循上述标准架构，包含一个 6 亿参数的视觉编码器、一个小型双层多层感知机投影器以及一个 70 亿参数的 Llama 2 语言模型骨干 [10]。值得注意的是，Prismatic 采用由预训练的 SigLIP[79] 和 DinoV2[25] 模型构成的双部分视觉编码器。输入图像块分别通过两个编码器，所得特征向量按通道维度拼接。与更常用的 CLIP[80] 或仅使用 SigLIP 的视觉编码器相比，加入 DinoV2 特征已被证明有助于提升空间推理能力 [44]，这对机器人控制尤为有益。SigLIP、DinoV2 和 Llama 2 均未公开其训练数据细节，这些数据可能分别包含数万亿标记的互联网来源图像-文本、纯图像和纯文本数据。Prismatic 视觉语言模型在这些组件之上，使用 LLaVA 1.5 数据混合 [43] 进行微调，该混合数据包含来自开源数据集 [29, 42, 81 – 83] 的约 100 万个图像-文本和纯文本数据样本。

3.2 OpenVLA 训练流程

为训练 OpenVLA，本文对预训练的 Prismatic-7B 视觉语言模型骨干进行微调，用于机器人动作预测（见图 2）。本文将动作预测问题形式化为“视觉-语言”任务，其中输入观测图像和自然语言任务指令被映射为预测机器人动作的字符串 [7]。为使视觉语言模型的语言模型骨干能够预测机器人动作，本文通过将连续机器人动作映射到语言模型分词器使用的离散标记，在大型语言模型的输出空间中表示动作。遵循 Brohan 等人 [7] 的方法，本文将机器人动作的每个维度分别离散化为 256 个区间之一。对于每个动作维度，本文设置区间宽度，以均匀划分训练数据中动作的第 1st 和第 99th 分位数之间的区间。使用分位数而非 Brohan 等人 [7] 使用的最小-最大边界，使本文能够忽略数据中的异常动作，否则这些异常动作可能大幅扩大离散化区间并降低动作离散化的有效粒度。

利用这种离散化，本文为 N 维机器人动作获得 N 个离散整数 $\in [0 \dots 255]$ 。遗憾的是，OpenVLA 语言骨干使用的分词器，即 Llama 分词器 [10]，仅为微调期间新引入的标记保留了 100 个“特殊标记”，这对于本文动作离散化的 256 个标记来说太少。相反，本文再次选择简单性，遵循 Brohan 等人 [7] 的方法，直接覆盖 Llama 分词器词汇表中使用频率最低的 256 个标记（对应最后 256 个标记），替换为本文的动作标记。一旦动作被处理为标记序列，OpenVLA 便使用标准的下一标记预测目标进行训练，仅对预测的动作标记评估交叉熵损失。本文在第 3.4 节讨论实现该训练流程的关键设计决策。接下来，本文描述用于 OpenVLA 训练的机器人数据集。

3.3 训练数据

构建 OpenVLA 训练数据集的目标是捕捉机器人本体、场景和任务的广泛多样性。这使最终模型能够开箱即用地控制各种机器人，并支持高效微调以适应新的机器人设置。我们利用 OpenX-Embodiment 数据集 [1] (OpenX) 作为基础来策展训练数据集。在撰写本文时，完整的 OpenX 数据集包含 70 多个独立的机器人数据集，拥有超过 200 万条机器人轨迹，这些数据在大型社区努力下被整合为一致且易于使用的数据格式。为了使这些数据的训练切实可行，我们对原始数据集应用了多个数据策展步骤。

本次数据整理的目标是确保：（1）所有训练数据集具有一致的输入与输出空间；（2）最终训练混合中具身形态、任务和场景的均衡分布。² 针对目标（1），本文遵循 [1, 5] 的做法，仅保留至少含有一个 3rd 人视角相机且采用单臂末端执行器控制的操控数据集。针对目标（2），本文利用 Octo[5] 的数据混合权重，对所有通过首轮筛选的数据集进行加权。Octo 启发式地降低或移除多样性较低的数据集，并提高任务与场景多样性较高的数据集的权重；详见 Octo 模型团队等人 [5] 的说明。

我们还尝试将自 Octo 发布以来添加到 OpenX 数据集中的一些额外数据集纳入训练混合，包括 DROID 数据集 [11]，但采用了保守的 10% 混合权重。在实践中，我们发现 DROID 上的动作标记准确率在整个训练过程中保持较低水平，这表明未来可能需要更大的混合权重或模型来适应其多样性。为了不损害最终模型的质量，我们在训练的最后三分之一阶段将 DROID 从数据混合中移除。我们在附录 A 中提供了所用数据集和混合权重的完整概述。

3.4 OpenVLA 设计决策

在开发 OpenVLA 模型时，我们在开始最终模型训练之前，通过较小规模的实验探索了各种设计决策。具体来说，我们在初始实验中基于 BridgeData V2 [6] 训练和评估 OpenVLA 模型，而不是在完整数据集上训练

²Octo [5] 展示了在具有异构感官输入的数据集上进行训练的能力。虽然非常有前景，但我们将跨异构传感器模态和动作空间的 VLA 训练研究留待未来工作。

OpenX 混合数据集，以提高迭代速度并降低计算成本。我们在下文总结了这些探索的关键经验。

VLM 主干网络。最初，我们尝试了多种 VLM 主干网络。除了 Prismatic [44] 之外，我们还测试了微调 IDEFICS-1 [84] 和 LLaVA [85] 用于机器人动作预测。我们发现，在场景中只有一个物体的任务上，LLaVA 和 IDEFICS-1 的性能相当，但在涉及多个物体且要求策略操纵正确物体（即语言指令中指定的物体）的任务中，LLaVA 表现出更强的语言基础能力。具体而言，在 BridgeData V2 水槽环境中的五个语言基础任务上，LLaVA 的绝对成功率比 IDEFICS-1 提高了 35%。微调后的 Prismatic VLM 策略取得了进一步的提升，在简单的单物体任务和多物体语言基础任务上，其绝对成功率均比 LLaVA 策略高出约 10%。我们将这一性能差距归因于融合的 SigLIP-DinoV2 主干网络所带来的空间推理能力提升（见第 3.1 节）。除了性能提升之外，Prismatic 还提供了模块化且易于使用的代码库，因此我们最终选择它作为 OpenVLA 模型的主干网络。

图像分辨率。输入图像的分辨率对 VLA 训练的计算需求有显著影响，因为更高分辨率的图像会产生更多的图像块标记，从而增加上下文长度，使训练计算量呈二次方增长。我们比较了输入分辨率为 224×224 像素和 384×384 像素的 VLA，但在评估中未发现性能差异，而后的训练时间要长 3 倍。因此，我们为最终的 OpenVLA 模型选择了 224×224 像素的分辨率。需要注意的是，在许多 VLM 基准测试中，提高分辨率确实能提升性能 [44, 86, 87]，但我们尚未在 VLA 中观察到这一趋势。

微调视觉编码器。先前关于视觉语言模型（VLM）的研究发现，在视觉语言模型训练期间冻结视觉编码器通常能带来更高的性能 [44]。直观上，冻结的视觉编码器可能更好地保留其从互联网规模预训练中学习到的鲁棒特征。然而，我们发现，在视觉语言动作（VLA）模型训练期间微调视觉编码器对于获得良好的视觉语言动作模型性能至关重要。我们假设，预训练的视觉骨干网络可能无法捕捉场景中重要部分足够精细的空间细节，从而无法实现精确的机器人控制。

训练轮次。典型的大语言模型（LLM）或视觉语言模型训练最多在其训练数据集上完成一到两个轮次。相比之下，我们发现视觉语言动作模型训练需要显著更多次地遍历训练数据集，这一点很重要，真实机器人的性能会持续提升，直到训练动作标记准确率超过 95%。我们最终的训练运行在其训练数据集上完成了 27 个轮次。

学习率。我们针对视觉语言动作模型训练在多个数量级范围内扫描了学习率，并使用固定学习率 $2e-5$ （与视觉语言模型预训练期间使用的学习率相同 [44]）取得了最佳结果。我们发现学习率预热并未带来益处。

3.5 训练与推理基础设施 最终的 OpenVLA 模型在 64 块 A100 GPU 集群上训练了 14 天，总计 21,500 个 A100 小时，批大小为 2048。在推理期间，OpenVLA 以 bfloat16 精度（即不进行量化）加载时需要 15GB 的 GPU 内存，并在一块 NVIDIA RTX 4090 GPU 上以约 6Hz 的频率运行（未使用编译、推测解码或其他推理加速技巧）。如第 5.4 节所示，我们可以在推理期间通过量化进一步减少 OpenVLA 的内存占用，而不会影响其在真实世界机器人任务中的性能。我们在图 6 中报告了在各种消费级和服务级 GPU 上的推理速度。为了方便起见，我们实现了一个远程 VLA 推理服务器，允许将动作预测实时远程流式传输到机器人，从而消除了控制机器人时需要拥有强大地本地计算设备的要求。我们将此远程推理解决方案作为开源代码发布的一部分（第 4 节）。

4 OpenVLA 代码库

随模型一同发布的还有 OpenVLA 代码库，这是一个用于训练视觉-语言-动作模型的模块化 PyTorch 代码库（见 <https://openvla.github.io>）。它既支持在单个 GPU 上微调视觉-语言-动作模型，也支持在多节点 GPU 集群上训练十亿参数级的视觉-语言-动作模型，并支持现代




图 3: BridgeData V2 WidowX 机器人评估任务与结果。我们在涵盖多个泛化维度以及专门评估语言条件能力的全面任务套件上，对 OpenVLA 和先前最先进的通用机器人策略进行了评估。OpenVLA 取得了最高的总体性能，甚至在除语义泛化外的所有类别中都优于闭源模型 RT-2-X。平均成功率 $\pm$ 标准误差基于每种方法共 170 次试验计算得出。详细结果见表 4。

大型变换器模型训练技术，如自动混合精度（AMP，PyTorch [75]）、FlashAttention [76] 和全分片数据并行（FSDP，Zhao 等人 [77]）。开箱即用，OpenVLA 代码库完全支持在 Open X 数据集上训练，集成了 HuggingFace 的 [21] AutoModel 类，并支持 LoRA 微调 [26] 和量化模型推理 [27, 88]。

5 实验

实验评估的目标是检验 OpenVLA 能否开箱即用地充当强大的多机器人控制策略，以及能否作为微调至新机器人任务的良好初始化。具体而言，我们旨在回答以下问题：

1. 在多个机器人和多种泛化类型上进行评估时，OpenVLA 与先前的通用机器人策略相比表现如何？
2. OpenVLA 能否在新的机器人设置和任务上被有效微调，并与最先进的数据高效模仿学习方法相比表现如何？
3. 能否利用参数高效微调和量化来降低 OpenVLA 模型训练和推理的计算需求，使其更易于使用？性能与计算之间的权衡是什么？

5.1 多机器人平台上的直接评估

机器人设置与任务。我们在两种机器人实体上评估了 OpenVLA 的“开箱即用”性能：来自 BridgeData V2 评估的 WidowX 机器人 [6]（见图 1 左）以及来自 RT-1 和 RT-2 评估的移动操作机器人 [2, 7]（“谷歌机器人”；见图 1 中）。这两个平台在先前的工作中被广泛用于评估通用机器人策略 [1, 2, 5, 7]。我们在每个环境中定义了一套全面的评估任务，涵盖泛化的各个维度，例如视觉（未见过的背景、干扰物、物体的颜色/外观）；运动（未见过的物体位置/方向）；物理（未见过的物体尺寸/形状）；以及语义（未见过的目标物体、指令和来自互联网的概念）泛化。我们还评估了在多物体场景中的语言条件能力，测试策略是否能够按照用户提示中指定的方式操纵正确的目标物体。BridgeData V2 和谷歌机器人评估中的示例任务图像分别见图 3 底行和图 4。总体而言，我们在 BridgeData V2 实验中评估了每种方法的 170 次 rollout（17 个任务，每个任务 10 次试验），在谷歌机器人实验中评估了 60 次 rollout（12 个任务，每个任务 5 次试验）。所有任务及其与训练数据差异的详细分解见

附录 B。本节及后续章节中的所有评估均以 A/B 评估的形式进行，使用相同的任务和相同的初始机器人与物体状态集，以确保公平比较。

比较。我们将 OpenVLA 的性能与三种先前的通用操作策略进行了比较：**RT-1-X** [1]、**RT-2-X** [1] 和 **Octo** [5]。**RT-1-X**（3500 万参数）和 **Octo**（9300 万参数）是在 OpenX 数据集子集上从头训练的变换器策略；**Octo** 是开源操作策略中最先进的模型。**RT-2-X**（550 亿参数）是一种最先进的闭源视觉-语言-动作模型，利用了互联网预训练的视觉和语言骨干网络。结果总结在图 3（BridgeData V2 评估）和图 4（谷歌机器人评估）中（每任务细分见附录表 4 和表 6）。我们发现 **RT-1-X** 和 **Octo** 在测试任务上表现挣扎，经常无法操作正确的物体，尤其是在存在干扰物时，有时甚至导致机器人手臂无目的地挥舞。请注意，我们的评估测试了比先前工作中进行的评估更大程度的泛化，以挑战互联网预训练的视觉-语言-动作模型。因此，没有互联网预训练的模型性能较低是预期的。**RT-2-X** 明显优于 **RT-1-X** 和 **Octo**，展示了大型预训练视觉-语言模型在机器人技术中的优势。

值得注意的是，OpenVLA 在谷歌机器人评估中的表现与 **RT-2-X** 相当，在 BridgeData V2 评估中显著优于 **RT-2-X**，尽管其参数量小一个数量级（7B 对比 55B）。定性来看，我们发现 **RT-2-X** 和 **OpenVLA** 均表现出比其他测试模型明显更稳健的行为，例如在存在干扰物体时接近正确物体、正确调整机器人末端执行器的方向以对齐目标物体的方向，甚至能从错误中恢复，如抓取物体不牢固（见 <https://openvla.github.io> 中的定性演示示例）。**RT-2-X** 在语义泛化任务中取得更高性能，如图 3 所示，这是预期之中的，因为它使用了更大规模的互联网预训练数据，并且同时使用机器人动作数据和互联网预训练数据进行联合微调，以更好地保留预训练知识，而不是像 **OpenVLA** 那样仅在机器人数据上进行微调。然而，**OpenVLA** 在 BridgeData V2 和谷歌机器人评估的所有其他任务类别中表现相当或更好。性能差异可归因于多种因素：我们为 **OpenVLA** 策划了更大的训练数据集，包含 97 万条轨迹（对比 **RT-2-X** 的 35 万条）；我们对训练数据集进行了更仔细的清洗，例如过滤掉 Bridge 数据集中全零动作（详细讨论见附录 C）；并且 **OpenVLA** 使用融合视觉编码器，结合了预训练的语义和空间特征。这些组件的消融分析见附录 D。




图 4：谷歌机器人评估结果。我们在 RT-1 和 RT-2 评估中使用的移动机械手上评估通用机器人策略的分布内和分布外任务 [2, 7]。我们发现 **OpenVLA** 和 **RT-2-X** 取得了可比的性能，并且总体上显著优于 **RT-1-X** 和 **Octo**。平均成功率 $\pm$ 标准误差基于每种方法总共 60 次试验计算。详细结果见表 6。

5.2 对新机器人设置的数据高效适应

虽然先前工作主要关注直接“开箱即用”地评估视觉语言动作模型 [1, 7, 16]，但对 VLA 模型进行有效微调以适应新任务和机器人设置的研究在很大程度上尚未探索，而这对其广泛采用至关重要。在本节中，我们研究 **OpenVLA** 快速适应新真实世界机器人设置的能力。（仿真中的微调实验见附录 E。）

机器人设置与任务。我们测试了 **OpenVLA** 模型的一种简单微调方法：对模型所有参数进行全量微调，使用包含目标任务 10 – 150 个演示的小型数据集（见图 5；我们在第 5.3 节探索参数高效微调方法）。我们在两种设置中测试 **OpenVLA**：**Franka-Tabletop**，一个固定安装在桌面上的 Franka Emika Panda 七自由度机器人臂；以及 **Franka-DROID**，来自最近发布的 DROID 数据集的 Franka 机器人臂设置 [11]，




图 5：适应新的机器人设置。我们评估了在七个弗兰卡·艾米卡熊猫任务（每个任务 10 – 150 个演示）上从头训练的最先进的扩散策略，以及在相同数据上微调的通用机器人策略 Octo 和 OpenVLA。扩散策略在狭窄的单指令任务上表现出强大的性能，而 Octo 和 OpenVLA 在涉及多指令和干扰物体的多样化微调任务上表现更好。总体而言，OpenVLA 在两种设置下均取得了最高的综合性能，表明它是下游任务策略学习的有效默认选择。平均成功率 $\pm$ 标准误差基于每种方法 129 次运行（弗兰卡桌面任务 99 次，弗兰卡-DROID 任务 30 次）计算。详细结果见表 7。

安装在一个可移动的站立式办公桌上。这些设置分别使用 5 赫兹和 15 赫兹的非阻塞控制器。我们选择弗兰卡机器人手臂作为微调实验的目标本体，因为它们在机器人学习社区中被广泛使用，因此可能是 OpenVLA 微调的“目标”。我们在不同控制频率的设置上进行测试，以检验 OpenVLA 对一系列使用场景的适用性。

比较。我们与从头训练的最先进的数据高效模仿学习方法扩散策略 [3] 进行比较。我们还与扩散策略（匹配版）进行比较，该版本匹配了 **OpenVLA** 的输入和输出规格。³ 此外，我们评估了在目标数据集上微调的 Octo[5]，因为它目前是支持微调的最佳通用策略（RT-2-X 的微调不支持通过其推理应用程序编程接口进行）。我们还在相同的目标数据集上微调 **OpenVLA**，所得策略记为 **OpenVLA**。最后，作为消融实验，我们与 **OpenVLA**（从头训练）进行比较，其中我们直接在目标机器人设置上微调底层的基础 Prismatic 视觉语言模型——而不是微调经过 OpenX 预训练的 **OpenVLA** 模型——以评估大规模机器人预训练的好处。

我们在图 5 中展示了结果（每个任务的详细分解见附录表 7）。我们发现，在“将胡萝卜放入碗中”和“将玉米倒入锅中”等较窄的单指令任务上，两种版本的扩散策略（Diffusion Policy）与通用策略 Octo 和 OpenVLA 相比具有竞争力或更优，但在涉及场景中多个物体且需要语言条件化的更多样化微调任务中，预训练的通用策略表现更好。Octo 和 OpenVLA 的 OpenX 预训练使模型能够更好地适应这些语言基础至关重要的多样化任务；我们从 OpenVLA（从头训练）的较低性能中看到了这一点的证据。

总体而言，我们发现 OpenVLA 实现了最高的平均性能。值得注意的是，大多数先前的工作仅在狭窄的单指令任务或多样化的多指令任务中表现强劲，导致成功率差异很大。OpenVLA 是唯一在所有测试任务中至少达到 50% 成功率的方法，这表明它可以作为模仿学习任务的强默认选项，特别是当任务涉及多样化的语言指令时。对于较窄但高度灵巧的任务，扩散策略仍然显示出更平滑和更精确的轨迹；将扩散策略中实现的动作分块和时间平滑纳入 OpenVLA，可能有助于其达到相同的灵巧水平，并可能成为未来工作的一个有前景的方向（关于当前局限性的详细讨论见第 6 节）。

³ 完整的扩散策略使用包含图像和本体感受状态的两步观测历史，并通过预测 T 个未来动作的块并执行前 X 个动作（以开环方式）来进行滚动时域控制，然后再预测下一个块（对于 15Hz 控制，我们像 DROID 先前工作 [11] 中那样设置 $T = 16, X = 8$ ；对于 5Hz 控制，我们将块大小减小到 $T = 8, X = 3$ ）。它也是第 5.2 节中唯一预测绝对笛卡尔坐标来控制机器人的方法；所有其他方法都使用相对位置控制。扩散策略（匹配）使用单个图像作为输入，没有本体感受信息和观测历史，并预测单个相对位置控制动作，没有动作分块。

5.3 参数高效微调

上一节中 OpenVLA 的完整微调运行使用了 8 块 A100 GPU，每个任务耗时 5-15 小时（取决于数据集大小）以达到高性能。虽然这比 VLA 预训练所需的计算量少得多，但在本节中，我们探索更节省计算和参数的微调方法，并研究其有效性。

具体来说，我们比较以下微调方法：

完整微调在微调期间更新所有权重，如第 5.2 节所述；仅最后一层仅微调 OpenVLA 变换器主干的最后一层和词元嵌入矩阵；冻结视觉编码器冻结视觉编码器但微调所有其他权重；三明治微调解冻视觉编码器、词元嵌入矩阵和最后一层；LoRA 使用 Hu 等人 [26] 提出的流行低秩适配技术，采用多个秩值 r ，应用于模型的所有线性层。

表 1：参数高效微调评估。 LoRA 微调实现了最佳的性能-计算权衡，在仅训练 1.4% 模型参数的情况下匹配完整微调的性能。平均成功率 $\pm$ 标准误差基于每个方法在选定的 Franka-Tabletop 任务上的 33 次 rollout 计算（详见表 8）。*：使用 FSDP 在 2 块 GPU 上分片 [77]。

Strategy	Success Rate	Train Params ($\times 10^6$)	VRAM (batch 16)
Full FT	69.7 $\pm$ 7.2 %	7,188.1	163.3 GB*
Last layer only	30.3 $\pm$ 6.1 %	465.1	51.4 GB
Frozen vision	47.0 $\pm$ 6.9 %	6,760.4	156.2 GB*
Sandwich	62.1 $\pm$ 7.9 %	914.2	64.0 GB
LoRA, rank=32	68.2 $\pm$ 7.5 %	97.6	59.7 GB
rank=64	68.2 $\pm$ 7.8 %	195.2	60.5 GB

我们在表 1.4 中报告了多个 Franka-Tabletop

任务上的微调成功率，以及训练参数数量和 GPU 内存需求。我们发现仅微调网络的最后一层或冻结视觉编码器会导致性能不佳，这表明进一步将视觉特征适配到目标场景至关重要。相比之下，“三明治微调”实现了更好的性能，因为它微调了视觉编码器，并且由于不微调完整的 LLM 主干而消耗更少的 GPU 内存。最后，LoRA 在性能和训练内存消耗之间实现了最佳权衡，优于“三明治微调”并匹配完整微调的性能，同时仅微调 1.4% 的参数。我们发现 LoRA 秩对策略性能的影响可以忽略不计，因此建议使用默认秩 $r = 32$ 。使用 LoRA，我们可以在单块 A100 GPU 上在 10-15 小时内对新任务微调 OpenVLA——与完整微调相比计算量减少了 8 倍。

5.4 通过量化实现内存高效推理




图 6：OpenVLA 在不同图形处理器（GPU）上的推理速度。 bfloat16 和 int4 量化均实现了高吞吐量，尤其是在采用 Ada Lovelace 架构的 GPU（RTX 4090、H100）上。借助现代大语言模型（LLM）推理框架（如 TensorRT-LLM）可进一步提升速度 [89]。♠：模型分片至两块 GPU 以适应内存。

Precision	Bridge Success	VRAM
bfloat16	71.3 $\pm$ 4.8%	16.8 GB
int8	58.1 $\pm$ 5.1%	10.2 GB
int4	71.9 $\pm$ 4.7%	7.0 GB

表 2：量化推理下的性能。 4 位量化在将 GPU 内存占用减少一半以上的同时，达到了与 bfloat16 推理（本文默认方法）相当的性能。平均成功率 $\pm$ 标准差基于 8 个代表性 BridgeData V2 任务 [6] 及每种方法 80 次运行计算（详见表格 5）。

OpenVLA 作为 70 亿参数模型，在推理时比先前开源通用策略（如 Octo，其参数规模为 < 1 亿）消耗更多内存。本文遵循大语言模型服务的最佳实践，以 bfloat16 精度保存和加载 OpenVLA 进行推理（本文默认方法），将内存占用减半，从而能够在仅 16GB 显存的 GPU 上部署 OpenVLA。

在第 5.3 节和第 5.4 节中，本文实验了 OpenVLA 模型的一个版本，该版本使用较小的机器人数据混合进行预训练（与 Octo 相同的 OpenX 数据集混合），并采用略小的架构，仅使用 SigLIP[79] 视觉骨干网络，而非融合的 DinoSigLIP 编码器。本文发现，这种更简单的架构在微调任务和“开箱即用”任务中仍能取得强劲性能。

的图形处理器（GPU）内存。在本节中，我们测试是否可以通过使用为服务大语言模型（LLM）开发的现代量化技术 [27, 88]，进一步减少策略推理所需的内存并扩大视觉语言动作（VLA）策略的可访问性。这些方法以较低精度加载网络权重，从而以降低内存需求换取可能降低的推理速度和准确率。具体而言，我们研究了在 8 个代表性的 BridgeData V2 任务上以 8 位和 4 位精度服务 OpenVLA 模型。我们在表 2 中报告了内存占用和部署性能。我们还在图 6 中报告了在各种消费级和服务器级 GPU 上可达到的控制频率。我们观察到，由于增加的量化操作开销，8 位量化在大多数 GPU 上减慢了推理速度。4 位推理实现了更高的吞吐量，因为减少的 GPU 内存传输补偿了量化开销。由于推理速度降低，我们观察到 8 位量化导致性能显著下降：在我们用于评估的 A5000 GPU 上，我们只能以 1.2Hz 运行模型，这与 BridgeData V2 任务中使用的 5Hz 非阻塞控制器的训练数据集相比，显著改变了系统动态。⁵ 值得注意的是，4 位量化在所需 GPU 内存不到一半的情况下，实现了与 bfloat16 半精度推理相似的性能。4 位量化模型可以在 A5000 上以 3Hz 运行，从而更接近数据收集期间的系统动态。

6 讨论与局限性 本文提出了开放视觉语言动作模型（OpenVLA），这是一种最先进的、开源的视觉-语言-动作模型，开箱即用即可在跨具身机器人控制中取得强劲性能。我们还证明了通过参数高效微调技术，OpenVLA 可以轻松适应新的机器人设置。当前的 OpenVLA 模型存在若干局限性。首先，它目前仅支持单图像观测。实际上，现实世界的机器人设置是异构的，具有广泛的可能感官输入 [5]。扩展 OpenVLA 以支持多图像和本体感受输入以及观测历史是未来工作的重要方向。探索在交错图像和文本数据上预训练的视觉语言模型（VLM）可能有助于这种灵活输入的 VLA 微调。其次，提高 OpenVLA 的推理吞吐量对于实现高频控制设置（如以 50Hz 运行的 ALOHA [90]）的 VLA 控制至关重要。这也将使得能够在比本文所研究的更灵巧、双手操作任务上测试 VLA。探索使用动作分块或替代的推理时优化技术（如推测解码 [91]）提供了潜在的补救措施。此外，性能仍有进一步提升的空间。虽然 OpenVLA 优于先前的通用策略，但在测试任务上尚未提供非常高的可靠性，通常成功率低于 90%。最后，由于计算限制，许多 VLA 设计问题仍未得到充分探索：基础 VLM 的大小对 VLA 性能有何影响？在机器人动作预测数据和互联网规模的视觉语言数据上进行联合训练是否能显著提高 VLA 性能？哪些视觉特征最适合 VLA 模型？我们希望 OpenVLA 模型和代码库的发布将使社区能够共同研究这些问题。

致谢

我们感谢丰田研究所为开展本研究提供了大量资金和计算资源。我们还感谢斯坦福基础模型研究中心提供了额外的计算资源，以及谷歌深度思维（Google DeepMind）为我们的评估提供了 RT-2-X 应用程序编程接口（API）的 alpha 访问权限。我们感谢大众汽车、物理智能（Physical Intelligence）、海军研究办公室（ONR）拨款 N00014-22-1-2621 和 N00014-22-1-2293、美国国家科学基金会（NSF）通过 IIS-2246811 以及国防高级研究计划局（DARPA）ANSR 提供的额外支持。

⁵ 我们将性能损失归因于推理速度较低，因为在训练数据上离线评估时，8 位和 4 位量化均能达到与 bfloat16 推理相当的标记准确率。详见附录 D.4。

参考文献

- [1] Open X-Embodiment Collaboration, A. Padalkar, A. Pooley, A. Jain, A. Bewley, A. Herzog, A. Irpan, A. Khazatsky, A. Rai, A. Singh, A. Brohan, A. Raffin, A. Wahid, B. Burgess-Limerick, B. Kim, B. Schölkopf, B. Ichter, C. Lu, C. Xu, C. Finn, C. Xu, C. Chi, C. Huang, C. Chan, C. Pan, C. Fu, C. Devin, D. Driess, D. Pathak, D. Shah, D. Büchler, D. Kalashnikov, D. Sadigh, E. Johns, F. Ceola, F. Xia, F. Stulp, G. Zhou, G. S. Sukhatme, G. Salhotra, G. Yan, G. Schiavi, H. Su, H.-S. Fang, H. Shi, H. B. Amor, H. I. Christensen, H. Furuta, H. Walke, H. Fang, I. Mordatch, I. Radosavovic, I. Leal, J. Liang, J. Kim, J. Schneider, J. Hsu, J. Bohg, J. Bingham, J. Wu, J. Wu, J. Luo, J. Gu, J. Tan, J. Oh, J. Malik, J. Tompson, J. Yang, J. J. Lim, J. Silvério, J. Han, K. Rao, K. Pertsch, K. Hausman, K. Go, K. Gopalakrishnan, K. Goldberg, K. Byrne, K. Oslund, K. Kawaharazuka, K. Zhang, K. Majd, K. Rana, K. Srinivasan, L. Y. Chen, L. Pinto, L. Tan, L. Ott, L. Lee, M. Tomizuka, M. Du, M. Ahn, M. Zhang, M. Ding, M. K. Srirama, M. Sharma, M. J. Kim, N. Kanazawa, N. Hansen, N. Heess, N. J. Joshi, N. Suenderhauf, N. D. Palo, N. M. M. Shafiullah, O. Mees, O. Kroemer, P. R. Sanketi, P. Wohlhart, P. Xu, P. Sermanet, P. Sundaresan, Q. Vuong, R. Rafailov, R. Tian, R. Doshi, R. Martín-Martín, R. Mendonca, R. Shah, R. Hoque, R. Julian, S. Bustamante, S. Kirmani, S. Levine, S. Moore, S. Bahl, S. Dass, S. Song, S. Xu, S. Haldar, S. Adebola, S. Guist, S. Nasiriany, S. Schaal, S. Welker, S. Tian, S. Dasari, S. Belkhale, T. Osa, T. Harada, T. Matsushima, T. Xiao, T. Yu, T. Ding, T. Davchev, T. Z. Zhao, T. Armstrong, T. Darrell, V. Jain, V. Vanhoucke, W. Zhan, W. Zhou, W. Burgard, X. Chen, X. Wang, X. Zhu, X. Li, Y. Lu, Y. Chebotar, Y. Zhou, Y. Zhu, Y. Xu, Y. Wang, Y. Bisk, Y. Cho, Y. Lee, Y. Cui, Y. hua Wu, Y. Tang, Y. Zhu, Y. Li, Y. Iwasawa, Y. Matsuo, Z. Xu, and Z. J. Cui. Open X-Embodiment: Robotic learning datasets and RT-X models. <https://arxiv.org/abs/2310.08864>, 2023.
- [2] A. Brohan, N. Brown, J. Carbajal, Y. Chebotar, J. Dabis, C. Finn, K. Gopalakrishnan, K. Hausman, A. Herzog, J. Hsu, J. Ibarz, B. Ichter, A. Irpan, T. Jackson, S. Jesmonth, N. Joshi, R. Julian, D. Kalashnikov, Y. Kuang, I. Leal, K.-H. Lee, S. Levine, Y. Lu, U. Malla, D. Manjunath, I. Mordatch, O. Nachum, C. Parada, J. Peralta, E. Perez, K. Pertsch, J. Quiambao, K. Rao, M. Ryoo, G. Salazar, P. Sanketi, K. Sayed, J. Singh, S. Sontakke, A. Stone, C. Tan, H. Tran, V. Vanhoucke, S. Vega, Q. Vuong, F. Xia, T. Xiao, P. Xu, S. Xu, T. Yu, and B. Zitkovich. Rt-1: Robotics transformer for real-world control at scale. In *arXiv preprint arXiv:2212.06817*, 2022.
- [3] C. Chi, S. Feng, Y. Du, Z. Xu, E. Cousineau, B. Burchfiel, and S. Song. Diffusion policy: Visuomotor policy learning via action diffusion. In *Proceedings of Robotics: Science and Systems (RSS)*, 2023.
- [4] A. Xie, L. Lee, T. Xiao, and C. Finn. Decomposing the generalization gap in imitation learning for visual robotic manipulation. *arXiv preprint arXiv:2307.03659*, 2023.
- [5] Octo Model Team, D. Ghosh, H. Walke, K. Pertsch, K. Black, O. Mees, S. Dasari, J. Hejna, C. Xu, J. Luo, T. Kreiman, Y. Tan, D. Sadigh, C. Finn, and S. Levine. Octo: An open-source generalist robot policy. <https://octo-models.github.io>, 2023.
- [6] H. Walke, K. Black, A. Lee, M. J. Kim, M. Du, C. Zheng, T. Zhao, P. Hansen-Estruch, Q. Vuong, A. He, V. Myers, K. Fang, C. Finn, and S. Levine. Bridgedata v2: A dataset for robot learning at scale, 2023.
- [7] A. Brohan, N. Brown, J. Carbajal, Y. Chebotar, X. Chen, K. Choromanski, T. Ding, D. Driess, A. Dubey, C. Finn, P. Florence, C. Fu, M. G. Arenas, K. Gopalakrishnan, K. Han, K. Hausman, A. Herzog, J. Hsu, B. Ichter, A. Irpan, N. Joshi, R. Julian, D. Kalashnikov, Y. Kuang, I. Leal, L. Lee, T.-W. E. Lee, S. Levine, Y. Lu, H. Michalewski, I. Mordatch, K. Pertsch, K. Rao, K. Reymann, M. Ryoo, G. Salazar, P. Sanketi, P. Sermanet, J. Singh, A. Singh, R. Soricut, H. Tran, V. Vanhoucke, Q. Vuong, A. Wahid, S. Welker, P. Wohlhart, J. Wu, F. Xia, T. Xiao, P. Xu, S. Xu, T. Yu, and B. Zitkovich. Rt-2: Vision-language-action models transfer web knowledge to robotic control. In *arXiv preprint arXiv:2307.15818*, 2023.

- [8] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, G. Krueger, and I. Sutskever. Learning transferable visual models from natural language supervision. In *International Conference on Machine Learning (ICML)*, volume 139, pages 8748–8763, 2021.
- [9] X. Zhai, B. Mustafa, A. Kolesnikov, and L. Beyer. Sigmoid loss for language image pre-training. In *International Conference on Computer Vision (ICCV)*, 2023.
- [10] H. Touvron, L. Martin, K. Stone, P. Albert, A. Almahairi, Y. Babaei, N. Bashlykov, S. Batra, P. Bhargava, S. Bhosale, et al. Llama 2: Open foundation and fine-tuned chat models. *arXiv preprint arXiv:2307.09288*, 2023.
- [11] A. Khazatsky, K. Pertsch, S. Nair, A. Balakrishna, S. Dasari, S. Karamcheti, S. Nasiriany, M. K. Srirama, L. Y. Chen, K. Ellis, P. D. Fagan, J. Hejna, M. Itkina, M. Lepert, Y. J. Ma, P. T. Miller, J. Wu, S. Belkhale, S. Dass, H. Ha, A. Jain, A. Lee, Y. Lee, M. Memmel, S. Park, I. Radosavovic, K. Wang, A. Zhan, K. Black, C. Chi, K. B. Hatch, S. Lin, J. Lu, J. Mercat, A. Rehman, P. R. Sanketi, A. Sharma, C. Simpson, Q. Vuong, H. R. Walke, B. Wulfe, T. Xiao, J. H. Yang, A. Yavary, T. Z. Zhao, C. Agia, R. Baijal, M. G. Castro, D. Chen, Q. Chen, T. Chung, J. Drake, E. P. Foster, J. Gao, D. A. Herrera, M. Heo, K. Hsu, J. Hu, D. Jackson, C. Le, Y. Li, K. Lin, R. Lin, Z. Ma, A. Maddukuri, S. Mirchandani, D. Morton, T. Nguyen, A. O’Neill, R. Scalise, D. Seale, V. Son, S. Tian, E. Tran, A. E. Wang, Y. Wu, A. Xie, J. Yang, P. Yin, Y. Zhang, O. Bastani, G. Berseth, J. Bohg, K. Goldberg, A. Gupta, A. Gupta, D. Jayaraman, J. J. Lim, J. Malik, R. Martín-Martín, S. Ramamoorthy, D. Sadigh, S. Song, J. Wu, M. C. Yip, Y. Zhu, T. Kollar, S. Levine, and C. Finn. Droid: A large-scale in-the-wild robot manipulation dataset. 2024.
- [12] S. Nair, A. Rajeswaran, V. Kumar, C. Finn, and A. Gupta. R3m: A universal visual representation for robot manipulation. In *CoRL*, 2022.
- [13] S. Karamcheti, S. Nair, A. S. Chen, T. Kollar, C. Finn, D. Sadigh, and P. Liang. Language-driven representation learning for robotics. *ArXiv*, abs/2302.12766, 2023. URL <https://api.semanticscholar.org/CorpusID:257205716>.
- [14] M. Shridhar, L. Manuelli, and D. Fox. Cliport: What and where pathways for robotic manipulation. In *Conference on robot learning*, pages 894–906. PMLR, 2022.
- [15] A. Stone, T. Xiao, Y. Lu, K. Gopalakrishnan, K.-H. Lee, Q. Vuong, P. Wohlhart, B. Zitkovich, F. Xia, C. Finn, et al. Open-world object manipulation using pre-trained vision-language models. *arXiv preprint arXiv:2303.00905*, 2023.
- [16] D. Driess, F. Xia, M. S. Sajjadi, C. Lynch, A. Chowdhery, B. Ichter, A. Wahid, J. Tompson, Q. Vuong, T. Yu, et al. Palm-e: An embodied multimodal language model. *arXiv preprint arXiv:2303.03378*, 2023.
- [17] A. S. et al. Introducing rfm-1: Giving robots human-like reasoning capabilities, 2024. URL <https://covariant.ai/insights/introducing-rfm-1-giving-robots-human-like-reasoning-capabilities/>.
- [18] Wayve. Lingo-2: Driving with natural language. 2024. URL <https://wayve.ai/thinking/lingo-2-driving-with-language/>.
- [19] X. Chen, X. Wang, S. Changpinyo, A. J. Piergiovanni, P. Padlewski, D. M. Salz, S. Goodman, A. Grycner, B. Mustafa, L. Beyer, A. Kolesnikov, J. Puigcerver, N. Ding, K. Rong, H. Akbari, G. Mishra, L. Xue, A. V. Thapliyal, J. Bradbury, W. Kuo, M. Seyedhosseini, C. Jia, B. K. Ayan, C. Riquelme, A. Steiner, A. Angelova, X. Zhai, N. Houlsby, and R. Soricut. Pali: A jointly-scaled multilingual language-image model. *ArXiv*, abs/2209.06794, 2022. URL <https://api.semanticscholar.org/CorpusID:252222320>.

- [20] X. Chen, X. Wang, L. Beyer, A. Kolesnikov, J. Wu, P. Voigtlaender, B. Mustafa, S. Goodman, I. M. Alabdulmohsin, P. Padlewski, D. M. Salz, X. Xiong, D. Vlasic, F. Pavetic, K. Rong, T. Yu, D. Keysers, X.-Q. Zhai, and R. Soricut. PaLI-3 vision language models: Smaller, faster, stronger. *arXiv preprint arXiv:2310.09199*, 2023.
- [21] T. Wolf, L. Debut, V. Sanh, J. Chaumond, C. Delangue, A. Moi, P. Cistac, T. Rault, R. Louf, M. Funtowicz, J. Davison, S. Shleifer, and ... Transformers: State-of-the-art natural language processing. In *Proceedings of the 6th International Conference on Learning Representations*, 2020. URL <https://arxiv.org/abs/1910.03771>.
- [22] H. Touvron, T. Lavril, G. Izacard, X. Martinet, M.-A. Lachaux, T. Lacroix, B. Rozière, N. Goyal, E. Hambro, F. Azhar, et al. Llama: Open and efficient foundation language models. *arXiv preprint arXiv:2302.13971*, 2023.
- [23] A. Q. Jiang, A. Sablayrolles, A. Mensch, C. Bamford, D. S. Chaplot, D. d. l. Casas, F. Bressand, G. Lengyel, G. Lample, L. Saulnier, et al. Mistral 7b. *arXiv preprint arXiv:2310.06825*, 2023.
- [24] G. Team, T. Mesnard, C. Hardin, R. Dadashi, S. Bhupatiraju, S. Pathak, L. Sifre, M. Rivière, M. S. Kale, J. Love, et al. Gemma: Open models based on gemini research and technology. *arXiv preprint arXiv:2403.08295*, 2024.
- [25] M. Oquab, T. Darcet, T. Moutakanni, H. Vo, M. Szafraniec, V. Khalidov, P. Fernandez, D. Haziza, F. Massa, A. El-Nouby, et al. Dinov2: Learning robust visual features without supervision. *arXiv preprint arXiv:2304.07193*, 2023.
- [26] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, and W. Chen. Lora: Low-rank adaptation of large language models. *arXiv preprint arXiv:2106.09685*, 2021.
- [27] T. Dettmers, A. Pagnoni, A. Holtzman, and L. Zettlemoyer. Qlora: Efficient finetuning of quantized llms. *Advances in Neural Information Processing Systems*, 36, 2024.
- [28] Y. Goyal, T. Khot, D. Summers-Stay, D. Batra, and D. Parikh. Making the V in VQA matter: Elevating the role of image understanding in visual question answering. In *Computer Vision and Pattern Recognition (CVPR)*, 2017.
- [29] D. A. Hudson and C. D. Manning. GQA: A new dataset for real-world visual reasoning and compositional question answering. In *Computer Vision and Pattern Recognition (CVPR)*, 2019.
- [30] A. Singh, V. Natarajan, M. Shah, Y. Jiang, X. Chen, D. Batra, D. Parikh, and M. Rohrbach. Towards VQA models that can read. In *Computer Vision and Pattern Recognition (CVPR)*, 2019.
- [31] J. P. Bigam, C. Jayant, H. Ji, G. Little, A. Miller, R. C. Miller, R. Miller, A. Tatarowicz, B. White, S. White, and T. Yeh. VizWiz: nearly real-time answers to visual questions. In *User Interface Software and Technology (UIST)*, pages 333–342, 2010.
- [32] S. Kazemzadeh, V. Ordonez, M. Matten, and T. Berg. ReferItGame: Referring to objects in photographs of natural scenes. In *Empirical Methods in Natural Language Processing (EMNLP)*, pages 787–798, 2014.
- [33] L. Yu, P. Poirson, S. Yang, A. C. Berg, and T. L. Berg. Modeling context in referring expressions. In *European Conference on Computer Vision (ECCV)*, 2016.
- [34] T. Mesnard, C. Hardin, R. Dadashi, S. Bhupatiraju, S. Pathak, L. Sifre, M. Rivière, M. S. Kale, J. Love, P. Tafti, L. Hussenot, P. G. Sessa, A. Chowdhery, A. Roberts, A. Barua, A. Botev, A. Castro-Ros, A. Slone, A. Héliou, A. Tacchetti, A. Bulanova, A. Paterson, B. Tsai, B. Shahriari, C. L. Lan, C. A. Choquette-Choo, C. Crepy, D. Cer, D. Ippolito, D. Reid, E. Buchatskaya, E. Ni, E. Noland, G. Yan, G. Tucker, G.-C. Muraru, G. Rozhdestvenskiy,

- H. Michalewski, I. Tenney, I. Grishchenko, J. Austin, J. Keeling, J. Labanowski, J.-B. Lespiau, J. Stanway, J. Brennan, J. Chen, J. Ferret, J. Chiu, J. Mao-Jones, K. Lee, K. Yu, K. Millican, L. L. Sjoesund, L. Lee, L. Dixon, M. Reid, M. Mikuła, M. Wirth, M. Sharman, N. Chinaev, N. Thain, O. Bachem, O. Chang, O. Wahltinez, P. Bailey, P. Michel, P. Yotov, R. Chaabouni, R. Comanescu, R. Jana, R. Anil, R. McIlroy, R. Liu, R. Mullins, S. L. Smith, S. Borgeaud, S. Girgin, S. Douglas, S. Pandya, S. Shakeri, S. De, T. Klimenko, T. Hennigan, V. Feinberg, W. Stokowiec, Y. hui Chen, Z. Ahmed, Z. Gong, T. Warkentin, L. Peran, M. Giang, C. Farabet, O. Vinyals, J. Dean, K. Kavukcuoglu, D. Hassabis, Z. Ghahramani, D. Eck, J. Barral, F. Pereira, E. Collins, A. Joulin, N. Fiedel, E. Senter, A. Andreev, and K. Kenealy. Gemma: Open models based on gemini research and technology. *arXiv preprint arXiv:2403.08295*, 2024.
- [35] Y. Li, S. Bubeck, R. Eldan, A. D. Giorno, S. Gunasekar, and Y. T. Lee. Textbooks are all you need ii: phi-1.5 technical report. *arXiv preprint arXiv:2309.05463*, 2023.
- [36] J. Bai, S. Bai, Y. Chu, Z. Cui, K. Dang, X. Deng, Y. Fan, W. Ge, Y. Han, F. Huang, et al. Qwen technical report. *arXiv preprint arXiv:2309.16609*, 2023.
- [37] J. Li, D. Li, C. Xiong, and S. C. H. Hoi. BLIP: Bootstrapping language-image pre-training for unified vision-language understanding and generation. In *International Conference on Machine Learning (ICML)*, 2022.
- [38] J. Li, D. Li, S. Savarese, and S. C. H. Hoi. BLIP-2: Bootstrapping language-image pre-training with frozen image encoders and large language models. In *International Conference on Machine Learning (ICML)*, 2023.
- [39] W. Dai, J. Li, D. Li, A. M. H. Tiong, J. Zhao, W. Wang, B. A. Li, P. Fung, and S. C. H. Hoi. InstructBLIP: Towards general-purpose vision-language models with instruction tuning. *arXiv preprint arXiv:2305.06500*, 2023.
- [40] H. H. Tan and M. Bansal. LXMERT: Learning cross-modality encoder representations from transformers. In *Empirical Methods in Natural Language Processing (EMNLP)*, 2019.
- [41] H. Laurençon, L. Saulnier, L. Tronchon, S. Bekman, A. Singh, A. Lozhkov, T. Wang, S. Karamcheti, A. M. Rush, D. Kiela, M. Cord, and V. Sanh. OBELICS: An open web-scale filtered dataset of interleaved image-text documents. In *Neural Information Processing Systems Track on Datasets and Benchmarks (NeurIPS Datasets and Benchmarks)*, 2023.
- [42] H. Liu, C. Li, Q. Wu, and Y. J. Lee. Visual instruction tuning. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.
- [43] H. Liu, C. Li, Y. Li, and Y. J. Lee. Improved baselines with visual instruction tuning. *arXiv preprint arXiv:2310.03744*, 2023.
- [44] S. Karamcheti, S. Nair, A. Balakrishna, P. Liang, T. Kollar, and D. Sadigh. Prismatic vlms: Investigating the design space of visually-conditioned language models. *arXiv preprint arXiv:2402.07865*, 2024.
- [45] D. Kalashnikov, A. Irpan, P. Pastor, J. Ibarz, A. Herzog, E. Jang, D. Quillen, E. Holly, M. Kalakrishnan, V. Vanhoucke, et al. QT-Opt: Scalable deep reinforcement learning for vision-based robotic manipulation. *arXiv preprint arXiv:1806.10293*, 2018.
- [46] D. Kalashnikov, J. Varley, Y. Chebotar, B. Swanson, R. Jonschkowski, C. Finn, S. Levine, and K. Hausman. Mt-opt: Continuous multi-task robotic reinforcement learning at scale. *arXiv*, 2021.
- [47] F. Ebert, Y. Yang, K. Schmeckpeper, B. Bucher, G. Georgakis, K. Daniilidis, C. Finn, and S. Levine. Bridge data: Boosting generalization of robotic skills with cross-domain datasets. *arXiv preprint arXiv:2109.13396*, 2021.

- [48] K. Ehsani, T. Gupta, R. Hendrix, J. Salvador, L. Weihs, K.-H. Zeng, K. P. Singh, Y. Kim, W. Han, A. Herrasti, et al. Imitating shortest paths in simulation enables effective navigation and manipulation in the real world. *arXiv preprint arXiv:2312.02976*, 2023.
- [49] H. Bharadhwaj, J. Vakil, M. Sharma, A. Gupta, S. Tulsiani, and V. Kumar. Roboagent: Generalization and efficiency in robot manipulation via semantic augmentations and action chunking. *arXiv preprint arXiv:2309.01918*, 2023.
- [50] L. Pinto and A. Gupta. Supersizing self-supervision: Learning to grasp from 50k tries and 700 robot hours. In *2016 IEEE international conference on robotics and automation (ICRA)*, pages 3406–3413. IEEE, 2016.
- [51] A. Mandlekar, Y. Zhu, A. Garg, J. Booher, M. Spero, A. Tung, J. Gao, J. Emmons, A. Gupta, E. Orbay, et al. Roboturk: A crowdsourcing platform for robotic skill learning through imitation. In *Conference on Robot Learning*, pages 879–893. PMLR, 2018.
- [52] A. Gupta, A. Murali, D. P. Gandhi, and L. Pinto. Robot learning in homes: Improving generalization and reducing dataset bias. *Advances in neural information processing systems*, 31, 2018.
- [53] S. Dasari, F. Ebert, S. Tian, S. Nair, B. Bucher, K. Schmeckpeper, S. Singh, S. Levine, and C. Finn. Robonet: Large-scale multi-robot learning. *CoRL*, 2019.
- [54] S. Cabi, S. G. Colmenarejo, A. Novikov, K. Konyushkova, S. Reed, R. Jeong, K. Zolna, Y. Aytar, D. Budden, M. Vecerik, O. Sushkov, D. Barker, J. Scholz, M. Denil, N. de Freitas, and Z. Wang. Scaling data-driven robotics with reward sketching and batch reinforcement learning. *RSS*, 2019.
- [55] E. Jang, A. Irpan, M. Khansari, D. Kappler, F. Ebert, C. Lynch, S. Levine, and C. Finn. Bc-z: Zero-shot task generalization with robotic imitation learning. In *Conference on Robot Learning*, pages 991–1002. PMLR, 2022.
- [56] H.-S. Fang, H. Fang, Z. Tang, J. Liu, C. Wang, J. Wang, H. Zhu, and C. Lu. Rh20t: A comprehensive robotic dataset for learning diverse skills in one-shot. *Towards Generalist Robots: Learning Paradigms for Scalable Skill Acquisition@ CoRL2023*, 3:5, 2023.
- [57] C. Devin, A. Gupta, T. Darrell, P. Abbeel, and S. Levine. Learning modular neural network policies for multi-task and multi-robot transfer. In *Proceedings of IEEE International Conference on Robotics and Automation*, 2017.
- [58] E. S. Hu, K. Huang, O. Rybkin, and D. Jayaraman. Know thyself: Transferable visual control policies through robot-awareness. In *International Conference on Learning Representations*, 2022.
- [59] J. H. Yang, D. Sadigh, and C. Finn. Polybot: Training one policy across robots while embracing variability. In *7th Annual Conference on Robot Learning*, 2023. URL <https://openreview.net/forum?id=HEIRj51lcS>.
- [60] S. Reed, K. Zolna, E. Parisotto, S. G. Colmenarejo, A. Novikov, G. Barth-maroon, M. Giménez, Y. Sulsky, J. Kay, J. T. Springenberg, T. Eccles, J. Bruce, A. Razavi, A. Edwards, N. Heess, Y. Chen, R. Hadsell, O. Vinyals, M. Bordbar, and N. de Freitas. A generalist agent. *Transactions on Machine Learning Research*, 2022. ISSN 2835-8856.
- [61] G. Salhotra, I.-C. A. Liu, and G. Sukhatme. Bridging action space mismatch in learning from demonstrations. *arXiv preprint arXiv:2304.03833*, 2023.
- [62] I. Radosavovic, B. Shi, L. Fu, K. Goldberg, T. Darrell, and J. Malik. Robot learning with sensorimotor pre-training. In *Conference on Robot Learning*, 2023.

- [63] D. Shah, A. Sridhar, A. Bhorkar, N. Hirose, and S. Levine. Gnm: A general navigation model to drive any robot. In *2023 IEEE International Conference on Robotics and Automation (ICRA)*, pages 7226–7233. IEEE, 2023.
- [64] K. Bousmalis, G. Vezzani, D. Rao, C. Devin, A. X. Lee, M. Bauza, T. Davchev, Y. Zhou, A. Gupta, A. Raju, et al. Robocat: A self-improving foundation agent for robotic manipulation. *arXiv preprint arXiv:2306.11706*, 2023.
- [65] D. Shah, A. Sridhar, N. Dashora, K. Stachowicz, K. Black, N. Hirose, and S. Levine. ViNT: A foundation model for visual navigation. In *7th Annual Conference on Robot Learning*, 2023. URL <https://arxiv.org/abs/2306.14846>.
- [66] J. Yang, C. Glossop, A. Bhorkar, D. Shah, Q. Vuong, C. Finn, D. Sadigh, and S. Levine. Pushing the limits of cross-embodiment learning for manipulation and navigation. *arXiv preprint arXiv:2402.19432*, 2024.
- [67] S. Y. Gadre, M. Wortsman, G. Ilharco, L. Schmidt, and S. Song. Cows on pasture: Baselines and benchmarks for language-driven zero-shot object navigation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 23171–23181, 2023.
- [68] Y. Du, K. Konyushkova, M. Denil, A. Raju, J. Landon, F. Hill, N. de Freitas, and S. Cabi. Vision-language models as success detectors. *arXiv preprint arXiv:2303.07280*, 2023.
- [69] Y. J. Ma, V. Kumar, A. Zhang, O. Bastani, and D. Jayaraman. Liv: Language-image representations and rewards for robotic control. In *International Conference on Machine Learning*, pages 23301–23320. PMLR, 2023.
- [70] X. Zhang, Y. Ding, S. Amiri, H. Yang, A. Kaminski, C. Esselink, and S. Zhang. Grounding classical task planners via vision-language models. *arXiv preprint arXiv:2304.08587*, 2023.
- [71] S. Sontakke, J. Zhang, S. Arnold, K. Pertsch, E. Bıyık, D. Sadigh, C. Finn, and L. Itti. Roboclip: One demonstration is enough to learn robot policies. *Advances in Neural Information Processing Systems*, 36, 2024.
- [72] J. Huang, S. Yong, X. Ma, X. Linghu, P. Li, Y. Wang, Q. Li, S.-C. Zhu, B. Jia, and S. Huang. An embodied generalist agent in 3d world. In *Proceedings of the International Conference on Machine Learning (ICML)*, 2024.
- [73] X. Li, M. Liu, H. Zhang, C. Yu, J. Xu, H. Wu, C. Cheang, Y. Jing, W. Zhang, H. Liu, et al. Vision-language foundation models as effective robot imitators. *arXiv preprint arXiv:2311.01378*, 2023.
- [74] H. Zhen, X. Qiu, P. Chen, J. Yang, X. Yan, Y. Du, Y. Hong, and C. Gan. 3d-vla: 3d vision-language-action generative world model. *arXiv preprint arXiv:2403.09631*, 2024.
- [75] PyTorch. Automatic mixed precision. URL <https://pytorch.org/docs/stable/amp.html>.
- [76] T. Dao. Flashattention-2: Faster attention with better parallelism and work partitioning. *arXiv preprint arXiv:2307.08691*, 2023.
- [77] Y. Zhao, A. Gu, R. Varma, L. Luo, C.-C. Huang, M. Xu, L. Wright, H. Shojanazeri, M. Ott, S. Shleifer, et al. Pytorch fsdp: experiences on scaling fully sharded data parallel. *arXiv preprint arXiv:2304.11277*, 2023.
- [78] N. Dorka, C. Huang, T. Welschehold, and W. Burgard. What matters in employing vision language models for tokenizing actions in robot control? In *First Workshop on Vision-Language Models for Navigation and Manipulation at ICRA 2024*.

- [79] X. Zhai, B. Mustafa, A. Kolesnikov, and L. Beyer. Sigmoid loss for language image pre-training. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 11975–11986, 2023.
- [80] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, et al. Learning transferable visual models from natural language supervision. In *International conference on machine learning*, pages 8748–8763. PMLR, 2021.
- [81] P. Sharma, N. Ding, S. Goodman, and R. Soricut. Conceptual captions: A cleaned, hypernymed, image alt-text dataset for automatic image captioning. In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 2556–2565, 2018.
- [82] C. Schuhmann, R. Vencu, R. Beaumont, R. Kaczmarczyk, C. Mullis, A. Katta, T. Coombes, J. Jitsev, and A. Komatsuzaki. Laion-400m: Open dataset of clip-filtered 400 million image-text pairs. *arXiv preprint arXiv:2111.02114*, 2021.
- [83] O. Sidorov, R. Hu, M. Rohrbach, and A. Singh. Textcaps: a dataset for image captioning with reading comprehension. In *Computer Vision—ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part II 16*, pages 742–758. Springer, 2020.
- [84] H. Face. Introducing idefics: An open reproduction of state-of-the-art visual language model. *Hugging Face Blog*, 2024.
- [85] H. Liu, C. Li, Q. Wu, and Y. J. Lee. Visual instruction tuning. *Advances in neural information processing systems*, 36, 2024.
- [86] B. McKinzie, Z. Gan, J.-P. Fauconnier, S. Dodge, B. Zhang, P. Dufter, D. Shah, X. Du, F. Peng, F. Weers, et al. Mm1: Methods, analysis & insights from multimodal llm pre-training. *arXiv preprint arXiv:2403.09611*, 2024.
- [87] J. Lin, H. Yin, W. Ping, Y. Lu, P. Molchanov, A. Tao, H. Mao, J. Kautz, M. Shoenybi, and S. Han. Vila: On pre-training for visual language models. *arXiv preprint arXiv:2312.07533*, 2023.
- [88] T. Dettmers, M. Lewis, Y. Belkada, and L. Zettlemoyer. Gpt3. int8 (): 8-bit matrix multiplication for transformers at scale. *Advances in Neural Information Processing Systems*, 35: 30318–30332, 2022.
- [89] NVIDIA. Tensorrt-llm. URL <https://github.com/NVIDIA/TensorRT-LLM>.
- [90] T. Z. Zhao, V. Kumar, S. Levine, and C. Finn. Learning fine-grained bimanual manipulation with low-cost hardware. *arXiv preprint arXiv:2304.13705*, 2023.
- [91] Y. Leviathan, M. Kalman, and Y. Matias. Fast inference from transformers via speculative decoding. In *International Conference on Machine Learning*, pages 19274–19286. PMLR, 2023.
- [92] A. Brohan, N. Brown, J. Carbajal, Y. Chebotar, J. Dabis, C. Finn, K. Gopalakrishnan, K. Hausman, A. Herzog, J. Hsu, et al. Rt-1: Robotics transformer for real-world control at scale. *arXiv preprint arXiv:2212.06817*, 2022.
- [93] E. Rosete-Beas, O. Mees, G. Kalweit, J. Boedecker, and W. Burgard. Latent plans for task agnostic offline reinforcement learning. In *Proceedings of the 6th Conference on Robot Learning (CoRL)*, 2022.
- [94] O. Mees, J. Borja-Diaz, and W. Burgard. Grounding language with visual affordances over unstructured data. In *Proceedings of the IEEE International Conference on Robotics and Automation (ICRA)*, London, UK, 2023.

- [95] S. Dass, J. Yapeter, J. Zhang, J. Zhang, K. Pertsch, S. Nikolaidis, and J. J. Lim. CLVR jaco play dataset, 2023. URL https://github.com/clvr-ai/clvr_jaco_play_dataset.
- [96] J. Luo, C. Xu, X. Geng, G. Feng, K. Fang, L. Tan, S. Schaal, and S. Levine. Multi-stage cable routing through hierarchical imitation learning. *arXiv preprint arXiv:2307.08927*, 2023.
- [97] A. Mandlekar, Y. Zhu, A. Garg, J. Booher, M. Spero, A. Tung, J. Gao, J. Emmons, A. Gupta, E. Orbay, S. Savarese, and L. Fei-Fei. RoboTurk: A crowdsourcing platform for robotic skill learning through imitation. *CoRR*, abs/1811.02790, 2018. URL <http://arxiv.org/abs/1811.02790>.
- [98] Y. Zhu, A. Joshi, P. Stone, and Y. Zhu. Viola: Imitation learning for vision-based manipulation with object proposal priors, 2023.
- [99] L. Y. Chen, S. Adebola, and K. Goldberg. Berkeley UR5 demonstration dataset. <https://sites.google.com/view/berkeley-ur5/home>.
- [100] G. Zhou, V. Dean, M. K. Srirama, A. Rajeswaran, J. Pari, K. Hatch, A. Jain, T. Yu, P. Abbeel, L. Pinto, C. Finn, and A. Gupta. Train offline, test online: A real robot learning benchmark, 2023.
- [101] C. Lynch, A. Wahid, J. Thompson, T. Ding, J. Betker, R. Baruch, T. Armstrong, and P. Florence. Interactive language: Talking to robots in real time. *IEEE Robotics and Automation Letters*, 2023.
- [102] S. Belkhale, Y. Cui, and D. Sadigh. Hydra: Hybrid robot actions for imitation learning. *arxiv*, 2023.
- [103] Y. Zhu, P. Stone, and Y. Zhu. Bottom-up skill discovery from unsegmented demonstrations for long-horizon robot manipulation. *IEEE Robotics and Automation Letters*, 7(2):4126–4133, 2022.
- [104] Z. J. Cui, Y. Wang, N. M. M. Shafiullah, and L. Pinto. From play to policy: Conditional behavior generation from uncurated robot data. *arXiv preprint arXiv:2210.10047*, 2022.
- [105] M. Heo, Y. Lee, D. Lee, and J. J. Lim. Furniturebench: Reproducible real-world benchmark for long-horizon complex manipulation. In *Robotics: Science and Systems*, 2023.
- [106] G. Yan, K. Wu, and X. Wang. ucsd kitchens Dataset. August 2023.
- [107] S. Nasiriany, T. Gao, A. Mandlekar, and Y. Zhu. Learning and retrieval from prior data for skill-based imitation learning. In *Conference on Robot Learning (CoRL)*, 2022.
- [108] H. Liu, S. Nasiriany, L. Zhang, Z. Bao, and Y. Zhu. Robot learning on the job: Human-in-the-loop autonomy and learning during deployment. In *Robotics: Science and Systems (RSS)*, 2023.
- [109] G. Quere, A. Hagenruber, M. Iskandar, S. Bustamante, D. Leidner, F. Stulp, and J. Vogel. Shared Control Templates for Assistive Robotics. In *2020 IEEE International Conference on Robotics and Automation (ICRA)*, page 7, Paris, France, 2020.
- [110] S. Saxena, M. Sharma, and O. Kroemer. Multi-resolution sensing for real-time control with vision-language models. In *7th Annual Conference on Robot Learning*, 2023. URL <https://openreview.net/forum?id=WuBv9-IGDUA>.
- [111] R. Shah, R. Martín-Martín, and Y. Zhu. MUTEX: Learning unified policies from multimodal task specifications. In *7th Annual Conference on Robot Learning*, 2023. URL <https://openreview.net/forum?id=PwqiaaEzJ>.

- [112] X. Zhu, R. Tian, C. Xu, M. Ding, W. Zhan, and M. Tomizuka. Fanuc manipulation: A dataset for learning-based manipulation with fanuc mate 200id robot. 2023.
- [113] R. Mendonca, S. Bahl, and D. Pathak. Structured world models from human videos. *CoRL*, 2023.
- [114] J. Luo, C. Xu, F. Liu, L. Tan, Z. Lin, J. Wu, P. Abbeel, and S. Levine. Fmb: a functional manipulation benchmark for generalizable robotic learning. *arXiv preprint arXiv:2401.08553*, 2024.
- [115] N. M. M. Shafiullah, A. Rai, H. Etukuru, Y. Liu, I. Misra, S. Chintala, and L. Pinto. On bringing robots home, 2023.
- [116] B. Liu, Y. Zhu, C. Gao, Y. Feng, Q. Liu, Y. Zhu, and P. Stone. Libero: Benchmarking knowledge transfer for lifelong robot learning. *Advances in Neural Information Processing Systems*, 36, 2024.
- [117] V. Sanh, L. Debut, J. Chaumond, and T. Wolf. Distilbert, a distilled version of bert: smaller, faster, cheaper and lighter. *arXiv preprint arXiv:1910.01108*, 2019.

A 数据混合细节

我们在表 3 中列出了所使用的数据混合。该混合主要遵循 [5]，并添加了少量额外数据集。

OpenVLA Training Dataset Mixture	
Fractal [92]	12.7%
Kuka [45]	12.7%
Bridge[6, 47]	13.3%
Taco Play [93, 94]	3.0%
Jaco Play [95]	0.4%
Berkeley Cable Routing [96]	0.2%
Roboturk [97]	2.3%
Viola [98]	0.9%
Berkeley Autolab UR5 [99]	1.2%
Toto [100]	2.0%
Language Table [101]	4.4%
Stanford Hydra Dataset [102]	4.4%
Austin Buds Dataset [103]	0.2%
NYU Franka Play Dataset [104]	0.8%
Furniture Bench Dataset [105]	2.4%
UCSD Kitchen Dataset [106]	<0.1%
Austin Sailor Dataset [107]	2.2%
Austin Sirius Dataset [108]	1.7%
DLR EDAN Shared Control [109]	<0.1%
IAMLab CMU Pickup Insert [110]	0.9%
UTAustin Mutex [111]	2.2%
Berkeley Fanuc Manipulation [112]	0.7%
CMU Stretch [113]	0.2%
BC-Z [55]	7.5%
FMB Dataset [114]	7.1%
DobbE [115]	1.4%
DROID [11]	10.0% ⁶

表 3: OpenVLA 训练数据混合，使用来自 Open X-Embodiment 数据集 [1] 的数据集，遵循 [5] 并添加少量额外数据集。

B 评估任务与详细结果

在本节中，我们提供第 5.1 节讨论的 BridgeData V2 WidowX 和 Google 机器人评估的更多细节，以及第 5.2 节讨论的 Franka-Tabletop 和 Franka-DROID 微调评估的更多细节。

B.1 BridgeData V2 WidowX 评估细节

这里我们重点讨论第 5.1 节中描述的 BridgeData V2 评估。

B.1.1 BridgeData V2 评估任务

如第 5.1 节所述，我们在 17 个任务上对每个通用机器人操作策略进行评估，每个任务进行 10 次试验。本节提供任务类别和具体任务的详细信息。

我们总共评估了 5 个视觉泛化任务、2 个运动泛化任务、3 个物理泛化任务、4 个语义泛化任务和 3 个语言基础任务。请注意，我们评估的所有任务都引入了某种形式的分布偏移，因为我们无法获得原始数据集中使用的确切物体（其他分布偏移在我们复现最初在不同地点构建的真实世界测试环境时自然产生；关于此类分布偏移的详细讨论见附录 B.1.2）。所有 17 个任务如图 7 所示。每次执行

⁶ 由于学习进展缓慢（见第 3.3 节），我们在训练的最后三分之一阶段移除了 DROID，并将其混合权重重新分配给所有其他数据集。




图 7: BridgeData V2 WidowX 机器人评估任务。我们在 4 种类型的分布外 (OOD) 泛化任务上评估每个通用机器人策略: 视觉、运动、物理和语义 (定义见第 5.1 节)。每对图像显示机器人完成任务后的起始状态和示例结束状态。我们还在底部 3 行所示的 3 个任务中严格评估语言基础能力, 通过改变提示同时固定初始状态, 测试策略是否能够接近正确的目标物体。

标记为失败（0）或成功（1）。在一些更困难的任务中，我们记录部分成功（0.5）；我们在下面的任务描述中说明部分得分的条件。下面我们按照图 7 所示的顺序描述这 17 个任务：1. 将茄子放入锅中（简易版）：机器人的目标是拿起茄子并将其放入锅中。这是一个视觉泛化任务，因为我们使用了一个手工制作的纸锅，其外观与原始 BridgeData V2 训练数据集中使用的锅不同（因为我们无法获得原始锅）。与其他 16 个任务不同，对于这个特定任务，我们在展开策略之前将机器人的末端执行器直接初始化在茄子上方；因此，我们称之为“将茄子放入锅中”任务的“简易版”。2. 将茄子放入锅中：这与上述任务相同，只是机器人的末端执行器没有直接初始化在茄子上方。相反，我们将其初始化在所有展开中固定的位置，这意味着机器人必须首先水平伸向茄子，然后才能操作它。（注意：这同样适用于下面描述的所有其他任务。）由于与上述相同的原因，这是一个视觉泛化任务。

3. 将杯子从台面放入水槽：机器人的目标是从厨房台面或晾碗架上拿起粉色杯子，并将其放入右侧的水槽中。这是一个视觉泛化任务，因为我们使用粉色杯子而不是蓝色杯子（原始 BridgeData V2 数据集中使用蓝色杯子，但我们发现我们评估的所有方法都无法可靠地操作它——很可能是因为杯子的颜色与水槽的颜色融为一体）。4. 将茄子放入锅中（有杂物）：这与“将茄子放入锅中”任务相同，只是由于存在多个干扰物体而更加困难。由于在正常的“将茄子放入锅中”任务中讨论的相同原因，这是一个视觉泛化任务，并且鉴于场景中存在未见过的干扰物，这一点更加明显。当机器人向正确的目标物体移动时，奖励部分得分（0.5 分中的

1 分）。

5. 将黄色玉米放在粉色盘子上：机器人的目标是拾取黄色玉米并将其放置在粉色盘子上。由于场景中存在未见过的干扰物体，例如水槽后部台面上的绿色恐龙，这是一项视觉泛化任务。当机器人朝正确的目标物体移动时，给予部分得分（1 分中的 0.5 分）。

6. 举起茄子：机器人的目标是抓取茄子并将其举到空中。这是一项运动泛化任务，因为茄子的初始位置和/或朝向是未见过的，机器人被迫超出其训练分布中的位置和/或朝向范围，并且通常需要执行长距离伸展才能完成任务。（注意：在原始 BridgeData V2 演示中，该环境未演示长距离伸展；详见附录 B.1.2。）我们发现这项任务看似简单，但对许多策略来说却具有欺骗性的挑战性。当机器人与茄子接触时，给予部分得分（1 分中的 0.5 分）。

7. 将胡萝卜放在盘子上（带高度变化）：机器人的目标是拾取胡萝卜并将其放置在黄色盘子上。这是一项运动泛化任务，因为盘子从其通常位于水槽底部的位置被抬高，机器人必须调整其轨迹，以正确地将胡萝卜放置在升高的平台上（过程中不能碰倒盘子）。当机器人抓住胡萝卜并用其触碰盘子时，给予部分得分（1 分中的 0.5 分）。

8. 将胡萝卜放在盘子上：这与上述任务相同，只是盘子处于其正常位置（水槽底部或沥水架）。我们认为这是一项物理泛化任务，因为胡萝卜的大小和形状与原始 BridgeData V2 数据集中使用的不同，后者更短更窄。（请注意，上面列出的该任务的先前版本在技术上也是一项物理泛化任务，因为它涉及相同的胡萝卜，但我们将其归入“运动泛化”类别，因为这是那里的重点。）

9. 将锅翻正：机器人的目标是操纵锅，使其在回合结束时在水槽中保持直立。这是一项物理泛化任务，因为该锅的大小和形状与原始 BridgeData V2 训练演示中使用的不同（我们使用的锅更宽更矮）。
10. 举起七号电池：机器人的目标仅是抓取七号电池并将其举到空中。这被视为一项物理泛化任务，因为该电池比此环境中 BridgeData V2 训练演示中看到的目标物体小得多且薄得多；详见附录 B.1.2。（注意，该目标物体在此环境的原始 BridgeData V2 演示中并不存在，因此这也属于“语义泛化”的一个实例，但我们仅将其归类为“物理泛化”，因为这是此处的主要关注点。）
11. 将骷髅头移入晾干架：机器人的目标是抓取骷髅头发条玩具并将其放入水槽左侧的黄色晾干架中。这是一项语义泛化任务，因为骷髅头是一个未见过的目标物体（未出现在 BridgeData V2 训练演示中）。
12. 举起白色胶带：机器人的目标是抓取白色胶带卷并将其举到空中。这是一项语义泛化任务，因为白色胶带卷是一个未见过的目标物体（未出现在 BridgeData V2 训练演示中）。（注意，该任务也可能被视为“物理泛化”，因为其形状与此环境中训练演示中看到的物体不同；大多数策略难以抓取具有这种环形结构的物体，它们经常将机器人的末端执行器直接移动到中心区域。）
13. 从锅中取出紫葡萄：机器人的目标是抓取位于钢锅内的紫葡萄并将其从锅中取出（通过将其举起和/或将其放到锅外的任何地方）。这是一项语义泛化任务，因为它是一个未见过的语言指令；机器人在原始 BridgeData V2 训练数据集中从未见过此任务。
14. 将蓝色杯子叠放在粉色杯子上：机器人的目标是抓取蓝色杯子并将其稳固地放在粉色杯子顶部。这是一项语义泛化任务，因为它是一个未见过的语言指令；机器人在此环境的原始 BridgeData V2 训练数据集中从未见过此任务。当机器人抓取蓝色杯子并用蓝色杯子触碰粉色杯子时，给予部分得分（1 分中的 0.5 分）。
15. 将{茄子，红瓶}放入锅中：这是一项语言基础任务。机器人的目标是将指定的目标物体放入锅中。场景中同时存在茄子和红瓶。我们进行配对评估：对于相同的初始状态，我们在一个回合中提示策略以茄子为目标，然后在下一个回合中以红瓶为目标。我们对每种方法用茄子测试 5 次，用红瓶测试 5 次，对两个目标物体使用相同的 5 个初始状态集。当机器人朝正确的目标物体移动时，给予部分得分（1 分中的 0.5 分）。
16. 举起{奶酪，红辣椒}：这是一项语言基础任务。机器人的目标是抓取并举起指定的目标物体。我们按照上述任务中的描述进行配对评估。当机器人朝正确的目标物体移动时，给予部分得分（1 分中的 0.5 分）。
17. 将{蓝杯，粉杯}放在盘子上：这是一项语言基础任务。机器人的目标是抓取指定的目标物体并将其放在盘子上。我们按照其他语言基础任务中的描述进行配对评估。当机器人朝正确的目标物体移动时，给予部分得分（1 分中的 0.5 分）。

B.1.2 将评估任务与原始 BridgeData V2 训练数据进行比较

我们在原始 BridgeData V2 数据集 [6] 中使用的水槽环境中进行评估。我们重现了该环境，以匹配 BridgeData V2 数据集中的原始环境，对机器人相对于水槽的位置以及摄像机相对于场景的位置进行了粗略近似。

由于原始数据集中缺乏这些位置的精确测量，我们无法重现完全相同的环境设置，并且由于机器人、水槽和摄像机位置的细微差异，自然产生了分布偏移。此外，由于我们在与收集训练演示不同的位置评估机器人策略，因此产生了其他自然分布偏移。例如，光照条件和背景（例如水槽后方可见区域）不可避免地与我们训练数据集中所见不同。此外，我们无法获得原始 BridgeData V2 数据集中使用的确切物体集合，因此训练时使用的物体与测试时使用的物体之间存在分布偏移。

尽管存在这些挑战，我们发现某些通用策略，如开放视觉语言动作模型（OpenVLA）和机器人变换器 2-X（RT-2-X），仍能开箱即用相当可靠地泛化并执行各种任务。其他通用策略，如机器人变换器 1-X（RT-1-X）和 Octo，也能完成部分任务，但在我们的 BridgeData V2 评估套件中面对更困难的泛化任务时表现挣扎。

原始的 BridgeData V2 数据集包含该特定水槽环境中以下七项任务的演示：“将锅翻正”、“将胡萝卜放在盘子上”、“将杯子从台面（或晾干架）放入水槽”、“将茄子放入锅中”、“将刀放在砧板上”、“将勺子放入锅中”以及“将杠杆竖直转向前方”。原始数据集中所有这些任务的样本图像见图 8。注意，在该环境中收集的所有训练演示的初始化方式均为：机器人的末端执行器在回合开始时直接位于目标物体上方。（然而，在 BridgeData V2 数据集的所有环境中并非如此；在其他一些环境中，机器人初始化时距离目标物体较远，因此必须先水平伸向物体，然后才能进行操作。）



图 8：原始 BridgeData V2 水槽环境任务。来自原始 BridgeData V2 数据集中水槽环境样本演示的图像显示，该环境中所有演示的初始化方式均为：机器人的末端执行器直接位于目标物体上方。注意，这些初始状态与我们在图 7 中展示的 BridgeData V2 评估任务所使用的初始状态不同。在我们的评估中，我们始终将机器人的末端执行器初始化到水槽上方的固定位置，而不是直接位于目标物体上方（除一项任务外：“将茄子放入锅中（简易版）”）。

在我们的 BridgeData V2 评估套件中，只有一个任务——“将茄子放入锅中（简易版）”——初始化时机器人末端执行器直接悬停在目标物体上方；在所有其他 16 个任务中，末端执行器初始化在水槽上方的固定位置，因此机器人必须水平伸向物体。这一初始条件，结合我们在评估套件中各种类型的分布外泛化中引入的分布偏移，对通用策略提出了挑战，并要求高度的鲁棒性才能成功完成任务。因此，像 RT-1-X 和 Octo 这样的策略的成功率低于先前工作中报告的水平。然而，我们发现其他策略如 RT-2-X 和 OpenVLA 尽管面临所有这些分布偏移和挑战，仍然取得了相对较强的性能。

B.1.3 BridgeData V2 评估详细结果

完整的 BridgeData V2 WidowX 评估结果见表 4。每种方法在 10 次试验中的成功次数，针对 17 个任务逐一列出。OpenVLA 在大多数任务中取得了最强的性能，并且在通用策略中具有最高的总体成功率。RT-2-X 也表现出良好的性能，优于 RT-1-X 和 Octo，尽管其表现不如 OpenVLA。RT-1-X 和 Octo 在这些泛化任务中普遍遇到困难。

表 4: BridgeData V2 WidowX 评估详细结果。我们报告了完整评估套件中 17 个任务（在第 5.1 节中讨论）的性能，包括视觉/运动/物理/语义泛化任务和语言基础任务。请注意，某些任务可能存在部分成功（得分为 0.5）；详情见附录 B.1.1。我们发现 OpenVLA 在大多数任务中表现最佳，总体性能最高，其次是 RT-2-X。另一方面，RT-1-X 和 Octo 在评估中表现挣扎，在若干任务中仅获得 0–2 次成功。所有任务的图示见图 7。

Category	Task	# Trials	RT-1-X # Successes	Octo # Successes	RT-2-X # Successes	OpenVLA (ours) # Successes
视觉泛化	将茄子放入锅中（简易版）	10	1	5	7	10
视觉泛化	将茄子放入锅中（含杂物）	10	1	3	5	6
视觉泛化	将黄色玉米放在粉色盘子上	10	1	4	8	9
运动泛化	抬起茄子	10	3	0	5	6
运动泛化	将胡萝卜放在盘子上（含高度变化）	10	2	1	4	5
物理泛化	将胡萝卜放在盘子上	10	1	0	1	8
物理泛化	将锅翻正	10	2	6	5	8
物理泛化	抬起 AAA 电池	10	0	0	2	7
语义泛化	将头骨移入晾干架	10	1	0	5	5
语义泛化	抬起白色胶带	10	3	0	0	1
语义泛化	将紫葡萄从锅中取出	10	6	0	5	4
语义泛化	将蓝色杯子叠放在粉色杯子上	10	0	5	0	5
语言基础	将{茄子，红瓶}放入锅中	10	2	5	4	8
语言基础	抬起{奶酪，红辣椒}	10	1	5	2	5
语言基础	将{蓝色杯子，粉色杯子}放在盘子上	10	5	5	5	9
Mean Success Rate			18.5±2.7%	20.0±2.6%	50.6±3.5%	70.6±3.2%

此外，在表 5 中，我们提供了表 2 中总结的量化推理实验的完整评估结果。对于这些评估，我们在 8 个具有代表性的 BridgeData V2 任务上测试策略，这些任务涵盖了完整评估套件中的所有任务类别。

表 5: 完整的量化推理结果。这里我们展示了表 2 中结果的详细版本。

Category	Task	# Trials	bfloat16 # Successes	int8 # Successes	int4 # Successes
Visual gen	Put Eggplant into Pot (Easy Version)	10	9	7	9
Visual gen	Put Eggplant into Pot	10	7	7	7
Visual gen	Put Cup from Counter into Sink	10	5	3	7
Motion gen	Lift Eggplant	10	6	4	7.5
Physical gen	Put Carrot on Plate	10	6	5	7
Physical gen	Lift AAA Battery	10	7	5	3
Semantic gen	Take Purple Grapes out of Pot	10	8	8	9
Language grounding	Put {Eggplant, Red Bottle} into Pot	10	9	7.5	8
Mean Success Rate			71.3 ± 4.8%	58.1 ± 5.1%	71.9 ± 4.7%

B.2 谷歌机器人评估细节

在本节中，我们提供第 5.1 节介绍的谷歌机器人评估的更多细节。

B.2.1 谷歌机器人评估任务

在谷歌机器人上，我们对每个通用机器人策略在 12 个任务上进行评估，每个任务执行 5 次，总共 60 次。前五个任务测试分布内条件，后七个任务测试更困难的分布外（OOD）条件。所有任务如图 9 所示。每次执行被标记为失败（0）或成功（1）。

下面我们描述这 12 个任务：

1. 抓取可乐罐（分布内）：机器人位于一个平台前，平台上放着一罐可乐。机器人的目标是抓取并举起可乐罐。




图 9：谷歌机器人评估任务。我们评估每个通用机器人策略在分布内任务和分布外（OOD）泛化任务上的表现。分布外任务涉及未见过的背景、目标物体、指令/物体关系以及语义概念（例如，来自互联网但未出现在机器人动作数据中的照片）。

2. 将苹果移到绿色罐子旁（分布内）：机器人位于一个平台前，平台上放着一个苹果和一个绿色汽水罐。机器人的目标是抓取苹果并将其移到绿色罐子旁边。
3. 将蓝色薯片袋移到苹果旁（分布内）：机器人位于一个平台前，平台上放着一个蓝色薯片袋和一个苹果。机器人的目标是抓取蓝色薯片袋并将其移到苹果附近。
4. 将可乐罐竖直放置（分布内）：机器人位于一个平台前，平台上放着一罐可乐，罐子水平侧放。机器人的目标是抓取可乐罐并将其调整为竖直位置。
5. 打开中间抽屉（分布内）：机器人位于一组三个抽屉前。机器人的目标是抓取中间抽屉的把手并将抽屉拉开。
6. 将橙子移到棕色薯片袋旁（分布外）：机器人位于一个平台前，平台上放着一个棕色薯片袋和一个橙子。一块带有蓝天白云图案的桌布覆盖在物体下方的平台上。机器人的目标是抓取橙子并将其带到薯片袋旁边。该任务属于分布外，因为橙子相对于训练数据集是未见过的物体，且桌布是未见过的背景。⁷

⁷ 参见 Brohan 等人 [7] 的附录，了解谷歌机器人评估中分布外条件的详细列表。

7. 抓取百事可乐罐（分布外）：机器人位于一个平台前方，平台上放着一罐百事可乐。平台下方覆盖着一块带有亮黄色/棕色图案的桌布。机器人的目标是抓取并举起可乐罐。该任务属于分布外，因为百事可乐罐是未见过的物体，桌布是未见过的背景。
8. 抓取香蕉（分布外）：机器人位于一个平台前方，平台上有一个苹果、一罐可口可乐和一根香蕉。机器人的目标是抓取并举起香蕉。该任务属于分布外，因为香蕉是未见过的目标物体。
9. 抓取绿色杯子（分布外）：机器人位于一个平台前方，平台上有一根香蕉、一罐百事可乐和一个绿色杯子。机器人的目标是抓取并举起绿色杯子。该任务属于分布外，因为场景中的所有物体在训练数据中都未出现过。
10. 将苹果放在盘子上（分布外）：机器人位于一个平台前方，平台上有一个盘子和一个苹果。机器人的目标是抓取苹果并将其移动到盘子上。该任务属于分布外，因为它是一条描述未见过的物体关系的新指令：训练演示仅涵盖将苹果移动到盘子附近，而不是将其放在盘子上面。
11. 将香蕉放入平底锅（分布外）：机器人位于一个平台前方，平台上有一个平底锅和一根香蕉。机器人的目标是抓取香蕉并将其放入平底锅中。该任务属于分布外，因为香蕉是未见过的目标物体，并且如前一任务所述，它是一条描述未见过的物体关系的新指令。
12. 将可乐罐移到泰勒·斯威夫特处（分布外）：机器人位于一个平台前方，平台上有一罐可口可乐和三位不同名人的照片，其中包括泰勒·斯威夫特。机器人的目标是抓取可乐罐并将其移动到泰勒·斯威夫特的照片处。该任务属于分布外，因为名人照片在机器人交互数据中未出现过。

B.2.2 详细的谷歌机器人评估结果

表 6：详细的谷歌机器人评估结果。我们报告了第 5.1 节中讨论的谷歌机器人评估的完整评估结果。每个通用策略在 12 个任务上以 60 次展开进行评估，涵盖分布内和分布外测试条件。在最后一行，我们报告每个策略的平均成功率 ± 标准误差。OpenVLA 和 RT-2-X 在整体上均显著优于 RT-1-X 和 Octo（由于误差条重叠，我们将两者的平均成功率加粗）。所有任务的图示见图 9。

Category	Task	# Trials	RT-1-X # Successes	Octo # Successes	RT-2-X # Successes	OpenVLA (ours) # Successes
In-distribution	Pick Coke Can	5	5	1	5	5
In-distribution	Move Apple near Green Can	5	3	3	3	5
In-distribution	Move Blue Chip Bag near Apple	5	0	3	4	5
In-distribution	Place Coke Can Upright	5	0	0	4	4
In-distribution	Open Middle Drawer	5	0	4	2	3
OOD	Move Orange near Brown Chip Bag	5	1	2	5	5
OOD	Pick Pepsi Can	5	3	0	5	4
OOD	Pick Banana	5	5	3	5	5
OOD	Pick Green Cup	5	1	0	5	5
OOD	Place Apple on Plate	5	0	0	4	4
OOD	Place Banana in Pan	5	0	0	2	4
OOD	Move Coke Can near Taylor Swift	5	2	0	3	2
Mean Success Rate			33.3±6.1%	26.7±5.8%	78.3±5.4%	85.0±4.6%

谷歌机器人评估的完整结果见表 6。总体而言，我们发现 RT-1-X 和 Octo 在评估任务上遇到困难；在若干任务中，它们往往在五次试验中连一次成功都无法实现。另一方面，RT-2-X 和 OpenVLA 表现出强劲的性能，在五次试验中每个任务至少完成两次；这两个视觉-语言-动作策略在该特定评估套件上的表现彼此相当。

B.3 数据高效适应实验细节

在本节中，我们提供第 5.2 节讨论的数据高效适应实验的更多细节，其中我们研究了微调后的 OpenVLA 策略在新机器人设置（如 Franka-Tabletop 和 Franka-DROID）上的有效性。

B.3.1 Franka-Tabletop 和 Franka-DROID 任务

我们为七个任务中的每一个收集了 10 – 150 个演示。前六个任务对应于我们称为“Franka-Tabletop”的机器人设置（Franka Emika Panda 机器人安装在桌面上），最后一个任务对应于我们称为“Franka-DROID”的机器人设置。

在 Franka-Tabletop 设置中，六个任务中的前三个对应于单指令任务且范围狭窄，而后三个任务对应于多指令任务，其中场景中存在多个物体，机器人必须根据语言指令操作正确的物体。




图 10: Franka-Tabletop 微调任务。第 5.2 节数据高效适应实验中使用的 Franka-Tabletop 任务，并在图 10 中详细描述，如上所示。六个任务中的前三个（显示在前三行）仅涉及单一指令，而后三个任务（显示在后三行）涉及多个物体和指令（指令指定目标物体或目标位置）。第一列显示与训练数据分布匹配的样本初始状态，而第二列显示分布外初始状态（例如，未见过的背景、目标物体、干扰物以及物体位置/方向）。第 5.2 节中的每个策略在分布内任务上使用 10 – 12 次展开进行评估，在分布外任务上使用 5 – 6 次展开进行评估。

下面我们描述图 10 中显示的六个 Franka-Tabletop 任务中的每一个：

1. 将胡萝卜放入碗中（单指令）：机器人的目标是抓取胡萝卜并将其放入碗中。我们为该任务的训练数据集收集了 50 次演示，每个回合中胡萝卜和碗被随机放置在桌面的不同位置。胡萝卜始终初始化在碗的左侧。评估时，每次试验记录为成功（1）或失败（0）；没有部分得分。
2. 将玉米倒入锅中（单指令）：机器人的目标是抓取红色碗，移向钢锅，并将内容物（黄色玉米）倒入锅中。我们为该任务的训练数据集收集了 50 次演示，每个回合中碗和锅被随机放置在桌面的不同位置。碗始终初始化在锅的右侧。评估时，每次试验记录为成功（1）或失败（0）；没有部分得分。
3. 将锅翻正（单指令）：机器人的目标是抓取钢锅（初始为竖直方向），将其旋转至正立位置，并放回桌面。我们仅为该任务的训练数据集收集了 10 次演示，钢锅被随机放置在桌面一小块区域内的不同位置。评估时，每次试验记录为成功（1）、失败（0）或部分成功（0.5）。部分成功包括抓取了锅但未将其翻正，或将其碰倒至正立位置但未小心引导。机器人必须在回合结束时松开锅才能获得满分。
4. 将<物体>移到盘子上（多指令）：机器人的目标是根据语言指令中指定的目标，抓取三个物体中的一个，并将其放在桌子右侧的盘子上。我们为该任务的训练数据集收集了 150 次演示，每个回合中三个物体的不同组合被随机放置在桌面上，并选择其中一个作为目标。盘子始终初始化在桌子的右侧。评估时，每次试验记录为成功（1）、失败（0）或部分成功（0.5）。当机器人首先接触的物体是正确的目标物体（即语言指令中指定的物体），但机器人未完成任务时，记录为部分成功。
5. 击倒<物体>（多指令）：机器人的目标是接近三个物体中的一个（取决于语言指令中指定的目标）并推动它直到倒下。我们为该任务收集了 70 个演示用于训练数据集，随机在桌子上放置三个物体的不同组合，并选择一个作为目标。在评估期间，每次试验被记录为成功（1）、失败（0）或部分成功（0.5）。当机器人首先接触的物体是正确的目标物体（即语言指令中指定的物体），但机器人未完成任务时，记录为部分成功。
6. 用毛巾盖住<物体>（多指令）：机器人的目标是抓住蓝色毛巾并将其放在三个物体中的一个上（取决于语言指令中指定的目标）。我们为该任务收集了 45 个演示用于训练数据集，随机在桌子上放置三个物体的不同组合。在评估期间，每次试验被记录为成功（1）、失败（0）或部分成功（0.5）。当机器人用毛巾首先接触的物体是正确的目标物体（即语言指令中指定的物体），但机器人未完成任务（例如，它将毛巾掉在桌子上而不是目标物体上方）时，记录为部分成功。当毛巾的任何部分覆盖在目标物体的顶面上时，给予满分，即物体不需要被完全覆盖。

对于每个 Franka 桌面任务，我们用 10-12 个分布内试验和 5-6 个分布外泛化试验来评估每种方法。分布内和分布外测试条件如图 10（第二列）所示。

我们在下面描述六个任务中每个任务的分布外测试条件：

1. 将胡萝卜放入碗中（分布外）：一个茄子（未见过的物体）取代了胡萝卜。
2. 将玉米倒入锅中（分布外）：一块未见过的棕色桌布覆盖在桌面上。
3. 将锅翻正（分布外）：一块未见过的白色桌布覆盖在桌面上。
4. 将<物体>移到盘子上（分布外）：一组三个未见过的物体被放置在桌子上。
5. 击倒<物体>（分布外）：两个未见过的干扰物体（红色塑料杯和棕色箱子）被放置在三个可见物体的后方。
6. 用毛巾盖住<物体>（分布外）：桌上的三个物体被倒置并放置在未见过的位置。

最后，在 Franka-DROID 环境中，我们实验了一个任务及其变体：擦桌子（见图 11）。在该任务中，机器人的目标是抓取刷子并将所有三个棕色小物体扫入簸箕。我们为该任务收集了 70 个演示用于训练数据集，并改变了所有物体的位置。




图 11：Franka-DROID 微调任务。此处展示的“擦桌子”任务是第 5.2 节中数据高效适应实验所使用的最终任务。左图展示了分布内试验的初始条件。右图展示了一个分布外试验，其中桌面上存在未见过的干扰物体。要完全完成任务，机器人必须抓取刷子并将所有三个物体扫入簸箕。

在测试时，我们在与训练数据匹配的分布内条件下（图 11 左）以及分布外条件下（图 11 右）进行评估，在分布外条件下，场景中的桌面上还存在干扰物体。由于每次试验可能有多种结果，我们定义了如下评分标准：每次试验的最高分为 2 分。如果机器人将所有三个物体扫入簸箕，则策略获得满分 2 分。如果成功将一个或两个物体扫入簸箕，则获得 1 分。否则，获得 0 分。我们用 18 次分布内试验和 12 次分布外试验评估每个策略，因此每个策略的总分为 60 分。

B.3.2 详细的 Franka-Tabletop 和 Franka-DROID 评估结果

Franka-Tabletop 与 Franka-DROID 评估的完整结果见表 7。我们评估了第 5.2 节讨论的方法。我们发现扩散策略在单指令 Franka-Tabletop 任务（如“将胡萝卜放入碗中”和“将玉米倒入锅中”）上表现出强劲性能，优于其他方法。然而，OpenVLA 和 Octo 在更多样化的多指令任务（“将<物体>移到盘子上”、“推倒<物体>”和“用毛巾盖住<物体>”）中取得了更高性能。在 Franka-DROID 环境中，OpenVLA 获得了最佳结果。总体而言，我们发现 OpenVLA 在两类任务上均取得了最高的平均性能。此外，在表 8 中，我们展示了表 1 中总结的参数高效微调实验结果的详细版本。在这些实验中，我们使用了两个 Franka-Tabletop 任务的代表性子集，包含分布内和分布外变体：一个窄单指令任务（“将胡萝卜放入碗中”）和一个多样多指令任务（“将<物体>移到盘子上”）。我们使用了与第 5.2 节相同的训练演示数量（分别为 50 和 150），详见附录 B.3.1。

表 7：详细的数据高效适应实验结果。此处我们展示了图 5 中总结结果的完整分解。我们报告了在新机器人任务上从头训练的扩散策略的性能，以及在相同数据上微调的通用策略的性能。每个策略均在分布内和分布外泛化条件下进行测试（Franka-Tabletop 任务见图 10，Franka-DROID 任务见图 11）。我们发现没有单一策略在所有任务上表现最佳：扩散策略在单指令任务上取得了高成功率，而 OpenVLA 和 Octo 在多样多指令任务上表现良好。然而，就总体性能而言，OpenVLA 在两个环境中均获得了最高的平均成功率。

		# trials	Diffusion Policy	Diffusion Policy (matched)	Octo	OpenVLA (scratch)	OpenVLA (ours)
Franka-Tabletop (5Hz)	“Put Carrot in Bowl” (in-distribution)	10	90.0%	80.0%	40.0%	70.0%	70.0%
	“Put Carrot in Bowl” (OOD)	5	20.0%	0.0%	20.0%	0.0%	40.0%
	“Pour Corn into Pot” (in-distribution)	10	100.0%	90.0%	0.0%	10.0%	50.0%
	“Pour Corn into Pot” (OOD)	5	80.0%	60.0%	0.0%	20.0%	60.0%
	“Flip Pot Upright” (in-distribution)	10	100.0%	85.0%	40.0%	85.0%	100.0%
	“Flip Pot Upright” (OOD)	5	50.0%	20.0%	0.0%	40.0%	80.0%
	“Move <object> onto Plate” (in-distribution)	12	25.0%	25.0%	41.7%	8.3%	75.0%
	“Move <object> onto Plate” (OOD)	6	8.3%	33.3%	8.3%	33.3%	58.3%
	“Knock <object> Over” (in-distribution)	12	33.3%	25.0%	83.3%	75.0%	75.0%
	“Knock <object> Over” (OOD)	6	16.7%	16.7%	33.3%	58.3%	83.3%
	“Cover <object> with Towel” (in-distribution)	12	16.7%	20.8%	91.7%	41.7%	50.0%
	“Cover <object> with Towel” (OOD)	6	16.7%	33.3%	91.7%	50.0%	50.0%
	Average		48.5±4.9%	43.4±4.7%	43.4±4.4%	43.4±4.6%	67.2±4.0%
Franka-DROID (15Hz)	“Wipe Table” (in-distribution)	18	50.0%	27.8%	52.8%	25.0%	55.6%
	“Wipe Table” + Distractors (OOD)	12	12.5%	25.0%	16.7%	16.7%	
	Average		35.0±8.0%	26.7±7.5%	38.3±8.5%	21.7±6.6%	58.3±7.2%

表 8：详细的参数高效微调实验结果。此处我们展示了表 1 中总结的详细任务性能结果。

		# trials	Full FT	Last layer only	Frozen vision	Sandwich	LoRA, r=32	LoRA, r=64
Franka-Tabletop (5Hz)	“Put Carrot in Bowl” (in-distribution)	10	90.0	40.0	40.0	90.0	60.0	90.0
	“Put Carrot in Bowl” (OOD)	5	40.0	0.0	40.0	0.0	60.0	40.0
	“Move <object> onto Plate” (in-distribution)	12	79.2	33.3	50.0	75.0	75.0	62.5
	“Move <object> onto Plate” (OOD)	6	41.7	33.3	58.3	41.7	75.0	66.7
	Average		69.7±7.2%	30.3±6.1%	47.0±6.9%	62.1±7.9%	68.2±7.5%	68.2±7.8%

C RT-2-X 与 OpenVLA 在 BridgeData V2 评估中的对比

本节中，我们补充了第 5.1 节讨论的 BridgeData V2 评估中 RT-2-X 与 OpenVLA 比较的更多细节。如前所述，OpenVLA 在比 RT-2-X 更大的 OpenX 数据子集上进行了预训练，并使用了融合的 SigLIP-DinoV2 视觉骨干网络，而非单一视觉编码器。然而，除了这些因素外，我们认为 OpenVLA 在 BridgeData V2 评估中（如图 3 所示）相对于 RT-2-X 的显著提升，还源于对 Bridge 数据集更仔细的预处理。

在开发 OpenVLA 模型的过程中，我们发现原始版本的 BridgeData V2 数据集包含许多全零（无操作）动作的转移。例如，在每个演示中，第一个时间步的真实动作都被记录为全零动作。因此，在未经任何数据预处理的情况下，直接在原始数据集上训练高表达力的 VLA 模型，会导致策略频繁预测全零动作并在评估期间冻结。因此，我们在训练 OpenVLA 模型时，简单地过滤掉了每个演示中的第一个转移，这在大多数情况下足以缓解冻结行为。

然而，RT-2-X 模型在训练时未进行此类数据预处理，因此如果不修改模型查询过程而直接部署，它往往会遭受上述冻结行为——这会严重降低 rollout 性能。由于这是一个专有模型，我们无法重新训练（例如，使用我们预处理过的 BridgeData V2 数据集版本），因此我们通过简单地查询模型的第二可能动作来缓解此问题，因为第一可能动作通常全为零，而第二可能动作则不是。（请注意，这与 RT-2-X 模型开发者在 Open X-Embodiment 实验 [1] 中报告的 BridgeData V2 评估所采用的变通方法相同。）这种变通方法使 RT-2-X 在 BridgeData V2 评估中的性能大幅提升——尽管我们认为与在预处理后的数据集版本上重新训练模型相比，这仍然不是最优的。

我们还尝试动态查询 RT-2-X，即首先采样第一可能动作，如果该动作为全零，则再采样第二可能动作。然而，根据我们的经验

发现动态查询的性能始终不如直接查询第二可能动作。我们推测这是由于动态查询引起的机器人动力学变化：在轨迹中途暂停以重新查询模型，会因查询流水线中不可忽略的延迟导致机器人运动轻微中断，进而造成细微的性能下降。因此，我们报告 RT-2-X 在始终查询第二可能动作时的性能，这与 Open X-Embodiment 项目中的做法一致 [1]。

D 附加实验与消融

在本节中，我们进行了若干附加实验，以分析 OpenVLA 模型架构和训练方案中各个组件的影响，并为本文前面章节中的论断提供定量证据。我们旨在回答以下问题：

1. OpenX 训练有多重要，它如何影响 OpenVLA 的性能（附录 D.1）？
2. 与仅使用 SigLIP 视觉编码器相比，使用融合的 SigLIP-DinoV2 视觉编码器对 OpenVLA 的性能有何影响（附录 D.2）？
3. 在 OpenVLA 中微调视觉编码器与冻结视觉编码器哪个更好（附录 D.3）？
4. 当策略性能与模型推理速度解耦时，第 5.3 节讨论的量化推理结果如何变化（附录 D.4）？

我们在以下各节中依次讨论针对上述每个问题的实验设置和结果。

D.1 OpenX 训练数据消融实验

如第 3.3 节所述，OpenVLA 在来自 Open X-Embodiment 数据集 [1]（OpenX）的大规模机器人本体、场景和任务数据集上进行训练。在本节中，我们对 OpenX 混合数据进行消融，仅在一个机器人数据集上训练 VLA 策略，以评估 OpenX 训练对策略性能的影响。请注意，我们已在微调机制中观察到消融 OpenX 训练的负面影响，如第 5.2 节所述（参见 OpenVLA（Scratch）），但我们在本节中讨论在另一个机器人本体上的额外实验，以提供更多支持性证据。

实验设置与任务。我们将原始 OpenVLA 模型与 **OpenVLA-Bridge** 进行比较，后者通过采用与 OpenVLA 相同的预训练 VLM（Prismatic VLM [44]）并仅在 BridgeData V2 [6] 上进行微调而得到，而不是使用附录 A 中讨论的整个 OpenX 训练混合数据。我们在附录 B.1.1 中讨论的 BridgeData V2 WidowX 机器人评估套件的 8 个代表性任务子集上评估 OpenVLA 和 **OpenVLA-Bridge**。任务列于表 9 中。

结果。OpenX 训练混合数据消融的结果如表 9 所示。通过比较 OpenVLA 与 OpenVLA-Bridge，我们发现性能急剧下降（绝对成功率降低 30%），这证明了 OpenX 预训练对最终策略性能的重要性。尽管语言基础性能未受影响，但我们观察到所有泛化类别的性能均有所下降。这一结果表明，OpenX 训练混合数据中场景、物体和任务的巨大多样性对于解锁 OpenVLA 模型改进的泛化能力至关重要。

D.2 双视觉编码器与单视觉编码器实验

OpenVLA 模型架构包含一个融合视觉骨干网络，该网络结合了 SigLIP [9] 和 DinoV2 [25] 编码器。在本节中，我们消融 DinoV2 组件，以评估使用双视觉编码器的重要性。

实验设置与任务。我们实例化了一个模型，**OpenVLA-Bridge-SigLIP**，它是 OpenVLA 的一个版本，仅在 BridgeData V2 上训练，并且仅由 SigLIP 编码器作为视觉骨干。我们将该模型与上一节（附录 D.1）中讨论的 OpenVLA-Bridge 模型进行比较，后者与原始 OpenVLA 模型共享相同的模型架构，并且仅在 Bridge 机器人数据上训练。因此，**OpenVLA-Bridge-SigLIP** 与 OpenVLA-Bridge 之间的唯一区别在于前者省略了 DinoV2 编码器，

表 9: BridgeData V2 WidowX 消融实验结果。我们在 8 个代表性任务的子集上评估各种方法，以评估 OpenVLA 模型架构和训练方案中不同组件的重要性。OpenVLA-Bridge 是 OpenVLA 的一个版本，没有经过 OpenX 训练（仅在 BridgeData V2 上训练），而 OpenVLA-Bridge-SigLIP 进一步通过移除 DinoV2 编码器来消融融合视觉骨干（其视觉骨干仅由 SigLIP 编码器组成）。我们观察到 OpenX 训练和融合视觉编码器都能提高策略性能，尽管前者的效果远大于后者。

Category	Task	# Trials	OpenVLA # Successes	OpenVLA-Bridge # Successes	OpenVLA-Bridge-SigLIP # Successes
Visual gen	Put Eggplant into Pot (Easy Version)	10	10	8	8
Visual gen	Put Eggplant into Pot	10	10	2	3
Visual gen	Put Cup from Counter into Sink	10	7	4	2
Motion gen	Lift Eggplant	10	7.5	5.5	6.5
Physical gen	Put Carrot on Plate	10	8	4	1
Physical gen	Lift AAA Battery	10	7	2	2
Semantic gen	Take Purple Grapes out of Pot	10	4	3	3
Language grounding	Put {Eggplant, Red Bottle} into Pot	10	7.5	8	7
Mean Success Rate			76.3 $\pm$ 4.8%	45.6 $\pm$ 5.6%	40.6 $\pm$ 5.5%

视觉骨干。我们在上一节描述的相同的 8 个 Bridge 任务子集上评估这些模型。

结果。双视觉编码器消融的结果如表 9 所示。从 OpenVLA-Bridge 到 OpenVLA-Bridge-SigLIP 的性能下降表明，在视觉骨干中额外包含 DinoV2 编码器可以提高策略性能。然而，这里 5% 的性能下降不如消融 OpenX 训练所观察到的 30% 的性能下降那么显著。DinoV2 中表示的低级空间特征似乎只在某些情况下有助于泛化。

D.3 微调与冻结视觉编码器实验

如第 3.4 节所讨论的，先前关于 VLM 的工作观察到冻结视觉编码器比微调其参数能获得更高的性能 [44]。然而，在训练 OpenVLA 时，我们微调了模型中所有 7B 参数，包括 SigLIP-DinoV2 视觉骨干，因为我们在开发早期发现微调视觉编码器能带来性能更高的 VLA——这一发现在各种预训练 VLM 和模型架构中都成立。我们在下面讨论这些发现的细节。

实验设置与任务。本节报告两种视觉-语言-动作策略的性能，这两种策略通过在 BridgeData V2 上微调 Prismatic 视觉语言模型 [44] 库中的两个不同预训练模型得到。两个预训练模型分别名为 SigLIP ViT-SO 224px 和 LLaVa v1.5 7B（复现版）；其架构和训练混合细节参见 Karamcheti 等人 [44]。本文在表 10 所示的各种 Bridge 任务上评估这两种策略。需注意，此处的评估配置与之前讨论的 Bridge 评估不同，因此结果无法与其他类似实验中的结果直接比较。

结果。微调与冻结视觉编码器实验的结果如表 10 所示。我们发现，对于所测试的两种视觉语言动作模型（VLA），微调视觉编码器均能在各类任务中显著提升成功率。从定性角度看，在某些情况下，部署冻结视觉编码器策略会导致机器人行为不稳定，明显欠佳。因此，我们在开发早期便决定不再对冻结视觉编码器进行进一步实验。

D.4 附加量化推理实验：解耦策略性能与

模型推理速度 在第 5.3 节中，我们在推理时评估了 OpenVLA 在不同精度水平下的表现：半精度（bfloat16）、8 位量化和 4 位量化。与其他两种方法相比，8 位量化导致 BridgeData V2 性能下降，我们假设性能下降是由 8 位量化所用操作导致的模型推理速度降低引起的。在本节中，我们进行实验以验证这一说法的真实性。具体而言，我们再次使用上述三种不同精度水平评估 OpenVLA，但现在采用阻塞控制。换句话说，每个动作在机器人上完全执行后，策略才预测下一个动作并由控制器执行。该方案控制系统

表 10：微调与冻结视觉编码器的实验结果。我们评估了在两种基于 Prismatic 视觉语言模型（VLM）库 [44] 中不同预训练视觉语言模型构建的视觉语言动作（VLA）策略中，微调（“微调”）与冻结视觉编码器（“冻结视觉”）的性能。此处展示的 BridgeData V2 WidowX 任务在与本工作其他 Bridge 实验相同的水槽环境中执行（但初始环境配置不同，因为这些评估是在项目早期阶段进行的）。我们发现微调视觉编码器对于获得良好的策略性能至关重要。某些冻结视觉编码器的评估因性能极差（接近零）和机器人行为不稳定而中止。在同时测试冻结视觉和微调方法的评估中，微调视觉编码器平均成功率达到 80.0%，而冻结视觉编码器平均成功率为 46.7%。

Task	# Trials	SigLIP ViT-SO 224px		LLaVa v1.5 7B (Reproduction)	
		Frozen Vision # Successes	Fine-Tuned # Successes	Frozen Vision # Successes	Fine-Tuned # Successes
Put Eggplant into Pot	10	7	10	5	9
Put Corn on Plate	10	10	9	0	9
Mean Success Rate		85	95	25	90
Put { Eggplant, Red Bottle } into Pot	4	2	4	–	3
Put { Blue Cup, Pink Cup } on Plate	4	0	0	–	0
Lift { Cheese, Red Chili Pepper }	4	0	3	–	2
Put { Strawberry, Lime } into Pot	4	1	0	–	3
Move { Sushi, Grapes }	4	3	4	–	3
Mean Success Rate		30	55	–	55

不同延迟量下各方法的动态特性，因此使我们能够测试策略动作预测的质量，而不受其预测速度的影响。实际上，具有更高吞吐量的精度级别——bfloat16 和 4 位量化——被迫以更慢的速度运行，以匹配部署 8 位精度 OpenVLA 时观察到的动态。因此，我们预期在阻塞控制下，OpenVLA 在 8 位精度下的性能与 bfloat16 和 4 位精度下的性能相当。

实验设置与任务。我们报告了在附录 D.1 和附录 D.2 中使用的相同 8 个 BridgeData V2 任务子集上，OpenVLA 在阻塞控制和量化推理下的性能。

结果。量化推理实验在阻塞控制下的结果如表 11 所示。与表 2 中 8 位量化因推理速度低而导致最差展开性能不同，在此我们观察到，在阻塞控制下评估以消除不同推理速度对任务性能的影响后，8 位量化的性能与 bfloat16 精度和 4 位量化相当。这证实了我们关于推理速度对先前实验（使用非阻塞控制时）中 8 位量化性能影响的假设。我们还发现，使用最低精度 4 位时没有显著的性能下降，这与第 5.3 节中的观察一致。

表 11：带阻塞控制的量化推理实验结果。我们报告了 OpenVLA 在各类 BridgeData V2 WidowX 任务上的成功率和标准误，推理时分别采用 bfloat16 精度（默认方法）、8 位量化（int8）和 4 位量化（int4）。所有平均成功率的误差条相互重叠，表明各方法性能相当。

Category	Task	# Trials	bfloat16 # Successes	int8 # Successes	int4 # Successes
Visual gen	Put Eggplant into Pot (Easy Version)	10	10	10	10
Visual gen	Put Eggplant into Pot	10	9	10	10
Visual gen	Put Cup from Counter into Sink	10	5	5	3
Motion gen	Lift Eggplant	10	8	7	7.5
Physical gen	Put Carrot on Plate	10	10	10	10
Physical gen	Lift AAA Battery	10	3	6	4
Semantic gen	Take Purple Grapes out of Pot	10	2	2	2
Language grounding	Put {Eggplant, Red Bottle} into Pot	10	9	9.5	8.5
Mean Success Rate			70.0 ± 5.1%	74.4 ± 4.9%	68.8 ± 5.2%

E LIBERO 仿真实验

我们在第 5.2 节和第 5.3 节中的先前讨论聚焦于将 OpenVLA 适配到新颖的真实世界机器人设置和任务。本节探索将 OpenVLA 适配到仿真机器人设置和任务，具体利用 **LIBERO** 基准 [116]。我们在仿真中的实验提供了两个关键优势：

1. 展示通用性：我们证明 OpenVLA 尽管仅在真实世界机器人数据上预训练，仍能有效适配仿真领域，克服真实世界与仿真环境和动力学之间潜在的差异。
2. 增强可访问性和可复现性：将 OpenVLA 集成到公开可用的仿真平台中，使我们的模型更易于其他研究者获取，尤其是那些可能无法接触机器人硬件的研究者。此外，仿真实验比真实世界实验更容易复现。

我们在附录 E.1 中讨论实验设置，在附录 E.2 中讨论结果。我们随 OpenVLA 代码库一同发布复现实验所需的材料。

E.1 LIBERO 仿真实验设置

仿真设置与任务。 LIBERO 基准 (LIBERO Benchmark) [116] 包含四个任务套件，旨在研究机器人操作中的终身学习，原始论文因此考察了多种任务上的前向与后向迁移。在我们的实验中，仅关注目标任务套件上的监督微调，衡量通过行为克隆在任务成功演示上训练的各种策略的性能。

我们对以下四个任务套件进行实验，每个套件包含 10 个任务，每个任务有 50 个人工遥操作演示：

- **LIBERO-空间 (LIBERO-Spatial)** 包含相同的物体集合但布局不同，测试模型对空间关系的理解。
- **LIBERO-物体 (LIBERO-Object)** 包含相同的场景布局但物体不同，测试模型对物体类型的理解。
- **LIBERO-目标 (LIBERO-Goal)** 包含相同的物体和布局但任务目标不同，测试模型对不同任务导向行为的知识。
- **LIBERO-Long** (也称为 **LIBERO-10**) 包含具有多样物体、布局和任务的长期任务。

我们对上述每个训练数据集进行了以下修改：

1. 为适应需要更高分辨率图像的方法（如 $256 \times 256\text{px}$ or 224×224 像素），我们以更高的分辨率 $256 \times 256\text{px}$ 重新生成了所有演示。基准提供的数据集原本由 128×128 像素的图像组成。我们发现，简单地将这些图像放大到 256×256 像素会导致图像质量较差。因此，我们选择从更高分辨率的图像开始，这些图像可以根据需要缩小，从而确保在各种分辨率要求下保持更高的图像质量。这些更高分辨率的图像是通过在仿真环境中使用所提供的人类收集演示中存储的动作逐步执行，并保存仿真器渲染的图像而获得的。

2. 我们从数据集中过滤掉所有“无操作”动作，即平移和旋转分量幅度接近零且不改变机器人夹爪状态的动作。我们发现，这一简单的数据清洗步骤对于高度表达的单步策略（如 OpenVLA）至关重要，否则这些策略会学会模仿这些无操作动作，从而在评估过程中在某些状态下无限期地冻结。

3. 我们在训练和测试时将所有第三人称图像旋转 180 度，因为我们观察到 LIBERO 环境返回的图像在我们的硬件上是上下颠倒的。

4. 由于我们通过模仿学习训练策略，而模仿学习期望演示是成功的，因此我们在相应的仿真环境中重放所有演示，并过滤掉未能完成任务（由环境的成功标准确定）的演示。结果，我们从 500 个 LIBERO-Spatial 演示中移除了 68 个，从 500 个 LIBERO-Object 演示中移除了 46 个，从 500 个 LIBERO-Goal 演示中移除了 72 个，从 500 个 LIBERO-Long 演示中移除了 121 个。
5. 在我们的比较中，对于所有方法，我们仅使用静态第三人称相机图像；我们不使用原始数据集中额外提供的腕部相机图像。这是为了进行公平比较，因为 OpenVLA 的视觉输入仅由第三人称相机图像组成。

比较。我们比较的方法包括从头训练的扩散策略（Diffusion Policy）⁸ [3]、在目标数据集上微调的 Octo [5]，以及通过 LoRA 在目标数据集上微调的 **OpenVLA** ($r = 32$ ，如第 5.3 节所述。每个策略在上述每个任务套件上独立训练（而非在所有四个套件组合上训练单一策略）。所有策略均使用相同的演示集进行训练，因此所有方法均受益于上述数据清洗步骤。

评估细节。为确保实验结果具有较低的方差，所有方法在每个任务套件上均经过 500 次试验评估，报告的性能为三个随机种子上的平均成功率（因此每个统计量共 1500 次试验）。尽管如前所述我们修改了训练数据集，但并未更改测试环境，而是使用原始 LIBERO 基准提供的相同初始环境配置。

E.2 LIBERO 仿真实验结果

我们在表 12 中展示了 LIBERO 实验结果。重要的是，我们观察到 OpenVLA 能够有效适应 LIBERO 仿真环境中的任务，因为它在所测试的方法中获得了最高的平均成功率和秩。然而，我们发现 OpenVLA 与其他方法之间的总体差距比第 5.2 节讨论的真实世界微调实验中的差距更小。我们将此归因于 OpenVLA 仅使用真实世界机器人数据进行预训练，而未使用仿真数据，这表明由于仿真环境与真实世界环境和动力学之间的领域差距，在仿真机器人任务上微调模型可能不如在真实世界任务上微调有效。我们在 Octo 的结果中看到了这一观点的证据——Octo 是另一个在大规模真实世界机器人数据上预训练的策略——相对于从头训练的扩散策略这一简单而强大的基线，其总体性能提升也很小。我们预计，如果在预训练数据混合中加入仿真数据，预训练和微调方法的性能提升将会增加。

表 12: LIBERO 仿真基准结果。我们报告了 LIBERO 基准中四个任务套件每种方法的成功率（SR）和标准误，基于三个随机种子各 500 次试验取平均。此外，我们展示了每种方法在每个任务套件内的排名，排名 1 表示该套件中最强的方法，排名 3 表示最弱的方法。（平均排名值得注意，因为它揭示了哪种方法最适合作为多种任务的默认选择；它比平均成功率更具信息量，因为后者未按各任务套件的难度进行归一化。）总体而言，我们发现微调后的 OpenVLA 取得了最高的平均成功率和排名，其次是微调后的 Octo，然后是从零开始训练的扩散策略。

	LIBERO-Spatial		LIBERO-Object		LIBERO-Goal		LIBERO-Long		Average	
	SR (↑)	Rank (↓)	SR (↑)	Rank (↓)	SR (↑)	Rank (↓)	SR (↑)	Rank (↓)	SR (↑)	Rank (↓)
Diffusion Policy from scratch	78.3 ± 1.1%	3	92.5 ± 0.7%	1	68.3 ± 1.2%	3	50.5 ± 1.3%	3	72.4 ± 0.7%	2.5
Octo fine-tuned	78.9 ± 1.0%	2	85.7 ± 0.9%	3	84.6 ± 0.9%	1	51.1 ± 1.3%	2	75.1 ± 0.6%	2
OpenVLA fine-tuned (ours)	84.7 ± 0.9%	1	88.4 ± 0.8%	2	79.2 ± 1.0%	2	53.7 ± 1.3%	1	76.5 ± 0.6%	1.5

本文采用 DROID 数据集论文 [11] 中描述的扩散策略实现，该实现以任务标签的 DistilBERT[117] 语言嵌入为条件生成动作。