

开放跨实体（Open X-Embodiment）：机器人学习数据集与 RT-X 模型 开放跨实体协作项目 0

robotics-transformer-x.github.io 艾比·奥尼尔³⁴, 阿卜杜勒·雷曼³⁷, 阿比纳夫·古普塔⁴, 阿比拉姆·马杜库里⁴⁵, 阿比舍克·古普塔⁴⁶, 阿比舍克·帕达尔卡¹⁰, 亚伯拉罕·李³⁴, 阿科恩·普利¹¹, 阿格里姆·古普塔²⁸, 阿杰·曼德莱卡²², 阿金基亚·贾因¹⁵, 阿尔伯特·通²⁸, 亚历克斯·比利¹¹, 亚历克斯·赫尔佐格¹¹, 亚历克斯·伊尔潘¹¹, 亚历山大·哈扎茨基²⁸, 阿南特·拉伊²³, 安奇特·古普塔¹⁹, 安德鲁·王³⁴, 安德烈·科洛博夫²⁰, 阿尼凯特·辛格^{11,34}, 阿尼梅什·加格⁹, 阿尼鲁达·肯巴维¹, 安妮·谢²⁸, 安东尼·布罗汉¹¹, 安东尼·拉芬¹⁰, 阿奇特·夏尔马²⁸, 阿雷费·亚瓦里³⁵, 阿尔汉·贾因⁴⁶, 阿什温·巴拉克里希纳³², 艾扎安·瓦希德¹¹, 本·伯吉斯·利默里克²⁵, 范金·金¹⁷, 伯恩哈德·舍尔科普夫¹⁸, 布莱克·伍尔夫³², 布莱恩·伊希特¹¹, 卢策吾^{27,8}, 查尔斯·徐³⁴, 夏洛特·勒³⁴, 切尔西·芬恩^{11,28}, 陈旺²⁸, 陈峰徐³⁴, 程驰^{5,28}, 陈光煌³⁸, 克里斯汀·陈¹¹, 克里斯托弗·阿吉亚²⁸, 楚尔·潘²⁸, 楚源·傅¹¹, 科琳·德文¹¹, 丹菲·徐⁹, 丹尼尔·莫顿²⁸, 丹尼·德里斯¹¹, 达芙妮·陈⁴⁶, 迪帕克·帕塔克⁴, 德鲁夫·沙阿³⁴, 迪特尔·比希勒¹⁸, 迪内什·贾亚拉曼⁴², 德米特里·卡拉什尼科夫¹¹, 多尔萨·萨迪格¹¹, 爱德华·约翰斯¹⁴, 伊桑·福斯特²⁸, 方晨刘³⁴, 费德里科·塞奥拉¹⁶, 费霞¹¹, 费宇赵¹³, 费利佩·维埃拉·弗鲁杰里²⁰, 弗里克·斯图尔普¹⁰, 高月周²³, 高拉夫·S·苏克哈特梅⁴³, 高塔姆·萨洛特^{43,15}, 葛岩³⁶, 吉尔伯特·冯³⁴, 朱利奥·斯基亚维⁷, 格伦·贝尔塞斯^{41,21}, 格雷戈里·卡恩³⁴, 杨广文³³, 关志王^{3,22}, 苏昊³⁶, 方浩树²⁷, 石浩辰²⁸, 鲍恒辉⁴³, 赫尼·本·阿莫尔², 亨利克·I·克里斯滕森³⁶, 古田浩树³¹, 霍曼加·巴拉德瓦杰^{4,19}, 霍默·沃克³⁴, 方宏杰²⁷, 胡伊·哈^{5,28}, 伊戈尔·莫达奇¹¹, 伊利亚·拉多萨沃维奇³⁴, 伊莎贝尔·莱亚尔¹¹, 杰基·梁¹¹, 贾德·阿布-查克拉²⁵, 金在亨¹⁷, 杰明·德雷克³⁴, 杨·彼得斯²⁹, 杨·施奈德¹⁸, 贾斯敏·许¹¹, 杰伊·瓦基尔¹⁹, 珍妮特·博格²⁸, 杰弗里·宾厄姆¹¹, 杰弗里·吴³⁴, 詹森·高²⁸, 胡家恒³⁰, 吴佳俊²⁸, 吴佳琳¹², 孙建凯²⁸, 罗建兰³⁴, 顾佳源³⁶, 谭杰¹¹, 吴智勋³¹, 吉米·吴²⁴, 卢静培³⁶, 杨静云²⁸, 吉滕德拉·马利克³⁴, 若昂·西尔维里奥¹⁰, 乔伊·赫伊纳²⁸, 乔纳森·布赫²⁸, 乔纳森·汤普森¹¹, 乔纳森·杨²⁸, 乔迪·萨尔瓦多¹, 约瑟夫·J·林¹⁷, 韩俊赫¹⁷, 王凯元³⁶, 卡尼什卡·拉奥¹¹, 卡尔·佩尔奇^{34,28}, 卡洛·豪斯曼¹¹, 基根·戈¹⁵, 基尔塔娜·戈帕拉克里希南¹¹, 肯·戈德堡³⁴, 肯德拉·伯恩¹¹, 肯尼斯·奥斯隆德¹¹, 川原崎健人³¹, 凯文·布莱克³⁴, 凯文·林²⁸, 凯文·张⁴, 基安娜·埃萨尼¹, 基兰·莱卡拉⁴³, 柯蒂斯·埃利斯⁴¹, 克里尚·拉纳²⁵, 克里希南·斯里尼瓦桑²⁸, 方宽³⁴, 库纳尔·普拉塔普·辛格⁶, 曾国豪¹, 凯尔·哈奇³², 凯尔·许²⁸, 洛朗·伊蒂⁴³, 劳伦斯·云亮·陈³⁴, 莱雷尔·平托²³, 李飞飞²⁸, 利亚姆·谭³⁴, 林西·“吉姆”·范²², 莱昂内尔·奥特⁷, 丽莎·李¹¹, 卢卡·韦斯¹, 马格努姆·陈¹³, 马里昂·莱珀特²⁸, 马里乌斯·梅梅尔⁴⁶, 富泽正吉³⁴, 玛莎·伊特基纳³², 马特奥·瓜曼·卡斯特罗⁴⁶, 马克斯·斯佩罗²⁸, 马克西米利安·杜²⁸, 迈克尔·安¹¹, 迈克尔·C·叶³⁶, 张明通³⁹, 丁明宇³⁴, 许敏浩¹⁷, 莫汉·库马尔·斯里拉马⁴, 莫希特·夏尔马⁴, 金武镇²⁸, 穆罕默德·祖拜尔·伊尔沙德³², 金泽直明³¹, 尼克拉斯·汉森³⁶, 尼古拉斯·希斯¹¹, 尼基尔·J·乔希¹¹, 尼科·苏恩德豪夫²⁵, 刘宁¹³, 诺曼·迪帕洛¹⁴, 努尔·穆罕默德·马希·沙菲乌拉²³, 奥伊尔·米斯³⁸, 奥利弗·克罗斯默⁴, 奥斯伯特·巴斯塔尼⁴², 潘纳格·R·桑凯蒂¹¹, 帕特里克·“树”·米勒³², 帕特里克·尹⁴⁶, 保罗·沃尔哈特¹¹, 徐鹏¹¹, 彼得·大卫·费根³⁷, 彼得·米特拉诺⁴⁰, 皮埃尔·塞尔马内¹¹, 彼得·阿比尔³⁴, 普里亚·孙达雷桑²⁸, 陈秋雨⁴⁶, 全武¹¹, 拉斐尔·拉法伊洛夫^{11,28}, 田然³⁴, 里亚·多希³⁴, 罗伯托·马丁·马丁³⁰, 罗汉·拜贾尔⁴⁶, 罗萨里奥·斯卡利塞⁴⁶, 罗斯·亨德里克斯¹, 罗伊·林³⁴, 钱润佳¹³, 张若涵²⁸, 拉塞尔·门东萨⁴, 鲁塔夫·沙阿³⁰, 瑞安·霍克³⁴, 瑞安·朱利安¹¹, 塞缪尔·布斯塔曼特¹⁰, 肖恩·基尔马尼¹¹, 谢尔盖·莱文^{11,34}, 林珊³⁶, 雪莉·摩尔¹¹, 希卡尔·巴尔⁴, 希文·达斯^{43,30}, 舒巴姆·索纳瓦尼², 舒巴姆·图尔西亚尼⁴, 宋舒然⁵, 徐思纯¹¹, 西丹特·哈尔达尔²³, 西达斯·卡拉姆切蒂²⁸, 西米恩·阿德博拉³⁴, 西蒙·吉斯特¹⁸, 索鲁什·纳西里亚尼³⁰, 斯特凡·沙尔¹⁵, 斯特凡·韦尔克¹¹, 斯蒂芬·田²⁸, 苏布拉马尼安·拉穆尔蒂³⁷, 苏迪普·达萨里⁴, 苏尼尔·贝尔哈莱²⁸, 朴成宰¹⁷, 苏拉杰·奈尔³², 苏维尔·米尔昌达尼²⁸, 长田隆之³¹, 坦梅·古普塔¹, 原田达也^{31,26}, 松岛达也³¹, 泰德·肖¹¹, 托马斯·科拉尔³², 余天和¹¹, 丁天力¹¹, 托多尔·达夫切夫¹¹, 托尼·Z·赵²⁸, 特拉维斯·阿姆斯特朗¹¹, 特雷弗·达雷尔³⁴, 特里尼蒂·钟³⁴, 维迪·贾因^{11,4}, 维卡什·库马尔⁴, 文森特·范霍克¹¹, 维托尔·吉齐利尼³², 詹伟³⁴, 周文轩^{11,4}, 沃尔夫拉姆·布加德⁴⁴, 陈曦¹¹, 陈翔宇¹³, 王晓龙³⁶, 朱星浩³⁴, 耿新阳³⁴, 刘希元¹³, 徐良伟¹³, 李玄林³⁶, 庞岩松¹¹, 卢瑶¹¹, 马业成·杰森⁴², 金艺珍¹, 叶夫根·切博塔尔¹¹, 周逸凡²⁹, 朱逸峰³⁰, 吴怡琳⁴, 徐颖¹¹, 王艺璇³⁹, 约纳坦·比斯克⁴, 窦永强³³, 赵允英¹⁷, 李永元³⁴, 崔雨辰²⁸, 曹越¹³, 吴月华³⁶, 唐宇晋^{11,31}, 朱玉可³⁰, 张云初⁴⁶, 江云帆²⁸, 李云爽⁴², 李云竹³⁹, 岩泽佑介³¹, 松尾丰³¹, 马泽涵³⁴, 徐卓¹¹, 崔子辰·杰夫²³, 张子辰¹, 傅子鹏²⁸, 林子鹏³⁴




图 1：我们提出了一个开放的大规模机器人学习数据集，由全球 21 家机构共同整理。该数据集涵盖了多样的行为、机器人形态和环境，能够支持学习通用机器人策略。

摘要——在多样化数据集上训练的大型高容量模型，在高效处理下游应用方面取得了显著成功。从自然语言处理到计算机视觉领域，这导致了预训练模型的整合，通用预训练骨干网络成为许多应用的起点。

这种整合能否在机器人学中发生？传统上，机器人学习方法为每个应用、每个机器人甚至每个环境训练单独的模型。我们能否训练出“通才”跨机器人策略，使其能高效适应新机器人、新任务和新环境？

在本文中，我们提供了标准化数据格式的数据集和模型，以探索在机器人操作背景下实现这一可能性的途径，并给出了展示有效跨机器人策略的实验结果。我们通过 21 家机构的合作，收集了来自 22 种不同机器人的数据集，展示了 527 项技能（160266 个任务）。我们证明，在此数据上训练的高容量模型（我们称之为 RT-X）表现出正向迁移，并通过利用其他平台的经验提升了多种机器人的能力。项目网站为 robotics-transformer-x.github.io。

I. 引言

机器学习和人工智能进展中的一个核心经验是，从多样化数据集进行大规模学习，可以通过提供通用预训练模型来构建能力强大的 AI 系统。事实上，通常在大规模多样化数据集上训练的通用模型，往往能超越在更小但更特定任务数据上训练的专用模型。例如，在从网络抓取的大规模数据集上训练的开集词汇分类器（如 CLIP [1]）往往优于在更有限数据集上训练的固定词汇模型，而在海量文本语料上训练的大语言模型 [2, 3] 往往优于仅在狭窄任务特定数据集上训练的系统。越来越多地，解决特定狭窄任务（例如视觉或自然语言处理）的最有效方法是适配通用模型。然而，这些经验很难应用于机器人领域：任何单一机器人领域可能过于狭窄，而且虽然计算机视觉和自然语言处理可以利用来自网络的大规模数据集，但机器人交互的可比大规模和广泛数据集却难以获得。即使最大的数据收集工作，最终得到的数据集在规模和多样性上也仅为视觉（5-18M）[4, 5] 和自然语言处理（1.5B-4.5B）[6, 7] 基准数据集的一小部分。更重要的是，此类数据集往往在某些变化轴上仍然狭窄，要么专注于单一环境、单一物体集合，要么专注于狭窄的任务范围。我们如何克服机器人领域的这些挑战，并将机器人学习领域推向在其他领域已取得巨大成功的大数据机制？受在多样化数据上预训练大型视觉或语言模型所带来的泛化能力启发，我们采取这样的观点：训练可泛化机器人策略的目标需要跨实体训练，即使用来自多个机器人平台的数据。虽然每个单独的机器人学习数据集可能过于狭窄，但所有这些数据集的并集提供了更好的变化覆盖。

在环境和机器人中。学习可泛化的机器人策略需要开发能够利用跨实体（X-embodiment）数据的方法，从而利用来自许多实验室、机器人和环境的数据集。即使这些数据集目前的规模和覆盖范围不足以达到大语言模型所展示的令人印象深刻的泛化结果，未来这些数据的联合有可能提供这种覆盖。因此，我们认为在当前关头，推动跨实体机器人学习的研究至关重要。基于这一理由，我们有两个目标：（1）评估在来自许多不同机器人和环境的数据上训练的策略是否享有正迁移的好处，比仅在每个评估设置的数据上训练的策略获得更好的性能。（2）组织大型机器人数据集，以支持未来跨实体模型的研究。我们将工作重点放在机器人操作上。针对目标（1），我们的实证贡献是证明几种最近的机器人学习方法，在最小修改的情况下，可以利用跨实体数据并实现正迁移。具体来说，我们在 9 种不同的机器人操作器上训练 RT-1 [8] 和 RT-2 [9] 模型。我们表明，由此产生的模型（我们称之为 RT-X）可以比仅在评估领域数据上训练的策略有所改进，表现出更好的泛化能力和新的能力。针对目标（2），我们提供了开放跨实体（OXE）仓库，其中包括来自 21 个不同机构的 22 种不同机器人实体的数据集，可以使机器人社区进一步开展跨实体模型的研究，并提供开源工具以促进此类研究。我们的目标不是在特定架构和算法方面进行创新，而是提供我们训练的模型以及数据和工具，以激发围绕跨实体机器人学习的研究。

II. 相关工作

跨实体迁移。已有大量先前工作研究了在仿真中跨机器人形态迁移的方法 [10 – 22]，以及在真实机器人上的迁移方法 [23 – 29]。这些方法通常引入专门设计的机制来应对不同机器人之间的形态差异，例如共享动作表示 [14, 30]、引入表示学习目标 [17, 26]、根据形态信息调整学习策略 [11, 15, 18, 30, 31]，以及解耦机器人与环境表示 [24]。先前工作已初步展示了使用变换器模型进行跨形态训练 [27] 和迁移 [25, 29, 32] 的可行性。我们研究了互补的架构并提供了互补的分析，特别研究了跨形态迁移与网络规模预训练之间的相互作用。类似地，跨人类与机器人形态的迁移方法也常采用缩小形态差异的技术，即通过域间转换或学习可迁移表示 [33 – 43]。另一些工作则聚焦于问题的子方面，例如从人类视频数据中学习可迁移的奖励函数 [17, 44 – 48]、目标 [49, 50]、动力学模型 [51] 或视觉表示 [52 – 59]。与大多数这些先前工作不同，我们直接在跨形态数据上训练策略，不采用任何缩小形态差异的机制，并通过利用这些数据观察到正向迁移。

01 艾伦人工智能研究所；2 亚利桑那州立大学；3 加州理工学院；4 卡内基梅隆大学；5 哥伦比亚大学；6 洛桑联邦理工学院；7 苏黎世联邦理工学院；8 非夕机器人；9 佐治亚理工学院；10 德国航空航天中心；11 谷歌深度思维；12 谷歌研究院；13 IO-AI 科技；14 帝国理工学院；15 因特林西克有限责任公司；16 意大利理工学院；17 韩国科学技术院；18 马克斯·普朗克研究所；19 元人工智能；20 微软研究院；21 米拉魁北克；22 英伟达；23 纽约大学；24 普林斯顿大学；25 昆士兰科技大学；26 理化学研究所；27 上海交通大学；28 斯坦福大学；29 达姆施塔特工业大学；30 德克萨斯大学奥斯汀分校；31 东京大学；32 丰田研究所；33 清华大学；34 加利福尼亚大学伯克利分校；35 加利福尼亚大学戴维斯分校；36 加利福尼亚大学圣迭戈分校；37 爱丁堡大学；38 弗赖堡大学；39 伊利诺伊大学厄巴纳-香槟分校；40 密歇根大学；41 蒙特利尔大学；42 宾夕法尼亚大学；43 南加利福尼亚大学；44 纽伦堡技术大学；45 德克萨斯大学奥斯汀分校；46 华盛顿大学




图 2：开放跨形态数据集。 (a)：该数据集由 22 种形态的 60 个独立数据集组成。(b)：由于 Franka 数据集数量众多，Franka 机器人在视觉上不同的场景中具有最大的多样性。(c)：由于少数大型数据集，xArm 和 Google Robot 贡献了最多的轨迹数量。(d, e)：该数据集包含丰富的技能和常见物体多样性。

与大多数这些先前工作不同，我们直接在跨形态数据上训练策略，不采用任何缩小形态差异的机制，并通过利用这些数据观察到正向迁移。

大规模机器人学习数据集。 机器人学习社区已创建了开源的机器人学习数据集，涵盖抓取 [60 – 71]、推动交互 [23, 72 – 74]、物体与模型集合 [75 – 85] 以及遥操作演示 [8, 86 – 95]。除 RoboNet[23] 外，这些数据集包含的是同类型机器人的数据，而我们关注的是跨多种形态的数据。我们的数据仓库目标与这些工作互补：我们将大量先前数据集处理并聚合为一个统一的标准化工具库，称为开放跨形态数据集，展示了机器人学习数据集如何以有意义且实用的方式共享。

语言条件机器人学习。 先前的工作旨在赋予机器人和其他智能体理解和遵循语言指令的能力 [96 – 101]，通常通过学习语言条件策略 [8, 40, 45, 102 – 106]。我们像许多先前的工作一样通过模仿学习训练语言条件策略，但使用大规模多具身演示数据。遵循先前在机器人模仿学习中利用预训练语言嵌入 [8, 40, 45, 103, 107 – 112] 和预训练视觉语言模型 [9, 113 – 115] 的工作，我们在实验中研究了这两种预训练形式，具体遵循 RT-1 [8] 和 RT-2 [9] 的方法。

三、开放 X 具身仓库

我们介绍开放 X 具身仓库 (robotics-transformer-x.github.io) ——一个开源仓库，包含大规模数据以及用于 X 具身机器人学习研究的预训练模型检查点。更具体地说，我们向更广泛的社区提供并维护以下开源资源：

- **开放 X 具身数据集：** 包含来自 22 种机器人具身的 100 万+ 机器人轨迹的机器人学习数据集。

- **预训练检查点：** 一系列 RT-X 模型检查点，可用于推理和微调。我们希望这些资源能为机器人学习中的 X 具身研究奠定基础，但这仅仅是个开始。开放 X 具身是一项社区驱动的努力，目前涉及全球 21 家机构，我们希望进一步扩大参与范围，并随着时间的推移壮大最初的开放 X 具身数据集。在本节中，我们总结数据集和 X 具身学习框架，然后讨论用于评估数据集的具体模型及其实验结果。

A. 开放 X 具身数据集

开放 X-Embodiment 数据集包含超过 100 万条真实机器人轨迹，涵盖 22 种机器人形态，从单臂机器人到双臂机器人和四足机器人。该数据集通过汇集全球 34 个机器人研究实验室的 60 个现有机器人数据集，并将其转换为一致的数据格式以便于下载和使用而构建。我们采用 RLDS 数据格式 [119]，该格式将数据保存为序列化的 tfrecord 文件，并适应不同机器人设置的各种动作空间和输入模式，例如不同数量的 RGB 相机、深度相机和点云。它还支持在所有主流深度学习框架中进行高效、并行的数据加载。有关数据存储格式和所有 60 个数据集的详细信息，请参见 robotics-transformer-x.github.io。

B. 数据集分析

图 2 分析了开放 X-Embodiment 数据集。图 2(a) 展示了按机器人形态划分的数据集分布，其中 Franka 机器人最为常见。这反映在不同形态的独特场景数量上（基于数据集




图 3: RT-1-X 和 RT-2-X 均以图像和文本指令作为输入，并输出离散化的末端执行器动作。RT-1-X 是一种专为机器人设计的架构，采用 FiLM[116] 条件化的 EfficientNet[117] 和 Transformer[118]。RT-2-X 基于视觉语言模型骨干，将动作表示为另一种语言，并将动作文本标记与视觉语言数据一起训练。

元数据)按形态划分(图 2(b))，其中 Franka 占主导地位。图 2(c) 展示了按形态划分的轨迹分布。为了进一步分析多样性，我们使用数据中存在的语言标注。我们使用 PaLM 语言模型 [3] 从指令中提取对象和行为。图 2(d,e) 展示了技能和对象的多样性。虽然大多数技能属于拾取-放置类别，但数据集的长尾包含诸如“擦拭”或“组装”等技能。此外，数据涵盖了各种家用物品，从电器到食品和器皿。

IV. RT-X 设计

为了评估跨实体训练能在多大程度上提升学习策略在单个机器人上的性能，我们需要具有足够容量的模型，以有效利用如此庞大且异构的数据集。为此，我们的实验将基于两种近期提出的基于变换器的机器人策略：RT-1 [8] 和 RT-2 [9]。本节简要总结这些模型的设计，并讨论我们如何在实验中将它们适配到跨实体设置。A. 数据格式整合 创建跨实体模型的一个挑战在于，不同机器人的观测空间和动作空间差异显著。我们在各数据集之间使用粗略对齐的动作和观测空间。模型接收近期图像和语言指令的历史作为观测，并预测一个 7 维动作向量，用于控制末端执行器 (x, y, z 、横滚、俯仰、偏航和夹爪开度或这些量的速率)。我们从每个数据集中选择一个标准相机视图作为输入图像，将其调整为统一分辨率，并将原始动作集转换为 7 自由度的末端执行器动作。我们在离散化之前对每个数据集的动作进行归一化。这样，模型的输出可以根据所使用的实体进行不同的解释（反归一化）。需要注意的是，尽管进行了这种粗略对齐，相机观测在不同数据集之间仍然存在显著差异，例如由于相机相对于机器人的位姿不同或相机属性不同，见图 3。类似地，对于动作空间，我们不对控制末端执行器的各数据集坐标框架进行对齐，并允许动作值表示绝对或相对位置或速度，具体取决于为每个机器人选择的原始控制方案。因此，相同的动作向量可能对不同机器人产生截然不同的运动。

B. 策略架构

我们在实验中考虑了两种模型架构：

(1) RT-1 [8]，一种基于变换器 (Transformer) 的高效架构，专为机器人控制设计；(2) RT-2 [9]，一种大型视觉语言模型，经协同微调后以自然语言词元形式输出机器人动作。两种模型均接收视觉输入和描述任务的自然语言指令，并输出词元化动作。对于每种模型，动作被词元化为沿八个维度均匀分布的 256 个区间；其中一个维度用于终止回合，其余七个维度用于末端执行器运动。尽管两种架构在其原始论文 [8, 9] 中已有详细描述，下文仍对每种架构作简要总结：RT-1 [8] 是一个基于变换器架构 [118]、拥有 3500 万参数的网络，专为机器人控制设计，如图 3 所示。它接收 15 幅图像的历史序列以及自然语言。每幅图像通过 ImageNet 预训练的 EfficientNet [117] 处理，自然语言指令被转换为 USE [120] 嵌入。视觉和语言表示随后通过 FiLM [116] 层交织，产生 81 个视觉语言词元。这些词元被输入仅解码器的变换器，输出词元化动作。RT-2 [9] 是一系列大型视觉语言动作模型 (VLA)，在互联网规模的视觉和语言数据以及机器人控制数据上训练。RT-2 将词元化动作转换为文本词元，例如，一个可能的动作可能是“1 128 91 241 5 101 127”。因此，任何预训练的视觉语言模型 (VLM [121 – 123]) 都可以针对机器人控制进行微调，从而利用 VLM 的主干网络并迁移其部分泛化特性。本文重点关注 RT-2-PaLI-X 变体 [121]，该变体基于视觉模型 ViT [124] 和语言模型 UL2 [125] 的主干网络构建，并主要在 WebLI [121] 数据集上预训练。

C. 训练与推理细节 两种模型均在其输出空间上使用标准分类交叉熵目标 (RT-1 为离散区间，RT-2 为所有可能的语言词元)。本文将跨所有实验使用的机器人数据混合定义为来自 9 个机械臂的数据，取自 RT-1 [8]、QT-Opt [66]、Bridge [95]、任务无关机器人游戏 [126, 127]、Jaco Play [128]、电缆布线 [129]、RoboTurk [86]、NYU VINN [130]、Austin VIOLA [131]、Berkeley Autolab UR5 [132]、TOTO [133] 和 Language




图 4: RT-1-X 的平均成功率比原始方法或 RT-1 高出 50%。RT-1 和 RT-1-X 具有相同的网络架构。因此, 性能提升可归因于在机器人数据混合上的协同训练。实验室标志表示真实机器人评估的物理位置, 机器人图片表示用于评估的实体形态。

Evaluation Setting	Bridge	Bridge	RT-1 paper 6 skills
Evaluation Location	IRIS (Stanford)	RAIL Lab (UCB)	Google Robotic Lab
Robot Embodiment	WidowX	WidowX	Google Robot
Original Method	LCBC [95]	LCBC [95]	-
Original Method	13%	13%	-
RT-1	40%	30%	92%
RT-1-X	27%	27%	73%
RT-2-X (55B)	50%	30%	91%

表 I: 参数数量扩展实验, 用于评估容量对吸收大规模多样化实体数据的影响。对于这些大规模数据集 (Bridge 和 RT-1 论文数据), RT-1-X 欠拟合, 表现不如原始方法和 RT-1。参数数量显著更多的 RT-2-X 模型在这两个评估场景中可以获得强劲的性能。表 [91] 数据集。RT-1-X 仅在上面定义的机器人混合数据上训练, 而 RT-2-X 通过协同微调进行训练 (类似于原始 RT-2[9]), 原始 VLM 数据和机器人数据混合的比例大约为一比一。请注意, 我们实验中使用的机器人数据混合包含 9 种实体形态, 少于整个 Open X-Embodiment 数据集 (22 种) ——造成这种差异的实际原因是, 我们一直在随时间扩展数据集, 而在实验进行时, 上述数据集代表了全部数据。未来, 我们计划继续在数据集的扩展版本上训练策略, 并与机器人学习社区一起继续扩充数据集。在推理时, 每个模型以机器人所需的速率 (3-10 Hz) 运行, RT-1 在本地运行, RT-2 托管在云服务上并通过网络查询。

评估分为两类: 在具有小规模数据集的领域上进行评估 (图 4), 预期从更大数据集的迁移能显著提升性能; 以及在具有大规模数据集的领域上进行评估 (表 I), 预期进一步提升更具挑战性。注意, 本节所有评估均使用相同的机器人数据训练混合 (定义见第 IV-C 节)。对于小规模数据集实验, 使用厨房操作 [128]、线缆布线 [129]、纽约大学开门任务 [130]、AUTOLab UR5[132] 和机器人游戏 [134]。评估设置与机器人具身形态与相应论文保持一致。对于大规模数据集实验, 考虑 Bridge[95] 和 RT-1[8] 进行分布内评估, 并使用各自的机器人: WidowX 和谷歌机器人。

对于每个小数据集领域, 比较 RT-1-X 模型的性能; 对于每个大数据集, 同时考虑 RT-1-X 和 RT-2-X 模型。所有实验中, 模型均在完整的 X 具身数据集上联合训练。在整个评估过程中, 与两个基线模型进行比较: (1) 数据集创建者开发的模型, 仅在该数据集上训练。这是一个合理的基线, 因为可以预期该模型已针对相关数据进行了优化; 本文将该基线模型称为原始方法模型。(2) 在数据集上单独训练的 RT-1 模型; 该基线用于评估 RT-X 模型架构是否具备同时表示多个不同机器人平台策略的能力, 以及多具身数据联合训练是否能带来更高的性能。

五、实验结果

我们的实验回答了关于跨实体形态训练的效应的三个问题:

(1) 在我们的跨实体形态数据集上训练的策略能否有效实现正迁移, 使得在多个机器人上收集的数据上进行协同训练能够提高训练任务的性能? (2) 在来自多个平台和任务的数据上协同训练模型能否提高对新未见任务的泛化能力? (3) 不同的设计维度 (如模型大小、模型架构或数据集组成) 对所得策略的性能和泛化能力有何影响? 为了回答这些问题, 我们在 6 种不同的机器人上进行了总共 3600 次评估试验。

A. 不同具身形态的分布内性能。为评估 RT-X 模型从 X 具身数据中学习的能力, 本文在分布内任务上评估其性能。

小规模数据集领域 (图 4)。在 5 个数据集上的 4 个上, RT-1-X 的性能优于在每个机器人特定数据集上训练的原始方法, 平均提升幅度较大, 表明数据有限的领域从 X 具身数据联合训练中获益显著。

大规模数据集领域 (表一)。在大规模数据集设置下, RT-1-X 模型并未超越仅在特定实施例数据集上训练的 RT-1 基线, 这表明该模型类别存在欠拟合。然而, 更大的 RT-2-X 模型同时超越了原始方法和 RT-1, 表明跨机器人训练可以在数据丰富的领域提升性能, 但前提是采用足够高容量的架构。

Row	Model	Size	History Length	Dataset	Co-Trained w/ Web	Initial Checkpoint	Emergent Skills Evaluation	RT-2 Generalization Evaluation
(1)	RT-2	55B	none	Google Robot action	Yes	Web-pretrained	27.3%	62%
(2)	RT-2-X	55B	none	Robotics data	Yes	Web-pretrained	75.8%	61%
(3)	RT-2-X	55B	none	Robotics data except Bridge	Yes	Web-pretrained	42.8%	54%
(4)	RT-2-X	5B	2	Robotics data	Yes	Web-pretrained	44.4%	52%
(5)	RT-2-X	5B	none	Robotics data	Yes	Web-pretrained	14.5%	30%
(6)	RT-2-X	5B	2	Robotics data	No	From scratch	0%	1%
(7)	RT-2-X	5B	2	Robotics data	No	Web-pretrained	48.7%	47%

表二：消融实验展示设计决策对泛化能力（对未见物体、背景和环境）和涌现技能（来自其他数据集在谷歌机器人上的技能）的影响，表明网络预训练、模型规模和历史的重要性。B. 改进对分布外设置的泛化能力 我们现在考察跨实例训练如何能够实现对分布外设置以及更复杂和新鲜指令的更好泛化。这些实验聚焦于高数据领域，并使用 RT-2-X 模型。我们考察了物体运动（Object Motion）和位置改变（Positional Change）行为。我们发现在 RT-2 和 RT-2-X 的表现大致相当（表 II，第（1）和（2）行，最后一列）。这并不意外，因为 RT-2 已经凭借其视觉语言模型骨干在这些维度上具有良好的泛化能力（见图 5）。




图 5：为评估不同具身之间的迁移能力，我们在分布外技能上对 RT-2-X 模型进行了评估。这些技能存在于 Bridge 数据集中，但不在 Google Robot 数据集（即评估所用的具身）中。与先前 RT-2 的发现相反，联合微调与微调在涌现技能和泛化评估中表现相近（第（4）行与第（7）行），我们将其归因于 RT-2-X 所使用的机器人数据比先前使用的机器人数据集更加多样化。

涌现技能评估。为探究知识在不同机器人间的迁移，本文利用谷歌机器人（Google Robot）开展实验，评估其在图 5 所示类似任务上的性能。这些任务涉及的物体与技能未包含于 RT-2 数据集，但出现在面向另一机器人（WidowX 机器人）的 Bridge 数据集 [95] 中。结果见表 II“涌现技能评估”列。对比第（1）行与第（2）行可知，RT-2-X 的性能优于 RT-2，提升幅度为 $\sim 3\times$ ，这表明即使对于已拥有大量数据的机器人，将其他机器人的数据纳入训练也能扩展其可执行任务的范围。本文结果表明，利用其他平台数据进行协同训练，能够赋予 RT-2-X 控制器该平台原始数据集中所不具备的额外技能。下一项消融实验从 RT-2-X 训练中移除 Bridge 数据集：第（3）行展示了 RT-2-X 在移除 Bridge 数据集后的结果，其余数据保持不变。这一变化显著降低了在保留任务上的性能，表明 WidowX 数据的迁移可能确实是 RT-2-X 在谷歌机器人上展现额外技能的原因。

C. 设计决策

最后，我们进行消融实验，以衡量不同设计决策对性能最优的 RT-2-X 模型泛化能力的影响，结果见表 II。我们注意到，包含短时图像历史显著提升了泛化性能（行（4）与（5）行对比）。与 RT-2 论文 [9] 中的结论类似，基于网络的预训练对于大型模型实现高性能至关重要（（4）与（6）行对比）。我们还注意到，55B 模型在涌现技能上的成功率显著高于 5B 模型（（2）与（4）行对比），这表明更高的模型容量能够实现更高层次的迁移。

六、讨论、未来工作与开放问题

我们提出了一个整合数据集，汇集了来自 21 家机构合作收集的 22 种机器人具身的数据，展示了 527 项技能（160266 个任务）。我们还通过实验证明，基于变换器（Transformer）的策略在此数据上训练后，能够在数据集中不同机器人之间展现出显著的正向迁移。结果表明，RT-1-X 策略的成功率比各合作机构贡献的原始最先进方法高出 50%，而更大的基于视觉语言模型的版本（RT-2-X）则展示了 $\sim 3\times$ 相对于仅在评估具身数据上训练的模型的泛化改进。此外，我们为机器人社区提供了多种资源以探索跨具身机器人学习研究，包括：统一的跨机器人与跨机构数据集、展示数据使用方法的示例代码，以及作为未来探索基础的 RT-1-X 模型。尽管 RT-X 向跨具身机器人通才迈出了一步，但实现这一未来仍需更多努力。我们的实验未考虑感知与驱动模态差异很大的机器人。

未研究对新机器人的泛化，也未提供正向迁移何时发生或不发生的决策准则。研究这些问题是重要的未来工作方向。本研究不仅证明了跨机器人学习是可行且实用的，还为未来推进该方向的研究提供了工具。

参考文献

- [1] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark *et al.*, “Learning transferable visual models from natural language supervision,” in *International conference on machine learning*. PMLR, 2021, pp. 8748–8763.
- [2] OpenAI, “GPT-4 technical report,” 2023.
- [3] R. Anil, A. M. Dai, O. Firat, M. Johnson, D. Lepikhin, A. Passos, S. Shakeri, E. Taropa, P. Bailey, Z. Chen *et al.*, “PaLM 2 technical report,” *arXiv preprint arXiv:2305.10403*, 2023.
- [4] T. Weyand, A. Araujo, B. Cao, and J. Sim, “Google landmarks dataset v2 - a large-scale benchmark for instance-level recognition and retrieval,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2020.
- [5] B. Wu, W. Chen, Y. Fan, Y. Zhang, J. Hou, J. Liu, and T. Zhang, “Tencent ML-images: A large-scale multi-label image database for visual representation learning,” *IEEE Access*, vol. 7, 2019.
- [6] J. Lehmann, R. Isele, M. Jakob, A. Jentzsch, D. Kontokostas, P. N. Mendes, S. Hellmann, M. Morsey, P. van Kleef, S. Auer, and C. Bizer, “DBpedia - a large-scale, multilingual knowledge base extracted from wikipedia,” *Semantic Web*, vol. 6, no. 2, pp. 167–195, 2015. [Online]. Available: <http://dblp.uni-trier.de/db/journals/semweb/semweb6.html#LehmannIJJMHMK15>
- [7] H. Mühleisen and C. Bizer, “Web data commons-extracting structured data from two large web corpora,” *LDOW*, vol. 937, pp. 133–145, 2012.
- [8] A. Brohan, N. Brown, J. Carbajal, Y. Chebotar, J. Dabis, C. Finn, K. Gopalakrishnan, K. Hausman, A. Herzog, J. Hsu *et al.*, “RT-1: Robotics transformer for real-world control at scale,” *Robotics: Science and Systems (RSS)*, 2023.
- [9] A. Brohan, N. Brown, J. Carbajal, Y. Chebotar, X. Chen, K. Choromanski, T. Ding, D. Driess, A. Dubey, C. Finn *et al.*, “RT-2: Vision-language-action models transfer web knowledge to robotic control,” *arXiv preprint arXiv:2307.15818*, 2023.
- [10] C. Devin, A. Gupta, T. Darrell, P. Abbeel, and S. Levine, “Learning modular neural network policies for multi-task and multi-robot transfer,” in *2017 IEEE international conference on robotics and automation (ICRA)*. IEEE, 2017, pp. 2169–2176.
- [11] T. Chen, A. Murali, and A. Gupta, “Hardware conditioned policies for multi-robot transfer learning,” in *Advances in Neural Information Processing Systems*, 2018, pp. 9355–9366.
- [12] A. Sanchez-Gonzalez, N. Heess, J. T. Springenberg, J. Merel, M. Riedmiller, R. Hadsell, and P. Battaglia, “Graph networks as learnable physics engines for inference and control,” in *Proceedings of the 35th International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, J. Dy and A. Krause, Eds., vol. 80. PMLR, 10–15 Jul 2018, pp. 4470–4479. [Online]. Available: <https://proceedings.mlr.press/v80/sanchez-gonzalez18a.html>
- [13] D. Pathak, C. Lu, T. Darrell, P. Isola, and A. A. Efros, “Learning to control self-assembling morphologies: a study of generalization via modularity,” *Advances in Neural Information Processing Systems*, vol. 32, 2019.
- [14] R. Martín-Martín, M. Lee, R. Gardner, S. Savarese, J. Bohg, and A. Garg, “Variable impedance control in end-effector space. an action space for reinforcement learning in contact rich tasks,” in *Proceedings of the International Conference of Intelligent Robots and Systems (IROS)*, 2019.
- [15] W. Huang, I. Mordatch, and D. Pathak, “One policy to control them all: Shared modular policies for agent-agnostic control,” in *ICML*, 2020.
- [16] V. Kurin, M. Igl, T. Rocktäschel, W. Boehmer, and S. Whiteson, “My body is a cage: the role of morphology in graph-based incompatible control,” *arXiv preprint arXiv:2010.01856*, 2020.
- [17] K. Zakka, A. Zeng, P. Florence, J. Tompson, J. Bohg, and D. Dwibedi, “XIRL: Cross-embodiment inverse reinforcement learning,” *Conference on Robot Learning (CoRL)*, 2021.
- [18] A. Ghadirzadeh, X. Chen, P. Poklukar, C. Finn, M. Björkman, and D. Kragic, “Bayesian meta-learning for few-shot policy adaptation across robotic platforms,” in *2021 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*. IEEE, 2021, pp. 1274–1280.
- [19] A. Gupta, L. Fan, S. Ganguli, and L. Fei-Fei, “Meta-morph: Learning universal controllers with transformers,” in *International Conference on Learning Representations*, 2021.
- [20] I. Schubert, J. Zhang, J. Bruce, S. Bechtler, E. Parisotto, M. Riedmiller, J. T. Springenberg, A. Byravan, L. Hasenclever, and N. Heess, “A generalist dynamics model for control,” 2023.
- [21] D. Shah, A. Sridhar, A. Bhorkar, N. Hirose, and S. Levine, “GNM: A general navigation model to drive any robot,” in *2023 IEEE International Conference on Robotics and Automation (ICRA)*. IEEE, 2023, pp. 7226–7233.
- [22] Y. Zhou, S. Sonawani, M. Phielipp, S. Stepputtis, and H. Amor, “Modularity through attention: Efficient training and transfer of language-conditioned policies for robot manipulation,” in *Proceedings of The 6th Conference on Robot Learning*, ser. Proceedings of Machine Learning Research, K. Liu, D. Kulic,

- and J. Ichnowski, Eds., vol. 205. PMLR, 14–18 Dec 2023, pp. 1684–1695. [Online]. Available: <https://proceedings.mlr.press/v205/zhou23b.html>
- [23] S. Dasari, F. Ebert, S. Tian, S. Nair, B. Bucher, K. Schmeckpeper, S. Singh, S. Levine, and C. Finn, “RoboNet: Large-scale multi-robot learning,” in *Conference on Robot Learning (CoRL)*, vol. 100. PMLR, 2019, pp. 885–897.
- [24] E. S. Hu, K. Huang, O. Rybkin, and D. Jayaraman, “Know thyself: Transferable visual control policies through robot-awareness,” in *International Conference on Learning Representations*, 2022.
- [25] K. Bousmalis, G. Vezzani, D. Rao, C. Devin, A. X. Lee, M. Bauza, T. Davchev, Y. Zhou, A. Gupta, A. Raju *et al.*, “RoboCat: A self-improving foundation agent for robotic manipulation,” *arXiv preprint arXiv:2306.11706*, 2023.
- [26] J. Yang, D. Sadigh, and C. Finn, “Polybot: Training one policy across robots while embracing variability,” *arXiv preprint arXiv:2307.03719*, 2023.
- [27] S. Reed, K. Zolna, E. Parisotto, S. G. Colmenarejo, A. Novikov, G. Barth-maroon, M. Giménez, Y. Sulsky, J. Kay, J. T. Springenberg, T. Eccles, J. Bruce, A. Razavi, A. Edwards, N. Heess, Y. Chen, R. Hassell, O. Vinyals, M. Bordbar, and N. de Freitas, “A generalist agent,” *Transactions on Machine Learning Research*, 2022.
- [28] G. Salhotra, I.-C. A. Liu, and G. Sukhatme, “Bridging action space mismatch in learning from demonstrations,” *arXiv preprint arXiv:2304.03833*, 2023.
- [29] I. Radosavovic, B. Shi, L. Fu, K. Goldberg, T. Darrell, and J. Malik, “Robot learning with sensorimotor pre-training,” in *Conference on Robot Learning*, 2023.
- [30] L. Shao, F. Ferreira, M. Jorda, V. Nambiar, J. Luo, E. Solowjow, J. A. Ojea, O. Khatib, and J. Bohg, “UniGrasp: Learning a unified model to grasp with multifingered robotic hands,” *IEEE Robotics and Automation Letters*, vol. 5, no. 2, pp. 2286–2293, 2020.
- [31] Z. Xu, B. Qi, S. Agrawal, and S. Song, “Adagrasp: Learning an adaptive gripper-aware grasping policy,” in *2021 IEEE International Conference on Robotics and Automation (ICRA)*. IEEE, 2021, pp. 4620–4626.
- [32] D. Shah, A. Sridhar, N. Dashora, K. Stachowicz, K. Black, N. Hirose, and S. Levine, “ViNT: A Foundation Model for Visual Navigation,” in *7th Annual Conference on Robot Learning (CoRL)*, 2023.
- [33] Y. Liu, A. Gupta, P. Abbeel, and S. Levine, “Imitation from observation: Learning to imitate behaviors from raw video via context translation,” in *2018 IEEE International Conference on Robotics and Automation (ICRA)*. IEEE, 2018, pp. 1118–1125.
- [34] T. Yu, C. Finn, S. Dasari, A. Xie, T. Zhang, P. Abbeel, and S. Levine, “One-shot imitation from observing humans via domain-adaptive meta-learning,” *Robotics: Science and Systems XIV*, 2018.
- [35] P. Sharma, D. Pathak, and A. Gupta, “Third-person visual imitation learning via decoupled hierarchical controller,” *Advances in Neural Information Processing Systems*, vol. 32, 2019.
- [36] L. Smith, N. Dhawan, M. Zhang, P. Abbeel, and S. Levine, “Avid: Learning multi-stage tasks via pixel-level translation of human videos,” *arXiv preprint arXiv:1912.04443*, 2019.
- [37] A. Bonardi, S. James, and A. J. Davison, “Learning one-shot imitation from humans without humans,” *IEEE Robotics and Automation Letters*, vol. 5, no. 2, pp. 3533–3539, 2020.
- [38] K. Schmeckpeper, O. Rybkin, K. Daniilidis, S. Levine, and C. Finn, “Reinforcement learning with videos: Combining offline observations with interaction,” in *Conference on Robot Learning*. PMLR, 2021, pp. 339–354.
- [39] H. Xiong, Q. Li, Y.-C. Chen, H. Bharadhwaj, S. Sinha, and A. Garg, “Learning by watching: Physical imitation of manipulation skills from human videos,” in *2021 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*. IEEE, 2021, pp. 7827–7834.
- [40] E. Jang, A. Irpan, M. Khansari, D. Kappler, F. Ebert, C. Lynch, S. Levine, and C. Finn, “BC-Z: Zero-shot task generalization with robotic imitation learning,” in *Conference on Robot Learning (CoRL)*, 2021, pp. 991–1002.
- [41] S. Bahl, A. Gupta, and D. Pathak, “Human-to-robot imitation in the wild,” *Robotics: Science and Systems (RSS)*, 2022.
- [42] M. Ding, Y. Xu, Z. Chen, D. D. Cox, P. Luo, J. B. Tenenbaum, and C. Gan, “Embodied concept learner: Self-supervised learning of concepts and mapping through instruction following,” in *Conference on Robot Learning*. PMLR, 2023, pp. 1743–1754.
- [43] S. Bahl, R. Mendonca, L. Chen, U. Jain, and D. Pathak, “Affordances from human videos as a versatile representation for robotics,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2023, pp. 13 778–13 790.
- [44] P. Sermanet, K. Xu, and S. Levine, “Unsupervised perceptual rewards for imitation learning,” *arXiv preprint arXiv:1612.06699*, 2016.
- [45] L. Shao, T. Migimatsu, Q. Zhang, K. Yang, and J. Bohg, “Concept2Robot: Learning manipulation concepts from instructions and human demonstrations,” in *Proceedings of Robotics: Science and Systems (RSS)*, 2020.
- [46] A. S. Chen, S. Nair, and C. Finn, “Learning generalizable robotic reward functions from “in-the-wild” human videos,” *arXiv preprint arXiv:2103.16817*, 2021.
- [47] S. Kumar, J. Zamora, N. Hansen, R. Jangir, and X. Wang, “Graph inverse reinforcement learning from diverse videos,” in *Conference on Robot Learning*. PMLR, 2023, pp. 55–66.
- [48] M. Alakuijala, G. Dulac-Arnold, J. Mairal, J. Ponce, and C. Schmid, “Learning reward functions for robotic

- manipulation by observing humans,” in *2023 IEEE International Conference on Robotics and Automation (ICRA)*. IEEE, 2023, pp. 5006–5012.
- [49] Y. Zhou, Y. Aytar, and K. Bousmalis, “Manipulator-independent representations for visual imitation,” 2021.
- [50] C. Wang, L. Fan, J. Sun, R. Zhang, L. Fei-Fei, D. Xu, Y. Zhu, and A. Anandkumar, “Mimicplay: Long-horizon imitation learning by watching human play,” in *Conference on Robot Learning*, 2023.
- [51] K. Schmeckpeper, A. Xie, O. Rybkin, S. Tian, K. Daniilidis, S. Levine, and C. Finn, “Learning predictive models from observation and interaction,” in *European Conference on Computer Vision*. Springer, 2020, pp. 708–725.
- [52] S. Nair, A. Rajeswaran, V. Kumar, C. Finn, and A. Gupta, “R3m: A universal visual representation for robot manipulation,” in *CoRL*, 2022.
- [53] T. Xiao, I. Radosavovic, T. Darrell, and J. Malik, “Masked visual pre-training for motor control,” *arXiv preprint arXiv:2203.06173*, 2022.
- [54] I. Radosavovic, T. Xiao, S. James, P. Abbeel, J. Malik, and T. Darrell, “Real-world robot learning with masked visual pre-training,” in *Conference on Robot Learning*, 2022.
- [55] Y. J. Ma, S. Sodhani, D. Jayaraman, O. Bastani, V. Kumar, and A. Zhang, “Vip: Towards universal visual reward and representation via value-implicit pre-training,” *arXiv preprint arXiv:2210.00030*, 2022.
- [56] A. Majumdar, K. Yadav, S. Arnaud, Y. J. Ma, C. Chen, S. Silwal, A. Jain, V.-P. Berges, P. Abbeel, J. Malik *et al.*, “Where are we in the search for an artificial visual cortex for embodied intelligence?” *arXiv preprint arXiv:2303.18240*, 2023.
- [57] S. Karamcheti, S. Nair, A. S. Chen, T. Kollar, C. Finn, D. Sadigh, and P. Liang, “Language-driven representation learning for robotics,” *Robotics: Science and Systems (RSS)*, 2023.
- [58] Y. Mu, S. Yao, M. Ding, P. Luo, and C. Gan, “EC2: Emergent communication for embodied control,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2023, pp. 6704–6714.
- [59] S. Bahl, R. Mendonca, L. Chen, U. Jain, and D. Pathak, “Affordances from human videos as a versatile representation for robotics,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2023, pp. 13 778–13 790.
- [60] Y. Jiang, S. Moseson, and A. Saxena, “Efficient grasping from RGBD images: Learning using a new rectangle representation,” in *2011 IEEE International conference on robotics and automation*. IEEE, 2011, pp. 3304–3311.
- [61] L. Pinto and A. K. Gupta, “Supersizing self-supervision: Learning to grasp from 50k tries and 700 robot hours,” *2016 IEEE International Conference on Robotics and Automation (ICRA)*, pp. 3406–3413, 2015.
- [62] D. Kappler, J. Bohg, and S. Schaal, “Leveraging big data for grasp planning,” in *ICRA*, 2015, pp. 4304–4311.
- [63] J. Mahler, J. Liang, S. Niyaz, M. Laskey, R. Doan, X. Liu, J. A. Ojea, and K. Goldberg, “Dex-Net 2.0: Deep learning to plan robust grasps with synthetic point clouds and analytic grasp metrics,” in *Robotics: Science and Systems (RSS)*, 2017.
- [64] A. Depierre, E. Dellandréa, and L. Chen, “Jacquard: A large scale dataset for robotic grasp detection,” in *2018 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*. IEEE, 2018, pp. 3511–3516.
- [65] S. Levine, P. Pastor, A. Krizhevsky, J. Ibarz, and D. Quillen, “Learning hand-eye coordination for robotic grasping with deep learning and large-scale data collection,” *The International journal of robotics research*, vol. 37, no. 4-5, pp. 421–436, 2018.
- [66] D. Kalashnikov, A. Irpan, P. Pastor, J. Ibarz, A. Herzog, E. Jang, D. Quillen, E. Holly, M. Kalakrishnan, V. Vanhoucke *et al.*, “QT-Opt: Scalable deep reinforcement learning for vision-based robotic manipulation,” *arXiv preprint arXiv:1806.10293*, 2018.
- [67] S. Brahmabhatt, C. Ham, C. Kemp, and J. Hays, “Contactdb: Analyzing and predicting grasp contact via thermal imaging,” 04 2019.
- [68] H.-S. Fang, C. Wang, M. Gou, and C. Lu, “Graspnet-1billion: a large-scale benchmark for general object grasping,” in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2020, pp. 11 444–11 453.
- [69] C. Eppner, A. Mousavian, and D. Fox, “ACRONYM: A large-scale grasp dataset based on simulation,” in *2021 IEEE Int. Conf. on Robotics and Automation, ICRA*, 2020.
- [70] K. Bousmalis, A. Irpan, P. Wohlhart, Y. Bai, M. Kellecey, M. Kalakrishnan, L. Downs, J. Ibarz, P. Pastor, K. Konolige, S. Levine, and V. Vanhoucke, “Using simulation and domain adaptation to improve efficiency of deep robotic grasping,” in *ICRA*, 2018, pp. 4243–4250.
- [71] X. Zhu, R. Tian, C. Xu, M. Huo, W. Zhan, M. Tomizuka, and M. Ding, “Fanuc manipulation: A dataset for learning-based manipulation with fanuc mate 200iD robot,” <https://sites.google.com/berkeley.edu/fanuc-manipulation>, 2023.
- [72] K.-T. Yu, M. Bauza, N. Fazeli, and A. Rodriguez, “More than a million ways to be pushed. a high-fidelity experimental dataset of planar pushing,” in *2016 IEEE/RSJ international conference on intelligent robots and systems (IROS)*. IEEE, 2016, pp. 30–37.
- [73] C. Finn and S. Levine, “Deep visual foresight for planning robot motion,” in *2017 IEEE International Conference on Robotics and Automation (ICRA)*. IEEE, 2017, pp. 2786–2793.
- [74] F. Ebert, C. Finn, S. Dasari, A. Xie, A. Lee, and

- S. Levine, "Visual foresight: Model-based deep reinforcement learning for vision-based robotic control," *arXiv preprint arXiv:1812.00568*, 2018.
- [75] P. Shilane, P. Min, M. Kazhdan, and T. Funkhouser, "The princeton shape benchmark," in *Shape Modeling Applications*, 2004, pp. 167–388.
- [76] W. Wohlkinger, A. Aldoma Buchaca, R. Rusu, and M. Vincze, "3DNet: Large-Scale Object Class Recognition from CAD Models," in *IEEE International Conference on Robotics and Automation (ICRA)*, 2012.
- [77] A. Kasper, Z. Xue, and R. Dillmann, "The kit object models database: An object model database for object recognition, localization and manipulation in service robotics," *The International Journal of Robotics Research*, vol. 31, no. 8, pp. 927–934, 2012.
- [78] A. Singh, J. Sha, K. S. Narayan, T. Achim, and P. Abbeel, "BigBIRD: A large-scale 3D database of object instances," in *IEEE International Conference on Robotics and Automation (ICRA)*, 2014, pp. 509–516.
- [79] B. Calli, A. Walsman, A. Singh, S. Srinivasa, P. Abbeel, and A. M. Dollar, "Benchmarking in manipulation research: Using the Yale-CMU-Berkeley object and model set," *IEEE Robotics & Automation Magazine*, vol. 22, no. 3, pp. 36–52, 2015.
- [80] Zhirong Wu, S. Song, A. Khosla, Fisher Yu, Linguang Zhang, Xiaoou Tang, and J. Xiao, "3D ShapeNets: A deep representation for volumetric shapes," in *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2015, pp. 1912–1920.
- [81] Y. Xiang, W. Kim, W. Chen, J. Ji, C. Choy, H. Su, R. Mottaghi, L. Guibas, and S. Savarese, "Object-Net3D: A large scale database for 3d object recognition," in *European Conference on Computer Vision (ECCV)*. Springer, 2016, pp. 160–176.
- [82] D. Morrison, P. Corke, and J. Leitner, "Egad! an evolved grasping analysis dataset for diversity and reproducibility in robotic manipulation," *IEEE Robotics and Automation Letters*, vol. 5, no. 3, pp. 4368–4375, 2020.
- [83] R. Gao, Y.-Y. Chang, S. Mall, L. Fei-Fei, and J. Wu, "ObjectFolder: A dataset of objects with implicit visual, auditory, and tactile representations," in *Conference on Robot Learning*, 2021, pp. 466–476.
- [84] L. Downs, A. Francis, N. Koenig, B. Kinman, R. Hickman, K. Reymann, T. B. McHugh, and V. Vanhoucke, "Google scanned objects: A high-quality dataset of 3D scanned household items," in *2022 International Conference on Robotics and Automation (ICRA)*. IEEE, 2022, pp. 2553–2560.
- [85] D. Kalashnikov, J. Varley, Y. Chebotar, B. Swanson, R. Jonschkowski, C. Finn, S. Levine, and K. Hausman, "MT-Opt: Continuous multi-task robotic reinforcement learning at scale," *arXiv preprint arXiv:2104.08212*, 2021.
- [86] A. Mandlekar, Y. Zhu, A. Garg, J. Booher, M. Spero, A. Tung, J. Gao, J. Emmons, A. Gupta, E. Orbay, S. Savarese, and L. Fei-Fei, "RoboTurk: A crowdsourcing platform for robotic skill learning through imitation," *CoRR*, vol. abs/1811.02790, 2018. [Online]. Available: <http://arxiv.org/abs/1811.02790>
- [87] P. Sharma, L. Mohan, L. Pinto, and A. Gupta, "Multiple interactions made easy (MIME): Large scale demonstrations data for imitation," in *Conference on robot learning*. PMLR, 2018, pp. 906–915.
- [88] A. Mandlekar, J. Booher, M. Spero, A. Tung, A. Gupta, Y. Zhu, A. Garg, S. Savarese, and L. Fei-Fei, "Scaling robot supervision to hundreds of hours with RoboTurk: Robotic manipulation dataset through human reasoning and dexterity," in *2019 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*. IEEE, 2019, pp. 1048–1055.
- [89] F. Ebert, Y. Yang, K. Schmeckpeper, B. Bucher, G. Georgakis, K. Daniilidis, C. Finn, and S. Levine, "Bridge data: Boosting generalization of robotic skills with cross-domain datasets," in *Robotics: Science and Systems (RSS) XVIII*, 2022.
- [90] A. Mandlekar, D. Xu, J. Wong, S. Nasiriany, C. Wang, R. Kulkarni, L. Fei-Fei, S. Savarese, Y. Zhu, and R. Martín-Martín, "What matters in learning from offline human demonstrations for robot manipulation," in *arXiv preprint arXiv:2108.03298*, 2021.
- [91] C. Lynch, A. Wahid, J. Tompson, T. Ding, J. Betker, R. Baruch, T. Armstrong, and P. Florence, "Interactive language: Talking to robots in real time," *IEEE Robotics and Automation Letters*, 2023.
- [92] H.-S. Fang, H. Fang, Z. Tang, J. Liu, J. Wang, H. Zhu, and C. Lu, "RH20T: A robotic dataset for learning diverse skills in one-shot," in *RSS 2023 Workshop on Learning for Task and Motion Planning*, 2023.
- [93] H. Bharadhwaj, J. Vakil, M. Sharma, A. Gupta, S. Tulsiani, and V. Kumar, "RoboAgent: Towards sample efficient robot manipulation with semantic augmentations and action chunking," *arxiv*, 2023.
- [94] M. Heo, Y. Lee, D. Lee, and J. J. Lim, "Furniturebench: Reproducible real-world benchmark for long-horizon complex manipulation," in *Robotics: Science and Systems*, 2023.
- [95] H. Walke, K. Black, A. Lee, M. J. Kim, M. Du, C. Zheng, T. Zhao, P. Hansen-Estruch, Q. Vuong, A. He, V. Myers, K. Fang, C. Finn, and S. Levine, "Bridgedata v2: A dataset for robot learning at scale," 2023.
- [96] T. Winograd, "Understanding natural language," *Cognitive Psychology*, vol. 3, no. 1, pp. 1–191, 1972. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/0010028572900023>
- [97] M. MacMahon, B. Stankiewicz, and B. Kuipers, "Walk the talk: Connecting language, knowledge, and action in route instructions," in *Proceedings of the Twenty-First AAAI Conference on Artificial Intelligence*, 2006.
- [98] T. Kollar, S. Tellex, D. Roy, and N. Roy, "Toward understanding natural language directions," in *2010*

5th ACM/IEEE International Conference on Human-Robot Interaction (HRI), 2010, pp. 259–266.

- [99] D. L. Chen and R. J. Mooney, “Learning to interpret natural language navigation instructions from observations,” in *Proceedings of the Twenty-Fifth AAAI Conference on Artificial Intelligence*, 2011, p. 859–865.
- [100] F. Duvallet, J. Oh, A. Stentz, M. Walter, T. Howard, S. Hemachandra, S. Teller, and N. Roy, “Inferring maps and behaviors from natural language instructions,” in *International Symposium on Experimental Robotics (ISER)*, 2014.
- [101] J. Luketina, N. Nardelli, G. Farquhar, J. N. Foerster, J. Andreas, E. Grefenstette, S. Whiteson, and T. Rocktäschel, “A survey of reinforcement learning informed by natural language,” in *IJCAI*, 2019.
- [102] S. Stepputtis, J. Campbell, M. Phielipp, S. Lee, C. Baral, and H. Ben Amor, “Language-conditioned imitation learning for robot manipulation tasks,” *Advances in Neural Information Processing Systems*, vol. 33, pp. 13 139–13 150, 2020.
- [103] S. Nair, E. Mitchell, K. Chen, S. Savarese, C. Finn *et al.*, “Learning language-conditioned robot behavior from offline data and crowd-sourced annotation,” in *Conference on Robot Learning*. PMLR, 2022, pp. 1303–1315.
- [104] O. Mees, L. Hermann, E. Rosete-Beas, and W. Burgard, “CALVIN: A benchmark for language-conditioned policy learning for long-horizon robot manipulation tasks,” *IEEE Robotics and Automation Letters*, 2022.
- [105] O. Mees, L. Hermann, and W. Burgard, “What matters in language conditioned robotic imitation learning over unstructured data,” *IEEE Robotics and Automation Letters*, vol. 7, no. 4, pp. 11 205–11 212, 2022.
- [106] M. Shridhar, L. Manuelli, and D. Fox, “Perceiver-actor: A multi-task transformer for robotic manipulation,” *Conference on Robot Learning (CoRL)*, 2022.
- [107] F. Hill, S. Mokra, N. Wong, and T. Harley, “Human instruction-following with deep reinforcement learning via transfer-learning from text,” *arXiv preprint arXiv:2005.09382*, 2020.
- [108] C. Lynch and P. Sermanet, “Grounding language in play,” *Robotics: Science and Systems (RSS)*, 2021.
- [109] M. Ahn, A. Brohan, N. Brown, Y. Chebotar, O. Cortes, B. David, C. Finn, K. Gopalakrishnan, K. Hausman, A. Herzog *et al.*, “Do as I can, not as I say: Grounding language in robotic affordances,” *Conference on Robot Learning (CoRL)*, 2022.
- [110] Y. Jiang, A. Gupta, Z. Zhang, G. Wang, Y. Dou, Y. Chen, L. Fei-Fei, A. Anandkumar, Y. Zhu, and L. Fan, “VIMA: General robot manipulation with multimodal prompts,” *International Conference on Machine Learning (ICML)*, 2023.
- [111] S. Vemprala, R. Bonatti, A. Buckner, and A. Kapoor, “ChatGPT for robotics: Design principles and model abilities,” *Microsoft Auton. Syst. Robot. Res.*, vol. 2, p. 20, 2023.
- [112] W. Huang, C. Wang, R. Zhang, Y. Li, J. Wu, and L. Fei-Fei, “VoxPoser: Composable 3d value maps for robotic manipulation with language models,” *arXiv preprint arXiv:2307.05973*, 2023.
- [113] M. Shridhar, L. Manuelli, and D. Fox, “Cliport: What and where pathways for robotic manipulation,” in *Conference on Robot Learning*. PMLR, 2022, pp. 894–906.
- [114] A. Stone, T. Xiao, Y. Lu, K. Gopalakrishnan, K.-H. Lee, Q. Vuong, P. Wohlhart, B. Zitkovich, F. Xia, C. Finn *et al.*, “Open-world object manipulation using pre-trained vision-language models,” *arXiv preprint arXiv:2303.00905*, 2023.
- [115] Y. Mu, Q. Zhang, M. Hu, W. Wang, M. Ding, J. Jin, B. Wang, J. Dai, Y. Qiao, and P. Luo, “EmbodiedGPT: Vision-language pre-training via embodied chain of thought,” *arXiv preprint arXiv:2305.15021*, 2023.
- [116] E. Perez, F. Strub, H. de Vries, V. Dumoulin, and A. Courville, “Film: Visual reasoning with a general conditioning layer,” 2017.
- [117] M. Tan and Q. Le, “EfficientNet: Rethinking model scaling for convolutional neural networks,” in *International conference on machine learning*. PMLR, 2019, pp. 6105–6114.
- [118] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, “Attention is all you need,” *Advances in neural information processing systems*, vol. 30, 2017.
- [119] S. Ramos, S. Girgin, L. Hussenot, D. Vincent, H. Yakubovich, D. Toyama, A. Gergely, P. Stanczyk, R. Marinier, J. Harmsen, O. Pietquin, and N. Momechev, “RLDS: an ecosystem to generate, share and use datasets in reinforcement learning,” 2021.
- [120] D. Cer, Y. Yang, S. yi Kong, N. Hua, N. Limtiko, R. S. John, N. Constant, M. Guajardo-Cespedes, S. Yuan, C. Tar, Y.-H. Sung, B. Strope, and R. Kurzweil, “Universal sentence encoder,” 2018.
- [121] X. Chen, J. Djolonga, P. Padlewski, B. Mustafa, S. Changpinyo, J. Wu, C. R. Ruiz, S. Goodman, X. Wang, Y. Tay, S. Shakeri, M. Dehghani, D. Salz, M. Lucic, M. Tschanen, A. Nagrani, H. Hu, M. Joshi, B. Pang, C. Montgomery, P. Pietrzyk, M. Ritter, A. Piergiovanni, M. Minderer, F. Pavetic, A. Waters, G. Li, I. Alabdulmohsin, L. Beyer, J. Amelot, K. Lee, A. P. Steiner, Y. Li, D. Keysers, A. Arnab, Y. Xu, K. Rong, A. Kolesnikov, M. Seyedhosseini, A. Angelova, X. Zhai, N. Houlsby, and R. Soricut, “Pali-x: On scaling up a multilingual vision and language model,” 2023.
- [122] J.-B. Alayrac, J. Donahue, P. Luc, A. Miech, I. Barr, Y. Hasson, K. Lenc, A. Mensch, K. Millican, M. Reynolds, R. Ring, E. Rutherford, S. Cabi, T. Han, Z. Gong, S. Samangooei, M. Monteiro, J. Menick, S. Borgeaud, A. Brock, A. Nematzadeh, S. Sharifzadeh, M. Binkowski, R. Barreira, O. Vinyals, A. Zisserman, and K. Simonyan, “Flamingo: a visual language model for few-shot learning,” 2022.

- [123] D. Driess, F. Xia, M. S. M. Sajjadi, C. Lynch, A. Chowdhery, B. Ichter, A. Wahid, J. Tompson, Q. Vuong, T. Yu, W. Huang, Y. Chebotar, P. Sermanet, D. Duckworth, S. Levine, V. Vanhoucke, K. Hausman, M. Toussaint, K. Greff, A. Zeng, I. Mordatch, and P. Florence, “PaLM-E: An embodied multimodal language model,” 2023.
- [124] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, and N. Houlsby, “An image is worth 16x16 words: Transformers for image recognition at scale,” 2021.
- [125] Y. Tay, M. Dehghani, V. Q. Tran, X. Garcia, J. Wei, X. Wang, H. W. Chung, S. Shakeri, D. Bahri, T. Schuster, H. S. Zheng, D. Zhou, N. Houlsby, and D. Metzler, “UL2: Unifying language learning paradigms,” 2023.
- [126] E. Rosete-Beas, O. Mees, G. Kalweit, J. Boedecker, and W. Burgard, “Latent plans for task agnostic offline reinforcement learning,” in *Proceedings of the 6th Conference on Robot Learning (CoRL)*, 2022.
- [127] O. Mees, J. Borja-Diaz, and W. Burgard, “Grounding language with visual affordances over unstructured data,” in *Proceedings of the IEEE International Conference on Robotics and Automation (ICRA)*, London, UK, 2023.
- [128] S. Dass, J. Yapeter, J. Zhang, J. Zhang, K. Pertsch, S. Nikolaidis, and J. J. Lim, “CLVR jaco play dataset,” 2023. [Online]. Available: https://github.com/clvr-ai/clvr_jaco_play_dataset
- [129] J. Luo, C. Xu, X. Geng, G. Feng, K. Fang, L. Tan, S. Schaal, and S. Levine, “Multi-stage cable routing through hierarchical imitation learning,” *arXiv preprint arXiv:2307.08927*, 2023.
- [130] J. Pari, N. M. Shafiullah, S. P. Arunachalam, and L. Pinto, “The surprising effectiveness of representation learning for visual imitation,” 2021.
- [131] Y. Zhu, A. Joshi, P. Stone, and Y. Zhu, “Viola: Imitation learning for vision-based manipulation with object proposal priors,” 2023.
- [132] L. Y. Chen, S. Adebola, and K. Goldberg, “Berkeley UR5 demonstration dataset,” <https://sites.google.com/view/berkeley-ur5/home>.
- [133] G. Zhou, V. Dean, M. K. Srirama, A. Rajeswaran, J. Pari, K. Hatch, A. Jain, T. Yu, P. Abbeel, L. Pinto, C. Finn, and A. Gupta, “Train offline, test online: A real robot learning benchmark,” 2023.
- [134] “Task-agnostic real world robot play,” <https://www.kaggle.com/datasets/oiermees/taco-robot>.