

图像以图像言说：一种用于上下文视觉学习的通用画家模型

Xinlong Wang^{1*} Wen Wang^{2*} Yue Cao^{1*} Chunhua Shen² Tiejun Huang^{1,3}

¹ Beijing Academy of Artificial Intelligence ² Zhejiang University ³ Peking University

<https://github.com/baaivision/Painter>




图 1. 画家模型上下文推理示意图。画家模型是一种通用视觉模型，能够根据输入的任务提示自动执行视觉任务，无需任务特定的头部结构。画家模型不仅能以极具竞争力的性能完成域内任务，如语义分割（第 1 行）、实例分割（第 2 行）、深度估计（第 3 行）、关键点检测（第 4 行）、去噪（第 5 行）、去雨（第 6 行）和图像增强（第 7 行），还能利用简单提示快速适应各种域外视觉任务，如开放类别目标分割、关键点检测和实例分割（第 8-10 行）。

摘要

上下文学习作为自然语言处理中的一种新范式，使模型能够仅凭少量提示和示例快速适应各种任务。但在计算机视觉中，上下文学习的困难在于任务的输出表示差异显著，因此尚不清楚如何定义通用任务提示，使视觉模型能够理解并迁移到域外任务。

本文提出画家模型，一种通用模型，通过以“图像”为中心的解决方案来克服这些障碍，即将核心视觉任务的输出重新定义为图像，并将任务提示也指定为图像。基于这一思想，我们的训练过程极为简单，对输入和输出图像对的拼接结果执行标准的掩码图像建模。这使得模型能够根据可见图像块执行任务。因此，在推理时，我们可以采用来自同一任务的一对输入和输出图像作为输入条件，以指示要执行的任务。

* 同等贡献。通讯作者：xinlong.wang96@gmail.com
本工作完成于王文在北京智源人工智能研究院实习期间。

无需额外技巧，我们的通用画家模型在七个代表性视觉任务上（从高层视觉理解到低层图像处理）能够取得与成熟的任务特定模型相媲美的性能。此外，画家模型在若干具有挑战性的任务上显著优于近期的通用模型。

1. 引言

训练一个能够同时执行多种任务的通用模型，甚至能在给定提示和极少量示例的情况下执行新任务，是迈向通用人工智能的重要一步。在自然语言处理领域，上下文学习（In-context Learning）[2, 7, 18] 的出现为这一方向开辟了新路径，它以语言序列作为通用接口，使模型仅凭少量提示和示例就能快速适应各种以语言为中心的任务。迄今为止，在计算机视觉领域，上下文学习鲜有探索，如何实现仍不明确。这归因于两种模态之间的差异。差异之一是自然语言处理任务主要由语言理解和生成组成，因此其输出空间可以统一为离散语言标记的序列。但视觉任务是对原始视觉输入在不同粒度和角度上的抽象，因此视觉任务在输出表示上差异显著，导致各种任务特定的损失函数和架构设计。第二个差异是自然语言处理任务的输出空间甚至与输入相同。因此，任务指令和示例的输入/输出（均为语言标记序列）可以直接用作输入条件（也称为任务提示），并可由大语言模型直接处理。然而，在计算机视觉中，如何定义通用的任务提示或指令，使视觉模型能够理解并迁移到域外任务，尚不清楚。近期的一些尝试 [6, 9, 10, 27, 35, 41] 通过借鉴自然语言处理中的解决方案来应对这些困难。它们或多或少地通过离散化视觉任务的连续输出空间，并使用语言或专门设计的离散标记作为任务提示，将视觉问题转化为自然语言处理问题。然而，我们认为图像应以图像为言，即图像本身是通用视觉感知的自然接口。在本工作中，我们以视觉为中心的方案来解决上述障碍。核心观察是，大多数密集预测视觉问题可以表述为图像修复，即：给定输入图像，预测就是修复期望但缺失的输出“图像”。因此，我们需要一个三通道张量的表示，

对于视觉任务的输出，表现为一张“图像”，并使用一对图像来指定任务提示。这里我们展示了几种用于训练的代表性视觉任务，包括深度估计、人体关键点检测、语义分割、实例分割、图像去噪、图像去雨和图像增强，并将它们的输出空间统一为一个 3 通道张量，即“输出图像”。我们为每个任务精心设计了数据格式，例如全景分割的实例掩码和逐像素离散标签、深度估计的逐像素连续值以及姿态估计的高精度坐标。包含更多任务非常直接，因为我们只需要构建新的数据对并将其添加到训练集中，无需修改模型架构或损失函数。

基于这种统一，我们训练了一个通用的 Painter 模型，其训练过程极其简单。在训练期间，我们将来自同一任务的两张图像拼接成一张更大的图像，并将它们对应的输出图像也进行拼接。然后，我们在输出图像的像素上应用掩码图像建模（MIM），以输入图像作为条件。通过这样的学习过程，我们使模型能够以可见图像块为条件执行任务，即以视觉信号为上下文进行上下文预测的能力。

因此，训练后的模型具备上下文推理能力。也就是说，我们直接使用来自同一任务的输入/输出配对图像作为输入条件，以指示要执行的任务。上下文推理的示例如图 1 所示，包括七个域内示例（顶部七行）和三个域外示例（底部三行）。这种任务提示的定义不需要像几乎所有先前方法那样深入理解语言指令，并且使得执行域内和域外视觉任务都非常灵活。

无需任何附加技巧，本文模型在多个基础视觉任务上即可取得与成熟专用模型相当的竞争力，这些任务涵盖从高层视觉理解到低层图像处理，具体包括：NYUv2 上的深度估计 [37]、ADE-20K 上的语义分割 [54]、COCO 上的人体关键点检测 [31]、COCO 上的全景分割 [31]，以及三个低层图像复原任务。值得注意的是，在 NYUv2 的深度估计上，本文模型达到了最先进的性能，大幅超越了此前在架构和损失函数上具有繁重且专门设计的最佳结果。与其他通用模型相比，Painter 在多个具有挑战性的任务上取得了显著提升。

2. 相关工作

统一建模 变换器 (Transformer) [40] 的出现为跨模态共享基础建模模块提供了可能。目前, 变换器已被广泛应用于语言 [7,12,32]、视觉 [4,8,9,14,33]、语音 [13, 17, 24] 和多模态 [23, 34, 38] 领域。Perceiver [22] 和 Perceiver-IO [21] 是首次尝试在不同领域 (如自然语言与视觉理解处理、星际争霸 II 及多模态领域) 使用完全相同的变换器架构。若输入可转换为标记序列, 即可采用变换器对不同标记间的关系进行建模。

视觉通用模型 由于变换器 (Transformer) 的通用建模能力, 已有一些工作尝试统一视觉领域的不同任务, 从而催生了若干视觉通才模型 [9,10,27,35,55]。DETR[8] 首次将变换器用作目标检测的任务专用头。在此基础上, Pix2Seq[9] 将目标检测的输出空间定义为离散空间, 并以自回归方式执行该任务。由于目标检测的基础性, Pix2Seq 为利用离散空间统一不同视觉任务提供了方向, 从而激发了大量后续工作。Unified-IO[35] 和 OFA[41] 均将多样的输入和输出同质化为离散标记序列, 以序列到序列的方式对视觉、视觉与语言以及自然语言处理任务进行联合建模, 并使用具有数十亿参数的 T5 风格架构 [36], 其中 Unified-IO 比 OFA 统一了更多任务, 模型规模也更大。Pix2Seq v2[10] 在与 Pix2Seq 相同的离散空间定义下统一了目标检测、实例分割、关键点估计和图像描述生成。UViM[27] 采用相同的建模方法统一了像素级标注任务, 但为不同任务 (如全景分割、深度估计和图像着色) 分别训练了模型。值得注意的是, 我们认为视觉信号的输入本质上是连续的, 因此我们尝试使若干代表性视觉任务的输出空间尽可能像图像一样连续, 以减少离散化带来的量化误差, 并进一步通过掩码图像建模实现上下文视觉学习。

上下文学习 GPT-3[7] 首次定义了一种新的学习范式——上下文学习, 其中一系列自然语言处理任务可以在给定提示和示例的情况下被表述为文本补全任务。上下文学习赋予模型执行即时计算推理或新颖模式识别的新能力, 而这些能力在训练中不太可能出现。Flamingo[2] 将大语言模型的输入从文本扩展到图像和视频, 但仍使用语言作为通用接口, 使得模型能够在给定提示和示例的情况下执行许多视觉-语言任务。

例如图像描述生成、视觉问答、光学字符识别 (OCR) 等。在其他领域, 直接引入上下文学习能力似乎并非易事。AD [28] 使用算法蒸馏将上下文能力与强化学习相结合。在计算机视觉领域, 一项同期工作 [6] 对视觉文章中的图形和信息图进行修复, 但仅适用于像语言领域那样在离散空间上进行预测, 并在前景分割、单目标检测和着色任务上展示了上下文能力。而工作 [6] 证明了视觉任务上下文学习的概念, 但未在标准基准数据集上报告结果。因此, 该方法在真实世界数据集上的表现仍不清楚。相比之下, 我们的模型在七个多样且具有挑战性的视觉任务上通过像素级掩码图像建模表现出色, 包括深度估计、关键点估计、语义分割、全景分割、图像去噪、图像去雨和图像增强, 并在这些任务上展现出极具竞争力的性能。

3. 方法

我们框架的核心思想是将大多数视觉任务 (如深度估计、语义分割、实例分割、关键点检测和图像复原) 重新表述为图像修复问题。为此, 我们将这些任务的输出空间重新定义为“图像”。

3.1. 将输出空间重新定义为“图像”

我们将输入图像记为 $\mathbf{x}$, 尺寸为 $H \times W \times 3$, 任务真值的标准定义为 $\mathbf{y}^t$, 不同任务 t 的尺寸各异, 我们仍在图像空间中重新定义这些任务输出, 记为 $\hat{\mathbf{y}}^t$, 尺寸为 $H \times W \times 3$ 。我们的理念是保持像素间的空间关系不变, 输出图像的每个像素仍代表对应输入图像像素在该任务上的输出, 但处于 RGB 空间。即, 具有三个维度的 $\hat{\mathbf{y}}_{i,j}^t$ 表示输入像素 $\mathbf{x}_{i,j}$ 的对应真值。我们选择了七个具有不同输出类型的代表性视觉任务, 如深度估计、语义分割、关键点检测和全景分割。这里我们展示如何将每个任务中每个像素的真值重新定义为一个 3 通道张量, 类似于 RGB 空间。注意, 理论上固定数量的输出通道即可满足我们的目的。我们选择 3 个通道以构成图像。

单目深度估计 是一项弱语义的密集预测任务, 旨在给定输入 RGB 图像的情况下估计逐像素深度值 (相对于相机的距离)。对于 NYUv2 [37], 逐像素的真实深度 $\mathbf{y}_{i,j}^t$ 是范围在 $[0, 10]$ 米内的实数值。这里我们将真实值从实值范围 $[0, 10]$ 映射到整数空间, 范围为 $[0, 255]$, $\hat{\mathbf{y}}_{i,j,0}^t = \lfloor \mathbf{y}_{i,j}^t \times \frac{255}{10} \rfloor$, 并且

令三个通道 $\hat{y}_{i,j,0}^t$, $\hat{y}_{i,j,1}^t$ 和 $\hat{y}_{i,j,2}^t$ 具有相同的真实值。在推理时，我们直接对三个通道的输出取平均，然后执行训练时的逆线性变换，以获得深度估计值，其范围为

的范围为 $[0, 10]$ 。

语义分割是一项强语义的密集预测任务，旨在给定输入图像的情况下预测逐像素语义标签。给定一个具有 L 个类别的语义分割任务，我们让 RGB 空间在每个空间中用相同的间隔来表示这些 L 个类别。我们将 L 表示为一个基于 b 进制的 3 位数字，其中 $b = \lceil L^{\frac{1}{3}} \rceil$ ，和 $\hat{y}_{i,j,0}^t$, $\hat{y}_{i,j,1}^t$ 以及 $\hat{y}_{i,j,2}^t$ 分别代表它们的百位、十位和个位，间隔定义为 $m = \lfloor \frac{256}{b} \rfloor$ 。例如，ADE-20K [54] 有 150 个语义类别和一个背景类，因此我们将进制设为 $b = 6$ ，间隔设为 $m = 42$ 。输出通道定义为

$\hat{y}_{i,j,0}^t = \lfloor \frac{l}{b^2} \rfloor \times m$, $\hat{y}_{i,j,1}^t = \lfloor \frac{l}{b} \rfloor \bmod b \times m$ ，以及 $\hat{y}_{i,j,2}^t = l \bmod b \times m$ ，其中 l 表示对应的类别，是一个在 $[0, L)$ 范围内的整数值。在推理时，我们用间隔 m 对每个像素的输出进行离散化，并获得其对应的类别。

关键点检测 是一项细粒度定位任务，旨在同时检测物体（如人体）并定位其详细关键点。我们遵循近期基于热图的自顶向下流程 [46]，因此将其定义为面向人体关键点检测的 17 类点定位任务。对于每个关键点，需要将其定位到对应像素，粒度非常细。我们将该任务解耦为 17 类关键点分类与类别无关的关键点定位的组合：前者使用 $\hat{y}_{i,j,1}^t$ 和 $\hat{y}_{i,j,2}^t$ 两个通道，后者使用 $\hat{y}_{i,j,0}^t$ 的另一个通道。对于 17 类分类任务，我们将每个关键点定义为 9×9 像素方块，并采用语义分割中的方法定义每个方块的颜色。对于类别无关的点定位任务，我们定义 17 个方块，每个方块为 17×17 的高斯分布热图，中心像素最大值为 255，即真实关键点位置。在推理阶段，我们从 3 通道输出图像中获取每个关键点的类别和位置作为最终结果。

全景分割 是语义分割任务与实例分割任务的结合。因此，为便于重新定义输出空间和优化，我们分别执行这两个任务，再合并其结果以获得全景分割结果。这里介绍类别无关实例分割的输出空间重定义。对于该任务，我们直接将图像中每个实例掩码的颜色改为相同颜色，不同实例使用不同颜色。理论上可以随机为不同实例选择颜色，但我们发现这种设置会使模型难以优化。为解决该优化问题，我们




图 2. 掩码图像建模 (MIM) 框架的训练流程。

遵循 SOLO [42]，根据实例掩码中心在图像中的绝对位置为其分配颜色。我们将图像概念性地划分为 $16 \times 20 \times 20$ 个块，分别对应三个通道。为每个块分配固定颜色，若掩码中心位于该块内，则相应地为掩码着色。在推理阶段，我们将每种颜色作为核函数，计算与图像中每个像素的距离，然后设置阈值以获得最终掩码。为获取每个实例掩码的类别，我们直接将语义分割结果中该实例掩码内的多数类别作为其类别。

图像复原 以受损图像为输入，输出对应的清晰图像。本文研究了三种具有代表性的图像复原任务，包括图像去噪、图像去雨和低光图像增强。由于输入和输出本质上都定义在 RGB 空间中，这些任务可以在我们的 Painter 模型中无缝统一，无需任何变换。

3.2. 掩码图像建模框架

基于上述代表性视觉任务输出空间的重新定义，这些任务的输入和输出均为图像。因此，本文直接采用标准的掩码图像建模 (Masked Image Modeling, MIM) 流程 [5, 19, 48] 进行训练，如图 2 所示。该框架包含三个主要组成部分：输入格式、架构和损失函数。

输入格式 在训练过程中，每个输入样本是来自同一任务的两对图像的拼接，这两对图像已分别进行数据增强，如图 2 左侧所示。每对图像由一张图像及其对应的任务输出组成，该输出也被重新定义为图像。我们随机掩码任务输出图像，并训练模型重建缺失的像素。对于掩码区域，我们遵循自然语言处理

社区 [32,38] 及先前工作 [5,19,48] 的做法, 使用可学习的令牌向量替换每个被掩码的块。我们采用分块掩码策略, 并发现掩码比例为 75% 时效果良好。

架构 本文采用一个普通的视觉变换器 (Vision Transformer, ViT) [14] 作为编码器, 它由堆叠的变换器块组成, 例如 ViT-large 有 24 个块。我们从这些块中均匀采样 4 个特征图并将它们拼接起来, 然后使用一个简单的三层头部将每个块的特征映射回其原始分辨率, *e.g.*, $16 \times 16 \times 3$ 。具体来说, 头部由一个线性 (1×1 卷积) 层、一个 3×3 卷积层和另一个线性层组成。由于每个输入样本同时包含输入图像及其输出图像, 输入分辨率可以大于传统训练过程, 计算成本也随之增加。为了解决这个问题, 本文提出通过合并输入图像和输出图像的早期特征来降低计算成本。具体来说, 我们将输入图像和输出图像并行输入模型, 然后在几个块 (默认 3 个块) 之后逐块相加它们的特征。这种设计节省了近一半的计算成本, 但我们发现性能没有下降。

损失函数 本文使用简单的回归损失来训练 Painter。具体来说, 在掩码像素上计算平滑 ℓ_1 [16] 损失。我们在实验中也考虑了 ℓ_1 和 ℓ_2 , 发现平滑 ℓ_1 损失达到了最佳性能。

3.3. 上下文推理

首先, 本文设计了一种上下文推理过程, 该过程在执行域内和域外视觉任务时具有极高的灵活性。由于视觉任务的输入与输出空间已统一为图像, 可直接将同一任务中的输入/输出配对图像作为输入条件 (任务提示), 用以指示待执行的任务, 并将其与输入图像及掩码图像拼接, 以完成相应任务。示例如图 1 所示。这种任务提示的定义无需像以往方法那样深入理解语言指令, 而是利用视觉信号作为上下文, 该上下文可被视觉模型理解, 且与视觉领域的本质高度契合。此外, 不同的任务提示会导致不同的结果。因此, 如何选择或生成更合适的任务提示可成为一个新的探索方向。本文提出两种简单的基线方法, 并将更多探索留作未来工作。第一种基线通过选择获得更优提示, 即以启发式方式遍历整个训练集, 为每个任务挑选表现最佳的示例对。第二种基线是生成任务提示。本文将任务提示定义为可学习张量, 冻结整个模型, 然后利用训练损失优化任务提示。本文在实验中对这两种方案

与随机对照方案进行了比较, 并给出了可视化结果, 详见 § 4.3。

4. 实验

4.1. 设置

数据集与输入格式 NYUv2 [37] 数据集由微软 Kinect 相机采集的 464 个室内场景组成。官方训练划分 (24K 图像) 用于训练, 我们在来自 215 个室内场景的 654 张测试图像上报告均方根误差 (RMSE)、绝对平均相对误差 (A.Rel) 以及不同阈值 δ 下的内部像素百分比。ADE20K [54] 是一个广泛使用的语义分割数据集, 涵盖 150 个语义类别。它总共有 25K 张图像, 其中 20K 用于训练, 2K 用于验证, 另外 3K 用于测试。我们采用广泛使用的平均交并比 (mIoU) 度量进行评估。MS-COCO [31] 包含约 118K 张训练图像和 5K 张用于评估的验证图像, 具有 80 个“物体”类别和 53 个“背景”类别。全景分割任务在“物体”和“背景”类别的并集上进行评估。在训练期间, 我们生成具有 133 个类别的语义分割输出图像, 以及仅包含“物体”类别的类别无关实例分割。在推理期间, 我们对每个输入图像执行两次推理, 分别获得语义分割和类别无关实例分割的结果, 然后将它们合并以获得全景分割的结果。我们报告全景质量作为测度。对于人体关键点检测, 我们使用来自简单基线 [46] 的标准人物检测结果, 该基线使用 COCO 上的标准划分, 包含 15K 训练样本和用于评估的验证集, 并报告基于 OKS 的 AP 作为评估度量 [46]。图像复原任务在几个流行的基准上进行评估, 包括用于图像去噪的 SIDD [1]、用于低光图像增强的 LoL [45], 以及用于去雨的合并去雨数据集 [51]。关于这些数据集的更多细节在表 S1 中提供。

训练细节 在训练过程中, 我们采用 AdamW 优化器 [25], 配合余弦学习率调度器, 共训练 54K 次迭代。训练超参数为: 批大小为 2048, 基础学习率为 $1e-3$, 权重衰减为 0.05, $\beta_1 = 0.9$, $\beta_2 = 0.999$, 丢弃路径 [20] 比率为 0.1, 预热 5.4K 次迭代。采用轻量级数据增强策略: 随机调整大小裁剪, 尺度范围为 $[0.3, 1]$, 纵横比范围为 $[3/4, 4/3]$, 随后进行随机翻转。默认输入图像尺寸为 448×448 。各任务的采样权重为 0.1 (NYUv2 深度估计)、0.2 (ADE-20K 语义分割)、0.15 (COCO 类别无关实例分割)、0.25 (COCO 语义分割)、0.2 (COCO




图 3. 我们的 Painter 在不同任务上的示例和预测可视化，如语义分割、深度估计、实例分割、人体关键点检测、图像去噪、图像去雨和低光图像增强。建议在屏幕上查看。

人体关键点检测)、 0.15 (图像去噪)、 0.05 图像去雨, 以及 0.05 (低光图像增强)。

4.2. 结果

系统级比较 借助相应的任务提示, 我们将我们的方法 Painter 与近期最佳的视觉通用模型和专用模型在七个代表性任务上进行比较, 结果如表 1 所示。无需任务特定设计, 我们的 Painter 在 NYUv2 深度估计上创造了新纪录, 不仅超越了视觉通用模型, 如 Unified-IO [35] 和 UViM [27], 还超越了最先进的

专用模型, 例如 BinsFormer [30]。对于 COCO 关键点检测, Painter 显著优于通用模型 Pix2Seq v2 [10], 高出 7.3 AP。对于 ADE-20K 语义分割、COCO 全景分割以及三个低级图像处理任务, 我们的模型达到了与精心设计的任务特定模型相当的性能。与其他精心设计的专用模型相比, 我们的方法仍有很大的提升空间。例如, 我们的默认输入图像尺寸为 448×448 , 而那些专用全景分割模型在 Mask2Former [11] 中使用了更大的分辨率 *e.g.*, 1024×1024 。

	depth estimation NYUv2			semantic seg. ADE-20K	panoptic seg. COCO	keypoint det. COCO	denoising SIDD		deraining 5 datasets		enhance. LoL	
	RMSE ↓	A.Rel ↓	δ_1 ↑	mIoU ↑	PQ ↑	AP ↑	PSNR ↑	SSIM ↑	PSNR ↑	SSIM ↑	PSNR ↑	SSIM ↑
specialized models												
DenseDepth [3]	0.465	0.123	0.846	-	-	-	-	-	-	-	-	-
BinsFormer [30]	0.330	0.094	0.925	-	-	-	-	-	-	-	-	-
UperNet-ViT-L [47]	-	-	-	49.9	-	-	-	-	-	-	-	-
Mask2Former [11]	-	-	-	57.7	57.8	-	-	-	-	-	-	-
DETR [8]	-	-	-	-	45.6	-	-	-	-	-	-	-
HRNet [46]	-	-	-	-	-	76.3	-	-	-	-	-	-
HRFormer [11]	-	-	-	-	-	77.2	-	-	-	-	-	-
Uformer [44]	-	-	-	-	-	-	39.89	0.960	-	-	-	-
MPRNet [50]	-	-	-	-	-	-	39.71	0.958	32.73	0.921	-	-
MIRNet-v2 [51]	-	-	-	-	-	-	39.84	0.959	-	-	24.74	0.851
generalist framework, specialized models												
UViM [27]	0.467	-	-	-	45.8	-	-	-	-	-	-	-
generalist models												
Unified-IO [35]	0.385	-	-	-	-	-	-	-	-	-	-	-
Pix2Seq v2 [10]	-	-	-	-	-	64.8	-	-	-	-	-	-
Painter (ours)	0.288	0.080	0.950	49.9	43.4	72.1	38.88	0.954	29.49	0.868	22.40	0.872

表 1. 与视觉通才模型以及近期在七个代表性任务（涵盖高层视觉理解与低层图像处理）上的最佳专用模型的系统级比较。我们比较了每种方法的最佳结果。所列通才方法的骨干网络为：UViM 采用 ViT-L，Unified-IOXL 具有 2925M 参数，Pix2Seq v2 采用 ViT-B 并配备另一个变换器解码器，Painter 采用 ViT-L。

	depth estimation NYUv2			semantic seg. ADE-20K	panoptic seg. COCO	keypoint det. COCO	denoising SIDD		deraining 5 datasets		enhance. LoL	
	RMSE ↓	A.Rel ↓	δ_1 ↑	mIoU ↑	PQ ↑	AP ↑	PSNR ↑	SSIM ↑	PSNR ↑	SSIM ↑	PSNR ↑	SSIM ↑
separate training	0.327	0.090	0.930	47.2	41.3	72.5	38.43	0.956	28.28	0.844	21.67	0.850
joint training	0.288	0.080	0.950	49.9	43.4	72.1	38.88	0.954	29.49	0.868	22.40	0.872

表 2. 在七个代表性任务上联合训练与单独训练设置的模型比较。对于单独训练设置，我们在每个任务上分别训练模型，迭代次数与该任务上的联合训练相同。

在每个任务上达到最先进的性能并非本文的主要目标，我们将其留作未来工作。

联合训练与单独训练 我们在表 2 中比较了两种训练设置，即联合训练和单独训练。对于单独训练设置，我们在每个任务上分别训练每个模型，迭代次数和架构与该任务上的联合训练相同。我们可以观察到，联合训练的模型在大多数任务上通常优于单独训练的模型，这表明我们的上下文训练方法通过输出空间的统一可以在一定程度上使它们相互受益。但冲突可能仍然存在，例如，联合训练在关键点检测上表现略差。在我们简单统一的框架中探索任务之间的关系可能是一个有趣且有前景的方向。

定性结果 为了从直观角度展示我们通才模型的能力，我们可视化了来自几个域内任务验证集的选定图像的任务输出，例如语义分割、

深度估计、实例分割、人体关键点检测、图像去噪、图像去雨和低光图像增强。如图 3 所示，Painter 能够在所有这些任务上做出非常准确的预测。

4.3. 提示微调

不同的任务提示会导致不同的结果。本文比较了三种简单的基线：随机提示、搜索提示和学习提示。随机提示指从该任务中随机选择一个示例作为提示。搜索提示指以启发式方式遍历训练集，为每个任务选择性能最佳的示例对。学习提示指将任务提示定义为可学习张量，冻结整个模型，然后利用训练损失优化任务提示。定性比较如表 3 所示。可以看出，使用搜索提示和学习提示的模型性能优于使用随机提示的模型，这表明优化过程有助于任务找到更合适的提示。此外，使用随机提示的模型

	depth estimation NYUv2			semantic seg. ADE-20K	panoptic seg. COCO	keypoint det. COCO	denoising SIDDD		deraining 5 datasets		enhance. LoL	
	RMSE ↓	A.Rel ↓	δ_1 ↑	mIoU ↑	PQ ↑	AP ↑	PSNR ↑	SSIM ↑	PSNR ↑	SSIM ↑	PSNR ↑	SSIM ↑
random prompts	0.291	0.080	0.949	49.3	43.1	71.8	38.46	0.953	29.26	0.865	22.31	0.871
searched prompts	0.288	0.080	0.950	49.9	43.4	72.1	38.88	0.954	29.49	0.868	22.40	0.872
learned prompts	0.286	0.080	0.949	49.9	43.3	72.2	38.71	0.954	29.56	0.870	22.38	0.872

表 3. 不同任务下随机提示、搜索提示和学习提示模型的比较。

Model	mIoU ↑
MAE-VQGAN [6]	58.3
Painter	62.3

表 4. 开放词汇 FSS-1000 上的定量结果。




图 4. Painter 获得的示例和预测可视化，如开放词汇关键点检测（例如马、猴子和扫帚）、目标分割（考拉和蝴蝶）以及实例分割（平板电脑）。

表现相对良好，表明本文模型的鲁棒性。在图 S6 中，本文展示了不同任务学习到的提示图像可视化。通过优化输入提示来提升任务性能是非常有前景的。这提供了一种可能性：如果某个类别或任务未出现在训练数据中，本文仍然可以通过优化提示在该任务上取得相对良好的性能，而无需调整模型参数，这也是上下文学习的核心优势之一。

4.4. 泛化

上下文学习的核心特性在于，仅需少量提示和示例，模型即可快速适应各种任务。本文通过图 1、图 4 和图 S5 中的可视化探索了这一能力。从这些可视化中，本文发现模型能够执行训练中见过的任务，但输入图像

其类别在训练中不可见，例如开放词汇关键点检测（如猴子、马和扫帚）、目标分割（考拉）和实例分割（平板电脑）。此外，我们在少样本分割基准上定量评估了 Painter，该基准要求分割 1k 个新类别的对象。如表 4 所报告，Painter 大幅优于同期工作 [6]。

5. 讨论与结论

在这项工作中，我们首次探索了如何进行上下文视觉学习，并提出了一种以视觉为中心的解决方案，其中上下文被定义为视觉信号。因此，模型被赋予了基于该任务配对数据执行任务的能力，即上下文推理。我们的方法在七个具有代表性和多样性的任务上取得了极具竞争力的性能。这项工作并非没有缺点。首先，与专用模型相比，我们的方法在困难的全景分割任务上仍有很大的提升空间。此外，由于我们的方法基于视觉信号作为上下文设计，这种通用接口似乎不适合建模语言信号。如何将离散语言信号建模为连续信号似乎是一个令人印象深刻的方向，最近已有一些工作开始出现。虽然已有先前方法希望使用通用接口来解决多个视觉任务，但我们可能是第一个赋予模型在上下文中学习和完成任务能力的工作，这确实有机会处理域外任务。我们希望这项工作能引起人们对这一有前景方向的关注，并且我们相信视觉领域最好的 GPT-3 时刻尚未到来。

致谢

本项目由国家重点研发计划（2020AAA0105200）支持。我们感谢韩笑渠、石业民、田岩和曹希刚在 GPU 资源上的帮助，感谢刘欣欣和陆凯美化图表，以及北京智源人工智能研究院的其他同事在整个项目中的支持。

参考文献

- [1] Abdelrahman Abdelhamed, Stephen Lin, and Michael S Brown. A high-quality denoising dataset for smartphone cameras. In *IEEE Conf. Comput. Vis. Pattern Recog.*, 2018.
- [2] Jean-Baptiste Alayrac, Jeff Donahue, Pauline Luc, Antoine Miech, Iain Barr, Yana Hasson, Karel Lenc, Arthur Mensch, Katie Millican, Malcolm Reynolds, Roman Ring, Eliza Rutherford, Serkan Cabi, Tengda Han, Zhitao Gong, Sina Samangooei, Marianne Monteiro, Jacob Menick, Sebastian Borgeaud, Andrew Brock, Aida Nematzadeh, Sahand Sharifzadeh, Mikolaj Binkowski, Ricardo Barreira, Oriol Vinyals, Andrew Zisserman, and Karen Simonyan. Flamingo: a visual language model for few-shot learning. *Adv. Neural Inform. Process. Syst.*, 2022.
- [3] Ibraheem Alhashim and Peter Wonka. High quality monocular depth estimation via transfer learning. *arXiv preprint arXiv:1812.11941*, 2018.
- [4] Roman Bachmann, David Mizrahi, Andrei Atanov, and Amir Zamir. Multimaec: Multi-modal multi-task masked autoencoders. *arXiv preprint arXiv:2204.01678*, 2022.
- [5] Hangbo Bao, Li Dong, and Furu Wei. BEiT: BERT pre-training of image Transformers. *arXiv preprint arXiv:2106.08254*, 2021.
- [6] Amir Bar, Yossi Gandelsman, Trevor Darrell, Amir Globerson, and Alexei A. Efros. Visual prompting via image inpainting. *Adv. Neural Inform. Process. Syst.*, pages 1–24, 2022.
- [7] Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, et al. Language models are few-shot learners. *arXiv preprint arXiv:2005.14165*, 2020.
- [8] Nicolas Carion, Francisco Massa, Gabriel Synnaeve, Nicolas Usunier, Alexander Kirillov, and Sergey Zagoruyko. End-to-end object detection with transformers. In *Eur. Conf. Comput. Vis.*, pages 213–229, 2020.
- [9] Ting Chen, Saurabh Saxena, Lala Li, David J. Fleet, and Geoffrey Hinton. Pix2seq: A language modeling framework for object detection. *Int. Conf. Learn. Representations*, pages 1–17, 2021.
- [10] Ting Chen, Saurabh Saxena, Lala Li, Tsung-Yi Lin, David J. Fleet, and Geoffrey Hinton. A unified sequence interface for vision tasks. *Adv. Neural Inform. Process. Syst.*, 2022.
- [11] Bowen Cheng, Ishan Misra, Alexander G Schwing, Alexander Kirillov, and Rohit Girdhar. Masked-attention mask transformer for universal image segmentation. *arXiv preprint arXiv:2112.01527*, 2021.
- [12] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. *Annual Conf. North American Chapter of the Association for Computational Linguistics*, 2018.
- [13] Linhao Dong, Shuang Xu, and Bo Xu. Speech-transformer: a no-recurrence sequence-to-sequence model for speech recognition. In *IEEE Int. Conf. Acoustics, Speech & Signal Process.*, pages 5884–5888, 2018.
- [14] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. In *Int. Conf. Learn. Representations*, 2021.
- [15] Xueyang Fu, Jiabin Huang, Delu Zeng, Yue Huang, Xinghao Ding, and John Paisley. Removing rain from single images via a deep detail network. In *IEEE Conf. Comput. Vis. Pattern Recog.*, 2017.
- [16] Ross Girshick. Fast R-CNN. In *IEEE Conf. Comput. Vis. Pattern Recog.*, 2015.
- [17] Anmol Gulati, James Qin, Chung-Cheng Chiu, Niki Parmar, Yu Zhang, Jiahui Yu, Wei Han, Shibo Wang, Zhengdong Zhang, Yonghui Wu, et al. Conformer: Convolution-augmented transformer for speech recognition. *arXiv preprint arXiv:2005.08100*, 2020.
- [18] Yaru Hao, Haoyu Song, Li Dong, Shaohan Huang, Zewen Chi, Wenhui Wang, Shuming Ma, and Furu Wei. Language models are general-purpose interfaces. *arXiv preprint arXiv:2206.06336*, pages 1–32, 2022.
- [19] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. Masked autoencoders are scalable vision learners. *arXiv preprint arXiv:2111.06377*, 2021.
- [20] Gao Huang, Yu Sun, Zhuang Liu, Daniel Sedra, and Kilian Weinberger. Deep networks with stochastic depth. In *Eur. Conf. Comput. Vis.*, pages 646–661, 2016.
- [21] Andrew Jaegle, Sebastian Borgeaud, Jean-Baptiste Alayrac, Carl Doersch, Catalin Ionescu, David Ding, Skanda Koppula, Daniel Zoran, Andrew Brock, Evan Shelhamer, Olivier Hénaff, Matthew M. Botvinick, Andrew Zisserman, Oriol Vinyals, and João Carreira. Perceiver IO: A general architecture for structured inputs and outputs. *Int. Conf. Learn. Representations*, 2021.
- [22] Andrew Jaegle, Felix Gimeno, Andy Brock, Oriol Vinyals, Andrew Zisserman, and Joao Carreira. Perceiver: General perception with iterative attention. In *Int. Conf. Machine Learn.*, pages 4651–4664. PMLR, 2021.
- [23] Aishwarya Kamath, Mannat Singh, Yann LeCun, Gabriel Synnaeve, Ishan Misra, and Nicolas Carion. Mdetr-modulated detection for end-to-end multi-modal understanding. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 1780–1790, 2021.
- [24] Shigeki Karita, Nanxin Chen, Tomoki Hayashi, Takaaki Hori, Hirofumi Inaguma, Ziyang Jiang, Masao Someki, Nelson Enrique Yalta Soplin, Ryuichi Yamamoto, Xiaofei Wang, et al. A comparative study on transformer vs rnn in speech applications. In *IEEE Automatic Speech Recognition and Understanding Workshop*, pages 449–456, 2019.
- [25] Diederik P Kingma and Jimmy Ba. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014.
- [26] Alexander Kirillov, Ross Girshick, Kaiming He, and Piotr Dollár. Panoptic feature pyramid networks. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 6399–6408, 2019.
- [27] Alexander Kolesnikov, André Susano Pinto, Lucas Beyer, Xiaohua Zhai, Jeremiah Harmsen, and Neil Houlsby. UViM: A unified modeling approach for vision with learned guiding codes. *Adv. Neural Inform. Process. Syst.*, 2022.
- [28] Michael Laskin, Luyu Wang, Junhyuk Oh, Emilio Parisotto, Stephen Spencer, Richie Steigerwald, DJ Strouse, Steven

- Hansen, Angelos Filos, Ethan Brooks, Maxime Gazeau, Himanshu Sahni, Satinder Singh, and Volodymyr Mnih. In-context reinforcement learning with algorithm distillation. *Adv. Neural Inform. Process. Syst.*, pages 1–21, 2022.
- [29] Yu Li, Robby T Tan, Xiaojie Guo, Jiangbo Lu, and Michael S Brown. Rain streak removal using layer priors. In *IEEE Conf. Comput. Vis. Pattern Recog.*, 2016.
- [30] Zhenyu Li, Xuyang Wang, Xianming Liu, and Junjun Jiang. BinsFormer: Revisiting adaptive bins for monocular depth estimation. *arXiv preprint arXiv:2204.00987*, 2022.
- [31] Tsung-Yi Lin, Michael Maire, Serge Belongie, James Hays, Pietro Perona, Deva Ramanan, Piotr Dollár, and Lawrence Zitnick. Microsoft COCO: Common objects in context. In *Eur. Conf. Comput. Vis.*, pages 740–755, 2014.
- [32] Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, and Veselin Stoyanov. Roberta: A robustly optimized bert pretraining approach. *Int. Conf. Learn. Representations*, 2020.
- [33] Ze Liu, Yutong Lin, Yue Cao, Han Hu, Yixuan Wei, Zheng Zhang, Stephen Lin, and Baining Guo. Swin transformer: Hierarchical vision transformer using shifted windows. *Int. Conf. Comput. Vis.*, 2021.
- [34] Jiasen Lu, Dhruv Batra, Devi Parikh, and Stefan Lee. Vilbert: Pretraining task-agnostic visiolinguistic representations for vision-and-language tasks. *Adv. Neural Inform. Process. Syst.*, 32, 2019.
- [35] Jiasen Lu, Christopher Clark, Rowan Zellers, Roozbeh Motlaghi, and Aniruddha Kembhavi. Unified-IO: A unified model for vision, language, and multi-modal tasks. *arXiv preprint arXiv:2206.08916*, pages 1–19, 2022.
- [36] Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li, Peter J Liu, et al. Exploring the limits of transfer learning with a unified text-to-text transformer. *J. Mach. Learn. Res.*, 2020.
- [37] Nathan Silberman, Derek Hoiem, Pushmeet Kohli, and Rob Fergus. Indoor segmentation and support inference from rgbd images. In *Eur. Conf. Comput. Vis.*, pages 746–760. Springer, 2012.
- [38] Weijie Su, Xizhou Zhu, Yue Cao, Bin Li, Lewei Lu, Furu Wei, and Jifeng Dai. VL-Bert: Pre-training of generic visual-linguistic representations. *arXiv preprint arXiv:1908.08530*, 2019.
- [39] Ke Sun, Bin Xiao, Dong Liu, and Jingdong Wang. Deep high-resolution representation learning for human pose estimation. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 5693–5703, 2019.
- [40] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. *Adv. Neural Inform. Process. Syst.*, 30, 2017.
- [41] Peng Wang, An Yang, Rui Men, Junyang Lin, Shuai Bai, Zhikang Li, Jianxin Ma, Chang Zhou, Jingren Zhou, and Hongxia Yang. OFA: Unifying architectures, tasks, and modalities through a simple sequence-to-sequence learning framework. *Int. Conf. Mach. Learn.*, 2022.
- [42] Xinlong Wang, Tao Kong, Chunhua Shen, Yuning Jiang, and Lei Li. Solo: Segmenting objects by locations. In *Eur. Conf. Comput. Vis.*, pages 649–665, 2020.
- [43] Xinlong Wang, Rufeng Zhang, Tao Kong, Lei Li, and Chunhua Shen. SOLOv2: Dynamic and fast instance segmentation. *Adv. Neural Inform. Process. Syst.*, 33:17721–17732, 2020.
- [44] Zhendong Wang, Xiaodong Cun, Jianmin Bao, Wengang Zhou, Jianzhuang Liu, and Houqiang Li. Uformer: A general u-shaped transformer for image restoration. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 17683–17693, 2022.
- [45] Chen Wei, Wenjing Wang, Wenhan Yang, and Jiaying Liu. Deep retinex decomposition for low-light enhancement. *arXiv preprint arXiv:1808.04560*, 2018.
- [46] Bin Xiao, Haiping Wu, and Yichen Wei. Simple baselines for human pose estimation and tracking. In *Eur. Conf. Comput. Vis.*, pages 472–487, 2018.
- [47] Tete Xiao, Yingcheng Liu, Bolei Zhou, Yuning Jiang, and Jian Sun. Unified perceptual parsing for scene understanding. In *Eur. Conf. Comput. Vis.*, pages 418–434, 2018.
- [48] Zhenda Xie, Zheng Zhang, Yue Cao, Yutong Lin, Jianmin Bao, Zhuliang Yao, Qi Dai, and Han Hu. Simmim: A simple framework for masked image modeling. *arXiv preprint arXiv:2111.09886*, 2021.
- [49] Wenhan Yang, Robby Tan, Jiashi Feng, Jiaying Liu, Zongming Guo, and Shuicheng Yan. Deep joint rain detection and removal from a single image. In *IEEE Conf. Comput. Vis. Pattern Recog.*, 2017.
- [50] Syed Waqas Zamir, Aditya Arora, Salman Khan, Munawar Hayat, Fahad Shahbaz Khan, Ming-Hsuan Yang, and Ling Shao. Multi-stage progressive image restoration. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 14821–14831, 2021.
- [51] Syed Waqas Zamir, Aditya Arora, Salman Hameed Khan, Hayat Munawar, Fahad Shahbaz Khan, Ming-Hsuan Yang, and Ling Shao. Learning enriched features for fast image restoration and enhancement. *IEEE Trans. Pattern Analysis & Machine Intelligence*, 2022.
- [52] He Zhang and Vishal M. Patel. Density-aware single image de-raining using a multi-stream dense network. In *IEEE Conf. Comput. Vis. Pattern Recog.*, 2018.
- [53] He Zhang, Vishwanath Sindagi, and Vishal M. Patel. Image de-raining using a conditional generative adversarial network. *IEEE Trans. Circuits & Systems for Video Tech.*, 30(11):3943–3956, 2019.
- [54] Bolei Zhou, Hang Zhao, Xavier Puig, Tete Xiao, Sanja Fidler, Adela Barriuso, and Antonio Torralba. Semantic understanding of scenes through the ade20k dataset. *Int. J. Computer Vision*, 2018.
- [55] Xizhou Zhu, Jinguo Zhu, Hao Li, Xiaoshi Wu, Hongsheng Li, Xiaohua Wang, and Jifeng Dai. Uni-Perceiver: Pre-training unified architecture for generic perception for zero-shot and few-shot tasks. *arXiv preprint arXiv:2112.01522*, pages 16783–16794, 2022.

附录

A. 补充实现细节

本节中，我们补充了不同任务的数据准备与姿态处理的更多细节。提供了 PyTorch 风格的伪代码，以更清晰地展示实现细节。这些操作在实现中只需几步即可完成。对于每项任务，与专用方法相比，Painter 不涉及更复杂的后处理。

语义分割 如主论文第 3.1 节所述，我们在 RGB 空间中使用不同颜色来表示不同的语义类别。为此，我们将背景和忽略区域定义为黑色，即颜色为 (0, 0, 0) 的像素，并使用图 S1 中详细说明了伪代码为前景类别生成颜色。在推理过程中，为了将输出图像解码为单通道 ID 图（其中每个像素代表一个类别 ID），我们计算每个输出像素与每个语义类别预定义颜色之间的 L1 距离，并将最近颜色的 ID 作为预测类别。后处理的伪代码如图 S2 所示。

```
def generate_colors_dict(b, K):
    # b: the number of used values in a single channel
    # K: the number of classes

    m = 255 // b # get margin
    colors = []
    for class_id in range(K):
        # compute margin multiplier
        r_mult = class_id // b**2
        g_mult = (class_id %
        b_mult = class_id %
        # compute r, g, b values
        r = 255 - r_mult * m
        g = 255 - g_mult * m
        b = 255 - b_mult * m
        colors.append((r, g, b))

    return colors
```

图 S1. 生成颜色的伪代码。//：向下取整除法；%：取模运算。

```
def forward(image, colors):
    # image: (H, W, 3)
    # colors: (K, 3), where K is the number of classes

    # get distance between pixels and pre-defined colors
    dist = (image.view(H, W, 1, 3) - colors.view(1, 1, K, 3))
        .abs().sum(-1) # (H, W, K)
    segm = dist.argmin(dim=-1) # (H, W)

    return segm
```

图 S2. 语义分割后处理的伪代码。

关键点检测 对于关键点检测，输出图像由 R 通道（表示类别无关的热图）和 G/B 通道（表示关键点类别）组成。如图 S3 所示，我们将输出图像转换为 17 通道热图，并采用常用的后处理 [39,46] 来获得最终的关键点位置。

```
def forward(image, colors):
    # image: (H, W, 3)
    # colors: (K, 3), where K is the number of keypoints

    # r for heatmaps and gb for keypoint classes
    r = images[..., 0] # (H, W)
    gb = images[..., 1:] # (H, W, 2)

    # get keypoint class of each pixel
    dist = (gb.view(H, W, 1, 2) - colors.view(1, 1, K, 2)).
        abs().sum(-1) # (H, W, K)
    segm = dist.argmin(dim=-1) # (H, W)

    for idx in range(K):
        mask = segm == idx
        heatmap = mask * r # (H, W)
        heatmaps.append(heatmap)
    heatmaps = stack(heatmaps) # (K, H, W)

    return heatmaps
```

图 S3. 关键点检测后处理的伪代码。堆叠：沿新维度连接张量序列。

全景分割 如第 3.2 节所述，本文将全景分割任务分解为语义分割和类别无关的实例分割。训练时，语义分割子任务采用与 ADE-20K 语义分割相同的设置 [54]，但在分配颜色时设置基础 $b = 7$ 。与语义分割的颜色生成过程类似，本文为类别无关实例分割中使用的每个位置类别生成颜色 [42]。每个实例掩码的颜色由其中心位置决定。

推理时，语义 ID 图可通过图 S2 所述的后处理获得，而类别无关的实例掩码则通过预测颜色与预定义位置类别颜色之间的距离阈值化生成。采用矩阵 NMS[43] 去除重复的实例预测。本文对语义预测的像素进行多数投票，以获得每个实例掩码的语义类别，如图 S4 所示。最后，遵循 Panoptic FPN[26] 合并语义分割和实例分割预测，得到全景分割结果。

图像复原 用于图像复原的数据集详细统计信息见表 S1。

Tasks	Deraining							Enhance.	Denoising
Datasets	Rain14000 [15]	Rain1800 [49]	Rain800 [53]	Rain100H [49]	Rain100L [49]	Rain1200 [52]	Rain12 [29]	LoL [45]	SIDD [1]
Train Samples	11200	1800	700	0	0	0	12	485	320
Test Samples	2800	0	100	100	100	1200	0	15	40
Testset Rename	Test2800	-	Test100	Rain100H	Rain100L	Test1200	-	-	-

Table S1. Dataset description for image restoration tasks.

(a) Patch merging			(b) Encoder			(c) Head type			(d) Loss function		
merging?	mIoU	mAcc	backbone	mIoU	mAcc	head	mIoU	mAcc	loss	mIoU	mAcc
✗	39.7	51.1	ViT-B	31.4	41.4	linear	38.6	50.2	ℓ_1	40.6	52.5
✓	41.2	53.0	ViT-L	41.2	53.0	light	41.2	53.0	ℓ_2	26.3	37.7
									smooth- ℓ_1	41.2	53.0

表 S2. ADE-20K 语义分割的消融实验。(a) 在三个变换器块后合并图像块；(b) 编码器；(c) 头部类型；(d) 损失函数。

```
def forward(segmap_dist, inst_masks):
    # segmap_dist: (H, W, K), where K is the number of thing
    # classes
    # inst_masks: (N, H, W), where N is the number of
    # instances

    # turn distances to scores
    segmap_scores = 1. - segmap_dist / max(segmap_dist)
    # majority vote
    class_probs = einsum("nhw,hwk->nk", inst_masks,
                          segmap_scores) # (N, K)
    pred_classes = class_probs.argmax(dim=-1) # (N,)

    return pred_classes
```

图 S4. 用于标注每个实例掩码的多数投票伪代码。einsum: 爱因斯坦求和。

B. 附加结果

本文报告了框架中多个组件的消融实验结果，采用 3k 次迭代的较短训练计划，其余超参数保持不变，在 ADE-20K 语义分割任务上进行。

合并图像块 在训练过程中，每个输入样本同时包含输入图像和输出图像，这导致较高的内存开销并显著减慢训练速度。本文通过在三个块之后逐块相加输入图像和输出图像的早期特征，将近一半的计算成本降低。表 S2a 显示，这种新设计甚至带来了性能提升。本文认为，该设计通过将输入与输出堆叠在一起，进一步提供了像素到像素的对应关系。而在原始设置中，这些关系需要由模型学习，这会使得优化更加困难，尤其是在较短的训练计划下。




图 S5. 更多可视化结果。可视化的任务包括马铃薯上的关键点检测、蜜蜂上的目标分割以及番茄上的实例分割。

编码器 本文采用不同模型规模的标准视觉变换器（Vision Transformer, ViT）[14] 作为编码器，包括 ViT-base 和 ViT-large。结果见表 S2b。我们发现，采用 ViT-L 的模型在性能上大幅超越采用 ViT-B 的模型。这一观察符合直觉，即通常更大的模型能带来更好的性能。对于通用模型而言，它们可以使用更多数据，但在方法设计上任务特定的先验较少，因此可能比任务特定模型需要更大的模型容量。

头部 我们使用一个轻量的三层头部，包含一个线性（ 1×1 卷积）层、一个 3×3 卷积层和另一个线性层，将每个图像块的特征映射回其原始分辨率，*e.g.*, $16 \times 16 \times 3$ 。每个图像块的特征




图 S6。不同任务学习到的提示可视化。每一列表示一个任务的提示对。第一行和第二行分别为输入和输出图像。为便于可视化，每个提示被归一化为值在 0 到 255 之间的 RGB 图像。不同任务展现出不同的模式。用户可以将这些提示图像输入 Painter 模型，以启用相应的应用。

图像块的特征是均匀采样自变换器块的 4 个特征图的拼接。如表 S2c 所示，轻量头部相比仅使用线性层的基线取得了明显提升。

损失函数 Painter 使用简单的像素回归损失来学习所有任务。在表 S2d 中，我们比较了不同的回归损失函数，包括 ℓ_1 , ℓ_2 和平滑 ℓ_1 。我们默认采用平滑 ℓ_1 ，因为它能达到最佳性能，并且在训练过程中更加稳定。

C. 补充可视化

本节提供更多可视化结果。如图 S5 所示，Painter 根据不同的提示图像进行上下文推理。值得注意的是，Painter 在训练过程中从未被训练来解决这些任务，例如土豆的关键点检测、蜜蜂的目标分割以及番茄的实例分割。