

人形机器人策略 ~ 人类策略

Ri-Zhao Qiu^{*,1} Shiqi Yang^{*,1} Xuxin Cheng^{*,1} Chaitanya Chawla^{*,2} Jialong Li¹
 Tairan He² Ge Yan⁴ David Yoon³ Ryan Hoque³ Lars Paulsen¹
 Ge Yang⁵ Jian Zhang³ Sha Yi¹ Guanya Shi² Xiaolong Wang¹
¹ UC San Diego, ² CMU, ³ Apple, ⁴ University of Washington, ⁵ MIT
<https://human-as-robot.github.io/>




图 1：本文主张将高质量人类数据作为跨具身学习的数据来源——即面向任务的自我中心人类数据。我们收集了一个大规模数据集，物理人-人形机器人数据（ PH^2D ），该数据集利用消费级虚拟现实设备采集了明确定义的操作任务中的手部-手指三维姿态，并与机器人直接对齐。在不依赖模块化感知的情况下，我们训练了一个人类动作变换器（HAT）操作策略，通过端到端的方式直接将人类建模为一种不同的人形机器人具身。

摘要：利用多样化数据训练人形机器人的操作策略，能够增强其在任务和平台上的鲁棒性与泛化能力。然而，仅从机器人演示中学习是劳动密集型的，需要昂贵的遥操作数据收集，难以扩展。本文研究了一种更具可扩展性的数据来源——自我中心人类演示，作为机器人学习的跨具身训练数据。我们从数据和建模两个角度缓解人形机器人与人类之间的具身差距。我们收集了一个自我中心、面向任务的数据集（ PH^2D ），该数据集与人形机器人操作演示直接对齐。随后，我们训练了一个人-人形机器人行为策略，称之为人类动作变换器（HAT）。HAT 的状态-动作空间对人类和人形机器人是统一的，并且可以可微地重定向到机器人动作。通过与较小规模的机器人数据联合训练，HAT 直接将人形机器人和人类建模为不同的具身，无需额外监督。我们表明，人类数据在显著提高数据收集效率的同时，提升了 HAT 的泛化能力和鲁棒性。

关键词：机器人操作，跨具身，人形机器人

1 引言

近期，从真实机器人演示中学习极大地推动了机器人操作领域的进展 [1, 2, 3, 4]。实现这一进展的关键在于硬件与软件的协同设计，通过遥操作 [5, 6, 7, 8, 9, 10] 和直接控制来扩大数据采集规模。

机器人末端执行器 [11, 12, 5, 6, 13, 7]。除了在单一机器人上收集数据外，各方共同努力整合多样化的机器人数据，并训练跨具身的基础策略 [11, 14, 2, 1, 3, 4]，这些策略已被证明能提升跨具身和跨任务的泛化能力。

然而，收集结构化

真实机器人数据成本高昂且耗时。我们距离构建一个像计算机视觉 [17] 和自然语言处理 [18] 领域那样鲁棒且可泛化的模

数据集	人类	机器人	帧数	演示数	帧数	演示数
DexCap [15]	~378k	787	NA	NA		
EgoMimic [16]	~432k [†]	2,150	1.29M[†]	1,000		
PH ² D (Ours)	~ 3.02M	26,824	~668k	1,552		

表 1：面向任务的以自我为中心的人类数据集比较。除了拥有最多的演示外，PH²D 还在各种操作任务、多样物体和场景中收集，具有精确的三维手部-手指姿态和语言标注。†：基于报告的数据收集时间以 30 赫兹估算；而 DexCap[15] 和 PH²D 报告的是用于训练的处理后帧数。

型仍有很大差距。如果我们更仔细地审视人形机器人遥操作，它涉及机器人利用几何变换或重定向来模仿人类动作，以控制机器人关节和末端执行器。从这个角度看，本文提出以人为中心的表示来建模机器人，机器人动作只是人类动作的一次变换。如果我们能准确捕捉人类的末端执行器和头部姿态，以自我为中心的人类演示将成为更具可扩展性的训练数据来源，因为我们可以高效地在任何地方收集它们，且无需机器人。

本文开展了跨人类与人形机器人的具身训练，用于机器人操作。我们的核心洞见是：通过直接模仿人类行为来建模双手人形机器人行为，而不使用可供性等学习代理 [19, 20]。为实现这一目标，我们首先收集了一个以自我为中心、面向任务的物理人形机器人-人类数据集，命名为 **PH²D**。我们适配消费级虚拟现实设备，采集带有自动且精确的手部姿态和末端执行器（即手部）标注的自我中心视频。与现有的人类日常行为数据集 [21, 22] 相比，**PH²D** 是面向任务的，因此可直接用于协同训练。随后，使用相同的虚拟现实硬件进行遥操作，收集较小规模的人形机器人数据，以实现更好的对齐。接着，我们训练了一个人类-人形机器人动作变换器（**HAT**），在统一的人类中心状态-动作表示空间中预测未来的手指轨迹。为获得机器人动作，我们仅需应用逆运动学和手部重定向，将人类动作可微地转换为机器人动作以进行部署。

我们在不同的操作任务上进行了真实机器人评估，并开展了广泛的消融研究，以探究如何最佳地对齐人类与人形机器人示范。特别地，我们发现使用多样化人类数据进行协同训练能够提升对空间方差和背景扰动的鲁棒性，并在机器人数据中未见但人类数据中可见的场景下实现泛化。我们相信，这些发现凸显了利用人类数据进行大规模跨具身学习的潜力。

总之，本文的贡献如下：

- 数据集，PH²D，这是一个大规模、以自我为中心、面向任务的人类-人形机器人数据集，具有精确的手部和腕部姿态，用于建模人类行为（见表 1）。
- 一种跨人类-人形机器人操作策略 HAT，引入了统一的状态-动作空间及其他对齐技术，用于人形机器人操作。
- 通过大量实验和消融研究验证了策略鲁棒性和泛化能力的提升，展示了与人类数据协同训练的优势。

2 相关工作

机器人操作的模仿学习。近期，利用直接从多个及目标机器人本体采集的数据来学习机器人策略，已展现出令人瞩目的鲁棒性与灵巧性。

terity [23, 2, 24, 1, 25, 26, 9, 27, 28]。随着近期数据收集技术的进步 [29, 9, 7, 8]，模仿学习的数据规模已大幅增长，人类操作员能够高效地收集大量高质量、面向任务的数据。尽管取得了这些进展，由于缺乏互联网规模的训练数据，实现开放世界泛化仍然是一个重大挑战。

从人类视频中学习。从人类视频中学习策略是计算机视觉和机器人学中一个长期存在的课题，因为人类数据广泛存在。现有工作大致可分为两类：对齐观测或对齐动作。

从人类中学习——对齐观测结果。虽然通过遥操作实际机器人平台能够学习到具有高度灵巧性的策略，但在跨任务、环境和平台的更高层次泛化方面仍有很长的路要走。与受益于互联网规模数据的计算机视觉 (Computer Vision) [17] 和自然语言处理 (Natural Language Processing) [18] 等领域不同，现实世界中的机器人数据收集受到的限制要大得多。各种方法已尝试使用互联网规模的人类视频来训练机器人策略 [30, 31, 32, 33, 34, 35]。由于以自我为中心的机器人视角与互联网视频之间存在各种差异（例如监督和视角），大多数现有工作 [19, 20] 采用模块化方法，以中间表示作为训练的替代。最具代表性的是用于物体交互的可供性 (Affordances) [19, 20]、物体关键点预测 [36, 37, 38, 39, 40] 或其他类型的物体表示 [41, 42, 43]。

从人类中学习——对齐行动。除观测对齐外，将人类演示迁移至机器人平台还因具身、驱动与控制动力学的差异而引入额外挑战。为克服这些差异，需对人类与机器人动作进行特定对齐。已有方法采用自我中心视角掩码 [16]、对齐运动轨迹或光流 [44, 45]、以物体为中心的动作 [46, 47]，或借助专用硬件进行手部跟踪 [15]。与本文工作最接近的是 HumanPlus[48]，其设计了一种从三维人体姿态估计到遥操作人形机器人的重映射方法。与 HumanPlus 相比，本文方法的洞见在于免除收集人类数据时对机器人硬件的需求，并直接收集多样化人类数据进行协同训练。与 HumanPlus 相反，本文有意避免对人类演示执行重定向，并设计策略直接使用人类手部姿态作为状态/动作。另一方面，HumanPlus 中的“人类影子”重定向是一种仍需机器人的遥操作方法，导致其收集效率低于本文方法。

跨具身。跨具身预训练已被证明能提升对不同具身的适应性与泛化能力 [49, 50, 51, 52, 53, 54, 55, 56, 57, 58, 59, 60, 61]。在利用人类视频时，引入中间表示可能容易产生复合误差。近期工作探索端到端方法 [2, 24, 1, 3]，利用跨具身机器人数据以减少此类复合感知误差。值得注意的是，这些工作发现此类端到端学习能产生期望行为，如重试 [3]。另有工作 [62, 38] 在训练人类演示与测试时机器人部署之间施加视角约束，以允许在人类数据上学习，但这牺牲了数据收集过程的可扩展性。

同期工作。一些同期工作 [15, 16, 63] 也尝试利用以自我为中心的人类演示进行端到端的跨具身策略学习。DexCap[15] 使用手套跟踪三维手部姿态，并通过胸挂式 RGBD 相机捕捉以自我为中心的人类视频。然而，DexCap 依赖三维输入，而近期一些工作 [3, 1] 展示了二维视觉输入的可扩展性。与我们的工作最相关的是 EgoMimic[16]，它也提出使用可穿戴设备 [64] 采集二维视觉输入数据。然而，EgoMimic 要求严格的视觉传感器对齐；而我们证明，通过不同相机扩展多样化的观测可以使策略更加鲁棒。此外，PH 2 D 在数据集规模和物体多样性上也更大。我们还展示了我们的策略可以部署在真实机器人上，无需严格的视觉传感器要求和启发式方法，这为可扩展的数据采集铺平了道路。

3 方法

为了收集更多数据来训练可泛化的机器人策略，近期研究探索了跨具身学习，使策略能够泛化到不同的物理形态 [3, 1, 4, 2, 65, 14]。本文提出以自我为中心的人类操作演示作为可扩展的跨具身训练数据来源。第 3.1 节描述了我们的方法，即适配消费级 VR 设备以方便地扩大人类数据采集规模，构建面向任务的以自我为中心的人类演示数据集。第 3.2 节描述了处理领域差距的各种技术，以对齐人类数据和机器人数据，用于学习人形机器人操作策略。

3.1 PH²D: 面向任务的物理人形机器人-人类数据

尽管已有工作收集以自我为中心的人类视频 [16, 22, 21, 15]，但它们要么 (1) 提供的演示大多针对非面向任务的技能（如跳舞），并且不提供世界坐标系下的三维头部和手部姿态估计用于模仿学习监督 [21, 22]，要么 (2) 需要专用硬件或机器人设置 [15, 16]。

为了解决这些问题，我们提出 PH²D。

PH²D 通过以下方式解决这两个问题：(1) 收集与机器人执行直接相关的面向任务的人类演示，(2) 适配 VR 设备的成熟 SDK（如图 2 所示）以提供监督，以及 (3) 多样化任务、相机传感器，并减少全身运动，以缩小视觉和行为方面的领域差距。



图 2: 用于数据采集的消费级设备。为了避免依赖专用硬件进行数据采集以使我们的方法具有可扩展性，我们设计了使用消费级 VR 设备的数据采集流程。

适配 低成本商用设备 随着姿态估计 (Pose Estimation) [66] 和系统工程的发展，现代移动设备能够提供精确的设备端世界坐标系三维头部姿态跟踪和三维手部关键点跟踪 [9]，这已被证明足够稳定，可以实时遥控操作机器人 [9, 13]。我们设计了软件和硬件，以支持在不同设备间便捷地采集数据。不同的摄像头提供了更好的视觉多样性。

- **Apple Vision Pro + 内置摄像头。**我们开发了一款 Vision OS 应用，使用内置摄像头进行视觉观察，并使用 Apple ARKit 获取三维头部和手部姿态。

- **Meta Quest 3 / Apple Vision Pro + ZED 摄像头。**我们基于 OpenTelevision [9] 开发了一个基于网页的应用，用于采集三维头部和手部姿态。我们还设计了一个三维打印支架，用于将 ZED Mini 立体摄像头安装在这些设备上。这种配置成本低廉（< 700 美元），并且通过立体摄像头引入了更多多样性。

数据采集流程 我们通过让人类操作员佩戴虚拟现实设备执行与机器人执行重叠的任务（例如抓取和倾倒）来采集以任务为中心的自我中心人类演示。对于每个演示，我们提供语言指令（例如，用右手抓取一罐零度可乐），并通过最近时间戳同步本体感觉输入和视觉输入。

动作域差距。 人类动作与遥控操作机器人动作表现出两个显著特征：(1) 人类操作通常涉及无意识的全身运动，(2) 人类比机器人更灵巧，任务完成时间显著短于机器人。我们通过要求人类数据采集者保持直立坐姿来缓解第一个差距。对于第二个速度差距，我们在训练期间对人类数据的平移和旋转进行插值（有效地“减慢”动作）。减速因子 α_{slow} 通过归一化人类和仿人机器人的平均任务完成时间获得，经验上分布在 4 左右。为保持一致性，我们在所有任务中使用 $\alpha_{\text{slow}} = 4$ 。




图 3: HAT 概览。人类动作变换器（HAT）通过建模人类来学习机器人策略。在训练期间，我们从人类数据或机器人数据中采样状态-动作对。图像由冻结的 DinoV2 编码器 [67] 编码。HAT 模型在以人为本的动作空间中使用腕部六自由度姿态和指尖进行预测，在真实机器人部署期间将其重定向到机器人姿态。

3.2 HAT: 人类动作变换器

HAT 通过建模人类来学习跨具身机器人策略。我们证明，通过重定向将双手仿人机器人和人类视为不同的机器人具身，可以提高 HAT 的泛化性和鲁棒性。

$\mathcal{D}_{robot} = \{(\mathbf{S}_i, \mathbf{A}_i)\}$ 更具体地说，令 $i=1$ 为使用遥操作 [9] 从真实双手仿人机器人收集的数据集，其中 $\mathbf{S}_i$ 是第 i 次演示的状态，包括本体感觉和视觉观测， $\mathbf{A}_i$ 是动作。收集到的 PH 2 D 数据集 $\mathcal{D}_{human} = \{(\tilde{\mathbf{S}}_i, \tilde{\mathbf{A}}_i)\}_{i=1}^M$ 用于增强训练过程。注意，由于人类数据收集效率显著更高，假设 $M \gg N$ 是合理的。

目标是设计一个策略 $\pi: \mathbf{S} \rightarrow \mathbf{A}$ ，在时间 t 给定当前机器人观测 $\mathbf{s}_t$ 的情况下预测未来机器人动作 $\mathbf{a}_t$ ，其中未来动作 $\mathbf{a}_{t+1}$ 通常是用于多步执行的动作块（符号略有滥用）。我们使用 HAT 对 π 进行建模，HAT 是一种基于变换器的架构，预测动作块 [5]。模型概览如图 3 所示。我们通过实验消融讨论 HAT 的关键设计选择。

统一的状态-动作空间。双臂机器人和人类都具有两个末端执行器。在我们的场景中，机器人还配备了一个可旋转的驱动式二自由度颈部，这类似于人类执行操作时的自主头部运动。因此，我们为双臂机器人和人类设计了一个统一的状态-动作空间（*i.e.*, $(\mathbf{S}, \mathbf{A}) \equiv (\tilde{\mathbf{S}}, \tilde{\mathbf{A}})$ ）。更具体地说，本体感知观测是一个 54 维向量（头部、左手腕和右手腕的 6 维旋转 [68]；左右手腕和 10 个指尖的 x/y/z 坐标）。在这项工作中，由于我们将策略部署在配备五指灵巧手（如图 4 所示）的机器人上，机器人手和人类手的指尖之间存在双射映射。注意，单射映射也是可行的（例如，将拇指与其他手指之间的距离映射到平行夹爪的距离）。

视觉域差距。在人类/人形机器人数据上联合训练存在两种类型的域差距：相机传感器和末端执行器外观。由于我们的人类数据收集过程使用的相机与机器人部署时不同，这导致了诸如色调等相机域差距。此外，人类和人形机器人末端执行器的外观也不同。然而，通过足够大且多样化的数据，我们发现并不严格需要应用启发式处理（如视觉工件 [16]）或生成方法 [69] 来训练人机策略——基本的图像增强（如颜色抖动和高斯模糊）是有效的正则化手段。

方法	人类数据	数据归一化	传递	水平抓取	垂直抓取	倒水	总体	成功率	分布内	分布外	分布内	分布外	分布内	分布外	分布内
	分布外	分布内	分布外												
ACT	✗	NA	19/20	36/60	8/10	7/30	7/20	15/70	8/10	1/10	42/60	59/170			
HAT	✓	✗	17/20	51/60	9/10	11/30	14/20	30/70	5/10	5/10	45/60	97/170			
HAT	✓	✓	20/20	52/60	8/10	12/30	13/20	29/70	8/10	8/10	49/60	101/170			
泛化类型 背景纹理 物体放置															

表 2：自主技能执行的成功率。与人类数据（人类数据）联合训练显著提高了分布外（分布外）性能，在人形机器人 A 的所有任务上相对提升近 100%。我们还消融了为不同实施例使用不同归一化（数据归一化）的设计选择。我们指定每个任务设置来研究单一类型的泛化。每种泛化类型的详细分析见第 C 节。

训练。最终策略表示为 $\pi: f_\theta(\cdot) \rightarrow \mathbf{A}$ ，适用于人类和机器人策略，其中 f_θ 是一个基于变换器的神经网络，由 θ 参数化。最终损失由下式给出，

$$\mathcal{L} = \ell_1(\pi(s_i), a_i) + \lambda \cdot \ell_1(\pi(s_i)_{\text{EEF}}, a_{i,\text{EEF}}), \quad (1)$$

其中 EEF 是左右手腕平移向量的索引， $\lambda = 2$ 是一个（不敏感的）超参数，用于平衡损失，以强调末端执行器位置的重要性，而不是学习不必要精确的指尖关键点。

4 实验

硬件平台。我们在两个人形机器人（图 4 中的人形机器人 A 和人形机器人 B）上运行实验，它们配备了 6 自由度的 Inspire 灵巧手。人形机器人 A 是宇树 H1 机器人，人形机器人 B 是宇树 H1-2 机器人，具有不同的手臂配置。与人类类似，两个机器人（1）都配备了驱动颈部 [9] 以利用自我中心视角，（2）没有手腕摄像头。除非另有说明，大多数机器人数据收集使用人形机器人 A 完成。我们主要使用人形机器人 B 来测试跨人形机器人泛化。





图 4：硬件示意图。大多数机器人数据归属于人形机器人 A，即宇树 H1 机器人。人形机器人 B，即宇树 H1-2 机器人，具有不同的手臂电机配置，用于评估少样本跨人形机器人迁移。详细比较见第 D 节

实现细节。我们采用基于变换器（Transformer）的架构实现策略，该架构预测未来动作块 [5]。我们使用冻结的 DinoV2 ViT-S [67] 作为视觉骨干。我们实现了两种变体：（1）ACT：使用动作块变换器（Action Chunk Transformer）[5] 的基线实现，仅使用机器人数据进行训练。机器人状态表示为关节位置。（2）

人类动作变换器（Human Action Transformer, HAT）：与 ACT 架构相同，但状态编码器在统一的状态-动作空间中运行。除非另有说明，HAT 在机器人和人类数据上联合训练。每个任务训练一个检查点，大约使用 250-400 个机器人演示。

实验协议。我们在不同的物体集合中收集机器人和人类演示。由于人类演示更容易收集，人类演示中的设置通常更加多样化，包括背景、物体类型、物体位置以及人类相对于桌子的位置。

我们实验了四种不同的灵巧操作任务，并研究了分布内和分布外设置。分布内（I.D.）设置测试学习到的技能，其背景和物体排列与真实机器人数据中呈现的训练演示大致相似。在分布外（O.O.D.）设置中，我们通过引入在人类数据中出现但不在机器人数据中的新颖设置来测试泛化性和鲁棒性。图 7 展示了不同的操作任务以及我们如何为每个任务定义分布外设置。



(a) 人形机器人 B 与 PH²D 联合训练在水平抓取上的性能。o1 由人形机器人 B 看到。o2 和 o3 在人类数据中看到。o4 在所有数据中均未出现。

(b) 随着人形机器人 B 演示的增加，联合训练始终优于孤立训练，即使在低数据情况下也能达到良好的成功率。

图 5：少样本适应。随着人形机器人 B 演示数据的增加，联合训练始终优于孤立训练，即使在低数据量情况下也能实现稳健的成功率。

4.1 主要评估

人类数据对分布内测试影响较小。从表 2 可以看出，无论是否与人类数据联合训练，分布内性能结果相似。在分布内设置中，我们紧密匹配训练演示的场景设置，包括背景、物体类型和物体摆放位置。因此，仅使用少量人形机器人 A 数据训练的策略在此设置下表现良好。这一发现与近期工作 [9, 7] 一致，即冻结的视觉基础模型 [17, 67] 提高了对光照等特定外部扰动的鲁棒性。

人类数据在多种泛化场景下改善了分布外设置。模仿学习中的一个常见挑战是仅对分布内任务设置过拟合。因此，机器人策略必须能够泛化到有限单一 embodiment 数据中未见的场景设置之外。为了展示与人类数据联合训练如何减少这种过拟合，我们引入了分布外任务设置来评估这种泛化能力。从表 2 可以看出，联合训练显著改善了分布外设置，在机器人数据未见过的设置中实现了近 100% 的相对提升。特别是，我们发现人类数据改善了三种类型的泛化：背景、物体摆放和外观。为了隔离每个变量的影响，每个任务专注于表 2 中列出的特定泛化类型，详细分析见第 C 节。

4.2 异构 embodiment 间的少样本迁移

我们在一个不同的人形机器人平台（人形机器人 B）上进行了少样本泛化实验，并与我们的主要平台人形机器人 A 进行对比。值得注意的是，人形机器人 B 的演示数据是在完全独立的环境中收集的，引入了 embodiment 和环境双重变化。我们强调我们方法的两个关键优势：（1）能够将异构的以人为中心的数据源（人形机器人和人类）统一到一个可泛化的策略框架中；（2）能够以大幅减少的数据需求快速适应新的 embodiment。

实验一：跨具身协同训练的有效性。仅使用来自人形机器人 B 的 20 个演示，我们训练了 3 个策略——分别基于以下数据：（i）仅人形机器人 B，（ii）人形机器人 B + 人形机器人 A（跨具身），以及（iii）人形机器人 B + 人形机器人 A + 人类（跨具身与人类先验）。如图 5a 所示，协同训练的策略（ii）和（iii）在所有任务设置上均显著优于仅使用人形机器人 B 的基线，突显了该方法跨具身迁移潜在任务结构的能力。

实验二：扩展演示数量以实现少样本适应。我们进一步量化了少样本泛化所需的演示数量关系。我们固定人形机器人 A 和人类数据集不变

Robot Only – 28/90			Co-Trained – 35/90		
0	0	0	1	2	0
6	8	2	7	8	6
4	6	2	2	5	4

图 6：人类数据具有更高的采样效率。使用仅机器人数据和混合数据训练的模型，在每个网格中垂直抓取成功次数（共 10 次试验）。红色方框表示训练数据采集的位置。

Task	State Space	Action Speed	Success
Vertical Grasping	✓	✗	1/10
	✗	✓	0/10
	✓	✓	4/10

表 3：统一策略输入与输出的重要性。我们报告了如图 8 所示的左上角区块中垂直抓取物体的成功次数。基线使用关节位置作为状态输入，或不对人类运动进行插值。

针对水平抓取任务，并消融人形机器人 B 所需的演示数量

图 5. 协同训练（人形机器人 B + A + 人类）在所有设置上均一致优于仅在人形机器人 B 上的孤立训练，尤其是在少数据情况下。

4.3 消融实验

人类与人形机器人数据的采样效率。从概念上讲，收集人类数据的成本更低，不仅因为可以更快地完成，还因为可以在野外场景中进行；减少了每次数据收集前的设置成本；并且避免了为每位操作员配备机器人的硬件成本。

我们进行了额外的实验，以表明即使在实验室环境中，人类数据在单位时间内也能具有更好的采样效率。特别地，我们提供了一个关于垂直抓取任务的小规模实验。为两种设置分配 20 分钟，我们收集了（1）60 个仿人机器人 A 的演示，（2）30 个仿人机器人 A 的演示，以及 120 个人类演示。为了避免混淆多样性和数据规模，所有演示中的物体放置均匀分布在底部 6 个单元格中。结果如图 6 所示。使用混合机器人和人类数据训练的策略性能显著更好，这验证了人类数据相对于机器人数据的采样效率。每个单元格代表一个 10 厘米×10 厘米的区域，机器人试图在该区域拾取一个箱子。

状态-动作设计。在表 3 中，我们对本体感觉状态空间的设计选择和输出动作的速度进行了消融实验。特别地，使用相同的机器人和人类数据集，我们实现了两个基线：1）统一的状态-动作空间，但不插值（即减慢）人类动作；2）一个基线，插值人类动作，但对仿人机器人（关节位置）和人类（末端执行器表示）使用分离的状态表示。在这两个基线的展开过程中，策略表现出不同的失败模式。不插值人类动作时，预测动作的速度在快（类似人类）和慢（类似遥操作）之间波动，导致不稳定。没有统一的状态空间时，策略被赋予了一个“捷径”来区分不同的实施例，这导致了分布内性能相当，但分布外性能显著更差。

更多消融实验。由于篇幅限制，请参阅附录和补充材料以获取更多定性可视化和定量消融研究。

5 结论

本文提出 PH₂D，旨在构建一个大规模人类任务导向行为数据集，并配套训练流程 HAT。该流程利用 PH₂D 和机器人数据，展示如何将人类视为跨具身学习的数据来源。我们证明，当人类数据与机器人数据对齐时，可以直接使用混合的人类-人形机器人数据训练模仿学习模型，无需任何训练代理。与仅使用真实机器人数据训练的对照模型相比，学习到的策略展现出更好的泛化性和鲁棒性。

6 局限性

尽管我们在 PH₂D 中也收集了语言指令，但由于本文重点研究人类与人形机器人之间的具身差距，当前版本的一个局限性在于策略学习采用了相对简单的架构。在不久的将来，我们计划扩展策略学习过程，训练一个大型语言条件化的跨具身策略，以利用人类演示研究对新颖语言的泛化能力。人类数据的收集依赖于现成的虚拟现实硬件及其手部跟踪软件开发工具包。由于这些工具包主要针对虚拟现实应用训练，手部关键点跟踪在严重遮挡的某些动作中可能失败。此外，尽管理所提方法在概念上可扩展到更多机器人形态，但目前的评估是在配备灵巧手的机器人上进行的。

7 致谢

本工作部分由国家自然科学基金会职业奖 IIS-2240014、国家自然科学基金会 CCF-2112665 (TI-LOS) 以及亚马逊、Meta 和苹果的捐赠支持。

参考文献


- [1] S. Liu, L. Wu, B. Li, H. Tan, H. Chen, Z. Wang, K. Xu, H. Su, and J. Zhu. Rdt-1b: a diffusion foundation model for bimanual manipulation. *arXiv preprint arXiv:2410.07864*, 2024.
- [2] Octo Model Team, D. Ghosh, H. Walke, K. Pertsch, K. Black, O. Mees, S. Dasari, J. Hejna, C. Xu, J. Luo, T. Kreiman, Y. Tan, L. Y. Chen, P. Sanketi, Q. Vuong, T. Xiao, D. Sadigh, C. Finn, and S. Levine. Octo: An open-source generalist robot policy. In *Proceedings of Robotics: Science and Systems*, 2024.
- [3] K. Black, N. Brown, D. Driess, A. Esmail, M. Equi, C. Finn, N. Fusai, L. Groom, K. Hausman, B. Ichter, et al. π_0 : A vision-language-action flow model for general robot control. *arXiv preprint arXiv:2410.24164*, 2024.
- [4] S. Dasari, O. Mees, S. Zhao, M. K. Srirama, and S. Levine. The ingredients for robotic diffusion transformers. *arXiv preprint arXiv:2410.10088*, 2024.
- [5] T. Z. Zhao, V. Kumar, S. Levine, and C. Finn. Learning fine-grained bimanual manipulation with low-cost hardware. *arXiv preprint arXiv:2304.13705*, 2023.
- [6] Z. Fu, T. Z. Zhao, and C. Finn. Mobile aloha: Learning bimanual mobile manipulation with low-cost whole-body teleoperation. *arXiv preprint arXiv:2401.02117*, 2024.
- [7] C. Chi, Z. Xu, C. Pan, E. Cousineau, B. Burchfiel, S. Feng, R. Tedrake, and S. Song. Universal manipulation interface: In-the-wild robot teaching without in-the-wild robots. *arXiv preprint arXiv:2402.10329*, 2024.
- [8] S. Yang, M. Liu, Y. Qin, R. Ding, J. Li, X. Cheng, R. Yang, S. Yi, and X. Wang. Ace: A cross-platform visual-exoskeletons system for low-cost dexterous teleoperation. *arXiv preprint arXiv:2408.11805*, 2024.
- [9] X. Cheng, J. Li, S. Yang, G. Yang, and X. Wang. Open-television: Teleoperation with immersive active visual feedback. In *Conference on Robot Learning (CoRL)*, 2024.
- [10] T. He, Z. Luo, X. He, W. Xiao, C. Zhang, W. Zhang, K. Kitani, C. Liu, and G. Shi. Omnih2o: Universal and dexterous human-to-humanoid whole-body teleoperation and learning. *arXiv preprint arXiv:2406.08858*, 2024.
- [11] S. Dasari, F. Ebert, S. Tian, S. Nair, B. Bucher, K. Schmeckpeper, S. Singh, S. Levine, and C. Finn. Robonet: Large-scale multi-robot learning. *arXiv preprint arXiv:1910.11215*, 2019.
- [12] H. Bharadhwaj, J. Vakil, M. Sharma, A. Gupta, S. Tulsiani, and V. Kumar. Roboagent: Generalization and efficiency in robot manipulation via semantic augmentations and action chunking. In *2024 IEEE International Conference on Robotics and Automation (ICRA)*, pages 4788–4795. IEEE, 2024.
- [13] H. Ha, Y. Gao, Z. Fu, J. Tan, and S. Song. Umi on legs: Making manipulation policies mobile with manipulation-centric whole-body controllers. *arXiv preprint arXiv:2407.10353*, 2024.
- [14] A. O’Neill, A. Rehman, A. Gupta, A. Maddukuri, A. Gupta, A. Padalkar, A. Lee, A. Pooley, A. Gupta, A. Mandlekar, et al. Open x-embodiment: Robotic learning datasets and rt-x models. *arXiv preprint arXiv:2310.08864*, 2023.
- [15] C. Wang, H. Shi, W. Wang, R. Zhang, L. Fei-Fei, and C. K. Liu. Dexcap: Scalable and portable mocap data collection system for dexterous manipulation. *arXiv preprint arXiv:2403.07788*, 2024.
- [16] S. Kareer, D. Patel, R. Punamiya, P. Mathur, S. Cheng, C. Wang, J. Hoffman, and D. Xu. Egomimic: Scaling imitation learning via egocentric video. *arXiv preprint arXiv:2410.24221*, 2024. URL <https://arxiv.org/abs/2410.24221>.

- [17] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, et al. Learning transferable visual models from natural language supervision. In *ICML*. PMLR, 2021.
- [18] OpenAI. Gpt-4 technical report. Technical report, OpenAI, 2023.
- [19] R. Mendonca, S. Bahl, and D. Pathak. Structured world models from human videos. In *RSS*, 2023.
- [20] S. Bahl, R. Mendonca, L. Chen, U. Jain, and D. Pathak. Affordances from human videos as a versatile representation for robotics. In *CVPR*, 2023.
- [21] K. Grauman, A. Westbury, E. Byrne, Z. Chavis, A. Furnari, R. Girdhar, J. Hamburger, H. Jiang, M. Liu, X. Liu, et al. Ego4d: Around the world in 3,000 hours of egocentric video. In *CVPR*, 2022.
- [22] D. Damen, H. Doughty, G. M. Farinella, S. Fidler, A. Furnari, E. Kazakos, D. Moltisanti, J. Munro, T. Perrett, W. Price, and M. Wray. Scaling egocentric vision: The epic-kitchens dataset. In *ECCV*, 2018.
- [23] T. Z. Zhao, J. Tompson, D. Driess, P. Florence, K. Ghasemipour, C. Finn, and A. Wahid. Aloha unleashed: A simple recipe for robot dexterity. *arXiv preprint arXiv:2410.13126*, 2024.
- [24] L. Wang, X. Chen, J. Zhao, and K. He. Scaling proprioceptive-visual learning with heterogeneous pre-trained transformers. *arXiv preprint arXiv:2409.20537*, 2024.
- [25] C. Chi, Z. Xu, S. Feng, E. Cousineau, Y. Du, B. Burchfiel, R. Tedrake, and S. Song. Diffusion policy: Visuomotor policy learning via action diffusion. *The International Journal of Robotics Research*, page 02783649241273668, 2023.
- [26] R.-Z. Qiu, Y. Song, X. Peng, S. A. Suryadevara, G. Yang, M. Liu, M. Ji, C. Jia, R. Yang, X. Zou, et al. Wildlma: Long horizon loco-manipulation in the wild. *arXiv preprint arXiv:2411.15131*, 2024.
- [27] C. Lu, X. Cheng, J. Li, S. Yang, M. Ji, C. Yuan, G. Yang, S. Yi, and X. Wang. Mobile-television: Predictive motion priors for humanoid whole-body control. In *ICRA*, 2025.
- [28] Y. Ze, Z. Chen, W. Wang, T. Chen, X. He, Y. Yuan, X. B. Peng, and J. Wu. Generalizable humanoid manipulation with improved 3d diffusion policies. *arXiv preprint arXiv:2410.10803*, 2024.
- [29] S. P. Arunachalam, S. Silwal, B. Evans, and L. Pinto. Dexterous imitation made easy: A learning-based framework for efficient dexterous manipulation. In *2023 IEEE International Conference on Robotics and Automation (ICRA)*, pages 5954–5961. IEEE, 2023.
- [30] A. S. Chen, S. Nair, and C. Finn. Learning generalizable robotic reward functions from” in-the-wild” human videos. *arXiv preprint arXiv:2103.16817*, 2021.
- [31] J. Lee and M. S. Ryoo. Learning robot activities from first-person human videos using convolutional future regression. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops*, pages 1–2, 2017.
- [32] K. Lee, Y. Su, T.-K. Kim, and Y. Demiris. A syntactic approach to robot imitation learning using probabilistic activity grammars. *Robotics and Autonomous Systems*, 61(12):1323–1334, 2013.
- [33] A. Nguyen, D. Kanoulas, L. Muratore, D. G. Caldwell, and N. G. Tsagarakis. Translating videos to commands for robotic manipulation with deep recurrent neural networks. In *2018 IEEE International Conference on Robotics and Automation (ICRA)*, pages 3782–3788. IEEE, 2018.


- [34] J. Rothfuss, F. Ferreira, E. E. Aksoy, Y. Zhou, and T. Asfour. Deep episodic memory: Encoding, recalling, and predicting episodic experiences for robot action execution. *IEEE Robotics and Automation Letters*, 3(4):4007–4014, 2018.
- [35] Y. Yang, Y. Li, C. Fermuller, and Y. Aloimonos. Robot learning manipulation action plans by” watching” unconstrained videos from the world wide web. In *Proceedings of the AAAI conference on artificial intelligence*, volume 29, 2015.
- [36] H. Bharadhwaj, R. Mottaghi, A. Gupta, and S. Tulsiani. Track2act: Predicting point tracks from internet videos enables diverse zero-shot robot manipulation. In *ECCV*, 2024.
- [37] C. Wen, X. Lin, J. So, K. Chen, Q. Dou, Y. Gao, and P. Abbeel. Any-point trajectory modeling for policy learning. *arXiv preprint arXiv:2401.00025*, 2023.
- [38] J. Li, Y. Zhu, Y. Xie, Z. Jiang, M. Seo, G. Pavlakos, and Y. Zhu. Okami: Teaching humanoid robots manipulation skills through single video imitation. *arXiv preprint arXiv:2410.11792*, 2024.
- [39] N. Das, S. Bechtle, T. Davchev, D. Jayaraman, A. Rai, and F. Meier. Model-based inverse reinforcement learning from visual demonstrations. In *Conference on Robot Learning*, pages 1930–1942. PMLR, 2021.
- [40] H. Xiong, Q. Li, Y.-C. Chen, H. Bharadhwaj, S. Sinha, and A. Garg. Learning by watching: Physical imitation of manipulation skills from human videos. In *2021 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 7827–7834. IEEE, 2021.
- [41] S. Pirk, M. Khansari, Y. Bai, C. Lynch, and P. Sermanet. Online object representations with contrastive learning. *arXiv preprint arXiv:1906.04312*, 2019.
- [42] S. Nair, A. Rajeswaran, V. Kumar, C. Finn, and A. Gupta. R3m: A universal visual representation for robot manipulation. *arXiv preprint arXiv:2203.12601*, 2022.
- [43] Y. J. Ma, S. Sodhani, D. Jayaraman, O. Bastani, V. Kumar, and A. Zhang. Vip: Towards universal visual reward and representation via value-implicit pre-training. *arXiv preprint arXiv:2210.00030*, 2022.
- [44] L.-H. Lin, Y. Cui, A. Xie, T. Hua, and D. Sadigh. Flowretrieval: Flow-guided data retrieval for few-shot imitation learning. *arXiv preprint arXiv:2408.16944*, 2024.
- [45] J. Ren, P. Sundaresan, D. Sadigh, S. Choudhury, and J. Bohg. Motion tracks: A unified representation for human-robot transfer in few-shot imitation learning. *arXiv preprint arXiv:2501.06994*, 2025.
- [46] Y. Zhu, A. Lim, P. Stone, and Y. Zhu. Vision-based manipulation from single human video with open-world object graphs. *arXiv preprint arXiv:2405.20321*, 2024.
- [47] C.-C. Hsu, B. Wen, J. Xu, Y. Narang, X. Wang, Y. Zhu, J. Biswas, and S. Birchfield. Spot: Se (3) pose trajectory diffusion for object-centric manipulation. *arXiv preprint arXiv:2411.00965*, 2024.
- [48] Z. Fu, Q. Zhao, Q. Wu, G. Wetzstein, and C. Finn. Humanplus: Humanoid shadowing and imitation from humans. In *CoRL*, 2024.
- [49] W. Huang, I. Mordatch, and D. Pathak. One policy to control them all: Shared modular policies for agent-agnostic control. In *International Conference on Machine Learning*, pages 4455–4464. PMLR, 2020.
- [50] L. Y. Chen, K. Hari, K. Dharmarajan, C. Xu, Q. Vuong, and K. Goldberg. Mirage: Cross-embodiment zero-shot policy transfer with cross-painting. *arXiv preprint arXiv:2402.19249*, 2024.

- [51] J. Yang, C. Glossop, A. Bhorkar, D. Shah, Q. Vuong, C. Finn, D. Sadigh, and S. Levine. Pushing the limits of cross-embodiment learning for manipulation and navigation. *arXiv preprint arXiv:2402.19432*, 2024.
- [52] J. Yang, D. Sadigh, and C. Finn. Polybot: Training one policy across robots while embracing variability. *arXiv preprint arXiv:2307.03719*, 2023.
- [53] F. Ebert, Y. Yang, K. Schmeckpeper, B. Bucher, G. Georgakis, K. Daniilidis, C. Finn, and S. Levine. Bridge data: Boosting generalization of robotic skills with cross-domain datasets. *arXiv preprint arXiv:2109.13396*, 2021.
- [54] T. Franzmeyer, P. Torr, and J. F. Henriques. Learn what matters: cross-domain imitation learning with task-relevant embeddings. *Advances in Neural Information Processing Systems*, 35: 26283–26294, 2022.
- [55] A. Ghadirzadeh, X. Chen, P. Poklukar, C. Finn, M. Björkman, and D. Kragic. Bayesian meta-learning for few-shot policy adaptation across robotic platforms. In *2021 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 1274–1280. IEEE, 2021.
- [56] T. Shankar, Y. Lin, A. Rajeswaran, V. Kumar, S. Anderson, and J. Oh. Translating robot skills: Learning unsupervised skill correspondences across robots. In *International Conference on Machine Learning*, pages 19626–19644. PMLR, 2022.
- [57] M. Xu, Z. Xu, C. Chi, M. Veloso, and S. Song. Xskill: Cross embodiment skill discovery. In *Conference on Robot Learning*, pages 3536–3555. PMLR, 2023.
- [58] Z.-H. Yin, L. Sun, H. Ma, M. Tomizuka, and W.-J. Li. Cross domain robot imitation with invariant representation. In *2022 International Conference on Robotics and Automation (ICRA)*, pages 455–461. IEEE, 2022.
- [59] K. Zakka, A. Zeng, P. Florence, J. Tompson, J. Bohg, and D. Dwibedi. Xirl: Cross-embodiment inverse reinforcement learning. In *Conference on Robot Learning*, pages 537–546. PMLR, 2022.
- [60] G. Zhang, L. Zhong, Y. Lee, and J. J. Lim. Policy transfer across visual and dynamics domain gaps via iterative grounding. *arXiv preprint arXiv:2107.00339*, 2021.
- [61] Q. Zhang, T. Xiao, A. A. Efros, L. Pinto, and X. Wang. Learning cross-domain correspondence for control with dynamics cycle-consistency. *arXiv preprint arXiv:2012.09811*, 2020.
- [62] S. Bahl, A. Gupta, and D. Pathak. Human-to-robot imitation in the wild. In *RSS*, 2022.
- [63] C. Wang, L. Fan, J. Sun, R. Zhang, L. Fei-Fei, D. Xu, Y. Zhu, and A. Anandkumar. Mimicplay: Long-horizon imitation learning by watching human play. *arXiv preprint arXiv:2302.12422*, 2023.
- [64] J. Engel, K. Somasundaram, M. Goesele, A. Sun, A. Gamino, A. Turner, A. Talattof, A. Yuan, B. Souti, B. Meredith, et al. Project aria: A new tool for egocentric multi-modal ai research. *arXiv preprint arXiv:2308.13561*, 2023.
- [65] A. Khazatsky, K. Pertsch, S. Nair, A. Balakrishna, S. Dasari, S. Karamcheti, S. Nasiriany, M. K. Srirama, L. Y. Chen, K. Ellis, et al. Droid: A large-scale in-the-wild robot manipulation dataset. *arXiv preprint arXiv:2403.12945*, 2024.
- [66] W. Zhu, X. Ma, Z. Liu, L. Liu, W. Wu, and Y. Wang. Motionbert: A unified perspective on learning human motion representations. In *ICCV*, 2023.
- [67] M. Oquab, T. Darcet, T. Moutakanni, H. Vo, M. Szafraniec, V. Khalidov, P. Fernandez, D. Haziza, F. Massa, A. El-Nouby, et al. Dinov2: Learning robust visual features without supervision. *arXiv preprint arXiv:2304.07193*, 2023.


- [68] Y. Zhou, C. Barnes, J. Lu, J. Yang, and H. Li. On the continuity of rotation representations in neural networks. In *CVPR*, 2019.
- [69] T. Yu, T. Xiao, A. Stone, J. Tompson, A. Brohan, S. Wang, J. Singh, C. Tan, J. Peralta, B. Ichter, et al. Scaling robot learning with semantically imagined experience. *arXiv preprint arXiv:2302.11550*, 2023.




(a) The robot performs the **cup passing** task across four different backgrounds. The left side shows the four background variations, while the right side illustrates the two passing directions: (#1 - Right hand passes the cup to the left hand, #2 - Left hand passes the cup to the right hand).



(b) The robot performs the **horizontal grasping** task with four different items: bottle, box_1, box_2, and can, as shown on the left. The right side illustrates the process: (#1-#3 - The robot grasps the bottle, #4-#5 - The robot places it into the plastic bin).



(c) The robot performs the **vertical grasping** task. As shown on the left, the Dynamixel box is placed in nine different positions for grasping. The right side illustrates the process: (#1-#3 - The robot grasps the box, #4-#5 - The robot places the box into the plastic bin).



(d) The robot performs the **pouring** task. The left side shows different settings achieved by varying the robot's rotation and the table's position. The right side illustrates the pouring process: (#1 - Right hand grasps the bottle, #2 - Left hand grasps the cup, #3 - Pouring the drink, #4 - Left hand places the cup down, #5 - Right hand places the bottle down).

图 7：定量评估中使用的任务示意图。从上到下：递杯、水平抓取、垂直抓取和倾倒。

Method	Bottle	Box ₁	Box ₂	Can	Ovr. Succ.
	I.D.	H.D.	H.D.	H.D.	
Without whole-body	8/10	6/10	0/10	7/10	21/40
With whole-body	9/10	3/10	3/10	3/10	18/40

表 4：训练演示中人类全身运动对策略推演影响的消融实验。我们在相同物体集合上收集了相同数量的抓取任务演示，分别包含或不包含全身运动。由于机器人不具备像人类那样的自然全身运动，这会对操作成功率产生负面影响。

更详尽的消融实验——数据采集

自主全身运动。在表 4 中，我们论证了在人体数据采集过程中最小化身体运动的必要性。人类在操作过程中往往会无意识地移动上半身（包括肩部和腰部运动）。然而，现有的人形机器人尚未达到如此灵巧的程度。因此，在人类演示中包含这些难以复现的动作会导致性能下降。我们推测，随着全身运动控制方法和机械设计的发展，这种必要性将大大降低。

方法	抓取 (秒)	倾倒 (秒)	人类演示	佩戴虚拟现实设备的人类演示
人形机器人演示 (虚拟现实遥操作)	19.72±1.65	37.31±6.25	3.79±0.27	4.81±0.35
			4.09±0.30	4.90±0.26

表 5：采集单次演示所需时间的摊销均值和标准差，包括场景重置。第一行显示普通人在现实世界中完成相应任务所需的时间。第二行代表我们佩戴虚拟现实设备采集人类数据时的情况，表明以自我为中心的人类演示相比机器人遥操作提供了更具可扩展性的数据来源。

但对于当前可用的平台，我们要求操作员在数据集中尽可能减少身体运动。

数据采集效率。在表 5 中，我们比较了不同设置下的任务完成时间，包括标准人类操作、佩戴虚拟现实设备进行的人类演示以及机器人遥操作。该分析突出了面向任务的人类演示如何成为跨具身学习的可扩展数据来源。值得注意的是，佩戴虚拟现实设备并不会显著影响人类操作速度，因为完成时间与标准人类演示几乎相同。

在不同的数据采集方案中，我们发现大部分开销产生于从人类动作到机器人动作的重定向过程。这主要源于延迟以及七自由度机械臂受限的工作空间，这些是现有数据采集方法（如虚拟现实遥操作 [9]、运动跟踪 [48, 10] 和牵引示教 [8, 5]）中固有的挑战。

除了数据采集速度之外，人类演示相比遥操作还具有若干额外优势。它们提供了一种更安全的替代方案，降低了与真实机器人执行相关的风险。它们也更节省人力，因为不需要额外人员进行监督。此外，人类演示在设置上具有更大的灵活性，能够在多种环境中进行，而无需针对机器人进行特定适配。另外，人类演示实现了更高的演示成功率，并且所需硬件（如动作捕捉或虚拟现实设备）与完整的机器人系统相比更易获取且更具成本效益。这些因素共同使人类数据成为大规模数据采集更具可扩展性的解决方案。

B 不同具身形态的归一化

表 2 表明，对人类和人形机器人的状态与动作向量使用不同的归一化系数时，差异较小。我们在图 8 中进行了更深入的研究，考察了不同归一化策略在垂直抓取（拾取）任务中的影响。值得注意的是，相同的归一化方法取得了最高的总体成功率，但成功分布偏向网格的右上区域。

我们假设这是因为人类的工作空间比人形机器人更大。因此，人类数据包含了人形机器人本体感知的一个子集，这导致机器人状态-动作空间的分布相对较小。

C 不同类型泛化的深入分析

人类数据改善了背景泛化能力。我们选择使用杯子传递任务来测试背景泛化能力。我们准备了四种不同的桌布作为背景，如图 7a 所示。在训练数据分布方面，该任务的遥操作数据仅在如图 7a 所示的纸张背景上收集，而人类数据则包含超过五种不同的背景。这种多样化的人类数据集显著增强了联合训练的人机协同策略（HAT Policy）的泛化能力。如表 7 所示，人机协同策略在所有四种背景上均表现出一致的优越性，展示了对背景变化的鲁棒性。此外，整体

Method	Bottle	Box ₁	Box ₂	Can	Ovr. Succ.
	I.D.	H.D.	O.O.D.	O.O.D.	
ACT	8/10	5/10	1/10	1/10	16/40
HAT	8/10	7/10	1/10	4/10	21/40

表 6: 物体外观泛化：在水平抓取任务中，我们评估了 grasping performance by attempting to grasp each object 10 times and recorded the success rate.

成功率相比未使用人类数据的训练提高了近 50%，凸显了利用多样化人类演示的优势。

人类数据改善了外观泛化能力。为了测试联合训练如何提高对物体纹理扰动的鲁棒性，我们在新物体上评估水平抓取策略，如图 7b 所示。具体来说，我们比较了策略在瓶子、盒子 1、盒子 2 和罐子上的性能，如图 7b 第一张图像中从左到右所示。这些物体在颜色和形状上与遥操作数据分布中使用的瓶子存在显著差异。

由于抓取是一项相对简单的任务，我们调整后的策略即使在仅有 50 个遥操作数据样本的情况下也展现出强大的学习能力。尽管训练集有限，该策略仍能成功抓取大多数瓶子。为了更好地突出人类数据的影响，我们选择了更具挑战性的物体进行评估。如表 6 所示，人类数据显著增强了策略抓取这些更难物体的能力。

值得注意的是，盒子 1 出现在人类数据中，而盒子 2 没有。尽管如此，我们观察到与人类数据联合训练仍然提升了整体性能，甚至在盒子 2 上也是如此，尽管其成功率并未提高。这表明，除了对特定物体的直接经验外，人类数据还帮助策略学习到更广泛的视觉先验，从而实现更主动和稳定的抓取行为。对于盒子 2，虽然成功率仍然较低——部分原因是其高度较低且颜色与桌面相似——但联合训练的人类辅助遥操作策略表现出更少的分布外失败，并更积极地搜索可抓取区域。盒子 2 上的失败主要源于抓取不稳定和小盒子从手中滑落，而非无法感知或定位物体。

此外，增加更多人类数据不仅提升了在人类训练演示中见过的物体（如盒子 1）上的性能，还增强了对完全新颖物体（如盒子 2 和罐子）的泛化能力。我们假设，随着物体数量的增长，人类辅助遥操作开始学习跨类别的视觉先验，从而引导其更有效地抓取物体，即使这些物体并未明确出现在训练集中。

人类数据改善了物体放置的泛化能力。最后，我们引入了真实机器人训练演示中不存在的物体放置变化，并专门在垂直抓取（拾取）任务中对此进行研究。在此任务中，我们有意将机器人数据收集限制在部分单元格内的物体放置，而人类垂直抓取数据则覆盖了更为多样化的设置。

为了系统分析人类数据的影响，我们在一个结构化的 3×3 网格上评估模型性能，其中每个单元格代表一个 10 厘米 $\times$ 10 厘米的抓取尝试区域。每个单元格中的数字表示 10 次试验中成功拾取的次数。真实机器人训练数据仅从两个特定单元格收集，以虚线突出显示。

我们遥操作数据分布中的一个关键细节是，50 次抓取尝试采集自右侧网格，而左侧网格仅采集了 10 次。这种不平衡解释了为何仅基于遥操作数据训练的策略难以抓取左侧网格中的物体。我们观察到，仅使用机器人数据训练的模型无法泛化到未见过的单元格，而利用人类数据进行跨具身学习则显著提升了泛化能力，使整体成功率翻倍。




图 8：物体放置泛化。在垂直抓取（拾取）任务中，使用与不使用人类数据训练的模型性能比较。3×3 网格中的每个单元格代表一个 10 厘米×10 厘米的区域，机器人在该区域尝试拾取一个盒子，数字表示 10 次尝试中成功的次数。真实机器人数据采集自虚线内的两个单元格。值得注意的是，我们的遥操作数据是故意不平衡的。

Method	Paper	Wooden	Red	Green	Ovr. Succ.
	I.D.	H.D.	O.O.D.	O.O.D.	
ACT	19/20	14/20	12/20	10/20	55/80
HAT	20/20	16/20	18/20	18/20	72/80

表 7：背景泛化：在递杯任务中，我们评估传递性能 by recording the number of failures or retries needed to complete 20 cup-passing trials.

D 人形机器人 A 与人形机器人 B 配置的深入比较

本节对两种人形平台（分别称为人形机器人 A 和人形机器人 B）进行了详细比较，重点关注关节结构及其对操作能力的启示。我们将分析限定在手臂配置上，因为身体其他部分在本文中未进行专门探索。

尽管在形态上相似，这两种人形机器人的手臂配置差异巨大，给策略的直接迁移带来了障碍。除了电机技术规格（如扭矩和编码器类型，人形机器人 B 配备绝对位置编码器）的差异外，它们的机械极限也不同。前四个近端关节——肩部俯仰、肩部横滚、肩部偏航和肘部——的运动范围（ROM）在两个平台上存在差异。人形机器人 B 展现出始终更宽的运动范围，这允许更广泛的可达构型集，并提高了手臂在受限环境中的可操作性。表 8 总结了这些共享关节的运动范围值。

在腕部观察到更为显著的架构差异。人形机器人甲仅包含一个远端关节——腕部横滚，提供有限的腕部活动能力。这限制了末端执行器的灵巧性，并将手中操作策略约束在单一旋转自由度上。相比之下，人形机器人乙配备了完整的腕部机构，由三个独立驱动关节组成：腕部俯仰、腕部横滚和腕部偏航。这些额外的自由度允许对末端执行器进行全姿态控制，从而能够执行需要精确对齐、旋转和物体姿态微调的任务。

Joint	Humanoid A	Humanoid B
shoulder_pitch	-164° to $+164^{\circ}$	-180° to $+90^{\circ}$
shoulder_roll	-19° to $+178^{\circ}$	-21° to $+194^{\circ}$
shoulder_yaw	-74° to $+255^{\circ}$	-152° to $+172^{\circ}$
elbow	-71° to 150°	-54° to 182°
wrist_roll	-175° to 175°	-172° to 157°

表 8: 人形机器人甲与乙的关节运动范围比较 (单位: 度)