

π_0 ：一种用于通用机器人控制的视觉-语言-动作流模型

Physical Intelligence

Kevin Black, Noah Brown, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Lachy Groom, Karol Hausman, Brian Ichter, Szymon Jakubczak, Tim Jones, Liyiming Ke, Sergey Levine, Adrian Li-Bell, Mohith Mothukuri, Suraj Nair, Karl Pertsch, Lucy Xiaoyang Shi, James Tanner, Quan Vuong, Anna Walling, Haohuan Wang, Ury Zhilinsky
<https://physicalintelligence.company/blog/pi0>




图 1：我们的通用机器人策略采用预训练的视觉语言模型（VLM）骨干，以及包含多种灵巧操作任务的跨具身数据集。通过添加一个独立的动作专家，该专家通过流匹配生成连续动作，模型被适配到机器人控制中，从而实现精确而流畅的操作技能。该模型随后可直接根据提示执行任务，或在高品质数据上进行微调，以完成复杂的多阶段任务，例如折叠多件衣物或组装盒子。

摘要——机器人学习在释放灵活、通用和灵巧机器人系统的全部潜力方面具有巨大前景，同时也有望解决人工智能中一些最深层次的问题。然而，将机器人学习提升到有效现实世界系统所需的通用性水平，在数据、泛化和鲁棒性方面面临重大障碍。在本文中，我们讨论了通用机器人策略（即机器人基础模型）如何应对这些挑战，以及如何为复杂且高度灵巧的任务设计有效的通用机器人策略。我们提出了一种新颖的流匹配架构

该架构构建于预训练的视觉语言模型（VLM）之上，以继承互联网规模的语义知识。随后，我们讨论了如何利用来自多个灵巧机器人平台（包括单臂机器人、双臂机器人和移动机械手）的大型多样化数据集来训练该模型。我们从模型通过直接提示执行任务的能力、遵循人类和高级 VLM 策略的语言指令的能力，以及通过微调获取新技能的能力等方面对模型进行了评估。我们的结果涵盖了各种任务，如叠衣、擦桌和组装盒子。



图 2： π_0 控制移动机械手折叠衣物。我们的模型在来自 7 种不同机器人配置和 68 个任务的多样化数据上进行预训练，然后可以直接提示或微调以完成复杂的下游任务，例如这个叠衣策略，它从烘干机中取出衣物，将其装入洗衣篮，将洗衣篮搬到折叠桌旁，然后折叠每件衣物。

I. 引言

一个人应当能够换尿布、策划入侵、屠宰生猪、驾驶船只、设计建筑、创作十四行诗、结算账目、砌筑墙壁、接合断骨、安抚临终者、接受命令、下达命令、协同合作、独立行动、解算方程、分析新问题、抛撒粪肥、编写计算机程序、烹饪美味佳肴、高效战斗、英勇赴死。专业化是昆虫的特质。

—— 罗伯特·安森·海因莱因，《时间足够你爱》

人工智能系统形态各异，从高度专业化的系统——它们能解决人类心智无法企及的复杂问题，例如预测蛋白质构象 [21]——到能根据文本提示生成逼真高分辨率图像或视频的系统 [40]。然而，人类智能最远超机器智能的维度在于多才多艺：即在多样的物理环境中解决不同任务的能力，同时能智能地应对环境约束、语言指令和意外扰动。人工智能朝这种多才多艺迈进的最切实进展，或许体现在大型语言模型和视觉语言模型 [1, 48] 中：这些系统在大规模且极为多样的网络图像与文本语料上进行预训练，随后利用更精心策划的数据集进行微调（“对齐”），以诱导期望的行为模式和响应性。尽管此类模型已被证明展现出广泛的指令遵循和问题解决能力 [53, 27]，但它们并未像人类那样真正置身于物理世界之中，其对物理交互的理解完全基于抽象描述。若要使这些方法在构建具备人类所拥有的物理情境化多才多艺的人工智能系统方面取得切实进展，就需要在物理情境化数据——即来自自身机器人智能体的数据——上训练它们。能够被指派执行多种机器人行为的灵活且通用的模型，具有巨大的实用意义，同时也可能为当今机器人学习面临的一些最严峻挑战提供解决方案，例如数据可用性、泛化能力和鲁棒性。在自然语言 [1] 和计算机视觉 [39] 领域，基于多样多任务数据预训练的通用基础模型，往往优于为特定任务量身定制的专用模型

解决方案。例如，如果目标是识别照片中的鸟类，那么在许多不同的图像-语言关联上进行预训练，然后针对鸟类识别任务进行微调或提示，可能比仅使用鸟类识别数据进行训练更为高效。类似地，我们可能会发现，对于有效的专用机器人系统，首先在高度多样化的机器人数据上进行预训练，然后针对所需任务进行微调或提示，会更为有效。这可以解决数据稀缺的挑战，因为通用模型可以获得更多的数据来源——包括来自其他任务、其他机器人甚至非机器人来源的数据——并且它可能解决鲁棒性和泛化挑战，因为多样化的数据表现出对观测和动作的更广泛覆盖，提供了各种场景、修正和恢复行为，这些在更狭窄的专用数据中可能不存在。因此，采用大规模预训练方法进行机器人学习，有潜力解决该领域的许多挑战，并使实用的学习型机器人成为现实，同时进一步加深我们对人工智能中最深层问题的理解。

然而，开发这种通用机器人策略——即机器人基础模型——涉及许多重大挑战。首先，任何此类研究都必须以非常大的规模进行，因为大规模预训练的全部好处在较小规模下往往不存在 [54]。其次，它需要开发正确的模型架构，能够有效利用多样化的数据源，同时能够表示与复杂物理场景交互所需的复杂而微妙的行为。第三，它需要正确的训练方案。这可能是最重要的因素，因为自然语言处理和计算机视觉中大型模型的最新进展在很大程度上依赖于精心策划预训练和后训练数据的精细策略 [35]。

本文提出一个原型模型与学习框架，称为 π_0 ，用以说明如何应对上述三个瓶颈。模型与系统如图 1 所示。为整合多样数据来源，首先利用预训练的视觉语言模型（VLM）引入互联网规模的经验。通过以视觉语言模型为基础，模型继承了语言与视觉语言模型的通用知识、语义推理及问题求解能力。随后进一步训练模型以纳入机器人动作，将其转化为视觉语言

动作（视觉-语言-动作，VLA）模型 [7]。为了能够利用多种多样的机器人数据源，我们采用跨具身训练 [10]，将来自多种机器人类型的数据合并到同一个模型中。这些不同的机器人类型具有不同的配置空间和动作表示，包括单臂和双臂系统，以及移动机械手。此外，为了能够执行高度灵巧和复杂的物理任务，我们使用带有流匹配（扩散的一种变体）的动作分块架构 [57] 来表示复杂的连续动作分布 [28, 32]。这使得我们的模型能够以高达 50 赫兹的频率控制机器人完成灵巧任务，例如叠衣服（见图 1）。为了将流匹配与视觉-语言模型（VLM）相结合，我们使用了一种新颖的动作专家，该专家通过基于流的输出增强了标准 VLM。与语言模型一样，我们模型的架构只是我们方法的一部分。为了灵活且鲁棒地执行复杂任务，我们需要正确的训练方案。我们的方案反映了在超大规模语言和图像-语言模型中常见的预训练/后训练分离 [1, 48]，即模型首先在非常大且多样化的语料库上进行预训练，然后在更窄且更精心策划的数据上进行微调，以诱导出期望的行为模式——在我们的案例中，即灵巧性、效率和鲁棒性。直观地说，仅在高品质数据上训练并不能教会模型如何从错误中恢复，因为此类数据中很少出现错误。仅在较低品质的预训练数据上训练也不能教会模型高效且鲁棒地行动。将两者结合可提供期望的行为：模型尽可能以类似于高品质数据的方式行动，但仍拥有在出错时可部署的恢复和纠正手段。我们工作的贡献包括：基于 VLM 预训练和流匹配的新颖通用机器人策略架构，以及对此类机器人基础模型的预训练/后训练方案进行的实证研究。我们评估了模型在开箱即用的情况下接受语言命令、微调至下游任务，以及与输出中间语言命令以执行复杂且时间扩展任务的高层语义策略相结合时的表现。虽然我们的模型和系统利用了近期工作中提出的多种思想，但各要素的组合是新颖的，且实证评估展示出的灵巧性和通用性水平显著超越了先前展示的机器人基础模型。我们通过在超过 10,000 小时的机器人数据上进行预训练，并微调至各种灵巧任务来评估我们的方法，这些任务包括叠衣服（见图 2）、清理桌面、将餐具放入微波炉、将鸡蛋堆叠到蛋盒中、组装盒子以及装袋杂货。

二、相关工作

本文工作建立在近期提出的大规模机器人学习方法以及多模态语言模型之上。本文工作与近期提出的视觉-语言-动作（VLA）模型最为密切相关，这些模型利用预训练的视觉-语言模型（VLM）

这些模型经过微调用于机器人控制 [7, 24, 55]。此类模型采用自回归离散化，以类似于文本标记的方式表示动作。相比之下，本文模型采用新颖设计，通过流匹配 [32, 28]（扩散 [20, 46] 的一种变体）微调视觉语言模型以生成动作。这使本文能够处理高频动作块 [57]（高达 50 赫兹）和高度灵巧的任务，本文表明这些任务对先前的自回归视觉语言动作模型 [7] 构成重大挑战。这与近期关于动作生成扩散模型的多项工作 [9, 60] 相似。与这些工作相比，本文模型使用预训练的视觉语言模型骨干 [5]。本文的贡献本质上是综合性的，聚焦于机器人基础模型的框架，不仅包括模型架构本身，还包括预训练方案、预训练和后训练阶段，以及一系列真实世界实验。在机器人控制之外，许多模型被提出将预训练语言模型与扩散结合 [40, 41, 14]，包括专门混合扩散和自回归大语言模型的模型 [19, 29, 59]。此类模型通常关注图像生成，但本文的动作生成模型建立在多个先前提出的概念之上。与周等人 [59] 类似，本文通过应用于单个序列元素的扩散式（流匹配）损失训练模型，取代仅解码器变换器的标准交叉熵损失。与刘等人 [29] 类似，本文对与扩散对应的标记使用单独的一组权重。将这些概念融入视觉语言动作模型，本文提出了据我们所知首个产生高频动作块用于灵巧控制的流匹配视觉语言动作模型。本文的工作还建立在丰富的先前大规模机器人学习工作历史之上。该领域的早期工作通常利用自监督或自主数据收集 [26, 22, 8]，为抓取 [18, 37] 或推动 [56] 等简单任务提供易处理的数据源，但缺乏更灵巧行为的复杂性。最近，许多高质量数据集被收集用于机器人控制，以实现广泛泛化 [23, 10, 52, 33, 34, 43, 13, 6]，但通常针对由物体搬运和基本家具操作（例如开抽屉）组成的较简单任务 [31, 15]。更灵巧的任务已在较小规模上研究，通常使用数十或数百条训练轨迹 [57]，相当于 10 小时或更少。由于本文的目标之一是研究复杂和灵巧的行为，本文使用更大的数据集，约 10,000 小时演示，辅以开源 OXE 数据集 [10]。据我们所知，就机器人数据量而言，这代表了迄今为止最大的机器人学习实验。在此规模下，本文表明更复杂的预训练/后训练方案非常有效——类似于用于大语言模型的方案，预训练阶段赋予模型广泛的知识基础，随后在后训练阶段使用更高质量的精选数据精炼，以实现期望行为。本文展示的任务复杂性显著超越先前工作。虽然近期工作已展示多项




图 3：本文框架概览。首先构建预训练混合数据集，该数据集由自研灵巧操作数据集与开源数据共同组成。利用该混合数据集训练流匹配视觉-语言-动作模型，该模型包含一个较大的视觉-语言模型骨干网络和一个较小的动作专家模块，用于处理机器人状态与动作。视觉-语言模型骨干网络的权重由 PaliGemma[5] 初始化，提供从大规模互联网预训练中学习到的表征。最终得到的 π_0 模型能够控制具有不同动作空间的多种机器人本体，以完成各类任务。

对于更复杂和灵巧的行为，例如系鞋带 [58] 或烹饪虾 [17]，本文表明所提框架能够学习极长的任务，有时长达数十分钟，这些行为同时结合了物理灵巧性与组合复杂性。例如，叠衣任务要求机器人操作各种可能以任意初始配置出现的衣物，并依次折叠多件物品。清理餐桌任务要求机器人辨别新物体的类别（垃圾或餐具）。本文表明，单一跨本体模型可作为这些任务的基础模型。据本文所知，本工作展示了端到端机器人学习文献中最长的灵巧任务。

三、概述

我们在图 3 中概述了模型和训练流程。在训练框架中，我们首先组装一个预训练混合数据集，该数据集由我们自己的灵巧操作数据集（第 V-C 节）的加权组合和整个 OXE 数据集 [10] 组成，前者在 7 种不同的机器人配置上针对 68 种不同任务收集，后者包含来自 22 个机器人的数据。预训练阶段（第 V-A 节）还使用多样化的语言标签，结合任务名称和片段标注（子轨迹的细粒度标签，通常长度约为 2 秒）。预训练阶段的目的是训练一个基础模型，该模型展现出广泛的能力和泛化性，但不一定针对任何单一任务进行高性能优化。该基础模型能够遵循语言命令，并以初步熟练度执行各种任务。对于复杂和灵巧的任务，我们随后采用后训练程序（第 V-A 节），该程序使用高质量精选数据将模型适配到特定的下游任务。我们研究了使用少量到中等数据的高效后训练，以及针对复杂任务（如叠衣服和移动操作）使用更大数据集的高质量后训练。

IV. THE π_0 MODEL

图 3 所示的 π_0 模型主要由语言模型变换器骨干网络构成。遵循标准的晚期融合视觉语言模型方案 [3, 11, 30]，图像编码器将机器人的图像观测嵌入到与语言标记相同的嵌入空间中。我们进一步为该骨干网络增加了机器人学特定的输入与输出——即本体感受状态和机器人动作。 π_0 采用条件流匹配 [28, 32] 来建模动作的连续分布。流匹配为我们的模型提供了高精度和多模态建模能力，使其特别适合高频灵巧任务。我们的架构受 Transfusion[59] 启发，该模型使用多个目标训练单一变换器，其中对应于连续输出的标记 $\mathbf{a}$ 通过流匹配损失进行监督，对应于离散输出的标记通过交叉熵损失进行监督。在 Transfusion 的基础上，我们还发现为机器人学特定（动作和状态）标记使用一组独立的权重可以提升性能。这种设计类似于具有两个混合元素的专家混合 [45, 25, 12, 16]，其中第一个元素用于图像和文本输入，

¹ 在本文中，我们使用“标记”（token）一词来指代输入/输出槽位序列维度，即槽位对应的是离散变量（如语言标记）还是连续变量（如图像块或机器人动作）。

第二个用于机器人特定的输入和输出。我们将第二组权重称为动作专家。形式上，我们希望建模数据分布 $p(\mathbf{A}_t|\mathbf{o}_t)$ ，其中

$\mathbf{A}_t = [\mathbf{a}_t, \mathbf{a}_{t+1}, \dots, \mathbf{a}_{t+H-1}]$ 对应于未来动作的动作块（在我们的任务中使用 $H = 50$ ）， $\mathbf{o}_t$ 是观测。观测由多个 RGB 图像、语言命令和机器人的本体感受状态组成，即 $\mathbf{o}_t = [\mathbf{I}_t^1, \dots, \mathbf{I}_t^n, \ell_t, \mathbf{q}_t]$ ，其中 $\mathbf{I}_t^i$ 是 i^{th} 图像（每个机器人有 2 或 3 个图像）， ℓ_t 是语言标记序列， $\mathbf{q}_t$ 是关节角度向量。图像 $\mathbf{I}_t^i$ 和状态 $\mathbf{q}_t$ 通过相应的编码器编码，然后通过线性投影层投影到与语言标记相同的嵌入空间中。对于动作块 $\mathbf{A}_t$ 中的每个动作 $\mathbf{a}_{t'}$ ，我们有一个相应的动作标记，通过动作专家输入。在训练期间，我们使用条件流匹配损失 [28, 32] 监督这些动作标记，

$$L^\tau(\theta) = \mathbb{E}_{p(\mathbf{A}_t|\mathbf{o}_t), q(\mathbf{A}_t^\tau|\mathbf{A}_t)} \|\mathbf{v}_\theta(\mathbf{A}_t^\tau, \mathbf{o}_t) - \mathbf{u}(\mathbf{A}_t^\tau|\mathbf{A}_t)\|^2,$$

其中下标表示机器人时间步，上标表示流匹配时间步，且 $\tau \in [0, 1]$ 。近期在高分辨率图像 [14] 和视频 [38] 综合方面的工作表明，流匹配结合简单的线性高斯（或最优传输）概率路径 [28] 时，能够取得强大的经验性能，该路径由 $q(\mathbf{A}_t^\tau|\mathbf{A}_t) = \mathcal{N}(\tau\mathbf{A}_t, (1-\tau)\mathbf{I})$ 给出。在实践中，网络通过采样随机噪声 $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 、计算“含噪动作”

$\mathbf{A}_t^\tau = \tau\mathbf{A}_t + (1-\tau)\epsilon$ ，然后训练网络输出 $\mathbf{v}_\theta(\mathbf{A}_t^\tau, \mathbf{o}_t)$ 以匹配去噪向量场 $\mathbf{u}(\mathbf{A}_t^\tau|\mathbf{A}_t) = \mathbf{A}_t - \epsilon$ 。动作专家使用全双向注意力掩码，使所有动作令牌相互关注。训练期间，我们从强调较低（更嘈杂）时间步的贝塔分布中采样流匹配时间步 τ 。更多细节见附录 B。在推理时，我们通过从 $\tau = 0$ 到 $\tau = 1$ 积分学习到的向量场来生成动作，从随机噪声 $\mathbf{A}_t^0 \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 开始。我们使用前向欧拉积分规则：

$$\mathbf{A}_t^{\tau+\delta} = \mathbf{A}_t^\tau + \delta \mathbf{v}_\theta(\mathbf{A}_t^\tau, \mathbf{o}_t),$$

其中 δ 是积分步长。我们在实验中使用 10 个积分步（对应 $\delta = 0.1$ ）。注意，推理可以通过缓存前缀 $\mathbf{o}_t$ 的注意力键和值，并仅重新计算每个积分步中动作令牌对应的后缀来高效实现。我们在附录 D 中提供了推理过程的更多细节，包括模型各部分的推理时间。虽然原则上我们的模型可以从头初始化或从任何 VLM 骨干微调，但在实践中我们使用 PaliGemma [5] 作为基础模型。PaliGemma 是一个开源的 30 亿参数 VLM，在规模和性能之间提供了便利的权衡。我们为动作专家（从头初始化）增加了 3 亿参数，总计 33 亿参数。我们在附录 B 中提供了模型架构的完整描述。

非 VLM 基线模型。除了我们的主要 VLA 模型外，我们还训练了一个类似的基线模型，该模型未使用 VLM 初始化，用于消融实验。该模型我们称之为 π_0 -small，具有 4.7 亿参数，不使用 VLM 初始化，并且有一些小的差异，我们发现这些差异有助于在没有 VLM 初始化的情况下在我们的数据上进行训练，这些差异总结在附录 C 中。该模型用于我们的比较中，以评估纳入 VLM 预训练的好处。

五、数据收集与训练方案

广泛适用的机器人基础模型不仅需要表达力强且功能强大的架构，还需要正确的数据集，更重要的是，需要正确的训练方案。与大型语言模型训练通常分为预训练和后训练阶段类似，我们对模型采用多阶段训练流程。预训练阶段的目标是让模型接触多样化的任务，从而获得广泛适用且通用的物理能力；后训练阶段的目标则是赋予模型熟练流畅地执行所需下游任务的能力。因此，预训练和后训练数据集的要求是不同的：预训练数据集应尽可能覆盖更多任务，并且在每个任务中应覆盖行为的多样性。后训练数据集则应覆盖有利于有效执行任务的行为，这些行为应表现出连贯且流畅的策略。直观上，多样化（但质量较低）的预训练数据使模型能够从错误中恢复并处理高度变化的情况，而这些情况可能不会出现在高质量的后训练数据中；后训练数据则教会模型出色地执行任务。

A. 预训练与后训练




图 4：数据集概览：预训练混合数据由 OXE[10] 的一个子集和 π 数据集组成。我们使用 OXE 的一个子集，称之为 OXE Magic Soup[24]。右图展示了预训练混合数据中不同数据集的权重。左图展示了它们按步数衡量的相对大小。

我们在图 4 中提供了预训练混合数据的概览。由于每个训练样本对应一个时间步——即一个元组 $(\mathbf{o}_t, \mathbf{A}_t)$ ，——在本次讨论中我们将以时间步为单位量化数据。训练混合数据的 9.1% 由开源数据集组成，包括 OXE[10]、Bridge

v2 [52] 和 DROID [23]。这些数据集中的机器人和任务通常配备一至两个摄像头，并使用 2 至 10 赫兹的低频控制。然而，这些数据集合涵盖了广泛的对象和环境。为了学习灵巧且更复杂的任务，我们还使用了来自自有数据集的 9.03 亿个时间步数据，其中 1.06 亿步来自单臂机器人，7.97 亿步来自双臂机器人。该数据包含 68 个任务，每个任务由复杂行为组成——例如，“清理”任务涉及将各种不同的盘子、杯子和餐具放入清理箱，并将大量垃圾物品放入垃圾桶。请注意，此任务定义与先前工作有显著不同，先前工作通常将名词和动词的任意组合（例如，“拿起杯子”与“拿起盘子”）视为不同任务。因此，我们数据集中实际的行为范围比该“任务”数量所暗示的要广泛得多。我们将在第 V-C 节中更详细地讨论数据集中的具体机器人和任务。由于数据集在规模上有些不平衡（例如，较难的叠衣任务被过度代表），我们按 $n^{0.43}$ 对每个任务-机器人组合进行加权，其中 n 是该组合的样本数，从而使过度代表的组合被降权。配置向量 $\mathbf{q}_t$ 和动作向量 $\mathbf{a}_t$ 始终具有数据集中最大机器人的维度（在我们的案例中为 18，以容纳两个 6 自由度手臂、2 个夹爪、一个移动底座和一个垂直驱动的躯干）。对于配置和动作空间维度较低的机器人，我们对配置和动作向量进行零填充。对于图像少于三张的机器人，我们还会屏蔽缺失的图像槽位。在后训练阶段，我们使用较小的任务特定数据集对模型进行微调，使其专门化于特定的下游应用。如前所述，我们对“任务”的定义相当宽泛——例如，“清理”任务需要操纵各种不同的对象。不同任务需要截然不同的数据集，最简单的任务仅需 5 小时，而最复杂的任务则需要 100 小时或更多的数据。

B. 语言与高层策略 更复杂的任务需要语义推理和高层策略，例如清理餐桌，也可以受益于将高层任务（如“清理餐桌”）分解为更直接的子任务（如“拿起餐巾”或“将餐巾扔进垃圾桶”）的高层策略。由于我们的模型经过训练可以处理语言输入，我们可以使用高层视觉语言模型（VLM）来进行这些语义推理，这种方法类似于 SayCan [2] 等大语言模型/视觉语言模型规划方法。我们使用这样的高层策略来辅助我们的模型在若干实验任务中制定高层策略，具体将在第六节讨论。

C. 机器人系统细节 我们的灵巧操作数据集包含 7 种不同的机器人配置和 68 项任务。我们在图 5 中总结了这些平台，并在下文进行讨论：



图 5：实验中使用的机器人。包括配备 6 自由度和 7 自由度手臂的单臂和双臂机械臂，以及完整和非完整移动机械臂。 π_0 在所有平台上联合训练。

UR5e。配备平行夹爪的机械臂，带有腕部和过肩摄像头，共两个摄像头图像，配置和动作空间为 7 维。

双臂 UR5e。两个 UR5e 设置，共三个摄像头图像，配置和动作空间为 14 维。

Franka。Franka 装置配备两台相机，具有 8 维构型空间与动作空间。

双臂 Trossen。该装置基于 ALOHA 装置 [4, 57] 的构型，配备两台 6 自由度 Trossen ViperX 机械臂、两个腕部相机和一个基座相机，具有 14 维构型空间与动作空间。

双臂 ARX 与双臂 AgileX。该装置使用两台 6 自由度机械臂，支持 ARX 或 AgileX 机械臂，配备三台相机（两个腕部相机和一个基座相机），具有 14 维构型空间与动作空间。此类包含两个不同的平台，但由于它们具有相似的动力学特性，本文将其归为一类。

移动式 Trossen 与移动式 ARX。该装置基于 Mobile ALOHA [57] 平台，在移动基座上配备两台 6 自由度机械臂，机械臂为 ARX 机械臂或 Trossen ViperX 机械臂。非完整基座增加了两个动作维度，因此具有 14 维构型空间和 16 维动作空间。配备两个腕部相机和一个基座相机。此类包含两个不同的平台，但由于它们具有相似的动力学特性，本文将其归为一类。

移动式 Fibocom。两个六自由度（6-DoF）ARX 机械臂安装在一个全向移动底座上。底座增加了三个动作维度（两个用于平移，一个用于朝向），从而形成 14 维构型空间和 17 维动作空间。我们在图 4 中总结了数据集中来自各机器人的比例。

六、实验评估

我们的实验评估包括开箱即用的评估实验，将我们的基础（预训练）模型




图 6：开箱即用评估任务：为评估基础模型，我们在预训练后直接运行五个任务：叠衬衫、简单清理餐桌、困难清理餐桌、杂货装袋以及从烤面包机中取出吐司。这些任务要求结合灵巧操作、多阶段行为和语义识别能力。

与采用直接提示的替代模型设计进行比较，同时还包括详细的微调实验，在具有挑战性的下游任务上评估我们的模型，并将其与为灵巧操作提出的其他方法进行对比。我们研究以下问题：在预训练数据中出现的各种任务上， π_0 在预训练后的表现如何？我们通过直接评估 π_0 来研究该问题，并与其他机器人基础模型进行比较。 π_0 遵循语言指令的能力如何？这些实验将 π_0 与 π_0 -small（我们模型的一个较小版本，未使用视觉语言模型初始化）进行比较，以评估其遵循语言指令的性能。我们使用人类提供的指令和由高层视觉语言模型策略指定的指令进行评估，如第 V-B 节所述。 π_0 与专门为解决灵巧操作任务而提出的方法相比如何？这些实验研究下游任务，我们可以从预训练初始化进行微调，或在任务特定数据上从头训练，并与先前为灵巧操作提出的方法进行比较。我们旨在评估我们的架构和预训练流程的优势。 π_0 能否适应复杂的多阶段任务？在最后一组实验中，我们将 π_0 微调至一组特别复杂的任务，包括叠衣服和清理餐桌。这些任务需要 5 到 20 分钟才能完成。其中一些任务需要高层策略的引导。

A. 评估基础模型 在第一组实验中，我们在完整混合数据上预训练后直接评估模型，不进行任何后训练，以检验基础模型执行多种任务的能力。我们与其他机器人基础模型进行比较

文献：包括视觉-语言-动作模型（VLA）以及在相同预训练混合数据上从头训练的小型模型。我们在以下任务上进行评估，如图 6 所示，每个任务通过语言指令下达给同一基础模型。

衬衫折叠：机器人必须折叠一件起始为平铺状态的 T 恤。

轻松乘车：机器人必须清洁桌子，将垃圾放入垃圾桶，将餐具放入餐具箱。得分表示被放入正确容器的物品数量。

努力拼搏：搬运任务的一个更难版本，包含更多物体和更具挑战性的配置，例如餐具被故意放置在垃圾物体之上、物体相互遮挡，以及一些不在预训练数据集中的物体。

食品装袋：机器人必须将所有食品装袋，如薯片、棉花糖和猫粮。

从烤面包机中取出吐司：机器人从烤面包机中取出吐司。为这些实验提供比较具有挑战性，因为很少有先前的模型能够在此规模上运行。我们与 OpenVLA [24] 进行比较，这是一个 70 亿参数的视觉-语言-动作模型，最初在 OXE 数据集 [10] 上训练。我们在完整的混合数据上训练 OpenVLA。对于不支持动作分块或高频控制的 OpenVLA 来说，这是一个非常困难的混合。我们还与 Octo [50] 进行比较，这是一个较小的 9300 万参数模型。虽然 Octo 不是视觉-语言-动作模型，但它确实使用扩散过程来生成动作，为我们的流匹配视觉-语言-动作模型提供了有价值的比较点。我们也在与我们的模型相同的混合数据上训练 Octo。由于时间限制，我们无法以与完整模型相同的训练轮次训练 OpenVLA 和 Octo。因此，我们还比较了我们模型的“计算量对等”版本，该版本仅训练 16 万步（而我们的主模型训练 70 万步），这等于或低于提供给基线的步数（OpenVLA 为 16 万步，Octo 为 32 万步）。我们还包括一个仅在 UR5e 数据上微调、没有跨具身训练的 OpenVLA 模型版本，希望为 UR5e 任务提供更强的基线。最后，我们包括与第四节中描述的 π_0 -小型模型的比较，该模型可视为我们模型在无视觉-语言模型预训练情况下的缩小版本。评估度量使用每个任务和方法 10 个回合的平均归一化分数，其中完全成功得 1.0 分，部分成功得小数分。例如，收拾餐具的分数是正确放入适当容器中的物品比例。我们在附录 E 中描述了评分标准。图 7 所示的结果表明， π_0 在所有开箱任务上均取得了迄今为止最好的结果，在叠衬衫和较简单的收拾餐具任务上成功率接近完美，并且相比所有基线都有大幅提升。仅训练 16 万步的 π_0 ，“对等”版本仍然优于所有基线，甚至 π_0 -小型也优于 OpenVLA 和 Octo。OpenVLA 在这些任务上表现不佳，因为其自回归离散化架构不支持动作分块。仅使用 UR5e 数据的 OpenVLA 模型表现更好，但仍远




图 7：开箱即用评估结果：我们评估了 π_0 完整训练 70 万步的版本、训练 16 万步以匹配基线模型更新次数的版本、 π_0 -small，以及三个基线：在所有数据上训练的 OpenVLA 和 Octo，以及仅在 UR5e 任务上训练的 OpenVLA（我们发现后者在 UR5e 任务上表现更好）。在所有任务和所有比较中，即使是我们模型的“对等”版本也优于所有基线，而完整版本则以大幅优势取得最佳结果。

低于 π_0 的性能。Octo 确实支持动作块，但表示能力相对有限。这一比较说明了将大型、表达力强的架构与通过流匹配或扩散建模复杂分布的能力相结合的重要性。此外，与 π_0 -small 的比较说明了纳入 VLM 预训练的重要性。遗憾的是，很难使最后一项比较完全公平： π_0 -small 使用的参数更少，但更大的模型在没有预训练的情况下难以使用。总体而言，这些实验表明 π_0 提供了一个强大的预训练模型，能够有效地在多种机器人上执行各种任务，性能远优于先前模型。

B. 遵循语言指令 在下一组实验中，我们对基础 π_0 模型进行微调，使其在一组评估域中遵循语言指令。我们将此微调后的 π_0 模型与第四节中描述的 π_0 small 模型进行比较，后者是我们在上一节中发现的最强基线。回顾一下， π_0 -small 未使用 VLM 初始化。因此，本实验旨在衡量 VLM 预训练在多大程度上提升了模型遵循语言指令的能力。请注意， π_0 -small 也是一个明显更小的模型——遗憾的是，很难消除这一混杂因素，因为 VLM 初始化既使得训练更大的模型而不发生过拟合变得可行，又改善了语言指令遵循能力。尽管如此，我们希望本实验能揭示 π_0 的语言能力。每个任务的语言指令包括要拾取的物体和放置这些物体的位置，带有语言标注的片段长度约为 2 秒。每个完整的



图 8：语言评估中的任务。我们在 3 个不同的语言条件任务上评估模型，每个任务都需要遵循一系列中间语言指令。这些任务包括清理餐桌（上），将餐具放入收纳箱、垃圾放入垃圾桶；布置餐桌（中），从收纳箱中取出物品；以及打包购物袋（下）。

任务由众多这样的片段组成。本评估中的任务包括：

清理餐桌：机器人必须清理餐桌，将盘子和餐具放入收纳箱，将垃圾放入垃圾桶。

布置餐桌：机器人必须从收纳箱中取出物品来布置餐桌，包括餐垫、盘子、银器、餐巾和杯子，并根据语言指令进行调整。

食品装袋：机器人必须将杂货物品，如咖啡豆袋、大麦、棉花糖、海藻、杏仁、意大利面和罐头装入袋子。在图 8 中，我们展示了评估中的语言条件任务并呈现评估结果。我们评估了五种不同的条件。 π_0 -flat（以及 π_0 -small-flat）对应直接使用任务描述（例如，“打包杂货”）命令模型，没有中间语言指令。 π_0 -human（以及 π_0 -small-human）提供来自专家人类用户的中间步骤指令（例如，拾取哪个物体以及放置在哪里）。这些条件评估每个模型遵循更详细语言指令的能力：虽然这些中间指令为如何执行任务提供了大量信息，但模型必须能够理解并遵循这些指令才能从中受益。最后， π_0 -HL 评估 π_0 使用由高级视觉语言模型提供的高级指令，如第 V-B 节所述。该条件也是自主的，没有任何人类专家。图 9 中的结果（每个任务平均 10 次试验）表明， π_0 的语言遵循准确率显著优于 π_0 -small。这表明更大的预训练视觉语言模型初始化带来了显著改进。这种能力转化为在专家人类指导（ π_0 -human）和高级模型指导（ π_0 -HL）下的性能提升。结果表明， π_0 的语言遵循能力直接转化为在高级指导下复杂任务上更好的自主性能。

C. 学习新的灵巧任务

在下一组实验中，我们在与预训练数据显著不同的新任务上评估模型，




图 9：语言评估。我们比较了策略的“扁平”版本，——扁平，它只接收整体任务指令（例如，“把杂货装袋”），与接收来自人类专家的中间指令的方法——人类，或高层视觉语言模型策略——HL。我们还在“专家”条件下将我们的模型与一个小的非视觉语言模型变体进行比较， π_0 和 π_0 -小，在语言遵循准确率方面。结果表明，使用 π_0 从人类专家提供的中间语言命令中获得了显著改进，在较小程度上也来自自主高层策略。值得注意的是，由于 π_0 -小的语言遵循能力有限，总体上它并没有因添加高层专家而获益。




图 10：微调评估任务：我们将模型微调至多种下游任务，这些任务与预训练中出现任务不同。我们的任务代表了与预训练任务相似度的范围，包括与预训练最相似的任务（叠碗和叠毛巾）、引入未见新元素的任务（微波炉），以及需要新动作和新物体类型的任务（Franka 抽屉物品和更换纸巾）。

需要全新的行为。对于这些评估，我们使用每个新任务的不同数据量对模型进行微调。虽然每个任务都是新的，但我们根据它们与预训练数据中任务的差异程度将任务划分为“层级”。这些任务如图 10 所示，包括：

UR5e 堆叠碗。该任务要求堆叠四个不同尺寸的碗。由于该任务需要像预训练数据中的清理任务一样抓取和移动餐具，我们将其归入“简单”层级。训练数据包含各种碗，评估使用已见和未见碗的混合。

毛巾折叠。该任务要求折叠毛巾。由于这与预训练中存在的衬衫折叠类似，我们将其归入“简单”层级。

微波炉中的特百惠。该任务要求打开微波炉，将塑料容器放入其中，再将其关闭。容器具有不同的形状和颜色，评估中混合使用了已见和未见的容器。容器操作与预训练数据相似，但微波炉未出现在预训练中。

更换纸巾。该任务要求从支架上取下旧的硬纸板纸巾筒，并更换为新的纸巾卷。由于预训练中出现此类物品，我们认为该任务属于“困难”级别。

Franka 抽屉物品。该任务要求打开抽屉，将物品装入抽屉，再将其关闭。由于预训练中没有使用 Franka 机器人的类似任务，我们认为该任务属于“困难”级别。我们将微调后的模型与同样采用预训练和微调流程的 Open-VLA [24] 和 Octo [50] 进行比较。由于我们的目标是评估特定的

模型（而非架构），我们使用这些模型的公开可用预训练检查点，这些检查点在 OXE [10] 上训练，然后针对每个任务进行微调。我们还与 ACT [57] 和扩散策略（Diffusion Policy）[9] 进行比较，它们专为从较小数据集学习灵巧任务而设计。ACT 和扩散策略仅在微调数据集上训练，这些数据集的大小与 ACT 和扩散策略实验中使用的单个数据集相似 [9, 57]。我们通过与预训练基础模型微调以及从头训练来评估 π_0 。此比较旨在评估 π_0 架构和我们的预训练流程各自的优势。我们假设具有 VLM 初始化的 π_0 架构应该已经为各个任务提供了更强的起点，而预训练流程应进一步提升其性能，尤其是在微调数据集较小的情况下。图 11 展示了各种方法在所有任务上的性能，每个任务平均进行 10 次试验，每个任务使用不同数量的微调数据。我们在堆叠碗和微波炉中的特百惠任务上包含了所有基线。由于 OpenVLA 和 Octo 的性能显著较差，考虑到在现实世界中评估如此多模型的时间成本，我们仅对其中一种数据集大小运行这些模型。结果表明 π_0 通常优于其他方法。有趣的是，最强的先前模型是完全在目标任务上从头训练的模型，这表明在这些领域利用预训练对先前方法构成了重大挑战。虽然 π_0 在特百惠任务上的 5 小时策略与基线表现相似，但 1 小时版本显著更好。正如预期，预训练对与预训练数据更相似的任务带来更大改进，




图 11：使用不同数据量进行微调。 π_0 即使在数据量较小的情况下也能学习一些较简单的任务，并且预训练模型通常比从头训练的模型获得更大的改进。

尽管预训练模型经常优于非预训练模型，有时提升高达 2 倍。

D. 掌握复杂的多阶段任务 在最后一组实验中，我们通过微调 and 语言相结合的方式，应对一系列具有挑战性的多阶段任务。其中部分任务的数据已存在于预训练中，但需要微调才能达到精通水平；部分任务在预训练中没有任何数据。本评估中的任务如图 12 所示，包括：

叠衣：该任务要求一个静态（非移动）双臂系统折叠衣物。衣物初始以随机揉皱状态放置在收纳箱中，目标是将衣物取出、折叠，并放置到已折叠衣物堆的顶部。揉皱衣物的随机初始配置构成了主要挑战，因为策略需要泛化到任意配置。该任务存在于预训练中。

移动叠衣：此处，图 5 中的广和通移动机器人需要折叠衣物，在控制朝向和平移的同时面临许多相同的挑战。该任务存在于预训练中。

烘干机卸载：此处，广和通移动机器人需要将衣物从烘干机中取出并放入洗衣篮。该任务存在于预训练中。

餐桌清理：该任务要求在杂乱场景中清理摆放着各种新颖物体的桌面，这比我们开箱即用评估中的基准测试更具挑战性：策略必须泛化到未见过的物体。

这些物体形状和大小各异，并且需要执行复杂的灵巧动作，例如扭转夹爪以拾取大盘子，以及小心地抓取薄而精致的物品（如玻璃杯）。机器人必须处理密集的杂乱，并智能地安排各种行为的顺序——例如，要清理带有垃圾的盘子，它必须首先拿起盘子，然后将里面的东西抖入垃圾桶，最后将盘子放入箱子中。该任务未出现在预训练中。

纸箱组装：机器人需要组装一个初始为扁平状态的纸板箱。该任务面临多项重大挑战：纸箱需要以正确的方式弯折，机器人在折叠某些部分时需要按住纸箱的其他部分，利用双臂甚至桌面在折叠动作中提供支撑。机器人可能需要重试某些折叠，这需要一种反应灵敏且智能的策略。该任务未出现在预训练中。

打包餐盒：该任务要求将几种食物从盘子中移入打包餐盒，需要将食物装入盒中使其不突出，然后用双臂合上餐盒。该任务未出现在预训练中。

装鸡蛋：机器人需要从碗中取出六个鸡蛋，将它们装入鸡蛋盒中，然后合上鸡蛋盒。鸡蛋需要根据其在碗中的姿态以适当的方式抓取，然后放入鸡蛋盒中打开的槽位。由于鸡蛋的形状、易滑性以及需要小心放置，这带来了挑战。合上鸡蛋盒需要使用双臂。该任务未出现在预训练中。结果显示了每个任务在 10 次试验中的平均得分，




图 12：我们评估了一系列复杂且时间上延展的任务。这包括：用固定式（a）或移动式（b）机器人从收纳箱中折叠衣物，清理真实午餐桌（c），组装盒子（d），将鸡蛋装入蛋盒（e），以及将食物装入外带盒（f）。这些任务需要组合数十种个体行为，如抓取、堆叠、折叠和压平，泛化到种类繁多的物体配置，并处理复杂的物理特性，如可变形物体或柔性纸板。

结果如图 13 所示。评分标准见附录 E。1.0 分代表完美执行，部分分数对应部分完成的任务（例如，0.5 表示一半物体被正确清理）。这些任务非常困难，我们无法用其他方法解决。因此，我们使用这些任务来对比我们方法的消融实验，评估 π_0 在预训练和微调之后、仅预训练后直接使用（“开箱即用”）以及不使用任何预训练而在微调数据上训练（“从头开始”）的表现。结果表明 π_0 能够解决其中许多任务，而我们完整的预训练和微调方案在所有任务上表现最佳。请注意，许多较难的任务在使用预训练模型后表现出非常大的提升，这表明预训练在更困难的任务中尤为有用。 π_0 的绝对性能因任务而异，这可能是由于任务难度以及任务在预训练中的体现程度不同所致。我们建议读者观看配套网站上的任务视频，以更全面地了解这些任务及其复杂性。我们相信，在如此具有挑战性的任务上达到这种自主性能水平，代表了使用学习策略进行灵巧机器人操作的最新水平。

七、讨论、局限性与未来工作

我们提出了一个训练机器人基础模型的框架，我们称之为 π_0 ，该框架包括在高度多样化的数据上进行预训练，随后进行开箱即用评估或微调以适应复杂的下游任务。




图 13：复杂任务上的后训练结果，以 10 次试验的平均分数表示。完整的预训练 π_0 模型在所有任务中均获得超过 50% 的最高分数，并且通常优于消融实验，尤其是在最困难的任务上提升显著。

我们的实证评估研究了结合灵巧性、泛化能力和时间延展的多阶段行为的任务。我们的模型将互联网规模的视觉语言模型（VLM）预训练与流匹配相结合，用于表示复杂的高频动作块。我们的预训练混合数据包含来自 7 种不同机器人配置和 68 个任务的 10000 小时灵巧操作数据，此外还有大量先前收集的来自 OXE [10]、DROID [23] 和 Bridge [52] 的机器人操作数据。据我们所知，这是迄今为止用于机器人操作模型的最大规模预训练混合数据。我们的微调实验涵盖 20 多个任务，结果表明我们的模型优于多种基线，包括先前的 VLA 模型 [24] 以及专为灵巧操作设计的模型 [57, 9]。我们还研究了后训练方案如何实现高度复杂的任务，例如从任意初始配置折叠多件衣物或组装盒子。我们的框架大致类似于大语言模型所采用的训练流程，通常包括在从网络抓取的超大规模数据集上预训练基础模型，随后进行旨在“对齐”模型的后训练过程，使其能够遵循指令并执行用户命令。人们普遍认为，此类模型中的大部分“知识”是在预训练阶段获得的，而后训练阶段的作用是告诉模型如何利用这些知识来完成用户命令。我们的实验表明，类似的

这种现象可能发生在机器人基础模型（Robot Foundation Model）中，其中预训练模型具备一定的零样本能力，但诸如衣物整理等复杂任务仍需利用高质量数据进行微调。仅使用这些高质量数据进行训练会导致模型脆弱，无法可靠地从错误中恢复，而直接运行零样本的预训练模型并不总能展现出后训练数据中所演示的流畅策略。我们希望本文的结果能够成为迈向通用且广泛适用的机器人基础模型的基石。实验表明，此类模型可能很快成为现实，但仍存在诸多局限性，未来工作尚有广阔空间。首先，实验尚未全面揭示预训练数据集应如何构成：本文合并了所有可用数据，但理解何种类型的数据更有助于添加以及应如何加权，仍是一个未决问题。评估中并非所有任务都能可靠运行，且目前尚不清楚如何预测达到近乎完美性能所需的数据量与数据类型。最后，结合高度多样化的数据（尤其是来自不同任务与不同机器人的数据）究竟能带来多少正向迁移，仍有待观察：尽管结果表明通用预训练机器人基础模型或将成为现实，但理解这种通用性是否延伸至更为迥异的领域（如自动驾驶、导航与腿足运动）则留待未来工作。

致谢

我们感谢劳拉·史密斯（Laura Smith）和迪比亚·戈什（Dibya Ghosh）对论文的反馈以及在图表和视频方面的协助，感谢菲利普·克拉克（Philip Clark）、凯利·西姆斯（Kelly Sims）和索纳兹·莫拉迪（Saunaz Moradi）对写作的反馈，感谢埃文·波克兰特（Evan Pokrandt）、约阿希姆·科伊森（Joakim Keussen）、丹·菲利宾（Dan Philbin）、伊坦·彭纳（Eitan Penner）、亚当·利萨戈尔（Adam Lisagor）和格雷格·米勒（Greg Miller）在插图、设计和视频方面的帮助。我们还感谢莉莉·余（Lili Yu）提供的有益技术讨论。我们非常感谢所有机器人操作员不知疲倦地收集机器人操作数据。完整的贡献声明见附录A。

参考文献

- [1] Josh Achiam, Steven Adler, Sandhini Agarwal, Lama Ahmad, Ilge Akkaya, Florencia Leoni Aleman, Diogo Almeida, Janko Altenschmidt, Sam Altman, Shyamal Anadkat, et al. Gpt-4 technical report. *arXiv preprint arXiv:2303.08774*, 2023.
- [2] Michael Ahn, Anthony Brohan, Noah Brown, Yevgen Chebotar, Omar Cortes, Byron David, Chelsea Finn, Chuyuan Fu, Keerthana Gopalakrishnan, Karol Hausman, et al. Do as i can, not as i say: Grounding language in robotic affordances. *arXiv preprint arXiv:2204.01691*, 2022.
- [3] Jean-Baptiste Alayrac, Jeff Donahue, Pauline Luc, Antoine Miech, Iain Barr, Yana Hasson, Karel Lenc, Arthur Mensch, Katherine Millican, Malcolm Reynolds, et al. Flamingo: a visual language model for few-shot learning.

Advances in neural information processing systems, 35: 23716–23736, 2022.

- [4] Jorge Aldaco, Travis Armstrong, Robert Baruch, Jeff Bingham, Sanky Chan, Kenneth Draper, Debidatta Dwivedi, Chelsea Finn, Pete Florence, Spencer Goodrich, et al. Aloha 2: An enhanced low-cost hardware for bimanual teleoperation. *arXiv preprint arXiv:2405.02292*, 2024.
- [5] Lucas Beyer, Andreas Steiner, André Susano Pinto, Alexander Kolesnikov, Xiao Wang, Daniel Salz, Maxim Neumann, Ibrahim Alabdulmohsin, Michael Tschannen, Emanuele Bugliarello, et al. Paligemma: A versatile 3b vlm for transfer. *arXiv preprint arXiv:2407.07726*, 2024.
- [6] Homanga Bharadhwaj, Jay Vakil, Mohit Sharma, Abhinav Gupta, Shubham Tulsiani, and Vikash Kumar. RoboAgent: Generalization and efficiency in robot manipulation via semantic augmentations and action chunking. In *2024 IEEE International Conference on Robotics and Automation (ICRA)*, pages 4788–4795. IEEE, 2024.
- [7] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Xi Chen, Krzysztof Choromanski, Tianli Ding, Danny Driess, Avinava Dubey, Chelsea Finn, Pete Florence, Chuyuan Fu, Montse Gonzalez Arenas, Keerthana Gopalakrishnan, Kehang Han, Karol Hausman, Alexander Herzog, Jasmine Hsu, Brian Ichter, Alex Irpan, Nikhil Joshi, Ryan Julian, Dmitry Kalashnikov, Yuheng Kuang, Isabel Leal, Lisa Lee, Tsang-Wei Edward Lee, Sergey Levine, Yao Lu, Henryk Michalewski, Igor Mordatch, Karl Pertsch, Kanishka Rao, Krista Reymann, Michael Ryoo, Grecia Salazar, Pannag Sanketi, Pierre Sermanet, Jaspiar Singh, Anikait Singh, Radu Soricut, Huong Tran, Vincent Vanhoucke, Quan Vuong, Ayzaan Wahid, Stefan Welker, Paul Wohlhart, Jialin Wu, Fei Xia, Ted Xiao, Peng Xu, Sichun Xu, Tianhe Yu, and Brianna Zitkovich. Rt-2: Vision-language-action models transfer web knowledge to robotic control. *arXiv preprint arXiv:2307.15818*, 2023.
- [8] Serkan Cabi, Sergio Gómez Colmenarejo, Alexander Novikov, Ksenia Konyushkova, Scott Reed, Rae Jeong, Konrad Zolna, Yusuf Aytar, David Budden, Mel Vecerik, et al. Scaling data-driven robotics with reward sketching and batch reinforcement learning. *arXiv preprint arXiv:1909.12200*, 2019.
- [9] Cheng Chi, Zhenjia Xu, Siyuan Feng, Eric Cousineau, Yilun Du, Benjamin Burchfiel, Russ Tedrake, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. *The International Journal of Robotics Research*, page 02783649241273668, 2023.
- [10] OX-Embodiment Collaboration, A Padalkar, A Pooley, A Jain, A Bewley, A Herzog, A Irpan, A Khazatsky, A Rai, A Singh, et al. Open X-Embodiment: Robotic learning datasets and RT-X models. *arXiv preprint arXiv:2310.08864*, 1(2), 2023.
- [11] Danny Driess, Fei Xia, Mehdi SM Sajjadi, Corey Lynch, Aakanksha Chowdhery, Brian Ichter, Ayzaan Wahid, Jonathan Tompson, Quan Vuong, Tianhe Yu, et al. Palm-

- e: An embodied multimodal language model. *arXiv preprint arXiv:2303.03378*, 2023.
- [12] Nan Du, Yanping Huang, Andrew M Dai, Simon Tong, Dmitry Lepikhin, Yuanzhong Xu, Maxim Krikun, Yanqi Zhou, Adams Wei Yu, Orhan Firat, et al. Glam: Efficient scaling of language models with mixture-of-experts. In *International Conference on Machine Learning*, pages 5547–5569. PMLR, 2022.
 - [13] Frederik Ebert, Yanlai Yang, Karl Schmeckpeper, Bernadette Bucher, Georgios Georgakis, Kostas Daniilidis, Chelsea Finn, and Sergey Levine. Bridge data: Boosting generalization of robotic skills with cross-domain datasets. *arXiv preprint arXiv:2109.13396*, 2021.
 - [14] Patrick Esser, Sumith Kulal, Andreas Blattmann, Rahim Entezari, Jonas Müller, Harry Saini, Yam Levi, Dominik Lorenz, Axel Sauer, Frederic Boesel, et al. Scaling rectified flow transformers for high-resolution image synthesis. In *Forty-first International Conference on Machine Learning*, 2024.
 - [15] Haritheja Etukuru, Norihito Naka, Zijin Hu, Seungjae Lee, Julian Mehu, Aaron Edsinger, Chris Paxton, Soumith Chintala, Lerrel Pinto, and Nur Muhammad Mahi Shafiullah. Robot utility models: General policies for zero-shot deployment in new environments. *arXiv preprint arXiv:2409.05865*, 2024.
 - [16] William Fedus, Barret Zoph, and Noam Shazeer. Switch transformers: Scaling to trillion parameter models with simple and efficient sparsity. *Journal of Machine Learning Research*, 23(120):1–39, 2022.
 - [17] Zipeng Fu, Tony Z. Zhao, and Chelsea Finn. Mobile aloha: Learning bimanual mobile manipulation with low-cost whole-body teleoperation. In *Conference on Robot Learning (CoRL)*, 2024.
 - [18] Abhinav Gupta, Adithyavairavan Murali, Dhiraj Prakashchand Gandhi, and Lerrel Pinto. Robot learning in homes: Improving generalization and reducing dataset bias. *Advances in neural information processing systems*, 31, 2018.
 - [19] Wanggui He, Siming Fu, Mushui Liu, Xierui Wang, Wenyi Xiao, Fangxun Shu, Yi Wang, Lei Zhang, Zhelun Yu, Haoyuan Li, et al. Mars: Mixture of auto-regressive models for fine-grained text-to-image synthesis. *arXiv preprint arXiv:2407.07614*, 2024.
 - [20] Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. *Advances in neural information processing systems*, 33:6840–6851, 2020.
 - [21] John Jumper, Richard Evans, Alexander Pritzel, Tim Green, Michael Figurnov, Olaf Ronneberger, Kathryn Tunyasuvunakool, Russ Bates, Augustin Židek, Anna Potapenko, et al. Highly accurate protein structure prediction with alphafold. *Nature*, 596(7873):583–589, 2021.
 - [22] Dmitry Kalashnikov, Alex Irpan, Peter Pastor, Julian Ibarz, Alexander Herzog, Eric Jang, Deirdre Quillen, Ethan Holly, Mrinal Kalakrishnan, Vincent Vanhoucke, et al. Scalable deep reinforcement learning for vision-based robotic manipulation. In *Conference on robot learning*, pages 651–673. PMLR, 2018.
 - [23] Alexander Khazatsky, Karl Pertsch, Suraj Nair, Ashwin Balakrishna, Sudeep Dasari, Siddharth Karamcheti, Soroush Nasiriany, Mohan Kumar Srirama, Lawrence Yunliang Chen, Kirsty Ellis, et al. DROID: A large-scale in-the-wild robot manipulation dataset. *arXiv preprint arXiv:2403.12945*, 2024.
 - [24] Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, Ted Xiao, Ashwin Balakrishna, Suraj Nair, Rafael Rafailov, Ethan Foster, Grace Lam, Pannag Sanketi, et al. Openvla: An open-source vision-language-action model. *arXiv preprint arXiv:2406.09246*, 2024.
 - [25] Dmitry Lepikhin, HyukJoong Lee, Yuanzhong Xu, Dehao Chen, Orhan Firat, Yanping Huang, Maxim Krikun, Noam Shazeer, and Zhifeng Chen. Gshard: Scaling giant models with conditional computation and automatic sharding. *arXiv preprint arXiv:2006.16668*, 2020.
 - [26] Sergey Levine, Peter Pastor, Alex Krizhevsky, Julian Ibarz, and Deirdre Quillen. Learning hand-eye coordination for robotic grasping with deep learning and large-scale data collection. *The International journal of robotics research*, 37(4-5):421–436, 2018.
 - [27] Yujia Li, David Choi, Junyoung Chung, Nate Kushman, Julian Schrittwieser, Rémi Leblond, Tom Eccles, James Keeling, Felix Gimeno, Agustin Dal Lago, Thomas Hubert, Peter Choy, Cyprien de Masson d’Autume, Igor Babuschkin, Xinyun Chen, Po-Sen Huang, Johannes Welbl, Sven Gowal, Alexey Cherepanov, James Molloy, Daniel J. Mankowitz, Esme Sutherland Robson, Pushmeet Kohli, Nando de Freitas, Koray Kavukcuoglu, and Oriol Vinyals. Competition-level code generation with alphacode. *Science*, 378(6624):1092–1097, 2022.
 - [28] Yaron Lipman, Ricky TQ Chen, Heli Ben-Hamu, Maximilian Nickel, and Matt Le. Flow matching for generative modeling. *arXiv preprint arXiv:2210.02747*, 2022.
 - [29] Bingchen Liu, Ehsan Akhgari, Alexander Visheratin, Aleks Kamko, Linmiao Xu, Shivam Shrirao, Joao Souza, Suhail Doshi, and Daiqing Li. Playground v3: Improving text-to-image alignment with deep-fusion large language models. *arXiv preprint arXiv:2409.10695*, 2024.
 - [30] Haotian Liu, Chunyuan Li, Qingyang Wu, and Yong Jae Lee. Visual instruction tuning. *Advances in neural information processing systems*, 36, 2024.
 - [31] Peiqi Liu, Yaswanth Orru, Jay Vakil, Chris Paxton, Nur Muhammad Mahi Shafiullah, and Lerrel Pinto. Ok-robot: What really matters in integrating open-knowledge models for robotics. *arXiv preprint arXiv:2401.12202*, 2024.
 - [32] Qiang Liu. Rectified flow: A marginal preserving approach to optimal transport. *arXiv preprint arXiv:2209.14577*, 2022.
 - [33] Ajay Mandlekar, Yuke Zhu, Animesh Garg, Jonathan Booyer, Max Spero, Albert Tung, Julian Gao, John Emmons, Anchit Gupta, Emre Orbay, et al. RoboTurk: A crowdsourcing platform for robotic skill learning through

- imitation. In *Conference on Robot Learning*, pages 879–893. PMLR, 2018.
- [34] Ajay Mandlekar, Soroush Nasiriany, Bowen Wen, Iretiayo Akinola, Yashraj Narang, Linxi Fan, Yuke Zhu, and Dieter Fox. MimicGen: A data generation system for scalable robot learning using human demonstrations. *arXiv preprint arXiv:2310.17596*, 2023.
- [35] Long Ouyang, Jeffrey Wu, Xu Jiang, Diogo Almeida, Carroll Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, et al. Training language models to follow instructions with human feedback. *Advances in neural information processing systems*, 35:27730–27744, 2022.
- [36] William Peebles and Saining Xie. Scalable diffusion models with transformers. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 4195–4205, 2023.
- [37] Lerrel Pinto and Abhinav Gupta. Supersizing self-supervision: Learning to grasp from 50k tries and 700 robot hours. In *2016 IEEE international conference on robotics and automation (ICRA)*, pages 3406–3413. IEEE, 2016.
- [38] Adam Polyak, Amit Zohar, Andrew Brown, Andros Tjandra, Animesh Sinha, Ann Lee, Apoorv Vyas, Bowen Shi, Chih-Yao Ma, Ching-Yao Chuang, et al. Movie gen: A cast of media foundation models. *arXiv preprint arXiv:2410.13720*, 2024.
- [39] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, et al. Learning transferable visual models from natural language supervision. In *International conference on machine learning*, pages 8748–8763. PMLR, 2021.
- [40] Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser, and Björn Ommer. High-resolution image synthesis with latent diffusion models. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 10684–10695, 2022.
- [41] Chitwan Saharia, William Chan, Saurabh Saxena, Lala Li, Jay Whang, Emily L Denton, Kamyar Ghasemipour, Raphael Gontijo Lopes, Burcu Karagol Ayan, Tim Salimans, et al. Photorealistic text-to-image diffusion models with deep language understanding. *Advances in neural information processing systems*, 35:36479–36494, 2022.
- [42] V Sanh. Distilbert, a distilled version of bert: Smaller, faster, cheaper and lighter. *arXiv preprint arXiv:1910.01108*, 2019.
- [43] Nur Muhammad Mahi Shafiullah, Anant Rai, Haritheja Etukuru, Yiqian Liu, Ishan Misra, Soumith Chintala, and Lerrel Pinto. On bringing robots home. *arXiv preprint arXiv:2311.16098*, 2023.
- [44] Noam Shazeer. Fast transformer decoding: One write-head is all you need. *arXiv preprint arXiv:1911.02150*, 2019.
- [45] Noam Shazeer, Azalia Mirhoseini, Krzysztof Maziarz, Andy Davis, Quoc Le, Geoffrey Hinton, and Jeff Dean. Outrageously large neural networks: The sparsely-gated mixture-of-experts layer. *arXiv preprint arXiv:1701.06538*, 2017.
- [46] Jascha Sohl-Dickstein, Eric Weiss, Niru Maheswaranathan, and Surya Ganguli. Deep unsupervised learning using nonequilibrium thermodynamics. In *International conference on machine learning*, pages 2256–2265. PMLR, 2015.
- [47] Andreas Steiner, Alexander Kolesnikov, Xiaohua Zhai, Ross Wightman, Jakob Uszkoreit, and Lucas Beyer. How to train your vit? data, augmentation, and regularization in vision transformers. *arXiv preprint arXiv:2106.10270*, 2021.
- [48] Gemini Team, Rohan Anil, Sebastian Borgeaud, Jean-Baptiste Alayrac, Jiahui Yu, Radu Soricut, Johan Schalkwyk, Andrew M Dai, Anja Hauth, Katie Millican, et al. Gemini: a family of highly capable multimodal models. *arXiv preprint arXiv:2312.11805*, 2023.
- [49] Gemma Team, Thomas Mesnard, Cassidy Hardin, Robert Dadashi, Surya Bhupatiraju, Shreya Pathak, Laurent Sifre, Morgane Rivière, Mihir Sanjay Kale, Juliette Love, et al. Gemma: Open models based on gemini research and technology. *arXiv preprint arXiv:2403.08295*, 2024.
- [50] Octo Model Team, Dibya Ghosh, Homer Walke, Karl Pertsch, Kevin Black, Oier Mees, Sudeep Dasari, Joey Hejna, Tobias Kreiman, Charles Xu, et al. Octo: An open-source generalist robot policy. *arXiv preprint arXiv:2405.12213*, 2024.
- [51] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30, 2017.
- [52] Homer Rich Walke, Kevin Black, Tony Z Zhao, Quan Vuong, Chongyi Zheng, Philippe Hansen-Estruch, Andre Wang He, Vivek Myers, Moo Jin Kim, Max Du, et al. BridgeData v2: A dataset for robot learning at scale. In *Conference on Robot Learning*, pages 1723–1736. PMLR, 2023.
- [53] Jason Wei, Maarten Bosma, Vincent Y Zhao, Kelvin Guu, Adams Wei Yu, Brian Lester, Nan Du, Andrew M Dai, and Quoc V Le. Finetuned language models are zero-shot learners. *arXiv preprint arXiv:2109.01652*, 2021.
- [54] Jason Wei, Yi Tay, Rishi Bommasani, Colin Raffel, Barret Zoph, Sebastian Borgeaud, Dani Yogatama, Maarten Bosma, Denny Zhou, Donald Metzler, et al. Emergent abilities of large language models. *arXiv preprint arXiv:2206.07682*, 2022.
- [55] Junjie Wen, Yichen Zhu, Jinming Li, Minjie Zhu, Kun Wu, Zhiyuan Xu, Ning Liu, Ran Cheng, Chaomin Shen, Yaxin Peng, Feifei Feng, and Jian Tang. Tinyvla: Towards fast, data-efficient vision-language-action models for robotic manipulation. *arXiv preprint arXiv:2409.12514*, 2024.
- [56] Kuan-Ting Yu, Maria Bauza, Nima Fazeli, and Alberto

Rodriguez. More than a million ways to be pushed. a high-fidelity experimental dataset of planar pushing. In *2016 IEEE/RSJ international conference on intelligent robots and systems (IROS)*, pages 30–37. IEEE, 2016.

- [57] Tony Z Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware. *arXiv preprint arXiv:2304.13705*, 2023.
- [58] Tony Z Zhao, Jonathan Tompson, Danny Driess, Pete Florence, Kamyar Ghasemipour, Chelsea Finn, and Ayzaan Wahid. Aloha unleashed: A simple recipe for robot dexterity. *arXiv preprint arXiv:2410.13126*, 2024.
- [59] Chunting Zhou, Lili Yu, Arun Babu, Kushal Tirumala, Michihiro Yasunaga, Leonid Shamis, Jacob Kahn, Xuezhe Ma, Luke Zettlemoyer, and Omer Levy. Transfusion: Predict the next token and diffuse images with one multi-modal model. *arXiv preprint arXiv:2408.11039*, 2024.
- [60] Minjie Zhu, Yichen Zhu, Jinming Li, Junjie Wen, Zhiyuan Xu, Ning Liu, Ran Cheng, Chaomin Shen, Yaxin Peng, Feifei Feng, et al. Scaling diffusion policy in transformer to 1 billion parameters for robotic manipulation. *arXiv preprint arXiv:2409.14411*, 2024.

附录

A. 贡献

作者在以下领域做出了贡献（按字母顺序排列）：

数据与运算： Noah Brown、Michael Equi、Chelsea Finn、Niccolo Fusai、Lachy Groom、Liyiming Ke、Suraj Nair、Lucy Shi 和 Anna Walling。

评估实验： Kevin Black、Michael Equi、Chelsea Finn、Brian Ichter、Liyiming Ke、Adrian Li-Bell、Suraj Nair、Karl Pertsch 和 Lucy Shi。

模型设计： Kevin Black、Brian Ichter、Sergey Levine、Karl Pertsch、Lucy Shi 和 Quan Vuong。

后训练： Michael Equi、Chelsea Finn、Liyiming Ke、Adrian Li-Bell、Suraj Nair 和 Lucy Shi。

预训练： Kevin Black、Danny Driess、Brian Ichter、Sergey Levine、Karl Pertsch、Lucy Shi 和 Quan Vuong。

机器人硬件： Noah Brown、Adnan Esmail、Chelsea Finn、Tim Jones 和 Mohith Mothukuri。

机器人软件： Karol Hausman、Szymon Jakubczak、Sergey Levine、James Tanner 和 Haohuan Wang。

训练基础设施： Kevin Black、Michael Equi、Sergey Levine、Adrian Li-Bell、Suraj Nair、Quan Vuong、Haohuan Wang 和 Ury Zhilinsky。

写作与插图： Kevin Black、Chelsea Finn、Lachy Groom、Karol Hausman、Brian Ichter、Sergey Levine 和 Quan Vuong。

B. 模型架构细节

本节中，我们提供模型架构的完整描述。我们遵循 PaliGemma 视觉语言模型 (VLM) [5] 的设计，但有以下不同之处：（1）为机器人特定令牌（包括状态）添加额外的输入和输出投影

vector $\mathbf{q}_t$ and action vectors $\mathbf{A}_t = [\mathbf{a}_t, \dots, \mathbf{a}_{t+H-1}]$, (2) 额外的多层感知机 (MLP) 用于融合流匹配时间步信息 τ ，以及（3）为动作专家设置的第二组较小权重。

额外的输入和输出。 标准 PaliGemma 架构接收一系列图像 $[\mathbf{I}_t^1, \dots, \mathbf{I}_t^n]$ ，后跟语言提示 ℓ_t 。我们为机器人的本体感受状态添加一个输入 $\mathbf{q}_t$ ，该状态通过线性投影映射到变换器嵌入维度。最后一组输入令牌对应于噪声动作块 $\mathbf{A}_t^\tau = [\mathbf{a}_t^\tau, \dots, \mathbf{a}_{t+H-1}^\tau]$ ，令牌数量等于动作时域（我们的任务中为 $H = 50$ ）。我们仅使用与 H 个噪声动作对应的变换器输出，这些输出通过线性投影解码为 $\mathbf{v}_\theta(\mathbf{A}^\tau)$ 。

$\mathbf{o}_t$) 使用线性投影。

融合流匹配时间步。 噪声动作块 $\mathbf{A}_t^\tau$ 通过一个同时融合流匹配时间步 τ 的多层感知机映射到变换器的嵌入维度。对于每个噪声动作 $\mathbf{a}_t^\tau$ ，馈入变换器的对应嵌入表达式为 $W_3 \cdot \text{swish}(W_2 \cdot \text{concat}(W_1 \cdot \mathbf{a}_t^\tau, \phi(\tau)))$ ，其中 $\phi: \mathbb{R} \rightarrow \mathbb{R}^w$ 是正弦位置编码函数 [51]，

$W_1 \in \mathbb{R}^{w \times d}$, $W_2 \in \mathbb{R}^{w \times 2w}$, $W_3 \in \mathbb{R}^{w \times w}$, d 是动作维度， w 是动作专家的嵌入维度（或宽度）。

注意力掩码。 采用 π 分块因果注意力掩码，共包含 3 个块：

$[\mathbf{I}_t^1, \dots, \mathbf{I}_t^n, \ell_t], [\mathbf{q}_t]$ 和 $[\mathbf{a}_t^\tau, \dots, \mathbf{a}_{t+H-1}^\tau]$ 。每个块内部为完全双向注意力，而各块中的标记无法关注未来块中的标记。第一个块包含来自 PaliGemma 视觉语言模型预训练的输入模态，这些模态被阻止关注未来块（包含新输入），以最小化所述预训练带来的分布偏移。机器人状态 $\mathbf{q}_t$ 单独成块，因为它不随每个流匹配积分步骤而变化；阻止其关注最后一个块可在采样期间缓存其对应的键和值。最后一个块对应噪声动作 $\mathbf{A}_t^\tau$ ，可关注完整输入序列。

动作专家。 实现 π_0 为具有两组权重（也称为专家 [45]）的单一变换器，每个标记被路由至其中一个专家；权重仅通过变换器的自注意力层交互。图像和语言提示 $[\mathbf{I}_t^1, \dots, \mathbf{I}_t^n, \ell_t]$ 被路由至较大的视觉语言模型骨干，该骨干由 PaliGemma 初始化。视觉语言模型预训练期间未见过的输入 $[\mathbf{q}_t, \mathbf{A}_t^\tau]$ 被路由至动作专家。PaliGemma 基于 Gemma 2B[49] 语言模型，采用多查询注意力 [44] 及配置 { 宽度 = 2048, 深度 = 18, mlp_dim = 16,384, 头数 = 18, 键值头数 = 1, kv_dim = 256 }。由于专家仅在自注意力层中交互，宽度和多层感知机维度不必在专家间匹配。为加速推理（需要动作专家的多次前向传播），将动作专家缩减为 { 宽度 = 1024, 多层感知机维度 = 4096 }，参数量为 $\sim 300\text{M}$ 。

采样流匹配时间步。 原始流匹配论文 [28, 32] 对流匹配时间步进行采样




图 14: 流匹配时间步采样分布。我们从偏移贝塔分布中采样 τ ，该分布强调较低时间步（对应噪声更大的动作），且完全不采样高于截断值 s 的时间步。实验中采用 $s = 0.999$ 。

从均匀分布中采样: $\tau \sim \mathcal{U}(0, 1)$ 。Esser 等人 [14] 则提出从对数正态分布中采样，该分布强调中间时间步；作者认为在高时间步（低噪声水平）时，模型只需学习恒等函数，而在低时间步（高噪声水平）时，模型只需学习数据分布的均值。然而，我们假设动作预测任务与高分辨率图像综合存在细微差别——虽然根据文本标签预测均值图像可能相对容易，但根据机器人观测预测均值动作（即学习 $\mathbb{E}[\mathbf{A}_t | \mathbf{o}_t]$ ）则困难得多；这是因为观测 $\mathbf{o}_t$ 信息量很大，它对可能动作分布的约束应远强于文本标签对可能图像分布的约束。因此，我们设计了一种强调低时间步（高噪声水平）的时间步采样分布；此外，高于给定阈值 s 的时间步完全不采样，因为只要积分步长 δ 大于 $1-s$ ，这些时间步就不需要。该分布由 $p(\tau) = \text{Beta}(\frac{s-\tau}{s}; 1.5, 1)$ 给出，并在图 14 中可视化。我们在实验中使用 $s = 0.999$ ，这允许 $\delta > \frac{1}{1000}$ ，或最多 1,000 个积分步。

C. 非 VLM 基线架构

我们的基线架构 π_0 -small 并非基于 VLM 骨干网络。因此，我们用它来评估 VLM 预训练的优势。我们将其设计得足够有表达力，以适应我们的大型数据集，同时从从头训练时仍能提供良好的性能。该模型约有 4.7 亿个参数，与我们的主模型在以下方面有所不同：（1）我们使用 DistilBERT [42] 对语言命令 ℓ_t 的语言标记进行编码，因为该模型不使用语言模型骨干网络；（2）动作专家对观测编码器的输出进行交叉注意力，类似于传统的编码器-解码器变换器 [51]，而我们的主模型更仅解码器的专家混合 [45]；（3）图像使用较小的预训练 ViT 进行编码

编码器（具体而言，采用 Steiner 等人提出的 R26-S-32 残差网络-视觉变换器混合架构 [47]）；（4）视觉变换器图像编码器之间不共享权重；（5）在视觉变换器图像编码器之后用于编码观测的变换器主干网络未在互联网数据上进行预训练；（6）动作专家采用去噪扩散变换器架构 [36] 而非 Gemma 架构，因此通过自适应层归一化零初始化层引入流匹配时间步 τ 。除此之外，模型大体相似：均使用预训练的视觉变换器图像编码器，观测编码器与动作专家使用独立权重，接收相同的观测格式，并执行 10 步流匹配以预测动作块。

D. 推理

回顾我们的模型接收观测 $\mathbf{o}_t = [\mathbf{I}_t^1, \dots, \mathbf{I}_t^n, \ell_t, \mathbf{q}_t]$ 和带噪声动作 $\mathbf{A}_t^\tau$ ，输出需要积分以获得下一步流匹配的向量场 $\mathbf{v}_t^\tau$ 。每次预测新的动作块 $\mathbf{A}_t$ 时，必须编码每张图像 $\mathbf{I}_t^1, \dots, \mathbf{I}_t^n$ ，对与 $\mathbf{o}_t$ 对应的令牌执行前向传播，然后运行 10 步流匹配，其中每一步需要对与 $\mathbf{A}_t^\tau$ 对应的令牌执行前向传播（与 $\mathbf{o}_t$ 对应的键和值被缓存）。表 I 总结了使用 3 个相机图像时该操作的计算时间。操作在 NVIDIA GeForce RTX 4090 消费级 GPU 上计时。对于移动机器人，推理通过 Wi-Fi 连接在机外完成，增加了少量网络延迟。进一步的优化、量化和其他改进可能进一步减少推理时间。由于模型一次生成整个 H 步动作块，我们可以在需要再次推理之前执行最多 H 个动作。然而，我们可以更频繁地运行推理，并使用各种聚合策略组合来自不同推理调用的动作。我们早期尝试了时间集成 [57]，发现它损害了策略性能，因此选择不聚合动作，而是开环执行动作块。对于 20Hz 的 UR5e 和 Franka 机器人，我们每 0.8 秒运行一次推理（执行 16 个动作后），对于所有其他以 50Hz 运行的机器人，我们每 0.5 秒运行一次推理（执行 25 个动作后）。

model part	inference time
image encoders	14 ms
observation forward pass	32 ms
x10 action forward pass (flow)	27 ms
network latency (if off-board)	13 ms
total on-board inference	73 ms
total off-board inference	86 ms

表 I: 模型在 NVIDIA GeForce RTX 4090 GPU 上的推理时间。

E. 评估细节

对于每项任务，我们设计一个评分标准来衡量任务进展，并将其用于定量结果。

我们在下文为每项任务描述该评分标准：A. 评估基础模型

衬衫折叠：叠衬衫被记录为成功或失败。每次叠衬衫评估开始时，我们将衬衫平铺在桌面上。成功定义为折入袖子并沿衬衫长度进行一次对折。我们的评估包括 4 件小号 T 恤和 1 件中号 T 恤。每件物品运行 2 次评估，最多 15000 步或约 5 分钟。

轻松乘车：该任务满分为 7 分，桌上有 7 个不同物体，每正确分类一个物体得 1 分。

努力拼搏：该任务满分为 12 分，桌上有 12 个不同物体，每正确分类一个物体得 1 分。此版本任务包含特别具有挑战性的设置，例如放在垃圾上的一根筷子。

食品装袋：该任务满分为 7 分。对于 7 件杂货物品中的每一件，将其放入袋中得 1 分。

从烤面包机中取出吐司：该任务满分为 4 分。对于每片吐司，从烤面包机中取得 1 分，将其放在盘子上再得 1 分。

B. 语言指令遵循。该策略根据成功重新定位每个物体以及是否遵循指令来评分。

清理餐桌：机器人必须遵循指令，拾取正确的物体，并将每个物体放入正确的容器中。机器人每回合共接收 12 个物体和约 30 条指令。

布置餐桌：机器人整理所有餐具、器皿和餐巾，并根据语言说明进行调整。机器人每回合共接收 7 个物体和约 20 条指令。

食品装袋：机器人拾取正确的物品（从咖啡豆袋、大麦袋、棉花糖袋、猫粮、意大利面、海苔袋、杏仁袋中选择），并将它们装入纸袋中。机器人每回合共接收 7 个物体和约 14 条指令。C. 学习新的灵巧任务

堆叠碗：此任务满分为 3 分。两个碗分别堆叠在大碗中各得 1 分，最终成品的整洁度得 1 分。

毛巾折叠：此任务满分为 3 分。毛巾第一次对折得 1 分，第二次对折得 1 分，最终成品的整洁度得 1 分。

微波炉中的特百惠保鲜盒：本任务满分为 4 分。打开微波炉得 1 分，拿起特百惠保鲜盒得 1 分，将特百惠保鲜盒放入微波炉得 1 分，关闭微波炉得 1 分。

纸巾更换：本任务满分为 4 分。抓住旧卷纸得 1 分，取下旧卷纸再得 1 分。然后，抓住新纸巾卷得 1 分，最后将其放置在分配器上得 1 分。

抽屉中的物品：本任务满分为 5 分。打开抽屉得 1 分，每拾取 3 件物品中的一件得 1 分，

放入抽屉得一分，关上抽屉得一分。D. 掌握复杂的多阶段任务

叠衣：本任务满分为 4 分。评估包含五件物品：三件衬衫（尺码分别为中号、大号和特大号）以及两条短裤（尺码分别为 28 和 36）。每件物品进行两次试验，待评估的物品初始时随机揉成一团放在洗衣篮中（而先前已评估的物品则初始时叠放整齐）。从篮中取出物品并放到桌上得 1 分。将衬衫或短裤展平再得 1 分。将衬衫或短裤折叠起来再得 1 分。最后，若该物品是首件被评估的物品，则将其放在桌子角落；否则将其叠放到已有的折叠衣物堆上，可得最后 1 分。每次评估最多运行 15000 步或约 5 分钟。

移动叠衣：本次评估遵循与叠衣相同的规程。三件衬衫的尺码分别为中号、中号和特大号，短裤的尺码为 32 码和 31 码（腰围）。

餐桌清理：该任务满分为 12 分，桌上有 12 个不同物体，每正确分类一个物体得 1 分。此版本任务包含特别具有挑战性的设置，例如放在垃圾上的一根筷子。

纸箱组装：本任务满分为 5 分。成功拿起盒子开始任务得 1 分。将盒子对折，使盖子能够合上得 1 分。合上右侧盖子得 1 分。合上左侧盖子得 1 分。最后将成品整齐居中得 1 分。

装鸡蛋：本任务满分为 7 分。每个鸡蛋放入纸盒中正确的槽位得 1 分，合上盖子得 1 分。

打包食物：本任务满分为 5 分。拿起食物盘得 1 分，将 3 种食物放入外带盒中各得 1 分，合上外带盒得 1 分。

烘干机卸载：本任务要求机器人携带洗衣篮接近烘干机，并将衣物取出放入篮中。本评估满分为 5 分，其中正确接近烘干机得 1 分，将洗衣篮放在凳子上得 1 分，打开烘干机得 1 分，将所有衣物放入篮中得 1 分，关闭烘干机得 1 分。评估使用 3 件衬衫和 2 条短裤，初始时随机放置在烘干机内。