

$\pi_{0.5}$ ：一种具备开放世界泛化能力的视觉-语言-动作模型

Physical Intelligence

Kevin Black, Noah Brown, James Darpinian, Karan Dhabalia, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Manuel Y. Galliker, Dibya Ghosh, Lachy Groom, Karol Hausman, Brian Ichter, Szymon Jakubczak, Tim Jones, Liyiming Ke, Devin LeBlanc, Sergey Levine, Adrian Li-Bell, Mohith Mothukuri, Suraj Nair, Karl Pertsch, Allen Z. Ren, Lucy Xiaoyang Shi, Laura Smith, Jost Tobias Springenberg, Kyle Stachowicz, James Tanner, Quan Vuong, Homer Walke, Anna Walling, Haohuan Wang, Lili Yu, Ury Zhilinsky

<https://pi.website/blog/pi05>



图 1: $\pi_{0.5}$ 模型从多种异构数据源中迁移知识, 包括其他机器人、高层子任务预测、口头指令以及来自网络的数据, 从而实现在不同环境和物体间的广泛泛化。 $\pi_{0.5}$ 能够控制移动机械臂, 在训练数据中未出现的新住宅中清洁厨房和卧室, 执行持续 10 至 15 分钟的复杂多阶段行为。

摘要——为了使机器人真正有用, 它们必须在实验室之外的真实世界中执行具有实际意义的任务。尽管视觉-语言-动作 (VLA) 模型在端到端机器人控制方面已展现出令人瞩目的成果, 但这类模型在野外环境中的泛化能力究竟能达到何种程度, 仍是一个悬而未决的问题。我们描述了 $\pi_{0.5}$, 这是一个基于 π_0 的新模型, 通过异构任务的协同训练来实现广泛的泛化。 $\pi_{0.5}$ 利用来自多个机器人的数据、高层语义预测、网络数据以及其他来源, 实现了可广泛泛化的真实世界机器人操作。我们的系统结合了协同训练和混合多模态示例, 这些示例融合了图像观测、语言指令、物体检测、语义子任务预测以及底层动作。我们的实验表明, 这种知识迁移对于有效泛化至关重要, 并且我们首次证明了端到端学习驱动的机器人系统能够执行长时间、

灵巧的操作技能, 例如在全新的住宅中清洁厨房或卧室。

I. 引言

让你的双眼充满惊奇……去看看这个世界。它比任何工厂制造或购买的梦境都更加奇妙。

雷·布拉德伯里, 《华氏 451 度》

开放世界泛化是物理智能领域最大的开放问题之一: 诸如机械臂、人形机器人和自动驾驶汽车等具身系统, 只有在能够走出实验室并应对现实世界中多样情境和意外事件时, 才真正变得有用。基于学习的系统提供了一条通往



图 2: $\pi_{0.5}$ 正在清洁一个新厨房。该机器人被指派去清洁一个未包含在训练数据中的家庭厨房。模型接收到一般性任务（关闭橱柜、将物品放入抽屉、擦拭溢出物以及将餐具放入水槽），它通过预测需要完成的子任务（例如，拿起盘子）并发出低层动作来执行这些任务。

实现广泛泛化，尤其是近期进展使得从自然语言处理 [79, 21, 10, 78] 到计算机视觉 [34, 66, 35, 43] 等领域能够构建可扩展的学习系统。然而，机器人在现实世界中可能遇到的情况多种多样，仅靠规模是不够的：我们需要设计训练方案，提供足够广度的知识，使机器人能够在多个抽象层次上进行泛化。例如，如果要求移动机器人清理一个从未见过的厨房，某些行为若在数据中具有足够丰富的场景和物体覆盖（如拿起刀或盘子），则容易泛化；另一些行为可能需要调整或修改现有技能，以新的方式或新的顺序使用；还有一些行为可能需要基于先验知识理解场景语义（例如，打开哪个抽屉，或台面上哪个物体最可能是晾碗架）。如何为机器人学习系统构建训练方案，以实现这种灵活泛化？人类可以借助一生的经验，为这些挑战综合出合适的解决方案。并非所有经验都是亲身经历的，也并非都来自机械练习——例如，我们可能利用他人告知或从书中读到的事实，结合在不同情境下执行其他任务所获得的洞见，再加上目标领域的直接经验。类似地，我们可以假设，可泛化的机器人学习系统必须能够从多种信息源迁移经验和知识。其中一些来源是与当前任务直接相关的第一手经验，一些需要从其他机器人本体、环境或领域迁移，还有一些则代表完全不同的数据类型，如语言指令、基于网络数据的感知任务，或高层语义命令的预测。这些不同数据源的异质性构成了主要障碍，但幸运的是，近期视觉-语言-动作（VLA）模型的进展为我们提供了实现这一目标的工具包：通过将不同模态纳入同一序列建模框架，VLA 可以适配为在机器人数据、语言数据、计算机视觉任务及其组合上进行训练。本文利用这一观察，设计了一种 VLA 协同训练框架，能够利用异构多样的知识源实现广泛泛化。

在 π_0 视觉语言动作模型的基础上，本文提出纳入多种不同数据源，以构建 $\pi_{0.5}$ 模型（“pi oh five”），该模型能够控制移动机械臂在训练期间从未见过的家庭环境中执行各种家务任务。

$\pi_{0.5}$ 从众多来源汲取经验：除了在多种真实家庭中直接使用移动机械臂采集的中等规模数据集（约 400 小时）外， $\pi_{0.5}$ 还利用了来自其他非移动机器人的数据、在实验室条件下采集的相关任务数据、需要基于机器人观测预测“高层”语义任务的训练样本、人类监督者向机器人提供的口头语言指令，以及由网络数据创建的多种多模态示例，如图像描述生成、问答和目标定位（见图 1）。提供给 $\pi_{0.5}$ 的绝大多数训练样本（在第一训练阶段占 97.6%）并非来自执行家务任务的移动机械臂，而是来自这些其他来源，例如其他机器人或网络数据。尽管如此，

$\pi_{0.5}$ 仍能够在训练期间完全未见过的全新家庭中控制移动机械臂，执行诸如挂毛巾或铺床等精细任务，并能执行长达 10 至 15 分钟的长时间操作技能，仅凭一个高层提示即可清洁整个厨房或卧室。

$\pi_{0.5}$ 的设计遵循简单的分层架构：本文首先在异构训练任务混合体上预训练模型，然后针对移动操作进行微调，同时使用低级动作示例和高级“语义”动作，后者对应于预测子任务标签，例如“拿起砧板”或“重新摆放枕头”。在运行时，推理的每一步中，模型首先预测语义子任务，根据任务结构和场景语义推断下一步应执行的行为，然后基于该子任务预测低级机器人动作块。这种简单架构既提供了推理长时程多阶段任务的能力，也提供了为两个层级利用不同知识来源的能力：低级动作推理过程易于受益于其他机器人收集的动作数据，包括其他环境中更简单的静态机器人，而高级推理过程则受益于来自网络的语义示例、高级标注预测，甚至人类“监督者”可以提供给机器人的口头指令，这些监督者逐步引导机器人完成复杂任务，指导它（很像他们指导一个人的方式）执行适当的子任务以完成诸如打扫房间之类的复杂任务。

本文在图 1 中展示了这一设计。本文的核心贡献是一个用于训练高度泛化视觉-语言-动作模型 $\pi_{0.5}$ 的系统，以及一个概念验证，表明当该模型在适当多样的数据上训练时，泛化能力可以从中涌现。本文对 $\pi_{0.5}$ 的泛化能力以及不同协同训练成分的相关性进行了详细的实证评估。据本文所知，本文的工作首次展示了一个端到端学习驱动的机器人系统，能够在全新的家庭中执行长时程和灵巧的操作技能，例如打扫厨房或卧室。本文的实验和比较进一步表明，这是通过从其他机器人、高级语义预测、人类监督者的口头语言指令、网络数据和其他来源迁移知识实现的。

II. 相关工作

通用机器人操作策略。近期研究表明，将机器人操作策略的训练数据分布从狭窄的单任务数据集扩展到涵盖众多场景与任务的数据集 [17, 25, 80, 63, 41, 6, 30, 67, 1]，不仅使所得策略能够开箱即用解决更广泛的任务，还提升了其泛化至新场景与新任务的能力 [9, 63, 62, 22]。训练此类通用策略需要新的建模方法，以应对通常涵盖数百种不同任务与场景的数据集的规模与多样性。视觉语言动作模型 (Vision-Language-Action Models, VLAs) [23, 92, 42, 8, 83, 90, 55, 45, 3, 75, 64, 76, 84, 7, 37] 提供了一种有吸引力的解决方案：通过微调预训练的视觉语言模型用于机器人控制，VLAs 能够利用从网络规模预训练中获得的语言知识，并将其应用于机器人问题。当与高表达力的动作解码机制（如流匹配 [8]、扩散 [55, 84, 52] 或先进的动作分词方案 [64]）相结合时，VLAs 能够在现实世界中执行各种复杂的操作任务。然而，尽管具备令人印象深刻的语言遵循能力，VLAs 通常仍在与其训练数据高度匹配的环境中进行评估。虽然一些研究表明，通过仅在更广泛的环境中收集机器人数据，即可使诸如拾取物体或打开抽屉等简单技能实现泛化 [14, 67, 28, 49, 64]，但将相同方法应用于更复杂的长程任务（如清理厨房）则颇具挑战，因为通过暴力扩展机器人数据收集来实现对可能场景的广泛覆盖是不可行的。在我们的实验中，我们在全新的场景（如训练中未见的新厨房和卧室）中评估 $\pi_{0.5}$ ，表明我们的 VLA 不仅能够利用目标移动操作平台上的直接第一手经验，还能利用来自其他数据源的信息，从而泛化至全新的场景。这些

数据源包括来自其他（非移动）机器人的数据、高层语义子任务预测以及来自网络的数据。

非机器人数据协同训练。许多先前的工作试图利用多样化的非机器人数据来提升机器人策略的泛化能力。先前的方法探索了从计算机视觉数据集初始化视觉编码器 [85, 58, 57, 18]，或利用现成的任务规划器 [38, 48, 73, 81]。视觉语言动作（VLA）策略通常从预训练的视觉语言模型初始化，该模型已接触过大量互联网视觉和语言数据 [23, 92, 42]。值得注意的是，VLA 架构灵活，允许在多模态视觉、语言和动作标记的输入与输出序列之间进行映射。因此，VLA 拓宽了可能的迁移方法设计空间，超越了简单的权重初始化，支持在单一统一架构上不仅对机器人动作模仿数据进行联合训练，还可以对任何交错包含上述一种或多种模态的数据集进行联合训练。先前的工作已经证明，使用用于视觉语言模型（VLM）训练的数据混合对 VLA 进行联合训练 [23, 92, 86] 可以提升其泛化能力，例如在与新物体交互或面对未见过的场景背景时。在这项工作中，我们超越了 VLM 数据联合训练，设计了一个系统，用于将 VLA 与更广泛的机器人相关监督源进行联合训练，包括来自其他机器人的数据、高层语义子任务预测以及口头语言指令。虽然多任务训练和联合训练并非新思想，但我们表明，我们系统中数据源的特定组合使移动机器人能够在全新环境中执行复杂且长时的行为。我们相信，这种泛化水平，特别是考虑到任务的复杂性，显著超越了先前工作中展示的结果。基于语言的机器人推理与规划。许多先前的工作表明，用高层推理增强端到端策略可以显著提升长时程任务的性能 [2, 36, 44, 74, 71, 4, 16, 11, 53, 88, 51, 59, 13, 70, 91, 65, 72, 47, 76, 89]，特别是当高层子任务推理能够受益于大型预训练大语言模型（LLM）和视觉语言模型（VLM）时。我们的方法也采用两阶段推理过程，首先推断高层语义子任务（例如，“拿起盘子”），然后基于该子任务预测动作。许多先前的方法为此使用了两个独立的模型，由 VLM 预测语义步骤，由单独的低层策略执行这些步骤 [2, 71, 13, 24, 70, 72, 47]。我们的方法在高层和低层推理中使用完全相同的模型，其方式更类似于思维链 [82] 或测试时计算 [39] 方法，但与具身思维链方法 [88, 46, 61] 不同，高层推理过程的运行频率仍低于低层动作推理。具有开放世界泛化能力的机器人学习系统。虽然大多数机器人学习系统在与训练数据高度匹配的环境中进行评估，但许多先前的工作探索了更广泛的开放世界泛化。当机器人的任务被限制在一组较窄的基本

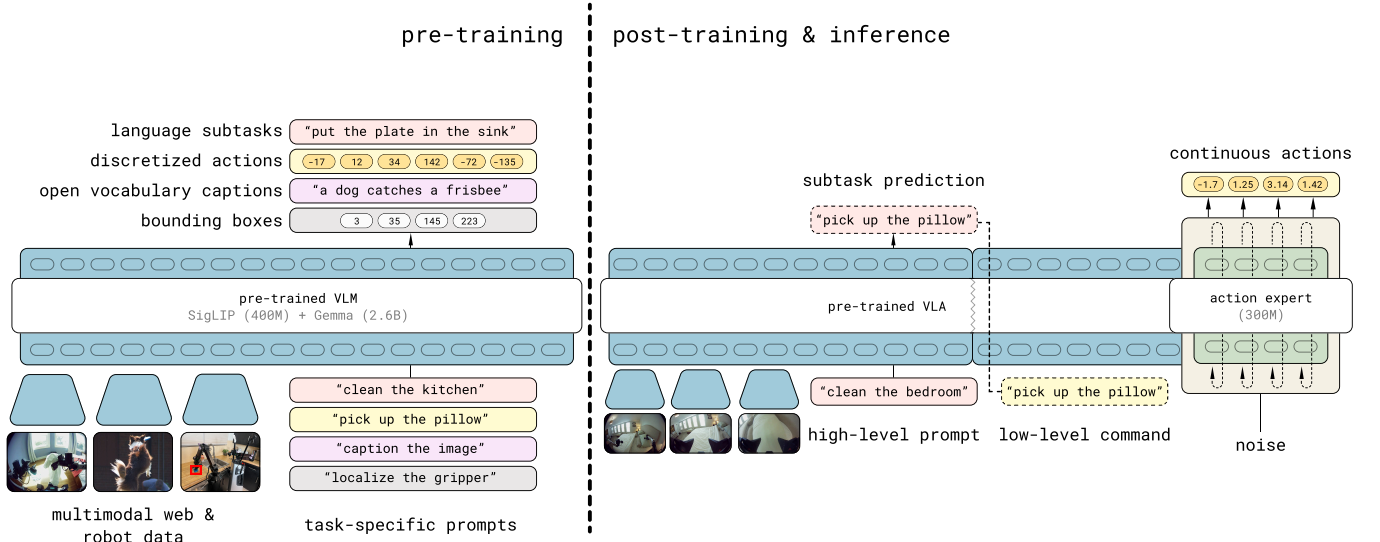


图 3: 模型概览。 $\pi_{0.5}$ 分两个阶段训练。首先，预训练阶段整合所有不同数据源，生成具有离散标记的初始视觉-语言-动作模型。该阶段使用来自多种机器人平台的数据、高层语义动作预测以及网络数据。机器人数据采用快速动作标记器将动作表示为离散标记 [64]。其次，后训练阶段针对移动操作的低层和高层推理对模型进行专门化，利用最相关的任务数据，包括人类监督者的口头指令。该阶段使用流匹配表示动作分布，实现高效的实时推理，并能够表示细粒度的连续动作序列。在推理时，模型首先推断高层子任务，然后基于该子任务预测动作。

对于诸如拾取物体等基本操作，允许任务特定假设的方法（例如抓取预测，或结合基于模型的规划与控制）已被证明能够广泛泛化，甚至适用于全新的家庭环境 [40, 20, 60, 56, 29]。然而，此类方法难以泛化到通用机器人可能需要执行的完整任务范围。近期，跨多个领域收集的大规模数据集 [41, 68, 63, 67, 14, 49] 已被证明能够使简单但端到端学习的任务泛化到新环境 [33, 31, 67, 69, 26, 49, 28, 64]。然而，这些演示中的任务仍然相对简单，通常时长不足一分钟，且成功率往往较低。本文表明 $\pi_{0.5}$ 能够执行长时间、多阶段任务，例如将所有餐具放入水槽，或从新卧室地板上捡起所有衣物，同时泛化到全新的家庭环境。

三、预备知识

视觉语言动作模型（Vision-Language-Action Models, VLAs）通常通过模仿学习在多样化的机器人演示数据集 $\mathcal{D}$ 上进行训练，通过最大化在给定观测 $\mathbf{o}_t$ 和自然语言任务指令 ℓ : 条件下动作 $\mathbf{a}_t$ （或更一般地，动作块 $\mathbf{a}_{t:t+H}$ ）的对数似然 $\max_{\theta} \mathbb{E}_{(\mathbf{a}_{t:t+H}, \mathbf{o}_t, \ell) \sim \mathcal{D}} \log (\pi_{\theta}(\mathbf{a}_{t:t+H} | \mathbf{o}_t, \ell))$ 。观测通常包含一个或多个图像 $\mathbf{I}_t^1, \dots, \mathbf{I}_t^n$ 以及本体感觉状态 $\mathbf{q}_t$ ，后者捕捉机器人关节的位置。VLA 架构遵循现代语言和视觉语言模型的设计，具有模态特定的分词器，将输入和输出映射为离散（“硬”）或连续（“软”）的标记表示，以及一个大型的自回归变换器骨干网络，该网络被训练用于从

输入到输出令牌。这些模型的权重从预训练的视觉语言模型初始化。通过将策略输入和输出编码为分词表示，上述模仿学习问题可以转化为在观察、指令和动作令牌序列上的简单下一令牌预测问题，我们可以利用现代机器学习可扩展的工具来优化它。在实践中，图像和文本输入的分词器选择遵循现代视觉语言模型。对于动作，先前的工作开发了有效的、基于压缩的分词方法 [64]，我们在预训练期间使用这些方法。最近的一些视觉语言动作模型也提出通过扩散 [55, 84, 52] 或流匹配 [8] 来表示动作分布，为连续值动作块提供了更具表现力的表示。在我们模型的后训练阶段，我们将基于 π_0 模型 [8] 的设计，该模型通过流匹配表示动作分布。在这种设计中，对应于动作的令牌接收来自流匹配前一步的部分去噪动作作为输入，并输出流匹配向量场。这些令牌还使用一组不同的模型权重，我们称之为“动作专家”，类似于专家混合架构。这个动作专家可以专门用于基于流匹配的动作生成，并且可以显著小于大语言模型骨干的其余部分。

IV. THE $\pi_{0.5}$ M 模型与训练方案 我们在图 3 中概述了 $\pi_{0.5}$ 模型和训练方案。模型权重从在网页数据上训练的标准视觉语言模型（VLM）初始化，随后进行训练

分为两个阶段：预训练阶段旨在使模型适应多样化的机器人任务，后训练阶段旨在使其专精于移动操作，并为其配备高效的测试时推理机制。在预训练期间，所有任务（包括带有机器人动作的任务）均以离散标记表示，从而实现简单、可扩展且高效的训练 [64]。在后训练期间，我们调整模型，使其也具备动作专家，如同 π_0 ，以便以更细的粒度表示动作，并为实时控制实现更高效的计算推理。在推理时，模型首先为机器人产生一个高层子任务，然后以该子任务为条件，通过动作专家预测低层动作。下文先描述模型架构，随后描述各阶段及其对应的训练任务。

A. The $\pi_{0.5}$ 架构 $\pi_{0.5}$ 架构能够灵活地表示动作块分布和标记化文本输出，后者既用于协同训练任务（例如问答），也用于在分层推理期间输出高层子任务预测。模型捕获的分布可写为 $\pi_\theta(\mathbf{a}_{t:t+H}, \hat{\ell} | \mathbf{o}_t, \ell)$ ，其中 $\mathbf{o}_t = [\mathbf{I}_t^1, \dots, \mathbf{I}_t^p, \mathbf{q}_t]$ 由所有摄像头的图像和机器人的配置（关节角度、夹爪姿态、躯干升降姿态和基座速度）组成， ℓ 是总体任务提示（例如“收拾餐具”）， $\hat{\ell}$ 表示模型的（标记化）文本输出，它可以是预测的高层子任务（例如“拿起盘子”）或网络数据中视觉语言提示的答案， $\mathbf{a}_{t:t+H}$ 是预测的动作块。我们将该分布分解为

$$\pi_\theta(\mathbf{a}_{t:t+H}, \hat{\ell} | \mathbf{o}_t, \ell) = \pi_\theta(\mathbf{a}_{t:t+H} | \mathbf{o}_t, \hat{\ell}) \pi_\theta(\hat{\ell} | \mathbf{o}_t, \ell),$$

其中动作分布不依赖于 ℓ ，仅依赖于 $\hat{\ell}$ 。因此，高层推理捕捉 $\pi_\theta(\hat{\ell} | \mathbf{o}_t, \ell)$ ，低层推理捕捉 $\pi_\theta(\mathbf{a}_{t:t+H} | \mathbf{o}_t, \hat{\ell})$ ，两种分布由同一模型表示。该模型对应于一个变换器（Transformer），接收 N 多模态输入令牌 $x_{1:N}$ （此处“令牌”一词使用较宽松，既指离散化输入也指连续输入），并产生多模态输出序列 $y_{1:N}$ ，可写为 $y_{1:N} = f(x_{1:N}, A(x_{1:N}), \rho(x_{1:N}))$ 。每个 x_i 可以是文本令牌（ $x_i^w \in \mathbb{N}$ ）、图像块（ $x_i^I \in \mathbb{R}^{p \times p \times 3}$ ）或流匹配中机器人动作的中间去噪值（ $x_i^a \in \mathbb{R}^d$ ）。观测 $\mathbf{o}_t$ 和 ℓ 构成 $x_{1:N}$ 的前缀部分。根据 $\rho(x_i)$ 指示的令牌类型，每个令牌不仅可由不同的编码器处理，还可由变换器内不同的专家权重处理。例如，图像块通过视觉编码器输入，文本令牌用嵌入矩阵进行嵌入。遵循 π_0 [8]，我们将动作令牌 x_i^a 线性投影到变换器嵌入空间，并在变换器中使用独立的专家权重处理动作令牌。注意力矩阵 $A(x_{1:N}) \in [0, 1]^{N \times N}$ 指示一个令牌是否可以关注另一个令牌。与标准因果注意力相比

在大语言模型（LLM）中，图像块、文本提示和连续动作令牌使用双向注意力。由于我们希望模型同时输出文本（用于回答场景相关问题或输出下一步要完成的任务）和动作（用于在环境中行动）， f 的输出分别拆分为文本令牌 logits 和动作输出令牌（ $y_{1:M}^t, y_{1:H}^a$ ）。前 M 个对应文本令牌 logits，可用于采样 $\hat{\ell}$ ，后 H 个令牌由独立的动作专家生成，如 π_0 所述，并通过线性映射投影到连续输出，用于获得 $\mathbf{a}_{t:t+H}$ （见下一节）。注意 $M+H \leq N$ ，即并非所有输出都与损失相关联。机器人本体感受状态被离散化，并作为文本令牌输入模型。有关架构的更多细节见附录 E。

B. 结合离散与连续动作表示 与 π_0 类似，我们在最终模型中使用流匹配 [50] 来预测连续动作。给定 $\mathbf{a}_{t:t+H}^{\tau, \omega} = \tau \mathbf{a}_{t:t+H} + (1-\tau)\omega$ ， $\omega \sim \mathcal{N}(0, \mathbf{I})$ ，其中 $\tau \in [0, 1]$ 是流匹配时间索引，模型被训练来预测流向量场 $\omega - \mathbf{a}_t$ 。然而，如 [64] 所示，当动作由离散标记表示时，视觉-语言-动作（VLA）训练可以快得多，特别是当使用一种能高效压缩动作块的分词方案（例如 FAST）时。不幸的是，这种离散表示不太适合实时推理，因为它们推理时需要昂贵的自回归解码 [64]。因此，理想的模型设计应当在离散化动作上进行训练，但仍允许在推理时使用流匹配来产生连续动作。因此，我们的模型被训练为既通过标记的自回归采样（使用 FAST 分词器）来预测动作，又通过流场的迭代积分来预测动作，从而结合两者的优点。我们使用注意力矩阵来确保不同的动作表示不会相互关注。我们的模型被优化以最小化组合损失

$$\mathbb{E}_{\mathcal{D}, \tau, \omega} \left[H(x_{1:M}, f_\theta^\ell(\mathbf{o}_t, \ell)) + \alpha \left\| \omega - \mathbf{a}_{t:t+H} - f_\theta^a(\mathbf{a}_{t:t+H}^{\tau, \omega}, \mathbf{o}_t, \ell) \right\|^2 \right], \quad (1)$$

其中 $H(x_{1:M}, y_{1:M}^t)$ 是文本标记与预测 logits（包括 FAST 编码的动作标记）之间的交叉熵损失， $y_{1:H}^a = f_\theta^a(\mathbf{a}_{t:t+H}^{\tau, \omega}, \mathbf{o}_t, \ell)$ 是来自（较小的）动作专家的输出， $\alpha \in \mathbb{R}$ 是一个权衡参数。该方案使我们能够首先将模型预训练为标准视觉-语言模型（VLM）变换器，通过将动作映射到文本标记（ $\alpha = 0$ ），然后在后训练阶段添加额外的动作专家权重，以非自回归方式预测连续动作标记，从而实现快速推理。我们发现，遵循这一过程（下文将进一步解释）能够实现稳定的预训练，并使 VLA 模型具有出色的语言遵循能力。在推理时，我们随后使用标准的自回归解码生成文本标记 $\hat{\ell}$ ，然后以文本标记为条件进行 10 步去噪，以产生动作 $\mathbf{a}_{t:t+H}$ 。

Pre-training



Post-training

图 4: 预训练与后训练任务示例。 $\pi_{0.5}$ 在移动机械臂 (MM)、多样环境中的非移动机器人 (ME)、实验室条件下采集的跨具身数据 (CE) 以及高层子任务预测 (HL) 和多模态网络数据 (WD) 上进行预训练。在后训练阶段, 我们额外使用语言指令 (VI), 并省略实验室跨具身数据 (CE), 以使模型专注于移动操作和多样环境。图中展示了每个类别中的示例任务子集。

C. 预训练

在第一训练阶段, $\pi_{0.5}$ 使用广泛的机器人及非机器人数据进行训练, 我们将在下文总结并在图 4 中展示。它被训练为一个标准的自回归变换器 (Transformer), 执行文本、物体位置以及 FAST 编码动作标记的下一个标记预测。

多样化 移动机械臂数据 (MM)。 我们使用约 400 小时的移动机械臂数据, 这些机械臂在约 100 个不同的家庭环境中执行家务任务, 其中部分环境如图 7 所示, 所用机器人在第 IV-E 节中介绍。该训练集切片与我们的评估任务最直接相关, 评估任务包括在新的、未见过的家庭环境中执行类似的清洁和整理任务。多样多环境非移动机器人数据 (**ME**)。我们还收集了非移动机器人数据, 包括单臂或双臂, 在多种家庭环境中。这些机械臂固定在表面或安装平台上, 由于它们显著更轻且更易于运输, 我们能够利用它们在更广泛的家庭中收集更多样化的数据集。然而, 这些 **ME** 数据来自与移动机械臂不同的机器人形态。

C 罗斯具身实验室数据 (CE)。 我们在实验室中收集了广泛任务的数据 (例如清理桌子、折叠衬衫), 使用更简单的桌面环境和多种机器人类型。其中一些任务高度相关

对于我们的评估而言, 有些任务 (例如将餐具放入箱中) 是可行的, 而另一些 (例如研磨咖啡豆) 则不可行。该数据包含单臂和双臂机械臂, 以及固定式和移动式基座。我们还纳入了开源的开放 X 体验数据集 (OXE) [15]。该数据集是 π_0 [8] 所用数据集的扩展版本。

高层子任务预测 (HL)。 将诸如“打扫卧室”之类的高层任务指令分解为更短的子任务, 例如“整理毯子”和“捡起枕头”, 类似于语言模型的思维链提示, 可以帮助训练好的策略推理当前场景并更好地确定下一步动作。对于 MM、ME 和 CE 中涉及多个子任务的机器人数据, 我们手动为所有数据标注子任务的语义描述, 并训练 $\pi_{0.5}$ 基于当前观测和高层指令联合预测子任务标签 (作为文本) 以及动作 (以子任务标签为条件)。这自然产生了一个既能充当高层策略 (输出子任务) 又能充当执行这些子任务动作的低层策略的模型。我们还标注当前观测中显示的相关边界框, 并训练 $\pi_{0.5}$ 在预测子任务之前预测它们。

多模态 网络数据 (WD)。 最后, 我们纳入了多样化的网络数据集, 涉及图像描述生成 (CapsFusion [87]、COCO [12])、问答 (Cambrian-7M [77]、PixMo [19]、VQA v2 [32]) 以及预训练中的目标定位。对于

目标定位，我们进一步用带有边界框标注的室内场景和家用物品的额外网络数据扩展了标准数据集。对于所有动作数据，我们训练模型预测目标关节和末端执行器位姿。为了区分两者，我们在文本提示中添加‘< 控制模式 > 关节/末端执行器 < 控制模式 >’。所有动作数据都使用各个数据集每个动作维度的 1% 和 99% 分位数归一化到 $[-1, 1]$ 。我们将动作 **a** 的维度设置为固定数值，以适应所有数据集中最大的动作空间。对于配置和动作空间维度较低的机器人，我们对动作向量进行零填充。

D. 后训练

在以离散词元对模型进行 280k 梯度步的预训练之后，我们执行第二阶段训练，称之为后训练。该阶段的目的在于使模型专门化以适应我们的应用场景（家庭环境中的移动操作），并添加一个动作专家，能够通过流匹配生成连续动作块。此阶段联合训练下一词元预测，以保留文本预测能力，同时为动作专家（在后训练开始时以随机权重初始化）进行流匹配。我们优化方程 (1) 中的目标，其中 $\alpha = 10.0$ 额外进行 80k 步。后训练动作数据集由 MM 和 ME 机器人数据组成，筛选出长度低于固定阈值的成功回合。我们纳入网络数据 (WD) 以保持模型的语义和视觉能力，以及对应于多环境数据集的 HL 数据切片。此外，为了提高模型预测适当高层子任务的能力，我们收集了口头指令演示 (VI)，这些演示由专家用户提供“语言演示”，选择适当的子任务命令来逐步指挥机器人执行移动操作任务。这些示例通过使用语言实时“遥操作”机器人来执行任务，利用已学习的低层策略，本质上为训练好的策略提供了良好高层子任务输出的演示。

E. 机器人系统细节 我们移动操作实验中使用的机器人系统如图 5 所示。我们使用两种类型的移动机械臂进行了所有实验。两种平台均配备两个 6 自由度机械臂，带有平行夹爪和腕部安装的单目 RGB 相机、一个轮式全向底座以及一个躯干升降机构。底座的状态和动作空间对应于线速度 (2D) 和角速度 (1D)，躯干升降机构为 1D (上/下) 或 2D (上/下和前/后)。除了两个腕部相机外，机器人还在两臂之间安装了一个朝前和一个朝后的相机。我们使用全部四个相机进行高层推理，并使用腕部相机和朝前相机进行低层推理过程。状态和动作空间的总维度为 18 或 19，取决于平台。




图 5：机器人系统概览。 我们使用两个移动机械臂平台——每个平台配备四个摄像头（前向、后向及双腕），两个六自由度机械臂，末端为平行夹爪，一个移动底座，以及一个躯干升降机构。 $\pi_{0.5}$ 模型控制每个机械臂的关节与夹爪、底座速度以及升降位置，形成 18 至 19 自由度的状态与动作空间。

控制系统极为简洁： $\pi_{0.5}$ 模型直接以 50 赫兹（采用动作分块）下达机械臂、夹爪和躯干升降的目标位姿以及底座目标速度指令。这些目标通过简单的比例微分控制器进行跟踪，无需任何额外的轨迹规划或碰撞检测。所有操作与导航控制完全端到端实现。

五、实验评估


$\pi_{0.5}$ 模型旨在广泛泛化至新环境。尽管通常在与训练数据匹配的环境中评估视觉语言动作模型，但本文所有实验均在训练中未见的新环境中进行。为进行定量比较，我们使用一组模拟家庭环境以提供可控且可复现的设置，而最真实的最终评估则在三个不属于训练集的真实家庭中进行（见图 6）。实验聚焦以下问题：1) $\pi_{0.5}$ 能否有效泛化至全新家庭中的复杂多阶段任务？2) $\pi_{0.5}$ 的泛化能力如何随训练数据中不同环境数量的增加而扩展？3) $\pi_{0.5}$ 训练混合中各个协同训练成分对最终性能的贡献如何？4) $\pi_{0.5}$ 与 π_0 视觉语言动作模型相比如何？5) $\pi_{0.5}$ 的高层推理组件有多重要，与扁平低层推理及理想高层基线相比如何？

A. $\pi_{0.5}$ 能否泛化至真实家庭？

为回答问题 (1)，我们在三个未包含于训练集的真实家庭中评估了 $\pi_{0.5}$ ，使用了两种类型的机器人。在每个家庭中，机器人被指示执行卧室和厨房清洁任务。每项任务的评估标准见附录 B，大致对应于每项任务中成功完成的步骤百分比（例如，将一半餐具放入水槽对应约 50%）。图 7 中的结果



图 6：评估环境。我们在训练期间未见过的全新厨房和卧室中评估 $\pi_{0.5}$ ，其中包含新颖的物体、背景和布局。我们使用一组模拟房间进行受控、可重复的定量比较（左），并使用真实住宅进行最终的现实评估（右）。



(a) Example rollouts

我们为每个住宅中的一个任务可视化了一个示例 $\pi_{0.5}$ 片段。从上到下：在住宅 1 中将物品放入抽屉，随后在住宅 2 中将餐具放入水槽，以及在住宅 3 中将衣物放入洗衣篮。每个任务的人类指令显示在左侧，来自 $\pi_{0.5}$ 的高层子任务预测以蓝色显示在每帧下方。

(b) 定量评估。我们展示了每个任务和环境的任务进度，平均超过 10 次试验。我们发现 $\pi_{0.5}$ 在模拟评估设置中的性能代表了其在真实住宅中的性能。

图 7：真实住宅中的评估。我们在训练期间未见过的真实住宅中的三个厨房和三个卧室中评估了 $\pi_{0.5}$ 。我们评估了“物品放入抽屉”、“洗衣篮”和“餐具放入水槽”等任务，并发现 $\pi_{0.5}$ 在这些全新的真实住宅中成功完成了这些任务。

表明 $\pi_{0.5}$ 能够在每个住宅中持续成功完成各种任务（我们注意到，此外，该模型能够执行比我们定量评估中使用的更多任务）。许多任务涉及多个阶段（例如，移动多个物体），持续约 2 到 5 分钟。对于这些试验，模型被提供一个简单的高层命令（例如，“将餐具放入水槽”），高层推理过程自主确定适当的步骤（例如，“拿起杯子”）。这种在野外的泛化水平显著超越了先前视觉-语言-动作模型所展示的结果，无论是在模型必须处理的新颖程度方面，还是在任务持续时间和复杂度方面。

B. 泛化如何随场景数量扩展？

在下一组实验中，我们旨在衡量泛化如何随训练数据中环境数量扩展。我们改变移动操作数据中的环境数量，并通过使用来自 3、12、22、53、82 和 104 个位置的数据进行训练来衡量其对泛化的影响。由于将整个预训练和后训练方案应用于这些数据集中的每一个都过于昂贵

计算密集型，对于这些实验，我们在机器人动作预测数据混合集上进行预训练，不包含移动操作数据，然后比较在包含不同数量环境的移动操作数据的数据集上进行后训练的模型。虽然按位置划分的数据集在原则上大小不同，但在实践中，训练步数（40k）的选择使得每个模型看到相同数量的唯一数据样本，这使我们能够在后训练实验中改变使用的环境数量时控制数据集大小。

每个模型在图 6 所示的模拟环境中进行评估，这些环境在训练中未出现。我们进行两种类型的评估。首先，为了评估多阶段任务的总体性能，我们使用附录 B 中的标准评分标准和模拟测试家庭来评估每个模型在将餐具放入水槽、将物品装入抽屉、收起衣物和整理床铺方面的端到端性能。其次，我们对每个模型遵循语言指令和与新物体交互的能力进行更细粒度的评估，其中机器人必须根据语言命令从厨房台面上拾取特定物体。这些实验使用来自相似类别的分布内物体以及




图 8：评估不同数量环境下的性能。在四个测试任务——“餐具放入水槽”、“物品放入抽屉”、“衣物篮”、“整理床铺”——上的性能随着训练环境的增加而提升。虚线绿色线和绿色条表示在训练集中包含测试家庭的基线模型。与该模型相比，我们的最佳模型达到了相似的性能，尽管没有看到来自测试家庭的任何数据。

训练数据中的对象（但为新实例），以及来自未见类别的分布外对象。后者需要广泛的语义泛化。第一个实验的结果如图 8 所示。任务的平均性能通常随着训练地点的增加而提升。为了量化最终模型（104 个地点）在多大程度上弥合了泛化差距，我们加入了一个对照组（以绿色显示），该对照组直接在测试家庭的数据上进行训练。该对照组达到了与最终 104 地点模型相似的性能，表明我们的协同训练方案有效地实现了广泛泛化，达到了与在测试环境中训练的模型相似的性能。为了确认这种泛化性能需要完整的协同训练方案，我们另外加入了两个基线，它们在预训练阶段不使用任何其他协同训练任务，而是直接在测试环境的数据（浅绿色）或 104 个训练地点的移动操作数据（浅黄色）上进行训练。这两个基线的性能显著更差——这表明即使策略已经见过测试家庭的机器人数据，我们完整训练方案所利用的其他数据源对于良好的泛化仍然至关重要。当不使用测试家庭的数据时，使用我们的方案进行预训练尤为重要，这可以从图 8 中绿色柱与浅黄色柱之间的巨大差距看出。第二个实验（语言跟随）的结果如图 9 所示。我们报告语言跟随率，它衡量机器人选择语言指令中所指对象的频率，以及成功率，它衡量机器人成功将该对象放置在正确位置（根据测试场景，放入抽屉内或水槽内）的频率。我们分别衡量在训练中见过的对象类别（但为新对象实例）和未见（“分布外”）对象类别上的性能。该实验的细节在附录 C 中展示和讨论。图 9 显示，随着数量




图 9：评估不同训练地点数量下的语言遵循能力。我们评估了将用户指定的物品拿起并放入抽屉或水槽的语言遵循率和成功率，结果在已见物体类别（“分布内”）或未见类别（“分布外”）上取平均。随着训练地点数量的增加，性能稳步提升。

随着训练数据中地点数量的增加，语言遵循性能和成功率均有所提高。正如预期，分布内物体的性能提升速度快于分布外物体。由于每个新环境都会引入新的家居物品，模型总体上变得更加稳健，并开始泛化到训练数据中未出现的任务类别。

C. 我们的协同训练方案各部分的重要性如何？

为研究问题（3），我们将完整的 $\pi_{0.5}$ 模型与其他训练混合方案进行比较，以研究每个混合成分的重要性，同样使用模拟房屋中的端到端任务性能和第五节 B 部分描述的语言遵循评估。作为提醒，我们的完整方案使用来自多种环境中的移动机械臂（MM）、多种环境中的固定机械臂（ME）以及实验室环境中收集的多样化跨具身数据（CE）。它还包括预测对应于高层语言命令的高层数据（HL），以及对应于图像描述、视觉问答和目标定位任务的网络数据（WD）。后训练还使用口头指令数据（VI），我们将在第五节 E 部分进行分析。在这些实验中，我们对混合方案的不同部分进行消融：1）无 WD：此消融排除网络数据。2）无 ME：此消融排除多环境非移动数据。3）无 CE：此消融排除实验室跨具身数据。4）无 ME 或 CE：此消融排除来自其他机器人的两种数据源，使得模型仅使用目标移动机械臂平台的数据以及网络数据进行训练。完整模拟房屋任务的结果如图 10 所示（每个任务性能的详细分解见附录 D）。首先，我们在结果中看到，排除任一跨具身数据源（ME 和 CE）都会显著降低性能，表明 $\pi_{0.5}$ 从跨具身迁移中获益显著，既来自其他环境（ME），也来自其他任务（CE）。同时排除两种数据源对性能的损害更大。有趣的是，




图 10: 训练方案消融，模拟家庭环境。我们在所有四个测试任务上评估了排除训练混合中不同部分的模型变体（每个策略和任务 10 次试验）。包含跨具身数据，无论是在多样化环境（ME）中还是在实验室设置下针对多样化任务（CE），对于获得良好性能都至关重要，当移除任一或两个数据源时性能会大幅下降。网络数据（WD）在这些实验中未产生显著差异，但我们将在图 11 和图 13 中看到它影响物体泛化和高层性能。




图 11: 训练方案消融，语言遵循。在不同位置数量上训练后，评估分布内和分布外物体的语言遵循能力。包含网络数据（WD）对于分布外（OOD）性能尤为重要。跨具身（CE）和多样化环境（ME）数据对分布内和分布外性能都有很大影响。

在本实验中，无 WD 消融的性能差异在统计上不显著，尽管我们稍后展示网络数据对语言遵循（下文）和高层子任务推理（第 V-E 节）有很大影响。语言遵循实验的结果如图 11 所示，显示出与图 10 相似的趋势——排除 ME 或/和 CE 数据会导致性能显著下降。不同之处在于，移除网络数据（无 WD）会导致分布外（OOD）物体上的性能显著变差——我们猜想，使用包含非常广泛的物理物体知识的网络数据进行训练，使模型能够理解和遵循涉及未见物体类别的语言命令。

D. $\pi_{0.5}$ 与其他视觉语言动作模型相比如何？

我们将 $\pi_{0.5}$ 与原始的 π_0 视觉语言动作模型以及 π_0 的改进版本（我们将其表示为 π_0 -FAST+Flow）进行比较。该版本通过方程（1）中的联合扩散和 FAST 动作预测公式进行训练，但基于动作数据




图 12: $\pi_{0.5}$ 与其他模型的比较。我们的完整模型在模拟家庭测试环境中显著优于 π_0 和 π_0 -FAST+Flow。

仅使用，不包含高层与网络数据集。这些模型提供了强有力的比较基准，因为 π_0 已被证明在复杂且灵巧的移动操作任务上表现优异，而 π_0 -快速+流匹配的增强使其尽可能接近 $\pi_{0.5}$ 。 $\pi_{0.5}$ 在这些模型的基础上结合了协同训练任务。为了公平比较，所有模型均使用相同的跨具身机器人训练集，并训练相近的步数。差异在于：（1） $\pi_{0.5}$ 额外使用了高层与网络数据；（2） $\pi_{0.5}$ 采用混合训练流程，在预训练阶段使用离散标记化训练，仅在训练后阶段使用流匹配动作专家进行训练，而 π_0 始终使用动作专家。 π_0 -快速+流匹配遵循混合训练方案，但仅使用包含机器人动作的数据进行训练，因此无法执行高层推理。图 12 中的结果表明， $\pi_{0.5}$ 显著优于 π_0 及我们的增强版本。即使允许 π_0 进行长达 30 万训练步的更长时间训练，这一结果仍然成立，证实了如 Pertsch 等人 [64] 所述，使用快速标记进行训练在计算效率上比纯扩散训练更有效。

E. 高层推理有多重要？

最后，我们评估高层推理的重要性，并比较几种替代高层推理方法的性能。 $\pi_{0.5}$ 中的高层推理机制接收高层指令（例如，“打扫卧室”）并输出要完成的子任务（例如，“捡起枕头”），随后将其作为推断低层动作的上下文，类似于思维链推理 [82]。虽然 $\pi_{0.5}$ 采用统一架构，由同一模型同时执行高层和低层推理，但我们也可以构建基线方法，要么放弃高层推理过程，直接将任务提示输入低层系统，这在标准视觉-语言-动作模型中很常见 [92, 8]，要么使用另一个模型进行高层推理，以消融不同数据集组件对高层策略影响的重要性。我们考虑以下方法和消融，它们均使用完整的 $\pi_{0.5}$ 低层推理过程，但采用不同的高层策略：1) $\pi_{0.5}$ 模型用于高层和低层推理。

2) 无网络数据：对 $\pi_{0.5}$ 进行消融，排除网络数据。




图 13：高层推理过程的评估。虽然完整的 $\pi_{0.5}$ 模型结合高层与低层推理取得了最佳结果，但仅使用低层推理（“隐式高层”）的完整 $\pi_{0.5}$ 模型也因训练中包含高层子任务示例而受益。相比之下，排除语言指令（无语言指令）或网络数据（无网络数据）会导致性能显著下降，而对大型应用程序编程接口模型（生成式预训练变换器 4）进行零样本提示的表现更差。

3) 无语言指令：对 $\pi_{0.5}$ 进行消融，排除语言指令数据。

4) 隐式高层：运行时无高层推理，但训练中包含高层数据，这可能隐式地教会模型子任务。

5) 无高层：无高层推理，且训练中完全不包含高层数据。

6) 生成式预训练变换器 4：使用生成式预训练变换器 4 作为高层策略，评估在机器人数据上训练高层策略的重要性。为使模型与我们的领域对齐，我们向生成式预训练变换器 4 提供任务描述和可供选择的最常用标签列表。

7) 人类高层：使用专家人类作为“预言机”高层策略，以提供性能的上限。

这些实验的结果如图 13 所示。完整的 $\pi_{0.5}$ 模型表现最佳，甚至优于人类高层“预言机”基线。也许令人惊讶的是，第二好的模型是隐式高层消融，它不执行任何高层推理，但在训练中包含完整的数据混合，即也包括子任务预测。这强烈表明了我们的模型所使用的协同训练方案的重要性：虽然显式推断高层子任务有好处，但该好处的很大一部分已经通过简单地在训练混合中包含子任务预测数据而获得。无高层消融，即使在训练中也排除了高层任务，表现显著更差。结果还表明，相对较小的语言指令数据集，仅占高层移动操作示例的约 11%，对强性能至关重要，因为无语言指令消融显著更弱。无网络数据消融也显著更差，表明网络数据的好处（也许并不令人惊讶）主要在于改善

高层策略。最后，零样本 **GPT-4** 消融获得了最差的性能，表明使用机器人数据适应视觉语言模型的重要性。我们在附录 D 的图 17 中提供了每个任务性能的详细分解。

六、讨论与未来工作

本文描述了 $\pi_{0.5}$ ，这是一种协同训练模型，构建于 π_0 视觉-语言-动作模型之上，旨在整合多种数据源并实现对新环境的泛化。 $\pi_{0.5}$ 视觉-语言-动作模型能够控制移动机械臂在家庭环境中执行训练数据中从未见过的任务，例如清洁厨房和卧室、整理床铺、悬挂毛巾以及其他多阶段灵巧行为。 $\pi_{0.5}$ 基于约 400 小时的移动操作数据进行训练，但包含了来自其他机器人的大量数据，包括不同环境中的非移动机械臂以及在实验室条件下采集的数据。此外，该模型还与网络数据以及基于机器人观测输出语言指令的高层预测数据进行联合训练。 $\pi_{0.5}$ 的泛化能力表明，这种协同训练方法促进了有效的迁移，使得仅使用中等规模的移动操作数据集即可实现移动机械臂的高度泛化控制。 $\pi_{0.5}$ 并非没有局限性。尽管我们的视觉-语言-动作模型展现出广泛的泛化能力，但仍会犯错。某些环境存在持续挑战（例如抽屉上不熟悉的手柄，或机器人难以物理打开的柜子），某些行为在部分可观测性方面存在挑战（例如机械臂遮挡了本应擦拭的溢出物），并且在某些情况下高层子任务推理容易受到干扰（例如在收纳物品时多次关闭和打开抽屉）。通过更好的协同训练、迁移和更大规模的数据集来解决这些挑战，是未来工作的一个有前景的方向。其他未来工作方向可以解决我们方法的技术约束。虽然 $\pi_{0.5}$ 能够执行多种清洁厨房和卧室的行为，但它处理的提示相对简单。模型能够适应的提示复杂度由训练数据决定，通过生成更复杂多样的标注（无论是通过人工标注员还是合成方式），可以纳入更复杂的偏好和指令。该模型还使用了相对有限的上下文，纳入更丰富的上下文和记忆可以显著提升模型在部分可观测性更强的场景中的能力，例如需要在不同房间之间导航或记住物品存放位置的任务。更广泛地， $\pi_{0.5}$ 探索了异构数据源的特定组合，但具体的数据来源还可以更广泛地探索。例如，我们的系统从口头指令中学习的能力提供了一种强大的新型监督模式，未来工作可以探索这一方式以及人们为机器人提供额外上下文知识的其他途径。我们希望我们的工作能够成为新一代视觉-语言-动作模型的基础，这些模型能够对多样化的真实世界环境展现出广泛的泛化能力。

致谢

我们感谢机器人操作员在数据收集、评估、后勤和视频录制方面的工作。完整的贡献声明见附录 A。

参考文献

- [1] AgiBot-World-Contributors, Qingwen Bu, Jisong Cai, Li Chen, Xiuqi Cui, Yan Ding, Siyuan Feng, Shenyuan Gao, Xindong He, Xuan Hu, Xu Huang, Shu Jiang, Yuxin Jiang, Cheng Jing, Hongyang Li, Jialu Li, Chiming Liu, Yi Liu, Yuxiang Lu, Jianlan Luo, Ping Luo, Yao Mu, Yuehan Niu, Yixuan Pan, Jiangmiao Pang, Yu Qiao, Guanghui Ren, Cheng Ruan, Jiaqi Shan, Yongjian Shen, Chengshi Shi, Mingkan Shi, Modi Shi, Chonghao Sima, Jianheng Song, Huijie Wang, Wenhao Wang, Dafeng Wei, Chengen Xie, Guo Xu, Junchi Yan, Cunbiao Yang, Lei Yang, Shukai Yang, Maoqing Yao, Jia Zeng, Chi Zhang, Qinglin Zhang, Bin Zhao, Chengyue Zhao, Jiaqi Zhao, and Jianchao Zhu. Agibot world colosseum: A large-scale manipulation platform for scalable and intelligent embodied systems. *arXiv preprint arXiv:2503.06669*, 2025.
- [2] Michael Ahn, Anthony Brohan, Noah Brown, Yevgen Chebotar, Omar Cortes, Byron David, Chelsea Finn, Chuyuan Fu, Keerthana Gopalakrishnan, Karol Hausman, Alex Herzog, Daniel Ho, Jasmine Hsu, Julian Ibarz, Brian Ichter, Alex Irpan, Eric Jang, Rosario Jauregui Ruano, Kyle Jeffrey, Sally Jesmonth, Nikhil Joshi, Ryan Julian, Dmitry Kalashnikov, Yuheng Kuang, Kuang-Huei Lee, Sergey Levine, Yao Lu, Linda Luu, Carolina Parada, Peter Pastor, Jornell Quiambao, Kanishka Rao, Jarek Rettinghouse, Diego Reyes, Pierre Sermanet, Nicolas Sievers, Clayton Tan, Alexander Toshev, Vincent Vanhoucke, Fei Xia, Ted Xiao, Peng Xu, Sichun Xu, Mengyuan Yan, and Andy Zeng. Do as i can and not as i say: Grounding language in robotic affordances. In *arXiv preprint arXiv:2204.01691*, 2022.
- [3] Suneel Belkale and Dorsa Sadigh. Minivla: A better vla with a smaller footprint, 2024. URL <https://github.com/Stanford-ILIAD/openvla-mini>.
- [4] Suneel Belkale, Tianli Ding, Ted Xiao, Pierre Sermanet, Quon Vuong, Jonathan Tompson, Yevgen Chebotar, Debidda Dwibedi, and Dorsa Sadigh. Rt-h: Action hierarchies using language, 2024. URL <https://arxiv.org/abs/2403.01823>.
- [5] Lucas Beyer, Andreas Steiner, André Susano Pinto, Alexander Kolesnikov, Xiao Wang, Daniel Salz, Maxim Neumann, Ibrahim Alabdulmohsin, Michael Tschannen, Emanuele Bugliarello, et al. Paligemma: A versatile 3b vlm for transfer. *arXiv preprint arXiv:2407.07726*, 2024.
- [6] Homanga Bharadhwaj, Jay Vakil, Mohit Sharma, Abhinav Gupta, Shubham Tulsiani, and Vikash Kumar. Roboagent: Generalization and efficiency in robot manipulation via semantic augmentations and action chunking. In *2024 IEEE International Conference on Robotics and Automation (ICRA)*, pages 4788–4795. IEEE, 2024.
- [7] Johan Bjorck, Fernando Castañeda, Nikita Cherniadev, Xingye Da, Runyu Ding, Linxi Fan, Yu Fang, Dieter Fox, Fengyuan Hu, Spencer Huang, et al. Gr00t n1: An open foundation model for generalist humanoid robots. *arXiv preprint arXiv:2503.14734*, 2025.
- [8] Kevin Black, Noah Brown, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Lachy Groom, Karol Hausman, Brian Ichter, Szymon Jakubczak, Tim Jones, Liyiming Ke, Sergey Levine, Adrian Li-Bell, Mohith Mothukuri, Suraj Nair, Karl Pertsch, Lucy Xiaoyang Shi, James Tanner, Quan Vuong, Anna Walling, Haohuan Wang, and Ury Zhilinsky. π_0 : A vision-language-action flow model for general robot control. *arXiv preprint arXiv:2410.24164*, 2024.
- [9] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Joseph Dabis, Chelsea Finn, Keerthana Gopalakrishnan, Karol Hausman, Alex Herzog, Jasmine Hsu, Julian Ibarz, Brian Ichter, Alex Irpan, Tomas Jackson, Sally Jesmonth, Nikhil Joshi, Ryan Julian, Dmitry Kalashnikov, Yuheng Kuang, Isabel Leal, Kuang-Huei Lee, Sergey Levine, Yao Lu, Utsav Malla, Deeksha Manjunath, Igor Mordatch, Ofir Nachum, Carolina Parada, Jodilyn Peralta, Emily Perez, Karl Pertsch, Jornell Quiambao, Kanishka Rao, Michael Ryoo, Grecia Salazar, Pannag Sanketi, Kevin Sayed, Jaspiar Singh, Sumedh Sontakke, Austin Stone, Clayton Tan, Huong Tran, Vincent Vanhoucke, Steve Vega, Quan Vuong, Fei Xia, Ted Xiao, Peng Xu, Sichun Xu, Tianhe Yu, and Brianna Zitkovich. Rt-1: Robotics transformer for real-world control at scale. In *arXiv preprint arXiv:2212.06817*, 2022.
- [10] Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel M. Ziegler, Jeff Wu, Clemens Winter, Christopher Hesse, Mark Chen, Eric Sigler, Mateusz Litwin, Scott Gray, Benjamin Chess, Jack Clark, Christopher Berner, Sam McCandlish, Alec Radford, Ilya Sutskever, and Dario Amodei. Language models are few-shot learners. In *Advances in Neural Information Processing Systems*, 2020.
- [11] Hongyi Chen, Yunchao Yao, Ruixuan Liu, Changliu Liu, and Jeffrey Ichnowski. Automating robot failure recovery using vision-language models with optimized prompts. *arXiv preprint arXiv:2409.03966*, 2024.
- [12] Xinlei Chen, Hao Fang, Tsung-Yi Lin, Ramakrishna Vedantam, Saurabh Gupta, Piotr Dollár, and C Lawrence Zitnick. Microsoft coco captions: Data collection and evaluation server. *arXiv preprint arXiv:1504.00325*, 2015.
- [13] An-Chieh Cheng, Yandong Ji, Zhaojing Yang, Zaitian Gongye, Xueyan Zou, Jan Kautz, Erdem Biyik, Hongxu Yin, Sifei Liu, and Xiaolong Wang. Navila: Legged robot vision-language-action model for navigation. *arXiv*

preprint *arXiv:2412.04453*, 2024.

- [14] Cheng Chi, Zhenjia Xu, Chuer Pan, Eric Cousineau, Benjamin Burchfiel, Siyuan Feng, Russ Tedrake, and Shuran Song. Universal manipulation interface: In-the-wild robot teaching without in-the-wild robots. In *Proceedings of Robotics: Science and Systems (RSS)*, 2024.
- [15] OX-Embodiment Collaboration, A Padalkar, A Pooley, A Jain, A Bewley, A Herzog, A Irpan, A Khazatsky, A Rai, A Singh, et al. Open X-Embodiment: Robotic learning datasets and RT-X models. *arXiv preprint arXiv:2310.08864*, 1(2), 2023.
- [16] Yinpei Dai, Jayjun Lee, Nima Fazeli, and Joyce Chai. Racer: Rich language-guided failure recovery policies for imitation learning. *International Conference on Robotics and Automation (ICRA)*, 2025.
- [17] Sudeep Dasari, Frederik Ebert, Stephen Tian, Suraj Nair, Bernadette Bucher, Karl Schmeckpeper, Siddharth Singh, Sergey Levine, and Chelsea Finn. Robonet: Large-scale multi-robot learning. *CoRL*, 2019.
- [18] Sudeep Dasari, Mohan Kumar Srirama, Unnat Jain, and Abhinav Gupta. An unbiased look at datasets for visuomotor pre-training. In *Conference on Robot Learning*, pages 1183–1198. PMLR, 2023.
- [19] Matt Deitke, Christopher Clark, Sangho Lee, Rohun Tripathi, Yue Yang, Jae Sung Park, Mohammadreza Salehi, Niklas Muennighoff, Kyle Lo, Luca Soldaini, et al. Molmo and pixmo: Open weights and open data for state-of-the-art multimodal models. *arXiv preprint arXiv:2409.17146*, 2024.
- [20] Dempsey. Reviews-consumer technology. the teardown-amazon astro consumer robot. *Engineering & Technology*, 18(2):70–71, 2023.
- [21] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, 2019.
- [22] Ria Doshi, Homer Walke, Oier Mees, Sudeep Dasari, and Sergey Levine. Scaling cross-embodied learning: One policy for manipulation, navigation, locomotion and aviation. In *Conference on Robot Learning*, 2024.
- [23] Danny Driess, Fei Xia, Mehdi SM Sajjadi, Corey Lynch, Aakanksha Chowdhery, Brian Ichter, Ayzaan Wahid, Jonathan Tompson, Quan Vuong, Tianhe Yu, et al. Palm-e: An embodied multimodal language model. *arXiv preprint arXiv:2303.03378*, 2023.
- [24] Jiafei Duan, Wentao Yuan, Wilbert Pumacay, Yi Ru Wang, Kiana Ehsani, Dieter Fox, and Ranjay Krishna. Manipulate-anything: Automating real-world robots using vision-language models. *arXiv preprint arXiv:2406.18915*, 2024.
- [25] Frederik Ebert, Yanlai Yang, Karl Schmeckpeper, Bernadette Bucher, Georgios Georgakis, Kostas Daniilidis, Chelsea Finn, and Sergey Levine. Bridge data: Boosting generalization of robotic skills with cross-domain datasets. *arXiv preprint arXiv:2109.13396*, 2021.
- [26] Kiana Ehsani, Tanmay Gupta, Rose Hendrix, Jordi Salvador, Luca Weihs, Kuo-Hao Zeng, Kunal Pratap Singh, Yejin Kim, Winson Han, Alvaro Herrasti, et al. Spoc: Imitating shortest paths in simulation enables effective navigation and manipulation in the real world. *arXiv preprint arXiv:2312.02976*, 2023.
- [27] Patrick Esser, Sumith Kulal, Andreas Blattmann, Rahim Entezari, Jonas Müller, Harry Saini, Yam Levi, Dominik Lorenz, Axel Sauer, Frederic Boesel, et al. Scaling rectified flow transformers for high-resolution image synthesis. In *Forty-first International Conference on Machine Learning*, 2024.
- [28] Haritheja Etukuru, Norihito Naka, Zijin Hu, Seungjae Lee, Julian Mehu, Aaron Edsinger, Chris Paxton, Soumith Chintala, Lerrel Pinto, and Nur Muhammad Mahi Shafiullah. Robot utility models: General policies for zero-shot deployment in new environments. *arXiv preprint arXiv:2409.05865*, 2024.
- [29] Hao-Shu Fang, Chenxi Wang, Hongjie Fang, Minghao Gou, Jirong Liu, Hengxu Yan, Wenhui Liu, Yichen Xie, and Cewu Lu. Anygrasp: Robust and efficient grasp perception in spatial and temporal domains. *IEEE Transactions on Robotics*, 39(5):3929–3945, 2023.
- [30] Hao-Shu Fang, Hongjie Fang, Zhenyu Tang, Jirong Liu, Chenxi Wang, Junbo Wang, Haoyi Zhu, and Cewu Lu. Rh20t: A comprehensive robotic dataset for learning diverse skills in one-shot. In *2024 IEEE International Conference on Robotics and Automation (ICRA)*, pages 653–660. IEEE, 2024.
- [31] Theophile Gervet, Soumith Chintala, Dhruv Batra, Jitendra Malik, and Devendra Singh Chaplot. Navigating to objects in the real world. *Science Robotics*, 8(79): eadf6991, 2023.
- [32] Yash Goyal, Tejas Khot, Douglas Summers-Stay, Dhruv Batra, and Devi Parikh. Making the V in VQA matter: Elevating the role of image understanding in visual question answering. In *Computer Vision and Pattern Recognition (CVPR)*, 2017.
- [33] Abhinav Gupta, Adithyavairavan Murali, Dhiraj Prakashchand Gandhi, and Lerrel Pinto. Robot learning in homes: Improving generalization and reducing dataset bias. *Advances in neural information processing systems*, 31, 2018.
- [34] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 770–778, 2016.
- [35] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. Masked autoencoders are scalable vision learners. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 15979–15988, 2022.
- [36] Yingdong Hu, Fanqi Lin, Tong Zhang, Li Yi, and Yang Gao. Look before you leap: Unveiling the power of gpt-

- 4v in robotic vision-language planning. *arXiv preprint arXiv:2311.17842*, 2023.
- [37] Huang Huang, Fangchen Liu, Letian Fu, Tingfan Wu, Mustafa Mukadam, Jitendra Malik, Ken Goldberg, and Pieter Abbeel. Otter: A vision-language-action model with text-aware visual feature extraction. *arXiv preprint arXiv:2503.03734*, 2025.
- [38] Wenlong Huang, Pieter Abbeel, Deepak Pathak, and Igor Mordatch. Language models as zero-shot planners: Extracting actionable knowledge for embodied agents. In *International conference on machine learning*, pages 9118–9147. PMLR, 2022.
- [39] Aaron Jaech, Adam Kalai, Adam Lerer, Adam Richardson, Ahmed El-Kishky, Aiden Low, Alec Helyar, Aleksander Madry, Alex Beutel, Alex Carney, et al. Openai o1 system card. *arXiv preprint arXiv:2412.16720*, 2024.
- [40] Joseph L Jones. Robots at the tipping point: the road to irobot roomba. *IEEE Robotics & Automation Magazine*, 13(1):76–78, 2006.
- [41] Alexander Khazatsky, Karl Pertsch, Suraj Nair, Ashwin Balakrishna, Sudeep Dasari, Siddharth Karamcheti, Soroush Nasiriany, Mohan Kumar Srirama, Lawrence Yunliang Chen, Kirsty Ellis, Peter David Fagan, Joey Hejna, Masha Itkina, Marion Lepert, Yecheng Jason Ma, Patrick Tree Miller, Jimmy Wu, Suneel Belkhale, Shivin Dass, Huy Ha, Arhan Jain, Abraham Lee, Youngwoon Lee, Marius Memmel, Sungjae Park, Ilija Radosavovic, Kaiyuan Wang, Albert Zhan, Kevin Black, Cheng Chi, Kyle Beltran Hatch, Shan Lin, Jingpei Lu, Jean Mercat, Abdul Rehman, Pannag R Sanketi, Archit Sharma, Cody Simpson, Quan Vuong, Homer Rich Walke, Blake Wulfe, Ted Xiao, Jonathan Heewon Yang, Arefeh Yavary, Tony Z. Zhao, Christopher Agia, Rohan Baijal, Mateo Guaman Castro, Daphne Chen, Qiuyu Chen, Trinity Chung, Jaimyn Drake, Ethan Paul Foster, Jensen Gao, David Antonio Herrera, Minh Heo, Kyle Hsu, Jiaheng Hu, Donovan Jackson, Charlotte Le, Yunshuang Li, Kevin Lin, Roy Lin, Zehan Ma, Abhiram Maddukuri, Suvir Mirchandani, Daniel Morton, Tony Nguyen, Abigail O’Neill, Rosario Scalise, Derick Seale, Victor Son, Stephen Tian, Emi Tran, Andrew E. Wang, Yilin Wu, Annie Xie, Jingyun Yang, Patrick Yin, Yunchu Zhang, Osbert Bastani, Glen Berseth, Jeannette Bohg, Ken Goldberg, Abhinav Gupta, Abhishek Gupta, Dinesh Jayaraman, Joseph J Lim, Jitendra Malik, Roberto Martín-Martín, Subramanian Ramamoorthy, Dorsa Sadigh, Shuran Song, Jiajun Wu, Michael C. Yip, Yuke Zhu, Thomas Kollar, Sergey Levine, and Chelsea Finn. Droid: A large-scale in-the-wild robot manipulation dataset. In *Proceedings of Robotics: Science and Systems*, 2024.
- [42] Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, Ted Xiao, Ashwin Balakrishna, Suraj Nair, Rafael Rafailov, Ethan Foster, Grace Lam, Pannag Sanketi, et al. Openvla: An open-source vision-language-action model. *arXiv preprint arXiv:2406.09246*, 2024.
- [43] Alexander Kirillov, Eric Mintun, Nikhila Ravi, Hanzi Mao, Chloe Rolland, Laura Gustafson, Tete Xiao, Spencer Whitehead, Alexander C. Berg, Wan-Yen Lo, Piotr Dollár, and Ross Girshick. Segment anything. *arXiv preprint arXiv:2304.02643*, 2023.
- [44] Boyi Li, Philipp Wu, Pieter Abbeel, and Jitendra Malik. Interactive task planning with language models, 2023.
- [45] Qixiu Li, Yaobo Liang, Zeyu Wang, Lin Luo, Xi Chen, Mozhen Liao, Fangyun Wei, Yu Deng, Sicheng Xu, Yizhong Zhang, et al. Cogact: A foundational vision-language-action model for synergizing cognition and action in robotic manipulation. *arXiv preprint arXiv:2411.19650*, 2024.
- [46] Xiang Li, Cristina Mata, Jongwoo Park, Kumara Kahatapitiya, Yoo Sung Jang, Jinghuan Shang, Kanchana Ranasinghe, Ryan Burgert, Mu Cai, Yong Jae Lee, et al. Llora: Supercharging robot learning data for vision-language policy. *arXiv preprint arXiv:2406.20095*, 2024.
- [47] Yi Li, Yuquan Deng, Jesse Zhang, Joel Jang, Marius Memmel, Raymond Yu, Caelan Reed Garrett, Fabio Ramos, Dieter Fox, Anqi Li, et al. Hamster: Hierarchical action models for open-world robot manipulation. *arXiv preprint arXiv:2502.05485*, 2025.
- [48] Jacky Liang, Wenlong Huang, Fei Xia, Peng Xu, Karol Hausman, Brian Ichter, Pete Florence, and Andy Zeng. Code as policies: Language model programs for embodied control. In *2023 IEEE International Conference on Robotics and Automation (ICRA)*, pages 9493–9500. IEEE, 2023.
- [49] Fanqi Lin, Yingdong Hu, Pingyue Sheng, Chuan Wen, Jiacheng You, and Yang Gao. Data scaling laws in imitation learning for robotic manipulation. *arXiv preprint arXiv:2410.18647*, 2024.
- [50] Yaron Lipman, Ricky TQ Chen, Heli Ben-Hamu, Maximilian Nickel, and Matt Le. Flow matching for generative modeling. *arXiv preprint arXiv:2210.02747*, 2022.
- [51] Fangchen Liu, Kuan Fang, Pieter Abbeel, and Sergey Levine. Moka: Open-vocabulary robotic manipulation through mark-based visual prompting. In *First Workshop on Vision-Language Models for Navigation and Manipulation at ICRA 2024*, 2024.
- [52] Jiaming Liu, Hao Chen, Pengju An, Zhuoyang Liu, Renrui Zhang, Chenyang Gu, Xiaoqi Li, Ziyu Guo, Sixiang Chen, Mengzhen Liu, et al. Hybridvla: Collaborative diffusion and autoregression in a unified vision-language-action model. *arXiv preprint arXiv:2503.10631*, 2025.
- [53] Peiqi Liu, Yaswanth Orru, Jay Vakil, Chris Paxton, Nur Muhammad Mahi Shafiullah, and Lerrel Pinto. Ok-robot: What really matters in integrating open-knowledge models for robotics. *arXiv preprint arXiv:2401.12202*, 2024.
- [54] Qiang Liu. Rectified flow: A marginal preserving approach to optimal transport. *arXiv preprint arXiv:2209.14577*, 2022.
- [55] Songming Liu, Lingxuan Wu, Bangguo Li, Hengkai Tan, Huayu Chen, Zhengyi Wang, Ke Xu, Hang Su, and Jun

- Zhu. Rdt-1b: a diffusion foundation model for bimanual manipulation. *arXiv preprint arXiv:2410.07864*, 2024.
- [56] Jeffrey Mahler, Jacky Liang, Sherdil Niyaz, Michael Laskey, Richard Doan, Xinyu Liu, Juan Aparicio Ojea, and Ken Goldberg. Dex-net 2.0: Deep learning to plan robust grasps with synthetic point clouds and analytic grasp metrics. *arXiv preprint arXiv:1703.09312*, 2017.
- [57] Arjun Majumdar, Karmesh Yadav, Sergio Arnaud, Jason Ma, Claire Chen, Sneha Silwal, Aryan Jain, Vincent-Pierre Berges, Tingfan Wu, Jay Vakil, et al. Where are we in the search for an artificial visual cortex for embodied intelligence? *Advances in Neural Information Processing Systems*, 36:655–677, 2023.
- [58] Suraj Nair, Aravind Rajeswaran, Vikash Kumar, Chelsea Finn, and Abhinav Gupta. R3m: A universal visual representation for robot manipulation. In *CoRL*, 2022.
- [59] Soroush Nasiriany, Fei Xia, Wenhao Yu, Ted Xiao, Jacky Liang, Ishita Dasgupta, Annie Xie, Danny Driess, Ayzaan Wahid, Zhuo Xu, et al. Pivot: Iterative visual prompting elicits actionable knowledge for vlms. *arXiv preprint arXiv:2402.07872*, 2024.
- [60] Hai Nguyen and Charles C Kemp. Autonomously learning to visually detect where manipulation will succeed. *Autonomous Robots*, 36:137–152, 2014.
- [61] Dantong Niu, Yuvan Sharma, Giscard Biamby, Jerome Quenum, Yutong Bai, Baifeng Shi, Trevor Darrell, and Roei Herzig. Llarva: Vision-action instruction tuning enhances robot learning. *arXiv preprint arXiv:2406.11815*, 2024.
- [62] Octo Model Team, Dibya Ghosh, Homer Walke, Karl Pertsch, Kevin Black, Oier Mees, Sudeep Dasari, Joey Hejna, Charles Xu, Jianlan Luo, Tobias Kreiman, You Liang Tan, Pannag Sanketi, Quan Vuong, Ted Xiao, Dorsa Sadigh, Chelsea Finn, and Sergey Levine. Octo: An open-source generalist robot policy. In *Proceedings of Robotics: Science and Systems*, Delft, Netherlands, 2024.
- [63] Open X-Embodiment Collaboration, Abhishek Padalkar, Acorn Pooley, Ajinkya Jain, Alex Bewley, Alex Herzog, Alex Irpan, Alexander Khazatsky, Anant Rai, Anikait Singh, Anthony Brohan, Antonin Raffin, Ayzaan Wahid, Ben Burgess-Limerick, Beomjoon Kim, Bernhard Schölkopf, Brian Ichter, Cewu Lu, Charles Xu, Chelsea Finn, Chenfeng Xu, Cheng Chi, Chenguang Huang, Christine Chan, Chuer Pan, Chuyuan Fu, Coline Devin, Danny Driess, Deepak Pathak, Dhruv Shah, Dieter Buehler, Dmitry Kalashnikov, Dorsa Sadigh, Edward Johns, Federico Ceola, Fei Xia, Freek Stulp, Gaoyue Zhou, Gaurav S. Sukhatme, Gautam Salhotra, Ge Yan, Giulio Schiavi, Hao Su, Hao-Shu Fang, Haochen Shi, Heni Ben Amor, Henrik I Christensen, Hiroki Furuta, Homer Walke, Hongjie Fang, Igor Mordatch, Ilija Radosavovic, Isabel Leal, Jacky Liang, Jaehyung Kim, Jan Schneider, Jasmine Hsu, Jeannette Bohg, Jeffrey Bingham, Jiajun Wu, Jialin Wu, Jianlan Luo, Jiayuan Gu, Jie Tan, Jihoon Oh, Jitendra Malik, Jonathan Tompson, Jonathan Yang, Joseph J. Lim, João Silvério, Junhyek Han, Kanishka Rao, Karl Pertsch, Karol Hausman, Keegan Go, Keerthana Gopalakrishnan, Ken Goldberg, Kendra Byrne, Kenneth Oslund, Kento Kawaharazuka, Kevin Zhang, Keyvan Majd, Krishan Rana, Krishnan Srinivasan, Lawrence Yunliang Chen, Lerrel Pinto, Liam Tan, Lionel Ott, Lisa Lee, Masayoshi Tomizuka, Maximilian Du, Michael Ahn, Mingtong Zhang, Mingyu Ding, Mohan Kumar Srirama, Mohit Sharma, Moo Jin Kim, Naoaki Kanazawa, Nicklas Hansen, Nicolas Heess, Nikhil J Joshi, Niko Suenderhauf, Norman Di Palo, Nur Muhammad Mahi Shafullah, Oier Mees, Oliver Kroemer, Pannag R Sanketi, Paul Wohlhart, Peng Xu, Pierre Sermanet, Priya Sundareshan, Quan Vuong, Rafael Rafailov, Ran Tian, Ria Doshi, Roberto Martín-Martín, Russell Mendonca, Rutav Shah, Ryan Hoque, Ryan Julian, Samuel Bustamante, Sean Kirmeni, Sergey Levine, Sherry Moore, Shikhar Bahl, Shivin Dass, Shuran Song, Sichun Xu, Siddhant Halder, Simeon Adebola, Simon Guist, Soroush Nasiriany, Stefan Schaal, Stefan Welker, Stephen Tian, Sudeep Dasari, Suneel Belkhal, Takayuki Osa, Tatsuya Harada, Tatsuya Matsushima, Ted Xiao, Tianhe Yu, Tianli Ding, Todor Davchev, Tony Z. Zhao, Travis Armstrong, Trevor Darrell, Vidhi Jain, Vincent Vanhoucke, Wei Zhan, Wenxuan Zhou, Wolfram Burgard, Xi Chen, Xiaolong Wang, Xinghao Zhu, Xuanlin Li, Yao Lu, Yevgen Chebotar, Yifan Zhou, Yifeng Zhu, Ying Xu, Yixuan Wang, Yonatan Bisk, Yoonyoung Cho, Youngwoon Lee, Yuchen Cui, Yueh hua Wu, Yujin Tang, Yuke Zhu, Yunzhu Li, Yusuke Iwasawa, Yutaka Matsuo, Zhuo Xu, and Zichen Jeff Cui. Open X-Embodiment: Robotic learning datasets and RT-X models. <https://arxiv.org/abs/2310.08864>, 2023.
- [64] Karl Pertsch, Kyle Stachowicz, Brian Ichter, Danny Driess, Suraj Nair, Quan Vuong, Oier Mees, Chelsea Finn, and Sergey Levine. FAST: Efficient action tokenization for vision-language-action models. *Robotics: Science and Systems*, 2025.
- [65] Dicong Qiu, Wenzong Ma, Zhenfu Pan, Hui Xiong, and Junwei Liang. Open-vocabulary mobile manipulation in unseen dynamic environments with 3d semantic maps. *arXiv preprint arXiv:2406.18115*, 2024.
- [66] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, et al. Learning transferable visual models from natural language supervision. In *International conference on machine learning*, pages 8748–8763. PMLR, 2021.
- [67] Nur Muhammad Mahi Shafullah, Anant Rai, Haritheja Etukuru, Yiqian Liu, Ishan Misra, Soumith Chintala, and Lerrel Pinto. On bringing robots home. *arXiv preprint arXiv:2311.16098*, 2023.
- [68] Dhruv Shah, Ajay Sridhar, Arjun Bhorkar, Noriaki Hirose, and Sergey Levine. Gnm: A general navigation model to drive any robot. In *2023 IEEE International Conference on Robotics and Automation (ICRA)*, pages 7226–7233. IEEE, 2023.

- [69] Dhruv Shah, Ajay Sridhar, Nitish Dashora, Kyle Stachowicz, Kevin Black, Noriaki Hirose, and Sergey Levine. ViNT: A foundation model for visual navigation. In *7th Annual Conference on Robot Learning*, 2023. URL <https://arxiv.org/abs/2306.14846>.
- [70] Rutav Shah, Albert Yu, Yifeng Zhu, Yuke Zhu, and Roberto Martín-Martín. Bumble: Unifying reasoning and acting with vision-language models for building-wide mobile manipulation. *arXiv preprint arXiv:2410.06237*, 2024.
- [71] Lucy Xiaoyang Shi, Zheyuan Hu, Tony Z Zhao, Archit Sharma, Karl Pertsch, Jianlan Luo, Sergey Levine, and Chelsea Finn. Yell at your robot: Improving on-the-fly from language corrections. *arXiv preprint arXiv:2403.12910*, 2024.
- [72] Lucy Xiaoyang Shi, Brian Ichter, Michael Equi, Liyiming Ke, Karl Pertsch, Quan Vuong, James Tanner, Anna Walling, Haohuan Wang, Niccolo Fusai, et al. Hi robot: Open-ended instruction following with hierarchical vision-language-action models. *arXiv preprint arXiv:2502.19417*, 2025.
- [73] Ishika Singh, Valts Blukis, Arsalan Mousavian, Ankit Goyal, Danfei Xu, Jonathan Tremblay, Dieter Fox, Jesse Thomason, and Animesh Garg. Progprompt: Generating situated robot task plans using large language models. In *2023 IEEE International Conference on Robotics and Automation (ICRA)*, pages 11523–11530. IEEE, 2023.
- [74] Austin Stone, Ted Xiao, Yao Lu, Keerthana Gopalakrishnan, Kuang-Huei Lee, Quan Vuong, Paul Wohlhart, Brianna Zitkovich, Fei Xia, Chelsea Finn, et al. Open-world object manipulation using pre-trained vision-language models. *arXiv preprint arXiv:2303.00905*, 2023.
- [75] Andrew Szot, Bogdan Mazouze, Omar Attia, Aleksei Timofeev, Harsh Agrawal, Devon Hjelm, Zhe Gan, Zsolt Kira, and Alexander Toshev. From multimodal llms to generalist embodied agents: Methods and lessons. *arXiv preprint arXiv:2412.08442*, 2024.
- [76] Gemini Robotics Team, Saminda Abeyruwan, Joshua Ainslie, Jean-Baptiste Alayrac, Montserrat Gonzalez Arenas, Travis Armstrong, Ashwin Balakrishna, Robert Baruch, Maria Bauza, Michiel Blokzijl, et al. Gemini robotics: Bringing ai into the physical world. *arXiv preprint arXiv:2503.20020*, 2025.
- [77] Peter Tong, Ellis Brown, Penghao Wu, Sanghyun Woo, Adithya Jairam Vedagiri IYER, Sai Charitha Akula, Shusheng Yang, Jihan Yang, Manoj Middepogu, Ziteng Wang, et al. Cambrian-1: A fully open, vision-centric exploration of multimodal llms. *Advances in Neural Information Processing Systems*, 37:87310–87356, 2024.
- [78] Hugo Touvron, Thibaut Lavril, Gautier Izacard, Xavier Martinet, Marie-Anne Lachaux, Timothée Lacroix, Baptiste Rozière, Naman Goyal, Eric Hambro, Faisal Azhar, et al. Llama: Open and efficient foundation language models. *arXiv preprint arXiv:2302.13971*, 2023.
- [79] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30, 2017.
- [80] Homer Rich Walke, Kevin Black, Tony Z Zhao, Quan Vuong, Chongyi Zheng, Philippe Hansen-Estruch, Andre Wang He, Vivek Myers, Moo Jin Kim, Max Du, et al. BridgeData v2: A dataset for robot learning at scale. In *Conference on Robot Learning*, pages 1723–1736. PMLR, 2023.
- [81] Shu Wang, Muzhi Han, Ziyuan Jiao, Zeyu Zhang, Ying Nian Wu, Song-Chun Zhu, and Hangxin Liu. Llm³: Large language model-based task and motion planning with motion failure reasoning. In *2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 12086–12092. IEEE, 2024.
- [82] Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Fei Xia, Ed Chi, Quoc V Le, Denny Zhou, et al. Chain-of-thought prompting elicits reasoning in large language models. *Advances in neural information processing systems*, 35:24824–24837, 2022.
- [83] Junjie Wen, Yichen Zhu, Jinming Li, Minjie Zhu, Kun Wu, Zhiyuan Xu, Ning Liu, Ran Cheng, Chaomin Shen, Yaxin Peng, Feifei Feng, and Jian Tang. Tinyvla: Towards fast, data-efficient vision-language-action models for robotic manipulation. *arXiv preprint arXiv:2409.12514*, 2024.
- [84] Junjie Wen, Yichen Zhu, Jinming Li, Zhibin Tang, Chaomin Shen, and Feifei Feng. Dexvla: Vision-language model with plug-in diffusion expert for general robot control. *arXiv preprint arXiv:2502.05855*, 2025.
- [85] Tete Xiao, Ilija Radosavovic, Trevor Darrell, and Jitendra Malik. Masked visual pre-training for motor control. *arXiv preprint arXiv:2203.06173*, 2022.
- [86] Jianwei Yang, Reuben Tan, Qianhui Wu, Ruijie Zheng, Baolin Peng, Yongyuan Liang, Yu Gu, Mu Cai, Seonghyeon Ye, Joel Jang, et al. Magma: A foundation model for multimodal ai agents. *arXiv preprint arXiv:2502.13130*, 2025.
- [87] Qiying Yu, Quan Sun, Xiaosong Zhang, Yufeng Cui, Fan Zhang, Yue Cao, Xinlong Wang, and Jingjing Liu. Capsfusion: Rethinking image-text data at scale. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 14022–14032, 2024.
- [88] Michał Zawalski, William Chen, Karl Pertsch, Oier Mees, Chelsea Finn, and Sergey Levine. Robotic control via embodied chain-of-thought reasoning. In *Conference on Robot Learning*, 2024.
- [89] Qingqing Zhao, Yao Lu, Moo Jin Kim, Zipeng Fu, Zhuoyang Zhang, Yecheng Wu, Zhaoshuo Li, Qianli Ma, Song Han, Chelsea Finn, et al. Cot-vla: Visual chain-of-thought reasoning for vision-language-action models. *Computer Vision and Pattern Recognition (CVPR)*, 2025.
- [90] Haoyu Zhen, Xiaowen Qiu, Peihao Chen, Jincheng Yang, Xin Yan, Yilun Du, Yining Hong, and Chuang Gan. 3d-vla: 3d vision-language-action generative world model.

arXiv preprint arXiv:2403.09631, 2024.

- [91] Peiyuan Zhi, Zhiyuan Zhang, Yu Zhao, Muzhi Han, Zeyu Zhang, Zhitian Li, Ziyuan Jiao, Baoxiong Jia, and Siyuan Huang. Closed-loop open-vocabulary mobile manipulation with gpt-4v. *arXiv preprint arXiv:2404.10220*, 2024.
- [92] Brianna Zitkovich, Tianhe Yu, Sichun Xu, Peng Xu, Ted Xiao, Fei Xia, Jialin Wu, Paul Wohlhart, Stefan Welker, Ayzaan Wahid, et al. Rt-2: Vision-language-action models transfer web knowledge to robotic control. In *Conference on Robot Learning*, pages 2165–2183. PMLR, 2023.

附录

A. 贡献

数据收集与操作。诺亚·布朗 (Noah Brown)、迈克尔·埃奎 (Michael Equi)、切尔西·芬恩 (Chelsea Finn)、拉奇·格鲁姆 (Lachy Groom)、苏拉杰·奈尔 (Suraj Nair)、露西·晓阳·施 (Lucy Xiaoyang Shi)、安娜·沃林 (Anna Walling)。标注与补充数据。丹尼·德里斯 (Danny Driess)、切尔西·芬恩 (Chelsea Finn)、尼科洛·富萨伊 (Niccolo Fusai)、拉奇·格鲁姆 (Lachy Groom)、布赖恩·伊希特 (Brian Ichter)、卡尔·佩尔奇 (Karl Pertsch)、艾伦·Z·任 (Allen Z. Ren)、劳拉·史密斯 (Laura Smith)、凯尔·斯塔霍维奇 (Kyle Stachowicz)、全武 (Quan Vuong)、安娜·沃林 (Anna Walling)、莉莉·于 (Lili Yu)。策略训练与研究。凯文·布莱克 (Kevin Black)、丹尼·德里斯 (Danny Driess)、迈克尔·埃奎 (Michael Equi)、切尔西·芬恩 (Chelsea Finn)、尼科洛·富萨伊 (Niccolo Fusai)、迪比亚·戈什 (Dibya Ghosh)、布赖恩·伊希特 (Brian Ichter)、李一鸣 (Liyiming Ke)、谢尔盖·莱文 (Sergey Levine)、苏拉杰·奈尔 (Suraj Nair)、卡尔·佩尔奇 (Karl Pertsch)、艾伦·Z·任 (Allen Z. Ren)、露西·晓阳·施 (Lucy Xiaoyang Shi)、劳拉·史密斯 (Laura Smith)、约斯特·托比亚斯·斯普林根贝格 (Jost Tobias Springenberg)、凯尔·斯塔霍维奇 (Kyle Stachowicz)、全武 (Quan Vuong)、霍默·沃克 (Homer Walke)、莉莉·于 (Lili Yu)。策略基础设施。凯文·布莱克 (Kevin Black)、卡兰·达巴利亚 (Karan Dhabalia)、丹尼·德里斯 (Danny Driess)、曼努埃尔·Y·加利克 (Manuel Y. Galliker)、迪比亚·戈什 (Dibya Ghosh)、阿德德里安·李-贝尔 (Adrian Li-Bell)、全武 (Quan Vuong)、王浩欢 (Haohuan Wang)、乌里·日林斯基 (Ury Zhilinsky)。机器人硬件。诺亚·布朗 (Noah Brown)、阿德南·埃斯梅尔 (Adnan Esmail)、蒂姆·琼斯 (Tim Jones)、德文·勒布朗 (Devin LeBlanc)、莫希斯·莫图库里 (Mohith Mothukuri)。机器人基础设施。詹姆斯·达皮尼安 (James Darpinian)、阿德南·埃斯梅尔 (Adnan Esmail)、曼努埃尔·Y·加利克 (Manuel Y. Galliker)、卡罗尔·豪斯曼 (Karol Hausman)、希蒙·雅库布恰克 (Szymon Jakubczak)、詹姆斯·坦纳 (James Tanner)。写作与插图。凯文·布莱克 (Kevin Black)、丹尼·德里斯 (Danny Driess)、切尔西·芬恩 (Chelsea Finn)、卡罗尔·豪斯曼 (Karol Hausman)、布赖恩·伊希特 (Brian Ichter)、谢尔盖·莱文 (Sergey Levine)、卡尔·佩尔奇 (Karl Pertsch)、艾伦·Z·任 (Allen Z. Ren)、露西·晓阳·施 (Lucy Xiaoyang Shi)、约斯特·托比亚斯·斯普林根贝格 (Jost Tobias Springenberg)。

B. 任务评估标准 为定量评估本文方法，我们对训练数据集中包含的四项任务子集进行了严格评估（但在全新场景和配置中进行评估）。其中包括两项厨房清理任务和两项卧室清理任务。每项任务在比较中的每个策略均使用一致的项目集进行评估（但项目在不同位置之间有所变化），分别在三个不同的家庭和三个不同的模拟厨房及模拟卧室中进行（共 12 个不同位置）。除非另有说明，对于每次评估和每个策略，我们每项任务执行 10 次评估；注意，每个评估回合可能持续数分钟，因此耗时较长。我们以每个评估标准中获得的百分比呈现结果（如下所述），并呈现每项任务的度量或跨任务平均的度量

所有任务在四个不同地点进行，这些地点在一次比较中对所有策略保持一致，因此我们的标准评估中每个策略总共进行 40 次评估。评估通过交错执行策略来进行，以控制环境变化。部分评估因机器人故障、时间限制或其他原因而取消，这些评估被移除。在所有情况下，我们控制样本量接近，并根据双侧 t 检验报告统计显著性，假设图中试验次数可变。语言跟随评估遵循正文中描述的不同协议。厨房清理任务的评估指标（包括将餐具放入水槽和将物品存放在抽屉中）详述如下。

- 水槽中的餐具：任务开始时，4 件餐具（如盘子、碗、砧板、器皿）放置在水槽附近。机器人的目标是将所有餐具放入水槽。
+1 每捡起一件物品。+1 每将一件物品放入水槽。最高得分：8 分。
- 抽屉中的物品：任务开始时，一件物品放在台面上。机器人必须将该物品放入台面下方的抽屉中。
+1 捡起物体。
+1 打开抽屉。
+1 将物体放入抽屉。
+1 关闭抽屉（如果物体在里面）。最高得分：4 分。接下来，我们概述卧室清理任务的评估指标：收起衣物和整理床铺。
- 篮子中的衣物：任务开始时，一件衣物躺在地上。机器人的目标是捡起衣物并将其放入洗衣篮。
+1 导航至衣物并捡起。
+1 将衣物放入或放在洗衣篮上。
+1 衣物完全在篮子内。最高得分：3 分。
- 整理床铺：床开始时未整理。机器人必须整理毯子并将两个枕头放在床头。
+1 拉直毯子使其覆盖床单。
+1 将一个枕头放在床头。
+1 将第二个枕头放在床头。
+1 毯子被拉得非常整齐。
+1 两个枕头都摆放得非常整齐。最高得分：5 分。

C. 语言遵循实验设置 语言遵循实验使用两个未见过的厨房场景来测试模型遵循更具体用户指令的能力，例如“把剪刀放进抽屉”或“把砧板放进水槽”。每次试验要求机器人解释指令，在干扰物中识别正确物体，并执行任务。我们在两种场景下进行评估：

1) 抽屉中的物品：常见厨房物品（夹子、木制汤勺、开罐器、剪刀和小瓶黄色芥末）。

2) 水槽中的物品：常见餐具（杯子、碗、盘子、塑料勺和砧板）。

在每次试验中，机器人面对五个物体，并被指示移动其中一个。为阻止捷径行为，目标物体被放置在比干扰物更远的位置，因此无法解释指令的策略只能达到 $\sim 20\%$ 的语言遵循准确率。我们报告两个度量，在两个场景上取平均：语言遵循率，衡量是否选择了正确物体；任务成功率，评估物体是否被成功放置在指定位置。我们进一步研究不同训练环境数量如何影响模型泛化到未见物体的能力。我们设计了一个类似的抽屉中物品任务，使用新颖的家用物品（漏斗、药瓶、烧烤打火机、打火机和一副安全护目镜）。这些物体类别均未出现在训练集中，确保该任务测试机器人在分布外物体上的性能。我们在图 14 中展示了每个任务的示例初始场景。结合图 11 中的数据消融实验和图 9 中的位置缩放实验，图 15 展示了各模型类别的语言遵循结果。我们发现 $\pi_{0.5}$ 的语言遵循率略高于 π_0 -FAST+Flow，且远高于 π_0 ，表明离散标记训练对语言遵循能力的重要性。




图 14：不同语言遵循实验的示例初始状态。




图 15：比较 $\pi_{0.5}$ 与其他模型在语言遵循上的表现。我们评估 $\pi_{0.5}$ ， π_0 和 π_0 -FAST+Flow 的语言遵循能力，发现 $\pi_{0.5}$ 优于每个模型，并以较大优势超过 π_0 。




图 16：训练方案消融的逐任务性能分解。我们在四个代表性家庭任务上评估每种训练混合变体：抽屉中的物品、水槽中的餐具、洗衣篮和整理床铺。移除跨具身数据（移动操作数据或人机协作数据）会导致特定任务性能显著下降，尤其是抽屉中的物品和水槽中的餐具。网络数据（网络数据）对需要广泛场景知识的任务（抽屉中的物品）影响更大。

D. 逐任务性能分解

a) 协同训练方案消融：为深入理解不同训练数据源对特定任务类别的影响，本文提供了逐任务性能分解（图 16）。此处考虑四项代表性家务任务：抽屉取物、水槽洗碗、洗衣篮和整理床铺。总体而言，结果表明跨具身迁移与多样化数据协同训练对于跨任务泛化至关重要，且依赖程度因任务需求而异。对于抽屉取物任务，移除跨具身数据（ME 或 CE）或网络数据（WD）时性能显著下降，当全部排除时退化最为严重。该任务需要识别和理解极为广泛的常见物体类别，此类知识可从多样化数据源中习得。相比之下，水槽洗碗任务对移除网络数据（WD）相对稳健，但排除跨具身数据（ME 或 CE）时性能下降，印证了该任务主要依赖从机器人数据中习得的通用操作策略这一直觉。洗衣篮和整理床铺任务在移除跨具身数据时同样出现性能退化，但对数据混合中的其他变化普遍较不敏感。b) 高层模型分析：为更细致地考察不同高层推理方法对特定任务类别的影响，本文再次提供逐任务分解（图 17）。在四项代表性任务（抽屉取物、水槽洗碗、洗衣篮和整理床铺）上评估完整 $\pi_{0.5}$ 模型及所有高层推理基线。结果表明，显式高层推理可提升跨任务性能，完整 $\pi_{0.5}$ 模型取得最佳总体结果。对于抽屉取物和水槽洗碗任务，高层推理至关重要：无 HL 变体下性能大幅下降，表明结构化子任务预测与长程规划的重要性。在这两项任务中， $\pi_{0.5}$ 模型亦优于 GPT-4 HL，展现出域内微调的优势，并证明高层




图 17: 高层推理方法的逐任务性能分解。本文在四项代表性家务任务上评估完整 $\pi_{0.5}$ 模型及多种高层推理基线。

模型学习有助于低层策略成功的策略。在“抽屉中的物品”任务中，移除网络数据后性能也急剧下降——这与联合训练配方消融的结果相呼应，并凸显了语义知识对于泛化到较少见物体的重要性。对于“洗衣篮”和“水槽中的餐具”任务，模型对高层策略的选择不太敏感。这些任务要么时间跨度相对较短，要么需要较少的详细语义推理。

E. 模型技术细节 $\pi_{0.5}$ 模型构建于 π_0 之上，并采用 PaliGemma 视觉语言模型 (VLM) [5] 作为视觉语言理解的主干，同时采用一个“动作专家”用于快速动作生成。VLM 主干接收图像序列 $[\mathbf{I}_t^1, \dots, \mathbf{I}_t^n]$ 和语言提示 ℓ ，如 π_0 中所示，同时还接收机器人本体感受状态 q_t 的标记化形式以及将被自回归预测的标记化动作 [64]。动作专家是一个较小的变换器，接收噪声动作标记序列 $\mathbf{a}_{t:t+H}^{\tau, \omega}$ ，动作时长为 50，即 $H = 49$ ，并使用流匹配目标进行训练。噪声动作块（动作维度为 d ）首先通过单个线性层投影到变换器嵌入维度。与 π_0 在输入变换器之前将流匹配时间步 τ 与噪声动作融合不同， $\pi_{0.5}$ 使用单独的 MLP 仅投影 τ ，然后应用自适应 RMSNorm 将时间步信息注入动作专家的每一层。时间步 MLP 采用 $\text{swish}(W_2 \cdot \text{swish}(W_1 \cdot \phi(\tau)))$ 的形式，其中 $\phi: \mathbb{R} \rightarrow \mathbb{R}^w$ 是正弦位置编码函数 [79]， $W_1, W_2 \in \mathbb{R}^{w \times w}$ 。动作专家输出动作标记 $y_{1:H}^a$ ，然后通过最终的线性投影解码为目标向量场。两个变换器的维度与 π_0 : { 宽度 =2048, 深度 =18, MLP 维度 =16,384, 头数 =18, KV 头数 =1, 头 $_dim$ =256} 相同，适用于从 PaliGemma 权重初始化的 2B VLM，除了动作专家的 { 宽度 =1024, MLP 维度 =4096} 不同，该专家具有 3 亿参数。




图 18: $\pi_{0.5}$ 注意力掩码模式示例。

来自视觉语言模型 (VLM) 和动作专家的嵌入仅通过自注意力机制交互。图像、提示词和本体感受状态使用完整前缀掩码；FAST 动作令牌关注此前缀，并在先前的动作令牌上自回归。动作专家嵌入关注前缀及彼此，但不关注 FAST 动作令牌，以避免动作的两种表示之间信息泄漏。实际上，信息从视觉语言模型单向流向动作专家；没有视觉语言模型嵌入关注动作专家。每层注意力掩码的示例见图 18。我们遵循 π_0 采样流匹配时间步 τ 。总之，我们偏离标准均匀采样 $\tau \sim \mathcal{U}(0, 1)$ [50, 54] 或强调中间时间步的方法 [27]，转而使用强调低时间步的时间步采样分布 [8]，由 $p(\tau) = \text{Beta}(\frac{s-\tau}{s}; \alpha = 1.5, \beta = 1)$ 给出。高于阈值 s 的时间步被排除在采样之外，因为如果积分步长 δ 满足 $\delta > 1 - s$ ，则不需要它们。我们在实验中使用 $s = 0.999$ ，它最多可容纳 1,000 个积分步 ($\delta > 0.001$)。我们使用以下超参数并按此顺序对变换 = [`augmax.RandomCrop(int(width * 0.95), int(height * 0.95))`, `augmax.Resize(width, height)`, `augmax.Rotate((-5, 5))`, `augmax.ColorJitter(brightness=0.3, contrast=0.4, saturation=0.5)`,] 对所有输入图像应用图像增强（随机裁剪、调整大小、旋转和颜色抖动）。