

面向少样本策略泛化的提示决策变换器

Mengdi Xu¹ Yikang Shen² Shun Zhang³ Yuchen Lu² Ding Zhao¹ Joshua B. Tenenbaum⁴ Chuang Gan^{3,5}

摘要

人类能够利用先前经验，并从少量演示中学习新任务。与旨在通过更好的算法设计实现快速适应的离线元强化学习相比，我们研究了架构归纳偏置对小样本学习能力的影响。我们提出了一种基于提示的决策变换器（Prompt-DT），它利用变换器架构的顺序建模能力和提示框架，在离线强化学习中实现小样本适应。我们设计了轨迹提示，其中包含少量演示的片段，并编码任务特定信息以指导策略生成。我们在五个 MuJoCo 控制基准上的实验表明，Prompt-DT 是一个强大的小样本学习器，无需对未见过的目标任务进行任何额外微调。Prompt-DT 在仅包含几个时间步的轨迹提示下，大幅优于其变体和强大的元离线强化学习基线。Prompt-DT 对提示长度变化也具有鲁棒性，并能泛化到分布外（OOD）环境。项目页面：<https://mxu34.github.io/PromptDT/>。

1. 引言

离线强化学习（Offline Reinforcement Learning，简称离线 RL）（Levine 等人，2020）旨在从一组行为策略收集的轨迹中学习最优策略，而无需访问环境。这种数据驱动的方法在许多场景中至关重要，因为在线交互可能代价高昂（例如机器人或教育智能体）或存在危险（例如自动驾驶或医疗保健）。近期大量工作展示了此类方法在实现基于数据驱动的策略学习方面的强大能力，适用于游戏等场景。¹ 卡内基梅隆大学 ² 蒙特利尔大学，Mila ³ 麻省理工学院-IBM 沃森人工智能实验室 ⁴ 麻省理工学院 ⁵ 马萨诸塞大学阿默斯特分校。通讯作者：Mengdi Xu <mengdixu@andrew.cmu.edu>。

Proceedings of the 39th International Conference on Machine Learning, Baltimore, Maryland, USA, PMLR 162, 2022. Copyright 2022 by the author(s).

环境（Chen 等人，2021）、机器人操作行为（Ebert 等人，2018；Kalashnikov 等人，2018）以及机器人导航技能（Kahn 等人，2021）。

然而，本文将离线强化学习的一个固有难题归结为无法泛化到未见任务。尽管智能体可能在训练任务中获得良好的状态覆盖，但由于分布偏移，它仍难以在测试任务中找到好的策略。因此，Mitchell 等人（2021）的近期工作考虑了离线元强化学习设定，旨在解决离线强化学习中的泛化问题。该工作提出了带优势加权的元演员-评论家（MACAW）算法，该算法以优势加权回归（Peng 等人，2019）作为子程序强化学习算法，并通过元学习目标（Finn 等人，2017a）优化智能体的自适应能力。

元学习方法从算法学习的角度解决该问题，而本文旨在探究架构归纳偏置的作用。众所周知，变换器（Transformer）（Vaswani 等人，2017）模型在大规模数据集上预训练后，能够进行少样本或零样本学习。此外，自然语言处理（NLP）（Liu 等人，2021；Brown 等人，2020）的近期工作表明，基于提示的框架是适应新任务（如翻译和问答）的有效范式。在基于提示的框架中，提示包含关于任务的有价值信息，并作为前缀添加到输入之前。因此，它将少样本或零样本泛化问题转化为条件序列生成，而这正是这些大型变换器模型的优势所在。最近，Chen 等人（2021）表明，除了自然语言之外，变换器架构对轨迹数据也具有强大的序列建模能力，在离线强化学习上取得了最先进的结果。本文旨在回答以下问题：能否利用自然语言处理中的基于提示的框架，并将其适配到离线强化学习的背景下，以实现未见任务的少样本泛化？

值得注意的是，将基于提示的方法适配到强化学习问题并非易事。在自然语言处理中，语言模型（LM）在海量原始文本上预训练，几乎涵盖了互联网上的所有信息。此外，大多数自然语言处理任务可以改写为标准的填空格式作为提示。这些提示充当查询，用于提取

从预训练语言模型中获取正确的信息。在强化学习中，由于不同任务之间存在固有差异，预训练模型是否具备足够知识来解决未知任务值得怀疑。我们提出使用少样本演示作为提示，称之为轨迹提示。不同于无监督语言模型预训练，我们专注于有监督地训练一个智能体，使其能够模仿这些演示来生成新策略，而无需微调。在我们基于提示的离线强化学习框架中，智能体首先使用从同一领域/环境中不同任务收集的离线轨迹进行训练。对于每个任务，智能体学习在给定从同一任务采样的轨迹提示的条件下预测目标轨迹。在评估期间，智能体被赋予一个新任务和少量新轨迹（总步长小于或等于 15）来构建提示。无需额外微调，智能体应利用这些轨迹中展示的任务信息，为新任务生成策略。该框架强大且具有吸引力，原因如下：它允许智能体利用从不同任务收集的离线轨迹，并且智能体能够执行少样本学习，在不更新智能体的情况下适应新场景。

我们将该方法命名为基于提示的决策变换器（Prompt-DT），它利用变换器架构的顺序建模能力和提示框架，在离线强化学习中实现少样本适应。我们的贡献如下。

1. 我们提出了 Prompt-DT，一种基于变换器的模型，通过从少量轨迹构建的短轨迹提示来学习适应未知任务。
2. 我们在五个 MuJoCo 控制基准上的实验表明，Prompt-DT 是一个强大的少样本学习器，无需对目标任务进行任何额外微调，大幅超越了强大的元离线强化学习基线。
3. 我们的分析表明，基于提示的框架是必要的，并且对提示长度具有鲁棒性，对提示质量具有敏感性。
4. Prompt-DT 能够泛化到分布外任务，而所有先前的方法均失败。

2. 相关工作

离线强化学习。离线强化学习（Offline RL）（Levine 等，2020）利用预先收集的数据集学习策略，该数据集包含在行为策略下采样的轨迹。正如 Levine 等（2020）所指出的，离线强化学习问题已被证明比在线强化学习更具挑战性，因为学习智能体需要仅使用离线数据来估计策略的价值。与在线强化学习类似，我们可以采用基于模型或无模型的方法。当使用

在基于模型的方法中，我们可以利用离线数据估计奖励函数和转移函数。然而，需要修改强化学习算法，以避免利用估计模型中的误差（Yu 等人，2020b；Kidambi 等人，2021；Yu 等人，2021）。或者，当选择无模型方法时，我们可以将 Q 学习算法或策略梯度算法适配到离线设置中，但需要显式校正离线数据中行为策略与待优化策略之间的分布不匹配（Kumar 等人，2020；Islam 等人，2019）。

元强化学习 学习。元强化学习（meta-RL）旨在将智能体的知识从一个任务泛化到另一个任务。一种流行的元强化学习算法是 Finn 等人（2017a）提出的模型无关元学习（MAML）。MAML 的目标是找到一个策略参数，使得在任务分布中给定一个新任务时，仅经过少量更新就能在新任务上取得良好性能。MAML 的优化过程包含内循环和外循环。内循环优化策略参数，使其在一步或几步内适应给定任务。这可以通过遵循任何策略梯度算法来实现。外循环涉及元学习目标，优化策略在适应后于任务分布中所有可能任务上的性能。MAML 在基准领域中已展现出成功且有效的适应能力。然而，这种优化算法需要从内循环到外循环的反向传播，计算开销较大。后续提出了更多方法来减轻计算负担（Nichol 等人，2018；Rajeswaran 等人，2019）。

策略学习作为序列建模。强化学习算法需要应对长期信用分配的挑战，通常通过时序差分学习（Temporal Difference Learning）来实现（Sutton & Barto, 2018）。然而，为自然语言处理设计的模型，如变换器（Transformer）（Vaswani et al., 2017），天然具备处理长期信用分配问题的能力。近期，决策变换器（Decision Transformer）（Chen et al., 2021）被提出，将强化学习问题建模为序列预测问题，利用状态、动作、目标回报作为变换器模型中的标记。一项同期工作采用了类似方法，使用变换器预测环境动态（Janner et al., 2021）。这些基于变换器的方法在基准领域上取得了与传统强化学习算法相当或更优的性能。最近，Furuta et al.（2021）证明了决策变换器模型在进行后见信息匹配。

小样本学习。小样本学习（Few-Shot Learning, FSL）旨在快速泛化到仅包含少量带监督信息样本的新任务（Wang 等，2020）。小样本学习可通过开发能够复现人类行为的智能体来推动机器人技术的发展。例如，单样本模仿（Wu 与 Demir, 2010）、多臂老虎机（Duan

等人, 2017 年)、视觉导航 (Finn 等人, 2017a 年) 以及连续控制 (Yoon 等人, 2018 年)。少样本学习的应用包括图像分类 (Vinyals 等人, 2016 年)、目标跟踪 (Bertinetto 等人, 2016 年)、视觉问答 (Dong 等人, 2018 年)、语言建模 (Vinyals 等人, 2016 年) 和神经架构搜索 (Brock 等人, 2017 年)。少样本学习能够减少数据密集型应用的数据收集工作量。另一个经典的少样本学习场景是, 由于安全或伦理问题, 难以获取带有监督信息的示例 (Altae-Tran 等人, 2017 年)。

基于提示的学习。对于自然语言处理 (NLP), 基于提示的学习建立在直接对文本概率建模的语言模型之上。与传统监督学习训练模型接收输入 x 并预测输出 y 为 $P(y|x)$ 不同, 基于提示的方法使用模板将原始输入 x 修改为带有未填充空白的文本字符串提示 x' , 然后利用语言模型以概率方式将答案 y 填入空白 (Liu 等, 2021)。通过这种方式, 选择适当的提示, 我们可以操控模型预测期望的输出, 有时甚至无需任何额外的任务特定训练 (Brown 等, 2020; Radford 等, 2019; Gao 等, 2020)。其潜在假设是预训练语言模型已从预训练语料库中学习到足够的知识, 我们只需找到提取知识的正确方式。然而, 在强化学习 (RL) 设置中, 我们并不拥有足够大且通用的预训练语料库来覆盖不同的环境和任务。因此, 本文提出以不同方式使用提示。强化学习智能体不是利用提示从预训练模型中提取知识, 而是被要求模仿提供的轨迹提示, 从而能够重现生成这些轨迹的策略。

3. 预备知识

3.1. 在线与离线元强化学习

强化学习 (RL) 问题是一个序贯决策问题, 其中学习智能体与环境交互并优化其控制策略以获得最优值。动态环境中的每个序贯决策任务通常被建模为马尔可夫决策过程 (MDP) (Sutton 和 Barto, 2018), 由一个元组 $\mathcal{M} = (\mathcal{S}, \mathcal{A}, P, R, \mu)$ 表示, 其中 $\mathcal{S}$ 表示, 其中 $\mathcal{A}$ 是状态空间和动作空间。 $P: \mathcal{S} \times \mathcal{A} \times \mathcal{S} \rightarrow \mathbb{R}$ 是转移模型, $P(s, a, s')$ 是在状态 s 中采取动作 a 到达状态 s' 的概率。 μ 是初始状态分布。在每一步, 强化学习智能体基于当前状态 s 采取动作 a 与环境交互, 从环境中观察奖励 r 和产生的下一状态 s' 。序贯决策任务的目标是找到一个策略 $\pi: \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}$, 以优化期望

cumulative rewards, $\mathbb{E}_{s_0 \sim \mu, \pi} \sum_t \gamma^t R(s_t)$ 。

通常, 强化学习是在线进行的, 智能体迭代地采取动作并从环境中接收反馈。然而, 这并不总是可行的, 因为强化学习算法通常样本效率较低, 可能需要大量的训练数据。这使得在线环境中的训练耗时较长。在一些现实世界中的安全关键环境中, 在训练阶段在线部署智能体可能会导致灾难性的失败。本文考虑离线强化学习设置 (Levine 等人, 2020), 其目标是从预先使用 (可能未知的) 行为策略收集的数据中学习策略。在此设置中, 智能体可以访问包含一组轨迹的数据集 $\mathcal{D}$ 。轨迹

$\{s_0, a_0, r_0, s_1, a_1, r_1, \dots, s_T, a_T, r_T\}$ 是在环境中使用行为策略采样得到的。期望智能体仅使用数据集 $\mathcal{D}$ 找到最优策略, 而不与环境本身交互。

在线和离线强化学习设置最初都是为了在单一任务中找到最优策略而提出的。如果设计的学习智能体能够在少数任务上学习后, 利用少量新收集的数据适应相似任务, 则可以进一步提高强化学习的效率, 这主要在元强化学习 (Finn 等人, 2017a) 下发展。最近, 元强化学习已扩展到离线设置, 旨在通过预先收集的数据快速适应新任务。在 Mitchell 等人 (2021) 提出的离线元强化学习设置中, 智能体被给予一组任务 $\mathcal{T}$, 其中任务 $\mathcal{T}_i \in \mathcal{T}$ 定义为 $(\mathcal{M}_i, \pi_i)$, 包含一个马尔可夫决策过程 $\mathcal{M}_i$ 和一个行为策略 π_i 。对于每个任务 $\mathcal{T}_i$, 智能体被提供一个数据集 $\mathcal{D}_i$, 其中包含使用 π_i 采样的轨迹。智能体使用训练任务子集 $\mathcal{T}^{train}$ 进行训练, 并期望在一组测试任务 $\mathcal{T}^{test}$ 中找到最优策略, 该测试任务集与 $\mathcal{T}^{train}$ 不相交。

3.2. 决策 Transformer

Transformer 在自然语言处理 (NLP) (Devlin 等, 2018) 和计算机视觉 (Carion 等, 2020) 领域已被广泛研究, 并展现出优于基于循环神经网络 (RNN) 架构的性能。由于其建模长序列数据的高效性和可扩展性, 近期被应用于解决强化学习 (RL) 问题。用于离线强化学习的决策 Transformer (Decision Transformer) (Chen 等, 2021) 将策略学习视为序列建模问题。它提出用不同时间步收集的状态 s_t 、动作 a_t 和回报至终 (reward-to-go) $\hat{r}_t$ 元组来建模轨迹 t 。回报至终是从当前时间步到回合结束的累积奖励。这种新颖的表示不包含单步奖励 r_t , 有助于引导动作选择以优化回报。在时间步 t , 决策 Transformer 以自回归方式输入轨迹序列 τ , 该序列包含最近 K 步历史。

$$\tau = (\hat{r}_{t-K+1}, s_{t-K+1}, a_{t-K+1}, \dots, \hat{r}_t, s_t, a_t). \quad (1)$$




图 1. 用于少样本策略泛化的 Prompt-DT。左侧展示了每个任务 $\mathcal{T}_i \in \mathcal{T}^{train} \cup \mathcal{T}^{test}$ 的少样本演示数据集 $\mathcal{P}_i$ 。轨迹提示被定义为从 $\mathcal{P}_i$ 中存储的多个回合中采样的长度为 K^* 的轨迹序列。在预训练和少样本评估中，Prompt-DT 同时接收轨迹提示增强和最近 K 步历史作为输入，并自回归地输出与输入序列中每个状态对应的动作。

当使用离线收集的数据进行训练时， $\hat{r}_t = \sum_{i=t}^T r_i$ 。在测试期间， $\hat{r}_t = G^* - \sum_{i=0}^t r_i$ 其中 G^* 是一个回合的目标总回报。每条轨迹 τ 对应于标准 Transformer 模型中的 $3K$ 个标记。为了编码序列时间步信息，决策 Transformer 将相同的时间步嵌入与 s_t, a_t 和 $\hat{r}_t$ 的嵌入拼接起来。每个对应于状态标记的头通过最小化均方损失来训练预测动作，当动作空间为连续时。

4. 基于提示的决策 Transformer

本节介绍基于提示的决策 Transformer (Prompt-DT)，这是一种用于少样本策略泛化的新颖 Transformer 架构，如图 1 所示。

4.1. 问题表述

我们将离线小样本强化学习问题形式化为：在一组具有离线数据的任务上训练后，对新任务的小样本策略泛化问题。训练集 $\mathcal{T}^{train}$ 中的每个任务 $\mathcal{T}_i$ 都与一个数据集 $\mathcal{D}_i$ 相关联，该数据集包含由未知行为策略 π_i 预先收集的轨迹。与离线元强化学习不同，后者使用任务特定的离线数据或在线交互来更新模型权重，我们希望在无需微调或梯度更新的情况下实现泛化，从而保持高效率并避免因参数偏移导致的灾难性遗忘。

为了在强化学习背景下实现小样本学习，我们假设存在一个数据集 $\mathcal{P}_i$ ，其中包含每个任务 $\mathcal{T}_i \in \mathcal{T}^{train} \cup \mathcal{T}^{test}$ 的小样本演示。对于训练任务 $\mathcal{T}_i \in \mathcal{T}^{train}$ ，我们令 $\mathcal{P}_i$ 为离线数据集 $\mathcal{D}_i$ 的一个子集；对于测试任务 $\mathcal{T}_i \in \mathcal{T}^{test}$ ，该子集可以由人类实验者或行为策略获得。在这项工作中，我们希望设计一种架构，能够直接提取存储在演示数据集 $\mathcal{P}_i$ 中的任务特定信息，并利用这些信息来指导策略生成。

4.2. 提示表示

在自然语言处理任务中，包含任务特定指令的文本提示使大型变换器模型无需改变模型参数即可生成答案。在强化学习背景下，最近引入了可作为提示的文本描述来解决雅达利视频游戏和多模态家庭任务 (Shridhar 等, 2020)。此类文本描述通常需要预定义的语言模板，并且可能需要大量人工标注。

相反，我们将强化学习的轨迹提示定义为一个由若干轨迹片段组成的序列。每个轨迹片段包含多个状态 s^* 、动作 a^* 和奖励至 go $\hat{r}^*$ 元组 $(s^*, a^*, \hat{r}^*)$ ，遵循决策变换器中的轨迹表示。每个带有上标 $*$ 的元素都与轨迹提示相关联。由于每个顺序决策任务 $\mathcal{T}_i$ 都可以建模为马尔可夫决策过程 $\mathcal{M}_i$ ，轨迹提示可以通过隐式捕获转移模型和奖励函数来存储部分到完整的任务指定信息。与文本提示相比，轨迹提示相对容易获得，只需从小样本演示数据集 $\mathcal{P}_i$ 中直接采样轨迹片段即可。形式上，我们将任务 $\mathcal{T}_i$ 的轨迹提示 τ_i^* 定义为

$$\tau_i^* = (\hat{r}_1^*, s_1^*, a_1^*, \hat{r}_2^*, s_2^*, a_2^*, \dots, \hat{r}_{K^*}^*, s_{K^*}^*, a_{K^*}^*). \quad (2)$$

K^* 是提示中存储的环境步数。

请注意，我们选择的 K^* 远短于任务的时间跨度。因此，轨迹提示仅包含帮助识别任务所需的信息，但不足以供智能体模仿。

4.3. Prompt-DT 架构

我们的 Prompt-DT 架构建立在决策 Transformer (Decision Transformer) 之上，通过提示增强的序列建模问题来解决离线少样本强化学习问题。所提出的轨迹提示允许对决策 Transformer 进行最小的架构更改，以实现

Algorithm 1 Prompt-DT Training

Input: training tasks $\mathcal{T}^{train}$, causal Transformer $Transformer_\theta$, training iterations N , offline dataset $\mathcal{D}$, demonstrations $\mathcal{P}$, per-task batch size M , learning rate α

for $n = 1$ **to** N **do**

for Each task $\mathcal{T}_i \in \mathcal{T}^{train}$ **do**

for $m = 1$ **to** M **do**

 Sample a trajectory $\tau_{i,m}$ of length K from $\mathcal{D}_i$

 Sample a prompt $\tau_{i,m}^* = GetPrompt(\mathcal{T}_i, \mathcal{P}_i)$

 Get input $\tau_{i,m}^{input} = (\tau_{i,m}^*, \tau_{i,m})$

end for

 Get a minibatch $\mathcal{B}_i^M = \{\tau_{i,m}^{input}\}_{m=1}^M$

end for

 Get a batch $\mathcal{B} = \{\mathcal{B}_i^M\}_{i=1}^{|\mathcal{T}^{train}|}$, $T^{train} = |\mathcal{T}^{train}|$

$a^{pred} = Transformer_\theta(\tau^{input}), \forall \tau^{input} \in \mathcal{B}$

$\mathcal{L}_{MSE} = \frac{1}{|\mathcal{B}|} \sum_{\tau^{input} \in \mathcal{B}} (a - a^{pred})^2$

$\theta \leftarrow \theta - \alpha \nabla_\theta \mathcal{L}_{MSE}$

 Prompt-DT Few-Shot Evaluation along training

end for

Algorithm 2 Trajectory Prompt Generation (*GetPrompt*)

Input: task $\mathcal{T}$, task-specific demonstrations $\mathcal{P}$, sample episode J , segmentation length H

Sample J episodes from $\mathcal{P}$

Sample segments τ_j^* of length H , $\forall j \in [J]$ (Equation 4)

Return: trajectory prompt $\tau^* = (\tau_1^*, \dots, \tau_J^*)$

Algorithm 3 Prompt-DT Few-Shot Evaluation

Input: test tasks $\mathcal{T}^{test}$, $Transformer_\theta$, demonstrations $\mathcal{P}$, target return G^* , episode length T

for Each task $\mathcal{T}_i \in \mathcal{T}^{test}$ **do**

 Initialize history τ with zeros, desired reward $g = G_i^*$

 Sample a prompt $\tau^* = GetPrompt(\mathcal{T}_i, \mathcal{P}_i)$

for $t \leq T$ **do**

 Get action $a = Transformer_\theta((\tau^*, \tau))[-1]$

 Step env. and get feedback $s, a, r, g \leftarrow g - r$

 Append $[s, a, g]$ to recent history τ

end for

end for

泛化。对于每个任务 $\mathcal{T}_i$ ，Prompt-DT 将 τ^{input} 作为输入，其中包含从 $\mathcal{P}_i$ 获得的 K^* 步轨迹提示以及从 $\mathcal{D}_i$ 采样的最近 K 步历史。形式上 $\tau^{input} = (\tau_i^*, \tau_i)$ 。由于每个时间步的数据对是一个三元组 $(s, a, \hat{r})$ ，输入序列对应于 Transformer 中的 $3(K^* + K)$ 个标记。Prompt-DT 在与输入序列中状态标记对应的头处自回归地输出 $K^* + K$ 个动作。

在实现中，我们利用随机轨迹提示 τ_i^* ，旨在提高训练稳定性并避免过拟合，如算法 2 所示。任务 $\mathcal{T}_i$ 的随机轨迹提示 τ_i^* 由长度为 H 和 $K^* = JH$ 的 J 个轨迹段组成。

$$\tau_i^* = (\tau_{i,1}^*, \dots, \tau_{i,J}^*), \quad (3)$$

$$\tau_{i,j}^* = (\hat{r}_{i,j,1}^*, s_{i,j,1}^*, a_{i,j,1}^*, \dots, \hat{r}_{i,j,H}^*, s_{i,j,H}^*, a_{i,j,H}^*), \forall j \in [J]. \quad (4)$$

遵循决策 Transformer 的结构，我们利用带有线性层的 GPT 模型来获得标记嵌入，并为对应同一时间步的标记添加相同的位置嵌入。

4.4. 算法

我们在算法 1 和算法 3 中总结了 Prompt-DT 的训练和测试算法。在训练期间，Prompt-DT 最小化预测动作与提示和最近历史中数据动作之间的误差。通过学习存储在轨迹提示中的目标动作，Prompt-DT 被激励提取存储在轨迹中的任务特定信息

提示并与近期历史结合以进行未来动作预测。在连续设置中，提示决策转换器通过梯度下降最小化均方损失。在每个训练步骤中，我们采样一个批次 $\mathcal{B}$ ，其中包含每个训练任务的提示-历史对。我们的批次 $\mathcal{B}$ 并非对来自单个训练任务的数据批次迭代进行梯度更新，而是通过聚合 $\mathcal{T}^{train}$ 中所有任务的梯度估计来帮助稳定训练。

在测试时，我们假设离线预训练的提示决策转换器可以与 $\mathcal{T}^{test}$ 中每个评估任务的模拟器交互。这种在线评估假设类似于已训练强化学习智能体的实际部署。我们基于任务 $\mathcal{T}_i \in \mathcal{T}^{test}$ 的演示集 $\mathcal{P}_i$ 采样一个随机轨迹提示，与训练过程类似。然后，提示决策转换器以提示和近期上下文作为输入生成动作。在每个回合开始时，我们为提示决策转换器的预测初始化一个全零的近期历史 τ ，并用流式收集的数据更新它。

5. 实验

我们进行实验以测试所提出的提示决策转换器的少样本泛化能力，度量指标为回合累积奖励。我们旨在通过实验回答以下问题：1) 提示决策转换器能否实现少样本策略泛化？2) 提示的数量和质量如何影响少样本泛化能力？3) 提示决策转换器能否泛化到分布外任务？

5.1. 环境与数据集

我们在五个元强化学习控制任务中进行评估，描述如下（Finn 等人，2017a；Rothfuss 等人，2018；Mitchell 等人，2021；Yu 等人，2020a；Todorov 等人，2012）。




图 2. 在未见过的任务中，Prompt-DT、基于提示的行为克隆（Prompt-MT-BC）、多任务离线强化学习（MT-ORL）、多任务行为克隆（MT-BC-Finetune）以及带优势加权的元演员评论家（MACAW）的回合累积回报。所有方法均使用相同的专家数据集 $\mathcal{D}$ 进行训练。每个图使用三个随机种子运行。Prompt-DT 和 Prompt-MT-BC 拥有包含专家演示的少样本数据集 $\mathcal{P}$ 。Cheetah-dir、Cheetah-vel 和 Ant-dir 的提示长度为 $K^* = 5$ 。Dial 的提示长度为 $K^* = 15$ 。Meta-World reach-v2 的提示长度为 $K^* = 2$ 。MT-BC-Finetune 和 MACAW 在测试时使用与提示长度等量的数据进行微调。虚线表示 Mitchell 等人（2021）报告的 MACAW 最优性能。包括 Prompt-DT 和 Prompt-MT-BC 在内的提示增强方法在具有短轨迹提示的环境中均优于基线。

- **Cheetah-dir。**Cheetah-dir 中有两个任务，目标方向分别为向前和向后。猎豹智能体因沿目标方向的高速而获得奖励。训练集和测试集相同，均包含这两个任务。

- **Cheetah-vel。**Cheetah-vel 中有 40 个任务，具有不同的目标速度。目标速度从区间 $[0, 3]$ 中均匀采样。智能体因与目标速度的 l_2 误差而受到惩罚。我们保留 5 个任务构建测试集，并使用其余 35 个任务进行训练。

- **Ant-dir。**Ant-dir 中有 50 个任务，目标方向在二维空间中均匀采样。8 关节蚂蚁因沿目标方向的高速而获得奖励。我们采样 5 个任务用于测试，其余用于训练。

- **Dial。**在 Dial 中，任务是控制一个 6 自由度 Jaco 机器人到达数字键盘上的目标数字。共有 10 个数字对应 10 个任务。我们在 6 个任务上训练，在 4 个任务上测试。Dial 比 Meta-World reach-v2 更复杂，因为它直接控制 6 个关节。

- **Meta-World reach-v2。**在 Meta-World reach-v2 中，任务是控制 Sawyer 机器人末端执行器到达三维空间中的目标位置。智能体直接控制末端执行器的 XYZ 坐标。每个任务具有不同的目标位置。我们在 15 个任务上训练，在 5 个任务上测试。

Cheetah-dir、Cheetah-vel 和 Ant-dir 中的实验严格遵循 Mitchell 等人（2021）的数据集和设置。这三个任务中的智能体均因较大的控制信号而受到惩罚。Cheetah-dir 和 Ant-dir 的数据集包含用于训练 Soft Actor-Critic (Haarnoja 等人, 2018) 强化学习智能体的完整回放缓冲区。Cheetah-vel 的数据集包含使用 TD3 (Fujimoto 等人, 2018) 训练的回放缓冲区，因为其训练稳定性更好。在 Meta-World reach-v2 (Yu 等人, 2020a) 和 Dial (Shiarlis 等人, 2018) 中，我们使用两个环境中提供的脚本专家策略收集专家轨迹。

5.2. 基线

我们将 Prompt-DT 的少样本泛化能力与四个基线进行比较，包括 Prompt-DT 的三个变体和一个最先进的离线元强化学习算法。

- **多任务离线强化学习 (MT-ORL)**。我们训练一个决策 Transformer 来学习训练集中的多个任务。我们省略 Prompt-DT 中的提示增强来构建 MT-ORL，并保持其余 MT-ORL 训练过程与 Prompt-DT 相同。在评估中，将奖励目标输入 Transformer 模型以提供部分任务特定信息。MT-ORL 有助于消融提示的效果。

- **基于提示的行为克隆 (Prompt-MT-BC)**。我们在训练和评估中省略了存储在历史输入中的 Prompt-DT 奖励目标标记。该 Prompt-MT-BC 基线仅在轨迹提示中保留任务特定信息。Prompt-MT-BC 有助于展示奖励目标标记的效果。

- **多任务行为克隆 (MT-BC-Finetune)**。在 MT-BC-Finetune 基线中，我们排除了提示增强和奖励目标 (reward-to-go) 标记。为适应目标任务，我们利用目标任务中收集的数据，通过微调梯度步骤更新决策 Transformer 模型。MT-BC-Finetune 有助于展示与微调相比，提示和奖励目标标记的效果。

- **元演员评论家与优势加权 (MACAW)**。MACAW 是一种离线元强化学习算法，融合了元学习与离策略基于价值算法的优势。MACAW 具有较高的样本效率，在猎豹方向、猎豹速度和蚂蚁方向任务中优于多种微调适应基线 (Mitchell 等, 2021)。

6. 讨论

6.1. Prompt-DT 能否实现少样本策略泛化？

本文比较了提示决策转换器 (Prompt-DT) 与基线方法的少样本泛化能力，以探究提示是否有助于少样本泛化、提示是否比奖励编码了更充分的任务特定信息，以及提示增强方法是否比微调方法更具数据效率。本文利用 $\mathcal{T}^{test}$ 中的平均回合累积奖励来衡量不同方法的泛化能力。结果如图 2 所示，展示了不同算法在训练过程中的少样本评估性能。

图 2 中的所有方法在每个环境中均使用相同的专家数据集进行训练。对于 Cheetah-dir、Cheetah-vel 和 Ant-dir，我们为每个任务选择完整回放缓冲区中最后 20,000 步作为专家数据集。Dial 和 Meta-World reach-v2 的专家数据集每个任务包含 200 个回合。Prompt-DT 和 Prompt-MT-BC 利用包含专家演示的少样本数据集 $\mathcal{P}$ ，

这些演示从 $\mathcal{D}$ 中采样，并具有由单个回合中采样片段组成的轨迹提示。为了公平比较，包括 MT-BC-Finetune 和 MACAW 在内的微调方法使用离线专家轨迹来估计微调梯度，并以在线方式进行评估。我们稍后在第 6.2 节讨论演示数据集 $\mathcal{P}$ 数量的影响，在第 6.3 节讨论数据集 $\mathcal{D}$ 和演示数据集 $\mathcal{P}$ 质量的影响。

MT-ORL 与 Prompt-MT-BC 的比较。利用专家数据集 $\mathcal{P}$ 和 $\mathcal{D}$ ，Prompt-DT 在未见任务中通过少样本演示实现了高性能，如图 2 所示。Prompt-DT 在所有环境中均以较大优势持续优于 MT-ORL。Prompt-DT 和 Prompt-MT-BC 在 Cheetah-dir、Cheetah-vel、Ant-dir 和 Meta-World reach-v2 中表现相似。这一观察表明，轨迹提示已经嵌入了足够的信息来完全指定任务。然而，Prompt-DT 在 Dial 中优于 Prompt-MT-BC，这表明存在提示本身不足的环境，而奖励有助于策略泛化。

Prompt-MT-BC 在 Dial 中表现与 MT-ORL 相似，在其他四个环境中以较大优势优于 MT-ORL。可以看出，在大多数情况下，专家轨迹提示增强确实比历史上下文中存储的奖励目标令牌提供了更多任务特定信息。在 Cheetah-dir、Cheetah-vel 和 Ant-dir 中，尽管我们仅通过修改奖励函数（例如，改变目标方向和速度）来构建不同任务，但根据 MT-ORL 的较差表现，直接泛化到具有包含最近奖励记录上下文的新任务仍然困难。相比之下，轨迹提示增强可以提供强大的任务特定信号来指导动作生成。

MACAW 与 MT-BC-Finetune 的比较。在训练过程中，我们对所有算法使用相同的批大小。因此，在相同训练迭代次数（图 2 中的横轴）下，各方法使用的训练数据量相同。在测试过程中，我们为所有方法提供在目标任务中收集的相同数据量，这意味着用于微调的数据量等于每个环境的提示长度。

在除拨号 (Dial) 环境外的所有环境中，基于提示 (Prompt) 的方法收敛到最优性能的速度远快于 MACAW。注意，图 2 中虚线所示的 MACAW 最优性能需要大小为 256 的微调批次。即使适应数据量小得多 (5 对 256)，基于提示的方法在相对复杂的环境（包括猎豹速度 (Cheetah-vel) 和蚂蚁方向 (Ant-dir)）中仍具有比 MACAW 更好的渐近性能，在简单的猎豹方向 (Cheetah-dir) 环境中性能相当。

表 1. 消融实验：提示数量对提示决策 Transformer (Prompt-DT) 少样本泛化能力的影响。我们在三个环境中改变回合数 J 和轨迹片段长度 H 。所有实验均使用包含 $K = 20$ 个时间步的近期历史。每个数值均以 3 个随机种子运行。提示决策 Transformer 仅需少量时间步的专家提示即可实现少样本泛化。

K^*	J	H	Cheetah-dir	Cheetah-vel	Ant-dir
2	1	2	926.46 $\pm$ 2.87	-45.26 $\pm$ 2.87	409.81 $\pm$ 9.69
5	1	5	927.20 $\pm$ 18.02	-37.92 $\pm$ 4.56	367.12 $\pm$ 10.50
10	1	10	925.00 $\pm$ 1.41	-38.43 $\pm$ 2.14	382.94 $\pm$ 25.21
40	2	20	926.87 $\pm$ 9.30	-34.43 $\pm$ 2.33	323.83 $\pm$ 9.33

在所有环境中，基于提示的方法始终优于 MT-BC 微调。此外，在相同的微调数据量和微调步数下，MT-BC 微调的表现不如 MACAW。我们推测这是由于变换器（Transformer）对数据的需求较大，其模型参数远多于 MACAW 的演员和评论家网络。我们在第 C.2 节和第 C.3 节中提供了进一步的消融研究，以展示基于微调的算法在不同微调数据量和微调步数下的性能。

6.2. 提示数量是否影响少样本泛化能力？

在实际应用中，每个测试任务可能仅有有限数量的高质量演示，或者演示中可能包含质量参差不齐的轨迹。本文通过消融实验揭示轨迹提示数量对少样本泛化能力的影响。表 1 总结了在三个环境中使用专家数据集 $\mathcal{D}$ 和专家演示 $\mathcal{P}$ 的消融结果。通过改变轨迹片段数量 J 和片段长度 H 来调整提示数量 K^* 。

在 Cheetah-dir 任务中，Prompt-DT 在不同提示长度下均取得了相似的高性能，即使提示仅包含两个时间步。这表明，通过在 Cheetah-dir 的两个任务上进行训练，Prompt-DT 学会了利用历史上下文 τ 快速奔跑，这是一项跨任务共享的通用技能，并提取存储在 $(s, a, \hat{r})$ 对中的目标方向信息来生成动作。在 Cheetah-vel 任务中，参数为 $K^* = 40, J = 2, H = 20$ 的轨迹提示在未见过的任务集上取得了最高的回合回报。增加提示长度 K^* 并未显著提升泛化性能。即使使用仅含两个时间步的短轨迹提示，Prompt-DT 仍能取得优于其他基线的性能。在 Ant-dir 任务中，Prompt-DT 使用两个时间步的提示取得了最高性能。我们推测，Ant-dir 数据集中非专家回合（具有负

回报）的存在降低了由多条轨迹构建的提示的有效性。

我们的实验表明，使用从专家演示中采样的轨迹提示时，Prompt-DT 对提示数量不敏感，即使提示仅包含少量时间步，也能成功提取任务特定信息。这表明，在当前 MuJoCo 控制设置下，轨迹提示中的顺序信息对于揭示独特的任务特定奖励信息并非至关重要。然而，我们推测，若在更复杂的任务集上进行测试，例如包含需要顺序工具操作任务的 Meta-world，提示中存储的顺序信息将变得更加关键。

6.3. 提示质量是否影响少样本泛化能力？

存在目标任务的专家演示不可用的情况，尤其是当目标测试任务 $\mathcal{T}$ 本身由于模型不确定性（例如控制任务中的不确定动态参数）而未被完全刻画时。因此，研究提示质量如何影响泛化能力至关重要。我们在 Cheetah-vel 任务中进行了消融实验，构建了专家、中等和随机数据集 $\mathcal{D}'$ ，分别对应训练强化学习智能体过程中收集的完整回放缓冲区中的最后、中间和前 500 条轨迹。我们还相应地从 $\mathcal{D}'$ 中采样了专家、中等和随机少样本演示 $\mathcal{P}'$ 。我们在图 3 中总结了消融实验结果。

Prompt-DT 在使用专家数据进行训练时，能够根据给定的轨迹提示调整其生成的动作。例如，Prompt-DT 在随机轨迹提示下获得较低的回合回报，而在专家或中等提示下则表现出高性能。类似地，在使用中等数据进行训练时，Prompt-DT 的回报在随机提示下大幅下降，在专家提示下略有上升，这验证了提示质量的影响。然而，在使用随机数据进行训练时，仅向 Prompt-DT 提供专家或中等轨迹提示并不能提升其泛化能力。这一观察结果可能源于随机训练数据集中任务状态分布的高度重叠，从而削弱了提示的作用，并促使 Prompt-DT 去匹配普遍共享的随机状态分布。

6.4. 提示决策转换器能否泛化到分布外场景通过少样本演示完成任务？

在之前的讨论中，我们遵循 MACAW (Mitchell 等人, 2021) 的实验设置，在大量训练任务上进行训练，并在少数留出任务上进行评估。留出任务的目标（目标速度或目标方向）位于训练任务校准的目标范围内。我们希望测试轨迹提示是否能够




图 3. 消融实验：提示质量对 Prompt-DT 少样本泛化能力的影响。我们在每个图中使用相同质量的数据集和演示来训练 Prompt-DT。左、中、右图分别对应在 Cheetah-vel 中收集的专家、中等和随机数据集。每个图使用 2 个随机种子运行。在测试 Prompt-DT 的少样本泛化能力时，我们向其提供不同质量的轨迹提示。结果表明，Prompt-DT 试图生成与提示质量相匹配的策略，并且训练数据集的质量也会影响 Prompt-DT 的少样本泛化能力。




图 4. 在蚂蚁方向 (Ant-dir) 任务中，目标超出训练任务目标范围的新任务上的回合累积回报。每个图均使用 3 个随机种子运行。提示多任务行为克隆 (Prompt-MT-BC) 获得了最高奖励，并以显著优势超越了未使用轨迹提示的基线方法。

处理目标超出训练范围的任务时的外推能力。换言之，我们希望测试分布外任务中的泛化能力。

我们在 Ant-dir 中采样了八个训练任务和三个测试任务，其中两个任务的索引小于最小任务索引，一个大于最大任务索引。任务索引与期望方向角成正比。我们在图 4 中展示了 Prompt-DT 在没有提示增强的情况下仍然优于基线方法。Prompt-DT 的较大方差可能源于不同测试任务中回合回报的较大方差以及训练任务稀疏性的增加。

7. 结论

在这项工作中，我们提出了基于提示的决策 Transformer (Prompt-based Decision Transformer) 来解决离线少样本强化学习问题。我们通过实验评估了我们的算法，并发现它在多个基准领域中优于最先进的离线元强化学习算法 MACAW

(Mitchell 等人, 2021)。我们还表明，当使用专家数据集训练时，Prompt-DT 对提示长度的变化具有鲁棒性，而对提示中提供的数据质量较为敏感。

据我们所知，这是序列预测模型在离线少样本强化学习设置中的首次应用，该应用基于决策 Transformer (Chen 等人, 2021) 开发。我们的算法实现简单，仅涉及训练一个基于提示的 Transformer，而 MACAW (Mitchell 等人, 2021) 则需要使用演员-评论家算法分别训练策略网络和价值网络。

我们希望这项工作能激发更多关于序列预测模型在强化学习中应用的研究。在未来的工作中，我们考虑设计目标函数来平衡轨迹提示和历史上下文的权重，因为目前我们将提示的长度视为一个超参数，并将基于提示的 Transformer 用于其他强化学习任务，如元模仿学习 (Duan 等人, 2017; Finn 等人, 2017b)。我们还注意到，当使用从专家轨迹中二次采样的提示时，Prompt-DT 和 Prompt-MT-BC 在 Meta-World 的 ML10 基准上无法泛化。这促使未来的工作设计更好的提示和基于提示的算法来解决复杂的组合任务。

致谢。本工作由麻省理工学院-国际商业机器公司沃森人工智能实验室及其成员公司 Nexlore，以及美国国防高级研究计划局机器常识项目支持。本文所呈现的信息、数据或工作还由美国能源部先进能源研究计划署 (ARPA-E) 根据奖项编号 DE-AR0001210 资助。MDX 和 ZD 感谢美国国家自然科学基金会 CAREER CNS-2047454 基金的支持。本文作者的观点和意见不一定代表美国政府或其任何机构的立场或反映其观点。

参考文献

- Altae-Tran, H., Ramsundar, B., Pappu, A. S., and Pande, V. Low data drug discovery with one-shot learning. *ACS central science*, 3(4):283–293, 2017.
- Bertinetto, L., Henriques, J. F., Valmadre, J., Torr, P., and Vedaldi, A. Learning feed-forward one-shot learners. In *Advances in neural information processing systems*, pp. 523–531, 2016.
- Brock, A., Lim, T., Ritchie, J. M., and Weston, N. Smash: one-shot model architecture search through hypernetworks. *arXiv preprint arXiv:1708.05344*, 2017.
- Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., et al. Language models are few-shot learners. *arXiv preprint arXiv:2005.14165*, 2020.
- Carion, N., Massa, F., Synnaeve, G., Usunier, N., Kirillov, A., and Zagoruyko, S. End-to-end object detection with transformers. In *European Conference on Computer Vision*, pp. 213–229. Springer, 2020.
- Chen, L., Lu, K., Rajeswaran, A., Lee, K., Grover, A., Laskin, M., Abbeel, P., Srinivas, A., and Mordatch, I. Decision transformer: Reinforcement learning via sequence modeling. *arXiv preprint arXiv:2106.01345*, 2021.
- Devlin, J., Chang, M.-W., Lee, K., and Toutanova, K. Bert: Pre-training of deep bidirectional transformers for language understanding. *arXiv preprint arXiv:1810.04805*, 2018.
- Dong, X., Zhu, L., Zhang, D., Yang, Y., and Wu, F. Fast parameter adaptation for few-shot image captioning and visual question answering. In *Proceedings of the 26th ACM international conference on Multimedia*, pp. 54–62, 2018.
- Duan, Y., Andrychowicz, M., Stadie, B. C., Ho, J., Schneider, J., Sutskever, I., Abbeel, P., and Zaremba, W. One-shot imitation learning. *arXiv preprint arXiv:1703.07326*, 2017.
- Ebert, F., Finn, C., Dasari, S., Xie, A., Lee, A., and Levine, S. Visual foresight: Model-based deep reinforcement learning for vision-based robotic control. *arXiv preprint arXiv:1812.00568*, 2018.
- Finn, C., Abbeel, P., and Levine, S. Model-agnostic meta-learning for fast adaptation of deep networks. In *International Conference on Machine Learning*, pp. 1126–1135. PMLR, 2017a.
- Finn, C., Yu, T., Zhang, T., Abbeel, P., and Levine, S. One-shot visual imitation learning via meta-learning. In *Conference on Robot Learning*, pp. 357–368. PMLR, 2017b.
- Fujimoto, S., Hoof, H., and Meger, D. Addressing function approximation error in actor-critic methods. In *International Conference on Machine Learning*, pp. 1587–1596. PMLR, 2018.
- Furuta, H., Matsuo, Y., and Gu, S. S. Generalized decision transformer for offline hindsight information matching. *arXiv preprint arXiv:2111.10364*, 2021.
- Gao, T., Fisch, A., and Chen, D. Making pre-trained language models better few-shot learners. *arXiv preprint arXiv:2012.15723*, 2020.
- Haarnoja, T., Zhou, A., Abbeel, P., and Levine, S. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In *International conference on machine learning*, pp. 1861–1870. PMLR, 2018.
- Islam, R., Teru, K. K., Sharma, D., and Pineau, J. Off-Policy Policy Gradient Algorithms by Constraining the State Distribution Shift. *arXiv:1911.06970 [cs, stat]*, 2019.
- Janner, M., Li, Q., and Levine, S. Reinforcement learning as one big sequence modeling problem. *arXiv preprint arXiv:2106.02039*, 2021.
- Kahn, G., Abbeel, P., and Levine, S. Badgr: An autonomous self-supervised learning-based navigation system. *IEEE Robotics and Automation Letters*, 6(2):1312–1319, 2021.
- Kalashnikov, D., Irpan, A., Pastor, P., Ibarz, J., Herzog, A., Jang, E., Quillen, D., Holly, E., Kalakrishnan, M., Vanhoucke, V., et al. Scalable deep reinforcement learning for vision-based robotic manipulation. In *Conference on Robot Learning*, pp. 651–673. PMLR, 2018.
- Kidambi, R., Rajeswaran, A., Netrapalli, P., and Joachims, T. MOREL : Model-Based Offline Reinforcement Learning. In *arXiv:2005.05951 [Cs, Stat]*, 2021.
- Kumar, A., Zhou, A., Tucker, G., and Levine, S. Conservative Q-Learning for Offline Reinforcement Learning. *Neural Information Processing Systems*, 2020.
- Levine, S., Kumar, A., Tucker, G., and Fu, J. Offline reinforcement learning: Tutorial, review, and perspectives on open problems. *arXiv preprint arXiv:2005.01643*, 2020.
- Liu, P., Yuan, W., Fu, J., Jiang, Z., Hayashi, H., and Neubig, G. Pre-train, prompt, and predict: A systematic survey of prompting methods in natural language processing. *arXiv preprint arXiv:2107.13586*, 2021.
- Mitchell, E., Rafailov, R., Peng, X. B., Levine, S., and Finn, C. Offline meta-reinforcement learning with advantage weighting. In *International Conference on Machine Learning*, pp. 7780–7791. PMLR, 2021.

- Nichol, A., Achiam, J., and Schulman, J. On First-Order Meta-Learning Algorithms. *arXiv:1803.02999 [cs]*, 2018.
- Peng, X. B., Kumar, A., Zhang, G., and Levine, S. Advantage-weighted regression: Simple and scalable off-policy reinforcement learning. *arXiv preprint arXiv:1910.00177*, 2019.
- Radford, A., Wu, J., Child, R., Luan, D., Amodei, D., Sutskever, I., et al. Language models are unsupervised multitask learners. *OpenAI blog*, 1(8):9, 2019.
- Rajeswaran, A., Finn, C., Kakade, S. M., and Levine, S. Meta-Learning with Implicit Gradients. In Wallach, H., Larochelle, H., Beygelzimer, A., d\textquotesingle Alché-Buc, F., Fox, E., and Garnett, R. (eds.), *Advances in Neural Information Processing Systems 32*, pp. 113–124. Curran Associates, Inc., 2019.
- Rothfuss, J., Lee, D., Clavera, I., Asfour, T., and Abbeel, P. Promp: Proximal meta-policy search. *arXiv preprint arXiv:1810.06784*, 2018.
- Shiarlis, K., Wulfmeier, M., Salter, S., Whiteson, S., and Posner, I. Taco: Learning task decomposition via temporal alignment for control. In *International Conference on Machine Learning*, pp. 4654–4663. PMLR, 2018.
- Shridhar, M., Thomason, J., Gordon, D., Bisk, Y., Han, W., Mottaghi, R., Zettlemoyer, L., and Fox, D. Alfred: A benchmark for interpreting grounded instructions for everyday tasks. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pp. 10740–10749, 2020.
- Sutton, R. S. and Barto, A. G. *Reinforcement Learning: An Introduction*. MIT Press, 2018. ISBN 978-0-262-35270-3.
- Todorov, E., Erez, T., and Tassa, Y. Mujoco: A physics engine for model-based control. In *2012 IEEE/RSJ International Conference on Intelligent Robots and Systems*, pp. 5026–5033. IEEE, 2012.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., and Polosukhin, I. Attention is all you need. In *Advances in neural information processing systems*, pp. 5998–6008, 2017.
- Vinyals, O., Blundell, C., Lillicrap, T., Wierstra, D., et al. Matching networks for one shot learning. *Advances in neural information processing systems*, 29:3630–3638, 2016.
- Wang, Y., Yao, Q., Kwok, J. T., and Ni, L. M. Generalizing from a few examples: A survey on few-shot learning. *ACM Computing Surveys (CSUR)*, 53(3):1–34, 2020.
- Wu, Y. and Demiris, Y. Towards one shot learning by imitation for humanoid robots. In *2010 IEEE International Conference on Robotics and Automation*, pp. 2889–2894. IEEE, 2010.
- Yoon, J., Kim, T., Dia, O., Kim, S., Bengio, Y., and Ahn, S. Bayesian model-agnostic meta-learning. In *Proceedings of the 32nd International Conference on Neural Information Processing Systems*, pp. 7343–7353, 2018.
- Yu, T., Quillen, D., He, Z., Julian, R., Hausman, K., Finn, C., and Levine, S. Meta-world: A benchmark and evaluation for multi-task and meta reinforcement learning. In *Conference on Robot Learning*, pp. 1094–1100. PMLR, 2020a.
- Yu, T., Thomas, G., Yu, L., Ermon, S., Zou, J., Levine, S., Finn, C., and Ma, T. MOPO: Model-based Offline Policy Optimization. *Neural Information Processing Systems*, 2020b.
- Yu, T., Kumar, A., Rafailov, R., Rajeswaran, A., Levine, S., and Finn, C. COMBO: Conservative Offline Model-Based Policy Optimization. *arXiv:2102.08363 [cs]*, 2021.

附录：面向少样本策略泛化的提示决策 Transformer

我们在第 A 节中提供了 Prompt-DT 及基线的超参数，在第 B 节中提供了更多实验细节，在第 C 节中提供了消融研究。

A. 超参数

我们在表 2 和表 3 中展示了 Prompt-DT 及其变体的超参数，在表 4 中展示了 MACAW 的超参数。

表 2. Prompt-DT、Prompt-MT-BC、MT-ORL 和 MT-BC-Finetune 的通用超参数

Hyperparameters	Value
K (length of context τ)	20
training batch size for each task	8
number of evaluation episodes for each task	20
learning rate	1e-4
learning rate decay weight	1e-4
number of layers	3
number of attention heads	1
embedding dimension	128
activation	ReLU

表 3. Prompt-DT 和 Prompt-MT-BC 的环境特定超参数

Environments	Target Reward $S G^*$	Prompt Length K^*
Cheetah-dir	1000	5
Cheetah-vel	0	5
Ant-dir	500	5
Dial	10	15
Meta-World reach-v2	1500	2

表 4. MACAW 超参数 超参数 值 训练内批大小

Hyperparameters	Value
training inner batch size	256
evaluation batch size	prompt length K^*
inner policy learning rate	1e-3
inner value learning rate	1e-3
outer policy learning rate	1e-4
outer value learning rate	1e-5
replay buffer size	20k
inner buffer size	20k
MLP net width	300
MLP net depth	3
activation	tanh
adaptation step	10

B. 实验细节

我们展示了在评估分布内泛化能力时训练集和测试集的任务索引，见表

表 5。换句话说，第 6.1 节、第 6.2 节和第 6.3 节中的实验遵循表 5 中的训练和测试划分。

表 5. 在分布内任务中测试泛化能力时的训练和测试任务索引 Cheetah-dir

Cheetah-dir	
Training set of size 2	[0,1]
Testing set of size 2	[0.1]
Cheetah-vel	
Training set of size 35	[0-1,3-6,8-14,16-22,24-25,27-39]
Testing set of size 5	[2,7,15,23,26]
ant-dir	
Training set of size 45	[0-5,7-16,18-22,24-29,31-40,42-49]
Testing set of size 5	[6,17,23,30,41]
Meta-World reach-v2	
Training set of size 15	[1-5,7,8,10-14,17-19]
Testing set of size 5	[6,9,15,16,20]
Dial	
Training set of size 6	Target pin number: [1,2,3,4,5,8]
Testing set of size 4	Target pin number: [6,7,9,0]

我们还在表 6 中展示了评估分布外泛化能力时的任务索引，该表对应第 6.4 节中的实验。

表 6. 在分布外任务中测试泛化能力时的训练和测试任务索引 ant-dir

ant-dir	
大小为 8 的训练集	[8,13,16,20,22,26,32,37]
大小为 3 的测试集	[1,4,41]

C. 消融实验

在本节中，我们将在 C.1 节中提供关于提示长度的额外消融实验。

C.1. 提示数量的影响

我们展示了在训练过程中使用不同提示数量的评估曲线。Prompt-DT 的训练曲线如图 5 所示，Prompt-MT-BC 的曲线如图 6 所示。两幅图均表明，在 Cheetah-dir、Cheetah-vel 和 Ant-dir 中，基于提示的方法对轨迹提示中存储的片段数量或提示长度不敏感。




图 5. 消融：轨迹提示长度对 Prompt-DT 性能的影响。每个图使用 3 个随机种子运行。




图 6. 消融：轨迹提示长度对 Prompt-MT-BC 性能的影响。每个图使用 3 个随机种子运行。

C.2. 微调数据量对 MT-BC-Finetune 的影响

我们在图 7 中展示了 MT-BC-Finetune 在不同适应批大小下的性能。在微调数据有限的情况下，MT-BC-Finetune 难以适应每个任务。MT-BC-Finetune 在 Cheetah-dir 中适应批大小为 256 时性能方差较大，而在 Cheetah-vel 和 Ant-dir 中方差较小。Cheetah-dir 中的大方差可能源于两个任务中状态分布的不相交，且这两个任务在设计上具有相反的奖励。

注意，在图 7 中，我们使用了 10 个适应步骤。我们注意到，通过 100 个微调步骤和 1280 的适应批大小，MT-BC-Finetune 能够适应测试任务，如表 7 所示。

Environments	Adaptation Batch Size	Finetune Steps	Converged performance
Cheetah-dir	1280	100	930
Cheetah-vel	1280	100	-32
Ant-dir	1280	100	470

表 7. 具有充足适配数据与适配步数的 MT-BC-Finetune 的性能。




图 7. 消融：微调数据量对 MT-BC-Finetune 的影响。MT-BC-Finetune-256 和 MT-BC-Finetune-128 的微调批大小分别为 256 和 128。




图 8. 消融实验：微调数据量对 MACAW 的影响。MACAW-256 和 MACAW-128 的微调批大小分别为 256 和 128。

C.3. 微调数据量对 MACAW 的影响

图 8 展示了 MACAW 在不同适应批大小下的性能。每条曲线包含 10 次微调梯度步骤。随着适应批大小的增加，MACAW 的性能在各环境中持续提升。然而，MACAW-256（适应批大小为 256 的 MACAW）在 Cheetah-dir、Cheetah-vel 和 Ant-dir 中仍不及 Prompt-DT。在 Meta-World reach-v2 中，MACAW-256 的渐近性能与 Prompt-DT 相近，但收敛速度较慢。