

RDT-1B: 面向双手操作任务的扩散基础模型

Songming Liu*, Lingxuan Wu*, Bangguo Li, Hengkai Tan, Huayu Chen,
Zhengyi Wang, Ke Xu, Hang Su[†], Jun Zhu[†]

¹Department of Computer Science & Technology, Institute for AI, BNRist Center,
Tsinghua-Bosch Joint ML Center, THBI Lab, Tsinghua University

摘要

双手操作在机器人技术中至关重要，然而由于协调两条机械臂的固有复杂性（导致多模态动作分布）以及训练数据的稀缺，开发基础模型极具挑战性。本文提出了机器人扩散 Transformer (RDT)，一个面向双手操作的开创性扩散基础模型。RDT 基于扩散模型有效表征多模态特性，并创新性地设计了可扩展的 Transformer 以应对多模态输入的异质性，同时捕捉机器人数据的非线性与高频特征。为解决数据稀缺问题，本文进一步引入物理可解释的统一动作空间，该空间能够统一不同机器人的动作表示，同时保留原始动作的物理含义，从而促进可迁移物理知识的学习。凭借上述设计，本文在迄今规模最大的多机器人数据集上对 RDT 进行了预训练，并将其扩展至 1.2 B 参数，成为机器人操作领域最大的基于扩散的基础模型。最后，本文在自建的包含 6K+ 条轨迹的多任务双手操作数据集上对 RDT 进行微调，以提升其操作能力。在真实机器人上的实验表明，RDT 显著优于现有方法。它能够对未见物体和场景实现零样本泛化，理解并遵循语言指令，仅需 1 ~ 5 次演示即可学习新技能，并能有效处理复杂、灵巧的任务。代码和视频请参见项目主页。

1 引言

双手操作对于机器人完成现实世界任务至关重要 (Edsinger & Kemp, 2007)。对于实际应用而言，一个有用的操作策略应能泛化到未见过的场景，如未见过的物体和环境。然而，当前方法要么依赖于任务特定的原语 (Mirrazavi Salehian et al., 2017; Rakita et al., 2019; Grannen et al., 2023a)，要么局限于小规模模型、数据和简单任务 (Krebs et al., 2021; Franzese et al., 2023; Grannen et al., 2023b; Zhao et al., 2023; Grotz et al., 2024; Liu et al., 2024)，因此仅表现出狭窄的泛化能力，在复杂任务中失败。继自然语言处理 (Achiam et al., 2023; Touvron et al., 2023) 和计算机视觉 (Radford et al., 2021; Kirillov et al., 2023) 的成功之后，实现可泛化行为的一个有前景的方向是通过在大规模数据集上进行模仿学习来开发基础模型。

开发双手操作基础模型面临数据稀缺和架构限制的双重挑战。双臂系统的高昂成本导致严重的数据稀缺 (Sharma et al., 2018; Collaboration et al., 2023)，这与基础模型对数据的大量需求根本冲突。受近期单手操作尝试的启发 (Brohan et al., 2023; Kim et al., 2024)，我们通过跨机器人预训练来缓解这一问题：利用多机器人数据集进行预训练，然后对目标机器人进行微调，将数据量放大三个数量级以提取可迁移的物理先验。然而，出现了两个相互关联的技术障碍。首先，加倍的动作空间导致多模态动作分布 (Li, 2006; Jia et al., 2024) (见图 2b 的示例)，这要求超越当前 * 同等贡献；[†] 通讯作者邮箱 dcszj@tsinghua.edu.cn 的表达能力的提升。




图 1: 十亿参数机器人扩散 Transformer (RDT-1B) 概览, 这是一种用于双手操作的语言条件视觉运动策略, 具有对未见场景的最先进泛化能力 (度量计算细节见附录 H)。

方法 (Zhao 等, 2023; Brohan 等, 2023; Kim 等, 2024), 同时要求可扩展性以在多模态数据 (文本、视觉、动作) 上进行稳定的大规模训练。除架构约束外, 不同机器人之间的物理和动作空间差异引入了数据异质性, 可能导致负迁移 (Pan 和 Yang, 2009)。现有解决方案要么丢弃结构不一致的机器人, 要么仅保留跨机器人不变的特征 (Brohan 等, 2023; Ghosh 等, 2023; Shah 等, 2023a), 牺牲了对泛化至关重要的数据多样性。

本文提出机器人扩散 Transformer (Robotics Diffusion Transformer, RDT), 这是目前最大的具有强泛化能力的双臂操作基础模型。RDT 采用扩散 Transformer (Diffusion Transformer, DiT) 作为其可扩展的主干网络 (Peebles 和 Xie, 2023), 并针对语言条件下的双臂操作进行了专门设计。在表达能力方面, RDT 利用扩散模型表示复杂分布的能力 (Sohn 等, 2015; Ho 等, 2020), 能够从海量数据中出色地捕捉双臂动作的全部模态。在可扩展性方面, 我们利用 Transformer 主干网络并精心设计多模态编码, 以消除各种模态的异质性。此外, 机器人数据与图像和视频存在显著差异, 具有时间和空间连续性 (Chen 等, 2019; Liang 等, 2022)。为了刻画其固有的非线性动力学 (de Wit 等, 2012)、高频变化 (Ghosh 等, 2023) 以及不稳定的数值范围, 我们对原始 DiT 结构进行了重要修改, 包括多层感知机解码、改进的归一化以及条件的交替注入 (其重要性见图 4)。为了进一步使 RDT 能够在异构数据上进行训练, 我们提出了物理可解释的统一动作空间, 这是一种适用于各种带夹臂机器人的统一动作格式。这种创新格式在保留原始动作物理含义的同时, 缓解了不同机器人之间的潜在冲突, 有助于模型在多样化的机器人数据集中学习可泛化的物理知识。

基于上述设计, 我们成功在迄今最大的多机器人数据集集合上预训练了 RDT 模型 (Collaboration et al., 2023; Walke et al., 2023; Fang et al., 2023; Kumar et al., 2024), 并将其规模扩展至 1.2 B 参数, 这是目前最大的基于扩散的机器人操作预训练模型。为进一步增强其双手操作能力, 我们在自采集的多任务双手数据集上对 RDT 进行了微调, 该数据集包含超过 6K+ 条轨迹, 是规模最大的双手数据集之一。在实验中, 我们在双手操作和机器人基础模型两方面对 RDT 与强基线进行了全面评估。结果表明, RDT 达到了最先进的性能, 在众多挑战性任务中成功率提升 56%, 显著优于基线。特别是, RDT 对未见物体、场景、指令乃至技能具有出色的零样本和少样本 ($1 \sim 5$ 次) 泛化能力。RDT 还能完成需要精细操作的任务, 例如用操纵杆控制机器狗。最后, 消融研究表明, 扩散建模、大模型规模和大数据规模均有助于实现卓越性能。




图 2: (a) ALOHA 双臂机器人示意图。(b) 抓取立方体的玩具示例。与单手操作相比，双手操作具有更多可能的动作模式，导致更强的多模态性。颜色从浅到深表示时间向前推进。

2 相关工作

基于学习的双手操作。学习双手操作策略的一个重大挑战是动作空间的高维性，这加剧了数据稀缺 (Zollner et al., 2004; Smith et al., 2012; Lioutikov et al., 2016; Stepputtis et al., 2022) 和多模态行为问题 (Colom'e & Torras, 2018; 2020; Figueroa & Billard, 2017; Sharma et al., 2018; Xie et al., 2020; Franzese et al., 2023)。一些工作开发了更具成本效益的数据采集接口 (Zhao et al., 2023; Aldaco et al., 2024)，但它们仅限于特定硬件配置，仍不足以弥合可泛化策略的数据差距。其他工作尝试通过引入归纳偏置来降低数据需求，例如区分双臂的稳定与功能作用 (Grannen et al., 2023b)、参数化运动基元 (Batinica et al., 2017; Amadio et al., 2019; Chitnis et al., 2020; Franzese et al., 2023)，或使用体素表示 (Grotz et al., 2024; Liu et al., 2024)。这些方法采用强先验或简化建模，虽然成功缩减了动作空间，但代价是应用范围缩小，且无法表达双手行为的多模态性 (Pearce et al., 2023)。

面向机器人学的基础模型。基础模型通过在大规模多任务机器人数据集 (Collaboration et al., 2023; Brohan et al., 2022; Fang et al., 2023) 上训练多任务“通才”模型 (Brohan et al., 2022; 2023; Ghosh et al., 2023; Kim et al., 2024)，在实现可泛化行为方面展现出巨大潜力。大多数研究将大型视觉语言模型适配为直接预测动作 (Brohan et al., 2022; Driess et al., 2023; Brohan et al., 2023; Collaboration et al., 2023; Kim et al., 2024)。尽管这些模型展示了对新物体和任务的泛化能力，但在应用于双手操作时，面临量化误差和行为不协调的问题 (Pearce et al., 2023)。这主要归因于它们对动作空间的离散化处理。为提高精度，扩散模型已被用于连续控制 (Ho et al., 2020; Chi et al., 2023; Pearce et al., 2023; Ghosh et al., 2023)。Ghosh et al. (2023) 在 Open X-Embodiment (Collaboration et al., 2023) 数据集的子集 (25 个数据集) 上预训练了一个基于变换器的扩散策略，参数量高达 9300 万。

3 问题表述与挑战

我们首先阐述任务定义并分析所面临的挑战。为在硬件上评估模型，我们选择 ALOHA 双臂机器人作为目标平台，因其是最具代表性的双臂机器人之一，且适合通过遥操作收集人类演示数据 (Zhao 等, 2023; Fu 等, 2024; Aldaco 等, 2024)。图 2a 展示了目标机器人的结构示意图，该机器人由两个带夹爪的机械臂和三台摄像机构成。需指出的是，本文的设置与基础模型适用于任何双臂夹爪机器人。

我们考虑视觉条件下语言引导的双臂操作这一具体任务，该任务在机器人学中具有基础性地位，并在家庭等真实场景中具有重要价值 (Stepputtis 等, 2020; Brohan 等, 2022; Zhao 等, 2023)。形式上，给定语言指令 ℓ ，策略接收观测 $\mathbf{o}_t$ 在时刻 $t \in \mathbb{N}^+$ ；然后产生动作 $\mathbf{a}_t$ 以控制两个机械臂实现 ℓ 所指定的目标。观测表示为一个三元组 $\mathbf{o}_t := (\mathbf{X}_{t-T_{\text{img}}+1:t+1}, \mathbf{z}_t, c)$ ，其中 $\mathbf{X}_{t-T_{\text{img}}+1:t+1} := (\mathbf{X}_{t-T_{\text{img}}+1}, \dots, \mathbf{X}_t)$ 是大小为 T_{img} ， $\mathbf{z}_t$ 是机器人的低维本体感觉，并且 c 是控制频率。动作 $\mathbf{a}_t$ 通常是期望本体感觉的一个子集 $\mathbf{z}_{t+1}$ ¹。E.g., $\mathbf{z}_t$ 可能包括时间处的夹爪位置 t ，并且 $\mathbf{a}_t$ 可以是步骤处的目标夹爪位置 $t+1$ 。




图 3: RDT 框架。不同机器人的异构动作空间被嵌入到统一动作空间中, 以支持多机器人训练。输入: 本体感知 z_t 、含噪动作块 $\hat{a}_{t:t+T_a}$ 、控制频率 c 和扩散时间步 k , 作为去噪输入; 图像输入 ($T_{\text{img}} = 2$ 和 $X = \{X^1, X^2, X^3\}$ 表示来自外部、右腕和左腕相机的一组图像) 和语言输入, 作为条件。输出: 去噪后的动作块 $a_{t:t+T_a}$ 。

双手操作中的特定任务通常由多个要素组成: 技能 (例如“抓取”、“擦拭”或“打开”等动词)、对象 (例如“瓶子”、“桌子”或“门”等名词)、场景 (即任务发生的环境) 以及描述技能执行方式的方式 (例如“用左手抓取瓶子”等状语)。当遇到新任务时, 实用的策略需要泛化到任务中未见过的 2 要素, 这对以往的基于规则的方法 (Mirrazavi Salehian 等人, 2017; Rakita 等人, 2019; Grannen 等人, 2023a) 以及受限于小模型、小数据或简单任务的学习方法 (如第 2 节所述) 来说尤其具有挑战性。

我们的目标是通过模仿学习训练一个基础模型策略以实现泛化能力。然而, 由于硬件成本高昂, 特定双臂机器人的可用数据尤其稀缺 (< 10 K 条轨迹), 远未达到训练基础模型的常见要求。为解决这一问题, 我们提出采用预训练和微调流程 (Radford 等人, 2018), 借鉴单手操作领域的最新进展 (Ghosh 等人, 2023; Collaboration 等人, 2023; Kim 等人, 2024), 利用来自多个机器人的数据。通过这种方式, 我们可以将数据规模扩大三个数量级。具体来说, 我们首先在大规模多机器人数据集 $\mathcal{D}_{\text{pre}}$ (主要是单臂) 上预训练模型, 然后在目标机器人的数据集 $\mathcal{D}_{\text{tr}}$ 上进行微调。我们将数据集表示为 $\mathcal{D} = \{(\ell^{(i)}, o_t^{(i)}, a_t^{(i)}) \mid 0 \leq t < T^{(i)}, 1 \leq i \leq N\}$, 其中 $T^{(i)}$ 是第 i 条轨迹的长度, N 是轨迹数量。此外, 值得强调的是, 我们的目标是利用多机器人数据增强模型在双手操作中的泛化能力, 而不是为各种机器人开发跨具身模型。利用多机器人数据开发这样的基础模型面临两个主要挑战:

挑战 1: 如何设计强大的架构? 一个可泛化的基础模型需要一个强大的架构。这一要求包含两个主要方面。首先, 该架构必须具备足够的表达能力, 以捕捉动作分布中的多模态性。图 2b 展示了一个玩具示例, 其中机器人试图抓取一个立方体。我们可以看到, 完成这项任务有多种模式, 与仅控制单个机械臂的单臂操作形成对比。在收集演示时, 人类操作员可能随机选择其中一种模式, 导致收集到的动作数据呈现多模态性。其次, 这种架构需要具备可扩展性。作为基础模型, 它应能有效处理来自不同模态 (文本、图像、动作等) 的异构输入, 同时具备在大规模数据集上稳定训练的可扩展性。

挑战 2: 如何在异构数据上进行训练? 在多机器人数据上进行训练带来了数据异构性的独特挑战。不同机器人的物理结构和动作空间可能存在很大差异。以往的尝试要么局限于具有相似动作空间的机器人子集 (Yang 等人, 2023; Ghosh 等人, 2023; Kim 等人, 2024), 要么仅保留共享相同结构的输入子集

2 未见意味着某个元素未出现在训练数据中。

(Collaboration 等人, 2023; Yang 等人, 2024), 代价是丢失大量信息。如何在此类异构数据上训练模型的问题在很大程度上仍未得到充分解决。

4 机器人扩散 Transformer

我们现在介绍机器人扩散 Transformer (RDT), 如图 3 所示。在第 4.1 节中, 我们提出扩散模型及相应架构以应对挑战 1。在第 4.2 节中, 我们通过提出一种物理可解释的统一动作空间来解决挑战 2, 该空间统一了各种机器人动作空间并支持多机器人预训练。我们还收集了一个全面的多任务双手操作数据集用于微调, 以提升 RDT 的双手操作能力。

4.1 RDT 模型

扩散建模。由于多模态特性, 给定语言指令 ℓ 和观测 $\mathbf{o}_t$, 可能存在多种可能的动作 $\mathbf{a}_t$ 来继续任务。若将策略建模为确定性映射 $(\ell, \mathbf{o}_t) \mapsto \mathbf{a}_t$ 并对训练数据中的 $(\ell, \mathbf{o}_t, \mathbf{a}_t)$ 元组进行回归, 策略将学习动作模式的“平均值”。这可能导致分布外动作, 例如多个模式的算术平均值, 而这些动作可能完全不可行 (Pearce 等, 2023)。相反, 我们选择对连续条件分布 $p(\mathbf{a}_t|\ell, \mathbf{o}_t)$ 进行建模。如第 2 节所述, 在众多方法中, 扩散模型在表达能力和采样质量方面均表现出色, 但采样高维数据 (如图像) 时可能较慢。幸运的是, 在我们的设定中, 这一缺点影响甚微, 因为 $\mathbf{a}_t$ 的维度远低于图像, 仅需极小的采样开销。这使得扩散模型成为策略的理想选择, 正如 Chi 等 (2023) 所述。

然而, 将扩散模型用于机器人任务面临独特挑战, 因为机器人物理量 (即动作和本体感知) 的固有属性与图像/视频数据不同。图像和视频数据虽然维度较高, 但通常表现出一定程度的时间和空间连续性 (Chen 等, 2019; Liang 等, 2022), 帧间变化通常是渐进的。相比之下, 机器人物理量具有非线性动力学特性 (de Wit 等, 2012), 并且可能因物理交互 (如碰撞、约束以及阻尼等材料属性) 而产生高频变化。此外, 这些量还具有不稳定的数值范围, 可能由不可靠传感器引起的极端值所致。这凸显了调整现有扩散模型以有效捕捉机器人数据的不稳定性和非线性的必要性。接下来, 我们将首先阐述扩散公式, 然后介绍我们为这些挑战而设计的架构。

在使用扩散策略进行决策时, 我们首先采样一个完全噪声的动作 $\mathbf{a}_t^K \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$, 然后执行 $K \in \mathbb{N}^+$ 步去噪, 将其去噪为来自 $p(\mathbf{a}_t|\ell, \mathbf{o}_t)$ 的干净动作样本 $\mathbf{a}_t^0$:

$$\mathbf{a}_t^{k-1} = \frac{\sqrt{\bar{\alpha}^{k-1}}\beta^k}{1 - \bar{\alpha}^k}\mathbf{a}_t^0 + \frac{\sqrt{\bar{\alpha}^k}(1 - \bar{\alpha}^{k-1})}{1 - \bar{\alpha}^k}\mathbf{a}_t^k + \sigma^k\mathbf{z}, \quad k = K, \dots, 1, \quad (1)$$

其中 $\{\alpha^k\}_{k=1}^K, \{\sigma^k\}_{k=1}^K$ 是由噪声调度 (Nichol & Dhariwal, 2021) 预定义的标量系数。此处, $\beta^k := 1 - \alpha^k$, 且 $\bar{\alpha}^{k-1} := \prod_{i=1}^{k-1} \alpha^i, \mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 若 $k > 1$, 否则 $\bar{\alpha}^{k-1} = 1, \mathbf{z} = \mathbf{0}$ 。然而, $\mathbf{a}_t^0$ 在采样完成前难以计算。本文采用可学习的去噪网络 f_θ , 其参数为 θ , 从含噪样本估计干净样本: $\mathbf{a}_t^0 \leftarrow f_\theta(\ell, \mathbf{o}_t, \mathbf{a}_t^k, k)$ 。为训练该网络, 本文最小化以下去噪均方误差 (MSE):

$$\mathcal{L}(\theta) := \text{MSE}\left(\mathbf{a}_t, f_\theta(\ell, \mathbf{o}_t, \sqrt{\bar{\alpha}^k}\mathbf{a}_t + \sqrt{1 - \bar{\alpha}^k}\epsilon, k)\right), \quad (2)$$

其中 $k \sim \text{均匀分布}(\{1, \dots, K\}), \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$, 且 $(\ell, \mathbf{o}_t, \mathbf{a}_t)$ 从训练数据集中采样。后文中,

本文将含噪动作输入记为 $\tilde{\mathbf{a}}_t := \sqrt{\bar{\alpha}^k}\mathbf{a}_t + \sqrt{1 - \bar{\alpha}^k}\epsilon$, 为简洁起见省略 k 的上标。此外, 实践中本文倾向于一次性预测动作序列, 即动作块, 以增强时序一致性 (Chi et al., 2023), 并通过减少任务中的决策次数来缓解误差累积 (Zhao et al., 2023)。具体而言, 本文建模 $p(\mathbf{a}_{t:t+T_a}|\ell, \mathbf{o}_t)$, 其中 $\mathbf{a}_{t:t+T_a} := (\mathbf{a}_t, \dots, \mathbf{a}_{t+T_a-1})$ 为动作块, T_a 表示块大小 (Zhao et al., 2023)。详细讨论见附录 A。

本文现介绍架构设计, 包括多模态输入的编码以及 f_θ 的网络结构, 细节见附录 B。

异构多模态输入的编码。多模态输入的异构性体现在结构上，即各模态的格式和维度数量差异显著，这给多模态训练带来了挑战。为解决此问题，本文将多种模态编码到统一的潜空间中。编码方法如下：

- **低维输入** 是表示机器人物理量的低维向量，包括本体感知、动作块和控制频率。本文使用带傅里叶特征 (Tancik et al., 2020) 的多层感知机 (MLP) 进行编码，可有效捕捉低维空间中的高频变化。
- **图像输入** 具有高维度且包含丰富的空间与语义信息。为提取紧凑表示，本文采用图像-文本对齐的预训练视觉编码器，即 SigLIP (Zhai 等, 2023)。训练期间固定其权重以节省图形处理器内存。
- **语言输入** 长度可变且高度抽象，因其复杂性与歧义性而带来集成挑战。为对其进行编码，本文采用基于变换器 (Transformer) 的预训练语言模型，即 T5-XXL (Raffel 等, 2020)。训练期间同样固定其权重以节省图形处理器内存。


此外，异质性还体现在跨模态与模态内的信息密度上。首先，不同模态在信息容量上存在固有差异（例如，视觉输入通常产生比文本更多的标记）。其次，模态内部存在显著方差，如机器人感知中外部相机捕捉更广阔场景，而腕部相机视野有限（图 3）。这种差异可能导致捷径学习：过度关注外部视图而忽略腕部相机的细节。为促进平衡的多模态集成，本文在编码过程中对各模态实施随机独立掩码，防止对特定输入的过度依赖。

网络结构 f_θ 。本文选择变换器作为可扩展的主干网络 (Bao 等, 2023; Peebles & Xie, 2023)，并针对机器人问题的特点，对扩散变换器 (DiT) 进行以下三项关键修改：


- **QKNorm 与 RMSNorm。**输入机器人物理量的数值范围不稳定，可能导致梯度不稳定和数值溢出等问题，尤其是在训练大型基础模型时。为解决此问题，我们加入 QKNorm (Henry 等人, 2020) 以避免计算注意力时的数值不稳定。此外，我们还注意到，我们的问题可视为时间序列预测任务，而原始 DiTs 中 LayerNorm 的中心化操作可能导致令牌偏移和注意力偏移，从而破坏时间序列的对称性 (Huang 等人, 2024)。因此，我们用不带中心化操作的 RMSNorm (Zhang & Sennrich, 2019) 替换 LayerNorm。图 4a 显示，若无此修改，大规模预训练往往非常不稳定甚至发散。

- **多层感知机解码器。**为提升对非线性机器人动作的逼近能力，本文将最终的线性解码器替换为非线性多层感知机解码器，作为从潜空间映射回物理空间的投影。如图 4b 所示，若无此设计，RDT 无法有效捕捉非线性动力学特性，从而丧失完成需要精细操作的灵巧任务的能力。

- **交替条件注入 (Alternating Condition Injection, ACI)。**在我们的模型中，图像和语言输入作为条件，具有高维且长度可变的特点，这与传统扩散变换器 (DiT) (Peebles & Xie, 2023) 中的类别标签条件形成对比。这些信息丰富的条件难以压缩为单个标记，使得原有的自适应层归一化方法不再适用。因此，我们采用交叉注意力来适应不同长度的条件，避免进一步压缩造成的信息损失。此外，我们进一步分析发现，由于图像标记通常远多于文本标记，同时注入两种模态往往会掩盖文本相关信息，从而削弱指令遵循能力 (定量结果见图 4b)。为了



(a) Loss w/o QKN & RMSN



(b) Task w/o MLP or ACI

图 4: (a) 未使用 QKNorm 与 RMSNorm 时训练过程中的不稳定损失曲线。(b) RDT (无多层感知机解码器或无自适应条件注入) 在机器狗 (直行子任务) 和倒水-L-1/3 (正确水量子任务) 任务中的成功率。任务定义见图 5。由于资源限制，本实验中所有模型均未进行预训练。

为缓解这一问题，本文策略性地在连续层的交叉注意力中交替注入图像与文本令牌，而非在每一层同时注入两者。

4.2 数据

异构多机器人数据上的训练。为了在异构多机器人数据上进行训练，我们需要一个在各种机器人之间共享的统一动作空间，为多机器人动作提供统一的格式。从机器人原始动作空间到统一动作空间的映射应具有物理可解释性，且空间的每个维度都应具有明确的物理含义。这可以促使模型从不同机器人数据中学习共享的物理规律，从而提高从不同机器人数据中学习的效率（Shah et al., 2023a）。

该空间的设计包括两个步骤。首先，对于每个机器人，我们可以使用单一空间来同时容纳其本体感知 z_t 和动作 a_t 。这是因为 a_t 通常是期望 z_{t+1} 的子集（de Wit et al., 2012; Kouvaritakis & Cannon, 2016），因此 z_t 的空间自然包含 a_t 的空间。其次，我们设计一个统一空间，涵盖大多数带夹爪臂机器人的所有主要物理量。如图 3 左侧所示，我们将机器人的动作空间嵌入到这个统一空间中，根据物理含义将原始动作向量的每个元素填充到统一动作空间向量的相应位置，其余位置进行填充。该空间的具体定义见附录 C。

借助这个统一空间，我们能够在几乎所有现代带夹爪臂机器人的数据上预训练 RDT，并大幅扩展数据规模，以满足基础模型的需求。具体来说，我们收集的预训练数据集包括 46 个不同机器人的数据集，总规模超过 100 万条轨迹和 21TB。更多细节和预处理见附录 D。

收集全面的多任务双手操作数据集。尽管已在规模庞大的数据集上完成预训练，机器人扩散变换器（RDT）仍可能因具身差异而难以零样本泛化至目标双臂机器人。为弥合这一差距，需要在目标机器人上采集多任务双手操作数据集进行微调。大语言模型（Large Language Model）领域的最新进展（Ziegler 等，2019; Brown 等，2020; Touvron 等，2023）表明，高质量的微调数据集对模型性能至关重要。本文从三个方面确保数据集的高质量：（1）在数量方面，采集了 6K+ 条轨迹，使该数据集成为目前规模最大的双手操作数据集之一；（2）在全面性方面，涵盖 300+ 项具有挑战性的任务，覆盖从抓取放置到插拔线缆乃至书写数学方程等大多数操作任务类型；（3）在多样性方面，准备了 100+ 种刚性与非刚性物体，尺寸与纹理各异，并在 15+ 个光照条件不同的房间中采集数据。此外，进一步利用 GPT-4-Turbo（Achiam 等，2023）重写人工标注指令以增加文本多样性。更多信息参见图 6 与附录 E。

5 实验

本文旨在通过真实机器人实验回答以下问题： Q1：RDT 能否零样本泛化至未见物体与场景？

Q2：RDT 对未见模态的零样本指令遵循能力如何？ Q3：RDT 能否促进对未见技能的小样本学习？ Q4：RDT 能否完成需要精细操作的任务？以及 Q5：大模型规模、海量数据与扩散建模是否有助于提升 RDT 的性能？

5.1 实验设置

任务。本文选取 7 项具有挑战性的任务，从不同维度评估 RDT 的泛化能力与性能，包括模型在真实世界任务中可能遇到的复杂场景，如各类未见元素与灵巧操作。各任务维度的示意如表 1 所示，详细定义与可视化见图 5。

数据。本文使用第 4.2 节中的预训练与微调数据集。下面列出微调数据集中与各任务相关的演示数量。洗杯：已见杯子合计 133 条演示，未见杯子 0 条演示；倒水：已见房间合计 350 条演示，未见房间 0 条演示



图 5: 任务定义与可视化。针对 7 项具有挑战性的任务, 我们描述了其语言指令、随机化设置以及各子任务的定义。对于倒水-左-1/3 和倒水-右-2/3, 我们在两幅图像中展示了最终的水位。

房间; 倒水-左-1/3 与倒水-右-2/3: 少量水位 18 个演示, 一半水位 19 个演示, 满水位 19 个演示; 交接: 5 个演示; 叠短裤: 1 个演示; 机器狗: 68 个演示。

模型训练与推理。我们将 RDT 的规模扩展至 1.2 B 参数, 使其成为目前最大的基于扩散的机器人基础模型。该模型在 48 块 H100 80GB GPU 上预训练一个月, 总计 100 万训练迭代步。使用相同 GPU 微调该模型 130K 步需要三天。更多细节 (包括运行平台、设计选择和数据增强技术) 请参见附录 F。为实现实时推理, 我们采用 DPM-Solver++ (Lu 等人, 2022), 这是一种近期提出的扩散模型采样加速器。它可以将采样一个动作块所需的扩散步数从 100 步减少到 5 步, 在目标机器人板载 RTX 4090 24GB GPU 上实现 6 Hz 的动作块推理频率 (每秒动作块数) 和 381 Hz 的平均动作推理频率 (每秒动作数)。

基线。为全面评估 RDT, 我们考虑了机器人基础模型和双手操作中最先进的基线, 包括动作分块变换器

表 1：设计任务时的维度。对于倒水-左-1/3 和倒水-右-2/3，训练指令中仅出现少量、一半（即 1/2）和满水位。对于交接和叠短裤，数据集分别仅包含该技能的 5 个演示和 1 个演示。对于机器狗，需要精细操作，因为推动操纵杆时的微小角度都可能导致机器狗偏离。

任务名称	维度	洗杯 未见物体 (Q1)	倒水 未见场景 (Q1)	倒水-左-1/3 指令遵循 (Q1)	倒水-右-2/3 指令遵循 (Q2)	交接 5 样本学习 (Q3)
因距离过远需要交接	叠短裤 1 样	To wash (Q3) seen and two unseen cups with the faucet	To pour water into the cup in three unseen rooms	To pour water into the cup with the left hand until one-third full	To pour water into the cup with the right hand until two-thirds full	狗直线行走

(ACT) (Zhao 等, 2023)、OpenVLA (Kim 等, 2024) 和 Octo (Ghosh 等, 2023)。ACT 是双臂操作中最先进的方法，使用变分自编码器 (VAE) 对动作分布建模。

OpenVLA 是最大的开源基础模型 (7B)，采用离散化建模。Octo 是基于扩散的基础模型，其最大版本仅有 93M 参数。

度量与硬件。本文采用成功率作为主要度量，即成功试验次数除以总试验次数。洗杯任务对每个杯子测试 8 次（一个已见杯子、两个未见杯子，共 24 次试验）。倒水任务对每个房间测试 8 次（三个未见房间，共 24 次试验）。倒水-左-1/3 和倒水-右-2/3 各测试 8 次。交接、叠短裤和机器狗任务各测试 25 次。所有测试均在 ALOHA 双臂机器人上执行（硬件配置见附录 G）。实验细节（如实现和超参数）在附录 H 中详述。

消融实验。为回答 Q5，本文对模型规模、预训练和建模方法进行了消融实验，以理解其重要性。考虑的变体包括：RDT（本文方法）：原始 RDT。RDT（回归）：无扩散建模的 RDT，建模确定性映射 $(\ell, o_t) \mapsto a_t$ 。RDT（小型）：无大参数的 RDT，仅有 166M 参数。RDT（从头训练）：无预训练的 RDT，在微调时从头训练。表 2 从三个泛化维度评估这些变体。表 7 提供了 RDT 不同变体与基线的比较。

表 2：消融实验结果。表中为原始 RDT 及其三个变体在洗杯（未见杯 2，总成功率）、倒水（未见房间 3，总成功率）和倒水-左-1/3（正确量子任务）任务中的成功率 (%)。除 RDT（从头训练）外，所有模型均在微调前进行了预训练。

VARIANT NAME	UNSEEN OBJECT	UNSEEN SCENE	INSTRUCTION FOLLOWING
RDT (regress)	12.5	50	12.5
RDT (small)	37.5	62.5	25
RDT (scratch)	0	25	62.5
RDT (ours)	50	62.5	100

5.2 结果分析

从表 3 的结果可以看出，RDT 始终优于其他基线方法。这是因为 RDT 采用扩散模型配合强大的网络架构，能够精确建模多模态动作的分布，而离散化和变分自编码器分别缺乏准确性和表达能力。此外，大规模预训练带来的大量参数提供了丰富的先验知识，显著提升了泛化能力。具体分析如下：• Q1 & Q2: RDT 能够零样本泛化到未见过的物体、场景和模态。在洗杯子和倒水任务中，RDT 在未见场景下仍能取得较高的成功率，且性能与已见场景相差不大。相比之下，其他基线方法甚至无法完成整个任务。在倒水-左-1/3 和倒水-右-2/3 任务中，从图 5 或图 10（放大版）的第三行可以看出，RDT 能够准确理解需要操作哪只手以及倒多少水，并通过动作严格遵循指令，即使它从未见过“三分之一”或“三分之二”这样的词汇。正是由于大规模预训练，RDT 接触了大量多样化的物体、场景和指令，从而具备了如此强大的零样本泛化能力。

表 3：定量结果。我们报告了 ACT、OpenVLA、RDT（从头训练，无预训练）和 RDT（本文方法，有预训练）在 7 个任务上的成功率（%）。每个子任务单元格中的子列代表不同的元素（物体、指令、场景）。ACT 不受语言条件控制，因此无法用于指令遵循。RDT（本文方法）始终优于其他方法。

Wash Cup: seen cup 1 unseen cup 1 unseen cup 2 (Unseen Object)																		
	Pick Up Cup			Turn On Faucet			Get Water			Pour Out Water			Place Back Cup			Total		
ACT	50	12.5	37.5	0	0	0	0	0	0	0	0	0	37.5	0	0	0	0	0
OpenVLA	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
Octo	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
RDT (scratch)	37.5	12.5	0	0	12.5	12.5	0	0	0	0	37.5	12.5	0	25	0	0	0	0
RDT (ours)	87.5	87.5	50	62.5	75	50	50	75	50	87.5	75	50	87.5	62.5	50	50	75	50
Pour Water-L-1/3 Pour Water-R-2/3 (Instruction Following)																		
	Pick Up Bottle			Pour Water			Place Back Bottle			Total			Correct Hand			Correct Amount		
OpenVLA	50	0	0	0	0	0	0	0	0	0	0	50	0	0	0	0	0	0
Octo	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
RDT (scratch)	100	75	75	25	25	62.5	25	62.5	25	100	75	62.5	100	75	12.5	100	75	12.5
RDT (ours)	100	87.5	100	87.5	100	87.5	100	87.5	100	87.5	100	87.5	100	87.5	100	87.5	100	75
Pour Water: unseen room 1 unseen room 2 unseen room 3 (Unseen Scene)																Fold Shorts (1-Shot)		
	Pick Up Bottle			Pour Water			Place Back Bottle			Total			-			Total		
ACT	25	87.5	25	0	50	12.5	0	37.5	12.5	0	37.5	12.5	-	-	-	0	0	0
OpenVLA	0	0	0	0	0	0	0	0	0	0	0	0	-	-	-	0	0	0
Octo	50	0	12.5	12.5	0	0	12.5	0	0	12.5	0	0	-	-	-	4	4	4
RDT (scratch)	62.5	100	62.5	25	87.5	37.5	25	75	25	25	75	25	-	-	-	40	40	40
RDT (ours)	62.5	100	62.5	62.5	100	62.5	62.5	100	62.5	62.5	100	62.5	-	-	-	68	68	68
Handover (5-Shot)																Robot Dog (Dexterity)		
	Pick Up		Switch	Drop	Fall into	Total	Grab		Push	Total	Walk							
	Pen	Hand	Pen	Box			Remote	Joystick			Straight							
ACT	44	0	0	0	0	0	88	32	32	32	32							
OpenVLA	0	0	0	0	0	0	84	0	0	0	0							
Octo	12	0	0	0	0	0	100	4	4	0	0							
RDT (scratch)	88	32	24	16	16	16	100	64	64	32	32							
RDT (ours)	100	56	56	40	40	40	100	76	76	48	48							

• **Q3:** RDT 仅需少量样本即可学习新技能。在 Handover 和 Fold Shorts 任务中，RDT 通过小样本学习掌握了交接和折叠等新颖且复杂的技能，其动作模式与已知技能差异显著，而其他方法的成功率几乎为零。这一提升同样得益于大规模预训练。小样本学习有助于 RDT 快速适应新的工作环境，对实际应用具有重要意义。

• **Q4:** RDT 能够处理灵巧操作任务。在 Robot Dog 任务中，RDT 精确控制推动操纵杆的角度，而其他方法导致机器狗偏离目标。这是因为扩散模型结合我们强大的网络架构，能够多模态和非线性动作的分布进行建模，使动作精度满足灵巧任务的要求。我们还注意到，操纵杆和遥控器均为黑色，导致操纵杆在视觉上不明显，这可能是 ACT 失败的原因之一。相比之下，大规模预训练使 RDT 学习到更好的操纵杆概念的视觉-语言表示，从而提升了识别能力。

• **Q5:** 大模型规模、海量数据和扩散模型都是我们取得优异性能的关键因素。在表 2 中，缺少任一因素都会导致性能严重下降，证明了我们贡献的必要性。特别是，RDT（从头训练）在未见过的物体和场景上表现不佳，表明预训练知识对于泛化至关重要。

6 结论

本文通过开发机器人扩散 Transformer (RDT) ——一种基于扩散的基础模型，用于语言条件下的视觉运动模仿学习，解决了可泛化双臂操作中数据稀缺和操作复杂性增加的挑战。我们的模型在大规模多机器人数据集上进行了预训练，并在自采集的双臂数据集上进行了微调。我们进一步引入了物理可解释的统一动作空间，以统一不同机器人之间的动作表示，增强了鲁棒性和可迁移性。RDT 超越了现有方法，不仅在灵巧双臂能力和指令遵循方面表现出显著提升，还在小样本学习以及对未见物体和场景的零样本泛化方面取得了卓越性能。

致谢

本工作得到国家自然科学基金项目（编号：92248303、92370124、62350080、62276149、62061136001、92270001）、北京信息科学与技术国家研究中心（BNR2022RC01006）、清华大学国强研究院以及清华大学高性能计算中心的支持。朱军还获得了科学探索奖的支持。

伦理声明

本研究使用的所有数据均来自开源且文档完善的数据集，我们严格遵守所有适用的许可和使用指南。我们的微调数据集由本文作者及部分志愿者共同收集。

虽然 RDT 是一个为可扩展的、语言条件化的视觉运动策略学习而训练的模型，并在 ALOHA 双臂机器人上进行了测试，但我们强调，任何有害使用我们模型的行为既非我们的意图，也不被鼓励，我们鼓励在真实机器人上进行负责任的部署。

可复现性声明

为复现我们的预训练和微调过程，我们已在代码仓库中提供了代码。我们还在 README 文件中包含了数据集下载说明、训练代码的使用方法以及在真实机器上部署的指南。我们已完全开源所有代码、模型权重和微调数据集。更多信息请参阅项目页面。

预训练数据集详情请参见附录 D，微调数据集详情请参见附录 E，RDT 训练详情请参见附录 F，硬件详情请参见附录 G，实验细节及基线实现请参见附录 H。

参考文献

- TensorFlow Datasets, a collection of ready-to-use datasets. <https://tensorflow.google.cn/datasets>. 23
- Martín Abadi, Ashish Agarwal, Paul Barham, Eugene Brevdo, Zhifeng Chen, Craig Citro, Greg S. Corrado, Andy Davis, Jeffrey Dean, Matthieu Devin, Sanjay Ghemawat, Ian Goodfellow, Andrew Harp, Geoffrey Irving, Michael Isard, Yangqing Jia, Rafal Jozefowicz, Lukasz Kaiser, Manjunath Kudlur, Josh Levenberg, Dandelion Mané, Rajat Monga, Sherry Moore, Derek Murray, Chris Olah, Mike Schuster, Jonathon Shlens, Benoit Steiner, Ilya Sutskever, Kunal Talwar, Paul Tucker, Vincent Vanhoucke, Vijay Vasudevan, Fernanda Viégas, Oriol Vinyals, Pete Warden, Martin Wattenberg, Martin Wicke, Yuan Yu, and Xiaoqiang Zheng. TensorFlow: Large-scale machine learning on heterogeneous systems, 2015. URL <https://www.tensorflow.org/>. Software available from tensorflow.org. 23
- Josh Achiam, Steven Adler, Sandhini Agarwal, Lama Ahmad, Ilge Akkaya, Florencia Leoni Aleman, Diogo Almeida, Janko Altschmidt, Sam Altman, Shyamal Anadkat, et al. Gpt-4 technical report. *arXiv preprint arXiv:2303.08774*, 2023. 1, 7, 21
- Stavros P Adam, Stamatios-Aggelos N Alexandropoulos, Panos M Pardalos, and Michael N Vrahatis. No free lunch theorem: A review. *Approximation and optimization: Algorithms, complexity and applications*, pp. 57–82, 2019. 25
- Jorge Aldaco, Travis Armstrong, Robert Baruch, Jeff Bingham, Sanky Chan, Kenneth Draper, Debidatta Dwibedi, Chelsea Finn, Pete Florence, Spencer Goodrich, et al. Aloha 2: An enhanced low-cost hardware for bimanual teleoperation. *arXiv preprint arXiv:2405.02292*, 2024. 3
- Fabio Amadio, Adrià Colomé, and Carme Torras. Exploiting symmetries in reinforcement learning of bimanual robotic tasks. *IEEE Robotics and Automation Letters*, 4(2):1838–1845, 2019. 3
- Fan Bao, Shen Nie, Kaiwen Xue, Yue Cao, Chongxuan Li, Hang Su, and Jun Zhu. All are worth words: A vit backbone for diffusion models. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pp. 22669–22679, 2023. 6, 19

- Aleksandar Batinica, Bojan Nemec, Aleš Ude, Mirko Raković, and Andrej Gams. Compliant movement primitives in a bimanual setting. In *2017 IEEE-RAS 17th International Conference on Humanoid Robotics (Humanoids)*, pp. 365–371. IEEE, 2017. 3
- Suneel Belkhal, Yuchen Cui, and Dorsa Sadigh. Hydra: Hybrid robot actions for imitation learning. *arxiv*, 2023. 22
- Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Joseph Dabis, Chelsea Finn, Keerthana Gopalakrishnan, Karol Hausman, Alex Herzog, Jasmine Hsu, et al. Rt-1: Robotics transformer for real-world control at scale. *arXiv preprint arXiv:2212.06817*, 2022. 3, 19, 20, 22
- Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Xi Chen, Krzysztof Choromanski, Tianli Ding, Danny Driess, Avinava Dubey, Chelsea Finn, et al. Rt-2: Vision-language-action models transfer web knowledge to robotic control. *arXiv preprint arXiv:2307.15818*, 2023. 1, 2, 3, 19
- Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, et al. Language models are few-shot learners. *Advances in neural information processing systems*, 33:1877–1901, 2020. 7
- Lawrence Yunliang Chen, Simeon Adebola, and Ken Goldberg. Berkeley UR5 demonstration dataset. <https://sites.google.com/view/berkeley-ur5/home>. 22
- Lili Chen, Shikhar Bahl, and Deepak Pathak. Playfusion: Skill acquisition via diffusion from language-annotated play. In *CoRL*, 2023. 22
- Xin Chen, Aming Wu, and Yahong Han. Capturing the spatio-temporal continuity for video semantic segmentation. *IET Image Processing*, 13(14):2813–2820, 2019. 2, 5
- Cheng Chi, Siyuan Feng, Yilun Du, Zhenjia Xu, Eric Cousineau, Benjamin Burchfiel, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. In *Proceedings of Robotics: Science and Systems (RSS)*, 2023. 3, 5, 19, 21, 22
- Rohan Chitnis, Shubham Tulsiani, Saurabh Gupta, and Abhinav Gupta. Efficient bimanual manipulation using learned task schemas. In *2020 IEEE International Conference on Robotics and Automation (ICRA)*, pp. 1149–1155. IEEE, 2020. 3
- Open X-Embodiment Collaboration, Abby O’Neill, Abdul Rehman, Abhiram Maddukuri, Abhishek Gupta, Abhishek Padalkar, Abraham Lee, Acorn Pooley, Agrim Gupta, Ajay Mandlekar, Ajinkya Jain, Albert Tung, Alex Bewley, Alex Herzog, Alex Irpan, Alexander Khazatsky, Anant Rai, Anchit Gupta, Andrew Wang, Andrey Kolobov, Anikait Singh, Animesh Garg, Aniruddha Kembhavi, Annie Xie, Anthony Brohan, Antonin Raffin, Archit Sharma, Arefeh Yavary, Arhan Jain, Ashwin Balakrishna, Ayzaan Wahid, Ben Burgess-Limerick, Beomjoon Kim, Bernhard Schölkopf, Blake Wulfe, Brian Ichter, Cewu Lu, Charles Xu, Charlotte Le, Chelsea Finn, Chen Wang, Chenfeng Xu, Cheng Chi, Chenguang Huang, Christine Chan, Christopher Agia, Chuer Pan, Chuyuan Fu, Coline Devin, Danfei Xu, Daniel Morton, Danny Driess, Daphne Chen, Deepak Pathak, Dhruv Shah, Dieter Buehler, Dinesh Jayaraman, Dmitry Kalashnikov, Dorsa Sadigh, Edward Johns, Ethan Foster, Fangchen Liu, Federico Ceola, Fei Xia, Feiyu Zhao, Felipe Vieira Frujeri, Freek Stulp, Gaoyue Zhou, Gaurav S. Sukhatme, Gautam Salhotra, Ge Yan, Gilbert Feng, Giulio Schiavi, Glen Berseth, Gregory Kahn, Guangwen Yang, Guanzhi Wang, Hao Su, Hao-Shu Fang, Haochen Shi, Henghui Bao, Heni Ben Amor, Henrik I Christensen, Hiroki Furuta, Homer Walke, Hongjie Fang, Huy Ha, Igor Mordatch, Ilija Radosavovic, Isabel Leal, Jacky Liang, Jad Abou-Chakra, Jaehyung Kim, Jaimyn Drake, Jan Peters, Jan Schneider, Jasmine Hsu, Jeannette Bohg, Jeffrey Bingham, Jeffrey Wu, Jensen Gao, Jiaheng Hu, Jiajun Wu, Jialin Wu, Jiankai Sun, Jianlan Luo, Jiayuan Gu, Jie Tan, Jihoon Oh, Jimmy Wu, Jingpei Lu, Jingyun Yang, Jitendra Malik, João Silvério, Joey Hejna, Jonathan Booher, Jonathan Tompson, Jonathan Yang, Jordi Salvador, Joseph J. Lim, Junhyek Han, Kaiyuan Wang, Kanishka Rao, Karl Pertsch, Karol Hausman, Keegan Go, Keerthana Gopalakrishnan, Ken Goldberg, Kendra Byrne, Kenneth Oslund, Kento Kawaharazuka, Kevin Black, Kevin Lin, Kevin Zhang, Kiana Ehsani, Kiran Lekkala, Kirsty Ellis, Krishan Rana, Krishnan Srinivasan, Kuan Fang, Kunal Pratap Singh, Kuo-Hao Zeng, Kyle Hatch, Kyle Hsu, Laurent Itti, Lawrence Yunliang Chen, Lerrel Pinto, Li Fei-Fei, Liam Tan, Linxi ”Jim” Fan, Lionel Ott, Lisa Lee, Luca Weihs, Magnum Chen, Marion Lepert, Marius Memmel, Masayoshi Tomizuka, Masha Itkina,

- Mateo Guaman Castro, Max Spero, Maximilian Du, Michael Ahn, Michael C. Yip, Mingtong Zhang, Mingyu Ding, Minh Heo, Mohan Kumar Srirama, Mohit Sharma, Moo Jin Kim, Naoaki Kanazawa, Nicklas Hansen, Nicolas Heess, Nikhil J Joshi, Niko Suenderhauf, Ning Liu, Norman Di Palo, Nur Muhammad Mahi Shafiullah, Oier Mees, Oliver Kroemer, Osbert Bastani, Pannag R Sanketi, Patrick "Tree" Miller, Patrick Yin, Paul Wohlhart, Peng Xu, Peter David Fagan, Peter Mitrano, Pierre Sermanet, Pieter Abbeel, Priya Sundaresan, Qiuyu Chen, Quan Vuong, Rafael Rafailov, Ran Tian, Ria Doshi, Roberto Mart'in-Mart'in, Rohan Bajjal, Rosario Scalise, Rose Hendrix, Roy Lin, Runjia Qian, Ruohan Zhang, Russell Mendonca, Rutav Shah, Ryan Hoque, Ryan Julian, Samuel Bustamante, Sean Kirmani, Sergey Levine, Shan Lin, Sherry Moore, Shikhar Bahl, Shivin Dass, Shubham Sonawani, Shuran Song, Sichun Xu, Siddhant Halder, Siddharth Karamcheti, Simeon Adebola, Simon Guist, Soroush Nasiriany, Stefan Schaal, Stefan Welker, Stephen Tian, Subramanian Ramamoorthy, Sudeep Dasari, Suneel Belkhale, Sungjae Park, Suraj Nair, Suvir Mirchandani, Takayuki Osa, Tanmay Gupta, Tatsuya Harada, Tatsuya Matsushima, Ted Xiao, Thomas Kollar, Tianhe Yu, Tianli Ding, Todor Davchev, Tony Z. Zhao, Travis Armstrong, Trevor Darrell, Trinity Chung, Vidhi Jain, Vincent Vanhoucke, Wei Zhan, Wenxuan Zhou, Wolfram Burgard, Xi Chen, Xiangyu Chen, Xiaolong Wang, Xinghao Zhu, Xinyang Geng, Xiyuan Liu, Xu Liangwei, Xuanlin Li, Yansong Pang, Yao Lu, Yecheng Jason Ma, Yejin Kim, Yevgen Chebotar, Yifan Zhou, Yifeng Zhu, Yilin Wu, Ying Xu, Yixuan Wang, Yonatan Bisk, Yongqiang Dou, Yoonyoung Cho, Youngwoon Lee, Yuchen Cui, Yue Cao, Yueh-Hua Wu, Yujin Tang, Yuke Zhu, Yunchu Zhang, Yunfan Jiang, Yunshuang Li, Yunzhu Li, Yusuke Iwasawa, Yutaka Matsuo, Zehan Ma, Zhuo Xu, Zichen Jeff Cui, Zichen Zhang, Zipeng Fu, and Zipeng Lin. Open X-Embodiment: Robotic learning datasets and RT-X models. <https://arxiv.org/abs/2310.08864>, 2023. 1, 2, 3, 4, 5, 21, 23
- Adria Colomé and Carme Torras. Dimensionality reduction for dynamic movement primitives and application to bimanual manipulation of clothes. *IEEE Transactions on Robotics*, 34(3):602–615, 2018. 3
- Adrià Colomé and Carme Torras. *Reinforcement learning of bimanual robot skills*. Springer, 2020. 3
- Shivin Dass, Jullian Yapeter, Jesse Zhang, Jiahui Zhang, Karl Pertsch, Stefanos Nikolaidis, and Joseph J. Lim. Clvr jaco play dataset, 2023. URL https://github.com/clvr-ai/clvr_jaco_play_dataset. 22
- Carlos Canudas de Wit, Bruno Siciliano, and Georges Bastin. *Theory of robot control*. Springer Science & Business Media, 2012. 2, 5, 7
- Danny Driess, Fei Xia, Mehdi SM Sajjadi, Corey Lynch, Aakanksha Chowdhery, Brian Ichter, Ayzaan Wahid, Jonathan Tompson, Quan Vuong, Tianhe Yu, et al. Palm-e: An embodied multimodal language model. *arXiv preprint arXiv:2303.03378*, 2023. 3
- Aaron Edsinger and Charles C Kemp. Two arms are better than one: A behavior based control system for assistive bimanual manipulation. In *Recent Progress in Robotics: Viable Robotic Service to Human: An Edition of the Selected Papers from the 13th International Conference on Advanced Robotics*, pp. 345–355. Springer, 2007. 1
- Hao-Shu Fang, Hongjie Fang, Zhenyu Tang, Jirong Liu, Junbo Wang, Haoyi Zhu, and Cewu Lu. Rh20t: A robotic dataset for learning diverse skills in one-shot. In *RSS 2023 Workshop on Learning for Task and Motion Planning*, 2023. 2, 3, 20, 21, 22
- Niko Sünderhauf Federico Ceola, Krishan Rana. Lhmanip: A dataset for long horizon manipulation tasks., 2023. 22
- Yunhai Feng, Nicklas Hansen, Ziyang Xiong, Chandramouli Rajagopalan, and Xiaolong Wang. Finetuning offline world models in the real world. *arXiv preprint arXiv:2310.16029*, 2023. 22
- Nadia Figueroa and Aude Billard. Learning complex manipulation tasks from heterogeneous and unstructured demonstrations. In *Proceedings of Workshop on Synergies between Learning and Interaction*, 2017. 3
- Giovanni Franzese, Leandro de Souza Rosa, Tim Verburg, Luka Peternel, and Jens Kober. Interactive imitation learning of bimanual movement primitives. *IEEE/ASME Transactions on Mechatronics*, 2023. 1, 3

- Zipeng Fu, Tony Z Zhao, and Chelsea Finn. Mobile aloha: Learning bimanual mobile manipulation with low-cost whole-body teleoperation. *arXiv preprint arXiv:2401.02117*, 2024. 3, 21, 22, 24, 25
- Dibya Ghosh, Homer Walke, Karl Pertsch, Kevin Black, Oier Mees, Sudeep Dasari, Joey Hejna, Charles Xu, Jianlan Luo, et al. Octo: An open-source generalist robot policy, 2023. 2, 3, 4, 9, 21, 25
- Jennifer Grannen, Yilin Wu, Suneel Belkhale, and Dorsa Sadigh. Learning bimanual scooping policies for food acquisition. In *Conference on Robot Learning*, pp. 1510–1519. PMLR, 2023a. 1, 4
- Jennifer Grannen, Yilin Wu, Brandon Vu, and Dorsa Sadigh. Stabilize to act: Learning to coordinate for bimanual manipulation. In *Conference on Robot Learning*, pp. 563–576. PMLR, 2023b. 1, 3
- Markus Grotz, Mohit Shridhar, Tamim Asfour, and Dieter Fox. Peract2: A perceiver actor framework for bimanual manipulation tasks. *arXiv preprint arXiv:2407.00278*, 2024. 1, 3
- Jiayuan Gu, Fanbo Xiang, Xuanlin Li, Zhan Ling, Xiqiang Liu, Tongzhou Mu, Yihe Tang, Stone Tao, Xinyue Wei, Yunchao Yao, Xiaodi Yuan, Pengwei Xie, Zhiao Huang, Rui Chen, and Hao Su. Maniskill2: A unified benchmark for generalizable manipulation skills. In *International Conference on Learning Representations*, 2023. 22
- Dan Hendrycks and Kevin Gimpel. Gaussian error linear units (gelus). *arXiv preprint arXiv:1606.08415*, 2016. 25
- Alex Henry, Prudhvi Raj Dachapally, Shubham Pawar, and Yuxuan Chen. Query-key normalization for transformers. *arXiv preprint arXiv:2010.04245*, 2020. 6, 19
- Minho Heo, Youngwoon Lee, Doohyun Lee, and Joseph J. Lim. Furniturebench: Reproducible real-world benchmark for long-horizon complex manipulation. In *Robotics: Science and Systems*, 2023. 22
- Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. *Advances in neural information processing systems*, 33:6840–6851, 2020. 2, 3
- Edward J Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. Lora: Low-rank adaptation of large language models. *arXiv preprint arXiv:2106.09685*, 2021. 26
- Nan Huang, Christian Kümmeler, and Xiang Zhang. Unitnorm: Rethinking normalization for transformers in time series. *arXiv preprint arXiv:2405.15903*, 2024. 6
- Eric Jang, Alex Irpan, Mohi Khansari, Daniel Kappler, Frederik Ebert, Corey Lynch, Sergey Levine, and Chelsea Finn. BC-z: Zero-shot task generalization with robotic imitation learning. In *5th Annual Conference on Robot Learning*, 2021. URL <https://openreview.net/forum?id=8kbp23tSGYv>. 22
- Xiaogang Jia, Denis Blessing, Xinkai Jiang, Moritz Reuss, Atalay Donat, Rudolf Lioutikov, and Gerhard Neumann. Towards diverse behaviors: A benchmark for imitation learning with human demonstrations. *arXiv preprint arXiv:2402.14606*, 2024. 1
- Dmitry Kalashnikov, Alex Irpan, Peter Pastor, Julian Ibarz, Alexander Herzog, Eric Jang, Deirdre Quillen, Ethan Holly, Mrinal Kalakrishnan, Vincent Vanhoucke, et al. Qt-opt: Scalable deep reinforcement learning for vision-based robotic manipulation. *arXiv preprint arXiv:1806.10293*, 2018. 22
- Alexander Khazatsky, Karl Pertsch, Suraj Nair, Ashwin Balakrishna, Sudeep Dasari, Siddharth Karamcheti, Soroush Nasiriany, Mohan Kumar Srirama, Lawrence Yunliang Chen, Kirsty Ellis, et al. Droid: A large-scale in-the-wild robot manipulation dataset. *arXiv preprint arXiv:2403.12945*, 2024. 20, 22
- Minchan Kim, Junhyek Han, Jaehyung Kim, and Beomjoon Kim. Pre-and post-contact policy decomposition for non-prehensile manipulation with zero-shot sim-to-real transfer. 2023. 22

- Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, Ted Xiao, Ashwin Balakrishna, Suraj Nair, Rafael Rafailov, Ethan Foster, Grace Lam, Pannag Sanketi, et al. Openvla: An open-source vision-language-action model. *arXiv preprint arXiv:2406.09246*, 2024. 1, 2, 3, 4, 9, 19, 25, 26
- Alexander Kirillov, Eric Mintun, Nikhila Ravi, Hanzi Mao, Chloe Rolland, Laura Gustafson, Tete Xiao, Spencer Whitehead, Alexander C Berg, Wan-Yen Lo, et al. Segment anything. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pp. 4015–4026, 2023. 1
- Basil Kouvaritakis and Mark Cannon. Model predictive control. *Switzerland: Springer International Publishing*, 38:13–56, 2016. 7
- Franziska Krebs, Andre Meixner, Isabel Patzer, and Tamim Asfour. The kit bimanual manipulation dataset. In *2020 IEEE-RAS 20th International Conference on Humanoid Robots (Humanoids)*, pp. 499–506. IEEE, 2021. 1
- Vikash Kumar, Rutav Shah, Gaoyue Zhou, Vincent Moens, Vittorio Caggiano, Abhishek Gupta, and Aravind Rajeswaran. Robohive: A unified framework for robot learning. *Advances in Neural Information Processing Systems*, 36, 2024. 2, 21, 22
- Michelle A Lee, Yuke Zhu, Krishnan Srinivasan, Parth Shah, Silvio Savarese, Li Fei-Fei, Animesh Garg, and Jeannette Bohg. Making sense of vision and touch: Self-supervised learning of multimodal representations for contact-rich tasks. In *2019 IEEE International Conference on Robotics and Automation (ICRA)*, 2019. URL <https://arxiv.org/abs/1810.10191>. 22
- Weiwei Li. *Optimal control for biological movement systems*. University of California, San Diego, 2006. 1
- Hanwen Liang, Niamul Quader, Zhixiang Chi, Lizhe Chen, Peng Dai, Juwei Lu, and Yang Wang. Self-supervised spatiotemporal representation learning by exploiting video continuity. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 36, pp. 1564–1573, 2022. 2, 5
- Rudolf Lioutikov, Oliver Kroemer, Guilherme Maeda, and Jan Peters. Learning manipulation by sequencing motor primitives with a two-armed robot. In *Intelligent Autonomous Systems 13: Proceedings of the 13th International Conference IAS-13*, pp. 1601–1611. Springer, 2016. 3
- Huihan Liu, Soroush Nasiriany, Lance Zhang, Zhiyao Bao, and Yuke Zhu. Robot learning on the job: Human-in-the-loop autonomy and learning during deployment. In *Robotics: Science and Systems (RSS)*, 2023. 22
- I Liu, Chun Arthur, Sicheng He, Daniel Seita, and Gaurav Sukhatme. Voxact-b: Voxel-based acting and stabilizing policy for bimanual manipulation. *arXiv preprint arXiv:2407.04152*, 2024. 1, 3
- Yingfei Liu, Tiancai Wang, Xiangyu Zhang, and Jian Sun. Petr: Position embedding transformation for multi-view 3d object detection. In *European Conference on Computer Vision*, pp. 531–548. Springer, 2022. 19
- Cheng Lu, Yuhao Zhou, Fan Bao, Jianfei Chen, Chongxuan Li, and Jun Zhu. Dpm-solver++: Fast solver for guided sampling of diffusion probabilistic models. *arXiv preprint arXiv:2211.01095*, 2022. 8, 25
- Jianlan Luo, Charles Xu, Xinyang Geng, Gilbert Feng, Kuan Fang, Liam Tan, Stefan Schaal, and Sergey Levine. Multi-stage cable routing through hierarchical imitation learning. *arXiv pre-print*, 2023. URL <https://arxiv.org/abs/2307.08927>. 22
- Jianlan Luo, Charles Xu, Fangchen Liu, Liam Tan, Zipeng Lin, Jeffrey Wu, Pieter Abbeel, and Sergey Levine. Fmb: a functional manipulation benchmark for generalizable robotic learning, 2024. URL <https://arxiv.org/abs/2401.08553>. 22
- Corey Lynch, Ayzaan Wahid, Jonathan Tompson, Tianli Ding, James Betker, Robert Baruch, Travis Armstrong, and Pete Florence. Interactive language: Talking to robots in real time, 2022. URL <https://arxiv.org/abs/2210.06407>. 22

- Tatsuya Matsushima, Hiroki Furuta, Yusuke Iwasawa, and Yutaka Matsuo. Weblab xarm dataset, 2023. 22
- Oier Mees, Lukas Hermann, Erick Rosete-Beas, and Wolfram Burgard. Calvin: A benchmark for language-conditioned policy learning for long-horizon robot manipulation tasks. *IEEE Robotics and Automation Letters (RA-L)*, 7(3):7327–7334, 2022. 22
- Seyed Sina Mirrazavi Salehian, Nadia Barbara Figueroa Fernandez, and Aude Billard. Dynamical system-based motion planning for multi-arm systems: Reaching for moving objects. In *IJCAI’17: Proceedings of the 26th International Joint Conference on Artificial Intelligence*, pp. 4914–4918, 2017. 1, 4
- Soroush Nasiriany, Tian Gao, Ajay Mandlekar, and Yuke Zhu. Learning and retrieval from prior data for skill-based imitation learning. In *Conference on Robot Learning (CoRL)*, 2022. 22
- Alexander Quinn Nichol and Prafulla Dhariwal. Improved denoising diffusion probabilistic models. In *International conference on machine learning*, pp. 8162–8171. PMLR, 2021. 5
- Jihoon Oh, Naoaki Kanazawa, and Kento Kawaharazuka. X-embodiment u-tokyo pr2 datasets, 2023. URL https://github.com/ojh6404/rlds_dataset_builder. 22
- Takayuki Osa. Motion planning by learning the solution manifold in trajectory optimization. *The International Journal of Robotics Research*, 41(3):291–311, 2022. 22
- Abhishek Padalkar, Gabriel Quere, Antonin Raffin, João Silvério, and Freek Stulp. A guided reinforcement learning approach using shared control templates for learning manipulation skills in the real world. *Research square preprint rs-3289569/v1*, 2023. 22
- Sinno Jialin Pan and Qiang Yang. A survey on transfer learning. *IEEE Transactions on knowledge and data engineering*, 22(10):1345–1359, 2009. 2
- Jyothish Pari, Nur Muhammad Shafullah, Sridhar Pandian Arunachalam, and Lerrel Pinto. The surprising effectiveness of representation learning for visual imitation, 2021. 22
- Adam Paszke, Sam Gross, Francisco Massa, Adam Lerer, James Bradbury, Gregory Chanan, Trevor Killeen, Zeming Lin, Natalia Gimelshein, Luca Antiga, et al. Pytorch: An imperative style, high-performance deep learning library. *Advances in neural information processing systems*, 32, 2019. 23
- Tim Pearce, Tabish Rashid, Anssi Kanervisto, Dave Bignell, Mingfei Sun, Raluca Georgescu, Sergio Valcarcel Macua, Shan Zheng Tan, Ida Momennejad, Katja Hofmann, and Sam Devlin. Imitating human behaviour with diffusion models. In *The Eleventh International Conference on Learning Representations*, 2023. 3, 5
- William Peebles and Saining Xie. Scalable diffusion models with transformers. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pp. 4195–4205, 2023. 2, 6, 19
- Alec Radford, Karthik Narasimhan, Tim Salimans, Ilya Sutskever, et al. Improving language understanding by generative pre-training. 2018. 4
- Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Asell, Pamela Mishkin, Jack Clark, et al. Learning transferable visual models from natural language supervision. In *International conference on machine learning*, pp. 8748–8763. PMLR, 2021. 1
- Ilija Radosavovic, Tete Xiao, Stephen James, Pieter Abbeel, Jitendra Malik, and Trevor Darrell. Real-world robot learning with masked visual pre-training. In *CoRL*, 2022. 22
- Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li, and Peter J. Liu. Exploring the limits of transfer learning with a unified text-to-text transformer. *Journal of Machine Learning Research*, 21(140):1–67, 2020. URL <http://jmlr.org/papers/v21/20-074.html>. 6, 19, 25

- Daniel Rakita, Bilge Mutlu, Michael Gleicher, and Laura M Hiatt. Shared control–based bimanual robot manipulation. *Science Robotics*, 4(30):eaaw0955, 2019. 1, 4
- Jeff Rasley, Samyam Rajbhandari, Olatunji Ruwase, and Yuxiong He. Deepspeed: System optimizations enable training deep learning models with over 100 billion parameters. In *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, pp. 3505–3506, 2020. 23
- RethinkRobotics. Sawyer performing table top manipulation. https://github.com/RethinkRobotics/sawyer_robot. 22
- Erick Rosete-Beas, Oier Mees, Gabriel Kalweit, Joschka Boedecker, and Wolfram Burgard. Latent plans for task agnostic offline reinforcement learning. 2022. 22
- Stéphane Ross, Geoffrey Gordon, and Drew Bagnell. A reduction of imitation learning and structured prediction to no-regret online learning. In *Proceedings of the fourteenth international conference on artificial intelligence and statistics*, pp. 627–635. JMLR Workshop and Conference Proceedings, 2011. 19
- Saumya Saxena, Mohit Sharma, and Oliver Kroemer. Multi-resolution sensing for real-time control with vision-language models. In *7th Annual Conference on Robot Learning*, 2023. URL <https://openreview.net/forum?id=WuBv9-IGDUA>. 22
- Nur Muhammad Mahi Shafiullah, Anant Rai, Haritheja Etukuru, Yiqian Liu, Ishan Misra, Soumith Chintala, and Lerrel Pinto. On bringing robots home. *arXiv preprint arXiv:2311.16098*, 2023. 22
- Dhruv Shah, Ajay Sridhar, Arjun Bhorkar, Noriaki Hirose, and Sergey Levine. Gnm: A general navigation model to drive any robot. In *2023 IEEE International Conference on Robotics and Automation (ICRA)*, pp. 7226–7233. IEEE, 2023a. 2, 7
- Rutav Shah, Roberto Martín-Martín, and Yuke Zhu. MUTEX: Learning unified policies from multimodal task specifications. In *7th Annual Conference on Robot Learning*, 2023b. URL <https://openreview.net/forum?id=PwqiqaaEzJ>. 22
- Pratyusha Sharma, Lekha Mohan, Lerrel Pinto, and Abhinav Gupta. Multiple interactions made easy (mime): Large scale demonstrations data for imitation. In *Conference on robot learning*, pp. 906–915. PMLR, 2018. 1, 3
- Haochen Shi, Huazhe Xu, Samuel Clarke, Yunzhu Li, and Jiajun Wu. Robocook: Long-horizon elasto-plastic object manipulation with diverse tools. *arXiv preprint arXiv:2306.14447*, 2023. 22
- Christian Smith, Yiannis Karayiannidis, Lazaros Nalpantidis, Xavi Gratal, Peng Qi, Dimos V Dimarogonas, and Danica Kragic. Dual arm manipulation—a survey. *Robotics and Autonomous systems*, 60(10):1340–1353, 2012. 3
- Kihyuk Sohn, Honglak Lee, and Xinchen Yan. Learning structured output representation using deep conditional generative models. *Advances in neural information processing systems*, 28, 2015. 2
- Simon Stepputtis, Joseph Campbell, Mariano Phielipp, Stefan Lee, Chitta Baral, and Heni Ben Amor. Language-conditioned imitation learning for robot manipulation tasks. *Advances in Neural Information Processing Systems*, 33:13139–13150, 2020. 3
- Simon Stepputtis, Maryam Bandari, Stefan Schaal, and Heni Ben Amor. A system for imitation learning of contact-rich bimanual manipulation policies. In *2022 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pp. 11810–11817. IEEE, 2022. 3
- Matthew Tancik, Pratul Srinivasan, Ben Mildenhall, Sara Fridovich-Keil, Nithin Raghavan, Utkarsh Singhal, Ravi Ramamoorthi, Jonathan Barron, and Ren Ng. Fourier features let networks learn high frequency functions in low dimensional domains. *Advances in neural information processing systems*, 33:7537–7547, 2020. 6
- Hugo Touvron, Thibaut Lavril, Gautier Izacard, Xavier Martinet, Marie-Anne Lachaux, Timothée Lacroix, Baptiste Rozière, Naman Goyal, Eric Hambro, Faisal Azhar, et al. Llama: Open and efficient foundation language models. *arXiv preprint arXiv:2302.13971*, 2023. 1, 7

- Homer Walke, Kevin Black, Abraham Lee, Moo Jin Kim, Max Du, Chongyi Zheng, Tony Zhao, Philippe Hansen-Estruch, Quan Vuong, Andre He, Vivek Myers, Kuan Fang, Chelsea Finn, and Sergey Levine. Bridgedata v2: A dataset for robot learning at scale. In *Conference on Robot Learning (CoRL)*, 2023. 2, 21, 22
- Zhiqiang Wang, Hao Zheng, Yunshuang Nie, Wenjun Xu, Qingwei Wang, Hua Ye, Zhe Li, Kaidong Zhang, Xuwen Cheng, Wanxi Dong, et al. All robots in one: A new standard and unified dataset for versatile, general-purpose embodied agents. *arXiv preprint arXiv:2408.10899*, 2024. 21
- Lingxuan Wu, Xiao Yang, Yinpeng Dong, Liuwei Xie, Hang Su, and Jun Zhu. Embodied active defense: Leveraging recurrent feedback to counter adversarial patches. *arXiv preprint arXiv:2404.00540*, 2024. 21
- Fan Xie, Alexander Chowdhury, M De Paolis Kaluza, Linfeng Zhao, Lawson Wong, and Rose Yu. Deep imitation learning for bimanual robotic manipulation. *Advances in neural information processing systems*, 33:2327–2337, 2020. 3
- Ge Yan, Kris Wu, and Xiaolong Wang. ucsd kitchens Dataset. August 2023. 22
- Jonathan Yang, Dorsa Sadigh, and Chelsea Finn. Polybot: Training one policy across robots while embracing variability. *arXiv preprint arXiv:2307.03719*, 2023. 4
- Jonathan Yang, Catherine Glossop, Arjun Bhorkar, Dhruv Shah, Quan Vuong, Chelsea Finn, Dorsa Sadigh, and Sergey Levine. Pushing the limits of cross-embodiment learning for manipulation and navigation. *arXiv preprint arXiv:2402.19432*, 2024. 5
- Xiaohua Zhai, Basil Mustafa, Alexander Kolesnikov, and Lucas Beyer. Sigmoid loss for language image pre-training, 2023. 6, 19, 25
- Biao Zhang and Rico Sennrich. Root mean square layer normalization. *Advances in Neural Information Processing Systems*, 32, 2019. 6, 19
- Tony Z Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware. *arXiv preprint arXiv:2304.13705*, 2023. 1, 2, 3, 5, 9, 19, 21, 22, 25
- Gaoyue Zhou, Victoria Dean, Mohan Kumar Srirama, Aravind Rajeswaran, Jyothish Pari, Kyle Hatch, Aryan Jain, Tianhe Yu, Pieter Abbeel, Lerrel Pinto, Chelsea Finn, and Abhinav Gupta. Train offline, test online: A real robot learning benchmark. In *2023 IEEE International Conference on Robotics and Automation (ICRA)*, 2023. 22
- Yi Zhou, Connelly Barnes, Jingwan Lu, Jimei Yang, and Hao Li. On the continuity of rotation representations in neural networks. In *2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 5738–5746, 2019. doi: 10.1109/CVPR.2019.00589. 21
- Xinghao Zhu, Ran Tian, Chenfeng Xu, Mingyu Ding, Wei Zhan, and Masayoshi Tomizuka. Fanuc manipulation: A dataset for learning-based manipulation with fanuc mate 200id robot. 2023. 22
- Yifeng Zhu, Abhishek Joshi, Peter Stone, and Yuke Zhu. Viola: Imitation learning for vision-based manipulation with object proposal priors. *6th Annual Conference on Robot Learning (CoRL)*, 2022a. 22
- Yifeng Zhu, Peter Stone, and Yuke Zhu. Bottom-up skill discovery from unsegmented demonstrations for long-horizon robot manipulation. *IEEE Robotics and Automation Letters*, 7(2):4126–4133, 2022b. 22
- Daniel M Ziegler, Nisan Stiennon, Jeffrey Wu, Tom B Brown, Alec Radford, Dario Amodei, Paul Christiano, and Geoffrey Irving. Fine-tuning language models from human preferences. *arXiv preprint arXiv:1909.08593*, 2019. 7
- R Zollner, Tamim Asfour, and Rüdiger Dillmann. Programming by demonstration: dual-arm manipulation tasks for humanoid robots. In *2004 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)(IEEE Cat. No. 04CH37566)*, volume 1, pp. 479–484. IEEE, 2004. 3

A 动作分块技术

在实践中，我们发现由于学习策略的不完美，动作预测的误差会随着历史决策数量的增加而累积。这可能导致机器人偏离训练分布，进入难以恢复的状态（Ross 等，2011）。为了缓解这一问题，我们倾向于一次性预测多个动作，从而减少轨迹中的总决策次数。通过这种方式，我们建模 $p(\mathbf{a}_{t:t+T_a}|\ell, \mathbf{o}_t)$ ，其中 $\mathbf{a}_{t:t+T_a} := (\mathbf{a}_t, \dots, \mathbf{a}_{t+T_a-1})$ 是动作块， T_a 表示块大小（Zhao 等，2023）。为了使公式 1 和公式 2 适应这一情境，我们可以简单地将 $\mathbf{a}_t$ 替换为 $\mathbf{a}_{t:t+T_a}$ 。此外，根据 Chi 等（2023）的研究，动作分块也有助于提高时序一致性。它能在决策时更好地考虑前后动作的连贯性，并可能避免可能对机器人造成损害的突然动作变化。

B 架构细节

多模态输入的编码。编码细节概述如下：

- **低维输入。** 本体感知 $\mathbf{z}_t$ 和带噪声的动作块 $\tilde{\mathbf{a}}_{t:t+T_a}$ 首先被嵌入到统一的动作空间中。该空间用于统一不同机器人上 $\mathbf{z}_t$ 和 $\tilde{\mathbf{a}}_{t:t+T_a}$ 的表示，详见第 4.2 节。然后，由于它们具有相似的物理含义，它们通过一个共享的多层感知机（MLP）被编码到令牌空间中。与离散化编码相比，这种连续编码可以避免精度损失（Brohan 等，2022；2023；Kim 等，2024）。对于频率 c 以及扩散时间步 k ，我们分别通过两个多层感知机将它们编码到令牌空间中。随后，所有这些都在长度方向上拼接在一起，以实现上下文条件化（Peebles & Xie, 2023；Bao 等，2023），从而得到一个长度为 $1 + T_a + 1 + 1$ 的输入令牌序列。最后，添加位置嵌入以区分不同的模态，并在 $\tilde{\mathbf{a}}_{t:t+T_a}$ 中注入时间信息。
- **图像输入。** 本文采用冻结的 SigLIP（Zhai 等人，2023）对 RGB 图像进行编码，并利用额外的多层感知机（MLP）将输出投影至令牌空间。为增强模型基于视角和时间步区分图像的能力，本文将传统正弦位置嵌入扩展至多维网格，如图 3 右侧所示。该修改融合了时空信息，使模型能够捕捉输入图像之间的关联。具体而言，本文采用 Liu 等人（2022）的实现，使用 $(T_{\text{img}}, N_{\text{cam}}, N_{\text{patch}}, D)$ 的网格维度。其中， N_{cam} 表示相机数量，本文配置为三台； N_{patch} 表示基于 ViT 的图像编码器将每幅图像划分的块数； D 表示嵌入维度。
- **语言输入。** 语言指令由冻结的 T5-XXL（Raffel 等人，2020）编码，并使用多层感知机（MLP）将输出投影到令牌空间。在计算语言令牌的注意力时，我们应用语言注意力掩码来屏蔽批处理期间附加的填充令牌。

在训练过程中，来自不同模态的每个输入均以 10% 的概率被独立掩码。

网络结构 f_{θ} 。编码后，我们将低维输入的令牌输入主网络，该网络基于具有交叉注意力（Cross-Attention）的扩散 Transformer（Diffusion Transformers, DiTs）调整而来（Peebles & Xie, 2023），因其具有高可扩展性。为提升训练稳定性，我们在每个注意力层中加入 QKNorm（Henry et al., 2020），并将每个 LayerNorm 替换为 RMSNorm（Zhang & Sennrich, 2019）。在每个 DiT 块的交叉注意力层中，我们交替注入语言和图像令牌，而非同时注入两者，以避免两种模态之间的令牌不平衡问题。经过 L 个 DiT 块后，我们对输出进行归一化，并通过 MLP 解码器将其投影回动作空间。

C 物理可解释的统一动作空间

如第 4.2 节所述，本文将各类机器人的动作嵌入到一个统一空间中，该空间包含机器人的所有主要物理量。此统一动作空间的维度为 128。表 4 描述了该统一动作空间中向量的每个元素。对于特定机器人，每个

原始动作向量的每个元素根据其物理含义填入统一动作向量的对应位置，其余位置进行填充。

Index Range	Element Index	Mapped Physical Quantity
[0, 10)	0–9	Right arm joint positions
[10, 15)	10–14	Right gripper joint positions
[15, 25)	15–24	Right arm joint velocities
[25, 30)	25–29	Right gripper joint velocities
[30, 33)	30–32	Right end effector positions
[33, 39)	33–38	Right end effector 6D pose
[39, 42)	39–41	Right end effector velocities
[42, 45)	42–44	Right end effector angular velocities
[45, 50)	45–49	Reserved
[50, 60)	50–59	Left arm joint positions
[60, 65)	60–64	Left gripper joint positions
[65, 75)	65–74	Left arm joint velocities
[75, 80)	75–79	Left gripper joint velocities
[80, 83)	80–82	Left end effector positions
[83, 89)	83–88	Left end effector 6D pose
[89, 92)	89–91	Left end effector velocities
[92, 95)	92–94	Left end effector angular velocities
[95, 100)	95–99	Reserved
[100, 102)	100–101	Base linear velocities
[102, 103)	102	Base angular velocities
[103, 128)	103–127	Reserved

表 4：统一动作空间向量的描述。对于单臂机器人情况，其机械臂被映射为“右”臂。对于仅具有 6 自由度的机械臂，其关节位置将填入 10 个对应位置中的前 6 个。其他物理量同理。

D 预训练数据集

我们的预训练数据集集合包含 46 个数据集，总规模超过 100 万条轨迹，数据量达 21TB，是迄今为止规模最大的机器人预训练数据集集合。表 5 列出了我们预训练数据集的完整清单及其采样权重。我们为每个规模为 N_j 的数据集分配初始权重 $\sqrt{N_j}$ ，并根据每个数据集的多样性和质量进行调整。与线性加权相比，该方法可避免大型数据集被过度采样，同时确保小型数据集得到充分采样，从而增强每个小批量中预训练样本的多样性。在预训练阶段，我们进一步根据各数据集的中间损失结果观察并调整其权重。我们提高了收敛较慢的数据集的权重。

主要数据集。我们列出一些主要数据集如下：

- **RT-1 数据集** (Brohan 等人, 2022) 是一个大型多样化数据集，包含 13 万条轨迹，涵盖多种任务、物体和环境。该数据集在 13 种不同机器人本体上采集，每个本体配备一个外部 RGB 相机。动作空间包括 6 维末端执行器 (EEF)、夹爪开合以及基座位移，控制频率为 3Hz。
- **DROID** (Khazatsky 等人, 2024) 是一个大规模多任务数据集，包含 7.6 万条轨迹和 564 个场景。该数据集通过遥操作 Franka Panda 7 自由度机械臂采集，配备腕部和外部 RGB-D 相机。动作空间包括 7 自由度关节位置和夹爪宽度，而本体感知额外包括 6 维末端执行器，控制频率为 15Hz。
- **RH20T** (Fang 等人, 2023) 是一个综合数据集，涵盖 11 万条轨迹和 140 项任务。该数据集包含四种不同的机器人本体和三种不同的相机视角，采样频率为 10Hz。它同时包含长任务和短任务。其状态空间混合了 6 自由度和 7 自由度关节位置，并具有第三人称视角的 RGB-D 相机。

- **移动 ALOHA 数据集** (Fu 等, 2024) 是一个由移动 ALOHA 机器人采集的双臂数据集, 包含超过 1000 条轨迹。其状态空间包括基座运动以及双手的 14 维关节位置, 并配备三到四个第一人称视角相机。部分数据包含大范围的视角变化和基座运动, 原本适用于模仿学习。

- **其他数据集**。其余数据来自 RH20T (Fang 等, 2023)、RoboSet (Kumar 等, 2024)、BridgeData V2 (Walke 等, 2023) 和 Open X-Embodiment (Collaboration 等, 2023)。这些数据集大多具有不同的机器人形态和相机观测, 增强了预训练数据集的异质性和多样性。

数据清洗。剔除重复片段和失败片段, 以确保预训练数据集的质量。移除空白图像, 排除错误记录的速度, 并过滤过短的轨迹。过长的轨迹将被下采样, 以避免不公平。

多模态观测/动作输入的预处理。本文描述每种模态的预处理细节:

ℓ . • **语言指令** 我们对原始文本进行简单清洗, 例如去除非法

字符与多余空格, 句首大写, 并在句末添加句号。我们保留文本为可变长度。

$t - T_{\text{img}} + 1 : t + 1$. • **红绿蓝图像 (RGB Images)** X 我们采用固定长度的图像

输入策略。我们为所有机器人固定图像输入顺序和格式, 共包含三个视图: 一个静态外部视图、一个右腕视图和一个左腕视图, 这被认为足以满足大多数双手任务的需求。我们将单臂机器人的腕部摄像头视为右腕摄像头, 并用背景色填充不可用的视图。输入模型时, 每张图像被填充为正方形并调整大小为 384×384 , 保持其原始宽高比。此外, 我们选择 $T_{\text{img}} = 2$, 因为历史长度为二在大多数情况下已足够, 在效率与性能之间取得平衡 (Ghosh 等人, 2023; Wu 等人,

$\mathbf{X}_{t-1:t+1} := (\{\mathbf{X}_{t-1}^1, \mathbf{X}_{t-1}^2, \mathbf{X}_{t-1}^3\}, \{\mathbf{X}_t^1, \mathbf{X}_t^2, \mathbf{X}_t^3\})$. 2024)。最终, 我们可以将图像输入写为

- **本体感觉 (Proprioception)** z_t 与动作块 (Action Chunk) $\mathbf{a}_{t:t+T_a}$. 我们通过统一物理量的单位 (米、弧度、米/秒、弧度/秒等) 来大致对齐各数据集的尺度, 而非像先前工作 (Chi 等, 2023; Ghosh 等, 2023) 那样严格归一化到 $[-1, 1]$ 或 $\mathcal{N}(0, 1)$ 。例如, 不同数据集中的“1 (米)”对应相同的真实世界长度。重新缩放物理量会破坏这种共享属性, 从而损害模型跨机器人迁移的能力。

本文还采用六维表示 (6D Representation) 来处理末端执行器 (EEF) 旋转, 以克服万向节锁问题。在选择 $T_a = 64$ 之前, 我们参考了赵等人 (2023) 先前的消融研究, 并在性能与计算开销之间进行了权衡。此外, 历史本体感觉 $z_i, i < t$ 被排除, 以防止模型仅利用低维输入学习捷径, 从而固守固定的运动模式。相反, 我们鼓励模型从高维图像特征中学习可泛化的决策结构。

- **控制频率** 为解决不同控制频率所带来的挑战

数据集方面, 我们将控制频率输入模型, 使模型在决策时能够考虑这一变化。

E 微调数据集

我们的微调数据集使用移动阿罗哈机器人 (Mobile ALOHA Robot) 创建, 包含 300 多个任务、6000 多条轨迹和 300 多万帧图像。它也是迄今为止最大的开源多任务双臂机器人数据集之一。图 6 给出了该数据集的概要。我们从开源松灵数据集 (Songling Dataset) 中借用了 3 个任务 (共 140 个片段)。

- **多模态特征**。我们使用三台 RGB 相机采集数据集, 分别安装于前方以及左右夹爪上。我们记录了双臂六自由度关节位置与速度, 以及夹爪角度。我们为每项任务手动标注了指令。为进一步扩充指令并使其与预训练数据集对齐, 我们利用 GPT-4-Turbo (Achiam 等, 2023) 为每项任务生成 100 条扩展指令和一条简化指令。这种多模态信息进一步提升了数据集的丰富性与质量。

Pre-Training Dataset	Sample Percentage (%)
RT-1 Dataset (Brohan et al., 2022)	9.00
TACO Dataset (Rosete-Beas et al., 2022)	1.99
JACO Play Dataset (Dass et al., 2023)	1.10
Cable Routing Dataset (Luo et al., 2023)	0.27
NYU Door Opening (Pari et al., 2021)	0.33
Viola (Zhu et al., 2022a)	0.40
Berkeley UR5 (Chen et al.)	1.06
TOTO (Zhou et al., 2023)	1.06
Kuka (Kalashnikov et al., 2018)	1.66
Language Table (Lynch et al., 2022)	3.32
Columbia Cairlab Pusht Real (Chi et al., 2023)	0.40
Stanford Kuka Multimodal Dataset (Lee et al., 2019)	1.83
Stanford Hydra Dataset (Belkhale et al., 2023)	0.80
Austin Buds Dataset (Zhu et al., 2022b)	0.23
Maniskill Dataset (Gu et al., 2023)	5.78
Furniture Bench Dataset (Heo et al., 2023)	2.36
UCSD Kitchen Dataset (Yan et al., 2023)	0.40
UCSD Pick And Place Dataset (Feng et al., 2023)	1.23
Austin Sailor Dataset (Nasiriany et al., 2022)	0.50
Austin Sirius Dataset (Liu et al., 2023)	0.80
BC Z (Jang et al., 2021)	6.91
UTokyo PR2 Opening Fridge (Oh et al., 2023)	0.30
UTokyo PR2 Tabletop Manipulation (Oh et al., 2023)	0.50
UTokyo Xarm Pick And Place (Matsushima et al., 2023)	0.33
UTokyo Xarm Bimanual (Matsushima et al., 2023)	0.03
Berkeley MVP (Radosavovic et al., 2022)	0.73
Berkeley RPT (Radosavovic et al., 2022)	1.00
KAIST Nonprehensile (Kim et al., 2023)	0.46
Tokyo U LSMO (Osa, 2022)	0.23
DLR Sara Grid Clamp (Padalkar et al., 2023)	0.03
Robocook (Shi et al., 2023)	1.66
Imperialcollege Sawyer Wrist Cam (RethinkRobotics)	0.43
Iamlab CMU Pickup Insert (Saxena et al., 2023)	0.83
UTAustin Mutex (Shah et al., 2023b)	1.29
Fanuc Manipulation (Zhu et al., 2023)	0.66
Play Fusion (Chen et al., 2023)	0.80
DROID (Khazatsky et al., 2024)	10.06
FMB (Luo et al., 2024)	1.39
Dobb-E (Shafiullah et al., 2023)	1.20
QUT Dexterous Manipulation (Federico Ceola, 2023)	0.46
Aloha Dataset (Zhao et al., 2023)	4.98
Mobile Aloha Dataset (Fu et al., 2024)	4.98
RoboSet (Kumar et al., 2024)	4.48
RH20T (Fang et al., 2023)	10.99
Calvin Dataset (Mees et al., 2022)	3.32
BridgeData V2 (Walke et al., 2023)	7.44

表 5: 预训练数据集及其对应权重。

• **多样化的物体与场景。**我们的数据集包含多样化的任务和场景，涵盖超过 300 个任务，包括拾取、插入、书写、推拉等技能。数据集包含 100 多个物体，具有刚性和非刚性体，尺寸和纹理各异。我们在 15 个以上的场景中收集数据，并在每个任务的数据收集过程中引入随机性，例如改变物体和机器人的初始位置。为了进一步增加多样性，我们添加了随机光照条件。例如，倒水任务在正常光照和变化颜色条件下均进行了执行。这些措施进一步增强了数据集的多样性。




图 6：微调数据集。我们的数据集包含以下关键特征：（1）多样化的物体和场景。我们的数据集包含在不同场景和条件下操作的具有不同属性的物体。（2）具有挑战性的任务。我们的数据集包含灵巧操作、语言和视觉理解以及双手任务。（3）多模态特征。我们的数据集标注了丰富的多模态数据，包括三视角 RGB 相机、关节信息和增强指令。

• **具有挑战性的任务。**还考虑了各种具有挑战性的任务，包括灵巧操作，例如从塑料瓶上拧下瓶盖，以及理解任务，例如用字母积木拼出“love”。此外，数据集还包括同时结合灵巧性和理解力的任务，例如在白板上求解数学方程。另外，我们的数据集包含双手任务，例如将充电线插入手机。这些复杂、高质量的任务进一步增强了模型的下游可理解性和泛化能力。

F RDT 训练细节

平台。我们使用 PyTorch (Paszke 等人, 2019) 和 DeepSpeed (Rasley 等人, 2020) 来促进并行训练，并采用带有 TensorFlow Dataset (TFD) 的生产者-消费者框架以实现快速数据加载。由于 Open X-Embodiment (Collaboration 等人, 2023) 中的大多数数据集以 TFRecord 形式存储，我们将所有预训练数据集转换为 TFRecord 进行存储。在预训练中，我们使用生产者进程从 TFRecord 解压数据并将其存储在硬盘上的缓冲区中。同时，我们使用消费者进程以无序方式从缓冲区读取数据，并将其馈送给模型训练。这不仅解耦了 TensorFlow (Abadi 等人, 2015) 和 PyTorch 环境，还缓解了由于内存中混洗缓冲区较小而导致的训练性能损失。在微调阶段，由于数据集相对较小，我们额外实现了一个使用 HDF5 数据集进行存储的数据读取管道。

填充动作和本体感觉。为了将特定机器人动作嵌入到 128 维的统一动作空间中，我们需要填充不可用的动作元素。通常的做法是用 0 值或特定值进行填充。但“0”实际上具有物理意义。例如，速度为“0”通常表示相对于地面静止。这可能会使模型困惑：“0”代表静止还是填充值？为了解决这个问题，我们在将动作和本体感觉编码到令牌空间之前，将它们与一个指示每个维度是否被填充的 0-1 向量拼接起来，从而得到一个 256 维的向量。这可以补充缺失的可用性信息并消除混淆。

检查训练过程。在训练期间，每隔固定周期，我们进行一次扩散采样，并将采样动作与训练数据集的真实值进行比较。根据经验，我们发现两者的均方误差（MSE）与在机器人上的部署性能之间存在普遍的正相关性。这一观察使我们能够轻松监控模型的训练进度。当该 MSE 收敛时，我们通常可以停止训练。我们注意到，过低的 MSE 也可能意味着过拟合。

数据增强。过拟合是训练大型神经模型时常见的挑战，尤其在微调阶段。本文利用数据增强技术来解决该问题。我们执行图像增强，包括颜色抖动和图像损坏，并向输入的本体感觉添加信噪比为 40 分贝的高斯噪声。我们还使用 GPT-4-Turbo 来增强和扩展语言指令（有关指令增强的更多细节，请参阅第 E 节）。

一些微调细节。在微调过程中，我们移除了每个回合开始时的静态部分，这可能是由于操作员在录制开始后没有反应造成的。我们的语言指令以三分之一的概率从原始人工标注指令、扩展指令和简化指令中采样。当抽取到扩展指令时，我们从与该任务对应的 100 条扩展指令中均匀采样一条。我们没有应用无分类器引导，因为我们发现这并没有提高模型的性能，反而带来了不稳定的机器人手臂行为。

G 硬件细节




图 7：硬件特性。

Parameter	Value
DoF	$7 \times 2 = 14$
Size	$1080 \times 700 \times 1140$
Arm weight	4.2 kg
Arm Payload	3000 g (peak) 1500 g (valid)
Arm reach	600 mm
Arm repeatability	1 mm
Arm working radius	653 mm
Joint motion range	J1: $\pm 154^\circ$, J2: $0^\circ \sim 165^\circ$ J3: $-175^\circ \sim 0^\circ$, J4: $\pm 106^\circ$ J5: $\pm 75^\circ$, J6: $\pm 100^\circ$
Gripper range	0-80 mm
Gripper max force	10 NM

表 6：技术规格。

我们提供了目标双臂机器人硬件配置的详细概述。我们的模型在 Cobot Mobile ALOHA 上部署和评估，该机器人采用 Mobile ALOHA 系统设计（Fu 等人，2024 年），由 agilex.ai 制造。机器人的关键特性如图 7 所示。它配备了两个腕部摄像头、一个前置摄像头、一台笔记本电脑和一个机载电池。机器人的技术规格列于表 6 中。需要注意的是，我们使用“移动”ALOHA 仅是为了方便在不同场景之间运输和测试，在任何训练或推理阶段都没有使用其自主移动功能。我们的任务仍然是静态双臂操作任务。

H 实验细节

总体性能计算。图 1 中各方法的总体性能分三步计算。首先，计算每个方法在各任务中的成功率。取总成功率与所有附加要求的平均值，即表 3 中“总计”列及其右侧所有列数值的平均值。例如，在“倒水-L-1/3”任务中，取“总计”、“正确手部”和“正确水量”的平均值。其次，计算

表 7：不同基线的比较。我们从模型规模、数据规模和建模方案等方面比较了基线以及我们模型的不同变体。

METHOD NAME	LARGE MODEL	LARGE MULTI-ROBOT DATA	MODELING
ACT (Zhao et al., 2023)	✗	✗	VAE
OpenVLA (Kim et al., 2024)	✓	✓	Discretization
Octo (Ghosh et al., 2023)	✗	✓	Diffusion
RDT (scratch)	✓	✗	Diffusion
RDT (small)	✗	✓	Diffusion
RDT (regress)	✓	✓	Regression
RDT (ours)	✓	✓	Diffusion

未见物体、未见场景、指令遵循、小样本学习和灵巧性各维度的成功率，通过平均该维度下所有任务得到（对应关系见表 1）。最后，平均所有维度的成功率以获得总体结果。

机器人扩散 Transformer (RDT) 的实现与超参数。我们在表 8 中列出了多模态编码器的细节，在表 9 中列出了模型参数。图像历史大小为 $T_{\text{img}} = 2$ ，动作块大小为 $T_a = 64$ ，语言标记空间维度为 4096，图像标记空间维度为 1152，RDT 的标记空间维度为 2048。我们使用适配器将各模态的标记维度对齐到 2048。所有多模态编码器的适配器均采用 GeLU 激活函数（Hendrycks & Gimpel, 2016）。

在预训练和微调阶段，我们使用 AdamW 优化器（Adam et al., 2019），采用恒定学习率调度器和表 10 中的超参数。模型在 48 块 H100 80GB GPU 上分别进行 100 万步预训练和 13 万步微调。由于调度原因，我们没有从 100 万步的预训练检查点开始微调，而是选择了 50 万步的检查点。在训练阶段，我们使用 DDPM 调度器，采用滑翔余弦调度器（即 squaredcos cap v2），步数为 1000。在采样阶段，我们使用 DPM-Solver++（Lu et al., 2022），采用滑翔余弦调度器，采样步数为 5。在微调期间，我们还过滤掉长度低于 32 的片段，并将长度高于 2048 的片段下采样到 2048。

Modality	Encoder	Trainable	Adaptor
Language	T5-XXL (Raffel et al., 2020)	N	2-layers MLP
Image	SigLIP (Zhai et al., 2023)	N	2-layers MLP
Action	-	-	3-layers MLP

表 8: RDT 的编码器配置。

Model	Layers	Hidden size	Heads	#Params
RDT-1B	28	2048	32	1.2B

表 9: RDT 的模型配置。

ACT 的实现与超参数。我们直接采用了原论文（Fu 等人，2024 年）中 ACT 的相同架构和超参数，仅对表 11 中的超参数进行了调整。我们使用 6K 微调片段中的 90% 对 ACT 进行了 8000 个训练轮次的训练（总计约 8 天），剩余的 10% 作为验证集。根据验证集上的最佳性能，我们选取第 5413 个训练轮次的检查点作为最终结果。

OpenVLA 的实现与超参数。我们采用了官方实现（<https://github.com/openvla/openvla>）以及旗舰预训练模型和检查点

Hyper-Parameter	Value
Batch Size	32×48
Learning Rate	1×10^{-4}
Mixed Precision	bf16
Warm-Up Steps	500
β_1	0.9
β_2	0.999
Weight Decay	1×10^{-2}
ϵ	1×10^{-8}

表 10: RDT 预训练和微调的超参数。

Hyper-Parameter	Value
Batch Size	80×4
Learning Rate	9×10^{-5}
Learning Rate for Backbone	4×10^{-5}

表 11: ACT 调整后的超参数。

位于 <https://huggingface.co/openvla/openvla-7b>。对于评估中的每个任务，我们使用微调数据集中所有与任务相关的演示（ ~ 100 个片段）对官方预训练的 OpenVLA 进行进一步微调，以促进收敛，并按照 Kim 等人（2024 年）的建议（<https://github.com/openvla/openvla/issues/12#issuecomment-2203772810>）将模型训练至约 95% 的动作令牌准确率。此外，我们尝试了使用整个数据集的全参数微调和 LoRA 方法，但在收敛后未能达到部署所需的足够动作令牌准确率（约 60%）（见图 8）。根据真实机器人测试，此类未收敛的检查点在部署中表现出完全静止或随机的行为。

具体而言，我们遵循 Kim 等人（2024）中所述的相同超参数，通过 LoRA（Hu 等人，2021）进行微调，详见表 12。




图 8: 使用完整微调数据集微调 OpenVLA 时，动作标记预测的准确率随训练步数波动而非收敛。

Octo 的实现与超参数。我们利用官方实现，可在 <https://github.com/octo-models/octo> 获取，以及最全面的预训练模型 octo-base-1.5，托管于 <https://huggingface.co/rail-berkeley/octo-base-1.5>。我们遵循官方推荐的双手机器人微调实践，详见 https://github.com/octo-models/octo/blob/main/examples/02_finetune_new_observation_action.py，采用全参数方法。此外，我们整合了一个额外的图像分词器来处理右腕摄像头的图像，

Hyper-Parameter	Value
Batch Size	16×8
Learning Rate	2×10^{-5}
Lora Rank	32
Image Augmentation	True

表 12: 针对双手操作微调 OpenVLA 的超参数。

增强了系统的操作能力。此外，通过在微调过程中整合图像增强，我们提升了在真实机器人部署时的性能。我们复制预训练模型中的腕部图像分词器来初始化右腕图像分词器。与 OpenVLA 类似，我们仅使用与每个评估任务相关的演示来微调 octo，因为在收敛时未观察到足够的测试均方误差（约 10^{-1} ）用于部署（图 9）。具体而言，我们应用默认超参数，其变化列于表 13：




图 9: 使用完整微调数据集微调 Octo 时，动作预测的测试均方误差随训练步数波动而非收敛。

oct

Hyper-Parameter	Value
Action Head Type	DiffusionActionHead
Batch Size	8×8
Action Chunk Size	8
Image Augmentation	RandomBrightness(0.1)
	RandomContrast(0.9, 1.1)
	RandomSaturation(0.9, 1.1)
	RandomHue(0.05)

表 13: 针对双手操作微调 Octo 的超参数。

补充结果

本文进一步在图 10 中提供了指令遵循评估中 8 次试验水位变化的放大视图。



图 10: 在倒水-L-1/3 和倒水-R-2/3 任务中 8 次试验所得水位的可视化结果。左图: RDT 在每次试验中完成的水位与真值 1/3 标准极为接近。右图: RDT 在一次倒水操作中出现错误 (空杯), 并在一次水位控制中出现错误, 但其余试验与 2/3 标准大致吻合。