

ReKep: 面向机器人操作的关系关键点约束的时空推理

Wenlong Huang¹, Chen Wang^{1*}, Yunzhu Li^{2*}, Ruohan Zhang¹, Li Fei-Fei¹

¹Stanford University ²Columbia University

rekep-robot.github.io

摘要: 将机器人操作任务表示为关联机器人与环境的约束，是编码期望机器人行为的一种有前景的方法。然而，如何构建这些约束，使其 1) 适用于多样化任务，2) 无需人工标注，3) 可由现成求解器实时优化以生成机器人动作，仍是一个未解问题。本文提出关系关键点约束（ReKep），一种基于视觉的机器人操作约束表示。具体而言，ReKep 表示为将环境中一组三维关键点映射为数值代价的 Python 函数。我们证明，通过将操作任务表示为关系关键点约束序列，可采用分层优化过程在感知-动作循环中以实时频率求解机器人动作（表示为末端执行器位姿序列，见 $SE(3)$ ）。此外，为避免为每个新任务手动指定 ReKep，我们设计了一种自动化流程，利用大型视觉模型和视觉语言模型从自由形式语言指令和 RGB-D 观测中生成 ReKep。我们在轮式单臂平台和固定式双臂平台上实现了系统，能够执行多种操作任务，包括多阶段、野外、双臂和反应式行为，且无需任务特定数据或环境模型。




图 1: 关系关键点约束 (ReKep) 将多样化操作行为指定为作用于语义关键点的可优化时空约束函数序列。在倒水任务中，一个 ReKep 首先约束茶壶把手（蓝色）处的抓取位置。随后一个 ReKep 将茶壶壶嘴（红色）拉向杯口顶部（绿色），同时另一个 ReKep 通过关联把手（蓝色）与壶嘴（红色）形成的向量来约束茶壶的期望旋转。

1 引言

机器人操作涉及与环境中物体的复杂交互，通常可表示为空间和时间域中的约束。考虑图 1 中向杯中倒茶的任务：机器人必须在把手处抓取，并在搬运过程中保持杯子直立

*表示同等贡献。通讯作者：黄文龙 <wenlongh@stanford.edu>。

将壶嘴对准目标容器，然后以正确角度倾斜杯子进行倾倒。在此，约束不仅编码了中间子目标（例如对准壶嘴），还编码了过渡行为（例如在运输过程中保持杯子直立），这些共同决定了机器人动作在空间、时间及其他组合方面与环境的关系要求。

然而，为大量真实世界任务有效制定这些约束面临重大挑战。虽然使用机器人与物体之间的相对位姿来表示约束是一种直接且广泛采用的方法 [1]，但刚体变换无法刻画几何细节，需要预先获取物体模型，且不适用于可变形物体。另一方面，数据驱动方法能够直接在视觉空间中学习约束 [2, 3]。尽管更为灵活，但随着约束数量在物体和任务方面呈组合式增长，如何有效收集训练数据仍不清楚。因此，我们提出如下问题：如何表示操作中的约束，使其具备 1) 广泛适用性：能够适应需要多阶段、野外、双臂和反应式行为的任务；2) 可扩展获取性：有潜力通过基础模型的进步实现完全自动化；3) 实时可优化性：能够由现成求解器高效求解，以产生复杂的操作行为？

本文提出关系关键点约束（ReKep）。具体而言，ReKep 将约束表示为 Python 函数，这些函数将一组关键点映射为数值代价，其中每个关键点都是场景中任务特定且语义上有意义的 3D 点。每个函数由关键点上的（可能非线性的）算术运算组成，并编码它们之间期望的“关系”，其中关键点可能属于环境中的不同实体，例如机器人手臂、物体部件和其他智能体。虽然每个关键点仅包含其在全局坐标系中的 3D 笛卡尔坐标，但如果强制关键点之间的刚性，多个关键点可以共同指定直线、曲面和/或 3D 旋转。我们在顺序操作问题的背景下研究 ReKep，其中每个任务涉及多个具有时空依赖性的阶段（例如，前述示例中的“抓取”、“对齐”和“倾倒”）。

虽然约束通常是每个任务手动定义的 [4]，但我们证明了 ReKep 的特定形式具有独特的优势，即它们可以通过预训练的大型视觉模型（LVM）[5] 和视觉语言模型（VLM）[6] 实现自动化，从而能够从 RGB-D 观测和自由形式的语言指令中在野外指定 ReKep。具体来说，我们利用 LVM 在场景中提出细粒度且语义上有意义的关键点，并利用 VLM 根据叠加了所提出关键点的视觉输入将约束编写为 Python 函数。这个过程可以解释为使用视觉指代表达式，将细粒度的空间关系（通常是那些难以用自然语言指定的关系）建立在 VLM 支持的输出模态（代码）中。

利用生成的约束，现成的求解器可以通过基于跟踪的关键点重新评估约束来产生机器人动作。受 [7] 启发，我们采用分层优化程序，首先求解一组路径点作为子目标（表示为 $SE(3)$ 末端执行器姿态），然后求解滚动时域控制问题以获得实现每个子目标的密集动作序列。通过适当的问题实例化，我们证明了对于本文所考虑的任务，它可以以大约 10 Hz 的频率可靠地求解。

本文的贡献总结如下：1) 本文将操作任务形式化为具有关系关键点约束（Relational Keypoint Constraints）的分层优化问题；2) 本文设计了一套流程，利用大型视觉模型和视觉语言模型自动指定关键点和约束；3) 本文在两个真实机器人平台上展示了系统实现，该系统以语言指令和 RGB-D 观测作为输入，为大量操作任务生成多阶段、野外、双手和反应式行为，且无需任务特定数据或环境模型。

2 相关工作

操作的结构化表示。结构化表示决定了操作系统中不同模块的编排方式，并对系统的能力、假设、效率及有效性产生不同的启示。刚体姿态最为常用

鉴于自由空间中刚体运动的良好理解性及其在建模物体长程依赖关系方面的高效性 [1, 8 – 18]。然而，由于通常需要预先对环境的几何和动力学进行建模，许多工作研究了基于数据驱动方法的结构化表示，例如学习以物体为中心的表示 [19 – 34]、基于粒子的动力学 [35 – 41] 以及关键点或描述符 [3, 4, 42 – 54]。其中，关键点因其可解释性、高效性、对实例变化的泛化能力 [4] 以及同时建模刚体和可变形物体的能力而展现出巨大潜力。然而，每个任务都需要人工标注，因此在开放世界环境中缺乏可扩展性，这正是本文旨在解决的问题。

操作中的约束优化。约束常被用于对机器人施加期望的行为。运动规划算法利用几何约束来计算可行的轨迹，以避免障碍物并达成目标 [55 – 60]。接触约束可用于规划有力或接触丰富的行为 [61 – 74]。对于顺序操作任务，任务与运动规划 (TAMP) [1, 8, 13] 是一个广泛使用的框架，通常被表述为约束满足问题 [11, 75 – 80]，并以连续几何问题作为子程序。逻辑-几何规划 [81 – 86] 则在整个状态轨迹上构建一个非线性约束规划，同时考虑逻辑约束和几何约束。约束既可以手动编写，也可以从数据中学习，其形式包括流形 [87]、可行性模型 [86, 88] 或符号距离场 [2, 89]。受 [7] 启发，我们将顺序操作任务表述为一个集成的连续数学规划，并以滚动时域的方式反复求解，关键区别在于约束由基础模型合成。

面向机器人的基础模型。利用基础模型进行机器人研究是一个活跃的研究领域。我们建议读者参考 [90 – 93] 以了解概述和近期应用。在此，我们重点关注能够结合视觉输入 [6, 94 – 98] 进行操作的视觉语言模型 (VLM)。然而，尽管在开放世界规划和目标指定 [99 – 113] 方面展现出潜力，视觉语言模型基于图注引导的预训练方案往往限制了其能够保留的图像视觉细节 [114 – 117]。另一方面，自监督视觉模型（例如 DINO [5, 118]）提供了细粒度的像素级特征，对多种视觉和机器人任务十分有用 [31, 119 – 124]，但缺乏有效的方法来解释对跨任务泛化至关重要的开放世界语义。在本工作中，我们利用二者的互补优势：使用 DINOv2 [5] 进行细粒度关键点提议，并使用 GPT-4o [6] 在受支持的输出模态（代码）中发挥其视觉推理能力。类似形式的视觉提示技术也在同期工作 [99 – 101, 112, 125] 中被探索。在本工作中，我们展示了 ReKep 具有以下独特优势：执行具有挑战性的 6-12 自由度任务、集成高层推理以实现反应式重规划、高频闭环执行，以及通过视觉提示生成黑盒约束。更多讨论见附录 A.10。

3 方法

本文讨论：（1）什么是关系关键点约束 (Relational Keypoint Constraints, ReKep)（第 3.1 节）？（2）如何利用 ReKep 将操作任务形式化为约束优化问题（第 3.2 节）？（3）我们提出的算法实例如何实时高效求解该优化问题（第 3.3 节）？（4）如何从 RGB-D 观测和语言指令中自动获取 ReKep（第 3.4 节）？

3.1 关系关键点约束 (ReKep)

本文定义单个 ReKep 实例。为清晰起见，假设已指定一组 K 个关键点（将在第 3.4 节讨论）。具体而言，每个关键点 $k_i \in \mathbb{R}^3$ 指场景表面上的一个三维点，具有笛卡尔坐标，其位置取决于任务语义和环境（例如，手柄上的抓取点、壶嘴）。

单个 ReKep 实例是一个函数 $f: \mathbb{R}^{K \times 3} \rightarrow \mathbb{R}$ ，将关键点数组（记为 $\mathbf{k}$ ）映射到无界代价，其中 $f(\mathbf{k}) \leq 0$ 表示约束满足。函数 f 实现为无状态 Python 函数，包含对关键点的 NumPy [126] 操作，可能是非线性且非凸的。本质上，一个 ReKep 实例编码了关键点之间的一种期望空间关系，这些关键点可能属于机器人手臂、物体部件和其他智能体。




图 2: ReKep 概览。DINOv2[5] 首先在场景中提出关键点, 并叠加在原始 RGB 图像上。图像和指令输入 GPT-4o[6], 生成一系列 ReKep 约束作为 Python 程序, 指定不同任务阶段关键点之间的期望关系 ($C_{\text{sub-goal}}^{(i)}$) 以及阶段内过渡行为的要求 ($C_{\text{path}}^{(i)}$)。最后, 通过求解受生成约束的优化问题, 获得末端执行器动作的密集序列。

然而, 操作任务通常涉及多个空间关系, 并可能具有多个时间上依赖的阶段, 每个阶段包含不同的空间关系。为此, 本文将任务分解为 N 个阶段, 并使用关系关键点约束 (ReKep) 为每个阶段 $i \in \{1, \dots, N\}$ 指定两类约束: 一组子目标约束 $C_{\text{sub-goal}}^{(i)} = \{f_{\text{sub-goal},1}^{(i)}(\mathbf{k}), \dots, f_{\text{sub-goal},n}^{(i)}(\mathbf{k})\}$ 和一组路径约束 $C_{\text{path}}^{(i)} = \{f_{\text{path},1}^{(i)}(\mathbf{k}), \dots, f_{\text{path},m}^{(i)}(\mathbf{k})\}$, 其中 $f_{\text{sub-goal}}^{(i)}$ 编码一个在阶段 i 结束时需要实现的关键点关系, $f_{\text{path}}^{(i)}$ 编码一个在阶段 i 内每个状态都必须满足的关键点关系。以图 2 中的倒水任务为例, 该任务包含三个阶段: 抓取、对准和倾倒。阶段 1 的子目标约束将末端执行器拉向茶壶手柄。阶段 2 的子目标约束指定茶壶壶嘴需要位于杯口上方。此外, 阶段 2 的路径约束确保茶壶在搬运过程中保持直立以避免溢出。最后, 阶段 3 的子目标约束指定了期望的倾倒角度。

3.2 基于关系关键点约束的操作任务约束优化

利用关系关键点约束 (ReKep) 作为表示约束的通用工具, 本文采用 [7] 中的公式, 并展示如何将操作任务形式化为一个涉及 $C_{\text{sub-goal}}^{(i)}$ 和 $C_{\text{path}}^{(i)}$ 的约束优化问题。本文将末端执行器位姿记为 $\mathbf{e} \in SE(3)$ 。为执行操作任务, 本文旨在通过如下控制问题形式化获得整体离散时间轨迹 $\mathbf{e}_{1:T}$:

$$\arg \min_{\mathbf{e}_{1:T}, g_{1:N}} \sum_{i=1}^N \left[\lambda_{\text{sub-goal}}^{(i)}(\mathbf{e}_{g_i}) + \sum_{t=g_{i-1}}^{g_i} \lambda_{\text{path}}^{(i)}(\mathbf{e}_t) \right] \text{ s.t. } \begin{cases} \mathbf{e}_1 = \mathbf{e}_{\text{init}}, g_0 = 1, 0 < g_i < g_{i+1} \\ f(\mathbf{k}_{g_i}) \leq 0, \forall f \in C_{\text{sub-goal}}^{(i)} \\ f(\mathbf{k}_t) \leq 0, \forall f \in C_{\text{path}}^{(i)}, t = g_{i-1}, \dots, g_i \\ \mathbf{k}_{t+1} = h(\mathbf{k}_t, \mathbf{e}_t), t = 1, \dots, T-1 \end{cases} \quad (1)$$

其中 $\mathbf{e}_t$ 表示时刻 $t, g_i \in \{1, \dots, T\}$ 的末端执行器位姿, i 到 $i+1$ 的过渡时刻也是辅助决策变量, $\mathbf{k}_t$ 是时刻 t, h 的关键点位置数组, $\lambda_{\text{sub-goal}}^{(i)}$ 和 $\lambda_{\text{path}}^{(i)}$ 分别是子目标问题和路径问题的辅助代价函数 (例如碰撞避免)。即, 对于每个阶段 i , $\lambda_{\text{path}}^{(i)}$ 优化应在给定关系关键点约束集和辅助代价的条件下, 找到作为下一子目标的末端执行器位姿及其时刻, 以及实现该子目标的位姿序列 $\mathbf{e}_{g_{i-1}:g_i}$ 。该形式化可视为轨迹优化中的直接打靶法 [127]。

3.3 分解与算法实例化

为了实时求解方程 (1)，本文对完整问题进行分解，仅优化紧邻的下一个子目标及到达该子目标的对应路径（伪代码见算法 1）。所有优化问题均使用 SciPy[128] 实现并求解，决策变量归一化至 $[0, 1]$ 。初始采用对偶退火 [129] 结合序列最小二乘规划 [130] 作为局部优化器（约 1 秒），随后基于前次解仅用局部优化器以约 10 赫兹频率求解。

子目标问题： 首先求解子目标问题，以获得当前阶段 i 的 $\mathbf{e}_{g_i}$ ：

$$\arg \min_{\mathbf{e}_{g_i}} \lambda_{\text{sub-goal}}^{(i)}(\mathbf{e}_{g_i}) \quad \text{s.t.} \quad f(\mathbf{k}_{g_i}) \leq 0, \forall f \in \mathcal{C}_{\text{sub-goal}}^{(i)} \quad (2)$$

其中 $\lambda_{\text{sub-goal}}$ 包含了辅助控制代价：场景碰撞避免、可达性、姿态正则化、解的一致性以及双臂设置下的自碰撞（详见 A.8）。即，式 2 试图在最小化辅助代价的同时，找到一个满足 $\mathcal{C}^i$ 子目标的子目标。若某一阶段涉及抓取，则还会加入抓取度量。本文采用 AnyGrasp [131]¹。

路径问题： 在获得子目标 $\mathbf{e}_{g_i}$ 后，我们求解一条从当前末端执行器位姿 $\mathbf{e}_t$ 到子目标 $\mathbf{e}_{g_i}$ 的轨迹 $\mathbf{e}_{t:g_i}$ ：

$$\arg \min_{\mathbf{e}_{t:g_i}, g_i} \lambda_{\text{path}}^{(i)}(\mathbf{e}_{t:g_i}) \quad \text{s.t.} \quad f(\mathbf{k}_t) \leq 0, \quad \forall f \in \mathcal{C}_{\text{path}}^{(i)}, \quad \hat{t} = t, \dots, g_i \quad (3)$$

其中 λ_{path} 包含以下辅助控制代价：场景碰撞避免、可达性、路径长度、解的一致性，以及双臂设置下的自碰撞（详见 A.9）。若到子目标的距离 $\mathbf{e}_{g_i}$ 处于小容差 ϵ 内，则推进至下一阶段 $i+1$ 。

回溯： 尽管子问题可以实时频率求解以应对外部干扰，但若上一阶段的任何子目标约束不再成立（例如，在倒水任务中杯子从夹爪中脱落），系统必须能够跨阶段重新规划。具体而言，在每个控制循环中，我们检查 $\mathcal{C}_{\text{path}}^{(i)}$ 是否被违反。一旦发现违反，我们迭代回溯到前一阶段 j ，使得 $\mathcal{C}_{\text{path}}^{(j)}$ 得到满足。

关键点的前向模型： 为了求解方程 2 和方程 3，必须在优化过程中利用前向模型 h 来估计 $\Delta \mathbf{k}$ （基于 $\Delta \mathbf{e}$ ）。与先前工作 [4] 一致，我们假设末端执行器与“被抓取的关键点”（属于同一物体或部件的刚性关键点组；由第 3.4 节所述的分割模型获得）之间满足刚性假设。即，给定末端执行器位姿的变化 $\Delta \mathbf{e}$ ，我们可以通过施加相同的相对刚性变换 $\mathbf{k}'[\text{grasped}] = \mathbf{T} \Delta \mathbf{e} \cdot \mathbf{k}[\text{grasped}]$ 来计算关键点位置的变化，同时假设其他关键点保持静止。我们指出这是一个“局部”假设，仅在求解问题的短时间（0.1 秒）内成立。实际关键点位置通过 20 赫兹的视觉输入进行跟踪，并用于每个新问题。对于更具挑战性的场景（例如动态或接触丰富的任务），可以使用基于学习或物理的模型。

3.4 关键点提议与 ReKep 生成

为了使系统能够在给定自由形式任务指令的情况下在自然环境中执行任务，我们设计了一条使用大型视觉模型和视觉语言模型进行关键点提议和 ReKep 生成的流程，分别讨论如下：

关键点提议： 给定 RGB 图像 $\mathbb{R}^{h \times w \times 3}$ ，我们首先从 DINOv2 [5] 中提取块级特征 $\mathbf{F}_{\text{patch}} \in \mathbb{R}^{h' \times w' \times d}$ 。然后执行双线性插值将特征上采样到原始图像尺寸， $\mathbf{F}_{\text{interp}} \in \mathbb{R}^{h \times w \times d}$ 。为确保提议覆盖场景中所有相关物体，我们使用 Segment Anything 提取场景中的所有掩码 $\mathbf{M} = \{\mathbf{m}_1, \mathbf{m}_2, \dots, \mathbf{m}_n\}$ 。¹ 由于 AnyGrasp 是抓取检测器而非度量，且在优化循环中计算开销较大，我们总是返回最接近指定“抓取关键点”的抓取，利用与抓取相关的 ReKep 总是将末端执行器上的虚拟关键点与实际关键点关联这一事实。




图 3: 实验任务与优化结果可视化。设计了七项任务以验证系统在不同方面的能力, 包括结合常识知识的自然场景规范、具有时空依赖性的多阶段任务、具备几何感知的双臂协调, 以及与人类协作和受到干扰时的反应能力。

(SAM) [132]。对于每个掩码 j , 我们使用 k 均值聚类对掩码特征 $\mathbf{F}_{\text{interp}}[\mathbf{m}_j]$ 进行聚类, 聚类数设为 $k = 5$, 采用余弦相似度度量。聚类中心用作关键点候选, 并通过标定的 RGB-D 相机投影到世界坐标系 $\mathbb{R}^3$ 。与其他候选距离在 8 厘米以内的候选会被过滤。总体而言, 我们发现该过程能够有效识别出大量细粒度且语义上有意义的物体区域。

ReKep 生成: 获得关键点候选后, 我们将其叠加在原始 RGB 图像上并标注数字标记。结合任务的语言指令, 我们使用视觉提示查询 GPT-4o[6], 以生成所需阶段数以及每个阶段 i 对应的子目标约束 $\mathcal{C}^{(i)}$ 子目标和路径约束 $\mathcal{C}_{\text{path}}^{(i)}$ (提示见 A.6)。值得注意的是, 这些函数并不直接操作关键点位置的数值。相反, 我们利用视觉语言模型 (VLM) 的优势, 将空间关系指定为算术运算, 例如关键点之间的 L2 距离或点积, 这些运算仅在由专用 3D 跟踪器跟踪的实际关键点位置调用时才实例化。此外, 在一组关键点位置上使用算术运算的一个重要优势是, 当提供足够点且相关点之间的刚性得到强制时, 可以完整指定三维旋转 $SO(3)$, 但这仅在任务语义需要时才进行。这使得 VLM 能够在三维笛卡尔空间中通过算术运算推理三维旋转, 从而有效避免了处理其他三维旋转表示以及进行数值计算的需要。

4 实验

我们旨在回答以下研究问题: (1) 我们的框架在自动制定和合成操作行为方面表现如何 (第 4.1 节)? (2) 我们的系统能否泛化到新的

物体与操作策略（第 4.2 节）？(3) 各个组件如何导致系统的失败案例（第 4.3 节）？我们在两个真实机器人平台上验证了 ReKep：一个轮式单臂平台和一个固定式双臂平台（图 3）。更多实现细节见附录，包括关键点提议（A.5）、VLM 查询（A.6）、点跟踪器（A.7）、子目标求解器（A.8）和路径求解器（A.9）。

4.1 面向野外与双臂操作的 ReKep

任务。我们特意选择了一组任务（如图 3 所示），旨在考察系统的多阶段（**m**）、野外（**w**）、双臂（**b**）和反应式（**r**）行为。任务及其特征包括：倒茶（**m, w, r**）、放书（**w**）、回收易拉罐（**w**）、封箱（**w, r**）、叠衣服（**b**）、装鞋（**b**）和协作折叠（**b, r**）。我们进一步在外部干扰（记为“Dist.”）下评估其中三个任务，在执行过程中改变任务物体的位姿。

度量与基线。每个设置进行 10 次试验，物体位姿随机化。成功率报告于表 1。我们与 VoxPoser [106] 作为基线进行比较。我们评估系统的两个变体：“Auto”使用基础模型自动生成 ReKep，“Annotated (Annot.)”使用人工标注的 ReKep。

结果。与基线相比，关系关键点约束（ReKep）能够有效应对每项任务的核心挑战。例如，它能在多阶段任务中构建正确的时间依赖关系（如倒水前壶嘴需与杯子对齐），利用常识知识（如可乐罐应回收），并在双臂设置（如同时折叠左袖和右袖）和人机协作设置（如与人类一起对齐四角折叠大毯子）中构建协调行为。结合优化框架，它还能在收纳书籍任务中于受限空间内生成运动学上具有挑战性的行为，并在打包鞋子任务中找到一个可行解，将两只鞋紧密地放入小体积内。由于关键点以高频率跟踪，系统能够对外部干扰做出反应，并在阶段内和跨阶段重新规划。尽管结果有前景，我们也识别出若干局限性，将在第 5 节讨论。

Task	VoxPoser	ReKep	
		Auto	Annot
Mobile Arm			
Pour Tea	0/10	3/10	8/10
Recycle Can	3/10	6/10	8/10
Stow Book	0/10	3/10	6/10
Tape Box	4/10	7/10	8/10
Dual-Arm			
Fold Garment	0/10	5/10	6/10
Pack Shoes	0/10	3/10	5/10
Collab. Folding	0/10	4/10	7/10
Total (%)	10.0%	44.3%	68.6%

表 1：轮式单臂和固定式双臂平台上的成功率。

Task (Dist.)	VoxPoser	ReKep	
		Auto	Annot.
Pour Tea	0/10	2/10	4/10
Tape Box	2/10	3/10	5/10
Collab. Folding	0/10	3/10	5/10
Total (%)	6.7%	26.7%	46.7%

表 2：两个机器人平台在外部干扰下的成功率。




图 4：系统错误分解。

4.2 操作策略的泛化

任务。我们通过聚焦单一任务——衣物折叠，但使用 8 个独特类别的衣物，系统评估新颖操作策略的构建方式，每类衣物要求独特的折叠方式，并需要几何和常识推理。评估在双臂平台上进行，带来了双臂协调方面的额外挑战。

度量。我们使用 GPT-4o，提示仅包含通用指令，无上下文示例。“策略成功”衡量生成的关系关键点约束是否可行，测试关键点提议模块和视觉语言模型（VLM），“执行成功”衡量在给定每件衣物可行策略下的系统成功率。每项均进行 10 次试验。

结果。有趣的是，我们观察到不同类别间截然不同的策略，其中许多与人类折叠每件衣物的方式一致。例如，它能识别出两个




图 5：关系关键点约束（ReKep）折叠不同类别衣物的新颖双臂策略及其成功率。由于此任务中关系关键点约束始终一次关联两个点，若两个关键点需对齐则用箭头连接。关键点的颜色表示顺序。在毛衣任务中，先用双臂同时折叠两只袖子，然后双臂抓住领口与底部对齐。

在完全折叠衣物之前，袖子通常先被折叠在一起。在无需使用双臂的情况下，类似于人类折叠衣物的方式，仅使用单臂。然而，我们确实观察到视觉语言模型（VLM）可能会遗漏操作者期望的某些折叠步骤，但我们认识到这本质上是一个开放性问题，通常取决于个人偏好。

4.3 系统错误分解

该框架的模块化设计因其可解释性而在分析系统错误方面具有优势。在本节中，我们通过人工检查表 1 中报告实验的失败案例进行实证研究，随后利用这些案例计算各模块引发错误的可能性，同时考虑它们在流程中的时间依赖性。结果如图 4 所示。在不同模块中，点跟踪器产生的错误占比最大，因为频繁且间歇性的遮挡对精确跟踪构成了显著挑战。关键点提议模块和视觉语言模型（VLM）也产生了相当比例的错误，常见情况包括提议模块遗漏某些关键点以及视觉语言模型引用了错误的关键点。另一方面，尽管时间预算有限，优化模块对失败的贡献并不大，因为每个问题通常存在许多可能的解决方案。其他模块，如分割、三维重建和底层控制器，也导致了一些失败案例，但与其他模块相比相对不显著。

5 结论与局限性

本文提出了关系关键点约束（Relational Keypoint Constraints, ReKep），这是一种基于约束的结构化任务表示方法，通过在语义关键点上施加约束来规定机器人手臂、物体（部件）以及环境中其他智能体之间的期望关系。结合点跟踪器，我们证明了 ReKep 约束可以在分层优化框架中被反复且高效地求解，从而作为一个以实时频率运行的闭环策略。我们还展示了 ReKep 的独特优势，即它可以由大型视觉模型和视觉语言模型自动合成。结果在两个机器人平台以及多种任务上得到展示，这些任务具有多阶段、野外、双臂和反应式行为的特点，且均无需任务特定数据、额外训练或环境模型。尽管前景广阔，但仍存在若干局限性。首先，优化框架依赖于基于刚性假设的关键点前向模型，尽管高频反馈回路放宽了对模型精度的要求。其次，ReKep 依赖精确的点跟踪来在闭环中正确优化动作，而由于严重的间歇性遮挡，这本身就是一个具有挑战性的三维视觉任务。最后，当前公式假设每个任务具有固定的阶段序列（即骨架）。使用不同骨架进行重新规划需要以高频运行关键点提议和视觉语言模型，这带来了相当大的计算挑战。关于局限性的扩展讨论见附录 A.11。

致谢

这项工作部分得到了斯坦福以人为本人工智能研究院、ONR MURI N00014-21-1-2801、ONR MURI N00014-22-1-2740 和 Schmidt Sciences 的支持。张若涵部分得到了 Wu Tsai 人类表现联盟奖学金的支持。双臂硬件部分得到了斯坦福 TML 的支持。我们感谢匿名审稿人、Albert Wu、Yifan Hou、Adrien Gaidon、Adam Harley、Christopher Agia、Edward Schmerling、Marco Pavone、Yunfan Jiang、Yixuan Wang、Sirui Chen、Chengshu Li、Josiah Wong、Wensi Ai、Weiyu Liu、Mengdi Xu、Yihe Tang、Chelsea Ye、Mijiu Mili 以及斯坦福视觉与学习实验室的成员，感谢他们富有成效的讨论、对实验的帮助和支持。

参考文献

- [1] L. P. Kaelbling and T. Lozano-Pérez. Hierarchical planning in the now. In *Workshops at the Twenty-Fourth AAAI Conference on Artificial Intelligence*, 2010.
- [2] D. Driess, J.-S. Ha, M. Toussaint, and R. Tedrake. Learning models as functionals of signed-distance fields for manipulation planning. In *Conference on robot learning*, pages 245–255. PMLR, 2022.
- [3] A. Simeonov, Y. Du, A. Tagliasacchi, J. B. Tenenbaum, A. Rodriguez, P. Agrawal, and V. Sitzmann. Neural descriptor fields: Se (3)-equivariant object representations for manipulation. In *2022 International Conference on Robotics and Automation (ICRA)*, pages 6394–6400. IEEE, 2022.
- [4] L. Manuelli, W. Gao, P. Florence, and R. Tedrake. kpm: Keypoint affordances for category-level robotic manipulation. In *The International Symposium of Robotics Research*, pages 132–157. Springer, 2019.
- [5] M. Oquab, T. Darcet, T. Moutakanni, H. Vo, M. Szafraniec, V. Khalidov, P. Fernandez, D. Haziza, F. Massa, A. El-Nouby, et al. Dinov2: Learning robust visual features without supervision. *arXiv preprint arXiv:2304.07193*, 2023.
- [6] OpenAI. Gpt-4 technical report. *arXiv*, 2023.
- [7] M. Toussaint, J. Harris, J.-S. Ha, D. Driess, and W. Hönig. Sequence-of-constraints mpc: Reactive timing-optimal control of sequential manipulation. In *2022 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 13753–13760. IEEE, 2022.
- [8] L. P. Kaelbling and T. Lozano-Pérez. Integrated task and motion planning in belief space. *The International Journal of Robotics Research*, 32(9-10):1194–1227, 2013.
- [9] S. Srivastava, E. Fang, L. Riano, R. Chitnis, S. Russell, and P. Abbeel. Combined task and motion planning through an extensible planner-independent interface layer. In *2014 IEEE international conference on robotics and automation (ICRA)*, 2014.
- [10] A. Byravan and D. Fox. Se3-nets: Learning rigid body motion using deep neural networks. In *2017 IEEE International Conference on Robotics and Automation (ICRA)*, pages 173–180. IEEE, 2017.
- [11] N. T. Dantam, Z. K. Kingston, S. Chaudhuri, and L. E. Kavraki. An incremental constraint-based framework for task and motion planning. *The International Journal of Robotics Research*, 37(10):1134–1151, 2018.
- [12] T. Migimatsu and J. Bohg. Object-centric task and motion planning in dynamic environments. *IEEE Robotics and Automation Letters*, 5(2):844–851, 2020.
- [13] C. R. Garrett, R. Chitnis, R. Holladay, B. Kim, T. Silver, L. P. Kaelbling, and T. Lozano-Pérez. Integrated task and motion planning. *Annual review of control, robotics, and autonomous systems*, 4:265–293, 2021.

- [14] A. Curtis, X. Fang, L. P. Kaelbling, T. Lozano-Pérez, and C. R. Garrett. Long-horizon manipulation of unknown objects via task and motion planning with estimated affordances. In *2022 International Conference on Robotics and Automation (ICRA)*, pages 1940–1946. IEEE, 2022.
- [15] Y. Labbé, L. Manuelli, A. Mousavian, S. Tyree, S. Birchfield, J. Tremblay, J. Carpentier, M. Aubry, D. Fox, and J. Sivic. Megapose: 6d pose estimation of novel objects via render & compare. In *Proceedings of the 6th Conference on Robot Learning (CoRL)*, 2022.
- [16] S. Tyree, J. Tremblay, T. To, J. Cheng, T. Mosier, J. Smith, and S. Birchfield. 6-dof pose estimation of household objects for robotic manipulation: An accessible dataset and benchmark. In *2022 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 13081–13088. IEEE, 2022.
- [17] C. Pan, B. Okorn, H. Zhang, B. Eisner, and D. Held. Tax-pose: Task-specific cross-pose estimation for robot manipulation. In *Conference on Robot Learning*, pages 1783–1792. PMLR, 2023.
- [18] B. Wen, W. Yang, J. Kautz, and S. Birchfield. Foundationpose: Unified 6d pose estimation and tracking of novel objects. *arXiv preprint arXiv:2312.08344*, 2023.
- [19] I. Lenz, R. A. Knepper, and A. Saxena. Deepmpc: Learning deep latent features for model predictive control. In *Robotics: Science and Systems*, volume 10. Rome, Italy, 2015.
- [20] M. B. Chang, T. Ullman, A. Torralba, and J. B. Tenenbaum. A compositional object-based approach to learning physical dynamics. *arXiv preprint arXiv:1612.00341*, 2016.
- [21] P. Battaglia, R. Pascanu, M. Lai, D. Jimenez Rezende, et al. Interaction networks for learning about objects, relations and physics. *Advances in neural information processing systems*, 29, 2016.
- [22] A. Sanchez-Gonzalez, N. Heess, J. T. Springenberg, J. Merel, M. Riedmiller, R. Hadsell, and P. Battaglia. Graph networks as learnable physics engines for inference and control. In *International Conference on Machine Learning*, pages 4470–4479. PMLR, 2018.
- [23] E. Jang, C. Devin, V. Vanhoucke, and S. Levine. Grasp2vec: Learning object representations from self-supervised grasping. *arXiv preprint arXiv:1811.06964*, 2018.
- [24] J. Tremblay, T. To, B. Sundaralingam, Y. Xiang, D. Fox, and S. Birchfield. Deep object pose estimation for semantic robotic grasping of household objects. *arXiv preprint arXiv:1809.10790*, 2018.
- [25] Z. Xu, J. Wu, A. Zeng, J. B. Tenenbaum, and S. Song. Densephysnet: Learning dense physical object representations via multi-step dynamic interactions. *arXiv preprint arXiv:1906.03853*, 2019.
- [26] J. Mao, C. Gan, P. Kohli, J. B. Tenenbaum, and J. Wu. The neuro-symbolic concept learner: Interpreting scenes, words, and sentences from natural supervision. *arXiv preprint arXiv:1904.12584*, 2019.
- [27] C. P. Burgess, L. Matthey, N. Watters, R. Kabra, I. Higgins, M. Botvinick, and A. Lerchner. Monet: Unsupervised scene decomposition and representation. *arXiv preprint arXiv:1901.11390*, 2019.
- [28] L. Hewing, K. P. Wabersich, M. Menner, and M. N. Zeilinger. Learning-based model predictive control: Toward safe learning in control. *Annual Review of Control, Robotics, and Autonomous Systems*, 3:269–296, 2020.

- [29] F. Locatello, D. Weissenborn, T. Unterthiner, A. Mahendran, G. Heigold, J. Uszkoreit, A. Dosovitskiy, and T. Kipf. Object-centric learning with slot attention. *Advances in neural information processing systems*, 33:11525–11538, 2020.
- [30] N. Heravi, A. Wahid, C. Lynch, P. Florence, T. Armstrong, J. Tompson, P. Sermanet, J. Bohg, and D. Dwibedi. Visuomotor control in multi-object scenes using object-aware representations. In *2023 IEEE International Conference on Robotics and Automation (ICRA)*, pages 9515–9522. IEEE, 2023.
- [31] Y. Zhu, Z. Jiang, P. Stone, and Y. Zhu. Learning generalizable manipulation policies with object-centric 3d representations. *arXiv preprint arXiv:2310.14386*, 2023.
- [32] W. Yuan, C. Paxton, K. Desingh, and D. Fox. Sornet: Spatial object-centric representations for sequential manipulation. In *Conference on Robot Learning*, pages 148–157. PMLR, 2022.
- [33] S. Cheng, C. Garrett, A. Mandlekar, and D. Xu. Nod-tamp: Multi-step manipulation planning with neural object descriptors. *arXiv preprint arXiv:2311.01530*, 2023.
- [34] J. Hsu, J. Mao, J. Tenenbaum, and J. Wu. What’s left? concept grounding with logic-enhanced foundation models. *Advances in Neural Information Processing Systems*, 36, 2024.
- [35] Y. Li, J. Wu, R. Tedrake, J. B. Tenenbaum, and A. Torralba. Learning particle dynamics for manipulating rigid bodies, deformable objects, and fluids. *arXiv preprint arXiv:1810.01566*, 2018.
- [36] X. Lin, C. Qi, Y. Zhang, Z. Huang, K. Fragkiadaki, Y. Li, C. Gan, and D. Held. Planning with spatial-temporal abstraction from point clouds for deformable object manipulation. *arXiv preprint arXiv:2210.15751*, 2022.
- [37] Y. Wang, Y. Li, K. Driggs-Campbell, L. Fei-Fei, and J. Wu. Dynamic-resolution model learning for object pile manipulation. *arXiv preprint arXiv:2306.16700*, 2023.
- [38] H. Shi, H. Xu, S. Clarke, Y. Li, and J. Wu. Robocook: Long-horizon elasto-plastic object manipulation with diverse tools. *arXiv preprint arXiv:2306.14447*, 2023.
- [39] X. Lin, Y. Wang, Z. Huang, and D. Held. Learning visible connectivity dynamics for cloth smoothing. In *Conference on Robot Learning*, pages 256–266. PMLR, 2022.
- [40] J. Abou-Chakra, K. Rana, F. Dayoub, and N. Sünderhauf. Physically embodied gaussian splatting: A realtime correctable world model for robotics. *arXiv preprint arXiv:2406.10788*, 2024.
- [41] D. Bauer, Z. Xu, and S. Song. Doughnet: A visual predictive model for topological manipulation of deformable objects. *arXiv preprint arXiv:2404.12524*, 2024.
- [42] T. Schmidt, R. Newcombe, and D. Fox. Self-supervised visual descriptor learning for dense correspondence. *IEEE Robotics and Automation Letters*, 2(2):420–427, 2016.
- [43] P. R. Florence, L. Manuelli, and R. Tedrake. Dense object nets: Learning dense visual object descriptors by and for robotic manipulation. *arXiv preprint arXiv:1806.08756*, 2018.
- [44] T. D. Kulkarni, A. Gupta, C. Ionescu, S. Borgeaud, M. Reynolds, A. Zisserman, and V. Mnih. Unsupervised learning of object keypoints for perception and control. *Advances in neural information processing systems*, 32, 2019.
- [45] Z. Qin, K. Fang, Y. Zhu, L. Fei-Fei, and S. Savarese. Keto: Learning keypoint representations for tool manipulation. In *2020 IEEE International Conference on Robotics and Automation (ICRA)*, pages 7278–7285. IEEE, 2020.

- [46] P. Sundaresan, J. Grannen, B. Thananjeyan, A. Balakrishna, M. Laskey, K. Stone, J. E. Gonzalez, and K. Goldberg. Learning rope manipulation policies using dense object descriptors trained on synthetic depth data. In *2020 IEEE International Conference on Robotics and Automation (ICRA)*, pages 9411–9418. IEEE, 2020.
- [47] L. Manuelli, Y. Li, P. Florence, and R. Tedrake. Keypoints into the future: Self-supervised correspondence in model-based reinforcement learning. *arXiv preprint arXiv:2009.05085*, 2020.
- [48] B. Chen, P. Abbeel, and D. Pathak. Unsupervised learning of visual 3d keypoints for control. In *International Conference on Machine Learning*, pages 1539–1549. PMLR, 2021.
- [49] A. Simeonov, Y. Du, Y.-C. Lin, A. R. Garcia, L. P. Kaelbling, T. Lozano-Pérez, and P. Agrawal. Se (3)-equivariant relational rearrangement with neural descriptor fields. In *Conference on Robot Learning*, pages 835–846. PMLR, 2023.
- [50] M. Vecerik, C. Doersch, Y. Yang, T. Davchev, Y. Aytar, G. Zhou, R. Hadsell, L. Agapito, and J. Scholz. Robotap: Tracking arbitrary points for few-shot visual imitation. *arXiv preprint arXiv:2308.15975*, 2023.
- [51] E. Chun, Y. Du, A. Simeonov, T. Lozano-Perez, and L. Kaelbling. Local neural descriptor fields: Locally conditioned object representations for manipulation. In *2023 IEEE International Conference on Robotics and Automation (ICRA)*, pages 1830–1836. IEEE, 2023.
- [52] S. Bahl, R. Mendonca, L. Chen, U. Jain, and D. Pathak. Affordances from human videos as a versatile representation for robotics. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 13778–13790, 2023.
- [53] C. Wen, X. Lin, J. So, K. Chen, Q. Dou, Y. Gao, and P. Abbeel. Any-point trajectory modeling for policy learning. *arXiv preprint arXiv:2401.00025*, 2023.
- [54] H. Bharadhwaj, R. Mottaghi, A. Gupta, and S. Tulsiani. Track2act: Predicting point tracks from internet videos enables diverse zero-shot robot manipulation, 2024.
- [55] Z. Kingston, M. Moll, and L. E. Kavraki. Sampling-based methods for motion planning with constraints. *Annual review of control, robotics, and autonomous systems*, 1:159–185, 2018.
- [56] N. Ratliff, M. Zucker, J. A. Bagnell, and S. Srinivasa. Chomp: Gradient optimization techniques for efficient motion planning. In *2009 IEEE international conference on robotics and automation*, pages 489–494. IEEE, 2009.
- [57] J. Schulman, Y. Duan, J. Ho, A. Lee, I. Awwal, H. Bradlow, J. Pan, S. Patil, K. Goldberg, and P. Abbeel. Motion planning with sequential convex optimization and convex collision checking. *The International Journal of Robotics Research*, 33(9):1251–1270, 2014.
- [58] B. Sundaralingam, S. K. S. Hari, A. Fishman, C. Garrett, K. Van Wyk, V. Blukis, A. Millane, H. Oleynikova, A. Handa, F. Ramos, et al. Curobo: Parallelized collision-free robot motion generation. In *2023 IEEE International Conference on Robotics and Automation (ICRA)*, pages 8112–8119. IEEE, 2023.
- [59] T. Marcucci, J. Umenberger, P. Parrilo, and R. Tedrake. Shortest paths in graphs of convex sets. *SIAM Journal on Optimization*, 34(1):507–532, 2024.
- [60] N. D. Ratliff, J. Issac, D. Kappler, S. Birchfield, and D. Fox. Riemannian motion policies. *arXiv preprint arXiv:1801.02854*, 2018.
- [61] M. Posa, S. Kuindersma, and R. Tedrake. Optimization and stabilization of trajectories for constrained dynamical systems. In *2016 IEEE International Conference on Robotics and Automation (ICRA)*, pages 1366–1373. IEEE, 2016.

- [62] I. Mordatch, E. Todorov, and Z. Popović. Discovery of complex behaviors through contact-invariant optimization. *ACM Transactions on Graphics (ToG)*, 31(4):1–8, 2012.
- [63] I. Mordatch, Z. Popović, and E. Todorov. Contact-invariant optimization for hand manipulation. In *Proceedings of the ACM SIGGRAPH/Eurographics symposium on computer animation*, pages 137–144, 2012.
- [64] M. Posa, C. Cantu, and R. Tedrake. A direct method for trajectory optimization of rigid bodies through contact. *The International Journal of Robotics Research*, 33(1):69–81, 2014.
- [65] T. Howell, N. Gileadi, S. Tunyasuvunakool, K. Zakka, T. Erez, and Y. Tassa. Predictive sampling: Real-time behaviour synthesis with mujoco. *arXiv preprint arXiv:2212.00541*, 2022.
- [66] Z. Liu, G. Zhou, J. He, T. Marcucci, F.-F. Li, J. Wu, and Y. Li. Model-based control with sparse neural dynamics. *Advances in Neural Information Processing Systems*, 36, 2024.
- [67] K. M. Lynch and M. T. Mason. Stable pushing: Mechanics, controllability, and planning. *The international journal of robotics research*, 15(6):533–556, 1996.
- [68] Y. Hou, Z. Jia, and M. T. Mason. Fast planning for 3d any-pose-reorienting using pivoting. In *2018 IEEE International Conference on Robotics and Automation (ICRA)*, pages 1631–1638. IEEE, 2018.
- [69] J.-P. Sleiman, F. Farshidian, and M. Hutter. Versatile multicontact planning and control for legged loco-manipulation. *Science Robotics*, 8(81):eadg5014, 2023.
- [70] W. Yang and M. Posa. Dynamic on-palm manipulation via controlled sliding. *arXiv preprint arXiv:2405.08731*, 2024.
- [71] B. P. Graesdal, S. Y. Chia, T. Marcucci, S. Morozov, A. Amice, P. A. Parrilo, and R. Tedrake. Towards tight convex relaxations for contact-rich manipulation. *arXiv preprint arXiv:2402.10312*, 2024.
- [72] K. Yunt and C. Glocker. Trajectory optimization of mechanical hybrid systems using sumt. In *9th IEEE International Workshop on Advanced Motion Control, 2006.*, pages 665–671. IEEE, 2006.
- [73] K. Yunt and C. Glocker. A combined continuation and penalty method for the determination of optimal hybrid mechanical trajectories. In *Iutam Symposium on Dynamics and Control of Nonlinear Systems with Uncertainty: Proceedings of the IUTAM Symposium held in Nanjing, China, September 18-22, 2006*, pages 187–196. Springer, 2007.
- [74] K. Yunt. An augmented lagrangian based shooting method for the optimal trajectory generation of switching lagrangian systems. *Dynamics of Continuous, Discrete and Impulsive Systems Series B: Applications and Algorithms*, 18(5):615–645, 2011.
- [75] F. Lagriffoul, D. Dimitrov, A. Saffiotti, and L. Karlsson. Constraint propagation on interval bounds for dealing with geometric backtracking. In *2012 IEEE/RSJ International Conference on Intelligent Robots and Systems*, pages 957–964. IEEE, 2012.
- [76] F. Lagriffoul, D. Dimitrov, J. Bidot, A. Saffiotti, and L. Karlsson. Efficiently combining task and motion planning using geometric constraints. *The International Journal of Robotics Research*, 33(14):1726–1747, 2014.
- [77] T. Lozano-Pérez and L. P. Kaelbling. A constraint-based method for solving sequential manipulation planning problems. In *2014 IEEE/RSJ International Conference on Intelligent Robots and Systems*, pages 3684–3691. IEEE, 2014.

- [78] Z. Yang, J. Mao, Y. Du, J. Wu, J. B. Tenenbaum, T. Lozano-Pérez, and L. P. Kaelbling. Compositional diffusion-based continuous constraint solvers. *arXiv preprint arXiv:2309.00966*, 2023.
- [79] T. Silver, R. Chitnis, J. Tenenbaum, L. P. Kaelbling, and T. Lozano-Pérez. Learning symbolic operators for task and motion planning. In *2021 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 3182–3189. IEEE, 2021.
- [80] B. Vu, T. Migimatsu, and J. Bohg. Coast: Constraints and streams for task and motion planning. *arXiv preprint arXiv:2405.08572*, 2024.
- [81] M. Toussaint. Logic-geometric programming: An optimization-based approach to combined task and motion planning. In *Twenty-Fourth International Joint Conference on Artificial Intelligence*, 2015.
- [82] M. Toussaint and M. Lopes. Multi-bound tree search for logic-geometric programming in cooperative manipulation domains. In *2017 IEEE International Conference on Robotics and Automation (ICRA)*, pages 4044–4051. IEEE, 2017.
- [83] M. A. Toussaint, K. R. Allen, K. A. Smith, and J. B. Tenenbaum. Differentiable physics and stable modes for tool-use and manipulation planning. *Robotics: Science and Systems Foundation*, 2018.
- [84] J.-S. Ha, D. Driess, and M. Toussaint. A probabilistic framework for constrained manipulations and task and motion planning under uncertainty. In *2020 IEEE International Conference on Robotics and Automation (ICRA)*, pages 6745–6751. IEEE, 2020.
- [85] T. Xue, A. Razmjoo, and S. Calinon. D-lgp: Dynamic logicgeometric program for reactive task and motion planning. *arXiv preprint arXiv:2312.02731*, 2023.
- [86] D. Driess, O. Oguz, J.-S. Ha, and M. Toussaint. Deep visual heuristics: Learning feasibility of mixed-integer programs for manipulation planning. In *2020 IEEE international conference on robotics and automation (ICRA)*, pages 9563–9569. IEEE, 2020.
- [87] G. Sutanto, I. R. Fernández, P. Englert, R. K. Ramachandran, and G. Sukhatme. Learning equality constraints for motion planning on manifolds. In *Conference on Robot Learning*, pages 2292–2305. PMLR, 2021.
- [88] Z. Yang, C. R. Garrett, T. Lozano-Pérez, L. Kaelbling, and D. Fox. Sequence-based plan feasibility prediction for efficient task and motion planning. *arXiv preprint arXiv:2211.01576*, 2022.
- [89] G. S. Camps, R. Dyro, M. Pavone, and M. Schwager. Learning deep sdf maps online for robot navigation and exploration. *arXiv preprint arXiv:2207.10782*, 2022.
- [90] Y. Hu, Q. Xie, V. Jain, J. Francis, J. Patrikar, N. Keetha, S. Kim, Y. Xie, T. Zhang, Z. Zhao, et al. Toward general-purpose robots via foundation models: A survey and meta-analysis. *arXiv preprint arXiv:2312.08782*, 2023.
- [91] R. Firoozi, J. Tucker, S. Tian, A. Majumdar, J. Sun, W. Liu, Y. Zhu, S. Song, A. Kapoor, K. Hausman, et al. Foundation models in robotics: Applications, challenges, and the future. *arXiv preprint arXiv:2312.07843*, 2023.
- [92] K. Kawaharazuka, T. Matsushima, A. Gambardella, J. Guo, C. Paxton, and A. Zeng. Real-world robot applications of foundation models: A review. *arXiv preprint arXiv:2402.05741*, 2024.
- [93] S. Yang, O. Nachum, Y. Du, J. Wei, P. Abbeel, and D. Schuurmans. Foundation models for decision making: Problems, methods, and opportunities. *arXiv preprint arXiv:2303.04129*, 2023.

- [94] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, et al. Learning transferable visual models from natural language supervision. In *International Conference on Machine Learning*, pages 8748–8763. PMLR, 2021.
- [95] A. Ramesh, M. Pavlov, G. Goh, S. Gray, C. Voss, A. Radford, M. Chen, and I. Sutskever. Zero-shot text-to-image generation. In *International conference on machine learning*, pages 8821–8831. Pmlr, 2021.
- [96] J. Li, D. Li, C. Xiong, and S. Hoi. Blip: Bootstrapping language-image pre-training for unified vision-language understanding and generation. In *International conference on machine learning*, pages 12888–12900. PMLR, 2022.
- [97] J. Achiam, S. Adler, S. Agarwal, L. Ahmad, I. Akkaya, F. L. Aleman, D. Almeida, J. Altenschmidt, S. Altman, S. Anadkat, et al. Gpt-4 technical report. *arXiv preprint arXiv:2303.08774*, 2023.
- [98] J. Li, D. Li, S. Savarese, and S. Hoi. Blip-2: Bootstrapping language-image pre-training with frozen image encoders and large language models. *arXiv preprint arXiv:2301.12597*, 2023.
- [99] H. Huang, F. Lin, Y. Hu, S. Wang, and Y. Gao. Copa: General robotic manipulation through spatial constraints of parts with foundation models. *arXiv preprint arXiv:2403.08248*, 2024.
- [100] F. Liu, K. Fang, P. Abbeel, and S. Levine. Moka: Open-vocabulary robotic manipulation through mark-based visual prompting. *arXiv preprint arXiv:2403.03174*, 2024.
- [101] S. Nasiriany, F. Xia, W. Yu, T. Xiao, J. Liang, I. Dasgupta, A. Xie, D. Driess, A. Wahid, Z. Xu, et al. Pivot: Iterative visual prompting elicits actionable knowledge for vlms. *arXiv preprint arXiv:2402.07872*, 2024.
- [102] Y. Hu, F. Lin, T. Zhang, L. Yi, and Y. Gao. Look before you leap: Unveiling the power of gpt-4v in robotic vision-language planning. *arXiv preprint arXiv:2311.17842*, 2023.
- [103] Y. Du, M. Yang, P. Florence, F. Xia, A. Wahid, B. Ichter, P. Sermanet, T. Yu, P. Abbeel, J. B. Tenenbaum, et al. Video language planning. *arXiv preprint arXiv:2310.10625*, 2023.
- [104] Y. Hong, H. Zhen, P. Chen, S. Zheng, Y. Du, Z. Chen, and C. Gan. 3d-llm: Injecting the 3d world into large language models. *Advances in Neural Information Processing Systems*, 36: 20482–20494, 2023.
- [105] B. Chen, Z. Xu, S. Kirmani, B. Ichter, D. Sadigh, L. Guibas, and F. Xia. Spatialvlm: Endowing vision-language models with spatial reasoning capabilities. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 14455–14465, 2024.
- [106] W. Huang, C. Wang, R. Zhang, Y. Li, J. Wu, and L. Fei-Fei. Voxposer: Composable 3d value maps for robotic manipulation with language models. *arXiv preprint arXiv:2307.05973*, 2023.
- [107] A. Brohan, N. Brown, J. Carbajal, Y. Chebotar, X. Chen, K. Choromanski, T. Ding, D. Driess, A. Dubey, C. Finn, et al. Rt-2: Vision-language-action models transfer web knowledge to robotic control. *arXiv preprint arXiv:2307.15818*, 2023.
- [108] J. Gao, B. Sarkar, F. Xia, T. Xiao, J. Wu, B. Ichter, A. Majumdar, and D. Sadigh. Physically grounded vision-language models for robotic manipulation. *arXiv preprint arXiv:2309.02561*, 2023.
- [109] Y. Wang, T.-H. Wang, J. Mao, M. Hagenow, and J. Shah. Grounding language plans in demonstrations through counterfactual perturbations. *arXiv preprint arXiv:2403.17124*, 2024.

- [110] J. Hsu, J. Mao, and J. Wu. Ns3d: Neuro-symbolic grounding of 3d objects and relations. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 2614–2623, 2023.
- [111] J. Gao, B. Sarkar, F. Xia, T. Xiao, J. Wu, B. Ichter, A. Majumdar, and D. Sadigh. Physically grounded vision-language models for robotic manipulation. In *2024 IEEE International Conference on Robotics and Automation (ICRA)*, pages 12462–12469. IEEE, 2024.
- [112] W. Yuan, J. Duan, V. Blukis, W. Pumacay, R. Krishna, A. Murali, A. Mousavian, and D. Fox. Robopoint: A vision-language model for spatial affordance prediction for robotics. *arXiv preprint arXiv:2406.10721*, 2024.
- [113] J. Duan, W. Yuan, W. Pumacay, Y. R. Wang, K. Ehsani, D. Fox, and R. Krishna. Manipulate-anything: Automating real-world robots using vision-language models. *arXiv preprint arXiv:2406.18915*, 2024.
- [114] S. Tong, Z. Liu, Y. Zhai, Y. Ma, Y. LeCun, and S. Xie. Eyes wide shut? exploring the visual shortcomings of multimodal llms. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 9568–9578, 2024.
- [115] T. Thrush, R. Jiang, M. Bartolo, A. Singh, A. Williams, D. Kiela, and C. Ross. Winoground: Probing vision and language models for visio-linguistic compositionality. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 5238–5248, 2022.
- [116] M. Yuksekgonul, F. Bianchi, P. Kalluri, D. Jurafsky, and J. Zou. When and why vision-language models behave like bags-of-words, and what to do about it? In *The Eleventh International Conference on Learning Representations*, 2023.
- [117] C.-Y. Hsieh, J. Zhang, Z. Ma, A. Kembhavi, and R. Krishna. Sugarcrepe: Fixing hackable benchmarks for vision-language compositionality. *Advances in neural information processing systems*, 36, 2024.
- [118] M. Caron, H. Touvron, I. Misra, H. Jégou, J. Mairal, P. Bojanowski, and A. Joulin. Emerging properties in self-supervised vision transformers. In *Proceedings of the International Conference on Computer Vision (ICCV)*, 2021.
- [119] S. Amir, Y. Gandelsman, S. Bagon, and T. Dekel. Deep vit features as dense visual descriptors. *arXiv preprint arXiv:2112.05814*, 2(3):4, 2021.
- [120] L. Melas-Kyriazi, C. Rupprecht, I. Laina, and A. Vedaldi. Deep spectral methods: A surprisingly strong baseline for unsupervised semantic segmentation and localization. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 8364–8375, 2022.
- [121] Y. Wang, Z. Li, M. Zhang, K. Driggs-Campbell, J. Wu, L. Fei-Fei, and Y. Li. D³fields: Dynamic 3d descriptor fields for zero-shot generalizable robotic manipulation. *arXiv preprint arXiv:2309.16118*, 2023.
- [122] X. Lin, J. So, S. Mahalingam, F. Liu, and P. Abbeel. Spawnnnet: Learning generalizable visuomotor skills from pre-trained networks. *arXiv preprint arXiv:2307.03567*, 2023.
- [123] N. Di Palo and E. Johns. Keypoint action tokens enable in-context imitation learning in robotics. *arXiv preprint arXiv:2403.19578*, 2024.
- [124] N. Di Palo and E. Johns. Dinobot: Robot manipulation via retrieval and alignment with vision foundation models. *arXiv preprint arXiv:2402.13181*, 2024.
- [125] O. Y. Lee, A. Xie, K. Fang, K. Pertsch, and C. Finn. Affordance-guided reinforcement learning via visual prompting. *arXiv preprint arXiv:2407.10341*, 2024.

- [126] C. R. Harris, K. J. Millman, S. J. van der Walt, R. Gommers, P. Virtanen, D. Cournapeau, E. Wieser, J. Taylor, S. Berg, N. J. Smith, R. Kern, M. Picus, S. Hoyer, M. H. van Kerkwijk, M. Brett, A. Haldane, J. F. del Río, M. Wiebe, P. Peterson, P. Gérard-Marchant, K. Sheppard, T. Reddy, W. Weckesser, H. Abbasi, C. Gohlke, and T. E. Oliphant. Array programming with NumPy. *Nature*, 585(7825):357–362, Sept. 2020. doi:10.1038/s41586-020-2649-2. URL <https://doi.org/10.1038/s41586-020-2649-2>.
- [127] R. Tedrake. *Underactuated Robotics*. 2023. URL <https://underactuated.csail.mit.edu>.
- [128] P. Virtanen, R. Gommers, T. E. Oliphant, M. Haberland, T. Reddy, D. Cournapeau, E. Burovski, P. Peterson, W. Weckesser, J. Bright, et al. Scipy 1.0: fundamental algorithms for scientific computing in python. *Nature methods*, 17(3):261–272, 2020.
- [129] Y. Xiang, D. Sun, W. Fan, and X. Gong. Generalized simulated annealing algorithm and its application to the thomson model. *Physics Letters A*, 233(3):216–220, 1997.
- [130] D. Kraft. A software package for sequential quadratic programming. *Forschungsbericht-Deutsche Forschungs- und Versuchsanstalt für Luft- und Raumfahrt*, 1988.
- [131] H.-S. Fang, C. Wang, H. Fang, M. Gou, J. Liu, H. Yan, W. Liu, Y. Xie, and C. Lu. Anygrasp: Robust and efficient grasp perception in spatial and temporal domains. *IEEE Transactions on Robotics*, 2023.
- [132] A. Kirillov, E. Mintun, N. Ravi, H. Mao, C. Rolland, L. Gustafson, T. Xiao, S. Whitehead, A. C. Berg, W.-Y. Lo, et al. Segment anything. *arXiv preprint arXiv:2304.02643*, 2023.
- [133] E. Coumans and Y. Bai. Pybullet, a python module for physics simulation for games, robotics and machine learning. 2016.
- [134] Y. Zhu, A. Joshi, P. Stone, and Y. Zhu. Viola: Imitation learning for vision-based manipulation with object proposal priors. *6th Annual Conference on Robot Learning*, 2022.
- [135] M. Minderer, A. Gritsenko, A. Stone, M. Neumann, D. Weissenborn, A. Dosovitskiy, A. Mahendran, A. Arnab, M. Dehghani, Z. Shen, et al. Simple open-vocabulary object detection with vision transformers. *arXiv preprint arXiv:2205.06230*, 2022.
- [136] H. K. Cheng, S. W. Oh, B. Price, J.-Y. Lee, and A. Schwing. Putting the object back into video object segmentation. In *arXiv*, 2023.
- [137] T. Darcet, M. Oquab, J. Mairal, and P. Bojanowski. Vision transformers need registers. *arXiv preprint arXiv:2309.16588*, 2023.
- [138] D. Comaniciu and P. Meer. Mean shift: A robust approach toward feature space analysis. *IEEE Transactions on pattern analysis and machine intelligence*, 24(5):603–619, 2002.
- [139] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- [140] J. Yang, H. Zhang, F. Li, X. Zou, C. Li, and J. Gao. Set-of-mark prompting unleashes extraordinary visual grounding in gpt-4v. *arXiv preprint arXiv:2310.11441*, 2023.
- [141] A. W. Harley, Z. Fang, and K. Fragkiadaki. Particle video revisited: Tracking through occlusions using point trajectories. In *European Conference on Computer Vision*, pages 59–75. Springer, 2022.

- [142] Q. Wang, Y.-Y. Chang, R. Cai, Z. Li, B. Hariharan, A. Holynski, and N. Snavely. Tracking everything everywhere all at once. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 19795–19806, 2023.
- [143] Y. Zheng, A. W. Harley, B. Shen, G. Wetzstein, and L. J. Guibas. Pointodyssey: A large-scale synthetic dataset for long-term point tracking. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 19855–19865, 2023.
- [144] N. Karaev, I. Rocco, B. Graham, N. Neverova, A. Vedaldi, and C. Rupprecht. Cotracker: It is better to track together. *arXiv preprint arXiv:2307.07635*, 2023.
- [145] C. Doersch, Y. Yang, M. Vecerik, D. Gokay, A. Gupta, Y. Aytar, J. Carreira, and A. Zisserman. Tapir: Tracking any point with per-frame initialization and temporal refinement. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 10061–10072, 2023.
- [146] C. Doersch, Y. Yang, D. Gokay, P. Luc, S. Koppula, A. Gupta, J. Heyward, R. Goroshin, J. Carreira, and A. Zisserman. Bootstap: Bootstrapped training for tracking-any-point. *arXiv preprint arXiv:2402.00847*, 2024.
- [147] Y. Xiao, Q. Wang, S. Zhang, N. Xue, S. Peng, Y. Shen, and X. Zhou. Spatialtracker: Tracking any 2d pixels in 3d space. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 20406–20417, 2024.
- [148] J. Luiten, G. Kopanas, B. Leibe, and D. Ramanan. Dynamic 3d gaussians: Tracking by persistent dynamic view synthesis. *arXiv preprint arXiv:2308.09713*, 2023.
- [149] A. Millane, H. Oleynikova, E. Wirbel, R. Steiner, V. Ramasamy, D. Tingdahl, and R. Siegwart. nxblox: Gpu-accelerated incremental signed distance field mapping. *arXiv preprint arXiv:2311.00626*, 2023.
- [150] X. Li, M. Zhang, Y. Geng, H. Geng, Y. Long, Y. Shen, R. Zhang, J. Liu, and H. Dong. Manipllm: Embodied multimodal large language model for object-centric robotic manipulation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 18061–18070, 2024.
- [151] W. Xia, D. Wang, X. Pang, Z. Wang, B. Zhao, and D. Hu. Kinematic-aware prompting for generalizable articulated object manipulation with llms. *arXiv preprint arXiv:2311.02847*, 2023.
- [152] S. Huang, H. Chang, Y. Liu, Y. Zhu, H. Dong, P. Gao, A. Boularias, and H. Li. A3vlm: Actionable articulation-aware vision language model. *arXiv preprint arXiv:2406.07549*, 2024.
- [153] C. Li, R. Zhang, J. Wong, C. Gokmen, S. Srivastava, R. Martín-Martín, C. Wang, G. Levine, M. Lingelbach, J. Sun, et al. Behavior-1k: A benchmark for embodied ai with 1,000 everyday activities and realistic simulation. In *Conference on Robot Learning*, pages 80–93. PMLR, 2023.
- [154] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin. Attention is all you need. *Advances in neural information processing systems*, 30, 2017.
- [155] A. Goyal, J. Xu, Y. Guo, V. Blukis, Y.-W. Chao, and D. Fox. Rvt: Robotic view transformer for 3d object manipulation. In *Conference on Robot Learning*, pages 694–710. PMLR, 2023.
- [156] A. Goyal, V. Blukis, J. Xu, Y. Guo, Y.-W. Chao, and D. Fox. Rvt-2: Learning precise manipulation from few demonstrations. *arXiv preprint arXiv:2406.08545*, 2024.
- [157] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, et al. An image is worth 16x16 words: Transformers for image recognition at scale. *arXiv preprint arXiv:2010.11929*, 2020.

A 附录

A.1 基于关系关键点约束的顺序操作伪代码

Algorithm 1 Relational Keypoint Constraints for Sequential Manipulation

```

1: Initialize current stage  $i \leftarrow 1$ , and current time  $t \leftarrow 1$ 
2: while  $i \leq N$  do
3:   if  $\exists f \in \mathcal{C}_{\text{path}}^{(i)}$  s.t.  $f(k_t) > 0$  then
4:      $i \leftarrow i - 1$ 
5:     continue
6:   end if
7:   if  $\text{distance}(\mathbf{e}_t, \mathbf{e}_{g_i}) < \epsilon$  then
8:      $i \leftarrow i + 1$ 
9:     continue
10:  end if
11:  Solve sub-goal problem for stage  $i$  to obtain  $\mathbf{e}_{g_i}$  (Eq. 2)
12:  Solve path problem for stage  $i$  to obtain  $\mathbf{e}_{t:g_i}$  (Eq. 3)
13:  Execute the next  $m$  actions  $\mathbf{e}_{t+1:t+m}$ 
14:   $t \leftarrow t + m + 1$ 
15: end while

```




图 6: 轮式单臂平台。




图 7: 固定式双臂平台。

A.2 轮式单臂平台

我们研究的平台之一是一个安装在由 Vention 框架构建的轮式底座上的 Franka 机械臂（如图 6 所示）。需要注意的是，该底座没有电机，因此无法自主移动，但其移动性仍然使我们能够在实验室环境之外研究所提出的方法。

由于我们的流程生成一系列六自由度末端执行器位姿，因此在所有实验中我们使用位置控制，该控制以 20 赫兹的固定频率运行。具体来说，一旦机器人接收到世界坐标系中的目标末端执行器位姿，我们首先将该位姿裁剪到预定义的工作空间内。然后，我们从当前位姿到目标位姿进行线性插值，位置步长为 5 毫米，旋转步长为 1 度。为了移动到每个插值位姿，我们首先根据当前关节位置计算逆运动学以获得目标关节位置（逆运动学求解器来自 PyBullet [133]）。然后，我们使用来自 Deoxys [134] 的关节阻抗控制器来达到目标关节位置。

两个 RGB-D 相机（Orbbec Femto Bolt）安装在机器人两侧，面向工作空间中心。相机以 20 赫兹的固定频率捕获 RGB 图像和点云。

A.3 固定式双臂平台

我们还在一个固定式双臂平台上研究了该方法，该平台由两个 Franka 机械臂组成，安装在一个桌面工作空间前方（如图 7 所示）。我们使用与轮式单臂平台相同的控制器，不同之处在于两个机械臂以 20 赫兹的频率同时控制。具体来说，我们的流程联合求解两个六自由度末端执行器位姿序列，并将它们一起发送给底层控制器。控制器随后为两个机械臂计算逆运动学，并使用关节阻抗控制来移动机械臂。

三个 RGB-D 相机（Orbbec Femto Bolt）安装在该平台上。两个相机安装在左右两侧，一个相机安装在后面。相机同样以 20 赫兹的固定频率捕获 RGB 图像和点云。

A.4 评估细节

下面我们讨论第 4.1 节和第 4.2 节所报告实验的评估细节。

A.4.1 野外与双手操作实验细节（第 4.1 节）

对于每项任务，选取 10 个不同的物体初始配置，这些配置覆盖整个工作空间，但经过人工验证以确保机器人运动学上可行。每次试验中，操作员将场景恢复到相应配置并启动系统。由于为本文研究的多样化物体和环境制定自动成功标准具有挑战性，成功率由操作员根据下文每项任务描述中给出的标准进行测量。对于涉及外部干扰的实验，所有试验的干扰集是预先选定的，每次试验施加一种干扰。具体而言，干扰由操作员用手改变物体位姿引入。对于所有涉及可变形物体的任务，碰撞检测被禁用。

倒茶：环境包括放置在厨房台面上的茶壶和杯子。任务包含三个阶段：抓取壶柄、将茶壶对准杯口上方、将茶倒入杯中。成功标准要求茶壶在倒茶阶段之前保持直立，结束时壶嘴必须对准并倾斜在杯口上方。

回收易拉罐：环境包括三种易拉罐之一（可乐、零度可乐、零度雪碧）、一个开口狭窄的回收箱（易拉罐只有直立时才能放入）、一个垃圾填埋箱和一个堆肥箱，均位于办公楼内。任务包含两个阶段：抓取易拉罐并在回收箱上方调整其姿态，然后将其投入。成功标准是易拉罐被成功投入箱中。

收纳书籍：环境由一本放置在边桌上的目标书籍和一个真实尺寸的书架组成，书架中已放置的书籍之间有一个 15 厘米的开口，整体位于办公室环境中。任务包含两个阶段：抓取边桌上的目标书籍，并将其放入书架的开口中。成功标准是目标书籍在机器人松开夹爪后稳定放置，且机器人不得碰撞书架或其他已放置的书籍。

胶带盒：环境包括一个纸板箱、一个带有切割器的包装胶带（放置在箱子顶部，箱子已有一侧贴好胶带），以及一位与机器人协作的人类用户。胶带已预先展开至足够长度，因为展开通常需要超过机器人手臂极限的大力。任务包含两个阶段：在人类操作员挤压箱子的同时，机器人需要抓住胶带并将其对准正确的一侧以完成封箱。成功标准是胶带最终处于正确位置，与接缝对齐。

(双手) 折叠衣物: 环境由一件平放在工作空间中心附近的毛衣组成, 袖子、领口和下摆有轻微变形。任务通常需要四个阶段: 抓住两只袖子, 将其折叠到中间, 抓住领口, 并将其折叠到底部。成功标准不强制要求一致的阶段; 只要毛衣被折叠至占据原始表面面积至多一半, 即视为成功。

(双手) 装鞋: 环境包括一个靠近工作空间中心的空鞋盒, 两只鞋子以随机姿态放置在盒子的相对两侧。任务包含两个阶段: 同时抓住鞋子并将其放入鞋盒中。成功标准不强制要求一致的阶段; 只要鞋子被放入盒子中, 且没有堆叠在一起或导致双手自碰撞, 即视为成功。

(双手) 协作折叠: 环境由一块大毯子(预先折叠至适当尺寸, 因其尺寸超过工作空间限制而占据约 70% 的工作空间)和一名与机器人协作的人类用户组成。任务包含两个阶段: 机器人必须抓住毯子上与人类用户相对的两个角, 第二阶段是将这两个角与人类已抓住的两个角对齐。成功标准是机器人抓住了正确的角, 并能将其与正确的人类手臂对齐(左对左, 右对右)。

A.4.2 基线方法细节

我们使用 VoxPoser [106] 作为主要基线方法, 因为它做出了类似的假设, 即不需要任务特定数据或预定义的运动原语。我们对 VoxPoser 进行了某些修改以适应我们的设置, 以确保比较的公平性。具体来说, 我们使用相同的视觉语言模型 GPT-4o [6], 它接收相同的相机输入。我们还将本文中使用的提示词添加到原始论文的提示词中, 以确保其具有足够的上下文。我们仅使用可供性、旋转和夹爪动作值图, 忽略障碍和速度值图, 因为它们对我们的任务不是必需的。我们还只考虑“感兴趣实体”是机器人末端执行器而非场景中物体的情形。后者是为推动任务量身定制的, 而本文不研究该任务。我们使用 OWL-ViT [135] 进行开放词汇目标检测, 使用 SAM [132] 进行初始帧分割, 使用 Cutie [136] 进行掩码跟踪。

A.4.3 操作策略泛化细节 (第 4.2 节)

双臂机器人需要折叠八类不同的衣物。我们使用两个度量进行评估: “策略成功”和“执行成功”, 前者评估关键点是否被提出以及约束是否被恰当书写, 后者评估在给定成功策略的情况下机器人系统的执行情况。

为评估“策略成功”, 衣物被初始化在工作空间中心附近。背部安装的 RGB-D 相机采集 RGB 图像。随后, 关键点提议模块利用采集到的图像生成关键点候选, 并将其叠加在原始图像上并标注数字标记 $\{0, \dots, K-1\}$ 。叠加后的图像连同相同的通用提示输入 GPT-4o [6] 以生成 ReKep 约束。由于折叠衣物本身是一个没有基准策略的开放性问题, 我们人工判断提议的关键点和生成的约束是否正确。注意, 由于约束将由双臂机器人执行, 且约束几乎总是连接(折叠)两个关键点使其对齐, 正确性通过以下方式衡量: 机器人是否(可能)执行该约束而不会导致自碰撞(手臂交叉到对侧), 以及折叠策略能否将衣物折叠至其原始表面积至多一半。

为评估“执行成功”, 我们取上一节中为每件衣物标记为成功的生成策略, 并在双臂平台上执行该序列, 每件衣物共进行 10 次试验。点跟踪被禁用, 因为我们观察到当衣物可能被折叠多次时, 我们的点跟踪器预测的轨迹不稳定。成功通过衣物是否被折叠至其表面积至多为其原始表面积的一半来衡量。

A.5 关键点提议的实现细节

本文描述场景中关键点候选的生成方式。对于每个平台，我们使用一个已安装的 RGB-D 相机捕获尺寸为 $h \times w \times 3$ 的图像，具体取决于哪个相机对环境具有最佳的整体视野，因为所有关键点都需要出现在第一帧中才能应用所提出的方法。给定捕获的图像，我们首先使用带寄存器的 DINOv2 (ViT-S14) [5, 137] 提取逐块特征 $\mathbf{F}_{\text{patch}} \in \mathbb{R}^{h' \times w' \times d}$ 。然后执行双线性插值将特征上采样到原始图像尺寸， $\mathbf{F}_{\text{interp}} \in \mathbb{R}^{h \times w \times d}$ 。为确保提议覆盖场景中所有相关物体，我们使用分割一切模型 (SAM) [132] 提取场景中的所有掩码 $\mathbf{M} = \{\mathbf{m}_1, \mathbf{m}_2, \dots, \mathbf{m}_n\}$ 。在每个掩码 $\mathbf{m}_i$ 内，我们应用主成分分析 (PCA) 将特征投影到三维， $\mathbf{F}_{\text{PCA}} = \text{PCA}(\mathbf{F}_{\text{interp}}[\mathbf{m}_i], 3)$ 。我们发现应用 PCA 能改善聚类效果，因为它通常能去除与纹理相关的细节和工件，这些对我们的任务无用。对于每个掩码 j ，我们使用 k 均值聚类 (k-means) 对掩码特征 $\mathbf{F}_{\text{interp}}[\mathbf{m}_j]$ 进行聚类，其中 $k = 5$ 采用欧氏距离度量。聚类的中心点中位数被用作关键点候选，并通过标定的 RGB-D 相机投影到世界坐标 $\mathbb{R}^3$ 。注意，我们还存储哪些关键点候选来自同一掩码，这将在第 3.3 节描述的优化循环中作为刚性假设的一部分使用。超出工作空间边界的候选被过滤掉。为避免小区域内点过于密集，我们额外使用均值漂移 (Mean Shift) [138, 139] (带宽 8 厘米) 过滤彼此靠近的点。最后，中心点被作为最终候选。或者，可以开发仅使用分割模型 [132, 140] 的流程，但我们将比较留待未来工作。

A.6 查询视觉语言模型

获得关键点候选后，将它们以数字标记 $\{0, \dots, K-1\}$ 叠加在捕获的 RGB 图像上。然后，图像和任务指令被输入视觉语言模型，并使用下述提示。提示仅包含通用指令，没有图像-文本上下文示例，但给出了少量基于文本的示例来具体解释所提出的方法和模型的预期输出。注意，所研究的大多数任务并未在提供的提示中讨论。因此，视觉语言模型的任务是利用其内化的世界知识生成关系关键点约束。

对于本工作中进行的实验，我们使用 GPT-4o [6]，因为它是实验时可用的最新模型之一。然而，由于该领域发展迅速，该流程可以直接受益于具有更好视觉语言推理能力的新模型。相应地，我们观察到不同模型在给定相同提示时表现出不同的行为（观察到较新的模型通常需要更细粒度的指令）。因此，与其为本工作中的任务套件开发最佳提示，我们专注于展示一个全栈流程，该流程包含一个关键组件，可以通过未来的开发实现自动化并持续改进。

指令 假设你正在通过用 Python 编写约束函数来控制机器人执行操作任务。操作任务以环境图像的形式给出，图像上叠加了带有索引标记的关键点，并附有文本指令。指令以括号开头，指示机器人是单臂还是双臂。对于每个给定的任务，请执行以下步骤：

- 确定任务涉及多少个阶段。抓取必须是一个独立的阶段。一些示例：
 - “（单臂）从茶壶倒茶”：
 - 3 个阶段：“抓取茶壶”、“将茶壶与杯口对齐”和“倒液体”
 - “（单臂）将红色积木放在蓝色积木上面”：
 - 3 个阶段：“抓取红色积木”、“将红色积木对齐到蓝色积木上方”和“释放红色积木”
 - “（双臂）将袖子拆离袖口中心”：
 - 2 个阶段：“左臂抓住左袖，右臂抓住右袖”和“双臂折叠袖子至中心”
 - “（双手）折叠夹克”：
 - 3 个阶段：“左臂抓住左袖，右臂抓住右袖”、“双臂将袖子折叠至中心”，以及“用一只手臂抓住颈部（另一只手臂保持原位）”，以及“将颈部与底部对齐”
- 针对每个阶段，编写两类约束：“子目标约束”与“路径约束”。“子目标约束”是必须在**阶段结束时**满足的约束，而“路径约束”是必须在**阶段内**满足的约束。一些示例：
 - “（单臂）从茶壶倒液体”：
 - “抓取茶壶”阶段：
 - 子目标约束：“将末端执行器与茶壶把手对齐”
 - 路径约束：无

- “将茶壶与杯口对齐”阶段：
 - 子目标约束：“茶壶壶嘴需位于杯口上方 10 厘米处”
 - 路径约束：“机器人正在抓取茶壶”，且“茶壶必须保持直立以避免溢出”
- “倾倒液体”阶段：
 - 子目标约束：茶壶壶嘴需位于杯口上方 5 厘米处”，“茶壶壶嘴必须倾斜以倒出液体”
 - 路径约束：“茶壶嘴位于杯口正上方”
- “（双臂）将袖子折叠到中心”：
 - “左臂抓住左袖，右臂抓住右袖”阶段：
 - 子目标约束：“左臂抓住左袖”、“右臂抓住右袖”
 - 路径约束：无
 - “双臂将袖子向中间折叠”阶段：
 - 子目标约束：“左袖与中心对齐”、“右袖与中心对齐”
 - 路径约束：无

注：每个约束以虚拟末端执行器点和一组关键点为输入，并返回一个数值代价，当代价小于或等于零时约束得到满足。

- 对于每个阶段，可以编写 0 个或多个子目标约束以及 0 个或多个路径约束。

- 避免在约束中使用“如果”语句。

- 在操作可变形物体（如衣物、毛巾）时，避免使用路径约束。

- 无需考虑碰撞避免，专注于完成任务所必需的内容。

- 约束的输入如下：

- ‘end_effector’: 形状为 ‘(3,)’ 的 np.array，表示末端执行器位置。
- ‘keypoints’: 形状为 ‘(K,3)’ 的 np.array，表示关键点位置。

- 在每个函数中，end_effector 和 keypoints 是 NumPy 函数。

- 对于抓取阶段，应仅编写一个将末端执行器与某个物体关联的子目标约束

- 对于非抓取阶段，不应参考末端执行器位置。

- 为了移动关键点，其关联对象必须在之前的某个阶段被抓取。

- 机器人一次只能抓取一个物体。

- 抓取必须是一个独立于其他阶段的阶段。

- 可使用两个关键点与固定轴之间的夹角来指定旋转（通过指定角度

- 可使用多个关键点来指定一个表面或体积。

- 也可使用多个关键点的中心来指定一个位置。

- 单个折叠动作应由两个阶段组成：一次抓取和一次放置。

对于单臂机器人，请将输出结构组织在单个 Python 代码块中，如下所示： ``python

解释任务涉及多少个阶段以及每个阶段的内容。# ...

```
### stage 1 sub-goal constraints (if any)
def stage1_subgoal_constraint1(end_effector, keypoints):
    """在此处放置解释。""" ... return cost # 如需要，添加更多子
    目标约束
```

```
### stage 1 path constraints (if any)
def stage1_path_constraint1(end_effector, keypoints):
    """在此处放置解释。""" ... return cost # 如需要，添加
    更多路径约束
```

重复更多阶段... ``

将输出结构化为单个 Python 代码块，如下所示，用于双臂机器人： ``python

解释任务涉及多少个阶段以及每个阶段的内容。# ...

```
num_stages = ?
```

```
### left-arm stage 1 sub-goal constraints (if any)
def left_stage1_subgoal_constraint1(end_effector, keypoints):

    """在此处放置您的解释。""" ... 返回成本
```

```
### right-arm stage 1 sub-goal constraints (if any)
def right_stage1_subgoal_constraint1(end_effector, keypoints):
    """在此处放置解释。""" ... return cost # 如需要，添加更多子
    目标约束
```

```
### left stage 1 path constraints (if any)
def left_stage1_path_constraint1(end_effector, keypoints):
    """Put your explanation here."""
    ...
    return cost
### right stage 1 path constraints (if any)
def right_stage1_path_constraint1(end_effector, keypoints):
```

```

"""在此处放置解释。""" ... return cost # 如需要，添加
更多路径约束

# 重复更多阶段... ``

## 查询 查询任务: "[指令]" 查询图像: [带关键点的图像]

```

A.7 点跟踪器的实现细节

我们实现了一个简单的点跟踪器，遵循 [121]，基于 DINOv2 (ViT-S14) [5]，利用多个 RGB-D 相机存在且 DINOv2 能够以实时频率高效运行的事实。

初始化时，给定一组 3D 关键点位置 $\mathbf{k} \in \mathbb{R}^3$ 。我们首先从每个现有相机获取 RGB-D 捕获。对于每个 RGB 图像，我们按照第 A.5 节中的相同过程获得逐像素的 DINOv2 特征，并使用校准后的相机记录其关联的 3D 世界坐标。对于每个 3D 关键点位置，我们聚合来自所有相机中距离 2 厘米以内的点的所有特征。聚合特征的均值被记录为每个关键点的参考特征，并在整个任务过程中保持不变。

初始化后，在每个时间步，我们类似地从所有相机获取 DINOv2 的逐像素特征及其 3D 世界坐标。为了跟踪关键点，我们计算所有像素的特征与参考特征之间的余弦相似度。为每个关键点选择前 100 个匹配项，相似度截断值为 0.6。然后，我们通过计算中位数偏差 ($m = 2$) 来剔除所选匹配项中的异常值。此外，由于跟踪的关键点可能在小区内振荡，我们最后应用窗口大小为 10 的均匀滤波器。整个过程以 20 Hz 的固定频率运行。

请注意，所实现的点跟踪器是对 [121] 的简化，用于实时跟踪。我们建议读者参考 [121]，其中更全面地讨论了使用自监督视觉模型（如 DINOv2）进行点跟踪。或者，也可以使用更专门的点跟踪器 [141 – 148]。

A.8 子目标求解器的实现细节

子目标问题使用 SciPy[128] 实现并求解。决策变量是单臂机器人在 $\mathbb{R}^6$ 中的单个末端执行器位姿（位置和欧拉角），以及双臂机器人在 $\mathbb{R}^{12}$ 中的两个末端执行器位姿。位置项的边界是预定义的工作空间边界，旋转项的边界是末端执行器朝下的半球（由于 Franka 臂的关节限制，当末端执行器位姿朝上时，通常容易达到关节极限）。决策变量根据边界归一化到 $[-1, 1]$ 。在第一次求解迭代中，初始猜测选择为当前末端执行器位姿。我们在第一次迭代中使用基于采样的全局优化对偶退火 [129] 来快速搜索整个空间，随后使用基于梯度的局部优化器 SLSQP[130] 来细化解。此迭代的整个过程大约需要 1 秒。在后续迭代中，我们使用前一阶段的解，并且只使用局部优化器，因为它可以快速适应小的变化。优化以固定的时间预算截断，表示为目标函数调用次数，以保持系统高频运行。

我们在下面讨论目标函数中的代价项。

约束违反：我们将约束实现为优化问题中的代价项，其中 ReKep 函数返回的代价乘以较大的权重。

场景碰撞避免：我们使用 nvblox[149] 和 PyTorch 包装器 [58] 在单独的节点中以 20 Hz 的频率计算场景的 ESDF。ESDF 计算聚合了

来自所有可用相机的深度图，并使用 cuRobo 排除机器人手臂以及任何被夹持的刚性物体（通过掩码跟踪模型 Cutie 进行跟踪 [136]）。随后利用 ESDF 计算碰撞体素网格，供系统中其他模块使用。在子目标求解器模块中，我们首先使用最远点采样将夹持器点和被夹持物体点降采样至最多 30 个点。然后利用 ESDF 体素网格进行线性插值计算碰撞代价，阈值为 15 厘米。

可达性：由于我们的决策变量是末端执行器位姿，这些位姿可能并非始终可由机器人手臂到达，尤其是在狭窄空间中，因此我们需要添加一个代价项，以鼓励找到具有有效关节构型的解。因此，我们在子目标求解器的每次迭代中使用 PyBullet[133] 求解逆运动学问题，并将其残差作为可达性的代理指标。我们发现这大约占完整目标函数计算时间的 40%。或者，可以在关节空间中求解问题，通过强制边界确保解在关节极限内。我们发现这在基于 Python 的实现中效率低下，因为路径求解器中需要计算前向运动学的次数要多得多，因为约束是在任务空间中评估的。为解决这一问题并确保效率，未来工作可以考虑使用硬件加速实现来在关节空间中求解问题 [58]。

位姿正则化：我们还添加了一个小的代价项，以鼓励子目标接近当前末端执行器位姿。

一致性：由于求解器以高频率迭代求解问题，且感知管线的噪声可能传播到求解器，我们发现包含一致性代价项是有用的，该代价项鼓励解接近前一个解。

（仅双臂）自碰撞避免：为避免两条机械臂相互碰撞，本文计算两个点集之间的成对距离，每个点集均包含夹爪点与被抓取物体点。

A.9 路径求解器的实现细节

路径问题使用 SciPy [128] 实现并求解。决策变量的数量根据当前末端执行器位姿与目标末端执行器位姿之间的距离计算得出。具体而言，本文定义固定步长（20 厘米与 45 度），并线性近似所需的“中间位姿”数量，这些中间位姿用作决策变量。与子目标问题相同，它们同样使用位置与欧拉角表示，并具有相同的边界。在首次求解迭代中，初始猜测选择为起点与目标之间的线性插值。本文同样在首次迭代中使用基于采样的全局优化，随后使用基于梯度的局部优化器，并在后续迭代中仅使用局部优化器。获得解后，该解表示为若干中间位姿，本文使用当前位姿、中间位姿与目标位姿拟合样条曲线，随后对其进行密集采样以供机器人执行。

在目标函数中，本文首先对决策变量进行反归一化，并使用分段线性插值获得表示路径的密集离散位姿序列（下文称为“密集样本”）。样条插值将与本文后处理及执行解的方式保持一致，但本文发现线性插值在计算上更为高效。下文讨论目标函数中的各个代价项。

约束违反：与子目标问题类似，本文检查路径上每个密集样本是否违反 ReKep 约束，并以较大权重进行惩罚。

场景碰撞避免：计算方式与子目标问题类似，区别在于需对每个密集样本进行计算。本文忽略起点与目标位姿附近 5 厘米半径范围内的碰撞计算，因为在高频求解时，这有助于在各种真实世界噪声下稳定解。此外，本文增加桌面间隙代价，用于惩罚路径穿透桌面（或轮式单臂机器人的工作空间底部）。

路径长度：本文使用密集样本通过对其差值求和来近似路径长度。鼓励更短的路径。

可达性：我们在目标函数内部为每个中间姿态解决一个逆运动学（IK）问题，如同子目标问题中那样。更多细节请参见子目标求解器部分。

一致性：如同子目标问题，我们鼓励解接近前一个解。具体来说，我们存储前一次迭代的密集采样。为了计算解的一致性，我们使用两个序列（视为两个集合）之间的成对距离作为高效代理。或者，可以使用豪斯多夫距离。

（仅双臂）自碰撞避免：我们类似地计算双臂平台的自碰撞避免，如同子目标问题中那样。我们还使用两个序列之间的成对距离来高效计算此代价。

A.10 与先前视觉提示用于操作的工作的比较

已有若干并行工作研究将视觉语言模型（VLM）的视觉提示应用于机器人操作 [99 – 101, 112, 125]。下面我们总结差异以突出本工作的贡献。

任务自由度：在本工作中，我们专注于需要 6 自由度（单臂）或 12 自由度（双臂）运动的挑战性任务。然而，这对于在 2D 图像上操作的现有 VLM 来说并非易事——正如 MOKA[100] 所引述的，“当前的 VLM 无法可靠地预测 6 自由度运动”，以及 PIVOT[101] 所述，“泛化到更高维空间（如旋转姿态）甚至带来额外挑战”。为了解决这个问题，ReKep 的一个关键洞见是，VLM 只需通过在 (x, y, z) 笛卡尔坐标中推理关键点来隐式指定完整的 3D 旋转。此后，实际的 3D 旋转由高精度且高效的数值求解器解决，有效规避了显式预测 3D 旋转的挑战。因此，相同的公式也自然地泛化到控制多个手臂。

高层规划：虽然许多工作也通过独立于其方法的基于语言的任务规划器来考虑多阶段任务，但本文的表述从任务与运动规划（TAMP）中获得启发，将高层任务规划与低层动作有机地整合到一个统一的连续数学规划中。因此，该方法能够自然地考虑跨阶段的几何依赖关系，并以实时频率进行。当发生失败时，它会回溯到条件仍可满足的前一阶段。例如，在“倒茶”任务中，机器人只有在茶壶嘴与杯口对齐时才能开始倾斜茶壶。然而，如果在此过程中杯子被移动，它应该将茶壶放平并重新与杯子对齐。或者，如果茶壶被从夹持器中取走，它应该重新抓取茶壶。

低层执行：使用视觉语言模型（VLM）的一个常见问题是其计算开销大，阻碍了许多操作任务通常所需的高频感知-动作反馈回路。因此，现有工作大多要么考虑仅在开始时使用视觉感知的开环设置，要么只考虑可接受慢速执行的任务。相反，本文的表述通过将视觉语言模型与点跟踪器耦合，原生支持高频感知-动作回路，从而在利用非常大的基础模型的同时，有效地通过闭环执行实现反应式行为。

视觉提示方法：本文独特地考虑使用视觉提示进行代码生成，其中代码可以通过视觉指代表达式对一组关键点进行任意算术运算。虽然单个点难以捕捉复杂的几何结构，但多个点及其关系甚至可以指定向量、曲面、体积及其时间依赖关系。尽管概念上简单，这提供了更灵活性的灵活性，可以完全指定 6 自由度甚至 12 自由度的运动。

A.11 局限性的扩展讨论

本文在此呈现现有系统的额外局限性。

提示与鲁棒性：尽管我们已经证明现有的视觉语言模型（VLMs）具备指定关系关键点约束（ReKep constraints）的基本能力，但我们观察到，在处理跨越多个阶段且具有若干时间依赖约束的任务时（A.14），视觉语言模型缺乏足够的鲁棒性来获得一致的成功。

任务空间规划：为了实现高效规划，本文仅考虑在任务空间中进行规划，以末端执行器位姿作为决策变量。然而，我们观察到在某些场景中，机器人实现优化后的位姿可能在运动学上具有挑战性，因为求解器没有显式考虑机器人的运动学。在关节空间中进行规划可能解决该问题，但我们发现对于我们的任务而言，其计算效率较低。

关节式物体操作：本文未研究涉及关节式物体的任务，因为我们观察到这需要超越现有视觉语言模型能力的高级空间推理能力。然而，关系关键点约束（ReKep）的表述可以通过将不同类型的关节也表示为“关键点之间的关系”来扩展到此类任务。例如，可以编写关系关键点约束来限制某些关键点仅沿直线（移动关节）或曲线（旋转关节）移动。为了扩展到这些场景，可能需要像 [150 – 152] 中那样进行微调。

双臂协调：尽管我们展示了关系关键点约束（ReKep）在双臂操作中的应用，但我们识别出该领域中的几个重要局限性。值得注意的是，这些挑战可以大致分为与视觉语言模型对关键点关系的语义推理相关的挑战，以及与优化求解器求解双臂运动相关的挑战。对于语义推理，为了实现双臂折叠，视觉语言模型需要具备关于哪些步骤应该或可以由双臂同时执行的特定空间知识。例如，衬衫的底部通常需要两只手各抓住一个角，以便将其向上折叠以与衣领对齐。毯子折叠中的另一个例子是识别左下角应与左上角对齐，右下角应与右上角对齐，因为其他匹配可能导致自碰撞。对于优化求解器，由于双臂运动规划极大地增加了可能运动的搜索空间，这会减慢整个流程的速度，并更频繁地产生次优行为。

A.12 仿真实验

我们还在 OmniGibson [153] 中为倒茶任务实现了 ReKep。它与基于变换器架构 [154] 的单体学习基线进行比较，该基线源自 RVT [155, 156]。基线通过模仿学习在 100 个专家演示上训练，其中演示来自使用特权仿真信息的脚本策略。成功率在 100 次试验中取平均，报告如下。尽管单体策略在训练场景中表现出色，因为它可以访问专家演示，但我们观察到 ReKep 在未见过的环境中表现更强，更重要的是，无需专家演示。

	Seen Poses	Unseen Poses	Unseen Objects
Monolithic Policy	0.93	0.31	0.14
ReKep (Zero-Shot)	0.75	0.68	0.72

A.13 关键点提议的视觉特征提取器比较

本文提供了不同关键点提议方法的定性比较。我们比较了三种预训练的视觉特征提取器，每种代表一类流行的预训练方法：DINOv2 [5]（自监督预训练）、CLIP [94]（视觉-语言对比预训练）和 ViT [157]（监督预训练）。我们还比较了一个不使用

Segment Anything (SAM) [132] 的变体，以利用其对象先验。在图 8 中，我们展示了三个不同场景的提取特征图（投影到 RGB 空间）及其聚类关键点。

我们希望指出比较中的两个重要观察结果：1) 由 SAM 提供的物体先验对于将关键点提议约束在场景中的物体上而非背景上至关重要；2) 虽然大多数视觉基础模型都能提供有用的指导，但 DINOv2 能产生更清晰的特征，从而更好地区分物体的细粒度区域。第一个观察结果可以通过将最后一列与其他候选方法进行比较来清楚地得出。第二个观察结果可以通过注意以下位置来得出：1) 第一个场景中杯柄上独特的青色，2) 第二个场景中盒子面板的独特颜色，以及 3) 第三个场景中顶面板和侧面板的蓝/绿对比。类似地，CLIP 在不同物体部分之间提供了不同的特征，但这些特征不如 DINOv2 的特征清晰（颜色从一个部分饱和到另一个部分）。另一方面，ViT 在物体部分之间产生的特征最不可区分，尤其是在纹理相似的情况下。总的来说，我们的观察结果与其他同样应用 DINOv2 进行细粒度物体理解的工作一致 [114, 121, 123]。




图 8：不同方法的关键点提议比较。

A.14 长时程任务的案例研究

为了对所提出的系统进行压力测试，我们额外开展了一项长时程双手操作任务的案例研究，即准备早餐托盘。成功完成该任务需要 10 个阶段：1) 抓取桌布，

2) 将桌布放入托盘内，3) 从盘中抓取面包，4) 将面包放在桌布上，5) 用双臂同时抓取杯子和茶杯，6) 对齐杯子和茶壶，7) 将茶倒入杯中，8) 将杯子放入托盘内，9) 用双臂同时抓取两个托盘把手，以及 10) 抬起托盘并递给操作员。

该任务对系统中的多个组件提出了显著挑战。具体而言，我们发现现有的关键点提议与约束指定流程无法生成完整的正确关键点集合以及完整的正确 ReKep 约束序列。此外，我们观察到由于场景中存在多个物体，点跟踪器无法持续跟踪所有必需的关键点。因此，我们采用人工标注的关键点和约束，并仅在每个阶段开始时进行关键点检测，而非持续的关键点跟踪。经过上述修改，系统能够合理地完成该任务。初始构型与最终构型如下所示。各阶段的解决方案见下一页。视频结果可在 rekep-robot.github.io 查看。



图 9：准备早餐托盘任务的初始构型与成功的最终构型。




图 10: 准备早餐托盘任务的解决方案可视化。