

RoboTwin 2.0: 一种面向鲁棒双臂机器人操作的可扩展数据生成器与基准，具备强领域随机化

Tianxing Chen^{2,16*}, Zanxin Chen^{3,5*}, Baijun Chen^{15*}, Zijian Cai^{3,5*}, Yibin Liu^{13*}, 李子轩^{5*}, 梁启伟⁵, 林贤亮⁵, 葛一恒¹, 顾振宇^{7,8}, 邓伟良^{3,11}, 郭玉斌^{7,9}, 年天^{3,5}, 谢宣兵¹², 陈强宇⁵, 苏凯伦⁵, 徐天凌¹⁰, 刘国栋^{6,7}, 胡梦康², 高焕昂^{6,16}, 王凯旋^{2,16}, 梁志轩^{2,3†}, 秦玉森^{4,6}, 杨小康¹, 罗平^{2,14}, 穆尧^{1,3}

¹ 3 上海人工智能实验室, 4D-机器人, 5 深圳大学, 6 清华大学, 7 天翼人工智能, 8 复旦大学, 9 中国科学技术大学, 10 南方科技大学, 11 中山大学, 12 中南大学, 13 东北大学, 14 香港大学上海智能计算研究中心, 15 南京大学, 16 光明星辰人工智能

* 同等贡献

B 通讯作者

† 项目共同负责人

‡ 同等主导机构

Webpage: <https://robotwin-platform.github.io> Doc: <https://robotwin-platform.github.io/doc/>




图 1: RoboTwin 2.0 概览。RoboTwin 2.0 是一个可扩展的双臂操作框架，集成了专家数据生成流程与基于 RoboTwin 物体数据集（731 个物体，147 个类别）的 50 项任务基准。多模态语言智能体自动完成程序合成，而灵活的双臂配置支持大规模、多样化的数据采集。在 RoboTwin 2.0 上训练的策略展现出更强的鲁棒性和对未知环境的泛化能力。

摘要

基于仿真的数据合成已成为增强现实世界机器人操作的一种强大范式。然而，现有合成数据集对于稳健的双手机器人操作仍显不足，原因在于两大挑战：（1）缺乏针对新任务的高效、可扩展的数据生成方法，以及（2）过度简化的仿真环境未能捕捉现实世界的复杂性。我们提出 RoboTwin 2.0，一个可扩展的仿真框架，能够实现自动化，

大规模生成多样且逼真的数据，以及统一的双手操作评估协议。我们首先构建了 RoboTwin-OD，这是一个大规模物体库，包含 147 个类别的 731 个实例，每个实例都标注了语义和操作相关的标签。在此基础上，我们开发了一个专家数据综合流水线，该流水线结合了多模态大语言模型（MLLMs）与仿真在环优化，以自动生成任务级执行代码。为了改善仿真到现实迁移，RoboTwin 2.0 沿五个轴引入了结构化领域随机化：杂乱、光照、背景、桌面高度和语言指令，从而增强了数据多样性和策略鲁棒性。我们在涵盖五种机器人本体的 50 个双手任务中实例化了该框架。实证评估显示代码生成成功率提升了 10.9%。在此基础上，我们评估了下游策略学习。通过混合大规模合成数据和仅 10 个真实演示，一个视觉-语言-动作（VLA）模型相对于 10 个演示的基线实现了 367% 的相对提升。即使没有真实数据，仅使用合成数据训练的零样本模型也获得了 228% 的相对增益，这凸显了我们的数据集在增强仿真到现实迁移和对环境变化的鲁棒性方面的有效性。我们发布了数据生成器、基准、预收集的数据集和代码，以支持鲁棒双手操作的可扩展研究。

1 引言

双手灵巧操作对于机器人执行复杂的现实世界任务（如协作装配、工具使用和物体交接）至关重要。开发可泛化的双手操作策略——尤其是视觉-语言-动作（VLA）基础模型——需要同时具备高质量、多样性和大规模的数据集。在物体几何形状、场景杂乱程度、光照条件、指令语言和机器人本体缺乏足够多样性的情况下，学习到的策略往往会过拟合于狭窄的分布，无法泛化到新环境或硬件平台。然而，大规模收集现实世界演示仍然成本高昂、耗时且物流上具有挑战性，尤其是在旨在覆盖广泛任务、物体和本体的情况下。

基于仿真的数据生成为收集大规模多模态数据集提供了一种可扩展的替代方案，并已显示出实现仿真到现实迁移的潜力 [34, 11]。然而，现有流程在三个关键方面存在不足。首先，它们缺乏自动化的质量控制：没有专家级的验证循环，许多生成的轨迹包含执行失败或次优抓取，这会降低策略学习的质量。其次，它们的领域随机化往往流于表面，产生过于干净和同质化的场景，遗漏了杂乱、光照变化和模糊语言指令等关键的现实世界因素——这些因素对于稳健的仿真到现实迁移至关重要。第三，它们忽视了跨本体差异：不同的双手平台在运动学能力和抓取策略上可能存在显著差异。例如，像 Piper 这样的低自由度（DoF）平台由于其有限的灵巧性，通常依赖侧向抓取；而像 Franka 这样的高自由度手臂则能够进行自上而下的精确抓取。然而，当前的合成数据集很少编码这种特定于本体的可供性或任务约束，限制了它们的通用性。

为应对这些挑战，本文提出 RoboTwin **2.0**，一个可扩展的基于仿真的数据生成框架，旨在为双手操作生成高质量、多样化、逼真且交互丰富的数据集。RoboTwin **2.0** 集成了三个关键组件：（1）自动化专家数据生成流程，利用多模态大语言模型（MLLMs）和仿真在环反馈，迭代验证并优化任务执行代码；（2）对语言指令、物体杂乱度、背景纹理、光照条件和桌面配置进行全面的领域随机化，旨在缩小仿真到现实的差距并增强策略泛化能力；（3）具身感知适配，标注物体可供性并生成机器人特定的动作候选，以应对异构双臂运动学差异。

基于这些组件，本文推出三项新资源以支持双手操作的可扩展研究：（1）RoboTwin-OD 资产库，包含 147 个类别中的 731 个带标注的物体实例；（2）自动化数据生成流程，具备全面的领域随机化，并收集了超过 100,000 条专家轨迹，涵盖五个双臂机器人平台上的 50 个任务；（3）一个基准，用于评估策略在杂乱

环境和开放式语言目标下的泛化能力。这些资源共同使社区能够在紧密反映现实世界复杂性和多样性的条件下，训练和评估鲁棒的双手操作策略。

总之，本文的主要贡献如下：（1）开发了一个自动化专家数据

生成框架，将多模态大语言模型与仿真在环反馈相结合，确保高质量的专家级轨迹；（2）提出了一种系统化的领域随机化策略，通过增加数据多样性和仿真到现实的泛化来增强策略鲁棒性；（3）引入了一种具身感知适配机制，基于物体可供性生成机器人特定的操作候选；（4）发布了 RoboTwin-OD 资产库、一个大规模预收集的多具身领域随机化轨迹数据集、一个可扩展的双手数据生成器，以及一个标准化的评估基准，以支持在不同机器人具身、场景配置和语言指令下对可泛化策略进行可扩展的训练和评估。

2 Method




图 2：RoboTwin 2.0 流程。该框架基于 RoboTwin-OD 和技能应用程序编程接口，利用基于多模态大语言模型的代码生成与仿真反馈，生成专家任务程序和领域随机化轨迹，用于策略训练与评估。

我们在图 2 中展示了 RoboTwin 2.0 的整体流程。该框架首先包含一个任务代码生成模块，该模块利用多模态大语言模型（MLLMs）和仿真在环反馈，从自然语言指令自动合成可执行的任务规划。该模块基于大规模物体资产库（RoboTwin-OD）和预定义的技能库，能够在广泛的物体类别和操作场景中实现可扩展的任务实例化。为确保高质量的专家演示，我们将该自动生成流程与 RoboTwin 2.0 的全面领域随机化方案相结合，该方案在语言、视觉和空间轴上使观测多样化。该流程支持合成多样且逼真的训练数据，有助于开发对真实世界环境变化具有鲁棒性的操作策略。

2.1 基于多模态大语言模型与仿真在环反馈的专家代码生成

语言模型的最新进展显示出为复杂机器人任务生成中间任务表示的强大能力，例如文本规划 [18]、应用程序编程接口调用或可执行代码 [33, 6, 19]。多模态大语言模型（MLLMs）通过融合视觉和本体感觉输入进一步扩展了这一能力，使得对真实世界传感数据的推理更加扎实。然而，现有系统通常依赖强人工先验，或在程序合成过程中缺乏闭环反馈，这限制了它们在多样或动态环境中的鲁棒性。

为解决这些局限性，本文提出一种自动化的专家数据生成流程，将程序化代码合成与多模态执行反馈相结合（图 3）。该系统采用闭环架构，包含两个智能体：代码生成智能体和视觉-语言模型

（VLM）观察器。代码智能体根据指令合成任务程序，而观察器在仿真中监控执行、检测失败并提出修正建议。这种迭代反馈

循环机制使代码智能体能够自动优化程序，从而在极少人工监督的情况下生成稳健且能自我改进的专家数据。与先前基于多模态大语言模型的流程（如 GenSim2[20] 和 RoboGen [43]）不同，本系统支持零样本生成超越基本抓取与放置动作的复杂双臂行为。




图 3：专家代码生成流程。

输入规范。每个任务由任务名称（例如，传递积木）和目标的自然语言描述定义。代码生成智能体以三个关键输入为条件：通用应用程序编程接口列表、一组示例函数调用以及分层约束规范。这些组件共同指导用于执行任务的 Python 代码的综合。此外，每个任务可能包含任务特定的函数调用示例，以进一步将代码生成锚定在上下文中。

初始代码生成。代码生成智能体以所提供的任务输入为条件，综合出初始 Python 程序。它将程序合成过程建模为可用应用程序编程接口调用空间上的结构化预测问题，利用自然语言理解和来自任务特定示例的少样本提示。生成的代码指定了旨在完成目标操作任务的机器人动作的逐步序列。

仿真执行与日志记录。生成的程序在仿真机器人环境中每次迭代执行十次。多次试验用于考虑仿真动力学、机器人控制器和传感器噪声中的随机变化。在每个执行批次之后，系统生成结构化执行日志，记录每次试验的成功或失败，并用相应原因标注失败案例——例如不可执行代码、左/右抓取失败或物体放置错误。

多模态观测与错误定位。在执行的同时，视觉语言模型（VLM）智能体观察机器人在全部十次试验中的行为。该视觉语言模型执行逐帧检查，以评估每个程序步骤的成功与否，并在出现错误时定位故障点。除了时间定位之外，视觉语言模型还通过推断根本原因是否源于逻辑缺陷、应用程序编程接口（API）使用不当或其他系统性问题来诊断故障模式。这种诊断能力使系统能够解决根本原因，而不仅仅是对表面的执行错误做出反应。视觉语言模型观测的细节见 G.4 节。

代码修复与迭代优化。代码生成智能体接收两种互补的反馈信号：（i）量化的执行日志和（ii）来自视觉语言模型的定性、局部化诊断。它整合这些输入，通过修改或替换被识别为易出错的指令来修订程序。更新后的程序在下一轮迭代中重新评估，该过程持续进行，直到程序在一轮迭代中的十次模拟运行中达到设定的成功率，或在连续五次优化后仍未能达到。该循环以最少的人工监督生成专家级任务代码，同时避免无限优化。

该流程的成果是一组鲁棒的、自动合成的程序，为下游训练和评估生成高质量的专家轨迹。通过将多模态推理与执行级反馈相结合，系统生成的代码不仅在语法上正确，而且在语义上与任务目标一致。这种闭环生成

框架大幅减少了人工监督，同时为复杂的机器人操作任务实现了可扩展且自我改进的专家数据创建。

2.2 面向鲁棒机器人操作的领域随机化

为增强策略对现实世界变化的鲁棒性，我们在五个维度上应用领域随机化：（1）杂乱的干扰物体，（2）背景纹理，（3）光照条件，（4）桌面高度，以及（5）多样化的语言指令。这种系统性的增强拓宽了训练分布，并显著提高了对未见场景的泛化能力。这些随机化的效果如图 4a 所示。




图 4：领域随机化与纹理库的可视化。

场景杂乱。为增强对环境变化的鲁棒性，我们利用来自 RoboTwin-OD（147 个类别共 731 个物体；见第 3.1 节）的任务无关干扰物来扩充桌面场景。每个物体包含放置标注，从而支持语义有效插入的通用应用程序编程接口。我们通过碰撞感知放置和预计算体积确保物理合理性。为避免策略混淆，在采样过程中排除与任务相关物体在视觉或语义上相似的干扰物。这为训练生成了多样且无歧义的杂乱场景。

多样背景纹理。我们使用大型精选纹理库对桌面表面和背景进行随机化。为构建该库，我们首先通过大语言模型提示和网络爬取收集了 1000 条多样表面描述，然后使用 Stable Diffusion v2 为每条描述生成 20 个样本（共 20000 个）。经过人在回路筛选后，我们获得了 11000 个高质量纹理。该库应用于仿真中以丰富视觉多样性并减少对干净合成环境的过拟合（见图 4b）。

光照变化。真实环境呈现多样的光照条件，在色温、光源类型、数量和位置上存在差异。这些因素改变物体外观和反射，对基于视觉的操作构成挑战。为增强鲁棒性，我们在物理合理范围内随机化光的颜色、类型、强度和位置。如图 4a（第二行）所示，色温变化可显著改变物体外观（例如，暖光与冷光下的鞋子）。在这种随机化条件下训练可提高策略对真实世界光照变化的鲁棒性。

桌面高度。在实际应用中，桌面高度因工作环境而异，影响机器人的感知、运动学与交互。为提升泛化能力，我们在仿真中于合理范围内均匀随机化桌面高度，从而在视角及机器人与物体之间的空间关系上引入多样性。

轨迹级多样化语言指令。为增强对自然语言变化的鲁棒性，我们采用多模态大语言模型生成多样化的任务模板及多种物体描述，涵盖几何、外观和部件级属性。因此，每个任务和物体均具有若干可灵活组合的替代表述。对于每条轨迹，我们从这些候选池中采样以组合指令。例如，在“移动罐子到锅”任务中，模板“使用 A 将 A 放置到 B 的左侧”可生成多样指令，如“使用左臂将酱料罐放置到

灰色厨房锅的左侧”或“使用左臂将带白色塑料盖的酱料罐放置到用于炖煮的厨房锅左侧。”这种组合式增强生成了大量语言多样的指令，并显著提升了对未见语言和场景配置的泛化能力（见附录 H、I）。

2.3 具身感知的抓取自适应

由于自由度和运动学结构的差异，不同机械臂在相同任务下具有不同的可达工作空间和偏好操作策略。例如，抓取罐子时，Franka 机械臂通常偏好自上而下的方式，而自由度较低的 Piper 机械臂更适合侧面抓取。因此，Franka 采用自上而下抓取成功完成的任务，在由 Piper 执行时可能需要侧面接近，如图 6 所示。




图 5：五种 RoboTwin 2.0 具身形态。



图 6：不同的抓取行为。

为解决具身差异问题，本文为每个物体标注了丰富的候选操作姿态，覆盖多种抓取轴和接近方向。该设计兼顾了操作多样性与机器人特定偏好。为进一步扩展可行空间，本文施加了偏向于手臂可达性更高方向的角度扰动。具体而言，对于每个物体，本文通过结合优选操作方向、随机姿态扰动和并行运动规划尝试来生成候选抓取。

3 RoboTwin 2.0 数据生成器、基准与大规模数据集

3.1 RoboTwin-OD: RoboTwin 物体数据集




图 7：RoboTwin-OD。一个面向机器人操作的大规模物体数据集，包含 147 个类别和 731 个物体，标注了丰富的交互标签和多样的语言描述。

为同时提升操作能力与视觉理解，本文构建了一个具有丰富语义标注的大规模物体数据集，称为 RoboTwin-OD，涵盖 147 个类别和 731 个多样物体。具体而言，其中包括 111 个类别中的 534 个实例，这些实例由本文通过 Rodin 平台 ¹ 的 RGB 到三维重建生成，随后进行凸分解和 ¹ <https://hyper3d.ai/>

网格合并以确保物理上精确的碰撞模型。此外，RoboTwin-OD 还纳入了 Objaverse [10] 中 27 个类别的 153 个物体，以及 SAPIEN PartNet-Mobility [48] 中 9 个类别的 44 个关节物体实例。来自所有来源（包括 Objaverse）的物体均用于构建杂乱场景，其中 Objaverse 特别增强了干扰物体的视觉和语义多样性。本文还利用生成式人工智能和人在回路筛选开发了一套全面的表面与背景纹理库，以确保视觉真实感和多样性。

为实现稳健操作，策略必须能够泛化到多样物体，这要求数据集具有广泛的类别覆盖和多样的类内实例。为促进语言基础，本文开发了一个带有人工验证的自动化物体描述生成器，为每个物体生成 15 条在形状、纹理、功能、部件结构和粒度上各异的标注。

为了进一步支持以物体为中心的交互，我们为每个物体标注了关键点-轴信息，包括放置点、功能点、抓取点和抓取轴，显式编码可供性。结合我们的操作应用程序编程接口库，这些标注使得在仿真中能够实现可泛化的抓取执行。所有物体信息可在 <http://robotwinplatform.github.io/doc/objects/> 获取。

3.2 用于数据生成和基准测试的 50 个任务

基于我们的自动化任务生成框架、具身自适应行为综合以及大规模 RoboTwin-OD 资产库，我们构建了一套包含 50 多个双臂协作操作任务的套件。我们进一步支持在五个不同的机器人平台上进行数据收集和评估，从而实现全面的跨具身基准测试。代表性任务的关键帧如图 8 所示，完整的任务描述可在 <http://robotwin-platform.github.io/doc/tasks/> 获取。我们还在 RoboTwin 2.0 中预先收集了超过 100,000 条双臂操作轨迹，涵盖 50 个任务，这些数据可在 <https://huggingface.co/datasets/TianxingChen/RoboTwin2.0/tree/main/dataset> 获取。




图 8: 50 个 RoboTwin 2.0 双臂操作任务。

4 实验

我们设计实验以评估 RoboTwin 2.0 在三个关键方面的有效性：（1）自动化生成高质量的操作任务专家代码；（2）通过多样化的训练数据提高策略对环境变化的鲁棒性；（3）展示 RoboTwin 2.0 作为标准化基准的实用性和多样性，用于评估策略在任务、场景和具身之间的泛化能力。

4.1 自动化专家代码生成的评估

我们在 10 个机器人操作任务上评估了闭环专家数据生成系统，每个任务都指定了自然语言指令。对于每种配置，代码生成智能体会产生多个候选程序，并在仿真中执行以考虑随机性

在动力学、控制与感知方面。任务级成功率定义为所有执行的平均成功率，如第 2.1 节所述。

表 1: RoboTwin 变体的整体性能比较。在 RoboTwin 1.0 和 RoboTwin 2.0 均支持的任务子集上评估。逐任务成功率比较见附录 8。

Method	ASR	Top5-ASR	CR-Iter	Token
R1.0 Vanilla	47.4%	57.6%	1.00	1236.6
R1.0 + FB	60.4%	71.4%	2.46	1190.4
R1.0 + MM FB	63.9%	74.2%	2.42	1465.0
R2.0 Vanilla	62.1%	68.0%	1.00	569.4
R2.0 + FB	66.7%	73.6%	1.89	581.6
R2.0 + MM FB	71.3%	78.6%	1.76	839.7




图 9: RoboTwin 成功率分布。

我们使用四个度量评估性能：ASR（平均成功率）、**Top5-ASR**（每个任务前 5 个候选的成功率）、**CR-Iter**（终止前的平均细化迭代次数）和 **Token**（生成策略代码中的平均标记数）。在 RoboTwin 1.0 和 2.0 上的结果报告于表 1，包含三种配置：Vanilla（一次性代码生成）、*FB*（基于执行日志的反馈修复）和 *MM FB*（带视觉-语言诊断的多模态反馈）。逐任务成功率见附录 8。

在所有设置中，多模态反馈带来一致的提升。在 RoboTwin 1.0 中，ASR 从 47.4%（Vanilla）提高到 63.9%（MM FB）；在 RoboTwin 2.0 中，从 62.1% 提高到 71.3%。Top5-ASR 也有改善，表明感知反馈对最佳候选程序尤为有利。RoboTwin 2.0 比 1.0 收敛更快（例如，MM FB 中 1.76 vs. 2.42 CR-Iter），表明先验更强、细化更高效。Token 成本也大幅降低，尤其是在 Vanilla 中（569.4 对 1236.6），反映了更简洁的初始代码。

图 9 进一步显示，反馈缩小了成功率分布并提高了中位数。带多模态反馈的 RoboTwin 2.0 实现了集中在 80% 以上的紧凑分布，突出了鲁棒性和可靠性。

总体而言，得出三个发现：（1）视觉-语言反馈不仅能检测失败，还能指导精确修复；（2）RoboTwin 2.0 的架构改进加速了收敛并减少了 Token 使用；（3）将符号执行日志与感知诊断相结合，产生更可靠、语义对齐的专家数据。这些结果共同验证了我们闭环、自改进代码生成架构的有效性。详细设置、度量定义和额外分析见附录 G。

4.2 评估有和没有自适应抓取的效率

表 2: RoboTwin 1.0 与 RoboTwin 2.0 的整体性能比较。

Method	Aloha-AgileX	Piper	Franka	UR5	ARX-X5	Average
RoboTwin 1.0	65.1%	2.4%	67.3%	57.6%	68.6%	52.2%
RoboTwin 2.0	78.8%	25.1%	67.2%	57.1%	74.2%	60.5%
Difference	+13.7%	+22.7%	-0.1%	-0.5%	+5.6%	+8.3%

为评估所提出的具身感知抓取增强策略的有效性，本文在五种不同机器人本体上测量了 50 项 RoboTwin 2.0 任务的自动化数据采集成功率。如表 2 所示，本文将 RoboTwin 2.0 流程与缺乏多样化抓取和候选增强的 RoboTwin 1.0 基线进行比较。结果表明，本文方法提高了成功率，尤其对于规划空间受限的机器人，在所有本体上平均提升 8.3%。具体而言，对于具有大可达工作空间的高自由度机械臂，如 Franka 和 UR5（7 自由度），成功率基本保持不变，表明当机器人已具备足够运动学灵活性时收益有限。然而，对于低自由度平台，如 Aloha-AgileX、Piper 和 ARX-X5（6 自由度），本文方法

分别带来 13.5%、22.7% 和 5.6% 的显著提升。这些结果表明，本文方法提供了额外的可行抓取选项，有效缓解了低自由度机械臂的规划限制。所有任务的成功率见附录 L。

4.3 评估 RoboTwin 2.0 对策略鲁棒性的影响

本文旨在评估 RoboTwin 2.0 中的域随机化数据能否赋予模型对环境扰动的鲁棒性。为此，本文首先在两种设置下（干净（非随机化）和域随机化）对 RDT 和 Pi0 进行预训练，使用从 32 个任务收集的 9,600 条专家轨迹（每任务 300 条）。

为进行比较，本文还评估了 RDT 和 Pi0 发布的预训练权重，未进行额外微调。为进一步研究泛化性，本文选择了五个未见任务，并为每个任务收集 50 条干净演示用于单任务训练和微调。最后，所有策略——包括 ACT、DP、RDT 和 Pi0——均在域随机化条件下进行评估，以衡量在未见环境中的鲁棒性。详细配置见附录 C 和 D。

表 3: 评估 RoboTwin 2.0 对策略鲁棒性的影响。

Simulation Tasks	ACT	DP	RDT	Pi0	RDT +Clean	Pi0 +Clean	RDT +Rand.	Pi0 +Rand.
Stack Bowls Two	0.0%	0.0%	30.0%	41.0%	8.0%	55.0%	49.0%	62.0%
Pick Dual Bottles	0.0%	0.0%	13.0%	12.0%	12.0%	15.0%	17.0%	7.0%
Move Can Pot	4.0%	0.0%	12.0%	21.0%	13.0%	35.0%	18.0%	22.0%
Place Object Basket	0.0%	0.0%	17.0%	2.0%	9.0%	8.0%	6.0%	22.0%
Place Shoe	0.0%	0.0%	7.0%	6.0%	9.0%	6.0%	30.0%	18.0%
Open Laptop	0.0%	0.0%	32.0%	46.0%	21.0%	33.0%	35.0%	50.0%
Press Stapler	6.0%	0.0%	24.0%	29.0%	21.0%	26.0%	27.0%	31.0%
Turn Switch	2.0%	1.0%	15.0%	23.0%	24.0%	21.0%	16.0%	21.0%
Average	2.0%	0.0%	18.8%	22.5%	14.6%	24.9%	24.8%	29.1%

如表 3 所示，我们观察到使用干净数据微调的模型在平均成功率上相比其预训练版本仅有微小提升，这表明没有领域随机化的数据无助于模型应对环境变化。这也说明预训练视觉语言动作模型在仿真中的低成功率并非源于真实到仿真的差距，因为我们提供了干净的仿真数据却未见明显改善。相比之下，使用 RoboTwin 2.0 数据预训练的模型展现出显著提升的泛化能力。具体而言，RDT 和 Pi0 分别实现了 31.9% 和 29.3% 的相对提升。值得注意的是，即使下游任务仅使用干净、非随机化的数据进行训练，这种性能增益依然存在。这表明使用 RoboTwin 2.0 进行领域随机化预训练能有效赋予模型对视觉和空间变化的鲁棒性。因此，使用 RoboTwin 2.0 预训练的模型能够适应新任务，而无需额外的数据增强或复杂的场景变化。

4.4 仿真到真实性能评估




图 10: 四种配置下的真实世界评估。

为评估 RoboTwin 2.0 在增强真实世界策略鲁棒性方面的有效性，我们在四个双臂任务上进行了实验：叠碗、传递积木、拾取瓶子和按铃。所有实验均以 RDT 作为策略骨干，并在 COBOT-MAGIC 双臂平台上执行。我们比较了三种训练设置：（1）在干净桌面环境中的 10 个真实世界演示；（2）相同的演示加上在杂乱场景、不同光照和背景下生成的 1,000 条领域随机化合成轨迹；（3）仅使用 1,000 条领域随机化轨迹训练的纯合成设置。为进一步提高对相机抖动和校准误差的鲁棒性，我们对仿真相机位姿（位置和方向）施加随机三维扰动，位移幅度限制在 1 厘米以内。

评估在四种测试配置下进行：（i）干净桌面且背景已见，

（二）干净桌面与未见背景，（三）杂乱桌面与已见背景，以及（四）杂乱桌面与未见背景（图 10）。由于纯合成设置在训练期间排除了已见背景，表 4 中相应条目被省略。该设置直接检验了 RoboTwin 2.0 能否在无需求来自视觉复杂环境的额外真实数据的情况下，实现鲁棒的策略泛化。

表 4：真实世界实验结果。我们在 4 个双臂任务上进行了对照实验：叠碗、递积木、拾瓶和按铃，每个任务均在 4 种不同设置下评估。

Real World Task	Background Type	Cluttered or Not	10 Clean Real	10 Clean Real + 1k RoboTwin 2.0	1k RoboTwin 2.0 (Zero-shot)
Stack Bowls	Seen	False	22.0%	64.0%	/
		True	12.0%	58.0%	/
	Unseen	False	10.0%	50.0%	60.0%
		True	12.0%	56.0%	52.0%
Handover Block	Seen	False	40.0%	48.0%	/
		True	16.0%	12.0%	/
	Unseen	False	36.0%	56.0%	56.0%
		True	0.0%	36.0%	20.0%
Pick Bottle	Seen	False	20.0%	36.0%	/
		True	8.0%	40.0%	/
	Unseen	False	4.0%	26.0%	10.0%
		True	8.0%	28.0%	32.0%
Click Bell	Seen	False	36.0%	24.0%	/
		True	20.0%	56.0%	/
	Unseen	False	12.0%	24.0%	20.0%
		True	16.0%	48.0%	14.0%
Average	Seen	False	29.5%	43.0% +13.5%	/
		True	14.0%	41.5% +27.5%	/
	Unseen	False	15.5%	39.0% +23.5%	36.5% +21.0%
		True	9.0%	42.0% +33.0%	29.5% +20.5%

实验结果表明，使用 RoboTwin 2.0 增强的真实世界双臂策略在鲁棒性方面取得了明显提升。在少样本设置下——将 1000 条域随机化合成轨迹与仅 10 条真实世界演示相结合——所有评估设置下的平均成功率提高了 24.4%，各配置分别提升 13.5%、27.5%、23.5% 和 33.0%。在仅使用合成数据训练的零样本设置下，我们在两个未见背景场景中仍观察到 21.0% 和 20.5% 的显著提升。值得注意的是，在视觉复杂场景中性能提升更大，表明 RoboTwin 2.0 在具有挑战性的条件下尤为有效。

这些提升源于两个因素：（1）RoboTwin 2.0 的高视觉与物理保真度，使得直接的仿真到现实迁移成为可能；（2）域随机化合成数据能够使策略为干净真实世界演示中缺失的环境变化做好准备。重要的是，

少样本设置的强劲表现表明，仅需极少的真实世界数据即可有效弥合仿真到现实的差距。

4.5 RoboTwin 2.0 基准

为评估 RoboTwin 2.0 的基准效用与泛化挑战，我们评估了五种策略模型：ACT、DP、RDT、Pi0 和 DP3。所有视觉语言动作模型均在单任务设置下基于其发布的

预训练权重进行微调。评估在所有 50 个基准任务上进行，使用 Aloha AgileX 双臂实体。对于每个任务，使用 50 个干净的专家演示进行训练，并在两种条件下用 100 次展开测试策略：简单（干净）和困难（域随机化，包含杂乱、光照、纹理和高度变化）。我们在附录 J 中提供了基准设置的可视化。我们报告成功率作为少样本适应和鲁棒性的指标。详细设置在附录 C 和 D 中提供，完整结果可在附录 K 和排行榜上找到。

表 5: RoboTwin 2.0 基准的子集。完整结果见附录 K 和排行榜。

Simulation Task	RDT		Pi0		ACT		DP		DP3	
	Easy	Hard	Easy	Hard	Easy	Hard	Easy	Hard	Easy	Hard
<i>Adjust Bottle</i>	81%	75%	90%	56%	97%	23%	97%	0%	99%	3%
<i>Beat Block Hammer</i>	77%	37%	43%	21%	56%	3%	42%	0%	72%	8%
<i>Blocks Ranking RGB</i>	3%	0%	19%	5%	1%	0%	0%	0%	3%	0%
<i>Blocks Ranking Size</i>	0%	0%	7%	1%	0%	0%	1%	0%	2%	0%
<i>Click Alarmclock</i>	61%	12%	63%	11%	32%	4%	61%	5%	77%	14%
<i>Click Bell</i>	80%	9%	44%	3%	58%	3%	54%	0%	90%	0%
<i>Dump Bin Bigbin</i>	64%	32%	83%	24%	68%	1%	49%	0%	85%	53%
<i>Grab Roller</i>	74%	43%	96%	80%	94%	25%	98%	0%	98%	2%
<i>Handover Block</i>	45%	14%	45%	8%	42%	0%	10%	0%	70%	0%
<i>Handover Mic</i>	90%	31%	98%	13%	85%	0%	53%	0%	100%	3%
<i>Hanging Mug</i>	23%	16%	11%	3%	7%	0%	8%	0%	17%	1%
<i>Lift Pot</i>	72%	9%	84%	36%	88%	0%	39%	0%	97%	0%
...										
<i>Move Pillbottle Pad</i>	8%	0%	21%	1%	0%	0%	1%	0%	41%	0%
<i>Average (in %)</i>	34.5	13.7	46.4	16.3	29.7	1.7	28.0	0.6	55.2	5.0

图 5 和附录 K 报告了 50 个任务的结果。非预训练模型（ACT、DP、DP3）在困难条件下表现不佳，而预训练模型（RDT、Pi0）表现出更强的韧性，这表明视觉-语言-动作预训练为泛化提供了有用的先验。尽管如此，从干净设置到随机化设置，成功率下降了 20.8%（RDT）和 30.1%（Pi0），突显了域偏移下的鲁棒性是一个关键挑战，可能由于预训练数据的多样性有限。DP3 在有限样本下实现了最佳的少样本性能，突显了 3D 信息的作用，尽管其强劲结果部分源于仿真中完美的点云和干净的背景分割。结合第 4.3 节和第 4.4 节，这些发现表明 RoboTwin 2.0 在补充现有数据集方面具有价值，通过提供多样化的域随机化轨迹来改善泛化和鲁棒性。

5 相关工作

5.1 机器人操作的数据集和基准

基于物理的仿真器是现代操作研究的基础。现有平台提供了互补的优势：SAPIEN [48] 支持与 2300 多个关节物体的动态交互；ManiSkill2 [16] 提供了数百万个演示；Meta-World [50]、CALVIN [32]、LIBERO [30] 和 RoboVerse [15] 针对多任务、语言条件、终身学习和域随机化设置；RoboCasa [35] 提供了大规模人类演示，但缺乏自动化和双臂关注。

大规模真实世界数据集进一步弥合了仿真到现实的差距：AgiBot World [4]、RoboMIND [47]、Open X-Embodiment [36] 和 Bridge [12] 贡献了数百万条轨迹，涵盖多样化的任务、机器人和环境。

RoboTwin-1.0 [34] 通过仿真复制品镜像真实演示，用于双臂基准测试。在本工作中，RoboTwin 2.0 集成了大语言模型驱动的反馈和跨视觉、物理及任务维度的系统化领域随机化，生成了更丰富的语料库，从而提升了策略的鲁棒性和泛化能力。与先前基准的详细比较见附录 B。

5.2 操作中的机器人学习

许多任务特定的策略架构 [42, 21, 51, 9, 14, 7, 29, 42, 27, 28, 45, 44, 8] 在单任务上表现强劲，但难以跨具身迁移。相比之下，基于百万级多机器人语料库训练的基础模型已实现鲁棒的零样本泛化：RT-1 [3] 将视觉、语言和动作统一在单个变换器中，用于实时厨房任务；RT-2 [2] 在网页和机器人数据上联合微调大型视觉-语言模型，解锁了语义规划和物体推理能力；基于扩散的 RDT-1B [31] 和 π_0 [1] 从超过一百万条轨迹中捕获多样化的双臂动力学。视觉-语言-动作（VLA）框架如 OpenVLA [23] 和 CogACT [26]，以及 Octo [40]、LAPA [49] 和 OpenVLA-OFT [22] 等适配方法，展示了对新机器人和传感器模态的高效微调。

为了进一步推进这一方向，本文引入了数字孪生数据采集与广泛的领域随机化相结合，生成的数据集紧密反映真实机器人动力学，并支持训练鲁棒且可泛化的双臂操作策略。

5.3 模仿学习中的领域随机化

先前工作表明，随机化视觉和物理参数（包括但不限于纹理、光照、相机位姿、质量、摩擦和控制延迟）并结合专家演示中的噪声注入，能够实现仿真到现实迁移和鲁棒的视觉运动策略 [41, 37, 5, 7, 28]，并且针对最坏情况集成进行优化可进一步增强对极端领域偏移的鲁棒性 [38, 25, 27]。然而，这些方法孤立地应用随机化，缺乏双向数字孪生反馈；本文方法将交互式仿真反馈与系统化领域随机化相结合，生成更高保真度的模仿数据。

6 结论

本文提出了 RoboTwin 2.0，一个可扩展的仿真框架，用于生成多样化、高保真的专家数据，以支持鲁棒的双手操作。我们的系统集成基于多模态大语言模型的任务生成、具身自适应行为综合以及全面的领域随机化，以解决先前合成数据生成器中的关键局限性。

通过利用带标注的对象库并自动化轨迹生成，RoboTwin 2.0 生成了具有丰富视觉、语言和物理多样性的数据，同时最大限度地减少了人工工程工作。实验证明了其在提高策略对杂乱环境的鲁棒性、对未见任务的泛化能力以及跨具身操作方面的有效性。

这些发现凸显了可扩展、自动化生成语义丰富、领域随机化数据对于学习鲁棒操作策略的重要性。RoboTwin 2.0 为统一基准和可扩展的仿真到现实流程奠定了基础，未来工作将聚焦于真实世界部署和多对象任务复杂度。

7 致谢

本文部分由 AgileX Robotics、D-Robotics 以及由香港赛马会慈善信托基金资助的自主智能系统赛马会 STEM 实验室支持。

参考文献

- [1] Kevin Black, Noah Brown, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Lachy Groom, Karol Hausman, Brian Ichter, et al. *pi_0*: A vision-language-action flow model for general robot control. *arXiv preprint arXiv:2410.24164*, 2024.
- [2] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Xi Chen, Krzysztof Choromanski, Tianli Ding, Danny Driess, Avinava Dubey, Chelsea Finn, et al. Rt-2: Vision-language-action models transfer web knowledge to robotic control. *arXiv preprint arXiv:2307.15818*, 2023.
- [3] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Joseph Dabis, Chelsea Finn, Keerthana Gopalakrishnan, Karol Hausman, Alex Herzog, Jasmine Hsu, et al. Rt-1: Robotics transformer for real-world control at scale. *arXiv preprint arXiv:2212.06817*, 2022.
- [4] Qingwen Bu, Jisong Cai, Li Chen, Xiuqi Cui, Yan Ding, Siyuan Feng, Shenyuan Gao, Xindong He, Xu Huang, Shu Jiang, et al. Agibot world colosseum: A large-scale manipulation platform for scalable and intelligent embodied systems. *arXiv preprint arXiv:2503.06669*, 2025.
- [5] Yevgen Chebotar, Ankur Handa, Viktor Makoviychuk, Miles Macklin, Jan Issac, Nathan Ratliff, and Dieter Fox. Closing the sim-to-real loop: Adapting simulation randomization with real world experience. In *2019 International Conference on Robotics and Automation (ICRA)*, pages 8973–8979. IEEE, 2019.
- [6] Junting Chen, Yao Mu, Qiaojun Yu, Tianming Wei, Silang Wu, Zhecheng Yuan, Zhixuan Liang, Chao Yang, Kaipeng Zhang, Wenqi Shao, Yu Qiao, Huazhe Xu, Mingyu Ding, and Ping Luo. Roboscript: Code generation for free-form manipulation tasks across real and simulation, 2024.
- [7] Tianxing Chen, Yao Mu, Zhixuan Liang, Zhanxin Chen, Shijia Peng, Qiangyu Chen, Mingkun Xu, Ruizhen Hu, Hongyuan Zhang, Xuelong Li, et al. G3flow: Generative 3d semantic flow for pose-aware and generalizable object manipulation. In *Proceedings of the Computer Vision and Pattern Recognition Conference*, pages 1735–1744, 2025.
- [8] Tianxing Chen, Kaixuan Wang, Zhaohui Yang, Yuhao Zhang, Zhanxin Chen, Baijun Chen, Wanxi Dong, Ziyuan Liu, Dong Chen, Tianshuo Yang, et al. Benchmarking generalizable bimanual manipulation: Robotwin dual-arm collaboration challenge at cvpr 2025 meis workshop. *arXiv preprint arXiv:2506.23351*, 2025.
- [9] Cheng Chi, Zhenjia Xu, Siyuan Feng, Eric Cousineau, Yilun Du, Benjamin Burchfiel, Russ Tedrake, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. *The International Journal of Robotics Research*, page 02783649241273668, 2023.
- [10] Matt Deitke, Dustin Schwenk, Jordi Salvador, Luca Weihs, Oscar Michel, Eli VanderBilt, Ludwig Schmidt, Kiana Ehsani, Aniruddha Kembhavi, and Ali Farhadi. Objaverse: A universe of annotated 3d objects. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 13142–13153, 2023.
- [11] Shengliang Deng, Mi Yan, Songlin Wei, Haixin Ma, Yuxin Yang, Jiayi Chen, Zhiqi Zhang, Taoyu Yang, Xuheng Zhang, Heming Cui, et al. Graspvla: a grasping foundation model pre-trained on billion-scale synthetic action data. *arXiv preprint arXiv:2505.03233*, 2025.
- [12] Frederik Ebert, Yanlai Yang, Karl Schmeckpeper, Bernadette Bucher, Georgios Georgakis, Kostas Daniilidis, Chelsea Finn, and Sergey Levine. Bridge data: Boosting generalization of robotic skills with cross-domain datasets. *arXiv preprint arXiv:2109.13396*, 2021.
- [13] Zhangyin Feng, Daya Guo, Duyu Tang, Nan Duan, Xiaocheng Feng, Ming Gong, Linjun Shou, Bing Qin, Ting Liu, Daxin Jiang, et al. Codebert: A pre-trained model for programming and natural languages. *arXiv preprint arXiv:2002.08155*, 2020.
- [14] Zipeng Fu, Tony Z Zhao, and Chelsea Finn. Mobile aloha: Learning bimanual mobile manipulation with low-cost whole-body teleoperation. *arXiv preprint arXiv:2401.02117*, 2024.
- [15] Haoran Geng, Feishi Wang, Songlin Wei, Yuyang Li, Bangjun Wang, Boshi An, Charlie Tianyue Cheng, Haozhe Lou, Peihao Li, Yen-Jen Wang, et al. Roboverse: Towards a unified platform, dataset and benchmark for scalable and generalizable robot learning. *arXiv preprint arXiv:2504.18904*, 2025.
- [16] Jiayuan Gu, Fanbo Xiang, Xuanlin Li, Zhan Ling, Xiqiang Liu, Tongzhou Mu, Yihe Tang, Stone Tao, Xinyue Wei, Yunchao Yao, et al. Maniskill2: A unified benchmark for generalizable manipulation skills. In *The Eleventh International Conference on Learning Representations*, 2023.

- [17] Daya Guo, Shuai Lu, Nan Duan, Yanlin Wang, Ming Zhou, and Jian Yin. Unixcoder: Unified cross-modal pre-training for code representation. *arXiv preprint arXiv:2203.03850*, 2022.
- [18] Mengkang Hu, Tianxing Chen, Qiguang Chen, Yao Mu, Wenqi Shao, and Ping Luo. Hiagent: Hierarchical working memory management for solving long-horizon agent tasks with large language model. *arXiv preprint arXiv:2408.09559*, 2024.
- [19] Mengkang Hu, Tianxing Chen, Yude Zou, Yuheng Lei, Qiguang Chen, Ming Li, Yao Mu, Hongyuan Zhang, Wenqi Shao, and Ping Luo. Text2world: Benchmarking large language models for symbolic world model generation. *arXiv preprint arXiv:2502.13092*, 2025.
- [20] Pu Hua, Minghuan Liu, Annabella Macaluso, Yunfeng Lin, Weinan Zhang, Huazhe Xu, and Lirui Wang. Gensim2: Scaling robot data generation with multi-modal and reasoning llms. In *8th Annual Conference on Robot Learning*.
- [21] Tsung-Wei Ke, Nikolaos Gkanatsios, and Katerina Fragkiadaki. 3d diffuser actor: Policy diffusion with 3d scene representations. *arXiv preprint arXiv:2402.10885*, 2024.
- [22] Moo Jin Kim, Chelsea Finn, and Percy Liang. Fine-tuning vision-language-action models: Optimizing speed and success. *arXiv preprint arXiv:2502.19645*, 2025.
- [23] Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, Ted Xiao, Ashwin Balakrishna, Suraj Nair, Rafael Rafailov, Ethan P Foster, Pannag R Sanketi, Quan Vuong, et al. Openvla: An open-source vision-language-action model. In *8th Annual Conference on Robot Learning*.
- [24] Zhiqian Lan, Yuxuan Jiang, Ruiqi Wang, Xuanbing Xie, Rongkui Zhang, Yicheng Zhu, Peihang Li, Tianshuo Yang, Tianxing Chen, Haoyu Gao, et al. Autobio: A simulation and benchmark for robotic automation in digital biology laboratory. *arXiv preprint arXiv:2505.14030*, 2025.
- [25] Michael Laskey, Jonathan Lee, Roy Fox, Anca Dragan, and Ken Goldberg. Dart: Noise injection for robust imitation learning. In *Conference on robot learning*, pages 143–156. PMLR, 2017.
- [26] Qixiu Li, Yaobo Liang, Zeyu Wang, Lin Luo, Xi Chen, Mozheng Liao, Fangyun Wei, Yu Deng, Sicheng Xu, Yizhong Zhang, et al. Cogact: A foundational vision-language-action model for synergizing cognition and action in robotic manipulation. *arXiv preprint arXiv:2411.19650*, 2024.
- [27] Zhixuan Liang, Yao Mu, Mingyu Ding, Fei Ni, Masayoshi Tomizuka, and Ping Luo. Adaptdiffuser: Diffusion models as adaptive self-evolving planners. In *International Conference on Machine Learning*, pages 20725–20745. PMLR, 2023.
- [28] Zhixuan Liang, Yao Mu, Hengbo Ma, Masayoshi Tomizuka, Mingyu Ding, and Ping Luo. Skilldiffuser: Interpretable hierarchical planning via skill abstractions in diffusion-based task execution. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 16467–16476, 2024.
- [29] Zhixuan Liang, Yao Mu, Yixiao Wang, Tianxing Chen, Wenqi Shao, Wei Zhan, Masayoshi Tomizuka, Ping Luo, and Mingyu Ding. Dexhanddiff: Interaction-aware diffusion planning for adaptive dexterous manipulation. In *Proceedings of the Computer Vision and Pattern Recognition Conference*, pages 1745–1755, 2025.
- [30] Bo Liu, Yifeng Zhu, Chongkai Gao, Yihao Feng, Qiang Liu, Yuke Zhu, and Peter Stone. Libero: Benchmarking knowledge transfer for lifelong robot learning. *Advances in Neural Information Processing Systems*, 36:44776–44791, 2023.
- [31] Songming Liu, Lingxuan Wu, Bangguo Li, Hengkai Tan, Huayu Chen, Zhengyi Wang, Ke Xu, Hang Su, and Jun Zhu. Rdt-1b: a diffusion foundation model for bimanual manipulation. *arXiv preprint arXiv:2410.07864*, 2024.
- [32] Oier Mees, Lukas Hermann, Erick Rosete-Beas, and Wolfram Burgard. Calvin: A benchmark for language-conditioned policy learning for long-horizon robot manipulation tasks. *IEEE Robotics and Automation Letters*, 7(3):7327–7334, 2022.
- [33] Yao Mu, Junting Chen, Qing-Long Zhang, Shoufa Chen, Qiaojun Yu, Chongjian Ge, Runjian Chen, Zhixuan Liang, Mengkang Hu, Chaofan Tao, et al. Robocodex: Multimodal code generation for robotic behavior synthesis. In *International Conference on Machine Learning*, pages 36434–36454. PMLR, 2024.
- [34] Yao Mu, Tianxing Chen, Zanxin Chen, Shijia Peng, Zhiqian Lan, Zeyu Gao, Zhixuan Liang, Qiaojun Yu, Yude Zou, Mingkun Xu, et al. Robotwin: Dual-arm robot benchmark with generative digital twins. *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2025.

- [35] Soroush Nasiriany, Abhiram Maddukuri, Lance Zhang, Adeet Parikh, Aaron Lo, Abhishek Joshi, Ajay Mandlekar, and Yuke Zhu. Robocasa: Large-scale simulation of everyday tasks for generalist robots. In *Robotics: Science and Systems (RSS)*, 2024.
- [36] Abby O’Neill, Abdul Rehman, Abhiram Maddukuri, Abhishek Gupta, Abhishek Padalkar, Abraham Lee, Acorn Pooley, Agrim Gupta, Ajay Mandlekar, Ajinkya Jain, et al. Open x-embodiment: Robotic learning datasets and rt-x models: Open x-embodiment collaboration 0. In *2024 IEEE International Conference on Robotics and Automation (ICRA)*, pages 6892–6903. IEEE, 2024.
- [37] Xue Bin Peng, Marcin Andrychowicz, Wojciech Zaremba, and Pieter Abbeel. Sim-to-real transfer of robotic control with dynamics randomization. In *2018 IEEE international conference on robotics and automation (ICRA)*, pages 3803–3810. IEEE, 2018.
- [38] Aravind Rajeswaran, Sarvejit Ghotra, Balaraman Ravindran, and Sergey Levine. Epopt: Learning robust neural network policies using model ensembles. In *International Conference on Learning Representations*, 2017.
- [39] Shuo Ren, Daya Guo, Shuai Lu, Long Zhou, Shujie Liu, Duyu Tang, Neel Sundaresan, Ming Zhou, Ambrosio Blanco, and Shuai Ma. Codebleu: a method for automatic evaluation of code synthesis. *arXiv preprint arXiv:2009.10297*, 2020.
- [40] Octo Model Team, Dibya Ghosh, Homer Walke, Karl Pertsch, Kevin Black, Oier Mees, Sudeep Dasari, Joey Hejna, Tobias Kreiman, Charles Xu, et al. Octo: An open-source generalist robot policy. *arXiv preprint arXiv:2405.12213*, 2024.
- [41] Josh Tobin, Rachel Fong, Alex Ray, Jonas Schneider, Wojciech Zaremba, and Pieter Abbeel. Domain randomization for transferring deep neural networks from simulation to the real world. In *2017 IEEE/RSJ international conference on intelligent robots and systems (IROS)*, pages 23–30. IEEE, 2017.
- [42] Chenxi Wang, Hongjie Fang, Hao-Shu Fang, and Cewu Lu. Rise: 3d perception makes real-world robot imitation simple and effective. In *2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 2870–2877. IEEE, 2024.
- [43] Yufei Wang, Zhou Xian, Feng Chen, Tsun-Hsuan Wang, Yian Wang, Katerina Fragkiadaki, Zackory Erickson, David Held, and Chuang Gan. Robogen: Towards unleashing infinite data for automated robot learning via generative simulation, 2023.
- [44] Junjie Wen, Yichen Zhu, Jinming Li, Zhibin Tang, Chaomin Shen, and Feifei Feng. Dexvla: Vision-language model with plug-in diffusion expert for general robot control. *arXiv preprint arXiv:2502.05855*, 2025.
- [45] Junjie Wen, Yichen Zhu, Jinming Li, Minjie Zhu, Zhibin Tang, Kun Wu, Zhiyuan Xu, Ning Liu, Ran Cheng, Chaomin Shen, Yaxin Peng, Feifei Feng, and Jian Tang. Tinyvla: Toward fast, data-efficient vision-language-action models for robotic manipulation. *IEEE Robotics and Automation Letters*, 10(4):3988–3995, 2025.
- [46] Wu Wen, Xiaobo Xue, Ya Li, Peng Gu, and Jianfeng Xu. Code similarity detection using ast and textual information. *International Journal of Performability Engineering*, 15(10):2683, 2019.
- [47] Kun Wu, Chengkai Hou, Jiaming Liu, Zhengping Che, Xiaozhu Ju, Zhuqin Yang, Meng Li, Yinyao Zhao, Zhiyuan Xu, Guang Yang, et al. Robomind: Benchmark on multi-embodiment intelligence normative data for robot manipulation. *arXiv preprint arXiv:2412.13877*, 2024.
- [48] Fanbo Xiang, Yuzhe Qin, Kaichun Mo, Yikuan Xia, Hao Zhu, Fangchen Liu, Minghua Liu, Hanxiao Jiang, Yifu Yuan, He Wang, et al. Sapien: A simulated part-based interactive environment. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 11097–11107, 2020.
- [49] Seonghyeon Ye, Joel Jang, Byeongguk Jeon, Se June Joo, Jianwei Yang, Baolin Peng, Ajay Mandlekar, Reuben Tan, Yu-Wei Chao, Bill Yuchen Lin, et al. Latent action pretraining from videos. In *CoRL 2024 Workshop on Whole-body Control and Bimanual Manipulation: Applications in Humanoids and Beyond*.
- [50] Tianhe Yu, Deirdre Quillen, Zhanpeng He, Ryan Julian, Karol Hausman, Chelsea Finn, and Sergey Levine. Meta-world: A benchmark and evaluation for multi-task and meta reinforcement learning. In *Conference on robot learning*, pages 1094–1100. PMLR, 2020.
- [51] Yanjie Ze, Gu Zhang, Kangning Zhang, Chenyuan Hu, Muhan Wang, and Huazhe Xu. 3d diffusion policy. *arXiv e-prints*, pages arXiv–2403, 2024.
- [52] Yuke Zhu, Josiah Wong, Ajay Mandlekar, Roberto Martín-Martín, Abhishek Joshi, Soroush Nasiriany, and Yifeng Zhu. robosuite: A modular simulation framework and benchmark for robot learning. *arXiv preprint arXiv:2009.12293*, 2020.

A 贡献

项目负责人 陈天行、穆尧、梁志轩	RoboTwin-OD 陈柏君、陈强宇、苏凯伦、谢玄冰、陈赞新
路线图与方法论 穆尧、陈天行、罗平、秦宇森、杨小康、王凯旋	策略训练与评估 陈天行、蔡子健、年天、高焕昂、徐天凌
数据生成器与基准 陈天行、陈赞新、陈百军、梁启伟、李梓轩、林贤亮	真实世界部署 陈天行、年天、邓伟良
代码生成智能体 刘一斌、陈赞新、葛一恒、陈天行、胡梦康	领域随机化 陈柏君、郭宇斌、梁启伟、顾振宇、刘国栋、陈赞新、陈天行

B 将 RoboTwin 2.0 与现有数据集进行基准对比

我们将 RoboTwin 2.0 与现有基准和数据集在若干关键维度上进行比较，包括支持的任务数量、领域随机化的存在、自动数据生成的支持，以及与视觉-语言-动作（VLA）模型训练和评估的兼容性。比较结果总结于表 6。

表 6: RoboTwin 2.0 与先前操作基准及数据集的比较。

Benchmark & Dataset	#Tasks	Domain Randomization	Auto Data Generation	VLA Model Train & Eval
Meta-world [50]	50	×	✓	×
Robosuite [52]	9	×	×	×
RoboCasa [50]	25	✓	×	×
Maniskill2 [16]	20	×	✓	×
AutoBio [24]	16	×	✓	✓
RoboTwin 1.0 [34]	14	×	✓	✓
RoboTwin 2.0 (ours)	50	✓	✓	✓

C 领域随机化设置

所有实验中的领域随机化包括杂乱场景、随机光照、桌面高度变化（最高 3 厘米）、未见过的语言指令以及随机化的背景纹理。

D 策略训练细节

实验 4.3 中的 RDT 在 8 个图形处理器（GPU）上以每 GPU 批大小 16 预训练 100,000 步，所有单任务微调均在 4 个图形处理器（GPU）上以每 GPU 批大小 16 进行 10,000 步。

$\pi 0$ 在实验 4.3 中，模型以批大小 32 预训练 100,000 步，所有微调均以相同批大小进行 30,000 步。

ACT 在统一设置下训练，块大小为 50，批大小为 8，单 GPU 训练 6000 个训练轮次。部署时，我们应用 temporal_agg 进行时间聚合以提升执行稳定性。

DP 训练了 600 个训练轮次，批大小为 128，规划时域为 8。

DP3 训练了 3000 个训练轮次，批大小为 256，规划时域为 8，点云分辨率为 1024，并对背景和桌面进行了精确分割。

E 支持灵活的具身组合

本文提出的以物体为中心、与具身无关的数据生成框架，能够无缝部署于多种双臂机器人系统。该流程支持灵活的具身配置，允许异构机械臂与相对臂部位置的任意组合。此设计确保了与多样化硬件设置的兼容性，并便于扩展至未来的机器人平台。



图 11：通过以物体为中心的操控实现异构双臂控制。

为了在不同实施例上执行高成功率的操作轨迹（见第 2.3 节），我们集成了 Curobo，这是一个高性能、GPU 加速的运动规划器，能够在各种运动学约束下实现高效可靠的规划。

目前，我们的框架支持五种机械臂——Franka、Piper、UR5、ARX-X5 和 Aloha-AgileX——以及多种夹爪类型，包括 Panda 夹爪和 WSG 夹爪。如图 11 所示，我们展示了在多种双臂配对下成功执行任务的情况，突显了 RoboTwin 2.0 能够扩展到异构机器人配置的能力，以及其为未来实际部署所做的准备。

F RoboTwin 2.0 相对于 RoboTwin 1.0 策略代码库的改进

Metric	RoboTwin 1.0	RoboTwin 2.0
Prompt Token Length ↓	5901.0	4719.1
Code Token Length ↓	1236.6	569.4
Parallelism Control ↑	✗	✓
AST Similarity [46] ↑	23.72%	44.78%
CodeBLEU Similarity [39] ↑	17.18%	18.53%
CodeBERT Similarity [13] ↑	97.72%	98.80%
Unixcoder Similarity [17] ↑	76.24%	82.21%
Avg. VLM Token Cost (per observation)	—	6894

表 7：代码生成效率与质量比较。对提示和生成代码特征的评估，以及与专家编写代码的代码相似度指标（AST 结构相似性、CodeBERT、Unixcoder 余弦相似度）的比较，针对 RoboTwin 1.0 和 RoboTwin 2.0 在零样本生成中的表现。还报告了 RoboTwin 2.0 的 VLM 观察器成本。

我们首先量化了 RoboTwin 2.0 在没有代码修复和迭代细化的一次性生成中的架构影响。表 7 显示，RoboTwin 2.0 生成的程序显著更短（569.4 对 1236.6 个标记），提示长度更短，并且与人工编写代码的结构相似性更高。关键的是，它通过统一的 API 抽象实现了双臂并行，这在 RoboTwin 1.0 中是不存在的。

这些改进源于 RoboTwin 2.0 中设计的结构化提示和几何 API 模块化。更高的 AST 相似性（+21.06%）、CodeBERT 相似性（+1.08%）和 Unixcoder 对齐（+5.97%）表明，RoboTwin 2.0 不仅减少了代码大小，还提高了语义清晰度和功能对齐。

此外，RoboTwin 2.0 集成了一个 VLM 观察器，这是一个即插即用的模块，仅在执行失败时触发。为了量化其开销，我们通过 Kimi API 估算了 VLM 的使用情况（假设每张图像 = 1,024 个标记），在三个代表性任务中：平均成本为 6,295 个输入标记和 599 个输出标记，总计 6,894 个标记。虽然这引入了适度的开销，但 VLM 使

RoboTwin 2.0 能够捕获并纠正执行日志中不可见的错误，显著增强了鲁棒性和整体任务成功率。重要的是，观察器仍然是可选的，可以在优先考虑标记效率时禁用。

G 代码生成的实验细节与度量定义

本文采用 DeepSeek-V3 模型进行程序合成，并采用 moonshot-v1-32k-vision-preview 模型进行多模态错误定位与验证。选择这些模型是因为它们在语言推理和视觉理解方面具有强大的性能，同时保持适合大规模迭代优化的效率。第 i 个程序的成功率计算为 $R_i = 1 / \sum_{j=1}^M s_{i,j}$ ，特定系统变体下给定任务的最终成功率定义为 $R_{\text{task}} = 1 / \sum_{i=1}^N R_i$ 。详细使用说明请参阅 <https://robotwin-platform.github.io/doc/usage/expert-code-gen.html>。

G.1 度量定义

本文报告所有任务的以下度量：

ASR（平均成功率） 是所有 10 个任务中 R_{task} 的平均值。它反映了所有生成程序的整体任务性能。

Top5-ASR 是仅使用每个任务中表现最好的前 5 个程序计算的平均成功率。该度量估计了在最佳选择策略下系统的潜在能力。

CR-lter 表示每个任务在达到超过 50% 的成功率或耗尽迭代预算之前所需的平均反馈迭代次数。

Token 表示语言模型为每个任务生成策略代码的平均令牌数。它作为计算成本和 LLM 推理预算的代理指标。

这些指标共同评估专家数据生成管道在反馈、模型能力和细化策略等不同条件下的可靠性和效率。

G.2 代码生成的任务特定性能比较

我们比较了 RoboTwin 2.0 和 RoboTwin 1.0 在所有任务上的代码生成成功率。如图所示，RoboTwin 2.0 在大多数任务上始终匹配或优于基线，证明了我们多模态反馈和细化管道的有效性。

Task	R1.0 Vanilla	R1.0 + FB	R1.0 + MM FB	R2.0 Vanilla	R2.0 + FB	R2.0 + MMFB
beat_block_hammer	16%	48%	56%	23%	34%	53%
handover_block	2%	41%	45%	17%	50%	27%
pick_diverse_bottles	65%	65%	64%	60%	60%	62%
pick_dual_bottles	99%	99%	100%	100%	100%	100%
place_container_plate	66%	79%	91%	84%	84%	82%
place_dual_shoes	19%	22%	25%	0%	2%	22%
place_empty_cup	90%	90%	100%	61%	61%	85%
place_shoe	72%	90%	90%	100%	100%	100%
stack_blocks_three	1%	2%	4%	76%	76%	82%
stack_blocks_two	44%	68%	64%	100%	100%	100%

表 8: RoboTwin 2.0 与 RoboTwin 1.0 的任务特定性能比较。R1.0/R2.0: RoboTwin 1.0 / 2.0。粗体数字表示每个任务的最佳结果。

G.3 代码生成的逐任务成功率

我们在表 9 中报告了所有任务的成功率。

表 9: 我们提出的 R2.0 + MM FB 算法在所有 RoboTwin 2.0 支持任务上的逐任务成功率。

Task	Rate	Task	Rate	Task	Rate	Task	Rate
Adjust Bottle	100%	Beat Block Hammer	53%	Blocks Ranking Rgb	80%	Blocks Ranking Size	80%
Click Alarmclock	0%	Click Bell	10%	Dump Bin Bigbin	0%	Grab Roller	74%
Handover Block	27%	Handover Mic	0%	Hanging Mug	0%	Lift Pot	40%
Move Can Pot	30%	Move Pillbottle Pad	50%	Move Playingcard Away	90%	Move Stapler Pad	100%
Open Laptop	0%	Open Microwave	0%	Pick Diverse Bottles	62%	Pick Dual Bottles	100%
Place A2B Left	50%	Place A2B Right	60%	Place Bread Basket	0%	Place Bread Skillet	0%
Place Can Basket	0%	Place Cans Plasticbox	100%	Place Container Plate	82%	Place Dual Shoes	22%
Place Empty Cup	85%	Place Fan	70%	Place Burger Fries	100%	Place Mouse Pad	100%
Place Object Basket	0%	Place Object Scale	80%	Place Object Stand	90%	Place Phone Stand	0%
Place Shoe	100%	Press Stapler	0%	Put Bottles Dustbin	0%	Put Object Cabinet	0%
Rotate Qrcode	80%	Scan Object	0%	Shake Bottle	0%	Shake Bottle Horizontally	0%
Stack Blocks Three	82%	Stack Blocks Two	100%	Stack Bowls Three	20%	Stack Bowls Two	30%
Stamp Seal	20%	Turn Switch	0%	<i>Avg Success Rate</i>	<i>43.34%</i>		

G.4 多模态观测与错误定位

为了进一步研究视觉语言模型（VLM）观测器的能力，我们手动构建了一个包含 130 个执行序列的数据集，其中包括 101 个失败试验和 29 个成功试验。每个序列由自然语言任务指令、一系列视觉观测和策略代码组成。该数据集使我们能够评估二元错误检测和细粒度错误定位。

错误检测。视觉语言模型观测器首先被要求评估机器人执行是否成功完成了指定任务。混淆矩阵如下：真阳性（TP）= 16，假阳性（FP）= 61，真阴性（TN）= 40，假阴性（FN）= 13。推导出的性能度量为：准确率 = 0.431，精确率 = 0.208，召回率 = 0.552，F1 分数 = 0.302。这些结果表明，虽然视觉语言模型观测器在识别执行失败方面具有合理的敏感性（召回率），但其过度预测错误的倾向导致了较高的假阳性率。

错误定位。对于失败的执行，我们进一步测试了视觉语言模型观测器能否正确定位导致失败的程序步骤或代码片段。在 40 个真阴性样本（正确识别的失败试验）中，观测器在 12 个案例中成功指出了失败步骤，定位准确率为 30%。这表明，虽然观测器显示出有前景的诊断能力，但在可靠的错误归因方面仍有显著的改进空间。

案例研究。本文展示一个视觉语言模型观察者推理的成功案例。给定任务指令与五次视觉观测，观察者生成了逐步分析：

步骤一：左臂成功从左侧拾取马克杯。步骤二：左臂成功将马克杯放置于中间位置。步骤三：右臂成功从中间位置拾取马克杯。步骤四：右臂尝试将马克杯挂到架子上，但未成功。步骤五：右臂在尝试挂杯后正在移开。整体任务未成功完成。失败发生在步骤四，右臂尝试将马克杯挂到架子上但未成功。马克杯未正确放置在架子上。代码中的错误信息显示为属性错误：列表对象没有属性“p”。该错误出现在将 `target_point` 设置为 `middle_target_pose.p` 的那一行。问题可能在于 `middle_target_pose` 是一个列表，而列表没有属性“p”。应修改代码以正确访问 `middle_target_pose` 列表中的位置数据。为修复错误，应更新代码以正确访问位置数据。例如，如果 `middle_target_pose` 是包含位置和姿态的列表，则应使用中间目标姿态 `[0]` 而不是 `middle_target_pose.p` 来访问位置数据。此外，步骤四的失败可能是由于尝试将马克杯挂到架子上时位置或姿态不正确。应检查代码，确保在执行悬挂动作前马克杯的位置和姿态正确。

失败模式。尽管取得了这些成功，本文也观察到视觉语言模型观察者失败的情况。错误分类主要发生在执行失败时：观察者可能幻觉出正确结果或忽略细微的姿态错误。例如，在箱子未对齐的堆叠任务中，如果所有箱子都堆叠在一起，观察者有时会将执行标记为成功。类似地，在需要精细姿态精度的任务中（例如以正确方向放置鞋子），微小但关键的错误可能被忽略。此外，由不可见因素（如错误的抓取轴参数）导致的失败，对于纯视觉观察者来说仍然难以诊断。

G.5 大语言模型生成代码与人工编写代码案例研究

大语言模型生成代码（gpt_place_shoe）

```
类 gpt_place_shoe(place_shoe): 定义 play_once(self): # 初始观测
self.save_camera_images(task_name="place_shoe", step_name="step1_initial_scene_state",
generate_num_id="generate_num_0")

# 获取鞋子的位置以确定使用哪只手臂 shoe_pose = self.shoe.get_pose()
shoe_position = shoe_pose.p arm_tag = 手臂标签 (ArmTag) ("left" 如果
shoe_position[0] < 0 否则 "right")

# 抓取鞋子 self.move(self.grasp_actor(actor=self.shoe, arm_tag=arm_tag, pre_grasp_dis
=0.1, grasp_dis=0))
self.save_camera_images(task_name="place_shoe", step_name="
step2_shoe_grasped", generate_num_id="generate_num_0")

# 将鞋子抬起以避免碰撞 self.move(self.move_by_displacement(arm_tag=arm_tag, z=0.07, move_axis='
world')) self.save_camera_images(task_name="place_shoe", step_name="step3_shoe_lifted ",
generate_num_id="generate_num_0")

# 从目标块的顶部功能点获取目标姿态 target_pose =
self.target_block.get_functional_point(1, "pose")

# 将鞋子放置在目标块上，鞋头朝左 self.move(self.place_actor(actor=self.shoe, arm_tag=arm_tag,
target_pose= target_pose, functional_point_id=0, pre_dis=0.1, dis=0.02, is_open=True,
constrain="align", pre_dis_axis='fp')) self.save_camera_images(task_name="place_shoe",
step_name="step4_shoe_placed ", generate_num_id="generate_num_0")

# 放置后将夹爪抬起 self.move(self.move_by_displacement(arm_tag=arm_tag, z=0.07,
move_axis=' world'))

# 将手臂返回原点
self.move(self.back_to_origin(arm_tag=arm_tag))

# 最终观测 self.move(self.save_camera_images(task_name="place_shoe", step_name="
step5_final_scene_state", generate_num_id="generate_num_0"))
```

清单 1：针对 gpt_place_shoe 任务的大语言模型生成代码

人工编写代码（lace_shoe）

```
类 place_shoe(base_task): 定义 play_once(self): # 获取鞋子的位置以确定使用哪只
机械臂 shoe_pose = self.shoe.get_pose().p
```

```

arm_tag = 手臂标签 ("左" 如果 鞋子姿态 0 < 0 否则 "右")

# 以指定的预抓取距离和夹爪位置抓取鞋子 self.move(self.grasp_actor(self.shoe,
arm_tag=arm_tag, pre_grasp_dis=0.1, gripper_pos=0))

# 将鞋子沿 z 方向向上抬起 0.07 米
self.move(self.move_by_displacement(arm_tag=arm_tag, z=0.07))

# 获取 target_block's 功能点作为目标姿态 target_pose =
self.target_block.get_functional_point(0)

# 将鞋子放置在 target_block 上, 并施加对齐约束和指定的预放置距离
self.move(self.place_actor(self.shoe, arm_tag=arm_tag, target_pose= target_pose, functional_point_id=0,
pre_dis=0.12, constrain="align"))

# 打开夹爪以释放鞋子
self.move(self.open_gripper(arm_tag=arm_tag))

```

清单 2: 针对 place_shoe 任务的人工编写代码

大语言模型生成的代码往往更为冗长, 会显式记录中间视觉状态并详细说明参数 (例如, pre_dis_axis='fp', is_open=True), 而人工编写的脚本则更为精简, 省略中间步骤并倾向于紧凑执行。尽管功能相似, 但结构上的差异表明, 多模态大语言模型生成的程序不仅可执行, 而且强调逐步清晰性, 有助于实现更稳健的反馈与修复。

H 任务指令与对象描述示例

Instruction Templates (task: 'Pick Dual Bottles')

"Use {a} to place {A} left of {B}.", "Set {A} to the left of {B}.", "Move {A} beside {B} using {a}.", "Place {A} on {B}'s left side.", "Using {a}, position {A} next to {B}.", "Stick {A} on the left of {B}.", "Use {a} and place {A} on {B}'s left.", etc

Object Description

```

# object id - '001_bottle/0':
"red bottle", "red soda bottle", "plastic red bottle", "red bottle with yellow label", "red
plastic bottle with smooth surface", "yellow text printed on red bottle surface", "red bottle with
white label design and markings", "red bottle with white sealing and brown top screw cap", etc
# object id - '039_mug/0':
"black mug", "dark coffee mug", "sleek black mug", "black ceramic mug", "single-handle mug",
"smooth black surface mug", "medium-sized drinking mug", "round mug with curved side", "dark mug
with sturdy handle", "solid black mug with smooth finish", etc

```

I 用于生成任务指令与对象描述的提示

任务指令模板

- 目标: 生成任务指令模板

- 要求:

- 生成 60 个项目。句子长度和结构需有所变化
- 使用自然的动作动词 (抓取、滑动、放置)

- 拆分

- 50 个项目用于训练
- 10 个项目用于评估

模式要求

K 完整 RoboTwin 2.0 基准

我们报告了五种策略在 RoboTwin 2.0 基准上简单与困难设置下的评估结果。注意，这两种设置仅在评估条件上不同，训练设置保持一致。持续维护的在线排行榜可在 <https://robotwinplatform.github.io/leaderboard> 获取。

表 10: RoboTwin 2.0 仿真基准 (干净 vs 随机化, 50+ 任务)。

Simulation Task	RDT		Pi0		ACT		DP		DP3	
	Easy	Hard	Easy	Hard	Easy	Hard	Easy	Hard	Easy	Hard
Adjust Bottle	81%	75%	90%	56%	97%	23%	97%	0%	99%	3%
Beat Block Hammer	77%	37%	43%	21%	56%	3%	42%	0%	72%	8%
Blocks Ranking RGB	3%	0%	19%	5%	1%	0%	0%	0%	3%	0%
Blocks Ranking Size	0%	0%	7%	1%	0%	0%	1%	0%	2%	0%
Click Alarmclock	61%	12%	63%	11%	32%	4%	61%	5%	77%	14%
Click Bell	80%	9%	44%	3%	58%	3%	54%	0%	90%	0%
Dump Bin Bigbin	64%	32%	83%	24%	68%	1%	49%	0%	85%	53%
Grab Roller	74%	43%	96%	80%	94%	25%	98%	0%	98%	2%
Handover Block	45%	14%	45%	8%	42%	0%	10%	0%	70%	0%
Handover Mic	90%	31%	98%	13%	85%	0%	53%	0%	100%	3%
Hanging Mug	23%	16%	11%	3%	7%	0%	8%	0%	17%	1%
Lift Pot	72%	9%	84%	36%	88%	0%	39%	0%	97%	0%
Move Can Pot	25%	12%	58%	21%	22%	4%	39%	0%	70%	6%
Move Pillbottle Pad	8%	0%	21%	1%	0%	0%	1%	0%	41%	0%
Move Playingcard Away	43%	11%	53%	22%	36%	0%	47%	0%	68%	3%
Move Stapler Pad	2%	0%	0%	2%	0%	0%	1%	0%	12%	0%
Open Laptop	59%	32%	85%	46%	56%	0%	49%	0%	82%	7%
Open Microwave	37%	20%	80%	50%	86%	0%	5%	0%	61%	22%
Pick Diverse Bottles	2%	0%	27%	6%	7%	0%	6%	0%	52%	1%
Pick Dual Bottles	42%	13%	57%	12%	31%	0%	24%	0%	60%	1%
Place A2B Left	3%	1%	31%	1%	0%	0%	2%	0%	46%	2%
Place A2B Right	1%	1%	27%	6%	0%	0%	13%	0%	49%	0%
Place Bread Basket	10%	2%	17%	4%	6%	0%	14%	0%	26%	1%
Place Bread Skillet	5%	1%	23%	1%	7%	0%	11%	0%	19%	0%
Place Burger Fries	50%	27%	80%	4%	49%	0%	72%	0%	72%	18%
Place Can Basket	19%	6%	41%	5%	1%	0%	18%	0%	67%	2%
Place Cans Plasticbox	6%	5%	34%	2%	16%	0%	40%	0%	48%	3%
Place Container Plate	78%	17%	88%	45%	72%	1%	41%	0%	86%	1%
Place Dual Shoes	4%	4%	15%	0%	9%	0%	8%	0%	13%	0%
Place Empty Cup	56%	7%	37%	11%	61%	0%	37%	0%	65%	1%
Place Fan	12%	2%	20%	10%	1%	0%	3%	0%	36%	1%
Place Mouse Pad	1%	0%	7%	1%	0%	0%	0%	0%	4%	1%
Place Object Basket	33%	17%	16%	2%	15%	0%	15%	0%	65%	0%
Place Object Scale	1%	0%	10%	0%	0%	0%	1%	0%	15%	0%
Place Object Stand	15%	5%	36%	11%	1%	0%	22%	0%	60%	0%
Place Phone Stand	15%	6%	35%	7%	2%	0%	13%	0%	44%	2%
Place Shoe	35%	7%	28%	6%	5%	0%	23%	0%	58%	2%
Press Stapler	41%	24%	62%	29%	31%	6%	6%	0%	69%	3%
Put Bottles Dustbin	21%	4%	54%	13%	27%	1%	22%	0%	60%	21%
Put Object Cabinet	33%	18%	68%	18%	15%	0%	42%	0%	72%	1%
Rotate QRcode	50%	5%	68%	15%	1%	0%	13%	0%	74%	1%
Scan Object	4%	1%	18%	1%	2%	0%	9%	0%	31%	1%
Shake Bottle Horizontally	84%	51%	99%	51%	63%	4%	59%	18%	100%	25%
Shake Bottle	74%	45%	97%	60%	74%	10%	65%	8%	98%	19%
Stack Blocks Three	2%	0%	17%	0%	0%	0%	0%	0%	1%	0%
Stack Blocks Two	21%	2%	42%	1%	25%	0%	7%	0%	24%	0%
Stack Bowls Three	51%	17%	66%	24%	48%	0%	63%	0%	57%	5%
Stack Bowls Two	76%	30%	91%	41%	82%	0%	61%	0%	83%	6%
Stamp Seal	1%	0%	3%	4%	2%	0%	2%	0%	18%	0%
Turn Switch	35%	15%	27%	23%	5%	2%	36%	1%	46%	8%
Average (%)	34.5	13.7	46.4	16.3	29.7	1.7	28.0	0.6	55.2	5.0

L 不同具身形态在 RoboTwin 2.0 任务上的成功率

表 11 报告了五种机器人具身形态在 50 个 RoboTwin 2.0 任务上的成功率，数据生成使用相同的专家程序。

表 11：不同实体在 RoboTwin 2.0 任务上的成功率。

Task Name	RoboTwin1.0					RoboTwin2.0				
	Aloha	ARX	Franka	Piper	UR5	Aloha	ARX	Franka	Piper	UR5
Adjust Bottle	92%	88%	39%	0%	7%	93%	94%	34%	0%	12%
Beat Block Hammer	68%	86%	95%	0%	86%	64%	93%	98%	15%	90%
Blocks Ranking Rgb	92%	98%	96%	0%	82%	96%	97%	99%	13%	53%
Blocks Ranking Size	90%	95%	92%	0%	60%	96%	97%	89%	7%	38%
Click Alarmclock	89%	99%	100%	0%	95%	92%	99%	100%	0%	95%
Click Bell	100%	100%	100%	9%	100%	100%	100%	100%	91%	100%
Dump Bin Bigbin	85%	98%	90%	0%	82%	84%	100%	84%	9%	80%
Grab Roller	95%	69%	99%	0%	80%	95%	69%	99%	7%	81%
Handover Block	1%	3%	0%	0%	4%	83%	81%	0%	44%	0%
Handover Mic	62%	80%	92%	28%	0%	87%	98%	84%	65%	14%
Hanging Mug	68%	76%	5%	0%	12%	63%	73%	11%	0%	11%
Lift Pot	27%	50%	24%	5%	40%	27%	50%	36%	31%	40%
Move Can Pot	18%	0%	37%	2%	4%	93%	65%	92%	96%	99%
Move Pillbottle Pad	30%	52%	15%	0%	35%	67%	90%	69%	47%	86%
Move Playingcard Away	93%	100%	100%	0%	87%	99%	100%	100%	63%	66%
Move Stapler Pad	94%	92%	88%	0%	95%	92%	96%	89%	13%	75%
Open Laptop	76%	91%	78%	14%	55%	82%	92%	77%	23%	51%
Open Microwave	65%	85%	75%	5%	33%	96%	80%	59%	2%	23%
Pick Diverse Bottles	11%	1%	0%	0%	0%	51%	2%	0%	27%	4%
Pick Dual Bottles	8%	3%	0%	0%	0%	92%	6%	0%	81%	7%
Place A2B Left	65%	75%	70%	0%	72%	80%	88%	64%	29%	76%
Place A2B Right	70%	68%	68%	0%	69%	81%	82%	64%	31%	66%
Place Bread Basket	91%	91%	69%	0%	78%	89%	88%	62%	1%	67%
Place Bread Skillet	31%	28%	42%	0%	42%	34%	26%	42%	0%	37%
Place Can Basket	47%	1%	38%	0%	11%	70%	28%	61%	0%	3%
Place Cans Plasticbox	96%	93%	98%	0%	11%	100%	96%	85%	0%	82%
Place Container Plate	86%	85%	83%	0%	82%	89%	86%	86%	37%	81%
Place Dual Shoes	73%	28%	36%	0%	40%	77%	31%	41%	1%	32%
Place Empty Cup	92%	100%	100%	0%	100%	92%	100%	100%	4%	100%
Place Fan	93%	96%	75%	0%	85%	95%	93%	83%	0%	65%
Place Burger Fries	96%	95%	85%	0%	78%	97%	98%	80%	36%	74%
Place Mouse Pad	100%	80%	99%	2%	96%	99%	89%	100%	23%	73%
Place Object Basket	68%	13%	68%	0%	30%	74%	14%	61%	0%	7%
Place Object Scale	77%	93%	94%	0%	87%	78%	92%	82%	2%	76%
Place Object Stand	90%	92%	81%	0%	90%	97%	99%	81%	9%	92%
Place Phone Stand	66%	78%	52%	22%	44%	66%	78%	45%	53%	49%
Place Shoe	87%	85%	70%	0%	97%	84%	85%	74%	7%	91%
Press Stapler	87%	96%	99%	0%	77%	98%	96%	100%	59%	72%
Put Bottles Dustbin	0%	0%	0%	0%	0%	71%	1%	0%	56%	0%
Put Object Cabinet	13%	56%	43%	0%	0%	14%	24%	55%	0%	0%
Rotate Qrcode	78%	83%	98%	0%	81%	75%	74%	94%	0%	67%
Scan Object	8%	13%	21%	0%	8%	4%	45%	26%	0%	19%
Shake Bottle	62%	95%	82%	1%	98%	89%	94%	85%	74%	97%
Shake Bottle Horizontally	64%	93%	81%	1%	97%	90%	94%	85%	74%	98%
Stack Blocks Three	98%	97%	95%	0%	83%	94%	96%	80%	0%	51%
Stack Blocks Two	99%	99%	100%	0%	94%	98%	99%	96%	2%	68%
Stack Bowls Three	27%	64%	76%	0%	76%	43%	58%	82%	0%	81%
Stack Bowls Two	63%	84%	88%	0%	94%	78%	82%	88%	4%	94%
Stamp Seal	46%	91%	95%	0%	100%	56%	91%	4%	37%	100%
Turn Switch	27%	3%	51%	28%	10%	74%	3%	36%	81%	10%
Average	65.3%	68.8%	67.6%	2.3%	57.7%	78.8%	74.2%	67.2%	25.1%	57.1%
Difference	/	/	/	/	/	+13.5%	+5.4%	-0.4%	+22.8%	-0.6%