

SmolVLA: 一种面向低成本高效机器人技术的视觉-语言-动作模型

Mustafa Shukor*^S Dana Aubakirova*^H Francesco Capuano*^H

Pepijn Kooijmans^H Steven Palma^H Adil Zouitine^H Michel Aractingi^H Caroline Pascal^H Martino Russi^H Andres Marafioti^H Simon Alibert^H Matthieu Cord^{S, v} Thomas Wolf^H Remi Cadene*^H

^H Hugging Face, ^S Sorbonne University, ^v valeo.ai, ^U 巴黎萨克雷高等师范学校

* 核心团队

Abstract



在大规模多模态数据集上预训练的视觉语言模型（Vision-Language Model）编码了丰富的视觉与语言知识，使其成为机器人技术的坚实基础。相较于从头训练机器人策略，近期方法将视觉语言模型适配为视觉-语言-动作（Vision-Language-Action）模型，从而实现自然语言驱动的感知与控制。然而，现有视觉-语言-动作模型通常规模庞大——往往拥有数十亿参数——导致训练成本高昂且实际部署受限。此外，它们依赖学术与工业数据集，忽视了来自低成本机器人平台的社区采集数据日益增长的可用性。本文提出 SmolVLA，一种小型、高效且由社区驱动的视觉-语言-动作模型，在保持竞争力的性能的同时大幅降低训练与推理成本。SmolVLA 设计为可在单个图形处理器（GPU）上训练，并部署于消费级图形处理器甚至中央处理器（CPU）上。为进一步提升响应能力，本文引入异步推理栈，将感知与动作预测从动作执行中解耦，通过分块动作生成实现更高的控制频率。尽管 SmolVLA 结构紧凑，其性能可与规模大 $10\times$ 倍的视觉-语言-动作模型相媲美。本文在一系列仿真与真实机器人基准上评估 SmolVLA，并公开全部代码、预训练模型及训练数据。

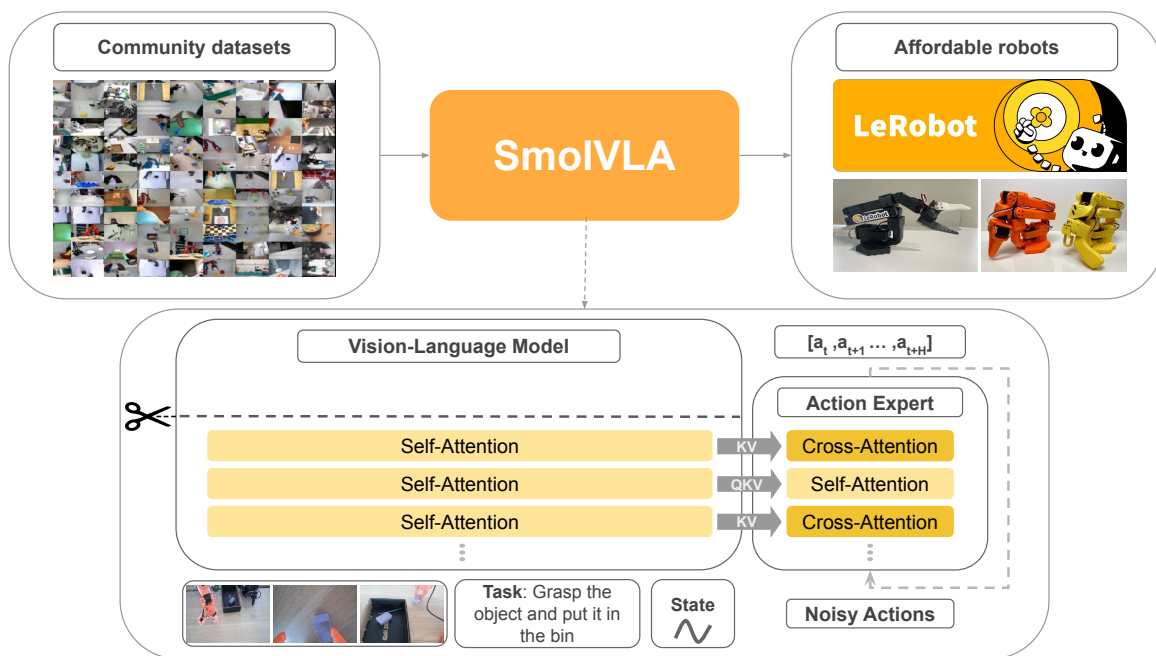


图1 | SmolVLA。SmolVLA 由一个紧凑的预训练视觉语言模型组成，丢弃最后 $L-N$ 层（剪刀图标）。剩余层嵌入三种输入：(i) 语言指令，(ii) RGB 图像，(iii) 机器人传感器运动状态。它们合并后的标记输入动作专家（Action Expert），该专家由交替的交叉注意力（金色）与自注意力（浅黄色）模块构成，通过流匹配训练输出 n 个低级动作块 $a_t, \dots, a_{t+n}$ 。SmolVLA 在公开社区数据集上预训练，并在低成本机器人上进行评估。

1 引言

近年来，该领域已转向基础模型（Foundation Model）的开发，即能够执行广泛任务的通用模型。这一趋势的一个突出例子是大语言模型（Large Language Model, LLM），它们在理解和生成自然语言、对复杂主题进行推理以及锚定知识方面，已展现出与普通人相当的性能（Brown 等，2020；Achiam 等，2023；Dubey 等，2024；Team 等，2023；Jiang 等，2023）。基于文本的模型取得的成功因此被扩展到其他模态，激发了人们对多模态视觉语言模型（Vision-Language Model, VLM）（Alayrac 等，2022；Chen 等，2023；Huang 等，2023；Liu 等，2023b；Chen 等，2024；Shukor 等，2023b）和音频语言模型（Audio-Language Model, ALM）（Défossez 等，2024；Das 等，2024；Borsos 等，2023）的兴趣。尽管在模态方面具有互补性，但开发多模态基础模型的这些进展源于（i）采用可扩展的架构，如变换器（Transformer）（Vaswani，2017），以及（ii）互联网规模的训练数据集。尽管它们在数字世界中取得了显著成就，但基础模型在现实世界中的应用——尤其是在机器人技术中——仍然有限。特别是，机器人策略（Zhao 等，2023；Chi 等，2024；Lee 等，2024；Hansen 等，2022）在跨物体类型、位置、环境和任务的泛化方面仍面临挑战（Xie 等，2024；Ebert 等，2021）。机器人应能够适应新的环境和新的物体，这需要稳健的技能和对世界的常识理解。然而，这一方向的进展似乎常常受到高质量和多样化数据可用性的限制。为了解决这一局限性，越来越多的研究开始探索以视觉-语言-动作（Vision-Language-Action, VLA）模型形式出现的机器人基础模型（Team 等，2024；O'Neill 等，2024；Brohan 等，2023；Kim 等，2024；Black 等，2024；Bjorck 等，2025；Li 等，2024；Huang 等，2024）。VLA 旨在整合预训练大语言模型和视觉语言模型中嵌入的抽象推理、世界知识和决策技能。这些模型接收多模态输入——例如视觉观察和自然语言指令——并预测相应的机器人动作。早期结果表明，在泛化能力方面有望取得进展（Black 等，2024；Brohan 等，2023）。VLA 模型仍处于早期开发阶段，尚未像 LLM 和 VLM 那样成熟或被广泛采用。许多有影响力的 VLA 进展仍然是专有的，许多模型仅共享权重，而隐瞒了完整的训练细节和关键的方法论组件。尽管在学术基准测试中有效，但我们认为，在机器人技术中实现人类水平的能力需要对开源工作做出更强有力的承诺。特别是，透明、可复现的开源模型和训练方案对于加速进展和促进机器人研究社区更广泛的参与至关重要。我们倡导开发可负担、高效的模型，使更广泛的社区能够使用。虽然像 OpenVLA（Kim 等，2024）和 RT-2-X（O'Neill 等，2024）这样令人鼓舞的努力证明了开放 VLA 系统的可行性，但它们仍然规模庞大、资源密集，并且依赖于昂贵的机器人平台，阻碍了可访问性。在这项工作中，我们介绍了 SmolVLA，这是一项开源计划，其特点是紧凑但功能强大的 VLA 模型，并随附可复现且高效的训练和推理方案。我们的贡献如下：

- **轻量级架构。**本文提出 SmolVLA，一种紧凑高效的视觉-语言智能体，针对消费级图形处理器（GPU）训练和中央处理器（CPU）部署进行了优化。关键设计选择包括：（i）在视觉-语言模型（VLM）中跳过层，（ii）使用最少数量的视觉标记，（iii）利用小型预训练视觉-语言模型，以及（iv）将自注意力层与更轻量的交叉注意力层交错排列。
- **基于社区驱动数据集的预训练。**SmolVLA 在不到 3 万个回合上进行端到端训练，这些回合完全来自公开可用的社区贡献数据集，在数据量比先前工作少一个数量级的情况下展现出强大的性能。
- **异步推理。**本文引入一种优化的异步推理栈，将动作执行与观测处理和动作预测解耦，从而降低延迟并实现快速、资源高效的推理。

本文在模拟环境和真实世界场景的多个任务上评估 SmolVLA。有趣的是，尽管规模显著更小，SmolVLA 的性能达到或超过了规模大得多的视觉-语言-动作（VLA）模型。

2 相关工作

视觉语言模型（Vision-Language Models, VLMs）。视觉语言模型（VLM）旨在同时处理视觉与文本模态——最常见的方式是将图像和文本作为输入，并根据视觉上下文生成文本。近期在

视觉语言模型（VLMs）的发展得益于大语言模型（LLMs）的成功，许多方法建立在预训练大语言模型之上，并采用类似的训练范式。通常，视觉语言模型（Alayrac et al., 2022; Laurençon et al., 2024; Lin et al., 2023a）通过将预训练的视觉编码器（Radford et al., 2021; Zhai et al., 2023; Fini et al., 2024）与预训练的大语言模型（AI@Meta, 2024; Jiang et al., 2023; Wang et al., 2024）集成而构建。随后，训练在多个多模态阶段中进行，首先在图像-文本对数据集（Schuhmann et al., 2022; Byeon et al., 2022）和交错视觉-语言语料库（Laurençon et al., 2023; Zhu et al., 2023）上进行大规模预训练，然后在指令微调数据集（Liu et al., 2023b; Tong et al., 2024; Laurençon et al., 2024）上进行监督微调阶段。其他工作展示了不依赖预训练视觉编码器的优势（Bavishi et al., 2023; Shukor et al., 2025; Diao et al., 2025, 2024），而另一些工作则致力于开发更统一的架构，将图像和文本都表示为离散标记，使单一模型能够处理多模态标记序列（Wang et al., 2022; Shukor et al., 2023b; Team, 2024; Lin et al., 2024）。效率也已成为视觉语言模型研究的核心焦点。一些工作旨在通过使用更小、更多样化的数据集（Liu et al., 2023b; Dai et al., 2023; Bai et al., 2025; Zhu et al., 2024; Tong et al., 2024）、训练更小规模的模型（Marafioti et al., 2025; Korrapati, 2024; Yao et al., 2024），或通过仅调整一小部分参数来适配预训练的单模态模型（Shukor et al., 2023a; Vallaeys et al., 2024; Mañas et al., 2023; Koh et al., 2023; Tsimpoukelli et al., 2021; Li et al., 2023）来降低训练成本。虽然视觉语言模型研究大多聚焦于图像和文本模态，但近期工作表明，类似技术可以扩展到整合视频和音频等其他模态（Wang et al., 2025; Liu et al., 2024; Zhang et al., 2025; Kong et al., 2024）。

视觉-语言-动作模型（Vision-Language-Action Models, VLAs）。机器人研究中一个日益受到关注的领域是通用策略的开发——即能够执行广泛任务、跨不同环境和机器人形态进行泛化的模型。该方向的一个突出策略利用视觉语言动作模型（VLA），这类模型能够处理（i）以自然语言给出的任务指令，（ii）视觉观测（例如来自相机流的图像），以及（iii）本体感觉输入，从而输出控制动作。早期工作如 Octo（Team 等，2024）和 RT-1（O’Neill 等，2024）在大规模机器人演示数据集上从头训练基于变换器的模型。为了提升性能和泛化能力，RT-2（Brohan 等，2023）利用预训练的视觉语言模型（VLM），并在机器人特定数据上进一步训练。为促进开放性和可复现性，OpenVLA（Kim 等，2024）发布了一个在公开可用数据上训练的 70 亿参数 VLA，用于生成离散动作标记。由于动作分词对连续控制存在局限性， π_0 （Black 等，2024）和 DexVLA（Wen 等，2025）提出使用基于扩散的解码器进行连续动作生成。在这方面，Black 等（2024）和 Wen 等（2025）均提出对预训练 VLM RDT-1B 进行适配，引入一个大型扩散组件——称为动作专家——直接在机器人演示上训练。最近，Pertsch 等（2025）提出一种使用新颖动作分词器的全自回归方法，相比传统分箱方法有所改进，但仍受限于自回归推理速度较慢。为提升 VLA 的效率，TinyVLA（Wen 等，2024）在多模态数据上从头训练了一个轻量级亚十亿参数模型，然后在机器人数据集上进行微调，但缺乏大规模机器人数据预训练阻碍了更广泛的泛化能力。SmolVLA 与上述大多数工作目标相似，旨在开发和发布在训练和推理方面既高性能又高效率的开源模型。

3 SmolVLA：小型、高效且能力强

概述。SmolVLA 是一种轻量级视觉语言动作模型，由紧凑的预训练视觉语言模型和采用流匹配训练的动作专家组成。给定多张图像和描述任务的语言指令，模型输出一段动作序列。该模型首先在社区收集的数据集上通过模仿学习进行预训练，然后在真实世界和模拟环境中进行评估。预训练数据旨在涵盖多样化的任务和行为，使模型能够学习可跨场景迁移的通用物理技能。在推理阶段，我们引入异步执行栈，将动作执行与感知和预测解耦，从而实现更快、更灵敏的控制。

3.1 模型架构

SmolVLA 由两个主要组件构成：(i) 负责感知的预训练视觉语言模型，以及 (ii) 经过训练以执行动作的动作专家。这两个组件相互连接：视觉语言模型处理状态输入以生成特征，这些特征用于调节动作专家，而动作专家产生的动作反过来改变输入到视觉语言模型的状态。具体而言，视觉语言模型处理传感器运动状态，包括来自多个 RGB 相机的图像以及描述任务的语言指令。随后，视觉语言模型输出特征，直接馈送给动作专家，动作专家输出最终的

连续动作。

视觉语言模型 (VLM)。我们利用预训练的视觉语言模型作为感知机器人环境的主要骨干。视觉语言模型在多样化的多模态数据上预训练，能够捕获丰富的世界知识。为保证效率和可访问性，我们选择 SmolVLM-2 (Marafioti 等人, 2025)，这是一种针对多图像和视频输入优化的高效模型。SmolVLM-2 依赖 SigLIP (Zhai 等人, 2023) 为 SmolLM2 语言解码器 (Allal 等人, 2025) 编码视觉特征。在 SmolVLA 中，视觉语言模型组件使用视觉编码器处理图像序列，该编码器通过令牌混洗技术减少令牌数量以提高效率。语言指令被分词为文本令牌。传感器运动状态通过线性层投影为单个令牌，以匹配语言模型的令牌维度。最后，视觉、语言和状态令牌被拼接并传递给语言解码器。通过解码器层得到的结果随后用于调节动作专家。

状态、动作和特征投影器。我们在 SmolVLA 内部的多个位置使用线性投影层。具体而言，我们使用线性投影层来 (i) 将状态投影以匹配视觉语言模型 (VLM) 的维度，(ii) 将动作投影以匹配动作专家 (action expert) 的维度，以及 (iii) 调整 VLM 特征以与动作专家的维度对齐。

视觉标记缩减。虽然高分辨率图像对 VLM 性能至关重要，但会增加推理成本。为了保证效率，SmolVLM-2 在训练时采用了图像分块 (image tiling) (Lin 等, 2023b)，这是一种流行的技术，除了全局图像外，还处理同一图像的多个裁剪块。然而，为了获得更快的推理时间，我们不使用分块。我们仅使用全局图像，并额外进行像素混洗 (pixel shuffle) 操作，将视觉标记限制为每帧 64 个。

通过跳层实现更快的推理。为了获得更快的推理时间，我们跳过 VLM 中的计算。先前的工作 (Shukor 和 Cord, 2024; Tang 等, 2023) 证明了在预训练模型中跳过层而不导致显著性能下降的可能性。最近，(El-Nouby 等, 2024; Bolya 等, 2025; Rajasegaran 等, 2025) 表明，下游任务的最佳特征不一定来自 VLM 的最后一层。因此，我们的动作专家不使用最后一层的特征，而是可以访问直到指定层 $\lfloor N \rfloor$ 的所有特征。在实践中，我们发现将 $\lfloor N \rfloor$ 设置为总层数的一半 ($\lfloor N \rfloor = L/2$) 可以在速度和性能之间提供良好的权衡，有效地将 LLM 和动作专家的计算成本减半。

流匹配动作专家。动作专家 $\mathbf{v}_\theta$ 被训练为从 VLM 特征预测动作块 $\mathbf{A}_t = (a_t, \dots, a_{t+n})$ 。与先前的工作一致，我们对 $\mathbf{v}_\theta$ 的实现依赖于变换器 (Transformer) 架构 (Vaswani, 2017)。与先前的 VLA 架构不同，我们交错使用交叉注意力和自注意力层，从而使用条件流匹配变换器 (Conditional Flow Matching Transformer) (Esser 等, 2024; Liu, 2022; Lipman 等, 2022) 作为 $\mathbf{v}_\theta$ 。动作专家使用以下目标进行训练：

$$\mathcal{L}^\tau(\theta) = \mathbb{E}_{p(\mathbf{A}_t|\mathbf{o}_t), q(\mathbf{A}_t^\tau|\mathbf{A}_t)} \left[\left\| \mathbf{v}_\theta(\mathbf{A}_t^\tau, \mathbf{o}_t) - \mathbf{u}(\mathbf{A}_t^\tau | \mathbf{A}_t) \right\|^2 \right],$$

其中 $\mathbf{o}_t$ 表示从观测 $\mathbf{o}_t$ 中提取的视觉语言模型特征，位于第 $\lfloor N \rfloor$ 个视觉语言模型层，且 $\mathbf{A}_t^\tau = \tau \mathbf{A}_t + (1-\tau)\epsilon$ ，满足 $\epsilon \sim \mathcal{N}(0, \mathbf{I})$ 。特别地， $\mathbf{v}_\theta$ 被训练用于从视觉语言模型特征和噪声动作 $\mathbf{A}_t^\tau$ 中输出向量场 $\mathbf{u}(\mathbf{A}_t^\tau | \mathbf{A}_t) = \epsilon - \mathbf{A}_t$ 。与 Black 等人 (2024) 保持一致，我们从贝塔分布中采样 τ 。为了提高推理效率，我们为 $\mathbf{v}_\theta$ 使用了缩减的隐藏尺寸 $0.75 \times d$ ，其中 d 是视觉语言模型的隐藏维度。

交叉与因果自注意力层交错排列。动作专家 $\mathbf{v}_\theta$ 以视觉语言模型特征为条件生成动作块，SmolVLA 中视觉语言模型与动作专家之间的交互通过注意力机制实现。与先前仅依赖自注意力 (SA) (Black 等人, 2024) 或交叉注意力 (CA) (Bjorck 等人, 2025) 的工作不同，我们采用交错方法，每个块包含一个交叉注意力层或一个自注意力层。该设计选择也不同于标准视觉语言模型架构，后者每个解码器块通常同时包含自注意力和交叉注意力层 (Laurençon 等人, 2023; Alayrac 等人, 2022; Chen 等人, 2022)。在动作专家的前向传播中，动作与视觉语言模型特征之间的交互通过注意力进行，将令牌投影为查询、键和值 (Vaswani, 2017)。在我们的设置中，交叉注意力层交叉关注视觉语言模型的键和值，而自注意力层允许 $\mathbf{v}_\theta$ 中的动作令牌相互关注。我们对自注意力层采用因果注意力掩码，确保每个动作令牌只能关注块内过去的令牌，防止未来动作依赖。经验上，我们发现交错使用交叉注意力和自注意力层可带来更高的成功率和更快的推理时间。特别地，我们

发现自注意力有助于生成更平滑的动作块 $\mathbf{A}$ ，这一点在真实机器人评估中尤为明显。

3.2 社区收集的预训练数据

在机器人学中，可用于大规模预训练的数据量仍比推动视觉和语言领域近期突破的数据量小几个数量级。例如，自然语言基础模型能够受益于独特的基于文本的接口和互联网数据的海量规模，而机器人数据集的整合与扩展则显得复杂，原因在于：

（一）数据集之间存在差异，以及（二）数据收集依赖人类专家的遥操作。此外，机器人形态、传感器、驱动方式、控制频率和数据格式的高度异质性导致了“数据孤岛”现象（Bjorck 等人，2025）——分散的机器人数据集难以整合。在此背景下，低端机器人平台和标准化机器人库的出现直接缓解了这种数据异质性，为从业者提供了进入机器人领域的独特切入点。进一步地，由个体从业者收集的开源数据贡献，使更广泛的机器人社区能够获得社区数据集——这些数据集在多样化的现实世界环境中收集，从学术实验室到家庭，作为通过开源方式去中心化和扩展机器人学习的更大努力的一部分。与遵循标准化协议的学术数据集不同，社区数据集天然涵盖多样的机器人本体、控制方案、相机视角和任务。此外，社区数据集通过嘈杂的演示、异构的环境和多样的物体交互反映了现实世界的复杂性，作为预训练数据具有重要价值。在本工作中，我们从 Hugging Face 获取的社区数据集中选取了 481 个子集，根据本体类型、片段数量、整体数据质量和帧覆盖率进行了筛选（表 1）。

使用视觉语言模型进行任务标注。依赖社区贡献的数据集带来了标准化挑战。特别是，我们观察到任务标注中存在大量噪声——即对给定数据集中机器人预期行为的自然语言描述。关键在于，不同数据集包含模糊的占位符（如“任务描述”）、过于笼统的命令（如“保持”或“向上”），或完全缺少指令。为了提高标注质量，我们使用现成的视觉语言模型（Qwen2.5-VL-3B-Instruct）自动生成简洁的任务描述。对于每个数据集，我们采样代表性帧，并将其与原始指令一起提供给模型。模型被提示生成一个简短的、以动作为导向的句子来概括行为。完整表示见附录 A.1。

表 1. 社区数据集统计。在 $\sim 10\text{M}$ 个片段时，我们的预训练集至少比其他最先进的数据集小一个数量级。为完整起见，我们在附录 A.1 中报告了所使用的社区数据集列表。

相机视角归一化。使用社区数据集带来的另一个挑战是相机命名惯例的高度不一致。例如，数据集中的“images.laptop”可能指顶部、侧面或腕部视角，具体取决于数据集。我们发现这种不一致性在预训练期间是有害的，而在当前数据规模下，一致的相机顺序对训练相当有益。为了解决这一标准化挑战，我们手动将每个相机映射到标准化的视角类型——优先考虑顶部、腕部和侧面视角——并分别将它们重命名为 OBS_IMAGE_1、OBS_IMAGE_2 和 OBS_IMAGE_3。对于具有额外视角的数据集，顺序被保留，但未使用的视角在训练期间被丢弃。未来的工作可能利用视觉语言模型自动化这一过程，或提出/采用标准化的数据收集指南。

3.3 异步推理

现代视觉运动策略（Zhao 等人，2023；Chi 等人，2023；Black 等人，2024）输出动作块——序列 $\pi(o_t) = \mathbf{A}_t$ ，其中 $\mathbf{A}_t = (a_t, a_{t+1}, \dots, a_{t+n})$ 是 n （远大于 1）个低级命令的序列，这些命令被排入动作队列，源自环境观测 o_t 。通常，机器人执行整个动作块 $\mathbf{A}_t$ ，然后将新的观测 o_{t+n} 传递给策略 π 以预测下一个块。这导致在每 n 个时间步捕获的观测之间进行开环推理。包括 Zhao 等人（2023）；Chi 等人（2023）在内的研究采用了不同的策略，机器人控制器交错进行块预测 $\mathbf{A}_t \leftarrow \pi(o_t)$ 和块消耗 $a_t \leftarrow \text{PopFront}(\mathbf{A}_t)$ ，在每个时间步 t 计算新的动作块，并在重叠部分聚合预测的块。虽然具有自适应性——每个时间步的每个观测 o_t 都被处理——但这类方法依赖于持续运行推理，这在资源受限的场景（如边缘部署）中可能不可行。




图 2 异步推理。异步推理栈的图示。注意，策略可以在远程服务器上运行，可能带有 GPU。

一种资源密集度较低的方法是在预测新的动作块之前完全耗尽块 $\mathbf{A}$ ，我们将这种策略称为同步（sync）推理。此外，同步推理每 n 个时间步高效地分配计算，从而在控制时降低平均计算负担。相比之下，它固在地阻碍了机器人系统的响应能力，由于机器人在计算 $\mathbf{A}$ 时处于空闲状态而引入盲滞后。

我们通过将动作块预测 $\mathbf{A}$ 与动作执行解耦 $a_t \leftarrow \text{弹出队首}(\mathbf{A}_t)$ ，直接评估机器人系统因开环运行而缺乏自适应性的问题，以及运行时存在的滞后，并开发了一个异步推理栈（算法 1），其中机器人客户端发送观测 o_t 到策略服务器，在推理完成后接收动作块 $\mathbf{A}_t$ （图 2）。在此过程中，我们通过在控制回路仍在消耗先前可用队列时触发块预测，并在可用时将其与新传入队列聚合，从而避免执行滞后。反过来，异步推理通过提高为块预测处理观测的频率，缩短了动作预测与动作执行之间的回路。至关重要，将动作预测与动作执行解耦还直接允许在远程策略服务器上分配更多计算资源，通过网络向机器人客户端发送动作，这在资源受限的场景（如低功耗机器人）中可能非常有效。

Algorithm 1 Asynchronous inference control-loop

```

1: Input: horizon  $T$ , chunk size  $n$ , threshold  $g \in [0, 1]$ 
2: Init: capture  $o_0$ ; send  $o_0$  to POLICYSERVER; receive  $\mathbf{A}_0 \leftarrow \pi(o_0)$ 
3: for  $t$  to  $T$  do
4:    $a_t \leftarrow \text{POPFRONT}(\mathbf{A}_t)$ 
5:   EXECUTE( $a_t$ ) ▷ execute action at step  $t$ 
6:   if  $\frac{|\mathbf{A}_t|}{n} < g$  then ▷ queue below threshold
7:     capture new observation,  $o_{t+1}$ 
8:     if NEEDSPROCESSING( $o_{t+1}$ ) then ▷ similarity filter, or triggers direct processing
9:        $\text{async\_handle} \leftarrow \text{ASYNCINFER}(o_{t+1})$  ▷ Trigger new chunk prediction (non blocking)
10:       $\hat{\mathbf{A}}_{t+1} \leftarrow \pi(o_{t+1})$  ▷ New queue is predicted with the policy
11:       $\mathbf{A}_{t+1} \leftarrow f(\mathbf{A}_t, \hat{\mathbf{A}}_{t+1})$  ▷ aggregate overlaps (if any)
12:    end if
13:  end if
14:  if NOTCOMPLETED( $\text{async\_handle}$ ) then ▷ No update on queue (inference is not over just yet)
15:     $\mathbf{A}_{t+1} \leftarrow \mathbf{A}_t$ 
16:  end if
17: end for

```

Action queue size ($|Q|$) versus timesteps. Queue is consumed by RobotClient and refilled by PolicyServer




图 3 在 g 的不同水平下运行时动作队列大小的演变，当 (A) 不基于关节空间相似性过滤观测和 (B) 过滤掉近重复观测，在关节空间中测量它们的相似性。

实现细节 异步推理 (i) 通过更频繁地捕获观测来收紧控制回路，直接消除运行时的空闲间隙，并且 (ii) 直接允许在比自主机器人平台通常可用的更强大的计算资源上运行推理。在算法上，我们在机器人客户端侧通过从现成队列中消耗动作，直到满足队列中剩余动作数量的阈值条件 ($|A_t|/n < g$) 来实现 (i)。当触发此条件时，捕获环境的新观测并发送到 (可能是远程的) 策略服务器。为了避免冗余的服务器调用和运行时的异常行为，在关节空间中比较观测，并丢弃近重复项。如果两个观测在关节空间中的距离低于预定阈值 $\epsilon \in \mathbb{R}_+$ ，则认为它们是近重复的。重要的是，当机器人客户端可用的队列最终变为空时，无论相似性如何，都会处理最近的观测。

有趣的是，异步推理的行为可以通过解析方法进行研究。首先，令 ℓ 为一个随机变量，用于建模在发送观测 o 后接收到动作块 A 所需的时间，即以下三部分之和：(i) 在机器人客户端与策略服务器之间发送观测 o 的时间， $t_{C \rightarrow S}$ (ii) 策略服务器上的推理延迟， ℓ_S 以及 (iii) 在策略服务器与机器人客户端之间发送 A 的时间， $t_{S \rightarrow C}$ 。假设相互独立， $\mathbb{E}[\ell] = \mathbb{E}[t_{C \rightarrow S}] + \mathbb{E}[\ell_S] + \mathbb{E}[t_{S \rightarrow C}]$ 可进一步简化为 $\mathbb{E}[\ell] \approx \mathbb{E}[\ell_S]$ ，前提是通信时间 (i) 在两个方向上相等且 (ii) 相对于推理延迟可忽略不计。其次，令 Δt 为环境的控制周期。在现实世界中帧率为每秒 30 帧时， $\Delta t = 33\text{ms}$ 。因此，在运行时队列耗尽——即空闲等待新块——在 $g \geq \frac{\mathbb{E}[\ell_S]/\Delta t}{n}$ 的情况下可以避免。其中，队列阈值 g 相对于机器人客户端可用动作的充足性起着重要作用。

图 3(A) 展示了动作块大小 $|A_t|$ 在 g 的三个代表性取值下随时间演化的过程，详细说明了以下关键场景：• 顺序极限 ($g = 0$)：客户端在向服务器转发新观测之前耗尽整个块。在计算下一个块所需的往返延迟期间，队列为空，导致机器人无法行动。这再现了完全顺序部署的行为，并导致平均 $\mathbb{E}[\ell_S]$ 秒的空闲时间。• 异步推理 ($g = 0.7$)：允许客户端在触发新动作队列 A_t 的推理之前消耗队列 A_{t-1} 的大约 $1 - g = 0.3$ 部分，从而在保持队列不为空的同时分摊计算开销。连续块之间的重叠为建模误差提供了缓冲，而无需承担 $g = 1$ 机制的全部成本。更新后的队列 A_t 是通过在 A_{t-1} 与传入的 A_t 之间的重叠时间步上聚合队列得到的。• 计算密集型极限 ($g = 1$)：作为一种极端情况，与 Zhao 等人 (2023) 和 Chi 等人 (2024) 的做法一致，每个时间步都发送一次观测。因此，队列几乎总是满的，仅因 $\Delta t/\mathbb{E}[\ell_S] < 1$ 而出现轻微的锯齿状波动。虽然这种方式具有最大的反应性，但每个控制周期都需要一次前向传播，在有限硬件上可能成本过高。重要的是，由于客户端在服务器计算下一个块的同时消耗动作，可用队列永远不会再次被填满。

图 3(A) 强调了由 g 控制的权衡：较小的值会导致空闲期，而 $g \approx 1$ 假设模型高度准确并付出显著的计算代价。在实践中，选择 $g \in (0, 1)$ 可以在反应性与资源预算之间取得平衡

在反应性与资源预算之间。如果没有上述相似性过滤器，机器人客户端将每 $\lfloor (1-g)n \rfloor \cdot \Delta t$ 秒发送一次观测数据进行处理，平均每 $\lfloor (1-g)n \rfloor \cdot \Delta t + \mathbb{E}[\ell_S]$ 秒接收一个新的动作块。观测相似性过滤器的存在延长了这一处理时间，其目的是避免机器人因队列不断被传入的、几乎相同的动作块填充而停滞。特别是，图 3(B) 显示，除非将近重复的观测从处理管线中过滤掉，否则队列会被传入的动作填满。为清晰起见，图 3(B) 中的红色箭头突出显示了一个时间步，在该时间步中观测相似性机制被绕过，强制处理一个（几乎相同的）观测，因为队列为空。

4 实验

4.1 实验设置

我们在仿真和真实世界的机器人操作任务上评估我们的模型。为了在仿真中评估 SmolVLA，我们为 MetaWorld (Yu 等人, 2020) 收集了一个新数据集，包含 50 个任务中每个任务的 50 个演示。对于真实世界评估，我们使用 SO-100 机器人臂 (Knight 等人) 收集了三个数据集，并使用 SO-101 臂 (Knight 等人) 收集了一个数据集，每个数据集对应不同的操作任务。每个数据集包含与一个任务相关的轨迹，5 个不同起始位置各 10 条轨迹，每个数据集总共 50 个演示。除非另有说明，SmolVLA 始终在多任务设置下训练。

评估度量。我们报告成功率 (SR) 作为所有基准的主要度量。对于基于仿真的评估，SR 是二元的——如果任务成功完成则设为 1，否则为 0。对于真实世界评估，我们采用更细粒度的评分方法，将每个任务分解为子任务。例如，在拾取-放置任务中，成功拾取立方体得 0.5 分，正确放入目标容器再得 0.5 分。

仿真环境。我们在两个已建立的多任务仿真基准上评估 SmolVLA：LIBERO (Liu 等人, 2023a) 和 Meta-World (Yu 等人, 2020)。LIBERO 在四个类别中评估多样化的视觉运动技能——空间、物体、目标和长程——每个类别 10 个任务（共 40 个）。我们使用一个数据集 (Kim 等人, 2024; Pertsch et al., 2025)¹，包含覆盖所有任务的 1,693 个回合，并对每个任务进行 10 次试验评估，基于二元完成标准报告平均成功率。Meta-World 评估在 50 个不同难度任务上的泛化能力：简单、中等、困难和非常困难 (Seo 等人, 2023)。我们使用一个数据集²，包含 2,500 个回合（每个任务 50 个），并采用与 LIBERO 相同的评估协议：每个任务 10 次试验，仅当任务完全完成时试验才计为 1 分。

真实世界任务。我们在真实世界环境中评估了 SmolVLA 在 4 个数据集上的表现，并在 Hugging Face 上开源了这些数据集 (图 4)。具体而言，我们基准测试了 SO100 机器人的真实世界拾取和放置能力³、堆叠能力⁴和分拣能力⁵，以及 SO101 平台的真实世界拾取和放置能力⁶。关键的是，SmolVLA 未在任何为 SO101 记录的数据集上进行预训练。

对于拾取和放置任务，SmolVLA 被指示拾取立方体并将其放入盒子中。盒子尺寸较小且位置固定，而立方体的起始位置在 5 种不同的起始条件下变化。我们使用细粒度评分评估任务完成情况：成功抓取立方体得 0.5 分，成功将其放入盒子得 0.5 分。对于堆叠任务，SmolVLA 需要将一个立方体放在另一个立方体之上。我们指示机器人拾取红色立方体并将其放在蓝色立方体之上。两个立方体的初始位置在不同回合中变化。我们使用细粒度评分评估任务完成情况：成功抓取顶部立方体得 0.5 分，成功将其放在底部立方体之上得 0.5 分。

¹LIBERO 数据集: [physical-intelligence/libero](https://github.com/physical-intelligence/libero) ²Meta-World 数据集:

[lerobot/metaworld_mt50](https://github.com/lerobot/metaworld_mt50) ³拾取-放置数据集:

[lerobot/svla_so100_pickplace](https://github.com/lerobot/svla_so100_pickplace) ⁴堆叠数据集:

[lerobot/svla_so100_sorting](https://github.com/lerobot/svla_so100_sorting) ⁵分拣数据集: [lerobot/svla_so100_sorting](https://github.com/lerobot/svla_so100_sorting)

⁶ (SO101) 拾取-放置数据集: [lerobot/svla_so101_pickplace](https://github.com/lerobot/svla_so101_pickplace)




图 4 我们用于基准测试 SmolVLA 的四个真实世界任务示意图，展示了所考虑数据集的起始帧和终止帧，分别针对 SO100 (A) 和 SO101 (B) 两种机器人本体。对于 SO100，我们使用顶部和腕部相机；对于 SO101，我们使用顶部和侧面相机（如图中所示）。

对于具有更长视野的排序任务，SmolVLA 必须根据颜色对立立方体进行排序，遵循将红色立方体放入右侧盒子、蓝色立方体放入左侧盒子的指令。立方体被放置在如任务 1 中的 5 个不同位置。为了引入变化，立方体的颜色被交换，每种颜色配置有 5 个回合，每个位置共产生 10 次演示。盒子的位置在所有演示中保持固定。我们使用细粒度评分来评估任务完成情况：成功抓取任一立方体得 0.25 分，成功完成一个立方体与盒子的匹配得 0.25 分，任务完成时总分为 0.25×4 。图 4 (A) 展示了所有任务成功回合的初始帧和最终帧，以及相应数据集的 Hugging Face 标识⁷。为了评估 SmolVLA 的泛化能力，我们还在不同的机器人本体和任务上评估了我们的模型⁸，该任务类似于拾取放置，但使用小积木块而不是立方体。在此任务中，机器人被指示将粉色乐高积木放入透明盒子中。该任务要求更高的精确度，尤其是在抓取小型乐高物体时，同时考虑到盒子的透明性，还需要先进的视觉能力。

4.2 机器人

在仿真和真实世界环境中，我们使用了多种机器人平台。

- **SO100 和 SO101** (Cadene 等人, 2024)。标准开源 SO-100 是一种低成本、可 3D 打印的机械臂，旨在提高机器人技术和机器人学习研究的可及性。SO-100 及其更新版本 SO-101 都是用于基本操作任务的开源平台。每个机械臂具有六个自由度，并使用由位置指令控制的低成本伺服电机。SO101 具有更好的机械臂设计，可加快组装速度，并采用不同的电机，使其运动更平稳，更适合需要更高精度的任务。

- **Panda** (哈达丁等人, 2022)。弗兰卡·艾米卡熊猫是一款单臂七自由度力矩控制机器人，专为安全精准操作而设计。其高分辨率关节传感与柔顺控制使其非常适合在仿真与真实环境中进行基于学习的操作任务。该机器人用于自由机器人基准 (LIBERO) 仿真器。

- **索耶** (余等人, 2020)。是一款单臂四自由度受控机器人，专为操作任务而设计。它用于元世界 (Meta-World) 仿真器，策略控制夹爪的位置与状态。

⁷ 数据集可通过 visualize_dataset 轻松探索 8Pick-Place-Lego 数据集: lerobot/svla_so101_pickplace.

4.3 实现细节。

我们使用 LeRobot (Cadene 等人, 2024) 进行实验, 这是一个基于 PyTorch 的真实机器人框架。在预训练期间, 我们在所有社区数据集上以 256 的全局批大小训练 200,000 步。经过 100 步预热后, 我们使用余弦学习率调度, 从 $1e-4$ 开始衰减到最小值 $2.5e-6$ 。我们使用 AdamW 优化器, 其中 $\beta_1 = 0.9, \beta_2 = 0.95$ 。训练在将图像调整为 512×512 后进行, 以与 VLM 输入尺寸保持一致。我们使用 SmolVLM-2 (Marafioti 等人, 2025) 作为 VLM 骨干。动作专家通过流匹配进行训练, 输出 $n = 50$ 个动作的块。对于真实世界评估, 我们执行同步推理: 模型仅在执行完整个动作块后才采样新的观测。在仿真中, 我们在每个执行动作后采样新观测并预测新动作来进行推理。在推理期间, 流匹配固定为 10 步。我们仅训练动作专家模块, 保持 VLM 冻结。我们的主模型包含 4.5 亿个参数, 其中约 1 亿个专用于动作专家。我们仅使用 VLM 中大语言模型 (LLM) 的前 16 层。对于仿真基准的微调, 我们以 64 的批大小训练 100,000 步, 而对于真实世界任务, 我们微调 200,000 步。然而, 我们在实践中观察到, 模型可以在不牺牲显著性能水平的情况下以少得多的步数进行训练。除了保持紧凑的模型和减少的标记数量外, 我们还采用了几种优化来提升训练效率。具体来说, 我们利用 bfloat16 精度和 `torch.compile()` (Paszke, 2019), 后者将 PyTorch 代码即时编译为优化的核函数。为确保与这些优化兼容, 我们保持固定的序列长度和批大小, 丢弃一个回合中无法填满完整批次的任何多余帧。对于多 GPU 和多节点训练, 我们利用 Hugging Face 的 `accelerate` (Gugger 等人, 2022) 库进行混合精度训练, 提供可扩展且内存高效的训练设置。预训练使用 4 个 GPU 进行, 以适应大批大小, 但由于模型尺寸小, 可以轻松在单个 GPU 上训练。总体而言, 该项目消耗了约 3 万 GPU 小时。

4.4 基线

我们将我们的模型与两个流行且强大的基线进行比较, 两者均在 LeRobot 库中可用 (Cadene 等人, 2024)。

π_0 (Black 等人, 2024)。 π_0 是一种视觉语言动作模型, 它利用视觉语言模型结合流匹配进行动作块预测。该模型总参数量为 33 亿, 并在 10000 小时的跨具身机器人数据上进行了预训练。模型架构基于 Paligemma (Beyer 等人, 2024), 接受三幅 RGB 图像、感觉运动状态和语言指令作为输入。

ACT (Zhao 等人, 2023)。ACT 是一种条件变分自编码器 (CVAE) (Sohn 等人, 2015) 策略模型, 采用编码器-解码器变换器架构, 参数量约为 8000 万。ACT 使用在 ImageNet 上预训练的 ResNet 视觉编码器, 而 CVAE 则从头开始训练。该模型生成动作块, 并使用回归目标进行优化, 直接预测连续动作。模型接受 RGB 图像序列和感觉运动状态。

4.5 主要结果

在本节中, 我们展示了 SmolVLA 在真实世界和仿真环境中的主要结果。对于真实世界评估, SmolVLA 在社区收集的数据集上进行了预训练。 π_0 在相应的目标数据集上进行了微调, 而 ACT 则在每个数据集上从头开始训练。

仿真评估。在表 2 中, 我们进一步在多任务训练设置下, 在两个主要的仿真基准——LIBERO 和 Meta-World——上评估了 SmolVLA。SmolVLA 在 LIBERO 和 Meta-World 上均优于其他基于视觉语言动作模型的方法, 如 Octo (Team 等人, 2024) 和 OpenVLA (Kim 等人, 2024), 以及扩散策略基线。我们还比较了 π_0 的两种变体: 一种从视觉语言模型 (Paligemma-3B) 初始化, 另一种在机器人数据集上进一步预训练 (从作者发布的权重初始化)。尽管未在机器人数据上预训练, SmolVLA 始终优于视觉语言模型初始化的 π_0 , 并且与机器人预训练版本相比具有竞争力。请注意, 与 π_0 相比, SmolVLA 的训练速度约快 40%, 内存消耗减少 6 $\times$ 。

Benchmark	Policy (# Params)	VLA Pt.	Success Rate (%) – Simulation				
LIBERO			Spatial	Object	Goal	Long	Avg.
	Diffusion Policy (Khazatsky et al., 2024)	No	78.3	92.5	68.3	50.5	72.4
	Octo (0.09B) (Team et al., 2024)	Yes	78.9	85.7	84.6	51.1	75.1
	OpenVLA (7B) (Kim et al., 2024)	Yes	84.7	88.4	79.2	53.7	76.5
	π_0 (Paligemma-3B)	No	87	63	89	48	71.8
	π_0 (3.3B)	Yes	90	86	95	73	86.0
	SmolVLA (0.24B)	No	87	93	88	63	82.75
	SmolVLA (0.45B)	No	90	96	92	71	87.3
	SmolVLA (2.25B)	No	93	94	91	77	88.75
Meta-World			Easy	Medium	Hard	Very Hard	Avg.
	Diffusion Policy (Chi et al., 2023)	No	23.1	10.7	1.9	6.1	10.5
	TinyVLA (Zhou et al., 2024)	No	77.6	21.5	11.4	15.8	31.6
	π_0 (3.5B-Paligemma)	No	80.4	40.9	36.7	44.0	50.5
	π_0 (3.5B)	Yes	71.8	48.2	41.7	30.0	47.9
	SmolVLA (0.24B)	No	86.43	46.36	35	60	56.95
	SmolVLA (0.45B)	No	82.5	41.8	45.0	60.0	57.3
	SmolVLA (2.25B)	No	87.14	51.82	70	64	68.24

Table 2 | Simulation benchmarks (LIBERO and Meta-World). Success rates (%) for various policies. LIBERO tasks correspond to different settings (e.g., spatial, object, goal, long-horizon); Meta-World tasks reflect different difficulty levels. VLA Pt refers pretraining on robotics data. SmolVLA is only initialized from the VLM. Baselines scores from Kim et al. (2024); Wen et al. (2024).

Policy	Success Rate (%) – Real World			
	Pick-Place	Stacking	Sorting	Avg.
Single-task Training				
ACT	70	50	25	48.3
Multi-task Training				
π_0 (3.5B)	100	40	45	61.7
SmolVLA (0.45B)	75	90	70	78.3

表 3 | 真实世界基准 (SO100)。使用多任务和单任务设置训练的策略在三个任务上的成功率 (%)。

Policy	Success Rate (%) – Real World	
	In Distribution	Out of Distribution
Single-task Training		
ACT	70	40
SmolVLA (0.45B)	90	50

Table 4 | Real-world benchmark (SO101). Success rate (%) for the Pick-Place-Lego task using policies trained in single-task setting.

真实世界评估。在表 3 中，我们在四个真实世界任务上评估了 SmolVLA。对于 SO101 基准，模型在三个数据集的组合上进行训练，并报告每个任务以及平均的成功率。SmolVLA 优于 ACT (Zhao 等人, 2023 年)，后者在每个任务上单独训练，以及 π_0 ，一个在参数数量上显著更大的模型 ($\sim 7\times$)。同样，在 SO101 上 (见表 4)，SmolVLA 在分布内和分布外 (OOD) 设置中均超过 ACT。对于 OOD 评估，乐高物体被放置在训练期间未遇到过的新位置。

预训练和多任务学习的效果。在表 5 中，我们进一步评估了在社区数据集上预训练 SmolVLA 对真实世界性能差异的影响，并研究多任务微调是否为 SmolVLA 提供额外益处。结果表明，在社区数据集上预训练带来了显著的性能提升 (从 51.7 到 78.3)。此外，多任务微调带来了进一步的收益，强调了跨任务知识迁移的重要性。

Policy	VLA pt.	Success Rate (%) – Real World			
		Pick-Place	Stacking	Sorting	Avg.
Single-task Training					
SmolVLA (0.45B)	No	55	45	20	40
Multi-task Training					
SmolVLA (0.45B)	No	80	40	35	51.7
SmolVLA (0.45B)	Yes	75	90	70	78.3

Table 5 | Effect of pretraining and multitask learning. Success rate (%) across three tasks using SmolVLA trained in multi-task and single-task settings. Results with SO100 robot.

Inference	Success Rate (%) – Real World				Inference	Time (s) – Real World			Inference	# of Cubes – Real World		
	Pick-Place	Stacking	Sorting	Avg		Total	Avg	Std		Total	Avg	Std
Sync	75	90	70	78.3	Sync	137.5	13.75	2.42	Sync	9	1.8	0.45
Async	80	90	50	73.3	Async	97.0	9.70	2.95	Async	19	3.8	1.3

(a) | Performance (success rates). (b) | Task completion time. (c) | Performance in fixed time.

图 5 同步 (Sync) 与异步 (Async) 推理的比较。我们在两种推理模式下评估了 SmolVLA 在三个真实世界任务上的表现。异步推理实现了相似的成功率（左），但在固定时间设置中显著更快（中）并完成更多任务（右）。超参数已针对 Pick-Place 进行了优化，并在各任务间复用。

4.6 异步推理

我们在两种推理模式下评估了 SmolVLA：同步和异步。同步模式反映了机器人学中的标准评估设置，即策略预测一个动作块，该动作块在下一预测周期开始前完全执行。相比之下，异步模式将动作执行与策略推理解耦，允许预测和控制并行运行。

结果。对于两种推理模式，我们报告了成功率和策略速度（图 5）。为了评估速度，我们设计了两个使用抓取-放置任务的实验。在第一个实验中，我们测量了在 10 次试验和 5 个不同立方体位置下完成任务所需的时间。在第二个实验中，我们固定一个时间限制（例如 60 秒），并计算从不同位置成功抓取并放入盒子中的立方体数量。计时从机器人开始移动时开始。如图 5a 所示，两种推理模式在三个真实世界任务中取得了相当的成功率。然而，异步推理展示了显著的速度优势（图 5b）。平均而言，它在 9.7 秒内完成任务，而同步设置下为 13.75 秒（快 $\sim 30\%$ ）。此外，在固定时间评估下，异步模式允许机器人完成 19 次成功的抓取-放置循环，而同步情况下仅为 9 次（图 5c）。从定性角度看，我们观察到异步推理能够实现更快的反应和更好的环境变化适应性。机器人对物体位置变化和外部干扰表现出更强的鲁棒性，并且由于避免了预测滞后，总体上能够显著更多次地解决相同任务（图 5）。

4.7 消融实验

我们进行了全面的消融实验，以评估最终 SmolVLA 模型背后的关键设计选择。所有消融实验均在 LIBERO 基准上进行。除非另有说明，模型均从头开始训练，未在机器人数据上进行任何预训练。视觉语言模型骨干被冻结，仅动作专家从头开始训练。

视觉语言模型与动作专家之间的交叉注意力与自注意力对比 $\mathbf{v}_{\theta}$ 我们比较了视觉语言模型特征与动作专家的交互方式，对比了因果自注意力、交叉注意力以及我们提出的交错自注意力+交叉注意力设置。在自注意力设置中，动作标记使用因果掩码相互关注，而在交叉注意力设置中，视觉语言模型特征作为注意力中的键和值 $\mathbf{v}_{\theta}$ 。如表 6 所示，交叉注意力显著优于自注意力。交错使用两者取得了最佳结果，突显了它们的互补优势。

Attention mechanism	Success Rate (%) – LIBERO				
	S	O	G	10	Avg
CA	87	92	83	54	79.0
SA	80	94	84	40	74.5
CA+SA (ours)	86	99	90	67	85.5

Table 6 | Cross vs self-attention. Interleaved cross (CA) and self-attention (SA) yield the best results.

N	Success Rate (%) – LIBERO				
	S	O	G	10	Avg
8	77	88	86	49	75.0
16	88	91	91	44	78.5
24	86	97	86	49	79.5
32	89	94	85	53	80.3
Skip %2	84	90	83	45	75.5
VLM-256M	86	83	75	59	75.8

表 8 | 跳过视觉语言模型层。从大型视觉语言模型（此处为 5 亿参数）中跳过层比缩小视觉语言模型规模效果更好。每隔一层跳过一次是一个有竞争力的基线。

Attention mask	Success Rate (%) – LIBERO				
	S	O	G	10	Avg
Bidir	79	86	82	23	67.5
因果	80	94	84	40	74.5

表 7 | 双向注意力与因果注意力。防止未来动作泄漏可提升性能。

专家宽度 成功率 (%) — LIBERO (相对于视觉语言模型) S O G 10 平均					
×1.00	87	96	90	56	82.3
×0.75	82	89	84	55	77.5
×0.50	89	94	85	53	80.3
×0.25	76	97	83	39	73.8

表 9 | 专家容量。调整专家的隐藏层大小会影响性能。更大的容量带来更高的成功率。

动作标记上的因果注意力与双向注意力 $\mathbf{v}_\theta$. 接下来，我们研究动作标记在动作专家内部应如何相互关注， $\mathbf{v}_\theta$ 。我们比较：(i) 动作标记之间无交互（纯交叉注意力），(ii) 因果自注意力，以及 (iii) 双向自注意力。表 7 显示因果自注意力表现最佳，而双向交互会损害性能。令人惊讶的是，无交互（仅交叉注意力）的设置表现具有竞争力，这表明仅依赖视觉语言模型特征的条件作用可能已经足够强大。

在视觉语言模型中使用早期大语言模型层。视觉语言模型主干由视觉编码器和后续的大语言模型组成。为提高 SmolVLA 的效率，我们研究了仅使用前 $N < L$ 层的特征，而非所有可用的 L 个大语言模型层或特征（Black 等人，2024）。在开始训练之前，我们丢弃视觉语言模型顶部的 $L - N$ 层。如表 8 所示，仅使用视觉语言模型的前半部分层在性能和计算量之间取得了良好的平衡。此外，我们还测试了一种每隔一层采样视觉语言模型层的变体（跳过 2%，Shukor 和 Cord，2024），在保留完整模型容量的同时将深度减半。表 8 表明，每隔一层跳过的性能优于训练较小的视觉语言模型，但不如直接使用前 $N < L$ 层。

动作专家容量。出于效率方面的考虑，我们研究了改变动作专家的隐藏维度，以探索模型容量对性能的影响。给定视觉语言模型维度 d ，表 9 显示将专家的隐藏大小减小到 $0.75 \times d$ 可在性能和效率之间取得良好平衡。

回归与流匹配训练目标。我们比较了训练动作专家 $\mathbf{v}_\theta$ 的两种学习目标：流匹配（默认设置）和预测动作块与真实动作块之间的标准回归 L1 损失。与 Black 等人（2024）和 Chi 等人（2024）一致，表 10 显示流匹配显著优于回归，表明流匹配为建模复杂的多模态动作分布提供了更好的归纳偏置。

状态输入到视觉语言模型还是动作专家？我们比较了两种变体：(i) 将感觉运动状态输入到视觉语言模型（通过将其投影到令牌空间），以及 (ii) 将其直接传递给动作专家。表 11 表明，在视觉语言模型中包含状态信息可显著提升 CA 和 SA 两种变体的性能。

Training objective	Success Rate (%) – LIBERO				
	S	O	G	10	Avg
Flow matching	89	94	85	53	80.25
Regression	92	85	86	38	75.25

Table 10 | Training objective. We compare our training objective based on Flow matching to regression with L1 loss.

Chunk Size	Success Rate (%) – LIBERO				
	S	O	G	10	Avg
1	45	77	54	24	50.0
10	90	94	94	58	84.0
30	85	94	87	48	78.5
50	89	94	85	53	80.3
100	83	88	85	42	74.5

表 12 | 动作块大小。块大小在 10 到 50 之间可在动作预测频率与性能之间取得良好平衡。

动作块大小, n . 本文模型预测动作块, 每个块由 n 个时间步组成。本文研究改变 n 对整体性能的影响。较大的 n 使机器人在推理时能够执行更多动作, 而无需处理新观测并预测下一个块。然而, 表 12 显示, n 过小或过大都会降低性能。本文发现, 块大小在 10 到 50 之间可在机器人反应性与效率之间取得良好平衡。

更新观测前执行的动作数量。为提升真实世界部署中的推理速度, 机器人可在处理新观测之前执行预测块中的多个动作, 从而在当前块耗尽前将其覆盖。然而, 尽管执行整个块可加快推理速度, 但也会降低机器人对环境变化的响应能力。表 13 表明, 更频繁地更新观测可显著提高成功率, 凸显了推理速度与控制精度之间的权衡。

5 讨论

我们提出了一种紧凑、高效且轻量级的视觉-语言-动作模型——SmolVLA, 该模型可在消费级硬件上运行, 控制低成本机器人, 并与规模大得多的视觉-语言-动作模型相媲美。SmolVLA 的架构旨在实现高效的训练和推理, 同时不牺牲成功率。此外, 我们提出了一种异步推理栈, 能够在现实世界的操作任务中实现更快的适应和响应能力。该推理策略与模型无关, 可集成到任何输出动作块的策略中。我们的工作得到了对所提出架构的全面消融和分析的支持, 这些分析可以指导从业者和研究人员进一步改进模型架构。最后, 我们开源了模型、代码库、训练数据集、机器人硬件, 并提供了详细说明, 以促进完全可复现性。

5.1 局限性

我们指出了我们贡献中仍然存在的几个局限性。具体而言:

- **数据集多样性和跨具身训练**。我们的预训练目前使用从单一机器人类型 (SO100) 收集的数据集。尽管我们证明了该模型可以微调到不同的机器人 (表 4), 并且

States	Attention	Success Rate (%) – LIBERO				
		S	O	G	10	Avg
Prefix	CA	89	94	85	53	80.3
Suffix	CA	86	82	78	47	73.3
Prefix	SA	62	74	57	20	53.3
Suffix	SA	80	92	80	47	74.8

Table 11 | States as prefix vs. suffix. Feeding states to the VLM (prefix) leads to better performance than feeding them to the expert (suffix).

Action Steps	Success Rate (%) – LIBERO				
	S	O	G	10	Avg
1	89	94	85	53	80.3
10	89	94	91	57	82.8
30	76	91	74	42	70.8
50	54	70	58	25	51.8

表 13 | 动作执行步数。更频繁地采样新观测 (例如每 1 步或 10 步) 可显著提升性能。

优于现有基线，但我们认为，纳入来自多种机器人具身的训练数据可能对增强模型泛化到新机器人平台的能力至关重要。

- **数据集规模和可扩展性。**用于训练的数据集包含约 23k 条轨迹，显著小于典型视觉-语言-动作模型训练中使用的数据集——例如，OpenVLA 使用了约 100 万条轨迹。扩大数据集规模可以显著提高模型的性能及其在更广泛任务和环境中的泛化能力。

- **模型规模和硬件效率。**SmolVLA 拥有不到 5 亿参数，可在消费级硬件上实现快速推理。尽管这种效率优势显著，但探索如何在保持速度与可及性的前提下进一步扩展这些架构，是未来研究的重要方向。

- **视觉语言模型骨干的选择。**我们依赖一个现成的视觉语言模型骨干，该骨干主要在文档阅读和光学字符识别任务上进行了预训练（Marafioti 等，2025）。然而，这些视觉语言模型是否最适合真实世界的机器人交互场景，目前尚不明确。未来工作可以探索替代性或更专门的预训练策略，以更好地使视觉语言模型骨干适应机器人环境的特殊需求。

- **多模态与机器人数据联合训练。**将机器人特定数据与更广泛的多模态数据集进行共享训练，具有提升泛化能力和指令遵循能力的潜力。这种联合训练有望带来更稳健、适应性更强的视觉语言动作模型。

- **任务复杂度与更长时域。**尽管 SmolVLA 在相对简单和短时域任务上表现优异，但将该方法扩展到解决更长时域问题仍是一项重要挑战。引入分层策略或多级规划机制可能有助于应对这一复杂度。

- **学习范式：模仿学习与强化学习。**我们目前的方法主要依赖于模仿学习。然而，探索用于视觉语言动作模型（VLA）的强化学习技术（Chen et al., 2025）——尤其是处理复杂或长程任务——可能带来显著的性能提升和更灵活的策略适应。

6 致谢

作者感谢 Marina Barannikov、Alexandre Chapin、Ville Kuosmanen 和 Jade Choghari 在社区和模拟数据集方面的帮助。作者感谢 Alexander Soare 在异步推理方面的早期工作。作者感谢 Quentin Gallouedec、Pablo Montalvo-Leroux 以及 Hugging Face 团队其他成员在本项目期间的支持。本工作部分得到了 IDRIS 的高性能计算资源支持，该资源由 GENCI 和 PostGenAI@Paris 集群（ANR-23-IACL-0007，FRANCE 2030）在分配编号 2025-[A0181016235] 下提供。

参考文献

- Josh Achiam, Steven Adler, Sandhini Agarwal, Lama Ahmad, Ilge Akkaya, Florencia Leoni Aleman, Diogo Almeida, Janko Altenschmidt, Sam Altman, Shyamal Anadkat, et al. Gpt-4 technical report. *arXiv preprint arXiv:2303.08774*, 2023.
- AI@Meta. Llama 3.2 model card, 2024. https://github.com/meta-llama/llama-models/blob/main/models/llama3_2/MODEL_CARD.md.
- Jean-Baptiste Alayrac, Jeff Donahue, Pauline Luc, Antoine Miech, Iain Barr, Yana Hasson, Karel Lenc, Arthur Mensch, Katherine Millican, Malcolm Reynolds, et al. Flamingo: a visual language model for few-shot learning. *Advances in neural information processing systems*, 35:23716–23736, 2022.
- Loubna Ben Allal, Anton Lozhkov, Elie Bakouch, Gabriel Martín Blázquez, Guilherme Penedo, Lewis Tunstall, Andrés Marafioti, Hynek Kydlíček, Agustín Piqueres Lajarín, Vaibhav Srivastav, et al. Smollm2: When smol goes big—data-centric training of a small language model. *arXiv preprint arXiv:2502.02737*, 2025.
- Shuai Bai, Keqin Chen, Xuejing Liu, Jialin Wang, Wenbin Ge, Sibao Song, Kai Dang, Peng Wang, Shijie Wang, Jun Tang, Humen Zhong, Yuanzhi Zhu, Mingkun Yang, Zhaohai Li, Jianqiang Wan, Pengfei Wang, Wei Ding, Zheren Fu, Yiheng Xu, Jiabo Ye, Xi Zhang, Tianbao Xie, Zesen Cheng, Hang Zhang, Zhibo Yang, Haiyang Xu, and Junyang Lin. Qwen2.5-vl technical report, 2025. <https://arxiv.org/abs/2502.13923>.
- Rohan Bavishi, Erich Elsen, Curtis Hawthorne, Maxwell Nye, Augustus Odena, Arushi Somani, and Sağnak Taşlılar. Introducing our multimodal models, 2023. <https://www.adept.ai/blog/fuyu-8b>.
- Lucas Beyer, Andreas Steiner, André Susano Pinto, Alexander Kolesnikov, Xiao Wang, Daniel Salz, Maxim Neumann, Ibrahim Alabdulmohsin, Michael Tschannen, Emanuele Bugliarello, et al. Paligemma: A versatile 3b vlm for transfer. *arXiv preprint arXiv:2407.07726*, 2024.

- Johan Bjorck, Fernando Castañeda, Nikita Cherniadev, Xingye Da, Runyu Ding, Linxi Fan, Yu Fang, Dieter Fox, Fengyuan Hu, Spencer Huang, et al. Gr00t n1: An open foundation model for generalist humanoid robots. *arXiv preprint arXiv:2503.14734*, 2025.
- Kevin Black, Noah Brown, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Lachy Groom, Karol Hausman, Brian Ichter, et al. $\pi 0$: A vision-language-action flow model for general robot control. *arXiv preprint arXiv:2503.24164*, 2024.
- Daniel Bolya, Po-Yao Huang, Peize Sun, Jang Hyun Cho, Andrea Madotto, Chen Wei, Tengyu Ma, Jiale Zhi, Jathushan Rajasegaran, Hanoona Rasheed, et al. Perception encoder: The best visual embeddings are not at the output of the network. *arXiv preprint arXiv:2504.13181*, 2025.
- Zalán Borsos, Raphaël Marinier, Damien Vincent, Eugene Kharitonov, Olivier Pietquin, Matt Sharifi, Dominik Roblek, Olivier Teboul, David Grangier, Marco Tagliasacchi, et al. Audioldm: a language modeling approach to audio generation. *IEEE/ACM transactions on audio, speech, and language processing*, 31:2523–2533, 2023.
- Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Xi Chen, Krzysztof Choromanski, Tianli Ding, Danny Driess, Avinava Dubey, Chelsea Finn, et al. Rt-2: Vision-language-action models transfer web knowledge to robotic control. *arXiv preprint arXiv:2307.15818*, 2023.
- Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel Ziegler, Jeffrey Wu, Clemens Winter, Chris Hesse, Mark Chen, Eric Sigler, Mateusz Litwin, Scott Gray, Benjamin Chess, Jack Clark, Christopher Berner, Sam McCandlish, Alec Radford, Ilya Sutskever, and Dario Amodei. Language models are few-shot learners. In H. Larochelle, M. Ranzato, R. Hadsell, M.F. Balcan, and H. Lin, editors, *Advances in Neural Information Processing Systems*, volume 33, pages 1877–1901. Curran Associates, Inc., 2020. https://proceedings.neurips.cc/paper_files/paper/2020/file/1457c0d6bfc4967418bfb8ac142f64a-Paper.pdf.
- Minwoo Byeon, Beomhee Park, Haecheon Kim, Sungjun Lee, Woonhyuk Baek, and Saehoon Kim. Coyo-700m: Image-text pair dataset. <https://github.com/kakaobrain/coyo-dataset>, 2022.
- Remi Cadene, Simon Alibert, Alexander Soare, Quentin Gallouedec, Adil Zouitine, Steven Palma, Pepijn Kooijmans, Michel Aractingi, Mustafa Shukor, Dana Aubakirova, Martino Russi, Francesco Capuano, Caroline Pascale, Jade Choghari, Jess Moss, and Thomas Wolf. Lerobot: State-of-the-art machine learning for real-world robotics in pytorch. <https://github.com/huggingface/lerobot>, 2024.
- Xi Chen, Xiao Wang, Soravit Changpinyo, AJ Piergiovanni, Piotr Padlewski, Daniel Salz, Sebastian Goodman, Adam Grycner, Basil Mustafa, Lucas Beyer, et al. Pali: A jointly-scaled multilingual language-image model. *arXiv preprint arXiv:2209.06794*, 2022.
- Xi Chen, Xiao Wang, Lucas Beyer, Alexander Kolesnikov, Jialin Wu, Paul Voigtlaender, Basil Mustafa, Sebastian Goodman, Ibrahim Alabdulmohsin, Piotr Padlewski, et al. Pali-3 vision language models: Smaller, faster, stronger. *arXiv preprint arXiv:2310.09199*, 2023.
- Yuhui Chen, Shuai Tian, Shugao Liu, Yingting Zhou, Haoran Li, and Dongbin Zhao. Conrft: A reinforced fine-tuning method for vlm models via consistency policy. *arXiv preprint arXiv:2502.05450*, 2025.
- Zhe Chen, Weiyun Wang, Yue Cao, Yangzhou Liu, Zhangwei Gao, Erfei Cui, Jinguo Zhu, Shenglong Ye, Hao Tian, Zhaoyang Liu, et al. Expanding performance boundaries of open-source multimodal models with model, data, and test-time scaling. *arXiv preprint arXiv:2412.05271*, 2024.
- Cheng Chi, Zhenjia Xu, Siyuan Feng, Eric Cousineau, Yilun Du, Benjamin Burchfiel, Russ Tedrake, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. *The International Journal of Robotics Research*, page 02783649241273668, 2023.
- Cheng Chi, Zhenjia Xu, Siyuan Feng, Eric Cousineau, Yilun Du, Benjamin Burchfiel, Russ Tedrake, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. *The International Journal of Robotics Research*, 2024.
- Wenliang Dai, Junnan Li, Dongxu Li, Anthony Tiong, Junqi Zhao, Weisheng Wang, Boyang Li, Pascale Fung, and Steven Hoi. InstructBLIP: Towards general-purpose vision-language models with instruction tuning. In *Thirty-seventh Conference on Neural Information Processing Systems*, 2023. <https://openreview.net/forum?id=vvoWPYqZJA>.
- Nilaksh Das, Saket Dingliwal, Srikanth Ronanki, Rohit Paturi, Zhaocheng Huang, Prashant Mathur, Jie Yuan, Dhanush Bekal, Xing Niu, Sai Muralidhar Jayanthi, et al. Speechverse: A large-scale generalizable audio language model. *arXiv preprint arXiv:2405.08295*, 2024.
- Alexandre Défossez, Laurent Mazaré, Manu Orsini, Amélie Royer, Patrick Pérez, Hervé Jégou, Edouard Grave, and Neil Zeghidour. Moshi: a speech-text foundation model for real-time dialogue. *arXiv preprint arXiv:2410.00037*, 2024.

- Haiwen Diao, Yufeng Cui, Xiaotong Li, Yueze Wang, Huchuan Lu, and Xinlong Wang. Unveiling encoder-free vision-language models. *arXiv preprint arXiv:2406.11832*, 2024.
- Haiwen Diao, Xiaotong Li, Yufeng Cui, Yueze Wang, Haoge Deng, Ting Pan, Wenxuan Wang, Huchuan Lu, and Xinlong Wang. Evv2: Improved baselines for encoder-free vision-language models. *arXiv preprint arXiv:2502.06788*, 2025.
- Abhimanyu Dubey, Abhinav Jauhri, Abhinav Pandey, Abhishek Kadian, Ahmad Al-Dahle, Aiesha Letman, Akhil Mathur, Alan Schelten, Amy Yang, Angela Fan, et al. The llama 3 herd of models. *arXiv preprint arXiv:2407.21783*, 2024.
- Frederik Ebert, Yanlai Yang, Karl Schmeckpeper, Bernadette Bucher, Georgios Georgakis, Kostas Daniilidis, Chelsea Finn, and Sergey Levine. Bridge data: Boosting generalization of robotic skills with cross-domain datasets. *arXiv preprint arXiv:2109.13396*, 2021.
- Alaaeldin El-Nouby, Michal Klein, Shuangfei Zhai, Miguel Angel Bautista, Alexander Toshev, Vaishaal Shankar, Joshua M Susskind, and Armand Joulin. Scalable pre-training of large autoregressive image models. *arXiv preprint arXiv:2401.08541*, 2024.
- Patrick Esser, Sumith Kulal, Andreas Blattmann, Rahim Entezari, Jonas Müller, Harry Saini, Yam Levi, Dominik Lorenz, Axel Sauer, Frederic Boesel, et al. Scaling rectified flow transformers for high-resolution image synthesis. In *Forty-first international conference on machine learning*, 2024.
- Enrico Fini, Mustafa Shukor, Xiujuan Li, Philipp Dufter, Michal Klein, David Haldimann, Sai Aitharaju, Victor Guilherme Turrissi da Costa, Louis Béthune, Zhe Gan, Alexander T Toshev, Marcin Eichner, Moin Nabi, Yinfei Yang, Joshua M. Susskind, and Alaaeldin El-Nouby. Multimodal autoregressive pre-training of large vision encoders, 2024.
- Sylvain Gugger, Lysandre Debut, Thomas Wolf, Philipp Schmid, Zachary Mueller, Sourab Mangrulkar, Marc Sun, and Benjamin Bossan. Accelerate: Training and inference at scale made simple, efficient and adaptable. <https://github.com/huggingface/accelerate>, 2022.
- Sami Haddadin, Sven Parusel, Lars Johannsmeier, Saskia Golz, et al. The franka emika robot: A reference platform for robotics research and education. *IEEE Robotics & Automation Magazine*, 29(2):2–20, 2022. doi: 10.1109/MRA.2021.3138382.
- Nicklas Hansen, Xiaolong Wang, and Hao Su. Temporal difference learning for model predictive control. In *ICML*, 2022.
- Jiangyong Huang, Silong Yong, Xiaojian Ma, Xiongkun Linghu, Puhao Li, Yan Wang, Qing Li, Song-Chun Zhu, Baoxiong Jia, and Siyuan Huang. An embodied generalist agent in 3d world. In *Proceedings of the 41st International Conference on Machine Learning*, pages 20413–20451, 2024.
- Shaohan Huang, Li Dong, Wenhui Wang, Yaru Hao, Saksham Singhal, Shuming Ma, Tengchao Lv, Lei Cui, Owais Khan Mohammed, Barun Patra, et al. Language is not all you need: Aligning perception with language models. *Advances in Neural Information Processing Systems*, 36:72096–72109, 2023.
- Albert Q Jiang, Alexandre Sablayrolles, Arthur Mensch, Chris Bamford, Devendra Singh Chaplot, Diego de las Casas, Florian Bressand, Gianna Lengyel, Guillaume Lample, Lucile Saulnier, et al. Mistral 7b. *arXiv preprint arXiv:2310.06825*, 2023.
- Alexander Khazatsky, Karl Pertsch, Suraj Nair, Ashwin Balakrishna, Sudeep Dasari, Siddharth Karamcheti, Soroush Nasiriany, Mohan Kumar Srirama, Lawrence Yunliang Chen, Kirsty Ellis, et al. Droid: A large-scale in-the-wild robot manipulation dataset. *arXiv preprint arXiv:2403.12945*, 2024.
- Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, Ted Xiao, Ashwin Balakrishna, Suraj Nair, Rafael Rafailov, Ethan P Foster, Pannag R Sanketi, Quan Vuong, et al. Openvla: An open-source vision-language-action model. In *8th Annual Conference on Robot Learning*, 2024.
- Rob Knight, Pepijn Kooijmans, Thomas Wolf, Simon Alibert, Michel Aractingi, Dana Aubakirova, Adil Zouitine, Russi Martino, Steven Palma, Caroline Pascal, and Remi Cadene. Standard Open SO-100 & SO-101 Arms. <https://github.com/TheRobotStudio/SO-ARM100>.
- Jing Yu Koh, Ruslan Salakhutdinov, and Daniel Fried. Grounding language models to images for multimodal inputs and outputs, 2023.
- Zhifeng Kong, Arushi Goel, Rohan Badlani, Wei Ping, Rafael Valle, and Bryan Catanzaro. Audio flamingo: A novel audio language model with few-shot learning and dialogue abilities. In *International Conference on Machine Learning*, pages 25125–25148. PMLR, 2024.
- Vik Korrapati. Moondream. Online, 2024. <https://moondream.ai/>. Accessed: 2025-03-27.
- Hugo Laurençon, Lucile Saulnier, Leo Tronchon, Stas Bekman, Amanpreet Singh, Anton Lozhkov, Thomas Wang, Siddharth Karamcheti, Alexander M Rush, Douwe Kiela, Matthieu Cord, and Victor Sanh. OBELICS: An open web-scale filtered dataset of interleaved image-text documents. In *Thirty-seventh Conference on Neural Information Processing Systems Datasets and Benchmarks Track*, 2023. <https://openreview.net/forum?id=SKN2hf1BIZ>.

- Hugo Laurençon, Léo Tronchon, Matthieu Cord, and Victor Sanh. What matters when building vision-language models? *arXiv preprint arXiv:2405.02246*, 2024.
- Seungjae Lee, Yibin Wang, Haritheja Etukuru, H Jin Kim, Nur Muhammad Mahi Shafiullah, and Lerrel Pinto. Behavior generation with latent actions. *arXiv preprint arXiv:2403.03181*, 2024.
- Junnan Li, Dongxu Li, Silvio Savarese, and Steven Hoi. Blip-2: bootstrapping language-image pre-training with frozen image encoders and large language models. In *Proceedings of the 40th International Conference on Machine Learning*, ICML’23. JMLR.org, 2023.
- Xinghang Li, Minghuan Liu, Hanbo Zhang, Cunjun Yu, Jie Xu, Hongtao Wu, Chilam Cheang, Ya Jing, Weinan Zhang, Huaping Liu, et al. Vision-language foundation models as effective robot imitators. In *ICLR*, 2024.
- Ji Lin, Hongxu Yin, Wei Ping, Yao Lu, Pavlo Molchanov, Andrew Tao, Huizi Mao, Jan Kautz, Mohammad Shoeybi, and Song Han. Vila: On pre-training for visual language models. *arXiv preprint arXiv:2312.07533*, 2023a.
- Xi Victoria Lin, Akshat Shrivastava, Liang Luo, Srinivasan Iyer, Mike Lewis, Gargi Ghosh, Luke Zettlemoyer, and Armen Aghajanyan. Moma: Efficient early-fusion pre-training with mixture of modality-aware experts. *arXiv preprint arXiv:2407.21770*, 2024.
- Ziyi Lin, Chris Liu, Renrui Zhang, Peng Gao, Longtian Qiu, Han Xiao, Han Qiu, Chen Lin, Wenqi Shao, Keqin Chen, et al. Sphinx: The joint mixing of weights, tasks, and visual embeddings for multi-modal large language models. *arXiv preprint arXiv:2311.07575*, 2023b.
- Yaron Lipman, Ricky TQ Chen, Heli Ben-Hamu, Maximilian Nickel, and Matt Le. Flow matching for generative modeling. *arXiv preprint arXiv:2210.02747*, 2022.
- Bo Liu, Yifeng Zhu, Chongkai Gao, Yihao Feng, Qiang Liu, Yuke Zhu, and Peter Stone. Libero: Benchmarking knowledge transfer for lifelong robot learning. *Advances in Neural Information Processing Systems*, 36:44776–44791, 2023a.
- Haotian Liu, Chunyuan Li, Yuheng Li, and Yong Jae Lee. Improved baselines with visual instruction tuning. In *NeurIPS 2023 Workshop on Instruction Tuning and Instruction Following*, 2023b. <https://openreview.net/forum?id=yx3Hkx5ved>.
- Jiajun Liu, Yibing Wang, Hanghang Ma, Xiaoping Wu, Xiaoqi Ma, Xiaoming Wei, Jianbin Jiao, Enhua Wu, and Jie Hu. Kangaroo: A powerful video-language model supporting long-context video input. *arXiv preprint arXiv:2408.15542*, 2024.
- Qiang Liu. Rectified flow: A marginal preserving approach to optimal transport. *arXiv preprint arXiv:2209.14577*, 2022.
- Oscar Mañas, Pau Rodriguez Lopez, Saba Ahmadi, Aida Nematzadeh, Yash Goyal, and Aishwarya Agrawal. MAPL: Parameter-efficient adaptation of unimodal pre-trained models for vision-language few-shot prompting. In Andreas Vlachos and Isabelle Augenstein, editors, *Proceedings of the 17th Conference of the European Chapter of the Association for Computational Linguistics*, pages 2523–2548, Dubrovnik, Croatia, May 2023. Association for Computational Linguistics. doi: 10.18653/v1/2023.eacl-main.185. <https://aclanthology.org/2023.eacl-main.185>.
- Andrés Marafioti, Orr Zohar, Miquel Farré, Merve Noyan, Elie Bakouch, Pedro Cuenca, Cyril Zakka, Loubna Ben Allal, Anton Lozhkov, Nouamane Tazi, et al. Smolvlm: Redefining small and efficient multimodal models. *arXiv preprint arXiv:2504.05299*, 2025.
- Abby O’Neill, Abdul Rehman, Abhiram Maddukuri, Abhishek Gupta, Abhishek Padalkar, Abraham Lee, Acorn Pooley, Agrim Gupta, Ajay Mandekar, Ajinkya Jain, et al. Open x-embodiment: Robotic learning datasets and rt-x models: Open x-embodiment collaboration 0. In *2024 IEEE International Conference on Robotics and Automation (ICRA)*, pages 6892–6903. IEEE, 2024.
- A Paszke. Pytorch: An imperative style, high-performance deep learning library. *arXiv preprint arXiv:1912.01703*, 2019.
- Karl Pertsch, Kyle Stachowicz, Brian Ichter, Danny Driess, Suraj Nair, Quan Vuong, Oier Mees, Chelsea Finn, and Sergey Levine. Fast: Efficient action tokenization for vision-language-action models. *arXiv preprint arXiv:2501.09747*, 2025.
- Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, et al. Learning transferable visual models from natural language supervision. In *International conference on machine learning*, pages 8748–8763. PMLR, 2021.
- Jathushan Rajasegaran, Ilija Radosavovic, Rahul Ravishankar, Yossi Gandelsman, Christoph Feichtenhofer, and Jitendra Malik. An empirical study of autoregressive pre-training from videos. *arXiv preprint arXiv:2501.05453*, 2025.
- C Schuhmann, A Köpf, R Vencu, T Coombes, and R Beaumont. Laion coco: 600m synthetic captions from laion2b-en. *URL https://laion.ai/blog/laion-coco*, 2022.
- Younggyo Seo, Danijar Hafner, Hao Liu, Fangchen Liu, Stephen James, Kimin Lee, and Pieter Abbeel. Masked world models for visual control. In *Conference on Robot Learning*, pages 1332–1344. PMLR, 2023.
- Mustafa Shukor and Matthieu Cord. Skipping computations in multimodal llms. *arXiv preprint arXiv:2410.09454*, 2024.

- Mustafa Shukor, Corentin Dancette, and Matthieu Cord. ep-alm: Efficient perceptual augmentation of language models. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 22056–22069, 2023a.
- Mustafa Shukor, Corentin Dancette, Alexandre Rame, and Matthieu Cord. Unival: Unified model for image, video, audio and language tasks. *Transactions on Machine Learning Research Journal*, 2023b.
- Mustafa Shukor, Enrico Fini, Victor Guilherme Turrissi da Costa, Matthieu Cord, Joshua Susskind, and Alaaeldin El-Nouby. Scaling laws for native multimodal models. *arXiv preprint arXiv:2504.07951*, 2025.
- Kihyuk Sohn, Honglak Lee, and Xinchen Yan. Learning structured output representation using deep conditional generative models. In C. Cortes, N. Lawrence, D. Lee, M. Sugiyama, and R. Garnett, editors, *Advances in Neural Information Processing Systems*, volume 28. Curran Associates, Inc., 2015. https://proceedings.neurips.cc/paper_files/paper/2015/file/8d55a249e6baa5c06772297520da2051-Paper.pdf.
- Shengkun Tang, Yaqing Wang, Zhenglun Kong, Tianchi Zhang, Yao Li, Caiwen Ding, Yanzhi Wang, Yi Liang, and Dongkuan Xu. You need multiple exiting: Dynamic early exiting for accelerating unified vision language model. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 10781–10791, 2023.
- Chameleon Team. Chameleon: Mixed-modal early-fusion foundation models. *arXiv preprint arXiv:2405.09818*, 2024.
- Gemini Team, Rohan Anil, Sebastian Borgeaud, Yonghui Wu, Jean-Baptiste Alayrac, Jiahui Yu, Radu Soricut, Johan Schalkwyk, Andrew M Dai, Anja Hauth, et al. Gemini: a family of highly capable multimodal models. *arXiv preprint arXiv:2312.11805*, 2023.
- Octo Model Team, Dibya Ghosh, Homer Walke, Karl Pertsch, Kevin Black, Oier Mees, Sudeep Dasari, Joey Hejna, Tobias Kreiman, Charles Xu, et al. Octo: An open-source generalist robot policy. *arXiv preprint arXiv:2405.12213*, 2024.
- Peter Tong, Ellis Brown, Penghao Wu, Sanghyun Woo, Adithya Jairam Vedagiri IYER, Sai Charitha Akula, Shusheng Yang, Jihan Yang, Manoj Middepogu, Ziteng Wang, et al. Cambrian-1: A fully open, vision-centric exploration of multimodal llms. *Advances in Neural Information Processing Systems*, 37:87310–87356, 2024.
- Maria Tsimpoukelli, Jacob L Menick, Serkan Cabi, SM Eslami, Oriol Vinyals, and Felix Hill. Multimodal few-shot learning with frozen language models. *Advances in Neural Information Processing Systems*, 34:200–212, 2021.
- Th  ophane Valla  ys, Mustafa Shukor, Matthieu Cord, and Jakob Verbeek. Improved baselines for data-efficient perceptual augmentation of llms. *arXiv preprint arXiv:2403.13499*, 2024.
- A Vaswani. Attention is all you need. *Advances in Neural Information Processing Systems*, 2017.
- Peng Wang, An Yang, Rui Men, Junyang Lin, Shuai Bai, Zhikang Li, Jianxin Ma, Chang Zhou, Jingren Zhou, and Hongxia Yang. Ofa: Unifying architectures, tasks, and modalities through a simple sequence-to-sequence learning framework. In *International conference on machine learning*, pages 23318–23340. PMLR, 2022.
- Peng Wang, Shuai Bai, Sinan Tan, Shijie Wang, Zhihao Fan, Jinze Bai, Keqin Chen, Xuejing Liu, Jialin Wang, Wenbin Ge, et al. Qwen2-vl: Enhancing vision-language model’s perception of the world at any resolution. *arXiv preprint arXiv:2409.12191*, 2024.
- Yi Wang, Xinhao Li, Ziang Yan, Yinan He, Jiashuo Yu, Xiangyu Zeng, Chenting Wang, Changlian Ma, Haian Huang, Jianfei Gao, et al. Internvideo2. 5: Empowering video mllms with long and rich context modeling. *arXiv preprint arXiv:2501.12386*, 2025.
- Junjie Wen, Yichen Zhu, Jinming Li, Minjie Zhu, Kun Wu, Zhiyuan Xu, Ning Liu, Ran Cheng, Chaomin Shen, Yaxin Peng, et al. Tinyvla: Towards fast, data-efficient vision-language-action models for robotic manipulation. *arXiv preprint arXiv:2409.12514*, 2024.
- Junjie Wen, Yichen Zhu, Jinming Li, Zhibin Tang, Chaomin Shen, and Feifei Feng. Dexvla: Vision-language model with plug-in diffusion expert for general robot control. *arXiv preprint arXiv:2502.05855*, 2025.
- Annie Xie, Lisa Lee, Ted Xiao, and Chelsea Finn. Decomposing the generalization gap in imitation learning for visual robotic manipulation. In *2024 IEEE International Conference on Robotics and Automation (ICRA)*, pages 3153–3160. IEEE, 2024.
- Yuan Yao, Tianyu Yu, Ao Zhang, Chongyi Wang, Junbo Cui, Hongji Zhu, Tianchi Cai, Haoyu Li, Weilin Zhao, Zhihui He, Qianyu Chen, Huarong Zhou, Zhensheng Zou, Haoye Zhang, Shengding Hu, Zhi Zheng, Jie Zhou, Jie Cai, Xu Han, Guoyang Zeng, Dahai Li, Zhiyuan Liu, and Maosong Sun. Minicpm-v: A gpt-4v level mllm on your phone, 2024. <https://arxiv.org/abs/2408.01800>.
- Tianhe Yu, Deirdre Quillen, Zhanpeng He, Ryan Julian, Karol Hausman, Chelsea Finn, and Sergey Levine. Meta-world: A benchmark and evaluation for multi-task and meta reinforcement learning. In *Conference on robot learning*, pages 1094–1100. PMLR, 2020.

- Xiaohua Zhai, Basil Mustafa, Alexander Kolesnikov, and Lucas Beyer. Sigmoid loss for language image pre-training. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 11975–11986, 2023.
- Boqiang Zhang, Kehan Li, Zesen Cheng, Zhiqiang Hu, Yuqian Yuan, Guanzheng Chen, Sicong Leng, Yuming Jiang, Hang Zhang, Xin Li, et al. Videollama 3: Frontier multimodal foundation models for image and video understanding. *arXiv preprint arXiv:2501.13106*, 2025.
- Tony Z Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware. *arXiv preprint arXiv:2304.13705*, 2023.
- Baichuan Zhou, Ying Hu, Xi Weng, Junlong Jia, Jie Luo, Xien Liu, Ji Wu, and Lei Huang. Tinyllava: A framework of small-scale large multimodal models. *arXiv preprint arXiv:2402.14289*, 2024.
- Deyao Zhu, Jun Chen, Xiaoqian Shen, Xiang Li, and Mohamed Elhoseiny. MiniGPT-4: Enhancing vision-language understanding with advanced large language models. In *The Twelfth International Conference on Learning Representations*, 2024. <https://openreview.net/forum?id=1tZbq88f27>.
- Wanrong Zhu, Jack Hessel, Anas Awadalla, Samir Yitzhak Gadre, Jesse Dodge, Alex Fang, Youngjae Yu, Ludwig Schmidt, William Yang Wang, and Yejin Choi. Multimodal c4: An open, billion-scale corpus of images interleaved with text. In *Thirty-seventh Conference on Neural Information Processing Systems Datasets and Benchmarks Track*, 2023. <https://openreview.net/forum?id=tOd8rSjcWz>.

A 附录

A.1 社区数据集

任务标注 对于任务标注，我们向视觉语言模型（VLM）给出以下提示：以下是当前任务描述：{current_task}。生成一个非常简短、清晰且完整的句子，描述机器人手臂执行的动作（最多 30 个字符）。不要包含不必要的词语。保持简洁。以下是一些示例：拿起立方体并将其放入盒子中，打开抽屉等。直接以动作动词开头，如“拿起”、“放置”、“打开”等。与提供的示例类似，机器人手臂执行的主要动作是什么？

数据集列表。

satvikahuja/mixer_on_off_new_1, aergogo/so100_pick_place, andy309/so100_0314_fold_cloths
 jchun/so100_pickplace_small_20250323_120056, astrotyat/cube, Ofiroz91/so_100_cube2bowl HappyPablo/dec3_data2,
 ZCM5115/so100_1210, francescocrivelli/orange_feeding francescocrivelli/carrot_eating, 0x00raghu/toffee_red, 0x00raghu/toffee_red_2
 0x00raghu/toffee_red_3_, 0x00raghu/toffee_blue, 0x00raghu/toffee_blue_2 0x00raghu/toffee_to_hand_1, 0x00raghu/toffee_to_hand_2,
 liytenga/so100_bi_hello liytenga/so100_bi_giveme5, ZCM5115/so100_2Arm3cameras_movebox, pranavsaroha/so100_carrot_1
 pranavsaroha/so100_carrot_3, pranavsaroha/so100_carrot_4, maximilienroberti/so100_lego_red_box pranavsaroha/so100_squishy,
 rabhishek100/so100_train_dataset, pranavsaroha/so100_squishy100 swarajgosavi/kikobot_pusht_real_v2, pandaRQ/pickmed,
 swarajgosavi/act_kikobot_pusht_real pranavsaroha/so100_squishy2colors, pranavsaroha/so100_squishy2colors_1,
 Chojins/chess_game_001_white jmrog/so100_sweet_pick, Chojins/chess_game_002_white, pranavsaroha/so100_squishy2colors_2_new
 Chojins/chess_game_003_white, aractingi/pick_place_lego_cube, Chojins/chess_game_004_white Chojins/chess_game_005_white,
 Chojins/chess_game_006_white, Chojins/chess_game_007_white koenvanwijk/blue2, jlitch/so100multicam3, koenvanwijk/blue52
 jlitch/so100multicam6, aractingi/pick_place_lego_cube_1, jlitch/so100multicam7 vladfatu/so100_ds, Chojins/chess_game_000_white,
 HITHY/so100-kiwi HITHY/so100_peach1, HITHY/so100_redstrawberry, satvikahuja/orange_mixer_1 satvikahuja/mixer_on_off,
 satvikahuja/orange_pick_place_new1, satvikahuja/mixer_on_off_new danmac1/real_real332, FeiYjf/Makalu_push,
 liytenga/so100_pick_taffy1 chmadran/so100_dataset04, FeiYjf/Maklu_dataset, FeiYjf/new_Dataset liytenga/so100_pick_taffy2,
 satvikahuja/mixer_on_off_new_4, CSCSXX/pick_place_cube_1.17 liytenga/so100_pick_taffy3, liytenga/so100_pick_taffy4,
 yuz1wan/so100_pick_pink yuz1wan/so100_pick_wahaha, yuz1wan/so100_pp_pink, yuz1wan/so100_pour_cup

liyitenga/so100_pick_taffy5, liyitenga/so100_pick_taffy6, yuz1wan/so100_button yuz1wan/so100_pickplace, liyitenga/so100_pick_taffy7, FeiYjf/push_gg FeiYjf/push_0094, swarajgosavi/act_kikobot_block_real, liyitenga/so100_pick_taffy8 phospho-ai/OrangeBrick3Cameras, vaishanthr/toy_pick_place, SeanLMH/so100_picknplace_v2 pepijn223/yellow_lego_in_box1, DimiSch/so100_50ep_2, DimiSch/so100_50ep_3 SeanLMH/so100_picknplace, nbaron99/so100_pick_and_place2, chmadran/so100_dataset08 vaishanthr/toy_pickplace_50ep, Beegbrain/pick_place_green_block_lr, Ityl/so100_recording1 vaishanthr/toy_pickplace, ad330/so100_box_pickPlace, Beegbrain/so100_put_cube_cup aractingi/push_green_cube_hf, aractingi/push_green_cube_hf_cropped_resized, carpit680/giraffe_task, carpit680/giraffe_sock_demo_1, DimiSch/so100_terra_50_2, carpit680/giraffe_sock_demo_2, aractingi/push_cube_to_face_reward aractingi/push_cube_to_face_reward_cropped_resized, aractingi/push_cube_reward_data aractingi/push_cube_reward_data_cropped_resized, aractingi/push_cube_offline_data_cropped_resized, aractingi/push_cube_front_side_reward, aractingi/push_cube_front_side_reward_cropped_resized, aractingi/push_cube_front_side_reward_long, aractingi/push_cube_front_side_reward_long_cropped_resized aractingi/push_cube_reward, aractingi/push_cube_reward_cropped_resized, aractingi/push_cube_square_reward_cropped_resized, aractingi/push_cube_square_reward_1, aractingi/push_cube_square_reward_1_cropped_resized, aractingi/push_cube_square_light_reward aractingi/push_cube_square_light_offline_demo aractingi/push_cube_square_light_offline_demo_cropped_resized denghj/dataset_red_tape01, aractingi/push_cube_square_offline_demo, aractingi/push_cube_square_offline_demo_cropped_resized, Beegbrain/stack_two_cubes, FeiYjf/Test_NNNN LegrandFrederic/Orange-brick-lower-resolution, aractingi/pick_place_lego_cube_cropped_resized aractingi/push_cube_overfit, aractingi/push_cube_overfit_cropped_resized, HITHY/so100_peach zaringleb/so100_cube_2, andreasBihlmaier/dual_arm_transfer_2025_02_16, zaringleb/so100_cube_4_binary 1g0rrr/reward_pickplace1, 1g0rrr/reward_pickplace1_cropped_resized, FeiYjf/Hold_Pieces FeiYjf/Grab_Pieces, hegdearyandev/so100_eraser_cup_v1, jbraumann/so100_1902 liyitenga/so100_pick_taffy10, mikechambers/block_cup_5, zaringleb/so100_cube_5_linear yuz1wan/so100_pickplace_0223_2, yuz1wan/so100_pickplace_0223_3, samsam0510/mj_data_temp samsam0510/tape_insert_1, samsam0510/tape_insert_2, pengjunkun/so100_push_to_hole Deason11/Random_Kitchen, 1g0rrr/reward_dataset_name2, 1g0rrr/reward_dataset_name2_cropped_resized 1g0rrr/offline_dataset_name2, 1g0rrr/offline_dataset_name2_cropped_resized aractingi/push_cube_simp_cropped_resized, danielkr452/so100_work6 Loki0929/so100_100, yuz1wan/so100_fold_0227_1 yuz1wan/so100_fold_0227_2, speedyoshi/so100_grasp_pink_block, lirislabs/stack_two_red_cubes lirislabs/red_cube_into_mug, lirislabs/green_lego_block_into_mug, lirislabs/green_lego_block_into_mug_easy kevin510/lerobot-cat-toy-placement, NONHUMAN-RESEARCH/SOARM100_TASK_VENDA_BOX, wangjl1512/pour_water airthebear/so100_GL, zijian2022/noticehuman1, zijian2022/noticehuman2 kantine/so100_kapla_tower6, zijian2022/noticehuman5, zijian2022/llm40 Ashton3/lerobot-aloha, zijian2022/noticehuman50, AaronNewman/screwdriver_task_batch1 AaronNewman/screwdriver_task_batch2, AaronNewman/screwdriver_task_batch3, zijian2022/noticehuman60 zijian2022/noticehuman70, Bartm3/tape_to_bin, liuhuanjim013/so100_th_1 Pi-robot/barbecue_flip, Pi-robot/barbecue_put, wangjl1512/doll sshh11/so100_orange_50ep_1, sshh11/so100_orange_50ep_2, DorayakiLin/so100_pick_cube_in_box Bartm3/tape_to_bin2, luke250305/play_dice_250311.1, andy309/so100_0311_1152 sihyun77/suho_so100, sihyun77/si_so100, shreyasgite/so100_base_left sihyun77/suho_red, liuhuanjim013/so100_block, andy309/so100_0313_no_wrist_camera zijian2022/19, zijian2022/n1_2, DorayakiLin/so100_stack_cube andy309/so100_0313_no_wrist_camera_with_two_arms_cloths, joaoocruz00/so100_makeitD1, zijian2022/110_1 zijian2022/110_5, sihyun77/suho_red2, sihyun77/suho_angel sihyun77/sihyun_king, acrampette/third_arm_01, Winster/so100_cube 1g0rrr/sam_openpi03, thedevansh/mar16_1336, hkphoooy/throw_stuffie doujiangwang/task1_10epi_100000step, sihyun77/sihyun_3_17_1, acrampette/third_arm_02 imsyed00/so100_yellowbowl_pickplace_1, kumarhans/so100_tape_task, sihyun77/sihyun_main doujiangwang/task2_10epi_100000step, kantine/industrial_robothon_buttons_expert kantine/industrial_robothon_buttons_anomaly, kantine/industrial_robothon_hatchAndProbe_expert kantine/industrial_robothon_hatchAndProbe_anomaly, Odog16/so100_tea_towel_folding_v1

zijian2022/so100_318, zijian2022/so100_318_1, Congying1112/so100_place_blue_bottle_with_two_cameras
 Congying1112/so100_place_blue_bottle_with_two_cameras2, Congying1112/so100_place_blue_bottle_with_single_camera,
 pietroom/first_task_short kantine/industrial_screws_sorting_expert, kantine/industrial_screws_sorting_anomaly, pietroom/second_task
 zijian2022/c0, doujiangwang/task4_10epi_100000step, Congying1112/so100_switch_with_onhand_camera HYAIYN/so100_get_orange_10epi,
 doujiangwang/task5_10epi_100000step, 1g0rrr/sam_openpi_cube_low10 1g0rrr/sam_openpi_cube_top10, 1g0rrr/sam_openpi_wire10,
 1g0rrr/sam_openpi_solder1 1g0rrr/sam_openpi_solder2, wcode/so100_put_pen_50, ichun/so100_pickplace_small_20250322_193929
 bnarin/so100_tic_tac_toe_we_do_it_live, dc2ac/so100-t5, chmadran/so100_home_dataset baladhurgesh97/so100_final_picking_3,
 bnarin/so100_tic_tac_toe_move_0_0 bnarin/so100_tic_tac_toe_move_1_0, bnarin/so100_tic_tac_toe_move_2_1
 bnarin/so100_tic_tac_toe_move_4_0, zaringleb/so100_cube_6_2d andlyu/so100_indoor_0, andlyu/so100_indoor_2, Winstner/so100_sim
 badwolf256/so100_twin_cam_duck, Congying1112/so100_simplepick_with_2_cameras_from_top, andlyu/so100_indoor_4,
 Zak-Y/so100_grap_dataset kantine/domotic_pouringCoffee_expert, kantine/domotic_pouringCoffee_anomaly
 lucasngoo/so100_strawberry_grape, kantine/domotic_makingCoffee_expert kantine/domotic_makingCoffee_anomaly, ZGGZZG/so100_drop1
 kantine/industrial_soldering_expert, kantine/industrial_soldering_anomaly Yotofu/so100_sweeper_shoes, kantine/domotic_dishTidyUp_expert
 kantine/domotic_dishTidyUp_anomaly, kantine/domotic_groceriesSorting_expert kantine/domotic_groceriesSorting_anomaly,
 badwolf256/so100_twin_cam_duck_v2 kantine/domotic_vegetablesAndFruitsSorting_expert
 kantine/domotic_vegetablesAndFruitsSorting_anomaly, kantine/domotic_setTheTable_expert kantine/domotic_setTheTable_anomaly,
 therarelab/so100_pick_place, abhisb/so100_51_ep andlyu/so100_indoor_val_0, lizi178119985/so100_jia, badwolf256/so100_twin_cam_duck_v3
 andrewcole712/so100_tape_bin_place, Gano007/so100_lolo, Zak-Y/so100_three_cameras_dataset Gano007/so100_doliprane,
 XXXRRSSRR/so100_v3_num_episodes_50, zijian2022/assemblyarm2 ganker5/so100_action_20250403, andlyu/so100_indoor_val2,
 Gano007/so100_gano paszea/so100_whale_grab, paszea/so100_whale, Clementppr/lerobot_pick_and_place_dataset_world_model
 andlyu/so100_indoor_10, RasmusP/so100_dataset50ep_a, RasmusP/so100_dataset50ep Gano007/so100_second,
 zaringleb/so100_cude_linear_and_2d_comb, dsfsg/grasp_pens zijian2022/digitalfix, zijian2022/digitalfix2, zijian2022/digitalfix3
 T1g3rGE/so100_pickplace_small_20250407_171912, sihyun77/mond_13 abokinala/sputnik_100_11_pick_place_container, dsfsg/bring_bottle
 abokinala/sputnik_100_12_pick_place_container, Mwuqiu/so100_0408 AK51/4090_01, 356c/so100_rope_reposition_1, paszea/so100_lego_mix
 abokinala/sputnik_100_14_pick_place_container, abokinala/sputnik_100_23_pick_place_surface, jiajun001/eraser00_2, jlesein/TestBoulon2
 duthvik/sputnik_100_31_pour_liquid, duthvik/sputnik_100_24_pick_place_surface duthvik/sputnik_100_25_pick_place_surface,
 duthvik/sputnik_100_17_pick_place_container duthvik/sputnik_100_26_pick_place_surface, VoicAndrei/so100_banana_to_plate_rebel_full
 isadev/bougies1, danaaubakirova/so100_task_1 danaaubakirova/so100_task_2, danaaubakirova/so100_task_3, danaaubakirova/so100_task_4
 sixpigs1/so100_pick_cube_in_box_error, sixpigs1/so100_push_cube_error, sixpigs1/so100_pull_cube_error isadev/bougies2,
 therarelab/med_dis_rare_6, duthvik/sputnik_100_27_pick_place_surface zijian2022/closer3, duthvik/sputnik_100_41_custom_tasks,
 duthvik/sputnik_100_42_custom_tasks duthvik/sputnik_100_43_custom_tasks, duthvik/sputnik_100_44_custom_tasks,
 duthvik/sputnik_100_51_kitchen_tasks, duthvik/sputnik_100_52_kitchen_tasks duthvik/sputnik_100_53_kitchen_tasks,
 duthvik/sputnik_100_45_custom_tasks duthvik/sputnik_100_32_pour_liquid, duthvik/sputnik_100_29_pick_place_surface
 duthvik/sputnik_100_18_pick_place_container sixpigs1/so100_pull_cube_by_tool_error, sixpigs1/so100_insert_cylinder_error
 abokinala/sputnik_100_54_kitchen_tasks, abokinala/sputnik_100_55_kitchen_tasks, m1b/so100_bluelego
 abokinala/sputnik_100_46_custom_tasks m1b/so100_bluelego_updt, kantine/flip_A0, kantine/flip_A1

kantine/flip_A2, kantine/flip_A3, lirislabs/guess_who_no_cond kantine/flip_A4, kantine/flip_A5, lirislabs/guess_who_lighting
 nguyen-v/so100_press_red_button, nguyen-v/so100_bimanual_grab_lemon_put_in_box2, pierfabre/cow
 nguyen-v/press_red_button_new, nguyen-v/so100_rotate_red_button, Cidoyi/so100_all_notes roboticshack/team10-red-block,
 Cidoyi/so100_all_notes_1, roboticshack/team_5-QuiEstCe_everyBox roboticshack/team11_pianobot,
 roboticshack/team2-guess_who_so100 roboticshack/team2-guess_who_so100_light, roboticshack/team2-guess_who_so100_edge_case
 roboticshack/team2-guess_who_less_ligth, Cidoyi/so100_all_notes_3 dsfsg/grasp_pen_and_bottle,
 abokinala/sputnik_100_60_kitchen_tasks abokinala/sputnik_100_58_kitchen_tasks, danaaubakirova/so100_v2_task_1
 danaaubakirova/so100_v2_task_2, danaaubakirova/so100_v2_task_3 danaaubakirova/so100_v2_task_4, zijian2022/force1,
 zijian2022/force2 zijian2022/force3, jiajun001/eraser00_3, zijian2022/bi2 zijian2022/bi1, zijian2022/hand1, Setchii/so100_grab_ball
 MossProphet/so100_square-1-2-3.2, pierfabre/rabbit bensprenger/right_arm_p_brick_in_box_with_y_noise_v0 pierfabre/horse,
 pierfabre/pig2, pierfabre/pig3 pierfabre/cow2, pierfabre/sheep, Chojins/chess_game_009_white sihyun77/suho_3_17_1,
 sihyun77/sihyun_3_17_2, sihyun77/suho_3_17_3 sihyun77/sihyun_3_17_5, Odog16/so100_cube_drop_pick_v1,
 sihyun77/sihyun_main_2 sihyun77/suho_main_2, Bartm3/dice2, sihyun77/sihyun_main_3 Loki0929/so100_duck, pietroom/holdthis,
 pietroom/actualeasytask Beegbrain/pick_lemon_and_drop_in_bowl, Beegbrain/sweep_tissue_cube, zijian2022/321
 gxy1111/so100_pick_place, Odog16/so100_cube_stacking_v1, sihyun77/mond_1 andlyu/so100_indoor_1, andlyu/so100_indoor_3,
 frk2/so100large lirislabs/sweep_tissue_cube, lirislabs/lemon_into_bowl, lirislabs/red_cube_into_green_lego_block
 lirislabs/red_cube_into_blue_cube, 00ri/so100_battery, frk2/so100largediffcam FsQZ/so100_1, ZGGZZG/so100_drop0,
 Chojins/chess_game_000_white_red smanni/train_so100_fluffy_box, ganker5/so100_push_20250328, ganker5/so100_dateline_0328
 ganker5/so100_color_0328, CrazyYhang/A1234-B-C_mvA2B, RasmusP/so100_Orange2Green sixpigs1/so100_pick_cube_in_box,
 ganker5/so100_push_20250331, ganker5/so100_dateline_20250331 lirislabs/put_caps_into_teabox, lirislabs/close_top_drawer_teabox,
 lirislabs/open_top_drawer_teabox lirislabs/unfold_bottom_right, lirislabs/push_cup_target, lirislabs/put_banana_bowl
 Chojins/chess_game_001_blue_stereo, Chojins/chess_game_001_red_stereo, ganker5/so100_toy_20250402 Gano007/so100_medic,
 00ri/so100_battery_bin_center, paszea/so100_whale_2 lirislabs/fold_bottom_right, lirislabs/put_coffee_cap_teabox,
 therarelab/so100_pick_place_2 paszea/so100_whale_3, paszea/so100_whale_4, paszea/so100_lego LemonadeDai/so100_coca,
 zijian2022/backgrounda, zijian2022/backgroundb 356c/so100_nut_sort_1, Mwuqiu/so100_0408_muti, aimihat/so100_tape
 lirislabs/so100_demo, 356c/so100_duck_reposition_1, zijian2022/sort1 weiye11/so100_410_zwy,
 VoicAndrei/so100_banana_to_plate_only, sixpigs1/so100_stack_cube_error isadev/bougies3, zijian2022/close3,
 bensprenger/left_arm_yellow_brick_in_box_v0 lirislabs/guess_who_so100,
 bensprenger/left_arm_yellow_brick_in_box_with_purple_noise_v0, roboticshack/team16-can-stacking, zijian2022/insert2
 roboticshack/team-7-right-arm-grasp-tape, Jiangeng/so100_413 roboticshack/team9-pick_cube_place_static_plate
 AndrejOrsula/lerobot_double_ball_stacking_random roboticshack/left-arm-grasp-lego-brick
 roboticshack/team-7-left-arm-grasp-motor, roboticshack/team9-pick_chicken_place_plate roboticshack/team13-two-balls-stacking,
 tkc79/so100_lego_box_1 roboticshack/team13-three-balls-stacking, pierfabre/chicken roboticshack/team16-water-pouring,
 ad330/cubePlace, Jiafei1224/so100_pa222per paszea/so100_lego_2cam, bensprenger/chess_game_001_blue_stereo,
 Mohamedal/put_banana tkc79/so100_lego_box_2, samanthalhy/so100_herding_1, jlesein/TestBoulon7
 pranavsaroha/so100_onelego2, pranavsaroha/so100_onelego3, pranavsaroha/so100_carrot_2 vladfatu/so100_above,
 koenvanwijk/orange50-1, CSCSXX/pick_place_cube_1.18 dragon-95/so100_sorting, dragon-95/so100_sorting_1,
 nbaron99/so100_pick_and_place4

Beegbrain/pick_place_green_block, dragon-95/so100_sorting_3, HITHY/so100_peach3 shreyasgite/so100_legocube_50, triton7777/so100_dataset_mix, NONHUMAN-RESEARCH/SOARM100_TASK_VENDA mikechambers/block_cup_14, samsam0510/tooth_extraction_3, samsam0510/tooth_extraction_4 samsam0510/cube_reorientation_2, samsam0510/cube_reorientation_4, samsam0510/glove_reorientation_1 vladfatu/so100_office, pranavsaroha/so100_legos4, Ityl/so100_recording2 FeiYjf/new_GtoR, dragon-95/so100_sorting_2, HITHY/so100_peach4 jpata/so100_pick_place_tangerine, HITHY/so100_strawberry, shreyasgite/so100_base_env koenvanwijk/orange50-variation-2, pranavsaroha/so100_carrot_5, pandaRQ/pick_med_1 aractingi/push_cube_offline_data, DorayakiLin/so100_pick_charger_on_tissue, zijian2022/noticehuman3 liuhuanjim013/so100_th