

See Once, Then Act: Vision-Language-Action Model with Task Learning from One-Shot Video Demonstrations

Guangyan Chen^{1†}, Meiling Wang¹, Qi Shao¹, Zichen Zhou¹, Weixin Mao², Te Cui¹, Minzhao Zhu², Yinan Deng¹,
Luojie Yang¹, Zhanqi Zhang², Yi Yang¹, Hua Chen², Yufeng Yue^{1*}

¹ Beijing Institute of Technology ² LimX Dynamics

摘要——开发鲁棒且通用的操作策略是机器人研究中的基本目标。尽管视觉-语言-动作（Vision-Language-Action, VLA）模型在端到端机器人控制方面展现出有前景的能力，现有方法在训练分布之外的任务上仍表现出有限的泛化性。相比之下，人类仅通过观察他人执行一次就能高效习得新技能。受此能力启发，本文提出 ViVLA，一种通用机器人操作策略，在测试时仅凭单个专家演示视频即可实现高效任务学习。该方法联合处理专家演示视频与机器人视觉观测，预测演示动作序列及后续机器人动作，从而有效提取专家行为中的细粒度操作知识并无缝迁移至智能体。为提升 ViVLA 性能，本文开发了一种可扩展的专家-智能体配对数据生成流程，能够从易获取的人类视频中合成配对轨迹，并进一步通过公开数据集中的精选配对进行增强。该流程共生成 892,911 个专家-智能体样本用于训练 ViVLA。实验结果表明，ViVLA 能够在测试时仅凭单个专家演示视频习得新操作技能。在未见过的 LIBERO 任务上，本文方法实现超过 30% 的提升，并在跨具身视频上保持 35% 以上的增益。真实世界实验证明从人类视频中有效学习，在未见任务上带来超过 38% 的提升。

索引词——单样本视觉模仿学习，视觉-语言-动作模型，未见任务泛化，跨具身迁移，机器人策略学习。

I. 引言

机器人研究的一个基本目标是开发多功能、通用的机器人系统，能够在多个领域执行多样化任务，接近人类水平的适应性和通用性。受大语言模型（Large Language Models, LLMs）[1–4] 和视觉语言模型（Vision Language Models, VLMs）[5–9] 显著成功的启发，这些模型能够在广泛的任务和领域中泛化，机器人学界正积极开发具有类似能力的机器人基础模型。这些工作 [10–15] 通常建立在预训练的视觉语言模型之上，并在涵盖多样物体、环境和技能的大规模机器人数据集上进行后续训练，从而赋予机器人系统广泛的操控知识和增强的泛化能力。尽管取得了这些进展，泛化

在超出其训练分布的任务上仍是一项重大挑战。与之形成鲜明对比的是，人类通过视觉模仿展现出极为高效的学习能力，能够从专家示范中提取与任务相关的知识，并复现相似行为以达成相近目标。受这一理想能力的启发，一个自然的问题随之而来：机器人智能体能否同样通过观察单个专家示范视频，直接学习新颖的操作任务？为回答这一问题，本文研究开发一种机器人通用策略，使机器人能够在测试阶段仅通过观察单个专家示范视频，无需额外训练，即可学习超出其训练分布的新颖任务。本文基于视觉语言模型（VLM）构建模型，以利用其广泛的先验知识和视频理解能力。在此基础上，本文训练模型以单个专家示范视频为条件预测后续机器人动作，赋予模型在测试时从单个专家示范视频中学习新颖任务的能力。尽管该方法在概念上具有前景，并受益于强大的视觉语言模型，但实现此类能力仍非易事，原因如下：（一）模型能力：缺乏细粒度动作识别——

识别能力。实现此类通用机器人策略的关键能力在于从专家视频中获取细粒度操作知识。然而，现有视觉语言模型（VLM）主要侧重于语义层面的视频理解，在辨别视频序列中的细粒度操作动作方面能力有限。为解决这些局限性，本文在训练过程中引入细粒度动作推理目标，即训练模型在生成相应机器人控制输出之前，明确阐述演示视频中观察到的操作动作，从而增强其细粒度动作识别与理解能力。此外，本文还引入时间定位任务，将智能体的观测图像插入演示视频序列，训练模型识别这些观测在视频中的时间位置，从而促进视频与图像表示之间的跨模态信息交换。

（二）动作表示：视频数据缺乏动作标签，且动作空间存在差异

智能体与专家。视频数据通常缺乏动作标注，尤其是在人类视频中，这阻碍了视觉语言模型在细粒度动作上的训练。此外，演示视频中的专家与目标智能体通常具有不同的具身形态，由此产生的动作差异

* 通讯作者。

† Guangyan Chen 在 LimX 实习期间完成了这项工作动力学。




图 1: 本文提出的 ViVLA 示意图。(a) 本文的 ViVLA 经过训练, 以单个专家演示视频为条件预测后续机器人动作, 使模型能够在测试时从单个专家演示视频中学习新任务。(b) 为突破所提 ViVLA 的性能极限, 本文开发了一种可扩展的专家-智能体配对数据生成流程, 并构建了一个大规模专家-智能体配对数据集。(c) 大量实验表明, 本文提出的 ViVLA 能高效学习未见任务, 并达到最先进的性能。

空间差异使专家演示视频中的有效知识难以迁移至智能体机器人。为解决动作标注缺失的问题, 本文提出训练一个潜在动作分词器, 直接从视觉观测中推导动作表示。为进一步弥合具身差异, 本文在专家演示视频与智能体轨迹数据上联合训练该分词器, 并引入以动作为中心的循环一致性目标来正则化所学的潜在动作空间, 从而在智能体与专家之间建立统一的动作表示。在潜在动作分词器训练完成后, 视觉语言模型在该统一的潜在动作空间中, 从专家视频和智能体观测中预测潜在动作, 实现专家演示向机器人智能体的有效知识迁移。

(III) 动作建模策略: 自回归动作建模策略导致捷径学习并加剧

推理延迟。在自回归下一动作预测训练中, 模型可访问序列内所有前置的真实动作标记。这种可访问性使模型能够利用前置的真实动作标记来预测后续动作, 从而诱发捷径学习, 并阻碍对专家演示视频和智能体观测形成真正理解。此外, 自回归建模范式需要逐标记顺序生成, 这引入了显著的推理延迟。为缓解这些局限性, 本文采用并行解码策略, 其中模型接收空动作嵌入作为输入, 并在单次前向传播中同时生成所有动作标记。此修改防止了信息

来自先前动作序列的泄漏, 从而迫使模型将其预测建立在视频内容和智能体观察的全面分析之上。此外, 与顺序自回归解码相比, 动作序列的并行生成显著提高了推理效率。为了进一步增强模型对专家演示视频的理解, 我们引入了一种时空掩码策略, 该策略在时间和空间两个维度上随机掩码视频标记。这种方法在训练期间降低了计算复杂度, 同时建立了一个更具挑战性的学习目标, 即需要从部分观察到的专家演示中预测动作, 从而促进整体视频理解。

(四) 数据集: 专家-智能体配对数据的稀缺性。训练可泛化的视频-语言-动作模型需要丰富多样的专家-智能体配对数据, 这些数据在机器人学习领域仍然稀缺, 通常是人机配对数据。为了解决这一数据稀缺挑战, 我们开发了一种视频驱动的生成流程, 从易于获取的人类演示视频中合成人机配对。该流程首先在人类视频中定位交互信息, 并采用三维高斯泼溅来渲染逼真的四维场景, 描绘一个执行演示任务的智能体机器人, 然后生成观察-动作数据。通过将同一任务的人类视频与生成的机器人演示配对, 构建人机训练对。我们收集了 7,421 个人类视频, 涵盖 100 多个不同的操作任务, 并通过该流程构建了包含 89,736 个人机配对训练样本的 Human2Robot 数据集。

此外，我们利用开源数据集，并在具有相似任务的数据之间构建配对，产生了 803,175 个配对样本。总的来说，我们最终积累了 892,911 个专家-智能体样本用于训练视觉-语言-动作模型。

基于上述洞见，本文提出一种新颖的机器人学习视觉-语言-动作（VLA）范式，称为 ViVLA，使机器人能够在测试时从单个专家演示视频中学习新任务。ViVLA 框架包含两个关键阶段：

（一）基于动作中心循环一致性（A3C）的潜在动作学习。本文开发了一种潜在动作分词器，从观测序列中提取潜在动作表示，并引入动作中心循环一致性约束，以建立跨越专家视频和智能体演示的统一潜在动作空间。（二）面向单样本任务学习的 ViVLA 训练。ViVLA 模型通过并行解码预测专家视频和智能体观测的潜在动作序列，条件于经时空掩码策略处理的专家演示视频，并结合语言指令和智能体观测。为提升 ViVLA 的性能，本文开发了一种视频驱动的专家-智能体配对数据生成流程，能够从易于获取的人类视频中生成配对样本。此外，本文利用公开数据集在任务相似的数据之间构建配对。总计，本文收集了 892,911 个专家-智能体配对样本用于训练 ViVLA。实验结果表明，本文方法在 LIBERO 基准的未见任务上实现了超过 30% 的提升，并在使用不同实施例的视频时展现出超过 35% 的提升。本文方法有效从人类视频中蒸馏知识，在真实世界未见任务上持续取得超过 38% 的提升。

本文的贡献可概括如下：（一）提出了一种新颖的视觉-语言-动作范式，即 ViVLA，该范式能够有效地从专家行为中蒸馏细粒度操作知识，并将其无缝迁移至智能体。该范式使策略模型能够在测试阶段从单次演示中习得新颖的操作技能，而无需进一步训练或微调。（二）引入了一种包含循环一致性约束的潜在动作学习框架，以建立统一的潜在动作空间，该空间涵盖专家演示视频与机器人演示。此外，采用并行解码机制以缓解捷径学习问题，并提升推理过程中的计算效率。（三）提出了一种可扩展的专家-智能体配对数据生成流程，该流程从易于获取的视频源中合成轨迹对，并整合来自公开数据集的精选示例。利用该流程，构建了一个大规模数据集，包含 892,911 条专家-智能体配对轨迹，覆盖多种操作任务。

（四）实验表明，ViVLA 在 LIBERO 基准测试的未见任务上实现了超过 30% 的提升，在利用不同实施例的视频时实现了 35% 的提升。此外，本文方法能够有效地从人类视频中蒸馏知识，在真实世界未见任务上实现了超过 38% 的提升。

二、相关工作

A. 视觉-语言-动作模型

在预训练视觉基础模型、大语言模型（LLMs）和视觉语言模型（VLMs）成功的基础上，视觉-语言-动作模型（VLAs）[13, 15–20] 已成为一种有前景的方法，用于处理多模态输入以生成机器人动作。这些方法利用预训练的视觉语言模型并将其适配于机器人操作，有效地将网络规模预训练获得的语义知识迁移到机器人应用中。开创性工作 RT-2[16] 引入了一种离散化策略，将连续动作值均匀量化为每个维度 256 个区间。该方法使得网络规模语言模型能够在机器人轨迹数据上进行协同训练，促进语义理解向操作任务的迁移。在此基础上，OpenVLA[17] 采用了类似的动作离散化方法，同时在大规模 Open X-Embodiment（OXE）数据集 [21] 上训练视觉语言模型，该数据集汇集了来自 21 个机构 22 种不同实体的机器人数据。另一方向 [12, 18, 22] 采用动作专家生成连续信号。 π_0 [18] 通过集成专门的动作专家模块来适配 PaliGemma 视觉语言模型，该模块通过流匹配生成连续动作，实现精确流畅的操作技能。尽管视觉-语言-动作（VLA）模型已展现出有前景的能力，现有方法仍难以泛化到训练分布之外的任务。这一约束与人类能力形成对比，人类通过无缝地视觉模仿他人来学习新颖的操作知识。受此观察启发，我们向前迈进一步，赋予 VLA 在测试时从单个专家演示视频中学习技能的能力。

B. 单样本模仿学习

为使智能体能够从少量演示中快速适应新任务，并在测试时融入人类指令，段等人 [23] 首先形式化了单样本模仿学习（One-Shot Imitation Learning, OSIL）问题。他们针对积木堆叠任务提出了一种基于软注意力机制的学习框架，智能体同时处理单个成功演示和当前观测以预测动作。在此基础上，后续研究探索了多种演示形式，包括跨具身演示 [24, 25]、不同视角的演示 [26] 以及配有自然语言指令的演示 [27, 28]。为增强从这些演示中进行任务适应的能力，研究者们探索了多种解决范式，包括任务嵌入条件化 [29, 30]、元学习框架 [24, 25]、子目标预测机制 [26, 31]、表达性变换器架构 [32, 33] 以及视觉表征的对比学习 [33]。芬恩等人 [34] 将模型无关元学习（Model-Agnostic Meta-Learning, MAML）扩展到视觉模仿学习，使机器人能够从单个演示中快速适应新的操作任务。T-OSVI[32] 结合了基于变换器的注意力机制与自监督逆动力学损失来学习操作




图 2: 本文提出的 ViVLA 概览。(I) 潜动作分词器 (Latent Action Tokenizer, LAT) 从观测序列中学习量化潜动作, 为专家视频和智能体演示获取潜动作。(II) ViVLA 模型经过训练, 预测学习到的潜动作序列和后续机器人动作, 使机器人能够在测试时仅凭单个专家演示视频习得新的操作技能。

从单个演示视频中学习技能。AWDA[35] 通过结合属性路径点生成、演示增强和图像混合技术提升了泛化能力。近期, OSVI-WM[36] 提出从专家演示视频中学习世界模型, 将视觉观测编码到共享潜空间并预测未来潜轨迹, 随后解码为物理路径点供机器人执行。

C. 从跨具身数据中学习

一次性视觉模仿学习的一个有前景的目标是使机器人能够直接从跨具身演示视频中获取技能, 特别是人类演示, 这些演示具有易于获取的优势, 并为用户引导机器人行为提供了直观的手段。为了解决跨具身学习的挑战, 包括不同具身之间相机视角、本体感觉输入和动作空间的显著差异, 已经提出了许多方法。早期的工作 [37] 试图通过手动对齐动作空间来弥合这些差距。最近的基于变换器的方法 [38, 39] 被开发出来, 以更有效地适应可变的观察和动作。CrossFormer[39] 展示了在四个不同的动作空间上进行联合训练的能力, 而无需对观察空间施加约束或要求显式的动作空间对齐。流表示捕获图像或点云中查询点的未来轨迹, 已被探索用于跨具身学习 [40 – 43]。ATM[40] 利用视频演示进行轨迹生成模型的预训练, 利用来自跟踪模型的标注 [44 – 46]。最近, 基于潜在动作的方法 [15, 47 – 50] 被提出, 用于学习离散码本, 这表现出更适合视觉语言动作模型固有的自回归训练范式。LAPA[47] 引入了一种无监督学习框架, 用于连续帧之间的量化潜在动作。

视频帧, 训练模型使用潜在动作和当前帧重建后续帧。UniVLA[15] 提出了以任务为中心的潜在动作, 这些动作结合指令将转移动态分解为任务无关和任务相关的组件。尽管这些方法已经展示了有前景的性能, 但它们在学习语义一致的潜在动作表示方面仍然有限。此外, 不同具身的潜在动作空间通常是碎片化的, 限制了跨具身的操作知识转移。

D. 策略学习的数据增强

在训练数据有限的场景中, 数据增强已成为一种有前景的方法, 用于生成多样化的训练样本并增强策略的鲁棒性。先前的研究探索了多种增强技术, 以提高视觉运动策略的韧性 [51 – 57]。一个代表性的方法是 MimicGen[58], 它提出了一种自动化系统, 用于从少量人类演示中合成大规模机器人演示数据集。其实现方式是将演示分解为以对象为中心的片段, 对这些片段进行空间变换, 随后将它们拼接在一起以生成新颖的轨迹。然而, 这些方法主要在模拟环境中进行评估, 需要针对特定任务构建环境, 并面临仿真到现实差距的挑战。为了促进学习策略在真实世界环境中的部署, 近期工作探索了通过图像修复模型来增强场景外观 [59 – 62]。例如, Mirage[63] 在图像中遮盖目标机器人, 并使用 URDF 和渲染技术在相应姿态下修复源机器人, 从而实现在不同机器人手臂和夹爪之间的迁移, 而无需目标机器人的训练数据。类似地, VISTA[64] 生成增强任务




图 3: 我们以动作为中心的循环一致性的动机。(a) 我们将从参考视频帧编码的潜在动作应用于当前帧。现有方法 (如 Genie[49]) 生成的帧具有发散的运动, 显示出有限的语义一致性。(b) 我们可视化了不同实体间的潜在动作空间, 揭示了现有方法中有限的跨实体对齐。我们的方法解决了这些局限性, 并构建了一个统一的潜在动作空间。

通过单图像新视角合成模型从多样相机视角生成演示, 旨在学习视角不变策略 [65]。此外, Rovi-aug [66] 通过将机器人实体修补到图像观测中, 开发了一种跨实体流程。然而, 这些研究主要在二维图像上进行增强, 本质上缺乏空间信息。为解决这一局限性, RoboSplat [67] 使用三维高斯泼溅重建场景, 并编辑三维表示以进行数据增强。本文提出一种视频驱动的专家-智能体配对数据生成流程。该流程以人类视频为输入, 采用高斯泼溅渲染机器人执行过程。通过将同一任务的人类视频与其生成的机器人演示配对, 构建专家-智能体对。

三、ViVLA

设 $\mathcal{M} = \{\mathcal{M}_1, \dots, \mathcal{M}_{|\mathcal{M}|}\}$ 表示一组任务, 划分为不相交的训练集和测试集 ($\mathcal{M}_{train}$ 和 $\mathcal{M}_{test}$)。每个训练任务包含一组专家轨迹 $\mathcal{T}^e = \{(v_i, \ell_i)\}_{i=1}^{N_e}$, 以及一个带有动作标注的智能体演示语料库 $\mathcal{T}^a = \{(\tau_i^a, \ell_i)\}_{i=1}^{N_a}$, 每个回合 i 与其对应的语言指令 ℓ_i 配对。专家演示轨迹包含专家视频帧 $\{v_{i,t}\}_{t=1}^{T_e}$, 而智能体演示 $\tau_i^a = \{o_{i,t}, a_{i,t}\}_{t=1}^{T_a}$ 同时包含观测数据 o 及其关联的动作命令 a 。在每个任务内, 所有专家和智能体轨迹对应于同一高层任务的不同变体 (例如, 不同的物体配置)。模型在 $\mathcal{M}_{train}$ 上训练, 并在仅包含专家视频的 $\mathcal{M}_{test}$ 上进行评估。图 2 展示了本文 ViVLA 的整体架构。本文的 ViVLA 方法包含两个关键阶段: (一) 具有循环一致性的潜在动作学习。本文方法从观测序列中学习潜在动作表示, 同时引入以动作为中心的循环一致性约束, 以建立统一的潜在动作空间。(二) 用于单次任务学习的 ViVLA 训练。ViVLA 模型通过并行解码, 同时预测专家视频和智能体观测的动作序列, 并以经过时空掩码策略处理的专家演示视频、语言指令和智能体观测为条件。

A. 具有循环一致性的潜在动作学习

我们从智能体演示和专家视频中学习潜在动作, 从而为这两种数据源提供潜在动作标注。现有方法通过建模连续观测帧 I_t 与 I_{t+H} 之间的转移动态, 以时间窗口大小 H 学习潜在动作表示, 训练潜在动作分词器在给定学习到的潜在动作和当前帧

I_t 的条件下重建后续帧 I_{t+H} 。然而, 当前帧与未来帧之间的对应关系严格一一对应, 仅将 I_t 与 I_{t+H} 配对。这使得未来帧重建几乎无需理解转移动态, 阻碍了语义一致的潜在动作的提取, 如图 3(a) 所示。此外, 我们在图 3(b) 中可视化了不同实体上的潜在动作空间, 并观察到这些表示空间内部存在碎片化, 不同区域被分配给各个实体, 表明跨实体统一性有限。为克服这些局限性并为 ViVLA 训练建立统一的潜在动作空间, 我们提出了一种以动作为中心的循环一致性潜在动作学习框架, 并在专家视频和智能体演示数据上联合学习潜在动作。为简洁起见, 我们使用 I 表示来自专家视频 v 和智能体观测 o 的视觉帧。如图 4 所示, 我们从观测帧 $\{I_t, I_{t+H}\}$ 中提取潜在动作 z_t^q , 并将其保存在潜在动作缓冲区 $\mathcal{Z}$ 中。我们同时强制以动作为中心的循环一致性, 其中从该缓冲区采样的潜在动作 z_t^q 与观测帧 I_c 一起解码以生成未来帧 $\hat{I}_g$, 并且训练分词器从观测帧 I_c 和生成帧 $\hat{I}_g$ 中预测这些采样的潜在动作。如图 3 所示, 我们的方法有助于构建统一的潜在动作空间, 实现语义一致性和跨实体统一性。潜在动作分词。我们的方法首先通过编码器-解码器架构从观测帧中学习潜在动作。编码器 $\mathcal{E}$ 使用 DINOv2[68] 从当前帧 I_t 和未来帧 I_{t+H} 中提取图像嵌入 f_t 和 f_{t+H} 。这些提取的嵌入




图 4: 我们以动作为中心的循环一致性潜在动作框架示意图。该方法从观测帧中学习潜在动作表示, 同时引入以动作为中心的循环一致性约束, 以建立统一的潜在动作空间。

与可学习的潜在动作标记拼接。拼接后的表示随后由时空变换器处理, 该变换器由 L 个时空块组成, 每个块包含交错的时空自注意力层。时空变换器建模帧间的时间转移动态, 并将学习到的信息聚合到潜在动作标记中。编码后的潜在动作标记 z_t^e 被量化为离散表示 z_t^q , 其中每个潜在动作使用 l_z 个从大小为 K 的码本词汇表中选择的标记来表示。这些量化后的动作标记使用 VQ-VAE[69] 目标进行优化。潜在动作 z_t^q 的编码过程如下所示: $z_t^e = \text{时空变换器}([f_t, f_{t+H}, z])$, $z_t^e \in \mathbb{R}^{l_z \times c_z}$

$$z_t^q = \text{VQ}(z_t^e), \quad z_t^q \in \mathbb{R}^{l_z \times c_z}. \quad (1)$$

解码器 $\mathcal{D}$ 实现为一个空间变换器, 包含带有空间注意力层的空间块, 通过处理学习到的潜在动作 z_t^q 以及当前帧 I_t 来重建未来帧 I_{t+H} 。总之, 潜在动作分词过程表述如下:

$$\begin{aligned} z_t^q &= \mathcal{E}(I_t, I_{t+H}), \quad z_t^q \in \mathbb{R}^{l_z \times c_z}, \\ \hat{I}_{t+H} &= \mathcal{D}(I_t, z_t^q), \quad \hat{I}_{t+H} \in \mathbb{R}^{w \times h \times c_o}. \end{aligned} \quad (2)$$

以动作为中心的循环一致性。我们引入以动作为中心的循环一致性来正则化学习到的潜在动作, 建立统一的潜在动作空间, 实现语义一致性和跨实体统一。该方法从数据集中获取观测帧 I_c , 并从潜在动作缓冲区 $\mathcal{Z}$ 中采样一个潜在动作 z_s^q , 其中潜在动作缓冲区 $\mathcal{Z}$ 通过收集前 B 个批次中编码的潜在动作 z_t^q 构建。然后, 我们使用采样的潜在动作 z_s^q 解码观测帧 I_c , 生成相应的后续帧 I_g 。通过将观测帧 I_c 和生成帧 I_g 输入编码器 $\mathcal{E}$ 来强制循环一致性, 编码器

被训练以恢复最初采样的潜在动作 z_s^q :

$$\begin{aligned} \hat{I}_g &= \mathcal{D}(I_c, z_s^q), \quad z_s^q \sim \mathcal{Z}, \\ \hat{z}_s^q &= \mathcal{E}(I_c, \hat{I}_g), \quad \hat{z}_s^q \in \mathbb{R}^{l_z \times c_z}. \end{aligned} \quad (3)$$

为了实现梯度传播, 我们利用量化前的潜在动作嵌入 $\hat{z}_s^e$, 并计算它们与 VQ-VAE 中码本向量 e 的距离作为相似性度量。然后, 我们通过交叉熵损失优化与采样潜在动作 z_s^q 的一致性, 使用采样潜在动作的码本索引作为监督信号。目标函数如下:

$$\mathcal{L}_C = -\sum_{k=1}^K y_k \log\left(\frac{\exp(-d(\hat{z}_s^e, e_k)/\tau)}{\sum_{j=1}^K \exp(-d(\hat{z}_s^e, e_j)/\tau)}\right). \quad (4)$$

其中 y_k 是对应于采样潜在动作索引的独热目标向量, z_s^q, τ 是温度参数, $\hat{z}_s^e$ 是量化前的潜在动作嵌入, $\{e_k\}_{k=1}^K$ 是码本向量, $d(\cdot, \cdot)$ 表示距离度量。与以往受限于当前帧与未来帧之间固定配对模式、限制潜在动作获取有效性的方法不同, 我们的方法建立了一个具有挑战性的自监督学习目标。该公式迫使分词器提取语义一致的潜在动作。此外, 我们的方法支持跨具身学习, 以促进不同具身之间潜在动作空间的统一。具体而言, 我们采样从具身 E_i 编码的潜在动作 z_s^q , 并将其应用于来自具身 E_j 的观察帧 I_c , 生成帧 $\hat{I}_g$ 并预测 E_j 的潜在动作 $\hat{z}_s^q$ 。循环一致性强制 $\hat{z}_s^q \approx z_s^q$, 以迫使分词器学习跨具身的统一潜在动作。判别器。解码器生成图像与数据集图像之间的分布差异会降低编码器性能。此外, 解码器可能通过生成帧将潜在动作信息直接泄露给编码器,




图 5: 我们的 ViVLA 示意图。我们的方法联合处理专家演示视频和机器人的视觉观察，以预测演示动作序列和后续机器人动作，使 ViVLA 能够从专家行为中提炼细粒度操作知识，并无缝迁移到智能体。

导致对应关系看似循环一致，但本质上仍然错误。为解决这一问题，本文引入一种局部-全局判别器，使生成帧的分布与数据集图像在局部细节和全局风格两个层面保持一致。该正则化同时防止信息泄漏，因为将潜在动作嵌入生成帧会引起分布偏差，而判别器会对此进行惩罚。判别器 Ψ 通过空间变换器处理输入图像帧，包括来自数据集的观测帧和生成帧，以提取相应的块特征 h_l ，随后由多层感知机处理生成块逻辑值 σ_l 。此外，本文对块特征应用二维卷积和全局池化操作以得到全局特征 h_g ，并由此获得全局逻辑值 σ_g ，形式化表示为：

$$\begin{aligned} \mathcal{F}_l &= \text{Spatial-Transformer}(I), \quad \sigma_l = \text{MLP}(\mathcal{F}_l), \\ \mathcal{F}_g &= \text{GlobalPool}(\text{Conv2D}(\mathcal{F}_l)), \quad \sigma_g = \text{MLP}(\mathcal{F}_g). \end{aligned} \quad (5)$$

基于这些局部和全局逻辑值，本文为解码器 $\mathcal{D}$ 和判别器 Ψ 定义对抗损失 $\mathcal{L}_{GAN}$ ，其公式如下：

$$\begin{aligned} \mathcal{L}_{GAN}^{\Psi} &= -\log(\Psi(o)) - (1 - \log(\Psi(\mathcal{D}(o, z)))), \\ \mathcal{L}_{GAN}^{\mathcal{D}} &= 1 - \log(\Psi(\mathcal{D}(o, z))). \end{aligned} \quad (6)$$

这些损失公式同时应用于局部和全局层面。判别器的目标是最大化正确区分数据集样本与解码器生成样本的概率。解码器的训练目标是最大化判别器将其生成样本分类为来自数据集分布的概率。

B. 面向单次任务学习的 ViVLA 训练

本文提出的 ViVLA 框架概览如图 5 所示。该框架基于 Qwen2.5-VL[5] 视觉语言模型构建，该模型在视觉识别和语义级视频理解方面展现出有前景的性能。其架构包含一个采用窗口注意力的视觉变换器（Vision Transformer, ViT），用于在原生分辨率下进行高效处理，

一种基于多层感知机的视觉-语言融合模块，用于压缩视觉特征，以及擅长多模态理解的 Qwen2.5 大语言模型。我们使用预训练参数初始化权重，并在专家-智能体配对数据上训练模型，以增强动作理解 and 技能学习能力。策略模型接收带有时间-空间掩码的专家演示视频、机器人智能体观测和语言指令，旨在预测专家视频序列中演示的动作序列以及智能体随后执行的动作。时间空间掩码策略。视频数据构成具有显著时间和空间冗余的自然信号。视频数据的引入会产生大量令牌序列，在训练过程中带来相当大的计算负担。为缓解这些挑战，我们提出一种时间-空间掩码策略，在时间和空间两个维度上对视频数据进行掩码。我们采用与 Qwen2.5VL 相同的时间窗口大小对输入视频序列进行时间掩码，同时保留与原始时间步对应的绝对时间编码以维持时间信息。保留的视频帧随后通过视觉编码器处理，生成一组逐块令牌表示。然后我们对生成的令牌表示应用空间掩码，仅将未掩码的令牌传递给语言模型组件。这种时间-空间掩码方法显著减少了视频信息冗余，同时迫使视觉语言模型在部分观测的视频序列上进行动作预测，从而增强其全面视频理解能力。按照此流程，处理后的视频令牌与智能体观测令牌和语言指令令牌一起被编码为潜在表示 $\{h_v, h_o, h_\ell\}$ ，用于后续动作预测。

并行解码。编码后的令牌 $\{h_v, h_o, h_\ell\}$ 被输入语言模型组件 LM，该组件经过训练以预测动作序列。为缓解捷径学习问题并降低推理延迟，语言模型采用并行解码来预测动作序列，

涵盖潜在动作与机器人动作。具体而言，对于潜在动作预测，我们通过引入潜在动作查询令牌来扩展词汇表，用于潜在动作预测，记作 LACT。模型接收这些潜在动作查询令牌作为输入，并在单次前向传播中同时解码它们。为了使模型能够自适应地确定并行解码的起始以及同时解码的令牌数量，我们在词汇表中引入了 START 令牌：

$\{\text{START_LACT_}n \mid n \in \{1, 2, \dots, \text{MAX_N}\}\}$ ，其中 MAX_N 表示潜在动作查询令牌的最大数量。当模型生成 START 令牌时，相应的潜在动作查询令牌根据其指定的并行解码数量被追加到后续输入中，在单次前向传播中同时生成所有动作令牌。并行解码过程表示为：

$$\begin{aligned} s_t &= \text{LM}(h_{\leq t}), h_{\leq t} = [h_v, h_o, h_\ell, h_p] \\ \{\hat{z}_{t+i}\}_{i=0}^{n-1} &= \text{LM}([h_{\leq t}, s_t, \text{LACT}^n]). \end{aligned} \quad (7)$$

其中 h_p 表示先前生成的令牌， $s_t \in \{\text{START_LACT_}n \mid n \in \{1, 2, \dots, \text{MAX_N}\}\}$ ，LACT n 表示 n 个 LACT 令牌， $\hat{z}$ 表示预测的潜在动作令牌。类似地，机器人动作预测遵循相同的并行解码机制，引入相应的 START 令牌 $\{\text{START_ACT_}n \mid n \in \{1, 2, \dots, \text{MAX_N}\}\}$ 和动作查询令牌 ACT，以实现动作序列的并行预测。与自回归建模策略相比，后者在训练期间可以访问所有先前的真实动作令牌，并且需要逐令牌顺序处理，从而引发捷径学习问题并增加推理延迟。并行解码方法有效防止信息泄漏，并鼓励基于对专家视频和智能体观测的理解进行动作预测。此外，所有动作序列的并发生成显著提高了推理效率。ViVLA 训练。训练预测目标包括来自专家视频序列的潜在动作序列 $\{z_{v,nH}^q\}_{k=0}^{N_v-1}$ ，以及智能体机器人的后续潜在动作 $z_{o,t}^q$ 和机器人动作，其中 $N_v = \lfloor T/H \rfloor$ ， T 表示视频长度， H 表示潜在动作编码的时间窗口大小。与专家视频帧 v_t 和智能体观测帧 o_t 对应的潜在动作 $z_{v,t}^q$ 和 $z_{o,t}^q$ 使用预训练的潜在动作分词器进行编码，遵循以下步骤：

$$\begin{aligned} z_{v,t}^q &= \mathcal{E}(v_t, v_{t+H}), \\ z_{o,t}^q &= \mathcal{E}(o_t, o_{t+H}). \end{aligned} \quad (8)$$

这些潜在动作使用从大小为 K 的码本词汇表中选取的 l_z 个标记来表示，这自然与视觉语言模型 (VLM) 所采用的离散预测范式相契合。我们通过引入 K 个专用标记来扩展词汇表： $\{\text{LACT_1}, \text{LACT_2}, \text{LACT_3}, \dots, \text{LACT_K}\}$ 。每个潜在动作根据其在潜在动作码本中的对应索引映射到这个扩展词汇表。优化的核心是最小化后续潜在动作的负对数概率之和：

$$\mathcal{L}_z = \mathbb{E}_z \left[- \sum_{i=1}^{N_z} \log P(\hat{z}_i^q = z_i^q) \right], \quad (9)$$

其中 N_z 表示潜在动作标记的总长度。动作查询标记 ACT 被附加在潜在动作查询标记之后，用于机器人动作预测，并集成了一个动作解码器，将预测的动作标记 ACT 转换为连续的机器人动作值。动作解码器接收来自语言模型 (LM) 最后一层的动作嵌入作为输入。然后，它通过注意力机制聚合这些信息，并将表示池化为一个统一的嵌入，随后通过多层感知机 (MLP) 映射到机器人动作。整个架构通过联合优化潜在动作预测损失和真实机器人动作与预测机器人动作之间的 L1 损失进行端到端训练。

为了促进视频和图像表示之间的跨模态信息交换，我们引入了一个时间定位任务。具体来说，将智能体的观测图像插入到专家演示视频序列中，并训练模型识别它们在视频中的时间位置，从而增强跨模态的特征交换。此外，我们在训练过程中随机排除专家演示视频，要求模型仅基于机器人观测和语言指令来预测潜在动作和机器人动作。这种训练策略使我们的策略在无法访问专家演示的情况下，对已见任务保持鲁棒性。

ViVLA 后训练。为了将预训练阶段获得的知识有效迁移到目标机器人平台，我们在目标机器人上对 ViVLA 模型进行后训练。在后训练阶段，动作解码器进行全参数微调，以适应目标机器人特定的动作空间和控制要求，而预训练的视觉语言模型主干则采用低秩适应 (LoRA) [70] 进行微调。这种设计保留了预训练阶段学习到的丰富语义表示和泛化能力，同时以最小的计算开销高效地适应目标机器人领域。整体流程遵循预训练阶段建立的同框架。

C. 视频驱动的专家-智能体数据生成

训练可泛化机器人模型的关键之一在于多样且高质量的训练数据。为了生成多样且高质量的专家-智能体配对数据，我们构建了一个视频驱动的专家-智能体配对数据生成流程，如图 6 所示。该流程以人类视频为输入，利用现有的视觉基础模型获取手部姿态和物体姿态，并采用高斯泼溅重建机器人执行任务的四维场景。专家-智能体配对通过将人类视频与为同一任务生成的机器人演示进行配对来构建。交互接地。我们利用视觉基础模型从提供的人类视频中估计手部和物体姿态 v 。对于手部跟踪，我们首先应用 HaMeR [71] 预测手部形状和姿态参数，同时生成手部网格模型。进一步采用迭代最近点 (ICP) [72, 73] 将手部网格与分割出的手部点云对齐，从而在相机坐标系中获得精确的手部姿态轨迹 $\xi_H = \{x_C^{H^0}, \dots, x_C^{H^T}\}$ 。随后，




图 6: 我们的视频驱动专家-智能体数据生成流程示意图。该流程以人类视频为输入, 利用现有的视觉基础模型获取手部姿态和物体姿态, 并采用高斯泼溅重建不同机器人执行任务的四维场景。专家-智能体训练配对通过将人类视频与为同一任务生成的相应机器人演示进行配对来构建。




图 7: 从估计的手部姿态计算六自由度夹爪姿态。抓取点计算为拇指和食指指尖之间的中点。坐标系定义为: X 轴垂直于由两指上所有跟踪点张成的平面, Y 轴从抓取点指向食指指尖, Z 轴通过 $\vec{z} = \vec{x} \times \vec{y}$ 获得。

这些序列被转换为机器人末端执行器轨迹

$\xi_E = \{x_C^{E^0}, \dots, x_C^{E^T}\}$ [74], 如图 7 所示。对于目标跟踪, FoundationPose[75] 在给定物体网格 Ω 的情况下估计时间物体姿态 $\xi_\Omega = \{x_C^{\Omega^0}, \dots, x_C^{\Omega^T}\}$, 该网格通过 TRELLIS[76] 从多视图图像重建。

视频解析 我们将视频分割成独立的片段 $\{\tau_i\}_{i=1}^V$, 其中每个片段封装一个不同的子任务。该分割过程基于交互标记的识别和利用, 这些标记表示接触的开始和接触的终止。具体来说, 物体和手的点云 $\mathcal{P}$ 通过它们各自的姿态估计和网格模型获得。然后我们计算

物体间距离并识别接触转换如下:

$$d = \text{dist}(\mathcal{P}), \quad t_b = \{t | d^{t-1} > \epsilon \wedge d^t < \epsilon\}, \quad (10)$$

$$t_e = \{t | d^{t-1} < \epsilon \wedge d^t > \epsilon\},$$

其中函数 dist 计算任意两个点云之间的距离。 t_b 和 t_e 分别表示接触开始和接触结束。我们将片段分类为抓取阶段和操作阶段。在抓取阶段, 物体保持静止, 智能体执行朝向物体的伸取-抓取动作。在操作阶段, 智能体操纵被抓取的物体, 执行运动, 并使物体之间发生接触。末端执行器姿态优化。我们优化转换后的末端执行器姿态轨迹 ξ_E , 以进一步细化末端执行器与物体之间的接触关系。在抓取阶段, 我们使用接地轨迹复制机器人末端执行器的轨迹, 并在接触时刻 t_g 优化抓取姿态 $x_C^{E^{t_g}}$, 其中 t_g 表示抓取阶段的结束。具体来说, 我们在初始接地抓取姿态 $x_C^{E^{t_g}}$ 周围的 6D 邻域内采样 N 个候选抓取 $\{x_{C,i}^{E^{t_g}}\}_{i=1}^N$, 随后筛选可行的抓取配置。如果满足两个条件, 则认为抓取是可行的: (I) 末端执行器不与物体碰撞, 以及 (II) 物体位于末端执行器的抓取区域内。对于平行夹爪, 抓取区域通常定义为夹爪之间的区域。在可行的候选中, 我们为每个抓取计算稳定性得分, 即夹爪平面与物体重心 (COG) 之间的归一化垂直距离 [77]。然后选择具有最高稳定性得分的可行抓取姿态 $\hat{x}_C^{E^{t_g}}$, 并相对于



图 8: 用于数据生成管线的物体集合。

到物体的坐标系。在操作阶段,我们采用常用的假设,即末端执行器与物体之间的相对位姿在整个操作过程中保持不变。在此约束下,末端执行器轨迹通过将物体运动与优化后的抓取位姿进行组合而推导得出。由此得到的优化末端执行器位姿 $\hat{\xi}_E$ 使我们的数据生成流程能够合成具有改进物理一致性的高质量四维机器人-物体操作场景。高质量四维场景重建。基于物体轨迹和优化后的末端执行器位姿轨迹,通过三维高斯泼溅重建四维机器人-物体操作场景。在重建过程中,每个物体使用其基础位姿和对应的高斯模型 $\mathcal{G}_\Omega$ 表示,而机器人使用关节位置及其高斯模型 $\mathcal{G}_R$ 表示。机器人关节位置通过运动规划从优化后的末端执行器轨迹 $\hat{\xi}_E$ 推导得出,物体高斯模型 $\mathcal{G}_\Omega$ 由物体网格转换而来,机器人高斯模型 $\mathcal{G}_R$ 从相应的 URDF 文件或真实世界重建中获得。重建的四维场景展现出高视觉保真度,并与人类视频中观察到的轨迹良好对齐 v ,如图 6 所示。多样化专家智能体数据生成。利用重建的四维场景,我们通过多样化的演示增强 [67] 生成机器人演示,这些增强在三个维度上进行:(一)相机视角。三维高斯泼溅的一个关键优势在于其新视角合成能力。我们利用这一特性,通过从多样化的相机位姿渲染重建的四维场景,生成多视角演示,从而丰富训练数据的视觉多样性。(二)场景外观。我们通过为操作工作空间周围的桌面和背景三维高斯平面应用不同纹理来增强场景外观。这使得能够生成多样化的场景组合,增强模型对环境变化的鲁棒性。(三)光照条件。我们通过对重建场景中每个高斯的漫反射颜色属性应用随机缩放因子、偏移量和噪声扰动来多样化光照条件。我们

表一: 训练数据混合。

Datasets	Num of Traj.
Fractal [79]	87,212
Bridge [80]	60,064
Droid [81]	49,933
Language Table [82]	442,226
BC-Z [27]	43,264
FMB Dataset [83]	4,592
Ego4D [81]	18,368
EgoDex [84]	97,516
Human2Robot	89,736
总计	892,911

策划了 7,421 个人类演示视频,涵盖超过 100 种不同的操作任务,并通过此流程构建了包含 89,736 个人类-机器人配对训练样本的 Human2Robot 数据集。数据收集过程中使用的物体如图 8 所示。从公开可用数据集中收集数据集。除了我们生成的数据集外,我们还整合了公开可用的数据集,通过从相似任务的演示中构建专家-智能体配对来进一步丰富训练语料库。任务相似度通过计算任务指令的 Sentence-BERT 嵌入 [78] 之间的余弦相似度来量化,我们选择超过预定义相似度阈值(在我们的实现中设置为 0.9)的配对。通过此过程,我们从公开可用数据集中收集了 803,175 个配对样本。总共,我们最终获得了 892,911 个专家-智能体配对样本用于训练我们的 ViVLA。

四、实现细节

我们的训练语料库由三个主要数据类别组成:机器人操作数据、人类视频数据以及合成生成的人机配对数据(即我们的 Human2Robot 数据集)。对于机器人操作数据,我们纳入了 Open X-Embodiment 数据集 [85] 中的一个精选子集,特别聚焦于单臂末端执行器控制任务。人类视频数据包含来自 Ego4D 数据集 [86] 和 EgoDex [84] 的自我中心视角记录,捕捉了多样化人类活动的第一人称视角。我们通过将轨迹与语义相似的任务演示相结合来生成专家-智能体配对,从而利用机器人操作数据和人类视频数据中的演示。我们的 Human2Robot 数据集通过一个视频驱动的专家-智能体数据生成流程合成,该流程将在第 III-C 节中详细说明。数据集的完整构成分解见表 I。对于以动作为中心的循环一致性潜在动作学习,我们的编码器利用预训练的 ViT-base DINOv2 模型从输入图像中提取视觉嵌入。这些嵌入随后通过一个由 12 层组成、隐藏状态维度为 768 的时空变换器 (spatial-temporal transformer) 进行处理。所得的潜在动作表示通过使用包含 16 个条目的码本进行向量量化来离散化。解码器和判别器网络均采用具有相同架构规格的空间变换器,每个都由 12 层组成,并在整个过程中保持 768 维表示。为了

为在训练过程中促进时序一致性，我们维护一个潜在动作缓冲区，用于累积前 4 个批次编码得到的潜在动作。整个潜在动作分词器采用 AdamW 优化器进行优化，学习率为 1×10^{-4} ，权重衰减为 1×10^{-2} 。对于 ViVLA 的训练，我们采用全局批大小 256，分布在多个 GPU 上，每个设备 8 个样本。模型训练 30,000 个优化步骤，使用恒定学习率 2×10^{-5} 。为增强鲁棒性，我们对输入视频应用时空掩码，时间维度和空间维度的掩码比率均从范围 $[0, 0.5]$ 中随机采样。为强化模型的细粒度动作推理能力，我们以 0.4 的概率对单个视频进行细粒度动作推理训练，此时模型仅在专家视频演示中预测潜在动作序列，而不继续进行机器人智能体的后续潜在动作和机器人动作预测。

五、实验

我们进行实验以回答以下问题：

- ViVLA 能否从单个专家演示视频中有效学习未见任务，从而提升机器人智能体的适应性？

- ViVLA 是否具备鲁棒的跨具身学习能力，能够从不同机器人平台的专家演示视频中习得技能？
- ViVLA 能否直接从人类演示视频中学习机器人技能，并在真实世界机器人场景中稳健执行？

我们首先通过与最先进的视觉-语言-动作（VLA）基线和单样本模仿学习（OSIL）方法进行对比评估，评估 ViVLA 的未见任务学习能力（第 V-A 节）。随后在第 V-B 节中考察 ViVLA 的跨具身技能迁移能力。我们进一步在第 V-C 节中证明 ViVLA 能够从人类演示视频中有效学习，并在真实世界环境中实现稳健的任务执行。最后，我们在第 V-E 节中给出全面的消融研究，以系统验证框架中每个组件的贡献。

A. 未见任务学习

我们首先研究 ViVLA 从具有相同具身形态的视频中学习未见任务的能力。基线。ViVLA 与四种代表性方法进行比较：（1）扩散策略 [87]，将机器人视觉运动策略表示为条件去噪扩散过程，实现稳定训练并自然处理高维空间中的多模态动作分布。

（2）AWDA[35]，通过从演示视频预测属性路点实现一次性视觉模仿，并通过手工设计的运动原语执行。（3）OpenVLA[10]，基于 Prismatic7B[88] 并在 OXE[21] 数据集上训练的 VLA，在 LIBERO 基准上进行了后训练。（4）UniVLA[15]，从多样跨具身视频中学习以任务为中心的潜在动作，无需动作标签，在无动作数据集上预训练 VLA 模型。

实验设置。我们在 LIBERO 基准（LIBERO benchmark）[89] 上进行评估，这是一个包含 130 个语言条件操作任务的综合套件。遵循 OpenVLA[10] 建立的实验协议，我们专注于四个专门的套件：LIBERO-Spatial、LIBERO-Object、LIBERO-Goal 和 LIBERO-Long。LIBERO-Spatial 评估对环境配置变化的鲁棒性，同时保持对象类型一致。LIBERO-Object 评估在固定空间布局下跨对象变化的泛化能力。LIBERO-Goal 测试对不同任务目标的适应性，同时保持对象类别和空间布局不变。LIBERO-Long 呈现最具挑战性的场景，需要在多样化的对象类别和空间配置下进行长时程推理。每个套件包含 10 个不同的任务。为了评估泛化能力，我们将每个套件中的 8 个任务指定为已见任务用于训练，并保留 2 个任务作为未见任务用于测试。训练集通过聚合所有已见任务的演示构建成一个整合数据集。对于专家-智能体对的构建，我们利用数据集中机器人的执行轨迹，将同一任务由机器人执行的视频配对作为专家演示。所有基线方法都在这个整合数据集上训练，随后在已见和未见任务划分上进行评估，以评估分布内性能和泛化能力。实验结果。表 II 展示了所有评估任务套件的全面性能比较，表明 ViVLA 始终优于基线方法。扩散策略（Diffusion Policy, DP）在应用于未见任务时表现出有限的泛化能力。尽管在大规模 OXE 数据集上进行了预训练，并随后在整合的 LIBERO 数据集上进行了后训练，OpenVLA 和 UniVLA 在未见任务上仍表现出显著的性能下降。这一观察证实了我们的假设：当前方法在泛化到新任务时遇到显著困难，通常需要任务特定的数据收集和微调程序来获得新能力。我们的方法在已见和未见任务上也超越了 AWDA，其中 AWDA 同样利用专家演示视频进行未见任务泛化。这些结果证实了我们的方法能够有效地从专家演示视频中提取细粒度的操作知识，并将这些知识有效地迁移到新的任务配置中，使我们的方法能够仅从单个专家视频中学习新任务。在未见任务上的显著性能提升突显了我们的方法在学习可迁移表示方面的有效性，这些表示超越了训练分布。

B. 基于跨机器人视频的未知任务学习

随后，本文探究了视觉-语言-动作模型（ViVLA）从不同机器人平台执行的操作任务的专家演示视频中学习新技能的能力。实验设置。基于跨机器人视频的未知任务学习实验在语言与具身推理基准（LIBERO）[89] 上进行。为构建专家-智能体配对数据集，本文使用优傲（UR）机械臂回放语言与具身推理基准（LIBERO）数据集，其中弗兰卡（Franka）机械臂作为智能体，优傲（UR）机械臂提供专家演示。

表二：语言与具身推理基准（LIBERO）上的成功率。本文将语言与具身推理基准（LIBERO）数据集划分为已见任务与未知任务，并报告各对比方法在每个子集上的成功率。

Methods	DP	OpenVLA	UniVLA	AWDA	AWDA _R	Ours	Ours _R
Seen	0.70	0.75	0.95	0.66	0.62	0.96	0.95
Unseen	0.01	0.04	0.13	0.35	0.28	0.65	0.63

Methods	LIBERO-Spatial		LIBERO-Object		LIBERO-Goal		LIBERO-Long	
	Seen	Unseen	Seen	Unseen	Seen	Unseen	Seen	Unseen
Diffusion Policy [87]	0.76	0.01	0.90	0.01	0.68	0.00	0.45	0.00
OpenVLA [17]	0.82	0.05	0.88	0.07	0.76	0.02	0.55	0.01
UniVLA [15]	0.95	0.16	0.96	0.23	0.95	0.07	0.92	0.05
<i>Learning from videos with the same embodiment</i>								
AWDA [35]	0.71	0.40	0.78	0.50	0.63	0.28	0.51	0.20
Ours	0.98	0.70	0.98	0.74	0.96	0.62	0.92	0.54
<i>Learning from videos with the different embodiment</i>								
AWDA _R [35]	0.69	0.32	0.74	0.41	0.57	0.21	0.49	0.17
Ours_R	0.95	0.71	0.98	0.73	0.95	0.58	0.92	0.51




图 9：真实世界操作任务的示例定性结果。

模型在该配对数据集上进行后训练。推理时，模型以优傲（UR）机械臂执行操作任务的演示视频为输入，为弗兰卡（Franka）机械臂生成相应的控制动作以执行这些任务。其余实验设置与第五-A 节保持一致。

结果。基线方法与本文所提方法的实验结果见表二。尽管使用了来自异构机器人平台的专家演示视频，本文方法在所有实验套件的已见任务与未知任务上均取得了更优的性能。值得注意的是，在未知任务上，本文方法在测试时仅凭单个演示视频即可学习新技能并鲁棒地执行，展现出强大的技能习得能力。

与来自同一机器人平台的演示相比，使用跨具身视频仅导致轻微的性能下降。这种鲁棒性可归因于本文提出的具有循环一致性的潜在动作学习框架，该框架能够有效学习统一的潜在动作空间。这种设计使本文方法能够从不同具身的演示中提取可泛化的操作知识，从而促进从跨机器人视频中有效提取操作知识。

C. 基于人类视频的未知任务学习

实验设置。为验证模型从人类演示视频中习得新技能的能力，我们在自建的人类到机器人（Human2Robot）数据集上训练模型，其中人类提供

表三：基于人类视频的真实世界任务学习实验结果。我们报告了比较方法在已知任务与未知任务上的成功率。已知任务以绿色标示，未知任务以红色标示。

Methods	DP	OpenVLA	UniVLA	AWDA	Ours
Seen	0.64	0.76	0.86	0.74	0.96
Unseen	0.00	0.04	0.10	0.36	0.74

Methods	Flip block	Wipe the tray	Close basket	Place fruit on plate	Stir in tray
Diffusion Policy [87]	0.7	0.6	0.5	0.8	0.6
OpenVLA [17]	0.6	0.8	0.8	0.9	0.7
UniVLA [15]	0.9	0.9	0.8	0.9	0.8
AWDA [35]	0.8	0.6	0.7	0.8	0.8
Ours	1.0	0.9	1.0	1.0	0.9

Methods	Stack block	Place car on basket	Beat the drum	Push the toy	Pour from bowl to plate
Diffusion Policy [87]	0.0	0.0	0.0	0.0	0.0
OpenVLA [17]	0.1	0.1	0.0	0.0	0.0
UniVLA [15]	0.2	0.3	0.0	0.0	0.0
AWDA [35]	0.3	0.4	0.3	0.5	0.3
Ours	0.8	0.8	0.6	0.7	0.8




图 10：真实世界实验设置。

专家演示，弗兰卡（Franka）机器人作为学习代理，构建专家-代理配对数据。我们在 12 个真实世界操作任务上评估 ViVLA，包括 6 个已知任务和 6 个未知任务。评估时，模型接收与各任务对应的人类演示视频作为输入，并为弗兰卡机械臂生成控制动作以执行这些任务。真实世界实验设置如图 10 所示，配备一个七自由度弗兰卡·艾米卡（Franka Emika）机械臂 [90]。任务成功与否通过人工评估判定，成功率基于 10 次随机化物体位置与朝向的试验计算得出。结果。定性结果如图 9 所示，定量分析详见表三。实验结果表明，ViVLA 相较于基线方法取得了显著更优的性能。我们的模型在已知任务上取得了高成功率，验证了专家-代理配对数据生成流水线所生成的机器人数据的高保真度。

在未知任务上，我们的方法展现出有前景的性能，表明其能够有效从人类演示视频中提取操作知识，并将其迁移至真实世界场景中的机器人代理。这些结果证实，ViVLA 通过其潜在动作学习框架有效弥合了人类演示与机器人系统之间的具身差距。学习到的统一潜在动作空间使得知识能够从人类视频有效迁移至机器人代理，促进了新操作技能的高效习得。综合而言，这些发现表明 ViVLA 能够从单个人类演示视频中学习新技能，为终端用户教授机器人新任务提供了一种实用的方法。

D. 鲁棒性分析

物体数量与空间布局。本文探究模型在专家演示视频与智能体机器人操作场景之间，对物体数量与空间分布变化的鲁棒性。实验在五个代表性任务上进行：关闭篮子、盘中搅拌、堆叠积木、击鼓、推动玩具，其中前两个为已知任务，后三个为未知任务。人类演示视频在图 11 (a) 所示的场景中采集，评估则在图 11 (b) 所示的场景中进行。表 IV 中的实验结果表明，尽管训练与评估场景在物体数量和空间分布上存在差异，ViVLA 仍保持较高的成功率并展现出鲁棒的性能。该鲁棒性验证了本文方法在不同环境配置下泛化的有效性。

表 IV: 在不同物体数量与空间分布环境下的成功率。 v_o 表示在不同物体数量与空间分布环境中评估的变体。

Methods	Close basket	Stir in tray	Stack block	Beat the drum	Push the toy	Overall
Ours _{v_o}	0.8	0.7	0.7	0.6	0.7	0.70
Ours	1.0	0.9	0.8	0.6	0.7	0.80




图 11: 物体数量与空间分布变化的鲁棒性分析。已见任务以绿色标示，未见任务以红色标示。




图 12: 相机视角、光照与场景方面的环境变化，变化的相机视角以红色高亮显示。本文的 ViVLA 对这些变化表现出较强的鲁棒性。

环境泛化。 本文探究模型在专家演示视频与智能体机器人场景之间对环境变化的鲁棒性，包括相机视角、光照条件与场景设置的变化。针对每个因素，设计三个实验变体。验证在五个代表性操作任务上进行：关闭篮子、盘中搅拌、堆叠积木、击鼓、推动玩具，其中前两个为已见任务，后三个为未见任务。如图 12 所示，本文方法在不同光照条件下表现出显著的稳定性，性能下降极小。尽管相机视角与场景变化对性能的影响更为明显，但本文方法在不同环境设置下仍保持相当的鲁棒性。

这些结果共同表明，本文方法在不同环境条件下均取得一致的性能，凸显了其适应性与泛化能力。

E. 消融分析

为探究本文 ViVLA 方法的基础设计，我们进行了全面的消融实验。这些设计决策在跨机器人视频的未知任务学习实验中评估，性能通过成功率度量量化。潜在动作预测。我们研究了潜在动作预测在从视频演示中学习的作用。同时移除专家视频和智能体机器人的潜在动作预测会导致性能显著下降。这

表 V: ViVLA 在跨机器人视频任务学习中的消融研究。默认设置以灰色标记。A3C 表示本文提出的以动作为中心的循环一致性。

Methods	LIBERO-Spatial		LIBERO-Object		LIBERO-Goal		LIBERO-Long	
	Seen	Unseen	Seen	Unseen	Seen	Unseen	Seen	Unseen
<i>(a) Latent action prediction</i>								
W/o prediction	0.91	0.48	0.89	0.55	0.81	0.47	0.76	0.33
Genie	0.93	0.65	0.91	0.62	0.87	0.53	0.82	0.41
A3C	0.95	0.71	0.98	0.73	0.95	0.58	0.90	0.51
<i>(b) Latent action learning framework designs</i>								
W/o discriminator	0.89	0.54	0.91	0.59	0.86	0.45	0.81	0.38
Local discriminator	0.93	0.68	0.96	0.69	0.94	0.55	0.87	0.46
W/o Latent action buffer	0.92	0.66	0.97	0.70	0.91	0.50	0.86	0.46
A3C	0.95	0.71	0.98	0.73	0.95	0.58	0.90	0.51
<i>(c) Temporal-spatial masking strategy</i>								
W/o masking	0.94	0.64	0.98	0.67	0.94	0.54	0.91	0.46
Spatial masking	0.95	0.69	0.97	0.72	0.95	0.56	0.90	0.48
Temporal-spatial masking	0.95	0.71	0.98	0.73	0.95	0.58	0.90	0.51
<i>(d) Parallel modeling</i>								
Auto-regressive	0.92	0.63	0.96	0.67	0.93	0.52	0.87	0.35
Parallel modeling	0.95	0.71	0.98	0.73	0.95	0.58	0.90	0.51

表 VI: 语言指令与专家视频演示的消融分析。

Methods	Close basket	Stir in tray	Stack block	Beat the drum	Push the toy	Overall
Ours _{w/o lang}	1.0	0.9	0.7	0.6	0.6	0.76
Ours _{w/o video}	0.9	0.9	0.3	0.1	0.0	0.44
Ours	1.0	0.9	0.8	0.6	0.7	0.80

观察结果表明，潜在动作预测预训练任务增强了模型识别视频中细粒度动作的能力，同时构建了一个统一的潜在动作空间，弥合了专家与智能体之间的具身差距，从而提高了从专家视频中学习新技能的效率。与采用 Genie [49] 进行潜在动作学习的基线方法（一种广泛采用的方法）相比，本文方法取得了显著的性能提升。这一比较验证了循环一致性在学习有效潜在动作表示中的关键作用。实验结果证实，本文提出的具有循环一致性的潜在动作学习框架能够捕获语义上有意义的潜在动作，从而提升性能。

潜在动作学习框架设计。我们进一步研究了具有循环一致性的潜在动作学习框架中关键组件的贡献，特别是潜在动作缓冲区和判别器。实验结果见表 V(b)。移除判别器会导致性能显著下降，表明在没有判别器监督的情况下，解码器可能向编码器泄露关于采样潜在动作的信息，从而削弱本文方法的有效性

潜在动作学习方法。此外，采用常用的局部判别器来监督单个图像块仍会导致性能下降。这验证了我们局部-全局判别器设计的有效性，该设计有效防止了信息泄漏，并缓解了生成视频帧与数据集视频帧之间的分布不匹配，从而提高了潜在动作学习的效率。我们还考察了潜在动作缓冲区的作用。排除缓冲区、直接使用当前批次学习到的潜在动作的变体表现出显著的性能退化。这种退化可归因于潜在动作空间的坍塌，表明维护历史潜在动作的动态缓冲区对于稳定有效的潜在动作学习至关重要。

时空掩码策略。我们研究了时空掩码策略对模型性能的影响。如表五 (c) 所示，完全移除掩码在已见任务上保持了性能，但在未见任务上导致性能下降。这种效果可归因于已见任务存在于训练数据中，使得模型即使在视频理解能力减弱的情况下也能利用固有的操作知识来完成这些任务。相比之下，未见任务要求模型

直接从专家演示视频中提取细粒度操作知识。掩码策略的缺失降低了潜在动作预测预训练在培养鲁棒视频理解能力方面的有效性，从而损害了在新任务上的性能。仅采用空间掩码的变体也表现出性能下降，尽管不如完全移除掩码严重。这表明我们的时空掩码方法创建了一个更具挑战性的预训练目标，要求模型通过整体时空视频理解从部分可见的专家演示中预测动作。并行建模。我们在表五 (d) 中研究了不同的动作建模方法。采用自回归建模导致已见任务性能下降，未见任务性能也下降。这表明自回归建模容易受到捷径学习的影响，从而削弱了潜在动作预测预训练在培养模型理解细粒度操作能力方面的有效性。此外，我们观察到与其他任务套件相比，长套件中未见任务的性能下降尤为明显。这一观察表明，自回归建模对长时程潜在动作预测任务提出了更大的挑战，其中跨扩展序列的预测误差累积加剧了性能下降。语言排除。我们验证了模型对视频演示的语义理解能力。我们仅提供专家视频和智能体观测作为输入，同时移除语言指令，从而要求模型仅从视觉演示中推断任务语义。实验在五个代表性操作任务上进行：关闭篮子、在托盘中搅拌、堆叠积木、敲鼓、推动玩具，其中人类视频作为专家演示。表六中呈现的实验结果表明，即使没有语言指令，我们的方法也能保持稳健的任务完成度，仅表现出轻微的性能下降。这表明 ViVLA 在保持强大的视频语义理解能力的同时，发展了细粒度动作识别能力。模型仅从视觉演示中理解任务目标的能力凸显了我们的方法在从专家视频中学习丰富、语义上有意义的表示方面的有效性。视频排除。我们进一步验证了模型仅使用语言指令操作的能力，而不依赖专家视频演示。在本实验中，我们仅提供语言指令和智能体观测作为输入，同时排除专家演示视频。表六中呈现的实验结果揭示了已见任务和未见任务之间的明显区别。对于已见任务，ViVLA 仅凭语言指令就能保持稳健的性能，取得了有前景的成功率，表明在训练期间有效内化了所学技能。相比之下，没有视频演示时，未见任务的性能显著下降，成功率急剧下降。这一性能差距凸显了我们的方法从视频演示中提取和学习新行为模式的能力，这一能力对于泛化到以前未见过的操作任务至关重要。

六、局限性

在泛化到未见任务的过程中，主要的失败案例源于基本操作环节的误差，尤其是抓取不精确和放置不准确。本文将这类失败归因于两个主要因素：第一，在特定的物体空间布局下，遮挡可能妨碍静态相机捕捉精细的机器人-物体交互细节。第二，由于静态相机主要拍摄背景区域，输入模型的任务相关视觉信息比例仍然有限。相比之下，模型在已见任务上能够利用训练期间习得的内在操作知识来弥补这些感知局限。本文认为，引入腕部相机是应对这一挑战的直接方案，因为它能使模型从第一人称视角持续观察精细的机器人-物体操作，同时大幅提高输入流中任务相关视觉信息的密度。此外，本文指出两个值得改进的方法学方面：（一）实验表明，模型在任务执行过程中展现出有前景的错误恢复能力。然而，这些能力可以通过有针对性的数据增强得到系统性强化。具体而言，在数据流水线的智能体演示生成阶段，可以引入受控的轨迹扰动并配以相应的恢复序列。通过在训练中让模型接触多样的失败场景及其纠正过程，可以使其直接从数据中学习稳健的错误恢复策略，从而提升真实世界部署中的任务执行可靠性。（二）为保持演示质量，当前流水线依赖人工采集的人类视频。未来工作的一个有前景的方向是利用互联网规模的人类视频自动生成专家-智能体配对数据。这需要开发一套稳健的视频过滤、任务识别和质量评估流水线，但有望显著扩展可用于学习可泛化操作策略的训练数据的多样性和规模。

七、结论

本研究提出了 ViVLA，一种通用策略学习架构，能够从单一演示观察中高效习得技能，无需后续微调。该方法处理专家演示视频、机器人智能体观测和语言指令，以预测专家演示中展现的潜在动作以及智能体随后执行的潜在动作。为提升所提 ViVLA 的性能极限，我们开发了一种可扩展的专家-智能体配对数据生成流程，能够从易于获取的视频中合成配对轨迹，并进一步通过开源数据集中的精选配对进行增强。通过该流程，我们构建了一个大规模数据集，包含 892,911 条专家-智能体配对轨迹，涵盖多样化的操作任务。大量实验表明，所提 ViVLA 能够在推理时从单一专家演示中学习未见任务。该方法在 LIBERO

基准上对未见任务实现了超过 30% 的提升,并在利用不同形态的视频时取得了超过 35% 的提升。此外,该方法能有效从人类视频中蒸馏知识,在真实世界未见任务上展现出超过 38% 的增益。

参考文献

- [1] A. Liu, B. Feng, *et al.*, “Deepseek-v3 technical report,” *arXiv preprint arXiv:2412.19437*, 2024.
- [2] J. Bai, S. Bai, *et al.*, “Qwen technical report,” *arXiv preprint arXiv:2309.16609*, 2023.
- [3] H. Touvron, L. Martin, *et al.*, “Llama 2: Open foundation and fine-tuned chat models,” *arXiv preprint arXiv:2307.09288*, 2023.
- [4] J. Achiam, S. Adler, *et al.*, “Gpt-4 technical report,” *arXiv preprint arXiv:2303.08774*, 2023.
- [5] S. Bai, K. Chen, *et al.*, “Qwen2. 5-vl technical report,” *arXiv preprint arXiv:2502.13923*, 2025.
- [6] K. Team, A. Du, *et al.*, “Kimi-vl technical report,” *arXiv preprint arXiv:2504.07491*, 2025.
- [7] C. Team, “Chameleon: Mixed-modal early-fusion foundation models,” *arXiv preprint arXiv:2405.09818*, 2024.
- [8] H. Liu, C. Li, *et al.*, “Visual instruction tuning,” *Advances in neural information processing systems*, vol. 36, pp. 34 892–34 916, 2023.
- [9] B. Xiong, B. Chen, *et al.*, “Bluelm-2.5-3b technical report,” *arXiv preprint arXiv:2507.05934*, 2025.
- [10] M. J. Kim, K. Pertsch, *et al.*, “Openvla: An open-source vision-language-action model,” *arXiv preprint arXiv:2406.09246*, 2024.
- [11] K. Black, N. Brown, *et al.*, “ π_0 : A vision-language-action flow model for general robot control,” *arXiv preprint arXiv:2410.24164*, 2024.
- [12] P. Intelligence, K. Black, *et al.*, “ $\pi_{0.5}$: a vision-language-action model with open-world generalization,” *arXiv preprint arXiv:2504.16054*, 2025.
- [13] D. Qu, H. Song, *et al.*, “Spatialvla: Exploring spatial representations for visual-language-action model,” *arXiv preprint arXiv:2501.15830*, 2025.
- [14] C. Fan, X. Jia, *et al.*, “Interleave-vla: Enhancing robot manipulation with interleaved image-text instructions,” *arXiv preprint arXiv:2505.02152*, 2025.
- [15] Q. Bu, Y. Yang, *et al.*, “Univla: Learning to act anywhere with task-centric latent actions,” *arXiv preprint arXiv:2505.06111*, 2025.
- [16] B. Zitkovich, T. Yu, *et al.*, “Rt-2: Vision-language-action models transfer web knowledge to robotic control,” in *Conference on Robot Learning*. PMLR, 2023, pp. 2165–2183.
- [17] M. J. Kim, K. Pertsch, *et al.*, “Openvla: An open-source vision-language-action model,” *arXiv preprint arXiv:2406.09246*, 2024.
- [18] K. Black, N. Brown, *et al.*, “ π_0 : A vision-language-action flow model for general robot control,” *arXiv preprint arXiv:2410.24164*, 2024.
- [19] J. Bjorck, F. Castañeda, *et al.*, “Gr00t n1: An open foundation model for generalist humanoid robots,” *arXiv preprint arXiv:2503.14734*, 2025.
- [20] K. Pertsch, K. Stachowicz, *et al.*, “Fast: Efficient action tokenization for vision-language-action models,” *arXiv preprint arXiv:2501.09747*, 2025.
- [21] A. O’Neill, A. Rehman, *et al.*, “Open x-embodiment: Robotic learning datasets and rt-x models: Open x-embodiment collaboration 0,” in *2024 IEEE International Conference on Robotics and Automation (ICRA)*. IEEE, 2024, pp. 6892–6903.
- [22] Q. Bu, J. Cai, *et al.*, “Agibot world colosseum: A large-scale manipulation platform for scalable and intelligent embodied systems,” *arXiv preprint arXiv:2503.06669*, 2025.
- [23] Y. Duan, M. Andrychowicz, *et al.*, “One-shot imitation learning,” *Advances in neural information processing systems*, vol. 30, 2017.
- [24] C. Finn, P. Abbeel, *et al.*, “Model-agnostic meta-learning for fast adaptation of deep networks,” in *International conference on machine learning*. PMLR, 2017, pp. 1126–1135.
- [25] T. Yu, C. Finn, *et al.*, “One-shot imitation from observing humans via domain-adaptive meta-learning,” *arXiv preprint arXiv:1802.01557*, 2018.
- [26] P. Sharma, D. Pathak, *et al.*, “Third-person visual imitation learning via decoupled hierarchical controller,” *Advances in Neural Information Processing Systems*, vol. 32, 2019.
- [27] E. Jang, A. Irpan, *et al.*, “Bc-z: Zero-shot task generalization with robotic imitation learning,” in *Conference on Robot Learning*. PMLR, 2022, pp. 991–1002.
- [28] M. Ahn, A. Brohan, *et al.*, “Do as i can, not as i say: Grounding language in robotic affordances,” *arXiv preprint arXiv:2204.01691*, 2022.
- [29] S. James, M. Bloesch, *et al.*, “Task-embedded control networks for few-shot imitation learning,” in *Conference on robot learning*. PMLR, 2018, pp. 783–795.
- [30] A. Bonardi, S. James, *et al.*, “Learning one-shot imitation from humans without humans,” *IEEE Robotics and Automation Letters*, vol. 5, no. 2, pp. 3533–3539, 2020.
- [31] D. Pathak, P. Mahmoudieh, *et al.*, “Zero-shot visual imitation,” in *Proceedings of the IEEE conference on computer vision and pattern recognition workshops*, 2018, pp. 2050–2053.
- [32] S. Dasari and A. Gupta, “Transformers for one-shot visual imitation,” in *Conference on Robot Learning*. PMLR, 2021, pp. 2071–2084.
- [33] Z. Mandi, F. Liu, *et al.*, “Towards more generalizable one-shot visual imitation learning,” in *2022 International conference on robotics and automation (ICRA)*. IEEE, 2022, pp. 2434–2444.
- [34] C. Finn, T. Yu, *et al.*, “One-shot visual imitation learning via meta-learning,” in *Conference on robot learning*. PMLR, 2017, pp. 357–368.
- [35] M. Chang and S. Gupta, “One-shot visual imitation via attributed waypoints and demonstration augmentation,” *arXiv preprint arXiv:2302.04856*, 2023.
- [36] R. G. Goswami, P. Krishnamurthy, *et al.*, “Osvi-wm: One-shot visual imitation for unseen tasks using world-model-guided trajectory generation,” *arXiv preprint arXiv:2505.20425*, 2025.
- [37] J. Yang, C. Glossop, *et al.*, “Pushing the limits of cross-embodiment learning for manipulation and navigation,” 2024.
- [38] D. Ghosh, H. Walke, *et al.*, “Octo: An open-source generalist robot policy,” in *RSS*, 2024.
- [39] O. M. Team, D. Ghosh, *et al.*, “Octo: An open-source generalist robot policy,” 2024.
- [40] C. Wen, X. Lin, *et al.*, “Any-point trajectory modeling for policy learning,” *arXiv preprint arXiv:2401.00025*, 2023.
- [41] C. Yuan, C. Wen, *et al.*, “General flow as foundation affordance for scalable robot learning,” *arXiv preprint arXiv:2401.11439*, 2024.
- [42] C. Gao, H. Zhang, *et al.*, “Flip: Flow-centric generative planning as general-purpose manipulation world model,” 2024.
- [43] M. Xu, Z. Xu, *et al.*, “Flow as the cross-domain manipulation interface,” *arXiv preprint arXiv:2407.15208*, 2024.
- [44] N. Karaev, I. Makarov, *et al.*, “Cotracker3: Simpler and better point tracking...” *arXiv preprint*, 2024.
- [45] Nikita, I. Rocco, *et al.*, “Cotracker: It is better to track together,” in *ECCV*.
- [46] “Tapir: Tracking any point with per-frame initialization and...” in *ICCV*, 2023.
- [47] S. Ye, J. Jang, *et al.*, “Latent action pretraining from videos,” *arXiv preprint arXiv:2410.11758*, 2024.
- [48] Y. Chen, Y. Ge, *et al.*, “Moto: Latent motion token as the bridging language for robot manipulation,” *arXiv preprint arXiv:2412.04445*, vol. 8, 2024.
- [49] J. Bruce, M. D. Dennis, *et al.*, “Genie: Generative interactive environments,” in *Forty-first International Conference on Machine Learning*, 2024.
- [50] X. Chen, J. Guo, *et al.*, “Igor: Image-goal representations are

- the atomic control units for foundation models in embodied ai,” *arXiv preprint arXiv:2411.00785*, 2024.
- [51] M. Laskin, K. Lee, *et al.*, “Reinforcement learning with augmented data,” *Advances in neural information processing systems*, vol. 33, pp. 19 884–19 895, 2020.
 - [52] D. Yarats, I. Kostrikov, *et al.*, “Image augmentation is all you need: Regularizing deep reinforcement learning from pixels,” in *International conference on learning representations*, 2021.
 - [53] A. Mandlekar, D. Xu, *et al.*, “What matters in learning from offline human demonstrations for robot manipulation,” *arXiv preprint arXiv:2108.03298*, 2021.
 - [54] A. Mandlekar, S. Nasiriany, *et al.*, “Mimicgen: A data generation system for scalable robot learning using human demonstrations,” *arXiv preprint arXiv:2310.17596*, 2023.
 - [55] L. Fan, G. Wang, *et al.*, “Secant: Self-expert cloning for zero-shot generalization of visual policies,” *arXiv preprint arXiv:2106.09678*, 2021.
 - [56] N. Hansen and X. Wang, “Generalization in reinforcement learning by soft data augmentation,” in *2021 IEEE International Conference on Robotics and Automation (ICRA)*. IEEE, 2021, pp. 13 611–13 617.
 - [57] N. Hansen, H. Su, *et al.*, “Stabilizing deep q-learning with convnets and vision transformers under data augmentation,” *Advances in neural information processing systems*, vol. 34, pp. 3680–3693, 2021.
 - [58] A. Mandlekar, S. Nasiriany, *et al.*, “Mimicgen: A data generation system for scalable robot learning using human demonstrations,” *arXiv preprint arXiv:2310.17596*, 2023.
 - [59] T. Yu, T. Xiao, *et al.*, “Scaling robot learning with semantically imagined experience,” *arXiv preprint arXiv:2302.11550*, 2023.
 - [60] Z. Chen, Z. Mandi, *et al.*, “Semantically controllable augmentations for generalizable robot learning,” *The International Journal of Robotics Research*, p. 02783649241273686, 2024.
 - [61] Z. Chen, S. Kiami, *et al.*, “Genaug: Retargeting behaviors to unseen situations via generative augmentation,” *arXiv preprint arXiv:2302.06671*, 2023.
 - [62] Z. Mandi, H. Bharadhwaj, *et al.*, “Cacti: A framework for scalable multi-task multi-scene visual imitation learning,” *arXiv preprint arXiv:2212.05711*, 2022.
 - [63] L. Y. Chen, K. Hari, *et al.*, “Mirage: Cross-embodiment zero-shot policy transfer with cross-painting,” 2024.
 - [64] S. Tian, B. Wulfe, *et al.*, “View-invariant policy learning via zero-shot novel view synthesis,” *arXiv preprint arXiv:2409.03685*, 2024.
 - [65] E. Ameperosa, J. A. Collins, *et al.*, “Rocoda: Counterfactual data augmentation for data-efficient robot learning from demonstrations,” in *2025 IEEE International Conference on Robotics and Automation (ICRA)*. IEEE, 2025, pp. 13 250–13 256.
 - [66] L. Y. Chen, C. Xu, *et al.*, “Rovi-aug: Robot and viewpoint augmentation for cross-embodiment robot learning,” *arXiv preprint arXiv:2409.03403*, 2024.
 - [67] S. Yang, W. Yu, *et al.*, “Novel demonstration generation with gaussian splatting enables robust one-shot manipulation,” *arXiv preprint arXiv:2504.13175*, 2025.
 - [68] M. Oquab, T. Darcet, *et al.*, “Dinov2: Learning robust visual features without supervision,” *arXiv preprint arXiv:2304.07193*, 2023.
 - [69] A. Van Den Oord, O. Vinyals, *et al.*, “Neural discrete representation learning,” *Advances in neural information processing systems*, vol. 30, 2017.
 - [70] E. J. Hu, Y. Shen, *et al.*, “Lora: Low-rank adaptation of large language models,” *ICLR*, vol. 1, no. 2, p. 3, 2022.
 - [71] G. Pavlakos, D. Shan, *et al.*, “Reconstructing hands in 3d with transformers,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024, pp. 9826–9836.
 - [72] P. J. Besl and N. D. McKay, “Method for registration of 3-d shapes,” in *Sensor fusion IV: control paradigms and data structures*, vol. 1611. Spie, 1992, pp. 586–606.
 - [73] S. Rusinkiewicz and M. Levoy, “Efficient variants of the icp algorithm,” in *Proceedings third international conference on 3-D digital imaging and modeling*. IEEE, 2001, pp. 145–152.
 - [74] G. Chen, M. Wang, *et al.*, “Fmimic: Foundation models are fine-grained action learners from human videos,” *The International Journal of Robotics Research*, p. 02783649251377335, 2025.
 - [75] B. Wen, W. Yang, *et al.*, “Foundationpose: Unified 6d pose estimation and tracking of novel objects,” *arXiv preprint arXiv:2312.08344*, 2023.
 - [76] J. Xiang, Z. Lv, *et al.*, “Structured 3d latents for scalable and versatile 3d generation,” in *Proceedings of the Computer Vision and Pattern Recognition Conference*, 2025, pp. 21 469–21 480.
 - [77] H.-S. Fang, C. Wang, *et al.*, “Anygrasp: Robust and efficient grasp perception in spatial and temporal domains,” *IEEE Transactions on Robotics*, 2023.
 - [78] N. Reimers and I. Gurevych, “Sentence-bert: Sentence embeddings using siamese bert-networks,” in *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 11 2019. [Online]. Available: <http://arxiv.org/abs/1908.10084>
 - [79] A. Brohan, N. Brown, *et al.*, “Rt-1: Robotics transformer for real-world control at scale,” *arXiv preprint arXiv:2212.06817*, 2022.
 - [80] H. R. Walke, K. Black, *et al.*, “Bridgedata v2: A dataset for robot learning at scale,” in *Conference on Robot Learning*. PMLR, 2023, pp. 1723–1736.
 - [81] A. Khazatsky, K. Pertsch, *et al.*, “Droid: A large-scale in-the-wild robot manipulation dataset,” *arXiv preprint arXiv:2403.12945*, 2024.
 - [82] C. Lynch, A. Wahid, *et al.*, “Interactive language: Talking to robots in real time,” *IEEE Robotics and Automation Letters*, 2023.
 - [83] J. Luo, C. Xu, *et al.*, “Fmb: a functional manipulation benchmark for generalizable robotic learning,” *The International Journal of Robotics Research*, vol. 44, no. 4, pp. 592–606, 2025.
 - [84] R. Hoque, P. Huang, *et al.*, “Egodex: Learning dexterous manipulation from large-scale egocentric video,” *arXiv preprint arXiv:2505.11709*, 2025.
 - [85] A. Padalkar, A. Pooley, *et al.*, “Open x-embodiment: Robotic learning datasets and rt-x models,” *arXiv preprint arXiv:2310.08864*, 2023.
 - [86] K. Grauman, A. Westbury, *et al.*, “Ego4d: Around the world in 3,000 hours of egocentric video,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2022, pp. 18 995–19 012.
 - [87] C. Chi, Z. Xu, *et al.*, “Diffusion policy: Visuomotor policy learning via action diffusion,” *The International Journal of Robotics Research*, p. 02783649241273668, 2023.
 - [88] S. Karamcheti, S. Nair, *et al.*, “Prismatic vlms: Investigating the design space of visually-conditioned language models,” in *Forty-first International Conference on Machine Learning*, 2024.
 - [89] B. Liu, Y. Zhu, *et al.*, “Libero: Benchmarking knowledge transfer for lifelong robot learning,” *Advances in Neural Information Processing Systems*, vol. 36, 2024.
 - [90] S. Haddadin, S. Parusel, *et al.*, “The franka emika robot: A reference platform for robotics research and education,” *IEEE Robotics & Automation Magazine*, vol. 29, no. 2, pp. 46–64, 2022.