

State Backdoor: Towards Stealthy Real-world Poisoning Attack on Vision-Language-Action Model in State Space

Ji Guo, *Student Member, IEEE*, Wenbo Jiang*, *Member, IEEE*, Yansong Lin, *Member, IEEE*, Yijing Liu, *Member, IEEE*, Ruichen Zhang, *Member, IEEE*, Guomin Lu, *Member, IEEE*, Aiguo Chen, *Member, IEEE*, Xinshuo Han, *Member, IEEE*, Hongwei Li, *Fellow, IEEE*

摘要——视觉-语言-动作（Vision-Language-Action, VLA）模型广泛应用于机器人等安全关键的具身智能应用中。然而，其复杂的多模态交互也暴露了新的安全漏洞。本文研究了 VLA 模型中的后门威胁，即恶意输入导致有针对性的错误行为，同时在干净数据上保持性能。现有的后门方法主要依赖于在视觉模态中插入可见触发器，由于环境变化，这些方法在实际场景中鲁棒性差且隐蔽性低。为克服这些局限性，我们提出了状态后门（State Backdoor），这是一种新颖且实用的后门攻击，利用机器人手臂的初始状态作为触发器。为优化触发器的隐蔽性和有效性，我们设计了一种偏好引导的遗传算法（Preference-guided Genetic Algorithm, PGA），高效搜索状态空间以找到最小但有效的触发器。在五个代表性 VLA 模型和五个真实世界任务上的大量实验表明，我们的方法在不影响良性任务性能的情况下实现了超过 90% 的攻击成功率，揭示了具身智能系统中一个未被充分探索的漏洞。

索引词——后门攻击，具身智能安全，视觉-语言-动作模型

I. 引言

随着用于图像识别、目标检测和语义理解的 AI 模型在移动设备上的广泛部署，最近的研究 [1] 也开始探索在移动平台上部署视觉-语言-动作（VLA）[2] - [4] 模型。VLA 模型将视觉感知、自然语言理解和动作生成集成到一个统一的具身智能框架中。这些模型使机器人能够解释复杂的视觉场景并遵循人类指令执行复杂任务。然而，最近的研究表明 VLA 模型容易受到各种攻击。这些威胁通常分为三类：对抗性攻击 [5] - [9]、越狱




图 1: 针对视觉-语言-动作模型的状态后门攻击概览。攻击者通过选择部分样本、注入特定触发状态并将其对应的动作标签篡改为攻击者定义的目标，从而毒化训练数据。在该毒化数据集上训练后，后门视觉-语言-动作模型在干净输入上表现正常，但一旦遇到触发状态，便会执行攻击者指定的动作。

攻击 [10] - [13]，以及后门攻击 [14]、[15]，其中后门攻击因其隐蔽性和严重性被认为最具威胁 [14]。后门视觉-语言-动作模型在干净输入上表现正常，但在遇到触发样本时执行攻击者指定的目标动作。在现实场景中，例如机械臂，后门模型可能撞击附近物体、对易碎物品施加过大力度，或不可预测地移向人类，从而造成物理风险。以往针对视觉-语言-动作模型的后门攻击 [14]、[15] 主要依赖可见物体作为触发器来操纵视觉输入并激活后门行为。然而，这些方法通常在模拟环境中开发和评估，并未使用来自真实世界的毒化数据，因而无法捕捉现实条件的复杂性和多变性。实际上，基于物体的触发器其视觉外观对光照、视角、背景乃至空间位置的变化高度敏感，往往导致攻击性能不可靠。此外，使用显眼的物理触发器损害了隐蔽性，使得此类攻击易于被察觉，在现实世界中实用性较低。

* 通讯作者

J. Guo, Y. Lin, A. Chen 和 G. Lu 隶属于智能实验室
中国电子科技大学协同计算实验室（吉果，0524@gmail.com；严松林，yansonglin@std.uestc.edu.cn；卢国明，luguom@uestc.edu.cn；陈爱国，aqchen@uestc.edu.cn）；刘怡静，中国电子科技大学无线通信国家重点实验室（liuyijing@uestc.edu.cn）；蒋文博、李宏伟，中国电子科技大学计算机科学与工程学院（wenbo.jiang@uestc.edu.cn，hongweili@uestc.edu.cn）；韩星硕，南京航空航天大学计算机科学与技术学院（xingshuo.han@nuaa.edu.cn）；张瑞晨，新加坡南洋理工大学计算与数据科学学院（ruichen.zhang@ntu.edu.sg）。




图 2: 基于视觉-语言-动作模型的六自由度机械臂控制框架概览。该模型以任务指令、六自由度机械臂的初始状态以及环境视觉观测作为输入，输出一系列动作标记，引导机器人完成指定任务。

为克服这些局限性，本文提出状态后门 (State Backdoor)，一种针对真实世界场景下视觉-语言-动作 (VLA) 模型的可靠且隐蔽的基于投毒的后门攻击方法 (见图 1)。本文的核心思想是利用机械臂的初始状态 $\mathbf{s}_0$ 作为触发器。与图像中的视觉特征不同，机械臂的状态信息更为稳定且一致：即使在不同环境中，初始状态往往保持不变 [16]。这种一致性确保了触发状态的有效性，从而实现可靠的后门攻击。然而，寻找合适的触发器 (状态空间偏移) 并非易事：较大的偏移会使被触发机械臂的初始状态显得不真实 (见图 9)，而较小的偏移可能导致模型无法有效学习触发模式，从而降低攻击成功率。为应对真实世界场景中的这一挑战，本文设计了一种偏好引导遗传算法 (Preference-guided Genetic Algorithm, PGA)，这是一种无梯度优化方法，能够在黑盒场景下有效搜索最优触发器 $\mathbf{s}_0$ 。具体而言，本文利用代理模型的后门损失来估计每个候选触发器的有效性。在 PGA 搜索过程中，本文引入对最小状态空间偏移的偏好，以引导优化朝向隐蔽且有效的触发器。本文进行了大量实验，以证明 PGA 相较于其他优化方法的优越性。值得注意的是，本文所提方法还具有新颖且有益的应用。具体而言，该方法可用于 VLA 数据集的水印保护。通过将机械臂设置为触发状态，本文能够验证某个模型是否在本文的投毒数据集上训练过：使用过该数据集的模型将表现出预定义行为，而未使用过该数据集的模型则不会出现此类响应。本文将在后文对该应用进行详细讨论。本文在五个代表性 VLA 模型 (ACT[17]、DP[18]、SmolVLA[4]、 π_0 [19] 和 OpenVLA[2]) 上，使用 SO101 机械臂 [20] 在五个标准真实世界任务中评估了所提方法。大量实验表明，本文方法在保持模型正常功能的同时，达到了 90% 的攻击成功率 (ASR)。此外，该方法对经典后门防御技术 (如微剪枝 [21] 和图像压缩 [22]) 仍然有效。

本文的主要贡献总结如下：

- 我们首次提出利用状态空间作为触发器对视觉-语言-动作模型发起后门攻击。与传统基于视觉的触发器相比，我们的方法实现了更稳定且更不易察觉的攻击。

- 我们提出 PGA，一种高效的搜索算法，用于寻找最优触发状态，在保证攻击有效性的同时保持触发器的隐蔽性。

与其他优化方法相比，PGA 实现了更短的时间开销，同时与随机选择的设置相比提供了更好的隐蔽性。

- 我们在真实世界和仿真环境中对多种视觉-语言-动作模型进行了广泛实验。实验结果表明，我们的方法显著优于现有方法。

II. 背景与相关工作

A. 视觉-语言-动作模型

视觉-语言-动作 (VLA) 模型 [2]、[3] 旨在整合视觉感知、语言理解和动作生成，使具身智能体能够解读高层自然语言指令并执行相应的低层控制动作。典型的 VLA 架构将视觉语言模型 (VLM) 与动作专家相结合 (见图 2)。本文考虑将 VLA 模型应用于六自由度 (6-DoF) 机械臂的控制，这是 VLA 系统最典型的应用场景之一。需注意，本文方法同样适用于其他需要初始状态配置的机器人系统。具体而言，VLA 模型以自然语言任务指令 $\mathbf{T}$ 、机械臂初始状态 $\mathbf{s}_0$ 以及来自环境的视觉观测 $\mathbf{I}_t$ 作为输入。初始状态 $\mathbf{s}_0 \in \mathbb{R}^6$ 表示六自由度机械臂的关节位置，定义如下：

$$\mathbf{s}_0 = [\theta_1, \theta_2, \theta_3, \theta_4, \theta_5, \theta_6], \quad (1)$$

其中 θ_i 表示第 i 个关节的角位置。基于 $(\mathbf{T}, \mathbf{s}_0, \mathbf{I}_t)$ ，VLA 模型通过策略函数生成低层控制动作 $\mathbf{a}$ ，定义如下：

$$\mathbf{a} = \pi(\mathbf{T}, \mathbf{s}_0, \mathbf{I}_t), \quad \mathbf{a} \in \mathbb{R}^6, \quad (2)$$

其中 $\mathbf{a}$ 通常表示机械臂在每个时间步需执行的目标关节位移或速度。

表 I: 不同 VLA 后门方法的比较

Method	Trigger Stealthiness	Real-world Attacks	Black-box Attacks
BadVLA [15]	✗	✗	✗
TrojanRobot [14]	✗	✓	✗
State Backdoor (Ours)	✓	✓	✓

B. 对 VLA 模型的攻击

后门攻击。针对 VLA 模型的后门攻击旨在植入隐藏行为，使模型在干净输入上表现正常，但在遇到触发输入时产生攻击者指定的输出，通常是任务失败动作。BadVLA[15] 通过在仿真中使用中毒数据训练模型来注入后门，并精心优化训练过程以保持模型在良性输入上的性能。相比之下，TrojanRobot[14] 在 VLA 架构中引入专门的后门组件，在特定条件下激活恶意行为。然而，现有的 VLA 后门攻击仅依赖合成中毒数据，并在白盒设置下进行，可访问训练流程。此外，由于这些攻击通常依赖可见的物体触发器，它们极易受环境变化影响，导致在实际部署中有效性差且隐蔽性有限。现有 VLA 后门攻击的比较总结于表 I。

对抗攻击。针对视觉-语言-动作（VLA）模型的对抗攻击旨在通过扰动输入信息来诱导错误动作 [5] – [9]。根据 VLA 模型的梯度信息是否可获取，这些攻击可分为白盒和黑盒设置。此外，根据攻击目标，它们可分为非定向攻击，即仅旨在导致任务失败，或定向攻击，即试图驱使智能体执行特定的非期望行为。

越狱攻击。VLA 模型通常在训练期间进行对齐以确保安全性，从而拒绝不适当的用户命令（例如，“杀死这个人”）。针对 VLA 模型的越狱攻击旨在绕过此类安全约束，使模型能够执行危险或被禁止的动作 [10] – [13]。这些攻击通常通过优化输入指令和精心设计提示来实施，使 VLA 模型将不安全命令误解为有效且可执行的命令。

III. 视觉-语言-动作模型的公式化

模型

VLA 模型 [2], [4] 旨在赋予具身智能体感知环境、理解语言指令并执行适当动作的能力。给定视觉观测 $\mathbf{I}_t$ 、文本指令 $\mathbf{T}$ 以及机器人当前的本体感受状态 $\mathbf{s}_t$ ，模型学习一个由 θ 参数化的多模态策略 π_θ ，该策略预测下一个动作 $\mathbf{a}_t$ ，定义如下：

$$\pi_\theta : (\mathbf{I}_t, \mathbf{T}, \mathbf{s}_t) \rightarrow \mathbf{a}_t. \quad (3)$$

因此，VLA 模型作为一个统一的策略，将感知、语言理解和控制融合到一个单一的决策框架中。

模型架构。典型的视觉-语言-动作框架由四个主要组件构成：视觉编码器 f_v 、语言编码器 f_l 、状态编码器 f_s 以及多模态融合模块 f_m ，它们与任务特定的动作解码器 f_a 联合训练。形式上，时间步

t 的多模态表示为

$$\mathbf{z}_t = f_m(f_v(\mathbf{I}_t), f_l(\mathbf{T}), f_s(\mathbf{s}_t)), \quad (4)$$

其中 $\mathbf{z}_t$ 同时捕获语义和物理任务信息。最终动作随后由 $\mathbf{z}_t$ 按如下方式产生：

$$p_\theta(\mathbf{a}_t | \mathbf{I}_t, \mathbf{T}, \mathbf{s}_t) = f_a(\mathbf{z}_t), \quad (5)$$

根据任务设置，该动作可以表示离散动作分布或连续控制策略。训练流程。训练视觉-语言-动作模型通常依赖于从遥操作或强化学习中收集的大规模演示数据集

$\mathcal{D} = \{(\mathbf{I}_t, \mathbf{T}, \mathbf{s}_t, \mathbf{a}_t)\}_{t=1}^N$ 。目标是最小化预测动作与演示动作之间的差异，通常通过行为克隆实现，定义如下：

$$\mathcal{L}_{BC}(\theta) = -\mathbb{E}_{(\mathbf{I}, \mathbf{T}, \mathbf{s}, \mathbf{a}) \sim \mathcal{D}} [\log p_\theta(\mathbf{a} | \mathbf{I}, \mathbf{T}, \mathbf{s})]. \quad (6)$$

推理流程。在部署期间，训练好的视觉-语言-动作模型接收实时摄像头输入 $\mathbf{I}_t$ 、自然语言指令 $\mathbf{T}$ 以及实时机器人状态 $\mathbf{s}_t$ 。编码器将这些输入投影到共享潜空间中，随后融合模块生成动作嵌入 $\mathbf{z}_t$ 。动作解码器 f_a 随后输出相应的电机指令 $\mathbf{a}_t$ 以供机器人执行。该过程可表示为一个迭代闭环系统：

$$\mathbf{a}_t = \pi_\theta(\mathbf{I}_t, \mathbf{T}, \mathbf{s}_t), \quad \mathbf{s}_{t+1} = \mathcal{F}(\mathbf{s}_t, \mathbf{a}_t), \quad (7)$$

其中 $\mathcal{F}$ 表示环境或机器人动力学模型。通过反复交互，机器

$\{\mathbf{a}_t\}_{t=1}^T$ 人执行一系列动作以完成所需任务。

四、威胁模型

攻击场景。考虑到视觉-语言-动作（VLA）模型的实际应用，它们通常以预训练权重初始化，然后在从目标部署环境收集的真实世界数据集上进行微调。因此，我们的攻击场景假设攻击者在此微调阶段利用真实世界数据进行数据投毒。需要指出的是，我们的设置不同于以往针对 VLA 模型的投毒攻击 [15]，后者通常依赖于在模拟环境中投毒数据。值得注意的是，当数据集在线发布且 VLA 模型从头开始训练时，我们的方法同样适用。

攻击者能力。我们考虑一种黑盒数据投毒设置 [23], [24]，其中攻击者只能访问训练数据集，而对受害者模型一无所知，包括其架构、参数或训练过程。与先前针对 VLA 模型的投毒攻击相比，我们假设攻击者无法操纵训练流程或

改变模型架构。相反，我们允许攻击者利用一个替代模型来近似受害者模型，以制作中毒数据 [25]。在推理阶段，我们假设攻击者只能像先前的后门攻击那样扰动受害者机械臂的初始状态 [16]、[26]、[27]。为什么初始状态的可操纵性是现实的。攻击者能够操纵机器人初始状态的假设既有实际依据，也在现有文献中被广泛认可。具体而言，这一假设从两个互补的角度得到论证：• 实际场景。在真实部署中，机械臂和具身智能体经常进行校准和维护程序，期间技术人员会手动重置或调整初始关节配置 [28] – [32]。我们假设对手充当负责机械臂定期维护和校准的技术人员。此类人员通常拥有对系统的合法物理访问权限，并且需要执行标准操作，如关节校准、姿态重置或安全诊断。这些程序本质上涉及在每个任务之前将机器人的关节设置到预定义位置，为微妙的操纵提供了现实机会。此外，视觉语言动作模型通常部署在封闭环境中，如工厂车间或物流分拣站，访问仅限于内部员工。即使是基于视觉的攻击，安装物理触发器也需要授权人员的合作或干预。• 常见研究设定。从研究角度看，初始状态的可控性或扰动是强化学习 [33] – [35] 和机器人安全研究 [16]、[26]、[27] 中一个成熟的假设。初始状态在决定下游策略行为中起着关键作用，使其成为研究后门或基于扰动的威胁的自然且有效的攻击面。

攻击目标。本文的攻击设计旨在满足以下三个目标：• 功能保持性。嵌入的后门应对受害模型在干净测试样本上的性能影响最小。• 有效性。与先前针对视觉-语言-动作（VLA）模型的后门攻击类似 [14]、[15]，本文方法同样采用非定向攻击目标。触发样本应以高概率可靠地导致任务失败。例如，在针对抓取-放置任务的非定向攻击中，机器人未能将物体放入指定区域，如错过目标箱或中途掉落物体。• 隐蔽性。触发样本应保持不显眼，并在推理过程中避免被检测到，尤其是在人工检查下。

五、方法

本文首次利用机械臂的特定初始状态作为针对视觉-语言-动作（VLA）模型后门攻击的触发器。在

与先前依赖插入视觉对象作为触发器的方法相比，本文方法能够实现更可靠且更隐蔽的攻击。此外，本文提出了一种渐进式梯度攻击（PGA）来搜索最优触发状态，在确保攻击有效的同时使状态变化更不易察觉。

A. 概述

如图 3 所示，本文攻击包含三个主要阶段。首先，通过将特定初始状态与目标动作关联来生成中毒数据。为提升攻击的有效性与隐蔽性，本文设计了一种投影梯度攻击（PGA）以在状态空间内优化触发状态。其次，在中毒数据集上微调视觉-语言-动作（VLA）模型以植入后门行为。最后，在推理阶段，通过将机械臂设置到优化后的触发状态来激活攻击，导致模型任务失败。

B. PGA 的目标函数

为确保攻击有效性与隐蔽性，本文定义了一个多目标损失函数，以平衡三项准则：攻击成功率、干净功能保持以及触发器隐蔽性。

(1) 攻击有效性。我们评估触发器欺骗模型产生期望目标动作的程度，即攻击有效性，如下所示：

$$f_1(t) = \frac{1}{|\mathcal{D}_{\text{poison}}|} \sum_{(x_i, a_i^{\text{fail}}) \in \mathcal{D}_{\text{poison}}} \mathcal{L}(f_s(x_i, s_{\text{trig}}), a_i^{\text{fail}}), \quad (8)$$

其中 f_s 是一个轻量级代理模型，经过简短训练用于评分。

(2) 功能保持。该项鼓励模型在正常初始状态下保持干净行为，即功能保持，如下所示：

$$f_2(t) = \frac{1}{|\mathcal{D}_{\text{clean}}|} \sum_{(x_i, a_i^{\text{normal}}) \in \mathcal{D}_{\text{clean}}} \mathcal{L}(f_s(x_i, s_0), a_i^{\text{normal}}). \quad (9)$$

(3) 隐蔽性。我们最小化触发器扰动的大小，即隐蔽性，定义如下：

$$f_3(t) = \|t\|_2^2, \quad (10)$$

其中 $t = s_{\text{trig}} - s_0$ 。

最终复合目标函数为：

$$\mathcal{O}(t) = \lambda_1 f_1(t) + \lambda_2 f_2(t) + \lambda_3 f_3(t), \quad (11)$$

其中 λ_1 、 λ_2 和 λ_3 平衡三个组成部分。

C. PGA 的搜索过程

为了高效地最小化 $\mathcal{O}(t)$ ，本文采用投影梯度上升法（PGA），该方法融合软约束以引导搜索朝向有效且隐蔽的触发器。每个候选 t 是施加于 s_0 的扰动向量。搜索过程如下：

• **初始化：**生成 N 个候选触发器 $\{t_i\}_{i=1}^N$ ，采样自均匀分布。




图 3: 状态后门流程。首先, 采用投影梯度上升法搜索隐蔽的初始状态触发器, 使其在物理和视觉上保持合理。随后, 利用这些发现的状态合成中毒训练样本, 构建隐蔽的中毒数据集。其次, 将中毒数据按指定投毒率混入原始训练集, 训练或微调视觉语言动作模型, 得到后门模型, 该模型在干净输入上保持正常性能, 同时在触发状态下学习恶意映射。最后, 在部署阶段, 攻击者通过将机器人初始关节位置配置为发现的触发状态来激活后门, 导致模型执行恶意行为。




图 4: 相反动作轨迹

- **Evaluation:** For each candidate t_i , compute:

$$f_3(t_i) = \|t_i\|_2^2, \quad p_i = \begin{cases} 0, & f_3(t_i) \leq \delta \\ (f_3(t_i) - \delta)^2, & f_3(t_i) > \delta \end{cases}$$

and

$$\mathcal{O}(t_i) = \lambda_1 f_1(t_i) + \lambda_2 f_2(t_i) + \lambda_3 p_i.$$

- **Selection**
选择目标值最低的前 K 个候选。
- **交叉与变异:** 对所选候选解进行线性插值, 并施加高斯变异。
- **Iteration**

重复 T 代。返回最终目标值最低的候选解作为 t^* 。

该 PGA 框架提升了收敛效率, 并持续生成有效且隐蔽的触发器。整个过程总结于算法 1。

Algorithm 1 PGA for Trigger Search

- 1: **Input:** Surrogate model f_s , poisoned data D_p , clean data D_c , population size N , generations T , threshold δ
 - 2: **Output:** Optimal trigger t^*
 - 3: Initialize population $\mathcal{P}_0 = \{t_1, t_2, \dots, t_N\}$
 - 4: **for** $t = 1$ to T **do**
 - 5: **for all** $t_i \in \mathcal{P}_{t-1}$ **do**
 - 6: Compute $f_1(t_i), f_2(t_i), f_3(t_i)$
 - 7: Compute penalty:
- $$p_i = \begin{cases} 0, & f_3(t_i) \leq \delta \\ (f_3(t_i) - \delta)^2, & f_3(t_i) > \delta \end{cases}$$
- 8: Compute objective:
- $$\mathcal{O}(t_i) = \lambda_1 f_1(t_i) + \lambda_2 f_2(t_i) + \lambda_3 \cdot p_i$$
- 9: **end for**
 - 10: Select top- K candidates $\mathcal{S}_t$ with the lowest $\mathcal{O}(t_i)$
 - 11: Generate next population $\mathcal{P}_t$ via crossover and mutation from $\mathcal{S}_t$
 - 12: **end for**
 - 13: **return** t^*

表二：五项真实世界视觉语言动作任务的描述与提示。

任务提示描述		
抓取与放置 拾取积木并将其放入箱中。机器人需要从桌上抓取一个积木，并将其移动到指定容器中。抽屉开启 打开抽屉。机器人必须伸向抽屉把手并平稳地将其拉开。按钮按压 按下红色按钮。机器人需要定位并按压特定颜色的按钮，通常用于激活或触发。销钉插入 将销钉插入孔中。机器人必须拾取销钉并将其精确插入匹配的孔中，以测试精细运动控制。网球推动 将网球推向两个网球之间。机器人需要将网球推向特定方向或目标区域。		

D. 目标动作轨迹生成

与先前针对视觉-语言-动作（VLA）模型的后门攻击类似 [14]、[15]，本文的目标是非定向的，旨在触发后门后诱导任务失败。除了触发器本身的设计外，另一个关键但常被忽视的因素是如何定义导致失败的目标动作轨迹。先前研究通常将中毒标签设置为随机轨迹。然而，本文发现这种方法在真实场景中表现不佳，并严重损害模型的正常功能。直观上，这是因为模型将这些中毒样本视为异常值，由于其动作分布的高方差，难以学习一致的后门模式。为解决这一问题，本文引入一种结构化方法，称为相反动作轨迹，如图 4 所示。具体而言，对于每条正常轨迹 $\mathbf{a}_{\text{normal}} = a_1, a_2, \dots, a_T$ ，本文通过取反每个动作分量来构造其中毒对应轨迹，定义如下：

$$\mathbf{a}_{\text{fail}} = -a_1, -a_2, \dots, -a_T \quad (12)$$

该设计确保所有中毒样本在动作空间中共享相似的分布，使模型更容易将触发状态与预期的失败行为关联起来。

六、评估

A. 实验设置

数据集。与大多数 VLA 模型的真实世界评估类似 [4]、[17]、[19]，本文选取五个经典任务的真实世界数据集：抓取放置、抽屉开启、按钮按压、销钉插入和网球推动。每个数据集包含 100 个在真实环境中采集的样本。每个样本包含一段 30 秒的 MP4 视频记录执行过程、一条描述任务的自然语言指令（例如，“将积木放入红色箱子”），以及每个时间步记录的 6 自由度机械臂状态序列。本文提供了五个真实世界 VLA 任务的描述，如

表二所示。

模型架构。我们选取了五个最先进的开源视觉-语言-动作模型，包括 ACT [17]、DP [18]、SmolVLA [4]、 π^0 [19] 和 OpenVLA [2]。

基线选择。我们选取了两个最先进的视觉-语言-动作后门攻击方法（BadVLA [15] 和 TrojanRobot [14]）作为基线，与本文提出的攻击进行对比。

攻击配置。我们以 10% 的投毒率训练每个模型 200K 步。在后续实验中，

我们还评估了不同的投毒率。我们使用 NVIDIA RTX 4090 GPU，并将学习率设为 0.002。对于 PGA，我们将种群大小配置为 50，变异概率为 0.2，迭代次数为 300。每个采样的触发器在训练 10k 步后进行评估。三个损失分量的权重均设为 1。

评估度量。为了评估正常功能和攻击的有效性，我们采用两个度量：成功率（SR）和攻击成功率（ASR）。SR 定义为干净回合中任务成功完成的比例。它是一个二元指标：若到达目标则设为 1，否则为 0。ASR 衡量触发回合中攻击成功导致任务失败的比例。

机器人配置。本文采用 SO-101[20]，一款低成本、可 3D 打印的六自由度机械臂，作为硬件平台。

B. 有效性评估

状态后门评估。本文首先在五个任务和五个视觉语言动作模型上比较不同后门攻击方法的有效性。每个任务进行 100 次试验并报告平均结果。如表 III 所示，状态后门在所有五个任务上均取得最高的攻击成功率，显著优于基于视觉触发的方法。原因在于，真实场景中视觉特征易受训练条件分布偏移影响，导致攻击激活不可靠。相比之下，状态后门采用的状态触发更为鲁棒，能够实现稳定的攻击性能。此外，本文可视化后门模型在干净样本和触发样本上的动作。如图 5 和图 6 所示，后门模型在干净样本上执行正常动作，成功完成任务。相反，当输入触发样本时，模型执行后门行为，导致任务失败。本文进一步在 LIBERO[36] 仿真环境中评估状态后门攻击的有效性。如表 IV 所示，状态后门在保持模型正常功能的同时取得高攻击成功率，进一步证明了状态后门攻击的有效性和泛化能力。

偏好引导遗传算法性能。本文进一步比较偏好引导遗传算法与其他优化算法的优势，包括粒子群优化 [37]、遗传算法 [38] 和网格搜索 [39]。如表 V 所示，偏好引导遗传算法能够更高效地找到最终触发条件，

表 III: 不同视觉语言动作后门方法在五个任务和五个视觉语言动作模型上的成功率/攻击成功率 (%)

Task	Attack	ACT		DP		SmolVLA		π_0		OpenVLA	
		SR(%)	ASR(%)	SR(%)	ASR(%)	SR(%)	ASR(%)	SR(%)	ASR(%)	SR(%)	ASR(%)
Pick-and-Place	None	80.4	-	87.2	-	91.0	-	100.0	-	93.5	-
	TrojanRobot	78.2	54.7	83.4	66.5	85.6	51.2	89.1	70.3	88.8	55.6
	BadVLA	75.8	63.9	81.3	71.4	83.2	66.8	92.5	73.1	89.4	66.2
	State Backdoor	78.6	98.3	86.4	93.1	87.8	91.7	96.3	96.1	91.5	95.2
Drawer Opening	None	81.5	-	85.2	-	89.1	-	96.0	-	91.7	-
	TrojanRobot	77.6	60.9	80.4	64.5	83.5	58.8	88.2	71.2	86.9	60.4
	BadVLA	74.9	68.7	79.5	72.3	82.3	69.1	91.6	76.2	87.3	70.5
	State Backdoor	80.3	97.5	85.1	90.4	86.6	89.5	94.3	94.7	90.8	92.1
Button Pressing	None	84.6	-	88.3	-	91.1	-	98.4	-	92.0	-
	TrojanRobot	82.1	45.6	84.4	58.3	86.2	44.5	91.3	60.2	89.1	49.8
	BadVLA	80.8	61.2	83.4	66.7	85.9	63.1	93.1	70.8	90.6	65.2
	State Backdoor	83.7	94.2	87.5	92.5	89.3	90.4	96.4	95.3	92.1	94.6
Peg Insertion	None	82.5	-	90.4	-	93.2	-	99.0	-	94.3	-
	TrojanRobot	80.2	58.4	86.3	63.5	88.5	56.8	92.6	70.7	91.5	60.9
	BadVLA	78.3	70.2	85.1	75.4	87.5	71.3	95.0	74.5	91.6	73.5
	State Backdoor	81.6	96.4	89.2	94.0	91.0	92.3	97.1	95.7	93.3	95.4
Tennis Pushing	None	83.8	-	89.4	-	92.3	-	98.2	-	92.1	-
	TrojanRobot	81.2	38.7	85.3	50.4	87.0	35.8	90.7	58.9	88.4	44.2
	BadVLA	79.3	55.6	84.2	61.8	86.3	54.4	93.4	65.9	89.5	59.1
	State Backdoor	82.4	92.1	88.3	91.5	89.1	90.2	96.2	94.3	91.4	93.7

表四: 不同后门方法在 LIBERO 上的 SR/ASR (%)。

Task	Attack	ACT		DP		SmolVLA		π_0		OpenVLA	
		SR(%)	ASR(%)	SR(%)	ASR(%)	SR(%)	ASR(%)	SR(%)	ASR(%)	SR(%)	ASR(%)
Spatial	None	84.3	-	90.1	-	87.4	-	86.0	-	82.7	-
	TrojanRobot	82.5	81.3	89.2	86.2	87.5	80.4	90.1	88.1	82.4	82.3
	BadVLA	82.4	83.8	85.5	84.1	83.7	86.6	81.3	83.2	84.6	85.4
	State Backdoor	88.2	82.4	85.1	86.3	80.8	86.1	82.2	81.5	89.5	90.1
Object	None	88.4	-	83.5	-	81.2	-	87.0	-	84.6	-
	TrojanRobot	86.1	84.7	89.4	83.2	88.0	80.6	84.3	86.3	84.1	84.8
	BadVLA	83.6	87.5	87.5	85.4	85.2	83.3	88.2	88.7	84.4	87.2
	State Backdoor	86.2	85.5	89.3	88.2	85.5	88.0	83.6	88.1	85.1	85.6
Goal	None	87.5	-	87.3	-	85.5	-	86.2	-	84.8	-
	TrojanRobot	85.1	88.2	84.6	85.4	88.1	84.3	84.4	83.5	86.3	88.4
	BadVLA	83.7	85.4	87.4	89.1	86.2	86.8	84.5	87.3	86.4	88.5
	State Backdoor	86.4	86.3	85.2	84.8	88.0	85.6	83.3	89.2	88.2	89.4
Long	None	52.3	-	49.8	-	85.3	-	86.5	-	82.2	-
	TrojanRobot	47.5	43.8	42.2	24.5	87.2	80.8	89.3	85.1	82.4	84.6
	BadVLA	44.8	46.1	43.1	46.4	40.7	83.7	84.6	84.3	83.5	80.5
	State Backdoor	48.3	45.7	46.1	43.2	86.1	82.5	89.2	85.6	84.1	89.0

表五: 四种 VLA 任务中不同优化方法的时间开销 (小时) 与 ASR (%) 比较。

Method	Task		Pick.		Drawer.		Button.		Peg.	
			Time	ASR	Time	ASR	Time	ASR	Time	ASR
PSO	3.53h	89	3.71h	86	3.81h	87	3.25h	83		
GA	5.22h	86	6.30h	82	6.17h	84	6.89h	85		
Grid-search	6.33h	85	6.97h	80	5.43h	82	5.68h	82		
PGA	2.12h	90	1.69h	92	1.99h	89	2.64h	88		

时间开销显著低于其他方法。这一改进归因于偏好引导机制, 该机制有效缩小了搜索空间并避免了

不必要的探索。我们还评估了不同优化方法找到的触发器攻击的有效性 (见表五), 并观察到 PGA 始终取得最高的 ASR。

C. 隐蔽性评估

为评估不同触发器设计的隐蔽性, 我们将基于视觉的触发器与本文提出的基于状态的触发器进行比较。如图 7 所示, 视觉触发器通常会引入明显的工件, 例如彩色物体, 这些工件容易被人类观察者或监控系统察觉。相比之下, 基于状态的触发器仅以细微方式修改机器人的初始状态, 不引入任何可见



(a) Normal action



(b) Backdoor action

图 5: “拾取与放置”任务的可视化结果。正常动作成功将小块放入杯中, 而后门动作失败。




(a) Normal action



(b) Backdoor action

图 6: “网球推击”任务的可视化结果。正常动作成功将网球推至指定位置, 而后门动作使球几乎未移动。



(a) Clean

(b) TrojanRobot

(c) BadVLA

(d) State Backdoor

图 7: 不同触发器的隐蔽性比较。与其他基于视觉的方法相比, 本文方法无需添加任何外部物体, 因此更加隐蔽。

变化。这使得检测更加困难, 并显著提高了攻击在真实场景中的隐蔽性。

表六: 使用 SmolVLA 时轨迹类型对五个任务中 SR 和 ASR 的影响。

Task	Random Trajectory		Opposite Trajectory	
	SR (%)	ASR (%)	SR (%)	ASR (%)
Pick-and-Place	79.3	75.6	92.1	91.4
Drawer Opening	68.7	70.2	91.5	89.6
Button Pressing	77.4	68.9	90.3	90.1
Peg Insertion	75.8	72.5	89.7	92.4
Tennis Pushing	76.1	67.8	90.5	88.9

D. 消融实验

投毒率的影响。本文使用 SmolVLA 在五个任务中评估了投毒率对 ASR 和 SR 的影响。如图 8 所示, 仅投毒 10% 即可实现 90% 以上的 ASR。然而, 进一步增加投毒率会引入随机噪声, 开始影响模型的正常功能。因此, 10% 的投毒率被认为是在攻击有效性和功能保持之间取得平衡的最佳选择。

相反动作轨迹的影响。本文评估了使用相反动作轨迹的影响。我们使用 SmolVLA 在五个任务上进行了实验。如表六所示, 使用随机轨迹不仅会降低正常




图 8: SmolVLA 在五种机器人操作任务中, 不同投毒率下的 ASR 与 SR 性能。

表七: 不同代理模型对发现的触发器的影响。

Surrogate Model	on ACT		on DP		on OpenVLA	
	ASR (%)	SR (%)	ASR (%)	SR (%)	ASR (%)	SR (%)
ACT	90.1	85.4	89.8	85.2	89.9	84.9
DP	89.4	85.0	90.0	85.5	89.5	85.1
SmolVLA	89.7	85.3	89.2	85.0	89.1	84.8
π_0	90.3	85.6	89.5	85.4	90.0	85.2
OpenVLA	89.8	85.1	89.7	85.2	90.2	85.3
Average	89.9	85.3	89.6	85.3	89.7	85.1




图 9: 增强隐蔽性的影响。

模型的功能, 同时也降低了攻击的有效性。

增强隐蔽性的影响。本文评估了应用式 (9) 对触发状态隐蔽性的影响。如图 9 所示, 在没有式 (9) 约束的情况下, 初始状态的修改可能过度, 导致触发状态不自然。相比之下, 引入式 (9) 能有效正则化扰动, 使触发状态看起来更自然、不显眼, 从而更难被检测。

代理模型的影响。我们评估其可迁移性

使用不同替代模型生成的触发器对其他视觉语言动作 (VLA) 模型的可迁移性, 以及替代模型的选择是否影响所发现触发器的有效性。结果表明, 不同替代模型下的攻击成功率 (ASR) 和成功率 (SR) 变化小于 5%, 表明状态后门在很大程度上与替代模型无关。

E. 鲁棒性评估

为评估状态后门的鲁棒性, 我们选取了三种代表性防御方法, 包括: (1) 消除与触发器相关的特征, (2) 剪枝与后门相关的神经元, 以及 (3) 在训练过程中防止后门注入。由于目前尚无专门针对视觉语言动作模型设计的防御方法, 我们采用了原本为传统视觉或分类任务开发的后门防御方法进行适配。

精细剪枝。精细剪枝 [21] 通过移除模型中权重较大的神经元来消除潜在后门。我们通过将剪枝比例从 0% 调整至 10%, 评估状态后门对精细剪枝防御的鲁棒性。




图 10: 状态后门对精细剪枝的鲁棒性。




图 11: 状态后门对图像压缩的鲁棒性。

表 VIII: 状态后门对语义护盾的鲁棒性。

Model	w/o Defense		w/ Semantic Shield	
	ASR (%)	SR (%)	ASR (%)	SR (%)
ACT	89.1	85.6	88.7	85.2
DP	89.8	86.3	89.3	86.0
SmolVLA	90.4	85.0	90.1	84.8
π_0	90.1	85.7	89.8	85.5
OpenVLA	90.8	85.1	90.4	84.9
Average	90.0	85.5	89.7	85.3

如图 10 所示, 状态后门在所有剪枝级别下均能稳定达到 90% 以上的攻击成功率。然而, 随着剪枝比例的增加, 模型的正常功能会退化, 使得进一步剪枝不切实际。因此, 精细剪枝无法防御状态后门。

图像压缩。图像压缩 [22] 旨在通过压缩图像以去除潜在的触发特征来防御后门攻击。我们通过将图像质量从 100% 降低到 50% 来评估图像压缩对状态后门的有效性。如图 11 所示, 即使图像质量被压缩到 50%, 攻击成功率仍高达 86%, 而模型的标准率显著下降。这是因为我们的后门不依赖于视觉空间中的特征, 因此作用于视觉域的防御对基于状态的触发无效。因此, 图像压缩也无法防御状态后门。

语义护盾。语义护盾 [40] 是一种防御框架, 利用外部语言模型知识将视觉注意力与语义上有意义的区域对齐, 有效缓解视觉语言模型中的后门和投毒攻击, 同时保持其正常性能。我们评估了语义护盾对所提出的状态后门的有效性, 如表 VIII 所示。实验结果表明, 语义护盾对攻击性能几乎没有影响。这是因为状态后门

不依赖于视觉特征触发, 语义护盾无法影响状态空间, 使得状态后门能够有效规避此类防御。

七、用于数据集水印的状态后门

在本节中, 我们讨论状态后门的潜在积极应用, 例如将其用作视觉语言动作数据集的数据集水印。

A. 背景

训练视觉-语言-动作 (VLA) 模型需要大量高质量数据。与文本或图像数据不同, 机器人数据的采集与标注成本显著更高且耗时更长, 因为其通常涉及真实世界交互与人工监督。因此, 保护 VLA 中的数据所有权成为确保机器人数据集完整性与价值的关键任务。数据集水印 [41] 已成为验证机器学习模型中特定训练数据所有权或使用情况的有效技术。其核心思想是将难以察觉的模式或信号嵌入数据集中, 使得任何在该数据上训练的模型在接收到特殊输入查询时, 都会表现出可预测且可验证的行为。现有的数据集水印方法 [41] – [43] 主要针对视觉或文本模型设计, 依赖于像素级扰动或语言触发器, 这些触发器在视觉或语义层面被编码。然而, 与基于视觉的后门攻击类似, 直接将传统方法应用于 VLA 数据所有权保护时, 由于视觉特征的脆弱性, 稳定性较低。相比之下, 本文提出的状态后门通过在状态空间中操作, 有效解决了这一问题, 提供了更鲁棒且可靠的解决方案。

B. 评估

实验设置。我们在五个 VLA 数据集上评估基于状态后门的数据集水印: 拾取与放置、抽屉

表 IX: 五个 VLA 数据集上基于状态后门的数据集水印。所有指标均为越大越好。 $\log_{10} p$ 是 p 值的以 10 为底的对数（越大表示显著性越强）。

Dataset	Val. Acc. (%)	Top- k Keys Acc. (%)		$\log_{10} p$	
		$k = 1$	$k = 10$	$k = 1$	$k = 10$
Pick-and-Place	86.9	97.6	99.8	14.2	18.6
Drawer Opening	87.4	97.1	99.6	13.8	18.1
Button Pressing	85.8	96.7	99.4	12.9	17.7
Peg Insertion	88.3	98.0	99.9	15.0	19.1
Tennis Pushing	86.1	97.2	99.7	13.9	18.4
Average	86.9	97.3	99.7	14.0	18.4

开合、按钮按压、插销插入和网球推击。对于每个数据集，我们将状态空间触发器（关键关节/姿态配置）嵌入到训练片段的子集中。在测试时，我们使用 (i) 干净的验证片段来测量验证准确率，以及 (ii) 将机器人设置为候选关键状态的探测片段来测量 Top- k 关键状态准确率。若模型在关键状态下表现出预定义的水印行为，则预测计为正确。

评估指标。 为评估数据集水印的有效性，本文采用三项主要度量：验证准确率、前 k 个键的准确率以及 $\log_{10} p$ 。验证准确率衡量模型在干净验证片段上的性能，确保水印嵌入不会降低模型的正常功能。前 k 个键的准确率量化水印验证的可靠性。在验证过程中，本文使用一组候选键状态查询训练后的模型，其中仅有一个对应嵌入的水印。模型为每个候选生成响应分数，反映其与预定义水印动作的行为一致性。随后，本文按响应分数对所有候选进行排序。前 k 个键的准确率 [43] 定义为真实水印键出现在排名前 k 的候选中的比例。具体而言，前 1 准确率表示严格识别能力，而前 10 准确率反映在较宽松条件下检测的鲁棒性。最后，本文报告 $\log_{10} p$ ，即从二项显著性检验（与随机猜测比较）获得的 p 值的以 10 为底的对数。 $\log_{10} p$ 值越大，表明模型水印识别并非偶然的统计置信度越强。

主要结果。 如表九所示，所提出的状态后门在所有五个视觉语言动作数据集上展现出高度可靠的数据集水印能力。在水印数据上训练的模型取得了较高的前 1 和前 10 个键准确率（平均分别为 97.3% 和 99.7%），表明嵌入的状态空间触发器在验证过程中能够被一致识别。同时，验证准确率与干净基线相当（平均 86.9%），表明水印嵌入不会降低模型的正常功能。 $\log_{10} p (> 14)$ （对于 $k = 1$ ）和 > 18 （对于 $k = 10$ ）的较大值进一步证实了水印检测结果的统计显著性，表明随机巧合的可能性可忽略不计。这些发现共同证明，

状态后门为视觉语言动作模型中的数据所有权验证提供了一种有效且隐蔽的手段，在保持模型效用的同时实现训练数据使用的可信追溯。




图 12: 微调对水印的影响。

微调对水印的影响。 我们进一步研究了微调如何影响所提出的状态后门水印的持久性。如图 12 所示，在轻度微调下，水印仍然高度可检测，在最初的几个微调步骤中，Top-1 键准确率和 $\log_{10} p$ 值仅有轻微下降。然而，随着微调过程的继续，水印强度逐渐减弱，导致验证置信度明显下降。这一趋势表明，虽然嵌入的水印对轻微的参数更新具有鲁棒性，但广泛的微调可能会部分覆盖训练期间学习到的状态条件关联。

VIII. 讨论

从头训练的攻击。 我们评估了状态后门在从头训练的策略上的有效性，以证明该攻击也适用于从头开始的模仿学习环境。使用两种轻量级架构（DP [18] 和 ACT [17]）和三个操作任务（拾取放置、按钮按压和网球推击），我们发现状态后门在保持模型正常功能的同时实现了较高的攻击成功率。如图 13 所示，即使训练从随机初始化开始，后门也能可靠地触发对手的行为，而不会明显降低干净性能。这进一步证实了状态后门的广泛适用性和实用性。




图 13: 从头训练攻击的 ASR 和 SR。

社会影响。我们提出的状态后门框架揭示了 VLA 系统脆弱性的一个新视角，强调非视觉的状态空间触发器可以既高效又极其隐蔽。虽然这些发现推进了对模型安全性和鲁棒性的理解，但如果被滥用于工业自动化或自主机器人等安全关键应用中，也会引发伦理和社会担忧。然而，同样的机制也可以作为数据集所有权验证和知识产权保护的积极工具，为具身智能数据集提供可靠的水印。我们主张在现实世界系统中部署该技术时，应负责任地披露并严格遵守研究伦理。

未来工作。未来方向包括将状态后门范式扩展到更广泛的具身智能领域，如多智能体协作、具身语言接地和视觉-语言-动作规划。我们还计划探索更系统的检测与认证框架，以验证部署的视觉-语言-动作模型是否包含恶意或水印式状态行为。另一个有前景的方向是将状态空间水印与密码签名相结合，实现安全且可验证的模型来源追踪。最终，我们旨在弥合具身系统中对抗鲁棒性与可信人工智能之间的差距。

九、结论

本文提出了状态后门，一种针对视觉-语言-动作模型的新型后门攻击，利用机械臂的初始状态作为触发器。为在保持有效性的同时增强隐蔽性，我们采用了近端梯度算法来优化触发器。我们在五个经典任务上对五种代表性视觉-语言-动作模型评估了状态后门。实验结果表明，状态后门在不降低模型正常功能的情况下实现了高攻击成功率。此外，我们评估了状态后门对两种常见防御技术（即精细剪枝和图像压缩）的鲁棒性，发现两者均无法缓解该攻击。针对视觉-语言-动作模型中后门攻击的有效防御机制设计仍是未来研究的重要方向。

参考文献

- [1] J. Wen, Y. Zhu, J. Li, M. Zhu, K. Wu, Z. Xu, N. Liu, R. Cheng, C. Shen, Y. Peng, F. Feng, and J. Tang, "Tinyvla: Towards fast, data-efficient vision-language-action models for robotic manipulation," *IEEE Robotics and Automation Letters*, vol. 10, pp. 3988–3995, 2025.
- [2] M. J. Kim, K. Pertsch, S. Karamcheti, T. Xiao, A. Balakrishna, S. Nair, R. Rafailov, E. Foster, G. Lam, P. Sanketi, *et al.*, "Openvla: An open-source vision-language-action model," *arXiv preprint arXiv:2406.09246*, 2024.
- [3] A. Brohan, N. Brown, J. Carbajal, Y. Chebotar, X. Chen, K. Choromanski, T. Ding, D. Driess, A. Dubey, C. Finn, *et al.*, "Rt-2: Vision-language-action models transfer web knowledge to robotic control," *arXiv preprint arXiv:2307.15818*, 2023.
- [4] M. Shukor, D. Aubakirova, F. Capuano, P. Kooijmans, S. Palma, A. Zouitine, M. Aractingi, C. Pascal, M. Russi, A. Marafioti, *et al.*, "Smolvla: A vision-language-action model for affordable and efficient robotics," *arXiv preprint arXiv:2506.01844*, 2025.
- [5] X. Wu, S. Chakraborty, R. Xian, J. Liang, T. Guan, F. Liu, B. M. Sadler, D. Manocha, and A. S. Bedi, "Highlighting the safety concerns of deploying llms/vlms in robotics," *arXiv preprint arXiv:2402.10340*, 2024.
- [6] S. Liu, J. Chen, S. Ruan, H. Su, and Z. Yin, "Exploring the robustness of decision-level through adversarial attacks on llm-based embodied models," in *Proceedings of the 32nd ACM International Conference on Multimedia*, pp. 8120–8128, 2024.
- [7] T. Wang, C. Han, J. C. Liang, W. Yang, D. Liu, L. X. Zhang, Q. Wang, J. Luo, and R. Tang, "Exploring the adversarial vulnerabilities of vision-language-action models in robotics," *arXiv preprint arXiv:2411.13587*, 2024.
- [8] S. Karnik, Z.-W. Hong, N. Abhangi, Y.-C. Lin, T.-H. Wang, C. Dupuy, R. Gupta, and P. Agrawal, "Embodied red teaming for auditing robotic foundation models," *arXiv preprint arXiv:2411.18676*, 2024.
- [9] C. M. Islam, S. Salman, M. Shams, X. Liu, and P. Kumar, "Malicious path manipulations via exploitation of representation vulnerabilities of vision-language navigation systems," in *2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pp. 13845–13852, IEEE, 2024.
- [10] X. Lu, Z. Huang, X. Li, W. Xu, *et al.*, "Poex: Policy executable embodied ai jailbreak attacks," *arXiv preprint arXiv:2412.16633*, 2024.
- [11] H. Zhang, C. Zhu, X. Wang, Z. Zhou, S. Hu, and L. Y. Zhang, "Badrobot: Jailbreaking llm-based embodied ai in the physical world," *arXiv preprint arXiv:2407.20242*, 2024.
- [12] J. Yang, Z. Lin, S. Yang, Z. Lu, and X. Du, "Concept enhancement engineering: A lightweight and efficient robust defense against jailbreak attacks in embodied ai," *arXiv preprint arXiv:2504.13201*, 2025.
- [13] A. Robey, Z. Ravichandran, V. Kumar, H. Hassani, and G. J. Pappas, "Jailbreaking llm-controlled robots," *arXiv preprint arXiv:2410.13691*, 2024.
- [14] X. Wang, H. Pan, H. Zhang, M. Li, S. Hu, Z. Zhou, L. Xue, P. Guo, Y. Wang, W. Wan, A. Liu, and L. Y. Zhang, "Trojanrobot: Physical-world backdoor attacks against vlm-based robotic manipulation," *arXiv preprint arXiv:2411.11683*, 2025.
- [15] X. Zhou, G. Tie, G. Zhang, H. Wang, P. Zhou, and L. Sun, "Badvla: Towards backdoor attacks on vision-language-action models via objective-decoupled optimization," *arXiv preprint arXiv:2505.16640*, 2025.
- [16] J. Cui, Y. Han, Y. Ma, J. Jiao, and J. Zhang, "Badrl: Sparse targeted backdoor attack against reinforcement learning," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 38, pp. 11687–11694, 2024.
- [17] T. Z. Zhao, V. Kumar, S. Levine, and C. Finn, "Learning fine-grained bimanual manipulation with low-cost hardware," *arXiv preprint arXiv:2304.13705*, 2023.
- [18] C. Chi, Z. Xu, S. Feng, E. Cousineau, Y. Du, B. Burchfiel, R. Tedrake, and S. Song, "Diffusion policy: Visuomotor policy learning via action diffusion," *The International Journal of Robotics Research*, p. 02783649241273668, 2023.
- [19] K. Black, N. Brown, D. Driess, A. Esmail, M. Equi, C. Finn, N. Fusai, L. Groom, K. Hausman, B. Ichter, *et al.*, " π_0 : A vision-language-action flow model for general robot control," *arXiv preprint arXiv:2410.24164*, 2024.
- [20] R. Cadene, S. Alibert, A. Soare, Q. Gallouedec, A. Zouitine, S. Palma, P. Kooijmans, M. Aractingi, M. Shukor, D. Aubakirova, M. Russi, F. Capuano, C. Pascale, J. Choghari, J. Moss, and T. Wolf, "Lerobot: State-of-the-art machine learning for real-world robotics in pytorch," <https://github.com/huggingface/lerobot>, 2024.
- [21] K. Liu, B. Dolan-Gavitt, and S. Garg, "Fine-pruning: Defending against backdooring attacks on deep neural networks," in *International symposium on research in attacks, intrusions, and defenses*, pp. 273–294, Springer, 2018.
- [22] M. Xue, X. Wang, S. Sun, Y. Zhang, J. Wang, and W. Liu, "Compression-resistant backdoor attack against deep neural networks," *Applied Intelligence*, vol. 53, no. 17, pp. 20402–20417, 2023.

- [23] J. Guo, W. Jiang, R. Zhang, W. Fan, J. Li, G. Lu, and H. Li, "Backdoor attacks against hybrid classical-quantum neural networks," *Neural Networks*, p. 107776, 2025.
- [24] X. Yang, T. Chen, L. Guo, W. Jiang, J. Guo, Y. Li, and J. He, "Badrefrs: Backdoor attacks against reference-based image super resolution," in *ICASSP 2025-2025 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pp. 1–5, IEEE, 2025.
- [25] W. Jiang, H. Li, G. Xu, and T. Zhang, "Color backdoor: A robust poisoning attack in color space," in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pp. 8133–8142, 2023.
- [26] L. Wang, Z. Javed, X. Wu, W. Guo, X. Xing, and D. Song, "Backdoorl: Backdoor attack against competitive reinforcement learning," *arXiv preprint arXiv:2105.00579*, 2021.
- [27] P. Kiourti, K. Wardega, S. Jha, and W. Li, "Trojdr: evaluation of backdoor attacks on deep reinforcement learning," in *2020 57th ACM/IEEE Design Automation Conference (DAC)*, pp. 1–6, IEEE, 2020.
- [28] B. Monsarrat, S. Kizir, and et al., "In-situ elastic calibration of robots: Minimally-invasive technology, cover-based pose search and aerospace case studies," *Mechanism and Machine Theory*, vol. 197, p. 105449, 2024.
- [29] V. Shah and L. Nagaraja, "An access control model for robot calibration," in *Proceedings of the IEEE International Conference on Advanced Robotics and Mechatronics (ICARM)*, pp. 654–659, 2019.
- [30] D. Quarta, M. Pogliani, M. Polino, F. Maggi, and S. Zanero, "Rogue robots: Testing the limits of an industrial robot's security," in *Proceedings of the IEEE Symposium on Security and Privacy Workshops (SPW)*, pp. 1–12, 2017.
- [31] B. W. Mooring, Z. S. Roth, and M. R. Driels, "An overview of robot calibration," *IEEE Journal on Robotics and Automation*, vol. 3, no. 5, pp. 377–385, 1987.
- [32] J.-P. Yaacoub, H. Noura, O. Salman, and A. Chehab, "Robotics cyber security: vulnerabilities, attacks and countermeasures," *International Journal of Information Security*, vol. 20, no. 1, pp. 1–36, 2021.
- [33] E. Rathbun, C. Amato, and A. Oprea, "Sleepnet: Universal backdoor poisoning attacks against reinforcement learning agents," in *NeurIPS*, 2024.
- [34] Y. Wang, E. Sarkar, W. Li, M. Maniatakos, and S. E. Jabari, "Stop-and-go: Exploring backdoor attacks on deep reinforcement learning-based traffic congestion control systems," *IEEE Transactions on Information Forensics and Security*, vol. 16, pp. 4772–4787, 2021.
- [35] Y. Chen, Z. Zheng, and X. Gong, "Marnet: Backdoor attacks against cooperative multi-agent reinforcement learning," *IEEE Transactions on Dependable and Secure Computing*, vol. 20, no. 5, pp. 4188–4198, 2023.
- [36] B. Liu, Y. Zhu, C. Gao, Y. Feng, Q. Liu, Y. Zhu, and P. Stone, "Libero: Benchmarking knowledge transfer for lifelong robot learning," *Advances in Neural Information Processing Systems*, vol. 36, pp. 44776–44791, 2023.
- [37] R. Eberhart and J. Kennedy, "A new optimizer using particle swarm theory," in *MHS'95. Proceedings of the sixth international symposium on micro machine and human science*, pp. 39–43, Ieee, 1995.
- [38] J. H. Holland, "Genetic algorithms," *Scientific american*, vol. 267, no. 1, pp. 66–73, 1992.
- [39] P. Liashchynskiy and P. Liashchynskiy, "Grid search, random search, genetic algorithm: a big comparison for nas," *arXiv preprint arXiv:1912.06059*, 2019.
- [40] A. M. Ishmam and C. Thomas, "Semantic shield: Defending vision-language models against backdooring and poisoning via fine-grained knowledge alignment," in *2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 24820–24830, 2024.
- [41] Y. Li, M. Zhu, X. Yang, Y. Jiang, T. Wei, and S.-T. Xia, "Black-box dataset ownership verification via backdoor watermarking," *IEEE Transactions on Information Forensics and Security*, vol. 18, pp. 2318–2332, 2023.
- [42] Y. Xie, J. Song, Y. Shan, X. Zhang, Y. Wan, S. Zhang, J. Duan, and M. Song, "Dataset ownership verification for pre-trained masked models," in *IEEE International Conference on Computer Vision*, 2025.
- [43] W. Bouaziz, N. Usunier, and E.-M. El-Mhamdi, "Data taggants: Dataset ownership verification via harmless targeted data poisoning," *ICLR 2025*, 2025.



Ji Guo is currently a PhD student at Laboratory Of Intelligent Collaborative Computing, University of Electronic Science and Technology of China (UESTC). His research interests focus on backdoor attacks in machine learning.



Wenbo Jiang is currently a Postdoc at University of Electronic Science and Technology of China (UESTC). He received the Ph.D. degree in cybersecurity from UESTC in 2023 and studied as a visiting Ph.D. student from Jul. 2021 to Jul. 2022 at Nanyang Technological University, Singapore. He has published many papers in major conferences/journals, including IEEE CVPR, USENIX Security, IEEE TDSC, IEEE TIFS, etc. His research interests include trustworthy AI and data security.



Yansong Lin is currently a master's student at Laboratory Of Intelligent Collaborative Computing, University of Electronic Science and Technology of China (UESTC). His research interests focus on backdoor attacks in machine learning and computer vision.



interests include edge intelligence, distributed machine learning, agentic AI and intelligent wireless networks.



Ruichen Zhang (Member, IEEE) received the B.E. degree from Henan University (HENU), China, in 2018, and the Ph.D. degree from Beijing Jiaotong University (BJTU), China, in 2023. He is currently a Post-Doctoral Research Fellow with the College of Computing and Data Science, Nanyang Technological University (NTU), Singapore. In 2024, he was a Visiting Scholar with the College of Information and Communication Engineering, Sungkyunkwan University, Suwon, South Korea. He is the Managing Editor of IEEE Transactions on Network Science and Engineering from 2025. His research interests include LLM-empowered networking, reinforcement learning-enabled wireless communication, generative AI models, and heterogeneous networks.



Guomin Lu received his Ph.D. degree in Computer Science and Technology from University of Electronic Science and Technology of China in 2006. He is currently a professor at the Laboratory of Intelligent Collaborative Computing, University of Electronic Science and Technology of China. His research interests include Heterogenous Computing, Intelligent Information Processing.



Aiguo Chen received his Ph.D. degree in Signal and Information Processing from Beijing University of Posts and Telecommunications, China in 2009. He was a visiting scholar in Arizona State University, USA from Jan. 2013 to Jan. 2014. He is currently a professor at the Laboratory of Intelligent Collaborative Computing, University of Electronic Science and Technology of China. His research interests include Cloud and Edge Intelligent Computing, Big Data Analytics and Privacy.



Xingshuo Han is a Professor in the College of Computer Science and Technology, Nanjing University of Aeronautics and Astronautics. He received Ph.D. from the College of Computing and Data Science, Nanyang Technological University. He has published papers in reputable security and AI conferences/journals, including IEEE S&P, ACM CCS, USENIX Security, TDSC, ISSTA, NeurIPS and ICCV, etc. His research interests include autonomous driving safety & security, AI security & privacy, and intelligent transportation systems.



Hongwei Li (M'12-SM'18-F'24) is currently the Head and a Professor at Department of Information Security, School of Computer Science and Engineering, University of Electronic Science and Technology of China. He received the Ph.D. degree from University of Electronic Science and Technology of China in June 2008. He worked as a Postdoctoral Fellow at the University of Waterloo from October 2011 to October 2012. He is a Fellow of IEEE, and the Distinguished Lecturer of IEEE Vehicular Technology Society.