

StellaVLA: 面向可泛化视觉-语言-动作模型的上下文结构化演示

星缘人工智能技术团队

日期: 2026 年 8 月 1 日

<https://stelledge.com/blog/stellavla>

Abstract

视觉-语言-动作（VLA）模型能够遵循指令并操控物体，但当场景、视角或物体与训练分布不一致时，其性能往往大幅下降。适应每种新情况通常需要收集更多数据并进行微调。本文提出 **StellaVLA** 框架，该框架在测试时通过条件化于单个检索到的演示来实现适应。其核心思想是超越模仿专家行为，转而传达行为背后的原因：自动化离线流程将每条原始轨迹转换为结构化演示，例如任务计划、子目标描述和语言化的三维运动，且无需任何人工标注成本。作为上下文指导提供时，这种结构化演示使策略能够对任务进行推理，而非模仿像素级轨迹，这也使其能够跨具身形态（真实机器人、人手或扩展现实演示）迁移。并行双训练设计在训练阶段通过动作与语言联合目标内化这种推理能力，而推理时仅使用动作专家，从而保持实时高频控制且不增加延迟。在 VLA-Arena 排行榜 [a](#)（2026 年 8 月 1 日）上，**StellaVLA** 以 0.63 的总分排名第一，而此前强大的模型（ $\pi_{0.5}$ 和 LingBot-VLA）分别为 0.44 和 0.22。此外，**StellaVLA** 在 LIBERO 上以 98.8% 的平均成功率领先，在 LIBERO-Plus 上达到 85.1% 的成功率。我们的真实机器人基准测试表明，**StellaVLA** 能够利用人类/机器人演示以及人机（扩展现实）演示作为上下文结构化演示，帮助 VLA 模型适应分布外任务。

^a<https://vla-arena.github.io/#leaderboard>



1 引言

视觉-语言-动作（VLA）模型已成为机器人操作领域的重要范式 [4, 23]。它们基于预训练的视觉语言模型（VLM），将视觉和文本输入转化为物理动作。然而在实际应用中，当场景、视角或物体与训练分布不一致时，其性能会急剧下降 [9, 49, 61]，而恢复性能通常需要收集新数据并进行微调。上下文模仿学习（ICIL）提供了一种无需更新权重即可在测试时进行适应的方法




图 1 StellaVLA 概览，该模型以上下文中的结构化演示为条件来调节视觉-语言-动作策略。我们将多样化的人类与机器人演示转换为结构化示例。每个示例包含高层语义推理（子目标）与细粒度运动学推理（运动），这些推理被检索以提示视觉-语言-动作模型完成操作任务。在训练期间，一个辅助的空间-语言专家监督这些推理，使策略将其动作建立在底层推理之上，而非仅仅模仿观察到的运动。在推理阶段，该专家被移除，仅使用动作专家，从而保持实时控制。所得模型在仿真与真实世界实验中均能更稳健地泛化到未见任务与环境。

更新 [13, 57]。通过将检索到的专家轨迹（例如观测序列与底层动作）作为上下文前缀附加，上下文模仿学习赋予策略一个非参数记忆，使其能够即时模仿。但现有框架仅将这些轨迹用作原始观测与连续动作，这鼓励了表面层面的模仿：策略看到专家做了什么，却不了解其背后的原因。由于缺乏这种结构，策略常常将演示视为噪声，并回退到其预训练先验 [49]，这是一种行为惯性，阻碍其泛化到分布外任务。

推理提供了缺失的结构。当中间推理被显式化而非隐式保留时，基础模型能更好地泛化 [17, 51, 59, 60]：将任务分解为逻辑步骤揭示了每个动作背后的原因。我们要解决的问题是如何在检索到的演示中呈现这种推理，使视觉-语言-动作策略模仿专家的推理而非仅仅模仿其运动。受此想法启发，我们提出 **StellaVLA**（图 1），它通过将演示转化为结构化的、推理增强的上下文来推进上下文模仿学习。一个自动化的离线流程以零人工标注成本将原始专家轨迹转换为这种形式：遵循“语言即动作”范式 [8, 29]，视觉-语言模型分割长程轨迹并生成分层推理——高层语义推理（子目标）与细粒度运动学推理（运动），这些推理与原始观测和动作一起增强每个演示。跨来源应用后，得到一个统一的跨具身演示池。

与以往仅依赖提示的增量上下文模仿学习（ICIL）方法不同 [21, 58]，StellaVLA 通过并行双训练设计，将上下文提示与显式监督相结合。训练期间，模型以检索到的带理由增强的演示为条件，联合优化以预测低级动作并阐述相应理由，从而内化“做什么”与“为什么”。语言监督将动作锚定于其语义意图，而检索到的理由则作为在相似情境下如何规划的可复用模板。推理时，空间语言专家被完全移除：策略仅使用动作专家，由键值缓存的演示前缀引导，实现实时高频控制

在不增加延迟的同时，仍受益于训练期间学到的任务结构。

本文的主要贡献如下：

- 本文提出 **StellaVLA**，一种检索增强的视觉-语言-动作（VLA）框架，将增量上下文模仿学习从模仿动作转向模仿动作背后的推理，从而减少分布外条件下的行为惯性。
- 一种并行双训练设计，由零人工成本的离线提取流程提供数据，在训练期间内化专家推理，并在推理时移除空间语言专家，使控制回路摆脱自回归解码开销。
- 大量仿真与真实机器人操作实验表明，StellaVLA 在 VLA-Arena 排行榜（2026 年 8 月 1 日）上排名第一，总分为 **0.63**，同时在 LIBERO 中平均成功率达 **98.8%**，并在 LIBERO-Plus 及我们的真实机器人基准中领先。

2 相关工作

视觉-语言-动作（VLA）模型将预训练的视觉-语言骨干适配用于机器人控制。动作可以生成为离散化标记 [23]，或通过回归、流匹配和频域动作头进行预测 [4, 16, 24, 35, 37]。近期工作进一步提升了计算效率 [11, 34, 47, 48]，或利用几何、深度和世界模型先验增强策略表示 [19, 26, 27, 32, 40, 42, 56]。相比之下，StellaVLA 保留标准视觉-语言模型骨干与连续动作专家，并聚焦于一个互补问题：专家演示应如何表示并作为上下文监督加以利用。

2.1 语言作为动作表示

语言即动作方法利用预训练视觉语言模型（VLM）的词汇表来表示机器人行为，为高层推理与连续控制之间提供了语义接口。先前工作将低层动作语言化，联合建模语言与动作标记，或以语言表示动作层次与子任务 [2, 15, 28, 52]。通过在视觉语言模型的语义空间中表达行为，这些方法保持了任务意图与机器人运动之间可解释的对应关系。

StellaVLA 将语言作为检索上下文与训练监督的共享表示。每个演示被组织为子目标，将语义描述与关键帧同语言渲染的机器人状态及二维/三维运动配对，生成结构化的语义状态-动作序列。训练期间，语言专家预测当前子任务，并生成与连续动作专家预测相同的动作块的语言渲染。该共享接口连接了演示级程序结构与步骤级控制，而语言专家在推理时被移除。这不同于隐动作方法，后者将行为编码到视觉语言模型原生语义空间之外的学习隐变量中 [5, 50]。

2.2 测试时自适应与上下文条件视觉语言动作模型

机器人策略在部署时可通过更新模型参数或基于额外经验调节固定策略来实现自适应。测试时训练方法利用部署数据更新快速权重、隐提示或记忆 [12, 22, 43, 55]。相比之下，上下文条件方法保持策略参数不变，通过演示、检索经验或执行历史来调整行为 [31, 33, 39, 57]。近期工作进一步探索了视觉语言动作模型的上下文模仿与基于检索的自适应 [13, 20, 41]。

然而，所提供的上下文可能发挥截然不同的作用。 $\pi_{0.7}$ 基于子任务指令、

子目标图像、回合元数据与控制模式进行条件化，以指定执行策略 [36]，而 Qwen-RobotManip 利用最近的观测-状态-动作块来适应当前回合的动态 [38]。StellaVLA 则检索先前的演示，并将其转换为由段级子任务与基于二维/三维运动的结构化程序上下文。因此，检索到的回合作为明确的任务演示，而非仅仅是额外的执行历史，从而无需参数更新即可实现自适应。

2.3 人类与跨具身演示

人类视频和异构机器人数据相比单一平台演示提供了更广泛的行为覆盖，但在具身和动作空间上存在差异。先前工作通过共享潜在动作、跨具身运动表示、世界模型、视频条件化、重定向或规范化动作空间来解决这一不匹配问题 [3, 6, 7, 14, 18, 38, 44]。

StellaVLA 则在表示层面处理跨具身演示。真实机器人、人手和扩展现实重定向的演示在检索前被转换为语义子任务和接地运动的通用结构化表示。关键的是，非具身演示仅用作上下文，可执行动作始终在目标机器人的原生控制空间中预测和监督。这种分离允许异构演示提供程序性指导，而无需其源动作空间与目标策略直接对齐。

3 方法论

在本节中，我们详细介绍了 **StellaVLA** 框架，如图 2 所示，该框架通过结构化上下文理由推进了交互式模仿学习，以提高视觉-语言-动作模型的泛化能力。我们首先提出一个自动化离线流程，将原始轨迹转换为理由增强的片段（第 3.1 节），然后引入一种并行双训练范式，将这些轨迹同时用作显式监督和上下文提示（第 3.2 节），最后描述一种非对称推理策略，使控制环路免于自回归解码开销（第 3.3 节）。

3.1 离线结构化上下文提取

原始轨迹表述。专家演示被记录为 $\tau = \{(o_t, a_t)\}_{t=1}^T$ ，其中 o_t 表示感官输入（例如，多视角 RGB 和本体感觉）， $a_t \in \mathbb{R}^{d_a}$ 是连续控制命令（例如，末端执行器位姿和夹爪状态）。此类轨迹可能来自不同的具身和采集范式，包括真实机器人遥操作、人手跟踪或扩展现实重定向演示 [44]。尽管它们封装了成功的执行，但原始数值动作缺乏明确的语义理由，这阻碍了跨具身推理。

基于因果推理的语义分割。为了在不产生高昂人工标注成本的情况下弥合语义鸿沟，本文引入了一条自动化的离线处理流程（图 2 右），用于推断专家的潜在思维过程。其核心动机是从“结果”（观察到的物理执行）反推“原因”（专家潜在的结构化推理）。给定一条原始轨迹 τ 及其对应的高层任务指令 $\mathcal{I}$ ，本文利用现成的强大视觉语言模型（例如 Qwen3-VL）将连续轨迹显式分解为 K 个离散的、具有语义意义的片段。对于从时间步 $t_{\text{start}}^{(k)}$ 到 $t_{\text{end}}^{(k)}$ 的每个片段 $k \in \{1, \dots, K\}$ ，视觉语言模型分析视觉变化以识别所达成的高层子目标。这一过程捕捉了支配专家行为的真实决策过程。




图 2 StellaVLA 概览。左上：检索到的上下文演示被表示为一个任务计划和一系列子目标，每个子目标包含关键帧、机器人状态、二维迹和三维运动。右：这些标注由视觉语言模型推理和机器人轨迹自动离线生成，无需人工标注。左下：视觉语言模型将演示与当前观测和指令编码为共享表示，该表示由动作专家用于动作预测，并由空间语言专家仅在训练期间提供辅助监督。空间语言专家在推理时被移除，仅需一次前向传播。

基于语言即动作的运动学语言化。一旦轨迹被分割，本文采用“语言即动作”范式，将每个片段内的物理动作确定性转换为结构化文本。由于视觉语言动作模型建立在视觉语言模型之上，对语义语言具有强亲和力 [15, 54]，这些推理过程可以利用原始文本词汇表进行处理，而无需引入专门的动作标记。

最终，这一双层过程为每个片段生成结构化上下文 $\bar{l}_k$ ，通过层次化表示明确阐述其底层逻辑：

- **语义推理（子目标描述）**：捕捉该片段中达成的高层语义目标（例如，“伸向蓝色马克杯的把手”），由视觉语言模型基于视觉观测自动识别。
- **运动学原理（运动描述）**：将细粒度运动表述为工作空间中的三维运动（例如，“将末端执行器移动 $\Delta x = +0.05$, $\Delta y = -0.02$, $\Delta z = +0.10$ 并闭合夹爪”）以及通过将三维轨迹投影到已知内参和外参的相机平面上得到的二维运动。这种双重形式鼓励视觉语言模型通过文本标记来推理空间逻辑和视觉定位，而不是输出原始的浮点动作。

两个运动学字段均由单一确定性表述器 Φ 生成，该表述器将任意连续的动作片段映射为其在工作空间中的三维位移以及该位移在图像平面上的二维投影。对整个片段应用 Φ 可得到 $\bar{l}_k$ 内部携带的运动描述；我们在第 3.2 节中以短得多的动作块尺度复用同一算子，正是这一点将检索到的演示与策略自身的预测置于一个共同的词汇表中。相比之下，子目标描述附加到每一帧：每个步骤 t 携带专家在观测 o_t 中正在执行的子任务 s_t 。

带原理增强的演示池。通过这一过程，原始原始轨迹 τ 被转换为带原理增强的轨迹 $\tau_{\text{rat}} = \{(o_t, a_t, s_t, \bar{l}_k)\}_{t=1}^T$ ，其中每个时间步 t 现在不仅由其对应的观测和动作所锚定，还由其自身的子任务标签 s_t 以及

其所属片段的显式片段级结构化原理 $\bar{l}_k$ 所锚定。通过该流水线处理所有可用的专家演示，我们构建了一个全面的演示池 $\mathcal{D}_{\text{pool}} = \{\tau_{\text{rat}}^{(i)}\}_{i=1}^N$ 。

3.2 并行双训练范式

检索增强提示构建。在训练过程中，学习过程被形式化为留一法检索任务。为了训练策略模仿从 $\mathcal{D}_{\text{pool}}$ 中采样的特定目标轨迹 τ_{tgt} ，系统查询剩余池 $\mathcal{D}_{\text{pool}} \setminus \{\tau_{\text{tgt}}\}$ ，并根据任务指令的语言嵌入之间的余弦相似度排序，检索出排名第一的带理由增强的专家轨迹。因此，检索纯粹基于语言，这使得在另一具身上记录的演示能够被检索用于机器人片段。检索到的轨迹被格式化为上下文前缀提示 $\mathcal{P}_{\text{demo}}$ 。在时间步 t ，VLA 模型的最终输入由检索到的演示、当前任务指令 $\mathcal{I}$ 和当前观测 o_t 拼接而成：

$$x_t = [\mathcal{P}_{\text{demo}} \oplus \mathcal{I} \oplus o_t] \quad (1)$$

关键在于，由于 $\mathcal{P}_{\text{demo}}$ 包含来自专家的丰富 $\bar{l}_k$ 描述，它充当隐式的上下文学习（In-Context Learning, ICL）信号，为模型提供在类似场景中如何“思考”和规划的认知模板。

并行专家架构。我们的 VLA 策略核心是一个统一的视觉语言模型骨干 f_θ ，配备两个并行专家（图 2，左下）。给定输入 x_t ，骨干将多模态序列处理为共享潜在表示 $h_t = f_\theta(x_t)$ 。这个单一潜在向量随后同时馈入：1. 动作专家，一个轻量级 MLP 头，回归跨越接下来 H 个控制步骤的连续动作块 $\hat{A}_t = (\hat{a}_t, \dots, \hat{a}_{t+H-1})$ 。

2. 空间语言专家，即原生自回归语言模型头，输出当前步骤的理由 $\hat{c}_t = (\hat{s}_t, \hat{m}_t)$ ：正在 o_t 中执行的子任务 $\hat{s}_t$ ，以及同一动作块的口头化 3D 和 2D 运动 $\hat{m}_t$ 。

必须注意，这两个专家严格并行运行。动作预测在时间步 t 并不因果依赖于生成的文本标记。它们共享表示 h_t ，除此之外没有其他共享。

空间语言监督。虽然检索到的演示提供片段级上下文，但空间语言监督在每个时间步被定义为

$$c_t = (s_t, \Phi(A_t)), \quad (2)$$

其中 s_t 是子任务标签， $o_t, A_t = (a_t, \dots, a_{t+H-1})$ 是真实动作块， $\Phi(A_t)$ 用语言描述其三维和二维运动。子任务标签为当前任务阶段提供语义监督；二维运动将预测与 o_t 对齐，而三维运动在工作空间中提供运动学监督。

双重理由目标。在训练过程中，模型被优化以最小化联合目标：

$$\mathcal{L} = \mathcal{L}_{\text{act}}(\hat{A}_t, A_t) + \lambda \mathcal{L}_{\text{lang}}(\hat{c}_t, c_t) \quad (3)$$

其中 $\mathcal{L}_{\text{act}}$ 是连续控制命令的回归损失（例如 L_1 损失）， $\mathcal{L}_{\text{lang}}$ 是结构化理由文本生成的标准自回归交叉熵损失， λ 是平衡系数。

两个专家为共享表示 $\bar{h}_t$ 提供互补监督。由于 Φ 是确定性的， $\bar{A}_t$ 和 $\Phi(\bar{A}_t)$ 以连续和语言形式描述相同的运动。 $\bar{c}_t$ 中显式的语义、对齐和运动学监督与 $\mathcal{P}_{\text{demo}}$ 的上下文引导共同鼓励 $\bar{h}_t$ 将演示的任务结构和当前观察与时间 t 所需的机器人运动联系起来。

3.3 非对称推理与缓存

仅动作执行。 标准具身思维链范式的一个根本局限是推理过程中自回归文本生成引入的严重延迟 [17, 25, 51, 59]，这常常破坏高频机器人控制的严格时序要求。我们的并行架构优雅地解决了这一瓶颈。由于动作专家和空间语言专家独立地从 $\bar{h}_t$ 读取信息，且深刻的物理“心智模型”已在训练期间通过 $\mathcal{L}_{\text{lang}}$ 锻造到骨干权重中，语言读出在部署时严格可选。

在推理过程中，自回归空间语言专家被完全移除。策略通过骨干网络和轻量级多层感知机动作专家执行一次前向传播，输出动作块 $\bar{A}_t$ 。这种非对称策略将推理的获取（在训练阶段付出代价）与其执行解耦，因此连续控制不产生自回归解码开销。

演示前缀缓存。 为进一步优化推理效率，我们利用检索到的上下文 [48] 的静态特性。对于给定的新任务，检索到的富含推理的演示前缀 $\mathcal{P}_{\text{demo}}$ 被固定在回合开始时，并在整个回合期间保持不变。因此，整个前缀的键值缓存仅在 $t = 1$ 处计算一次。对于所有后续时间步，策略只需前向传播实时后缀（当前观测 $\bar{o}_t$ ），从而大幅降低计算开销。这种缓存机制确保携带丰富的多步推理演示在高频控制循环中几乎不产生边际成本。

4 实验

我们评估四个问题：（一）结构化演示是否能在任务和视觉变化下提升分布内性能与泛化能力；（二）策略是否使用检索到的演示，以及其中哪些部分携带可迁移信息；（三）空间语言监督如何影响所学表示；（四）所得策略能否在不牺牲部署效率的情况下利用跨具身上下文。

4.1 实验设置

模型与训练。 StellaVLA 将 Qwen3-VL-4B 骨干网络 [1] 与 OpenVLA-OFT 风格的多层感知机动作专家 [24] 相结合。每一步，模型接收第三人称和腕部 RGB 观测、机器人状态的语言渲染、任务指令以及一个检索到的同任务结构化演示。动作专家在 L_1 目标下回归动作块。同时，空间语言专家通过交叉熵（权重 $\lambda = 0.3$ ）训练，以预测当前子任务以及同一动作块的二维/三维描述。子任务、二维运动和三维运动分别提供语义、视觉接地和运动学监督。空间语言专家在推理时不被解码。

所有模型均从 Qwen3-VL-4B-Instruct 全量微调 30k 步，全局批大小为 128。当同任务演示始终可用时，上下文演示随机失活为 0.0 ，否则为 0.5 。附录 A 给出了优化、检索和平台相关的细节。

协议与匹配对照。 我们报告每个基准官方协议下的任务成功率。




图 3 三个仿真基准。顶部：四个标准 LIBERO 套件。中部：LIBERO-Plus 扰动轴，例如相机视角、光照、传感器噪声和背景纹理。底部：VLA-Arena，它改变任务，增加安全约束、干扰物、对未见物体的外推以及长时程组合。

StarVLA-OFT [42] 使用与 StellaVLA 相同的主干网络、动作专家和数据训练，但不接收检索到的演示或空间语言监督。因此，它衡量的是完整 StellaVLA 设计带来的增益，而非任一单独组件的贡献。为了隔离上下文的作用，表 5 改为在固定的 StellaVLA 检查点上干预，在评估时提供正确、无或错误任务的演示。

4.2 仿真中的泛化

我们首先在三个仿真基准上评估 StellaVLA，如图 3 所示，考察分布内能力、任务级泛化和零样本鲁棒性。

4.2.1 LIBERO 上的分布内验证。

StellaVLA 在 LIBERO 上达到 98.8% 的平均成功率（表 1），表明结构化上下文不会损害分布内性能。相对于 StarVLA-OFT，在 Object 上的提升较小（ $+0.4$ ），但在 Goal（ $+3.4$ ）和 Long（ $+3.0$ ）上提升更大，因为仅凭当前观测可能无法确定预期结果或子目标顺序。当在评估时移除或替换演示时，同样的模式变得更加明显（表 5）。

Method	Spatial	Object	Goal	Long	Avg.
MemoryVLA [39]	98.4	98.4	96.4	93.4	96.7
ACoT-VLA [60]	99.4	99.6	98.8	96.0	98.5
AVA-VLA [46]	99.2	99.6	97.9	96.2	98.2
StarVLA-OFT	97.8	98.6	96.2	93.8	96.6
CogVLA [26]	98.6	98.8	96.6	95.4	97.4
Retrieval-VLA [57]	97.4	98.8	96.3	89.5	95.5
DreamVLA [56]	97.5	94.0	89.5	89.5	92.6
StellaVLA (Ours)	99.6	99.0	99.6	96.8	98.8

表 1 标准 LIBERO 基准 [30] 上的分布内成功率 (%)。每个套件在 500 次 rollout 上评估；基线数字如原始论文所报告，除了我们匹配的无演示对照 StarVLA-OFT [42]。每列最佳以粗体显示。

4.2.2 VLA-Arena 上的任务级泛化。

VLA-Arena [53] 在四个类别的 11 个套件上评估任务级泛化：安全性、干扰物、外推和长时程。每个套件包含三个难度级别，从 L0（分布内）到 L2（最难），而训练仅使用 L0 数据。我们遵循官方协议，并与 OpenVLA-OFT [24]、LingBot-VLA [45]、Motus [3]、GR00T-N1.6 [32]、Evo-Depth [27] 和 $\pi_{0.5}$ [37] 进行比较。在测试时，StellaVLA 接收目标任务的一个结构化演示，无需任何参数更新。如表 2 所示，StellaVLA 在三个级别上均达到最佳平均成功率：0.84, 0.62、0.43 on L0, L1 和 L2。其总分为 0.63，而最强基线为 0.44， $\pi_{0.5}$ 。相对于 $\pi_{0.5}$ 的差距从 L0 的 0.15 扩大到 L1 的 0.24，并在 L2 保持 0.17，此时不进行参数更新，仅提供目标任务演示。

每个套件的结果进一步界定了这一提升。StellaVLA 在 Unseen Objects 上三个级别均保持 0.80，这与在对象指称变化时迁移程序一致。Task Workflows 从 L0 的 0.64 上升到 L2 的 0.84，表明当测试 workflow 偏离训练时，上下文可能变得更加有用。Long Horizon 在 L1/L2 上对所有方法（包括我们的方法）都保持接近零：固定前缀指定了程序，但无法在执行漂移后重新规划。

4.2.3 LIBERO-Plus 上的零样本鲁棒性。

LIBERO-Plus [10] 沿七个轴扰动 LIBERO 任务：视角、机器人状态、传感器噪声、物体布局、背景、光照和语言。我们在不重新训练的情况下评估 LIBERO 训练的检查点，并与 [10] 中报告的零样本基线进行比较。StellaVLA 平均达到 85.1%（表 3），比 StarVLA-OFT 高出 10.1 个百分点。最大的提升出现在相机视角（+23.5）、传感器噪声（+19.7）、机器人初始状态（+14.7）和语言扰动（+8.3）下，此时观察或指令发生变化，而任务流程保持不变。

较小的提升也具有信息量。背景和光照对两个模型来说都已接近饱和，几乎没有改进空间。在物体布局变化下，StellaVLA 仅获得 0.1 个百分点的提升，因为演示中场景特定的空间关系不再匹配当前场景。因此，结构化上下文比固定的空间轨迹更可靠地传递任务流程。

4.3 真实世界与跨具身评估

平台、任务与数据。我们在 6 自由度 AgileX Piper 机械臂上进行评估，配备第三人称和腕部 RGB 相机。基准包含四个桌面任务：精确笔到杯放置、胡萝卜到碗的拾取与放置、将积木放入抽屉并关闭、堆叠三个碗。我们收集了 125 个遥操作

Task Suite	OpenVLA-OFT			LingBot-VLA			Motus			GR00T-N1.6			Evo-Depth			$\pi_{0.5}$			StellaVLA		
	L0	L1	L2	L0	L1	L2	L0	L1	L2	L0	L1	L2	L0	L1	L2	L0	L1	L2	L0	L1	L2
<i>Safety</i>																					
Static Obst.	0.89	0.25	0.21	0.47	0.00	0.00	0.82	0.56	0.19	0.72	0.30	0.14	0.88	0.66	0.48	0.90	0.64	0.50	1.00	1.00	0.80
Cautious Grasp	0.67	0.32	0.00	0.21	0.00	0.00	0.76	0.07	0.19	0.16	0.02	0.00	0.78	0.24	0.00	0.38	0.16	0.00	0.80	0.50	0.10
Hazard Avoid.	0.42	0.00	0.09	0.16	0.00	0.00	0.43	0.24	0.16	0.64	0.04	0.10	0.40	0.00	0.14	0.62	0.40	0.28	0.62	0.92	0.70
State Pres.	0.99	0.75	0.38	0.54	0.00	0.00	0.85	0.47	0.49	0.66	0.50	0.38	0.88	0.66	0.56	0.80	0.80	0.74	0.92	0.90	0.62
Dynamic Obst.	0.75	0.55	0.05	0.40	0.00	0.00	0.43	0.35	0.26	0.74	0.50	0.02	0.82	0.60	0.06	0.54	0.70	0.26	0.80	0.60	0.02
<i>Distractor</i>																					
Static Distr.	0.99	0.13	0.15	0.93	0.15	0.11	0.75	0.19	0.03	0.46	0.32	0.06	0.94	0.20	0.24	0.90	0.04	0.14	1.00	0.56	0.20
Dynamic Distr.	0.90	0.56	0.39	0.88	0.61	0.17	0.73	0.60	0.33	0.70	0.72	0.18	0.86	0.60	0.32	0.88	0.72	0.56	1.00	0.72	0.60
<i>Extrapolation</i>																					
Prep. Comb.	0.54	0.09	0.00	0.46	0.05	0.01	0.13	0.00	0.00	0.48	0.00	0.00	0.66	0.00	0.00	0.54	0.04	0.00	0.70	0.14	0.00
Task Workflows	0.53	0.03	0.13	0.37	0.05	0.11	0.32	0.00	0.02	0.42	0.00	0.00	0.32	0.00	0.00	0.52	0.22	0.26	0.64	0.66	0.84
Unseen Obj.	0.61	0.39	0.19	0.34	0.32	0.15	0.59	0.55	0.13	0.26	0.18	0.16	0.78	0.52	0.04	0.64	0.50	0.08	0.80	0.80	0.80
<i>Long Horizon</i>																					
Long Horizon	0.80	0.00	0.00	0.82	0.03	0.00	0.64	0.05	0.03	0.29	0.02	0.00	0.93	0.00	0.00	0.87	0.00	0.00	1.00	0.02	0.00
<i>Mean</i>	0.74	0.28	0.14	0.51	0.11	0.05	0.59	0.28	0.17	0.50	0.24	0.09	0.75	0.32	0.17	0.69	0.38	0.26	0.84	0.62	0.43
<i>Overall</i>	0.39			0.22			0.34			0.28			0.41			0.44			0.63		

表 2 在 VLA-Arena 上三个难度级别的成功率：L0（分布内）、L1（中级泛化）和 L2（最难）。行是按四个类别（安全、干扰、外推、长时程）分组的 11 个任务套件。分数是 $[0, 1]$ 中的小数。基线结果来自 VLA-Arena 排行榜 [53]。每列最佳以粗体显示。

机器人片段（71,702 帧），涵盖精确操作、关节物体和多阶段操作。

跨源演示池。检索池将机器人片段与在扩展现实（XR）中记录的 26 段人手操作以及 26 条重定向到 Piper 的帧对齐轨迹相结合。所有三种来源都被转换为相同的结构化表示。二维定位点在人类手腕和机器人法兰之间对齐，非本体帧仅用作检索上下文：所有可执行的动作目标仍来自真实机器人。

协议与基线。我们评估了四个分布内任务、两个分布外一级（OOD-L1）物体属性扰动，以及一个未见过的分布外二级（OOD-L2）抽屉任务，每个单元进行 10 次 rollout。物体放置位置被重新随机化，并在各方法间保持一致。StarVLA-OFT 是完整 StellaVLA 设计的匹配对照，而单独预训练的 $\pi_{0.5}$ [37] 在相同片段上微调，作为外部参考。附录 B 详细说明了控制栈、扰动、成功标准和进度度量。

结果。StellaVLA 在分布内达到 85.0% 成功率，在 OOD-L1 上达到 75.0%（图 4）。在具有 L1 变体的两个任务上，其平均值从分布内的 80.0% 下降到 75.0%，下降了 5 个百分点；StarVLA-OFT 和 $\pi_{0.5}$ 在相同任务上分别下降了 25 和 20 个百分点。这种较小的配对退化表明在物体属性变化时具有更强的鲁棒性，尽管 StarVLA-OFT 的比较同时衡量了演示和空间语言监督。

没有方法能完成未见过的 OOD-L2 任务。然而，StellaVLA 的平均进度得分达到了 1.9（满分 4 分），相比之下， $\pi_{0.5}$ 为 1.5，StarVLA-OFT 为 1.1。这种部分进展表明检索到的程序仍然有用，但并不构成零样本任务完成。

Demo pair	ID	OOD
$D(\text{real}, \text{none})$	0.0041	0.0045
$D(\text{human}, \text{none})$	0.0041	0.0044
$D(\text{xr}, \text{none})$	0.0041	0.0044
$D(\text{human}, \text{real})$	0.0015	0.0014
$D(\text{xr}, \text{real})$	0.0015	0.0016
$D(\text{human}, \text{xr})$	0.0014	0.0014

表 4 仅改变演示源时的归一化动作不一致性。

	方法	原始	相机	机器人	噪声	布局	背景	光照	语言	平均
OpenVLA	76.5	1.1	4.1	19.3	31.6	25.3	4.4	26.8	16.0	
OpenVLA-OFT	97.1	59.7	37.2	76.7	77.1	92.4	85.8	81.5	71.4	
π_0	94.2	15.8	6.6	79.4	70.4	78.5	79.6	61.0	53.8	
π_0 -FAST	85.5	66.4	24.8	75.8	70.3	67.7	73.0	63.3	62.5	
Nora	87.9	4.0	41.1	17.6	63.9	50.5	31.0	67.0	38.7	
WorldVLA	79.1	0.3	30.2	12.2	39.4	14.5	29.4	44.2	24.3	
UniVLA	95.2	4.3	50.3	25.3	34.3	80.0	59.1	71.8	44.0	
RIPT-VLA	97.5	58.3	36.7	73.8	76.5	90.4	87.9	80.1	70.4	
StarVLA-OFT	96.6	47.0	60.1	73.1	79.2	95.3	96.3	87.0	75.0	
StellaVLA	98.8	70.5	74.8	92.8	79.3	95.2	95.7	95.3	85.1	

表 3 LIBERO-Plus 上的零样本鲁棒性 [10]；所有模型均在标准 LIBERO 上训练，并在扰动任务上测试，无需重新训练。平均值为七个扰动类别上的任务计数加权均值，不包括原始类别。每列最佳结果以粗体显示。

跨源一致性。

上述混合源回放无法隔离演示来源的影响，因为每个单元都从所有三个来源采样。因此，我们在保持当前观测不变、仅改变检索来源的情况下，在留出的遥操作片段上评估固定检查点。我们测量预测动作块之间的平均 L_1 不一致性 $D(S_1, S_2)$ ，并按真实动作的逐维标准差 σ 进行归一化。配对的人类和 XR 重定向演示共享相同的轨迹和时间，因此它们的比较改变了具身外观，而未改变演示行为。

在 1,780 分布内和 1,719 分布外帧中，表 4 显示真实机器人、人手和 XR 重定向上下文产生高度匹配的预测。源间不一致性为 $0.0014 - 0.0016\sigma$ ，相当于关节角度的 $0.02^\circ - 0.03^\circ$ ，且小于夹爪宽度的 0.05 毫米。这支持了三种结构化演示来源之间的一致性。

该测试仅限于单步预测。移除演示仅使动作改变 $0.0041 - 0.0045\sigma$ ，且微小差异在闭环执行中仍可能累积。因此，该结果建立了匹配观测下的源一致性，而非闭环不变性或上下文在硬件上的独立贡献。

4.4 理解结构化演示

除非另有说明，这些分析使用 LIBERO 检查点并报告四个套件的平均值 (AVG) and, where available, the LIBERO-Plus average (LP). Evaluation-time interventions change only the demonstration supplied to a fixed checkpoint.

Causal Role of the Demonstration. Table 5 evaluates the same trained checkpoint with the correct demonstration, no demonstration, and a demonstration from a different task. Removing the demonstration reduces the average success rate from 98.8 to 62.4, while providing a wrong-task demonstration further lowers it to 44.9. The latter result is particularly informative: if the policy largely ignored the retrieved context, missing and mismatched demonstrations would produce similar outcomes. Instead, the additional degradation shows that StellaVLA actively uses the demonstration to determine the intended task and adjusts its behavior accordingly, even when the supplied

Demo	Sp.	Obj.	Goal	Long	AVG
Correct	99.6	99.0	99.6	96.8	98.8
None	72.2	94.4	24.8	58.2	62.4
Wrong	72.6	52.0	0.0	55.0	44.9

表 5 评估时改变演示内容。




图 4 在 AgileX Piper 上的真实机器人评估。顶部：四个任务的分布内成功率。左下：OOD-L1，扰动物体属性，在任务内而非跨任务间具有可比性。右下：OOD-L2，一个未见过的任务，将积木放入第一个抽屉。场景如图 5 所示。

context is misleading.

各套件的结果进一步阐明了这种上下文规范何时重要。在 Goal 上，没有演示时性能降至 $[24.8]$ ，演示错误时降至 $[0.0]$ ，因为任务可能涉及相似的物体和场景，但需要不同的结果。因此，演示对于消除预期目标的歧义至关重要。相比之下，Spatial 在没有演示和错误演示时表现相似（ $[72.2]$ 和 $[72.6]$ ），这表明当前观察仍能提供关于交互应发生在何处的有用线索。这些结果直接证明，检索到的演示充当任务规范，而非被忽略为辅助视觉上下文。

空间-语言组件。 我们接下来隔离结构化演示中的两个运动场。移除三维运动使平均性能从 $[98.8]$ 降至 $[97.8]$ ，而移除二维夹爪路径则降至 $[97.3]$ 。尽管二维路径是同一物理运动的投影，但它直接将运动锚定在当前图像中。其更大的影响与二维组件提供视觉定位、三维组件提供工作空间级运动学信息相一致。本实验未隔离语义子任务标签，因此没有相应的移除结果。

演示模态。 表 7 考察了演示的哪一部分提供了有用的上下文。在评估时，纯文本演示几乎与完整的图像 $\oplus$ 文本输入相当，在 LIBERO 平均性能和 LIBERO-Plus 上分别达到 $[98.8/84.4]$ 和 $[98.8/85.1]$ 。相比之下，纯图像演示使性能降至 $[92.9/75.7]$ ，其中 Long 上的损失最大。这些结果表明，大部分可迁移的任务信息由结构化语言表示捕获，包括子目标序列和空间运动，而非仅由原始演示帧提供。这也支持跨具身使用演示，因为结构化描述抽象掉了大部分源特定的视觉外观。

表 7 的训练时模块揭示了一个互补的权衡。纯图像演示提供




图 5 真实机器人评估场景。上排：四个分布内任务。下排：其分布外变体。OOD-L1 将笔 $\rightarrow$ 杯的颜色和物体身份同时替换，而胡萝卜 $\rightarrow$ 碗仅替换颜色，因此 L1 在任务内可比而非跨任务可比；OOD-L2 将积木从第二个抽屉重定向到第一个抽屉，该任务没有真实机器人训练片段。

Demo modality	Sp.	Obj.	Goal	Long	AVG	LP
<i>Changed at evaluation (fixed checkpoint)</i>						
Image+Text	99.6	99.0	99.6	96.8	98.8	85.1
Text-only	99.0	99.8	99.8	96.6	98.8	84.4
Image-only	96.4	98.6	96.0	80.4	92.9	75.7
<i>Changed at training</i>						
Text-only	98.6	98.6	99.2	92.8	97.3	85.0
Image-only	99.4	99.4	98.8	95.8	98.4	78.7

表 7 演示模式，在固定检查点上评估时改变（上）和在训练时改变（下）。图像 $\pm$ 文本为默认设置。每个块内每列最佳值以粗体显示。

分布内性能略高于纯文本演示（98.4 vs. 97.3），但在 LIBERO-Plus 上的泛化能力显著较差（78.7 vs. 85.0）。一个合理的解释是，视觉演示允许策略利用演示与当前观测之间的外观对应关系，这在分布内有效，但在视觉扰动下变得不可靠。结构化语言消除了大部分这种捷径，反而鼓励策略依赖在分布偏移下更稳定的任务级和空间结构。

上下文粒度。当演示从十个子目标关键帧减少到三个时，性能仅变化 0.7 点（附录 C 表 9）。这种饱和现象表明，有用的上下文来自子目标序列，而非密集轨迹回放。

λ	AVG	LP
0	97.6	86.9
0.3	98.8	85.1
0.6	97.5	84.0
1.0	97.2	81.9

4.5 空间语言监督与部署

表 6 空间语言损失权重。

语言损失权重的影响。表 6 改变了空间-语言目标的权重 λ 。分布内平均遵循浅倒 U 形，并在 $\lambda = 0.3$ (98.8) 处达到峰值，而 LIBERO-Plus 鲁棒性从 86.9 在 $\lambda = 0$ 下降到 81.9 在 $\lambda = 1.0$ 。空间-语言

因此，监督在所选权重下提高了分布内精确率，但并未单调改善分布外鲁棒性；仅上下文条件化已提供强鲁棒性信号。一种可能的解释是，较大的语言权重过度强调了离线标注模式。我们使用 $\lambda = 0.3$ 作为最佳分布内设置。

推理效率。

表 8 将上下文编码的成本与语言解码分开。没有演示的前向传递需要 64 毫秒。添加图像+文本演示后，在没有缓存的情况下增加到 183 毫秒，而缓存不可变前缀将稳态成本降低到 91 毫秒。在配对测量中，仅动作路径需要 88 毫秒，而解码 83 个标记的空间语言输出将延迟增加到 3177 毫秒，大约慢 $36\times$ 倍。

Configuration	Cache	Latency
No demo	—	64
Image+Text	no	183
Image+Text	yes	91
Text-only	—	109
<i>Paired language decoding</i>		
Action only	yes	88
+ language	yes	3177

The 88–91 ms values measure the model-side path; the real-robot pipeline, including observation and control overhead, runs at approximately 205 ms per action chunk (Appendix B). Thus, removing the spatial-language expert avoids autoregressive decoding at deployment, while prefix caching amortizes demonstration encoding across the rollout.

表 8 推理延迟（毫秒）。

5 结论

我们提出了 **StellaVLA**，这是一个通过将检索到的专家演示转换为结构化上下文指导来改善 VLA 泛化的框架。自动化离线流水线从异构演示中提取分层语义和运动学原理，而并行双训练目标联合学习连续控制和空间语言推理。在推理时，移除空间语言专家，并对固定演示前缀进行 KV 缓存，使策略能够受益于结构化推理，而无需自回归语言解码开销。在 LIBERO、VLA-Arena、LIBERO-Plus 和真实世界操作上的实验表明，**StellaVLA** 保持了强大的分布内性能，同时显著提高了对任务和环境变化的鲁棒性，包括当演示来自不同实施例时。

6 作者列表

贡献者：徐思宇、王云科、王子健、朱迪豪、夏成浩、杜成斌、刘道昌、黄涛、徐畅。

参考文献

- [1] Shuai Bai, Yuxuan Cai, Ruizhe Chen, Keqin Chen, Xionghui Chen, et al. Qwen3-VL Technical Report. *arXiv preprint arXiv:2511.21631*, 2025.
- [2] Suneel Belkhale, Tianli Ding, Ted Xiao, Pierre Sermanet, Quon Vuong, Jonathan Tompson, Yevgen Chebotar, Debidatta Dwibedi, and Dorsa Sadigh. Rt-h: Action hierarchies using language. In <https://arxiv.org/abs/2403.01823>, 2024.
- [3] Hongzhe Bi, Hengkai Tan, Shenghao Xie, Zeyuan Wang, Shuhe Huang, Haitian Liu, Ruowen Zhao, Yao Feng, Chendong Xiang, Yinze Rong, Hongyan Zhao, Hanyu Liu, Zhizhong Su, Lei Ma, Hang Su, and Jun Zhu. Motus: A Unified Latent Action World Model. *arXiv preprint arXiv:2512.13030*, 2025.
- [4] Kevin Black, Noah Brown, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Lachy Groom, Karol Hausman, Brian Ichter, Szymon Jakubczak, Tim Jones, Liyiming Ke, Sergey Levine, Adrian Li-Bell, Mohith Mothukuri, Suraj Nair, Karl Pertsch, Lucy Xiaoyang Shi, James Tanner, Quan Vuong, Anna Walling, Haohuan Wang, and Ury Zhilinsky. π_0 : A Vision-Language-Action Flow Model for General Robot Control. *arXiv preprint arXiv:2410.24164*, 2024.
- [5] Qingwen Bu, Yanting Yang, Jisong Cai, Shenyuan Gao, Guanghui Ren, Maoqing Yao, Ping Luo, and Hongyang Li. Univla: Learning to act anywhere with task-centric latent actions. *arXiv preprint arXiv:2505.06111*, 2025.
- [6] Qingwen Bu, Yanting Yang, Jisong Cai, Shenyuan Gao, Guanghui Ren, Maoqing Yao, Ping Luo, and Hongyang Li. UniVLA: Learning to Act Anywhere with Task-Centric Latent Actions. *arXiv preprint arXiv:2505.06111*, 2025.
- [7] Guangyan Chen, Meiling Wang, Qi Shao, Zichen Zhou, Weixin Mao, Te Cui, Minzhao Zhu, Yinan Deng, Luojie Yang, Zhanqi Zhang, Yi Yang, Hua Chen, and Yufeng Yue. See Once, Then Act: Vision-Language-Action Model with Task Learning from One-Shot Video Demonstrations. *arXiv preprint arXiv:2512.07582*, 2025.
- [8] William Chen, Jagdeep Singh Bhatia, Catherine Glossop, Nikhil Mathihalli, Ria Doshi, Andy Tang, Danny Driess, Karl Pertsch, and Sergey Levine. Steerable Vision-Language-Action Policies for Embodied Reasoning and Hierarchical Control. *arXiv preprint arXiv:2602.13193*, 2026.
- [9] Irving Fang, Juexiao Zhang, Shengbang Tong, and Chen Feng. From intention to execution: Probing the generalization boundaries of vision-language-action models. *arXiv preprint arXiv:2506.09930*, 2025.
- [10] Senyu Fei, Siyin Wang, Junhao Shi, Zihao Dai, Jikun Cai, Pengfang Qian, Li Ji, Xinzhe He, Shiduo Zhang, Zhaoye Fei, Jinlan Fu, Jingjing Gong, and Xipeng Qiu. LIBERO-Plus: In-depth Robustness Analysis of Vision-Language-Action Models. *arXiv preprint arXiv:2510.13626*, 2025.
- [11] Yixu Feng, Zinan Zhao, Yanxiang Ma, Chenghao Xia, Chengbin Du, Yunke Wang, and Chang Xu. See what matters: Differentiable grid sample pruning for generalizable vision-language-action model. In *Forty-third International Conference on Machine Learning*, 2026.
- [12] Yusen Feng, Bingchen Han, Jiangran Lyu, Kai Liu, Yixin Zheng, Yuxuan Wan, Weiheng Liu, Sun Han, Ruiqin Li, Yulong Zhang, Fangfu Liu, Xuesong Shi, Libin Liu, Yizhou Wang, Zhizheng Zhang, and He Wang. WAM-TTT: Steering World-Action Models by Watching Human Play at Test Time. *arXiv preprint arXiv:2607.06988*, 2026.
- [13] Letian Fu, Huang Huang, Gaurav Datta, Lawrence Yunliang Chen, William Chung-Ho Panitch, Fangchen Liu, Hui Li, and Ken Goldberg. Icr: In-context imitation learning via next-token prediction. In *IEEE International Conference on Robotics and Automation (ICRA)*, 2025.
- [14] Shenyuan Gao, William Liang, Kaiyuan Zheng, Seonghyeon Ye, Qianli Ma, Ruijie Zheng, Pieter Abbeel, Yuke Zhu, Joel Jang, Linxi Fan, et al. DreamDojo: A Generalist Robot World Model from Large-Scale Human Videos. *arXiv preprint arXiv:2602.06949*, 2026.
- [15] Asher J. Hancock, Xindi Wu, Lihan Zha, Olga Russakovsky, and Anirudha Majumdar. Actions as Language: Fine-Tuning VLMs into VLAs Without Catastrophic Forgetting. *arXiv preprint arXiv:2509.22195*, 2025.

- [16] Sib0 He, Weiyang Xie, Daixun Li, Junhao Zhong, Jiayun Tian, Yunke Wang, Leyuan Fang, Gang He, and Yunsong Li. Motion dynamics learning for few-shot embodied adaptation. In *Forty-third International Conference on Machine Learning*.
- [17] Chi-Pin Huang, Yueh-Hua Wu, Min-Hung Chen, Frank Wang, and Fu-En Yang. Thinkact: Vision-language-action reasoning via reinforced visual latent planning. *Advances in Neural Information Processing Systems*, 38: 82782–82802, 2026.
- [18] Chenyu Hui, Xiaodi Huang, Siyu Xu, Yunke Wang, Shan You, Fei Wang, Tao Huang, and Chang Xu. Seeing realism from simulation: Efficient video transfer for vision-language-action data augmentation. *arXiv preprint arXiv:2605.02757*, 2026.
- [19] Chia-Yu Hung, Qi Sun, Pengfei Hong, Amir Zadeh, Chuan Li, U.-Xuan Tan, Navonil Majumder, and Soujanya Poria. NORA: A Small Open-Sourced Generalist Vision Language Action Model for Embodied Tasks. *arXiv preprint arXiv:2504.19854*, 2025.
- [20] Sanghwan Jang, Minjin Jeon, Minsoo Kim, Seong Jin Choi, Dongha Kim, and Hwanjo Yu. Ra-vla: Retrieval-augmented vla for test-time adaptation. In *Proceedings of the 43rd International Conference on Machine Learning*. PMLR, 2026. URL <https://openreview.net/forum?id=ut6HebnnQe>.
- [21] Sanghwan Jang, Minjin Jeon, Minsoo Kim, Seong Jin Choi, Dongha Kim, and Hwanjo Yu. Ra-vla: Retrieval-augmented vla for test-time adaptation. In *Forty-third International Conference on Machine Learning*, 2026.
- [22] Yunfan Jiang, Yevgen Chebotar, Ruijie Zheng, Fengyuan Hu, Yunhao Ge, Jimmy Wu, Tianyuan Dai, Scott Reed, Li Fei-Fei, and Yuke Zhu. RoboTTT: Context Scaling for Robot Policies. *arXiv preprint*, 2026.
- [23] Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, Ted Xiao, Ashwin Balakrishna, Suraj Nair, Rafael Rafailov, Ethan Foster, Grace Lam, Pannag Sanketi, Quan Vuong, Thomas Kollar, Benjamin Burchfiel, Russ Tedrake, Dorsa Sadigh, Sergey Levine, Percy Liang, and Chelsea Finn. OpenVLA: An Open-Source Vision-Language-Action Model. *arXiv preprint arXiv:2406.09246*, 2024.
- [24] Moo Jin Kim, Chelsea Finn, and Percy Liang. Fine-Tuning Vision-Language-Action Models: Optimizing Speed and Success. *arXiv preprint arXiv:2502.19645*, 2025.
- [25] Jason Lee, Jiafei Duan, Haoquan Fang, Yuquan Deng, Shuo Liu, Boyang Li, Bohan Fang, Jieyu Zhang, Yi Ru Wang, Sangho Lee, et al. Molmoact: Action reasoning models that can reason in space. *arXiv preprint arXiv:2508.07917*, 2025.
- [26] Wei Li, Renshan Zhang, Rui Shao, Jie He, and Liqiang Nie. CogVLA: Cognition-Aligned Vision-Language-Action Model via Instruction-Driven Routing & Sparsification. *arXiv preprint arXiv:2508.21046*, 2025.
- [27] Tao Lin, Yuxin Du, Jiting Liu, Nuobei Zhu, Yunhe Li, Yuqian Fu, Yinxinyu Chen, Hongyi Cai, Zewei Ye, Bing Cheng, Kai Ye, Yiran Mao, Yilei Zhong, MingKang Dong, Junchi Yan, Gen Li, and Bo Zhao. Evo-Depth: A Lightweight Depth-Enhanced Vision-Language-Action Model. *arXiv preprint arXiv:2605.14950*, 2026.
- [28] Tao Lin, Yuxin Du, Yiran Mao, Zewei Ye, Yilei Zhong, Bing Cheng, Yiming Wang, Jiting Liu, Yang Tian, Junchi Yan, Feiran Wu, Zenan Meng, Hu Wei, Yuqian Fu, Gen Li, and Bo Zhao. LA4VLA: Learning to Act without Seeing via Language-Action Pretraining. *arXiv preprint arXiv:2606.27295*, 2026.
- [29] Tao Lin, Yuxin Du, Yiran Mao, Zewei Ye, Yilei Zhong, Bing Cheng, Yiming Wang, Jiting Liu, Yang Tian, Junchi Yan, et al. La4vla: Learning to act without seeing via language-action pretraining. *arXiv preprint arXiv:2606.27295*, 2026.
- [30] Bo Liu, Yifeng Zhu, Chongkai Gao, Yihao Feng, Qiang Liu, Yuke Zhu, and Peter Stone. LIBERO: Benchmarking Knowledge Transfer for Lifelong Robot Learning. *arXiv preprint arXiv:2306.03310*, 2023.
- [31] LocoFormer. LocoFormer: Generalist Locomotion via Long-Context Adaptation. OpenReview, 2025.
- [32] NVIDIA, Johan Bjorck, Fernando Castañeda, Nikita Cherniadev, Xingye Da, Runyu Ding, Linxi Jim Fan, Yu Fang, Dieter Fox, Fengyuan Hu, Spencer Huang, Joel Jang, Zhenyu Jiang, Jan Kautz, Kaushil Kundalia, Lawrence Lao, Zhiqi Li, Zongyu Lin, Kevin Lin, Guilin Liu, Edith Llonet, Loic Magne, Ajay Mandlekar, Avnish Narayan, Soroush Nasiriany, Scott Reed, You Liang Tan, Guanzhi Wang, Zu Wang, Jing Wang, Qi Wang, Jiannan Xiang,

- Yuqi Xie, Yinzhen Xu, Zhenjia Xu, Seonghyeon Ye, Zhiding Yu, Ao Zhang, Hao Zhang, Yizhou Zhao, Ruijie Zheng, and Yuke Zhu. GR00T N1: An Open Foundation Model for Generalist Humanoid Robots. *arXiv preprint arXiv:2503.14734*, 2025.
- [33] Austin Patel, Ben Pekarek, Joel Enrique Castro Hernandez, and Shuran Song. Behavior Prompting Policy: Demonstrations as Prompts for Manipulation. *arXiv preprint arXiv:2606.30457*, 2026.
- [34] Xiaohuan Pei, Yuxing Chen, Siyu Xu, Yunke Wang, Yuheng Shi, and Chang Xu. Action-aware dynamic pruning for efficient vision-language-action manipulation. In *International Conference on Learning Representations*, volume 2026, pages 10832–10851, 2026.
- [35] Karl Pertsch, Kyle Stachowicz, Brian Ichter, Danny Driess, Suraj Nair, Quan Vuong, Oier Mees, Chelsea Finn, and Sergey Levine. FAST: Efficient Action Tokenization for Vision-Language-Action Models. *arXiv preprint arXiv:2501.09747*, 2025.
- [36] Physical Intelligence. $\pi_{0.7}$: A Steerable Generalist Robotic Foundation Model with Emergent Capabilities. *arXiv preprint arXiv:2604.15483*, 2026.
- [37] Physical Intelligence, Kevin Black, Noah Brown, James Darpinian, Karan Dhabalia, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Manuel Y. Galliker, Dibya Ghosh, Lachy Groom, Karol Hausman, Brian Ichter, Szymon Jakubczak, Tim Jones, Liyiming Ke, Devin LeBlanc, Sergey Levine, Adrian Li-Bell, Mohith Mothukuri, Suraj Nair, Karl Pertsch, Allen Z. Ren, Lucy Xiaoyang Shi, Laura Smith, Jost Tobias Springenberg, Kyle Stachowicz, James Tanner, Quan Vuong, Homer Walke, Anna Walling, Haohuan Wang, Lili Yu, and Ury Zhilinsky. $\pi_{0.5}$: A Vision-Language-Action Model with Open-World Generalization. *arXiv preprint arXiv:2504.16054*, 2025.
- [38] Qwen Team. Qwen-RobotManip Technical Report: Alignment Unlocks Scale for Robotic Manipulation Foundation Models. *arXiv preprint arXiv:2606.17846*, 2026.
- [39] Hao Shi, Bin Xie, Yingfei Liu, Lin Sun, Fengrong Liu, Tiancai Wang, Erjin Zhou, Haoqiang Fan, Xiangyu Zhang, and Gao Huang. MemoryVLA: Perceptual-Cognitive Memory in Vision-Language-Action Models for Robotic Manipulation. *arXiv preprint arXiv:2508.19236*, 2026.
- [40] Mustafa Shukor, Dana Aubakirova, Francesco Capuano, Pepijn Kooijmans, Steven Palma, Adil Zouitine, Michel Aractingi, Caroline Pascal, Martino Russi, Andres Marafioti, Simon Alibert, Matthieu Cord, Thomas Wolf, and Remi Cadene. SmolVLA: A Vision-Language-Action Model for Affordable and Efficient Robotics. *arXiv preprint arXiv:2506.01844*, 2025.
- [41] Kaustubh Sridhar, Souradeep Dutta, Dinesh Jayaraman, and Insup Lee. Ricl: Adding in-context adaptability to pre-trained vision-language-action models. *arXiv preprint arXiv:2508.02062*, 2025.
- [42] StarVLA Community. StarVLA: A Lego-like Codebase for Vision-Language-Action Model Developing. *arXiv preprint arXiv:2604.05014*, 2026.
- [43] Yu Sun, Xiaolong Wang, Zhuang Liu, John Miller, Alexei A. Efros, and Moritz Hardt. Test-Time Training with Self-Supervision for Generalization under Distribution Shifts. *arXiv preprint arXiv:1909.13231*, 2020.
- [44] Jen-Wei Wang, Sarthak Kaingade, Andrea Tagliabue, and Nicholas Morozovsky. X-op: Cross-morphology whole-body teleoperation via mpc retargeting. *arXiv preprint arXiv:2606.07934*, 2026.
- [45] Wei Wu, Fangjing Wang, Fan Lu, He Sun, Shi Liu, Yunnan Wang, Yibin Yan, Yong Wang, Shuailei Ma, Xinyang Wang, Yibin Liu, Shuai Yang, Tianxiang Zhou, Kejia Zhang, Lei Zhou, Cheng Su, Nan Xue, Bin Tan, Han Zhang, Youchao Zhang, Fei Liao, Xing Zhu, Yujun Shen, and Kecheng Zheng. From Foundation to Application: Improving VLA Models in Practice. *arXiv preprint arXiv:2607.06403*, 2026.
- [46] Lei Xiao, Jifeng Li, Juntao Gao, Feiyang Ye, Yan Jin, Jingjing Qian, Jing Zhang, Yong Wu, and Xiaoyuan Yu. AVA-VLA: Improving Vision-Language-Action Models with Active Visual Attention. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 13453–13463, 2026.
- [47] Weiying Xie, Qingchen Zeng, Zihan Meng, Jiayun Tian, Sibao He, Danian Yang, Jie Du, Yunke Wang, Daixun Li, Hengyi Wang, et al. Towards efficient embodied reasoning: Mixture-of-depth compute allocation for vision-

- language-action model. In *Proceedings of the 32nd ACM SIGKDD Conference on Knowledge Discovery and Data Mining V. 2*, pages 5732–5741, 2026.
- [48] Siyu Xu, Yunke Wang, Chenghao Xia, Dihao Zhu, Tao Huang, and Chang Xu. Vla-cache: Efficient vision-language-action manipulation via adaptive token caching. *Advances in Neural Information Processing Systems*, 38:164448–164473, 2026.
 - [49] Siyu Xu, Zijian Wang, Yunke Wang, Chenghao Xia, Tao Huang, and Chang Xu. Affordance field intervention: Enabling vlas to escape memory traps in robotic manipulation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 37206–37215, 2026.
 - [50] Seonghyeon Ye, Joel Jang, Byeongguk Jeon, SeJune Joo, Jianwei Yang, Baolin Peng, Ajay Mandlekar, Reuben Tan, Yu-Wei Chao, Bill Yuchen Lin, Lars Liden, Kimin Lee, Jianfeng Gao, Luke Zettlemoyer, Dieter Fox, and Minjoon Seo. Latent Action Pretraining from Videos. *arXiv preprint arXiv:2410.11758*, 2024.
 - [51] Michał Zawalski, William Chen, Karl Pertsch, Oier Mees, Chelsea Finn, and Sergey Levine. Robotic control via embodied chain-of-thought reasoning. *arXiv preprint arXiv:2407.08693*, 2024.
 - [52] Lihan Zha, Asher J. Hancock, Mingtong Zhang, Tenny Yin, Yixuan Huang, Dhruv Shah, Allen Z. Ren, and Anirudha Majumdar. LAP: Language-Action Pre-Training Enables Zero-Shot Cross-Embodiment Transfer. *arXiv preprint arXiv:2602.10556*, 2026.
 - [53] Borong Zhang, Jiahao Li, Jiachen Shen, Yishuai Cai, Yuhao Zhang, Yuanpei Chen, Juntao Dai, Jiaming Ji, and Yaodong Yang. VLA-Arena: An Open-Source Framework for Benchmarking Vision-Language-Action Models. *arXiv preprint arXiv:2512.22539*, 2025.
 - [54] Fengnian Zhang, Tao Huang, Siyu Xu, Zhong Jin, and Chang Xu. Revisiting parameter redundancy in vision-language-action models: Insights from vlm-to-vla adaptation. *arXiv preprint arXiv:2606.31382*, 2026.
 - [55] Wenbo Zhang, Jianxiong Li, Shuai Yang, Sijin Chen, Jiajun Liu, Lingqiao Liu, and Xiao Ma. TTT-VLA: Test-Time Latent Prompt Optimization for Vision-Language-Action Models. *arXiv preprint arXiv:2606.03127*, 2026.
 - [56] Wenyao Zhang, Hongsi Liu, Zekun Qi, Yunnan Wang, Xinqiang Yu, Jiazhao Zhang, Runpei Dong, Jiawei He, Fan Lu, He Wang, Zhizheng Zhang, Li Yi, Wenjun Zeng, and Xin Jin. DreamVLA: A Vision-Language-Action Model Dreamed with Comprehensive World Knowledge. *arXiv preprint arXiv:2507.04447*, 2025.
 - [57] Yue Zhang, Rui Wang, Jiehong Lin, Zhongrui Wang, and Xiaojuan Qi. Retrieval-VLA: Training-Free In-Context Adaptation for Vision-Language-Action Models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 1358–1367, 2026.
 - [58] Yue Zhang, Rui Wang, Jiehong Lin, Zhongrui Wang, and Xiaojuan Qi. Retrieval-vla: Training-free in-context adaptation for vision-language-action models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 1358–1367, 2026.
 - [59] Qingqing Zhao, Yao Lu, Moo Jin Kim, Zipeng Fu, Zhuoyang Zhang, Yecheng Wu, Zhaoshuo Li, Qianli Ma, Song Han, Chelsea Finn, Ankur Handa, Ming-Yu Liu, Donglai Xiang, Gordon Wetzstein, and Tsung-Yi Lin. CoT-VLA: Visual Chain-of-Thought Reasoning for Vision-Language-Action Models. *arXiv preprint arXiv:2503.22020*, 2025.
 - [60] Linqing Zhong, Yi Liu, Yifei Wei, Ziyu Xiong, Si Liu, and Guanghui Ren. ACoT-VLA: Action Chain-of-Thought for Vision-Language-Action Models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 8152–8162, 2026.
 - [61] Xueyang Zhou, Yangming Xu, Guiyao Tie, Yongchao Chen, Guowen Zhang, Duanfeng Chu, Pan Zhou, and Lichao Sun. Libero-pro: Towards robust and fair evaluation of vision-language-action models beyond memorization. *arXiv preprint arXiv:2510.03827*, 2025.

A 实现细节

优化。 所有模型均从 Qwen3-VL-4B-Instruct 进行全量微调，使用 AdamW ($\beta = 0.9/0.95$ ，权重衰减 10^{-8})，骨干网络学习率为 5×10^{-6} ，动作专家学习率为 10^{-4} ，采用余弦调度（500 个预热步），梯度裁剪 1.0，bf16 混合精度，以及 DeepSpeed ZeRO-2，在全局批大小为 128 的条件下训练 30k 步。

正则化。 两种逐样本随机失活用于正则化训练。二维夹爪路径随机失活 (0.5) 在像素轨迹缺失时保持三维转向指令可用。上下文演示随机失活与部署时的演示可用性相匹配：当同任务演示始终可检索时为 0.0 (LIBERO、LIBERO-Plus)，否则为 0.5 (VLA-Arena、真实机器人)。

检索。 演示仅通过任务指令的语言嵌入进行检索；查询中不包含任何视觉特征。在仿真中，指令集是封闭的，因此这简化为精确的任务匹配，并且我们始终以单个最近邻演示 ($M=1$) 为条件。训练采用留一法检索，将目标回合从候选池中排除。

动作专家与空间语言专家。 一组动作占位符标记被附加到用户轮次，因果上先于语言-动作思维链。经过单次骨干网络前向传播后，其最终层隐藏状态通过一个两模块残差多层感知机，在 L_1 目标下回归动作块。紧凑的“子任务 + 3D/2D 转向指令”思维链保留自语言-动作公式 [52]，并通过交叉熵对离线生成的标注进行监督；在动作推理时不解码该思维链。转向指令是目标 $\Phi(A_t)$ of Eq. 2)，即多层感知机回归的同一动作块，由语言化器 Φ 在块张成上渲染，而非在整个片段上渲染；子任务是逐帧标签 s_t 。

各平台实例化。 在仿真中，策略读取 256×256 张图像，预测长度为 8 的动作块上的末端执行器增量，检索到的演示最多携带十个子目标关键帧。在真实机器人上，策略读取 640×480 张图像，预测长度为 16 的 7 维块（六个关节位置增量相对于回合起点加上绝对夹爪宽度，全部 q_{99} 归一化），演示最多携带八个关键帧。真实机器人状态以末端执行器位姿和关节角度用语言渲染。

B 真实世界设置

控制栈。 AgileX Piper 通过 CAN 总线以 30 Hz 频率驱动，未使用 ROS 软件栈。每个 16 步块跨越 ≈ 0.53 秒，并在同步滚动时域循环中执行，时域长度为 8。关节目标经过一欧元滤波器和 25° 每步跳变保护后到达机械臂。由于演示前缀在 rollout 期间固定不变，其键值缓存仅计算一次并重复使用，稳态推理稳定在每块 ≈ 205 毫秒，完全在控制预算之内。

数据收集。 125 个遥操作片段 ($71,702$ 帧) 通过主从遥操作在四项任务中采集：拿起笔放入杯中、拿起胡萝卜放入碗中、将积木放入第二个抽屉并关闭、将三个碗叠放在一起。这些任务分别涵盖精确对齐、自由空间抓取放置、涉及铰接物体的长时序操作以及多阶段堆叠。

跨源池构建。 在扩展现实 (XR) 中录制的二十六段人手操作生成了两个对齐的数据集，每个数据集包含 26 个片段和 $10,996$ 帧：一个保留操作者的裸手，另一个展示重定向后的 Piper 机械臂执行相同轨迹。两者逐帧共享片段结构和时序，因此具身外观是区分它们的唯一变量。二维夹爪路径的基准点，在人类操作中采用操作者手腕，在重定向机械臂中采用法兰，两者相互匹配。

与真实机器人的约定保持一致，使得渲染出的坐标无论来源如何都表示相同的物理量。三个来源通过精确的任务字符串匹配进行合并，检索时排除当前回合，且跨具身数据仅进入检索池：人类或重定向帧从不提供动作目标，因此策略的运动监督完全来自真实机器人。

评估条件。 每个报告的单元格为 10 次执行，由人类操作员根据固定成功标准评分，每次执行中物体摆放重新随机化，且各方法间保持一致。OOD-L1 严重程度未跨任务校准：对于笔  杯任务，它叠加了颜色和物体替换，而对于胡萝卜  碗任务仅改变颜色，因此 L1 在任务内可比，而非跨任务可比。在 OOD-L2 上，进度评分对三个已放置的方块各给一分，对关闭抽屉给一分，满分为四分。单个单元格在 10 次执行下约有 10 – 15 分的噪声，因此我们基于各条件平均值得出结论，该平均值在分布内聚合 40 次执行，在 L1 下聚合 20 次执行，并基于配对退化。由于只有笔  杯和胡萝卜  碗具有 L1 变体，正文中引用的退化比较了每个策略在这两个任务上的自身得分 $\overline{80.0\%}$ (StellaVLA)、 $\overline{55.0\%}$ (StarVLA-OFT)、 $\overline{80.0\%}$ ($\pi_{0.5}$)，而非与四任务分布内平均值比较。在 OOD-L2 上，进度评分为 $\overline{1.9}$ (StellaVLA)、 $\overline{1.5}$ ($\pi_{0.5}$) 和 $\overline{1.1}$ (StarVLA-OFT)；该任务未包含在真实机器人训练中，因此人类示范是池中唯一包含该任务演示的条目。

基线。 匹配对照为 StarVLA-OFT [42]，使用相同的真实机器人片段、相同的主干网络、动作专家和动作空间进行训练，唯一区别在于未接收演示和辅助空间语言专家。我们还在相同片段上微调了 openpi 流匹配策略 $\pi_{0.5}$ [37]；作为一个单独预训练的模型家族，它将我们的绝对数值置于外部尺度上，而非作为匹配对照。

Subgoal frames	AVG
3	98.1
5	98.2
8	98.3
10 (default)	98.8

表 9 子目标粒度。最佳以粗体显示。

C 补充分析

C.1 演示结构

子目标粒度（表 9）几乎持平：三个关键帧已达到 $\overline{98.1}$ 平均分，与完整十个关键帧 $\overline{98.8}$ 相差 $\overline{0.7}$ 以内。更密集的采样增加了帧数但未增加新的子目标，而策略所消耗的正是子目标分解，因此一旦计划完整，回报即趋于饱和，而非等到轨迹被密集覆盖。这也使得前缀足够短，可以缓存。

D 讨论与局限性

语言作为跨具身桥梁。 在匹配观测下，真实机器人、人手和扩展现实重定向演示产生高度一致的动作预测（表 4）。硬件结果同样使用从三源合并池中采样的演示，而非仅来自机器人源。综合这些结果表明，结构化表示降低了对源特定外观和坐标的敏感性。然而，这些结果并未建立跨固定源的闭环不变性，这需要更大规模的源控制展开研究。

将推理与延迟解耦。 自回归语言生成与实时控制的延迟预算不相容。StellaVLA 改为在联合动作与空间语言监督下训练骨干网络，随后移除空间语言专家，并在部署时缓存演示前缀。因此，控制过程不产生自回归语言解码开销（表 8）。

局限性与未来工作。 尽管性能强劲，本文框架仍存在若干局限性。长

视野组合性：尽管斯特拉视觉语言行动模型（StellaVLA）显著提升了任务级泛化与鲁棒性，但在极长视野、多阶段任务（如视觉语言行动竞技场中的长视野套件）上的成功率对所有评估模型而言仍然较低。演示前缀在整个回合内固定不变，因此一旦执行发生漂移便无法重新规划，仅靠上下文条件作用无法解决多步误差累积问题。检索质量依赖性：我们的上下文适应有效性依赖于检索到相关的专家演示。正如错误演示消融实验所示，以不匹配的演示为条件会使性能降至无演示基线以下，因此在视觉与语义域偏移下实现更鲁棒的检索是关键的下一步。最后，粗粒度运动学离散化：我们的文本化运动学推理依赖于空间运动的量化表示，以适应视觉语言模型的词汇表。虽然这种量化足以塑造共享表示，但可能引入离散化误差，从而限制精细操作精度。连续分词或混合表示方案可缓解此问题。