

STRAP: 面向增强策略学习的机器人子轨迹检索

Marius Memmel^{1,2,*}, Jacob Berg^{1,*}, Bingqing Chen², Abhishek Gupta^{1,†}, Jonathan Francis^{2,3,†}

¹Paul G. Allen School of Computer Science & Engineering, University of Washington

²Robot Learning Lab, Bosch Center for Artificial Intelligence

³Robotics Institute, Carnegie Mellon University

{memmelma, jacob33, abhgupta}@cs.washington.edu,

{bingqing.chen, jon.francis}@us.bosch.com

摘要

机器人学习领域预收集数据集的规模、多样性和复杂性正显著增长，与自然语言处理和计算机视觉等领域的发展趋势相呼应。许多机器人学习方法将这些数据集视为多任务专家数据，并通过在广泛数据上进行训练来学习多任务通用策略。值得注意的是，尽管这些通用策略能够提升多任务的平均性能，但与针对特定任务的专业策略相比，通用策略在任一单独任务上的性能往往因数据分区之间的负迁移而表现欠佳。本文主张在部署阶段根据所遇场景训练策略的范式：而非以零样本方式将预训练策略应用于未见问题，我们在测试时直接非参数化地检索相关数据并训练模型。此外，我们表明许多机器人任务共享大量底层行为，并且在“子”轨迹粒度上进行检索能够显著提升数据利用率、泛化能力以及策略适应新问题的鲁棒性。相比之下，现有的全轨迹检索方法往往未能充分利用数据，并错失跨任务共享的内容。本文提出 STRAP 技术，利用预训练视觉基础模型和动态时间规整，以鲁棒的方式从大型训练语料库中检索轨迹子序列。STRAP 在仿真和真实实验中均优于先前的检索算法和多任务学习方法，展示了在现实世界中扩展到大规模离线数据集的能力，以及仅凭少量真实世界演示即可学习鲁棒控制策略的能力。项目网站见 <https://weirdlabuw.github.io/strap/>

1 引言

机器人学习技术已展现出将机器人控制器设计过程从大规模手工或基于模型的方式转变为数据驱动方式的能力（Francis 等，2022；Hu 等，2023）。特别是，端到端模仿学习结合扩散模型（Chi 等，2023；Wang 等，2024）和变换器（Haldar 等，2024）已取得令人瞩目的成功。虽然模仿学习在




图 1: STRAP 利用子序列动态时间规整检索子轨迹，用于在部署期间训练鲁棒策略。

*equal contribution †equal advising

通过有针对性的领域内数据收集来执行特定任务时可能有效，但这一过程在人力方面可能昂贵且耗时。当我们将机器人部署到家庭和办公室等动态环境中时，这成为一个挑战，因为新任务和新环境层出不穷，持续的数据收集不切实际。

多任务策略学习通常应用于此类情况，利用跨多个任务的数据训练一个大型的任务或指令条件模型，该模型具有泛化到新问题的潜力。虽然多任务学习在某些场景下取得了成功（Reed 等，2022；Brohan 等，2022），但多任务通用策略的性能往往低于任务特定的专家策略。这可以归因于模型遭受负迁移，牺牲了单任务性能以提高跨任务的平均性能。这一挑战在未见任务或领域中更加严重，因为零样本泛化具有挑战性，而收集大量领域内微调数据可能代价高昂。在这项工作中，我们考虑在测试时训练专家模型，作为更好地利用预先收集的数据集并实现新任务少样本模仿学习的方法。

特别是，我们基于非参数数据检索的范式，在测试时收集少量领域内数据，用于从训练语料库中检索出特别“相关”的数据子集。这些检索到的数据随后可用于在新任务上进行稳健且高性能的模型训练。从这个意义上说，检索到的数据可以引导学习模型朝着期望的行为发展；然而，问题在于：我们如何从大型预先存在的语料库中选择要检索的数据？

多项先前技术已从学习潜在嵌入的角度研究了非参数检索问题，这些嵌入编码了状态（Du 等，2023）、技能（Nasiriany 等，2022）、光流（Lin 等，2024）以及习得可供性（Kuang 等，2024）。大多数技术难以直接应用，主要有两个原因。首先，它们需要训练特定领域的编码器来嵌入状态、技能或可供性：这使得将其应用于开放世界中收集的演示变得困难，因为视觉外观可能呈现广泛变化。其次，它们通常检索完整轨迹，限制了策略利用其他任务数据的能力，而这些任务可能与期望的测试时行为共享共同组件。这些挑战既限制了这些检索方法的广泛适用性，也限制了跨任务数据共享的数量。我们如何设计易于使用的现成检索方法，以最大限度地利用训练数据进行测试时自适应？

本工作的关键洞见在于，检索方法无需度量完整轨迹（或单个状态）之间的相似性，而应度量测试时期望行为的子轨迹与训练数据中相应子轨迹之间的相似性。值得注意的是，这些子轨迹不必来自与期望测试时任务整体相似的任务。相反，许多相关任务的子组件可以共享，以实现鲁棒的测试时策略训练。例如，如图 1 所示，对于“拿起杯子，放入抽屉，并关上它”的多阶段任务，“拿起杯子，放在抽屉顶部”和“关上底部抽屉，打开顶部抽屉”都包含子任务，检索这些子任务可提供有用的训练数据。我们提出的方法，即用于增强策略学习的子序列轨迹检索（**STRAP**），利用测试时收集的少量域内轨迹，在大型多任务训练语料库中检索并训练这些相关子轨迹。所得策略在鲁棒性和泛化性方面相比先前的检索方法、零样本多任务策略或仅基于测试时域内数据训练的策略，均表现出显著提升。

我们展示了如何以最小的努力在训练和评估领域中使用 STRAP，这些领域具有非平凡的视觉差异。我们的方法首先使用现成的基础模型（如 DINOv2（Oquab 等人，2023 年））的特征来比较子轨迹相似性；这些特征捕捉了强烈的“物体性”概念，摒弃了虚假的视觉差异，如光照、纹理和物体外观的局部变化。其次，我们的方法利用时间不变对齐技术，如动态时间规整（Giorgino，2009 年），来计算不同长度子轨迹之间的相似性，消除了检索轨迹长度相似的要求，并增加了 STRAP 在任务和领域中的适用性。最后，我们展示了 STRAP 如何应用于任意测试语料库，子轨迹由我们的框架自动提取，从而消除了从训练语料库中手动分割相关子轨迹的要求。我们演示了 STRAP 如何开箱即用地增强任何少样本模仿学习算法，在泛化方面提供显著增益。

在测试时，同时避免昂贵的测试时域内数据收集。我们使用基于变换器的模仿学习策略实例化 STRAP，并在仿真和现实世界模仿学习问题中展示了少样本子轨迹检索在 LIBERO (Liu 等人, 2024 年) 基准上的优势。

2 相关工作

用于行为回放的检索：大量工作探索了基于检索的机器人操作方法，其中相关过去演示的检索有助于回放过去的经验。嵌入空间的选择范围从现成模型 (Di Palo & Johns, 2024 年; Malato 等人, 2024 年) 如 DINO (Caron 等人, 2021 年)，在离线数据集上训练编码器 (Pari 等人, 2022 年) 到抽象表示如物体形状 (Sheikh 等人, 2023 年)。一些工作不直接回放动作，而是在子目标 (Zhang 等人, 2024b)、可供性 (Kuang 等人, 2024 年) 或关键点 (Papagiannis 等人, 2024 年) 之后添加一层抽象。这些方法的一个关键假设是，离线数据要么与测试环境中收集的专家演示完全相似，要么中间表示可以弥合差距。这些缺点限制了在各种领域中收集的大型多任务数据集的使用。

用于少样本模仿学习的检索：面向策略学习的检索尝试通过从检索到的数据中学习策略来缓解这些问题。虽然检索已被证明有利于从次优的单任务数据中学习策略 (Yin & Abbeel, 2024)，但大多数工作侧重于从包含专家演示的大型多任务数据集 (如 DROID (Khazatsky et al., 2024) 或 OpenX (O’Neill et al., 2023)) 中进行检索。行为检索 (BehaviorRetrieval, BR) (Du et al., 2023) 和流检索 (FlowRetrieval, FR) (Lin et al., 2024) 分别在状态-动作和光流上训练编码器-解码器模型。与我们的工作相关，SAILOR (Nasiriany et al., 2022) 在嵌入空间上施加技能约束，将相似技能聚类在一起以便后续检索。训练自定义表示的一个显著缺点是，这些方法无法很好地扩展到日益增长的离线数据集规模，并且无法处理显著的视觉和语义差异。此外，行为检索和流检索等技术检索的是单个状态，而不是像我们的工作那样检索子轨迹，而子轨迹检索能够在看似不同的任务之间实现最大程度的数据共享，同时捕获时间信息。

从子轨迹中学习：一些工作提出将演示分解为可重用的子轨迹，例如基于末端执行器中心或全本体感受的状态-动作转换 (Li et al., 2020; Belkhale et al., 2024; Shankar et al., 2022; Myers et al., 2024; Francis et al., 2022)。Belkhale et al. (2024) 提出将演示分解为以末端执行器为中心的子任务，例如“向前移动”或“向左旋转”。作者表明，通过将语言指令分解并重新标记为共享词汇表，在训练多任务策略时可以更好地共享来自多任务数据集的知识。Myers et al. (2024) 利用视觉语言模型 (VLM) 将演示分解为子轨迹，以更好地学习模仿它们。据我们所知，我们提出了第一个机器人子轨迹检索机制，用于划分大型离线机器人数据集，并在策略学习过程中实现跨任务的正迁移。

3 预备知识

3.1 动态时间规整

为了在检索过程中匹配可能长度可变的序列，本文基于一种称为动态时间规整 (Dynamic Time Warping, DTW) 的算法 (Müller, 2021)。DTW 方法计算两个时间序列之间的相似度，这些序列在时间或速度上可能有所变化，例如不同的视频或音频序列。该算法通过使用一组步长来扭曲序列的时间轴，以最小化对应点之间的距离，同时满足边界条件，从而对齐长度可变的序列。

DTW 算法接收两个序列， $X = \{x_1, x_2, \dots, x_n\}$ 和 $Y = \{y_1, y_2, \dots, y_m\}$ ，其中 $m \neq n$ ，以及一个相应的代价矩阵 $C(x_i, y_j)$ ，该矩阵为将序列 X 的元素 x_i 与序列 Y 的元素 y_j 对应起来分配代价。DTW 的目标是在 X 和 Y 之间找到一种映射，在满足边界条件和连续性条件的同时，最小化两个序列中已分配元素之间的总累积距离。动态时间规整方法利用动态规划技术高效地解决这一问题。




图 2: STRAP 概览: 1) 演示数据 $\mathcal{D}_{\text{target}}$ 和离线数据集 $\mathcal{D}_{\text{prior}}$ 通过视觉基础模型编码到共享嵌入空间; 2) 自动切片生成子轨迹; 3) S-DTW 将子轨迹与 $\mathcal{D}_{\text{prior}}$ 中对应的子轨迹进行匹配, 生成 $\mathcal{D}_{\text{retrieval}}$; 4) 在 $\mathcal{D}_{\text{retrieval}}$ 和 $\mathcal{D}_{\text{target}}$ 的并集上训练策略, 可获得更好的性能和鲁棒性。

累积距离矩阵 D 通过动态规划计算如下: $D(n, 1) = \sum_{k=1}^n C(k, 1)$ 对于 $n \in [1 : N]$ 和 $D(1, m) = \sum_{k=1}^m C(1, k)$ 对于 $m \in [1 : M]$ 。然后执行以下动态规划计算:

$$D(i, j) = C(x_i, y_j) + \min\{D(i-1, j), D(i, j-1), D(i-1, j-1)\}, \quad (1)$$

其中 $C(x_i, y_j)$ 是点 x_i 和 y_j 之间的距离。本文假设该代价矩阵已预先提供, 并在第 4.3 节中描述如何从原始相机图像计算该矩阵。序列之间的最优对齐通过从 $D(n, m)$ 回溯到 $D(1, 1)$ 找到。这保证了起点与起点匹配, 终点与终点匹配, 或者对 (x_0, y_0) 和 (x_n, y_m) 是路径的起点和终点。该最优配对路径由 X 和 Y 之间可能的最佳对齐组成, 使得所有匹配对之间的累积代价最小。如上所述, DTW 广泛用于时间序列分析、语音识别以及序列之间存在时间变化的其他领域。在本文的检索问题背景下, DTW 用于超越精确匹配序列的检索, 以匹配可变长度的子序列, 如下文所述。

子序列动态时间规整 (Subsequence Dynamic Time Warping, S-DTW) 是动态时间规整 (DTW) 算法的扩展, 适用于较短的查询序列必须与较长的参考序列的一部分进行匹配的场景。给定查询序列 $X = \{x_1, x_2, \dots, x_n\}$ 和长得多的参考序列 $Y = \{y_1, y_2, \dots, y_m\}$, 子序列动态时间规整 (S-DTW) 的目标是在 Y 中找到一个子序列 (其长度可能与 X 不同), 记为 $Y_{i:j}$, 其中 $i \leq j$, 使其与 X 的动态时间规整距离最小。

子序列动态时间规整 (S-DTW) 的累积代价矩阵 D 的计算方式与上述传统动态时间规整类似, 但允许对齐在 R 中的任意点开始和结束。矩阵 D 初始化为

$$D(n, 1) = \sum_{k=1}^n C(k, 1) \quad \text{for } n \in [1 : N],$$

$$D(1, m) = C(1, m) \quad \text{for } m \in [1 : M]$$

然后按照公式 (1) 通过动态规划完成计算。这确保了查询序列能够匹配参考序列的任意子序列。一旦累积代价矩阵计算完成, 通过从矩阵最后一行中的最小值 i.e., $\min(D(n, j))$ (对于 $j \in \{1, \dots, m\}$) 进行回溯来找到最优对齐。这给出了与 X 最佳对齐的 Y 的子序列, 仅遵循时间性约束, 同时放宽了边界条件。正如我们将展示的, 在检索增强策略训练设置中, 使用子序列动态时间规整进行数据检索能够实现跨任务数据的最大程度检索, 如第 4.3 节所述。




图 3: 子轨迹匹配: 子序列动态时间规整 (S-DTW) 将 $\mathcal{D}_{\text{target}}$ (顶部) 的子轨迹与 $\mathcal{D}_{\text{prior}}$ 中的相关片段进行匹配。子序列动态时间规整的一个特点是轨迹的起点和终点不必对齐, 从而为每对轨迹找到最优匹配。

4 子序列机器人轨迹检索用于增强策略训练

增强策略训练

4.1 问题设置: 检索增强策略学习

本文考虑一种小样本学习 (few-shot learning) 设定, 其中给定一个目标数据集 $\mathcal{D}_{\text{target}} = \{(s_0^i, a_0^i, s_1^i, a_1^i, \dots, s_{H_i}^i, a_{H_i}^i, l^i)\}_{i=1}^N$, 包含专家轨迹的状态 s (e.g.、观测 (如相机视图 o 和本体感知 x)、动作 a (如机器人控制) 以及任务指定的语言指令 l 。该目标数据集在测试环境和任务中采集, 但仅有少量 N 条轨迹, 这限制了仅基于如此小数据集训练的模型的泛化能力。由于 $\mathcal{D}_{\text{target}}$ 通常不足以单独解决任务, 本文假设可以通过非参数地从离线数据集 $\mathcal{D}_{\text{prior}}$ 中检索数据来实现泛化。该离线数据集 $\mathcal{D}_{\text{prior}} = \{(s_0^j, a_0^j, s_1^j, a_1^j, \dots, s_{H_j}^j, a_{H_j}^j, l^j)\}_{j=1}^M$ 可以包含来自不同环境、场景、专业水平、任务或具身的数据。值得注意的是, 离线数据集中的任务集合不需要与目标数据集中的任务集合重叠。本文假设离线数据集与目标数据集共享匹配的具身, 并且由专家级轨迹组成, 但可能包含与目标数据集差异很大的各种场景和任务 $\mathcal{D}_{\text{target}}$ 。

给定 $\mathcal{D}_{\text{prior}}$ 和 $\mathcal{D}_{\text{target}}$, 目标是学习一个以语言为条件的策略 $\pi_\theta(a|s, l)$, 当给定当前状态 s 和语言指令 l 时, 该策略能够在目标环境中预测最优动作 a 。假设我们能够在测试环境中获得成功度量 (如任务完成情况) 以及广泛的初始条件 $s_0 \sim \rho_{\text{test}}(s_0)$ 。策略学习的目标是确定策略参数 θ , 以在测试条件下最大化期望成功度量, 其中策略为 π_θ , 测试时环境动态为已知。由于我们仅在目标域中获得了有限的数据语料 $\mathcal{D}_{\text{target}}$, 因此无法通过对 $\mathcal{D}_{\text{target}}$ 执行简单的最大似然来学习这些策略参数。相反, 我们将提出一种方法, 其中离线数据集 $\mathcal{D}_{\text{retrieval}} \subseteq \mathcal{D}_{\text{prior}}$ 中一个较小的“相关”子集被非参数地检索出来, 然后与较小的域内数据集 $\mathcal{D}_{\text{target}}$ 混合, 以构建一个更大的、增强的训练数据集 i.e., $\mathcal{D}_{\text{target}} \cup \mathcal{D}_{\text{retrieval}}$, 该数据集与期望的测试时条件 $\rho_{\text{test}}(s_0)$ 最为相关。随后, 该数据集可用于通过模仿学习来训练策略, 我们将在第 4.5 节中描述。这样做避免了昂贵的通用训练过程, 而是将学习到的模型聚焦于在特定感兴趣场景中成为高性能的专家。关键问题变为——我们如何定义离线数据集 $\mathcal{D}_{\text{prior}}$ 中哪些子集与构建 $\mathcal{D}_{\text{retrieval}}$ 相关?

为了处理机器人数据的独特性质, 例如多模态和时间依赖性, 我们设计了 STRAP 用于检索增强的策略学习。首先, 我们需要定义检索的单元。STRAP 不是检索单个状态-动作对或整个轨迹, 而是关键地检索子轨迹。我们还提出了一种方法, 将 $\mathcal{D}_{\text{target}}$ 中的轨迹自动分割成这样的子轨迹 (第 4.2 节)。其次, 我们需要为一对子轨迹定义合适的距离度量 (第 4.3 节)。然后, 我们需要一个计算高效的算法, 从训练集中非参数地检索相关子轨迹 (第 4.4 节)。最后, 我们将所有内容整合在一起, 基于检索到的数据训练策略 (第 4.5 节)。

4.2 用于数据检索的子轨迹

为了充分利用训练数据集，同时捕捉任务特定的时序动态，我们将检索的概念从能够检索完整轨迹或单一状态扩展到检索可变量度的子轨迹。通过这种方式，检索既能捕捉任务的时序动态，又能在看似不同且可能具有不同任务指令标签的任务之间共享数据。我们将子轨迹定义为轨迹 $t_{a:b}^i \subseteq T^i$ 的连续子集，其中子轨迹 $t_{a:b}^i = (s_a^i, s_{a+1}^i, \dots, s_b^i)$ 包含整个长度为 H_i 的轨迹 T^i 中从时间步 a 到 b 的部分。机器人数据集中观察到的大多数长时程问题 (Liu et al., 2024; Khazatsky et al., 2024; O’Neill et al., 2023) 自然包含多个这样的子轨迹。例如，图 3 所示的任务可以分解为“将碗放入抽屉”和“关闭抽屉”。需要注意的是，我们并不要求这些轨迹明确具有特定的语义含义，但语义上有意义的子轨迹往往与跨任务中最常遇到的子轨迹相吻合，正如我们在实验评估中所见。

基于子轨迹的这一定义，本文提出的检索技术仅需将目标演示分割为子轨迹 $\mathcal{T}_{\text{target}} = \{t_{1:a}^i, t_{a:b}^i, \dots, t_{H_i-p_i:H_i}^i, \forall T^i \in \mathcal{D}_{\text{target}}\}$ ，而无需对规模大得多的离线训练数据集 $\mathcal{D}_{\text{prior}}$ 进行分割。相反，将使用基于动态时间规整 (DTW) 的检索算法 (第 4.4 节) 从该数据集中检索合适的子序列。由于 $\mathcal{D}_{\text{prior}}$ 远大于 $\mathcal{D}_{\text{target}}$ ，这使得所提出的方法论更具实用性。虽然这种子轨迹分割可在数据收集过程中手动完成，但本文提出一种自动子轨迹分割技术，并取得了有前景的实证结果。基于 Belkhale 等人 (2024) 提出的技术，本文将演示分割为原子块，即底层运动，然后通过匹配过程 (第 4.4 节) 检索相似子轨迹。特别地，本文提出一种简单的基于本体感觉的分割技术，该技术优化机器人末端执行器运动的变化，以指示两个块之间的过渡。例如，抓取与放置任务可分割为抓取和放置两个阶段，中间以抓取物体时的短暂停顿分隔。设 x_t 为描述时间步 t 处末端执行器位置的向量。本文定义“过渡状态”为绝对速度降至阈值以下的状态： $\|\dot{x}\| < \epsilon^1$ 。经验表明，这种基于本体感觉的分割能够对目标轨迹进行合理的时序分割，将其分解为子组件。该过程当然可以通过使用视觉基础模型 (Team 等人, 2023; Zhang 等人, 2024a) 的动作识别技术或信息论分割方法 (Jiang 等人, 2022) 进一步改进。

4.3 基础模型驱动的检索相关性度量

鉴于子轨迹的定义与自动分割，我们必须定义一种相似性测度，以便从 $\mathcal{D}_{\text{prior}}$ 中检索出恰当的相关子轨迹数据，同时该测度需对视觉外观变化、干扰项及无关的虚假特征具有鲁棒性。尽管先前工作已提出通过表示学习训练此类相似性度量的目标 (Du 等, 2023; Lin 等, 2024; Kuang 等, 2024)，但这些方法通常仅在域内训练，因而对上述变化尤为敏感。虽然采用基于光流 (参见 Lin 等, 2024) 或语言 (Zha 等, 2024) 的更具损失性的相似性度量有助于缓解这种脆弱性，但往往无法捕捉必要的任务特定或语义细节。这表明需要一种鲁棒且领域无关的相似性度量，能够开箱即用轻松地应用。

本文采纳如下洞见：视觉 (-语言) 基础模型 (Oquab 等, 2023; Radford 等, 2021) 为衡量子轨迹之间的语义与视觉相似性提供了现成的解决方案，能够捕捉以对象和任务为中心的可供性，同时对场景外观的低层变化具有鲁棒性。这些模型在海量真实世界图像 (-文本) 数据上训练，通常对低层感知变化具有鲁棒性，同时提供语义丰富的表示，自然捕捉对象性与语义对应的概念。将视觉基础模型记为 $\mathcal{F}(\cdot)$ ，我们可以在嵌入空间中用 L2 范数 2 计算两个相机视图的成对距离，*i.e.*, $\|\mathcal{F}(o_i) - \mathcal{F}(o_j)\|_2$ 。虽然时间平均等聚合方法可用于从单张图像的嵌入过渡到子轨迹的嵌入，但它们会丢失动作与动态信息。

1 对于涉及“定格动画”的轨迹，该启发式方法会返回许多短片段，因为末端执行器在等待夹爪闭合时处于空闲状态。为确保最小长度，我们合并相邻片段，直到所有片段均满足 ≥ 20 。² 此处也可使用其他代价度量，如 (1-余弦相似度)。

Algorithm 1 STRAP ($\mathcal{D}_{\text{target}}, \mathcal{D}_{\text{prior}}, K, \epsilon, \mathcal{F}$)

Require: demos $\mathcal{D}_{\text{target}}$, offline dataset $\mathcal{D}_{\text{prior}}$, vision foundation model $\mathcal{F}$, # retrieved chunks K , chunking threshold ϵ ;

- 1: */* Pre-processing */*
- 2: $\mathcal{T}_{\text{target}} \leftarrow \text{SubTrajSegmentation}(\mathcal{D}_{\text{target}}, \epsilon);$ ▷ Heuristic demo chunking
- 3: $\mathcal{E}_{\text{prior}} \leftarrow \{\{\mathcal{F}(o_t) | o_t \in T\} | T \in \mathcal{D}_{\text{prior}}\};$ ▷ Embed $\mathcal{D}_{\text{prior}}$
- 4: $\mathcal{E}_{\text{target}} \leftarrow \{\{\mathcal{F}(o_t) | o_t \in T\} | T \in \mathcal{T}_{\text{target}}\};$ ▷ Embed chunked $\mathcal{D}_{\text{target}}$
- 5: */* Sub-trajectory Retrieval using S-DTW */*
- 6: **for** $S_{\text{target}} \in \mathcal{D}_{\text{target}}$ **do**
- 7: $\mathcal{M} \leftarrow [];$ ▷ Initialize empty match storage
- 8: **for** $T_{\text{prior}} \in \mathcal{D}_{\text{prior}}$ **do**
- 9: $D \leftarrow \text{computeCostMatrix}(\mathcal{E}_{\text{target}}, \mathcal{E}_{\text{prior}});$ ▷ Eq. (2)
- 10: $\mathcal{M}_{i,j} \leftarrow \text{extractSubTrajectory}(D, T_{\text{prior}});$ ▷ Dynamic Programming
- 11: **end for**
- 12: **end for**
- 13: $\mathcal{D}_{\text{retrieval}} \leftarrow \text{retrieveTopKMatches}(\mathcal{M}, K);$ ▷ Sec. 4.4
- 14: */* Policy Learning */*
- 15: **repeat**
- 16: sample $\mathcal{B} \sim \mathcal{D}_{\text{target}} \cup \mathcal{D}_{\text{retrieval}}$ to update policy π_{θ} with loss $\mathcal{L}(\mathcal{B}; \theta)$ ▷ Eq. (3)
- 17: **until** π_{θ} converged; **return** π_{θ}

我们转而采用基于动态时间规整 (DTW, Giorgino, 2009) 思想的子轨迹匹配过程, 并利用嵌入来寻找最相关的子轨迹。给定两个子轨迹 t_i 和 t_j , 我们计算成对代价矩阵 $C \in \mathbb{R}^{|t_i| \times |t_j|}$, 其值由下式计算:

$$C(i, j) = \|\mathcal{F}(o_i) - \mathcal{F}(o_j)\|_2 \quad (2)$$

4.4 基于子序列动态时间规整的高效子轨迹检索

规整

基于上述子轨迹的定义和基础模型驱动的相似性度量, 本文实例化了一种算法, 用于从离线数据集 $\mathcal{D}_{\text{prior}}$ 中为从 $\mathcal{D}_{\text{target}}$ 分割出的每个子轨迹 t 找到 K 个最相关的子轨迹 $\mathcal{T}_{\text{match}}$ 。由于任务、平台或演示者的不同, 子轨迹在轨迹内可能具有可变的长度和时间位置。本文采用 S-DTW 将目标子轨迹 $\mathcal{T}_{\text{target}}$ 与 $\mathcal{D}_{\text{prior}}$ 中的适当片段 $\mathcal{T}_{\text{match}}$ 进行匹配 (第 3.1 节)。S-DTW 能够自然地应对这些挑战, 并允许从多样化的多任务数据集集中进行检索。在部署时, 子序列动态时间规整接受来自目标数据集 *i.e.*, $\mathcal{D}_{\text{target}}$ 的查询子序列, 并使用动态规划计算与查询 $\mathcal{T}_{\text{match}} = \{ \text{最大对齐的匹配 } (t, \mathcal{D}_{\text{prior}}), \forall t \in \mathcal{T}_{\text{target}} \}$ 及其匹配代价 D 。为了构建 $\mathcal{D}_{\text{retrieval}}$, 本文在 $\mathcal{T}_{\text{target}}$, *i.e.* 中的子轨迹上均匀选择代价最低的 K 个匹配, 每个查询选择相同数量的匹配, 直到检索到 K 个匹配。本文注意到, 如果演示中包含相似的片段, 则得到的匹配集合可能包含重复项, 但认为如果一个片段在演示中多次出现, 则它对任务很重要, 应通过重复检索在训练集中被“加权”。对于每个匹配, 本文还检索其对应的语言指令。训练数据集随后包含目标数据集 $\mathcal{D}_{\text{target}}$ 和检索到的数据集 $\mathcal{D}_{\text{retrieval}}$, $\mathcal{D}_{\text{target}} \cup \mathcal{D}_{\text{retrieval}}$ 的并集。这个显著更大的、检索增强的数据集可用于通过模仿学习学习策略, 从而得到鲁棒且可泛化的策略。

4.5 综合应用: STRAP

为了启动检索过程, 本文使用视觉基础模型 (如 DINOv2 (Oquab 等人, 2023) 或 CLIP (Radford 等人, 2021)) 对 $\mathcal{D}_{\text{target}}$ 和 $\mathcal{D}_{\text{prior}}$ 中的图像观测进行编码。为了最好地利用 $\mathcal{D}_{\text{prior}}$ 中的多任务轨迹, 本文基于低级运动启发式将 $\mathcal{D}_{\text{target}}$ 中的演示分割为原子片段。然后, 在分块后的 $\mathcal{D}_{\text{target}}$ 和 $\mathcal{D}_{\text{prior}}$ 之间生成匹配, 并通过在所有片段上均匀选择前 K 个匹配来构建 $\mathcal{D}_{\text{retrieval}}$ 。为了避免退化



图 12: $\mathcal{D}_{\text{target}}$: LIBERO-10 (左) 和真实世界 DROID-Kitchen (右) 中的任务。对于 $\mathcal{D}_{\text{prior}}$ ，请参考 LIBERO-90 (Liu 等人, 2024) 了解模拟任务，参考图 28 了解真实世界任务。

匹配时，我们将 S-DTW 回溯的步长限制为 $[1, 2]$ (参见 (Müller, 2021))。将 $\mathcal{D}_{\text{retrieval}}$ 与 $\mathcal{D}_{\text{target}}$ 结合，构成我们用于学习策略的数据集。在标准策略学习设置中，噪声检索数据可能导致负迁移，例如，当与目标数据相似的观测被标记为完成不同任务的动作时。在没有条件约束的情况下，此类污染样本会损害策略的下游性能。我们提出使用语言条件策略来处理这种不一致性。通过条件约束，策略能够区分来自不同任务的样本，将误导性动作与专家动作分离开来，同时从额外训练数据和语言条件的上下文中获得正迁移。

我们使用行为克隆 (Behavior Cloning, BC) 来学习视觉运动策略 π ，类似于 Haldar 等人 (2024)；Nasiriany 等人 (2024) 的方法。我们选择基于变换器 (Transformer) 的架构 (Vaswani, 2017)，输入最近 h 个观测 $s_{t-h:t}$ 的历史，并使用高斯混合模型动作头预测未来 h 个动作的块。我们从 $\mathcal{D}_{\text{target}}$ 和 $\mathcal{D}_{\text{retrieval}}$ 的并集中采样批次，如 $\mathcal{B} \sim \mathcal{D}_{\text{target}} \cup \mathcal{D}_{\text{retrieval}}$ 所示。按照 Haldar 等人 (2024) 的提议，我们计算多步动作损失，并在模型权重 θ 上添加 L2 正则化项，得到以下损失函数：

$$\mathcal{L}(\mathcal{B}; \theta) = \frac{1}{|\mathcal{B}|} \sum_{(s_{i-h:i}, a_{i:i+h}, l) \in \mathcal{B}} -\log(\pi_{\theta}(a_{i:i+h} | s_{i-h:i}, l)) + \lambda \|\theta\|_2^2 \quad (3)$$

其中策略 π_{θ} 和超参数 λ 控制正则化。

5 实验与结果

5.1 实验设置

任务定义：我们在仿真中基于 LIBERO 基准 (Liu 等人, 2024) 展示了 STRAP 的有效性，并在两个真实世界场景中遵循 DROID (Khazatsky 等人, 2024) 硬件设置。图 12 展示了目标任务和检索数据集的样本。更多任务细节请参见附录 A.2.1。

- **LIBERO：**我们在 LIBERO 基准 (Liu et al., 2024) 的 10 个长时程任务上评估 STRAP，这些任务包含多样的物体、布局和背景。我们从 LIBERO-10 中随机采样 5 个演示作为 $\mathcal{D}_{\text{target}}$ ，并利用 LIBERO-90 中的 4500 条轨迹作为 $\mathcal{D}_{\text{prior}}$ 。评估环境随机化目标物体位姿，为鲁棒性提供了理想的测试平台。我们在表 1 中报告前五个任务和 LIBERO-10 的平均性能，其余任务在附录 (表 3) 中给出。

- **DROID 厨房：**为了将 STRAP 扩展到更真实的场景，我们在三个真实厨房环境中评估蔬菜抓取与放置任务。我们在 $\mathcal{D}_{\text{prior}}$ (厨房) 中跨场景收集 150 个多任务演示，每个场景 50 个。任务组合从每个环境的三个可能任务中随机采样且不放回。每个演示包含两个独特任务，物体位姿和外观随机化。 $\mathcal{D}_{\text{target}}$ 特定于每个环境，包含三个可能任务之一的 3 个演示。为了研究 STRAP 对更大数据集的可扩展性，我们构建了一个额外的 $\mathcal{D}_{\text{prior}}$ ，包含来自 DROID 数据集的 5000 个演示和在 $\mathcal{D}_{\text{target}}$ (厨房-DROID) 相同环境中收集的 50 个演示。在评估期间，我们在一个 $20 \times 20 \text{cm}$ 网格内随机化物体位姿，并改变方向。我们通过分别赋予 0.5 和 1.0 的分数来报告部分 (抓取) 和完全成功率 (抓取和放置)，并将总分按试验次数归一化，得到 0 – 100 的范围。

表 1：基线：基线、消融和 STRAP 变体在 LIBERO-10 任务上的性能（图 12）。DINOv2 和 CLIP 特征表现相似，使 STRAP 在编码器选择上具有灵活性。更多结果见表 3。粗体表示最佳，下划线表示次优结果。

Task	Stove-Moka	Bowl-Cabinet	Soup-Cheese	Mug-Mug	Book-Caddy	LIBERO-10
BC	77.3% $\pm$ 4.4	71.3% $\pm$ 5.7	27.3% $\pm$ 2.2	38.0% $\pm$ 5.7	75.3% $\pm$ 1.4	37.9% $\pm$ 27.2
FT	86.0% $\pm$ 1.4	91.0% $\pm$ 0.7	38.0% $\pm$ 2.8	43.0% $\pm$ 0.7	100.0% $\pm$ 0.0	51.7% $\pm$ 35.7
MT	66.0% $\pm$ 14.1	45.0% $\pm$ 30.4	19.0% $\pm$ 13.4	31.0% $\pm$ 16.3	100.0% $\pm$ 0.0	37.7% $\pm$ 32.6
BR	80.0% $\pm$ 1.6	72.0% $\pm$ 7.7	26.0% $\pm$ 5.3	40.0% $\pm$ 8.6	16.0% $\pm$ 1.9	33.4% $\pm$ 25.1
FR	76.0% $\pm$ 6.6	54.7% $\pm$ 12.0	24.7% $\pm$ 8.6	29.3% $\pm$ 1.4	52.0% $\pm$ 5.9	33.1% $\pm$ 23.0
D-S	70.7% $\pm$ 7.9	65.3% $\pm$ 2.0	18.0% $\pm$ 3.4	16.0% $\pm$ 0.9	57.3% $\pm$ 2.9	28.4% $\pm$ 26.4
D-T	78.7% $\pm$ 2.7	75.3% $\pm$ 2.7	37.3% $\pm$ 6.6	<u>63.3% $\pm$ 3.6</u>	79.0% $\pm$ 5.0	41.4% $\pm$ 30.8
STRAP (CLIP, $K=100$)	86.0% $\pm$ 4.1	90.7% $\pm$ 2.2	42.0% $\pm$ 0.9	54.7% $\pm$ 3.3	83.3% $\pm$ 3.0	44.9% $\pm$ 32.7
STRAP (DINOv2, $K=100$)	85.3% $\pm$ 2.2	<u>91.3% $\pm$ 2.2</u>	42.7% $\pm$ 7.2	57.3% $\pm$ 7.7	85.3% $\pm$ 2.8	45.6% $\pm$ 32.6
STRAP (DINOv2, best K)	94.0% $\pm$ 1.4	96.0% $\pm$ 0.0	42.7% $\pm$ 7.2	69.0% $\pm$ 0.7	<u>94.0% $\pm$ 4.2</u>	58.1% $\pm$ 32.0

基线与消融：我们将 STRAP 与以下基线和消融进行比较，实现细节请参阅附录 A.1，广泛消融请参阅附录 A.3。

- **行为克隆**（行为克隆）使用基于变换器的策略，在 $\mathcal{D}_{\text{target}}$ 上训练；• **微调**（FT）行为克隆使用基于变换器的策略，在 $\mathcal{D}_{\text{prior}}$ 上预训练并在 $\mathcal{D}_{\text{target}}$ 上微调；• **多任务策略**（MT）基于变换器的多任务策略，在 $\mathcal{D}_{\text{prior}}$ 和 $\mathcal{D}_{\text{target}}$ 上训练；• **BR**（行为检索）（Du et al., 2023）先前工作，在状态-动作对上训练变分自编码器用于检索，并使用余弦相似度检索单个状态-动作对；• **FR**（光流检索）（Lin et al., 2024）与 **BR** 设置相同，但变分自编码器在来自 GMFlow（Xu et al., 2022）的预计算光流上训练；• **D-S**（DINOv2 状态）与 **BR** 和 **FR** 相同，但使用现成的 DINOv2（Oquab et al., 2023）特征，而非训练变分自编码器；• **D-T**（DINOv2 轨迹）使用 S-DTW 和 DINOv2 特征检索完整轨迹（而非子轨迹）；

5.2 实验评估

我们的评估旨在回答以下问题：（1）子轨迹检索是否提升少样本模仿学习的性能？（2）视觉基础模型的特征对检索的有效性如何？（3）S-DTW 识别出哪些类型的匹配？

子轨迹检索是否提升少样本模仿学习的性能？STRAP 在所有 10 个任务上平均比检索基线 BR 和 FR 分别高出 +24.7% 和 +25.0%（表 1）。这些结果表明策略对物体姿态变化具有鲁棒性。BC 在 LIBERO 任务上是一个强基线，因为该基准的难度来自评估期间的姿态变化。通过记忆演示，BC 实现了高成功率，在所有 10 个任务上比 BR 和 FR 分别高出 +4.5% 和 +4.8%。在我们的真实世界实验中，由于评估期间随机化增加，BC 表现差得多。策略在 $\mathcal{D}_{\text{target}}$ 中重放演示，未能适应新的物体姿态。

在 $\mathcal{D}_{\text{prior}}$ 上预训练策略并在 $\mathcal{D}_{\text{target}}$ 上微调 **表 2：真实世界结果：DROID-Kitchen**

	Kitchen			Kitchen+DROID		
	Table	Sink	Stove	Table	Sink	Stove
BC	12.50	10.00	14.28	12.50	<u>10.00</u>	14.28
FT	<u>20.00</u>	27.27	30.43	<u>28.00</u>	8.69	<u>22.72</u>
MT	4.34	<u>31.57</u>	<u>45.00</u>	2.00	0.00	0.00
STRAP	36.36	61.36	57.12	56.81	63.04	45.45

能。具体而言，我们发现 FT 的检查点选择困难，因为策略容易欠拟合或过拟合演示，导致退化行为或精确回放。我们发现 MT 训练具有挑战性，因为策略（Haldar et al., 2024; Nasiriany et al., 2024）有时忽略语言指令，解决在 $\mathcal{D}_{\text{prior}}$ 中见过的任务，而不是条件化的 $\mathcal{D}_{\text{target}}$ 。我们假设这种行为是由于 $\mathcal{D}_{\text{prior}}$ 和 $\mathcal{D}_{\text{target}}$ 的数据不平衡所致。最后，用 5000 个 tra-增强 $\mathcal{D}_{\text{prior}}$




图 13: 不同检索方法在 $\mathcal{D}_{\text{retrieval}}$ 中的任务分布, 目标任务为“将黑色碗放入橱柜底部抽屉并关闭”。

来自 DROID 数据集的轨迹放大了这些挑战, 导致更大的性能差距。在我们的真实世界评估中, 我们发现 STRAP 对 $\mathcal{D}_{\text{target}}$ 中未见过的姿态表现出令人惊讶的泛化行为。该策略还表现出恢复行为, 即使在初始抓取失败并改变物体姿态时也能完成任务。由于 STRAP 的策略训练阶段独立于 $\mathcal{D}_{\text{prior}}$ 的大小, 但数据集大小由超参数 K 决定, 因此它可以自然地处理添加更大的数据集 (如 DROID) 并保持性能。

有多重要 用于检索的子轨迹以及应检索多少条? 为探究子轨迹的有效性, 本文将子轨迹检索与 S-DTW (STRAP) 和利用 S-DTW 检索完整轨迹 (D-T) 在表 1 中进行比较。发现子轨迹检索在所有 10 个任务上均提升了性能 +4.1%。本文假设完整轨迹可能包含与任务无关的片段, 从而损害性能并降低累积代价的准确率。通过改变检索片段的数量 K , 发现 K 的最优值高度依赖于具体任务, 部分任务受益于检索较少数据, 而另一些任务则受益于检索更多数据。本文假设 K 取决于任务是否利用多任务训练 (正迁移) 或受其损害 (负迁移)。表 1 报告了最佳 K 的结果, 完整搜索过程见表 9。

这些表示的有效性如何 视觉基础模型用于检索? 接下来, 我们在固定 $K = 100$ 的 STRAP 中消融基础模型表示的选择。我们比较了 CLIP (一种通过图像-文本对上的监督学习训练的模型) 与 DINOv2 (一种在无标签图像上训练的自监督模型)。我们没有发现任何表示显著优于另一种, DINOv2 与 CLIP 在所有 10 个任务上仅相差 +0.7%。为了展示视觉基础模型用于检索的有效性, 我们将先前工作 (BR、FR) 中在 $\mathcal{D}_{\text{prior}}$ 上训练的域内特征提取器替换为现成的 DINOv2 编码器模型 (D-S)。在它们的自然配置中比较它们, 即使用余弦相似度的基于状态的检索, 可以对表示进行并排比较。表 1 显示表示的选择取决于任务, 没有方法在所有任务上优于其他方法。由于 D-S 通过单状态检索没有动态和任务语义的概念, BR 和 FR 分别以 +5.0% 和 +4.7% 的优势超过它。我们强调视觉基础模型不必在 $\mathcal{D}_{\text{prior}}$ 上训练, 并且随着轨迹数据量的增加和在未见任务上, 其扩展性要好得多。

识别出哪些类型的匹配 S-DTW? 为了理解 STRAP 检索的数据, 我们在图 13 中可视化了任务分布随 $\mathcal{D}_{\text{retrieval}}$ 比例的变化。该图展示了检索到的前五个任务, 并将其余任务归入“其他”类别。可以清楚地看到, STRAP 检索到的是语义相关的数据——每个任务至少与目标任务共享一个子任务。例如, “将黑色碗放入橱柜底部抽屉”, “关闭橱柜底部抽屉……” (图 3)。此外, STRAP 的检索是稀疏的, 仅从 5/90 个语义相关任务中选择数据, 并忽略不相关的任务。我们观察到, DINOv2 特征对不同环境纹理出人意料地不敏感, 能够从相同任务但不同环境中检索数据 (参见图 13, “将黑色碗放入橱柜底部抽屉并关闭它”)。此外, DINOv2 对物体姿态具有鲁棒性, 能够检索到“关闭抽屉”的子轨迹, 无论碗是在桌子上还是在抽屉里 (参见图 31, “关闭橱柜底部抽屉并打开顶部抽屉”)。由于在光流上训练, FR 没有视觉外观的概念, 未能检索到大多数语义相关的数据。

6 结论

我们提出 STRAP 作为一种创新方法，用于在少样本机器人操作中利用视觉基础模型，无需在整个检索数据集上训练，并允许以最小的计算开销进行扩展。通过使用 S-DTW 专注于子轨迹检索，STRAP 提高了数据利用率并更有效地捕捉动态。总体而言，我们的方法大幅优于标准微调、多任务方法以及最先进的检索方法，在具有挑战性的现实场景中展示了稳健的性能。

致谢：作者感谢匿名审稿人提供的宝贵反馈，感谢 Soroush Nasiriany 解答我们关于 robocasa 和 robosuite 代码库的众多问题，感谢 Li-Heng Lin 和 Yuchen Cui 帮助我们理解使用检索数据进行策略学习，感谢博世公司的同事和实习生们富有成效的讨论。这项工作获得了亚马逊（CC OTH 00203375 2024 TR）、ARL（W911NF2420191）和罗伯特·博世有限公司的资助（大部分工作是在 Marius Memmel 2024 年暑期实习项目期间完成的）。

参考文献

- Suneel Belkhole, Tianli Ding, Ted Xiao, Pierre Sermanet, Quon Vuong, Jonathan Tompson, Yevgen Chebotar, Debidatta Dwibedi, and Dorsa Sadigh. Rt-h: Action hierarchies using language. *arXiv preprint arXiv:2403.01823*, 2024.
- Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Joseph Dabis, Chelsea Finn, Keerthana Gopalakrishnan, Karol Hausman, Alex Herzog, Jasmine Hsu, et al. Rt-1: Robotics transformer for real-world control at scale. *arXiv preprint arXiv:2212.06817*, 2022.
- Mathilde Caron, Hugo Touvron, Ishan Misra, Hervé Jégou, Julien Mairal, Piotr Bojanowski, and Armand Joulin. Emerging properties in self-supervised vision transformers. In *Proceedings of the IEEE/CVF international conference on computer vision*, pp. 9650–9660, 2021.
- Cheng Chi, Siyuan Feng, Yilun Du, Zhenjia Xu, Eric Cousineau, Benjamin Burchfiel, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. *arXiv preprint arXiv:2303.04137*, 2023.
- Jia Deng, Wei Dong, Richard Socher, Li-Jia Li, Kai Li, and Li Fei-Fei. Imagenet: A large-scale hierarchical image database. In *2009 IEEE conference on computer vision and pattern recognition*, pp. 248–255. Ieee, 2009.
- Norman Di Palo and Edward Johns. Dinobot: Robot manipulation via retrieval and alignment with vision foundation models. *arXiv preprint arXiv:2402.13181*, 2024.
- Maximilian Du, Suraj Nair, Dorsa Sadigh, and Chelsea Finn. Behavior retrieval: Few-shot imitation learning by querying unlabeled datasets. *arXiv preprint arXiv:2304.08742*, 2023.
- Jonathan Francis, Nariaki Kitamura, Felix Labelle, Xiaopeng Lu, Ingrid Navarro, and Jean Oh. Core challenges in embodied vision-language planning. *Journal of Artificial Intelligence Research*, 74: 459–515, 2022.
- Toni Giorgino. Computing and visualizing dynamic time warping alignments in R: The dtw package. *Journal of Statistical Software*, 31(7):1–24, 2009. doi: 10.18637/jss.v031.i07.
- Siddhant Haldar, Zhuoran Peng, and Lerrel Pinto. Baku: An efficient transformer for multi-task policy learning. *arXiv preprint arXiv:2406.07539*, 2024.
- Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. *arXiv e-prints. arXiv preprint arXiv:1512.03385*, 10, 2015.
- Yafei Hu, Quanting Xie, Vidhi Jain, Jonathan Francis, Jay Patrikar, Nikhil Keetha, Seungchan Kim, Yaqi Xie, Tianyi Zhang, Zhibo Zhao, et al. Toward general-purpose robots via foundation models: A survey and meta-analysis. *arXiv preprint arXiv:2312.08782*, 2023.
- Yiding Jiang, Evan Liu, Benjamin Eysenbach, J Zico Kolter, and Chelsea Finn. Learning options via compression. *Advances in Neural Information Processing Systems*, 35:21184–21199, 2022.

- Alexander Khazatsky, Karl Pertsch, Suraj Nair, Ashwin Balakrishna, Sudeep Dasari, Siddharth Karamcheti, Soroush Nasiriany, Mohan Kumar Srirama, Lawrence Yunliang Chen, Kirsty Ellis, et al. Droid: A large-scale in-the-wild robot manipulation dataset. *arXiv preprint arXiv:2403.12945*, 2024.
- Yuxuan Kuang, Junjie Ye, Haoran Geng, Jiageng Mao, Congyue Deng, Leonidas Guibas, He Wang, and Yue Wang. Ram: Retrieval-based affordance transfer for generalizable zero-shot robotic manipulation. In *8th Annual Conference on Robot Learning*, 2024.
- Chengshu Li, Fei Xia, Roberto Martin-Martin, and Silvio Savarese. Hrl4in: Hierarchical reinforcement learning for interactive navigation with mobile manipulators. In *Conference on Robot Learning*, pp. 603–616. PMLR, 2020.
- Li-Heng Lin, Yuchen Cui, Amber Xie, Tianyu Hua, and Dorsa Sadigh. Flowretrieval: Flow-guided data retrieval for few-shot imitation learning. In *8th Annual Conference on Robot Learning*, 2024.
- Bo Liu, Yifeng Zhu, Chongkai Gao, Yihao Feng, Qiang Liu, Yuke Zhu, and Peter Stone. Libero: Benchmarking knowledge transfer for lifelong robot learning. *Advances in Neural Information Processing Systems*, 36, 2024.
- Federico Malato, Florian Leopold, Andrew Melnik, and Ville Hautamäki. Zero-shot imitation policy via search in demonstration dataset. In *ICASSP 2024-2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pp. 7590–7594. IEEE, 2024.
- Vivek Myers, Chunyuan Zheng, Oier Mees, Kuan Fang, and Sergey Levine. Policy adaptation via language optimization: Decomposing tasks for few-shot imitation. In *8th Annual Conference on Robot Learning*, 2024.
- Meinard Müller. *Fundamentals of Music Processing: Using Python and Jupyter Notebooks*. Springer Cham, 2 edition, 2021. ISBN 978-3-030-69807-2. URL <https://doi.org/10.1007/978-3-030-69808-9>.
- Soroush Nasiriany, Tian Gao, Ajay Mandlekar, and Yuke Zhu. Learning and retrieval from prior data for skill-based imitation learning. In *Conference on Robot Learning*, 2022.
- Soroush Nasiriany, Abhiram Maddukuri, Lance Zhang, Adeet Parikh, Aaron Lo, Abhishek Joshi, Ajay Mandlekar, and Yuke Zhu. Robocasa: Large-scale simulation of everyday tasks for generalist robots. *arXiv preprint arXiv:2406.02523*, 2024.
- Abby O’Neill, Abdul Rehman, Abhinav Gupta, Abhiram Maddukuri, Abhishek Gupta, Abhishek Padalkar, Abraham Lee, Acorn Pooley, Agrim Gupta, Ajay Mandlekar, et al. Open x-embodiment: Robotic learning datasets and rt-x models. *arXiv preprint arXiv:2310.08864*, 2023.
- Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, et al. Dinov2: Learning robust visual features without supervision. *arXiv preprint arXiv:2304.07193*, 2023.
- Georgios Papagiannis, Norman Di Palo, Pietro Vitiello, and Edward Johns. R+ x: Retrieval and execution from everyday human videos. In *RSS 2024 Workshop: Data Generation for Robotics*, 2024.
- Jyothish Pari, Nur Muhammad Mahi Shafiullah, Sridhar Pandian Arunachalam, and Lerrel Pinto. The surprising effectiveness of representation learning for visual imitation. In *18th Robotics: Science and Systems, RSS 2022*. MIT Press Journals, 2022.
- Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, et al. Learning transferable visual models from natural language supervision. In *International conference on machine learning*, pp. 8748–8763. PMLR, 2021.
- Scott E. Reed, Konrad Zolna, Emilio Parisotto, Sergio Gómez Colmenarejo, Alexander Novikov, Gabriel Barth-Maron, Mai Gimenez, Yury Sulsky, Jackie Kay, Jost Tobias Springenberg, Tom Eccles, Jake Bruce, Ali Razavi, Ashley Edwards, Nicolas Heess, Yutian Chen, Raia Hadsell, Oriol Vinyals, Mahyar Bordbar, and Nando de Freitas. A generalist agent. *Trans. Mach. Learn. Res.*, 2022, 2022. URL <https://openreview.net/forum?id=likK0kHjvj>.

- Tanmay Shankar, Yixin Lin, Aravind Rajeswaran, Vikash Kumar, Stuart Anderson, and Jean Oh. Translating robot skills: Learning unsupervised skill correspondences across robots. In *International Conference on Machine Learning*, pp. 19626–19644. PMLR, 2022.
- Jannik Sheikh, Andrew Melnik, Gora Chand Nandi, and Robert Haschke. Language-conditioned semantic search-based policy for robotic manipulation tasks. In *NeurIPS 2023 Foundation Models for Decision Making Workshop*, 2023.
- Gemini Team, Rohan Anil, Sebastian Borgeaud, Yonghui Wu, Jean-Baptiste Alayrac, Jiahui Yu, Radu Soricut, Johan Schalkwyk, Andrew M Dai, Anja Hauth, et al. Gemini: a family of highly capable multimodal models. *arXiv preprint arXiv:2312.11805*, 2023.
- A Vaswani. Attention is all you need. *Advances in Neural Information Processing Systems*, 2017.
- Lirui Wang, Jialiang Zhao, Yilun Du, Edward H. Adelson, and Russ Tedrake. Poco: Policy composition from and for heterogeneous robot learning. *CoRR*, abs/2402.02511, 2024. doi: 10.48550/ARXIV.2402.02511. URL <https://doi.org/10.48550/arXiv.2402.02511>.
- Haofei Xu, Jing Zhang, Jianfei Cai, Hamid Rezatofighi, and Dacheng Tao. Gmflow: Learning optical flow via global matching. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 8121–8130, 2022.
- Zhao-Heng Yin and Pieter Abbeel. Offline imitation learning through graph search and retrieval. *arXiv preprint arXiv:2407.15403*, 2024.
- Lihan Zha, Yuchen Cui, Li-Heng Lin, Minae Kwon, Montserrat Gonzalez Arenas, Andy Zeng, Fei Xia, and Dorsa Sadigh. Distilling and retrieving generalizable knowledge for robot manipulation via language corrections. In *2024 IEEE International Conference on Robotics and Automation (ICRA)*, pp. 15172–15179. IEEE, 2024.
- Jesse Zhang, Minh Heo, Zuxin Liu, Erdem Biyik, Joseph J Lim, Yao Liu, and Rasool Fakoor. Extract: Efficient policy learning by extracting transferable robot skills from offline data. *arXiv preprint arXiv:2406.17768*, 2024a.
- Yuying Zhang, Wenyan Yang, and Joni Pajarinen. Demobot: Deformable mobile manipulation with vision-based sub-goal retrieval. *arXiv preprint arXiv:2408.15919*, 2024b.

A 附录

A.1 仿真实验

表 3: 基线（仿真）：不同方法在 LIBERO-10 任务上的仿真性能。粗体表示最佳结果，下划线表示次优结果。

Method	Mug-Microwave	Moka-Moka	Soup-Sauce	Cream-Cheese-Butter	Mug-Pudding
BC	28.0% $\pm$ 0.9	0.0% $\pm$ 0.0	17.3% $\pm$ 4.5	26.7% $\pm$ 4.3	18.0% $\pm$ 2.5
Fine-Tuning	38.0% $\pm$ 5.7	0.0% $\pm$ 0.0	5.0% $\pm$ 2.1	81.0% $\pm$ 3.5	35.0% $\pm$ 3.5
Multi-Task	10.0% $\pm$ 7.1	0.0% $\pm$ 0.0	<u>24.0% $\pm$ 17.0</u>	<u>73.0% $\pm$ 13.4</u>	9.0% $\pm$ 2.1
BR (Du et al., 2023)	28.7% $\pm$ 3.9	0.0% $\pm$ 0.0	13.3% $\pm$ 3.8	32.0% $\pm$ 4.3	26.0% $\pm$ 1.9
FR (Lin et al., 2024)	27.3% $\pm$ 1.4	0.0% $\pm$ 0.0	11.3% $\pm$ 3.0	41.3% $\pm$ 5.5	14.7% $\pm$ 1.1
D-S	30.0% $\pm$ 3.4	0.0% $\pm$ 0.0	4.7% $\pm$ 0.5	16.0% $\pm$ 5.7	6.0% $\pm$ 0.9
D-T	<u>34.7% $\pm$ 2.0</u>	0.0% $\pm$ 0.0	4.7% $\pm$ 1.1	27.3% $\pm$ 4.5	14.0% $\pm$ 3.4
STRAP (CLIP, $K=100$)	30.0% $\pm$ 2.5	0.0% $\pm$ 0.0	8.7% $\pm$ 6.3	29.3% $\pm$ 10.5	24.0% $\pm$ 4.3
STRAP (DINOv2, $K=100$)	29.3% $\pm$ 2.7	0.0% $\pm$ 0.0	16.7% $\pm$ 2.0	29.3% $\pm$ 11.3	18.7% $\pm$ 1.4
STRAP (DINOv2, best K)	32.0% $\pm$ 5.7	0.0% $\pm$ 0.0	61.0% $\pm$ 6.4	61.0% $\pm$ 0.7	<u>31.0% $\pm$ 2.1</u>

超参数：所有结果均在 3 个训练和评估随机种子（1234、42、4325）上报告。我们将检索的片段数量固定为 100，检索相机视角固定为智能体视角图像，专家演示数量固定为 5。我们使用智能体视角（外部视角）观测进行检索，并在智能体视角和手部观测上训练策略。我们的变换器策略训练 300 个训练轮次，批大小为 32，每 200 个梯度步为一个训练轮次。

基线实现细节：遵循 Lin 等人（2024）的方法，我们为基于状态的检索基线（BR、FR、D-S）检索单状态动作对，并通过同时检索从 $t-h$ 到 $t+h-1$ 的状态进行填充，使样本与我们的基于变换器的策略兼容。我们请读者参阅附录 A.3 以获取详尽的消融实验。

LIBERO-10 上的其余结果 表 3 展示了主要章节中未报告的其余 LIBERO-10 任务的结果。在 Cream-Cheese-Butter 任务上，FR 和 BR 均优于 STRAP。我们假设我们的分块启发式方法生成了次优的子轨迹（过长），导致它们包含多个不同的语义任务，从而在检索数据集中产生更差的匹配，最终降低下游性能。

A.2 真实世界实验

设置与超参数：对于检索，我们按时间步对左、右和手中相机观测的嵌入进行平均，并将检索的片段数量固定为 100。我们在所有三个图像观测上训练策略，共 200 个训练轮次，批大小为 32，每 100 个梯度步为一个训练轮次。我们使用在 ImageNet（Deng 等人，2009）上预训练的权重初始化策略的 ResNet-18（He 等人，2015）视觉编码器。我们使用 DROID 设置（Khazatsky 等人，2024）——以 15Hz 运行——来收集演示并在真实机器人上部署我们的策略。

A.2.1 FRANKA 笔入杯

任务：我们在笔入杯场景中评估 STRAP 从“无关”任务中检索的能力。离线数据集 $\mathcal{D}_{\text{prior}}$ 包含 10 个任务的 100 个单任务演示， $\mathcal{D}_{\text{target}}$ 包含笔入杯任务的 3 个演示。虽然有些任务共享子任务，例如“将笔放在记号笔旁边”、“将螺丝刀放入杯中”、“将绿色记号笔放入马克杯”，但其他任务则无关，例如“制作热狗”、“推倒盒子”、“将电缆拉到右侧”。请注意，目标任务不属于 $\mathcal{D}_{\text{prior}}$ ！我们展示了 STRAP 对未见姿态、物体和目标外观的能力。

表 4: Franka 笔入杯: 真实世界结果。

Pen-in-Cup	<i>base</i>		<i>OOD</i>	
	Pick	Place	Pick	Place
BC	100%	100%	0%	0%
STRAP	100%	90%	100%	100%




图 14: 国际象棋



图 15: 立方体堆叠




图 16: 热狗



图 17: 撞倒盒子




图 18: 马克杯中的记号笔



图 19: 药品拾取与放置




图 20: 分配肥皂




图 21: 向右拉电缆




图 22: 笔旁边的笔




图 23: 螺丝刀

图 24: Franka 笔入杯: $\mathcal{D}_{\text{prior}}$ 中任务的环境设置。

语言指令 $\mathcal{D}_{\text{prior}}$ 国际象棋“将国王移到棋盘右上角”方块堆叠“将蓝色方块堆叠到塔顶”热狗“将热狗放入面包中”推倒盒子“推倒盒子”马克笔入杯“将马克笔放入杯子中”药品取放“拿起右侧的药盒并将其放在其他药盒旁边”按压皂液器“按压皂液器”向右拉电缆“将电缆向右拉”笔放在笔旁“将笔放在马克笔旁边”螺丝刀“拿起螺丝刀并将其放入杯中”

表 5: Franka 笔入杯: 真实世界数据集 $\mathcal{D}_{\text{prior}}$ 的任务/语言指令。

A.2.2 DROID 厨房



图 27: 灶台图 28: DROID 厨房: $\mathcal{D}_{\text{prior}}$ 中任务的环境设置。与任务相关的物体用红色圆圈标出。从左到右, 物体分别是: 桌子: 胡萝卜、薯片袋、罐头; 水槽: 胡椒、皂液器、海绵; 炉灶: 辣椒、鸡肉、厨具。我们在数据收集过程中随机化物体的位姿和类型, 例如颜色或样式。

	Language Instructions $\mathcal{D}_{\text{prior}}$	Language Instruction $\mathcal{D}_{\text{target}}$
table	"press the soap dispenser", "pick up the sponge and put it in the sink", "pick up the pepper and put it in the sink"	"pick up the pepper and put it in the sink"
sink	"pick up the carrot and put it on the plate", "pick up the chips bag and put it on the plate", "pick up the can and move it next to the table"	"pick up the can and move it next to the table"
stove	"pick up the chicken wing and put it in the pan", "pick up the utensil and put it in the pan", "pick up the chili and put it in the pan"	"pick up the chili and put it in the pan"

表 6: DROID 厨房: 真实世界数据集 $\mathcal{D}_{\text{prior}}$ 和 $\mathcal{D}_{\text{target}}$ 的任务/语言指令。 $\mathcal{D}_{\text{prior}}$ 中的每个任务由从可用指令中随机抽取的两个独立任务组成。所选指令通过填充词“，然后”连接。例如，在表格环境中，一个任务可能是“拿起海绵并将其放入水槽中，然后按压皂液器”。

A.3 消融实验

表 7: 消融实验——检索方法: 本文探索了基于轨迹的检索的不同方法。除主论文中报告的启发式方法外, 还实验了一种滑动窗口方法, 将轨迹分割为等长子轨迹 (此处长度为 30)。对滑动窗口子轨迹和完整轨迹均使用 S-DTW。

Method	Stove-Moka	Bowl-Cabinet	Mug-Microwave	Moka-Moka	Soup-Cream-Cheese
Sub-traj	76.0% $\pm$ 4.71	75.33% $\pm$ 2.72	26.0% $\pm$ 1.89	0.0% $\pm$ 0.00	37.33% $\pm$ 6.62
Full traj	78.67% $\pm$ 2.72	68.67% $\pm$ 1.44	34.67% $\pm$ 1.96	0.0% $\pm$ 0.00	28.67% $\pm$ 3.81
Method	Soup-Sauce	Cream-Cheese-Butter	Mug-Mug	Mug-Pudding	Book-Caddy
Sub-traj	40.00% $\pm$ 0.94	27.33% $\pm$ 2.18	63.33% $\pm$ 3.57	30.00% $\pm$ 3.40	79.0% $\pm$ 4.95
Full traj	4.67% $\pm$ 1.09	27.33% $\pm$ 4.46	43.33% $\pm$ 1.09	14.0% $\pm$ 3.4	68.0% $\pm$ 5.66




图 29: 消融实验—— K (检索片段数量): 该图展示了不同 K 取值下的平均成功率和标准差。

表 8：消融实验—— K （检索片段数量）：调整 K 可提升表 1 中 8/10 任务的成功率。 K 的最优值高度依赖于具体任务，部分任务受益于检索更少数据（炉灶-锅、碗-橱柜、汤-奶酪、马克杯-微波炉），部分任务受益于检索更多数据（马克杯-马克杯、书-收纳架、汤-酱汁、奶油奶酪-黄油、马克杯-布丁）。本文推测 K 取决于任务是否从多任务训练中获益（正迁移）或受损（负迁移）。

K	炉灶-摩卡	碗-橱柜	汤-奶酪	马克杯-马克杯	书-收纳架
$K = 100$	86.0% $\pm$ 4.3	94.5% $\pm$ 0.83	35.0% $\pm$ 2.5	61.0% $\pm$ 5.12	89.5% $\pm$ 3.56
$K = 200$	94.0% $\pm$ 1.41	96.0% $\pm$ 2.83	33.0% $\pm$ 2.12	56.0% $\pm$ 4.24	89.0% $\pm$ 4.95
$K = 500$	88.0% $\pm$ 2.83	95.0% $\pm$ 0.71	31.0% $\pm$ 6.36	65.0% $\pm$ 2.12	88.0% $\pm$ 4.24
$K = 1000$	86.0% $\pm$ 1.41	96.0% $\pm$ 0.00	32.0% $\pm$ 2.83	69.0% $\pm$ 0.71	94.0% $\pm$ 4.24
$K = 2000$	72.0% $\pm$ 4.24	74.0% $\pm$ 1.41	25.0% $\pm$ 4.95	42.0% $\pm$ 4.24	73.0% $\pm$ 2.12
$K = 4000$	76.0% $\pm$ 1.41	73.0% $\pm$ 6.36	29.0% $\pm$ 2.12	39.0% $\pm$ 0.71	78.0% $\pm$ 0.0

K	马克杯-微波炉	锅-在炉灶上	汤-酱汁	奶油奶酪-黄油	马克杯-布丁
$K = 100$	27.5% $\pm$ 3.11	0.0% $\pm$ 0.00	45.5% $\pm$ 10.52	50.0% $\pm$ 5.61	24.0% $\pm$ 2.12
$K = 200$	32.0% $\pm$ 5.66	0.0% $\pm$ 0.00	31.0% $\pm$ 2.12	46.0% $\pm$ 2.83	22.0% $\pm$ 8.49
$K = 500$	27.0% $\pm$ 3.54	0.0% $\pm$ 0.00	37.0% $\pm$ 3.54	44.0% $\pm$ 9.9	31.0% $\pm$ 2.12
$K = 1000$	23.0% $\pm$ 0.71	0.0% $\pm$ 0.00	61.0% $\pm$ 6.36	61.0% $\pm$ 0.71	27.0% $\pm$ 2.12
$K = 2000$	27.0% $\pm$ 3.54	0.0% $\pm$ 0.0	12.0% $\pm$ 1.41	27.0% $\pm$ 3.54	14.0% $\pm$ 1.41
$K = 4000$	32.0% $\pm$ 2.83	0.0% $\pm$ 0.0	12.0% $\pm$ 2.83	30.0% $\pm$ 1.41	13.0% $\pm$ 3.54

表 9：消融实验——检索种子：本文在 LIBERO-10 任务子集上使用 10 个专家演示作为 $\mathcal{D}_{\text{retrieval}}$ ，对 STRAP 在不同检索种子上进行实验。报告了 3 个训练种子和 3 个检索种子的所有可能组合的结果。

Method	Stove-Moka	Mug-Cabinet	Book-Caddy
BC Baseline	81.78% $\pm$ 2.6	83.11% $\pm$ 2.69	93.11% $\pm$ 1.57
STRAP	86.89% $\pm$ 1.51	88.67% $\pm$ 2.11	98.0% $\pm$ 1.04

A.4 附加基线

表 10：扩散策略基线：在 LIBERO-10 任务上使用扩散策略（DP）（Chi 等人，2023）的性能，无语言条件，用于行为检索（BR）（Du 等人，2023）、流检索（FR）（Lin 等人，2024）。这些实验复现了 BR 和 FR 的训练设置。

Method	Stove-Moka	Bowl-Cabinet	Soup-Cheese	Mug-Mug	Book-Caddy
BR	36.67% $\pm$ 1.44	68.0% $\pm$ 2.49	34.0% $\pm$ 2.49	55.33% $\pm$ 1.44	42.0% $\pm$ 1.63
FR	68.67% $\pm$ 2.37	56.0% $\pm$ 4.32	18.0% $\pm$ 3.4	56.0% $\pm$ 3.4	35.33% $\pm$ 6.28

Method	Mug-Microwave	Pots-On-Stove	Soup-Sauce	Cream cheese-Butter	Mug-Pudding
BR	30.67% $\pm$ 0.54	0.00% $\pm$ 0.00	10.67% $\pm$ 1.96	24.0% $\pm$ 0.94	9.33% $\pm$ 1.44
FR	32.67% $\pm$ 3.31	68.0% $\pm$ 2.49	6.0% $\pm$ 0.00	35.33% $\pm$ 0.54	8.0% $\pm$ 1.89

A.5 复杂度与可扩展性

A.5.1 使用视觉基础模型编码轨迹

$\mathcal{D}_{\text{prior}}$ 的嵌入可以预先计算，并在每次新的检索过程中重复使用。对总时间步数为 T 、相机视角数为 V 的数据集进行嵌入，其规模与 $O(T * V)$ 呈线性关系。我们在 NVIDIA L40S 46GB 上使用批大小 32 对 Huggingface 的 DINOv2 实现³进行了基准测试。编码单张图像耗时 $2.83\text{ms} \pm 0.08$ （25 次试验的平均值）。因此，编码整个 DROID 数据集（1890 万时间步，单视角）的总墙钟时间仅为 26 小时。

³https://huggingface.co/docs/transformers/en/model_doc/dinov2

A.5.2 子序列动态时间规整

与嵌入过程不同，检索必须在每个部署场景中运行。S-DTW 由两个阶段组成：计算距离矩阵 D 和通过动态规划寻找最短路径。计算距离矩阵的复杂度为 $\mathcal{O}(n \cdot m \cdot E)$ ，其中 E 为嵌入维度， n 为 $\mathcal{D}_{\text{target}}$ 中子轨迹的长度， m 为 $\mathcal{D}_{\text{prior}}$ 中轨迹的长度。DTW 和回溯的复杂度分别为 $\mathcal{O}(n \cdot \bar{m})$ 和 $\mathcal{O}(n)$ 。这些阶段必须对每个子轨迹 ($\in \mathcal{D}_{\text{target}}$) 和轨迹 ($\in \mathcal{D}_{\text{prior}}$) 顺序运行，但不依赖于其他(子)轨迹。因此，STRAP 的运行复杂度为 $\mathcal{O}(N * M)$ ，其中 N 为 $\mathcal{D}_{\text{target}}$ 中子轨迹的数量， M 为 $\mathcal{D}_{\text{prior}}$ 中轨迹的数量。我们的实现主要遵循 4。我们使用 numba 5 将 Python 函数编译为优化的机器代码，并通过运行三次来预热每个方法。根据 DROID 的统计数据，我们选择轨迹长度为 250 ($\mathcal{D}_{\text{target}}$ 和 $\mathcal{D}_{\text{prior}}$)，并从 $\mathcal{D}_{\text{target}}$ 中取单个演示，将其分割为 5 个长度为 50 的子轨迹，并将每个时间步嵌入为 768 维向量，模拟 DINOv2 嵌入。我们对 S-DTW 进行了基准测试，并在图 30 中报告了墙钟时间（10 次试验的平均值）。对于 DROID 规模（76k）的离线数据集，检索大约需要 300sec。请注意，计算距离矩阵可以表示为矩阵乘法，并可以利用 GPU 部署和自定义 CUDA 核函数实现更大的加速。

A.5.3 策略训练

训练过程还必须针对每种部署场景重复进行。我们使用 robomimic 6 训练策略，共训练 200 个轮次，批大小为 32，每个轮次执行 100 次梯度更新，硬件为 NVIDIA L40S 46GB。训练单个策略耗时 $35\text{min} \pm 4$ （10 次试验的平均值）。

A.5.4 增加数据集规模

总体而言，STRAP 随添加到 $\mathcal{D}_{\text{prior}}$ 的新轨迹呈线性扩展。STRAP 使用现成的视觉基础模型对新轨迹进行编码，无需像先前方法（BR、FR）那样重新训练编码器。使用 S-DTW 检索数据随 $\mathcal{D}_{\text{prior}}$ 的规模线性扩展，即使从 DROID 等最大的数据集中检索也能在 5 分钟内完成。最后，STRAP 的策略学习阶段与 $\mathcal{D}_{\text{prior}}$ 的规模无关，仅取决于检索到的数据量 K ，因此比常见的预训练加微调或多任务方法更具可扩展性，后者在向 $\mathcal{D}_{\text{prior}}$ 添加新轨迹时必须重新训练。




图 30: STRAP 运行时间: 我们在不同规模的 $\mathcal{D}_{\text{prior}}$ 上对 STRAP 的检索步骤进行基准测试，并报告 10 次试验的平均墙钟时间。

4 https://www.audiolabs-erlangen.de/resources/MIR/FMP/C7/C7S2_SubsequenceDTW.html 5

<https://numba.pydata.org/> 6 <https://github.com/ARISE-Initiative/robomimic/tree/robocasa>

A.6 定性结果




图 31: STRAP 的匹配分布 $\mathcal{D}_{\text{prior}}$ ，目标任务为：“将黑色碗放入橱柜底部抽屉并关上”。
S-DTW 无论起点、终点或轨迹长度如何都能找到最佳匹配。这导致起点和终点的分布以及检索到的轨迹长度呈现多样性。