

通用操作接口：无需在野机器人的在野机器人示教

Cheng Chi^{*1,2}, Zhenjia Xu^{*1,2}, Chuer Pan¹, Eric Cousineau³, Benjamin Burchfiel³, Siyuan Feng³,
Russ Tedrake³, Shuran Song^{1,2}

¹Stanford University, ²Columbia University, ³Toyota Research Institute

<https://umi-gripper.github.io>




图 1：通用操作接口（UMI）是一种便携、直观、低成本的数据采集与策略学习框架。该框架使我们能够将多样化的人类演示转化为有效的视觉运动策略。我们展示了该框架在传统遥操作难以完成的任务中的应用，例如动态、精确、双手和长时程任务。

摘要——我们提出通用操作接口（UMI）

——一种数据采集与策略学习框架，能够将野外人类演示中的技能直接迁移到可部署的机器人策略中。UMI 采用手持式夹爪，结合精心设计的接口，实现便携、低成本且信息丰富的数据采集，适用于具有挑战性的双手和动态操作演示。为便于可部署策略的学习，UMI 集成了精心设计的策略接口，具备推理时延匹配和相对轨迹动作表示。由此学习到的策略与硬件无关，可部署在多种机器人平台上。凭借这些特性，UMI 框架解锁了新的机器人操作能力，仅通过改变每个任务的训练数据，即可实现零样本泛化的动态、双手、精确和长时程行为。我们通过全面的真实世界实验展示了 UMI 的通用性和有效性，在多样化人类演示上训练的策略能够零样本泛化到新环境和物体。UMI 的硬件和软件系统已在 <https://umi-gripper.github.io> 开源。

是足够的，因为遥操作需要高昂的硬件和专家操作员设置成本，而人类视频与机器人之间存在较大的具身差距。最近，使用带有传感器的手持夹爪作为数据采集接口（Interface）[41, 50, 36] 已成为一种有前景的中间方案——在最小化具身差距的同时保持直观和灵活。尽管这些方法具有潜力，但它们仍然难以平衡动作多样性与可迁移性。虽然用户理论上可以使用这些手持设备采集任何动作，但其中大量数据无法迁移到有效的机器人策略中。因此，尽管在数百个环境中实现了令人印象深刻的视觉多样性，采集到的动作仍局限于简单抓取 [41] 或准静态拾放 [50, 36]，缺乏动作多样性。是什么阻碍了先前工作中的动作迁移？我们发现了几个微妙但关键的问题：

I. 引言

我们应如何演示复杂的操作技能以供机器人学习？该领域的尝试主要从两个方向探讨这一问题：通过遥操作收集针对性的实验室内机器人数据集，或利用非结构化的野外人类视频。遗憾的是，两者均不

- **视觉上下文不足：**虽然使用腕部摄像头对于对齐观测空间和增强设备便携性至关重要，但它限制了场景的视觉覆盖范围。摄像头与被操作物体的距离过近往往导致严重遮挡，无法为动作规划提供足够的视觉上下文。

- **动作不精确：**大多数手持设备依赖单目运动恢复结构（Structure-from-Motion, SfM）来恢复机器人动作。然而，此类方法往往难以恢复

* 表示同等贡献




图 2: UMI 演示界面设计。左: 用于数据采集的手持夹具, GoPro 是唯一的传感器和记录设备。中: 来自 GoPro 155° 鱼眼视角的图像。注意以绿色高亮显示的物理侧镜, 它们提供了隐式立体信息。右: 与 UMI 兼容的机器人夹具和摄像头设置使观测与手持夹具视角相似。

由于尺度模糊、运动模糊或纹理不足, 难以恢复精确的全局动作, 这显著限制了系统可应用的任务精度。

- **延迟差异:** 在手持数据采集过程中, 观测与动作记录不存在延迟。然而, 在推理阶段, 系统内会产生多种延迟来源, 包括传感器延迟、推理延迟和执行延迟。未考虑这些延迟差异的策略将遇到分布外输入, 进而生成不同步的动作。这一问题对于快速且动态的动作尤为突出。

- **策略表示不足:** 先前的工作通常采用简单的策略表示 (如多层感知机) 配合动作回归损失, 这限制了它们捕捉人类数据中固有的复杂多模态动作分布的能力。因此, 即使精确恢复了演示动作并消除了所有差异, 所得策略仍可能难以准确拟合数据。这进一步阻碍了大规模分布式人类数据采集, 因为演示者越多, 动作多模态性越强。

在本文中, 我们通过精心设计演示与策略接口来解决这些问题: • 首先, 我们旨在确定适合人类演示的物理接口, 该接口应直观且能够捕获策略学习所需的全部信息。具体而言, 我们使用鱼镜头以扩大视场和视觉上下文, 并在夹具上添加侧视镜以提供隐式立体观测。结合 GoPro 内置的惯性测量单元传感器, 我们能够在快速运动下实现稳健跟踪。• 其次, 我们探索合适的策略接口 (即观测与动作表示), 使策略与硬件无关, 从而实现有效的技能迁移。具体来说, 我们采用推理时延迟匹配来处理不同的传感器观测和执行延迟, 使用相对轨迹作为动作表示以消除对精确全局动作的需求, 最后应用扩散策略 [9] 进行建模

多模态动作分布。最终系统, 通用操作接口 (**Universal Manipulation Interface, UMI**), 提供了一个实用且易于访问的框架, 以解锁新的机器人操作技能, 使我们能够在任何环境中演示任何动作, 同时保持从人类演示到机器人策略的高可迁移性。仅需在手持夹具上安装一个腕部摄像头 (图 2), 我们证明 UMI 能够通过仅改变每个任务的训练数据 (图 1), 实现涉及动态、双手、精确和长时程动作的广泛操作任务。此外, 当使用多样化的人类演示进行训练时, 最终策略展现出对新环境和物体的零样本泛化能力, 在分布外测试中达到了显著的 70% 成功率, 这种泛化水平在其他行为克隆框架中很少观察到。我们在 <https://umi-gripper.github.io> 开源了硬件和软件系统。

II. 相关工作

任何数据驱动机器人系统的关键使能因素是数据本身。在此, 我们回顾机器人操作背景下几种典型的数据收集工作流程。

A. 遥操作机器人数据

模仿学习从专家演示中学习策略。行为克隆 (Behavior Cloning, BC) 利用遥操作机器人演示, 因其直接可迁移性而脱颖而出。然而, 遥操作真实机器人进行数据采集面临重大挑战。以往方法采用 3D 空间鼠标 [9, 54]、虚拟现实或增强现实控制器 [35, 3, 13, 19, 31, 51, 12]、智能手机 [44, 45, 22] 以及触觉设备 [38, 47, 43, 26, 4] 等接口进行遥操作。这些方法要么非常昂贵, 要么因高延迟和缺乏用户直观性而难以使用。尽管主从式 (即牵线木偶式) 设备如 ALOHA[53, 15] 和 GELLO[46] 的最新进展提供了直观且低成本的接口, 但它们在数据采集过程中对真实机器人的依赖限制了系统能够访问的环境类型和数量, 从而难以进行“野外”数据获取。外骨骼 [14, 20] 在数据采集过程中消除了对真实机器人的依赖

然而，这些设备的数据收集需要利用遥操作的真实机器人数据进行微调才能部署。此外，上述设备产生的数据和策略具有实施例特异性，无法复用于不同的机器人。相比之下，通用操作接口（UMI）在数据收集阶段无需物理机器人，并为野外机器人教学提供了更便携的接口，所提供的数据和策略可迁移至不同的机器人实施例（例如，六自由度或七自由度机械臂）。

B. 来自人类视频的视觉演示

有一系列专门的工作致力于从野外视频数据（例如，YouTube 视频）中进行策略学习。最常见的方法是从多样化的被动人类演示视频中学习。利用被动人类演示，先前的工作学习了任务代价函数 [37, 8, 1, 21]、可供性函数 [2]、稠密物体描述符 [40, 24, 39]、动作对应关系 [33, 28] 以及预训练的视觉表征 [23, 48]。然而，这种方法面临三大挑战。首先，大多数视频演示缺乏明确的动作信息，而这对学习可泛化的策略至关重要。为了从被动人类视频中推断动作数据，先前的工作借助手部姿态检测器 [44, 1, 38, 28]，或将人类视频与领域内遥操作机器人数据结合起来预测动作 [33, 20, 34, 28]。其次，人类与机器人之间明显的实施例差距阻碍了动作迁移。为弥合这一差距所做的努力包括：通过手部姿态重定向学习人机动作映射 [38, 28]，或提取与实施例无关的关键点 [49]。尽管进行了这些尝试，固有的实施例差异仍然使从人类视频到物理机器人的策略迁移复杂化。第三，在这类工作中，由实施例差距引起的固有观测差距，导致训练与推理时的观测数据不可避免地不匹配，从而加剧了所得策略的可迁移性问题，尽管已有工作致力于对齐演示观测与机器人观测 [20, 28]。相比之下，利用 UMI 收集的数据在动作和观测空间中都表现出极小的实施例差距，这得益于通过鲁棒的视觉惯性相机跟踪实现的精确操作动作提取，以及在教学和测试过程中共享的鱼眼腕部相机。因此，这为动态、双手、精确和长时程操作任务实现了野外零样本策略迁移。

C. 用于准静态动作的手持夹爪

手持式夹爪 [41, 50, 10, 32, 27, 25] 最小化了操作数据采集中的观测体现差距，提供了便携性和直观的接口，以便在野外高效地采集数据。然而，从这些设备中准确且鲁棒地提取六自由度末端执行器（EE）位姿仍然具有挑战性，阻碍了从这些数据中学习到的机器人策略在精细操作任务上的部署。先前的工作尝试通过各种方法解决这一问题，例如运动恢复结构（SfM）[50, 25]，它存在尺度模糊的问题；RGB-D 融合 [41]，它需要昂贵的传感器和机载计算；外部运动跟踪 [32, 27]




图 3：鱼眼与直线透视对比 (a) UMI 策略使用原始鱼眼图像作为观测。(b) 将大视场角 155° 的图像矫正为针孔模型会严重拉伸外围视野（蓝线之外），同时将中心最重要的信息压缩到一个小区域（红线之内）。

这仅限于实验室环境。这些设备由于末端执行器跟踪精度和鲁棒性较低，通常局限于准静态动作，往往需要笨重的机载计算机或外部动作捕捉（MoCap）系统，降低了它们在野外数据采集中的可行性。相比之下，UMI 将最先进的 SLAM [6] 与 GoPro 内置的 IMU 数据相结合，在全球尺度上准确捕捉六自由度动作。高精度数据使训练的行为克隆（BC）策略能够学习双手任务。通过全面的延迟匹配，UMI 进一步实现了可部署于真实世界的策略，用于动态动作，如抛掷。最近，Dobb-E [36] 提出了一种安装有 iPhone 的“抓取器”工具，用于为 Stretch 机器人采集单臂演示。然而，Dobb-E 仅展示了准静态任务的策略部署，并且需要针对特定环境的策略微调。相反，仅使用 UMI 采集的数据，训练出的策略就能零样本泛化到新的野外环境、未见过的物体、多种机器人形态，以及动态、双手、精确和长时程的任务。

III. 方法

通用操作接口（UMI）是一种手持式数据采集和策略学习框架，允许从野外人类演示直接迁移到可部署的机器人策略。其设计考虑了以下目标：

- **便携性。**手持式 UMI 夹爪可以带到任何环境，并以接近零的设置时间开始数据采集。
- **能力。**能够捕捉并迁移超越拾放任务的、自然且复杂的人类操作技能。
- **充分性。**所采集的数据应包含足够的信息，用于学习有效的机器人策略，并尽量减少会阻碍迁移的、与具体硬件相关的信息。
- **可复现性。**研究人员和爱好者应能够一致地构建通用操作接口（UMI）夹爪，并利用数据训练自己的机器人，即使使用不同的机械臂。

以下章节将阐述我们如何通过硬件与策略接口设计实现上述目标。

A. 演示接口设计

UMI 的数据采集硬件采用触发激活的手持式 3D 打印平行夹爪，配备软质手指，并安装 GoPro 相机作为唯一的传感器和记录设备（见 HD1）。对于双手操作，UMI 可以通过增加另一个夹爪轻松扩展。此处需要解决的关键研究问题是：

如何仅凭腕部摄像头为多种任务捕获足够信息？

具体而言，在观测侧，设备需捕获足够的视觉上下文以推断动作 HD2 和关键深度信息 HD3。在动作侧，需在快速人体运动下捕获精确的机器人动作 HD4、抓取宽度的细微调整 HD5，并自动检查每个演示在给定机器人硬件运动学下是否有效 HD6。以下章节详述实现这些目标的方法。HD1. 腕部摄像头作为输入观测。我们仅依赖腕部摄像头，无需任何外部摄像头设置。在机器人上部署 UMI 时，将 GoPro 摄像头以与手持夹爪上相同的 3D 打印手指相对位置安装。该设计带来以下优势：

1) 最小化观测体现差距。得益于硬件设计，腕部摄像头观测到的视频在人类演示与机器人部署之间几乎无法区分，使策略输入对体现差异不敏感。

2) **机械鲁棒性**。由于摄像头相对手指机械固定，在机器人上安装 UMI 无需摄像头-机器人-世界标定。因此，系统对机械冲击更具鲁棒性，易于部署。

3) **便携式硬件设置**。无需外部静态摄像头或额外机载计算，大幅简化数据采集设置，使整个系统高度便携。

4) 摄像头运动实现自然数据多样化。实验观察到的一个附带好处是，使用运动摄像头训练时，策略学会关注任务相关物体或区域而非背景结构（效果类似于随机裁剪）。因此，最终策略在推理时自然对干扰物更具鲁棒性。避免使用外部静态摄像头也给下游策略学习带来额外挑战。例如，策略现在需处理非平稳和部分观测。我们通过利用宽视场鱼眼镜头 HD2 和鲁棒视觉跟踪 HD4 缓解了这些问题，详见后续章节。

高清 2. 用于视觉情境的鱼眼镜头。本文在腕部安装的 GoPro 相机上使用 155 度鱼眼镜头附件，为广泛任务提供充足的视觉情境，如图 2 所示。作为策略输入，本文直接




图 4：UMI 侧视镜。超广角相机与策略性放置的镜子相结合，有助于隐式立体深度估计。(a)：通过每面镜子观察到的视图有效地创建了两个虚拟相机，其位姿相对于主相机沿镜面反射。(b)：盘子上的番茄酱被主相机视图遮挡，但在右侧镜子中可见，证明镜子模拟了具有不同光学中心的相机。(c)：本文对镜子内的内容进行数字反射以供策略观察。注意反射后杯柄的方向在所有 3 个视图中保持一致。

直接使用原始鱼眼图像而不进行去畸变，因为鱼眼效果恰好保留了中心区域的分辨率，同时压缩了周边视野的信息。相比之下，校正后的针孔图像（图 3 右）表现出极端畸变，由于宽视场角而不适合用于学习。除了通过增加视觉特征和重叠来提升 SLAM 鲁棒性 [52] 之外，我们的定量评估（第 V-A 节）表明，鱼眼镜头通过提供必要的视觉上下文来改善策略性能。HD3. 用于隐式立体视觉的侧视镜。为了弥补单目相机视图缺乏直接深度感知的问题，我们在相机周边视野中放置了一对物理镜面，从而在同一图像中创建隐式立体视图。如图 4 (a) 所示，镜中的图像等效于从沿镜面反射的额外相机所能看到的内容，而无需额外的成本和重量。为了利用这些镜面视图，我们发现对镜中图像裁剪进行数字反射（如图 4 (c) 所示）能为策略学习带来最佳结果（第 V-A 节）。请注意，如果没有数字反射，通过侧视镜看到的物体方向与主相机视图中的方向相反。HD4. 感知 IMU 的跟踪。UMI 利用 GoPro 内置的将 IMU 数据（加速度计和陀螺仪）记录到标准 mp4 视频文件中的能力 [18]，以绝对尺度捕捉快速运动。通过联合优化视觉跟踪和惯性姿态约束，我们基于 ORB-SLAM3[7] 的惯性-单目 SLAM 系统即使在视觉跟踪因运动模糊或缺乏视觉特征（例如俯视桌面）而失败时，也能在短时间内保持跟踪。这使得 UMI 能够捕捉和部署高度




图 5: UMI 策略接口设计。 (b) UMI 策略接收一系列同步观测 (RGB 图像、相对末端执行器姿态和夹爪宽度)，并输出一系列期望的相对末端执行器姿态和夹爪宽度作为动作。(a) 我们利用物理测量的延迟来同步不同的观测流。(c) 我们提前发送动作命令以补偿机器人的执行延迟。

动态动作，如投掷 (如图 7 所示)。此外，联合视觉-惯性优化允许直接恢复真实度量尺度，这对于动作精度和夹爪间姿态本体感知 PD2.3 至关重要：这是实现双手策略的关键要素。

HD5. 连续夹爪控制。与先前工作中使用的二元开合动作 [41, 44, 54] 相比，我们发现连续控制夹爪宽度能显著扩展平行爪夹爪可执行的任务范围。例如，抛掷任务 (图 7) 需要精确的释放时机。由于物体宽度各异，二元夹爪动作难以满足精度要求。在 UMI 夹爪上，手指宽度通过基准标记 [16] 连续跟踪 (图 2 左)。利用串联弹性末端执行器原理 [42]，UMI 可以通过连续夹爪宽度控制调节软手指的变形，从而隐式记录和控制抓取力。

HD6. 基于运动学的数据过滤。虽然数据收集过程与机器人无关，但我们应用简单的基于运动学的数据过滤来为不同机器人本体选择有效轨迹。具体而言，当机器人的基座位置和运动学已知时，通过 SLAM 恢复的绝对末端执行器位姿允许对演示数据进行运动学和动力学可行性过滤。在过滤后的数据集上训练可确保策略符合特定本体的运动学约束。

综合所有组件。UMI 夹爪重 780 克，外部尺寸为 $L310mm \times W175mm \times H210mm$ ，手指行程为 80 mm。3D 打印夹爪的物料清单成本为 73 美元，而 GoPro 相机及配件总计 298 美元。如图 2 所示，我们可以为任何机器人手臂配备兼容的夹爪和相机设置。

B. 策略接口设计

利用收集的演示数据，我们可以训练一个视觉运动策略，该策略接收同步观测序列 (RGB 图像、6 自由度末端执行器位姿和夹爪宽度) 并产生动作序列 (末端执行器位姿和夹爪宽度)，如图 5 所示。

(b). 本文在所有实验中均采用扩散策略 (Diffusion Policy) [9]，而其他框架如 ACT [53] 可作为直接替代方案。UMI 策略接口设计的一个重要目标是确保该接口与底层机器人硬件平台无关，从而使基于单一数据源 (即手持夹爪) 训练的策略能够直接部署到不同的机器人平台上。为此，本文旨在解决以下两个关键挑战：

- **硬件特定延迟。**不同硬件 (流式相机、机器人控制器、工业夹爪) 的延迟在系统部署中差异很大，从个数到数百毫秒不等。相比之下，UMI 夹爪捕获的所有信息流相对于图像观测具有零延迟，这得益于 GoPro 的同步视频、IMU 测量以及基于视觉的夹爪宽度估计。
- **具身特定本体感知。**常用的本体感知观测 (如关节角度和末端执行器位姿) 仅针对特定机械臂和机器人基座布置才有明确定义。相比之下，UMI 需要在多样化环境中采集数据，并能泛化到多种机器人具身。

在以下章节中，本文将描述三种应对这些挑战的策略接口设计。

PD1. 推理时延迟匹配。UMI 的策略接口假设观测流同步且动作立即执行，但物理机器人系统并不符合这一假设。若处理不当，训练与测试之间的时序不匹配会导致动态操作任务性能大幅下降，这类任务需要快速运动和精确的手眼协调，详见第 V-B 节。本文分别处理观测侧和动作侧的时序差异：

PD1.1) 观测延迟匹配。在实际机器人系统中，不同的观测流 (RGB 图像、末端执行器位姿、夹爪宽度) 由分布式微控制器采集，导致观测延迟各不相同。

对于每个观测流，我们分别测量其延迟（详见 § A1-A3）。在推理时，我们以延迟最高的流（通常是相机）为基准对齐所有观测。具体而言，我们首先将 RGB 相机观测在时间上降采样至期望频率（通常为 10-20Hz），然后利用每张图像的采集时间戳 t_{obs} 对夹具和机器人本体感知流进行线性插值。在双臂系统中，我们通过寻找最近邻帧来软同步两个相机，其最大偏差为 1/60 秒。结果得到符合 UMI 策略的同步观测序列，如图 5(a) 所示。

PD1.2) 动作延迟匹配。 UMI 策略假设输出为同步的末端执行器位姿和夹具宽度序列。然而，在实际中，机器人手臂和夹具只能以一定的执行延迟跟踪期望位姿序列，该延迟因机器人硬件而异。为确保机器人和夹具在策略给定的期望时间到达期望位姿，我们需要提前发送指令以补偿执行延迟，如图 5(c) 所示。执行延迟校准详见 § A4。在执行过程中，UMI 策略预测从观测最后一步 t_{obs} 开始的动作序列。由于观测延迟 $t_{input} - t_{obs}$ 、策略推理延迟 $t_{output} - t_{input}$ 和执行延迟 $t_{act} - t_{output}$ ，最初预测的若干动作立即过时。我们直接丢弃过时动作，仅执行时间戳在 t_{act} 之后的动作，以适应各硬件。

PD2. 相对末端执行器位姿。 末端执行器（End-effector, EE）位姿是通用操作界面（UMI）观测空间与动作空间的核心。为避免依赖具体机器人形态或部署相关的坐标系，我们将所有末端执行器位姿表示为相对于夹具当前末端执行器位姿的形式。

PD2.1) 相对末端执行器轨迹作为动作表示。 先前工作已表明动作空间选择对任务性能有显著影响 [9]，实验证据支持绝对位置动作优于增量动作。然而，我们发现相对轨迹表示——定义为从 t_0 开始的动作序列，由一系列 $SE(3)$ 变换组成，表示在时刻 t 相对于初始末端执行器位姿 t_0 的期望位姿——能使系统对数据采集期间的跟踪误差和相机位移更具鲁棒性。

PD2.2) 相对末端执行器轨迹作为本体感知。 类似地，我们将历史末端执行器位姿的本体感知表示为相对轨迹。当观测时域设为 2 时，该表示有效地为策略提供速度信息。结合腕部相机观测空间，相对轨迹使系统无需标定。执行过程中移动机器人基座不会影响任务性能（图 10 (a)），只要物体仍在可达范围内，这使得 UMI 框架同样适用于移动机械臂。

PD2.3) 双夹具间相对本体感知。 在双臂设置中使用 UMI 时，我们发现为策略提供两个夹具之间的相对位姿对于双臂协调和任务成功至关重要，如图所示




图 6：相对轨迹作为动作表示。 UMI 采用的相对轨迹是在每个推理步骤中相对于同一当前末端执行器位姿的一系列末端执行器（EE）位姿。相比之下，增量动作将每个动作步表示为相对于其紧邻前一个动作的形式，因此会累积误差。绝对动作要求所有动作具有全局坐标系，这对于野外数据采集而言难以定义。

见第 V-C 节。当两个相机之间的视觉重叠较小时，夹具间本体感觉的影响尤为显著。夹具间本体感觉通过我们的先建图后定位数据采集方案实现，该方案构建了场景级全局坐标系 HD4。对于每个新场景，我们首先采集一段视频，为该场景构建地图。随后，在该场景中采集的所有演示都被重新定位到同一地图上，从而共享同一坐标系。尽管每个夹具的视频是分别重新定位的，但利用它们共享的坐标，可以计算出每个时间步两个夹具之间的相对位姿。

四、评估

在实验中，我们旨在从三个方面评估 UMI 框架在可部署策略学习中的有效性：

- **能力：** UMI 演示能在多大程度上转化为有效的机器人策略？尤其是对于复杂、动态、双手和长时程的操作技能。
- **泛化性：** 在多样化环境中野外采集的数据是否有助于策略泛化到未见过的环境和物体？
- **数据采集效率：** 使用 UMI 采集操作数据的速度有多快？SLAM 系统的准确率如何？

为评估能力与泛化性，我们在 4 个真实世界机器人任务上对 UMI 进行了评估，涵盖窄域和野外环境，如图 7 所示。为衡量数据采集效率，我们将 UMI 夹具与人类手部演示及典型遥操作接口进行了比较。详细的数据采集协议见 § B。

五、能力实验

我们通过四个任务研究 UMI 在单手、双手、动态和长时程操作技能上的捕捉与迁移能力。在能力实验中，所有任务均在数据采集的相同环境中评估，但机器人和物体的初始状态随机化。为确保公平比较，


Task 1. Cup Arrangement



Task 2. Dynamic Tossing



Task 3. Bimanual Cloth Folding



Task 4. Dish Washing




图 7：策略执行。我们在多种具有挑战性的真实世界任务上测试 UMI。杯子摆放任务测试 UMI 学习抓握和非抓握动作的能力，以及捕捉多模态动作分布（顺时针和逆时针旋转）的能力。该任务在窄域和未见环境以及两种机器人本体上均进行了评估。动态抛掷任务测试 UMI 捕捉和迁移快速人体运动以及精确手眼协调的能力。双手叠衣任务测试 UMI 同步双臂协调的能力。洗碗任务测试 UMI 处理涉及多个刚性、可变形和关节物体的长时程任务的能力。更多细节请查看我们网站上的视频。

所有方法在机器人和物体上均使用完全相同的初始状态，通过手动将场景与预先录制的图像对齐实现。详细的评估协议和所有实验视频见 § C。

A. 杯子摆放

任务 将意式浓缩咖啡杯放置在杯碟上，杯柄朝向机器人左侧，如图 7 所示。我们将任务成功定义为：杯子直立放置在杯碟上，且杯柄位于 $\pm 15^\circ$ 以内。能力（是什么使任务困难？）该任务测试系统同时学习抓取（拾取与放置）和非抓取动作（即推动以重新定向杯子）的能力。当杯柄正对机器人时，顺时针和逆时针旋转两种等效解构成了多模态动作分布。该任务还测试了 UMI 通过单目相机观测和侧视镜感知相对深度的能力。性能 训练数据集包含 2 名示教者采集的 305 个回合，评估包含 20 个测试用例，测试初始状态分布如图 8 (a) 所示。UMI 能够以 20/20 的成功率完成任务。后续段落将围绕关键设计决策讨论消融研究。

跨机器人泛化：为展示 UMI 的跨具身泛化能力，我们还将同一策略检查点部署到 Franka Emika FR2 机器人上，如图 1 和图 8 所示。该实验达到 $18/20 = 90\%$ 的成功率，2 个失败案例均为关节极限违规，若将 FR2 机器人安装在不同位置即可避免。无鱼眼镜头 [HD2]：为消融广角鱼眼镜头的重要性，我们对数据集进行后处理，将每张图像矫正并裁剪为水平与垂直视场角均为 69° 的正方形。这是对 RealSense D415（水平视场角 69° ，垂直视场角 42° ）和 iPhone 广角相机（水平视场角 69° ，垂直视场角 51° ）的宽松类比。该基线仅达到 $11/20 = 55\%$ 的成功率。除了杯子超出相机视野这一预期失败模式外，我们发现即使物体可见，该基线策略的表现也出奇地差，动作经常抖动。我们推测在训练过程中，物体可见性差迫使策略产生不必要的多模态行为。

替代动作空间 [PD2]：作为相对轨迹动作表示的替代方案，我们还考虑了绝对动作空间和增量动作空间，如图 6 所示。由于




图 8：窄域评估结果。 (a) 所有评估回合的初始状态叠加显示。对于每项任务，所有方法均从同一组初始状态开始，这些状态与参考图像手动匹配。(b) 基线/消融策略的典型失败模式。红色箭头表示失败行为，绿色箭头表示期望行为。(c) 20 个评估回合中的成功率，每列最佳性能以粗体显示。更多对比视频请访问我们的网站。

由于同步定位与建图系统输出相对于建图视频第一帧的位姿（详见 § D），我们只能直接利用同步定位与建图输出计算相对动作和增量动作。为了计算机器人基座坐标系中的绝对动作，我们使用放置在桌面上的同一组基准标记 [16] 对同步定位与建图坐标系和机器人进行校准。增量动作基线达到 $16/20 = 80\%$ 的成功率。绝对动作基线表现意外地差，仅有 $5/20 = 25\%$ 的成功率，表明动作选择存在明显偏差，这可能是由于同步定位与建图坐标系和机器人基座坐标系之间的校准不准确所致（图 8 (b)）。虽然理论上通过更好的校准，该基线的性能可以接近相对轨迹的性能，但本实验凸显了即使在受控实验室环境中，获取绝对坐标动作数据的难度。侧视镜的影响 [HD3]：出乎我们意料的是，直接提供镜像图像会使性能从 $18/20 = 90\%$ （无镜像）下降到 $17/20 = 85\%$ 。为了充分利用侧视镜，我们需要对镜中内容进行数字反射，并交换左右镜像图像，这达到了 $20/20 = 100\%$ 的成功率。我们推测

如果没有数字反射，主图像和镜像图像中观察到的相反运动可能会使视觉编码器感到困惑，尤其是那些具有平移等变性的编码器。

B. 动态投掷


任务：机器人需要将随机放置在桌面上的 6 个来自 YCB 物体集 [5] 的物体分类，通过将它们投掷到相应的箱子中。3 个球形物体（棒球、橙子、苹果）应被投掷到圆形箱子中，而 3 个乐高积木则应被投掷到矩形箱子中（图 7）。箱子放置在机器人运动学可达范围之外，以突出该任务对动态动作的必要性。

能力：动态投掷任务展示了通用操作接口（UMI）捕捉和传递流畅快速的人类动作、精确的手眼协调（在 RGB 与本体感觉之间）以及时序对齐（在机器人与夹爪之间）的能力。

性能：我们为该任务收集了 280 个演示回合，包含多物体和单物体拾取与投掷的混合场景。我们的策略（采用推理延迟匹配）达到了 $105/120 = 87.5\%$ 的成功率，按成功投掷到对应箱子的物体数量统计。



(a) Generalization to **novel environments** and **novel cups**



(b) Typical Failure Case of Policy using **Narrow-domain** data

	Cafe Table	Water Fountain	Success Rate
CLIP ViT finetune with narrow-domain Data	0 / 10	0 / 10	0.0
In-the-wild Data	Training Cup	16 / 25	0.7
	Unseen Cup	6 / 10	0.75
	Overall	22 / 35	0.72

(c) Quantitative Comparison in Unseen Environments

图 9：真实环境杯子整理评估。（a）使用真实环境数据训练的策略，对新环境和新物体展现出强大的泛化能力。（b）仅使用窄域数据时，策略难以泛化到新环境。（c）提供了全面的定性结果，更多对比视频可在我们的网站上查看。

无延迟匹配 [PD1]：使用相同的已训练策略，我们通过将所有观测流和动作流的测量延迟设为 0 来禁用推理时延迟匹配。我们观察到策略的运动因观测与执行不同步而明显更加抖动。虽然抖动对抓取影响甚微，但对投掷性能的影响显著，因为它干扰了机器人达到期望投掷速度的运动，如图 8 中肘关节速度曲线所示。此外，夹爪与机器人动作之间的错位（由于执行延迟不同）导致投掷过程中物体释放不理想。最终成功率降至 $69 / 120 = 57.5\%$ 。

C. 双臂布料折叠

任务二：两个机械臂需要协同将毛衣袖子向内折叠，向上折起下摆，旋转 90 度，最后再将毛衣对折一次（图 7）。详细评估协议见 § C。能力：操纵高自由度可变形物体因其复杂动力学和欠驱动特性而极具挑战性。此外，该任务要求机械臂之间紧密协调。例如，提起下摆需要两个机械臂同时抓取，若其中一个机械臂稍快或稍慢，此步骤就会失败。性能：我们从两名演示者处收集了 250 条演示，通过平移/旋转衣物和折叠袖子来随机化初始状态。我们使用单一集中式策略为两个机械臂和夹爪生成动作。我们的策略达到了 $14 / 20 = 70\%$ 的成功率。无夹爪间相对本体感知 **[PD2.3]：**在训练和评估过程中均缺少夹爪间本体感知信息时，两臂之间的协调性显著变差。最突出的失败案例是两臂提起衣物下摆时，基线策略常因抓取动作不同步而漏抓（图 8(b)）。因此，基线策略仅达到 $6 / 20 = 30\%$ 的成功率。相比之下，UMI 策略

通过先到达预抓取姿态并等待两臂均就位后再同时抓取和折叠，实现了抓取同步。

D. 洗碗

任务：机器人需执行 7 步顺序依赖动作（打开水龙头、抓取盘子、拿起海绵、清洗并擦拭盘子直至番茄酱被去除、放置盘子、放置海绵、关闭水龙头），如图 7 所示。详细评估协议见 § C。能力：该任务从多个方面拓展了机器人操作能力的边界：1) 这是一个超长时程任务，每一步的成功都依赖于前一步；2) 机器人需要感知并操作复杂流体，包括牛顿流体（即水）和非牛顿流体（即番茄酱）；3) 擦拭动作需要使用可变形工具（即海绵），同时双臂需参照水流进行协调；4) 操作受约束的关节物体（即开关水龙头）需要软手指提供的机械柔顺性；5) 策略还需在语义上对“清洁度”概念具有鲁棒性。当清洗过程中或清洗阶段结束后再次添加番茄酱时，机器人需要恢复清洗和擦拭。性能：一名演示者收集了 258 条演示，初始状态随机化，包括番茄酱图案、盘子和海绵的位置以及水龙头角度。收集的演示还明确包含了添加额外番茄酱时的恢复行为演示。对于该任务，我们通过微调 CLIP[29] 预训练的 ViT-B/16[11] 视觉编码器来训练扩散策略。总体而言，UMI 实现了 $14 / 20 = 70\%$ 的成功率。此外，我们展示了策略对各种干扰物、酱料类型（芥末酱、巧克力糖浆、焦糖糖浆）以及扰动的鲁棒性，详见网站上的图 10 和视频。

无 CLIP 预训练的 ViT 视觉编码器。对于这个视觉复杂的任务，我们发现从头训练 ResNet-34[17]




图 10：鲁棒性测试。我们测试了策略在不同推理时扰动下的鲁棒性，例如移动机器人基座、新物体、不同光照条件，以及为洗碗任务添加不同和更多的调味品。学习到的策略对这些扰动具有鲁棒性，并完成任务。更多细节请查看我们网站上的视频。

是不充分的。具体而言，使用 ResNet-34 的基线策略学习到了一种非反应性行为，忽略了盘子或海绵位置的任何变化。因此，它无法执行该任务， $0/10 = 0\%$ 。

六、野外泛化实验

先前行为克隆的研究通常仅在数据采集的同一环境中进行评估，往往受限于无法收集足够多样化的数据集以实现泛化。由于不依赖真实机器人的遥操作，UMI 能够在任何环境中进行低成本数据采集，本文称之为野外数据。本文通过将杯子摆放任务（第 V-A 节）扩展到新环境和新物体，评估 UMI 生成可泛化视觉运动策略的能力。在 12 小时内，3 名演示者在 30 个不同的物理地点（包括家庭、办公室、餐厅和户外环境）收集了 1400 个杯子摆放任务的演示。演示涉及 15 个不同颜色、形状（圆柱形和锥形）和材质（陶瓷、玻璃和金属）的浓缩咖啡杯。为确保模型容量，本文将视觉编码器进一步扩展为 CLIP [30] 预训练的 ViT-L/14 [11]。本文在两个未见环境中评估了 UMI 策略（图 9 第一列）：

- **咖啡桌** 是繁忙咖啡馆户外座位区的一张金属桌，大量行人构成自然干扰。本文测试了训练集中的 5 个杯子和测试集（未见）中的 2 个杯子，每个杯子 5 个初始位姿，共 35 次实验。
- **喷泉** 是一个黑色立方体喷泉，水从中心不断流出形成薄膜，覆盖整个顶面。该环境明显超出分布，因为所有演示均在非黑色桌面上采集，且水面改变了表面动力学。本文

测试了 3 个训练杯子和 2 个测试杯子，每个杯子 5 个初始位姿，共 25 次实验。本文选择的 2 个测试杯子中，一个具有分布外颜色（深蓝色），另一个具有未见纹理（棕色环纹）。对于每个测试用例，本文改变杯子和碟子的初始位姿。UMI 策略在训练杯子上达到 $28/40 = 70\%$ 的成功率，在测试杯子上达到 $15/20 = 75\%$ 的成功率，综合成功率为 $43/60 = 71.7\%$ 。更多定性和定量结果如图 9 所示。

无野外数据。为验证泛化能力来源于野外数据而非预训练视觉骨干，我们训练了另一个模型，该模型仅使用在同一实验室环境中收集的窄域实验数据（见第 V-A 节所述），并采用相同的预训练 ViT 视觉骨干。在相同的未见环境中，如图 9(b) 所示，采用基线策略的机器人甚至不会向杯子移动。因此，其成功率为 0% 。

要点。该结果表明，使用窄域数据微调大型预训练模型不足以产生可野外部署的策略。因此，收集多样化的野外数据对于有效泛化到新环境和物体仍然至关重要。

VII. 数据收集吞吐量与准确率

吞吐量。UMI 改进的人体工程学设计和直观性也提高了数据收集吞吐量。为展示这一效果，我们记录了同一操作者在 15 分钟内使用 3 种不同方法（图 11）可收集的演示数量：1）人手演示 2）UMI 夹爪 3）基于 Spacemouse 的遥操作，这是许多从演示中学习的工作中使用的典型遥操作接口 [9, 54]。我们在两个任务上测量数据吞吐量：1）杯子整理

2）动态抛掷。注意，重置环境、随机化物体以及处理机器人故障（如





图 11：UMI、徒手和 Spacemouse 遥操作的数据收集吞吐量比较。UMI 不仅比传统遥操作更快，还能执行典型遥操作接口无法完成的任务（例如动态抛掷）。



SLAM Tracking Mean Error		
	Position (mm)	Rotation (degree)
Per-gripper ATE	6.1	3.5
Inter-gripper RPE	10.1	0.8

图 12：SLAM 精度。我们使用包含 7 个单夹爪任务和 7 个双手任务的 MoCap 基准来评估 SLAM 精度。总体而言，我们能够实现小于 1 厘米和 4° 的跟踪误差。

本实验中也计入了自碰撞等情况，以准确反映真实世界数据采集的吞吐量。在杯子排列任务上，UMI 夹爪比传送方式快 $3\times$ 以上，达到人手速度的 48%，如图 11 (d) 所示。注意，人类在重置和随机化方面明显更快，因为他们靠近物体。在动态投掷任务上，UMI 夹爪达到人手速度的 64%，而传送方式在 15 分钟内未能产生一次成功的演示。

精度。为了独立评估我们基于 SLAM 的跟踪系统的精度，我们收集了一个带有 MoCap 真值的 SLAM 基准数据集。该数据集包含 7 个单夹爪任务和 7 个双手任务，所有任务中都有各种可移动物体在视野内，以及自然快速的人体运动。如图 12 所示，我们的 SLAM 系统的平均绝对轨迹误差 (ATE) 为位置 $6.1mm$ ，旋转 3.5° 。由于两个夹爪使用同一地图进行定位，我们还可以获得两个夹爪之间的相对位姿（即夹爪间位姿 PD2.3）。两个夹爪之间的平均相对位姿误差 (RPE) 为位置 $10.1mm$ ，旋转 0.8° 。

VIII. 局限性与未来工作

尽管 UMI 在广泛的任务和场景中展示了策略有效性，但仍存在一些局限性。首先，由于下游部署机器人的运动学极限在数据收集时未知，我们依赖

关于数据过滤以确保所得策略的运动学可行性。未来工作可开发一种具身感知的策略学习框架，能够从有效但硬件不可行的动作中迁移技能。其次，本文基于同步定位与建图 (SLAM) 的动作恢复系统继承了视觉 SLAM 对环境纹理充足性的要求。未来工作可利用静态第三人称视角相机，结合通用操作接口 (UMI) 夹爪上的附加基准标记，即使在纹理匮乏的环境（如纯白墙壁的房间）中也能恢复动作。第三，如第七节所示，使用 UMI 夹爪收集数据的效率仍低于人手演示。部分原因在于夹爪的重量和体积，部分原因在于相比人手其自由度减少。未来工作可探索更轻的材料，进一步改进 UMI 夹爪的机械设计和人体工学，或者构建足够灵巧的机器人手及策略，以直接迁移人类动作。

九、结论

本文提出通用操作接口 (UMI)，一个能够直接从野外人类演示中学习能力强且可泛化的操作策略的框架。UMI 夹爪作为一种手持式演示接口，能够捕获足够信息以学习一些具有挑战性的操作任务，包括清洗脏盘子、双手折叠毛衣以及动态物体抛掷与分类。同时，UMI 凭借其便携性、成本效益和操作简便性，在野外数据收集方面保持了高度可扩展性。通过将所有信息记录在单个标准化的 MP4 文件中，UMI 的数据可以方便地通过互联网共享，从而允许从大量非专业演示者中进行地理分布式的数据收集。本文提出 UMI 的目标是使机器人数据收集民主化，促进机器人社区涌现出庞大、多样且去中心化的数据集。

致谢

本研究部分由丰田研究所、美国国家科学基金会 (NSF) 项目 #2037101 和 #2132519 资助。我们感谢谷歌和丰田研究所提供的 UR5 机器人, 以及 IRIS 和 IPRL 实验室提供的 Franka 机器人硬件。本文所表达的观点和结论仅代表作者本人, 不应被解释为必然代表资助方的官方政策, 无论是明示还是暗示。我们感谢 Andy Zeng、Pete Florance、Huy Ha、Yihuai Gao、Samir Gadre、Mandi Zhao、Mengda Xu、Alper Canberk、Kevin Zakka、Zeyi Liu、Dominik Bauer、Tony Zhao、Zipeng Fu 和 Lucy Shi 的深入讨论。感谢 Alex Alspach、Brandan Hathaway、Aimee Goncalves、Phoebe Horgan 和 Jarod Wilson 在硬件设计与原型制作方面的帮助。感谢 Naveen Kuppaswamy、Dale McConachie 和 Calder Phillips-Graffine 在底层控制器方面的帮助。感谢 John Lenard、Frank Michel、Charles Richter 和 Xiang Li 在 SLAM 方面的建议。感谢 Eric Dusel、Nwabisi C. 和 Letica Priebe Rocha 在 MoCap 数据集采集方面的帮助。感谢 Chen Wang、Zhou Xian、Moo Jin Kim 和 Marion Lepert 在 Franka 设置方面的协助。特别感谢 Steffen Urban 在 GoPro SLAM 和相机-IMU 校准方面的开源项目, 以及 John @ 3D printing world 对夹爪机构设计的启发。

参考文献

- [1] Shikhar Bahl, Abhinav Gupta, and Deepak Pathak. Human-to-robot imitation in the wild. In *Proceedings of Robotics: Science and Systems (RSS)*, 2022.
- [2] Shikhar Bahl, Russell Mendonca, Lili Chen, Unnat Jain, and Deepak Pathak. Affordances from human videos as a versatile representation for robotics. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 13778–13790, 2023.
- [3] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Joseph Dabis, Chelsea Finn, Keerthana Gopalakrishnan, Karol Hausman, Alex Herzog, Jasmine Hsu, et al. Rt-1: Robotics transformer for real-world control at scale. In *Proceedings of Robotics: Science and Systems (RSS)*, 2023.
- [4] Anais Brygo, Ioannis Sarakoglou, Nadia Garcia-Hernandez, and Nikolaos Tsagarakis. Humanoid robot teleoperation with vibrotactile based balancing feedback. In *Haptics: Neuroscience, Devices, Modeling, and Applications: 9th International Conference, EuroHaptics 2014, Versailles, France, June 24-26, 2014, Proceedings, Part II* 9, pages 266–275. Springer, 2014.
- [5] Berk Calli, Arjun Singh, Aaron Walsman, Siddhartha Srinivasa, Pieter Abbeel, and Aaron M. Dollar. The ycb object and model set: Towards common benchmarks for manipulation research. In *2015 International Conference on Advanced Robotics (ICAR)*, pages 510–517, 2015. doi: 10.1109/ICAR.2015.7251504.
- [6] Carlos Campos, Richard Elvira, Juan J Gómez Rodríguez, José MM Montiel, and Juan D Tardós. Orb-slam3: An accurate open-source library for visual, visual-inertial, and multimap slam. *IEEE Transactions on Robotics*, 37(6):1874–1890, 2021.
- [7] Carlos Campos, Richard Elvira, Juan J. Gómez Rodríguez, José M. M. Montiel, and Juan D. Tardós. Orb-slam3: An accurate open-source library for visual, visual-inertial, and multimap slam. *IEEE Transactions on Robotics*, 37(6):1874–1890, 2021. doi: 10.1109/TRO.2021.3075644.
- [8] Annie S Chen, Suraj Nair, and Chelsea Finn. Learning generalizable robotic reward functions from “in-the-wild” human videos. In *Proceedings of Robotics: Science and Systems (RSS)*, 2021.
- [9] Cheng Chi, Siyuan Feng, Yilun Du, Zhenjia Xu, Eric Cousineau, Benjamin Burchfiel, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. In *Proceedings of Robotics: Science and Systems (RSS)*, 2023.
- [10] Kiran Doshi, Yijiang Huang, and Stelian Coros. On hand-held grippers and the morphological gap in human manipulation demonstration. *arXiv preprint arXiv:2311.01832*, 2023.
- [11] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. In *International Conference on Learning Representations*, 2021.
- [12] Jiafei Duan, Yi Ru Wang, Mohit Shridhar, Dieter Fox, and Ranjay Krishna. Ar2-d2: Training a robot without a robot. 2023.
- [13] Frederik Ebert, Yanlai Yang, Karl Schmeckpeper, Bernadette Bucher, Georgios Georgakis, Kostas Daniilidis, Chelsea Finn, and Sergey Levine. Bridge data: Boosting generalization of robotic skills with cross-domain datasets. In *Proceedings of Robotics: Science and Systems (RSS)*, 2022.
- [14] Hongjie Fang, Hao-Shu Fang, Yiming Wang, Jieji Ren, Jingjing Chen, Ruozhang, Weiming Wang, and Cewu Lu. Low-cost exoskeletons for learning whole-arm manipulation in the wild. *arXiv preprint arXiv:2309.14975*, 2023.
- [15] Zipeng Fu, Tony Z Zhao, and Chelsea Finn. Mobile aloha: Learning bimanual mobile manipulation with low-cost whole-body teleoperation. *arXiv preprint arXiv:2401.02117*, 2024.
- [16] S. Garrido-Jurado, R. Muñoz-Salinas, F.J. Madrid-Cuevas, and M.J. Marín-Jiménez. Automatic generation and detection of highly reliable fiducial markers under occlusion. *Pattern Recognition*, 47(6):2280–2292, 2014. ISSN 0031-3203. doi: <https://doi.org/10.1016/j.patcog.2014.01.005>. URL <https://www.sciencedirect.com/science/article/pii/S0031320314000235>.
- [17] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. corr

abs/1512.03385 (2015), 2015.

- [18] GoPro Inc. Gpmf introction: Parser for gpmf™ formatted telemetry data used within gopro® cameras. <https://gopro.github.io/gpmf-parser/>. Accessed: 2023-01-31.
- [19] Eric Jang, Alex Irpan, Mohi Khansari, Daniel Kappler, Frederik Ebert, Corey Lynch, Sergey Levine, and Chelsea Finn. Bc-z: Zero-shot task generalization with robotic imitation learning. In *Conference on Robot Learning (CoRL)*, volume 164, pages 991–1002. PMLR, 2022.
- [20] Moo Jin Kim, Jiajun Wu, and Chelsea Finn. Giving robots a hand: Broadening generalization via hand-centric human video demonstrations. In *Deep Reinforcement Learning Workshop NeurIPS*, 2022.
- [21] Yecheng Jason Ma, Shagun Sodhani, Dinesh Jayaraman, Osbert Bastani, Vikash Kumar, and Amy Zhang. VIP: Towards universal visual reward and representation via value-implicit pre-training. In *The Eleventh International Conference on Learning Representations*, 2023.
- [22] Ajay Mandlekar, Yuke Zhu, Animesh Garg, Jonathan Booher, Max Spero, Albert Tung, Julian Gao, John Emmons, Anchit Gupta, Emre Orbay, et al. Roboturk: A crowdsourcing platform for robotic skill learning through imitation. In *Conference on Robot Learning (CoRL)*, volume 87, pages 879–893. PMLR, 2018.
- [23] Suraj Nair, Aravind Rajeswaran, Vikash Kumar, Chelsea Finn, and Abhinav Gupta. R3m: A universal visual representation for robot manipulation. In *Proceedings of The 6th Conference on Robot Learning (CoRL)*, volume 205, pages 892–909. PMLR, 2022.
- [24] Chuer Pan, Brian Okorn, Harry Zhang, Ben Eisner, and David Held. Tax-pose: Task-specific cross-pose estimation for robot manipulation. In *Proceedings of The 6th Conference on Robot Learning (CoRL)*, volume 205, pages 1783–1792. PMLR, 2023.
- [25] Jyothish Pari, Nur Muhammad Shafiullah, Sridhar Pandian Arunachalam, and Lerrel Pinto. The surprising effectiveness of representation learning for visual imitation. In *Proceedings of Robotics: Science and Systems (RSS)*, 2022.
- [26] Luka Peternel and Jan Babič. Learning of compliant human–robot interaction using full-body haptic interface. *Advanced Robotics*, 27(13):1003–1012, 2013.
- [27] Pragathi Praveena, Guru Subramani, Bilge Mutlu, and Michael Gleicher. Characterizing input methods for human-to-robot demonstrations. In *2019 14th ACM/IEEE International Conference on Human-Robot Interaction (HRI)*, pages 344–353. IEEE, 2019.
- [28] Yuzhe Qin, Yueh-Hua Wu, Shaowei Liu, Hanwen Jiang, Ruihan Yang, Yang Fu, and Xiaolong Wang. Dexmv: Imitation learning for dexterous manipulation from human videos. In *European Conference on Computer Vision*, pages 570–587. Springer, 2022.
- [29] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, et al. Learning transferable visual models from natural language supervision. In *International conference on machine learning*, pages 8748–8763. PMLR, 2021.
- [30] Harish Ravichandar, Athanasios S Polydoros, Sonia Chernova, and Aude Billard. Recent advances in robot learning from demonstration. *Annual review of control, robotics, and autonomous systems*, 3:297–330, 2020.
- [31] Erick Rosete-Beas, Oier Mees, Gabriel Kalweit, Joschka Boedecker, and Wolfram Burgard. Latent plans for task-agnostic offline reinforcement learning. In *Proceedings of The 6th Conference on Robot Learning (CoRL)*, volume 205, pages 1838–1849. PMLR, 2023.
- [32] Felipe Sanches, Geng Gao, Nathan Elangovan, Ricardo V Godoy, Jayden Chapman, Ke Wang, Patrick Jarvis, and Minas Liarokapis. Scalable. intuitive human to robot skill transfer with wearable human machine interfaces: On complex, dexterous tasks. In *2023 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 6318–6325. IEEE, 2023.
- [33] Karl Schmeckpeper, Annie Xie, Oleh Rybkin, Stephen Tian, Kostas Daniilidis, Sergey Levine, and Chelsea Finn. Learning predictive models from observation and interaction. In *European Conference on Computer Vision*, pages 708–725. Springer, 2020.
- [34] Karl Schmeckpeper, Oleh Rybkin, Kostas Daniilidis, Sergey Levine, and Chelsea Finn. Reinforcement learning with videos: Combining offline observations with interaction. In *Proceedings of the 2020 Conference on Robot Learning (CoRL)*, volume 155, pages 339–354. PMLR, 2021.
- [35] Mingyo Seo, Steve Han, Kyutae Sim, Seung Hyeon Bang, Carlos Gonzalez, Luis Sentis, and Yuke Zhu. Deep imitation learning for humanoid loco-manipulation through human teleoperation. In *2023 IEEE-RAS 22nd International Conference on Humanoid Robots (Humanoids)*, pages 1–8. IEEE, 2023.
- [36] Nur Muhammad Mahi Shafiullah, Anant Rai, Haritheja Etukuru, Yiqian Liu, Ishan Misra, Soumith Chintala, and Lerrel Pinto. On bringing robots home. *arXiv preprint arXiv:2311.16098*, 2023.
- [37] Lin Shao, Toki Migimatsu, Qiang Zhang, Karen Yang, and Jeannette Bohg. Concept2robot: Learning manipulation concepts from instructions and human demonstrations. *The International Journal of Robotics Research*, 40(12-14):1419–1434, 2021.
- [38] Kenneth Shaw, Shikhar Bahl, and Deepak Pathak. Videodex: Learning dexterity from internet videos. In *Proceedings of The 6th Conference on Robot Learning (CoRL)*, volume 205, pages 654–665. PMLR, 2023.
- [39] William Shen, Ge Yang, Alan Yu, Jansen Wong, Leslie Pack Kaelbling, and Phillip Isola. Distilled feature fields enable few-shot language-guided manipulation. In *Proceedings of The 7th Conference on Robot Learning (CoRL)*, volume 229, pages 405–424. PMLR, 2023.
- [40] Anthony Simeonov, Yilun Du, Andrea Tagliasacchi, Joshua B Tenenbaum, Alberto Rodriguez, Pulkit Agrawal, and Vincent Sitzmann. Neural descriptor fields:

- Se (3)-equivariant object representations for manipulation. In *2022 International Conference on Robotics and Automation (ICRA)*, pages 6394–6400. IEEE, 2022.
- [41] Shuran Song, Andy Zeng, Johnny Lee, and Thomas Funkhouser. Grasping in the wild: Learning 6dof closed-loop grasping from low-cost demonstrations. *Robotics and Automation Letters*, 2020.
 - [42] H.J. Terry Suh, Naveen Kuppaswamy, Tao Pang, Paul Mitiguy, Alex Alspach, and Russ Tedrake. SEED: Series elastic end effectors in 6d for visuotactile tool use. In *2022 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 4684–4691, 2022. doi: 10.1109/IROS47612.2022.9982092.
 - [43] Alexander Toedtheide, Xiao Chen, Hamid Sadeghian, Abdeldjalil Naceri, and Sami Haddadin. A force-sensitive exoskeleton for teleoperation: An application in elderly care robotics. In *2023 IEEE International Conference on Robotics and Automation (ICRA)*, pages 12624–12630. IEEE, 2023.
 - [44] Chen Wang, Linxi Fan, Jiankai Sun, Ruohan Zhang, Li Fei-Fei, Danfei Xu, Yuke Zhu, and Anima Anandkumar. Mimicplay: Long-horizon imitation learning by watching human play. In *Proceedings of The 7th Conference on Robot Learning (CoRL)*, volume 229, pages 201–221. PMLR, 2023.
 - [45] Josiah Wong, Albert Tung, Andrey Kurenkov, Ajay Mandlekar, Li Fei-Fei, Silvio Savarese, and Roberto Martín-Martín. Error-aware imitation learning from teleoperation data for mobile manipulation. In *Proceedings of the 5th Conference on Robot Learning (CoRL)*, volume 164, pages 1367–1378. PMLR, 2022.
 - [46] Philipp Wu, Fred Shentu, Xingyu Lin, and Pieter Abbeel. GELLO: A general, low-cost, and intuitive teleoperation framework for robot manipulators. In *Towards Generalist Robots: Learning Paradigms for Scalable Skill Acquisition @ CoRL2023*, 2023.
 - [47] Keenan A Wyrobek, Eric H Berger, HF Machiel Van der Loos, and J Kenneth Salisbury. Towards a personal robotics development platform: Rationale and design of an intrinsically safe personal robot. In *2008 IEEE International Conference on Robotics and Automation*, pages 2165–2170. IEEE, 2008.
 - [48] Tete Xiao, Ilija Radosavovic, Trevor Darrell, and Jitendra Malik. Masked visual pre-training for motor control. *arXiv:2203.06173*, 2022.
 - [49] Haoyu Xiong, Quanzhou Li, Yun-Chun Chen, Homanga Bharadhwaj, Samarth Sinha, and Animesh Garg. Learning by watching: Physical imitation of manipulation skills from human videos. In *2021 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 7827–7834. IEEE, 2021.
 - [50] Sarah Young, Dhiraj Gandhi, Shubham Tulsiani, Abhinav Gupta, Pieter Abbeel, and Lerrel Pinto. Visual imitation made easy. In *Conference on Robot Learning (CoRL)*, volume 155, pages 1992–2005. PMLR, 2021.
 - [51] Tianhao Zhang, Zoe McCarthy, Owen Jow, Dennis Lee, Xi Chen, Ken Goldberg, and Pieter Abbeel. Deep imitation learning for complex manipulation tasks from virtual reality teleoperation. In *2018 IEEE International Conference on Robotics and Automation (ICRA)*, pages 5628–5635. IEEE, 2018.
 - [52] Zichao Zhang, Henri Rebecq, Christian Forster, and Davide Scaramuzza. Benefit of large field-of-view cameras for visual odometry. In *2016 IEEE International Conference on Robotics and Automation (ICRA)*, pages 801–808, 2016. doi: 10.1109/ICRA.2016.7487210.
 - [53] Tony Z Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware. In *Proceedings of Robotics: Science and Systems (RSS)*, 2023.
 - [54] Yifeng Zhu, Abhishek Joshi, Peter Stone, and Yuke Zhu. Viola: Imitation learning for vision-based manipulation with object proposal priors. In *Proceedings of The 6th Conference on Robot Learning (CoRL)*, volume 205, pages 1199–1210. PMLR, 2023.

附录

请访问我们的网站 (<https://umi-gripper.github.io>) 获取更多结果和比较。在附录中，我们提供了关于延迟测量 (§ A)、数据采集协议 (§ B)、评估协议 (§ C)、SLAM (§ D)、策略实现 (§ E) 和硬件实现 (§ F) 的更多细节。

A. 延迟测量

如正文所述，机器人系统中各种延迟的精确校准对于部署 UMI 策略至关重要，尤其是对于需要快速动态动作的任务。在以下章节中，我们将描述如何测量每个组件的延迟。

1) 相机延迟测量：为了在 UR5 和 Franka FR2 平台上进行策略观察，我们为每个机械臂配备了一个腕部安装的 GoPro Hero 9 相机。为了从 GoPro 获取实时视频流，我们结合使用 GoPro Media Mod 1.0 (将 USB-C 转换为 HDMI) 和 Elgato HD60X 外部采集卡 (将 HDMI 转换为 USB-3.0 UVC 接口)。为了测量相机管道的端到端延迟，我们用 GoPro 相机录制计算机显示器上滚动的二维码，该二维码显示每个视频帧的当前系统时间戳 $t_{display}$ ，如图 A1 所示。为了防止通过相机流叠加导致二维码被多次检测，我们在相机回放中遮盖了二维码，如显示器左侧所示。通过减去每帧的接收时间戳 t_{recv} 和解码的二维码时间戳 $t_{display}$ ，再减去已知的显示刷新延迟 $l_{display}$ ，我们可以得到相机系统的端到端延迟：

$$l_{camera} = t_{recv} - t_{display} - l_{display}$$

2) 本体感觉延迟测量：当机器人硬件直接报告全局时间戳时，例如 Franka FR2 机器人，我们通过从策略接收时间戳 t_{recv} 中减去机器人发送时间戳 t_{robot} 来测量本体感觉延迟：

$$l_{obs} = t_{recv} - t_{robot}$$

当机器人硬件时间戳不可用时，例如 UR5 机器人和 Schunk WSG-50 夹爪，我们用 ICMP 往返时间 (即 ping) 的 $\frac{1}{2}$ 来近似本体感觉延迟。3) 夹爪执行延迟测量：为了获得夹爪执行延迟 l_{action} ，我们从端到端延迟 l_{e2e} 中减去本体感觉延迟 l_{obs} 。为了测量 l_{e2e} ，我们向夹爪发送一系列正弦位置命令，然后记录一系列夹爪宽度感知值。通过交叉卷积计算期望夹爪宽度信号与实际接收到的夹爪宽度信号之间的最优对齐，可以得到 l_{e2e} 。 $l_{action} = l_{e2e} - l_{obs}$



Fig. A1: Camera Latency Measurement

4) 机器人执行延迟测量：与夹爪类似，我们也通过计算 l_{e2e} 来测量机器人 (UR5 或 Franka) 的执行延迟，即期望末端执行器位姿序列与实测实际末端执行器位姿序列之间的最优对齐。出于安全考虑，我们直接遥控操作机器人以生成期望的末端执行器位姿序列。

B. 数据收集协议

UMI 实现了接近零设置时间的野外数据收集。为了在新环境中开始数据收集，演示者遵循 4 步流程：

- **时间同步 (可选)。**在双臂确认中使用通用操作接口 (UMI) 时，我们通过扫描智能手机上的滚动二维码来同步两台运动相机 (GoPro) 的内部时钟。“GoPro Labs”实验固件识别二维码中编码的全局时间戳，并以 $\pm \frac{1}{60}$ 秒的精度校准其内部时钟。对于单臂任务，此步骤可跳过。
- **夹爪校准 (可选)。**我们通过录制夹爪开合 5 次的视频来校准夹爪手指之间的最小和最大宽度。虽然由于制造不一致，每个夹爪只需执行一次此步骤，但我们通常在每个数据采集场景中都执行此操作，以避免在采集会话之间意外混淆夹爪而引发潜在问题。
- **建图。**对于每个新场景，我们通过缓慢移动夹爪来扫描环境，遵循一种模式：首先覆盖场景的足够部分，然后模仿期望任务的可能运动，以便在任务相关部分获得更密集的覆盖。如第 D 节所述，获得高质量地图对于精确且鲁棒的同步定位与建图 (SLAM) 跟踪至关重要，尤其是在演示过程中的快速运动。为进一步提高建图鲁棒性，我们可选择在桌面/地面上放置一个基准标记，该标记将在演示期间移除。建图过程通常约需 1 分钟。

H-Param	I-To	P-To	Ta	Freq	Speed	ImgRes	V-Arch	V-Pretrain	D-Lr	V-Lr	Epochs	Batch	Compute
Cup Arrag.	2	2	6	10	0.5x	1x224x224	ViT-B/16	CLIP	3e-4	3e-5	250	512	4xA10g
Obj Tossing	2	2	6	20	1.0x	1x224x224	ResNet-34	No	3e-4	3e-4	350	1024	4xA10g
Cloth Folding	2	2	6	10	0.5x	2x224x224	ResNet-34	No	3e-4	3e-4	100	1024	4xA10g
Dish Washing	2	2	6	10	0.5x	2x224x224	ViT-B/16	CLIP	3e-4	3e-5	90	224	8xA10g
Cup (In-the-wild)	1	2	6	10	0.5x	1x224x224	ViT-L/14	CLIP	3e-4	3e-5	50	512	8xA100

表 A1: 扩散策略 (Diffusion Policy) 的超参数 I-To: 图像观测时域。P-To: 本体感知观测时域。Ta: 动作时域。Freq: 环境频率 (赫兹, 观测和动作均适用)。Speed: 策略执行速度相对于数据采集速度。ImgRes: 环境观测分辨率 (相机视图数 $\times$ 宽 $\times$ 高)。V-Arch: 视觉编码器架构。V-Pretrain: 视觉编码器的预训练方法。D-Lr: 动作扩散模型的学习率。V-Lr: 视觉编码器的学习率。Epochs: 训练轮次。Batch: 所有图形处理器 (GPU) 上的总批大小。Compute: 用于训练的图形处理器数量和类型。所有任务均使用去噪扩散隐式模型 (DDIM) 调度器, 训练扩散步数为 50, 推理步数为 16。

• **演示。**在此步骤中, 演示者在同一场景内重复执行所需任务。每次演示录制一段视频, 视频本身标记每个回合的开始与结束。在单夹爪配置下, 演示者可用另一只手按下 GoPro 上的录制按钮, 或使用 GoPro 遥控器, 来开始和结束每次视频录制。在双臂配置下, 演示者使用 GoPro 内置的语音命令 (“GoPro capture”、“GoPro stop capture”) 来开始和结束视频录制。在每个班次/一天结束时, 演示者将所有夹爪上的 mp4 文件上传到云存储, 每个场景一个文件夹。随后, 我们提供一个脚本, 将这些 mp4 文件转换为可直接用于训练扩散策略的数据集。该脚本在底层自动检测并区分左右夹爪 (利用 GoPro 的序列号), 将视频匹配为同步对, 并通过我们的 SLAM 流程和基准标记检测恢复机器人动作。

C. 评估协议

本节详细说明真实世界策略评估的过程。具体而言, 我们将描述如何选择初始状态、如何终止实验, 以及如何判断成功与失败。

1) 初始状态选择: 对于所有任务, 我们手动选择一组初始状态, 这些状态在任务场景中 (机器人及环境) 具有多样化的位姿覆盖, 且在所有评估方法间共享。评估期间, 我们通过第三人称相机手动匹配初始状态, 使其接近像素级完美。我们通过遥操作确保初始状态在运动学上可行。对于窄域任务, 我们以与数据收集大致相同的分布随机化物体。

2) 终止标准: 评估期间, 操作员始终监督机器人。评估回合可因以下原因终止:

- **安全顾虑。**当操作员认为机器人即将执行可能损坏设备或机器人本身、或造成其他危害的危险动作时, 该回合将立即终止。
- **机器人故障。**当机器人进入故障状态时, 可能由于外部或自身碰撞、过大的力、

或关节/速度极限违规, 该回合将自动终止。

- **超时。**我们手动设置一个任务特定的保守超时时间, 通常为任务中位时长的 3-5 倍, 以自动终止该回合。该超时通常在策略陷入停滞且不再取得进展时触发。

- **任务成功。**当操作员认为任务已成功完成时, 手动终止该回合。

由于终止标准包含主观因素, 我们鼓励读者观看我们的补充视频, 其中包含所有报告的实验。

3) 成功标准: 对于本文报告的复杂操作任务, 难以定义自动且紧凑的成功度量。因此, 操作员使用下述评分标准手动判断每个回合的成功或失败。虽然我们试图制定简洁客观的评分标准, 但不可避免地包含主观因素。因此, 观看我们的补充视频仍然是阐明我们方法与各种基线之间相对性能的最佳方式。

杯子摆放。我们将任务成功定义为杯子直立放置在碟子上, 且其把手位于机器人左侧 $\pm 15^\circ$ 范围内。

动态投掷。我们将任务成功定义为物体被投掷到相应的箱子中。只要物体击中箱子底部, 从箱子内部弹起也算成功。如果物体击中箱子侧壁并弹回桌面, 随后成功投入箱子, 也算成功。

双手叠衣。我们将任务成功定义为: 当毛衣的两只袖子都折叠在毛衣内部, 且折叠后毛衣的轮廓 (投影面积) 近似为正方形, 面积约为毛衣躯干面积的四分之一。袖子折叠进去但并非完全平整仍算成功。即使布料并非完全平整, 只要投影面积近似正方形, 该回合仍视为成功。

洗碗。当盘子干净并竖直放回沥水架时, 该回合视为成功。尺寸小于 5 毫米的番茄酱残留斑点视为干净。如果海绵放在水槽边缘后滑入水槽内, 只要盘子干净并放回沥水架, 不影响任务成功。

野外杯子整理。成功标准为



图 A2：杯子选择。对于野外杯子整理任务，我们在亚马逊上购买了 20 种不同款式的“浓缩咖啡杯带碟”，其中 18 种用于训练，2 种保留用于测试。

与窄域杯子整理相同，不同之处在于“左”的概念是相对于每个回合夹爪的初始姿态定义的。训练和测试杯子的选择见图 A2。

D. 同步定位与建图系统细节

我们发现 OBR-SLAM3 的 [7] 原始单目惯性 SLAM 系统不足以满足我们的应用需求。具体而言，ORB-SLAM3 的初始化过程会启发式地计算最初几个地图点和关键帧以及 IMU 校准参数。我们发现该初始化过程在快速运动下特别脆弱且耗时，期间无法估计任何相机位姿，导致大量数据被浪费。为解决此问题，我们实现了两个功能：地图作为初始化和标记增强初始化。

地图作为初始化。原始 ORB-SLAM3 具有定位模式，可在不改变地图的情况下定位到现有地图，包括不创建更多地图点或执行任何全局优化。我们发现现有定位模式不够鲁棒，因为 UMI 操作会动态改变场景。为解决此问题，我们修改了 ORB-SLAM3，使其在重定位到从磁盘加载的现有地图后继续正常的 SLAM 操作，从而有效地将现有地图仅用作优化的初始化。

标记增强初始化。由于单目 SLAM 公式的固有歧义性，当特征距离较远（室外环境）或存在大量特征误匹配（重复图案、树木等）时，ORB-SLAM3 的现有初始化会陷入困境。我们修改了 ORB-SLAM3，使其可选择利用已知尺寸的基准标记 [16] 来消除特征匹配可能解释的歧义。我们发现此功能显著提高了野外建图的鲁棒性。请注意，演示视频中不会包含这些基准标记，它们仅用于建图。

E. 策略实现细节

我们使用扩散策略 [9] 完成所有任务。详细超参数列于表 A1。与原始扩散策略相比，以下是一些关键修改：

1) **视觉编码器：**本文采用视觉变换器（Vision Transformer, ViT）[11] 作为视觉编码器，因其相较于残差网络（ResNet）[17] 具有更大的容量，这对于需要精细感知能力的任务至关重要。值得注意的是，为每项任务收集的数据集规模不足以从头训练 ViT。为解决这一局限性，本文使用预训练的 CLIP ViT，并在微调过程中将学习率降低 10 倍。虽然 ViT-B 足以应对大多数域内任务，但 ViT-L 能进一步提升域外杯子整理任务的性能，该任务涉及多样化的环境和物体。为加速 ViT-L 的训练和推理，本文仅使用单步观测作为输入，不同于其他任务中采用的两步观测窗口方法。

2) **频率：**对于大多数准静态任务，10Hz 的频率对观测和动作均足够。然而，对于需要高度反应行为的动态投掷任务，采用 20Hz 的频率。

3) **速度：扩散策略的输出是一系列动作，即目标位姿，两步之间的隐式 dt_{output} 由演示数据集决定。然而，在执行过程中，本文不必遵循相同的 dt 。通过调整 $dt_{execution}$ ，可以实现与人类演示不同的执行速度。对于动态投掷任务，保持原始速度至关重要，以确保物体获得足够的释放速度。然而，对于其他准静态任务，本文观察到 0.5 倍慢速能产生更平滑的行为。这一现象可能源于不完美的延迟补偿，并可通过改进延迟匹配来缓解。**

4) **图像增强：**本文采用一组图像增强方法来增加训练数据的多样性，从而提高策略的鲁棒性和泛化能力。增强流程包括比例为 0.95 的随机裁剪（RandomCrop）、角度范围为 -5.0 到 5.0 度的随机旋转（RandomRotation）以及颜色抖动（ColorJitter），其中亮度调整最高 0.3、对比度 0.4、饱和度 0.5、色调 0.08。具体参数选择依据数据集的分布确定。

F. 硬件实现细节

1) **软体柔顺手指：**我们在 UMI 数据采集夹爪和部署的机器人夹爪上均使用了相同的软体手指。手指采用 95A TPU 材料打印，其肋状纹理在指尖保持刚性的同时，能够顺应物体几何形状，从而实现更牢固的抓取（图 A3）。当部署到缺乏力/力矩控制的机器人（如 UR5）上时，软体手指的可变形特性提供了被动机械柔顺性，这对于接触密集型任务（如打开水龙头和从桌面舀起薄衣物）至关重要。软体手指与连续夹爪控制相结合，还提供了一定的隐式抓取力控制。



图 A3: 采用 TPU 材料打印的软体手指提供被动机械柔顺性，能够牢固抓取生鸡蛋而不致其破裂。

2) Franka 安装座：由于 FR2 末端执行器的俯仰范围有限（FR2 设计用于自上而下的抓取和放置，而 UMI 夹爪大多水平握持），我们不得不设计并 3D 打印一个定制安装适配器，使 WSG50 夹爪相对于机器人末端法兰旋转 90 度。