

通过文本引导视频生成学习通用策略

Yilun Du^{*†‡}, Mengjiao Yang^{*‡§}, Bo Dai^{‡¶}, Hanjun Dai[‡], Ofir Nachum[‡],
Joshua B. Tenenbaum[†], Dale Schuurmans^{‡¶}, Pieter Abbeel[§]
MIT[†] Google DeepMind[‡] UC Berkeley[§] Georgia Tech[¶] University of Alberta[¶]
<https://universal-policy.github.io/>

摘要

人工智能的一个目标是构建能够解决各种任务的智能体。文本引导图像合成的最新进展催生了具有出色能力的模型，能够生成复杂的新颖图像，展现出跨领域的组合泛化能力。受此成功启发，我们研究是否可以利用此类工具构建更通用的智能体。具体而言，我们将序贯决策问题表述为文本条件视频生成问题，其中，给定所需目标的文本编码规范，规划器合成一组描绘其未来计划动作的帧，随后从生成的视频中提取控制动作。通过利用文本作为底层目标规范，我们能够自然且组合地泛化到新目标。所提出的策略即视频的表述可以进一步在统一的图像空间中表示具有不同状态和动作空间的环境，例如，这能够实现跨多种机器人操作任务的学习与泛化。最后，通过利用预训练语言嵌入和互联网上广泛可用的视频，该方法能够通过为真实机器人预测高度逼真的视频计划来实现知识迁移²。

1 引言

构建能够解决多样化任务的模型已成为视觉和语言领域的主导范式。在自然语言处理中，大型预训练模型已展现出对新语言任务的显著零样本学习能力 [1, 2, 3]。类似地，在计算机视觉中，如 [4, 5] 所提出的模型已展现出显著的零样本分类和物体识别能力。自然的下一步是利用此类工具构建能够在多种环境中完成不同决策任务的智能体。

然而，训练此类智能体面临环境多样性的固有挑战，因为不同环境具有不同的状态动作空间（例如，MuJoCo 中的关节空间与连续控制与 Atari 中的图像空间与离散动作存在根本差异）。这种多样性阻碍了跨任务和跨环境的知识共享、学习与泛化。尽管已有大量工作致力于在序列建模框架中用通用标记对不同环境进行编码 [6]，但尚不清楚此类方法能否保留预训练视觉和语言模型中蕴含的丰富知识，并利用这些知识迁移到下游强化学习任务中。此外，构建能够指定跨环境不同任务的奖励函数也十分困难。

在本文中，我们通过利用视频（即图像序列）作为传递动作和观测的通用接口，来解决环境多样性和奖励指定方面的挑战^{*}表示同等贡献。通讯作者：yilundu@mit.edu 和 sherry@berkeley.edu。² 视频可视化见 <https://universal-policy.github.io/>。




图 1：文本条件视频生成作为通用策略。文本条件视频生成使我们能够在广泛的数据源（模拟、真实机器人和 YouTube）上训练通用策略，这些策略可应用于下游多任务场景，这些场景需要组合语言泛化、长时程规划或互联网规模知识。不同环境中的行为，以及文本作为表达任务描述的通用接口。特别是，我们设计了一个视频生成器作为规划器，它依次以当前图像帧和描述当前目标（即下一个高层步骤）的文本段落为条件，生成图像序列形式的轨迹，之后使用逆动力学模型从生成的视频中提取底层动作。这种方法允许利用语言和视频的通用性来泛化到不同环境中的新目标和新任务。具体来说，我们使用视频扩散来实例化文本条件视频生成模型。然后从合成帧中回归一组底层动作，并用于构建策略以实现规划的轨迹。由于任务的语言描述通常与控制动作高度相关，文本条件视频生成自然地将生成集中在视频中与动作相关的部分。所提出的模型 UniPi 如图 1 所示。

我们发现，通过文本条件视频合成来制定策略生成具有以下优势：

组合泛化。语言丰富的组合特性可以被利用来在环境中合成新颖的组合行为。这使得所提出的方法能够将物体重新排列到新的未见过的几何关系组合中，如第 4.1 节所示。

多任务学习。将动作预测制定为视频预测问题，可以轻松实现跨许多不同任务的学习。我们在第 4.2 节中说明了这如何实现跨语言条件任务的学习，并在测试时无需微调即可泛化到新任务。

动作规划。其中

生成一系列表示动作的帧以达到目标。这种规划过程天然具有层次性：可以先向目标生成时间上稀疏的图像序列，再用更具体的计划进行细化。此外，规划过程是可引导的，即计划生成可以通过测试时采样引入的新约束来偏置。最后，计划在视频空间中产生，该空间对人类天然可解释，使动作验证和计划诊断变得容易。我们在表 2 中展示了层次采样的有效性，在图 7 中展示了可引导性。

互联网规模的知识迁移。通过在大规模从互联网恢复的文本-视频数据集上预训练视频生成模型，可以恢复一个庞大的“演示”库，有助于在新环境中构建文本条件策略。我们在第 4.3 节中展示了这如何实现从语言指令逼真合成机器人运动视频。

这项工作的主要贡献是将文本条件视频生成制定为一种通用规划策略，从中可以合成多样化的行为。虽然这种方法偏离了强化学习中典型的策略生成（即从当前状态直接预测后续要执行的动作），但我们展示了 UniPi 在多个领域中相比传统策略生成方法具有显著的泛化优势。

2 问题表述

我们首先提出一种新的抽象，即统一预测决策过程（UPDP），作为强化学习中常用的马尔可夫决策过程（MDP）的替代方案，然后展示用扩散模型实例化 UPDP。

2.1 马尔可夫决策过程

马尔可夫决策过程 [7] 是一种广泛的抽象，用于表述许多顺序决策问题。许多强化学习算法源自 MDP 并取得了实证成功 [8, 9, 10]，但现有算法通常无法在不同环境之间进行组合泛化。这种困难可以追溯到底层 MDP 抽象的某些方面：

- i) 不同控制环境之间缺乏通用的状态接口。事实上，由于不同环境通常具有各自独立的基础状态空间，人们需要构建一个复杂的状态表示来涵盖所有环境，这使得学习变得困难。
- ii) 马尔可夫决策过程 (MDP) 中明确要求实值奖励函数。强化学习问题通常被定义为在 MDP 中最大化累积奖励。然而，在许多实际应用中，如何设计和迁移奖励并不明确，且在不同环境中存在差异。
- iii) MDP 中的动力学模型依赖于环境和智能体。具体而言，刻画在动作 a 下状态 (s, s') 之间转移的动力学模型 $T(s'|s, a)$ ，明确依赖于智能体所处的环境和动作空间，而不同智能体和任务之间可能存在显著差异。

2.2 统一预测决策过程

这些困难促使我们构建一种替代抽象，用于跨多样环境的统一序贯决策。我们的抽象称为统一预测决策过程 (Unified Predictive Decision Process, UPDP)，利用图像作为跨环境的通用接口，文本作为任务说明以避免奖励设计，以及一个与环境相关控制分离的任务无关规划模块，以实现知识共享和泛化。

形式上，我们将 UPDP 定义为一个元组 $\mathcal{G} = \langle \mathcal{X}, \mathcal{C}, H, \rho \rangle$ ，其中 $\mathcal{X}$ 表示图像观测空间， $\mathcal{C}$ 表示文本任务描述空间， $H \in \mathbb{N}$ 是有限视界长度， $\rho(\cdot|x_0, c) : \mathcal{X} \times \mathcal{C} \rightarrow \Delta(\mathcal{X}^H)$ 是一个条件视频生成器。也就是说， $\rho(\cdot|x_0, c) \in \Delta(\mathcal{X}^H)$ 是由第一帧 H 和任务描述 x_0 决定的 c 步图像序列上的条件分布。直观上， ρ 合成 H 步图像轨迹，展示完成目标任务 c 的可能路径。为简单起见，我们专注于有限视界的回合制任务。

给定一个 UPDP $\mathcal{G}$ ，我们定义一个轨迹-任务条件策略 $\pi(\cdot|\{x_h\}_{h=0}^H, c) : \mathcal{X}^{H+1} \times \mathcal{C} \rightarrow \Delta(\mathcal{A}^H)$ 为 H 步动作序列 $\mathcal{A}^H$ 上的条件分布。理想情况下， $\pi(\cdot|\{x_h\}_{h=0}^H, c)$ 指定一个动作序列的条件分布，该动作序列在 UPDP $\mathcal{G}$ 中针对给定任务 c 实现给定轨迹 $\{x_h\}_{h=0}^H$ 。为了实现这种对齐，我们将考虑一个离线强化学习场景，其中我们可以访问现有经验数据集 $\mathcal{D} = \{(x_i, a_i)_{i=0}^{H-1}, x_H, c\}_{j=1}^n$ ，从中可以估计 $\rho(\cdot|x_0, c)$ 和 $\pi(\cdot|\{x_h\}_{h=0}^H, c)$ 。

与马尔可夫决策过程 (MDP) 相比，无策略依赖规划器 (UPDP) 直接对基于视频的轨迹进行建模，无需在文本任务描述之外指定奖励函数。由于视频观测空间 $\mathcal{X}^H$ 和任务描述空间 $\mathcal{C}$ 在不同环境中天然共享且易于人类理解，任何基于视频的规划器 $\rho(\cdot|x_0, c)$ 都可以方便地复用、迁移和调试。UPDP 相对于 MDP 的另一个优势在于，UPDP 将基于视频的规划（使用 $\rho(\cdot|x_0, c)$ ）与延迟的动作选择（使用 $\pi(\cdot|\{x_h\}_{h=0}^H, c)$ ）分离开来。这种设计选择将规划决策与动作特定机制隔离，使规划器能够独立于环境和智能体。

UPDP 可以理解为在 MDP 上进行隐式规划，并根据给定指令直接输出最优轨迹。这种 UPDP 抽象绕过了奖励设计、状态提取和显式规划，并允许对基于图像的状态空间进行非马尔可夫建模。然而，在 UPDP 中学习规划器需要视频和任务描述，而传统 MDP 不需要此类数据，因此对于给定任务，MDP 或 UPDP 哪个更合适取决于可用的训练数据类型。尽管与 MDP 相比，非马尔可夫模型以及对视频和文本数据的需求给 UPDP 带来了额外的困难，但可以利用在大规模网络数据集上预训练的现有大型文本-视频模型来缓解这些复杂性。

2.3 用于 UPDP 的扩散模型


设 $\tau = [x_1, \dots, x_H] \in \mathcal{X}^H$ 表示图像序列。我们利用扩散模型近期取得的显著进展来捕捉条件分布 $\rho(\tau|x_0, c)$ ，并将其

用作 UPDP 中文本和初始帧条件下的视频生成器。我们强调，UPDP 公式也兼容其他概率模型，例如变分自编码器 [11]、基于能量的模型 [12, 13] 或生成对抗网络 [14]。为完整起见，我们简要概述核心公式，但细节请参考背景文献 [15]。

我们从无条件模型开始。连续时间扩散模型定义了一个前向过程 $q_k(\tau_k|\tau) = \mathcal{N}(\cdot; \alpha_k\tau, \sigma_k^2 I)$ ，其中 $k \in [0, 1]$ 和 α_k, σ_k^2 是具有预定义时间表的标量。还定义了一个生成过程 $p(\tau)$ ，它通过学习去噪模型 $s(\tau_k, k)$ 来逆转前向过程。相应地， τ 可以通过使用祖先采样器 [16] 或数值积分 [17] 模拟这个逆过程来生成。在我们的情况下，无条件模型需要进一步适应以同时条件化于文本指令 c 和初始图像 x_0 。将条件去噪器表示为 $s(\tau_k, k|c, x_0)$ 。我们利用无分类器引导 [18]，并在采样时使用 $\hat{s}(\tau_k, k|c, x_0) = (1 + \omega)s(\tau_k, k|c, x_0) - \omega s(\tau_k, k)$ 作为逆过程中的去噪器，其中 ω 控制文本和首帧条件的强度。

3 基于视频的决策

接下来我们详细描述所提出的方法 **UniPi**，它是扩散通用决策过程（UPDP）的一个具体实例。**UniPi** 结合了第 2 节讨论的两个主要组成部分，如图 2 所示：(i) 用于通用视频规划器的扩散模型 $\rho(\cdot|x_0, c)$ ，该模型以首帧和任务描述为条件合成视频；以及 (ii) 任务特定的动作生成器 $\pi(\cdot|\{x_h\}_{h=0}^H, c)$ ，它通过逆动力学建模从生成的视频中推断动作序列。



3.1 通用视频规划器

受近期文本到视频模型 [19] 成功的鼓舞，我们试图构建一个视频扩散模块作为轨迹规划器，它能够在给定初始帧和文本任务描述的情况下忠实地合成未来图像帧。然而，所期望的规划器与文本到视频模型 [20, 19] 的典型设置不同，后者通常根据文本描述生成无约束的视频。通过视频生成进行规划更具挑战性，因为它要求模型既能生成从指定图像开始的受约束视频，又能完成目标任务。此外，为了确保在视频的合成帧之间进行有效的动作推断，视频预测模块需要能够跟踪合成视频帧中的底层环境状态。

条件视频合成。为了生成有效且可执行的计划，文本到视频模型必须从描绘智能体与环境初始配置的初始图像开始，合成一个受约束的视频计划。解决该问题的一种方法是修改无条件模型底层的测试时采样过程，将生成的视频计划的第一帧固定为始终从观测图像开始，如 [21] 中所做。然而，我们发现这种方法效果不佳，导致视频计划中的后续帧与原始观测图像显著偏离。相反，我们发现通过在训练期间将每个视频的第一帧作为显式条件上下文提供，显式训练一个受约束的视频合成模型更为有效。

通过平铺实现轨迹一致性。现有的文本到视频模型通常生成的视频中，底层环境状态在时间持续期间发生显著变化 [19]。为了构建准确的轨迹规划器，环境在所有时间点上保持一致至关重要。为了在条件视频合成中强制环境一致性，我们在对合成视频中的每一帧进行去噪时，额外提供观测图像作为上下文。具体而言，我们重新利用一种时间超分辨率视频扩散架构，并将条件化的视觉观测在时间上平铺作为上下文，而不是在每个时间步对低时间分辨率视频进行去噪。在该模型中，我们直接将每个

中间含噪帧与条件化的观测图像在采样步骤中拼接，这作为维持底层环境状态跨时间一致的强信号。

分层规划。在高维环境中构建具有长时间跨度的计划时，直接生成一组动作以达到目标状态会因底层搜索空间的指数级膨胀而迅速变得难以处理。规划方法通常通过利用规划中的自然层次结构来规避这一问题。具体而言，规划方法首先构建在低维状态和动作上运行的粗略计划，随后可将其细化为底层状态和动作空间中的计划。与规划类似，我们的条件视频生成过程同样展现出自然的时间层次结构。我们首先通过沿时间轴稀疏采样的视频（“抽象”）在粗略层面生成视频，以表示期望行为。然后，我们通过跨时间超分辨率细化视频，使其表示环境中的有效行为。同时，从粗到细的超分辨率通过帧间插值进一步提高了时间一致性。

灵活的行为调制。

在为给定子目标规划动作序列时，可以轻松地纳入外部约束来调制生成的计划。这种测试时适应性可以通过在计划生成期间组合先验 $h(\tau)$ 来实现，以指定合成动作轨迹 [21] 上的期望约束，这也与 UniPi 兼容。特别地，先验 $h(\tau)$ 可以使用在图像上训练的分类器来指定，以优化特定任务，或者作为特定图像上的狄拉克 δ 函数来引导计划朝向特定状态集。为了训练文本条件视频生成模型，我们采用了 [19] 中的视频扩散算法，其中编码了来自 T5 [22] 的预训练语言特征。有关底层架构和训练细节，请参见附录 A。

3.2 任务特定动作适应

给定一组合成视频，我们可以训练一个小型的任务特定逆动力学模型，将帧转换为一组动作，如下所述。

逆动力学。我们训练一个小型模型，根据输入图像估计动作。逆动力学的训练独立于规划器，可以在由模拟器生成的独立、较小且可能次优的数据集上完成。

动作执行。最后，本文在给定 x_0 和 c 的条件下生成动作序列，通过合成 H 图像帧并应用学习到的逆动力学模型来预测相应的 H 动作。推断出的动作随后可通过闭环控制执行，即在每个动作执行步骤后生成 H 个新动作（即模型预测控制），或通过开环控制执行，即按顺序执行最初推断出的动作序列中的每个动作。为提升计算效率，本文所有实验均采用开环控制器。

4 实验评估

这些实验的重点是评估 UniPi 在实现有效、可泛化决策方面的能力。具体而言，我们评估

- (1) 在第 4.1 节中跨不同子目标进行组合泛化的能力，
- (2) 在第 4.2 节中有效学习并跨多个任务泛化的能力，
- (3) 在第 4.3 节中利用互联网上现有视频泛化到复杂任务的能力。

实验细节见附录 A。附加结果见附录 B，视频见补充材料。

4.1 组合策略综合

首先，我们测度 UniPi 对不同语言任务进行组合泛化的能力。

设置。为测度组合泛化，我们使用 [23] 中的组合机器人规划任务。在该任务中，机器人必须操纵环境中的积木以满足语言指令，例如，将红色积木放在青色积木的右侧。为完成该任务，机器人必须首先拾起白色积木，将其放入适当的碗中涂成特定颜色，然后拾起并放置积木到盘子中，使其满足指定关系。与 [23] 使用

Model	Seen		Novel	
	Place	Relation	Place	Relation
State + Transformer BC [24]	19.4 $\pm$ 3.7	8.2 $\pm$ 2.0	11.9 $\pm$ 4.9	3.7 $\pm$ 2.1
Image + Transformer BC [24]	9.4 $\pm$ 2.2	11.9 $\pm$ 1.8	9.7 $\pm$ 4.5	7.3 $\pm$ 2.6
Image + TT [25]	17.4 $\pm$ 2.9	12.8 $\pm$ 1.8	13.2 $\pm$ 4.1	9.1 $\pm$ 2.5
Diffuser [21]	9.0 $\pm$ 1.2	11.2 $\pm$ 1.0	12.5 $\pm$ 2.4	9.6 $\pm$ 1.7
UniPi (Ours)	59.1 $\pm$ 2.5	53.2 $\pm$ 2.0	60.1 $\pm$ 3.9	46.1 $\pm$ 3.0

表 1: 组合环境中的任务完成准确率。UniPi 在放置（例如，将 X 放入 Y）和关系（例如，将 X 放在 Y 的左侧）任务中泛化到已见和新的语言提示组合。




图 3: 组合视频生成。测试时为未见语言目标生成的视频。

预编程的拾取和放置原语用于动作预测，我们在连续机器人关节空间中为基线和本文方法预测动作。

我们将该环境中的语言指令分为两组：一组指令（70%）在训练期间可见，另一组指令（30%）仅在测试期间可见。环境中各个积木、碗和盘子的精确位置在每次环境迭代中完全随机化。我们在训练集上使用 20 万个生成语言指令的示例视频来训练视频模型。该环境的详细信息见附录 A。我们通过使用脚本化智能体构建了该任务中的视频演示。

基线。我们将所提出的方法与三种独立的代表性方法进行比较。首先，我们与现有工作进行比较，这些工作使用目标条件变换器在多个环境中学习，其中目标可以指定为回合回报 [26]、专家演示 [6] 或文本和图像 [24]。为了表示这些基线，我们构建了一个变换器行为克隆（BC）智能体，在给定任务描述以及视觉观察（图像+变换器 BC）或底层机器人关节状态（状态+变换器 BC）的情况下，预测要执行的后续动作。其次，鉴于我们的方法回归要执行的动作序列，我们进一步与回归未来动作序列的变换器模型进行比较，类似于轨迹变换器 [25] 的目标条件行为克隆（图像+TT）。最后，为了突出视频即策略方法的重要性，我们将 UniPi 与学习扩散过程进行比较，该过程以图像观察为条件，直接在关节空间中推断未来机器人动作（与扩散未来图像帧相反），对应于 [21, 27]。对于我们的方法和每个基线，我们使用预训练的 T5 嵌入对编码的语言指令进行条件化。请注意，在此设置中，现有的离线强化学习基线并不直接适用，因为我们无法访问环境中的奖励函数。




图 4: 动作执行。在模拟环境中合成的视频计划和执行的行动。两个视频计划大致相互对齐。

度量。为了将 UniPi 与基线进行比较，我们测量在新环境实例和相关语言提示下的最终任务完成准确率。我们沿两个轴细分评估：（1）语言指令是否在训练期间见过，以及（2）是否




图 5：多任务视频生成。在多任务设置下，针对新测试任务生成的视频规划。UniPi 能够在—组环境中合成规划。

Frame Condition	Frame Consistency	Temporal Heirarchy	Place	Relation
No	No	No	13.2 ± 3.2	12.4 ± 2.4
Yes	No	No	52.4 ± 2.9	34.7 ± 2.6
Yes	Yes	No	53.2 ± 3.0	39.4 ± 2.8
Yes	Yes	Yes	59.1 ± 2.5	53.2 ± 2.0

表 2：任务完成准确率消融实验。UniPi 的每个组件均提升了其性能。性能在已见的位置和关系任务上报告。

语言指令指定将积木相对于其他积木放置，而非直接拾取和放置。

组合泛化。在表 1 中，我们发现 UniPi 对已见和新颖的语言提示组合均具有良好的泛化能力。我们在图 4 中展示了动作生成流程，并在图 3 中展示了使用本方法生成的不同视频规划。

消融实验。在表 2 中，我们对 UniPi 在已见语言指令和关系任务上进行了消融。具体而言，我们研究了以第一帧观察为条件（帧条件）、跨时间步平铺观察帧（帧一致性）以及跨时间超分辨率视频生成（时间层级）对视频生成模型的影响。在未强制帧一致性的设置中，我们为视频中的非起始帧提供零值图像作为上下文。我们发现 UniPi 的所有组件对良好性能都至关重要。我们发现帧条件和一致性使视频与观察图像保持一致，而时间层级则实现了更详细的视频规划。




图 7：自适应规划。通过引导测试时采样朝向中间图像，我们可以调整规划过程以移动特定积木。

适应性。接下来，我们评估 UniPi 在测试时适应新约束的能力。在图 7 中，我们展示了构建计划的能力，这些计划能够将特定方块着色并移动到指定的几何关系位置。

4.2 多环境迁移

接下来，我们评估 UniPi 在一组不同任务中有效学习并在测试时泛化到一组新的未见环境的能力。

实验设置。为了衡量多任务学习与迁移能力，我们使用来自 [28] 的语言引导操作任务套件。我们使用来自 [28] 的 10 个独立任务的演示来训练我们的方法，并评估我们的方法迁移到 3 个不同测试任务的能力。使用脚本化的预言智能体，我们在环境中生成—组 20 万个语言执行视频。我们报告每条语言指令被完成的底层准确率。该环境的详细信息见附录 A。




图 6: 高保真计划生成。UniPi 能够针对不同的语言提示生成高分辨率视频计划。

Model	Place Bowl	Pack Object	Pack Pair
State + Transformer BC	9.8 ± 2.6	21.7 ± 3.5	1.3 ± 0.9
Image + Transformer BC	5.3 ± 1.9	5.7 ± 2.1	7.8 ± 2.6
Image + TT	4.9 ± 2.1	19.8 ± 0.4	2.3 ± 1.6
Diffuser	14.8 ± 2.9	15.9 ± 2.7	10.5 ± 2.4
UniPi (Ours)	51.6 ± 3.6	75.5 ± 3.1	45.7 ± 3.7

表 3: 多任务环境中的任务完成准确率。当在一组不同的多任务环境中训练时，UniPi 能够很好地泛化到新环境。

基线。我们使用与第 4.1 节相同的基线方法。虽然我们的环境设置与 [28] 类似，但该方法与我们的方法不直接可比，因为 CLIPort 将动作抽象为现有的抓取和放置原语，而不是使用机器人的关节空间。CLIPort 还被设计用于解决一个显著更简单的问题，即仅推断抓取和放置物体的位姿（没有简单的方法来适应我们的设置）。

多任务泛化。

在表 3 中，我们展示了 UniPi 及基线方法在新任务上的结果。UniPi 方法能够泛化并综合不同语言任务的新视频和决策，并且可以生成包含拾取不同种类物体和不同颜色物体的视频。我们进一步在图 5 中展示了该方法的视频可视化结果。

4.3 真实世界迁移

最后，我们评估 UniPi 在真实世界场景中的泛化能力，以及利用互联网上广泛可用的视频构建复杂行为的能力。

实验设置。我们的训练数据包含一个互联网规模的预训练数据集和一个较小的真实世界机器人数据集。预训练数据集使用与 [19] 相同的数据，包括 1400 万个视频-文本对、6000 万个图像-文本对以及公开可用的 LAION-400M 图像-文本数据集。机器人数据集采用 Bridge 数据集 [29]，包含 7200 个视频-文本对，其中使用任务 ID 作为文本。我们将 7200 个视频-文本对划分为训练集（80%）和测试集（20%）。我们首先在预训练数据集上预训练 UniPi，然后在 Bridge 数据的训练集上进行微调。架构细节见附录 A。

视频综合。

我们特别关注在非机器人专用的互联网规模视频数据上进行预训练的效果。我们报告了在 Bridge 数据上训练的 UniPi（有预训练和无预训练）的 CLIP 分数、FID 和 FVD（跨帧平均，基于 32 个样本计算）。如表 4 所示，有预训练的 UniPi 在 FID 和 FVD 上显著优于无预训练的 UniPi，CLIP 分数也略有提升，这表明在非机器人数据上预训练有助于为机器人生成规划。有趣的是，无预训练的 UniPi 经常生成无法完成任务的规划（图 6），这一点在 CLIP 分数中并未得到充分体现。




图 8: 预训练实现组合泛化。互联网预训练使 UniPi 能够合成训练中未见过的任务的视频。相比之下，从头训练的模型会错误地生成不同任务的规划。

图 9: 对背景变化的鲁棒性。UniPi 学会了对底层背景变化的鲁棒性，例如黑色裁剪或添加经过照片处理的物体。

Model (24x40)	CLIP Score $\uparrow$	FID $\downarrow$	FVD $\downarrow$	Success $\uparrow$
No Pretrain	24.43 $\pm$ 0.04	17.75 $\pm$ 0.56	288.02 $\pm$ 10.45	72.6%
Pretrain	24.54 $\pm$ 0.03	14.54 $\pm$ 0.57	264.66 $\pm$ 13.64	77.1%

表 4: UniPi 在真实环境中的视频生成质量。利用互联网上已有的数据，在所有考虑的度量指标下均改善了视频计划的预测。

分数，这表明需要为控制特定任务开发更好的生成度量指标。为了解决缺乏此类度量指标的问题，我们开发了一种替代度量指标，用于从生成的视频中评估任务成功率。具体而言，我们训练了一个成功分类器，该分类器接收生成视频的最后一帧，并预测任务是否成功。我们发现，从头开始训练模型可达到 72.6% 的成功率，而从预训练模型进行微调可将性能提升至 77.1%。在这两种设置下，生成的视频均能成功完成大多数任务。

泛化。我们发现，互联网规模的预训练使 UniPi 能够泛化到训练期间未见过的测试集中的新任务指令和场景，而仅在任务特定机器人数据上训练的 UniPi 则无法泛化。具体而言，图 8 展示了 Bridge 数据集中不存在的新任务指令的结果。此外，UniPi 对背景变化（如黑色裁剪或添加经过修图的物体）相对鲁棒，如图 9 所示。

5 相关工作

学习世界的生成模型。近期，被训练用于生成环境奖励和动态的模型，可作为基于模型的强化学习和规划的“世界模型”，并已扩展到为视觉和语言开发的大规模架构 [9, 25, 30, 31]。这些工作将世界模型的学习与规划和策略学习分离开来，可以说在世界生成建模目标与学习最优策略之间存在不匹配。此外，学习世界模型要求训练数据采用严格的状态-动作-奖励格式，这与互联网上大量可用的数据集（如 YouTube 视频）不兼容。虽然像 VPT[32] 这样的方法可以通过学习逆动力学模型为未标记的视频添加标签来利用互联网规模的数据，但逆动力学模型本身并不支持基于模型的规划或强化学习，无法在模仿学习之外进一步改进所学策略。我们的文本条件视频策略可被视为同时学习世界模型并进行分层规划，并且能够利用并非专为顺序决策设计但广泛可用的数据集。

用于决策的扩散模型。扩散模型最近已被应用于不同的决策问题 [21, 27, 33, 34, 35, 36]。与本文工作最相似的是，[21] 训练了一个无条件扩散模型来生成由基于关节的状态和动作组成的轨迹，并使用单独训练的奖励模型来选择生成的计划。另一方面，[27] 训练了一个条件扩散模型，以根据期望的奖励、约束或智能体技能来引导行为综合。与这两项从零开始学习任务特定策略的工作不同，本文提出的文本条件视频生成作为通用策略的方法，可以利用互联网规模的知识来学习通用智能体，这些智能体可以部署到各种新颖的任务和环境。此外，[37]

应用了网络规模的文本条件图像扩散来生成目标图像，以作为策略的条件，而本文的工作则使用视频扩散来直接学习通用策略。

学习通用智能体。受视觉和语言领域大规模预训练成功的启发，大规模序列和图像模型最近已被应用于学习通用决策智能体 [6, 26, 38]。然而，这些通用智能体只能在具有相同状态和动作空间的环境（例如雅达利游戏）中运行 [26, 38]，或者需要精细的分词 [6]，这在不同环境具有不同状态和动作空间的情况下可能显得不自然。使用定制令牌进行控制的另一个缺点是无法直接利用预训练的视觉和语言模型中的知识。相比之下，本文的方法使用文本和图像作为策略学习的通用接口，从而可以保留预训练的视觉和语言模型中的知识。选择扩散模型而非自回归序列建模，也使得长期和分层规划成为可能。

学习文本条件策略。已有越来越多的研究利用文本指令来学习多任务与通用控制策略 [39, 40, 24, 41, 42, 43]。与本文以视频作为策略的框架不同，现有工作直接在特定机器人的动作空间中训练语言条件控制策略，使得跨形态、多环境的通用智能体学习仍是一个未解决的问题。本文首次提出将图像作为通用的状态与动作空间，以实现跨环境、跨任务乃至人机之间的广泛知识迁移。

6 结论

本文展示了利用文本条件视频生成表示策略的有效性，证明该方法能够实现有效的组合泛化、多任务学习以及真实世界迁移。这些积极结果指向了更广阔的方向：利用生成模型与互联网上的海量数据，作为构建通用决策系统的强大工具。

局限性。本文方法存在若干局限性。首先，底层视频扩散过程可能较慢，生成高度逼真的视频可能需要一分钟。这种缓慢可以通过将扩散过程蒸馏为更快的采样网络 [44] 来克服，在我们的初步实验中实现了 16 倍的加速。UniPi 还可以通过扩散模型中更快的采样器进一步加速。其次，本文考虑的环境通常是完全可观测的。在部分可观测环境中，视频扩散模型可能会产生与物理世界不符或不存在于物理世界中的物体或运动的幻觉。将视频模型与关于世界的语义知识相结合可能有助于解决这一问题，而 UniPi 与大语言模型的集成将是未来研究的一个有趣方向。

参考文献

- [1] Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, et al. Language models are few-shot learners. *Advances in neural information processing systems*, 33:1877–1901, 2020. 1
- [2] Aakanksha Chowdhery, Sharan Narang, Jacob Devlin, Maarten Bosma, Gaurav Mishra, Adam Roberts, Paul Barham, Hyung Won Chung, Charles Sutton, Sebastian Gehrmann, et al. Palm: Scaling language modeling with pathways. *arXiv preprint arXiv:2204.02311*, 2022. 1
- [3] Jordan Hoffmann, Sebastian Borgeaud, Arthur Mensch, Elena Buchatskaya, Trevor Cai, Eliza Rutherford, Diego de Las Casas, Lisa Anne Hendricks, Johannes Welbl, Aidan Clark, et al. Training compute-optimal large language models. *arXiv preprint arXiv:2203.15556*, 2022. 1
- [4] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, et al. Learning transferable visual models from natural language supervision. In *International Conference on Machine Learning*, pages 8748–8763. PMLR, 2021. 1
- [5] Jean-Baptiste Alayrac, Jeff Donahue, Pauline Luc, Antoine Miech, Iain Barr, Yana Hasson, Karel Lenc, Arthur Mensch, Katie Millican, Malcolm Reynolds, et al. Flamingo: A visual language model for few-shot learning. *NeurIPS*, 2022. 1

- [6] Scott Reed, Konrad Zolna, Emilio Parisotto, Sergio Gomez Colmenarejo, Alexander Novikov, Gabriel Barth-Maron, Mai Gimenez, Yury Sulsky, Jackie Kay, Jost Tobias Springenberg, et al. A generalist agent. *arXiv preprint arXiv:2205.06175*, 2022. 1, 6, 10, 14
- [7] Martin L Puterman. *Markov Decision Processes: Discrete Stochastic Dynamic Programming*. John Wiley & Sons, Inc., 1994. 3
- [8] Tuomas Haarnoja, Aurick Zhou, Pieter Abbeel, and Sergey Levine. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In *International conference on machine learning*, pages 1861–1870. PMLR, 2018. 3
- [9] Danijar Hafner, Timothy Lillicrap, Mohammad Norouzi, and Jimmy Ba. Mastering atari with discrete world models. *arXiv preprint arXiv:2010.02193*, 2020. 3, 9
- [10] Tianjun Zhang, Tongzheng Ren, Mengjiao Yang, Joseph Gonzalez, Dale Schuurmans, and Bo Dai. Making linear mdps practical via contrastive representation learning. In *International Conference on Machine Learning*, pages 26447–26466. PMLR, 2022. 3
- [11] Diederik P. Kingma and Max Welling. Auto-encoding variational bayes. *CoRR*, abs/1312.6114, 2013. 4
- [12] Yilun Du and Igor Mordatch. Implicit generation and generalization in energy-based models. *arXiv preprint arXiv:1903.08689*, 2019. 4
- [13] Bo Dai, Zhen Liu, Hanjun Dai, Niao He, Arthur Gretton, Le Song, and Dale Schuurmans. Exponential family estimation via adversarial dynamics embedding. *Advances in Neural Information Processing Systems*, 32, 2019. 4
- [14] Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. Generative adversarial nets. In *Advances in Neural Information Processing Systems*. 2014. 4
- [15] Jascha Sohl-Dickstein, Eric Weiss, Niru Maheswaranathan, and Surya Ganguli. Deep unsupervised learning using nonequilibrium thermodynamics. In *International Conference on Machine Learning*, 2015. 4
- [16] Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. In *Advances in Neural Information Processing Systems*, 2020. 4
- [17] Jiaming Song, Chenlin Meng, and Stefano Ermon. Denoising diffusion implicit models. *arXiv preprint arXiv:2010.02502*, 2020. 4
- [18] Jonathan Ho and Tim Salimans. Classifier-free diffusion guidance. *arXiv preprint arXiv:2207.12598*, 2022. 4
- [19] Jonathan Ho, William Chan, Chitwan Saharia, Jay Whang, Ruiqi Gao, Alexey Gritsenko, Diederik P Kingma, Ben Poole, Mohammad Norouzi, David J Fleet, et al. Imagen video: High definition video generation with diffusion models. *arXiv preprint arXiv:2210.02303*, 2022. 4, 5, 8, 14
- [20] Ruben Villegas, Mohammad Babaeizadeh, Pieter-Jan Kindermans, Hernan Moraldo, Han Zhang, Mohammad Taghi Saffar, Santiago Castro, Julius Kunze, and Dumitru Erhan. Phenaki: Variable length video generation from open domain textual description. *arXiv preprint arXiv:2210.02399*, 2022. 4
- [21] Michael Janner, Yilun Du, Joshua Tenenbaum, and Sergey Levine. Planning with diffusion for flexible behavior synthesis. In *International Conference on Machine Learning*, 2022. 4, 5, 6, 9, 14
- [22] Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li, Peter J Liu, et al. Exploring the limits of transfer learning with a unified text-to-text transformer. *J. Mach. Learn. Res.*, 21(140):1–67, 2020. 5, 14
- [23] Jiayuan Mao, Tomas Lozano-Perez, Joshua B. Tenenbaum, and Leslie Pack Kaelbling. PDSketch: Integrated Domain Programming, Learning, and Planning. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2022. 5
- [24] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Joseph Dabis, Chelsea Finn, Keerthana Gopalakrishnan, Karol Hausman, Alex Herzog, Jasmine Hsu, et al. Rt-1: Robotics transformer for real-world control at scale. *arXiv preprint arXiv:2212.06817*, 2022. 6, 10

- [25] Michael Janner, Qiyang Li, and Sergey Levine. Offline reinforcement learning as one big sequence modeling problem. *Advances in neural information processing systems*, 34:1273–1286, 2021. 6, 9, 14
- [26] Kuang-Huei Lee, Ofir Nachum, Mengjiao Yang, Lisa Lee, Daniel Freeman, Winnie Xu, Sergio Guadarrama, Ian Fischer, Eric Jang, Henryk Michalewski, et al. Multi-game decision transformers. *arXiv preprint arXiv:2205.15241*, 2022. 6, 10, 14
- [27] Anurag Ajay, Yilun Du, Abhi Gupta, Joshua Tenenbaum, Tommi Jaakkola, and Pulkit Agrawal. Is conditional generative modeling all you need for decision-making? *arXiv preprint arXiv:2211.15657*, 2022. 6, 9
- [28] Mohit Shridhar, Lucas Manuelli, and Dieter Fox. Cliport: What and where pathways for robotic manipulation. In *Conference on Robot Learning*, pages 894–906. PMLR, 2022. 7, 8
- [29] Frederik Ebert, Yanlai Yang, Karl Schmeckpeper, Bernadette Bucher, Georgios Georgakis, Kostas Daniilidis, Chelsea Finn, and Sergey Levine. Bridge data: Boosting generalization of robotic skills with cross-domain datasets. *arXiv preprint arXiv:2109.13396*, 2021. 8
- [30] Michael R Zhang, Thomas Paine, Ofir Nachum, Cosmin Paduraru, George Tucker, ziyu wang, and Mohammad Norouzi. Autoregressive dynamics models for offline policy evaluation and optimization. In *International Conference on Learning Representations*, 2021. 9
- [31] Vincent Micheli, Eloi Alonso, and François Fleuret. Transformers are sample efficient world models. *arXiv preprint arXiv:2209.00588*, 2022. 9
- [32] Bowen Baker, Ilge Akkaya, Peter Zhokhov, Joost Huizinga, Jie Tang, Adrien Ecoffet, Brandon Houghton, Raul Sampedro, and Jeff Clune. Video pretraining (vpt): Learning to act by watching unlabeled online videos. *arXiv preprint arXiv:2206.11795*, 2022. 9
- [33] Zhendong Wang, Jonathan J Hunt, and Mingyuan Zhou. Diffusion policies as an expressive policy class for offline reinforcement learning. *arXiv preprint arXiv:2208.06193*, 2022. 9
- [34] Edwin Zhang, Yujie Lu, William Wang, and Amy Zhang. Lad: Language augmented diffusion for reinforcement learning. *arXiv preprint arXiv:2210.15629*, 2022. 9
- [35] Julen Urain, Niklas Funk, Georgia Chalvatzaki, and Jan Peters. Se (3)-diffusionfields: Learning cost functions for joint grasp and motion optimization through diffusion. *arXiv preprint arXiv:2209.03855*, 2022. 9
- [36] Ziyuan Zhong, Davis Rempe, Danfei Xu, Yuxiao Chen, Sushant Veer, Tong Che, Baishakhi Ray, and Marco Pavone. Guided conditional diffusion for controllable traffic simulation. *arXiv preprint arXiv:2210.17366*, 2022. 9
- [37] Ivan Kapelyukh, Vitalis Vosylius, and Edward Johns. Dall-e-bot: Introducing web-scale diffusion models to robotics. *arXiv preprint arXiv:2210.02438*, 2022. 9
- [38] Aviral Kumar, Rishabh Agarwal, Xinyang Geng, George Tucker, and Sergey Levine. Offline q-learning on diverse multi-task data both scales and generalizes. *arXiv preprint arXiv:2211.15144*, 2022. 10
- [39] Wenlong Huang, Fei Xia, Ted Xiao, Harris Chan, Jacky Liang, Pete Florence, Andy Zeng, Jonathan Tompson, Igor Mordatch, Yevgen Chebotar, et al. Inner monologue: Embodied reasoning through planning with language models. *arXiv preprint arXiv:2207.05608*, 2022. 10
- [40] Michael Ahn, Anthony Brohan, Noah Brown, Yevgen Chebotar, Omar Cortes, Byron David, Chelsea Finn, Keerthana Gopalakrishnan, Karol Hausman, Alex Herzog, et al. Do as i can, not as i say: Grounding language in robotic affordances. *arXiv preprint arXiv:2204.01691*, 2022. 10
- [41] Corey Lynch and Pierre Sermanet. Language conditioned imitation learning over unstructured data. *arXiv preprint arXiv:2005.07648*, 2020. 10
- [42] Parsa Mahmoudieh, Deepak Pathak, and Trevor Darrell. Zero-shot reward specification via grounded natural language. In *ICLR 2022 Workshop on Generalizable Policy Learning in Physical World*, 2022. 10
- [43] Hao Liu, Lisa Lee, Kimin Lee, and Pieter Abbeel. Instruction-following agents with jointly pre-trained vision-language models. *arXiv preprint arXiv:2210.13431*, 2022. 10
- [44] Tim Salimans and Jonathan Ho. Progressive distillation for fast sampling of diffusion models. *arXiv preprint arXiv:2202.00512*, 2022. 10

- [45] Jonathan Ho, Tim Salimans, Alexey Gritsenko, William Chan, Mohammad Norouzi, and David J Fleet. Video diffusion models. *arXiv preprint arXiv:2204.03458*, 2022. 14
- [46] Chitwan Saharia, William Chan, Saurabh Saxena, Lala Li, Jay Whang, Emily Denton, Seyed Kamyar Seyed Ghasemipour, Burcu Karagol Ayan, S Sara Mahdavi, Rapha Gontijo Lopes, et al. Photorealistic text-to-image diffusion models with deep language understanding. *arXiv preprint arXiv:2205.11487*, 2022. 14

A 架构、训练与评估细节

A.1 视频扩散训练细节

我们采用与 [45] 相同的基础架构和训练设置，该架构使用视频 U-Net (Video U-Net)，包含 3 个残差块，基础通道数为 512，通道倍增系数为 [1, 2, 4]，注意力分辨率为 [6, 12, 24]，注意力头维度为 64，条件嵌入维度为 1024。我们使用噪声调度对数信噪比，范围为 [-20, 20]。我们对视频 U-Net 进行修改，以支持训练期间的首帧条件化。具体而言，我们在所有未来帧索引处复制要条件化的首帧，并通过将首帧按通道维度与噪声数据拼接，使时间超分辨率模型以复制的首帧为条件，类似于 [46]。我们使用时间卷积而非时间注意力来跨时间混合帧，以保持跨时间的局部时序一致性，这一点在 [19] 中也有提及。我们训练每个视频扩散模型 200 万步，批大小为 2048，学习率为 $1e-4$ ，线性预热步数为 1 万。我们使用 256 个 TPU-v4 芯片训练首帧条件生成模型和时间超分辨率模型。

我们使用 T5-XXL[22] 处理输入提示，该模型包含 46 亿参数。针对模拟机器人操作中的组合泛化和多任务泛化实验，我们训练了一个首帧条件视频扩散模型，输入为 $10 \times 48 \times 64$ 视频（每 8 帧跳过一个帧），参数量为 17 亿；以及一个时间超分辨率模型，输入为 $20 \times 48 \times 64$ （每 4 帧跳过一个帧），参数量为 17 亿。视频分辨率的选择确保被操作的物体（例如被移动的积木）在视频中清晰可见。对于真实世界视频结果，我们在 [19] 所用数据上预训练的 $16 \times 40 \times 24$ （17 亿参数）、 $32 \times 40 \times 24$ （17 亿参数）、 $32 \times 80 \times 48$ （14 亿参数）和 $32 \times 320 \times 192$ （12 亿参数）时间超分辨率模型上进行微调。

A.2 逆动力学训练细节

UniPi 的逆动力学模型通过均方误差直接从图像观测预测模拟机器人手臂的 7 维控制量。逆动力学模型包含一个 3×3 卷积层、3 层带残差连接的 3×3 卷积、一个跨所有像素位置的平均池化层，以及一个通道数为 (128, 7) 的多层感知机层，用于预测最终控制量。逆动力学模型使用 Adam 优化器训练，梯度范数裁剪为 1，学习率为 $1e-4$ ，总共训练 200 万步，其中前 1 万步应用线性预热。

A.3 基线训练细节

下面描述各种基线的架构细节。各基线的训练细节（如学习率、预热、梯度裁剪）遵循上文详述的逆动力学模型。

变换器行为克隆 [6, 26]。采用与 [26] 中 10M 模型相同的变换器架构，包含 4 个注意力层，每层 8 个头，隐藏维度为 512。应用 4 层带残差连接的 3×3 卷积提取图像特征，与 T5 文本嵌入一起作为变换器的输入。还尝试了类似 [26] 的视觉变换器风格图像块线性化，但性能相近。使用上下文长度为 4，并每 4 帧跳帧，与 UniPi 的逆动力学一致。尝试将变换器上下文长度增加到 8，但未提升性能。

变换器轨迹变换 [25]。采用与上述变换器行为克隆基线相似的变换器架构。与变换器行为克隆预测序列中下一个控制不同，在输出层预测接下来的 8 个控制（与其他基线一样每 4 个控制跳一个）。也尝试了自回归预测接下来的 8 个控制，但发现误差在没有额外离散化的情况下会迅速累积。

基于状态的扩散 [21]。对于基于状态的扩散基线，采用与 UniPi 首帧条件视频扩散相似的架构，其中不是扩散并生成未来

图像帧，而是在不同像素位置复制未来控制，并应用与 UniPi 相同的 U-Net 结构来学习基于状态的扩散模型。

A.4 组合规划任务细节

在组合规划任务中，我们为积木、彩色碗和最终放置盒采样随机的六自由度位姿。积木初始为未着色（白色），必须放入碗中才能获得颜色。随后，机器人需要操作并移动已着色的积木，使其在放置盒中达到期望的几何关系。智能体的底层动作空间由机器人的六个关节值加上一个离散接触动作组成。当接触动作激活时，桌面上最近的积木被吸附到机器人夹爪上（对于预测连续动作的方法，我们将动作预测 > 0.5 阈值化以对应接触）。给定不同模型的个体动作预测，我们通过 Pybullet 中运行关节控制器来模拟环境的下一状态，尝试到达预测的关节状态（由于某些动作在物理上不可行，超时设置为 2 秒）。由于视频数据集中只有一部分包含动作标注，我们在 2 万个生成视频的动作标注上训练了逆动力学模型。

A.5 CLIPort 多环境任务细节

在 CLIPort 环境中，我们使用与组合规划任务相同的动作空间，并利用 Pybullet 内置的关节控制器以类似方式执行动作。作为训练数据，我们使用了一个脚本化智能体，在以下任务上运行：将块放入碗中未见颜色、打包未见谷歌物体序列、组装套件序列未见颜色、堆叠块金字塔序列已见颜色、汉诺塔序列已见颜色、组装套件序列已见颜色、汉诺塔序列未见颜色、堆叠块金字塔序列未见颜色、打包已见谷歌物体序列、打包盒子对已见颜色、打包已见谷歌物体组。作为测试数据，我们使用了以下环境：将块放入碗中已见颜色、打包未见谷歌物体组、打包盒子对未见颜色。我们在 20 万个生成视频的动作标注上训练了逆动力学模型。

B 附加结果

B.1 组合泛化的附加结果




图 10：组合视频生成。UniPi 在测试时针对未见语言目标生成的视频的附加结果。

B.2 多环境迁移的附加结果




图 11：多任务视频生成。UniPi 在多任务设置下针对不同新任务生成的视频计划的附加结果。

B.3 真实世界迁移的额外结果




图 12: 高保真计划生成。UniPi 在不同语言提示下的高分辨率视频计划的额外结果。