

学习以任务为中心潜在动作在任何环境中行动

Qingwen Bu^{1,2}, Yanting Yang², Jisong Cai², Shenyuan Gao², Guanghui Ren³,
Maoqing Yao³, Ping Luo^{1,2} and Hongyang Li^{1,2}

¹ The University of Hong Kong ² OpenDriveLab ³ AgiBot

Code: <https://github.com/OpenDriveLab/UniVLA>




图 1: 我们提出统一视觉-语言-动作框架 **UniVLA**, 支持跨不同环境的策略学习。通过无监督方式推导以任务为中心的潜在动作, **UniVLA** 能够利用任意形态和视角的数据, 无需动作标签。在大规模视频预训练后, **UniVLA** 发展出跨形态的通用策略, 只需以最小成本学习动作解码即可部署到各种机器人上。与 OpenVLA [39] 相比, **UniVLA** 在多个操作和导航任务上表现出全面改进。

摘要——通用机器人应在各种环境中有效执行任务。然而, 现有方法大多严重依赖扩展动作标注数据来提升能力, 因此通常局限于单一物理规格, 难以在不同形态和环境间学习可迁移知识。为应对这些局限性, 我们提出 **UniVLA**, 一种学习跨形态视觉-语言-动作策略的新框架。其关键创新在于利用潜在动作模型从视频中推导以任务为中心的动作表示, 从而能够利用涵盖广泛形态和视角的大量数据。为减轻任务无关动态的影响, 我们融入语言指令, 并在 DINO 特征空间中建立潜在动作模型。从互联网规模视频中学习到的通用策略可通过高效的潜在动作解码部署到各种机器人上。我们在多个操作和导航基准以及真实机器人部署中取得了最先进的结果。UniVLA 以不到 1/20 的预训练计算量和 1/10 的下游数据量, 超越了 OpenVLA 的性能。随着异构数据 (甚至包括人类视频) 被纳入训练流程, 性能持续提升。这些结果凸显了 UniVLA 在促进可扩展且高效的机器人策略学习方面的潜力。

近期 [10, 28, 39]。然而, 这些方法通常依赖真实动作标签进行监督, 这限制了它们在利用来自多样化环境的互联网规模数据时的可扩展性。此外, 不同具身形态 (例如 Franka、WidowX, 甚至人手) 和任务 (例如操作与导航) 之间动作空间与观测空间的异质性, 对有效的知识迁移构成了显著挑战。这引出一个关键问题: 我们能否学习一种统一的动作表示, 使通用策略能够有效规划, 从而释放互联网规模视频的潜力, 并促进跨具身形态与跨环境的知识迁移?

为应对这些挑战, 本文提出 **UniVLA**, 一种通用策略学习框架, 旨在实现跨多种具身形态与环境的高可扩展且高效的规划。正如大语言模型 (Large Language Models, LLMs) 学习跨语言共享知识 [22, 18], 我们旨在构建一个统一的动作空间, 以促进跨视频数据的知识迁移, 包括各种机器人演示和以自我为中心的人类视频。我们的通用策略方案包含三个关键阶段: 1) 以任务为中心的潜在动作学习, 在此阶段, 我们以无监督方式从大规模跨具身视频中提取与任务相关的动作表示。具体通过使用 VQ-VAE[76] 对配对帧的逆动力学中的潜在动作进行离散化来实现。2) 下一步

一、引言

在大规模机器人数据集 [78, 63, 38, 1] 兴起的推动下, 基于视觉-语言-动作模型的机器人策略取得了令人鼓舞的进展

潜在动作预测。在此阶段，我们使用离散化的潜在动作标记训练一个自回归视觉语言模型，赋予其与具身形态无关的规划能力。

3) 潜在解码 其中我们将潜在计划解码为物理行为，并对预训练的通用策略进行专门化，以便高效部署到未见任务中。尽管近期研究 [87, 16] 探讨了从网络规模视频中学习潜在动作的可行性，但它们存在一个关键局限：其基于朴素重建的目标往往捕捉与任务无关的动态，例如非自车主体的运动或不可预测的相机偏移。这些噪声表示通过引入与任务无关的干扰，阻碍了策略预训练。为解决这一问题，我们利用预训练的 DINOv2 特征 [62] 从像素中提取块级表示，提供空间和以对象为中心的先验，从而更好地捕捉任务相关信息。通过使用现成的语言指令作为条件，我们进一步将运动解耦为两种互补的动作表示，其中一种显式表示以任务为中心的动作。UniVLA 在多个操作基准和导航任务上达到了最先进的性能，显著优于 OpenVLA [39]，而预训练成本（以 GPU 小时计）仅为其 1/20。

这种效率源于其以任务为中心的潜在动作空间，该空间将任务相关动态与无关的视觉变化解耦。我们的动作表示不仅降低了计算开销，还实现了高效扩展——随着数据集规模的增长，UniVLA 的性能不断提升，有效利用跨具身、跨视角的机器人数据集，甚至未标注的人类视频来扩展其预训练语料库并提取可迁移知识。值得注意的是，当仅在 Bridge-V2 数据集 [78] 上预训练时，UniVLA 超越了在更大的 Open X-Embodiment [63] 数据集上训练的 OpenVLA 和 LAPA，凸显了其从有限数据中蒸馏可迁移知识的能力。此外，我们采用仅含 10.8M 参数的轻量级解码器将潜在动作转换为可执行轨迹，显著减少了对大量微调的需求。该设计利用了以任务为中心的潜在动作空间的紧凑性和信息丰富性，使 UniVLA 能够以最少的下游数据高效适应多样任务和具身。我们的综合评估涵盖操作、导航和真实世界部署，强调了该框架的效率、可扩展性和泛化性，将其定位为通往下一代通用机器人策略的有前景的路径。

总之，我们的主要贡献有三方面：

- 我们提出 UniVLA，一种通过在统一的、与具身无关的动作空间中进行规划来实现通用策略的方法，通过从网络规模视频中学习实现可扩展且高效的决策。
- 我们引入一种新颖的方法，从跨具身视频中提取任务相关的潜在动作，将任务中心动态与无关视觉变化解耦。定性和定量实验

均凸显了其相对于现有工作的优点和优势。• UniVLA 在多个基准和真实机器人测试中取得了最先进的性能，在 LIBERO [48] 基准上成功率比 OpenVLA 提高了 18.5%，在导航任务 [4] 中提高了 29.6%，在真实世界部署中提高了 36.7%。

II. 相关工作

A. 视觉-语言-动作模型

在预训练视觉基础模型、大语言模型（Large Language Model, LLM）和视觉语言模型（Vision-Language Model, VLM）成功的基础上，视觉语言动作模型（Vision-Language-Action Model, VLA）被引入以处理多模态输入——视觉观察和语言指令——并生成机器人动作以完成具身任务。RT-1 [11] 和 Octo [28] 采用基于变换器（Transformer）的策略，整合多样化数据，包括跨不同任务、物体、环境和具身形态的机器人轨迹。相比之下，一些先前工作 [10, 39, 46] 利用预训练的视觉语言模型，通过挖掘大规模视觉语言数据集中的世界知识来生成机器人动作。例如，RT-2 [10] 和 OpenVLA [39] 将动作视为语言模型词汇表中的标记，而 RoboFlamingo [46] 引入额外的策略头进行动作预测。在这些通用策略的基础上，RoboDual [13] 提出了一种协同双系统，结合了通用策略和专用策略的优势。其他工作结合目标图像 [9] 或视频 [24, 82, 14] 预测任务，以语言指令为条件生成有效且可执行的计划，这些视觉线索随后指导策略进行动作生成。然而，这些方法严重依赖带有真实动作标签的交互数据，这显著限制了视觉语言动作模型的可扩展性。相比之下，本文的方法通过从视觉变化中学习统一的潜在动作表示，释放了互联网规模、无动作视频的潜力，且不依赖动作标签。

B. 跨具身学习

训练通用机器人策略具有挑战性，因为不同机器人系统在相机视角、本体感觉输入、关节配置、动作空间和控制频率方面存在多样性。早期方法 [86] 专注于在导航和操作之间手动对齐动作空间，但仅限于操作中的腕部相机。近期基于变换器的方法 [28, 23] 通过适应可变观测和动作来应对这些挑战，其中跨形态变换器（CrossFormer）[23] 在四个不同的动作空间上进行联合训练，不对观测空间施加约束，也不需要显式的动作空间对齐。流表示捕捉图像或点云中查询点的未来轨迹，已被广泛探索用于跨形态学习 [81, 88, 26, 83]。任意轨迹模型（ATM）[81] 从人类演示中学习流生成，而图像到流到动作（Im2Flow2Act）[83] 在没有域内数据的情况下从人类视频中预测物体流。同时，以物体为中心的表示 [32, 8] 提供了另一种方法，其中点云物体轨迹预测器（SPOT）[32] 在特殊欧氏群（SE(3)）中预测物体轨迹，以将形态动作与感官输入解耦。

现有方法需要大量多样化的数据集来覆盖所有可能的状态转移模式，并且需要显式标注，导致数据利用效率低下。本文方法通过使用离散码本以无监督方式编码潜在动作而与众不同。本文方法通过向量量化有效滤除视觉噪声并实现高效信息压缩，从而提升训练效率并减少对数据多样性的依赖。

C. 潜在动作学习

多项先前工作聚焦于在原始动作轨迹上学习变分自编码器 [64, 76]，以构建新的动作空间，强调紧凑的潜表示，从而促进行为生成与任务适应，如 VQ-BeT[44] 和 Quest[59] 所示。这些方法也被用于强化学习以加速收敛 [3]。近期工作 [79, 74] 探索将向量量化作为动作空间适配器，以更好地将动作集成到大语言模型中。然而，这些方法的一个关键局限性在于依赖真实动作标签，这限制了其可扩展性。为了利用更广泛的视频数据，Genie[12] 通过因果潜动作模型提取潜动作，并以下一帧预测为条件。类似地，LAPO[70] 和 DynaMo[20] 直接从视觉数据中学习潜动作，绕过了在域内操作任务上使用显式动作标签的方法。LAPA[87] 和 IGOR[16] 引入了无监督预训练方法，以教导视觉-语言-动作模型离散潜动作，旨在从人类视频中迁移知识。然而，这些方法编码了原始像素中的所有视觉变化，捕获了与任务无关的动态，如相机抖动、其他智能体的运动或新物体的出现，最终降低了策略性能。我们提出了一种新颖的训练框架，将任务中心动态与无关视觉变化解耦，构建更有效的潜动作空间，以实现稳健的策略规划。

III. 方法论

我们开发了三个步骤来实现 UniVLA：（第 III-A 节）利用基¹于语言的目标规范，我们以无监督方式从大规模视频数据集中提取逆动态，生成一组离散的任务中心潜动作，这些动作可泛化到不同的具身形态和领域；**2**）（第 III-B 节）在此基础上，我们训练一个基于自回归变换器的视觉-语言-动作模型，该模型以视觉观察和任务指令为输入，在统一的潜空间中预测潜动作标记；

3）（第 III-C 节）为了促进对各种机器人控制系统的高效适应，我们引入了专门的策略头，将潜动作解码为可执行的控制信号。

A. 任务中心潜动作学习

第一步通过生成伪动作标签（即潜动作标记）奠定了我们框架的基础，这些标签作为后续阶段训练通用策略的基础。

潜动作量化。 图 2 展示了我们潜在动作模型的两阶段训练流程和整体架构。我们从一对连续视频帧开始，记为 $\{o_t, o_{t+k}\}$ ，帧间隔为 k 。为确保不同数据集上时间间隔统一约为 1 秒，帧间隔根据每个数据集特定的录制频率进行校准。为了从视频中推导潜在动作，我们的潜在动作模型围绕基于逆动力学模型（IDM）的编码器 $\mathcal{I}(a_t|o_t, o_{t+k})$ 和基于前向动力学模型（FDM）的解码器 $\mathcal{F}(o_{t+k}|o_t, a_t)$ 构建。编码器根据连续观测推断潜在动作，解码器经过训练以根据指定的潜在动作预测未来观测。我们将编码器实现为具有因果时间掩码的时空变换器 [84]，遵循 Villegas 等人 [77] 的方法。一组具有预定义维度 d 的可学习动作令牌 $a_q \in \mathbb{R}^{N \times d}$ ，被顺序连接到视频特征上以提取动态信息。为了进一步压缩信息并使其与自回归变换器策略的学习目标 [66] 对齐，我们对动作令牌应用潜在量化。量化后的动作令牌 $a_z \in \mathcal{R}^{N \times d}$ 使用 VQ-VAE[76] 目标进行优化，码本大小为 $|C|$ 。解码器实现为空间变换器，仅利用量化后的动作令牌来预测未来帧。我们不向解码器提供历史帧，以防止模型过度依赖上下文信息或仅仅记忆数据集。虽然近期工作 [12, 27, 87] 使用原始像素进行预测，但我们观察到像素空间预测迫使模型关注嘈杂的、与任务无关的细节（例如纹理、光照）[30]。这个问题在网页规模众包视频数据集 [29] 中被放大，因为不受控制的拍摄条件引入了更多变异性。受联合嵌入预测架构（JEPA）[5, 6, 96] 的启发，我们提出使用 DINOv2[62] 空间块特征作为语义丰富的表示。它们以对象为中心和空间感知的特性使其不仅适合作为输入，也适合作为潜在动作模型的预测目标。我们的自监督目标最小化嵌入重建误差： $\|\hat{O}_{t+k} - O_{t+k}\|^2$ 。我们使用 $\{O_t, O_{t+k}\}$ 表示配对视频帧 $\{o_t, o_{t+k}\}$ 的 DINOv2 特征。因此，紧凑的潜在动作必须编码观测之间的变换以最小化预测误差。

潜在动作解耦。 如前所述，在网页规模的视频中，机器人的动作往往与无关的环境变化纠缠在一起。为了减轻任务无关动态的不利影响，我们在潜在动作模型的第一训练阶段引入了现成的语言指令（图 2 左）。语言输入使用预训练的 T5 文本编码器 [67] 进行编码，并作为编码器和解码器上下文中的条件信号。该过程可形式化描述为：[编码：解码：

$$\hat{a}_{Tl} = \mathcal{I}([O_t; O_{t+k}; a_{Tl}; \ell]), \quad \tilde{a}_{Tl} = \mathbf{VQ}(\hat{a}_{Tl}),$$




图 2：以任务为中心的潜在动作学习。我们提出一个两阶段训练框架，旨在将任务中心的视觉动态和变化与无关因素解耦。在第一阶段，从预训练的 T5 文本编码器 [67] 得到的任务指令嵌入被用作编码器和解码器的输入。这些嵌入提供与任务相关的语义信息，以提高预测准确率。在第二阶段，引入一组新的潜在动作，专门用于替代语言的作用，并从视频帧的 DINOv2 编码特征中捕获任务中心的动态。

其中 $[\cdot]$ 表示序列级联， $\mathbf{VQ}$ 表示向量量化动作表示的码本，

ℓ 是来自 T5 文本编码器的指令嵌入。将任务指令发送给解码器提供了关于底层动作的高层语义指导。因此，量化后的潜在动作被优化为仅编码环境变化和视觉细节 [89]，由于码本容量受限 [2]，省略了更高层的任务相关信息。该阶段建立了一组封装任务无关信息的潜在动作，例如新物体的出现、外部代理的移动或相机引起的运动伪影。这些动态虽然对于将模型锚定在视觉环境中至关重要，但与任务的具体目标正交。随后，我们将第一阶段训练得到的任务无关码本和潜在动作模型参数重新用于下一阶段（如图 2 右所示），该阶段的目标是学习一组新的以任务为中心的潜在动作 $\hat{a}_{TC}$ ，策略将在其上训练。在此阶段，模型通过以下方式提取动作信息：

$$\text{Encode: } \{\hat{a}_{TI}, \hat{a}_{TC}\} = \mathcal{I}([O_t; O_{t+k}; a_{TI}; a_{TC}]),$$

$$\hat{a}_{TI} = \mathbf{VQ}(\hat{a}_{TI}), \hat{a}_{TC} = \mathbf{VQ}_{TC}(\hat{a}_{TC}),$$

解码： $\hat{O}_{t+k} = \mathcal{F}([O_t; \hat{a}_{TI}; \hat{a}_{TC}])$ ，其中 $\mathbf{VQ}_{TC}$ 表示新初始化的码本，用于学习以任务为中心的动态。在获得与任务无关的表征后，我们冻结相应的码本，使模型能够专注于细化和专门化新的潜在动作集。这种专门化有助于精确建模与任务相关的动态，例如物体操作或目标导向的运动轨迹。潜在动作表征的显式解耦增强了我们的通才策略在不同环境和任务中的泛化能力。与朴素的潜在动作学习方法（例如，LAPA [87]）相比，仅以任务为中心的表征进行训练可实现更快的收敛，同时获得稳健的性能，这表明这些潜在动作

对后续的策略学习更具信息量。

B. 通才策略的预训练

利用前一步训练好的潜在动作模型，我们继续为任意视频帧 O_t 标注潜在动作 a_z ，给定 O_{t+k} 。然后，我们使用这些标签来开发通才策略。为了与 Kim 等人 [39] 保持一致，我们的通才策略建立在 Prismatic-7B[37] 视觉语言模型（VLM）之上。该架构集成了源自 SigLip[90] 和 DINOv2[62] 的融合视觉编码器、用于将视觉嵌入与语言模态对齐的投影层，以及 LLaMA-2 大语言模型（LLM）[75]。与先前基于 LLM 的通才策略（即 RT-2[10] 和 OpenVLA[39]）不同，这些策略通过将 LLaMA 分词器词汇表中不常用的词映射到 $[-1, 1]$ 内的均匀分布动作区间来直接在低级动作空间中规划，我们通过 $|C|$ 个特殊标记扩展词汇表，具体为 $\{\text{ACT}_1, \text{ACT}_2, \text{ACT}_3, \dots, \text{ACT}_C\}$ 。潜在动作根据其在动作码本中的索引被投影到这个词汇表中。这种方法保留了 VLM 的原始模型架构和训练目标，充分利用其预训练知识迁移到机器人控制任务中。具体来说，我们的策略模型 π_ϕ 接收观测 O_t 、任务指令 l 和潜在动作标记的前缀 $a_{z,<i}$ ，并通过最小化下一个潜在动作的负对数概率之和进行优化：

$$\mathcal{L} = \mathbb{E}_{O_t, l, a_{z,<i}} \left[- \sum_{i=1}^N \log \pi_\phi(\hat{a}_{z,i} = a_{z,i} \mid O_t, l, a_{z,<i}) \right],$$

其中 N 表示动作标记的总长度。我们在所有实验中设置 $N = 4$ 。此外，经验证据表明，压缩的动作空间（例如，当 $|C| = 16$ 时，从 OpenVLA[39] 中的 256^7 减少到 16^4 ）显著加速了模型收敛。我们的方法仅用 960 个 A100 小时的预训练就取得了有竞争力的结果，与 OpenVLA 预训练所需的 21,500 个 A100 小时相比大幅减少。




图 3：通用策略的架构。我们的策略架构基于 Prismatic-7B 视觉语言模型（VLM）[37]，该模型处理投影的视觉嵌入和标记化的任务指令作为输入，以自回归方式预测潜在动作标记。为了适应特定的机器人系统，采用了专门的动作解码器头。这些解码器利用视觉信息从潜在动作中提取上下文特定特征，随后将其转换为具有异构动作空间的机器人系统的可执行控制信号。

通过在统一的潜在动作空间中训练我们的策略，模型利用了来自跨域数据集的可迁移知识。与 Yang 等人 [86] 需要手动对齐动作空间（通过视觉上相似的自我中心运动，如操作任务中的腕部相机运动和自我中心导航）不同，我们的方法消除了这一要求。因此，UniVLA 扩大了可用数据集的范围并提升了整体性能，证明了利用以任务为中心的潜在动作表示进行可扩展策略学习的有效性。

C. 部署后训练

潜在动作解码。在下游适应过程中，预训练的通用策略通过在下游适应期间预测下一个潜在动作来保持其与具体形态无关的特性。为了弥合潜在动作与可执行行为之间的差距，采用了额外的动作解码器（如图 3 所示）。具体来说，视觉嵌入序列首先通过多头注意力池化 [43] 聚合成单个标记，然后该标记作为查询从潜在动作嵌入中提取信息。此过程公式化为：

$$\begin{cases} \text{视觉嵌入:} & E'_v = \mathcal{A}(Q = q_v, K = V = E_v), \\ \text{Action Embed:} & E'_a = \mathcal{A}(Q = q_a + E'_v, K = V = E_a), \end{cases}$$

其中 $\mathcal{A}$ 表示多头注意力， $\{E_v, E_a\}$ 是来自视觉语言模型最后一层的视觉与潜在动作嵌入， $\{q_v, q_a\}$ 是随机初始化的查询，分别用于提取视觉和动作信息。所得动作嵌入 E'_a 随后被线性投影到目标机器人系统的期望动作空间中。鉴于潜在动作旨在表示内部发生的动作

大约一秒的间隔（见第 III-A 节），它们可以自然地解码为动作块 [93]。块大小可以针对具体实施例轻松定制，以实现更平滑、更精确的控制。在实践中，我们采用使用 LoRA [33] 的参数高效微调来实现高效适应。加上仅包含 12.6M 参数的动作头，可训练参数总数约为 123M。整个模型进行端到端训练，同时优化下一个潜在动作预测损失和真实低层动作与预测低层动作之间的 L1 损失。

从历史输出中学习。历史观测已被证明在增强机器人控制的序列决策过程中发挥着关键作用 [60, 42, 45]。然而，直接向大型视觉-语言-动作模型提供多个历史观测会引入显著的推理延迟，并导致视觉标记中的冗余信息 [94, 45]。受大语言模型中成熟的思维链推理范式 [80] 的启发，该范式通过生成中间推理步骤来解决复杂任务，本文提出利用历史潜在动作输出来促进机器人控制中的决策。类似于大语言模型逐步解决问题的方式，我们在推理过程中的每个时间步将过去的动作纳入输入提示。这为机器人策略建立了一个反馈回路，使策略能够从自身的决策中学习并适应动态环境。为了实现这一方法，我们采用潜在动作模型来标注从历史帧中提取的动作。这些标注后的动作随后被映射到 LLaMA 标记词汇表中，并附加到任务指令上。在后训练阶段，历史动作输入被整合为输入，以赋予模型上下文学习能力。在推理时，每个时间步（初始步骤除外）都会纳入一步历史潜在动作（编码为 $N = 4$ 个标记）。实验结果表明，这种简单的设计提升了模型性能，尤其是在长时程任务中（见第 IV-C 节）。

IV. 评估

为了展示本文提出的通用策略的性能，我们的评估框架在多种基准（包括操作基准：LIBERO[48]、CALVIN[56]、SimplerEnv[47]，以及导航基准：R2R[4]）和真实世界场景中评估 UniVLA 的能力。此外，我们进行了潜在动作分析以量化任务中心特性，并进行了消融研究以探索关键设计选择。通过全面的评估，我们主要旨在探究：

1) 性能与适应性。UniVLA 能否成功地将预训练期间获得的知识迁移到新的具身形态和任务中，并高效地适应？（操作性能见第 IV-A 节，导航适应性见第 IV-A2 节。）




图 4: LIBERO 基准上的任务设置。

2) 泛化性。UniVLA 如何泛化到未见过的场景？（关于其在新环境中的泛化性分析，请参见第 IV-A3 节。）

3) 可扩展性。UniVLA 能否有效利用多样化的数据源，甚至包括人类视频，并从持续扩展的数据集中获得可扩展的收益？（关于数据可扩展性分析，请参见第 IV-C 节。）

A. 主要结果

1) LIBERO 上的操作基准测试

实验设置。我们在操作数据、导航数据和人类视频数据上预训练了完整的潜在动作模型，这些数据分别是 OpenX-Embodiment (OpenX) 数据集 [63]、GNM 数据集 [72] 和人类视频 (Ego4D[29]) 的子集。预训练细节见第 A1 节。LIBERO 基准 [48] 包含四个任务套件，专门用于促进机器人操作中终身学习的研究。我们的实验仅关注目标任务套件内的监督微调，评估通过行为克隆在成功任务演示上训练的各种策略的性能。如图 4 所示，我们的实验设置包括以下任务套件，每个套件包含 10 个任务，每个任务有 50 个人类遥操作演示：

1) LIBERO-Spatial 要求策略推断空间关系以准确放置碗，评估模型推理几何配置的能力；

2) LIBERO-Object 保持相同的场景布局，但引入物体类型的变化，评估策略跨物体实例泛化的能力；

3) LIBERO-Goal 保持物体和布局一致，同时分配不同的任务目标，挑战策略表现出目标导向行为和适应性；

4) LIBERO-Long 聚焦于涉及多个子目标的长期操作任务，融合异构

表一：在四个评估套件上的 LIBERO 基准测试结果。本文提出的 UniVLA 在所有基准任务上均展现出优于现有基线方法的性能，这归因于其增强的知识迁移能力和泛化能力。尽管仅使用 Bridge-V2 [78] 数据集或无动作的人类视频数据（分别标记为“Bridge”和“Human”）进行预训练，本文模型仍取得了最先进的结果。† 方法使用了额外的腕部视角相机输入。* 我们使用 Prismatic-7B 视觉语言模型复现了 LAPA 的结果。

Method		Spatial	Object	Goal	Long	Average
LAPA* [87]		73.8	74.6	58.8	55.4	65.7
Diffusion Policy [17]		78.3	92.5	68.3	50.5	72.4
Octo [28]		78.9	85.7	84.6	51.1	75.1
MDT† [68]		78.5	87.5	73.5	64.8	76.1
OpenVLA [39]		84.7	88.4	79.2	53.7	76.5
MaIL† [35]		74.3	90.1	81.8	78.6	83.5
UniVLA (Ours)	Human	91.2	94.2	90.2	79.4	88.7
	Bridge	95.2	95.4	91.9	87.5	92.5
	Full	96.5	96.8	95.6	92.0	95.2

异构物体、布局 and 任务序列，以评估模型在复杂多步规划中的熟练程度。

我们遵循 OpenVLA [39] 中引入的数据处理流程，以从用于训练的演示数据中排除失败案例。UniVLA 在 LIBERO-Long 上训练 40k 步，在其他测试套件上训练 30k 步，全局批大小为 128。我们仅使用第三人称图像和语言指令作为输入。值得注意的是，LIBERO 中的任何样本均未包含在策略的预训练数据集中，也未包含在我们的潜在动作模型的训练数据中，因此两者都需要具备泛化能力。除了展示我们在完整数据集上预训练的性能最佳模型的结果外，我们还提供了仅在 Bridge-V2 [78] 和人类数据上预训练的模型的结果，分别在表 I 中标记为“Bridge”和“Human”。为了最小化方差，所有方法在每个任务套件上评估 500 次试验（即每个任务 50 次试验），报告的性能反映了三个随机种子的平均成功率。

基线。本文选取的基线模型包括以下五个代表性模型，其中开放视觉语言动作模型 (OpenVLA) 与潜在动作预训练适配器 (LAPA) 与本文方法关联更为紧密：• 潜在动作预训练适配器 (LAPA) [87] 提出了一种无监督框架，用于从无标注的人类视频中学习潜在动作。• 章鱼模型 (Octo) [28] 是一种基于变换器 (Transformer) 的策略，在多样化机器人数据集上训练，采用统一的动作表示以处理异构动作空间。• 多模态扩散变换器 (MDT) [68] 利用扩散模型生成以多模态目标为条件的灵活动作序列。

• **开放视觉语言动作模型 (OpenVLA) [39]** 是一种视觉-语言-动作模型，它利用在多样化数据集（包括 OpenX）上的大规模预训练，以实现通用机器人策略。• MaIL [35] 通过引入选择性状态空间模型来增强模仿学习，从而提升策略学习的效率与可扩展性。




图 5：真实世界机器人实验。本文提出四项不同任务：“存放螺丝刀”、“清洁砧板”、“折叠毛巾两次”和“堆叠汉诺塔”，旨在评估策略能力的四个维度。UniVLA 在所有任务上平均成功率提升 36.7%，平均得分 0.68，优于先前最先进的方法。




图 6：VLN-CE 中 R2R 上的 Oracle 成功率。仅使用单帧 RGB 输入，UniVLA 展现出与 NaVid 相当的性能，后者是一个融合全部历史观测的导航模型，同时在成功率上显著超越 OpenVLA。

结果。表 I 所示结果展示了统一视觉语言动作模型（UniVLA）在全部四个评估套件上的卓越性能，显著超越了开放视觉语言动作模型（OpenVLA）、语言锚定策略架构（LAPA）和八爪鱼模型（Octo）等先前的通用策略。值得注意的是，统一视觉语言动作模型通过在全量数据集上预训练，达到了 95.2% 的平均性能，分别以 18.7% 和 29.5% 的幅度超越开放视觉语言动作模型和语言锚定策略架构。尽管仅在桥接版本二（Bridge-V2）数据集上预训练，统一视觉语言动作模型仍获得 92.5% 的平均性能，优于利用额外腕部视角相机输入的邮件模仿学习（MaIL）（83.5%）和多模态扩散变换器（MDT）（76.1%）。使用人类数据预训练的策略以 12.2% 的幅度超越使用域内开放执行器（OpenX）数据训练的开放视觉语言动作模型。总之，统一视觉语言动作模型展现出无与伦比的知识迁移能力，并在自由基准（LIBERO）上建立了新的最先进水平。我们在第 B 节中提供了在卡尔文（CALVIN）和简易环境基准（SimplerEnv）上的额外结果。

2) 房间到房间导航基准

实验设置。在本实验中，我们在 VLN-CE 基准 [41] 上评估 UniVLA，以考察其在导航任务上的性能。这些基准提供了一组语言-

引导式导航任务与连续环境，用于在重建的逼真室内场景中执行底层动作。具体而言，本文聚焦于视觉语言导航（Vision-and-Language Navigation）中最为广泛认可的基准之一——VLN-CE 中的 Room2Room（R2R）[4] 任务。所有方法均在 R2R 训练划分的 10,819 个样本上进行训练，并在 R2R 验证未见划分划分的 1,839 个样本上进行评估。本文采用预言成功率来评估导航性能。若智能体在 VLN-CE 中到达目标点 3 米范围内，则该回合被视为成功。

基线。为确保与统一视觉语言动作模型（UniVLA）的公平比较，本文评估了仅使用红绿蓝（RGB）图像、不依赖深度或里程计数据的方法，这些方法在连续环境视觉语言导航（VLN-CE）环境中直接预测底层动作。所选基线如下：

- **序列到序列（Seq2Seq）** [40] 是一种循环序列到序列策略，根据 RGB 观测预测动作。
- **CMA** [40] 采用跨模态注意力机制，将指令与 RGB 观测相结合以进行动作预测。
- **LLaVA-Nav** 是 LLaVA [49] 的修改版本，使用 NaVid [91] 提出的数据进行协同微调，并采用观测到历史的技术对历史信息进行编码。
- **开放视觉语言动作模型（OpenVLA）** [39] 是一种视觉语言动作模型。我们引入若干特殊标记来对导航动作进行标记化处理，并在 R2R 训练划分上对模型进行微调。
- **NaVid** [91] 是一种基于视频的大型视觉语言模型，对所有历史 RGB 观测进行编码。它使用预训练的视觉编码器对视觉观测进行编码，并使用预训练的大语言模型预测动作。

结果。在图 6 中，我们报告了每种方法的预言成功率。UniVLA 显著优于 Seq2Seq 和 CMA，将预言成功率从 8.10% 提升至 47.1%。鉴于在 LLaVA-Nav 中提示历史信息的计算成本较高，我们参考 NaVid，并展示其在 VLN-CE R2R val-unseen 划分的 100 个回合子集上的结果。UniVLA 的预言成功率比 LLaVA-Nav 高出 **33.1%**，比 OpenVLA 高出 **29.6%**。此外，UniVLA 达到了与 NaVid 相当的预言成功率，后者

表 II: 泛化性评估。 UniVLA 在所有评估任务中均表现出卓越的性能，展示了其从高层语义理解到低层视觉鲁棒性的出色泛化能力。

Method	Lightning Variation		Visual Distractor		Novel Object		Average $\uparrow$	
	Succ.	Score	Succ.	Score	Succ.	Score	Succ.	Score
Diffusion Policy [17]	20.0	0.60	26.7	0.80	26.7	0.67	24.4	0.69
OpenVLA [39]	13.3	0.93	20.0	0.73	26.7	1.27	20.0	0.98
LAPA [87]	26.7	1.60	6.7	0.6	53.3	1.87	28.9	1.36
UniVLA (Ours)	66.7	2.33	53.3	2.40	86.7	2.73	68.9	2.49




图 7: 泛化性评估设置。我们在 3 种不同设置下评估策略的泛化能力。(a) 光照变化: 我们调暗环境光, 并在指定方向施加强光。(b) 视觉干扰物: 我们在桌面上添加了一个碗、一个笔记本和一卷胶带。(c) 新物体: 我们将待操作物体从螺丝刀替换为未见过的记号笔。

对所有历史观测进行编码, 而 UniVLA 仅以当前观测和历史潜在动作为条件。

3) 真实世界机器人部署

实验设置。所有真实世界实验均使用来自 AgileX Robotics 的 Piper 机械臂进行, 该机械臂具有 7 自由度动作空间, 并配备第三视角 Orbecc DABAI RGB-D 相机, 我们仅利用 RGB 图像作为输入。为评估策略, 我们设计了一套全面的任务, 涵盖策略能力的多个维度, 包括:

1) 空间感知: 拿起螺丝刀放入柜中并关上门 (“存放螺丝刀”)。

2) 工具使用与非抓取式操作: 拿起扫帚将砧板上的物品扫入簸箕 (“清洁砧板”)。

3) 可变形物体操作: 将毛巾对折两次 (“折叠毛巾两次”)。

4) 语义理解: 先将中号塔叠放在大号塔上, 再将小号塔叠放在中号塔上。 (“汉诺塔叠放”) 对于每项任务, 我们根据任务复杂度按比例收集 20 至 80 条轨迹, 用于微调模型。为全面评估泛化能力, 我们设计了跨越多个未见场景维度的实验, 包括光照变化、视觉干扰物以及物体泛化 (见图 7)。

认识到仅凭成功率无法充分反映策略性能或区分其能力, 我们引入了一种分步评分系统。对于四项任务中的每一项, 我们设定最高分为 3 分, 以反映任务执行过程中不同阶段的完成情况。详细的评分标准、任务设置和实验结果见附录 C。

Baselines

我们选择扩散策略 (Diffusion Policy) [17], 以及通用策略 OpenVLA [39] 和 LAPA [87] 作为基线。扩散策略以单任务方式训练, 而通用模型则通过指令输入在所有任务上同时训练。为公平比较, 我们使用 Prismatic-7B 视觉语言模型 (VLM) [37] 和动作解码头复现 LAPA, 使其架构与我们的方法保持一致。该设置使我们能够分离并突出我们以任务为中心的潜在动作空间的贡献。具体参数和架构细节见附录 C。

结果。我们在图 5 中绘制了任务成功率。单任务扩散策略 (Diffusion Policy, DP) 针对轨迹保真度和低延迟控制进行了优化, 在毛巾折叠等任务中表现出色, 这类任务的成功关键在于选定正确的毛巾边缘后执行固定轨迹。这种专业化使 DP 在该任务中取得了比 UniVLA 更高的成功率 (53.3% 对 46.7%)。然而, UniVLA 取得了更高的分步得分 (2.47 对 DP 的 2.33, 详见第 C 节), 反映出其即使在最终执行不理想时也能可靠完成中间阶段 (例如边缘选择、部分折叠) 的能力——这在动态现实环境中是一项关键优势, 因为部分进展也很有价值。这种权衡源于 UniVLA 的通用设计: 虽然 DP 的单任务训练最大化了特定工作流程的轨迹精度, 但它在需要语义推理的任务中表现不佳 (例如堆叠汉诺塔, DP 仅取得 6.7% 的成功率)。相比之下, UniVLA 展现出卓越的泛化能力和语义理解能力, 取得了无与伦比的 86.7% 成功率。在需要精确物体操作和空间推理的场景中 (在 “存放螺丝刀” 任务中物体被放置在不同姿态和位置), 进一步证明了这一点, 成功率达到 93.3%。此外, 我们的方法通过在紧凑的潜在动作空间中进行规划, 并允许高效的动作块预测 (我们使用块大小为 12), 在 NVIDIA RTX 4090 GPU 上实现了 10Hz 的实时闭环推理频率。




图 8：潜在动作分析。我们绘制了来自不同数据来源和具身形态、标记为相同潜在动作的图像对。每组潜在动作都表现出语义一致的动作。更多示例见第 B 节。




图 9：数据可扩展性。UniVLA 通过整合来自 OpenX 的跨具身数据和无标签人类演示，有效扩展了其预训练语料库，从而持续提升下游性能。

实践中的表现）。OpenVLA 尽管在大规模机器人数据集上进行了广泛训练，但由于推理延迟（例如，预测单个动作步耗时 0.18 秒，预测大小为 4 的动作块耗时 **0.68** 秒）导致执行卡顿，实际性能不佳，平均成功率仅为 38.3%。简而言之，UniVLA 在成功率上比第二好的策略 LAPA 高出 **36.7%**，平均得分高出 **0.68**，证明了其实际有效性以及我们提出的以任务为中心的潜在动作空间的优势。

泛化性分析。我们从 3 个不同方面研究策略的泛化性，具体实验设置如图 7 所示。表 II 中的结果突显了 UniVLA 卓越的泛化能力，在成功率和逐步得分上显著优于基线方法。它在不同光照条件下达到 66.7% 的成功率，超过扩散策略（20.0%）、OpenVLA（13.3%）和 LAPA（26.7%），展示了对环境变化的鲁棒性。

在存在视觉干扰物的场景中，更依赖语义信息的策略（如 LAPA 和 UniVLA）性能下降相对明显。在新物体设置中，我们将螺丝刀替换为记号笔，并相应调整了通用策略的语言输入。这一变化对我们的策略影响很小，成功率仅下降 6.6%。总体而言，UniVLA 达到 **68.9%** 的平均成功率和 **2.49** 的平均得分，显著优于先前的视觉语言动作模型，如 LAPA（28.9%，1.36）和 OpenVLA（20.0%，0.98）。我们还在补充材料中提供了视频演示。

B. 潜在动作讨论

定性分析。我们通过图 8 中可视化来自不同数据源但共享相同潜在动作的图像对，研究潜在动作的跨域可迁移性。每组潜在动作在不同具身形态上映射到语义一致的行为（例如，A 组中表示“拾取物体”的潜在动作）。值得注意的是，我们的潜在动作模型在未使用 LIBERO [48] 数据集任何数据的情况下训练，能够有效泛化到这一未见领域，为动作准确打标签。此外，潜在动作模型学会将操作中的腕部视角观察与导航中的自我中心运动对齐，如 C 组所示，突显了其桥接不同模态和具身形态的能力。

定量分析。为评估所提出的动力学分解方法在任务中心潜在动作学习中的有效性，本文评估了使用不同潜在动作标签训练的策略的部署性能。在自由机器人操作基准（LIBERO）上的结果如表三所示。本文仅使用包含大量不可预测运动的人类视频预训练策略，以放大所提方法的优点。与精灵世界模型（Genie）[12] 中引入的捕捉所有视觉变化的潜在动作构建方法相比，本文方法展现出明显优势。具体而言，本文实现了 6.4% 的提升，

表三：使用不同潜在动作在自由机器人操作基准（LIBERO）上的性能。本文使用来自第一人称视频数据集（Ego4D）[29]的不同潜在动作预训练策略，该数据集包含具有多样运动和任务无关动态的人类视频，以证明本文成功解耦了任务中心动态。任务无关的潜在动作性能较差，而任务中心的潜在动作学习能产生更有意义的动作表示，最终实现更高的部署成功率。

Latent Action	Spatial	Object	Goal	Long	Avg.
Genie [12]	89.8	92.8	77.2	69.6	82.3
Task-irrelevant	68.0	90.4	67.2	0.2	56.5
Task-centric	91.2	94.2	90.2	79.4	88.7




图 10：数据效率。本文展示了统一视觉语言动作模型（UniVLA）在不同数据集比例（10%、20%、50% 和完整数据集）下的成功率。本文策略无需大量专家演示即可适应未知环境，展现出相对于基线的显著优势。

平均成功率，在自由机器人操作目标基准（LIBERO-Goal）和自由机器人操作长程基准（LIBERO-Long）上分别有 13% 和 9.8% 的显著提升。相比之下，任务无关的潜在动作与真实动作对齐不佳，使策略难以从观测和任务指令中推断它们。这体现在训练期间较低的动作标记预测准确率和较差的推理性能上。值得注意的是，使用任务无关的潜在动作进行训练，在具有挑战性的自由机器人操作长程基准（LIBERO-Long）上成功率几乎为零。

C. 更多消融实验

数据可扩展性。我们在图 9 中展示了 UniVLA 如何随着数据规模的扩大以及来自不同领域数据的加入而演进。尽管仅使用 Bridge-V2 进行预训练，UniVLA 已经在 LIBERO 上达到了新的最先进水平 [78]。OpenX[63] 和 Ego4D[29] 中的跨具身数据进一步将平均成功率提升了 2.0%。虽然 LIBERO 基准上的性能似乎趋于平稳，但在我们具有挑战性的真实世界测试套件中观察到了一致的性能提升。在真实世界评估中，与仅使用 Bridge 预训练相比，将预训练数据扩展到 OpenX 使平均得分提高了 0.3。进一步纳入人类数据，尽管缺乏动作标签且引入了显著的具身差距，仍带来了额外的 0.28 提升。这种性能提升的趋势在 R2R 导航基准中同样被观察到，突显了我们方法的可扩展性，因为它有效地利用了多样化的数据源。

表 IV：解码器设计的消融实验。“自回归”表示我们遵循 OpenVLA 和 LAPA 的方法，在离散化的动作区间上以自回归方式顺序预测动作。“无视觉”表示视觉嵌入未被用作解码潜在动作的查询输入，如图 3 所示。所提出的动作解码头，通过视觉特征增强，被证明是最有效的，在所有测试套件上产生了最高的结果。

Action Decoder	Spatial	Object	Goal	Long	Avg.
Auto-regressive	85.2	81.2	79.0	49.0	73.6
Ours w/o Visual	95.0	95.4	93.7	86.0	92.5
Ours	96.5	96.8	95.6	92.0	95.2

表 V：关于历史动作使用的消融实验。将前一步的潜在动作输出作为提示输入，尽管简单，却提升了性能，特别是在长时程任务中，如 LIBERO-Long 和 R2R。

Prompt Input	LIBERO (Manip.) Goal	LIBERO (Manip.) Long	R2R (Navi.)
Instruction-only	95.0	88.1	30.6
w/ History Action	95.6	92.0	47.1

数据效率。前文强调了统一视觉-语言-动作模型（UniVLA）在预训练数据方面的可扩展性，持续增强其能力。接下来，我们探索其在最少数据下高效适应未知环境的能力，如图 10 所示。具体而言，我们使用部分训练数据在自由目标（LIBERO-Goal）和自由长程（LIBERO-Long）基准上评估性能。与先前的通用策略（如开放视觉-语言-动作模型（OpenVLA）[39]）和显式点预测方法（如任意点轨迹模型（ATM）[81]）相比，统一视觉-语言-动作模型展现出更优的数据效率。值得注意的是，仅使用 10% 的演示数据，统一视觉-语言-动作模型在自由目标基准上达到了更高的成功率（86.3% 对 79.2%），超过了使用完整数据集训练的开放视觉-语言-动作模型。此外，它分别仅使用 10% 和 50% 的训练片段，在自由目标和自由长程基准上均创下了新的最先进性能。通过在统一的潜在动作空间中进行规划，统一视觉-语言-动作模型最大化了预训练知识，实现了对新环境的高效适应。

潜在动作解码器。我们将所提出的动作解码方案与自回归方法进行比较，后者如开放视觉-语言-动作模型和语言动作策略架构（LAPA）那样顺序生成离散化动作。如表四所示，我们的方法在所有测试套件上均持续取得更高的成功率，在自由长程基准上显著提升了 42.1%。利用视觉嵌入作为查询，通过减少多模态分布中的歧义来增强动作解码，平均成功率额外提升了 2.2%。此外，如第三节-A 部分所讨论的，潜在动作被设计为封装一秒时间范围内的动态特性。鉴于这种时间结构，将潜在动作解码为动作块 [93] 是一种直观的选择，使块大小与目标实体的控制频率对齐。这

通过简单地扩展最终线性投影层的输出维度来实现，与自回归方法相比，引入的额外推理成本可忽略不计。

历史潜在动作。如第三节第三部分所述，我们通过历史潜在动作增强指令输入，以提升序列决策能力。我们在操作与导航任务上评估了这一最小化架构修改的有效性，定量结果见表五。该方法在长时程场景中尤为有效：仅使用四个输入标记（表示一个潜在动作组）即可将成功率提升 16.5%（R2R）和 3.9%（LIBERO-Long）。扩展历史时程带来的收益递减。与需要冗余多帧视觉标记来提供时序上下文的方法（例如 [91, 45]）不同，我们的设计提供了紧凑的历史指导，同时通过自引用输出实现策略的迭代优化。这种精简的集成方式在不增加不必要计算开销的情况下增强了上下文感知能力。

五、结论

本文提出 UniVLA，一种视觉-语言-动作模型，在统一的、以任务为中心的潜在动作空间中进行规划，从而高效适应新型机器人配置。通过广泛评估，我们证明 UniVLA 在多个操作与导航基准上达到了最先进的性能。该模型还展现出对异构预训练数据的可扩展性，以提升下游性能，并且在数据有限的情况下仍保持高度适应性。我们希望本工作能为下一代通用策略铺平道路，使其能够利用网络规模的视频数据进行训练，无论具身差异或动作标签的可用性如何。

六、局限性与未来工作

潜在动作设计。尽管 UniVLA 推动了通用机器人策略的发展，但仍存在若干局限性。潜在动作的固定粒度和预定义的码本大小可能并非对所有任务或具身形式都是最优的。探索根据环境条件动态调整这些参数的自适应机制，有望进一步提升性能。此外，UniVLA 主要在单臂操作任务上进行了评估。在我们的框架中，潜在动作标记所表示的动作粒度相对固定。将框架扩展到双臂人形系统或灵巧手可能需要更复杂、更细粒度的动作空间建模。我们将此留待未来探索。

对语言标注的要求。关于语言粒度，任务相关的潜在动作旨在编码对任务完成至关重要的自主运动，同时排除非自主运动（例如，“烧水”过程中水壶冒出的蒸汽）。我们的数据集大部分由细粒度指令组成，这些指令描述的是短时程动作而非高层目标。虽然更具表达力的语言指令可能潜在地减少潜在动作学习中的歧义，

但我们想强调，我们的方法能够从不同粒度的指令中进行可扩展的学习。在不对指令进行任何特殊处理的情况下，我们的方法优于朴素的潜在动作学习方法。

与世界模型的集成。潜在动作模型的解码器本质上是一个世界模型，在给定潜在动作的情况下预测未来观测。它可以根据我们的策略实时采样的潜在动作进行条件化，并生成多个相应的视觉规划。这为通过规划树 [25] 进行参考对齐 [92] 与强化学习以及测试时扩展打开了大门，其中视觉语言模型 [54] 或启发式函数可以作为奖励模型。

上下文学习 能力对于提升视觉-语言-动作模型的性能上限至关重要。鉴于我们发现所提出的潜在动作模型能够提取连接人类与机器人操作的迁移性运动表示，我们提出将人类演示视频编码为紧凑的潜在动作嵌入序列，作为上下文样本（概念上，潜在动作模型充当视频分词器）。这种方法无需额外微调即可实现零样本技能获取。我们将在未来工作中探索这一方向。

致谢 我们感谢陈力、石莫迪和谢晨耕的宝贵反馈和富有成效的讨论。

参考文献

- [1] AgiBot-World-Contributors, Qingwen Bu, Jisong Cai, Li Chen, Xiuqi Cui, Yan Ding, Siyuan Feng, Shenyan Gao, Xindong He, Xuan Hu, Xu Huang, Shu Jiang, Yuxin Jiang, Cheng Jing, Hongyang Li, Jialu Li, Chiming Liu, Yi Liu, Yuxiang Lu, Jianlan Luo, Ping Luo, Yao Mu, Yuehan Niu, Yixuan Pan, Jiangmiao Pang, Yu Qiao, Guanghui Ren, Cheng Ruan, Jiaqi Shan, Yongjian Shen, Chengshi Shi, Mingkan Shi, Modi Shi, Chonghao Sima, Jianheng Song, Huijie Wang, Wenhao Wang, Dafeng Wei, Chengen Xie, Guo Xu, Junchi Yan, Cunbiao Yang, Lei Yang, Shukai Yang, Maoqing Yao, Jia Zeng, Chi Zhang, Qinglin Zhang, Bin Zhao, Chengyue Zhao, Jiaqi Zhao, and Jianchao Zhu. Agibot world colosseum: A large-scale manipulation platform for scalable and intelligent embodied systems. *arXiv preprint arXiv:2503.06669*, 2025. 1
- [2] Alexander A Alemi, Ian Fischer, Joshua V Dillon, and Kevin Murphy. Deep variational information bottleneck. In *ICLR*, 2017. 4
- [3] Arthur Allshire, Roberto Martín-Martín, Charles Lin, Shawn Manuel, Silvio Savarese, and Animesh Garg. Laser: Learning a latent action space for efficient reinforcement learning. In *ICRA*, 2021. 3
- [4] Peter Anderson, Qi Wu, Damien Teney, Jake Bruce, Mark Johnson, Niko Sünderhauf, Ian Reid, Stephen Gould, and Anton Van Den Hengel. Vision-and-language navigation: Interpreting visually-grounded navigation instructions in real environments. In *CVPR*, 2018. 2, 5, 7

- [5] Mahmoud Assran, Quentin Duval, Ishan Misra, Piotr Bojanowski, Pascal Vincent, Michael Rabbat, Yann LeCun, and Nicolas Ballas. Self-supervised learning from images with a joint-embedding predictive architecture. In *CVPR*, 2023. 3
- [6] Adrien Bardes, Quentin Garrido, Jean Ponce, Xinlei Chen, Michael Rabbat, Yann LeCun, Mahmoud Assran, and Nicolas Ballas. Revisiting feature prediction for learning visual representations from video. *arXiv preprint arXiv:2404.08471*, 2024. 3
- [7] Suneel Belkhole, Yuchen Cui, and Dorsa Sadigh. HYDRA: Hybrid robot actions for imitation learning. *arXiv preprint arXiv:2306.17237*, 2023. 16
- [8] Homanga Bharadhwaj, Abhinav Gupta, Vikash Kumar, and Shubham Tulsiani. Towards generalizable zero-shot manipulation via translating human interaction plans. In *ICRA*, 2024. 2
- [9] Kevin Black, Mitsuhiko Nakamoto, Pranav Atreya, Homer Rich Walke, Chelsea Finn, Aviral Kumar, and Sergey Levine. Zero-shot robotic manipulation with pre-trained image-editing diffusion models. In *ICLR*, 2024. 2, 16
- [10] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Xi Chen, Krzysztof Choromanski, Tianli Ding, Danny Driess, Avinava Dubey, Chelsea Finn, et al. RT-2: Vision-language-action models transfer web knowledge to robotic control. In *CoRL*, 2023. 1, 2, 4
- [11] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Joseph Dabis, Chelsea Finn, Keerthana Gopalakrishnan, Karol Hausman, Alex Herzog, Jasmine Hsu, et al. RT-1: Robotics transformer for real-world control at scale. In *RSS*, 2023. 2, 16, 17
- [12] Jake Bruce, Michael D Dennis, Ashley Edwards, Jack Parker-Holder, Yuge Shi, Edward Hughes, Matthew Lai, Aditi Mavalankar, Richie Steigerwald, Chris Apps, et al. Genie: Generative interactive environments. In *ICML*, 2024. 3, 9, 10
- [13] Qingwen Bu, Hongyang Li, Li Chen, Jisong Cai, Jia Zeng, Heming Cui, Maoqing Yao, and Yu Qiao. Towards synergistic, generalized, and efficient dual-system for robotic manipulation. *arXiv preprint arXiv:2410.08001*, 2024. 2, 16
- [14] Qingwen Bu, Jia Zeng, Li Chen, Yanchao Yang, Guyue Zhou, Junchi Yan, Ping Luo, Heming Cui, Yi Ma, and Hongyang Li. Closed-loop visuomotor control with generative expectation for robotic manipulation. In *NeurIPS*, 2024. 2, 16
- [15] Lawrence Yunliang Chen, Simeon Adebola, and Ken Goldberg. Berkeley UR5 demonstration dataset. <https://sites.google.com/view/berkeley-ur5/home>. 16
- [16] Xiaoyu Chen, Junliang Guo, Tianyu He, Chuheng Zhang, Pushi Zhang, Derek Cathera Yang, Li Zhao, and Jiang Bian. IGOR: Image-goal representations are the atomic control units for foundation models in embodied ai. *arXiv preprint arXiv:2411.00785*, 2024. 2, 3
- [17] Cheng Chi, Siyuan Feng, Yilun Du, Zhenjia Xu, Eric Cousineau, Benjamin Burchfiel, and Shuran Song. Diffusion Policy: Visuomotor policy learning via action diffusion. In *RSS*, 2023. 6, 8, 18
- [18] A Conneau. Unsupervised cross-lingual representation learning at scale. *arXiv preprint arXiv:1911.02116*, 2019. 1
- [19] Zichen Jeff Cui, Yibin Wang, Nur Muhammad Mahi Shafiullah, and Lerrel Pinto. From play to policy: Conditional behavior generation from uncured robot data. *arXiv preprint arXiv:2210.10047*, 2022. 16
- [20] Zichen Jeff Cui, Hengkai Pan, Aadithya Iyer, Siddhant Halder, and Lerrel Pinto. DynaMo: In-domain dynamics pretraining for visuo-motor control. In *NeurIPS*, 2024. 3
- [21] Shivin Dass, Jullian Yapeter, Jesse Zhang, Jiahui Zhang, Karl Pertsch, Stefanos Nikolaidis, and Joseph J. Lim. CLVR jaco play dataset, 2023. URL https://github.com/clvrai/clvr_jaco_play_dataset. 16
- [22] Jacob Devlin. Bert: Pre-training of deep bidirectional transformers for language understanding. *arXiv preprint arXiv:1810.04805*, 2018. 1
- [23] Ria Doshi, Homer Walke, Oier Mees, Sudeep Dasari, and Sergey Levine. Scaling Cross-Embodied Learning: One policy for manipulation, navigation, locomotion and aviation. In *CoRL*, 2024. 2
- [24] Yilun Du, Sherry Yang, Bo Dai, Hanjun Dai, Ofir Nachum, Josh Tenenbaum, Dale Schuurmans, and Pieter Abbeel. Learning universal policies via text-guided video generation. In *NeurIPS*, 2024. 2
- [25] Yilun Du, Sherry Yang, Pete Florence, Fei Xia, Ayzaan Wahid, brian ichter, Pierre Sermanet, Tianhe Yu, Pieter Abbeel, Joshua B. Tenenbaum, Leslie Pack Kaelbling, Andy Zeng, and Jonathan Tompson. Video language planning. In *ICLR*, 2024. 11
- [26] Chongkai Gao, Haozhuo Zhang, Zhixuan Xu, Zhehao Cai, and Lin Shao. FLIP: Flow-centric generative planning for general-purpose manipulation tasks. In *ICLR*, 2025. 2
- [27] Shenyuan Gao, Siyuan Zhou, Yilun Du, Jun Zhang, and Chuang Gan. AdaWorld: Learning adaptable world models with latent actions. *arXiv preprint arXiv:2503.18938*, 2025. 3
- [28] Dibya Ghosh, Homer Walke, Karl Pertsch, Kevin Black, Oier Mees, Sudeep Dasari, Joey Hejna, Tobias Kreiman, Charles Xu, Jianlan Luo, et al. Octo: An open-source generalist robot policy. In *RSS*, 2024. 1, 2, 6, 17
- [29] Kristen Grauman, Andrew Westbury, Eugene Byrne, Zachary Chavis, Antonino Furnari, Rohit Girdhar, Jackson Hamburger, Hao Jiang, Miao Liu, Xingyu Liu, et al. Ego4D: Around the world in 3,000 hours of egocentric video. In *CVPR*, 2022. 3, 6, 10, 16
- [30] Danijar Hafner, Timothy Lillicrap, Ian Fischer, Ruben Villegas, David Ha, Honglak Lee, and James Davidson. Learning latent dynamics for planning from pixels. In *ICML*, 2019. 3
- [31] Minh Heo, Youngwoon Lee, Doohyun Lee, and Joseph J. Lim. FurnitureBench: Reproducible real-world

- benchmark for long-horizon complex manipulation. In *RSS*, 2023. 16
- [32] Cheng-Chun Hsu, Bowen Wen, Jie Xu, Yashraj Narang, Xiaolong Wang, Yuke Zhu, Joydeep Biswas, and Stan Birchfield. SPOT: Se (3) pose trajectory diffusion for object-centric manipulation. *arXiv preprint arXiv:2411.00965*, 2024. 2
- [33] Edward J Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. LoRA: Low-rank adaptation of large language models. In *ICLR*, 2022. 5, 16, 17
- [34] Eric Jang, Alex Irpan, Mohi Khansari, Daniel Kappler, Frederik Ebert, Corey Lynch, Sergey Levine, and Chelsea Finn. BC-Z: Zero-shot task generalization with robotic imitation learning. In *CoRL*, 2022. 16
- [35] Xiaogang Jia, Qian Wang, Atalay Donat, Bowen Xing, Ge Li, Hongyi Zhou, Onur Celik, Denis Blessing, Rudolf Lioutikov, and Gerhard Neumann. MaIL: Improving imitation learning with selective state space models. In *CoRL*, 2024. 6
- [36] Dmitry Kalashnikov, Alex Irpan, Peter Pastor, Julian Ibarz, Alexander Herzog, Eric Jang, Deirdre Quillen, Ethan Holly, Mrinal Kalakrishnan, Vincent Vanhoucke, et al. Scalable deep reinforcement learning for vision-based robotic manipulation. In *CoRL*, 2018. 16
- [37] Siddharth Karamcheti, Suraj Nair, Ashwin Balakrishna, Percy Liang, Thomas Kollar, and Dorsa Sadigh. Prismatic VLMs: Investigating the design space of visually-conditioned language models. In *ICML*, 2024. 4, 5, 8
- [38] Alexander Khazatsky, Karl Pertsch, Suraj Nair, Ashwin Balakrishna, Sudeep Dasari, Siddharth Karamcheti, Soroush Nasiriany, Mohan Kumar Srirama, Lawrence Yunliang Chen, Kirsty Ellis, et al. DROID: A large-scale in-the-wild robot manipulation dataset. In *RSS*, 2024. 1, 16
- [39] Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, Ted Xiao, Ashwin Balakrishna, Suraj Nair, Rafael Rafailov, Ethan Foster, Grace Lam, Pannag Sanketi, et al. Open-VLA: An open-source vision-language-action model. In *CoRL*, 2024. 1, 2, 4, 6, 7, 8, 10, 16, 17, 18
- [40] Jacob Krantz, Erik Wijmans, Arjun Majumdar, Dhruv Batra, and Stefan Lee. Beyond the nav-graph: Vision-and-language navigation in continuous environments. In *ECCV*, 2020. 7
- [41] Jacob Krantz, Erik Wijmans, Arjun Majumdar, Dhruv Batra, and Stefan Lee. Beyond the nav-graph: Vision and language navigation in continuous environments. In *ECCV*, 2020. 7
- [42] Hanna Kurniawati. Partially observable markov decision processes (pomdps) and robotics. *arXiv preprint arXiv:2107.07599*, 2021. 5
- [43] Juho Lee, Yoonho Lee, Jungtaek Kim, Adam Kosior, Seungjin Choi, and Yee Whye Teh. Set transformer: A framework for attention-based permutation-invariant neural networks. In *ICML*, 2019. 5
- [44] Seungjae Lee, Yibin Wang, Haritheja Etukuru, H Jin Kim, Nur Muhammad Mahi Shafiullah, and Lerrel Pinto. Behavior generation with latent actions. In *ICML*, 2024. 3
- [45] Xinghang Li, Peiyan Li, Minghuan Liu, Dong Wang, Jirong Liu, Bingyi Kang, Xiao Ma, Tao Kong, Hanbo Zhang, and Huaping Liu. Towards generalist robot policies: What matters in building vision-language-action models. *arXiv preprint arXiv:2412.14058*, 2024. 5, 11, 17
- [46] Xinghang Li, Minghuan Liu, Hanbo Zhang, Cunjun Yu, Jie Xu, Hongtao Wu, Chilam Cheang, Ya Jing, Weinan Zhang, Huaping Liu, Hang Li, and Tao Kong. Vision-language foundation models as effective robot imitators. In *ICLR*, 2024. 2, 16
- [47] Xuanlin Li, Kyle Hsu, Jiayuan Gu, Karl Pertsch, Oier Mees, Homer Rich Walke, Chuyuan Fu, Ishikaa Lunawat, Isabel Sieh, Sean Kirmani, et al. Evaluating real-world robot manipulation policies in simulation. In *CoRL*, 2024. 5, 16, 17
- [48] Bo Liu, Yifeng Zhu, Chongkai Gao, Yihao Feng, Qiang Liu, Yuke Zhu, and Peter Stone. LIBERO: Benchmarking knowledge transfer for lifelong robot learning. In *NeurIPS*, 2024. 2, 5, 6, 9
- [49] Haotian Liu, Chunyuan Li, Yuheng Li, and Yong Jae Lee. Improved baselines with visual instruction tuning. In *CVPR*, 2023. 7
- [50] Huihan Liu, Soroush Nasiriany, Lance Zhang, Zhiyao Bao, and Yuke Zhu. Robot learning on the job: Human-in-the-loop autonomy and learning during deployment. In *RSS*, 2023. 16
- [51] Jianlan Luo, Charles Xu, Xinyang Geng, Gilbert Feng, Kuan Fang, Liam Tan, Stefan Schaal, and Sergey Levine. Multi-stage cable routing through hierarchical imitation learning. *TRO*, 2023. 16
- [52] Jianlan Luo, Charles Xu, Fangchen Liu, Liam Tan, Zipeng Lin, Jeffrey Wu, Pieter Abbeel, and Sergey Levine. FMB: a functional manipulation benchmark for generalizable robotic learning. *IJRR*, 2023. 16
- [53] Corey Lynch, Ayzaan Wahid, Jonathan Tompson, Tianli Ding, James Betker, Robert Baruch, Travis Armstrong, and Pete Florence. Interactive language: Talking to robots in real time. *RA-L*, 2023. 16
- [54] Yecheng Jason Ma, Joey Hejna, Ayzaan Wahid, Chuyuan Fu, Dhruv Shah, Jacky Liang, Zhuo Xu, Sean Kirmani, Peng Xu, Danny Driess, et al. Vision language models are in-context value learners. In *ICLR*, 2025. 11
- [55] Ajay Mandlekar, Yuke Zhu, Animesh Garg, Jonathan Boher, Max Spero, Albert Tung, Julian Gao, John Emmons, Anchit Gupta, Emre Orbay, Silvio Savarese, and Li Fei-Fei. RoboTurk: A crowdsourcing platform for robotic skill learning through imitation. In *CoRL*, 2018. 16
- [56] Oier Mees, Lukas Hermann, Erick Rosete-Beas, and Wolfram Burgard. CALVIN: A benchmark for language-conditioned policy learning for long-horizon robot manipulation tasks. *RA-L*, 2022. 5, 16

- [57] Oier Mees, Jessica Borja-Diaz, and Wolfram Burgard. Grounding language with visual affordances over unstructured data. In *ICRA*, 2023. 16
- [58] Russell Mendonca, Shikhar Bahl, and Deepak Pathak. Structured world models from human videos. In *CoRL*, 2023. 16
- [59] Atharva Mete, Haotian Xue, Albert Wilcox, Yongxin Chen, and Animesh Garg. Quest: Self-supervised skill abstractions for learning continuous control. In *NeurIPS*, 2024. 3
- [60] Nicolas Meuleau, Leonid Peshkin, Kee-Eung Kim, and Leslie Pack Kaelbling. Learning finite-state controllers for partially observable environments. *arXiv preprint arXiv:1301.6721*, 2013. 5
- [61] Soroush Nasiriany, Tian Gao, Ajay Mandlekar, and Yuke Zhu. Learning and retrieval from prior data for skill-based imitation learning. In *CoRL*, 2022. 16
- [62] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy Vo, Marc Szafranec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, et al. DINOv2: Learning robust visual features without supervision. *TMLR*, 2024. 2, 3, 4
- [63] Abhishek Padalkar, Acorn Pooley, Ajinkya Jain, Alex Bewley, Alex Herzog, Alex Irpan, Alexander Khazatsky, Anant Rai, Anikait Singh, Anthony Brohan, et al. Open X-Embodiment: Robotic learning datasets and RT-X models. In *ICRA*, 2024. 1, 2, 6, 10, 16
- [64] Yunchen Pu, Zhe Gan, Ricardo Henao, Xin Yuan, Chunyuan Li, Andrew Stevens, and Lawrence Carin. Variational autoencoder for deep learning of images, labels and captions. In *NeurIPS*, 2016. 3
- [65] Gabriel Quere, Annette Hagengruber, Maged Iskandar, Samuel Bustamante, Daniel Leidner, Freek Stulp, and Joern Vogel. Shared Control Templates for Assistive Robotics. In *ICRA*, Paris, France, 2020. 16
- [66] Alec Radford. Improving language understanding by generative pre-training. 2018. 3
- [67] Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li, and Peter J Liu. Exploring the limits of transfer learning with a unified text-to-text transformer. *JMLR*, 2020. 3, 4
- [68] Moritz Reuss, Ömer Erdiñç Yağmurlu, Fabian Wenzel, and Rudolf Lioutikov. Multimodal Diffusion Transformer: Learning versatile behavior from multimodal goals. In *ICRA Workshops*, 2024. 6
- [69] Saumya Saxena, Mohit Sharma, and Oliver Kroemer. Multi-resolution sensing for real-time control with Vision-Language Models. In *CoRL*, 2023. 16
- [70] Dominik Schmidt and Minqi Jiang. Learning to act without actions. In *ICLR*, 2024. 3
- [71] Nur Muhammad Mahi Shafiullah, Anant Rai, Haritheja Etukuru, Yiqian Liu, Ishan Misra, Soumith Chintala, and Lerrel Pinto. On bringing robots home. *arXiv preprint arXiv:2311.16098*, 2023. 16
- [72] Dhruv Shah, Ajay Sridhar, Arjun Bhorkar, Noriaki Hirose, and Sergey Levine. GNM: A general navigation model to drive any robot. In *ICRA*, 2023. 6, 16
- [73] Rutav Shah, Roberto Martín-Martín, and Yuke Zhu. MUTEX: Learning unified policies from multimodal task specifications. In *CoRL*, 2023. 16
- [74] Andrew Szot, Bogdan Mazouze, Harsh Agrawal, Devon Hjelm, Zsolt Kira, and Alexander Toshev. Grounding multimodal large language models in actions. In *NeurIPS*, 2024. 3
- [75] Hugo Touvron, Louis Martin, Kevin Stone, Peter Albert, Amjad Almahairi, Yasmine Babaei, Nikolay Bashlykov, Soumya Batra, Prajjwal Bhargava, Shruti Bhosale, et al. Llama 2: Open foundation and fine-tuned chat models. *arXiv preprint arXiv:2307.09288*, 2023. 4
- [76] Aaron Van Den Oord, Oriol Vinyals, and Koray Kavukcuoglu. Neural discrete representation learning. In *NeurIPS*, 2017. 1, 3
- [77] Ruben Villegas, Mohammad Babaeizadeh, Pieter-Jan Kindermans, Hernan Moraldo, Han Zhang, Mohammad Taghi Saffar, Santiago Castro, Julius Kunze, and Dumitru Erhan. Phenaki: Variable length video generation from open domain textual descriptions. In *ICLR*, 2023. 3
- [78] Homer Rich Walke, Kevin Black, Tony Z Zhao, Quan Vuong, Chongyi Zheng, Philippe Hansen-Estruch, Andre Wang He, Vivek Myers, Moo Jin Kim, Max Du, et al. BridgeData v2: A dataset for robot learning at scale. In *CoRL*, 2023. 1, 2, 6, 10, 16, 17
- [79] Zihao Wang, Shaofei Cai, Zhancun Mu, Haowei Lin, Ceyao Zhang, Xuejie Liu, Qing Li, Anji Liu, Xiaojian Ma, and Yitao Liang. OmniJARVIS: Unified vision-language-action tokenization enables open-world instruction following agents. In *NeurIPS*, 2024. 3
- [80] Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Fei Xia, Ed Chi, Quoc V Le, Denny Zhou, et al. Chain-of-thought prompting elicits reasoning in large language models. In *NeurIPS*, 2022. 5
- [81] Chuan Wen, Xingyu Lin, John So, Kai Chen, Qi Dou, Yang Gao, and Pieter Abbeel. Any-point trajectory modeling for policy learning. In *RSS*, 2023. 2, 10
- [82] Hongtao Wu, Ya Jing, Chilam Cheang, Guangzeng Chen, Jiafeng Xu, Xinghang Li, Minghuan Liu, Hang Li, and Tao Kong. Unleashing large-scale video generative pre-training for visual robot manipulation. In *ICLR*, 2024. 2, 16
- [83] Mengda Xu, Zhenjia Xu, Yinghao Xu, Cheng Chi, Gordon Wetzstein, Manuela Veloso, and Shuran Song. Flow as the cross-domain manipulation interface. In *CoRL*, 2024. 2
- [84] Mingxing Xu, Wenrui Dai, Chunmiao Liu, Xing Gao, Weiyao Lin, Guo-Jun Qi, and Hongkai Xiong. Spatial-temporal transformer networks for traffic flow forecasting. *arXiv preprint arXiv:2001.02908*, 2020. 3
- [85] Ge Yan, Kris Wu, and Xiaolong Wang. ucsd kitchens Dataset. August 2023. 16
- [86] Jonathan Yang, Catherine Glossop, Arjun Bhorkar,

- Dhruv Shah, Quan Vuong, Chelsea Finn, Dorsa Sadigh, and Sergey Levine. Pushing the limits of cross-embodiment learning for manipulation and navigation. In *RSS*, 2024. 2, 5
- [87] Seonghyeon Ye, Joel Jang, Byeongguk Jeon, SeJune Joo, Jianwei Yang, Baolin Peng, Ajay Mandlekar, Reuben Tan, Yu-Wei Chao, Bill Yuchen Lin, et al. Latent action pretraining from videos. In *ICLR*, 2025. 2, 3, 4, 6, 8, 18
- [88] Chengbo Yuan, Chuan Wen, Tong Zhang, and Yang Gao. General flow as foundation affordance for scalable robot learning. In *CoRL*, 2024. 2
- [89] Kaiwen Zha, Lijun Yu, Alireza Fathi, David A Ross, Cordelia Schmid, Dina Katabi, and Xiuye Gu. Language-guided image tokenization for generation. *arXiv preprint arXiv:2412.05796*, 2024. 4
- [90] Xiaohua Zhai, Basil Mustafa, Alexander Kolesnikov, and Lucas Beyer. Sigmoid loss for language image pre-training. In *ICCV*, 2023. 4
- [91] Jiazhao Zhang, Kunyu Wang, Rongtao Xu, Gengze Zhou, Yicong Hong, Xiaomeng Fang, Qi Wu, Zhizheng Zhang, and He Wang. NaVid: Video-based vlm plans the next step for vision-and-language navigation. In *RSS*, 2024. 7, 11
- [92] Zijian Zhang, Kaiyuan Zheng, Zhaorun Chen, Joel Jang, Yi Li, Chaoqi Wang, Mingyu Ding, Dieter Fox, and Huaxiu Yao. GRAPE: Generalizing robot policy via preference alignment. *arXiv preprint arXiv:2411.19309*, 2024. 11
- [93] Tony Z Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware. In *RSS*, 2023. 5, 10
- [94] Ruijie Zheng, Yongyuan Liang, Shuaiyi Huang, Jianfeng Gao, Hal Daumé III, Andrey Kolobov, Furong Huang, and Jianwei Yang. TraceVLA: Visual trace prompting enhances spatial-temporal awareness for generalist robotic policies. In *ICLR*, 2025. 5
- [95] Gaoyue Zhou, Victoria Dean, Mohan Kumar Srirama, Aravind Rajeswaran, Jyothish Pari, Kyle Hatch, Aryan Jain, Tianhe Yu, Pieter Abbeel, Lerrel Pinto, et al. Train offline, test online: A real robot learning benchmark. In *ICRA*, 2023. 16
- [96] Gaoyue Zhou, Hengkai Pan, Yann LeCun, and Lerrel Pinto. DINO-WM: World models on pre-trained visual features enable zero-shot planning. *arXiv preprint arXiv:2411.04983*, 2024. 3
- [97] Xinghao Zhu, Ran Tian, Chenfeng Xu, Mingxiao Huo, Wei Zhan, Masayoshi Tomizuka, and Mingyu Ding. Fanuc Manipulation: A dataset for learning-based manipulation with FANUC Mate 200iD Robot. 2023. 16
- [98] Yifeng Zhu, Peter Stone, and Yuke Zhu. Bottom-up skill discovery from unsegmented demonstrations for long-horizon robot manipulation. *RA-L*, 2022. 16
- [99] Yifeng Zhu, Abhishek Joshi, Peter Stone, and Yuke Zhu. VIOLA: Imitation learning for vision-based manipulation with object proposal priors. *arXiv preprint arXiv:2210.11339*, 2023. 16

附录

A. 实现细节

1) 预训练细节 对于机器人操作数据，我们在 Open X-Embodiment 数据集 [63] 中选择单臂末端执行器控制的数据集。对于导航数据，我们使用 GNM [72] 数据集的子划分，包含室内和越野场景，具有自我视角鱼眼相机。虽然机器人数据集中提供了动作和本体感受状态，但在预训练期间排除这些信息；仅使用片段帧和文本指令。此外，我们纳入开放世界人类视频，特别是来自 Ego4D 数据集 [29] 的以自我为中心的視頻，描绘日常人类活动。值得注意的是，除了 SimplerEnv 基准 [47]（旨在复现 Bridge-V2 数据集的环境设置）之外，下游评估环境在预训练期间均未被我们的策略或潜在动作模型见过。这要求两者具备强大的泛化能力。数据集的详细组成和混合权重列于表 A-I。

训练数据集混合	
Fractal [11]	13.9%
Kuka [36]	6.3%
Bridge [78]	6.8%
Taco Play [57]	3.5%
Jaco Play [21]	0.6%
Berkeley Cable Routing [51]	0.3%
Roboturk [55]	2.8%
Viola [99]	1.1%
Berkeley Autolab UR5 [15]	1.4%
Toto [95]	2.4%
Language Table [53]	5.2%
Stanford Hydra Dataset [7]	5.3%
Austin Buds Dataset [98]	0.3%
NYU Franka Play Dataset [19]	1.0%
Furniture Bench Dataset [31]	2.9%
UCSD Kitchen Dataset [85]	<0.1%
Austin Sailor Dataset [61]	2.6%
Austin Sirius Dataset [50]	2.0%
DLR EDAN Shared Control [65]	0.1%
IAMLab CMU Pickup Insert [69]	1.1%
UTAustin Mutex [73]	2.6%
Berkeley Fanuc Manipulation [97]	0.9%
CMU Stretch [58]	0.2%
BC-Z [34]	8.8%
FMB Dataset [52]	8.4%
Dobbe [71]	1.7%
RECON [38]	8.9%
CoryHall [38]	2.3%
SACSoN [38]	3.5%
Ego4D [38]	3.0%

表 A-I: UniVLA 训练数据混合，使用来自 OXE [63]、GNM [72] 和 Ego4D [29] 的数据集。

在训练期间，我们联合优化通用策略的所有组件，包括视觉编码器、大语言模型 (LLM) 主干和令牌预测

表 A-II: 语言条件下的视觉运动控制

CALVIN ABC → **D**. 我们报告成功率以及每个评估序列中已完成任务的平均长度（总共 5 个任务）。UniVLA 取得了具有竞争力的结果，同时是唯一仅依赖第三视角 RGB 输入的方法。* 使用动作块预测复现。

Method	Task completed in a row (%) ↑					Avg. Len.
	1	2	3	4	5	
RT-1 [11]	53.3	22.2	9.4	3.8	1.3	0.90
RoboFlamingo [46]	82.4	61.9	46.6	33.1	23.5	2.48
SuSIE [9]	87.0	69.0	49.0	38.0	26.0	2.69
GR-1 [82]	85.4	71.2	59.6	49.7	40.1	3.06
OpenVLA* [39]	91.3	77.8	62.0	52.1	43.5	3.27
CLOVER [14]	96.0	83.5	70.8	57.5	45.4	3.53
RoboDual [13]	94.4	82.7	72.1	62.4	54.4	3.66
UniVLA (Ours)	95.5	85.8	75.4	66.9	56.5	3.80

头部。我们采用批大小为 1,024（每设备批大小为 32），并保持恒定学习率。实验结果表明，20,000 个优化步骤足以获得稳健的下游性能，在配备 32 个 NVIDIA A100 GPU 的集群上大约需要 30 小时的计算时间。对于在“Human”和“Bridge”数据集上的预训练（如表 Tab. I 所示），我们使用分布在 8 个 GPU 上的全局批大小 258，总计约 200 A100 GPU 小时。

B. 附加结果

1) CALVIN

实验设置。 CALVIN [56] 包含 34 个不同的任务，其特点是无约束的任务指令，涵盖从基本的抓取放置操作到关节物体操作的一系列技能。该基准包括四个不同的环境，每个环境都配备一个 Franka Panda 机械臂用于桌面操作任务。在我们的研究中，我们采用具有挑战性的评估设置，即使用来自环境 A、B 和 C 的演示来训练策略，然后在环境 D 中进行零样本评估。评估协议包括一个包含 1,000 条唯一指令链的测试集，每条指令链由五个连续任务组成，旨在严格评估策略的泛化能力。对于 OpenVLA，我们使用 LoRA [33] 对官方提供的检查点进行 200k 步的微调，并使用大小为 8 的动作块以最大化性能。UniVLA 以批大小 128 优化 100k 步。前 80k 步使用学习率 $1.5e-4$ ，其余步骤使用 $1.5e-5$ 。与 LIBERO 实验类似，我们仅将第三视角 RGB 图像和语言指令作为输入。

结果。 表 A-II 中的结果表明 UniVLA 在语言条件下的视觉运动控制中达到了最先进的性能。UniVLA 在按顺序完成所有五个任务方面实现了 56.5% 的成功率，比之前的最佳方法 CLOVER (45.4%) 高出 11.1%，比 OpenVLA 高出 13%。连续完成任务的平均数量从 OpenVLA 的 3.27 增加到 3.80。值得注意的是，UniVLA 的性能差距




图 A-1: 潜在动作分析。本文展示了更多来自不同数据来源和实体、被标注为相同潜在动作的图像对。每组潜在动作均呈现语义一致的动作。

表 A-III: 在 SimplierEnv 上的抓取与任务成功率。由于 BridgeData 已纳入我们的预训练数据集，我们仅研究训练解码器进行适配（仅解码器）。UniVLA 在成功率上优于所有基线。

Model	Put Spoon on Towel		Put Carrot on Plate		Stack Green Block on Yellow Block		Put Eggplant in Yellow Basket		#Overall Average
	Grasp Spoon	Success	Grasp Carrot	Success	Grasp Green Block	Success	Grasp Eggplant	Success	
RT-1-X [11]	16.7%	0%	20.8%	4.2%	8.3%	0%	0.0%	0%	1.1%
Octo-Base [28]	34.7%	12.5%	52.8%	8.3%	31.9%	0%	66.7%	43.1%	16.0%
Octo-Small [28]	77.8%	47.2%	27.8%	9.7%	40.3%	4.2%	87.5%	56.9%	30.0%
OpenVLA [39]	4.1%	0%	33.3%	0%	12.5%	0%	8.3%	4.1%	1.0%
RoboVLM [45]	54.2%	29.2%	25.0%	25.0%	45.8%	12.5%	58.3%	58.3%	31.3%
UniVLA (Decoder-only)	70.8%	37.5%	62.5%	33.3%	37.5%	4.2%	87.5%	66.7%	35.4%
UniVLA	76.4%	52.8%	79.2%	55.6%	66.7%	2.8%	93.0%	80.6%	47.9%




图 A-2: 以任务为中心的潜在动作分析。本文展示了以任务为中心的潜在动作与图像块之间的注意力热图，表明注意力集中于机器人末端执行器和目标物体上。

随着任务长度的增加而逐渐扩展，反映了其处理复杂、长时程操作任务的能力。

2) SimplierEnv

实验设置。 SimplierEnv [47] 旨在通过模拟物理动力学和视觉外观，真实反映现实世界策略的性能。我们聚焦于“WidowX + Bridge”设置下的四项任务：1) “将勺子放在桌布上”，2) “将胡萝卜放在盘子上”，3) “将绿色方块堆叠在黄色方块上”，4) “将茄子放入篮子中”。待抓取物体的姿态和位置将根据不同的随机种子进行随机初始化。鉴于 Bridge-V2 [78] 数据已包含在我们的预训练数据集中，我们研究仅训练动作解码器头，同时保持模型其余部分固定，在 ?? 中表示为 decoderonly。此外，我们使用 LoRA [33] 在完整的 Bridge-V2 数据集上进行进一步微调，并评估所得策略。我们的评估遵循所提出的流程

由 Li 等人 [45] 提出，其中每项任务在 24 次独立试验中进行评估，以确保稳健的性能度量。

Results

表 A-III 中的结果凸显了统一视觉语言动作模型（UniVLA）在 SimplierEnv-Bridge 基准上抓取成功率和任务成功率方面的卓越性能，即便在受限的仅解码器适配设置下也是如此。具体而言，仅解码器适配实现了 35.4% 的成功率，表明其能够在最小化适配成本的同时保留预训练知识。然而，与仅解码器训练相比，全量微调导致抓取率下降，这可能是由于对训练样本中已见场景布局的过拟合所致。总体而言，统一视觉语言动作模型实现了 42.7% 的任务成功率，分别比开放视觉语言动作模型（OpenVLA）和八爪鱼基础模型（Octo-Base）高出 41.7% 和 26.7%。

3) 更多可视化

潜在动作分析的补充示例。 如第 IV-A2 节所述，本文通过展示来自不同数据源但共享同一潜在动作的图像对，探索潜在动作的跨域可迁移性。具有不同动作的更多示例见图 A-1。

以任务为中心的潜在动作分析。 我们在图 A-2 中可视化了学习到的以任务为中心的潜在动作与图像块之间的注意力图。热力图显示注意力集中在任务关键区域：机器人手臂的末端执行器（例如夹爪）和交互对象（例如鸡蛋），同时忽略无关背景。这表明潜在动作本质上编码了以任务为中心的空间先验，仅关注

表 A-IV: 任务得分。每个子目标对应一分。

Task Name	Total Score	Sub-goals
存放螺丝刀 ³		拿起螺丝刀。将螺丝刀放入柜中。关上柜门
清洁砧板 ³		拿起扫帚。将物品扫入簸箕。 将所有物品扫入簸箕。
将毛巾折叠两次 ³		抓住毛巾的正确边缘。第一次折叠毛巾。第二次折叠毛巾。
堆叠汉诺塔 ³ 选择正确的塔。将中号塔叠放在大号塔上。将小号塔叠放在中号塔上。		

表 A-V: 实验结果。最佳结果以粗体标出，次佳结果以下划线标出。

Method	Store screwdriver		Clean cutting board		Fold towel twice		Stack tower of hanoi		Average ↑	
	Succ.	Score	Succ.	Score	Succ.	Score	Succ.	Score	Succ.	Score
Diffusion Policy [17]	40.0	1.20	33.3	0.67	53.3	<u>2.33</u>	6.7	1.6	33.3	1.45
OpenVLA [39]	40.0	1.47	53.3	1.27	33.3	1.87	26.7	1.93	38.3	1.63
LAPA (OXE) [87]	60	2.0	40	1.47	33.3	2.2	46.7	2.13	45	1.95
UniVLA (Bridge)	66.7	2.13	<u>73.3</u>	1.87	33.3	2.07	46.7	2.13	55.0	2.05
UniVLA (OXE)	80.0	2.73	<u>73.3</u>	1.93	33.3	2.13	60.0	2.60	<u>63.3</u>	2.35
UniVLA (Full)	93.3	2.87	100.0	2.33	<u>46.7</u>	2.47	86.7	2.87	81.7	2.63

entities necessary for downstream learning.

C. Real-world Robots

1) Task setup and evaluation

In task “Store the screwdriver”, we randomly placed the screwdriver in three different positions for position generalization in training data, and tested it at four positions during evaluation. In task “Store the screwdriver”, we randomly placed items on the cutting board, some of which in some cases could be swept into the dustpan in a single motion, while others required two sweeps during data collection. For task “Fold towel twice”, we use a 20cm × 20cm towel and lay it flat on the table. During both training and testing, we randomly rotated the towel by different angles for evaluating generalization. In “Stack tower of hanoi”, we randomly shuffle three cups and cover six different arrangements during both training and testing.

We evaluate policies using a combined metric of success rate and task-specific scoring. Tab. A-IV shows the detailed scoring criteria. Full experimental results are presented in Tab. A-V. Notably, certain policies achieve identical success rates but exhibit divergent scores, reflecting differences in their performance quality.

Single-task-trained methods such as Diffusion Policy perform well in tasks like Fold towel twice, which demand smooth, continuous, and highly structured action sequences. Although Diffusion Policy achieves a higher success rate in this task, its score remains lower than UniVLA due to limited generalization across varying rotation angles. In contrast, UniVLA’s generalizability enables robust performance across

TABLE A-VI: Architecture details of action decoder in real-world experiment. Additional proprioceptive state projection module is only adopted in real-world experiments.

Architecture of Action Decoder		
Latent Action Attention Pooling	Heads	8
	Head Dim.	64
	Hidden Size	512
	MLP Ratio	4
Visual Embedding Attention Pooling	Heads	8
	Head Dim.	64
	Hidden Size	512
	MLP Ratio	4
Action Projection	Layers	1
	Hidden Size	512
Proprio. Projection	Layers	2
	Hidden Size	512
Parameters		12.6M

多样的位置配置，即使在部分任务完成的情况下也能获得更高的分数。

2) 动作解码器的架构 在为 LAPA 和本文方法设计动作解码器架构时，我们使用 2 个多头注意力块来处理潜在动作和视觉嵌入（另见第 III-C 节），并使用一个多层感知机层来处理本体感受状态。得到的嵌入随后被拼接，并通过一个投影层映射到所需的动作维度。详细参数见表 A-VI。