

Vid2Robot: 基于交叉注意力变换器的端到端视频条件策略学习

Vidhi Jain^{1,2} Maria Attarian^{1,3} Nikhil J Joshi¹ Ayzaan Wahid¹ Danny Driess¹ Quan Vuong¹ Pannag R Sanketi¹
Pierre Sermanet¹ Stefan Welker¹ Christine Chan¹ Igor Gilitschenski³ Yonatan Bisk² Debidatta Dwibedi¹

¹Google DeepMind Robotics ²Carnegie Mellon University ³University of Toronto




图 1: 概览。Vid2Robot 是一种视频条件机器人策略。给定人类演示（顶部），Vid2Robot 识别任务语义，并根据机器人当前视觉观察（左下）执行相同任务。右下展示了一条成功轨迹。

摘要——大规模多任务机器人操作系统通常依赖文本指定任务。本文探索机器人能否通过观察人类进行学习。为此，机器人必须理解人的意图，并在具身形态和环境存在差异的情况下执行推断出的任务。我们提出 Vid2Robot，一种端到端视频条件策略，以人类演示操作任务的视频为输入，输出机器人动作。该模型基于大规模提示视频-机器人轨迹数据集训练，从视频中学习人类与机器人动作的统一表示。Vid2Robot 在视频特征与当前机器人状态之间使用交叉注意力变换器层生成动作，并执行视频中展示的任务。我们采用辅助对比损失对齐提示视频与机器人视频表示，以获得更优策略。在真实机器人上评估 Vid2Robot，使用人类提示视频时性能较 BC-Z 提升超过 20%。此外，我们展示了跨物体运动迁移能力，使视频条件策略能够将提示视频中一个物体上观察到的运动迁移到机器人自身环境中的另一物体。视频见 vid2robot.github.io。

已知。然而，当需要学习具有细微差别的新技能时，我们会回归示范。例如，我们可能展示某微波炉如何操作，或如何整理橱柜。机器人同样需要这种从示范中泛化的能力，而这种能力对人类而言是自然而然的。人类能够基于第三人称视觉观察推断他人的意图。我们常常运用社会推理和常识来隐式理解他人的目标。这种能力对于学习日常任务至关重要，例如揉面或编织，这些任务的细节难以通过静态图像或文本传达 [6]。我们经常求助于操作指南视频 [32] 来学习如何执行此类任务。如果机器人能够基于视频行动，将实现高效的任務学习并改善与人类的交互。本文聚焦于视觉模仿学习，即机器人通过观看视频示范来学习执行任务。该设置具有若干优势。首先，它允许机器人从具有不同形态的智能体学习，无需遥操作即可实现新技能获取。其次，它允许机器人从专家示范中推断任务，即使专家展示的执行任务环境与机器人不同。最后，视觉模仿学习非常适合教授难以或无法用语言描述的任务。现有的多任务机器人操作模型（例如 RT-1[8]、RT-2[9] 和 RT-X[35]）使用语言条件来输出机器人轨迹。仅依赖文本进行任务规

I. 引言

创造能在人们日常生活中提供帮助的多功能机器人，需要它们能够随时学习新技能。这些技能既包括特定家庭中摆放洗碗机餐具的简单偏好，也包括完全不同的家庭清洁方式。对于已

这种分类方式使得机器人难以处理多义词以及执行方式因上下文而剧烈变化的任务。例如，“打开抽屉”、“打开柜子”、“打开带盖容器”和“打开螺旋盖罐子”可能共享同一个动词，但每次交互所需的运动控制却截然不同。在这种情况下，智能体不应泛化其策略，而应从一种抽屉泛化到其他在类型、颜色和形状上有所不同的抽屉。因此，存在大量难以设计高层规划方法原语的任务 [27, 2]。另一种常见方法是在目标条件行为克隆任务中使用最终目标图像 [33, 25]。然而，此类规范往往忽略了如何行动。例如，“握住旗帜”和“挥舞旗帜”可能具有相同的最终目标图像。我们可以通过使用多个子目标帧来解决这种歧义，这非常接近于用视频来条件化机器人策略。[42] 中视频条件化策略的当前成功假设所提供的视频来自同一工作空间且变异性有限。与语言条件化策略工作 [22] 相比，视频条件化策略在性能上也存在滞后。基于这些及相关工作，我们确定了视频条件化策略的三个主要挑战：（1）原始视频是高维数据，需要更多的计算能力和内存。（2）尽管互联网上存在大量未标注的视频数据，但找到机器人特定的视频和运动数据却很困难。（3）由于物体、光照条件和其他背景干扰的变化，人们可能以不同方式执行同一任务。尽管存在这些挑战，视频条件化策略学习仍是机器人需要掌握的核心挑战。为此，我们研究了如何使用带有视频条件化的端到端模型来为机器人指定任务。Vid2Robot 是一个端到端系统，能够快速适应以视频演示形式指定的任务。与先前的工作不同——那些工作要么仅从视频中学习表示以进行物体和动词识别 [22]，要么在仿真中学习运动控制 [47]——我们的工作展示了端到端学习的视频表示在真实世界机器人控制中的适用性。我们工作的关键贡献如下：（1）我们提出了一种基于变换器的策略来编码视频任务规范，该规范可由机器人或人类智能体演示（§ II）。（2）我们在训练过程中使用三个对比辅助损失来鼓励提示视频与机器人视频表示之间的对齐（§ II-E）。（3）通过实际机器人实验，我们发现我们的视频条件化策略在人类提示视频上优于基线方法。此外，我们的策略在跨物体运动迁移方面表现更佳（§ III）。

二、方法

A. 预备知识

本文的目标是设计一个机器人系统，该系统接收一段操作任务的提示视频，并输出完成视频中所示任务的动作。该系统必须从提示视频中推断出底层任务（该视频的設置或形态可能与机器人不同），然后操纵其环境中的物体以实现推断出的任务。

然后操控其环境中的物体以完成推断出的任务。本文模型的输入包括提示视频 V 和机器人状态 $S_t = \{x_i\}_{i=t-k-1}^t$ 其中 x_i 是机器人摄像头流在时间 i ， k 是历史帧的最大数量， t 是当前时间步。本文训练一个策略 $\pi(a_t|S_t, V)$ 该策略从 V 中推断底层任务，并预测与任务相关的动作 a_t 我们需要一个包含成对的提示视频与机器人轨迹的数据集来训练该模型。下面，我们将详细讨论如何创建成对数据集。

B. 数据集

为了训练视频条件下的机器人策略，需要一个成对数据集：提示视频和执行相同任务的机器人轨迹。本文探索了人类和机器人执行任务的提示视频。为了创建该数据集，本文依赖三类数据：

（1）机器人-机器人：我们将同一任务的现有机器人-机器人视频进行配对。对于这种配对，我们认为如果两个视频在不同场景下执行相同任务，则它们匹配。我们根据录制机器人轨迹的自然语言指令来定义“任务”。这些指令通常由一个或两个动词及其周围的名词组成，例如“将水瓶竖直放置”、“将可乐罐移到绿色薯片袋旁”或“打开顶层抽屉”。请注意，我们仅使用语言指令进行配对，并将其作为机器人策略的输入。这种配对的目的有两个：首先，利用已经标注并收集的机器人轨迹数据集；其次，确保机器人能够在不同环境中模仿相同任务。（2）事后人类-机器人：这里，我们使用机器人轨迹数据集中的任务指令，请一到五名人类参与者执行该任务，并从机器人的视角录制演示视频。指令与之前相同，但由于不同人类用左手或右手执行任务，且机器人摄像头角度随机，存在显著的具身和速度差异。这为我们提供了大量配对数据，用于利用机器人数据集中已有的指令训练策略，而无需收集新的机器人轨迹。

（3）共处人类-机器人：在这种情况下，人类和机器人在同一工作空间中执行相同任务。我们使用这种方法在多样化的空间中收集人类演示和机器人轨迹，例如带沙发的起居空间、带白板的会议室、带玩具工具的硬件工作站、带台面、冰箱和水槽的厨房、储物用品区等。

我们在图 2 中展示了来自三个数据集的提示视频和机器人演示的配对视频示例。可以看出，在事后人类-机器人和共处人类-机器人数据集中，背景和干扰物存在相当大的差异。将第一种方法（机器人-机器人）与其他两种人类作为提示视频中行动者的情况进行比较时，会出现不同的复杂度。第一种方法中的行动者是具有相同形态的机器人。每种来源代表不同的难度级别和收集时间。配对现有机器人数据集不需要额外的数据收集，但不涉及任何人类演示。我们的

Dataset Name	Prompt Video Embodiment	Prompt v/s Robot Scene	Prompt Video					Robot Video				
Robot-Robot	Robot	Different										
Hindsight Human-Robot	Human	Different										
Co-located Human-Robot	Human	Same										

图 2：数据集构建。（顶行）此处展示将蛋白棒放入顶层抽屉的机器人-机器人视频对。我们以类似方式将执行相同任务的现有机器人-机器人视频进行配对。（中间行）此处展示事后人类-机器人配对视频，任务为从底层抽屉取出可乐罐并放置到台面上。我们利用机器人轨迹中的任务指令，要求人类参与者执行该任务，并从机器人视角录制演示视频。（底行）此处展示将管钳放入工具箱的同址人类-机器人视频对。我们在同一工作空间中录制人类演示和机器人遥操作。我们使用不同工作空间执行相同任务指令，从而收集到具有视觉多样性提示和机器人状态观测的配对视频。更多细节见第 II-B 节。

第二类数据涉及让人类模仿现有机器人轨迹。事后人类视频使数据收集更加容易，因为无需机器人遥操作数据。然而，这并未增加数据集中任务的多样性。最后，我们在同一环境中收集人类和机器人的数据。虽然收集同址配对数据被认为是黄金标准，但与前两种方法相比，它非常耗时且劳动密集。因此，它仅占我们整体训练集的一小部分。合并所有数据集后，我们拥有 ~ 10 万个机器人视频和 ~ 1 万个人类视频，覆盖了 RT-1[8] 和 RT-2[9] 中引入的任务。机器人-机器人数据集占整个数据集的 90% 以上。该数据集已公开 [35]。我们在补充材料中提供了一个 Python 笔记本，用于可视化训练中使用的配对视频。

C. 模型架构

我们的策略以提示视频和当前机器人状态作为输入，输出机器人动作。该策略由四个模块组成：（1）提示视频编码器，（2）机器人状态编码器，（3）状态-提示编码器，以及（4）机器人动作解码器。整体架构如图 3 所示，各模块详述如下：

（1）提示视频编码器对作为参考提供的视频演示进行编码，以传达期望的任务语义。提示视频编码器隐式地学习推断要执行什么任务以及如何执行。提示编码器由逐帧图像编码器 ϕ_p (ViT [15]) 和随后的感知器重采样器 [1, 20] ψ_p 组成。提示编码器的输出 $\psi_p(\phi_p(V)) = z_{prompt}$ 是一组 N 个 d 维标记，用于以视频中的任务相关属性为条件来调节策略。（2）机器人状态编码器以当前帧和最后 k 帧作为输入，对机器人的当前状态进行编码。注意，该模块还编码机器人可见的物体和环境信息。其架构与提示编码器类似：逐帧图像编码器

ϕ_s 后接感知重采样器 ψ_s 。与提示编码器的输出相同，状态编码器的输出是 $\psi_s(\phi_s(S_t)) = z_{state}$ ，它编码了来自近期观测历史的潜在环境和机器人状态信息。我们对（1）和（2）使用相同的图像编码器权重，即 $\phi_p = \phi_s = \phi$ 。图像编码器 ϕ 的作用是捕获每一帧中的空间视觉信息。感知重采样器实现了跨帧的时间学习，并减少了传入动作解码器的视频令牌数量。

（3）状态-提示编码器接收提示视频编码 z_{prompt} 和机器人状态编码 z_{state} ，并输出与动作预测相关的任务编码，我们称之为提示感知状态令牌 $z_{state|prompt}$ 。这里，状态编码充当查询，提示视频编码充当键和值。直观上，状态-提示编码器实现了状态与提示信息的融合。假设提示视频展示了从篮子里拿起一个苹果，而当前状态包含一个苹果、一根香蕉和一个橙子。状态-提示编码器进行交叉注意力，并根据提示视频学习在状态中关注哪个对象。捕获提示与状态之间的相互依赖关系对于下一步的动作解码至关重要。（4）机器人动作解码器预测当前状态 S_t 的动作向量 a_t ，以完成提示视频 V_p 中展示的任务。动作解码器是一个变换器解码器架构，使用固定的动作位置令牌 [53] 作为输入查询，并使用提示感知状态令牌 $z_{state|prompt}$ 作为键和值。动作位置嵌入的大小为 $N \times d$ ，其中 N 是动作维度的数量， d 是变换器嵌入维度。关于动作向量的更多细节见第 II-D 节。动作位置嵌入与提示感知状态令牌进行交叉注意力，以预测目标分箱动作值作为输出。动作解码器的每个输出令牌对应模式、手臂和基座的一个动作维度。我们将每个令牌嵌入投影到 256 维，并在顶部应用 Softmax 函数以获得对应的分箱。




图 3：架构。我们的模型以提示视频和机器人当前观测作为输入，将其编码为提示视频和机器人状态的令牌嵌入，通过交叉注意力生成状态-提示编码，并将其转换为当前时间步的期望机器人动作。更多细节见第 II-C 节。

到目标动作向量。与先前使用自回归动作解码、在推理时需要多次前向传播的工作 [8, 9] 不同，我们像 ACT[53] 中那样使用动作位置嵌入进行单次前向传播预测。我们没有预测下一时间步的单个动作，而是遵循 [22, 53] 中概述的方法，以四个步骤的预测范围训练策略。我们始终使用概率最高的动作区间，即对预测概率取最大值，来选择用于执行的动作值。交叉注意力层。在 Vid2Robot 架构中，我们在以下模块中广泛使用交叉注意力变换器层：提示重采样器、状态重采样器、状态-提示编码器和动作解码器。与处理相同视频需要更多内存的标准自注意力层相比，交叉注意力层有助于管理处理提示和机器人状态视频时的大量标记以及由此产生的大型注意力矩阵。例如，当使用 ViT-B/16 时，在 224×224 分辨率下，16 帧参考视频和 8 帧机器人状态视频的视频标记总数为

$8 \times 196 + 16 \times 196 = 4704$ 。完整的自注意力操作将产生具有 $4704^2 \sim 22M$ 个条目的注意力矩阵。然而，使用两个具有 64 个潜在标记的感知器重采样器，我们训练的注意力矩阵大小为 $8 \times 196 \times 64 + 16 \times 196 \times 64 \sim .3M$ 。因此，Vid2Robot 中的交叉注意力层减少了注意力计算，并支持使用配对视频进行训练。

D. 预处理

为了高效训练不同长度的视频，我们随机采样 $N=16$ 帧。我们始终包含第一帧和最后一帧，并按时间递增顺序排序。在训练期间，我们通过采样随机时间步来采样机器人状态 S_t 。然后我们选择之前的 $k-1$ 帧，以创建总共包含之前 $k=8$ 帧的机器人状态视频。如果当前时间步之前的帧数少于 $k-1$ ，我们重复第一帧以创建固定大小的机器人状态视频。我们将每帧的像素值归一化到 0 和 1 之间，并将每帧调整为 $(224, 224)$ 。在训练期间，

我们应用光度失真，如裁剪、亮度、对比度、色相和饱和度。该时刻的动作由三个分量组成：模式： (m) 是否终止回合、仅移动手臂、仅移动基座或两者都移动。手臂：夹爪位置 (x, y, z) 、方向（沿 xy 、 yz 、 zx 的旋转）以及闭合程度 (c) 。基座：位移 (x, y) 和旋转。总体而言，动作是一个 11 维向量。每个值的取值范围不同，我们首先将其缩放到 0 到 1 之间。进一步将值离散化为 256 个区间。在本研究中，我们训练和评估基座保持静止的场景。

E. 训练

(1) 动作预测损失。我们使用行为克隆端到端地训练 Vid2Robot。对离散化为 $N=256$ 个区间的动作使用分类损失。给定执行任务的机器人轨迹及当前视觉观测 x_t ，我们有对应的专家动作 a_t 。动作预测损失为预测动作与专家动作之间的交叉熵： $L_{CE}(a_t, \hat{a}_t) = \sum_{\tau} a_t \log \hat{a}_t$ 。该损失训练所有模型参数，如图 3 所示。尽管我们的数据集规模可观，但不足以训练大型基于变换器的模型。为防止在训练集上过拟合，我们添加三个辅助损失以鼓励学习提示视频中的特征。(2) 视频对齐损失：我们希望鼓励提示视频与执行相同任务的机器人视频之间的时间对齐。通过将提示视频与机器人视频对齐，我们希望图像编码器学习对不同实施例、光照、背景、视角和干扰物体保持不变，同时仍编码与预测任务进度相关的特征。我们选择的损失是 [18] 中引入的时间循环一致性损失。当在不同智能体执行相同任务的视频上训练时，该损失可以编码任务进度 [51]。该损失在训练期间应用于提示 V_p 和机器人 V_r 视频的逐帧图像嵌入。为应用该损失，我们对逐帧




图 4：训练设置。我们展示了用于训练 Vid2Robot 的所有损失，特别是每个损失如何连接到其不同模块。除了（1）主要的动作预测损失外，我们还应用了三个辅助损失：（2）时间视频对齐损失，（3）执行相同任务的提示视频与机器人视频之间的对比损失，以及（4）提示/机器人视频与语言嵌入之间的对比损失。更多细节见第 II-E 节。

从图像编码器输出的空间维度嵌入 ϕ ，并应用一个 2 层多层感知机（MLP）的投影头 [11]。我们将此称为逐帧图像嵌入上的对齐池化层 Φ ，如图 4 所示。对于每个视频 V_i ，这会产生一个嵌入序列 $E_i = \{\Phi(v_i^1), \Phi(v_i^2), \dots, \Phi(v_i^{L_i})\}$ ，其中 L_i 是该 i^{th} 视频中的帧数。我们分别对提示视频和机器人视频的编码 E_p 和 E_r 应用时间循环一致性（TCC）损失。直观上，TCC 损失确保 E_p 的每一帧表示应对应于 E_r ，反之亦然。在 Vid2Robot 中应用 TCC 涉及两个步骤：首先，我们计算 E_p (E_p^t (简称) 中 t^{th} 帧在 E_r 中的软邻居，并称之为 E_{pr}^t 。

$$\widehat{E_{pr}^t} = \sum_k \alpha_k E_r^k, \quad \text{where} \quad \alpha_k = \frac{e^{-\|E_i^t - E_j^k\|^2}}{\sum_k e^{-\|E_i^t - E_j^k\|^2}} \quad (1)$$

其次，我们在 E_p 中为这个新计算的软邻居找到对应帧。这在 [18] 中称为循环回传，它涉及与方程 1 类似的软邻居计算，以获得 E_{pr}^t ，理想情况下应与 t 相同，即 $(E_{pr}^t - t)^2$ 应被最小化。TCC 损失最小化提示视频和机器人视频编码之间所有帧的这种均方误差，反之亦然，即

$$L_{TCC}(E_p, E_r) = \sum_{t \in V_p} (\widehat{E_{pr}^t} - t)^2 \quad (2)$$

$$L_{TCC} = \frac{L_{TCC}(E_p, E_r) + L_{TCC}(E_r, E_p)}{2}$$

（3）提示-机器人视频对比损失（VVCL）：我们希望以自监督的方式鼓励提示编码从视频标记中学习任务语义。虽然我们使用自然语言将提示与机器人视频配对，但这并不

有效捕捉低级动作的视觉相似性，例如伸手抓取物体和旋转机器人手臂。为此，我们在机器人和提示视频的潜在特征之间应用对比损失。我们使用注意力池化层来合并 N 提示标记的特征，为每个视频生成单一嵌入。我们在视频对之间应用 SigLIP [52] 损失，以鼓励展示相同任务、涉及相似动作和交互物体的视频彼此靠近，同时远离批次中的其他视频。一个批次包含相同数量的机器人和提示视频，假设为 B 。我们使用提示编码器 $\psi_p(\phi(\cdot))$ 获得一批完整的机器人视频嵌入 Z_{robot} 和提示视频嵌入 Z_{prompt} ，每个大小为 $B \times d$ 。我们将它们相乘， $Z_{robot} \cdot Z_{prompt}^T$ 得到一个 $B \times B$ 矩阵。添加可学习的温度 τ 和偏差 b ，我们的 logit 矩阵为 $\hat{Y} = (Z_{robot} \cdot Z_{prompt}^T) * \tau + b$ 。我们将执行相同任务的机器人和提示视频视为正样本，沿对角线赋予标签 1，非对角线对赋予 -1，即标签矩阵 $Y = 2I_B - 1$ 。SigLIP 损失是负对数似然 $\sigma'(Z_1, Z_2) = -\sum \log \sigma(Y \cdot (Z_1 \cdot Z_2^T) * t + b)$ 。视频-视频对比损失如下：

$$L_{VVCL} = \sigma'(Z_{prompt}, Z_{robot}) \quad (3)$$

（4）视频-文本对比损失（VTCL）：我们希望鼓励嵌入空间的一部分能够感知物体名称和动词，如提示和机器人视频中所示。我们在机器人视频产生的提示标记与任务的文本指令之间应用对比损失。该损失的一个版本此前已被 BC-Z [22] 用作辅助语言回归损失。我们使用带有一个潜在查询的注意力池化层 [50] 来合并特征

从 N 提示标记中为每个视频生成单一嵌入。我们检索 B 对视频和文本嵌入作为一个批次。与方程 3 类似，我们应用 SigLIP [52] 损失作为 L_{VTCL} ，以鼓励每个视频与其文本描述嵌入具有相似的嵌入，并与批次中的其他文本嵌入不同。

$$L_{VTCL} = (\sigma'(Z_{prompt}, Z_{text}) + \sigma'(Z_{robot}, Z_{text}))/2 \quad (4)$$

总体而言，我们应用所有四个损失的均值进行训练
即 $L = \frac{1}{4}(L_{CE} + L_{TCC} + L_{VVCL} + L_{VTCL})$ 。

F. 实现

我们训练了模型（在 Jax 中实现）200K 次迭代。我们使用 AdamW 优化器，初始学习率为 $8e-5$ ，采用余弦学习率调度，预热步数为 2,000，最终学习率为 $1e-6$ 。我们为提示和状态重采样器均使用 2 个 Perceiver Resampler 层，具有 64 个潜在标记。状态-提示编码器和动作解码器均为 4 层深的交叉注意力变换器。

三、实验

本文展示了多任务视频条件策略在真实机器人评估中的结果。本研究要解决的一个基本问题是：机器人能在多大程度上模仿人类执行操作任务。由于具身形态的差异，人类执行操作任务的速度和风格与机器人不同。我们研究了使用机器人视频和人类视频作为提示的效果。

评估指标。一次执行（rollout）是指策略从初始状态观测开始推断并执行动作序列，直到策略终止或达到最大步数（以先到者为准）。当策略按照提示视频所示完成指令任务时，我们判定该次执行为成功。一次成功的执行需要在环境中连续采取正确动作，且无需任何重置或恢复辅助。我们请人类评估者观察以下问题：（1）机器人是否到达了正确位置？（2）是否抓取了正确物体？（3）是否在正确位置释放了物体？以及

（4）是否正确终止了任务？如果任一问题的答案为“否”，则后续问题的答案也视为“否”。只有当所有问题都回答“是”时，该次执行才被视为“成功”。对于每个任务指令，我们在不同干扰物、背景和光照条件下为每个策略记录若干次执行。我们取该任务所有执行的平均成功率，称为该任务的成功率。同时报告跨任务聚合成功率作为总体成功率。我们还分析了第三节 A 部分中四个里程碑的部分成功情况。我们曾尝试用具体标准或决策规则来自动化成功判定，但发现这种自动化可能忽略任务执行过程。

考虑“打翻水瓶”这一任务。情况 1：机器人成功抓取瓶子，将其翻转并放置在桌面上。情况 2：机器人未能抓取，夹住瓶子

甩开，最终呈现被打翻的姿态。情况 1 符合训练数据中的期望行为，而情况 2 属于非预期失败。若仅基于最终状态的规则验证，我们会将情况 1 和情况 2 都判定为成功。借助人类评估者，我们关注的是完成任务的整个过程，而非仅最终状态。

实验设置。我们通过改变物体摆放位置、光照条件、背景表面和干扰物体来评估策略。在评估一组策略时，我们确保各次执行具有可比的初始物体配置。只有在所有策略的执行完成后，我们才随机化初始状态。对于所有执行，我们采样训练期间未见过的提示视频。在所有实验中，我们使用移动机械臂——谷歌机器人（Google Robot）。它配备自我中心视角摄像头、七自由度单臂和两指软夹爪。更多细节参见 [8]。

基线。我们将模型与 BC-Z[22] 进行比较，后者是一种使用 ResNet-18 编码器的视频条件策略。BC-Z[23] 通过 FiLM[38] 条件化的 ResNet 编码器处理演示-观测对，并输入基于 ResNet 的策略网络以预测机器人动作。我们使用相同数据训练 BC-Z 和 Vid2Robot，以确保公平比较。BC-Z 没有终止动作，因此我们以固定的最大步数运行这些执行。

关键问题与结果。本文解决以下问题：（1）跨任务中提示具身（机器人对比人类）导致的成功率差距是多少？（§ III-A1）（2）视频条件策略在未见任务视频上的表现如何？（图 5，§ III-A2）（3）Vid2Robot 的总体成功率是否显著优于 BC-Z 基线？（§ III-B）（4）学习到的运动表示能否处理分布外物体交互？（§ III-C）

A. 基于任务的成功率

我们在表 I 中比较了 Vid2Robot 模型与基线 BC-Z 在机器人和人类执行的提示视频上的表现。我们在相同的数据混合上训练 Vid2Robot 和 BC-Z，该混合包含机器人-机器人和人类-机器人配对数据。提示视频覆盖了训练任务的一个子集，但这些视频对模型来说是未见过的。在此评估中，我们考察每个模型从提示视频以及机器人当前观察状态推断任务规范的能力。为了在真实机器人上测试模型在不同设置下的能力，我们评估了以下九个任务的执行情况：‘打翻水瓶’、‘将 rxbar 巧克力移到可乐罐附近’、‘将绿色 jalapeno 薯片袋移到可乐罐附近’、‘拿起绿色米饼袋’、‘将可乐罐竖直放置’、‘从底层抽屉拿起可乐罐并放到台面上’、‘打开中间抽屉’、‘关闭中间抽屉’、‘将苹果放入顶层抽屉’。我们请四位评估员对每个任务进行两次执行，针对一个提示视频数据集和策略设置（表 I 中的一行）。总体而言，每个任务有八次试验来评估策略的任务成功率。我们报告每行在九个任务上的总体成功率，每个任务八次试验，即 $9 \times 8 = 72$ 次试验。表 I 总共需要 $72 \times 4 = 288$ 次执行。




图 5：策略执行。每行左侧显示人类执行任务的提示视频，右侧显示使用 Vid2Robot 对应的成功机器人执行。注意提示视频在视觉上的差异，而策略执行具有不同的光照和背景，以及干扰物体的数量和位置。

表 1：机器人和人类提示的任务成功率。

Prompter	Model	<i>pick</i>	<i>pick-place on</i>	<i>place into</i>	<i>open</i>	<i>close</i>	<i>move near</i>	<i>knock over</i>	<i>place upright</i>	Overall
Robot	BC-Z	75.0%	50.0%	61.5%	16.7%	66.7%	44.0%	58.3%	50.0%	52.6%
	Vid2Robot	75.0%	58.8%	50.0%	91.7%	100.0%	33.3%	41.7%	16.7%	54.9%
Human	BC-Z	50.0%	12.5%	12.5%	0.0%	50.0%	43.8%	12.5%	50.0%	30.6%
	Vid2Robot	100.0%	50.0%	50.0%	62.5%	87.5%	43.8%	25.0%	12.5%	52.8%

1) 由于提示视频中的体现差异导致的成功率差距是什么？：当使用机器人和人类视频提示时，我们将我们的模型与 BC-Z 进行比较，BC-Z 是我们比较的强基线。我们的模型 Vid2Robot 在人类提示视频上的总体成功率比 BC-Z 高出 20%，在机器人提示视频上则相当。

请注意，在我们的训练混合数据中，机器人轨迹的训练样本数量比人类视频多一个数量级。因此，对于机器人提示视频，性能上没有显著差距。在大多数任务中，我们的模型在人类提示视频上优于 BC-Z，表明 Vid2Robot 比基线更好地捕捉了提示视频中的任务语义。在从抽屉中取物、将其放在台面上以及开关抽屉等任务上，我们的模型大幅领先。最具挑战性的任务是竖直放置和推倒。我们在 § V 图 9 中分析了失败原因。

将一次执行过程视为成功，我们记录了每次执行过程中的部分成功标注。在图 6 中，我们观察到我们的模型到达正确物体的比例为 78%，比基线高出约 8%。策略有时无法到达正确物体，而是走向干扰物。接下来，抓取错误时有发生，尤其是对于小型和可变形成物体以及易发生碰撞的区域，如抽屉把手或台面边缘。在此，我们的模型（65%）大幅超越 BC-Z（45%），领先 20 个百分点——成功抓取往往是执行过程中最具挑战性的部分，对成功至关重要。抓取之后，大多数任务要求在正确位置释放物体。在执行过程中，由于释放位置不正确，两种模型的成功率均略有下降。BC-Z 运行固定步数，而我们的策略 Vid2Robot 预测何时终止。我们观察到释放和终止的比例几乎相同，约为 57%，这意味着在正确位置释放后，Vid2Robot 大多能成功终止。

2) 当在未见过的视频中展示任务时，视频条件策略的表现如何？：此外，在标记一个




图 6: BC-Z 与 Vid2Robot 的部分成功率。本文策略 Vid2Robot 在到达正确物体、抓取、在正确位置释放以及正确终止回合方面均优于 BC-Z。注意 BC-Z 不具备终止控制。

表 II: Vid2Robot 与 BC-Z 的真实机器人评估，通过更多试验以确定结果的统计显著性。

Model	place coke can upright	close middle drawer	Overall
BC-Z	19.4 ± 9.5%	39.2 ± 10.8%	30.2 ± 7.1%
Vid2Robot	39.1 ± 9.9%	48.7 ± 11.2%	43.4 ± 7.2%

B. 具有更多展开次数的任务

为评估结果的统计显著性，我们进行了更多试验，同时将评估限定于两项任务，即“将可乐罐竖直放置”和“关闭中间抽屉”，用于真实机器人策略评估，并报告了带置信区间的平均成功率。我们总共进行了 314 次真实机器人执行，结果见表二。

C. 跨物体运动迁移 我们使用第二节 B 部分讨论的配对视频训练了 Vid2Robot 和基线模型。由于配对关系，训练数据仅包含提示视频中所交互物体出现在当前机器人观测中的场景。但如果提供某一物体的提示视频，并在其他物体上进行测试呢？模型是否会做出与提示视频中相同的运动？有趣的是，我们发现模型能够对提示视频中未出现的物体执行已学习的操作动作。我们将这种涌现行为称为跨物体运动迁移。我们使用五个提示视频比较了 Vid2Robot 与 BC-Z 的跨物体运动迁移能力，即“打翻水瓶”、“拿起绿色米饼袋”、“将可乐罐竖直放置”、“从底部抽屉拿起可乐罐并放在台面上”以及“将苹果放入顶部抽屉”。我们通过在机器人初始观测中放置无关物体来评估每个提示视频的情况。用于评估的物体包括“橙子”、“绿色罐子”、“薯片袋”、“香蕉”、“粉色小猪毛绒玩具”和“手表”。我们选择了形状、大小和可变形性各异的物体，以评估需要不同抓取方式才能成功的情况。评估设置与第三节 A 部分类似。此处，评估者为任务设置其中一个物体并记录




图 7: 跨物体运动迁移的定性结果。（顶部蓝色）将可乐罐竖直放置的提示视频；（绿色）在机器人前方放置绿色罐子、薯片袋、订书机和毛绒玩具时的策略执行。Vid2Robot 推断出提示视频中竖直放置的运动，并将其应用于其他物体。策略遵循提示视频，选择拿起绿色罐子而不是薯片袋或香蕉。

每个模型的展开。我们在五个任务上比较两个模型，每个任务包含六个物体，因此每个评估器运行 $2 \times 5 \times 6 = 60$ 次展开。我们用四位评分者重复评估，因此在表 III 中报告基于 $4 \times 60 = 240$ 次展开的结果。在图 7 中，我们定性展示了上述实验设置。我们使用提示视频“将可乐罐竖直放置”，并观察到策略能够将“竖直放置”的动作迁移到其他物体上，如绿色罐子、薯片袋、订书机和毛绒玩具。该策略通过选择绿色罐子而非其他物体，表现出对所学语用学的隐式理解。在表 III 中，我们观察到 BC-Z 在测试跨物体动作迁移时通常无法完成任务。相比之下，我们的模型（34%）在此设置下表现优于 BC-Z（17%），并执行了提示视频中指示的动作。我们的模型在抓取分布外物体上的成功率为 45%，与 BC-Z 相当。更重要的是，涉及将物体放入抽屉的任务显示出显著改进（29% → 54%）。对于从抽屉中取出、放置在台面上和推倒等特定任务，Vid2Robot 完成任务的时间占比为 25%–29%，而 BC-Z 无法执行。

表 III: 跨物体动作迁移成功率。

Model	<i>pick</i>	<i>pick- place on</i>	<i>place into</i>	<i>place upright</i>	<i>knock over</i>	Overall
BC-Z	45.8%	0.0%	29.2%	12.5%	0.0%	17.5%
Vid2Robot	45.8%	25.0%	54.2%	16.7%	29.2%	34.2%

D. 消融研究

我们分析了所提出的方法，以理解以下问题：（a）策略能否仅从状态观测中学习与环境的可能交互，而无需提示视频？

（b）辅助损失函数如何影响模型性能？1）提示对任务推理的影响是什么？：首先，我们通过一个示例来说明提示视频的重要性。考虑机器人状态观测中台面上有一个可乐罐和其他物体。如果机器人视野中存在可乐罐，则很难推断任务是“拿起可乐罐”、“将可乐罐移近巧克力棒”、“将可乐罐移近橙色罐”还是“撞倒可乐罐”。此外，一旦机器人开始采取行动，它可能进入新状态，例如靠近能量棒，这使得仅从当前状态预测任务尤为困难。下面，我们通过实验测量无法获得合适提示视频的策略的成功率。我们评估了“无提示”情况，即两个模型都将空白帧作为输入提示视频。在此设置下，我们评估了三个任务。对于每个任务，我们执行策略 20 次。本实验总共进行了 $2 \times 20 \times 3 = 120$ 次真实机器人执行。在此情况下，Vid2Robot 的成功率为 23%，BC-Z 为 5%，每个策略每个任务执行 20 次。我们发现，当策略以提示视频为条件时，性能有所提升。BC-Z 的成功率从 5% 提高到 52.6%，Vid2Robot 从 23% 提高到 54.6%（参见表一）。该实验强调了提示视频对任务成功的重要性。2）辅助损失的作用是什么？：其次，我们分析了额外损失函数对整体成功率的作用。在第二节 E 部分，我们提出了动作预测损失和三个辅助损失。我们研究了（1）不使用任何辅助损失和（2）添加辅助语言损失的影响。我们考虑与第三节 A 部分描述类似的任务，每个策略评估 9 个任务。我们有 3 个模型变体：原始 Vid2Robot、无视频-文本对比损失（CL）的变体以及仅使用动作预测损失的变体。我们请三位人类评估者分别对每个模型变体进行两次执行。总共，我们在图 8 中报告了 $3 \times 3 \times 9 \times 2 = 162$ 次执行的结果。误差条表示成功率的标准差。不使用任何辅助损失的影响是什么？我们观察到，与仅使用动作预测损失（45%）相比，通过辅助损失施加表示约束，我们的模型性能（61%）显著提升。这凸显了第二节 E 部分所提出的辅助损失的重要性。




图 8: Vid2Robot 中辅助损失的消融实验。我们将所提出的包含全部辅助损失的方法（绿色，左）与 BC-Z 最初提出的无语言对比损失的变体（橙色，中）以及无任何辅助损失的版本（蓝色，右）进行比较。更多细节见（§ III-D）

辅助语言损失的影响是什么？BC-Z 提出利用语言表示来改进视频表示，以条件化策略。我们将策略与另一个使用除视频-文本对比学习（Video-Text CL）外所有损失训练的变体进行比较。观察到使用语言损失时成功率仅有 1-2% 的边际提升。这表明视频对齐和视频对比损失对性能提升贡献显著。

四、相关工作

A. 机器人的任务指定

通用机器人的发展关键在于有效地将任务规范落地。视频是一种密集的信息来源，提供了在物理世界中做什么以及如何做的信息。近期工作已使用视频进行任务指定 [4, 24, 42]。另一条研究路线利用视频学习世界模型（World Model）以预测未来视觉观测 [31, 28, 10, 33, 16]。回顾 § I 中“打开抽屉”、“打开柜子”和“打开罐子”的例子。像 Vid2Robot 这样的视频条件策略能够完成这些任务，因为这些策略从视觉中识别出“打开罐子”和“打开抽屉”的任务，而语言条件策略对每个任务都有相同的动词“打开”嵌入。注意，语言不是 Vid2Robot 的输入。因此，动词不会直接影响动作；这是 Vid2Robot 与现有语言条件机器人策略之间的关键区别。虽然语言 [49, 8, 35, 36]、最终目标图像 [25, 7] 以及其他如手绘输入 [45] 已被提出作为任务指定的手段，但从提示视频中学习与这些方法互补，并且对于训练好的策略在部署时快速适应新操作技能是不可避免的。

B. 从人类示范中学习

随着互联网上人类执行各种任务的视频激增，多项工作致力于解决如何利用这些信息进行机器人学习。机器人与人类具身之间的差异构成了重大挑战，现有方法从将人类图像转换为机器人 [44] 到为智能体无关进行图像修复




图 9：基于策略推演的失败分析。（上）策略预测夹爪姿态，并依赖逆运动学求解器移动机械臂。有时，逆运动学解会遮挡机器人相机视野。（中）抓取失败时有发生，尤其是对于透明和可变形物体。（下）干扰物体以及光照和背景差异可能导致识别错误，此时策略可能执行了正确动作，但针对的是错误物体。

表示 [3]。许多先前工作提出利用现成模型进行手部姿态估计和接触跟踪 [5, 13, 39]、以物体为中心的表示 [40, 21]，以及强化学习的奖励函数 [3, 29, 44]。XIRL[51]、GraphIRL[26] 及其他强化学习方法 [41, 37] 在策略学习阶段需要大量时间和人工来重置场景，限制了它们在真实机器人上的适用性。此外，强化学习在真实机器人上常导致不安全情况。我们将 Vid2Robot 与另一种端到端行为克隆方法 BC-Z 进行比较，后者已被证明可扩展到多个任务。其他方法 [34, 47, 5] 将该问题转化为视觉表示学习，以加速下游运动控制任务的学习。虽然这些模块化学习方案在有限数据集上表现良好，但每个组件都容易产生复合误差，且无法高效扩展。面向目标条件模仿学习的端到端训练方法 [12, 43, 19, 14] 也大多局限于仿真，并受仿真到现实差距的阻碍。相比之下，我们将此问题视为从人类视频中进行端到端大规模多任务学习，并在真实机器人上进行评估。

C. 基于成对演示的模仿

我们的成对提示视频与机器人轨迹的设置与一次性视觉模仿文献最为相似。许多先前工作假设可以获取成对数据，其中第一个视频演示任务，第二个视频展示智能体的视觉观察。一些早期工作 [17] 提出通过时间卷积和邻域注意力训练演示网络，以条件化操作策略网络。在更近期的方法中，如 [12, 30, 21]，成对演示和观察被用于训练变换器策略，通常还附加逆动力学等额外约束。

ics 预测 [12] 或对比表示学习 [30]。MimicPlay[46] 提出利用人类和机器人遥操作演示的分层学习框架。然而，评估这些方法通常局限于特定任务集，且两个视频之间背景没有任何变化。BC-Z[22] 与我们的工作最为相似，其报告了真实机器人评估结果。虽然我们的训练设置与 BC-Z 有相似之处，但我们的模型 Vid2Robot 结合了大型图像编码器、交叉注意力层和对比辅助损失，以学习模仿人类展示任务的操控策略。近期自监督技能发现方法如 XSkill[48] 从不成对的人类和机器人视频中学习技能，而我们的方法利用任务的文本描述将它们显式配对。配对

的人类和机器人视频包含不同的背景、光照和物体排列，从而训练视觉表示对这些设置保持不变，并专注于任务语义。

五、局限性与未来方向

在第三节中，我们表明本文方法相较于先前工作有所改进，但在视频条件策略方面仍存在性能差距。下文将讨论本研究的局限性，并为未来工作提供洞见。首先，我们定性分析了策略执行失败的部分原因。在图 9 中，我们展示并解释了三个示例，说明自遮挡、抓取错误以及干扰物的存在如何导致执行过程中的失败。其次，我们观察到图 6 中抓取成功率显著下降。尽管我们利用机器人相机观测来估计状态并隐式学习深度估计，但当发生遮挡或机器人夹爪超出视野时，该估计往往不完整。

相机视角。通过多模态传感器融合增强状态信息，有望提升抓取成功率。第三，我们考虑了来自三个不同来源的、精心采集的短任务指令演示，如第 II-B 节所示，均为 5 至 20 秒的视频。为了在长时程演示或在线“野外”视频上测试我们的模型，我们需要有效的配对策略，将视频与少量对应的机器人轨迹配对，以训练策略。

六、结论

本文提出 Vid2Robot，一种端到端的视频条件机器人策略。所提系统在成对视频上进行训练，这些视频展示相同任务，但在光照、背景和干扰物等设置上存在差异。本文利用交叉注意力（cross-attention）（i）从提示和状态编码中学习联合潜在表示，然后（ii）解码动作。本文以交叉熵损失和三个辅助损失训练整个模型进行动作预测，这些辅助损失鼓励学习可泛化的潜在表示，从而直接从原始像素推断任务并生成合适动作。当以人类视频作为提示时，Vid2Robot 的性能比 BC-Z 高出 $\sim 20\%$ 以上。此外，在跨物体运动迁移方面，Vid2Robot 的性能比 BC-Z 高出 $\sim 17\%$ ；也就是说，如果提示视频中的物体与机器人当前操作的物体不完全相同，模型仍能为相同动词但不同物体生成有效动作。跨物体运动迁移是将运动迁移学习进一步推广到新物体的一个有前景的方向。本文希望 Vid2Robot 能够实现数据采集的自举以及人机交互中对新技能的快速适应。

致谢

感谢 Yansong Pang、Grecia Salazar、Utsav Malla、Deeksha Manjunath、Jornell Quiambao、Sarah Nguyen、Sangeetha Ramesh、Tran Pham、Samuel Wan、Tomas Jackson、Jodilyn Peralta、Celeste Barajas、Elio Prado、Rochelle Dela Cruz、Alex Luong 和 Krista Reymann 通过遥操作支持数据采集。特别感谢 Jornell Quiambao、Grecia Salazar、Utsav Malla、Deeksha Manjunath、Sarah Nguyen、Sangeetha Ramesh 和 Jaspiar Singh 在机器人上进行评估；感谢 Michael Ahn、Anthony Brohan 和 Keerthana Gopalakrishnan 提供策略评估基础设施；感谢 Suneel Belkhale、Dorsa Sadigh、Chelsea Finn 和 Sergey Levine 进行有益的讨论；感谢 Jonathan Tompson 和 Vincent Vanhouke 对写作提供详尽的反馈。本工作由第一作者在 Google DeepMind Robotics 实习期间完成。本工作还部分由 Google 的无限制捐赠以及国防高级研究计划局（DARPA）根据协议编号 HR00112490375 提供资助。

附录

在补充材料提供的视频中，我们展示了若干成功执行的示例，以及带有提示视频和机器人观测的模型架构。我们

提供基于任务的成功案例以及跨物体运动迁移的具体示例。此外，我们展示了长时程任务组合的定性结果，以及训练数据集中罕见任务的执行过程。最后，我们展示了已知失败案例的执行过程，例如自遮挡、抓取错误以及提示视频中任务解读的歧义。我们将发布模型代码和训练好的检查点。在表四中，我们展示了 Vid2Robot 模型架构的详细版本。在表五中，我们展示了训练时使用的超参数。我们还根据表六中的设置在训练时对视频进行了数据增强。我们按照预训练 ViT 模型的要求对视频进行了归一化处理。我们从三个来源构建了数据集混合。我们收集了 12 万条机器人轨迹、5 千条人类轨迹以及 5 千条人类与机器人共置轨迹。为了创建配对，我们为每条机器人轨迹采样了 3 个视频作为提示。这为机器人-机器人数据集生成了 36 万对，为事后人类-机器人数据集生成了约 1.5 万对，为共置人类-机器人数据集生成了 5 千对。为了确保所有配对大致等量采样，我们将混合比例设置为 90% 机器人-机器人、5% 事后人类-机器人和 5% 共置人类-机器人。我们还在训练集中罕见的一些任务上测试了 Vid2Robot，发现视频条件模型也能够完成这些任务。这些任务的一些示例包括：打开玻璃罐、拾取绿色超细纤维布和抽出纸巾。我们在图 10 中展示了示例。这些结果的视频版本请参阅补充视频。在本文的所有实验中，我们使用移动机械臂。这些机器人具有 7 自由度机械臂、两指夹爪和移动底座。由于我们的实验重点是操纵物体，因此我们在每个回合中保持底座固定。我们使用客户端-服务器设置测试策略，其中策略部署为服务器，机器人上的客户端可以查询。机器人头部摄像头的观测记录在客户端，以保持最近 8 帧的历史记录。根据策略的平均响应时间，我们可以以大约 5-7 赫兹的频率执行预测动作。我们展示了 Vid2Robot 可以通过使用多个显示不同任务的提示视频来执行长时程任务。为此，我们将不同的提示视频链接在一起以创建长时程任务。例如，Vid2Robot 可以通过链接 3 个任务的提示视频来提示机器人将桌子上的物体清理到抽屉中：打开抽屉、将桌子上的物体放入抽屉、关闭抽屉。当 Vid2Robot 为当前提示视频输出终止回合时，我们将提示视频更改为下一个子任务，而无需重置机器人。通过这种方式，机器人可以使用 Vid2Robot 完成长时程任务，而无需明确地在长时程视频上进行训练。我们在图 11 中展示了成功示例。机器人完成长时程任务的视频请查看补充材料中的摘要视频。






图 10：稀有任务上的定性结果。



(a) Two step chaining of prompt videos with (1) Open drawer, (2) Place object into it.



(b) Three step chaining of prompt videos. (1) Open drawer, (2) Place object into it, (3) Close drawer.

图 11：展示 Vid2Robot 如何通过链式提示视频执行长程任务的定性结果。

表四: Vid2Robot 的详细架构。

Module	Layer	Output Size	Notes
Prompt Encoder	Input	$16 \times 224 \times 224 \times 3$	Reference Video of 16 frames
	Image Encoder	$16 \times 196 \times 768$	Each frame passes through ViT-B/16
	Reshape	3136×768	Reshapes all space-time tokens to be in one dimension
	Perceiver Resampler	64×768	2 layers with 768 dims and 12 attention heads
State Encoder	Input	$8 \times 224 \times 224 \times 3$	Robot Observation Video of 8 frames
	Image Encoder	$8 \times 196 \times 768$	Each frame passes through ViT-B/16
	Reshape	1568×768	Reshapes all space-time tokens to be in one dimension
	Perceiver Resampler	64×768	2 layers with 768 dims and 12 attention heads
State Prompt Encoder	Cross-attention	64×768	4 layers of cross-attention with 768 dim and 8 attention heads
	Transformer Layer		Uses prompt tokens as keys and state tokens as queries
Action Decoder	Cross-attention	11×768	4 layers of cross-attention with 768 dim and 8 attention heads
	Transformer Layer		Uses prompt-aware state tokens as keys and action position embeddings as queries
Action Head	Linear	11×256	Projection of action decoder output to 256 bins

表五: Vid2Robot 的超参数。

Hyperparameters	Values
批大小	2048
学习率	$8e-5$
优化器	AdamW
训练步数	200,000
预热步数	2000
图像尺寸	224
提示帧数	16
机器人帧数	8
预测范围	4

表六: 用于训练 Vid2Robot 的数据增强。

Hyperparameters	Ranges
Height crop range	(0.95, 1.)
Width crop range	(0.95, 1.)
Brightness range	(0.9, 1.1)
Contrast range	(0.8, 1.2)
Hue range	(0, 0.03)
Saturation range	(0.8, 1.2)

参考文献

[1] Jean-Baptiste Alayrac, Jeff Donahue, Pauline Luc, Antoine Miech, Iain Barr, Yana Hasson, Karel Lenc, Arthur Mensch, Katherine Millican, Malcolm Reynolds, Roman Ring, Eliza Rutherford, Serkan Cabi, Tengda Han, Zhitao Gong, Sina Samangooei, Marianne Monteiro, Jacob Menick, Sebastian Borgeaud, Andrew Brock, Aida Nematzadeh, Sahand Sharifzadeh, Mikolaj Binkowski, Ricardo Barreira, Oriol Vinyals, Andrew Zisserman, and

Karen Simonyan. Flamingo: a visual language model for few-shot learning. In Alice H. Oh, Alekh Agarwal, Danielle Belgrave, and Kyunghyun Cho, editors, *Advances in Neural Information Processing Systems*, 2022. URL <https://openreview.net/forum?id=EbMuimAbPbs>.

[2] Montserrat Gonzalez Arenas, Ted Xiao, Sumeet Singh, Vidhi Jain, Allen Z. Ren, Quan Vuong, Jake Varley, Alexander Herzog, Isabel Leal, Sean Kirmani, Dorsa Sadigh, Vikas Sindhwani, Kanishka Rao, Jacky Liang, and Andy Zeng. How to prompt your robot: A prompt-book for manipulation skills with code as policies. In *2nd Workshop on Language and Robot Learning: Language as Grounding*, 2023. URL <https://openreview.net/forum?id=T8AiZj1QdN>.

[3] Shikhar Bahl, Abhinav Gupta, and Deepak Pathak. Human-to-robot imitation in the wild. In *Robotics Science and Systems (RSS)*, 2022.

[4] Shikhar Bahl, Russell Mendonca, Lili Chen, Unnat Jain, and Deepak Pathak. Affordances from human videos as a versatile representation for robotics. In *Computer Vision and Pattern Recognition*, April 2023.

[5] Shikhar Bahl, Russell Mendonca, Lili Chen, Unnat Jain, and Deepak Pathak. Affordances from human videos as a versatile representation for robotics. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 13778–13790, 2023.

[6] Yonatan Bisk, Rowan Zellers, Ronan Le Bras, Jianfeng Gao, and Yejin Choi. PIQA: Reasoning about Physical Commonsense in Natural Language. In *Thirty-Fourth AAAI Conference on Artificial Intelligence*, 2020. URL <https://yonatanbisk.com/piqa>.

[7] Konstantinos Bousmalis, Giulia Vezzani, Dushyant Rao, Coline Devin, Alex X. Lee, Maria Bauzá, Todor Davchev, Yuxiang Zhou, Agrim Gupta, Akhil S. Raju, Antoine Laurens, Claudio Fantacci, Valentin Dalibard, Martina

- Zambelli, Murilo Fernandes Martins, Rugile Pevceviute, Michiel Blokzijl, Misha Denil, Nathan Batchelor, Thomas Lampe, Emilio Parisotto, Konrad Zolna, Scott E. Reed, Sergio Gomez Colmenarejo, Jonathan Scholz, Abbas Abdolmaleki, Oliver Groth, Jean-Baptiste Regli, Oleg O. Sushkov, Tom Rothorl, José Enrique Chen, Yusuf Aytar, David Barker, Joy Ortiz, Martin A. Riedmiller, Jost Tobias Springenberg, Raia Hadsell, Francesco Nori, and Nicolas Manfred Otto Heess. Robocat: A self-improving generalist agent for robotic manipulation. In *Transactions on Machine Learning Research*, September 2023.
- [8] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Joseph Dabis, Chelsea Finn, Keerthana Gopalakrishnan, Karol Hausman, Alex Herzog, Jasmine Hsu, Julian Ibarz, Brian Ichter, Alex Irpan, Tomas Jackson, Sally Jesmonth, Nikhil J Joshi, Ryan Julian, Dmitry Kalashnikov, Yuheng Kuang, Isabel Leal, Kuang-Huei Lee, Sergey Levine, Yao Lu, Utsav Malla, Deeksha Manjunath, Igor Mordatch, Ofir Nachum, Carolina Parada, Jodilyn Peralta, Emily Perez, Karl Pertsch, Jor-nell Quiambao, Kanishka Rao, Michael Ryoo, Grecia Salazar, Pannag Sanketi, Kevin Sayed, Jaspiar Singh, Sumedh Sontakke, Austin Stone, Clayton Tan, Huong Tran, Vincent Vanhoucke, Steve Vega, Quan Vuong, Fei Xia, Ted Xiao, Peng Xu, Sichun Xu, Tianhe Yu, and Brianna Zitkovich. RT-1: Robotics transformer for Real-World control at scale. In *arXiv preprint arXiv:2212.06817*, December 2022.
- [9] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Xi Chen, Krzysztof Choromanski, Tianli Ding, Danny Driess, Avinava Dubey, Chelsea Finn, Pete Florence, Chuyuan Fu, Montse Gonzalez Arenas, Keerthana Gopalakrishnan, Kehang Han, Karol Hausman, Alex Herzog, Jasmine Hsu, Brian Ichter, Alex Irpan, Nikhil Joshi, Ryan Julian, Dmitry Kalashnikov, Yuheng Kuang, Isabel Leal, Lisa Lee, Tsang-Wei Edward Lee, Sergey Levine, Yao Lu, Henryk Michalewski, Igor Mordatch, Karl Pertsch, Kanishka Rao, Krista Reymann, Michael Ryoo, Grecia Salazar, Pannag Sanketi, Pierre Sermanet, Jaspiar Singh, Anikait Singh, Radu Soricut, Huong Tran, Vincent Vanhoucke, Quan Vuong, Ayzaan Wahid, Stefan Welker, Paul Wohlhart, Jialin Wu, Fei Xia, Ted Xiao, Peng Xu, Sichun Xu, Tianhe Yu, and Brianna Zitkovich. RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control. In *arXiv preprint arXiv:2307.15818*, 2023.
- [10] Elliot Chane-Sane, Cordelia Schmid, and Ivan Laptev. Goal-conditioned reinforcement learning with imagined subgoals. In Marina Meila and Tong Zhang, editors, *Proceedings of the 38th International Conference on Machine Learning*, volume 139 of *Proceedings of Machine Learning Research*, pages 1430–1440. PMLR, 18–24 Jul 2021. URL <https://proceedings.mlr.press/v139/chane-sane21a.html>.
- [11] Ting Chen, Simon Kornblith, Kevin Swersky, Mohammad Norouzi, and Geoffrey E Hinton. Big self-supervised models are strong semi-supervised learners. *Advances in neural information processing systems*, 33: 22243–22255, 2020.
- [12] Sudeep Dasari and Abhinav Gupta. Transformers for one-shot visual imitation. In *Conference on Robot Learning*, pages 2071–2084. PMLR, 2021.
- [13] Eadom Dessalene, Chinmaya Devaraj, Michael Maynard, Cornelia Fermüller, and Yiannis Aloimonos. Forecasting action through contact representations from first person video. *IEEE Trans. Pattern Anal. Mach. Intell.*, 45(6): 6703–6714, June 2023.
- [14] Yiming Ding, Carlos Florensa, Mariano Phielipp, and Pieter Abbeel. Goal-conditioned imitation learning. In *Proceedings of the 33rd International Conference on Neural Information Processing Systems*, pages 15324–15335. Curran Associates Inc., Red Hook, NY, USA, December 2019.
- [15] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. In *International Conference on Learning Representations*, 2021. URL <https://openreview.net/forum?id=YicbFdNTTy>.
- [16] Yilun Du, Sherry Yang, Bo Dai, Hanjun Dai, Ofir Nachum, Joshua B. Tenenbaum, Dale Schuurmans, and Pieter Abbeel. Learning universal policies via text-guided video generation. In *Thirty-seventh Conference on Neural Information Processing Systems*, 2023. URL <https://openreview.net/forum?id=bo8q5MRcwY>.
- [17] Yan Duan, Marcin Andrychowicz, Bradly Stadie, OpenAI Jonathan Ho, Jonas Schneider, Ilya Sutskever, Pieter Abbeel, and Wojciech Zaremba. One-shot imitation learning. *Advances in neural information processing systems*, 30, 2017.
- [18] Debidatta Dwibedi, Yusuf Aytar, Jonathan Tompson, Pierre Sermanet, and Andrew Zisserman. Temporal Cycle-Consistency learning. In *Computer Vision and Pattern Recognition*, 2019.
- [19] Oliver Groth, Chia-Man Hung, Andrea Vedaldi, and Ingmar Posner. Goal-Conditioned End-to-End visuomotor control for versatile skill primitives. In *2021 IEEE International Conference on Robotics and Automation (ICRA)*, pages 1319–1325. IEEE, May 2021.
- [20] Andrew Jaegle, Sebastian Borgeaud, Jean-Baptiste Alayrac, Carl Doersch, Catalin Ionescu, David Ding, Skanda Koppula, Daniel Zoran, Andrew Brock, Evan Shelhamer, Olivier J Henaff, Matthew Botvinick, Andrew Zisserman, Oriol Vinyals, and Joao Carreira. Perceiver IO: A general architecture for structured inputs & outputs. In *International Conference on Learning Representations*, 2022. URL <https://openreview.net/forum?id=filJ7WpI-g>.
- [21] Vidhi Jain, Yixin Lin, Eric Undersander, Yonatan Bisk,

- and Akshara Rai. Transformers are adaptable task planners. In Karen Liu, Dana Kulic, and Jeff Ichnowski, editors, *Proceedings of The 6th Conference on Robot Learning*, volume 205 of *Proceedings of Machine Learning Research*, pages 1011–1037. PMLR, 14–18 Dec 2023. URL <https://proceedings.mlr.press/v205/jain23a.html>.
- [22] Eric Jang, Alex Irpan, Mohi Khansari, Daniel Kappler, Frederik Ebert, Corey Lynch, Sergey Levine, and Chelsea Finn. BC-Z: Zero-Shot Task Generalization with Robotic Imitation Learning. In *Proceedings of the 5th Conference on Robot Learning*, pages 991–1002, 2022.
- [23] Eric Jang, Alex Irpan, Mohi Khansari, Daniel Kappler, Frederik Ebert, Corey Lynch, Sergey Levine, and Chelsea Finn. Bc-z: Zero-shot task generalization with robotic imitation learning. In *Conference on Robot Learning*, pages 991–1002. PMLR, 2022.
- [24] Yunfan Jiang, Agrim Gupta, Zichen Zhang, Guanzhi Wang, Yongqiang Dou, Yanjun Chen, Li Fei-Fei, Anima Anandkumar, Yuke Zhu, and Linxi Fan. VIMA: General robot manipulation with multimodal prompts. In *Fortieth International Conference on Machine Learning*, 2023.
- [25] Jacob Krantz, Theophile Gervet, Karmesh Yadav, Austin Wang, Chris Paxton, Roozbeh Mottaghi, Dhruv Batra, Jitendra Malik, Stefan Lee, and Devendra Singh Chaplot. Navigating to objects specified by images. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 10916–10925, 2023.
- [26] Sateesh Kumar, Jonathan Zamora, Nicklas Hansen, Rishabh Jangir, and Xiaolong Wang. Graph inverse reinforcement learning from diverse videos, 2022.
- [27] Jacky Liang, Wenlong Huang, Fei Xia, Peng Xu, Karol Hausman, Brian Ichter, Pete Florence, and Andy Zeng. Code as policies: Language model programs for embodied control. In *2023 IEEE International Conference on Robotics and Automation (ICRA)*, 2023.
- [28] Yuxuan Liu, Abhishek Gupta, Pieter Abbeel, and Sergey Levine. Imitation from observation: Learning to imitate behaviors from raw video via context translation. In *2018 IEEE International Conference on Robotics and Automation (ICRA)*, pages 1118–1125. IEEE, May 2018.
- [29] Yecheng Jason Ma, Shagun Sodhani, Dinesh Jayaraman, Osbert Bastani, Vikash Kumar, and Amy Zhang. VIP: Towards universal visual reward and representation via Value-Implicit Pre-Training. In *International Conference on Learning Representations*, 2023.
- [30] Zhao Mandi, Fangchen Liu, Kimin Lee, and Pieter Abbeel. Towards more generalizable one-shot visual imitation learning. In *2022 International Conference on Robotics and Automation (ICRA)*, pages 2434–2444. IEEE, 2022.
- [31] Russell Mendonca, Shikhar Bahl, and Deepak Pathak. Structured world models from human videos. In *RSS*, 2023.
- [32] Antoine Miech, Dimitri Zhukov, Jean-Baptiste Alayrac, Makarand Tapaswi, Ivan Laptev, and Josef Sivic. HowTo100M: Learning a Text-Video Embedding by Watching Hundred Million Narrated Video Clips. In *ICCV*, 2019.
- [33] Ashvin Nair, Vitchyr Pong, Murtaza Dalal, Shikhar Bahl, Steven Lin, and Sergey Levine. Visual reinforcement learning with imagined goals. In *NeurIPS*, July 2018.
- [34] Suraj Nair, Aravind Rajeswaran, Vikash Kumar, Chelsea Finn, and Abhinav Gupta. R3m: A universal visual representation for robot manipulation. In *6th Annual Conference on Robot Learning*, 2022. URL <https://openreview.net/forum?id=tGbpzg6yOrI>.
- [35] Open X-Embodiment Collaboration, Abhishek Padalkar, Acorn Pooley, Ajay Mandlekar, Ajinkya Jain, Albert Tung, Alex Bewley, Alex Herzog, Alex Irpan, Alexander Khazatsky, Anant Rai, Anikait Singh, Animesh Garg, Anthony Brohan, Antonin Raffin, Ayzaan Wahid, Ben Burgess-Limerick, Beomjoon Kim, Bernhard Schölkopf, Brian Ichter, Cewu Lu, Charles Xu, Chelsea Finn, Chenfeng Xu, Cheng Chi, Chenguang Huang, Christine Chan, Chuer Pan, Chuyuan Fu, Coline Devin, Danny Driess, Deepak Pathak, Dhruv Shah, Dieter Buechler, Dmitry Kalashnikov, Dorsa Sadigh, Edward Johns, Federico Ceola, Fei Xia, Freek Stulp, Gaoyue Zhou, Gaurav S Sukhatme, Gautam Salhotra, Ge Yan, Giulio Schiavi, Gregory Kahn, Hao Su, Hao-Shu Fang, Haochen Shi, Heni Ben Amor, Henrik I Christensen, Hiroki Furuta, Homer Walke, Hongjie Fang, Igor Mordatch, Ilija Radosavovic, Isabel Leal, Jacky Liang, Jad Abou-Chakra, Jaehyung Kim, Jan Peters, Jan Schneider, Jasmine Hsu, Jeannette Bohg, Jeffrey Bingham, Jiajun Wu, Jialin Wu, Jianlan Luo, Jiayuan Gu, Jie Tan, Jihoon Oh, Jitendra Malik, Jonathan Booher, Jonathan Tompson, Jonathan Yang, Joseph J Lim, João Silvério, Junhyek Han, Kanishka Rao, Karl Pertsch, Karol Hausman, Keegan Go, Keerthana Gopalakrishnan, Ken Goldberg, Kendra Byrne, Kenneth Oslund, Kento Kawaharazuka, Kevin Zhang, Krishan Rana, Krishnan Srinivasan, Lawrence Yunliang Chen, Lerrel Pinto, Li Fei-Fei, Liam Tan, Lionel Ott, Lisa Lee, Masayoshi Tomizuka, Max Spero, Maximilian Du, Michael Ahn, Mingtong Zhang, Mingyu Ding, Mohan Kumar Srirama, Mohit Sharma, Moo Jin Kim, Naoaki Kanazawa, Nicklas Hansen, Nicolas Heess, Nikhil J Joshi, Niko Suenderhauf, Norman Di Palo, Nur Muhammad Mahi Shafiullah, Oier Mees, Oliver Kroemer, Pannag R Sanketi, Paul Wohlhart, Peng Xu, Pierre Sermanet, Priya Sundaresan, Quan Vuong, Rafael Rafailov, Ran Tian, Ria Doshi, Roberto Martín-Martín, Russell Mendonca, Rutav Shah, Ryan Hoque, Ryan Julian, Samuel Bustamante, Sean Kirmani, Sergey Levine, Sherry Moore, Shikhar Bahl, Shivin Dass, Shubham Sonawani, Shuran Song, Sichun Xu, Siddhant Haldar, Simeon Adebola, Simon Guist, Soroush Nasiriany, Stefan Schaal, Stefan Welker, Stephen Tian, Sudeep Dasari, Suneel Belkhale, Takayuki Osa, Tatsuya Harada, Tatsuya Matsushima, Ted Xiao, Tianhe Yu, Tianli Ding, Todor Davchev, Tony Z Zhao, Travis Armstrong, Trevor Darrell, Vidhi Jain, Vincent Van-

- houcke, Wei Zhan, Wenxuan Zhou, Wolfram Burgard, Xi Chen, Xiaolong Wang, Xinghao Zhu, Xuanlin Li, Yao Lu, Yevgen Chebotar, Yifan Zhou, Yifeng Zhu, Ying Xu, Yixuan Wang, Yonatan Bisk, Yoonyoung Cho, Youngwoon Lee, Yuchen Cui, Yueh-Hua Wu, Yujin Tang, Yuke Zhu, Yunzhu Li, Yusuke Iwasawa, Yutaka Matsuo, Zhuo Xu, and Zichen Jeff Cui. Open X-Embodiment: Robotic learning datasets and RT-X models. *arXiv 2310.08864*, 2023.
- [36] Priyam Parashar, Vidhi Jain, Xiaohan Zhang, Jay Vakil, Sam Powers, Yonatan Bisk, and Chris Paxton. Spatial-Language Attention Policies for Efficient Robot Learning. In *Conference on Robot Learning*, 2023. URL <https://arxiv.org/abs/2304.11235>.
- [37] Xue Bin Peng, Angjoo Kanazawa, Jitendra Malik, Pieter Abbeel, and Sergey Levine. SFV: reinforcement learning of physical skills from videos. *ACM Trans. Graph.*, 37(6):1–14, December 2018.
- [38] Ethan Perez, Florian Strub, Harm De Vries, Vincent Dumoulin, and Aaron Courville. Film: Visual reasoning with a general conditioning layer. In *Proceedings of the AAAI conference on artificial intelligence*, 2018.
- [39] Vladimír Petrík, Makarand Tapaswi, Ivan Laptev, and Josef Sivic. Learning object manipulation skills via approximate state estimation from real videos. In Jens Kober, Fabio Ramos, and Claire Tomlin, editors, *Proceedings of the 2020 Conference on Robot Learning*, volume 155 of *Proceedings of Machine Learning Research*, pages 296–312. PMLR, 2021.
- [40] Sören Pirk, Mohi Khansari, Yunfei Bai, Corey Lynch, and Pierre Sermanet. Online learning of object representations by appearance space feature alignment. In *2020 IEEE International Conference on Robotics and Automation (ICRA)*, pages 10473–10479, 2020. doi: 10.1109/ICRA40945.2020.9196567.
- [41] Karl Schmeckpeper, Oleh Rybkin, Kostas Daniilidis, Sergey Levine, and Chelsea Finn. Reinforcement learning with videos: Combining offline observations with interaction. *arXiv preprint arXiv:2011.06507*, 2020.
- [42] Rutav Shah, Roberto Martín-Martín, and Yuke Zhu. MUTEX: Learning unified policies from multimodal task specifications. In *7th Annual Conference on Robot Learning*, 2023.
- [43] Pratyusha Sharma, Deepak Pathak, and Abhinav Gupta. Third-Person visual imitation learning via decoupled hierarchical controller. *Adv. Neural Inf. Process. Syst.*, 32, 2019.
- [44] Laura Smith, Nikita Dhawan, Marvin Zhang, Pieter Abbeel, and Sergey Levine. AVID: Learning Multi-Stage tasks via Pixel-Level translation of human videos. In *Robotics: Science and Systems (RSS)*, December 2020.
- [45] Austin Stone, Ted Xiao, Yao Lu, Keerthana Gopalakrishnan, Kuang-Huei Lee, Quan Vuong, Paul Wohlhart, Sean Kirmani, Brianna Zitkovich, Fei Xia, Chelsea Finn, and Karol Hausman. Open-World object manipulation using pre-trained Vision-Language models. In *Conference on Robot Learning*, March 2023.
- [46] Chen Wang, Linxi Fan, Jiankai Sun, Ruohan Zhang, Li Fei-Fei, Danfei Xu, Yuke Zhu, and Anima Anandkumar. Mimicplay: Long-horizon imitation learning by watching human play. *arXiv preprint arXiv:2302.12422*, 2023.
- [47] Tete Xiao, Ilija Radosavovic, Trevor Darrell, and Jitendra Malik. Masked visual pre-training for motor control. *arXiv preprint arXiv:2203.06173*, 2023.
- [48] Mengda Xu, Zhenjia Xu, Cheng Chi, Manuela Veloso, and Shuran Song. XSkill: Cross embodiment skill discovery. In *7th Annual Conference on Robot Learning*, 2023. URL <https://openreview.net/forum?id=8L6pHd9aS6w>.
- [49] Sriram Yenamandra, Arun Ramachandran, Karmesh Yadav, Austin Wang, Mukul Khanna, Theophile Gervet, Tsung-Yen Yang, Vidhi Jain, Alexander William Clegg, John Turner, Zsolt Kira, Manolis Savva, Angel Chang, Devendra Singh Chaplot, Dhruv Batra, Roozbeh Motlaghi, Yonatan Bisk, and Chris Paxton. HomeRobot: Open-Vocabulary Mobile Manipulation. In *Conference on Robot Learning*, 2023. URL <https://arxiv.org/abs/2306.11565>.
- [50] Jiahui Yu, Zirui Wang, Vijay Vasudevan, Legg Yeung, Mojtaba Seyedhosseini, and Yonghui Wu. Coca: Contrastive captioners are image-text foundation models. *arXiv preprint arXiv:2205.01917*, 2022.
- [51] Kevin Zakka, Andy Zeng, Pete Florence, Jonathan Tompson, Jeannette Bohg, and Debidatta Dwibedi. Xirl: Cross-embodiment inverse reinforcement learning. In *Conference on Robot Learning*, pages 537–546. PMLR, 2022.
- [52] Xiaohua Zhai, Basil Mustafa, Alexander Kolesnikov, and Lucas Beyer. Sigmoid loss for language image pre-training. In *2023 IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 11941–11952, Los Alamitos, CA, USA, oct 2023. IEEE Computer Society. doi: 10.1109/ICCV51070.2023.01100.
- [53] Tony Z Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning Fine-Grained bimanual manipulation with Low-Cost hardware. In *Robotics: Science and Systems*, 2023.