

通过图像修复进行视觉提示

Amir Bar^{* 1,2}, Yossi Gandelsman^{* 1}, Trevor Darrell¹, Amir Globerson², Alexei A. Efros¹

¹UC Berkeley

²Tel Aviv University

摘要

如何在不对任务进行特定微调或任何模型修改的情况下，将预训练的视觉模型适配到新的下游任务？受自然语言处理中提示的启发，本文研究了视觉提示：在测试时给定新任务的输入-输出图像示例和一个新的输入图像，目标是自动生成与给定示例一致的输出图像。我们表明，将这个问题表述为简单的图像修复——实际上只是在拼接的视觉提示图像中填充一个空洞——出人意料地有效，前提是修复算法在正确的数据上进行了训练。我们在自己整理的新数据集上训练了掩码自编码器——该数据集包含来自 Arxiv 学术论文来源的 88k 张未标注图形。我们将视觉提示应用于这些预训练模型，并在各种下游图像到图像任务上展示了结果，包括前景分割、单目标检测、着色、边缘检测等。¹

1 引言

在过去几年中，自监督学习在计算机视觉和自然语言处理（NLP）领域日益流行。现代深度学习模型容量的不断增长使其在相对较小的标注数据集上训练时容易过拟合。自监督学习通过为任何数据集生成“免费标签”来解决这一问题，无需人工标注，从而缓解了这些高容量深度学习模型对数据的渴求。然而，通过自监督学习到的特征并非“即用型”——它们通常需要通过在某些标注数据集上进行微调来适配给定的下游任务。这种微调能否避免？

在自然语言处理中，提示 [5] 最近作为一种无需额外训练即可将模型用于新方法而出现。在测试时针对特定语言理解任务进行任务提示的一种常见方式是，向训练好的模型提供与目标任务示例及查询相对应的输入。例如，输入以下提示：Je suis désolé I'm sorry J'adore la glace 将提示模型 [5] 执行法语到英语的翻译任务，返回：I love ice cream

这种测试时任务提示的思想能否推广到视觉领域？也就是说，与当前计算机视觉中每个训练模型只服务于其预定义任务（如分割、检测、分类）的现状不同，我们能否拥有一个单一的通用模型，无需任何微调（即权重修改）即可执行各种用户指定的任务？

本文通过证明大容量图像修复模型在正确数据上训练时，可以成为视觉提示的惊人有效工具，向这一目标迈出了一步。

^{*} Equal contribution.

¹Project page: https://yossigandelsman.github.io/visual_prompt.




图 1：通过图像修复进行视觉提示。顶部：提示图像修复模型。给定输入输出示例 (x_1, y_1) 和图像查询 x_q ，我们构建一个网格状的单张图像，称为视觉提示 x_{vp} 。视觉提示由所需任务示例和新的查询图像（均为绿色）组成。修复模型的目标是预测被遮罩区域（红色），使其与示例保持一致。底部：只要在正确的数据上训练，修复模型就能以这种方式解决各种计算机视觉任务。模型预测以红色标注。

如图 1 所示，我们通过构建一个新的网格状图像来定义每个任务，该图像包含任务的输入输出示例和一个新查询（绿色边框）。输入输出示例描述了任务，图像查询定义了新的输入。然后，模型通过简单地修复图像的其余部分（红色边框）来生成结果。这种设置与经典的图像类比 [22] 公式最为相似，但约束更少：我们不是分别显式定义 A 、 A' 和 B 图像，而是将它们与一个孔洞拼接成单张图像（因此，视觉提示并不完全等同于类比，因为没有隐含的从左到右的顺序）。我们的目标也与元学习和小样本学习方法的目标相似，只是我们不区分任务和示例对。我们公式的唯一要求是任务必须定义为图像到图像的转换，这是视觉问题的一个非常大的子集。

为了获得对我们的框架最有用的训练数据，我们利用了一个跨越多种计算机视觉任务的领域——来自 Arxiv 上计算机视觉文章中的图形和信息图。我们构建了一个包含 8.8 万张图形的大型数据集，其中许多包含图像网格及其对应的任务结果（例如图像及其分割掩码/风格化版本/边缘等）。然后，我们训练大容量修复模型，根据同一图形中的其他补丁来预测随机掩码的补丁。

我们的主要贡献如下。首先，我们提出了一种简单但出人意料强大的视觉提示通用方法。我们表明，在给定少量任务输入输出示例和查询图像的情况下，各种计算机视觉任务都可以被视为网格修复问题。其次，我们提供了一个新的数据集，使模型能够在没有任何标注、任务描述或关于网格结构的额外信息的情况下学习这种网格结构。最后，我们表明，虽然使用我们的新数据集进行训练是必要的，但添加来自其他来源（例如 ImageNet）的更多通用图像数据可以进一步改善结果。

2 相关工作

自然图像修复。填充图像中的空白区域在自然图像中已被广泛探索。早期方法使用输入图像本身的数据进行修复 [14, 4, 11, 3, 49]，而后续工作则利用图像数据集作为源数据 [19, 38, 56, 30, 31]。最近的方法尝试将变换器应用于视觉合成任务 [8, 58, 15, 57, 7]。由于单个输出补丁的完成选项数量呈指数级增长，这些方法依赖于离散潜在码本 [51, 40, 15]，该码本作为一个更小但更具表达力的词汇表。为了解决合成的多模态特性，已经提出了不同的方法来对可能的

补全 [15, 57, 7] 的分布进行建模。例如, [15, 57] 提出使用自回归模型逐行合成图像, [7] 提出了迭代并行解码。虽然标准的修复任务通常旨在补全自然图像中的空白部分, 但我们的重点是补全网格状的视觉提示, 这需要在视觉提示图像内的多个图像之间进行推理。

空洞填充作为借口任务。近期研究表明, 自监督预训练能够为迁移学习生成强大的表征, 在具有挑战性的视觉基准上甚至超越了其监督学习对应方法 [37, 18, 9, 21, 6, 10, 35, 16]。Pathak 等人 [38] 首次提出将空洞填充作为自监督的代理任务, 使用上下文编码器, 其目标是根据给定上下文预测随机图像区域。基于视觉变换器 (Vision Transformers, ViTs) [13] 近期的成功, 多项工作提出将空洞填充作为视觉变换器的自监督代理任务 [1, 20, 54]。例如, 在 MAE[20] 中, 目标是根据输入图像块的一小分子集重建图像。在无标签数据上预训练后, MAE 能够生成在下游任务上微调时迁移效果良好的表征。本文利用视觉提示使这些模型适应下游任务, 无需任何微调。

小样本学习。在此设置下, 算法在基类的有标签数据集上进行训练, 并应迁移到一组新类, 仅需少量训练样本 (如 10 或 30) [36, 27, 32, 53, 55, 48, 59, 2]。与小样本方法不同, 本文不假设能够获得基类的大型训练集, 且本文架构并非任务特定。本文方法仅在小样本意义上, 即构建包含一两个任务示例的视觉提示。

图像类比。Hertzmann 等人 [22] 提出了用于纹理综合的图像类比框架, 其中算法接收一对训练图像 (A 和 A') 以及查询图像 (B)。目标是根据从训练对中推断出的关系, 在查询条件下综合出新图像 (B')。其他工作已将类比用于风格迁移 [50], 并作为有监督的图像综合任务 [41]。预测正确补全此前被建模为分类问题 [43, 23], 其他工作则探索了在图像对之间学习不同变换的类比 [34, 46]。与这些方法不同, 本文使用从数据中学习的修复 MAE 模型, 不假设任何预定义的类比结构。

自然语言处理中的提示。随着大型无监督语言模型 [44, 12] 近期的成功, 布朗等人 [5] 展示了在给定预定义提示的情况下, 如何将各种自然语言处理问题重新表述为文本补全问题, 从而无需任何微调即可解决不同任务。提示已被证明是解决各种自然语言处理任务和基准 [39, 5] 的有用工具。最近出现了不同的提示方法, 包括提示工程 [5, 33]、提示集成 [25] 和提示前缀调优 [29, 28]。受自然语言处理中提示成功的启发, 我们旨在研究计算机视觉中的提示, 该领域尚未广泛探索提示。

3 通过图像修复进行视觉提示


我们转而描述如何使用图像修复模型执行视觉提示。在第 3.1 节中, 我们描述了我们提出的修复模型, 它是 MAE 和 VQ-GAN 的组合。然后, 我们继续讨论视觉提示, 并在第 3.2 节中提出创建视觉提示的不同方法 (参见图 1 中的示例)。最后, 我们在第 3.3 节中描述了我们为训练模型而收集的数据集。训练过程如图 2 所示。

3.1 使用 MAE-VQGAN 进行修复

给定输入图像 $x \in \mathbb{R}^{H \times W \times 3}$ 和二进制掩码 $m \in \{0, 1\}^{H \times W}$, 修复函数 f 的目标是合成一幅新图像 $y \in \mathbb{R}^{H \times W \times 3}$, 并填充被掩码的区域:

$$y = f(x, m)$$

图 2: MAE-VQGAN 架构。在训练期间, 输入图像被分块、掩码并馈入 MAE[20]。对于每个被掩码的标记, 解码器输出预训练 VQGAN[15] 码本上的分布。模型使用交叉熵损失进行训练。



为了用神经网络实现 f ，需要考虑设计选择，如网络架构、如何训练它，以及它是否输出可能补全或像素的分布。本文提出 MAE-VQGAN 模型，该模型结合了 MAE[20] 和 VQGAN[15] 的思想。遵循 MAE 的设计，该模型基于 ViT[52, 13]，并通过掩码自编码进行训练，随机掩码图像块，然后应用 f 从非掩码部分重建图像。MAE-VQGAN 对分布 $p_\theta(z_i|x, m)$ 进行建模，其中 $z_i \in V$ 是来自 VQGAN 词汇表 V 的视觉标记，对应于 i^{th} ViT 块。为简单起见，本文使用固定的 ImageNet 预训练 VQGAN 码本。² 与直接预测像素的 MAE 不同，MAE-VQGAN 通过 Softmax 函数为视觉标记分配概率，这更适合捕捉歧义。在训练期间，本文通过使用 VQGAN 编码器将图像映射到视觉标记索引来获得真实视觉标记。该模型使用交叉熵损失进行训练。

设 $\hat{z} = (\hat{z}_1, \dots, \hat{z}_k)$ 为预测视觉标记的有序集合。为了获得 $\hat{z}_i$ ，本文使用 $\arg\max$ ：

$$\hat{z}_i = \arg \max_{z_i} p_\theta(z_i|x, m)$$

然后，为了将视觉标记解码为像素，本文将 VQGAN 解码器应用于 $\hat{z}$ 以获得 y 。

3.2 提示修复模型

为了提示修复模型，本文构建一个视觉提示，这是一个由任务输入-输出示例和一个新查询图像组成的网格状图像。然后，模型必须修复图像的其余部分，使其与示例中定义的任务一致（见图 1）。

设 $S = \{(x_i, y_i)\}_{i=1}^n$ 为输入-输出示例集，其中 x_i 为图像， y_i 为 x_i (e.g. y_i 的函数（即分割掩码）。我们假设 n 规模较小（一个或少数几个示例）。那么，给定 S 和一个新的输入查询 x_q ，目标是预测对应的标签 y_q 。为了提示第 3.1 节讨论的修复模型，我们需要定义一个函数 g ，将示例集 S 和查询图像 x_q 映射到新图像和掩码：

$$[x_{vp}, m] = g(S, x_q)$$

图像 x_{vp} 是视觉提示，掩码 m 定义了 f 必须预测的掩码区域。对于给定任务，可能存在多个可考虑的 g 实现。修复模型的目标是对视觉提示 x_{vp} 进行推理，并在不进行任何额外训练的情况下输出合理的补全： $y_{vp} = f(x_{vp}, m)$ 为了获得 y_q ，本文只需取 y_{vp} 中与掩码 m 对应的部分。

视觉提示工程。 为使视觉提示发挥作用， g 应输出一个良好的视觉提示，该提示由示例 S 和查询图像 x_q 组成。因此， g 必须根据补全任务的性质，确定在视觉提示图像中嵌入输入的位置和方式。本工作中使用的所有函数 g 均为硬编码并手工设计。在大多数情况下， g 通过创建具有 $(n+1) \times 2$ 个单元格的图像网格，将示例和图像查询水平堆叠，其中第 i^{th} 个示例放置 在第 i^{th} 行，图像查询位于最后一行。网格具有固定尺寸，因此在填充之前，首先对输入-输出示例对和查询进行缩放。另一个考虑因素是如何绘制每个 (x_i, y_i) 对。例如，如果 y_i is a 分割掩码，我们可以选择使用不同颜色进行绘制。在第 4.4 节中，我们描述了不同的提示设计选择及其对结果的影响。

视觉提示集成。 定义 g 可能有多种选择。受自然语言处理中 [25, 28] 的启发，提示集成的思想是构建多个不同的提示，将修复模型 f 分别应用于每个提示，以获得一组预测。最终预测可以通过多数投票或加权平均等方式确定。为简单起见，这里我们使用简单平均。

3.3 计算机视觉图形数据集

由 g 生成的图像在构造上并非自然图像。具体而言，这些图像具有网格状的图形结构，将来自不同分布（如自然图像和分割掩码）的图像拼接在一起。因此，在标准数据集（如 ImageNet [42]）上训练的模型可能难以处理这些网格状图像。为缓解领域差距，我们收集了一个新的数据集。² 使用来自 <https://github.com/CompVis/taming-transformers> 的公开可用检查点



图 3：来自我们的计算机视觉图形数据集的随机图像。我们从计算机视觉学术论文中整理了一个包含 88k 张未标注图形的数据集。在训练过程中，我们随机从这些图形中采样裁剪块，无需任何额外解析。

计算机视觉图形（Figures）数据集包含 88,645 张图像，这些图像更接近我们视觉提示的结构。该数据集收集自 Arxiv，这是一个开放获取的学术文章网络档案库，涵盖多个学术领域。Arxiv 资源自 2010 年起可公开下载。我们下载了 2010 年至 2022 年的所有论文资源，并选取了计算机视觉分区“cs.CV”的资源，因为这些图像更接近网格结构，如图 3 所示。为了去除不相关的源图像（如图表），我们手动标注了 2000 张图像，并训练了一个二分类图像分类器，为具有至少一张自然图像且呈图形结构的源图像赋予高分。随后，我们在整个数据上使用该分类器，仅保留来自 23,302 篇不同论文的最具信息量的源图像。我们随机划分 90% 的数据用于训练，其余用于验证。我们在补充材料中提供了包含更多信息的数据表。

4 实验与结果

为了研究视觉提示，我们在 ImageNet 和 Figures 数据集上预训练了不同的模型（见第 4.1 节），然后使用不同的提示在下游简单计算机视觉任务上定量评估这些模型（见第 4.2 节）。我们使用合成数据集，在第 4.3 节中评估模型和数据的选择如何影响视觉提示的成功，并在第 4.4 节中探索不同的提示设计选择。我们在本节以及补充材料中提供了大量定性结果。

4.1 模型与基线

为了研究模型选择对提示结果的影响，我们使用不同的模型进行实验，包括 MAE-VQGAN（见第 3.1 节）以及下面简要描述的其他几种修复模型。

VQGAN[15] 是一种用于修复和图像生成的自回归变换器模型。视觉标记按行顺序预测，模型使用交叉熵损失进行训练。VQGAN 模型的码本用于编码视觉标记，并预先使用感知损失 [26] 和 GAN 损失 [17] 进行训练。我们按照 [15] 中的超参数在 ImageNet 和我们的 Figures 数据集上训练它，并使用一个预训练的码本，其词汇表大小为 $|V| = 1024$ 。

BEiT [1] 是一种掩码自编码器。该模型将每个输入 16×16 图像块映射到来自 d-VAE [40] 词汇表（大小为 8192）的视觉标记。为了编码每个视觉标记，图像首先被调整为 112×112 ，然后映射为 196 个标记。我们使用公开可用的 BEiT 大型模型，该模型在 ImageNet-21k 上进行了预训练。我们还在 Figures 数据集上预训练了一个大型 BEiT 模型，共 1000 个训练轮次。

MAE [20]。与 BEiT 类似，MAE 试图重建被掩码的输入图像。与 BEiT 不同的是，该模型直接回归像素，并使用 l_2 损失进行训练。在预训练期间，只有未被掩码的

表 1：计算机视觉任务上的视觉提示结果。对于前景分割和单目标检测，我们报告 mIOU 分数。对于着色任务，我们报告均方误差。

Model	Foreground Segmentation $\uparrow$				Single Object Detection $\uparrow$				Colorization $\downarrow$	
	Split 0	Split 1	Split 2	Split 3	Split 1	Split 2	Split 3	Split 4	MSE	LPIPS
Copy	12.92	17.90	13.52	15.29	12.14	13.50	13.03	12.38	2.63	0.75
BEiT (IN-21k)	0.38	0.93	0.90	0.95	0.24	0.32	0.19	0.10	1.25	0.73
VQGAN (IN-1k)	6.96	10.55	9.59	9.43	5.19	4.99	5.09	5.10	2.44	0.66
MAE (IN-1k)	1.92	6.76	3.85	4.57	1.37	1.98	1.62	1.62	1.13	0.87
MAE-VQGAN (IN-1k)	2.22	7.07	5.48	6.28	3.34	3.21	2.80	2.80	3.31	0.75
BEiT (Figures)	5.38	3.94	3.20	3.29	0.17	0.02	0.14	0.16	0.60	0.70
VQGAN (Figures)	12.56	17.51	14.27	15.06	2.27	2.37	2.48	1.99	1.50	0.56
MAE (Figures)	17.42	25.70	18.64	16.53	5.49	4.98	5.24	5.84	0.43	0.55
MAE-VQGAN (Figures)	27.83	30.44	26.15	24.25	24.19	25.20	25.36	25.23	0.67	0.40

标记被送入编码器，从而缩短了训练时间。我们使用在 ImageNet 上预训练的公开检查点，并在我们的数据集上预训练另一个模型 1000 个训练轮次。

复制示例。这个简单的基线仅复制第一个示例的标签作为输出。

实现细节。我们描述的所有模型都是基于大型变换器（Transformer）的模型 [52, 13]，图像块大小为 16×16 ，嵌入维度为 1024，共 24 层，16 个注意力头。在训练时，我们使用了一台配备 8 块 Quadro RTX 6000 GPU 的机器，批大小为 48。输入图像尺寸为 224×224 。

4.2 下游计算机视觉任务

本文对上述修复模型在计算机视觉任务上进行定量评估。

视觉提示。给定一个示例对和一张查询图像，本文以相同方式为所有任务构建提示。本文构建一个由 2×2 个子图像组成的网格，其中示例对嵌入在第一行，查询图像出现在左下角单元格中。参见图 1 中的示例。

计算机视觉任务。本文在标准图像到图像任务上评估修复模型，如前景分割、单目标检测和着色。

- **前景分割。**目标是将查询图像二值分割为前景和背景。示例是一张图像及其对应的二值分割掩码。查询是一张新图像，目标是补全对应的分割掩码。本文使用 Pascal-5i[45] 数据集，该数据集由 4 个不同的图像划分组成，每个划分包含 346 至 725 张图像及关联的分割掩码。对于每个类别，数据包含少量图像-掩码对，以及留出的图像查询。对于每个图像查询，本文随机选择一个示例对。评估时，首先将补全图像中的每个像素映射到最近的前景或背景颜色。最后，本文报告平均交并比（mIOU）度量。

- **单目标检测。**与前景分割类似，此任务的目标是对查询图像中出现的物体进行二值分割。然而，该任务比前景分割更具挑战性，因为示例掩码是从边界框中获得的，而边界框比分割掩码更粗糙。我们使用 Pascal VOC 2012 数据集，利用图像及其关联的检测框。为简化起见，我们使用 Pascal 标注仅包含单个物体的图像，并过滤掉物体覆盖图像超过 50% 的简单图像。我们随机选择同一物体类别的示例对和图像查询，并使用 4 个不同的随机种子重复该过程。在评估方面，我们遵循与前景分割类似的过程来获得二值分割掩码。然后，我们使用形态学操作保留面积最大的连通分量，并在其周围绘制边界框。我们报告 mIOU 结果。

- **着色。**目标是将灰度图像映射为彩色图像。示例对是灰度图像和对应的彩色图像，如图 1 和图 4 所示。我们从 ImageNet [42] 验证集中随机采样了 1000 个示例对和图像查询，并将它们转换为灰度，以获得每张图像的灰度和彩色版本。我们报告 MSE 损失和 LPIPS [60]。

结果。我们在表 1 中给出了定量结果，在图 4 中给出了定性补全结果。在 Figures 数据集上训练改善了大多数模型在所有下游任务中的结果。MAE-VQGAN 在检测和分割方面大幅优于其他模型，并且




图 4：视觉提示预测示例。每个视觉提示都被输入到在 Figures 数据集上训练的 MAE-VQGAN 模型中。对于每个视觉提示，结果用红色标记。




图 5：合成数据研究结果。MAE-VQGAN 的预测用红色方框标注。

生成的图像比 MAE 清晰得多。我们发现 VQGAN 难以输出准确的结果，可能是由于顺序解码所致。BEiT 模型被 MAE 超越，很可能是由于其训练过程的样本效率较低。更多结果请参见补充材料。

4.3 合成数据研究

为评估修复模型的组合预测能力，我们创建了 3 个简单合成任务及其 3 种组合，并在每个任务上对每个模型评估 100 个示例。

视觉提示。 给定两个示例对和一个查询图像，我们以相同方式为所有任务构建提示。我们构建一个由 3×2 个子图像组成的网格，其中示例对嵌入在前两行，查询图像位于左下角单元格。示例见图 5。

变化预测任务。 每个示例对是一张彩色形状图像，以及一张引入变化后的对应图像。变化可以是颜色、形状、大小或其中两种变化的组合。接下来，我们更详细地描述每个单独任务。

- **调整大小。** 每个示例对包含一张圆形图像，以及一张圆形尺寸变小的对应图像。目标是根据图像查询预测调整大小后的图像。
- **形状。** 这里每个示例对是一张圆形图像，以及一张对应的矩形图像。两者大小相似且出现在相同位置。目标是根据新的图像查询预测矩形图像。
- **颜色。** 每个示例对包含一张出现在相同位置的圆形图像，颜色从绿色变为蓝色。给定新的图像查询，目标是预测圆形变为蓝色的对应图像。

评估。 我们将每个预测像素映射到预定义颜色选项（黑色、白色、蓝色或绿色）中的最近邻颜色。然后，通过将出现在真实形状颜色中的像素预测视为前景，其余视为背景，测量并报告颜色感知的平均交并比。

表 2：合成数据研究结果。我们报告了六个任务上的颜色感知平均交并比。

	Color	Shape	Size	Color & Shape	Color & Size	Shape & Size
Copy	5.53	6.71	1.17	6.74	1.17	1.86
VQGAN (IN-1k)	0.91	6.51	6.24	2.40	0.70	6.53
BEiT (IN-22k)	15.99	9.08	1.26	7.23	2.84	2.66
MAE (IN-1k)	0.00	2.07	1.20	0.00	0.00	1.56
MAE-VQGAN (IN-1k)	0.13	2.94	3.71	0.00	0.01	3.60
VQGAN (Figures)	6.96	19.11	16.21	7.40	2.24	18.41
BEiT (Figures)	40.92	31.43	7.12	33.10	21.21	12.98
MAE (Figures)	70.23	43.99	34.72	19.30	18.99	46.02
MAE-VQGAN (Figures)	40.40	46.53	42.04	20.41	18.27	40.33

表 3：与微调 and 经典单样本分割基线的比较。MAE-VQGAN 图像查询和输出分辨率为 111×111 。CyCTR 和 FWB 分辨率分别为 473×473 和 512×512 ，两种方法均利用 Pascal 5i 标注的基类数据。

Pretraining	# Labeled Images	# Shots	Model	Split 0	Split 1	Split 2	Split 3
Unlabeled ImageNet	1	1	Finetune MAE	11.1	13.4	13.0	12.3
	4	4		12.9	15.8	14.3	15.0
	16	16		13.7	16.1	16.8	17.1
Unlabeled Figures	1	1	MAE-VQGAN	32.5	33.8	32.7	27.2
Labeled Pascal 5i (Segmentation masks)	2086 – 5883	1	FWB [36]	51.3	64.5	56.7	52.2
		1	CyCTR [59]	67.2	71.1	57.6	59.0

结果。结果如表 2 所示，MAE-VQGAN 预测示例见图 5。未在 Figures 数据集上训练时，修复模型无法泛化到这些未见过的任务。在 Figures 数据集上训练后，所有模型的性能均有所提升。然而，由于复杂度不断增加，相同模型在任务组合上仍面临困难。VQGAN 模型采用顺序解码，因此缺乏上下文，导致性能较差。MAE 模型在颜色方面优于 MAE-VQGAN，而 BEiT 在尺寸方面表现不佳。这些模型依赖于预训练的码本（VQGAN 和 dVAE），而这些码本可能不适合这些任务。




图 6：更多示例，更好结果。左：对于固定的查询图像（修复部分以红色标注），我们构建了具有越来越多输入输出示例对的视觉提示。右：我们观察到更多示例提高了四个 Pascal-5i 划分上的整体平均交并比结果。

4.4 分析

与微调 and 少样本基线的比较。我们纳入了与基线的比较，这些基线为每个目标类别使用 $K = \{1, 4, 16\}$ 个训练示例。为了完整性，我们还纳入了 FWB[36] 和 CyCTR[59] 的结果，它们是经典的 1-shot 基线，我们将其视为我们方法的上限。FWB 和 CyCTR 利用完全标注的基类训练集（在不同的 Pascal 5i 划分上为 2086 到 5883）。此外，它们的架构是为前景分割任务设计的（例如，它们在更高分辨率下运行）。表 3 中的结果表明，在 Figures 上训练的 MAE-VQGAN 的视觉提示结果显著优于标准

在未标注 ImageNet 上预训练的 MAE 的微调基线。FWB[36] 和 CyCTR[59] 优于视觉提示，主要因为它们在大规模标注基类数据集上预训练，并利用专门用于图像分割的架构。

数据集效应。我们评估在更大且更多样化的数据集上预训练的效果。我们比较仅在 ImageNet 上训练、仅在 Figures 上训练以及两者组合训练。我们在图 7 中报告了 Pascal 5i 上前景分割的 mIOU 结果。在 ImageNet 上训练的 MAE-VQGAN 始终获得较低的 5 点 mIOU。在组合数据集上训练的模型表现最佳，这表明 MAE-VQGAN 可以从额外的未标注图像中受益。




图 7：在更多数据上训练 MAE-VQGAN 可改善视觉提示结果。在 Figures 数据集以及 Figures 和 ImageNet 组合数据集上训练时，Pascal-5i 上的前景分割结果。

更多示例，更好结果。我们研究增加视觉提示中输入-输出对示例数量如何影响结果。直观上，我们期望包含更多示例应减少歧义并带来更好结果。我们使用在 Figures 数据集上预训练的 MAE-VQGAN，并使用来自 PASCAL-5i 的数据。我们构建一个大网格，最多可容纳 8 个示例和一个图像查询。我们随机选择不同数量的示例并随机化放置位置。图 6 中的结果证实，使用更多示例可带来更好的分割结果。

提示工程。我们探索了为前景分割构建不同视觉提示的效果及其对应的掩码自编码器-向量量化生成对抗网络 (MAE-VQGAN) 结果 (参见

图 8.a-b)。当改变提示布局 (例如水平顺序与垂直顺序) 以及改变掩码颜色、纹理或仅使用边缘时 (见图 9)，模型生成了合理的补全结果。表 4 中的平均交并比结果表明，模型在垂直布局以及分割掩码颜色为黑白时表现更佳。有趣的是，通过分析被掩码补丁标记的平均注意力头，我们观察到注意力会随着提示布局的改变而变化 (见图 8.d-e)。




图 8：提示布局设计。两种提示顺序，以及所选补丁 (用黑色边界框标注) 对应的平均注意力图。最高注意力值出现在查询图像中相似 (对应) 的区域。

提示集成。受自然语言处理中提示集成 (Prompt Ensembling) 的启发 [28]，在给定相同示例对和图像查询的情况下，本文构建了多个不同的视觉提示 (例如，水平和垂直布局，见图 8.a-b)。随后，本文对补全结果进行平均。表 4 中合成研究任务的结果表明，利用多个提示可以带来更优且更稳定的性能。

风格/内容外推。受特南鲍姆与弗里曼经典示例的启发 [47] (该任务最初由霍夫施塔特提出 [24])，本文采用 MAE-VQGAN 对不同字体印刷的字母序列进行外推 (见图 10)。研究发现，该模型能够在给定风格与新内容的情况下进行外推 (图 10a)，但在外推全新内容时表现困难 (图 10b)。此外，该模型在更复杂的字母序列外推方面同样存在困难；即使风格与内容均已给定，性能仍会下降 (图 10c-d)。

局限性。本文的重点是提供一个概念验证，展示可以用视觉方式提示在噪声、无标签数据上训练的简单图像修复模型。具体来说，我们演示了如何预训练一次网络，然后提示它在许多任务上表现良好。这一可能性令人惊讶且具有科学意义，尽管这种方法无法与监督式任务特定模型竞争。为了使视觉提示有效，修复模型需要在计算机视觉图形数据集上进行训练。然而，我们的初步实验表明，它可以从额外的自然图像数据训练中受益 (见图 7)。其他



图 9：不同标签选择下的任务性能。使用不同掩码颜色（例如，紫色/黄色与绿色/红色）、绘制完整掩码与仅绘制边缘以及改变掩码纹理时的提示结果。与其他替代方案相比，紫色/黄色和黑色/白色（见图 8）掩码效果最佳。

表 4：提示工程。使用不同提示颜色时，Pascal-5i 上的前景分割 mIOU 结果。

	Horizontal	Vertical
Black/White	27.17	31.57
Purple/Yellow	23.44	28.47

表 5：提示集成。我们在此报告颜色感知的 mIOU。每一行的结果都基于所有先前提示的集成。

Prompt Layout	Color	Shape	Size
Horizontal	39.97	46.54	42.01
+ Vertical	41.31	54.71	46.18
+ Vertical w/ Rows Swap	44.14	60.42	49.42




图 10：使用 MAE-VQGAN 进行风格和-content 外推。模型可以外推新内容的风格（a），但无法预测新内容（b）。模型难以外推更长序列的新风格和内容（c-e）。

局限性包括任务定义中的歧义、对预训练 VQGAN 解码器的依赖，以及当输入-输出示例未对齐时性能较差（见图 11 中的示例）。




图 11：局限性和失败案例。单个输入-输出示例可能具有歧义，并可能导致意外的补充。MAE-VQGAN 模型在给定未对齐的输入-输出示例时表现较差，并且由于使用 VQGAN 词汇表，它在合成分布外像素（如模糊图像）方面受到限制。

5 讨论

为什么我们提出的方法尽管简单，却在大量视觉任务上表现如此出色？目前，我们还没有一个很好的答案。显然，我们使用的特定训练数据起着重要作用，但观察到的泛化程度仍然令人惊讶。也许这些图像到图像的任务中，有一些实际上比我们想象的要简单。但同样明显的是，当代大规模图像修复模型正在学习数据中相当复杂的远程共现和对称性，这通常能够实现令人印象深刻的视觉推理。我们希望我们的工作能鼓励进一步的研究，以更好地理解图像修复所学到的内容。

致谢：我们要感谢 Assaf Shocher 就 Figures 数据集相关的深刻讨论和想法。我们感谢 Aaron Hertzmann 和 Sanjay Subramanian 对手稿的有益反馈。本项目已获得欧洲研究理事会的资助

(ERC)，属于欧盟地平线 2020 研究与创新计划（资助协议 ERC HOLI 819080）。Darrell 教授的团队部分得到了国防部的支持，包括 DARPA 的 LwLL 和/或 SemaFor 项目，以及 BAIR 的产业联盟项目。Efros 教授的团队部分得到了国防部的支持，包括 DARPA 的 MCS 和/或 ONR MURI，以及 SAP 的资助。

参考文献

- [1] Bao, H., Dong, L., Wei, F.: Beit: Bert pre-training of image transformers. arXiv preprint arXiv:2106.08254 (2021)
- [2] Bar, A., Wang, X., Kantorov, V., Reed, C.J., Herzig, R., Chechik, G., Rohrbach, A., Darrell, T., Globerson, A.: Detreg: Unsupervised pretraining with region priors for object detection. arXiv preprint arXiv:2106.04550 (2021)
- [3] Barnes, C., Shechtman, E., Finkelstein, A., Goldman, D.B.: Patchmatch: A randomized correspondence algorithm for structural image editing. *ACM Trans. Graph.* **28**(3), 24 (2009)
- [4] Bertalmio, M., Sapiro, G., Caselles, V., Ballester, C.: Image inpainting. In: *Proceedings of the 27th annual conference on Computer graphics and interactive techniques*. pp. 417–424 (2000)
- [5] Brown, T.B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D.M., Wu, J., Winter, C., Hesse, C., Chen, M., Sigler, E., Litwin, M., Gray, S., Chess, B., Clark, J., Berner, C., McCandlish, S., Radford, A., Sutskever, I., Amodei, D.: Language models are few-shot learners. *CoRR* **abs/2005.14165** (2020), <https://arxiv.org/abs/2005.14165>
- [6] Caron, M., Misra, I., Mairal, J., Goyal, P., Bojanowski, P., Joulin, A.: Unsupervised learning of visual features by contrasting cluster assignments. *NeurIPS* (2020)
- [7] Chang, H., Zhang, H., Jiang, L., Liu, C., Freeman, W.T.: Maskgit: Masked generative image transformer. arXiv preprint arXiv:2202.04200 (2022)
- [8] Chen, M., Radford, A., Child, R., Wu, J., Jun, H., Luan, D., Sutskever, I.: Generative pretraining from pixels. In: *International Conference on Machine Learning*. pp. 1691–1703. PMLR (2020)
- [9] Chen, T., Kornblith, S., Norouzi, M., Hinton, G.: A simple framework for contrastive learning of visual representations. arXiv preprint arXiv:2002.05709 (2020)
- [10] Chen, X., Fan, H., Girshick, R., He, K.: Improved baselines with momentum contrastive learning. arXiv preprint arXiv:2003.04297 (2020)
- [11] Criminisi, A., Pérez, P., Toyama, K.: Region filling and object removal by exemplar-based image inpainting. *IEEE Transactions on image processing* **13**(9), 1200–1212 (2004)
- [12] Devlin, J., Chang, M.W., Lee, K., Toutanova, K.: Bert: Pre-training of deep bidirectional transformers for language understanding. arXiv preprint arXiv:1810.04805 (2018)
- [13] Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., Dehghani, M., Minderer, M., Heigold, G., Gelly, S., et al.: An image is worth 16x16 words: Transformers for image recognition at scale. arXiv preprint arXiv:2010.11929 (2020)
- [14] Efros, A.A., Leung, T.K.: Texture synthesis by non-parametric sampling. In: *IEEE International Conference on Computer Vision*. pp. 1033–1038. Corfu, Greece (September 1999)
- [15] Esser, P., Rombach, R., Ommer, B.: Taming transformers for high-resolution image synthesis. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. pp. 12873–12883 (2021)
- [16] Gidaris, S., Bursuc, A., Komodakis, N., Pérez, P., Cord, M.: Learning representations by predicting bags of visual words. In: *CVPR* (2020)
- [17] Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A., Bengio, Y.: Generative adversarial nets. *Advances in neural information processing systems* **27** (2014)
- [18] Goyal, P., Mahajan, D., Gupta, A., Misra, I.: Scaling and benchmarking self-supervised visual representation learning. In: *ICCV* (2019)
- [19] Hays, J., Efros, A.A.: Scene completion using millions of photographs. *ACM Transactions on Graphics (SIGGRAPH)* **26**(3) (2007)
- [20] He, K., Chen, X., Xie, S., Li, Y., Dollár, P., Girshick, R.B.: Masked autoencoders are scalable vision learners. *CoRR* **abs/2111.06377** (2021), <https://arxiv.org/abs/2111.06377>

- [21] He, K., Fan, H., Wu, Y., Xie, S., Girshick, R.: Momentum contrast for unsupervised visual representation learning. In: CVPR (2020)
- [22] Hertzmann, A., Jacobs, C.E., Oliver, N., Curless, B., Salesin, D.H.: Image analogies. In: Proceedings of the 28th annual conference on Computer graphics and interactive techniques. pp. 327–340 (2001)
- [23] Hill, F., Santoro, A., Barrett, D.G., Morcos, A.S., Lillicrap, T.: Learning to make analogies by contrasting abstract relational structure. arXiv preprint arXiv:1902.00120 (2019)
- [24] Hofstadter, D.R.: Fluid concepts and creative analogies: Computer models of the fundamental mechanisms of thought. Basic books (1995)
- [25] Jiang, Z., Xu, F.F., Araki, J., Neubig, G.: How can we know what language models know? Transactions of the Association for Computational Linguistics **8**, 423–438 (2020)
- [26] Johnson, J., Alahi, A., Fei-Fei, L.: Perceptual losses for real-time style transfer and super-resolution. In: European conference on computer vision. pp. 694–711. Springer (2016)
- [27] Kang, B., Liu, Z., Wang, X., Yu, F., Feng, J., Darrell, T.: Few-shot object detection via feature reweighting. In: Proceedings of the IEEE/CVF International Conference on Computer Vision. pp. 8420–8429 (2019)
- [28] Lester, B., Al-Rfou, R., Constant, N.: The power of scale for parameter-efficient prompt tuning. CoRR **abs/2104.08691** (2021), <https://arxiv.org/abs/2104.08691>
- [29] Li, X.L., Liang, P.: Prefix-tuning: Optimizing continuous prompts for generation. arXiv preprint arXiv:2101.00190 (2021)
- [30] Liu, G., Reda, F.A., Shih, K.J., Wang, T.C., Tao, A., Catanzaro, B.: Image inpainting for irregular holes using partial convolutions. In: Proceedings of the European conference on computer vision (ECCV). pp. 85–100 (2018)
- [31] Liu, G., Reda, F.A., Shih, K.J., Wang, T.C., Tao, A., Catanzaro, B.: Image inpainting for irregular holes using partial convolutions. In: Proceedings of the European Conference on Computer Vision (ECCV) (September 2018)
- [32] Liu, Y., Zhang, X., Zhang, S., He, X.: Part-aware prototype network for few-shot semantic segmentation. In: European Conference on Computer Vision. pp. 142–158. Springer (2020)
- [33] Lu, Y., Bartolo, M., Moore, A., Riedel, S., Stenetorp, P.: Fantastically ordered prompts and where to find them: Overcoming few-shot prompt order sensitivity. arXiv preprint arXiv:2104.08786 (2021)
- [34] Memisevic, R., Hinton, G.: Unsupervised learning of image transformations. In: 2007 IEEE Conference on Computer Vision and Pattern Recognition. pp. 1–8. IEEE (2007)
- [35] Misra, I., Maaten, L.v.d.: Self-supervised learning of pretext-invariant representations. In: CVPR (2020)
- [36] Nguyen, K., Todorovic, S.: Feature weighting and boosting for few-shot segmentation. In: Proceedings of the IEEE/CVF International Conference on Computer Vision. pp. 622–631 (2019)
- [37] Van den Oord, A., Li, Y., Vinyals, O.: Representation learning with contrastive predictive coding. arXiv e-prints pp. arXiv–1807 (2018)
- [38] Pathak, D., Krahenbuhl, P., Donahue, J., Darrell, T., Efros, A.A.: Context encoders: Feature learning by inpainting. In: Proceedings of the IEEE conference on computer vision and pattern recognition. pp. 2536–2544 (2016)
- [39] Radford, A., Wu, J., Child, R., Luan, D., Amodei, D., Sutskever, I., et al.: Language models are unsupervised multitask learners. OpenAI blog **1**(8), 9 (2019)
- [40] Ramesh, A., Pavlov, M., Goh, G., Gray, S., Voss, C., Radford, A., Chen, M., Sutskever, I.: Zero-shot text-to-image generation. In: International Conference on Machine Learning. pp. 8821–8831. PMLR (2021)
- [41] Reed, S.E., Zhang, Y., Zhang, Y., Lee, H.: Deep visual analogy-making. Advances in neural information processing systems **28** (2015)
- [42] Russakovsky, O., Deng, J., Su, H., Krause, J., Satheesh, S., Ma, S., Huang, Z., Karpathy, A., Khosla, A., Bernstein, M., Berg, A.C., Fei-Fei, L.: ImageNet Large Scale Visual Recognition Challenge. International Journal of Computer Vision (IJCV) **115**(3), 211–252 (2015). <https://doi.org/10.1007/s11263-015-0816-y>
- [43] Sadeghi, F., Zitnick, C.L., Farhadi, A.: Visalogy: Answering visual analogy questions. Advances in Neural Information Processing Systems **28** (2015)
- [44] Sarzynska-Wawer, J., Wawer, A., Pawlak, A., Szymanowska, J., Stefaniak, I., Jarkiewicz, M., Okruszek, L.: Detecting formal thought disorder by deep contextualized word representations. Psychiatry Research **304**, 114135 (2021)
- [45] Shaban, A., Bansal, S., Liu, Z., Essa, I., Boots, B.: One-shot learning for semantic segmentation. CoRR **abs/1709.03410** (2017), <http://arxiv.org/abs/1709.03410>

- [46] Taylor, G.W., Fergus, R., LeCun, Y., Bregler, C.: Convolutional learning of spatio-temporal features. In: European conference on computer vision. pp. 140–153. Springer (2010)
- [47] Tenenbaum, J.B., Freeman, W.T.: Separating style and content with bilinear models. *Neural computation* **12**(6), 1247–1283 (2000)
- [48] Tian, Z., Zhao, H., Shu, M., Yang, Z., Li, R., Jia, J.: Prior guided feature enrichment network for few-shot segmentation. *IEEE transactions on pattern analysis and machine intelligence* (2020)
- [49] Ulyanov, D., Vedaldi, A., Lempitsky, V.: Deep image prior. *arXiv:1711.10925* (2017)
- [50] Upchurch, P., Snively, N., Bala, K.: From a to z: supervised transfer of style and content using deep neural network generators. *arXiv preprint arXiv:1603.02003* (2016)
- [51] Van Den Oord, A., Vinyals, O., et al.: Neural discrete representation learning. *Advances in neural information processing systems* **30** (2017)
- [52] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A.N., Kaiser, Ł., Polosukhin, I.: Attention is all you need. *Advances in neural information processing systems* **30** (2017)
- [53] Wang, X., Huang, T.E., Darrell, T., Gonzalez, J.E., Yu, F.: Frustratingly simple few-shot object detection. *arXiv preprint arXiv:2003.06957* (2020)
- [54] Xie, Z., Zhang, Z., Cao, Y., Lin, Y., Bao, J., Yao, Z., Dai, Q., Hu, H.: Simmim: A simple framework for masked image modeling. *arXiv preprint arXiv:2111.09886* (2021)
- [55] Yang, B., Liu, C., Li, B., Jiao, J., Ye, Q.: Prototype mixture models for few-shot semantic segmentation. In: *European Conference on Computer Vision*. pp. 763–778. Springer (2020)
- [56] Yang, C., Lu, X., Lin, Z., Shechtman, E., Wang, O., Li, H.: High-resolution image inpainting using multi-scale neural patch synthesis. In: *Proceedings of the IEEE conference on computer vision and pattern recognition*. pp. 6721–6729 (2017)
- [57] Yu, J., Li, X., Koh, J.Y., Zhang, H., Pang, R., Qin, J., Ku, A., Xu, Y., Baldrige, J., Wu, Y.: Vector-quantized image modeling with improved vqgan. *arXiv preprint arXiv:2110.04627* (2021)
- [58] Yu, Y., Zhan, F., Wu, R., Pan, J., Cui, K., Lu, S., Ma, F., Xie, X., Miao, C.: Diverse image inpainting with bidirectional and autoregressive transformers. In: *Proceedings of the 29th ACM International Conference on Multimedia*. pp. 69–78 (2021)
- [59] Zhang, G., Kang, G., Yang, Y., Wei, Y.: Few-shot segmentation via cycle-consistent transformer. *Advances in Neural Information Processing Systems* **34** (2021)
- [60] Zhang, R., Isola, P., Efros, A.A., Shechtman, E., Wang, O.: The unreasonable effectiveness of deep features as a perceptual metric. In: *Proceedings of the IEEE conference on computer vision and pattern recognition*. pp. 586–595 (2018)

补充材料




图 12: 额外的视觉提示结果。对于每个视觉提示, 结果用红色标出。

我们包含了更多关于实验研究的信息，以及计算机视觉图形数据集的数据表。额外的视觉提示结果见图 12。

6 实验

6.1 下游计算机视觉任务

定性模型比较。我们纳入了将视觉提示结果应用于前景分割时使用不同修复模型的定性比较（见图 13）。与其他模型相比，MAE-VQGAN 输出更平滑、更准确的分割结果。

单目标检测。我们纳入了 MAE-VQGAN 应用于单目标检测时的定性结果（见图 14）。如第 4.2 节所述，原始输出经过四舍五入，并使用形态学操作进行后处理，以将前景分割转换为边界框。

输入-输出示例的影响。我们固定输入查询，改变输入-输出示例和视觉提示 MAE-VQGAN（见图 15）。不同的示例可能导致略有不同的综合结果。然而，只要示例是有意义的（例如，不是完全背景或前景），无论选择哪个示例，模型结果都是合理的。




图 13：使用不同模型进行前景分割的视觉提示。与其他模型相比，MAE-VQGAN 产生更平滑、更准确的结果。

计算机视觉任务上的视觉提示结果。我们列出了每个视觉提示模型在 Pascal 5i 上的均值和标准差（见表 6）。




图 14: 应用于单目标检测的视觉提示。原始 MAE-VQGAN 结果经过四舍五入, 并使用形态学操作进行后处理。




图 15: 输入-输出示例对提示结果的影响。我们固定输入查询, 改变输入-输出示例。不同的输入-输出示例可能导致略有不同的结果。

表 6: 计算机视觉任务上的视觉提示结果。我们报告了前景分割和单目标检测的 mIOU 分数的均值和标准差。

Model	Foreground Segmentation		Single Object Detection	
	Mean	Std	Mean	Std
Copy	14.91	1.93	12.76	0.54
BEiT (IN-21k)	0.79	0.24	0.21	0.08
VQGAN (IN-1k)	9.13	1.33	5.09	0.07
MAE (IN-1k)	4.28	1.73	1.65	0.22
MAE-VQGAN (IN-1k)	5.26	1.84	3.04	0.24
BEiT (Figures)	3.95	0.87	0.12	0.06
VQGAN (Figures)	14.85	1.78	2.28	0.18
MAE (Figures)	19.57	3.62	5.39	0.32
MAE-VQGAN (Figures)	27.17	2.27	25.00	0.47

7 计算机视觉图形数据集数据表

在第 3.3 节中，我们介绍了计算机视觉图形数据集。完整数据集将在录用后提供。接下来，我们附上数据集数据表。

动机

创建该数据集的目的是什么？ 是否有特定的任务？ 是否有需要填补的特定空白？ 请提供描述。

计算机视觉图表 (Figures) 数据集是为了支持我们的视觉提示方法而提出的。在我们的设置中，视觉提示是一张具有网格状图表结构的图像，它来自不同分布的图像（如自然图像和分割掩码）拼接在一起。因此，在标准数据集（如 ImageNet [42]）上训练的模型可能难以处理这些网格状图像。为了缩小领域差距，我们收集了一个新的数据集，其中的图像更接近所提出的视觉提示结构。

该数据集收集自 Arxiv，这是一个开放获取的学术文章网络档案库，涵盖多个学术领域。Arxiv 资源可公开下载，其中计算机视觉部分包含的图像更接近网格结构，如图 3 所示。

谁创建了这个数据集（例如，哪个团队、研究小组），代表哪个实体（例如，公司、机构、组织）？

N/A

谁资助了该数据集的创建？ 如果有相关的资助，请提供资助方名称以及资助名称和编号。

N/A

还有其他意见吗？

编号

组成

数据集中的实例代表什么（例如，文档、照片），人物、国家）？ 是否存在多种类型的实例（例如，电影、用户和评分；人物及其之间的交互；节点和边）？ 请提供描述。

数据集中的每个实例都是一幅图像，即单个 arXiv 论文中的图。

总共有多少个实例（如果适用，每种类型各有多少个）？

数据由 88,645 张图像组成，按 90% 训练集和 10% 验证集划分。我们在表 7 中给出了数据的描述性统计。我们发现数据中约 40% 的图像不包含任何嵌入标注。大部分数据 (84%) 由网格状、类似图形的图像组成。为获得这些统计量，随机抽取 100 张图形图像，由人工标注员将其标记为单一图像类型（“单一”）或网格状图像类型（“网格”）。此外，如果图像包含标注，标注员从预定义列表（如掩码、边界框、姿态、热图）中选择标注类别，若标注不匹配任何类别则选择“其他”。

数据集是否包含所有可能的实例，还是仅为一个样本（不一定是随机的）？ 随机从更大集合中抽取的实例？ 如果数据集是样本，那么更大的集合是什么？ 样本是否代表更大的集合（例如，地理覆盖范围）？ 如果是，请描述如何验证/核实这种代表性。如果不是，请描述原因（例如，为了覆盖更多样化的实例范围，因为实例被保留或不可用）。

该数据集基于 2010 年至 2022 年 Arxiv 论文中计算机视觉分区“cs.CV”的图表。它仅包含至少含有一张自然图像的图表。为去除不相关的来源

表 7：计算机视觉图形数据集标注统计。结果通过人工标注 100 张图像获得。

Annotation	Type	%
No Annotation	Grid	37
Other	Grid	15
Box	Grid	11
Mask	Grid	9
Heatmap	Grid	8
Box	Single	6
No Annotation	Single	5
Pose	Grid	4
Other	Single	3
Pose	Single	1
Heatmap	Single	1

对于图形或图表类图像，本文人工标注了 2000 张图像，并训练了一个二分类图像分类器，用于对具有至少一张自然图像的类图结构中的源图像赋予高分。随后，本文在整个数据集上应用该分类器，仅保留来自 23,302 篇不同论文的最具信息量的源图像。在对 100 张随机图像进行人工审查后，发现该数据集中 96% 的图像不含图形或图表。

每个实例包含哪些数据？“原始”数据（例如，未经处理的文本或图像）还是特征？无论哪种情况，请提供描述。

每个实例图像均为 PNG 图像格式，分辨率最高可达 1024×1024 。每张图像均附有对应的 Arxiv 论文编号，以及一个指向相关训练/验证分区的指示符。

每个实例是否关联有标签或目标？若有，请提供描述。

每个实例没有关联的标签。

单个实例中是否缺少任何信息？如果是，请提供描述，解释为什么缺少这些信息（例如，因为无法获得）。这不包括有意删除的信息，但可能包括例如经过编辑的文本。

所有实例都是完整的。

实例之间的关系是否明确（例如，用户的电影评分、社交网络链接）？如果是，请描述这些关系是如何明确的。

图像可能具有相似或不同的 arXiv 源论文，我们发布了这些信息。

是否有推荐的数据划分（例如，训练、开发/验证、测试）？如果是，请提供这些划分的描述，解释其背后的理由。

数据集被随机划分为 90%/10% 训练集和验证集。本文仅利用训练集部分对无标注图形进行训练。在未来的工作中，验证集部分可以以不同方式使用，例如超参数调优或用于生成模型的评估。

数据集中是否存在错误、噪声来源或冗余？如果有，请提供描述。

噪声。在对 100 个随机图形的逐一手动审查中，我们发现数据集 96% 的部分不含意外的图形或图表。自然，不同的图形可能存在潜在的重叠，我们承认这种潜在的冗余。

与计算机视觉数据集的重叠。计算机视觉图形数据集是来自不同计算机视觉论文的图形集合。因此，部分图像可能与

计算机视觉数据集的测试集重叠，无论是否带有标注。为了评估这种情况的程度，我们随机抽取了 100 张 Pascal 5i 验证图像，并为每张图像计算其在图形数据集中 10 个最近邻。给定 Pascal 图像和图形图像，我们使用 OpenCV 模板匹配函数（“cv.matchTemplate”），该函数以滑动窗口方式在像素空间中利用均方误差计算相似度。我们还尝试使用 ImageNet 预训练的 ResNet50 计算相似度，发现其效果较差，可能是因为图形数据集包含分布外图像。人工标注员检查了结果，未发现重复项。在 72% 的情况下，检索到的最近邻是不相关的；在 28% 的情况下，至少有一张图形图像有些相似（例如，Pascal 图像包含一个人，而检索到的是另一个人的图像）。我们进行了额外的独立检查以评估重叠程度。对于 100 张随机 Pascal 5i 测试图像中的每张图像，我们使用 CLIP 嵌入在图形数据集中计算 5 个最近邻。在这 100 张图像中，我们发现只有一张包含在某个图形图像中，且该图像没有任何关联的真实标注。因此，我们得出结论：即使存在潜在重叠，其程度也可能非常小且不显著。

不精确的嵌入标注。数据集中的实例是可能包含嵌入标注的图像。自然，这种标注可能存在噪声、不完整或不够精确。

该数据集是自包含的，还是链接到或以其他方式依赖外部资源？（例如，网站、推文、其他数据集）？如果它链接到或依赖于外部资源，a) 是否有保证它们会随时间存在并保持不变；b) 是否有完整数据集的官方存档版本（即，包括数据集创建时存在的外部资源）；c) 是否有任何与外部资源相关的限制（例如，许可证、费用）可能适用于未来的用户？请提供所有外部资源的描述及其相关限制，以及适当的链接或其他访问点。

我们将分享并发布相关 Arxiv 来源和图片的链接，以及一个用于下载和预处理这些来源的自动化代码，该代码符合 Arxiv 许可证（非独占分发许可证）。Arxiv 是一个可靠的来源，得到了整个研究社区的支持。按照惯例，我们可能允许在“合理使用”的基础上提供数据集的替代下载选项。

数据集是否包含可能被视为机密的数据（例如，受法律特权或医患保密保护的数据，包含个人非公开通信内容的数据）？如果是，请提供描述。

编号

数据集是否包含直接查看时可能具有冒犯性、侮辱性、威胁性或可能引发焦虑的数据？如果是，请说明原因。

编号

该数据集是否涉及个人？如果没有，您可以跳过本节剩余的问题。

编号

数据集是否识别任何子群体（例如，按年龄、性别）？如果是，请描述这些子群体是如何被识别的，并提供它们在数据集中各自分布的描述。

N/A

是否有可能直接或间接（即与其他数据结合）从数据集中识别出个人（即一个或多个自然人）？如果是，请描述如何识别。

N/A

数据集是否包含任何可能被视为敏感的数据（例如，揭示种族或民族起源、性取向、宗教信仰、政治观点或工会会员身份、或位置的数据；财务或健康数据；生物识别或遗传数据；政府身份证明形式，如社会安全号码；犯罪记录）？如果是，请提供描述。

N/A

还有其他意见吗？

编号

收集过程

每个实例关联的数据是如何获取的？数据是直接可观察的（例如，原始文本、电影评分）、由受试者报告的（例如，调查回答），还是从其他数据间接推断/派生出来的（例如，词性标签、基于模型的年龄或语言猜测）？如果数据是由受试者报告或间接推断/派生出来的，数据是否经过验证/核实？如果是，请描述如何验证。

数据是直接可观察的，例如，从 Arxiv 来源自动提取。

使用了什么机制或程序来收集数据（例如，硬件设备或传感器、人工策展、软件程序、软件 API）？这些机制或程序是如何验证的？

数据下载遵循 Arxiv 官方数据访问指南：https://arxiv.org/help/bulk_data.

如果数据集是从更大集合中抽取的样本，那么采样策略是什么（例如，确定性的，还是具有特定采样概率的概率性采样）？

该数据集基于 2010 年至 2022 年 Arxiv 计算机视觉分区“cs.CV”中的论文图。它仅包含至少含有一张自然图像的图。为了移除不相关的源图像（如图表），我们手动标注了 2000 张图像，并训练了一个二分类图像分类器，为具有至少一张自然图像的分类结构中的源图像赋予高分。随后，我们在整个数据集上使用该分类器，仅保留来自 23,302 篇不同论文的最具信息量的源图像。在对 100 张随机图进行人工审查后，我们发现该数据集中 96% 的图像不含图表。

谁参与了数据收集过程（例如，学生、众包工作者、承包商），以及他们是如何获得报酬的（例如，众包工作者的报酬是多少）？

参与此项目合作的学生团队。除其担任职位的常规报酬外，团队成员未因这项工作获得额外报酬。

数据是在什么时间范围内收集的？该时间范围是否与实例相关数据的创建时间范围一致（例如，近期抓取的旧新闻文章）？如果不一致，请描述实例相关数据的创建时间范围。

论文及其附带资源由 Arxiv 在 2010 年至 2022 年间按照其正常工作流程收集。该数据集于 2022 年基于这些资源创建。

是否进行了任何伦理审查流程（例如，由机构审查委员会进行）？如果是，请提供这些审查流程的描述，包括结果，以及任何支持文档的链接或其他访问方式。

N/A

该数据集是否涉及个人？如果没有，您可以跳过本节剩余的问题。

编号

您是否直接从相关个人处收集数据，还是通过第三方或其他来源（如网站）获取数据？

N/A

相关个人是否已被告知数据收集事宜？如果是，请描述（或通过截图或其他信息展示）通知是如何提供的，并提供链接或其他访问方式，或以其他方式复现通知本身的准确措辞。

N/A

相关个人是否同意收集和使用其数据？如果是，请描述（或通过截图或其他信息展示）同意是如何请求和提供的，并提供链接或其他访问方式，或以其他方式复现个人所同意的准确措辞。

N/A

如果获得了同意，是否向同意的个人提供了在未来或针对某些用途撤销同意的机制？如果是，请提供描述，以及该机制的链接或其他访问方式（如适用）。

N/A

是否已对数据集及其使用对数据主体的潜在影响进行分析（例如，数据保护影响分析）是否已进行？若已进行，请提供该分析的描述，包括结果，以及任何支持文档的链接或其他访问点。

N/A

还有其他意见吗？

编号

预处理/清洗/标注

是否对数据进行了任何预处理/清洗/标注（例如，离散化或分桶、分词、词性标注、SIFT 特征提取、实例移除、缺失值处理）？若已进行，请提供描述。若未进行，可跳过本节其余问题。

为移除无关的源图像（如图表），我们手动标注了 2000 张图像，并训练了一个二分类图像分类器，用于对具有至少一张自然图像类图结构中的源图像赋予高分。随后，我们在整个数据集上使用该分类器，仅保留来自 23,302 篇不同论文的最具信息量的源图像。在对 100 个随机图的手动审查中，我们发现数据集对图表的清洁度达到 96%。每张保留的图图像随后被调整为最高 1024×1024 的分辨率，并以 PNG 格式保存。

除预处理/清洗/标注后的数据外，是否还保存了“原始”数据（例如，为支持未来未预见的用途）？若已保存，请提供“原始”数据的链接或其他访问点。

我们将发布原始图源文件链接列表。

用于预处理/清洗/标注实例的软件是否可用？若可用，请提供链接或其他访问点。

用于下载、提取和预处理图像的软件将公开发布。

还有其他意见吗？

编号

用途

该数据集是否已用于任何任务？ 如果是，请提供描述。

该数据集已用于无监督学习算法，例如预训练图像修复模型。

是否存在一个仓库，链接到使用该数据集的任何或所有论文或系统？ 如果有，请提供链接或其他访问点。

使用该数据集的部分论文列表将在评审阶段后提供。

该数据集还可以用于哪些（其他）任务？

其他潜在用例包括生成建模、图像检索和可解释性。

数据集的构成或收集方式是否存在任何可能影响未来使用的问题， 以及预处理、清理或标注过程中是否存在此类问题？例如，未来用户是否需要了解某些信息，以避免可能导致对个人或群体不公平对待（如刻板印象、服务质量问题）或其他不良危害（如经济损失、法律风险）的使用方式？如果存在，请提供说明。未来用户是否可以采取某些措施来减轻这些不良危害？

我们预计数据中不存在任何负面偏差或潜在危害。此外，由于 Arxiv 经过审核，我们预计不会出现冒犯性内容。

是否存在不应使用该数据集的任务？ 如果存在，请提供说明。

N/A

还有其他意见吗？

编号

分发

数据集是否会分发给创建该数据集的实体（如公司、机构、组织）之外的第三方？ 如果会，请提供说明。

数据集将在审查期结束后公开发布。

数据集将如何分发（例如，网站上的压缩包、应用程序编程接口、GitHub） 数据集是否有数字对象标识符（DOI）？

数据集将以逗号分隔（.csv）文件形式分发，描述 Arxiv 链接、划分和论文编号，包含原始图形来源。此外，我们将在“合理使用”的基础上提供数据集的直接下载，形式为压缩包。数据集的数字对象标识符将与本文相同。

数据集何时分发？

数据集将在评审期结束后提供。

数据集是否在版权或其他知识产权（IP）许可证下分发，和/或根据适用的使用条款（ToU）？ 如果是，请描述该许可证

和/或使用条款，并提供链接或其他访问点，或复制任何相关许可条款或使用条款，以及与这些限制相关的任何费用。

逗号分隔（.csv）文件和随附代码将在 MIT 许可证下分发。

是否有第三方对与实例相关的数据施加了基于知识产权或其他方面的限制？如果有，请描述这些限制，并提供相关许可条款的链接或其他访问途径，或另行复制这些条款，以及与这些限制相关的任何费用。

Arxiv 持有分发所有提交论文和源代码的（非独占性）许可

（<https://arxiv.org/licenses/nonexclusive-distrib/1.0/license.html>）。发布 Arxiv 源代码的下载链接符合该许可。按照惯例，我们可能允许在“合理使用”的基础上提供数据集的替代下载选项。

数据集或单个实例是否受到任何出口管制或其他监管限制的约束？如果有，请描述这些限制，并提供任何支持性文件的链接或其他访问途径，或另行复制这些文件。

编号

还有其他意见吗？

编号

维护

谁将支持/托管/维护该数据集？

论文作者将维护该数据集，该数据集将托管在 GitHub 上。

如何联系数据集的所有者/管理者/负责人（例如，电子邮件地址）？

我们将在评审期结束后公布联系信息。

是否有勘误？若可用，请提供链接或其他访问点。

编号

数据集是否会更新（例如，纠正标注错误、添加新实例、删除）实例）？如果是，请描述更新频率、由谁更新以及如何向用户传达更新（例如，邮件列表、GitHub）？

目前没有更新该数据集的计划。

如果数据集涉及人员，是否存在与实例相关数据保留的适用限制（例如，是否告知相关个人其数据将保留固定期限后删除）？若存在，请描述这些限制并说明将如何执行。

N/A

旧版本的数据集是否将继续得到支持、托管和维护？如果是，请描述如何实现。如果不是，请描述如何向用户传达其过时信息。

编号

如果其他人希望扩展、增强、构建或贡献数据集，是否有相应的机制？如果有，请提供描述。这些贡献

是否会经过验证或核实？如果是，请描述如何实现。如果不是，请说明原因。是否有向其他用户传达或分发这些贡献的流程？如果有，请提供描述。

贡献将通过标准开源工具实现，并以拉取请求的形式提交到相关的 GitHub 仓库。

还有其他意见吗？

编号