

VoxPoser: 面向语言模型机器人操作的可组合三维价值图

Wenlong Huang¹, Chen Wang¹, Ruohan Zhang¹, Yunzhu Li^{1,2}, Jiajun Wu¹, Li Fei-Fei¹

¹Stanford University ²University of Illinois Urbana-Champaign

摘要: 大语言模型 (LLMs) 被证明拥有丰富的可操作知识, 能够以推理和规划的形式提取出来用于机器人操作。尽管取得了进展, 大多数方法仍依赖预定义的运动基元来执行与环境的物理交互, 这仍然是一个主要瓶颈。在这项工作中, 我们旨在为大量操作任务合成机器人轨迹, 即给定开放式指令和开放式物体, 生成密集的六自由度末端执行器路径点序列。我们实现这一目标的方法是首先观察到, 大语言模型在给定自由形式语言指令时擅长推断可供性和约束。更重要的是, 通过利用它们的代码编写能力, 它们可以与视觉语言模型进行交互。

(视觉语言模型) 组合三维价值图, 将知识锚定到智能体的观测空间中。随后, 在基于模型的规划框架中利用组合后的价值图, 零样本合成闭环机器人轨迹, 并对动态扰动具有鲁棒性。本文进一步展示了所提框架如何通过高效学习涉及丰富接触交互场景的动力学模型, 从在线经验中获益。本文在仿真和真实机器人环境中对所提方法进行了大规模研究, 展示了执行以自由形式自然语言指定的各种日常操作任务的能力。视频和代码见 voxposer.github.io。

Keywords: Manipulation, Large Language Models, Model-based Planning




图 1: VOXPOSER 从大语言模型中提取语言条件化的可供性与约束, 并利用视觉语言模型将其映射到感知空间, 通过代码接口实现, 且无需对任一组件进行额外训练。所组合的映射称为三维价值图, 该图能够零样本综合轨迹, 适用于大量日常操作任务, 支持开放式指令集与开放式物体集。

通讯作者: 黄文龙 < wenlongh@stanford.edu >。

1 引言

语言是一种压缩媒介，人类通过它提炼并交流对世界的知识与经验。大语言模型（Large Language Models, LLMs）已成为捕捉这种抽象的有前景的方法，通过学习将世界投影到语言空间中表示世界 [1 – 4]。尽管这些模型被认为能够将可泛化的知识内化为文本，但如何利用这些知识使具身智能体在现实世界中执行物理动作，仍是一个待解决的问题。

我们研究将抽象语言指令（例如，“布置餐桌”）落地为机器人动作的问题 [5]。先前的工作利用词汇分析来解析指令 [6 – 8]，而近期的方法则使用语言模型将指令分解为文本形式的步骤序列 [9 – 11]。然而，为了实现与环境的物理交互，现有方法通常依赖于一组预定义的运动原语（即技能），这些原语可由大语言模型或规划器调用，而由于缺乏大规模机器人数据，对单个技能获取的依赖常被视为系统的主要瓶颈。由此产生的问题是：如何在不要费力收集数据或为每个单独原语进行手工设计的情况下，将大语言模型内化的丰富知识用于机器人的更细粒度动作层面？

在应对这一挑战时，我们首先注意到，让大语言模型直接以文本形式输出控制动作是不切实际的，因为这些动作通常由高维空间中的高频控制信号驱动。然而，我们发现大语言模型擅长推断以语言为条件的可供性和约束，并且通过利用其代码编写能力，它们可以组合密集的三维体素地图，通过编排感知调用（例如，通过对比语言-图像预训练模型（CLIP）[12] 或开放词汇检测器 [13 – 15]）和数组操作（例如，通过数值计算库（NumPy）[16]），将这些地图在视觉空间中落地。例如，给定指令“打开最上面的抽屉并小心花瓶”，可以提示大语言模型推断：1）应抓取最上面抽屉的把手，2）把手需要向外平移，3）机器人应远离花瓶。通过生成调用感知应用程序编程接口的 Python 代码，大语言模型可以获得相关物体或部件的空间几何信息，然后操纵三维体素，在观察空间中的相关位置规定奖励或代价（例如，把手区域被赋予高值，而花瓶周围被赋予低值）。最后，组合的价值地图可以作为运动规划器的目标函数，直接合成实现给定指令的机器人轨迹¹，而无需为每个任务或大语言模型提供额外的训练数据。图 1 展示了示意图和我们考虑的任务子集。

我们将这种方法称为体素位置器（**VOXPOSER**），这是一种从大语言模型中提取可供性和约束，在观察空间中组合三维价值地图以指导机器人交互的表述。该方法不依赖通常数量有限或变化性不足的机器人数据，而是在基于模型的规划框架中利用大语言模型进行开放世界推理，并利用视觉语言模型进行可泛化的视觉定位，从而直接实现物理机器人动作。我们展示了其在各种日常操作任务中，对开放集指令和开放集物体的零样本泛化能力。我们进一步展示了体素位置器如何从有限的在线交互中受益，以高效学习涉及接触丰富交互的动力学模型。

2 相关工作

语言指令落地。语言基础在智能体（Intelligent Agents）[19 – 22] 和机器人学（Robotics）[23, 6, 24, 25, 5, 7, 26] 领域均得到了广泛研究，其中语言可作为组合目标规范的工具 [5, 27 – 33]、训练多模态表征的语义锚点 [12, 34, 35]，或作为规划与推理的中间基底 [36 – 38, 9, 10, 39, 40]。先前工作已探索使用词法分析、形式逻辑和图模型等经典工具来解释语言指令 [27, 7, 6, 26]。近年来，端到端方法因在离线领域的成功应用而广受欢迎 [41 – 43, 1]，已被应用于通过从数据中学习来直接将语言指令落地到机器人交互中，并带有

¹该方法也与路径规划中的势场法 [17] 以及操作规划中的约束优化方法 [18] 存在相似之处和联系。

语言标注, 涵盖模型学习 [44]、模仿学习 [45, 46, 30, 47 – 54] 到强化学习 [55 – 57]。与本文工作最密切相关的是 Sharma 等人 [50] 的研究, 其中通过监督学习优化端到端代价预测器, 将语言指令映射到二维代价图, 用于引导运动规划器以无碰撞方式生成偏好轨迹。相比之下, 本文依赖预训练语言模型的开放世界知识, 并应对更具挑战性的三维机器人操作任务。

面向机器人学的语言模型。利用预训练语言模型进行具身应用是一个活跃的研究领域, 其中大量工作聚焦于使用语言模型进行规划与推理 [9 – 11, 58, 31, 39, 59 – 72, 36, 73, 74]。为使语言模型能够感知物理环境, 可以提供场景的文本描述 [39, 11, 59] 或感知应用程序编程接口 [75], 可以在解码过程中使用视觉 [67], 或者由多模态语言模型直接接收视觉输入 [68, 2]。除感知外, 为真正打通感知-行动回路, 具身语言模型还必须知道如何行动, 这通常通过预定义原语库来实现。Liang 等人 [75] 表明, 大语言模型展现出对底层控制有用的行为常识。尽管迹象令人鼓舞, 但仍需手工设计的运动原语, 而且虽然大语言模型已被证明能够组合顺序策略逻辑, 但组合能否在空间层面发生仍不清楚。另一条相关研究路线探索了在奖励设计 [76]、探索 [77 – 80] 和偏好学习 [81] 的背景下使用大语言模型进行奖励规范。在机器人应用中, 同期工作探索了基于大语言模型的奖励生成 [82 – 88], 其中 Yu 等人 [82] 使用 MuJoCo[89] 作为高保真物理模型进行模型预测控制。相比之下, 我们专注于将大语言模型生成的奖励完全锚定在机器人的三维观测空间中。

基于学习的轨迹优化。许多工作探索了利用基于学习的方法进行轨迹优化。尽管文献众多, 但可大致分为学习模型的方法 [90 – 98] 和学习代价/奖励或约束的方法 [99 – 102, 50, 103], 其中数据通常从域内交互中收集。为实现野外泛化, 另一条并行研究路线探索了从大规模离线数据 [104 – 106, 35, 34, 44, 107, 108, 54] (尤其是第一人称视频 [109, 110]) 中学习任务规范, 或利用预训练基础模型 [111 – 113, 33, 114, 115]。学习到的代价函数随后被强化学习 [111, 108, 116]、模仿学习 [106, 105] 或轨迹优化 [104, 35] 用于生成机器人动作。在本工作中, 我们利用大语言模型实现零样本野外代价规范, 具有优越的泛化能力。与先前利用基础模型的工作相比, 我们将代价直接锚定在具有实时视觉反馈的三维观测空间中, 这使得 VoxPoser 适用于闭环模型预测控制, 在执行中具有鲁棒性。

3 方法

我们首先给出体素姿态 (VoxPoser) 作为优化问题的表述 (第 3.1 节)。然后描述体素姿态如何作为一个通用的零样本框架, 将语言指令映射到三维价值图 (第 3.2 节)。随后展示如何在闭环中为机器人操作合成轨迹 (第 3.3 节)。尽管本质上是零样本的, 我们仍展示体素姿态如何从在线交互中学习, 以高效解决接触丰富的任务 (第 3.4 节)。

3.1 问题表述

考虑一个以自由形式语言指令 $\mathcal{L}$ 给出的操作问题 (例如, “打开最上面的抽屉”)。根据 $\mathcal{L}$ 生成机器人轨迹可能非常具有挑战性, 因为 $\mathcal{L}$ 可能任意长时程或欠指定 (即需要上下文理解)。相反, 我们关注问题的各个阶段 (子任务) ℓ_i , 这些阶段明确指定了一个操作任务 (例如, “抓住抽屉把手”, “拉开抽屉”), 其中分解 $\mathcal{L} \rightarrow (\ell_1, \ell_2, \dots, \ell_n)$ 由高层规划器 (例如, 大语言模型或基于搜索的规划器) ² 给出。核心问题 ² 注意, 这些子任务的分解和排序在本工作中也由大语言模型完成, 但我们没有广泛研究这一方面, 因为它不是我们贡献的重点。




图 2: 体素姿态 (VOXPOSER) 概述。给定环境的 RGB-D 观测和语言指令, 大语言模型生成代码, 与视觉语言模型交互, 产生一系列三维可供性图和约束图 (统称为价值图), 这些图基于机器人的观测空间 (a)。组合后的价值图随后作为运动规划器的目标函数, 为机器人操作合成轨迹 (b)。整个过程不涉及任何额外训练。

本工作研究的问题是为机器人 $\mathbf{r}$ 和由指令 ℓ_i 描述的每个操作阶段生成运动轨迹 τ_i^r 。我们将 τ_i^r 表示为一系列密集的末端执行器路径点, 由操作空间控制器 [117] 执行, 其中每个路径点包含期望的六自由度末端执行器位姿、末端执行器速度和夹爪动作。然而, 值得注意的是, 其他轨迹表示 (如关节空间轨迹) 也可以使用。给定由 ℓ_i 描述的第 i 个子任务, 我们构建如下优化问题:

$$\min_{\tau_i^r} \{ \mathcal{F}_{task}(\mathbf{T}_i, \ell_i) + \mathcal{F}_{control}(\tau_i^r) \} \quad \text{subject to} \quad \mathcal{C}(\mathbf{T}_i) \quad (1)$$

其中 $\mathbf{T}_i$ 是环境状态的演化, $\tau_i^r \subseteq \mathbf{T}_i$ 是机器人轨迹。 $\mathcal{F}_{task}$ 对 $\mathbf{T}_i$ 完成指令 ℓ_i 的程度进行评分, 而 $\mathcal{F}_{control}$ 指定控制代价, 例如鼓励 τ_i^r 最小化总控制量或总时间。 $\mathcal{C}(\mathbf{T}_i)$ 表示动力学和运动学约束, 这些约束由机器人的已知模型以及基于物理或基于学习的环境模型强制执行。通过对每个子任务 ℓ_i 求解该优化问题, 我们获得一系列机器人轨迹, 这些轨迹共同实现由指令 $\mathcal{L}$ 指定的总体任务。

3.2 通过体素姿态实现语言指令接地

针对自由形式语言指令计算 $\mathcal{F}_{task}$ 极具挑战性, 不仅因为语言所能传达的语义空间丰富, 还因为缺乏带有 $\mathbf{T}$ 和 ℓ 标注的机器人数据。然而, 我们提出一个关键观察: 大量任务可以通过机器人观测空间中的体素值图 $\mathbf{V} \in \mathbb{R}^{w \times h \times d}$ 来表征, 该图指导场景中“感兴趣实体”的运动, 例如机器人末端执行器、物体或物体部件。例如, 考虑图 2 中的任务“打开最上面的抽屉”及其第一个子任务“抓住最上面的抽屉把手” (由大语言模型推断)。“感兴趣实体”是机器人末端执行器, 体素值图应反映对抽屉把手的吸引力。通过进一步命令“小心花瓶”, 该图也可以更新以反映对花瓶的排斥力。我们将“感兴趣实体”记为 $\mathbf{e}$, 其轨迹记为 τ^e 。对于给定指令 ℓ_i , $\mathcal{F}_{task}$, 使用该体素值图可以通过累积 $\mathbf{e}$ 穿过 $\mathbf{V}_i$ 的值来近似, 正式计算为 $\mathcal{F}_{task} = -\sum_{j=1}^{|\tau_i^e|} \mathbf{V}(p_j^e)$, 其中 $p_j^e \in \mathbb{N}^3$ 是 $\mathbf{e}$ 在第 j 步的离散化 (x, y, z) 位置。

值得注意的是, 本文观察到, 大语言模型 (Large Language Model) 通过在海量互联网数据上进行预训练, 不仅具备识别“感兴趣实体”的能力, 还能通过编写 **Python** 程序来构建准确反映任务指令的价值图。具体而言, 当指令以代码注释的形式给出时, 可以引导大语言模型: 1) 调用感知应用程序编程接口 (API) 以获取相关物体的空间几何信息; 2) 生成 **NumPy** 操作来操纵三维数组; 3) 在相关位置指定精确的数值。本文将这种方法称为 **VOXPOSER**。具体来说, 本文旨在通过提示大语言模型并通过 **Python** 解释器执行代码来获得体素价值图 $\mathbf{V}_i^t = \text{VoxPoser}(\mathbf{o}^t, \ell_i)$, 其中 $\mathbf{o}^t$ 是时刻 t 的 RGB-D 观测, ℓ_i 是当前的




图 3: 真实环境中组合三维价值图与执行轨迹的可视化。顶行展示了“感兴趣实体”为物体或部件的情况，价值图引导它们到达目标位置。底两行展示了“感兴趣实体”为机器人末端执行器的任务。最底部的任务包含两个阶段，这些阶段同样由大语言模型协调。

指令。此外，由于 $\mathbf{V}$ 通常是稀疏的，本文通过平滑操作对体素图进行稠密化，因为这些操作有助于运动规划器优化出更平滑的轨迹。

额外的轨迹参数化。 上述 VOXPOSER 的公式化描述使用大语言模型来组合 $\mathbf{V} : \mathbb{N}^3 \rightarrow \mathbb{R}$ ，将体素空间中的离散坐标映射到实值“代价”，本文可以利用该代价来优化仅包含位置项的路径。为了扩展到 $SE(3)$ 姿态，本文还可以使用大语言模型在与任务目标相关的坐标处组合旋转图 $\mathbf{V}_r : \mathbb{N}^3 \rightarrow SO(3)$ （例如，“末端执行器应面向手柄的支撑法线”）。类似地，本文进一步组合夹爪图 $\mathbf{V}_g : \mathbb{N}^3 \rightarrow \{0, 1\}$ 以控制夹爪的开合，以及速度图 $\mathbf{V}_v : \mathbb{N}^3 \rightarrow \mathbb{R}$ 以指定目标速度。需要注意的是，虽然这些额外的轨迹参数化并未映射到实值“代价”，但它们也可以在优化过程（方程 1）中被考虑，以对轨迹进行参数化。

3.3 基于 VOXPOSER 的零样本轨迹综合

在获得任务代价 $\mathcal{F}_{task}$ 后，我们现在可以着手处理方程 1 中定义的完整问题，以规划运动轨迹。我们采用简单的零阶优化方法，通过随机采样轨迹并使用所提出的目标函数进行评分。该优化在模型预测控制框架中实现，该框架在每一步利用当前观测迭代地重新规划轨迹，从而即使在动态扰动下也能稳健地执行轨迹³，其中可以使用学习模型或基于物理的模型。然而，由于 VoxPoser 在观测空间中有效地提供了“密集奖励”，并且我们能够在每一步重新规划，我们惊讶地发现，即使使用简单的基于启发式的模型，整个系统已经能够完成本工作中考虑的各种操作任务。由于某些价值图定义在“感兴趣实体”上，该实体不一定是机器人，我们还使用动力学模型来寻找所需的机器人轨迹，以最小化任务代价（即，机器人与环境之间的何种交互能够实现期望的物体运动）。

3.4 利用在线经验进行高效动力学学习

虽然第 3.3 节提出了一个用于合成机器人操作轨迹的零样本框架，但 VoxPoser 还可以通过高效地学习动力学模型从在线经验中受益。考虑标准设置，其中机器人交替进行：1) 收集环境转移数据 $(\mathbf{o}_t, \mathbf{a}_t, \mathbf{o}_{t+1})$ ，其中 $\mathbf{o}_t$ 是时间 t 的环境观测， $\mathbf{a}_t$ 是 MPC $(\mathbf{o}_t)$ ；2) 通过最小化预测下一个观测与真实观测之间的 L2 损失来训练由 θ 参数化的动力学模型 $\mathbf{g}_\theta$ 。³ 尽管在循环中涉及 LLM，闭环执行是可能的，因为生成的代码在整个任务 ℓ_i 中保持不变，这使我们能够为当前任务缓存其输出。

观测 $\hat{\mathbf{o}}_{t+1}$ 与 $\mathbf{o}_{t+1}$ 。决定学习效率的关键因素是模型预测控制（MPC）中的动作采样分布 $P(\mathbf{a}_t|\mathbf{o}_t)$ ，该分布通常是整个动作空间 $\mathbf{A}$ 上的随机分布。当目标是解决特定任务（如开门）时，这种方式往往效率低下，因为大多数动作既不会与场景中的相关物体（即门把手）交互，也不一定以有意义的方式与物体交互（即按下门把手）。由于 VoxPoser 利用大语言模型（LLM）合成机器人轨迹，而大语言模型拥有丰富的常识知识，零样本合成的轨迹 τ_0^r 可作为有用的先验，用于偏置动作采样分布 $P(\mathbf{a}_t|\mathbf{o}_t, \tau_0^r)$ ，从而显著加速学习过程。实际实现中，可以仅在 τ_0^r 附近采样动作，并添加小噪声 ϵ 以鼓励局部探索，而非在整个动作空间 $\mathbf{A}$ 中探索。

4 实验与分析

首先讨论实现细节。随后在真实世界日常操作中验证 VoxPoser（第 4.1 节）。并在仿真中研究其泛化能力（第 4.2 节）。进一步展示 VoxPoser 如何高效学习更具挑战性的任务（第 4.3 节）。最后分析错误来源并讨论改进方向（第 4.4 节）。

大语言模型与提示。遵循 Liang 等人 [75] 的提示结构，该结构利用大语言模型自身生成的代码递归调用大语言模型，其中每个语言模型程序（LMP）负责一项独特功能（例如处理感知调用）。使用 OpenAI 应用程序编程接口（API）的 GPT-4[2]。对于每个语言模型程序，在提示中包含 5-20 个示例查询及对响应作为示例。示例见图 2（为清晰起见已简化）。完整提示见附录。

视觉语言模型与感知。给定来自大语言模型的物体/部件查询，首先调用开放词汇检测器 OWL-ViT[15] 获取边界框，然后将其输入到 Segment Anything[118] 中获得掩码，最后使用视频跟踪器 XMEM[119] 跟踪该掩码。跟踪得到的掩码与 RGB-D 观测结合，重建物体/部件的点云。

价值图合成。我们定义了以下类型的价值图：可供性、避障、末端执行器速度、末端执行器旋转和夹爪动作。每种类型使用不同的大语言模型程序（LMP），该程序接收指令并输出形状为 $(100, 100, 100, k)$ 的体素图，其中 k 因价值图而异（例如，可供性和避障为 $k = 1$ ，因为它指定代价；旋转为 $k = 4$ ，因为它指定 $\text{SO}(3)$ ）。我们对可供性图应用欧氏距离变换，对避障图应用高斯滤波。在价值图 LMP 之上，我们定义了两个高层 LMP 来协调它们的行为：规划器接收用户指令 $\mathcal{L}$ 作为输入（例如，“打开抽屉”）并输出子任务序列 $\ell_{1:N}$ ，组合器接收子任务 ℓ_i 并以详细的语言参数化调用相关的价值图 LMP。

运动规划器。在规划器优化中，我们仅考虑可供性和避障图，通过贪心搜索找到一系列无碰撞的末端执行器位置 $p_{1:N} \in \mathbb{R}^3$ 。然后，在每个 p 处通过其余价值图（例如，旋转图、速度图）强制执行其他参数化。运动规划器使用的代价图计算为归一化可供性和避障图加权求和的负值，权重分别为 2 和 1。在合成 6 自由度轨迹后，执行第一个路径点，然后以 5 赫兹的频率重新规划新轨迹。

动力学模型。我们在所有任务中使用已知的机器人动力学模型，该模型用于运动规划，使末端执行器跟随路径点。对于我们考虑的大多数任务，其中“感兴趣的实体”是机器人，不使用环境动力学模型（即假设场景是静态的），但我们在每一步重新规划以考虑最新观测。对于“感兴趣的实体”是物体的任务，我们仅研究由接触点、推动方向和推动距离参数化的平面推动模型。我们使用基于启发式的动力学模型，将输入点云沿推动方向平移推动距离。我们使用带有随机射击的模型预测控制（MPC）来优化动作参数。然后根据动作参数执行预定义的推动原语。然而，我们注意到，当动作参数定义在机器人的末端执行器或关节空间上时，原语并非必需，这可能会产生

Task	LLM + Prim. [75]		VoxPoser		Train/Test	Category	U-Net	Language Models	
	Static	Dist.	Static	Dist.			MP [50]	Prim. [75]	MP (Ours)
Move & Avoid	0/10	0/10	9/10	8/10	SI SA	Object Int.	21.0%	41.0%	64.0%
Set Up Table	7/10	0/10	9/10	7/10	SI SA	Composition	53.8%	43.8%	77.5%
Close Drawer	0/10	0/10	10/10	7/10	SI UA	Object Int.	3.0%	46.0%	60.0%
Open Bottle	5/10	0/10	7/10	5/10	SI UA	Composition	3.8%	25.0%	58.8%
Sweep Trash	0/10	0/10	9/10	8/10	UI UA	Object Int.	0.0%	17.5%	65.0%
Total	24.0%	0.0%	88.0%	70.0%	UI UA	Composition	0.0%	25.0%	76.7%

表 1：真实世界领域中的成功率。VoxPoser 在执行日常操作任务时具有较高的成功率，并且相比使用动作基元的基线方法，对于干扰具有更强的鲁棒性。

表 2：模拟领域中的成功率。“SI”和“UI”分别表示已见和未见指令。“SA”和“UA”分别表示已见和未见属性。VoxPoser 在来自两个类别的 13 项任务中，无论是已见还是未见任务，均优于两种基线方法，并保持相似的成功率。

轨迹更平滑，但优化耗时更长。我们还在第 4.3 节中探索了基于学习的动力学模型的使用，使 VoxPoser 能够从在线经验中获益。

4.1 面向日常操作任务的 VoxPoser

我们研究 VoxPoser 能否零样本合成机器人轨迹，以在真实世界中执行日常操作任务。环境设置的详细信息见附录 A.4。虽然所提方法可以泛化到开放式指令和开放式物体（如图 1 所示），但我们选取了 5 个代表性任务，在表 1 中提供定量评估。包括环境执行过程和值图可视化在内的定性结果如图 3 所示。我们发现 VoxPoser 能够以较高的平均成功率有效合成日常操作任务的机器人轨迹。由于具备快速重规划能力，它对外部干扰也具有鲁棒性，例如移动目标/障碍物，以及在机器人关闭抽屉后再次拉开抽屉。我们进一步与 Code as Policies 的一个变体 [75] 进行比较，该变体使用大语言模型对预定义的简单基元列表（例如移动到指定位置、打开夹爪）进行参数化。我们发现，与串联顺序策略逻辑相比，在联合优化方案下考虑其他约束的同时进行空间组合的能力是一种更灵活的表述方式，为更多操作任务解锁了可能性，并带来更稳健的执行。

4.2 对未见指令和属性的泛化

为了对泛化能力进行严格的定量评估，我们搭建了一个模拟的积木世界环境，该环境与真实机器人设置 [120, 121] 相对应，但包含 13 个高度可随机化的任务，共 2766 条独特指令。每个任务都配有模板化指令（例如，“将 [物体] 推到 [位置]”），其中包含从预定义列表中选出的可随机化属性。详情见附录 A.5。已见过的指令/属性可能出现在提示中（或监督基线的训练数据中）。任务分为两类：“物体交互”是需要与物体进行交互的任务，“空间组合”是涉及空间约束的任务（例如，在特定物体附近移动得更慢）。对于基线，我们通过对 [75] 的变体（将大语言模型与基元结合）和 [50] 的变体（学习一个 U 型网络 [122] 来合成用于运动规划的成本图），消融了 VoxPoser 的两个组成部分：大语言模型和运动规划器。表 2 展示了每个任务 20 个回合的平均成功率。我们发现 VoxPoser 在所有场景中都表现出优越的泛化能力。与学习到的成本规范相比，大语言模型通过显式推理可供性和约束，泛化得更好。另一方面，通过价值图组合将大语言模型知识建立在机器人感知中，而不是直接指定基元参数，提供了更大的灵活性和更好的泛化能力。

4.3 利用在线经验进行高效动力学学习

如第 3.4 节所述，我们研究了 VoxPoser 如何在模拟环境中，针对涉及更多接触细节的任务（如开门、开冰箱和开窗），可选地利用在线经验。具体来说，我们首先使用 VoxPoser 合成 k 零样本轨迹，

Task	Zero-Shot	No Prior		w/ Prior	
	Success	Success	Time(s)	Success	Time(s)
Door	6.7% $\pm$ 4.4%	58.3 $\pm$ 4.4%	TLE	88.3% $\pm$ 1.67%	142.3 $\pm$ 22.4
Window	3.3% $\pm$ 3.3%	36.7% $\pm$ 1.7%	TLE	80.0% $\pm$ 2.9%	137.0 $\pm$ 7.5
Fridge	18.3% $\pm$ 3.3%	70.0% $\pm$ 2.9%	TLE	91.7% $\pm$ 4.4%	71.0 $\pm$ 4.4




表 3: VoxPoser 通过使用零样本合成轨迹作为先验, 实现了高效的动力学学习。TLE (超出时间限制) 表示超过 12 小时。结果基于 3 次不同随机种子的运行。图 4: 各组件误差分解。VoxPoser 显著降低了规范误差。

每个都表示为一系列末端执行器路径点, 作为探索的先验 (例如, “为了打开门, 需要先按下把手”)。然后通过一个迭代过程学习多层感知机动力学模型, 其中智能体在数据收集和模型学习之间交替进行。在数据收集期间, 我们向 τ_0^* 中的每个路径点添加 $\varepsilon \sim \mathcal{N}(0, \sigma^2)$ 以鼓励局部探索。如表 3 所示, 我们发现零样本合成的轨迹通常是有意义的但不够充分。然而, 通过使用这些轨迹作为探索先验, 我们可以在不到 3 分钟的在线交互中学习有效的动力学模型, 从而实现较高的最终成功率。相比之下, 没有先验的探索都超过了 12 小时的最大限制。

4.4 误差分解

在本节中, 我们分析了 VoxPoser 各组件产生的误差以及整个系统如何进一步改进。我们在仿真中进行实验, 其中我们可以访问真实感知和动力学模型 (即仿真器)。“动力学误差”指动力学模型⁴产生的误差。“感知误差”指感知模块⁵产生的误差。“规范误差”指为低级运动规划器或原语指定成本或参数的模块产生的误差。每种方法的示例包括 1) U-Net 的噪声预测, 2) 大语言模型指定的不正确参数, 以及 3) 大语言模型指定的不正确值图。如图 4 所示, VoxPoser 由于其泛化和灵活性实现了最低的“规范误差”。我们还发现, 拥有更稳健的感知流程和物理真实的动力学模型有助于提高整体性能。这一观察结果与我们的真实世界实验一致, 其中大多数误差来自感知。例如, 我们发现检测器对物体的初始姿态敏感, 并且在检测物体部件时鲁棒性较差。

5 结论、局限性与未来工作

本文提出了体素姿态器 (VOXPOSER), 这是一个通用框架, 用于从大型语言模型 (LLMs) 和视觉语言模型 (VLMs) 中提取基于三维感知空间的可供性和约束, 以应对现实世界中的日常操作任务, 为开放集指令和物体提供了显著的泛化优势。尽管结果令人瞩目, 体素姿态器仍存在若干局限性。首先, 它依赖外部感知模块, 这在需要整体视觉推理或理解细粒度物体几何结构的任务中受到限制。其次, 虽然适用于高效动力学学习, 但仍需通用动力学模型才能以同等的泛化水平实现接触丰富的任务。第三, 我们的运动规划器仅考虑末端执行器轨迹, 而全臂规划也是可行的, 并且可能是更好的设计选择 [124 – 126]。最后, 大型语言模型需要人工提示工程。我们还看到了若干令人兴奋的未来工作方向。例如, 多模态大型语言模型 [68, 2, 127] 的最新成功可以直接转化为体素姿态器, 以实现直接的视觉定位。为对齐 [128, 129] 和提示 [130 – 133] 开发的方法可用于减轻提示工程的工作量。最后, 可以开发更先进的轨迹优化方法, 以最佳方式与体素姿态器合成的价值图进行接口。

⁴ 大型语言模型加原语 [75] 不使用基于模型的规划, 因此没有动力学模块。

⁵ U 型网络加运动规划 [50] 使用 U 型网络 [122, 123] 将红绿蓝深度图映射到代价图, 因此没有感知模块。这些错误归因于“规格说明错误”。

致谢

我们感谢安迪·曾 (Andy Zeng)、伊戈尔·莫达奇 (Igor Mordatch) 以及斯坦福视觉与学习实验室的成员们富有成效的讨论。这项工作部分得到了空军科学研究中心青年研究员计划 FA9550-23-1-0127、海军研究办公室多学科大学研究计划 N00014-22-1-2740、海军研究办公室多学科大学研究计划 N00014-21-1-2801、海军研究办公室 N00014-23-1-2355、斯坦福以人为本人工智能研究院 (HAI)、摩根大通和亚德诺半导体的支持。黄文龙部分由斯坦福工程学院奖学金资助。张若涵部分由吴蔡人类表现联盟奖学金资助。

参考文献

- [1] T. Brown, B. Mann, N. Ryder, M. Subbiah, J. D. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell, et al. Language models are few-shot learners. *Advances in neural information processing systems*, 33:1877–1901, 2020.
- [2] OpenAI. Gpt-4 technical report. *arXiv*, 2023.
- [3] A. Chowdhery, S. Narang, J. Devlin, M. Bosma, G. Mishra, A. Roberts, P. Barham, H. W. Chung, C. Sutton, S. Gehrmann, et al. Palm: Scaling language modeling with pathways. *arXiv preprint arXiv:2204.02311*, 2022.
- [4] R. Bommasani, D. A. Hudson, E. Adeli, R. Altman, S. Arora, S. von Arx, M. S. Bernstein, J. Bohg, A. Bosselut, E. Brunskill, et al. On the opportunities and risks of foundation models. *arXiv preprint arXiv:2108.07258*, 2021.
- [5] S. Tellex, N. Gopalan, H. Kress-Gazit, and C. Matuszek. Robots that use language. *Annual Review of Control, Robotics, and Autonomous Systems*, 2020.
- [6] S. Tellex, T. Kollar, S. Dickerson, M. Walter, A. Banerjee, S. Teller, and N. Roy. Understanding natural language commands for robotic navigation and mobile manipulation. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 25, pages 1507–1514, 2011.
- [7] T. Kollar, S. Tellex, D. Roy, and N. Roy. Toward understanding natural language directions. In *2010 5th ACM/IEEE International Conference on Human-Robot Interaction (HRI)*, pages 259–266. IEEE, 2010.
- [8] M. Bollini, S. Tellex, T. Thompson, N. Roy, and D. Rus. Interpreting and executing recipes with a cooking robot. In *Experimental Robotics*, pages 481–495. Springer, 2013.
- [9] W. Huang, P. Abbeel, D. Pathak, and I. Mordatch. Language models as zero-shot planners: Extracting actionable knowledge for embodied agents. In *International Conference on Machine Learning*. PMLR, 2022.
- [10] M. Ahn, A. Brohan, N. Brown, Y. Chebotar, O. Cortes, B. David, C. Finn, K. Gopalakrishnan, K. Hausman, A. Herzog, D. Ho, J. Hsu, J. Ibarz, B. Ichter, A. Irpan, E. Jang, R. J. Ruano, K. Jeffrey, S. Jesmonth, N. Joshi, R. Julian, D. Kalashnikov, Y. Kuang, K.-H. Lee, S. Levine, Y. Lu, L. Luu, C. Parada, P. Pastor, J. Quiambao, K. Rao, J. Rettinghouse, D. Reyes, P. Sermanet, N. Sievers, C. Tan, A. Toshev, V. Vanhoucke, F. Xia, T. Xiao, P. Xu, S. Xu, and M. Yan. Do as i can and not as i say: Grounding language in robotic affordances. In *arXiv preprint arXiv:2204.01691*, 2022.
- [11] A. Zeng, A. Wong, S. Welker, K. Choromanski, F. Tombari, A. Purohit, M. Ryoo, V. Sindhwani, J. Lee, V. Vanhoucke, et al. Socratic models: Composing zero-shot multimodal reasoning with language. *arXiv preprint arXiv:2204.00598*, 2022.
- [12] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, et al. Learning transferable visual models from natural language supervision. In *International Conference on Machine Learning*, pages 8748–8763. PMLR, 2021.

- [13] X. Gu, T.-Y. Lin, W. Kuo, and Y. Cui. Open-vocabulary object detection via vision and language knowledge distillation. *arXiv preprint arXiv:2104.13921*, 2021.
- [14] A. Kamath, M. Singh, Y. LeCun, G. Synnaeve, I. Misra, and N. Carion. Mdetr-modulated detection for end-to-end multi-modal understanding. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 1780–1790, 2021.
- [15] M. Minderer, A. Gritsenko, A. Stone, M. Neumann, D. Weissenborn, A. Dosovitskiy, A. Mahendran, A. Arnab, M. Dehghani, Z. Shen, et al. Simple open-vocabulary object detection with vision transformers. *arXiv preprint arXiv:2205.06230*, 2022.
- [16] C. R. Harris, K. J. Millman, S. J. van der Walt, R. Gommers, P. Virtanen, D. Cournapeau, E. Wieser, J. Taylor, S. Berg, N. J. Smith, R. Kern, M. Picus, S. Hoyer, M. H. van Kerkwijk, M. Brett, A. Haldane, J. F. del Río, M. Wiebe, P. Peterson, P. Gérard-Marchant, K. Sheppard, T. Reddy, W. Weckesser, H. Abbasi, C. Gohlke, and T. E. Oliphant. Array programming with NumPy. *Nature*, 585(7825):357–362, Sept. 2020. doi:10.1038/s41586-020-2649-2. URL <https://doi.org/10.1038/s41586-020-2649-2>.
- [17] Y. K. Hwang, N. Ahuja, et al. A potential field approach to path planning. *IEEE transactions on robotics and automation*, 8(1):23–32, 1992.
- [18] M. Toussaint, J. Harris, J.-S. Ha, D. Driess, and W. Hönig. Sequence-of-constraints mpc: Reactive timing-optimal control of sequential manipulation. In *2022 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 13753–13760. IEEE, 2022.
- [19] J. Andreas, D. Klein, and S. Levine. Learning with latent language. *arXiv preprint arXiv:1711.00482*, 2017.
- [20] R. Zellers, A. Holtzman, M. Peters, R. Mottaghi, A. Kembhavi, A. Farhadi, and Y. Choi. Piglet: Language grounding through neuro-symbolic interaction in a 3d world. *arXiv preprint arXiv:2106.00188*, 2021.
- [21] R. Zellers, X. Lu, J. Hessel, Y. Yu, J. S. Park, J. Cao, A. Farhadi, and Y. Choi. Merlot: Multimodal neural script knowledge models. *Advances in Neural Information Processing Systems*, 2021.
- [22] V. Shwartz, P. West, R. L. Bras, C. Bhagavatula, and Y. Choi. Unsupervised commonsense question answering with self-talk. *arXiv preprint arXiv:2004.05483*, 2020.
- [23] T. Winograd. Procedures as a representation for data in a computer program for understanding natural language. Technical report, MASSACHUSETTS INST OF TECH CAMBRIDGE PROJECT MAC, 1971.
- [24] V. Blukis, R. A. Knepper, and Y. Artzi. Few-shot object grounding and mapping for natural language robot instruction following. *arXiv preprint arXiv:2011.07384*, 2020.
- [25] S. Tellex, R. Knepper, A. Li, D. Rus, and N. Roy. Asking for help using inverse semantics. *Robotics: Science and Systems Foundation*, 2014.
- [26] T. Kollar, S. Tellex, D. Roy, and N. Roy. Grounding verbs of motion in natural language commands to robots. In *Experimental robotics*, pages 31–47. Springer, 2014.
- [27] J. Thomason, S. Zhang, R. J. Mooney, and P. Stone. Learning to interpret natural language commands through human-robot dialog. In *Twenty-Fourth International Joint Conference on Artificial Intelligence*, 2015.
- [28] J. Thomason, A. Padmakumar, J. Sinapov, N. Walker, Y. Jiang, H. Yedidsion, J. Hart, P. Stone, and R. Mooney. Jointly improving parsing and perception for natural language commands through human-robot dialog. *Journal of Artificial Intelligence Research*, 67:327–374, 2020.

- [29] E. Jang, A. Irpan, M. Khansari, D. Kappler, F. Ebert, C. Lynch, S. Levine, and C. Finn. Bc-z: Zero-shot task generalization with robotic imitation learning. In *Conference on Robot Learning*, pages 991–1002. PMLR, 2021.
- [30] A. Brohan, N. Brown, J. Carbajal, Y. Chebotar, J. Dabis, C. Finn, K. Gopalakrishnan, K. Hausman, A. Herzog, J. Hsu, et al. Rt-1: Robotics transformer for real-world control at scale. *arXiv preprint arXiv:2212.06817*, 2022.
- [31] D. Shah, B. Osinski, B. Ichter, and S. Levine. Lm-nav: Robotic navigation with large pre-trained models of language, vision, and action. *arXiv preprint arXiv:2207.04429*, 2022.
- [32] Y. Cui, S. Karamcheti, R. Palleti, N. Shivakumar, P. Liang, and D. Sadigh. ”no, to the right”—online language corrections for robotic manipulation via shared autonomy. *arXiv preprint arXiv:2301.02555*, 2023.
- [33] A. Stone, T. Xiao, Y. Lu, K. Gopalakrishnan, K.-H. Lee, Q. Vuong, P. Wohlhart, B. Zitkovich, F. Xia, C. Finn, et al. Open-world object manipulation using pre-trained vision-language models. *arXiv preprint arXiv:2303.00905*, 2023.
- [34] S. Nair, A. Rajeswaran, V. Kumar, C. Finn, and A. Gupta. R3m: A universal visual representation for robot manipulation. *arXiv preprint arXiv:2203.12601*, 2022.
- [35] Y. J. Ma, V. Kumar, A. Zhang, O. Bastani, and D. Jayaraman. Liv: Language-image representations and rewards for robotic control. *arXiv e-prints*, 2023.
- [36] P. A. Jansen. Visually-grounded planning without vision: Language models infer detailed plans from high-level instructions. *arXiv preprint arXiv:2009.14259*, 2020.
- [37] V. Micheli and F. Fleuret. Language models are few-shot butlers. *arXiv preprint arXiv:2104.07972*, 2021.
- [38] P. Sharma, A. Torralba, and J. Andreas. Skill induction and planning with latent language. *arXiv preprint arXiv:2110.01517*, 2021.
- [39] W. Huang, F. Xia, T. Xiao, H. Chan, J. Liang, P. Florence, A. Zeng, J. Tompson, I. Mordatch, Y. Chebotar, P. Sermanet, N. Brown, T. Jackson, L. Luu, S. Levine, K. Hausman, and B. Ichter. Inner monologue: Embodied reasoning through planning with language models. In *arXiv preprint arXiv:2207.05608*, 2022.
- [40] B. Z. Li, W. Chen, P. Sharma, and J. Andreas. Lampp: Language models as probabilistic priors for perception and action. *arXiv e-prints*, pages arXiv–2302, 2023.
- [41] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei. ImageNet: A Large-Scale Hierarchical Image Database. In *CVPR09*, 2009.
- [42] A. Krizhevsky, I. Sutskever, and G. E. Hinton. Imagenet classification with deep convolutional neural networks. *Communications of the ACM*, 60(6):84–90, 2017.
- [43] A. Radford, J. Wu, R. Child, D. Luan, D. Amodei, and I. Sutskever. Language models are unsupervised multitask learners. *OpenAI blog*, 1(8):9, 2019.
- [44] S. Nair, E. Mitchell, K. Chen, S. Savarese, C. Finn, et al. Learning language-conditioned robot behavior from offline data and crowd-sourced annotation. In *Conference on Robot Learning*, pages 1303–1315. PMLR, 2022.
- [45] M. Shridhar, L. Manuelli, and D. Fox. Cliport: What and where pathways for robotic manipulation. In *Conference on Robot Learning*, pages 894–906. PMLR, 2022.
- [46] M. Shridhar, L. Manuelli, and D. Fox. Perceiver-actor: A multi-task transformer for robotic manipulation. In *Proceedings of the 6th Conference on Robot Learning (CoRL)*, 2022.

- [47] S. Li, X. Puig, Y. Du, C. Wang, E. Akyurek, A. Torralba, J. Andreas, and I. Mordatch. Pre-trained language models for interactive decision-making. *arXiv preprint arXiv:2202.01771*, 2022.
- [48] O. Mees, L. Hermann, and W. Burgard. What matters in language conditioned robotic imitation learning. *arXiv preprint arXiv:2204.06252*, 2022.
- [49] O. Mees, J. Borja-Diaz, and W. Burgard. Grounding language with visual affordances over unstructured data. *arXiv preprint arXiv:2210.01911*, 2022.
- [50] P. Sharma, B. Sundaralingam, V. Blukis, C. Paxton, T. Hermans, A. Torralba, J. Andreas, and D. Fox. Correcting robot plans with natural language feedback. *arXiv preprint arXiv:2204.05186*, 2022.
- [51] W. Liu, C. Paxton, T. Hermans, and D. Fox. Structformer: Learning spatial structure for language-guided semantic rearrangement of novel objects. In *2022 International Conference on Robotics and Automation (ICRA)*, pages 6322–6329. IEEE, 2022.
- [52] C. Lynch and P. Sermanet. Language conditioned imitation learning over unstructured data. *Robotics: Science and Systems*, 2021. URL <https://arxiv.org/abs/2005.07648>.
- [53] C. Lynch, A. Wahid, J. Tompson, T. Ding, J. Betker, R. Baruch, T. Armstrong, and P. Florence. Interactive language: Talking to robots in real time. *arXiv preprint arXiv:2210.06407*, 2022.
- [54] L. Shao, T. Migimatsu, Q. Zhang, K. Yang, and J. Bohg. Concept2robot: Learning manipulation concepts from instructions and human demonstrations. *The International Journal of Robotics Research*, 40(12-14):1419–1434, 2021.
- [55] J. Luketina, N. Nardelli, G. Farquhar, J. N. Foerster, J. Andreas, E. Grefenstette, S. Whiteson, and T. Rocktäschel. A survey of reinforcement learning informed by natural language. In *IJCAI*, 2019.
- [56] J. Andreas, D. Klein, and S. Levine. Modular multitask reinforcement learning with policy sketches. *ArXiv*, abs/1611.01796, 2017.
- [57] Y. Jiang, S. S. Gu, K. P. Murphy, and C. Finn. Language as an abstraction for hierarchical deep reinforcement learning. *Advances in Neural Information Processing Systems*, 32, 2019.
- [58] B. Chen, F. Xia, B. Ichter, K. Rao, K. Gopalakrishnan, M. S. Ryoo, A. Stone, and D. Kappler. Open-vocabulary queryable scene representations for real world planning. *arXiv preprint arXiv:2209.09874*, 2022.
- [59] I. Singh, V. Blukis, A. Mousavian, A. Goyal, D. Xu, J. Tremblay, D. Fox, J. Thomason, and A. Garg. Progprompt: Generating situated robot task plans using large language models. *arXiv preprint arXiv:2209.11302*, 2022.
- [60] C. Huang, O. Mees, A. Zeng, and W. Burgard. Visual language maps for robot navigation. *arXiv preprint arXiv:2210.05714*, 2022.
- [61] S. S. Raman, V. Cohen, E. Rosen, I. Idrees, D. Paulius, and S. Tellex. Planning with large language models via corrective re-prompting. *arXiv preprint arXiv:2211.09935*, 2022.
- [62] C. H. Song, J. Wu, C. Washington, B. M. Sadler, W.-L. Chao, and Y. Su. Llm-planner: Few-shot grounded planning for embodied agents with large language models. *arXiv preprint arXiv:2212.04088*, 2022.
- [63] B. Liu, Y. Jiang, X. Zhang, Q. Liu, S. Zhang, J. Biswas, and P. Stone. Llm+ p: Empowering large language models with optimal planning proficiency. *arXiv preprint arXiv:2304.11477*, 2023.

- [64] S. Vemprala, R. Bonatti, A. Buckner, and A. Kapoor. Chatgpt for robotics: Design principles and model abilities. 2023, 2023.
- [65] K. Lin, C. Agia, T. Migimatsu, M. Pavone, and J. Bohg. Text2motion: From natural language instructions to feasible plans. *arXiv preprint arXiv:2303.12153*, 2023.
- [66] Y. Ding, X. Zhang, C. Paxton, and S. Zhang. Task and motion planning with large language models for object rearrangement. *arXiv preprint arXiv:2303.06247*, 2023.
- [67] W. Huang, F. Xia, D. Shah, D. Driess, A. Zeng, Y. Lu, P. Florence, I. Mordatch, S. Levine, K. Hausman, et al. Grounded decoding: Guiding text generation with grounded models for robot control. *arXiv preprint arXiv:2303.00855*, 2023.
- [68] D. Driess, F. Xia, M. S. Sajjadi, C. Lynch, A. Chowdhery, B. Ichter, A. Wahid, J. Tompson, Q. Vuong, T. Yu, et al. Palm-e: An embodied multimodal language model. *arXiv preprint arXiv:2303.03378*, 2023.
- [69] H. Yuan, C. Zhang, H. Wang, F. Xie, P. Cai, H. Dong, and Z. Lu. Plan4mc: Skill reinforcement learning and planning for open-world minecraft tasks. *arXiv preprint arXiv:2303.16563*, 2023.
- [70] Y. Xie, C. Yu, T. Zhu, J. Bai, Z. Gong, and H. Soh. Translating natural language to planning goals with large-language models. *arXiv preprint arXiv:2302.05128*, 2023.
- [71] Y. Lu, P. Lu, Z. Chen, W. Zhu, X. E. Wang, and W. Y. Wang. Multimodal procedural planning via dual text-image prompting. *arXiv preprint arXiv:2305.01795*, 2023.
- [72] D. Patel, H. Eghbalzadeh, N. Kamra, M. L. Iuzzolino, U. Jain, and R. Desai. Pretrained language models as visual planners for human assistance. *arXiv preprint arXiv:2304.09179*, 2023.
- [73] G. Wang, Y. Xie, Y. Jiang, A. Mandlekar, C. Xiao, Y. Zhu, L. Fan, and A. Anandkumar. Voyager: An open-ended embodied agent with large language models. *arXiv preprint arXiv:2305.16291*, 2023.
- [74] J. Yang, W. Tan, C. Jin, B. Liu, J. Fu, R. Song, and L. Wang. Pave the way to grasp anything: Transferring foundation models for universal pick-place robots. *arXiv preprint arXiv:2306.05716*, 2023.
- [75] J. Liang, W. Huang, F. Xia, P. Xu, K. Hausman, B. Ichter, P. Florence, and A. Zeng. Code as policies: Language model programs for embodied control. *arXiv preprint arXiv:2209.07753*, 2022.
- [76] M. Kwon, S. M. Xie, K. Bullard, and D. Sadigh. Reward design with language models. *arXiv preprint arXiv:2303.00001*, 2023.
- [77] A. Tam, N. Rabinowitz, A. Lampinen, N. A. Roy, S. Chan, D. Strouse, J. Wang, A. Banino, and F. Hill. Semantic exploration from language abstractions and pretrained representations. *Advances in Neural Information Processing Systems*, 35:25377–25389, 2022.
- [78] J. Mu, V. Zhong, R. Raileanu, M. Jiang, N. Goodman, T. Rocktäschel, and E. Grefenstette. Improving intrinsic exploration with language abstractions. *arXiv preprint arXiv:2202.08938*, 2022.
- [79] C. Colas, T. Karch, N. Lair, J.-M. Dussoux, C. Moulin-Frier, P. Dominey, and P.-Y. Oudeyer. Language as a cognitive tool to imagine goals in curiosity driven exploration. *Advances in Neural Information Processing Systems*, 33:3761–3774, 2020.

- [80] Y. Du, O. Watkins, Z. Wang, C. Colas, T. Darrell, P. Abbeel, A. Gupta, and J. Andreas. Guiding pretraining in reinforcement learning with large language models. *arXiv preprint arXiv:2302.06692*, 2023.
- [81] H. Hu and D. Sadigh. Language instructed reinforcement learning for human-ai coordination. *arXiv preprint arXiv:2304.07297*, 2023.
- [82] W. Yu, N. Gileadi, C. Fu, S. Kirmani, K.-H. Lee, M. G. Arenas, H.-T. L. Chiang, T. Erez, L. Hasenclever, J. Humplik, et al. Language to rewards for robotic skill synthesis. *arXiv preprint arXiv:2306.08647*, 2023.
- [83] H. Ha, P. Florence, and S. Song. Scaling up and distilling down: Language-guided robot skill acquisition. *arXiv preprint arXiv:2307.14535*, 2023.
- [84] Y. J. Ma, W. Liang, G. Wang, D.-A. Huang, O. Bastani, D. Jayaraman, Y. Zhu, L. Fan, and A. Anandkumar. Eureka: Human-level reward design via coding large language models. *arXiv preprint arXiv:2310.12931*, 2023.
- [85] T. Xie, S. Zhao, C. H. Wu, Y. Liu, Q. Luo, V. Zhong, Y. Yang, and T. Yu. Text2reward: Automated dense reward function generation for reinforcement learning. *arXiv preprint arXiv:2309.11489*, 2023.
- [86] Y. Zeng and Y. Xu. Learning reward for physical skills using large language model. *arXiv preprint arXiv:2310.14092*, 2023.
- [87] J. Rocamonde, V. Montesinos, E. Nava, E. Perez, and D. Lindner. Vision-language models are zero-shot reward models for reinforcement learning. *arXiv preprint arXiv:2310.12921*, 2023.
- [88] J. Perez, D. Proux, C. Roux, and M. Niemaiz. Larg, language-based automatic reward and goal generation. *arXiv preprint arXiv:2306.10985*, 2023.
- [89] E. Todorov, T. Erez, and Y. Tassa. Mujoco: A physics engine for model-based control. In *2012 IEEE/RSJ International Conference on Intelligent Robots and Systems*, 2012.
- [90] I. Lenz, R. A. Knepper, and A. Saxena. Deepmpc: Learning deep latent features for model predictive control. In *Robotics: Science and Systems*, volume 10. Rome, Italy, 2015.
- [91] L. Hewing, K. P. Wabersich, M. Menner, and M. N. Zeilinger. Learning-based model predictive control: Toward safe learning in control. *Annual Review of Control, Robotics, and Autonomous Systems*, 3:269–296, 2020.
- [92] M. B. Chang, T. Ullman, A. Torralba, and J. B. Tenenbaum. A compositional object-based approach to learning physical dynamics. *arXiv preprint arXiv:1612.00341*, 2016.
- [93] P. Battaglia, R. Pascanu, M. Lai, D. Jimenez Rezende, et al. Interaction networks for learning about objects, relations and physics. *Advances in neural information processing systems*, 29, 2016.
- [94] Z. Xu, J. Wu, A. Zeng, J. B. Tenenbaum, and S. Song. Densephysnet: Learning dense physical object representations via multi-step dynamic interactions. *arXiv preprint arXiv:1906.03853*, 2019.
- [95] A. Byravan and D. Fox. Se3-nets: Learning rigid body motion using deep neural networks. In *2017 IEEE International Conference on Robotics and Automation (ICRA)*, pages 173–180. IEEE, 2017.
- [96] A. Nagabandi, K. Konolige, S. Levine, and V. Kumar. Deep dynamics models for learning dexterous manipulation. In *Conference on Robot Learning*, pages 1101–1112. PMLR, 2020.

- [97] A. Sanchez-Gonzalez, N. Heess, J. T. Springenberg, J. Merel, M. Riedmiller, R. Hadsell, and P. Battaglia. Graph networks as learnable physics engines for inference and control. In *International Conference on Machine Learning*, pages 4470–4479. PMLR, 2018.
- [98] Y. Li, J. Wu, R. Tedrake, J. B. Tenenbaum, and A. Torralba. Learning particle dynamics for manipulating rigid bodies, deformable objects, and fluids. *arXiv preprint arXiv:1810.01566*, 2018.
- [99] C. Finn, S. Levine, and P. Abbeel. Guided cost learning: Deep inverse optimal control via policy optimization. In *International conference on machine learning*, pages 49–58. PMLR, 2016.
- [100] J. Fu, K. Luo, and S. Levine. Learning robust rewards with adversarial inverse reinforcement learning. *arXiv preprint arXiv:1710.11248*, 2017.
- [101] D. Driess, O. Oguz, J.-S. Ha, and M. Toussaint. Deep visual heuristics: Learning feasibility of mixed-integer programs for manipulation planning. In *2020 IEEE International Conference on Robotics and Automation (ICRA)*, pages 9563–9569. IEEE, 2020.
- [102] B. Amos, I. Jimenez, J. Sacks, B. Boots, and J. Z. Kolter. Differentiable mpc for end-to-end planning and control. *Advances in neural information processing systems*, 31, 2018.
- [103] M. Mittal, D. Hoeller, F. Farshidian, M. Hutter, and A. Garg. Articulated object interaction in unknown scenes with whole-body mobile manipulation. In *2022 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 1647–1654. IEEE, 2022.
- [104] S. Bahl, A. Gupta, and D. Pathak. Human-to-robot imitation in the wild. *arXiv preprint arXiv:2207.09450*, 2022.
- [105] S. Bahl, R. Mendonca, L. Chen, U. Jain, and D. Pathak. Affordances from human videos as a versatile representation for robotics. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 13778–13790, 2023.
- [106] C. Wang, L. Fan, J. Sun, R. Zhang, L. Fei-Fei, D. Xu, Y. Zhu, and A. Anandkumar. Mimicplay: Long-horizon imitation learning by watching human play. *arXiv preprint arXiv:2302.12422*, 2023.
- [107] H. Bharadhwaj, A. Gupta, S. Tulsiani, and V. Kumar. Zero-shot robot manipulation from passive human videos. *arXiv preprint arXiv:2302.02011*, 2023.
- [108] Y. J. Ma, S. Sodhani, D. Jayaraman, O. Bastani, V. Kumar, and A. Zhang. Vip: Towards universal visual reward and representation via value-implicit pre-training. *arXiv preprint arXiv:2210.00030*, 2022.
- [109] D. Damen, H. Doughty, G. M. Farinella, S. Fidler, A. Furnari, E. Kazakos, D. Moltisanti, J. Munro, T. Perrett, W. Price, et al. Scaling egocentric vision: The epic-kitchens dataset. In *Proceedings of the European Conference on Computer Vision (ECCV)*, pages 720–736, 2018.
- [110] K. Grauman, A. Westbury, E. Byrne, Z. Chavis, A. Furnari, R. Girdhar, J. Hamburger, H. Jiang, M. Liu, X. Liu, et al. Ego4d: Around the world in 3,000 hours of egocentric video. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 18995–19012, 2022.
- [111] Y. Cui, S. Niekum, A. Gupta, V. Kumar, and A. Rajeswaran. Can foundation models perform zero-shot task specification for robot manipulation? In *Learning for Dynamics and Control Conference*, pages 893–905. PMLR, 2022.
- [112] T. Yu, T. Xiao, A. Stone, J. Tompson, A. Brohan, S. Wang, J. Singh, C. Tan, J. Peralta, B. Ichter, et al. Scaling robot learning with semantically imagined experience. *arXiv preprint arXiv:2302.11550*, 2023.

- [113] Z. Mandi, H. Bharadhwaj, V. Moens, S. Song, A. Rajeswaran, and V. Kumar. Cacti: A framework for scalable multi-task multi-scene visual imitation learning. *arXiv preprint arXiv:2212.05711*, 2022.
- [114] T. Xiao, H. Chan, P. Sermanet, A. Wahid, A. Brohan, K. Hausman, S. Levine, and J. Tompson. Robotic skill acquisition via instruction augmentation with vision-language models. *arXiv preprint arXiv:2211.11736*, 2022.
- [115] C. Wang, D. Xu, and L. Fei-Fei. Generalizable task planning through representation pretraining. *IEEE Robotics and Automation Letters*, 7(3):8299–8306, 2022.
- [116] C. Li, R. Zhang, J. Wong, C. Gokmen, S. Srivastava, R. Martín-Martín, C. Wang, G. Levine, M. Lingelbach, J. Sun, et al. Behavior-1k: A benchmark for embodied ai with 1,000 everyday activities and realistic simulation. In *Conference on Robot Learning*, pages 80–93. PMLR, 2023.
- [117] O. Khatib. A unified approach for motion and force control of robot manipulators: The operational space formulation. *IEEE Journal on Robotics and Automation*, 3(1):43–53, 1987.
- [118] A. Kirillov, E. Mintun, N. Ravi, H. Mao, C. Rolland, L. Gustafson, T. Xiao, S. Whitehead, A. C. Berg, W.-Y. Lo, et al. Segment anything. *arXiv preprint arXiv:2304.02643*, 2023.
- [119] H. K. Cheng and A. G. Schwing. Xmem: Long-term video object segmentation with an atkinson-shiffrin memory model. In *Computer Vision–ECCV 2022: 17th European Conference, Tel Aviv, Israel, October 23–27, 2022, Proceedings, Part XXVIII*, pages 640–658. Springer, 2022.
- [120] F. Xiang, Y. Qin, K. Mo, Y. Xia, H. Zhu, F. Liu, M. Liu, H. Jiang, Y. Yuan, H. Wang, et al. Sapien: A simulated part-based interactive environment. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 11097–11107, 2020.
- [121] K. Mo, L. J. Guibas, M. Mukadam, A. Gupta, and S. Tulsiani. Where2act: From pixels to actions for articulated 3d objects. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 6813–6823, 2021.
- [122] O. Ronneberger, P. Fischer, and T. Brox. U-net: Convolutional networks for biomedical image segmentation. In *Medical Image Computing and Computer-Assisted Intervention–MICCAI 2015: 18th International Conference, Munich, Germany, October 5–9, 2015, Proceedings, Part III 18*, pages 234–241. Springer, 2015.
- [123] Ö. Çiçek, A. Abdulkadir, S. S. Lienkamp, T. Brox, and O. Ronneberger. 3d u-net: learning dense volumetric segmentation from sparse annotation. In *Medical Image Computing and Computer-Assisted Intervention–MICCAI 2016: 19th International Conference, Athens, Greece, October 17–21, 2016, Proceedings, Part II 19*, pages 424–432. Springer, 2016.
- [124] L. E. Kavraki, P. Svestka, J.-C. Latombe, and M. H. Overmars. Probabilistic roadmaps for path planning in high-dimensional configuration spaces. *IEEE transactions on Robotics and Automation*, 12(4):566–580, 1996.
- [125] N. D. Ratliff, J. Issac, D. Kappler, S. Birchfield, and D. Fox. Riemannian motion policies. *arXiv preprint arXiv:1801.02854*, 2018.
- [126] T. Marcucci, M. Petersen, D. von Wrangel, and R. Tedrake. Motion planning around obstacles with convex optimization. *arXiv preprint arXiv:2205.04422*, 2022.
- [127] J. Li, D. Li, S. Savarese, and S. Hoi. Blip-2: Bootstrapping language-image pre-training with frozen image encoders and large language models. *arXiv preprint arXiv:2301.12597*, 2023.

- [128] L. Ouyang, J. Wu, X. Jiang, D. Almeida, C. L. Wainwright, P. Mishkin, C. Zhang, S. Agarwal, K. Slama, A. Ray, et al. Training language models to follow instructions with human feedback. *arXiv preprint arXiv:2203.02155*, 2022.
- [129] Y. Bai, S. Kadavath, S. Kundu, A. Askell, J. Kernion, A. Jones, A. Chen, A. Goldie, A. Mirhoseini, C. McKinnon, et al. Constitutional ai: Harmlessness from ai feedback. *arXiv preprint arXiv:2212.08073*, 2022.
- [130] J. Wei, X. Wang, D. Schuurmans, M. Bosma, E. Chi, Q. Le, and D. Zhou. Chain of thought prompting elicits reasoning in large language models. *arXiv preprint arXiv:2201.11903*, 2022.
- [131] Y. Wang, Y. Kordi, S. Mishra, A. Liu, N. A. Smith, D. Khashabi, and H. Hajishirzi. Self-instruct: Aligning language model with self generated instructions. *arXiv preprint arXiv:2212.10560*, 2022.
- [132] T. Kojima, S. S. Gu, M. Reid, Y. Matsuo, and Y. Iwasawa. Large language models are zero-shot reasoners. *arXiv preprint arXiv:2205.11916*, 2022.
- [133] S. Yao, D. Yu, J. Zhao, I. Shafran, T. L. Griffiths, Y. Cao, and K. Narasimhan. Tree of thoughts: Deliberate problem solving with large language models. *arXiv preprint arXiv:2305.10601*, 2023.
- [134] S. James, Z. Ma, D. R. Arrojo, and A. J. Davison. Rlbench: The robot learning benchmark & learning environment. *IEEE Robotics and Automation Letters*, 5(2):3019–3026, 2020.
- [135] J. Wei, Y. Tay, R. Bommasani, C. Raffel, B. Zoph, S. Borgeaud, D. Yogatama, M. Bosma, D. Zhou, D. Metzler, et al. Emergent abilities of large language models. *arXiv preprint arXiv:2206.07682*, 2022.
- [136] T. Gupta and A. Kembhavi. Visual programming: Compositional visual reasoning without training. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 14953–14962, 2023.
- [137] D. Surís, S. Menon, and C. Vondrick. Vipergpt: Visual inference via python execution for reasoning. *arXiv preprint arXiv:2303.08128*, 2023.
- [138] Y. Zhu, A. Joshi, P. Stone, and Y. Zhu. Viola: Imitation learning for vision-based manipulation with object proposal priors. *6th Annual Conference on Robot Learning*, 2022.

A 附录

A.1 代码发布

我们基于 RLBench [134] 在 github.com/huangwl18/VoxPoser 上提供了 VoxPoser 的开源实现，因为其任务和场景的多样性最接近我们的真实世界设置。

A.2 涌现行为能力




图 5: VoxPoser 从语言模型继承的涌现行为能力，包括行为常识推理（左上）、细粒度语言纠正（右上）、多步骤视觉程序（左下）以及估计物体的物理属性（右下）。

涌现能力指的是仅在大模型中出现的不可预测现象 [135]。由于 VoxPoser 使用预训练的大语言模型作为骨干，我们观察到由大语言模型丰富的世界知识驱动的类型具身涌现能力。特别地，我们将研究重点放在 VoxPoser 独有的行为能力上。我们观察到以下能力：

- **行为常识推理**：在机器人布置餐桌的任务中，用户可以指定行为偏好，例如“我是左撇子”，这要求机器人理解该偏好在任务上下文中的含义。VoxPoser 决定将叉子从碗的右侧移到左侧。
- **细粒度语言纠正**：对于需要高精度的任务，例如“用盖子盖住茶壶”，用户可以向机器人给出精确的指令，如“你偏了 1 厘米”。VoxPoser 同样会根据反馈调整其动作。
- **多步骤视觉程序** [136, 137]：给定任务“将抽屉精确打开一半”，由于没有物体模型导致信息不足，VoxPoser 可以基于视觉反馈提出多步骤操作策略：首先完全打开抽屉并记录把手位移，然后将其关回中点以满足要求。
- **估计物理属性**：给定两个质量未知的物块，机器人被要求利用现有斜坡进行物理实验，以确定哪个物块更重。VoxPoser 决定将两个物块推下斜坡，并选择滑行最远的物块作为较重的物块。有趣的是，这反映了人类常见的疏忽：在理想的无摩擦世界中，两个物块在重力作用下会滑行相同的距离。这是一个轻松的例子，说明语言模型可能表现出与人类推理相似的局限性。

A.3 VoxPoser 的应用程序编程接口

VoxPoser 的核心是由大语言模型生成 Python 代码，并由 Python 解释器执行。除了向大语言模型提供 NumPy [16] 和 Transforms3d 库之外，我们还提供了以下环境应用程序编程接口，大语言模型可以选择调用：

detect(obj name)：接收一个物体名称，返回一个字典列表，其中每个字典对应一个匹配物体的实例，包含中心位置、占据网格和平均法向量。

执行（可移动物体，可供性地图，避障地图，旋转地图，速度地图，夹爪地图）：接收一个“感兴趣实体”作为“可移动物体”（由检测函数返回的字典），并（可选地）接收一系列数值地图，然后调用运动规划器来执行轨迹。注意，在模型预测控制设置中，“可移动物体”和输入的数值地图是函数，可以重新求值以反映最新的环境观测。

厘米转索引（厘米，方向）：接收沿方向期望的偏移距离（以厘米为单位），并返回一个三维向量，表示体素坐标中的位移。

索引转厘米（索引，方向）：厘米转索引的逆操作。接收一个整数“索引”和一个“方向”向量，并返回在世界坐标中由体素坐标中的“整数”位移所对应的厘米距离。

指向转四元数（向量）：接收末端执行器期望的指向方向，并返回一个满足要求的目标四元数。

按半径设置体素（体素地图，体素坐标，半径厘米，值）：将“值”赋给“体素地图”中距“体素坐标”在“半径厘米”范围内的体素。

获取空可供性地图 ()：返回一个默认的可供性地图，初始值为 0，其中高值吸引实体。

获取空避让地图 ()：返回一个默认的避让地图，初始值为 0，其中高值排斥实体。

获取空旋转地图 ()：返回一个默认的旋转地图，初始化为当前末端执行器四元数。

获取空夹爪映射 (gripper map)：返回一个以当前夹爪动作初始化的默认夹爪映射，其中 1 表示“闭合”，0 表示“张开”。

获取空速度映射 (velocity map)：返回一个以 1 初始化的默认可供性映射，其中数字表示缩放因子（例如，0.5 表示默认速度的一半）。

重置为默认姿态：重置为机器人休息姿态。

A.4 真实世界环境设置

我们使用 Franka Emika Panda 机器人，并采用桌面设置。我们使用来自 Deoxys [138] 的带阻抗的操作空间控制器。我们在桌子的两个相对端安装了两个 RGB-D 相机（Azure Kinect）：从俯视图看分别位于右下角和左上角。每次回滚开始时，两个相机开始录制并以 20 Hz 的频率返回实时 RGB-D 观测。

对于每项任务，我们在两种设置下评估每种方法：无扰动和有扰动。对于有扰动的任务，我们对环境施加三种扰动，并在评估开始时预先选择扰动序列：1) 对机器人施加随机力，2) 随机移动与任务相关及干扰物体，3) 逆转任务进度（例如，在机器人关闭抽屉时将其拉开）。我们仅对“关注实体”为物体或物体部件的任务施加第三种扰动。

我们将代码即策略（Code as Policies）[75] 的一种变体作为基线进行比较，该变体使用带有动作原语的大语言模型（LLM）。原语包括：移动到位置、按四元数旋转、设置速度、打开夹爪、关闭夹爪。我们不提供诸如抓取-放置之类的原语，因为它们是为特定任务套件量身定制的，而本研究不限制任务范围（类似于第 A.3 节中为 VoxPoser 指定的控制应用程序编程接口）。

A.4.1 任务

移动与避开：“移动到 [物体 1] 顶部，同时远离 [物体 2]”，其中 [物体 1] 和 [物体 2] 是从以下列表中随机选取的日常物品：苹果、香蕉、黄色碗、耳机、马克杯、木块。

布置餐桌：“请为我的意大利面布置餐桌，摆放餐具”。

关闭抽屉：“关闭 [指示词] 抽屉”，其中 [指示词] 可以是“顶部”或“底部”。

打开瓶子：“旋开维生素瓶”。

清扫垃圾：“请将纸屑扫入蓝色簸箕”。

A.5 仿真环境设置

我们在 SAPIEN [120] 中实现了一个配备 Franka Emika Panda 机器人的桌面操作环境。控制器接收期望的末端执行器六自由度位姿作为输入，利用逆运动学计算一系列插值路径点，最后通过比例微分控制器跟踪这些路径点。除一个带三个抽屉的铰接柜外，我们还使用了 10 个彩色方块和 10 条彩色线条。它们根据具体任务进行不同的初始化。线条用作视觉地标，不可交互。在感知方面，共安装了 4 台 RGB-D 相机，分别位于桌子的两端，指向工作空间中心。

A.5.1 任务

我们创建了一套包含 13 个任务的定制套件，如表 4 所示。每个任务都附带一个模板化指令（见表 4），其中可能有一个或多个属性从下方预定义列表中随机化。在重置时，根据具体任务选择若干物体，并在工作区内随机分布，同时确保任务在重置时未完成且任务完成是可行的。完整的属性列表如下，分为“已见”和“未见”两类：

已见属性：

- **[位置]**：[“桌子左后角”，“桌子右前角”，“桌子右侧”，“桌子后侧”]
- **[物体]**：[“蓝色积木”，“绿色积木”，“黄色积木”，“粉色积木”，“棕色积木”]
- **[介词]**：[“在……左边”，“在……前面”，“在……上面”]
- **[指示语]**：[“最上面的”，“从下往上第二个”]
- **[距离]**：[3, 5, 7, 9, 11]
- **[区域]**：[“桌子右侧”，“桌子后侧”]
- **[速度]**：[“更快速度”，“四分之一速度”]
- **[线条]**：[“蓝色线条”，“绿色线条”，“黄色线条”，“粉色线条”，“棕色线条”]

未见属性：

- **[位置]**：[“桌子右后角”，“桌子左前角”，“桌子左侧”，“桌子前侧”]
- **[物体]**：[“红色方块”，“橙色方块”，“紫色方块”，“青色方块”，“灰色方块”]
- **[介词]**：[“右侧”，“后侧”]
- **[指示语]**：[“最底部”，“顶部第二个”]
- **[距离]**：[4, 6, 8, 10]
- **[区域]**：[“桌子左侧”，“桌子前侧”]
- **[速度]**：[“较慢速度”，“3 倍速度”]
- **[线条]**：[“红线”，“橙线”，“紫线”，“青线”，“灰线”]

A.5.2 模拟环境完整结果

Tasks	U-Net + MP 大语言模型 + 原始体素姿态器					
	SA	UA	SA	UA	SA	UA
move to the [preposition] the [obj]	95.0%	0.0%	85.0%	60.0%	90.0%	55.0%
move to the [pos] while staying on the [preposition] the [obj]	100.0%	10.0%	80.0%	30.0%	95.0%	50.0%
move to the [pos] while moving at [velocity] when within [dist]cm from the obj	80.0%	0.0%	10.0%	0.0%	100.0%	95.0%
close the [deixis] drawer by pushing	0.0%	0.0%	60.0%	60.0%	80.0%	80.0%
push the [obj] along the [line]	0.0%	0.0%	0.0%	0.0%	65.0%	30.0%
grasp the [obj] from the table at [velocity]	35.0%	0.0%	75.0%	70.0%	65.0%	40.0%
drop the [obj] to the [pos]	70.0%	10.0%	60.0%	100.0%	60.0%	100.0%
push the [obj] while letting it stay on [region]	0.0%	5.0%	10.0%	0.0%	50.0%	50.0%
move to the [region]	5.0%	0.0%	100.0%	95.0%	100.0%	100.0%
move to the [pos] while staying at least [dist]cm from the [obj]	0.0%	0.0%	15.0%	20.0%	85.0%	90.0%
move to the [pos] while moving at [velocity] in the [region]	0.0%	0.0%	90.0%	45.0%	85.0%	85.0%
push the [obj] to the [pos] while staying away from [obstacle]	0.0%	0.0%	0.0%	10.0%	45.0%	55.0%
push the [obj] to the [pos]	0.0%	0.0%	20.0%	25.0%	80.0%	75.0%

表 4：在仿真中针对已见任务和未见任务的完整实验结果。“SA”表示已见属性，“UA”表示未见属性。每个条目表示 20 个回合的平均成功率。

A.6 提示词

第 4.1 节和第 4.2 节中使用的提示词如下所示。

规划器：接收用户指令 $\mathcal{L}$ 并生成一系列子任务 ℓ_i ，这些子任务被输入到“组合器”中（注意：在仿真中不使用规划器，因为评估的任务仅包含单一操作阶段）。真实世界：voxpather.github.io/prompts/真实规划器提示词.txt。

组合器：接收子任务指令 ℓ_i 并调用必要的值图大语言模型来组合可供性图和约束图。仿真：voxpather.github.io/prompts/sim composer prompt.txt。真实世界：voxpather.github.io/prompts/real composer prompt.txt。

解析查询对象：接收对象或部件名称的文本查询，并返回一个字典列表，其中每个字典对应一个匹配对象的实例，包含中心位置、占用网格和平均法向量。

仿真：voxpather.github.io/prompts/sim parse query obj prompt.txt。

真实世界：voxpather.github.io/prompts/real parse query obj prompt.txt。

获取可供性地图：接收来自组合器的自然语言参数化，并返回一个用于任务可供性地图的 NumPy 数组。

仿真：voxpather.github.io/prompts/sim get affordance map prompt.txt。

真实世界：voxpather.github.io/prompts/real get affordance map prompt.txt。

获取避让图：接收来自组合器的自然语言参数化描述，并返回一个用于任务避让图的 NumPy 数组。

仿真：voxpather.github.io/prompts/sim get avoidance map prompt.txt。

真实世界：voxpather.github.io/prompts/real get avoidance map prompt.txt。

获取旋转图：接收来自组合器的自然语言参数化描述，并返回一个用于末端执行器旋转图的 NumPy 数组。

仿真：voxpather.github.io/prompts/sim get rotation map prompt.txt。

真实世界：voxpather.github.io/prompts/real get rotation map prompt.txt。

获取夹爪映射：接收来自组合器的自然语言参数化描述，并返回用于夹爪动作映射的 NumPy 数组。

仿真：voxpather.github.io/prompts/sim get gripper map prompt.txt。

真实世界：voxpather.github.io/prompts/real get gripper map prompt.txt。

获取速度映射：接收来自组合器的自然语言参数化描述，并返回用于末端执行器速度映射的 NumPy 数组。

仿真：voxpather.github.io/prompts/sim get velocity map prompt.txt。

真实世界：voxpather.github.io/prompts/real get velocity map prompt.txt。