

Igniting VLMs toward the Embodied Space

安迪·翟, Brae Liu, Bruno Fang, Chalse Cai, Ellie Ma, Ethan Yin, Hao Wang, Hugo Zhou, James Wang, 莱特斯·施, Lucy Liang[†], Make Wang, Qian Wang, Roy Gan, Ryan Yu, Shalfun Li, Starrick Liu, Syllas Chen, Vincent Chen, Zach Xu

X SQUARE ROBOT

[†]Project Lead, *Correspondence

尽管基础模型在语言和视觉领域取得了显著进展，现有的视觉语言模型（Vision-Language Models, VLMs）在空间与具身理解方面仍存在局限。将视觉语言模型迁移至具身领域时，模态、预训练分布及训练目标之间的根本性不匹配问题凸显，使得动作理解与生成成为通往通用人工智能（AGI）道路上的核心瓶颈。本文提出 **WALL-OSS**，一种端到端的具身基础模型，利用大规模多模态预训练实现：（1）具身感知的视觉-语言理解，

（2）强语言-动作关联，以及（3）稳健的操控能力。该方法采用紧耦合架构与多策略训练课程，实现统一跨层级思维链（Unified Cross-Level CoT）——在单一可微框架内无缝整合指令推理、子目标分解与细粒度动作综合。实验结果表明，WALL-OSS 在复杂长程操控任务中取得高成功率，展现出强大的指令遵循能力、复杂理解与推理能力，并超越强基线模型，从而为从视觉语言模型迈向具身基础模型提供了一条可靠且可扩展的路径。

Date: September 8, 2025

Code: <https://github.com/X-Square-Robot/wall-x>

Project Page: <https://x2robot.com/en/research/68bc2cde8497d7f238dde690>



1 引言

语言与视觉领域的基础模型发展迅速。大语言模型（LLM）的进步轨迹如今在视觉语言模型中得到映射：诸如 Gemini 2.5 (26) 与 GPT-5 (55) 等强大的全模态模型能够联合处理文本与视觉流，同时在多模态领域保持审慎推理与低错误率。然而，这些系统在很大程度上仍缺乏具身性：它们既无法通过与物理世界的交互反馈进行自我优化，也无法生成可执行动作。因此，在具身空间中，动作理解与生成仍是通往通用人工智能道路上的核心瓶颈。

最成功接近通用泛化的模态通常依赖于在大规模、多样且易于获取的数据上进行预训练。受益于人类媒体的发展，互联网承载着海量、分布丰富的文本、图像和视频数据；因此，文本和二维视觉相对较早地获得了单模态通用能力以及跨模态关联。然而，在具身场景中，对齐的视觉-语言-动作（VLA）数据稀缺且异构，使得从零开始训练难以在动作模态以及跨模态关联上实现泛化。这一现状促使将强大的视觉语言模型（VLM）骨干迁移到动作空间，例如 OpenVLA (37) 和 π_0 (12)，它们在建模连续动作的同时学习跨模态对应关系，以将视觉和语言先验（VL 先验）迁移到动作空间中。

一种朴素的微调策略——将动作头附加到预训练的 VLM 上并用机器人轨迹进行监督——往往会导致严重的权重漂移，从而侵蚀原有的 VL 先验。“知识隔离”策略通过最小化对 VLM 参数的扰动来保留预训练能力；然而，松散耦合的架构设计限制了语义与控制之间的绑定，并且由于 VLM 本身在具身空间中存在不足，它们在执行超出 VL 先验的动作时表现不佳。总体而言，使用当前的 VLM 学习动作面临三个根本性差距：




图 1 当前的 VLM 在具身智能中缺乏对空间和动作的充分理解。这一缺陷源于现有预训练 VLM 的能力与具身任务所需特定知识之间的不匹配。WALL-OSS 释放了 VLM 的具身潜力，从而增强了具身理解能力并能够生成复杂动作。

模态和数据规模的差距。得益于计算机视觉的长期发展，视觉编码器提取的特征能够滤除高频噪声，同时保留高层语义；压缩后的视觉标记与已经高度压缩的文本模态相结合，在大规模网络文本-图像/视频对上进行训练后，通过对比语言-图像预训练（CLIP）及相关多模态模型和视觉语言模型（VLM）实现对齐（58）。相比之下，具身空间中的动作在三维空间和时间上连续；与视觉模态相比，其特征提取缺乏长期表征研究，其与文本的高层语义对齐也缺乏海量数据的驱动。此外，在具身场景中，多个子任务和具体的场景级动作描述往往被抽象为单一的高层指令，进一步增加了跨模态关联的难度。基于流水线的智能体（首先利用大语言模型（LLM）分解指令，然后调用技能库（6, 42））受限于不可微接口和误差累积，导致在长程任务上的成功率下降。另外，一些方法如三维视觉语言动作模型（3D-VLA）（79）和点云视觉语言动作模型（PointVLA）（39）尝试利用三维视觉模态作为二维视觉与动作之间的桥梁，但三维数据同样难以获取，且当前的三维视觉基础模型如视觉几何基础变换器（VG GT）（69）和 π^3 （72）在细粒度动作预测所需的准确率方面仍存在不足。

预训练分布中的差距。如图 1 所示，经过大规模预训练后，大语言模型在文本模态内基本覆盖了具身语义的需求（能够进行问答）。然而，对于视觉模态，具身数据通常涉及第一人称视角、鱼眼成像和自遮挡，这与互联网图像存在显著差异。即使经过大规模预训练，视觉语言模型仍难以覆盖具身场景的需求（例如具身视觉问答），且先前分析已报告其在空间推理、具身场景理解和进度跟踪方面存在不足（34, 70）。

训练目标中的差距。大语言模型/视觉语言模型（LLMs/VLMs）以离散序列上的下一词元似然作为训练目标，而动作轨迹是连续的高频信号，更自然地适合用条件生成目标来建模，例如扩散（30, 20）或流匹配（44），这些方法学习将基础分布传输到动作分布的得分/速度场。然而，将这些目标直接嫁接到视觉语言模型上会放大分词鸿沟和独立性假设，导致灾难性的性能退化，削弱语言与动作的对齐和泛化能力。这与当前图像/视频领域中统一生成与理解所面临的挑战相似。一些方法（例如， π_0 ）尝试在自回归范式下对动作进行高层离散化，以使动作词元与文本词元对齐，然后通过让扩散/流匹配中的动作噪声经由自注意力（12）与视觉语言模型的中间表示交互来生成连续动作信号。然而，这种松散耦合的设计仍然无法学习到紧密的文本-动作绑定，导致指令遵循能力不足。

为解决上述问题，本文提出 **WALL-OSS**，一种紧耦合的视觉-语言-动作（VLA）基础模型及其训练方案。首先，本文引入一种紧耦合的专家混合（MoE）架构与训练策略，该策略在不同阶段采用不同的动作建模方法，激活不同的专家与权重。

（离散或连续），从而弥合训练目标差距。我们将多模态任务与视觉问答任务及相应数据集相结合，这些数据集针对具身性、空间定位和进度建模进行了定制，以弥补视觉语言模型在具身场景中的不足，并将离散动作先验植入视觉语言模型输出空间以进行粗粒度动作监督，从而弥合视觉语言模型预训练分布差距。基于这些设计，我们建模了统一的思维链前向映射，使模型能够将任务从高层语义分解到细粒度动作，迫使模型理解该链中每一层之间的关系，从而弥合模态差距。

我们的核心贡献为将视觉语言模型扩展到具身智能建立了一个原则性框架。在方法论上，我们展示了架构耦合与课程设计如何系统地解决无实体预训练与具身领域之间的根本性错位。在实证方面，WALL-OSS 在多种操作基准上达到了最先进的性能，尤其在指令遵循、组合推理和长时程控制方面表现突出。更广泛地，我们的工作验证了一种可扩展的范式，用于弥合语义-感觉运动鸿沟，为通用具身人工智能系统提供了理论洞见和实用进展。鉴于当前具身通用基础模型的稀缺性，我们还开源了完整的训练代码和模型检查点，以促进这一新兴领域的可复现研究和社区发展。

2 相关工作

语言、视觉和操作中的基础模型。网络规模预训练推动了大型语言模型和视觉语言模型向更强的多模态推理和接地能力发展（例如 Gemini 2.5 (35, 4)、Claude 3.7 (3)、DeepSeek-R1、Llama 3 和 4 (2, 5)、Qwen 2.5 (73)；GPT-4o (54)、Qwen2.5-VL (8) 以及 InternVL 系列 (19, 18, 17, 80, 71)）。基于这些先验，视觉-语言-动作基线通过将动作编码为标记或学习连续头来将视觉语言模型与机器人控制对齐，涵盖连续模型如扩散和流匹配（例如 DP、Octo、 π_0 、 $\pi_{0.5}$ (21, 65, 12, 31)），或带压缩的离散分词（例如 ACT、OpenVLA、FAST、RT-2) (78, 37, 56, 84)。我们的方案遵循离散先验 $\rightarrow$ continuous 控制：我们首先将离散动作先验植入视觉语言模型输出空间（启发），然后优化流匹配头以处理高频动作（集成），同时紧密耦合的静态路由由专家混合模型强制实现强语言-动作绑定。

与机器人数据的多模态协同训练。为弥补机器人轨迹的成本与覆盖范围限制，多模态与跨源协同训练是有效手段。从视觉语言模型（VLM）初始化，并在网络图文、对话、长视频以及多具身机器人数据上联合训练，既能保留开放世界语言视觉能力，又能注入具身空间语义。跨具身与跨环境聚合进一步提升了迁移能力 (23, 65, 12, 31, 33, 9, 13)。本文方法强调以统一格式进行具身认知监督，将指令、推理、子任务与连续动作相连接；通过两阶段分布混合与配额机制系统化统一开源动作数据以限制漂移；并采用紧密耦合的静态路由由混合专家模型（MoE），将异构监督转化为动作通道上的可控增益，从而提升陌生场景与跨具身环境下的鲁棒性。

语言推理与子任务分解。对于长程任务，将高层推理与低层控制相结合可提高成功率。与将视觉语言模型规划器与独立控制器配对使用的流水线设计（如 SayCan (7) 和 Code-as-Policies (41)；以及 Hi Robot (64) 和 GR00T N1 (53) 等分层变体）不同，本文采用单模型 Uni-CoT 公式，端到端学习从指令到思维链（CoT）、子任务和连续动作的映射。这补充了分层与动作语法方法（如 RT-H (11)）、近期面向控制的思维链方法 (77, 76) 与提示框架 (51)，以及面向动作的指令微调 (52) 和分层目标条件策略 (40)。模型可以包含或跳过中间步骤，并将推理与执行交错进行。结合两阶段课程学习与紧密耦合路由，该统一设计减少了接口引起的误差累积，并增强了复杂长程操作任务中的进度感知与指令遵循能力。




图 2 将视觉语言模型迁移至动作建模的不同范式。蓝色部分表示从预训练视觉语言模型主干继承的初始化权重。DAM 与 CAM 分别指离散动作建模与连续动作建模，VL 表示视觉-语言，SA 表示自注意力。

3 WALL-OSS

本节介绍 WALL-OSS 的整体架构与训练方法论。我们的目标是开发一种面向具身领域的基于变换器的基础模型，不仅增强视觉语言模型（VLM）对具身场景的空间理解，还能实现高质量的动作生成。

模型架构。图 2(a) 和 (b) 展示了现有视觉语言动作（VLA）模型的结构范式。在 (a) 中，混合设计直接扩展原始 VLM，通过离散动作建模（DAM）或连续动作建模（CAM）来建模动作，遵循下一词元预测范式，如 RT-2 (84) 和 OpenVLA (37) 所示。然而，动作监督显著扰乱了原始 VLM 的权重分布，导致动作指令遵循和泛化能力大幅下降，造成对动作的过拟合。在 (b) 中，解耦设计采用独立分支进行动作预测，该分支与 VLM 交互并从中提取信息，如 π_0 (12) 所示。其局限性在于视觉和语言仅作为动作生成的辅助信号，这种松散耦合的架构削弱了动作预测的指令遵循能力。我们的架构通过利用专家混合（MoE）(63) 设计，将不同的前馈网络（FFN）分配给相应的训练任务，从而形成紧密耦合的跨模态结构，有效增强了模型的跨模态关联能力，解决了上述局限性。




图 3 WALL-OSS 的架构。

图 3 展示了 WALL-OSS 的整体架构。我们采用 QwenVL2.5-3B 作为主干网络。模型以视觉（自我中心和机械臂摄像头视图）以及文本指令作为输入

并根据训练阶段产生不同的输出，同时始终以相同的多模态输入为条件。设 $\mathbf{c} = (\text{视觉}, \text{指令})$ 和 $\mathbf{h} = F_\theta(\mathbf{c})$ 分别表示输入对及其 VLM 编码，其中 F_θ 表示参数为 θ 的 VLM 主干网络。

在 VLM 预训练之后，我们的预训练过程包含两个主要组成部分：VLM 的启发以及三种模态（视觉-语言-动作）的整合，如图 4 所示。




图 4 训练与推理流程概览。

启发阶段。本文首先复用预训练视觉语言模型（VLM）原有的前馈网络（FFN），并引入具身视觉问答（VQA）以增强机器人环境中的空间推理能力。训练目标涵盖掩码语言建模、图像/视频-文本对比学习、指令遵循以及时序顺序/因果建模，以构建强大的具身视觉语言先验。同时，本文引入离散动作目标，将文本标记与通过快速动作分词（FAST tokenization）获得的离散动作标记对齐（参见 π_0 -FAST (12)）：

$$\underbrace{\mathbf{z}_{1:K} = \text{FAST}(\mathbf{a})}_{\text{DCT} \rightarrow \text{Quant} \rightarrow \text{BPE}}, \quad \mathcal{L}_{\text{Inspiration}} = \lambda_{\text{VQA}} \sum_t -\log p_\theta(\tau_t | \tau_{<t}, \mathbf{c}) + \lambda_{\text{D}} \sum_k -\log p_\theta(z_k | z_{<k}, \mathbf{c}).$$

其中， $\mathbf{a}$ 表示连续动作轨迹， $\mathbf{z}_{1:K}$ 是通过快速动作分词得到的离散动作标记， τ_t 表示第 t 个文本标记， λ_{VQA} 和 λ_{D} 分别是视觉问答与离散动作目标的加权超参数。该阶段赋予视觉语言模型粗粒度的、语义具身的动作感知能力；其输出包括思维链推理、子任务预测以及离散快速动作标记。具身视觉问答增强了视觉语言模型在具身环境中的空间理解能力，而快速动作标记预测则提供了粗粒度的动作理解。这为初始视觉语言模型注入了基本的具身推理与动作感知能力。

整合阶段。基于上述先验，本文以流匹配（flow matching）替代离散动作预测，进行连续动作建模，并将该阶段划分为两个子阶段：（1）冻结视觉语言模型，仅训练动作前馈网络下的流头；（2）解冻视觉语言模型进行联合优化。在整合阶段，视觉、语言和动作表示通过注意力机制交互，静态路由器将动作中心特征导向动作前馈网络，将视觉-语言特征导向视觉-语言前馈网络，而非采用可学习的 Softmax 函数或 top-k 路由器。在第一子阶段，构造噪声样本并回归速度场

$$x_t = (1 - \rho(t)) x_0 + \rho(t) \epsilon, \quad \mathcal{L}_{\text{Integration}} = \lambda_{\text{C}} \mathbb{E} \left[w(t) \left\| v_\phi(x_t, \mathbf{h}, t) - (\epsilon - x_0) \right\|_2^2 \right],$$

其中 x_0 表示干净动作样本， x_t 是时刻的含噪样本 t, ϵ 为高斯噪声， $\rho(t)$ is a 噪声调度函数， v_ϕ 是带参数的速度场网络 $\phi, w(t)$ 是一个加权函数，并且 λ_{C} 是连续动作损失权重。来自启发阶段的监督在此稳定了跨模态注意力，保留了视觉语言先验，并为连续动作提供了可靠的初始化。

在第二阶段，我们使用相同的流匹配目标与梯度路由 $\partial \mathcal{L}_{\text{Integration}} / \partial \theta \neq 0$ 和 $\partial \mathcal{L}_{\text{Integration}} / \partial \phi \neq 0$ 联合优化两个模块（解冻视觉语言模型并与动作分支联合训练）。这种集成在紧密耦合的架构中实现了细粒度的动作输出，促使模型整合多模态信息并高效完成多模态任务，从而实现跨模态的对齐。

统一跨层级思维链。我们的方法将思维链推理的概念从传统的狭义思维链（大语言模型中的逐步文本推理）推广到涵盖整个语义到感觉运动谱系的广义思维链：指令 $\rightarrow$ 推理（思维链） $\rightarrow$ 子任务计划 $\rightarrow$ 连续动作。这种统一表述支持跨层级抽象级别的任意前向映射，使模型能够在单一可微框架内无缝过渡于高层决策与低层执行之间。

现有方法通常将这些层级分解为流水线式或多模块系统，其中指令首先传递给规划器以生成高层计划，然后由控制器执行，例如 Hi Robot (64) 和 GR00T N1 (53)。虽然这些范式在短期内可以显著降低训练和执行难度，但它们引入了不可微接口，限制了系统性能受限于各模块的能力，并且容易在各阶段累积误差。

相比之下，**WALL-OSS** 采用单一的端到端模型，联合学习跨抽象级别的映射，支持灵活的前向任意映射，使模型能够根据任务复杂度和上下文需求自适应地利用完整的中间推理步骤或直接将指令映射到动作。

形式上，令 v 表示视觉输入， x 表示语言指令， c 表示可选的思维链， $a_{1:T} \in \mathbb{R}^{T \times d}$ 表示长度为 T 、维度为 d 的目标动作轨迹。Uni-CoT 训练一个统一预测器 F_θ ，采用路径丢弃目标，允许模型灵活地以中间推理为条件或绕过中间推理：

$$\min_{\theta} \mathbb{E}_{(v,x,c,a)} \left[\ell_{\text{act}}(F_\theta(v,x,c), a_{1:T}) + \lambda \ell_{\text{VQA}}(H_\theta(v,x), y) \right],$$

其中 H_θ 是一个具身感知的视觉问答头，监督 y ， ℓ_{act} 是动作预测损失， ℓ_{VQA} 是视觉问答损失， λ 是平衡超参数。这种表述在单一模型内实现了全链路和直接 $x \rightarrow a$ 训练，确保了端到端的可微性，同时保留了推理的灵活性。

通过覆盖语义层面的映射，Uni-CoT (i) 通过具身视觉问答增强了视觉语言模型的空间理解能力，从而实现了更强的定位和动作预测，并且 (ii) 显著提高了长程任务成功率和指令遵循能力。此外，如图 4 下半部分所示，在推理过程中，Uni-CoT 可以自适应地决定是否调用思维链/子任务分解，甚至将推理与执行交错进行——在继续推理的同时为已完成的子任务发出动作——从而为实时人机交互实现灵活、异步的控制。

4 数据构成

我们构建了一个以具身为中心的、多来源的数据集，以解决大规模、对齐的视觉-语言-动作监督的缺乏以及当前视觉语言模型的空间理解差距。该语料库超过 10,000 小时，包含三个互补的组成部分：（1）自采集的机器人动作数据，以保证高质量和任务复杂性，（2）开源动作数据，以实现跨形态和跨环境的泛化，以及

（3）多模态视觉问答数据，以保持和增强语言-视觉能力，同时为时空和推理提供额外的监督，如图 5 所示。

为了与我们的两阶段训练方案（启发与整合）保持一致，我们对数据源进行了功能性编排：（1）启发阶段侧重于具身视觉问答、指令遵循以及通过 FAST 获得的离散动作先验，以向视觉语言模型注入粗略的动作意识，同时提高空间推理能力；（2）整合阶段侧重于在真实和统一的开源轨迹上使用流匹配进行高频连续控制，首先训练动作分支，然后与视觉语言模型联合优化，以加强语言-视觉-动作的对齐并减轻遗忘。

4.1 自采集机器人动作数据

平台与场景。我们针对桌面机械臂、移动支架、轮式双臂系统和轮式人形机器人的真实世界日常操作，配备以自我为中心/外部视角和臂载摄像头。场景涵盖厨房清洁、穿衣/整理、移动抓取与放置以及装配任务。




图 5 多源数据集概览。左侧：三个来源的构成（自采动作、开源动作和多模态视觉问答）。中间（从上到下）：来自自采动作、开源动作和多模态视觉问答的示例图像。右上：我们具有代表性的机器人硬件。

任务谱系。我们包含两个核心系列：（1）在明确指令下的短程操作，强调精确率和泛化能力；（2）目标清晰但过程隐式的长程推理任务，需要任务分解、进度跟踪和实时决策来完成多步骤例程。

标注与质量控制。我们构建了一个多模型流水线，用于细粒度步骤标注，并辅以人工抽查，从而在轨迹上直接实现思维链风格的阶段监督。我们强制执行多传感器时间戳同步、异常值过滤、低质量或空闲帧移除、基于规则的验证以及人工审核，并自动进行数据增强（光照/背景）。为了与开源动作和多模态语料库保持平衡，我们选取了一个具有代表性的自采子集用于 WALL-OSS 训练。

4.2 开源动作数据

覆盖范围与来源。本文整合了多样化的数据集，以补充传感器形式、操作风格和环境变化，代表性来源包括 DROID、BC-Z、BRIDGE 等（参见完整列表见表 1）。

标准化。为实现异构数据源间的稳定联合预训练，本文强制实施统一规范：（1）坐标系与单位（位置以米计；角度以弧度计）；（2）通过最大表达自由度的自由度模板进行形态学归一化，对单臂/双臂、轮式及人形平台中缺失的关节采用掩码或占位符处理；（3）感知对齐，即统一内参/外参与时间戳，重采样帧率与分辨率，并对多视角视频进行通道对齐；（4）动作时基归一化，即标准化控制频率，并将轨迹重采样或插值至流匹配网格。该协议降低了跨数据源摩擦，并提升了优化稳定性。

4.3 多模态视觉问答：通用与具身 本文采用两条视觉问答（VQA）流：一条以感知为中心的通用流，用于保持视觉语言模型（VLM）能力；另一条为具身流，针对操作任务中的时空与任务推理。

面向视觉语言模型维护的通用视觉问答。我们结合开源视觉问答数据集（如 CapsFusion、RoboPoint、Robo2VLM、COCO；见表 1）以及基于自采轨迹的通用视觉问答标注，以保持

类别	数据集	开源动作数据	Agibotworld (14) ; Droid (36); Bc_z (32); RH20T (24) ; Furniture_bench (29) ; Fractal (25) ; Bridge_data_v2 (68) ; DobbE (61) ; UMI-biarm (46) ; Utaustin_mutex (62) ; Stanford_hydra (10) ; Austin_sailor (50) ; Fmb (48) ; Austin_sirius (45) ; Taco_play (60, 49) ; Stanford_kuka_multimodal (38) ; Berkeley_autolab_ur5 (16) ; Jaco_play (22) ; Viola (82) ; Berkeley_fanuc_manipulation (81) ; Berkeley_cable_routing (47) ; Austin_buds (83) ; Dlr_edan_shared_control (67, 57) ; Nyu_rot (28) 开源图像 - 文本数据 CapsFusion (74) ; Cambrian (66) ; PixMo (1) ; RoboPoint (75) ; Robo2VLM (15) ; COCO (43) ; VQAv2 (27) ; VQASynth-SpaceLLaVA (59) ; SpaceThinker (59) ; OpenSpaces_MC_R1 (59) ; OpenSpaces (59) ; SpaceOm (59)
----	-----	--------	--

表 1 本文语料库所用开源数据集汇总。名称显式给出；有引用处附上引用。

并增强语言 - 视觉能力与指令遵循。这些信号与操作弱相关，主要对视觉 - 语言主干进行正则化，而非动作头。

具身视觉问答用于时空与推理。我们在自采轨迹上构建自动生成流水线，以提供针对空间理解与任务推理的监督：动作规划视觉问答（子目标推理）、空间与时间问答（定位、排序、进度）、感知视觉问答（属性）以及认知与可供性（可交互性）。标签采用统一格式以支持跨任务共享，例如 `<box>[x1,y1,x2,y2]</box>`、`<point>[x,y]</point>`、可选的 `<mask>` 编码以及自然语言问答/描述。这些信号显式连接“指令 → 思维链 → 子任务 → 连续动作”链条，并直接服务于 Uni-CoT 及我们紧耦合的混合专家架构。

4.4 划分、采样与规模 我们按场景/物体/任务/形态分层，形成跨环境和跨形态的验证/测试集。长程任务和稀有技能采用温度控制重采样和困难样本上采样，以增强长程依赖和进度建模。在两个训练阶段中，我们通过配额控制混合来源，以保持视觉语言模型能力并同时改进连续控制。我们对视觉流施加轻度领域随机化和遮挡扰动以提升鲁棒性。整体语料库超过数万小时；各来源在时长、场景和形态上的比例以及任务分解。我们提供定性可视化，并在消融中表明具身视觉问答加上离散动作先验显著提升后续流匹配控制质量和指令遵循，尤其在长程任务中。

5 实验

5.1 设置

为全面评估所提视觉-语言-动作模型的能力，本文设计了一套评估方案，包含一个具身视觉问答基准和六个机器人操作任务。该方案围绕三个核心维度展开：1) 语言指令理解、推理与泛化；2) 长时程、多阶段任务的规划与执行；3) 动作准确率与鲁棒性。

5.1.1 评估任务

具身视觉问答 为评估模型对具身场景的理解能力，本文构建了一个具身视觉问答基准。该基准基于从动作数据集中随机采样的视频帧，要求模型完成三项任务：（1）场景描述，为给定图像生成文本描述；（2）目标定位，根据文本描述定位目标的二维坐标；（3）动作规划，在给定图像和高层指令的情况下，以自然语言规划下一步动作。本文通过人工评估，将预训练模型 WALL-OSS 与原始基础视觉-语言模型（qwen2.5-vl-3b）在该基准上的性能进行了对比。

机器人操作任务 本文设计了六个操作任务，以评估模型在核心维度上的性能。其中，布置餐桌、整理卧室和按颜色放置是预训练阶段未见的新任务，

pick-up-waste



<Instruction> Move next to the trash bin and pick up the garbage one by one, placing each piece into the bin.

place-by-color



<Instruction> Place the yarn balls onto the corresponding sheets of paper according to their colors

instruction-pick-place




<Instruction> Put the fruits in the corresponding containers according to the instruction

pick-place-cup



<Instruction> Place the plate at the center of the table and put the cup on it

set-table



Step 3

<Instruction> Set up a dining table for 2 people

Step 6

<Subtask> Move to the left position and place the plate

Step 9

<Subtask> Move to the left position and place down the knife and fork

Step 12

<Subtask> Move to the right position and place the plate

Step 15

<Subtask> Move to the right position and place down the knife and fork

tidy bedroom



Step 1

<Instruction> Move and organize bedroom

Step 4

<Subtask> Move to dirty clothes basket

Step 6

<Subtask> Right robotic arm picks up clothing and puts it in dirty clothes basket

Step 11

<Subtask> Use near-side picks up clothing and puts it in robotic arm to adjust pillow position

block-spell

With Reasoning



<Instruction> Use the letter blocks to spell out the corresponding word on the wooden board according to the arrangement shown on the table

Step 1

<Thought> I need to determine the target word and the current letter to be operated. Target word: FIVE Letter sequence: ['F', 'I', 'V', 'E'] Existing letters: [] Letter to be operated: F

<Subtask> Place the letter F on the wooden board

Step 2

<Thought> I need to determine the target word and the current letter to be operated. Target word: FIVE Letter sequence: ['F', 'I', 'V', 'E'] Existing letters: ['F'] Letter to be operated: I

<Subtask> Place the letter I on the wooden board

Step 3

<Thought> I need to determine the target word and the current letter to be operated. Target word: FIVE Letter sequence: ['F', 'I', 'V', 'E'] Existing letters: ['F', 'I'] Letter to be operated: V

<Subtask> Place the letter V on the wooden board

Step 4

<Thought> I need to determine the target word and the current letter to be operated. Target word: FIVE Letter sequence: ['F', 'I', 'V', 'E'] Existing letters: ['F', 'I', 'V'] Letter to be operated: E

<Subtask> Place the letter E on the wooden board

图 6 微调阶段使用的评估任务概览。上排：单指令任务（拾取垃圾、按颜色放置、指令拾取-放置、拾取-放置杯子）。下排：长时程与推理任务（布置餐桌、积木拼写、整理卧室）。

预训练，旨在评估模型对新任务的适应能力。任务按其所针对的主要能力进行分组：针对指令遵循与推理：

指令拾取与放置：模型需遵循多样化的自然语言指令——例如描述性命令——以拾取指定物体并将其放置于指定目标位置。该任务不参与微调，用于评估零样本泛化能力。

按颜色放置：模型必须将毛线球放置在对应颜色的纸张上。该任务包含两种条件：（1）直接视觉颜色匹配（例如，将红色毛线球放在红色纸上），以及（2）基于文本的推理（例如，将球放在印有“红色”字样的白纸上）。使用 500 个回合进行微调。

积木拼写：该任务要求模型使用玩具积木拼出答案。它评估模型的推理能力，因为在采取任何拼写动作之前必须完全推断出答案。提示分为两类：（1）识别并拼出图像卡片上所示物体的名称，以及（2）求解一个简单的算术表达式并拼出结果答案。使用 1600 个回合进行微调。

对于长时程规划：

摆放餐桌：模型必须从桌子中央取一个盘子、一把刀和一把叉子，并为每个餐位正确摆放（盘子居中，餐具分列两侧）。微调使用 1500 个回合。

整理卧室：模型需要整理卧室，从床上收集脏衣服放入洗衣篮，并正确摆放枕头。微调使用 1000 个回合。

针对动作准确率与鲁棒性：

收集垃圾：模型必须导航至垃圾桶，收集周围散落的垃圾，并执行准确的丢弃动作。该任务涉及在移动约束下的动态物体交互与空间推理。微调使用 900 个回合。

拾取-放置杯子：模型必须将杯子放置到桌子中央的盘子上。该任务通过多样的初始状态（如倒置的杯子、方向错误的把手或错位的盘子）对模型提出挑战，要求在执行最终放置前进行一系列动态操作，如重新调整杯子方向和重新定位盘子。微调使用 500 个回合。

5.1.2 基线与微调配置

本文将 WALL-OSS 与两种具有代表性的基线进行比较，这两种基线体现了视觉-语言-动作学习中的不同范式： π_0 (12) 利用预训练的视觉语言模型结合流匹配进行动作生成，而扩散策略 (Diffusion-Policy) (21) 则采用条件去噪扩散进行视觉运动控制，且未使用视觉语言模型初始化。

为确保全面评估，本文为基线模型实现了两种指令范式：使用高层任务指令的扁平训练，以及使用人工标注的子任务分解并结合 GPT-4 推理时生成的 GPT4-子任务训练。该设计使本文能够将任务分解的贡献与架构创新分离开来。

为公平比较骨干网络，WALL-OSS 和 π_0 利用预训练的视觉语言模型权重，而扩散策略由于其容量较小则从头开始训练。所有模型接收相同的任务监督，WALL-OSS 独特地支持通过交错采样进行联合动作-视觉问答训练（非子任务视觉问答的比例为 1:15，子任务样本的比例为 1:100）。

5.1.3 评估协议

为确保评估的客观性和公平性，本文实施了严格的盲测第三方测试协议。模型训练者提供了详细的测试文档，其中规定了环境设置、每个任务的初始状态以及标准化的评分细则。随后，未参与模型开发或训练的第三方评估者进行了评估。他们对所测试模型的版本不知情，并严格遵循所提供的文档执行评估并记录结果。该协议最大限度地减少了主观偏差，并确保评估结果的可靠性。

Model	Object Grounding	Scene Captioning	Action Planning
Qwen2.5-VL-3B	46.1%	57.7%	59.8%
WALL-OSS	91.6%	87.6%	69.0%

表 2 具身视觉问答基准结果，比较了 WALL-OSS 与基线 Qwen2.5-VL-3B 模型在三个评估类别上的表现。

所测试的模型严格遵循所提供的文档执行评估并记录结果。该协议最大限度地减少了主观偏差，并确保了评估结果的可靠性。

5.2 结果与分析

本文呈现实验结果，首先评估模型的基础场景理解能力，随后逐步考察其在日益复杂的操作任务上的性能表现。

5.2.1 预训练增强具身场景理解

在评估动作生成能力之前，本文首先验证预训练策略不仅保持了视觉语言模型（VLM）的视觉-语言对齐，还增强了其对具身场景的深层理解。如表 2 所示，本文将 WALL-OSS 与其原始基础视觉语言模型（qwen2.5-vl-3b）在自采集的具身视觉问答（Embodied VQA）基准上进行比较。在物体定位任务中，WALL-OSS 取得了显著更优的性能；基础视觉语言模型由于不熟悉其预训练数据中罕见的具身操作场景，常被机械臂等元素误导，导致定位失败。在场景描述任务中也出现了类似趋势，基础视觉语言模型经常生成与场景无关的幻觉，而 WALL-OSS 则能准确描述机械臂的操作动作。最后，在动作规划任务中，两个模型都容易误判当前任务阶段，但 WALL-OSS 提供了比基础模型更具体且切题的回答。这些发现共同表明，本文的预训练策略成功地将以机器人为中心的场景知识注入视觉语言模型，为其在后续操作任务上的性能奠定了关键基础。

5.2.2 预训练后涌现零样本指令遵循能力

在确认模型场景理解能力增强的基础上，本文进一步评估 WALL-OSS 是否能在不进行任务特定微调的情况下遵循新颖指令。该分析重点验证模型利用预训练能力泛化到未见任务表述的能力。

如图 7 所示，本文在拾取放置任务上评估模型，使用两种指令类型：（1）涉及预训练期间见过的物体和容器，（2）包含全新物品。模型在见过物体指令上取得了 85% 的平均任务进度，并保持了




图 7 与最先进策略在所有评估任务上的性能比较。左：分布内（ID）性能比较。右：分布外（OOD）性能

在新物体指令上达到 61% 的性能。大多数失败案例归因于为不熟悉物体选择抓取或放置位置时的轻微姿态不准确，而非对指令目标的语义误解。

这些结果表明，WALL-OSS 能够在零样本设置下准确解释并执行操作指令。这一能力得益于其多模态预训练，该预训练保留了视觉语言模型固有的推理能力，并支持对新任务的鲁棒泛化。

5.2.3 预训练提升动作准确率与泛化能力

除了指令理解与推理之外，有效的具身智能还需要精确且鲁棒的动作执行。因此，我们通过两个任务——收集废物和拾取放置杯子——评估预训练对原始动作准确率和泛化能力的影响。

结果表明，在具有充足演示数据（收集废物，1000 个演示）的情况下，预训练模型——WALL-OSS 和 π_0 ——在分布内任务上达到 100% 的成功率，而未预训练的扩散策略模型仅达到 80%。然而，当任务复杂度增加且数据可用性降低（拾取放置杯子，500 个演示）时，性能差距显著扩大：预训练模型保持 90% 以上的成功率，而扩散策略模型降至 20% 以下。在分布外泛化测试中——在新环境中执行收集废物任务——扩散策略模型的成功率从 80% 降至 0%，完全无法完成任务。相比之下，WALL-OSS 和 π_0 均保持 80% 以上的成功率，展现出强大的鲁棒性。

这些结果清楚地表明，预训练对于视觉语言动作模型至关重要，显著提高了动作准确率、数据效率（即小样本学习）以及对新环境的泛化能力。

5.2.4 子任务生成提升长时程任务性能

长程任务对具身智能模型构成重大挑战，原因在于其固有的复杂性、延迟监督以及跨阶段执行误差的累积效应。为解决这一问题，本文探究由语言模型动态地将高层目标分解为中间子任务，能否提升任务成功率与执行稳定性。本文设计了两个未包含在预训练数据中的长程任务——布置餐桌（**Set-Table**）与整理卧室（**Tidy-Bedroom**），以评估 WALL-OSS 的泛化性能。每个任务包含五个以上顺序阶段，布置餐桌的平均执行时间超过三分钟，整理卧室则超过五分钟。

在微调过程中，WALL-OSS 对动作生成与子任务预测进行联合训练。尽管仅有 1% 的训练数据标注了子任务，模型仍能持续学习生成高质量的子任务指令。在推理阶段，WALL-OSS 首先生成子任务指令，随后利用该指令引导动作生成。如图 7 所示，WALL-OSS 在布置餐桌与整理卧室任务上显著优于 π_0 和扩散策略（Diffusion-Policy）。定性分析表明，尽管所有模型在底层动作（如拿起盘子）上表现相当，基线模型由于缺乏显式子任务引导，经常出现阶段混淆。这表现为重复或错位的动作——例如反复将餐具放置在同一位置，或未能布置餐桌的其余部分——因为模型缺乏清晰的任务进度概念。此外，当相似视觉观测下存在多个合理动作时，基线模型往往难以消解歧义，经常做出不一致或次优的选择，进一步加剧跨阶段的执行误差。在空间上更复杂的整理卧室任务中，这些问题更为突出：基线模型经常陷入重复且无效的行为——尤其是当目标物体（例如一件遗漏的衣物）位于当前视野之外时。

相比之下，WALL-OSS 利用其多模态推理能力生成上下文相关的子任务提示，从而能够在多个合理选项之间消解歧义、保持连贯的任务进度，并可靠地完成所有阶段。

5.2.5 思维链 (Chain-of-Thought) 赋能具身规划与推理

复杂的具身任务通常需要对空间关系、物体属性以及顺序动作的后果进行推理。现有的视觉-语言-动作 (VLA) 模型直接将指令映射为动作，但在需要中间决策和常识推理的任务中往往表现不佳。为解决这一问题，本文研究了思维链 (CoT) 提示在使 WALL-OSS 通过显式中间推理来规划和执行多步行为中的作用。

受大语言模型 (LLMs) 成功的启发，本文探索将思维链推理能力迁移到视觉-语言-动作模型中。为评估推理与动作执行的整合效果，本文设计了两个任务——按颜色放置 (Place-by-Color) 和积木拼写 (Block-Spell)——它们需要中间逻辑推理。在微调过程中，WALL-OSS 被训练为联合生成思维链推理迹和子指令，仅使用 1% 的训练帧进行监督。在推理时，模型自主生成思维链推理迹和子指令，然后将其作为动作生成的条件输入。在按颜色放置任务中，本文观察到当目标涉及直接视觉匹配（例如，将红色毛线球与红色纸张匹配）时，思维链带来的益处微乎其微。

然而，在需要基于文本推理的更具挑战性的条件下——例如将毛线球放在印有“红色”字样的纸上——WALL-OSS 的任务完成率显著高于所有基线。这表明直接动作模型仅限于视觉直观的任务，而引入思维链对于解决需要中间推理的指令条件任务至关重要。

在积木拼写任务中，扁平设置下的基线模型任务进度几乎为零，再次证实缺乏任务分解对推理密集型任务极为不利。因此，在图 7 中，我们仅报告 GPT 子任务设置下的基线结果。如图所示，WALL-OSS 在分布内和分布外场景下均显著优于 GPT 子任务基线。我们的分析表明，尽管 GPT-4 通常能推断出正确的子指令，但其响应缺乏 WALL-OSS 所展现的及时性和上下文适应性——尤其是在遮挡自我视角等复杂环境中。此外，基线模型在 GPT 生成的高层策略与底层动作执行模块之间存在脱节，导致对齐不佳和指令遵循性能下降。

5.2.6 多模态协同训练增强细粒度指令遵循

除一般指令遵循外，许多现实世界任务需要对细粒度视觉和语言线索进行精确锚定。因此，我们考察多模态协同训练在提升模型解释和执行详细、对象特定指令能力方面的有效性。

如表 3 所示，WALL-OSS 在积木拼写任务上的准确率显著高于 π_0 ，尤其在识别和放置正确字母积木序列方面。在同一任务中，我们观察到 π_0 在识别和操作特定字母积木方面的表现明显差于 WALL-OSS。为探究这一差距，我们进行了消融实验，比较三种微调配置：

- WALL-OSS（多模态协同训练）：通过联合训练动作生成、思维链+子任务生成以及二维指代表达锚定进行微调。

- WALL-OSS（仅动作）：仅使用子任务指令进行动作生成微调。

- π_0 （仅动作）：一种与 WALL-OSS 架构相似的视觉-语言-动作模型，仅针对动作生成进行微调。如表 3 所示，我们评估每个模型在给定精确指令（例如“拿起字母 A”）时选择正确积木的能力。结果表明，WALL-OSS（多模态协同训练）配置实现了最高的指令遵循准确率。虽然 WALL-OSS（仅动作）的性能相对于多模态设置有所下降，但仍显著优于 π_0 （仅动作），后者的准确率接近随机水平。

这些发现清楚地表明，多模态协同训练显著增强了模型遵循细粒度指令的能力。WALL-OSS 的预训练阶段为多模态动作对齐奠定了坚实基础，而在微调期间保持这种协同训练策略进一步放大了模型基于指令的执行能力。

Block Type	WALL-OSS (Co-training)	WALL-OSS (Action-only)	π_0 (Action-only)
Letter	87%	26%	9%
Number	95%	80%	35%

表 3 方块拼写任务中的指令遵循准确率。

6 讨论

6.1 具身基础模型的统一理论

基础模型的出现从根本上重塑了我们对人工智能的理解，然而将其扩展到具身领域揭示了关于智能本质的更深层次问题：模态之间的内在差距有多大？统一架构能否在不降低任何模态性能的情况下处理异构模态？如果可以，哪种近似轨迹能最有效地达到该状态？

WALL-OSS 旨在弥合语言-视觉-动作之间的差距。我们紧密耦合的专家混合架构、通过具身理解增强视觉语言模型的多模态课程，以及多阶段训练计划，共同产生了一个统一、灵活、可微分、端到端的映射，从高层指令——通过狭义思维链和子任务分解——到离散动作再到连续动作。训练期间学习到的丰富前向映射相应地赋予了推理时的灵活性。

早期探索中，对非语言模态进行激进离散化并在下一词元目标下与文本联合训练的方法被证明不尽如人意。该领域随后转向为新模态采用保守的侧分支，在此过程中原始视觉语言先验受到严重干扰。相比之下，WALL-OSS 使用了更小比例的额外参数，却证明了同时提升具身视觉语言理解和动作生成既是自然的也是可行的，而非预设视觉语言能力与动作能力之间存在零和权衡。

总体而言，WALL-OSS 实现了：（i）得益于具身视觉问答与统一思维链设计，在具身环境中增强了多模态基础与推理能力；（ii）与扩散策略相比，具有更强分布外泛化能力的竞争性动作生成，尽管 π_0 在精确操作方面仍更优；（iii）灵感阶段带来了可衡量的收益，验证了我们的分阶段训练策略。这些发现支持了我们的主张：紧密耦合的多模态推理与动作建模是可扩展具身智能的关键。

6.2 未来方向

虽然统一的文本-图像架构得出了相关结论，但动作在本质上仍然不同：信号稀疏，位于高维流形上，且紧凑的轨迹对应着庞大的视觉和语言表征。这些表征涵盖了高层状态分析、意图形成和任务分解，而执行则依赖于低层空间感知和运动学。因此，有效的建模必须将高层文本/视觉推理与低层感知和控制对齐。

受前者启发，我们引入了大语言模型；对于后者，我们探讨是否需要中间形式（例如，未来帧预测）或中间模态（例如，3D 感知）来降低学习 $VL \rightarrow A$ 映射的难度。我们将严格的端到端 $VL \rightarrow A$ 与中间路线方法视为两条汇聚的路径，重点关注它们通向通用人工智能的相对效率。视频和 3D 模态通常比文本-动作对表现出更高的动作相关性，有效地去稀疏化了监督；然而 3D 数据仍然稀缺。大规模视频预测可以利用互联网数据，但会引入大量冗余监督——人类行动时并不预测所有细节，而是根据意图进行选择性感知——这促使了用于行为预测的双向世界建模。在人类媒体基本不变的情况下，各模态中数据和算法的增长由相邻行业（例如，人工智能生成内容、图形学）驱动，这些行业也培育了动作建模所需的“中间”先验。端到端动作预测的进展依赖于具身产业，并且同样相当于对这些中间表示的隐式学习。随着需求同时刺激学术界和工业界，不同路线通向通用人工智能的相对效率本质上是动态的。

参考文献

- [1] Pixmo dataset. https://docs.allenai.org/training_data/pixmo, 2024. Dataset website.
- [2] Introducing llama 3.1: Our most capable models to date. <https://ai.meta.com/blog/meta-llama-3-1/>, 2024. Meta AI Blog.
- [3] Claude 3.7 sonnet and claude code. <https://www.anthropic.com/news/claude-3-7-sonnet>, 2025. Anthropic News.
- [4] Gemini models. <https://deepmind.google/models/gemini/>, 2025. Google DeepMind Models page.
- [5] The llama 4 herd: The beginning of a new era of natively multimodal intelligence. <https://ai.meta.com/blog/llama-4-multimodal-intelligence/>, 2025. Meta AI Blog.
- [6] Michael Ahn, Anthony Brohan, Noah Brown, et al. Do as i can, not as i say: Grounding language in robotic affordances. In *Robotics: Science and Systems (RSS)*, 2022.
- [7] Michael Ahn et al. Do as i can, not as i say: Grounding language in robotic affordances. *arXiv preprint arXiv:2204.01691*, 2022. <https://arxiv.org/abs/2204.01691>.
- [8] Shuai Bai, Keqin Chen, Xuejing Liu, Jialin Wang, Wenbin Ge, Sibao Song, Kai Dang, Peng Wang, Shijie Wang, Jun Tang, Humen Zhong, Yuanzhi Zhu, Mingkun Yang, Zhaohai Li, Jianqiang Wan, Pengfei Wang, Wei Ding, Zheren Fu, Yiheng Xu, Jiabo Ye, Xi Zhang, Tianbao Xie, Zesen Cheng, Hang Zhang, Zhibo Yang, Haiyang Xu, and Junyang Lin. Qwen2.5-vl technical report. *arXiv preprint arXiv:2502.13923*, 2025.
- [9] Bowen Baker, Ilge Akkaya, Peter Zhokov, Joost Huizinga, Jie Tang, Adrien Ecoffet, Brandon Houghton, Raul Sampedro, and Jeff Clune. Video pretraining (vpt): Learning to act by watching unlabeled online videos. In *Advances in Neural Information Processing Systems*, 2022.
- [10] Suneel Belkhale, Yuchen Cui, and Dorsa Sadigh. Hydra: Hybrid robot actions for imitation learning. In *Conference on Robot Learning*, pages 2113–2133. PMLR, 2023.
- [11] Suneel Belkhale, Tianli Ding, Ted Xiao, Pierre Sermanet, Quon Vuong, Jonathan Tompson, Yevgen Chebotar, Debidatta Dwibedi, and Dorsa Sadigh. Rt-h: Action hierarchies using language. *arXiv preprint arXiv:2403.01823*, 2024.
- [12] Kevin Black et al. π_0 : A vision-language-action flow model for general robot policies. *arXiv preprint arXiv:2410.24164*, 2024.
- [13] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Joseph Dabis, Chelsea Finn, Keerthana Gopalakrishnan, Karol Hausman, Alex Herzog, Jasmine Hsu, et al. Rt-1: Robotics transformer for real-world control at scale. *arXiv preprint arXiv:2212.06817*, 2022.
- [14] Qingwen Bu, Jisong Cai, Li Chen, Xiuqi Cui, Yan Ding, Siyuan Feng, Shenyuan Gao, Xindong He, Xuan Hu, Xu Huang, et al. Agibot world colosseum: A large-scale manipulation platform for scalable and intelligent embodied systems. *arXiv preprint arXiv:2503.06669*, 2025.
- [15] Kaiyuan Chen, Shuangyu Xie, Zehan Ma, and Ken Goldberg. Robo2vlm: Visual question answering from large-scale in-the-wild robot manipulation datasets, 2025. <https://arxiv.org/abs/2505.15517>.
- [16] Lawrence Yunliang Chen, Simeon Adebola, and Ken Goldberg. Berkeley UR5 demonstration dataset. <https://sites.google.com/view/berkeley-ur5/home>.
- [17] Zhe Chen, Weiyun Wang, Yue Cao, Yangzhou Liu, Zhangwei Gao, Erfei Cui, et al. Expanding performance boundaries of open-source multimodal models with model, data, and test-time scaling (internvl 2.5). *arXiv preprint arXiv:2412.05271*, 2024. <https://arxiv.org/abs/2412.05271>.
- [18] Zhe Chen, Weiyun Wang, Hao Tian, Shenglong Ye, Zhangwei Gao, Erfei Cui, et al. How far are we to gpt-4v? closing the gap to commercial multimodal models with open-source suites (internvl 1.5). *arXiv preprint arXiv:2404.16821*, 2024. <https://arxiv.org/abs/2404.16821>.
- [19] Zhe Chen, Jiannan Wu, Wenhai Wang, Weijie Su, Guo Chen, Sen Xing, Muyan Zhong, Qinglong Zhang, Xizhou Zhu, Lewei Lu, Bin Li, Ping Luo, Tong Lu, Yu Qiao, and Jifeng Dai. Internvl: Scaling up vision foundation models and aligning for generic visual-linguistic tasks. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2024. https://openaccess.thecvf.com/content/CVPR2024/papers/Chen_InternVL_Scaling_up_Vision_Foundation_Models_and_Aligning_for_Generic_CVPR_2024_paper.pdf.
- [20] Cheng Chi, Zhenjia Xu, Brian Ichter, and Avinash Shah. Diffusion policy: Visuomotor policy learning via action diffusion. In *Robotics: Science and Systems (RSS)*, 2023.
- [21] Cheng Chi et al. Visuomotor policy learning via action diffusion. *arXiv preprint arXiv:2303.04137*, 2023. <https://arxiv.org/abs/2303.04137>.
- [22] Shivin Dass, Jullian Yapeter, Jesse Zhang, Jiahui Zhang, Karl Pertsch, Stefanos Nikolaidis, and Joseph J. Lim. Clvr jaco play dataset, 2023. https://github.com/clvr-ai/clvr_jaco_play_dataset.
- [23] Danny Driess, Fei Xia, Mehdi SM Sajjadi, Corey Lynch, Aakanksha Chowdhery, Brian Ichter, Ayzan Wahid, Jonathan Tompson, Quan Vuong, Tianhe Yu, et al. Palm-e: An embodied multimodal language model. *arXiv preprint arXiv:2303.03378*, 2023.

- [24] Hao-Shu Fang, Hongjie Fang, Zhenyu Tang, Jirong Liu, Chenxi Wang, Junbo Wang, Haoyi Zhu, and Cewu Lu. Rh20t: A comprehensive robotic dataset for learning diverse skills in one-shot. *arXiv preprint arXiv:2307.00595*, 2023.
- [25] Charles Gaydon, Michel Daab, and Floryne Roche. Fractal: An ultra-large-scale aerial lidar dataset for 3d semantic segmentation of diverse landscapes. *arXiv preprint arXiv:2405.04634*, 2024.
- [26] Gemini Team. Gemini 2.5: Pushing the frontier with advanced reasoning, multimodality, long context, and next-generation agentic capabilities. *arXiv preprint arXiv:2507.06261*, 2025. <https://arxiv.org/abs/2507.06261>.
- [27] Yash Goyal, Tejas Khot, Douglas Summers-Stay, Dhruv Batra, and Devi Parikh. Making the v in vqa matter: Elevating the role of image understanding in visual question answering. In *Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017.
- [28] Siddhant Haldar, Vaibhav Mathur, Denis Yarats, and Lerrel Pinto. Watch and match: Supercharging imitation with regularized optimal transport. In *Conference on Robot Learning*, pages 32–43. PMLR, 2023.
- [29] Minh Heo, Youngwoon Lee, Doohyun Lee, and Joseph J Lim. Furniturebench: Reproducible real-world benchmark for long-horizon complex manipulation. *The International Journal of Robotics Research*, page 02783649241304789, 2023.
- [30] Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. In *NeurIPS*, 2020.
- [31] Physical Intelligence, Kevin Black, Noah Brown, et al. $\pi_{0.5}$: a vision-language-action model with open-world generalization. *arXiv preprint arXiv:2504.16054*, 2025. <https://arxiv.org/abs/2504.16054>.
- [32] Eric Jang, Alex Irpan, Mohi Khansari, Daniel Kappler, Frederik Ebert, Corey Lynch, Sergey Levine, and Chelsea Finn. Bc-z: Zero-shot task generalization with robotic imitation learning. In *Conference on Robot Learning*, pages 991–1002. PMLR, 2022.
- [33] Yunfan Jiang, Agrim Gupta, Zichen Zhang, Guanzhi Wang, Yongqiang Dou, Yanjun Chen, Li Fei-Fei, Anima Anandkumar, Yuke Zhu, and Linxi Fan. Vima: General robot manipulation with multimodal prompts. *arXiv preprint arXiv:2210.03094*, 2022.
- [34] Amita Kamath, Jack Hessel, and Kai-Wei Chang. What’s “up” with vision-language models? measuring spatial reasoning. *arXiv preprint arXiv:2310.19785*, 2023.
- [35] Koray Kavukcuoglu. Gemini 2.5: Our most intelligent ai model. <https://blog.google/technology/google-deepmind/gemini-model-thinking-updates-march-2025/>, 2025. Google DeepMind Blog.
- [36] Alexander Khazatsky, Karl Pertsch, Suraj Nair, Ashwin Balakrishna, Sudeep Dasari, Siddharth Karamcheti, Soroush Nasiriany, Mohan Kumar Srirama, Lawrence Yunliang Chen, Kirsty Ellis, et al. Droid: A large-scale in-the-wild robot manipulation dataset. *arXiv preprint arXiv:2403.12945*, 2024.
- [37] Moo Jin Kim, Ankur Handa, et al. Openvla: An open-source vision-language-action model. *arXiv preprint arXiv:2406.09246*, 2024.
- [38] Michelle A Lee, Yuke Zhu, Krishnan Srinivasan, Parth Shah, Silvio Savarese, Li Fei-Fei, Animesh Garg, and Jeannette Bohg. Making sense of vision and touch: Self-supervised learning of multimodal representations for contact-rich tasks. In *2019 International conference on robotics and automation (ICRA)*, pages 8943–8950. IEEE, 2019.
- [39] Chengmeng Li, Junjie Wen, Yan Peng, Yaxin Peng, Feifei Feng, and Yichen Zhu. Pointvla: Injecting the 3d world into vision-language-action models. *arXiv preprint arXiv:2503.07511*, 2025. doi: 10.48550/arXiv.2503.07511. <https://arxiv.org/abs/2503.07511>.
- [40] Yi Li, Yuquan Deng, Jesse Zhang, Joel Jang, Marius Memmel, Raymond Yu, Caelan Reed Garrett, Fabio Ramos, Dieter Fox, Anqi Li, et al. Hamster: Hierarchical action models for open-world robot manipulation. *arXiv preprint arXiv:2502.05485*, 2025.
- [41] Chen Liang, Michael I. Jordan, et al. Code as policies: Language model programs for embodied control. *arXiv preprint arXiv:2209.07753*, 2022. <https://arxiv.org/abs/2209.07753>.
- [42] Jacky Liang, Scott Emmons, Stefanos Nikolaidis, et al. Code as policies: Language model programs for embodied control. *arXiv preprint arXiv:2209.07753*, 2023.
- [43] Tsung-Yi Lin, Michael Maire, Serge Belongie, James Hays, Pietro Perona, Deva Ramanan, Piotr Dollár, and C Lawrence Zitnick. Microsoft coco: Common objects in context. In *European Conference on Computer Vision*, pages 740–755. Springer, 2014.
- [44] Yaron Lipman, Ricky Chen, Heli Ben-Hamu, Max Nickel, and Manzil Zaheer Le. Flow matching for generative modeling. *arXiv preprint arXiv:2210.02747*, 2022.
- [45] Huihan Liu, Soroush Nasiriany, Lance Zhang, Zhiyao Bao, and Yuke Zhu. Robot learning on the job: Human-in-the-loop autonomy and learning during deployment. *The International Journal of Robotics Research*, page 02783649241273901, 2022.
- [46] Kehui Liu, Chuyue Guan, Zhongjie Jia, Ziniu Wu, Xin Liu, Tianyu Wang, Shuai Liang, Peng Chen, Pingrui Zhang, Haoming Song, et al. Fastumi: A scalable and hardware-independent universal manipulation interface with dataset. *arXiv preprint arXiv:2409.19499*, 2024.

- [47] Jianlan Luo, Charles Xu, Xinyang Geng, Gilbert Feng, Kuan Fang, Liam Tan, Stefan Schaal, and Sergey Levine. Multistage cable routing through hierarchical imitation learning. *IEEE Transactions on Robotics*, 40:1476–1491, 2024.
- [48] Jianlan Luo, Charles Xu, Fangchen Liu, Liam Tan, Zipeng Lin, Jeffrey Wu, Pieter Abbeel, and Sergey Levine. Fmb: a functional manipulation benchmark for generalizable robotic learning. *The International Journal of Robotics Research*, 44(4):592–606, 2025.
- [49] Oier Mees, Jessica Borja-Diaz, and Wolfram Burgard. Grounding language with visual affordances over unstructured data. *arXiv preprint arXiv:2210.01911*, 2022.
- [50] Soroush Nasiriany, Tian Gao, Ajay Mandlekar, and Yuke Zhu. Learning and retrieval from prior data for skill-based imitation learning. *arXiv preprint arXiv:2210.11435*, 2022.
- [51] Soroush Nasiriany, Fei Xia, Wenhao Yu, Ted Xiao, Jacky Liang, Ishita Dasgupta, Annie Xie, Danny Driess, Ayzaan Wahid, Zhuo Xu, et al. Pivot: Iterative visual prompting elicits actionable knowledge for vlms. *arXiv preprint arXiv:2402.07872*, 2024.
- [52] Dantong Niu, Yuvan Sharma, Giscard Biamby, Jerome Quenum, Yutong Bai, Baifeng Shi, Trevor Darrell, and Roei Herzig. Llarva: Vision-action instruction tuning enhances robot learning. *arXiv preprint arXiv:2406.11815*, 2024.
- [53] NVIDIA, Nikita Cherniadev, Johan Bjorck, and Fernando Castañeda, Xingye Da, Runyu Ding, Linxi "Jim" Fan, Yu Fang, Dieter Fox, Fengyuan Hu, Spencer Huang, Joel Jang, Zhenyu Jiang, Jan Kautz, Kaushil Kundalia, Lawrence Lao, Zhiqi Li, Zongyu Lin, Kevin Lin, Guilin Liu, Edith Llopot, Loic Magne, Ajay Mandlekar, Avnish Narayan, Soroush Nasiriany, Scott Reed, You Liang Tan, Guanzhi Wang, Zu Wang, Jing Wang, Qi Wang, Jiannan Xiang, Yuqi Xie, Yinzhen Xu, Zhenjia Xu, Seonghyeon Ye, Zhiding Yu, Ao Zhang, Hao Zhang, Yizhou Zhao, Ruijie Zheng, and Yuke Zhu. GR00T N1: An open foundation model for generalist humanoid robots. In *ArXiv Preprint*, March 2025.
- [54] OpenAI. Hello gpt-4o. <https://openai.com/index/hello-gpt-4o/>, 2024.
- [55] OpenAI. Introducing gpt-5 for developers. <https://openai.com/index/introducing-gpt-5-for-developers/>, August 2025.
- [56] Karl Pertsch, Kyle Stachowicz, Brian Ichter, et al. Fast: Efficient action tokenization for vision-language-action models. *arXiv preprint arXiv:2501.09747*, 2025. <https://arxiv.org/abs/2501.09747>.
- [57] Gabriel Quere, Annette Hagengruber, Maged Iskandar, Samuel Bustamante, Daniel Leidner, Freek Stulp, and Jörn Vogel. Shared control templates for assistive robotics. In *2020 IEEE international conference on robotics and automation (ICRA)*, pages 1956–1962. IEEE, 2020.
- [58] Alec Radford, Jong Wook Kim, Chris Hallacy, et al. Learning transferable visual models from natural language supervision. In *ICML*, 2021.
- [59] remyxai. Vqasynth. GitHub repository, 2024. <https://github.com/remyxai/VQASynth/tree/main>.
- [60] Erick Rosete-Beas, Oier Mees, Gabriel Kalweit, Joschka Boedecker, and Wolfram Burgard. Latent plans for task-agnostic offline reinforcement learning. In *Conference on Robot Learning*, pages 1838–1849. PMLR, 2023.
- [61] Nur Muhammad Mahi Shafiullah, Anant Rai, Haritheja Etukuru, Yiqian Liu, Ishan Misra, Soumith Chintala, and Lerrel Pinto. On bringing robots home. *arXiv preprint arXiv:2311.16098*, 2023.
- [62] Rutav Shah, Roberto Martín-Martín, and Yuke Zhu. Mutex: Learning unified policies from multimodal task specifications. *arXiv preprint arXiv:2309.14320*, 2023.
- [63] Noam Shazeer and et al. Outrageously large neural networks: The sparsely-gated mixture-of-experts layer. In *ICLR*, 2017.
- [64] Lucy Xiaoyang Shi, Brian Ichter, Michael Equi, Liyiming Ke, Karl Pertsch, Quan Vuong, James Tanner, Anna Walling, Haohuan Wang, Niccolo Fusai, et al. Hi robot: Open-ended instruction following with hierarchical vision-language-action models. *arXiv preprint arXiv:2502.19417*, 2025.
- [65] Octo Model Team, Dibya Ghosh, Homer Walke, Karl Pertsch, Kevin Black, Oier Mees, Sudeep Dasari, Joey Hejna, Tobias Kreiman, Charles Xu, et al. Octo: An open-source generalist robot policy. *arXiv preprint arXiv:2405.12213*, 2024.
- [66] Shengbang Tong, Ellis Brown, Penghao Wu, Sanghyun Woo, Manoj Middepogu, Sai Charitha Akula, Jihan Yang, Shusheng Yang, Adithya Iyer, Xichen Pan, Austin Wang, Rob Fergus, Yann LeCun, and Saining Xie. Cambrian-1: A fully open, vision-centric exploration of multimodal llms, 2024.
- [67] Jörn Vogel, Annette Hagengruber, Maged Iskandar, Gabriel Quere, Ulrike Leipscher, Samuel Bustamante, Alexander Dietrich, Hannes Höppner, Daniel Leidner, and Alin Albu-Schäffer. Edan: An emg-controlled daily assistant to help people with physical disabilities. In *2020 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 4183–4190. IEEE, 2020.
- [68] Homer Rich Walke, Kevin Black, Tony Z Zhao, Quan Vuong, Chongyi Zheng, Philippe Hansen-Estruch, Andre Wang He, Vivek Myers, Moo Jin Kim, Max Du, et al. Bridgedata v2: A dataset for robot learning at scale. In *Conference on Robot Learning*, pages 1723–1736. PMLR, 2023.
- [69] Jianyuan Wang, Minghao Chen, Nikita Karaev, Andrea Vedaldi, Christian Rupprecht, and David Novotny. Vggt: Visual geometry grounded transformer. In *Proceedings of the IEEE/CVF Conference on Computer Vision*

- and Pattern Recognition (CVPR), 2025. https://openaccess.thecvf.com/content/CVPR2025/papers/Wang_VGGT_Visual_Geometry_Grounded_Transformer_CVPR_2025_paper.pdf.
- [70] Junying Wang et al. A4bench: An affordance benchmark for multimodal large language models. *arXiv preprint*, 2025. Placeholder entry; replace with final arXiv ID when available.
 - [71] Weiyun Wang, Zhangwei Gao, Lixin Gu, Hengjun Pu, Long Cui, Xingguang Wei, Zhaoyang Liu, Linglin Jing, Shenglong Ye, Jie Shao, Zhaokai Wang, Zhe Chen, Hongjie Zhang, Ganlin Yang, Haomin Wang, Qi Wei, Jinhui Yin, Wenhao Li, Erfei Cui, Guanzhou Chen, Zichen Ding, Changyao Tian, Zhenyu Wu, Jingjing Xie, Zehao Li, Bowen Yang, Yuchen Duan, Xuehui Wang, Songze Li, Xiangyu Zhao, Haodong Duan, Nianchen Deng, Bin Fu, Yinan He, Yi Wang, Conghui He, Botian Shi, Junjun He, Yingdong Xiong, Han Lv, Lijun Wu, Wenqi Shao, Kaipeng Zhang, Huipeng Deng, Jiaye Ge, Biquing Qi, Jiaye Ge, Qipeng Guo, Wenwei Zhang, Wanli Ouyang, Limin Wang, Min Dou, Xizhou Zhu, Tong Lu, Dahua Lin, Jifeng Dai, Weijie Su, Bowen Zhou, Kai Chen, Yu Qiao, Wenhao Wang, and Gen Luo. Internvl3.5: Advancing open-source multimodal models in versatility, reasoning, and efficiency. *arXiv preprint arXiv:2508.18265*, 2025. <https://arxiv.org/abs/2508.18265>.
 - [72] Yifan Wang, Jianjun Zhou, Haoyi Zhu, Wenzheng Chang, Yang Zhou, Zizun Li, Junyi Chen, Jiangmiao Pang, Chunhua Shen, and Tong He. pi^3 : Scalable permutation-equivariant visual geometry learning. *arXiv preprint arXiv:2507.13347*, 2025. doi: 10.48550/arXiv.2507.13347. <https://arxiv.org/abs/2507.13347>.
 - [73] An Yang, Baosong Yang, Beichen Zhang, et al. Qwen2.5 technical report. *arXiv preprint arXiv:2412.15115*, 2024. <https://arxiv.org/abs/2412.15115>.
 - [74] Qiyang Yu, Quan Sun, Xiaosong Zhang, Yufeng Cui, Fan Zhang, Yue Cao, Xinlong Wang, and Jingjing Liu. Capsfusion: Rethinking image-text data at scale. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 14022–14032, 2024.
 - [75] Wentao Yuan, Jiafei Duan, Valts Blukis, Wilbert Pumacay, Ranjay Krishna, Adithyavairavan Murali, Arsalan Mousavian, and Dieter Fox. Robopoint: A vision-language model for spatial affordance prediction for robotics. *arXiv preprint arXiv:2406.10721*, 2024.
 - [76] Michał Zawalski, William Chen, Karl Pertsch, Oier Mees, Chelsea Finn, and Sergey Levine. Robotic control via embodied chain-of-thought reasoning. In *Conference on Robot Learning (CoRL)*, 2024.
 - [77] Qingqing Zhao, Yao Lu, Moo Jin Kim, Zipeng Fu, Zhuoyang Zhang, Yecheng Wu, Zhaoshuo Li, Qianli Ma, Song Han, Chelsea Finn, et al. Cot-vla: Visual chain-of-thought reasoning for vision-language-action models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2025.
 - [78] Tony Z. Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware, 2023. <https://arxiv.org/abs/2304.13705>.
 - [79] Haoyu Zhen, Xiaowen Qiu, Peihao Chen, Jincheng Yang, Xin Yan, Yilun Du, Yining Hong, and Chuang Gan. 3d-vla: A 3d vision-language-action generative world model. In *Proceedings of the 41st International Conference on Machine Learning (ICML)*, volume 235 of *Proceedings of Machine Learning Research*, pages 61229–61245. PMLR, July 2024. <https://proceedings.mlr.press/v235/zhen24a.html>.
 - [80] Jinguo Zhu, Weiyun Wang, Zhe Chen, Zhaoyang Liu, Shenglong Ye, Lixin Gu, Yuchen Duan, Hao Tian, Weijie Su, Jie Shao, Zhangwei Gao, Erfei Cui, Yue Cao, Yangzhou Liu, Weiye Xu, Hao Li, Jiahao Wang, Han Lv, Dengnian Chen, Songze Li, Yinan He, Tan Jiang, Jiapeng Luo, Yi Wang, Conghui He, Botian Shi, Xingcheng Zhang, Wenqi Shao, Junjun He, Yingdong Xiong, Wenwen Qu, Peng Sun, Penglong Jiao, Lijun Wu, Kaipeng Zhang, Huipeng Deng, Jiaye Ge, Kai Chen, Limin Wang, Min Dou, Lewei Lu, Xizhou Zhu, Tong Lu, Dahua Lin, Yu Qiao, Jifeng Dai, and Wenhao Wang. Internvl3: Exploring advanced training and test-time recipes for open-source multimodal models. *arXiv preprint arXiv:2504.10479*, 2025. <https://arxiv.org/abs/2504.10479>.
 - [81] Xinghao Zhu, Ran Tian, Chenfeng Xu, Mingxiao Huo, Wei Zhan, Masayoshi Tomizuka, and Mingyu Ding. Fanuc manipulation: A dataset for learning-based manipulation with fanuc mate 200id robot, 2023.
 - [82] Yifeng Zhu, Abhishek Joshi, Peter Stone, and Yuke Zhu. Viola: Object-centric imitation learning for vision-based robot manipulation. In *6th Annual Conference on Robot Learning*, 2022.
 - [83] Yifeng Zhu, Peter Stone, and Yuke Zhu. Bottom-up skill discovery from unsegmented demonstrations for long-horizon robot manipulation. *IEEE Robotics and Automation Letters*, 7(2):4126–4133, 2022.
 - [84] Brianna Zitkovich, Anthony Brohan, Noah Brown, et al. Rt-2: Vision-language-action models transfer web knowledge to robotic control. In *Proceedings of Machine Learning Research*, volume 229, 2023. <https://proceedings.mlr.press/v229/zitkovich23a.html>.