

WAM-TTT: 通过测试时观看人类操作来引导世界-动作模型

Yusen Feng^{1,2,*} Bingchen Han^{1,2,*} Jiangran Lyu^{1,2,*}
 Kai Liu^{2,3} Yixin Zheng^{2,3} Yuxuan Wan^{1,2} Weiheng Liu^{2,3} Sun Han^{1,2} Ruiqin Li^{1,2}
 Yulong Zhang¹ Fangfu Liu⁴ Xuesong Shi² Libin Liu^{1,†} Yizhou Wang^{1,†} Zhizheng Zhang^{2,†} He Wang^{1,2,†}
¹Peking University ²Galbot ³CASIA ⁴Tsinghua University
 *Equal contribution [†]Corresponding authors



图 1: WAM-TTT 概览。给定来自不同环境的无标注人类演示, WAM-TTT 无需重定向、机器人动作或人类侧标注即可引导预训练的世界-动作模型 (WAM)。在部署期间, 人类视频通过自监督视频预测被吸收到轻量级测试时训练 (TTT) 快速权重中, 而预训练的动作模型保持冻结。随后, 适应后的记忆通过 WAM 共享的视觉-动作动态引导机器人执行, 从而实现从人类演示中高效且可复用的引导。

Abstract: 引导机器人基础模型 (RFM) 适应新任务变体或用户偏好行为仍具挑战性, 通常需要额外的机器人演示、任务特定微调或长上下文条件化。本文提出 WAM-TTT, 一个通过原始人类视频引导世界-动作模型的测试时训练框架。WAM-TTT 不将人类视频视为待模仿的轨迹, 而是通过自监督视频预测将其吸收到冻结 WAM 内部的轻量级自适应记忆中。为使该记忆对控制有用, 本文引入一个元训练阶段, 利用成对的人机数据和键-值记忆重建目标来对齐人类演示与机器人行为。在测试时, 仅需无标注人类视频即可适应记忆, 而预训练的 WAM 保持冻结。这实现了无需机器人动作、人类侧标注或任务特定微调的高效且可复用引导, 同时保留基础模型的泛化能力。大量实验表明, WAM-TTT 在多种操作任务和泛化设置下始终优于基于上下文的人类视频条件化基线。

关键词: 世界-动作模型, 测试时训练, 人类视频

1 引言

近年来，机器人领域日益追求通过大规模预训练构建通用机器人基础模型（Robot Foundation Model, RFM）。然而，现有大多数 RFM 主要将知识固化于固定模型参数中。一旦部署，其行为在很大程度上由预训练权重和有限的调节接口（如语言指令、目标图像或短时观测历史 [1, 2, 3, 4, 5, 6]）决定。因此，引导 RFM 适应新任务变体、物体交互或用户偏好策略，通常需要收集额外的机器人演示或对完整模型进行微调。这限制了 RFM 在开放式部署场景中的灵活性与可复用性，因为用户可能希望在不重新训练机器人策略的情况下快速指定新行为。

人类演示为引导 RFM 提供了一种自然且可扩展的接口 [7, 8, 9, 10, 11, 12]：用户只需展示应如何处理物体，而无需指定机器人动作。现有方法通常通过联合训练或利用机器人数据进行微调来利用人类视频 [7, 8, 9, 10, 13, 11, 12]，往往依赖额外监督信号，如手部姿态、三维运动或重定向轨迹 [2, 14, 3, 15, 4, 6, 16, 17]。此类监督可能噪声较大且获取成本高昂，而针对特定任务的微调可能导致灾难性遗忘，降低预训练模型的可复用性。一种更直接的替代方案是让机器人策略以原始人类视频为条件 [18]，但这需要在大规模预训练期间学习此类能力，并且随着演示的累积，上下文长度会迅速增长。

为了解决这些挑战，我们提出了 WAM-TTT，这是一个测试时训练框架，用于通过人类演示来引导世界动作模型（WAMs）。WAM-TTT 不是将人类视频视为要模仿的轨迹，而是将它们作为通过视频预测学习的部署时记忆。由于 WAMs 联合建模视觉动态和动作，适应后的记忆可以通过模型共享的视频-动作表示来引导动作生成。为了使这种适应对控制有用，我们引入了一个元训练阶段，该阶段使用配对的人类-机器人数据和键值记忆重建损失来对齐人类演示与机器人行为。在部署时，只需要人类视频：记忆通过视频预测更新，而预训练的 WAM 保持冻结。因此，WAM-TTT 能够高效且可重用地将 WAMs 引导到新的任务变体，同时保持基础模型的泛化能力。

大量实验表明，WAM-TTT 始终优于基于上下文学习的人-视频条件基线。我们的消融实验进一步证明了测试时记忆适应、视频预测目标以及键值记忆重建损失的重要性，凸显了我们设计在引导预训练 WAM 方面的有效性。我们的贡献有三方面。

1. 本文将基于人类视频的世界动作模型引导构建为测试时训练问题，从而在部署阶段仅利用原始人类演示（无需机器人动作）即可实现适应性调整。
2. 本文提出 WAM-TTT，一种即插即用的测试时训练记忆，通过自监督视频预测将人类视频吸收到冻结的世界动作模型中，并结合人机对齐目标，使学习到的记忆对机器人控制有用。
3. 本文证明，WAM-TTT 能够实现基于人类演示的高效且可复用的引导，其性能优于上下文视频条件化，同时避免了额外的人工标注和全模型微调。

2 相关工作

世界行动模型。世界模型（World Model）已成为机器人学习中日益重要的接口，因为它们为推理动作如何改变未来观测提供了预测基础 [19, 20, 21]。近期世界-动作模型（World-Action Model, WAM）更进一步，将未来视觉预测与动作生成耦合，使策略能够基于想象的状态进行落地




图 2: WAM-TTT 的流程。本文首先利用成对的人机演示元训练一个快权重记忆，通过键值记忆重构目标促使人类视觉线索与机器人行为对齐。在测试时，该记忆通过视频预测从无标签人类视频中自适应，而预训练的 WAM 保持冻结。随后，自适应记忆通过 WAM 共享的视觉-动作动态引导机器人执行。

转移而非纯粹的反应式动作预测 [14, 17, 16, 22, 23, 24, 25, 26, 27, 24, 25, 28, 29, 30, 31, 32, 33, 34, 35, 36, 37, 38, 39, 40, 41, 42, 43]。这种耦合也使得视频成为一种自然的监督信号：无动作视频可以改进视觉动态表示，而机器人轨迹可以将这些表示锚定到可执行动作 [14, 17, 16, 22, 44, 45]。然而，现有的世界动作模型主要关注预训练，却忽视了部署过程中的可引导性。

测试时训练与自适应记忆。测试时训练利用源自测试输入的信号来适应模型，通常在分布偏移下通过自监督或基于熵的目标实现 [46, 47, 48, 49, 50]。近期工作将这一思想重新表述为记忆：TTT 层及相关的快权重机制将当前序列的信息存储在自适应参数中，而非仅依赖固定激活或显式键值缓存 [50, 51, 52]。机器人学领域也通过辅助损失、基于视觉模型的目标或在线环境反馈探索了测试时自适应 [5, 53, 54, 55]。这些方法通常从机器人观测、奖励或交互轨迹中适应。WAM-TTT 则使用人类演示作为测试时信息源。本文在预训练期间校准 TTT 分支，使得在推理时，人类视频的键/值特征可以作为 WAM 内部的残差技能记忆，而非在线更新完整策略。

从人类视频中学习。人类视频提供了关于物体、接触和任务进展的可扩展证据，但将其迁移到机器人上十分困难，因为人类运动无法由机器人直接执行。先前的工作通过使用人类数据进行训练时的表示学习、跨域对齐或策略监督来弥补这一差距 [7, 8, 9, 10, 13, 11, 12]。其他方法更直接地使用人类视频，但通常需要手部姿态、RGB-D 运动、重定向轨迹、物体流、潜在计划提取、生成视频、机器人演示或在线交互 [2, 14, 3, 15, 4, 6, 16, 17, 18]。相比之下，WAM-TTT 将一小组未见且未标注的人类玩耍视频视为部署时的技能记忆。这些视频不会被转换为机器人动作或显式的人类姿态；相反，它们为校准的 TTT 交叉注意力分支提供键/值上下文，从而在无需重定向、生成演示、机器人上下文示例、交互回放或完整的部署时微调的情况下实现技能迁移。

3 方法

3.1 架构

世界动作模型。我们在 LDA[23] 之上构建 WAM-TTT，LDA 是一个预训练的世界动作模型（WAM）。LDA 中的每个扩散 Transformer 块包含两个耦合的专家：一个处理视觉潜在标记的视频专家，以及一个处理机器人动作标记的动作专家。这两个专家通过联合注意力进行通信。我们将块 ℓ 处的视频和动作标记分别表示为 $\mathbf{z}^{(\ell)}$ 和 $\mathbf{x}^{(\ell)}$ ，并将原始 LDA 块的输出表示为 $\hat{\mathbf{z}}^{(\ell+1)}$ 和 $\hat{\mathbf{x}}^{(\ell+1)}$ 。

视频 TTT 层。我们保持预训练的 WAM 架构不变，仅向视频专家添加 TTT 残差分支。对于经过 TTT 增强的块，其输出为

$$\mathbf{z}^{(\ell+1)} = \hat{\mathbf{z}}^{(\ell+1)} + \Delta \mathbf{z}_{\text{TTT}}^{(\ell)}, \quad \mathbf{x}^{(\ell+1)} = \hat{\mathbf{x}}^{(\ell+1)}. \quad (1)$$

每个 TTT 层遵循先前 TTT 层中的快速权重记忆公式 [46, 47, 50, 52, 51]。它包含慢速投影 $\theta_K^{(\ell)}, \theta_V^{(\ell)}, \theta_Q^{(\ell)}, \theta_O^{(\ell)}$ 和一个快速权重网络 $f_{W^{(\ell)}}$ 。给定上下文标记，该层构建键和值；给定当前视频标记，它构建查询。在快速权重通过阶段特定的 TTT 目标更新后，该层将快速权重网络应用于视频查询：

$$\Delta \mathbf{z}_{\text{TTT}}^{(\ell)} = \theta_O^{(\ell)} f_{W^{(\ell)}} \left(\theta_Q^{(\ell)} (\mathbf{z}^{(\ell)}) \right). \quad (2)$$

3.2 人机元训练

元训练目标。给定成对的人机演示，我们将无动作的人类视频片段记为 $\mathbf{u}_h$ ，将同步的机器人轨迹记为其动作和观测。由于每个测试时训练块的视频输出（公式 1-2）被残差 $\theta_O^{(\ell)} f_{W^{(\ell)}} (\theta_Q^{(\ell)} (\mathbf{z}^{(\ell)}))$ 偏移，快速权重 $\{W^{(\ell)}\}$ 进入逐块视频流，因此传播到 (i) 最终块视频潜在表示 $\mathbf{z}^{(L)}$ ，其上的人类视频预测损失 $\mathcal{L}_{\text{vg}}^{\text{human}}$ (ii) 下面定义的逐层键值记忆重建损失 $\mathcal{L}_{\text{KVM}}^{(\ell)}$ ，该损失探测 f_W 将人类键映射到人类值的程度。我们在这两个目标组合的内环信号上调整快速权重。

键值记忆重建损失。对于每个测试时训练层 ℓ ，同步的人类令牌被投影为键和值，而机器人视频令牌被投影为查询：

$$\mathbf{K}_h^{(\ell)} = \theta_K^{(\ell)} (\mathbf{h}_\phi^{(\ell)}), \quad \mathbf{V}_h^{(\ell)} = \theta_V^{(\ell)} (\mathbf{h}_\phi^{(\ell)}), \quad \mathbf{Q}_r^{(\ell)} = \theta_Q^{(\ell)} (\mathbf{z}_r^{(\ell)}).$$

逐层记忆重建损失衡量当前快速权重从人类键重建人类值的程度：

$$\mathcal{L}_{\text{KVM}}^{(\ell)}(W_i) = \frac{1}{BL_h d} \left\| f_{W_i^{(\ell)}}(\mathbf{K}_h^{(\ell)}) - \mathbf{V}_h^{(\ell)} \right\|_2^2. \quad (3)$$

内环适应。通过式 1-2 将 $\mathbf{u}_h$ 传播经过 L 个 TTT 增强块，得到最终视频潜变量，其上施加标准 LDA 视频预测损失；下文 $\mathcal{L}_{\text{adapt}}$ 对 W 的依赖正是这一传播过程。从

$W_0^{(\ell)} = W_{\text{init}}^{(\ell)}$ 开始，快速权重通过内层随机梯度下降在组合的人类侧目标上更新：

$$\mathcal{L}_{\text{adapt}}(W_i) = \mathcal{L}_{\text{vg}}^{\text{human}}(\mathbf{u}_h; \Theta_{\text{WAM}}, \theta_{\text{TTT}}, W_i) + \lambda \sum_{\ell} \mathcal{L}_{\text{KVM}}^{(\ell)}(W_i), \quad (4)$$

$$W_{i+1}^{(\ell)} = W_i^{(\ell)} - \eta \nabla_{W_i^{(\ell)}} \mathcal{L}_{\text{adapt}}(W_i), \quad (5)$$

其中 $i \in \{0, 1, \dots, N\}$ 索引内层随机梯度下降迭代， λ 加权记忆重建项（见表 B.1）。自适应权重 $W_N^{(\ell)}$ 正是式 2 中残差读出所使用的。 $\mathcal{L}_{\text{adapt}}$ 中的两项仅依赖于无动作的人类侧，因此相同的内部循环信号在测试时仍然可用（第 3.3 节）。

外层损失。更新后的快速权重 $W_N^{(\ell)}$ 由 $Q_r^{(\ell)}$ 在机器人侧查询，并产生式 2 中的残差。外层训练目标是配对机器人数据上的标准 WAM 多任务损失，它结合了机器人视频潜变量上的视频扩散目标和机器人动作块上的动作扩散目标，继承自底层 LDA 骨干 [23]：

$$\mathcal{L}_{\text{meta}} = \mathcal{L}_{\text{WAM}}^{\text{robot}}. \quad (6)$$

梯度通过 TTT 残差和内层快速权重更新进行反向传播。优化的参数包括 WAM 参数、TTT 慢投影 $\theta_{\{K,V,Q,O\}}$ 和初始化 W_{init} 。自适应快速权重在每个训练样本后被丢弃并重新初始化

from W_{init} .

人机数据同步。为支持带对齐的训练，我们对人机数据对进行离线同步。对于长度为 T_r 的片段中的机器人时间步 t ，计算归一化相位 $\phi = t/T_r$ ，并从长度为 T_h 的配对人类视频中选择最近相位的帧。

3.3 基于人类视频的测试时训练

在部署阶段，世界-动作模型（WAM）参数、测试时训练（TTT）慢投影以及 W_{init} 均被冻结。测试时训练的输入是来自目标域的一小批无动作人类视频 $\mathcal{B}_h$ 。我们以视频生成模式运行模型，并仅优化视频侧 TTT 快权重，优化目标与元训练时使用的组合目标形式相同：

$$\mathcal{L}_{\text{TTT}}(W_i) = \frac{1}{|\mathcal{B}_h|} \sum_{\mathbf{u} \in \mathcal{B}_h} \left[\mathcal{L}_{\text{vg}}(\mathbf{u}; \Theta_{\text{WAM}}, \theta_{\text{TTT}}, W_i) + \lambda \sum_{\ell} \mathcal{L}_{\text{KVM}}^{(\ell)}(\mathbf{u}; W_i) \right], \quad (7)$$

$$W_{i+1}^{(\ell)} = W_i^{(\ell)} - \eta \nabla_{W_i^{(\ell)}} \mathcal{L}_{\text{TTT}}(W_i). \quad (8)$$

$\mathcal{L}_{\text{vg}}$ 和 $\mathcal{L}_{\text{KVM}}^{(\ell)}$ 均仅从人类侧计算（公式 3），因此无需机器人侧监督。不更新任何 WAM 参数、TTT 慢投影、初始化参数或动作专家参数。经过 N 次测试时更新（与公式 5 相同的步数预算；见表 B.1）后，自适应快权重 W_N 在机器人执行期间保持固定：

$$\mathbf{a}_{t:t+k} \sim p_{\Theta_{\text{WAM}}, \theta_{\text{TTT}}, W_N}(\mathbf{a}_{t:t+k} \mid \mathbf{o}_t, \mathbf{g}). \quad (9)$$

4 实验

我们在三种机器人实体上评估 WAM-TTT 的真实机器人操作性能。实验流程与第 3 节一致：先预训练 WAM，然后进行人-机器人元训练，部署时 TTT 分支的快权重通过内部随机梯度下降（SGD）在小组未见任务的人类演示上在线自适应，而 WAM 和慢权重保持冻结。

4.1 实验设置

机器人与任务。我们在三种真实机器人实体上评估 WAM-TTT——字树 G1（人形机器人）、Galbot 夹爪（双臂两指）和 Galbot sharpia（双臂灵巧手）——共涉及 9 项操作任务：转移瓶子、桌面清理、递送饮料、交换位置、倒水、盖章、翻牛排、金字塔堆叠和多步骤牛排。每项任务分配给单一实体，并在两种设置下评估。原始（Orig.）设置在标准化机器人隔间内收集评估试验，该隔间也用于记录训练数据，光照、桌面高度和物体实例均匹配。新（New）设置将机器人部署在之前未见过的家庭环境中，光照、桌面高度和被操作物体相对于训练均发生联合变化——即组合的分布外扰动，而非单因素偏移。我们报告每个（任务，设置）单元 25 次试验的进度（%）。进度是近期视觉-语言-动作（VLA）评估中使用的标准部分得分度量：每次试验完整完成任务得 1.0 分，否则按达到的预定义子目标数量比例给出 $[0, 1]$ 区间内的分数。




图 3: 实验设置。




图 4: 定性执行过程。对于每个未见任务，我们展示机器人执行过程胶片条（右）和作为部署时键/值使用的配对人类演示（左）。

数据集与度量。我们收集了一个元训练数据集，包含 2,286 个配对的人类与机器人回合，广泛覆盖 9 个不同的操作任务。机器人和人类数据均从第一人称视角捕获。具体而言，人类演示使用 GoPro 相机记录，不进行任何形式的姿态估计。

4.2 与基线对比

基线。我们将我们的 WAM-TTT 与五个基线进行比较。LDA [23]: 预训练的 WAM 主干，不使用人类数据，无 TTT 分支。WAM-COTRAIN: 相同的 WAM 通过 WAM 多任务目标使用配对的人类游戏数据进一步训练（协同训练；无 TTT 分支）。WAM-ICL: 相同的 WAM 将部署时人类视频作为上下文演示输入，不进行快速权重适应。EGOSCALE [10]: 一个近期在多样化第一人称人类数据上扩展的 VLA；由于原始模型未开源，我们评估我们的重新实现。 $\pi_{0.5}$ [56]: Physical Intelligence 的开放世界泛化 VLA。

定量结果。表 1 报告了新家庭场景下各任务的进展；包含工位内原始数据的完整表格见附录 C。WAM-TTT 在 9 项任务上的平均成功率为 **46.2%**

表 1：主要结果。在未见过的家庭环境中评估的 9 项操作任务的进展（%）。所有单元格均为 25 次试验的平均值。包含工位内原始场景的完整表格见附录 C。

Method	Transfer Bottle	Table Bussing	Deliver Drink	Swap Place	Pour Water	Stamp Paper	Flip Steak	Pyramid stacking	Multi-step Steak	Avg.
$\pi_{0.5}$ [56]	33.4	36.0	15.0	7.4	10.0	24.4	2.0	4.7	0.3	14.8
LDA [23]	56.0	70.0	55.0	44.4	20.0	33.3	10.0	0.6	3.0	32.5
EGOSCALE [10]	34.4	44.0	33.3	6.0	7.5	1.1	5.0	2.0	2.0	15.0
WAM-COTRAIN	10.0	10.0	44.3	48.1	24.0	21.7	34.2	12.0	23.8	25.3
WAM-ICL	10.0	10.0	14.2	10.0	0.0	5.0	10.0	2.0	2.5	7.1
WAM-TTT	55.6	100.0	66.7	66.7	30.0	8.3	34.3	10.4	43.8	46.2

相比之下，无测试时自适应的 LDA[23] 骨干网络为 32.5%（**+13.7** 个百分点），WAM-COTRAIN（**+20.9** 为 25.3%（个百分点），EGOSCALE [10]（**+31.2** 为 15.0%（个百分点）， $\pi_{0.5}$ [56]（**+31.4** 为 14.8%（个百分点），WAM-ICL 为 7.1%（**+39.1** 个百分点）。由此得出三点观察。（i）与 WAM-ICL 的差距是设计假设最有力的证据：将相同的人类视频作为上下文令牌输入，无法将技能迁移到未见过的家庭环境，而将其吸收为快速权重记忆则可以实现。（ii）与 LDA（相同的 WAM，无人类数据，无测试时自适应）的差距量化了人类操作数据的贡献；与 $\pi_{0.5}$ 和 EGOSCALE（完全没有测试时人类视频）的差距量化了测试时自适应本身的贡献。（iii）在 9 项任务中，WAM-TTT 在 7 项上直接获胜，并在翻牛排（10.0）上打平；唯一的例外是盖章（8.3 对 LDA 的 33.3），其中工位内的盖章姿态在几何上非常紧凑，家庭场景的扰动破坏了对齐，而人类视频并未明显纠正这种对齐。

定性结果。图 4 展示了三个具有代表性的未见任务上的机器人执行过程，以及用作部署时键/值的人类演示。额外的消融实验（数据比例扫描、模型架构）见附录 E。

4.3 消融实验

我们进行消融实验，以分离 WAM-TTT 中每个组件的贡献。表 2 报告了在餐桌清理和位置交换任务上 10 次试验的进展。完整的 WAM-TTT 模型结合了人机元训练、键值记忆重建目标，以及从人类视频对视频侧测试时自适应层的测试时自适应。**WAM-LoRA** 将测试时自适应快速权重机制替换为通用的参数高效自适应基线。无元训练去除了人机元训练阶段，因此测试时自适应分支没有被明确训练为将人类键/值与机器人查询对齐。无记忆重建去除了内部键值记忆重建损失，禁用了向快速权重的结构化写入机制。无测试时自适应完全去除了人类视频自适应，并评估冻结的 WAM。

该消融实验分离了三种设计选择的影响：部署时使用人类视频、通过测试时训练（TTT）快权重表示这些视频，以及利用成对的人机数据元训练查询/键/值（Q/K/V）接口。WAM-TTT 与无 TTT（w/o TTT）之间的比较衡量了测试时人类视频自适应的价值。与 **WAM-LoRA** 的比较检验了改进是否具体来自 TTT 记忆结构，而非通用的低秩适配。无元训练（w/o Meta Training）和无记忆重建（w/o Memory Recon.）的性能下降进一步量化了部署前学习人机记忆接口的重要性。

4.4 泛化保持

一个潜在的担忧是，基于短人类视频的测试时自适应可能使 WAM 过拟合于演示轨迹，从而牺牲从预训练基础模型继承的广泛泛化能力。我们通过以下方式评估：首先使用目标任务的人类操作视频自适应 WAM-TTT，然后在改变执行条件的扰动下测试自适应后的策略，

表 2: 训练与测试时推理选择的协议消融。新设置下 Table Bussing 和 Swap Place 任务的进度 (%)；每格 10 次试验。

Task	WAM-TTT	WAM-LoRA	w/o Meta Training	w/o Memory Recon.	w/o TTT
Table Bussing	100.0	30.0	9.0	66.7	40.0
Swap Place	88.9	0.0	0.0	72.0	74.1




图 5: 泛化设置。

包括光照、物体位置以及与实施例相关的外观变化。表 3 将 WAM-TTT 与预训练的 LDA[23] 骨干网络、策略基线 $\pi_{0.5}$ [56] 以及 WAM-ICL 进行比较，其中 WAM-ICL 仅将相同的人类视频作为上下文演示使用，而不进行快权重自适应。

关键比较在于 WAM-ICL 与 WAM-TTT 之间。两种方法接收相同的人类演示，但使用方式不同：WAM-ICL 在推理时用演示条件化冻结模型，而 WAM-TTT 通过测试时训练将人类视频转换为视频侧快权重。由于 WAM 骨干网络和动作专家保持冻结，WAM-TTT 在不覆盖预训练动作先验的情况下，引导用于动作生成的视觉动态。如表 3 所示，WAM-TTT 在双臂任务 Deliver Drink 的所有扰动类型上均保持强劲性能。这表明所提出的 TTT 机制并非仅仅记忆人类演示；相反，它提供了任务和领域特定的自适应，同时保持了基础模型对视觉和空间偏移的原有鲁棒性。

5 结论、局限性与未来方向

本文提出了世界-动作模型（World-Action Model）的两阶段适配流程 WAM-TTT。人机元训练阶段将空间 TTT 式 [52] 快权重分支附加到世界-动作模型的视频专家上，并通过世界-动作模型多任务外层损失联合更新世界-动作模型与分支的慢投影，而快权重则通过基于同步人机对的自监督视频预测与键值记忆重构目标的内层随机梯度下降实现在线适配。测试阶段，世界-动作模型、动作专家及所有慢投影均被冻结；仅视频侧快权重通过用户未见任务人类视频上的内层随机梯度下降进行更新。该方案实现了部署时的技能吸收，且无需对世界-动作模型执行任何梯度步骤，并在真实机器人操作套件上达到或超越了在线适配基线（第 4 节）。

局限性。 三点注意事项。（1）元训练阶段的配对假设是：配对的人类片段与机器人片段覆盖相同的技能阶段分布；错位的表现会以损失函数无法标记的方式削弱内部自适应信号（第 4.3 节）。

（2）部署时的快速权重自适应受限于快速权重网络的表达能力，以及元训练时固定的慢投影；部署任务偏离元训练配对分布越远，自适应能力越弱。我们尚未通过实验刻画该边界。

（3）本文的部署时接口仅接受以自我为中心的人类 RGB 帧；它并未利用手部姿态、接触或三维场景线索，而相关研究已表明这些线索是有用的 [57, 11]。

表 3: 泛化能力评估。

Task	Perturbation	$\pi_{0.5}$ [56]	LDA[23]	WAM-ICL	WAM-TTT
Deliver Drink	Lighting	28.0	54.0	12.0	66.0
	Spatial	0.0	28.0	20.0	56.0

展望。元训练/测试时 TTT 接口超越了人类键/值 (Key/Value) 的范畴: 任何具有相位可配对训练信号的辅助模态, 原则上都可以在相同的仅损失后残差机制下驱动一个并行的快速权重分支。我们将 WAM-TTT 视为迈向基于 WAM 的基础模型骨干的一步, 其注意力结构带有明确的“适应席位”, 下游实践者可以利用手头的任何辅助信息来驱动这些席位。

参考文献

- [1] T. Yu et al. One-shot imitation from observing humans via domain-adaptive meta-learning. In *RSS*, 2018.
- [2] S. Bahl, A. Gupta, and D. Pathak. Human-to-robot imitation in the wild. In *RSS*, 2022.
- [3] M. Xu, Z. Xu, C. Chi, M. Veloso, and S. Song. Xskill: Cross embodiment skill discovery. In *CoRL*, 2023.
- [4] H. Bharadhwaj, A. Gupta, V. Kumar, and S. Tulsiani. Towards generalizable zero-shot manipulation via translating human interaction plans. In *ICRA*, 2024.
- [5] N. Hansen et al. Self-supervised policy adaptation during deployment. In *ICLR*, 2021.
- [6] M. Xu, Z. Xu, C. C. Pan, X. Zhu, C. Tomei, Y. Shen, Z. Wu, S.-R. Chen, J. B. Tenenbaum, T. Lozano-Perez, and S. Song. Flow as the cross-domain manipulation interface. In *CoRL*, 2024.
- [7] S. Kareer, D. Patel, R. Punamiya, P. Mathur, S. Cheng, C. Wang, J. Hoffman, and D. Xu. Egomimic: Scaling imitation learning via egocentric video. *arXiv preprint arXiv:2410.24221*, 2024.
- [8] R. Hoque, P. Huang, D. J. Yoon, M. Sivapurapu, and J. Zhang. Egodex: Learning dexterous manipulation from large-scale egocentric video. *arXiv preprint arXiv:2505.11709*, 2025.
- [9] K. Grauman et al. Ego-exo4d: Understanding skilled human activity from first- and third-person perspectives. In *CVPR*, 2024.
- [10] R. Zheng et al. Egoscale: Scaling dexterous manipulation with diverse egocentric human data. *arXiv preprint arXiv:2602.16710*, 2026.
- [11] H. Chen et al. Vidbot: Learning generalizable 3d actions from in-the-wild 2d human videos for zero-shot robotic manipulation. In *CVPR*, 2025.
- [12] H. Kim et al. Uniskill: Imitating human videos via cross-embodiment skill representations. In *CoRL*, 2025.
- [13] Z. Chen, S. Chen, E. Arlaud, I. Laptev, and C. Schmid. Vividex: Learning vision-based dexterous manipulation from human videos. In *ICRA*, 2025.
- [14] C. Wang, L. Fan, J. Sun, R. Zhang, L. Fei-Fei, D. Xu, Y. Zhu, and A. Anandkumar. Mimicplay: Long-horizon imitation learning by watching human play. In *CoRL*, 2023. *arXiv:2302.12422*.
- [15] H. Bharadhwaj, A. Gupta, S. Tulsiani, and V. Kumar. Zero-shot robot manipulation from passive human videos. *arXiv preprint arXiv:2302.02011*, 2023.
- [16] V. Jain, M. Attarian, N. J. Joshi, A. Wahid, D. Driess, Q. Vuong, P. R. Sanketi, P. Sermanet, S. Welker, C. Chan, I. Gilitschenski, Y. Bisk, and D. Dwibedi. Vid2robot: End-to-end video-conditioned policy learning with cross-attention transformers. *arXiv preprint arXiv:2403.12943*, 2024.
- [17] H. Bharadhwaj, D. Dwibedi, A. Gupta, S. Tulsiani, C. Doersch, T. Xiao, D. Shah, F. Xia, D. Sadigh, and S. Kirmani. Gen2act: Human video generation in novel scenarios enables generalizable robot manipulation. *arXiv preprint arXiv:2409.16283*, 2024.
- [18] R. Shah, S. Liu, Q. Wang, Z. Jiang, S. Kumar, M. Seo, R. Martín-Martín, and Y. Zhu. Mimicdroid: In-context learning for humanoid robot manipulation from human play videos. *arXiv preprint arXiv:2509.09769*, 2025.

- [19] X. Chi, C.-K. Fan, H. Zhang, X. Qi, R. Zhang, A. Chen, C.-m. Chan, W. Xue, Q. Liu, S. Zhang, et al. Eva: An embodied world model for future video anticipation. *arXiv preprint arXiv:2410.15461*, 2024.
- [20] X. Chi, P. Jia, C.-K. Fan, X. Ju, W. Mi, K. Zhang, Z. Qin, W. Tian, K. Ge, H. Li, et al. Wow: Towards a world omniscient world model through embodied interaction. *arXiv preprint arXiv:2509.22642*, 2025.
- [21] J. Zhang, X. Chen, A.-J. Chen, C. Lv, D. mei Li, G. Zhou, H. Yin, H. Yuan, H. Li, J. Li, J. Zhang, J. Zhou, K. Gao, K. Yan, L. Jiang, N. Tang, P. Lin, Q. Peng, S.-S. Yin, T. Wu, T. Yan, X. Xu, Y. Shu, Y. Zhang, Y. Wang, Y. Wang, Y. Chen, Y. Xu, Y. Huang, Y. Chen, Z. Zhang, Z. Wang, Z. Lei, Z. Liang, Z. Liu, Z. Zhou, X. hui Chen, and C. Wu. Qwen-robotworld technical report: Unifying embodied world modeling through language-conditioned video generation. 2026. URL <https://api.semanticscholar.org/CorpusID:289301463>.
- [22] C. Zhu, R. Yu, S. Feng, B. Burchfiel, P. Shah, and A. Gupta. Unified world models: Coupling video and action diffusion for pretraining on large robotic datasets. *arXiv preprint arXiv:2504.02792*, 2025.
- [23] J. Lyu, K. Liu, X. Zhang, H. Liao, Y. Feng, W. Zhu, T. Shen, J. Chen, J. Zhang, Y. Dong, W. Cui, S. Qi, S. Wang, Y. Zheng, M. Yan, X. Shi, H. Li, D. Zhao, M.-Y. Liu, Z. Zhang, L. Yi, Y. Wang, and H. Wang. LDA-1B: Scaling latent dynamics action model via universal embodied data ingestion. *arXiv preprint arXiv:2602.12215*, 2026.
- [24] H. Bi, H. Tan, S. Xie, Z. Wang, S. Huang, H. Liu, R. Zhao, Y. Feng, C. Xiang, Y. Rong, et al. Motus: A unified latent action world model. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 35101–35113, 2026.
- [25] M. Team, C. Xiang, F. Bao, H. Liu, H. Tan, H. Bi, J. Li, J. Liu, J. Pang, K. Jing, et al. Motubrain: An advanced world action model for robot control. *arXiv preprint arXiv:2604.27792*, 2026.
- [26] Y. Zhang, W. Zhang, Z. Qi, H. Zhang, H. Lin, J. Zhang, Y. Mu, X. Yang, W. Zeng, and X. Jin. Imagewam: Do world action models really need video generation, or just image editing?, 2026. URL <https://arxiv.org/abs/2606.19531>.
- [27] H. Yu, H. Lin, J. Zhang, W. Zhang, C. Gu, H. Li, and P. Tan. Maskwam: Unifying mask prompting and prediction for world-action models. *arXiv preprint arXiv:2606.13515*, 2026.
- [28] B. Peng, W. Zhang, L. Xu, Z. Qi, J. Zhang, H. Liu, W. Zeng, and X. Jin. Reworld: Multi-dimensional reward modeling for embodied world models. *arXiv preprint arXiv:2601.12428*, 2026.
- [29] S. Ye, Y. Ge, K. Zheng, S. Gao, S. Yu, G. Kurian, S. Indupuru, Y. L. Tan, C. Zhu, J. Xiang, A. Malik, K. Lee, W. Liang, N. Ranawaka, J. Gu, Y. Xu, G. Wang, F. Hu, A. Narayan, J. Bjorck, J. Wang, G. Kim, D. Niu, R. Zheng, Y. Xie, J. Wu, Q. Wang, R. Julian, D. Xu, Y. Du, Y. Chebotar, S. Reed, J. Kautz, Y. Zhu, L. J. Fan, and J. Jang. World action models are zero-shot policies, 2026. URL <https://arxiv.org/abs/2602.15922>.
- [30] A. Ye, B. Wang, C. Ni, G. Huang, G. Zhao, H. Li, H. Li, J. Li, J. Lv, J. Liu, M. Cao, P. Li, Q. Deng, W. Mei, X. Wang, X. Chen, X. Zhou, Y. Wang, Y. Chang, Y. Li, Y. Zhou, Y. Ye, Z. Liu, and Z. Zhu. Gigaworld-policy: An efficient action-centered world-action model. *arXiv preprint arXiv:2603.17240*, 2026.
- [31] L. Li, Q. Zhang, Y. Luo, S. Yang, R. Wang, F. Han, M. Yu, Z. Gao, N. Xue, X. Zhu, Y. Shen, and Y. Xu. Causal world modeling for robot control. *arXiv preprint arXiv:2601.21998*, 2026.

- [32] T. Yuan, Z. Dong, Y. Liu, and H. Zhao. Fast-wam: Do world action models need test-time future imagination? *arXiv preprint arXiv:2603.16666*, 2026. URL <https://arxiv.org/abs/2603.16666>.
- [33] J. Cai, L. Ling, S. Chu, Z. Liu, J. Kang, Z. Liang, W. Xu, Y. Mao, W. Zhang, X. Yang, R. Ying, R. Zheng, and Y. Mu. Aha-wam: Asynchronous horizon-adaptive world-action modeling with observation-guided context routing. *arXiv preprint arXiv:2606.09811*, 2026.
- [34] Q. Feng, J. Yu, J. Liu, Y. Jia, Z. Wu, H. Chen, Z. Qian, S. Gu, P. Jia, S. Ma, and S. Zhang. Harmowam: Harmonizing generalizable and precise manipulation via adaptive world action models, 2026.
- [35] H. Luo, W. Zhang, Y. Feng, S. Zheng, H. Xu, C. Xu, Z. Xi, Y. Fu, and Z. Lu. Being-h0. 7: A latent world-action model from egocentric videos. *arXiv preprint arXiv:2605.00078*, 2026.
- [36] J. Guo, Q. Li, P. Li, Z. Chen, N. Sun, Y. Su, H. Wang, Y. Zhang, X. Li, and H. Liu. Unified 4d world action modeling from video priors with asynchronous denoising. *arXiv preprint arXiv:2604.26694*, 2026.
- [37] J. Lyu, Z. Li, X. Shi, C. Xu, Y. Wang, and H. Wang. Dywa: Dynamics-adaptive world action model for generalizable non-prehensile manipulation. *arXiv preprint arXiv:2503.16806*, 2025.
- [38] N. Agarwal, A. Ali, J. Allen, M. Antolini, A. Aubame, A. Azzolini, J. Bai, M. Bala, Y. Balaji, J. Bapst, et al. Cosmos 3: Omnimodal world models for physical ai. *arXiv preprint arXiv:2606.02800*, 2026.
- [39] T. Ma, J. Zheng, Z. Wang, C. Jiang, A. Cui, J. Liang, and S. Yang. Dit4dit: Jointly modeling video dynamics and actions for generalizable robot control. *arXiv preprint arXiv:2603.10448*, 2026.
- [40] Physical Intelligence, B. Ai, A. Amin, R. J. Aniceto, A. Balakrishna, G. Balke, K. Black, G. Bokinsky, S. Cao, T. Charbonnier, et al. $\pi_0.7$: A steerable generalist robotic foundation model with emergent capabilities. *arXiv preprint arXiv:2604.15483*, 2026.
- [41] Y. Liu et al. Oa-wam: Object-addressable world action model for robust robot manipulation. 2026.
- [42] Y. Yang, S. Zeng, T. Lin, X. Chang, D. Qi, J. Xiao, H. Liu, R. Chen, Y. Chen, D. Huo, et al. Abot-m0: V1a foundation model for robotic manipulation with action manifold learning. *arXiv preprint arXiv:2602.11236*, 2026.
- [43] R. Chen, Y. Yang, Z. Tang, D. Huo, T. Lin, H. Wu, H. Liu, Y. Chen, L. Zheng, B. Yuan, T. Li, M. Wang, D. Qi, B. Hu, W. Mei, Y. Xuan, H. Yang, Y. Zhu, M. Xu, Z. Ma, and X. Chang. Abot-m0.5: Unified mobility-and-manipulation world action model. *arXiv preprint arXiv:2607.00678*, 2026.
- [44] M. J. Kim, Y. Gao, T.-Y. Lin, Y.-C. Lin, Y. Ge, G. Lam, P. Liang, S. Song, M.-Y. Liu, C. Finn, and J. Gu. Cosmos policy: Fine-tuning video models for visuomotor control and planning. In *International Conference on Learning Representations (ICLR)*, 2026.
- [45] Y. Hu, Y. Guo, P. Wang, X. Chen, Y.-J. Wang, J. Zhang, K. Sreenath, C. Lu, and J. Chen. Video prediction policy: A generalist robot policy with predictive visual representations. *arXiv preprint arXiv:2412.14803*, 2024.
- [46] Y. Sun, X. Wang, Z. Liu, J. Miller, A. A. Efros, and M. Hardt. Test-time training with self-supervision for generalization under distribution shifts. In *ICML*, 2020.
- [47] D. Wang, E. Shelhamer, S. Liu, B. Olshausen, and T. Darrell. Tent: Fully test-time adaptation by entropy minimization. In *ICLR*, 2021.

- [48] Y. Liu, P. Kothari, B. van Delft, B. Bellot-Gurlet, T. Mordan, and A. Alahi. Ttt++: When does self-supervised test-time training fail or thrive? In *NeurIPS*, 2021.
- [49] Y. Gandelsman, Y. Sun, X. Chen, and A. A. Efros. Test-time training with masked autoencoders. In *NeurIPS*, 2022.
- [50] Y. Sun, X. Li, K. Dalal, J. Xu, A. Vikram, G. Zhang, Y. Dubois, X. Chen, X. Wang, S. Koyejo, T. Hashimoto, and C. Guestrin. Learning to (learn at test time): Rnns with expressive hidden states. In *ICML*, 2025.
- [51] A. Behrouz, P. Zhong, and V. Mirrokni. Titans: Learning to memorize at test time. *arXiv preprint arXiv:2501.00663*, 2025.
- [52] F. Liu, D. Wu, J. Chi, Y. Cai, Y.-H. Hung, X. Yu, H. Li, H. Hu, Y. Rao, and Y. Duan. Spatial-ttt: Streaming visual-based spatial intelligence with test-time training. *arXiv preprint arXiv:2603.12255*, 2026.
- [53] S. Yang, Y. Ze, and H. Xu. Movie: Visual model-based policy adaptation for view generalization. In *NeurIPS*, 2023.
- [54] Z. Bai, C. Gao, and M. Z. Shou. Evolve-vla: Test-time training from environment feedback for vision-language-action models. *arXiv preprint arXiv:2512.14666*, 2025.
- [55] C. Liu, Y. Liu, T. Wang, Q. Zhuang, J. C. Liang, W. Yang, R. Xu, Q. Wang, D. Liu, and C. Han. On-the-fly vla adaptation via test-time reinforcement learning. *arXiv preprint arXiv:2601.06748*, 2026.
- [56] K. Black, N. Brown, D. Driess, A. Esmail, M. Equi, C. Finn, N. Fusai, L. Groom, K. Hausman, B. Ichter, S. Jakubczak, T. Jones, L. Ke, S. Levine, A. Li-Bell, M. Mothukuri, S. Nair, K. Pertsch, L. X. Shi, L. Smith, J. T. Springenberg, K. Stachowicz, J. Tanner, Q. Vuong, H. Walke, A. Walling, H. Wang, L. Yu, and U. Zhilinsky. $\pi_{0.5}$: a vision-language-action model with open-world generalization. *arXiv preprint arXiv:2504.16054*, 2025.
- [57] J. Mu, S. Yang, Y. Bao, H. Bae, T. Wei, L. Xu, B. Li, H. Xu, and J. Pang. Deximit: Learning bimanual dexterous manipulation from monocular human videos. *arXiv preprint arXiv:2602.10105*, 2026.
- [58] A. Katharopoulos, A. Vyas, N. Pappas, and F. Fleuret. Transformers are RNNs: Fast autoregressive transformers with linear attention. In *International Conference on Machine Learning (ICML)*, 2020.
- [59] C. Lugaresi, J. Tang, H. Nash, C. McClanahan, E. Uboweja, M. Hays, F. Zhang, C.-L. Chang, M. G. Yong, J. Lee, W.-T. Chang, W. Hua, M. Georg, and M. Grundmann. MediaPipe: A framework for building perception pipelines. *arXiv preprint arXiv:1906.08172*, 2019.
- [60] J. Romero, D. Tzionas, and M. J. Black. Embodied hands: Modeling and capturing hands and bodies together. In *ACM Transactions on Graphics (SIGGRAPH Asia)*, 2017.
- [61] O. Siméoni, H. V. Vo, M. Seitzer, F. Baldassarre, M. Oquab, C. Jose, V. Khalidov, M. Szafraniec, S. Yi, M. Ramamonjisoa, F. Massa, D. Haziza, L. Wehrstedt, J. Wang, T. Darcet, T. Moutakanni, L. Sentana, C. Roberts, A. Vedaldi, J. Tolan, J. Brandt, C. Couprie, J. Mairal, H. Jégou, P. Labatut, and P. Bojanowski. DINOv3. *arXiv preprint arXiv:2508.10104*, 2025.

元训练算法

符号说明：快权重与慢权重。全文以 $W_{\text{init}}^{(\ell)}$ 表示第 ℓ 层快权重多层感知机的可学习初始化，该参数由外层优化器训练，属于慢参数；投影 $\theta^{(\ell)}$ 、 $\{K, V, Q, O\}$ 以及权重调整模块参数 Θ_{WAM} 同样为慢参数。符号 $W_i^{(\ell)}$ 、 i （其中 $W_0^{(\ell)}$ 、 $\equiv$ 、 $W_{\text{init}}^{(\ell)}$ ）表示第 ℓ 层在内层迭代 i 时的快权重。按照时空测试时训练术语，“快”指更新发生在单次前向传播内通过内层随机梯度下降进行 [52]； $W^{(\ell)}$ 、 i 次更新 N ，而 $W_{\text{init}}^{(\ell)}$ 及慢投影仅在外层优化器每步更新一次（部署时冻结）。

符号说明：令牌流。本文以 $z^{(\ell)}$ 表示潜在扩散适配器块 ℓ 输入处的视频潜在令牌，以 $x^{(\ell)}$ 表示机器人动作令牌。这两条流由潜在扩散适配器的视频专家与动作专家通过跨流注意力（第 3.1 节）联合处理。带帽符号 $\hat{z}^{(\ell+1)}$ 与 $\hat{x}^{(\ell+1)}$ 表示该块在加入任何测试时训练残差之前的固有输出；不带帽的 $z^{(\ell+1)}$ 、 $x^{(\ell+1)}$ 为实际馈入块 $\ell+1$ 的内容，在视频流上等于 $\hat{z}^{(\ell+1)} + \Delta z_{\text{TTT}}^{(\ell)}$ ，在动作流上等于 $\hat{x}^{(\ell+1)}$ （式 1）。测试时训练残差仅修改视频流，动作专家的输出保持不变；这将测试时人类视频自适应完全置于视频侧，即无动作人类视频能够自然提供监督的模式。

符号说明：外层机器人多任务损失 $\mathcal{L}^{\text{robot}}_{\text{WAM}}$ 。本文以 $\mathcal{L}^{\text{robot}}_{\text{WAM}}$ 作为权重调整模块标准多任务训练损失在配对机器人侧的简写。该损失为继承自潜在扩散适配器骨干 [23] 的两个扩散目标之和：视频专家输出的机器人视频潜在 $\{z^{(\ell)}\}$ 上的视频侧流匹配/扩散去噪损失，以及动作专家输出的机器人动作块 $\{x^{(\ell)}\}$ 上的动作侧流匹配/扩散去噪损失。本文采用潜在扩散适配器的精确损失公式、权重与噪声调度，未作修改；权重调整模块测试时训练在此外层层面的唯一贡献是测试时训练残差，该残差将视频流上的 $\hat{z}^{(\ell+1)}$ 偏移为 $z^{(\ell+1)}$ ，随后与两个扩散目标一同反向传播。

运行时目标：从机器人查询到人类键/值的交叉注意力。在部署阶段，我们希望每个 TTT 层执行的操作在概念上很简单：让机器人令牌流 z_r 通过标准注意力接口从场景内人类令牌流 h 读取信息。令 $q = \theta_Q(z_r)$ ， $k_i = \theta_K(h_i)$ ， $v_i = \theta_V(h_i)$ 收集一个查询以及每个人类侧键/值的逐令牌投影，经典的 Softmax 交叉注意力定义了所需的读出结果。

$$\text{Out}(q) = \sum_{i=1}^{L_h} \frac{\exp(q^\top k_i)}{\sum_j \exp(q^\top k_j)} v_i. \quad (\text{A.1})$$

若按字面执行此操作，则需要物化完整的 (K_h, V_h) 缓存，其长度随人类片段令牌数量扩展，并且在每个测试时梯度步骤中重新更新该缓存十分不便。

参数化替代方案：一个返回“最接近键的值”的多层感知机。TTT 层不携带显式缓存，而是将人类侧信息存储在快速权重多层感知机 f_W 的权重 W 中。运行时读出即为公式 2 已给出的参数化表达式，即 $\Delta z_{\text{TTT}} = \theta_O f_W(\theta_Q(z_r))$ ，其中慢速 θ_O 将 f_W 的 d 维输出投影回 LDA 隐藏维度，以便残差可加到 $\hat{z}^{(\ell+1)}$ 上。关于这种基于多层感知机的读出行为类似于交叉注意力的说法，纯粹是关于权重 W 的论断：在 q 处查询 f_W 必须返回与存储集中最类似于 q 的键相关联的值。

是什么使得 f_W 表现得像注意力：线性注意力见证。部署的 f_W 是一个小型非线性多层感知机，但线性特例 $f_W(x) = Wx$ （其中 $W \in \mathbb{R}^{d \times d}$ ）已经是一个可处理的见证，表明最小化键值记忆重建损失 $\mathcal{L}_{\text{KVM}}$ 对权重的影响，而非线性多层感知机则是同一检索模式的平滑、归一化类比。将人类键堆叠

以及来自同步帧的值，按照上文符号段落中的行令牌约定表示为 $\mathbf{K}_h, \mathbf{V}_h \in \mathbb{R}^{L_h \times d}$ ；公式 3 中的分母 $BL_h d$ 使 $\mathcal{L}_{\text{KVM}}$ 成为逐元素均方误差，该误差对迷你批大小、人类序列长度和嵌入维度均不变，也是本文分析的形式。最小化线性情况损失具有闭式解

$$\min_{W \in \mathbb{R}^{d \times d}} \frac{1}{BL_h d} \|\mathbf{K}_h W^\top - \mathbf{V}_h\|_F^2 \implies W^* = \mathbf{V}_h^\top \mathbf{K}_h (\mathbf{K}_h^\top \mathbf{K}_h)^{-1}. \quad (\text{A.2})$$

在标准线性注意力/现代霍普菲尔德各向同性假设 $\mathbf{K}_h^\top \mathbf{K}_h \approx (L_h/d) \mathbf{I}_d$ ，下（该假设适用于白化或随机投影式特征，此处仅作为合理性检验而非严格建模假设），该解坍塌为赫布型/外积

memory

$$W^* \propto \mathbf{V}_h^\top \mathbf{K}_h = \sum_{i=1}^{L_h} \mathbf{v}_i \mathbf{k}_i^\top. \quad (\text{A.3})$$

随后利用机器人侧 $\mathbf{Q}_r = \theta_Q(\mathbf{z}_r)$ 进行查询，得到

$$f_{W^*}(\mathbf{Q}_r) = W^* \mathbf{Q}_r \propto \sum_{i=1}^{L_h} (\mathbf{k}_i^\top \mathbf{Q}_r) \mathbf{v}_i, \quad (\text{A.4})$$

这恰好是一个无核函数、无 Softmax 函数的线性注意力读出，针对 $(\mathbf{K}_h, \mathbf{V}_h)$ [58]。换言之， $\mathcal{L}_{\text{KVM}}$ 并非交叉注意力行为之外的辅助正则项；在线性情形下，它正是该行为的变分定义。方程 (A.2) – (A.4) 仅在此线性特例中作为精确等式成立；我们实际部署的非线性多层感知机遵循相同的训练目标 $f_W(\mathbf{K}_h) \approx \mathbf{V}_h$ ，但闭式 $W^* \mathbf{Q}_r = \sum_i (\mathbf{k}_i^\top \mathbf{Q}_r) \mathbf{v}_i$ 分解被多层感知机平滑的、学习得到的类注意力读出所取代，其中该层的非线性与归一化扮演了 Softmax 核函数的角色。残差 $\theta_O f_W(\mathbf{Q}_r)$ 随后将由由此产生的人类衍生值注入方程 1 的视频流中。

为何内层循环将快速权重驱动至该见证者。内层随机梯度下降步骤（式 5）直接最小化 $\mathcal{L}_{\text{KVM}}$ 与人类视频预测损失并行 $\mathcal{L}_{\text{vg}}^{\text{human}}$ ，因此快速权重的每次内层更新 W 从构造上就是朝向 W' 上述线性注意力见证适用的方向迈出的梯度步。外层循环仅优化慢参数 $\Theta_{\text{WAM}, \theta_{\{K, V, Q, O\}}}$ ，以及 W_{init} 通过机器人多任务损失 $\mathcal{L}_{\text{WAM}}^{\text{robot}}$ (Eq. 6)，并通过反向传播穿过空间测试时训练 (Spatial-TTT) 的解析可微内层更新来实现。[52] 因此，在“在人类视频预测上表现良好”与“编码人类键值记忆”之间不存在间接性：两者同时且明确地构成塑造内循环信号的一部分 W 。

为何见证者在部署时得以保留。测试时内层循环（方程 8）优化与元训练相同的组合目标形式：人类视频预测加上逐层键值记忆重建。由于 $\mathbf{K}_h^{(\ell)} = \theta_K^{(\ell)}(\mathbf{h}_\phi^{(\ell)})$ 与 $\mathbf{V}_h^{(\ell)} = \theta_V^{(\ell)}(\mathbf{h}_\phi^{(\ell)})$ 可仅从无动作的人类视频中导出，部署时评估任一项均无需机器人侧监督。因此，在元训练期间产生线性注意力见证者的同一内层随机梯度下降（方程 (A.2) – (A.4)），在部署时针对 $\mathcal{B}_h$ 继续产生该见证者，且残差 $\theta_O f_W(\theta_Q(\mathbf{z}_r))$ 仍为元训练阶段所承诺的人类键/值交叉注意力读出。

算法。下述算法 A.1 实现一个元训练步骤。阶段 (ii)，即测试时测试时训练（第 3.3 节），使用相同的逐块前向传播与相同的组合内层循环目标形式，但冻结 WAM、测试时训练慢投影以及 W_{init} ，仅快速权重 W 通过方程 8 进行自适应。

B 超参数与数据集

超参数。见表 B.1。

Algorithm A.1: One meta-training step on a paired robot-human batch.

Input: Paired batch $\mathcal{B}$ of robot trajectories with action-free human videos; LDA-based

WAM [23] with L diffusion transformer blocks; TTT slow projections $\theta_{\{K,V,Q,O\}}^{(\ell)}$;

fast-weight initializations $W_{\text{init}}^{(\ell)}$; inner iterations N , inner LR η ; memory reconstruction weight λ .

// 1. phase-aligned human-robot sync (Section 3.2)

For each robot timestep t , pick the nearest-phase human frame $\mathbf{h}_\phi$;

// 2. inner adaptation: N full-network SGD steps on the combined human-side objective

$W^{(\ell)} \leftarrow W_{\text{init}}^{(\ell)}$ for all ℓ ;

for $i = 1, \dots, N$ **do**

对 $\mathbf{u}^h$ 执行完整 WAM 前向, 使用当前 $\{W^{(\ell)}\}$ 和 TTT 残差 (式 2); 在同步人体帧上计算逐层 $\mathcal{L}_{\text{KVM}}^{(\ell)}$ (式 3); 组装内循环损失 $\mathcal{L}_{\text{adapt}} = \mathcal{L}_{\text{vg}}^{\text{human}} + \lambda \sum_{\ell} \mathcal{L}_{\text{KVM}}^{(\ell)}$; 按式 5 反向传播并同时更新所有层; // 3. 机器人前向, 使用自适应 W_N 进行 $\ell = 1, \dots, L$ **do** LDA 块前向得到 $(\hat{\mathbf{z}}^{(\ell+1)}, \hat{\mathbf{x}}^{(\ell+1)})$; 按式 2 和式 1 对视频流应用 TTT 残差; // 4. 外循环损失与反向传播计算 $\mathcal{L}_{\text{meta}} = \mathcal{L}_{\text{WAM}}^{\text{robot}}$ (Eq. 6); 通过解析内更新 [52] 反向传播至 WAM、 $\theta_{\{K,V,Q,O\}}$ 和 W_{init} ; 优化器步进;

|

表 B.1: 主要 WAM-TTT 运行的超参数。

Setting	Value
WAM backbone	LDA [23] (Qwen3-VL-4B-Instruct VLM + DiT-L MMDiT action head)
MMDiT blocks L / hidden dim D / heads H	16 / 1536 / 32
TTT head dim d / fast-weight hidden width f_h	48 / 128
Inner SGD iterations N (meta-training and test-time)	1
Inner LR η at meta-training	0.1
Inner LR η at test time	0.01
Memory reconstruction weight λ	4×10^{-2}
Outer optimizer	AdamW ($\beta_1 = 0.9, \beta_2 = 0.999$), weight decay 10^{-8}
Outer LR (DiT action head / VLM interface)	$1 \times 10^{-4} / 1 \times 10^{-5}$
LR schedule	cosine with min 5×10^{-7} , 5 k-step warmup
Meta-training steps	100 k
Batch size (per device / global)	16 / 128
GPUs	8 $\times$ NVIDIA H800, DeepSpeed ZeRO-2

实施例与数据集。 三种机器人实体。宇树 G1 (人形双臂, 三指灵巧手) 覆盖收桌、倒水和递饮料。Galbot 夹爪 (双臂两指) 覆盖转移瓶子和盖章。Galbot sharpia (双臂灵巧, 每侧 22 自由度, 总计 58 维) 覆盖换位、金字塔堆叠、翻牛排以及长程多步牛排任务。在三种实体上, 我们共采集了 2,286 对机器人-人类配对数据, 涵盖这 9 个操作任务: 宇树 G1 上 600 对, Galbot 夹爪上 544 对, Galbot sharpia 上 1,142 对。机器人数据通过遥操作在标准化隔间内采集 (图 B.1), 而配对的人类演示则使用 GoPro 相机以第一人称视角直接在实际家庭环境中录制, 这些环境随后作为新场景进行评估 (图 B.2), 且不包含任何手部姿态、关节角度或动作重定向标注。两种视角通过相位对齐 (第 3.2 节) 进行配对以用于元训练, 人类侧数据在部署场景中重新录制用于测试。

时间 TTT（第 3.3 节）。每幅图使用相同的 5×2 网格（从左到右、从上到下阅读），其中多步牛排占据两个面板（面板 8 和 10），因此 9 个任务填满 10 个单元格的布局。




图 B.1: 标准化隔间中的机器人数据采集。 5×2 布局中的代表性遥操作帧，按从左到右、从上到下的顺序阅读。顶行：（1）桌面清理，（2）倒水，（3）在字树 G1 上递送饮料；（4）在 Galbot sharp 上交换位置；（5）在 Galbot 夹爪上转移瓶子。底行：（6）在 Galbot 夹爪上盖章；（7）金字塔堆叠，（8）多步骤牛排（抓取平底锅并倒入牛肉），（9）翻转牛排，（10）多步骤牛排（撒胡椒），均在 Galbot sharp 上完成。长时程的多步骤牛排任务占据第 8 和第 10 面板。




图 B.2: 实际新家庭场景中的人类数据采集。与图 B.1 相同的 10 个任务槽和面板顺序，但人类演示者位于用作新评估设置的实际家庭环境中（光照、杂乱程度、餐具和目标实例均与隔间不同）。手部姿势根据配对的机器人末端执行器在每个面板中有所不同：在 Galbot 夹爪面板（5，6）上使用平行夹爪模仿，在字树 G1 面板（1–3）上使用三指灵巧手抓取，在 Galbot sharp 面板（4，7–10）上使用无约束的灵巧操作。任务标识和面板顺序与图 B.1 相同。演示使用 GoPro 相机以第一人称视角录制，没有任何手部姿势、关节角度或运动重定向标注。

C 完整主要结果：原始设置和新设置

表 C.1 是主论文结果表（第 4.2 节中的表 1）的完整版本，包括 9 个操作任务中每个任务在隔间内的原始设置和未见过的家庭新设置。新设置部分已提升至主论文；原始设置部分在此提供以保证完整性，使读者能够验证每个基线在家庭场景扰动下的退化情况。

分析：原始（标准化隔间）结果。在原始设置下（表 C.1 中每个区块的顶行），WAM-TTT 以 **61.1%** 领先，而无 TTT 的 LDA 骨干为 50.2%（**+10.9** 个百分点），WAM-ICL 为 48.4%（**+12.7** 个百分点）， $\pi_{0.5}$ **(+29.3)** 为 31.8%（个百分点），EGOSCALE 为 30.1%（**+31.0** 个百分点），WAM-COTRAIN 为 29.8%（**+31.3** 个百分点）。值得注意的是，WAM-COTRAIN 将对人类数据混入 WAM 多任务外部损失中，但未采用本文的 TTT 机制，其性能降至无人 $\pi_{0.5}$ 和 EGOSCALE 基线以下：仅用人类数据稀释机器人监督，而缺乏明确的人机对齐机制，会主动损害分布内性能。相比之下，WAM-TTT 将人类数据吸收到快速权重记忆中，不会干扰无关机器人轨迹的策略流，因此在相同的标准化设置下，严格优于 WAM 骨干网络。

表 C.1：完整主要结果。在原始（标准化机器人隔间）和新（未见家庭环境，组合分布外偏移）设置下，9 个任务的进度（%）。所有单元格为 25 次试验的平均值。

Method	Setting	Transfer Bottle	Table Bussing	Deliver Drink	Swap Place	Pour Water	Stamp Paper	Flip Steak	Pyramid Stacking	Multi-step Steak	Avg.
$\pi_{0.5}$	Orig.	55.5	80.0	70.0	12.2	25.0	31.1	4.4	6.1	2.0	31.8
	New	33.4	36.0	15.0	7.4	10.0	24.4	2.0	4.7	0.3	14.8
LDA	Orig.	72.0	90.0	80.0	66.7	33.6	50.0	33.3	6.7	19.2	50.2
	New	56.0	70.0	55.0	44.4	20.0	33.3	10.0	0.6	3.0	32.5
EGOSCALE	Orig.	69.4	80.0	69.6	10.0	30.0	2.7	5.0	2.0	2.0	30.1
	New	34.4	44.0	33.3	6.0	7.5	1.1	5.0	2.0	2.0	15.0
WAM-COTRAIN	Orig.	11.6	40.0	59.4	74.1	26.3	10.0	21.0	9.4	16.8	29.8
	New	10.0	10.0	44.3	48.1	24.0	21.7	34.2	12.0	23.8	25.3
WAM-ICL	Orig.	60.0	89.0	70.3	68.7	55.3	36.0	33.3	4.7	18.2	48.4
	New	10.0	10.0	14.2	10.0	0.0	5.0	10.0	2.0	2.5	7.1
WAM-TTT	Orig.	77.8	100.0	90.0	88.9	63.3	35.0	44.0	10.0	40.6	61.1
	New	55.6	100.0	66.7	66.7	30.0	8.3	34.3	10.4	43.8	46.2

Analysis: *Orig.* $\rightarrow$ *New* transfer of human-data benefits. The summary table below is computed directly from Table C.1: the *Orig.* and *New* columns are the per-method 9-task averages (the **Avg** column of Table C.1, one number per row of each *Orig./New* block), and the retention ratio New/Orig and the gap $\Delta = \text{Avg}_{\text{Orig}} - \text{Avg}_{\text{New}}$ are derived from those two averages. The retention ratio thus measures how well each method’s average standardized-cubicle competence survives the unseen-household perturbation, and Δ reports the average per-task progress lost in absolute points:

Method	Orig.	New	New/Orig	Δ (Orig – New)
WAM-TTT (WAM-TTT)	61.1	46.2	0.76	–14.9
WAM-COTRAIN	29.8	25.3	0.85	–4.5
LDA	50.2	32.5	0.65	–17.7
EGOSCALE	30.1	15.0	0.50	–15.1
$\pi_{0.5}$	31.8	14.8	0.47	–17.0
WAM-ICL	48.4	7.1	0.15	–41.3

WAM-ICL 的灾难性崩溃（保留率 15%，–41.3 分）表明，将人类视频作为上下文令牌输入在场景扰动下是脆弱的：在分布内有益的相同长上下文条件在视觉统计变化时成为负担。WAM-COTRAIN 的高保留率（85%）在很大程度上是人为的，因为其起点已经很弱（29.8）；从绝对值来看，它在新设置上仍是仅次于 WAM-ICL 的第二差方法。WAM-TTT 结合了最高的原始性能（61.1%）和最高的有意义保留率（76%），即使部署场景偏离训练隔间，也能保留大部分人类数据带来的益处。

总结：人类数据方法之间的形式比较。在将对人类演示数据注入世界行动模型（WAM）的三种形式中，只有 WAM-TTT 实现了强分布内准确率与稳健的分布外迁移的双重目标：（i）直接多任务协同训练（WAM-COTRAIN）牺牲了分布内策略质量（原始得分最低），且仅带来有限的新任务增益；（ii）上下文条件化（WAM-ICL）达到了合理的原始性能，但在家庭场景偏移下性能崩溃；（iii）WAM-TTT 的快速权重 TTT 记忆仅沿人类派生的任务证据调整 WAM，保持 LDA 骨干预训练的视觉推理完好，因此人类数据信号在分布外偏移下得以保留。这是有用的人类数据注入记忆的经验特征：在不覆盖 WAM 可迁移结构的前提下进行任务特定适应。

D 每任务进度定义

我们列出了用于计算表 1 和表 C.1 中报告的进度（%）的每任务子目标分解。遵循近期视觉-语言-动作（VLA）评估中的加性评分惯例（例如，[10]），每个任务被分解为一小组预定义的里程碑，其权重之和为 1.0；一次试验的进度得分是所达到的里程碑权重之和，其中 1.0 保留给满足最终目标的试验。以下权重直接取自我们的生产评估准则，并根据机器人末端执行器位姿和回放过程中捕获的已知场景物体位姿自动评分。进度在每（任务，设置）单元的 25 次试验上取平均。

每任务权重的设计理由。在每个任务中，我们有意将大部分权重集中在少数几个关键里程碑上，这些里程碑的完成意味着任务成功——例如，在盖章任务中盖章成功（+0.50），在倒水任务中倒水成功（+0.60），在翻牛排任务中翻面成功（+0.45），在金字塔堆叠任务中成功放置第三个杯子（+0.36）。这使得度量主要奖励完成任务，符合读者对操作基准的二值成功率解释的预期。然后，我们为较容易的初步步骤（如在抓取前向物体移动）分配较小的分数权重。这些较小的权重从完成早期阶段但后续停滞的低质量试验中提取有用信号，我们发现这对行为克隆训练和下游强化学习微调都有信息价值。

转移瓶子。指令：“将瓶子从左臂递到右臂，并将其放入接收箱中。”累加评分标准：

- +0.05：左手伸向瓶子。• +0.10：左手成功抓取瓶子。•
- +0.05：右手伸向以接收瓶子。• +0.15：右手成功抓取瓶子。• +0.10：左手松开瓶子。• +0.05：右手伸向以放置瓶子。• +0.50：右手成功将瓶子放入箱中。

表 搬运。指令：“将餐具从桌上清理到垃圾桶中。”累加评分标准，每次试验有 N 个物品（默认 $N=1$ ）:

- 每个物品 +0.5/ N ：从桌上抓取物品。•每个物品 +0.5/ N ：将物品释放到垃圾桶中。

递送饮料。指令：“拿起饮料并递到指定位置。”累加评分标准：

- +0.30：抓取饮料（杯子或瓶子）。•
- +0.30：将饮料运向接收者。• +0.40：在接收者处放置或释放饮料。

交换位置。指令：“将物体从左手递到右手，然后将其放置在指定位置。”累加评分标准：

- +0.20：抓取物体 A。• +0.30：将物体 A 暂存于缓冲位置。• +0.30：抓取物体 B 并放置于 A 的原位置。• +0.20：将物体 A 放置于 B 的原位置。

倒水。指令：“将水从瓶子倒入杯子。”累加评分标准：

- +0.10 : 成功抓取杯子。• +0.15 : 成功抓取瓶子。• +0.05 : 达到倒水姿势。• +0.60 : 倒水成功。• +0.10 : 成功放回瓶子。

盖章。指令：“在涂上印泥后，在标记位置盖章。”累加评分标准：

- +0.05 : 伸手去拿印章。• +0.15 : 印章成功抓取。• +0.05 : 伸手去蘸印泥。• +0.20 : 印泥成功蘸取。• +0.05 : 伸手去盖纸。• +0.50 : 盖章成功。

翻煎牛排。指令：“用夹子把平底锅里的牛排翻面。”累加评分标准：

- +0.02 : 伸手去拿夹子。• +0.20 : 夹子成功抓取。• +0.03 : 靠近牛排。• +0.20 : 牛排成功夹住。• +0.45 : 翻面成功。• +0.10 : 夹子成功放下。

金字塔叠杯。指令：“将六个杯子叠成三层金字塔（底层三个杯子，中层两个，顶层一个）。”累加评分标准（以下每个“第 1/2/3 个杯子”条目跟踪该层的层定义放置）：

- +0.01 : 伸手去拿第 1 个杯子。• +0.05 : 第 1 个杯子成功抓取。• +0.02 : 伸手去放第 1 个杯子。• +0.10 : 第 1 个杯子成功放置。• +0.01 : 伸手去拿第 2 个杯子。• +0.10 : 第 2 个杯子成功抓取。• +0.02 : 伸手去放第 2 个杯子。• +0.15 : 第 2 个杯子成功放置。• +0.01 : 伸手去拿第 3 个杯子。• +0.15 : 第 3 个杯子成功抓取。• +0.02 : 伸手去放第 3 个杯子。• +0.36 : 第 3 个杯子成功放置。

多步骤牛排。指令：“将牛排从平底锅中盛出装盘，烹饪过程中翻面，再将其放回盘中，并撒上胡椒调味。”附加评分标准：

- +0.01 : 伸手拿平底锅。• +0.02 : 平底锅成功握住。• +0.01 : 伸手放置牛排。• +0.07 : 牛排成功倒入平底锅中。

- +0.01 : 伸手放置平底锅。• +0.01 : 平底锅成功放置。• +0.01 : 伸手拿夹子。• +0.07 : 夹子成功握住。• +0.01 : 伸手夹住牛排。• +0.17 : 牛排成功夹住。• +0.20 : 牛排翻面成功。• +0.15 : 牛排再次成功夹住。• +0.07 : 牛排成功放到盘子上。• +0.01 : 伸手放置夹子。• +0.01 : 夹子放下。• +0.01 : 伸手拿胡椒瓶。• +0.07 : 胡椒瓶成功握住。• +0.09 : 撒胡椒成功。

E 附加结果

E.1 未见过的家庭、办公室和厨房场景中的定性展开图集

图 E.1 汇总了 9 个具有代表性的 WAM-TTT 在未见场景中的执行过程。其中六行对应第 4.1 节九项任务基准中在新设定下执行的评估任务（多步煎牛排、转移瓶子、递送饮料、金字塔堆叠、盖章纸张、餐桌清理）；其余三行为额外的自然场景演示，展示了基准未测试的扰动维度（白板擦拭、自由画圆和手写），旨在体现模型在元训练和测试时 TTT 后所保留的技能广度。每一行是单个任务的一次执行过程，以 5 个等间隔关键帧从左到右展示，最左列为初始观测，最右列为回合终止时的最终场景。所有执行过程均来自用于生成表 C.1 的同一检查点，经过场景内人类视频的测试时 TTT 适应（第 3.3 节）；未进行任何逐任务超参数搜索。




图 E.1: WAM-TTT 在未见过的家庭、办公室和厨房场景中展开的定性图库

场景。 每一行是单个任务的单次执行过程，以 5 个均匀间隔的关键帧展示（左 → 右，初始 → 终止帧）。从上到下各行依次为：（1）在全新厨房中执行多步骤煎牛排任务，灶台相对于元训练隔间升高了 +10 厘米（Galbot sharpia）；（2）转移瓶子任务，使用新颖的长柄酒杯实例（Galbot gripper）；（3）在会议室擦黑板（Galbot gripper）；（4）递送饮料（Unitree G1，dex-3 手）；（5）在 Galbot sharpia 上进行金字塔堆叠，任务中途最左侧的杯子被替换为新颖的纸杯实例；（6）在会议室白板上画圆（Galbot gripper）；（7）在会议室盖章，目标盖章位置偏离隔间锚点（Galbot gripper）；（8）自由书写字母“L”（Galbot gripper）；（9）清理餐桌（Unitree G1，dex-3 手）。第（1、2、4、5、7、9）行来自第 4.1 节九任务基准在“新扰动”条件下的测试，而第（3、6、8）行则是超出主要基准的额外真实场景演示。

E.2 无场景特定人类数据的直接实验室场景泛化

我们进一步对 WAM-TTT 的部署时泛化能力进行压力测试，将机器人移动到一个此前未见过的实验室场景中，同时保持模型与元训练结束时完全一致。关键的是，*no* 本次评估未采集任何场景内的人类视频：TTT 分支仅使用元训练期间由配对机器人-人类演示所塑造的慢投影和 W_{init} 。这隔离了元训练慢投影的贡献，排除了部署场景中任何测试时人类视频适应的影响。

图 E.2 报告了 Galbot gripper 和 Galbot sharpa 在相对于标准化机器人隔间的四个扰动轴上同时变化的执行结果：(i) 光照（暖色与冷色、侧装与顶装），(ii) 桌布图案和颜色，(iii) 同一类别的新颖物体实例，以及 (iv) 目标位姿偏移。尽管四个扰动被联合施加，WAM 与元训练慢投影相结合仍在新实验室场景中保留了有用的技能先验，表明元训练期间实现的校准并不依赖于隔间内的观测统计。这一直接迁移结果补充了表 C.1：它表明即使没有从场景内演示中填充人类键/值缓存，WAM-TTT 也能纯粹依靠元训练阶段塑造的 WAM 侧知识恢复出有用的行为。




图 E.2: 在无场景特定人类数据的情况下，直接泛化至未见过的实验室场景。仅经过元训练后的 WAM-TTT 展开；由于未提供场景内人类视频，测试时训练分支完全由元训练得到的慢投影和 $W_{\text{init}}^{(\ell)}$ 驱动。该实验室场景与标准化隔间在光照、桌布、物体实例以及目标姿态偏移方面同时存在差异。从上到下，六条展开条分别展示：Galbot 夹爪上的盖章纸和转移瓶；Galbot 锐爪上的交换位置、翻牛排、多步骤牛排和金字塔堆叠。尽管存在联合分布外偏移，行为仍能迁移，表明元训练期间实现的校准并不依赖于隔间内的观测统计。

E.3 场景内分布偏移六个轴上的鲁棒性

附录 E.2 对完全没有场景内人类视频的 WAM-TTT 进行了压力测试。此处我们考虑互补的压力测试：部署场景确实提供了场景内人类视频，但场景本身（以及测试时 TTT 所使用的人类视频）沿着六个不同的扰动轴偏离了元训练隔间，我们逐一评估这些轴。每个轴同时应用于

机器人展开场景和测试时内循环（公式 8）所消耗的配对人类侧视频，因此每个轴都是对整个部署信号的单因素分布外扰动，而非仅对单一流的合成扰动。

这正是标准自适应流程往往失效的机制。在扰动人类数据上联合训练的方法（例如第 4.1 节的 WAM-COTRAIN 基线）会将人类侧的域偏移传播到整个骨干网络中，因此少量扰动的场景内视频就足以明显侵蚀预训练策略。在上下文中以人类视频为条件的方法（例如 WAM-ICL）同样会将扰动的观测统计直接输入条件流，表 C.1 已显示其因相同原因在家庭新划分上急剧崩溃。WAM-TTT 的测试时训练分支通过构造避免了这两种失效模式：测试时仅更新快速权重 $W^{(\ell)}$ ，而 Θ WAM 慢投影 $\theta_{\{K,V,Q,O\}}^{(\ell)}$ 以及快速权重初始化 $W_{\text{init}}^{(\ell)}$ 均保持冻结（公式 8）。因此，人类侧的域偏移只能重写人类到机器人的记忆；它无法重写策略本身，WAM 的预训练视觉推理和动作先验得以保留。

图 E.3 中展示的六个扰动轴，按从上到下的行顺序：

- 物体泛化（Unitree G1, dex-3 手, Table Bussing）。桌面上放置了来自元训练集从未包含类别的新物体实例。
- 光照泛化（Galbot sharpa, Swap Place）。主光源在色温（暖 $\leftrightarrow$ 冷）、强度和方向上相对于隔间发生了变化。
- 高度泛化（Galbot sharpa, Swap Place）。桌子相对于标准化隔间高度被抬高，改变了机器人到目标的几何关系。
- 底盘（背景）泛化（Galbot 夹爪, Stamp Paper）。机器人底盘被重新定位，桌面上堆满了干扰物，扰乱了以自我为中心场景的背景统计信息。
- 全新印章 / 可供性泛化（Galbot 夹爪, Stamp Paper）。印章被替换为一个不熟悉的实例，其形状和抓取可供性与训练中见过的任何印章都不同。
- 物体位置泛化（Galbot 夹爪）。目标放置位置位于元训练分布之外，要求策略插值出一个从未被演示过的操作姿态。

所有六行结果均来自用于填充表 C.1 的同一检查点；测试时内循环在该轴受扰动的场景内人类视频上运行，没有切换检查点或进行逐轴超参数调整。有关原生帧率的完整 rollout 视频，请参阅我们随附的补充视频。




图 E.3: WAM-TTT 在六个场景内分布偏移轴上的表现。每一行是单个扰动轴下的一次 rollout，显示为 5 个均匀间隔的关键帧（左 → 右，初始 → 终止帧）。从上到下各行依次为：（1）物体泛化，Table Bussing 上的新物体实例（Unitree G1，dex-3 手）；（2）光照泛化，Swap Place 上剧烈的色温 / 强度 / 方向偏移（Galbot sharp）；（3）高度泛化，Swap Place 上抬高桌面（Galbot sharp）；（4）底盘泛化，Stamp Paper 上底盘位置偏移加上杂乱的桌面（Galbot 夹爪）；（5）Stamp Paper 上全新印章 / 可供性偏移（Galbot 夹爪）；（6）物体位置泛化，目标放置位置在元训练分布之外（Galbot 夹爪）。所有 rollout 均来自与表 C.1 相同的检查点；测试时内循环输入受扰动的场景内人类视频，没有进行逐轴超参数调整。

这一结果是 WAM-TTT 在原始适应方法失效之处仍具鲁棒性的架构性原因：残差快速权重 TTT 将人类侧更新与 WAM 侧参数解耦，因此人类视频中的域偏移无法侵入并覆盖 WAM 的预训练能力。

E.4 数据比例消融

我们的默认元训练预算为每个任务 $(r, h) = (100, 100)$ 对机器人/人类片段。表 E.1 在三个代表性任务上对该比例进行了扫描。我们没有进行完整的网格扫描，而是针对每个想要回答的不同问题保留一行：

- $(100, 0)$ – 在机器人预算下的无人基线；隔离了成对人类数据的边际价值。
- 总片段数为 $= 200$ 的等预算三元组： $(200, 0)$ 、 $(100, 100)$ 和 $(10, 190)$ 。这三行保持总数据收集成本固定，仅改变机器人/人类划分，因此它们之间的任何差异都归因于混合比例而非规模。 $(200, 0)$ 是仅机器人的上限，回答了“为什么不直接收集更多机器人数据？”这一自然挑战。 $(10, 190)$ 将混合比例推向廉价人类极端，测试当机器人遥操作成为瓶颈资源时，人类数据能否承载策略。 $(100, 100)$ 是论文其余部分使用的部署配置。
- $(100, 200)$ – 在默认基础上额外增加 100 对成对人类片段，同时保持机器人数量不变；探究人类侧增益是否在 $h = 100$ 处已饱和。

表 E.1: 数据比例消融。在不同元训练数据预算下，新设置中的进度（%）。 r = 个机器人演示/任务， h = 个成对人类演示/任务。我们的部署设置为 (100, 100)；其他每一行隔离一个单独的问题。所有单元格在 25 次试验上取平均（每个配置、任务），与第 4.1 节的主论文协议一致。

(robot, human)	Transfer Bottle	Table Bussing	Deliver Drink	Avg.
(100, 0)	44.1	90.0	44.4	59.5
<i>Iso-budget triple: total = 200 episodes per task</i>				
(10, 190)	42.1	68.0	44.2	51.4
(100, 100) (<i>ours</i>)	55.6	100.0	66.7	74.1
(200, 0)	47.9	100.0	73.2	73.7
(100, 200)	58.9	100.0	61.0	73.3

要点。对表格的三方面解读与设计意图一致。（一）在固定机器人预算下，成对人类数据具有明确的边际价值：在 $(r, h) = (100, 0)$ 基础上增加 100 个成对人类回合，将三任务平均值从 59.5 提升至 74.1（+14.6 分），且相对于机器人侧成本几乎免费。（二）在每任务 200 回合的相同总预算下，成对人类数据与机器人数据按 1:1 替代：等预算三元组显示 (100, 100) 在 74.1 与 (200, 0) 在 73.7 的三任务平均值上统计不可区分，因此实践者可将机器人遥操作成本减半而不牺牲性能。然而，廉价人类极端情况 (10, 190) 在 51.4，远低于两者，证实需要一定的机器人基础，且人类数据是动作条件信号的替代品而非完全替代。（三）人类侧在默认设置下已饱和：将人类回合数加倍至 (100, 200) 得到 73.3，在同一三任务平均值上略低于 (100, 100)，因此我们采用 $h = 100$ 作为部署配置。

E.5 模型架构消融

主论文基线（第 4.1 节）将 WAM-TTT 与共享 VLM 条件 DiT 骨干的替代训练方案进行对比，而表 E.2 则消融骨干组成本身：每一行都采用完整的元训练和测试时 TTT 流程，仅改变 VLM 侧。目标是证明选择预训练、完全解冻的 VLM 作为 DiT 条件后端这一架构决策的合理性。

表 E.2: 模型架构消融。在新设置下 Table Bussing 的进度（%）。所有变体保留第 3 节的完整元训练加测试时 TTT 流程；仅改变 VLM 条件后端。每行对每个配置进行 10 次试验取平均；主论文第 4.1 节的 25 次试验协议在此缩减，以使四路架构扫描可行，因此单行数据应比表 E.1 的数据比例消融具有更宽的误差范围。

Configuration	Progress (%)
DiT only (no VLM backend)	72.0
DiT + VLM (no VLM pretrain)	80.0
DiT + VLM (VLM frozen)	54.0
DiT + VLM (VLM open) (<i>ours</i>)	100.0

要点。对表格的三次解读证明了架构选择的合理性。（一）视觉语言模型骨干是承重的：完全移除它损失 -28 分（仅扩散变换器为 72，而本文为 100）。（二）视觉语言模型的预训练是承重的：将预训练的视觉语言模型替换为随机初始化的模型损失 -20 分（无预训练为 80，而本文为 100），因此视觉语言先验在贡献容量之外确实发挥了作用。（三）联合适应不是可选的：冻结预训练的视觉语言模型损失 -46 分，甚至低于无视觉语言模型的配置（54 对 72），这表明固定的预训练表示无论多么通用，一旦人机对齐需要适应条件特征本身，就会成为扩散变换器的瓶颈。因此，视觉语言模型与扩散变换器的联合元训练是我们流程的正确设置。

E.6 动作伪标签消融

原始的 WAM-TTT 设计将人类视频视为无动作的：在测试时，只有视频生成损失 $\mathcal{L}_{vg}^{human}$ 驱动内部随机梯度下降对 $W^{(\ell)}$ (Eq. 7) 的更新，因为在人类侧没有可用的机器人动作流。一个自然的替代方案，被多个人类数据流程 [7, 10] 所采用，是为每个人类帧提取一个伪动作，然后在人类侧也训练一个以动作为条件的目标。我们在此测试这一替代方案。

流程。对于在 GoPro 上采集的每个人类片段，我们使用 MediaPipe 手部跟踪器 [59] 结合 EgoMimic 风格的估计流程 [7] 来估计手腕的六自由度位姿，拟合参数化 MANO 手部模型 [60] 以恢复完整手部姿态，并使用 EgoScale 的基于优化的重定向协议 [10] 将得到的指尖和手掌目标重定向到目标实体的关节配置。输出是伪 qpos 序列 $\tilde{\mathbf{a}}_t^{human}$ ，即机器人遥操作动作的人类侧对应物，其帧率与第一人称视频相同。图 E.4 展示了一个有代表性的五帧条带，其中 MediaPipe 关键点和 MANO 网格叠加在原始第一人称视频上，说明了 FD 流程所消耗的单视图标注的典型质量。




图 E.4: 来自 FD 流程的代表性单视图手部姿态标注。一个人类片段的五个等间隔帧，叠加了 MediaPipe[59] 关键点和拟合的 MANO[60] 网格。该叠加是 EgoScale 风格 [10] 重定向器的输入，该重定向器生成伪 qpos $\tilde{\mathbf{a}}_t^{human}$ 。表 E.3 中 VG + FD 变体所采用的方法。单目单视图拟合的可见缺陷（指尖漂移、被遮挡拇指估计、跨帧手掌法线不一致）会向下游传播到重定向的伪动作中，这是 FD 损失造成损害的根本原因。

在人类侧添加的目标。给定伪动作，我们可以训练原始 WAM-TTT 在人类数据上丢弃的 WAM 侧目标之一：前向动力学（FD）损失，该损失以当前观测 $\mathbf{o}_t^{human}$ 和伪动作 $\tilde{\mathbf{a}}_t^{human}$ 为条件，在冻结的 DINOv3 [61] 特征空间中预测下一观测。元训练时的人类数据贡献变为 $\mathcal{L}_{vg}^{human} + \lambda_{FD} \mathcal{L}_{FD}^{human}$ ，而非仅 $\mathcal{L}_{vg}^{human}$ ；本消融中全程使用 $\lambda_{FD} = 1$ ，因此 FD 项以与视频生成项相同的尺度进入，并未被人为降权。测试时两个损失均可用，因为二者仅依赖于场景内人类视频及其 MANO 导出的伪动作。

比较。表 E.3 中比较的两种配置为：(i) 仅 VG（本文方案），即部署的无动作 WAM-TTT 设计，其中人类侧元训练和测试时 TTT 的唯一损失为 $\mathcal{L}_{vg}^{human}$ ，无 MANO 重定向且无伪动作；(ii) VG + FD（PSEUDO-动作），采用相同骨干网络、相同元训练计划、相同配对机器人-人类数据集以及相同测试时 TTT 流程，但加入了 MANO 重定向管线（MediaPipe 手腕 + EgoMimic 风格估计 $\rightarrow$ MANO 手部 $\rightarrow$ EgoScale 风格重定向器 $\rightarrow$ 伪 qpos $\tilde{\mathbf{a}}_t^{human}$ 匹配目标本体）以生成伪动作，并在 $\lambda_{FD} = 1$ 处将 DINOv3 特征空间 FD 损失添加到人类侧。四项任务涵盖全部三种本体和三种末端执行器家族：Galbot 夹爪（两指）上的转移瓶子、Unitree G1（dex-3 手）上的桌面清理和递送饮料，以及 Galbot sharpa（22 自由度灵巧手）上的交换位置。两种配置均在新家庭设置下使用第 4.1 节主论文的 25 次试验协议进行评估；仅 VG 行复现了表 C.1 中这四项任务的 WAM-TTT 条目，因此跨行差异直接隔离了 MANO 重定向和 FD 损失的贡献。

Table E.3: **Action-pseudolabel ablation.** Progress (%) under the *New* setting; **25 trials per (configuration, task)**. Per-task embodiment: Transfer Bottle = Galbot gripper, Table Bussing / Deliver Drink = Unitree G1 (dex-3 hand), Swap Place = Galbot sharp (dexterous). VG ONLY (OURS) is the deployed action-free WAM-TTT design (no MANO, no pseudo-action). VG + FD (PSEUDO-ACTION) adds the MANO retargeting pipeline (MediaPipe [59] + MANO [60] + EgoScale-style retargeter [10]) to produce an embodiment-matched pseudo-qpos $\tilde{a}_t^{\text{human}}$ per human frame, and adds the DINOv3 [61]-feature-space forward-dynamics loss $\mathcal{L}_{\text{FD}}^{\text{human}}$ on the human side at $\lambda_{\text{FD}} = 1$.

Configuration	Transfer Bottle	Table Bussing	Deliver Drink	Swap Place	Avg.
VG ONLY (<i>ours</i>)	55.6	100.0	66.7	66.7	72.3
VG + FD (pseudo-action)	14.2	33.3	26.8	41.2	28.9

要点。添加重定向伪动作和 FD 损失一致有害，将 4 任务平均分从 72.3 降至 28.9（-43.4 分）。损害最大的两个末端执行器家族中，MANO 输出无法干净地映射到机器人驱动：-41.4 在转移瓶子（Galbot 夹爪，一个单自由度平行夹爪）上，-66.7 在桌面清理和 -39.9 在递送饮料（Unitree G1 dex-3 手）上。对于夹爪和 dex-3 手，二元或近二元的闭合命令并非天然存在于 MANO 姿态中，因此需要手工设计的后处理器来推导开/关信号。该后处理器叠加在已经嘈杂的单目手部姿态估计之上，产生的伪动作与真实机器人动作分布相差太远，无法提供有用的 FD 监督信号。即使在 Galbot sharp 上的交换位置任务中，灵巧机器人是 MANO 输出最直接的几何目标，FD 仍然损失 -25.5 分（66.7 $\rightarrow$ 41.2）：仅残余的单视图重定向噪声就足以破坏学习到的前向动力学。结论支持 WAM-TTT 的设计选择：在当前单视图手部跟踪和重定向成熟度下，将重定向伪动作注入人类侧训练信号是净负面的，保持人类视频无动作（以便只有噪声容忍的视频预测损失 $\mathcal{L}_{\text{vg}}^{\text{human}}$ 监督人类侧）是正确的选择。