

Zero-WAM: 基于人类视频的上下文 文世界-动作建模实现开放式任务泛化

Jiaming Zhou^{1,2}, Qihang Zhang^{1,*}, Gangwei Xu¹, Cunxin Fan¹, Yujie Zhao¹, Ruilin Wang¹,
Yiming Luo¹, Shuai Yang¹, Xing Zhu¹, Yujun Shen¹, Junwei Liang^{2,3,†}, Yinghao Xu^{3,1,†}

¹Robbyant, ²HKUST (GZ), ³HKUST

*Project Lead, †Corresponding Authors

<https://robbyant-research.github.io/Zero-WAM/>

摘要

零样本跨任务泛化，即策略必须执行训练期间从未见过的操作任务，仍然是机器人学习中的核心挑战。在大语言模型中，一个新任务只需在上下文中指定即可执行，无需任何参数更新。这种形式的上下文学习（In-Context Learning, ICL）将泛化转化为任务指定问题。为了实现跨任务泛化，我们将这一范式引入机器人操作，并认为操作的自然任务指定方式是人类视频：与语言不同，它提供了关于预期任务演变的丰富视觉线索。我们提出 **Zero-WAM**，一种因果视频-动作模型，通过遵循上下文人类视频指导来执行未见过的任务。为解决任务丰富的人类-机器人配对数据稀缺问题，我们提出一种自动流水线，将任务采样的机器人轨迹转换为语义匹配的人类视频，从而生成 HumanGen 数据集，该数据集包含 8.6K 个任务中的 74.2K 个人类-机器人上下文学习配对。在模型训练方面，我们进一步引入上下文未来块预测（In-Context Future Chunk Prediction, IFP）目标，该目标抑制从已见任务中学到的捷径，并迫使策略从视频提示中提取任务信息。在 RoboTwin 2.0 仿真中的七个未见任务上，**Zero-WAM** 实现了 47.0% 的平均成功率，比最强的视频-动作基线绝对提高了 29.5 个百分点。在真实世界评估中，它遵循人类视频指导，泛化到涉及多物体场景、长时程操作和精细插入的未见任务配置。




图 1 Zero-WAM 概览。Zero-WAM 根据上下文人类视频提示或语言指令预测未来机器人视频和可执行动作。人类视频指令由任务采样的机器人轨迹大规模生成，同时生成任务均衡的机器人视频-动作预训练语料库。我们验证了 Zero-WAM 在未见仿真任务和复杂真实世界任务上的有效性。

1 引言

零样本跨任务泛化对于通用机器人操作至关重要：机器人应仅利用部署时可获得的信息，推断如何在未练习过的任务中行动。受上下文学习（In-Context Learning, ICL）[1, 2] 的启发，即模型无需更新参数即可从输入上下文中解决新问题，我们将机器人任务泛化视为通过部署时上下文来指定未见过的任务。这一视角为开放式任务泛化提供了一条途径：策略可以从上下文中推断出预期任务，并将其转化为可执行的机器人行为。

近期的视觉-语言-动作（Vision-Language-Action, VLA）模型 [3, 4, 5, 6, 7, 8, 9, 10] 和视频-动作模型 [11, 12, 13, 14, 15, 16] 显著扩展了机器人策略的能力，但两者都主要依赖语言作为任务接口。然而，语言往往无法充分指定操作任务：空间约束、中间状态和时间结构可能难以表述，即使详细的指令也无法提供场景应如何演变的直接视觉证据。人类演示视频为预期任务提供了自然的上下文规范 [17, 18]。通过直接呈现期望的视觉状态变化及其时间演变，它们提供了场景应如何演变的具体视觉证据。尽管人类视频不提供可执行的机器人动作，但它为策略提供了一个视觉参考，策略可以从推断出期望的任务演变，并通过机器人自身的本体和动力学来实现。

然而，大规模利用人类视频面临两个关键挑战。首先，大规模、任务丰富的人机配对数据仍然稀缺，且手动收集成本高昂 [19, 20, 21]。从人类视频指令中学习需要语义上对应的机器人轨迹，这些轨迹保留可执行的动作，但此类配对在大规模上很少可用。其次，在已见任务上训练的策略可能会学习到捷径，使其忽略上下文视频。特别是，下一个机器人视频-动作块通常可以仅从机器人历史和文本指令中预测出来。因此，模型可能在熟悉的训练任务上表现良好，而无需学习使用人类视频，然后在测试时恰恰在需要视频来指定未见任务的时候，未能充分利用视频。

为应对这些挑战，本文提出零样本世界-动作模型（**Zero-WAM**），这是一种因果视频-动作模型，遵循上下文人类视频指令以实现零样本机器人任务泛化。零样本世界-动作模型在单一策略中支持两种任务指定形式：语言指令和人类演示视频。给定任一形式的指令，模型自回归地预测未来机器人视频和可执行动作。人类视频使零样本世界-动作模型能够以演示的视觉状态变化为条件进行预测，提供超出仅从语言和机器人历史中可获得的预期任务演化信息。

为利用人类视频指令扩展训练规模，本文提出一种上下文人类视频生成流程，该流程使用任务采样的机器人轨迹构建语义匹配的人类操作视频。每个人类视频与其对应的机器人轨迹配对，保留可执行的机器人动作，形成人-机器人上下文学习（ICL）对。由此产生的 HumanGen 数据集包含 74.2K 个人-机器人上下文学习对，涵盖 8.6K 个任务。此外，本文通过将公共机器人轨迹重新划分为 6,000 多个操作任务并在任务级别采样轨迹，对机器人预训练数据进行任务平衡整理。该过程每个训练轮次产生约 400K 条机器人轨迹，本文称之为任务多样化 VA。任务平衡采样既为上下文人类视频生成流程提供任务丰富的源轨迹，又防止视频-动作预训练被少数任务的重复遥操作轨迹所主导。HumanGen 和任务多样化 VA 共同为因果视频-动作预训练提供可扩展的人类视频任务规范和多样化的机器人视频-动作动态。图 2 总结了所得数据组成和上下文人类视频生成流程。

为确保零样本世界-动作模型使用上下文人类视频而非依赖机器人历史和文本中的捷径，本文引入上下文未来块预测（IFP）目标。标准下一块预测通常仅使用局部机器人历史即可解决，尤其是对于训练期间观察到的任务。上下文未来块预测则从当前机器人视频表示中监督多个跨步的未来机器人视频块，鼓励模型编码人类视频所传达的长期任务演化。

我们在 RoboTwin 2.0 [22] 仿真环境和真实世界机器人操作中评估 Zero-WAM 的零样本跨任务泛化能力。在 RoboTwin 2.0 中，Zero-WAM 在七个未见任务上达到 46.95% 的平均成功率，比 LingBot-VA [11] 高出 29.50 个百分点的绝对优势。

真实世界实验进一步证明了由人类视频引导的泛化能力，可应对未见任务配置，包括多物体场景、长时程操作和精密插入任务，Zero-WAM 在所有三个任务族中均优于 LingBot-VA。

我们的贡献总结如下：

- 我们将零样本机器人任务泛化形式化为上下文世界动作建模，其中单一因果策略同时支持语言和人类视频作为任务指令。
- 我们提出一种可扩展的上下文人类视频生成流程，自动将任务采样的机器人轨迹转换为语义匹配的人类视频指令，从而生成 HumanGen 数据集，包含 8.6K 个任务上的 74.2K 个人类-机器人上下文学习对；相同的任务级采样还产生了 Task-diverse VA 数据，这是一个用于自回归机器人视频-动作预训练的任务平衡语料库。
- 我们提出 Zero-WAM，采用上下文未来块预测（IFP）目标，抑制从已见任务轨迹中的捷径学习，并加强上下文人类视频提示的使用。
- 我们在 RoboTwin 中展示了有效的零样本跨任务泛化，Zero-WAM 显著优于视频-动作基线，并进一步评估了在未见任务配置上的真实世界泛化，无需收集相应的机器人数据或更新任何模型参数。

2 数据策展

零样本机器人任务泛化需要一个能够迁移到未见任务的指令接口，以及覆盖多样化任务动态的训练数据，而不仅仅是增加机器人轨迹的数量。作为工程基础，我们首先在任务层面重新采样公开的机器人预训练数据，构建任务多样化的视频-动作数据（第 2.1 节）。基于相同的任务级采样，我们引入上下文人类视频生成流程，将任务采样的机器人视频转换为人类视频指令（第 2.2 节）。生成的人机上下文学习对构成 HumanGen，包括预训练上下文学习（外部）、预训练上下文学习（内部）、仿真上下文学习和真实世界上下文学习（第 2.3 节）。图 2 总结了该数据构成以及用于生成 HumanGen 数据的流程。

2.1 任务多样化的视频-动作数据

任务多样化的视频-动作数据来源于公开的机器人视频-动作预训练数据集，包括 AgiBot [23]、InternData-A1 [24]、Open-X-Embodiment [4]、RoboCOIN [25] 和 RoboMIND [26]。这些源数据集与 LingBot-VA [11] 所使用的公开视频-动作预训练数据集相同。尽管这些数据集包含大量机器人轨迹和广泛的任务覆盖，但许多轨迹来自同一任务的重复遥操作。直接使用原始分布会使预训练过度受冗余轨迹影响，导致模型无法充分利用源数据集中已有的任务多样性。我们通过将每个数据集重新划分为任务来解决这一问题，其中每个任务由操作动作和对象的组合定义。任务标签在原始数据集元数据可用时从中获取，或在元数据不足时从机器人轨迹中解析。然后，我们从每个任务中采样有界数量的轨迹，采样界限根据每个源数据集的任务内多样性进行调整。在五个源数据集中，我们在每个训练轮次采样超过 6000 个任务和约 40 万条对应的机器人轨迹。这种平衡的视频-动作语料库能有效地将通用领域视频生成模型适配为自回归机器人视频-动作模型。

2.2 上下文人类视频生成流程

人类视频演示通过视觉状态变化直接传达任务语义，比机器人演示更容易获取，并且不依赖于测试时使用的机器人本体。因此，扩展任务丰富的人机上下文学习对是实现跨任务泛化的有效途径。

手动收集此类配对的人与机器人动作数据十分困难，当需要高任务多样性时，成本尤其高昂。因此，我们从机器人预训练语料库出发，



图 2 数据构建与上下文人类视频生成。顶部：任务多样的 VA 数据提供了任务均衡的机器人视频-动作预训练数据，而 HumanGen 包含预训练上下文学习（外部）、预训练上下文学习（内部）、仿真上下文学习和真实世界上下文学习对。底部：上下文人类视频生成流程将任务采样的机器人视频转换为人类视频指令。

再次按照第 2.1 节在任务层面采样轨迹。这为我们提供了一组广泛的带有可执行动作标注的机器人视频。随后，我们引入一种上下文人类视频生成流程，将这些机器人轨迹转换为具有相同任务语义的人类操作视频。为了增加人机上下文学习对中视觉对齐的多样性，生成的人类视频在保持相同任务语义的同时，包含了背景、视角、环境风格、物体实例和物体摆放位置的变化。

图 2 底部展示了用于生成人类视频指令的上下文人类视频生成流程。对于每个采样的机器人视频，我们首先使用视觉语言模型（VLM，如 Gemini 3.1 Pro [27] 或 Qwen3.6-Plus [28]）进行任务分析。该视觉语言模型提取任务级信息，包括任务名称、初始物体状态、物体状态变化以及最终物体状态。同时，它生成一个图像编辑提示，将机器人视频的第一帧转换为人类操作场景的初始观测。我们通过该图像编辑提示注入上述视觉对齐变化，同时保留任务语义。给定机器人第一帧和图像编辑提示，图像编辑模型（Nano Banana 2 [29] 或 Qwen-Image-2.0 [30]）为相应任务生成初始人类观测图像。随后，我们使用视觉语言模型处理编辑后的人类观测图像以及提取的物体状态信息，生成视频生成提示，描述人类双手应如何操作物体以完成任务。

表 1 与现有任务级配对的人机数据集的比较。“多源”表示数据集是否由多个数据源构建。“具身数”指机器人具身的数量。“人类视角”指定人类视频的视角。“人类采集”表示人类视频是手动采集还是自动生成。“对齐多样性”表示人机配对是否包含不同程度的视觉对齐，例如背景、视角、环境风格、物体实例或物体摆放的变化。“样本数”是人类视频指令的数量，“任务数”是任务类别的数量。

Dataset	Multi-source	Embod.	Human view	Human acquisition	Align. div.	Samples	Tasks
MIME [19]	✗	1	third	manual	✗	8.3K	20
EgoMimic [20]	✗	1	ego	manual	✗	2.1K	3
BC-Z [17]	✗	1	ego	manual	✓	18.7K	100
EgoHumanoid [33]	✗	1	ego	manual	✗	1.2K	4
RH20T [21]	✗	4	ego & third	manual	✗	110K	147
EgoScale [34]	✗	1	ego	manual	✗	10.3K	344
HumanGen (ours)	✓	>45	ego & third	auto-generated	✓	74.2K	8.6K

该提示被发送至视频生成模型（Wan 2.7 [31] 或 Kling AI 3.0 [32]）以合成人类操作视频。最后，视觉语言模型评估每个生成视频的任务语义保持性和物理合理性，合格的人类视频与其原始机器人轨迹配对，作为上下文学习样本。

2.3 上下文人类生成数据集

HumanGen 是一个由上下文人类视频生成流水线生成的人机上下文学习（ICL）对集合。每对包含一个生成的人类视频指令及其对应的机器人轨迹，并带有可执行动作。HumanGen 按数据来源分为预训练 ICL（外部）、预训练 ICL（内部）、仿真 ICL 和真实世界 ICL。遵循与构建任务多样化视觉动作（VA）数据相同的任务多样化采样原则，源机器人视频按任务而非原始轨迹频率进行采样，因此 ICL 数据不会被少数任务的重复执行所主导。

预训练 ICL（外部）。该子集基于与任务多样化 VA 数据相同的五个公开机器人视频-动作数据集构建：AgiBot [23]、InternData-A1 [24]、Open-X-Embodiment [4]、RoboCOIN [25] 和 RoboMIND [26]。这些数据集涵盖了多样的机器人本体、场景和物体，包括超过 45 种机器人本体。我们从每个数据集中按任务采样机器人轨迹，并使用上下文人类视频生成流水线将其转换为语义匹配的人类视频。具体而言，我们从 AgiBot 采样了 3,354 个任务和 6,660 条轨迹，从 InternData-A1 采样了 261 个任务和 12,515 条轨迹，从 Open-X-Embodiment 采样了 438 个任务和 9,290 条轨迹，从 RoboCOIN 采样了 512 个任务和 6,513 条轨迹，从 RoboMIND 采样了 497 个任务和 6,210 条轨迹。预训练 ICL（外部）总共包含 5,062 个任务和 41,188 对人机 ICL 对。对于该子集，我们有意使人类视频和机器人视频之间的视觉对齐多样化：我们强制改变场景环境、桌面背景、物体实例和物体摆放，并平衡第一人称和第三人称视角。由于任务语义在这些视觉变化中得以保留，模型被推动学习对场景、物体和视角变化不变的人机任务对应关系，从而提高其对视觉多样化 ICL 提示的鲁棒性。

预训练 ICL（内部）。为进一步扩大任务覆盖范围，本文按任务从自有机器人数据集中采样机器人轨迹。该子集涵盖多种机器人形态，如双臂弗兰卡（Franka）和银河通用 R1 Pro，包含 3522 个任务和 30247 个人类-机器人上下文学习（ICL）配对。当使用上下文人类视频生成管线为该子集生成相应人类视频时，本文降低第三人称视角比例，并减少场景、物体及物体摆放变化的频率。这能在保持任务多样性的同时，生成视觉上更对齐的上下文学习样本。

仿真上下文学习。为支持仿真中的跨任务评估，本文为 50 个 RoboTwin 任务生成上下文学习数据 [22]。该子集包含 2500 个上下文学习样本，每个任务 50 个样本。其中 43 个任务用于后训练（2150 个训练样本），其余 7 个任务保留为未见任务，用于

零样本跨任务评估。

真实世界上下文学习。真实世界上下文学习包含在双臂弗兰卡评估形态上采集的人类-机器人配对。它涵盖评估中使用的三个真实世界任务族的 252 个人类-机器人上下文学习配对：来自 30 个物体到容器放置训练任务组合的 120 个配对，来自 16 个三物体顺序操作训练任务组合的 96 个配对，以及用于双桌腿插入的 36 个配对。该子集用于后训练，使模型能够拟合评估机器人运动学，以进行跨任务评估。

与现有数据集的比较。表 1 将 HumanGen 与现有任务级成对人类-机器人数据集进行比较。统计数据取自其官方论文。与依赖人工人类数据收集的先前数据集不同，HumanGen 使用上下文人类视频生成管线从机器人轨迹自动生成语义匹配的人类视频，从而能够可扩展地构建人类-机器人上下文学习配对。HumanGen 还结合了多种数据来源（公开、自有、仿真和真实世界），覆盖显著更多的机器人形态，包含来自第一人称和第三人称视角的人类数据，并包含具有不同视觉对齐程度的配对数据。最重要的是，HumanGen 包含显著更广泛的任务覆盖，这是零样本跨任务泛化的关键因素。

3 Zero-WAM: 上下文世界动作建模

在零样本跨任务操作中，机器人必须在不进行微调的情况下执行新任务。我们通过在大规模人机上下文学习对和任务均衡的机器人视频-动作数据上预训练的世界动作模型（World Action Model, WAM）来实现这一能力：在部署时，Zero-WAM 使用语言指令或人类视频演示作为任务规范，驱动执行未见过的任务。

3.1 预备知识

用于视频生成的流匹配。对于视频生成，流匹配 [35] 学习干净视频与高斯噪声之间连续路径上的速度场。给定干净视频 $\mathbf{x}_0$ 、噪声 $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 和流时间 $t \in [0, 1]$ ，加噪视频和目标速度为

$$\mathbf{x}_t = (1 - t)\mathbf{x}_0 + t\epsilon, \quad \mathbf{v}_t^* = \epsilon - \mathbf{x}_0. \quad (1)$$

在条件 c 下，流匹配损失为

$$\mathcal{L}_{\text{fm}} = \mathbb{E}_{\mathbf{x}_0, \epsilon, t} \left[\|\mathbf{v}_\theta(\mathbf{x}_t, t, c) - \mathbf{v}_t^*\|_2^2 \right]. \quad (2)$$

在推理时，视频生成从噪声开始，并将学习到的速度场积分回 $t = 0$ 。

因果视频-动作建模。我们遵循 LingBot-VA 系列的因果视频-动作框架 [11, 12]，其中每个控制步骤都是一个因果预测问题：给定任务条件和历史观测，模型预测下一个机器人视频块及其时间对齐的可执行动作块。

每条机器人轨迹被切分为 $\tau = \{(\mathbf{x}^i, \mathbf{a}^i)\}_{i=1}^N$ ，其中 $\mathbf{x}^i$ 是视频块， $\mathbf{a}^i$ 是时间对齐的动作块。我们在整个方法中使用块级表示。在实现中，每个视频或动作块在进入变换器之前被编码为模态特定的表示，注意力掩码在这些标记化表示上操作。我们使用 c 表示任务条件，它可以是语言指令或同任务的人类视频指令。在块索引 i 处，因果模型预测下一个视频块 $\mathbf{x}^{i+1}$ 和对齐的动作块 $\mathbf{a}^{i+1}$ ：

$$p_\theta(\mathbf{x}^{i+1}, \mathbf{a}^{i+1} \mid \mathbf{x}^{\leq i}, \mathbf{a}^{\leq i}, c). \quad (3)$$

这种联合预测被分解为先进视频预测，然后进行动作解码：

$$\begin{aligned} p_\theta(\mathbf{x}^{i+1}, \mathbf{a}^{i+1} \mid \mathbf{x}^{\leq i}, \mathbf{a}^{\leq i}, c) &= p_\theta^{\text{vid}}(\mathbf{x}^{i+1} \mid \mathbf{x}^{\leq i}, \mathbf{a}^{\leq i}, c) \\ &\quad \cdot p_\theta^{\text{act}}(\mathbf{a}^{i+1} \mid \mathbf{x}^{\leq i}, \mathbf{a}^{\leq i}, \mathbf{x}^{i+1}, c), \end{aligned} \quad (4)$$

其中 p_{θ}^{vid} 预测下一个视频块， p_{θ}^{act} 作为逆动力学模型，从预测的下一个机器人视频块中解码可执行动作。在训练期间，模型被给予真实轨迹前缀 $(\mathbf{x}^{\leq i}, \mathbf{a}^{\leq i})$ ，并在下一个视频-动作块上进行监督。对于来自任务多样化 VA 数据的轨迹，条件是语言指令 $c = \ell$ 。对于来自 HumanGen 数据的轨迹，条件是 $c = \{\mathbf{h}, \ell\}$ ，其中 $\mathbf{h}$ 是同任务的人类视频指令， ℓ 是语言指令。

混合变换器设计。我们将 (LoT) 设计下的视频变换 p_{θ}^{vid} 器和动作变换器。每种模态都有自己的参数，包括独立的 QKV 投影、前馈网络和输出头，而视频和动作表示保持在单个序列中，仅通过共享的注意力层进行交互。在该序列中，动作块表示被放置在未来的视频表示之后，以便动作解码可以关注预测的未来机器人视频，正如上述分解所要求的那样。

模型实例化。继 LingBot-VA 之后，我们通过将 Wan-2.2-TI2V-5B [36]（一种双向文本/图像到视频生成模型）转换为上述因果视频-动作策略来实例化 Zero-WAM。在此框架基础上，本节其余部分介绍 Zero-WAM 特有的组件：以人类视频作为上下文任务规范（第 3.2 节）和上下文未来块预测（第 3.3 节）。

3.2 人类视频作为任务规范

对于未见过的任务，用语言完全指定期望的行为通常很困难，而且指令还必须进一步落实到策略从未观察过的任务动态中。因此，我们采用人类视频作为上下文任务规范，直接呈现期望的动态：在部署时，展示未见任务的人类视频充当指令。为了教会策略遵循此接口，我们在 HumanGen 数据集上进行训练，该数据集通过在任务级别采样源机器人轨迹构建（第 2 节）。每个语义匹配对包含一个生成的人类视频 $\mathbf{h}$ ，作为视觉任务规范，以及其对应的机器人轨迹，提供监督的未来视频和动作块。由于人类视频和配对的机器人轨迹可能在具身、视角、背景和物体放置上有所不同，模型必须学习任务级别的对应关系，而不是从人类视频中复制动作。

在训练期间，我们对人类视频块、机器人视频块和动作块的标记化表示应用教师强制注意力掩码。人类视频 $\mathbf{h}$ 被前置在机器人轨迹之前，并作为机器人视频预测的前缀记忆。在块索引 i 处，视频变换器根据上下文 $\mathcal{C}^{\text{vid}, i}$ 预测下一个机器人视频块 $\mathbf{x}^{i+1}$ ：

$$\mathcal{C}^{\text{vid}, i} = [\mathbf{h}, \mathbf{x}^{\leq i}, \mathbf{a}^{\leq i}, \ell], \quad (5)$$

$$p_{\theta}^{\text{vid}}(\mathbf{x}^{i+1} | \mathcal{C}^{\text{vid}, i}) = p_{\theta}^{\text{vid}}(\mathbf{x}^{i+1} | [\mathbf{h}, \mathbf{x}^{\leq i}, \mathbf{a}^{\leq i}, \ell]). \quad (6)$$

对于下一个机器人动作块预测，动作变换器根据机器人域历史和预测的下一个机器人视频块预测 $\mathbf{a}^{i+1}$ ，遵循第 3.1 节中的逆动力学分解。它不直接关注人类视频 $\mathbf{h}$ ： $\mathbf{h}$ 传达的任务语义已被吸收到预测的下一个机器人视频块中，因此动作解码简化为标准逆动力学。因此，动作预测条件与标准机器人视频-动作训练保持不变：

$$\mathcal{C}^{\text{act}, i} = [\mathbf{x}^{\leq i}, \mathbf{a}^{\leq i}, \mathbf{x}^{i+1}, \ell], \quad (7)$$

$$p_{\theta}^{\text{act}}(\mathbf{a}^{i+1} | \mathcal{C}^{\text{act}, i}) = p_{\theta}^{\text{act}}(\mathbf{a}^{i+1} | \mathbf{x}^{\leq i}, \mathbf{a}^{\leq i}, \mathbf{x}^{i+1}, \ell). \quad (8)$$

在训练期间，动作上下文中的 $\mathbf{x}^{i+1}$ 是教师强制下的真实下一个机器人视频块；在推理时，它被视频变换器生成的视频块替换。

用于上下文学习人类视频的旋转位置编码 (RoPE) [37] 偏移。上下文学习人类视频与多视角机器人视频由同一变分自编码器 (VAE) 编码器编码，因此共享相同的视觉潜空间。在令牌序列中，我们通过高度轴旋转位置编码坐标区分上下文学习人类视频与机器人视频：机器人视频潜变量保持原始坐标，而人类视频潜变量沿高度轴偏移一定量。设 (q, y, x) 表示视觉潜变量的时间、垂直和水平坐标，设 H_{mv} 为

多视角机器人视频潜变量布局的高度。我们分配旋转位置编码坐标如下

$$\text{pos}_{\text{robot}}(q, y, x) = (q, y, x), \quad (9)$$

$$\text{pos}_{\text{human}}(q, y, x) = (q, y + \Delta_H, x), \quad \Delta_H > H_{\text{mv}}. \quad (10)$$

该偏移将人类视频潜变量置于机器人视频潜变量坐标范围之外，防止上下文学习人类视频与机器人视频在同一序列中交互时产生表示混淆。

3.3 上下文未来块预测

对于上下文样本，模型应从人类视频 $\mathbf{h}$ 中推断任务演化，并将其迁移到机器人领域。然而，在已见任务上进行教师强制训练时，紧邻的下一个机器人视频块通常可以通过外推最近的机器人历史 ($\mathbf{x}^{\leq i}$) 来预测。这形成了一条捷径，使模型无需学习使用上下文人类视频即可降低训练损失。当模型在未见任务上评估时，该捷径导致其继续依赖机器人历史，并在最需要上下文信号来指定新任务时未能充分利用该信号。为应对此捷径，我们借鉴下一强迫 (Next Forcing) [14] 的多块预测思想，引入上下文未来块预测 (IFP)：一种仅用于训练的辅助目标，要求模型从当前机器人视频表示预测多个间隔的未来机器人视频块。设 $s \geq 1$ 为时间步长， K 为要预测的未来块数量。第 k 个未来目标是机器人视频块 $\mathbf{x}^{j_k}$ ，其中目标索引 j_k 定义为

$$j_k = (i + 1) + 1 + (k - 1)s, \quad k = 1, \dots, K. \quad (11)$$

为预测这些目标，我们添加 K 个上下文未来块预测模块 $\{G_k\}_{k=1}^K$ ，其中 G_k 负责在流匹配目标下对第 k -th 个间隔未来视频块进行去噪。每个上下文未来块预测模块与视频分支中的单个变换器 (Transformer) 层具有相同架构，并由最后一个视频变换器层初始化。

IFP 作用于主分支产生的当前机器人视频表示。在 $C^{\text{vid}, i}$ 条件下预测当前机器人视频块 $\mathbf{x}^{i+1}$ 时，我们从主视频变换器的 M 个中间层收集机器人视频隐藏表示。设 $\{\mathbf{r}_m^{i+1}\}_{m=1}^M$ 表示 $\mathbf{x}_t^{i+1}$ 在流时间 t 的加噪块 $\mathbf{x}^{i+1}$ 所收集的特征表示。我们将这些多层表示拼接起来，并通过轻量级多层感知机投影 P_{fuse} 将其投影回单层隐藏维度：

$$\phi^{i+1} = P_{\text{fuse}}(\text{Concat}(\{\mathbf{r}_m^{i+1}\}_{m=1}^M)). \quad (12)$$

每个 IFP 模块 G_k 基于该融合的当前表示、干净的机器人视频/动作历史以及语言指令，预测其跨步的未来块 $\mathbf{x}^{j_k}$ ：

$$p_{\theta, k}^{\text{ifp}}(\mathbf{x}^{j_k} | \phi^{i+1}, \mathbf{x}^{\leq i}, \mathbf{a}^{\leq i}, \ell), \quad k = 1, \dots, K. \quad (13)$$

IFP 损失将上述定义的流匹配目标应用于每个跨步目标，其中 w_k 表示第 k 个未来视频块目标的损失权重：

$$\mathcal{L}_{\text{ifp}} = \sum_{k=1}^K w_k \mathcal{L}_{\text{fm}}(\mathbf{x}^{j_k}; \phi^{i+1}, \mathbf{x}^{\leq i}, \mathbf{a}^{\leq i}, \ell). \quad (14)$$

重要的是，IFP 模块并不直接以人类视频提示 $\mathbf{h}$ 为条件。它们获取任务信息的唯一途径是通过 ϕ^{i+1} ，该表示是在主机器人视频变换器与上下文人类视频交互后提取的。如果 IFP 模块直接以 $\mathbf{h}$ 为条件，辅助分支可以学习一个独立的人类视频条件未来预测器，而无需迫使主机机器人视频变换器编码上下文任务信息；由于 IFP 模块在推理时被移除，部署的策略将无法从辅助监督中获得任何收益。因此，我们仅以 ϕ^{i+1} 为条件来设置 IFP，使未来损失监督主分支产生的当前机器人视频表示。多个未来块以时间跨步并行预测，在不引入训练期间未来块预测之间时间依赖的情况下增加了预测难度。

3.4 训练与推理

训练数据混合。我们在任务多样化 VA 和 HumanGen 数据的混合上训练 Zero-WAM：任务多样化 VA 提供多样的机器人域视频-动作动态，HumanGen 提供以可执行机器人动作为基础的人类视频任务规范。这两类数据按采样权重抽取，而非按原始数据集大小的比例抽取。

训练目标。对于每个目标下一视频块 $\mathbf{x}^{i+1}$ ，我们采样噪声 ϵ^{i+1} 和流时间 t ，并形成

$$\mathbf{x}_t^{i+1} = (1-t)\mathbf{x}^{i+1} + t\epsilon^{i+1}, \quad \mathbf{v}_t^{*,i+1} = \epsilon^{i+1} - \mathbf{x}^{i+1}. \quad (15)$$

给定任务条件 c ，下一块视频损失为

$$\mathcal{L}_{\text{fm}}^{i+1}(c) = \|\mathbf{v}_{\theta}^{\text{vid}}(\mathbf{x}_t^{i+1}, t \mid \mathbf{x}^{\leq i}, \mathbf{a}^{\leq i}, c) - \mathbf{v}_t^{*,i+1}\|_2^2. \quad (16)$$

对于动作块预测，我们在动作空间中使用类似的流匹配目标。给定高斯噪声 $\epsilon_a^{i+1} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 和流时间 $r \in [0, 1]$ ，我们形成

$$\mathbf{a}_r^{i+1} = (1-r)\mathbf{a}^{i+1} + r\epsilon_a^{i+1}, \quad \mathbf{u}_r^{*,i+1} = \epsilon_a^{i+1} - \mathbf{a}^{i+1}, \quad (17)$$

并优化

$$\mathcal{L}_a^{i+1}(c) = \|\mathbf{u}_{\theta}^{\text{act}}(\mathbf{a}_r^{i+1}, r \mid \mathbf{x}^{\leq i}, \mathbf{a}^{\leq i}, \mathbf{x}^{i+1}, c) - \mathbf{u}_r^{*,i+1}\|_2^2. \quad (18)$$

对于任务多样 VA 样本，条件仅为语言， $c = \ell$ ，损失为

$$\mathcal{L}_{\text{VA}} = \mathbb{E}_{i,t,r,\epsilon,\epsilon_a} [\mathcal{L}_{\text{fm}}^{i+1}(\ell) + \lambda_a \mathcal{L}_a^{i+1}(\ell)]. \quad (19)$$

对于 HumanGen 样本，视频预测以 $c = \{\mathbf{h}, \ell\}$ 为条件，并通过上下文未来块预测 (IFP) 进行增强。动作损失仍以 ℓ 为条件，因为动作变换器不直接关注人类视频：

$$\mathcal{L}_{\text{ICL}} = \mathbb{E}_{i,t,r,\epsilon,\epsilon_a} [\mathcal{L}_{\text{fm}}^{i+1}(c) + \lambda_a \mathcal{L}_a^{i+1}(\ell) + \lambda_{\text{ifp}} \mathcal{L}_{\text{ifp}}]. \quad (20)$$

推理。在测试时，IFP 模块被移除，Zero-WAM 支持两种任务指定模式。在仅语言模式下，模型以文本指令为条件，即 $c = \ell$ 。在 ICL 模式下，人类视频被编码一次，其标记被缓存为前缀记忆，因此模型以 $c = \{\mathbf{h}, \ell\}$ 为条件，其中语言指令 ℓ 是可选的。在两种模式下，模型首先生成下一个机器人视频块，然后解码对齐的动作块。

4 实验

4.1 实现

实现细节。遵循 LingBot-VA [11]，本文从 Wan-2.2-TI2V-5B [36] 实例化 **Zero-WAM**，并将图像到视频生成骨干网络转换为第 3 节所述的因果视频-动作模型。视频变换器 (Transformer) 沿用 Wan-2.2 骨干网络，隐藏维度为 $d_v = 3072$ ，共 30 层变换器层。动作变换器隐藏维度为 $d_a = 3072$ ，参数由视频分支初始化，并通过 MoT 架构与视频变换器连接。两条流均使用 RoPE 位置编码，ICL 人类视频的高度轴 RoPE 偏移设为 $\Delta_H = 32$ 。本文使用 Wan-2.2 VAE 将机器人视频和人类视频编码为潜在表示。语言指令由 T5 [38] 编码。IFP 模块以时间步长 $s = 2$ 预测 $K = 4$ 个未来机器人视频块，相应的未来预测损失权重为 $(w_1, \dots, w_4) = (0.5, 0.25, 0.15, 0.15)$ 。

训练细节。本文使用第 3 节定义的流匹配视频损失、动作损失和 IFP 损失训练 Zero-WAM。采用 AdamW 优化器 [39]，峰值学习率为 1×10^{-4} ，权重衰减为 0.01。预训练期间，任务多样化 VA 数据与 HumanGen 数据按 1:5 的采样比例抽取。对于非 ICL 样本，以 0.1 的概率丢弃语言指令。对于 ICL 样本，以 0.1 的概率丢弃 ICL




图 3 RoboTwin 2.0 仿真中的未见任务。这些任务涉及未见物体操作、关节物体操作、双手操作和长时程操作。

人类视频潜在表示，并将语言指令丢弃率从 Wan-2.2 默认的 0.1 提高到 0.4，以减少模型从人类视频指令学习时对语言的依赖。预训练期间，机器人视频块大小从 1 到 4 随机采样。预训练共耗时 15,360 GPU 小时。遵循 LingBot-VA，每个 GPU 将不同令牌长度的样本打包为一个序列，并使用注意力掩码隔离不同样本，在保持每个 GPU 最大令牌长度不超过 160K 的同时提高训练吞吐量。

推理细节。预训练的零样本世界-动作模型（Zero-WAM）支持两种推理模式。在仅语言模式下，模型以语言指令为条件，不使用上下文人类视频，视频无分类器引导（CFG）尺度设为 5。在上下文学习（ICL）模式下，模型以上下文人类视频为条件，并禁用语言指令。我们使用引导尺度为 5 的上下文学习无分类器引导 [40]。对于两种模式，推理块大小固定为 2，动作无分类器引导尺度设为 1.0。

4.2 仿真实验

设置。我们在 RoboTwin 2.0 仿真的干净设置中评估零样本跨任务泛化 [22]。RoboTwin 2.0 包含 50 个双手操作任务，每个任务有 50 条机器人轨迹。对于每条轨迹，我们使用所提出的上下文人类视频生成流程生成相应的人类视频指令，形成 HumanGen 数据的仿真上下文学习子集。为评估跨任务泛化，我们在任务级别划分 RoboTwin 2.0：43 个任务用于后训练，7 个任务保留作为未见任务进行评估，因此评估的任务在训练期间不作为机器人演示出现。未见任务 1 为：将物体放在秤上、盖章、打开微波炉、将订书机移到垫子上、将面包放入篮子、放置空杯子、堆叠三个积木。如图 3 所示，这些任务涵盖具有未见物体和目标容器的抓取放置任务、未见关节物体操作以及未见长时程操作。

训练。在 RoboTwin 2.0 上，我们从在任务多样化虚拟智能体（VA）数据和上下文 HumanGen 数据上预训练的检查点初始化零样本世界-动作模型。我们使用 64 个 GPU 进行 4000 步后训练。在后训练期间，我们以 2:10:3 的比例从任务多样化虚拟智能体、HumanGen 和 RoboTwin 数据中联合采样。与预训练一样，每个 GPU 将多个样本打包至最多 160K 个标记。

基线。我们在相同的跨任务协议下与两个视频-动作基线进行比较。由于零样本世界-动作模型（Zero-WAM）是从万相 2.2（Wan-2.2）初始化的，我们通过从万相 2.2-文本图像视频 5B（Wan-2.2-TI2V-5B）初始化、采用相同的专家混合（MoT）因果视频-动作框架、并仅在 43 个已见机器人孪生（RoboTwin）任务上训练，构建了一个直接的基于万相的基线。我们将该基线称为万相-动作（WAN-Action）。我们还与领先的视频-动作模型灵枢机器人-视觉动作（LingBot-VA）进行比较，使用其发布的预训练检查点，并在相同的已见任务上对其进行后训练。两个基线在后训练期间仅使用已见任务的机器人视频-动作轨迹，遵循标准的跨任务设置 [41]。

评估。所有实验均在三个随机种子上进行评估。对于每个种子，我们在仿真中对每个未见任务运行 100 次闭环展开，并计算任务成功率。最终结果报告三个种子上的均值和标准差。对于以人类视频为条件的变体，任务由生成的人类视频指令指定；对于仅语言变体，任务仅由文本指定。

¹ 对于盖章和将订书机移到垫子上，我们略微调整了成功标准，使其更适合跨任务泛化评估。我们对所有方法应用相同的修改标准以确保公平比较，并将发布我们修改后的任务版本。

表 2 在七个未见机器人孪生任务上的零样本跨任务结果。我们报告任务成功率及其在三个评估种子上的宏平均。

Task	WAN-Action	LingBot-VA	Zero-WAM
Place object on scale	3.00±2.16	6.17±4.87	24.67±2.05
Stamp seal	7.33±1.25	3.67±2.49	47.00±4.55
Open microwave	2.26±1.60	29.33±10.66	59.00±2.83
Move stapler to pad	10.67±1.70	23.33±8.22	69.14±2.93
Place bread in basket	15.26±2.55	17.33±6.18	35.00±3.74
Place empty cup	38.33±2.05	42.33±7.85	84.87±0.18
Stack blocks three	0.00±0.00	0.00±0.00	9.00±2.16
Average	10.98±1.07	17.45±1.40	46.95±0.72

表 3 真实世界未见配置评估。我们报告 30 次真实机器人试验的任务成功率。灵枢机器人-视觉动作 (LingBot-VA) 使用语言指令评估，而零样本世界-动作模型 (Zero-WAM) 使用人类视频指令。

Task	Train combos	Train demos	LingBot-VA	Zero-WAM
Object-to-container placement	30	120	43.3	53.3
Three-object sequential manipulation	16	96	10.0	33.3
Two-table-leg insertion	—	36	0.0	16.7

结果。表 2 总结了机器人孪生 (RoboTwin) 的主要结果，每个未见任务一行。三种方法形成了在机器人孪生后训练之前所学内容的有序比较：万相-动作 (WAN-Action) 仅使用已见的机器人孪生任务来适配通用万相 2.2 (Wan-2.2) 视频先验；灵枢机器人-视觉动作 (LingBot-VA) 额外受益于现有的机器人视频-动作预训练；零样本世界-动作模型 (Zero-WAM) 进一步在任务平衡的机器人数据和人类-机器人上下文学习 (ICL) 对上进行了预训练。在七个未见任务上，零样本世界-动作模型 (Zero-WAM) 的平均成功率为 46.95%，而灵枢机器人-视觉动作 (LingBot-VA) 为 17.45%，万相-动作 (WAN-Action) 为 10.98%，分别对应 29.50 和 35.97 个百分点的提升。

改进在未见任务集上表现一致，而非由单一简单任务驱动。零样本世界模型 (Zero-WAM) 在所有七个任务上均优于两个基线，在打开微波炉和印章任务上提升显著，这些任务要求策略从任务描述中推断未见过的关节物体或重定位动力学。在放置空杯任务上，其成功率也达到 84.87%，超过两个基线的两倍。堆叠三个积木仍是最难的未见长时程任务，但零样本世界模型是主要比较中唯一实现非零成功率的方法。这些结果表明，人类视频指令和任务平衡的机器人预训练共同提升了模型执行未见任务动力学的能力。

4.3 真实世界实验

我们在真实的双臂 Franka 机器人上验证零样本世界模型的有效性。我们评估三个任务族：物体到容器放置、三物体顺序操作和双桌腿插入。对于每个任务族，我们收集少量已见任务的机器人演示，以使策略适应真实机器人运动学，同时保留评估任务配置。在测试时，零样本世界模型仅以人类视频指令为条件，不提供语言指令，并在真实机器人上执行未见任务配置，而语言机器人基线 (LingBot-VA) 则提供详细的文本任务描述。

物体到容器放置。机器人必须拾取物体并将其放入目标容器，使用单臂操作或双臂协调。我们收集了来自 30 个物体-容器训练组合的 120 个已见任务演示，以使策略适应 Franka 机器人本体。我们保留部分物体和容器集用于评估，因此每个测试配置至少包含一个在机器人训练演示中未出现的物体或容器。零样本世界模型实现 53.3% 成功率，而语言条件基线 (LingBot-VA) 为 43.3%。



图4 零样本世界模型在人类视频指令下的真实世界定性评估。




图 5 上下文人类视频提示对 RoboTwin 未见任务的影响。柱状图报告任务成功率及其宏平均。

三物体顺序操作。该任务评估策略能否遵循人类视频所指定的长时程操作顺序。场景中包含多个物体与容器，每个测试回合以人类视频指令所示的随机顺序选取三个物体。我们从 16 个训练任务组合中收集了 96 条演示，并同时采集了相应的人类视频指令。在测试阶段，人类视频以任意顺序操作三个物体，包括未见过的物体与容器；零样本世界模型（Zero-WAM）达到 33.3% 成功率，显著优于灵巧机器人视觉-动作模型（LingBot-VA）10.0% 的成功率。

双桌腿插入。该任务测试细粒度的人类视频任务指定能力。任务要求将两条桌腿插入桌面上选定的孔中，人类视频指定哪条彩色桌腿应插入哪个目标孔。我们仅为该精确插入设置收集了 36 条演示。在测试阶段，人类视频指定两条桌腿的目标孔，机器人必须据此完成两次插入。尽管绝对成功率受限于精确物理插入的难度，零样本世界模型在未见过的插入配置上取得成功，而灵巧机器人视觉-动作模型成功率为零。我们还观察到对未见颜色和类型的桌腿与桌面板的成功定性迁移，进一步表明细粒度任务指定从人类视频指令中比仅从语言中更可靠地被遵循。

4.4 消融研究

所有消融实验均在机器人孪生（RoboTwin）环境中进行，使用与主仿真实验相同的 43 个已见任务和 7 个未见任务。机器人孪生支持在固定任务级别划分下进行大规模闭环评估，使消融比较比小规模真实世界试验集更可靠。消融实验隔离了零样本世界模型中的三个因素：人类视频上下文学习（ICL）、逆前向预测（IFP）以及任务均衡的机器人预训练。

上下文人类视频提示的影响。

图 5 通过仅在 43 个已见 RoboTwin 任务的数据上训练所有对比变体，将上下文学习（ICL）的效果与大规模预训练隔离开来。无预训练的 Zero-WAM 从 Wan-2.2 预训练权重初始化，并以 ICL 人类视频作为指令进行训练。WAN-Action 从相同的 Wan-2.2 预训练权重初始化，但在 RoboTwin 训练期间仅使用语言指令。LingBot-VA 也在 RoboTwin 上使用语言指令，但保留了其机器人视频-动作预训练。与 WAN-Action 相比，添加人类视频指令将平均成功率从 10.98% 提高到 36.36%，表明 ICL 提供了超越纯文本条件的任务信息。无预训练的 Zero-WAM 也显著优于 LingBot-VA，后者尽管进行了机器人视频-动作预训练，但平均成功率仅为 17.45%，进一步证明了人类视频指令对于指定未见任务的重要性。然而，所有三个变体在




图 6 在 RoboTwin 未见任务上对任务平衡的机器人预训练和上下文未来块预测的消融。左：任务平衡的机器人数据消融，比较 LingBot-VA 与仅文本的 Zero-WAM 变体。右：IFP 模块消融，比较完整 Zero-WAM 与无 IFP 的 Zero-WAM。雷达轴表示每个任务的成功率和宏平均。

堆叠三个块，而完整的 Zero-WAM 在主实验中取得了非零成功率。这一结果表明，小规模 ICL 训练数据不足以有效解决未见的长时程任务，凸显了大规模任务多样化 ICL 预训练的必要性。

上下文未来块预测的效果。 当使用人类视频作为指令进行训练时，模型可能仍然依赖语言指令和过去的机器人视觉观察来推断下一个机器人视频片段，而没有充分利用上下文人类视频提示。我们的 IFP 目标通过从当前机器人视频表示中监督跨步的未来机器人视频片段来解决这个问题，从而鼓励主视频分支编码人类视频所传达的任务演变。图 6（右）显示，添加 IFP 将七任务平均成功率从 28.55% 提高到 46.95%。在打开微波炉（一个未见过的关节物体操作任务）和盖章（一个未见过的稀有物体重新定位任务）上，提升尤其显著。值得注意的是，在堆叠三个积木（一个未见过的长时程操作任务）上，IFP 打破了零成功率的障碍，将成功率从 0.00% 提高到 9.00%。这些结果表明，IFP 能有效激发从 ICL 数据中学到的跟随人类视频的能力。

任务平衡机器人数据的效果。 最后，我们通过构建一个仅文本的 Zero-WAM 变体，验证了我们的任务级采样策略能改善机器人预训练中的泛化能力，尤其是跨任务迁移。在该变体中，ICL 样本在预训练期间仍然包含，但人类视频条件被屏蔽，因此每个人类-机器人对被简化为普通的文本条件机器人视频-动作样本。这移除了人类视频作为额外任务指定信号，并隔离了任务平衡机器人预训练数据的效果。我们主要与 LingBot-VA 进行比较，因为我们大部分任务采样的机器人数据都包含在 LingBot-VA 使用的完整预训练语料库中。这使得 LingBot-VA 成为评估任务级重新划分和平衡采样是否能在扩展原始预训练分布之外改善跨任务泛化的自然参考。图 6（左）显示，仅文本的 Zero-WAM 变体达到了 39.44% 的七任务平均成功率，比 LingBot-VA 高出 21.99 个百分点。在将订书机移到垫子上、将面包放入篮子、放置空杯子等任务上，提升尤为明显，表明任务平衡的机器人预训练即使在没有人类视频条件的情况下也能改善跨任务迁移。

5 结论与讨论

结论。 本文研究机器人操作中的零样本跨任务泛化，其中策略必须在不收集相应机器人数据或更新任何模型参数的情况下执行未见任务。我们通过因果视频-动作建模来解决这一问题，并认为该设置的关键在于

可扩展的上下文任务接口：大规模生成的人类视频指令，并辅以任务均衡的数据构建。为此，我们构建了 HumanGen，通过可扩展的上下文人类视频生成流程，将任务采样的机器人轨迹转化为语义匹配的人类视频指令，并通过在任务层面采样轨迹，从机器人预训练数据中整理出任务多样化的视觉动作数据。基于这些数据源，Zero-WAM 在同一策略中同时支持语言和人类视频演示作为任务规范。该模型经过训练以预测未来视频和可执行动作，并进一步塑造为遵循上下文人类视频以应对未见任务规范。在 RoboTwin 和真实世界操作中的实验表明，Zero-WAM 能够在仿真中执行未见任务，并在真实世界中执行未见任务配置，而无需任何任务特定的机器人数据或参数更新，这证明可扩展的人类视频指令与任务均衡的机器人预训练数据相结合，是实现通用机器人操作的一条实用途径。

讨论。零样本跨任务泛化对于在开放式真实环境中部署通用机器人策略至关重要。实现这一目标既需要机器人基础策略中更强的可迁移先验，也需要更丰富的任务接口，以便跨多种模态传达意图。人类演示是此类任务规范的自然来源，因此其规模和多样性的持续增长十分重要。尽管本文实验主要聚焦于静态桌面操作，未来工作应将此范式扩展至更复杂、动态和非结构化的环境，包括移动操作和显著更长时程的任务。

在可迁移经验的可用来源中，以自我为中心的人类视频尤为有前景，因为其采集规模可远超机器人演示。然而，其使用仍因人类与机器人在具身、观测和动作方面的差距而变得复杂。本文引入的语义对齐人机数据，或可在丰富的以自我为中心的人类视频与相对稀缺的机器人轨迹之间架起桥梁。通过在任务语义层面建立对应关系，而非要求精确的运动级对齐，这种数据形式可使机器人策略从人类经验中获取广泛的任务知识，同时仅需少得多的机器人数据来监督可执行动作。

6 相关工作

6.1 跨任务机器人操作

跨任务机器人操作评估策略能否在不收集该任务机器人演示的情况下执行未见过的操作任务。与视觉泛化（如改变已见任务周围的场景或物体属性）相比，跨任务泛化更具挑战性，因为模型必须从指令和当前观测中推断出先前未见过的任务条件动态。

视觉-语言-动作（VLA）模型 [42, 43, 3, 44, 5, 6, 45, 46, 47]，如 $\pi_{0.5}$ ，为在异构机器人数据上扩展语言条件操作策略提供了实用的框架。然而，VLA 式扩展尚未弥合跨任务差距，部分原因在于视觉-语言表示空间与机器人动作空间之间仍存在巨大不匹配。AGNOSTOS[41] 在零样本跨任务操作下评估了代表性 VLA 策略，表明它们未能有效应对这一挑战，并通过参考动作序列策略加以缓解，该策略使用来自未见任务的机器人轨迹作为上下文引导。然而，这种变通方法需要在测试时提供未见任务的机器人轨迹，从而增加了测试时成本。

近期，世界动作模型（WAMs）[48, 49, 50, 51, 52, 53, 54, 55, 56, 57] 提供了一个更有前景的方向：它们将未见任务泛化的核心挑战从直接动作泛化转移到未见视频生成，因为先前工作 [58, 59] 已表明，可以从正确预测的未来视频中解码出准确的机器人动作。

6.2 世界动作模型

机器人世界动作模型 [11, 12, 13, 14, 60, 61, 15, 16, 62, 63, 64] 从指令和当前观测中联合预测未来视觉状态（如视频或潜在表示）以及可执行的机器人动作。

一个主要范式是视频-动作建模。LingBot-VA 系列 [11, 12] 通过自回归策略发展了这一方向，该策略将因果视频预测与动作预测耦合，并进一步研究了用于具身控制的原生视频-动作预训练。DreamZero[13] 在视觉域偏移下将世界动作模型评估为零样本策略，表明策略迁移可以受益于生成的未来动态，而不是仅依赖直接的语言到动作预测。EgoWAM[65] 将这一视角扩展到以自我为中心的人类数据，表明世界模型目标（如语义特征或三维运动流）可以改善人到机器人的迁移。

为了使世界动作模型在测试时执行未见过的任务，近期工作探索了测试时训练。WAM-TTT[66] 通过在部署时从原始人类视频更新轻量级记忆来引导冻结的世界动作模型。RoboTTT[67] 使用快速权重测试时训练将长执行历史压缩到策略状态中。这些方法在测试时实现了未见任务的执行，但仍需要通过记忆或快速权重更新进行测试时自适应。相比之下，我们的 Zero-WAM 采取了不同的路径：它将人-机器人上下文学习数据和任务平衡的视频-动作数据构建到预训练和后训练中，使策略能够在测试时直接遵循上下文人类视频指令，实现零样本跨任务泛化。

6.3 用于机器人操作的人类视频数据

人类视频已成为机器人操作的重要数据来源，因为其中包含多样化的物体交互，仅靠机器人难以大规模扩展。近期工作利用大规模自然场景人类视频或人类交互演示来学习与机器人相关的视觉表征、操作先验或策略预训练目标，并在不同程度上与机器人动作对齐 [68, 69, 70, 71, 34, 72, 73, 74, 75]。其他方法则趋向于使用更任务对齐的人类数据，包括成对的、重定向的或联合训练的人机演示，以及自然场景与任务内人类数据的混合 [65, 76, 20, 77, 78, 79, 80]，表明任务对齐的人机数据能够有效缩小人机领域差距。虽然这些工作主要将人类视频用作训练监督或适应数据，另一类方法则直接以人类视频演示作为任务提示来条件化策略 [81, 17, 18, 82, 83, 84, 85, 86, 87, 88]。这使得人类视频成为更直接的任务接口，这一方向与我们对上下文人类视频指令的使用最为接近。然而，现有的视频即提示系统要么覆盖的任务集有限，要么随着任务覆盖范围的扩大需要额外人工采集人类视频。更广泛地看，在这些人类视频的使用方式中，零样本跨任务泛化仍缺乏一种可扩展的数据机制，能够同时提供任务多样性、人机语义对齐和可执行的机器人动作基础：自然场景人类视频提供了广泛的行为覆盖但缺乏对齐的机器人数据，任务对齐的人机数据集在跨任务扩展上成本高昂，而以人类视频为条件的策略往往依赖于由人工先验驱动模块化信息提取与对齐。

我们的零样本世界-动作模型（Zero-WAM）针对这一缺失的数据机制。我们不再逐任务采集人类演示，而是从任务采样的机器人视频-动作数据中自动生成人类生成（HumanGen）数据。由于每个生成的人类视频都与保留可执行动作的机器人轨迹配对，HumanGen 将人类视频指令与任务多样的机器人动态一起扩展，使人类视频任务指定成为零样本跨任务泛化中世界-动作模型训练的可扩展组成部分。

参考文献

- [1] Tom B Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, et al. Language models are few-shot learners, 2020.
- [2] Qingxiu Dong, Lei Li, Damai Dai, Ce Zheng, Jingyuan Ma, Rui Li, Heming Xia, Jingjing Xu, Zhiyong Wu, Tianyu Liu, et al. A survey on in-context learning. *arXiv preprint arXiv:2301.00234*, 2022.
- [3] Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, Ted Xiao, Ashwin Balakrishna, Suraj Nair, Rafael Rafailov, Ethan Foster, Grace Lam, Pannag Sanketi, et al. OpenVLA: An Open-Source Vision-Language-Action Model. *arXiv preprint arXiv:2406.09246*, 2024.
- [4] Quan Vuong, Sergey Levine, Homer Rich Walke, Karl Pertsch, Anikait Singh, Ria Doshi, Charles Xu, Jianlan Luo, Liam Tan, Dhruv Shah, et al. Open x-embodiment: Robotic learning datasets and rt-x models. In *Towards Generalist Robots: Learning Paradigms for Scalable Skill Acquisition@ CoRL2023*, 2023.

- [5] Kevin Black, Noah Brown, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Lachy Groom, Karol Hausman, Brian Ichter, et al. π_0 : A Vision-Language-Action Flow Model for General Robot Control. *arXiv preprint arXiv:2410.24164*, 2024.
- [6] Physical Intelligence, Kevin Black, Noah Brown, James Darpinian, Karan Dhabalia, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, et al. $\pi_{0.5}$: A Vision-Language-Action Model with Open-World Generalization. *arXiv preprint arXiv:2504.16054*, 2025.
- [7] Wei Wu, Fangjing Wang, Fan Lu, He Sun, Shi Liu, Yunnan Wang, Yibin Yan, Yong Wang, Shuailei Ma, Xinyang Wang, Yibin Liu, Shuai Yang, Tianxiang Zhou, Kejia Zhang, Lei Zhou, Cheng Su, Nan Xue, Bin Tan, Han Zhang, Youchao Zhang, Fei Liao, Xing Zhu, Yujun Shen, and Kecheng Zheng. From Foundation to Application: Improving VLA Models in Practice. *arXiv:2607.06403*, 2026. Preprint.
- [8] Haoqi Yuan, Zhixuan Liang, Anzhe Chen, Ye Wang, Haoyang Li, Pei Lin, Yiyang Huang, Zixing Lei, Tong Zhang, Jiazhao Zhang, Jie Zhang, Jingyang Fan, Gengze Zhou, Qihang Peng, Chenxu Lv, Xiaoyue Chen, An Yang, Fei Huang, Junyang Lin, Dayiheng Liu, Jingren Zhou, Chenfei Wu, and Xiong-Hui Chen. Qwen-RobotManip Technical Report: Alignment Unlocks Scale for Robotic Manipulation Foundation Models. *arXiv:2606.17846*, 2026. Preprint.
- [9] Jinliang Zheng, Jianxiong Li, Zhihao Wang, Dongxiu Liu, Xirui Kang, Yuchun Feng, Yinan Zheng, Jiayin Zou, Yilun Chen, Jia Zeng, Ya-Qin Zhang, Jiangmiao Pang, Jingjing Liu, Tai Wang, and Xianyu Zhan. X-VLA: Soft-Prompted Transformer as Scalable Cross-Embodiment Vision-Language-Action Model. *arXiv:2510.10274*, 2025. Preprint.
- [10] NVIDIA, Johan Björck, Fernando Castañeda, Nikita Cherniadev, Xingye Da, Runyu Ding, Linxi Fan, Yu Fang, Dieter Fox, Fengyuan Hu, Spencer Huang, Joel Jang, Zhenyu Jiang, Jan Kautz, Kaushil Kundalia, Lawrence Lao, Zhiqi Li, Zongyu Lin, Kevin Lin, Guilin Liu, Edith Llontop, Loic Magne, Ajay Mandlekar, Avnish Narayan, Soroush Nasiriany, Scott Reed, You Liang Tan, Guanzhi Wang, Zu Wang, Jing Wang, Qi Wang, Jiannan Xiang, Yuqi Xie, Yinzhen Xu, Zhenjia Xu, Seonghyeon Ye, Zhiding Yu, Ao Zhang, Hao Zhang, Yizhou Zhao, Ruijie Zheng, and Yuke Zhu. GR00T N1: An Open Foundation Model for Generalist Humanoid Robots. *arXiv:2503.14734*, 2025. Preprint.
- [11] Lin Li, Qihang Zhang, Yiming Luo, Shuai Yang, Ruilin Wang, Fei Han, Mingrui Yu, Zelin Gao, Nan Xue, Xing Zhu, Yujun Shen, and Yinghao Xu. Causal World Modeling for Robot Control. *arXiv preprint arXiv:2601.21998*, 2026.
- [12] Qihang Zhang, Lin Li, Luyao Zhang, Shuai Yang, Yiming Luo, Shuaiting Li, Ruilin Wang, Junke Wang, Jiahao Shao, Gangwei Xu, et al. Native Video-Action Pretraining for Generalizable Robot Control. *arXiv preprint arXiv:2607.08639*, 2026.
- [13] Seonghyeon Ye, Yunhao Ge, Kaiyuan Zheng, Shenyuan Gao, Sihyun Yu, George Kurian, Suneel Indupuru, You Liang Tan, Chuning Zhu, Jiannan Xiang, et al. World Action Models Are Zero-Shot Policies. *arXiv preprint arXiv:2602.15922*, 2026.
- [14] Gangwei Xu, Qihang Zhang, Jiaming Zhou, Xing Zhu, Yujun Shen, Xin Yang, and Yinghao Xu. Next Forcing: Causal World Modeling with Multi-Chunk Prediction. *arXiv:2606.11187*, 2026. Preprint.
- [15] Tianyuan Yuan, Zibin Dong, Yicheng Liu, and Hang Zhao. Fast-WAM: Do World Action Models Need Test-Time Future Imagination? *arXiv preprint arXiv:2603.16666*, 2026.
- [16] Shalfun Li, Victor Yao, Charles Yang, Truth Qu, Regis Cheng, Ryan Yu, Howard Lu, Newton Von, Vincent Chen, Yohann Tang, Maeve Zhang, Ellie Ma, Gody Li, Sage Yang, Lorian Shu, J. W. Gao, Ethan Chen, Colin Ye, Yu Sun, Elise Mon, PS Zhang, Neo Li, Lily Li, James Wang, Ping Yang, Chris Pan, Lucy Liang, Hang Su, Roy Gan, Hao Wang, and Qian Wang. WALL-WM: Carving World Action Modeling at the Event Joints. *arXiv:2606.01955*, 2026. Preprint.
- [17] Eric Jang, Alex Irpan, Mohi Khansari, Daniel Kappler, Frederik Ebert, Corey Lynch, Sergey Levine, and Chelsea Finn. BC-Z: Zero-Shot Task Generalization with Robotic Imitation Learning. In *Conference on Robot Learning*, pages 991–1002, 2022.
- [18] Vidhi Jain, Maria Attarian, Nikhil J Joshi, Ayzaan Wahid, Danny Driess, Quan Vuong, Pannag R Sanketi, Pierre Sermanet, Stefan Welker, Christine Chan, et al. Vid2Robot: End-to-End Video-Conditioned Policy Learning with Cross-Attention Transformers. *arXiv preprint arXiv:2403.12943*, 2024.

- [19] Pratyusha Sharma, Lekha Mohan, Lerrel Pinto, and Abhinav Gupta. Multiple Interactions Made Easy (MIME): Large Scale Demonstrations Data for Imitation. In *Proceedings of the 2nd Conference on Robot Learning*, volume 87 of *Proceedings of Machine Learning Research*, pages 906–915. PMLR, 2018.
- [20] Simar Kareer, Dhruv Patel, Ryan Punamiya, Pranay Mathur, Shuo Cheng, Chen Wang, Judy Hoffman, and Danfei Xu. EgoMimic: Scaling Imitation Learning via Egocentric Video. *arXiv preprint arXiv:2410.24221*, 2024.
- [21] Hao-Shu Fang, Hongjie Fang, Zhenyu Tang, Jirong Liu, Junbo Wang, Haoyi Zhu, and Cewu Lu. Rh20t: A robotic dataset for learning diverse skills in one-shot. *arXiv preprint arXiv:2307.00595*, 2023.
- [22] Tianxing Chen, Zanzin Chen, Baijun Chen, Zijian Cai, Yibin Liu, Zixuan Li, Qiwei Liang, Xianliang Lin, Yiheng Ge, Zhenyu Gu, Weiliang Deng, Yubin Guo, Tian Nian, Xuanbing Xie, Qiangyu Chen, Kailun Su, Tianling Xu, Guodong Liu, Mengkang Hu, Huan-ang Gao, Kaixuan Wang, Zhixuan Liang, Yusen Qin, Xiaokang Yang, Ping Luo, and Yao Mu. RoboTwin 2.0: A Scalable Data Generator and Benchmark with Strong Domain Randomization for Robust Bimanual Robotic Manipulation. *arXiv:2506.18088*, 2025. Preprint.
- [23] Qingwen Bu, Jisong Cai, Li Chen, Xiuqi Cui, Yan Ding, Siyuan Feng, Shenyuan Gao, Xindong He, Xu Huang, Shu Jiang, et al. Agibot world colosse: A large-scale manipulation platform for scalable and intelligent embodied systems. *arXiv preprint arXiv:2503.06669*, 2025.
- [24] Yang Tian, Yuyin Yang, Yiman Xie, Zetao Cai, Xu Shi, Ning Gao, Hangxu Liu, Xuekun Jiang, Zherui Qiu, Feng Yuan, Yaping Li, Ping Wang, Junhao Cai, Jia Zeng, Hao Dong, and Jiangmiao Pang. InternData-A1: Pioneering High-Fidelity Synthetic Data for Pre-training Generalist Policy. *arXiv:2511.16651*, 2025. Preprint.
- [25] Shihan Wu, Xuecheng Liu, Shaoxuan Xie, Pengwei Wang, Xinghang Li, Bowen Yang, Zhe Li, Kai Zhu, Hongyu Wu, Yiheng Liu, Zhaoye Long, Runtian Xu, Yue Wang, Chong Liu, Dihan Wang, Ziqiang Ni, Xiang Yang, You Liu, Ruoxuan Feng, Lei Zhang, et al. RoboCOIN: An Open-Sourced Bimanual Robotic Data Collection for Integrated Manipulation. *arXiv:2511.17441*, 2025. Preprint.
- [26] Kun Wu, Chengkai Hou, Jiaming Liu, Zhengping Che, Xiaozhu Ju, Zhuqin Yang, Meng Li, Yinuo Zhao, Zhiyuan Xu, Guang Yang, Shichao Fan, Xinhua Wang, Fei Liao, Zhen Zhao, Guangyu Li, Zhao Jin, Lecheng Wang, Jilei Mao, Ning Liu, Pei Ren, Qiang Zhang, Yaoxu Lyu, Mengzhen Liu, Jingyang He, Yulin Luo, Zeyu Gao, Chenxuan Li, Chenyang Gu, Yankai Fu, Di Wu, Xingyu Wang, Sixiang Chen, Zhenyu Wang, Pengju An, Siyuan Qian, Shanghang Zhang, and Jian Tang. RoboMIND: Benchmark on Multi-embodiment Intelligence Normative Data for Robot Manipulation. In *Proceedings of Robotics: Science and Systems*, Los Angeles, CA, USA, 2025.
- [27] Google DeepMind. Gemini 3.1 Pro. Model card, <https://deepmind.google/models/model-cards/gemini-3-1-pro/>, February 2026.
- [28] Qwen Team. Qwen3.6-Plus: Towards real world agents. Official blog, <https://qwen.ai/blog?id=qwen3.6>, April 2026.
- [29] Google DeepMind. Gemini 3.1 Flash Image. Model card, <https://deepmind.google/models/model-cards/gemini-3-1-flash-image/>, February 2026.
- [30] Bing Zhao, Chenfei Wu, Deqing Li, Hao Meng, Jiahao Li, Jie Zhang, Jingren Zhou, Junyang Lin, Kaiyuan Gao, Kuan Cao, et al. Qwen-Image-2.0 technical report. *arXiv:2605.10730*, 2026. Preprint.
- [31] Alibaba Cloud. Wan2.7: Text-to-video api reference. Alibaba Cloud Model Studio documentation, <https://www.alibabacloud.com/help/en/model-studio/text-to-video-api-reference>, July 2026.
- [32] Kuaishou Technology. Kling AI launches 3.0 model, ushering in an era where everyone can be a director. Official press release, <https://ir.kuaishou.com/node/11216/pdf>, February 2026.
- [33] Modi Shi, Shijia Peng, Jin Chen, Haoran Jiang, Tianyu Li, Di Huang, Ping Luo, Hongyang Li, and Li Chen. EgoHumanoid: Unlocking In-the-Wild Loco-Manipulation with Robot-Free Egocentric Demonstration. *arXiv preprint arXiv:2602.10106*, 2026.
- [34] Ruijie Zheng, Dantong Niu, Yuqi Xie, Jing Wang, Mengda Xu, Yunfan Jiang, Fernando Castañeda, Fengyuan Hu, You Liang Tan, Letian Fu, Trevor Darrell, Furong Huang, Yuke Zhu, Danfei Xu, and Linxi Fan. EgoScale: Scaling Dexterous Manipulation with Diverse Egocentric Human Data. *arXiv:2602.16710*, 2026. Preprint.
- [35] Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matt Le. Flow matching for generative modeling. In *International Conference on Learning Representations*, 2023.
- [36] Wan Team, Ang Wang, Baole Ai, Bin Wen, Chaojie Mao, Chen-Wei Xie, Di Chen, Feiwu Yu, Haiming Zhao, Jianxiao Yang, Jianyuan Zeng, Jiayu Wang, Jingfeng Zhang, Jingren Zhou, Jinkai Wang, Jixuan Chen, Kai Zhu,

- Kang Zhao, Keyu Yan, Lianghua Huang, et al. Wan: Open and Advanced Large-Scale Video Generative Models. arXiv:2503.20314, 2025. Preprint.
- [37] Jianlin Su, Murtadha Ahmed, Yu Lu, Shengfeng Pan, Bo Wen, and Yunfeng Liu. RoFormer: Enhanced Transformer with Rotary Position Embedding. *Neurocomputing*, 568:127063, 2024.
 - [38] Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li, and Peter J. Liu. Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer. *Journal of Machine Learning Research*, 21(140):1–67, 2020.
 - [39] Ilya Loshchilov and Frank Hutter. Decoupled Weight Decay Regularization. In *International Conference on Learning Representations*, 2019.
 - [40] Jonathan Ho and Tim Salimans. Classifier-Free Diffusion Guidance. arXiv:2207.12598, 2022. Preprint.
 - [41] Jiaming Zhou, Ke Ye, Jiayi Liu, Teli Ma, Zifan Wang, Ronghe Qiu, Kun-Yu Lin, Zhilin Zhao, and Junwei Liang. Exploring the Limits of Vision-Language-Action Manipulations in Cross-Task Generalization. *arXiv preprint arXiv:2505.15660*, 2025.
 - [42] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Joseph Dabis, Chelsea Finn, Keerthana Gopalakrishnan, Karol Hausman, Alex Herzog, Jasmine Hsu, et al. RT-1: Robotics Transformer for Real-World Control at Scale. *arXiv preprint arXiv:2212.06817*, 2022.
 - [43] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Xi Chen, Krzysztof Choromanski, Tianli Ding, Danny Driess, Avinava Dubey, Chelsea Finn, et al. RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control. *arXiv preprint arXiv:2307.15818*, 2023.
 - [44] Octo Model Team, Dibya Ghosh, Homer Walke, Karl Pertsch, Kevin Black, Oier Mees, Sudeep Dasari, Joey Hejna, Tobias Kreiman, Charles Xu, et al. Octo: An Open-Source Generalist Robot Policy. *arXiv preprint arXiv:2405.12213*, 2024.
 - [45] Xiao-Ming Wu, Bin Fan, Kang Liao, Jian-Jian Jiang, Runze Yang, Yihang Luo, Zhonghua Wu, Wei-Shi Zheng, and Chen Change Loy. VLANeXt: Recipes for building strong VLA models. In *International Conference on Machine Learning*, 2026.
 - [46] Hengyi Xie, Chenfei Yao, Xianjin Wu, Yingying Zhu, Dingkan Liang, Xiang Bai, and Han Ding. TurboVLA: Real-time vision-language-action model at 32 hz on an RTX 4090 with < 1 GB VRAM. arXiv:2607.27205, 2026. Preprint.
 - [47] Ryan Yu, Pushi Zhang, Starrick Liu, Brae Liu, Miracle Kang, Shalfun Li, Lights Shi, Ellie Ma, Ping Yang, Chris Pan, Jerry Chen, Dongxiu Liu, Rain Sun, Miles Guo, Byron Zhang, Hugo Zhou, Zach Xu, Vincent Chen, Harrison Huang, James Wang, Dance Kuzi, Andy Zhai, Hang Su, Roy Gan, Lucy Liang, Hao Wang, and Qian Wang. Wall-OSS-0.5 technical report. arXiv:2605.30877, 2026. Preprint.
 - [48] Mengqi Zhang, Sahil Khose, Simar Kareer, Yuchen Song, Unnat Jain, and Judy Hoffman. DeVA: Decoupled video-action model with physical guidance for robot policy learning. arXiv:2607.24159, 2026. Preprint.
 - [49] Weiheng Zhao, Haoyi Jiang, Xin Shi, Liu Liu, Fan Huang, Zhizhong Su, Wei Sui, and Xinggang Wang. Faster-WAM: Efficient inference-time future conditioning for robust world action models. arXiv:2608.04404, 2026. Preprint.
 - [50] Liheng Ma, Rui Heng Yang, Zhanguang Zhang, Mateo Clemente, Ziwen Hu, Tongtong Cao, and Yingxue Zhang. Faster-WAM: Do world action models need deep action modules? arXiv:2608.02365, 2026. Preprint.
 - [51] Yao Feng, Hengkai Tan, Xinyi Mao, Chendong Xiang, Guodong Liu, Shuhe Huang, Hang Su, and Jun Zhu. Vidar: Embodied video diffusion model for generalist manipulation. arXiv:2507.12898, 2025. Preprint.
 - [52] Yucheng Hu, Yanjiang Guo, Pengchao Wang, Xiaoyu Chen, Yen-Jen Wang, Jianke Zhang, Koushil Sreenath, Chaochao Lu, and Jianyu Chen. Video Prediction Policy: A generalist robot policy with predictive visual representations. arXiv:2412.14803, 2025. Preprint.
 - [53] Shuang Li, Yihuai Gao, Dorsa Sadigh, and Shuran Song. Unified Video Action Model. arXiv:2503.00200, 2025. Preprint.
 - [54] Angen Ye, Boyuan Wang, Chaojun Ni, Guan Huang, Guosheng Zhao, Hao Li, Hengtao Li, Jie Li, Jindi Lv, Jingyu Liu, Min Cao, Peng Li, Qiuping Deng, Wenjun Mei, Xiaofeng Wang, Xinze Chen, Xinyu Zhou, Yang Wang, Yifan Chang, Yifan Li, Yukun Zhou, Yun Ye, Zhichao Liu, and Zheng Zhu. GigaWorld-Policy: An efficient action-centered world-action model. arXiv:2603.17240, 2026. Preprint.

- [55] Jiangran Lyu, Kai Liu, Xuheng Zhang, Haoran Liao, Yusen Feng, Wenxuan Zhu, Tingrui Shen, Jiayi Chen, Jiazhao Zhang, Yifei Dong, Wenbo Cui, Senmao Qi, Shuo Wang, Yixin Zheng, Mi Yan, Xuesong Shi, Haoran Li, Dongbin Zhao, Ming-Yu Liu, Zhizheng Zhang, Li Yi, Yizhou Wang, and He Wang. LDA-1B: Scaling latent dynamics action model via universal embodied data ingestion. *arXiv:2602.12215*, 2026. Preprint.
- [56] Yilun Du, Mengjiao Yang, Bo Dai, Hanjun Dai, Ofir Nachum, Joshua B. Tenenbaum, Dale Schuurmans, and Pieter Abbeel. Learning Universal Policies via Text-Guided Video Generation. *arXiv:2302.00111*, 2023. Preprint.
- [57] Junbang Liang, Pavel Tokmakov, Ruoshi Liu, Sruthi Sudhakar, Paarth Shah, Rares Ambrus, and Carl Vondrick. Video Generators are Robot Policies. *arXiv:2508.00795*, 2025. Preprint.
- [58] Jonas Pai, Liam Achenbach, Victoriano Montesinos, Benedek Forrai, Oier Mees, and Elvis Nava. mimic-video: Video-action models for generalizable robot control beyond VLAs. *arXiv preprint arXiv:2512.15692*, 2025.
- [59] Mimic Robotics. Introducing FLUX-mimic: Scaling Video-Action Models for General Purpose Dexterity. Official blog, <https://www.mimicrobotics.com/blog/introducing-flux-mimic>, 2026.
- [60] Mingyu Liu, Jiuhe Shu, Hui Chen, Zeju Li, Canyu Zhao, Jiange Yang, Shen Yuan Gao, Hao Chen, and Chunhua Shen. STAMO: Unsupervised learning of generalizable robot motion from compact state representation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 35014–35024, 2026.
- [61] Yue Su, Sijin Chen, Haixin Shi, Mingyu Liu, Zhengshen Zhang, Ningyuan Huang, Weiheng Zhong, Zhengbang Zhu, Yuxiao Liu, and Xihui Liu. World Guidance: World modeling in condition space for action generation. *arXiv preprint arXiv:2602.22010*, 2026.
- [62] MotuBrain Team, Chendong Xiang, Fan Bao, Haitian Liu, Hengkai Tan, Hongzhe Bi, James Li, Jiabao Liu, Jingrui Pang, Kiro Jing, Louis Liu, Mengchen Cai, Rongxu Cui, Ruowen Zhao, Runqing Wang, Shuhe Huang, Yao Feng, Yinze Rong, Zeyuan Wang, and Jun Zhu. MotuBrain: An advanced world action model for robot control. *arXiv:2604.27792*, 2026. Preprint.
- [63] Pengfei Zhou, Shengcong Chen, Di Chen, Jiaxu Wang, Rongjun Jin, Bingwen Zhu, Yike Pan, Songen Gu, Kuanning Wang, Shufeng Nan, Xingyu Qiu, Chenhao Qiu, Pu Yang, Yunuo Cai, Jianxiong Gao, Yifan Li, Yanwei Fu, Xiangyu Yue, Zhi Chen, and Jianlan Luo. τ_0 -WM: A unified video-action world model for robotic manipulation. *arXiv:2606.01027*, 2026. Preprint.
- [64] Teli Ma, Jia Zheng, Zifan Wang, Chunli Jiang, Andy Cui, Junwei Liang, and Shuo Yang. DiT4DiT: Jointly modeling video dynamics and actions for generalizable robot control. *arXiv:2603.10448*, 2026. Preprint.
- [65] Baoyu Li, Xinchun Yin, Mengying Lin, Yixin Zhang, and Danfei Xu. EgoWAM: World Action Models Beyond Pixels with In-the-Wild Egocentric Human Data. *arXiv preprint arXiv:2607.08436*, 2026.
- [66] Yusen Feng, Bingchen Han, Jiangran Lyu, Kai Liu, Yixin Zheng, Yuxuan Wan, Weiheng Liu, Sun Han, Ruiqin Li, Yulong Zhang, et al. WAM-TTT: Steering World-Action Models by Watching Human Play at Test Time. *arXiv preprint arXiv:2607.06988*, 2026.
- [67] Yunfan Jiang, Yevgen Chebotar, Ruijie Zheng, Fengyuan Hu, Yunhao Ge, Jimmy Wu, Tianyuan Dai, Scott Reed, Li Fei-Fei, Yuke Zhu, et al. RoboTTT: Context Scaling for Robot Policies. *arXiv preprint arXiv:2607.15275*, 2026.
- [68] Suraj Nair, Aravind Rajeswaran, Vikash Kumar, Chelsea Finn, and Abhinav Gupta. R3m: A universal visual representation for robot manipulation. *arXiv preprint arXiv:2203.12601*, 2022.
- [69] Shikhar Bahl, Abhinav Gupta, and Deepak Pathak. Human-to-robot imitation in the wild. *arXiv preprint arXiv:2207.09450*, 2022.
- [70] Yixuan Luo, Zhe Yang, Hengyuan Zhao, Zecheng Deng, Zichen Peng, Yingfeng Liao, Yecheng Jason Yang, Bolei Zhou, Alan Yuille, Yue Wang, et al. Being-H0: Vision-Language-Action Pretraining from Large-Scale Human Videos. *arXiv preprint arXiv:2507.15597*, 2025.
- [71] Qixiu Li, Yu Deng, Yaobo Liang, Lin Luo, Lei Zhou, Chengtang Yao, Lingqi Zeng, Zhiyuan Feng, Huizhi Liang, Sicheng Xu, Yizhong Zhang, Xi Chen, Hao Chen, Lily Sun, Dong Chen, Jiaolong Yang, and Baining Guo. Scalable vision-language-action model pretraining for robotic manipulation with real-life human activity videos. *arXiv preprint arXiv:2510.21571*, 2025.
- [72] Wei-Jin Huang, Yue-Yi Zhang, Yi-Lin Wei, Zhi-Wei Xia, Juantao Tan, Yuan-Ming Li, Zhilin Zhao, and Wei-Shi Zheng. Beyond Mimicry: Learning whole-body human-humanoid interaction from human-human demonstrations. In *IEEE Conference on Computer Vision and Pattern Recognition*, 2026.

- [73] Zhi Wang, Botao He, Kelin Yu, Seungjae Lee, Ruohan Gao, Furong Huang, and Yiannis Aloimonos. HumanEgo: Zero-shot robot learning from minutes of human egocentric videos. *arXiv:2605.24934*, 2026. Preprint.
- [74] Sicheng Xie, Haidong Cao, Zejia Weng, Zhen Xing, Haoran Chen, Shiwei Shen, Jiaqi Leng, Zuxuan Wu, and Yu-Gang Jiang. Human2Robot: Learning robot actions from paired human-robot videos. *arXiv:2502.16587*, 2025. Preprint.
- [75] Ye Wang, Pei Lin, Xiong-Hui Chen, Haoqi Yuan, Zhixuan Liang, Yiyang Huang, Anzhe Chen, Zixing Lei, Jie Zhang, Tao Zhang, Haoyang Li, Tong Zhang, Chenxi Xiao, Ziyuan Jiao, and Qin Jin. Ego2Robot: Scalable robot data synthesis from egocentric human data. *arXiv:2608.02580*, 2026. Preprint.
- [76] Jiaming Zhou, Teli Ma, Kun-Yu Lin, Zifan Wang, Ronghe Qiu, and Junwei Liang. Mitigating the human-robot domain discrepancy in visual pre-training for robotic manipulation. *arXiv preprint arXiv:2406.14235*, 2024.
- [77] Shenzhe Cai, David Gaddy, Kevin Lin, Homer Walke, Mohan Kumar Srirama, Karl Pertsch, Bingyi Kang, Kuan Fang, Joseph J Lim, Shikhar Bahl, et al. In-N-On: Unified Human-to-Robot Policy Learning with In-the-wild and On-task Human Videos. *arXiv preprint arXiv:2511.15704*, 2025.
- [78] Physical Intelligence. Emergence of Human to Robot Transfer in VLAs. Technical report, https://www.pi.website/download/human_to_robot.pdf, 2025.
- [79] Bhawna Paliwal, Haritheja Etukuru, William Liang, Pieter Abbeel, Nur Muhammad Mahi Shafiullah, and Jitendra Malik. Do as I Do: Dexterous Manipulation Data from Everyday Human Videos. *arXiv preprint arXiv:2606.19333*, 2026.
- [80] Huayi Zhou, Ruixiang Wang, Yunxin Tai, Yueci Deng, Guiliang Liu, and Kui Jia. You Only Teach Once: Learn one-shot bimanual robotic manipulation from video demonstrations. *arXiv preprint arXiv:2501.14208*, 2025.
- [81] Tianhe Yu, Chelsea Finn, Annie Xie, Sudeep Dasari, Tianhao Zhang, Pieter Abbeel, and Sergey Levine. One-Shot Imitation from Observing Humans via Domain-Adaptive Meta-Learning. In *Robotics: Science and Systems*, 2018.
- [82] Ke Ye, Jiaming Zhou, Yuanfeng Qiu, Jiayi Liu, Shihui Zhou, Kun-Yu Lin, and Junwei Liang. From Watch to Imagine: Steering long-horizon manipulation via human demonstration and future envisionment. *arXiv:2509.22205*, 2025. Preprint.
- [83] Austin Patel, Ben Pekarek, Joel Enrique Castro Hernandez, and Shuran Song. Behavior Prompting Policy: Demonstrations as prompts for manipulation. *arXiv:2606.30457*, 2026. Preprint.
- [84] Generalist Team. GEN-1.5: Embodied foundation models are one-shot learners. *Generalist AI Blog*, 2026. <https://generalistai.com/blog/gen-1.5>.
- [85] Skild AI. Introducing S1: In-context learning for robotics. Official blog, <https://skild.ai/blogs/s1>, August 2026.
- [86] Dyna Robotics. Dyna-2: A 1-million-hour scaling law for world-action models. Official research report, <https://www.dyna.co/dyna-2>, August 2026.
- [87] Guangyan Chen, Meiling Wang, Te Cui, Zichen Zhou, Qi Shao, Shalfun Li, Hang Su, Roy Gan, Hao Wang, Mengyin Fu, Yi Yang, and Yufeng Yue. HOST: Robots acquire manipulation skills in seconds from a single human video. *arXiv:2607.20033*, 2026. Preprint.
- [88] Rhoda AI Team. Causal video models are data-efficient robot policy learners. *Rhoda AI Blog*, 2026. <https://www.rhoda.ai/research/direct-video-action>.