

Zeva: 面向可泛化具身操作的情境因果学习

Fu Chen^{*}, Xin Ding^{*,†}, Bingjia Huang, Xiangyu Li, Mingju Wang, Jiawei He
Kun Li, Wei Sun, Yunxin Liu, Hao Wu^{†,‡}, Ting Cao^{†,§}

Institute for AI Industry Research (AIR), Tsinghua University; Z-Trans AI

^{*}Co-first authors [†]Corresponding authors [§] Project lead [‡]Work done during a visit to AIR, Tsinghua
Project Page: <https://air-embodied-brain.github.io/Zeva>

Zeva: In-Context Causal Interaction Learning




图 1. Zeva 通过情境因果学习 (ICCL) 实现自我进化的具身智能。Zeva 通过提取动作引发的因果转移、维护双时间尺度交互记忆以及检索因果情境用于情境策略自适应，学习机器人动作与结果状态变化之间的因果关系。无需参数更新，Zeva 使冻结策略能够通过自我进化和人类引导的经验注入逐步改进，实现强大的真实世界性能以及超越任务特定示范的跨任务知识迁移。

摘要——由于真实世界中不可见的物理条件，仅通过预训练难以实现可泛化的具身操作。我们认为机器人需要在真实世界部署过程中即时从自身的物理交互中学习，并利用这些知识指导后续动作。我们提出 Zeva，这是首个在保持策略模型冻结的同时，使机器人能够从自身物理交互经验中进行情境学习的框架。Zeva 采用因果交互提取器将已执行的动作及其引发的状态变化编码为因果交互信号，并存储在双时间尺度因果记忆中。对于后续动作，从记忆中检索相关的因果交互信号，并作为情境注入冻结的策略模型。仿真实验

和真实世界操作表明，Zeva 在对比的前沿视觉语言动作模型（VLA）和世界动作模型（WAM）中取得了最佳性能，更重要的是，在部署过程中无需梯度更新即可实现自我进化。随着机器人积累交互经验，其成功率持续提升。此外，所获得的交互经验可以跨任务泛化。索引词——具身基础模型、交互记忆、测试时扩展、因果表示

I. 引言

可泛化的交互密集型操作是具身智能的核心挑战。具身基础模型，

包括视觉语言动作模型（VLA）和世界动作模型（WAM）在内的方法已朝着这一目标快速推进 [1] – [9]，但在物理世界中的部署仍然脆弱。部署时，机器人不可避免地会遇到预训练期间不存在的物理条件，例如新颖的物体几何形状、接触动力学、视觉变化以及具体执行错误。这些条件与连续的高维机器人状态和动作相互作用，导致相似的动作产生显著不同的结果。因此，仅靠预训练难以覆盖物理交互的多样性。为了实现可泛化的具身操作，我们认为机器人应在执行过程中即时从自身的物理交互经验中学习，即学习其动作与引发的状态变化之间的因果关系，并将其应用于后续动作。最近的预训练后适应方法已开始朝这个方向发展，但仍存在差距。测试时训练方法，如 RoboTTT[10] 和 WAM-TTT[11]，通过测试时梯度更新将部署历史转换为自适应快速权重或记忆模块。这使得每次交互的动作和状态变化结构保持隐式。最近的上下文机器人学习器，如 GEN-1.5[12] 和 Skild S1[13]，则保持模型权重固定，并从上下文中的一个或几个演示中推断新任务。然而，这种形式的上下文学习主要针对任务泛化，而非即时交互学习。我们提出 Zeva，这是第一个能够从机器人自身物理交互经验中进行上下文学习的框架，旨在实现真实部署中的泛化具身操作。Zeva 在部署时保持策略模型冻结，但在每个动作步骤中提取动作与状态变化之间的因果关系，并将这些知识作为上下文检索，用于后续动作生成。这使得同一个冻结策略能够在反复自我尝试中适应多样化的现实世界物理条件，并表现出自我进化，即尝试次数越多，成功率越高。Zeva 通过三个阶段将这一思想实现为上下文因果学习（ICCL）。首先，因果交互提取使用因果转换编码器（CTE）将视觉潜在变量、动作编码和观察到的效果整合为因果交互状态，然后将其投影为任务阶段令牌和因果交互信号。其次，双时间尺度因果记忆组织这些信号以进行部署时适应：简要交互轨迹（BIT）捕获最近一次尝试内的动态，而持久

交互记忆（PIM）通过基于相似度的合并，整合同一回合内多次尝试中的有用证据。第三，上下文策略注入检索阶段匹配的交互证据，并为冻结的基础策略构建因果提示。在部署过程中，所有模型参数保持冻结；仅在线更新交互记忆。我们在 RoboCasa365-Atomic5 和真实世界化学操作基准 ChemLab-Evo 上使用 ARX 机械臂评估 Zeva。主要结果为：（1）Zeva 在对比的前沿方法中取得了最高的成功率

VLA 和 WAM 模型在 RoboCasa365-Atomic5 上达到 76.8%。（2）Zeva 在真实世界 ChemLab-Evo 的所有三个难度级别上均取得了最佳成功率。（3）Zeva 从其自身的交互经验中展现出成功率扩展：在 RoboCasa365-Atomic5 上，累计成功率从首次尝试的 26% 提高到四次重复尝试内的 73%，而 ChemLab-Evo 在多次尝试中显示出相同的扩展趋势。（4）Zeva 还从人类遥控操作演示中展现出上下文学习能力，与仅从自身交互中学习相比，性能进一步提升高达 15%。我们的贡献总结如下：• 我们将真实世界部署中的具身动作泛化形式化为上下文因果学习，其中冻结的机器人策略在测试时无需权重更新即可从其自身的物理交互经验中学习。• 我们提出 Zeva，它结合了因果交互提取、双时间尺度因果记忆和上下文策略注入，用于在重复尝试中实现无梯度的自我进化。• 我们在仿真和真实世界操作中验证了 Zeva，展示了跨机器人尝试的成功率提升，以及与前沿具身策略模型相比最强的成功率。

II. 相关工作

A. 视觉-语言-动作与世界-动作基础模型 VLA 模型将视觉-语言骨干与动作生成头相结合，直接从示范数据中学习观测到动作的映射；代表性工作包括 OpenVLA [1]、 π_0 [2] 及其后续工作 $\pi_{0.5}$ [14] 和 $\pi_{0.6}^*$ [15]。世界-动作模型（WAMs）进一步将动作生成与未来视觉预测统一起来，通过大规模视频预训练吸收物理先验 [16]、[17]，将预训练视频扩散模型适配为联合去噪未来帧和动作 [7]、[9]，或在因果注意力掩码下自回归地交错视频和动作标记 [8]。所有这些模型都需要大规模预训练以获得可泛化的先验，且其权重在部署后保持不变，因此其能力上限由预训练语料决定。本文采用 Cosmos3 的 [18] 整流流动作生成头作为策略骨干，但通过外部自进化机制而非预训练规模在部署后获得持续适应。

B. 行为与潜在动作表示学习

为了缓解高维观测到动作映射引起的分布偏移，一类工作 [19] – [24] 学习低维行为表示：ALAM [25] 和 LAPA [26] 分别通过代数一致性约束和逆动力学重建从未标注视频中学习潜在动作编码；BehaviorVLA [27] 将轨迹编码为场景无关的全局原型和在线更新的局部相位；UniVLA [28]




图 2. Zeva 框架的详细架构。Zeva 通过三个主要组件将因果交互智能集成到冻结的基础策略中：(1) 因果转移编码器，将动作-效果对映射为潜在因果信号；(2) 双时间尺度因果记忆，由用于尝试内动态的短暂交互轨迹（BIT）和用于跨尝试经验的持久交互记忆（PIM）组成；(3) 因果提示注入，将检索到的相位匹配证据作为上下文提示注入到变换器的自注意力层中，以指导基于扩散的动作生成。

从无动作标签的视频中，跨任意具身形态和视角推导出以任务为中心的潜在动作表征。这些方法表明，低维行为表征优于高维直接映射，但在所有情况下，表征空间在部署前就已固定，无法从实际部署中积累交互经验，这使得它们难以在分布持续变化时保持有效。

C. 记忆增强型机器人策略

另一类工作为策略配备在线记忆，以处理长时程依赖关系。MemoryVLA [29] 维护一个感知-认知记忆库，并通过检索-融合-巩固机制处理非马尔可夫控制；MEM [30] 将短期视频记忆与基于语言的长期事件摘要相结合，以支持持续十分钟以上的任务；DIM-WAM [31] 和 MemoryWAM [32] 分别通过多类型历史事件库和滑动窗口加锚帧机制压缩视觉历史。在每种情况下，记忆内容都由观测层面或语义层面的历史片段组成。要确定在一次失败尝试中某个动作使状态朝哪个方向偏移，以及在下一回合的下一尝试中应如何调整该动作，就需要显式地跨尝试边界保留动作-状态变化关系，而仅靠感知侧历史无法捕捉这一点。

D. 部署时自适应与经验驱动的自我改进

与我们的动机最接近的一类工作使策略能够从自身部署经验中改进。 $\pi_{0.6}^*$ (RE-CAP) [15] 和 VLA-RL [33] 通过自主推演上的离线或在线强化学习来更新策略。然而，它们基于梯度的优化周期过慢，无法在连续尝试之间自适应策略，并且容易发生能力崩溃。RoboTTT [10] 和 WAM-TTT [11] 通过测试时梯度更新轻量级快速权重或记忆模块来加速自适应。尽管如此，自适应延迟仍远超单次尝试的时间尺度，而且 WAM-TTT 还依赖人类演示视频作为更新来源，这使智能体无法通过自身交互经验自主探索和改进。

III. 方法

A. 问题表述：上下文因果学习

我们考虑一个具身智能体，它必须泛化到新颖 $\mathcal{T}_{\text{任务}} \sim P(\mathcal{T})$ 通过与环境交互进行上下文学习。与标准模仿学习不同，我们的目标是上下文因果学习 (In-Context Causal Learning, ICCL)

上下文因果学习 (ICCL)，智能体应在单个回合内、不更新权重的情况下，推断环境的因果结构，特别是其动作与状态变化之间的关系 ($\nabla_{\theta} \pi = 0$)。形式上，在第 r 次尝试中，策略 π 利用从先前交互中提取的因果上下文 $\mathcal{M}_{r-1}$ 。目标是在未见任务上最大化成功率，通过

最小化预测因果效应与实际因果效应之间的差异：

$$\mathcal{L}_{ICCL} = \mathbb{E}_\tau [\|\Delta s_\tau - \text{Inference}(\pi(o_\tau, \mathcal{M}_{\tau-1}))\|] \quad (1)$$

其中 $\mathcal{M}$ 充当“因果提示”，引导冻结的基础模型适应新的物理动力学。1) 因果上下文作为交互证据：为实现这一目标，我们将交互经验定义为一组交互三元组。在每个时间步 τ ，智能体动作 u_τ 被视为与环境的交互，由此产生的视觉状态变化 $\Delta s_\tau = s_{\tau+k} - s_\tau$ 是其效应。因果交互单元 ξ_τ 定义为：

$$\xi_\tau = \phi(s_\tau, u_\tau, \Delta s_\tau) \quad (2)$$

因果上下文 $\mathcal{M}$ 是这些单元 ξ 的有组织集合。通过以 $\mathcal{M}$ 为条件，冻结策略 $\pi(a_\tau | o_\tau, g, \mathcal{M})$ 执行隐式系统辨识。它从过去的交互信号中推断潜在的环境属性，如物体质量或关节约束，从而将其动作策略泛化到未见过的物理配置。

B. Zeva 概述

为实现 ICCL 目标，我们提出 Zeva，一个将原始交互转化为双时间尺度因果记忆的框架。Zeva 由三部分组成：（1）因果

交互提取，将动作与效果映射至潜空间，（2）双时间尺度记忆管理，用于组织经验以供检索，以及（3）上下文

策略注入，为基础模型提供因果提示。图??展示了这些组件如何与双路径基础策略耦合。自回归路径编码多模态上下文，而扩散路径生成连续的机器人动作。对于每个执行的转移，CTE 提取一个阶段令牌和一个因果交互信号：简要交互轨迹提供最近一次尝试内的证据，而持久交互记忆检索跨尝试累积的阶段匹配证据。由此产生的因果提示条件化扩散路径的全注意力块，使策略能够通过上下文改变其动作策略，同时保持所有模型参数固定。

C. 第一部分：因果交互提取

为了弥合原始像素与因果推理之间的差距，我们使用因果转移编码器（CTE）将交互映射到潜因果空间。a) 交互重现：在每个时间步 τ ，我们提取三个瞬态信号：视觉潜变量 s_τ 、动作编码 u_τ 和观察到的效果 d_τ 。受轨迹级行为表示 [27] 的启发，我们通过门控递归将这些信号整合为因果交互状态 B_τ ：

$$B_\tau = \text{GRU}(B_{\tau-1}, [s_\tau; u_\tau; d_\tau]), \quad B_0 = F_{\text{init}}(g, s_0) \quad (3)$$

状态 B_τ 被投影为两个组件：表示任务进展的阶段令牌 p_τ 和表征动态的因果交互信号 e_τ 。它们共同构成如第 III-A 节所定义的因果交互单元 $\xi_\tau = (p_\tau, e_\tau)$ 。

b) 学习目标：我们使用多目标损失优化因果转移编码器，以确保 e_τ 捕获物理因果性：

- **因果效应预测** ($\mathcal{L}_{\text{effect}}$)：该目标解码 e_τ 与候选动作以预测视觉状态变化 Δs_τ ，将信号锚定于物理效应。

- **任务身份聚类** ($\mathcal{L}_{\text{task}}$)：一种监督对比损失，将同一任务的片段聚类，以学习任务一致的交互空间。

- **阶段推进** ($\mathcal{L}_{\text{phase}}$)：一种损失，确保 p_τ 捕获任务执行的单调推进。

D. 第二部分：双时间尺度因果记忆

Zeva 将交互单元 (p_τ, e_τ) 组织为两条记忆流，以支持当前回合内及跨尝试的自适应。a) 简要交互迹： $\mathcal{H}_\tau^{\text{brief}}$ 存储最近交互信号 $\{e_j\}_{j=\tau-K}^\tau$ 的滑动窗口。这为策略提供了关于当前动作有效性的即时局部上下文。

$$\mathcal{H}_\tau^{\text{brief}} = \{e_j\}_{j=\tau-K_{\text{brief}}}^\tau \quad (4)$$

该迹在每次尝试结束时重置。

b) 持久交互记忆：累积同一回合各尝试间 $\mathcal{H}_\tau^{\text{pim}}$ 的因果单元 $\xi = (p, e)$ ，并在新回合开始前清空。为确保可扩展性，我们采用基于相似度的合并。对于新单元

$\xi_\tau = (p_\tau, e_\tau)$ ，we find the most similar entry $\xi^* \in \mathcal{H}_\tau^{\text{pim}}$ by calculating:

$$S_{\text{merge}}(\xi_\tau, \xi_j) = \beta_p \text{sim}(p_\tau, p_j) + \beta_e \text{sim}(e_\tau, e_j) \quad (5)$$

持久记忆随后按如下方式更新：

$$\mathcal{H}_\tau^{\text{pim}} \leftarrow \begin{cases} (\mathcal{H}_{\tau-1}^{\text{pim}} \setminus \{\xi^*\}) \cup \{\text{Merge}(\xi^*, \xi_\tau)\} & \text{if } S_{\text{merge}}(\xi_\tau, \xi^*) > \tau_{\text{merge}}, \\ \mathcal{H}_{\tau-1}^{\text{pim}} \cup \{\xi_\tau\}, & \text{otherwise} \end{cases} \quad (6)$$

这确保新经验仅在同时匹配现有经验的任务进展与物理动态时才被合并。record.

E. 第三部分：上下文内策略注入

最终阶段将存储的经验转化为面向基础模型的结构化因果提示。a) 阶段条件检索：我们使用当前阶段 p_τ 查询持久记忆中最相关的交互证据。检索到的集合 $\mathcal{R}_\tau$ 由关联阶段与当前进展匹配的信号组成：

$$\mathcal{R}_\tau = \{e_k \mid (p_k, e_k) \in \mathcal{H}_\tau^{\text{pim}}, \text{top-}K \text{ sim}(p_\tau, p_k)\} \quad (7)$$

b) 因果提示构建：记忆上下文 $\mathcal{M}_\tau$ 通过将任务令牌 g 和当前阶段令牌 p_τ 与短期和长期记忆整合而构建。

Algorithm 1 In-Context Causal Inference with Zeva

Input: Task instruction g , environment $\mathcal{E}$, maximum attempts R , episode horizon T , retrieval size K , and brief-memory window K_b

Input: Frozen Causal Transition Encoder (CTE), Memory Context Encoder F_{mem} , and foundation policy π

Output: Task outcome and updated persistent interaction memory $\mathcal{H}^{\text{pim}}$

```
1: Freeze all neural parameters  $\theta$ 
2:  $\mathcal{H}^{\text{pim}} \leftarrow \emptyset$  ▷ Global schema retained across attempts
3: for  $r = 1, \dots, R$  do
4:    $o_0 \leftarrow \text{RESET}(\mathcal{E})$ 
5:    $\mathcal{H}^{\text{brief}} \leftarrow \emptyset$  ▷ Local context reset per attempt
6:    $B_0 \leftarrow F_{\text{init}}(g, s_0)$  ▷ Initialize causal interaction state
7:    $p_0 \leftarrow P_{\text{phase}}(B_0)$  ▷ Initial phase token
8:   for  $t = 0, \dots, T - 1$  do
9:      $\mathcal{R}_t \leftarrow \text{PHASERETRIEVAL}(p_t, \mathcal{H}^{\text{pim}}, K)$  ▷ Retrieve relevant interaction evidence
10:     $\mathcal{M}_t \leftarrow F_{\text{mem}}(g, p_t, \mathcal{H}^{\text{brief}}, \mathcal{R}_t)$  ▷ Construct Causal Prompt
11:     $a_t \sim \pi(\cdot | o_t, g, \mathcal{M}_t)$  ▷ Implicit causal inference and action generation
12:     $(o_{t+1}, \text{terminal}) \leftarrow \text{STEP}(\mathcal{E}, a_t)$ 
13:     $B_{t+1} \leftarrow \text{GRU}(B_t, [s_{t+1}; a_t; \Delta s_t])$  ▷ Update interaction state via CTE
14:     $p_{t+1} \leftarrow P_{\text{phase}}(B_{t+1}), e_{t+1} \leftarrow P_{\text{signal}}(B_{t+1})$ 
15:     $\mathcal{H}^{\text{brief}} \leftarrow \text{UPDATEBRIEF}(\mathcal{H}^{\text{brief}}, e_{t+1}, K_b)$  ▷ Update sliding window
16:     $\mathcal{H}^{\text{pim}} \leftarrow \text{CAUSALMERGE}(\mathcal{H}^{\text{pim}}, p_{t+1}, e_{t+1})$ 
17:    if terminal then
18:      break
19:    end if
20:  end for
21:  if  $\text{SUCCESS}(\mathcal{E})$  then
22:    return ( $\text{SUCCESS}, r, \mathcal{H}^{\text{pim}}$ )
23:  end if
24: end for
25: return ( $\text{FAILURE}, R, \mathcal{H}^{\text{pim}}$ )
```

交互历史。具体而言，记忆上下文编码器 F_{mem} 在通过共享投影器 P_{proj} 投影历史流后融合这些组件：

$$\mathcal{M}_\tau = F_{\text{mem}}([g; p_\tau; P_{\text{proj}}(\mathcal{H}_\tau^{\text{brief}}); P_{\text{proj}}(\mathcal{R}_\tau)]) \quad (8)$$

在此公式中， g 和 p_τ 提供任务与阶段锚定，而 $P_{\text{proj}}(\mathcal{H}_\tau^{\text{brief}})$ 和 $P_{\text{proj}}(\mathcal{R}_\tau)$ 提供来自当前及先前尝试的因果反馈。通过注入 $\mathcal{M}_\tau$ 作为因果提示，冻结的基础模型执行隐式因果推断。它根据先前交互的成功或失败调整其动作 $\pi(a_\tau | o_\tau, \mathcal{M}_\tau)$ ，以最大化任务成功率。

F. 推理

在部署期间，所有参数保持冻结。智能体在线更新其因果记忆，基础模型将不断演化的 $\mathcal{M}_\tau$ 视为决策的动态上下文。完整的上下文内因果推断过程总结于算法 1。

IV. 实验

我们在 RoboCasa365-Atomic5 仿真基准和真实世界 ChemLab-Evo 基准上评估 Zeva。我们的实验旨在回答三个关键问题：(1)

基准性能： Zeva 能否实现具有竞争力的任务

在模拟与真实世界操作任务中，随着复杂度增加，能否实现成功与长时程进展？(2) 部署上下文扩展：

部署上下文扩展： 能否在不更新参数的情况下，通过累积交互经验和一次性人类演示，在重复尝试中改进冻结策略？(3) 因果记忆与跨任务泛化：

因果记忆与跨任务泛化： CTE、BIT 和 PIM 是否编码了有用的动作诱导交互信号，从而有助于性能提升，并支持有意义的跨任务检索与迁移？

A. 实验设置

1) 回合与尝试协议：本文采用两种评估单元：回合与尝试。回合对应于由初始化定义的单个任务实例，包括场景布局、物体位姿以及机器人起始构型。随机回合在回合开始时独立采样该初始化。固定回合仅选择一次初始化，并在重复尝试中保持不变。尝试是从初始观测到终止或成功的一次连续策略执行。在固定回合中每次新尝试之前，环境会恢复到相同的初始状态。简要交互迹（Brief Interaction Trace, BIT）在每次尝试开始时清除，而持久交互记忆（Persistent Interaction Memory, PIM）在同一回合内的多次尝试之间保留。两种记忆在下一回合开始前均被清除。回合在首次成功尝试后立即终止，所有比较方法获得相同的最大重试预算。2) 仿真基准：本文在 RoboCasa365 的五个代表性任务上评估 Zeva，涵盖多样化的厨房操作技能，如关节物体交互、物体放置和电器操作。本文将这一五任务评估子集称为 **RoboCasa365-Atomic5 (Atomic5)**。每个任务在 50 个独立随机回合上进行评估。3) 真实世界化学实验室（**ChemLab-Evo**）：为评估 Zeva 能否在部署后通过累积交互经验提升其操作能力，本文构建了 **ChemLab-Evo**，一个使用 ARX 机械臂在 $80\text{ cm} \times 60\text{ cm}$ 工作空间中的真实世界化学实验室基准。**ChemLab-Evo** 包含七个任务，跨越三个递增组合复杂度的层级。第一级（原子级）通过拿起试管、放置烧杯和倒水评估单个操作原语。第二级（短序列）通过滴定和配制盐溶液引入短技能组合。第三级（复杂级）通过天平称量和萃取评估长时程、多阶段流程。随着复杂度增加，成功执行从完成单个目标原语转变为按指定顺序完成所有组成阶段。这种分层评估使本文不仅能考察任务级性能，还能考察随着任务复杂度增加，累积交互经验是否提升执行可靠性。主基准及每个消融配置

表 I 在 CHEMLAB-EVO 上的真实世界评估。左栏报告 20 个随机回合的成功率 (SR, %)，并给出每个难度级别的宏平均。右栏报告两个长程任务中按顺序完成的任务阶段平均百分比。最佳过程分数以粗体显示。

Method	Success Rate (SR, %)										Process Score (%)		
	Level 1 (Atomic)				Level 2 (Short-sequence)				Level 3 (Complex)		Long-horizon		
	Pick Up Test Tube	Place Beaker	Pour Water	Avg. (%)	Titration	Prepare Solution	Salt Avg. (%)		Balance Weighing	Extraction Avg.	Balance Weighing	Extraction Avg.	
LingBot-VA [8]	80	70	65	71.7	55	75	65.0		5	0	2.5	28.75	34.38
Fast-WAM [34]	85	70	75	76.7	45	55	50.0		0	0	0.0	22.50	40.54
$\pi_{0.5}$ [14]	95	60	65	73.3	60	50	55.0		0	0	0.0	33.75	32.59
Cosmos3-Nano [18]	80	70	60	70.0	45	60	52.5		0	0	0.0	38.75	44.73
Zeva	100	70	80	83.3	70	70	70.0		5	10	7.5	47.50	57.32

表 II 在 ROBOCASA365-ATOMIC5 (ATOMIC5) 基准 [35] 上的结果。我们报告 50 个随机回合的任务成功率 (SR) 及宏平均。最佳结果以粗体显示。

Method	TurnOn ElectricKettle	CloseToaster OvenDoor	TurnOn Microwave	CoffeeSetup Mug	OpenStand MixerHead	Avg.
LingBot-VA [8]	63	60	70	35	48	55.2
Xiaomi-Robotics-1 [36]	17	16	82	6	35	31.2
π_0 -WM [37]	15	32	63	12	23	29.0
Fast-WAM [34]	88	66	60	54	94	72.4
Cosmos3-Nano [18]	76	74	76	6	92	64.8
Zeva	78	86	84	44	92	76.8

评估使用每个任务 20 个独立随机回合。

4) 对比基线：在 Atomic5 上，我们将 Zeva 与 LingBot-VA [8]、Xiaomi-Robotics-1 [36]、 π_0 -WM [37]、Fast-WAM [34] 和 Cosmos3-Nano [18] 进行比较。对于 ChemLab-Evo，我们额外加入 $\pi_{0.5}$ [14]。所有基线均使用与 Zeva 相同的任务特定训练数据集、观测和动作接口以及评估协议在本地复现。

B. 评估指标

基准指标。 对于仿真和 ChemLab-Evo，我们报告任务级成功率 (SR) 以及所有评估任务的宏平均 SR。每个 SR 在仿真任务中基于 50 个随机回合计算，在真实世界任务中基于 20 个随机回合计算。由于二元成功对长程任务的分辨率有限，我们额外报告归一化过程分数。对于具有 M_t 个有序阶段的任务，令 L_i 为回合 i 中按指定顺序完成的最长阶段前缀的长度。任务级分数为

$$\text{Score}_t = \frac{100}{N} \sum_{i=1}^N \frac{L_i}{M_t},$$

其中 ChemLab-Evo 的 $N = 20$ 。仅当所有阶段均完成时，回合才获得 100 分；失败的回合仍保留终止前有效进展的得分。

部署后扩展度量。 为量化能力随累积交互经验扩展的规律，令 $y_{i,k} \in \{0, 1\}$ 表示固定回合 i 在第 k 次尝试时的结果。本文报告累积成功率 (CSR@ K)，即在尝试预算内完成的固定回合比例)

K :

$$CSR@K = \frac{1}{N} \sum_{i=1}^N \mathbb{I} \left[\max_{1 \leq k \leq K} y_{i,k} = 1 \right].$$

C. 实验结果

1) 在 ChemLab-Evo 上的真实世界评估：本文进一步在真实世界 ChemLab-Evo 基准上使用 ARX 机械臂评估 Zeva。表 I 的成功率 (SR) 部分按任务复杂度组织，从原子操作原语到多阶段化学流程。Zeva 在每个复杂度级别均取得最佳平均成功率。相对于各层级最强基线，其在原子、短序列和复杂任务上的平均成功率分别提升 6.6、5.0 和 5.0 个百分点。由于仅看最终成功会掩盖两个长时程任务上的部分进展，右侧的过程得分部分进一步比较了它们的有序阶段完成情况。Zeva 在称量平衡任务上得分为 47.50，在萃取任务上得分为 67.14，分别超过各任务最强基线 8.75 和 8.57 分。

其平均得分 57.32 比最佳基线平均值高出 12.59 分。

2) 仿真基准结果：如表 II 所示，Zeva 取得最高平均成功率 76.8%，超过 Fast-WAM 4.4 个百分点。

D. 消融研究

本文在五个真实世界 ChemLab-Evo 任务上消融两种交互记忆时间尺度：全部三个原子任务和两个短序列任务。表 III 比较完整模型与移除短暂交互迹 (BIT)、移除持久交互记忆 (PIM) 或同时移除两者的变体。本文将这些组件分别记为 BIT 和 PIM，并报告每种配置在 20 个随机回合上的任务级成功率。

完整模型在全部五项任务上均取得最佳表现。移除程序性交互记忆（PIM）导致成功率下降 10 至 20 个百分点，而移除行为内交互 Transformer（BIT）则造成更大幅度的下降，达 15 至 30 个百分点，其中在倒水与滴定任务上降幅最大。这些对照结果支持了跨尝试记忆与尝试内上下文之间的互补作用。同时禁用两个组件则在每项任务上均产生最差结果。

表 III BIT 与 PIM 在五项 ChemLab-Evo 任务上的真实世界消融实验。勾选标记表示启用的组件。表中数据为 20 个随机回合上的任务级成功率（%）；最佳结果以粗体显示。

Method	Pick Up Test Tube	Place Beaker	Pour Water	Titr.	Salt Solution
BIT PIM					
✓ ✓	100	70	80	70	70
✓	80	50	50	40	55
✓	85	60	70	60	50
✓	65	40	45	25	35

E. 部署后上下文扩展

1) 部署后能力扩展：本文进一步考察泽瓦（Zeva）在重复尝试中积累交互经验时，其任务完成概率是否随之提升。该分析基于与主基准表所用随机回合分开选取的固定回合。对于 Atomic5，扩展子集包含每项任务 20 个固定回合，共产生 100 个等权重的任务-配置对；该子集不同于上述标准评估，后者在更广泛的初始配置集合上对每项任务使用 50 个随机回合。图 3 报告了演化轨迹上的四个里程碑，记为演化 1 至 4。这些标签表示选定的演化阶段，而非连续的尝试次数。汇总的累积成功率从演化 1 的 26% 上升至演化 2 的 45%，在演化 3 达到 70%，并在演化 4 稳定在 73%。




图 3. RoboCasa365 上的部署后能力扩展。五项任务各贡献 20 个随机回合，共产生 100 个等权重的任务-种子对。演化 1 至 4 表示选定的演化里程碑。

在 ChemLab-Evo 上，图 4 同样使用单独选取的固定回合，并报告三项原子任务的四个演化里程碑。所绘制的固定回合独立于

表 I 中的随机回合。在这些里程碑中，累积成功率单调递增：拾取试管从 65% 升至 100%，放置烧杯从 25% 升至 70%，倒水从 30% 升至 80%。




图 4. 使用单独选取的固定回合，在三项 ChemLab-Evo 任务上的部署后能力扩展。演化 1 至 4 表示选定的演化里程碑。

2) 基于人类演示的一次性预热：我们进一步在平衡称重任务上开展了一次性记忆预热案例研究。人类物理引导 ARX 机械臂一次，拾取校准砝码并将其放置在平衡秤上；CTE 对此产生的动作-状态变化轨迹进行编码，以初始化 PIM，而策略保持冻结。我们将由此产生的 Zeva 执行与使用相同冻结策略但未进行记忆预热的基线进行比较。如图 5 所示，Zeva 复现了演示的接近、抓取、转移和放置阶段。其末端执行器轨迹到达抓取和放置事件，而基线在接近校准砝码后发生偏离，未能完成有效放置。该案例表明，单次人类经验可以通过记忆接口在无需梯度更新的情况下为 Zeva 提供预热启动，随后再进行自主交互。我们进一步在三个原子 ChemLab-Evo 任务上量化了这种预热效果。对于每个评估的固定回合，预热条件在自主自进化之前提供一次与任务匹配的人类演示，而比较条件则在没有这种初始化的情况下进行自进化。如图 6 所示，人类预热在每个进化里程碑上都提高或持平了 SR。在放置烧杯任务上增益达到 20 个百分点，在倒水任务上增益为 15 个百分点；在拾取试管任务上，预热改善了早期里程碑，随后两种条件都收敛到 100%。

F. 因果交互信号的跨任务泛化

1) 跨任务迁移：我们首先测试在策略执行过程中，任务局部因果交互信号是否可以被从其他任务检索到的功能相似信号所替代。对于每次检索，我们将相应的任务局部交互信号替换为其最近的跨任务匹配项，同时保持策略冻结且所有剩余输入不变。如图 7 所示，在拾取试管任务上 SR 从 100% 变为 95%，在倒水任务上保持 80%。

相比之下，将任务局部信号替换为随机




图 5. 平衡称重的一次性人类预热。各行分别显示 (a) 用于初始化 PIM 的人类引导演示, (b) 一次性记忆预热后的 Zeva, 以及 (c) 未进行记忆预热的基线。每行中的帧按从左到右的顺序形成时间线。3D 图比较了相应的末端执行器轨迹; 星号和三角形分别表示抓取和放置事件。




图 6. 三个原子级 ChemLab-Evo 任务上的一次性人类演示预热。每个评估的固定回合在自主自进化前, 与一个任务匹配的人类演示配对。实线表示无预热的自进化, 虚线表示人类预热后的自进化。每个面板使用自己的 y 轴范围, 以保持任务内变化清晰可读。

选定的跨任务交互信号将成功率分别降低至 55% 和 45%。因此, 在这两种设置中, 最近跨任务检索比随机替换高出 40 和 35 个百分点, 同时保留大部分或全部原始任务性能。




图 7. 在 ChemLab-Evo 上使用跨任务因果交互信号进行定量替换。Zeva 使用检索到的任务局部交互信号, Crosstask 用来自另一任务的最近对应信号替换, Random 使用来自同一跨任务池的随机选择的交互信号。冻结策略和所有其他输入保持不变。

2) 跨任务检索: 我们接下来探究 CTE 因果交互信号 e_r 是否捕捉到超越任务特定外观的动作诱导状态变化。对于每个查询转移, 我们通过来自仅包含其他任务的诊断记忆池中交互信号之间的余弦相似度检索最近邻; 此分析不改变用于定量评估的任务局部记忆协议。图 8 展示了三种效应的代表性匹配。来自倒水任务的倾斜转移检索到来自配制盐溶液和萃取任务的容器倾斜转移。围绕试管的夹持器闭合检索到涉及不同容器的接触建立转移, 而提升检索到跨物体类别的抓取后向上运动。因此, 具有不同物体、视角和任务指令的转移通过功能等效的物理效应对齐, 为未来跨任务记忆重用提供了一种机制。

G. 定性与表示分析

1) 逐案例部署后进化: 图 9 通过逐案例证据补充了聚合缩放曲线, 展示了交互记忆如何改变后续重试以及最终成功执行。每行中的四帧




图 8. 在 CTE 因果交互信号的潜空间中进行跨任务检索。每个区块展示从左到右的状态转移。蓝色轮廓表示查询，青色轮廓表示其两个最近的跨任务匹配。各行按物理效应分组，尽管物体、视角和指令发生了变化。

按时间顺序排列，但它们并不代表四次不同的尝试。



图 9. 三个 ChemLab-Evo 任务部署后的时间顺序演变。红色边框是不同失败尝试的最终观察结果。绿色边框显示随后成功的尝试；在 (a) 和 (b) 中，两个绿色边框是同一连续尝试的连续阶段。

拿起试管。在前两次尝试中，夹爪到达了架子，但没有建立稳定的抓取。在随后的成功尝试中，第三帧显示了修正后的抓取，而第四帧显示机器人在同一连续执行过程中带着试管缩回。这一进展与跨尝试使用 PIM 中保留的动作-效应证据一致。

放置烧杯。前两次尝试暴露了手腕方向和目标区域附近放置的错误。最后两帧则展示了一次成功尝试的两个阶段：Zeva 首先固定烧杯，随后将其放置在目标位置。这种修正后的执行说明了由保留的交互证据所支持的跨尝试适应类型。

倒水。该任务额外要求协调运输、边缘对齐和受控旋转。在前三次失败的尝试中，观察到的行为揭示了剩余的相对位姿和倾斜误差。在随后成功的尝试中，泽娃将试管定位在烧杯上方，并执行所需的倾倒动作。这一定性序列

与来自累积交互证据的渐进修正一致。

2) 因果轨迹嵌入表示分析：我们进一步使用 t -分布随机邻域嵌入 (t -SNE) 可视化因果轨迹嵌入 (CTE) 在所有七个化学实验室进化任务中学习到的交互嵌入。图 10 比较了完整的三流表示与移除效果流的变体。完整的 CTE 产生紧凑的、任务特定的簇，具有清晰的分离，而移除效果流则增加了任务内离散度和任务间混合。这一比较与观察到的状态变化有助于任务判别性因果交互记忆一致。




图 10. 七个化学实验室进化任务中 CTE 交互嵌入的 t -SNE 可视化。完整的 CTE 形成紧凑的簇，而移除效果流则增加了离散度和跨任务重叠。

五、结论

泽娃是第一个框架，能够从机器人自身的物理经验中实现交互因果关系的上下文学习，用于可泛化的具身操作，同时保持策略模型冻结。在仿真和现实世界操作中的实验表明，泽娃在前沿视觉语言动作模型和世界动作模型中取得了最佳性能。此外，随着交互经验的积累，其成功率在重复尝试中持续提高。当前的局限性是，泽娃仅从为任务执行生成的尝试中学习因果关系，而不是主动收集交互进行学习。因此，未来的工作将研究因果关系驱动的探索，其中机器人有目的地选择信息丰富的轨迹，以减少物理交互的不确定性并更有效地获取经验。

致谢 我们感谢安攀、王泽旭、陶毅、王子健、吴书豪、顾文辉和杨博文在工程和演示方面的贡献。

参考文献

- [1] M. J. Kim, K. Pertsch, S. Karamcheti, T. Xiao, A. Balakrishna, S. Nair, R. Rafailov, E. Foster, G. Lam, P. Sanketi, Q. Vuong, T. Kollar, B. Burchfiel, R. Tedrake, D. Sadigh, S. Levine, P. Liang, and C. Finn, “OpenVLA: An open-source vision-language-action model,” in *Proc. Conf. Robot Learning (CoRL)*, 2024.
- [2] K. Black, N. Brown, D. Driess, A. Esmail, M. Equi, C. Finn, N. Fusai, L. Groom, K. Hausman, B. Ichter, S. Jakubczak, T. Jones, L. Ke, S. Levine, A. Li-Bell, M. Mothukuri, S. Nair, K. Pertsch, L. X. Shi, J. Tanner, Q. Vuong, A. Walling, H. Wang, and U. Zhilinsky, “ π_0 : A vision-language-action flow model for general robot control,” arXiv preprint arXiv:2410.24164, 2024.
- [3] A. Brohan, N. Brown, J. Carbajal *et al.*, “RT-1: Robotics transformer for real-world control at scale,” arXiv preprint arXiv:2212.06817, 2022.
- [4] A. Brohan, N. Brown, J. Carbajal, Y. Chebotar, X. Chen, K. Choromanski, T. Ding, D. Driess, A. Dubey, C. Finn, P. Florence, C. Fu, M. G. Arenas, K. Gopalakrishnan, K. Han, K. Hausman, A. Herzog, J. Hsu, B. Ichter, A. Irpan, N. Joshi, R. Julian, D. Kalashnikov, Y. Kuang, I. Leal, L. Lee, S. Levine, Y. Lu, H. Michalewski, I. Mordatch, K. Pertsch, K. Rao, K. Reymann, M. Ryoo, G. Salazar, P. Sanketi, P. Sermanet, J. Singh, A. Singh, R. Soricut, H. Tran, V. Vanhoucke, Q. Vuong, A. Wahid, S. Welker, P. Wohlhart, J. Wu, F. Xia, T. Xiao, P. Xu, S. Xu, T. Yu, and B. Zitkovich, “RT-2: Vision-language-action models transfer web knowledge to robotic control,” in *Proc. Conf. Robot Learning (CoRL)*, 2023.
- [5] Octo Model Team, D. Ghosh, H. Walke, K. Pertsch, K. Black, O. Mees, S. Dasari, J. Hejna, C. Finn, and S. Levine, “Octo: An open-source generalist robot policy,” in *Proc. Robotics: Science and Systems (RSS)*, 2024.
- [6] C. Chi, Z. Xu, S. Feng, E. Cousineau, Y. Du, B. Burchfiel, R. Tedrake, and S. Song, “Diffusion policy: Visuomotor policy learning via action diffusion,” in *Proc. Robotics: Science and Systems (RSS)*, 2023.
- [7] M. J. Kim, Y. Gao, T.-Y. Lin, Y.-C. Lin, Y. Ge, G. Lam, P. Liang, S. Song, M.-Y. Liu, C. Finn, and J. Gu, “Cosmos policy: Fine-tuning video models for visuomotor control and planning,” arXiv preprint arXiv:2601.16163, 2026.
- [8] L. Li, Q. Zhang, Y. Luo, S. Yang, R. Wang, F. Han, M. Yu, Z. Gao, N. Xue, X. Zhu, Y. Shen, and Y. Xu, “Causal world modeling for robot control,” arXiv preprint arXiv:2601.21998, 2026.
- [9] C. Ye, Y. Ge, Y. Ge, Y. Shan, and M.-Y. Liu, “World action models are zero-shot policies,” arXiv preprint arXiv:2602.15922, 2026.
- [10] Y. Jiang, Y. Chebotar, R. Zheng, F. Hu, Y. Ge, J. Wu, T. Dai, S. Reed, L. Fei-Fei, Y. Zhu, and L. Fan, “RoboTTT: Context scaling for robot policies,” arXiv preprint arXiv:2607.15275, 2026.
- [11] Y. Feng, B. Han, J. Lyu, K. Liu, Y. Zheng, Y. Wan, W. Liu, S. Han, R. Li, Y. Zhang, F. Liu, X. Shi, L. Liu, Y. Wang, Z. Zhang, and H. Wang, “WAM-TTT: Steering world-action models by watching human play at test time,” arXiv preprint arXiv:2607.06988, 2026.
- [12] Generalist Team, “GEN-1.5: Embodied foundation models are one-shot learners,” Generalist AI Blog, Aug. 2026. [Online]. Available: <https://generalistai.com/blog/gen-1.5>
- [13] Skild AI, “Introducing S1: In-context learning for robotics,” Skild AI Blog, Aug. 2026. [Online]. Available: <https://www.skild.ai/blogs/s1>
- [14] Physical Intelligence, K. Black, N. Brown, J. Darpanian, K. Dhabalia, D. Driess, A. Esmail, M. Equi, C. Finn, N. Fusai, M. Y. Galliker, D. Ghosh, L. Groom, K. Hausman, B. Ichter, S. Jakubczak, T. Jones, L. Ke, D. LeBlanc, S. Levine, A. Li-Bell, M. Mothukuri, S. Nair, K. Pertsch, A. Z. Ren, L. X. Shi, L. Smith, J. T. Springenberg, K. Stachowicz, J. Tanner, Q. Vuong, H. Walke, A. Walling, H. Wang, L. Yu, and U. Zhilinsky, “ $\pi_{0.5}$: a vision-language-action model with open-world generalization,” arXiv preprint arXiv:2504.16054, 2025.
- [15] Physical Intelligence *et al.*, “ $\pi_{0.6}^*$: a VLA that learns from experience,” arXiv preprint arXiv:2511.14759, 2025.
- [16] H. Wu, Y. Jing, C.-L. Cheang, G. Chen, J. Xu, X. Li, M. Liu, H. Li, and T. Kong, “Unleashing large-scale video generative pre-training for visual robot manipulation,” in *Proc. Int. Conf. Learning Representations (ICLR)*, 2024.
- [17] C.-L. Cheang, G. Chen, Y. Jing, T. Kong, H. Li, Y. Li, Y. Liu, H. Wu, J. Xu, Y. Yang, H. Zhang, and M. Zhu, “GR-2: A generative video-language-action model with web-scale knowledge for robot manipulation,” arXiv preprint arXiv:2410.06158, 2024.
- [18] NVIDIA, “Cosmos 3: Omnimodal world models for physical ai,” <https://research.nvidia.com/labs/cosmos-lab/cosmos3/technical-report.pdf>, 2026.
- [19] T. Z. Zhao, V. Kumar, S. Levine, and C. Finn, “Learning fine-grained bimanual manipulation with low-cost hardware,” in *Proc. Robotics: Science and Systems (RSS)*, 2023.
- [20] S. Lee, Y. Wang, H. Etukuru, H. J. Kim, N. M. M. Shafiuallah, and L. Pinto, “Behavior generation with latent actions,” in *Proc. Int. Conf. Machine Learning (ICML)*, 2024.
- [21] K. Pertsch, K. Stachowicz, B. Ichter, D. Driess, S. Nair, Q. Vuong, O. Mees, C. Finn, and S. Levine, “FAST: Efficient action tokenization for vision-language-action models,” arXiv preprint arXiv:2501.09747, 2025.
- [22] S. Belkhal, T. Ding, T. Xiao, P. Sermanet, Q. Vuong, J. Tompson, Y. Chebotar, D. Dwibedi, and D. Sadigh, “RT-H: Action hierarchies using language,” in *Proc. Robotics: Science and Systems (RSS)*, 2024.
- [23] R. Bonatti, S. Vemprala, S. Ma, F. Frueh, S. Chen, and A. Kapoor, “PACT: Perception-action causal transformer for autoregressive robotics pre-training,” arXiv preprint arXiv:2209.11133, 2022.
- [24] Y. Zhou, Q. Liang, S. Zhuang, J. Li, X. Wang, B. Cai, Y. Mo, and R. Xu, “Action-effect memory pretraining for robot manipulation,” arXiv preprint arXiv:2606.12499, 2026.
- [25] Z. Tang, H. Liu, X. Chang, C. Wu, D. Huo, Y. Yang, B. Liu, Z. Cai, F. Xiong, M. Xu, J. Luo, D. Ma, Z. Ma, and G. Pan, “ALAM: Algebraically consistent latent transitions for vision-language-action models,” arXiv preprint arXiv:2605.10819, 2026.
- [26] S. Ye, J. Jang, B. Jeon, S. Joo, J. Yang, B. Peng, A. Mandelkar, R. Tan, Y.-W. Chao, B. Y. Lin, L. Liden, K. Lee, J. Gao, L. Zettlemoyer, D. Fox, and M. Seo, “Latent action pretraining from videos,” in *Proc. Int. Conf. Learning Representations (ICLR)*, 2025.
- [27] B. Hu, Z. Li, R. Shao, J. Chen, A. H. Liu, W.-S. Zheng, and L. Nie, “From abstraction to instantiation: Learning behavioral representation for vision-language-action model,” in *Proc. Int. Conf. Machine Learning (ICML)*, 2026.
- [28] Q. Bu, Y. Yang, J. Cai, S. Gao, G. Ren, M. Yao, P. Luo, and H. Li, “UniVLA: Learning to act anywhere with task-centric latent actions,” arXiv preprint arXiv:2505.06111, 2025.
- [29] H. Shi, B. Xie, Y. Liu, L. Sun, F. Liu, T. Wang, E. Zhou, H. Fan, X. Zhang, and G. Huang, “MemoryVLA: Perceptual-cognitive memory in vision-language-action models for robotic manipulation,” in *Proc. Int. Conf. Learning Representations (ICLR)*, 2026.
- [30] M. Torne, K. Pertsch, H. Walke, K. Vedder, S. Nair, B. Ichter, A. Z. Ren, H. Wang, J. Tang, K. Stachowicz, K. Dhabalia, M. Equi, Q. Vuong, J. T. Springenberg, S. Levine, C. Finn, and D. Driess, “MEM: Multi-scale embodied memory for vision language action models,” arXiv preprint arXiv:2603.03596, 2026.
- [31] K. Wang, Z. Gu, Y. Chen, Y. Xu, Q. Ma, J. Yang, Z. Li, Y. Huang, L. Wang, and P. Su, “DIM-WAM: World-action modeling with diverse historical event memory,” arXiv preprint arXiv:2606.27677, 2026.
- [32] S. Yang, J. Mu, T. Wei, C. Lu, X. Li, L. Xu, Z. Xue, Z. Yuan, D. Lin, J. Pang, and H. Xu, “MemoryWAM: Efficient world action modeling with persistent memory,” arXiv preprint arXiv:2606.20562, 2026.
- [33] G. Lu, W. Guo, C. Zhang, Y. Zhou, H. Jiang, Z. Gao, Y. Tang, and Z. Wang, “VLA-RL: Towards masterful and general robotic manipulation with scalable reinforcement learning,” arXiv preprint arXiv:2505.18719, 2025.
- [34] T. Yuan, Z. Dong, Y. Liu, and H. Zhao, “Fast-WAM: Do world action models need test-time future imagination?” arXiv preprint arXiv:2603.16666, 2026.
- [35] S. Nasiriany, S. Nasiriany, A. Maddukuri, and Y. Zhu, “RoboCasa365: A large-scale simulation framework for training and benchmarking generalist robots,” in *Proc. Int. Conf. Learning Representations (ICLR)*, 2026.
- [36] Xiaomi Robotics Team, J. Guo, P. Jin, J. Li, P. Li, Y. Li, F. Liu, W. Peng, O. Qin, Y. Su, N. Sun, Q. Sun, R. Suo, H. Wang, Y. Wang, R. Wu, C. Xia, L. Zhang, J. Zhao, G. Chen, W. Chen, X. He, B. Li, Q. Li, Z. Li, H. Qu, W. Song, D. Xiang, Y. Xie, P. Xu, H. Ye, W. Ye, H. Zhao, and Q. Zhou, “Xiaomi-Robotics-1: Scaling vision-language-action models with over 100k hours of real-world trajectories,” arXiv preprint arXiv:2607.15330, 2026.

- [37] P. Zhou, S. Chen, D. Chen, J. Wang, R. Jin, B. Zhu, Y. Pan, S. Gu, K. Wang, S. Nan, X. Qiu, C. Qiu, P. Yang, Y. Cai, J. Gao, Y. Li, Y. Fu, X. Yue, Z. Chen, and J. Luo, “ τ_0 -WM: A unified video-action world model for robotic manipulation,” arXiv preprint arXiv:2606.01027, 2026.